

FCM-YOLO: 一种基于特征增强和多尺度融合的 PCB缺陷检测方法

严舒^{1,2}, 郭颖^{1,2†}, 黄骏^{1,2}

(1. 南京信息工程大学 江苏省大气环境与装备技术协同创新中心, 南京 210044;
2. 南京信息工程大学 自动化学院, 南京 210044)

摘要: 针对PCB缺陷检测任务中存在的目标与背景相混淆、缺陷目标较小不易识别等问题,提出一种基于特征增强和多尺度融合的PCB缺陷检测方法FCM-YOLO. 所提出方法以YOLOv5s为基础,首先在特征提取网络中引入由空间到深度层和非跨步卷积层的组合,构建特征重提取模块,以减少信息丢失,保留小目标特征信息;然后,在特征提取网络的最深层引入上下文注意力模块,通过学习上下文信息,使用可变形卷积提取小目标特征,以此增强对目标与背景的区分能力,从而减少漏检情况;最后,在特征融合网络中引入多尺度感受野增强模块,通过多分支结构加强特征信息间的相关性,增强特征的语义表示. 在PCB缺陷数据集和GC10-DET数据集上对不同算法进行对比实验,实验结果表明,FCM-YOLO能够更加精确地识别缺陷目标,相比改进前的YOLOv5s算法,所提出算法在这两个数据集上的检测精度分别提高4.7%和3.7%.

关键词: 机器视觉; 缺陷检测; 印刷电路板; YOLOv5; 上下文信息; 特征增强

中图分类号: TP391.41; TN41

文献标志码: A

DOI: 10.13195/j.kzyjc.2023.1753

引用格式: 严舒,郭颖,黄骏. FCM-YOLO: 一种基于特征增强和多尺度融合的PCB缺陷检测方法[J]. 控制与决策, 2024, 39(10): 3181-3189.

FCM-YOLO: A PCB defect detection method based on feature enhancement and multi-scale fusion

YAN Shu^{1,2}, GUO Ying^{1,2†}, HUANG Jun^{1,2}

(1. Jiangsu Collaborative Innovation Center of Atmospheric Environment and Equipment Technology (CICAEET), Nanjing University of Information Science & Technology, Nanjing 210044, China; 2. Institute of Automation, Nanjing University of Information Science & Technology, Nanjing 210044, China)

Abstract: In response to the challenges in PCB (printed circuit board) defect detection tasks, such as confusion between targets and backgrounds and difficulty in identifying small defective targets, a PCB defect detection method using feature context enhancement and multi-scale fusion YOLO (FCM-YOLO) is proposed. Firstly, based on the YOLOv5s, the method introduces a feature re-extraction module in the feature extraction network, incorporating a combination of spatial-to-depth layers and non-stride convolution layers to reduce information loss and retain features of small targets. Then, a context self attention module is introduced at the deepest layer of the feature extraction network, leveraging deformable convolution to extract features of small targets by learning contextual information, thereby enhancing the discriminative ability between targets and backgrounds and reducing false negatives. Finally, a multi-scale receptive field enhancement block is introduced in the feature fusion network, strengthening the correlation between feature information through a multi-branch structure and enhancing the semantic representation of features. Experimental results comparisons on PCB defect datasets and GC10-DET dataset demonstrate the FCM-YOLO can more accurately identify defective targets. In comparison with the improved YOLOv5s algorithm, the proposed method achieves a detection accuracy improvement of 4.7% and 3.7% on these two datasets, respectively.

Keywords: machine vision; defect detection; PCB; YOLOv5; context information; feature enhancement

收稿日期: 2023-12-17; 录用日期: 2024-03-11.

基金项目: 国家自然科学基金项目(61971229).

责任编辑: 阳春华.

[†]通讯作者. E-mail: yguo@nuist.edu.cn.

0 引言

随着电子工业的发展,电子工业在现代制造业中占有重要的地位,印刷电路板(printed circuit board, PCB)是一种重要的电子元器件,为设备提供线路连接和硬件支持.然而,PCB通常由玻璃纤维、复合环氧树脂和层压材料组成,其制造过程非常复杂,且易出错,造成PCB表面有缺陷存在^[1].因此,为了保证电子产品的安全可靠,在出厂前对PCB进行表面缺陷检测是十分必要的^[2].

传统的人工检测极易受到外界因素的干扰,影响检测的质量和效率^[3],具有不确定性^[4].后期由于电子设备的发展,研究人员使用电气检测^[5]代替人工检测,但是由于需要制作相应的检测工具,成本高,制作困难,不适合广泛运用.目前,深度学习快速发展,研究人员将其应用于缺陷类目标检测的任务^[6]取得了重大进展.

现有的深度学习目标检测算法主要有两类:一类是以R-CNN^[7]系列为代表的二阶段算法,该类算法在第1阶段利用区域建议网络生成大量的锚框,第2阶段在这些锚框的基础上进行目标的分类和回归操作.如Niu等^[8]提出了一种基于Faster RCNN改进的PCB缺陷检测算法,将普通卷积替换为深度可分离卷积,以减少计算量,改进特征金字塔进行多层深度提取特征,实现底层几何细节信息与语义的有效结合;Zeng等^[9]提出了一种基于非对称平衡特征金字塔网络的增强型多尺度特征融合算法,利用空洞卷积获取充分的上下文信息,实现有效的PCB缺陷检测;Zhang等^[10]提出了成本敏感的残差卷积神经网络,有效平衡了PCB检测中样品不平衡和真假缺陷的不同误分类成本.另一类是以YOLO(you only look once)^[11]系列和SSD(single shot MultiBox detector)^[12]为代表的一阶段算法,该类算法直接使用卷积神经网络提取目标特征,对目标做出分类和回归.如Tang等^[13]在YOLOv4的基础上设计了双域注意力机制,采用多样化的激活函数,并改进跨级特征融合,以此有效检测PCB的微小缺陷;Tang等^[14]在YOLOv5的基础上加入了小目标检测层,使得整体模型更加关注小目标,在主干网络中加入变压器,减少了前景与背景间的相互干扰,提高了网络分析能力;周彦等^[15]基于YOLOv5算法提出了多尺度轻量化注意力的钢材表面缺陷检测方法,引入了轻型通道注意力模块,有效关注重要通道,且利用空洞卷积扩大感受野,提取有用信息,改善了检测效果.

本文面向PCB缺陷检测任务,提出一种基于YOLOv5s改进的PCB缺陷检测方法(FCM-YOLO).针对缺陷目标较小,特征提取不充分且易丢失的问

题,提出一种基于SPDConv^[16]的特征重提取模块(feature re-extraction module, FRM),尽可能提取充分的特征.针对PCB板背景复杂,表面缺陷与背景相似易混淆的问题,设计上下文注意力模块(context self attention module, CSAM),旨在减弱背景对缺陷检测的不利影响,从而有效缓解漏检问题.针对缺陷目标在特征融合的过程中语义信息丢失严重的问题,设计多尺度感受野增强模块(multi-scale receptive field enhancement block, MREB),促进多层次多尺度的特征进行信息融合,以便模型充分理解和区分不同类型的缺陷.实验结果表明,改进后的模型在缺陷类检测数据集上能够取得明显提升.

1 本文方法

所提出FCM-YOLO算法整体结构如图1所示.首先,该模型使用特征重提取模块(FRM)堆叠搭建主干网络,对输入图像进行特征重提取,获得丰富的信息.然后,在主干网络的最深层采用上下文注意力模块(CSAM),捕获顶级特征的全局长期依赖性,强化模型对图像中缺陷目标的理解能力,弱化背景对检测的干扰.在颈部网络中,引入SPDConv,减少语义信息的丢失,促进特征融合.为进一步加强缺陷目标的特征表示,优化检测结果,引入多尺度感受野增强模块(MREB),构建特征信息间不同尺度不同范围的依赖关系,显著提高特征信息的完整度.最后,使用YOLO检测头对获得的特征进行检测,以提升模型的检测性能.

1.1 特征重提取模块

卷积神经网络在提取特征信息的过程中,由于跨步卷积和池化层的存在,常常导致许多细粒度信息在提取特征的过程中丢失,得到学习率较低的特征,卷积神经网络的性能也随之急剧下降^[17].YOLOv5选用CSPDarkNet 53、SPPF作为主干网络, PANet作为颈部网络,其中存在步长为2的卷积,会导致信息的非歧视性丢失.因此,本文为了加强模型的特征提取能力,重点强调缺陷目标的显著特征,提出基于SPDConv的特征重提取模块,对特征图中的像素信息进行双重提取,尽可能保留所有的判别特征信息,进一步强化目标的特征表示.图2(a)为特征重提取模块结构.

首先,采用SPDConv对输入特征图进行特征提取,获得丰富的细粒度信息,SPDConv结构如图2(b)所示.SPDCConv能够将隔点采样后的空间信息转换为通道信息,达到下采样的目的,同时优化模型的特




图1 网络模型整体结构




图2 特征重提取模块

征提取能力. 然后, 将经过深度可分离卷积和普通卷积的特征图进行拼接, 得到初始增强特征, 将其送入瓶颈块, 促使更有效的信息传递. 为了进一步提取更抽象的特征, 使用最大池化强调局部信息, 与瓶颈块的输出进行逐元素相加, 得到重提取的特征信息. 最后, 将初始增强特征作为补充信息, 与重提取特征按照逐元素相加的方式进行特征融合, 保证了更为完整的特征信息.

1.2 上下文注意力模块

输入特征图在经主干网络提取特征后, 为整体模型提供了更加丰富的细粒度信息, 然而, 这只能得到有限的上下文信息^[18], 待检测的有效信息所占比例较小, 背景和未检测对象信息所占比例较大, 这对于与背景易混淆的缺陷小目标检测是非常不利的^[19]. 为了捕获全局的长距离依赖关系, 实现全面且具有差异性的特征表示, 区分小目标与背景, 本文提出了上

下文注意力模块,整体结构如图3所示。




图3 上下文注意力模块

上下文注意力模块主要分为两个部分:基于可变形卷积^[20]注意力模块AM和基于深度可分离卷积^[21]模块DM。在AM中:首先,将输入的特征图进行组归一化处理;然后,进入可变形卷积注意力模块(DCA),经 1×1 卷积和GELU激活函数对特征图做出初步处理后,通过两个连续的 3×3 和 5×5 可变形卷积,其原理如图3(c)所示,根据输入图片中目标的特征,扭曲标准采样网络,使得卷积核尽量贴合小目标进行特征提取,实现注意力在感受野中灵活运行;接着,加入残差连接,进行逐元素相乘,调整通道数与输入模块的特征图进行逐元素相加;最后,加入DropPath正则化操作,使得特征的泛化性和鲁棒性得到增强。在DM中:主要是采用深度可分离卷积加强特征表示,且其与传统卷积相比,深度可分离卷积属于轻量化操作,减少了计算成本。然后在AM和DM外部加入残差连接,并在整体上下文注意力模块中加入残差连接,丰富像素信息间的联系,增强复杂背景下的抗干扰能力和缺陷目标发现能力。上述过程可表示为

$$X' = \text{DCA}(\text{GN}(X_{\text{input}})) + X_{\text{input}}, \quad (1)$$

$$X_{\text{output}} = \text{GELU}(\text{DWConv}(\text{GN}(X'))) + X' + X_{\text{input}}. \quad (2)$$

其中: X_{input} 为上下文注意力模块的输入; X_{output} 为上下文注意力模块的输出; X' 为AM的输出,同时是DM的输入;GN表示组归一化;DWConv表示卷积核为 3×3 的深度可分离卷积。

1.3 多尺度感受野增强模块

小目标随着网络深度的增加易丢失,特征混乱,语义信息冲突,不同尺度间语义信息相关性较弱,融合后的特征无法丰富特征信息,不利于小目标检测^[22]。为了增强多尺度信息间的鲁棒性,扩大感受野,从不同感受野上捕捉更为广泛的特征信息,本文提出了多尺度感受野增强模块,整体结构如图4所示。




图4 多尺度感受野增强模块结构

首先对输入特征图做切片操作,得到4张通道维度相同的子图;然后进入将普通卷积与空洞卷积混合的多分支卷积层,普通卷积后加空洞卷积的设计是为了能够扩大感受野的同时获取更高分辨率的特征,其中3个分支的空洞卷积空洞率分别为3、3和5。使用 1×3 和 3×1 的普通卷积代替 3×3 卷积,目的是能够减少计算量,进一步降低模型潜在过拟合的风险,得到非线性结构更好的网络。此外,通过残差连接将不同分支联系起来,充分利用每个子图,实现多分支特征信息的共享,学习具有表现力的多尺度特征表示。为了优化输出结果,加入瓶颈层,与多分支的输出特征图进行逐元素相加,获取目标边缘细节信息,强调特征,弱化背景区域,从而提高小目标检测的准确率。

1.4 损失函数改进

在目标检测中,常使用IoU度量边界框间的相似性,但是局限于边界框的重叠度,若边界框间不存在重叠区域,则IoU对位置偏差的敏感性非常强,这严重影响了目标的检测性能。尤其是对于小目标检测,小目标的位置偏差对于IoU度量有极大的影响,导致

最终标签分配时易产生矛盾,不利于检测. 鉴于此,本文采用NWD(normalized wasserstein distance)^[23]代替IoU来评价边界框的相似性,以提高检测性能.

NWD首先进行边界框的高斯分布建模,在边界框中,背景常常有较大的占比,为了更好地区分目标与背景在边界框中的占比,选择将边界框进行二维高斯分布建模,在边界框的中心,即前景像素,占比最高,像素在边界框中所占的比重由中心向外递减. 对于边界框 $R=(cx, cy, w, h)$. 其中: (cx, cy) 为边界框的中心坐标, w 为边界框的宽度, h 为边界框的高度. 使用二维高斯分布的概率密度函数为

$$f(x|\mu, \Sigma) = \frac{\exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right)}{2\pi|\Sigma|^{\frac{1}{2}}}. \quad (3)$$

这里: x 为坐标, μ 为均值, Σ 为方差.

将边界框 R 建模为二维高斯分布 $N(\mu, \Sigma)$,有

$$\mu = \begin{bmatrix} cx \\ cy \end{bmatrix}, \Sigma = \begin{bmatrix} w^2/4 & 0 \\ 0 & h^2/4 \end{bmatrix}. \quad (4)$$

然后使用Wasserstein Distance度量高斯分布的相似性,对两个边界框 $A=(cx_a, cy_a, w_a, h_a)$, $B=(cx_b, cy_b, w_b, h_b)$ 进行建模,其高斯分布分别为 N_a 和 N_b ,则它们的Wasserstein Distance为

$$W_2^2(N_a, N_b) = \left\| \begin{bmatrix} cx_a, cy_a, \frac{w_a}{2}, \frac{h_a}{2} \end{bmatrix}^T, \begin{bmatrix} cx_b, cy_b, \frac{w_b}{2}, \frac{h_b}{2} \end{bmatrix}^T \right\|_2^2. \quad (5)$$

由于需要取代IoU作为相似性度量,对Wasserstein Distance进行归一化操作,得到NWD,即

$$NWD(N_a, N_b) = \exp\left(-\frac{\sqrt{W_2^2(N_a, N_b)}}{C}\right), \quad (6)$$

其中 C 为与数据集相关的常数.

2 实验结果与分析

2.1 数据集

本文所采用的数据集为北京大学智能机器人开放实验室公开的PCB缺陷数据集^[24],共有6种PCB缺陷: 缺孔(missing_hole)、鼠咬(mouse_bite)、开路(open_circuit)、短路(short)、毛刺(spur)以及杂铜(spurious_copper),共693张图像. 由于样本较少,通过调整亮度、cutout、随机旋转、裁剪、镜像等操作扩充数据集,扩充后有4158张图像,按照8:1:1的比例划分训练集、验证集和测试集. 此外,本文还选择了GC10-DET数据集^[25]验证所提出算法在缺陷类目标检测任务上的有效性.

2.2 实验配置与评价指标

本文实验使用NVIDIA RTX 3080 Ti显卡,在Ubuntu 16.04的Linux系统下,实验环境为

CUDA 10.2、Python 3.8、Pytorch 1.7.0,使用Pytorch深度学习框架搭建、训练以及测试模型,将图像输入尺寸调整为 800×800 像素,设置学习率初始值为0.01, batchsize为16,训练epoch为300,采用SGD优化模型训练. 实验衡量指标为数据集中各类目标的平均精度AP、所有目标平均精度均值mAP、每秒帧数FPS和召回率Recall.

2.3 消融实验

可变形卷积核的大小对特征提取效果有极大的影响,为了验证上下文注意力模块中可变形卷积对缺陷目标特征提取的有效性,设计一组消融实验. 对图3(b)中的可变形卷积核 k_1 、 k_2 设置3组不同大小的可变形卷积核,在PCB数据集上进行实验,实验结果如表1所示. 本文数据集中的缺陷目标较小,因此, 3×3 和 5×5 可变形卷积组合更有利于所提出模型的检测,与另外两组相比,在精度和速度上达到最佳. 此外,对上下文注意力模块中的整体残差结构进行验证,了解添加卷积能否提升模型性能. 如图3(a)所示: 在shortcut上分别加入 1×1 ($k_3=1$)和 3×3 ($k_3=3$)卷积. 实验结果表明:添加卷积结构能够使得模型性能有小幅度的提升,但是效果不如简单的直连. 3×3 和 5×5 可变形卷积组合和整体残差结构中的直连结构能够使得CSAM获得最高检测精度95.6%.

表1 上下文注意力模块和多尺度感受野增强模块的消融实验

	method	mAP/%	FPS
	baseline	93.6	74.63
CSAM	$k_1=3, k_2=5$	95.1	41.92
	$k_1=5, k_2=7$	95.0	40.95
	$k_1=7, k_2=9$	94.8	40.32
	$k_1=3, k_2=5, k_3=1$	95.2	41.59
	$k_1=3, k_2=5, k_3=3$	95.5	40.63
	$k_1=3, k_2=5, \text{shortcut}$	95.6	41.84
MREB	$d_1=1, d_2=3, d_3=5$	94.0	67.12
	$d_1=3, d_2=3, d_3=5$	94.3	65.89
	$d_1=3, d_2=5, d_3=7$	94.3	60.73
	$d_1=3, d_2=3, d_3=5, \text{cascade}$	94.9	54.64

为了了解多尺度感受野增强模块的结构设计如何有助于提升整体模型性能,首先针对分支上的不同空洞率组合进行训练,然后对该模块的分支是否需要信息共享进行训练. 对图4中空洞卷积的 d_1 、 d_2 、 d_3 设置3组不同大小的空洞率,实验结果如表1所示. 采用空洞率组合为(3,3,5)和(3,5,7)时,获得检测精度为94.3%,但是综合而言组合(3,3,5)能够在精度和速度上实现最佳性能. 在分支选取空洞率组合(3,3,5)的基础上,通过级联的方式为多分支添加信息共享,前一支处理完特征信息后,与后一支的输入进行融

合,获得检测精度为94.9%.实验结果表明,使用空洞率组合(3,3,5)与分支间信息共享,多尺度感受野增强模块对改进模型性能贡献最佳.

为了验证FCM-YOLO各模块的有效性,设计一

组消融实验,以YOLOv5s为基准方法,将所提出模块与YOLOv5s模型组合进行对比实验,消融实验在北大公开的PCB数据集上完成,实验结果如表2所示,√表示模型含有该模块.

表 2 消融实验结果对比

FRM	CSAM	MREB	NWD	data augmentation	mAP/%	increased percentage	Recall/%	FPS
					93.6		91.7	74.63
√					95.3	1.7	93.7	76.92
	√				95.6	2.0	94.4	41.84
		√			94.9	1.3	91.2	54.64
			√		94.0	0.4	91.3	75.88
√	√		√		96.2	2.6	94.8	40.11
√		√	√		95.8	2.2	93.9	62.52
	√	√	√		96.5	2.9	93.3	36.64
√	√	√			96.8	3.2	94.6	34.21
√	√	√	√		97.3	3.7	95.3	34.33
√	√	√	√	√	98.3	4.7	95.8	33.91

由表2可知,所提出各模块在PCB缺陷检测任务上均获得良好性能.其中:上下文注意力模块CSAM贡献最大,通过可变形卷积使得小目标的特征与背景得到明显的区分,促使模型更好地进行检测任务,其精度与基准相比提高了2.0%,但正是由于可变形卷积,模型产生了较多的参数,导致模型速度下降了很多.由于引入SPDConv,缺陷目标的判别特征信息被尽可能地保留在通道中,通过特征重提取模块FRM强调局部信息,精度较基准提升了1.7%.多尺度感受野增强模块MREB实现了多尺度的特征融合,精度也提升了1.3%.这3个模块在两两组合加入模型后,模型性能出现一定程度的抑制,在共同组合后,使得模型性能更加优越.采用NWD对损失函数进行改进后,使得对边界框的评价更具广泛性,能够进一步优化小目标的检测,使得改进模型的性能达到最佳.采用扩充后的数据集进行训练,然后在测试模型性能时,采用扩充前的数据集,实验结果表明:所提出算法鲁棒性增强,在原数据集上能够达到更高的准确率.图5为模块可视化效果图.由图5可知:SPDConv能够提取较为全面的特征信息,经特征重提取模块,特征得到了有效增强,而上下文注意力模块能够使得模

型更关注目标位置.

在目标检测中特征增强、注意力和多尺度特征融合策略十分有利于检测性能,为了验证FCM-YOLO各模块的先进性,将FRM与其他特征增强模块、CSAM与其他注意力模块、MREB与其他多尺度融合模块进行实验对比,实验结果如表3所示.由表3可知,FCM-YOLO各模块能够在特征增强、注意力、多尺度特征融合策略上分别取得较好的检测结果.

表 3 本文各模块与其他模块实验结果对比

module	mAP/%	increased percentage	Recall/%
baseline	93.6		91.7
Res 2 Net Block ^[26]	94.0	0.4	92.6
FasterNet Block ^[27]	94.4	0.8	92.2
FRM	95.3	1.7	93.7
Biformer ^[28]	94.4	0.8	93.7
EMA ^[29]	94.8	1.2	92.1
CSAM	95.6	2.0	94.4
PPM ^[30]	93.9	0.3	90.3
Scale-Aware RFE Module ^[31]	94.3	0.7	91.5
MREB	94.9	1.3	91.2

2.4 对比实验

在北大公开的PCB缺陷数据集上,将FCM-YOLO与主流目标检测算法进行比较,以AP、mAP作为模型性能的评价指标,AP、mAP值越高,检测性能越好.实验结果如表4所示.

由表4可知,YOLOv7采用了新的特征提取结构ELAN,设计了更深的网络,精度达到92.5%,但是越深层的网络往往越易导致小目标和边缘信息的丢失,这极其不利于PCB缺陷检测.YOLO-MBBi使用移动倒置残差瓶颈块增强特征,检测精度有小幅提升,




图 5 模块可视化效果图

为 95.3 %。Extended FPN 基于 FPN 对特征语义信息进行卷积横向融合,其检测精度达到了 96.2 %,但是不利于更复杂环境下的 PCB 缺陷检测。Light-PDD 通过双域注意力机制有效解决了 PCB 缺陷尺寸较小,难以识别的问题,精度达到了 97.1 %。由于数据集中毛刺与鼠咬这两类形态特征相似,误检非常多,本文通过上下文注意力模块 CSAM 学习到各类别的有效特征,同时弱化背景对特征提取的影响,多尺度感受野增强模块 MREB 大大增强了像素信息间的联系,弥补了特征提取过程中的边缘信息丢失,获取更多的特征信息用于检测,FCM-YOLO 的检测精度达到了 98.3 %,尤其在毛刺和鼠咬这两个易混淆的类别上,FCM-YOLO 远超于其他算法,取得了最优效果。图 6

为 FCM-YOLO 在 PCB 缺陷数据集上的部分可视化检测结果,以及基准算法 YOLOv5s 的检测结果。由图 6 可见:基准算法存在检测精度低,误检漏检等问题,而 FCM-YOLO 能够较好地检测到缺陷目标,有效提升检测精度,缓解了 YOLOv5s 的误检漏检问题,因此所提出算法具有良好的 PCB 表面缺陷检测性能。

为了验证 FCM-YOLO 在缺陷类目标检测任务上的通用性,选择 GC 10-DET 数据集进行实验,该数据集包含 10 种钢铁表面缺陷:冲孔(Pu)、焊缝(Wl)、新月形缺口(Cg)、水斑(Ws)、油斑(Os)、丝斑(Ss)、夹杂物(In)、轧坑(Rp)、折痕(Cr)、腰折(Wf),共 3 570 张灰度图像,按照与 PCB 缺陷数据集相同的比例划分该数据集。实验结果如表 5 所示。

表 4 PCB 缺陷数据集上本文算法与其他算法的精度对比

method	missing_hole	mouse_bite	open_circuit	short	spur	spurious_copper	mAP/%
Faster RCNN ^[32]	91.7	78.2	80.6	84.8	74.8	85.1	82.5
Cascade RCNN ^[33]	91.5	74.9	78.2	81.1	73.9	82.2	80.3
SSD ^[12]	85.3	70.6	71.7	82.0	67.1	73.2	74.9
YOLOX ^[34]	99.5	91.2	92.5	90.1	86.3	94.4	92.3
YOLOv7 ^[35]	99.5	91.8	93.1	93.6	83.9	93.1	92.5
PCB-YOLO ^[14]	99.5	90.7	99.5	98.5	90.9	96.7	95.9
YOLO-MBBi ^[36]	97.6	94.5	97.3	92.1	94.5	95.7	95.3
Extended FPN ^[37]	97.1	95.2	93.2	98.4	95.6	96.3	96.2
Light-PDD ^[13]	99.5	97.1	97.7	96.5	94.7	97.2	97.1
YOLOv5s	99.5	94.0	94.2	94.0	84.5	95.7	93.6
ours	99.5	98.1	98.9	97.8	97.4	98.5	98.3




图 6 检测效果可视化对比

表 5 GC 10-DET 数据集上本文算法与其他算法的精度对比

method	Pu	Wl	Cg	Ws	Os	Ss	In	Rp	Cr	Wf	mAP/%
Faster RCNN ^[32]	94.4	75.1	86.0	59.9	65.5	50.1	24.5	24.4	55.0	88.3	62.3
Cascade RCNN ^[33]	98.4	89.8	94.8	73.0	72.3	60.2	18.5	34.6	16.7	66.6	62.5
TridentNet ^[38]	94.5	66.4	95.8	76.7	72.9	67.2	38.7	41.7	38.5	82.1	67.5
Retinanet ^[39]	97.6	76.0	93.6	65.2	53.7	59.2	9.9	21.8	3.2	82.6	56.3
SSD ^[12]	91.6	74.4	92.8	55.2	61.2	68.9	16.8	15.5	52.7	87.2	61.6
Swin transformer ^[40]	97.6	86.5	94.6	70.0	64.8	61.6	14.1	28.0	8.3	88.2	61.4
Yolov5s	96.5	86.1	93.4	78.6	74.3	60.8	41.9	55.7	41.4	85.9	71.5
ours	98.4	90.1	93.2	77.9	76.8	69.0	42.1	58.4	56.6	89.3	75.2

由表 5 可知:FCM-YOLO 在 GC 10-DET 数据集上的精度为 75.2 %,较主流二阶段、一阶段算法均有较大提升,尤其是在夹杂物、轧坑和折痕这 3 类上,目标特征不规则,尺度小且特征与其他类别相似度较高,特征提取困难,不利于其检测。尽管 RetinaNet 引入了 Focal Loss 使得模型专注于难以分类的样本,

Swin transformer 使用了多头注意力增强全局信息,但是它们的检测性能非常差,在这 3 类上检测精度甚至低于 10 %。而所提出模型能够较好地解决缺陷检测问题,特征重提取模块 FRM 保留具有判别性的特征信息,上下文注意力模块 CSAM 通过可变形卷积和深度可分离卷积提取高质量特征,尽可能捕捉到更多

的缺陷目标,超越普通卷积,以充分缓解漏检问题.本文还使用多尺度特征融合完善特征信息,以便更有效地区分不同类别,有效缓解了误检问题,同时也表明所提出算法在缺陷类目标检测的任务上有良好的检测效果.

3 结论

为了解决PCB缺陷检测任务中目标特征与背景过于相似、目标占比小易被漏检、误检等问题,本文基于YOLOV5s进行改进,提出了一种特征增强和多尺度融合的PCB缺陷检测方法FCM-YOLO.通过构建特征重提取模块,对浅层特征进行双重提取,通过上下文注意力模块,增强了与背景相似的小目标的特征表示,缓解了误检和漏检问题,使用多尺度感受野增强模块,特征像素间进行有效联系,提升了缺陷目标特征的表达能力.将FCM-YOLO在PCB缺陷数据集和GC 10-DET数据集上进行了实验验证,实验结果表明了所提出算法在缺陷检测任务上的有效性.接下来,将进一步优化模型,尽可能减少参数数量和计算量,使其能够适应更多的缺陷检测任务,提升模型的鲁棒性和泛化性.

参考文献(References)

- [1] Wang X, Gao J S, Hou B J, et al. A lightweight modified YOLOX network using coordinate attention mechanism for PCB surface defect detection[J]. IEEE Sensors Journal, 2022, 22(21): 20910-20920.
- [2] 叶卓勋, 刘妹琴, 张森林. 基于轻量化深度学习网络的工业环境小目标缺陷检测[J]. 控制与决策, 2023, 38(5): 1231-1238.
(Ye Z X, Liu M Q, Zhang S L. Small-scale defect detection in industrial environment based on lightweight deep learning network[J]. Control and Decision, 2023, 38(5): 1231-1238.)
- [3] 闫涵, 卢伟, 吴玉虎. 基于轻量化卷积神经网络的金属断口图像识别[J]. 控制与决策, 2024, 39(9): 2858-2866.
(Yan H, Lu W, Wu Y H. Metal fracture recognition based on lightweight convolutional neural network[J]. Control and Decision, 2024, 39(9): 2858-2866.)
- [4] Chen B Y, Dang Z C. Fast PCB defect detection method based on FasterNet backbone network and CBAM attention mechanism integrated with feature fusion module in improved YOLOv7[J]. IEEE Access, 2023, 11: 95092-95103.
- [5] Li W T, Yang J J, Lv X J, et al. A new path planning method for flying probe test arms[C]. Chinese Control and Decision Conference. Hefei, 2020: 1552-1556.
- [6] Zheng J F, Sun X P, Zhou H X, et al. Printed circuit boards defect detection method based on improved fully convolutional networks[J]. IEEE Access, 2022, 10: 109908-109918.
- [7] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]. Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2014: 580-587.
- [8] Niu J, Huang J, Cui L, et al. A PCB defect detection algorithm with improved faster R-CNN[C]. Proceedings of the International Conference on Big Data & Artificial Intelligence & Software Engineering. Guangzhou, 2022: 21-23.
- [9] Zeng N Y, Wu P S, Wang Z D, et al. A small-sized object detection oriented multi-scale feature fusion approach with application to defect detection[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 3507014.
- [10] Zhang H, Jiang L X, Li C Q. CS-ResNet: Cost-sensitive residual convolutional neural network for PCB cosmetic defect detection[J]. Expert Systems with Applications, 2021, 185: 115673.
- [11] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, 2016: 779-788.
- [12] Liu W, Anguelov D, Erhan D, et al. SSD: Single shot MultiBox detector[M]. Cham: Springer International Publishing, 2016: 21-37.
- [13] Tang J, Wang Z D, Zhang H Y, et al. A lightweight surface defect detection framework combined with dual-domain attention mechanism[J]. Expert Systems with Applications, 2024, 238: 121726.
- [14] Tang J L, Liu S B, Zhao D X, et al. PCB-YOLO: An improved detection algorithm of PCB surface defects based on YOLOv5[J]. Sustainability, 2023, 15(7): 5963.
- [15] 周彦, 孟江南, 王冬丽, 等. 基于多尺度轻量化注意力的钢材缺陷检测[J]. 控制与决策, 2024, 39(3): 901-909.
(Zhou Y, Meng J N, Wang D L, et al. Steel defect detection based on multi-scale lightweight attention[J]. Control and Decision, 2024, 39(3): 901-909.)
- [16] Sunkara R, Luo T. No more strided convolutions or pooling: A new CNN building block for low-resolution images and small objects[C]. Joint European Conference on Machine Learning and Knowledge Discovery in Databases. Cham: Springer, 2023: 443-459.
- [17] Gu Z C, Zhu K, You S T. YOLO-SSFS: A method combining SPD-conv/STD/L/IM-FPN/SIoU for outdoor small target vehicle detection[J]. Electronics, 2023, 12(18): 3744.
- [18] Quan Y, Zhang D, Zhang L Y, et al. Centralized feature pyramid for object detection[J/OL]. 2022, arXiv: 2210.02093.
- [19] 李雅雯, 孙浩然, 胡跃明, 等. 基于注意力机制与多尺度特征融合的电极缺陷YOLO检测算法[J]. 控制与决

- 策, 2023, 38(9): 2578-2586.
(Li Y W, Sun H R, Hu Y M, et al. Electrode defect YOLO detection algorithm based on attention mechanism and multi-scale feature fusion[J]. Control and Decision, 2023, 38(9): 2578-2586.)
- [20] Dai J F, Qi H Z, Xiong Y W, et al. Deformable convolutional networks[C]. Proceedings of the IEEE International Conference on Computer Vision. Venice, 2017: 764-773.
- [21] Howard A G, Zhu M L, Chen B, et al. MobileNets: Efficient convolutional neural networks for mobile vision applications[J/OL]. 2017, arXiv: 1704.04861.
- [22] 陈鸿坤, 罗会兰. 多尺度语义信息融合的目标检测[J]. 电子与信息学报, 2021, 43(7): 2087-2095.
(Chen H K, Luo H L. Multi-scale semantic information fusion for object detection[J]. Journal of Electronics & Information Technology, 2021, 43(7): 2087-2095.)
- [23] Wang J W, Xu C, Yang W, et al. A normalized Gaussian Wasserstein distance for tiny object detection[J/OL]. 2021, arXiv: 2110.13389.
- [24] Ding R W, Dai L H, Li G P, et al. TDD-net: A tiny defect detection network for printed circuit boards[J]. CAAI Transactions on Intelligence Technology, 2019, 4(2): 110-116.
- [25] Lv X M, Duan F J, Jiang J J, et al. Deep metallic surface defect detection: The new benchmark and detection network[J]. Sensors, 2020, 20(6): 1562.
- [26] Gao S H, Cheng M M, Zhao K, et al. Res2Net: A new multi-scale backbone architecture[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 43(2): 652-662.
- [27] Chen J R, Kao S H, He H, et al. Run, don't walk: Chasing higher FLOPS for faster neural networks[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver, 2023: 12021-12031.
- [28] Zhu L, Wang X J, Ke Z H, et al. BiFormer: Vision transformer with Bi-level routing attention[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver, 2023: 10323-10333.
- [29] Ouyang D L, He S, Zhang G Z, et al. Efficient multi-scale attention module with cross-spatial learning[C]. ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing. Rhodes Island, 2023: 1-5.
- [30] Zhao H S, Shi J P, Qi X J, et al. Pyramid scene parsing network[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, 2017: 2881-2890.
- [31] Yu Z P, Huang H B, Chen W J, et al. YOLO-FaceV2: A scale and occlusion aware face detector[J/OL]. 2022, arXiv: 2208.02019.
- [32] Ren S Q, He K M, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.
- [33] Cai Z W, Vasconcelos N. Cascade R-CNN: Delving into high quality object detection[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City, 2018: 6154-6162.
- [34] Ge Z, Liu S T, Wang F, et al. YOLOX: Exceeding YOLO series in 2021[J/OL]. 2021, arXiv: 2107.08430.
- [35] Wang C Y, Bochkovskiy A, Liao H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver, 2023: 7464-7475.
- [36] Du B W, Wan F, Lei G B, et al. YOLO-MBBi: PCB surface defect detection method based on enhanced YOLOv5[J]. Electronics, 2023, 12(13): 2821.
- [37] Li C J, Qu Z, Wang S Y, et al. A method of defect detection for focal hard samples PCB based on extended FPN model[J]. IEEE Transactions on Components, Packaging and Manufacturing Technology, 2022, 12(2): 217-227.
- [38] Paz D, Zhang H Y, Christensen H I. TridentNet: A conditional generative model for dynamic trajectory generation[C]. International Conference on Intelligent Autonomous Systems. Cham: Springer, 2022: 403-416.
- [39] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]. Proceedings of the IEEE International Conference on Computer Vision. Venice, 2017: 2980-2988.
- [40] Liu Z, Lin Y T, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. Montreal, 2021: 10012-10022.

作者简介

严舒(2000—), 女, 硕士生, 从事计算机视觉、目标检测等研究, E-mail: 2739076735@qq.com;

郭颖(1985—), 男, 副教授, 博士, 从事计算机视觉、微弱信号检测等研究, E-mail: yguo@nuist.edu.cn;

黄骏(1998—), 男, 硕士生, 从事计算机视觉、目标检测等研究, E-mail: 2316698302@qq.com.