

YOLO 十年演进：从实时检测先锋到多任务智能前沿

岑伟迪¹, 江佳玲², 黄勃^{2,3†}, 倪福川^{3,4}, 李高健²

1. 中国移动通信集团浙江有限公司, 浙江 杭州 310016;
2. 上海工程技术大学 电子电气工程学院, 上海 201620;
3. 华中农业大学 农业智能技术教育部工程研究中心, 湖北 武汉 430070;
4. 华中农业大学 信息学院, 农业农村部智慧养殖技术重点实验室, 湖北 武汉 430070

收稿日期: 2025-05-09 † 通信联系人 E-mail: huangbosues@sues.edu.cn

基金项目: 华中农业大学农业智能技术教育部工程研究中心开放课题(ERCITA-KF002); 中国移动浙江公司 2023 年 B 域数据应用研发项目

第一作者: 岑伟迪, 男, 硕士生, 主要从事模式识别与智能系统方面的研究。E-mail: cenweidi@139.com

摘要: 目标检测是计算机视觉的基石, 在医疗成像、工业缺陷检测、自动驾驶和农业监测等领域有着广泛的应用。YOLO (You Only Look Once) 作为单阶段目标检测的开创性算法, 以其卓越的实时性和高效性成为计算机视觉领域的核心技术。从 2016 年 YOLOv1 的首次亮相到 2025 年 YOLOv12 的发布, YOLO 通过持续优化网络架构、改进损失函数设计和创新数据增强策略, 显著提升了检测性能和应用适配性。本文系统回顾了 YOLO 长达十年的发展历程, 分析了其在不同领域的应用, 并探讨了其快速发展背后的驱动力, 包括深度学习技术的突破、开源社区的广泛协作以及对实时性和边缘计算的迫切需求。与双阶段算法(如 Faster R-CNN)和基于 Transformer 的方法(如 DETR)相比, YOLO 在速度和工程部署上展现出显著优势, 但在小目标检测、密集场景处理和复杂背景下的鲁棒性方面仍面临挑战。未来 YOLO 或可通过整合轻量级 Transformer 模块、优化多任务学习框架以及引入生成式 AI 增强数据多样性, 有望进一步提升精度和场景适应能力。

关键词: YOLO; 目标检测; 计算机视觉

中图分类号: TP18

文献标志码: A

文章编号: 1671-8836(2026)01-0005-16

Ten Years of YOLO Evolution: From Real-Time Detection Pioneer to Multi-Tasking Intelligence Frontier

CEN Weidi¹, JIANG Jialing², HUANG Bo^{2,3†}, NI Fuchuan^{3,4}, LI Gaojian²

1. China Mobile Communications Group Zhejiang Co., Ltd., Hangzhou 310016, Zhejiang, China;
2. School of Electronic and Electrical Engineering, Shanghai University of Engineering Science, Shanghai 201620, China;
3. Engineering Research Center of Intelligent Technology for Agriculture, Ministry of Education, Huazhong Agricultural University, Wuhan 430070, Hubei, China;
4. Key Laboratory of Smart Farming Technology for Agricultural Animals, Ministry of Agriculture and Rural Affairs, College of Informatics, Huazhong Agricultural University, Wuhan 430070, Hubei, China

Abstract: Target detection is the cornerstone of computer vision, with a wide range of applications such as medical imaging, industrial defect detection, autonomous driving and agricultural monitoring, etc. YOLO (You Only Look Once), a pioneering algorithm for single-stage target detection, has become a core technology in the field of computer vision due to its excellent real-time performance and high efficiency. From the debut of YOLOv1 in 2016 to the release of YOLOv12 in 2025, YOLO has significantly improved its detection performance and application suitability through continuous optimization of the network architecture, improvement of the loss function design and innovative data enhancement strategies. In this paper, we systematically review YOLO's

引用格式: 岑伟迪, 江佳玲, 黄勃, 等. YOLO 十年演进: 从实时检测先锋到多任务智能前沿[J]. 武汉大学学报(理学版), 2026, 72(1): 5-20. DOI: 10.14188/j.1671-8836.2025.0116.

CEN Weidi, JIANG Jialing, HUANG Bo, *et al.* Ten Years of YOLO Evolution: From Real-Time Detection Pioneer to Multi-Tasking Intelligence Frontier [J]. *J Wuhan Univ (Nat Sci Ed)*, 2026, 72(1): 5-20. DOI: 10.14188/j.1671-8836.2025.0116(Ch).

decade-long development history, analyze its applications in different domains, and discuss the driving forces behind its rapid development, including breakthroughs in deep learning technology, extensive collaboration in the open source community, and the pressing need for real-time and edge computing. Compared with two-stage algorithms (e.g., Faster R-CNN) and Transformer-based methods (e.g., DETR), YOLO demonstrates significant advantages in terms of speed and engineering deployment, but its limitation is that it still faces challenges in terms of small-target detection, dense-scene processing, and robustness in complex contexts. In the future, YOLO may be able to enhance data diversity by integrating a lightweight Transformer module, optimizing the multi-task learning framework, and introducing generative AI, which is expected to further improve accuracy and scene adaptation.

Key words: YOLO(You Only Look Once); target detection; computer vision

0 引言

目标检测作为计算机视觉的核心技术,旨在从图像或视频中识别并定位物体,广泛应用于医疗影像分析、工业缺陷检测、自动驾驶和农业监测等领域。传统目标检测方法依赖手工设计的特征提取,受限于表达能力^[1],难以应对复杂场景。2012年,AlexNet引入卷积神经网络(CNN)^[2],凭借强大的特征学习能力开启了深度学习时代,显著提升了目标检测的性能。此后,目标检测算法逐渐分为双阶段和单阶段两大流派^[3]。双阶段方法(如R-CNN系列)通过候选区域生成和精细回归实现高精度,但计算复杂度高,难以满足实时需求。相比之下,单阶段方法以速度见长,尤其以YOLO(You Only Look Once)为代表,通过一次前向传播同时预测边界框和类别概率,树立了实时检测的里程碑。

自2016年YOLOv1首次发布以来^[4],YOLO系列通过持续优化网络架构、损失函数和数据增强策略,演进至2025年的YOLOv12,显著提升了检测性能和多任务适应性。YOLOv8和YOLOv10引入解耦头和端到端检测设计,拓展了实例分割、姿态估计等任务;YOLOv11通过C3k2和C2PSA模块优化了多尺度特征融合;YOLOv12首次全面融入注意力机制,突破传统卷积网络局限,进一步平衡精度与效率。关于YOLO的综述研究已有积累,如毛少华等^[5]聚焦网络结构改进,米增等^[6]侧重通用检测应用。

与现有YOLO综述相比,本文剖析了YOLOv8/v10-v12的多任务框架(如实例分割、姿态估计等),补充了现有综述的分析不足;系统总结YOLOv5-v12的轻量化设计对边缘计算的适配性;对YOLOv10的端到端检测设计进行定量分析,为目标检测研究提供新参考。

1 YOLO发展历程与框架原理

目标检测作为计算机视觉领域的关键任务之

一,最早可以追溯到20世纪90年代,其核心要义为从图像或视频序列中精准判定物体的存在性、所属类别以及空间位置。此项任务既涵盖分类问题,即将物体归置于预先设定的类别范畴,又涵盖回归问题,即明确物体的精准位置。目标检测算法能够获取目标物体的中心点坐标以及其宽度与高度,绘制出矩形选择框,同时对目标物体的类别予以识别。目标检测算法可划分为两大类:传统检测方法与基于深度学习的检测方法。由于早期缺乏有效的图像表示,因此传统检测方法不得不用手工设计特征提取方法构建可训练模型。它们的基本工作流程:首先在输入图像上滑动不同尺寸的窗口生成候选框,然后运用基于颜色、纹理、形状等特性的分类器展开分类,最终通过非极大值抑制算法剔除冗余的检测框。传统方法的特征表达能力十分有限,因此在模型的分类精准度和泛化能力上有很大的局限。2012年,AlexNet的出现让全世界见证了卷积神经网络强大的特征学习能力,这也是卷积神经网络首次被应用于大规模图像分类任务,标志着目标检测进入了深度学习时代。

作为深度学习目标检测算法中单阶段检测算法的代表YOLO算法从v1发展到v12,及其多个改进版本,已被广泛应用于医学、工业、农业等领域。以下分析YOLO系列算法的基本思想和框架及原理。

1) YOLO目标检测算法的基本思想

YOLO是一种开创性的单阶段实时目标检测方法^[4]。在计算机视觉领域引起了一场技术革命,这种方法极大地提高了目标检测的速度,达到实时处理的水平,同时保持了较高的准确性。自YOLOv1问世以来,到目前为止,已经更新到了YOLOv12版本,图1展示了YOLO系列主流目标检测算法的演变历程^[7-8]。

YOLO系列算法的核心思想是把输入的图像划分成多个网格,每个网格负责检测中心点落在该网格内的目标。它将目标检测转化为回归问题,通过划分

网格直接预测边界框和类别概率。在检测过程中,对每个网格进行预测,不仅包括边界框的坐标和尺寸,还涵盖了目标所属的类别信息。这种方式能够实现

端到端的快速检测,同时通过引入不同尺度的特征图处理不同大小的目标,提高检测的准确性和全面性。从 v1 到 v12, YOLO 不断迭代优化。




图1 12个版本的YOLO的发布时间

Fig. 1 Publication timeline of the 12 YOLO versions

2) YOLO 系列各版本网络框架及原理

YOLO 系列目标检测算法的整体网络由三部分组成:主干网络(Backbone)^[9]、颈部网络(Neck)和头部网络(Head)^[10]。主干网络提取多尺度特征,颈部网络融合特征,头部网络输出预测结果。主干网络是每一代 YOLO 的核心部分,通过多层卷积操作将输入图像转换为多尺度、多层次的特征图,用于提取图像特征;颈部网络负责将主干部分提取的特征进行进一步处理和融合,方便模型更好地理解图像特征,检测不同尺寸的目标;头部网络通过接收颈部网络的特征图实现目标分类和定位,其通常会输出一个多维数组,数组中包含每个网格单元的预测信息,包括类别和置信度分数等。图2为 YOLO 系列算法流程图^[4]。




图2 YOLO 系列算法流程图^[4]

Fig. 2 Flowchart of the YOLO series algorithms^[4]

1.1 YOLOv1:实时检测的奠基之作

YOLOv1 (You Only Look Once) 由 Redmon 等于 2016 年提出^[4],受到 GoogleNet^[11]和 Network in Network 的启发,使用 1×1 的卷积层减少特征图

数量并保持较低参数,将输入图像划分为 $S \times S$ 个网格,每个网格产生 B 个候选框和 C 个类别概率,最后输出一个多维数组包含上述信息。在 VOC 2007 数据集^[12]上实现了 63.4% 的 mAP(平均精度)。

YOLOv1 中,没有显式的颈部网络部分,输入图像尺寸固定为 448×448 ,不可改变。将输入图像划分为 $S \times S$ 个网格,网格中若包含图像中的某个物体的中心点,那么该网格就负责预测该物体;每个中心点会生成 2 个候选框,每个候选框包含 5 个值 (x, y, w, h, c) ,其中 x 和 y 代表候选框中心坐标, w 代表候选框与整个图像的宽度之比, h 代表候选框与整个图像的高度之比, c 代表候选框的类别置信度,计算如下:

$$c = \Pr(\text{Object}) \cdot \text{IOU} \frac{\text{truth}}{\text{pred}} \quad (1)$$

其中, $\Pr(\text{Object})$ 表示候选框是否包含待检测目标,当候选框里有物体时, $\Pr(\text{Object}) = 1$; 当候选框里没有物体时, $\Pr(\text{Object}) = 0$ 。 $\text{IOU} \frac{\text{truth}}{\text{pred}}$ 表示候选框与真实框之间的交并比^[13],反映两者重叠程度。每个网格还要预测 C 个类别的概率,因此 YOLOv1 输出 $S \times S \times (B \times 5 + C)$ 维的向量。其中, S 表示划分网格的数量, $S = 7$; B 表示候选框数量, $B = 2$; 5 表示为候选框包含的 5 个值,分别为 (x, y, w, h, c) ; $C = 20$,表示预测的类别数量;由于 YOLOv1 共有 $S \times S$ 个网格,每个网格产生 2 个候选框,因此 YOLOv1 共产生 $S \times S \times 2$ 个候选框,这些候选框通过非极大值抑制(Non-Maximum Suppression, NMS,

接提供了一条允许梯度直接回流的捷径,有效缓解了梯度消失问题。也就是说,残差连接允许原始输入信息直接传递到后面的层,这意味着即使后面的层学习效果不佳,网络也能保留原始信息,不会变得更差。而对于这些学习效果不佳的层,网络赋予一个接近0的权重,忽略掉该层。所以对于残差连接通俗的解释便是“添加后至少不比添加前差”。

2) 特征金字塔网络。该网络旨在有效地处理多尺度的目标。其主要思想是生成多尺度的特征图,从而更好地检测不同大小的目标。特征金字塔网络主要通过自上而下的路径进行特征融合。它从主干网络的高层特征图开始,通过上采样将特征图逐层传递到较低层。这种结构增强了小目标检测能力,因为高层特征图具有较丰富的语义信息。在每个上采样步骤中,来自较高层的特征图与来自相邻较低层的特征图进行相加操作,从而生成更具语义信息的多尺度特征图。

3) 更多的先验框尺寸^[20]。为了接受特征金字塔网络不同尺度的特征图,YOLOv3也产生了与之相匹配的不同尺寸的先验框,分别用于预测大、中、小物体。其原理和YOLOv2生成的先验框类似,都是通过聚类的方法,只是数量变成了9个。

4) SoftMax改进。在目标检测任务中,提取图像特征固然重要,但最终的分类任务对模型性能也有很大的影响。当数据集允许一个对象被同时分为多个类别时,由于传统的SoftMax^[21]假设类别是互斥的,即一个对象只能属于一个类别,显然不适合多标签分类任务;所以YOLOv3通过使用二元交叉熵损失替代分类交叉熵损失,独立计算每个类别的概率,最终输出各类别概率,从而完成多标签分类任务。YOLOv3在保持高速度的同时,大大提高了多尺度下目标检测任务的精度。

1.4 YOLOv4:技术融合的性能巅峰

在YOLOv3出现后的一段时间,YOLO系列演化都处于停滞状态,直到两年后,Bochkovskiy团队提出了YOLOv4^[21]。相较前几代版本,YOLOv4主要从两方面进行了改进,一是网络设计方面,二是数据处理方面。

在网络设计方面,YOLOv4选取CSPDarkNet-53作为主干网络,是将CSPNet(Cross Stage Partial Network)的思想^[22]融合进了Darknet53的结构。也就是说,CSPDarkNet-53仍然保持53层卷积和残差连接的主体架构,但引入了CSP连接。CSP连接的核心思想是将特征图分成两部分^[23]:一部分通过残差块进行处理,另一部分直接传递到后续层。设输入为 x ,特征图分割为 x_1 和 x_2 , x_1 通过残差块处理得到 $F(x_1)$,然后将 x_2 和 $F(x_1)$ 进行融合得到最终输出。虽然残差连接也能缓解梯度消失问题,但CSPNet通过结构化的特征图分割和融合进一步优化了梯度流动,提高了网络的计算效率的同时还保留了未处理特征和处理后的特征的多样性,提高了特征表达能力。主干网络末端引入了SPP(Spatial Pyramid Pooling)模块,旨在通过在不同尺度上进行池化,捕捉特征图中的多尺度信息,提高模型的识别能力。其通过在特征图上应用不同尺寸的池化窗口,生成多个不同尺度的特征图,再将这些不同尺度的特征图拼接在一起,形成一个具有多尺度信息的特征图。YOLOv4还引入了路径聚合网络PAN,其包含一个自底向上的路径、一个自顶向下的路径和一个横向连接^[24]。底层特征图包含更多的细节信息,适合检测小目标;顶层特征图包含更多的语义信息,适合检测大目标,不同尺度的特征图负责检测不同大小的目标;横向连接将自顶向下路径中的特征图与自底向上路径中相同尺度的特征图进行融合。通过双向路径实现更充分的多尺度和多层次特征融合,增强了整体检测性能,如图4所示^[21]。




图4 YOLOv4架构图^[21]

Fig. 4 Architecture diagram of YOLOv4^[21]

在数据处理方面, YOLOv4 引入了许多特殊的训练技巧, 提出了 BoF 策略, 其中比较出名的便是参考 CutMix 方法的一种新的数据增强技术^[5]: Mosaic。它通过将四张不同的图片拼接在一起, 形成一张新的训练图像。由于拼接后的图像使模型在训练时看到了更多样化的背景和目标, 这种方式不仅增强了模型的鲁棒性, 还在一定程度上缓解了数据集不足的问题。YOLOv4 还采用了 CIoU 损失函数(Complete Intersection over Union Loss), 考虑了边界框的中心点距离、面积比和长宽比等因素, 从而更全面地评估预测框和真实框之间的差异, 提高了边界框回归的精度。

YOLOv4 一个突出的优点是所有实验都是由单 GPU 完成的, 对没有高算力能力的研究人员非常友好, 使更多普通人也可以轻松入门目标检测算法。

1.5 YOLOv5: 轻量化部署的里程碑

YOLOv5 是 YOLO 系列算法的里程碑之一, 其首次将开发环境更换为 PyTorch^[6]。PyTorch 由于易用性、强大的社区支持以及动态计算图的特性, 在学术界和工业界都广受欢迎。如果说 YOLOv4 的亲民性在于硬件, 那么 YOLOv5 的亲民性便是社区的成熟维护, 方便研究人员进行二次开发。

YOLOv5 是在 YOLOv4 基础上改进的^[6](YOLOv5 最新的 7.0 版本相较于 1.0 版本也有很大的不同, 所以本节只概括最新的 7.0 版本), 改进包括以下几点:

1) 自适应锚框计算和 Mosaic 数据增强。YOLOv5 可进行自适应锚框计算, 自动分析数据集并动态调整锚框尺寸和比例, 更好地匹配不同目标尺度。在此过程中, 用户无需干预, 锚框调整过程全自动, 减少了调参的复杂性。也对 Mosaic 进行了一些改进, 模型将不再是随机拼接四张图片生成新的训练样本, 而是在拼接后进行平滑处理, 减少拼接边界对训练的干扰, 大大增强了模型对边界目标的检测能力。

2) Focus 模块的引入。6.0 版本之前, YOLOv5 使用 Focus 模块对图片进行切片操作, 实现了输入图像尺寸的缩小, 但并不是下采样操作, 因为 Focus 会保留图像的原始信息, 不会出现卷积下采样的特征丢失问题。之后 YOLOv5 使用一个 6×6 的卷积层取而代之, 因为在某些硬件上 Focus 的操作不容易实现, 并且普通卷积也可以使模型架构变得更加统一和简化, 便于理解和部署。由于标准卷积是所有深度学习框架和加速库都高度支持的操作, 这使得 YOLOv5 模型在不同的开发环境中更容易迁移和复用。

3) SPPF (Spatial Pyramid Pooling - Fast) 模块的引入。SPPF 和 SPP 目的和原理都相同, 只不过 SPPF 通过减少池化操作的次数提高计算效率, 只使用一个 3×3 的池化核, 每次池化后的特征图被拼接起来, 在保留多尺度特征提取能力的同时大大降低了计算量。

YOLOv5 相较于 YOLOv4 的改进主要集中在轻量化操作上。YOLOv5 也提供了不同规模的模型(如 YOLOv5s, YOLOv5m, YOLOv5l, YOLOv5x), 用户可以根据实际需求选择合适的模型规模, 实现性能与速度之间的平衡。YOLOv5 在不同硬件平台上的兼容性更好, 尤其是在嵌入式设备和移动设备上, 轻量化模型更易于部署。

1.6 YOLOv6: 高效推理的再进化

YOLOv6 于 2022 年 9 月由美团视觉团队发布^[25]。该网络借鉴 RepVGG 结构的重参数化, 提出 EfficientRep 的主干网络, 使用一个 PAN 拓扑颈部网络, 借鉴 YOLOX^[7]的检测头设计了一个高效的解耦头部, 采用混合通道策略。另外, 该团队还使用增强量化技术实现更快、更准确的检测器。

YOLOv6 主干网络的设计灵感来源于 RepVGG, 核心思想是将复杂的多分支结构简化为单一卷积层的架构, 在训练时, 使用包含多个卷积和残差分支的复杂结构, 以增强模型的学习能力; 在推理时, 将这些多分支结构的参数合并成一个等效的单一卷积层, 以降低计算复杂度, 提高推理速度。EfficientRep 在训练阶段使用多分支卷积结构和不同的特征融合方式提取特征, 其内部也包括了残差连接用于缓解深层网络中的梯度消失问题, 使得网络更容易训练; 在推理阶段, EfficientRep 通过重参数化技术将多分支的卷积核参数合并成一个单一的卷积核。这一过程确保了合并后的单层卷积能够保留训练期间多分支结构所学到的特征, 并且大幅减少了计算量。如果多分支结构中存在偏置项, 这些偏置项也会在重参数化过程中进行合并, 确保推理时的输出与训练时保持一致。

颈部网络的 PAN 和 YOLOv5 在设计原则上保持一致, 只不过进行了一些优化, 用于提升模型性能和效率。YOLOv6 在 PAN 中广泛应用了更轻量的卷积操作和优化的卷积块, 这些改进使得 PAN 在处理多尺度特征时能够以更高效的方式进行融合, 从而减少计算负担。在特征融合时, 特别注重特征图的对齐和尺度匹配, 这种精细化处理有助于减少在不同尺度特征之间融合时的信息丢失, 同时

动态调整各层特征的权重,这种自适应性使得 PAN 能够根据不同的输入图像或场景,自主决定特征融合的策略,从而提高了检测的准确性和鲁棒性。

YOLOv6 在设计检测头部时参考了 YOLOX^[7] 的设计,采用了一个解耦头部结构。解耦头部将分类任务和定位任务分开处理,这样可以更好地优化每个任务的损失函数,提高检测的精度。

最后该团队使用了增强量化技术而不是简单的模型蒸馏,两者虽都有助于优化模型,但增强量化技术主要关注于在硬件部署时的效率和精度平衡,而模型蒸馏则更关注于压缩模型以减少其复杂度,同时尽量保持高性能。在当时的 COCO 数据集上达到了 35% 的精度,推理速度也大大提升。

1.7 YOLOv7:特征聚合的深度探索

YOLOv7 的出现,再一次优化了 YOLO 系列模型的检测效率^[26]。YOLOv7 的主干网络采用了 ELAN(Efficient Layer Aggregation Network)结构,这种设计旨在更高效地聚合不同层次的特征。在模型重参数化和动态标签匹配技术上也进行了提升和改进。

主干网络 ELAN 的设计目标是更高效地整合多层次的特征,特别是在深层网络中,能够在保持计算量可控的情况下,增强网络的特征提取能力。它通过一种新的特征聚合机制,在不破坏原来梯度路径的情况下不断地提高网络的学习能力,最大化不同层次特征的互补性,从而提高整体的特征表达能力。RepConv 是一种重参数化技术模块,其设计思想依然源自 RepVGG。YOLOv6 的重参数化技术,主要作用在主干网络的卷积模块上,YOLOv7 的 RepConv 模块则是被用在了包括主干网络和头部网络中。YOLOv5 中使用的动态标签匹配是通过自动锚框分配实现的,这种方法主要作用于锚框的优化和匹配,而 YOLOv7 则通过对所有预测框排序,根据 IoU 和置信度动态选择正样本,更加关注全局的预测框与真实标签的匹配。

YOLOv7 具备前两代的优点,依旧具有平民性,可以部署在普通单 GPU 和云平台上,设置了 YOLOv7、YOLOv7-tiny/W6 3 种模型。

1.8 YOLOv8:多任务能力的统一框架

YOLOv8 由开发 YOLOv5 的 Ultralytics 团队发布^[27],提供了统一的框架,可以解决目标检测、分割、跟踪、分类、姿态估计等各种计算机视觉任务,因此该框架在网络结构上类似于 YOLOv5,使用 C2f 代

替了 CSP 模块,使用效果更好的解耦头来代替原来的检测头。

C2f 模块使用了类似于 CSP 的特征分块和跨阶段连接方法,与 CSP 不同的是,C2f 模块强调特征的细粒度融合。引入分组卷积和密集连接机制,提供了更高的特征复用率,有助于在多尺度特征融合中实现更高的精度,因此 C2f 模块可以更高效地捕捉细节信息,提升网络的表达能力。YOLOv5 使用耦合设计的检测头,这种设计将分类和回归任务的特征提取融合在同一个网络中。这意味着在检测头中,网络同时处理类别预测和边界框回归,虽然耦合设计可以减少计算量,提高检测速度,效率很高,但因为分类和定位任务的目标不同,耦合设计可能会在某些复杂情况下降低精度,尤其是类别分布不均衡或目标尺寸差异较大时。而 YOLOv8 的检测头将分类和定位任务的特征提取分成了两个独立的分支。这种解耦设计允许网络更专注于各自任务的特征提取和优化。

1.9 YOLOv9:梯度优化的智能创新

YOLOv9 建立在 YOLOv7 基础上^[28],具有两个创新点:可编程梯度信息(PGI)和新的特征聚合网络(Generalized Efficient Layer Aggregation Network, GELAN)。

YOLO 系列的早期版本主要使用 PAN 结构,先自上而下进行特征提取,再自下而上进行特征聚合。这种做法存在如下弊端:当网络深度过大时,反向传播时特征信息丢失严重,无法保证模型对小目标和关键特征的有效捕获。后续有些版本加入了横向连接,但这样也只是以牺牲计算量为代价进行的改进。YOLOv9 提出了一个新的概念,称为可编程梯度信息 PGI。通过一种辅助可分离分支改进训练过程中的梯度传播,即在训练时多加一条路径用于梯度传播,最大程度地保留特征信息,推理时删除该分支,避免增加计算量。这种灵活的架构确保模型能够更有效地学习和更新权重。

此外,YOLOv9 引入了一种新的轻量级骨干架构,广义高效层聚合网络 GELAN。相较于 YOLOv7 的 ELAN,GELAN 通过梯度路径规划和灵活的计算块设计,提升了特征保留能力和任务适配性。ELAN 依赖固定残差连接,适合快速推理但对复杂任务适配性较弱,而 GELAN 通过 PGI 辅助分支在训练时保留细粒度特征,推理时移除分支保持高效性。GELAN 结合了 ELAN 和 CSPNet 的优势,基于梯度路径规划进行设计,减少了计算量和参数数量,在保持网络轻量化和高速度的同时,实

现高精度的目标检测。GELAN 的另一个好处就是它允许使用任意的计算块作为其基础模块,这使得网络架构更加灵活,可以根据不同的任务需求进行定制和优化。

1.10 YOLOv10:端到端检测的智能巅峰

YOLOv10 是由清华大学开发的^[29],是 YOLO 系列首个实时端到端目标检测模型,其网络结构继承于 YOLOv8。YOLOv10 提出了 YOLO 无非极大抑制(Non-Maximum Suppression, NMS)训练的一致双重分配,降低了推理延迟,还提出了轻量级分类头、空间通道解耦下采样和大内核卷积等,以提高模型的效率和准确性。相较于前代版本,它提供了更多的预训练模型。

先前的 YOLO 系列算法在训练过程中通常利用任务分配学习为每个实例分配多个正样本,这种做法可以产生丰富的监督信号,促进了优化并使模型实现了卓越的性能。但是实时检测要求高效率,显然此前的系列无法满足,因此 YOLOv10 不依赖于 NMS 后处理,一对一分配一个预测。YOLOv10 还引入了另一种一对一 Head 结构,与原始的一对多分支相同,并采用相同的优化目标,使用一对一分配方式来确定标签分配,也就是说在训练时两个 Head 联合优化,但在推理时仍然利用一对一 Head 做出预测。这使得 YOLO 能够进行端到端部署,而不会产生任何额外的推理成本。

常规的 YOLO 使用步长为 2 的标准 3×3 卷积实现下采样操作,这存在一个问题:在下采样过程中会增加计算成本和参数。YOLOv10 首先利用逐点卷积调制通道维度,然后利用深度卷积执行空间下采样,最大限度地保留了下采样过程中的信息,不仅减少延迟而且增加了竞争力。另外,在网络的布局上 YOLOv10 也更加合理,当前目标检测的一个难点就是小目标检测问题,而 YOLOv10 采用大核深度卷积达到扩大感受野和增强模型能力。相较于前代 YOLO 的“一对多”标签分配,YOLOv10 的“一对一”策略通过一致双重分配消除 NMS 后处理,显著降低推理延迟。端到端设计和高效标签分配策略,标志着 YOLO 系列在实时性与精度平衡上的新高度。

1.11 YOLOv11:多任务实时检测的新里程碑

YOLOv11,由 Ultralytics 开发,并于 2024 年在 YOLO Vision 2024(YV24)会议上发布。它的发布标志着多任务实时目标检测技术的重大突破^[30]。基于 YOLOv8 的架构基础,YOLOv11 通过引入 C3k2 块、SPPF(空间金字塔池化-快速)和 C2PSA

(并行空间注意力卷积块)等创新组件,显著增强了特征提取能力和模型效率,同时参数比 YOLOv8m 变体减少 22%,实现了精度与计算效率的优异平衡。YOLOv11 不仅支持传统目标检测,还扩展至实例分割、姿态估计、定向对象检测(OBB)、图像分类和对象跟踪等多种计算机视觉任务,展现出卓越的多任务适应性。其设计聚焦于实时性与实用性的融合,通过优化训练流程和架构改进,大幅降低推理延迟,同时保持高精度,适配从边缘设备到高性能云平台的多样化部署场景。在 COCO 数据集上,YOLOv11m 变体展现出优异的平均精度(mAP),推理速度和每秒帧数(FPS)均优于前代,凸显其在实时应用中的竞争力。C3k2 块增强了跨层特征融合,SPPF 模块提升多尺度特征处理能力,C2PSA 通过空间注意力机制有效聚焦图像关键区域,从而提升复杂场景和小目标检测的性能。YOLOv11 进一步优化了标签分配策略,简化后处理需求,强化了端到端推理流程。相较于双阶段检测方法和基于 Transformer 的模型,YOLOv11 在速度与精度的平衡上更具优势,尤其在小目标和复杂场景中的表现得到改善。模型系列涵盖从纳米(Nano)到超大型(Extra-Large)的多种规模,满足不同资源需求,其中纳米变体在速度和效率上的提升尤为显著,适合移动设备和嵌入式系统的实时应用。YOLOv11 通过更灵活的数据增强和优化目标,提升了模型鲁棒性和泛化能力,其开源特性(支持 AGPL-3.0 和企业许可)促进了社区协作与商业应用的无缝整合,推动了 YOLO 生态的持续发展。这些进步对自动驾驶、监控系统、医疗成像和工业自动化等领域具有深远影响,YOLOv11 的多任务支持和高效率使其成为解决复杂视觉挑战的综合解决方案。

1.12 YOLOv12:注意力驱动的实时检测新标杆

YOLOv12,由 Ultralytics 于 2025 年发布^[31],是 YOLO 系列的最新迭代,首次将注意力机制全面融入实时目标检测框架,打破了传统卷积神经网络(CNN)在 YOLO 系列中的主导地位,显著提升了检测精度,同时保持了卓越的推理速度。YOLOv12 基于 YOLOv11 的架构基础,通过引入区域注意力模块(Area Attention, A2)、残差高效层聚合网络(RELAN)以及多项架构优化,实现了精度与效率的优异平衡,适用于对象检测、实例分割、姿态估计、定向对象检测(OBB)和图像分类等多种视觉计算机任务。区域注意力模块通过将特征图均匀划分为多个区域(默认 4 个,水平或垂直方向),在保持大感受野

的同时显著降低计算复杂度。R-ELAN 在传统 ELAN 基础上引入残差连接和优化的特征聚合策略,解决了大模型训练中的收敛难题,同时减少计算量,YOLOv12-L 的 FLOPs 降低 31.4×10^9 ,展现了更高的计算效率。YOLOv12 还通过一系列架构优化进一步提升性能:移除位置编码以简化模型结构,调整多层感知机(MLP)比例(从 4 降至 1.2)以平衡注意力与全连接层的计算负载,采用卷积操作替代线性层以提升计算效率,并集成 FlashAttention 以优化内存访问,显著降低了推理过程中的内存开销。YOLOv12 提供从纳米到超大型的 5 种模型规模,满足从资源受限的边缘设备到高性能云平台的不同需求,其中纳米变体的速度提升尤为显著,适合实时应用场景如移动设备和嵌入式系统。YOLOv12 通过精炼的训练流程和多样化的数据增强技术,显著增强了模型在复杂环境下的稳定性和适用范围。其采用 AGPL-3.0 许可并支持企业定制,推动了学术界与产业界的深度合作,加速了 YOLO 生态的持续扩展。与 YOLOv11 的 C2PSA 模块不同,YOLOv12 引入了自适应的区域注意力机制,特别优化了小目标和高密度场景的检测能力,通过动态特征优化和多层次信息整合,成功应对遮挡物体的识别难题。YOLOv12 的多功能性使其在工业自动化等领域的应用前景广阔,凭借高效性与多任务处理能力,成为应对多样化视觉挑战的理想工具。

1.13 YOLO 系列算法小结

数据增强对深度学习至关重要,尤其在目标检测中,它能显著提升模型的泛化能力。YOLO 利用数据增强提升训练效果,包括旋转、裁剪、缩放、翻转等常见方法。YOLOv4 首次引入 Mosaic 技术,通过拼接四张图像生成多样化训练样本,提高小目标检测能力;YOLOv5 优化拼接边界平滑处理,减少噪声干扰。YOLOv7 提出动态标签匹配策略,使数据增强能自动调整正负样本分配。YOLOv10 进一

步引入随机擦除(Random Erasing)和光照变换,增强复杂光照环境下的鲁棒性。

YOLO 是一种经典的单阶段目标检测算法,注重速度与精度的平衡。YOLOv4、YOLOv5、YOLOv6 等版本通过改进网络结构(如 CSPDarknet、EfficientNet)提升性能。损失函数优化方面,YOLOv4 采用 CIoU 损失,结合中心点距离与长宽比优化边界框回归;YOLOv8 提出解耦头结构,独立优化分类与定位任务,COCO 数据集 AP50 提升 3.2%。非极大抑制(NMS)优化方面,YOLOv9 引入软 NMS,减少重叠目标误检。在多尺度检测任务中,YOLOv3 通过特征金字塔(FPN)增强小目标检测能力,YOLOv5 进一步优化自适应锚框匹配,提高检测稳定性。

目标跟踪要求模型在视频帧中识别并跟踪目标。YOLO 结合 ReID(行人重识别)与跟踪算法(如 SORT、DeepSORT),提升目标跟踪精度和稳定性。YOLOv5 输出检测框后,DeepSORT 通过卡尔曼滤波与外观特征匹配,实现跨帧跟踪,在 MOT17 数据集上 MOTA 达 68.5%。YOLOv6-N 通过重参数化技术压缩模型至 4.3×10^6 参数,实现无人机视频实时跟踪,FPS 达 30。YOLOv9 引入可编程梯度信息(PGI),减少长时跟踪中的特征退化问题,ID 切换率降低 18%。

YOLO 不仅用于目标检测,还可拓展至多任务学习。YOLOv8 集成 Mask R-CNN 分支(图 5),实现实例分割。YOLOv7 结合关键点检测头,支持人体姿态估计,可应用于安防与医疗监护。YOLOv10 采用空间通道解耦下采样,优化语义分割。

从 YOLOv1 的单阶段检测到 YOLOv12 的注意力驱动架构,YOLO 系列不断突破实时目标检测的边界,其演化为计算机视觉领域检测树立了新的标杆。本文对 YOLOv1 至 YOLOv12 在开发框架、主干网络、颈部网络和头部网络等方面的演进进行了总结并列于表 1。




图5 用于实例分割的Mask R-CNN框架

Fig. 5 Mask R-CNN framework for instance segmentation

表 1 YOLOv1 到 YOLOv12 的演化
Table 1 Evolution of YOLOv1 to YOLOv12

YOLO 版本	开发者	开发框架	主干网络	颈部网络	头部网络
v1	Redmon 等 ^[4]	DarkNet	GoogleNet 提取特征, Dropout 防止过拟合	—	全连接网络
v2	Redmon 等 ^[14]	DarkNet	Darknet-19 替代 GoogleNet 减少计算量, BN、ReLU 替代 Dropout 提高收敛速度	—	Coupled head
v3	Redmon 等 ^[18]	DarkNet	Darknet-53 加深网络提高特征提取能力, Leaky ReLU 修复“神经元死亡”问题	自下而上的特征金字塔 FPN 融合低层和高层特征信息, 实现多尺度预测	Coupled head
v4	Bochkovskiy 等 ^[21]	DarkNet	Darknet-53 加入 CSP 丰富梯度信息, Mish、Drop-Block 改善梯度消失和梯度爆炸	SPP 改善感受野, PAN 丰富 FPN 多尺度特征	Coupled head
v5	Ultralytics LLC 公司 ^[6]	PyTorch	CSPDarknet-53 引入 Focus 减少信息损失	C3 替换 CBL, 残差丰富特征	Coupled head
v6	美团视觉团队 ^[25]	PyTorch	EfficientRep 提取特征, 减少训练和推理时间	Rep-PAN 提高推理速度	Decoupled head
v7	Wang 等 ^[26]	PyTorch	ELAN 网络控制梯度距离, 进一步加强特征提取能力	SPP 基础上融合更多特征, E-ELAN 提高特征学习能力	Decoupled head
v8	Ultralytics LLC 公司 ^[27]	PyTorch	CSPDarknet-53 引入 C2f 丰富梯度流	C2f 替换 C3, 细化特征融合	Decoupled head
v9	Wang 等 ^[28]	PyTorch	GELAN 网络梯度路径规划保留重要特征	GELAN 保留更多特征信息	Decoupled head
v10	清华大学团队 ^[29]	PyTorch	改进的 CSPDarknet	PAN(路径聚合网络)层, 训练和推理时匹配不同数量的检测头	
v11	Ultralytics LLC 公司 ^[30]	PyTorch	改进的 CSPDarknet53, 融入 C3k2 模块增强梯度流和特征提取	PANet 结合 C3k2 和 C2PSA 模块, 优化多尺度特征融合	Decoupled head
v12	Tian 等 ^[31]	PyTorch, 集成 FlashAttention 优化	R-ELAN(残差高效层聚合网络), 提升多尺度特征提取效率	区域注意力机制(A2 模块), 细化特征融合并降低计算量	优化 Decoupled head, 减少参数, 支持检测与分割

2 YOLO 目标检测算法数据集

2.1 目标检测常用数据集

在目标检测领域,数据集扮演着至关重要的角色。因其包含大量标注好的图像数据,模型可以学习如何识别图像中的不同目标,用于训练目标检测

模型;除了训练数据集,还有验证和测试数据集。验证集用于在训练过程中调整模型的超参数以及评估模型的性能,而测试集则用于在训练完成后对模型进行最终评估。测试集应与训练集独立且分布相似,以确保模型的通用性和鲁棒性。高质量的大规模数据集推动了目标检测领域的发展。例如,

COCO 数据集的复杂性促使了许多创新性模型的产生,这激励研究人员开发更先进的模型来提升性能。

常见的目标检测数据集^[5-6]包含以下几种:

Pascal VOC数据集:它是目标检测领域中最早且最具影响力的数据集之一,最初用于PASCAL VOC挑战赛。常见版本包括VOC 2007和VOC 2012。它包含约20个类别的对象,每张图像中可能有多个目标,每个目标都带有边界框和类别标签。在早期的YOLO系列算法中,VOC数据集是最常用的测试模型性能的数据集。

COCO数据集:COCO数据集是目前目标检测领域中使用最广泛的数据集之一,它由Microsoft发布,具有更高的复杂性和多样性。它包含80个类别,图像中通常包含多个目标,且目标的尺度和姿态变化较大,背景也更加复杂。因此COCO数据集的多样性和复杂性使它成为训练和评估YOLO模型的理想选择,尤其是对模型的泛化能力有较高要求的任务。COCO被广泛用于YOLOv3及以后的版本的训练和测试。

ImageNet数据集:ImageNet是一个大规模的视觉数据集,最初用于图像分类任务。尽管如此,ImageNet也包含了用于目标检测的子集。它包含200个类别的对象,图像数量庞大,适合大规模训练。它通常用于模型的预训练,可以利用其大规模数据集的优势,提升模型的初始性能,这种预训练模型可以在COCO、VOC等数据集上进行进一步微调。

KITTI数据集:KITTI是一个专注于自动驾驶的视觉数据集,由卡尔斯鲁厄理工学院(KIT)和丰田技术研究院(Toyota Technological Institute at Chicago, TTI-C)合作创建。它包含多种任务的标注,如目标检测、立体视觉、光流等。该数据集主要关注自动驾驶场景中的物体,如车辆、行人、骑行者等,注释信息包括2D边界框和3D边界框。上述数据集为YOLO模型的训练和评估提供了数据支持,其多样性直接影响评价指标。以下将介绍YOLO常用的评估指标及其计算方法。

2.2 目标检测模型评价指标

YOLO 算法的评估指标采用目标检测算法最流行的单类平均准确率 AP(Average-Precision), AP的计算方式是计算精确率 P (Precision)和召回率 R (Recall)的曲线,并求取该曲线下的面积, P 、 R 和AP的计算方式分别如下式所示:

$$P = \frac{TP}{TP + FP} \quad (2)$$

$$R = \frac{TP}{TP + FN} \quad (3)$$

$$AP = \int (P \times \frac{R}{1+R}) dR \quad (4)$$

在AP指标基础上,更为精细的评估指标被研究者划分,mAP表示所有类别AP的平均值,APS、APM、APL分别表示数据集中物体尺寸小、中、大为预设标签,AP50表示预设的IoU阈值为大于50%时预测正确,IoU计算方式如下:

$$IOU = \frac{DR \cap GT}{DR \cup GT} \quad (5)$$

其中,DR表示预测边界框;GT表示真实边界框。

此外,为了衡量模型复杂度,采用每秒传输帧数FPS、每秒浮点运算次数FLOPs、参数量Param、推理速度Speed评估YOLO。根据论文与开源平台发布的数据,本文整理了YOLO模型在PASCAL-VOC与MS COCO评估数据集的实验结果于表2和表3。表2在PASCAL VOC上主要通过mAP和FPS衡量早期的YOLOv1与YOLOv2性能;表3为使用AP、AP50、FPS等细分衡量指标对其余版本YOLO在MS COCO上进行评估。

表2 YOLOv1与YOLOv2在PASCAL VOC实验结果
Table 2 Experimental results of YOLOv1 and YOLOv2 on PASCAL VOC

基础模型	模型变体	输入尺寸	mAP	FPS
YOLOv1	Fast YOLO	448×448	52.7	155
	YOLOv1	448×448	63.4	45
	YOLOv2	288×288	69.0	91
YOLOv2	YOLOv2	352×352	73.7	81
	YOLOv2	416×416	76.8	67
	YOLOv2	480×480	77.8	59
	YOLOv2	544×544	78.6	40

3 与其他算法的比较

YOLO作为单阶段检测的代表,与双阶段算法和新兴方法相比,各有优劣,其独特定位在于高效性和工程适用性。

1) 与双阶段算法的比较。双阶段算法(如Faster R-CNN)通过候选区域生成(Region Proposal)和精细回归实现高精度。例如,Faster R-CNN在COCO上的AP约为40,AP50达60,但其两阶段流程导致推理速度慢,FPS通常低于10,难以满足实时需求。相比之下,YOLOv10-E的AP为54.4。然而,双阶段算法对小目标和复杂场景的处理更优,其候选区域机制可生成更多边界框,召回率高于YOLO。例如,Mask

表 3 除 YOLOv1 与 YOLOv2 的 YOLO 在 COCO 的实验结果^[6,31]Table 3 Experimental results of YOLO variants (excluding YOLOv1 and YOLOv2) on COCO^[6,31]

基础模型	模型变体	输入尺寸	AP	AP50	FPS	Params/ 10^6	FLOPs/ 10^9
YOLOv3	YOLOv3	320×320	28.2	51.5	45		
	YOLOv3	416×416	31.0	55.3	35		
	YOLOv3	608×608	33.0	57.9	20		
	YOLOv3-SPP	608×608	36.2	60.6	20		
YOLOv4	YOLOv4	416×416	41.2	62.8	38		
	YOLOv4	512×512	43.0	64.9	31		
	YOLOv4	608×608	43.5	54.7	23		
YOLOv5	YOLOv5-N	640×640	28.0	45.7	602	1.9	4.5
	YOLOv5-S	640×640	37.4	56.8	376	7.2	16.5
	YOLOv5-M	640×640	45.4	64.1	182	21.2	49.0
	YOLOv5-L	640×640	49.0	67.3	113	46.5	109.1
YOLOv6	YOLOv6-N	640×640	35.9	51.2	802	4.3	11.1
	YOLOv6-T	640×640	40.3	56.6	449	15.0	36.7
	YOLOv6-S	640×640	43.5	60.4	358	17.2	44.2
	YOLOv6-M	640×640	49.5	66.8	179	34.3	82.2
	YOLOv6-L-ReLU	640×640	51.7	69.2	113	58.5	144.0
	YOLOv6-L	640×640	52.5	70.0	98	58.5	144.0
YOLOv7	YOLOv7-tiny	416×416	35.2	52.8	273	6.2	5.8
	YOLOv7	640×640	51.2	69.7	118	36.9	104.7
	YOLOv7-X	640×640	52.9	71.1	98	71.3	189.9
	YOLOv7-E6	$1\ 280 \times 1\ 280$	55.9	73.5	54	97.2	515.2
	YOLOv7-D6	$1\ 280 \times 1\ 280$	56.3	73.8	43	154.7	806.8
	YOLOv7-E6E	$1\ 280 \times 1\ 280$	56.8	74.4	35	151.7	843.2
YOLOv8	YOLOv8-N	640×640	37.3	52.6		3.2	8.7
	YOLOv8-S	640×640	44.9	61.8		11.2	28.6
	YOLOv8-M	640×640	50.2	67.2		25.9	78.9
	YOLOv8-L	640×640	52.9	69.8		43.7	165.2
	YOLOv8-X	640×640	53.9	71.0		68.2	257.8
YOLOv9	YOLOv9-T	640×640	38.3	53.1		2.0	7.7
	YOLOv9-S	640×640	46.8	63.4		7.1	26.4
	YOLOv9-M	640×640	51.4	68.1		20.0	76.3
	YOLOv9-C	640×640	53.0	70.2		25.3	102.1
	YOLOv9-E	640×640	55.6	72.8		57.3	189.0
YOLOv10	YOLOv10-N	640×640	38.5	53.8		2.3	6.7
	YOLOv10-S	640×640	46.3	63.0		7.2	21.6
	YOLOv10-M	640×640	51.1	68.1		15.4	59.1
	YOLOv10-B	640×640	52.5	69.6		19.1	92.0
	YOLOv10-L	640×640	53.2	70.1		24.4	120.3
	YOLOv10-E	640×640	54.4	71.3		29.5	160.4
YOLOv11	YOLOv11-N	640×640	39.4	55.3		2.6	6.5
	YOLOv11-S	640×640	46.9	63.9		9.4	21.5
	YOLOv11-M	640×640	51.5	68.5		20.1	68.0
	YOLOv11-L	640×640	53.3	70.1		25.3	86.9
	YOLOv11-X	640×640	54.6	71.6		56.9	194.9

续表

基础模型	模型变体	输入尺寸	AP	AP50	FPS	Params/ 10^6	FLOPs/ 10^9
YOLOv12	YOLOv12-N	640×640	40.6	56.7		2.6	6.5
	YOLOv12-S	640×640	48.0	65.0		9.3	21.4
	YOLOv12-M	640×640	52.5	69.6		20.2	67.5
	YOLOv12-L	640×640	53.7	70.7		26.4	88.9
	YOLOv12-X	640×640	55.2	72.0		59.1	199.0

注:空白表示未查到相关数据或未提供。

R-CNN 在小目标分割上的 Dice 系数可达 0.9,而 YOLOv8 仅为 0.89。这一权衡反映了 YOLO 优先考虑速度,牺牲部分精度以换取实时性。

复杂场景下的差异原因:在小目标检测任务中(如 COCO 中的 AP 指标),双阶段算法表现更优。例如,Mask R-CNN 的 AP 可达 40,而 YOLOv10-N 仅为 38.5。这种差距源于双阶段算法的候选区域机制能生成更多边界框,覆盖小目标的可能性更高,而 YOLO 依赖网格划分和有限的预测框数量,可能遗漏未落入网格中心的微小目标。此外,密集重叠场景(如人群监控等)对算法的鲁棒性提出了更高要求。双阶段检测算法通过多阶段筛选机制,能够有效减少漏检情况,而单阶段检测算法如 YOLO 系列,由于依赖非极大值抑制(NMS)进行后处理,在高度重叠的目标检测中可能出现误删的情况。例如,在多目标跟踪任务中,双阶段检测器结合跟踪算法通常能取得更优的跟踪精度,而 YOLO 系列模型在相同场景下的表现稍逊,这反映了其在密集目标检测方面的局限性。YOLO 可借鉴双阶段算法的区域提议思想,引入自适应网格划分或多阶段候选筛选机制,在不显著牺牲速度的前提下提升小目标和密集场景的召回率。例如,设计动态网格调整策略,根据目标密度自动增加预测框数量。

2) 与 Transformer-based 方法的比较。近年兴起的 Transformer-based 检测算法(如 DETR)引入全局注意力机制,COCO AP 约 45,略高于 YOLOv8-S 的 44.9。DETR 通过自注意力捕捉目标间关系,对小目标和密集场景的处理优于 YOLO,例如其 APS 可达 40 以上。然而,DETR 的计算复杂度高(FLOPs 超 200×10^9),推理速度慢($FPS < 20$),且需要大规模预训练,部署难度较大。YOLOv10-E 凭借端到端设计和轻量化优化(FLOPs 仅 160.4×10^9),在边缘设备上更具优势,但缺乏全局上下文建模能力,限制了其在复杂背景中的表现。在复杂低光照背景(如雾霾、夜间)下,DETR 通过自注意力机制建模全局上下文,能有效区分目标与噪声,其误检率低于 YOLO。例如,在 KITTI 自动驾驶数据集的夜间场景中,DETR 的 mAP 可达 65%,而 YOLOv10 达不到这个数值,反映了 YOLO 缺

乏全局特征建模能力。在多目标交互场景(如体育比赛视频),DETR 利用注意力机制捕捉目标间空间关系,MOTA 可提升 5%~10%,而 YOLO 依赖局部特征提取,易受遮挡干扰。YOLO 可融合轻量化 Transformer 模块(如 Swin Transformer 的局部注意力),增强全局上下文感知能力,同时控制计算成本。针对复杂背景,可以引入背景抑制的预处理模块,或通过自监督学习提升模型对噪声的鲁棒性。

4 发展驱动力与局限性

4.1 发展驱动力

YOLO 从 2016 年的 v1 迭代至 2025 年的 v12,在短短的 10 年间实现快速演进,其背后有多种因素共同推动。这种快速发展不仅体现了深度学习领域的技术活力,也反映了算法设计与应用需求的紧密结合。

1) YOLO 的快速迭代得益于深度学习核心技术的持续优化。首先,卷积神经网络(CNN)的改进为 YOLO 提供了更强的特征提取能力。例如,v3 引入的 DarkNet-53 借鉴 ResNet 的残差连接,缓解深层网络中的梯度消失问题,使模型能提取更丰富的语义信息;v4 和 v5 融合 CSPNet,通过跨阶段特征分割优化梯度流,进一步提升性能。其次,损失函数的改进显著增强了检测精度,如 v4 采用的 CIoU 损失综合考虑边界框的中心距离、长宽比和重叠面积,相较 v1 的 MSE 损失,回归精度提高约 10%。此外,数据增强策略的创新也至关重要。v4 首次引入 Mosaic 增强,通过拼接四张图像生成多样化样本,增强模型对小目标和复杂背景的适应性,COCO AP 提升约 3%。与此同时,大语言模型(如 DeepSeek)的兴起为 YOLO 的优化提供了新助力,其强大的代码生成与分析能力可辅助研究者快速验证网络结构、调试超参数并生成数据处理脚本,从而加速算法设计与实验迭代。这些技术进步共同为 YOLO 性能的持续跃升奠定了坚实基础。

2) 开源社区的活跃性和开发框架的易用性大

幅加速了 YOLO 的迭代。v5 转向 PyTorch 框架后, 受益于其动态计算图和丰富 API, 降低了开发门槛, 使研究者能快速实现新想法并测试改进。例如, YOLOv5 的 Focus 模块最初通过切片操作优化输入分辨率, 后因硬件兼容性问题改为标准卷积, 这一调整得益于 PyTorch 的灵活性。此外, 开源社区提供了丰富的预训练模型和工具链, 如 Ultralytics 的 YOLOv5/v8 仓库, 吸引了全球开发者参与优化。相比之下, v1-v3 使用 DarkNet 框架时, 社区支持较弱, 迭代速度较慢。社区生态的繁荣使 YOLO 从 v5 起进入快速发展期, 例如 v6 由美团团队开发, v10 由清华大学贡献, 体现了协作创新的力量。

3) 实时性与边缘计算需求的激增是 YOLO 快速发展的外部驱动力。在自动驾驶领域, 车辆需在毫秒级内识别行人、障碍物等目标, 推动 YOLO 不断优化速度, 如 v10 通过端到端设计将推理延迟降至新低, FPS 在嵌入式设备上仍超 30。边缘计算的兴起也要求模型轻量化, v5 提供的多规模模型(Nano 到 XLarge)和 v6 的重参数化技术显著降低参数量(如 v6-N 仅 4.3×10^6), 适配无人机、物联网设备等场景。此外, 行业定制化需求促使 YOLO 适配特定任务, 如医疗影像中的肿瘤检测需高精度分割, v8 因此引入解耦头和实例分割分支。这些需求驱动 YOLO 从通用检测向多场景优化演进。

4.2 当前局限性

尽管进步显著, YOLO 仍面临挑战: 小目标召回率低、密集场景漏检率高、复杂背景下的鲁棒性不足。这些问题限制其在极端条件下的表现。

1) YOLO 对小目标的检测能力不足, 尤其在早期版本中表现明显。这主要源于网格划分机制: 小目标可能未落在网格中心, 导致漏检; 此外, 早期的浅层主干网络(如 v1 的 GoogleNet)难以捕捉细粒度特征。虽然 v3 引入 FPN、v9 优化特征融合, 但与双阶段算法相比仍有差距。这一问题在遥感图像或密集人群监控中尤为突出。

2) 在目标密集或重叠的场景中, YOLO 易产生漏检。例如, 当多个目标中心落入同一网格(如 v1 的 7×7 划分), 模型只能预测有限数量的边界框, 导致部分目标被忽略。尽管 v2 引入先验框、v10 优化标签分配策略, 缓解了部分问题, 但密集场景(如拥挤街道或细胞显微镜图像)仍挑战其能力。NMS(非极大抑制)的冗余抑制也可能误删重叠目标, 软 NMS 虽有改进, 但计算成本增加。

3) YOLO 在复杂背景或光照变化下的鲁棒性有限。例如, 在强光、雾霾或夜间条件下, 特征提取

易受干扰, 导致误检率上升。v3 的 DarkNet-53 虽提升语义表达, 但缺乏针对背景噪声的自适应机制。相比之下, 基于 Transformer 的模型(如 DETR)通过全局建模更具优势。数据增强(如 v10 的随机擦除等)缓解了部分问题, 但未从根本上解决复杂环境下的泛化难题。

这些局限性表明, YOLO 在极端条件下的表现仍有优化空间, 需要通过结构创新或数据策略加以突破。

5 结 语

YOLO 算法自 v1 问世以来, 历经十年快速演进, 已从实时目标检测的先锋演变为多任务智能的前沿代表。本文系统回顾了 YOLO 从 v1 到 v12 的技术演进历程, 剖析了其网络结构优化、损失函数改进及数据增强策略的持续进步。YOLO 以单阶段设计的简洁性和高效性为核心优势, 在速度与精度的平衡上不断突破, 逐步拓展至农业监测、工业检测、医疗影像分析等多领域应用, 展现出强大的工程适用性与场景适配能力。

YOLO 的快速发展得益于深度学习技术的革新、开源社区的协作以及实时性需求的推动。v1 开创性的回归思想奠定了基础, 后续版本通过 DarkNet、CSPNet、GELAN 等主干网络的迭代, 以及 FPN、PAN 等特征融合结构的引入, 显著提升了检测性能。Mosaic 增强、CIoU 损失及解耦头等创新进一步优化了模型的鲁棒性和精度。与双阶段算法(如 Faster R-CNN)和 Transformer-based 方法(如 DETR)相比, YOLO 在实时性与轻量化上占据优势, 但在小目标检测、密集场景处理及复杂背景适应性上仍有不足。YOLO 的局限性也为其未来发展指明了方向。随着边缘计算和多任务需求的增长, YOLO 有望进一步向轻量化与多功能集成方向演进, 通过融合新兴技术提升在精度敏感任务中的潜力。轻量化 Transformer 模块的引入是重要趋势。例如, 借鉴 Swin Transformer 的局部注意力机制, YOLO 可增强全局上下文建模能力, 同时通过优化计算复杂度适配边缘设备。生成式 AI 可生成多样化合成数据, 增强 YOLO 在复杂场景(如夜间、雾霾等)的鲁棒性。此外, YOLO 可参考 RT-DETR 的高效注意力机制, 设计统一的端到端框架, 整合目标检测、实例分割和关键点检测等任务, 适配自动驾驶和增强现实(AR)等场景。开源社区的协作和深度学习技术的进步将继续推动 YOLO 在实

时性、精度和场景适配性上的突破,为智能化目标检测提供更广阔的应用前景。

YOLO 系列算法的十年演进不仅是目标检测领域技术进步的缩影,也反映了深度学习与实际应用深度结合的趋势。未来通过结构创新与应用定制化,YOLO 有望在更多复杂场景中发挥关键作用,推动计算机视觉技术的智能化进程。

参考文献:

- [1] FELZENSZWALB P F, GIRSHICK R B, MCALLESTER D, *et al.* Object detection with discriminatively trained part-based models [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2010, **32**(9): 1627-1645. DOI: 10.1109/TPAMI.2009.167.
- [2] KRIZHEVSKY A, SUTSKEVER I, HINTON G. Imagenet classification with deep convolutional neural networks[DB/OL]. [2025-01-02]. https://proceedings.neurips.cc/paper_files/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf.
- [3] 吕璐, 程虎, 朱鸿泰, 等. 基于深度学习的目标检测研究与应用综述[J]. *电子与封装*, 2022, **22**(1): 72-80. DOI: 10.16257/j.cnki.1681-1070.2022.0114.
- LÜ L, CHENG H, ZHU H T, *et al.* Progress of research and application of object detection based on deep learning [J]. *Electronics & Packaging*, 2022, **22**(1): 72-80. DOI: 10.16257/j.cnki.1681-1070.2022.0114 (Ch).
- [4] REDMON J, DIVVALA S, GIRSHICK R, *et al.* You only look once: Unified, real-time object detection[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE Press, 2016: 779-788. DOI: 10.1109/CVPR.2016.91.
- [5] 毛少华, 王文东. 基于深度学习的 YOLO 系列物体检测算法研究综述[J]. *延安大学学报(自然科学版)*, 2024, **43**(2): 88-95. DOI: 10.13876/J.cnki.ydnse.230044.
- MAO S H, WANG W D. Research review of YOLO series object detection algorithms based on deep learning [J]. *Journal of Yan'an University (Natural Science Edition)*, 2024, **43**(2): 88-95. DOI: 10.13876/J.cnki.ydnse.230044 (Ch).
- [6] 米增, 连哲. 面向通用目标检测的 YOLO 方法研究综述[J]. *计算机工程与应用*, 2024, **60**(21): 38-54. DOI: 10.3778/j.issn.1002-8331.2404-0130.
- MI Z, LIAN Z. Review of YOLO methods for universal object detection[J]. *Computer Engineering and Applications*, 2024, **60**(21): 38-54. DOI: 10.3778/j.issn.1002-8331.2404-0130 (Ch).
- [7] WANG L L, LI J J, KANG F. Crack location and degree detection method based on YOLOX model [J]. *Applied Sciences*, 2022, **12**(24): 12572. DOI: 10.3390/app122412572.
- [8] WANG C, YE H I, LIAO H M. You only learn one representation: Unified network for multiple tasks [J]. *Journal of Information Science and Engineering*, 2023, **39**(3): 691-709. DOI: 10.6688/JISE.202305_39(3).0015.
- [9] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[C]//International Conference on Learning Representations. San Diego: Computational and Biological Learning Society, 2015. DOI: 10.48550/arXiv.1409.1556.
- [10] WANG C Y, BOCHKOVSKIY A, LIAO H M. Scaled-YOLOv4: Scaling cross stage partial network[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE Press, 2021: 13024-13033. DOI: 10.1109/CVPR46437.2021.01283.
- [11] SZEGEDY C, LIU W, JIA Y Q, *et al.* Going deeper with convolutions [C]//2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE Press, 2015: 1-9. DOI: 10.1109/CVPR.2015.7298594.
- [12] EVERINGHAM M, VAN Gool L, WILLIAMS C K I, *et al.* The pascal visual object classes (VOC) challenge [J]. *International Journal of Computer Vision*, 2010, **88**(2): 303-338. DOI: 10.1007/s11263-009-0275-4.
- [13] YU J H, JIANG Y N, WANG Z Y, *et al.* UnitBox: An advanced object detection network [C]//Proceedings of the 24th ACM International Conference on Multimedia. New York: ACM, 2016: 516-520. DOI: 10.1145/2964284.2967274.
- [14] REDMON J, FARHADI A. YOLO9000: Better, faster, stronger[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE Press, 2017: 6517-6525. DOI: 10.1109/CVPR.2017.690.
- [15] IOFFE S, SZEGEDY C. Batch normalization: Accelerating deep network training by reducing internal covariate shift [C]//Proceedings of the 32nd International Conference on International Conference on Machine Learning. Lille: PMLR, 2015: 448-456. DOI: 10.5555/3045118.3045167.
- [16] LIN T Y, MAIRE M, BELONGIE S, *et al.* Microsoft COCO: Common objects in context [C]//Computer Vision — ECCV 2014. Cham: Springer, 2014: 740-755. DOI: 10.1007/978-3-319-10602-1_48.
- [17] LI Z, YANG L, ZHOU F. FSSD: Feature fusion single shot multibox detector[DB/OL]. [2025-01-03]. <https://arxiv.org/pdf/1712.00960>.
- [18] REDMON J, FARHADI A. YOLOv3: An incremental improvement[EB/OL]. 2018: arXiv: 1804.02767. <https://arxiv.org/abs/1804.02767>.
- [19] HE K, ZHANG X, REN S, *et al.* Spatial pyramid pooling in

- deep convolutional networks for visual recognition[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2015, **37** (9): 1904–1916. DOI: 10.1109/TPAMI.2015.2389824.
- [20] MIKOLOV T, KOMBRINK S, BURGET L, *et al.* Extensions of recurrent neural network language model[C]//2011 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). New York: IEEE Press, 2011: 5528–5531. DOI: 10.1109/ICASSP.2011.5947611.
- [21] BOCHKOVSKIY A, WANG C Y, LIAO H M. YOLOv4: Optimal speed and accuracy of object detection[EB/OL]. 2020: arXiv: 2004.10934. <https://arxiv.org/abs/2004.10934>.
- [22] LIU S, QI L, QIN H F, *et al.* Path aggregation network for instance segmentation[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE Press, 2018: 8759–8768. DOI: 10.1109/CVPR.2018.00913.
- [23] WANG C Y, LIAO H Y M, WU Y H, *et al.* CSPNet: A new backbone that can enhance learning capability of CNN [C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). New York: IEEE Press, 2020: 1571–1580. DOI: 10.1109/CVPRW50498.2020.00203.
- [24] YUN S, HAN D, CHUN S, *et al.* CutMix: Regularization strategy to train strong classifiers with localizable features[C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV). New York: IEEE Press, 2019: 6022–6031. DOI: 10.1109/ICCV.2019.00612.
- [25] LI C Y, LI L L, JIANG H L, *et al.* YOLOv6: A single-stage object detection framework for industrial applications [EB/OL]. 2022: arXiv: 2209.02976. <https://arxiv.org/abs/2209.02976>.
- [26] WANG C Y, BOCHKOVSKIY A, LIAO H M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE Press, 2023: 7464–7475. DOI: 10.1109/CVPR52729.2023.00721.
- [27] SOHAN M, SAI RAM T, RAMI REDDY C V. A review on YOLOv8 and its advancements[C]//Data Intelligence and Cognitive Informatics. Singapore: Springer, 2024: 529–545. DOI: 10.1007/978-981-99-7962-2_39.
- [28] WANG C Y, YEH I H, MARK LIAO H Y. YOLOv9: Learning what you want to learn using programmable gradient information[C]//Computer Vision — ECCV 2024. Cham: Springer, 2025: 1–21. DOI: 10.1007/978-3-031-72751-1_1.
- [29] WANG A, CHEN H, LIU L, *et al.* Yolov10: Real-time end-to-end object detection[J]. *Advances in Neural Information Processing Systems*, 2024, **37**: 107984–108011. DOI:10.48550/arXiv.2405.14458.
- [30] KHANAM R, HUSSAIN M. YOLOv11: An overview of the key architectural enhancements [EB/OL]. 2024: arXiv: 2410.17725. <https://arxiv.org/abs/2410.17725>.
- [31] TIAN Y J, YE Q X, DOERMANN D. YOLOv12: Attention-centric real-time object detectors[EB/OL]. 2025: arXiv: 2502.12524. <https://arxiv.org/abs/2502.12524>.

□