

可在 TFT-LCD 面板中实现多背景视觉细微缺陷检测的 YOLO-DSM 方法*

孔祥飞¹, 王森¹, 赵林², 陈明方¹

1. 昆明理工大学机电工程学院, 云南 昆明 650500
2. 河南中烟工业有限责任公司, 河南 郑州 450000

摘要: 提出了一种基于 YOLO-DSM 深度学习图像检测模型。首先, 在每个 Dark 模块后引入 HMU 模块, 以提高 TFT-LCD 面板上目标缺陷的检测精度。将原始 SPP 替换为 SSMA, 使得网络更加关注背景低对比度目标。其次, 引入 DSM 模块以帮助网络增强有用特征且抑制无用特征, 增强语义信息的集成。最后, 用 ODConv 模块替换原始网络的下采样卷积, 细化局部特征映射, 实现局部缺陷特征的充分提取。在自制的 TFT-LCD 缺陷数据集中, 与当前较为先进的算法进行对比。结果表明, YOLO-DSM 网络在 mAP 精度方面达到了 97.40%, 且 FPS 达到了 77.42 帧, 可满足 TFT-LCD 缺陷任务检测要求。

关键词: 视觉细微缺陷; YOLO-DSM; 全维动态卷积; SCSE 注意力机制

中图分类号: TP394.1; TH691.9 **文献标志码:** A **文章编号:** 2097-0137(2025)02-0129-09

YOLO-DSM method for detecting multi-background visual micro-defects in TFT-LCD panels

KONG Xiangfei¹, WANG Sen¹, ZHAO Lin², CHEN Mingfang¹

1. Faculty of Mechanical and Electrical Engineering, Kunming University of Science and Technology, Kunming 650500, China
2. Henan Tobacco Industry Company Limited, Zhengzhou 450000, China

Abstract: A deep learning image detection model based on You Only Look Once-Double Spatial-Squeeze Module (YOLO-DSM) is proposed. First, the Hierarchical Mixed-scale Unit (HMU) module is introduced after each Dark module to improve the detection accuracy of target defects on TFT-LCD panels. The original Spatial Pyramid Pooling (SPP) is replaced with Simple Spatial Mlp Attention (SSMA) to enable the network to focus more on targets with low contrast against the background. Second, the Double Spatial-Squeeze Module (DSM) is introduced to help the network enhance useful features and suppress useless ones, thereby enhancing the integration of semantic information. Finally, the Omni-dimensional Dynamic Convolution (ODConv) module replaces the down-sampling convolution of the original network to refine local feature mapping and achieve full extraction of local defect features. In comparative experiments on a self-made TFT-LCD defect dataset, the YOLO-DSM

* 收稿日期: 2024-08-20

录用日期: 2024-09-05

网络首发日期: 2024-10-14

基金项目: 国家自然科学基金(52065035)

作者简介: 孔祥飞(1998年生), 女; 研究方向: 图像处理;

E-mail: kxf1494079475@163.com

通信作者: 陈明方(1975年生), 男; 研究方向: 机器人控制算法;

E-mail: mfchen111@kust.edu.cn

增强出版



ZR20240261

全文阅读



ZR20240261

network achieved an mAP accuracy of 97.40% and an FPS of 77.42 frames. This meets the requirements of TFT-LCD defect detection tasks.

Key words: visual micro-defects; YOLO-DSM; omni-dimensional dynamic convolution; spatial and channel squeeze & excitation

薄膜晶体管液晶显示器(TFT-LCD, thin film transistor liquid crystal display)制造流程繁杂且工艺复杂,对生产环境的要求极为严格。生产过程中任何细微的缺陷均可导致 TFT-LCD 面板出现不可修复的质量问题。目前, TFT-LCD 面板缺陷的分类算法主要是包括特征提取和分类器识别的两阶段自动光学检测方法。这些方法将研究对象从图像矩阵格式转换为特征向量格式,分类器识别将上一阶段提取到的缺陷特征输入以支持向量机(SVM)为主的各类分类器中,实现缺陷分类(Dalal et al., 2005)。Huang et al.(2012)引入了颜色和 SIFT 特征以描述缺陷区域,将每个特征分开学习后可用基于多核卡方核函数的 SVM 获得最佳分类器。但上述方法极为依赖人为选取的特征,对场景的变化比较敏感。

基于机器视觉的缺陷检测方法大致分为基于背景重建和深度学习两类。在图像背景重建方面, Yang et al.(2018)提出一种基于阈值预判和区域梯度水平集的 mura 缺陷视觉检测方法。为了去除背景的不均匀度, Ngo et al.(2017)提出了一种基于背景重建和评估 mura 指数水平的自动检测方法。Sun et al.(2019)使用均值偏移和水平集级联的方式检测 mura 缺陷,但级联也进一步增加了计算时间和资源消耗。在小规模场景数据集的应用中, Wang et al.(2023)设计了一种结合卷积自注意力模块和可变形卷积模块的模型。Chen et al.(2023)将 Resnet 与高效通道注意力机制相融合分割 LCD 缺陷,但模型结构的复杂性导致其在小数据集上出现过拟合。因此, Mao et al.(2023)提出了一种具有特性提取和特征测量模块的注意力关系网络,将注意力机制应用于度量学习以测量特征之间的距离,但注意力机制和度量学习在训练过程中需要精细调节,增加了训练难度和时间。Chang et al.(2022)将卷积神经网络与自动光学检测相结合以识别 LCD 像素缺陷,而光学检测对环境光照条件较为敏感。Chen et al.(2022)对 YOLOV4 (Bochkovskiy et al., 2022)进行改进,增加空间金字塔融合模块和 SE 模块,在增加网络的感受野的同时提高了缺陷检测的准确率。Lin et al.(2022)将

深层通道注意力分类网络作为特征提取工具,结合卷积神经网络的对抗性训练算法,实现了少镜头场景下的 mura 缺陷检测。以上这些方法在检测缺陷方面虽然有效,但存在复杂背景适应性差、计算复杂度高、参数设置敏感、环境依赖性强等问题。因此,本文提出了 YOLO-DSM 网络模型,以实现显示器的高效检测。

1 YOLO-DSM 网络改进算法

1.1 YOLO-DSM 框架

本文提出的 YOLO-DSM 网络引入了 HMU、SSMA、SCSE、ODConv 和 SCAM 模块,并将 SCSE 和 SCAM 整合为 DSM 模块,如图 1 所示。第一部分 Backbone 中 Dark 模块后引入 HMU 模块,能缓解网络在经过 Dark 模块后可能出现的细节信息丢失问题。为了避免网络深度增加可能导致的微小缺陷目标边缘信息丢失问题,在 Backbone 中将原始的 SPP 替换成 SSMA 模块。缺陷图像输入到 Backbone 部分,将获得 feat1、feat2 和 feat3 三个特征层映射。

由于显示器缺陷目标在图像中的占比很小,卷积计算大多是在无关背景区域进行。为此,在第二部分 DSMFPN 中引入 SCSE、DSM 和 ODConv 模块。SCSE 注意力模块通过预先学习的方式提前校准特征图不同位置的权重,以提高有目标子区域的重要性。SCAM 模块可在通道信息及长距离空间信息下进行特征提取,并通过学习一组权重突出特征图中各个有用元素的作用。针对低信噪比、背景低对比度、色彩弱化等缺陷导致图像缺陷特征难以提取的问题,引入全维动态卷积(ODConv)代替普通卷积进行特征提取。ODConv 在不同空间维度上自适应地调整卷积核,从而有效提升特征提取的质量和丰富度。在进行特征融合后,可以利用 SCSE 模块进行再次的特征层权重分配。

第三部分 Head 输出 3 个尺度的特征图用于检测小、中和大物体。第四部分 Prediction 通过对目标进行检测,获得目标的类别信息和位置信息。




图1 YOLO-DSM网络结构

Fig. 1 YOLO-DSM network architecture

1.2 HMU 模块

由于多背景干扰导致显示器缺陷检测精度较低,而显示器的黑点mura缺陷占比较大,因此需要引入HMU模块以增强特征提取能力。HMU模块通过级联融合输入特征,使浅层特征与深层特征能够有效结合,提取出更丰富的语义信息,增强信道间的信息交互和特征细化能力。该模块能够更好地整合显示器中的微小特征,并最大程度地保留上下文信息。

如图2所示,将每个Dark模块得到的特征输入到HMU模块(Pang et al., 2022)后,可以通过卷积、归一化BN、激活函数ReLU、分割、分组迭代和信道调制对特征进行整合。分组迭代可通过 1×1 卷积扩张特征图的通道数。将特征沿通道维度

分为 M 组 $\{m_j\}_{j=1}^M$ 后,各组之间的特征交互通常以迭代方式进行。第一组 $\{m_1\}$ 经过卷积块后被分成三个特征数据集。第一个数据集用于与下一组进行信息交换,另外两个用于信道调制。这种调制方式可以将特征通过一个卷积网络整合并转换为特征调制向量 R ,再与另一个特征 $\{m_j'^3\}_{j=1}^M$ 进行加权和卷积处理。在第 $j(1 < j < M)$ 组中,沿着信息通道将特征 m_j 与上一组的特征 $m_{j-1}'^1$ 进行连接、卷积和分割操作。该特征组同样被分为三个特征集。在此需要注意的是,输入形式与前几组相似的 M 组输出只包含 $m_M'^2$ 和 $m_M'^3$ 。这种迭代混合策略旨在从不同的通道中学习到关键信息,以获得更强的特征表征能力。




图2 HMU 模块

Fig. 2 HMU module

1.3 SSMA 模块

在显示器缺陷检测中,低对比度的缺陷目标易被网络误判为背景。为提升检测精度并抑制背景干扰,本文将基准模型的SPP模块替换成图3的SSMA模块。该模块由简化空间金字塔池化(SSPP)、多层感知机(MLP)、Attention模块组成。输入特征首先经过包括 1×1 卷积进行归一化(BN)、激活函数FReLU和平均池化的SSPP模块。平均池化降低了特征尺寸,但丢失了细节信息。为尽量恢复有用信息,引入MLP模块和Attention。MLP模块包含基于深度卷积和基于信道MLP的残差模块。信道MLP模块的输入是深度卷积模块的输出。每个模块之后有通道缩放和Dropout操作,以提高特征泛化和鲁棒性。通过空间和信道特征信息的交互,MLP能更好地建立特征的长依赖、全局关系和空间关系,从而捕捉全局上下文信息。然而,Dropout会导致一些重要细节信息丢失,Attention模块通过聚焦关键特征,弥补信息缺失,提高整体特征的代表能力和检测精度。通过这种设计,SSMA模块能够更好地处理低对比度缺陷。




图3 SSMA模块

Fig. 3 SSMA module

1.4 SCSE 模块

在DSMFpn部分引入图4所示的SCSE(Roy et al., 2018)注意力机制,以此丰富图像中的语义信息。该注意力机制模块由CSE和SSE模块以并行加和的形式组成,具备同时作用于空间和通道的双重特性。SSE模块首先对特征图进行 1×1 卷积,将 $[C, H, W]$ 变为 $[1, H, W]$ 。使用Sigmoid进行激活后,可以得到空间注意力图。将其施加到原始特征图中,完成空间的信息校准。CSE模块首先将特征图通过全局平均池化,使用 1×1 卷积进行信息处理后得到多维的向量,使用Sigmoid函数进行归一化,最后通过channel-wise相乘,得到经过信息校准的特征图。




图4 SCSE模块

Fig. 4 SCSE module

1.5 DSM 框架

由于缺陷的尺寸和形状各异,引入图5所示的SCAM模块,结合通道和空间信息进行特征提取。该模块学习权重以突出有用元素并抑制无用元素,使网络能够融合更多有用特征。SCSE和SCAM模块整合为图6所示的DSM模块。DSM不仅增强了对细微缺陷的检测能力,还更有效地融合了图像中的关键信息。




图5 SCAM模块

Fig. 5 SCAM module



图6 DSM模块

Fig. 6 DSM module

坐标注意力机制(CA)(Hou et al., 2021)通过赋予重要通道和微小特征更大权重,嵌入方向感知、位置感知和跨通道信息。本文改进了CA,去除

BN, 直接进行 SiLU 激活。输入特征图先经过 SCSE 模块, 再输入 SCAM 模块, 增强空间和通道信息融合以精确定位缺陷。DSM 模块充分发挥两者在特征增强和信息捕捉方面的优势, 提高了整体的检测性能。

1.6 ODConv 模块

图7所示的ODConv模块(Li et al., 2022)首先通过全局平均池化层将输入特征 X 压缩成特征向量, 再通过全连接层将其映射到低维空间, 以降低复杂度。使用 ReLU 函数去除负值后, 建立4个分支从而生成 ODConv 卷积模块的4类注意力标量。Branch1 预测每个卷积核不同空间位置权重, 精确定位缺陷区域。Branch2 预测每个卷积核不同

输入通道权重, 有效分析通道内缺陷的结构特征, 实现不同背景下缺陷颜色特征精确提取。Branch3 预测不同输出通道权重, 避免卷积运算时通道间缺陷特征信息丢失。Branch4 预测不同卷积核权重, 细化不同背景下缺陷的局部特征。Branch1、Branch2 和 Branch3 分支经过 Sigmoid 激活函数生成归一化注意力标量。Branch4 分支经过 Softmax 激活函数生成归一化注意力标量, 实现对不同背景下不同形状和规则特征分类。最后, 通过逐元素加和操作连接各分支的输出。因此, 本文的网络模型通过对输入特征的卷积核调制, 确保能够充分提取多类背景下的多类缺陷特征, 从而提高检测精度。




图7 ODConv 模块

Fig. 7 ODConv module

2 实验与结果

2.1 采集数据集和评价指标

实验样本来源于车间搜集的有缺陷的显示器产品, 数据采集场景如增强出版:附图1所示。产品缺陷主要包括黑点 mura (Black spot mura)、白点 mura (White spot mura)、异物 (Foreign matter)、线 mura (Line mura)、漏光 (Light leakage) 和白线 mura

(White line mura) 共六类。采集的图像分辨率分别为 2590×1942 和 3072×2048 。在实验样本上运行测试软件, 并在切换蓝、白、灰、红、绿和 32 灰阶等显示背景的同时进行图像采集。图8中仅展示了各个类型显示器缺陷的部分背景颜色。

本次显示器缺陷数据集包含 2 062 幅有效缺陷图像, 其中 1 448 幅分辨率为 2590×1942 , 包含白点 mura 248 幅, 黑点 mura 849 幅, 线 mura 185 幅,




图8 显示器缺陷数据集

Fig. 8 Display defect data set

异物318幅。614幅分辨率为3 072×2 048, 包含漏光326幅、白线mura 247幅。对交叉缺陷图像细分后, 人工归纳出152幅含有多个或多类缺陷的图像。利用Labelimg软件进行人工标注, 将数据集分为1 669幅训练图像、186幅验证图像和207幅测试图像。所有检测算法采用同一个数据集进行实验。

网络模型训练在NVIDIA GeForce RTX 4070Ti上进行。将VOC数据集提供的预训练权重加载至本文构建的网络框架中, 利用显示器缺陷数据集进行网络模型的参数微调, 通过不断调参和迭代训练获得检测效果相对最佳的权重参数。迭代训练时, 图像输入尺寸为640×640。训练过程为不冻结主干训练方式并训练所有网络, 参数批量大小为16, 训练次数为210轮次。为了全面地评价改进网络的性能, 采用目标检测任务中的常用指标Precision(P), Recall(R), mAP, AP, F1, FPS, MB来评估模型检测效果。

2.2 消融实验

消融实验验证了YOLO-DSM网络架构的性能, 增强出版:附表1列出了12种不同组合模式的实验结果。可以看出, 将SPP替换成SSMA模块后, mAP提高了1.28%, 白点mura和白线mura的检测精度分别提升4.17%和4.78%。漏光略微下降1.1%。表明SSMA增强了对低对比度背景下目标的细节关注。

加入SCSE模块后, mAP提高了0.97%, 黑点mura、白点mura和漏光的精度分别提升3.86%、4.17%和2.73%, 但线mura的精度下降5.27%, 表明SCSE增强了对小目标的关注, 但对细长目标不敏感。加入SCAM模块后, mAP提高了1.35%, 白点mura和漏光检测精度分别提升4.17%和2.56%, 表明SCAM更关注与背景相似的目标。加

入ODConv模块后, mAP提高了0.77%, 白点mura和漏光检测精度分别提升4.17%和2.82%。白线mura的精度下降3.66%, 表明ODConv模块增强了小目标的细节捕捉, 但对背景相似的细长目标进行了过度抑制。加入HMU模块后, mAP提高了1.11%, 黑点mura和漏光检测精度分别提高了3.68%和2.8%。说明HMU增强了对边缘微小特征的关注。


将HMU模块与SCSE结合(HMU+SCSE), 白线mura检测精度提升4.25%, 将HMU与SSMA结合(HMU+SSMA), 白线mura和漏光检测精度分别提升了3.43%和2.13%, 进一步加入SCAM(HMU+SSMA+SCAM), 漏光检测精度提升了4.45%, 加入SCSE后(HMU+SSMA+SCAM+SCSE), 白点mura、白线mura和漏光精度分别提升了4.17%、3.96%和2.72%。说明背景抑制得到了有效缓解, 增强了对低对比度目标的关注。

最终加入ODConv(HMU+SSMA+SCAM+SCSE+ODConv), mAP提高2.27%, 白点mura、白线mura和漏光的检测精度分别提升4.17%、5.44%和2.56%。HMU降低了FPS并增加了参数量, 但仍满足显示器检测需求。如果不加入HMU(SSMA+SCAM+SCSE+ODConv), 网络的mAP精度减少1.24%, 除白点mura和漏光的检测精度提升外, 其余的检测精度几乎没变化, 验证了HMU对网络的重要性。特别是对于黑点mura的检测。图9展示了各模块对目标的关注程度。这些结果表明, YOLO-DSM在显示器缺陷检测中显著提高了检测精度, 同时保持了高检测速度。

2.3 不同缺陷检测算法的比较

为进一步验证YOLO-DSM网络的检测性能, 选用YOLO系列YOLOX_nano、YOLOX_tiny、YOLOX_s、YOLOX_m、YOLOV5(Zhu et al., 2021)、YOLOV7(Wang et al., 2023)、Retinanet(Lin et al., 2017)、YOLOV8、Chenping(Chen et al., 2023)等算法进行显示器缺陷检测性能对比, 如增强出版:附表2所示。所有实验均使用同一数据集训练且每次训练次数均为210。由于GPU算力有限, 不同算法采用不同的批量大小(Retinanet为8, YOLOV7为4, YOLOX_nano、YOLOX_tiny、YOLOX_s、YOLOX_m、YOLOV5_s、YOLOV8_s和Chenping均为16)。图10展示了不同算法在六类缺陷检测中的F1、Precision和Recall指标。

从实验结果分析可知, YOLO-DSM在很多方面的表现优于其他算法。增强出版:附表2中,



(上到下依次为黑点 mura, 异物, 漏光, 线 mura, 白线 mura, 原始图片。从左至右依次为增强出版:附表 1 中的 YOLOX_s, Add A, Add H, Add S, Add C, Add O, Add H+S, Add H+A+C, Add A+H, Add A+H+C+S, Add A+C+S+O, Add A+H+C+S+O)

图 9 消融实验热力图

Fig. 9 Ablation experiment heatmap




图 10 F1-P-R 结果

Fig. 10 F1-P-R results

YOLO-DSM 的 mAP 比其他算法分别高出 3.96%、2.68%、2.27%、2.17%、20.12%、18.29%、25.4%、23.45% 和 65.7%。在检测六类缺陷的结果中，YOLOX 系列模型整体优于其他算法；YOLOV5_s 在检测线 mura 和漏光时 Precision 虽然达到了 100%，但其 Recall 仅有 2.04% 和 2.94%，F1 仅为 0.04 和 0.06。YOLOV8_s 在检测黑点 mura、线 mura 和漏光时，Precision 分别达到了 95.60%、100% 和 97.14%，但 Recall 仅分别为 34.80%、1.15% 和 37.36%，F1 分别为 0.51、0.02 和 0.54。YOLOV7 在检测线 mura 缺陷时的 F1 为 0，在检测白线 mura 时 Precision 虽然达到了 100%，但 Rercall 仅为 2.94%，F1 仅为 0.06。Chenping 在检测白线 mura 时，Precision 达到了 85.71%，但 Rercall 却仅为 26.09%，F1 为 0.4。

从图 10 可以看出，除了检测白线 mura 和漏光时 Precison 略低于 Retinanet，本文提出的 YOLO-DSM 在 Precision、Recall 和 F1 指标方面均优于其他算法。这表明 YOLO-DSM 在显示器缺陷检测中具有显著优势，极大提高了检测精度和鲁棒性。

为了验证 YOLO-DSM 在六类显示器缺陷检测中的可靠性，对 207 幅测试集图像的检测结果进行统计分析。依照显示器的检测要求，需要检测出缺陷类型、数量和位置。测试集包含 112 个黑点 mura、32 个异物、32 个线 mura、24 个白点 mura、23 个白线 mura 和 34 个漏光缺陷。不同算法在检测这些缺陷时的表现如表 1 所示，部分检测可视化效果如图 11 所示。表 1 中 YOLO-DSM（标记为 Ours）在所有缺陷类型的检测上表现出色，YOLOX 系列在大多数缺陷检测上也表现稳定，YOLOV5_s 和 YOLOV8_s 的线 mura 和白线 mura 检测效果不佳。YOLOV7 和 Retinanet 检测效果较差。Chenping 在白线 mura 和线 mura 的检测上效果较差。从图 11 可视化结果看出，YOLO-DSM 整体表现均优于其他算法。

总体来说，YOLO-DSM 在各类缺陷检测上均表现优异，验证了其在显示器缺陷检测任务中的高效性和可靠性。相比其他算法，YOLO-DSM 不仅在检测精度和召回率上有显著提升，而且在多种缺陷类型上均表现稳定，满足了显示器的检测技术要求。

3 结 论

本文提出了一种改进的显示器缺陷检测网络

表 1 缺陷数量统计
Table 1 Defect quantity statistics

算法	黑点	异物	线	白点	白线	漏光
YOLOX_nano	110	32	32	24	22	34
YOLOX_tiny	110	32	32	24	24	34
YOLOX_s	110	32	32	24	23	34
YOLOX_m	112	32	32	24	23	34
YOLOV5_s	97	31	0	23	17	0
YOLOV7	69	29	0	19	15	0
YOLOV8_s	46	32	0	13	20	17
Chenping	100	26	23	24	7	34
Retinanet	0	31	0	0	13	0
Ours	112	32	32	24	24	34




图 11 各个算法检测效果

Fig. 11 The detection effects of each algorithm

YOLO-DSM。在 YOLOX_s 主干网络中嵌入了 HMU 模块和 SSMA 模块。通过融合 SCSE 模块和 SCAM 模块，DSM 模块增强了网络对有用特征的

提取能力并抑制无用特征。将ODConv卷积替换YOLOX_s原始下采样卷积,以细化多类缺陷的局部特征映射,实现了对局部缺陷特征的充分提取。与当前流行的检测算法相比,YOLO-DSM达到了更高的检测精度,mAP达到了97.40%,检测速度

达到了74.42 FPS。且YOLO-DSM在保持速度和准确性平衡方面具有显著优势,达到了更高的准确率、更快的检测速度和更小的模型大小。然而,目前模型在检测有边框的显示器缺陷时精度还很低,不适用于摄像机拍摄角度有倾斜的情况。

参考文献:

- BOCHKOVSKIY A, WANG C Y, LIAO H Y M, 2020. YOLOv4: Optimal speed and accuracy of object detection [EB/OL]. arXiv:2004.10934.
- CHANG Y C, CHANG K H, MENG H M, et al, 2022. A novel multicategory defect detection method based on the convolutional neural network method for TFT-LCD panels[J]. Math Probl Eng:6505372.
- CHEN M, CHEN P, WANG S, et al, 2022. TFT-LCD mura defect visual inspection method in multiple backgrounds [J]. J Soc Info Display, 30(11): 818-831.
- CHEN M, CHEN S, WANG S, et al, 2023. Accurate segmentation of small targets for LCD defects using deep convolutional neural networks [J]. J Soc Info Disp, 31(1): 13-25.
- CHEN P, CHEN M, WANG S, et al, 2023. Real-time defect detection of TFT-LCD displays using a lightweight network architecture[J]. J Intell Manuf,35(3): 1-16.
- DALAL N, TRIGGS B, 2005. Histograms of oriented gradients for human detection [C]//IEEE Computer Society Conference on Computer Vision and Pattern Recognition(CVPR'05).
- HOU Q, ZHOU D, FENG J, 2021. Coordinate attention for efficient mobile network design [C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition.
- HUANG W, LU H, 2012. Defect classification of TFT-LCD with bag of visual words approach [C]//IEEE 6th International Conference on Information and Automation for Sustainability.
- LI C, ZHOU A, YAO A, 2022. Omni-dimensional dynamic convolution[EB/OL]. arXiv:2209.07947.
- LIN G, KONG L, LIU T, et al, 2022. An antagonistic training algorithm for TFT-LCD module mura defect detection [J]. Signal Process Image Commun, 107: 116791.
- LIN T Y, GOYAL P, GIRSHICK R, et al, 2017. Focal loss for dense object detection [C]//IEEE International Conference on Computer Vision.
- MAO J, XU G, HE L, et al, 2023. Attention-relation network for mobile phone screen defect classification via a few samples [J]. Digit Commun Netw, 10(4): 1113-1120.
- NGO C, PARK Y J, JUNG J, et al, 2017. A new algorithm on the automatic TFT-LCD mura defects inspection based on an effective background reconstruction[J]. J Soc Info Disp, 25(12): 737-752.
- PANG Y, ZHAO X, XIANG T Z, et al, 2022. Zoom in and out: A mixed-scale triplet network for camouflaged object detection [C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition.
- ROY A G, NAVAB N, WACHINGER C, 2018. Concurrent spatial and channel 'squeeze & excitation' in fully convolutional networks[M]. Cham: Springer: 421-429.
- SUN Y, LI X, XIAO J, 2019. A cascaded mura defect detection method based on mean shift and level set algorithm for active-matrix OLED display panel[J]. J Soc Info Disp, 27(1):13-20.
- WANG C Y, BOCHKOVSKIY A, LIAO H Y M, 2023. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors [C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition.
- WANG L, HUANG X, ZHENG Z, 2023. Surface defect detection method for electronic panels based on attention mechanism and dual detection heads [J]. PloS One, 18(1): e0280363.
- YANG H, SONG K, MEI S, et al, 2018. An accurate mura defect vision inspection method using outlier-prejudging-based image background construction and region-gradient-based level set[J]. IEEE Trans Autom Sci Eng, 15(4): 1704-1721.
- ZHU X, LYU S, WANG X, et al, 2021. TPH-YOLOv5: Improved YOLOv5 based on transformer prediction head for object detection on drone-captured scenarios [C]//IEEE/CVF International Conference on Computer Vision.

(责任编辑 王海蓉)