

DOI: 10.3969/j.issn.1009-9492.2026.01.019

周璐, 王娟平. 基于BLE-YOLO的高效钢材表面缺陷检测算法 [J]. 机电工程技术, 2026, 55 (01): 109-118.

基于BLE-YOLO的高效钢材表面缺陷检测算法*

周 璐¹, 王娟平^{1,2*}

(1. 宝鸡文理学院 机械工程学院, 陕西宝鸡 721016; 2. 陕西信达合瑞科技有限公司, 陕西宝鸡 721000)

摘要: 针对目前钢材表面缺陷检测算法在实际应用中精度不高、资源消耗高等问题, 提出了一种高效、高精度、低计算量和参数量的钢材表面缺陷检测算法BLE-YOLO。利用高效远程注意网络(LFE)的优势, 将其引入YOLOv11中的C3K2模块中, 融合成一种可以动态筛选高频关键区域的C3K2_LFE模块, 增强对不同尺寸和形状缺陷局部特征的提取能力。在主干网络中引入双层路由(Bi-Level Routing)结构, 并对双层路由结构进行改进和优化, 提出一种高效的Bi-Level Routing Attention_NCHW注意力机制, 增强了特征提取的能力同时减少计算复杂度, 使得模型能够更加高效完成特征提取任务。最后, 提出了一种更低计算量和参数量的检测头Efficient-Head, 将原始检测头替换为Efficient-Head, 实现更加快速和准确的缺陷检测。在NEU-DET数据集上的实验结果表明, 所提出的算法在钢材表面缺陷检测任务中取得了82.2%的平均精度均值(mAP), 比原始YOLOv11模型提高了2.8%, 模型计算量少1.3 GFLOPs, 参数量少0.1M。BLE-YOLO有效地提高了钢材缺陷检测的准确性, 更好地满足了工业检测要求。

关键词: 钢材表面缺陷检测; YOLOv11; 高效远程注意网络; 机器视觉; Bi-Level Routing_NCHW

中图分类号: TP391.41; TG115; TP18

文献标志码: A

文章编号: 1009-9492(2026)01-0109-10

An Efficient Steel Surface Defect Detection Algorithm Based on BLE-YOLO

Zhou Lu¹, Wang Juanping^{1,2}

(1. School of Mechanical Engineering, Baoji University of Arts and Sciences, Baoji, Shaanxi 721016, China;

2. Shaanxi Xinda Herui Technology Co., Ltd., Baoji, Shaanxi 721000, China)

Abstract: Aiming at the problems of insufficient accuracy and excessive resource consumption in the practical application of existing steel surface defect detection algorithms, BLE-YOLO is introduced, which is an efficient and high-precision detection algorithm featuring low computational load and parameter count. Firstly, leveraging the advantages of the Low-frequency Enhancement (LFE) network, it is introduced into the C3K2 module of YOLOv11 to form a C3K2_LFE module that can dynamically filter high-frequency key regions, enhancing the ability to extract local features of defects with different sizes and shapes. Secondly, a BiLevelRouting structure is introduced into the backbone network, and through improvement and optimization of the bi-level routing structure, an efficient Bi Level Routing Attention_NCHW attention mechanism is proposed, which enhances feature extraction capability while reducing computational complexity, enabling the model to complete feature extraction tasks more efficiently. Finally, a detection head named Efficient-Head with lower computational complexity and number of parameters is proposed, replacing the original detection head to achieve faster and more accurate defect detection. Experimental results on the NEU-DET dataset show that the proposed algorithm achieves a mean average precision (mAP) of 82.2% in steel surface defect detection, an improvement of 2.8% over the original YOLOv11 model, with a computational complexity reduction of 1.3 GFLOPs and a parameter count reduction of 0.1 M. BLE-YOLO significantly enhances the accuracy of steel defect detection, providing a better match for industrial inspection requirements.

Key words: steel surface defect detection; YOLOv11; efficient long-range attention network; machine vision; Bi-Level Routing_NCHW

0 引言

钢材是实际生活中不可或缺的材料, 也是一种重要的基础材料, 在机械行业也有着重要的作用。目前, 钢铁材料主要通过冶炼、回收、提炼等过程转化, 在这一系列转化过程中由于成本限制、设备限制、现有技术和表面粗糙度等因素^[1], 不可避免地会产生各种各样的缺陷。这些缺陷主要包括裂纹、夹杂、补丁、麻点等^[2]。这些缺陷不仅降低了钢材的外观质量, 还可能对材料性能产生不良影响。

目前, 针对不同的技术水平和应用需求的表面缺陷

检测方法主要有传统检测技术、基于机器视觉检测技术和基于深度学习的智能检测技术。传统检测技术包括人工检测法^[3]、磁粉检测^[4]、渗透检测^[5]等方法。人工检测主要依靠人的视觉观察, 或是借助各种工具直接观察材料表面的缺陷。此方法效率低、成本高且主观能动性差, 不易满足现代工业生产中对检测的精度和速度的要求。中等技术水平的缺陷检测方法中的机器视觉检测自动化程度高, 检测效率高, 能够进行批量生产中的在线检测。这一技术的出现, 在钢材表面缺陷的检测上取得了较大的进步, 比传统的检测技术方法更加高效也更为实用。

基金项目: 陕西省秦创原“科学家+工程师”队伍建设项目(2022KXJ-048); 陕西省秦创原总窗口“四链”融合重点项目(2024PT-ZCK-24); 西安市重点产业链技术攻关项目(23ZDCYJSGG0029-2023); 陕西省技术创新引导专项(2024ZC-YYDP-85)。

随着高新技术的飞速发展,基于深度学习的缺陷检测技术应运而生。基于机器视觉^[6]的钢材表面缺陷检测技术逐渐成为研究热点。通过图像采集、处理及模式识别,机器视觉技术能够实现钢材表面缺陷的高效、精确、非接触式检测,为钢材生产的质量控制提供了技术支撑。目前主流的深度学习目标检测算法大致分为两种:两阶算法和一阶算法。两阶算法^[7]包括:R-CNN^[8]、Faster R-CNN^[9]、Mask R-CNN^[10]等;一阶算法包括SSD^[11]、YOLO^[12]算法等,以及DETR^[13]等基于Transformer架构的目标检测算法。两阶段目标检测算法收敛速度快且具有较高的检测精度,但由于在检测过程中会生成一系列候选框,因此检测目标的速度比单阶段目标检测算法慢。一阶段目标检测算法则是将它们转化为回归问题。Shi等^[14]提出了一种改进的Faster R-CNN,在钢材表面的检测的平均精度(mAP)为80.78%,运行速度提高,但其精度对工业精度的要求还有待提高。由此,Liu等^[15]提出了一种基于SSD的用于钢材表面缺陷检测的级联卷积神经网络,采用改进SSD模型来学习可能的缺陷,并提出了一种深度残差网络(ResNet)来进行缺陷分类。一阶目标检测算法因其检测速度较高,故非常适合用于工业中的钢材表面缺陷的检测任务。Kou等^[16]提出一种基于YOLO-V3的缺陷检测模型,利用无锚特征选择机制替代基于锚的特征结构,选择理想的特征尺度进行模型训练,缩短计算时间,同时引入专门设计的密集卷积块,提取丰富的特征信息,有效提高特征重用率和特征传播效率,增强网络的表征能力,在NEU-DET数据集上产生了72.2%的mAP。Wang等^[17]提出一种基于改进的单阶段检测器的Swin-Transformer-YOLOv5模型,解决了缺陷照片背景杂乱、缺陷类别容易混淆以及不同尺度目标差异大、对细小瑕疵检测效果不佳的问题,提升了检测器对不同尺度目标的适应能力,实现轻量化设计的同时保证了74.9%的平均精度。曹义亲等^[18]提出一种基于改进YOLOX算法的钢材表面缺陷检测方法,在YOLOX模型的基础上改进了激活函数和损失函数,解决由于带钢的高反特性导致图像过度曝光、内容失真而降低图像质量的问题,并嵌入子注意机制,增强隐藏小目标的区域特征,实现了80.7%的平均精度(mAP)。Li等^[19]提出一种高效、高精度的带钢表面缺陷检测算法DEW-YOLO和一种可以灵活采样特征的C2f_DCN模块,将显式视觉中心(EVC)引入骨干网络,使用了Wise-IoU(WIoU)损失函数,在钢材表面缺陷检测任务中实现了80.3%的平均精度(mAP)。

虽然这些方法在缺陷检测的检测速度上表现良好,但对于实际工作的检测精度和速度还存在提升的空间。针对检测的资源消耗较大和精度精度较低的情况,本研究的目的是设计一种高效的缺陷检测方法。通过修改

YOLOv11模型,增强了其特征提取和识别的能力。实验结果表明,对包含6种常见的钢材表面缺陷(裂纹、夹杂、斑块、麻面、氧化铁皮压入和划痕)的数据集能进行自动识别与检测,在一定条件下满足了实际工作的需求。

本文引入LFE并与C3K2模块组合形成C3K2_LFE模块,增强局部特征的提取能力,减少计算资源消耗。将改进的双层路由(Bi Level Routing_NCHW)结构嵌入到YOLOv11的骨干网络中,以实现更灵活的计算分配和内容感知,使其具备动态的查询感知稀疏性,并且删除原双层路由结构中未使用的参数和组件、避免因频繁排列、以及输入特征图方式的和池化不同,导致数值的差异。从而使得模型的具有良好的性能和高计算效率。将原有的Detect改Detect-efficient(一种高效的目标检测头部结构),采用了轻量级的网络设计和高效的模型参数设置,提高缺陷检测的速度和准确率,以能够保持高效率的地适应各种场景和要求,提供更稳定可靠的检测结果,尤其适用于真实的工业检测场景。

1 相关研究

1.1 钢材表面缺陷检测

目前,机器视觉技术^[20]代表了最广泛和最可靠的钢材表面缺陷检测方法,使生产人员可以方便地识别钢材表面的各种缺陷,并制定适当的质量控制和维护计划。然而,钢材表面缺陷的检测过程在传统方法中过度依赖人工设定的特征提取标准,导致检测效率低下,且对复杂缺陷的识别效果较差。随着计算机视觉技术的发展,自动化的钢材表面缺陷检测技术得到显著提升,深度学习和视觉识别算法在该领域日益普及。诸如基于卷积神经网络(CNN)的目标检测、分割算法以及多任务学习的研究,逐步构建了从图像采集、图像处理、特征提取到缺陷分类与分析的完整检测框架,为高效、智能的钢材表面缺陷检测提供了基础^[21]。

1.2 YOLO算法

传统钢材表面缺陷检测主要依靠人工目检和光学检测,但其过分依赖人力和工艺限制导致检测效率低且不稳定。进入深度学习时代,涉及YOLO系列算法的目标检测带来了性能的提升,如快速检测和高精度传递。YOLO的核心思想是将目标检测任务简化为一个单一的回归问题,通过一个神经网络直接从输入图像中预测目标的类别和位置。其检测算法是将输入图像划分为 $S \times S$ 的网格单元,但仍然存在一些不足。物体中心所在的网格单元负责检测物体,使得检测附近物体变得困难^[22]。为了提高YOLO在不同领域的适应性,研究人员引入了注意力机制,并修改了检测组件以增强性能。然而,在钢材表面缺陷的检测中,先前的研究主要集中在裂纹缺陷上,忽略了表现出重叠状态的缺陷。这种研究的稀缺性为YOLO算法应用于钢材缺陷检测带来了挑战。

2 数据集

本研究采用东北大学 NEU-DET^[23]数据集, 该数据集包含 6 种常见的钢材表面缺陷: 裂纹 (Cr)、夹杂 (In)、斑块 (Pa)、麻面 (PS)、氧化铁皮压入 (RS) 和划痕 (Sc)。每类 300 幅图像, 共计 1 800 幅图像, 图像大小为 200 pixel×200 pixel。该数据集提供了标注缺陷图像位置和类别信息的注释。为了更好地进行实验, 随机选择了 1 440 张图像作为训练集, 180 张图像作为验证集, 180 张图像作为测试集 (即数据集按 8:1:1 的比例分配)。NEU-DET 数据集中钢表面缺陷的类别如图 1 所示, 数据分布如图 2 所示。




图 1 钢材上的 6 种表面缺陷

Fig. 1 Six types of surface defects on steel




图 2 训练数据的基本信息

Fig. 2 Basic information of the training data

3 模型结构

YOLO 模型是一种典型的单阶段目标检测算法, 在工程中得到广泛应用。然而, 传统的 YOLO 模型在实际

工业应用中仍存在若干局限。首先, 由于其网格检测机制的限制, 当相似缺陷聚集或多种缺陷重叠时, 检测精度会显著下降; 其次, 在处理钢材表面不同尺寸和形状的缺陷时表现欠佳, 尤其在检测小型目标缺陷方面存在明显短板; 最后, 尽管 YOLO 系列算法持续优化, 但在计算资源有限的工业环境中, 仍需平衡计算负荷、参数量与检测精度之间的关系。这些技术瓶颈制约了 YOLO 算法在高精度钢材表面缺陷检测中的实际应用效果。因此, 本文基于 YOLOv11 设计了 BLE-YOLO 模型, 该模型结合了高效长距离注意力网络 (Efficient Long-Range Attention Network for Image Super-resolution)、双层路由 (BiLevelRouting_NCHW)、一种高效的目标检测头部结构 (Efficient-Head) 进行优化。具体来说就是将 YOLOv11 原有的 C3K2 和 LFE 相结合, 增强图像细节恢复能力, 降低模型的计算复杂度和训练成本; 增加了双层路由机制, 使得模型能够更加高效地提取感兴趣的区域, 避免特征图输入方式以及池化方式不同带来的差异, 从而提高了预测的精度; 在计算量略微较高的情况下, 用 Efficient-Head (一种高效的目标检测头部结构) 替换了原本的 Detect, 用了轻量级的网络设计和高效的模型参数设置, 提高缺陷检测的速度和准确率, 以能够在保持高效率的同时适应各种场景和要求。

优化的 BLE-YOLO 由图 3 所示的 3 种网络结构组成: 主干、颈部和头部。




图 3 BLE-YOLO 网络结构

Fig. 3 Network architecture of the BLE-YOLO model

主干负责从输入的钢材图像中提取缺陷特征, 颈部将识别的缺陷与头部融合。最后, 对头部生成的钢材表

面缺陷的位置和类别进行回归预测。在网络的主干网络中,输入图像最初在空间维度上被缩放和重新排列。通过增加卷积层的数量来提取不同感受野下的特征图。优化后的主干网络由 Conv、C3k2_LFE、SPPF、C2PSA、BiLevelRoutingAttention_NCHW 组成。为了便于提取微小特征,矩形自校准模块捕捉全局上下文信息作为注意力模块的替代方案。但是,矩形自校准模块会降低召回率,增加训练的复杂度和资源的消耗。为了解决这些限制,同时保持有效的特征提取能力,引入 C3K2_LFE 模块通过轻量化结构融合上下文信息以及对特征进行局部增强来突出细节,减少了计算的开销。在颈部网络架构中,改进的 BiLevelRouting_NCHW 聚合分布机制与 YOLOv11 的特征金字塔结构实现了战略级融合。相较于传统特征融合方法对所有空间位置进行统一处理的方式, BiLevelRouting_NCHW 采用动态的内容感知注意力分配策略。该机制首先在粗粒度分辨率下聚合特征以识别关键区域,随后根据信息量需求,将计算资源自适应地分配到更精细分辨率的特征区域。

这种集成设计带来了三大核心优势。(1) 通过选择性计算实现多尺度特征图的高效处理;(2) 通过对信息密集区域实施聚焦式注意力机制,增强对细微缺陷的表征能力;(3) 优化跨尺度信息流以同时保留全局上下文与局部细节——这对区分相似缺陷类型至关重要。实验结果表明,这种集成方法在检测夹杂物、凹坑表面等小型缺陷时效果尤为显著,这类场景中上下文与细节的平衡尤为关键。经过颈部网络增强的特征图随后被传递至检测头进行最终预测。在此过程中,用提出的高效头部替代了原有的检测头,该设计采用轻量级架构并优化参数配置。高效头部通过任务解耦和动态计算分配实现双重优化:将分类路径与定位路径分离以减少任务间干扰,同时在非关键路径中用参数高效的卷积替换标准卷积。这种重新设计在保持检测精度的前提下,使计算复杂度降低约 20% 且参数数量减少 0.1 M。高效头部的轻量化特性使其特别适合资源受限的工业检测场景,这类场景对实时性能要求极高。

3.1 高效长距离注意力网络

高效长距离注意力网络 (Efficient Long-Range Attention Network for Image Super-resolution, ELAN) 通过结构化稀疏注意力路径与自适应区域选择策略,在显著降低计算开销的同时,突破传统卷积网络的局部感受野限制与 Transformer 的平方复杂度瓶颈,是解决图像超分辨率任务中全局依赖建模的高计算复杂度问题的一种轻量化注意力机制。该模块包括 3 个部分,首先浅层中低分辨率的图片通过由 3×3 的卷积层组成的特征提取模块提取局部的特征;在深层中第一步通过 1×1 卷积和移位操作

构成的移位卷积和 ReLU 函数进行残差连接,再由第一步得到的结果将特征分成不同尺寸的局部区域,在每个区域内进行自注意力计算,从而实现长程依赖的建模,组内多尺度自注意力 (GMSA) 进行残差连接,结合成多个高效长程注意力模块 (ELAB),捕获图像的局部以及长程依赖性;最后结合浅层和深层提取得到的特征通过高分辨率重建模块,生成高质量且高分辨率的图像^[24],整个流程如图 4 所示。

ELAN 因计算资源消耗较低且能够轻松集成到现有的深度学习模型中而被广泛应用。尽管如此,在共享注意力深度的增加,计算资源以及推理时间减少的情况下,其性能略有下降。因为 ELAN 的性能高度依赖动态区域选择的准确性,若关键区域漏选可能导致上下文信息丢失。Yu 等^[25]在实验中发现,当注意力机制漏选破损边缘区域时,修复后的图像会出现边缘断裂或纹理不连续问题。ELAN 的跨尺度特征金字塔和动态卷积核生成技术提升了多退化场景的鲁棒性,并通过通道分组权重共享极大地降低参数量,并在实时的移动端展现出清晰的边缘与细节恢复能力。

3.2 C3K2_LFE 模型

C3K2_LFE 模块通过引入专用低频增强 (LFE) 机制,对传统跨阶段局部 (CSP) 结构实现了重大升级。钢材表面缺陷在频域中往往呈现独特特征,关键缺陷信息主要集中在低频成分。传统卷积网络虽然擅长提取空间特征,但在捕捉这些频域特性方面可能存在不足。该模块在保持原始 C3K2 设计计算效率的同时,新增并行低频增强分支。这种双分支结构可同步提取空间细节与频域特征,从而全面表征钢材表面缺陷。低频增强 (LFE) 分支采用频率选择性增强处理流程,其表达式为

$$F_{LFE}(x) = F^{-1}(M_{\omega} \odot F(x)) \quad (1)$$

式中: $F(x)$ 为输入特征图 x 的二维傅里叶变换; F^{-1} 为逆傅里叶变换; M_{ω} 为截止频率,为 ω 的低频带通掩模。

通过哈达玛积 $\odot$ 将频率掩模施加于图像,可选择性增强低频分量。该操作能有效凸显缺陷 (如裂纹、凹坑和夹杂物) 的结构特征,这些缺陷通常在频域表现为低频模式。参数 ω 用于控制增强频率成分的带宽,其数值需通过钢材表面缺陷数据集的实验进行经验确定。

最佳值在过窄的频带 (可能忽略关键缺陷信息) 和过宽的频带 (可能引入噪声) 之间取得平衡。

在获得频率增强特征后,实现了一个特征融合策略,将它们与原始空间特征相结合,即

$$y = \text{Conv}_{3 \times 3}(\text{Concat}[x, F_{LFE}(x)]) \quad (2)$$

其中, Concat 表示通道级拼接操作, Conv3×3 是一个 3×3 卷积层,用于整合拼接后的特征。这种融合策略使网络能够同时利用空间和频率域的特征,从而生成更




图4 ELAN的整体流程

Fig. 4 Overall workflow of ELAN

全面的特征表示。尽管引入了傅里叶变换, C3K2_LFE模块的实现仍然具有计算效率。利用快速傅里叶变换 (FFT) 算法来最小化计算开销。此外, 该模块设计为与现有的骨干架构兼容, 只需对整体网络结构进行最小的修改。

3.3 双层路由 (Bi-Level Routing)

效率和精度是现有算法所追求的主要评价指标, YOLO算法和注意力机制的结合可以在效率较高的情况下保持着较高的精度, 从而达到现代工厂的生产需求。在分割、分类、目标检测等任务中传统的注意力机制取得了较好的效果, 但是在捕捉长距离依赖关系时会产生较大的计算负担和大量的内存占用, 无法较好地平衡效率与精度。为了解决该问题, Zhu等^[26]提出了一种具有双层路由注意机制的视觉转换器, 能更好地提取感兴趣的区域, 同时降低复杂度, 平衡效率与精度, 如图5所示。

路由机制首先生成一个路由掩码, 该路由掩码标识出目标区域为

$$\text{RouteMask} = \text{Sigmoid}\left(\text{Conv}_{1 \times 1}\left(\text{Pool}_{\text{avg}}(x)\right)\right) \quad (3)$$

其中, Pool_{avg} 执行平均池化以捕捉区域重要性, 随后通过 1×1 卷积和 Sigmoid 激活生成归一化的注意力分布

图。该掩码能有效区分需要密集处理的区域与可高效处理的区域。

与此同时, 传统卷积网络对所有区域进行统一处理, 导致计算资源分配效率低下。标准注意力机制可表述为

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{soft max} \left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} \right) \mathbf{V} \quad (4)$$

式中: $\mathbf{Q}$ 、 $\mathbf{K}$ 和 $\mathbf{V}$ 分别为查询矩阵、键矩阵和值矩阵; d_k 为键的维度。

该机制在捕捉长距离依赖关系方面展现出显著效果。然而, 若将这种机制统一应用于整个特征图, 会带来巨大的计算开销, 特别是在目标检测网络中处理高分辨率特征图时尤为明显。

完整的 BiLevelRoutingAttention 操作可表示为 $\text{BiLevelAttention}(x) = \text{RouteMask} \cdot \text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) + (1 - \text{RouteMask}) \cdot x$ (5)

式 (5) 创建了一个计算效率高的双重路径: 高信息区域 (主要是缺陷区域) 接收完整的注意力处理, 而低信息区域 (主要是背景) 绕过了计算密集型的注意力操作, 保留了原始特征。




图5 BiFormer模型
Fig. 5 BiFormer model

因此，将 BiLevelRoutingAttention 引入 YOLOv11 降低了传统注意力机制对背景区域的冗余计算，对关键区域进行动态聚焦，特别是对小目标边缘的关键区域进行动态聚焦，参数限制每窗口参与交互的区域数，避免了传统 Transformer 类方法中频繁的矩阵转置开销，并采用 NCHW 输入的 BiLevelRoutingAttention 删除了未使用的参数和组件、避免频繁的排列，显著提升 GPU 计算效率。

3.4 目标检测头部结构 (Efficient-Head)

传统检测头主要依赖全连接层或密集卷积运算，导致参数开销大、计算效率低。这些局限性在资源受限的工业环境中尤为突出，而实时性能对这类场景至关重要。

在精度满足需求的情况下，轻量化和效率在当前的机器视觉中也是不可忽视的一部分。通常情况下主干用于图像特征提取，颈部则利用空间金字塔池化快速 (SP-PP) 和上采样来融合提取的特征，提高对特征的捕获能力，提升网络性能。而检测头作为检测的最后一环，是对颈部网络所输出的特征图，对目标检测的位置、大小和分类进行预测。传统分类头通常依赖全连接层，导致参数量大且计算效率低。

可将 Efficient-Head^[27] 的参数效率量化为

$$\text{Params}_{\text{efficient}} = \sum_{l=1}^3 (C_{\text{in}}^{(l)} C_{\text{out}}^{(l)} K^2) + \sum_{j=1}^2 (D_j^2) \quad (6)$$

式中： $C_{\text{in}}^{(l)}$ 和 $C_{\text{out}}^{(l)}$ 分别表示第 l 层的输入和输出通道； K 为核大小； D_j 为第 j 阶段的动态通道压缩系数。

该公式展示了通过战略性地管理通道维度所实现的显著参数减少。

Efficient-Head 结构如图 6 所示，通过以下几种架构创新解决了这些限制。

- (1) 轻量级架构设计：通过优化滤波器配置实现参数效率高的卷积层，显著降低计算开销，同时保持表征能力。
- (2) 任务特定解耦：将分类和定位任务分离到并行路径中，为每个任务提供专门的特征处理，并减少冗余计算。
- (3) 动态计算分配：根据特征复杂度自适应调整计




图6 Efficient-head 结构
Fig. 6 Structural diagram of the efficient-head

算资源，将更大的处理能力分配给信息区域，同时最小化对背景区域的操作。

(4) 优化的特征聚合：采用高效的特征融合机制来集成多尺度信息，增强不同尺寸对象的检测性能。

4 实验

4.1 实验环境和参数配置

实验环境使用 Windows 11 作系统、16 GB RAM、11th Gen Intel (R) Core (TM) i7-11800H @ 2.30GHz 2.30 GHz、具有 8 GB 显存的 NVIDIA GeForce RTX 3050 笔记本电脑显卡 (NVIDIA, 美国加利福尼亚州圣克拉拉市) 和 PyTorch 2.5.1 作为深度学习框架。Python 版本为 3.10, CUDA 版本为 12.4, cuDNN 版本为 12.4。为确保可重复性并便于比较分析，仔细选择和配置了实验参数，如表 1 所示。在所有实验迭代中保持这些参数的一致性，以确保不同模型配置之间的公平比较。

表 1 实验参数设置
Tab. 1 Experimental parameter settings

Parameter	Setting	Parameter	Setting
Epochs	300	Initial learning rate	0.01
Input image size	640 × 640	Momentum	0.937
Batch size	16	Optimizer	SGD

4.2 评估指标

钢带表面缺陷检测模型的性能评估采用多种互补指

标, 综合评估准确性和效率。主要准确性指标包括精确度 (P)、召回率 (R) 和平均精度 (mAP), 其数学定义为

$$P = \frac{N_{TP}}{N_{TP} + N_{FP}} \quad (7)$$

$$R = \frac{N_{TP}}{N_{TP} + N_{FN}} \quad (8)$$

$$P_{mAP} = \frac{1}{n} \sum_{i=1}^n AP_i \quad (9)$$

式中: N_{TP} 为真阳性案例; N_{FN} 为假阴性案例; N_{FP} 为假阳性案例, n 为案例总数。

此外, 为了全面评估模型效率和部署可行性, 提出了以下测量指标。

(1) 计算复杂度 (GFLOPs): 量化单次前向传递所需的浮点运算次数, 反映模型的计算负担。

(2) 参数数量 (Params): 表示可训练参数的总数, 与模型大小和内存要求相关。

(3) 推理速度 (FPS): 衡量每秒处理的帧数, 这对实时工业应用至关重要。

这些指标共同提供了一个全面的评估框架, 用于评估所提出的钢表面缺陷检测模型的检测精度和计算效率。

5 实验结果和分析

5.1 消融实验

为了验证所提出的改进策略的有效性, 进行了一组对比消融实验。实验以 YOLOv11 为基准模型, 实验结果如表 2 所示。表中, C3K2_LFE、BiLevelRoutingAttention_NCHW 和 Detect_Efficient 代表了本研究中提出的 3 个改进点, “√” 表示改进点的采用。

表 2 消融实验结果

Tab. 2 Ablation experiment results

序号	C3K2_LFE	BiLevelRoutingAttention_NCHW	Detect_Efficient	mAP@0.5	Params (M)	GFLOPs
1				0.794	2.583 322	6.3
2	√			0.817	2.491 186	6.2
3		√		0.801	2.849 050	6.4
4			√	0.787	2.314 394	5.1
5	√	√		0.818	2.756 914	6.2
6	√	√	√	0.822	2.487 986	5.0

根据表 2 中的消融实验结果, 可以得出结论: 第一组直接采用原始 YOLOv11 模型实现了 mAP 值为 79.4%, 参数为 2.58 M, GFLOPs 为 6.3。在第二组中, C3K2_LFE 模块网络取代了 backbone 中的 C3K2 模块。这一模块的改变能够加强模型对多层次特征的整合效率, 动态把握感知区域的范围与分布, 从而能够更佳灵活地处理钢材表面的各类缺陷, 优化了模型的检测精度, mAP 值提高到 81.7%, 表明 C3K2_LFE 模块可以有效增强模型捕捉多层次特征的能力, 使其适应不同钢材表面缺陷, 同时还能减少参数数量。第三组将 Bi-Level Routing Atten-

tion_NCHW 模块嵌入到 YOLOv11 的骨干网络中, 模型融合改进后的双层动态路由注意力机制, 对关键区域进行筛选与动态聚焦, 提高对小目标的检测能力, 模型的平均精度分数 (mAP) 提升至 80.1%, 不过计算复杂度也略有增加。第四组将 YOLOv11 的检测头替换为 efficient-head, 平均精度分数 (mAP) 虽小幅下降至 78.7%, 但参数数量 (2.31 M) 和计算复杂度 (5.1 GFLOPs) 均显著降低。这种性能折衷充分体现了该组件的效率导向特性, 在资源受限的环境中具有重要价值。C3K2_LFE 与双层级路由注意力机制 (BiLevelRoutingAttention_NCHW, 第 5 组) 的协同应用, 使平均精度分数 (mAP) 达到 81.8%, 充分证明了这两个组件的强强联合能显著提升检测性能。当将全部三项优化方案 (第 6 组) 完整实施后, 不仅实现了 mAP 值的突破性提升至 82.2%, 同时将计算复杂度降至 5.0 GFLOPs, 参数数量也精简至 2.49 M。这些消融研究清楚地表明, 每个提出的改进都对模型的性能有积极的贡献, 它们的组合在检测准确性和计算效率之间产生了最佳的平衡。

5.2 对比实验

为了直观地评估本文提出的算法的检测效果, 在对比实验中, 将 YOLOv11 模型与本文提出的模型的混淆矩阵进行了比较, 比较结果如图 8 所示。在这些矩阵中, 行代表真实类别, 而列表示预测类别。对角线元素表示正确分类实例的比例, 而非对角线元素则表示错误分类。




图 8 YOLOv11 模型与提出的模型对比

Fig. 8 Comparison between the YOLOv11 model and the proposed model

如图 9 和图 10 所示, PR 曲线图分别描述了 YOLOv11 和 BLE-YOLO 的 mAP 值的比较。PR 曲线图反映了各种缺陷类别的 mAP 值, 其中“所有类别”表示所有类别的平均 mAP 值。与改进前的结果相比, 总体 mAP 值从 79.4% 增加到 82.2%, 提高了 2.8%。结果表明, 改进后的模型可以提高多个缺陷类别的检测精度。除麻面缺陷的 mAP 值略有下降 0.3% 外, 其他 5 个缺陷都得到不同程度的改善, 尤其是夹杂, 其 mAP 值从 81.9% 增加到 87.4%, 增加了 5.5%, 划痕的 mAP 值最高, 达到 93.7%。

5.3 结果可视化

为了更直观地比较本文算法与 YOLOv11 算法在钢材表面缺陷检测中的有效性, 将 BLE-YOLO 模型与 YO-




图9 YOLOv11算法的P-R曲线

Fig. 9 P-R curve of the YOLOv11 algorithm




图10 BLE-YOLO算法的P-R曲线

Fig. 10 P-R curve of the BLE-YOLO algorithm

LOv11模型应用于同一测试集中的缺陷检测，部分缺陷检测效果如图11所示。从图中可以看出，原始YOLOv11模型存在漏检或准确率低的问题，部分类别的检测性能特别差，而BLE-YOLO模型在效果上明显优于原始YOLOv11模型；当检测到图10中的部分目标时，能更全面地识别出缺陷目标。YOLOv11模型存在漏检或准确率低的问题，部分类别的检测性能特别差，而BLE-YOLO模型在效果上明显优于原始YOLOv11模型；在对部分缺陷目标进行检测时，能更全面地识别出缺陷目标，检测精度也有显著提高。BLE-YOLO模型检测出了基线模型漏检的缺陷，并且在检测相同位置的缺陷时比基线模型具

有更高的置信度。可视化结果揭示了BLE-YOLO的三大优势：

(1) 检测灵敏度提升：BLE-YOLO成功检测出原始模型完全漏检的缺陷，证明其具有更优的特征提取能力。


(2) 改进的分类准确度：模型在区分视觉相似的缺陷类型时更精确，减少了误分类错误。

(3) 更高置信度评分：对于两个模型都检测到的缺陷，BLE-YOLO始终给出更高的置信度评分，表明其预测结果具有更高的确定性。

这些定性结果与定量指标一致，并证实了BLE-YOLO显著提高了钢表面缺陷的检测性能，为工业带钢生产过程中的质量控制提供了更可靠的基础。

5.4 不同模型的对比实验

烧蚀实验验证了所提算法的可行性。为进一步验证其性能，在相同的数据集划分条件下，将本文提出的改进模型与YOLO系列3种主流模型的结果进行对比。这个实验结果见表3。从表中的实验结果可以看出，本文提出的BLE-YOLO模型的mAP值与SSD、Fast R-CNN、YOLOv8、YOLOv10和YOLOv11相比分别提高了10.3%、5.9%、2.3%、16.8%和2.8%，准确率有显著提高。BLE-YOLO表现出卓越的计算效率，只有5.0 GFLOPs，大大低于SSD (62.7 GFLOPs)、Fast R-CNN (370.2 GFLOPs)、YOLOv8 (8.1 GFLOPs)、YOLOv10 (8.2 GFLOPs)和YOLOv11 (6.3 GFLOPs)。BLE-YOLO仅2.49M参数，在所有对比模型中具有最紧凑的模型结构，需要比SSD (25.4M)和Fast R-CNN (24.76M)等传统模型显著更少的内存和存储资源。特定类别性能：BLE-YOLO在大多数缺陷类别中实现了最高的检测准确度，尤其在检测裂纹(50.2%)、夹杂(87.4%)、斑块(94.7%)、氧化铁皮压入(77.5%)和划痕(93.7%)方面表现突出。平衡性能：虽然YOLOv11展示了值得称赞的参数效率和计算性能，但BLE-YOLO成功地解决了其精度限制，同时进一步提高了效率指标。



(a) YOLOv11模型的检测效果

(b) BLE-YOLO模型的检测效果

图11 检测结果的比较

Fig. 11 Comparison of detection results

表3 不同网络模型的实验结果对比

Tab. 3 Comparison of experimental results for different network models

缺陷类型	SSD	Fast R-CNN	YOLOv8	YOLOv10	YOLOv11	BLE-YOLO
Crazing	0.452	0.474	0.456	0.309	0.459	0.502
Inclusion	0.818	0.849	0.838	0.722	0.819	0.874
Patches	0.880	0.916	0.943	0.86	0.9	0.947
Pitted_Surface	0.842	0.851	0.891	0.695	0.902	0.899
Rolled_in_Scale	0.602	0.541	0.753	0.55	0.757	0.775
Scratches	0.722	0.947	0.914	0.787	0.928	0.937
mAP50	71.9	76.3	0.799	0.654	0.794	0.822
Parameters (M)	26.04	138	3.006 818	2.696 756	2.583 322	2.487 986
GFLOPs	62.7	370.2	8.1	8.2	6.3	5.0

这些全面的对比验证了 BLE-YOLO 在钢材表面缺陷检测领域实现了重大突破, 在检测精度与计算效率之间达到了最佳平衡。这使得它特别适合实时工业部署场景, 而这两项指标在此类场景中都至关重要。

6 结束语

为了解决当前带钢表面缺陷检测算法在实际应用中存在的检测精度不高等问题, 本文在 YOLOv11 的基础上, 提出了一种有效的带钢表面缺陷检测算法 BLE-YOLO。本算法将高效长程注意力网络集成到 C3K2 架构中, 创建了 C3K2-LFE, 取代了主干网络中的原始 C3K2 模块, 具有提高一致性和计算速度的优势, 降低了模型的实现成本。

这使得模型可以实现对高频关键区域的筛选并且将不同层次特征进行结合, 增加了模型对不同缺陷的提取能力的同时降低计算开销。该模型融合 BiLevelRoutingAttention_NCHW 的双层动态路由注意力机制, 解决长距离依赖关系时产生的较高的计算量和资源消耗, 并提高模型对小目标的检测能力。最后, 将 Detect 检测头替换为 Detect_Efficient, 以实现更加快速和更准确的目标检测, 降低模型的计算量和参数量。经过广泛实验以及多维度的算法比较, 所提方案的可行性得以验证, 更突出了技术体系的完整性, 有效提高了检测精度, 同时拥有较低的计算量和参数量。该算法在 NEU-DET 带材表面缺陷数据集上的 mAP 达到 82.2%, 比原始算法提高了 2.8%, 使其在实际带材生产中更加高效和灵活。在与原始模型相比较, 改进后的模型检测准确性明显提高, 模型的计算量和参数量降低 20.6%, 并且仍然适用于在移动设备上的部署。该方法适用于当前钢材表面缺陷检测的需求。

机器视觉技术在解决钢材表面的缺陷检测具有实际意义, 为其他材料以及工业部门的缺陷检测问题提供了参考价值。未来将进一步研究所提出的方法, 优化模型的计算量和参数量, 进一步提高检测精度。

参考文献:

[1] DUSPARA M,SAVKOVIĆ B,DUDIC B,et al. Effective Detection of the Machinability of Stainless Steel from the Aspect of the Roughness of the Machined Surface[J]. Coatings,2023,13(2): 447.

[2] 伍麟,郝鸿宇,宋友. 基于计算机视觉的工业金属表面缺陷检测综述[J]. 自动化学报,2024,50(7): 1261-1283.

WU L,HAO H Y,SONG Y.A Review of Industrial Metal Surface Defect Detection Based on Computer Vision [J].Acta Automatica Sinica,2024,50(7):1261-1283.

[3] 胡皓. 基于机器视觉的金属表面缺陷检测系统研究[D]. 西安: 西安电子科技大学,2023.

[4] 王宗伟. 磁粉检测技术[J]. 黑龙江科技信息,2013 (36): 16.

WANG Z W. Magnetic Particle Inspection Technology [J]. Heilongjiang Science and Technology Information,2013(36): 16.

[5] 李少波,杨静,王铮,等. 缺陷检测技术的发展与应用研究综述[J]. 自动化学报,2020,46(11): 2319-2336.

LI S B,YANG J,WANG Z,et al.A Review on the Development and Application of Defect Detection Technologies[J].Acta Automatica Sinica,2020,46(11): 2319-2336.

[6] 米春风,卢琨,汪文艳,等. 基于机器视觉的带钢表面缺陷检测研究进展[J]. 安徽工业大学学报 (自然科学版),2022,39(2): 180-188.

MI C F,LU K,WANG W Y,et al.Research Progress on Strip Steel Surface Defect Detection Based on Machine Vision[J].Journal of Anhui University of Technology (Natural Science Edition),2022, 39(2): 180-188.

[7] ZOU Z,CHEN K,SHI Z,et al. Object detection in 20 years: A survey. Proc. IEEE 2023,111,257-276.

[8] YANG F,HUO J,CHENG Z,et al. An improved Mask R-CNN micro-crack detection model for the surface of metal structural parts[J]. Sensors,2023,24(1): 62.

[9] 黄凤荣,李杨,郭兰申,等. 基于 Faster R-CNN 的零件表面缺陷检测算法[J]. 计算机辅助设计与图形学学报,2020,32(6): 883-893.

HUANG F R,LI Y,GUO L S,et al.Part Surface Defect Detection Algorithm Based on Faster R-CNN[J]. Journal of Computer-Aided Design & Computer Graphics,2020,32(6): 883-893.

[10] 翁玉尚,肖金球,夏禹. 改进 Mask R-CNN 算法的带钢表面缺陷检测[J]. 计算机工程与应用,2021,57(19):235-242.

WENG Y S,XIAO J Q,XIA Y. Strip Steel Surface Defect Detection Based on an Improved Mask R-CNN Algorithm [J].Journal of Computer Engineering & Applications,2021,57(19):235-242.

[11] 王艳玲,苏盈盈,罗好,等. 基于 SSD 模型的钢带表面缺陷检测系统设计[J]. 重庆科技学院学报(自然科学版),2021,23(3):95-98.

WANG Y L,SU Y Y,LUO Y. Design of a Strip Steel Surface Defect Detection System Based on the SSD Model[J]. Journal of Chongqing University of Science and Technology (Natural Science Edition),2021,23(3):95-98.

[12] REDMON J,DIVVALA S,GIRSHICK R,et al. You only look once: Unified,real-time object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 779-788.

[13] CARION N,MASSA F,SYNNAEVE G,et al. End-to-end object detection with transformers[C]//European Conference on Computer Vision. Cham: Springer International Publishing, 2020: 213-229.

[14] 冷岳峰,刘正,徐宝祯,等. 改进 Faster R-CNN 的钢材表面缺陷检测[J]. 机械科学与技术,2025,44(1): 75-83.

- LENG Y F, LIU Z, XU B Y, et al. Steel Surface Defect Detection Based on an Improved Faster R-CNN[J]. Mechanical Science and Technology for Aerospace Engineering, 2025, 44(1): 75-83.
- [15] 李孟娇. 基于改进YOLOv4和Mask R-CNN的钢材表面缺陷检测研究与应用[D]. 青岛: 青岛大学, 2023.
- [16] 马自勇, 屈言森, 马立东, 等. 基于EFN-YOLO的钢管表面缺陷检测[J]. 组合机床与自动化加工技术, 2025(1): 195-200.
- MA Z Y, QU Y S, MA L D, et al. Steel Pipe Surface Defect Detection Based on EFN-YOLO[J]. Modular Machine Tool & Automatic Manufacturing Technique, 2025, (1): 195-200.
- [17] 冒浩杰, 巩永旺. 改进YOLOv5s的小目标钢材表面缺陷检测算法[J]. 电子科技, 2025, 38(10): 10-18.
- MAO H J, GONG Y W. Small-Target Steel Surface Defect Detection Algorithm Based on Improved YOLOv5s[J]. Electronics Science and Technology, 2025, 38(10): 10-18.
- [18] 曹义亲, 曹鑫晨. 融合膨胀卷积与ECA的钢材缺陷检测算法[J]. 计算机工程与设计, 2024, 45(11): 3312-3319.
- Cao Y Q, Cao X C. Steel Defect Detection Algorithm Integrating Dilated Convolution and ECA[J]. Computer Engineering and Design, 2024, 45(11): 3312-3319.
- [19] LI J, CHEN M. DEW-YOLO: An Efficient Algorithm for Steel Surface Defect Detection[J]. Applied Sciences, 2024, 14(12): 5171.
- [20] 苗琳, 施永刚, 毛志恒, 等. 机器视觉检测技术的典型应用探析[J]. 科技创新与应用, 2025, 15(01): 185-188.
- MIAO L, SHI Y G, MAO Z H, et al. Analysis of Typical Applications of Machine Vision Inspection Technology[J]. Science and Technology Innovation and Application, 2025, 15(1): 185-188.
- [21] 周飞燕, 金林鹏, 董军. 卷积神经网络研究综述[J]. 计算机学报, 2017, 40(6): 1229-1251.
- ZHOU F Y, JIN L P, DONG J. A Review of Convolutional Neural Network Research[J]. Journal of Computer Research and Development, 2017, 40(6): 1229-1251.
- [22] DIWAN T, ANIRUDH G, TEMBHURNE J V. Object detection using YOLO: Challenges, architectural successors, datasets and applications[J]. Multimedia Tools and Applications, 2023, 82(6): 9243-9275.
- [23] BAO Y, SONG K, LIU J, et al. Triplet-graph reasoning network for few-shot metal generic surface defect segmentation[J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-11.
- [24] ZHANG X, ZENG H, GUO S, et al. Efficient long-range attention network for image super-resolution[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2022: 649-667.
- [25] YU J, LIN Z, YANG J, et al. Generative image inpainting with contextual attention[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 5505-5514.
- [26] ZHU L, WANG X, KE Z, et al. Biformer: Vision transformer with bi-level routing attention[C]//Proceedings of The IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 10323-10333.
- [27] ZHANG C, LIU H, DENG Y, et al. TokenHPE: Learning orientation tokens for efficient head pose estimation via transformers [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 8897-8906.
- 作者简介: 周璐 (1997—), 女, 四川泸州人, 硕士, 助理工程师, 研究领域为机器视觉。
- ※通信作者简介: 王娟平 (1976—), 女, 陕西宝鸡人, 硕士, 副教授, 研究领域为机械自动化控制、机器视觉、智能制造、非标自动化。
-
- (上接第67页)
- of dissimilar copper-aluminum thin sheets with high brightness lasers[M]. Switzerland: Springer International Publishing, 2016.
- [12] SHENG J, KONG F R, TONG W. Experimental investigations on mechanical properties of AA6061-T6 aluminum alloy joined by laser welding using digital image correlation[J]. International Journal of Advanced Manufacturing Technology, 2024, 132(3-4): 1951-1967.
- [13] MIRAKHORLI F, NADEAU F, GUILLEMETTE G C. Single pass laser cold-wire welding of thick section AA6061-T6 aluminum alloy[J]. Journal of Laser Applications, 2018, 30(3): 032421.
- [14] XIAO R S, ZHANG X Y. Problems and issues in laser beam welding of aluminum-lithium alloys[J]. Journal of Manufacturing Processes, 2014, 16(2): 166-175.
- [15] XIAO R S. Laser beam welding of aluminum alloys[J]. Lasers in Material Processing and Manufacturing, 2008: 6825.
- [16] TROMETER N, CHEN B W, MOODISPAW M, et al. Modeling and validation of hydrogen porosity formation in aluminum laser welding[J]. Journal of Manufacturing Processes, 2024, 124: 877-890.
- [17] ZHU Z X, LIU Z, XIA L, et al. Study on microstructure and composition segregation of laser welded joints of 2A14 aluminum alloy[J]. Materials Research Express, 2019, 6(2): 026563.
- [18] MIAO H B, YU G, HE X U L, et al. Comparative study of hybrid laser-MIG leading configuration on porosity in aluminum alloy bead-on-plate welding[J]. The International Journal of Advanced Manufacturing Technology, 2017, 91(5/8): 2681-2688.
- [19] OLA O, DOERN F. Keyhole-induced porosity in aluminum alloy bead-on-plate welding[J]. International Journal of Advanced Manufacturing Technology, 2015, 80(1/4): 3-10.
- [20] 邵明皓, 张华, 张健, 等. 6082 铝合金激光填丝焊接接头组织及力学性能研究[J]. 热加工工艺, 2023, 52(11): 28-32.
- SHAO M H, ZHANG H, ZHANG J, et al. Microstructure and Mechanical Properties of Laser Filler Welding Joint of 6082 Aluminum Alloy[J]. Hot Working Technology, 2023, 52(11): 28-32.
- [21] 李志强, 飞尚才. 6061 铝合金FSW焊接接头组织和力学性能分析[J]. 焊接技术, 2024, 53(8): 44-49.
- LI Z Q, FEI S C. Analysis of microstructure and mechanical properties of 6061 aluminum alloy welded joint by FSW[J]. Welding Technology, 2024, 53(8): 44-49.
- 作者简介:
- 王浩然 (2002—), 男, 硕士研究生, 研究领域为铝合金激光焊接。
- 温淳杰 (2000—), 男, 硕士研究生, 研究领域为铝合金激光焊接。
- 武威 (1984—), 女, 博士, 副教授, 研究领域为汽车装备机器人与弧焊机器人多机协同控制、电弧增材制造、焊接过程图像、数字化弧焊电源电参数的数据处理等。
- ※通信作者简介: 姚屏 (1978—), 女, 博士, 教授, 研究领域为智能制造、制造过程智能化检测与控制。