

基于 DCGAN 数据增强和 YOLO 算法的不锈钢缺陷检测

Stainless Steel Defect Detection Based on DCGAN Data Augmentation and YOLO Algorithm

陈欣 CHEN Xin; 王伟 WANG Wei; 许威 XU Wei;
刘海林 LIU Hai-lin; 李维锋 LI Wei-feng; 翟志国 ZHAI Zhi-guo
(海洋石油工程股份有限公司, 天津 300461)
(Offshore Oil Engineering Co., Ltd., Tianjin 300461, China)

摘要: 金属材料广泛用于航空航天、汽车制造等产业, 钢材作为用途最多、适应性最强的材料之一, 生产过程中表面缺陷的种类、数量和分布直接影响产品性能和使用寿命。本文基于机器视觉方法, 采用 DCGAN 算法进行数据增强处理, 并利用 YOLOv4 算法建立检测模型, 提出了一种小样本条件下的视觉检测新方法。结果表明: 数据增强处理后, 模型 mAP 得到显著提高, 由 85.2% 增强至 95.54%。进一步采用剪枝算法简化 YOLOv4 模型, 修剪后的模型 mAP 为 93.4%, 而检测速度由 51f/s 增强至 65.4f/s。因此, 该方法可以对小样本的钢材缺陷进行实时、准确的检测。

Abstract: Metal materials are widely used in industries such as aerospace and automotive manufacturing. Steel, as one of the most versatile and adaptable materials, has a direct impact on product performance and service life due to the types, quantities, and distribution of surface defects during production. This article is based on machine vision methods, using DCGAN algorithm for data augmentation processing, and using YOLOv4 algorithm to establish a detection model, proposing a new visual detection method under small sample conditions. The results showed that after data augmentation processing, the mAP of the model was significantly improved, increasing from 85.2% to 95.54%. Further use of pruning algorithm to simplify the YOLOv4 model resulted in a trimmed mAP of 93.4% and an enhanced detection speed from 51f/s to 65.4f/s. Therefore, this method can perform real-time and accurate detection of steel defects in small samples.

关键词: 钢缺陷检测; YOLOv4; DCGAN

Key words: steel defect detection; YOLOv4; DCGAN

中图分类号: TG115 文献标识码: A 文章编号: 1006-4311 (2025) 28-011-04 doi:10.3969/j.issn.1006-4311.2025.28.004

0 引言

钢铁是一种重要的工业产品, 用途广泛。然而, 普遍存在的钢材表面缺陷已成为困扰钢铁生产的一大难题。由于原材料质量差, 轧制工艺有缺陷, 可能导致钢材表面出现划痕、水渍、焊缝、冲孔、油斑、丝斑等缺陷。在生产过程中, 这些缺陷会降低钢的耐磨性、耐腐蚀性、耐高温性和疲劳强度。随着深度卷积神经网络 (deep convolutional neural networks, DCNNs) 在图像分类^[1-3]和图像处理^[4-6]等方面的迅速发展, 基于视觉的检测方法因其检测成本低、适应性好、检测速度快和检测灵敏度高等优点受到了广泛的关注。Xu 等^[7]提出了一种基于 YOLO 模型的改进金属表面缺陷检测技术。结果表明, 改进的 YOLO 模型平均检测精度可达 75.1%, 这是在拥有大量数据集的前提下进行的。然而, 当训练数据变小时, mAP 将被丢弃。为了解决这一问题, Fu 等^[8]采用预训练的 squeezenet 作为主干架构, 只需要少量针对缺陷的训练样本就可以实现高精度识别, 但网络结构仍然庞大, 难以满足边缘部署。本文提出了一种使用 DCGAN 算法进行数据增强, 使用 YOLOv4 算法建立检测模型的检测方法。同时, 采用剪枝算法简化网络, 加快检测速度, 满足移动终端部署和边缘计算的需求。

1 方法

本研究主要采用基于深度学习的目标检测算法建立钢材缺陷检测模型。该金属缺陷检测模型建立的主要流程由数据增强、建模、模型剪枝三部分组成, 如图 1 所示。




图 1 金属缺陷检测流程

1.1 DCGAN 模型

DCGAN 是一种无监督的数据增强方法, 其将卷积神经网络引入生成模型中进行无监督训练, 一个完整的生成式对抗网络结构包括生成器 (generator) 和鉴别器 (discriminator), 如图 2 所示。

1.2 YOLOv4 模型

如图 3, 选择 YOLOv4 模型来识别图像中缺陷的位置和类别。YOLOv4 结构包含 Input and Backbone、Neck 和 Prediction 三部分。Input and Backbone 部分是卷积神经网络, 用于细粒度提取图像特征; Neck 则混合和传递特征至预测层; Prediction 层生成边界框并预测类别。

1.3 模型剪枝

CBL 模块是 YOLOv4 网络结构中最小的组件, 由

作者简介: 陈欣 (1967-), 男, 湖北咸宁人, 高级工程师, 研究方向为海洋工程领域。




图2 DCGAN 结构示意图

Conv+Bn+Leaky_relu 三个激活函数组成。在 YOLOv4 的 CBL 模块中存在如下关系：内核卷积对应于十亿（批正常化）层，其中 BN 层的每个比例因子 γ 对应于一个特定的卷积通道或卷积层中的神经元层，如图 4 (a) 所示，修剪后，我们得到一个紧凑的 YOLOv4-PR 模型（如图 4 (b) 所示）。




图3 YOLOv4 神经网络结构框架




图4 通道剪枝算法剪枝原理图

2 试验

2.1 数据增强

原始图像收集与处理：

本研究使用的图像来源于 GC10-DET 数据集^[9]，图像大小为 2048×1000 ，为了确保减少计算量的同时能够识别缺陷，将图像的大小缩放到 416×416 。本研究缺陷为划痕、水渍、焊缝、冲孔、油斑、丝斑，如图 5 所示。

DCGAN 训练中，Learning rate 设置为 0.0002，epoch 设置为 12000。考虑到服务器的内存限制，将 Batch_size 设置为 64。从现有的 6 类图像中各选取 200-240 张图像作为表 1 中的原始图像。DCGAN 数据增强方法生成的图像数量如表 1 所示。

生成的图像和原始图像如图 6 所示。从图 6 中可以看出，DCGAN 生成的图片与真实图片的相似度非常高。

DCGAN 生成的图像与原始图像一起构成新的图像数据集。为了避免奇点的图像样本，选择 80% 的图像数据作为 YOLOv4 模型和 YOLOv4-PR 模型的训练集，其余 20% 作为验证集，用于测试和评估模型的性能。

2.2 YOLOv4 训练

经过多次参数调试，创建了一个高度精确的模型，网




图5 缺陷类型

表1 DCGAN 图像增强处理后的图像

	划痕	水渍	焊缝	冲孔	油斑	丝斑
原始图像	220	204	232	244	236	238
DCGAN 生成图像	480	496	468	456	464	462
总计图像	700	700	700	700	700	700




图6 真实(R)和生成(S)数据集的样本

络输入大小设置为 $416\text{px} \times 416\text{px}$, Learning rate 设置为 0.001, epoch 设置为 1000, Batch_size 设置为 8。图 7 为训练过程中的损失曲线, 当训练 Epoch 数达到 720 左右时, 模型的学习效率达到饱和, 损失值在 0.4–0.6 上下。




图7 YOLOv4 检测模型的训练损失曲线

2.3 模型剪枝与微调

2.3.1 稀疏训练

为使YOLOv4 模型具有高稀疏度和高精度, 在稀疏训练阶段, 通过多次实验和比较找到合适的参数: Scale Spare rate 设置为 0.005, Batch_size 设置为 8, Learning rate 设置为 0.008, Epochs 设置为 500。选择的稀疏类型为全局

稀疏, Gmma 的学习率衰减 0.1。稀疏训练的 mAP 曲线如图 8 所示, 可以看到学习率降低反弹后, mAP 最终达到了 0.546。




图8 稀疏训练 mAP

2.3.2 通道和层数剪枝

随着深度模型层数的增加, 误差越来越大, 难以收敛到较好的解。为建立高精度的 YOLOv4 模型, 我们首先利用全局阈值找到每个卷积层的掩码, 然后对连接到每一组快捷键(捷径结构)的每个卷积层的被修剪的掩码取并, 利用合并后的掩码进行剪枝。该方法不仅考虑了每个相关

表 3 原始数据和 DCGAN 数据建立

	Group_1	Group_2	Group_3	Group_4	Group_5
Data Type	Original	DCGAN Hybrid	DCGAN Hybrid	DCGAN Hybrid	DCGAN Hybrid
Number of Original Images	240	240	240	240	240
Number of DCGAN Images	0	100	200	300	400
Total number of Images	240	340	440	540	640
Model	YOLOv4	YOLOv4	YOLOv4	YOLOv4	YOLOv4
Training Epochs	300	300	300	300	300

表 4 原始数据和 DCGAN 数据实验结果

	Group_1	Group_2	Group_3	Group_4	Group_5
mAP	0.802	0.853	0.883	0.914	0.955
Precision	0.900	0.903	0.907	0.886	0.950
Recall	0.738	0.792	0.803	0.902	0.934

层,而且对每个层的保留通道进行了限制。通过试验发现当百分比为 0.43 时,mAP 和压缩参数达到最佳平衡,mAP 为 0.508762,参数为 24763394。

2.3.3 微调

修剪后模型的 mAP 有一定程度的损坏,因此需要对其进行微调,以尽可能地提高精度。微调参数设置如下: learning_rate 设置为 0.001,epoch 设置为 500,batch_size 设置为 8。调优后的 mAP 曲线如图 9 所示,微调后的 mAP 已经恢复到 93.4%。




图 9 微调后的 mAP

表 2 比较了原始 YOLOv4 模型和 YOLOv4-PR 模型的结果。与 YOLOv4 相比,YOLOv4-PR 模型参数数量减少了 61.26%,模型大小减少了 149.47MB,前向推理时间缩短了 4.3ms,mAP 减少了 1.6%。在检测速度方面,YOLOv4-PR 提高了 14.4 f/s,达到 65.4 f/s。

表 2 剪枝前后 YOLOv4 参数对比

Metric	YOLOv4	YOLOv4-PR
mAP	0.955	0.934
Total model parameters	63937686	24763394
Inference	0.0196	0.0153
Model size (MB)	243.97	94.5

2.4 试验结果及分析

为了验证 DCGAN 对数据增强的有效性,我们进行了 5 组对比实验。数据如表 3 所示。每组训练步骤设置为 300。

五组实验结果对比如表 4 所示。可以看出,使用 DCGAN 增强数据集的组的 mAP 一般高于未进行数据增

强的组,并且进行数据增强的样本数量越多,mAP 越高。其中,第五组的 mAP 最高可达 95.5%,比仅使用原始数据集的第一组 mAP 高出 15.3%。实验表明,采用 DCGAN 数据增强技术对钢的缺陷检测是有效的。

3 结论

①提出利用 DCGAN 网络进行小样本数据增强,增强后的数据集 mAP、精度和召回率在 YOLOv4 中分别可以达到 95.5%、95%、93.4%,比仅使用原始数据的 mAP、精度和召回率分别提高了 15.3%、5.0%、19.6%。②YOLOv4-PR 模型参数数量减少 61.26%,模型大小减少 149.47MB。在检测精度方面,YOLOv4-PR 的 mAP 为 0.934,仅比 YOLOv4 低 0.016。在检测速度方面,YOLOv4-PR 的检测速度为 65.4f/s,比 YOLOv4 的检测速度高 14.4f/s。

参考文献:

- [1]Krizhevsky A, Sutskever I, Hinton GE. Imagenet classification with deep convolutional neural networks. Advances in neural information processing systems. 2012 25.
- [2]Bodapati JD, Veeranjanyulu N. Feature extraction and classification using deep convolutional neural networks. Journal of Cyber Security and Mobility. 2019 261-76.
- [3]Baker N, Lu H, Erlikhman G, Kellman PJ. Local features and global shape information in object classification by deep convolutional neural networks. Vision research. 2020 Jul 1 172: 46-61.
- [4]Rawat W, Wang Z. Deep convolutional neural networks for image classification: A comprehensive review. Neural computation. 2017 Aug 24 29(9) 2352-449.
- [5]Unterberg M, Niemietz P, Trauth D, Wehrle K, Bergs T. In-situ material classification in sheet-metal blanking using deep convolutional neural networks. Production Engineering. 2019 Dec 13(6) 743-9.
- [6]Wang S, Xia X, Ye L, Yang B. Automatic detection and classification of steel surface defect using deep convolutional neural networks. Metals. 2021 Mar 11(3) 388.
- [7]Xu Y, Zhang K, Wang L. Metal Surface Defect Detection Using Modified YOLO. Algorithms. 2021 Sep 14(9) 257.
- [8]Fu G, Sun P, Zhu W, Yang J, Cao Y, Yang MY, Cao Y. A deep-learning-based approach for fast and robust steel surface defects classification. Optics and Lasers in Engineering. 2019 Oct 1 121 397-405.
- [9]Lv X, Duan F, Jiang JJ, Fu X, Gan L. Deep metallic surface defect detection: The new benchmark and detection network. Sensors. 2020 Jan 20(6) 1562.