

基于 I-YOLO 模型的轴瓦零件缺陷视觉检测方法

吴晓成, 缪晨炜, 王要波, 陈 鹏

(中国船舶重工集团公司第七〇三研究所, 江苏 无锡 214151)

摘 要: 轴瓦是水力测功器的重要零部件, 其质量影响机组的安全运行。基于传统机器视觉的轴瓦缺陷检测方法存在准确率低、漏检率高的问题。针对该问题, 提出一种基于改进 YOLO 模型的轴瓦缺陷检测方法。首先, 对数据集进行图像预处理, 扩大训练样本; 然后, 改进 YOLO 模型结构, 通过候选框维度聚类和多尺度训练, 提出一种新的 I-YOLO 深度学习模型; 最后, 在轴瓦数据集训练和测试 I-YOLO 模型, 并将该模型与 YOLOv4、YOLOv3 模型进行对比。结果表明, 改进的 I-YOLO 模型在轴瓦缺陷检测中的准确率达到 98.73%, 比 YOLOv4、YOLOv3 模型分别提高了 3.01%、10.88%, 证明改进的模型能在提高检测准确率的同时有效降低漏检率。

关键词: 深度学习, 轴瓦, 卷积神经模型, 视觉识别, 缺陷检测

中图分类号: TP391

文献标识码: A

DOI: 10.19769/j.zdhy.2024.04.057

Visual Detection Method for Defects in Bearing Parts Based on I-YOLO Model

WU Xiaocheng, MIU Chenwei, WANG Yaobo, CHEN Peng

(703rd Research Institute of China Shipbuilding Industry Corporation, Wuxi, Jiangsu 214151, China)

Abstract: Bearing is an important component of hydraulic dynamometer, and its quality affects the safe operation of the unit. The traditional machine vision based bearing defect detection method has the problems of low accuracy and high missed detection rate. A bearing defect detection method based on an improved YOLO model is proposed to address this issue. Firstly, image preprocessing is performed on the dataset to expand the training samples. Then, by improving the YOLO model structure, a new I-YOLO deep learning model is proposed through candidate box dimension clustering and multi-scale training. Finally, train and test the I-YOLO model on the bearing dataset, and compare it with the YOLOv4 and YOLOv3 models. The result shows that the improved I-YOLO model achieves an accuracy of 98.73% in bearing defect detection, which is 3.01% and 10.88% higher than the YOLOv4 and YOLOv3 models, respectively. This proves that the improved model can effectively reduce the missed detection rate while improving detection accuracy.

Key words: deep learning, bearings, convolutional neural models, visual recognition, defect detection

0 引言

水力测功器一直是测量和诊断发动机性能的重要设备之一,而作为水力测功器上的重要零部件,轴瓦在动力试验领域发挥着至关重要的作用。由于材料特性和加工工艺的限制,轴瓦在生产过程中不可避免地会出现裂纹、破损、凹坑等表面缺陷,若存在缺陷的轴瓦直接安装在机组,将严重影响机组的安全运行,因此,在水力测功器检修过程中,必须检测轴瓦的表面缺陷。

缺陷检测是机器视觉检测技术中的一个重要研究领域^[1]。目前,在工业过程中通常使用人工检测来检测轴瓦的表面缺陷,这种方法不仅准确率低,还严重影响工业生产效率。为提高工业生产效率,基于机器视觉的缺陷检测技术已广泛应用于工业产品的表面质量控制。文献[2]基

作者简介:吴晓成,男,1995年生,硕士,研究方向为测量与控制, E-mail:615282445@qq.com。

于图像差分及邻域特性自动检测航空磁环的表面缺陷,通过图像差分及邻域特性算法提取缺陷区域并检测缺陷。文献[3]先对锂电池极片缺陷图片进行感兴趣区域(ROI)提取,并采用预处理对缺陷特征进行突出、分割、填充,以保证缺陷检测的准确性。文献[4]提出一种结合图像双边滤波和区域生长的算法,该算法能准确识别电池极片的缺陷。传统缺陷检测算法通过特征提取算法可以设计特征识别算法,获得较好的检测效果,但对于缺陷形态不规则、位置随机的工业制品,单一的特征提取算法难以满足检测精度与速度的要求。

近年来,深度学习在目标检测领域取得显著进展^[5]。文献[6]提出改进的 Faster R-CNN 深度学习网络,通过加强小目标缺陷的检测能力提高棉布包装缺陷的检测精度。文献[7]提出一种改进的 Mask RCNN 实例分割网络实现对图像的缺陷检测和分割。文献[8]提出一种用于印刷电路板缺陷检测的密集 YOLOv3 目标检测算法,在优化算法结

构的同时提高了识别精度。其中, YOLO^[9]模型将目标识别问题转化为回归问题, 实现了端到端的目标检测, 同时具备了较快的检测速度和较高的识别精度, 在轴瓦检测方面显示了重要的研究价值和应用潜力。

针对轴瓦缺陷的特征以及工业实时在线检测的要求, 本文提出了一种基于改进 YOLO 模型的轴瓦缺陷检测方法。首先, 采用图像增强扩充原始图像, 增加训练样本数量, 提高轴瓦缺陷的特征清晰度及模型鲁棒性; 然后, 改进 YOLO 模型结构, 增加模型预测尺度, 增强对微小缺陷的辨识能力; 最后, 重新聚类分析轴瓦缺陷目标框, 通过多尺度训练的方法, 使模型对不同尺度的图像有更强的泛化能力, 以提高模型的适应性和准确率。

1 数据集构建

在深度学习和目标检测研究中, 测试与实验所需的数据集必不可少。本文通过调整饱和度、曝光量、色调、几何变换等数据增广方法对轴瓦初始数据集进行人为数据扩充, 形成轴瓦缺陷数据集。轴瓦缺陷数据集中包含轴瓦常见的部分缺陷: Blowhole 缺陷、Crack 缺陷、Fray 缺陷、Uneven 缺陷。部分缺陷示意图如图 1 所示。其中, 训练集和测试集按 9:1 的比例进行划分。




图 1 部分缺陷示意图

2 方法

本文以识别轴瓦缺陷展开研究, 提出了一种基于 YOLO 模型改进的 I-YOLO 模型缺陷检测方法, 设计的结构框架如图 2 所示。




图 2 轴瓦缺陷检测结构框架

首先, 构建混合轴瓦数据集, 对轴瓦缺陷图像进行模型训练, 通过损失函数不断调整训练参数, 得到改进后 I-YOLO 模型; 然后, 将轴瓦缺陷图像输入 I-YOLO 模型进行缺陷检测(该模型以 Darknet-53 为主干网络进行特征提

取, 能快速预测边界框, 提高所属类特征的识别精度); 最后, 通过融合多尺度识别方法, 快速精确地识别缺陷种类及位置。

2.1 多尺度识别的模型结构

I-YOLO 采用了跨尺度检测方法。首先, 该模型会通过卷积神经网络扩充到 19×19 的特征尺度(下采样倍数为 32), 适合检测轴瓦图像中较大的缺陷目标。然后, 19×19 的特征尺度通过乘 2 采样扩充到 38×38 的特征尺度, 并与上层中 38×38 的特征尺度拼接得到新的 38×38 特征尺度(下采样倍数为 16), 适合检测轴瓦图像中中等的缺陷目标。最后, 38×38 的特征尺度通过乘 2 采样扩充到 76×76 , 并与上层中 76×76 的特征尺度拼接得到新的 76×76 特征尺度(下采样倍数为 8), 适合检测轴瓦图像中较小的缺陷目标。但轴瓦缺陷图像中的部分缺陷非常微小, YOLO 模型在识别这些微小缺陷时, 尺度仍稍显不足, 为使模型对微小缺陷更敏感, 本文在原 YOLO 中 3 尺度基础上再通过乘 2 上采样增加至 4 尺度: 152×152 尺度。该尺度可为轴瓦图像中的微小缺陷分配更准确的候选框。其具体改进结构如图 3 的方框处。




图 3 改进的 I-YOLO 模型结构

2.2 目标框聚类分析

锚点框(Anchor Boxes)是一组固定尺寸大小和宽高比的初始候选框, 其尺寸直接影响目标检测的速度和精度。由于轴瓦中部分缺陷的体积较小, 导致其宽高比与 PASCAL_VOC、COCO 等数据库中获取的比例存在明显不同。因此, 本文需通过 k-means 聚类算法重新计算混合轴瓦数据集初始候选框的宽高比维度, 以提升模型定位的精准度。

本文按不同的 Anchor Boxes 数量进行聚类后, 最终得到的对应平均交并比如图 4 所示。虽然增加初始候选边框的数量会导致模型的检测速度变慢, 但本文权衡了平均交

并比与 Znchor 的数量关系,并综合考虑了检测的准确性,最终选取了9个 Anchors,分别为(32,127)、(36,19)、(70,295)、(88,25)、(111,42)、(182,100)、(234,269)、(511,113)、(561,35)。




图4 锚点框数量与平均交并比的关系

2.3 多尺度训练

训练分类模型是分类检测的重要环节。其中,模型训练的优劣会明显影响模型提取特征的能力和速度。本文采用分辨率不同的自制数据集进行多尺度训练,具体改进如下。(1)采用 320×320 低分辨率的图像数据集进行预训练。(2)采用 416×416 分辨率的轴图像数据集微调模型,使模型适应中等分辨率的轴瓦缺陷特征。(3)中等分辨率输入模型微调完成后,在 1 280 分辨率的图像数据集进行迭代,使模型逐层调整权重,以适应高分辨率轴瓦缺陷图像数据集中的缺陷特征。

3 实验结果与讨论

3.1 训练模型

表1为本文实验平台参数表。本文采用自制混合数据集从零开始训练模型,以开源深度学习框架 Darknet 为基础,以改进的 I-YOLO 为模型,结合维度聚类分析、模型预训练、多尺度训练模型的方法,训练轴瓦缺陷检测模型。本文在同样的实验环境下采用相同的数据集重新训练了 YOLOv4 模型、YOLOv3 模型,以便于在测试集与本文模型 I-YOLO 的检测结果进行对比。

表1 实验平台参数表

名称	相关配置
中央处理器	Intel(R) Core(TM) i7-8700@3.2 GHz
内存	2×USCORSAIR DDR4 3000 MHz 8 GB
GPU	NVIDIA GeForce RTX 2070
GPU 加速器	CUDA10.1, CUDNN10.0
操作系统	Ubuntu16.04
数据处理	Python, OpenCV
深度学习框架	Darknet

3.2 模型性能评价

由于本文研究内容属于多目标检测,因此,改进的模型需通过 Precision、Recall、AP、mean Average Precision (mAP) 进行综合对比,P-R 曲线下的面积即为 AP 大小。P、R、mAP 的计算公式为:

$$P = TP / (TP + FP) \quad (1)$$

$$R = TP / (TP + FN) \quad (2)$$

$$mAP = (AP_{\text{Blowhole}} + AP_{\text{Break}} + AP_{\text{Crack}} + AP_{\text{Fray}} + AP_{\text{Uneven}}) / 2 \quad (3)$$

以 Fray 缺陷为例,其中,TP 为模型识别 Fray 缺陷的正确数量,FP 为模型将其他缺陷误检为 Fray 缺陷的数量,FN 为模型将 Fray 缺陷识别误检为其他缺陷的数量,AP 为单个缺陷的识别精度,mAP 为所有缺陷类别的 AP 均值,也为评价检测模型准确性的直观评价标准。

模型训练时,如学习率、损失函数值等多个参数不断进行动态变化,使得模型表现与迭代次数之间无法形成严谨的线性对应关系。因此,判断模型的优劣不仅要结合上述评价指标,更应考虑模型的收敛性。只有模型在正确率较高且收敛性好的情况下,模型进行预测时才能保持鲁棒性和稳定性。图5为 I-YOLO 模型训练过程中损失值的收敛曲线。其中,loss 值代表预测框图与实际框图的误差值,loss 值越低代表缺陷检测的精度越高。完成 10 000 次的模型训练后,各项参数的已基本稳定,观察损失值的收敛程度,可判断模型的训练效果较理想。




图5 损失曲线

为定量分析本文方法实验效果,本文分别在数据集中使用 I-YOLO、YOLOv4、YOLOv3 这3种模型计算4种缺陷的平均准确率(AP)与平均精准度均值(mAP),基于不同模型的缺陷检测算法的检测结果对比如表2所列。基于 I-YOLO 模型的缺陷检测算法对磁瓦缺陷检测的平均准确率为 98.73%,与其他模型检测结果对比均有明显提高。在单类缺陷的检测效果方面,I-YOLO 模型针对 Blowhole 缺陷和 Fray 缺陷的检测效果最佳,识别精确率均为 100%;在检测时间方面,I-YOLO 模型单幅图片的识别时间略有延长,达到 24.2 ms。与 YOLOv4、YOLOv3 相比,本文方法的网络模型更复杂,但仍满足工业生产需求。

表2 基于不同模型的检测结果对比

模型	评价指标					处理 时间/ms
	AP				mAP	
	Blowhole	Crack	Fray	Uneven		
I-YOLO	100%	98.71%	100%	96.21%	98.73%	24.2
YOLOv4	99.76%	90.55%	100%	92.57%	95.72%	20.6
YOLOv3	96.30%	82.10%	91.30%	81.70%	87.85%	30.5

基于不同模型的检测效果对比如图6所示。图6(a)中,3种模型均能成功识别 Blowhole 缺陷。图6(b)中,YOLOv3 模型检测 Crack 缺陷时发生了遗漏现象,而 I-YOLO 模型

则较好地检测了 Crack 缺陷。图 6(c)、(d)中,对于 Fray 缺陷和 Uneven 缺陷,I-YOLO 模型能完整地检测该类别的缺陷,但 YOLOv4、YOLOv3 均出现漏检。由此说明,若缺少多尺度检测结构,则微小的缺陷特征也无法被准确识别,这也从侧面更验证了增加尺度预测结构对提高模型识别精度的重要性。




图 6 基于不同模型的检测效果对比图

本文提出的基于 I-YOLO 模型的缺陷检测算法在测试轴瓦数据集时具有更高的准确率,改进效果明显,在检测精度与检测效率上均优于其他算法。分析其原因,一方面,本文改进了 YOLOv3 中的尺度检测模块,将原有的 3 个尺度检测扩展为 4 个尺度,增加了 152×152 的尺度,使得 I-YOLO 模型可在较大特征图上给微小目标分配更准确的候选框;另一方面,通过维度聚类候选框后,本文重新确定了 Anchor Box 的大小,以便让模型更适合本数据及中轴瓦缺陷的检测,并通过多尺度训练使模型适应不同尺度的输入图像,进一步提高了缺陷检测的准确率。

4 结语

针对目前水力测功器轴瓦表面缺陷的检测问题,本文

提出了基于改进 YOLO 模型的解决方法,解决了传统轴瓦缺陷检测算法准确率低、漏检率高的问题。从实验结果来看,本文提出的模型识别准确率为 98.73%,同时单张图片检测速度达到了 24.2 ms。与基于其他算法的缺陷检测方法相比,本文算法具有较高的正检率和较低的误检率,并具有较强的鲁棒性。由于改进模型的结构更复杂,计算量更大,下一步的工作将着力扩充数据集,同时在不影响检测精度的前提下进一步加快速度,加强模型对复杂场景的应变能力。本文的研究可用于轴瓦及其他工业零件表面缺陷的视觉检测。

参考文献

[1] 杨泽青,张明轩,陈英妹,等.基于机器视觉的表面缺陷检测方法研究进展[J].现代制造工程,2023(4):143-156.

[2] 陈琳琳,邓华军,张殿喜,等.基于图像差分及邻域特性的航空磁环缺陷检测[J].科技创新与应用,2023,13(23):50-53.

[3] 毛伟生,李林升,周文一,等.基于小波阈值与区域分裂合并的锂电池极片缺陷检测方法[J].国外电子测量技术,2022,41(8):46-53.

[4] 王庆秋,李林升,毛晓,等.基于双边滤波与区域生长的锂电池极片缺陷检测方法[J].机械设计与研究,2022,38(2):158-162.

[5] 罗东亮,蔡雨莹,杨子豪,等.工业缺陷检测深度学习方法综述[J].中国科学:信息科学,2022,52(6):1002-1039.

[6] 曾秀云,陆华才,吕禾丰.基于改进 Faster R-CNN 的棉布包装缺陷检测的方法研究[J].电子测量与仪器学报,2022,36(4):179-186.

[7] 杨彬,亚森江·木沙,安波.改进 Mask RCNN 的焊缝缺陷检测[J].机械设计与制造,2023(6):157-161.

[8] 杨杰,张书杰.基于密集 YOLOv3 的印刷电路板缺陷识别[J].北京邮电大学学报,2022,45(5):42-48.

[9] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Computer Vision & Pattern Recognition, 2016:1-10.

(责任编辑:黄 霞)