

基于 KAS-YOLO 的钢板表面缺陷检测^{*}

敖思铭^{a,b,c}, 周诗洋^{a,b,c}, 杨智颖^{a,b,c}, 刘怀广^{a,b,c}

(武汉科技大学 a. 冶金装备及其控制教育部重点实验室; b. 机械传动与制造工程湖北省重点实验室; c. 精密制造研究院, 武汉 430081)

摘要: 针对当前基于视觉的钢板表面缺陷检测方法对小缺陷目标识别困难造成检测精度低的问题, 提出一种基于 YOLOv5s 的钢板表面缺陷检测模型 KAS-YOLO。首先, 通过使用空洞空间金字塔池化模块来获取更大的感受野以提取更多表面缺陷的特征信息, 并融入坐标注意力机制来提高特征提取能力; 其次, 用 K-means 算法聚类得到更匹配的锚框, 不仅增加了正样本的数量, 而且加速了模型的收敛; 最后, 采用 SIoU 损失函数来进一步提升模型对表面缺陷目标的定位和检测能力。实验结果表明, 提出的 KAS-YOLO 模型对钢板表面缺陷的检测精度和速度优于 Faster R-CNN、SSD、RetinaNet 和 YOLOv5s 等主流检测方法。

关键词: 钢板表面缺陷; YOLOv5s; 注意力机制; 锚框; 损失函数

中图分类号: TH165; TG659

文献标识码: A

Surface Defect Detection of Steel Plate Based on KAS-YOLO

AO Siming^{a,b,c}, ZHOU Shiyang^{a,b,c}, YANG Zhiying^{a,b,c}, LIU Huaiguang^{a,b,c}

(a. Key Laboratory of Metallurgical Equipment and Control, Ministry of Education; b. Hubei Key Laboratory of Mechanical Transmission and Manufacturing Engineering; c. Precision Manufacturing Institute, Wuhan University of Science and Technology, Wuhan 430081, China)

Abstract: As the difficulty in identifying small defect targets, the vision-based of steel plate surface defect detection method has the problem of low detection accuracy. The model KAS-YOLO based on YOLOv5s is proposed for steel plate surface defect detection. Firstly, the hollow space pyramid pooling module is used to obtain a larger receptive field to extract more feature information of surface defects, and coordinate attention mechanism is chosen to improve the feature extraction ability. Then the K-means algorithm is used to obtain a more matched anchor frame, which not only increases the number of positive samples, but also accelerates the convergence of the model. Finally, the loss function of SIoU is used to improve the ability of locating and detecting for surface defect targets furtherly. The experimental results show that the proposed KAS-YOLO model is superior to the methods such as Faster R-CNN, SSD, RetinaNet and YOLOv5s in the detection accuracy and speed for the detection of steel plate surface defects.

Key words: surface defect of steel sheet; YOLOv5s; attention mechanism; anchor; loss function

0 引言

在钢板生产制造过程中, 由于技术水平的参差不齐和实际生产环境差等因素, 其表面时常会出现多种缺陷, 例如裂纹、划痕和斑块等。这些缺陷会引发钢板性能的下降。因此, 对钢板表面进行质量检测对于提高产品的市场竞争力具有重要的意义。传统的人工检测方法仅依赖人眼判断, 容易出现漏检或误检^[1-3]。随着机器视觉技术的快速发展, 基于视觉检测的方法广泛地应用于钢板表面缺陷检测中, 一种是基于显示特征提取的传统方法, 一种是基于自动提取特征的深度

学习方法^[4]。WEN 等^[5]为了解决复杂的感兴趣的钢板表面区域的检测, 提出了一种将 2D 灰度信息和 3D 深度信息进行融合的方法。WANG 等^[6]在缺陷的各种图案、伪缺陷的干扰以及背景中灰度的随机排列情况下, 为了准确定位缺陷, 提出了一种以简单引导模板为基础的带钢表面缺陷检测算法。HOU 等^[7]为了提高精度并节省运行时间, 提出了一种基于二阶锥规划优化的多核向量机方法。上述传统的机器视觉检测方法的通用性较低、对缺陷检测环境的要求较高、缺陷检测装置成本较高。

基于深度学习的目标检测方法有两种, 一种方法

收稿日期: 2023-10-08; 修回日期: 2023-11-15

^{*} 基金项目: 国家自然科学基金项目(51805386)

作者简介: 敖思铭(1996—), 男, 硕士研究生, 研究方向为缺陷检测、深度学习, (E-mail) 1162194096@qq.com; 通信作者: 周诗洋(1987—), 男, 副教授, 硕士生导师, 博士, 研究方向为产品表面质量检测, (E-mail) zhoushiyang@wust.edu.cn。

引用本文: 敖思铭, 周诗洋, 杨智颖, 等. 基于 KAS-YOLO 的钢板表面缺陷检测[J]. 组合机床与自动化加工技术, 2024(8): 168-174.

AO Siming, ZHOU Shiyang, YANG Zhiying, et al. Surface defect detection of steel plate based on KAS-YOLO[J]. Modular Machine Tool & Automatic Manufacturing Technique, 2024(8): 168-174.

是通过卷积神经网络 (convolutional neural networks, CNN) 对每个目标建议区域进行分类,以确定其所属的目标类别,这种方法可以被看作是两阶段目标检测方法,如 R-CNN^[1]、Fast R-CNN^[2]、Faster R-CNN^[3]等;另一种方法是目标检测看作回归问题,使用 CNN 得到边界框的位置及其所属的类别,这种方法可以被看作是一阶段目标检测方法,如 YOLO^[4-6]、SSD^[7]等。LIN 等^[8]结合单目标检测方法提出了 RetinaNet 模型并利用 Focal Loss 损失函数解决了前景和背景类别不平衡的问题,提高了对困难样本的识别精度。由于小缺陷目标在图像中的像素占比小,上述方法通过使用卷积网络进行特征提取得到的特征信息不足以对小目标进行准确地表达^[6-9]。杨慧剑等^[10]以 YOLOv5 为基础,针对航拍图像中目标占比小的问题,采用数据增强、融入注意力和使用空洞空间金字塔池化 (atrous spatial pyramid pooling, ASPP)^[11] 替换空间金字塔池化结构 (spatial pyramid pooling, SPP) 等,提高了航拍小目标的检测能力。ZHANG 等^[12]针对小目标检测不佳问题,在 YOLOv5 上结合坐标注意力机制 (coordinate attention, CA)^[13] 和上下文特征增强模块,提高了小目标检测方面的性能。邹旺等^[14]提出了一种结合多尺度检测与空间注意力机制的改进 YOLOv4-tiny 算法,其带钢表面缺陷检测的精确性和检测速度都有所提升。杜少聪等^[15]提出一种使用图像增强、嵌入多头注意力和融入浅层信息的改进 YOLOv5 的钢轨表面缺陷检测的算法,实现不同环境缺陷的精准检测。曹义亲等^[16]提出了一种使用带残差边的 SPP_Res 特征金字塔结构,引入了多头注意力机制,并融合浅层和深层特征的改进的 YOLOv5 算法,提升了钢材表面缺陷检测的准确性。李鑫等^[17]提出了一种改进的 YOLOv5s-GSD 算法,通过使用 GhostBottleneck 结构替换 C3 模块和部分卷积,引入 SE 注意力机制以及使用 DW 卷积替换部分标准卷积,虽然检测精度比原 YOLOv5s 提高了 3.3%,但存在部分缺陷的预测锚框 (anchor box) 不匹配等问题。李维刚等^[18]提出了一种使用 K-means 选取锚框和融合浅层、深层特征的改进的 YOLOv3 算法,提高了小缺陷目标的检测精度。梁秀满等^[19]提出了一种改进特征提取模块、特征融合模块和损失函数 SIoU^[20] 的改进 YOLOv4 算法,实现了带钢缺陷的实时检测。上述检测方法在钢板表面检测方面取得了很大的进步,但依然存在如下问题:①由于钢板缺陷往往是小目标,缺陷的尺寸较小,很容易被忽略或错误地分类为正常区域导致对小目标缺陷的检测效果不佳,容易产生漏检;②由于钢板表面缺陷的形状大小不一,导致预测锚框和实际缺陷目标的位置和大小匹配不准确。

针对上述问题,本文以 YOLOv5s 为基础,采用 ASPP 模块获取更大感受野以提高小缺陷目标的识别能力;通过融入注意力模块 CA,增强缺陷目标位置信息的敏感度,以更准确地定位和识别小缺陷目标;优化自适应锚框算法,获得匹配度更高的锚框参数,有助于模型快速收敛;采用 SIoU 损失函数来提高模型的训练效率以及增强边界框预测的稳定性。

1 YOLOv5s 模型概述

1.1 网络结构

YOLOv5s 是一种轻量级的深度学习模型,包括输入端、骨干网络、颈网络和预测网络。输入端通过采用 Mosaic 数据增强方式,对图像进行缩放、翻转等操作。其次,通过自适应锚框功能对输入的数据集匹配较合适的锚框。骨干网络主要用来提取特征,其主要包括 Conv、Focus、C3 和 SPP。其中 Conv 是卷积模块,主要是提取特征,并通过归一化操作加速模型的收敛,从而提高目标检测的准确率。Focus 模块通过图片进行切片操作来减少计算开销,提升速度。C3 模块中包含了 3 个标准卷积层以及多个 Bottleneck 模块,通过融合由不同尺度的卷积层提取到的不同层次的特征来捕捉目标的尺度和语义信息,并加快网络的运行速度。SPP 模块的核心思想就是将输入图像并行通过多个不同大小的最大池化层进行下采样后与原输入进行拼接,扩大了感受野的同时也保留了更多的上下文特征和边缘信息。通过聚合不同池化尺度信息,网络能够获取更丰富的信息。颈网络是具有特征融合功能的网络,通过结合特征金字塔网络和路径聚合网络,可以实现图像的多尺度特征融合。预测网络综合采用 CIoU 损失函数和非极大值抑制算法,根据 3 个检测终端结合特征信息预测不同尺度的输出。

1.2 损失函数

YOLOv5s 损失函数由置信度损失 L_{conf} 、分类损失 L_{cls} 和位置损失 L_{box} 三部分组成,表达式为:

$$L = L_{\text{conf}} + L_{\text{cls}} + L_{\text{box}} \quad (1)$$

置信度损失表达式为:

$$L_{\text{conf}} = - \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{\text{obj}} [\bar{C}_i^j \log C_i^j + (1 - \bar{C}_i^j) \log (1 - C_i^j)] - \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{\text{noobj}} [\bar{C}_i^j \log C_i^j + (1 - \bar{C}_i^j) \log (1 - C_i^j)] \quad (2)$$

式中: S^2 为网格数, B 为锚框数, I_{ij}^{obj} 为第 i, j 处有无目标,有目标取 1,反之取 0; I_{ij}^{noobj} 为预测框是否包含目标,包含取 0,反之取 1; C_i^j 为预测置信度, $\bar{C}_i^j$ 为真实置信度。

分类损失表达式为:

$$L_{\text{cls}} = - \sum_{i=0}^{S^2} I_{ij}^{\text{obj}} \{ \bar{P}_i^j(c) \log [P_i^j(c)] + [\bar{P}_i^j(d) - \bar{P}_i^j(c)] \log [\bar{P}_i^j(d) - P_i^j(c)] \} \quad (3)$$

式中: c 为检测目标所属的种类, $P_i^j(c)$ 为预测概率, $\bar{P}_i^j(c)$ 为目标属于类别 c 的实际概率。

位置损失采用的是 CIoU 损失函数,表达式为:

$$L_{\text{box}} = 1 - IoU + \frac{\rho^2(B, B^{\text{gt}})}{m^2} + \alpha v \quad (4)$$

式中: IoU 为预测框和真实框的交并比, (B, B^{gt}) 为预测框和真实框的中心点坐标, $\rho^2(B, B^{\text{gt}})$ 为欧氏距离, m 为同时包含预测框和真实框的最小外接矩形的对角线距离, α 为权重系数, v 为长宽比一致性参数,其中,

$$\alpha = \frac{v}{1 - IoU + v} \quad (5)$$

$$v = \frac{4}{\pi^2} \left(\arctan \frac{\omega_{\text{gt}}}{h_{\text{gt}}} - \arctan \frac{\omega}{h} \right)^2 \quad (6)$$

式中: ω_{gt} 和 h_{gt} 为真实框的宽和高, ω, h 分别为预测框

$$g^h = \sigma(F_h(f^h)) \quad (10)$$

$$g^w = \sigma(F_w(f^w)) \quad (11)$$

将输出 g^h 和 g^w 合并成权重矩阵,得到 CA 输出:

$$y_c(i,j) = x_c(i,j) \times g_c^h(i) \times g_c^w(j) \quad (12)$$

最后输出的 $y_c(i,j)$ 不仅考虑到空间和通道之间的关系,还考虑到长距离依赖问题,增加对目标位置的关注度,使得算法更加注重目标区域的细节和特征。通过增强模型对目标位置信息的敏感度可以更准确地定位和识别小缺陷目标,提高模型检测效果。

2.3 锚框生成优化

预设锚框是用于辅助目标检测的重要参数,用于定义不同尺度下的默认框,以便在训练过程中更好地适应不同大小的目标。由于包络钢板表面缺陷目标的

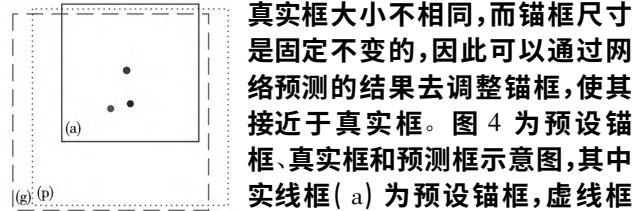


图 4 锚框、真实框和预测框示意图

三者关系的表达式为:

$$\begin{aligned} t_x^p &= \frac{x_p - x_a}{w_a}, t_y^p = \frac{y_p - y_a}{h_a} \\ t_w^p &= \log\left(\frac{w_p}{w_a}\right), t_h^p = \log\left(\frac{h_p}{h_a}\right) \\ t_x^g &= \frac{x_g - x_a}{w_a}, t_y^g = \frac{y_g - y_a}{h_a} \\ t_w^g &= \log\left(\frac{w_g}{w_a}\right), t_h^g = \log\left(\frac{h_g}{h_a}\right) \end{aligned} \quad (13)$$

式中: (t_x^p, t_y^p) 为预测框中心点相对锚框的中心点的偏移量, (t_w^p, t_h^p) 为预测框相对锚框的宽高缩放系数, (t_x^g, t_y^g) 为真实框标注框中心点相对锚框的中心点的偏移量, (t_w^g, t_h^g) 为真实标注框相对锚框的宽高缩放系数。

式(13)中的前两个子式是通过网络预测的偏移量对预设锚框进行调整来获得预测框,中心点的计算要除以锚框的宽和高进行归一化,预测框的宽高取 $\log$ 是为了抑制过长或过宽的物体对整体网络损失的影响。后两个子式是通过计算真实框与预测框之间的偏移量对网络造成的损失来调整网络参数。因此,预设锚框设置的好坏在一定程度上会影响网络预测的结果,本文采用 1-IoU^[1] 作为评价指标,使用 K-means 算法对钢板表面缺陷图像数据集进行聚类,并根据遗传算法对聚类结果进行变异,计算出预选锚框,其结果如表 1 所示。

表 1 锚框对比表

YOLOv5s 锚框	KAS-YOLO 锚框
(10,13)	(48,90)
(16,30)	(127,82)
(33,23)	(73,193)
(30,61)	(56,586)
(62,45)	(199,235)
(59,119)	(567,101)
(116,90)	(117,550)
(156,198)	(246,562)
(373,326)	(636,636)

使用 K-means 算法,具体步骤为:

步骤 1: 随机选取簇的个数 K ;

步骤 2: 簇的初始中心的随机选取;

步骤 3: 每个样本分配到距离最近的簇中;

步骤 4: 更替簇中心,每个簇中样本均值为新的簇中心;

步骤 5: 重复上面两步,直到簇中心不在变化或变化很小满足给定终止条件。

改进后的锚框和原锚框采用 BPR(best possible recall) 进行比较,BPR 的值越接近 1 表明锚框效果越好。由表 2 可知,改进后的锚框结果优于原锚框。

$$BPR = g^{t_{call}} / g^{t_{total}} \quad (14)$$

式中: $g^{t_{call}}$ 为召回的真实标注框总数目, $g^{t_{total}}$ 为原真实标注框总数目。

表 2 锚框 BPR 对比表

模型	BPR
YOLOv5s	0.981 7
KAS-YOLO	0.999 2

2.4 损失函数改进

损失函数 CIoU 对于预测框和真实框之间的位置偏移非常敏感,微小的位置偏移也会导致 CIoU 值大幅变化,无法准确反映目标检测框质量。由于 CIoU 在计算时需要考虑预测框和真实框的中心点距离,以及宽高比之间的差异,可能会导致边界预测的不稳定。本文以 SIoU 损失函数为基础,进一步考虑真实框和预测框之间的向量角度,在 SIoU 损失函数计算边界框的重叠程度时,引入一个惩罚项,可以减小边界框的偏移,从而提高了边界框预测的稳定性。具体包含 4 个部分: 角度损失、距离损失、形状损失和 IoU 损失。图 5 为 SIoU 损失计算示意图。




图 5 SIoU 损失计算示意图

角度损失公式为:

$$\Delta = 1 - 2 * \sin^2\left(\arcsin(x) - \frac{\pi}{4}\right) \quad (15)$$

式中:

$$x = \frac{c_h}{\sigma} = \sin(\alpha)$$

式中: σ 为预测框中心点与真实框中心点的距离, c_h 为预测框中心点与真实框中心点的高度差。

距离损失公式为:

$$\Delta = \sum_{t=x,y} (1 - e^{-\gamma t}) \quad (16)$$

式中:

$$\rho_x = \left(\frac{b_x^{gt} - b_x}{c_w}\right)^2, \rho_y = \left(\frac{b_y^{gt} - b_y}{c_w}\right)^2, \gamma = 2 - \Delta$$

当 α 趋于 0° 时,距离损失的贡献就会减小; 当 α 趋于 45° 时,距离损失的贡献就会增加。

形状损失公式为:

$$\Omega = \sum_{t=w,h} (1 - e^{-\omega t})^\theta \quad (17)$$

式中: $\omega_w = \frac{|w - w^{gt}|}{\max(w, w^{gt})}$, $\omega_h = \frac{|h - h^{gt}|}{\max(h, h^{gt})}$, (w, h) 和 (w^{gt}, h^{gt})

h^{gt}) 分别是预测框和真实框的宽高,通过 θ 对形状损失进行控制, θ 的参数范围为 $[2,6]$ 。

IoU 损失公式为:

$$IoU = \frac{|B \cap B^{gt}|}{|B \cup B^{gt}|} \quad (18)$$

综上所述,SIoU 损失函数为:

$$L_{Siou} = 1 - IoU + \frac{\Delta + \Omega}{2} \quad (19)$$

3 实验结果与分析

3.1 实验环境及数据集

本文的实验选用 NEU-DET 钢板表面缺陷数据集的 3 类有缺陷样本,以及现场采集的 1 类无缺陷样本,每类图片各 300 张,图片大小为 200×200 。如图 6 所示,1 类无缺陷(Original) 样本,3 类钢板表面缺陷分别为夹杂(Inclusion)、斑块(Patches) 及划痕(Scratches)。数据集按照 9:1 的比例以随机划分的方式分成训练集和测试集,具体实验环境如表 3 所示。输入图片尺寸为 640×640 ,一共训练 300 轮次,批处理 Batch-size 为 16。




图 6 本文采用的钢板表面缺陷数据集样本示意图

表 3 实验环境

名称	环境参数
操作系统	Windows11 64 位
处理器	Intel(R) Core(TM) i7-42700H CPU @ 2.30 GHz
显卡	NVIDIA GeForce RTX3070Ti
Python	3.8
深度学习框架	PyTorch1.10、CUDA 11.3

3.2 评价指标

本文采用平均精度(average precision, AP)、平均精度均值(mean average precision, mAP) 以及检测速度(FPS) 这 3 项指标对所提出的方法进行评价。其中, AP 是 P-R(precision-recall) 曲线下的面积,用来评估模型在单个检测类别上的精度,mAP 是所有类别 AP 的均值,用来评估整体检测精度,本文使用 IoU 为 0.5 时的 mAP。

精确率 P 和召回率 R 的计算公式为:

$$P = \frac{N_{TP}}{N_{TP} + N_{FP}}, R = \frac{N_{TP}}{N_{TP} + N_{FN}} \quad (20)$$

式中: N_{TP} 表示检测正确的目标数量, N_{FP} 表示检测错误的目标数量, N_{FN} 表示漏检的目标数量。

AP 的计算公式为:

$$AP = \int_0^1 P(R) dR \quad (21)$$

mAP 的计算公式为:

$$mAP = \frac{\sum_{i=1}^N AP_i}{N} \quad (22)$$

式中: N 为数据集样本分类数量。

$$FPS = \frac{FrameNum}{ElapsedTime} \quad (23)$$

式中: $FrameNum$ 为模型检测图片的总数, $ElapsedTime$ 为模型检测花费的总时间。

3.3 收敛分析及消融实验

本文实验的训练过程进行 300 轮次(epoch) 的迭代,得到的损失曲线如图 7 所示,其中,Box_loss 表示模型预测框和真实框之间的差异大小,Class_loss 表示分类损失,用于判断模型是否能准确识别表面缺陷图像中的缺陷目标,并将其分类到正确的类别中,Object_loss 为置信度损失,用于检测网格中是否存在物体,并计算网络的置信度。

从图 7 中可以看出,当 Epoch 为 300 时, KAS-YOLO 网络的各项 loss 值已经不再下降,网络已经收敛并趋于稳定。




图 7 KAS-YOLO 模型迭代收敛曲线

为了验证本文对 YOLOv5s 算法所做的各项改进对表面缺陷检测的影响,通过消融实验来对各个添加模块进行评估,评估结果如表 4 所示,“√”代表添加此模块。

表 4 消融试验结果对比

序号	ASPP	CA	anchors	Siou	AP /%				mAP /%
					Original	Inclusion	Patch	Scratch	
1					99.7	84.3	81.3	77.2	85.6
2	√				99.6	81.6	78.3	83.5	85.7
3	√	√			99.6	82.9	81.1	80.5	86.0
4	√	√	√		99.6	79.2	78.1	87.3	86.0
5	√	√		√	99.6	79.2	82.8	80.2	85.4
6	√		√	√	99.6	84.5	79.0	86.8	87.5
7	√	√	√	√	84.9	99.6	84.1	82.5	87.8

由表 4 可以看出,在识别 Scratch 类别时,每组实验的 AP 均有提升,其中第 4 组提升最大,相较原始基线网络提升了 10.1%;这是因为该缺陷以长方形居多,更适合改进后 K-means 聚类的 anchors。第 2 组在添加 ASPP 模块后, mAP 相较原始基线网络提升了 0.1%;第 3 组再添加 ASPP 和 CA 模块后, mAP 相较原始基线网络提升了 0.3%;第 4 组在添加 ASPP、CA 和 anchors 后, mAP 相较原始基线网络提升了 0.3%;第 7 组再添加 ASPP、CA、anchors 和 Siou 后, mAP 相较原始基线网络提升了 2.2%;由第 3 和 4 组得到结果可以看出,添加 anchors 可以显著提高网络对于 Scratch 的识别能力,但代价是降低了对其他缺陷的识别精度 AP;由第 4 和 7 组的结果可看出,添加 Siou 后虽然 Scratch 的识别能力有所下降,但其他类别缺陷的识别精度 AP 都有所提高,这对于不同缺陷的检测更有利;由第 4、5 和 7 组的结果可看出,同时添加 anchors 和 Siou 相较于单独添加 anchors 和 Siou 的 mAP 分别提升了 1.8% 和 2.4%,说明同时添加 anchors 和 Siou 可以更全面地提高钢板表面缺陷的识别精度;由第 2 和 3 组的结果

可看出,添加 CA 可以有效提高网络对缺陷的检测能力,并在一定程度上提高了对 Inclusion 和 Patch 的识别精度 AP ,适当平衡了识别 Scratch 的识别精度 AP 。从上述分析结果可以看出,本文提出的 KAS-YOLO 模型通过逐步改进骨干网络和颈网络的特征提取和特征融合部分,提升了钢板表面缺陷检测的精度。

3.4 实验结果对比

为了验证所提 KAS-YOLO 模型的检测性能,与现有主流目标检测模型 Faster R-CNN、SSD、RetinaNet 和 YOLOv5s 等进行对比,实验结果如图 8、图 9 和表 5 所示。




图 8 KAS-YOLO 和 YOLOv5s 的 Precision-Recall 曲线图对比

如图 8 所示,KAS-YOLO 整体的 mAP 为 87.8%, 相较 YOLOv5s 的 85.6% 提升了 2.2%。KAS-YOLO 对 3 类缺陷检测精度均有提升,其中 Inclusion 提升了 0.6%,Scratch 提升了 5.3%,Patches 提升了 2.8%。




图 9 不同方法的检测效果可视化对比

从图 9 可以看出,YOLOv5s 对缺陷的检测存在锚框不匹配、漏检的问题以及对小缺陷目标检测很困难。KAS-YOLO 在检测小缺陷目标,锚框匹配问题上得到了很大的改善,说明改进的特征融合模块,提高了小缺陷目标检测能力,添加的注意力机制有利于更好地定位缺陷位置,模型具有更好的鲁棒性和检测精度。

表 5 不同方法的检测实验结果对比

方法	AP / %				mAP / %	FPS / (frame · s ⁻¹)
	Original	Inclusion	Patch	Scratch		
Faster R-CNN	100.00	65.7	74.9	79.8	80.1	11
SSD	100.00	55.0	71.9	66.3	73.3	30
RetinaNet	100.00	27.6	67.0	31.2	56.5	25
YOLOv5s	99.70	84.3	81.3	77.2	85.6	66
KAS-YOLO	99.60	84.9	84.1	82.5	87.8	55

由表 5 可知,KAS-YOLO 算法的 mAP 为 87.8%,

相较 YOLOv5s 算法提高 2.2%;相比于 RetinaNet 提高了 31.3%;相比于 SSD 提高了 14.5%;相比于 Faster R-CNN 提高了 7.7%。KAS-YOLO 在 Inclusion、Patch、Scratch 这 3 类缺陷上达到了最大的 AP ,分别为 84.9%、84.1% 和 82.5%。

4 结束语

本文以钢板表面缺陷为研究对象,结合表面缺陷图像的特点,在 YOLOv5s 的基础上优化改进了特征提取模块、特征融合模块、K-means 算法聚类锚框和优化损失函数。从实验结果可以看出,采用的 ASPP 模块相较 SPP 模块对小缺陷目标的检测更佳;通过添加 CA 注意力模块以及采用 K-means 聚类后的锚框,所提出的模型对小缺陷目标的定位和识别更加准确;采用的 SIOU 损失函数,对 Scratch 缺陷识别略有下降,但对其他缺陷的识别均有提升。本文提出的 KAS-YOLO 模型在提高钢板表面缺陷检测精度的同时还保持了较快地检测速度,实现了对钢板表面缺陷的智能化检测。

参考文献

[1] 李少波,杨静,王铮,等. 缺陷检测技术的发展与应用研究综述 [J]. 自动化学报,2020,46(11):2319-2336.
[2] 徐科,王磊,王璟瑜. 基于 Tetrolet 变换的热轧钢板表面缺陷识别方法 [J]. 机械工程学报,2016,52(4):13-19.
[3] 苏虎,张家斌,张博豪,等. 基于视觉感知的表面缺陷检测综述 [J]. 计算机集成制造系统,2023,29(1):169-191.
[4] WEN X, SONG K C, HUANG L M, et al. Complex surface ROI detection for steel plate fusing the gray image and 3D depth information [J]. Optik,2019,198:163313.
[5] WANG H Y, ZHANG J W, TIAN Y, et al. A simple guidance template-based defect detection method for strip steel surfaces [J]. IEEE Transactions on Industrial Informatics,2019,15(5):2798-2809.
[6] HOU J Z, XIA K W, YANG F, et al. Strip steel surface defects recognition based on socp optimized multiple kernel RVM [J]. Mathematical Problems in Engineering,2018,2018(1):9298017.
[7] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation [C] //IEEE Conference on Computer Vision and Pattern Recognition,Piscataway,NJ,IEEE,2014.
[8] GIRSHICK R. Fast R-CNN [J] //IEEE International Conference on Computer Vision,Piscataway,NJ,IEEE,2015.
[9] REN S Q, HE K M, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence,2017,39(6):1137-1149.
[10] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: unified, real-time object detection [C] //IEEE Conference on Computer Vision and Pattern Recognition,Piscataway,NJ,IEEE,2016.
[11] REDMON J, FARHADI A. YOLO9000: better, faster, stronger [J] //IEEE Conference on Computer Vision and Pattern Recognition,Piscataway,NJ,IEEE,2017.
[12] REDMON J, FARHADI A. YOLOv3: an incremental improvement [J]. ArXiv,2018.
[13] BOCHKOVSKIY A, WANG C Y, LIAO H Y M. YOLOv4: opti-

- mal speed and accuracy of object detection [J]. ArXiv, 2020.
- [4] LIU W, ANGUELOV D, ERHAN D, et al. SSD: single shot multibox detector [C] // 14th European Conference on Computer Vision, Berlin, Springer, 2016.
- [5] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection [C] // IEEE International Conference on Computer Vision, Piscataway, NJ, IEEE, 2017.
- [6] 刘洪江, 王懋, 刘丽华, 等. 基于深度学习的小目标检测综述 [J]. 计算机工程与科学, 2021, 43(8): 1429–1442.
- [7] GU J X, WANG Z H, KUEN J, et al. Recent advances in convolutional neural networks [J]. Pattern Recognition, 2018, 77: 354–377.
- [8] JIANG B R, LUO R X, MAO J Y, et al. Acquisition of localization confidence for accurate object detection [C] // Proceedings of the European Conference on Computer Vision, Berlin, Springer, 2018.
- [9] ZHANG C Y, BENGIO S, HARDDT M, et al. Understanding deep learning requires rethinking generalization [J]. Communications of the ACM, 2021, 64(3): 107–115.
- [10] 杨慧剑, 孟亮. 基于改进的 YOLOv5 的航拍图像中小目标检测算法 [J]. 计算机工程与科学, 2023, 45(6): 1063–1070.
- [11] YANG M, YU K, ZHANG C, et al. Dense aspp for semantic segmentation in street scenes [C] // IEEE Conference on Computer Vision and Pattern Recognition, Piscataway, NJ, IEEE, 2018.
- [12] ZHANG T Y, LI J, CHAI J, et al. Improved YOLOv5 network with attention and context for small object detection [C] // International Conference on Intelligent Computing, Berlin, Springer, 2022.
- [13] HOU Q B, ZHOU D Q, FENG J S. Coordinate attention for efficient mobile network design [C] // IEEE Conference on Computer Vision and Pattern Recognition, Piscataway, NJ, IEEE, 2021.
- [14] 邹旺, 吉畅. 一种改进 YOLOv4-tiny 的带钢表面缺陷实时检测方法 [J]. 机械科学与技术, 2023, 42(6): 883–889.
- [15] 杜少聪, 张红钢, 王小敏. 基于改进 YOLOv5 的钢轨表面缺陷检测 [J]. 北京交通大学学报, 2023, 47(2): 129–136.
- [16] 曹义亲, 伍铭林, 徐露. 基于改进 YOLOv5 算法的钢材表面缺陷检测 [J]. 图学学报, 2023, 44(2): 335–345.
- [17] 李鑫, 汪诚, 李彬, 等. 改进 YOLOv5 的钢材表面缺陷检测算法 [J]. 空军工程大学学报(自然科学版), 2022, 23(2): 26–33.
- [18] 李维刚, 叶欣, 赵云涛, 等. 基于改进 YOLOv3 算法的带钢表面缺陷检测 [J]. 电子学报, 2020, 48(7): 1284–1292.
- [19] 梁秀满, 肖寒. 基于 SDD-YOLO 的轻量级带钢缺陷实时检测算法 [J/OL]. 中国测试. <http://kns.cnki.net/kcms/detail/51.1714.TB.20230109.1648.002.html>.
- [20] GEVORGYAN Z. Siou loss: more powerful learning for bounding box regression [J]. ArXiv, 2022.

(编辑 祝智铭)

(上接第 167 页)

特征进行有针对性的训练和分类,可以有效地提升故障识别精度,主要结论为:

(1) 风电齿轮箱运行结构复杂,传统的 RSSD 方法不能完全提取振动信号中的故障信息,加入 AR-MED 算法可以有效增强低共振分量中微弱的周期性冲击特征。

(2) 使用 1DCNN 有效避免了有用信息的丢失,充分发挥 1DCNN 对一维原始振动信号进行特征提取的优势。

(3) 对比实验结果表明,在齿轮箱故障诊断领域,本文所提方法的故障识别率远高于其他先进模型。

参考文献

- [1] DAI J C, YANG X, WEN L. Development of wind power industry in China: a comprehensive assessment [J]. Renewable and Sustainable Energy Reviews, 2018, 97: 156–164.
- [2] DING X, XU J, WANG J H, et al. Fault diagnosis of wind turbine generator bearings using fast spectral correlation [J]. Wind Engineering, 2022, 46(3): 724–736.
- [3] 钟建华, 林云树, 叶锦华. 基于 1DCNN 的齿轮箱小样本故障诊断 [J]. 组合机床与自动化加工技术, 2022(7): 81–84, 89.
- [4] WANG H C, LIU C, DU W L, et al. Intelligent diagnosis of rotating machinery based on optimized adaptive learning dictionary and 1DCNN [J]. Applied Sciences, 2021, 11(23): 11325.
- [5] 张延军, 杨博. 基于 EMD 与 SSA-SVM 的轴承故障诊断 [J]. 组合机床与自动化加工技术, 2023(8): 113–117.
- [6] HE D Z, WEI Z. Intelligent fault diagnosis of train axle box bearing based on parameter optimization VMD and improved DBN [J]. Engineering Applications of Artificial Intelligence, 2022, 110: 104713.
- [7] LI X, MA J, WANG X D, et al. An improved local mean decomposition method based on improved composite interpolation envelope and its application in bearing fault feature extraction [J]. ISA Transactions, 2020, 97: 365–383.
- [8] SELESNICK I W. Resonance-based signal decomposition: a new sparsity-enabled signal analysis method [J]. Signal Processing, 2011, 91(12): 2793–2809.
- [9] 黄文涛, 付强, 窦宏印. 基于自适应优化品质因子的共振稀疏分解方法及其在行星齿轮箱复合故障诊断中的应用 [J]. 机械工程学报, 2016, 52(15): 44–51.
- [10] WIGGINS R A. Minimum entropy deconvolution [J]. Geophysical, 1978, 16(1): 21–35.
- [11] 张龙, 胡俊峰, 熊国良. 基于 MED 和 SK 的滚动轴承循环冲击特征增强 [J]. 振动. 测试与诊断, 2017, 37(1): 97–101, 201.
- [12] STARCK J L, MOUDDEN Y, BOBIN J, et al. Morphological component analysis [J]. Wavelets XI. SPIE, 2005, 5914: 209–223.
- [13] BENGTTSSON T, CAVANAUGH J E. An improved Akaike information criterion for state-space model selection [J]. Computational Statistics & Data Analysis, 2006, 50(10): 2635–2654.
- [14] KIZILKAYA A, KAYRAN A H. ARMA model parameter estimation based on the equivalent MA approach [J]. Digital Signal Processing, 2006, 16(6): 670–681.
- [15] 何群, 郭源耕, 王霄, 等. 基于信号共振稀疏分解和最大相关峭度解卷积的齿轮箱故障诊断 [J]. 中国机械工程, 2017, 28(13): 1528–1534.

(编辑 祝智铭)