

分类号: (按中国图书分类法, 学位办网上可查)

单位代码: 11057

密 级: 非涉密文件

学 号: 222201855010



硕士学位论文

论文题目: 基于 TS-YOLO 的三叉轴
表面缺陷检测算法研究

作 者 李腾越

指导教师 祝邦文、曹丽丽

学科专业 机械

二级学院 机械与能源工程学院

提交日期 2024 年 12 月 5 日

**A Thesis Submitted to
Zhejiang University of Science and Technology for
Master's Degree**

**Dissertation Title: Identification
of Surface Defect Detection for Triaxial
Bearing Journal Based on TS-YOLO
Algorithm**

Candidate: TengYue Li

Supervisor: Bangwen Zhu\ Lili Cao

**Zhejiang University of Science and
Technology**

Hangzhou China

December 2024



基于 TS-YOLO 的三叉轴
表面缺陷检测算法研究

论文作者签名: 李 腾 越

指导教师签名: 祝邦文、曹丽丽

论文评阅人 1: _____

评阅人 2: _____

评阅人 3: _____

评阅人 4: _____

评阅人 5: _____

答辩委员会主席: 顾大强\教授\浙江大学

委员 1: 朱旭升\高级工程师\杭州东城电子有限公司

委员 2: 马红萍\教授\浙江科技大学

委员 3: 袁斌\副教授\浙江科技大学

委员 4: 张敬强\副教授\浙江科技大学

委员 5: 曹丽丽\讲师\浙江科技大学

答辩日期: 2024 年 12 月 5 日



浙江科技大学
ZHEJIANG UNIVERSITY OF SCIENCE & TECHNOLOGY

**Identification of Surface Defect Detection for Triaxial
Bearing Journal Based on Deep Learning Algorithm**

Candidate's signature: Tengyue Li

Supervisor's signature: Bangwen Zhu\ Lili Cao

Thesis reviewer 1: _____

Thesis reviewer 2: _____

Thesis reviewer 3: _____

Thesis reviewer 4: _____

Thesis reviewer 5: _____

Chair: Daqiang Gu
(Committee of oral defence)

Committeeman 1: Xusheng Zhu

Committeeman 2: Hongping Ma

Committeeman 3: Bin Yuan

Committeeman 4: Jingqiang Zhang

Committeeman 5: Lili Cao

Date of oral defence: 2024.12.5

摘 要

近年来,深度学习人工智能快速发展,由于其高精度和高效率的特性,基于深度学习的表面缺陷检测技术被广泛应用于工业缺陷检测。但在实际的工业表面缺陷检测时,深度学习算法也面临着一些挑战,如真实场景中缺陷图像数据难收集、表面缺陷复杂导致检测精度降低、模型参数量大、部署难度大等问题。为此本文提出了一种基于 TS-YOLO 算法的表面缺陷检测方法,以及一种通用性高且灵活方便的三叉轴缺陷自动检测解决方案。主要工作内容如下:

(1) 针对缺陷图像数据难收集,缺陷样本不均衡问题,收集了三叉轴缺陷样本。关于三叉轴的表面缺陷,市面上并没有相关的公开数据集,故对于工业场景中产生的三叉轴表面缺陷进行了采集,定义相关缺陷类型,制作了三叉轴的数据集。

(2) 对于表面缺陷复杂导致检测精度降低、模型参数量大的问题,平衡检测准确率和计算量,提出了一种基于 YOLOv8 算法改进的 TS-YOLO 方法:首先网络结构部分,在主干网络的尾部添加了结合空间重构单元(SRU)和通道重构单元(CRU)的 ScConv,促进代表性特征提取;其次特征融合部分,使用 CSConv 替换标准卷积,引入 VoV-GSCSP 模块,提高了检测精度;最后使用融合了 Inner-IoU、Shape-IoU 的 Inner-ShapeIoU 代替 CIoU 损失函数,考虑边界框本身的形状、尺度因素,同时使用辅助边界框加速边界框的回归,着重提高了小目标的检测精度。结果显示改进后的 TS-YOLO 算法参数量减少,并在三叉轴缺陷数据集上 mAP 达到 84.8%,相较于改进前的 79.1%提升了 5.7%。

(3) 对于实际工业场景部署难度大的问题,本文提出了一种基于海康 Vision Master 视觉软件进行模型部署的方法,结合了设备通信、深度学习算法、传统图像算法、UI 界面设计,通过图形化界面配置流程,大大提高了部署的灵活性和可扩展性,降低了部署难度。

关键词: 三叉轴表面缺陷检测, TS-YOLO, ScConv, VoV-GSCSP, Inner-ShapeIoU

ABSTRACT

In recent years, with the rapid development of deep learning and artificial intelligence, surface defect detection technology based on deep learning has been widely applied in industrial defect detection due to its high accuracy and efficiency. However, in practical industrial surface defect detection, deep learning algorithms also face several challenges, such as the difficulty of collecting defect image data in real-world scenarios, the complexity of surface defects leading to reduced detection accuracy, large model parameters, and high deployment difficulty. To address these issues, this paper proposes a surface defect detection method based on the TS-YOLO algorithm, as well as a highly general and flexible automatic defect detection solution for triaxial bearings. The main contributions are as follows.

(1) To address the issue of difficult defect image data collection and imbalance in defect samples, a dataset of triaxial bearing defects was collected. For object detection algorithms, the quality of the dataset is crucial. However, there is no publicly available dataset related to surface defects of triaxial bearings. Therefore, defect data from triaxial bearing surfaces produced in industrial settings were collected, relevant defect types were defined, and a dataset for triaxial bearings was created.

(2) To address the issues of reduced detection speed due to complex surface defects and large model parameters, the TS-YOLO method based on improvements to the YOLOv8 algorithm is proposed. This method balances detection accuracy and computational load while also improving the precision for small object detection. First, in the network structure, a ScConv module combining the Spatial Reconstruction Unit (SRU) and the Channel Reconstruction Unit (CRU) is added to the tail of the backbone network to enhance representative feature extraction. Second, in the feature fusion part, CSConv is used to replace the standard convolution, and the VoV-GSCSP module is introduced, effectively reducing computational load while improving detection accuracy. Finally, the Inner-ShapeIoU loss function, which integrates Inner-IoU and Shape-IoU, is used to replace the CIoU loss function. This approach considers the shape and scale factors of the bounding box and utilizes auxiliary bounding boxes to

accelerate bounding box regression, significantly improving small object detection precision. The results show that the improved TS-YOLO algorithm reduces the number of parameters and achieves a mean average precision (mAP) of 84.8% on the triaxial bearing defect dataset, a 5.7 percentage point increase compared to the 79.1% before the improvements.

(3) To address the issue of high deployment difficulty in practical industrial scenarios, this paper proposes a method for model deployment based on Hikvision's Vision Master vision software. By integrating device communication, deep learning algorithms, and a user interface into one system, and configuring the workflow through a graphical interface, this method significantly enhances deployment flexibility and scalability, while reducing deployment complexity.

Key Words: Triaxial Bearing Surface Defect Detection, TS-YOLO, ScConv, VoV-GSCSP, Inner-ShapeIoU

目 录

第 1 章 引言.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 传统目标检测算法.....	3
1.2.2 深度学习目标检测算法.....	4
1.2.3 深度神经网络模型轻量化技术.....	5
1.2.4 基于深度学习目标检测算法的表面缺陷检测	6
1.3 论文研究内容.....	6
第 2 章 深度学习目标检测技术基础	8
2.1 卷积神经网络基本原理.....	8
2.1.1 CNN 网络结构	8
2.2 深度学习算法构建过程.....	11
2.2.1 数据预处理.....	12
2.2.2 算法模型构建.....	12
2.2.3 模型训练.....	13
2.3 本章小结.....	18
第 3 章 基于 YOLOv8 算法的三叉轴表面缺陷检测.....	19
3.1 三叉轴表面缺陷数据集制作	19
3.1.1 缺陷数据集介绍.....	19
3.1.2 缺陷数据标注及数据增强.....	22
3.2 YOLOv8 算法.....	24
3.2.1 YOLOv8 网络结构介绍.....	24
3.2.2 实验评价指标.....	28
3.2.3 实验结果与分析.....	29
3.3 本章小结.....	30
第 4 章 TS-YOLO 算法介绍与结果分析	31
4.1 TS-YOLO 模型整体结构	31
4.2 Backbone 改进.....	32
4.3 改进的 Neck 设计范式	34
4.4 Inner_Shape-IoU 损失.....	35
4.5 实验结果及分析.....	37
4.5.1 对比实验.....	37
4.5.2 消融实验.....	40
4.5.3 与海康原算法对比.....	41

4.6 本章小结.....	43
第5章 改进的 TS-YOLO 算法部署	44
5.1 引言.....	44
5.2 需求分析.....	45
5.3 硬件设备介绍.....	45
5.4 软件系统配置.....	48
5.5 部署推理.....	51
5.5.1 TS-YOLO 模型训练.....	51
5.5.2 Vision Master 软件二次开发	52
5.5.3 Vision Master 软件整体流程	57
5.5.4 Vision Master 软件界面开发	61
5.6 本章小结.....	61
第6章 总结与展望	63
6.1 总结.....	63
6.2 展望.....	64
参考文献.....	65

第1章 引言

1.1 研究背景及意义

当前,我国正处于从制造业大国向制造业强国转型的关键时期,产品质量的提升已成为制造业发展的核心目标^[1]。钢铁行业作为我国重要的原材料产业之一,对产品质量的要求尤为严格。表面缺陷是制造业中普遍存在的问题,它不仅直接影响产品的外观质量,还会对产品的性能、寿命和可靠性产生重大影响^[2]。尤其在高精度、高性能要求的领域,微小的表面缺陷都有可能引发严重的设备故障,甚至造成安全隐患。

传统的表面缺陷检测方法主要依赖于人工检测,这种方法具有较高的灵活性,但也存在主观性强、效率低、易受检测人员疲劳和经验影响等不足。此外,传统图像处理和机器视觉方法在处理复杂、细微的表面缺陷时,往往难以取得理想的效果,尤其在多种缺陷同时存在、背景复杂或者表面纹理复杂的情况下,传统方法的检测准确率和鲁棒性不足。

随着人工智能和深度学习技术的不断发展^[3],基于深度学习的表面缺陷检测方法逐渐成为研究的热点。深度学习能够通过大量样本数据的学习,自动提取图像中的特征,并具备强大的分类和识别能力。其在图像处理和目标检测领域取得了显著的成功,为表面缺陷检测提供了新的技术路径和解决方案。

开发基于深度学习的表面缺陷检测方法具有重要的实际意义^[4]。首先,它有助于实现检测过程的自动化和智能化,大幅提升检测效率和准确性,降低人工成本,避免人工检测中的主观性误差。其次,通过深度学习模型对复杂缺陷特征的自动提取和学习,可以有效应对多样化、复杂化的缺陷形态,提高对不同类型缺陷的检测能力,增强系统的鲁棒性。

对于三叉轴等关键工业零部件,由于其表面结构复杂、形态多样,传统检测方法难以满足精确检测的要求。通过引入深度学习技术,可以在此领域取得新的突破,为制造业提供更精确、更可靠的质量控制工具,提升产品的整体质量和可靠性。此外,这一研究还具有推广应用的潜力,可为其他机械零部件的表面缺陷检测提供技术参考,推动整个制造业的智能化进程。

最后，基于深度学习的表面缺陷检测研究还有助于推动制造业的可持续发展。一方面，通过提升产品质量，延长设备使用寿命，可以减少资源浪费和降低生产成本；另一方面，推动自动化、智能化检测技术的发展，有助于提高制造业的整体竞争力，支持我国制造业向高质量、可持续发展迈进。

1.2 国内外研究现状

在早期，尤其是 20 世纪中期到 21 世纪初，大多数工厂的缺陷检测主要依靠人工挑选。工人通过目视检查和经验判断对产品进行质量筛查。这种方法虽然在某种程度上能够满足质量检测的需求，但存在明显的弊端。首先，人工检测的效率低，随着生产规模的扩大和产品数量的增加，人工检测难以满足大规模、高速生产线的需求。其次，人工检测的准确性和一致性较差，受检测人员的经验、主观判断以及疲劳程度的影响，容易出现漏检或误检的情况。基于这些局限性，迫切需要一种更高效、自动化的检测方法，这也是基于深度学习的目标检测算法逐渐兴起的重要原因。根据目标检测算法中特征提取方式的不同，可以将其分为传统目标检测算法和基于深度学习的目标检测算法。图 1-1 显示了目标检测算法的不同类别。




图 1-1 目标检测算法分类

1.2.1 传统目标检测算法

传统目标检测算法依赖于人工设计的特征和浅层可训练结构来进行识别。然而，当构建复杂系统应用于复杂缺陷识别时，其性能往往不尽如人意。这类传统算法包括人工神经网络（Artificial Neural Network, ANN）、主成分分析（Principal Component Analysis, PCA）、支持向量机（Support Vector Machines, SVM）等。图 1-2 展示了传统算法的整体框架。




图 1-2 传统算法的整体框架

传统机器学习目标检测算法通常包含以下几个关键步骤：候选框生成、特征提取、分类器选择和候选框精修。

国内外科研人员使用传统算法完成缺陷检测任务的已有很多。2013 年，Reddy^[5]等人提出用 S-Transform 提取图像特征，然后使用 SVM 处理获取到的特征信息完成缺陷检测。尽管 SVM 有较好的性能，但在工业生产环境中大部分图像的背景较为复杂，SVM 在空间维度上特征处理能力较弱，因此 SVM 的性能很难达到使用要求。2014 年，Oberweger M^[6]等人提取了局部梯度目标图像特征，并将其映射到椭圆空间中，用作缺陷检测。2015 年，Chaou^[7]等人为了实现绝缘子缺陷检测，首先对图像数据进行了处理，采用形态学算法消除图像中的噪声干扰，最后将图像转换为四维向量并输入分类器进行检测。

然而传统算法有很多缺点。

（1）特征设计依赖经验：传统算法依赖于人工设计特征，设计特征的好坏直接影响检测性能，这需要大量的领域知识和经验。

（2）适应性差：在处理复杂、多样化的目标和场景时，传统算法的泛化能力较弱，容易受到背景、光照、尺度变化等因素的影响。

（3）性能有限：在处理高维特征和复杂目标检测任务时，传统算法的性能往往不如深度学习算法。

这些步骤构成了传统目标检测算法的核心流程。然而，受限于上述的缺点，

传统算法在处理复杂场景和多样化目标时，往往难以达到理想的检测效果。随着深度学习的发展，基于深度学习的目标检测算法逐渐取代了这些传统方法，展现出更强的性能和更广泛的应用前景。

1.2.2 深度学习目标检测算法

目前基于深度学习的目标检测算法主要分为单阶段和双阶段两类。单阶段方法包括 YOLO^[8-12]算法系列和 SSD^[13]等，它们通过直接在输入图像上进行密集预测，实现了快速目标检测。双阶段方法则包括 Mask R-CNN^[14]、Fast-RCNN^[15]和 Faster-RCNN^[16]等，首先生成候选区域，然后对每个区域进行分类和定位，获取目标检测结果。相比之下，单阶段方法速度更快，更适合实际应用场景。

YOLO（You Only Look Once）算法是目标检测领域中非常重要的一系列算法，通过不断的改进和优化，YOLO 系列在速度和准确性上取得了显著的进步。

YOLOv1（2015）其主要思想是将目标检测视为一个单一的回归问题，将输入图像划分为 $S \times S$ 的网格，每个网格负责预测一个或多个边界框及其所属类别。它将整个检测过程从图像处理到边界框预测统一到一个神经网络中，因此得名“Only Look Once”。

YOLOv3（2018）加入了多尺度预测：YOLOv3 可在不同的网络层上进行预测，分别在 3 个不同尺度上进行目标检测，这使得它在检测小目标上性能更好。它使用了 Darknet-53 网络，它由 53 层卷积层组成，采用残差网络结构（Residual Blocks），提高了特征提取的能力。YOLOv3 使用独立的逻辑回归（Logistic Regression）代替 Softmax，允许同一框包含多个标签，适应多标签分类任务。

YOLOv5（2020）并不是由 YOLO 的原作者发布的，但它在社区中得到了广泛关注和应用。YOLOv5 在实现中引入了更简洁、高效的代码，使得模型更容易训练和部署；引入了 Mosaic、MixUp 等数据增强策略，提高了模型的泛化能力；还引入 Focus 层、CSP 层和改进的 FPN/PAFPN 结构，以进一步提高检测性能。该算法模型在不同大小的模型中提供了 S、M、L、X 等版本，可以根据实际需求选择在速度和精度上进行权衡。

YOLOv8（2023）进一步优化了检测性能，旨在提供更高的精度和更低的推理延迟，适用于各种复杂场景和实际应用。它使用了 C2f 模块，实现了进一步的

轻量化,同时使用了 SPPF 模块。网络颈部将 YOLOv5 中 PAN-FPN 上采样阶段中的卷积结构删除了,同时也将 C3 模块替换为了 C2f 模块。网络分类头使用了 Decoupled-Head,抛弃了以往的 Anchor-Base,使用了 Anchor-Free 的思想。YOLOv8 具备更好的推理速度和模型大小,在实际应用中展现了更好的灵活性和可部署性。

1.2.3 深度神经网络模型轻量化技术

在深层卷积神经网络中,标准卷积的高参数量和计算复杂度通常成为模型优化的瓶颈,促使了轻量化卷积模块和其他卷积操作改进方案的出现,2017 年,Xie S 等人提出了 ResNeXt^[17],其采用分组卷积的方式,将多个分支进行融合。与 ResNet 相比,ResNeXt 在保持相同计算量的前提下,能够实现更优的识别效果。Howard 等人^[18]提出了轻量化的 MobileNet 网络,该网络中设计了一种轻量化的深度可分离卷积 (Depthwise Separable Convolution)。相较于使用标准卷积,深度可分离卷积可以大幅度降低计算量,提升网络运算速度。2018 年 Zhang 等人^{[19][13]}提出了 ShuffleNet 网络,该网络中设计了分组逐点卷积,并使用通道混洗的方法进一步减少卷积所需计算量,同时确保模型精度。同年 Sandler 等人提出的 MobileNet V2^[20]中进一步设计了逆残差结构,将 1*1 卷积增加在深度卷积 3*3 之前,提高了模型的效率。2019 年,MobileNetV3^[21]模型被提出,它采用“移动平均”和“自适应宽度”技术来减少网络中的计算量和参数数量,实现更好的效果。

2019 年,吴涛^[22]等人改进了 YOLOv3 算法,将原有的主干网络轻量化,提高了模型的推理速度,大大减少了模型的计算量。然而,该轻量化方法在图像特征提取过程中使用了下采样方式,且通道数的增加幅度较小,导致深层特征信息大量丢失无法有效捕捉复杂的细节,影响了准确度。2023 年,贾晓芬^[23]等人通过引入深度可分离卷积优化了 YOLOv5 算法,大幅降低了计算量,提升了推理速度,最后通过多添加一个检测层,提高了模型的精度。2023 年,王道累^[24]等人通过深度可分离卷积对 YOLOv5 算法进行轻量化优化,在保留浅层细节特征的同时扩大感受野,从而提升了算法性能。

1.2.4 基于深度学习目标检测算法的表面缺陷检测

2020年, Detection Transformer^[25] (DETR)的作者将 Transformer 从文本领域引入到了视觉领域,为目标检测带来了新的发展方向。前人在深度学习缺陷检测方向,取得了显著的成果。例如, Zhao Y^[26]等人提出的一种名为 GRP-YOLOv5 的轴承表面缺陷检测算法,在主干网络部分将 ResC2Net^[27]与残差状结构相结合,并在特征融合部分增加了 PConv 卷积,在轴承缺陷数据集上精度达到了 93.5%; 崔克彬^[28]等人针对缺陷检测中高误检率和漏检率等问题,提出了 MCB-FAH-YOLOv8,他们通过引入改进后的卷积注意力机制模块(CBAM)和可替换的四头 ASFF 预测头(FAH),有效提升了网络对微小物体和密集目标的检测能力,同时在牺牲速度的情况下提高了精度。Chen^[29]等人提出了一种名为 Transformer-YOLO 模型,将 Transformer 作为提取特征的主干网络,该模型在轴承套圈数据集上达到了 97.4%的精度;另外,侯玥^[30]等人设计了一种由 Swin Transformer 模块和 PANET 模块组成的学习器,显著提高了对小样本检测任务的性能。

1.3 论文研究内容

已有的研究成果,从不同的方面分别提高了缺陷检测的性能,但是在提高精度的同时无法兼顾模型的轻量要求,且小目标缺陷的精度依然较低难以满足缺陷检测行业要求。故本文提出了一种对小目标友好的方法,并且很好地平衡了检测精度与模型参数数量的 TS-YOLO 算法。

(1) 提出了一种平衡了计算量和检测精度的对小目标友好的算法 TS-YOLO,在主干网络的尾部添加了 ScConv 卷积,促进代表特征学习强化特征质量。

(2) 在特征融合部分,引入了 GSConv 来替换标准卷积,并引入 VoV-GSCSP 模块在有效节省计算量的同时,提高了检测精度。

(3) 优化了损失函数,使用 Inner-ShapeIoU 来代替 CIoU 损失函数,考虑边界框本身的形状和尺度因素对回归结果产生影响的同时,注意到损失项本身的局限性,根据不同回归样本使用不同尺度的辅助边界框,着重提高了小目标的检测精度。

(4) 制作了三叉轴表面缺陷数据集,并将算法应用到该数据集。实验证明

了该算法在提高精度的同时兼顾了模型检测速度的需求且对小目标友好。

(5) 在海康 Vision Master 视觉软件上完成了部署，较海康 VM 软件原算法精度有较大提升，该方法可作为一种工件表面缺陷自动检测的解决方案。

第2章 深度学习目标检测技术基础

深度学习目标检测是一项计算机视觉领域的核心技术,广泛应用于工业缺陷检测领域。本章节将重点介绍深度学习在缺陷检测中的相关算法原理以及理论知识。首先,将讲解卷积神经网络的基础知识,其中包括卷积层、池化层、激活函数、损失函数以及全连接层等基本结构。同时,还将特别关注轻量化卷积和损失函数,为后续章节中的算法研究提供必要的理论基础。

2.1 卷积神经网络基本原理

卷积神经网络(Convolutional Neural Network, CNN)是一种深度学习模型,专门用于处理具有网格结构的数据,如图像。自从 LeNet-5 首次引入卷积神经网络以来,CNN 在深度学习领域取得了长足的发展。后来出现的模型,如 AlexNet^[31]、GoogleNet^[32]、VGG^[34]、ResNet^[35]等,进一步提高了网络的深度和复杂度,显著增强了模型的性能。卷积神经网络的核心组件为卷积层(Convolutional Layer)、池化层(Pooling Layer)、激活函数(Activation Function)等,网络由多个卷积层池化层交替堆叠组成,每个层次都有特定的功能。整体结构如图 2-1 所示。本章节会对卷积神经网络的各个核心组件作详细介绍。




图 2-1 CNN 结构图

2.1.1 CNN 网络结构

(1) 数据输入及预处理

在卷积神经网络(CNN)中,数据输入及预处理是模型训练和性能优化的重

要步骤。数据输入通常是图像，而预处理的目的是提高模型的训练效率、性能和泛化能力。

数据预处理：为了使模型能够处理不同尺寸的图像，通常会对输入图像进行尺寸调整，将其缩放到一个固定大小。归一化是为了将输入图像的像素值缩放到一个标准范围内，通常是 $[0,1]$ 或 $[-1,1]$ 。这样做可以加速模型的收敛，并防止数值溢出。对于一个像素值，标准归一化公式如 2-1 所示。

$$x_{norm} = \frac{x - mean}{std} \quad (2-1)$$

其中，**mean** 和 **std** 是数据集的均值和标准差。

(2) 卷积层

卷积层^[36]是卷积神经网络（CNN）中核心的组成部分，主要用于从输入数据中提取特征。

卷积核是一个小矩阵，通常远小于输入图像，由一组可学习的参数组成。每个卷积核可以学习到一种特定类型的特征，如水平边缘、垂直边缘或特定纹理。若给定图像 $X \in R^{M \times N}$ 和一个卷积核 $W \in R^{A \times B}$ ，那么其卷积操作如公式 2-2 所示。

$$y_{ij} = \sum_{a=1}^A \sum_{b=1}^B w_{ab} x_{i-a+1, j-b+1} \quad (2-2)$$

那么输入信息 X 和卷积核 W 的二维卷积定义如公式 2-3 所示。

$$Y = W * X \quad (2-3)$$

其中 $*$ 表示卷积运算，图 2-2 给出了卷积的示意图。




图 2-2 卷积操作

一个卷积核生成一个特征图，多核可以生成多个特征图。对于输入尺寸为 $H \times W$ 的图像，卷积核尺寸为 $K \times K$ ，步长为 S ，填充为 P ，输出特征图的尺寸计算公式如 2-4 所示。

$$Output = \left\lceil \frac{H + 2P - K}{S} \right\rceil + 1 \quad (2-4)$$

图 2.2 示例中卷积核尺寸为 3×3 ，步长为 1，采用零值填充故最终的输出大小为 3×3 。图像处理中，卷积经常作为特征提取的有效方法。图 2-3 直观地显示了卷积操作后的效果，可看出特征图保留了较为突出的边缘特征。




图 2-3 卷积操作后特征图实例

(3) 池化层

池化层^[37] (Pooling Layer) 是卷积神经网络 (CNN) 中的一种下采样操作，主要用于减小特征图的尺寸，降低模型的计算复杂度，同时保留输入图像的重要特征。池化层通过对输入特征图进行局部操作，提取每个局部区域中的代表性值，从而实现信息的压缩。

常见的池化操作有最大池化 (Max Pooling)、平均池化 (Average Pooling)。

池化操作会减小特征图的尺寸，输出的特征图尺寸公式与卷积操作类似，图 2-4 直观地显示了池化操作后的效果，图中可看出图像像素值明显减少，且尽量保留了原本的轮廓。




图 2-4 池化操作后结果实例

(4) 全连接层

全连接层^[38] (Fully Connected Layer) 通常位于网络的最后几层, 用于综合和分类从前面卷积层和池化层中提取到的特征, 实现最终的分类或回归任务。

全连接层的输入通常是由前面的卷积层和池化层生成的特征图, 经过展平 (Flatten) 操作, 将这些特征图转换为一维向量。然后将输入向量进行线性变换, 即将输入向量与权重矩阵相乘, 然后加上一个偏置向量, 最后通过激活函数 (如 ReLU、Sigmoid、Tanh 等) 进行非线性变换得到最终结果, 总体流程如公式 2-5 所示。

$$y = \sigma(w * x + b) \quad (2-5)$$

其中, y 为输出结果, σ 为激活函数, w 为权重矩阵, b 为偏置向量。

2.2 深度学习算法构建过程

深度学习算法的训练过程大致包括以下几个主要步骤: 数据预处理、模型构建、损失函数和优化器的选择、训练过程以及最终的模型效果评估。通过这些步骤, 模型逐步学习并优化参数, 从而提高预测性能。图 2-5 形象地展示了算法的构建流程。




图 2-5 算法构建流程

2.2.1 数据预处理

数据预处理是深度学习模型训练前的重要步骤之一，直接影响模型的训练效果和性能。高质量的数据能够帮助模型更好地学习特征并提高泛化能力，减少噪声、偏差和其他潜在问题。

为了评估模型的泛化能力，通常将原始数据集划分为不同的部分：训练集、验证集、测试集。训练集，用于模型的训练，通常占数据集的 70%-80%；验证集，用于在训练过程中评估模型性能，帮助调参和监控模型的过拟合情况，验证集的比例通常为 10%-15%；测试集，用于最终评估模型的泛化性能，测试集在训练过程中不会被使用，其比例通常为 10%-15%。

2.2.2 算法模型构建

算法模型构建是深度学习中的关键阶段，它决定了模型的结构、复杂度以及最终的表现。模型的构建包括主干网络^[39]（Backbone）、特征融合（Neck）、模型检测头（Head）。就本论文的任务目标检测而言，算法模型应具备预测输入属于那种类别并确定目标位置坐标的能力。下面介绍算法模型构建的步骤。

（1）主干网络（Backbone）

构建目标检测模型时，通常采用深度卷积神经网络（如 VGG、ResNet）作为特征提取的基础，并在此基础上添加额外的检测模块。

目标检测算法通常使用预训练的卷积神经网络作为主干网络（Backbone）。特征提取网络的选择对整个目标检测模型的性能起着决定性的作用。常见的特征提取网络有 VGGNet、ResNet、MobileNet、EfficientNet^[40]等。

（2）特征融合（Neck）

特征金字塔网络^[41] (FPN, Feature Pyramid Network) 是一种常用于多尺度目标检测的网络结构。它在深度卷积网络的不同层次上构建金字塔型特征图,用于捕捉不同尺度的物体。FPN 从高层次特征开始,通过上采样^[42] (upsample) 逐步生成低层次特征,使得低层特征具有更多的语义信息,并将上采样的高层特征与相应层次的低层特征进行融合,形成具有强语义信息且包含细节的特征图。其不同尺度的特征图上进行物体检测,有助于提高对大小不一的物体的检测效果。

(3) 模型检测头 (Head)

模型检测头 (Head) 负责将经过主干网络提、特征融合得到的特征进行处理,最终输出物体的类别和边界框。检测头的设计直接影响模型的性能,特别是检测精度和速度。目标检测任务检测头包含两个主要任务: 类别分类 (Classification)、边界框回归 (Bounding Box Regression)。

2.2.3 模型训练

在目标检测中,模型的训练过程是将网络的参数调整至最佳状态,以使其能够准确预测图像中的物体。整个训练过程涉及多个步骤,包括损失函数选择、优化器选择、前向传播、反向传播与权重更新。图 2-6 为模型训练具体流程。




图 2-6 模型训练的具体流程

(1) 算法模型初始化

模型算法的初始化决定了模型的权重在训练开始时的初始状态。良好的初始化可以加速收敛速度,避免梯度消失或爆炸等问题,从而提高模型训练的效率 and 最终的性能。

(2) 前向推理

前向推理是模型在接收到输入数据后,通过层层神经网络逐层计算得到输出结果的过程。这个过程包括了卷积、池化、激活函数^[43]等操作,逐层提取特征并最终输出一个预测值。

若神经网络有 L 层,第 l 层的输出记作 $A^{[l]}$,在每一层(卷积层或全连接层),输入特征 $A^{[l-1]}$ 与对应的权重矩阵 $W^{[l]}$ 和偏置项 $b^{[l]}$ 进行线性变换。线性变换如公式 2-6。

$$Z^{[l]} = W^{[l]}A^{[l-1]} + b^{[l]} \quad (2-6)$$

式中 $W^{[l]}$ —第 l 层的权重矩阵

$A^{[l-1]}$ —上一层输出(对于第 1 层即为原始数据)

$b^{[l]}$ —该层的偏置项

$Z^{[l]}$ —是第 l 层线性变换的结果

线性变换完成后,接下来是将其通过一个非线性激活函数,引入非线性变换。常见的激活函数包括 ReLU^[44]、Sigmoid^[45]、Tanh^[46]等。通过激活函数后的结果成为激活值 $A^{[l]}$,如公式 2-7。

$$A^{[l]} = f(Z^{[l]}) \quad (2-7)$$

神经网络中的每个隐藏层重复上述线性变换和非线性激活的过程。

(3) 损失计算

损失函数用于衡量模型预测输出与真实标签之间的差距。不同任务使用不同的损失函数,通过计算损失函数值,模型可以了解当前预测与目标之间的误差大小,并根据此误差在反向传播阶段更新模型参数,从而逐步优化模型性能。不同类型的任务如分类、回归等使用不同的损失函数。

分类任务中常使用交叉熵损失^[47](Cross-Entropy Loss),一种用于衡量两个概率分布之间差异的度量,常用于多类分类问题。公式如 2-8 所示。

$$Cross - EntropyLoss = -\sum_{i=1}^n y_i \log(\hat{y}_i) \quad (2-8)$$

其中, y_i 是实际类别的 one-hot^[48]编码, $\hat{y}_i$ 是模型预测的概率分布。

在分类任务中, 交叉熵损失能够有效衡量模型预测的概率分布与真实类别的接近程度。对于二分类问题, 通常使用二元交叉熵损失^[49] (Binary Cross-Entropy Loss)。

回归任务中常使用均方误差损失 (Mean Squared Error, MSE)^[50]或 IOU 系列损失。

i 均方误差损失 (Mean Squared Error, MSE)

均方误差衡量的是模型预测值 $\hat{y}$ 与真实值 y 之间的误差的平方平均值。其公式如 2-9 所示。

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2-9)$$

式中 n —样本数量

y_i —是第 i 个样本的真实值

$\hat{y}_i$ —是模型预测的第 i 个样本值

MSE 反映了预测值和真实值之间的平均差距。在模型训练过程中, 优化的目标是最小化 MSE, 也就是让预测值尽可能接近真实值。

ii IOU 损失

IoU^[51] (Intersection over Union) 损失是目标检测任务中常用的一种损失函数, 特别是在边界框回归 (bounding box regression) 中, 用于衡量预测的边界框与真实的边界框之间的重叠程度。定义为预测框和真实框的交集面积与并集面积的比值。其公式如 2-10 所示。

$$IoU = \frac{|B \cap B^{gt}|}{|B \cup B^{gt}|} \quad (2-10)$$

式中 B —预测框区域

B^{gt} —真实框区域

IoU 损失的表达式如 2-11 所示。

$$L_{IoU} = 1 - IoU \quad (2-11)$$

因此, IoU 损失越小, 索命预测框和真实框的重叠部分越大, 模型的预测效果越好。但其缺点也十分明显, 即在 IoU 接近 0 时, 梯度不连续, 可能导致在训练早期无法提供足够有效的梯度信息, 当 IoU 为 0 时, 损失函数的值固定为 1, 这对完全不重叠的预测框可能无法提供足够的惩罚。

iii GIoU 损失

GIoU^[52]损失 (Generalized Intersection over Union Loss) 是对传统 IoU 损失的改进版本, 旨在解决 IoU 损失函数的一些局限性, 尤其是当预测框与真实框不重叠 (即 IoU 为 0) 时, 无法提供有效的梯度信息的问题。

GIoU 不仅考虑预测框与真实框的交并比, 还通过引入一个封闭框来综合考虑预测框与真实框的相对位置和大小关系。GIoU 的计算公式如 2-12 所示。

$$GIoU = IoU - \frac{|C - B \cap B^{gt}|}{|C|} \quad (2-12)$$

式中 C —预测框与真实框的最小外接矩形。

当预测框和真实框没有交集时, 传统 IoU 损失会直接变为 0, 这时无法提供有效的梯度。而 GIoU 通过引入封闭矩形框, 可以对预测框与真实框的相对位置关系进行惩罚, 提供更有意义的梯度信息。但是当预测框在真实框内部, 且预测框的大小相同时, 预测框和真实框的差都是相同的, GIoU 便无法区分相对的位置了。

iv DIoU 损失

DIoU^[53]在计算 IoU 的基础上, 引入了边界框中心点之间的欧几里得距离, 使得预测框的更新不仅受重叠区域影响, 还受到它与真实框之间距离的影响。DIoU 的公式如 2-13 所示。

$$DIoU = IoU - \frac{\rho^2(b, b^{gt})}{c^2} \quad (2-13)$$

式中 ρ —表示两个中心点之间的欧氏距离。

b —表示预测框的中心点。

b^{gt} —表示真实框的中心点。

c —表示能够同时包含预测框和真实框的最小闭包区域的对角线距离。

GIoU 在一个框包含了另一个框是失去了作用, DIoU 考虑了包围盒之间的距

离约束，并且在 IOU 的基础上增加了质心归一化距离损失项，在预测框与真实框重叠时，仍然可以为预测框提供移动方向，且直接最小化两个目标框的距离，使其回归结果更准确。但是 DIoU 并没有考虑到长宽比对 IoU 变化的影响。

v CIOU 损失

CIoU^[54]在 DIoU 的基础上，加入了对宽高比的一项惩罚，使得损失函数能够同时考虑三个因素包括：交并比、中心点距离、宽高比一致性。具体 CIOU 公式如 2-14~2-16 所示。

$$CIoU = IoU - (\frac{\rho^2(b, b^{gt})}{c^2} + \alpha v) \quad (2-14)$$

$$\alpha = \frac{v}{(1 - IoU) + v} \quad (2-15)$$

$$v = \frac{4}{\pi^2} (\arctan \frac{w^{gt}}{h^{gt}} - \arctan \frac{w}{h})^2 \quad (2-16)$$

式中 α 一是权重系数，用于平衡宽高比损失。

v 一宽高比一致性度量。

CIoU 进一步考虑 GT 和锚框之间的形状相似性，通过添加新的形状损失项来减少锚框和 GT 框之间的纵横比差异。

(4) 反向传播、参数更新

反向传播是基于链式法则（链式求导），通过逐层计算损失相对于每个参数的梯度，然后使用这些梯度来更新模型参数的过程。根据损失值，计算损失相对于每个参数的梯度（导数） $\frac{\partial L}{\partial W^{[l]}}$ 、 $\frac{\partial L}{\partial b^{[l]}}$ ，即损失函数对网络中每层参数的敏感性。通过反向传播^[55]，模型知道各个参数对最终损失的影响，从而可以在下一步中更新这些参数。

一旦通过反向传播计算出每层参数的梯度，接下来就是根据这些梯度更新模型的参数。参数更新使用优化算法（如梯度下降、Adam^[56]等）来更新参数。梯度下降的更新规则如公式 2-17,2-18。

$$W^{[l]} = W^{[l]} - \eta \frac{\partial L}{\partial W^{[l]}} \quad (2-17)$$

$$b^{[l]} = b^{[l]} - \eta \frac{\partial L}{\partial b^{[l]}} \quad (2-18)$$

其中， η 是学习率（Learning Rate），表示每次更新时，沿梯度方向前进的步长。

前向推理、损失计算、反向传播和参数更新的整个过程被称为一个训练迭代（Iteration）。深度学习模型通过多次迭代，不断调整参数，使得损失函数的值逐渐减小，最终得到一个能够有效预测的模型。

2.3 本章小结

（1）本章介绍卷积神经网络的基本原理，包括数据输入与预处理、卷积层、池化层、全连接层的介绍。

（2）分别从数据预处理、算法模型构建、模型训练介绍深度学习算法构建的整体流程。其中着重介绍了算法模型构建中各部分的作用，以及模型训练中的损失函数部分，为后面深度学习算法的改进提供理论基础。


第3章 基于 YOLOv8 算法的三叉轴表面缺陷检测

3.1 三叉轴表面缺陷数据集制作

差速器中的三叉轴是核心的传动部件，其主要作用是连接和支撑差速器中的半轴齿轮。通过它，发动机传递过来的动力可以分配到左右两个半轴，从而驱动车轮转动。三叉轴与差速器的其他部件共同作用，帮助实现左右车轮的差速。也就是说，当车辆转弯时，三叉轴允许内外侧车轮以不同的转速运转，以避免打滑或轮胎磨损过快。三叉轴表面的微小缺陷可能在使用过程中因应力集中而扩大，形成更严重的损伤，进而缩短零件的使用寿命。通过及时发现和处理表面缺陷，可以延长三叉轴的使用寿命，提高车辆的可靠性。故对三叉轴表面缺陷进行检测具有重要意义。

3.1.1 缺陷数据集介绍

本文采用的数据集为三叉轴轴颈的外表面缺陷数据集。三叉轴工件示意图如 3-1 所示。



3-1 三叉轴工件示意图

图像数据来自工厂采集，根据三叉轴的尺寸大小选择合适的硬件装置包括相机、镜头、光源等，由杭州欧谱洛博自动化技术有限公司搭建了图像采集系统对三叉轴图像数据进行采集，光源使用的是 COL20-20，分别使用了五个相机，5 号相机拍摄三叉轴端面，其余相机负责拍摄轴颈，为拍摄完整轴颈每个相机负责轴颈的不同角度，分前端和整体两次拍摄，相机型号为 Hikvision MV-CS050-10GM，

相机镜头的型号为 MVL-KF2528M-12MPE。

图像采集装置如图 3-2 所示。




图 3-2 图像采集装置

对三叉轴表面缺陷图像进行采集后制作成数据集。数据集共 5180 张，包括缺肉、磕碰、欠加工、锈斑、倒角 5 类缺陷。其中这 5 类缺陷的检测要求如表格 3-1 所示。

表 3-1 缺陷说明表

编号	缺陷种类	数量分布	缺陷描述说明
1	轴颈锈斑	4766	可以检出 1mm*1mm 以上的黑色锈斑。
2	轴颈磕碰伤	12401	可以检出 1mm*1mm,深度 0.5mm 以上的尖锐轴颈型磕碰伤。
3	轴颈欠加工	1248	可以检出 1mm*1mm，轴径未加工缺陷。
4	缺肉	7725	可以检出缺肉面积大于 2mm*2mm 以上。
5	倒角缺陷	7780	可以检出倒角上缺陷面积大于 2mm*2mm 以上。

其中，各类缺陷的形成原因，以及会产生的后果说明如下。

（1）轴颈锈斑

锈斑是表面氧化引起的缺陷。锈斑会削弱金属表面的强度，造成应力集中，并为裂纹扩展提供起点。在湿度较高或腐蚀环境中，锈斑还可能进一步扩大，从而加速三叉轴的劣化，严重影响其寿命。

（2）轴颈磕碰伤

磕碰可能导致表面凹陷或微裂纹,降低三叉轴的结构完整性。由于应力集中,磕碰处更容易发生疲劳断裂,影响使用寿命。

(3) 轴颈欠加工

表面欠加工指加工未达标,可能导致表面粗糙度不佳,摩擦增大。在运行中,粗糙的表面会加速磨损,导致表面剥落或疲劳损伤,影响三叉轴的寿命。


(4) 缺肉

缺肉是指表面材料局部缺失,可能由于制造缺陷或磨损所致。这种缺陷会削弱三叉轴的承载能力,降低抗疲劳强度,导致提前失效。


(5) 倒角不良

倒角处理不当会使三叉轴在装配和运转中产生不均匀的受力,特别是在应力集中区域加剧磨损,导致疲劳寿命缩短。此外,不良倒角还可能引起装配困难或干涉,影响差速器整体性能。


该数据集缺陷示意图如图 3-3 所示。




(a) 锈斑




(b) 磕碰



(c) 欠加工



(d) 凹坑



(e) 倒角缺陷

图 3-3 缺陷示意图

对于训练所用数据，按 8:1:1 的比例分为训练集、测试集和验证集。训练集：大部分数据用于训练，以确保模型能够学习到数据中的模式和特征。更多的训练数据通常能够让模型获得更好的泛化能力，因为它见过的数据样本更多，能更准确地捕捉数据分布。验证集：主要用于模型训练过程中实时评估模型性能，确保模型不仅仅适应训练集，还能在未见过的数据上表现良好。测试集：本文采集的数据集一共有 5180 张图片，有 500 多张图片在模型训练和验证过程中都没有被使用过，具备统计意义。按这样的比例分配能确保有足够的用于训练模型，同时保留一部分数据用于验证和测试，保证模型泛化能力足够的前提下，有一定量的验证和测试数据。

3.1.2 缺陷数据标注及数据增强

(1) 缺陷数据标注

文章数据标注采用 LabelImg 软件，LabelImg 是一个开源的图像标注工具，常用于计算机视觉任务中的数据集标注，特别是在目标检测和图像分类任务中。它以简单易用的界面和灵活的功能受到广泛欢迎，适用于创建边界框（bounding box）标注。缺陷标注过程如图 3-4 所示。




图 3-4 LabelImg 缺陷标注

通过 LabelImg 标注软件标注后获得 json 文件记录了缺陷图片的一系列数据包括文件位置、文件名、图像尺寸信息、标注角点坐标信息，具体如图 3-5 所示。

```
<annotation>
  <folder>part2</folder>
  <filename>CIP1_2023_11_28_15_07_20_672.bmp</filename>
  <path>E:\data-li\总图片\part2\CIP1_2023_11_28_15_07_20_672.bmp</path>
  <source>
    <database>Unknown</database>
    <source>
  </source>
  <size>
    <width>1440</width>
    <height>1080</height>
    <depth>1</depth>
  </size>
  <segmented>0</segmented>
  <object>
    <name>kepeng</name>
    <pose>Unspecified</pose>
    <truncated>0</truncated>
    <difficult>0</difficult>
    <bndbox>
      <xmin>782</xmin>
      <ymin>358</ymin>
      <xmax>810</xmax>
      <ymax>388</ymax>
    </bndbox>
  </object>
</annotation>
```

图像尺寸信息

标注框角点坐标信息

图 3-5 缺陷标注获得的 Json 文件

图 3-5 中 filename 为文件名，path 为文件路径，size 为图像尺寸信息，object 为标注出的缺陷，bndbox 为标注框角点的坐标信息。

(2) 数据增强

Mosaic 数据增强是一种图像数据增强技术，它通过将多张图像(通常是 4 张)拼接成一张图像，来增加训练数据的多样性，同时保留图像中的关键信息。

Mosaic 数据增强的工作原理分为三点：图像拼接、标签调整、随机裁剪。图

像拼接从数据集中随机选取 4 张图像,将它们按照 2x2 的布局拼接成一张新图像。每张原始图像在新图像中会占据四分之一的比例。拼接过程还可以随机改变每张图像的缩放比例和位置,使得每次拼接的结果都不相同。标签调整在进行图像拼接的同时,目标的标注信息(如目标框的位置、类别等)也会相应调整,以匹配新拼接图像中的坐标。新拼接的图像经过进一步随机裁剪,确保生成的新样本具备更丰富的场景和比例变化。

Mosaic 数据增强能够增加背景的多样性;通过随机组合和裁剪,Mosaic 技术能大大增加训练样本的多样性,降低模型过拟合的风险,避免过拟合;且在拼接图像时,原图可能被缩小,这样在较大比例下的小目标也可以被模型更好地学习,从而提高小目标检测的效果。Mosaic 数据增强运用的效果图如图 3-6 所示。




图 3-6 Mosaic 数据增强效果图

3.2 YOLOv8 算法

3.2.1 YOLOv8 网络结构介绍

本文研究基于 YOLOv8 模型,YOLO 系列在单阶段检测方法中因其较高的检测精度和优异的检测速度被广泛使用,YOLOv8 是 YOLO 系列的基本模型,其网络结构由三大部分组成:主干网络(Backbone)、特征融合(Neck)、网络头部(Head)整体网络结构如图 3-7 所示。




图 3-7 YOLOv8 网络结构图

(1) 主干网络部分 (Backbone)

由五个卷积模块和四个 C2f 模块和一个 SPPF 模块组成。

i 卷积模块

其中卷积模块参数包括输入通道数(c1)、输出通道数(c2)、卷积核大小(k)、步长(s)、填充(p)。这里主要用于提取特征,且每经过一次卷积模块通道数翻倍特征图尺寸缩小一半。卷积模块作为神经网络的基本模块由卷积、批归一化、SiLU 激活函数组成。卷积模块组成如图 3-8 所示。




图 3-8 卷积模块

ii Bottleneck 模块

Bottleneck 层是在深度残差网络 (ResNet) 中引入的一种重要组件,用于降低模型的计算复杂度并提升特征提取能力。Bottleneck 模块组成如图 3-9 组成。




图 3-9 Bottleneck 模块组成

Bottleneck 模块通过使用 1×1 卷积层降低输入的通道数，减少了后续 3×3 卷积层的计算量，降低了计算复杂度，这对于深层网络的训练和推理过程都具有重要意义。且 3×3 卷积层用于在减少维度后进行特征提取，增加了网络对输入特征的表达能力。这样可以在保持较少计算复杂度的同时，提高模型的性能和表示能力。

iii CSPLayer_2Conv 模块

在 YOLOv8 网络结构中，C2F 模块（CSP Bottleneck with 2 Convolutions）是一个关键组件，用于实现跨阶段部分聚合。CSPLayer_2Conv 模块的组成如图 3-10 所示。




图 3-10 CSPLayer_2Conv 模块的组成

C2f 模块通过将不同 Bottleneck 模块的输出和原始特征图拼接在一起，C2F 模块能够更好地聚合多尺度信息。而且 C2F 模块中的卷积操作可以有效地压缩特征图，减少计算量，同时保持或增强模型的表达能力。

iv SPPF 模块

SPPF(Spatial Pyramid Pooling-Fast)模块是为了高效地捕捉多尺度信息而设计的，它利用简化版的空间金字塔池化。这个模块使得网络可以处理不同尺度的特

征，这在目标检测任务中特别有用，因为目标在图像中可能以不同的大小出现。SPPF 模块的组成如图 3-11 所示。




图 3-11 SPPF 模块的组成

主干网络部分通过上面的一系列操作提取了图片的信息得到了特征图，再通过特征融合部分将主干网络提取的多尺度特征进行进一步处理和融合，帮助模型更好地理解目标的全局和局部信息。

（2）特征融合部分（Neck）

YOLOV8 中引入了 PAN-FPN (Path Aggregation Network -Feature Pyramid Network)作为其特征金字塔网络，进一步增强了多尺度特征的代表能力。

在 YOLOv8 中，特征金字塔（FPN）主要负责构建从低层到高层的多尺度特征图。自顶向下从深层特征开始逐渐上采样，每一层的上采样特征与相应的低层特征进行融合，以补充空间信息和增强语义信息。

路径聚合网络（PAN）是在 FPN 的基础上，进一步增强特征金字塔的网络结构，从底向上逐层传递特征，每层下采样特征与相应的高层特征图进行融合，确保每一层的特征都包含不同尺度的信息。

（3）网络头部（Head）

网络头部负责将 Neck 部分输出的特征进行进一步处理，以生成最终的检测结果，主要功能是将特征图转换为目标检测所需的具体信息，包括类别、位置和置信度。

3.2.2 实验评价指标

在 YOLOv8 模型中,评价指标是衡量目标检测模型性能的关键标准。它们用于评估模型在检测任务中定位和分类目标的准确性、速度以及对实际场景的适应性。

(1) TP、FP、TN、FN

i 正确的正向预测 (True Positive, TP)

本身是正样本被正确检测的数量,需要满足置信度(Confidence Score)大于阈值;预测类型与标签类型匹配;预测的 Bounding Box 与 Ground Truth 的交并比大于阈值(e.g.0.5),当有多个满足条件的预选框,则选择置信度最大的作为 TP,其余的作 FP。

ii 错误的正向预测(False Positive, FP)

负样本被检测为正样本的数量,也称误报,预测的 Bounding Box 与 Ground Truth 的 IoU 小于阈值的检测框(定位错误)或者预测的类型与标签类型不匹配(分类错误)。

iii 错误的负向预测(False Negative, FN)

正样本没被检测为负样本的数量,也称漏报,指没有检测出的 Ground Truth 区域。

iv 正确的负向预测(True Negative, TN)

是负样本且被检测出的数量,无法计算,在目标检测中,通常也不关注 TN。

(2) 准确率和召回率

i 准确率 (Precision)

准确度也叫查准率,在所有被模型预测为正类(缺陷)的样本中,实际为正类(真实存在缺陷)的比例。例:模型识别出 100 个缺陷,有 80 个是正确的缺陷,准确率即为 80%。具体公式如 3-1 所示。

$$Precision = \frac{TP}{TP + FP} \quad (3-1)$$

ii 召回率 (Recall)

召回率是在所有真实为正类(真实存在缺陷)的样本中,模型能够正确预测为正类的比例。例:真正的缺陷有 100 个,模型找到了 80 个,即召回率为 80%。具体公式如 3-2 所示。

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3-2)$$

(3) 平均精度均值 (Mean Average Precision, mAP)

mAP 是目标检测领域中最常用的综合评价指标，它将模型的精确率和召回率进行结合，以全面衡量模型的性能。

mAP 是计算每个类别的平均精度(AP),然后对所有类别的 AP 取平均值。AP 本质上是精确率-召回率曲线下的面积,在不同的置信度阈值下计算不同点的精确率和召回率,并取这些点的平均值。

3.2.3 实验结果与分析

本文实验的操作系统使用 ubuntu22.04, 处理器为英特尔酷睿 i7-9700 CPU, 显卡为 RTX 3090, 显存为 24G, python 版本为 3.8,CUDA 版本为 11.3, 使用 Pytorch 框架进行训练, torch 版本为 1.13.1, 迭代次数为 100, 批次大小为 8, 图像输出尺寸为 1280*1280 像素。

实验检测效果如图 3-12 所示。




图 3-12 试验检测效果图

YOLOv8 算法模型在三叉轴表面缺陷检测中 mAP@0.5 达到了 0.791，其中缺肉为 0.681，磕碰为 0.863，欠加工为 0.994，锈斑为 0.648，倒角缺陷为 0.767。检测结果如表 3-2 所示。

表 3-2 YOLOv8 检测结果

Model	AP 缺肉	AP 磕碰	AP 欠加工	AP 锈斑	AP 倒角	mAP@0.5
YOLOv8	0.681	0.863	0.994	0.648	0.767	0.791

3.3 本章小结

- （1）本章首先根据工厂采集的三叉轴轴颈图片制作表面缺陷数据集。
- （2）然后详细介绍了文章用到的 YOLOv8 算法，包括主干网络、特征融合、网络头部。
- （3）最后将 YOLOv8 算法应用到三叉轴数据集中，mAP 达到了 0.791 并展示了模型检测的效果图。

第4章 TS-YOLO 算法介绍与结果分析

4.1 TS-YOLO 模型整体结构

由于工业环境中三叉轴表面缺陷的复杂性以及众多小缺陷的存在，原始 YOLOv8 网络可能无法准确定位和检测这些缺陷。我们在本节中介绍了 TS-YOLO 算法。网络结构部分，首先在骨干网络的末端添加了 ScConv，以增加少部分计算量为代价增强了模型的特征提取能力。其次，在特征融合部分采用了 GSCConv 代替传统卷积。此外，提出了 VoV-GSCSPC 模块，在高效节约计算量的同时提高检测精度。最后，将 CIoU 损失函数替换为 Inner-ShapeIoU，进一步提高了模型的检测精度，特别是在小目标方面。图 4-1 展示了整体网络结构。




图 4-1 TS-YOLO 网络结构

4.2 Backbone 改进

Yolov8 沿用了 Yolov5 的网络结构思想, 使用 CSP (紧凑与分离) 的主干网络。为了提高检测精度的同时平衡模型的参数量, 本文在主干网络结尾使用结合空间重构单元 (SRU) 和通道重构单元 (CRU) 的 ScConv^[57]。

ScConv 首先将输入特征 X 通过 Spatial Reconstruction Unit (SRU) 获得空间重组特征 X^w , 然后再经过 Channel Reconstruction Unit (CRU) 获得通道细化特征, 最终得到输出结果 Y 。本文 ScConv 整体结构如图 4-2 所示。




图 4-2 ScConv 整体结构

首先经过用于空间冗余的 SRU 目的在于将特征信息丰富的 feature map 与特征信息较少的 feature map 进行分离。具体过程为利用 Group Normalization 层, 对输入 X 进行标准化。 α 用作表示每个批次和通道的空间像素的方差。利用公式 W_i 来表示每一个特征图的重要性。再利用 sigmoid 函数将 W_i 的值缩放到 (0,1) 之间, 然后设定阈值, 将权重大于阈值的作为特征信息丰富的 feature map 信息权重为 W_1 , 权重低于阈值的反之 (在实验中阈值设置为 0.5), 整体的公式如 4-

1 所示。

$$W = \text{Gate}(\text{Sigmoid}(W_a(\text{GN}(X)))) \quad (4-1)$$

为了减少空间方面的冗余，提出了一种融合操作，用包含信息量大的特征加上包含信息量小的特征，生成大信息量的特征的同时节省了内存空间。整体过程如公式 4-2。

$$\begin{cases} X_1^w = W_1 \otimes X, \\ X_2^w = W_2 \otimes X, \\ X_{11}^w \oplus X_{22}^w = X^{w1}, \\ X_{21}^w \oplus X_{12}^w = X^{w2}, \\ X^{w1} \cup X^{w2} = X^w. \end{cases} \quad (4-2)$$

$\otimes$ 是逐元素相乘， $\oplus$ 是逐元素相加， $\cup$ 是 **concat** 操作。在 SRU 被应用到特征 X 之后，我们不仅将信息量多的特征与信息量少的特征分开，而且重建了它们以增强代表性特征并对空间维度上的冗余特征进行抑制。然而，空间细化的特征图 X^w 在通道维度上仍然保持冗余。

接下来经过用于通道冗余的 CRU，减少通道冗余。用 CRU 代替标准卷积，CRU 通过三个运算符 **Split**（分离），**Transform**（转换）和 **Fuse**（混合）来实现。分离操作将通道分为两个部分， $0 \leq \alpha \leq 1$ 是区分的比例，利用 1×1 卷积改变通道数，减少计算量。压缩比率通常设置为 2（ 1×1 卷积输出的通道为原来的一半），在分裂和挤压操作之后，我们将空间细化特征 X_w 分成上部 X_{up} 和下部 X_{low} 。将 X_{up} 送入上级转换，作为丰富特征提取器，利用相同特征图 X_{up} 上的 GWC（分组卷积）和 PWC（ 1×1 卷积，改变通道数）的组合来以较少的计算成本提取丰富的代表性特征 Y_1 。 X_{low} 被输入到较廉价的 1×1 PWC 操作部分，来生成具有浅层细节的特征，用作补充上半部分特征提取器。紧接着，将生成和原始特征连接起来以形成较低级的 Y_2 输出，整体流程如公式 4-3 所示。

$$\begin{cases} Y_1 = C^G X_{up} + C^P X_{up}, \\ Y_2 = C^P X_{low} \cup X_{low}. \end{cases} \quad (4-3)$$

其中 C^G 为分组卷积， C^P 为 1×1 卷积。

Fuse（混合）操作使用全局平均池化来收集全局的空间信息然后，堆叠上下全局平均池化后的结果 G_1 、 G_2 ，利用通道软注意力操作来产生通道重要性向量。

最终，在通道重要性向量 β_1, β_2 的指导下，通过通道的方式将上部丰富特征 Y_1 和下部特征 Y_2 合并起来获得最终结果，通道细化特征 Y ，整体流程如公式 4-4 所示。

$$\begin{cases} G_d = \text{AveragePooling}(Y_d), d=1,2 \\ \beta_1 = \frac{e^{G_1}}{e^{G_1} + e^{G_2}}, \beta_2 = \frac{e^{G_2}}{e^{G_1} + e^{G_2}}, \\ \beta_1 + \beta_2 = 1, \\ Y = \beta_1 Y_1 + \beta_2 Y_2. \end{cases} \quad (4-4)$$

4.3 改进的 Neck 设计范式

YOLOv8 网络中的颈部网络使用了 PANet，作用在于使得主干网络的特征提取能力更强。主干网络的浅层特征图具有高分辨率和准确的定位信息，但缺乏丰富的语义信息。相比之下，主干网络的深层特征图具有丰富的语义信息，但分辨率较低且定位信息不够准确。PANet 通过整合自底向上和自顶向下两种路径，融合各尺度的特征，提高了高层信息的定位准确性。这种融合策略提升了骨干网络输出特征图的定位能力，从而提高了网络的性能。

PANet^[59]的基本组成模块是 CSPLayer，在实际运用中模型的推理速度，是判断模型好坏的重要指标，但是由大量 DS 卷积层构建的轻量级模型会使得准确性降低。文章引入 GSConv^[60]能够在减少计算量的同时具有较高的准确性，实现了模型准确性和速度之间的有效平衡。基于 GSConv 引入新的设计范式 VoV-GSCSP 来替换原始的 CSPLayer 模块。

GSConv 的基本思路认为 SC(普通卷积)和 DSC(深度可分离卷积)是可以相互合作的。为了使 DSC 的输出尽可能接近 SC，文章使用 SC、DSC 混洗的混合卷积，称为 GSConv，整体结构如图 4-3 所示。




图 4-3 GSConv 结构图

使用 shuffle 将 SC 生成的信息与 DSC 生成的信息混合。这种方法使得模型能够在不同信息通道上均匀的交换局部特征信息，将 SC 获取的信息完全的混合到 DSC 的输出中。

使用 GSConv 模块替换原 YOLOv8 的瓶颈模块中所使用的 Conv。然后，采用一次聚合的方法设计了跨阶段部分网络(GSCSP)模块 VoV-GSCSP，模块整体结构如图 4-4。图 4（a）中 GSbottleneck 将原有的标准卷积替换成 GSConv，图 4（b）中再由 GSbottleneck 替换原 CSPLayer 中的 bottleneck 部分。该模块结构简单没有冗余的操作，效率更高。

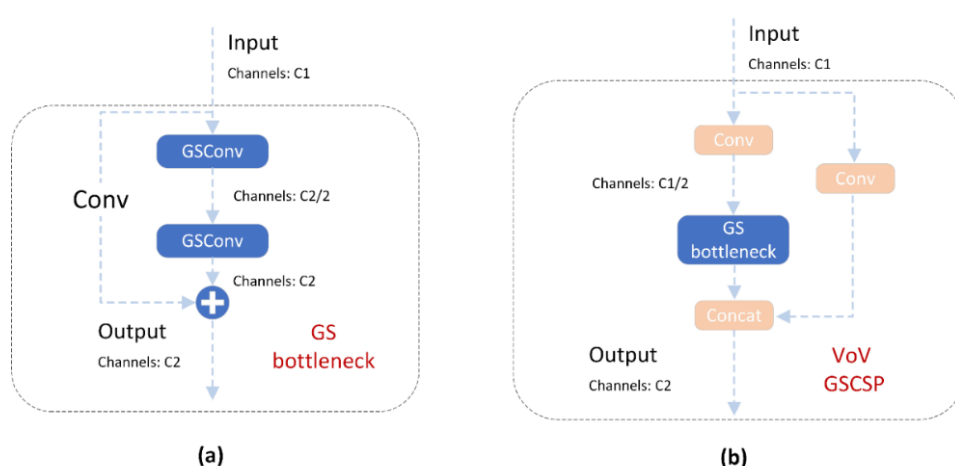


图 4-4 VoV-GSCSP 模块整体结构

4.4 Inner_Shape-IoU 损失

在目标检测任务中，损失函数对模型性能有很大影响，尤其是边界框损失函数在其中起着重要作用。YOLOv8 中的边界框预测函数采用了 CIoU Loss 作为损失函数的核心，CIoU Loss 考虑了预测框和真实框的宽高比，但是忽视了边界框的形状和尺寸这些固有的属性，而且也不能根据不同的检测器和检测任务进行自我调整。本文使用 Inner_Shape-IoU^[61]来代替原有的 CIoU，该损失函数可以根据不同的回归样本，使用不同尺度的辅助包围盒来计算损失，并且能够关注包围框本身的形状和尺度。Inner_Shape-IoU 公式如 4-5 到 4-10 所示。

$$\begin{aligned} inner = & \left(\min(b_r^{gt}, b_r) - \max(b_l^{gt}, b_l) \right) \\ & * \left(\min(b_b^{gt}, b_b) - \max(b_t^{gt}, b_t) \right) \end{aligned} \quad (4-5)$$

$$union = (w^{gt} * h^{gt}) * (ratio)^2 + (w * h) * (ratio)^2 - inter \quad (4-6)$$

$$IoU^{inner} = \frac{inter}{union} \quad (4-7)$$

$$distance^{shape} = hh * (x_c - x_c^{gt})^2 / c^2 + ww * (y_c - y_c^{gt})^2 / c^2 \quad (4-8)$$

$$\Omega^{shape} = \sum_{t=w,h} (1 - e^{-\omega_t})^\varepsilon, \varepsilon = 4 \quad (4-9)$$

$$\begin{cases} \omega_w = hh * \frac{|w - w^{gt}|}{\max(w, w^{gt})} \\ \omega_h = ww * \frac{|h - h^{gt}|}{\max(h, h^{gt})} \end{cases} \quad (4-10)$$

其中 b_{gt} 表示辅助的真实框和 b 表示了辅助的预测框, l 、 r 、 t 、 b 下标为左右上下顶点坐标, $inter$ 计算出了辅助预测框与辅助真实框相交的面积即交集, $union$ 表示两类包围框的并集, IoU^{inner} 则计算出了辅助框的 IoU 值, 用于加速真实框预测框的收敛; ww 和 hh 分别是水平和垂直方向上的权重系数将边界框自身属性拉入损失函数的考量范围, 其值与 GT 框的形状相关; x_c 、 y_c 表示中心点 x 、 y 坐标, c^2 为最小外接矩形面积, 故 $distance$ 表示加上了原 gt 框形状的权重的距离损失, ω 从宽和高来衡量回归框的形状与标签框形状的相似度, ε 为形状成本即对形状的关注度, 故 Ω 表示加上了原 gt 框形状的权重的形状损失。整体公式如 4-11 所示。

$$L_{Inner_Shape-IoU} = 1 - IoU^{inner} + distance^{shape} + 0.5 * \Omega^{shape} \quad (4-11)$$

$Inner_Shape-IoU$ 在加速网络收敛的同时, 提高了网络精度, 特别是小目标。主要原因是当真实边界框本身尺寸较小时, 尺寸变化, 对 IOU 变化影响更大。


综上所述, 首先将 $ScConv$ 加入到主干网络尾部, 在只增加了少量计算量的情况下提高了网络的特征提取能力, 并在颈部引入 $GSCConv$ 基于 $GSCConv$ 引入新的设计范式 $VoV-GSCSP$ 来替换原始的 $CSPLayer$ 模块, 减少计算量的同时提高了检测精度。最后优化损失函数设计, 将 $CIoU$ 损失函数替换为融合的 $Inner_Shape-IoU$ 损失函数, 进一步提高了模型精度特别是小目标的精度。

4.5 实验结果及分析

4.5.1 对比实验

为了验证本文算法 (TS-YOLO) 的有效性, 在保证相关配置不变的情况下, 使用相同的数据集, 与目标检测算法 Faster R-CNN、SSD、YOLOv3、YOLOv5、YOLOv8 进行对比实验。实验结果如表 4-1 所示。

结果表明, TS-YOLO 在三叉轴数据集上表现最佳, 取得了 84.8% 的 mAP, 超越了其他主流模型。为了更好地说明模型在检测三叉轴表面缺陷方面的性能, 使用这些模型对三叉轴表面进行缺陷检测。结果如图 4-5 所示。






图 4-5 各模型推理结果图片

其中第一行图片显示 YOLOv5 算法只检测出了一个正确标签，而本文算法能准确检测出所有三个标签；第二行图片 YOLOv5 和 YOLOv8 算法都出现了漏检和误检；第三行图片所有算法都检测出了正确的标签，但是 YOLOv8 出现了误检；第四行第五行图片中 YOLOv5 算法都出现漏检。整体看来 YOLOv5 检测出图片的置信度都比较高，但是对于小目标很容易出现漏检问题，YOLOv8 算法较 v5 好一些但依然存在漏检问题，而本文提出的 TS-YOLO 算法能比较全面的检测图片中的缺陷，对小目标友好。

表 4-1 多种检测模型对比结果

Model	AP	AP	AP	AP	AP	mAP@0.5
	缺肉	磕碰	欠加工	锈斑	倒角	
Faster R-CNN	0.636	0.744	0.892	0.433	0.601	0.661
SSD	0.654	0.792	0.876	0.503	0.654	0.696
YOLOv3	0.666	0.841	0.988	0.599	0.754	0.77
YOLOv5	0.67	0.853	0.982	0.497	0.772	0.755
YOLOv8	0.681	0.863	0.994	0.648	0.767	0.791
TS-YOLO	0.678	0.88	0.99	0.907	0.787	0.848

上表为模型对比实验结果，其中，磕碰、锈斑、倒角这些小缺陷类型缺陷效果有明显提升，而缺肉缺陷类型大小不一有小幅下降，欠加工缺陷类型特征明

显且尺寸都很大检测效果良好，有小幅下降影响不大。

为了进一步说明 TS-YOLO 算法的普遍意义，在保证相关配置不变的情况下使用不同的数据集进行对比试验，包括轴承外平缺陷数据集和 Kaggle GC10-DET 钢铁表面缺陷公共数据集，轴承外平缺陷数据集缺陷包括磕碰（1mm*1mm 以上）、黑块（1mm*1mm 以上）、缺口（2mm*2mm 以上）三类，缺陷示意图如 4-6 所示。




图 4-6 轴承外平表面缺陷种类示意图

Kaggle GC10- DET 钢铁表面缺陷公共数据集缺陷包括冲孔、焊缝、月牙弯、水斑等十类。轴承外平面数据集中不同算法对比实验结果如表 4-2 所示。Kaggle GC10-DET 钢铁表面缺陷公共数据集对比实验结果如表 4-3 所示。

表 4-2 轴承外平表面缺陷数据集各算法结果

Model	AP 磕碰	AP 黑块	AP 缺口	mAP@0.5
YOLOv8	0.903	0.951	0.939	0.931
TS-YOLO	0.946	0.963	0.965	0.958

表 4-3 Kaggle GC10-DET 钢铁表面缺陷公共数据集各算法结果

Model	AP 冲孔	AP 焊缝	AP 月牙弯	AP 水斑	AP 油斑	AP 丝斑	AP 异物	AP 折痕	AP 腰折	AP 凹坑	mAP@0.5
YOLOv8	0.928	0.873	0.921	0.855	0.699	0.541	0.182	0.351	0.482	0.706	0.654
TS-YOLO	0.96	0.925	0.967	0.870	0.646	0.546	0.319	0.413	0.587	0.741	0.697

结果表明, TS-YOLO 算法在轴承外平面数据集上各个缺陷的 AP 都有所提高, 特别是磕碰这类较小的缺陷提升了 4.3%, 总体 mAP 提高了 2.7%; 在 Kaggle GC10-DET 钢铁表面缺陷公共数据集中, 除了油斑的检测效果有少许下降, 其他缺陷都有提升, 整体 mAP 提高了 4.3%, 证明了该算法的优越性。

4.5.2 消融实验

为了展示经过改进的 ScConv、Neck 部分的 VoV-GSCSP 模块、以及损失函数 Inner_Shape-IoU 对于 YOLOv8 模型算法的不同影响, 本文在实验条件相同的情况下进行了消融实验, 结果如表 4-4 所示。

表 4-4 消融实验结果

YOLOv8	ScConv	VoV-GSCSP	Inner_Shape-IoU	mAP@0.5	P	r	GFLOPs	mAP@0.5-0.95
√	—	—	—	0.791	0.781	0.736	164.8	0.477
√	√	—	—	0.823	0.786	0.779	165.2	0.507
√	—	√	—	0.827	0.809	0.78	159.1	0.507
√	—	—	√	0.825	0.75	0.825	164.8	0.506
√	√	√	—	0.82	0.727	0.817	163.3	0.505
√	√	—	√	0.841	0.756	0.841	165.2	0.514
√	—	√	√	0.828	0.796	0.769	159.1	0.519
√	√	√	√	0.848	0.781	0.836	163.3	0.527

上表可以看出, 与 YOLOv8 相比, 加入 ScConv 模块的模型的 mAP@0.5 和 mAP@0.5-0.95 分别提高了 3.2%和 3%, 准确率提高了 0.5%, 召回率提高了 4.3%, 计算量只增加了 0.4 个点, 这表示 ScConv 模块在空间通道能够提取更丰富的特征信息, 有效提升了模型的精度, 且去除了通道方面的冗余, 计算量增加的很少。单独在颈部添加 VoV-GSCSP 模块时 mAP@0.5 和 mAP@0.5-0.95 分别提高了 3.2%和 3%, 准确率提高了 0.5%, 召回率提高了 4.3%, 计算量减少了 5.7GFLOPs, 这表示该模块不仅能够有效去除冗余信息, 降低计算量的同时还能提高模型精度。

单独使用 Inner_Shape-IoU 的模型 mAP@0.5 和 mAP@0.5-0.95 分别提高了

3.4%和 2.9%，准确率降低了 3.1%，但是召回率提高了 8.9%，可以看出相较于 CIoU, Inner_Shape-IoU 考虑了边界框本身的尺寸和辅助边界框之后使得模型在收敛的过程中更加稳定、高效，模型的检测精度也得到了提高。通过消融实验可以得出文章提出的三种改进模型的方法，能够有效地提高模型的性能，在降低计算复杂度的同时能够有效地提高模型检测精度，在检测精度和计算量之间达到了很好的平衡，图 4-7 为模型训练时损失和 mAP 随迭代次数的变化图。




图 4-7 损失和 mAP 随迭代次数的变化图

4.5.3 与海康原算法对比

海康 Vision Master 算法开发平台是一种机器视觉软件，由 HIKROBOT 自主开发，致力于为客户提供快速搭建视觉应用、解决视觉检测难题的算法工具，能满足测量尺寸、工件定位、缺陷检测以及文本识别等工业视觉方面的应用，是市面上主流的工业检测软件。

为了进一步验证和评估本文算法，本文将提出的 TS-YOLO 算法部署在海康 VM 软件上与海康 VM 软件自带的目标检测算法对比，海康 VM 算法的参数配

置为迭代轮次：100 轮，Patch 大小：大（适合小目标），模型能力为高精度与本文算法匹配，数据集大小与本文算法相同，最终在检测速度慢于 TS-YOLO 算法的情况下，检测精度依然落后于本文算法。效果如图 4-8 所示。




图 4-8 TS-Yolo 算法与海康算法对比

随机选取的三张效果对比图，更加直观地显示了本文算法与海康 VM 软件

原算法相比的优越性。其中第一行图片海康 VM 算法和本文算法都正确检出了对象，本文 TS-YOLO 算法置信度更高；第二行海康 VM 算法在小目标缺陷方面出现了漏检而本文算法能够检出；第三行海康算法对小目标漏检严重，而 TS-YOLO 算法将小目标全部检出，且置信度较高。

综上所述，本文方法很好的检测出了三叉轴轴颈磕碰和凹坑等小目标，减少了误检和漏检的情况，且具有实用性。

4.6 本章小结

(1) 整体介绍了改进的 TS-YOLO 算法，然后分别从主干网络、特征融合、损失函数完成对网络改进细节的介绍。

(2) 将改进的 TS-YOLO 算法做实验并对实验结果进行分析，实验部分包括相同数据集不同算法对比实验、消融实验、与海康原算法的对比实验，从各个方面证明了算法的优越性。

第 5 章 改进的 TS-YOLO 算法部署

5.1 引言

随着智能制造和工业自动化的快速发展，视觉检测技术在现代工业生产中的应用愈发广泛。在制造业中，表面缺陷检测任务是保证产品质量的重要环节。本文完成了 TS-YOLO 算法的部署，并讨论其在实际工业生产中的部署过程。

为了将 TS-YOLO 算法有效地应用于生产线，本章采用海康威视 Vision Master 的自定义算法开发模块，将算法嵌入到 Vision Master 软件中，并通过该软件与 PLC（可编程逻辑控制器）进行通信，形成完整的视觉检测与自动化控制系统。通过这种集成方式，TS-YOLO 算法不仅能够完成精确的目标检测任务，还可以与生产设备高效交互，实现自动化生产流程的智能化升级。

本章的主要内容包括 TS-YOLO 算法的部署流程，Vision Master 软件中自定义算法的开发与集成，以及利用 Vision Master 与 PLC 的通信功能完成检测与控制任务的具体方法。这一部署过程将展示如何将先进的视觉检测算法应用于实际工业生产中，并提升生产自动化水平。图 5-1 显示了算法部署的具体流程。




图 5-1 算法部署流程

5.2 需求分析

随着我国制造业智能化水平的不断提高,国家层面大力推进“中国制造 2025”等战略,旨在提升工业自动化水平,尤其是在高精度加工制造领域。三叉轴作为机械系统中的关键部件,其表面质量的高标准要求对检测技术提出了严格的需求。本文所讨论的表面缺陷检测系统,针对三叉轴零件,需同时满足高精度、合理的检测速度以及方法的通用性,以适应智能制造的需要。

算法的一系列改进其目的都是实现工业化应用,针对行业需求,三叉轴表面缺陷检测方案需要具备以下要求。(1) 三叉轴表面可能存在的缺陷包括磕碰、凹坑、锈斑等,这些缺陷不仅影响零件的外观,更会影响其力学性能和使用寿命。因此,系统设计的核心是保证检测的精度,尤其是在小型或微小缺陷的检测上,要求算法能够捕捉到这些细微的瑕疵。(2) 尽管表面缺陷检测对精度要求高,但其检测速度不需要特别快,只需跟上生产线图像采集和分选节拍即可。系统的检测速度需要与实际生产过程的节奏相匹配,确保不会影响生产线的正常运行和分拣流程。(3) 为了适应未来更多工业场景的应用需求,检测方法的通用性至关重要。在这方面,我们采用了海康 Vision Master 软件,结合自定义算法开发模块,实现了对不同场景下检测任务的灵活适配。这种方法保证了算法的可复制性,能够迅速迁移到其他类似的检测场景中应用,为未来在其他工业领域的推广应用提供了基础。

5.3 硬件设备介绍

为了完成表面缺陷检测算法的部署,需要提前做好硬件选型。文章主要使用的硬件设备包括计算机、工业相机、工业镜头、光源,下面是各个硬件的详细介绍。

(1) 计算机

在本文的三叉轴表面缺陷检测系统中,计算机作为核心处理单元,发挥了算法运行与推理、数据处理与存储、系统控制与通信、以及界面交互与界面显示的关键作用。因此,对其处理器性能、显卡配置等硬件参数有一定要求,同时还需要在考虑工业环境的实际应用时兼顾成本等经济因素。本文使用的计算机硬件配置参数详见表 5-1。

表 5-1 计算机硬件配置参数表

参数类型	参数值
CPU	Intel(R) Core(TM) i7-9700 CPU @ 3.00GHz
显卡	1660s
系统类型	64 位操作系统
机带 RAM	12GB

计算机实物图如图 5-2。



5-2 计算机

（2）工业相机

工业镜头的首要功能是高精度地采集三叉轴表面的图像。镜头通过光学成像系统将检测区域的光信号转化为相机传感器可以处理的数字信号，为后续的图像处理与缺陷检测提供原始数据。

工业镜头通常具有高分辨率和优秀的成像质量，能够清晰捕捉到三叉轴表面的细微缺陷，如磕碰、凹坑等。这对于确保系统能够准确识别小型缺陷，提升检测精度非常关键。

成像稳定性方面，工业镜头具备较好的稳定性和一致性，可以在不同的环境条件下，保持图像质量的稳定，避免失真和模糊。其设计能够适应工业场景中的震动、温度变化和复杂光照环境。镜头焦距和光圈等参数也可以根据检测需求进行调节，以适应不同尺寸、形状和材质的三叉轴表面，确保成像清晰度和检测效果的最佳状态。

文章采用海康威视公司的 MV-CS050-10GM 工业面阵形机，具备 500 万像素

的高分辨率，能够捕捉到细致的图像细节，非常适合进行高精度的工业检测。具体技术参数如表 5-2 所示。

表 5-2 工业相机技术参数

参数类型	参数值
品牌	海康
型号	MV-CS050-10GM
分辨率	2448*2048
像元尺寸	3.45 μm *3.45 μm
传感器类型	CMOS，全局快门
最大帧率	24.2 fps
成像图像	黑白/彩色

（3）工业镜头

在工业视觉系统中，选择合适的镜头对保证检测效果至关重要。选择合适的镜头需要综合考虑检测对象的尺寸、精度要求和环境因素。通过合理选择焦距、光圈、分辨率以及镜头类型，可以最大化检测系统的性能，确保获得清晰、稳定且高质量的图像，从而提高检测精度和效率。文章选用的镜头参数如表 5-3 所示。

表 5-3 工业镜头参数

参数类型	参数值
品牌	海康
型号	MVL-KF2528M-12MPE
焦距	6mm
畸变	2.5%
最近视距	0.1m
光圈控制	手动
焦距控制	手动

相机加镜头实物图像如图 5-2。



图 5-3 工业相机加镜头实物图

外观检测设备整体图像如图 5-3 所示。工位被防尘门遮挡，其内部是图 3-2 所示的图片采集装置；计算机显示器方便进行软件更新，以及通过软件 UI 界面实时显示图像检测结果；工业人机界面用于控制 PLC 设备；检测完成后由机械臂抓取三叉轴工件至物料传送带进行分拣。



图 5-4 缺陷检测设备

5.4 软件系统配置

(1) Ubuntu 操作系统

Ubuntu 是一个基于 Linux 内核的开源操作系统，由 Canonical 公司及其社区开发和维护。自 2004 年发布以来，Ubuntu 已成为全球最受欢迎的 Linux 发行版之一，广泛应用于服务器、桌面和嵌入式设备等多个领域。

Ubuntu 支持多种编程语言和开发环境,如 Python、C++、Java、Node.js 等。此外,Ubuntu 还集成了众多开发工具(如 Git、Docker、Kubernetes 等),并与常见的集成开发环境(IDE)如 Visual Studio Code、PyCharm 等兼容。

Ubuntu 操作系统以其用户友好性、开源特性和强大的软件支持而闻名,适合从初学者到高级开发者的广泛使用需求。它在桌面、服务器、云计算和嵌入式系统等领域都有广泛应用,成为现代 IT 和开发环境中的重要选择之一。

(2) CUDA 和 cuDNN

CUDA (Compute Unified Device Architecture) 和 cuDNN (CUDA Deep Neural Network Library) 是 NVIDIA 为加速计算和深度学习而开发的两种重要技术。它们广泛用于深度学习、科学计算和高性能计算(HPC)领域,主要用于利用 NVIDIA 显卡的强大计算能力。

CUDA 是 NVIDIA 于 2007 年推出的并行计算架构,允许开发者利用 NVIDIA GPU 的并行处理能力进行通用计算,而不仅限于图形处理。它为开发者提供了一套完整的编程模型和 API,方便使用 C、C++、Fortran 等语言编写代码来加速各种计算密集型应用。

cuDNN 是 NVIDIA 基于 CUDA 架构开发的深度学习加速库,专门用于加速深度神经网络(DNN)的训练和推理。cuDNN 提供了高度优化的基础函数库,包括卷积、池化、激活、归一化等操作,能够大大提升深度学习模型的运行效率。

(3) PyTorch 深度学习框架

PyTorch 是一个由 Facebook AI Research 团队开发的开源深度学习框架,它以灵活性、易用性和动态计算图的优势而广受开发者和研究人员的欢迎。PyTorch 尤其适合用于研究和开发深度学习模型,并在计算机视觉、自然语言处理、强化学习等多个领域中有着广泛应用。

PyTorch 原生支持 GPU 加速,开发者可以轻松将模型和数据迁移到 GPU 上运行,充分利用 GPU 的并行计算能力,大幅提升计算效率,且提供了高度简洁和直观的 API,易于上手,尤其适合从事研究的人员快速构建和实验不同的深度学习模型。与 Numpy 类似的张量(Tensor)操作使得 PyTorch 既能处理 GPU 加速的大规模张量运算,又能进行与 Numpy 相似的矩阵操作。

(4) OpenCV-DNN

OpenCV-DNN 是 OpenCV 库中的深度学习模块，用于在 OpenCV 框架中执行深度神经网络的推理。该模块可以加载和运行通过各种深度学习框架训练的模型，并进行高效的推理，尤其在计算机视觉领域应用广泛。OpenCV-DNN 模块支持多个流行的深度学习框架，如 TensorFlow、Caffe、ONNX、PyTorch 等，能够加载预训练模型并用于任务如图像分类、目标检测、语义分割等。

相比 TensorFlow、PyTorch 等大型深度学习框架，OpenCV-DNN 侧重于推理而非训练。其主要优势在于轻量级、高效的推理性能，适合部署到嵌入式设备或边缘计算环境中。然而，它不具备完整的深度学习训练功能，适用于加载预训练模型并进行推理的场景。

OpenCV-DNN 是一个轻量、跨平台且高效的深度学习推理模块，适合在资源受限的环境中进行图像分类、目标检测、图像分割等任务。其强大的框架兼容性和易用性使得开发者可以快速将各种预训练模型应用于计算机视觉任务中，并在 CPU 或 GPU 上高效运行推理。表 5-4 展示了所使用的软件系统配置及版本。

5-4 软件系统配置及版本

配置名称	版本	作用
Ubuntu 操作系统	20.04	操作系统，协调硬件设备、执行应用程序、管理资源等
CUDA	11.1	通用的并行计算平台，适用于各类计算密集型应用
cuDNN	8.2.1	加速深度神经网络（DNN）的训练和推理
Pytorch	1.9.1	开源深度学习框架
Opencv	4.7.0	开源的计算机视觉库，用于实时图像处理等
Numpy	1.24.4	Python 生态系统中用于数值计算和数据分析的核心库
Onnx	1.16.1	开源格式，用于表示深度学习模型
Pandas	2.0.3	开源的 Python 数据分析和数据处理库

5.5 部署推理

完成了硬件和软件系统的配置后，本节将介绍通过海康 Vision Master 软件配合部署和推理的过程。部署过程包括：Vision Master 软件二次开发、模型训练、通信、界面开发。具体部署流程如图 5-5 所示。




图 5-5 结合 VM 软件的部署流程

5.5.1 TS-YOLO 模型训练

推理部署的第一步是要通过深度学习模型训练获取针对于三叉轴表面缺陷数据集的最优权重文件，并将得到的权重文件转换成适合于模型推理的 ONNX 中间格式，从而充分发挥模型的性能。

(1) 创建虚拟环境

创建虚拟环境的主要作用是在同一台计算机上为不同的项目隔离其依赖的 Python 包和库，避免不同项目之间的冲突。虚拟环境在开发、部署和维护 Python 项目时非常有用，特别是当多个项目使用不同版本的库或需要不同的 Python 版本时。在终端输入如下命令：

```
conda create -n TS-YOLO python=3.8 # 创建名为 TS-YOLO 的虚拟环境
conda activate TS-YOLO # 进入该虚拟环境
```

(2) 依次安装 yolov8 所需要的依赖包

依次安装 YOLOv8 所需的依赖包的主要目的是确保项目能够正确运行，避免版本冲突，并确保各个依赖包之间的兼容性。YOLOv8 是一个基于深度学习的目标检测模型，需要多个第三方库和工具来进行训练和推理。在终端输入如下命令：

```
pip install ultralytics #安装 ultralytics 库即可
```

(3) 模型训练及格式转换

模型训练是深度学习开发过程中的核心步骤，通过训练让模型学习数据中的模式和规律，使其能够在新数据上进行预测或分类。将模型格式转换为 ONNX 的作用主要体现在模型的构建、优化、跨平台部署和性能提升等方面。采用命令行来实现这两种操作：

```
yolo task=detect mode=train model=yolov8n.pt args.. #目标检测模型的训练
```

```
yolo task=detect mode=export model= best.pt format=onnx #导出最优权重转换成 ONNX 格式
```

完成以上步骤之后，即得到了模型最优的权重文件，可用于下一步推理部署。

5.5.2 Vision Master 软件二次开发

海康 Vision Master 软件提供了模块生成工具来辅助用户进行自定义算法的嵌入，可以预生成大部分接口代码，通过该模块生成工具开发者能够将自己开发的算法封装成 VM 模块，增强了基于该软件的缺陷检测系统的灵活性与可扩展性，提高了开发效率。模块开发是主要涉及三个部分分别是：界面层、算法层、空间层，算法开发流程中对应的工程文件如图 5-6。





图 5-6 算法开发流程中对应的工程文件

(1) 三层构架文件生成

i 打开 VM 软件，选择自定义模块生成工具，输入模块名称，输出参数并导出（新建 VM 自定义项目文件夹）得到.iofml 格式文件，如图 5-7 所示。



5-7 自定义生成工具 xml 配置界面

ii 给定算法界面自定义运行参数（运行参数还有 int 参数名称：imgsize 取值范围：640-1280），依次生成三层构架文件，至此生成的三个构架文件如图 5-8 所示。



图 5-8 生成构架文件

(2) 界面层开发

界面层是系统的前端，用于定义用户与算法交互的界面元素和参数配置。通常是通过 XML 文件来描述界面布局和组件。下面介绍界面层开发的操作流程。

i 将生成的三层架构文件，分别使用 Visual Studio 软件编译，编译完成后点击界面层文件夹，会生成如图 5-9 文件。

 Det_Modes.dll	2024/7/13 15:52	应用程序扩展	357 KB
 Det_Modes.pdb	2024/7/13 15:52	VisualStudio.pd...	5,804 KB
 Det_Modes	2024/7/12 17:58	Microsoft Edge ...	6 KB
 Det_Modes_NormalLogo	2023/6/3 17:56	PNG 图片文件	1 KB
 Det_Modes_StateLogo	2023/6/3 17:56	PNG 图片文件	1 KB
 Det_ModesAlgorithm	2024/7/12 17:58	Microsoft Edge ...	1 KB
 Det_ModesAlgorithmTab	2024/7/12 17:58	Microsoft Edge ...	4 KB
 Det_ModesCs.dll	2024/7/12 18:01	应用程序扩展	4 KB
 Det_ModesCs.pdb	2024/7/12 18:01	VisualStudio.pd...	20 KB
 Det_ModesDisplay	2024/7/12 17:58	Microsoft Edge ...	3 KB
 Det_ModesImageEnable	2023/6/3 17:56	PNG 图片文件	2 KB
 onnxruntime.dll	2024/1/31 13:05	应用程序扩展	12,404 KB
 onnxruntime_providers_cuda.dll	2024/1/31 11:26	应用程序扩展	361,682 KB
 onnxruntime_providers_shared.dll	2024/1/31 13:01	应用程序扩展	23 KB
 onnxruntime_providers_tensorrt.dll	2024/1/31 13:02	应用程序扩展	695 KB
 ToolItemInfo	2024/7/12 17:58	Microsoft Edge ...	1 KB

图 5-9 编译后生成的文件

ii 将界面层文件夹拷贝至 VisionMaster4.3.0 文件根目录完成模块框架导入，最终效果如图 5-10 所示。



5-10 界面层最终效果

完成界面层的开发之后，能够通过拖拽将自定义模块框架导入 VM 方案流程中，但只是空壳无法实现具体功能，需要进一步修改算法层文件，完成具体功能的实现。

（3） 算法层开发

算法层是核心部分，通常使用 C++ 语言开发，负责实现检测算法的逻辑和功能。算法层执行与图像处理、数据分析和检测相关的核心操作。

i 参数定义与传输

界面层定义的参数以及算法层获取参数主要通过 `SetParam()` 函数以及 `GetParam()` 函数完成。

本文算法中主要有两个参数的设置，分别为图片尺寸“`imgsize`”参数和模型路径“`Model_path`”参数。

ii 联合 OpenCV 开发

海康 VM 软件中图片格式为 `HKA_IMAGE`，需转换成 OpenCV 使用的 `Mat` 格式，由 OpenCV-DNN 进行推理，再将推理出的结果转换成 `HKA_IMAGE` 格式，由海康 VM 软件进行显示。具体流程如图 5-11 所示。




图 5-11 算法处层理流程

iii 推理部分

将 HKA_IMAGE 格式图片转换成 Mat 格式后, 交给 inference.h 头文件和 inference.cpp 源文件处理, 获取 VM 自定义模块输出结果, 如 Class、Confidencve、X、Y、W、H 坐标等。具体的 inference 源文件内部前向推理得到最终结果的过程如图 5-12 所示。




图 5-12 模型推理过程

iv VM 输出结果

将图像转换成 Mat 格式并完成推理过程后, 得到缺陷检测结果, 最终通过 VM 软件的图形化界面显示。三叉轴图像经过前行推理后, 利用 OpenCV 绘制了预测框, 在 VM 界面中显示的代码为:

```
memcpy_s (inputimage.data[0], nLenSharedMem, output_image.data[0], nLenSharedMem);
```

结果输出的代码为:

```
VM_M_SetFloat(hOutput, "confidence", i, confidences[i]); // 这里输出的是置信度其格式为浮点数。
```

最终图像在 VM 界面中显示的效果如图 5-13 所示。输出结果如图 5-14 所示。




图 5-13 VM 界面中推理得到的图像

参数名称	当前结果	全局变量
▼ Det_Model1		
confidence	0.8655906,0.7445869	
ClassID	0,1	
ClassNmae	querou,keping	
X	690,956	
Y	339,440	
W	37,13	
H	42,27	
模块状态	1	
▼ 输出图像		
输出图像数据		
输出图像宽度	1440	
输出图像高度	1080	
输出图像像素格式	35127316	

图 5-14 VM 自定义模块结果

5.5.3 Vision Master 软件整体流程

本文采用 VM 软件配合传统算法以及改进的 TS-YOLO 算法实现了三叉轴表面的缺陷检测任务，该方案可作为一种通用的表面缺陷检测方案，其具有可扩展性高、灵活、开发难度低的特点，整体实施流程包括：VM 软件与 PLC 通信控制设备运行、相机采集图像、算法推理、返回推理结果、PLC 接收结果信号完成工件的分拣。该方案整体的实施流程如图 5-15 中所示。




图 5-15 三叉轴表面缺陷检测自动检测方案整体流程图

在图 12 中，PLC 给上位机 VM 软件发送 R111 请求采图信号。上位机发送判断是否处于空闲状态的 R112 信号给 PLC，若空闲状态则 PLC 控制相机开始拍摄。R121-R129 信号为 PLC 发送给 VM 软件拍摄的信号。图像采集完成直接交给 VM 软件中 TS-YOLO 算法处理，并在上位机中统计最终结果，处理完 VM 发送 R131 等待再次触发，R113 信号为最终结果好坏料信号由 VM 发出给 PLC，由 PLC 控制机器完成三叉轴好料和坏料的分拣。

(1) 深度学习算法流程

相机 1-4 主要拍摄位置为轴颈部分，由于缺陷较为复杂，故采用深度学习算法进行缺陷检测，具体模块处理流程如图 5-16 所示。

该流程主要功能是将相机拍摄完成后的图片交给 VM 软件进行缺陷检测，并通过设置全局变量：“筛选后真实缺陷个数”，以及组合模块来对算法输出的结果进行进一步处理，提高检测设备的可靠性，最终将 OK、NG 结果发送给 PLC。

流程第一步先将全局变量“筛选后真实缺陷个数”置零；第二步，将相机拍摄到的图像交由上文自定义开发的 DetectModu 模块处理，得到检测缺陷的个数、置信度、类别、长、宽、中心点坐标信息；第三步，组合模块获取缺陷个数，开启循环使能，在循环中比对缺陷长宽以及置信度，若长、宽、置信度都

达到了缺陷标准则筛选后真实缺陷个数随之增加；最终用筛选后的缺陷个数判断工件是否合格，并通过条件分支模块实现 OK、NG 数据的发送。




图 5-16 深度学习算法处理流程图

（2）传统图像处理算法流程

相机 5 拍摄的图片为三叉轴的端面部分，由于端面部分缺陷为外圆缺口及端面表面上较为明显的异常，缺陷外观单一且识别难度较小，故采用传统图像处理方法，具体流程如图 5-17 所示。

首先对相机 5 采集到的图片进行圆查找，定位端面的具体位置；然后分两个支路分别检测外圆缺口以及表面异常，圆弧边缘缺陷检测用于检测外圆缺口，表面异常部分首先使用图像二值化区分异常区域与背景，再通过 Blob 分析确定表面异常缺陷的位置。图 5-18（a）（b）（c）分别展示了传统算法的检测效果。

通过 Vision Master 软件实现了深度学习算法与传统图像处理方法的结合使用，发挥了其各自的优点，深度学习能准确识别较为复杂的缺陷场景，但是占用硬件资源较多、速度慢，而传统图像算法只能够识别简单的缺陷，但是占用硬件资源少、速度快且不需要专门收集数据集进行训练，该部署方法能够扬长避短，更加灵活。




图 5-17 传统图像算法处理流程图




图 5-18 传统算法各模块效果

5.5.4 Vision Master 软件界面开发

VM 软件的界面能够实时显示每个相机采集的工件图像，其中三叉轴上的 4 个相机分别负责前后两个部位的图像采集，而第 5 个相机则用于获取工件的端面图像，共计 9 张图像。界面还包括工件的二维图像展示、缺陷检测结果的回看功能以及运行控制按钮，便于用户操作。

通过 VM 软件，用户不仅可以直观地查看各个模块的运行结果，还能清晰地标注和识别检测到的缺陷区域。此外，软件还能生成相应的统计数据，如缺陷数量、类型和位置。

与其他界面开发工具相比，VM 软件的开发过程更加直观、便捷，提供了集成的功能模块和易于使用的开发环境，大幅提升了开发效率和系统的实用性。本文设计的界面如图 5-19 所示。




图 5-19 VM 软件界面

5.6 本章小结

- 本章完成了改进的 TS-YOLO 算法在实际生产中的部署工作。
- (1) 针对三叉轴表面缺陷检测的需求进行了详细的分析，明确了检测的关键技术要求和性能指标；
 - (2) 从硬件选型入手，选择了适合该任务的相机、处理器等设备，为后续

部署奠定了坚实的基础；

（3）通过 Vision Master 软件的自定义深度学习模块，将改进的 TS-YOLO 算法成功以及传统图像算法集成并部署到检测系统中。该方案不仅有效完成了三叉轴表面缺陷的检测任务，还具备较强的通用性，能够应用于其他类型的表面缺陷检测场景。

第6章 总结与展望

6.1 总结

本文基于工业生产中的实际需求,围绕三叉轴表面缺陷检测展开研究。三叉轴是工业生产中重要的机械部件,其表面质量直接影响整机的使用性能和寿命。然而,由于三叉轴表面结构复杂、缺陷种类多样且尺寸不一,传统的人工检测方式效率低下且精度有限,难以满足现代工业对高效、精准质量检测的需求。随着深度学习技术的快速发展,基于深度学习的表面缺陷检测方法逐渐在工业领域得到应用,但在实际应用中仍面临诸多挑战,如缺陷图像数据难以获取、算法复杂度高、部署难度大等问题。针对这些问题提出了基于 TS-YOLO 算法的三叉轴表面缺陷检测方法,改进目标检测中常见的准确率低、模型复杂度高的问题。文章主要的工作包括:

(1) 结合工厂实际生产中收集的三叉轴缺陷图片,本文使用 LabelImg 软件对表面缺陷进行了精确标注,制作了一个完整的三叉轴表面缺陷数据集。该数据集包含了多种常见的表面缺陷类型,如磕碰、凹坑、锈斑等,为后续的模型训练和验证提供了可靠的数据支持。详细介绍了 YOLOv8 算法的网络结构,并在本文制作的三叉轴表面缺陷数据集中做了实验,实验结果表明,YOLOv8 算法在三叉轴缺陷数据集上的平均精度 (mAP) 达到了 79.1%。

(2) 提出了新型的 TS-YOLO 算法,在主干网络加入 ScConv 卷积,加强空间特征的提取能力,并减少通道空间的冗余特征;在特征融合部分引入 VoV-GSCSP 模块,降低了模型的复杂度;在损失函数方面引入了 Inner_Shape-IoU,提高了算法对小目标的检测能力。该方法在提升检测精度的同时有效减少了计算量,实现了检测精度与模型复杂度的良好平衡。结果显示改进后的 TS-YOLO 算法参数量减少,并在三叉轴表面缺陷数据集上 mAP 达到 84.8%,相较于改进前的 79.1%提升了 5.7%。

(3) 最后,本文在海康 Vision Master 软件平台上成功实现了传统算法结合 TS-YOLO 算法的部署,针对工业场景中的三叉轴表面缺陷检测需求,设计了一套高效的自动化检测方案。结果显示,相较于海康原有模型,该算法在检测速度和精度上都有显著提升,证明了其在实际工业场景中的实用性。

6.2 展望

未来的研究和应用可以围绕以下几个方面展开,以进一步提升三叉轴表面缺陷检测的性能与应用广度。

(1) 为解决缺陷数据难以采集的问题,未来可以探索基于生成对抗网络(GAN)或其他生成模型的方法,智能生成高质量的缺陷图像数据。这不仅可以减少对实际工厂生产数据的依赖,还能有效扩展数据多样性,提升算法在处理不同缺陷类型和工况下的表现。

(2) 尽管 TS-YOLO 在精度和速度上取得了良好平衡,但对于更复杂的工业场景,进一步优化模型结构和减少计算开销仍然是重要的研究方向。未来可探索更多适合工业应用的轻量化模型设计,通过剪枝、量化和知识蒸馏等技术,进一步降低模型的计算复杂度和硬件资源占用,使其更易于部署在边缘设备和嵌入式系统中。

参 考 文 献

- [1] 中阳刘. 机械设计制造及自动化发展方向研究[J]. 工程技术与管理, 2024, 8(6): 66-68.
- [2] 张大卫, 周长其, 周晓波, 等. 机械自动化在汽车制造中的优势与发展[J]. 工程管理与技术探讨, 2024, 6(7): 250-252.
- [3] 金映谷, 张涛, 杨亚宁, 等. 基于深度学习的产品缺陷检测方法综述 [J]. 大连民族大学学报, 2020, 22 (5): 420-427.
- [4] 伍麟, 郝鸿宇, 宋友. 基于计算机视觉的工业金属表面 缺陷检测综述[J/OL]. 自动化学报, 2024, 22 (4): 1-24.
- [5] Reddy M J B , B, K C , Mohanta D K .Condition monitoring of 11 k V distribution system insulators incorporating complex imagery using combined DOST-SVM approach[J]. IEEE Transactions on Dielectrics & Electrical Insulation, 2013, 20(2):664-674.
- [6] Oberweger M, Wendel A, Bischof H. Visual recognition and fault detection for power line insulators[J]//Proc. 19th Comput. Vis. Winter Workshop. 2014: 1-8.
- [7] Chaou A K, Mekhaldi A, Teguar M . Elaboration of novel image processing algorithm for arcing discharges recognition on HV polluted insulator model[J]. IEEE Transactions on Dielectrics and Electrical Insulation, 2015, 22(2):990-999.
- [8] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: Unified, Real-time object detection[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 779-788.
- [9] REDMON J, FARHADI A. YOLO9000: better, faster, stronger[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 7263-7271.
- [10] Farhadi A, Redmon J. Yolov3: An incremental improvement[C]//Computer vision and pattern recognition. Berlin/Heidelberg, Germany: Springer, 2018, 1804: 1-6.
- [11] Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.
- [12] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: Trainable bag-of-

- freebies sets new state-of-the-art for real-time object detectors[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 7464-7475.
- [13] LIU W, ANGUELOV D, ERHAN D, et al. Ssd: Single shot multibox detector[C]//Computer Vision - ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11 - 14, 2016, Proceedings, Part I 14. Springer International Publishing, 2016: 21-37.
- [14] HE K, GKIOXARI G, DOLLÁR P, et al. Mask r-cnn[C]// Proceedings of The IEEE International Conference on Computer Vision. 2017: 2961-2969.
- [15] GIRSHICK R. Fast r-cnn[C]//Proceedings of the IEEE International Conference on Computer Vision. 2015: 1440-1448.
- [16] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(6): 1137-1149.
- [17] Xie S, Girshick R, Dollár P, et al. Aggregated residual transformations for deep neural networks[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Honolulu, USA, 2017: 1492-1500.
- [18] Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. ArXiv Preprint ArXiv:1704.04861, 2017: 1-9.
- [19] Zhang X, Zhou X, Lin M, et al. Shufflenet: An extremely efficient convolutional neural network for mobile devices[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City, USA, 2018: 6848-6856.
- [20] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City, USA, 2018: 4510-4520.
- [21] Howard A, Sandler M, Chu G. Searching for mobilenetv3[C]// Proceedings of the IEEE/CVF international conference on computer vision. 2019: 1314-1324.

- [22] 吴涛,王伟斌,于力等.轻量级 YOLOV3 的绝缘子缺陷检测方法[J].计算机工程,2019,45(8):275-280.
- [23] 贾晓芬,吴雪茹,赵佰亭.绝缘子自爆缺陷的轻量化检测网络 DE-YOLO[J/OL].电子测量与仪器学报:1-8[2023-04-16]
- [24] 王道累,张世恒,袁斌霞,赵文彬,朱瑞.基于改进 YOLOv5 的轻量化玻璃绝缘子自爆缺陷检测研究[J/OL].高电压技术:1-9[2023-04-17].
- [25] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers[C]// European Conference on Computer Vision. Cham: Springer International Publishing, 2020: 213-229.
- [26] ZHAO Y, CHEN B, LIU B, ET AL. GRP-YOLOv5: An improved bearing defect detection algorithm based on YOLOv5[J]. Sensors, 2023, 23(17): 7437.
- [27] 唐善成, 陈明, 王瀚博, 等. 采用变分自编码器的无监督压敏电阻表面缺陷检测[J]. 计算机集成制造系统, 2022, 28(5): 1337-1351.
- [28] 崔克彬, 焦静颐. 基于 MCB-FAH-YOLOv8 的钢材表面缺陷检测算法[J]. 图学学报, 2024, 45(1): 112.
- [29] CHEN W, HUANG Z, MU Q, ET AL. PCB defect detection method based on transformer-YOLO[J]. IEEE Access, 2022, 10: 129480-129489.
- [30] 侯玥, 王开宇, 金顺福. 一种基于 YOLOv5 的小样本目标检测模型[J]. 燕山大学学报, 2023, 47(1): 64-72.
- [31] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [32] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [33] Szegedy C, Liu W, Jia Y Q, et al. Going deeper with convolutions[C].Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 1-9.
- [34] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition , 2017: 4700-4708.
- [35] He K M, Zhang X Y, Ren S Q, et al. Deep residual learning for image

- recognition[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778.
- [36] Lin M. Network in network[J]. arXiv preprint arXiv:1312.4400, 2013.
- [37] Yu D, Wang H, Chen P, et al. Mixed pooling for convolutional neural networks[C]//Rough Sets and Knowledge Technology: 9th International Conference, RSKT 2014, Shanghai, China, October 24-26, 2014, Proceedings 9. Springer International Publishing, 2014: 364-375.
- [38] Basha S H S, Dubey S R, Pulabaigari V, et al. Impact of fully connected layers on performance of convolutional neural networks for image classification[J]. Neurocomputing, 2020, 378: 112-119.
- [39] Gao S H, Cheng M M, Zhao K, et al. Res2net: A new multi-scale backbone architecture[J]. IEEE transactions on pattern analysis and machine intelligence, 2019, 43(2): 652-662.
- [40] Tan M, Le Q. Efficientnet: Rethinking model scaling for convolutional neural networks[C]//International conference on machine learning. PMLR, 2019: 6105-6114.
- [41] LIN T Y, DOLLÁR P, GIRSHICK R, et al. Feature pyramid networks for object detection[C]//Proceedings Of The IEEE Conference on Computer Vision and Pattern Recognition. 2017: 2117-2125.
- [42] Liu W, Lu H, Fu H, et al. Learning to upsample by learning to sample[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 6027-6037.
- [43] 张焕, 张庆, 于纪言. 激活函数的发展综述及其性质分析[J]. 西华大学学报(自然科学版), 2021, 40(4): 1-10.
- [44] Banerjee C, Mukherjee T, Pasiliao Jr E. An empirical study on generalizations of the ReLU activation function[C]//Proceedings of the 2019 ACM Southeast Conference. 2019: 164-167.
- [45] Zhang C, Woodland P C. Parameterised sigmoid and ReLU hidden activation functions for DNN acoustic modelling[C]//Sixteenth annual conference of the international speech communication association. 2015.

- [46] Li X, Hu Z, Huang X. Combine relu with tanh[C]//2020 IEEE 4th Information Technology, Networking, Electronic and Automation Control Conference (ITNEC). IEEE, 2020, 1: 51-55.
- [47] Mao A, Mohri M, Zhong Y. Cross-entropy loss functions: Theoretical analysis and applications[C]//International conference on Machine learning. PMLR, 2023: 23803-23828.
- [48] Rodríguez P, Bautista M A, Gonzalez J, et al. Beyond one-hot encoding: Lower dimensional target embedding[J]. Image and Vision Computing, 2018, 75: 21-31.
- [49] Ruby U, Yendapalli V. Binary cross entropy with deep learning technique for image classification[J]. Int. J. Adv. Trends Comput. Sci. Eng, 2020, 9(10).
- [50] Das K, Jiang J, Rao J N K. Mean squared error of empirical predictor[J]. 2004.
- [51] Zhou D, Fang J, Song X, et al. Iou loss for 2d/3d object detection[C]//2019 international conference on 3D vision (3DV). IEEE, 2019: 85-94.
- [52] Verma S, Verma O P, Gupta H, et al. Performance Analysis of GIoU Loss Function for Object Tracking[C]//International Conference on Soft Computing: Theories and Applications. Singapore: Springer Nature Singapore, 2023: 465-472.
- [53] Zheng Z, Wang P, Liu W, et al. Distance-IoU loss: Faster and better learning for bounding box regression[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(07): 12993-13000.
- [54] TONG Z, CHEN Y, XU Z, et al. Wise-IoU: bounding box regression loss with dynamic focusing mechanism[J]. arXiv preprint arXiv:2301.10051, 2023.
- [55] Olah C. Calculus on computational graphs: Backpropagation[J]. 2015.
- [56] Kingma D P. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.
- [57] 李红儿, 叶建锋. 差速器十字轴成形工艺研究与应用[J]. 汽车制造业, 2021, (06): 49-50.
- [58] LI J, WEN Y, HE L. Scconv: spatial and channel reconstruction convolution for feature redundancy[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 6153-6162.
- [59] ZHENG Z, WANG P, REN D, et al. Enhancing geometric factors in model learning

- and inference for object detection and instance segmentation[J]. IEEE Transactions on Cybernetics, 2021, 52(8): 8574-8586.
- [60] LI H, LI J, WEI H, et al. Slim-neck by GSConv: A better design paradigm of detector architectures for autonomy-ous vehicles[J]. arXiv preprint arXiv: 2206.02424, 2022.
- [61] ZHANG H, ZHANG S. Shape-IoU: More Accurate Metric considering Bounding Box Shape and Scale[J]. arXiv preprint arXiv:2312.17663, 2023.
- [62] ZHANG H, XU C, ZHANG S. INNER-IOU: MORE EFFECTIVE INTERSECTION OVER UNION LOSS WITH AUXILIARY BOUNDING BOX[J]. ARXIV PREPRINT ARXIV:2311.02877, 2023.