

分类号: TP391.4

单位代码: 10335

密 级: 非涉密论文

学 号: 11725006

浙江大学

硕士学位论文



中文论文题目: 基于 YOLO-Bush 模型的轴瓦
表面缺陷检测技术研究

英文论文题目: Research on bearing bush surface defect
detection based on YOLO-Bush model

申请人姓名: 綦荣新

指导教师: 李凌丰

合作导师: _____

专业名称: 机械制造及其自动化

研究方向: 机器视觉缺陷检测

所在学院: 机械工程学院

论文提交日期 2021 年 7 月 9 日

基于 YOLO-Bush 模型的轴瓦表面缺陷检测技术研究



论文作者签名:_____

指导教师签名:_____

论文评阅人 1: _____ 隐名

评阅人 2: _____ 隐名

评阅人 3: _____ 隐名

评阅人 4: _____

评阅人 5: _____

答辩委员会主席: _____ 张树有 教授

委员 1: _____ 纪杨建 教授

委员 2: _____ 汪延成 教授

委员 3: _____ 董辉跃 研究员

委员 4: _____ 李兴林 高级工程师

委员 5: _____

答辩日期: _____ 2021 年 9 月 13 日

Research on bearing bush surface defect detection
based on YOLO-Bush model



Author's signature: _____

Supervisor's signature: _____

Thesis reviewer 1: _____ Anonymous _____

Thesis reviewer 2: _____ Anonymous _____

Thesis reviewer 3: _____ Anonymous _____

Thesis reviewer 4: _____ _____

Thesis reviewer 5: _____ _____

Chair: Prof.ZHANG Shuyou(Zhejiang Univ.)
(Committee of oral defence)

Committeeman 1: Prof.JI Yangjian(Zhejiang Univ.)

Committeeman 2: Prof.WANG Yancheng(Zhejiang Univ.)

Committeeman 3: Prof.DONG Huiyue(Zhejiang Univ.)

Committeeman 4: SN ENGR.LI Xinglin(HBRC Co.,LTD)

Committeeman 5: _____

Date of oral defence: 2021.9.13

摘要

轴瓦作为一种广泛应用于各类旋转机械的零件，在多种领域发挥着重要作用，然而带有表面缺陷的轴瓦会严重降低产品的质量，造成不必要的经济损失，因此在生产过程中对于轴瓦表面缺陷进行检测是十分必要的。目前轴瓦表面缺陷检测仍然以人工目视检测为主，检测效率低、漏检率高，而基于数字图像处理的传统机器视觉方法需要人工设计提取特征，难以用于检测形态复杂多变的轴瓦表面缺陷。本文基于深度学习算法中的卷积神经网络和目标检测模型，提出了一种轴瓦表面缺陷检测模型 YOLO-Bush，该模型具有检测精度高、速度快的特点，实现了轴瓦表面缺陷的高效精确检测。论文研究内容主要包括以下四个方面：

首先，针对轴瓦表面各类缺陷的特点，设计了基于目标检测模型的轴瓦表面缺陷检测方案，并搭建了实验平台。通过实验平台采集了轴瓦图像并完成数据标注，据此提出一种轴瓦表面缺陷数据集。该数据集可用于目标检测模型的训练与检测性能评价，极大程度地扩充了轴瓦表面缺陷检测领域的的数据规模。

其次，针对工业现场缺陷轴瓦较少，数据集规模相对不足的问题，提出了一种混合样本在线数据增强方法，以弥补数据集规模的不足，并进一步探究了数据集扩充规模与缺陷检测精度之间的关系。同时，引入了基于深度迁移学习的目标检测模型训练过程改进方法。通过大型数据集对模型进行预训练，并将模型所学知识迁移至轴瓦表面缺陷检测问题中，实现了图像低层特征的迁移，从而确保模型在数据集规模较小的情况下具有良好的训练效果。

再次，提出了一种针对轴瓦表面缺陷的高效检测模型 YOLO-Bush。该模型通过深浅层特征融合、通道特征增强、多尺度特征融合、局部与全局特征融合等特征提取方法，以及动态调整轴瓦表面缺陷数据集中难易样本权重的方法，实现了轴瓦表面各类缺陷的精确识别。同时，该模型通过距离交并比损失函数计算预测框与真实框之间的误差，实现了轴瓦表面缺陷的精确定位。

最后，基于轴瓦表面缺陷检测总体方案，开发了一款具有图形交互界面的轴

瓦表面缺陷检测软件，其可以对生产环境中的轴瓦表面缺陷进行检测。该软件可以在检测过程中积累缺陷样本，从而可对 YOLO-Bush 模型进行二次训练并实现校准，确保了模型在不断迭代的过程中对于轴瓦表面缺陷的检测性能得以进一步提升。

本文提出的 YOLO-Bush 模型克服了轴瓦表面反光及其大曲率外形对于表面缺陷检测的干扰，提高了现有深度学习目标检测模型的检测精度和鲁棒性，可满足工业现场对于轴瓦表面缺陷检测精度与检测效率的要求。

关键词：轴瓦缺陷检测，深度学习，卷积神经网络，特征融合，YOLO-Bush 模型

Abstract

As a kind of machinery part, bearing bush is widely used in various types of rotating machinery and plays an important role in many fields. However, bearing bush with surface defects will seriously decrease the quality of the product and cause unnecessary economic losses. Therefore, it is of great importance to detect the surface defects of the bearing bush. At present, the detection of bearing bush surface defects is still based on manual visual inspection, which causes low detection efficiency and high rate of missed detection. Traditional machine vision methods based on image processing require manual extraction of features, which are not suitable for detecting complex and changeable bearing bush surface defects. Based on the convolutional neural network and the target detection model in the deep learning algorithm, this paper proposes a bearing bush surface defect detection model YOLO-Bush, which has the characteristics of high detection accuracy and detection speed, and realizes the efficient and accurate detection results of bearing bush surface defects. The research content of the thesis mainly includes the following four aspects:

First of all, according to the characteristics of various defects on the bearing bush surface, a detection plan for bearing bush surface defects based on the target detection model is designed, and an experimental platform is built. Through the experimental platform, the bearing bush image is collected and the data is marked. Based on bearing bushes' image and data, a data set of bearing surface defects is proposed. This data set can be used for the training of the target detection model and the evaluation of detection performance, which greatly expands the data scale in the field of bearing surface defect detection.

Secondly, in view of the problem that there are fewer defective bearing bush in the industrial field and the relatively insufficient data set size, a hybrid sample online data enhancement method is proposed to make up for the lack of data set size, and the relationship between the data set expansion scale and defect detection accuracy is explored. relationship. At the same time, a method to improve the training process of target detection model based on deep transfer learning is proposed. The model is pre-

trained through a large data set, and the knowledge of the model is transferred to the bearing bush surface defect detection problem, which realizes the migration of low-level features of the image, thereby ensuring that the model has a good training effect in the case of a small data set.

Thirdly, a high-efficiency detection model YOLO-Bush for bearing bush surface defects is proposed. The model uses deep and shallow layer feature fusion, channel feature enhancement, multi-scale feature fusion, local and global feature fusion, and other feature extraction methods. Meanwhile, YOLO-Bush uses the method of focal loss to dynamically adjust the weight of the difficult and easy samples in the bearing bush surface defect data set, and realizes the accurate detection of various defects on the bearing bush surface. At the same time, the model calculates the loss between the predicted bounding box and the ground truth box through the distance intersection over union loss function, and realizes the accurate positioning of the bearing bush surface defects.

Finally, based on the plan of bearing bush surface defect detection, a bearing bush surface defect detection software with a graphical interactive interface was developed, which can detect the surface defects of the bearing bush in the production environment. The software can accumulate defect samples during the inspection process, so that the YOLO-Bush model can be re-trained and calibrated, ensuring that the model's detection performance for bearing bush surface defects can be further improved in the process of iteration.

The YOLO-Bush model proposed in this paper overcomes the interference of the bearing bush surface defects detection, which caused by surface reflection and the large curvature shape of the bush. At the same time, the model improves the detection accuracy and robustness of the existing deep learning target detection model, and can meet the requirements for efficiency and detection accuracy of bearing bush surface defects detection in industrial field.

Key Words: Bearing bush defect detection, deep learning, convolutional neural network, feature fusion, YOLO-Bush model

目 录

第 1 章 绪论.....	1
1.1 论文研究背景与意义.....	1
1.2 机器视觉表面缺陷检测研究现状	3
1.2.1 基于数字图像处理的表面缺陷检测方法	3
1.2.2 基于深度学习的表面缺陷检测方法.....	6
1.3 论文研究内容与架构.....	9
1.4 本章小结.....	12
第 2 章 轴瓦表面缺陷检测方案设计	13
2.1 引言.....	13
2.2 轴瓦制造工艺流程与整体检测方案	13
2.2.1 轴瓦制造工艺流程.....	13
2.2.2 轴瓦表面缺陷分析及检测目标.....	14
2.2.3 轴瓦表面缺陷检测整体流程.....	15
2.2.4 轴瓦表面缺陷检测实验平台搭建.....	16
2.3 轴瓦表面缺陷数据集构建	18
2.4 轴瓦表面缺陷检测模型选择	21
2.4.1 基于区域生成的目标检测模型.....	21
2.4.2 基于回归的目标检测模型.....	24
2.5 目标检测模型评价指标.....	25
2.6 本章小结.....	27
第 3 章 轴瓦表面缺陷数据增强策略研究	28
3.1 引言.....	28
3.2 轴瓦表面缺陷检测模型实验参数设置	28
3.3 轴瓦表面缺陷数据集基准性能测试	30
3.4 基于数据增广的缺陷检测性能改进	33
3.4.1 轴瓦表面缺陷数据集单样本及混合样本在线数据增强	34
3.4.2 数据集扩充规模与缺陷检测性能消融实验	37
3.5 基于深度迁移学习的缺陷检测性能改进	40
3.5.1 深度迁移学习及模型微调.....	40
3.5.2 深度迁移学习改进缺陷检测性能结果分析	42
3.6 本章小结.....	47
第 4 章 YOLO-Bush 模型结构与损失函数研究.....	48
4.1 引言.....	48
4.2 YOLOv3 模型结构及检测原理	48

4.2.1 模型基本结构.....	48
4.2.2 边界框预测原理.....	50
4.2.3 损失函数.....	52
4.3 基于 YOLOv3 的多特征融合与通道特征增强模型	53
4.3.1 基于 Dense Net 稠密块的深浅层特征融合	53
4.3.2 基于 SE 注意力机制模块的通道特征增强.....	56
4.3.3 基于 FPN 的多尺度预测结构改进	59
4.3.4 基于 SPP 的全局特征与局部特征融合	60
4.4 基于 K-means++ 聚类算法的锚框优化	62
4.5 基于 DIoU Loss 与 Focal Loss 的损失函数优化	65
4.5.1 基于 DIoU Loss 的坐标预测损失函数优化.....	65
4.5.2 基于 Focal Loss 的置信度与分类损失函数优化	68
4.6 YOLOv3 改进模型实验结果及分析	70
4.6.1 YOLOv3 模型改进方法消融实验结果对比	70
4.6.2 YOLO-Bush 模型轴瓦表面缺陷检测综合实验	74
4.7 本章小结.....	78
第 5 章 轴瓦表面缺陷检测软件设计与实验验证	79
5.1 引言.....	79
5.2 软件模块设计.....	79
5.3 软件主要模块实现.....	81
5.4 YOLO-Bush 检测性能对比实验	83
5.5 本章小结.....	88
第 6 章 总结与展望	89
6.1 工作总结.....	89
6.2 工作展望.....	90
参考文献.....	91

第1章 绪论

1.1 论文研究背景与意义

随着《中国制造 2025》纲领的提出，我国正式进入从制造大国到制造强国的转型阶段，传统的粗放式工业发展模式已不能适应未来中国制造业的发展趋势，其中一个突出问题是产品质量问题^[1]。有数据表明，国家监督抽查产品质量不合格率高达 10%，制造业每年因产品质量问题造成的直接经济损失超过 2000 亿元^[2]。尽管我国制造业具备强大的产业基础，但在制造产品的过程中，缺陷的产生往往是不可避免的。表面缺陷是各类产品缺陷中比较典型的一种，表面缺陷不仅影响产品的美观性，而且也会对产品的使用性能造成不良影响^[3]。传统表面缺陷检测方法通常为人工检测，具有抽检率低、实时性差、准确性不高、劳动强度大等缺点，而机器视觉表面缺陷检测方法可以有效克服上述弊端，因此开展基于机器视觉的表面缺陷检测技术研究对于实现智能化、自动化制造具有重要的意义。

轴瓦是滑动轴承结构中 与轴颈相接触的部分，其 在内燃机、空压机、汽轮机、电机、水泵等各类旋转机械上有着广泛的应用，在我国的工业、农业、交通、国防等各个领域发挥着重要作用^[4]。作为滑动轴承中的滑动部件，轴瓦在各类机械中主要起到减少摩擦的作用，其外形为半圆环状，内表面光滑，通常使用青铜或减摩合金等耐磨材料制成。由于轴瓦工作时往往需要承受较大的动载荷以及高温的影响，表面带有缺陷的轴瓦可能会在工作过程中产生烧熔、变形、断裂等损坏，因此轴瓦的质量直接决定了相关机械设备的工作性能和稳定性。图 1.1 所示为轴瓦实物图。



图 1.1 轴瓦实物图

轴瓦的制造过程为大批量流水线生产，对检测效率有着较高的要求。根据现行国家标准 GB/T 7308-2008《滑动轴承：有法兰或无法兰薄壁轴瓦公差、结构要素和检验方法》^[5]中的规定，轴瓦的表面缺陷检测应采用目测法及表面轮廓测量、磁粉探伤^[6]、超声波探伤^[7]等物理方法。然而，上述方法需要借助于轮廓仪、磁粉探伤仪、超声波探伤仪等检测设备通过人工抽检的方式实现检测，检测效率较低，对人员的工作状态要求较高，检测成本较高，且难以完成百分百全检，容易发生漏检现象。相反，基于机器视觉的缺陷检测系统具有智能化程度高、无接触、无损伤、检测速度快、准确率高等优点。随着工业相机性能的提升、光源技术的进步，以及计算机处理能力的不断提升，机器视觉检测相关理论与算法得以蓬勃发展，在智能化制造领域的应用日益广泛^[8]。

机器视觉检测系统是一种借助于光学装置和非接触式传感器获得检测目标的图像，并通过计算机从图像中提取特征信息，进行分析处理，然后根据特征信息进行定位、识别、分级等操作，进而实现检测控制的装置。典型的工业机器视觉检测系统由工业相机、光学镜头、照明光源、上位机、执行机构等部分组成^[9]，如图 1.2 所示。




图 1.2 工业机器视觉检测系统示意图

当检测目标在传送带上运动至工业相机视场范围内时会触发电光传感器，随后上位机对工业相机发出图像采集信号，通过光学镜头将光线汇聚至工业相机感

光元件上，从而获取检测目标的图像。为了获取质量更高的图像，通常需要在检测目标附近布置照明光源。图像采集完成后，会通过千兆以太网等传输方式被传输至上位机。随后，上位机通过执行相应的图像处理程序对采集到的图像进行相关处理，并从中提取所需信息。最终，上位机根据程序处理的结果，将执行指令发送至执行机构，并完成相应的筛选、分类等操作。

基于以上背景，本文依托于浙江某轴瓦制造厂商所委托的项目“基于机器视觉的轴瓦自动化检测系统”，开展了基于机器视觉的轴瓦表面缺陷检测技术的研究，将机器视觉检测技术应用于轴瓦零件生产线的在线检测，以提高轴瓦表面缺陷的检测效率与检测精度，降低漏检风险，从而提高轴瓦产品的合格率，节约企业的人工成本。

1.2 机器视觉表面缺陷检测研究现状

机器视觉表面缺陷检测技术的核心是通过提取缺陷特征来判断给定图像中缺陷目标出现的位置及其类别。根据缺陷特征提取过程的不同，可以将机器视觉表面缺陷检测技术分为两类，分别为基于数字图像处理的表面缺陷检测和基于深度学习的表面缺陷检测，国内外已有众多学者对此开展了广泛的研究。

1.2.1 基于数字图像处理的表面缺陷检测方法

基于数字图像处理的表面缺陷检测方法通常分为如下步骤：首先对图像进行预处理，选取可能包含缺陷的候选区域；然后针对不同种类的缺陷人工设计特征提取方法，例如阈值分割、边缘检测、纹理特征提取、数学形态学操作等；再制定相应规则将提取到的特征输入到支持向量机^[10]（Support Vector Machine, SVM）、自适应提升算法^[11]（Adaptive Boosting, AdaBoost）等分类器中进行分类；最后得到表面缺陷的检测结果。上述步骤中最关键的环节是选取合适的特征提取算法，目前比较成熟的特征提取算法有 Canny^[12]、Gabor^[13]、Otsu^[14]、尺度不变特征变换^[15]（Scale Invariant Feature Transform, SIFT）、局部二值模式^[16]（Local Binary Patterns, LBP）、方向梯度直方图^[17]（Histogram of Gradient, HOG）等。

早在 2002 年，Mandriota 等^[18]就采用 Gabor 滤波器、小波变换以及 Gabor 小

波变换开展了钢轨表面缺陷检测的研究,实验结果表明,Gabor 滤波器具有方向敏感性,对于波纹缺陷具有良好的检测效果。Jeon 等^[19]首先通过 Gabor 滤波器削弱光照条件对板坯图像的干扰并进行边缘检测,然后结合直方图和梯度纹理特征生成特征向量,最后通过 SVM 实现了板坯划痕缺陷检测。Deotale 等^[20]提出了一种基于灰度共生矩阵、Gabor 小波变换及随机决策森林^[21] (Random Decision Forest, RDF)的织物表面缺陷检测算法,通过提取纹理特征,实现织物图像重构,并利用 RDF 实现缺陷分类。

Ng 等^[22]提出了一种谷值强调阈值分割算法,通过选取出现概率较小的阈值并最大化灰度直方图类间方差,解决了 Otsu 算法在直方图为单峰或接近单峰时存在的分割失败问题,该算法对于检测金属板表面划痕具有良好的效果。Senthikumar 等^[23]提出了一种基于迭代阈值的金属表面缺陷检测算法,实现了金属表面缺陷的高效实时检测。Truong 等^[24]提出了一种基于 Otsu 算法改进的自动阈值技术,通过熵加权方法,实现了微小缺陷的检测。Yuan 等^[25]在 Otsu 算法的基础上进行改进,通过对类间方差进行加权,得到缺陷出现的累积概率,确保了阈值始终是一个位于双峰之间的谷值或单峰直方图的左下边缘的值。

Wakaf 等^[26]提出了一种自动检测缺陷阈值的方法,该方法通过将基于像素强度值平均值的掩模与图像本身的锐化副本进行比较,有效地分离了缺陷区域直方图,进而能够从背景中同时检测出小缺陷及大缺陷。Cao 等^[27]提出了一种混合表面缺陷检测方法。将图像分成具有相似特征的背景和特殊图案区域。对于背景区域使用梯度阈值分割方法进行缺陷检测,对于特殊图案区域,采用图像配准和图像差分的方法进行缺陷检测,以适应形状和外观不连续的不规则图像内容。

Zhou 等^[28]首先使用改进的二维经验模态分解提取算法过滤掉金属表面上的复杂纹理,然后利用 Canny 边缘检测算子来检测缺陷边缘,最终通过连接边缘断点和图像填充操作来获取缺陷边缘。Kunakornvong 等^[29]研究了一种硬盘万向节空气轴承表面缺陷检测系统,利用图像分割生成块状矩阵来检测缺陷,同时采用了子块和子感兴趣区域,以确定并行处理体系结构中的缺陷。

Liu 等^[30]提出了一种基于梯度局部二值模式的表面缺陷检测方法,该方法采

用邻域内八个方向的加权二进制输出值来表示局部灰度变化,抑制了光照和噪声对检测结果的影响,为表面缺陷检测提供了良好的特征信息。Jahanshahi 等^[31]基于 LBP、SVM 和贝叶斯决策理论,提出了一种金属表面裂纹检测方法,该方法综合了不同视频帧的信息,增强了检测的鲁棒性和可靠性。Zhou 等^[32]提出了一种基于纹理特征的钢丝绳表面损伤检测方法—WR-LBPML。应用同态滤波算法,结合均匀局部二值模式算子对特征进行提取,并通过主成分分析^[33]对特征进行处理,最终取得 93.3%的准确率。

Wu 等^[34]首先通过改进的灰度共生矩阵^[35] (Gray-level Co-occurrence Matrix, GLCM) 获取金属表面信息,然后提取 GLCM 的差矩和熵作为金属表面的特征,最后将检测图像的特征与预设的置信区间进行比较,以确定金属表面是否存在缺陷。Iivarinen 等^[36]基于 GLCM 和 LBP,结合自组织映射算法^[37],对金属表面进行了缺陷检测,结果表明,两种方法的性能没有明显差异,但 LBP 的计算要求更低。Shanmugamani^[38]等首先通过扩展极大值变换方法对枪管表面图像进行分割,并根据直方图和 GLCM 提取纹理特征,同时采用顺序前向特征选择方法对图像进行排序,最终通过实验证明了 SVM 具有良好的分类效果。

Suvdaa 等^[39]提出了一种基于 SIFT 算法的钢材表面缺陷检测方法,并且提出了最终决策的投票策略,该策略在特定缺陷类型的前提下可以解决输入图像具有多个输出的问题。Li 等^[40]通过 SIFT 算法实现了电缆表面缺陷图像特征点的检测、提取、描述和匹配,并通过图像融合获得完整图像,最终在图像中显示完整的缺陷。实验结果表明,该方法对于提高电缆表面缺陷的检测精度和完整性具有良好的效果。

Min 等^[41]提出了一种基于机器视觉的钢轨表面缺陷实时检测方法。该方法利用数学形态学处理对钢轨表面缺陷进行优化,并通过跟踪方向链码获得缺陷的特征,确保了钢轨表面缺陷检测的实时性能。Wang 等^[42]研究了一种基于形态学的分水岭分割方法,该方法结合模糊聚类算法的空间增量矩阵计算方法和图像分割方法,保证了分割图像的可视性和缺陷图像的分割精度,满足了表面缺陷在线检测的要求。

Annaby 等^[43]提出了一种低复杂度标准化互相关方法，首先将印制电路板表面缺陷二维子图像转换为一维特征描述符，然后对子图像进行垂直和水平扫描，同时使用空间统计量进行扩充，最后通过离散余弦变换^[44]进行变换以创建特征描述符。Zhou 等^[45]通过多尺度 Hessian 矩阵融合方法从车身表面图像中提取候选缺陷区域，并通过提取形状、大小、统计信息等特征，结合 SVM 将候选缺陷区域分为伪缺陷、凹痕和划痕。实验结果表明，该方法可以有效减少图像噪声造成的误检现象。

尽管前人已经做了大量改进工作，但事实上基于数字图像处理的缺陷检测方法仍然存在着如下问题：第一，检测过程中通常需要对整张图像进行滑动窗口扫描以确定候选区域，缺乏对于检测目标的针对性；第二，人工设计特征提取方法对于先验知识的依赖程度较高，复杂背景中的缺陷特征提取方法设计难度较大；第三，不同属性的表面需要设计不同的特征提取方法，且容易受到光照条件的干扰，普适性和鲁棒性较差。

1.2.2 基于深度学习的表面缺陷检测方法

基于深度学习的表面缺陷检测方法是一种端到端的检测方法，通过神经网络自动从图像中提取缺陷特征，与基于数字图像处理的表面缺陷检测方法相比，该方法所提取的特征更丰富，且不容易受外界环境干扰，检测效果更好，鲁棒性更强，具有较强的泛化能力。因此，基于深度学习的表面缺陷检测方法正逐渐取代基于数字图像处理的传统机器视觉表面缺陷检测方法，应用愈发广泛。

Mujeeb 等^[46]提出了一种基于深度自编码器（Deep Auto-encoder, DAE）的方法来进行表面缺陷检测。该方法首先对参考图像进行数据增强，并将参考图像输入至 DAE 生成参考图像描述符，然后将测试图像输入到经过训练的网络以生成测试图像描述符，最后通过匹配参考描述符和测试描述符，产生相似性分数，并利用该分数判断是否存在缺陷。实验结果表明，该方法比数字图像处理方法更具有通用性。Tao 等^[47]设计了一种级联自动编码器结构，将输入的金属缺陷图像转换为像素级掩模，并通过卷积神经网络将分割出的缺陷区域划分为特定类别。Yun

等^[48]提出了一种条件卷积变分自编码器,用于生成金属表面缺陷图像,并将其生成的缺陷数据输入到深度卷积神经网络中进行分类。实验结果表明,该方法可以满足金属表面缺陷检测的鲁棒性和准确性要求。

Wang 等^[49]首先对输入图像执行高斯滤波以限制随机噪声,并通过 Hough 变换^[50]进行感兴趣区域提取,然后基于卷积神经网络构建了缺陷检测模块,并引入反残差块作为基本块,在表面缺陷检测精度和计算效率之间取得了良好的平衡。Guan 等^[51]提出了一种基于可变形卷积神经网络的镁合金板材表面缺陷检测方法,该方法通过在采样位置增加可自由调整的偏移量以获取更大的感受野,进而提高了缺陷检测的准确性。Faghih-Roohi 等^[52]提出了一种基于深度卷积神经网络(Deep Convolutional Neural Network, DCNN)的钢轨表面缺陷检测方法,将原始图像作为检测模型的唯一输入,然后使用小批量梯度下降方法优化网络,最终通过实验比较了大、中、小三种 DCNN 结构的分类性能和训练时间,结果表明大型 DCNN 结构具有更好的检测性能。

Lee 等^[53]建立了一种基于 VGG (Visual Geometry Group) 网络^[54]的钢材检测模型,通过全局平均池化操作增强了模型的解释能力,并采用类激活图来描述模型决策过程中的显著区域,以分析图像中的局部缺陷。实验结果表明,该模型的准确率可达 99.44%。Arikan 等^[55]提出了一种 SurfNet 金属表面缺陷检测模型,该模型基于 VGG 网络进行改进,并采用了参数化修正线性单元^[56]用于优化模型训练过程。

Lian 等^[57]提出了一种针对微小表面缺陷的缺陷放大方法,通过将图像中的几何与颜色变化作为正则项来生成无缺陷图像和对应的放大缺陷图像,同时提出了一种生成对抗网络^[58]用于扩充缺陷检测的训练数据集,以保证微小表面缺陷检测的准确性。Deshpande 等^[59]提出了一种基于 Siamese 孪生卷积神经网络^[60]的钢板表面缺陷检测方法,通过对比候选图像与某个类别的示例图像之间的特征差异来判断缺陷类别,该方法可以显著降低模型对于训练数据规模的要求,且具有实时性。

Yu 等^[61]提出了一种小样本检测模型,该模型移除了 YOLO (You Only Look

Once) 模型^[62]中的批量归一化层, 并采用两种不同尺度的特征图以实现更精确的缺陷定位。实验结果表明, 该模型具有良好的特征提取性能, 并解决了表面缺陷检测中样本较少的问题。Lin 等^[63]提出了一种分层模型用于检测钢坯表面缺陷, 首先通过 SSD (Single Shot MultiBox Detector) 模型^[64]对缺陷进行定位, 然后使用残差网络^[65] (Residual Network, ResNet) 对不同类型的缺陷进行分类。实验结果表明, 该模型具有较高的准确率及召回率。

Wu 等^[66]提出了一种基于卷积神经网络的表面缺陷检测方法, 首先采用 GoogLeNet 网络^[67]中的 Inception 层增强网络表现, 然后通过投票机制来解决图像块误分类导致的整张图像误分类以及定位错误问题, 最后设置了 64×64 和 32×32 两种尺寸的输入图像对网络进行训练, 并通过加权评分对两种尺寸图像的得分结果进行整合, 实现了多尺度检测。Shihavuddin 等^[68]提出了一种基于 Inception-ResNet-v2 网络结构的改进 Faster R-CNN (Faster Region-Based Convolutional Network) 模型^[69], 并采用多尺度金字塔和数据增强克服了缺陷样本稀缺的问题, 最终使叶片表面缺陷检测精度达到了 81.10%。

Dong 等^[70]提出了一种基于金字塔特征融合和全局上下文注意力网络的钢板表面缺陷检测方法。该网络首先从特征提取网络中提取多尺度特征, 然后利用金字塔特征融合模块, 通过密集跳跃连接将特征融合成五种分辨率, 最后将全局上下文注意力模块应用于相邻分辨率的融合特征图, 使得有效信息可以从低分辨率融合特征图传播到高分辨率融合特征图。He 等^[71]提出了一种基于卷积神经网络的多级特征融合网络, 该网络首先将多个层次的特征融合为一个特征, 以包含更多的缺陷位置细节, 然后采用区域生成网络结合上述特征生成感兴趣区域, 最终由分类器和边界框回归器组成的检测器对于每个感兴趣区域产生检测结果。

Guo 等^[72]提出了一种基于 ResNet 的表面缺陷检测方法。首先通过多尺度学习模块提取缺陷的多尺度特征, 然后在训练过程中使用一组堆叠的残差学习模块来学习更多的抽象特征, 最后利用全局平均池化实现了缺陷识别的回归过程。Liu 等^[73]提出了一种基于卷积神经网络和长短期记忆^[74] (Long Short-Term Memory, LSTM) 网络的热轧钢板表面缺陷检测方法。首先通过神经网络提取缺陷图像的

特征，然后将提取的特征向量输入 LSTM 网络进行缺陷识别。实验结果表明，该方法对于周期性缺陷具有良好的检测效果。

Sylvio 等^[75]提出了一种基于 RetinaNet 模型的冲压金属表面缺陷检测方法，该方法将卷积神经网络的检测和分类与跨视频帧的对象跟踪相结合，提高了缺陷识别率并降低了误检率。Chen 等^[76]提出了一种基于卷积神经网络和朴素贝叶斯数据融合的 NB-CNN 表面缺陷检测模型，该模型通过聚合各个视频帧中的信息来增强检测性能和鲁棒性，并通过朴素贝叶斯决策有效降低了误检率。

综上所述，与基于数字图像处理的传统机器视觉表面缺陷检测方法相比，基于深度学习的表面缺陷检测方法可以有效解决因光照条件、图像噪声、缺陷形态变化等因素造成的检测效率低下、精度不高，以及特征提取方法难以设计等问题，是一类十分具有发展前景的缺陷检测方法。

1.3 论文研究内容与架构

轴瓦缺陷检测面临一系列难以解决的问题。一方面，轴瓦作为一种内壁光滑、大曲率的金属零件，在对其内表面进行检测的过程中会存在光照不均现象，导致反光区域缺陷难以识别；另一方面，轴瓦表面部分种类的缺陷纹理与轴瓦自身纹理相似，且轴瓦表面缺陷会根据其在轴瓦圆弧面上位置的不同而呈现出不同的形态，造成特征难以提取。目前，深度学习算法在轴瓦表面缺陷检测领域的应用较少，本文考虑到基于深度学习的缺陷检测方法的优点，将深度学习算法引入轴瓦表面缺陷检测问题中，通过构建深度神经网络对轴瓦图像特征进行学习，并根据轴瓦表面缺陷特征实现缺陷的识别与定位，以提升轴瓦表面缺陷检测的效率、精度及鲁棒性。本文的主要工作如下：

(1) 针对轴瓦表面各类缺陷的特点，设计了基于目标检测模型的轴瓦表面缺陷检测方案，并搭建了实验平台。通过实验平台采集了轴瓦图像并完成数据标注，据此提出一种轴瓦表面缺陷数据集。该数据集可用于目标检测模型的训练与检测性能评价，极大程度地扩充了轴瓦表面缺陷检测领域的数据库。

(2) 针对工业现场缺陷轴瓦较少，数据集规模相对不足的问题，提出了一种

混合样本在线数据增强方法，弥补数据集规模的不足，并进一步探究了数据集扩充规模与缺陷检测精度之间的关系。同时，引入了基于深度迁移学习的目标检测模型训练过程改进方法。通过大型数据集对模型进行预训练，并将模型所学知识迁移至轴瓦表面缺陷检测问题中，实现了图像低层特征的迁移，从而确保模型在数据集规模较小的情况下具有良好的训练效果。

(3) 提出了一种针对轴瓦表面缺陷的高效检测模型 YOLO-Bush。该模型通过深浅层特征融合、通道特征增强、多尺度特征融合、局部与全局特征融合等特征提取方法，以及动态调整轴瓦表面缺陷数据集中难易样本权重的方法，实现了轴瓦表面各类缺陷的精确识别。同时，该模型通过距离交并比损失函数计算预测框与真实框之间的误差，实现了轴瓦表面缺陷的精确定位。

(4) 基于轴瓦表面缺陷检测总体方案，开发了一款具有图形交互界面的轴瓦表面缺陷检测软件，其可以对生产环境中的轴瓦表面缺陷进行检测。该软件可以在检测过程中积累缺陷样本，从而可对 YOLO-Bush 模型进行二次训练并实现校准，确保了模型在不断迭代的过程中对于轴瓦表面缺陷的检测性能得以进一步提升。

本文共分为六章，各章的内容安排如下：

第1章，首先阐述本文的研究背景和意义；然后介绍了基于数字图像处理和深度学习的表面缺陷检测技术的研究现状；最后给出了本文主要工作和论文框架。

第2章，阐述了轴瓦表面缺陷检测方案设计过程。首先介绍了轴瓦的制造工艺与缺陷特点，据此设计出基于深度学习目标检测模型的轴瓦表面缺陷检测整体方案，并搭建了实验平台；然后采集轴瓦图像并构建了轴瓦表面缺陷数据集；接着介绍了几种经典的基于区域生成的目标检测模型和基于回归的目标检测模型，并完成本文基础模型的选择；最后给出了目标检测模型的常用评价指标。

第3章，开展了轴瓦表面缺陷数据增强策略研究。首先介绍了轴瓦表面缺陷检测模型的实验参数设置；然后采用四种经典目标检测模型开展了轴瓦表面缺陷数据集的基准性能测试；接着提出了混合样本在线数据增强方法，对轴瓦数据进行增广，并进一步通过消融实验探究了数据集扩充规模与检测性能之间的关系；

最后基于深度迁移学习中的预训练与模型微调方法对四种模型的训练过程进行优化并进行对比实验，同时选取 YOLOv3 作为后续研究的基础模型。

第4章，阐述了 YOLO-Bush 模型的设计过程。首先介绍了 YOLOv3 模型结构及其检测原理；然后提出了四种基于特征融合及通道特征增强的特征提取改进方法；接着通过 K-means++ 聚类算法对模型锚框数量以及尺寸进行了优化；随后，提出了距离交并比与聚焦损失相结合的损失函数，用于解决数据集中样本不均匀的问题，并提高模型预测的定位精度；最后通过消融实验对本章所提出方法的有效性进行了验证。

第5章，首先介绍了轴瓦表面缺陷检测软件的整体架构；然后，针对检测软件中主要模块的具体功能实现进行了详细介绍；最后基于检测软件对 YOLO-Bush 及三种经典模型的检测精度与效率开展了对比实验。

第6章，对全文进行总结，并对轴瓦表面缺陷检测的后续研究工作做出展望。

本文的内容框架如图 1.3 所示。




图 1.3 本文的内容框架

1.4 本章小结

本章阐述了开展轴瓦表面缺陷检测研究的背景与意义，介绍了基于数字图像处理 and 深度学习表面缺陷检测方法的国内外研究现状，并概括了本文主要工作，最后给出了本文的各章内容及架构。

第2章 轴瓦表面缺陷检测方案设计

2.1 引言

轴瓦表面缺陷检测从本质上而言是一种目标检测任务，即判断给定的轴瓦图像中是否存在缺陷以及缺陷所出现的位置。近年来，随着深度学习算法的蓬勃发展，目标检测领域的研究重点正逐渐从传统图像处理算法过渡到基于深度神经网络的目标检测方法。常见的深度学习目标检测方法主要包括自编码神经网络、卷积神经网络、深度残差网络等，其中基于卷积神经网络的方法应用最为广泛。据此，本章开展了轴瓦表面缺陷检测的方案设计工作。首先简要介绍了轴瓦制造工艺流程，并对轴瓦表面的凹坑、划痕、擦伤、污渍四类缺陷的特征进行了分析；在此基础上给出了本文基于深度学习目标检测模型的轴瓦表面缺陷检测整体实验方案；随后搭建了实验平台，同时构建了轴瓦表面缺陷数据集；最后简要介绍了几种经典目标检测模型，并给出了目标检测模型的常用评价指标。

2.2 轴瓦制造工艺流程与整体检测方案

2.2.1 轴瓦制造工艺流程

轴瓦的结构形式有平轴瓦、翻边轴瓦、法兰轴瓦等，其中应用最为广泛的为平轴瓦，其主要包括油孔、油槽、定位凸台、油孔内倒角、端面内倒角、对口内倒角等结构，平轴瓦的外观及结构如图 2.1 所示。




图 2.1 平轴瓦外观及结构示意图

轴瓦通常选用 20 高锡铝合金或铜铅合金等减摩材料制成，其制造工艺流程

包括备料、冲压成形、粗镗内圆、车两端面、倒角、冲定位凸台、拉削对口平面、钻孔、车铣油槽、检验和包装。经过冲压成形后轴瓦的壁厚在整个圆周上分布是不均匀的，会影响到后道工序对口平面的加工精度，因此轴瓦冲压成形后需要先通过粗镗内圆工序来保证内圆表面的粗糙度和精度，在此基础上，再通过其他工序保证轴瓦的整体加工精度。在上述机械加工的过程中，由于原材料质量、加工工艺、设备状况、刀具磨损、操作人员工作状态等诸多因素的影响，轴瓦的内表面可能会产生一系列的缺陷，例如：划痕、凹坑、擦伤、污渍、结构缺失等，如不及时检出上述缺陷，将会导致轴瓦所装配的设备性能降低甚至损坏。

本文采用的实验对象为 C90C-R 型空压机轴瓦，该轴瓦属于平轴瓦，其尺寸参数如表 2.1 所示。根据样品缺陷和企业生产的实际情况，本文针对上述缺陷中的划痕、凹坑、擦伤、污渍，以及油孔、油槽结构缺失的检测方法开展了研究。

表 2.1 C90C-R 型空压机轴瓦尺寸参数

外径	宽度	壁厚	油槽宽度	油孔直径
42.00mm	22.00mm	2.00mm	2.20mm	6.00mm

2.2.2 轴瓦表面缺陷分析及检测目标

(1) 轴瓦结构缺失检测

在轴瓦加工过程中，钻孔、车铣油槽工序遗漏会造成油孔、油槽等重要结构的缺失，具有这类缺陷的轴瓦如未经检验而被装配到设备中，会造成轴瓦在运转过程中缺少润滑油的润滑作用而局部温度过高、内表面合金软化甚至熔化，进而导致设备损坏。图 2.2 为缺失油孔及油槽的轴瓦。




图 2.2 缺失油孔及油槽的轴瓦

(2) 轴瓦表面缺陷检测

轴瓦表面缺陷具有多种形态，例如划痕、凹坑、擦伤、污渍等，划痕通常是

在加工、运输过程中受到尖锐物体刻划而产生的一种缺陷，呈均匀线状，宽度一般为 $0.2\text{mm}\sim 1\text{mm}$ ；凹坑由轴瓦在加工或运输过程中的剧烈碰撞所产生，呈近似圆形，直径一般为 $0.5\text{mm}\sim 3\text{mm}$ ；擦伤则为异物摩擦所造成的片状交错的缺陷，尺寸通常为 $1\text{mm}\sim 5\text{mm}$ ；污渍由轴瓦加工过程中的油污残留或其他杂质附着在轴瓦表面所产生，一般为黑色斑点状，尺寸通常为 $0.5\text{mm}\sim 3\text{mm}$ 。上述缺陷可能出现在轴瓦表面的任意位置，此类缺陷的存在会造成轴瓦工作表面局部润滑不良，或者工作表面载荷分布不均匀而产生局部峰值压力，进而导致轴瓦表面出现网状裂纹、片状剥落损坏等现象。图 2.3 为轴瓦表面的四种缺陷。在工业现场中，上述各类缺陷的检出率需达到 95%以上，单个轴瓦的检测耗时要求低于 0.2s 。




图 2.3 轴瓦表面的四种缺陷

2.2.3 轴瓦表面缺陷检测整体流程

由于轴瓦表面缺陷的形态、出现位置都不固定，且从不同角度拍摄轴瓦图像时可能会造成光照条件变化，产生反光等问题。因此设计一套精确、高效且具有鲁棒性的方案来应对轴瓦表面缺陷的复杂性与多样性具有重要的意义。本文采用深度学习目标检测模型实现轴瓦表面缺陷检测，整体检测流程如图 2.4 所示。




图 2.4 轴瓦表面缺陷检测整体流程图

上图中的检测过程分为三个部分：

（1）数据集构建

深度学习目标检测模型通常需要大量数据的支撑才能够实现有效检测，因此数据集的构建是开展本文研究的基础。本文首先搭建了轴瓦表面缺陷检测实验平台并采集了轴瓦图像；然后对图像中的缺陷及轴瓦结构进行数据标注以构建轴瓦表面缺陷数据集；最后将数据集划分为训练集、验证集、测试集，用于后续的模型训练与测试过程。

（2）模型训练

在轴瓦表面缺陷数据集构建完成后，本文首先通过 PyTorch®深度学习框架设计网络结构及模型训练参数，实现了多种目标检测模型；然后通过轴瓦表面缺陷数据集中的训练集对模型进行训练，并通过验证集对模型训练精度进行验证，当模型无法收敛时，调整模型训练参数后再重新训练；最后，当模型收敛时，通过测试集对模型的检测性能进行测试，如果不满足精度要求，则对网络结构进行调整，并重新开始训练，直至达到精度要求。

（3）缺陷检测

当模型训练完成后，将待检测轴瓦图像输入模型，即可获取轴瓦表面缺陷的位置以及类别。同时，本文设计了一种模型校准机制，将检测结果为不合格的轴瓦图像加入训练集中，当带有缺陷的轴瓦图像数量累积至足量时，对模型进行二次训练，从而不断提升模型的检测性能。

2.2.4 轴瓦表面缺陷检测实验平台搭建

如上文所述，数据集构建是采用深度学习目标检测模型开展轴瓦表面缺陷检测的基础，而构建数据集的第一个环节便是图像采集。因此，图像采集相关的硬件设备选择将直接影响模型检测性能的优劣。由图 1.2 可知，机器视觉表面缺陷检测系统的图像采集设备通常包括工业相机、光学镜头、照明光源、上位机等。本文根据 C90C-R 型轴瓦尺寸以及轴瓦表面各类缺陷的特点，对上述图像采集设备做出如下选型：工业相机选用大恒 MER-132-30GM 型 GigE CCD 工业相机，

分辨率为 1292×964 ；光学镜头选用 OPT-C2514-2M 型 C 口镜头，焦距为 25mm；照明光源选用 YSC-R9060W 型白色 LED 环形光源，以多角度照明方式对轴瓦进行打光，其光路示意图如图 2.5 所示。观察图 2.5 可知，轴瓦的半圆形外观使得进入相机的反射光线主要集中在轴瓦底部，而轴瓦侧壁的反射光线则难以进入相机，因此即使采用多角度照明方式打光，轴瓦图像也难免会出现光照不均现象，表现为轴瓦底部明亮，而侧壁则会形成暗区。




图 2.5 环形光源照明光路示意图

其他图像采集设备包括：YSC-KZQ-2 型光源控制器、机器视觉检测专用实验台、计算机。最终搭建的轴瓦表面缺陷图像采集平台如图 2.6 所示。




图 2.6 轴瓦表面缺陷图像采集平台

完成图像采集后，需要通过服务器对目标检测模型进行训练。本文基于 Linux 服务器开展模型训练和测试实验，图 2.7 为服务器的实物图，该服务器的硬件配

置、软件配置如表 2.2 所示。



图 2.7 服务器实物图

表 2.2 服务器硬件配置与软件配置

硬件配置	软件配置
Ubuntu 18.04.4 LTS 操作系统	Python 3.7 编程语言
2×NVIDIA GeForce RTX 2080Ti 11GB GPU	PyTorch 1.3.0 深度学习框架
Intel Core i9-9900K 3.60GHz CPU	CUDA 10.1.243 计算架构
2×Kingston DDR4 3200MHz 32GB 内存	cuDNN 7.6.5 GPU 加速库

2.3 轴瓦表面缺陷数据集构建

在深度学习目标检测任务中，模型训练的好坏与数据集的质量有着密不可分的关系。这是因为训练模型的过程是一个有监督学习的过程，需要将大量的带有标签的样本作为真值（Ground Truth）输入到模型中，通过损失函数计算预测值与真值之间的误差，并使用梯度下降优化算法来更新网络参数，直至损失函数达到最小值使模型收敛。虽然目标检测领域已经有 ImageNet^[77]、PASCAL VOC^[78]、MS COCO^[79]等工业界常用的公开数据集以及 DAGM 2007^[80]、NEU-DET^[81]为代表的缺陷检测数据集，但以上数据集中并不包含本文所研究的轴瓦表面缺陷类型，因此并不能应用于本文的轴瓦缺陷检测任务中。于是本文在轴瓦表面缺陷检测实验平台上采集了 2100 张轴瓦图像并进行数据标注，构建出轴瓦表面缺陷数据集。

目标检测模型实际上是一种输入图像和目标物体出现位置及分类概率之间的一种映射关系，因此需要在数据标注阶段事先定义出各个目标的位置及类别。

本文采用图像标注软件 LabelImg[®]对 2100 张轴瓦图像进行了标注，并按照 PASCAL VOC 格式保存数据集，标注时使用矩形框选出各个目标，记录标注框的左上角点坐标 (x_{min}, y_{min})、右下角点坐标 (x_{max}, y_{max}) 以及目标类别，进而可以求得标注框中心坐标 (x, y)、宽高 (w, h)。图 2.8、2.9 分别为轴瓦表面缺陷的标注界面，以及本文构建的轴瓦表面缺陷数据集的部分样本示例。




图 2.8 LabelImg 数据标注界面




图 2.9 轴瓦表面缺陷数据集样本示例

本数据集中共有 6 种标签，分别为 4 种缺陷，包括：凹坑 (pit)、划痕 (nick)、擦伤 (scratch)、污渍 (blot)，以及 2 种轴瓦结构，包括：油孔 (hole)、油槽 (gap)。如图 2.9 所示，其中第一行为尺寸较大的缺陷以及油槽、油孔样本，第

二行为中等尺寸的各类缺陷样本，第三行为各类尺寸较小的缺陷样本。为了确保标注数据的真实性与有效性，数据集中的每张图像都经过3名人员标注，并对矩形框的坐标及宽高取平均值，最终由一名具有10年以上工作经验的人员复核数据标注结果。图2.10为本文构建的轴瓦缺陷检测数据集中各类别样本的数量统计，从图中可以看出各类样本的数量分布存在一定的不均匀性。




图 2.10 各类别样本数量统计

由于每个轴瓦具有两个油槽结构，因此上图中油槽样本数量显著大于其余样本。此外，由于凹坑、划痕缺陷尺度通常较小，同一张轴瓦图像中有时会含有多处凹坑或划痕缺陷，因此这两类缺陷样本的数量多于擦伤和划痕。




图 2.11 各尺度样本数量分布情况

目标检测任务中，根据目标的标注框面积相对于图像所占的比例，可以将目标划分为大、中、小三种尺度。图2.11为不同尺度样本数量的分布情况，其中小目标为像素面积小于图像面积0.2%的目标，中目标像素面积占比为0.2%~0.8%，

大目标像素面积占比大于 0.8%。本文所拍摄的轴瓦图像分辨率为 1292×964 ，按照上述比例换算，小尺度目标面积应小于 2490 像素，中尺度目标面积为 2490~9963 像素，大尺度目标面积应大于 9963 像素。

2.4 轴瓦表面缺陷检测模型选择

如上文检测方案所述，本文通过构建轴瓦表面缺陷数据集，并采用基于深度学习的目标检测模型对轴瓦表面缺陷进行检测，因此合理选择模型是轴瓦表面缺陷检测效果优劣的重要影响因素。深度学习目标检测模型根据检测阶段数目的不同，可被分为双阶段（Two-stage）检测模型和单阶段（One-stage）检测模型两类。其中，Two-stage 检测模型也被称作基于区域生成的目标检测模型，该类模型需要首先生成可能包含待测物体的候选区域（Region Proposal），然后再对候选区域进行细粒度的校准和分类，方可获得最终的检测结果。这类模型的代表是区域卷积神经网络（Region-Based Convolutional Network, R-CNN）系列模型和 R-FCN 模型。One-stage 检测模型也被称作基于回归的目标检测模型，该类模型不需要生成候选区域，直接在网络中提取特征并给出最终的检测结果，其中的代表是 YOLO 系列模型和 SSD 模型。

2.4.1 基于区域生成的目标检测模型

（1）R-CNN 系列模型

R-CNN 是由 Ross Girshick 等^[82]于 2013 年提出的一种结合区域生成和卷积神经网络的目标检测模型，该模型将检测任务分为区域建议和特征提取两个阶段。第一阶段通过 Selective Search 算法^[83]在输入图像中生成大约 2000 个形状大小各不相同的可能包含物体的候选区域，然后对候选区域进行缩放操作，以适应卷积神经网络（Convolutional Neural Network, CNN）对于输入的尺寸要求；第二阶段将先前生成的候选区域输入到 CNN 中进行训练得到特征向量，再将特征向量输入到支持向量机（SVM）和回归器中进行目标分类和定位。通过使用 Selective Search 算法，R-CNN 筛选候选区域的速度相比采用滑动窗口算法的传统目标检测方法有了显著的提升。此外，由于 R-CNN 引入了线性回归器，这使其能够对边

框进行调整，提高了边框定位的精确度。图 2.12 为 R-CNN 的检测流程图。




图 2.12 R-CNN 检测流程

Fast R-CNN（Fast Region-Based Convolutional Network）模型是 Firshick 等^[84]在 2015 年提出的改进版 R-CNN 模型，该模型引入了感兴趣区域（Region on Interesting, ROI）池化层。ROI 池化层可将原始图像中的候选区域映射到特征图中，对于任意一个候选区域，只需要获取该区域左上角和右下角在特征图中的对应位置，即可通过特征图来提取该区域的特征。

为了解决 R-CNN、Fast R-CNN 使用 Selective Search 算法生成大量无效候选区域所造成的计算资源浪费及漏检问题，Ren 等在 2015 年提出了 Faster R-CNN（Faster Region-Based Convolutional Network）模型。该模型最重要的特性是在 Fast R-CNN 的特征提取网络中加入了区域建议网络(Region Proposal Network, RPN)，取代了 Selective Search 算法，使得检测任务中的候选区域生成、候选区域特征提取、边框回归、分类等步骤可以一次性完成，真正实现了端到端学习。




图 2.13 RPN 原理示意图^[69]

图 2.13 为 RPN 原理图。RPN 的原理是将任意尺寸的一张图像作为输入，然

后在特征图上输出一系列矩形区域对应目标的分数和位置信息。即在最终得到的卷积特征层上通过滑动窗口在每个点上生成 k 个不同的矩形框来提取区域特征。上述矩形框也被称作锚框 (Anchor)，锚框所覆盖的图像属于前景或背景需要通过分类器来判断，而边框回归的精确位置需要通过回归模型来判断。虽然 Faster R-CNN 通过 RPN 进一步提升了模型的训练效率和检测速度，但是其仍然要先进行 ROI 生成，再对区域进行分类判断来完成目标检测，这意味着 Faster R-CNN 的计算量依然很大，难以作为实时检测模型使用。

(2) R-FCN 模型

R-FCN^[85] (Region-based Fully Convolutional Network, R-FCN) 是一种由 Faster R-CNN 演变而来的模型，由 Dai 等在 2016 年提出，该模型相比于 Faster R-CNN 的主要改进在于引入了位置敏感得分图，提高了检测速度。R-FCN 模型在检测的过程中，首先通过特征提取网络提取图像特征并生成特征图，再通过 RPN 从特征图中提取 ROI。R-FCN 和 Faster R-CNN 在提取 ROI 之前的流程是相同的，二者之间的主要差别体现在对于 ROI 的分类与回归方法上。




图 2.14 全连接与局部连接示意图

Faster R-CNN 需要利用一组全连接层实现对目标的分类与回归，每个 ROI 都要进行全连接计算。如图 2.14 所示，全连接中的每个神经元都需要与图像中的所有像素建立连接，权重参数数量庞大，从而导致计算量较大，消耗时间较长。而 R-FCN 将全卷积层输出的特征图与两组额外添加的卷积层进行运算，生成位置敏感得分图，并将 ROI 和得分图输入 Softmax 层进行投票，实现对目标的分类与回归运算，相当于利用卷积层取代了 Faster R-CNN 中的全连接层。如图 2.14 所示，

卷积层中的局部连接以及参数共享机制可以有效减少连接数量，从而减少权重参数，进而降低模型计算量，因此 R-FCN 的检测速度得以提升。

2.4.2 基于回归的目标检测模型

(1) YOLO 系列模型

YOLOv1 是 Redmon 等在 2015 年提出的一种 One-stage 模型。该模型直接将整张图像输入到神经网络中，然后预测出边界框（Bounding Box）坐标以及物体的类别和置信度，因此其检测速度远超 R-CNN 系列模型，可以实现实时检测。YOLOv1 在检测过程中，需要首先将输入图像缩放至固定尺寸，然后将图像划分为 $S \times S$ 的网格，其中每个网格负责预测 2 个边界框，再对所有网格进行分类和定位。当目标大于网格的大小时，不同网格可能属于同一个物体的不同部分，此时需要对边框进行合并，合并阶段会涉及到很多重叠的边框，需要通过非极大值抑制（Non-Maximum Suppression, NMS）算法^[86]消除重叠边框。图 2.15 为 YOLOv1 模型的检测流程示意图。




图 2.15 YOLOv1 检测流程示意图

Redmon 等于 2017 年提出了 YOLOv2 模型^[87]，以解决 YOLOv1 检测精度不高的问题。YOLOv2 在网络中加入了批量归一化（Batch Normalization, BN）层，对每一层的输入都进行归一化，加快了模型的收敛速度，并减小了模型出现过拟

合的可能性。此外，由于 YOLOv1 直接使用全连接神经网络预测边框的位置，并不区分不同长宽比的物体，导致物体的空间信息丢失，定位精度较差。因此 YOLOv2 借鉴了 Faster R-CNN 中的锚框的概念，将锚框引入到网络中，并通过 K-means 聚类算法将回归框进行聚类，以确定最佳的锚框形状。

2018 年，YOLO 系列模型的作者 Redmon 等再次对 YOLOv2 进行了改进，提出了 YOLOv3 模型^[88]。YOLOv3 将特征提取网络由 DarkNet-19 替换为了 DarkNet-53 残差网络，并且融入了特征金字塔网络^[89]（Feature Pyramid Network, FPN）结构，将浅层特征层和深层特征层之间进行连接，提升了 YOLOv3 对于小目标物体的检测性能。同时，YOLOv3 将先前网络结构中的 Softmax 层换成了逻辑回归层，使得 YOLOv3 可以实现多标签分类。

（2）SSD 模型

2016 年，Liu 等提出一种融合了 Faster R-CNN 中的锚框机制和 YOLO 中无区域生成特点的 SSD 模型，该模型在保证检测精度的同时，也具有较高的检测速度。在 SSD 中，锚框可以在特征提取网络 VGG-16 中的最后几个特征层 Conv6、Conv7、Conv8、Conv9、Conv10 上产生，这些特征层的大小依次递减，意味着同一个锚框在越靠近高层特征层处的感受野越大，可以检测的目标也就越大。这种结构使得 SSD 具有多尺度检测的特点，在一定程度上提高了小目标的检测精度。

考虑到工业生产现场对于轴瓦表面缺陷检测精度和速度均有着较高的要求，因此本文分别选取上述经典目标检测模型中检测精度相对较高的 Two-stage 模型 Faster R-CNN、R-FCN，以及检测速度相对较快的 One-stage 模型 SSD、YOLOv3 作为本文研究的四种基础模型，并对各模型的实际检测性能开展对比研究。

2.5 目标检测模型评价指标

在目标检测任务中，通常将图像中的待检测目标称作正例（Positive），将背景称作负例（Negative）。目标的真实类别和模型预测类别之间的关系，可以通过混淆矩阵来描述，如表 2.3 所示。

表 2.3 混淆矩阵

		预测类别	
		正例	负例
真实类别	正例	真正例 (True Positive, TP)	假负例 (False Negative, FN)
	负例	假正例 (False Positive, FP)	真负例 (True Negative, TN)

为了使模型可以在图像中区分正例与负例,通常使用交并比 (Intersection over Union, IoU) 作为判断条件。即模型生成的预测边界框 (Bounding Box) 与数据集中事先标注好的真实框 (Ground Truth) 之间的重叠程度,相当于两个矩形的交集除以并集,其定义如式 (2-1) 所示。

$$IoU = \frac{Groud\ Truth \cap Bounding\ Box}{Groud\ Truth \cup Bounding\ Box} \quad (2-1)$$

如图 2.16 所示, IoU 即为图中黄色区域面积除以蓝、绿、黄三部分面积之和。在实际应用中,通常会为 IoU 设置一个阈值,来表明重叠程度的大小,用以区分正例与负例,当 $IoU \geq 0.5$ 时,可以认为两个矩形基本相交,即预测框中的目标为正例。因此,本文后续章节的实验中, IoU 阈值均设置为 0.5。




图 2.16 IoU 计算原理

对于本文研究的轴瓦表面缺陷检测问题而言,应尽可能全面地将轴瓦上的缺陷检出,避免漏检。因为漏检可能会导致带有缺陷的轴瓦流向后续生产环节,影响下游产品的质量,造成更多经济损失。因此引入召回率 (Recall) 作为模型评价指标之一,召回率表示真正例样本占有所有实际为正例的样本的比例,反映了模型的查全性能,其定义如下:

$$Recall = \frac{TP}{TP + FN} \quad (2-2)$$

同时，引入精确率（Precision）用于描述模型对某个类别检测的准确程度，精确率表示真正例样本占有所有被检测为正例的样本的比例，反映了模型的查准性能，其定义如下：

$$Precision = \frac{TP}{TP + FP} \quad (2-3)$$

为了建立召回率和精确率之间的关系，描述模型在两种指标之间的差异程度，分类问题中通常还会使用 F1 值作为分类效果的评价指标，其定义如下：

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (2-4)$$

对于具有多个类别目标的检测任务而言，可以绘制出每一个类别的精确率-召回率（Precision-Recall, PR）曲线，PR 曲线与坐标轴围成的面积表示模型对于该类别的检测精度，表示为平均精确率（Average Precision, AP），对于连续的 PR 曲线而言，AP 的计算公式如式（2-5）所示。

$$AP = \int_0^1 P(R) dR \quad (2-5)$$

数据集中所有类别的 AP 平均值称为平均精确率均值（Mean Average Precision, mAP），反映了模型对于各类目标的总体检测性能，mAP 的表达式如下式（2-6）所示，其中 n 为样本中的类别总数， i 为当前类别， AP_i 为当前类别的 AP。

$$mAP = \frac{\sum_{i=1}^n AP_i}{n} \quad (2-6)$$

2.6 本章小结

本章主要阐述了基于深度学习目标检测模型的轴瓦表面缺陷检测方案，并完成了数据准备及模型选择。首先介绍了轴瓦制造工艺流程，并分析了轴瓦表面缺陷的特征，在此基础上设计了检测方案并搭建了实验平台；然后利用实验平台采集了轴瓦图像并完成数据标注，构建出轴瓦表面缺陷数据集；接着介绍了 Faster R-CNN、R-FCN、YOLOv3、SSD 四种经典目标检测模型的原理；最后给出了常用的目标检测模型评价指标。

第3章 轴瓦表面缺陷数据增强策略研究

3.1 引言

本文通过构建轴瓦表面缺陷数据集，并采用基于深度学习的目标检测模型对轴瓦表面缺陷进行检测。深度学习目标检测的效果主要由数据集、模型结构、损失函数三个关键因素所决定。本章针对其中的首要因素——数据集，开展了轴瓦表面缺陷检测的初步研究。首先，通过轴瓦表面缺陷数据集对四种经典目标检测模型进行了对比研究；其次，针对工业现场难以获取充足的轴瓦表面缺陷样本的问题，提出了基于数据增广的缺陷检测性能改进方法，分别通过单样本以及混合样本在线数据增强方法对数据集进行扩充，并通过消融实验验证了本文数据增强方法的有效性；随后，提出了基于深度迁移学习的模型训练过程改进方法，通过大型数据集对模型进行预训练，并将模型所学知识迁移至轴瓦表面缺陷检测问题中，实现了图像底层特征的迁移，从而确保模型在数据集规模较小的情况下具有良好的训练效果；最后，选定后续研究的基础模型 YOLOv3，并分析了该模型在缺陷检测过程中存在的问题以及改进的方向。

3.2 轴瓦表面缺陷检测模型实验参数设置

基于深度学习的目标检测模型在实际应用的过程中需要对模型训练超参数、特征提取网络、输入图像分辨率、优化器算法等实验参数进行设置，同时需要对数据集进行划分。本文对于以上实验参数的设置如下所述。

模型训练超参数方面，默认采用均值为 0、标准差为 1 的正态分布对权重参数进行随机初始化，同时设置批处理大小(Batch Size)为 128，总迭代次数(Epoch)为 100，初始学习率(Learning Rate)为 0.001，学习率衰减策略采用阶梯状周期衰减策略(MultiStep LR)，在 Epoch 为 50、80 时将学习率调整为先前的 0.1 倍，以适应模型训练后期权重参数变化较小的特点，确保模型更好地收敛。

实验中各模型的特征提取网络及输入图像分辨率设置如表 3.1 所示。

表 3.1 各模型特征提取网络及输入图像分辨率

检测模型	特征提取网络	输入图像分辨率
Faster R-CNN	ResNet-50	短边 600
R-FCN	ResNet-50	短边 600
SSD	VGG-16	512×512
YOLOv3	DarkNet-53	608×608

在训练模型的过程中，本文采用基于梯度下降的方法对权重参数进行更新。梯度下降是一种比较常见的参数优化方法，该方法的主要思想是，通过输入训练样本不断迭代权重参数，在接近目标值的时候，减小更新步长（即学习率 η ），使得损失函数向着负梯度方向进行优化，以逐渐逼近最优解。根据每次迭代所使用的数据批量，梯度下降法可以分为批量梯度下降法（Batch Gradient Descent, BGD）和随机梯度下降法（Stochastic Gradient Descent, SGD）。其中 BGD 使用所有的训练样本进行单次迭代，优点是梯度计算结果稳定，容易获取全局最优解，缺点是计算速度很慢，而且由于消耗资源过多，内存可能无法一次性加载所有数据，这意味着 BGD 通常难以实现；而 SGD 每次只取一个样本进行单次迭代，优点是节约计算资源，缺点是梯度计算结果不稳定，有时梯度下降会很慢，容易产生震荡，但从整体上看结果是趋近于最优解的。然而，上述两种优化算法在实际应用中均存在难以选取合适的学习率、容易使模型陷入局部最优解的问题，因此又出现了基于梯度下降法改进的优化算法。

Adam 算法^[90]是一种自适应学习率的梯度下降算法，该算法可以利用梯度的一阶矩估计和二阶矩估计来动态调整每个参数的学习率，其公式如下：

$$m_t = \mu \cdot m_{t-1} + (1 - \mu) \cdot g_t \quad (3-1)$$

$$n_t = \nu \cdot n_{t-1} + (1 - \nu) \cdot g_t^2 \quad (3-2)$$

$$\hat{m}_t = \frac{m_t}{1 - \mu_t} \quad (3-3)$$

$$\hat{n}_t = \frac{n_t}{1 - \nu_t} \quad (3-4)$$

$$\Delta\theta_t = -\frac{\hat{m}_t}{\sqrt{\hat{n}_t + \epsilon}} \cdot \eta$$

(3-5)

式中， t 表示当前时刻， $t-1$ 表示上一时刻， g_t 为当前的梯度， m_t 和 n_t 分别为对梯度的一阶矩估计和二阶矩估计， $\hat{m}_t$ 和 $\hat{n}_t$ 是对 m_t 和 n_t 的校正。 μ 和 ν 为动量，表示当前时刻之前梯度计算量的累加，动量的表达式如下，其中 γ 为每次迭代的动量衰减幅度， η 为学习率， θ 为模型参数， $\nabla_{\theta} J(\theta)$ 为损失函数的梯度。

$$v_{t+1} = \gamma v_t + \eta \nabla_{\theta} J(\theta)$$

(3-6)

$$\theta_{t+1} = \theta_t - v_{t+1}$$

(3-7)

由式（3-5）可见，Adam 算法可以根据梯度动态调整每个参数的学习率，这使其在训练的后期能够取得良好的效果，是大多数情况下理想的参数优化算法。因此本文选用 Adam 作为优化方法，并设置动量系数为 0.9，衰减权重为 0.0005。

本文将轴瓦表面缺陷数据集按照 8:2 划分为训练集与测试集，其中训练集的 25% 作为模型训练的验证集，测试集用于对模型检测性能进行评价。划分后的数据集中各类别不同尺度的样本数量统计如表 3.2 所示。

表 3.2 轴瓦表面缺陷数据集样本统计

样本类别	训练集/测试集样本总数	训练集/测试集各尺度样本个数		
		小样本	中样本	大样本
油孔	1527/416	136/33	408/112	983/271
油槽	3079/822	112/25	574/193	2393/604
凹坑	1382/445	496/153	787/251	99/41
划痕	1373/395	552/153	706/198	115/44
擦伤	1105/253	118/27	750/169	237/57
污渍	731/231	278/82	355/114	98/35

3.3 轴瓦表面缺陷数据集基准性能测试

本节选用上文所述的四种经典目标检测模型：Faster R-CNN、R-FCN、SSD、YOLOv3，分别采用 2.2.4 节中的软硬件环境以及 3.2 节所述的模型实验参数，在轴瓦表面缺陷数据集上对以上模型进行训练，并通过目标检测模型评价指标对各

模型的检测结果进行评价，从而测试轴瓦表面缺陷数据集的基准性能。

图 3.1 所示为轴瓦表面缺陷检测结果示意图，图中 hole 表示油孔，gap 表示油槽，右侧图例展示了轴瓦图像中各类缺陷与上文 2.2.2 节所述四种轴瓦表面缺陷之间的对应关系。图中 nick 表示划痕缺陷，呈狭长线状；pit 表示凹坑缺陷，为凹凸不平的圆形；scratch 表示擦伤缺陷，呈交错片状；blot 表示污渍缺陷，呈黑色斑点状。




图 3.1 轴瓦表面缺陷检测结果示意图

图 3.2 分别为 Faster R-CNN、R-FCN、SSD、YOLOv3 模型对于测试集中某张轴瓦图像的检测效果对比（图中黑色无关背景已截去，下文不再赘述）。观察图像可以发现图(c)中 SSD 模型的检测精度较差，对于轴瓦上边缘右侧凹坑出现漏检，此外，在轴瓦上边缘左侧凹坑以及下边缘污渍处存在预测框冗余问题，而且其他特征的预测框也存在着较大的定位误差。图(a)、(b)、(d)中的其余三种模型对于该图像均能够检测出所有缺陷以及油孔油槽，但三者对于检测目标的置信度以及预测框定位精度存在着一定的差异。整体而言，同为 Two-stage 模型的 Faster R-CNN 和 R-FCN 对于各类目标的预测框定位精度较高，优于 One-stage 的 YOLOv3 模型，但图(a)中的 Faster R-CNN 模型对于轴瓦上边缘右侧凹坑的检测结果存在冗余，图(b)中的 R-FCN 模型对于轴瓦上边缘左侧凹坑的检测结果存在冗余。此外，YOLOv3 对于擦伤、下边缘污渍以及上边缘右侧凹坑的检测置信度高于 Faster R-CNN 和 R-FCN，而三种模型对于轴瓦上下边缘的凹坑、污渍以及

反光区域的划痕检测置信度整体偏低。




图 3.2 各模型轴瓦表面缺陷检测效果对比

在上图中，轴瓦上、下边缘的凹坑和污渍位于轴瓦与黑色背景的交界处，图像灰度变化显著，缺陷尺度较小且形态与轴瓦端面内倒角类似，导致模型难以判断是否存在缺陷，因此置信度较低。此外，对于油孔正上方的划痕而言，根据上文图 2.5 所示的环形光源照明光路图可知，划痕所在区域所反射的光线与相机光轴基本平行，因此该区域的反光现象较为严重，导致缺陷特征被湮没在白色反光中而难以提取，从而降低了置信度。预测框定位方面，可以观察到(c)、(d)两图中 SSD 与 YOLOv3 的油槽预测框与油槽边缘之间存在着一定的间隙，而(a)、(b)图中 Faster R-CNN 与 R-FCN 的油槽预测框则更贴合油槽边缘，定位误差较小。

表 3.3 为上述四种检测模型对于轴瓦表面各类缺陷及结构的检测精度对比。从整体上看，R-FCN 对于各类别目标的检测精度略高于 Faster R-CNN 与 YOLOv3，SSD 的检测精度则相对较差。同时，四种模型对于凹坑、污渍、油孔、油槽的检测精度均高于划痕和擦伤，这是由于轴瓦的油孔、油槽两种结构以及凹坑、污渍两种缺陷在图像中的特征相对清晰，因此几种模型都可以较为准确地检测出上述四种目标，而划痕、擦伤两种缺陷与轴瓦表面纹理相似，特征不显著，更容易受

到反光干扰，所以检测精度偏低。

表 3.3 基于随机初始化权重训练的各模型检测精度对比

检测模型	检测精度 AP/%					
	凹坑	划痕	擦伤	污渍	油孔	油槽
Faster R-CNN	80.59	77.22	76.05	81.96	90.78	93.52
R-FCN	84.83	82.32	80.51	85.38	91.54	94.39
SSD	76.18	73.37	72.43	77.02	87.48	90.62
YOLOv3	83.02	80.68	79.15	84.60	90.99	92.27

表 3.4 为 Faster R-CNN、R-FCN、SSD、YOLOv3 四种模型对于轴瓦表面缺陷检测的各项性能指标对比。观察表格数据可知，R-FCN 模型在检测精度上略优于 Faster R-CNN 模型及 YOLOv3 模型，SSD 模型的检测精度则相对较差，mAP 未达到 80%。此外，由于 Two-stage 模型中 Region Proposal 阶段的存在，Faster R-CNN 和 R-FCN 检测单张图像的平均耗时远大于另外两种 One-stage 模型。

表 3.4 基于随机初始化权重训练的各模型检测性能指标对比

检测模型	精确率/%	召回率/%	F1 值/%	mAP/%	检测耗时/ms
Faster R-CNN	86.30	81.09	83.61	83.35	327.80
R-FCN	88.12	85.11	86.59	86.49	205.28
SSD	81.69	75.07	78.24	79.51	42.73
YOLOv3	87.51	84.62	86.04	85.11	25.44

综合上述实验结果可以看出，除 SSD 模型的检测精度较低之外，其余三种模型在轴瓦表面缺陷数据集上的 mAP 值均可达到 80%以上，可以检出大多数轴瓦表面缺陷。但整体而言，各模型对于划痕、擦伤等不明显缺陷，以及微小缺陷、反光区域缺陷的检测精度均偏低。考虑到本文构建的轴瓦表面缺陷数据集的规模有限，因此从提高数据丰富程度的角度而言，该数据集的性能存在一定的提升空间，下节将通过数据增广的方法进一步提升其对于轴瓦表面缺陷检测的性能。

3.4 基于数据增广的缺陷检测性能改进

对于深度学习目标检测任务而言，充足且有效的数据是保证模型训练效果和检测精度的关键，但通常情况下难以获取足够多的可用数据。例如在本文所研究

的场景中，构建大规模且高质量的轴瓦表面缺陷数据集主要面临以下三个问题：第一，轴瓦缺陷检测领域内缺乏成熟的公开数据集，且生产企业所积累的轴瓦数据较少，导致可用数据相对不足；第二，轴瓦图像的数据标注需要由专业人员消耗大量时间与精力来完成，从而造成标注成本较高；第三，带缺陷的轴瓦在实际生产中所占比例较低，因此难以收集充足的轴瓦缺陷样本。针对目前轴瓦表面缺陷数据集中样本数量少的问题，本节重点从数据层面提出了单样本及混合样本在线数据增强方法，实现轴瓦表面缺陷数据增广，以丰富数据类型，弥补数据集规模的不足，从而提升缺陷检测性能。

3.4.1 轴瓦表面缺陷数据集单样本及混合样本在线数据增强

由于轴瓦在实际检测中摆放的位置较为随机，且轴瓦本身为对称结构，因此本节首先提出了旋转、平移、翻转、缩放四种基于单样本的几何变换方法，来模拟实际检测过程中轴瓦可能出现的位置，从而提升数据丰富程度，减轻模型过拟合现象。其中，采用旋转变换时，每幅轴瓦图像随机顺时针旋转 $45^{\circ}\sim 315^{\circ}$ ，用于模拟轴瓦在检测平台上按照任意方向摆放的情况，同时对旋转过程中产生的倾斜标注框进行重新标注，利用倾斜框的四个顶点重新构造外接矩形，以将标注框调整为水平框；采用平移变换时，每幅图像随机左右平移或上下平移对应边长的 $1/8\sim 1/2$ ，并将平移后的空白区域采用黑色背景填充，用于模拟轴瓦出现在相机视场中的任意位置；采用翻转变换时，每幅图像随机进行水平翻转或垂直翻转，由于轴瓦的摆放位置通常不在画面正中心，且其摆放方向与水平方向呈一定的夹角，因此该方法可以模拟轴瓦出现在对称位置的情况；采用缩放变换时，每幅图像随机缩放 $0.50\sim 2.00$ 倍，用于模拟轴瓦表面不同尺度的缺陷，同时，为了保证轴瓦图像尺寸的一致性，当图像缩小时，图像周围空余部分采用黑色背景填充。

此外，考虑到工业生产现场的粉尘会对采集轴瓦图像造成不良影响，因此为了提高模型对于图像噪声的抗干扰能力，增强鲁棒性，本文提出添加高斯噪声的方法对轴瓦表面缺陷数据进行增强。每幅图像随机添加均值 $\mu=0$ ，方差 σ^2 为 $0.001\sim 0.01$ 的高斯噪声。各数据增强方法的示例如图 3.3 所示。




图 3.3 轴瓦表面缺陷数据集单样本增强示例

如上文图 2.11 所示，轴瓦表面缺陷数据集中的小目标所占比例为 18.41%，与中目标、大目标相比的所占比重较低，数量相对不足。这种缺陷尺度不平衡问题意味着可供模型学习的小目标特征较少，造成模型对于小目标的学习效果较差，从而导致微小缺陷的检测性能较低。因此，为了改善轴瓦表面缺陷数据集中不同尺度目标的数量不平衡所带来的影响，提高模型对于微小缺陷的检测性能，本文在上述单样本数据增强方法的基础上，进一步提出了一种基于多样本融合的混合样本数据增强方法。该方法分别对四幅轴瓦图像采用单样本增强方法进行随机变换，然后将各个图像分辨率调整至原始分辨率的 50% 后进行拼接，形成一幅与原始图像分辨率相同的增强图像。由于本文所定义的最大缩放倍数为 2.00，所以经过缩放 50% 再拼接所产生的增强图像中，除先前缩放 2.00 倍的图像之外，其余子图像中的目标尺寸均小于原始图像中的目标尺寸。因此，混合样本数据增强方法为轴瓦表面缺陷数据集引入了大量小目标，且单幅增强图像同时包含有四幅原始图像的信息，使得模型可以学习的特征更为丰富，有助于提升缺陷检测性能。图 3.4 为混合样本数据增强的原理示意图，虚线框内的图(a)~(d)代表四幅不同的原始图像，首先对四幅图像分别执行图中所示的旋转、平移、翻转、缩放、添加高斯噪声等操作后，再将各图像缩放为原始分辨率的 50%，最后将缩放后的图像按图

示位置进行拼接，即可获取增强图像。




图 3.4 轴瓦表面缺陷数据集混合样本增强示例

本节开展了消融实验以验证上述数据增强方法的有效性，实验过程中采用与 3.3 节相同的软硬件环境及模型实验参数，实验中的数据增强流程如图 3.5 所示。




图 3.5 轴瓦表面缺陷数据增强流程图

训练模型的过程中采用在线增强方法，每次从数据集中加载一个批次(Batch)的图像，其中包含 Batch Size 张图像，并随机选择执行单样本数据增强或者混合样本数据增强。当执行单样本数据增强时，从 Batch 中按顺序取出 1 幅图像，依次随机执行旋转、平移、翻转、缩放、添加高斯噪声等方法，其中各方法的参数在上文设定的范围内随机选取，最终将增强后的图像输入模型。当执行混合样本

数据增强时，首先从 Batch 中随机取出 4 幅图像，然后对 4 幅图像分别执行单样本数据增强，接着将缩放 50%后的图像进行拼接，最终将增强图像输入模型中进行训练。以上所有数据增强方法仅应用于训练集，而测试集保持不变。

表 3.5 为各模型引入上述数据增强方法后的消融实验结果。观察表中数据可知，引入旋转变换后，各模型的检测精度相比于未采用数据增强的模型而言均有不同程度的提升，提升幅度约为 1.0~2.5%。将旋转变换依次与其他四种单样本数据增强方法相结合时，模型检测精度呈现逐步提高的趋势，其中引入平移变换时，各模型检测精度大约提升 0.5~1.5%；引入翻转、高斯噪声时，各模型检测精度提升幅度相对较小，普遍不足 1.0%；而引入缩放变换时，检测精度提升幅度约为 1.0~2.0%。在各个单样本数据增强方法随机组合的基础上，进一步引入混合样本数据增强时，除 SSD 的精度提升幅度为不足 1.0%之外，其余三种模型的检测精度提升幅度均为 1.5~2.5%，提升幅度相对较大。最终，将本文提出的所有数据增强方法相结合时，各模型的检测精度相比于无数据增强的情况有了显著提升，Faster R-CNN、R-FCN、SSD、YOLOv3 的 mAP 提升幅度分别达到 8.29%、6.40%、6.41%、7.11%，表明本文所提出的数据增强方法可以有效提高轴瓦表面缺陷数据集中的样本丰富程度，从而增强模型对于各类缺陷的检测性能。

表 3.5 各模型数据增强检测精度消融实验结果对比

数据增强方法						mAP/%			
旋转	平移	翻转	缩放	高斯噪声	混合增强	Faster R-CNN	R-FCN	SSD	YOLOv3
						83.35	86.49	79.51	85.11
√						85.72	87.58	81.12	86.85
√	√					86.52	88.15	82.80	88.30
√	√	√				86.90	88.63	82.95	88.81
√	√	√	√			88.97	90.02	84.63	90.09
√	√	√	√	√		89.38	90.75	85.04	90.57
√	√	√	√	√	√	91.64	92.89	85.92	92.22

3.4.2 数据集扩充规模与缺陷检测性能消融实验

上节实验结果证明了数据增强在轴瓦表面缺陷数据集中对于提高模型检测

精度的有效性。除了上述在线数据增强的方法,利用旋转、平移、缩放等数据增强方法,理论上可以实现数据集的无限扩充。因此,为了进一步探究数据集扩充规模与缺陷检测精度之间的关系,本节开展了三组消融实验。实验过程中所采用的软硬件环境以及模型实验参数与3.3节相同。同时,三组消融实验分别采用旋转、平移、缩放变换对轴瓦表面缺陷数据集进行扩充,扩充时采用离线增强方法对训练集中的全部样本按照相应参数进行变换,扩充后的数据集规模与变换参数的数量成正比。其中,采用旋转方法时,图像分别顺时针旋转 $45^{\circ}\sim 315^{\circ}$,旋转增量为 45° ,最多包括7种组合方式,表明数据集规模最大可扩充7倍;采用平移方法时,图像分别向右平移长边尺寸的 $1/8$ 、 $1/6$ 、 $1/4$ 、 $1/3$ 、 $1/2$,最多包括5种组合方式,数据集规模至多可扩充5倍;采用缩放方法时,分别将图像缩放0.50、0.75、1.25、1.50、1.75、2.00倍,最多包括6种组合方式,数据集规模可扩充6倍。经过上述各方法处理后的图像中的空余区域均通过黑色背景填充。在此基础上,分别对Faster R-CNN、R-FCN、SSD、YOLOv3模型进行训练,实验结果如表3.6~3.8所示。

通过表3.6中数据可知,随着轴瓦图像旋转角度种类的增加,数据集规模不断增大,但各模型检测精度呈现出先增大后减小的变化规律。其中,Faster R-CNN、R-FCN、YOLOv3在第5种组合的数据集上取得检测精度最大值,而SSD则在第6种组合的数据集上取得最高检测精度。类似地,表3.7中的数据同样反映出,当采用平移方法对轴瓦表面缺陷数据集进行扩充时,模型检测精度随着平移比例种类的增加,呈现出先增大后减小的变化规律。其中,Faster R-CNN、YOLOv3的mAP在平移比例为 $1/8$ 、 $1/6$ 、 $1/4$ 、 $1/3$ 的组合时达到最大值86.23%、87.34%,而R-FCN和SSD的mAP在平移比例为 $1/8$ 、 $1/6$ 、 $1/4$ 的组合时达到最大值88.74%、81.43%。此外,表3.8中的数据也展现出类似的规律,各模型检测精度随着数据集中缩放比例种类的增多而呈现出先增大后减小的变化趋势。其中,Faster R-CNN、R-FCN、SSD在数据集规模扩充为5倍时取得最高检测精度,而YOLOv3则在数据集规模扩充为4倍时取得检测精度最大值87.63%。

表 3.6 旋转角度与各模型检测精度关系

数据集	旋转角度							mAP/%			
	45°	90°	135°	180°	225°	270°	315°	Faster R-CNN	R-FCN	SSD	YOLOv3
1								83.35	86.49	79.51	85.11
2	√							84.02	87.56	80.03	86.08
3	√	√						84.28	87.98	80.38	86.36
4	√	√	√					84.74	88.65	80.49	86.97
5	√	√	√	√				85.31	88.98	80.77	87.58
6	√	√	√	√	√			85.09	87.82	81.35	87.43
7	√	√	√	√	√	√		84.62	87.41	80.86	87.25
8	√	√	√	√	√	√	√	84.11	87.31	80.42	86.71

表 3.7 平移比例与各模型检测精度关系

数据集	平移比例					mAP/%			
	1/8	1/6	1/4	1/3	1/2	Faster R-CNN	R-FCN	SSD	YOLOv3
1						83.35	86.49	79.51	85.11
2	√					84.98	87.89	80.77	86.21
3	√	√				85.52	88.44	81.20	86.67
4	√	√	√			85.89	88.74	81.43	86.81
5	√	√	√	√		86.23	88.23	81.29	87.34
6	√	√	√	√	√	85.75	87.74	80.96	86.85

表 3.8 缩放比例与各模型检测精度关系

数据集	缩放比例						mAP/%			
	0.50	0.75	1.25	1.50	1.75	2.00	Faster R-CNN	R-FCN	SSD	YOLOv3
1							83.35	86.49	79.51	85.11
2	√						84.83	88.22	81.66	87.14
3	√	√					85.41	88.70	82.22	87.52
4	√	√	√				85.80	88.97	82.56	87.63
5	√	√	√	√			86.33	89.14	82.87	87.44
6	√	√	√	√	√		86.09	88.55	82.35	87.37
7	√	√	√	√	√	√	85.74	88.11	82.01	86.96

上述实验结果表明，在采用旋转、平移、缩放等方法进行数据增强时，随着数据集规模的不断增大，各模型对于轴瓦表面缺陷的检测精度并没有持续提高，三种方法均存在对应的检测精度极大值。尽管数据增强在理论上可以令数据集规模无限扩大，但当轴瓦表面缺陷数据集的规模超过某个临界值后，模型检测精度

反而会下降。造成该现象的主要原因可能是：与原始图像相比，数据增强方法生成的图像中可供模型学习的信息有限。当扩充规模过大时，数据集中原始样本所占比重过小，模型的训练过程由增强图像主导，而非原始图像，从而导致模型所学习到的特征与实际情况存在较大差异，出现过拟合现象，造成检测精度下降。

3.5 基于深度迁移学习的缺陷检测性能改进

考虑到本文构建的轴瓦表面缺陷数据集的规模有限，在随机初始化权重的前提下，模型直接从头开始训练，梯度更新的过程中容易出现梯度消失现象，使得权重参数变化较小且更新速度慢，进而可能造成模型训练不够充分，陷入局部最优解。因此本文在数据增强的基础上，提出了基于深度迁移学习的模型训练过程改进方法，以进一步提升轴瓦表面缺陷检测性能。

3.5.1 深度迁移学习及模型微调

深度迁移学习的思想是将模型在一个问题（源域）中训练所学习到的知识迁移到新问题（目标域）中，以提升解决新问题的效果^[91]，从而解决深度学习任务中数据量较少的问题。假设一个域可以用 $D\{\mathcal{X}, P(X)\}$ 表示，其中 $\mathcal{X}$ 表示特征空间， $P(X)$ 为特征空间 $\mathcal{X}$ 中的集合 $X = \{x_1, \dots, x_n\}$ 的边缘概率分布。同时，一个任务可以用 $T\{y, f(x)\}$ 表示，其中 y 为表示标签空间， $f(x)$ 表示目标检测函数，也可以看作条件概率函数 $P(y|x)$ ，则深度迁移学习的原理如图 3.6 所示。




图 3.6 深度迁移学习原理图

上图中，给定源域为 D_s 、目标域为 D_t 、源任务为 T_s 、目标任务为 T_t ，其中源

域的样本数通常远大于目标域的样本数, 即 $D_s \gg D_t$, 且源任务和目标任务通常不相同, 即 $T_s \neq T_t$ 。于是深度迁移学习的作用可以表述为“找到将源域和源任务中包含的潜在知识转移到目标域和目标任务中的方法, 以提高目标任务中的目标检测函数 $f_t(x)$ 的性能表现”。

模型微调是深度迁移学习的一种具体实现方法, 其实现过程是将模型事先在大型数据集 (ImageNet、PASCAL VOC、COCO 等) 上训练得到的预训练权重加载到模型中作为初始化权重, 以取代随机初始化权重方法, 并根据目标数据集与源数据集之间的相似程度以及目标数据集的规模对预训练模型结构进行调整, 然后在目标数据集上重新训练模型, 以达到较好的训练效果。这相当于让模型从一个良好的起点开始学习, 节省算力的同时可以从一定程度上降低训练模型所需的时间。此外, 由于模型已经经过了大量数据的训练, 因此可以通过更少的额外数据训练出期望的模型, 并改善过拟合现象。模型微调的有效性主要来源于卷积神经网络对于特征提取的普适性。




图 3.7 卷积核可视化^[92]

图 3.7 所示为某分类任务的卷积神经网络在 ImageNet 数据集上训练后的前三层特征可视化结果^[92]。从图中可以看出, 网络在低层所提取的特征较为具体, 主

要包括图像中的边缘、纹理、角点、颜色等，而随着网络层次的加深，提取的特征逐渐转变为更高级的语义特征。由于低层特征对于大多数图像而言是具有普适性的，因此即使源数据集中并不包含缺陷样本，也依然可以用来提取通用特征并应用在缺陷检测任务中。

3.5.2 深度迁移学习改进缺陷检测性能结果分析

本节采用与 3.3 节相同的软硬件环境，并使用 COCO 2017 数据集作为源数据集来开展深度迁移学习实验。COCO 数据集是微软公司于 2014 年首次发布的大型目标检测数据集，其中包括 80 类物体，例如人、汽车、飞机等，共计 20 万张带有标注的图像。考虑到本文构建的轴瓦表面缺陷数据集的规模相对较小，且 COCO 2017 数据集与轴瓦表面缺陷数据集相似程度不高，因此采用冻结低层网络，并训练高层网络及分类器的模型微调方法对各模型进行训练。

训练过程中，分别加载各模型在 COCO 2017 数据集上的预训练权重，并冻结 Faster R-CNN、R-FCN 的前 22 层卷积层，SSD 的前 9 层卷积层，以及 YOLOv3 的前 27 层卷积层。被冻结的层在训练阶段的反向传播过程中不参与梯度下降，因此权重参数不会被更新。在冻结指定的卷积层之后，各模型其余实验参数与 3.3 节保持一致，同时采用 3.4.1 节所述的单样本及混合样本数据增强方法，对数据集进行增广，然后对剩余网络层与分类器进行训练。

图 3.8 为各模型训练过程中的准确率（Accuracy）曲线与损失（Loss）曲线，其中准确率表示预测正确的样本占样本总数的比例。观察曲线可知，随着训练迭代次数的增加，各模型的准确率都快速提高，并在第 70 次迭代后趋于稳定。在随机初始化权重的条件下，Accuracy 曲线波动幅度较大，且初始准确率较低。而在深度迁移学习的条件下，各模型的初始准确率更高，Accuracy 曲线波动幅度更小，表明模型更容易向正确方向收敛，收敛后的模型准确率均提高了 2% 左右。同时，各模型训练过程中，Loss 曲线的值不断减小，并在第 70 次迭代后趋于稳定，采用深度迁移学习对模型进行训练时的 Loss 曲线下降更快，波动幅度更小，且最终的 Loss 值低于随机初始化权重训练的模型。以上结果证明了使用深度迁移学习改

进 Faster R-CNN、R-FCN、SSD、YOLOv3 模型在轴瓦表面缺陷数据集上训练效果的有效性。




图 3.8 各模型训练准确率曲线与损失曲线

图 3.9 为以 YOLOv3 模型为例的特征图可视化结果，通过观察特征图可以了解到模型对于图像特征的提取过程。下图中(a)为输入到模型中的原始轴瓦图像，(b)~(f)分别为特征图随着 YOLOv3 特征提取网络中残差块组数逐渐增多而发生的變化。从图中可以观察到不同特征图对于特征提取的侧重点各不相同，一部分特征图关注于轴瓦图像背景的提取，而另一部分特征图则着重进行轴瓦轮廓、油孔、污渍等特征的提取。随着网络层次的加深，纹理、形状等浅层特征逐渐减少，图像细节逐渐消失，取而代之的是不断丰富的高层语义特征，此时图像的特征较为抽象，难以辨别。




图 3.9 YOLOv3 轴瓦特征图可视化

表 3.9 为引入深度迁移学习前后各模型的检测精度对比，表中左栏数据为随机初始化权重条件下的结果，右栏数据为引入深度迁移学习方法后的结果。观察表中数据可知，Faster R-CNN、R-FCN、YOLOv3 模型的检测精度仍然相差不大，而 SSD 模型的检测精度则较低，各模型的检测精度相比于随机初始化权重的模型精度均有不同程度的提高。其中，划痕和擦伤两种缺陷的提升幅度相对较大，约为 2~3%，凹坑和污渍缺陷的提升幅度次之，约为 1~2%，油孔、油槽由于在先前的条件下已经达到很高的检测精度，因此提升幅度普遍不足 0.5%。

表 3.9 深度迁移学习方法改进前后的各模型检测精度对比

检测模型	随机初始化权重/深度迁移学习检测精度 AP(%)					
	凹坑	划痕	擦伤	污渍	油孔	油槽
Faster R-CNN	89.36/91.36	85.15/88.15	86.03/88.16	91.37/92.03	98.58/99.01	99.32/99.60
R-FCN	90.18/91.89	87.85/90.90	88.21/90.43	92.69/93.24	98.84/99.17	99.56/99.62
SSD	80.56/82.93	79.39/82.50	75.92/79.82	84.23/86.25	96.61/97.58	98.85/99.03
YOLOv3	90.37/92.19	86.73/90.69	87.96/89.88	90.31/92.96	98.55/98.93	99.41/99.52

表 3.10 为各模型在使用深度迁移学习方法训练前后，对于轴瓦表面缺陷的检

测性能指标对比，表中左栏数据为随机初始化权重条件下的结果，右栏数据为引入深度迁移学习方法后的结果。观察表格数据可知，除 SSD 模型外，其余各模型的精确率、召回率、F1 值、mAP 相比于随机初始化权重训练的模型均有不同程度的提高，各指标整体提升幅度约为 0.5~2%。此外，各模型的检测耗时与随机初始化权重训练的模型相比并无显著变化。

表 3.10 深度迁移学习方法改进前后的各模型检测性能指标对比

检测模型	精确率/%	召回率/%	F1 值/%	mAP/%	检测耗时/ms
Faster R-CNN	94.13/95.22	90.69/91.26	92.37/93.19	91.64/93.05	326.68/327.47
R-FCN	95.79/96.12	91.96/92.77	93.84/94.42	92.89/94.20	203.95/202.59
SSD	89.54/91.17	82.39/85.51	85.82/88.25	85.92/88.01	40.43/41.49
YOLOv3	94.43/95.60	90.60/92.29	92.48/93.92	92.22/94.02	26.12/25.91

表 3.11 为各模型对于不同尺度目标的检测精度对比，表中左栏数据为随机初始化权重条件下的结果，右栏数据为引入深度迁移学习方法后的结果。观察表中数据可知，在随机初始化权重的条件下，各模型对于小尺寸目标的检测精度偏低，AP 值均未达到 90%，对于大尺寸目标的检测精度则较高，普遍可达 95%以上。整体而言，Faster R-CNN、R-FCN、YOLOv3 三种模型对于小尺寸、中尺寸目标的检测精度显著高于 SSD 模型。在使用深度迁移学习方法进行训练后，各模型对于不同尺寸目标的检测精度均有一定程度的提高，小目标提升幅度约为 1.5~2.5%，中目标提升幅度约为 0.5~1.5%，大目标提升幅度较小，约为 0.5%。

表 3.11 深度迁移学习方法改进前后的多尺度目标检测精度对比

检测模型	随机初始化权重/深度迁移学习检测精度 AP(%)		
	小目标	中目标	大目标
Faster R-CNN	86.06/88.42	90.57/91.90	97.29/97.44
R-FCN	88.52/90.79	92.23/92.88	97.46/98.28
SSD	79.65/81.24	83.82/85.05	95.71/96.32
YOLOv3	87.66/89.85	91.58/92.71	97.30/98.01

图 3.10 为各模型在深度迁移学习条件下训练后的一组检测效果对比图，其中轴瓦图像与图 3.2 相同。与图 3.2 相比，四种模型对于各类缺陷的检测置信度均有不同程度的提升。




图 3.10 采用深度迁移学习方法训练的各模型检测效果对比图

其中, Faster R-CNN 对于各类缺陷的置信度提升幅度为 0.03~0.08; R-FCN 对于各类缺陷的置信度提升了 0.08~0.16, 且预测框冗余问题消失; SSD 对于各类缺陷的置信度提升幅度为 0.02~0.10; YOLOv3 对于各类缺陷的置信度提升了 0.01~0.09。然而, Faster R-CNN 仍然存在预测框冗余问题, 且 SSD 依然未检出轴瓦右上边缘的凹坑, 同时, YOLOv3 的预测框也存在一定的定位误差。

通过上述实验结果可知, 深度迁移学习方法对于 Faster R-CNN、R-FCN、SSD、YOLOv3 模型在轴瓦表面缺陷数据集上的检测性能具有一定的提升作用。其中 Faster R-CNN、R-FCN、YOLOv3 模型的检测性能指标相近, mAP 均可达到 93% 以上, SSD 模型的检测性能指标相对较差, mAP 仅为 88.01%, 对于小目标及不明显缺陷的漏检问题较为严重。实际检测效果方面, Faster R-CNN、R-FCN 在个别图像中存在预测框冗余问题, 且检测耗时较长, 达到数百毫秒量级。相比之下, SSD 与 YOLOv3 为 One-stage 模型, 检测耗时较少, 其中 YOLOv3 模型对于各类缺陷的整体检测精度良好, 与 R-FCN 相近, 且检测速度在上述四种模型中最高, 考虑到工业生产中对于检测精度以及检测效率的要求, 因此本文选用兼具检测精度与效率的 YOLOv3 作为下文进一步研究轴瓦表面缺陷检测的基础模型。

然而, 尽管 YOLOv3 模型在采用数据增强、深度迁移学习等数据层面的改进方法进行训练后的 mAP 已达到 94.02%, 但其仍然存在部分缺陷容易漏检以及预测框定位误差较大等问题。如图 3.11 所示, 图(a)中存在反光区域凹坑漏检问题, 图(b)中存在微小污渍漏检问题, 图(c)中存在划痕漏检问题, 图(d)中存在预测框定位误差较大问题。上述问题的存在使 YOLOv3 模型距离在工业生产环境中应用还有一定的差距, 因此本文将在后续章节从模型结构以及损失函数的角度, 进一步开展提升轴瓦表面缺陷检测精度的研究工作。




图 3.11 YOLOv3 模型各类检测异常情况

3.6 本章小结

本章主要研究了数据增强及深度迁移学习方法对于轴瓦缺陷检测性能的提升效果。首先, 采用随机初始化权重的模型训练方法对 Faster R-CNN、R-FCN、SSD、YOLOv3 四种经典目标检测模型开展了训练, 以评价轴瓦表面缺陷数据集的基准性能; 其次, 提出了单样本以及混合样本在线数据增强方法, 并通过消融实验得出各模型的 mAP 相比于未进行数据增强的情况分别提升了 8.29%、6.40%、6.41%、7.11%, 证明了数据增强的有效性; 再次, 通过消融实验探究了数据集扩充规模与缺陷检测性能之间的关系, 实验结果表明, 轴瓦表面缺陷检测性能并不会随着数据集扩充规模的增大而无限提高; 随后, 引入了深度迁移学习方法对模型训练过程进行了改进, 实验结果表明, 该方法可以有效提升缺陷检测性能; 最后, 综合考虑各模型对于轴瓦表面缺陷的检测效果与检测时间等因素的影响, 选择其中兼顾检测精度与检测效率的 YOLOv3 模型作为后续研究的基础模型, 其 mAP 可达 94.02%, 检测耗时仅为 25.91ms。

第4章 YOLO-Bush 模型结构与损失函数研究

4.1 引言

本章介绍了 YOLOv3 模型的原理，并据此针对其在检测轴瓦表面缺陷过程中存在的漏检以及预测框定位误差等问题进行了改进。首先，提出了基于 YOLOv3 的多特征融合与通道特征增强模型，以提高模型对于缺陷的识别能力；其次，引入了 K-means++ 聚类算法对锚框数量与尺寸进行优化；再次，提出了基于 DIoU 与 Focal Loss 相结合的损失函数改进方法，以提高预测框定位精度，并动态调节数据集中难易样本的权重，增强模型训练效果；随后，通过消融实验证明了各改进方法的有效性，据此提出 YOLO-Bush 模型；最后，开展了 YOLO-Bush 模型综合实验，对其实际检测效果进行了验证。YOLOv3 模型的改进流程如图 4.1 所示。




图 4.1 YOLOv3 模型改进流程图

4.2 YOLOv3 模型结构及检测原理

4.2.1 模型基本结构

YOLOv3 模型的特征提取网络为 DarkNet-53，该网络采用全卷积结构代替传

统卷积神经网络中的池化层，以避免池化层在特征提取过程中所造成的信息丢失。DarkNet-53 网络中的卷积核只有 1×1 和 3×3 两种尺寸，总计包含 52 个用于特征提取的卷积层以及 1 个用于获取全局特征向量的连接层。图 4.2 所示为 DarkNet-53 的结构，其中共包含 23 个残差单元和 5 个步长为 2 的单独的卷积层，步长为 2 的卷积层的作用是降低特征图的维度（图中未注明的卷积核步长为 1，下同），以提高计算效率，引入残差单元的目的是为了简化深层网络的训练，解决梯度消失问题^[93]。其中，每个残差单元包括一个 1×1 和 3×3 卷积层，且每个卷积层又由三个连续的操作组成：卷积、批量归一化^[94]、Leaky ReLU^[95]。在每个残差单元的末尾，输入和输出向量之间会将元素逐个相加。

数量	层类型	卷积核		输出尺寸
		数量	尺寸/步长	
1×	卷积层	32	3×3	608×608
	卷积层	64	3×3/2	304×304
	卷积层	32	1×1	304×304
	卷积层	64	3×3	
	残差单元			
2×	卷积层	128	3×3/2	152×152
	卷积层	64	1×1	152×152
	卷积层	128	3×3	
	残差单元			
	8×	卷积层	256	3×3/2
卷积层		128	1×1	76×76
卷积层		256	3×3	
残差单元				
8×		卷积层	512	3×3/2
	卷积层	256	1×1	38×38
	卷积层	512	3×3	
	残差单元			
	4×	卷积层	1024	3×3/2
卷积层		512	1×1	19×19
卷积层		1024	3×3	
残差单元				

图 4.2 DarkNet-53 网络结构

图 4.3 为 YOLOv3 的网络结构示意图。YOLOv3 借鉴了特征金字塔网络(FPN)在小尺寸目标检测中的思想，构建了一个三层特征金字塔，分别采用 32、16、8 为倍数对输入图像进行降采样，输出原始图像尺寸 $1/32$ 、 $1/16$ 和 $1/8$ 的特征图，每一种尺寸的特征图都对应于检测一种不同尺度的物体，以实现不同目标的多尺度预测。在多尺度预测的过程中，网络首先将输入图像缩放为固定大小 608×608 ，

然后对输入图像进行 32 倍降采样, 得到 19×19 大小的特征图, 该特征图具有较大的感受野, 可用于大尺度目标检测; 接着对该结果进行上采样, 并与 16 倍降采样的结果进行张量拼接与卷积运算, 以获得 38×38 大小的特征图, 用于检测中等尺度的目标; 随后继续对上述结果进行上采样, 并与 8 倍降采样的结果进行张量拼接, 再进行卷积, 得到 76×76 大小的特征图, 该特征图的感受野较小, 适用于小目标的检测。上述三种尺寸特征图中的每个网格需要预测 3 个边界框, 每个边界框具有横坐标、纵坐标、宽度、高度、置信度 5 个参数以及各类别的条件概率, 以本文的轴瓦表面缺陷数据集为例, 该数据集中共包括 6 类目标, 每个边界框需要预测 6 个类别的物体, 因此特征图的通道数是 $3 \times (5+6)=33$ 。




图 4.3 YOLOv3 网络结构示意图

4.2.2 边界框预测原理

YOLOv3 参考了 Faster R-CNN 中的锚框机制, 用于在训练模型的过程中确定并调整预测边界框的位置。锚框是一组宽度和高度固定的先验边界框, 其作用是检测特定尺度及宽高比的对象, 锚框的尺寸和比例将直接影响模型在目标检测中的精度和速度。依据检测任务的不同, 锚框的数量以及尺寸可以自由调整, 通常

来说，锚框数量越多，预测边界框的位置也更加容易，但所需的计算成本也更高。YOLOv3 通过 K 均值（K-means）聚类算法^[96]对 COCO 数据集中的真实框尺寸进行聚类，确定了 9 种不同尺寸的锚框，将这 9 种锚框平均分配至 3 种尺度的特征图中，则每种特征图对应于 3 种尺寸的锚框，如表 4.1 所示。

表 4.1 YOLOv3 锚框尺寸

特征图尺度	52×52	26×26	13×13
感受野大小	小	中	大
锚框尺寸	10×13	30×61	116×90
	16×30	62×45	156×198
	33×23	59×119	373×326

由图 4.3 可知，YOLOv3 通过 3 种不同尺度的输出特征图将输入图像分别划分为 19×19 、 38×38 、 76×76 个网格，在预测阶段，如果目标的中心落入某个网格，则由当前网格对目标进行检测。每个网格单元定义了边界框及其相应的置信度得分，置信度反映了网格包含目标的概率以及边界框预测的精度，其定义如下式 (4-1) 所示，如果目标的中心落在网格中，则 $P(Object)=1$ ，否则 $P(Object)=0$ ， IoU_{pred}^{truth} 为上文 2.4 节所述的交并比，表示预测边界框和真实框之间的重叠程度。

$$Confidence = P(Object) \times IoU_{pred}^{truth}$$

(4-1)

图 4.4 为 YOLOv3 边界框预测原理示意图，其中 (t_x, t_y) 表示边界框中心点到当前所在网格的左上角点之间的水平、竖直距离， (c_x, c_y) 表示当前边界框中心点所在的网格到特征图左上角点之间的偏移量， (p_w, p_h) 表示锚框的宽度和高度。




图 4.4 边界框预测原理

在对边界框进行预测之前，YOLOv3 会根据置信度阈值过滤掉置信度小于阈值的边界框，然后通过非极大值抑制（NMS）算法筛选出剩余边界框中置信度得分最高的一个。通过这种方法可以去除重复的边界框，减少计算量，提升模型运算速度。在预测边界框的过程中， t_x 和 t_y 会通过 Sigmoid 函数进行归一化，得到 $\sigma(t_x)$ 与 $\sigma(t_y)$ 。最终经过修正的预测边界框位置 (b_x, b_y, b_w, b_h) 的表达式如图 4.4 所示。

4.2.3 损失函数

YOLOv3 的损失函数由三部分组成，分别为坐标预测损失函数（均方差）、置信度损失函数（交叉熵）、目标类别损失函数（交叉熵），如公式（4-2）所示：

$$Loss = \sum_{i=0}^{S^2} (Error_{coord} + Error_{iou} + Error_{class}) \quad (4-2)$$

公式（4-2）第一项 $Error_{coord}$ 代表坐标预测损失，表达式如下：

$$\begin{aligned} Error_{coord} = & \lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{obj} \left[(x_i^j - \hat{x}_i^j)^2 + (y_i^j - \hat{y}_i^j)^2 \right] \\ & + \lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{obj} \left[\left(\sqrt{w_i^j} - \sqrt{\hat{w}_i^j} \right)^2 + \left(\sqrt{h_i^j} - \sqrt{\hat{h}_i^j} \right)^2 \right] \end{aligned} \quad (4-3)$$

其中 λ_{coord} 代表坐标损失的权重，其取值通常为 $\lambda_{coord} = 5$ ， S^2 表示网格数量， B 代表每个网格中边界框的数量， I_{ij}^{obj} 代表是否有一个对象落在第 i 个网格中的第 j 个边界框中。 $x_i^j, y_i^j, w_i^j, h_i^j$ 分别代表第 i 个网格中的第 j 个预测框中心的横纵坐标及宽度、高度， $\hat{x}_i^j, \hat{y}_i^j, \hat{w}_i^j, \hat{h}_i^j$ 分别代表第 i 个网格中的第 j 个真实框中心的横纵坐标、宽度、高度。

公式（4-2）第二项 $Error_{iou}$ 代表置信度损失，其定义为：

$$\begin{aligned} Error_{iou} = & - \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{obj} [\hat{C}_i^j \log(C_i^j) + (1 - \hat{C}_i^j) \log(1 - C_i^j)] \\ & - \lambda_{noobj} \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{noobj} [\hat{C}_i^j \log(C_i^j) + (1 - \hat{C}_i^j) \log(1 - C_i^j)] \end{aligned} \quad (4-4)$$

其中 λ_{noobj} 表示网格中没有对象时的置信度损失，其取值通常为 $\lambda_{noobj} = 0.5$ ，而

C_i^j 和 $\hat{C}_i^j$ 分别代表第 i 个网格中的第 j 个边界框的预测置信度和真实置信度。

公式 (4-2) 第三项 $Error_{class}$ 代表分类损失，其定义为：

$$Error_{class} = - \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{obj} \sum_{c \in classes} [\hat{P}_i^j \log(P_i^j) + (1 - \hat{P}_i^j) \log(1 - \hat{P}_i^j)] \quad (4-5)$$

其中 c 表示目标的类别总数， $P_i^j(c)$ 和 $\hat{P}_i^j(c)$ 分别代表第 i 个网格中的第 j 个边界框中类别的预测概率和真实概率。

4.3 基于 YOLOv3 的多特征融合与通道特征增强模型

针对 YOLOv3 模型在检测轴瓦表面缺陷的过程中存在的反光区域缺陷、微小缺陷、划痕擦伤缺陷难以检测的问题，本文提出了四种 YOLOv3 网络结构改进方法，通过对不同网络层的多种特征进行融合，增强 YOLOv3 模型的特征提取能力，以解决上述缺陷难以检测的问题。

4.3.1 基于 DenseNet 稠密块的深浅层特征融合

卷积神经网络中的每一层提取特征的过程都可以看做是对输入进行的一种非线性变换。随着网络层次的不加深，多个非线性变换叠加后，变换的复杂度增大，导致特征在传递的过程中会出现部分信息丢失的问题。当数据集中的训练样本数量相对匮乏时，模型容易出现过拟合现象，导致泛化能力不强，检测效果较差。因此，本文提出了一种引入 DenseNet 稠密块以替换残差块的 DarkNet-53 网络改进方法，从而实现深浅层特征融合，加强梯度信息传递及特征复用，增强 YOLOv3 模型对于轴瓦表面划痕、擦伤等难检测缺陷的检测性能。

稠密连接网络^[97] (DenseNet) 是 2017 年 CVPR 会议上提出的一种卷积神经网络，该网络可以通过跳跃连接的方式将网络中每一层与之前的所有层相连，使得当前层能够接收其之前所有层的特征作为输入。DenseNet 的稠密连接机制如图 4.5 所示。




图 4.5 DenseNet 稠密连接机制示意图

DenseNet 由稠密块、瓶颈层、过渡层三种结构组成，DenseNet 通常包含多个稠密块，不同稠密块之间采用过渡层进行连接，过渡层由“批量归一化、 1×1 卷积、 2×2 平均池化”的组合操作构成，用于改变输出特征图的尺寸。稠密块由多个稠密层组成，且每个稠密层中包含“批量归一化、ReLU 激活函数、 3×3 卷积”三个连续操作，稠密层的结构如图 4.6 所示。




图 4.6 稠密层结构

设稠密块的输入为 $\mathbf{X}_0$ ，稠密块中的某层为 i ，第 i 层的输出为 $\mathbf{X}_i$ ，将第 0 到 $i-1$ 层特征图的张量拼接表示为 $[\mathbf{X}_0, \mathbf{X}_1, \dots, \mathbf{X}_{i-1}]$ ，每一个稠密层实现一个由“批量归一化、ReLU 激活函数、 3×3 卷积”组成的非线性变换 H_i ，则稠密块的输出 $\mathbf{X}_i$ 可通过下式计算：

$$\mathbf{X}_i = H_i([\mathbf{X}_0, \mathbf{X}_1, \dots, \mathbf{X}_{i-1}]) \quad (4-6)$$

对于一个 L 层的稠密块而言， $\mathbf{X}_1$ 层有 1 个输入层， $\mathbf{X}_2$ 层有 2 个输入层， $\mathbf{X}_3$ 层有 3 个输入层，以此类推，第 i 层的输入包含了之前 $i-1$ 个卷积层的输出，具有 i 个输入层。如果稠密块的输入 $\mathbf{X}_0$ 的维度为 m ，每个稠密层输出特征图的通道数为 k ，则第 i 层的输入特征图个数为 $m + (i-1) \times k$ ，因此整个稠密块中各个稠密层的输入特征图总数为 $\sum_{i=0}^L m + (i-1) \times k$ ，对于数量如此庞大的特征图直接进行 $3 \times$

3 卷积运算会导致计算量过大，所以 DenseNet 在稠密层中的 3×3 卷积层前引入 1×1 卷积层构成瓶颈结构，通过 1×1 卷积生成 $2k$ 通道的特征图，再通过 3×3 卷积输出 k 通道的特征图，以减小特征维度和计算量，从而提高模型计算效率，图 4.7 为具有瓶颈结构的稠密层。




图 4.7 具有瓶颈结构的稠密层

与残差网络相比，DenseNet 所提取的特征信息既包含浅层细节特征，又包含深层语义特征，最大程度地保留了输入图像的原始特征，可实现不同维度的特征复用与融合，同时增强了梯度的反向传播，在一定程度上缓解了梯度消失的问题。

本文提出的具有 DenseNet 稠密块结构的特征提取网络如图 4.8 所示。该网络保留了 DarkNet-53 中输出为 304×304 和 152×152 的两组残差块，将另外三组输出为 76×76 、 38×38 、 19×19 的残差块替换为具有瓶颈结构的稠密块。

数量	层类型	卷积核		输出尺寸
		数量	尺寸/步长	
1×	卷积层	32	3×3	608×608
	卷积层	64	$3\times3/2$	304×304
	卷积层	32	1×1	304×304
	卷积层	64	3×3	
	残差单元			
2×	卷积层	128	$3\times3/2$	152×152
	卷积层	64	1×1	152×152
	卷积层	128	3×3	
	残差单元			
4×	卷积层	256	$3\times3/2$	76×76
	稠密层	128	1×1	76×76
	稠密层	64	3×3	
	卷积层	512	$3\times3/2$	38×38
4×	稠密层	256	1×1	38×38
	稠密层	128	3×3	
	卷积层	1024	$3\times3/2$	19×19
	稠密层	512	1×1	19×19
2×	稠密层	256	3×3	

图 4.8 引入稠密块的 YOLOv3 特征提取网络结构

上图中, 76×76 和 38×38 输出尺寸的稠密块分别由 4 组稠密层组成, 19×19 输出尺寸的稠密块由 2 组稠密层组成, 各稠密层中的激活函数由 ReLU 替换为 Leaky ReLU, 以避免梯度消失。此外, 各稠密块之间的连接依然沿用 DarkNet-53 中的步长为 2 的 3×3 卷积层, 用于改变输出特征图的尺寸, 最终输出特征图的尺寸与原始网络一致。

4.3.2 基于 SE 注意力机制模块的通道特征增强

卷积神经网络的核心为卷积层, 而卷积操作的过程是通过卷积核从先前的输入特征图学习到新特征图并输出, 该过程从本质上而言是卷积核对局部感受野中的特征进行融合, 包括 H 、 W 维度的空间特征融合以及 C 维度的通道间特征融合。然而, 卷积操作默认是对输入特征图的所有通道进行融合, 通道之间的相互关系被隐含在了卷积运算对于感受野中元素的相乘求和运算中, 并最终与空间特征融合在一起。这意味着传统卷积操作并没有考虑特征图不同通道之间的相互关系, 使得通道信息出现丢失。

为了使模型关注特征图各个通道中的重要信息, 增强模型对于轴瓦缺陷特征的提取能力, 本文提出了一种在 DarkNet-53 特征提取网络中引入 SE (Squeeze-and-Excitation) 注意力机制模块^[98]的 DarkNet-53 网络改进方法。SE 模块的结构如图 4.9 所示, 该模块通过自适应地为特征图的每个通道进行加权, 显式地建立了通道之间的相互依赖性模型, 使网络可以自适应地调整每个特征图的权重, 以增强卷积层对于不同重要程度通道的学习能力。这种注意力机制使模型更加关注对于目标任务有用的特征通道, 并抑制不重要的特征通道, 以平衡空间特征和通道特征。此外, SE 模块是通用的, 其可以被轻易地嵌入到现有的网络结构中, 并以较低的额外计算成本和模型复杂度带来网络性能的显著提升。




图 4.9 SE 模块的结构示意图

如上图所示, SE 模块主要由压缩(Squeeze)、激发(Excitation)、缩放(Scale)三个操作组成。设输入图像 $\mathbf{X}$ 的维度为 $H' \times W' \times C'$, 其中 H' 、 W' 、 C' 分别代表高度、宽度、通道数, 令 $s=1, 2, \dots, C'$ 作为输入图像 $\mathbf{X}$ 的通道数索引。图像经过特征映射运算 $\mathbf{F}_r$ 的操作后得到特征图 $\mathbf{U}=[\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_C]$, 其维度表示为 $H \times W \times C$, $\mathbf{u}_c$ 代表输出特征图的第 c 个通道; $\mathbf{F}_r$ 通常是由一系列卷积核 $\mathbf{V}=[\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_C]$ 所构成的卷积运算, $\mathbf{v}_c$ 代表第 c 个卷积核。上述卷积运算过程可以表示为下式 (4-7)、(4-8)。

$$\mathbf{F}_r: \mathbf{X} \rightarrow \mathbf{U}, \mathbf{X} \in \mathbb{R}^{H' \times W' \times C'}, \mathbf{U} \in \mathbb{R}^{H \times W \times C} \quad (4-7)$$

$$\mathbf{u}_c = \mathbf{v}_c * \mathbf{X} = \sum_{s=1}^{C'} \mathbf{v}_c^s * \mathbf{x}^s \quad (4-8)$$

由于卷积层的输出是通过所有通道求和产生的, 通道之间的相关性被隐藏在卷积核 $\mathbf{v}_c$ 中, 与卷积核所提取到的局部空间特征混合在一起, 很难获取足够的信息来提取通道之间的关系。因此 SE 模块首先通过压缩操作对通道上的整个空间特征进行编码, 采用全局平均池化将全局空间信息压缩到长度为 C 的通道特征描述子 $\mathbf{z}$ 中, 其中 z_c 为第 c 个通道的特征描述子, 如式 (4-9) 所示。

$$z_c = \mathbf{F}_{sq}(\mathbf{u}_c) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W \mathbf{u}_c(i, j) \quad (4-9)$$

在通过压缩操作获得通道特征描述子的基础上, SE 模块进一步通过激发操作生成每通道权重的集合, 即激活向量 $\mathbf{s}$ 。激发操作需要满足两个条件: 首先是该操作必须具有足够的灵活性, 以确保能够学习到不同通道之间的非线性相互依赖关系; 其次是该操作必须能够学习到非互斥的通道间关系, 以确保可以激活多个通道。因此, SE 模块使用包含两个全连接层的瓶颈结构, 结合 Sigmoid 函数的门控机制对通道特征进行激活, 如式 (4-10) 所示。

$$\mathbf{s} = \mathbf{F}_{ex}(\mathbf{z}, \mathbf{W}) = \sigma(\mathbf{W}_2 \delta(\mathbf{W}_1 \mathbf{z})) \quad (4-10)$$

式中, σ 表示 Sigmoid 函数, δ 表示 ReLU 非线性激活函数, $\mathbf{W}_1 \in \mathbb{R}^{\frac{C}{r} \times C}$ 、

$\mathbf{W}_2 \in \mathbb{R}^{C \times \frac{C}{r}}$ 为全连接层, 其中 $\mathbf{W}_1$ 起到对通道维度的降维作用, 超参数 r 为全连接层对于通道维度的放缩系数, 本文将其设置为 16, 以实现模型性能和复杂度之间的平衡。降维后的通道经过 ReLU 激活后借助 $\mathbf{W}_2$ 将通道维度恢复至与特征图 $\mathbf{U}$ 相同的维度, 然后经过 Sigmoid 函数将输出值调整为 0 到 1 之间的通道权重, 最后通过缩放操作将学习到的各个通道权重与特征图 $\mathbf{U}$ 上的原始特征相乘, 得到 SE 模块的最终输出 $\tilde{\mathbf{X}} = [\tilde{\mathbf{x}}_1, \tilde{\mathbf{x}}_2, \dots, \tilde{\mathbf{x}}_C]$ 。缩放操作的计算过程如下式 (4-11) 所示。

$$\tilde{\mathbf{x}}_c = \mathbf{F}_{scale}(\mathbf{u}_c, \mathbf{s}_c) = \mathbf{s}_c \mathbf{u}_c \quad (4-11)$$

式中, $\mathbf{F}_{scale}(\mathbf{u}_c, \mathbf{s}_c)$ 表示某特征图 $\mathbf{u}_c \in \mathbb{R}^{H \times W}$ 与其通道权重 $\mathbf{s}_c$ 的乘积。

考虑到轴瓦缺陷检测过程中存在的特征提取不充分问题与 SE 模块的通用性, 本文将引入的 SE 模块嵌入到 YOLOv3 模型的特征提取网络中。图 4.10 为 SE 模块的两种嵌入方式。

数量	层类型	卷积核		输出尺寸
		数量	尺寸/步长	
1×	卷积层	32	3×3	608×608
	卷积层	64	3×3/2	304×304
	卷积层	32	1×1	304×304
	卷积层	64	3×3	
	残差单元			152×152
	卷积层	128	3×3/2	152×152
	卷积层	64	1×1	
	卷积层	128	3×3	
	残差单元			76×76
	卷积层	256	3×3/2	76×76
8×	卷积层	128	1×1	
	卷积层	256	3×3	
	残差单元			
1×	SE模块			38×38
	卷积层	512	3×3/2	
8×	卷积层	256	1×1	38×38
	卷积层	512	3×3	
	残差单元			
1×	SE模块			19×19
	卷积层	1024	3×3/2	
4×	卷积层	512	1×1	19×19
	卷积层	1024	3×3	
	残差单元			

(a) YOLOv3-SE

数量	层类型	卷积核		输出尺寸
		数量	尺寸/步长	
1×	卷积层	32	3×3	608×608
	卷积层	64	3×3/2	304×304
	卷积层	32	1×1	304×304
	卷积层	64	3×3	
	残差单元			152×152
	卷积层	128	3×3/2	152×152
	卷积层	64	1×1	
	卷积层	128	3×3	
	残差单元			76×76
	卷积层	256	3×3/2	76×76
4×	稠密层	128	1×1	
	稠密层	64	3×3	
1×	SE模块			38×38
	卷积层	512	3×3/2	
4×	稠密层	256	1×1	38×38
	稠密层	128	3×3	
	SE模块			19×19
2×	稠密层	512	1×1	
	稠密层	256	3×3	

(b) YOLOv3-Dense-SE

图 4.10 SE 模块的两种嵌入方式

图 4.10 中, (a)表示将 SE 模块嵌入原始 DarkNet-53 网络中的后三组残差块之

间, (b)表示将 SE 模块嵌入经过 DenseNet 稠密块改进的 DarkNet-53 网络的三组稠密块之间。

4.3.3 基于 FPN 的多尺度预测结构改进

在卷积神经网络中, 浅层网络更注重提取图像的低层特征信息, 深层网络更注重提取图像的高层语义信息, 如果忽略从浅层网络中获取的低层图像特征, 则很容易漏检或误检较小尺寸的目标。如上文所述, YOLOv3 模型采用 FPN 思想, 通过上采样方法将深浅层特征进行融合, 实现了多尺度目标的预测。鉴于在本文所研究的轴瓦表面缺陷检测问题中, 凹坑、划痕、污渍等微小缺陷较多, 且原始的 YOLOv3 模型对此类缺陷的检测精度难以达到实际应用的要求, 因此本文沿用 FPN 思想, 提出了一种在 YOLOv3 模型的多尺度预测结构中引入第四种预测尺度的模型改进方法, 以增强 YOLOv3 模型对于微小缺陷的检测能力。

本文提出的改进 YOLOv3 多尺度预测结构如图 4.11 所示, 该结构具有四个检测尺度, 152×152 、 76×76 、 38×38 、 19×19 层对应的左侧分支为自下而上的特征金字塔, 对应于特征提取网络中的特征图下采样阶段, 右侧分支为自上而下的特征金字塔, 在该分支中, 网络对 19×19 、 38×38 、 76×76 的特征图进行上采样, 并分别与 38×38 、 76×76 、 152×152 的特征图进行侧向连接, 因此左侧特征金字塔中每一层特征图获取的信息都能够被右侧特征金字塔中的下一层重用, 实现了低层细节信息与高层语义信息的融合。




图 4.11 改进 YOLOv3 多尺度预测结构示意图

与原有的三种预测尺度相比,本文引入的 152×152 特征图感受野更小,因此该尺度特征图更适合检测较小的目标,有利于提高 YOLOv3 模型对于微小缺陷的检测精度。

4.3.4 基于 SPP 的全局特征与局部特征融合

卷积神经网络在提取图像特征的过程中,随着网络层次的加深,感受野逐渐增大,特征提取能力也逐渐增强^[99],提取的特征更加抽象,语义信息会持续增多,而图像的细节和位置信息会不断减少。尽管 YOLOv3 中的多尺度预测结构可以对不同尺度的特征图进行融合,但融合的过程只考虑了不同尺度特征图中的全局特征,却忽略了特征图中的局部特征。此时,如果小目标物体在特征图中的形状模糊,则其位置信息就可能不准确,造成轴瓦表面微小缺陷的检测精度较低。

为了解决上述问题,本文参考 SPPNet 模型^[100]中的空间金字塔池化思想,提出了一种在 YOLOv3 模型中引入空间金字塔池化 (Spatial Pyramid Pooling, SPP) 模块进行局部特征与全局特征融合的方法,通过融合特征图中的局部特征与全局特征来增强特征图的表达能力,从而提高多尺度目标的检测精度,尤其是利用更丰富的局部特征来提高小目标的检测精度。该模块的结构如下图所示。




图 4.12 SPP 模块的结构

本文在 DarkNet-53 网络的末端与五层卷积单元之间引入了一个 SPP 模块,该模块由三个最大池化操作和一个跳跃连接组成,池化步长均为 1,池化窗口的尺寸可通过公式 $size_{pool} = \lceil size_{fmap} / n_i \rceil$ 计算,其中 $size_{fmap}$ 表示输入特征图的尺寸,

$size_{pool}$ 为池化窗口的尺寸, $n_i = 1, 2, 3$ 。当 608×608 的输入图像在特征提取网络中经过 5 次下采样生成 19×19 的特征图后, 该特征图会被输入到 SPP 模块进行三次最大池化, 其中池化窗口的尺寸为 7×7 、 10×10 、 19×19 。为了使最大池化后的特征图尺寸与输入特征图相同, SPP 模块使用零填充对输入特征图进行处理。池化后的各输出特征图与输入特征图的通道数相同, 各个特征图最后会与输入特征图进行张量拼接, 实现局部特征与整体特征的融合, 并生成最终的输出特征图。

在 SPPNet 模型中, SPP 层的作用是对输入特征图进行不同尺寸的最大池化运算以获得多个固定维度的子特征图并进行拼接, 再将拼接后的特征图输入到全连接层中得到最终输出。由于 YOLOv3 模型的输出层中并不包含全连接层, 因此 SPP 模块的作用并非将特征图划分为固定大小的网格, 而是通过池化操作对局部特征和全局特征进行融合, 从而增强 YOLOv3 模型对于微小缺陷的检测能力。




图 4.13 YOLO-Bush 网络结构图

图 4.13 为本文 4.3.1~4.3.4 节提出的四种 YOLOv3 模型改进方法相结合后的模型。其中，将 DarkNet-53 的后三组残差块替换为稠密块，实现深浅层特征的融合，并在三组稠密块之间分别引入 SE 模块，实现通道特征增强，本文将这种由稠密块与 SE 模块相结合的改进特征提取网络称为 DarkNet-Bush。输入图像经过 DarkNet-Bush 进行特征提取后输入至 SPP 模块中，实现局部特征与全局特征融合（SPP 模块的结构已在图 4.12 中给出），最后通过改进的 FPN 多尺度预测结构对特征图进行三次上采样与张量拼接，实现四种尺度的预测。

4.4 基于 K-means++ 聚类算法的锚框优化

如上文 4.2.2 节所述，YOLOv3 模型的锚框个数与尺寸是通过对 COCO 数据集的真实框进行 K-means 聚类而生成的。COCO 数据集中共包含 80 种目标，如飞机、汽车、猫、狗等，目标之间的尺度差异较大，与本文所研究的轴瓦缺陷之间的尺度也有着显著的差异。因此这 9 种锚框并不能完全满足轴瓦表面缺陷检测的要求，需要对轴瓦表面缺陷数据集中的标注框进行聚类分析，重新确定锚框的个数与尺寸。

K-means 算法在进行锚框聚类时，首先需要在数据集中随机选取 K 个真实框尺寸作为候选锚框尺寸（即聚类中心），然后分别求取数据集中剩余的每个真实框与 K 个候选框之间的距离，通常情况下，K-means 算法使用欧氏距离来完成聚类，但由于尺寸较大的真实框其欧氏距离也较大，会造成聚类精确度较低，因此锚框聚类中使用真实框与候选框之间的交并比作为评价标准，交并比越大，则距离越小，表明真实框越有可能与候选框属于同一类别，距离函数的表达式如下：

$$d(\text{Box}, \text{Centroid}) = 1 - R_{\text{IoU}}(\text{Box}, \text{Centroid}) \quad (4-12)$$

式中， Box 表示数据集中真实框的大小， Centroid 表示真实框的中心坐标， $R_{\text{IoU}}(\text{Box}, \text{Centroid})$ 表示真实框与候选框之间的交并比，计算距离的过程中，每个真实框的中心点与聚类中心保持重合。求取真实框与候选框的距离后，K-means 算法会将当前真实框分配给与其距离最近的聚类中心，当所有真实框都完成分配后，对各个聚类中心所在的簇重新计算聚类中心，并重复分配真实框和计算聚类

中心的过程，直至达到最大迭代次数或新生成的聚类中心保持不变。

从 K-means 算法对锚框聚类的过程中可以发现，该算法需要一次性随机指定所有初始聚类中心，这一点对于未知数据而言会带来较大的局限性，使得聚类结果对于初始聚类中心的选择比较敏感，当聚类中心选择不当时，结果会受到噪声干扰，造成聚类结果存在较大的误差。因此，本文引入 K-means++ 算法^[101]来优化锚框聚类的过程。设聚类总簇数为 K ，某候选锚框的宽高为 $(W_i, H_i), i \in \{1, 2, \dots, K\}$ ，真实框总数为 N ，某真实框为 $(x_j, y_j, w_j, h_j), j \in \{1, 2, \dots, N\}$ ，其中 (x_j, y_j) 表示真实框的中心点坐标， (w_j, h_j) 表示真实框的宽高，则 K-means++ 算法的执行流程如下。

- (1) 随机选取一个真实框作为初始聚类中心；
- (2) 通过距离函数 $d(\text{Box}, \text{Centroid}) = 1 - R_{\text{IoU}}(\text{Box}, \text{Centroid})$ 计算每个真实框与已经初始化的聚类中心之间的距离，并选取其中的最短距离记为当前真实框到该聚类中心的距离 d_i ；
- (3) 当所有真实框与聚类中心的距离求取完成后，按照加权概率分布随机选取一个真实框作为新的聚类中心，其中权重与距离 d_i 的平方成正比，即距离聚类中心越远的真实框越有可能被选取为新的聚类中心；
- (4) 重复上述 (2)、(3) 步骤，直至选取的聚类中心个数达到 K ；
- (5) 将先前选取的 K 个聚类中心作为初始聚类中心，按照 K-means 算法完成锚框聚类。

综上所述，K-means++ 算法与 K-means 算法最大的不同在于初始聚类中心的选取方式，K-means 为一次性选取所有聚类中心，而 K-means++ 为按照间距尽可能远的原则逐个选取聚类中心。

本文对于轴瓦表面缺陷数据集中的真实框尺寸进行了 K-means++ 聚类分析，并与 K-means 聚类结果进行对比，聚类总簇数 K 设置为 1~20，每种算法各执行 20 次并取结果的平均值，聚类过程中采用平均 IoU (Avg IoU) 作为聚类结果的评价指标，Avg IoU 值越高，表明聚类效果越好，下式 (4-13) 为 Avg IoU 的计算公式，其中 argmax 为求取最大值所对应的自变量点集的函数。

$$\text{Avg IoU} = \arg \max \frac{\sum_{i=1}^K \sum_{j=1}^N R_{\text{IoU}}(\text{Box}, \text{Centroid})}{N} \quad (4-13)$$

K-means++算法与 K-means 算法的锚框聚类结果如图 4.14 所示。从聚类结果图可以看出，K-means++的 Avg IoU 整体上高于 K-means 的 Avg IoU，增长幅度约为 3%，随着聚类中心数量的增加，二者的 Avg IoU 均逐渐增大，且增长速度逐渐减慢。考虑到上文所提出的 FPN 多尺度预测结构改进模型具有 4 种尺度的输出特征图，因此为了平衡模型的计算量与候选锚框数量所带来的误差，本文选取聚类总簇数 $K=12$ 时 K-means++锚框聚类的结果作为改进后的锚框尺寸，此时 Avg IoU 为 83.95%。




图 4.14 K-means++与 K-means 锚框数量与 Avg IoU 结果对比

图 4.15 为 $K=12$ 时 K-means++的锚框聚类结果，其中红点表示聚类中心。




图 4.15 K-means++锚框聚类散点图

从上图中可以看出,数据集中的样本分布存在着一定的不均匀性,在 75×100 范围内存在大量重叠的样本,表明轴瓦表面缺陷以中、小尺寸居多,而(83,111)处存在一个聚类中心,是因为此处有大量油孔样本存在重叠,(47,222)、(166,59)附近存在较多的重叠点,主要为油槽样本,其余样本主要为各类缺陷。

由于本文 4.3.3 节提出了一种基于 FPN 的多尺度预测结构改进方法,在 YOLOv3 模型原有的 3 种尺度特征图的基础上增加了一个 152×152 尺度的特征图。因此在引入第 4 种预测尺度时,本文将 12 种锚框尺寸平均分配到 4 种尺度的特征图中,各尺度特征图与锚框尺寸的对应关系如表 4.2 所示。

表 4.2 四种尺度特征图的锚框尺寸

特征图尺度	152×152	76×76	38×38	19×19
感受野大小	微小	小	中	大
锚框尺寸	6×8	43×83	74×213	152×122
	27×33	47×222	83×111	162×87
	37×51	66×58	112×185	166×59

当不使用多尺度预测结构改进方法时,输出特征图为 3 种尺度,将 12 种锚框尺寸平均分配到 3 种尺度的特征图中,即每种尺度的特征图对应 4 种锚框尺寸,如表 4.3 所示。

表 4.3 三种尺度特征图的锚框尺寸

特征图尺度	76×76	38×38	19×19
感受野大小	小	中	大
锚框尺寸	6×8	47×222	112×185
	27×33	66×58	152×122
	37×51	74×213	162×87
	43×83	83×111	166×59

4.5 基于 DIoU Loss 与 Focal Loss 的损失函数优化

4.5.1 基于 DIoU Loss 的坐标预测损失函数优化

如上文 4.2.3 节所述,YOLOv3 模型采用均方差函数作为坐标预测损失函数。然而,均方差函数在计算损失的过程中需要分别对边界框的中心点坐标、宽高求取损失值,然后将损失值叠加,因此其对目标尺度的变化较为敏感,容易导致训

训练集中的异常值影响模型训练的效果，从而降低模型性能。为了改进均方差损失函数的缺点，Yu 等^[102]提出了一种利用交并比损失函数（IoU Loss）计算坐标预测误差的方法，该方法首先计算预测框与真实框之间的 IoU，然后通过 $L_{IoU} = 1 - IoU$ 计算损失。实验结果表明 IoU Loss 对目标尺度变化不敏感，与均方差相比，可以轻微提升计算坐标预测损失的效果。然而，IoU Loss 也具有其局限性：假设预测框和真实框不相交，则根据定义，IoU 等于 0，显然此时无法反映当前目标的预测框与真实框之间的距离，因此损失函数中的坐标预测误差将无法对梯度进行反向传播，从而影响网络的学习和训练。此外，当预测框和真实框的相交面积相等但距离不相等时，计算出的 IoU 却始终相等，因此 IoU 此时无法准确反映二者的重合情况，例如图 4.16 所示的三种情况，其中蓝色矩形表示预测框，绿色矩形表示真实框，黄色为预测框与真实框的重叠部分，则三种情况的 IoU 均为 0.33，但重叠程度并不相同。




图 4.16 IoU 相等时的三种重叠情况

为了改进 IoU Loss 的上述两种缺点，Hamid 等^[103]提出了广义交并比（Generalized IoU, GIoU）。如图 4.16 所示，GIoU 需要通过预测框 A 和真实框 B 以及二者的最小外接矩形 C 进行计算，其表达式如下：

$$GIoU = IoU - \frac{C - (A \cup B)}{C} \quad (4-14)$$

GIoU 作为一种距离度量，与 IoU 类似，同样具有对目标尺度的不敏感性，当 GIoU 作为损失函数时，其表达式为 $L_{GIoU} = 1 - GIoU$ 。此外，GIoU 不仅关注了

预测框与真实框之间的重叠区域，还关注了最小外接矩形中的非重叠区域，因此 GIoU 能够更准确地反映预测框与真实框之间的重叠程度，即使预测框与真实框之间没有重叠部分，也可以对梯度进行更新。

虽然 GIoU 解决了 IoU 无法关注非重叠区域的问题，但当预测框和真实框之间出现包含现象的时候 GIoU 将会退化为 IoU，仍然无法反映预测框与真实框之间的重叠情况。因此，本文提出了一种基于距离交并比（Distance IoU, DIoU）对 YOLOv3 坐标预测损失函数进行改进的方法，以提升边界框回归的鲁棒性，减小预测框定位误差。与 GIoU 类似，DIoU 同样通过预测框 A、真实框 B 以及二者的最小外接矩形 C 进行计算，如图 4.17 所示。




图 4.17 DIoU 计算原理示意图

在计算过程中，DIoU 并非直接计算两框之间的交并关系，而是引入了测量参数，当预测框和真实框不重叠时，就会产生损失，其表达式如下：

$$DIoU = IoU - \frac{\rho^2(b, b^{gt})}{c^2} \quad (4-15)$$

式中， b 和 b^{gt} 分别代表预测框和真实框的中心点， ρ 代表两点之间的欧氏距离， c 代表可以同时包含预测框和真实框的最小外接矩形的对角线长度，式 (4-15) 的计算结果为图 4.17 中 d 的值。DIoU 综合考虑了预测框与真实框之间的距离、重叠率以及尺度等因素，使得边界框回归变得更加稳定，当预测框和真实框不重叠时，仍然可以为边界框调整提供梯度更新的方向，使预测框和真实框之间的距离最小化，因此 DIoU 损失函数的收敛速度比 IoU 和 GIoU 更快。当 DIoU 作为损失函数时，其表达式为 $L_{DIoU} = 1 - DIoU$ ，在训练 YOLOv3 模型的过程中，将 DIoU

Loss 加入损失函数中, 可以使损失函数的值随着迭代次数的增加而逐渐减小, 预测框和真实框重叠程度增加, 从而使预测框的定位误差更小。综上所述, 本文基于 DIoU Loss 所改进的 YOLOv3 坐标预测损失函数的表达式为:

$$\begin{aligned} Error_{coord} &= \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{obj} \times (1 - DIoU) \times \left[2 - \frac{\hat{w}_i^j \times \hat{h}_i^j}{w_i^j \times h_i^j} \right] \\ &= \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{obj} \times (1 - IoU + \frac{\rho^2(b, b^{gt})}{c^2}) \times \left[2 - \frac{\hat{w}_i^j \times \hat{h}_i^j}{w_i^j \times h_i^j} \right] \end{aligned} \quad (4-16)$$

4.5.2 基于 Focal Loss 的置信度与分类损失函数优化

如上文 4.2.3 节所述, YOLOv3 模型损失函数的置信度损失、目标类别损失为交叉熵损失函数。交叉熵损失函数的一般表达式如式 (4-17) 所示。

$$L(p_t) = \begin{cases} -\log(p_t), & y_t = 1 \\ -\log(1 - p_t), & y_t = 0 \end{cases} \quad (4-17)$$

式中, t 代表数据集中某样本的编号, p_t 为模型对于该样本的预测概率, 满足 $p_t \in [0, 1]$, y_t 表示样本的真实值, 其中, 当 $y_t = 1$ 时, 表示第 t 个样本属于正样本 (即前景), 当 $y_t = 0$ 时, 表示第 t 个样本属于负样本 (即背景), 训练 YOLOv3 模型可以看做调整各权重参数使 $\sum_t L(p_t)$ 趋于最小值的过程。当第 t 个样本为正样本 ($y_t = 1$) 时, 其预测概率 p_t 应接近于 1, 如果 p_t 与 1 之间的偏差较大, 则说明当前的模型参数并不适合对此样本进行预测, 因此当前样本属于困难样本, 该样本需要在训练模型过程中比其他样本发挥更重要的作用。相反, 当第 t 个样本为负样本 ($y_t = 0$) 时, p_t 应接近于 0, 如果 p_t 与 0 之间的偏差较大, 则该样本同样为困难样本, 在训练模型的过程中也应发挥更重要的作用。如果某样本不是困难样本, 则将该样本定义为简单样本。

本文构建的轴瓦表面缺陷数据集中, 图像的黑色背景以及完好的轴瓦表面在图像中所占的比例较高, 而凹坑、划痕、擦伤、污渍 4 种缺陷和油孔、油槽在图像中只占一小部分, 因此正负样本之间存在数量不平衡, 负样本的数量远多于正样本, 该现象会导致容易分类的负样本贡献大部分的置信度损失, 并对梯度更新

起着主导作用。此外，数据集中不同类别的样本数量同样存在不平衡问题，例如容易分类的油孔、油槽与难分类的反光区域缺陷、划痕、擦伤之间存在着较大的数量差异。在使用交叉熵损失函数作为置信度损失函数和目标类别损失函数时，上述置信度和类别不平衡问题可能会导致模型的训练缺乏有效性，因为图像中的大多数位置是容易分类的背景样本，无法提供有用的特征供模型学习。

为了解决正负样本、难易样本之间的不平衡问题，本文提出了一种引入聚焦损失^[104]（Focal Loss）函数优化 YOLOv3 模型置信度与分类损失函数的方法，以动态调节不同类别的损失，增强模型对于轴瓦表面难检测缺陷的检测能力，Focal Loss 的表达式如下。

$$FL(p_t) = \begin{cases} -\alpha_t(1-p_t)^\gamma \log(p_t), & y_t = 1 \\ -\alpha_t p_t^\gamma \log(1-p_t), & y_t = 0 \end{cases} \quad (4-18)$$

式中， $\alpha_t(1-p_t)^\gamma$ 和 $\alpha_t p_t^\gamma$ 分别为正负样本的调制系数， p_t 为模型对于第 t 个样本的预测概率， γ 为难易样本权重的调节因子，其取值范围为 $\gamma \in [0, +\infty]$ ，当 $\gamma = 0$ 时，上式退化为平衡交叉熵损失函数，此时损失函数只对正负样本进行平衡。此外， α_t 为正负样本权重的调节因子，可以表示为式（4-19）。

$$\alpha_t = \begin{cases} \alpha, & y_t = 1 \\ 1-\alpha, & y_t = 0 \end{cases} \quad (4-19)$$

上式中 $\alpha \in [0, 1]$ ，当 $\alpha > 0.5$ 时，可以确保正样本（ $y_t = 1$ ）比负样本（ $y_t = 0$ ）具有更大的 α_t ，本文取 $\alpha = 0.75$ ，即正负样本之间的 α_t 比值为 3，大幅提高正样本在式（4-18）中对于损失函数的影响，减轻正负样本不平衡所带来的负面影响。

本文取 $\gamma = 2$ ，则对于式（4-18）有：当 $y_t = 1$ 时，简单样本的 p_t 趋近于 1，而 $(1-p_t)^\gamma$ 趋近于 0，相反，困难样本的 p_t 偏离 1，而 $(1-p_t)^\gamma$ 将会远大于简单样本，因此困难样本对于损失函数的影响大于简单样本。同理，当 $y_t = 0$ 时，简单样本的 p_t 趋近于 0， p_t^γ 同样趋近于 0，而困难样本的 p_t 偏离 0，则其 p_t^γ 远大于简单样本，因此困难样本对于损失函数的影响大于简单样本。

综上所述，本文采用 Focal Loss 对 YOLOv3 模型的置信度损失函数及分类损

失函数进行改进，与式（4-16）基于 DIoU Loss 改进的坐标预测损失函数结合后的损失函数如下式（4-20）所示。

$$\begin{aligned}
 Loss &= \sum_{i=0}^{S^2} (Error_{coord} + Error_{iou} + Error_{class}) \\
 &= \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{obj} \times (1 - IoU + \frac{\rho^2(b, b^{gt})}{c^2}) \times \left[2 - \frac{\hat{w}_i^j \times \hat{h}_i^j}{w_i^j \times h_i^j} \right] \\
 &\quad - \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{obj} [\alpha_i^j (1 - C_i^j)^\gamma \hat{C}_i^j \log(C_i^j) + \alpha_i^j (C_i^j)^\gamma (1 - \hat{C}_i^j) \log(1 - C_i^j)] \quad (4-20) \\
 &\quad - \lambda_{noobj} \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{noobj} [\alpha_i^j (1 - C_i^j)^\gamma \hat{C}_i^j \log(C_i^j) + \alpha_i^j (C_i^j)^\gamma (1 - \hat{C}_i^j) \log(1 - C_i^j)] \\
 &\quad - \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{obj} \sum_{c \in classes} [\alpha_i^j (1 - P_i^j)^\gamma \hat{P}_i^j \log(P_i^j) + \alpha_i^j (P_i^j)^\gamma (1 - \hat{P}_i^j) \log(1 - \hat{P}_i^j)]
 \end{aligned}$$

4.6 YOLOv3 改进模型实验结果及分析

为了验证本文 4.3~4.5 节所提出的 YOLOv3 模型各改进方法的有效性，本节开展了消融实验，对不同的改进方法进行组合以获取多种改进模型，并分别在轴瓦表面缺陷数据集上进行训练与测试，最终与原始 YOLOv3 模型进行对比以验证改进的有效性。

4.6.1 YOLOv3 模型改进方法消融实验结果对比

本小节实验所采用的软、硬件环境以及模型实验参数与上文 3.4.1 节相同，并进行单样本与混合样本在线数据增强。模型结构方面，本节分别对引入 DenseNet 稠密块（Dense）、引入 SE 注意力机制模块（SE）、引入第四种预测尺度（FPN）、引入空间金字塔池化模块（SPP）改进的模型采用消融实验的方法进行组合，并设置了一个没有修改网络结构的 YOLOv3 模型作为对照组。此外，所有模型的锚框均采用 4.4 节 K-means++ 聚类所得的尺寸，在采用原始损失函数和 DIoU+Focal Loss 改进损失函数的条件下，分别开展两组实验，每组实验中包含 16 种模型改进方法的组合，对每种组合的检测结果进行对比。表 4.4 为各改进模型对于轴瓦表面各类缺陷及结构的检测精度对比，表中左栏数据表示原始损失函数的实验结果，右栏数据表示采用 DIoU+Focal Loss 改进损失函数条件下的实验结果。

表 4.4 各改进模型采用原始/DIoU+Focal Loss 损失函数的检测精度对比

模型改进方法				原始/改进损失函数检测精度 AP(%)					
Dense	SE	FPN	SPP	凹坑	划痕	擦伤	污渍	油孔	油槽
				90.71/91.61	87.39/89.55	88.57/90.68	91.18/91.47	98.74/98.31	99.52/99.33
√				93.35/94.75	91.40/92.83	91.19/92.30	94.06/94.37	99.01/98.70	99.69/99.46
	√			92.24/93.47	90.17/92.27	90.22/92.58	92.62/93.30	98.88/98.91	99.60/98.95
		√		94.11/95.62	91.51/93.21	89.84/92.82	94.23/94.78	98.82/98.98	99.58/99.16
			√	93.38/94.99	90.26/92.17	90.31/92.09	92.56/94.11	98.93/98.93	99.62/99.09
√	√			94.16/95.75	92.77/93.55	92.47/93.79	94.95/95.24	98.90/98.83	99.63/99.28
√		√		95.39/95.91	93.49/94.13	91.48/93.64	95.52/95.60	99.19/98.78	99.65/98.80
√			√	95.06/96.36	92.91/93.80	92.65/94.02	94.87/96.37	98.85/98.82	99.68/98.74
	√	√		95.29/96.62	92.73/93.84	91.01/93.43	94.68/95.94	98.89/99.10	99.64/98.72
	√		√	94.90/97.07	92.63/93.59	92.05/93.85	93.89/96.01	99.21/98.64	99.73/99.03
		√	√	94.51/96.78	93.17/94.69	91.33/94.20	94.62/95.86	99.13/99.18	99.61/99.13
√	√	√		95.85/97.35	94.62/95.23	93.39/95.77	95.84/97.18	98.92/98.82	99.69/98.64
√	√		√	95.69/97.05	94.03/94.86	93.89/95.35	95.31/96.85	98.99/98.84	99.70/98.66
√		√	√	96.15/97.47	94.48/95.75	93.03/95.94	95.90/96.87	99.20/98.61	99.65/99.14
	√	√	√	95.54/97.26	94.31/95.58	93.58/95.35	96.11/96.92	98.96/99.07	99.72/98.81
√	√	√	√	96.67/97.62	95.04/96.47	94.81/96.03	96.67/97.85	99.32/99.20	99.81/99.55

对于采用原始损失函数的各改进模型而言，通过表中第 1 行数据可以看出，只采用 K-means++算法实现锚框重新聚类后的 YOLOv3 模型对于轴瓦表面缺陷及油孔、油槽的检测精度相比于表 3.9 中采用随机初始化权重训练的 YOLOv3 模型均有小幅度提升，提升幅度约为 0.1~0.9%之间，证明了 K-means++锚框聚类方法对于提升 YOLOv3 模型轴瓦表面缺陷检测精度的有效性。

表中第 2 行至第 5 行数据分别表示仅引入 DenseNet 稠密块、仅引入 SE 注意力机制模块、仅引入第四种预测尺度、仅引入空间金字塔池化模块的四种改进模型的检测精度对比。其中，第 2 行除油孔、油槽检测精度小幅提升外，其余各项缺陷的检测精度相比于表 3.9 中 YOLOv3 的检测精度均有较大幅度的提升，其中划痕缺陷检测精度提升幅度最大，达到 4.67%，其余各缺陷检测精度提升范围为 2.98~3.75%之间，证明了本文提出的引入 DenseNet 稠密块的方法对于融合深浅层特征并提高模型检测精度的有效性。

表中第3行数据表明,轴瓦表面各类缺陷的检测精度相比于改进前模型均普遍提高,证明SE注意力机制模块对于提升YOLOv3模型检测轴瓦表面缺陷精度的有效性。根据表中第4行可知,凹坑、划痕、污渍三种缺陷的检测精度提升幅度较大,均达到3.5%以上,而擦伤缺陷的检测精度提升幅度相对较低,为1.88%,油孔、油槽的检测精度则没有明显提升,该现象表明引入第四种预测尺度可以增强模型对于小目标的检测精度,而对于大目标的检测则提升十分有限。表中第5行数据反映了引入空间金字塔池化模块对各类缺陷的检测精度均有不同程度的提升,其中,凹坑、划痕这类小目标的检测精度提升幅度较大,达到3%以上,表明空间金字塔池化模块局部特征融合的特性对于提升小目标检测精度的有效性。

此外,观察表中第6至16行的各改进模型检测精度结果可知,总体而言,不同改进方法之间的组合,会在单一改进方法的基础上,进一步提高YOLOv3模型对于轴瓦表面缺陷及结构的检测精度,但并非各改进方法提升幅度之间的线性叠加。

为了探究上文所提出的DIOU+Focal Loss损失函数的有效性,本文在消融实验各改进模型的基础上,进一步将模型的损失函数修改为DIOU+Focal Loss,对模型检测各类轴瓦表面缺陷及结构的精度进行对比。观察表4.4右栏数据可知,引入DIOU+Focal Loss损失函数后,各改进模型对于凹坑、划痕、擦伤、污渍四类缺陷的检测精度均有不同程度的提升,其中凹坑、划痕、擦伤三种缺陷的检测精度提升幅度较大,约为1.0~2.5%,而污渍缺陷检测精度提升幅度相对较小,增幅普遍不足1.5%,此外,油孔、油槽两种特征的检测精度均出现了小幅度下降。上述数据表明,凹坑、划痕、擦伤等难分类缺陷主导了本次模型的训练过程,而油孔、油槽等易分类目标对于模型训练的作用受到了抑制,说明Focal Loss损失函数在本实验中对于调节不同类别样本的损失具有有效性。

表4.5为各改进模型采用原始损失函数和DIOU+Focal Loss改进损失函数的检测性能指标对比,表中左栏数据为原始损失函数的实验结果,右栏数据为DIOU+Focal Loss改进损失函数的实验结果。对于采用原始损失函数的各改进模型而言,表中第1行只改进锚框的YOLOv3模型对照组相比于表3.10中随机初

始化权重的 YOLOv3 模型精确率、召回率、F1 值、mAP 分别提升了 0.85%、0.33%、0.59%、1.05%，证明了 K-means++ 算法对于锚框优化的有效性。此外，表中第 2 至 5 行的各改进模型的检测性能指标也有不同程度的提高，总体而言，各项指标的提升幅度约为 1.0~2.0%。观察表中第 6 至 16 行数据可知，当各种改进方法相互组合时，各检测性能指标有进一步提升的趋势，其中，将 Dense、SE、FPN、SPP 四种改进方法相结合的模式各项指标最高，该模型精确率为 97.85%、召回率为 95.33%、F1 值为 96.57%、mAP 为 96.97%，与随机初始化权重的 YOLOv3 模型相比，上述指标分别提升了 3.42%、4.73%、4.09%、4.75%，提升幅度较大。

表 4.5 各改进模型采用原始/DIoU+Focal Loss 损失函数的检测性能指标对比

模型改进方法				精确率/%	召回率/%	F1 值/%	mAP/%
Dense	SE	FPN	SPP				
				94.98/95.22	91.02/92.66	92.96/93.92	92.69/93.49
√				95.35/95.60	92.74/93.87	94.03/94.73	94.78/95.40
	√			95.59/95.84	91.80/92.90	93.66/94.35	93.96/94.91
		√		95.44/95.92	92.58/93.52	93.99/94.71	94.68/95.76
			√	95.61/95.90	92.15/93.33	93.85/94.60	94.17/95.23
√	√			96.02/96.11	93.79/94.85	94.89/95.47	95.54/96.07
√		√		96.17/96.44	93.91/95.12	95.03/95.78	95.78/96.09
√			√	96.54/96.71	93.32/94.18	94.91/95.43	95.67/96.35
	√	√		95.75/96.44	93.01/94.03	94.36/95.22	95.37/96.28
	√		√	96.36/96.85	93.63/94.65	94.98/95.74	95.40/96.37
		√	√	96.15/97.03	92.89/93.91	94.50/95.45	95.39/96.64
√	√	√		97.02/97.53	94.57/95.60	95.78/96.55	96.38/97.17
√	√		√	96.88/97.21	94.26/95.43	95.55/96.31	96.26/96.94
√		√	√	97.20/97.85	94.85/96.06	96.01/96.95	96.40/97.30
	√	√	√	96.62/97.41	94.03/95.20	95.31/96.29	96.37/97.17
√	√	√	√	97.85/98.11	95.33/96.68	96.57/97.39	97.05/97.79

对于采用 DIoU+Focal Loss 改进损失函数的各模型而言，观察表 4.5 中右栏数据可知，各模型检测性能指标相比于采用原始损失函数的模型均有不同程度的提升，其中召回率提升幅度普遍超过 1.0%，精确率和 mAP 提升幅度相对较小，

提升幅度约为 0.5~1.0%，精确率提升幅度最小，普遍不足 0.5%。上述结果表明，引入 DIoU+Focal Loss 可以有效提升 YOLOv3 模型的检测性能。

综合本小节实验结果可得如下结论：通过 K-means++ 聚类算法对锚框重新聚类可以小幅度提升 YOLOv3 模型的检测性能。同时，引入 DenseNet 稠密块、SE 注意力机制模块、第四种预测尺度、空间金字塔池化模块并进行组合可以有效提升 YOLOv3 模型对于各类轴瓦表面缺陷的检测精度。此外，引入 DIoU+Focal Loss 损失函数可以起到平衡难易样本的作用，进一步提升各改进模型的检测精度。

上述实验数据表明，经过 K-means++ 锚框聚类并结合四种模型改进方法，同时采用 DIoU+Focal Loss 的改进模型具有最佳的检测性能，其精确率为 98.11%，召回率达到 96.68%，F1 值为 97.39%，mAP 达到 97.79%。与随机初始化权重的 YOLOv3 模型相比，该模型的上述指标分别提升了 3.68%、6.08%、4.91%、5.57%，本文将其命名为 YOLO-Bush，并在下文继续开展实验，对其在轴瓦表面缺陷数据集中的实际检测效果进行验证。


4.6.2 YOLO-Bush 模型轴瓦表面缺陷检测综合实验

对于目标检测模型而言，PR 曲线以及 PR-F1 曲线是评判其有效性和鲁棒性的基本指标之一。图 4.18(a)、(b)分别为 YOLO-Bush 对于轴瓦表面各类别目标的 PR 曲线与 PR-F1 曲线。观察 PR 曲线可知，随着召回率的增加，各类别的精确率总体呈现逐渐降低的趋势。


图 4.18(a)中，油孔、油槽的 PR 曲线平衡点更靠近坐标空间的右上角，曲线下方面积更大，表明 YOLO-Bush 对于油孔、油槽的检测精度更高。相比之下，其余四种类别的 PR 曲线平衡点与坐标空间右上角的距离相对较大，表明 YOLO-Bush 对于四类缺陷的检测精度稍差于油孔、油槽。同时，划痕和擦伤两类别的精确率在召回率为 0.05~0.40 范围内时大约降低了 0.01~0.02，该现象使得 PR 曲线下方面积进一步减小，因此 YOLO-Bush 对于这两类缺陷的检测精度低于凹坑和污渍。

尽管各类别 PR 曲线的变化规律呈现出一定差异，但当精确率为 0.90 时，各

曲线的召回率均大于 0.97；反之，当召回率为 0.90 时，各曲线的召回率均大于 0.96。上述规律表明 YOLO-Bush 模型在各类别的精确率和召回率之间取得了良好的平衡，对于各类别缺陷以及结构具有较高的检测精度和鲁棒性。



(a) PR 曲线



(b) PR-F1 曲线

图 4.18 YOLO-Bush 模型各类别 PR 曲线与 PR-F1 曲线

观察图 4.18(b)可知，随着召回率的增加，以及精确率的减小，YOLO-Bush 对于各类别的 F1 值总体呈现出先增大后减小的变化趋势。与 PR 曲线类似，油孔、油槽的 PR-F1 曲线更靠近坐标空间的右上角，F1 值相比于其它类别更大，其余四

种类别缺陷的 F1 值则相对较小。但整体而言，凹坑、划痕、擦伤、污渍、油孔、油槽的 F1 最大值分别达到了 0.9629、0.9710、0.9679、0.9687、0.9812、0.9896，表明 YOLO-Bush 在各类别的精确率与召回率之间均取得了良好的平衡，证明了 YOLO-Bush 对于轴瓦表面各类缺陷及结构具有优异的检测性能。

图 4.19 为 YOLO-Bush 模型与原始 YOLOv3 模型的预测框定位精度对比结果，图(a)~(d)中左侧与右侧图像分别为 YOLOv3 和 YOLO-Bush 的检测结果，虚线框表示真实框。观察图像可以发现，图(a)中 YOLOv3 对于凹坑的预测框与其真实框之间存在一定的间隔，表明预测框位置存在一定程度的误差，而 YOLO-Bush 的预测框与凹坑的真实框基本贴合，定位误差很小；图(b)中 YOLOv3 的预测框与划痕真实框的左、右、下边缘之间存在较大的误差，而 YOLO-Bush 的预测框与真实框除右边缘外，其余部分基本贴合，定位误差相对较小；图(c)中 YOLOv3 对于擦伤的右、上边缘，以及油槽的左、右边缘存在较大的定位误差，而 YOLO-Bush 只在擦伤的右边缘处存在较小的定位误差；图(d)中，YOLOv3 对于油槽存在较大的定位误差，同时，其将污渍错检为凹坑，且预测框并没有与真实框贴合，而 YOLO-Bush 对于油槽以及污渍的预测框则基本与真实框贴合。





图 4.19 YOLOv3 与 YOLOv3-Bush 预测框定位精度对比

上述实验结果表明,本文提出的基于 DIoU Loss 改进的 YOLOv3 坐标预测损失函数可以有效减小预测框与真实框之间的定位误差,从而提高 YOLO-Bush 模型对于轴瓦表面缺陷以及结构的定位精度。这将有助于利用模型的检测结果进行数据标注,减少人工复核数据标注的工作量。

图 4.20 为 YOLO-Bush 与 YOLOv3 对于微小缺陷、反光区域缺陷、暗区缺陷等难检测缺陷的检测效果对比,图中(a)、(c)组为 YOLOv3 检测结果,(b)、(d)组为 YOLO-Bush 检测结果。在图(a-1)~(a-3)与(b-1)~(b-3)中,YOLOv3 分别未检出反光区域的凹坑、微小污渍、微小划痕,而 YOLO-Bush 则均成功将上述三种缺陷检出;在图(c-1)与(d-1)中,YOLOv3 未检出暗区中的污渍,而 YOLO-Bush 可以检出;在图(c-2)与(d-2)中,YOLOv3 未检出靠近油槽的污渍以及暗区中的凹坑,而 YOLO-Bush 成功将这两种缺陷检出;在图(c-3)与(d-3)中,YOLOv3 未检出油槽下方的擦伤,YOLO-Bush 可以检出,此外,对于轴瓦上边缘的污渍,YOLO-Bush 的置信度 0.98 高于 YOLOv3 的 0.92。因此,通过上述实验结果可得结论,YOLO-Bush 对于微小缺陷、反光区域缺陷、暗区缺陷的检测能力相比于 YOLOv3 有明显提升,且对于 YOLOv3 可检出的缺陷,其置信度也会有一定程度的提升。






图 4.20 YOLOv3 与 YOLOv3-Bush 难检测缺陷检测效果对比

4.7 本章小结

本章主要阐述了 YOLO-Bush 模型的设计过程。首先介绍了 YOLOv3 模型结构及其检测原理；然后提出了四种基于特征融合及通道特征增强的特征提取改进方法；接着通过 K-means++ 聚类算法对模型锚框数量以及尺寸进行了优化；同时，提出了 DIoU Loss 与 Focal Loss 相结合的损失函数，用于提高模型预测的定位精度，并解决数据集中样本不均衡的问题；最后通过消融实验对本章所提出方法的有效性进行了验证，并据此提出 YOLO-Bush 模型。实验结果表明，YOLO-Bush 的精确率、召回率、F1 值、mAP 分别可达 98.11%、96.68%、97.39%、97.79%，其对于微小缺陷、反光区域缺陷、暗区缺陷具有较高的检测性能，同时其预测框具有较高的定位精度。

第5章 轴瓦表面缺陷检测软件设计与实验验证

5.1 引言

本文在先前章节中介绍了轴瓦表面缺陷数据集的构建过程，并基于数据增强与深度迁移学习方法改进了模型训练效果，同时提出了一种 YOLO-Bush 模型。本章对上文所做工作进行汇总，设计并开发出一款具有人机交互界面的轴瓦表面缺陷检测软件，对 YOLO-Bush 模型进行了封装以提高其易用性，从而降低软件在工业现场的应用门槛。最后利用该软件完成轴瓦表面缺陷检测对比实验，对 YOLO-Bush 模型的检测精度、检测效率以及鲁棒性进行了验证。

5.2 软件模块设计

本文基于 MATLAB® R2020b GUI 工具箱开发了一款具有人机交互界面的轴瓦表面缺陷检测软件，将上文所提出的 YOLO-Bush 模型进行了封装，并在软件中进行调用，实现了轴瓦表面缺陷位置及类别的直观展示，提高了 YOLO-Bush 模型的易用性。该软件包括 5 个模块，分别为：表面缺陷检测模块、历史数据查询模块、检测模型校准模块、轴瓦图像查询模块、轴瓦批次设置模块，软件的模块组成如图 5.1 所示。




图 5.1 轴瓦表面缺陷检测软件模块

图 5.1 中，表面缺陷检测模块为该软件的核心模块，主要用于实时展示轴瓦批次信息、拍摄条件、检测结果等信息，并设置图像采集参数，以及调用其他模

块；历史数据查询模块基于 MySQL 数据库与 JDBC 数据库连接工具实现，主要用于查询某一批次中特定时段的轴瓦缺陷数据统计信息；检测模型校准模块的作用是对带有缺陷的轴瓦图像检测结果进行复核，并利用检测结果对原数据集进行扩充，从而对 YOLO-Bush 模型进行二次训练，提高检测精度；轴瓦图像查询模块主要用于查看轴瓦图像采集路径中的图像；轴瓦批次设置模块的作用是对轴瓦订单编号、批次编号、型号、镜头焦距、相机物距等信息进行设置，并在数据库中创建相应数据表。

图 5.2 为轴瓦表面缺陷检测软件的执行流程图。在缺陷检测流程中，首先将待检测图像输入软件，然后软件对 YOLO-Bush 模型进行调用，随后模型对轴瓦表面缺陷进行检测并返回检测结果，最后，软件根据轴瓦合格性执行训练集扩充并输出检测结果。在模型校准流程中，软件将缺陷检测流程中检出的不合格轴瓦图像加入轴瓦表面缺陷数据集的训练集中，当新增图像达到一定规模后，由人工完成新增缺陷样本的复核标注工作，之后对 YOLO-Bush 模型进行二次训练以实现模型校准，并采用固定的测试集对迭代后的模型检测性能进行测试，最后，更新缺陷检测流程中 YOLO-Bush 模型的权重文件并输出模型校准结果。




图 5.2 轴瓦表面缺陷检测软件执行流程图

5.3 软件主要模块实现

(1) 表面缺陷检测模块

轴瓦缺陷检测软件的主界面如图 5.3 所示, 该界面为表面缺陷检测模块的核心, 共计包括 7 个区域。图中区域 1 为批次信息显示区域, 显示当前订单编号、批次编号、轴瓦型号等信息; 区域 2 为图像采集及检测控制区域, 可选择在线采集图像或对离线图像进行检测。点击“在线连接”按钮可以将图像来源切换为工业相机在线采集, 修改“本地路径”可以对指定路径的图像进行检测。点击“开始检测”按钮开始执行轴瓦表面缺陷检测, 并将输入检测模型的原始图像和检测结果显示在界面中央; 区域 3 为图像拍摄条件显示区域, 显示当前轴瓦图像采集所采用的镜头焦距以及相机物距; 区域 4 为操作面板, 用于调用相应模块; 区域 5 为原始图像及检测结果显示区域, “原始图像”区域显示未经检测的轴瓦原始图像, “检测结果”区域显示轴瓦表面各类缺陷以及油孔油槽的位置、类别、置信度; 区域 6 为当前批次总体检测数据统计显示区域, 主要数据包括被检测轴瓦总数、合格总数、不合格总数、合格率与不合格率; 区域 7 为轴瓦检测日志区域, 实时显示当前轴瓦的合格性以及缺陷类别等信息, 便于用户了解软件运行状况。




图 5.3 轴瓦表面缺陷检测软件主界面

(2) 历史数据查询模块

图 5.4 为轴瓦表面缺陷检测软件的历史数据查询界面，该界面共分为 3 个区域。区域 1 为查询参数设置区域，查询时，首先输入订单编号、批次编号、轴瓦型号以确定查询的数据表，然后输入起始日期、终止日期以确定查询的时间范围，最后勾选缺陷类别并点击“查询所选范围数据”按钮，即可加载数据库中符合条件的轴瓦检测结果数据；区域 2 为历史检测结果数据显示区域，显示根据区域 1 中条件所查询出的数据，包括轴瓦编号、检测结果、缺陷类型、检测时间、镜头焦距以及相机物距；区域 3 为查询结果数据汇总显示区域，展示了各类别缺陷所对应的轴瓦数量，便于用户针对性地对缺陷的产生原因进行排查。同时，区域 3 还展示了查询结果的总量，该值可用于判断轴瓦表面缺陷数据集中新增缺陷样本数量是否充足，从而进一步判断 YOLO-Bush 模型是否具备校准条件。

历史数据查询

区域1

订单编号: ZD003 批次编号: 132 轴瓦型号: C90C-R

起始日期: 2020-12-19 终止日期: 2020-12-19 查询所选范围数据

油孔缺失: ☐ 油槽缺失: ☐ 凹坑: ☒ 划痕: ☒ 擦伤: ☒ 污渍: ☒

轴瓦编号	检测结果	缺陷类型	检测时间	焦距	物距
1379	不合格	污渍	2020-12-19 15:12:35	25	360
1411	不合格	凹坑、擦伤	2020-12-19 15:14:17	25	360
1426	不合格	划痕	2020-12-19 15:15:20	25	360
1455	不合格	擦伤、污渍、划痕	2020-12-19 15:18:43	25	360

区域2

区域3

油孔缺失: 0 凹坑: 1 擦伤: 2 数据总量: 4

油槽缺失: 0 划痕: 2 污渍: 2

图 5.4 历史数据查询界面

(3) 检测模型校准模块

本文针对轴瓦表面缺陷检测软件设计了模型校准模块，以在该软件的应用过程中对 YOLO-Bush 模型进行迭代，不断优化其检测性能。该模块首先利用模型检测结果对不合格轴瓦图像进行数据标注，并生成 xml 文件加入到轴瓦表面缺陷数据集中，实现训练集的扩充；然后，根据模型预测结果，由用户对标注框位置

进行人工调整；最后，通过对 YOLO-Bush 模型进行二次训练，同时利用上文 3.2 中的固定测试集进行测试，完成模型校准并输出校准结果。

图 5.5 为检测模型校准界面，该界面共分为 4 个区域。区域 1 为操作面板，输入带有缺陷的轴瓦编号后，点击“查看图像”按钮即可将轴瓦表面缺陷检测结果加载到界面中。点击“图像标注”按钮可以调用 LabelImg®软件，对当前轴瓦图像中定位误差较大的预测框进行重新标注，当所有图像标注完成后，点击“重新训练”按钮即可对 YOLO-Bush 模型进行重新训练。在模型训练完成后，点击“查询校准结果”按钮，可通过测试集对模型检测性能进行测试；区域 2 为缺陷检测结果显示区域，用于人工核对各类缺陷及油孔油槽的预测框定位精度；区域 3 为目标类别显示区域，可以作为用户复核数据标注情况的参考；区域 4 为模型校准结果显示区域，用于展示模型校准后的各项检测性能指标。




图 5.5 轴瓦表面缺陷检测模型校准界面

5.4 YOLO-Bush 检测性能对比实验

本节基于轴瓦表面缺陷检测软件开展了 YOLO-Bush 缺陷检测性能对比实验，

以对比 YOLO-Bush 与上文所述的 Faster R-CNN、R-FCN、YOLOv3 三种经典模型之间的检测性能差异，并验证检测软件的可用性。实验过程中首先采用随机初始化权重方法，利用 COCO 2017 数据集对 YOLO-Bush 模型进行预训练，总迭代次数（Epoch）设置为 80，学习率衰减策略采用 MultiStep LR，在 Epoch 为 50、70 时将学习率调整为先前的 0.1 倍，其余模型实验参数以及软硬件环境与 3.3 节保持一致，并进行单样本与混合样本在线数据增强。预训练完成后，令 YOLO-Bush 模型加载预训练权重，采用深度迁移学习方法在轴瓦表面缺陷数据集上进行正式训练，训练时冻结 DarkNet-Bush 网络中第一组稠密块之前的网络层，并对剩余层进行训练，其余模型训练参数与上文 3.5.2 节中保持一致。

表 5.1 为 YOLO-Bush 模型与采用深度迁移学习方法训练的 Faster R-CNN、R-FCN、YOLOv3 模型对于轴瓦表面各类缺陷及结构的检测精度对比。观察表格数据可知，YOLO-Bush 对于凹坑、划痕、擦伤、污渍四种轴瓦缺陷的检测精度相比于其他三种模型有了大幅度提升，其中，凹坑检测精度约提升 6%，划痕检测精度提升约 6~8%，擦伤检测精度提升约 6~8%，污渍检测精度提升约 6%。相反，由于 Faster R-CNN、R-FCN、YOLOv3 对于油孔油槽的检测精度已经达到较高水平，因此 YOLO-Bush 对于这两类目标的检测精度提升幅度相对较小，其中油孔检测精度提升幅度不足 0.40%，油槽检测精度增幅小于 0.15%。

表 5.1 YOLO-Bush 与其他三种模型的检测精度对比

检测模型	检测精度 AP/%						mAP/%
	凹坑	划痕	擦伤	污渍	油孔	油槽	
Faster R-CNN	91.36	88.15	88.16	92.03	99.01	99.60	93.05
R-FCN	91.89	90.90	90.43	93.24	99.17	99.62	94.20
YOLOv3	92.19	90.69	89.88	92.96	98.93	99.52	94.03
YOLO-Bush	98.01	96.68	96.47	98.14	99.31	99.65	98.04

表 5.2 为 YOLO-Bush 模型与基于深度迁移学习方法训练的其他三种模型的检测性能指标对比。观察表中数据可知，除检测耗时外，YOLO-Bush 的各项检测性能指标相比于其他三种模型均有较大幅度的提升，其中精确率增幅约为 2~3%，召回率增幅约为 4~7%，F1 值增幅约为 3~4%，mAP 增幅约为 3~4%。此外，与上

文表 4.4、4.5 中右栏的检测精度及性能指标相比，表 5.1、5.2 中基于深度迁移学习方法训练的 YOLO-Bush 模型的各指标均有约 0.1~0.5%的提升。检测耗时方面，由于 YOLO-Bush 相比于 YOLOv3 模型的计算量有所增加，因此 YOLO-Bush 的检测耗时增加 4.25ms，达到 30.16ms，涨幅为 16.40%，但 YOLO-Bush 的检测耗时仍然远小于 Faster R-CNN 和 R-FCN 两种 Two-stage 模型。

表 5.2 YOLO-Bush 与其他三种模型的检测性能指标对比

检测模型	精确率/%	召回率/%	F1 值/%	mAP/%	检测耗时/ms
Faster R-CNN	95.22	91.26	93.19	93.05	327.47
R-FCN	96.12	92.77	94.42	94.20	202.59
YOLOv3	95.60	92.29	93.92	94.03	25.91
YOLO-Bush	98.33	97.02	97.67	98.04	30.16

如上文所述，Faster R-CNN、R-FCN、YOLOv3 三种模型从整体上可达到良好的轴瓦表面缺陷检测效果，但各模型对于微小目标的检测能力均呈现出一定的不足。因此，本节通过实验对比了 YOLO-Bush 模型与其他三种模型对于小、中、大三种尺度目标的检测精度，实验结果如表 5.3 所示。通过表中数据可知，YOLO-Bush 对于小尺度目标的检测精度相比于其他三种模型有较大幅度的提升，提升幅度约 6~8%，中尺度目标的检测精度增幅约 5~6%，大尺度目标的增幅相对较小，低于 2%。

表 5.3 YOLO-Bush 与其他三种模型对于不同尺度目标的检测精度对比

检测模型	检测精度 AP/%		
	小尺度	中尺度	大尺度
Faster R-CNN	88.42	91.90	97.44
R-FCN	90.79	92.88	98.28
YOLOv3	89.85	92.71	98.01
YOLO-Bush	96.73	97.87	99.12

图 5.6 为 YOLO-Bush 与其他三种模型的训练时间与检测时间的对比，图中训练时间为各模型在深度迁移学习条件下的训练时间，检测时间为通过本文的轴瓦表面缺陷检测软件分别调用各模型至获取检测结果的耗时。观察图中数据可知，YOLO-Bush 模型的训练时间相比于 YOLOv3 有一定程度的增加，增幅为 11.84%，

但仍然小于 Faster R-CNN 和 R-FCN 的训练时间。此外，通过检测软件对各模型进行调用时，由于不同进程之间通信的影响，各模型的检测时间均比直接运行的情况下增加 6~7ms，但 YOLOv3 和 YOLO-Bush 的检测时间仍然远小于 Faster R-CNN 和 R-FCN，满足轴瓦表面缺陷检测的实时性要求。






图 5.6 各模型训练时间与检测时间对比

图 5.7 为 YOLO-Bush 与 Faster R-CNN、R-FCN、YOLOv3 的检测效果对比，图(a)、(b)、(c)分别为三张具有各类缺陷的轴瓦图像。从整体上看，YOLO-Bush 的漏检情况明显少于另外三种模型，且置信度也高于其他模型，同时预测框的定位精度也高于其他模型。


其中，通过图(a-1)~(a-4)可以看出，除 YOLO-Bush 和 YOLOv3 外，其余两种模型对于左侧擦伤均出现漏检，且 Faster R-CNN 和 YOLOv3 对于右侧油槽预测框中的划痕也出现了漏检；图(b-1)~(b-4)中，Faster R-CNN 对于左侧擦伤出现漏检，R-FCN 对于左侧油槽上方的凹坑出现漏检，同时，除 YOLO-Bush 外的三种模型对于左侧油槽上方的微小污渍，以及右侧油槽下方反光区域中的划痕均出现漏检；通过图(c-1)~(c-4)可以看出，Faster R-CNN 将轴瓦上边缘凹坑错检为污渍，同时将右侧油槽上边缘的污渍错检为凹坑。而 R-FCN 则将上边缘的光照突变错检为凹坑，且漏检右侧暗区中的凹坑。此外，YOLOv3 对于暗区中的凹坑也存在漏检现象。同时，除 YOLO-Bush 之外，其余三种模型对于油孔右上方以及左下方反光区域中的凹坑、划痕均存在漏检问题。




(a-1) Faster R-CNN




(a-2) R-FCN




(a-3) YOLOv3




(a-4) YOLO-Bush




(b-1) Faster R-CNN



(b-2) R-FCN



(b-3) YOLOv3



(b-4) YOLO-Bush




图 5.7 YOLO-Bush 与其他模型检测效果对比

综上所述，本文提出的 YOLO-Bush 模型与经典的 Faster R-CNN、R-FCN、YOLOv3 模型相比，对于轴瓦表面缺陷具有更高的检测精度以及更强的鲁棒性。无论是各类微小缺陷，抑或反光区域以及暗区中的不明显缺陷，YOLO-Bush 均可取得优异的检测效果。同时，本文所设计的轴瓦表面缺陷检测软件在采用 YOLO-Bush 模型的条件下，检测单张轴瓦图像仅需36.65ms，可以满足工业生产现场对于实时性的要求。

5.5 本章小结

本章主要介绍了轴瓦表面缺陷检测软件的设计与 YOLO-Bush 模型的综合实验。首先，给出了软件的整体架构与各模块总体功能；然后，对检测软件中主要模块的具体功能进行了详细介绍；最后，采用深度迁移学习方法对 YOLO-Bush 模型进行了训练，并开展了与 Faster R-CNN、R-FCN、YOLOv3 三种模型的对比实验。实验结果表明，YOLO-Bush 模型的 mAP 可达 98.04%，相比于经典模型具有更高的检测精度以及更强的鲁棒性，且该模型运行在本文所开发的轴瓦表面缺陷检测软件中时，检测耗时仅为36.65ms，可以满足工业生产现场对于实时性的要求。

第6章 总结与展望

6.1 工作总结

在工业自动化、智能化的背景下，生产现场对于精确、高效的机器视觉缺陷检测系统的需求尤为迫切。轴瓦作为一种广泛应用于各类旋转机械的零件，在多种领域发挥着重要作用。在实际应用中，带有表面缺陷的轴瓦会严重降低产品的质量，造成不必要的经济损失，因此在生产过程中对轴瓦表面缺陷进行检测是十分必要的。然而基于数字图像处理的传统机器视觉方法需要人工设计提取特征，对于先验知识的依赖程度较高，难以用于检测复杂多变的轴瓦表面缺陷。本文基于深度学习目标检测模型开展了轴瓦表面缺陷检测研究，主要工作如下：

(1) 设计了基于目标检测模型的轴瓦表面缺陷检测方案，搭建了实验平台并采集了轴瓦图像，从而完成数据标注，提出了一种轴瓦表面缺陷数据集。该数据集主要包括工业场景中常见的凹坑、划痕、擦伤、污渍等表面缺陷，以及油孔、油槽等轴瓦结构，并对不同尺度的样本进行了划分。该数据集可用于目标检测模型的训练与检测性能评价，极大程度地扩充了轴瓦表面缺陷检测领域的规模。

(2) 基于 Faster R-CNN、R-FCN、SSD、YOLOv3 四种经典目标检测模型进行了轴瓦表面缺陷检测对比实验。考虑到工业生产现场难以获取充足且有效的轴瓦表面缺陷数据，并且训练出检测精度较高的模型，因此提出了一种混合样本在线数据增强方法，弥补数据集规模的不足，并进一步探究了数据集扩充规模与缺陷检测精度之间的关系。同时，引入了基于深度迁移学习的目标检测模型训练过程改进方法。通过工业界经典数据集对模型进行预训练，并将模型所学知识迁移至轴瓦表面缺陷检测问题中，实现了图像低层特征的迁移，从而确保模型在数据集规模较小的情况下依然具有良好的训练效果。

(3) 提出了一种针对轴瓦表面缺陷的高效检测模型 YOLO-Bush。该模型采用了如下特征提取方法：基于 DenseNet 稠密块的深浅层特征融合；基于 SE 注意力机制模块的通道特征增强；基于 FPN 的多尺度特征融合；基于 SPP 模块的全

局与局部特征融合。同时，提出了一种基于 Focal Loss 与 DIOU Loss 相结合的损失函数，实现了轴瓦表面缺陷中难易样本权重的动态调整和预测框的精确定位。综合实验结果表明，YOLO-Bush 对于微小缺陷、反光区域缺陷、暗区缺陷具有优异的检测性能，检测精度可达 98.04%。

(4) 基于轴瓦表面缺陷检测总体方案，开发了一款具有图形交互界面的轴瓦表面缺陷检测软件，该软件可以在工业生产环境中对轴瓦表面缺陷进行检测。实验结果表明，YOLO-Bush 模型对于轴瓦表面缺陷具有优异的检测精度以及鲁棒性，且该模型运行在本文所开发的轴瓦表面缺陷检测软件中时，可以满足工业生产现场对于检测精度和实时性的要求。

6.2 工作展望

本文研究了基于深度学习目标检测模型的轴瓦表面缺陷检测技术，提出了一种缺陷检测模型 YOLO-Bush。实验结果表明，该模型具有较高的检测精度、检测效率以及鲁棒性，能够满足工业生产环境的要求。但由于作者自身水平以及时间所限，本文中的某些问题仍值得进一步研究，现对今后的研究内容做出如下展望：

(1) 本文在对轴瓦表面缺陷进行检测时采用的是定性判断方法。对于轴瓦表面的各类缺陷，本文模型只对其存在性进行了判断，而没有对缺陷程度进行区分。事实上，工业生产中对于缺陷有着严格的分级标准，因此后续研究可以引入渐变样本，将同种缺陷按照程度分成轻微缺陷、中等缺陷、严重缺陷等类别，实现更加精细的缺陷检测效果。

(2) 本文对于轴瓦表面各类缺陷均采用水平矩形边界框进行定位，在检测倾斜的油槽、划痕等狭长目标时，边界框中会包含大量非目标的背景信息。因此后续研究可以在矩形边界框中引入角度参数，实现倾斜框定位，从而提高检测精度。

(3) 本文方法在检测轴瓦表面缺陷时是对各类缺陷的简单识别，并没有精确计算缺陷的长度、宽度、面积等尺寸参数。因此后续研究可以将深度学习实例分割算法应用于轴瓦表面缺陷检测，将缺陷像素从图像背景中分离，实现对缺陷尺寸的精确测量，从而实现产品等级的精确划分。

参考文献

- [1] 黄群慧, 贺俊. 中国制造业的核心能力、功能定位与发展战略——兼评《中国制造2025》[J]. 中国工业经济, 2015(06): 5-17.
- [2] 周济. 智能制造——“中国制造2025”的主攻方向[J]. 中国机械工程, 2015(17): 2273-2284.
- [3] 汤勃, 孔建益, 伍世虔. 机器视觉表面缺陷检测综述[J]. 中国图象图形学报, 2017, 22(12): 1640-1663.
- [4] 李柱国, 石云山, 张乐山. 内燃机滑动轴承[M]. 上海: 上海交通大学出版社, 2003.
- [5] 中国机械工业联合会. GB/T 7308-2008 滑动轴承: 有法兰或无法兰薄壁轴瓦公差、结构要素和检验方法[S]. 北京: 中国标准出版社, 2008.
- [6] 马涛, 孙振国, 陈强. 基于几何与纹理特征相融合的磁粉探伤裂纹提取算法[J]. 清华大学学报(自然科学版), 2018, 58(01): 50-54.
- [7] 谭超. 多相流过程参数检测技术综述[J]. 自动化学报, 2013, 39(11): 1923-1932.
- [8] 王耀南, 陈铁健, 贺振东等. 智能制造装备视觉检测控制方法综述[J]. 控制理论与应用, 2015, 32(03): 273-286.
- [9] 章炜. 机器视觉技术发展及其工业应用[J]. 红外, 2006, 27(2): 11-17.
- [10] Burges C J C. A Tutorial on Support Vector Machines for Pattern Recognition[J]. Data mining and knowledge discovery, 1998, 2(2): 121-167.
- [11] Freund Y, Schapire R. Experiments with a New Boosting Algorithm[C]// Proceedings of the International Conference in Machine Learning. 1996: 1-15.
- [12] Canny J. A Computational Approach to Edge Detection[J]. IEEE transactions on pattern analysis and machine intelligence, 1986, PAMI-8(6): 679-698.
- [13] Gabor D. Theory of communication. Part 1: The analysis of information[J]. Journal of the Institution of Electrical Engineers - Part III: Radio and Communication Engineering, 1946, 93(26): 429-441.
- [14] Otsu N. A Threshold Selection Method from Gray-Level Histograms[J]. IEEE

- transactions on systems, man, and cybernetics, 1979, 9(1): 62-66.
- [15] Lowe D. Object recognition from local scale-invariant features[C]// Proceedings of the Seventh IEEE International Conference on Computer Vision. IEEE, 1999: 1-8.
- [16] Ojala T, Pietikäinen M, Harwood D. A comparative study of texture measures with classification based on featured distributions[J]. Pattern recognition, 1996, 29(1): 51-59.
- [17] Dalal N, B T. Histograms of oriented gradients for human detection[C]//IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2005: 1-8.
- [18] Mandriota C, Nitti M, Ancona N, et al. Filter-based feature selection for rail defect detection[J]. Machine vision and applications, 2004, 15(4): 179-185.
- [19] Jeon Y, Choi D, Yun J P, et al. Detection of scratch defects on slab surface[C]//11th International Conference on Control, Automation and Systems. IEEE, 2011: 1274-1278.
- [20] Deotale N T, Sarode T K. Fabric Defect Detection Adopting Combined GLCM, Gabor Wavelet Features and Random Decision Forest[J]. 3D research, 2019, 10(1): 1-13.
- [21] Ho T K. Random Decision Forests[C]//Proceedings of 3rd International Conference on Document Analysis and Recognition. IEEE, 1995: 278-282.
- [22] Ng H. Automatic thresholding for defect detection[J]. Pattern Recognition Letters, 2006, 27(14): 1644-1649.
- [23] Senthikumar M, Palanisamy V, Jaya J. Metal surface defect detection using iterative thresholding technique[C]//Second International Conference on Current Trends In Engineering and Technology - ICCTET 2014. IEEE, 2014: 561-564.
- [24] Truong M T N, Kim S, Park J H, et al. Automatic image thresholding using Otsu's method and entropy weighting scheme for surface defect detection[J]. Soft computing (Berlin, Germany), 2018, 22(13): 4197-4203.
- [25] Yuan X, Wu L, Peng Q. An improved Otsu method using the weighted object variance for defect detection[J]. Applied surface science, 2015, 349: 472-484.
- [26] Wakaf Z, Jalab H A. Defect detection based on extreme edge of defective region histogram[J]. Journal of King Saud University. Computer and information sciences,

- 2018, 30(1): 33-40.
- [27] Cao G, Ruan S, Peng Y, et al. Large-Complex-Surface Defect Detection by Hybrid Gradient Threshold Segmentation and Image Registration[J]. IEEE access, 2018, 6: 36235-36246.
- [28] Zhou A, Zheng H, Li M, et al. Defect Inspection Algorithm of Metal Surface Based on Machine Vision[C]//12th International Conference on Measuring Technology and Mechatronics Automation (ICMTMA). IEEE, 2020: 45-49.
- [29] Kunakornvong P, Sooraksa P. Machine Vision for Defect Detection on the Air Bearing Surface[C]//International Symposium on Computer, Consumer and Control (IS3C). IEEE, 2016: 37-40.
- [30] Liu X, Xue F, Teng L. Surface Defect Detection Based on Gradient LBP[C]// IEEE 3rd International Conference on Image, Vision and Computing (ICIVC). IEEE, 2018: 133-137.
- [31] Chen F, Jahanshahi M R, Wu R. A texture-Based Video Processing Methodology Using Bayesian Data Fusion for Autonomous Crack Detection on Metallic Surfaces[J]. Computer-Aided Civil and Infrastructure Engineering, 2017, 32(4): 271-287.
- [32] Zhou P, Zhou G, He Z, et al. A novel texture-based damage detection method for wire ropes[J]. Measurement, 2019, 148: 106954.
- [33] Wold S, Esbensen K, Geladi P. Principal component analysis[J]. Chemometrics and Intelligent Laboratory Systems, 1987, 2(1-3): 37-52.
- [34] Wu W, Hou C. Automated metal surface inspection through machine vision[J]. The imaging science journal, 2003, 51(2): 79-88.
- [35] Haralick R M, Shanmugam K, Dinstein I. Textural Features for Image Classification[J]. IEEE transactions on systems, man, and cybernetics, 1973, SMC-3(6): 610-621.
- [36] Iivarinen J. Surface defect detection with histogram-based texture features[C]// Intelligent Systems and Smart Manufacturing. SPIE, 2000: 140-145.
- [37] Kohonen T. The self-organizing map[J]. Neurocomputing, 1998, 21(1): 1-6.
- [38] Shanmugamani R, Sadique M, Ramamoorthy B. Detection and classification of

- surface defects of gun barrels using computer vision and machine learning[J]. Measurement : journal of the International Measurement Confederation, 2015,60: 222-230.
- [39] Suvdaa B, Ahn J, Ko J. Steel Surface Defects Detection and Classification Using SIFT and Voting Strategy[J]. International Journal of Software Engineering and Its Applications, 2012, 6(2): 161-166.
- [40] Li X K, Gao C, Guo Y C, et al. Image Mosaic Using SIFT for Bridge Cable Surface Flaw Detection[J]. Applied Mechanics and Materials, 2013, 333-335: 1654-1658.
- [41] Min Y, Xiao B, Dang J, et al. Real time detection system for rail surface defects based on machine vision[J]. EURASIP journal on image and video processing, 2018, 2018(1): 1-11.
- [42] Wang L, Zhao Y, Zhou Y, et al. Calculation of flexible printed circuit boards (FPC) global and local defect detection based on computer visio[J]. Circuit World, 2016, 42(2): 49-54.
- [43] Annaby M H, Fouda Y M, Rushdi M A. Improved Normalized Cross-Correlation for Defect Detection in Printed-Circuit Boards[J]. IEEE transactions on semiconductor manufacturing, 2019, 32(2): 199-211.
- [44] STRANG G. The Discrete Cosine Transform[J]. SIAM review, 1999, 41(1): 135-147.
- [45] Zhou Q, Chen R, Huang B, et al. An Automatic Surface Defect Inspection System for Automobiles Using Machine Vision Methods[J]. Sensors (Basel, Switzerland), 2019, 19(3): 644.
- [46] Mujeeb A, Dai W, Erdt M, et al. Unsupervised Surface Defect Detection Using Deep Autoencoders and Data Augmentation[C]//International Conference on Cyberworlds (CW). IEEE, 2018: 391-398.
- [47] Tao X, Zhang D, Ma W, et al. Automatic Metallic Surface Defect Detection and Recognition with Convolutional Neural Networks[J]. Applied sciences, 2018, 8(9): 1575.
- [48] Yun J P, Shin W C, Koo G, et al. Automated defect inspection system for metal surfaces based on deep learning and data augmentation[J]. Journal of manufacturing

- systems, 2020, 55: 317-324.
- [49] Wang J, Fu P, Gao R X. Machine vision intelligence for product defect inspection based on deep learning and Hough transform[J]. Journal of manufacturing systems, 2019, 51: 52-60.
- [50] Ballard D H. Generalizing the Hough transform to detect arbitrary shapes[J]. Pattern Recognition, 1981, 13(2): 111-122.
- [51] Guan S Y, Zhang W Y, Jiang Y F. A surface defect detection method of the magnesium alloy sheet based on deformable convolution neural network[J]. METALURGIJA, 2020, 59(3): 325-328.
- [52] Faghih-Roohi S, Hajizadeh S, Núñez A, et al. Deep convolutional neural networks for detection of rail surface defects[C]//International Joint Conference on Neural Networks (IJCNN). IEEE, 2016: 2584-2589.
- [53] Lee S Y, Tama B A, Moon S J, et al. Steel Surface Defect Diagnostics Using Deep Convolutional Neural Network and Class Activation Map[J]. Applied sciences, 2019, 9(24): 5449.
- [54] Simonyan K, Zisserman A. Very Deep Convolutional Networks for Large-Scale Image Recognition[J]. 2014: 1-14.
- [55] Arikan S, Varanasi K, Stricker D. Surface Defect Classification in Real-Time Using Convolutional Neural Networks[J]. 2019: 1-16.
- [56] He K, Zhang X, Ren S, et al. Delving Deep into Rectifiers Surpassing Human-Level Performance on ImageNet Classification[C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). IEEE, 2015: 1026-1034.
- [57] Lian J, Jia W, Zareapoor M, et al. Deep-Learning-Based Small Surface Defect Detection via an Exaggerated Local Variation-Based Generative Adversarial Network[J]. IEEE transactions on industrial informatics, 2020, 16(2): 1343-1351.
- [58] Goodfellow I J, Pouget-Abadie J, Mirza M. Generative Adversarial Nets[J]. arXiv preprint arXiv:1406.2661, 2014: 1-9.
- [59] Deshpande A M, Minai A A, Kumar M. One-Shot Recognition of Manufacturing Defects in Steel Surfaces[J]. Procedia Manufacturing, 2020, 48: 1064-1071.
- [60] Bromley, Jane. Signature verification using a "siamese" time delay neural

- network[J]. Advances in neural information processing systems, 1993, 6: 737-744.
- [61] Yu W, Zhang Y, Shi H. Surface Defect Inspection Under a Small Training Set Condition[M]//Cham: Springer International Publishing, 2019: 517-528.
- [62] Redmon J, Divvala S, Girshick R. You Only Look Once: Unified, Real-Time Object Detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2016: 779-788.
- [63] Lin C, Chen C, Yang C, et al. Cascading Convolutional Neural Network for Steel Surface Defect Detection[M]//Cham: Springer International Publishing, 2019: 202-212.
- [64] Liu W, Anguelov D, Erhan D, et al. Single Shot MultiBox Detector[C]//European conference on computer vision. LNCS, 2016: 21-37.
- [65] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2016: 770-778.
- [66] Wu X, Cao K, Gu X. A Surface Defect Detection Based on Convolutional Neural Network[C]//International Conference on Computer Vision Systems. LNCS, 2017: 185-194.
- [67] Szegedy C, Liu W, Jia Y, et al. Going Deeper With Convolutions[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2015: 1-9.
- [68] Shihavuddin A, Chen X, Fedorov V, et al. Wind Turbine Surface Damage Detection by Deep Learning Aided Drone Inspection Analysis[J]. Energies (Basel), 2019, 12(4): 676.
- [69] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[C]//IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2015: 1-14.
- [70] Dong H, Song K, He Y, et al. PGA-Net: Pyramid Feature Fusion and Global Context Attention Network for Automated Surface Defect Detection[J]. IEEE transactions on industrial informatics, 2020, 16(12): 7448-7458.
- [71] He Y, Song K, Meng Q, et al. An End-to-End Steel Surface Defect Detection

- Approach via Fusing Multiple Hierarchical Features[J]. IEEE transactions on instrumentation and measurement, 2020, 69(4): 1493-1504.
- [72] Guo T, Wu L, Wang C, et al. Damage detection in a novel deep-learning framework: a robust method for feature extraction[J]. Structural health monitoring, 2020, 19(2): 424-442.
- [73] Liu Y, Xu K, Xu J. Periodic Surface Defect Detection in Steel Plates Based on Deep Learning[J]. Applied sciences, 2019, 9(15): 3127.
- [74] Hochreiter S, Schmidhuber J. Long Short-term Memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [75] Block S B, Da Silva R D, Dorini L B, et al. Inspection of Imprint Defects in Stamped Metal Surfaces Using Deep Learning and Tracking[J]. IEEE transactions on industrial electronics (1982), 2021, 68(5): 4498-4507.
- [76] Chen F, Jahanshahi M R. NB-CNN: Deep learning-based crack detection using convolutional neural network and Naïve Bayes data fusion[J]. IEEE Transactions on Industrial Electronics, 2017, 65(5): 4392-4400.
- [77] Deng J, Dong W, Socher R, et al. ImageNet: A large-scale hierarchical image database[C]//IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2009: 248-255.
- [78] Everingham M, Van Gool L, Williams C K I, et al. The PASCAL Visual Object Classes (VOC) Challenge[J]. International Journal of Computer Vision, 2010, 88: 303-338.
- [79] Lin T, Maire M, Belongie S, et al. Microsoft COCO: Common Objects in Context[C]//European Conference on Computer Vision. LNCS, 2014: 740-755.
- [80] Koch R, Schiele B. DAGM 2007 dataset[EB/OL]. Germany: DAGM, [2020-9-25]. <https://www.dagm.de/the-german-association-for-pattern-recognition>.
- [81] Song K, Yan Y. NEU surface defect database[EB/OL]. China: Northeastern University, [2020-9-25]. http://faculty.neu.edu.cn/me/songkc/Vision-based_SIS_Steel.html.
- [82] Girshick R, Donahue J, Darrell T, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]//Proceedings of the IEEE

- Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2014: 580-587.
- [83]Uijlings J R R, van de Sande K E A, Gevers T, et al. Selective Search for Object Recognition[J]. International Journal of Computer Vision, 2013, 104: 154-171.
- [84]Girshick R. Fast R-CNN[C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). IEEE, 2015: 1440-1448.
- [85]Dai J, Li Y, He K. R-FCN: Object Detection via Region-based Fully Convolutional Networks[C]//Conference and Workshop on Neural Information Processing Systems. IEEE, 2016: 1-11.
- [86]Lowe D G. Distinctive Image Features from Scale-Invariant Keypoints[J]. International Journal of Computer Vision, 2004, 60: 91-110.
- [87]Redmon J, Farhadi A. YOLO9000: Better, Faster, Stronger[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2017: 7263-7271.
- [88]Redmon J, Farhadi A. YOLOv3: An Incremental Improvement[J]. arXiv preprint arXiv:1804.02767, 2018: 1-6.
- [89]Lin T, Dollar P, Girshick R, et al. Feature Pyramid Networks for Object Detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2017: 2117-2125.
- [90]Kingma D P, Ba J. Adam: A Method for Stochastic Optimization[C]//International Conference for Learning Representations. 2015: 1-15.
- [91]Tan C, Sun F, Kong T, et al. A Survey on Deep Transfer Learning[C]//International Conference on Artificial Neural Networks. LNCS, 2018: 270-279.
- [92]Zeiler M D, Fergus R. Visualizing and Understanding Convolutional Networks[C]//European Conference on Computer Vision. LNCS, 2014: 818-833.
- [93]He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2016: 770-778.
- [94]Ioffe S, Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[C]//Proceedings of the 32nd International

-
- Conference on Machine Learning. PMLR, 2015: 448-456.
- [95] Maas A L, Hannun A Y, Ng A Y. Rectifier Nonlinearities Improve Neural Network Acoustic Models[C]//Proceedings of the 30th International Conference on Machine Learning. 2013: 1-6.
- [96] MacQueen J. Some methods for classification and analysis of multivariate observations[J]. Berkeley Symposium on Mathematical Statistics and Probability, 1967, 5(1): 281-297.
- [97] Huang G, Liu Z, van der Maaten L, et al. Densely Connected Convolutional Networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2017: 4700-4708.
- [98] Hu J, Shen L, Sun G. Squeeze-and-Excitation Networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2018: 7132-7141.
- [99] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015, 521: 436-444.
- [100] He K, Zhang X, Ren S, et al. Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015,37(9): 1904-1916.
- [101] Arthur D, Vassilvitskii S. K-means++: The Advantages of Careful Seeding[R]. Stanford University, 2006.
- [102] Yu J, Jiang Y, Wang Z, et al. UnitBox: An Advanced Object Detection Network[C]//Proceedings of the 24th ACM international conference on Multimedia. ACM, 2016: 516-520.
- [103] Rezatofighi H, Tsoi N, Gwak J, et al. Generalized Intersection Over Union: A Metric and a Loss for Bounding Box Regression[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2019: 658-666.
- [104] Lin T, Goyal P, Girshick R, et al. Focal Loss for Dense Object Detection[C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). IEEE, 2017: 2980-2988.