

分类号 022

学校代码 10495

U D C 51

密 级 公开

武汉纺织大学

硕士学位论文

基于 YOLO 改进的目标检测算法及应用研究

作者姓名:	詹晨美
学 号:	2215173016
指导教师:	阮曙芬 副教授
学科门类:	理学
专 业:	数学
研究方向:	计算机视觉
完成日期:	二零二五年五月

Wuhan Textile University

M. S. Dissertation

**Research on Improvements and Applications of
YOLO-Based Object Detection Algorithms**

Candidate: Zhan Chenmei

Supervisor: Assoc. Prof. Ruan Shufen

Time: May 2025

摘要

目标检测作为计算机视觉领域的核心技术，在工业智能化进程中发挥着关键作用。尽管 YOLO 系列算法凭借其卓越的平衡性在工业检测领域占据主导地位，但在复杂应用场景中仍面临三大核心挑战：首先，小目标特征表征不足导致检测精度受限；其次，多尺度目标间几何差异显著引发的尺度适应性缺陷；此外，复杂背景噪声干扰造成的误检率攀升问题。为此，本研究提出两种改进框架：基于 YOLOv5 架构提出 PCD-YOLO 模型，以强化遥感图像中多尺度目标特征捕获能力并提高复杂背景下模型的检测能力；基于 YOLOv9 框架提出 EPSC-YOLO 模型，以提升表面缺陷检测过程中小目标的检测能力以及复杂场景下的检测鲁棒性。

1. 针对高空视角下目标尺度剧烈变化引发的多尺度适应问题，以及复杂地表环境干扰带来的检测不稳定性问题。本文基于 YOLOv5 提出了一种改进算法 PCD-YOLO：首先设计了一个基于无参数注意力机制 (SimAM) 的卷积模块 PSConv，以提升多尺度目标检测能力。其次设计了一个注意力卷积模块 CGAM，缓解了复杂背景下目标难以检测问题。最后，检测头更换为解耦合头 (Decoupled Head)，以进一步提高目标检测的整体性能。在六个公开数据集上的实验结果显示，改进后的算法 PCD-YOLO 在保持实时检测速度的前提下， mAP_{50}^{val} 提升了 0.7%-4.33%， $mAP_{50:95}^{val}$ 提升了 0.83%-2.63%，表明本算法在精度与适应性上均在遥感图像目标检测中表现出显著优势，验证了其有效性与广泛适用性。

2. 针对工业产品表面缺陷检测面临微小缺陷易被忽略、缺陷尺寸变化剧烈以及表面纹理、反光等干扰导致误检率升高的问题。本文基于 YOLOv9 提出了一种改进算法 EPSC-YOLO：首先引入了多尺度注意模块 (EMA)，并在主干网络中设计了两种新的金字塔卷积，以更好地进行特征提取；其次，使用 Soft-NMS 作为后处理算法，以提高目标检测精度。最后，设计了一种新的卷积注意力模块 CISBA，以提高对复杂背景下小目标的检测能力。在两个公开数据集上的实验结果显示，改进后的 EPSC-YOLO 模型在保持实时检测速度的前提下， mAP_{50}^{val} 提升了 2%-2.4%， $mAP_{50:95}^{val}$ 增加了 2.4%-5.1%，显示出 EPSC-YOLO 算法显著的精度优势。

关键词：目标检测；YOLO；注意力机制；多尺度目标；小目标

研究类型：应用研究

Abstract

Object detection, as a core technology in the field of computer vision, plays a crucial role in the process of industrial intelligence. Although the YOLO series algorithms dominate industrial inspection due to their outstanding balance of speed and accuracy, they still face three major challenges in complex application scenarios: First, insufficient feature representation of small objects limits detection accuracy. Second, significant geometric differences among multi-scale objects lead to scale adaptability issues. Additionally, interference from complex background noise results in an increased false detection rate. To address these challenges, this study proposes two improved frameworks: the PCD-YOLO model, based on the YOLOv5 architecture, to enhance the capability of capturing multi-scale object features in remote sensing images and improve detection performance in complex backgrounds; and the EPSC-YOLO model, based on the YOLOv9 architecture, to improve the detection accuracy of small objects in surface defect inspection and enhance detection robustness in complex scenarios.

1. To address the multi-scale adaptation challenges caused by drastic variations in object sizes from high-altitude perspectives and the detection instability introduced by complex surface environments, this paper proposes an improved algorithm, PCD-YOLO, based on YOLOv5. Firstly, a convolutional module, PSConv, based on the parameter-free attention mechanism (SimAM) was designed to enhance multi-scale object detection capability. Second, a Convolutional Global Attention Module (CGAM) is introduced to mitigate the difficulty of detecting objects in complex backgrounds. Finally, the detection head is replaced with a Decoupled Head to further improve overall detection performance. Experimental results on six public datasets demonstrate that PCD-YOLO achieves a 0.7%–4.33% improvement in mAP_{50}^{val} and a 0.83%–2.63% improvement in $mAP_{50:95}^{val}$ while maintaining real-time detection speed. These results indicate that the proposed algorithm exhibits significant advantages in accuracy and adaptability for remote sensing object detection, verifying its effectiveness and broad applicability.

2. To address the challenges in industrial surface defect detection, including the tendency to overlook small defects, drastic variations in defect sizes, and increased false detection rates caused by surface textures and reflections, this paper proposes an improved algorithm, EPSC-YOLO, based on YOLOv9. First, a multi-scale attention module (EMA) is introduced, along with two newly designed pyramid convolutions in the backbone network,

to enhance feature extraction. Second, Soft-NMS is adopted as the post-processing algorithm to improve detection accuracy. Finally, a novel Convolutional Attention Module (CISBA) is designed to enhance the detection of small objects in complex backgrounds. Experimental results on two public datasets demonstrate that the improved EPSC-YOLO model achieves a 2%–2.4% increase in mAP_{50}^{val} and a 2.4%–5.1% improvement in $mAP_{50:95}^{val}$ while maintaining real-time detection speed, highlighting its significant accuracy advantage.

Key words: Object detection; YOLO; Attention mechanism; Multi-scale objects; Small objects

Thesis: Applied research

目 录

1 绪论.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	1
1.2.1 遥感图像目标检测算法研究.....	3
1.2.2 表面缺陷检测算法研究.....	4
1.3 现阶段存在的问题.....	5
1.4 研究内容与论文结构安排	6
1.4.1 研究内容	6
1.4.2 论文结构安排.....	7
2 相关理论基础	8
2.1 卷积神经网络.....	8
2.1.1 卷积层.....	9
2.1.2 池化层.....	10
2.1.3 全连接层	11
2.1.4 激活函数	11
2.2 区域卷积神经网络系列算法分析	12
2.3 YOLO 系列算法分析.....	15
2.4 YOLOv5 目标检测算法.....	17
2.4.1 网络结构	17
2.4.2 Backbone.....	17
2.4.3 Neck	19
2.4.4 Head	19
2.4.5 损失函数	19
2.4.6 非极大值抑制(Non-Maximum Suppression, NMS).....	20
2.5 YOLOv9 目标检测算法.....	21
2.5.1 网络架构	21
2.5.2 Backbone.....	22
2.5.3 Neck	24
2.5.4 Head	24
2.5.5 损失函数	24
2.6 基于改进 YOLO 的目标检测算法	24
2.6.1 卷积.....	25
2.6.2 注意力机制.....	25
2.6.3 非极大值抑制(NMS)	25

2.7 数据集介绍.....	27
2.7.1 遥感图像目标检测数据集.....	27
2.7.2 钢材表面缺陷检测数据集.....	30
2.8 本章小结.....	32
3 基于改进 YOLOv5 的遥感图像目标检测算法.....	33
3.1 引言.....	33
3.2 基于金字塔卷积设计的 PSConv 模块.....	33
3.3 基于全局注意力机制设计的 CGAM 模块.....	35
3.4 解耦合头.....	37
3.5 PCD-YOLO 目标检测算法实验分析.....	37
3.5.1 网络架构.....	38
3.5.2 消融实验及分析.....	38
3.5.3 对比实验及分析.....	41
3.6 本章小结.....	44
4 基于改进 YOLOv9 的钢材表面缺陷目标检测算法.....	45
4.1 引言.....	45
4.2 基于跨空间学习的高效多尺度注意力模块(EMA).....	45
4.3 金字塔卷积.....	46
4.4 Soft-NMS.....	47
4.5 基于卷积块注意力模块设计的 CISBA 模块.....	49
4.6 EPSC-YOLO 目标检测算法实验分析.....	51
4.6.1 网络架构.....	52
4.6.2 消融实验及分析.....	52
4.6.3 可视化结果及分析.....	54
4.6.4 对比实验及分析.....	56
4.7 本章小结.....	60
5 总结与展望.....	61
5.1 工作总结.....	61
5.2 未来展望.....	61
参考文献.....	62

1 绪论

1.1 研究背景和意义

在大数据时代全面来临的当下，海量、异构且动态更新的数据资源已然成为推动社会发展的核心要素。数据形态大致可分为结构化数据（像数据库表格）、半结构化数据（例如 XML 文件）以及非结构化数据（如文本、图像、音频等）这三大类。在非结构化数据里，图像和视频信息由于蕴含着丰富的视觉语义，成为了信息提取的关键载体。而目标检测技术作为解析这类数据的核心手段，在有着自动化、智能化以及安全性需求的场景中发挥着不可替代的作用。其应用已经深入渗透到工业质检、农业监测、运动分析以及医学影像等多个不同领域，为产业升级提供了坚实的技术保障。随着计算机视觉技术取得突破以及硬件算力不断提升，目标检测不仅能够在复杂背景中精准地定位目标，还能在实时性和鲁棒性之间找到平衡，成为智能化转型的核心驱动力之一。

遥感图像分析属于目标检测技术的一个重要应用方向。近年来，遥感数据集的规模和复杂程度持续增加，其涵盖的建筑分布、交通路网、农田布局以及自然资源等地理信息，为地球观测^[1]、环境监测^[2]和城市规划^[3]等宏观决策提供了至关重要的数据支持。高分辨率、多光谱的遥感图像通常包含大量细粒度目标，比如小型车辆、低空无人机或者植被病害区域等，这对检测算法的多尺度特征提取能力和抗背景干扰能力提出了更高的要求。怎样从这些图像中精确识别目标并提取语义信息，已经成为遥感智能解译面临的核心挑战，同时也是推动卫星遥感从“数据获取”迈向“知识服务”的关键技术突破点。

在微观生产领域，随着消费市场对产品品质的要求日益提高，工业质检逐渐成为衡量制造业竞争力的核心指标。目标检测技术通过精准识别产品缺陷（如表面瑕疵、装配误差等）来提高良品率，从而降低人力成本并加快生产节奏。例如工业上产品缺陷检测过程中，它可以实现焊点质量的全流程自动化检测。此外，该技术还能够实时监测危险操作或设备异常情况，保障生产的安全与合规性。以工业产品缺陷检测为例，通过高精度视觉检测系统（如 3D 机器视觉或 X 射线成像技术）对产品表面裂纹、尺寸偏差等缺陷进行实时监测，及时发现问题，从而达到优化产品质量^[4]、降低生产成本^[5]、提高生产效率^[5]、确保安全^[6]等目的。传统上，缺陷检测是由人工来完成的。但是，人工缺陷检查非常昂贵危险并且效率低下。因此，一个结构简单、高效率、高精度的目标检测算法是非常重要的。

1.2 国内外研究现状

目标检测算法的发展经历了两个关键时期，2012 年之前的传统算法时期以及 2014 年之后的深度学习算法时期。传统算法时期，目标检测主要依赖于人工设计的特征和传

统的计算机视觉技术。这些传统的技术通常包括特征提取、目标分类以及检测框后处理。传统的目标检测算法易受背景的干扰，泛化能力较弱。2001 年，Viola 和 Jones 引入了 VJ 目标检测框架，实现了显著的任务识别^[7]，Dalal 和 Triggs 在 2005 年提出了一种定向梯度（HOG）检测器^[8]。Felzenszwalb 等人在 2010 年提出了基于 HOG 的可变形部分模型（DPM）^[9]，这些算法遭受高计算成本和复杂的检测过程。2012 年，Hinton 等人利用基于 CNNs（卷积神经网络）的深度学习模型 AlexNet 在 ImageNet 大规模图像分类竞赛中取得了突破。这一突破引发了深度学习的兴起，并导致了第一个具有 CNN 特征的目标检测模型的诞生，它被称为 R-CNN（区域卷积神经网络）^[11]，该模型的出现解决了上述问题，标志着目标检测算法的开始。尽管 R-CNN 解决了传统目标检测算法中精度低的问题，但它存在检测速度慢的缺点。为了解决这个问题，逐渐出现了 Fast R-CNN（Fast Region Convolutional Neural Network）^[13]，Faster R-CNN（Faster Region Convolutional Neural Network）^[14]和 Mask R-CNN（Mask Region Convolutional Neural Network）^[15]等算法。上述的两阶段目标检测方法虽然通过两个独立的处理阶段可以提供准确的检测结果和精确的边界框定位，但是第一阶段的候选区域需要生成大量的候选框，导致算法需要显著的计算和时间开销，影响算法的整体效率。此外，在具有高实时性能要求的应用程序中，它们受到相对低处理速度的限制。

2016 年，Liu 等人提出了单阶段目标检测算法（Single Shot MultiBox Detection, SSD）^[16]。与传统的两阶段目标检测算法不同，SSD 对单个图像直接进行目标检测，无需显式生成区域，以更快的速度下实现较高的检测精度，适用于实时性能应用。但 SSD 涉及一级处理程序，设计相对复杂。同年，Joseph Redmon 和他的团队提出了 YOLOv1 目标检测算法作为对上述挑战的假设^[17]。与两阶段方法和 SSD 不同，YOLOv1 将目标检测任务视为一个回归问题。通过引入单一前向传播网络，YOLOv1 算法一次性预测图像中多个目标的边界框和类别概率，显著提高了检测速度，实现了实时性能。同时，该算法通过将图像划分为网格并采用多尺度处理来解决不同尺度目标检测的问题。YOLOv1 的出现标志着目标检测领域的重大进展，为 YOLO 系列目标检测算法的后续发展奠定了坚实的基础。同年，Joseph Redmon 等人提出了 YOLOv2（YOLO9000）该算法在 YOLOv1 的基础上引入了多尺度预测和锚框。通过对吞吐量结构的改进，该算法还支持多类目标检测，显著提高了算法的准确性和鲁棒性^[18]。2018 年，Joseph Redmon 等人提出了 YOLOv3^[19]。YOLOv3 算法通过引入多尺度检测、优化锚框以及采用更深的 Darknet-53 网络结构，解决了目标检测中小目标和多尺度目标精确检测的难题。2020 年，Bochkovskiy 等人提出了 YOLOv4^[20]该算法通过引入 CSPDarknet53^[21]、SPP^[22]和 PANet^[23]等技术优化网络结构和训练策略，显著提高了目标检测算法的精度和速度。2020 年 6 月，Glenn Jocher 发布了 YOLOv5^[24]。2022 年，美团的视觉智能部门开发了 YOLOv6^[25]，

致力于工业应用，该框架同样重视检测精度和推理效率。2023 年，Bochkovskiy 等人提出了 YOLOv7^[26]，它专注于优化训练过程。YOLOv7 结合了几种优化的模块和方法，通过增加训练成本，以提高目标检测的准确性，但不增加推理成本。这不同于其他要么专注于生产低功耗单片机解决方案，以提高边缘 CPU 推理速度，要么专注于提高各种 GPU 的推理速度的目标检测算法。YOLOv8 算法提出了一个 C2f 模块，实现了高效的特征提取和特征融合^[27]。当前的目标检测方法主要关注设计合适的目标函数和网络架构，以使模型的预测尽可能接近实际情况，但在这一过程中常常面临信息丢失的问题。2024 年，Wang 等人提出了 YOLOv9 算法，该算法通过引入 PGI 和 GELAN 网络架构的概念，解决了信息的丢失问题^[28]。YOLOv9 算法在 MS-COCO 数据集上取得了最好的性能。同年，Wang 等人提出了 YOLOv10，YOLOv10 算法采用了一致的对偶分配策略，消除了该算法对 NMS 的依赖性。提出了一种全息效率-精度驱动模型设计，包括轻量级分类头、空间通道解耦降采样和秩引导块设计^[29]。Khanam 等人提出的 YOLOv11 通过引入 C3k2 模块、SPPF 结构与 C2PSA 组件增强多尺度特征提取能力，扩展支持目标检测、实例分割、姿态估计及旋转目标检测等多任务，在参数效率与计算性能间取得平衡，其多尺寸模型（nano 至 extra-large）适配边缘端到云端场景，显著提升实时计算机视觉应用的精度与泛化能力^[30]。Tian 等人于 2025 年提出 YOLOv12，YOLOv12 是一种以注意力机制为核心的全新框架，首次在保持与 CNN 模型相当推理速度的前提下，充分释放注意力机制的建模优势，其各规模模型（如 YOLOv12-N/S）在精度与效率上均显著超越现有实时检测器^[31]。

1.2.1 遥感图像目标检测算法研究

遥感图像通常是从较高高度拍摄得到，所以大多数目标都较小^[32]，与周围背景难以区分，导致检测精度下降。其次，遥感图像通常是从空中俯拍得到，视角相对单一，导致有用信息有限，对于细节方面的识别比较困难。并且对于遥感图像数据集，通常会出现数据集中某些类别的目标数量可能远多于其他类别，导致模型在训练时对这些类别的关注度不同，从而导致模型对某些类别的目标检测性能下降。

Ren 等人针对光学遥感图像中的小目标检测问题，提出了一种改进的 Fast R-CNN 方法^[32]，通过优化 RPN 阶段的锚点设置，设计利用高分辨率特征图的架构，整合上下文信息，解决类别不平衡问题，并在训练过程中引入“随机旋转”数据增强方法，有效增强了 Fast R-CNN 在检测小目标的性能。Zhang 等人提出了一种改进的 Faster R-CNN 算法^[34]，通过设计多分辨率卷积特征提取模块，并在区域建议网络（RPN）中对更大特征图进行 ROI 池化，增强了对小型和聚集船舶的检测能力。Xie 等人提出了一种新的目标检测网络 NEOOD^[35]，通过设计特征提取、特征融合、特征增强和多尺度检测四个模块，结合残差模块、感受野增强（RFE）模块以及并行的多尺度检测器，显示整合高低级特

征并增强小目标信息。此外采用 Focal Loss 解决类别不平衡问题, 并引入 Soft-NMS 优化密集目标的边界框保留。NEOOD 算法有效提高了小目标检测的能力。Zhu 等人提出了一种基于多尺度和动态锚定分配 (DAA) 策略的新型目标检测算法 SELU-DenseNet (MSE-DenseNet) [36], 用于遥感图像的多尺度目标检测。Chang 等人在 YOLOv2 的基础上开发了一种层数较少的新架构 YOLOv2-reduced[37], 该方法在 SAR 图像中的船舶检测中获得更高的精度。Nie 等人提出了一种改进的 Mask-RCNN 方法, 通过在 Mask R-CNN 的 FPN 结构中添加自下而上的结构, 并在自下而上的结构中使用通道级注意力来分配每个通道的权重, 使用空间注意力机制为特征图中的每个像素分配相应的权重。该方法可以在像素级准确检测和分割船舶[38]。Ma 等人提出了一种改进的 YOLOv3 算法[39]。通过将主干网络替换为轻量级的 ShuffleNetv2, 并将损失函数替换为 GIoU, 该算法在地震后高分辨率卫星图像检测中非常有效。Wan 等人提出了一种增强的方法, 名为 HR-YOLOv5[40], 该方法利用多层特征金字塔、多检测头策略和混合注意力模块来提高目标检测网络在光学遥感图像中的效果。

1.2.2 表面缺陷检测算法研究

缺陷检测在优化产品质量[41]、降低生产成本[42]、提高生产效率[43]、确保安全[44]、符合监管标准、提供数据分析和增强市场竞争力等方面起着至关重要的作用, 已成为现代制造和生产过程中不可或缺的环节。传统的缺陷检测主要依赖于人工完成, 但这种方法不仅效率低、成本高, 而且可能存在安全隐患。因此, 如何解决人工缺陷检测中的问题, 开发一种结构简单、快速且高精度的自动化检测算法, 显得尤为关键。目前, 越来越多先进的缺陷检测算法应运而生, 这些算法多基于机器学习和计算机视觉技术, 能够实现自动或半自动的缺陷识别与异常检测。随着研究的不断深入, 相关算法的性能不断提升, 逐渐成为各类企业中不可或缺的重要工具。

Zeng 等人提出了一种多尺度特征融合方法, 称为空洞空间金字塔池化-平衡特征金字塔网络 (ABFPN) [45], 该方法使用了跳跃式空洞空间金字塔池化模块 (包含五个 D-ASPP 块[46]) 和平衡模块 (包含三个块, 分别是调整大小和平均块、空间非局部块和残差块[47][48])。Rudolph 等人提出了一种创新的全卷积跨尺度归一化流 (CS-Flow) 方法[49], 能够联合处理不同尺度的多个特征图。Lv 等人提出了一种基于单发多框检测器 (SSD) 的新型缺陷检测网络 (EDDN[50]), 能够处理不同尺度的缺陷。Cheng 等人提出了一种新的深度神经网络 DEA_RetinaNet[51], 使用了自适应空间特征融合 (ASFF) 模块和一种新颖的通道注意力机制。Rudolph 提出了一种名为 DifferNet 的新型网络[52], 利用卷积神经网络提取的描述性特征, 通过归一化流估计其密度。Xu 等人提出了一种改进的 Mask R-CNN 算法[53], 用于隧道表面缺陷检测和分割, 该算法引入了路径聚合特征金字塔网络 (PAFPN) 并增加了边缘检测分支。路面上的裂缝、龟裂和坑洞容易导致

交通安全问题，因此及时检测和识别这些缺陷对于减少危害至关重要。Chen 等人提出了一种基于多尺度移动注意力的网络 MANet^[54]，用于路面缺陷检测。MANet 不仅采用了编码器-解码器架构，还结合了多尺度卷积和混合注意力模块。Fan 等人提出了一种改进的缺陷苹果检测算法^[55]，该算法基于 YOLOv4，结合了通道剪枝和层剪枝方法，以及一种新的基于 L1 范数的非极大值抑制（NMS）技术。该算法成功实现了苹果分选过程中的缺陷检测，但在光照变化下表现不佳，难以检测复杂背景中的小缺陷，并且在区分不同类型水果时存在精度问题。Hu 等人提出了一种改进的 YOLOv5 算法^[56]，用于检测橙子表面缺陷，该算法集成了 CBAM 注意力机制并将损失函数替换为 DIoU。该方法提高了柑橘表皮缺陷的检测精度，但在区分小缺陷和表皮噪声方面仍存在挑战，尤其是当多种表面缺陷共存时。Xiong 等人提出了一种改进的 YOLOv5 深度学习算法^[57]，用于车牌缺陷检测，该方法引入了一种结合 ECA-net 和 CBAM 的新型注意力模块，采用了简化的 BottleneckCSP 结构，并将损失函数修改为 Alpha-IoU。该算法在检测低对比度和小缺陷时表现不佳，且在复杂背景下的误检率较高。Xu 等人提出了一种改进的 YOLOv7 算法^[58]，用于焊缝表面缺陷检测，该算法引入了坐标注意力机制，并将新设计的 Le-HorBlock 模块集成到骨干网络的最后四个 CBS 模块中以充分提取信息。此外，将 CIoU 损失函数替换为 SIoU 损失函数。该算法在管道焊缝表面缺陷检测方面取得了一定进展，但在大规模焊缝缺陷检测的实时性和高精度平衡方面仍存在挑战。Zhang 等人提出了一种 YOLOv8-CM 框架^[59]，结合了卷积块注意力模块（CBAM）、Segment Anything Model（SAM）和 U 形网络（U-net），该算法提高了隧道缺陷和物体自动检测与分割的精度，但在分割复杂形状缺陷时存在问题，尤其是在重叠或结构相似的区域，算法可能会出现误识别或漏检。Lu 等人提出了一种基于 YOLOv9 的改进算法 WSS-YOLO^[60]，该算法结合了 C2f-DSC（将动态蛇形卷积集成到 C2f 中）、GSConv 和 VOV-GSCSP 模块，改进了钢材表面缺陷检测网络，但算法在处理不规则和微小缺陷时性能仍有限，尤其是当刚才表面存在氧化物、腐蚀和其他复杂纹理时，缺陷检测结果不稳定。

1.3 现阶段存在的问题

目标检测作为计算机视觉领域的重要研究方向，近年来在各类应用中取得了显著的进展。然而，尽管算法性能不断提升，目标检测仍然面临诸多挑战。首先，精度问题仍是一个突出难题，特别是在小目标检测和密集目标重叠的情况下，现有算法常常出现误检或漏检的情况。其次，许多高精度算法计算开销巨大，推理速度较慢，这对于需要实时处理的应用场景（如视频监控、自动驾驶等）来说，构成了不小的瓶颈。此外，目标检测算法在复杂环境中的适应性较差，例如光照变化、视角变化和目标遮挡等因素，都可能导致检测精度的下降。数据标注问题也是制约算法发展的关键因素，标注成本高且数据不平衡问题使得模型对少数类别的识别能力较弱。再者，在复杂背景或遮挡场景下，

算法的鲁棒性受到显著影响，背景干扰和遮挡问题使得目标检测精度无法得到有效保证。加之，现有的深度学习模型通常具有较差的可解释性，这使得其在某些安全敏感领域的应用受到限制。最后，跨域迁移能力差，使得目标检测模型在不同领域之间的迁移往往面临性能下降的问题。综上所述，尽管目标检测技术取得了许多突破，但其在实际应用中的普及仍面临诸多挑战，亟需进一步的研究和优化。

1.4 研究内容与论文结构安排

1.4.1 研究内容

针对遥感图像以及表面缺陷的目标检测任务现存的一些问题，本文基于 YOLOv5 目标检测算法进行改进，主要包括骨干网络的特征提取模块，颈部网络特征提取模块，以及检测头等方面。通过将多种改进进行结合提出了针对遥感图像目标检测的 PCD-YOLO 算法和针对表面缺陷检测的 EPSC-YOLO 算法，并进行了实验和验证。本文主要工作分为六个章节来进行论述。

第一章，绪论。首先对本文的研究背景进行叙述，并综合分析国内外的研究现状，给出本文的研究目的与研究意义；然后概括本文的主要研究内容，并在此基础上，梳理本文的技术路线；最后给出本文的论文结构安排。

第二章，相关理论基础知识。首先，详细介绍了卷积神经网络的基本架构，并对卷积神经网络在目标检测中的应用与挑战进行了分析。其次，对一系列的区域卷积神经网络进行了对比分析详细分析了 YOLOv5、YOLOv9 算法的网络架构以及创新。最后介绍了本文的数据集选取以及依据。

第三章，基于改进 YOLO 的目标检测算法。本章针对 YOLO 算法可改进的点做了详细的描述，主要包括改进原始的 Conv 模块，引入注意力机制，使用改进的后处理方法。

第四章，基于改进 YOLOv5 的遥感图像目标检测算法，PCD-YOLO。基于经典的 YOLOv5 模型，首先，提出了基于无参数注意力机制 (SimAM) 的卷积模块，PSConv，用于增强模型对重要多尺度目标的检测能力。其次，提出了基于全局注意力机制的卷积模块，CGAM，用于增强模型层之间的依赖关系，以进一步提高模型提取特征的能力。最后，使用了解耦合头替换传统的耦合头进一步增强模型的定位以及分类的精度。

第五章，基于改进 YOLOv9 的钢材表面缺陷目标检测算法，EPSC-YOLO。在经典的 YOLOv9 模型的基础上，首先，引入基于跨空间学习的高效多尺度注意力机制用于提高对多尺度重要目标的注意力。其次，将一个三层的金字塔卷积和一个两层的金字塔卷积整合在 YOLOv9 的不同位置用于提高网络对多尺度目标的特征提取能力以及检测精度。接下来，设计了一种新的卷积注意机制模块 CISBA 模块用于提高在复杂背景下模

型对小目标的检测能力。最后，使用 Soft-NMS 替换传统的 NMS 用于平滑和抑制重叠检测框的分数，减少信息丢失，提高多目标检测精度。

第六章，总结与展望。本文针对特定的场景下 YOLO 算法会存在，小目标检测精度不高、多尺度目标检测以及跨域目标检测精度不高等问题，提出了两种改进算法：PCD-YOLO、EPSC-YOLO，并对模型的缺陷进行了阐述以及接下来的改进方向。

1.4.2 论文结构安排

本文共包括六个章节，具体安排见图 1.1:




图 1.1 论文结构图

Fig. 1.1 The structure of paper

2 相关理论基础

2.1 卷积神经网络

卷积神经网络的起源可以追溯到 20 世纪 80 年代,其核心灵感来自日本学者福岛邦彦在 1979^{[61][62]}和 1980^[63]年发表的 neocognitron 模型。福岛邦彦通过模拟生物视觉皮层的结构,设计出了 neocognitron 这一神经网络。neocognitron 是一种具有深度结构的神经网络,被认为是最早的深度学习算法之一。在该模型中,隐层由交替的 S 层和 C 层构成,S 层单元在局部感受野内提取图像特征,而 C 层则负责汇聚来自不同感受野的相同特征信息。S 层与 C 层的组合有效地实现了特征提取与筛选功能,类似于卷积神经网络中的卷积层和池化层。因此,neocognitron 被认为是卷积神经网络研究的启蒙工作之一,对后续神经网络的发展起到了开创性作用。直到 20 世纪 90 年代,卷积神经网络才开始在实际应用中展现其潜力。由 Yann LeCun 等人提出的 LeNet 网络^[64],采用了类似 neocognitron 的 S 层与 C 层的结构,并成功应用于手写数字识别任务,成为卷积神经网络在现实世界问题中应用的开端。卷积神经网络架构与常规人工神经网络架构非常相似,通常由输入层、卷积层、池化层、全连接层、输出层构成。常见的卷积神经网络架构(手写数字识别 LeNet 为例),见图 2.1。




图 2.1 LeNet 网络架构

Fig. 2.1 The structure of LeNet

卷积神经网络的输入层负责接收多维输入数据,并对其进行预处理,例如均值化和归一化等操作,以确保数据适配后续层的处理。对于彩色图像,输入数据通常是一个三维张量,包含图像的高度、宽度和颜色通道数(RGB);而对于灰度图像(如图 2.1),输入数据则为二维矩阵,仅包含图像的高度和宽度。

2.1.1 卷积层

卷积层是卷积神经网络的核心，它通过卷积操作来提取输入数据中的局部特征。卷积操作使用一个名为“卷积核”或“滤波器”的矩阵，通过在输入图像上滑动（卷积）来进行特征提取。卷积核的大小以及滑动的长度决定了输出特征图的尺寸。通过卷积操作，网络可以自动学习从简单的边缘、角点到复杂的形状、纹理等高级特征。

以 RGB 彩色图像为例，见图 2.2 中的二维卷积过程^[11]：




图 2.2 二维卷积计算

Fig. 2.2 2D convolution computation

如图 2.2 所示，图 2.2 中的输入图像包含三个通道（红绿蓝三个矩阵表示，矩阵中的数字代表当前位置的像素值），每个通道的宽、高均为 3，一个卷积核，卷积核通道数也为三（对应三个黄色矩阵），卷积核大小为 2×2 ，步长 $\text{stride} = 1$ ， $\text{padding} = 0$ 。

二维卷积计算过程：卷积核从图像的左上角开始，覆盖一个 2×2 的区域。卷积核依次在图像上滑动（滑动步长为 1），逐步覆盖整个图像。每次滑动时，卷积核与图像当前覆盖的区域进行计算：相应位置的像素值进行相乘再相加。

以红色通道为例，公式见(2.1)，具体过程见图 2.3：

$$O_R = I_R \odot K_R \quad (2.1)$$




图 2.3 卷积计算

Fig. 2.3 Convolution computation

$$1 \times 2 + 2 \times 1 + 4 \times 3 + 5 \times 5 = 41$$

$$2 \times 2 + 3 \times 1 + 5 \times 3 + 6 \times 5 = 52$$

$$4 \times 2 + 5 \times 1 + 7 \times 3 + 8 \times 5 = 74$$

$$5 \times 2 + 6 \times 1 + 8 \times 3 + 9 \times 5 = 85$$

2.1.2 池化层

池化是卷积神经网络中的一种下采样方法，经过卷积层进行特征提取后的特征图被传递至池化层来进行特征的提取以及过滤。常见的池化方式有平均池化以及最大池化两种，以单通道池化为例，计算过程见图 2.4:




图 2.4 池化

Fig. 2.4 Pooling

平均池化是通过计算图像区域的平均值作为该区域池化后的值，最大池化则是通过

选择图像区域的最大值作为该区域池化后的值。

2.1.3 全连接层

全连接层等价于传统前馈神经网络中的隐含层，一般位于卷积神经网络的最后一部分，起到“分类器”的作用。

卷积神经网络的输出层用于输出最终的结果。对于分类任务，输出结果为类别标签（离散的值）；对于回归任务，输出结果为一个数值（0-1 之间的值）；对于目标检测任务，输出结果为目标类别及位置信息。在神经网络中，回归问题通常选择恒等函数作为激活函数，而对于分类问题，通常选择 softmax 函数作为激活函数。

2.1.4 激活函数

激活函数是神经网络中的关键组成部分，用于引入非线性特性，从而使得网络能够学习和表示复杂的非线性关系，通常位于卷积核之后。激活函数通过对输入加权求和的结果进行非线性变换，使得网络能够处理更复杂的数据模式。常见的激活函数包括 Sigmoid、Tanh、ReLU、SiLU、Mish 等及其变种，见公式(2.2)至公式(2.6)，函数图像见下图 2.5。每种激活函数都有不同的数学定义和特性，能适用于不同的场景。

(1) Sigmoid 激活函数

$$f(x) = \frac{1}{1+e^{-x}} \quad (2.2)$$

(2) Tanh 激活函数

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.3)$$

(3) ReLU 激活函数

$$f(x) = \max(0, x) \quad (2.4)$$

(4) SiLU 激活函数

$$f(x) = x \cdot \text{sigmoid}(x) = \frac{x}{1+e^{-x}} \quad (2.5)$$

(5) Mish 激活函数

$$f(x) = x \cdot \tanh(\ln 1 + e^x) \quad (2.6)$$




图 2.5 激活函数图像

Fig. 2.5 Graphs of activation functions

激活函数通过非线性变换增强了神经网络的表达能力，不同的激活函数在不同场景汇总具有独特的优势。选择合适的激活函数对于网络性能的提升和训练的高效性至关重要。

2.2 区域卷积神经网络系列算法分析

目标检测是计算机视觉领域的重要任务之一，旨在准确分类并定位图像中的目标。传统方法依赖手工选取特征和滑动窗口，计算复杂且识别精度有限。区域卷积神经网络（Region-based CNN, R-CNN）系列算法的提出，成功将深度学习引入目标检测领域，并通过不断优化，提高了检测精度和速度。

R-CNN^[12]通过选择性搜索算法（Selective Search, SS）生成候选区域，并采用卷积神经网络（CNN）提取特征，但计算量大时间长。Fast R-CNN^[13]通过共享 CNN 计算和感兴趣区域池化（Region of Interest Pooling, RoI Pooling）提升了计算效率，而 Faster R-CNN^[14]进一步引入区域候选网络（Region Proposal Network, RPN），实现了端到端的目标检测，以及更高效的候选区域的生成。Mask R-CNN^[15]在 Faster R-CNN 的基础上增加实例分割分支，并采用感兴趣区域对齐（Region of Interest Pooling, RoI Align）提高定位精度。下表 2.1 为四种区域卷积神经网络算法的对比。

表 2.1 区域卷积神经网络系列算法对比

Table 2.1 Comparison of Regional Convolutional Neural Network Series Algorithms

算法	候选区域方法	特征提取方法	分类方式	训练方式	速度	特点
R-CNN	SS	AlexNet	支持向量机 (SVM)	多阶段	最慢	开创 R-CNN 框架, 检测精度高, 但计算量大速度慢
Fast R-CNN	SS	VGG16	Softmax	端到端	快	计算效率大幅提升, 但仍依赖 SS 算法
Faster R-CNN	RPN	ResNet-101	Softmax	端到端	更快	用 RPN 替代 SS 算法, 显著提高速度
Mask R-CNN	RPN	ResNet-50-FPN	Softmax	端到端	略慢	增加 Mask 分支, 实例分割

(1) 区域卷积神经网络 (R-CNN)

R-CNN 首次将深度学习与传统区域建议方法结合, 显著提高了目标检测的精度, 为后续目标检测算法的发展奠定了基础。传统的目标检测算法主要以来于手工提取特征, 和滑动窗口算法检测物体, 不仅耗时长精度低, 模型的计算量大泛化能力弱。R-CNN 首先引入卷积神经网络用于提取特征, 利用卷积神经网络自动学习高层次的特征来代替手工设计特征。其次, R-CNN 通过选择性搜索算法来生成候选区域, 减少计算量。

R-CNN 工作流程:

生成候选区域: 使用选择性搜索算法, 基于颜色、纹理等特征, 生成可能包含物体的区域。

区域归一化: 将候选区域缩放至固定尺寸, 已使用卷积神经网络对输入的要求。

特征提取: 采用预训练模型 (LeNet 等) 进行微调, 将候选框与真实框之间 $\text{IoU} \geq 0.5$ 的候选框保留, $\text{IoU} \leq 0.5$ 的候选框去除, 然后提取剩余候选区域的特征向量。

分类与回归: 使用支持向量机 (SVM) 对特征向量进行分类, 判断物体的类别; 使用线性回归模型调整区域候选框的位置, 提高模型的定位精度。

(2) Fast R-CNN

Fast R-CNN 由 Ross Girshick 于 2015 年提出, 旨在解决 R-CNN 的三大核心问题: 速度慢 (逐区域提取特征)、多阶段训练复杂 (分步训练 CNN、SVM、回归器)、存储开销大 (需缓存所有区域特征)。其核心目标是实现端到端的高效目标检测, 同时提升精度与速度。

Fast R-CNN 的工作流程:

图像输入与特征提取：使用预训练的卷积神经网络（如 VGG16、ResNet 等）生成全局共享的特征图。

生成候选区域：使用选择性搜索算法（SS）生成约 2000 个候选框。

RoI Pooling：首先，将候选框在原图中的坐标按比例映射到共享特征图上；随后，将每个候选区域的特征均匀划分为固定数量的网格；最后，在每个网格内执行最大池化操作，提取局部最显著特征，生成统一尺寸的输出。

分类和边界框回归：经过 ROI Pooling 生成的固定尺寸特征首先被展平为一维向量，随后输入至全连接层以进一步提取高层语义信息。网络最终通过两个并行分支输出结果：分类分支采用 Softmax 函数直接预测每个候选框的类别概率；回归分支则预测边界框的偏移量($\Delta x, \Delta y, \Delta w, \Delta h$)，通过线性变换对候选框位置进行精细化调整，并采用 Smooth L1 Loss 作为损失函数。

(3) Faster R-CNN

Faster R-CNN 是目标检测领域的里程碑模型，由 Ross Girshick 等人于 2015 年提出。它在 Fast R-CNN 的基础上，将候选区域生成（Region Proposal）与目标检测统一到同一个深度学习框架中，实现了完全端到端的训练和推理。

Faster R-CNN 的工作流程：

特征提取：原始图像输入至预训练的卷积神经网络（如 VGG16 或 ResNet）。该网络通过一系列卷积和池化操作提取图像的高层次语义特征，生成共享特征图。

区域建议网络（RPN）生成候选区域：RPN 通过多尺度锚框（Anchor Boxes）生成候选区域：首先，在特征图的每个像素点预设不同尺度和长宽比的锚框，覆盖图像中各类目标；随后，通过分类分支预测锚框中物体存在的概率，并利用回归分支预测边界框偏移量以调整锚框位置；最后，按分类得分排序保留前 1.2 万个高分锚框，并通过非极大值抑制（NMS）去除冗余框，最终输出约 2000 个高质量候选区域。

区域池化（ROI Pooling）：ROI Pooling 将 RPN 生成的候选区域坐标与共享特征图结合，首先将候选框从原图坐标按比例映射到特征图对应区域，接着将每个区域划分为固定网格，并在每个网格内进行最大池化以提取关键特征，最终输出统一尺寸的特征向量

分类与回归：ROI Pooling 输出的标准化特征经全连接层进一步抽象后，通过双分支输出结果：分类分支使用 Softmax 预测候选区域的类别概率，回归分支预测边界框的二次偏移量以微调候选框位置。

(4) Mask R-CNN

Mask R-CNN 首次将目标检测与实例分割（Instance Segmentation）统一到端到端框架中，既能输出物体边界框与类别，还能生成像素级掩膜（Mask）。Mask R-CNN 主要有三大改进：1. 使用了掩码分支：通过全卷积网络（FCN）为每个候选区域生成像素级

分割掩膜，输出与类别数对应的二值掩膜，实现实例级精准分割。2.将 ROI Pooling 替换为 ROI Align: 使用双线性插值取代取整操作，保留特征图亚像素级对齐。3.解耦分类与分割任务。

Mask R-CNN 的工作流程:

特征提取: 输入图像经主干网络生成多尺度特征图。

区域建议网络 (RPN): 使用 RPN 生成高质量候选框。

ROI Align: 从特征图中提取候选区域特征, 通过双线性插值保留亚像素级位置信息, 输出对齐后的固定尺寸特征。分类分支使用 Softmax 预测类别概率。回归分支用于优化边界框位置($\Delta x, \Delta y, \Delta w, \Delta h$)。掩膜分支输出像素级分割结果。

2.3 YOLO 系列算法分析

虽然区域卷积神经网络 (R-CNN) 系列方法在精度上取得了显著提升, 但这类依赖候选区域生成, 计算复杂度较高, 难以满足工业中实时检测的需求。为了解决这一问题, YOLO (You Only Look Once) 系列算法提出了一种全新的检测框架, 将目标检测视为单阶段回归问题, 直接从输入图像预测目标类别和位置, 实现端到端的高效检测。YOLO 系列各算法详情见表 2.2。

表 2.2 YOLO 系列算法对比

Table 2.2 Comparison of YOLO Series Algorithms

算法	骨干网络	结构创新
YOLOv1	GoogleNet 变体	-----
YOLOv2	Darknet-19	使用的一种基于 WordTree 结构的方法 使用批量规范化
YOLOv3	Darknet-53	使用更好、更大的 CNN 骨干网 使用独立的 Logistic 分类器代替 softmax 函数
YOLOv4	CSPDarknet53	使用跨阶段部分网络策略的 DarkNet-53 使用修改后的空间金字塔池化和路径聚合网络
YOLOv5	CSPDarknet	引入 Focus 切片操作 优化了 Cross Stage Partial(CSP)结构 使用 FPN+PAN 结构
YOLOv6	EfficientRep	使用 EfficientRep 作为主干网络 Neck 部分使用 Rep-PAN 拓扑 使用 Efficient Decoupled Head
YOLOv7	E-ELAN	使用 E-ELAN 作为主干网络 改进使用设计的 MPANet 采用符合缩放方法
YOLOv8	CSPDarknet	采用高级的 Backbone 和 Neck 架构 使用无锚分体式 Ultralytics 头
YOLOv9	CSPDarknet53	引入可编程梯度信息 (PGI) 和广义高效层聚合网络
YOLOv10	C2f、SCDown、PSA	使用了新的卷积机制 C3k2
YOLOv11	C3k2	使用了新的卷积机制 C3k2
YOLOv12	R-ELAN、C3k2、 A2C2f	构建注意力核心的 YOLO 框架 提出区域注意力模块 (A2) 引入残差高效层聚合网络

2.4 YOLOv5 目标检测算法

2.4.1 网络结构




图 2.6 YOLOv5 算法结构

Fig. 2.6 The structure of YOLOv5

2.4.2 Backbone

主要组件: Conv (CBS), C3, 快速空间金字塔池化 (Spatial Pyramid Pooling Fast, SPPF)

YOLOv5 的 Conv 模块中包含了卷积 (Conv2d)、批量归一化 (Batch Normalization) 和激活函数 (SiLU 激活函数), 见图 2.7:



图 2.7 Conv 模块

Fig. 2.7 Conv module

YOLOv5 借鉴了 CSPNet 的思想，并将其运用于 DarkNet53 骨干网络中。YOLOv5 使用 C3 模块（见图 2.8）替代了 BottleneckCSP 模块（见图 2.9）：




图 2.8 C3 模块

Fig. 2.8 C3 module




图 2.9 BottleneckCSP 模块

Fig. 2.9 BottleneckCSP module

C3 和 BottleneckCSP 结构和作用给基本相同，均为 CSP 架构，只是在修正单元的选择上有所不同，C3 模块包含了 3 个标准卷积层以及多个 Bottleneck 模块，与 BottleneckCSP 不同的是，经过 Bottleneck 模块输出后的 Conv 模块被去掉了。

SPPF 模块采用多个小尺寸池化核代替 SPP（见图 2.11）中的单个大池化核，从而保留其原有功能，即融合不同感受野的特征图，丰富特征图的表达能力的前提下，进一步提高运行速度，见图 2.10。




图 2.10 SPPF 模块

Fig. 2.10 SPPF module




图 2.11 SPP 模块

Fig. 2.11 SPPmodule

2.4.3 Neck

Neck 部分采用图像金字塔 (Feature Pyramid Networks, FPN) + 路径聚合网络 (Path Aggregation Network, PAN) 结构多图像进行多尺度特征融合, 其中上层特征图因为网络层数更深, 包含目标的语义信息更强, 而下层特征因为经过卷积层数较少, 目标的位置信息顺势就更少, FPN 结构通过自顶向下进行上采样, 使得底层特征图包含更强的图像强语义信息, PAN 结构自底向上进行下采样, 使顶层特征包含图像位置信息, 两个特征最后进行融合, 使得不同尺寸的特征图都包含推向语义信息和图像特征信息, 保证了对不同尺寸的图片的准确预测。

2.4.4 Head

YOLOv5 的 Head 对 Neck 中得到的不同尺度的特征图分别通过 1×1 卷积将通道进行扩展, 扩展后的特征通道数见公式 2.7:

$$(\text{类别数量} + 5) \times \text{每个检测层上的 anchor 数量} \quad (2.7)$$

其中 5 分别对应的是预测框的中心横坐标、纵坐标、宽度、高度和置信度。Head 中包含 3 个检测层, 分别对应 Neck 中得到的 3 中不同尺寸的特征图。

2.4.5 损失函数

YOLOv5 的损失主要包含三个方面的损失: 边界框损失 ($\text{bbox}_{\text{loss}}$)、分类损失 (cls_{loss}) 以及置信度损失 (obj_{loss})。总损失表达式 (见公式(2.8)) 为:

$$\text{Loss} = \text{box}_{\text{gain}} \times \text{bbox}_{\text{loss}} + \text{cls}_{\text{gain}} \times \text{cls}_{\text{loss}} + \text{obj}_{\text{gain}} \times \text{obj}_{\text{loss}} \quad (2.8)$$

其中 box_{gain} 、 cls_{gain} 和 obj_{gain} 分别对应不同的损失权重, 默认值分别为 0.05、0.5 和 1。

边界框损失采用 CIOU 损失 (见公式(2.9)) 作为其损失函数。

$$L_{\text{CIOU}} = 1 - \text{IoU} + \frac{\rho^2(b, b^{\text{gt}})}{c^2} + \alpha v \quad (2.9)$$

其中 α 是权重参数, 表达式 (见公式(2.10)) 为:

$$\alpha = \frac{v}{(1 - \text{IoU}) + v} \quad (2.10)$$

v 是用来衡量宽高比的一致性, 表达式 (见公式(2.11)) 为:

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w^{gt}}{h^{gt}} - \arctan \frac{w}{h} \right)^2 \quad (2.11)$$

分类损失采用二元交叉熵损失函数来计算分类损失。二元交叉熵函数 (见公式(2.12)) 的定义为:

$$L = -y \log p - (1 - y) \log (1 - p) = \begin{cases} -\log p, & y = 1 \\ -\log (1 - p), & y = 0 \end{cases} \quad (2.12)$$

其中 y 为输入样本对应的标签 (正样本为 1, 负样本为 0), p 为模型预测该输入样本为正样本的概率。

假设

$$p_t = \begin{cases} p, & y = 1 \\ 1 - p, & y = 0 \end{cases} \quad (2.13)$$

则交叉熵损失函数的定义 (见公式(2.14)) 可简化为

$$L = -\log p_t \quad (2.14)$$

每个预测框的置信度表示这个预测框的可靠程度, 值越大表示该预测框越可靠, 也表示更接近真实框。

2.4.6 非极大值抑制 (Non-Maximum Suppression, NMS)

非极大值抑制的本质是搜索局部最大值, 抑制非极大值元素。主要是用来去除冗余的检测框。在目标检测任务中, 在同一目标的位置会产生大量的边界候选框, 这些候选框之间会出现重叠, 非极大值抑制就是通过去除重叠的框, 找到最佳的目标边界框。

算法流程, 见图 5.4:

1. 对所有候选框的置信度按降序排序
2. 选出置信度最高的后宣布框, 并计算其与其他预测框的 IoU 值
3. 根据计算的 IoU 值去除重叠度较高的框, IoU 大于阈值的候选框直接删除
4. 继续步骤 2, 直至没有冗余的候选框

2.5 YOLOv9 目标检测算法

2.5.1 网络架构




图 2.12 YOLOv9 架构

Fig. 2.12 The structure of YOLOv9

YOLOv9 是 YOLOv7 的改进版本，见上图 2.12，主要是用于解决目前检测算法存在的两个问题：1. 现有方法都是关注如何设计一个更好的损失函数，而一个好的网络结构可以获取更多的信息以提升预测效果；2. 现有方案忽略了在一层一层的特征提取中会损失大量信息的问题。基于上述两个问题，YOLOv9 首先提出了一个轻量级的网络结构：泛化高效层聚合网络（Generalized Efficient Layer Aggregation Network, GELAN），即图 2.12 中的 RepNCSPELAN4。GELAN 的设计综合考虑了参数数量、计算复杂度、推理速度和精度等多个方面的因素，并通过传统卷积运算来优化参数的使用，从而提升网络的整体效率。其次，YOLOv9 引入了“可编程梯度信息”（Programmable Gradient Information, PGI）的概念，旨在通过辅助的可逆分支生成更稳定、可靠的梯度。

GELAN 结合了高效层聚合网络（Efficient Layer Aggregation Network, ELAN）和跨阶段局部网络（Cross Stage Partial Network, CSPNet），见图 2.13，该结构可以使用任意的计算块，例如 Bottleneck 或 ResBlock，以提高计算的效率。




图 2.13 GELAN 结构: (a) CSPNet (b) ELAN (c) GELAN

Fig. 2.13 The structure of GELAN: (a) CSPNet (b) ELAN (c) GELAN

PGI 主要由三个核心部分组成（结构见图 2.14）：主分支、辅助可逆分支和多级辅助信息。见图。主分支负责推理过程，辅助可逆分支通过生成可靠的梯度来更新网络参数，从而解决深度神经网络带来的梯度传递问题。辅助可逆分支的引入有助于缓解深层特征在复杂任务中可能丢失的信息问题。多级辅助信息则通过在辅助监督的特征金字塔层级和主分支之间插入一个集成网络，结合不同预测头返回的梯度信息，有效处理深度监督中误差的积累，尤其适用于多预测分支架构和轻量化模型的优化。




图 2.14 PGI 结构

Fig. 2.14 The structure of PGI

2.5.2 Backbone

主要组件: Conv、RepNCSPeLan (GELAN) 、ADown

YOLOv9 的 Conv 模块中包含了卷积 (Conv2d)、批量归一化 (Batch Normalization) 和激活函数 (SiLU 激活函数)，见图 2.7。

RepNCSPELAN 结构主要由 Conv 模块和 RepNCSP 模块构成，见下图 2.15。




图 2.15 RepNCSPELAN 结构

Fig. 2.15 The structure of RepNCSPELAN

ADown 模块是 YOLOv9 的下采样方法，它不仅十分高效还可以实现参数量的显著下降，其结构见下图 2.16:




图 2.16 ADown 结构图

Fig. 2.16 The structure of ADown

2.5.3 Neck

YOLOv9 的 Neck 使用的依旧是特征金字塔网络 (FPN)，通过对高维数据进行卷积池化，并通过上采样与浅层特征进行融合以保证网络检测不同尺度目标的精度。

2.5.4 Head

YOLOv9 的 Head 由预测层、分类以及回归分支等部分组成。预测层由卷积层和激活函数构成，用于生成最终的预测结果，预测结果包括预测框的位置信息、置信度以及类别概率。

2.5.5 损失函数

YOLOv9 的损失主要包含两个方面的损失：类别损失和定位损失。

类别损失采用的是二元交叉熵损失函数，公式见(2.15)：

$$\text{Loss}_{\text{cls}} = -\frac{1}{N} \sum_{i=1}^N y_i \cdot \log(p(y_i)) + (1 - y_i) \cdot \log(1 - p(y_i)) \quad (2.15)$$

其中 y 为标签 (0 或 1)， $p(y)$ 为输出属于标签的概率， N 为模型预测对象的数量。

使用 CIOU Loss 和 DFL Loss 作为回归损失，公式见(2.16)和(2.19)：

$$\text{CIOU Loss} = 1 - \text{CIOU} = 1 - \text{IoU} + \frac{\rho^2(p, p^*)}{c^2} + \alpha v \quad (2.16)$$

其中

$$\alpha = \begin{cases} 0 & , \text{IoU} < 0.5 \\ \frac{v}{(1 - \text{IoU}) + v} & , \text{IoU} \geq 0.5 \end{cases} \quad (2.17)$$

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w^{\text{gt}}}{h^{\text{gt}}} - \arctan \frac{w}{h} \right) \quad (2.18)$$

$$\text{DFL}(S_i, S_{i+1}) = -(y_{i+1} - y) \log(S_i) + (y - y_i) \log(S_{i+1}) \quad (2.19)$$

其中 S_i 为网络输出的预测值， S_{i+1} 为网络输出的临近预测值， y 为标签的真实值， y_i 为标签积分值， y_{i+1} 为临近标签积分值。

2.6 基于改进 YOLO 的目标检测算法

本节详细描述了目标检测算法中的三大核心模块（卷积操作、注意力机制与非极大值抑制）的技术演进与优化方向。通过优化卷积模块的结构设计（如深度可分离卷积与残差网络融合、基于 Pconv 的快速特征提取），可以有效提升模型对局部特征与全局上下文信息的平衡能力；结合注意力机制的多维度创新（如多通道并行注意、坐标注意力嵌入、动态头块分工），可以实现对关键区域的智能聚焦与计算资源的高效分配，显著降低了复杂背景干扰；针对 NMS 算法的阈值敏感性与邻近目标误删问题，本章进一步探讨了其改进潜力，为后处理冗余抑制提供了理论优化空间。

2.6.1 卷积

基于卷积的目标检测算法在检测过程中具有较高的自动化程度,但依旧面临着复杂背景下检测小目标时的精度低等挑战。这些算法中的卷积模块在解决这些问题时受到了限制,这主要是由于它们对局部特征的敏感性和对上下文信息的捕获不足。因此,改进这些卷积模块或引入新的卷积模块可以有效地提高模型识别关键缺陷特征的能力,从而提高检测精度和鲁棒性。Su 等人结合了深度可分离卷积和 Resnet-34 网络结构,改进了特征提取骨干网络^{[66][67]}。Li 等人采用了基于 Pconv 的快速融合速度模块作为基本操作符,在保持速度的同时,提高了浅层网络的特征提取能力^[68]。

2.6.2 注意力机制

传统的目标检测方法通常包括对整个图像进行穷举搜索,以定位潜在的目标的位置。这些方法的计算成本高,特别是在处理高分辨率工业图像时。搜索每一个可能的目标位置和规模不仅耗时,而且容易降低检测精度,导致假阳性和假阴性。相比之下,包含注意机制的目标检测方法可以更智能地聚焦于图像中可能出现目标的关键区域。通过对这些关键区域分配更多的权重,注意机制减少了与无关区域相关的计算负担,显著提高了目标检测的准确性和效率,并确保更精确的目标定位。Xuan 等人引入了不同的注意机制来提高小目标的检测能力^{[69][70][71][72]}。Ma 等人设计了一个并行的双通道注意模块,以增强不同通道对特征图的效果^[73]。Chen 等人将 SE 模块引入了局部重要池化模块中,从而提高了局部重要池化对信道特性的敏感性^[74]。Xiao 等人等人引入了条件注意 (CA) 模块,取代了主干网络的空间金字塔池 (SPP) 结构。这一变化进一步分解了池化操作,有效地提高了网络定位缺陷的能力^[75]。Zheng 等人在 YOLOv7 中引入了坐标注意机制 (CA),以增强了模型的特征提取能力^[76]。

2.6.3 非极大值抑制 (NMS)

非最大抑制 (NMS)^[77]在计算机视觉领域有非常重要的应用,如物体跟踪、数据挖掘、三维重建、物体识别等。NMS 可以理解作为一种局部最大搜索方法:它通过抑制非最大元素来保留最大元素。在 YOLO 系列的目标检测算法中,NMS 的目的是保留来自多个可能的检测对象的最优检测结果,并抑制其他次优的重叠检测盒,从而减少冗余检测。具体步骤如下:

1. 对于每个类别,根据置信度得分对预测的方框进行排序,并选择置信度最高的一个作为参考。
2. 删除参考框,然后从剩余的预测框中选择与参考框重叠面积最大的框。如果重叠区域超过了某个阈值,则删除。
3. 对其余的预测框重复步骤 2,直到所有重叠区域都低于阈值或没有可删除的框。

NMS 算法通过抑制高度重叠的盒子来提高目标检测算法的精度。但是，NMS 算法存在两个问题：当两个对象框相互接近时，得分较低的框可能由于与得分较高的框重叠面积较大而被删除；我们需要手动设置 NMS 的阈值，如果阈值过低，可能会错过检测，如果阈值过高，可能会导致误报。使用改进的后处理方法能够更进一步环节模型漏检误检问题，进而提高模型的精度。

2.7 数据集介绍

2.7.1 遥感图像目标检测数据集

为了检验所提出的 PCD-YOLO 算法的可行性和有效性, 选取了六个常用的公开遥感图像数据集, 包括 NWPU VHR-10^[65]、SIMD^[66]、DIOR^[67]、DOTAv1.0^[68]、VisDrone2019^[69] 和 HRSC2016^[70]。各数据集里训练集中图像标签的详细信息如图 2.17 所示, 其中包括数据集所包含的每个类别的数量 (左上)、真实框的大小和数量 (右上)、真实框的中心坐标 (左下) 以及真实框的高度和宽度 (右下)。




图 2.17 遥感图像数据集详情

Fig. 2.17 Details of remote sensing image datasets

(1) NWPU VHR-10

NWPU VHR-10 数据集由西北理工大学于 2014 年发布。它是一个设计用于空间目标检测的 10 级地理遥感数据集。该数据集包含 650 张包含对象的图像和 150 张背景图像, 总计 800 张图像。目标类别包括飞机、船舶、油罐、棒球场、网球场、篮球场、运动场、港口、桥梁和汽车, 共计 10 个类。本文只使用了 600 张包含目标的图像, 其中 450 张图像作为训练集, 150 张图像作为验证集。

(2) SIMD

SIMD 数据集由巴基斯坦国立科技大学于 2020 年提出, 主要为车辆检测而设计。该

数据集包括 5000 张遥感图像（图像大小：1024×768），共计 45096 个实例，分为 15 个类。

(3) DIOR

DIOR 数据集由西北理工大学于 2019 年发布。该数据集包括从谷歌地球上获得的 23,463 张图像，总共包括 20 种遥感陆地物体。

(4) DOTA v1.0

DOTA v1.0 数据集，由哥伦比亚大学的计算机视觉实验室提供。该数据集包括数千个高分辨率数字正射影瓷砖（图像大小：几百像素~几千像素），每一个都伴随着地理参考信息。该数据集跨越多个地理区域，包括各种类别，包括道路、建筑物、水体、植被等。

(5) VisDrone2019

VisDrone2019 年的数据集是由天津大学机器学习和数据挖掘实验室的通道眼团队收集的。它总共由 10,209 张静态图像组成（图像大小：2000×1500），训练集中 6471 张图像，验证集 548 张图像，测试集中 1610 张图像组成。该数据集包括十个类：“行人”、“人”、“自行车”、“汽车”、“货车”、“卡车”、“三轮车”、“遮阳篷三轮车”、“公共汽车”和“马达”。

(6) HRSC2016

HRSC2016 数据集是由西北理工大学于 2016 年发布的，这些数据集来自谷歌地球上的 6 个重要港口，包括 1680 张图像（大小：300×300 ~ 1500×900）。其中，训练集中有 436 张图像，验证集中有 181 张图像，测试集中有 444 张图像，共计 2976 个目标。

下表 2.3、表 2.4 为数据集数值化之后对应的类别。

表 2.3 遥感图像数据集对应类别

Table 2.3 Corresponding categories of remote sensing image datasets

Categorie	WPU VHR-10	SIMD	DIOR	DOTAv1.0
0	airplane	car	airplane	plane
1	ship	truck	Airport	ship
2	storage tank	van	Baseball field	storage tank
3	baseball diamond	longvehicle	Basketball court	baseball diamond
4	tennis court	bus	Bridge	tennis court
5	basketball court	airliner	Chimney	basketball court
6	ground track field	propeller	Dam	ground track field
7	harbor	trainer	Expressway service area	harbor
8	bridge	chartered	Expressway toll station	bridge
9	vehicle	fighter	Golf course	large vehicle
10		other	Ground track field	small vehicle
11		stairtruck	Harbor	helicopter
12		pushbacktruck	Overpass	roundabout
13		helicopter	Ship	soccer ball field
14		boat	Stadium	swimming pool
15			Storage tank	
16			Tennis court	
17			Train station	
18			Vehicle	
19			Wind mill	

表 2.4 遥感图像数据集对应类别

Table 2.4 Corresponding categories of remote sensing image datasets

Categorie	VisDrone	HRSC2016		
0	Pedestrian	ship	none	21
1	People	aircraft carrier	Hovercraft	22
2	Bicycle	warcraft	none	23
3	Car	merchant ship	yacht	24
4	Van	Nimitz	CntShip	25
5	Truck	Enterpris	Cruise	26
6	Tricycle	Arleigh Burke	submarine	27
7	Awning-tricycle	WhidbeyIsland	lute	28
8	Bus	Perry	Medical	29
9	motor	Sanantonio	Ford-class	30
10		Ticonderoga	Midway-class	31
11		Kitty Hawk	Invincible-class	32
12		Kuznetsov		
13		Abukuma		
14		Austen		
15		Tarawa		
16		Blue Ridge		
17		Container		
18		OXo		
19		Car carrier		

2.7.2 钢材表面缺陷检测数据集

为了检验所提出的 EPSC-YOLO 算法的可行性和有效性, 选取了两个常用的公开表面缺陷检测数据集, 包括 NEU-DET^[71]和 GC10-DET^[72]。各数据集里训练集中图像标签的详细信息如图所示, 其中包括数据集所包含的每个类别的数量 (左上)、真实框的大小和数量 (右上)、真实框的中心坐标 (左下) 以及真实框的高度和宽度 (右下), 见图 2.18。




图 2.18 表面缺陷检测数据集详情

Fig. 2.18 Details of surface defect detection datasets

(1) NEU-DET

NEU-DET（东北大学表面缺陷检测数据库）是由中国东北大学开发的一个表面缺陷检测数据集。它包括在钢表面上发现的六种典型类型的缺陷，每种类型有 300 张图像。每幅图像的分辨率为 200×200 像素。

(2) GC10-DET

GC10-DET（GongChang 表面缺陷检测数据库）数据集由 14,300 张图像组成，描述了来自真实工业场景的钢表面缺陷。它涵盖了 10 种常见类型的金属表面缺陷，每种类型大约有 1430 张图像。每幅图像的分辨率为 256×256 像素。

下表 2.5 为数据集数值化之后对应的类别。

表 2.5 表面缺陷检测数据集对应类别

Table 2.5 Corresponding categories of surface defect detection datasets

类别	NEU-DET	GC10-DET
0	Crazing	Waist folding
1	Inclusion	Pu
2	Patches	WI
3	Pitted_surface	Cg
4	Rolled-in_scale	Water Spot
5	Scratches	Oi Spot
6	-----	Silk Spot
7	-----	Inclusion
8	-----	Rolled Pit
9	-----	Crease

2.8 本章小结

本章对卷积神经网络的理论基础和 YOLOv5、YOLOv9 目标检测算法进行了详细介绍和分析。首先,介绍了深度学习目标检测模型的基本网络结构,包括输入层、卷积层、池化层、全连接层和输出层,以及 YOLO 算法中常用的分类损失、定位损失和置信度损失的计算方法。然后,对 YOLO 系列算法的发展历程进行了概述和分析,重点讨论了 YOLOv5 和 YOLOv9 算法的创新点和网络结构。接着,介绍了本文基于 YOLO 算法改进的方向,并对每一个可改进的点提供了相关的改进算法,表明改进方向的有效性。最后,介绍了本文实验中使用的六个开源的遥感图像数据集和两个开源的表面缺陷检测数据集。

3 基于改进 YOLOv5 的遥感图像目标检测算法

3.1 引言

遥感技术作为现代地理信息系统的重要组成部分，在地球观测、环境监测、城市规划等等领域发挥着至关重要的作用。然而，在遥感图像中进行目标检测是一项极具挑战性的任务，由于遥感图像的复杂性和多样性，传统的目标检测算法往往难以取得理想的效果。近年来，YOLOv5 算法作为单阶段目标检测算法的佼佼者，以其高效性和准确性在目标检测领域得到了广泛应用。然而，针对遥感图像的特性，YOLOv5 算法仍存在一些局限性，如对多尺度目标检测效果不佳、对复杂背景适应性差等。因此，本文提出了一种基于改进 YOLOv5 的遥感图像目标检测算法，旨在通过优化特征提取网络、调整模型参数等手段，提高遥感图像目标检测的准确性和效率。本章内容主要包括算法改进与实现、实验设计与结果分析等方面，旨在通过实证研究验证改进算法的有效性和优越性。本文的研究不仅具有重要的理论价值，而且在实际应用中具有广泛的前景和意义。

3.2 基于金字塔卷积设计的 PSConv 模块

对于标准卷积，见图 4.1，假设输入图像的大小为 $W \times H \times FM_i$ ，输出图像的大小为 $W_1 \times H_1 \times FM_o$ ，卷积核的大小为 $K_1 \times K_1 \times FM_i$ ，它采用了固定的卷积核和步长。




图 4.1 标准卷积

Fig. 4.1 Standard convolution

由于遥感图像中存在大量的多尺度目标，标准卷积不足以进行有效的目标检测。为了解决这一限制，PCD-YOLO 算法采用金字塔卷积。




图 4.2 n 层的金字塔卷积

Fig. 4.2 N-layer pyramid convolution

根据图 4.2, 一个 n 层的金字塔式卷积由 n 个不同类型的卷积核的组成。每一层核的空间大小是不同的, 从金字塔的底部到顶部移动, 核的大小从 k_1 逐渐增加到 k_n , 而从第 1 层到第 n 层深度减小。金字塔卷积采用分组卷积的概念, 将输入特征映射划分为不同的组, 每个组利用不同深度的卷积核。随着组数的增加, 卷积核的深度减小, 从而导致参数的数量和计算成本的减少。金字塔卷积是卷积神经网络中一种特殊的卷积运算, 与标准卷积相比, 它可以在不增加成本的情况下扩大卷积核, 并同时应用具有不同空间分辨率和深度的卷积核。因此, 金字塔卷积可以在多个过滤尺度上处理输入, 以捕获更详细的信息^[98]。

标准卷积的参数量见公式(4.1):

$$K_1 * K_1 * FM_i * FM_o \quad (4.1)$$

FLOPs 见公式(4.2):

$$K_1 * K_1 * FM_i * FM_o * W_1 * H_1 \quad (4.2)$$

n 层金字塔卷积的参数量见公式(4.3):

$$k_1^2 * FM_i * FM_{o1} + k_2^2 * \frac{FM_i}{\binom{k_2}{k_1}} * FM_{o2} + \dots + k_n^2 * \frac{FM_i}{\binom{k_n}{k_1}} * FM_{on} \quad (4.3)$$

FLOPs 见公式(4.4):

$$(k_1^2 * FM_i * FM_{o1} + k_2^2 * \frac{FM_i}{\binom{k_2}{k_1}} * FM_{o2} + \dots + k_n^2 * \frac{FM_i}{\binom{k_n}{k_1}} * FM_{on}) * W * H \quad (4.4)$$

金字塔卷积有着比标准卷积更少的参数和 FLOPs。并且, 在相同数量的模型参数下, 金字塔卷积由于其高水平的并行性, 比标准卷积更有效。此外, 对于网络的每一层, 可以灵活的设计金字塔卷积。因此, 金字塔式卷积具有较高的灵活性和可扩展性。由于金字塔卷积的灵活性, 本章提出了一个基于无参数注意力机制的卷积模块, PSConv。




图 4.3 SimAM 结构

Fig. 4.3 The structure of SimAM

首先，设计了一个四层的金字塔卷积。其次，因为 SimAM（一个简单的、无参数的注意模块，见图 4.3）不需要学习额外的参数，这使得它易集成到神经网络中，它也在保持模型精度的同时降低了训练和推理的复杂性，所以将 SimAM 集成到 PyConv4 的每一层中，得到最终的 PSConv 模块，见图 4.4。




图 4.4 PSConv 模块

Fig. 4.4 PSConv module

3.3 基于全局注意力机制设计的 CGAM 模块

C3 模块（见图 4.5）是 BottleneckCSP 的简化版本，它可以帮助减少参数的数量，

但 C3 模块缺乏一个集成的注意力机制,这就限制了其在特征图中强调关键区域的能力。这种限制可能会对检测精度产生不利影响,特别是在涉及复杂背景或被遮挡物体的场景中。本文设计了一个 CGAM 模块,在 C3 模块第二个分支的 CBM 之后引入全局注意力机制 (GAM^[99]) (如图 4.6 所示)。CGAM 的结构如图 4.7 所示。




图 4.5 C3 模块

Fig. 4.5 C3 module




图 4.6 GAM 模块

Fig. 4.6 GAM module




图 4.7 CGAM 模块

Fig. 4.7 CGAM module

从图 4.7 中可以看出,通过在 C3 中引入 GAM,可以增强 C3 模块内各层之间的依赖关系,提高模型的上下文理解,提高模型的性能,加速推理过程。

3.4 解耦合头

YOLOv5 检测头是一个耦合设计，结合了分类和回归分支。然而，分类侧重于纹理，而定位强调边缘，这限制了跨任务的特征表达。遥感图像采集方法的不同会影响模型的性能，为了解决这个问题，我们使用解耦合头替了解耦合头，它分别提取和合并目标位置和类别信息，这改进了特定任务的特征表达，并更好地适应了各种遥感图像类型和环境。YOLOX 中的检测头使用两个 3×3 卷积，YOLOv6 使用单个 3×3 卷积。与 YOLOX 相比，YOLOv6 的检测头更简单，并减少了延迟。在本研究中，本文使用了 YOLOv6 的检测头（图 4.8）^[25]。




图 4.8 解耦合头

Fig. 4.8 Decoupled head

3.5 PCD-YOLO 目标检测算法实验分析

实验在 Linux 系统上进行，实验环境包括 Python 3.8.18、PyTorch 1.13.1 和 CUDA 11.7。所有模型都在 8 个 NVIDIA A30 24GB GPU 上使用分布式训练进行训练。

选择了四个主要指标：(1) P (Precision 精度) (2) R (Recall 召回率) (3) mAP_{50}^{val}

(平均精度 (IoU 阈值为 0.5)) (4) $\text{mAP}_{50:95}^{\text{val}}$ (平均精度 (IoU 阈值从 0.5 到 0.95))。

3.5.1 网络架构




图 4.9 PCD-YOLO 网络架构

Fig. 4.9 The structure of PCD-YOLO

PCD-YOLO 网络架构见上图 4.9 所示，首先，我们设计了一个四层的金字塔卷积 (PyConv4)，并在主干网络中使用其替换最后一个卷积模块。其次，我们在这个四层金字塔卷积的基础上设计了一个 PSConv 模块，它将一种简单且无需参数的注意力机制 (SimAM) 集成到主干网络中使用的金字塔卷积中。接下来，我们提出了一个 CGAM 模块，该模块将全局注意力机制 (GAM) 融入 Neck 网络部分使用的 C3 模块中。最后，耦合头被替换为解耦合头 (DH)。

3.5.2 消融实验及分析

为了评估各模块在基线模型上的性能, 即 PyConv4 模块、PSConv 模块、CGAM 模

块和 DH，我们在 6 个数据集上进行了消融实验。消融实验结果见表 4.1。由表 4.1 可以看出，通过使用四种新策略，该算法在 6 个数据集上获得了更好的 mAP_{50}^{val} 和 $mAP_{50:95}^{val}$ 。与基线模型相比， mAP_{50}^{val} 分别增加了 1.26%、1%、1.2%、0.7%、1.26% 和 4.33%， $mAP_{50:95}^{val}$ 分别增加了 1.47%、1.3%、2.63%、1.33%、0.83% 和 1.9%。

表 4.1 消融实验结果
Table 4.1 Ablation Experiment Results

数据集	算法	mAP ₅₀ ^{val}	mAP _{50:95} ^{val}
NWPU VHR-10	YOLOv5s	95.07	59.80
	+PyConv4	95.10	60.32
	+PSConv	95.70	60.30
	+CGAM	95.60	60.63
	+DH	96.33	61.27
SIMD	YOLOv5s	82.27	65.97
	+PyConv4	82.33	66.07
	+PSConv	82.33	65.90
	+CGAM	82.47	65.90
	+DH	83.27	67.27
DIOR	YOLOv5s	81.00	58.87
	+PyConv4	77.80	59.10
	+PSConv	81.30	59.10
	+CGAM	78.47	53.90
	+DH	82.20	61.50
DOTAv1.0	YOLOv5s	71.87	46.00
	+PyConv4	71.97	46.00
	+PSConv	72.10	45.97
	+CGAM	71.80	46.20
	+DH	72.57	47.33
VisDrone	YOLOv5s	34.27	18.77
	+PyConv4	34.37	18.90
	+PSConv	34.57	18.87
	+CGAM	34.47	18.80
	+DH	35.53	19.60
HRSC2016	YOLOv5s	58.60	49.20
	+PyConv4	55.23	44.93
	+PSConv	54.93	45.07
	+CGAM	51.17	41.93
	+DH	62.93	51.10

在本次消融实验中，我们评估了不同改进模块对 YOLOv5s 目标检测性能的影响，实验结果（见表 4.1）表明，各种模块均在不同数据集上带来了不同程度的性能提升。

PyConv4 模块通过多尺度卷积核增强了网络对目标的感知能力，使检测模型在复杂

场景下能够提取更加丰富的特征。实验表明, PyConv4 在多个数据集上均带来了不同程度的性能提升。例如, 在 SIMD 和 NWPU VHR-10 数据集中, PyConv4 使 $mAP_{50:95}^{val}$ 提升至 66.07% 和 60.32%, 表明该模块在高分辨率遥感图像中的小目标检测任务中具有一定的优势。此外, 在 VisDrone 和 DOTA v1.0 数据集中, PyConv4 也带来了一定的性能优化, 证明了其良好的泛化能力。

PSConv 模块在 PyConv4 的基础上引入了 SimAM 注意力机制, 从而进一步增强了特征提取能力, 使模型能够更有效地关注目标区域, 同时减少背景干扰。实验表明, 在多个数据集上, PSConv 均在 PyConv4 的基础上进一步提升了检测性能。例如, 在 NWPU VHR-10 和 DIOR 数据集中, PSConv 使 mAP_{50}^{val} 分别提升至 95.70% 和 81.30%, 同时 $mAP_{50:95}^{val}$ 也有所提升, 表明该模块在复杂背景下对目标的辨别能力进一步增强。此外, 在 DOTA v1.0 和 VisDrone 数据集中, PSConv 也带来了稳定的性能优化, 进一步验证了其在不同场景中的适用性。

CGAM 模块通过在 C3 模块中引入全局注意力机制, 使模型能够更加精准地聚焦目标区域, 并减少无关背景信息的干扰。在 SIMD 和 NWPU VHR-10 数据集中, CGAM 使 $mAP_{50:95}^{val}$ 分别提升至 65.90% 和 60.63%, 显示了其有效增强目标区域关注能力的特性。此外, 在 DOTA v1.0 数据集上, CGAM 使 $mAP_{50:95}^{val}$ 提升至 46.20%, 进一步证明其在遥感图像中的有效性。

DH 模块是本次实验中带来最大提升的改进模块, 在所有数据集上均取得了最佳的检测效果。该模块能够有效增强特征表达能力, 提高检测精度, 并在复杂背景下展现更强的目标区分能力。例如, 在 NWPU VHR-10 和 SIMD 数据集中, DH 使 $mAP_{50:95}^{val}$ 分别提升至 61.27% 和 67.27%, 在 HRSC2016 数据集中, DH 使 mAP_{50}^{val} 和 $mAP_{50:95}^{val}$ 达到 62.93% 和 51.10%, 均为该数据集上的最佳性能。对于 VisDrone 和 DOTA v1.0 数据集, DH 也带来了稳定的性能提升, 进一步验证了其在多种目标检测任务中的广泛适用性。

3.5.3 对比实验及分析

为检验所提算法的可行性和有效性, 我们在六个公开数据集上进行了实验。将所提模型分别与基线模型 (YOLOv5s)、YOLOv9c^[28]、Gold-YOLO^[78]、YOLOv6^[25]和 YOLOv3^[19]算法在六个数据集上进行对比, 结果如表 4.2 所示。

表 4.2 与经典算法对比实验结果

Table 4.2 Comparison experiment results with classic algorithms

数据集	算法	mAP_{50}^{val}	$mAP_{50:95}^{val}$
NWPU VHR-10	YOLOv3	96.1	62.50
	YOLOv6	84.23	49.8
	Gold-YOLO	85.77	49.63
	YOLOv9c	94.6	61.80
	YOLOv5s	95.07	59.80
	PCD-YOLO	96.33	61.27
SIMD	YOLOv3	83.4	67.6
	YOLOv6	77.50	61.37
	Gold-YOLO	79.93	63.76
	YOLOv9c	83	67.80
	YOLOv5s	82.27	65.97
	PCD-YOLO	83.27	67.27
DIOR	YOLOv3	81.2	61.4
	YOLOv6	76.03	55.77
	Gold-YOLO	76.97	56.03
	YOLOv9c	83.8	43.7
	YOLOv5s	81.00	58.87
	PCD-YOLO	82.20	61.50
DOTAv1.0	YOLOv3	75	50
	YOLOv6	63.77	41.30
	Gold-YOLO	64.06	41.96
	YOLOv9c	69.40	42
	YOLOv5s	71.87	46.00
	PCD-YOLO	72.57	47.33
VisDrone	YOLOv3	33.53	19.47
	YOLOv6	35.07	20.47
	Gold-YOLO	34.93	20.16
	YOLOv9c	0.06	0.02
	YOLOv5s	34.27	18.77
	PCD-YOLO	35.53	19.60
HRSC2016	YOLOv3	72.7	62.4
	YOLOv6	27.8	19.90
	Gold-YOLO	29.43	21.83
	YOLOv9c	73.5	65.20

	YOLOv5s	58.60	49.20
	PCD-YOLO	62.93	51.10

由表 4.2 可知, 所提算法具有一定优势。在六个数据集上, 本算法 PCD-YOLO 的 mAP_{50}^{val} 和 $mAP_{50:95}^{val}$ 均优于 YOLOv5s。具体而言, 在 NWPU VHR-10 数据集上, PCD-YOLO 比 YOLOv9c 高 1.73%, 比 Gold-YOLO 高 10.56%; 在 SIMD 数据集上, PCD-YOLO 比 YOLOv9c 高 0.27%, 比 Gold-YOLO 高 3.35%; 在 DIOR 数据集上, PCD-YOLO 比 Gold-YOLO 高 5.23%; 在 VisDrone2019 数据集上, PCD-YOLO 比 YOLOv9c 高 35.47%, 比 Gold-YOLO 高 0.6%。此外, 本模型在各数据集上的 $mAP_{50:95}^{val}$ 指标也表现出更优性能: 在 NWPU VHR-10 数据集上比 Gold-YOLO 高 10.64%; 在 SIMD 数据集上比 Gold-YOLO 高 3.51%; 在 DIOR 数据集上比 YOLOv9c 高 17.8%, 比 Gold-YOLO 高 5.47%; 在 DOTA v1.0 数据集上比 YOLOv9c 高 5.33%, 比 Gold-YOLO 高 0.37%; 在 VisDrone2019 数据集上比 YOLOv9c 高 19.58%。

表 4.3 与改进算法对比实验结果

Table 4.3 Comparison experiment results with improved algorithms

数据集			
NWPU VHR-10		DIOR	
算法	mAP_{50}^{val}	算法	mAP_{50}^{val}
KCFS-YOLOv5 ^[79]	94.21	Xu et al ^[84]	80.5
Improved-YOLOv5s ^[80]	85.4	Liu et al ^[85]	82.9
AF-SSD ^[81]	69.8	Zhang et al ^[86]	83.1
YOLO-SE ^[82]	94.9	Hou et al ^[87]	76.29
DS-YOLOv8 ^[83]	92.9	Deng et al ^[88]	92.9
PCD-YOLO	96.33	PCD-YOLO	82.2

表 4.3 中的实验结果表明, 在 NWPU VHR-10 数据集上 PCD-YOLO 的表现最为优异, mAP_{50}^{val} 达到了 96.33%, 远超其他对比方法。PCD-YOLO 通过引入更强大的特征提取模块, 有效增强了目标区域的表达能力, 使得模型在复杂背景下依然能够精准识别小目标和密集目标。相比之下, YOLO-SE 和 KCFS-YOLOv5 也取得了较好的检测效果, mAP_{50}^{val} 分别为 94.9% 和 94.21%, 表明它们在优化特征提取和注意力机制方面的改进同样提升了检测能力。然而, PCD-YOLO 进一步优化了多尺度特征融合, 结合更优的检测策略, 使得其在遥感目标检测任务中达到更高的检测精度。DS-YOLOv8 的 mAP_{50}^{val} 为 92.9%, 虽然表现不俗, 但仍低于 PCD-YOLO, 这表明 PCD-YOLO 在遥感数据集上的优化策略更适应复杂场景, 能够有效提升目标的区分能力。此外,

Improved-YOLOv5s 和 AF-SSD 的 mAP_{50}^{val} 相对较低, 分别为 85.4% 和 69.8%, 说明它们在遥感目标检测任务中仍有较大的优化空间。

在 DIOR 数据集上, PCD-YOLO 在该数据集上依然取得了较好的检测效果, mAP_{50}^{val} 达到 82.2%, 进一步验证了其强大的特征提取能力和鲁棒性。PCD-YOLO 通过增强不同尺度特征的信息交互, 使得小目标和复杂背景下的目标检测效果大幅提升, 因此在 DIOR 这样的挑战性数据集中依然能保持较高的检测精度。Deng 等人提出的 DS-YOLOv8 在该数据集上的 mAP_{50}^{val} 为 92.9%, 表现相当优异, 表明该模型在 DIOR 任务上具有较强的适应性。然而, PCD-YOLO 依然在该数据集上保持了稳健的检测能力, 并在部分目标类别上取得了更好的检测效果, 特别是在小目标检测任务上表现突出。Zhang 和 Liu 等人提出的方法在 DIOR 数据集上 mAP_{50}^{val} 分别为 83.1% 和 82.9%, 相比 PCD-YOLO 表现接近, 说明这些方法在 DIOR 数据集上的适应性较强。然而, PCD-YOLO 在检测精度和鲁棒性方面依然保持优势, 使其在更广泛的目标检测任务中具有更强的泛化能力。相比之下, Xu 和 Hou 等人提出的方法 mAP_{50}^{val} 分别为 80.5% 和 76.29%, 在该数据集上的表现相对较弱, 说明这些方法在复杂场景下的适应性仍需进一步优化。

3.6 本章小结

本章针对遥感目标检测中多尺度目标差异、遥感图像背景复杂及小目标多样性等问题, 采用三种策略改进 YOLOv5 的性能。首先, 基于一个四层的金字塔卷积设计了基于无参数注意力机制的卷积模块, PSConv。其次, 设计了注意力卷积模块, CGAM。最后, 检测头使用解耦合头。通过上述三种策略, 本章提出的新型实时目标检测算法 PCD-YOLO 相较于 YOLOv5s、YOLOv9c、Gold-YOLO、YOLOv6、YOLOv3 等六个模型, 在多个数据集上均展现出更优的性能。同时, 与 KCFS-YOLOv5、DS-YOLOv8 等十种基于 YOLO 的改进算法相比, 本算法同样具有性能优势。

4 基于改进 YOLOv9 的钢材表面缺陷目标检测算法

4.1 引言

钢材表面缺陷检测是工业质量控制中的关键环节，直接影响产品质量与生产安全。传统检测方法依赖人工目检或图像处理技术，存在效率低、漏检率高、难以适应复杂工业场景等问题。近年来，基于深度学习的目标检测算法（如 YOLO 系列）因其高精度与实时性，逐渐成为主流解决方案。然而，钢材表面缺陷具有形态多样、尺度变化大、背景干扰复杂等特点，现有 YOLOv9 模型在面临小目标缺陷检测及复杂背景抑制时仍存在局限性。为此，本研究提出一种改进的 YOLOv9 算法 EPSC-YOLO，旨在通过优化特征提取网络、调整模型参数等手段，提高表面缺陷检测的准确性和效率。本章内容主要包括算法改进与实现、实验设计与结果分析等方面，旨在通过实证研究验证改进算法的有效性和优越性。本文的研究不仅具有重要的理论价值，而且在实际应用中具有广泛的前景和意义。

4.2 基于跨空间学习的高效多尺度注意力模块（EMA）

传统的卷积由于其接受域的固定大小，难以同时捕捉小物体的细节和大物体的全局特征，这影响了其在多尺度目标检测中的有效性。此外，卷积主要依赖于局部特征提取，难以捕获对象之间的长期依赖关系和全局上下文信息，限制了其在复杂场景中检测被遮挡或密集目标的能力。相比之下，注意力机制会动态地调整特征的权重，增强对全局信息的捕获和远程依赖关系，自适应地关注重要特征，有效地处理多尺度对象，从而解决了卷积在捕获全局信息和处理多尺度特征方面的不足。因此，我们引入了一种名为高效多尺度注意模块（EMA）^[89]。EMA 模块可以通过并行子结构避免更多的顺序处理和更大的深度。其结构如图 5.1 所示。




图 5.1 EMA 模块

Fig. 5.1 EMA module

根据图 5.1, EMA 模块首先采用平行的水平和垂直池化操作, 对输入特征图的高度和宽度进行自适应平均池化, 从而提取多尺度空间信息。接下来, 使用 1×1 卷积来融合合并后的特征, 并通过分解操作将融合后的特征分离成与高度和宽度相关的组件。这种并行处理方法允许模型在同一层次上捕获来自不同尺度的信息, 避免了顺序处理的复杂性, 从而提高了计算效率。为了进一步稳定训练过程, EMA 模块使用组规范化 (GN) 对每一组内的特征进行规范化, 确保即使使用浅层网络, 仍然可以实现有效的训练。然后, 该模块使用 3×3 卷积来进一步细化特征, 捕获局部空间信息, 并增强模型的局部感知能力。接下来, EMA 模块通过自适应平均池化, 对每个通道的空间信息进行加权计算每个特征映射的全局上下文信息。然后, 应用 Softmax 计算空间注意权重, 使模型能够自动学习如何跨多尺度和多通道水平的空间位置权重。通过这一系列的设计, EMA 模块有效地减少了网络层数, 提取了多尺度特征, 提高了计算效率和模型的表达能力。

4.3 金字塔卷积

根据 4.4.2 节对标准卷积以及金字塔卷积的对比分析, 我们设计了两种不同的金字

塔卷积: PyConv2、PyConv3。结构见下图 5.2 和图 5.3:




图 5.2 PyConv2 模块

Fig. 5.2 PyConv2 module




图 5.3 PyConv3 模块

Fig. 5.3 PyConv3 module

4.4 Soft-NMS

Soft-NMS 是一种基于 NMS 的改进算法, 它采用了一种 Soft 方法, 见图 5.4 中的绿框。

```

Input :  $\mathcal{B} = \{b_1, b_2, \dots, b_N\}, S = \{s_1, s_2, \dots, s_N\}, N_t$ 
 $\mathcal{B}$  is the list of initial detection boxes
 $S$  contains corresponding detection scores
 $N_t$  is the NMS threshold

begin
 $\mathcal{D} \leftarrow \{\}$ 
while  $\mathcal{B} \neq \text{empty}$  do
     $m \leftarrow \text{argmax } S$ 
     $\mathcal{M} \leftarrow b_m$ 
     $\mathcal{D} \leftarrow \mathcal{D} \cup \mathcal{M}; \mathcal{B} \leftarrow \mathcal{B} - \mathcal{M}$ 
    for  $b_i$  in  $\mathcal{B}$  do
        if  $\text{iou}(\mathcal{M}, b_i) \geq N_t$  then
             $\mathcal{B} \leftarrow \mathcal{B} - b_i; S \leftarrow S - s_i$ 
        End
         $s_i \leftarrow s_i f(\text{iou}(\mathcal{M}, b_i))$ 
    end
end
return  $\mathcal{D}, S$ 
end
    
```

图 5.4 SoftNMS 算法

Fig. 5.4 SoftNMS algorithm

Soft-NMS 不会直接删除所有 IoU 大于阈值的候选框；相反，它降低了 IoU 大于阈值的所有候选框的置信度分数^[100]。Soft-NMS 的具体步骤如下：

1. 对候选框进行排序：根据置信度（分类分数）对检测到的候选框进行降序排序，对置信度较高的候选框进行优先排序。
2. 选择置信度最高的框：从已排序的候选框列表中，选择置信度最高的框作为当前框，并将其添加到最终的结果列表中。
3. 计算值（交并比）：对于其余候选框，用当前框 $\mathcal{M}$ 计算其值（联合交集）。
4. 更新置信度：对于当前框 $\mathcal{M}$ 大于一定阈值的候选框（即明显重叠的框），不直接删除，但通过以下方法逐步降低置信度：根据不同的衰减函数调整每个重叠候选框的置信度。在 Soft-NMS 中常用的衰减函数包括公式 5.1 和公式 5.2：

线性衰减：

$$s_i = s_i * (1 - \text{IoU}(\mathcal{M}, B_i)) \quad (5.1)$$

高斯衰减

$$s_i = s_i * e^{\frac{-\text{IoU}(\mathcal{M}, B_i)^2}{\sigma}} \quad (5.2)$$

其中, s_i 是候选框的原始置信度得分, $\text{IoU}(\mathcal{M}, B_i)$ 是当前框 $\mathcal{M}$ 和候选框 B_i 之间的 IOU 值, σ 是控制衰减率的参数。

5. 删除低置信度框: 从列表中删除置信度分数低于阈值的候选框。

6. 重复上述步骤: 从剩余的候选框中选择新的高度置信度框, 并重复步骤 3-5, 直到所有候选框都已处理完毕。

7. 输出结果: 剩余的候选框作为最终的检测结果输出。Soft-NMS 通过置信度衰减机制保留了更多的潜在目标, 从而提高了检测性能, 而不影响定位精度。

基于 Soft-NMS 的优势, EPSC-YOLO 算法使用 Soft-NMS 作为后处理算法。

4.5 基于卷积块注意力模块设计的 CISBA 模块

CBAM (如图 5.5) 是一个将空间注意力和通道注意力相结合的注意力机制模块^[101]。




图 5.5 CBAM 模块

Fig. 5.5 CBAM module

输入特征图首先经过通道注意力模块, 通过自适应平均池化和最大池化压缩空间维度, 得到两个 $1 \times 1 \times C$ 的通道描述向量; 随后这两个向量分别经过共享的轻量级 MLP (由两个 1×1 卷积构成, 中间通过 ReLU 激活和降维), 将输出的权重相加后经 Sigmoid 生成通道注意力掩码, 与原特征图逐通道相乘, 强化关键通道的特征响应。接着, 加权后的特征图进入空间注意力模块: 沿通道维度分别进行平均池化和最大池化, 得到两个 $H \times W \times 1$ 的空间特征图, 拼接后通过一个 7×7 卷积层融合空间信息, 再经 Sigmoid 生成空间注意力权重, 最终与特征图逐位置相乘, 突出重要区域的空间细节。经过通道与空间双重注意力机制的级联调整, 输出特征图在通道维度和空间维度上均实现了对关

键信息的自适应增强。虽然 CBAM 可以通过通道注意模块来适应特征图中各通道的重要性,但突出了整个图像中的关键局部区域仍需要改进,因此本文提出了一个新的模块,名为 CISBA 模块,结构如图 5.6 所示。




图 5.6 CISBA 模块

Fig. 5.6 CISBA module

根据图 5.6, CISBA 模块集成了三个核心机制:通道注意力机制、Involution 操作和空间注意力机制。这些机制在各自的级别上优化了输入特征映射,从而显著提高了模型的特征提取能力。

首先,通道注意力机制给每个通道分配不同的权重来细化特征映射的通道维数。该机制使用平均池化和最大池化技术捕获每个通道的全局特征,然后通过卷积层生成通道权重。这些权重用来调整每个通道的贡献度,增强最具区别性通道的特征,使网络能够专注于更有价值的信息。在 CISBA 模块中,将通道注意机制首先应用于输入特征图,确保网络在后续处理过程中优先关注信息最丰富的通道。为了保持原始信息的完整性,CISBA 模块中使用了残差连接,允许将输入特征直接添加到通道注意机制的输出中,从而防止由于过度处理而导致的信息丢失问题。

接下来,Involution 操作通过动态生成卷积核来增强局部特征的表达能力。与传统固定卷积核不同,Involution 根据输入特征图自适应生成卷积核参数。此类动态生成的卷积核在捕捉局部空间关系时更具灵活性,尤其在处理复杂局部特征时展现出更高的精度与效率。该操作通过卷积层生成卷积核权重,随后对输入特征图执行展开、加权及求

和操作, 最终输出优化后的局部特征图。在 CISBA 模块中, Involution 操作接收经过通道注意力机制加权的特征图, 从而进一步提升其局部空间表征能力。为确保原始特征信息的完整性, 残差连接再次被引入, 将原始输入特征直接叠加至 Involution 操作后的结果上, 这一机制有效促进了网络训练过程中更高效的梯度传播。

最终, 空间注意力机制通过基于空间位置的重要性分配权重, 优化特征图的空间分布。该机制首先对输入特征图执行池化操作, 分别通过平均池化和最大池化提取每个空间位置的特征信息, 随后通过卷积层生成空间注意力图。该注意力图表征了各空间位置的权重值, 经 Sigmoid 激活函数处理后, 与原始特征图进行逐元素相乘, 从而突出关键区域特征, 同时抑制无关区域的影响。在 CISBA 模块中, 空间注意力机制被部署于 Involution 操作之后, 进一步从空间层面增强特征图的表征能力。与此前机制相同, 残差连接在此阶段同样至关重要, 其将空间注意力机制的输出与 Involution 操作后的特征图相连接。

CISBA 模块的设计既确保了原始特征信息不被丢弃, 又为模型训练的稳定性与收敛性提供了保障。通过整合上述机制, CISBA 模块实现了特征图在多层级上的协同优化, 显著提升了模型的表达能力与整体性能。

4.6 EPSC-YOLO 目标检测算法实验分析

实验在 Linux 系统上进行, 实验环境包括 Python 3.8.18、PyTorch 1.13.1 和 CUDA 11.7。所有模型都在 8 个 NVIDIA A30 24GB GPU 上使用分布式训练进行训练。

选择了四个主要指标: (1) P (Precision 精度) (2) R (Recall 召回率) (3) mAP_{50}^{val} (平均精度 (IoU 阈值为 0.5)) (4) $mAP_{50:95}^{val}$ (平均精度 (IoU 阈值从 0.5 到 0.95))。

4.6.1 网络架构




图 5.7 EPSC-YOLO 网络架构

Fig. 5.7 The structure of EPSC-YOLO

EPSC-YOLO 算法的总体结构见上图 5.7。首先，在主干网络中原始的 Conv 模块后引入了有效的多尺度注意力机制。其次，我们设计了两种类型的金字塔卷积，PyConv2、PyConv3。第三，我们提出了一种新的卷积注意机制模块 CISBA 模块，通过将其放置在主干网络和颈部网络之间，来提高复杂背景下小目标的检测能力。最后，我们使用 Soft-NMS 代替 NMS 来进一步提高目标检测的精度。

4.6.2 消融实验及分析

在本节中，我们在相同实验环境下在 NEU-DET 和 GC10-DET 数据集上进行了五组消融实验，以验证 YOLOv9c 算法中各项改进操作的有效性。具体改进包括：引入 EMA 机制、设计 PyConv3 与 PyConv2 模块和 CISBA 模块、以及使用 SoftNMS 替代原始的 NMS 算法。实验结果如表 5.1 和表 5.2 所示，其中加粗部分表示改进后模型的性能表现。

表 5.1 NEU-DET 数据上的消融实验结果

Table 5.1 Ablation experiment results on the NEU-DET dataset

数据集	NEU-DET			
评价指标	P	R	mAP_{50}^{val}	$mAP_{50:95}^{val}$
YOLOv9c	75.9	71.2	75.6	44.9
+EMA	75.3	74.1	75.6	45.2
+PyCOnv	75.4	74.4	78.7	46.5
+SoftNMS	73.8	74.4	77.9	49.5
+CISBA	74.5	74.3	77.6	50

表 5.2 GC10-DET 数据上的消融实验结果

Table 5.2 Ablation experiment results on the GC10-DET dataset

数据集	GC10-DET			
评价指标	P	R	mAP_{50}^{val}	$mAP_{50:95}^{val}$
YOLOv9c	71.5	69.9	70.6	37.5
+EMA	72.4	71.1	73.8	39.8
+PyCOnv	71	67.3	69.2	36.2
+SoftNMS	70.2	72.6	74.2	39
+CISBA	74.5	70.1	73	39.9

由表 5.1 可知：首先，在主干网络第二个卷积模块后引入 EMA 模块，模型的 P 值为 75.3，较原始模型略微下降 0.6%，但 R 值与 $mAP_{50:95}^{val}$ 分别提升 2% 和 0.3%；其次，将主干网络和检测头中的原始卷积模块替换为 PyConv2 (双层金字塔卷积) 和 PyConv3 (三层金字塔卷积)，在 EMA 模块的基础上引入金字塔卷积后，模型的四项评估指标均提升，其中 mAP_{50}^{val} 显著提升 3.1%，验证了金字塔卷积的有效性；再次，使用 SoftNMS 替代原 NMS 算法，表 5.1 结果显示 $mAP_{50:95}^{val}$ 提升显著，表明模型对小目标的检测能力进一步增强；最后，引入 CISBA 模块后，P 值、 mAP_{50}^{val} 和 $mAP_{50:95}^{val}$ 均有提升，进一步验证了该模块对小目标特征增强的有效性。

由表 5.2 可见，本文提出的改进措施均有效提升了模型在 GC10-DET 数据集上的检测能力。与基线算法 YOLOv9c 相比，改进后算法的四项评价指标——精确率 (P)、召回率 (R)、验证集 mAP_{50}^{val} 和 $mAP_{50:95}^{val}$ 分别提升了 3%、0.2%、2.4% 和 2.4%，各项性能均获得不同程度优化。

4.6.3 可视化结果及分析

为了直观展示该 EPSC-YOLO 算法的检测性能,我们将具有代表性的检测结果图像可视化,如图 5.8 和图 5.9 所示。

图 5.8 显示了来自两个数据集的代表性检测结果图像。第一行用于 NEU-DET 数据集,第二行用于 GC10-DET 数据集。从左到右,图像分别为:原始图像 (A (1)、B (1))、原始模型的检测结果 (A (2)、B (2))、改进算法的检测结果 (A (3)、B (3))。

图 5.9 显示了来自两个数据集的代表性检测结果图像。第一行是 NEU-DET 数据集,第二行是 GC10-DET 数据集。从左到右,图像分别为:原始图像 (A (1)、B (1))、原始模型的检测结果 (A (2)、B (2))、改进算法的检测结果 (A (3)、B (3))。图 5.9 更加直观地比较了 NEU-DET 和 GC10-DET 数据集上的检测结果,分为两个显示组(左和右)。在每组中,原始图像(图 5.9 (A1)、(B1))、YOLOv9c 检测结果(图 5.9 (A2)、(B2))和所提出的 EPSC-YOLO 算法检测结果(图 5.9 (A3)、(B3))按顺序显示。




图 5.8 原始图像以及 YOLOv9c 和 EPSC-YOLO 的可视化结果。A(1-3): NEU-DET, B(1-3): GC10-DET。

Fig. 5.8 Original image and visualization results of YOLOv9c and EPSC-YOLO. A(1-3): NEU-DET, B(1-3): GC10-DET.

根据图 5.8, 在 NEU-DET 数据集中, 改进的 EPSC-YOLO 算法检测到 YOLOv9c 遗漏的包含(见图 5.8 (A3)), EPSC-YOLO 的置信度高于 YOLOv9c。在 GC10-DET 数据集中, 虽然 EPSC-YOLO 的置信度不高于 YOLOv9c, 但它接近 YOLOv9c, 改进的

EPSC-YOLO 算法检测到 YOLOv9 遗漏的油点 (见图 5.8 (B3))。




图 5.9 原始图像及 YOLOv9c 和 EPSC-YOLO 的检测结果可视化: A(1-3):NEU-DET, B(1-3):GC10-DET.

Fig. 5.9 Original image and visualization of detection results for YOLOv9c and EPSC-YOLO: A(1-3): NEU-DET, B(1-3): GC10-DET.

根据图 5.9, 在 NEU-DET 数据集中, 改进的 EPSC-YOLO 算法检测到 YOLOv9c 遗漏的包含 (见图 5.9 (A3)), EPSC-YOLO 的置信度高于 YOLOv9c。在 GC10-DET 数据集中, 虽然 EPSC-YOLO 的置信度不高于 YOLOv9c, 但它接近 YOLOv9c, 改进的 EPSC-YOLO 算法检测到 YOLOv9 遗漏的油点 (见图 5.9 (B3))。根据图 5.9, 在 NEU-DET 数据集中, 改进的 EPSC-YOLO 算法检测 YOLOv9c 遗漏的划痕 (见图 5.9 (A3) 中的紫色框), 在 GC10-DET 数据集中, 改进的 EPSC-YOLO 算法检测 YOLOv9 遗漏的丝点 (见图 5.9 (B3) 中的红框)。此外, 在两个数据集中, EPSC-YOLO 的置信度得分均高于 YOLOv9c。

综上对图 5.8 和图 5.9 的分析, 改进后的算法不仅在检测小缺陷方面具有显著的优势, 而且在检测方面提供了更广泛、更全面的覆盖面, 且该算法的性能优于原始算法

4.6.4 对比实验及分析

为了进一步验证本文提出的改进算法的检测性能, 我们进行了比较分析。将所提出的目标检测算法与各种经典算法和改进的算法进行了比较, 包括 7 种经典方法 (如 YOLOv5、Gold-YOLO 等), 实验结果见表 5.3 和表 5.4。以及改进的方法 (如 Li 等人提出的改进算法), 见表 5.5 和表 5.6。

表 5.3 NEU-DET 数据集上各算法实验对比结果

Table 5.3 Experimental comparison results of various algorithms on the NEU-DET dataset

数据集	NEU-DET			
模型	P	R	mAP ₅₀ ^{val}	mAP _{50:95} ^{val}
YOLOv3	78.00	68.5	72.50	40.60
YOLOv5	73.58	73.70	74.23	41.48
YOLOv6	41.37	62.47	73.37	41.37
YOLOv8	81.00	70.10	75.30	44.90
Gold-YOLO	42.57	66.43	75.27	42.57
YOLOv9	75.90	71.20	75.60	44.90
YOLOv10	76.10	70.60	76.30	44.80
EPSC-YOLO	74.50	74.30	77.60	50

表 5.4 GC10-DET 数据集上的经典模型实验对比结果

Table 5.4 Experimental comparison results of various algorithms on the GC10-DET dataset.

数据集	GC10-DET			
模型	P	R	mAP_{50}^{val}	$mAP_{50:95}^{val}$
YOLOv3	68.50	69.50	69.90	35.10
YOLOv5	75.63	61.97	68.73	34.80
YOLOv6	31.73	53.03	65.00	31.73
YOLOv8	74.30	68.80	70.50	36.50
Gold-YOLO	33.07	55.63	66.03	33.07
YOLOv9	71.50	69.90	70.60	37.50
YOLOv10	68.80	65.60	68.50	34.50
EPSC-YOLO	74.50	70.10	73	39.90

表 5.3 和表 5.4 分别显示了不同的 YOLO 模型在 NEU-DET 和 GC10-DET 数据集上的性能。

根据表 5.3 中的数据,就 P 而言,EPSC-YOLO 的 P 为 74.50,与其他 YOLO 模型相比表现适中。在精度方面,YOLOv8 领先,P 为 81.00,表现出最强的假阳性抑制能力,确保了检测结果的准确性。紧随其后的是 YOLOv3,P 为 78.00,其性能也很强,具有良好的准确性。YOLOv9 和 YOLOv10 的 P 值分别为 75.90 和 76.10,并且在需要高精度的任务中仍然表现出色。相比之下,YOLOv5 的 P 为 73.58,略低,但仍保持着良好的精度,适用于各种应用场景。YOLOv6 和 Gold-YOLO 的精度值分别为 41.37 和 42.57。较低的精度表明,它们可能产生更多的假阳性,限制了它们在高精度检测任务中的使用。

在召回率 (R) 方面,EPSC-YOLO 以 74.30 的值突出,显示了其捕获缺陷的特殊能力。YOLOv5 紧随其后,R 为 73.70,也表现出色,能够捕获大多数缺陷。YOLOv9 和 YOLOv10 的 R 值分别为 71.20 和 70.60,R 值略低,但性能仍然表现很好,适用于各种缺陷检测场景。YOLOv8 的 R 值为 70.10,略低于其他模型,但仍具有较强的缺陷捕获能力。Gold-YOLO 和 YOLOv6 的 R 值分别为 66.43 和 62.47,表现较差,可能无法捕捉到所有缺陷,这限制了它们在复杂任务中的应用。

在 mAP_{50}^{val} 方面,EPSC-YOLO 以 mAP_{50}^{val} 为 77.60 领先,显示了其在 $IoU = 0.5$ 条件下的优异性能。YOLOv10 紧随其后,其 mAP_{50}^{val} 为 76.30,性能稳定,精度高,排名第二。YOLOv9 和 YOLOv8 的 mAP_{50}^{val} 值分别为 75.60 和 75.30,在 $IoU = 0.5$ 时提供了稳定的精度,使它们适用于表面缺陷检测任务。Gold-YOLO 的 mAP_{50}^{val} 为 75.27,比较稳定,但略低于 YOLOv8 和 YOLOv9。YOLOv5 的 mAP_{50}^{val} 为 74.23,略低于其他高精度模型,但仍提供了良好的检测能力。YOLOv6 的 mAP_{50} 为 73.37,虽保持了一定精度,但显著低

于其他先进模型，导致其在 $\text{IoU}=0.5$ 时的性能表现欠佳；而 YOLOv3 的验证集 mAP_{50} ($\text{mAP}_{50\text{val}}$) 最低 (72.50)，表明其在中低交并比 (IoU) 条件下的检测精度相对不足，可能导致关键缺陷漏检。

在 $\text{mAP}_{50:95}^{\text{val}}$ 指标中，EPSC-YOLO 以 50% 的数值再次表现突出，远超其他模型，表明其能够在多个 IoU 阈值下保持高检测精度；YOLOv8 与 YOLOv9 的 $\text{mAP}_{50:95}^{\text{val}}$ 均为 44.90%，体现二者在跨阈值条件下的均衡性能与稳定检测能力；YOLOv10 的 $\text{mAP}_{50:95}^{\text{val}}$ 为 44.80%，虽略低于 YOLOv8/YOLOv9，但仍保持较强检测性能。相比之下，YOLOv5 的 $\text{mAP}_{50:95}^{\text{val}}$ 为 41.48%，在高 IoU 阈值下性能有所下降；而 YOLOv6 与 Gold-YOLO 的 $\text{mAP}_{50:95}^{\text{val}}$ 分别为 41.37% 和 42.57%，其在高阈值条件下难以维持精度，导致复杂检测任务中性能欠佳。

根据表 5.4 所示数据，在精度(P)方面，EPSC-YOLO 的精度为 74.50，为中等，在所有模型中处于上限范围。YOLOv5 的 P 为 75.63，略高于 EPSC-YOLO，显示出其在减少假阳性方面的优势。YOLOv9 的 P 值为 71.50，排名第三。虽然略低于 YOLOv5，但它仍具有良好的假阳性抑制能力。YOLOv8 和 YOLOv10 的 P 分别为 74.30 和 68.80，说明它们在减少假阳性方面的表现相对相似，尤其是 YOLOv8，其表现相对较好。YOLOv3 和 Gold-YOLO 的精度分别为 68.50 和 33.07，表现较差，尤其是 Gold-YOLO，其精度远低于其他模型，表明假阳性抑制存在显著问题。YOLOv6 在所有模型中 P 最低，为 31.73，可能导致较高的假阳性。

在召回率 (R) 方面，EPSC-YOLO 以 70.10 的 R 值领先于所有模型，展示了其优秀的缺陷检测能力。YOLOv9 和 YOLOv8 的召回率分别为 69.90 和 68.80，接近于体外循环，并且在捕捉大多数缺陷方面也表现良好。YOLOv5 的 R 为 61.97，略低于前三名，但仍然保持着很强的缺陷检测能力。YOLOv3 的 R 值为 69.50，表现良好。YOLOv6 和 Gold-YOLO 的 R 分别为 53.03 和 55.63，与其他模型相比，R 较低，可能导致检测失败，并影响它们在复杂场景中的应用。

在 $\text{mAP}_{50}^{\text{val}}$ 指标上，EPSC-YOLO 以 73% 的数值位居榜首，在 $\text{IoU}=0.5$ 条件下表现出色；YOLOv9 以 70.60% 位列第二，展现出优异的高精度检测能力；YOLOv8 以 70.50% 紧随其后，性能与 YOLOv9 相近。YOLOv5 的 $\text{mAP}_{50}^{\text{val}}$ 为 68.73%，虽略低但仍保持稳定；YOLOv3 与 YOLOv10 分别以 69.90% 和 68.50% 的 $\text{mAP}_{50}^{\text{val}}$ 落后于主流模型；而 Gold-YOLO (66.03%) 与 YOLOv6 (65.00%) 的 $\text{mAP}_{50}^{\text{val}}$ 显著偏低，表明其在 $\text{IoU}=0.5$ 条件下的检测精度不足，影响表面缺陷检测的可靠性。

在 $\text{mAP}_{50:95}^{\text{val}}$ 指标上，EPSC-YOLO 再次以 39.9% 的数值领先所有模型，凸显其跨 IoU 阈值的高精度保持能力；YOLOv9 (37.50%) 与 YOLOv8 (36.50%) 分列二、三位，展现较强的多阈值检测稳定性；YOLOv5 以 34.80% 的 $\text{mAP}_{50:95}^{\text{val}}$ 低于上述三种模型，但仍适

用于常规检测任务；YOLOv3 (35.10%) 与 YOLOv10 (34.50%) 表现中等，可满足低精度需求场景；而 Gold-YOLO (33.07%) 和 YOLOv6 (31.73%) 的 $mAP_{50:95}^{val}$ 在所有模型中垫底，其跨阈值检测能力薄弱，难以应对复杂工业场景下的缺陷识别需求。

表 5.5 NEU-DET 数据集上改进模型实验对比结果

Table 5.5 Experimental comparison results of the improved model on the NEU-DET dataset

数据集	NEU-DET	
模型	mAP_{50}^{val}	$mAP_{50:95}^{val}$
EDNN ^[102]	72.4	-----
Improved-YOLOv5 ^[103]	73.08	37.57
Regularized YOLO ^[104]	80.77	47.62
MSFT-YOLO ^[105]	75.2	-----
Improved Multi-Scale YOLO-v5 ^[106]	72	37.2
Kou's ^[107]	72.2	-----
YOLO-LFPD ^[108]	81.2	-----
WFRE-YOLOv8s ^[109]	79.4	-----
EPSC-YOLO	77.6	50

表 5.6 GC10-DET 数据集上改进模型实验对比结果

Table 5.6 Experimental comparison results of the improved model on the GC10-DET dataset

数据集	GC10-DET	
模型	mAP_{50}^{val}	$mAP_{50:95}^{val}$
EDNN ^[102]	65.1	-----
Kou's ^[107]	71.3	-----
YOLO-LFPD ^[108]	72.8	-----
WFRE-YOLOv8s ^[109]	69.4	-----
Improved-YOLOX ^[110]	70.5	-----
LSD-YOLOv5 ^[111]	67.9	-----
EPSC-YOLO	73	39.9

表 5.5 和表 5.6 展示了 EPSC-YOLO 模型在 NEU-DET 和 GC10-DET 数据集上与其他改进的目标检测模型的性能对比。

根据表 5.5 中 NEU-DET 数据集上 mAP_{50}^{val} 性能的对比，多数模型结果较为接近。其中，Regularized YOLO 以 80.77% 的 mAP_{50}^{val} 取得最佳性能，略优于 mAP_{50}^{val} 为 81.2% 的

YOLO-LFPD, 两者表现相近。相比之下, EPSC-YOLO (本文模型) 的 mAP_{50}^{val} 为 77.6%, 虽稍低于前两者, 但仍展现出较强的目标检测能力, 尤其是其 mAP_{50}^{val} 表现突出。其他模型如 Improved-YOLOv5 (73.08%) 和 Improved Multi-Scale YOLO-v5 (72%) 在此指标中表现较弱, 表明这些模型可能存在边界框定位不准确或漏检问题, 从而影响了 mAP_{50}^{val} 。在更严格的 $mAP_{50:95}^{val}$ 评估标准下, EPSC-YOLO (本文模型) 以 50%的数值显著领先, 表明其在高 IoU 阈值下的精确定位与高质量检测能力上具有明显优势。Regularized YOLO 以 47.62%紧随其后, 但在严格 IoU 标准下稍显不足。Improved-YOLOv5 (37.57%) 和 Improved Multi-Scale YOLO-v5 (37.2%) 的 $mAP_{50:95}^{val}$ 较低, 表明这些模型在高精度目标定位中存在显著缺陷, 可能因无法有效优化边界框而难以满足高精度检测需求。

根据表 5.6 中 GC10-DET 数据集上 $mAP_{50:95}^{val}$ 性能的对比, EPSC-YOLO (本文模型) 以 73%的得分表现最佳, 领先其他模型, 表明其在该数据集上具备可靠的检测能力。Kou's 模型以 71.3%的 $mAP_{50:95}^{val}$ 次之, EDNN (65.1%)、YOLO-LFPD (72.8%)、WFRE-YOLOv8s (69.4%) 及 Improved-YOLOX (70.5%) 等模型表现较弱, 表明其在 GC10-DET 数据集上的检测能力存在局限。在更严格的 $mAP_{50:95}^{val}$ 标准下, EPSC-YOLO (本文模型) 再次以 39.9%的得分脱颖而出。

综上, EPSC-YOLO 在 NEU-DET 与 GC10-DET 数据集上均表现优异, 尤其在高 IoU 标准下显著领先, 验证了其强大的目标检测能力。

4.7 本章小结

本章提出了一种面向工业表面缺陷检测的改进算法 EPSC-YOLOv9, 旨在解决小尺寸缺陷和复杂形状缺陷的检测难题。首先, 设计了两种金字塔卷积以实现多尺度目标的并行处理; 其次, 针对复杂背景下小缺陷检测困难的问题, 引入 EMA 注意力机制并和 CISBA 模块以增强其有效性; 最后采用 SoftNMS 替代原 NMS 方法进一步提升模型检测能力。实验结果表明, EPSC-YOLO 在 NEU-DET 和 GC10-DET 数据集上的 mAP_{50}^{val} 值分别达到 77.6%和 73%, 较 YOLOv9c 提升 2%和 2.4%; $mAP_{50:95}^{val}$ 值分别为 50%和 39.9%, 在两类数据集上分别提升 5.1%和 2.4%。相较于经典目标检测模型, 本模型各项指标均表现优异, 特别是在 $mAP_{50:95}^{val}$ 指标上优势显著; 相比其他改进的目标检测模型, 本模型同样展现出明显优势。结果表明, EPSC-YOLO 能有效满足实际工业应用中的缺陷检测需求。

5 总结与展望

5.1 工作总结

目标检测在实际应用中极其广泛，作为目标检测中使用的最多效果最好的模型，YOLO 算法依旧存在一些待优化问题。如针对特定的场景下 YOLO 算法会存在，小目标检测精度不高、多尺度目标检测以及跨域目标检测精度不高等问题。

本文基于主流 YOLOv5 和 YOLOv9 算法，针对遥感图像目标检测领域存在的多尺度目标、复杂背景下目标漏检率高等问题，提出了一种新的实时目标检测算法 PCD-YOLO。在工业制造领域，针对产品表面缺陷检测中普遍存在的微小缺陷识别困难、不规则几何形态特征提取不足以及类间相似性导致的误检率偏高等问题，提出了一种改进的 EPSC-YOLO 算法用于工业表面缺陷检测。

在 PCD-YOLO 中，首先针对多尺度目标检测能力不足的问题，设计了一个基于无参数注意力机制 (SimAM) 的卷积模块 PSConv，抑制复杂背景的干扰并增强对不同尺度重要目标的关注，从而提升多尺度目标检测能力。其次，为缓解复杂背景下目标难以检测问题，提出注意力卷积模块 CGAM，在 C3 模块中采用全局注意力机制 (GAM)，充分利用全局上下文信息提升小目标检测能力。最后，采用解耦头 (Decoupled Head) 替代 YOLOv5 中的耦合头 (Coupled Head)，通过分离分类与回归任务的分支，进一步提高目标检测的整体性能。

在 EPSC-YOLO 中首先引入了多尺度注意模块 (EMA)，并在主干网络中使用两种新设计的金字塔卷积来更好地识别多尺度缺陷；其次，引入 Soft-NMS 来代替传统的 NMS，通过平滑和抑制重叠框的分数，可以减少信息丢失，提高多目标检测精度。此外，还设计了一种新的卷积注意力模块 CISBA，以提高对复杂背景下小目标的检测能力。

总体而言，以上改进算法有效提升了多尺度目标和复杂背景下小目标的检测能力，为实际应用中的目标检测任务提供了更精准且高效的支持。

5.2 未来展望

本文基于主流的 YOLOv5 和 YOLOv9 算法，针对遥感图像和工业制造领域的特定挑战，提出了 PCD-YOLO 和 EPSC-YOLO 两种改进算法，初步实现了提升检测精度的目标。然而，当前的检测精度和模型规模仍有提升空间。未来的研究将继续朝着更高精度、更快速度和更小模型体积的方向努力。此外，集成多模态信息和优化模型推理效率也是未来研究的重要方向之一。

参考文献

- [1] Li X, Shao G. Object-based urban vegetation mapping with high-resolution aerial photography as a single data source[J]. International journal of remote sensing, 2013, 34(3): 771-789.
- [2] Damodaran B B, Nidamanuri R R. Dynamic linear classifier system for hyperspectral image classification for land cover mapping[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2014, 7(6): 2080-2093.
- [3] Wellmann T, Lausch A, Andersson E, et al. Remote sensing in urban planning: Contributions towards ecologically sound policies?[J]. Landscape and urban planning, 2020, 204: 103921.
- [4] Wang C, Wei X, Jiang X. An automated defect detection method for optimizing industrial quality inspection[J]. Engineering Applications of Artificial Intelligence, 2024, 127: 107387.
- [5] Birlutiu A, Burlacu A, Kadar M, et al. Defect detection in porcelain industry based on deep learning techniques[C]//2017 19th International Symposium on Symbolic and Numeric Algorithms for Scientific Computing (SYNASC). IEEE, 2017: 263-270.
- [6] Wang T, Chen Y, Qiao M, et al. A fast and robust convolutional neural network-based defect detection model in product quality control[J]. The International Journal of Advanced Manufacturing Technology, 2018, 94: 3465-3471.
- [7] Feng H, Jiang Z, Xie F, et al. Automatic fastener classification and defect detection in vision-based railway inspection systems[J]. IEEE transactions on instrumentation and measurement, 2013, 63(4): 877-888.
- [8] Viola P, Jones M J. Robust real-time face detection[J]. International journal of computer vision, 2004, 57: 137-154.
- [9] Dalal N, Triggs B. Histograms of oriented gradients for human detection[C]//2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05). Ieee, 2005, 1: 886-893.
- [10] Felzenszwalb P F, Girshick R B, McAllester D, et al. Object detection with discriminatively trained part-based models[J]. IEEE transactions on pattern analysis and machine intelligence, 2009, 32(9): 1627-1645.
- [11] 陈好男. 基于 YOLO 的密集小目标检测算法研究[D]. 齐鲁工业大学, 2024.DOI:10.27278/d.cnki.gsdqc.2024.000042.
- [12] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 580-587.
- [13] Girshick R. Fast r-cnn[C]//Proceedings of the IEEE international conference on

computer vision. 2015: 1440-1448.

[14] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28.

[15] He K, Gkioxari G, Dollár P, et al. Mask r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2961-2969.

[16] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]//Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14. Springer International Publishing, 2016: 21-37.

[17] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.

[18] Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 7263-7271.

[19] Redmon J, Farhadi A. Yolov3: An incremental improvement[J]. arXiv preprint arXiv:1804.02767, 2018.

[20] Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.

[21] Wang C Y, Liao H Y M, Wu Y H, et al. CSPNet: A new backbone that can enhance learning capability of CNN[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops. 2020: 390-391.

[22] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 37(9): 1904-1916.

[23] Liu S, Qi L, Qin H, et al. Path aggregation network for instance segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 8759-8768.

[24] Jocher G, Stoken A, Chaurasia A, et al. ultralytics/yolov5: v6. 0-YOLOv5n'Nano'models, Roboflow integration, TensorFlow export, OpenCV DNN support[J]. Zenodo, 2021.

[25] Li C, Li L, Jiang H, et al. YOLOv6: A single-stage object detection framework for industrial applications[J]. arXiv preprint arXiv:2209.02976, 2022.

[26] Wang C Y, Bochkovskiy A, Liao H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 7464-7475.

[27] Jocher G, Chaurasia A, Qiu J. Ultralytics YOLO (Version 8.0.0) [Computer software]. <https://github.com/ultralytics/ultralytics>.

- [28] Wang C Y, Yeh I H, Mark Liao H Y. Yolov9: Learning what you want to learn using programmable gradient information[C]//European conference on computer vision. Cham: Springer Nature Switzerland, 2024: 1-21.
- [29] Wang A, Chen H, Liu L, et al. Yolov10: Real-time end-to-end object detection[J]. Advances in Neural Information Processing Systems, 2024, 37: 107984-108011.
- [30] Khanam R, Hussain M. Yolov11: An overview of the key architectural enhancements[J]. arXiv preprint arXiv:2410.17725, 2024.
- [31] Tian Y, Ye Q, Doermann D. Yolov12: Attention-centric real-time object detectors[J]. arXiv preprint arXiv:2502.12524, 2025.
- [32] 韩俊, 袁小平, 王准, 等. 基于YOLOv5s的无人机密集小目标检测算法[J]. 浙江大学学报(工学版), 2023, 57(06): 1224-1233.
- [33] Ren Y, Zhu C, Xiao S. Small object detection in optical remote sensing images via modified faster R-CNN[J]. Applied Sciences, 2018, 8(5): 813.
- [34] Zhang S, Wu R, Xu K, et al. R-CNN-based ship detection from high resolution remote sensing imagery[J]. Remote Sensing, 2019, 11(6): 631.
- [35] Xie W, Qin H, Li Y, et al. A novel effectively optimized one-stage network for object detection in remote sensing imagery[J]. Remote Sensing, 2019, 11(11): 1376.
- [36] Zhu H, Zhang P, Wang L, et al. A multiscale object detection approach for remote sensing images based on MSE-DenseNet and the dynamic anchor assignment[J]. Remote Sensing Letters, 2019, 10(10): 959-967.
- [37] Chang Y L, Anagaw A, Chang L, et al. Ship detection based on YOLOv2 for SAR imagery[J]. Remote Sensing, 2019, 11(7): 786.
- [38] Nie X, Duan M, Ding H, et al. Attention mask R-CNN for ship detection and segmentation from remote sensing images[J]. Ieee Access, 2020, 8: 9325-9334.
- [39] Ma H, Liu Y, Ren Y, et al. Detection of collapsed buildings in post-earthquake remote sensing images based on the improved YOLOv3[J]. Remote Sensing, 2019, 12(1): 44.
- [40] Wan D, Lu R, Wang S, et al. Yolo-hr: Improved yolov5 for object detection in high-resolution optical remote sensing images[J]. Remote Sensing, 2023, 15(3): 614.
- [41] Wang C, Wei X, Jiang X. An automated defect detection method for optimizing industrial quality inspection[J]. Engineering Applications of Artificial Intelligence, 2024, 127: 107387.
- [42] Birlutiu A, Burlacu A, Kadar M, et al. Defect detection in porcelain industry based on deep learning techniques[C]//2017 19th International Symposium on Symbolic and Numeric Algorithms for Scientific Computing (SYNASC). IEEE, 2017: 263-270.
- [43] Wang T, Chen Y, Qiao M, et al. A fast and robust convolutional neural network-based defect detection model in product quality control[J]. The International Journal of Advanced Manufacturing Technology, 2018, 94: 3465-3471.
- [44] Feng H, Jiang Z, Xie F, et al. Automatic fastener classification and defect detection

in vision-based railway inspection systems[J]. IEEE transactions on instrumentation and measurement, 2013, 63(4): 877-888.

[45] Zeng N, Wu P, Wang Z, et al. A small-sized object detection oriented multi-scale feature fusion approach with application to defect detection[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-14.

[46] Yang M, Yu K, Zhang C, et al. Densaspp for semantic segmentation in street scenes[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 3684-3692.

[47] Pang J, Chen K, Shi J, et al. Libra r-cnn: Towards balanced learning for object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 821-830.

[48] Wang X, Girshick R, Gupta A, et al. Non-local neural networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7794-7803.

[49] Rudolph M, Wehrbein T, Rosenhahn B, et al. Fully convolutional cross-scale-flows for image-based defect detection[C]//Proceedings of the IEEE/CVF winter conference on applications of computer vision. 2022: 1088-1097.

[50] Lv X, Duan F, Jiang J, et al. Deep metallic surface defect detection: The new benchmark and detection network[J]. Sensors, 2020, 20(6): 1562.

[51] Cheng X, Yu J. RetinaNet with difference channel attention and adaptively spatial feature fusion for steel surface defect detection[J]. IEEE Transactions on Instrumentation and Measurement, 2020, 70: 1-11.

[52] Rudolph M, Wandt B, Rosenhahn B. Same same but different: Semi-supervised defect detection with normalizing flows[C]//Proceedings of the IEEE/CVF winter conference on applications of computer vision. 2021: 1907-1916.

[53] Xu Y, Li D, Xie Q, et al. Automatic defect detection and segmentation of tunnel surface using modified Mask R-CNN[J]. Measurement, 2021, 178: 109316.

[54] Chen J, Wen Y, Nanekaran Y A, et al. Multiscale attention networks for pavement defect detection[J]. IEEE Transactions on Instrumentation and Measurement, 2023, 72: 1-12.

[55] Fan S, Liang X, Huang W, et al. Real-time defects detection for apple sorting using NIR cameras with pruning-based YOLOV4 network[J]. Computers and Electronics in Agriculture, 2022, 193: 106715.

[56] Hu W X, Xiong J T, Liang J H, et al. A method of citrus epidermis defects detection based on an improved YOLOv5[J]. Biosystems Engineering, 2023, 227: 19-35.

[57] Xiong C, Hu S, Fang Z. Application of improved YOLOV5 in plate defect detection[J]. The International Journal of Advanced Manufacturing Technology, 2022: 1-13.

[58] Xu X, Li X. Research on surface defect detection algorithm of pipeline weld based on YOLOv7[J]. Scientific reports, 2024, 14(1): 1881.

[59] Zhang C, Chen X, Liu P, et al. Automated detection and segmentation of tunnel

defects and objects using YOLOv8-CM[J]. Tunnelling and Underground Space Technology, 2024, 150: 105857.

[60] Lu M, Sheng W, Zou Y, et al. WSS-YOLO: An improved industrial defect detection network for steel surface defects[J]. Measurement, 2024, 236: 115060.

[61] 福島邦彦, 1979. コグニトロンのパターン分離能力の向上. 電子情報通信学会論文志 A, 62(10), 650-657.

[62] 福島邦彦, 1979. 位置ずれに影響されないパターン認識機構の神経回路モデル—ネオコグニロン—. 電子情報通信学会論文志 A, 62(10), 658-665.

[63] Fukushima K. Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position[J]. Biological cybernetics, 1980, 36(4): 193-202.

[64] Santry D J. Convolutional neural networks[J]. 2024, 111-131.

[65] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. nature, 2015, 521(7553): 436-444.

[66] Su Y, Yan P. A defect detection method of gear end-face based on modified YOLO-V3[C]//2020 10th Institute of Electrical and Electronics Engineers International Conference on Cyber Technology in Automation, Control, and Intelligent Systems (CYBER). IEEE, 2020: 283-288.

[67] Wang G Q, Zhang C Z, Chen M S, et al. A high-accuracy and lightweight detector based on a graph convolution network for strip surface defect detection[J]. Advanced Engineering Informatics, 2024, 59: 102280.

[68] Li Y, Xu S, Zhu Z, et al. EFC-YOLO: An efficient surface-defect-detection algorithm for steel strips[J]. Sensors, 2023, 23(17): 7619.

[69] Xuan W, Jian-She G, Bo-Jie H, et al. A lightweight modified YOLOX network using coordinate attention mechanism for PCB surface defect detection[J]. IEEE sensors journal, 2022, 22(21): 20910-20920.

[70] Peng C, Li X, Wang Y. Td-yoloa: An efficient yolo network with attention mechanism for tire defect detection[J]. IEEE Transactions on Instrumentation and Measurement, 2023, 72: 1-11.

[71] Wang R, Liang F, Wang B, et al. ODCA-YOLO: An omni-dynamic convolution coordinate attention-based YOLO for wood defect detection[J]. Forests, 2023, 14(9): 1885.

[72] Tang J, Wang Z, Zhang H, et al. A lightweight surface defect detection framework combined with dual-domain attention mechanism[J]. Expert Systems with Applications, 2024, 238: 121726.

[73] Ma Z, Li Y, Huang M, et al. A lightweight detector based on attention mechanism for aluminum strip surface defect detection[J]. Computers in Industry, 2022, 136: 103585.

[74] Chen H, Du Y, Fu Y, et al. DCAM-Net: A rapid detection network for strip steel surface defects based on deformable convolution and attention mechanism[J]. IEEE

Transactions on Instrumentation and Measurement, 2023, 72: 1-12.

[75] Xiao G, Hou S, Zhou H. PCB defect detection algorithm based on CDI-YOLO[J]. Scientific Reports, 2024, 14(1): 7351.

[76] Zheng H, Chen X, Cheng H, et al. MD-YOLO: surface defect detector for industrial complex environments[J]. Optics and Lasers in Engineering, 2024, 178: 108170.

[77] Neubeck A, Van Gool L. Efficient non-maximum suppression[C]//18th international conference on pattern recognition (ICPR'06). IEEE, 2006, 3: 850-855.

[78] Wang C, He W, Nie Y, et al. Gold-YOLO: Efficient object detector via gather-and-distribute mechanism[J]. Advances in Neural Information Processing Systems, 2023, 36: 51094-51112.

[79] Tian Z, Huang J, Yang Y, et al. KCFS-YOLOv5: A high-precision detection method for object detection in aerial remote sensing images[J]. Applied Sciences, 2023, 13(1): 649.

[80] Ma P, Che J. Remote Sensing Image Detection Based on Attention Mechanism and YOLOv5[C]//Chinese Conference on Pattern Recognition and Computer Vision (PRCV). Cham: Springer Nature Switzerland, 2022: 376-388.

[81] Lu X, Ji J, Xing Z, et al. Attention and feature fusion SSD for remote sensing object detection[J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-9.

[82] Wu T, Dong Y. YOLO-SE: Improved YOLOv8 for remote sensing object detection and recognition[J]. Applied Sciences, 2023, 13(24): 12977.

[83] Shen L, Lang B, Song Z. DS-YOLOv8-based object detection method for remote sensing images[J]. Ieee Access, 2023, 11: 125122-125137.

[84] Xu C, Yin H, Song Z, et al. Improved YOLOv5 network method for remote sensing image objects detection[C]//2022 China Automation Congress (CAC). IEEE, 2022: 1628-1633.

[85] Liu X, Gong W, Shang L, et al. Remote sensing image target detection and recognition based on yolov5[J]. Remote Sensing, 2023, 15(18): 4459.

[86] Zhang, J.; Chen, Z.; Yan, G.; Wang, Y.; Hu, B. Faster and Lightweight: An Improved YOLOv5 Object Detector for Remote Sensing Images. Remote Sensing 2023, 15, 4974.

[87] Hou S, Fan L, Zhang F, et al. An improved lightweight YOLOv5 for remote sensing images[C]//International Conference on Artificial Neural Networks. Cham: Springer Nature Switzerland, 2023: 77-89.

[88] Deng T, Liu X, Mao G. Improved YOLOv5 based on hybrid domain attention for small object detection in optical remote sensing images[J]. Electronics, 2022, 11(17): 2657.

[89] Ouyang D, He S, Zhang G, et al. Efficient multi-scale attention module with cross-spatial learning[C]//ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.

- [90] Cheng G, Han J. A survey on object detection in optical remote sensing images[J]. ISPRS journal of photogrammetry and remote sensing, 2016, 117: 11-28.
- [91] Li K, Wan G, Cheng G, et al. Object detection in optical remote sensing images: A survey and a new benchmark[J]. ISPRS journal of photogrammetry and remote sensing, 2020, 159: 296-307.
- [92] Haroon M, Shahzad M, Fraz M M. Multisized object detection using spaceborne optical imagery[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2020, 13: 3032-3046.
- [93] Xia G S, Bai X, Ding J, et al. DOTA: A large-scale dataset for object detection in aerial images[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 3974-3983.
- [94] Zhu P, Wen L, Du D, et al. Detection and tracking meet drones challenge[J]. IEEE transactions on pattern analysis and machine intelligence, 2021, 44(11): 7380-7399.
- [95] Chen W, Han B, Yang Z, et al. Mssdet: Multi-scale ship-detection framework in optical remote-sensing images and new benchmark[J]. Remote Sensing, 2022, 14(21): 5460.
- [96] He Y, Song K, Meng Q, et al. An end-to-end steel surface defect detection approach via fusing multiple hierarchical features[J]. IEEE transactions on instrumentation and measurement, 2019, 69(4): 1493-1504.
- [97] Lv X, Duan F, Jiang J, et al. Deep metallic surface defect detection: The new benchmark and detection network[J]. Sensors, 2020, 20(6): 1562.
- [98] Duta I C, Liu L, Zhu F, et al. Pyramidal convolution: Rethinking convolutional neural networks for visual recognition[J]. arXiv preprint arXiv:2006.11538, 2020.
- [99] Liu Y, Shao Z, Hoffmann N. Global attention mechanism: Retain information to enhance channel-spatial interactions[J]. arXiv preprint arXiv:2112.05561, 2021.
- [100] Bodla N, Singh B, Chellappa R, et al. Soft-NMS--improving object detection with one line of code[C]//Proceedings of the IEEE international conference on computer vision. 2017: 5561-5569.
- [101] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [102] Lv X, Duan F, Jiang J, et al. Deep metallic surface defect detection: The new benchmark and detection network[J]. Sensors, 2020, 20(6): 1562.
- [103] Li Z, Wei X, Hassaballah M, et al. A deep learning model for steel surface defect detection[J]. Complex & Intelligent Systems, 2024, 10(1): 885-897.
- [104] Zou Y, Fan Y. An infrared image defect detection method for steel based on regularized YOLO[J]. Sensors, 2024, 24(5): 1674.
- [105] Guo Z, Wang C, Yang G, et al. Msft-yolo: Improved yolov5 based on transformer for detecting defects of steel surface[J]. Sensors, 2022, 22(9): 3467.
- [106] Wang L, Liu X, Ma J, et al. Real-time steel surface defect detection with improved

multi-scale YOLO-v5[J]. Processes, 2023, 11(5): 1357.

[107] Kou X, Liu S, Cheng K, et al. Development of a YOLO-V3-based model for detecting defects on steel strip surface[J]. Measurement, 2021, 182: 109454.

[108] Lu J, Zhu M, Qin K, et al. YOLO-LFPD: A Lightweight Method for Strip Surface Defect Detection[J]. Biomimetics, 2024, 9(10): 607.

[109] Huang Y, Tan W, Li L, et al. Wfre-yolov8s: a new type of defect detector for steel surfaces[J]. Coatings, 2023, 13(12): 2011.

[110] Wang X, Zhuang K. An improved YOLOX method for surface defect detection of steel strips[C]//2023 IEEE 3rd International Conference on Power, Electronics and Computer Applications (ICPECA). IEEE, 2023: 152-157.

[111] Zhao H, Wan F, Lei G, et al. LSD-YOLOv5: a steel strip surface defect detection algorithm based on lightweight network and enhanced feature fusion mode[J]. Sensors, 2023, 23(14): 6558.