

分类号 TP391

学校代码 10495

U D C 621

密 级 公开

武汉纺织大学
学术型硕士学位论文

基于 YOLO 的钢轨表面缺陷轻量级检测算法研究

作者姓名：	刘玉娜
学 号：	2215033001
指导教师：	马双宝
学科门类：	工学
专 业：	机械工程
研究方向：	机械电子工程
完成日期：	二零二五年五月

Wuhan Textile university

M. E. Dissertation

**Research on Rail Surface Defect Detection Lightweight
Algorithm Based on YOLO**

Candidate: Yuna Liu

Supervisor: Prof. Shuangbao Ma

Time: May 2025

摘要

钢轨作为铁路运输过程的重要组成部分,由于常年暴露在外,受自然环境腐蚀以及列车的挤压等多种原因导致产生缺陷,若钢轨维护不及时将对列车的行驶造成安全隐患,故钢轨表面缺陷的精准检测对铁路运输的安全至关重要。然而,传统的人工视觉钢轨表面缺陷检测方式存在误差大、效率低、检测精度不高等问题,本文运用深度学习理论与方法,研究一种基于 YOLO 的钢轨表面缺陷轻量级检测算法,旨在提高检测精度的同时降低模型计算成本,以满足嵌入式设备的实时检测需求。

首先,本文在对国内外钢轨表面缺陷检测相关研究现状进行分析的基础上,提出一种基于改进 YOLO 的钢轨表面缺陷检测方案。结合网络 Roboflow 上公开的 Anotasi 数据集和 RailDefect 钢轨表面缺陷数据集,通过 Mosaic 数据增强和色彩变换等方法对数据集扩充,形成本文研究的样本数据集。针对目前钢轨表面缺陷不同目标类型差异大的特点,本文在 YOLOv8n 基础上提出了 BAL-YOLOv8 网络模型,引入 BRA 注意力机制和使用 Adown 优化下采样结构以增强对不同尺度缺陷的检测能力,同时利用轻量化共享卷积检测头 LSCDH 提升检测精度并降低参数量。在数据集上进行消融实验与算法性能对比试验,实验结果表明 BAL-YOLOv8 比原模型 YOLOv8n 在 GFLOPs、模型体积和参数量分别降低了 17.28%、15.78%和 16.61%,而 FPS 和平均精度均值 $mAP@0.5$ 指标提高了 18.29%和 2.01%。与 Faster R-CNN、单阶段 SSD 和 YOLO 系列算法相比, BAL-YOLOv8 在检测精度和计算效率等方面均表现出明显的优越性。

其次,为解决深层次网络在嵌入式设备上难以部署的问题,在 BAL-YOLOv8 模型的基础上,本文进一步研究 HBAL-YOLOv8 轻量化网络模型。通过 HGNetV2 轻量化卷积模块优化网络结构,并结合 BN 层稀疏化的通道剪枝方法减少模型参数量与计算复杂度,构建了 HBAL-YOLOv8 轻量化网络模型。实验结果表明 HBAL-YOLOv8 模型,相比于 BAL-YOLOv8 在 GFLOPs、模型参数量和模型体积指标上分别降低了 28.36%、42.63%和 39.62%, $mAP@0.5$ 仅减少了 0.10%;剪枝后的 HBAL-YOLOv8 相比于 BAL-YOLOv8 在模型体积以及参数量分别降低 69.81%和 77.69%, $mAP@0.5$ 为 98.03%,轻量化后的模型仍保持着较高的精度。

最后,将剪枝后的 HBAL-YOLOv8 部署至 RK3588S 嵌入式平台,并进行量化处理以优化运行效率。HBAL-YOLOv8 模型相比基础模型推理速度 FPS 提升至 88 帧/秒,检

测速度提高 57.14%，mAP@0.5 为 91.01%，在轻量化与高精度检测之间实现良好的平衡，可以满足实时检测的应用需求。经过实验验证本文所提出轻量化钢轨表面缺陷检测模型在嵌入式设备上实施的有效性和可行性，为钢轨表面缺陷检测提供了一种高效、低计算成本的解决方案。

关键词：YOLO；钢轨表面缺陷检测；轻量化目标检测；通道剪枝；嵌入式部署

研究类型：应用研究

Abstract

Rail as an important part of the railway transport process, due to year-round exposure, corrosion by the natural environment and the extrusion of the train and other reasons lead to defects, if the rail maintenance is not timely will cause safety hazards on the train, so the accurate detection of rail surface defects is crucial to the safety of railway transport. However, the traditional artificial visual rail surface defects there are large errors, low efficiency, detection accuracy is not high, this paper uses deep learning theory and method to study a YOLO-based rail surface defects lightweight detection algorithm, aims to improve detection accuracy while reducing the model computational cost, in order to meet the real-time detection needs of embedded devices.

Firstly, this paper proposes a surface defect detection scheme based on improved YOLO based on the analysis of the current research status related to rail surface defect detection at home and abroad. Combining the Anotasi dataset and RailDefect rail surface defects dataset publicly available on the network Roboflow, the dataset is expanded by Mosaic data enhancement and colour transformation to form the sample dataset for the study of this paper. In view of the current characteristics of rail surface defects with large differences in different target types, this paper proposes the BAL-YOLOv8 network model on the basis of YOLOv8n, introduces the BRA attention mechanism and optimises the downsampling structure by using ADown to enhance the detection capability of defects of different scales, and at the same time, uses the Lightweight Shared Convolutional Detection Head (LSCDH) to improve the detection accuracy and reduce the number of parameters. Ablation experiments are conducted on the dataset to compare the performance of the algorithm, and the experimental results show that BAL-YOLOv8 reduces the GFLOPs, model volume and number of parameters by 17.28%, 15.78% and 16.61%, respectively, and improves the FPS and the mean average accuracy mAP@0.5 metrics by 18.29% and 2.01% than the original model YOLOv8n. Compared with Faster R-CNN, single-stage SSD and YOLO series algorithms, BAL-YOLOv8 shows obvious superiority in terms of detection accuracy and computational efficiency.

Secondly, in order to solve the problem that deep-level networks are difficult to be deployed on embedded devices, based on the BAL-YOLOv8 model, this paper further investigates the HBAL-YOLOv8 lightweight network model. The HBAL-YOLOv8 lightweight network model is constructed by optimising the network structure through the HGNetV2 lightweight convolution module, and reducing the number of model parameters and computational complexity by combining the channel pruning method with BN layer

sparsification. The experimental results show that the HBAL-YOLOv8 model, compared with BAL-YOLOv8, reduces the GFLOPs, the number of model parameters and the model volume by 28.36%, 42.63% and 39.62%, respectively, and mAP@0.5 reduces by only 0.10%; the pruned HBAL-YOLOv8 reduces the GFLOPs, the number of model parameters and the model volume by 69.5% and the number of model parameters, respectively, compared with BAL-YOLOv8. volume as well as the number of parameters are reduced by 69.81% and 77.69% respectively, mAP@0.5 is 98.03%, and the lightweight model still maintains a high accuracy.

Finally, the pruned HBAL-YOLOv8 is deployed to the RK3588S embedded platform and quantised to optimise the operation efficiency. The inference speed of the HBAL-YOLOv8 model compared to the base model is increased to 88 frames per second in terms of FPS, and the detection speed is improved by 57.14%, mAP@0.5 to 91.01%, achieving a good balance between lightweighting and high-precision detection, which can meet the real-time detection good balance between lightweight and high-precision detection, which can meet the application requirements of real-time detection. After experiments to verify the effectiveness and feasibility of the lightweight rail surface defects detection model proposed in this paper implemented on embedded devices, which provides an efficient and low-cost solution for rail surface defects detection.

Keywords: YOLO; Rail surface defect detection; Lightweight object detection; Channel pruning; Embedded deployment

Thesis: Application Research

目 录

1 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 钢轨检测国内外现状.....	2
1.2.2 基于深度神经网络的目标检测算法.....	4
1.2.3 轻量化目标检测研究现状.....	6
1.3 研究内容与章节安排.....	8
2 钢轨表面缺陷目标检测相关理论	11
2.1 钢轨表面缺陷类型和形成机理	11
2.2 卷积神经网络.....	12
2.2.1 卷积层.....	13
2.2.2 池化层.....	14
2.2.3 激活函数层.....	14
2.2.4 全连接层.....	16
2.3 YOLO 目标检测原理.....	16
2.4 轻量化技术.....	17
2.5 目标检测算法性能指标.....	19
2.6 本章小结.....	19
3 基于多尺度融合的钢轨表面缺陷检测	21
3.1 钢轨表面缺陷检测基础网络	21
3.2 BAL-YOLOv8 改进方法设计	22
3.2.1 BAL-YOLOv8 模型的构建	22
3.2.2 注意力机制改进.....	23
3.2.3 Adown 下采样改进	25
3.2.4 检测头改进设计.....	26
3.3 实验数据与实验环境.....	27
3.3.1 实验数据	27
3.3.2 实验环境.....	29
3.4 实验结果分析.....	30
3.4.1 对比试验.....	30
3.4.2 消融实验.....	35
3.5 本章小结.....	36
4 钢轨表面缺陷检测模型的部署	38
4.1 HBAL-YOLOv8 轻量化设计	38

4.1.1 轻量化网络.....	38
4.1.2 结合通道剪枝的模型压缩.....	41
4.2 轻量化模型边缘部署.....	43
4.2.1 边缘部署框架.....	43
4.2.2 RK3588 芯片	44
4.2.3 模型量化.....	46
4.3 实验结果分析.....	47
4.3.1 轻量化网络实验.....	47
4.3.2 剪枝实验.....	49
4.3.3 模型部署验证.....	51
4.4 本章小结.....	53
5 总结与展望.....	54
5.1 论文总结.....	54
5.2 研究展望.....	55
参考文献.....	56

1 绪论

1.1 研究背景及意义

铁路作为国家重要的交通运输方式，以其快速便捷的特点成为人们出行的主要交通方式，为国民经济的增长注入了活力，其直接涉及到人民的生命财产安全。铁路行业深入贯彻习近平新时代中国特色社会主义思想，积极学习和宣传党的二十大精神，坚定推进中国式现代化，推动铁路高质量发展，为开启全面建设社会主义现代化国家的新局面贡献力量。

随着我国现代化水平的不断提高，铁路作为主要的交通运输载体，得到了国家的大力发展，截至 2023 年全国铁路密度网为 165.2 公里/万平方公里，铁路营业里程为 15.9 万公里。随着客运量以及运行速度地不断增加^[1]，再加上钢轨常年暴露在外，受自然环境和列车挤压的影响，钢轨表面出现缺陷的概率增加。根据中国铁道行业标准 TB/T1778-2010《钢轨损伤分类》^[2]，钢轨是铁路轨道系统的重要组成部分，承受着列车的巨大压力和频繁的载荷变化，任何细微的表面缺陷都可能导致严重的后果，如轨道断裂、脱轨事故等，图 1.1 为列车事故图。据统计，由于钢轨缺陷引发的列车安全事故占有事故的 30%^[3]。例如，在 2020 年 2 月 8 日 22 时 38 分，由沈阳局集团公司 HXN3 型 0293 号机车牵引的 48406 次货物列车在小堡站-本溪站间在李家隧道内脱轨，中断行车 23 小时 32 分，造成铁路交通较大事故，造成直接经济损失 91.66 万元，该事故发生的主要原因由于钢轨接头处夹板发生疲劳断裂导致脱轨。故及时发现并维护钢轨表面缺陷对于保障列车的运行安全至关重要。




图 1.1 列车事故图

Fig.1.1 Train accident diagram

目前,传统的钢轨表面检测主要依赖铁路工作人员的人工巡检和无损检测技术。无损检测技术包括超声波、电涡流和漏磁等^{[4]-[6]}。由于我国铁路运营里程长,轨道地势复杂,人工巡检受主观因素影响较大,容易出现漏检和误检,人工巡检十分繁琐和困难,难以完成全面的铁路轨道安全检查^[7]。超声波检测通过发射和接收超声波来判断内部是否存在缺陷,但对工件的平整性和缺陷种类的区分要求较高,准确度较低。漏磁检测利用磁传感器检测表面漏磁场信息,仅适用于表面缺陷,无法判断损伤的类别和程度。电磁超声法通过电磁耦合激励和接收超声波进行检测,但受到一定限制。激光扫描检测法利用激光发射光束进行二维图像分析,尽管可以完成缺陷检测,但设备昂贵、体积庞大、操作复杂,限制了其广泛应用,这些传统方法主要用于内部结构缺陷检测,但在高精度和高速度场合存在局限性。

随着图像处理器(Graphics Process Unit, GPU)计算能力的提升和大数据技术的发展,机器学习和深度学习在图像处理和模式识别领域取得了显著进展。特别是深度学习中的卷积神经网络(CNN),在图像分类和目标检测中表现出色,为目标检测提供了更多的方法和途径。但现有的目标检测算法对硬件的算力资源要求较高、设备成本大,在实际应用中,钢轨表面缺陷检测系统往往需要在资源受限的环境下运行,如车载系统或边缘设备,而目前算法的检测精度虽显著得到提高,但其模型大小和参数量较大,计算复杂度较高,不适合部署到算力有限的边缘设备中。

随着深度学习的发展,衍生出了许多检测速度快且计算复杂度小的目标检测技术,例如单阶段检测网络YOLO(You Only Look Once)和SSD。近年来,许多学者开始探索深度学习模型轻量化的方法,以降低计算资源需求和功耗,使模型能够部署到资源有限的嵌入式或移动终端设备中,在保证检测精度的前提下,实现实时在线监测,有助于及时发现和处理钢轨表面的缺陷,保障列车的行驶安全。

1.2 国内外研究现状

在钢轨表面缺陷检测的研究中,国内外的的工作主要集中于传统无损检测技术与现代深度学习方法这两个方向。欧美等发达国家早在20世纪初便开始使用无损检测技术来识别钢轨缺陷。然而,受限于当时的计算机硬件和图像处理技术,基于图像处理的钢轨表面缺陷检测方法并未广泛应用。随着近几十年超大规模集成电路的发展,计算能力的提升,基于深度学习的目标检测技术逐渐成为研究热点。

1.2.1 钢轨检测国内外现状

国外铁路系统起步较早,钢轨检测涵盖了表面缺陷、紧固件丢失和轨距检测等多个

方面。许多国家已经投入运营了一系列结合无损检测和视觉识别技术的轨道综合检测列车。

美国 Ensco 公司是轨道检测技术的领军者之一，其研发的综合检测系统结合了传统的超声波和电涡流检测技术，并整合了先进的视觉识别技术。Ensco 公司引入铁路表面成像系统 RSIS (Rail Surface Imaging System)，该系统采用高速相机，在不接触钢轨表面的情况下获取详细图像，通过算法评估滚动接触疲劳 (RCF) 和其他表面损伤，并同步生成检测报告，确保钢轨的安全性。此外，美国纽约的 KLD 实验室设计了一种名为 ORIAN 的光学系统用于对钢轨缺陷进行非接触式检测和判断，检测速度可达 175 公里每小时^[8]。

意大利铁路基础设施公司 (RFI) 的“阿基米德”号综合检测列车，通过改进列车结构和传感器系统，优化了检测数据的采集与分析能力^[9]。法国国家铁路公司 (SNCF) 的“IRIS320”检测列车采用了多源信息融合的测速定位系统，通过统一的分析平台实现了检测数据的集成分析与地面数据交换，并配套开发了基于检测数据的轨道维护管理系统^[10]。东日本旅客铁路公司 (JR East) 在钢轨表面缺陷检测方面，拥有多种综合检测列车。例如多功能轨道检测车 (Track Inspection Vehicle, TIV) 集成了多种检测技术，包括超声波检测、光学检测和几何检测等。采用高精度的传感器，能够在高速行驶时实时检测钢轨的表面和内部缺陷。图 1.2 为国内外轨道检测车情况图。



图 1.2 国内外轨道检测车

Fig.1.2 Rail inspection vehicles at home and abroad

国内铁路系统虽然起步较晚，但随着机器视觉的发展，钢轨缺陷检测技术取得了显著进步。GTC-80 型钢轨探伤车是我国为高速铁路设计的新一代探伤设备，配备了超声波检测系统和轨道巡检系统，能够在 80km/h 的速度下进行高效检测。该车采用多角度超声波入射，通过回波分析钢轨内部缺陷，并通过高清线阵 CCD 扫描系统进行轨道表面状况的巡检，确保钢轨的安全性。0 号高速综合检测列车是由中国铁道科学研究院基础设施检测研究所负责系统集成和综合系统的研制开发，该列车于 2008 年投入使用，

达到 250 km/h 的检测等级。2022 年 4 月 23 日最新上线的 CR450 动车组具备世界领先的检测能力，在郑州至重庆高速铁路巴东至万州段成功实现隧道内单列时速 403 公里、相对交会时速达 806 公里^[11]。尽管探伤车检测方便且功能丰富，但造价昂贵，检测过程易受环境噪声影响。

从便携性和实用性出发，开发一款适合作业人员低速操作的检测小车具有显著优势。与常规速度及高速检测列车相比，这类小车更适合在长距离线路上使用。由于大型检测列车只能在夜间天窗时段运行，且受制于夜间环境和照明条件，其检测准确性往往难以保证。因此，国内研究机构纷纷研制了多种适合人工操作的轨道检测小车以应对这些挑战。1993 年，西南交通大学设计了国内首套轨道检测系统 TWAMS。该系统通过图像处理技术自动分析和处理采集的轨道图像，评估钢轨的磨损情况。但其检测精度依赖于图像质量，不适合在铁路中恶劣的环境，并不是实时进行检测并输出结果^[12]。2014 年湖南大学贾康成^[13]通过设计高速线扫描相机成像系统，提出了图像增强和自动阈值分割的疤痕检测算法及基于 Chan-Vese 模型的裂纹检测方法，在实际测试中，该系统实现了铁轨表面缺陷的准确识别，具有良好效果。2016 年西南交通大学的张俊^[14]等人开发了一套有轨电车磨耗检测系统，通过创新设计的推杆定位装置进行轨道磨损的自动监测，提升了检测效率和精度。

目前钢轨检测仍面临高精度与实时性之间的矛盾等问题，为解决这些挑战，基于深度神经网络的目标检测算法逐渐成为研究热点。相比传统方法，深度学习能够自动提取多层次特征，提升检测精度和鲁棒性。

1.2.2 基于深度神经网络的目标检测算法

目标检测是计算机视觉领域中的重要问题，其核心任务是从图像或视频中定位并分类出特定的目标。许多研究通过手工分析铁轨表面缺陷图像设计手工特征或预定义特征，早期研究中，Wu 等^[15]人提出局部韦伯类对比度(LWLC)算法增强图像，突出缺陷特征，灰度拉伸最大熵(GSME)分割方法实现高效缺陷检测。Cao 等^[16]人利用结构化激光传感器采集图像数据并转换为三维点云模式，通过特征分析，提出了数字化铁轨表面重建方法及改进的动态缺陷检测算法。这些方法的特点是依赖特定特征的人工设计，有较好的泛化能力，但此类算法对噪声敏感，其局限性在于对复杂场景和多样化目标的检测能力有限。

近年来，深度学习的发展得到广泛研究，不同学者从网络结构改进、模型优化和应用拓展等多个方面推动了该领域的进步。2012 年，Krizhevsky 等^[17]人将 AlexNet 模型使用在 ImageNet 图像分类挑战赛中的出色表现使卷积神经网络(CNN)受到广泛关注，

带动了深度学习的研究热潮。Goodfellow 等^[18]人提出生成对抗网络 (GAN)，通过生成器和判别器对抗的方式，实现了图像生成、数据增强等应用，丰富了深度学习的应用场景。2018 年，冉建民^[19]运用卷积神经网络 (Convolutional Neural Network, CNN) 对提取的钢轨表面的缺陷特征进行建模和分类；张博等^[20]人利用机器学习分类器对钢轨表面缺陷进行分类，结合深度学习算法改进了多类缺陷的检测效果。这些基于特征学习的方法弥补了手工特征设计的不足，使检测系统在复杂场景中表现更佳。为解决深层网络训练中常见的梯度消失和收敛问题，Ren 等人 2015 年提出的 ResNet^[21]残差网络结构有效使得深度网络得以进一步扩展并成为目标检测等领域的主流技术。罗维平等^[22]人通过对 ResNet50 网络的残差模块进行改进，使得该模型在疵点织物目标的检测精度和泛化能力得到了提高。继 ResNet 之后，Szegedy 等^[23]人提出了 Inception 网络结构，该网络通过模块化设计提高了计算效率，且更易于深层次扩展，成为目标检测和图像分类领域的另一种常用模型。

根据检测阶段数量的不同，基于深度学习的目标检测算法分为两阶段检测算法 (Two-stage) 和单阶段检测算法 (One-stage)。2014 年 Girshick 等^[24]人提出一种将区域建议与卷积神经网络结合的两阶段对象检测方法 R-CNN。为解决 R-CNN 在效率方面的不足，2015 年，Ren et al 等^[25]人提出了 Faster R-CNN，通过引入区域建议网络 (Region Proposal Network, RPN) 来生成候选区域，RPN 通过共享卷积特征，与检测网络一体化完成候选区域生成和检测，极大地提高了检测效率。2020 年我国上海理工大学的苏烨^[26]等人对钢轨图像进行预处理，利用 Radon 变换等方法将图像进行反转，基于 Faster R-CNN 对钢轨表面缺陷进行检测，其检测准确率虽达 90% 以上，但对于小目标缺陷识别效果不佳，且检测速度较慢。2021 年徐广隆^[27]根据多类多尺度钢轨表面伤损特征，运用 Gabor 滤波等对图像进行去噪，并对数据进行增广，改进 Faster R-CNN 模型的空间注意力机制的特征提取模块和损失函数等，提高了模型的检测精度。后续研究者在 Faster R-CNN 的基础上提出了 Mask R-CNN^[28]、Cascade R-CNN^[29]等改进版本，罗晖等人^[30]也将 Cascade R-CNN 算法运用到了钢轨表面缺陷检测中，相比于其他的算法，Cascade R-CNN 通过多级分类和回归进一步提升检测精度。

单阶段中的代表算法 SSD^[31] (Single Shot multibox Detector)、YOLO^[32] (You Only Look Once) 等相比于两阶段算法都具有更高的检测速度。YOLO 是单阶段检测算法的开创性工作，由 Redmon 等人于 2015 年提出。Redmon 等^[33]人和 Farhadi 等^[33]人又相继推出了 YOLOv2 和 YOLOv3。韦若禹^[35]等人在 2020 年利用 K-means 算法对目标候选框的尺寸进行聚类，再通过对 YOLOv3 的层级结构进行改进后，将其运用到轨道扣件缺陷检测中，创新了 YOLO 的应用领域。SSD 于 2016 年发布，SSD 使用多尺度特征映射并在

每个尺度上进行预测,通过直接在不同特征层上进行目标检测,可以有效检测多尺度目标。Zhang 等人^[36]提出了一种基于卷积神经网络(CNN)的多模型铁轨表面缺陷检测系统(MRSDI-CNN),通过融合 YOLOv3 和 SSD 检测模型提升铁轨表面缺陷识别的准确性和鲁棒性。2022 年陆楠菲^[37]将 YOLOv4^[39]应用到铁轨表面裂纹检测中,检测精度与速度都取得了不错的效果,进一步推进了单阶段目标检测算法在铁路中的应用。李开智等人^[39]和周淼森等人^[40]针对钢轨表面多尺度缺陷目标的特点,在 YOLOv5 算法模型的基础上,从通道和空间两个维度进行改进,使模型更好的捕获通道和位置信息,增强主干网络对细小尺度缺陷的低层特征提取能力。针对钢轨表面缺陷样本数量少和精度不足等问题,吴永军等人^[41]和宫永刚等人^[42]通过对 YOLOv8 模型优化,显著提升了钢轨表面缺陷检测的精度与分割性能,为铁路智能化运维提供技术支持。孙铁强等人^[42]为解决钢轨表面缺陷区域与背景区域特征相似特性导致的模型检测性能下降问题,基于 YOLOv8n 模型设计双模态特征交互修正融合模块,并在多尺度特征构建阶段引入 EVCBlock,提高了模型小缺陷目标的检测能力。直至 2024 年,YOLO 更新迭代到了 YOLOv11,进一步优化了模型结构和训练策略,使得在速度和精度上均得到显著提升^{[44]-[45]}。

基于深度神经网络的目标检测研究主要经历了从手工特征到深度学习特征的演进。深度学习模型在目标检测中表现优异,其单阶段算法不断优化网络结构和特征融合策略,提升了检测速度和实时性,在钢轨裂纹、扣件缺陷等多尺度目标检测中表现出色,为铁路安全监测提供了高效可靠的技术支持。

1.2.3 轻量化目标检测研究现状

近年来,基于深度学习的目标检测技术已成为钢轨表面缺陷检测中的重要手段。针对目前深度学习模型参数量大、计算复杂等问题,研究者们提出了一系列轻量化目标检测模型,以减少深度学习模型的参数量和计算量,同时保持其检测性能。轻量化目标检测模型通常通过优化网络结构、剪枝冗余计算、以及知识蒸馏等方式,降低模型的复杂度,以适应计算资源有限的平台。

高效网络结构是轻量化深度学习模型的核心。早期的轻量化网络通过减少卷积层的参数量来减小模型大小。AlexNet 模型在检测精度上虽有不错的表现,但其共有约 6000 万个参数,存在全连接层参数冗余、存储和计算成本高等问题。后续模型(如 VGG、ResNet)通过引入更深的网络结构和跳跃连接等技术,提高了特征学习能力。Iandola 等^[46]人在 2016 年提出 SqueezeNet, SqueezeNet 使用 fire 模块,通过 1×1 卷积减少通道数和参数量,并利用小卷积核和在网络末端采用全局平均池化代替全连接层,减少了计

算量和参数数量，参数量相比 AlexNet 模型的 1/50。谷歌团队^[47]在 2017 基于深度可分离卷积（Depthwise Separable Convolution）提出了轻量级 MobileNet 模型，通过将传统卷积分解为深度卷积和逐点卷积，有效降低了计算复杂度和参数量，同时保持较高的检测精度。张元等^[48]人将 MobileNet v3 应用到 YOLOv5 的主干网络，结合双注意力机制和 GSSN 模块去检测钢轨扣件缺陷，改进后模型的收敛速度和模型体积等性能均有提升。随后 2018 年出现的 ShuffleNet^[49]网络模型利用组卷积和通道重排序技术，进一步降低参数量并提升效率。武子强^[50]针对 YOLOv4 在钢轨表面伤损检测速度慢的问题，运用 MobileNetv3 和 Shufflenetv2 这两个轻量化网络对 YOLOv4 进行优化改进，提出了 Mobilenet-SA-Yolov4 和 Shufflenet-SA-Yolov4 算法，性能表现良好。许贵阳等^[51]人在 YOLOv7 的主干网络中引入 Ghost 卷积，GhostNet 通过生成冗余特征图进一步减少参数量和计算量，大大减小了模型检测钢轨螺孔伤损的参数量和推理时间。

为进一步对模型进行轻量化，研究者们采用剪枝技术去除冗余参数和计算来减少模型的复杂性，如图 1.3 所示为两种不同剪枝结构的操作情况。

非结构化剪枝是最早提出的剪枝方法，它主要通过评估模型参数的大小或重要性来去除冗余的连接。Li 等^[52]人通过计算 L_p 范数评估重要性，将 L_p 范数较小的滤波器裁剪来减少计算成本。Luo 等^[53]人和 Yu 等^[54]人基于重建误差的剪枝技术，通过选择对下一层影响最小的通道优化模型。Z. Li 等^[55]人基于提出的三阶段通道剪枝算法，通过反复迭代实现模型复杂度与检测精度的平衡，但该方法仅适用于包含批归一化（BN）层的网络，不适用于没有 BN 层的模型。




图 1.3 非结构化剪枝和结构化剪枝

Fig.1.3 Unstructured pruning and structured pruning

随着深度学习硬件的发展，研究者开始关注更加硬件友好的结构化剪枝方法。为了进一步提高剪枝效率，研究者们开始将剪枝与其他优化技术相结合，如知识蒸馏、量化和低秩分解等。2015 年 Hinton 等人^[56]最早提出了知识蒸馏框架，主要思想是通过一个

大的预训练模型指导一个较小的模型进行学习,旨在利用教师模型丰富的知识提升学生模型的性能。杨田甜^[57]通过对轨道检测模型的损失函数增加 L1 正则约束 BN 层,诱导系数稀疏化,再通过通道剪枝减少模型的参数量,实现模型的轻量化,将其部署到 Nvidia Jetson AGXXavier 平台,在保证精度的情况下提高了检测速度。曾泰恒^[58]为解决轨道检测应用深度学习模型在移动设备应用部署限制的问题,对 YOLOv5 模型的 Neck 层进行通道剪枝并去除 Focus 层,再利用 NCNN(Nihui Convolutional Neural Networks)框架对改进后模型进行量化操作,模型体积减少了 51.1%,在算力较低的移动端的检测帧数较基准 YOLOv5s 提升了 268%。通过这些方法与剪枝结合,可以在更小的模型中保持较高的检测精度,得益于这些改进,轻量化模型逐步被部署到嵌入式设备中。

1.3 研究内容与章节安排

针对目前神经网络模型对钢轨表面缺陷的检测中,基于深度学习的钢轨检测模型取得了不错的检测效果,但模型存在大量的冗余参数、计算复杂度较高难以部署到嵌入式设备和移动端等问题。本文鉴于不同网络模型的检测能力,选择更能平衡检测精度和速度的 YOLO 系列算法,通过对比不同算法在检测钢轨表面缺陷的精度和速度性能,选择了 YOLOv8n 作为基础模型。针对钢轨表面缺陷多尺度检测目标研究了多尺度的轻量化模型 BAL-YOLOv8,并利用对比试验以及消融实验对其性能进行验证;为提高 BAL-YOLOv8 模型在钢轨表面检测中的实时检测速度,利用通道剪枝以及优化网络结构等方法,研究了轻量化模型 HBAL-YOLOv8,将其成功部署到嵌入式设备中。

根据本文研究内容,将论文分为五个章节,如图 1.4 所示,具体安排如下:

第一章绪论。本章首先介绍了钢轨表面缺陷检测研究的背景和意义;接着,分析了国内外钢轨检测的现状,以及深度神经网络算法和轻量化目标检测的研究进展。最后,概述了本文的研究内容和论文结构安排。

第二章钢轨表面缺陷目标检测相关原理。首先介绍了钢轨表面缺陷类型和形成机理,分析钢轨缺陷特征在检测过程中可能遇到的难点。然后阐述卷积神经网络的基本组成结构,为本文设计的轻量级钢轨表面缺陷检测模型奠定理论基础。随后介绍 YOLO 目标检测网络基础原理和深度学习中常用的网络结构轻量化、模型压缩技术,为后续模型的轻量化准备理论支撑。其次详细介绍了本文实验中用到的目标检测算法性能评价指标。最后对本章进行总结。

第三章基于多尺度融合的轻量化钢轨表面缺陷检测。首先详细介绍了本文所选基础模型 YOLOv8 主干网络(Backbone)、颈部网络(Neck)和头部网络(Head)的详细结

构。接着介绍了实验所用的数据集情况和实验环境。本文以 YOLOv8n 为基础模型，运用注意力机制 BRA（Bi-Level Routing Attention）、Adown 改进下采样结构和 LSCDH 替换原模型的检测头，提出了多尺度融合的轻量化 BAL-YOLOv8 模型；利用第二章提出的算法性能评价指标评价 BAL-YOLOv8 模型，对算法进行消融实验以及与其他经典算进行对比试验验证模型的有效性和先进性。




图 1.4 论文整体结构

Fig.1.4 The overall structure of the paper

第四章面向边缘设备部署的超轻量化钢轨表面缺陷检测算法。为解决当前检测算法难以部署到边缘设备的问题，本章主要针对第三章 BAL-YOLOv8 模型展开研究。采用轻量级网络结构 HGNetv2 对 BAL-YOLOv8 的主干网络进行优化；然后再利用通道剪枝的方法对冗余通道进行剪枝，提高模型的实时监测速度。然后通过对比实验验证本文

超轻量化 HBAL-YOLOv8 模型方法的有效性，最后将 HBAL-YOLOv8 部署到 RK3588 嵌入式设备中。

第五章总结与展望。对本文的工作进行总结，分析本文研究的不足并提出建议与展望。

2 钢轨表面缺陷目标检测相关理论

钢轨作为铁路运输的重要基础设施，其表面缺陷直接影响运行安全和使用寿命。因此，钢轨表面缺陷的检测具有重要的工程价值。随着深度学习和计算机视觉技术的发展，基于图像处理的缺陷检测方法逐渐成为研究热点，目标检测技术在缺陷识别中发挥了关键作用。自 20 世纪 80 年代提出卷积神经网络（Convolutional Neural Network, CNN）以来，CNN 因其在图像处理、语音识别和自然语言处理等领域的卓越表现，成为深度学习的重要组成部分。以 YOLO 和 Faster R-CNN 为代表的深度学习算法凭借高精度和实时性优势，已广泛应用于工业检测领域。其中，YOLO 框架因其端到端检测和较高的速度，尤其适合钢轨表面缺陷的实时检测需求，基于 YOLO 的轻量化检测算法研究具有重要的应用价值和发展前景。本章主要介绍目标检测相关理论、YOLO 算法原理、轻量化技术基本原理以及目标检测算法性能评价指标。

2.1 钢轨表面缺陷类型和形成机理

钢轨表面缺陷通常也称为钢轨损伤，依据钢轨损伤程度，将表面缺陷类型分为剥离裂纹、断裂、剥离掉块以及擦伤等，如图 2.1 所示。



图 2.1 钢轨表面缺陷图

Fig.2.1 Picture of rail surface defects

剥离裂纹通常由滚动接触疲劳（RCF）引起，列车车轮与钢轨长时间接触产生交变应力，使钢轨表层材料出现微观疲劳裂纹，裂纹呈网状或平行分布，深度较浅（通常 0.5~2 mm），裂纹扩展至一定程度后，表层材料发生剥落。受复杂环境光照影响，在传统目标检测过程中很难提取到有效特征信息。

钢轨断裂主要由疲劳裂纹扩展或冲击载荷作用下材料脆性破坏引起。当钢轨内部存在缺陷（如冶金缺陷、微裂纹等），列车重复作用会使裂纹扩展，最终导致断裂。此外，低温环境下材料韧性下降，也可能促使断裂发生。断裂通常发生在应力集中区域（如焊

接接头、螺栓孔附近等),与周围结构形态相似,可能导致模型误检或漏检,在改进模型时需增强对裂纹区域的关注。断裂面可能呈现贝壳状或纤维状,断口光滑表明脆性断裂,而粗糙断口表明韧性断裂。此时,需尽快检测到钢轨断裂情况进行及时修复,保障列车运行安全。

剥离掉块是剥离裂纹进一步发展的结果,裂纹沿钢轨表层扩展,导致局部材料脱落,形成凹坑。此过程通常由重复荷载、摩擦磨损及环境腐蚀共同作用引起。剥离掉块表现为不规则形状的表面缺失,可能导致钢轨表面凹坑,影响列车平稳运行,并进一步加速钢轨损伤。

钢轨擦伤主要由列车车轮打滑、异物摩擦、制动作用等因素导致,长期作用会使钢轨表面金属层被磨损。擦伤通常表现为钢轨表面纵向或横向的划痕,浅层损伤影响有限,但严重磨损可能导致钢轨截面减小、局部硬化或塑性变形。

2.2 卷积神经网络

卷积神经网络(Convolutional Neural Networks, CNN)的概念最早由 Hubel 和 Wiesel 在 20 世纪 60 年代研究猫的视觉系统时启发提出^[59]。他们发现动物视觉皮层具有分层的特征提取机制,对特定的视觉特征(如边缘和线条)具有高度敏感性。随后, Fukushima^[60]在 1980 年提出了第一个神经感知机模型——“神经认知机”(Neocognitron),为卷积神经网络奠定了理论基础。在 1998 年, Yann LeCun^[61]提出的 LeNet-5 是首个应用于手写数字识别的成功 CNN 模型,展示了卷积、池化和全连接层的结构框架。这一模型为现代 CNN 的设计提供了蓝图。2012 年, Krizhevsky 等人提出的 AlexNet 利用 ReLU 激活函数、Dropout 正则化和 GPU 加速,在 ImageNet 竞赛中大获成功。这一突破标志着深度学习时代的到来,卷积神经网络被广泛应用于各类任务。




图 2.2 卷积神经网络结构图

Fig.2.2 Convolutional neural network structure diagram

卷积神经网络通过引入局部连接(Local Connectivity)、权重共享(Weight Sharing)和多层特征抽象,能够高效提取数据的空间特征。如图 2.2 所示为卷积神经网络结构图。其基本组件与作用为:卷积层提取输入数据的局部特征,池化层负责实现特征降维,激

活函数引入非线性，全连接层负责将处理好的特征信息连接到激活函数中完成高维特征到目标空间的映射。

2.2.1 卷积层

卷积神经网络专为处理具有二维结构数据（如图像）的人工神经网络，卷积层（Convolutional Layer）是卷积神经网络（CNN）中的核心组件之一，负责从输入数据中通过局部感受野（Receptive Field）提取图像的局部特征，从而将原始图像转换为具有更高层次特征的代表。卷积层的工作原理基于卷积运算，卷积运算如图 2.3 所示。




图 2.3 卷积运算过程

Fig.2.3 Convolutional operation process

在卷积操作中，卷积核（Convolutional Kernel）以滑动窗口的方式沿输入特征图移动，并与覆盖区域进行加权求和，生成输出特征图（Feature Map）。每个卷积核由一组权重参数和偏置组成，它们通过前向传播和反向传播优化，能够提取特定的图像特征。卷积操作的计算公式可以表示为：

$$Y_{i,j} = \sigma \left(\sum_{m=1}^w \sum_{n=1}^h X_{i+m,j+n} \cdot K_{m,n} + b \right) \quad \text{式 (2.1)}$$

式 (2.1) 中， $X_{i+m,j+n}$ 为输入特征图对应区域的像素值； $Y_{i,j}$ 为卷积操作后输出特征图在位置 (i,j) 的值； $K_{m,n}$ 为卷积核的权重， w 、 h 和 b 分别为卷积核的宽、高和偏置； $\sigma(\cdot)$ 为非线性激活函数。卷积核在每个局部区域上执行相同的操作逐步提取局部特征，卷积层的输出特征图的尺寸还受到卷积核数量、填充（Padding, P ）、步长（Stride, S ）等参数的影响，输出特征图的尺寸（即宽和高）可通过以下公式计算：

$$N_{out} = \frac{W - F + 2P}{S} + 1 \quad \text{式 (2.2)}$$

式 (2.2) 中， N_{out} 表示输出特征图的宽或高； W 为输入特征图的宽或高； F 为卷积

核尺寸, P 为填充, 可以保证卷积操作后输出特征图的尺寸和输入图像的尺寸有一个良好的比例, 特别是在使用较大的卷积核时; S 为步长, 步长决定了卷积操作过程中卷积核在图像上的移动速度。

2.2.2 池化层

池化层是卷积神经网络中的一种下采样操作。池化过程一般在卷积过程之后, 用于特征降维, 通过聚合统计池化窗口内的元素来减少数据空间大小, 可降低模型的复杂度并增强模型的泛化能力, 同时保留重要的数据特征信息。图池化层中最常见的操作方式有最大池化(Max Pooling)和平均池化(Average Pooling)等, 池化操作过程如图 2.4 所示。最大池化基本思想是在输入特征图的某个区域内选择像素值最大的元素作为该区域的代表值, 通常采用尺寸为 2×2 的滤波器, 并以 2 步长对每个深度切片进行下采样, 从而舍弃其中约 75% 的激活信息。平均池化通过计算窗口内所有像素值的平均值, 得到一个区域的代表值。通过这种方式, 平均池化可以提取区域中最显著的特征, 增强特征的表达能力。与最大池化不同, 平均池化保留了更多整体的特征信息, 反映区域的平均特性。




图 2.4 平均池化和最大池化操作过程

Fig.2.4 Process of Average Pooling and Max Pooling Operations.

2.2.3 激活函数层

激活函数是卷积神经网络 (CNN) 中不可或缺的组件, 其核心作用是引入非线性能力, 使得神经网络能够拟合和学习复杂的非线性映射关系。卷积和全连接层本质上是线性操作, 若无激活函数, 网络将退化为线性变换, 无法解决非线性问题。激活函数通过对输入进行非线性变换, 使网络能够更好地捕捉数据中的复杂特征, 提高模型表达能力。不同激活函数的特点不同, 根据任务需求选择最适合的方式, 提高模型的准确性与效率。

常见的激活函数有 ReLU、Sigmoid、Tanh、Leaky ReLU 等，这几种激活函数的图像如图 2.5 所示，函数表达式分别如下所示：

$$ReLU(x) = \max(0, x) \quad \text{式 (2.3)}$$

$$Sigmoid(x) = \frac{1}{1 + e^{-x}} \quad \text{式 (2.4)}$$

$$Tanh = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad \text{式 (2.5)}$$

$$Leaky ReLU(x) = \begin{cases} x, & x > 0 \\ \alpha x, & x \leq 0 \end{cases} \quad \text{式 (2.6)}$$




图 2.5 常见激活函数图像

Fig.2.5 Image of common activation functions

ReLU 是卷积神经网络中最常用的激活函数之一，属于分段函数，如图 2.5 的 a 所示。ReLU 能够有效地引入非线性，并且通过对负值的屏蔽作用（置零），能够稀疏化网络的激活值，减少计算量。Sigmoid 函数如图 2.5 的 b 所示，适用于需要将输出压缩到

一个概率区间的场景（如二分类任务），但容易在极值区间（输入绝对值很大时）出现梯度消失问题。结合式(2.5)和图 2.5 的 c 可知, Tanh 函数输出范围在 $(-1, 1)$, 相比 Sigmoid , 其输出对称性（关于原点对称）更适用于以零为中心的数据分布, 从而更有利于梯度下降优化, 但输入值绝对值较大时, 同样容易导致梯度更新缓慢。 Leaky ReLU 解决了标准 ReLU 可能导致神经元“死区”（即梯度为零, 神经元永不更新）的问题。式 (2.6) 中的 α 是一个较小的正数（如 0.01）, 由图 2.5 的 d 图看出, 当输入为负值时, 它会给出一个小的非零输出, 而不是完全置零, 适用于梯度消失风险较高的深度网络。这使得负值区间也保留了一定的梯度, 从而缓解了训练过程中可能出现的神经元“失活”问题, 同时保留了 ReLU 的计算效率和稀疏性优势。

2.2.4 全连接层

全连接层 (Fully Connected Layer, FC) 是卷积神经网络 (CNN) 中的关键组成部分, 全连接层核心作用在于将前一层提取的局部特征进行全局整合, 学习特征之间的依赖关系, 并通过线性变换与非线性映射将特征转换为网络最终的输出结果。图 2.6 为全连接层结构示意图。与卷积层不同, 全连接层将输入的每一个特征与输出的每一个节点都进行全连接, 参数量较大, 表达能力更强, 但也增加了计算复杂度与过拟合风险。因此, 在实际应用中, 全连接层常与正则化技术（如 Dropout ）结合使用, 以提高模型的泛化能力。




图 2.6 全连接层神经元连接示意图

Fig.2.6 Schematic Diagram of Neuron Connections in the Fully Connected Layer

2.3 YOLO 目标检测原理

YOLO 算法的核心思想是将目标检测问题转换为回归问题, 通过单次网络前向传播同时预测图像中的目标类别和位置, 由 Redmon 等人于 2015 年提出。相比于传统的目

标检测方法，YOLO 摒弃了区域建议和候选框生成的复杂过程，实现了检测和分类的端到端统一，大幅提升了检测速度，同时保持了较高的检测精度。图 2.7 为 YOLO 系列目标检测算法的核心框架。YOLO 将输入图像划分为固定网格，每个网格负责检测其范围内的目标，并直接回归出目标的边界框坐标、置信度以及类别概率。输入图像经过卷积神经网络后生成特征图，该特征图被划分为 $m \times n$ 的单元格，每个单元格输出一个维度为 $5 \times B + N$ 的特征向量。其中， B 表示每个单元格预测的边界框数量， N 表示类别数，输出包含每个边界框的中心坐标 (x, y) 、宽高 (w, h) 、置信度 (C) 以及目标的类别概率分布。通过这种方式，YOLO 算法将目标检测任务转化为单次前向传播的回归问题，实现了从定位到分类的端到端检测，大幅提升了检测效率。




图 2.7 YOLO 系列目标检测算法的核心框架

Fig.2.7 The core framework of the YOLO series object detection algorithms

2.4 轻量化技术

随着深度学习技术的快速发展，神经网络的规模和复杂度显著增加，这在提升模型性能的同时也带来了巨大的计算和存储开销。因此，为了适应资源受限环境（如移动设备和嵌入式平台）的需求，研究人员提出了一系列轻量化网络结构设计方法，以降低模型复杂度并提高推理效率，本节将介绍几种比较常见的轻量化方法。

深度可分离卷积是轻量化网络设计中的核心思想之一，可将模型压缩。它将标准卷积分解为深度卷积（Depthwise Convolution）和逐点卷积（Pointwise Convolution）两部分。深度卷积针对每个输入通道独立应用卷积操作，用于捕获空间信息，而逐点卷积使用 1×1 卷积核实现通道间的信息融合。MobileNet^[62]系列模型采用深度可分离结构，有效提升了模型的计算效率和部署适应性，这种显著的计算复杂度降低使其特别适合移动设备和嵌入式系统等计算资源有限的应用场景；ShuffleNet^[63]系列在分组卷积基础上引

入深度可分离卷积，进一步压缩模型；GhostNet^[64]提出“廉价操作”（Cheap Operations）生成冗余特征，减少标准卷积的计算量。




图 2.8 深度可分离卷积过程

Fig.2.8 Process of depthwise separable convolution

如图 2.8 所示为深度可分离卷积过程，设输入和输出特征图为 $X \in R^{(H \times W \times N)}$ 和 $Y \in R^{(H \times W \times M)}$ ，其中 H 和 W 分别表示为特征图的尺寸大小宽和高， M 和 N 表示特征图通道数量。在深度卷积这一阶段，每个卷积核仅作用于输入特征图的一个通道，而不会跨通道操作。因此，对于输入通道数量为 C_{in} 的特征图，深度卷积将为每个通道分配一个 $k \times k$ 的卷积核。紧接深度卷积之后，逐点卷积使用 1×1 的卷积核，对深度卷积产生的输出特征图进行跨通道的线性组合，从而融合各通道的信息，完成特征的重组和信息整合。逐点卷积保证了最终输出具有充分的通道交互能力，同时对通道维度进行调整，产生相同数量的输出通道 C_{out} 。通过上述描述，计算深度可分离卷积最后总参数量为 $Y = H \cdot W (C_{in} \cdot K \cdot K + C_{in} \cdot C_{out})$ 。而标准卷积仅通过一个卷积核同时对输入特征图的所有通道（channels）进行空间和通道方向的特征提取，参数量为 $Y' = H \cdot W \cdot C_{in} \cdot K \cdot K$ 。与标准卷积相比，深度可分离卷积的计算复杂度减少 $1/C_{out} + 1/k^2$ ，它通过减少参数量和计算复杂度，同时保持与标准卷积相似的性能表现。

模型剪枝是一种广泛应用于深度学习中的模型压缩技术，其核心思想是通过系统性分析神经元间的权重参数贡献度，对冗余计算单元进行选择性地修剪，从而显著降低模型的存储需求和运算负载，最终达成计算效率与表征能力的最优平衡，为资源受限的环境部署高效模型提供解决方案。按照剪枝粒度的不同，模型剪枝可分为非结构化剪枝和结构化剪枝两大类。非结构化剪枝主要针对网络中的权重参数，通过设置权重阈值或正则化约束来删除较小的权重值。尽管这种方法剪枝效果显著，但会导致稀疏矩阵形式的模

型表示，从而增加硬件实现的复杂性。Anwar 等人在文献[65]中引入了结构化剪枝的概念，旨在克服非结构化剪枝所面临的挑战，该方法通过定义重要性指标，并借助贪心算法来执行剪枝操作。He 等^[66]人提出的柔性剪枝方法通过允许被剪掉的滤波器在训练中继续更新，提升了深度神经网络的推理效率，为网络提供了更大的容量和优化空间，降低了对预训练模型的依赖，从而实现从头开始训练模型的可能性。相比之下，结构化剪枝以通道、过滤器或层为单位对网络进行剪枝，保持了模型结构的规则性，更适合硬件加速和工程部署。

2.5 目标检测算法性能指标

目标检测算法的性能通常通过评价指标进行评价，以便全面衡量算法在检测任务中的效果和效率。为更好地验证改进目标检测模型的性能以及实验的有效性，本文选用了以下几种评价指标。

平均精度均值（Mean Average Precision, mAP），所有类别的平均精度（AP）的均值，是衡量目标检测算法精度的主要指标。它通过计算不同类别目标的平均精度，再取均值以综合反映算法对目标位置和类别的识别能力。

召回率（Recall, R）和精确率（Precision, P）分别衡量算法的检测能力和准确性。召回率反映了检测出的正样本数量与实际正样本总数的比值，而精确率则表示检测出的正样本中真正为正样本的比例。这两项指标通常通过精确率-召回率曲线（Precision-Recall Curve, P-R）共同分析，以全面评估算法在检测任务中的性能。

检测速度是另一个重要指标，通常以每秒帧数（Frames Per Second, FPS）表示，用于评估算法的实时性和计算效率。较高的 FPS 意味着算法能够在更短的时间内处理更多的图像，适合实时检测任务。

最后，模型参数量、计算复杂度 GFLOPs 和模型体积也是重要的性能衡量标准，尤其是在轻量化模型的研究中。参数量通常以百万参数（Million Parameters, M）计，反映模型的复杂度。GFLOPs（Giga Floating Point Operations）是衡量深度学习模型计算复杂度的核心指标之一，表示模型完成一次前向推理（即处理一张输入图像）所需的十亿次浮点运算次数，它直接反映模型的计算效率和硬件资源消耗。

2.6 本章小结

本章首先然后对钢轨表面缺陷类型和形成的机理进行说明，分析钢轨表面缺陷目标在检测过程中可能遇到的难点；然后介绍卷积神经网络相关的理论知识；其次，对 YOLO

算法的检测原理进行了分析，并详细介绍了本文运用的 YOLO 目标检测算法的基础原理；接着，对常见几种轻量化技术方法进行了阐述；最后介绍目标检测算法性能评价指标。

3 基于多尺度融合的钢轨表面缺陷检测

钢轨作为铁路轨道的核心部件，其表面缺陷如裂纹、剥落、擦伤等的精准检测对保障列车运行安全至关重要。由于钢轨表面缺陷通常呈现多尺度、形态不规则等特点，且受复杂环境噪声干扰，现有基于深度学习的检测方法在小目标识别精度与计算效率之间的平衡仍面临严峻挑战。YOLOv8 作为 YOLO 系列代表算法之一，虽在实时性与检测性能上具有显著优势，但 YOLOv8n 在处理钢轨表面微小缺陷时仍存在特征提取不足、多尺度融合能力有限等问题，导致漏检与误检率较高。针对上述问题，本章提出一种基于多尺度特征融合的目标检测算法 BAL-YOLOv8，提升钢轨表面缺陷检测的精度与效率。

3.1 钢轨表面缺陷检测基础网络

Ultralytics 于 2023 年推出 YOLOv8 目标检测模型，该模型在保持 YOLO 系列快速、准确检测特性的基础上进一步优化了网络架构，并支持端到端部署和轻量化设计，已广泛应用于工业检测、缺陷识别等领域。YOLOv8 提供了多种网络规模版本，以适应不同应用需求，并在特征提取和特征融合方面进行了显著改进，从而提升了检测性能。根据各个模型的特点，并考虑到模型的参数数量和规模对算法实时性的显著影响，该研究选择了 YOLOv8n 作为基础模型。YOLOv8 的网络结构主要由主干网络（Backbone）、颈部网络（Neck）和头部网络（Head）三部分组成，图 3.1 为 YOLOv8 的网络结构图。

主干网络负责从输入图像中提取特征，是网络的基础部分。YOLOv8 在主干网络上进行了优化，采用了更轻量化的设计，同时具备高效的特征提取能力。采用改进的 CSPNet 结构，通过跨阶段部分（CSP）模块对输入特征进行分解与聚合，有效降低冗余计算，同时增强特征表达能力。与 YOLOv5 不同，YOLOv8 移除了 Focus 模块，直接采用标准卷积层对输入图像进行下采样和特征提取，同时将 C3 替换为 C2f 模块。并减少了 3×3 卷积核的使用，改为 1×1 卷积核，增加了特征融合的灵活性，使得低层特征与高层特征更加有效地交互。此外，引入的空间金字塔池化（SPPF）模块通过多尺度池化操作扩大感受野，进一步提升了模型在复杂背景下的检测能力。

颈部网络结合了特征金字塔网络（FPN）和路径聚合网络（PANet）的设计优势。FPN（Feature Pyramid Network）自上而下传递强语义特征，主要解决多尺度目标检测问题，提高网络鲁棒性。而 PANet 采用自下而上的路径结构，进一步聚合浅层特征，从而提升目标定位精度。这种双向特征融合机制增强了网络对尺度变化和位置变化的适应性。

解耦头网络包括三个不同尺度的检测层，负责输出目标边界框和类别信息。在损失

函数方面，回归分支使用了 Distribution Focal Loss 和 CIOU 损失函数，CIOU 相较于 GIOU 更适合解决预测框重叠不足的问题，从而提升边界框回归精度，分类使用 BCE Loss。此外，YOLOv8 还采用动态分配正负样本的方法，提高模型训练的稳定性和适应性。




图 3.1 YOLOv8 的网络结构

Fig.3.1 The network structure of YOLOv8

3.2 BAL-YOLOv8 改进方法设计

3.2.1 BAL-YOLOv8 模型的构建

YOLOv8n 虽对钢轨表面缺陷的检测精度以及速度表现良好，但在模型的计算复杂度以及精度等指标上仍有改进的空间。由于 YOLOv8n 采用较小的网络结构和较浅的特征提取层，虽然计算效率较高，但对小尺寸缺陷（如裂纹和轻微剥落）难以捕获足够的细节特征，容易导致漏检或误检。其次，钢轨表面缺陷通常表现为边缘不规则或纹理异常，而 YOLOv8n 依赖标准卷积和池化操作提取特征，这种方式容易忽略微小的边缘变化和复杂纹理细节，影响缺陷的定位精度和分类准确性。钢轨表面缺陷还存在尺度变化较大的情况，从微小裂纹到较大剥落均可能出现，而 YOLOv8n 在多尺度特征融合方面较弱，其 FPN（特征金字塔网络）结构无法充分捕获不同尺度特征信息，导致在尺度变

化较大的缺陷检测任务中表现欠佳。

针对上述问题,本文设计了 BAL-YOLOv8 模型,如图 3.2 所示。通过引入双层路由注意力 Bi-Level Routing Attention (BRA) 结构于 Backbone 的末端,来增强网络对钢轨裂纹缺陷特征的全局提取能力,提高模型对擦伤区域的细粒度感知能力;其次,采用整合特征结合多路径特征提取和高效下采样策略的 Adown 优化原网络的下采样结构,充分捕捉钢轨表面的细节特征信息;随后,结合轻量化共享卷积的思想改进检测头为 LSCDH,融合高低层特征信息,确保模型多尺度检测能力同时轻量化改进模型。




图 3.2 BAL-YOLOv8 模型结构

Fig.3.2 Structure of the BAL-YOLOv8 model

3.2.2 注意力机制改进

钢轨表面缺陷通常尺寸较小,且形态复杂,比如钢轨表面的裂纹可能仅占据图像的一小部分,容易与正常纹理混淆,但对钢轨的安全性影响巨大。因此,检测模型需要具备极高的分辨率和特征捕捉能力。本研究采用 Bi-Level Routing Attention (简称 BRA)^[67]是一种用于视觉转换器 (Vision Transformer) 的高效注意力机制,旨在通过分层路由策略捕获长距离依赖关系,优化计算资源分配,提高对钢轨图像内容的感知能力。BRA 注意力机制能够动态地调整模型对输入数据中不同部分的关注度,从而增强关键特征,抑制非关键特征。其结合粗粒度的区域级路由注意力与细粒度的 token to token 注意力,

在图像的区域划分中捕捉局部重要特征，而细粒度的标记级注意力能够深入挖掘区域内部的细节特征，能很好地适配钢轨表面缺陷检测的特点，从微小裂纹到大面积剥落都能得到精准表达。




图 3.3 Bi-Level Routing Attention 结构

Fig.3.3 Structure of Bi-Level Routing Attention

BRA 的模型结构如图 3.3 所示，首先，输入图像 $X \in R^{H \times W \times H}$ 被划分为 $S \times S$ 的非重叠区域，每个区域包含的特征向量被重构映射为 $X_r \in R^{S^2 \times \frac{HW}{S^2} \times C}$ 。其中， H 和 W 分别表示输入图像的高度和宽度； S^2 表示分块后区域的数量； C 表示通道维度。在每个区域内，通过平均池化（Average Pooling）计算区域级特征，得到每个区域的平均特征表示。对每个区域的特征向量使用线性变换生成查询（Query, Q）、键（Key, K）和值（Value, V）向量。线性映射的权重矩阵如下式：

$$Q_r = X_r W_q, K_r = X_r W_k, V_r = X_r W_v \quad \text{式 (3.1)}$$

式 (3.1) 中， W_q 、 W_k 、 W_v 为线性映射的权重矩阵， Q_r 、 K_r 、 V_r 分别表示区域级的查询、键和值。

然后，在区域级别，计算区域之间的相关性矩阵（邻接矩阵）：

$$A_r = Q_r (K_q)^T \quad \text{式 (3.2)}$$

其中， $A_r \in R^{S^2 \times S^2}$ 表示所有区域之间的相关性得分。为了降低计算复杂度，仅保留每个区域与其他区域的前 k 个高相关性连接（Top-k 连接）。通过路由索引矩阵 I_r 保存这些连接：

$$I_r = \text{TopK}(A_r, k) \quad \text{式 (3.3)}$$

其中， $I_r \in N^{S^2 \times k}$ 表示每个区域的前 k 个高相关性索引， $\text{TopK}(\cdot)$ 为行向运算符。

之后，通过索引矩阵 I_r ，对键（K）和值（V）进行路由聚合：

$$K_g = \text{Gather}(K, I_r), V_g = \text{Gather}(V, I_r) \quad \text{式 (3.4)}$$

其中， K_g 、 V_g 表示通过路由索引聚合后的键和值； Gather 操作通过索引矩阵 I_r 从键和值中提取对应的高相关性信息。

在粗粒度区域路由的基础上，进一步对每个区域内的特征计算细粒度的标记（Token）级注意力。这一过程通过 键值对的收集和分散（Key-Value Collection and Dispersion）实现，先对聚合后的键和值执行标记到标记（Token-to-Token）级别的注意力计算，捕获区域内部的细节信息，从而提高模型的识别能力；最终生成增强的特征表示。

3.2.3 Adown 下采样改进

YOLOv8 的下采样操作主要采用步幅卷积（stride convolution）和最大池化（max pooling），虽然这些方法具有计算简单、执行高效的优点，但下采样过程按照固定步幅和核大小进行操作，缺乏自适应性，难以灵活处理具有不同尺度或形状的目标；步幅卷积和最大池化会导致特征图尺寸减小，从而丢失部分空间信息和细节特征，特别是在处理小目标或边缘信息时表现不佳。在本文的钢轨表面缺陷检测中，缺陷图像形状大小不一，背景与检测目标相近，YOLOv8 的标准下采样方式虽然计算高效，但在信息保留、空间信息表达和全局感受野方面存在缺陷，尤其在小目标检测和复杂背景处理方面表现有限。因此，进一步改进 YOLOv8 下采样模块为 Adown^[68]提升模型的检测性能和适应性。Adown 是 YOLOv9 中的创新下采样模块，是一种结合多路径特征提取和高效下采样策略的网络结构，能在下采样过程中最大限度地保留特征信息，同时降低计算复杂度，提高模型对小目标和边缘细节的捕获能力。Adown 的网络结构如图 3.4 所示。

输入特征图在 Adown 中首先经过平均池化，其作用是对局部区域像素进行平均计算，从而保留平滑和背景信息，有助于捕获整体结构和低频特征。接下来，经过池化操作的特征图在通道维度上进行分割（Split）。输入特征图的通道数为 C，在分割后，每个路径分别保留输入特征图通道数的一半，即 C/2。这种通道划分方式可以减少计算复杂度，并保证每条路径专注于提取不同类型的特征信息，为后续的特征增强操作提供基础。

随后，分割后的特征分别经过卷积层 CBS 和最大池化。CBS 模块是卷积（Conv）、批归一化（BatchNorm）和 SiLU 激活函数的组合。通过卷积操作对输入特征进行线性变换，以提取局部特征和空间相关性；利用批归一化对特征进行标准化处理，减少内部协变量偏移问题，提高训练稳定性；最后，通过 SiLU 激活函数引入非线性变换，增强模型的非线性表达能力，并抑制梯度消失问题，从而提高模型的特征表示能力和收敛速度。

最大池化从局部区域中提取最大值，从而强化边缘和纹理等高频信息，有利于捕获物体的边缘细节和关键特征。




图 3.4 Adown 网络结构图

Fig.3.4 Adown network structure diagram

经过 CBS 模块处理后的两个路径的特征图在通道维度上通过拼接操作（Concat）重新合并。合并后的特征通道数恢复到输入特征图的通道数 C ，这一操作不仅将两条路径的特征信息进行融合，还通过多尺度特征互补提高了输出特征的丰富性和表达能力。

经过上述步骤处理后，输出特征图（Output）既保留了输入特征的整体语义信息和边缘细节，又通过分组处理和并行路径操作降低了计算复杂度，提升了模型对多尺度目标的检测能力，同时适应于复杂场景和小目标检测任务。Adown 模块通过平均池化和最大池化相结合的双路径策略，在下采样过程中兼顾了全局平滑特征和局部边缘特征的提取，同时结合卷积增强模块与特征拼接操作，进一步强化了特征表达能力与计算效率，为目标检测等任务提供了性能优越的下采样解决方案。

3.2.4 检测头改进设计

YOLOv8n 原网络用 3 个检测头分别检测不同尺寸的目标，但随着模型的加深，在处理微小目标时表现较差。针对该问题，本研究采用轻量化共享卷积思想的检测头 LSCDH（Lightweight Share Convolutional Detection Head）改进 YOLOv8n 的检测头，增

强网络处理钢轨表面缺陷多尺度检测目标的精度与速度。

检测头 LSCDH 整体结构如图 3.5 所示,首先,将 1×1 卷积核替代传统 3×3 卷积核,对输入特征进行压缩,减少计算复杂度。同时使用 GroupNorm (组归一化)^[69]对不同分支输出的特征信息进行融合和归一化,消除不同尺度特征之间的分布差异,增强特征的一致性和鲁棒性,能够更好地适应钢轨表面缺陷的尺度变化需求。随后,采用两个共享卷积 (Conv_GN) 模块对多尺度特征图进行处理,对处理后的特征图引入激活函数,增强网络的非线性表达能力,提升模型对复杂缺陷的识别能力。最后,将特征图按照尺寸的大小分为 3 个分支,每个分支分别执行回归和分类任务。回归输出通过 Scale 层将特征图维度还原到输入大小,融合高低层特征,确保多尺度检测能力。分类输出根据目标位置和类别进行分类预测,进一步优化检测精度。




图 3.5 检测头 LSCDH 整体结构

Fig.3.5 Overall structure of detection Head LSCDH

3.3 实验数据与实验环境

3.3.1 实验数据

为验证本文所提方法在钢轨表面缺陷的有效性和泛化能力,本文制作了两种钢轨表面缺陷数据集用以实验训练和结果验证。首先,采集了网络 Roboflow 上公开的 Anotasi 钢轨表面缺陷数据集, Anotasi 数据集提供了钢轨缺陷类型的多样性,弥补国内数据不足;同时对比实验揭示国内实际应用场景中存在的模型适配性问题,本文改进算法在该数据集上进行训练,并与目前先进的目标检测算法进行比较。为了进一步验证所提模型在实际工程环境中的适用性和鲁棒性,引入国家铁道科学研究院测试中心建设的 9 km 铁路试验环道采集的 RailDefect 数据集^[70]。该数据集包含更贴近我国铁路运行工况的真实图像,用以评估模型在实测场景中的泛化能力与实际检测效果。

针对上述描述有缺陷目标的图像,运用开源标注工具 LabelImg 进行标注,标注格

式为 txt。根据中国铁道行业标准 TB/T1778-2010《钢轨损伤分类》的分类标准，将网络 Roboflow 上公开的 Anotasi 钢轨表面缺陷数据缺陷类型标注为钢轨表面剥离裂纹(328)、断裂(284)、剥离掉块(650)和擦伤(771)四种缺陷类型，共 2030 张图像，数据集部分图像如 3.6 所示。



图 3.6 Roboflow 的 Anotasi 部分数据集样本

Fig.3.6 Partial Aotasi dataset of Roboflow

RailDefect 数据集标注为损伤(198)、污渍 152 以及裂纹(50)三类，其中损伤包括除裂纹外，影响钢轨使用性能的弯曲变形、压陷(或凹陷)、压溃等伤损。其中，RailDefect 数据集图像有 10000 张，本文筛选了 400 张钢轨表面缺陷图像，数据集部分图像如 3.7 所示。




图 3.7 RailDefect 部分数据集样本

Fig.3.7 RailDefect dataset

由于钢轨表面图像中存在大量复杂纹理信息、背景噪声干扰以及不同缺陷类型之间的细微差异，为提升模型对微小缺陷的敏感性、增强其泛化能力及鲁棒性，并缓解过拟

合风险, 本文引入 YOLOv8 中的 Mosaic 数据增强策略。该策略将多张图像随机拼接为一张新图像, 提升样本多样性, 显著增强模型对目标尺度变化的适应能力。此外, 还采用了图像旋转、缩放、裁剪、亮度和色彩变换等多种数据增强方式。经过增强处理后, Anotasi 数据集扩展至 6090 张图像, RailDefect 数据集扩展至 3200 张图像。本文均以 8:1:1 的比例随机划分数据集为训练集、测试集和验证集。



图 3.8 标注钢轨缺陷

Fig.3.8 Marking rail defects

3.3.2 实验环境

本实验在 64 位 Windows 10 操作系统平台上进行, 配备 NVIDIA GeForce RTX 3060Ti 显卡, 采用 Python 3.11.5 版本, 并在深度学习框架 Pytorch 2.1.0 环境下开展各项实验。通过使用 CUDNN 12.1 和 CUDA 12.1 对 GPU 进行加速, 以提高网络训练效率。训练参数设置如表 3.1 所示。

表 3.1 训练参数设置

Table 3.1 Training parameter settings

参数	设置	参数	设置
optimizer	SGD	weight_decay	0.0005
epochs	200	close_mosaic	10
workers	8	batch	16
lr	0.01	momentum	0.9
imgsz	640		

在进行实验训练前, 先对实验的超参数进行设计。首先, 确定基础模型后, 将划分

好的数据集用模型进行训练，不断调整实验参数，测试模型的性能，保留满足实验要求的网络参数。训练结果如图 3.9 所示。其中，优化器采用 SGD（随机梯度下降），其简单且稳健，适合深度学习模型训练，并配合动量参数提升训练效果；学习率设置为 0.01，其能够较快地找到损失函数下降方向，同时避免步长过大导致震荡或过小导致收敛缓慢；权重衰减设置为 0.0005，通过 L2 正则化约束防止过拟合，增强模型的泛化能力；精度设置在 200 轮，此时曲线基本稳定保持在最优值附近，让模型得到充分训练。




图 3.9 训练结果图

Fig.3.9 Training results

3.4 实验结果分析

3.4.1 对比试验

(1) 注意力机制对比实验

针对钢轨表面缺陷多尺度、形状大一差异大的问题，本文在 YOLOv8n 的主干网络末端引入双层路由注意力 BRA（BiLevelRouting Attention），增强网络对钢轨缺陷特征的全局提取能力。为验证 BRA 注意力机制在钢轨表面缺陷检测中的优势，本节在相同数据集（Roboflow 公开网络数据集 Anotasi）、同一实验环境下，在 YOLOv8n 相同位置添加了目前主流的 5 中注意力机制，即 DAttention^[71]（Deformable Attention Transformer）、混合局部通道注意力 MLCA^[72]（Mixed Local Channel Attention）、通过结合通道注意力和空间注意力 CBAM^[73]（Convolutional Block Attention Module）、三个分支结构的 Triplet Attention^[74]以及无参注意力 SimAM^[75]。实验结果使用不同的钢轨表面缺陷类型的 GFLOP、P、R、mAP@0.5 作为评价指标，验证 BRA 注意力在不同尺度钢轨缺陷特征

提取能力的优势。实验结果如表 3.2 所示。

表 3.2 不同注意力机制对比试验

Table 3.2 Comparative experiments of different attention mechanisms

算法	GFLOPs/G	P/%	R/%	mAP@0.5/%
YOLOv8n (基准线)	8.1	92.59	97.81	96.56
YOLOv8n+ DAttention	8.3	92.66	94.09	96.25
YOLOv8n+MPCA	8.1	90.28	98.24	94.70
YOLOv8n+CBAM	8.1	96.10	95.70	98.10
YOLOv8n+TripletAttention	8.1	94.82	96.23	98.12
YOLOv8n+SimAM	8.1	94.50	97.01	98.12
YOLOv8n+ BiLevelRouting (BRA)	8.2	94.40	97.53	98.20

从上表的实验结果可以看出,在 YOLOv8n 网络的 Backbone 末端引入注意力后,除了 DAttention 和 MPCA 外,其他模型的 mAP@0.5 均有提升;P 指标除加入 MPCA 注意力外,也均有一定程度的提高,在一定程度上加强了模型对钢轨特征信息的提取能力,且模型的计算复杂度并未有显著增加。在这六种主流的注意力中,DAttention 的召回率和平均精度性能指标表现最差;加入 CBAM 后的精确度提高了 3.51 个百分点,该指标在同类注意力中提升效果最佳,但其召回率相比于原模型性能指标下降明显;TripletAttention 和 SimAM 注意力各项性能指标表现相近;BiLevel Routing Attention(BRA)的计算复杂度虽比原模型多 0.1G,但在平均精度和精确度指标上分别提升了 1.64 个百分点和 1.81 个百分点。综合上述实验分析,相比之下本文所用的双层路由注意力 BRA 综合性能表现最优。

表 3.3 不同注意力机制 AP 对比试验

Table 3.3 Comparative experiments of different attention mechanisms in AP

模型	AP/%				mAP@0.5/%
	裂纹	断裂	剥离掉快	擦伤	
YOLOv8n (基准线)	99.50	92.11	96.51	98.13	96.56
YOLOv8n+ DAttention	99.50	93.80	95.49	96.19	96.25
YOLOv8n+MPCA	99.41	84.50	96.75	98.12	94.70
YOLOv8n+CBAM	99.40	98.86	97.70	96.34	98.10
YOLOv8n+TripletAttention	99.41	97.26	97.45	98.36	98.12
YOLOv8n+SimAM	99.50	98.27	97.03	97.69	98.12
YOLOv8n+BRA	99.15	98.94	97.51	98.20	98.20

为更近一步验证双层路由注意力 BRA 在钢轨表面各类缺陷的检测能力,选取 AP 值和 mAP@0.5 作为评价指标。表 3.3 为四类钢轨表面缺陷在不同注意力下的 AP 值和 mAP@0.5 检测结果。由检测数据可看出,加入注意力 BRA 后,除了在裂纹缺陷降低了 0.35 个百分点,在断裂、剥离掉块以及擦伤缺陷类型中,AP 值均有提升,特别是针对断裂缺陷的特征提取能力上升最明显,共提升了 6.83 个百分点。在对缺陷深度不明显的擦伤类型检测中,除了本文选用的 BRA 双层路由注意力和三个分支结构的 TripletAttention 注意力外,加入其他 4 个注意力的平均精度均有一定程度的下降。相对其他的注意力, BRA 对钢轨各类缺陷全局特征信息的捕捉能力最优。

(2) 不同算法对比实验

为验证本文算法 BAL-YOLOv8n 相比其他经典算法的有效性,本节在增强后的 Roboflow 网络数据集和相同实验环境下,以 YOLOv8n 模型作为基准网络模型,使用 GFLOPs、模型体积、模型参数量、FPS、R、mAP@0.5 为评价指标,选取经典两阶段模型 Faster R-CNN、具有代表性的单阶段 SSD 和 YOLO 系列算法与本研究 BAL-YOLOv8n 算法进行对比试验。实验结果如表 3.4 所示。

表 3.4 不同算法对比实验

Table 3.4 Comparative experiments of different algorithms

算法	GFLOPs /G	模型体积 /MB	参数量 /M	FPS /(frame · s ⁻¹)	R/%	mAP@0.5 /%
Faster R-CNN	134.4	134.4	41.76	23.62	97.16	95.41
SSD	62.6	100.5	26.29	56.34	92.52	89.21
YOLOv5n	7.1	5.3	2.50	86.91	95.10	96.55
YOLOv6n	11.8	8.7	4.23	83.87	95.20	96.60
YOLOv8n	8.1	6.3	3.01	80.91	97.81	96.56
YOLOv9	7.6	4.7	1.97	87.32	96.40	95.72
YOLOv10n	6.5	5.8	2.27	84.85	94.70	95.70
BAL-YOLOv8	6.7	5.3	2.51	95.71	97.90	98.50

由上表中的实验数据得出,相比于单阶段网络,双阶段算法的计算复杂度更高、模型体积更大和参数量更多。Faster R-CNN 模型的 GFLOPs 和参数量指标比单阶段表现最差的 SSD 还高出 71.8G 和 15.47M。单阶段算法中,SSD 虽在计算复杂度和模型体积以及参数量方面都比双阶段表现更好,但在 mAP@0.5 指标上表现比 Faster R-CNN 低 6.2 个百分点;相比之下,YOLO 系列算法在平衡钢轨表面缺陷检测精度以及速度上,比 SSD 算法更具有优势。在 YOLO 系列算法中,YOLOv5n、YOLOv9n 和 YOLOv10n 的 GFLOPs、

模型体积和参数量虽比 YOLOv8n 小，但在召回率 R 和平均精度均值 $mAP@0.5$ 中 YOLOv8n 表现最佳；而 YOLOv6n 虽在 $mAP@0.5$ 值中比 YOLOv8n 高，但其计算复杂度和参数量等方面均不及 YOLOv8n。综上所述，YOLOv8n 模型综合各项指标最佳，故本文选用 YOLOv8n 模型作为基础模型。改进型后的 BAL-YOLOv8 模型在轻量化以及精度上都有了一定程度的提升，相比于原模型 YOLOv8n，GFLOPs、模型体积和参数量分别降低了 17.28%、15.78% 和 16.61%，召回率 R、FPS 和平均精度均值 $mAP@0.5$ 指标提高了 0.09%、18.29% 和 2.01%。




图 3.10 BAL-YOLOv8 和 YOLOv8 模型检测曲线

Fig.3.10 Detection curves of BAL-YOLOv8 and YOLOv8 models

图 3.10 为基础模型 YOLOv8n 和本节改进 BAL-YOLOv8 模型的 $mAP@0.5$ 、P (precision) 精确度、召回率 R (recall) 和损失函数 loss 的训练曲线对比图。如 a 图所示，BAL-YOLOv8 在大部分轮数中比 YOLOv8n 的精度更高。b 图 $mAP@0.5$ 的曲线图显示，BAL-YOLOv8 在训练过程中均保持了较高的 $mAP@0.5$ 值，表现出了更快、更稳定的收敛速度。c 图显示的是两种模型的召回率曲线，由图可看出 BAL-YOLOv8 的召回率曲线跟 YOLOv8n 相差较小，结合表 3.4，可看出 BAL-YOLOv8 总体召回率比 YOLOv8n

更高。由 d 图 loss 曲线可看出 YOLOv8n 和 BAL-YOLOv8 模型的损失值基本一致，均有较低的损失值。总体而言，BAL-YOLOv8 在目标检测任务中表现出较好的准确性和稳定性。

(3) RailDefect 数据集上不同算法对比实验

为验证 BAL-YOLOv8 算法在钢轨表面缺陷检测的泛化能力，本节在 RailDefect 钢轨数据集中将改进的 BAL-YOLOv8 与不同经典算法进行对比试验。实验结果如表 3.5 所示。

表 3.5 RailDefect 数据集不同算法对比实验

算法	模型体积/MB	FPS/(frame · s ⁻¹)	R/%	mAP@0.5/%
Faster R-CNN	134.4	18.23	72.81	74.32
SSD	100.5	46.71	50.76	69.54
YOLOv5	5.3	91.23	67.10	76.21
YOLOv6	8.7	85.29	75.15	81.14
YOLOv8n (基准)	6.3	90.59	75.10	81.30
YOLOv9	4.7	93.22	77.10	80.07
YOLOv10	5.8	87.32	55.20	71.76
BAL-YOLOv8	5.3	99.91	83.30	85.60

由表 3.5 中 BAL-YOLOv8 与不同算法进行对比实验结果可知，双阶段的 Faster R-CNN 的召回率 R 和平均精确度均值 mAP@0.5 指标在对钢轨表面缺陷检测中均比 YOLOv8n 低，模型体积在不同经典算法中最大。与 YOLO 同类型的单阶段 SSD 算法模型体积依然庞大，召回率 R 和平均精确度均值 mAP@0.5 指标在这几类经典算法中表现最差。YOLO 系列算法中，YOLOv10 的模型体积较小，但 R 和 mAP@0.5 表现最差；YOLOv9 的模型体积最小，召回率比比本文所选基础模型 YOLOv8n 高 2 个百分点，mAP@0.5 比 YOLOv8n 低 1.13 个百分点；YOLOv8 模型在 mAP@0.5 指标中表现最优，模型体积和召回率指标表现一般；YOLOv5 的模型体积比 YOLOv8n 小，但召回率和 mAP@0.5 指标分别比 YOLOv8n 低 8 个百分点和 5.09 个百分点；YOLOv6 的模型体积在这几个 YOLO 系列算法中最大，召回率比 YOLOv8n 高 0.05 个百分点，mAP@0.5 则比 YOLOv8n 低了 0.16 个百分点。综上分析，YOLOv8n 在不同经典算法检测钢轨表面缺陷中综合表现最优。改进的 BAL-YOLOv8 算法在召回率、mAP@0.5 指标比基础模型 YOLOv8n 分别提高了 8.2 和 4.3 个百分点，模型体积比原模型降低了 1M。故 BAL-YOLOv8 算法在实验检测钢轨表面缺陷目标中表现出较好的性能，具有较好的鲁棒性与

泛化能力。

3.4.2 消融实验

为验证本文 BAL-YOLOv8 算法各项改进模块具体提升效果的有效性,本节以 YOLOv8n 作为基准模型,依次引入双层路由注意力 BRA、优化下采样为 Adown 和替换检测头为 LSCDH,在相同数据集以及同一实验环境下进行 8 组消融实验,以 P、R、GFLOPs 和 mAP@0.5 作为评价指标,实验结果如表 3.6 所示,其中“√”表示使用相应的模块。

表 3.6 消融实验结果
Table 3.6 Dissolution experiment results

实验 序号	BRA	Adown	LSCDH	GFLOPs/G	P/%	R/%	mAP@0.5/%
1				8.1	92.59	97.81	96.56
2	√			8.3	94.40	97.53	98.20
3		√		7.4	91.10	97.10	97.80
4			√	6.5	94.31	98.62	98.47
5	√	√		8.1	96.00	97.41	98.20
6	√		√	6.7	96.20	98.40	98.50
7		√	√	6.1	94.33	97.51	97.99
8	√	√	√	6.7	96.80	97.90	98.52

由表 3.6 的消融实验结果可得:(1)为解决 YOLOv8n 模型在钢轨表面多尺度缺陷目标检测的精度,引入双层路由注意力 BRA,在 GFLOPs 增加 0.2G 和 R 降低 0.28 个百分点的情况下,精确度 P 和 mAP@0.5 分别提升了 1.81 和 1.64 的百分点,这意味着 BRA 在一定程度上增强了模型对钢轨图像内容的感知能力,通过细粒度的标记级注意力深入挖掘区域内部的细节特征,很好地适配了钢轨表面缺陷检测的特点;(2)为进一步充分捕捉钢轨表面的细节特征信息,利用 Adown 优化原网络的下采样结构,相比于原模型,模型的计算复杂度减少了 8.64%,P 和 R 指标分别降低 1.61%和 0.73%,mAP@0.5 增加了 1.27%;(3)针对模型参数量大以及检测目标多尺度的问题,本文利用轻量化共享卷积思想设计 LSCDH 检测头,GFLOPs 减少 19.8%,P、R 和 mAP@0.5 分别提升 1.86%、0.83%和 1.98%;(4)在增加了 BRA 的基础上,依次利用 Adown 改进下采样和 LSCDH 优化检测头:引入 Adown 改进下采样结构后,P 和 mAP@0.5 指标分别提高 3.67%和 1.70%,R 降低 0.41%;最后将检测头替换为 LSCDH 后,P、R 和 mAP@0.5 相比于原模

型均有提高，分别提升了 4.55%、0.09%和 2.03%，同时 GFLOPs 减少 17.28%，在减少模型计算复杂度的情况下又提升了检测精度。由上述实验结果分析可知，每个模块的改进均对模型检测钢轨表面缺陷的能力产生了有利的影响，本节的改进算法 BAL-YOLOv8 检测钢轨表面缺陷的有效性得到了验证。

图 3.11 为在 Roboflow 网络公开数据集上进行的 YOLOv8n 和 BAL-YOLOv8 可视化对比结果。由图可知 BAL-YOLOv8 在检测铁轨表面缺陷时表现出优于 YOLOv8n 的检测性能。在第一列检测的断裂缺陷中，YOLOv8n 的检测精度为 0.69，而 BAL-YOLOv8 为 0.70，相比于 YOLOv8n，BAL-YOLOv8 对缺陷区域的检测准确率更高，尤其是在断裂、剥落等复杂背景下。BAL-YOLOv8 在分类时的稳定性更强，错误分类的概率更低。在第三列和第四列的多种类型缺陷（剥落、裂纹等）混杂的情况下，BAL-YOLOv8 仍能较好地地区分不同类型的缺陷，检测精度均优于 YOLOv8n。由上述实验结果分析可知，本节的 BAL-YOLOv8 通过改进的网络架构和优化的训练策略，在钢轨表面缺陷检测任务上取得了优于 YOLOv8n 的性能，验证了 BAL-YOLOv8 的优越性。




图 3.11 YOLOv8n 和 BAL-YOLOv8 可视化对比结果

Fig.3.11 Comparison of YOLOv8n and BAL-YOLOv8 visualizations

3.5 本章小结

本章主要针对多尺度的钢轨表面缺陷特征，增加模型对细小特征信息的提取能力以及轻量化模型，并通过实验验证本节提出的 BAL-YOLOv8 模型的有效性。本节先对实验所用的两种数据集和基础模型 YOLOv8 进行了介绍，随后详细对改进的 BRA 注意力、Adown 下采样和 LSCDH 检测头各个模块进行分析；最后，从召回率 R、类平均精度 mAP@0.5、检测速度 FPS、计算复杂度（GFLOPs）、模型参数量（Params）及模型体积

等性能评价指标，对注意力机制与其他经典算法进行测试，验证 BAL-YOLOv8 模型性能的优越性。实验结果表明，BAL-YOLOv8 在保持轻量化特性的同时，显著提升了多尺度缺陷检测性能：相较于基础模型 YOLOv8n，其 GFLOPs、模型体积及参数量分别降低 17.28%、15.78%与 16.61%，而 mAP@0.5 与 FPS 分别提升 2.01%与 18.29%。

4 钢轨表面缺陷检测模型的部署

因为钢轨表面缺陷目标的形状、外观都各不相同，现有目标检测算法针对多尺度目标检测能力不足；随着深度学习的发展，在目标检测领域的应用原来越广泛，但模型的深度和复杂度也不断增加，而近几年深度学习部署到算力资源有限的移动端越来越多。为解决这些问题，学者们提出了轻量级模型框架，具体研究情况已在第一章第二小节介绍。本文在第三章中在 YOLOv8n 模型的基础上进行改进，提出了 BAL-YOLOv8 多尺度特征融合的轻量化钢轨表面缺陷检测算法。改进后的 BAL-YOLOv8 模型在检测平均精度、模型体积等指标上均比原模型表现良好，但网络的参数和检测速度上还有改进空间，在本章利用轻量级框架进一步对改进 BAL-YOLOv8 模型进行轻量化，提出了 HBAL-YOLOv8 模型，随后更进一步以利用通道剪枝的模型压缩技术对模型超轻量化。轻量级框架采用模型压缩采用 HGNetv2 网络结构，模型剪枝中通道剪枝的方式，通道剪枝具体流程如图 4.1 所示，包括稀疏化训练、剪枝操作、模型微调和迭代剪枝等阶段。在 RailDefect 数据集上验证该模型的有效性，最后将基础模型 YOLOv8n、BAL-YOLOv8 和剪枝后的 HBAL-YOLOv8 模型分别部署到嵌入式设备，进一步验证提出剪枝模型 BAL-YOLOv8 的有效性。




图 4.1 模型剪枝流程

Fig.4.1 Model pruning process

4.1 HBAL-YOLOv8 轻量化设计

4.1.1 轻量化网络

由于缺陷检测在实际应用中需部署到移动端，而移动设备上的算力资源有限，对模型的参数量和计算复杂度等要求较高。而 YOLOv8 中的主干网络部分主要由普通卷积 Conv 和 C2f 模块构成，虽然采用了参数共享以提高模型的检测效率，但随着网络层数的加深，网络的参数量和计算复杂度也变得庞大，影响了模型对检测目标的推理速度。

分组卷积通过将通道划分为多个组，每组通道只与一部分卷积核进行操作，而不是对所有通道和卷积核进行全连接操作，以降低计算开销。然而，这种策略可能导致组之

间的信息流动受限。针对该问题, ShuffleNet 引入了通道混洗机制(channel shuffle), 通过随机重组不同组的通道, 实现信息交互和特征共享, 进一步提高了网络表达能力和精度。ShuffleNetV2 进一步优化了通道划分和特征融合策略, 如图 4.2 所示为 ShuffleNetV2 卷积块结构。由图可知, ShuffleNetV2 加入了 channel split 操作, 将输入通道分为两个分支, 左边分支做恒等映射, 右边分支连续经过 3 个卷积, 最后通过 concat 连接进行 channel shuffle 后输出, 在保持高精度的同时提升计算效率。




图 4.2 ShuffleNetV2 卷积块

Fig.4.2 ShuffleNetV2 convolutional block

GhostNet 幻影卷积 (Ghost Convolution) 模块, 通过少量标准卷积生成基础特征图, 再通过线性变换产生冗余特征图, 以模拟复杂卷积核的效果, GhostNet 设计核心如图 4.3 所示。这种设计显著减少了参数数量和计算量, 同时保留了网络的表达能力。GhostNetV2 在此基础上引入了解耦全连接注意力机制 (DFC), 以降低空间依赖关系建模的复杂度, 并进一步提高网络性能。

鉴于钢轨缺陷通常具有多样化的尺寸和形状 (如裂纹、剥落、锈蚀等), 且小缺陷容易与背景噪声混淆, 本文采用 HGNetv2^[76], 轻量化网络结构, 对第三章提出的 BAL-YOLOv8 模型的主干网络进行进一步优化, 以用于钢轨表面缺陷的实际检测。

HGNetV2 是百度为实时检测器 RT-DETR 提出的轻量化主干网络, 其设计目标是提高计算效率、减少模型大小, 并通过优化特征提取和多尺度处理能力增强模型的检测性能。相比于传统轻量级网络可能因过度压缩层级或简化结构 (如单一路径设计), 导致

小目标细节丢失或上下文信息不足，其通过改进的特征金字塔结构（如跨阶段多层级融合），能够更精细地捕捉不同尺度的缺陷特征。HGNetV2 核心结构包括 HGStem、HGBlock 和可学习的下采样层（LDS），通过层次化的特征提取方式适应多尺度目标检测，同时减小计算量。相比于第一版 HGNet，HGNetV2 取消了 ESE 模块，引入了 LightConv 和 DWConv 模块以增强模型的特征提取效果；针对 GPU 设备，对网络进行分析和归纳后选择尽可能多的运用 3x3 标准卷积，使其计算密度达到最高。HGNetV2 分为数据预处理部分和 4 个 HG_Stage 阶段，HGNetV2 网络结构如图 4.4。




图 4.3 GhostNet 设计核心

Fig.4.3 Core design of GhostNet

HGNetV2 网络的先由 channel 为 96 的 Stem 模块对输入图像进行初步处理。首先，通过一次 3×3 的卷积提取初始特征，然后将特征图分为两路：一路通过最大池化操作减小空间尺寸，另一路通过 2×2 的卷积降低通道数，随后对该分支进行填充并再次执行 2×2 的卷积恢复通道数并减半特征图尺寸。最后，两路特征图拼接在一起，并通过两次卷积操作进一步减少通道数和空间尺寸，最终输出的特征图尺寸是输入图像的 $1/4$ ，有效降低了后续特征提取阶段的计算负载。

随后 HGNetV2 的特征提取共经历 4 个 HG_Stage。即经过 HGStem 处理后的特征图输入到 HG_Stage 层的堆叠结构中进行逐步处理。HGBlock 是 HGNetV2 的核心模块，用于分层提取特征以综合局部细节和全局语义信息。每个 HGBlock 包含深度可分离卷积（DWConv）和特征融合操作，其中 DWConv 减少了参数量和计算复杂度，而特征融合通过多分支结构提升了特征表达能力。HGBlock 的层次化设计使得网络能够逐步从低级特征中提取细节信息，同时在高层获得抽象语义表达，特别适合多尺度目标的检测任务。

在 HGBlock 之间，HGNetV2 使用可学习的下采样层（LDS）进行空间降维。LDS 的核心功能是通过减少特征图的空间分辨率来降低计算复杂度，同时保留关键信息并增强感受野。这一过程通过可学习的参数优化下采样操作，以最小化信息丢失。通过 LDS

层的处理，特征图的空间尺寸逐渐减小，但语义信息更加聚焦，有助于后续 HGBlock 提取高级语义特征。




图 4.4 HGNetV2 网络结构

Fig.4.4 HGNetV2 network structure

网络的最后一部分是全局平均池化（GAP）层和分类头。GAP 层通过对每个特征图计算全局平均值，将空间维度压缩为单个向量。这一操作不仅减少了计算复杂度，还增强了网络对空间变换的鲁棒性。最终，分类头使用卷积层和全连接层将特征映射到目标类别空间，其中卷积层用于组合特征，全连接层完成分类任务。相比传统的主干网络，其轻量化设计大幅减小了模型大小，适用于资源受限的边缘设备，同时多尺度特征提取能力使其能够在复杂场景中实现高精度目标检测。

4.1.2 结合通道剪枝的模型压缩

结构化剪枝通过移除整个卷积核、通道或滤波器，而不是单独剪掉权重矩阵中的孤立元素。这种方式保留了模型的结构完整性，使其生成的稀疏模型能够直接兼容现有的硬件加速器，无需额外的优化或特殊稀疏矩阵存储格式。剪枝后的模型仍然保持了原始网络的框架结构，仅减少了卷积核或通道数量。这种结构化的特点使得剪枝模型能够无缝地集成到常见的深度学习框架中，便于实际应用中的部署和使用。

本研究在改进后的 HBAL-YOLOv8 模型，采用模型剪枝中的 BN 层稀疏化通道剪枝的方式进行模型压缩，如图 4.5 所示，通道剪枝过程包括稀疏化训练、剪枝操作等阶段。首先，训练一个完整的基础模型以确保其具备较好的性能，选取批归一化层（Batch Normalization，简称 BN）根据特定标准评估网络中的参数或结构重要性。BN 层本质上是一种归一化的处理方式，可在深度神经网络训练中替代局部响应归一化层（Local Response Normalization，简称 LRN），从而加速权重参数的收敛。BN 层用于缓解深层神经网络中由于层数增加而导致的梯度消失或梯度爆炸问题，同时加快网络的收敛速度并提高泛化能力。其核心原理是对每一层网络的输入特征进行归一化处理，使得特征在一

个小批量数据内具有零均值和单位方差，并通过可学习的缩放和平移参数恢复模型的表达能力。




图 4.5 通道剪枝过程

Fig.4.5 Channel pruning process

在稀疏化训练阶段，为了便于剪枝操作，采用 L1 正则化对权重、通道输出进行稀疏化约束，使部分单元的重要性逐渐降低。接着，在剪枝操作中，根据重要性评估结果直接删除低贡献度的过滤器、通道，并调整相应的输入输出结构。最后，通过精度微调恢复模型性能，并在必要时迭代剪枝和微调操作以进一步优化压缩效果。通过设置不同大小的稀疏化比例因子 γ ，统计权重接近零的通道数量，从而分析在不同稀疏化比例下冗余通道数量对准确率 $mAP@0.5$ 的影响。

在 BN 层中，计算流程可以分为四步，首先是对样本均值 μ_β 的计算，其次是对样本方差 σ_β 的计算，接着是对数据进行归一化处理，最后，引入了 γ 和 β 两个可学习参数，通过这两个参数，对归一化后的特征进行线性变换，可以进行进一步的变换和重构，帮助网络学习恢复原始的特征分布，如公式(4.1)~(4.4)：

$$\mu_B = \frac{1}{m} \sum_{i=1}^m x_i \quad \text{式 (4.1)}$$

$$\sigma_B^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2 \quad \text{式 (4.2)}$$

$$\hat{x} = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}} \quad \text{式 (4.3)}$$

$$y_i = \gamma \hat{x} + \beta \quad \text{式 (4.4)}$$

式(4.1)~(4.4)中，式中 x_i 为样本， m 为样本总数。 β 为当前的 minibatch； σ_β 是输入激活量的标准差； μ_β 是输入激活量的均值； ε 是归一化系数。

因此，每个卷积通道的激活值 y_i 与参数 γ 呈正相关关系。如果 γ 的值过小接近于零，对应的激活值 y_i 也会变得非常小。筛除那些 γ 接近于零的卷积通道是一种可行的策略。

本小节在对 HBAL-YOLOv8 模型进行稀疏训练的过程中，对参数 γ 施加正则化约束，从而使用 BN 层中引入的可学习参数 γ 作为衡量通道重要性的尺度因子，计算该尺度因子 γ 添加 L1 正则化带来的损失，公式如下(4.5)：

$$L = \sum_{(x,y)} l(f(x,W), y) + \lambda \sum_{\lambda \in \Gamma} g(\gamma) \quad \text{式 (4.5)}$$

式(4.5)中第一项为 HBAL-YOLOv8 模型进行稀疏化正常的网络损失函数， (x, y) 为训练的输入和目标， $f(x, W)$ 表示模型的前向计算过程，即通过输入 x 和参数 W 计算预测结果；第二项为尺度因子 γ 的正则化，第二项中的 λ 是稀疏化因子，稀疏因子 λ 的选择和调整策略对参数 γ 的稀疏效果及模型训练后的精度具有显著影响， $g(\gamma)$ 为正则化项。常见的调整策略是采用恒定稀疏因子，在整个稀疏训练过程中对参数 γ 施加固定大小的梯度，能够实现较高的稀疏度。

4.2 轻量化模型边缘部署

4.2.1 边缘部署框架

神经网络处理器(NPU)是一种专门针对深度学习和机器学习任务优化的计算单元，旨在高效处理复杂的神经网络模型。相较于传统的中央处理器(CPU)和图形处理器(GPU)，NPU在神经网络运算中展现出显著的优势，不仅计算效率更高，而且能耗更低。这一优势主要源于其在硬件层面对卷积运算、矩阵乘法以及激活函数等核心操作的深度优化。然而，由于RK3588S的NPU无法直接运行由不同深度学习框架生成的模型，因此需要将这些模型转换为NPU兼容的RKNN格式。

在前面章节中，本文已收集并整理钢轨表面缺陷图像数据，进行数据增强和预处理，确保数据集包含多种典型缺陷类型，并划分为训练集、验证集和测试集。接着，选择适合钢轨表面缺陷检测的目标检测算法，使用PyTorch等框架对模型进行训练，优化超参数以提高检测精度，提出了HBAL-YOLOv8模型，基于BN层稀疏化对模型进行通道剪枝训练。训练完成后，将PyTorch模型导出为ONNX格式，并通过瑞芯微的RKNN-Toolkit将ONNX模型转换为RK3588 NPU适配的RKNN格式，模型转换流程如图4.6所示。RKNN是瑞芯微专为其NPU(神经网络处理单元)设计的模型格式，能够充分发挥RK3588平台的硬件加速能力，从而实现高效的推理任务。然后，将转换后的RKNN模型文件部署到RK3588S板卡，利用RK3588板卡的NPU加速能力和MPP框架完成

目标检测推理，借助 RGA 引擎对输入图像进行预处理，包括缩放、格式转换等，以适配模型输入要求。在推理过程中，优化输入图像的分辨率和批量大小，提高推理效率，记录并分析模型的检测精度、速度和硬件资源使用情况。通过实际场景测试，验证框架的鲁棒性，确保能够高效检测不同纹理和缺陷类型的钢轨表面缺陷，进一步优化模型以提升检测精度和召回率。




图 4.6 模型转换流程

Fig.4.6 Model conversion process

4.2.2 RK3588 芯片

RK3588 是一款高性能、多功能的国产 AI 芯片，专为嵌入式智能应用设计。其集成了丰富的硬件单元和强大的计算能力，适用于人工智能、图像处理、多媒体应用等多个领域。RK3588 的芯片架构如图 4.7 所示，其内置多核 CPU、GPU 和第三代神经网络处理单元（NPU），提供了强大的算力支持。其中，NPU 支持 INT4、INT8、INT16 和 FP16 的混合运算，在 INT8 模式下算力可达 6TOPS，且功耗显著低于传统 GPU，具有优异的高能效比。

在图像处理方面，RK3588 配备了先进的图像信号处理器（ISP），支持高达 4800 万像素的图像处理，并具备 HDR、3A（自动对焦、自动曝光、自动白平衡）、去雾、鱼眼校正等功能。此外，RK3588 还提供了硬件加速的 JPEG 编解码能力，能够高效处理图

像数据。其专用的图形加速引擎（RGA）支持图像缩放、旋转、拷贝、格式转换和合成等多种操作，结合瑞芯微的多媒体处理平台（MPP），实现了对 H.264、H.265、VP9 和 AV1 等主流视频编解码标准的支持，能够满足 8K@60fps 的高分辨率视频处理需求。




图 4.7 RK3588 的芯片架构

Fig.4.7 Chip architecture of the RK3588

RK3588 还提供了丰富的外围接口，包括 PCIE 3.0、USB 3.0、HDMI、以太网以及多种调试接口，支持模块化扩展，适配蓝牙、WiFi 等外设，方便开发者构建复杂的嵌入式系统，如图 4.8 所示。其强大的性能、卓越的图像处理能力以及多样化的接口设计，使其成为嵌入式 AI 平台开发和目标检测、图像分类等智能任务的理想选择。




图 4.8 RK3588S 开发板资源


Fig. 4.8 Resources of RK3588S development board

4.2.3 模型量化

根据国际电工电子工程师学会（IEEE 754）的标准，32 位单精度浮点数（FP32）由 1 位符号位（Sign Bit）、8 位指数位（Exponent）、23 位尾数位（Mantissa）组成。这种格式能够提供较高的数值表示范围和精度，因此广泛用于深度学习模型的训练和推理。然而，FP32 格式的存储和计算开销较大，特别是在嵌入式设备、移动端或边缘计算环境中，使用 FP32 进行推理可能会导致较高的内存占用和计算延迟。通过模型量化能够减小计算复杂度以及模型的大小，利于模型部署到资源有限的设备中。

16 位半精度浮点数（FP16）的结构包括 1 位符号位、5 位指数位和 10 位尾数位，其指数范围较 FP32 缩小，同时尾数部分的精度降低。这使得 FP16 在减少存储需求的同时仍能提供相对较高的计算精度。因此，FP16 广泛应用于深度学习加速（如 Tensor Cores）以及低功耗推理场景，尤其是在 NVIDIA TensorRT、AMD ROCm 和部分 AI 加速硬件中，FP16 被用作权衡精度与计算性能的主要数据格式。

要想进一步降低位宽，8 位整型（INT8）的结构更为精简，仅包含 1 位符号位和 7 位有效数值位，完全舍弃了指数部分，使用定点数表示。这种格式的计算效率极高，适用于需要极致优化推理速度的应用场景，如移动端、嵌入式设备和云端推理加速。与 FP32 相比，将模型参数从 FP32 转换为 INT8 格式的量化过程能够显著减少存储空间、降低计算负载，并提高推理速度。但由于数值范围和精度的降低，模型可能会出现一定程度的量化误差，影响推理的准确性。RKNN-Toolkit2 提供的模型量化功能旨在通过将 FP32 格式的权重转换为 INT8 格式，在不显著影响模型预测精度的情况下加速推理计算。在许多深度学习应用中，INT8 量化能够在保证计算精度基本可接受的前提下，大幅提高推理速度，并降低内存带宽需求，使得深度学习模型能更高效地在低功耗设备上运行。模型量化方式如图 4.9 所示。



如图 4.9 模型量化方式示意图

Fig.4.9 Schematic diagram of the model quantification method

并非所有模型都能在量化后保持与原始模型相同的精度水平。对于某些特定结构或

对数值分布敏感的神经网络（如 Transformer 架构、某些 RNN/LSTM 网络），量化可能会导致较大的精度损失。特别是在存在较大动态范围的情况下，量化误差可能会累积，最终影响模型的预测结果。因此，在实际应用中，需要权衡量化带来的速度提升与可能的精度下降，并结合后量化校准（Post-Training Quantization, PTQ）或量化感知训练（Quantization-Aware Training, QAT）等方法来优化模型性能。为了在性能和精度之间取得平衡，RKNN-Toolkit2 提供了混合量化（Hybrid Quantization）功能。混合量化允许模型的部分层继续使用浮点数（FP16 或 FP32）表示，而其他层转换为定点数（INT8），从而兼顾计算效率和模型精度。

4.3 实验结果分析

4.3.1 轻量化网络实验

（1）轻量化网络对比试验

为验证本文轻量化 HGNetV2 网络在 GFLOPs、模型参数量、模型体积等指标的有效性，在实验环境相同的情况下使用相同网络 Roboflow 上公开的 Anotasi 数据集，将 AKConv^[76]、ShuffleNetv2、MobileNetv3、GhostNet 四个主流轻量化网络结构与其进行对比实验。实验结果如表 4.1 所示。

表 4.1 轻量化网络对比试验

Table 4.1 Comparative test of lightweight network

模型	GFLOPs/G	模型参数量/M	mAP@0.5/%
YOLOv8+AKConv	7.4	2.64	97.40
YOLOv8+ShuffleNetv2	13.1	6.38	97.70
YOLOv8+MobileNetv3	2.4	1.19	96.50
YOLOv8+GhostNet	5.0	1.71	95.71
YOLOv8+HGNetV2	6.9	2.35	97.91

由上表实验结果可看出，在这 5 个轻量化网络中，MobileNetv3 的 GFLOPs、模型参数量和指标表现最优，FPS 指标也有所提高，但 mAP@0.5 指标比原基础网络模型降低了 0.05 的百分点。HGNetV2 的 FPS 和 mAP@0.5 指标是这 5 个实验的最优，GFLOPs、模型参数量相比基础模型 YOLOv8n 分别减少了 1.2G、0.66M。综上所述，HGNetV2 替换为主干网络后，模型参数量等指标均有改进，综合性能比其他主流轻量化网络表现良好。

为进一步验证 HGNetV2 相比于其他主干模型的优越性，将各模型 mAP@0.5 指标

的训练轮次进行可视化，即图 4.10 展示的就是 YOLOv8 结合不同主流的主干网络 MobileNetv3、HGNetV2、GhostNet、ShuffleNetv2、AKConv 在训练过程中 mAP@0.5 的性能变化曲线。由图 4.10 中可以看出，蓝色曲线代表 HGNetV2 在训练过程中表现出较高的性能指标，其随着训练轮数的增加，mAP@0.5 性能提升显著；相比于其他主干网络模型，HGNetV2 能够在较少的训练轮数内达到较高的性能水平。这表明 HGNetV2 作为主干网络具有更强的特征提取能力，能够更快地学习到有效的特征表示。除此之外，YOLOv8+HGNetV2 的训练曲线较为平滑，波动较小，表明其在训练过程中具有较好的稳定性。




图 4.10 不同主干网络 mAP@0.5 的性能变化

Fig.4.10 Performance changes of mAP@0.5 in different backbone networks

在 BAL-YOLOv8 模型的基础上，根据轻量化网络对比实验的结果，运用各方面性能较好的 HGNetV2 替换 BAL-YOLOv8 模型的主干网络结构。表 4.2 为 BAL-YOLOv8 改进主干网络前后的对比试验，将修改后的模型命名为 HBAL-YOLOv8。由实验表中的数据可知，改进后的模型 HBAL-YOLOv8 在 GFLOPs、模型参数量和模型体积指标上均有明显改进，相比于 BAL-YOLOv8 分别降低了 28.36%、42.63%和 39.62%，mAP@0.5 仅减少了 0.10%。

表 4.2 BAL-YOLOv8 和 HBAL-YOLOv8 对比试验

Table 4.2 Comparative trial of BAL-YOLOv8 and HBAL-YOLOv8

模型	GFLOPs/G	模型参数量/M	模型体积/MB	mAP@0.5/%
BAL-YOLOv8	6.7	2.51	5.3	98.50
HBAL-YOLOv8	4.8	1.44	3.2	98.40

(2) RailDefect 数据集可视化对比实验

为进一步验证改进模型的泛化能力，在相同的实验环境下用 RailDefect 数据集进行

可视化,图 4.11 展示了 YOLOv8n 与改进后的 HBAL-YOLOv8 在 RailDefect 钢轨表面缺陷数据集检测任务中的四组对比实验结果。

其中,图 4.11 的(a)为原始 YOLOv8n 模型的检测结果,(b)为 HBAL-YOLOv8 模型的检测结果。通过对比可以观察到,HBAL-YOLOv8 在多个方面相较于 YOLOv8n 具有显著优势。在(a)图中,YOLOv8n 存在明显的漏检问题,部分缺陷目标未能成功识别;而在(b)图中,HBAL-YOLOv8 在整体检测精度上表现更优,能够更准确地识别和分类不同类型的缺陷目标,从而有效减少漏检现象并提高检测的可靠性。此外,HBAL-YOLOv8 在保持较高精度的同时优化了模型的计算复杂度,使其更适用于实际工业场景中的实时检测需求。综上所述,实验结果充分验证了 HBAL-YOLOv8n 在钢轨表面缺陷检测任务中的优越性,为后续的工业应用提供了一种更高效、精准且低计算成本的检测方案。




图 4.11 YOLOv8n 和 HBAL-YOLOv8 可视化对比结果

Fig.4.11 Comparison of YOLOv8n and HBAL-YOLOv8 visualizations

4.3.2 剪枝实验

本节内容对轻量化后的 HBAL-YOLOv8 网络进行通道剪枝实验与分析,实验环境同第三章的实验相同。本文基于 BN 层的稀疏化对网络结构进行通道剪枝,即在 BN 层网络中加入稀疏因子进行稀疏化训练,选择合适的稀疏因子可保证网络精度减少损失;稀疏化训练完成后对 BN 层 γ 接近于 0 的参数进行剪枝,最后对剪枝后的模型进行微调。

首先,在损失函数中加入 L1 正则化项,针对 BN 层不同的 γ 参数进行稀疏化。在模型训练过程中,不同的稀疏化因子 λ 会对最终模型的精度产生显著影响,而确定一个合适的初始 λ 值通常需要耗费大量时间和资源。为了解决这一问题,在训练初期,采用较

大的 λ 值以快速推动 BN 层参数 γ 的稀疏化；随着训练的深入，逐步降低 λ 值，从而使 BN 层参数逐渐稳定并恢复模型的精度。尽管这种策略在训练后期可能会因为 λ 值过小而使得 BN 层参数 γ 的稀疏度有所下降，但其优势在于初始 λ 值的选取更加简便，避免了繁琐的调参过程。不同稀疏因子 λ 下的 γ 参数对应实验结果图如 4.12 所示。




图 4.12 不同稀疏因子 λ 对应的 γ 参数

Fig.4.12 γ parameters corresponding to different sparsity factors λ

在图 4.12 的 a 图正常训练（无稀疏约束）检测结果中， γ 值集中在 1.0 附近，呈正态分布。b 图中 $\lambda = 0.1$ 时， γ 值虽集中在 0.0 附近，但分布较为分散，较大的稀疏因子 λ 导致模型参数 γ 趋向于 0，使得模型过于稀疏，丢失了大量有用信息，从而导致性能大幅下降，mAP@0.5 显著下降至 31.4%，性能较差。c 图 $\lambda = 0.005$ 的 γ 值集中在 0.0 附近，分布较为集中，模型仍然能够保持较高的性能，mAP@0.5 为 97.1%，性能接近正常训练。d 图 $\lambda = 0.01$ 实验结果中，在稀疏性和性能之间取得了较好的平衡，模型性能仅略微下降，mAP@0.5 为 96.8%，性能略低于 $\lambda = 0.005$ ，但仍保持较高水平。本节选择 $\lambda = 0.005$ ，因为它在性能和稀疏性之间取得了较好的平衡，适合大多数实际应用场景。

如前文所述，稀疏化实验结束后对所有卷积的通道进行重要性排序， γ 值越接近 0，

表明该通道对模型的贡献越小,可以被剪枝。根据设置的剪枝率计算对应参数 γ 的阈值,将重要性低的通道进行剪枝操作,同时移除与之对应的卷积核和特征图。为了研究不同剪枝率对模型性能的影响,本小节在 Roboflow 数据集上进行了对比实验。实验中,剪枝率分别设置为 20%、30%、40%和 50%,以评估不同程度的剪枝对模型表现的具体影响。通过在不同数据集上的实验,可以全面分析剪枝率对模型性能的作用及其适用性。

表 4.3 HBAL-YOLOv8 模型剪枝性能对比

Table 4.3 Comparison of pruning performance of HBAL-YOLOv8 model

剪枝率	模型体积/MB	参数量/M	mAP@0.5/%
0	3.2	1.44	98.40
20%	2.8	0.85	98.10
30%	2.3	0.75	97.85
40%	1.6	0.56	98.03
50%	1.3	0.41	95.53

通常情况下剪枝率越高,通道中被剪枝的数量越多,模型的计算复杂度也相对小,但相应的模型对提取特征信息的能力会变低,精度也会受到不同程度的损失。表 4.3 为不同剪枝率下微调后的部分性能指标对比情况,由该表可看出剪枝率在 20%-40%时,mAP@0.5 的变化较小,此时模型对轻度剪枝具有较强的鲁棒性。当剪枝率达到 50%时,mAP@0.5 显著下降,此时剪枝移除了过多的重要参数,导致模型性能下降;在剪枝率为 40%时,相比于 BAL-YOLOv8, mAP@0.5 仅降低 0.48%,但模型体积以及参数量分别降低 69.81%和 77.69%,能够在显著压缩模型的同时保持较高的精度。本节实验验证了模型剪枝的有效性,部署到 RK3588S 上的模型建在剪枝率 40%的 HBAL-YOLOv8 上进行。

4.3.3 模型部署验证

为在 RK3588S 芯片的 NPU 上进行推理,本节选择上一节中剪枝率为 40%的 HBAL-YOLOv8 模型进行模型部署。先将模型训练出的.pt 文件通过转化为 ONNX 模型,然后通过 RKNNToolkit2 再转化为 RKNN 模型。部署实验环境如表 4.4 所示。

本研究采用瑞芯微 RKNN-Toolkit2 工具链对轻量化的 HBAL-YOLOv8 模型进行量化,将预训练的模型导入 RKNN 对象,设置输入尺寸(640×640)、归一化参数及量化类型。采用钢轨缺陷数据集的代表性样本作为校准集,动态调整缩放因子和零点,优化量化误差。针对模型敏感层(如检测头),保留 FP16 精度以维持特征提取能力。其余卷积层采用 INT8 量化,减少计算负载。然后将生成的 RKNN 模型加载到 RK3588S 板卡的

NPU 上运行，通过调用 NPU 的硬件加速接口。

表 4.4 模型部署实验环境

Table 4.4 Experimental environment for model deployment

环境名称	量化类型
实验板卡	RK3588S
镜像系统	Debian11
RKNN-Toolkit2 版本	1.6.0
板卡 NPU 驱动版本	0.8.8
RKNPU2 版本	1.6.0
PC 环境	Ubuntu20.04

为验证不同模型量化方式在网络检测性能的影响，使用相同实验环境、参数设置、数据集等的情况下，本节对比了 INT8 和 INT16 量化方式的 FPS 和 mAP@0.5 性能指标，实验结果如表 4.5 所示。由实验结果可看出，未使用量化模型移植模型到 RK3588S 上时，HBAL-YOLOv8 剪枝模型检测目标的精度虽比较高，但帧率较低，实时检测速度达不到要求。使用 INT8 和 INT16 量化的模型在检测速度上有了极大的提升，虽然精度有所下降。相比之下，运用 INT8 进行模型量化的检测速度更高，在精度-速度权衡曲线上占据优势位置，且精度损失较小，故本节选用 INT8 进行模型量化。

表 4.5 不同量化模式对比

Table 4.5 Comparison of different quantification models

模型	量化类型	FPS/(frame · s ⁻¹)	mAP@0.5/%
HBAL-YOLOv8 (剪枝模型)	无	12.9	94.76
HBAL-YOLOv8 (剪枝模型)	INT8	88	91.01
HBAL-YOLOv8 (剪枝模型)	INT16	78	89.76

表 4.6 部署实验对比

Table 4.6 Comparison of deployment experiments

模型	FPS/(frame · s ⁻¹)	mAP@0.5/%
YOLOv8n (基准)	56	88.53
BAL-YOLOv8	61	92.21
HBAL-YOLOv8	64	92.76
HBAL-YOLOv8 (剪枝模型)	88	91.01

表 4.6 为不同模型在经过量化后的 FPS 和 mAP@0.5 性能指标对比情况。由图可看出，经本文改进后的 BAL-YOLOv8、HBAL-YOLOv8 和 HBAL-YOLOv8 剪枝后的模型均比基础模型的各项性能更优。HBAL-YOLOv8 剪枝后的 mAP@0.5 性能虽不是最优，

但检测速度明显改善，比基础模型提高 36.36%， $mAP@0.5$ 也比基础模型提高 2.80%。在实际工程中，铁轨移动检测终端对检测速度要求为 60 – 90 FPS，HBAL-YOLOv8 的剪枝模型达 88FPS，符合实际应用场景的要求。实验结果表明，经剪枝后的模型 HBAL-YOLOv8 更能平衡检测精度和速度，进一步验证了本文改进算法的优越性。

4.4 本章小结

本章首先对第三章提出的 BAL-YOLOv8 模型运用 HGNetv2 进行主干网络的轻量化，改进后的模型为 HBAL-YOLOv8。为验证改进方法的有效性，本章在实验环境以及实验数据集等相同的情况下，对不同的轻量化网络进行对比实验，验证本文所选轻量化网络的优越性。随后，对主干网络轻量化的模型 HBAL-YOLOv8 基于 BN 层的稀疏化进行通道剪枝，对网络模型的通道进行重要性排序，将重要性较低的通道进行剪枝，减少模型的参数量和计算复杂度，最后通过模型微调的方式减少精度的损失。针对不同剪枝率对模型影响程度的不同，利用实验测试了不同剪枝率下模型精度和检测速度的性能，选取了更能平衡检测精度和速度的剪枝率 40%。最后，搭建边缘部署平台，将剪枝后的 HBAL-YOLOv8 模型进行量化，部署到边缘设备 RK3588 设备中。

5 总结与展望

5.1 论文总结

铁路作为我国主要的交通方式，钢轨作为铁路轨道的重要组成部分，对铁路安全运行起至关重要的作用。由于钢轨长期暴露在外和长期被挤压的导致钢轨表面出现不同类型的缺陷目标，若不及时处理可能会对列车的正常运行产生不利影响。目前很多学者加入到钢轨表面缺陷检测的研究，基于对钢轨表面缺陷检测的国内外研究，针对目前钢轨细小目标检测精度不够高、模型参数量较高等问题，本文详细分析了深度神经网络的目标检测算法以及轻量化目标检测的研究现状，了解钢轨表面缺陷检测的难点，针对这些难点问题，阐述当前检测方法的局限性。然后介绍了目标检测相关的相关理论为后续的研究做基础，并围绕提高模型检测钢轨表面精度以及轻量化模型两个目标对 YOLO 检测算法展开研究。

本文采集了网络 Roboflow 上公开的 Anotasi 钢轨表面缺陷数据集和国家铁道科学研究院测试中心建设的 9 km 铁路试验环道采集的 RailDefect 数据集，利用开源标注工具 Labellmg 进行标注。针对钢轨表面缺陷呈现形状各异、大小不一等问题，在 YOLOv8n 模型的基础上，本文设计了多尺度融合 BAL-YOLOv8 的目标检测算法。首先通过 Mosaic、色彩变换等数据增强的方式扩充数据集，增强模型抗干扰的能力。BAL-YOLOv8 通过引入注意力机制 BRA 增强模型对不同尺度目标的检测能力，运用 Adown 优化下采样减少钢轨表面缺陷小目标检测出现误检、漏检的情况；再利用轻量化共享卷积的思想设计 LSCDH 优化检测头，在提高检测精度的同时降低模型的参数量。最后通过消融实验和选取经典两阶段模型 Faster R-CNN、单阶段 SSD 和 YOLO 系列算法与本研究 BAL-YOLOv8n 算法进行对比试验验证改进模块的有效性与优越性。

为解决硬件设备算力资源有限的问题，对 BAL-YOLOv8 算法利用轻量化卷积和通道剪枝的方法进行轻量化。首先，利用轻量化卷积模块 HGNetV2 调整 BAL-YOLOv8 模型的网络结构，将模型改进为 HBAL-YOLOv8，减少模型的参数量和计算复杂度。然后，基于 BN 层稀疏化的通道剪枝方法对模型进行压缩：在对 HBAL-YOLOv8 进行通道剪枝时，对稀疏化因子 λ 进行相应调整，找出合适的 λ 能够快速实现参数 γ 的稀疏化；随后，对稀疏化后的模型进行通道剪枝，并通过微调的方式减少精度损失的问题。剪枝后的 HBAL-YOLOv8 相比于 BAL-YOLOv8，mAP@0.5 仅降低 0.48%，但模型体积以及参数量分别降低 69.81% 和 77.69%，能够在显著压缩模型的同时保持较高的精度。

最后，搭建嵌入式 RK3588 环境，将改进后的模型进行量化后部署到硬件设备中，进一步验证改进模型轻量化的有效性和可行性。相比于基础模型 YOLOv8n，经改进剪枝后的 HBAL-YOLOv8 模型精度为 91.01%，FPS 达到 88 帧/秒，符合实时检测的应用要求。

5.2 研究展望

钢轨表面缺陷检测作为铁路安全运维的重要组成部分，其智能化与轻量化研究对提升铁路系统的可靠性和运行效率具有重要的工程价值。尽管本文提出的 BAL-YOLOv8 和 HBAL-YOLOv8 模型在检测精度、轻量化程度及实时性方面均取得了显著提升，但考虑到钢轨检测场景的复杂性及相关技术的持续发展，未来研究仍可从以下几个方面进一步深化：

本文训练过程中采用了 Roboflow 平台公开的 Anotasi 钢轨表面缺陷数据集以及国家铁道科学研究院测试中心在 9 km 铁路试验环道采集的 RailDefect 数据集。然而，现有数据集中仍缺乏在极端光照、雨雪等复杂环境条件下的样本，这可能限制模型的泛化能力。未来研究可结合生成对抗网络（GAN）等数据增强技术，合成更符合真实工况的高质量训练数据，以提升模型对复杂场景的适应性。此外，针对钢轨表面缺陷的微小尺度及形态多样性，可引入高分辨率成像技术（如激光扫描或红外热成像）与可见光图像的融合，通过跨模态特征增强提高模型对微小缺陷的检测能力。

在计算资源受限的硬件环境中，本文通过 HGNetV2 结合通道剪枝实现了模型压缩，有效降低了推理计算的开销，轻量化深度学习技术仍在快速发展，未来研究可进一步探索动态稀疏训练（Dynamic Sparse Training,DST）、神经架构搜索（Neural Architecture Search,NAS）及知识蒸馏等前沿优化策略，以在保证模型精度的同时进一步提高计算效率。此外，本文模型已在 RK3588S 平台上完成验证，表明其在边缘设备上的可行性。然而，不同边缘计算平台 Jetson 系列、FPGA 等在算力、存储和能耗方面存在显著差异，因此未来研究可针对不同硬件架构设计定制化优化策略，提升模型的跨平台适配能力。

参考文献

- [1] 李维刚, 梅洋, 樊响, 等. 基于车载激光点云的铁路轨道检测 [J]. 中国激光, 2022, (004): 162-173.
- [2] 中华人民共和国国家铁路局. 文献著录: 钢轨损伤分类: TB/T1778-2010[S], 北京: 中国铁道出版社, 2010.
- [3] 刘启跃, 王文健, 周仲荣. 高速与重载铁路钢轨损伤及预防技术差异研究[J]. 润滑与密封. 2007, 32(11): 11-14.
- [4] 杜晨琛, 刘文波, 陈旺才. 多传感器特征决策融合的钢轨裂纹识别方法[J]. 电子测量技术, 2017, 40(11): 157-160.
- [5] 田贵云, 高斌, 高运来, 等. 铁路钢轨缺陷伤损巡检与监测技术综述[J]. 仪器仪表学报, 2016, 37(8): 1763-1780.
- [6] ALVA R ENGA T A, CA R VALHO A L, HONO RIO L M, et al. Detection and classification system for rail surface defects based on Eddy current [J]. Sensors, 2021, 21(23): 7937.
- [7] 张琳娜, 岑翼刚. 铁轨图像的低秩矩阵分解缺陷检测 [J]. 信号处理, 2019, 35(4): 667-675.
- [8] Daniel LM. Non-contact technology for track speed rail measurements: ORIAN. Proc.SPIE, Vol.2458: 45-51, 1995.
- [9] Moretti M, Triglia M, Maffei G. ARCHIMEDE-the first European diagnostic train for global monitoring of railway infrastructure[C]//2004 IEEE Intelligent Vehicles Symposium. Parma, 2004: 522-526.
- [10] 仲崇成, 李恒奎, 李鹏等. 高速综合检测列车综述[J]. 中国铁路, 2013(06): 89-93. DOI:10.19549/j.issn.1001-683x.2013.06.021.
- [11] 樊曦. 世界领先新型复兴号高速综合检测列车上线运行[J]. 科技传播, 2022, 14(08): 8. DOI:10.16607/j.cnki.1674-6708.2022.08.033.
- [12] 李应璋, 何洪涛, 何长江. 微机控制数据采集光学系统[J]. 现代电子技术, 1994, (03): 49-52+48.
- [13] 贾康成. 线扫描铁轨表面成像系统与缺陷检测算法研究[D]. 湖南大学, 2014.
- [14] 张俊, 陈建政. 有轨电车轨道磨耗检测方法研究[J]. 无线互联科技, 2016(2): 118-120.
- [15] Wu Y, Qin Y, Wang Z, et al. A UAV-based visual inspection method for rail surface defects[J]. Applied sciences, 2018, 8(7): 1028.

- [16] Cao X, Xie W, Ahmed S M, et al. Defect detection method for rail surface based on line-structured light[J]. Measurement, 2020, 159: 107771.
- [17] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.
- [18] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[J]. Advances in neural information processing systems, 2014, 27.
- [19] 冉建民.基于图像和 CNN 模型的钢轨表面缺陷识别研究[D].兰州交通大学,2018.
- [20] 张博,刘秀波,赵志荣,等.基于视觉的钢轨表面缺陷识别方法综述[J].铁道建筑,2020,60(09):136-140.
- [21] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [22] 罗维平,徐洋,陈永恒,等.基于迁移学习和改进 ResNet50 网络的织物疵点检测算法[J].毛纺科技,2021,49(02):71-78.DOI:10.19333/j.mfkj.20200501408.
- [23] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 1-9.
- [24] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 580-587.
- [25] Ren S. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. arXiv preprint arXiv:1506.01497, 2015.
- [26] 苏烨,李筠,杨海马,等.基于 Faster R-CNN 的钢轨表面缺陷识别研究[J]. Electronic Science & Technology, 2020, 33(9).
- [27] 徐广隆.基于改进 Faster R-CNN 的多类多尺度钢轨表面伤损检测算法研究[D].江西.,2021:华东交通大学.
- [28] He K, Gkioxari G, Dollár P, et al. Mask r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2961-2969.
- [29] Cai Z, Vasconcelos N. Cascade r-cnn: Delving into high quality object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 6154-6162.
- [30] 罗晖,李健,贾晨.基于图像增强与改进 Cascade R-CNN 的钢轨表面缺陷检测[J].激光与光电子学进展, 2021(022):058.DOI:10.3788/LOP202158.2212001.
- [31] Qi J, Nguyen M, Yan W (2022) .Waste classification from digital images using ConvNeXt.

- Pacific-Rim Symposium on Image and Video Technology, pp.1–13.
- [32] Redmon J. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016.
- [33] REDMON J, FARHADI A. Yolo9000: better, faster, stronger [c]//proceedings of the ieec conference on computer vision and pattern recognition.[C].YOLO9000: better, faster, stronger [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017.
- [34] REDMON J, FARHADI A. Yolov3: An incremental improvement[J]. arXivpreprint arXiv:1804.02767, 2018.
- [35] 韦若禹,李舒婷,吴松荣,等.基于改进 YOLOV3 算法的轨道扣件缺陷检测[J].铁道标准设计,2020,64(12):30-36.DOI:10.13238/j.issn.1004-2954.201912090005.
- [36] Zhang H, Song Y, Chen Y, et al. MRSDI-CNN: Multi-model rail surface defect inspection system based on convolutional neural networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23(8): 11162-11177.
- [37] 陆楠菲,基于改进 YOLOv4 的铁轨表面裂纹检测研究[D].宁夏大学,2022.
- [38] A. Boch kovskiy, C. Y. Wang, H. Y. M. Liao. Yolov4: Optimal Speed and Accuracy of Object Detection[J]. Computing Reserch Repository, 2020, 2004.10934.
- [39] 李开智. 基于 YOLO 的铁轨表面缺陷检测方法研究 [D]. 曲阜师范大学,2023.DOI:10.27267/d.cnki.gqfsu.2023.000813.
- [40] 周淼森. 基于改进 YOLOv5 的铁轨表面缺陷检测研究 [D]. 宁夏大学,2023.DOI:10.27257/d.cnki.gnxhc.2023.000882.
- [41] 吴永军,崔灿,何永福.基于语义增广与 YOLOv8 的钢轨表面缺陷检测方法[J].铁道科学与工程学报,2024,21(09):3864-3875.DOI:10.19713/j.cnki.43-1423/u.T20231930.
- [42] 宫永刚,任兰柱,邹晓越.基于改进 YOLOv8 的钢轨表面缺陷检测算法[J].自动化应用,2024,65(18):169-171+175.DOI:10.19769/j.zdhy.2024.18.050.
- [43] 孙铁强,魏光辉,宋超,等.基于 YOLO 的多模态钢轨表面缺陷检测方法[J].电子测量技术, 2025, 47(21): 72-81.
- [44] Li C, Li L, Jiang H, et al. YOLOv6: A single-stage object detection framework for industrial applications[J]. arxiv preprint arxiv:2209.02976, 2022.
- [45] Wang C Y,Bochkovskiy A,Liao H Y M.YOLOv7:Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[J].arXiv preprint arXiv:2207.02696,2022.
- [46] Iandola F N, Han S, Moskewicz M W, et al. SqueezeNet: AlexNet-level accuracy with 50x

- fewer parameters and < 0.5 MB model size[J]. arXiv preprint arXiv:1602.07360, 2016.
- [47] Howard A G , Zhu M , Chen B ,et al.MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications[J]. 2017.DOI:10.48550/arXiv.1704.04861.
- [48] 张元,吕德芳,孟建军,等.基于双注意力和 GSSN 轻量化的钢轨扣件缺陷检测[J/OL].计算机工程,1-11[2024-12-03].<https://doi.org/10.19678/j.issn.1000-3428.0068491>.
- [49] Zhang X, Zhou X, Lin M, et al. Shufflenet: An extremely efficient convolutional neural network for mobile devices[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 6848-6856.
- [50] 武子强.基于 YOLOv4 的钢轨表面伤损检测算法研究[D].哈尔滨理工大学,2023.DOI:10.27063/d.cnki.ghlg.2023.001118.
- [51] 许贵阳,付伟,张玉华,等.基于改进 YOLOv7 的钢轨螺孔伤损检测方法[J].铁道建筑,2024,64(03):52-58.
- [52] Li H, Kadav A, Durdanovic I, et al. Pruning Filters for Efficient ConvNets[C]//Proceedings of the International Conference on Learning Representations (ICLR). San Juan, Puerto Rico: OpenReview, 2017.
- [53] Luo J H, Wu J, Lin W. ThiNet: A Filter Level Pruning Method for Deep Neural Network Compression[C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). Venice, Italy: IEEE, 2017: 5058–5066.
- [54] Yu R , Li A , Chen C F ,et al.NISP: Pruning Networks Using Neuron Importance Score Propagation[J].IEEE, 2018.DOI:10.1109/CVPR.2018.00958.
- [55] Z. H. Huang, N. Y. Wang. Data-driven Sparse Structure Selection for Deep Neural Networks[C]. Proceedings of the European Conference on Computer Vision (ECCV), 2018: 304-320.
- [56] Hinton G. Distilling the Knowledge in a Neural Network[J]. arXiv preprint arXiv:1503.02531, 2015.
- [57] 杨田甜.基于嵌入式平台的深度学习算法优化与轨道检测应用[D].北京交通大学,2023.DOI:10.26944/d.cnki.gbfju.2023.001616.
- [58] 曾泰恒.基于 YOLO 的轻量化番茄实时检测算法及移动端部署[D].福建农林大学,2023.DOI:10.27018/d.cnki.gfjnu.2023.000274.
- [59] Hubel D H, Wiesel T N. Receptive fields, binocular interaction and functional architecture in the cat's visual cortex[J]. The Journal of physiology, 1962, 160(1): 106.
- [60] Fukushima K. Neocognitron: A self-organizing neural network model for a mechanism of

- pattern recognition unaffected by shift in position[J]. Biological cybernetics, 1980, 36(4): 193-202.
- [61] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [62] Howard A, Sandler M, Chu G, et al. Searching for mobilenetv3[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 1314-1324.
- [63] Ma N, Zhang X, Zheng H T, et al. Shufflenet v2: Practical guidelines for efficient cnn architecture design[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 116-131.
- [64] Han K, Wang Y, Tian Q, et al. Ghostnet: More features from cheap operations[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 1580-1589.
- [65] Anwar S, Hwang K, Sung W. Structured Pruning of Deep Convolutional Neural Networks[J]. ACM Journal on Emerging Technologies in Computing Systems, 2017, 13(3): 32:1-32:18.
- [66] He Y, Kang G, Dong X, Fu Y, Yang Y. Soft filter pruning for accelerating deep convolutional neural networks[C]//Proceedings of the 27th International Joint Conference on Artificial Intelligence. Stockholm, Sweden: AAAI Press, 2018: 2234-2240.
- [67] Xie Z, Fu M, Liu X. Detection of Fittings Based on the Dynamic Graph CNN and U-Net Embedded with Bi-Level Routing Attention[J]. Electronics, 2023, 12(22): 4611.
- [68] Wang C Y, Yeh I H, Liao H Y M. YOLOv9: Learning what you want to learn using programmable gradient information. arXiv 2024[J]. arXiv preprint arXiv:2402.13616.
- [69] Yi D ,Ahmedov B H ,Jiang S , et al. Coordinate-Aware Mask R-CNN with Group Normalization: A underwater marine animal instance segmentation framework [J]. Neurocomputing, 2024, 583 127488-. DOI:10.1016/j.neucom.2024.127488.
- [70] LI H, WANG F, LIU J, et al. Ensemble model for rail surface defects detection[J]. PLoS one, 2022, 17(5): e0268518.
- [71] XIA Z, PAN X, SONG S, et al. Vision transformer with deformable attention[C]// Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 4794-4803.
- [72] Wan D, Lu R, Shen S, et al. Mixed local channel attention for object detection[J]. Engineering Applications of Artificial Intelligence, 2023, 123: 106442.DOI:10.1016/

- j.engappai.2023.106442.
- [73] WOO S Y, PARK J H, LEE J Y, et al. CBAM: convolutional block attention module[C]//Proceedings of the 15th European Conference on Computer Vision(ECCV). Munich: Springer, 2018:3-19.
- [74] Misra D, Nalamada T, Arasanipalai A U, et al. Rotate to attend: Convolutional triplet attention module[C]//Proceedings of the IEEE/CVF winter conference on applications of computer vision. 2021: 3139-3148.
- [75] Yang L, Zhang R Y, Li L, et al. Simam: A simple, parameter-free attention module for convolutional neural networks[C]//International conference on machine learning. PMLR, 2021: 11863-11874.
- [76] ZHAO Y AN, LYU W Y, XU SH L, et al. Detsr beat yolos on real-time object detection[J]. ArXiv preprint arXiv:2304.08069, 2023.
- [77] Zhang X, Song Y, Song T, et al. AKConv: Convolutional Kernel with Arbitrary Sampled Shapes and Arbitrary Number of Parameters[J]. arXiv preprint arXiv:2311.11587, 2023