

分类号:

学校代码: 10112

密 级:

太原理工大学

硕士学位论文

(学术学位)

基于 YOLO 算法的激光器芯片缺陷检测技术研究

姓 名: 胡 玮

学 号: 2021510450

培养单位: 电子信息与光学工程学院

学 科: 信息与通信工程

研究方向: 图像处理

指导教师: 赵菊敏 教授

论文提交日期: 2024 年 6 月

A Dissertation Submitted to
Taiyuan University of Technology
In partial fulfillment of the requirement
For the degree of Master

**Research on Laser Chip Defect Detection Technology
Based on YOLO Algorithm**

By
Wei Hu

College of Electronic Information and Optical Engineering
June 2024

学位论文答辩信息表

论文题目	基于 YOLO 算法的激光器芯片缺陷检测技术研究		
答辩日期	2024 年 6 月 1 日	答辩秘书	李付江
学位论文答辩委员会成员			
姓名	职称	工作单位	备注
陈平	教授	中北大学	主席
郝晓燕	副教授	太原理工大学	委员
贾华宇	副教授	太原理工大学	委员

摘要

高功率半导体激光器在信息与通信领域中发挥着至关重要的作用，其可靠性是系统正常运行的关键。激光器芯片正常工作过程中产生的光学灾变损伤（Catastrophic Optical Damage, COD）缺陷是影响芯片效能和寿命的主要因素，会导致光输出功率的突然下降。精确检测光学灾变损伤的出现位置和发展过程，实现对缺陷的自动检测 and 智能识别，是当前亟待解决的问题。这能够帮助工程师研究失效机理和退化模式，改进制造工艺并优化芯片结构设计。传统的激光器芯片缺陷检测依赖于人工操作，其过程耗时费力，基于传统机器视觉的技术精度不足。基于深度学习的缺陷检测技术，因其具有深层特征提取能力，展现出高精确度和强鲁棒性，适用于复杂多变场景下的激光器芯片缺陷检测任务。现有的缺陷检测算法主要用于芯片表面缺陷的识别任务，缺乏针对有源区光学灾变损伤缺陷的检测算法，同时激光器芯片缺陷检测算法缺乏在实际工业场景中的应用方案。因此，针对上述问题，提出了基于 YOLO（You Only Look Once）算法的激光器芯片缺陷检测技术研究。本文的贡献和内容如下：

（1）针对激光器芯片光学灾变损伤缺陷特征相似、图像模糊、背景复杂、空间定位不准确等问题，本文提出基于深度学习的缺陷检测架构 COD-YOLO，实现对光学灾变损伤的高精度检测。以单阶段目标检测器 YOLOv7 架构为基础，利用可变形卷积重构高效聚合模块，自适应提取条形缺陷的丰富特征，同时应用注意力机制突出强调缺陷信息。基于空间与内容感知的上采样结构，实现多尺度特征融合，结合语义和空间信息，防止在上采样过程中缺陷关键位置信息的丢失。另外，由于缺乏细粒度的缺陷信息，微小缺陷对位置偏差敏感，线性叠加针对小目标的损失函数，优化边界框坐标回归损失，增强模型对不同尺寸缺陷的检测能力和识别精度。实验结果表明，本文提出的 COD-YOLO 模型在激光器芯片缺陷检测任务中表现出良好性能。

（2）针对当前缺陷检测网络参数庞大而难以实际应用的问题，本文在此背景下提出轻量级激光器芯片 COD 缺陷检测与模型部署的解决方案。采用轻量化卷积神经网络（Convolutional Neural Network, CNN）结构作为模型特征提取主干，设计轻量级的 Fast-COD-YOLO 系列模型。同时，利用结构重参数化模块弥补轻量化造成的精度误差，有效降低模型推理时的参数量和计算量。此外，针对检测网络中存在冗余参数的问题，进行模型剪枝实验，在保证检测性能的前提下，提高计算效率和资源利用率。最后，根据实际应用环境，将算法模型部署到图像采集系统的本地服务器中，实现光学灾变损伤缺陷检测算法的初步应用。

关键词：半导体激光器芯片；光学灾变损伤；YOLO；缺陷检测；模型部署

ABSTRACT

High-power semiconductor lasers play a crucial role in the field of information and communication, where their reliability is key to the normal operation of systems. Catastrophic optical damage (COD) that occurs during the normal operation of laser chips is a major factor affecting the efficiency and lifespan of the chips, leading to a sudden drop in their optical output power. Precisely detecting the location and development of catastrophic optical damage, achieving automatic detection and intelligent recognition of defects, is an urgent issue to be addressed. This can help engineers study failure mechanisms and degradation modes, improve manufacturing processes, and optimize structural designs. Traditional defect detection of laser chips relies on manual operations, which are time-consuming and labor-intensive, and the accuracy of traditional machine vision-based techniques is insufficient. Defect detection technology based on deep learning, due to its deep feature extraction capabilities, offers high accuracy and robustness, suitable for complex and variable scenarios in laser chip defect detection tasks. Existing defect detection algorithms mainly focus on the identification of surface defects of chips and lack algorithms for detecting catastrophic optical damage in active regions. Moreover, there is a shortage of practical industrial application schemes for laser chip defect detection algorithms. Therefore, addressing the above issues, this study proposes a YOLO-based (You Look Only Once) laser chip defect detection technology research. The contributions and content of this dissertation are as follows:

(1) Addressing issues such as similarity of catastrophic optical damage defects, background complexity, image blur, and inaccurate spatial localization, this dissertation introduces a deep learning-based defect detection architecture, COD-YOLO, for high-precision detection of catastrophic optical damage defects. Based on the one-stage object detector YOLOv7 architecture, it utilizes deformable convolutions to reconstruct an efficient layer aggregation network module that adaptively extracts rich features of strip-like defects, while applying channel attention to emphasize defect information. With a spatial-content-based up-sampling structure, it achieves multi-scale feature fusion, combining semantic and coordinate information to prevent loss of crucial defect position information during up-sampling. Additionally, due to the lack of fine-grained defect information and sensitivity to the positional deviation of tiny defects, the boundary box coordinate regression loss function is optimized, and a loss function tailored for small targets is linearly superimposed, enhancing the model's detection ability and recognition accuracy. Experimental results show that the COD-YOLO

model proposed in this dissertation demonstrates good performance in detecting catastrophic optical damage defects in laser chips.

(2) In response to the issue of current defect detection networks having large parameters, making them impractical for real-world applications, this dissertation presents a lightweight laser chip COD defect detection and model deployment solution. By utilizing a lightweight convolutional neural network (CNN) structure as the backbone for model feature extraction, a lightweight Fast-COD-YOLO series model is proposed. Additionally, to compensate for the accuracy loss caused by lightweighting, a structure re-parameterization module is employed, effectively reducing the model's parameter count and computational load during inference. Furthermore, to address the issue of redundant parameters in the detection network, model pruning experiments are conducted to improve computational efficiency and resource utilization without compromising detection performance. Finally, tailored to the real-world application environment, the algorithmic model is deployed on a local server in the image acquisition system, facilitating the preliminary application of the catastrophic optical damage detection algorithm.

Keywords: semiconductor laser chip; catastrophic optical damage; YOLO; defect detection; model deployment

目 录

第 1 章 绪论.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	2
1.2.1 光学灾变损伤研究现状.....	2
1.2.2 深度学习目标检测研究现状.....	3
1.2.3 半导体芯片缺陷检测研究现状.....	4
1.3 论文研究内容与章节安排	6
1.4 本章小结.....	7
第 2 章 激光器芯片缺陷检测理论基础	9
2.1 引言	9
2.2 光学灾变损伤理论基础.....	9
2.3 深度学习理论基础.....	11
2.3.1 卷积神经网络.....	11
2.3.2 目标检测.....	15
2.3.3 模型压缩.....	15
2.4 本章小结.....	16
第 3 章 基于 YOLOv7 的激光器芯片 COD 缺陷检测.....	17
3.1 引言	17
3.2 激光器芯片 COD 缺陷检测	18
3.2.1 COD-YOLO 总体结构.....	18
3.2.2 可变形高效聚合网络.....	19
3.2.3 基于空间和内容感知的上采样模块	21
3.2.4 针对 COD 的坐标回归损失函数	22
3.3 实验结果与分析.....	23
3.3.1 数据集.....	23
3.3.2 评价指标.....	24
3.3.3 实验细节.....	24
3.3.4 结果与讨论.....	25
3.4 本章小结.....	32
第 4 章 基于轻量化 CNN 的 COD 缺陷检测与模型部署	33
4.1 引言	33
4.2 轻量级激光器芯片 COD 缺陷检测	34
4.2.1 Fast-COD-YOLO 总体结构.....	34
4.2.2 轻量化特征提取主干.....	36

4.2.3 Diverse Branch Block 模块	38
4.2.4 实验结果与讨论	39
4.3 模型压缩	42
4.3.1 模型剪枝	43
4.3.2 剪枝实验结果与讨论	44
4.4 模型部署	46
4.5 本章小结	48
第 5 章 总结与展望	49
5.1 全文工作总结	49
5.2 未来工作展望	50
参考文献	51

图目录

图 1-1 论文总体结构	7
Fig. 1-1 Overall structure of the dissertation.....	7
图 2-1 激光器芯片光学灾变损伤图像	10
Fig. 2-1 Image of laser chip with Catastrophic Optical Damage	10
图 2-2 图像采集系统结构简图	11
Fig. 2-2 Image acquisition system structure diagram.....	11
图 2-3 卷积神经网络模型结构 ^[54]	12
Fig. 2-3 Convolutional neural network model architecture ^[54]	12
图 2-4 卷积运算	12
Fig. 2-4 Convolution operation	12
图 2-5 最大池化和平均池化操作	13
Fig. 2-5 Max pooling and averaging pooling operation	13
图 2-6 LeakyReLU 激活函数	13
Fig. 2-6 LeakyReLU activation function.....	13
图 2-7 SiLU 激活函数	14
Fig. 2-7 SiLU activation function.....	14
图 2-8 YOLO 基本检测过程	15
Fig. 2-8 YOLO basic detection process.....	15
图 3-1 激光器芯片可见光与电致发光图像	17
Fig. 3-1 VL and EL images of laser chips	17
图 3-2 缺陷检测框架 COD-YOLO	19
Fig. 3-2 Defect detection framework COD-YOLO.....	19
图 3-3 可变形高效聚合网络和通道注意力模块结构图	20
Fig. 3-3 D-ELAN and SE structure diagram	20
图 3-4 DCNv3 的结构	20
Fig. 3-4 The structure of DCNv3.....	20
图 3-5 基于空间和内容感知的上采样模块：坐标卷积和 CARAFE	21
Fig. 3-5 SC-UP structure: CoordConv and CARAFE	21

图 3-6 不同尺寸缺陷边界框交并比差异	22
Fig. 3-6 Differences in IoU for defect bounding boxes at various scales	22
图 3-7 对比实验的可视化检测结果	27
Fig. 3-7 Visual detection results of the comparison experiment.....	27
图 3-8 COD-YOLO 类激活热力图	27
Fig. 3-8 CAM visualization results for COD-YOLO	27
图 3-9 混淆矩阵	28
Fig. 3-9 Confusion matrix.....	28
图 3-10 模型主干不同结构组合的精度变化	29
Fig. 3-10 AP variations with different combinations of backbone structures.....	29
图 3-11 不同损失函数的性能分析, 其中蓝色表示 $\lambda=1$ 的 COD-Loss 损失即 IoU 损失, 橙色表示 $\lambda=0.7$ 的 COD-Loss 损失, 绿色表示 $\lambda=0.5$ 的 COD-Loss 损失.....	30
Fig. 3-11 Performance analysis of different loss functions, where the blue represents IoU loss, the orange line represents COD-Loss with $\lambda=0.7$, and the green represents COD-Loss with $\lambda=0.5$	30
图 3-12 YOLOv7 和 COD-YOLO 的可视化结果	31
Fig. 3-12 Visualizing results: YOLOv7 vs our COD-YOLO.....	31
图 4-1 缺陷检测系统的工作流程图	33
Fig. 4-1 The workflow of the COD defect detection system	33
图 4-2 轻量级光学灾变损伤缺陷检测模型总体结构	35
Fig. 4-2 Lightweight model architecture for COD defect detection.....	35
图 4-3 基于 MobileNetv3 的主干	36
Fig. 4-3 Backbone based on MobileNetv3.....	36
图 4-4 基于 FasterNet 的主干	38
Fig. 4-4 Architecture of FasterNet	38
图 4-5 DBB 结构	39
Fig. 4-5 Structure of DBB.....	39
图 4-6 轻量级模型的可视化结果	42
Fig. 4-6 Visualization of the lightweight model	42
图 4-7 非结构剪枝: Drop Out 和 Drop Connect.....	43
Fig. 4-7 Unstructured pruning: Drop Out and Drop Connect.....	43
图 4-8 通道剪枝示意图	44

Fig. 4-8 Schematic diagram of channel pruning.....	44
图 4-9 剪枝前后的通道对比图.....	46
Fig. 4-9 Channel comparison before and after pruning.....	46
图 4-10 检测模型部署应用.....	47
Fig. 4-10 Detection model deployment application	47

表目录

表 3-1 光学灾变损伤缺陷数据集分布	23
Table 3-1 Distribution of COD defect dataset	23
表 3-2 COD-YOLO 模型的超参数	25
Table 3-2 Hyperparameters of COD-YOLO	25
表 3-3 不同检测方法的对比实验结果	25
Table 3-3 Comparative experimental results of different detection methods	25
表 3-4 不同尺寸缺陷下检测模型性能比较	26
Table 3-4 Comparison of detection model performance under different size defects	26
表 3-5 不同超参数实验结果比较	28
Table 3-5 Results comparison with different hyperparameters	28
表 3-6 COD-YOLO 检测器消融实验	29
Table 3-6 Study of ablation of the COD-YOLO detector	29
表 3-7 模型主干不同结构组合实验结果	29
Table 3-7 Experimental results of different structural combinations in the backbone	29
表 3-8 不同注意力机制的消融实验	30
Table 3-8 Ablation experiments using different attention mechanisms	30
表 3-9 钢材表面缺陷数据集通用性实验结果	32
Table 3-9 Universality experiment results on the NEU-DET dataset	32
表 4-1 MobileNetv3 网络结构	37
Table 4-1 Architecture of MobileNetv3	37
表 4-2 实验环境配置	40
Table 4-2 Experimental environment configuration	40
表 4-3 轻量级网络对比实验结果	41
Table 4-3 Comparative experimental results of lightweight networks	41
表 4-4 改进模型的消融实验结果	41
Table 4-4 Ablation experimental results of the improved model	41
表 4-5 PAGCP 剪枝实验就结果: YOLOv7 和 YOLOv7-Tiny	45
Table 4-5 The results of the PAGCP pruning experiment are: YOLOv7 and YOLOv7-Tiny ..	45

表 4-6 不同剪枝算法实验结果比较	46
Table 4-6 Comparing results of different pruning experiments	46

第 1 章 绪论

1.1 研究背景和意义

自 2015 年 5 月，国务院正式印发《中国制造 2025》，部署全面推进实施制造强国战略^[1]。中国制造 2025 是利用信息化技术引领产业升级转型，推进工业制造智能化进程，提高我国工业的竞争力，在新一轮的工业革命中掌握主动。在 2023 年 6 月，工业和信息化部等五部门联合发布了《制造业可靠性提升实施意见》，强调可靠性是反映产品质量水平的核心指标，提高基础产品可靠性，深化数字技术在可靠性提升中的应用^[2]。智能激光器芯片缺陷自动化检测系统正是传统半导体制造业向智能化方向和提高可靠性方向的转变，响应国家倡导的“中国制造 2025”战略和“制造业可靠性提升实施意见”的号召。

自 20 世纪 60 年代半导体激光器诞生起，伴随着半导体制造工艺的优化与完善，在过去的数十年取得显著的进步，在激光技术领域确立无可替代的地位。作为关键性的光电器件组成部分，半导体激光器在信息产业中的作用日益凸显，由于其波长覆盖面广、传输性能强、光电转化效率高、易于调制的优势^[3]，被广泛的应用于工业^[4]、医疗^[5]、通信^[6]和国防^[7]等领域。随着对半导体激光器需求的不断增加，其光输出功率也越来越高，导致半导体激光器容易发生瞬态的光学灾变损伤（Catastrophic Optical Damage, COD）。光学灾变损伤是影响激光器工作寿命的主要因素，微小源区的缺陷损伤会导致整个通信系统的失效。因此，可靠性和稳定性已成为半导体激光器实际应用中的关键问题。

在半导体激光器所有退化机制中，COD 是最主要的突然失效过程，广泛出现在边发射激光器中。一旦 COD 缺陷开始发生，量子阱内未转化成光的功率将导致芯片内局部区域出现强烈发热并且最终造成激光器设备产生故障^[8]。随着半导体激光器技术的持续进步，其生产工艺变得更加精细化。因此，针对失效激光器芯片的缺陷检测与分析工作显得尤为关键，是提升半导体激光器可靠性的必由之路。激光器芯片有源区的电致发光图像是损伤信息的重要来源，能精确检测 COD 的产生位置和发展过程，实现对缺陷自动和智能的识别，对辅助研究失效机理和退化模式，改进芯片生产工艺和制造水平，避免缺陷再次发生具有重要的现实意义^[9]。

在半导体激光器芯片制造领域，传统的缺陷检测方法主要依赖于人工检测过程，工程师通过高分辨率显微镜完成分析任务。为了完成缺陷图像的分析，要求执行严格的操作步骤，逐一对失效芯片进行检测，判断缺陷类型，同时还需要具备相应的专业知识保证检测精准。人工检测方法随着激光器芯片数量的激增，开始出现效率低下、成本昂贵的问题，容易受到主观因素影响的问题，检查结果高度依赖于操作人员的经验。此外，

由于芯片尺寸大小属于微米级，电致发光技术（Electroluminescence, EL）^[10]采集的图像相对模糊，难以满足高精度、高速度的检测需求。因此，激光器芯片光学灾变损伤的智能检测变得至关重要。在早期，基于机器视觉的传统检测方法依赖手动特征提取和支持向量机（Support Vector Machine, SVM）的分类器^[11]，人工的特征描述涉及专业知识和繁琐的参数调整，需要针对特定的场景进行设计，缺乏泛化性和鲁棒性，检测精度相对较低。随着人工智能技术的飞速进步，基于深度学习的自动视觉检测技术不仅在多个领域得到广泛应用，特别是在半导体制造行业中，通过其高效的数据处理能力和卓越的检测准确性，已经证明了其不可替代的价值。这些技术突破了传统检测方法在数据复杂性处理和实时检测精度方面的局限，展现出强大的技术优势和广阔的应用前景。

因此，实现高效准确的激光器芯片光学灾变损伤缺陷检测是当前亟待解决的问题。基于深度学习的方法在缺陷检测方面表现出了优异的性能，通过将图片输入端到端的检测模型中，利用深度神经网络中的多层卷积提取特征，将其转化为高维度的语义信息，实现高精度的识别任务。该方法能够从大规模数据中自动学习潜在的统计规律，性能不容易受到光照强度或电流大小等因素影响，具有良好的检测精度和泛化能力。但在复杂背景噪声干扰下对近红外电致发光图像中芯片缺陷进行检测仍面临很大挑战，涉及到缺陷纹理模糊、尺寸大小不一以及感受野不规则等问题。在此基础上，需要开发基于深度学习的激光器芯片缺陷检测算法，实现更高效的自动化检测和对不同光学灾变损伤的准确分类。此外，考虑到深度学习算法在实际应用中存在的局限性，探索适合的模型部署策略也至关重要。综上所述，研究基于深度学习的激光器芯片缺陷检测技术显得尤为迫切和关键。

在本文中的主要研究对象是波长为 1310nm 的 InP 基分布式反馈激光器（Distributed Feedback Laser, DFB Laser），损伤芯片的智能缺陷检测旨在电致发光图像中识别和定位光学灾变损伤的类别和位置。利用基于深度学习的算法对光学灾变损伤图像实现智能化缺陷检测，提供一种效率更高、准确度更高的分析手段。该方法能够降低缺陷检测的复杂性，并迅速提取损伤缺陷位置的关键信息，同时能够帮助测试公司批量高效的处理大量出现光学灾变损伤的数据，提高分析的效率和准确性，降低分析成本，具有一定的实际应用价值。

1.2 国内外研究现状

1.2.1 光学灾变损伤研究现状

高功率半导体激光器芯片的退化模式根据时间演化，主要有三种表现形式：正常老化、快速退化和灾难性退化^[12]。限制正常工作的激光器芯片可靠性的主要原因就是灾难性的失效，是正常工作寿命后突然出现的快速退化过程。当达到特定条件时，退化过程

被激活,事先没有迹象表明损伤可能发生,难以及时筛选。光学灾变损伤的根源产生于芯片内部的腔面或腔体中晶体中不完美的位置,以暗线的形式限制在有源区传播。根据退化开始的位置分为光学灾变腔面损伤(Catastrophic Optical Mirror Damage, COMD)和光学灾变腔体损伤(Catastrophic Optical Bulk Damage, COBD)。COMD与端面相联系,由于表面电流载流子和光子的吸收导致端面温度升高,端面上的局部区域发生熔化,使暗线缺陷从表面起始点向后延伸到腔体内^[13]。COBD的降解机制还没有统一的结论,Sin等人^[14]提出利用TR-EL(Time-resolved Electroluminescence)、EBIC(Electron Beam Induced Current)和DLTS(Deep-level Transient Spectroscopy)等技术建立了COBD缺陷损伤模型。有源区预先存在的点缺陷作为非辐射聚合中心(Nonradiative Recombination Centers, NRCs),会显著吸收光子形成局部热源,使得温度升高,通过复合增强缺陷反应(Recombination Enhanced Defect Reaction, REDR)形成位错,产生更多热量,超过临界温度导致热失控,产生的COBD沿着腔内传播向两边传播^[14]。

由于没有明显的前兆,半导体激光器的失效机理一直以来都是研究的难点。对退化机制的研究可以追溯到上世纪60年代,1966年Services Electronics Research Lab.的研究人员Cooper等^[15]首先对出现在GaAs基激光器内部的COD进行研究报道。1967年RCA Laboratories的Kressel等人^[16]也发表了关于COD的观测报告。在1970s年代早期,随着异质结激光器的发展和连续波工作模式的提出,激光器的退化出现的更加频繁。1973年Eliseev等人^[17]将COD的发展过程定性为微观的热爆炸。1979年Henry等人^[18]对COD的起源以及发展动力学进行了全面的阐述,研究表明COD是快速热失控引起的,初始化该过程的温度称为临界温度,由此得到两个结论:局部融化的发生是由于无缺陷的有源区表面或缺陷处发生了强烈的非辐射聚合;暗线是由于有源区中的熔融点的传播造成。Tang等人^[19]首次报道了这一发展过程的实验验证,并对热失控的临界温度进行测量。进入20世纪后,二极管激光器COD损伤机理同力学问题仍被广泛研究。由于制造工艺与表面钝化技术的发展,COMD的阈值功率不断提高,使得主要的失效模式已经转变为COBD^[20]。Bou等人^[21]采用光致发光技术(Photoluminescence, PL)研究了高功率激光器中出现的COMD现象,发现缺陷从端面开始,沿着腔内平行于波导的方向传播。Sin团队^[22]利用EL技术观察到引起失效的暗线缺陷从腔体内部开始,表明发生COBD现象,其产生于谐振腔内的非辐射聚合中心,点缺陷向两边生长成暗线缺陷。上述研究采用不同检测技术对激光器芯片中发生的失效现象进行研究,分析出光学灾变损伤的失效机理和形状特点,更加详细的内容将2.2节进行介绍,为本文中对光学灾变损伤的分类和标记过程提供了理论支撑。

1.2.2 深度学习目标检测研究现状

基于深度学习的计算机视觉,从2012年卷积神经网络提出开始得到重生成为主流。

近年来,深度学习得到迅速发展,在各个领域产生了重大影响尤其是图像分类、目标检测和图像分割这三项具有代表性的任务。深度神经网络能自动学习到图像中的高维特征,避免了人工设计的繁琐过程,具有优异的准确率和鲁棒性。详细的理论知识将在本文的2.3节中进行讨论,此处只对深度学习的发展进行简单介绍。深度学习开始于分类模型,主要的功能是实现物体深层次的特征信息提取,可以作为下游任务的特征提取主干。常见的网络结构包括: AlexNet^[23]、VGGNet^[24]、GoogLeNet^[25]、ResNet^[26]、MobileNet^[27-29]、ConvNext^[30]、FasterNet^[31]等。ResNet^[26]因其在解决深层神经网络训练难题方面的重大突破被广泛应用,为了缓解随着网络深度增加而出现的梯度消失和梯度爆炸问题,引入残差的捷径连接,直接将输入传递到后续层的输出,使模型专注于学习更深层次的增量特征,同时批量归一化(Batch Normalization, BN)^[32]的使用,稳定训练过程加快收敛速度。目标检测在同一时间得到迅速发展,根据是否分阶段进行目标识别和位置定位将其分为两类:两阶段(Two-Stage)目标检测和单阶段(One-Stage)目标检测。RCNN^[33](Region-based Convolutional Neural Network)系列是两阶段目标检测网络的代表,率先使用卷积神经网络来提取特征,将目标检测分为两步操作:区域提议(Region Proposal),通过某种策略生成潜在目标所在的候选框或区域;在候选框的基础上进一步提取特征并进行分类和边界框回归。相对于单阶段目标检测,其更精确但计算成本较高。Redmon 等人^[34-36]提出了实时的目标检测网络 YOLO (You Only Look Once) 系列,是单阶段目标检测的代表,直接在特征图上预测类别和边界框坐标,输出每个像素点或特定锚点(Anchor)上的目标类别和位置信息。倾向于在追求更高的实时性,在保证一定精度的前提下减少计算复杂度。随着算法的迭代和新技术如特征金字塔网络(Feature Pyramid Networks, FPN)^[37]、Anchor 机制、Transformer^[38]、结构重参数化^[39]等的引入,深度学习在目标检测领域的表现不断刷新纪录,为自动驾驶、缺陷检测等诸多应用提供了强大工具。YOLOv7^[40]是当前目标检测领域的代表性模型之一,拥有着强大的网络结构,更有效的特征提取方式,提高实时检测的精度。深度学习的繁荣为生产实践中的缺陷检测应用提供了有效的技术支持。

本文旨在运用深度学习技术研发针对激光器芯片缺陷的高精度实时检测系统,并将其部署到计算资源有限的实际仪器设备中。为此,本文选用 YOLO 系列的先进目标检测网络作为基础模型进行优化实现缺陷检测功能,以达到检测精度与运算效率的平衡。此外,为适应低功耗、低成本环境下的模型部署需求,在此基础上提出了轻量级模型并采取剪枝的模型压缩技术,在保证检测性能的同时有效地减小模型体积,前瞻性地为其他检测算法的潜在部署提供可能。

1.2.3 半导体芯片缺陷检测研究现状

基于深度学习的缺陷检测已在半导体芯片领域得到成功应用,用于缺陷产品的剔除

和期望的质量控制。Chen 等人^[41]在 YOLOv3 的基础上结合 DenseNet^[42]的密集连接结构,提出了一种名为 YOLOv3-dense 的 SMD-LED 芯片缺陷检测器,同时引入了田口法评估超参数的灵敏度。Shu 等人^[43]针对 LED 芯片提出了一种用于其表面缺陷检测的并行空间金字塔池化的深度学习模型(PSPP-net)。利用空间金字塔池化的优势,解决 LED 芯片表面质量安全检测中的离线特征训练提取和在线缺陷识别问题。同样针对 LED 芯片,Maiké 等人^[44]提出将全卷积网络用于芯片级缺陷检测,通过跳跃连接的残差结构,实现从单一到集群的 LED 晶圆缺陷检测。Yu 等人^[45]提出一种轻量级、高效的微小缺陷检测网络。在主干网络中,利用对角特征金字塔融合更多原始特征,减小计算成本,自适应定位损失函数调节对微小缺陷的灵敏度,在 PCB 缺陷数据集中表现良好。Liu^[46]等人提出了基于 Faster R-CNN 的光伏电池电致发光图像缺陷检测算法,通过卷积神经网络实现特征的多尺度融合,有效识别光伏电池断栅缺陷。Su 等人^[47]研究了基于 YOLO 的算法模型,用于太阳能电池板电致发光图像的自动缺陷检测,设计新型的注意力网络,嵌入到检测模型的融合结构中,构建了端到端检测框架,并将其应用于无人机中实现检测功能。通过上述研究进展可以发现,深度学习具有优秀的特征提取能力,广泛应用于芯片缺陷检测任务中,但是目前仍缺少针对半导体激光器芯片的缺陷检测算法,因此本文对此为实现对激光器芯片的缺陷检测进行调查研究。

Hou 等人^[9]首次使用深度学习的方法对 DFB 激光器芯片不同部位的缺陷进行分类,开发基于 GoogLeNet 的低功耗离线手持式激光器芯片缺陷图像分类器。在此研究基础上,Hou 等人^[48]的团队又提出基于连续子空间学习的激光芯片缺陷分类模型,实现便携式激光芯片缺陷分类器。Klehr 等人^[49]提出了一种基于纵模谱傅里叶变换的无损检测方法,可以精确检测半导体激光器腔内的缺陷位置,空间精度达到 ± 2 微米,但在面对多条暗线缺陷时具有一定局限性。Wang^[50]等人实现基于显微成像系统和深度卷积神经网络的微光字符识别系统,以方便 DFB 芯片的微字符识别。Zhang 等人^[51]针对 TO56 封装的半导体激光器芯片,提出基于 DeepLabv3 改进的缺陷自动识别网络。该方法通过串联方式实现了引线缺陷的定位、分割和识别。定位针对激光器芯片与其引线,将引线进行分割,判断引线的缺陷类别,实现了 TO56 封装激光器引脚的缺陷检测。Guo 等人^[52]针对激光器芯片光学灾变损伤缺陷提出新型缺陷分类网络 CODDNet,构建端到端的缺陷分类模型,利用多尺度条形卷积提取更丰富的不同缺陷类别信息。综上所述,现有针对激光器芯片的缺陷检测大多未涉及到光学灾变损伤缺陷,而光学灾变损伤是严重制约高功率激光器性能的关键因素之一。同时针对光学灾变损伤的研究无法精确定位缺陷位置。本文针对上述工作在处理激光器芯片光学灾变损伤缺陷检测方面的空白与不足,展开激光器芯片光学灾变损伤缺陷检测技术的研究,包括检测缺陷的类别与位置信息,采用实时性强的单阶段目标检测模型 YOLO 并将其部署应用到工业生产中,对激光器芯片的智能制造和质量溯源起到一定作用。

1.3 论文研究内容与章节安排

本文旨在解决激光器芯片制造过程中的质量控制问题，针对激光器芯片的缺陷检测算法与应用进行研究。针对现有的缺陷检测算法难以有效检测光学灾变损伤缺陷，准确率低、鲁棒性差和缺陷检测算法难以在实际中应用等问题。研究的目标是结合机器视觉和深度学习实现高准确率、高实时性的半导体激光器芯片光学灾变损伤缺陷检测。主要包含两部分内容：

(1) 基于 YOLOv7 的激光器芯片 COD 缺陷检测

针对光学灾变损伤缺陷纹理模糊、背景复杂、尺寸较小、发光强度不一造成图像灰度值波动等问题，本文在分析和对比后，提出了一种基于深度学习的缺陷检测架构 COD-YOLO。提出的模型以 YOLOv7 为基础，使用可变形卷积重构高效聚合模块，提高对条形缺陷的特征提取能力，同时应用注意力机制突出强调缺陷信息。为充分挖掘并有效整合多尺度缺陷特征，采取结合空间与内容感知的上采样模块，防止在融合过程中导致空间信息流失。另外，鉴于缺陷尺寸存在随机变化的特性，对边界框坐标回归损失函数进行了调整，线性叠加针对小目标的损失函数，有助于增强模型对微小目标缺陷特征的检测和识别精度。根据上述改进策略，本文提出的 COD-YOLO 模型在激光器芯片光学灾变损伤缺陷检测任务中表现出良好性能。

(2) 基于轻量化 CNN 的 COD 缺陷检测与模型部署

面对当前缺陷检测网络普遍存在的因参数规模过大而难以实际部署的问题，本文在此背景下构建针对激光器芯片 COD 缺陷的轻量化检测与部署解决方案。提出轻量级的 Fast-COD-YOLO 系列模型，其核心采用轻量化卷积神经网络作为特征提取的基础网络，并且在特征融合模块中使用增强模型性能的多分支结构，使得模型能在不同层次的上下文环境中灵活整合多维度缺陷信息，有效降低模型所需的参数量和计算量。为增强模型在硬件资源有限条件下的适用性和有效性，进行模型剪枝技术实验，进一步减少冗余参数。基于对检测模型具体应用环境的需求分析，决定采用本地部署方案，并成功将缺陷检测模型集成到图像采集系统的本地服务器中，实现对光学灾变损伤缺陷检测算法初步应用。

本文的整体内容结构如图 1-1 所示，论文共由五章组成，具体安排如下：

第 1 章本文首先阐述基于 YOLO 算法的激光器芯片缺陷检测技术的研究背景和意义；随后梳理相关研究现状，包括光学灾变损伤的研究、简述深度学习目标检测的发展以及半导体芯片缺陷检测的研究进展，重点关注激光器芯片缺陷检测技术；最后概括文章的研究内容及章节具体安排。

第 2 章主要介绍本文所依托的理论基础，特别是激光器芯片缺陷检测相关的核心知识。本章首先阐释光学灾变损伤缺陷的理论原理，为缺陷分类和标注提供依据。随后，深入探讨深度学习相关知识，为后续实验方法和结果分析奠定了坚实的理论基础。

第3章详细介绍基于YOLOv7的激光器芯片COD缺陷检测算法,将其命名为COD-YOLO,针对高精度检测光学灾变损伤设计。该模型在YOLOv7实时目标检测器的基础上,引入可变形卷积重构高效聚合模块、结合空间和内容感知的上采样以及针对COD缺陷的坐标回归损失函数,提高在光学灾变损伤数据集上的检测性能。本章首先阐述COD-YOLO的总体结构,根据基础模型和缺陷特点进行模型优化。然后,通过对比实验和消融研究,验证COD-YOLO在激光器芯片COD缺陷检测应用中的有效性。

第4章深入探讨针对激光器芯片COD缺陷检测的轻量级模型设计与部署。章节首先分析第3章缺陷检测模型由于参数庞大难以直接应用于实际的挑战。基于该问题,本章提出轻量级缺陷检测Fast-COD-YOLO系列模型,采用轻量化卷积神经网络主干和结构重参数化改进。接着通过模型剪枝,进一步降低参数量和计算量,增强计算资源有限的适用性和效率。最终将缺陷检测模型成功部署到图像采集系统中,实现光学灾变损伤的实时检测,初步完成缺陷检测算法的实际应用。

第5章是本文的总结与展望部分,主要回顾整体研究内容,对本文工作进行梳理。同时对当前光学灾变损伤缺陷检测算法的局限性进行分析,提出了对未来研究方向的展望,为后续的相关研究提供了思路和建议。




图 1-1 论文总体结构

Fig. 1-1 Overall structure of the dissertation

1.4 本章小结

本章阐述了激光器芯片缺陷检测技术研究的背景和重要性,首先强调研究的意义与

技术价值。接着，对当前激光器芯片所面临的光学灾变损伤问题的研究进展、深度学习目标检测技术的发展趋势以及半导体芯片缺陷检测的研究现状进行梳理。最后，明确指出本文的核心研究内容及其对应的章节组织架构，为后续深入探讨奠定基础。

第2章 激光器芯片缺陷检测理论基础

2.1 引言

本章集中讨论激光器芯片缺陷检测所依赖的关键理论基础，系统性地包含此项研究所需的基础知识。对激光器芯片内部光学灾变损伤缺陷背后的理论原理进行深入解读，为后续对缺陷进行准确分类和有效标注起到理论指导作用。接下来，本章对深度学习基本原理和方法进行介绍，主要包括卷积神经网络、目标检测和模型压缩技术。本章作为本文的核心理论组成，旨在与读者搭建交流的桥梁，引导其系统学习和理解激光器芯片缺陷检测基础理论知识。

2.2 光学灾变损伤理论基础

在半导体激光器的生产制造到封装使用的全生命周期中，都会面临缺陷的困扰，在第1章中，本文简单说明三种可能的失效模式：正常老化、快速退化和灾难性退化。正常老化是激光器芯片随着使用时间的增长，性能逐渐衰退的过程，是普遍存在的正常现象。快速退化发生在前一百个小时内是光功率快速降低的过程，可以在质量筛选阶段通过老化实验进行区分。而引起灾难性退化的光学灾变损伤是特殊的突然失效机制，没有明显的前兆，涉及到光输出功率大量或全部损失。COD是热失控的过程，会导致激光器内部结构的变化，造成有源区内部的物理破坏，需要通过显微镜才能有效观察^[8]。热失控可能发生在腔面或腔体中的任何位置。起始点是该点处的额外温度升高，导致热失控现象出现，形成损伤缺陷造成光输出功率突然下降。COD主要包含两种模式COMD和COBD，它们具有相似的性质。COMD的过程可以被描述成芯片腔面温度升高时，发生带隙偏移导致载流子的密度增加，出现强烈的非辐射电子-空穴复合反应，使表面温度不断升高至超过表面材料的温度阈值，造成局部区域熔化。在激光器腔面处出现的该区域形成暗点，随着缺陷的积累形成暗线缺陷（Dark Line Defects, DLDs），其向后蔓延沿有源区传播。COBD的失效模式与COMD不同，是出现在腔体内部的损伤。有源区中预先存在的点缺陷作为非辐射聚合中心，通过局部增益饱和和界面复合产生足够的载流子，导致局部温度升高，光被强烈吸收，进而导致热失控，局部区域发生熔化，向两端传播形成暗线缺陷，使内部结构被破坏导致COBD产生^[53]。

通过对激光器芯片进行缺陷检测，制造商可以针对COD不同类别采取相应的解决方法。针对COMD可以通过镀膜钝化激光器的腔面，提高COMD产生的阈值功率，减少激光在腔面的吸收。对于COBD可以通过改善材料质量、优化设计、控制工艺参数、

加强散热管理以及研发新材料和器件结构等方法，降低局部热效应，防止热失控的发生，延长激光器的使用寿命。因此，提出基于 YOLO 算法的激光器芯片缺陷检测技术研究，更精确高效的 COD 缺陷检测技术的实现，有助于制造商分析缺陷因素，持续推动设计优化。综上所述，如图 2-1 所示，图像模糊缺陷微小，COD 是有源区中生长的暗线缺陷，即发光下的黑色条形，依据缺陷的位置，对激光器芯片有源区 COD 缺陷进行分类。




图 2-1 激光器芯片光学灾变损伤图像

Fig. 2-1 Image of laser chip with Catastrophic Optical Damage

为构建激光器芯片 EL 图像数据集，接下来详细介绍所搭建的图像采集系统。系统围绕波长1310nm 的激光器芯片设计，以 P 极朝下的方式安装在基座上进行图像获取。考虑到激光器芯片微米级的尺寸，图像采集系统的结构简图如图 2-2 所示。采集系统主要由精密探针台、红外电耦合器件（Charge-coupled Device, CCD）相机以及配套的拍摄软件构成，整套设置于在光学洁净实验室中，以减少外界因素对图像质量的干扰。核心是采用的增强型手动探针台，用作激光器芯片的承载与移动平台，集成光学显微镜与红外 CCD 相机等关键组件。通过光学显微镜，实验人员可在可见光源下观察样品表面情

况；同时，手动操作连接到电源正负极的探针为芯片供电。切换至红外光源后，系统能够捕捉到有源区的发光特性。红外 CCD 相机专门用于拍摄激光器芯片在电致发光下的光学灾变损伤图像，具备 640×512 的图像分辨率。在整个工作流程中，缺陷图像经红外 CCD 相机捕捉后，实时显示于配套的拍摄软件界面中，研究人员通过软件进行图像存储。此外，本地服务器作为核心的数据处理及模型部署平台，负责接收采集的图像数据，执行缺陷检测算法，并最终呈现可视化结果。




图 2-2 图像采集系统结构简图

Fig. 2-2 Image acquisition system structure diagram

2.3 深度学习理论基础

本文核心内容聚焦于基于深度学习的激光器芯片 COD 缺陷检测算法，为了确保研究过程的顺利进行，本节就对深度学习的相关基础理论进行全面回顾与梳理，包括卷积神经网络的基础理论、经典目标检测网络架构以及模型压缩相关知识等内容。

2.3.1 卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）^[54]是深度学习中的一种核心架构，用于处理具有明显空间层次结构的数据，如图像等。被广泛应用于图像处理、计算机视觉等领域，主要解决的任务包括图像分类、目标检测、语义分割等。CNN 能够从原始像素中自动学习有意义的特征表示，具有局部感知、参数共享、平移不变性等特点。其模型结构如图 2-3 所示，主要由卷积层、池化层、全连接层等构成，每层之间存在激活函数、归一化层等。CNN 专注于识别和处理张量数据，利用其卷积层能有效捕捉局部特征，并通过逐层抽象的方式提取高层次的特征，能够有效地捕捉数据的空间和结构信息，是深度学习领域最重要的工具之一。




图 2-3 卷积神经网络模型结构^[54]

Fig. 2-3 Convolutional neural network model architecture^[54]

(1) 卷积层

卷积层是 CNN 的核心，负责提取输入数据中的特征。在这层中，数据处理是通过卷积操作实现的，该操作包含了卷积核（亦称作滤波器）在输入数据上逐步滑动的过程，并在每一步中执行内积运算。通过使用不同形状和数量的卷积核能提取输入数据的不同信息，卷积运算公式如下所示：

$$(X * K)(i, j) = \sum_m \sum_n K(m, n) \cdot X(i - m, j - n) \quad (2-1)$$

其中 X 和 K 分别表示输入和卷积核， $*$ 代表卷积操作， (i, j) 表示输出特征图的元素位置， m 和 n 遍历卷积核的维度。经过卷积后特征图的空间维度会发生变换，输入和输出特征之间的关系可表达为：

$$X_{out} = \frac{X_{in} - K + 2P}{S} + 1 \quad (2-2)$$

其中 P 代表填充大小， S 是步长既卷积核每次滑动的距离，卷积计算过程如图 2-4 所示。




图 2-4 卷积运算

Fig. 2-4 Convolution operation

(2) 池化层

在卷积层之后，通常会接续池化层的操作，旨在降低特征图（Feature Map）的空间维度。其中，最常用的池化方法包含最大池化和平均池化两种。参考图 2-5 所示，以 2x2 大小的池化层为例说明其下采样过程。




图 2-5 最大池化和平均池化操作

Fig. 2-5 Max pooling and averaging pooling operation

(3) 激活函数

激活函数在 CNN 中扮演着不可或缺的角色，它是提升网络捕获复杂数据模式和实现高效表征学习的关键要素之一。在 CNN 的大多数层中，尽管卷积和其他线性运算构成了网络的基础架构，但正是激活函数凭借其非线性特征赋予模型理解和适应各种复杂关系的能力。诸如 Sigmoid、ReLU、Tanh 等激活函数被广泛应用在 CNN 之中，通过非线性转换显著增强模型对输入数据的抽象表达和分类边界的学习能力。本文中使用的激活函数主要包括 LeakyReLU 和 SiLU。LeakyReLU 的数学表达式如下式：

$$f(x) = \max(\alpha x, x) \quad (2-3)$$

其中 α 是小于 1 的常数，取值通常为 0.01。如图 2-6 所示，LeakyReLU 激活函数通过在负半轴引入的非零斜率，缓解了神经元可能陷入“死亡”状态的问题。




图 2-6 LeakyReLU 激活函数

Fig. 2-6 LeakyReLU activation function

表达式 (2-4) 所展示的是 SiLU 函数的数学模型，在图 2-6 中得以形象地可视化。

融合了 Sigmoid 函数的动态响应与 ReLU 函数在正区间的线性激活，对于复杂的数据分布和网络结构有更强表达能力。

$$f(x) = \frac{x}{1+e^{-x}} \quad (2-4)$$




图 2-7 SiLU 激活函数

Fig. 2-7 SiLU activation function

(4) 全连接层

全连接层是 CNN 最后的层结构，用于实现对前一层所有节点的全连接，以进行全局的特征整合与分类，通常承担着“分类器”的角色，将前面各层提取的高级特征转化为样本所属各类别的概率分布，最终用于模型预测。其计算公式下：

$$[y_1, y_2] = [x_1, x_2, x_3] * \begin{bmatrix} w_{11} & w_{12} \\ w_{21} & w_{22} \\ w_{31} & w_{32} \end{bmatrix} + [b_1, b_2] \quad (2-5)$$

其中 x_i 是输入特征矩阵， y_i 表示输出特征矩阵， w 代表权重， b 代表偏置。

(5) 归一化层

归一化层通过调整卷积神经网络中间层的输出，有助于加速训练过程，一定程度上解决梯度消失和梯度爆炸，能够提高模型的稳定性和性能。归一化操作通常是在网络的不同层之间进行，旨在将输入数据规范化到零均值和单位方差的分布，从而减少内部协变量偏移。BN^[32]是应用最广泛的归一化技术， $\hat{x}_i$ 表示 x_i 归一化后数据，具体公式如下：

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} \quad (2-6)$$

其中 μ_B 和 σ_B^2 分别代表数据集的均值和方差。利用式 (2-7) 对输入数据进行变换，允许网络恢复非归一化的情况，式中 γ 和 β 是可学习参数，分别表示尺度变换和偏移变换。

$$y_i = \gamma \hat{x}_i + \beta \quad (2-7)$$

2.3.2 目标检测

目标检测是计算机视觉研究中的重要分支，致力于自动识别并定位图像内的多个目标实体。这领域集成了图像处理、模式识别与机器学习等多个学科的理论与方法，旨在通过计算机算法模拟人类视觉系统的目标识别能力。目标检测不仅需准确地分类图像中的目标对象，还要精确地预测其在图像中的位置，通常表示为对象周围的边界框。在众多目标检测算法中，YOLO 因其一次性对整幅图像进行分析并预测目标的能力而显著。该算法通过将检测任务简化为单一的回归问题，实现了对目标类别和位置的同时预测，大幅提高了处理速度与效率。此外，YOLO 算法在实时缺陷检测领域的应用展现了其对工业质量控制的显著贡献，能够有效地在生产线上实时识别和定位缺陷，从而提高制造精度和效率。接下来对 YOLO 算法的相关知识进行简单介绍。

YOLO 系列的算法结构简单，直到如今仍在不断进行版本更新。将输入图像划分为 $S \times S$ 个网格，如图 2-8 所示。以每个网格为中心进行检测，预测边界框，判断是否存在目标物体。对于预测相同目标的边界框，选择置信度最高的作为预测框。YOLO 包含很多实现细节，包括非极大值抑制^[55]用来处理多个预测框重叠的问题，确保目标只被检测一次；多尺度预测在不同尺度特征图进行预测，提高对不同大小物体的检测性能；锚框聚类确定最优的初始锚框尺寸等。




图 2-8 YOLO 基本检测过程

Fig. 2-8 YOLO basic detection process

2.3.3 模型压缩

模型压缩的探索起始于 LeCun 等人^[56]的开创性工作 Optimal Brain Damage(OBD)，这项研究揭示了神经网络中参数的冗余性，并指出通过精心移除某些权重，可以得到既

减小了规模又保持或甚至提升性能。这一发现奠定了模型压缩技术的基础，为后续的研究提供了重要的理论支持。模型压缩目的是降低深度学习模型的计算需求、存储成本和复杂度，通过去除模型中非关键的结构和参数来减少模型的体积和对计算资源的依赖。如今，模型压缩已经发展出多种方法，包括剪枝（Pruning）、量化（Quantization）、分解（Decomposition）和知识蒸馏（Knowledge Distillation）等，这些技术都旨在实现更高效的深度学习模型，以适应资源受限的环境。

剪枝技术^[57]通过评估参数的重要性来移除神经网络中的非关键部分，分为结构化剪枝和非结构化剪枝。结构化剪枝，常用的方式是通道剪枝，以通道为基本单位，通过评估通道的重要性进行剪枝；而非结构化剪枝则依赖启发式方法，将不重要的参数置零。这一过程不仅显著减小模型的体积，提升计算效率降低能耗，还充当正则化约束，提高模型的泛化能力。剪枝通过简化模型结构，优化模型在资源受限环境下的部署与运行，使得模型在多种应用场景下更为高效和实用。

量化^[58]作为一种广泛应用的技术手段，对众多模型和硬件设备均具有良好的适用性。是用较低精度的权重（例如，8 位整数）逼近全精度权重（32 位浮点数）的过程。量化技术显著降低计算和存储的成本，同时提升运算速度并减少设备的能耗。虽然量化过程会带来一定的精度下降，但借助精心设计的量化策略和细致的后续优化，精度损失能够得到有效控制，实现资源使用效率的最大化，兼顾性能与效率间的平衡。

分解技术^[59]是一种将原始的高维张量矩阵转化为多个低秩张量矩阵乘积的方法，这一过程能够显著降低模型参数数量，减轻存储需求和计算负荷，主要包括满秩分解和奇异值分解等方法。此项技术揭示数据的内在结构，但在分解过程中出现的信息损失可能对模型的预测性能产生一定的负面影响。通常，分解技术与剪枝相结合使用，旨在提高深度学习模型的效率和灵活性。

知识蒸馏^[60]是一种有效的模型压缩方法，通过教师-学生架构，将从复杂大型模型中提炼出的知识迁移到更简单的小型模型中，以增强小模型的性能。其核心思想是利用预训练、性能强的教师网络来指导结构简单的学生网络训练，使后者能够近似地模拟前者的行为，并达到相近的性能水平。这种策略尽管需要进行两次训练，延长训练时间，但在提升小模型性能方面优势明显，成为优化深度学习模型的一种高效策略。

2.4 本章小结

本章重点阐述了所涉及的激光器芯片缺陷检测的基础理论，系统涵盖研究相关的知识概念。首先，详细剖析激光器芯片内部发生的光学灾变损伤缺陷的失效机理，该部分为后续缺陷类型的准确划分和有效标注提供理论支撑。其次，介绍深度学习基础理论与方法，涵盖卷积神经网络的基本原理、目标检测算法的设计和模型压缩技术等内容，讨论在激光器芯片缺陷检测任务中的应用。

第3章 基于YOLOv7的激光器芯片COD缺陷检测

3.1 引言

在激光器芯片的生产制造和使用过程中,有源区内的光学灾变损伤会导致整个系统的瘫痪。对失效芯片进行缺陷检测,了解光学灾变损伤的失效原理和退化机制,是提高半导体激光器可靠性的必经之路。缺陷检测对帮助工程师分析芯片损伤的具体原因,识别生产环节中导致缺陷产生的具体流程,避免损伤再次发生具有一定的现实意义。导致输出功率下降的主要原因是源区内的光学灾变损伤 COD,由可见光图像可以观察到腔体位置,EL 电致发光技术观测有源区内部缺陷,暗线缺陷是亮光中生长的黑色条带。激光器芯片有源区的电致发光近红外图像中的光学灾变损伤缺陷主要包含两种:光学灾变腔面损伤 COMD 和光学灾变腔体损伤 COBD,缺陷形状相近条形,位置大小存在差异背景复杂,如图 3-1 所示。




图 3-1 激光器芯片可见光与电致发光图像

Fig. 3-1 VL and EL images of laser chips

研究对象是 1310nm 的 InP 基 DFB 激光器,损伤芯片的智能检测旨在识别电致发光图像中光学灾变损伤的类别和位置。分析芯片缺陷图像是一项被严格执行的任务,在传统的手动检查中,工程师必须具备相应的专业知识,使用显微镜进行反复检测和分析,显著增加了人力成本,导致检测效率低下。因此,基于计算机视觉的自动检测至关重要。基于深度学习的计算机视觉,自 2012 年卷积神经网络得到重生^[23]以来已成为主流。深度神经网络能够学习到图像高维的特征,自动学习和提取图像中的信息,因此被广泛应用于缺陷产品剔除和期望的质量控制,在工业领域越来越受欢迎^[61]。

在复杂背景干扰下的近红外图像中检测芯片缺陷仍然具有很大的挑战性。技术难点在于光学灾变损伤具有复杂的缺陷形状和不规则的感受野，传统的卷积无法满足提取缺陷细节信息的要求。因此，选择合适的算法以匹配缺陷的形状和位置特征是面临的首要问题。其次，随着网络的加深和下采样，微小损伤缺陷的特征容易丢失，缺失的特征将会导致检测结果恶化。如何能在网络中保留完整的特征以提高多尺度损伤缺陷检测的有效性。针对微小光学灾变损伤的检测，与传统的目标检测相比存在差异，在边界框坐标回归损失方面尤为突出。设计出满足不同大小缺陷的损失函数至关重要，以确保精准的位置定位和识别准确性。

为了解决上述问题，提出基于 YOLOv7^[40] 的激光器芯片光学灾变损伤缺陷检测模型，将其命名为 COD-YOLO。该网络使用可变形卷积（Deformable Convolution, DCNv3）^[62] 来重新构建高效的聚合模块，核心思想是通过动态的稀疏卷积 DCNv3 更好地适应感受野，学习缺陷特征信息，并引入长距离依赖和自适应空间聚合。同时，在模块的输出层使用通道注意力机制^[63]，自主学习特征通道的重要性，以便精准地定位和识别感兴趣的缺陷信息。此外，设计针对光学灾变损伤的坐标回归损失函数，将 IoU 的损失函数和 NWD（Normalized Gaussian Wasserstein Distance）^[64] 的损失函数进行融合；在特征融合结构中基于空间和内容感知进行上采样^[65]，以充分利用坐标信息。提出的 COD-YOLO 检测算法在激光器光学灾变损伤的缺陷检测任务中展现出了良好的识别和定位能力。

3.2 激光器芯片 COD 缺陷检测

3.2.1 COD-YOLO 总体结构

COD-YOLO 缺陷检测网络总体结构如图 3-2 所示。光学灾变损伤缺陷检测器采用可变形的高效聚合模块、基于空间和内容感知的上采样模块、针对光学灾变损伤的坐标回归损失，能够在复杂的背景干扰中匹配损伤缺陷的特征。检测网络主要包含三个部分：特征提取、特征融合以及包含分类与定位功能的检测头。值得注意的是，除改进模块外，其余架构都是参考基础模型 YOLOv7 进行设计。

半导体激光器芯片光学灾变损伤的原始电致发光图像被输入到检测网络，该网络用于提取缺陷的纹理与几何特征。为确保信息完整性和检测准确率，将原始图像像素 640×512 填充至 640×640 ，邻域值的填充可以减少边界对模型性能的影响。图像预处理后，选用 CSP-Darknet^[66] 作为检测器的主干提取缺陷的细节特征，主干网络中的层结构由下采样模块与可变形高效聚合网络构成，旨在有效的提取缺陷不同尺寸和形状的特征。具体来说，通过 3×3 的可变形卷积重构高效聚合模块，经由注意力加权输出，使其拥有学习复杂形状缺陷的能力，同时引入长距离依赖与自适应空间聚合。接着，在特征融合金字塔中嵌入坐标卷积和基于内容感知的上采样结构。底层特征图包含缺陷纹理信息，顶

层特征图包含大量的类别信息,不同尺寸的缺陷信息通过上采样核进行融合,极大提高EL图像中暗线缺陷的特征表示能力。最后,预测结果采用YOLOR^[67]的隐含知识检测头输出,具有学习隐藏在神经网络中无法观察到的隐式知识的能力。通过三个尺度的检测头对不同尺寸的缺陷进行预测,微小缺陷由大尺度检测头预测,包含更多细节信息,小尺度检测头对正常尺寸缺陷进行预测,更多的包含高维的语义信息。上述架构的设计从多方面综合考虑半导体激光器芯片缺陷的特征,提高检测网络的精度。




图 3-2 缺陷检测框架 COD-YOLO

Fig. 3-2 Defect detection framework COD-YOLO

3.2.2 可变形高效聚合网络

提出的可变形高效聚合网络(D-ELAN)利用可变形卷积DCNv3^[62]重构高效聚合模块(Efficient Layer Aggregation Network, ELAN)^[68],自适应学习卷积核的位置与权重,旨在适应不同尺寸和形状的有源区光学灾变损伤,处理EL图像非均匀特征的变化,聚焦于发光区域内的暗线缺陷提高模型精度。从图3-3可以观察到具体结构,特征图将同时输入两通道进行特征提取,一路通道以传统卷积构建,另外一路通道通过可变形卷积堆叠实现。经过不同卷积结构提取的特征进行融合,并应用通道注意力机制(Squeeze-and-Excitation, SE)^[63]得出最终输出。可变形卷积采用动态的稀疏卷积引入长距离依赖和自适应空间聚合,虽然继承自传统卷积但是收敛相对困难。ELAN模块通过控制最长最短的梯度路径,使得深度神经网络能够更有效地学习和收敛,两者融合呈现相互补充与相互促进的关系,共同发挥作用。

腔体缺陷非均匀的分布特征导致难以对缺陷进行有效建模,EL图像还包含不同放大倍率下的缺陷图像。同时不同材料的腔体发生光学灾变损伤后,产生缺陷的表现形式各不相同,例如空心孔洞和暗线缺陷等。DCNv3在保持CNN归纳偏置局部相关性和平移不变性的同时实现稀疏建模,带来长距离空间依赖,更好地平衡计算量和精度。D-

ELAN 模块，在保留特征信息的同时减少收敛时间，有效提高检测精度。SE 注意力被用来构建通道之间的相互依赖关系，更好地捕获图像中的重要特征，使网络能够更加有效地聚焦于关键信息区域，从而增强网络的性能，同时保持一定的计算效率，提高整体网络的检测表现。




图 3-3 可变形高效聚合网络和通道注意力模块结构图

Fig. 3-3 D-ELAN and SE structure diagram




图 3-4 DCNv3 的结构

Fig. 3-4 The structure of DCNv3

如上图 3-4 所示，以 3×3 大小的可变形卷积为例。对输入特征分组 $F \in \mathbb{R}^{H \times W \times C}$ ，每组分别自适应学习偏移信息。具体来说通过卷积操作，学习卷积核中每个像素点的位置偏移以及偏移权重；将分组的动态偏移拼接求和，求解得到偏移的变形核进行卷积计算，经激活函数后得到输出特征 $F' \in \mathbb{R}^{H \times W \times C}$ 。综上所述，下式表示 DCNv3^[62]运算过程：

$$F(a_0) = \text{Silu} \left(\sum_{g=1}^G \sum_{n=1}^N w_g b_{gn} x_g (a_0 + a_n \Delta a_{gn}) \right) \quad (3-1)$$

其中， a_0 表示当前像素点的位置， G 表示对输入特征图进行分组的数量， N 表示卷积核

中总采样点数。对于第 g 组， $w_g \in \mathbb{R}^{C \times C'}$ 代表当前组的权重，其中 $C' = C/G$ 表示每个组的维度。 $b_{gn} \in \mathbb{R}$ 表示第 g 组中的第 n 个采样点的偏置标量。这些偏置通过softmax函数在 N 维度上进行归一化。输入特征图的当前组用 $x_g \in \mathbb{R}^{H \times W \times C'}$ 表示， a_n 表示传统卷积核在以当前位置为中心的采样点位置，即 $(-1, -1) \dots (0, 0) \dots (+1, +1)$ 。 Δa_{gn} 表示第 g 组中卷积核采样点 a_n 的位置偏移。最后， $Silu$ 表示可变形卷积使用的激活函数。

3.2.3 基于空间和内容感知的上采样模块

特征上采样是卷积网络架构的关键操作，在模型颈部的特征金字塔结构中，融合基于空间和内容感知的上采样模块（Spatial-Content-Based Upsampling, SC-UP），旨在上采样特征图时丰富特征内容，增强对缺陷特征的辨别能力。将传统的基于插值的上采样方法和相邻的传统卷积层替换为基于内容感知的特征重组模块（Content-Aware ReAssembly of Features, CARAFE）^[65]和坐标卷积^[69]。坐标卷积能够匹配局部缺陷在整体中的位置信息，基于内容的特征重组动态地学习在大感受野内聚合信息重组特征，使模型保留更多缺陷的特征信息，同时保持高效的计算效率。这些改进的方法共同组成上采样模块，提高缺陷特征的融合能力，进一步提升模型的检测性能。




图 3-5 基于空间和内容感知的上采样模块：坐标卷积和 CARAFE

Fig. 3-5 SC-UP structure: CoordConv and CARAFE

基于空间和内容感知的上采样模块的结构和工作原理如上图 3-5 所示。坐标卷积通过先在特征图中拼接空间维度后再进行卷积运算，用部分平移不变性建模空间信息表达能力^[69]。基于内容的特征重组模块^[65]由两部分组成。第一步，根据内容感知预测上采样卷积核。具体操作包括通过内容编码卷积减少通道数，降低计算量；调整通道数至特定值，由像素重组操作获得预测核。第二步，利用感知的重组核和上采样比例，对当前像素附近区域的特征进行预定义，得到上采样结果。在全局感受野内动态感知生成特征，

适用于捕捉缺陷独特的结构信息。此外，轻量化的结构导致附加的计算开销可忽略不计，同时与上文的可变形卷积相呼应，增强检测网络的整体性能。

3.2.4 针对 COD 的坐标回归损失函数

提出针对光学灾变损伤缺陷的坐标回归损失（COD-Loss）。该损失函数融合了针对微小目标的 NWD 损失函数和目标检测中常用的交并比（Intersection over Union, IoU）损失函数的设计思想。通过对数据集中缺陷真实框的尺寸进行聚类分析，两个损失函数按照相应比例进行协同作用。其中，NWD 损失函数针对微小损伤缺陷的边界框坐标回归策略，IoU 损失偏向计算正常缺陷的坐标回归。线性叠加的比例是基于实验结果的经验值，针对不同数据集进行对应调整。优化不同尺寸缺陷边界框的回归度量标准，提升微小缺陷的检测精度。

损失函数在机器学习任务中具有至关重要的作用，作为模型优化的目标函数，用于度量预测结果与真实值之间的差异。在应对信息匮乏的微小缺陷时，IoU 损失函数的评价标准会导致预测框的分配错误。如图 3-6 所示，A 表示真实框，B 和 C 分别代表不同的预测框。对于微小目标，当预测框由 B 变为预测框 C 时，尽管偏移量很小，但与真实框之间的交并比却发生显著下降。相比于正常尺寸的缺陷，位置偏移对交并比的影响相对较少。综上所述，针对微小缺陷，轻微的位置偏移会导致交并比的显著降低，IoU 损失在处理多尺寸缺陷时会产生错误的梯度。




图 3-6 不同尺寸缺陷边界框交并比差异

Fig. 3-6 Differences in IoU for defect bounding boxes at various scales

为解决上述问题，针对不同尺寸形状的缺陷，在 IoU 损失的基础上线性叠加 NWD 损失函数。NWD 损失用于对微小光学灾变损伤缺陷进行坐标回归，函数涉及将真实框和预测框建模为二维正态分布，计算正态分布之间的归一化 Wasserstein 距离^[64]。公式 3-2 表示了预测框和真实框建模后的 Wasserstein 距离。

$$W_2^2(N_a, N_b) = \left\| \left[cx_a, cy_a, \frac{w_a}{2}, \frac{h_a}{2} \right]^T, \left[cx_b, cy_b, \frac{w_b}{2}, \frac{h_b}{2} \right]^T \right\|_2^2 \quad (3-2)$$

其中， cx 和 cy 表示边界框中心点的坐标， w 和 h 分别表示边界框的宽度和高度， $\|_2^2$ 表

示欧几里得范数。经归一化处理后,映射为模型的NWD损失函数,其定义如下:

$$Loss_{nwd} = 1 - \exp\left(-\frac{\sqrt{W_2^2(N_a, N_b)}}{C}\right) \quad (3-3)$$

上述公式中, C 代表数据集中缺陷大小的平均值。将两种针对不同尺寸的坐标回归损失函数线性组合,得到针对光学灾变损伤的坐标回归损失函数,定义为:

$$Loss_{COD} = \lambda Loss_{iou} + (1 - \lambda) Loss_{nwd} \quad (3-4)$$

3.3 实验结果与分析

3.3.1 数据集

原始数据来源于 EL 图像,能够依据光学灾变损伤的位置进行缺陷检测。接通电源后,有源区中没有缺陷的部分由于电子和空穴复合发出光子,没有电子和空穴符合的部分呈现暗缺陷。由于有源区位于芯片内部,为采集到有源区光学灾变损伤的 EL 图像,需要对芯片进行破坏性失效分析。相较于传统的刻蚀技术,采用更有效率的抛光技术。从芯片背面采用倾斜抛光技术,去除衬底和部分 N 极电极,保留少部分电极用于探针供电。破坏后样品的接通电流维持在 1 毫安左右,调整环境的红外光拍摄到清晰的电致发光鸟瞰图。由于激发电流的差异,芯片 EL 图像的亮度显示出不一致的特性。

原始数据总共包含 376 张分辨率为 640×512 的缺陷图像,由自行设计的图像采集系统和武汉光迅科技股份有限公司共同提供。采集过程相对繁琐,需要在可见光下使用光学显微镜,操作探针给芯片供电,切换红外光通过红外 CCD 相机拍摄,型号 PSEL-VGA-15um,光谱响应范围 900-1700nm,曝光时间 30us。采用数据增强对原始数据进行扩增,包括旋转、翻折和高斯噪声等。最终,构建 3766 张具有光学灾变损伤的缺陷数据集,评估 COD-YOLO 模型的分类和检测效果。使用开源标注软件(Labelimg)进行 YOLO 格式的标注,标注过程只需使用边界框紧密地框住缺陷即可,不需要具备先验知识,结果保存为 TXT 格式文件,扩增后数据集的分布如表 3-1 所示。

表 3-1 光学灾变损伤缺陷数据集分布

Table 3-1 Distribution of COD defect dataset

数据集(扩增后)	缺陷图像	COMD	COBD
训练集	2710		
验证集	302	2819	1646
测试集	754		
总量	3766	2819	1646

3.3.2 评价指标

本章节通过以下多个评价指标全面的评估模型的性能。使用平均精度（Average Precision, AP）和平均精度均值（mean Average Precision, mAP），参数量（#Params），运算量（FLOPs）等来评估缺陷检测方法的性能。AP 和 mAP 分别适用于评估单类别和多类别的平均精度。平均精度通过绘制精确率-召回率曲线（Precision-Recall, P-R），计算曲线下面积得出，能全面地评估模型在不同置信度下的性能，计算公式如式 3-5 所示。

$$AP = \int_0^1 Precision(Recall) dRecall \quad (3-5)$$

mAP 则对所有类别的 AP 的均值，反映了模型在整体上的性能。

$$mAP = \frac{1}{m} \sum_{i=1}^m AP_m \quad (3-6)$$

在计算 mAP 时需要考虑不同 IoU 的情况，以适用于不同的应用场景。当网络预测的图像框与真实图像框的 IoU 大于阈值时，即认为该预测框能正确匹配缺陷。根据 IoU 阈值变化，可以计算多个 mAP 结果，包括：mAP (IoU=0.5)、mAP (IoU=0.75) 和 mAP (IoU=0.5:0.05:0.95)。同时，通过 APS (Small)、APM (Medium) 和 APL (Large) 等指标来深入分析模型对不同尺寸缺陷的检测能力，分别对应目标像素大小为：小于 32×32 ，大于 32×32 但小于 96×96 ，大于 96×96 。鉴于光学灾变损伤缺陷微小，因此主要参考 APS 进行模型评价。此外，还测试网络的推理速度，参数量、计算量、FPS（每秒检测图像的数量）和推理时间（Latency）等进行评估。此外，为进一步评价模型分类结果，采用精确率（Precision, P），召回率（Recall, R）和混淆矩阵分析模型的分类表现。综合考虑以上所有评价指标，全面了解所提出的缺陷检测器在不同场景下的性能表现，并据此对其实际应用价值进行评估。

$$IoU = \frac{Ground\ True \cap Prediction\ Box}{Ground\ True \cup Prediction\ Box} \quad (3-7)$$

$$Precision = \frac{TP}{TP + FP} \quad (3-8)$$

$$Recall = \frac{TP}{TP + FN} \quad (3-9)$$

其中，TP（True Positive）指的是模型成功检测到的缺陷数量。FP（False Positive）表示模型错误地将非缺陷预测为缺陷的数目。FN（False Negative）表示模型未能正确检测到的缺陷数量。IoU 用于衡量边界框与真实框之间的重叠程度。

3.3.3 实验细节

本章实验中，COD-YOLO 基于 PyTorch 框架进行搭建。实验在配置有 Intel Core i9-

10900X CPU 和 NVIDIA GeForce RTX 3090 GPU 的服务器上进行。数据集按照 7:1:2 的比例划分为训练集、验证集和测试集，训练集用以训练模型，验证集评估结果，测试集模拟实际应用中的表现。经过不断实验调整，Batch size 设定 24，最大迭代次数 300 轮。选用随机梯度下降（Stochastic Gradient Descent，SGD）优化器更新权重进行梯度下降，初始学习率为 0.01，同时应用权重衰减策略。如表 3-2 所示，详细的参数设定可以帮助更好地理解实验。需要注意的是，在实际应用中，应使用预训练权重进行模型微调，以提高在有限数据下的收敛速度和检测精度。

表 3-2 COD-YOLO 模型的超参数

Table 3-2 Hyperparameters of COD-YOLO

训练	权重衰减	初始学习率	周期学习率	动量	mosica 增强
	0.0005	0.01	0.1	2819	True
	最大迭代	输入图像	Batch size	优化器	预热
	300	(640,640)	24	SGD	True
测试	分类阈值		非极大值抑制阈值		mosica 增强
	0.25		0.45		False

3.3.4 结果与讨论

在本节中比较所提出的 COD-YOLO 算法与 YOLO 系列及基于 Transformer 的目标检测算法的性能。所提出的改进模块在一定程度上增强模型对微小光学灾变损伤缺陷的特征表达能力，提升激光器芯片有源区 COD 缺陷的检测效果，实验结果如表 3-3 所示。

表 3-3 不同检测方法的对比实验结果

Table 3-3 Comparative experimental results of different detection methods

模型	mAP	mAP(IoU=0.5)	mAP(IoU=0.75)	#Params(M)	Flops(G)	FPS	Time(ms)
YOLOR	50.5%	63.5%	53.1%	52.92	121.0	54	18.4
YOLOX	65.1%	93.7%	73.8%	54.15	155.6	37	27.3
YOLOv5	67.5%	93.7%	77.3%	46.11	107.7	98	10.2
DETR	53.2%	93.2%	54.6%	41.28	86.0	24	41.2
YOLOv6	69.0%	94.1%	77.1%	59.54	150.5	62	16.1
YOLOv7	65.9%	91.4%	74.6%	36.48	103.2	87	14.1
COD-YOLO	68.0%	94.7%	76.5%	35.56	99.4	51	19.7

为验证 COD-YOLO 模型性能，与先进的 YOLO 系列实时目标检测器进行对比实验，选取 YOLO 架构进行对比的主要原因在于网络有着相似的整体结构。针对光学灾变损伤的缺陷检测，COD-YOLO 相较于基础模型 YOLOv7^[40]，在检测精度方面实现全面

提升,检测精度达到 94.7%,在 mAP 和 mAP (IoU=0.5) 分别提升 2.1%和 3.3%。计算量和参数量也分别减少 2.6%和 3.8%。但是由于可变形卷积需要将数据搬运到 GPU 进行推理导致推理速度和时间的延长。另外,从 YOLOR^[67]的实验结果能够观察到,其在芯片缺陷检测任务中的表现不佳,精度远低于其他算法。虽然检测速度较快,但无法满足实际应用的精度要求,无法有效地检测细微或模糊的损伤缺陷。COD-YOLO 与无锚框 (Anchor-Free) 的 YOLOX^[70]算法相比,检测精度 mAP (IoU=0.5) 提高近 1%,推理时延缩短约三分之一,同基于 Transformer 的目标检测网络 DETR^[71]相比,推理速度提升一倍多,表明 Transformer 架构目前尚不能满足推理速度的要求。此外,比较 COD-YOLO 和 YOLOv5 发现,模型在减少了 29.6%参数量和 8.4%计算量的同时精度提升近 1%。对于在缺陷检测中经常使用的 mAP (IoU=0.5) 指标, COD-YOLO 与相近推理时延的网络 YOLOv6^[72]相比提升 0.6%。综合而言,本章所提出的模型 COD-YOLO 在特定场景下的激光器芯片光学灾变损伤缺陷检测的任务中取得精度和速度的良好平衡。

进一步强调 COD-YOLO 模型提升了对微小缺陷的检测能力,通过 APS, APM, APL 指标对不同尺寸缺陷进行有效评估,见下表 3-4。COD-YOLO 在小缺陷检测上表现最为出色,APS 达到 55.8%。针对中等大小和较大尺寸的缺陷,也表现出良好的性能标准,APM 和 APL 分别达到 77.1%和 77.6%。进一步分析推理时性能,单图像推理的延迟为 19.7 毫秒, FPS 为 51,较慢的推理速度归因于可变形卷积约束造成的数据搬运。

表 3-4 不同尺寸缺陷下检测模型性能比较

Table 3-4 Comparison of detection model performance under different size defects

模型	APS	APM	APL
YOLOR	38.3%	46.0%	56.3%
YOLOX	49.9%	75.0%	80.0%
YOLOv5	55.7%	74.8%	71.0%
DETR	36.5%	66.1%	85.4%
YOLOv6	53.5%	78.3%	72.9%
YOLOv7	52.7%	74.9%	71.2%
COD-YOLO	55.8%	77.1%	77.6%

在深入分析对比实验后,为更加清晰地展示数据,通过可视化手段直观阐述检测结果间的差异。在图 3-7 中对比 4 种网络模型的可视化缺陷检测结果,可以观察到 COD-YOLO 在识别和定位缺陷方面表现出色。相比之下,其他模型在某些情况下可能存在一些漏检或误检。图 3-8 中 COD-YOLO 的 CAM 热力图提供了关于模型关注的具体位置的宝贵信息。通过类激活映射可以清晰地看到模型对于缺陷区域的关注程度,这有助于理解模型是如何定位和识别缺陷的。可视化结果不仅增强了对模型性能的解释,而且为

缺陷检测算法的进一步优化和调整提供了有力的指导。




图 3-7 对比实验的可视化检测结果

Fig. 3-7 Visual detection results of the comparison experiment




图 3-8 COD-YOLO 类激活热力图

Fig. 3-8 CAM visualization results for COD-YOLO

评估 COD-YOLO 的分类性能，其精确率为 96.8%，召回率为 91.3%。高召回率保证在智能制造过程中存在缺陷的激光器芯片不容易被忽视，这对芯片的可靠性分析至关重要。通过绘制混淆矩阵进行综合评价，如图 3-9 所示。该混淆矩阵清晰地显示两种不同类型的光学灾变损伤缺陷被明确地区分。值得注意的是，对于本章所提出的模型，在混

淆矩阵的对角线上可观察到,CODM 类别的灵敏度为 93%,COBD 类别的灵敏度为 94%。在 COD-YOLO 的混淆矩阵中,只有 1%的 COBD 被错误分类为 CODM,但也存在将背景错误识别为缺陷的风险。




图 3-9 混淆矩阵

Fig. 3-9 Confusion matrix

网络架构和训练相关的超参数对于深度学习模型的性能和泛化能力至关重要。这些超参数包括但不限于学习率、Batch size、优化器类型、正则化参数等,它们的选择直接影响着模型在训练集和测试集上的表现。在实际应用中,优化超参数是深度学习工程师和研究人员经常需要面临的挑战之一。接下来的实验以 COD-YOLO 模型为基线,针对 Batch size 和优化器这两个关键的超参数展开了详细的实验研究。尝试不同 Batch size(8、16、24)和优化器(SGD、Adam)的组合,以探索其对模型性能的影响。根据检测精度分析,在表 3-5 中选择最优的超参数组合(Batch size 为 24,优化器为 SGD)。

表 3-5 不同超参数实验结果比较

Table 3-5 Results comparison with different hyperparameters

超参数	mAP	mAP(IoU=0.50)	mAP(IoU=0.75)
Batch size 24	68.0%	94.7%	76.5%
Batch size 16	67.3%	93.5%	77.0%
Batch size 8	65.5%	93.8%	73.8%
SGD 优化器	68.0%	94.7%	76.5%
Adam 优化器	66.9%	93.5%	75.7%

采用逐步添加模块的策略进行了消融研究,以验证改进模型的有效性。从表 3-6 的实验结果中可以观察到,通过引入可变形的高效聚合模块,基础模型的 mAP(IoU=0.5)提升 1.4%。在针对光学灾变损伤的坐标回归损失和基于空间和内容感知的上采样共同作用下,模型相较之前提高 1.2%。最终,在引入了注意力机制和检测头的坐标卷积进行微调后,COD-YOLO 的最终精度 mAP 达到 68%,mAP(IoU=0.5)达到 94.7%。改进模块的协同作用使得检测网络性能逐步提升,从而验证优化结构的有效性。

表 3-6 COD-YOLO 检测器消融实验

Table 3-6 Study of ablation of the COD-YOLO detector

模型	P	R	mAP	mAP(IoU=0.5)	#Params(M)
YOLOv7	94.7%	87.0%	65.9%	91.4%	36.48
YOLOv7+D-ELAN	96.0%	89.5%	64.0%	92.8%	35.09
YOLOv7+D-ELAN+COD-Loss	98.4%	89.0%	65.6%	93.0%	35.09
YOLOv7+D-ELAN+COD-Loss+SC-UP	96.9%	90.9%	67.6%	94.0%	35.24
COD-YOLO	96.8%	91.3%	68.0%	94.7%	35.56

在表 3-7 中，基于 D-ELAN 模块设计不同结构组合的实验。对比四种不同的结构组合，其中对号表示使用 D-ELAN 代替主干不同层中的 ELAN 结构。通过比较检测精度，可发现可变形卷积能够在深层维度中更精确地拟合缺陷的特征信息。然而，也可以观察到，连续堆叠过多的可变形卷积层会导致网络性能的下降，因为随着层数的加深，可变形卷积所附加的计算量和参数量也会同时增加。从图 3-10 中可以观察到不同结构组合的准确率变化曲线，其中红色线代表的（a）结构具有较高的准确率。最终，COD-YOLO 采用结构（a）的组合，在 mAP 上最大提高 3.2%。该结构策略在有限的计算资源下具有较好的检测精度，实现缺陷检测中性能与参数量之间的平衡。

表 3-7 模型主干不同结构组合实验结果

Table 3-7 Experimental results of different structural combinations in the backbone

结构	Layer1	Layer2	Layer3	Layer4	mAP	mAP(IoU=0.5)
(a)		✓		✓	68.0%	94.7%
(b)	✓		✓		65.3%	91.8%
(c)	✓			✓	64.8%	92.5%
(d)			✓	✓	66.4%	92.8%




图 3-10 模型主干不同结构组合的精度变化

Fig. 3-10 AP variations with different combinations of backbone structures

在图 3-11 中，进行了坐标回归损失的消融实验，以验证 COD-Loss 对于缺陷边界框回归的有效性。COD-Loss 主要通过 NWD 与 IoU 损失的协同作用，评估预测框与真实框之间的梯度损失。实验验证损失函数不同线性叠加的效果，以评价 NWD 损失在坐标回归损失中的作用。蓝色线表示 $\lambda=1$ 的 COD-Loss 只使用 IoU 损失函数；橙色线表示 $\lambda=0.7$ 的 COD-Loss 开始使用 NWD 损失，其中该损失所占比重较小；绿色线表示 $\lambda=0.5$ 的 COD-Loss，其中 NWD 损失比例增加。从图中明显观察到，COD-Loss 的使用有效地降低边界框坐标回归损失。当 NWD 损失函数所占比重增加时，缺陷边界框的坐标回归损失越低，同时目标损失和类别损失保持原有性能不变。




图 3-11 不同损失函数的性能分析，其中蓝色表示 $\lambda=1$ 的 COD-Loss 损失即 IoU 损失，橙色表示 $\lambda=0.7$ 的 COD-Loss 损失，绿色表示 $\lambda=0.5$ 的 COD-Loss 损失

Fig. 3-11 Performance analysis of different loss functions, where the blue represents IoU loss, the orange line represents COD-Loss with $\lambda=0.7$, and the green represents COD-Loss with $\lambda=0.5$

通过注意力消融实验验证使用不同注意力模块搭建的 COD-YOLO 算法的性能。实验使用相同超参数确保公平。结果见表 3-8，使用的注意力包括：SE 注意力^[63]、Coordinate 注意力^[73]、CBAM^[74]、Shuffle 注意力^[75]和 SimAM^[76]。尽管各注意力对检测器参数量的影响可忽略不计，但对精度的影响显著。SE 注意力在相同参数量下实现最佳结果，检测精度最大提高 1.8%。

表 3-8 不同注意力机制的消融实验

Table 3-8 Ablation experiments using different attention mechanisms

注意力机制	mAP	mAP(IoU=0.5)	Flops
SE 注意力	68.0%	94.7%	99.4G
Coordinate 注意力	67.7%	94.0%	99.6G
CBAM	67.0%	93.6%	99.8G
Shuffle 注意力	67.5%	93.8%	99.2G
SimAM	65.4%	92.9%	99.2G

可视化检测结果是对模型性能直观评估的重要组成部分。它不仅提供结果的解释性，还能验证模型是否准确识别和定位缺陷。在图 3-12 中，对 6 幅代表性的缺陷图像进行了详细的定性分析。每张图片的左下角显示缺陷区域的放大图，并通过红色圆圈标示出




图 3-12 YOLOv7 和 COD-YOLO 的可视化结果

Fig. 3-12 Visualizing results: YOLOv7 vs our COD-YOLO

检测错误。值得注意的是,在这项分析中,COD-YOLO 模型没有出现明显的检测错误,而 YOLOv7 则存在 1 次误检情况。这些实验结果进一步证明 COD-YOLO 在准确率和误检率方面的出色表现,表明其具有更高的鲁棒性。特别值得一提的是,在复杂背景干扰的情况下,COD-YOLO 相较于 YOLOv7 实现更为准确的缺陷位置预测。对比实验进一步验证 COD-YOLO 模型在激光器芯片缺陷检测任务中的优越性,为芯片缺陷检测提供更可靠的解决方案。

为验证模型的通用性和泛化性,在开源的工业缺陷数据集 NEU-DET^[77]上进行对比试验,热轧钢带表面缺陷数据共包含 6 种缺陷类别,分别是氧化铁皮压入(rolled-in scale, RS)、斑块(patch, Pa)、开裂(crazing, Cr)、麻点(pitted surface, PS)、夹杂(inclusion, In)和划痕(scratches, Sc)。其中每个类别包含 300 张 200×200 像素大小的图像,共 1800 张缺陷灰度图。训练验证集比率 8:2,输入图片填充到 224×224 像素点,其余实验参数未进行改动,实验结果见下表 3-9,在复杂的工业缺陷数据中,COD-YOLO 模型仍保持良好的实验表现。

表 3-9 钢材表面缺陷数据集通用性实验结果

Table 3-9 Universality experiment results on the NEU-DET dataset

模型	mAP(IoU=0.5)	氧化铁皮压入	斑块	开裂	麻点	夹杂	划痕
YOLOv5	77.3%	66.3%	93.2%	46.8%	84.3%	79.8%	93.5%
YOLOv6	76.1%	62.0%	94.8%	45.2%	84.4%	77.4%	92.8%
YOLOv7	76.0%	59.2%	93.1%	43.6%	86.4%	80.2%	93.8%
COD-YOLO	77.5%	62.5%	94.0%	43.3%	89.7%	81.3%	94.3%

3.4 本章小结

本章详细介绍针对半导体激光器芯片有源区光学灾变损伤的缺陷检测模型 COD-YOLO。该模型的构建基于实时目标检测网络 YOLOv7,在此基础上融合提出的可变形高效聚合网络、结合空间和内容感知的上采样模块以及针对光学灾变损伤的坐标回归损失函数。这些改进使 COD-YOLO 能够在 EL 图像中准确地识别出 COMD 和 COBD 两类缺陷,尤其在处理多尺度 COD 缺陷方面显示出良好的性能。实验结果验证 COD-YOLO 在光学灾变损伤缺陷检测领域的出色表现,其定量检测精度高达 94.7%,优于现有的检测网络。此外,COD-YOLO 在开源钢材表面缺陷数据集 NEU-DET 进行的通用性实验,展示该模型在工业缺陷检测任务中具有一定应用潜力。

第4章 基于轻量化 CNN 的 COD 缺陷检测与模型部署

4.1 引言

第3章聚焦于提升激光器芯片有源区 COD 缺陷检测精度的问题,特别是针对 COMD 和 COBD 的缺陷识别进行探讨。虽然所构建的 COD-YOLO 缺陷检测模型利用深层特征表达增强缺陷检测的精度,但在实际应用中面临由设备计算资源限制引起的挑战,影响模型在图像采集系统中的应用。针对上述问题,第4章将深入探讨轻量级的激光器芯片 COD 缺陷检测与模型的高效部署。




图 4-1 缺陷检测系统的工作流程图

Fig. 4-1 The workflow of the COD defect detection system

激光器芯片有源区缺陷图像的获取依赖于专门的图像采集设备。为深入理解和展示智能缺陷检测系统的工作机制,本文绘制展示该系统工作流程的简图,见图 4-1 所示。该系统主要分为三个关键阶段:数据采集、缺陷检测以及缺陷识别结果的实时显示。该系统能够实时识别激光器芯片 COD 的类型和位置,从而有效地执行检测任务。具体来说,缺陷 EL 图像数据集通过采集设备获得,然后通过数据增强和预处理步骤进行处理,用于训练深度学习缺陷检测模型。最终,将缺陷检测算法部署到采集系统中,实现在图像采集过程中对缺陷的实时检测,以准确识别缺陷的种类并确定其位置信息。这不仅增

强实时数据的处理能力，还为深入理解损伤产生的机理提供关键支持。本章的重点是探究如何在该系统框架内实现轻量级 COD 缺陷检测模型的设计与部署，确保检测算法在系统中高效准确运行。

在计算机视觉领域，深度学习技术因其深层的特征识别能力而被广泛应用，尤其在缺陷检测等任务中，展现其卓越的准确性和稳定性。然而，深度学习模型通常需要大量的参数和计算资源，这不可避免地依赖于高性能的硬件，如 GPU，来支持这类计算密集型任务。在缺陷检测流程中，模型的训练和部署是至关重要的两个环节。部署阶段的主要任务是将训练好的神经网络模型应用于实际生产环境，实现数据的即时处理和结果的快速预测。但在执行工业级芯片检测等高标准任务时，模型的部署面临实时性能、成本效益以及环境适配性等多重挑战。为克服这些挑战，本章从多个维度全面考虑，包括部署环境、模型转换、部署策略和性能评估，确定了适用于本研究的缺陷检测模型的高效部署方案。

本章详细介绍针对激光器芯片 COD 缺陷检测模型的轻量级设计及其部署策略。为解决轻量化的挑战，本文开发轻量级的激光器芯片 COD 缺陷检测模型，通过简化网络结构和减少参数量来降低计算复杂度。关键策略包括采用如 MobileNetv3^[29]和 FasterNet^[31]等轻量化卷积神经网络作为模型特征提取主干，以提升模型的推理效率。面对轻量化模型的特征表达能力欠缺的挑战，本章引入 Diverse Branch Block (DBB)^[78]模块，该训练与推理解耦的模块在特征融合结构中提升模型对不同层次特征信息的捕捉能力，增强模型性能和通用性。此外，采用模型压缩中的剪枝技术，针对深度学习模型中的参数冗余问题进行了细致的优化。通过合理删除不必要的权重参数，实现模型计算和存储成本的降低，同时保持接近原始结构的性能。在完成上述一系列优化后，模型被成功部署到图像采集设备的本地服务器，确保算法在实际环境中的有效应用，使质量筛选环节能够高效执行缺陷检测任务。

4.2 轻量级激光器芯片 COD 缺陷检测

4.2.1 Fast-COD-YOLO 总体结构

本节介绍设计的轻量级激光器芯片 COD 缺陷检测模型 Fast-COD-YOLO，旨在通过结合轻量化特征提取主干和类 Inception^[25]结构的 DBB 模块，提供高效且精确的检测框架。Fast-COD-YOLO 的架构细节如图 4-2 所示，该模型基于经典的 YOLOv7-Tiny^[40]架构，并细分为特征提取、特征融合和检测头三个关键部分。在特征提取阶段，选择轻量化网络 FasterNet^[31]和 MobileNetv3^[29]作为主干模块，优化了计算资源使用，并提升模型的部署效率。在特征融合阶段的轻量高效聚合网络中引入 DBB 模块 (DBB-ELAN)。该模块采用多分支结构，增强特征的空间映射能力，有效提升模型的检测精度。DBB 模块

的重参数化设计不仅保持推理时的速度，而且提高模型的检测性能。此外，Fast-COD-YOLO 在保留 YOLOv7-Tiny 设计精髓的同时，通过这些优化结构，保持轻量级缺陷检测模型在光学灾变损伤数据集中的应用表现。




图 4-2 轻量级光学灾变损伤缺陷检测模型总体结构

Fig. 4-2 Lightweight model architecture for COD defect detection

轻量级光学灾变损伤缺陷检测算法 Fast-COD-YOLO 结合轻量化主干和 DBB 结构，以高效地捕获激光器芯片缺陷特征。该模型的整体架构分为四个核心阶段。首先，在预处理阶段，输入的电致发光图像尺寸从 640×512 调整至 640×640 ，使用零填充法补全图像。随后，特征提取阶段采用轻量化卷积神经网络作为主干，目的是抽取缺陷的语义信息并降低参数数量。在特征融合阶段，DBB-ELAN 结构被用于融合不同层次的特征图 L2、L3、L4，其中 DBB 模块的引入优化信息聚合能力，增强特征表征。最后，模型通过三个不同尺度的检测头细化并预测缺陷特征，输出包含分类类别和位置坐标的预测张量，从而针对各种尺寸的缺陷进行有效检测。上述设计旨在减少模型参数的同时，确保良好的检测性能。

损失函数在评估模型性能中扮演着至关重要的角色。借鉴原始 YOLOv7-Tiny 模型，损失函数由三部分组成：分类损失、目标损失和坐标回归损失。尽管在第 3 章中的 COD-YOLO 模型中对坐标回归损失进行了专门的优化，但本章中仍使用原始损失函数保持效率，具体包括以下几部分：

$$Loss = 0.1Loss_{obj} + 0.125Loss_{cls} + 0.05Loss_{iou} \quad (4-1)$$

$$Loss_{BCE} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] \quad (4-2)$$

$$Loss_{CIoU} = 1 - IoU + \frac{\rho^2(b, b^{gt})}{c^2} + \alpha v \quad (4-3)$$

$$\alpha = \frac{v}{(1 - IoU) + v}, v = \frac{4}{\pi^2} \left(\arctan \frac{w_{gt}}{h_{gt}} - \arctan \frac{w}{h} \right)^2 \quad (4-4)$$

其中，分类损失和目标损失采用二元交叉熵损失进行计算，坐标回归损失使用 CIoU 损失。在 CIoU^[79]损失公式中， b 和 b^{gt} 分别代表预测框和真实框的中心点， ρ^2 表示欧式距离， c 表示最小闭包矩形对角线长度， α 是权重函数， v 用于衡量边界框长宽比一致性。通过损失函数的约束，模型能够逐步收敛，从而实现高精度检测任务。

4.2.2 轻量化特征提取主干

本章提出的采用轻量化网络 MobileNetv3^[29]和 FasterNet^[31]替代原始的卷积神经网络，作为 Fast-COD-YOLO 的特征提取主干。该替换旨在本地缺陷图像采集系统实现更高效的图像分类和目标检测。首先，在本节详细介绍基于 MobileNetv3 改进的轻量化主干网络。该网络的核心是采用倒残差结构的深度可分离卷积模块，此设计显著降低模型的参数量和计算量。MobileNetv3 通过神经网络搜索技术优化特征提取网络的参数，并在倒残差模块中集成通道注意力机制，如图 4-3 所展示，以增强对重要通道维度的关注。本节使用的是 MobileNetv3-small 作为主干网络，详细结构见表 4-1。




图 4-3 基于 MobileNetv3 的主干

Fig. 4-3 Backbone based on MobileNetv3

倒残差结构能够有效的优化深层网络中的梯度传递，防止梯度消失或爆炸现象出现，从而提高模型训练的效率。该结构通过特征层间的捷径连接，加深模型深度，有助于减少不必要的特征提取，从而减轻过拟合现象并增强模型的泛化能力。深层网络结构的采

用进一步增强对数据的表征能力,提高图像处理的效果。在计算机视觉任务中,注意力机制的引入有助于网络集中处理缺陷图像关键部位的信息。特别是 SE 注意力机制,在增强模型对关键特征捕捉的同时,提升计算的效率,为模型带来性能上的改善。通过建立通道间的依赖,该机制能够精确地聚焦于缺陷图像中的重要信息,从而优化网络的性能表现。

表 4-1 MobileNetv3 网络结构

Table 4-1 Architecture of MobileNetv3

输入大小	卷积大小	输出通道	步长	通道注意力	激活函数
$640^2 \times 3$	Conv	16	2		h-swish
$320^2 \times 16$	倒残差结构 3×3	16	1		relu
$320^2 \times 16$	倒残差结构 3×3	24	2		relu
$160^2 \times 24$	倒残差结构 3×3	24	1		relu
$160^2 \times 24$	倒残差结构 5×5	40	2	✓	relu
$80^2 \times 40$	倒残差结构 5×5	40	1	✓	relu
$80^2 \times 40$	倒残差结构 5×5	40	1	✓	relu
$80^2 \times 40$	倒残差结构 3×3	80	2		h-swish
$40^2 \times 80$	倒残差结构 3×3	80	1		h-swish
$40^2 \times 80$	倒残差结构 3×3	80	1		h-swish
$40^2 \times 80$	倒残差结构 3×3	80	1		h-swish
$40^2 \times 80$	倒残差结构 3×3	112	1	✓	h-swish
$40^2 \times 112$	倒残差结构 3×3	112	1	✓	h-swish
$40^2 \times 112$	倒残差结构 5×5	160	2	✓	h-swish
$20^2 \times 160$	倒残差结构 5×5	160	1	✓	h-swish
$20^2 \times 160$	倒残差结构 5×5	160	1	✓	h-swish

尽管深度可分离卷积在减少参数量和计算量方面表现出色,但其对存储器的频繁访问增加在资源受限设备上的内存访问次数,导致延迟增加,进而影响了整体的推理速度。为了解决这个问题,采用了轻量化特征提取模型 FasterNet^[31]来充当 Fast-COD-YOLO 模型的特征提取主干。FasterNet 的核心卷积模块是 Partial Conv (PConv),该模块通过利用特征图在不同通道间的相似冗余优化传统卷积过程,减少参数数量和内存访问的开销。与深度可分离卷积相似,PConv 后接逐点卷积形成有效的 T 形感受野,突出中心位置的特征提取。FasterNet 的主干网络结构如图 4-4 所示,其设计简洁,由四个顺序连接的部分组成,每部分包含常规卷积和 PConv,其中常规卷积用于扩展通道数并进行空间维度的下采样。同时,引入 BN 归一化和 GELU 激活函数,以确保特征提取的多样性和高效

的推理速度。




图 4-4 基于 FasterNet 的主干

Fig. 4-4 Architecture of FasterNet

4.2.3 Diverse Branch Block 模块

轻量级 COD 缺陷检测模型旨在减少参数数量和计算负载，但这往往会对检测精度造成一定影响。特别是在网络传播过程中，激光器芯片 COD 缺陷的细节特征可能会部分丢失，影响模型的识别和定位性能。为丰富模型对缺陷特征的表达能力，本章引入基于 DBB^[78]模块的高效聚合网络（DBB-ELAN），该网络通过多分支并联拓扑结构，优化了缺陷特征的提取和融合过程。DBB-ELAN 的核心是对 YOLOv7-Tiny 结构中的轻量的高效聚合模块进行了重构，使其能够在特征融合阶段有效提升特征的表现力。与第 3 章改进主干网络不同，这种改进的多分支聚合结构能够更有效地整合主干网络提取的特征，即使在保持轻量化的同时，也能显著增强模型对缺陷的检测精度和鲁棒性。DBB 结构通过融合多个不同尺度和复杂度的分支，强化模型对细微缺陷的识别能力。此外，DBB 模块的训练和推理解耦特性仅增加训练阶段的计算复杂度，在推理阶段可以简化为单一卷积层，优化了推理效率。

图 4-5 展示使用的类 Inception 结构的 DBB 模块的详细构造。在训练过程中，特征图被分别传入四个不同的分支，每个分支提取特定的缺陷特征： 1×1 分支、 1×1 和 $K \times K$ 分支、 1×1 和平均池化下采样分支以及 $K \times K$ 分支。这些分支处理后的特征图相加结合，并通过非线性层得到最终输出，增强了模型的特征表达能力。每个卷积操作后都关联 BN 层归一化以增强模型的非线性表达。多尺度卷积并联架构能够有效地捕获并整合不同尺寸缺陷的特征信息，有效提升了网络的性能表现。在推理阶段，分支结构被融合成简化的 $K \times K$ 卷积层，实现了从复杂到简单的结构转换，优化了推理效率。总体而言，

DBB 模块通过在训练阶段提升模型性能的同时，保证了推理阶段的高效性。




图 4-5 DBB 结构

Fig. 4-5 Structure of DBB

DBB 结构的优化得益于结构重参数化技术的设计。这一技术在训练阶段允许将单个模块拆分成多个相同或不同的模块分支，并在推理阶段将多分支结构整合成功能等效的单一模块。其中经典的融合方法是将卷积层和 BN 层的线性计算合并，省略归一化层的独立计算，从而提升了网络的推理效率。在整个过程中，归一化层充当了中介，确保合并的有效性和无缝性。下面将详细介绍合并过程：

$$x_1 = w \times x + b \quad (4-5)$$

$$x_2 = \gamma \times \frac{x_1 - \mu}{\sqrt{\sigma^2 + \varepsilon}} + \beta \quad (4-6)$$

上述公式表示合并前的卷积 x_1 和归一化 x_2 操作，其中 μ 和 σ 分别代表均值和方差。对两线性计算层进行合并：

$$x_2 = \gamma \times \frac{w \times x + b - \mu}{\sqrt{\sigma^2 + \varepsilon}} + \beta = \frac{\gamma \times w}{\sqrt{\sigma^2 + \varepsilon}} \times x + \beta + \gamma \times \frac{b - \mu}{\sqrt{\sigma^2 + \varepsilon}} \quad (4-7)$$

在此基础上重新定义权重 $\bar{w}$ 和偏置 $\bar{b}$ ，得到合并后的公式：

$$\bar{w} = \frac{\gamma \times w}{\sqrt{\sigma^2 + \varepsilon}}, \bar{b} = \beta + \gamma \times \frac{b - \mu}{\sqrt{\sigma^2 + \varepsilon}} \quad (4-8)$$

$$x_2 = \bar{w} \times x + \bar{b} \quad (4-9)$$

4.2.4 实验结果与讨论

为了评估所提出方法的有效性，对激光器芯片 EL 有源区 COD 缺陷数据集进行一系列对比实验。实验结果表明，在具有挑战的微小缺陷检测任务中，轻量级模型 Fast-

COD-YOLO 的性能相比以前的方法实验结果有一定提升。在以下部分，我们简单介绍数据集和实验细节，然后提供一系列实验结果和讨论验证提出算法的有效性。

本章实验中数据集依旧选用在第 3 章实验中制作的 DFB 激光器有源区光学灾变损伤缺陷数据集，总共包含 3766 缺陷 EL 图像，通过红外 CCD 相机在 200 放大倍数下采集得到，分辨率为 640×512 ，其中训练集 2710 张、验证集 302 张和测试集 754 张。为了提高模型的有效性，采用了数据增强手段增强图像。详细数据介绍请见 3.3.1 节。实验具体环境配置如表 4-2 所示。

表 4-2 实验环境配置

Table 4-2 Experimental environment configuration

名称	配置
操作系统	Ubuntu 20.04
内存	56GB
显卡	GeForce RTX 3090, 24GB
开发语言	Python 3.8
深度学习框架	Pytorch1.11

本章实验评价指标与第 3 章使用的相似，都采用 mAP 评估缺陷检测模型的精度。由于是设计轻量级的激光器芯片 COD 缺陷检测模型，除精度外还着重考虑参数量、计算量、模型大小和检测时间等对网络性能进行评估。由于模型参数较小，将训练批次设置为 200，Batch size 设置为 64，数据集全部加载到缓存中加速模型训练效率。

为了验证优化后模型的性能，在激光器芯片 EL 有源区 COD 缺陷数据集上进行了一系列比较实验。实验涵盖的算法包括：YOLOv7 模型、YOLOv7-Tiny 模型，以及采用 MobileNetv3 和 FasterNet 作为 YOLOv7-Tiny 轻量化主干，结合 DBB-ELAN 结构的两种变体模型，分别命名为 Fast-COD-YOLO-M 和 Fast-COD-YOLO-F。在训练集上对这些模型进行训练，并保留了 mAP 指标最优的模型结果。接着，在验证集上评估了各模型的性能，通过 mAP、mAP (IoU=0.5)、参数量和计算量等关键指标来反映模型的表现。

表 4-3 呈现上述讨论的模型在激光器芯片 COD 数据集上的性能对比。实验数据表明，YOLOv7 在 mAP (IoU=0.5) 精度指标上展现出明显的优势，达到了 91.4%。然而，其较高的计算开销成为模型部署的挑战，特别是在面对检测设备资源限制的情况下。针对此问题，通过采用轻量化的特征提取架构，Fast-COD-YOLO-M 和 Fast-COD-YOLO-F 两个改进模型实现模型参数大幅减少，分别仅为 YOLOv7-Tiny 原始模型的 48.59% 和 68.05%，计算量也降低为 29.23% 和 65.38%。与第 3 章模型 COD-YOLO 相比参数量是 8.21% 和 11.50%。在精度方面，YOLOv7-Tiny、Fast-COD-YOLO-M 和 Fast-COD-YOLO-F 也分别达到了 87.1%、85.2% 和 86.1%，最大精度差仅为 1.9%，对检测效果的

影响较小可以忽略。通过引入轻量化主干和 DBB 模块,模型在保证检测性能的同时,更加符合实际工业生产中的缺陷检测需求。综合而言,FasterNet 改良版的 YOLOv7-Tiny (Fast-COD-YOLO-F) 模型在检测准确率和模型轻量化之间实现有效的平衡,适合完成轻量级的激光器芯片 COD 缺陷检测任务。

表 4-3 轻量级网络对比实验结果

Table 4-3 Comparative experimental results of lightweight networks

模型	#Params(M)	Flops(G)	mAP(IoU=0.5)	mAP
YOLOv7	36.48	103.2	0.914	0.659
YOLOv7-Tiny	6.01	13.0	0.871	0.579
Fast-COD-YOLO-M	2.92	3.8	0.852	0.561
Fast-COD-YOLO-F	4.09	8.5	0.861	0.564

为直观展示本章引入的优化结构的有效性,同样采用逐步增加模块的消融实验进行详细分析。具体来说,对 Fast-COD-YOLO-M(表中第三行)和 Fast-COD-YOLO-F(表中第五行)进行了消融实验,相关结果展示在表 4-4 中。通过对特征提取网络进行优化,显著降低了模型的参数量和计算量:采用 MobileNetv3 作为主干时,参数量和计算量分别降至原来的 48.59%和 29.23%;在使用 FasterNet 作为主干时,这些数值分别是 68.05%和 65.38%。虽然这些改进不可避免地引起一定程度的精度下降,但通过引入 DBB 模块,在保持参数量的同时,训练时的多结构增强了模型对缺陷特征的表达能力,其中 mAP (IoU=0.5) 分别提升 1.0%和 0.3%,有效提高检测模型的推理效率。这些优化结构的综合应用,实现在降低模型参数的同时保持有效的检测精度,以减少模型的资源占用,证明改进措施的有效性。

表 4-4 改进模型的消融实验结果

Table 4-4 Ablation experimental results of the improved model

模型	#Params(M)	Flops(G)	mAP(IoU=0.5)	mAP
YOLOv7-Tiny	6.01	13.0	0.871	0.579
YOLOv7-Tiny+MobileNetv3	2.91	3.9	0.842	0.550
YOLOv7-Tiny+MobileNetv3+DBB	2.92	3.8	0.852	0.561
YOLOv7-Tiny+FasterNet	4.10	8.5	0.858	0.568
YOLOv7-Tiny+FasterNet+DBB	4.09	8.5	0.861	0.564

对设计的轻量级激光器芯片 COD 缺陷检测算法进行可视化分析,选取 4 张典型的缺陷图像进行结果预测,展示在图 4-6 中。检测结果表明,绝大多数缺陷图像被精确地识别。只有参数量最小的网络 Fast-COD-YOLO-M 存在 1 处漏检。即使在缺陷尺寸较小或图像整体亮度较低的情况下,轻量级模型展示出良好的检测性能,能够准确地辨识

COMD 和 COBD 两种缺陷类型。




图 4-6 轻量级模型的可视化结果

Fig. 4-6 Visualization of the lightweight model

4.3 模型压缩

在深入分析轻量级激光器芯片 COD 缺陷检测网络的设计和性能之后，本文强调模型轻量化改进在检测任务中的有效应用。简单的模型部署会造成功耗、时延等方面的问题，鉴于实际部署的需求，本研究认识到进一步增强模型的效率和部署的灵活性是必要的。因此，在本节中，将介绍模型压缩技术中的模型剪枝，作为优化策略的关键组成部分，为后续部署更多其他缺陷检测算法预留充足的算力资源，以确保未来开发过程的顺

利进行。

4.3.1 模型剪枝

考虑到模型压缩技术各自的特性，本章采用模型剪枝技术压缩轻量级激光器芯片 COD 缺陷检测模型。深度神经网络存在过参数化的问题，在训练阶段依靠数据驱动学习网络中的权重参数，在此过程中需要大量的参数来捕捉数据背后隐藏的统计规律，然而一旦训练完成进入推理阶段，只是对新输入数据计算输出结果并不需要如此庞大的参数。剪枝是通过删除网络的组成结构，产生用于加速和压缩的稀疏模型。它的目的是在不显著影响模型性能的情况下最小化参数的数量，节约计算资源。在上述内容中，剪枝包括非结构化剪枝和结构化剪枝。非结构化剪枝包括细粒度剪枝、向量剪枝、核剪枝，常见的有 Drop Out^[80]和 Drop Connect^[81]两种典型代表。如下图 4-7 所示，黑色代表输入输出，黄色中间的隐藏层。第一张图是正常的神经元计算操作即 $y = wx + b$ ，此处忽略偏置 b 、第二张图表示使用 Drop Out 的算法，随机将部分神经元的输出置零、第三张图代表 Drop Connect 的方法，随机的将神经元之间的连接置零，使权值矩阵稀疏化。能够实现更高的压缩率，但带来的稀疏结构需要特定的硬件的支持才能实现实际应用中的加速。




图 4-7 非结构剪枝：Drop Out 和 Drop Connect

Fig. 4-7 Unstructured pruning: Drop Out and Drop Connect

结构化剪枝主要是研究方向是通道剪枝^[82]，也叫做滤波器剪枝，可以改变神经网络中的滤波器组数目和特征通道维度。可以利用基本线性代数子程序 BLAS 库等高效库的优势，用标准硬件实现实际工程项目中的加速和压缩。剪枝的流程主要包括三部分：训练、剪枝以及微调。训练是指对模型进行训练，使模型能够在具体任务中具有良好的表现。在本章的 4.2 节中，对轻量级激光器芯片 COD 缺陷检测网络进行训练。剪枝是核心阶段，对深度神经网络应用剪枝算法，实现参数减少，并对模型结构进行评估。微调是用来恢复结构变化后模型表达能力的过程，通过少量训练重新学习遗失的知识，保持稳定的检测性能。剪枝和微调阶段的实验将在本节中进行介绍。

通道剪枝通常可以被描述成下面的表达式：

$$(r_1, r_2, \dots, r_L) = \min_{r_1, r_2, \dots, r_L} \text{Loss}(N(r_1, r_2, \dots, r_L; W)) \quad (4-10)$$

其中 $r_1, r_2, \dots, r_L$ 分别代表每层的剪枝率, $Loss(\cdot)$ 表示损失函数, 即任务的目标函数, 例如分类中的交叉熵损失, N 和 W 分别表示卷积神经网络及其对应的权重参数。 r_i 通过剪枝前后滤波器数目比值计算:

$$r_i = \frac{c_i}{c_i'} \quad (4-11)$$

式中 c_i 和 c_i' 分别表示剪枝前后模型的第 i 层滤波器个数, 图 4-8 提供了一个简单的通道剪枝示意图。




图 4-8 通道剪枝示意图

Fig. 4-8 Schematic diagram of channel pruning

在了解结构剪枝的基本概念后, 在本节中使用基于性能感知的全局信道剪枝框架 (Performance-aware Approximation of Global Channel Pruning, PAGCP) [83] 对轻量级模型 YOLOv7-Tiny 进行剪枝实验。PAGCP 针对多任务进行模型压缩, 考虑层内和层间不同滤波器的联合显著性进行全局通道剪枝, 显著性是指通过设计与性能相关的度量来评估滤波器的协同重要性, 保留全局与任务相关最多的过滤器, 实现了高压缩比和高性能的平衡, 性能下降更加可控。PAGCP 可以表示为:

$$\min_{\theta \in \Omega} \mathbb{E}_{x \sim D_x} [S(x; \theta)] \text{ s.t. } g(\theta) < \alpha. \quad (4-12)$$

其中 S 是联合显著性指标, 用于评价滤波器的重要程度。 x 是输入图像服从 D_x 分布, θ 代表模型的一种剪枝选择, $g(\cdot)$ 表示包含参数量和计算量衰减的矩阵, α 代表期望阈值矩阵。此外, 本文还使用多种剪枝算法对轻量级激光器芯片 COD 缺陷检测模型进行实验。

4.3.2 剪枝实验结果与讨论

为系统地验证剪枝模型的有效性, 本研究对模型展开详尽的性能分析过程, 其中包括了对实验参数的精心设计, 涵盖对 YOLOv7 和 YOLOv7-Tiny 模型的 PAGCP 剪枝实

验实施情况，以及 Fast-COD-YOLO-F 不同剪枝算法的对比实验设计与执行。

通过对实验结果的深入剖析，旨在揭示剪枝网络在实验条件下的实际效能。具体而言，本章节的实验在 4.2 节所训练的网络权重的基础上进行全局剪枝。剪枝后的微调阶段，模型迭代次数设定为 100，批量大小设置为 64，初始学习率设定为 0.01，并引入了学习率衰减的策略以渐进式优化模型。在优化算法的选择上，采纳经典的随机梯度下降方法。关于实验所采用数据集的详细参数配置，请参阅 3.3.1 节内容。

在本节的实验结果部分，表 4-5 详实记录了采用 PAGCP 剪枝策略对 YOLOv7 及其 Tiny 版本模型性能优化的过程及其效果。通过比较剪枝前后各项关键指标，可以清晰看到 PAGCP 剪枝技术所带来的性能改变。基础 YOLOv7 模型具有 36487166 个参数量和 103.2 GFLOPs 的计算量，展现出良好的检测性能，其 mAP (IoU=0.5) 达到 0.914，mAP 达到 0.659。在应用 PAGCP 剪枝后，YOLOv7-PAGCP 模型成功瘦身至 14305294 个参数量节省为原来的 39.21%，并将计算量减少至 46.32%，降低至 47.8 GFLOPs。在大幅度的剪枝后，YOLOv7-PAGCP 模型仍保持了相当高的检测精度，仅使得 mAP (IoU=0.5) 微幅下降至 0.909，mAP 略微下滑至 0.638。同样，对于轻量级的 YOLOv7-Tiny 模型，观察到一系列逐渐精简但仍保持良好性能的 PAGCP 剪枝的结构。YOLOv7-Tiny-PAGCP1 只对部分层结构进行剪枝，YOLOv7-Tiny-PAGCP2 和 YOLOv7-Tiny-PAGCP3 是使用不同剪枝阈值参数的全局剪枝。各变体在不同程度上减少了模型参数和计算量，尤其是在 YOLOv7-Tiny-PAGCP3 中达到了最为极致的压缩，参数量仅剩 2286032 削减为原来的 38.20%，计算量骤降至 37.69%达到 4.9 GFLOPs。尽管随着剪枝强度的增加，mAP 数值有所下降，但即使是压缩幅度最大的剪枝模型，在适度牺牲精度的情况下，仍然保持了较好的检测性能。综上所述，证明剪枝技术在深度学习模型压缩领域的有效性。不仅能显著减少模型尺寸和计算需求，还保持较高的模型检测精度，兼顾模型性能与资源效率之间的平衡。

表 4-5 PAGCP 剪枝实验就结果：YOLOv7 和 YOLOv7-Tiny

Table 4-5 The results of the PAGCP pruning experiment are: YOLOv7 and YOLOv7-Tiny

模型	Parameters	GFLOPs	mAP(IoU=0.5)	mAP
YOLOv7(Baseline)	36487166	103.2	0.914	0.659
YOLOv7-PAGCP	14305294(39.21%)	47.8(46.32%)	0.909(-0.005)	0.638(-0.021)
YOLOv7-Tiny(Baseline)	6010302	13.0	0.871	0.579
YOLOv7-Tiny-PAGCP1	5474815(91.09%)	9.8(75.38%)	0.868(-0.003)	0.573(-0.006)
YOLOv7-Tiny-PAGCP2	2952844(49.13%)	7.5(57.69%)	0.870(-0.001)	0.560(-0.019)
YOLOv7-Tiny-PAGCP3	2286032(38.20%)	4.9(37.69%)	0.852(-0.019)	0.534(-0.035)

表 4-6 展示了轻量化模型 Fast-COD-YOLO-F (Baseline) 在采用五种不同的剪枝方

法后的性能对比结果。**Baseline** 表示原始未剪枝模型,采用的五种不同剪枝算法分别是: **Random**、**Lamp**^[84]、**Norm**^[85]、**Hessian**^[56]和 **Taylor**^[86]。通过调整模型剪枝的参数,各模型的数量均显著减少至 50%左右,如 **Random** 减至 47.22%、**Taylor** 减至 50.24%等。同时,计算量也对应降低,但对模型精度 **mAP** (**IoU=0.5**) 的影响可忽略不计,针对更严格的 **mAP** 指标均存在不同程度降低。总体而言,该表直观展示了不同剪枝方法的结果,为后续模型优化提供了有价值的参考依据。最后,绘制剪枝前后的通道对比图 4-9,展示了剪枝前后的通道分布差异,观察到大部分通道经剪枝后缩减为原来一半。

表 4-6 不同剪枝算法实验结果比较

Table 4-6 Comparing results of different pruning experiments

剪枝方法	Parameters	GFLOPs	mAP(IoU=0.5)	mAP
Fast-COD-YOLO-F(Baseline)	4092258	8.5	0.861	0.564
Random	1932188(47.22%)	4.2(49.41%)	0.852(-0.009)	0.520(-0.044)
Lamp	1834942(44.84%)	4.0(47.06%)	0.858(-0.003)	0.517(0.047)
Norm	1999291(48.86%)	4.3(50.59%)	0.859(-0.002)	0.530(-0.034)
Hessian	1932188(47.22%)	4.2(49.41%)	0.859(-0.002)	0.541(-0.023)
Taylor	2055811(50.24%)	4.4(51.76%)	0.857(-0.004)	0.549(-0.015)




图 4-9 剪枝前后的通道对比图

Fig. 4-9 Channel comparison before and after pruning

4.4 模型部署

通过本章先前阐述的分析内容,揭示了所提出的激光器芯片的 **COD** 检测模型在识别有源区缺陷方面的有效性。为了将缺陷检测算法运用到检测仪器设备中,本节在先前实验研究的基础上,已初步完成了模型的简易部署工作。经过部署后模型能够实时处理由红外 **CCD** 捕获的 **EL** 图像,从而实现对激光器芯片潜在 **COD** 的有效监测。在激光器芯片缺陷检测流程中,模型部署是一项关键步骤,特别是在深度学习框架下,模型部署意味着将训练好的模型移植并在目标执行环境之中稳定运行。目前,模型部署策略主要包括两大途径:云端部署方案与本地部署方案。

云端部署是指将训练好的模型部署在云服务器上,通过网络接口面向用户提供即时的预测与推理服务。得益于强大的云服务器性能,能为参数庞大的模型提供充足的计算支持。但是,推理过程中对网络具有较高依赖,网络延迟直接影响检测效率,出于半导体行业对数据安全和隐私保护的考虑,云端部署方案在应用时易受阻碍。

本地部署则是指将训练完成的模型直接安装在本地计算资源上运行,所有数据处理在本地执行,避免了网络传输环节,增强数据安全性。由于消除网络延迟的影响,适用于对实时性较高的应用场景,并且能够依据具体需求定制,展现出良好的环境适应能力。本地部署可以在本地服务器或嵌入式硬件设备上运行推理。

结合实际检测场景的情况,考虑到图像采集系统内置了专用 PC 硬件设备,本文采取本地部署方案,将模型直接部署至本地之中,不仅有助于降低支出成本,同时保障数据安全。历经工业实践和学术界的长期钻研与积累,模型部署已经发展成一套成熟的流程体系,主要包括四个阶段:第一阶段着重于选择合适的深度学习架构来构建模型,此前的一系列实验正是围绕模型设计和训练开展。到第二阶段,重点在于模型的导出与转换,本章中将训练好的 PyTorch 模型转化为跨平台兼容的通用模型格式 Open Neural Network Exchange (ONNX),以此确保模型能在不同硬件平台和软件框架间实现无缝对接。接下来是第三阶段,聚焦于选择匹配硬件特性的高效推理框架。鉴于本地部署的图像采集系统是无显卡环境,选用 ONNX Runtime 作为模型推理引擎。该框架充分利用 CPU 优化性能,与图像采集系统紧密耦合,确保在接受芯片图像后得到返回检测结果流畅。最后,在第四阶段进行部署验证,将模型置于真实的检测场景中进行测试,评估其在真实场景中的精度,以此验证模型部署的正确性和有效性,如图 4-10 所示。




图 4-10 检测模型部署应用

Fig. 4-10 Detection model deployment application

在完成部署流程后，实现对激光器芯片光学灾变损伤缺陷检测算法的实际应用。左图是红外 CCD 相机软件在采集芯片的 EL 图像，部署后的模型会截取部分屏幕实时处理并输出缺陷类别与位置信息，通过可视化技术在原始图像旁进行展示，生成类似右图中的缺陷检测结果。特别值得注意的是，轻量级模型在采集系统的硬件配置下实现了大约每秒 62 帧 FPS 的检测速度，确保了在实时应用场景中，能够实现高效的缺陷检测检测与识别，满足对低延迟响应的要求。

4.5 本章小结

本章围绕轻量级激光器芯片 COD 缺陷检测与部署进行深入讨论，完成了从模型设计到部署应用的全流程探究。通过替换轻量化特征提取主干网络和集成 DBB 模块的设计，提出了 Fast-COD-YOLO 系列的两个模型，检测精度分别达到 85.1%和 86.1%，较为精准的实现缺陷检测任务。进一步的剪枝实验表明，在模型规模缩减约 50%左右的情况下，算法仍能保持稳定的检测精度，证明了剪枝策略对于提升模型在有限计算资源下的适用性和实效性方面起积极作用，同时为后续部署其他的检测算法预留空间。最后将轻量级模型部署至检测仪器的图像采集处理系统中，基本实现 COD 的缺陷检测任务，这是基于深度学习的缺陷检测算法在 COD 实时分析仪上应用的初步尝试。

第5章 总结与展望

5.1 全文工作总结

高功率半导体激光器是信息和通信技术领域的核心器件,随着需求的不断增加和质量要求的不断提高,可靠性和稳定性已成为其在实际应用中的关键问题。光学灾变损伤是严重制约半导体激光器性能的关键因素之一,从激光器芯片的生产制造到实际应用,一直面临着光学灾变损伤产生的潜在影响。损伤一旦出现,芯片输出功率骤然下降,对整个系统产生严重影响。因此,对出现光学灾变损伤的激光器芯片进行检测与分析,确定缺陷类别与位置信息对于工程师改进制造工艺、优化结构设计、提高芯片的质量和良品率起着重要作用。基于深度学习的激光器芯片缺陷检测算法能够有效为检测与分析过程提供保障。深度学习因其强大的特征提取能力,被广泛应用于半导体器件缺陷检测领域,能够在一定程度上解决芯片缺陷特征相似、尺寸大小随机和对比度低的问题。本文从光学灾变损伤缺陷检测系统出发,包含高精度激光器芯片缺陷检测算法和轻量级检测算法与部署两部分内容。本文的工作总结如下:

(1) 通过光学灾变损伤过程实时分析仪的图像采集系统,共收集到 376 张 DFB 激光器芯片有源区缺陷的电致发光图像,包括自行采集和合作公司提供。通过数据增强技术,对原始数据进行扩增,创建了涵盖 COMD 和 COBD 两种类型光学灾变损伤的激光器芯片缺陷数据集。

(2) 针对光学灾变损伤纹理模糊、背景复杂等问题,本文提出基于 YOLOv7 的缺陷检测架构 COD-YOLO。提出的模型采用可变形高效聚合网络,提升条形缺陷的特征提取能力,同时在其中应用注意力模块突出强调缺陷信息。为充分利用缺陷多尺度特征,防止空间信息在融合时丢失,引入基于空间和内容感知的上采样结构。此外,针对缺陷大小随机的问题,优化边界框坐标回归损失,提高对小目标缺陷的检测和识别能力。实验结果表明,本文提出的 COD-YOLO 模型在激光器芯片光学灾变损伤缺陷检测任务中表现出良好的性能。

(3) 针对缺陷检测网络参数庞大,难以实际应用的缺点,本文在先前基础上提出轻量级激光器芯片 COD 缺陷检测与模型部署方案。设计 Fast-COD-YOLO 系列的缺陷检测模型,使用轻量化卷积神经网络作为特征提取主干并引入推理与训练解耦的多分枝模块,在上下文中融合多维度缺陷信息,减少模型参数量与计算量。为提高模型在资源有限系统中的实用性,通过剪枝的模型压缩方法进一步减少模型参数。根据实际应用环境,选取本地服务器部署的方案,将检测模型部署至检测仪器的图像采集系统中,初步实现缺陷检测算法的应用。

5.2 未来工作展望

本文工作主要针对边发射 DFB 激光器有源区的光学灾变损伤缺陷展开，致力于通过对其的缺陷检测辅助分析缺陷成因，提升芯片制造工艺。基于 YOLO 算法的激光器芯片缺陷检测技术取得了阶段性的成果。但在相关研究和实时性方面仍然存在不足，具体来说在未来的工作中可以进行如下展望：

（1）激光器芯片缺陷种类丰富，除了光学灾变损伤外，芯片的质量筛选还包含相对容易检测的表面缺陷等。本文针对有源区缺陷设计的检测模型难以在表面缺陷检测中有效应用。在后续工作中期望通过图像融合算法，集成多模态的缺陷信息，开发同时实现芯片表面缺陷及有源区缺陷检测的算法，完善缺陷检测功能。

（2）激光器芯片缺陷检测存在部分图像模糊导致识别精度受限的问题，在未来的研究中，可以聚焦于超分辨率技术提升芯片红外显微图像的质量和细节还原能力。结合深度学习和传统图像处理，研究图像的超分辨率重建，提高检测系统可靠性。

（3）在激光器芯片缺陷检测中，目标检测算法仅能粗略实现缺陷定位而缺乏详细的量化信息。在后续的改进工作中通过融入基于深度学习的图像分割技术，实现像素级的缺陷识别，更精准计算缺陷数量、长度、宽度和面积，丰富缺陷描述的维度，提供更为详实的数据支持，帮助工程师深入分析失效机理。

参考文献

- [1] 国务院关于印发《中国制造 2025》的通知[J]. 中华人民共和国国务院公报, 2015(16): 10-26.
- [2] 加快提升产品可靠性水平助力制造业高质量发展——五部门联合印发《制造业可靠性提升实施意见》[J]. 上海质量, 2023, (07): 4-5.
- [3] Cai J, Lv C, Watanabe A. Cost-effective fabrication of high-performance flexible all-solid-state carbon micro-supercapacitors by blue-violet laser direct writing and further surface treatment[J]. Journal of Materials Chemistry A, 2016, 4(5): 1671-1679.
- [4] Yang Q, Zhang P, Lu Q, et al. Application and development of blue and green laser in industrial manufacturing: A review[J]. Optics & Laser Technology, 2024, 170: 110202.
- [5] Lai D, Zhou S, Cheng S, et al. Laser therapy in the treatment of melasma: a systematic review and meta-analysis[J]. Lasers in Medical Science, 2022, 37(4): 2099-2110.
- [6] Amiri I, Rashed A N Z, Mohammed A E A, et al. Spatial continuous wave laser and spatiotemporal VCSEL for high-speed long haul optical wireless communication channels[J]. Journal of Optical Communications, 2023, 44(1): 43-51.
- [7] Ahmed S A, Mohsin M, Ali S M Z. Survey and technological analysis of laser and its defense applications[J]. Defence Technology, 2021, 17(2): 583-592.
- [8] Tomm J W, Ziegler M, Hempel M, et al. Mechanisms and fast kinetics of the catastrophic optical damage (COD) in GaAs-based diode lasers[J]. Laser & Photonics Reviews, 2011, 5(3): 422-441.
- [9] Hou D, Liu T, Pan Y-T, et al. AI on edge device for laser chip defect detection[C]. 2019 IEEE 9th Annual Computing and Communication Workshop and Conference, 2019: 0247-0251.
- [10] Mitschke U, Bäuerle P. The electroluminescence of organic materials[J]. Journal of Materials Chemistry, 2000, 10(7): 1471-1507.
- [11] O'Mahony N, Campbell S, Carvalho A, et al. Deep learning vs. traditional computer vision[C]. Advances in Computer Vision: Proceedings of the 2019 Computer Vision Conference, Volume 1 1, 2020: 128-144.
- [12] Pierścińska D. Thermoreflectance spectroscopy—Analysis of thermal processes in semiconductor lasers[J]. Journal of Physics D: Applied Physics, 2017, 51(1): 013001.
- [13] Eliseev P G. Optical strength of semiconductor laser materials[J]. Progress in quantum electronics, 1996, 20(1): 1-82.
- [14] Sin Y, Bae I-T, Lingley Z. Degradation in high-power broad-area lasers with quantum well and quantum dot active regions: a comparative study[C]. High-Power Diode Laser Technology XXI, 2023: 73-85.
- [15] Cooper D, Gooch C, Sherwell R. Internal self-damage of gallium arsenide lasers[J]. IEEE Journal of Quantum Electronics, 1966, 2(8): 329-330.
- [16] Kressel H, Mierop H. Catastrophic degradation in GaAs injection lasers[J]. Journal of Applied Physics, 1967, 38(13): 5419-5421.
- [17] Eliseev P G. Degradation of injection lasers[J]. Journal of Luminescence, 1973, 7: 338-356.
- [18] Henry C, Petroff P, Logan R, et al. Catastrophic damage of $\text{Al}_x\text{Ga}_{1-x}\text{As}$ double-heterostructure laser material[J]. Journal of Applied Physics, 1979, 50(5): 3721-3732.
- [19] Tang W, Rosen H, Vettiger P, et al. Raman microprobe study of the time development of AlGaAs single

- quantum well laser facet temperature on route to catastrophic breakdown[J]. Applied physics letters, 1991, 58(6): 557-559.
- [20] Sin Y, Presser N, Lingley Z, et al. Reliability, failure modes, and degradation mechanisms in high power single-and multi-mode InGaAs-AlGaAs strained quantum well lasers[C]. High-Power Diode Laser Technology and Applications XIV, 2016: 17-29.
- [21] Bou Sanayeh M, Jaeger A, Schmid W, et al. Investigation of dark line defects induced by catastrophic optical damage in broad-area AlGaInP laser diodes[J]. Applied physics letters, 2006, 89(10): 101111.
- [22] Sin Y, Stuart S, Brodie M, et al. Physics of failure based reliability model of high-power InGaAs-AlGaAs strained QW lasers prone to COBD failure[C]. High-Power Diode Laser Technology XVIII, 2020: 39-50.
- [23] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.
- [24] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [25] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2015: 1-9.
- [26] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 770-778.
- [27] Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv preprint arXiv:1704.04861, 2017.
- [28] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 4510-4520.
- [29] Howard A, Sandler M, Chu G, et al. Searching for mobilenetv3[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2019: 1314-1324.
- [30] Liu Z, Mao H, Wu C-Y, et al. A convnet for the 2020s[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022: 11976-11986.
- [31] Chen J, Kao S-H, He H, et al. Run, Don't walk: Chasing higher FLOPS for faster neural networks[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023: 12021-12031.
- [32] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]. International conference on machine learning, 2015: 448-456.
- [33] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28: 91-99.
- [34] Redmon J, Farhadi A. Yolov3: An incremental improvement[J]. arXiv preprint arXiv:1804.02767, 2018.
- [35] Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 7263-7271.
- [36] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 779-788.
- [37] Lin T-Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 2117-2125.
- [38] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017: 6000-6010.
- [39] Ding X, Zhang X, Ma N, et al. Repvgg: Making vgg-style convnets great again[C]. Proceedings of the

- IEEE/CVF conference on computer vision and pattern recognition, 2021: 13733-13742.
- [40] Wang C-Y, Bochkovskiy A, Liao H-Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2023: 7464-7475.
- [41] Chen S-H, Tsai C-C. SMD LED chips defect detection using a YOLOv3-dense model[J]. Advanced engineering informatics, 2021, 47: 101255.
- [42] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 4700-4708.
- [43] Shu Y, Li B, Lin H. Quality safety monitoring of LED chips using deep learning-based vision inspection methods[J]. Measurement, 2021, 168: 108123.
- [44] Stern M L, Schellenberger M. Fully convolutional networks for chip-wise defect detection employing photoluminescence images: Efficient quality control in LED manufacturing[J]. Journal of Intelligent Manufacturing, 2021, 32: 113-126.
- [45] Yu Z, Wu Y, Wei B, et al. A lightweight and efficient model for surface tiny defect detection[J]. Applied Intelligence, 2023, 53(6): 6344-6353.
- [46] Liu L, Zhu Y, Rahman M R U, et al. Surface defect detection of solar cells based on feature pyramid network and GA-faster-RCNN[C]. 2019 2nd China Symposium on Cognitive Computing and Hybrid Intelligence, 2019: 292-297.
- [47] Su B, Chen H, Liu K, et al. RCAG-Net: Residual channelwise attention gate network for hot spot defect detection of photovoltaic farms[J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-14.
- [48] Hou D, Liu T, Zhang X, et al. DFB laser chip defect detection based on successive subspace learning[C]. 2020 10th Annual Computing and Communication Workshop and Conference, 2020: 0061-0064.
- [49] Klehr A, Beister G, Erbert G, et al. Defect recognition via longitudinal mode analysis of high power fundamental mode and broad area edge emitting laser diodes[J]. Journal of Applied Physics, 2001, 90(1): 43-47.
- [50] Wang X, Li Y, Liu J, et al. Intelligent micron optical character recognition of DFB chip using deep convolutional neural network[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-9.
- [51] Zhang H, Li R, Zou D, et al. An automatic defect detection method for TO56 semiconductor laser using deep convolutional neural network[J]. Computers & Industrial Engineering, 2023, 179: 109148.
- [52] Guo S, Li D, Zhao J, et al. Automated catastrophic optical damage inspection of semiconductor laser chip based on multi-scale strip convolution aggregation[J]. International Journal of Machine Learning and Cybernetics, 2024: 1-16.
- [53] Sin Y, Ives N, LaLumondiere S, et al. Catastrophic optical bulk damage (COBD) in high power multi-mode InGaAs-AlGaAs strained quantum well lasers[C]. High-Power Diode Laser Technology and Applications IX, 2011: 26-37.
- [54] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [55] Neubeck A, Van Gool L. Efficient non-maximum suppression[C]. 18th international conference on pattern recognition, 2006: 850-855.
- [56] LeCun Y, Denker J, Solla S. Optimal brain damage[J]. Advances in neural information processing systems, 1989, 2: 598-605.

- [57] Han S, Pool J, Tran J, et al. Learning both weights and connections for efficient neural network[J]. Advances in neural information processing systems, 2015, 28.
- [58] Nagel M, Fournarakis M, Amjad R A, et al. A white paper on neural network quantization[J]. arXiv preprint arXiv:2106.08295, 2021.
- [59] Depeweg S, Hernandez-Lobato J-M, Doshi-Velez F, et al. Decomposition of uncertainty in Bayesian deep learning for efficient and risk-sensitive learning[C]. International conference on machine learning, 2018: 1184-1193.
- [60] Gou J, Yu B, Maybank S J, et al. Knowledge distillation: A survey[J]. International Journal of Computer Vision, 2021, 129(6): 1789-1819.
- [61] Singh S A, Desai K. Automated surface defect detection framework using machine vision and convolutional neural networks[J]. Journal of Intelligent Manufacturing, 2023, 34(4): 1995-2011.
- [62] Wang W, Dai J, Chen Z, et al. Internimage: Exploring large-scale vision foundation models with deformable convolutions[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023: 14408-14419.
- [63] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 7132-7141.
- [64] Wang J, Xu C, Yang W, et al. A normalized Gaussian Wasserstein distance for tiny object detection[J]. arXiv preprint arXiv:2110.13389, 2021.
- [65] Wang J, Chen K, Xu R, et al. Carafe: Content-aware reassembly of features[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2019: 3007-3016.
- [66] Bochkovskiy A, Wang C-Y, Liao H-Y M. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.
- [67] Wang C-Y, Yeh I-H, Liao H-Y M. You only learn one representation: Unified network for multiple tasks[J]. arXiv preprint arXiv:2105.04206, 2021.
- [68] Wang C-Y, Liao H-Y M, Yeh I-H. Designing network design strategies through gradient path analysis[J]. arXiv preprint arXiv:2211.04800, 2022.
- [69] Liu R, Lehman J, Molino P, et al. An intriguing failing of convolutional neural networks and the coordconv solution[J]. Advances in neural information processing systems, 2018, 31.
- [70] Ge Z, Liu S, Wang F, et al. YoloX: Exceeding yolo series in 2021[J]. arXiv preprint arXiv:2107.08430, 2021.
- [71] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers[C]. European conference on computer vision, 2020: 213-229.
- [72] Li C, Li L, Jiang H, et al. YOLOv6: A single-stage object detection framework for industrial applications[J]. arXiv preprint arXiv:2209.02976, 2022.
- [73] Hou Q, Zhou D, Feng J. Coordinate attention for efficient mobile network design[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021: 13713-13722.
- [74] Woo S, Park J, Lee J-Y, et al. Cbam: Convolutional block attention module[C]. Proceedings of the European conference on computer vision, 2018: 3-19.
- [75] Zhang Q-L, Yang Y-B. Sa-net: Shuffle attention for deep convolutional neural networks[C]. ICASSP 2021-2021 IEEE International Conference on Acoustics, Speech and Signal Processing, 2021: 2235-2239.
- [76] Yang L, Zhang R-Y, Li L, et al. Simam: A simple, parameter-free attention module for convolutional neural networks[C]. International conference on machine learning, 2021: 11863-11874.

- [77] He Y, Song K, Meng Q, et al. An end-to-end steel surface defect detection approach via fusing multiple hierarchical features[J]. IEEE Transactions on Instrumentation and Measurement, 2019, 69(4): 1493-1504.
- [78] Ding X, Zhang X, Han J, et al. Diverse branch block: Building a convolution as an inception-like unit[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021: 10886-10895.
- [79] Zheng Z, Wang P, Liu W, et al. Distance-IoU loss: Faster and better learning for bounding box regression[C]. Proceedings of the AAAI conference on artificial intelligence, 2020: 12993-13000.
- [80] Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. The journal of machine learning research, 2014, 15(1): 1929-1958.
- [81] Wan L, Zeiler M, Zhang S, et al. Regularization of neural networks using dropconnect[C]. International conference on machine learning, 2013: 1058-1066.
- [82] He Y, Zhang X, Sun J. Channel pruning for accelerating very deep neural networks[C]. Proceedings of the IEEE international conference on computer vision, 2017: 1389-1397.
- [83] Ye H, Zhang B, Chen T, et al. Performance-aware approximation of global channel pruning for multitask cnns[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023: 10267-10284.
- [84] Lee J, Park S, Mo S, et al. Layer-adaptive sparsity for the magnitude-based pruning[J]. arXiv preprint arXiv:2010.07611, 2020.
- [85] Fang G, Ma X, Song M, et al. Depgraph: Towards any structural pruning[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023: 16091-16101.
- [86] Molchanov P, Mallya A, Tyree S, et al. Importance estimation for neural network pruning[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019: 11264-11272.