

基于多版本YOLO模型的工业缺陷检测性能对比研究

侯芯露^{1,2,3}, 黄凌霄^{1,2,3}, 姚新波^{1,2,3}, 徐海喆^{1,2,3}

(1. 宁夏大学 信息工程学院, 宁夏 银川 750021; 2. 宁夏“东数西算”人工智能与信息安全重点实验室, 宁夏 银川 750021; 3. 宁夏大数据与人工智能省部共建协同创新中心, 宁夏 银川 750021)

摘要:为解决工业缺陷检测中精度与实时性的平衡难题,该研究旨在对主流的YOLO系列目标检测算法在该场景下的性能进行系统性评估。研究以YOLOv5、YOLOv8、YOLOv10s、YOLOv11四种模型为对象,在公开的东北大学热轧带钢表面缺陷数据集上进行了严格的对比实验,并基于PyTorch框架构建了一套可集成上述模型的多功能检测系统。实验结果表明,尽管各模型均能实现缺陷检测,但在综合性能上存在显著差异。其中,YOLOv11在检测精度(mAP50=0.73)和训练效率(单轮耗时5.0 s)上均表现最优。研究结论认为,YOLOv11是当前更适用于高精度、高效率工业缺陷检测场景的解决方案。该研究为工业视觉质检领域的算法选型与系统开发提供了直接的实证依据。

关键词:YOLO算法;工业缺陷检测;目标检测;深度学习;性能对比;工业缺陷检测系统

中图分类号:TP391 **文献标识码:**A

文章编号:1009-3044(2025)31-0020-06

DOI:10.14004/j.cnki.ckt.2025.1565

开放科学(资源服务)标识码(OSID):



0 引言

随着全球制造业竞争日趋激烈以及消费者对产品质量要求的不断提升,企业对工业制品的质量控制提出了更高要求。产品表面质量作为衡量产品品质的重要指标,已成为市场竞争的核心依据,其在工业生产中的质量控制工作也因此愈发重要。在机械零部件制造中,受设备精度、原材料质量及工艺偏差影响,表面细微缺陷成为制约金属件质量提升的主要因素。近年来,工业成像、计算机视觉与深度学习技术的发展,推动了基于视觉的缺陷检测技术突破。该技术为产品外观检测提供了智能化解决方案,不仅具备良好的应用前景,也获得了各界的广泛关注^[1]。

在工业自动化起步阶段,传统检测方法是质量管控的核心手段。受限于计算能力与算法复杂度,工程师只能依赖边缘检测^[2]、阈值分割^[3-5]等技术,通过人工设计特征、设定判断规则,从工业图像中提取缺陷的几何轮廓与灰度差异,以此识别表面裂纹、孔洞等缺陷。这类方法精度有限,且高度依赖人工调参,仅能应对简单场景下的基础检测需求。

随着工业4.0对高精度、实时性以及复杂场景适配需求的升高,传统检测方法的局限性被进一步放大,已难以应对复杂多变的缺陷形态。而深度学习凭借自动特征学习、端到端推理等优势,成了工业缺陷检测的变革性力量。Xu等^[6]通过在Mask R-CNN中引

入特征金字塔网络并增加边缘检测分支,有效增强了模型对隧道表面缺陷的分割能力,特别是在缺陷边缘的识别精度方面取得了显著提升。Yang等^[7]在FCN的基础上,采用空洞卷积技术扩大模型感受野,同时设计多尺度池化层增强对缺陷细节的捕捉能力,改进后的FCN模型不仅在绝缘子缺陷检测性能上有明显提升,还增强了对复杂背景的抗干扰能力。Jiang等^[8]提出了一种决策融合网络并开发了感知模块,强化了网络的综合检测能力,进一步保障了检测结果的准确性。深度学习通过海量工业图像训练,使模型能够自主学习缺陷的纹理、形状、分布规律,既适配单一产线的定制化检测,也能支撑多场景通用模型的开发,推动工业质检从经验驱动迈向数据智能驱动^[9]。

基于此,本研究旨在回答:1)主流的YOLO系列模型(v5、v8、v10s、v11)在工业缺陷检测任务上的性能表现(精度、速度)有何差异? 2)哪种模型能够在该特定场景下,实现最佳的精度与效率平衡? 3)如何将这些模型集成到一个统一的、便于比较和应用的检测系统中?

1 目标检测相关理论

目标检测领域的发展始终围绕“精度”与“速度”的平衡展开,形成了单阶段(One-stage)与两阶段(Two-stage)两类核心检测器并行演进的格局。

收稿日期:2025-09-24

基金项目:2025年宁夏大学大学生创新创业训练计划项目“基于深度学习的工业图像缺陷检测系统实现”(S202510749312);宁夏回族自治区教育厅高等学校科学研究项目(NYG2024033)

作者简介:侯芯露(2006—),女,山西长治人,本科生,研究方向为计算机视觉;黄凌霄(1977—),男,河北邯郸人,通信作者,副教授,博士,研究方向为计算机视觉、计算水力学;姚新波(1975—),女,宁夏银川人,讲师,硕士,研究方向为计算机视觉;徐海喆(2002—),男,山东德州人,硕士研究生,研究方向为计算机视觉。

1.1 发展脉络

两阶段检测器以分步骤精细化检测为起点。2014年,R-CNN首次引入深度学习,通过选择性搜索生成候选区域,虽奠定了精度基础,但因重复计算导致速度极慢;2015年,Fast R-CNN凭借共享特征机制与ROI Pooling层,将检测速度提升10倍以上;2016年,Faster R-CNN用区域生成网络(RPN)实现了端到端检测,单图速度可达到0.2 s/图,成为两阶段检测器的成熟标杆,后续改进也未脱离其核心逻辑。

与之不同,单阶段检测器摒弃候选区域步骤,直接在特征图上同步完成边界框回归与类别预测。发展初期,YOLO、SSD凭借“单次推理”实现实时检测,但精度不足;直到RetinaNet提出Focal Loss,有效解决了类别不平衡问题,单阶段精度才首次超越两阶段;如今以YOLOv5、YOLOv8、YOLOv11为代表的新一代模型,通过轻量化设计、多尺度特征融合与损失函数优化,实现速度与精度双突破,推动单阶段进入“高速高精度融合”阶段。

1.2 核心差异

两阶段检测器和单阶段检测器的核心差异源于检测逻辑。具体体现在多个方面:流程上,两阶段须经过生成候选区域和分类回归两步,单阶段则直接在特征图上同步完成检测,一步即可;速度上,两阶段因为需要经过两次特征计算,耗时较长,单阶段仅一次计算,速度可达10~100 fps,满足实时需求;精度上,两阶段靠候选区域筛选减少背景干扰,小目标与复杂背景检测更优,单阶段早期精度低,但经技术优化后已接近两阶段水平;计算复杂度与适用场景上,两阶段参数和计算量更大,适配医学影像检测等高精度场景,单阶段更轻量化,适配工业流水线质检等实时场景。

1.3 YOLO 系列定位

在目标检测框架演进中,YOLO系列作为单阶段检测器的典型代表,首次将检测任务构建为基于网格回归与类别预测的端到端回归问题,从理论上奠定了单阶段检测的范式基础。该设计不仅验证了单阶段方法在实时检测中的潜力,也为后续研究提供了重要的架构参考。

随着系列迭代,YOLO在YOLOv4阶段通过融合两阶段技术优势显著提升了精度,至YOLOv11已实现速度与精度的有效统一,成功突破了“高精度必伴随低速度”的传统局限。这一演进过程不仅推动了单阶段检测方法的理论发展,更确立了YOLO在实时高精度检测领域的核心地位。

2 YOLO 系列模型

YOLO(You Only Look Once)是一种基于深度学习的实时目标检测算法,其核心特点是将目标检测任务转化为单阶段回归问题——通过单次神经网络推理,同步预测目标边界框位置与类别概率,具有检测速度快、端到端部署便捷的优势。

2.1 YOLOv5

YOLOv5由Ultralytics团队开发,凭借工程化优势得到了广泛应用,以平衡精度、速度与部署灵活性,支持多尺度输入和轻量化版本为目标。

输入层采用归一化、Mosaic增强,创新性引入自适应锚框聚类,该方法可依据数据集自动计算最优锚框尺寸,提高检测框与目标的匹配度;主干网络以CSP1_X和SPP模块为核心,使用Leaky ReLU激活函数;CSP1_X模块通过跨阶段局部连接,能够在降低计算量的同时增强特征提取能力;SPP模块利用不同尺寸的池化核提取多尺度特征,提升识别精度;Neck采用PANet双向融合结构,能有效融合高层和底层特征,经CSP2_X模块处理,进一步增强特征融合效果;输出层为耦合检测头,将分类和回归任务耦合,用CIoU损失函数和NMS,通过卷积层连接各部分。YOLOv5网络模型如图1所示^[10]。

李和平等^[11]提出了一种改进YOLOv5s的检测算法YOLOv5s-STCD,该算法引入了Swin Transformer结构、坐标注意力(CA)机制,在钢材表面缺陷数据集




图1 YOLOv5模型图^[10]

GC10-DET上,精确率为92.1%,平均检测精度为84.8%,相比原YOLOv5s算法提升了5.6%和3%。

2.2 YOLOv8

YOLOv8在YOLOv5的基础上进行升级,提升了检测精度与速度,增强了对复杂场景的适应能力。输入层用自适应图像缩放,新增数据增强,改用动态锚框;主干网络以C2f替代CSP1_X,SPPF替代SPP,提升了模型性能和计算效率,激活函数换为SiLU;Neck部分采用简化的PANet结构,通过减少卷积连接层并引入C2f模块,进一步优化了多尺度特征融合效率;输出层采用解耦检测头,将分类和回归分支分离,减少任务干扰,损失函数改用DFL,能更好地处理边界框的




图 2 YOLOv8模型图^[8]

回归问题,NMS 升级为 DIoU-NMS,DIoU-NMS 在 NMS 过程中考虑了目标框的方向和位置关系,提升了遮挡场景下的检测效果。YOLOv8 网络模型如图 2 所示^[8]。

2.3 YOLOv10

YOLOv10 由清华大学研发,聚焦轻量化与实时性。输入层支持小尺寸输入,降低了对硬件算力的要求,并简化了数据增强;主干网络在 C2f 模块中引入通道洗牌机制以增强特征交互,并通过简化残差块与减少通道数来降低模型复杂度,同时移除 SPPF 模块以适应轻量化设计;Neck 精简 PANet 融合次数,加入轻量注意力模块,在减少计算量的同时,能更有效地关注重要特征;输出层用动态检测头,可根据目标尺度自适应调整预测分支,并通过端到端检测头消除 NMS 依赖,适配




图 3 YOLOv10模型图^[8]




图 4 YOLOv11模型图^[8]

低算力设备。YOLOv10 网络模型如图 3 所示^[8]。

2.4 YOLOv11

YOLOv11 作为 Ultralytics 最新开发的 YOLO 模型,集合了多种先进技术,能适应更加复杂多样的视觉任务需求。

输入层支持超分辨率,采用多尺度训练和针对性增强,提升模型应对多尺度目标和复杂环境的能力;主干网络升级为 C3f 模块,加入跨阶段注意力和多尺度卷积;Neck 融合 FPN 和 PAN 的优势,新增跨尺度连接,使特征融合更加充分;输出层用“解耦头+空间注意力”,能更准确地定位和分类目标,损失函数使用 EIou,EIou 在 CIou 的基础上,额外考虑了目标框的宽高比差异,提升了小目标和极端场景下的检测精度。YOLOv11 网络模型如图 4 所示^[8]。

徐洁等^[12]改进了 YOLOv11n,引入了全新的高效多尺度卷积模块、轻量级下采样模块、融合注意力机制的特征提取模块,在钢材缺陷检测任务中的 mAP 值达到 80.1%,相比原 YOLOv11n 提升 4.0%,模型参数量和计算量较基准模型分别降低 20.9% 和 17.5%。

3 实验准备

3.1 工业缺陷数据集

在目标检测领域中,数据集作为模型训练、验证与测试的核心基础,其规模、质量及标注准确性直接决定了系统的识别精度与泛化能力。丰富且具有代表性的数据能够有效提升模型鲁棒性,是逼近模型性能上限、保障实际应用可靠性的关键支撑。

本研究使用的数据集来自东北大学热轧带钢表面缺陷数据集(NEU surface defect database),由东北大学发布,是面向钢铁行业带钢质量检测需求的重要公开资源。该数据集收集了夹杂、麻点、划痕、裂纹、压入氧化皮和斑块 6 种缺陷,每类缺陷有 300 张样本图像,尺寸均为 200x200 像素,格式为灰度图像,具有高分辨率、多样性和实际场景的特点,能够准确反映缺陷的细节。图 5 选取东北大学热轧

带钢表面缺陷数据集集中的部分样本图像进行展示。




图5 东北大学表面缺陷数据集图像实例

3.2 环境配置

为确保对比实验的一致性与结果可信度,本研究明确了统一的实验环境配置,具体参数如下:操作系统选用 Windows 11,为实验提供兼容且流畅的运行基础;处理器(CPU)采用 Intel Core i7-13700H,其多核心运算能力可满足模型训练与检测过程中的算力需求;内存配置为 16 GB,能够有效支撑工业缺陷图像数据的加载、处理及多模型并行计算,避免因内存不足导致的程序卡顿或数据处理延迟,为后续 YOLO 系列算法的性能对比提供了一致且高效的硬件与系统支撑。

3.3 评价指标

本实验选用精确率(Precision)、召回率(Recall)、F₁值以及 mAP50 作为评价指标。在工业缺陷检测场景中,精确率衡量的是模型预测为有缺陷的目标中确实为真实缺陷的比例;召回率体现了模型对真实缺陷的检出能力,即模型能够找出多少真实存在的缺陷;F₁值通过计算精确率与召回率的调和平均数,实现对模型性能的综合评估;mAP50 则是在交并比(IoU) 阈值设定为 0.5 的情况下,对数据集中所有类别 AP 值求平均得到的结果。各指标的计算公式如(1)~(4)所示。

$$Precision = \frac{TP}{TP + FP}$$
 (1)

$$Recall = \frac{TP}{TP + FN}$$
 (2)

$$F_1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$
 (3)

$$mAP50 = \frac{1}{C} \sum_{i=1}^C AP_i$$
 (4)

式中:TP(True Positives)表示模型正确地预测为“有缺陷”的样本数量;FP(False Positives)表示模型错误地预测为“有缺陷”的样本数量。FN(False Negatives)表示模型将“有缺陷”错误预测为“无缺陷”的样本数量。C表示类别的数量,AP_i表示第*i*个类别的平均精度。

4 实验结果分析

YOLO 系列模型具备出色的高效性与准确性,在

目标检测任务中应用广泛。YOLOv5、YOLOv8、YOLOv10 与 YOLOv11 作为该系列中具有代表性的模型,集中体现了 YOLO 系列的重要技术进展与独特优势。表 1 详细总结了各模型的核心性能指标,包括输入图像尺寸、在 COCO 数据集上的平均精度(mAP)、模型参数数量(Param) 及每秒浮点运算次数(FLOPs);图 6 则直观展现了各模型在 COCO 数据集上的平均精度随参数数量变化的趋势特征。

表1 YOLO 系列算法性能指标表

模型	尺寸/像素	mAP ^{val} 50-95	参数/M	FLOPs/B
YOLOv5-n	640	28.0	1.9	4.5
YOLOv5-s	640	37.4	7.2	16.5
YOLOv5-m	640	45.4	21.2	49.0
YOLOv5-l	640	49.0	46.5	109.1
YOLOv5-k	640	50.7	86.7	205.7
YOLOv8-n	640	37.3	3.2	8.7
YOLOv8-s	640	44.9	11.2	28.6
YOLOv8-m	640	50.2	25.9	78.9
YOLOv8-l	640	52.9	43.7	165.2
YOLOv8-x	640	53.9	68.2	257.8
YOLOv10-n	640	38.5	2.3	6.7
YOLOv10-s	640	46.3	7.2	21.6
YOLOv10-m	640	51.1	15.4	59.1
YOLOv10-b	640	52.5	19.1	92.0
YOLOv10-l	640	53.2	24.4	120.3
YOLOv10-x	640	54.4	29.5	160.4
YOLOv11-n	640	39.5	2.6	6.5
YOLOv11-s	640	47.0	9.4	21.5
YOLOv11-m	640	51.5	20.1	68.0
YOLOv11-l	640	53.4	25.3	86.9
YOLOv11-x	640	54.7	56.9	194.9




图6 YOLO 系列算法性能对比图

为了系统对比主流 YOLO 系列模型在工业缺陷检测场景中的性能表现,本研究以 YOLOv5、YOLOv8、YOLOv10s、YOLOv11 为研究对象开展对比实验,所有网络均训练 300 轮以保证充分学习。实验采用东北大学研发的热轧带钢表面缺陷数据集,并按 7:2:1 比例

随机分割为训练、验证和测试子集,以检验模型的泛化性能。通过对比分析,旨在明确各网络架构在工业缺陷检测场景中的性能优劣与适用特性。各评价指标结果见表 2,各模型 P-R 曲线对比图见图 7,检测结果对比图见图 8。

表 2 四种模型在同一数据集上的实验结果

模型	单轮训练时间/s	P	R	F1 值	mAP50	mAP50-95
YOLOv5	5.2	0.80	0.74	0.77	0.67	0.37
YOLOv8	6.5	0.64	0.73	0.69	0.72	0.40
YOLOv10s	6.3	0.66	0.74	0.70	0.68	0.39
YOLOv11	5.0	0.82	0.75	0.78	0.73	0.42




图 7 四种模型的 P-R 曲线对比图




图 8 东北大学热轧带钢表面缺陷数据集上模型对比效果

图中不同颜色的检测框用于区分不同的钢铁缺陷类别:左边蓝色框对应“crazing(裂纹)”类缺陷,中间白色框对应“inclusion(夹杂)”类缺陷,右边青色框对应“patches(斑块)”和“scratches(划痕)”类缺陷。YOLOv11 检测框更贴合,置信度更高。

根据实验数据分析,各模型在训练效率与检测精度方面呈现出明显的性能差异。

在训练效率方面,YOLOv11 单轮训练耗时最短

(5.0 s),YOLOv5 次之(5.2 s),而 YOLOv8 和 YOLOv10s 的训练时间相对较长,分别为 6.5 s 和 6.3 s,表明 YOLOv11 具有更优的训练迭代效率。

在检测精度方面,YOLOv11 在精确率、召回率、F₁ 值和 mAP50 等关键指标上均表现最佳。从图 7 的 P-R 曲线对比可以看出,YOLOv11 的曲线最靠近右上方,且曲线下面积最大,这表明该模型在不同置信度阈值下都能保持较高的精确率和召回率,展现出最均衡且优越的检测性能。相比之下,YOLOv5 的 P-R 曲线波动较大,在高召回率区间精确率下降明显;YOLOv8 和 YOLOv10s 的曲线位置相对较低,说明其整体检测性能有限。

在具体检测效果上,YOLOv11 展现出卓越的缺陷识别能力,特别是在复杂缺陷的检测中表现出更强的鲁棒性。从图 8 的检测结果对比可见,YOLOv11 的检测框更贴合缺陷区域且置信度更高,有效降低了漏检和误检的风险。相比之下,YOLOv5 在基础精度指标上表现尚可,但在复杂缺陷检测方面稍显不足;YOLOv8 和 YOLOv10s 在各项指标上整体表现相对较弱,对复杂缺陷的细节捕捉能力有限。

综合来看,YOLOv11 在训练效率与检测精度之间实现了最佳平衡,特别适合对检测效率和精度要求较高的工业场景。在实际应用中,可根据具体的精度需求、效率要求和工程条件,在 YOLOv5、YOLOv8 和 YOLOv10s 之间进行灵活选择,以实现成本与性能的最优配置。

5 讨论与结论

5.1 系统实现与应用

该工业缺陷检测系统以前文的研究成果为基础,以实现工业产品缺陷的精准识别与定位为核心目标。系统具备多场景适配能力,可应对不同类型工业产品的检测需求,能通过内置算法分析识别缺陷类别,并定位缺陷具体位置;同时支持多样化检测需求,可根据工业生产中的精度、效率要求更换模型,兼顾检测准确性与生产节拍,为工业质检环节提供高效、可靠的技术支撑。系统界面如图 9 所示。

5.2 实验结论与讨论

本文围绕工业缺陷检测领域展开研究,从理论与实践两个角度进行,旨在为工业质检的智能化升级提供具备应用实效的解决方案。

理论层面,本文通过系统解析 YOLOv5、YOLOv8、YOLOv10、YOLOv11 四种主流模型的网络结构设计,构建起清晰的算法理论认知体系。

实践层面,本文以理论研究为基础进行了对比实验与系统开发。首先基于选定的工业缺陷数据集,对 YOLOv5、YOLOv8、YOLOv10s、YOLOv11 开展性能对比实验,围绕检测精度、推理速度等关键性能指标量化评估模型表现,最终得出 YOLOv11 在该数据集上总体性能更优的结论。在上述实验的支撑下,本文开发了一套集成 YOLO 系列算法的工业缺陷检测系统,该




图9 系统界面图

系统能够自主选择相适配的算法,针对不同缺陷类型进行识别与定位,有效提升了其在多样化工业场景下的检测效果。

5.3 研究局限性

本研究也存在一定局限性。首先,数据集仅包含6种热轧带钢表面缺陷,模型在其他工业产品(如纺织品、PCB板)或其他缺陷类型上的泛化能力有待验证。其次,研究主要对比了模型的检测性能,未深入进行模型轻量化以适应资源极度受限的嵌入式设备。

5.4 未来展望

未来本研究可从以下3个方面进行深化拓展:1)在数据层面,当前系统依赖东北大学热轧带钢表面缺陷数据集,后续可采用多产品、多缺陷类型的工业混合数据集以提升模型泛化能力;2)在算法层面,针对YOLOv11在微小缺陷识别任务中存在的精度不足问题,可引入注意力机制优化网络,同时探索模型轻量化方案以适配工业边缘设备部署;3)在系统应用层面,可将检测系统与工业互联网平台对接,增加缺陷溯源、质量预警功能,推动工业质检从被动识别向主

动预防升级,进而适配智能制造需求。

参考文献:

[1] 罗东亮,蔡雨萱,杨子豪,等.工业缺陷检测深度学习方法综述[J].中国科学:信息科学,2022,52(6):1002-1039.
[2] 杨洪成,岳杰,赵明瞻,等.基于U2NET的边缘检测研究[J].河北建筑工程学院学报,2024,42(2):229-235.
[3] ZHANG Y,LIU X Y,SUN W,et al.Multi-threshold remote sensing image segmentation based on improved black-winged kite algorithm[J].Biomimetics,2025,10(5):331.
[4] 赵宇航,吴超华,王鑫,等.基于改进Otsu算法的轴承图像阈值分割方法[J/OL].机电工程,2025:1-12.[2025-07-22].https://kns.cnki.net/KCMS/detail/detail.aspx filename=JDGC20250718005&dbname=CJFD&dbcode=CJFQ.
[5] 潘盛湖,彭论文,吕彭杰.基于改进阈值分割算法的刀具损伤检测方法[J].组合机床与自动化加工技术,2024(9):142-146,152.
[6] XU Y Y,LI D W,XIE Q,et alAutomatic defect detection and segmentation of tunnel surface using modified Mask R-CNN[J].Measurement,2021,178:109316.
[7] YANG Y J, TANG L L, ZHENG Y. Improving full convolutional networks to optimize insulator defect detection[J]. Mechanical Design and Manufacturing, 2021 (3): 177-180.
[8] JIANG X, TIAN S, ZHU Z, et al. Decision fusion network with perception fine-tuning for defect classification[EB/OL]. (2023-09-21) [2025-05-28]. https://arxiv.org/abs/2309.12630.
[9] 洪景山,祝颖丹,宋康康,等.基于深度学习的工业缺陷检测研究进展[J].计算机科学,2024,51(10):261-275.
[10] 方帅,沈岳,龙强,等.基于YOLO算法的鸟类检测技术研究综述[J].农业与技术,2025,45(3):56-62.
[11] 李和平,陈中举,许浩然,等.改进YOLO的钢材表面缺陷检测算法[J].现代电子技术,2024,47(13):7-14.
[12] 徐洁,贾宇昂,汪志锋.基于改进YOLO11n的钢材表面缺陷检测算法[J/OL].激光与光电子学进展,2025:1-19.[2025-08-16].https://kns.cnki.net/KCMS/detail/detail.aspx filename=JGDJ2025081500E&dbname=CJFD&dbcode=CJFQ.

【通联编辑:唐一东】

(上接第19页)

[3] MATSUBARA S,TAKATSU M,MIYAZAWA T,et al.Digital annealer for high-speed solving of combinatorial optimization problems and its applications[C]//Beijing:2020 25th Asia and South Pacific Design Automation Conference (ASP-DAC). IEEE,2020:667-672.
[4] WANG L,YANG Z J,GUO S S,et al.LSMCore:a 69k-synapse/mm2 single-core digital neuromorphic processor for liquid state machine[J].IEEE Transactions on Circuits and Systems I: Regular Papers,2022,69(5):1976-1989.
[5] SHI C,FU X,WANG H B,et al.Ghost reservoir: a memory-efficient low-power and real-time neuromorphic processor of liquid state machine with on-chip learning[J].IEEE Transactions on Circuits and Systems II:Express Briefs,2024,71(10):4526-4530.
[6] JIN Y,LIU Y,LI P.SSO-LSM:a Sparse and Self-Organizing architecture for Liquid State Machine based neural processors [C]//Beijing:2016 IEEE/ACM International Symposium on Nanoscale Architectures (NANOARCH).IEEE,2016:55-60.

[7] YAMAMOTO K,KAWAMURA K,ANDO K,et al.STATICA: a 512-spin 0.25M-weight annealing processor with an all-spin-updates-at-once architecture for combinatorial optimization with complete spin-spin interactions[J].IEEE Journal of Solid-State Circuits,2021,56(1):165-178.
[8] 张见.CMOS型伊辛芯片及其应用研究[D].长沙:国防科技大学,2018.
[9] LUCAS A.Ising formulations of many NP problems[J].Frontiers in Physics,2014,2:5.
[10] OKUYAMA T,SONOBE T,KAWARABAYASHI K I,et al.Binary optimization by momentum annealing[J].Physical Review E,2019,100:012111.
[11] JIANG D,WANG X R,HUANG Z H,et al.A spin scale-aware self-adaptive Ising annealing processing architecture for combinatorial optimization problems[J].IEEE Transactions on Circuits and Systems I:Regular Papers,2025,72(10):5811-5824.
[12] 万雷.基于FPGA器件的脉冲神经网络硬件实现研究[D].桂林:广西师范大学,2019.

【通联编辑:李雅琪】