

基于层次化自适应增强的芯片表面缺陷检测 算法 HAE-YOLO

李长江¹, 邓剑勋², 蒲俊宇¹, 孙宏森¹, 刘凯¹, 靳清清¹, 余先伦^{1,*}

(1. 重庆三峡学院 电子与信息工程学院, 重庆 404020;

2. 重庆电子科技职业大学 数字经济与管理学院, 重庆 401331)

摘要: 针对半导体芯片表面缺陷检测中存在的微小缺陷识别困难、缺陷特征复杂多样等挑战, 提出了一种基于 YOLOv8n 改进的层次化自适应增强的芯片表面缺陷检测算法 HAE-YOLO。采用渐进式通道感知 C2f 特征金字塔通道注意力 (C2f_PCA) 特征提取模块融合视觉混合器与卷积门控线性单元, 借助层次化状态空间动态机制增强微小缺陷的特征表征能力; 构建多路径自适应特征融合网络 (MPAFFN), 提升对不同类型缺陷的自适应能力; 引入跨层特征对齐模块 (CFAB) 实现了骨干 (Backbone) 网络与颈部 (Neck) 网络的高效桥接及跨层级特征语义的对齐。实验结果表明, 相较于基准模型, HAE-YOLO 算法的平均精度均值 (mAP@0.5) 提高了 4.6%, mAP@0.5~0.95 提高了 5.2%, 同时参数量 (Params) 减少了 29%, 计算量 (GFLOPs) 减少了 0.5。该算法可为晶圆生产线芯片表面缺陷实时检测提供高效的解决方案, 对减少缺陷芯片流入后续工序、提高制备良率具有重要意义。

关键词: 芯片表面缺陷检测; YOLOv8; 特征融合; 多尺度特征; 注意力机制

中图分类号: TN407 **文献标识码:** A **文章编号:** 1003-353 (2026) 01-0077-01

HAE-YOLO: a Chip Surface Defect Detection Algorithm Based on Hierarchical Adaptive Enhancement

Li Changjiang¹, Deng Jianxun², Pu Junyu¹, Sun Hongsen¹,

Liu Kai¹, Jin Qingqing¹, Yu Xianlun^{1,*}

(1. School of Electronics and Information Engineering, Chongqing Three Gorges University,
Chongqing 404020, China;

2. School of Digital Economy and Management, Chongqing Polytechnic University of Electronic Technology,
Chongqing 401331, China)

Abstract: To address the challenges of difficulty in recognizing small defects and complex diversity of defect features in semiconductor chip surface defect detection, the hierarchical adaptive enhancement HAE-YOLO chip surface defect detection algorithm based on improved YOLOv8n, was proposed. The progressive channel-aware C2f pyramid channel attention (C2f_PCA) feature extraction module was adopted to fuse the vision mixer and convolutional gated linear unit, and the feature representation capability for small defects was enhanced through a hierarchical state space dynamic mechanism. A multi-path adaptive feature fusion network (MPAFFN) was constructed to improve adaptability to different defect types. The cross-layer feature alignment block (CFAB) was introduced to build an efficient bridge

基金项目: 重庆市教委科学技术研究项目 (KJZD-M202303101); 国家自然科学基金 (U2030116); 国家重点研发计划 (2021YFB3901405)

* 通信作者: 余先伦

between the Backbone network and Neck network and achieve cross-level feature semantic alignment. Experimental results demonstrate that the HAE-YOLO algorithm increases mean average precision (mAP@0.5) by 4.6% and mAP@0.5-0.95 by 5.2% compared with the baseline model, while reducing the parameters (Params) by 29% and computational complexity (GFLOPs) by 0.5. This algorithm provides an efficient solution for real-time chip surface defect detection in wafer production lines, which is of great significance for reducing the flow of defective chips into subsequent processes and improving manufacturing yield.

Keywords: chip surface defect detection; YOLOv8; feature fusion; multi-scale feature; attention mechanism

EEACC: 7320Z

0 引言

半导体芯片是现代电子设备的核心器件，随着集成电路技术向更高密度和更小特征尺寸方向发展，高质量的芯片表面缺陷检测系统对半导体产业的可持续发展具有重要意义^[1]。芯片表面缺陷检测技术经历人工检测、传统机器视觉检测至深度学习检测的演进历程^[2]。人工检测速度慢、成本高，易受到主观因素的影响；传统机器视觉检测面对噪声、复杂纹理背景等因素时表现不佳，且需人工进行特征提取^[3]。深度学习技术的发展为芯片缺陷检测带来了突破。

基于深度学习的表面缺陷检测算法可以分为单阶段和双阶段算法。双阶段算法（如 Faster R-CNN^[4]和 Mask R-CNN^[5]）需要对预先生成的候选区域进行分类和定位，精度较高，但检测速度慢。因此越来越多的研究人员开始重点研究能够更好地平衡速度和精度的单阶段算法（如 YOLO 系列^[6-8]、SSD^[9]和 CenterNet^[10]）。例如，林文迪等人^[11]基于 YOLOv3 集成空间金字塔池化（SPP）与空间注意力机制（SAM），显著提高了微波芯片缺陷检测中的多尺度检测指标。陈澍元等人^[12]提出了基于改进 YOLOv8 的芯片 BGA 缺陷检测方法，引入双层路由注意力机制，增强长程依赖捕捉能力，并采用双标签分配策略减少了计算量。马一凡等人^[13]针对芯片封装基板外观缺陷，利用星形块与上下文锚点注意力机制重构 YOLOv10n 中的 C2f 模块，提升了模型的特征提取能力。孙佩月等人^[14]基于 YOLOv11n 采用轻量级自适应提取（LAE）卷积减少参数量（Params），并集成动态上采样（DySample）模块，提高了特征重构效率。

深度学习技术已在半导体芯片表面缺陷检测领域取得了巨大进展，但仍然面临以下技术挑战。①多尺度缺陷检测挑战：半导体芯片表面缺陷的尺度差异显著。②长距离空间依赖建模困难：针对划痕类缺陷，其完整性检测需建立跨越数百像素的长距离空间关联。③复杂背景干扰与特征相似性问题：半导体芯片表面存在复杂的结构纹理，部分纹理与缺陷特征高度相似，易增加检测过程中假阳性检测的风险。④实时性与精度的平衡需求：半导体制备过程要求缺陷检测系统具备毫秒级实时响应与高检测精度，这对算法的计算效率与模型复杂度构成严格约束。

针对上述挑战，本文提出了基于层次化自适应增强的芯片表面缺陷检测算法 HAE-YOLO，主要工作如下：①开发了渐进式通道感知 C2f 特征金字塔通道注意力（C2f_PCA）特征提取模块，融合卷积门控线性单元与视觉混合器，通过层次化状态空间动态机制提高了长距离空间依赖关系建模能力；②设计了多路径自适应特征融合网络（MPAFFN），引入自适应特征融合机制和多粒度卷积，增强了网络对不同类型及变尺度缺陷的检测能力；③开发了跨层特征对齐模块（CFAB），实现了跨层级特征语义对齐，提高了对细微局部结构及广泛上下文信息的获取能力。通过上述改进，所提算法在确保检测速度的同时显著提升了检测精度，同时减少了模型的参数量。

1 HAE-YOLO 算法

在工业缺陷检测领域，YOLOv8 凭借卓越的实时性和检测精度成为主流选择。在 YOLOv8n 的基础上提出了一种基于层次化自适应增强的芯片表面缺陷检测算法 HAE-YOLO，如图 1 所示。




图1 HAE-YOLO 网络结构图

1.1 C2f_PCA 特征提取模块

传统的 C2f 模块中，其简化的特征聚合机制对颗粒污染、划痕等微小及具有长距离空间相关性的缺陷存在显著的检测盲区，且对多类别缺陷的区分能力不足。为解决上述问题，提出了 C2f_PCA 特征提取模块，如图 2 所示。与参考文献 [11] 中仅使用 SAM 不同，该模块融合了层次化状态空间动态机制与卷积门控线性单元，实现了局部细节特征与全局语义信息的深度整合，能够在维持计算复杂度的同时显著增强对长距离空间依赖关系的建模

能力。相较于现有方法，微小及细长缺陷的特征表征能力有所提高。

C2f_PCA 特征提取模块的关键工作流程由特征分离层、深度特征增强层、分级融合层和动态特征聚合层 4 级结构构成。给定输入特征 $X \in \mathbb{R}^{b \times c \times h \times w}$ ，其中 b 表示批次大小， c 表示通道数（ c_{in} 表示输入通道数， c_{out} 表示输出通道数）， h 和 w 分别表示特征图的高度和宽度。图 2 中 k 表示卷积核尺寸， s 表示步长， p 表示填充尺寸。模块首先通过 1×1 卷积实现特征通道重组和维度映射，得到两路平行特征




图2 C2f_PCA 特征提取模块结构图

流 Y_1 、 Y_2 。 Y_1 作为恒定映射保留原始特征信息， Y_2 则通过级联的渐进式金字塔通道注意力 (PCA) 进行深度特征增强。

PCA 是模块的核心处理单元，集成了深度卷积 (DWConv)、隐状态混合器状态空间对偶性 (HSM-SSD)^[15] 模块和卷积门控线性单元 (CGLU)^[16] 3 种互补的特征变换机制。每个 PCA 的整体变换函数 X_{PCA} 可表示为

$$X_{\text{PCA}} = X' + \sum_{i=1}^4 \sigma(\alpha_i) \odot \mathcal{F}_i(X', \theta_i) \quad (1)$$

式中： X' 为 PCA 模块的输入特征； $\sigma(\alpha_i)$ 为可学习参数 $\alpha_i \in \mathbb{R}^{1 \times c}$ 经 Sigmoid 函数得到的第 i 个通道的动态权重系数； $\odot$ 为 Hadamard 乘积； $\mathcal{F}_i$ 对应 4 种不同的特征转换操作，即深度卷积 $\mathcal{F}_1$ 、HSM-SSD 机制 $\mathcal{F}_2$ 、第二深度卷积 $\mathcal{F}_3$ 和卷积门控线性单元 $\mathcal{F}_4$ ； θ_i 为相应的参数集合。

PCA 通过空间-通道双域协同机制提升了微小且具有长距离空间相关性的缺陷特征表征能力。HSM-SSD 主要在空间维度进行全局建模，通过层次化状态空间动态机制获取像素间长距离依赖关系，以明确需关注的空间位置。CGLU 专注于通道维度的自适应增强，通过门控机制实现不同特征通道的自适应选择性激活，使网络能够针对不同类型的缺陷特征进行选择增强。HSM-SSD 模块的输出特征 $X_{\text{HSM-SSD}}$ 为

$$X_{\text{HSM-SSD}} = C \cdot W_{\text{out}} \cdot \{[(A \odot B)^T X'] \odot \sigma[(A \odot B)^T X' W_z]\} \quad (2)$$

$$\{\hat{B}, C, \Delta\} = \text{Linear}(X'') \quad (3)$$

$$\{A, B\} = \text{Discretization}(\hat{a}, \hat{B}, \Delta) \quad (4)$$

式中： X'' 为 CGLU 模块的输入特征， X'' 和 $X_{\text{HSM-SSD}} \in \mathbb{R}^{L \times D}$ ，其中 L 为序列长度， D 为特征维度； A 、 B 、 C 分别为重要性权重矩阵、输入投影矩阵和输出投影矩阵， A 、 B 、 $C \in \mathbb{R}^{L \times D}$ ； W_z 和 W_{out} 分别为门控权重和输出权重， W_z 和 $W_{\text{out}} \in \mathbb{R}^{D \times D}$ ； $\hat{B}$ 为离散化前的投影矩阵； Δ 为时间步长； $\hat{a}$ 为全局重要性权重向量。HSM-SSD 模块的核心思想是通过 $(A \odot B)^T$ 将计算从 $L \times D$ 维度压缩到 $N \times D$ 维度 (N 表示隐藏状态数， $N \ll L$)，在压缩的隐藏状态空间内执行通道混合，将计算复杂度从 $o(LD^2)$ 降低到 $o(ND^2)$ 。该机制通过学习动态状态转移矩阵，实现了跨空间位置的信息交互，适合获取芯片表面缺陷的长距离依赖关系和全局上下文信息。CGLU 通过在 GLU 的门控分支激活函数之前添加最小形式的 3×3 深度卷积，使其结构符合门控通道注意力的设计思想，并将其转换为基于最近邻特征的门控通道注意力机制。

最终，所有经过处理的特征流与初始分离的特征均通过级联和 1×1 卷积层融合，形成最终的输出特征映射。整个 C2f_PCA 特征提取模块的前向传播过程 $X_{\text{C2f-PCA}}$ 可表示为

$$X_{\text{C2f-PCA}} = \mathcal{F}_{\text{cv2}}\{[Y_1, Y_2, \mathcal{M}_1(Y_2), \mathcal{M}_2(Y_2), \dots, \mathcal{M}_j(Y_2)]; \theta_{\text{cv2}}\} \quad (5)$$

式中： $\mathcal{M}_j$ 为第 j 个 PCA 模块； $\mathcal{F}_{\text{cv2}}$ 为最终的卷积层； θ_{cv2} 为相应的参数集合。

为直观展示 C2f_PCA 特征提取模块在芯片表面缺陷检测中的性能提升，利用 Grad-CAM++ 方法^[17] 生成检测结果热力图，其对比结果如图 3 所示。




图3 C2f_PCA 热力图对比结果

针对颗粒污染和划痕等微小以及具有长距离空间相关性的缺陷类型，YOLOv8n 基准模型的热力图呈现出激活区域覆盖不完整、边缘模糊且明显的特征丢失现象。尤其对于长距离、细长型划痕，热力图两端区域响应较弱，呈现出局部断续的响应模式，无法获取划痕的完整几何形态。在添加 C2f_PCA 特征提取模块后，热力图红色激活区域与实际缺陷区域的形状和位置高度吻合，展现出连续、一致的线性特征响应，能够完整覆盖整个划痕区域，从起点到终点均保持较高的激活强度。该结果充分验证了 C2f_PCA 模块能够突出微小缺陷特征、抑制背景噪声干扰，以及在建模长距离空间依赖关

系方面的有效性。

1.2 MPAFFN

传统的路径聚合网络（PAFPN）特征融合网络简单的上、下采样和特征融合机制无法充分获取多尺度缺陷特征之间的复杂关联关系，难以识别颗粒污染、刻蚀阻塞等尺度变化大、形态各异的缺陷。为解决上述问题，提出了 MPAFFN，如图 4 所示。不同于文献 [12] 中的双层路由注意力机制和文献 [14] 中的 DySample 模块，该网络采用更加综合的多尺度特征融合策略，增强不同尺度特征之间的信息流动，提高变尺度缺陷的检测能力，同时保持计算效率。




图 4 MPAFFN 网络结构图

MPAFFN 首先通过改进的 C2f_PCA 特征提取模块从骨干（Backbone）网络中提取 3 个尺度的原始特征；然后构建双向多分支特征金字塔，在该金字塔结构中引入高密度连接与额外的融合路径，形成具备丰富特征流动的网络结构。为增强网络对不同缺陷特征的自适应能力，MPAFFN 采用自适应特征融合机制，通过可学习权重对不同来源的特征进行加权融合。同时，引入高效上采样卷积模块（EUCB）^[18]，在保持特征表征能力的同时减少了模型的计算量。此外，MPAFFN 还集成了跨阶段部分-多尺度分级卷积节点（CSP-MGCN），该节点融合多尺度深度卷积操作与通道混洗操作，获取了不同尺度下的缺陷特征。

Fusion 模块实现了基于双向特征金字塔网络

（BiFPN）^[19]的自适应特征融合，其核心思想是为各输入特征分配一个可学习的权重系数，进行加权融合。与简单的特征相加或拼接相比，这种自适应融合方式能够根据不同特征的重要性动态调整其贡献。

EUCB 模块使用上采样操作（缩放因子为 2）增大特征图尺寸，采用 3×3 DWConv 获取局部上下文信息，通过批量归一化（BN）和 ReLU 激活函数增强非线性特性，采用 1×1 卷积调整通道数以匹配下一阶段需求。其创新在于采用计算效率更高的 DWConv 替代传统 3×3 卷积，显著减少了参数量和计算量。

CSP-MGCN 模块基于 CSP 设计理念，集成了 MGCN 模块。MGCN 模块受到多尺度深度卷积（MS-DC）^[18]模块的启发：原始 MSDC 模块的 ReLU6 激活

函数会将负值特征完全截断，导致划痕缺陷、微粒等细微及低对比度缺陷的特征信息丢失，同时在深层网络中易产生“死神经元”问题。因此，采用 Leaky ReLU6 激活函数 ($\text{Leaky ReLU6}(x) = \min(\max(\alpha x, x), 6), \alpha = 0.01$) 替换 ReLU6，这样既保留了负向特征响应以获取微弱缺陷信息，又维持了数值稳定性的上限，从而提高模型对芯片表面细微缺陷的检测精度和鲁棒性。CSP-MGCN 的工作流程包括特征分离、多尺度深度卷积和特征融合 3 个主要阶段。CSP-MGCCN 的输出结果 $Z_{\text{CSP-MGCCN}}$ 可表示为

$$Z_{\text{CSP-MGCCN}} = Z + \mathcal{F}_{\text{pwc2}}\{\Phi_{\text{shuffle}}\{\mathcal{F}_{\text{mgcn}}[\mathcal{F}_{\text{pwc1}}(Z)]\}\} \quad (6)$$

式中： Z 为 CSP-MGCN 模块的输入特征； $\mathcal{F}_{\text{pwc1}}$ 和 $\mathcal{F}_{\text{pwc2}}$ 分别为输入和输出的点卷积层； Φ_{shuffle} 为通道混洗操作； $\mathcal{F}_{\text{mgcn}}$ 为多尺度深度卷积操作，其数学表达式为

$$\mathcal{F}_{\text{mgcn}}(Z') = \begin{cases} \sum_{i=1}^k \mathcal{F}_{\text{dwc}}^i(Z') & (\text{add} = \text{True}) \\ [\mathcal{F}_{\text{dwc}}^1(Z'), \mathcal{F}_{\text{dwc}}^2(Z'), \dots, \mathcal{F}_{\text{dwc}}^k(Z')] & (\text{add} = \text{False}) \end{cases} \quad (7)$$

式中： $\mathcal{F}_{\text{dwc}}^i$ 为使用第 i 种卷积核尺寸的深度卷积操作；add 为 MGCN 中多尺度特征融合策略的控制开关； Z' 为 MGCN 模块的输入特征。

1.3 CFAB

基于 C2f_PCA 特征提取模块和 MPAAFN 分析发现：尽管 MPAAFN 已构建了丰富的多尺度特征表征，但颈部 (Neck) 网络和 Backbone 网络间的特征融合仍以简单的通道维度操作为主，缺乏针对空间维度的细粒度注意力分配机制；同时，不同层级特征之间的信息整合未充分利用语义-视觉特征的互补性，尤其是当高层语义特征与底层细节特征存在差异时，模型难以做出准确判断。针对上述问题，提出了 CFAB，其结构如图 5 所示。相较于文献 [13] 中的动态检测头方法，该模块通过双域注意力机制 (DSAM) [20] 实现特征图数值校正并突出缺陷区域；同时，采用多尺度层次化特征增强策略，在保留各层级特征独特优势的同时，实现了跨层级特征的语义对齐和优化融合，显著提高了对形态复杂和纹理丰富的缺陷类型的识别精度。




图 5 CFAB 结构图

CFAB 设计为连接 Backbone 和 Neck 网络的桥梁结构，用于同步处理空间分辨率相同但语义层级不同的特征。其核心是通过多粒度注意力机制和层次化特征融合，实现特征增强和优化。该模块的整体工作流程可以概括为

$$F_{\text{out}} = \mathcal{F}\{\mathcal{R}\{S\{D_L[\mathcal{P}_1(F_1)]; D_C[\mathcal{P}_1(F_1)]; D_L[\mathcal{P}_2(F_2)]; D_C[\mathcal{P}_2(F_2)]; \text{Conv}_{3 \times 3}[\mathcal{P}_1(F_1) + \mathcal{P}_2(F_2)]\}\}\} \quad (8)$$

式中： F_1 和 F_2 分别为 Backbone 和 Neck 网络的输入特征， $F_1, F_2 \in \mathbb{R}^{c \times h \times w}$ ； $\mathcal{P}_i$ 为 1×1 卷积投影函数；

D_L 和 D_G 分别为局部(2×2)和全局(4×4)注意力函数； $\{;$ 为通道维度拼接； $\mathcal{S}$ 、 $\mathcal{R}$ 、 $\mathcal{F}$ 分别为通道压缩卷积、重参数化卷积(RepConv)^[21]和输出卷积； F_{out} 为最终输出特征。该设计通过多粒度注意力机制和旁路连接融合，实现了对芯片表面缺陷的精准检测。

CFAB通过DSAM对特征进行多粒度分解和重构，实现了空间和语义维度的联合优化。同时使用不同粒度(例如2×2和4×4)的DSAM单元，如式(7)中的 D_L 和 D_G ，分别关注不同尺度的空间依赖关系。小粒度(2×2)DSAM单元擅长获取精细的局部结构和纹理信息，对于检测单晶刻蚀烧伤、刻蚀阻塞等复杂纹理缺陷至关重要；大粒度(4×4)DSAM单元专注于获取更广范的上下文信息，有助于识别划痕和刻蚀阻塞等跨越较大区域的缺陷。

CFAB的最终阶段为特征融合与优化，该阶段采用RepConv，通过训练的多分支结构与推理时的单一等效卷积，实现了表达能力和计算效率的平衡。此阶段整合了所有注意力增强的特征及基础残差连接。通过多阶段特征优化过程，CFAB能够融合不同层次与尺度的信息，生成更具判别能力的特征表征，从而提升模型对形态复杂、纹理丰富类缺陷的检测能力。

2 实验与结果分析

2.1 数据集构建与特征分析

采用自建半导体芯片表面缺陷数据集，所有图

像数据均由合作企业12英寸(1英寸=2.54 cm)晶圆生产线的3D自动光学检测系统(3D AOI)采集。该系统与生产线晶圆传输系统联动，在晶圆历经化学气相沉积(CVD)、离子注入、刻蚀等重要工序后，自动启动图像采集流程，相机采取垂直拍摄方式，工作距离达200 mm，曝光时间设定为50 μs，以确保在生产节拍内获取到优质的图像。最终形成640×640像素的4 118张芯片表面图像，涵盖6类典型缺陷。①颗粒污染：光刻胶涂布过程中的微粒沉积或化学反应副产物，尺寸微小，易与芯片表面纹理混淆，导致局部电路短路或开路；②划痕：晶圆传输或加工过程中的机械摩擦损伤，呈线性或弧形条纹，长、宽比极大，需要长距离空间依赖建模，部分区域可能中断，从而破坏电路连续性；③颗粒缺陷：离子注入或等离子体处理过程中的颗粒沉积，呈相对规整的圆形，边缘清晰，对比度中等，与正常的金属焊盘特征相似；④单晶刻蚀烧伤：干法刻蚀过程中温度过高或等离子体能量过强导致，形态复杂多变，与正常刻蚀图案边界模糊；⑤刻蚀阻塞：刻蚀过程中光刻胶残留或刻蚀气体流动不均导致，尺寸跨度大，内部可能有梯度变化，需要多尺度特征融合；⑥微粒：环境污染或设备磨损产生的微小颗粒，尺寸极小、边缘锐利，单个影响有限，但大量聚集时会影响器件的性能。使用LabelImg软件对缺陷图像进行标注，并按8:1:1划分为训练集、验证集和测试集。该数据集的各类缺陷详细参数如表1所示。

表1 各类缺陷参数

缺陷类型	缺陷图像数/张	比例/%	平均分辨率	分辨率范围
颗粒污染	892	21.7	15×18	8×10~35×40
划痕	756	18.4	120×8	45×3~280×15
颗粒缺陷	643	15.6	22×25	12×14~58×62
单晶刻蚀烧伤	698	17.0	85×92	40×45~180×195
刻蚀阻塞	634	15.4	156×142	68×72~320×285
微粒	495	12.0	18×20	6×8~42×48

2.2 实验环境及参数配置

本次实验在Windows 11(64 bit)操作系统下进行，硬件配置为Intel Core i9-13900HX CPU、NVIDIA GeForce RTX 4070 GPU(32 GB显存)及CUDA 12.8。软件环境采用Python 3.10.14和深度学习框架PyTorch 2.2.2。训练时，使用随机梯度下降(SGD)优化器采样，批处理大小设置为16，图像像素为640×640，初始学习率为0.01，动量因子为0.937，权重衰减为0.000 5，训练轮

次为300轮。

2.3 评价指标

为全面评估缺陷检测模型的性能，采用如下评价指标：精度(P)、召回率(R)、平均精度(AP)、平均精度均值(mAP@0.5、mAP@0.5~0.95)、检测速度(FPS)和十亿次的浮点运算量(GFLOPs)。计算公式分别为

$$P = \frac{TP}{TP + FP} \quad (9)$$

$$R = \frac{TP}{TP + FN} \tag{10}$$

$$AP = \int_0^1 P(R) dR \tag{11}$$

$$mAP = \frac{1}{N'} \sum_{i=1}^{N'} AP_i \tag{12}$$

$$FPS = 1/T \tag{13}$$

式中：真正例（ TP ）为被正确预测为正样本的数量；假正例（ FP ）为被错误预测为正样本的数量；假负例（ FN ）为被错误预测为负样本的数量； T 为每张图像的检测时间； N' 表示缺陷种类的总数。

2.4 消融实验

为验证 HAE-YOLO 算法各核心模块的有效性，进行了系统性消融实验，结果如表 3 所示。

表 3 消融实验结果

YOLOv8n	C2f-PCA	MPAFFN	CFAB	mAP@0.5/%	mAP@0.5~0.95/%	GFLOPs	Params	检测速度/(f·s ⁻¹)
√				77.7	50.0	8.7	3.1×10 ⁶	241
√	√			79.1	52.0	8.4	2.9×10 ⁶	242
√		√		80.1	52.2	7.7	2.2×10 ⁶	226
√			√	77.8	52.6	8.8	2.9×10 ⁶	221
√	√	√		81.6	52.3	7.6	2.1×10 ⁶	210
√	√		√	80.8	52.1	8.5	2.7×10 ⁶	220
√		√	√	79.5	54.4	8.3	2.3×10 ⁶	217
√	√	√	√	82.3	55.2	8.2	2.2×10 ⁶	209

以 YOLOv8n 为基准模型（其 mAP@0.5 为 0.777），通过逐步添加 C2f-PCA 特征提取模块、MPAFFN 模块和 CFAB，以及对上述模块进行组合的方式，对各模块的性能贡献展开量化分析。实验结果表明，单独添加各模块均能提升性能，MPAFFN 模块贡献最大（mAP@0.5 提升 2.4%），集成 3 个模块后完整的 HAE-YOLO 算法性能最佳（mAP@0.5 为 82.3%，mAP@0.5~0.95 为 55.2%），较基准模型分别提升了 4.6% 和 5.2%。进一步分析显示，C2f-PCA 模块对微小缺陷（如颗粒污染）检测效果显著；MPAFFN 模块在处理变尺度缺陷（如微粒和刻蚀阻塞）方面表现卓越；CFAB 则通

过 DSAM 整合不同层次特征信息。完整模型相较于基准模型在提高检测精度的同时，GFLOPs 为 8.2，减少了 0.5，Params 为 2.2×10⁶，减少了 29%。在保持较高检测速度（209 f/s）的同时实现了精度与效率的双重优化，充分证明了 HAE-YOLO 算法在芯片表面缺陷检测任务中的有效性和先进性。

2.5 对比实验

为全面评估 HAE-YOLO 算法的性能，将其与当前主流目标检测算法进行对比分析，关键性能指标的对比结果如表 4 所示。所有实验均在相同的芯片表面缺陷数据集和硬件环境下进行，以确保实验结果的可比性。

表 4 HAE-YOLO 与当前主流目标检测算法对比实验结果

网络模型	P/%	R/%	mAP@0.5/%	mAP@0.5~0.95/%	GFLOPs	Params	检测速度/(f·s ⁻¹)
Faster R-CNN	78.3	71.8	78.5	51.8	194.6	41.7×10 ⁶	55
SSD	71.2	65.4	70.9	42.3	28.3	24.5×10 ⁶	81
YOLOv5s	73.6	69.8	73.5	48.2	16.5	8.8×10 ⁶	244
YOLOv7tiny	75.3	69.3	73.2	48.4	13.2	6.2×10 ⁶	253
YOLOv8n	75.1	71	77.7	50	8.7	3.1×10 ⁶	241
YOLOv10n	77.4	68.8	75.8	50.3	6.7	2.2×10 ⁶	252
YOLOv11n	76.4	74.1	74.3	49.4	6.6	2.5×10 ⁶	265
HAE-YOLO	79.4	75.7	82.3	55.2	8.2	2.2×10 ⁶	209

由表 4 可知，HAE-YOLO 在检测精度和计算效率方面均取得了良好平衡：与二阶段检测器 Faster R-CNN 相比，HAE-YOLO 的 mAP@0.5 提高了 4.8%，mAP@0.5~0.95 提高了 6.6%，同时模型 Params 仅为其 5.3%，GFLOPs 仅为其 4.2%，FPS 提高近 3 倍，且在工业现场可使用低功耗 GPU

部署。与同为单阶段检测器的 YOLO 系列相比，HAE-YOLO 的 mAP@0.5 和 mAP@0.5~0.95 均显著领先。与 Params 相近的 YOLOv10n 相比，在保持相同硬件部署成本的前提下，mAP@0.5 提高了 8.6%，这意味着在相同的投资预算下可获得更高的缺陷检出率。与最新的 YOLOv11n 相比，HAE-

YOLO 在略微减少 Params 的同时, mAP@0.5 提高了 10.7%, 显著降低了缺陷芯片流入后续工序的风险。同时, 其 209 f/s 的检测速度为工业现场提供了充足的处理能力储备, 在生产线负载波动或需要重复检测时仍能保持稳定的实时性能。因此, 从工程实际应用角度出发, HAE-YOLO 相比其他算法具有显著优势。

为直观比较本文改进模型 HAE-YOLO 相对于基准模型 YOLOv8n 的性能提升, 分别使用 HAE-YOLO

与 YOLOv8n 模型在自建芯片表面缺陷数据集上进行定性分析, 并可视化展示了部分检测结果, 如图 6 所示。实验结果表明, 改进后的模型在该数据集的 6 类缺陷检测任务中性能提升显著, 展现出更高的置信度, 并减少了漏检现象。尤其针对微粒、划痕等微小缺陷, 以及需要长距离依赖关系建模的缺陷类型, 基准模型存在明显的误检现象, 改进模型可实现高效识别。这一结果充分验证了改进模型对不同尺度、形态及复杂缺陷的全面处理能力。




图 6 缺陷检测结果对比图

3 结论

本文提出了基于层次化自适应增强的芯片表面缺陷检测算法 HAE-YOLO, 通过 3 个创新模块解决了半导体芯片表面缺陷检测的关键问题。实验结果表明, 与基准算法 YOLOv8n 相比, 本文 HAE-YOLO 算法的 mAP@0.5 提高了 4.6%, mAP@0.5~0.95 提高了 5.2%, 同时参数量减少了 29%, 计算复杂度略有下降。与其他先进检测算法相比, HAE-YOLO 在 209 f/s 的检测速度下实现了 82.3% 的 mAP@0.5 和 55.2% 的 mAP@0.5~0.95, 展现出优异的综合性能。该算法在芯片高速生产线上实现了实时高精度检测, 为提高半导体制备过程的质量控制水平和优化制程参数提供了技术支持, 具有显著的工程应用价值和经济效益。

参考文献:

- [1] SABERIRONAGHI A, REN J, EL-GINDY M. Defect detection methods for industrial products using deep learning techniques: a review [J]. Algorithms, 2023, 16 (2): 95.
- [2] 胡志强, 吴一全. 基于机器视觉的芯片缺陷检测研究进展 [J]. 仪器仪表学报, 2024, 45 (7): 1-26.
- [3] REN Z H, FANG F Z, YAN N, et al. State of the art in defect detection based on machine vision [J]. International Journal of Precision Engineering and Manufacturing-Green Technology, 2022, 9 (2): 661-691.
- [4] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 39 (6): 1137-1149.
- [5] HE K M, GKIOXARI G, DOLLAR P, et al. Mask

- R-CNN [C] // Proceedings of IEEE International Conference on Computer Vision (ICCV). Venice, Italy, 2017: 2980–2988.
- [6] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: unified, real-time object detection [C] // Proceedings of IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas, USA, 2016: 779–788.
- [7] BOCHKOVSKIY A, WANG C Y, LIAO H Y M. YOLOv4: optimal speed and accuracy of object detection [DB/OL]. arXiv: 2004.10934. (2020-04-23) [2024-12-08]. https://arxiv.org/abs/2004.10934.
- [8] GE Z, LIU S T, WANG F, et al. YOLOX: exceeding YOLO series in 2021 [DB/OL]. arXiv: 2107.08430. (2021-07-18) [2024-12-04]. https://arxiv.org/abs/2107.08430.
- [9] LIU W, ANGUELOV D, ERHAN D, et al. SSD: single shot MultiBox detector [C] // Proceedings of the 14th European Conference on Computer Vision. Amalfi, Italy, 2016: 21–37.
- [10] DUAN K W, BAI S, XIE L X, et al. CenterNet: key-point triplets for object detection [C] // Proceedings of IEEE/CVF International Conference on Computer Vision (ICCV). Seoul, Korea, 2019: 6568–6577.
- [11] 林文迪, 周睿阳, 邸志雄. 基于 YOLOv3 的芯片缺陷检测模型设计与优化 [J]. 半导体技术, 2024, 49 (7): 660–665.
- [12] 陈澍元, 王鸣昕, 赵嘉宁, 等. 基于改进 YOLOv8 网络模型的芯片 BGA 缺陷检测 [J]. 半导体技术, 2025, 50 (4): 378–384.
- [13] 马一凡, 朱晓春, 王鸣昕, 等. 基于改进 YOLOv10n 网络模型的芯片封装基板外观缺陷检测 [J]. 半导体技术, 2025, 50 (8): 833–842.
- [14] 孙佩月, 黄娟, 顾寄南, 等. 基于 YOLO11n 的轻量化芯片表面缺陷检测方法 [J]. 半导体技术, 2025, 50 (7): 707–713.
- [15] LEE S, CHOI J, KIM H J. EfficientViM: efficient vision mamba with hidden state mixer based state space duality [C] // Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, USA, 2025: 14923–14933.
- [16] SHI D. TransNeXt: robust foveal visual perception for vision transformers [C] // Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, USA, 2024: 17773–17783.
- [17] CHATTOPADHAY A, SARKAR A, HOWLADER P, et al. Grad-CAM++: generalized gradient-based visual explanations for deep convolutional networks [C] // Proceedings of IEEE Winter Conference on Applications of Computer Vision (WACV). Lake Tahoe, USA, 2018: 839–847.
- [18] RAHMAN M M, MUNIR M, MARCULESCU R. EMCAD: efficient multi-scale convolutional attention decoding for medical image segmentation [C] // Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, USA, 2024: 11769–11779.
- [19] TAN M X, PANG R M, LE Q V. EfficientDet: scalable and efficient object detection [C] // Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, USA, 2020: 10778–10787.
- [20] XU S B, ZHENG S C, XU W H, et al. HCF-net: hierarchical context fusion network for infrared small object detection [C] // Proceedings of IEEE International Conference on Multimedia and Expo (ICME). Niagara Falls, Canada, 2024: 1–6.
- [21] DING X H, ZHANG X Y, MA N N, et al. RepVGG: Making VGG-style ConvNets great again [C] // Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, USA, 2021: 13728–13737.

(收稿日期: 2025-07-09)

作者简介:

李长江 (2000—), 男, 重庆人, 硕士研究生, 主要研究方向为计算机视觉、图像处理、目标检测、自动光学检测等;



余先伦 (1967—), 男, 重庆人, 硕士, 教授, 硕士生导师, 主要研究方向为数值算法、激光技术、量子通信等。