

Defect Detection of Electrical Connector Based on Improved Yolo v3^{*}

WU Weihao, LI Qing^{*}

(College of Mechanical and Electrical Engineering, China Jiliang University, Hangzhou 310018, China)

Abstract: Aiming at the problems of electrical connector defect detection, such as low automation, low detection accuracy, slow detection speed, and poor robustness, this paper proposes an improved Yolo v3 algorithm to detect electrical connector defects. First, the *K*-means clustering algorithm is used to perform cluster analysis on the data set of this paper to obtain three kinds of candidate frames with aspect ratios to improve the detection accuracy for the defective objects in this paper; the 8-times downsampling feature of the third residual block output of the backbone network The image is up-sampled 4 times, and the obtained feature map is merged with the down-sampled feature map of the second residual block to obtain the fusion feature detection layer; the 6 DBL units passed by the target detection layer are changed to 2 DBL unit plus 2 residual units to improve feature reuse and acquisition; In addition, this paper chooses single-scale feature maps for target detection instead of multi-scale prediction of the original network, which not only saves the calculation amount, but also avoids it to a certain extent False detection. The qualitative and quantitative experimental results show that the improved Yolo v3 algorithm has better performance and speed for electrical connector defect detection, with an accuracy rate of 93.5%, which is more accurate than Faster R-CNN, and the original Yolo v3 is more It is fast and basically meets the requirements of industrial field for electrical connector testing.

Key words: defect etection; electrical connector; machine vision; deep learning; Yolo v3

EEACC: 7230

doi: 10.3969/j.issn.1004-1699.2020.02.022

基于改进 Yolo v3 的电连接器缺陷检测^{*}

吴伟浩, 李 青^{*}

(中国计量大学机电工程学院, 杭州 310018)

摘 要: 针对电连接器缺陷检测目前存在自动化程度低、检测精度低、检测速度慢以及鲁棒性较差等问题, 提出了一种改进的 Yolo v3 算法来检测电连接器的缺陷。首先采用 *K*-means 聚类算法对本文数据集进行聚类分析得到 3 种宽高比的候选框, 针对本文缺陷对象提高检测精度; 对主干网络第三个残差块输出的 8 倍降采样特征图进行 4 倍上采样, 将得到的特征图与第二个残差块输出的 2 倍降采样特征图进行拼接得到融合特征检测层; 将目标检测层之前经过的 6 个 DBL 单元改为 2 个 DBL 单元加上 2 个残差单元, 以提高特征的复用与获取; 另外本文选择单尺度特征图进行目标检测, 而不是原网络的多尺度预测, 既节省了计算量, 又一定程度上避免误检。通过定性与定量的实验结果表明, 本文改进后的 Yolo v3 算法对电连接器缺陷检测有着更好的性能以及速度, 准确率为 93.5%, 相较于 Faster R-CNN 更加准确, 原 Yolo v3 更加快速, 基本上满足了工业现场对电连接器检测的要求。

关键词: 缺陷检测; 电连接器; 机器视觉; 深度学习; Yolo v3

中图分类号: TP391.4

文献标识码: A

文章编号: 1004-1699(2020)02-0299-09

电连接器在整体航天工业中是使用量非常大且比较重要的部件, 其起到电源连接、数据连接的作用^[1], 由于其封接强度、弯曲强度高、气密性好等特点, 在航空航天、家用电器等领域的连接和封装方面

有着举足轻重的作用^[2]。由于圆形电连接器生产工艺中焊锡点极易掉落在焊杯上(如图 1 所示), 导致焊杯表面出现焊锡点从而导致连接时出现无法完全密封, 甚至无法连接的情况, 因此需要检测出焊锡

项目来源: 浙江省重点研发计划项目(2018C03035)

收稿日期: 2019-12-09 修改日期: 2020-01-07

点是否存在从而剔除焊锡。另一方面在焊接地线的过程中,由于机器或者人工操作失误会导致地线错焊,会直接导致电连接器插针没有接地甚至出现短路情况,会导致整个系统崩溃,因此需要检测定位出地线的位置,从而判断地线是否错焊。含有缺陷的电连接器一旦在使用过程中发生问题,将会造成整个系统奔溃甚至危及人的生命财产安全,损失无法估计。因此,航空电连接器的可靠性对整个系统的安全至关重要^[3]。



图 1 焊锡点缺陷

目前电连接器主要检测方式有以下 2 类:①人眼观察法,此方式检测效率低,检测受人主观因素影响大,精度无法保证,另外检测人员需要用手拿起工件,放置于放大镜下进行观察,手中汗渍以及拿取工件时磕碰都有可能金属工件腐蚀或者磕碰损坏;②机器视觉检测法,此方式相对于人眼来说效率高,精度高,可重复性高而且采用非接触方式,对工件无损。相比较于人眼检测来说机器视觉有着更加明显的优势,但是目前对于电连接器缺陷检测大部分还是采用人眼观察法,其在检测时主要依赖人眼,检测的精度和结果都无法得到保证且不具有重复性和可追溯性^[4]。

目前国内外对于电连接器的视觉检测研究较少,其中研究较多的存在的问题是电连接器外壳的缺陷,对于电连接器插座部分存在的缺陷研究较少。江苏大学的李健康研究提出了基于小波分析的纹理缺陷检测方法检测电连接器表面粗糙度^[1]。他创新的提出了粗糙度特征参数提取并建立粗糙度模型,他主要研究的方面是对于外壳的外观检测,而本文研究的重点更在于电连接器的功能缺陷检测,判断能否正常使用,另其外壳检测只能离线检测不满足现代自动化生产线的需求。哈尔滨工业大学的卢佳宇提出了基于灰度特征的模板匹配算法进行插针

识别以及基于灰度质心算法进行插针定位^[2]。其主要实现了对于插针的识别定位但是并没有进行下一步的检测,还尚未完成主要的缺陷检测,该方法只能识别一种电连接器并且只能放置在特定位置,不然无法识别。北京航空航天大学的杜福洲提出通过双目视觉基于支持向量机(SVM)的方式对多种类型插针进行分类识别以及识别出相应插针存在的缺陷,但是该方式平均识别耗时 1.1 s 有待提高^[5],对于不同摆放位置电连接器也无法识别。

深度学习起源于人们对神经网络的研究,它是现代人工智能的核心算法,它以机器学习为基础不断发展在目标检测领域取得了重大的进展,相对于传统图像处理的方式它的效率更高,计算速度更快,识别更加准确,对于本课题的将要识别的缺陷会有更好的效果。在目标检测领域中,目前 Faster RCNN (faster region-based convolutional neural networks) 模型、Yolo (you only look once) 模型^[6]和 SSD (single shot multiBox detector)^[7]模型都具有精度高、速度快等优点^[8]。不同于 Faster RCNN 模型采用“两步检测”的方式,Yolo 模型采用回归机制,只要输入整幅图形就可以检测目标。因此选取的候选框个数比 Faster RCNN 模型要少,而 SSD 模型虽然借鉴 Faster RCNN 模型的锚框机制,但并没有在每个位置都进行精调,所以相比较而言 SSD 的精度较低。这些原因使得 Yolo 模型和 SSD 模型在检测速度方面会优于 Faster RCNN 模型,而在检测精度方面则略差于 Faster RCNN 模型。Yolo 的迭代第三版 Yolo v3 加入了多尺度预测从而提高了对于小目标的检测,并且加深了网络从而提高了精度,使得 Yolo v3 精度超过 Faster RCNN 并且速度比它快 100 倍。本文对于电连接器缺陷检测速度和精度要求很高,因此本文将采用 Yolo v3 网络为基础的改进网络以满足工业生产要求,针对本课题研究对象电连接器缺陷的特征做分析,根据实际需求改进网络以适应现代工业生产线的要求。

1 电连接器缺陷特征分析

1.1 焊锡点缺陷特征分析

本文研究对象之一是由于生产工艺问题产生的散落在电连接器焊杯上形成的焊锡点,该焊锡点可能散落在焊杯上的任意位置,并且形状以及尺寸不固定,如图 1 所示即为焊锡点缺陷。其中焊杯为插针的固定底座,该部位是电连接器的连接部分,在有焊锡点存在的情况下可能会导致接触不良甚至连接不上的情况,因此在工件出厂前都必须经过检

测排除这一类情况。该焊锡点的大小以及形状均不固定,经过灰度预处理之后,在不均匀的光照条件下将会显示出不同的灰度值,对于传统的图像处理技术来说检测较为困难,精度以及速度都很难达到现代化生产线的检测要求。

1.2 地线错焊缺陷分析

本文的另一个研究对象是电连接器的地线,由于在生产过程中操作人员或者机器的操作失误,会导致地线没有焊接在指定的插针上,而焊接在了该插针的左边插针或者右边插针上,如图2所示即为地线错焊示意图。其中绿色框表示地线应该正确焊接位置,而两个红色叉的框即为地线可能会焊接错的位置,该图即为正确焊接位置。在地线错焊或者漏焊的情况下将会可能会导致漏电事故严重的甚至会影响到人们的生命财产安全。本文研究内容都是基于现代化生产线上在线检测要求前提下,在检测时电连接器位置不固定,从而无法确定地线相对于整个电连接器的位置,无法确定地线究竟是否焊接正确,对于传统的图像处理技术来说可以实现检测地线,但是传统图像处理技术侧重对特征的提取,对于略显复杂的场景特征更多样化,不能很好的提取特征,只能在较为简单的背景以及实时性要求不高的场景下使用,显然该方式无法满足本课题,而近几年较为热门的深度学习网络模型却能够很好解决该问题,相比较于传统目标检测算法,深度学习采用多层卷积网络能够提取更高层次的信息,同时对于底层特征也能很好的获取,精度更高,泛化能力也更强。Yolo v3 网络模型有着很快的识别速度同时兼顾精度,并且加入了对于小目标识别的优化,对本课题来说较为合适。



图2 地线错焊示意图

2 Yolo v3 算法

Yolo 算法由 Redmon^[9]等人在 2016 年提出,它将整张图作为输入,将物体检测问题转化成了简单

的回归问题,在 2018 年已经发展到了第三代 Yolo V3^[10]。顾名思义,它只要完成一次前向运算就可以完成目标检测,正因为这种特性,相较于其他目标检测算法其运算速度更快,但是精度有所下降。而 Yolo v3 在保持 Yolo v2 的速度下^[11],又极大的提高了检测准确率,尤其对于小目标的识别更加准确。

2.1 网络结构

Yolo 每一代的提升很大一部分都是通过改进现有的主干网络结构来实现的,Yolo v3 也不例外,从 Yolo v2 的 Darknet-19 提升到了 Darknet-53^[12],卷积层增加到了 53 层,其网络框架如图3所示。Darknet-53 借鉴了残差神经网络(resnet)的思想,在网络中加入了 5 个残差块(residual),每个残差块中包含不同数量的残差单元^[13](res_unit)。残差单元主要由输入和两个数码累计造型(DBL)单元构成残差结构^[14],其中,DBL 单元是 Yolo v3 的基本构成单元也就是卷积、批归一化(BN)和 Leaky relu 激活函数。正因为 Darknet-53 网络中加入了残差单元,所以在加深网络的基础上,解决了梯度消失的问题,并且提高了对特征的复用。另外在整个 v3 网络中是没有池化层与全连接层的,所以在前向传播的过程中,张量的尺寸变化通过改变卷积核的步长大小来实现,将步长设置为 2 时每次通过卷积层之后图像的尺寸将会变为原来的一半,而面积变为原来的四分之一。




图3 Yolo v3 网络结构图

2.2 多尺度检测

Yolo v3 在检测小尺寸目标方面借鉴了 FPN^[15](feature pyramid networks)的思想,对于不同的尺寸的目标通过多尺度预测的方式来实现。Yolo v3 网络的最终输出是原图 1/32,1/16,1/8 大小的特征图。主要实现过程是在第 79 层之后经过几个卷积过程先得到 1/32(13×13)的特征图,该特征图感受野大,对于大尺度的目标检测较为合适。而后该结果经过上采样与 61 层的结果进行 concat(张量拼接),再经过卷

积得到 $1/16(26 \times 26)$ 的特征图,该特征图对于中等尺度的目标检测效果较好。而后该结果经过上采样与 36 层结果进行 concat,再经过卷积得到 $1/8(52 \times 52)$ 的特征图,该特征图感受野较小所以对于小目标的检测效果较好。如图 4 所示,在输入图像尺寸为 $416 \times 416 \times 3$ 大小时 Yolo v3 输出了 3 个不同尺寸的特征图,输出的特征图为 y_1, y_2 和 y_3 ,分别表示 $13 \times 13, 26 \times 26$ 和 52×52 网格的特征图。Yolo v3 中设定每个网格预测 3 个 box,而每个 box 需要 $(x, y, w, h, \text{confidence})$ 5 个参数,在 COCO 类别中每个 box 需要识别的有 80 个类,因此特征图的深度均为 255。Yolo v3 网络将浅层特征图叠加到邻近通道,使得网络能够同时学习到深层和浅层的特征,模型多了细粒度特征,从而提高了模型对小目标的检测能力。




图 4 多尺度预测

2.3 目标边界框预测

Yolo v3 和 Yolo v2 一样都通过 $K\text{-means}^{[16]}$ (均值聚类法) 来获得图像中目标的先验框的尺寸,因为 Yolo v3 一共输出了 3 种尺度的特征图,并且对应大中小 3 个尺寸各有三个先验框,所以一共包含了 9 种尺寸的先验框。对于 COCO 数据集而言,9 个聚类得到的先验框如表 1 所示,不同尺度的特征图对应不同尺寸的先验框。

表 1 COCO 数据集 9 种先验框

不同尺度特征图	感受野	先验框
13×13	大	(116×90), (156×198), (373×326)
26×26	中	(30×61), (62×45), (59×119)
52×52	小	(10×13), (16×30), (33×23)

Yolo v3 在对于 Bounding box (目标边界框) 进行预测之前,采用 Logistic regression^[17] (逻辑回归) 的方式对先验框包围的区域进行 Objectness score (目标性评分),即判断该区域是目标区域的可能性的,对于不是最佳的目标区域,模型不会对其进行预测,只有目标存在可能性得分最高的区域才会开始预测。有了这一步操作可以去掉不必要的先验框,减少计算量,模型运行速度将会更快。经过筛选

之后与 Yolo v2 相同采用直接预测的办法而不是 RPN (区域候选网络) 中的 anchor (锚点) 机制,如图 5 所示。其中 (t_x, t_y) 表示该点所在框的左上角点到目标中心点的距离大小,在这里采用了 sigmoid 函数归一化处理而并不是原来采用的 softmax 回归的方式,因为 softmax 方式会增加最大可能类别概率的值而抑制其他类别的值,不适合多标签分类问题,相比较而言采用 sigmoid 函数会更加准确。 (c_x, c_y) 表示该点所在网格相对于左上角网格的相差的格子数。 (p_w, p_h) 表示先验框的宽高。




图 5 Bounding box 预测机制^[9]

由式(1)可以看出, Bounding-box 的位置宽高以及 confidence (置信度) 都可以通过 $(t_x, t_y, t_w, t_h, t_o)$ 直接计算得到。

$$\begin{aligned} b_x &= \sigma(t_x) + c_x \\ b_y &= \sigma(t_y) + c_y \\ b_w &= p_w e^{t_w} \\ b_h &= p_h e^{t_h} \end{aligned}$$

$$P_r(\text{object}) \times \text{IOU}(b, \text{object}) = \sigma(t_o) \quad (1)$$

2.4 损失函数

在 Yolo v3 中的损失函数主要有三大部分,目标置信度损失函数 $L_{\text{conf}}(o, c)$, 目标分类损失函数 $L_{\text{cla}}(O, C)$ 以及目标定位损失函数 $L_{\text{loc}}(l, g)$, 如式(2)所示。

$$L(O, o, C, c, l, g) = k_1 L_{\text{conf}}(o, c) + k_2 L_{\text{cla}}(O, C) + k_3 L_{\text{loc}}(l, g) \quad (2)$$

其目标定位损失中包含了预测框宽高 (w, h) 损失函数以及中心点 (x, y) 损失函数,前者采用了误差平方和的方式来计算,后者采用二值交叉熵的方式来计算损失函数,目的是为了能够应对更加复杂的情况,对于同一个目标而言其可能被归为多类。包括目标置信度损失函数以及目标分类损失函数也采用该方式。

3 改进的 Yolo v3 模型

本文的研究对象是存在于圆形电连接器上的小缺陷,主要检测任务是对于小目标的检测。在 Yolo v3 的

中先验框的大小是根据 COCO 数据集使用 K -means 来聚类分析得到其 9 个尺寸的,但是对于本课题的研究对象而言,显然是不适合的。另外一方面,在 Yolo v3 的网络中虽然加入了多尺度预测的方式来优化对于小目标的检测,但是效果并没有想象中那么好,因此本文针对 Yolo v3 的改进主要在聚类方式以及修改网络层级上。

3.1 Anchor boxes 的聚类分析

Yolo v3 中采用了 Faster R-CNN 中的 Anchor boxes^[18](先验框)机制,先验框的是一组宽高固定的先验候选框,其尺寸的大小以及比例会直接影响网络模型对目标检测的精度与速度。在 Yolo v3 中采用了 K -means 聚类的方式来确定其大小以及尺寸,对于 COCO 数据集而言一共聚类出 9 种尺寸的先验框,如表一所示,但是本课题研究对象而言并不合适,该数据集聚类出的先验框大小并不能满足圆形电连接器的缺陷尺寸要求。所以需要重新对本课题数据集进行 K -means 聚类分析,在对数据集进行聚类分析时采用 Avg IOU(平均交并比)作为聚类结果的好坏的评判标准,Avg IOU 值越高表示聚类效果越好。式(3)表示了 Avg IOU 的计算方法。

$$f = \operatorname{argmax} \frac{\sum_{i=1}^k \sum_{j=1}^{n_k} I_{\text{IOU}}(T, P)}{n} \quad (3)$$

式中: T 表示真实的目標框,也就是样本; P 表示簇的中心,也就是聚类框。 $I_{\text{IOU}}(T, P)$ 表示目标中心框与聚类框之间的 IOU(交并比); k 表示簇的总共个数; n 表示样本的总数; n_k 表示第 k 个聚类中心的样本个数; i 表示样本的序号; j 表示聚类中心的样本序号。

k 代表 K -means 聚类中簇的个数,也就是最终想要获得的簇的个数,可以自由选择其中个数。在本次实验中选取了 $k=1 \sim 20$,一共 20 个簇分别对图像数据集进行聚类分析,聚类结果如图 6 所示。从聚类结果图可以看到,随着簇个数的增加,判断指标 Avg IOU 越来越高,随之增长率也不断减小,变化变得缓慢,从而可以将曲线斜率最大点之后的点视为最佳点。一方面较少的点可以减少计算量,加快损失函数的收敛,另一方面也可以去除由候选框带来




图 6 聚类分析结果图

的误差,选择出更符合本课题的先验框个数以及尺寸。从图 6 可以看出在簇的个数为 3 时为最佳点,在本数据集上得到的 3 个聚类中心的维度分别为 (13,20)(18,19)(23,12)。

3.2 改进的 Yolo v3 网络结构

在 Yolo v3 中随着网络层级的加深,图像的细节以及位置信息会不断减少,但是语义信息不断加强。对于目标的定位而言需要更多的细节信息,更多需要的是底层网络的特征,而对于类别检测而言需要更多的高层语义信息,对于目标检测而言既要识别出目标位置又要确定其类别,所以在 Yolo v3 原网络结构中采用了多尺度融合预测的方式来检测目标,使用上采样将高层的网络与底层网络进行融合,从而获得更多的特征信息用于定位与分类。Yolo v3 对于小目标的预测采用了 8 倍降采样之后的特征图,但是当检测目标小于 8×8 个像素点时会出现弊端,而本文将要检测的缺陷都很小,将出现检测困难的情况,为了解决这个问题本文提出采用其上一层的网络信息即原网络中 2 倍降采样的特征图进行检测,其包含更多的细节与位置信息对于本文中的缺陷小目标的识别更加准确。为了获得更多的高层特征提高目标分类的准确率,对 Yolo v3 网络输出的 8 倍降采样图进行 4 倍上采样从而得到 2 倍降采样的特征图,再将该特征图与网络中第 2 个残差块输出的 2 倍降采样图进行拼接,从而得到了 2 倍降采样的目标检测特征图,如图 7 所示。




图 7 改进的 Yolo v3 网络结构图

为了对本课题中出现的小缺陷有更好的识别效果,本文在原来的残差块输出中又添加了 2 个残差单元。如图 8 所示,在 Yolo v3 输出层之前需要经过 6 个 DBL 单元和 1 个 1×1 卷积核的卷积单元,本文将其改为 2 个 DBL 单元以及 2 个残差单元从而一定程度上增强了特征的使用,避免了梯度消失问题,这同主网络中采用残差结构有着异曲同工之妙,从而获得了更多底层的细节和位置信息。




图 8 残差结构

前文提到 Yolo v3 网络中采用的多尺度预测的方式来实现对大中小目标的检测,大中小三种尺度分别对应 3 种不同的先验框尺寸,如表 1 所示。但是本课题的缺陷目标属于小目标,所以并不需要三种尺度,只选用 2 倍降采样的融合特征图做作为目标检测层,其中融合特征图选择融合了其下两层残差块输出的特征图,并没有加入 4 倍降采样的特征图,一方面简化了网络,减少了计算,提高了检测速度,另一方面该部分对于小目标的识别来说显得冗余,实际作用不大。本文单一尺度预测的方式一方面提高模型对小目标的召回率,另一方面提高模型的检测准确率,更加适应电连接器的缺陷检测,该方法同样适用于已确定目标尺寸的缺陷检测。

4 基于改进的 Yolo v3 模型的圆形电连接器缺陷检测实验

4.1 实验数据集以及实验条件

与传统的目标检测不同,深度学习中的数据集起着至关重要的作用,甚至很大程度上决定了模型的优劣,由于本文将要检测的圆形电连接器缺陷一直没有公开的数据集可以使用,因此本文制作了 50 000 张图片数据集。实验装置如图 9 所示,通过



图 9 实验装置

该装置获取原图。为了增强网络模型的鲁棒性,需要尽可能多的获取不同的情况下的电连接器图像。首先保证工件放于同一位置,仅改变光照强度来获取一部分图像。其次对工件进行旋转,获取工件不同角度图像,之后在每一个不同角度下又改变光照强度获取一部分图像。再之后水平移动工件,获取工件位于镜头不同位置下的图像,之后重复改变光照以及旋转工件操作获取更多不同的图像。

50 000 张数据集主要分为三类,其中分别有 20 000 张单独地线标签的图像,20 000 张单独焊锡点标签的图像以及 10 000 张地线和焊锡点混合标签。本文中采用对数据集进行标注标签的工具为 labellmg,在使用 labellmg 工具中只需要将目标点框出来,自定义其类目即可,将会自动生成网络所能识别的 xml 文件,其中包含了一些位置信息以及类别信息。labellmg 操作界面如图 10 所示。




图 10 labellmg 界面

本文进行目标检测实验的条件:操作系统 Windows10, CPU 为 i5-8300H, GPU 为 1050ti, 内存 16 GB, 深度学习框架为 tensorflow。

4.2 改进的 Yolo v3 网络的训练

对改进的 Yolo v3 网络进行训练时训练集与验证集的比例为 9:1, 对网络主要参数进行初始化,其中将学习率 (learning rate) 设为 0.001, 迭代次数 (epoch) 设为 300, 批量大小 (batch size) 设为 2, 衰减系数 (weight decay) 设为 0.0005。

改进的 Yolo v3 在网络训练得到的 loss (损失) 值如图 11 所示,其中可以看到在全部样本迭代 300 次的情况后 loss 已经趋近于 0.1 左右,从 loss 值的




图 11 改进的 Yolo v3 loss 值曲线

收敛情况可以看出,该网络训练的结果较为理想,可以作为一个合格的网络模型进行测试。

4.3 圆形电连接器缺陷检测网络的测试

4.3.1 单个缺陷检测实验

目标检测网络领域中召回率 R 和精确率 P ^[19] 是评判网络模型检测优劣最基础的指标,召回率 R 以及精确率 P 可以通过式(4)、式(5)来计算。

$$R=\frac{N_{TP}}{N_{TP}+N_{FN}} \tag{4}$$

$$P=\frac{N_{TP}}{N_{TP}+N_{FP}} \tag{5}$$

式中: N_{TP} 表示网络正确检测出来的目标数量; N_{FN} 表示网络没有检测到的目标数量; N_{FP} 表示网络检测错

误的目标数量。

测试的图像一共有 5 000 张,其中包含的焊锡点缺陷一共有 6 000 个,包含地线的缺陷一共有 6 000个,将训练好的网络对该数据集进行测试,得到的召回率 R 和精确率 P 结果如表 2 所示。从表 2 中可以看出,改进后的 Yolo v3 相比较于原网络在两类缺陷的识别中都得到相应的提升,焊锡点缺陷召回率从 85.7%提高到了 92.8%,地线召回率从88.6%提高到了 94.8%,焊锡点缺陷精确率从 85.3%提高到了 92.2%,地线缺陷精确率从 88.3%提高到了 93.8%,从侧面说明本文改进后的算法对于两种缺陷而言,召回率以及精确率都有了明显提高。

表 2 Yolo v3 与改进 Yolo v3 单种缺陷检测结果对比

Detection algorithm		N_{TP}	N_{FN}	N_{FP}	$R/\%$	$P/\%$	$AP/\%$
焊锡点	Yolov3	5 144	856	890	85.7	85.3	85.6
	Improved Yolo v3	5 566	434	467	92.8	92.2	92.5
地线	Yolov3	5 313	687	702	88.6	88.3	88.4
	Improved Yolo v3	5 689	311	376	94.8	93.8	94.5

为了更好的表征模型的准确性,在目标检测领域引入了平均精确率(AP)的概念,平均准确率从召回率和精确率两个方面评价网络的准确性,适合于单个种类的检测评价,其量化方式就是计算 Precision-recall 曲线(精确率-召回率曲线)下所包含的面积,通常 AP 值越高,表征该模型的分类效果越好。AP 的计算方式称为 11 piont 法,首先在数据集中找到最大的 11 个精确率值,将数据得分由高到低排序,计算相应的召回率和精确率,然后选取召回率 $R=\{0,0.1,0.2,0.3,0.4,0.5,0.6,0.7,0.8,0.9,1.0\}$ 一共 11 个点,绘制出 P-R 曲线,通过式(6)计算出 AP,式中 x 表示当前召回率下 11 个最大预测值其中的一个元素。


$$AP_{11point}=\frac{1}{11}\times(\sum x)(x\in \text{Maxprecision}) \tag{6}$$

将本文数据集中的单类缺陷数据集投入 Yolo v3 网络与本文改进后的 Yolo v3 网络后,分别计算得到相应平均精准度后得到的结果如表 3 所示。


表 3 Yolo v3 与改进的 Yolo v3 网络性能对比

Detection algorithm	AP/%		mAP /%	误检率/%	漏检率/%
	焊锡点	地线			
Yolo v3	85.6	88.3	86.9	8.3	4.8
Improved Yolo v3	92.5	94.5	93.5	3.9	2.6

可以看到相比较于原 Yolo v3 网络,本文改进后的 Yolo v3 网络分别对缺陷 1,2 进行检测时,平均准确率都有了不同程度的提升,焊锡点缺陷检测 AP 值从 85.6%提升到了 92.5%,地线缺陷检测 AP 值从 88.4%提升到了 94.5%。更直观的检测效果提升可以通过不同网络检测结果图 12 看到。



(a) 原Yolo v3网络



(b) 本文改进后的Yolo v3

图 12 Yolo v3 网络与本文改进后的 Yolo v3 网络地线缺陷检测结果对比图

其中图 12(a) 是 Yolo v3 原网络的识别结果, 图 12(b) 是本文改进后的网络识别结果, 对比图 12(a)、(b) 可以看到原 Yolo v3 网络对于焊锡点缺陷检测时存在错检和漏检情况, 其中深色长条区域表示网络检测出的位置, 白色框表示错检测或者漏检的地方, 黑色框表示正确框出的位置。综上所述本文的改进算法从一定程度上降低了错检和漏检的情况。

4.3.2 混合缺陷检测实验

评判一个目标检测模型的好坏不仅仅是对于某一单类目标检测效果来评判, 分别使用原 Yolo v3 网络, 本文改进后的 Yolo v3 网络对混合的缺陷目标进行检测。数据集采用本文自制的数据集, 评价标准通过平均准确率均值 (mAP) 来表征。mAP 的值越高表示网络对于不同种类目标的检测效果更好, 综合性能更强, mAP 计算公式如式 (7) 所示。

mAP = \frac{1}{N} \sum_{i \in N} AP(i) \tag{7}

式中: AP 表示平均准确率, N 表示检测的目标种类数, mAP 即对不同种类的 AP 求均值。测试结果如表 3 所示, 可以看到本文改进后的 Yolo v3 网络将 mAP 从 86.9% 提升到了 93.5%, 误检率从 8.3% 降低到 3.9%, 漏检率从 4.8% 降低到 2.6%, 在数据层面本文改进后的网络有更好的性能, 为了更好的检验本文缺陷检测的效果, 本文选择对实际缺陷进行检测对比。

从图 13 可以看到两个网络在实际检测过程中




图 13 Yolo v3 网络与本文改进后的 Yolo v3 网络缺陷检测结果对比图

的结果。图 13(a) 是原 Yolo v3 网络的检测结果, 图 13(b) 是本文改进算法得到的结果图。

对比图 13(a)、(b) 可以看到原 Yolo v3 网络存在错检的情况, 将一些光斑错误识别为焊锡点的情况^[20], 而本文改进后的 Yolo v3 网络对于焊锡点缺陷识别更准确, 一定程度上减少了错检的情况。另外可以看到 Yolo v3 网络并没有将所有的地线识别出来, 出现漏检的情况, 而本文改进后的算法准确的识别出了所有的缺陷, 说明本文改进后的算法不论是在检测单类缺陷还是多类缺陷时, 都比原 Yolo v3 网络更加精确。

4.4 不同目标检测模型的对比

由于本文识别目标是圆形电连接器的缺陷, 所以对于本文的识别任务而言, 最重要的是网络模型的准确率以及实时性, 准确率可以用 mAP 来表征, 实时性通过检测单次所花费的时间来评判。本文使用同一数据集, 分别使用 Faster R-CNN、SSD、Yolo v3 以及本文改进后的 Yolo v3 网络来进行检测, 得到的结果如表 4 所示。

表 4 不同算法的缺陷检测结果表

目标检测算法	Anchor Boxes	IOU	mAP/%	单张图片平均识别时间/ms
Faster R-CNN	9	0.63	91.2	1268
SSD	9+	—	82.7	20.60
Yolo v3	9	0.56	86.9	12.89
改进的 Yolo v3	3	0.67	93.5	10.63

从表 4 中可以看到, 本文改进 Yolo v3 的 mAP 得分最高, 达到了 93.5%, Faster R-CNN 其次, 达到了 91.2%, 说明本文改进后的网络有着更好的检测性能, 并且相较于其他网络更加快速, 综合 mAP 以及检测时间来看, 本文改进后的算法性能较为均衡, 在保证精度的情况下, 尽可能加快了检测速度, 可以更好的担任对电连接器缺陷的检测任务。


5 结论

本文改进算法主要是基于 Yolo v3 网络, 其主要改进点在对候选框的选择, 采用了自制数据集进行聚类分析, 计算得到适合本文的候选框个数以及尺寸; 另外本文对主干网络结构进行重新构造, 将网络中 2 倍降采样特征图与深层网络输出特征图进行拼接融合, 得到了 2 倍降采样的融合特征图; 为了对小型缺陷目标的识别有更好的识别效果, 本文在最后的残差块输出中又增加了 2 个残差单元, 对小型缺陷检测有更好的效果; 由于本文的检测目标为圆形电连接器的缺陷检测, 目标较小, 为了满足网络模型对于实时性

的要求,以及更好的支持的小型缺陷识别,采用了单尺度的预测,而不是原网络中采用的大中小3种尺度的预测,并且将目标检测层之前的6个DBL单元改为2个DBL单元和2个残差单元。通过实验可以看到,相比较不同的目标检测算法,本文改进后的 Yolo v3 网络有着更加均衡的性能,相比较于原 Yolo v3 网络,对本文缺陷的召回率,准确率以及 mAP 都有了一定程度的提高,并且在保证精度的情况下,识别速度也有所提升,基本满足了工业现场对圆形电连接器缺陷检测准确率和实时性的要求。说明本文算法有一定的实际意义,并且在工业现场小目标缺陷的识别上有一定借鉴作用,可以通过不同针对不同的数据集进行聚类分析,采用本文改进后的网络都会获得较为理想的检测效果。本文改进后的 Yolo v3 获得比 Faster R-CNN 更高的 mAP,而其检测速度只有 Faster R-CNN 的1%不到,相比较于其他模型有较大进步,但是对于网络的检测性能还有很大的进步空间,下一步主要研究方向还是在继续提高精度以及速度上。

参考文献:

- [1] 黄新,童宣科.基于 OpenCV 的航空插头内焊杯坐标定位[J]. 仪器仪表用户,2018,25(4):49-52,61.
- [2] 李健康.电连接器壳体零件表面粗糙度视觉检测方法研究[D]. 镇江:江苏大学,2016.
- [3] 卢佳宇.基于机器视觉的航空电连接器插针检测技术研究[D]. 哈尔滨:哈尔滨工业大学,2017.
- [4] 周朗明.微(小)型物体视觉测量与重构方法研究[D]. 武汉:武汉大学,2013:11.
- [5] 杜福洲,赵德龙.基于双目视觉的多型号电连接器检测技[J]. 航空精密制造技术,2016,52(5):23-28.
- [6] Redmon J,Divvala S,Girshick R,et al. You Only Look Once: Unified, Real-Time Object Detection[C]//IEEE Conference on Computer Vision and Pattern Recognition,2016:779-788.
- [7] Liu W,Anguelov D,Erhan D,et al. SSD:Single Shot Multibox.Detector[C]//European Conference on Computer Vision,2016:21-37.
- [8] Rens,Hek,Girshick R,et al. Faster R-CNN:Towards Real-Time Object Detection with Region Proposal Networks[J]. IEEE Transaction on Pattern Analysis and Machine Intelligence,2017(6):1137-1149.
- [9] Redmon J,Divvala S,Girshick R,et al. You Only Look Once: Unified, Real Time Object Detection[C]//Computer Vision and Pattern Recognition. 2016:779-788.
- [10] Redmon J,Farhadi A.YOLOv3: An Incremental Improvement[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2018.
- [11] Redmon J, Farhadi A. YOLO9000: Better, Faster, Stronger[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2017:6517-6525.
- [12] 刘博,王胜正,赵建森,等.基于 Darknet 网络和 YOLOv3 算法的船舶跟踪识别[J]. 计算机应用,2019,39(6):1663-1668.
- [13] Meng Wang, Shengyu Hou, Huaifeng Li, et al. Generative Image Deblurring Based on Multi-Scaled Residual Adversary Network driven by Composed Prior-Posterior Loss[J]. Journal of Visual Communication and Image Representation,2019.
- [14] 司彦娜,普杰信,臧绍飞.基于残差梯度法的神经网络 Q 学习算法[J/OL]. 计算机工程与应用:1-7[2019-10-31]. <http://kns.cnki.net/kcms/detail/11.2127.TP.20190926.1044.014.html>.
- [15] 李靛,贺柏根,霍家道. FPN 在遥感图像检测中的应用[J]. 指挥控制与仿真,2019,41(2):130-136.
- [16] 王千,王成,冯振元,等. K-means 聚类算法研究综述[J]. 电子设计工程,2012,20(7):21-24.
- [17] Preisser J S, Das K, Benecha H, et al. Logistic Regression for Dichotomized Counts[J]. Statistical Methods in Medical Research, 2014:0962280214536893.
- [18] Gao M, Du Y, Yang Y, et al. Adaptive Anchor Box Mechanism to Improve the Accuracy in the Object Detection System[J]. Multimedia Tools and Applications, 2019, 78(1):27383-27402.
- [19] 陈咏秋,孙凌卿,张永泽,等.基于 YOLO v3 的输电线路鸟类检测技术研究[J/OL]. 计算机工程:1-7[2020-01-07]. <http://kns.cnki.net/kcms/detail/31.1289.TP.20190809.1140.013.html>.
- [20] 袁统帅.基于机器视觉的焊点检测研究[D]. 哈尔滨:哈尔滨工业大学,2017.



吴伟浩(1996-),男,2018年于中国计量大学获得学士学位,现为中国计量大学在读硕士研究生,主要研究方向为计算机视觉,1132579083@qq.com;



李青(1955-),男,通信作者,1982年于哈尔滨工业大学获得学士学位,现为中国计量大学教授,主要研究方向为电子电路设计与研究,1q13306532957@163.com。