

电子科技大学
UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

专业学位硕士学位论文

MASTER THESIS FOR PROFESSIONAL DEGREE



论文题目 **基于改进 YOLO 的 PCB 缺陷
检测方法研究**

专业学位类别 **电子信息**

学 号 **202152100109**

作者姓名 **姚印涛**

指导教师 **毕闯 副教授**

学 院 **航空航天学院**

分类号 TP389.1 密级 公开
UDC ^{注1} 004.8

学 位 论 文

基于改进 YOLO 的 PCB 缺陷 检测方法研究

(题名和副题名)

姚印涛

(作者姓名)

指导教师 毕闯 副教授
电子科技大学 成 都
(姓名、职称、单位名称)

申请学位级别 硕士 专业学位类别 电子信息
提交论文日期 2024 年 4 月 11 日 论文答辩日期 2024 年 5 月 31 日
学位授予单位和日期 电子科技大学 2024 年 6 月
答辩委员会主席 陈敏
评阅人

注 1: 注明《国际十进分类法 UDC》的类号。

Research on PCB Defect Detection Methods Based on Improved YOLO

A Master Thesis Submitted to
University of Electronic Science and Technology of China

Discipline **Electronic Information**

Student ID **202152100109**

Author **Yao Yintao**

Supervisor **Associate Prof. Bi Chuang**

School **School of Aeronautics and Astronautics**

摘要

印制电路板（Printed Circuit Board, PCB）是电子产品中较为核心的部件，在 PCB 的生产过程中，由于设备、工艺、人为操作等问题，容易产生诸多缺陷，如鼠咬、空洞、露铜、短路、断路、毛刺等。实现 PCB 缺陷精准、快速的检测，已然成为必要的一环。目前，对于 PCB 缺陷的检测有着多种方法：费时费力的人工视检，高操作要求的电气特性检测，基于图像处理的传统视觉检测，以及基于深度学习的目标检测等。其中，基于深度学习的目标检测方法因精度高、运算速度快而获得广大学者的青睐。PCB 缺陷检测目前大多采用 YOLO 作为深度学习模型，但它对 PCB 这类小缺陷目标的检测精度较低，近年也有着诸如 Transformer 等新模型的出现，故 PCB 缺陷检测方法有着很大的优化空间。

本文以单面的 PCB 裸板为检测对象，以常见的鼠咬、空洞、露铜、短路、断路、毛刺等六种缺陷为检测目标，结合当前最常用的图像处理与深度学习两种方法，提出一种基于改进 YOLOv5 的 PCB 缺陷检测方法。论文的核心研究内容包括：

（1）针对 PCB 小缺陷目标可提取特征少、信息在卷积过程易丢失的问题，在对比不同的图像预处理算法（包含图像增强与阈值分割）之后，选取了基于 Scharr 算子的图像锐化方法与 RGB 三通道的单阈值分割方法对 PCB 数据集做预处理工作，以强化其缺陷的信息特征，辅助模型进行特征提取。

（2）针对目前 YOLOv5 模型对小缺陷目标检测精度较低的问题，设计了一种基于改进 YOLOv5s 的 PCB 缺陷检测模型。该模型采用最新深度学习模型之一的 PVTv2（Pyramid Vision Transformer version 2）模型对 YOLOv5s 的 backbone 特征提取网络进行替换，同时使用广义金字塔 GFPN（Generalized-FPN）策略替换 YOLOv5s 模型 neck 网络的 PANet 策略，加强相邻两层之间的信息融合以更好地保留缺陷特征。

（3）设计了一种基于改进 YOLOv5s 模型的 PCB 缺陷检测系统，该软件可通过人机交互界面，指定选取对应的训练权重与训练模型，对 PCB 缺陷做检测。功能项分为图片检测、视频检测以及摄像头实时检测。

最后通过实验整理了改进后的模型的检测精度，实验结果表明：对比原有的 YOLOv5s 模型对 PCB 缺陷的检测效果，改进后的 YOLOv5s 模型的平均准确率均值（mAP）由原本的 95.99%提升至 98.60%，提升了 2.61%，且相对于 YOLOv8s 的 mAP 也更高，说明改进后的 YOLOv5s 模型在 PCB 缺陷检测的应用中达到了预期。

关键词：缺陷检测，图像预处理，PVTv2，GFPN

ABSTRACT

Printed Circuit Board (PCB) is a core component of electronic products. In the process of PCB production, due to equipment, process, human operation and other problems, many defects are prone to occur, such as mouse bite, missing hole, spurious copper, short, open circuit, spur, etc. To achieve accurate and rapid detection of PCB defects has become a necessary part. At present, there are many methods for PCB defect detection: time-consuming manual visual inspection, electrical characteristics detection with high operation requirements, traditional vision detection based on image processing, and object detection based on deep learning. Among them, the object detection method based on deep learning has been favored by many scholars due to its high accuracy and fast computing speed. Currently, most of the PCB defect detection methods use YOLO as a deep learning model, but its detection accuracy is low for small defect targets such as PCB. And in recent years, some new models, such as Transformer, are emerging, so there is great room for optimization of PCB defect detection methods.

In this thesis, with single-sided PCB bare plate as the detection object, six common defects such as mouse bite, missing hole, spurious copper, short, open circuit, spur as the detection targets, combined with the two most commonly used methods of image processing and deep learning, a PCB defect detection method based on improved YOLOv5 is proposed. The core research contents of the thesis include:

(1) For the problems of PCB small defects, which can extract few features and the information is easy to be lost in convolution process, different image preprocessing algorithms (including image enhancement and threshold segmentation) are firstly compared. And the image sharpening method based on the Scharr operator and the single threshold segmentation method of RGB three channels are selected to preprocess the PCB data set, so as to enhance the information features of the defects and assist the model in feature extraction.

(2) For the problem of low accuracy of the current YOLOv5 model for small defects, a PCB defect detection model based on an enhanced version of YOLOv5s is designed. This enhanced model uses PVTv2 (Pyramid Vision Transformer version 2), a state-of-the-art deep learning architecture, to supplant the backbone feature extraction network of YOLOv5s. At the same time, the generalized pyramid GFPN (Generalized-FPN) strategy is used to replace the PANet strategy of the neck network of YOLOv5s model, and the

information fusion between adjacent layers is strengthened to better retain the defect features.

(3) A PCB defect detection system based on improved YOLOv5s model is designed. The software can select the corresponding training weight and training model through the human-computer interactive interface to detect PCB defects. The functions are divided into image detection, video detection and real-time camera detection.

Finally, the detection accuracy of the improved model was summarized through experiments. The experimental results show that compared with the original YOLOv5s model for PCB defect detection, the average accuracy rate (mAP) of the improved YOLOv5s model was increased from 95.99% to 98.60%, an increase of 2.61%. Compared with the mAP of YOLOv8s, the improved YOLOv5s model also has a higher mAP, indicating that the improved YOLOv5s model has achieved the expected results in the application of PCB defect detection.

Keywords: Defect Detection, Image Preprocessing, PVTv2, GFPN

目 录

第一章 绪论.....	1
1.1 研究背景.....	1
1.2 国内外研究现状.....	2
1.2.1 国外研究现状.....	4
1.2.2 国内研究现状.....	5
1.3 研究目的与意义.....	6
1.4 研究内容与论文结构.....	7
1.4.1 研究内容.....	7
1.4.2 论文结构.....	10
第二章 YOLO 数据增强策略的优化.....	11
2.1 数据集获取与扩充.....	11
2.1.1 数据集扩充.....	11
2.1.2 数据集标签.....	12
2.2 图像预处理.....	13
2.2.1 图像增强.....	14
2.2.2 阈值分割.....	22
2.2.3 RGB 图像处理.....	26
2.3 数据增强策略的优化.....	27
2.4 本章小结.....	29
第三章 YOLO 结构改进方案的研究.....	30
3.1 基于深度学习的目标检测方法.....	30
3.1.1 特征提取与分类算法.....	30
3.1.2 BP 神经网络.....	31
3.1.3 卷积神经网络.....	32
3.1.4 常见的卷积神经网络.....	35
3.2 YOLOv5s 模型结构.....	38
3.2.1 backbone 网络.....	39
3.2.2 neck 网络.....	41
3.2.3 head 网络.....	43
3.2.4 YOLOv5s 模型总结.....	43
3.3 PVTv2 模型结构.....	43
3.3.1 Transformer 模型.....	44
3.3.2 PVTv1 模型.....	48
3.3.3 PVTv2 模型.....	49

3.3.4 PVTv2 模型总结	51
3.4 GFPN 模型结构	51
3.5 YOLOv5s 模型结构的改进	51
3.6 本章小结.....	53
第四章 软件系统设计与实验验证	54
4.1 软件系统实现.....	54
4.1.1 软件设计.....	54
4.1.2 人机交互界面实现.....	56
4.2 模型训练评价指标.....	59
4.3 模型训练.....	62
4.3.1 YOLOv5s 模型的训练结果	63
4.3.2 YOLOv5s+Scharrx 的训练结果	64
4.3.3 YOLOv5s+Scharrx+threshold 的训练结果	65
4.3.4 改进模型的训练结果.....	67
4.3.5 改进模型+Scharrx 的训练结果.....	68
4.3.6 改进模型+Scharrx+threshold 的训练结果.....	69
4.4 模型训练结果分析.....	71
4.4.1 数据整合与对比.....	71
4.4.2 YOLOv8s 结果对比	72
4.4.3 结果分析.....	73
4.5 PCB 缺陷检测效果测试.....	74
4.6 本章小结.....	75
第五章 总结与展望	76
5.1 总结.....	76
5.2 展望.....	77
参考文献.....	78

第一章 绪论

1.1 研究背景

得益于信息技术的发展,摄像机、扫地机器人、高端音响以及笔记本电脑等电子产品也在迅速地迭代升级中,它们逐渐成为了人们生活中随处可见的物品。随着“万物互联”思想的提出,一大批新兴技术正在国家政策的鼓励下越发壮大,比如大数据、人工智能等,但这些高技术产品也对基础硬件提出了更高的质量需求。

印刷电路板作为我国诸多行业的基础硬件产品,从改革开放以来,其复杂度、精细度都越来越高,在诸多 PCB (Printed Circuit Board, PCB) 生产厂家日益提高的生产力驱动下,PCB 的使用规模逐渐覆盖了我国各大行业领域,比如扫地机器人等民用产品、无人机等军用产品以及送餐机器人等商用产品。相对国外微电子行业的发展而言,我国这方面的起步较晚,但也出现了许多优秀的集成电路企业,如芯片行业中的中芯国际、手机起家的华为以及科技公司宁德时代等。

PCB 行业概况^[1]: 从目前世界发展的角度看,PCB 的应用几乎遍布了生活的所有领域,比如消费电子、医疗电子、汽车电子以及航空航天等。从人民使用与国家应用的角度来说,PCB 产业的发展水平可以体现在生活的各个方面,因此它能作为衡量一个地区高度自动化的标准,进而反映整个国家的工业自动化水平。PCB 产业水平越高,一般对应的电子制造产业发展速度越快。在科技发展的视角来看,全球各国正逐步迈向一个以智能制造为核心的新经济时代。在这一浪潮中,国外诸如德国和美国等国家已经率先提出了具有战略意义的发展目标,如德国的“工业 4.0”和美国的“工业互联网”,这些战略旨在通过深度整合先进技术与制造业,引领全球产业结构的转型升级,开启经济发展的新篇章。我国也随即提出了新的战略目标“中国制造 2025”,这一伟大而深远的目标是为了提升生产效率,促进产业升级和转型,进而提高智能制造的水平。为响应政策号召,通过“三步走”的规划以实现我国快速发展时期提出的制造业强国的战略目标,各部门先后出台了诸多政策以推动智能化产业,其中就包含对 PCB 行业的大力支持^[2]。

展望未来,PCB 行业将延续其稳健发展的态势。自我国改革开放以来,电子信息制造业始终占据着重要的战略地位,PCB 作为该领域的基础构件,相关行业在国家政策的推动下,必将持续健康发展。同时,随着汽车电子、消费电子等产业链的快速发展,PCB 作为各类电子产品不可或缺的组成部分,其市场需求必将呈现出爆发式增长的趋势。然而,由于 PCB 生产制作流程的复杂与繁复,包含钻孔、掩膜、电镀、刻蚀等在内的任何一个环节出现错误都会导致产品不合格率的提升。

因此, 针对 PCB 小缺陷目标的检测也成为关键环节, 完善这一过程不仅能提升工业生产效率, 同时能在保证产品合格率的情况下减少产品生产后期的功能异常。

本文的研究目标是: 基于现有的 PCB 缺陷检测模型, 从其特征提取、特征融合等环节寻找优化方案, 提升缺陷检测精度。下文将继续介绍国内外 PCB 缺陷检测的研究现状。

1.2 国内外研究现状

自我国生产 PCB 以来, 其表面缺陷检测从曾经的落后、缓慢发展到了现在的智能化, 整个发展过程出现的主要方法有: 人工目测法、电气检测法和传统视觉检测法。

(1) 人工目测法:

该方法依赖于人员劳动, 是工作人员使用具有一定精度的放大镜或者校准后的显微镜, 然后依靠自身肉眼的观测, 来确认 PCB 板是否符合工艺要求。这种方法的人工劳动强度大, 检测结果的有效性也受到很大限制, 且无法满足大量 PCB 板的检测需求。

(2) 电气检测法

这是一类使用飞针测试进行 PCB 缺陷检测的电气方法, 主要测量的 PCB 缺陷种类包含短路、开路、虚焊与漏焊等。但由于飞针检测是一种接触式检测, 故这种方法对产品存在着一定的损害。

(3) 传统视觉检测法

这是一种基于图像处理的 PCB 缺陷检测方法, 该方法依赖于高精度的图片与好的工业判断标准。首先通过摄像头对 PCB 板进行图像采集, 然后使用传统的图像处理算法将 PCB 缺陷进行放大, 然后将待检测的 PCB 板图像与标准合格的基准板图像做对比, 并使用设定好的参数、判断标准来对 PCB 缺陷进行判断。这种方法本身的图像配准算法泛化能力不强, 而且检测信息也有一定的不足^[3]。

近年来, 随着科技发展, PCB 板的制作工业要求越来越高, 其复杂度、精密度都远超以往, 由此对 PCB 缺陷的检测提出了更高的要求。但人工检测的不精准、高人力物力, 以及电气特性检测的高操作技术要求等问题, 都极大地限制了实际工业中的检测效率与精度; 而传统视觉检测法的算法大多是基于参考法的, 该方法的处理过程就决定了它难以处理复杂的背景信息, 所以对于 PCB 这类小缺陷目标的检测难度则更高。

与此同时, 出现了基于神经网络的深度学习检测方法, 这类方法的核心是使用神经网络对特征进行提取并学习, 而后进行缺陷检测, 相较于传统的视觉检测方法,

在拟合性和鲁棒性等方面表现出了显著优势，因此在图像检测领域得到了广泛应用^[4-6]。

随着众多学者的研究与实践，该领域也出现了诸多优点各异的卷积神经网络^[2]（Convolutional Neural Networks, CNN），如经典的 AlexNet^[7]、VGG^[8]、ResNet^[9]、GoogleNet^[10]等。它们在各个阶段（比如特征提取阶段或者特征融合阶段等）做出了适应性调整，取得了突出的成绩，而且这些网络的出发点也各不相同，有的从网络深度出发，有的从网络广度出发，去研究如何能够提高分类任务的识别精度。此外，由于当时有限的资源环境，各大神经网络也做出了相应调整，如 SqueezeNet^[11]、MobileNet^[12]、ShuffleNet^[13]、ESPNet^[14]等网络，其着眼点不仅在于降低参数量，同时也在保证精度的同时尝试提高训练速度，在经过改进后，相较于改进前的模型而言，它们虽然在图像分类的精度上没有取得很好的进展，但模型的层数在一定程度上减少了。

神经网络的检测方法，或注重检测速度，或注重检测精度，因而分为两类方法：

（1）以检测精度优先的双阶段检测网络，如 R-CNN 系列算法，这类网络旨在追求更高精度的检测结果，其检测流程分为两个核心阶段。首先，网络会对输入的图片进行初步分析，提取其中可能包含目标的候选区域，并生成候选框；然后，对所有的候选框根据各自特点进行分类，并根据目标独有的特征信息对其进行目标检测^[15]；

（2）以检测速度优先的单阶段检测网络，诸如 YOLO 系列算法，其特点在于将检测与预测融为一体，无需复杂的预选区域步骤。它采用简洁高效的线性回归计算方式，不仅加快了检测速度，更能直接预测待检测目标的类别与图中所处位置，显著提升了检测效率。

文献[16]对卷积神经网络进行了综述概括，鉴于深度学习在检测精度、速度等性能上远超传统方法，众多学者纷纷将其应用于缺陷检测领域，这一趋势也推动了深度学习在 PCB 缺陷检测领域的广泛应用，为相关研究带来了新的突破和进展。随着众多学者对目标检测的研究逐渐深入，近些年来，除了传统的基于神经网络的深度学习目标检测方法外，也出现了基于其他机制的深度学习模型，比如 Google 团队于 2017 年提出了基于自注意力（Self-Attention）机制的 Transformer 模型。该模型一开始主要用于处理序列数据，不同于传统基于卷积操作的检测方法，通过其独特的 Self-Attention 机制，在提升了训练速度的同时，可以直接获取任意两个位置元素之间的关系，从而获得了更完整的全局信息。

后来该模型逐渐被应用于目标检测，且取得了很不错的效果，广大学者也在其基础之上研究了诸多变种模型。比如 Google 团队在 2020 年提出的 Vit（Vision

Transformer) 模型, 就是在 Transformer 模型上加入了图片的分块处理等策略以减少模型运算量。在其基础上, 王文海等人提出的 PVT (Pyramid Vision Transformer) 模型^[17], 在 Transformer 模型基础上引入了 FPN 金字塔以获取更多尺度的特征图。

在广大学者的努力下, 关于深度学习领域的模型研究与改进仍在不断深入, 相应地, PCB 缺陷检测的模型也将持续处于迭代更新状态, 接下来, 将介绍国内外学者对 PCB 检测的研究状况。

1.2.1 国外研究现状

国外对部分先进技术的研究常早于国内, 但由于当前 PCB 数据样本量不足的局限性, 学者们更多将注意力放在了数据集丰富的磁瓦以及纺织物等材料的缺陷检测上^[1], 故对于 PCB 缺陷检测的研究进展相对较慢。

为了提升 PCB 小缺陷目标检测的准确性, 一些研究者持续对算法进行优化改进, 最终成功开发出一种基于丰富语义信息的单发检测器^[18]; 这种检测器在应用中展现出了优异的效果, 单发检测器将深层的语义信息传播到较低层, 并进行两个不同尺度的语义信息融合, 而后使用注意力机制来学习融合后的语义信息与特征关系; 实验证明, 该检测器的检测精度优于传统缺陷检测算法, 并且其 mAP (mean average precision) 值达到了 81.3%。针对 PCB 缺陷检测的问题, 有学者在数据集层面提出了一种创新性的改进算法^[19], 在该方法中, 他们不仅采用了传统的旋转、拼接等放射变换手段来丰富数据集, 还特意加入了经过人工模拟产生的数据集样本, 并利用卷积神经网络对缺陷特征进行高效提取, 最后根据实验结果对模型进行细致调整; 实验结果表明, 这种改进方法不仅显著提高了计算效率, 而且相较于原有模型, 其运算过程更为简洁, 同时能够准确识别出各类缺陷。Silva 等人从机器视觉的角度出发, 提出了一种自动光学检测方法^[20], 但由于当时落后的采集条件, 能够获取到的数据集样本较少, 无法满足模型因学习而产生的对大量数据样本的需求, 最终他们使用了预训练模型 VGG16 以及 ResNet50, 在数据样本有限的条件下完成了迁移学习; 实验证明, 此方法在采用迁移学习的策略后, 对 PCB 缺陷的检测精度达到了 89% 以上。Khalilian 等研究者提出了一种基于卷积操作的去噪自编码器方法^[21], 该方法被应用于 PCB 缺陷的分类检测中, 该方法首先通过该编码器实现了对 PCB 图像的重构, 然后使用参考法, 将待检测的 PCB 图像与标准基板图像进行比对, 从差异中定位缺陷所在位置; 实验证明, 该检测方法的检测精度高达 97.5%, 给当时该领域的研究者带来了巨大的鼓舞。文献[22]基于 RPN 与 Faster R-CNN 网络, 并采用 RPN 网络进行特征提取, 提出了一种基于 Faster R-CNN 的裂纹缺陷检测方法, 该方法最后结合 Faster R-CNN 网络实现了对缺陷的定位与分

类。文献[23]以 SSD 结构和 YOLO 结构为基础,全新构建了一个从粗到细的级联检测网络,该方法不仅在缺陷检测方面有着很好的应用前景,还对于固件的定位、缺陷分类有着良好的应用效果。文献[24]在文献[21]提出的卷积去噪自编码网络基础上,结合图像金字塔策略提出了一种斑点缺陷检测方法。文献[25]着眼于图像分割以及缺陷定位,提出了一种级联自动编码器结构。文献[26]中, Volkau 等人探究了一个新的模型,即尝试采用无监督深度学习模型对缺陷数量较少的样本进行训练。为了确定数据样本的最佳成本敏感阈值, Miao 等研究者采用了 NSGA-II 等优化算法,他们进一步提出了一种新颖的代价敏感神经网络深度学习模型^[27],并将此模型成功应用于 PCB 缺陷检测中,效果超过以往,使得其检测精度提高到了 97.60%。文献[28]中, Gang 等人从数据集的角度出发,提出了一个能够对不断增加的数据集做出相应的 n 点抽样的基础集,以及一个能够评估深度学习模型有效深度的核心集,其中模型对图像核心集的检测准确率提高到了 98.27%。

1.2.2 国内研究现状

国内对于 PCB 缺陷检测的相关研究,此前主要是使用一些传统表面缺陷检测的方法,比如图像配准法,而基于深度学习的目标检测方法的研究则起步相对较晚。

王永利等研究者在传统参考法的基础上进行了创新,提出了一种基于卷积神经网络的 PCB 缺陷检测方法^[29],该新算法首先利用参考法准确判定 PCB 的缺陷区域,接着设计了一个独特的卷积特征提取网络,对已经判定的缺陷区域进行深入的特征提取;实验证明,该方法的准确率远远高于传统的缺陷检测算法,且能够对已知的多种 PCB 缺陷有区分地进行识别。刘伟森等人将注意力放在卷积操作本身,使用改进的深度可分离卷积,从而提出了一种基于多尺度轻量级卷积网络的 PCB 缺陷识别算法^[30];实验证明,该算法不仅优于传统缺陷检测法,也优于经典卷积网络,并且其泛用性也比较高。文献[31]为了解决小样本和难样本问题,提出了两种改进的目标检测算法,从而提升了缺陷检测的正确率。沈非尧等人在对检测系统的现状与需求进行整体分析后,他们采用了一种新颖的方法完成了对小零件缺陷的检测^[32],即引入计算机显微视觉。文献[33]针对模型的结构进行研究,对模型的深度进行了堆叠,并结合归一化函数便捷化数据处理;实验证明,最终缺陷检测精度达到了 85%以上。后来有学者通过研究图像金字塔的结构、并利用其特点获取了多尺度的特征图,提出了一种微小的缺陷检测网络 TDD-Net,用于对 PCB 小缺陷目标进行检测^[34];实验证明,该方法的 mAP 高达 98.9%。文献[35]设计了一种新的 backbone 网络,即将 ResNet50 与 FPN 相结合,提出了一种基于改进 Faster R-CNN 与 FPN 结合的 PCB 缺陷检测方法;实验证明,该方法的 mAP 达到了 95.6%。

文献[36]提出了一种基于改进 YOLOv4 的 PCB 缺陷检测方法, 实验证明, 该改进方法的 mAP 达到了 96.88%。

1.3 研究目的与意义

由前文国内外研究现状可以看出: 对于 PCB 缺陷检测的方法整体分为两类, 一类是基于图像配准的传统视觉检测方法, 该类方法的检测速度较慢, 且检测精度很大程度受限于背景复杂度; 后来兴起的检测精度与速度整体更优的第二类检测方法, 为基于深度学习的 PCB 缺陷检测方法, 但该类方法目前研究所选用的模型大多较为老旧, 且检测精度仍有一定的可提升空间。

比如 Faster R-CNN 系列网络, 是基于先验框进行缺陷检测的, 但由于其先验框是预先设定好且不可调整的, 所以会出现先验框与数据集中的缺陷不适配的情形, 且互相重叠的候选框导致的特征冗余也极大地影响了缺陷检测效率; SSD (Single Shot MultiBox Detector) 模型检测精度略优于 YOLO, 但它依旧是采用基于 anchor 的策略来生成候选框, 这种方式对于密集目标的检测效果不够好, 容易出现重叠框的情况; YOLO 系列算法在精度与速度之间展现出了良好的平衡性, 多受工业检测领域的青睐, 尤其是其中的 YOLOv4 和 YOLOv5, 它们不仅在精度上表现出色, 同时在速度上也达到了较高的水平。然而, 当 YOLO 算法直接应用于 PCB 检测时, 仍存在一些不足和局限性, 需要进一步的研究和改进, 比如对于小缺陷目标检测效果差、精度较低。目前基于深度学习的目标检测, 对 PCB 的缺陷检测存在一定的可改进点^[1], 具体如下:

(1) 数据样本问题

目前 PCB 带有缺陷的数据样本严重不足, 目前大都依赖于北京大学的 693 张公开数据集图片。但基于深度学习的目标检测算法, 其模型训练效果、检测精度都在很大程度上与足够的数据样本量挂钩。然而实际情况却是, 众多 PCB 生产企业在当前的有限条件下, 无法对带有缺陷标签的数据集进行较大规模的采集, 因此 PCB 缺陷检测只利用了一部分深度学习的优势。

(2) 迁移学习精度受限

在深度学习领域, 迁移学习是一种提升模型精度的常用方法^[37], 该方法的有效性是建立在待检测数据集与公共数据集的图像之间的联系性上的, 要求二者具有相似的语义特征。在此基础上, 使用预训练模型, 并按照需求修改模型的输出层, 从而实现对缺陷的检测。但实际上 PCB 待检测的缺陷图像与公共数据集有着明显差异, 违反了迁移学习的基础, 因此若将迁移学习直接应用于 PCB 缺陷检测, 检测精度会受到限制。

(3) 模型改进空间大

现阶段而言，PCB 缺陷检测所采用的模型，普遍存在精度不够高、泛化能力偏弱等问题，因此模型需要针对很多不同领域的缺陷检测要求做优化或适应性调整。且近年来，目标检测领域还提出了一些优秀的模型方案，如 Transformer 模型及其变种等，而这些方案还未被广泛应用于 PCB 缺陷检测。

所以，本文的研究目的是：对于 PCB 这类小缺陷的目标检测，在现有 YOLOv5 模型架构基础上，借鉴新的深度学习模型，寻找检测速度更快、精度更高的优化方案，并在此基础上搭建 PCB 缺陷检测系统，对缺陷进行高效、高精度、实时检测，以满足当下市场对于 PCB 制造过程的诸多检测需求。

可以看出，不论是对模型改进方案的研究，还是对 PCB 缺陷检测系统的搭建，本文的研究都具备一定的实用性。

1.4 研究内容与论文结构

1.4.1 研究内容

在目标检测领域，若检测目标的尺寸不超过整张图像的十分之一，则被归属于小缺陷目标检测^[38]。如图 1-1 是本文六种 PCB 缺陷示意。




图 1-1 六种常见 PCB 缺陷。(a)缺失孔；(b)鼠咬；(c)开路；(d)短路；(e)毛刺；(f)余铜

图 1-1 对应的六类缺陷为：缺失孔--missing_hole、鼠咬--mouse_bite、开路--open_circui、短路--short、毛刺--spur、余铜--spurious_copper。可以看出：

(1) 这六类缺陷在整个图像中的占比是非常小的，所以是一种小缺陷目标检测。

(2) 六种缺陷集中在线路边缘与焊点区域, 所以如何提取并保留这些区域的特征, 是本文研究的重要出发点。

由于 PCB 缺陷属于小缺陷目标, 其分辨率低、可提取特征少, 信息在卷积过程中容易丢失, 故保留每一层缺陷的位置信息与语义信息显得尤为重要, 这直接影响到模型训练效果与最终检测精度。

基于上述小缺陷目标检测的特点与需求, 本文主要研究内容如下:

(1) 针对 PCB 小缺陷目标可提取特征少、信息卷积过程易丢失的问题, 本文考虑使用图像预处理, 强化数据集的缺陷特征, 辅助模型进行特征提取。图像预处理分为图像增强与阈值分割两部分, 本文将对直方图均衡与图像锐化中常用的算法以选取合适的图像增强算法, 对比 OTSU 阈值分割与单阈值分割等方法以选取合适的阈值分割算法。

(2) 针对目前 YOLOv5 模型对小缺陷目标检测精度较低的问题, 本文考虑借鉴当前特征提取与特征融合效果较好的新模型、新策略, 对 YOLOv5s 模型进行优化, 以提高模型检测精度。本文拟研究基于 Self-Attention 机制的 PVTv2 模型的优缺点, 并分析将其作为 backbone 网络进行特征提取的可行性; 此外, 将分析 YOLOv5s 的 PANet 策略, 对比广义金字塔 Generalized-FPN (GFPN) 策略于 PCB 缺陷检测的适用性, 以选取合适的特征融合策略。

(3) 为了满足工业中对 PCB 缺陷进行便捷、高效、实时的检测需求, 本文将设计一种基于改进 YOLOv5s 模型的 PCB 缺陷检测系统, 并搭建人机交互界面, 开发图片检测、视频检测以及摄像头实时检测功能。

针对上述研究内容, 给出对应实现的技术路线图, 如图 1-2 所示。




图 1-2 技术路线图

对技术路线图做如下说明：

(1) YOLO 优化分为两个部分

1) 对比并选取合适的图像预处理算法，以优化 YOLOv5 的数据增强策略。

2) 对模型结构进行改进, 使用 PVTv2 结构替换 YOLOv5s 的 backbone 特征提取网络, 并使用 GFPN 策略替换 neck 网络的 PANet 策略。

(2) 系统的软件设计包含两部分:

1) 模型的改进与训练

改进前后的模型均需训练, 且需要将训练好的模型权重文件提供给 PCB 缺陷检测系统, 用以后续的 PCB 缺陷检测。

2) PCB 缺陷检测系统

模型改进后, 将基于改进的模型设计 PCB 缺陷检测系统, 并搭建人机交互界面, 以便捷的操作实现对 PCB 缺陷的检测。

(3) 测试与验证包含两部分

1) 使用模型训练后导出的训练数据, 对比训练精度与混淆矩阵以确认模型改进的效果。

2) 使用 PCB 缺陷检测系统对数据集做缺陷检测, 并统计检测的精度。

1.4.2 论文结构

围绕论文的核心研究内容与目标, 本文的内容分为五章:

第一章, 绪论。首先对本文的研究背景进行叙述, 并综合分析国内外的研究现状, 给出本文的研究目的与研究意义; 然后概括本文的主要研究内容, 并在此基础上, 梳理本文的技术路线; 最后给出本文的论文结构安排。

第二章, YOLO 数据增强策略的优化。这一章节是本文模型改进方案的第一部分内容, 目的在于完成数据集的准备 (包含基础数据集与扩充数据集), 并完成图像预处理算法的对比、阐述 YOLOv5 的数据增强方案, 以选取合适的图像处理算法增加到 YOLOv5 的数据增强方案中。

第三章, YOLO 结构改进方案的研究。这一章节是本文模型改进方案的第二部分内容, 着重于分析 YOLOv5 网络结构合理的改进方案。在探究了 YOLOv5s 结构、PVTv2 结构以及 GFPN 结构的优缺点之后, 得出了合理的模型结构改进方案。

第四章, 软件系统设计与实验验证。在前文所有章节的研究基础上, 首先对本文软件设计方案做说明, 并完成 PCB 缺陷检测系统、人机交互界面的实现。之后将改进前后的模型进行训练并对比训练参数, 以验证模型改进的有效性。最后使用基于改进模型的缺陷检测系统对数据集进行测试, 以验证最终的检测精度。

第五章, 总结与展望。这一部分回顾了全文的研究内容, 对本文的研究成果进行工作总结, 并从实践角度出发, 对 PCB 缺陷检测系统的进一步改进方向进行展望。

第二章 YOLO 数据增强策略的优化

本章是 YOLOv5s 模型改进方案的第一部分，着重于 YOLO 数据增强策略的优化，将在获取数据集的基础上完成对数据集的扩充与图像预处理（包含图像增强与阈值分割）算法的选取。前者是支撑本文所有研究的数据来源；后者的目的在于研究可行的图像预处理方案以优化 YOLOv5 的图像增强策略，辅助模型进行特征提取。

鉴于本文研究的 PCB 缺陷属于小缺陷目标数据样本，缺陷特征在多次提取后易丢失，而图像预处理操作能更好凸显其特征信息，故本章在通过对比多种图像增强、阈值分割算法的实际处理效果后，对 YOLOv5 模型本身采用的数据增强操作进行了适应性调整，加入合适的图像增强与阈值分割操作，从一定程度强化了缺陷特征。

2.1 数据集获取与扩充

本文所采用的数据集为北京大学公开的 PCB 数据集，样本量本身只有 693 张，包含六类缺陷，即：缺失孔--missing_hole、鼠咬--mouse_bite、开路--open_circui、短路--short、毛刺--spur、余铜--spurious_copper。

2.1.1 数据集扩充

由于神经网络学习需要大量的数据集以保证模型的训练效果，所以需要 PCB 数据集进行扩充以满足 YOLO 模型的训练数据集要求。

数据增强^[39]是完成数据集扩充的常见方法，它是在原本已有的数据集样本基础上，通过旋转、裁剪、添加噪声和缩放等方式来扩增数据样本量。其目的在于获得足够大的样本数据用于模型训练，从而提升模型的鲁棒性与泛化能力，足够的样本用于训练也能够提升模型的检测精度。

常见的数据增强方式^[1]可以分为如下几种：

（1）几何增强

通过旋转、裁剪、缩放、平移以及添加噪声等几何变换的方式，消除数据集的尺度、位置和视角等差异。

（2）光学增强

采取多种手段进行数据预处理，包括调整样本的亮度、对比度，以及实施通道分离等方法，进行颜色空间变换，以消除数据集的色彩、亮度等差异。

（3）Mosaic 数据增强

该数据增强方式是从原本数据样本中随机选择一些图像区域，然后用这些图像区域的平均值来替换原本数据样本中的图像的像素值，从而产生一种模糊的效果。

(4) 其它增强方法，例如多样本数据增强和 CutMix 数据增强等。

本文通过缩放、翻转、旋转、添加噪声等共计 12 种图像变换方式，加上原始的图片，将原始数据集扩大为原来的 13 倍，共计 9009 张图片。图 2-1 是部分数据增强的效果。




图 2-1 部分数据增强效果。(a)调整亮度；(b)随机翻转；(c)垂直翻转；(d)调整对比度

考虑到 PVTv2 作为骨干网络需要较大的数据量以学习缺陷特征，但过大的数据量用于训练又会导致过拟合，故大致按照 5:3:2 的比例划分数据集，即选取其中 4500 张图片作为训练集，2500 张作为验证集，2000 张作为测试集；本文对应选取了 YOLOv5 中的轻量级网络 YOLOv5s 为基础进行模型的改进与优化，训练的 epoch 设置为 100，batch 大小设置为 16。

2.1.2 数据集标签

训练过程不仅需要带有缺陷的数据集，还需要标记有缺陷所在位置的标签文件，标签信息包含所检测缺陷种类的 id 编号（如 1 代表 missing_hole）和缺陷所在位置的坐标信息。

坐标信息一般用目标标注框的角点坐标来体现，以图像左上角为坐标原点，向右为 x 轴正方向，向下为 y 轴正方向建立直角坐标系，将缺陷所在边框的左上角、左下角、右上角、右下角坐标进行记录，即为标签文件需要的坐标信息。

本文使用 LabelImg 数据标注工具完成所有 PCB 数据集的缺陷标注，如图 2-2 是一个添加标签的过程。




图 2-2 LabelImg 工具添加标签

对数据样本中的每一个缺陷进行标注后，生成对应的 XML 文件信息，如图 2-3 所示。

```
<?xml version="1.0" encoding="UTF-8" standalone="no" ?>
<annotation>
  <folder>Missing hole</folder> //标签名称
  <filename>008555.jpg</filename> //图片名称
  <path>/home/weapony/Desktop/PCB DATASET/Missing hole/01 missing hole 01.jpg</path> //源文件路径
  <source>
    <database>Unknown</database>
  </source>
  <size>
    <width>3034</width> //图片宽
    <height>1586</height> //图片高
    <depth>3</depth> //图片通道数
  </size>
  <segmented>0</segmented>
  <object>
    <name>missing hole</name> //图片第一个目标类别名称
    <pose>Unspecified</pose>
    <truncated>0</truncated>
    <difficult>0</difficult>
    <bndbox>
      <xmin>2459</xmin> //图片第一个目标类别坐标信息
      <ymin>1274</ymin>
      <xmax>2530</xmax>
      <ymax>1329</ymax>
    </bndbox>
  </object>
  <object>
    <name>missing hole</name>
    <pose>Unspecified</pose>
    <truncated>0</truncated>
```

图 2-3 XML 文件

2.2 图像预处理

YOLO 作为单阶段检测网络，精度略有不足，而且本文 PCB 缺陷属于小缺陷目标，故为辅助模型进行特征提取，以提高检测精度，本文首先从输入图片入手，对 PCB 图像进行图像预处理。

鉴于图像预处理阶段，目的在于对比算法处理的效果，从而选取合适算法，故考虑到灰度图与 RGB 图的处理便捷性差异，所有的图像处理操作先选用灰度图进

行处理，以展示图像处理结果与对比算法的优劣，之后采用对应的算法进行 RGB 彩色图的图像处理。

2.2.1 图像增强

图像增强是图像处理中的常见手段，通过调整图像中像素分布，加强图像的部分特征区域，从而使图像具有丰富的信息量，以用于机器学习。常见的图像增强方法^[40]有直方图均衡、图像锐化（包含 Sobel 算子、Scharrx 算子、Laplacian 算子等）。

（1）直方图均衡

图像的不同部分具有差异性的像素分布，这些像素的灰度值信息以及像素之间的关联性，是整个图像的关键信息所在。一张理想的图片能够让处理任务事半功倍，但实际却是很多图像的像素分布集中在很狭小的区域，使得图像的对比度低，无法有效凸显需要的特征区域。直方图均衡能够适应性调整整张图的像素分布，被广泛应用于各种场景。

图 2-4 是一张 PCB 图像，因各点像素值不一样而呈现出不同的色彩。图 2-5 是像素直方图的示意，直方图均衡就是将这些像素按照一定比例重新分布，使其分布得更为均衡。




图 2-4 PCB 图片示意




图 2-5 像素直方图

直方图均衡是一种基于概率密度函数（Probability Density Function, PDF）的图形处理方法。对图像中的参量，设定 k 表示图像的灰度值；设定 X_k 是一个随机变量，对应灰度值为 k 的像素点在图中出现的频率；设定 r_k 表示灰度值为 k 的像素个数；设定图像像素总数为 N ；那么 r_k 在 N 中的比例 r_k/N 设定为灰度值 k 的概率 p_k 。直方图均衡计算方式是先统计每个像素值 k 的频率 X_k ，然后使用概率分布函数，计算每个像素出现的概率，即累计分布函数 $c(X)$ ，最后计算经过直方图均衡后的像素值，从而将像素的重新分布。在统计单个像素值 k 在图中出现的频率后，计算该离散灰度值的累计分布函数，它是对概率密度函数的积分，见式(2-1)：

$$c(X) = \sum_{i=0}^k p(X_i) \quad (2-1)$$

随后需要对均衡后的像素值进行计算，即将累积分布函数映射到另一个均衡化函数 $f(k)$ 。设图像中的最大灰度值为 L ，则 $f(k)$ 满足式(2-2)：

$$f(k) = (L-1)c(k) = (L-1) \sum_{i=0}^k p(X_i) \quad k = 0, 1, 2, \dots, L-1 \quad (2-2)$$

直方图均衡的意义在于，将图像中的像素映射到了分布更加广泛的区间范围。以数据集其中一张 PCB 图像为例，图 2-6 为其数据集 RGB 图片，图 2-7 为其灰度图，图 2-8 为其 RGB 图对应的 RGB 直方图，图 2-9 为其灰度图对应的像素直方图：




图 2-6 数据集原始 RGB 图像




图 2-7 数据集图像对应的灰度图




图 2-8 图像 RGB 图对应的直方图




图 2-9 图像灰度图对应的直方图

对灰度图进行直方图均衡，得到处理后的灰度图与直方图，如图 2-10、图 2-11 所示：




图 2-10 直方图均衡后的图像灰度图




图 2-11 直方图均衡后的图像灰度图对应的直方图

对比图 2-9 均衡前的直方图和图 2-11 均衡后的直方图，可以看出：经过直方图均衡后，图像中所有区域的灰度值被重新均衡分配，原本数据集图片中的灰度大都集中于 25 至 75 的区间内，而直方图均衡后，所有的灰度值被扩展到更大的 0 至 255 的范围内。由图 2-10 也可以看出，直方图均衡处理导致图像中原本的焊点、线路边缘与其余区域的差异减小。

本文所做的目标检测，对应的感兴趣区域是图中的焊点区域与线路边缘，在特征提取时需要获取相应的语义信息，所以图像预处理时需要增大焊点区域、线路边缘与其余区域的差异性，但直方图均衡的实际处理效果却与之相反，故不适用于本文的 PCB 图像处理。

（2）图像锐化

这是一种有目的地、利用图像中像素变化速度的不同，对图像中某些边缘信息进行鲜明化处理的方法。使用图像锐化，一方面能够将模糊的图像变得更加清晰，使原图像具有更大的对比度；另一方面能够凸显检测目标边缘，使其更适合于特征提取。本文研究的 PCB 小缺陷目标，主要分布在线路边缘与焊点区域，因此更关注它们与背景信息的差异，接下来将对基于不同算子的图像锐化方法进行图像处理效果展示。

1) Sobel 锐化

Sobel 算子是一种常用的一阶微分算子，不同于二阶算子，它对图像梯度变化的敏感度适中。针对给定的图像 $f(x,y)$ ，为了计算梯度的幅度，首先需要计算在 x 方向和 y 方向上的梯度，准确捕捉图像在不同维度上的灰度变化特征，随后进行梯度幅度的确定。这一过程有助于捕捉图像中线条和边缘的细微变化，从而增强图像的清晰度，计算公式如(2-3)：

$$|grad[f(x,y)]| = \sqrt{\left(\frac{\partial f}{\partial x}\right)^2 + \left(\frac{\partial f}{\partial y}\right)^2} \quad (2-3)$$

由于图像的灰度值是离散的，与连续图像不一样，故需要将上述公式改写成式(2-4)：

$$|grad[f(i_c, i_r)]| = \sqrt{[f(i_c+1, i_r) - f(i_c, i_r)]^2 + [f(i_c, i_r+1) - f(i_c, i_r)]^2} \quad (2-4)$$

进一步考虑到图像的处理速度，在实际应用中，会将该公式进行处理，常采用近似公式(2-5)进行计算：

$$|grad[f(i_c, i_r)]| = |f(i_c+1, i_r) - f(i_c, i_r)| + |f(i_c, i_r+1) - f(i_c, i_r)| \quad (2-5)$$

可以看出，这种计算是一种基于邻域的计算方式，即使用中心点与周围相邻点的灰度值。考虑到精确度，常用 8 邻域模板，其结构如图 2-12 所示：

P1	P2	P3
P4	P5	P6
P7	P8	P9

图 2-12 图像的 8 邻域结构

假设像素 p_5 是 3×3 梯度模板的中心点，则对应的 x 、 y 方向的 Sobel 锐化后的灰度值应该分开计算，如公式(2-6)所示。

$$G_x = \begin{bmatrix} -1 & 0 & +1 \\ -2 & 0 & +2 \\ -1 & 0 & +1 \end{bmatrix} * A \quad \text{and} \quad G_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ +1 & +2 & +1 \end{bmatrix} * A \quad (2-6)$$

其中 A 为原始图像，根据 x 方向和 y 方向上的权值矩阵，得到 Sobel 算子下的梯度计算公式(2-7)：

$$|grad[f(p_5)]| = \left| [f(p_7) + 2f(p_8) + f(p_9)] - [f(p_1) + 2f(p_2) + f(p_3)] \right| + \left| [f(p_3) + 2f(p_6) + f(p_9)] - [f(p_1) + 2f(p_4) + f(p_7)] \right| \quad (2-7)$$

对于任意一张灰度图，使用式(2-7)就可以计算图像中的各点在 Sobel 锐化处理下的梯度值，然后采取合适的方法改变各像素点灰度值，比如将梯度大于某一阈值的像素灰度值全增大。按照这种方式，就可以实现对图像感兴趣区域的增强。

现对图 2-7 灰度图进行 Sobel 锐化，其结果如图 2-13 所示：




图 2-13 Sobel 锐化后的图像

对比图 2-7，可以看出：经过 Sobel 锐化后，图像中所有边缘都得到了增强显示，能够更加明显地区分开焊点区域、线路边缘与其他区域，即图中的缺陷被展示得更为明显。

2) Scharrx 锐化

Scharrx 锐化的原理与 Sobel 锐化类似，也属于一阶微分算子，只是对应的权重不同，如式(2-8)为 x 、 y 方向上的 Scharrx 算子：

$$G_x = \begin{bmatrix} -3 & 0 & +3 \\ -10 & 0 & +10 \\ -3 & 0 & +3 \end{bmatrix} * A \quad \text{and} \quad G_y = \begin{bmatrix} -3 & -10 & -3 \\ 0 & 0 & 0 \\ +3 & +10 & +3 \end{bmatrix} \quad (2-8)$$

现对图 2-7 灰度图进行 Scharrx 锐化，其结果如图 2-14 所示：




图 2-14 Scharrx 锐化后的图像

对比图 2-7，可以看出：经过 Scharrx 锐化后，同样可以达到本文需要的图像增强效果。

3) Laplacian 锐化

相对于前文提到的一阶微分算子，Laplacian 算子是对图像做二阶微分处理，进而得到梯度变化更为明显的图像。对应的 Laplacian 算子如式(2-9)所示：

$$G = \begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix} \quad (2-9)$$

那么对于给定的任意图像 $f(x,y)$ 而言，可以定义它的拉普拉斯锐化计算公式，如式(2-10)：

$$\text{grad}^2[f(x,y)] = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2} \quad (2-10)$$

类似与 Sobel 算子的处理办法，在实际图像处理中，常使用公式(2-10)的离散形式，即式(2-11)：

$$\text{grad}^2[f(i_c, i_r)] = f(i_c + 1, i_r) + f(i_c - 1, i_r) + f(i_c, i_r + 1) + f(i_c, i_r - 1) - 4f(i_c, i_r) \quad (2-11)$$

由于是二阶微分操作，Laplacian 算子对像素值的突变更为敏感。实际应用中，通常会将 Laplacian 算子作用后的结果通过线性运算作用后，叠加到原图中，从而得到锐化后的图像。若设锐化后的图像为 $g(x,y)$ ，那么上述过程可以表示为式(2-12)：

$$g(x,y) = f(x,y) + c \cdot \text{grad}^2[f(x,y)] \quad (2-12)$$

其中，为了计算过程与实际处理的便捷性， c 通常取 1 或 -1。

现对图 2-7 灰度图进行 Laplacian 锐化，其结果如图 2-15 所示：




图 2-15 Laplacian 锐化后的图像

对比图 2-7, 可以看出: 经过 Laplacian 锐化, 图像中的边缘信息得到了进一步的增强, 但是图像已经模糊。

(3) 图像增强方案选取

前文对直方图均衡以及图像锐化的处理效果进行了展示, 根据实际效果决定, 本文选取图像锐化方式而非直方图均衡进行图像增强。

为了进一步选择后续使用的图像锐化算法, 现对 Laplacian、Sobel、Scharrx 锐化的结果进行对比, 对比效果如图 2-16 所示:




图 2-16 图像锐化后的图像对比。(a)Laplacian 锐化; (b)Sobel 锐化; (c)Scharrx 锐化

由图 2-16 可以看出，图像锐化中，Scharrx 锐化后的效果最佳，故本文后续对于图像增强的算法，选取基于 Scharrx 算子的图像锐化方法。

2.2.2 阈值分割

图像分割，顾名思义，是将一幅图像按照一定的规则进行分割从而获取对应的图像处理效果，一般是放大不同区域的特征差异。常见的阈值分割处理方法有最大类间方差法（OTSU）、全局单阈值分割等。

（1）OTSU 阈值分割

OTSU 是一种自适应确定阈值的算法。设定图像中所有的灰度等级分别为 $[1, 2, 3, \dots, L]$ ；设定灰度值为 i 的像素个数为 n_i ；那么原始图像 $f(x, y)$ 中的总像素个数为 $N = n_1 + n_2 + \dots + n_L$ 。在对灰度值进行二分类前，需要计算灰度值 i 对应的归一化概率 p_i ，如式(2-13)：

$$p_i = n_i / N \quad (2-13)$$

由于 OTSU 是一种基于二乘法的二分类算法，故需要将图像按照灰度值 k 的大小区别划分为 C_0 和 C_1 两类，其中，设定类 C_0 的灰度范围是 $[1, 2, 3, \dots, k]$ ，则类 C_1 的灰度范围是 $[k+1, k+2, k+3, \dots, L]$ 。由此，可以计算两个类的概率，如式(2-14)：

$$\begin{cases} \omega_0 = \omega_k = \sum_{i=1}^k p_i \\ \omega_1 = 1 - \omega_k = \sum_{i=k+1}^L p_i \end{cases} \quad (2-14)$$

更进一步，可以由式(2-15)求得两个不同类的均值：

$$\begin{cases} \mu_0 = \sum_{i=1}^k i p_i / \omega_0 \\ \mu_1 = \sum_{i=k+1}^L i p_i / \omega_1 \end{cases} \quad (2-15)$$

为了得到两个类的类间方差，先计算两个类各自的方差，如式(2-16)：

$$\begin{cases} \sigma_0^2 = \sum_{i=1}^k (i - \mu_0)^2 p_i / \omega_0 \\ \sigma_1^2 = \sum_{i=k+1}^L (i - \mu_1)^2 p_i / \omega_1 \end{cases} \quad (2-16)$$

最后由式(2-17)，可得到类间方差 σ_B^2 为：

$$\sigma_B^2 = \omega_0 (\mu_0 - \mu_T)^2 + \omega_1 (\mu_1 - \mu_T)^2 = \omega_0 \omega_1 (\mu_0 - \mu_1)^2 \quad (2-17)$$

其中， μ_T 是样本灰度值的总体均值，而 σ_B^2 则可以反映出两个类（即 C_0 和 C_1 ）之间的差异大小，它是一个以灰度值 k 为自变量的函数。而 OTSU 的核心思想就

是在灰度 $[1, 2, \dots, L]$ 中，通过最小二乘法找出合适的灰度值 k' ，使类间方差 σ_B^2 的取值最大。

由于已经选定图像锐化方法，现对经过 Scharrx 锐化后的图像进行 OTSU 阈值分割，其结果如图 2-17 所示：




图 2-17 OTSU 阈值分割后的图像，最佳阈值=49.0

对比 Scharrx 锐化后的图 2-14，从图 2-17 中可以看出，采取 OTSU 对图像进行阈值分割后，图像中的焊点区域与线路边缘被添加了过多毛刺，不利于后续的缺陷检测，故 OTSU 阈值分割不适合于本文的数据处理。

(2) 全局单阈值分割

全局单阈值分割指无论图像样本的像素大小，均按照统一的阈值拆分为两大类，而后对每一类做不同的处理，从而使得两个类中的像素差异增大，从而达到阈值分割目的。假设给定的图像 $f(x,y)$ ，按照不同需求设定一个阈值 T ，将像素分为两类，对大于 T 的像素值统一增大，小于 T 的像素值统一减小。由此，分割后的图像 $g(x,y)$ 的灰度重新分布，如式(2-18)所示：

$$g(x,y) = \begin{cases} 1, & \text{if } f(x,y) > T \\ 0, & \text{if } f(x,y) \leq T \end{cases} \quad (2-18)$$

其中， (x,y) 的取值范围是原始图像 $f(x,y)$ 中所有像素点。

灰度值范围为 0 到 255，其中 0 为黑色，255 为白色。在 OpenCV 的单阈值分割函数中，存在多种处理方式：

BINARY：超过设定阈值的部分取 255，否则取 0。

BINARY_INV：与 BINARY 操作相反。

TOZERO: 大于设定阈值的部分不改变, 否则设为 0。

TOZERO_INV: 与 TOZERO 操作相反。

TRUNC: 大于设定阈值的部分取设定阈值, 否则不变。

由于本文检测的缺陷存在于图像的焊点区域与线路边缘, 故需要尽可能放大焊点区域、线路边缘与其余区域的差别。焊点区域在灰度图中接近于白色, 即 255 灰度值, 线路颜色也比背景区域浅很多, 因此理论上选择 TOZERO 的方式进行单阈值分割最合适。

为进一步确认检测效果, 采用上述 5 种类型参数进行多次阈值分割, 结果如图 2-18 所示, 并逐一检验, 确实也是 TOZERO 的方式最合适。





图 2-18 单阈值分割后各种参数下的图片

对经过 Scharrx 锐化后的图像进行 TOZERO 单阈值分割, 取设定阈值为 10、25、50 的结果进行展示, 如图 2-19:



(a)




图 2-19 TOZER 单阈值分割后的图像。(a)阈值=10；(b)阈值=25；(c)阈值=50

对比图 2-19 中的三种阈值下的处理图像，可以看出，阈值为 10 时效果较好，不仅增强了图像中的线路边缘信息，也使得焊点与非焊点区域保持了一个较大的差异性。

(3) 阈值分割算法的选取

根据前文分析，OTSU 阈值分割使得线路边缘出现了很多毛刺，不利于后续的缺陷检测；而 TOZER 的单阈值分割能够很好地将焊点区域、线路边缘进行凸显，与本文放大缺陷特征信息的方向是一致的，故本文后续采用参数为 TOZER 的单阈值分割方法进行阈值分割操作。

2.2.3 RGB 图像处理

根据前文对图像增强算法（包含直方图均衡与图像锐化）以及阈值分割算法（包含单阈值分割与 OTSU 分割）的实践与对比，本文最终选用基于 Scharrx 算子的图像锐化方法实现图像增强，之后选用参数为 TOZER 的单阈值分割算法实现阈值分割。

由于 PCB 数据集为 RGB 图，本文继续完成 RGB 三通道的图像处理。RGB 图如图 2-20 所示，对其进行图像处理的效果展示。




图 2-20 RGB 原图

经过基于 Scharrx 算子的图像锐化后，其结果如图 2-21 所示。




图 2-21 RGB 图像-基于 Scharrx 算子的图像锐化图像

可以看出，对于 RGB 图像，经过基于 Scharrx 算子的图像锐化后，有效加强了线路边缘与焊点区域，即对凸显缺陷区域是有效的。

在此基础上, 继续进行阈值分割操作, 结果如图 2-22 所示。




图 2-22 RGB 图像-图像锐化、阈值分割后的图像

可以看出, 对于 RGB 图像, 在图像锐化后, 进行阈值分割, 进一步强化了焊点区域、线路边缘与背景的区别。

2.3 数据增强策略的优化

前文研究的图像增强、阈值分割方法后续将加入 YOLOv5 模型对 PCB 图像的处理操作中, 为探究其可行性, 先了解 YOLOv5s 本身的数据增强策略。

(1) YOLOv5s 的数据增强策略

YOLO 中为了加强训练的有效性, 在图片输入到神经网络前, 对数据集的图片也做了一定的图像增强处理, 前文在数据集扩充部分初步介绍了图像增强的几种方式, 包含几何增强、光学增强、Mosaic 增强等, 在此额外详尽介绍 YOLOv5 为加强模型鲁棒性而采用的 4 邻域 Mosaic 增强。

Mosaic 数据增强技术, 作为一种常见的数据增强手段, 可以用于提高深度学习模型在目标检测、图像分割等任务中的性能。Mosaic 数据增强的核心思想是在图像中随机选取一些区域, 然后用这些区域的平均值或中值来替换原图像中的像素值, 从而产生一种模糊的效果, 类似于图像中的马赛克。

具体来说, Mosaic 数据增强可以通过以下步骤来实现:

- 1) 随机选取一些区域: 在原图像中随机选取一些区域, 可以使用固定大小的窗口或者根据图像大小和目标尺寸来计算合适的窗口大小。
- 2) 生成马赛克效果: 将选取的区域用区域内像素值的平均值或中值来替换原图像中的像素值, 从而产生一种模糊的效果。

3) 调整参数: 可以根据需要调整马赛克窗口的大小和像素值替换的方法, 以得到更好的数据增强效果。

4) Mosaic 数据增强有着诸多好处, 一方面可以帮助模型以更好的方式学习和识别目标, 从而提高模型的性能和鲁棒性。此外, Mosaic 数据增强还可以通过增加数据的多样性的方式有效地防止过拟合, 从而提高模型的泛化能力。

总之, Mosaic 数据增强作为常见的数据增强技术, 可以用于提高深度学习模型在目标检测、图像分割等任务中的性能。

YOLOv5 使用的 4 邻域 Mosaic 增强从 YOLOv4 开始被引入的, 它利用随机方式增强后的四张图片, 对四张图片进行随机拼接, 形成新的数据图片, 之后再传入神经网络中进行训练, 这样就极大丰富了数据样本的检测背景复杂度, 从而提升了模型训练效果与鲁棒性。图 2-23 是 YOLOv5s 训练过程中的一组 batch 图片, 可以看到每一张输入图片都是经过了 4 邻域 Mosaic 增强的。




图 2-23 YOLOv5 的一组 batch-4 邻域 Mosaic 增强

(2) 数据增强策略的优化

根据官方文件, YOLOv5s 有着包含旋转、剪切、平移以及 Mosaic 增强在内的多种图像增强方式, 但并不包含本章研究的图像增强与阈值分割操作, 故在后续的数据集的处理中, 会在 YOLOv5 的数据增强板块, 加入基于 Scharrx 算子的图像锐化方法与 RGB 三通道的单阈值分割方法, 在模型训练过程中使用。

2.4 本章小结

本章完成了用于模型训练与测试的数据集的获取与扩充, 以及图像预处理相关算法的对比选取。由于 PCB 缺陷属于小缺陷目标, 其特征在卷积过程中容易丢失, 故每一层缺陷特征的保留都显得尤为重要, 本章着重于对数据集进行图像增强、阈值分割等预处理操作, 以强化 PCB 本身的缺陷特征, 辅助模型进行特征提取。在后续章节中, 本章研究的图像增强与阈值分割方法将加入 YOLOv5 的数据增强策略中。

第三章 YOLO 结构改进方案的研究

本章是 YOLOv5s 模型改进方案的第二部分,着重于 YOLO 模型结构的改进。自 YOLO 模型发展至今,其特征提取网络 backbone、特征融合网络 neck 与预测网络 head 部分经过不断优化与改进,其模型的鲁棒性、预测准确率等都逐渐上升,也出现了越来越多的改进方案与优化算法。其中,结合 FPN 特征金字塔与 Transformer 后形成的 PVT (Pyramid Vision Transformer) 模型成为了近些年研究的热门;此外,FPN 的一种改进策略 Generalized-FPN (GFPN) 也逐渐适用于诸多场景。本章将先探讨基于深度学习的检测算法,然后重点分析 YOLOv5s 模型、PVT 模型与 GFPN 的结构与特点,以选取合适的方案与策略对 YOLOv5s 模型结构进行改进。

3.1 基于深度学习的目标检测方法

基于深度学习的缺陷目标检测技术,具备自我识别目标特点的功能,其在模型匹配和稳健性上都超过了常规的目标识别技术,因此已被普遍运用到图像识别的各个环节^[4-6]。

神经网络的检测方法,或注重检测速度,或注重检测精度,因而分为两类方法:

(1) 以检测精度优先的双阶段检测网络,如 R-CNN 系列算法,这类网络旨在追求更高精度的检测结果,其检测流程分为两个核心阶段。首先,网络会对输入的图片进行初步分析,提取其中可能包含目标的候选区域,并生成候选框;然后,对所有的候选框根据各自特点进行分类,并根据目标独有的特征信息对其进行目标检测^[15];

(2) 以检测速度优先的单阶段检测网络,诸如 YOLO 系列算法,其特点在于将检测与预测融为一体,无需复杂的预选区域步骤。它采用简洁高效的线性回归计算方式,不仅加快了检测速度,更能直接预测待检测目标的类别与图中所处位置,显著提升了检测效率。

3.1.1 特征提取与分类算法

(1) 特征提取

王姮、钱晓亮等人深入研究了表面缺陷图片的特征提取方法^[41-42],其方式是借助视觉显著性这一技术手段(视觉显著性,即通过算法模拟人类视觉机制)有效凸显图像中的关键区域,当图像表面缺陷明显且与其他部分形成鲜明对比时,采用此方法尤为有效。在文献^[41]中,研究者们将图像细分为若干小块,并从四个方面综

合考量其视觉显著性：与整体图像平均值的比较、在所属图像中的独特程度、颜色方面的突出性以及图像布局中的位置。此外，文献[43-47]还提及了二维傅里叶变换和小波变换在提取产品表面特征方面的应用。文献[43]通过应用二维傅里叶变换，实现了缺陷与背景的分离，进而实现了对缺陷特征的精准提取，这一方法不仅提高了缺陷检测的准确性，也为后续的表面质量分析提供了有力支持。

(2) 分类算法

张宏杰等人运用了贝叶斯最小风险决策理论^[47]，建立了基于图像识别的焊点质量分类器。另一方面，支持向量机（SVM）分类方法因其卓越的性能而备受瞩目，它所需样本量少、训练速度快且泛化能力强，因此在表面质量检测领域得到了广泛的应用和认可^[45-46]。这些方法的结合与应用，不仅提升了分类的准确性，也为表面质量检测提供了更为可靠的技术支持。

3.1.2 BP 神经网络

神经网络^[48]，顾名思义，是一种类似大脑神经的数学模型，它借鉴神经网络的结构与特点，以神经元间的连接为基础来捕获和处理输入信息，主要分为 BP 神经网络^[48]与卷积神经网络（CNN）^[16]两大类。

BP 神经网络主要用于特征向量的回归与分类。其结构较为复杂，如图 3-1 所示，它是一种多层组合的前馈网络，由输入层、中间层（也称隐含层，因为输入层与输出层才与外界连接）和输出层构成。




图 3-1 BP 神经网络结构

图 3-1 中, X_i 代表神经网络的输入, v_{ij} 与 ω_{ij} 表示神经元之间的连接权重, f_i 表示隐含层的输出, Y_i 表示网络的输出, a 为隐含层阈值, b 为输出层阈值。

可以看出, BP 神经网络包含信息前向传播路线以及误差反向传播路线。其中, 信息前向传播路线, 主要用于计算神经网络的实际输出, 并根据样本真实值, 构建误差函数; 而误差反向传播路线, 主要在于使用误差函数优化网络参数, 使得输出误差达到最小值, 从而保证结果的精确性。

3.1.3 卷积神经网络

卷积神经网络 (CNN) 主要用于特征提取。相较于传统机器学习方法, 其显著优势在于无需人工干预特征设计和阈值设定, 而是完全依赖样本训练来自动调整模型参数。这种自动学习的特性使得 CNN 能够直接接收图片输入, 并直接输出识别结果, 从而极大地简化了特征提取和分类过程。

通过深入研究, 学者们发现 CNN 的性能与其层数密切相关。具体而言, 网络层数越深, 其学习和表达能力便越强, 这种深层次的神经网络被称为深度神经网络, 并在实际应用中被众多学者广泛采用。

卷积神经网络是一种与 BP 神经网络完全不同的前馈网络, 它的算法基于特征提取能力更强的卷积操作, 同时为了减小运算量, 在卷积层后叠加了池化层。在这种独特的结构作用之下, CNN 能够通过多次卷积与下采样对底层特征图进行处理, 从而获得语义信息更强的高层特征图。其中 LeNet 网络是最早的 CNN 之一^[48], 它的提出最初是用于识别手写字符的, 结构如图 3-2 所示。




图 3-2 LeNet 网络结构

从图 3-2 中可以看出, LeNet 网络通过连续多次的卷积、下采样结合的方式, 获取了多层特征图。

(1) 卷积层

卷积层通过对邻域进行卷积运算, 利用合适大小的卷积核进行特征提取。卷积层运算如图 3-3 所示。




图 3-3 卷积层卷积运算

(2) 池化层

池化层的作用在于缓解计算过程中的内存压力。其操作主要基于最大池化和平均池化两种方法。具体而言，平均池化是通过累加池化窗口内的像素特征值，并计算其平均值，进而将该平均值作为特征输出。而最大池化则是通过寻找池化窗口内所有像素点特征值的最大值，并将其作为特征输出。两种池化过程如图 3-4 所示。




图 3-4 平均池化与最大池化运算

(3) 激活函数

线性模型中，输出结果是输入的加权和，其显著特性在于任何线性模型的组合仍旧保持其线性属性，即组合后的模型依然为线性模型。这一特点确保了线性模型的灵活性和可组合性，为实际应用提供了广泛的适用性，但线性函数的复杂度与学习能力有限，因此引入非线性激活函数，以提高神经网络的学习能力。

1) Sigmoid 激活函数，常用于二分类任务，式(3-1)为其函数表达式：

$$a = \frac{1}{1 + e^{-z}} \tag{3-1}$$

对应的图像是一种 S 型曲线，如图 3-5 所示。




图 3-5 Sigmoid 激活函数

通过上图可知，其值域落在 $(0,1)$ 区间内。特别地，当 z 取值为 0 时，输出恰好等于 0.5，即 Sigmoid 函数的输出值中心并非 0，而是以 0.5 为中心，这种非中心化的输出特性对于后续的训练过程并不利。除此之外，Sigmoid 函数有着更严重的缺点：当输入 z 的数值过大或过小时，函数输出值趋于定值，对应的梯度会趋近于 0，也就是会导致梯度消失现象。所以，在实际的样本训练任务中，Sigmoid 激活函数的使用频率较低，而常使用 tanh 激活函数作为替代。

2) Tanh 激活函数，数学表达式为(3-2)：

$$a = \frac{e^z - e^{-z}}{e^z + e^{-z}} \quad (3-2)$$

函数图如图 3-6 所示。




图 3-6 Tanh 激活函数

根据上图的展示，其值域范围是 $(-1,1)$ 。在 $z=0$ 的情况下，输出值为 0。Tanh 函数的输出值以 0 为中心，这种数据中心化的效果有助于提升下一层的学习效率。

然而，与 Sigmoid 函数相似， z 过大或过小，其输出也趋于固定值，易导致梯度消失现象。

3) ReLu 激活函数，数学表达式为(3-3):

$$a = \max(0, z) \quad (3-3)$$

函数图如图 3-7 所示。




图 3-7 Relu 激活函

由图 3-7 可知，当 $z \geq 0$ 时， $a=z$ ；当 $z < 0$ 时， $a=0$ 。由于其函数值与自变量是线性关系，且梯度更大，所以它在前向传播和反向传播过程中均展现出了极快的计算速度，这一特点使得 ReLu 激活函数在处理大规模数据集和复杂神经网络时具有显著优势，能够有效提高训练效率。

然而，ReLu 函数也有着一定的缺点：当输入 $z < 0$ 时，函数输出值为 0，对应的梯度也为零。但因为大部分输入 z 一般都是正值，所以 ReLu 函数依旧适用于大多数场景。

3.1.4 常见的卷积神经网络

随着众多学者的研究与实践，出现了诸多优点各异的卷积神经网络^[2]，如经典的 AlexNet^[7]、VGG^[8]、ResNet^[9]、GoogleNet^[10]等。它们在各个阶段（比如特征提取阶段或者特征融合阶段等）做出了适应性调整，取得了突出的成绩，而且这些网络的出发点也各不相同，有的从网络深度出发，有的从网络广度出发，去研究如何能够提高分类任务的识别精度^[49]。此外，由于当时有限的资源环境，各大神经网络也做出了相应调整，如 SqueezeNet^[11]、MobileNet^[12]、ShuffleNet^[13]、ESPNet^[14]等网络，其着眼点不仅在于降低参数量，同时也在保证精度的同时尝试提高训练速度，

在经过改进后,相较于改进前的模型而言,它们虽然在图像分类的精度上没有取得很好的进展,但模型的层数在一定程度减少了。

(1) AlexNet

AlexNet 是在 LeNet^[50]结构上,通过调整不同层级网络的层数而进行改进的。其结构如图 3-8 所示。




图 3-8 AlexNet 模型

AlexNet 网络通过增加一个 GPU 的方式使模型能够并行计算,在卷积后选择最大池化层减少运算参数,且最后使用 Dropout 方法增加模型的鲁棒性。

(2) VGG

VGG 模型与 AlexNet 不同,其训练过程的参数更多,但适当减少了拟合次数,且比 AlexNet 性能更好,结构如图 3-9 所示。




图 3-9 VGG 模型

(3) GoogleNet

GoogleNet 的提出,旨在解决计算过程庞大的参数量问题,该模型提出了具备多分支特性的 inception 结构,通过融合不同尺寸的卷积核以及池化操作,它能够捕获到多样化的感受野,从而丰富网络的特征表示能力。这种设计使得 inception 结构在深度学习中具有广泛的应用前景,尤其在处理图像识别等复杂任务时表现出色。如图 3-10 所示,是 GoogleNetv1 的网络结构。

type	patch size/ stride	output size	depth	#1×1	#3×3 reduce	#3×3	#5×5 reduce	#5×5	pool proj	params	ops
convolution	7×7/2	112×112×64	1							2.7K	34M
max pool	3×3/2	56×56×64	0								
convolution	3×3/1	56×56×192	2		64	192				112K	360M
max pool	3×3/2	28×28×192	0								
inception (3a)		28×28×256	2	64	96	128	16	32	32	159K	128M
inception (3b)		28×28×480	2	128	128	192	32	96	64	380K	304M
max pool	3×3/2	14×14×480	0								
inception (4a)		14×14×512	2	192	96	208	16	48	64	364K	73M
inception (4b)		14×14×512	2	160	112	224	24	64	64	437K	88M
inception (4c)		14×14×512	2	128	128	256	24	64	64	463K	100M
inception (4d)		14×14×528	2	112	144	288	32	64	64	580K	119M
inception (4e)		14×14×832	2	256	160	320	32	128	128	840K	170M
max pool	3×3/2	7×7×832	0								
inception (5a)		7×7×832	2	256	160	320	32	128	128	1072K	54M
inception (5b)		7×7×1024	2	384	192	384	48	128	128	1388K	71M
avg pool	7×7/1	1×1×1024	0								
dropout (40%)		1×1×1024	0								
linear		1×1×1000	1							1000K	1M
softmax		1×1×1000	0								

图 3-10 GoogleNetv1 模型

(4) ResNet

ResNet 的提出是为了处理训练过程的梯度消失问题，核心结构是残差网络，结构如图 3-11 所示。




图 3-11 shortcut 连接

在此基础上，图 3-12 是 ResNet34 的结构。




图 3-12 ResNet34 结构

（5）Faster R-CNN

Faster R-CNN 是一类基于候选区域的经典算法^[51]，其基础是 R-CNN 模型^[52]。R-CNN 模型对于候选区域的生成，所采用的算法是选择性搜索，但该方法产生了许多相互重叠的候选框而导致特征冗余。文献[53]提出一种 Fast R-CNN 模型，直接将候选框映射到最后一层特征图像，从而减少了重复计算量，然而 Fast R-CNN 模型的候选区域生成方法仍然是选择性搜索。文献[54]提出的 Faster R-CNN 用神经网络来生成候选框，大大提升了算法速度，其网络结构如图 3-13 所示。




图 3-13 Fater R-CNN 网络结构图

（6）YOLO 模型与近年最新的基于自注意力机制的 PVTv2 模型，是本文所用的核心模型，在下一部分着重介绍。

3.2 YOLOv5s 模型结构

YOLOv5s 的模型结构如图 3-14 所示：




图 3-14 YOLOv5s 模型结构图

3.2.1 backbone 网络

(1) 模块组成

backbone 网络由若干卷积层 CBS/Conv 与若干 C3/CSP 模块，以及最后一层的 SPPF 模块组成。

CBS/Conv 模块：该模块内嵌卷积操作 Conv 模块、用于对同一 batch 中数据进行归一化处理的 Batch Normalization (BN) 模块，以及非线性激活模块 SiLU。

C3/CSP 模块：结构如图 3-15 所示。将输入特征图卷积后得到特征图 1，将特征图 1 经过 Bottleneck（结构如图 3-16 所示）残差块后得到特征图 2，最后再将特征图 1 与特征图 2 进行拼接。即将原始输入与经过残差块（在当前特征图结果上

加上上一层全部信息，以尽可能保留更多卷积前的特征信息) 后的结果相加，在尽可能保留特征信息与精度的同时减少运算量。




图 3-15 C3 模块图




图 3-16 Backbone 中的 Bottleneck 结构图

SPPF 模块：结构模块图如图 3-17 所示。将经过 CSB 后的输入 x 、一次最大池化后的输出 y_1 、两次最大池化后的输出 y_2 以及三次最大池化后的输出 y_3 进行拼接，目的在于尽可能多地提取高层次特征图的语义特征。




图 3-17 SPPF 模块结构图

(2) 参数

backbone 网络参数如下图 3-18 所示:

```
# Parameters
nc: 80 # number of classes
depth_multiple: 0.33 # model depth multiple
width_multiple: 0.50 # layer channel multiple

# YOLOv5 v6.0 backbone
backbone:
  # [from, number, module, args]
  [[-1, 1, Conv, [64, 6, 2, 2]], # 0-P1/2
   [-1, 1, Conv, [128, 3, 2]], # 1-P2/4
   [-1, 3, C3, [128]],
   [-1, 1, Conv, [256, 3, 2]], # 3-P3/8
   [-1, 6, C3, [256]],
   [-1, 1, Conv, [512, 3, 2]], # 5-P4/16
   [-1, 9, C3, [512]],
   [-1, 1, Conv, [1024, 3, 2]], # 7-P5/32
   [-1, 3, C3, [1024]],
   [-1, 1, SPPF, [1024, 5]], # 9
  ]
```

图 3-18 Backbone 参数

nc=80: 表示数据集中的类别数。

depth_multiple=0.33: 该参数用于控制模型的深度, 数值代表着当前模块的数量, 但仅用于 number 不为 1 时。[-1, 3, C3, [128]]中, C3 模块有 1 个 (3×0.33)。

width_multiple=0.50: 该参数通过调整卷积核的大小从而控制模型的宽度, 如 ch_out=64, 代表当前的卷积核为 64×0.5 , 对应结果会输出 32 通道的特征图。

from: 表示从第 n 层获得输入, 其中 -1 表示上一层。

number: 表示模块的数目, 不为 1 时需要乘以模型深度。

model: 表示具体模块。

args: 向模块需要传递的参数[ch_out, kernel, stride, padding, groups]。

stride: 卷积操作中的步长设置。

padding: 保证特征图尺寸时的填充值。

group: 分组卷积。

每一层特征图的尺寸计算公式为:

$$Feature_new = (Feature_old - kernel + 2 \times padding) / stride + 1$$

3.2.2 neck 网络

(1) 模块组成

neck 网络由 CBS、Upsample、Concat 与不带有 shortcut 的 C3/CSP 模块组成。

其中 CBS、Concat 模块与 Backbone 网络中一致。

而 C3 模块略有差异，不具有残差效果，结构如图 3-19 所示。




图 3-19 neck 中的 Bottleneck 结构图

Upsample: 上采样，将特征图尺度恢复到原来的尺寸，以进行进一步的特征融合或者特征提取。与之相对应的下采样，常使用卷积层或池化层，作用在于降低特征维度，减少计算量，同时也使得后续的语义信息更为明显。

(2) FPN 改进结构 PANet

卷积后上层的深度更深，所以包含的语义信息更明显，而卷积加深的过程，也会逐渐丢失位置信息。即更丰富的语义信息在深层网络，更准确的位置信息在底层网络。为了将深层的语义信息与底层的位置信息进行融合，YOLOv5s 的 neck 部分设计是基于 FPN 金字塔的改进结构 PANet，其结构如图 3-20 所示。




图 3-20 FPN 与 PANet

1) FPN 结构

自下而上，通过下采样丰富语义信息的同时缩小特征图尺度；

自上而下，通过上采样丰富位置信息的同时还原特征图尺度；

横向连接，将两个过程中的同尺度特征图进行尺度融合，以获取位置信息、语义信息都丰富的特征图，用于最后的预测。

2) PANet 结构

在 FPN 结构的基础上，对自下而上的线路进行了加强，然后对位置信息与语义信息做进一步跨层融合，获得更丰富的信息，用于最后的预测。

3.2.3 head 网络

Head 网络的核心组成部分是三个 Detect 检测器，它们负责在不同尺度的特征图上进行精准的目标检测任务。对于 YOLOv5s 模型，其输入为 640×640 的图片，最终用于预测的特征图尺度为 80×80 、 40×40 、 20×20 。预测网格的尺寸与特征图尺寸相同，即 20×20 的特征图会变成 20×20 的网格，由于图像本身是 640×640 ，故每一个网格对应的像素大小为 32×32 。

3.2.4 YOLOv5s 模型总结

根据前文对 YOLOv5s 模型结构的梳理，可以看出：

(1) YOLOv5s 模型的 backbone 特征提取网络是完全基于卷积操作的，在这个过程中，图片原本的信息存在丢失。

(2) YOLOv5s 模型的 neck 特征融合网络采用 FPN 的改进结构 PANet，进一步加强了信息融合效果。

(3) 对于本文的 PCB 小缺陷目标类型，每一层的语义信息和位置信息都非常重要。而卷积过程容易丢失信息；且 PANet 的融合方式是跨层的多尺度融合，没有相邻层的信息融合与保留。故后续考虑对特征提取、特征融合网络做改进，寻求更优化的模型方案。

3.3 PVTv2 模型结构

PVTv2 (Pyramid Vision Transformer version 2) 模型是基于 Transformer 模型的最新改进模型之一，其特征提取并不依赖于卷积操作，可以更好保留缺陷信息，且能够很便捷地获取任意两个位置元素之间的信息，所以能够作为新的特征提取网络。相对 YOLOv5 的 backbone 特征提取网络，PVT2 结构具有更好的特征提取效果，本文将采用 PVTv2 模型用于 YOLOv5s 模型 backbone 网络的替换，而 PVTv2

模型是在 PVTv1 模型基础上进行改进的,后者又是基于 Transformer 模型的变种模型,故此先对相关模型做概述。

3.3.1 Transformer 模型

Transformer 模型是 google brain 在 2017 年提出的专注于解决自然语言处理的深度学习模型,它的出现旨在引入自注意力机制(Self-Attention)机制来解决 RNN 系列模型在处理长序列数据时的部分问题,比如 RNN 难以进行并行计算与难以捕捉长距离依赖的问题。由于它具备训练时间更少、并行度更好、效果更好以及模型架构简单等诸多优点,在随后的时间里,深度学习领域涌现了大量基于 Transformer 模型的变种模型,而 PVT(Pyramid Vision Transformer)模型正是其中之一,在其基础改进的 PVTv2^[17]模型更是最新提出的模型之一。

在卷积神经网络中,由于卷积的窗口很小,对于两个相差较远的像素,如果要得到这两个像素之间的关系,需要一层一层堆叠很多卷积层,但这样容易带来过拟合、梯度爆炸等问题。而基于 Self-Attention 机制的 Transformer 模型,每一层都能拿到全部的像素信息,从而解决了卷积网络难以对长序列进行建模的问题;考虑到卷积网络具有多个输出通道,为达到同样的效果,Transformer 模型同步提出了 Multi-Head Attention(即多头注意力)机制,以学习执行不同的任务。

(1) Self-Attention 机制

与 YOLO 系列的卷积不同,Transformer 模型的核心思想在于运用 Self-Attention 机制对输入序列进行建模,这种机制是对传统 Attention 机制的一种优化,能够更有效地捕捉序列中的信息。其中 Attention 的计算方式如图 3-21 所示。




图 3-21 注意力机制计算方法三阶段

如图，注意力机制计算方法分为三阶段。

阶段 1: 对于给定的输入序列，首先计算每个位置相对应的查询向量(Query)、键向量(Key)与值向量(Value)。Query 与每一个 Key 计算二者之间的相似性从而得到相似性评分 s 。

阶段 2: 将相似性评分 s 经过 softmax 归一化为[0,1]之间的概率分布。

阶段 3: 将每一个概率作为权值矩阵，随后对 Values 进行加权求和得到最后的 Attention 值。

即针对每一个输入序列的 embedding 矩阵，其包含的输入词向量 x 会经过三个特定的权值矩阵进行转换，从而得到计算 Attention 所需的 Query、Key 和 Value 值。这一转换过程旨在提取输入序列中的关键信息，为后续的注意力计算提供基础。

Attention 机制本身发生在 Source(源语言句子)元素与 Target(目标语言句子)元素之间，且预测时不需要目标数据，而是基于上一时间节点的预测值，这样大大节省了训练时间，并且注意力机制能够获取局部的重要信息。

在此基础之上，改进的 Self-Attention，计算过程与 Attention 一样，但 Attention 发生在 Source 元素内部或者 Target 元素内部之间，使得计算过程能够直接将任意两个单词联系起来。

由此可知，Self-Attention 机制使得模型可以为各个元素分配不同的权重，从算法角度去提高模型捕捉序列内部关系的能力。相对于传统的卷积神经网络(CNN)与循环神经网络(RNN)，Self-Attention 机制具备如下优点：

1) 并行计算能力：Self-Attention 允许模型对输入元素进行并行计算，从而加快了模型的训练速度；

2) 获取长期依赖关系：Self-Attention 机制使得每一层都能够获得所有的序列信息，因此可以直接获取任意两个位置元素之间关系；

3) 全局信息获取优化：由于 Self-Attention 机制是对整个序列进行建模，而非局部区域，所以能够获得更完整的全局信息。

(2) 模型结构

接下来介绍 Transformer 模型的框架，其结构如图 3-22 所示。




图 3-22 Transformer 模型结构

如图，Transformer 是一个基于 encoder-decoder 框架的模型，其主要结构可以分为四部分：红框部分的 Input、蓝框部分的 encoder block、绿框部分的 decoder block 以及黄框部分的 Output。

encoder 与 decoder 的结构十分相似，其区别在于：encoder 可以一次性看到所有的词，但 decoder 只能按顺序挨个生成每个词。

1) Input

Transformer 的输入是一个序列数据（包含源语言句子和目标语言句子），经过嵌入层，输入的每一个语句都会被分成单独的词向量，并加上位置编码（positional encoding）构成完整的输入序列。在 Self-Attention 的机制下，即便两个元素之间相距较远，也不会影响两个元素之间实际的关系。也就是说，Input 就相当于一个词库模型，不依赖于词与词之间的关系。

2) encoder block

encoder block 是由多个 encoder 层叠加构建而成的，具体层数为 $N \times n$ 。在图 3-22 中，蓝框部分展示了单个 encoder 的内部结构。每个 encoder 主要由两部分组成：用于关联处于不同位置的元素的多头注意力模块（Multi-Head Attention），以及用于前向信息传递的前馈神经网络（Feed Forward）。并且，在这两个模块之后，都添加了 Add & Norm 模块，以进一步提升模型的性能。

Multi-Head Attention 模块的作用是计算输入的注意力权重，并生成带有编码信息的输出向量，即对于输入序列 embedding 矩阵，在经过 Self-Attention 机制后会得到对应的 Attention 值，而 Multi-Head Attention 多头注意力机制采用多个头进行

Self-Attention 处理,可以更高效、细致地学习信息,由此得到鲁棒性更强、精度更高的结果。

Add & Norm 模块,先对运算结果进行残差叠加,避免神经网络在训练过程发生退化(Loss 减小,趋于饱和),然后使用 Layer Normalization (LN) 进行归一化处理。Transformer 的 LN 与 YOLOv5 所采用的 Batch Normalization (BN) 存在显著差异, LN 是在同一个样本的不同神经元之间进行归一化,而 BN 是在同一个 batch 中不同样本之间的同一位置的神经元之间进行归一化。其中, LN 相对于 BN 更加稳定,因为无论样本长短,其运算都是在每个样本内计算。

Feed Forward 模块是一种由两层神经网络构成的模块。它首先通过线性变换将输入映射至更高维度的空间以提升模型的表达能力。接着,使用 ReLU 激活函数增强模型的复杂性。最后,再次通过线性变换将特征映射回原始维度,作为输出。

3) decoder block

decoder 结构与 encoder 结构基本相同,仅多了一个 Masked Multi-Head Attention 模块,即 Mask 掩码过程,Transformer 模型中添加了两种 mask: padding mask 与 sequence mask。

padding mask: 由于来自于数据集的输入序列的长度各不相同,为便于统一处理,需对序列长度进行对齐操作。具体来说,对于过长的序列,进行截断并舍弃多余部分;对于过短的序列,则会通过填充 0 的方式,达到所需长度。由于填充位置实际没有任何意义,故此在操作时一般在这些位置添加一个非常大的负数,因为经过 softmax 后其概率会趋于 0。padding mask 是 encoder 与 decoder 的 Multi-Head Attention 均有的操作。

sequence mask: 为了提升 Transformer 的训练速度,需要使预测过程不依赖于 Target 数据,故加入 sequence mask 使 decoder 不能看见未来的信息,而仅依赖于某一时刻前的输入进行预测。sequence mask 仅 decoder 的 Multi-Head Attention 有。

4) Output

Output 的结构首先会对输入进行一次线性变换,随后利用 softmax 函数进行归一化处理,得到输出的概率分布。在此基础上,选择概率最大的单词作为最终的预测输出,从而确保输出结果的准确性和可靠性。

(3) 应用

由于不依赖于卷积进行特征提取,Transformer 模型已被广泛用于自然语言处理与计算机视觉领域,例如:机器翻译、语言建模、问答系统、目标检测。

在目标检测中,可利用预训练的 Transformer 模型作为目标检测任务的特征提取器以进行迁移学习^[37],能够大大减少目标任务的训练数据量,提升模型效果。

3.3.2 PVTv1 模型

Transformer 模型具有一定的优点,即训练效果好,可并行训练、训练快,且解决了长距离依赖问题。在此基础上,Transformer 模型出现了很多改进模型,其中 PVT 模型^[17]是一种能够提高多种任务(如目标检测、语义分割等)性能模型。为了适用于密集预测任务,PVT 在 Transformer 中引入了特征金字塔的设计,从而能够生成多尺度的 feature maps,这一改动增强了模型对不同尺度特征的捕捉能力,提升了它在密集预测任务中的性能表现。PVT 的完整网络结构如图 3-23 所示。




图 3-23 PVT 模型结构图

如图,PVT 结构主要由四个 Stage 构成,每个 Stage 的结构类似,均是由 patch embedding 层和多个 encoder 层组成。对第一个 Stage,输入图像分解为若干 patch 后,经过线性投影得到嵌入后的 patch,然后将 patch 与位置编码一同给到 encoder 层中,然后将输出 reshape 后得到第一个尺度的 F1 特征图。同理可得到 stage2-4 的另外尺度的特征图。

(1) 特征金字塔的引入

上述得到的每一个特征图 F,组合就能构成多尺度的特征金字塔,但与神经网络通过卷积获得多尺度特征层不同,PVT 可以在每个 stage 通过 patch 嵌入层使用渐进缩减策略来灵活控制特征图的尺寸,即可以构造较为灵活的多尺度特征金字塔。

(2) encoder 模块的改进

由于 PVT 需要处理高分辨率的特征图,因此在 PVT 中对 Multi-Head Attention (MHA) 模块结构进行了改进。与 MHA 相同,将 query、key 与 value 作为输入,但对 key 与 value 值进行缩小 R 倍,构成新的 Spatial Reduction Attention (SRA) 模块(使用卷积操作),减小了计算的复杂度,从而可以处理更高分辨率的特征图。MHA 与 SRA 结构^[17]对比如图 3-24 所示。




图 3-24 MHA 与 SRA 结构对比

PVT 模型，通过设计了一个渐进缩减金字塔和一个空间缩减注意力层，获得了多尺度、更高分辨率的特征图，因此可以作为目标检测的 backbone 网络进行特征提取。如 PVT 模型每个 stage 后得到的特征图尺寸可以是 160×160 、 80×80 、 40×40 、 20×20 。

3.3.3 PVTv2 模型

PVT 模型虽然具备获得多尺度、高分辨率特征图的能力，但其本身依旧存在一定局限性：将图像看作了互不重叠的若干 patch 序列，导致一定程度上损失了图像的局部连续性；处理高分辨率输入时计算复杂度依旧大；位置编码的大小是固定的，缺乏灵活性。

因此，王文海等人再次对 PVT 模型进行改进得到 PVTv2 模型^[17]，其改动点在于：优化空间缩减注意力层以减少计算量；将图片重叠切块嵌入以保留图像的局部连续性；引入零填充编码以解决位置编码固定大小的问题。

(1) 优化空间缩减注意力层

将 SRA 中的卷积操作替换为平均池化层，构成 Linear SRA，从而进一步减少注意力操作导致的计算成本。PVTv1 与 PVTv2 的 SRA 模块结构^[17]如图 3-25 所示。




图 3-25 PVTv1 与 PVTv2 的结构图

(2) 重叠切块嵌入

对于输入图片，为了保留相邻分块区域的连续性，PVTv2 将补丁窗口放大，使相邻窗口重叠一半面积，并对特征图进行零填充以保持分辨率。PVTv1 与 PVTv2 的切块嵌入差异^[17]如图 3-26 所示。




图 3-26 PVTv1 与 PVTv2 的切块嵌入差异

(3) 灵活的位置编码

在前馈网络中删除了固定大小的位置编码，并引入零填充，添加 padding 为 1 的卷积放置于第一个 FC 层和 GELU 层之间。PVTv1 与 PVTv2 的前馈模块如图 3-27 所示。




图 3-27 PVTv1 与 PVTv2 的前馈模块图

PVTv2 模型每个 stage 后可得到的特征图尺寸可以为 160×160 、 80×80 、 40×40 、 20×20 ，也可以灵活地生成其它尺度特征图。

至此, PVTv2 不仅显著增强了图像与特征图上的局部连续性, 提升了模型的特征捕捉能力; 同时, 它还展现出了对可变分辨率输入更高的灵活性; 最关键的, 它有着更低的计算复杂度。

3.3.4 PVTv2 模型总结

PVT 模型继承了 Transformer 模型不依赖于卷积、训练速度快、精度高的优点, 并引入了 FPN 金字塔以灵活获取更多尺度的特征图, 但其分块处理图像的机制使图像信息一定程度上丢失了局部连续性。PVTv2 在 PVT 模型基础上, 优化了图像处理策略, 获得了更优化的图像局部连续性, 并进一步缩减了运算量。相对于基于卷积的 YOLOv5 网络, PVTv2 在特征提取过程对 PCB 这类小缺陷目标的信息保留更为完整, 局部连续性也更优。

综上, 可以使用 PVTv2 替换 YOLOv5s 中依赖于卷积操作的 backbone 网络, 进行特征提取。

3.4 GFPN 模型结构

前文已经说明, 本文研究的 PCB 缺陷属于小缺陷目标类型, 其本身具有的像素信息有限, 在下采样过程中极易丢失, 故检测器学习到足够的高层次语义特征和低层空间特征、并进行融合, 是至关重要的。YOLOv5s 在 neck 网络中采用 PANet 结构来进行融合高层语义信息与底层的位置信息, 但这种策略本身关注的是层间特征交互(跨层融合), 而在本文 PCB 小缺陷目标检测任务中, 注重相邻层内特征交互以保留缺陷特征更为重要。

近年来, 目标检测领域提出了广义金字塔 Generalized-FPN(即 GFPN 模型^[55])特征网络, 相对 PANet 网络, GFPN 具有更高的精确度。其多尺度特征融合除了本身的跨层融合, 也加入了前一层和当前层的相邻层融合, 不仅充分交换了高层语义信息与低层空间信息, 也在保留相邻层特征关系的同时保证了全局信息的整合。对于本文 PCB 小缺陷目标类型的信息保留, GFPN 的机制能够获得比 PANet 更好的多尺度融合效果, 故本文将使用 GFPN 策略替换 YOLOv5s 的 neck 网络中的 PANet 策略。

3.5 YOLOv5s 模型结构的改进

根据前文分析可知, YOLOv5s 模型具备预测速度快、精度较高的优点, 但其本身也有着缺点: 它几乎完全依赖于高质量的卷积操作来进行局部特征提取与目标检测, 当层数堆叠过多、数据样本过大时, 容易导致过拟合以及语义信息的丢失;

此外,它的检测过程是对每个图像区域进行单独检测,并未考虑图像区域之间可能存在的关系,缺少全局性的特征学习。

而基于 Self-Attention 机制的 Transformer 模型,同时对全局与局部特征进行了学习,提升了模型的整体性与特征提取能力,并且可以直接捕捉序列中不同位置之间的像素关系,从而避免了梯度传播问题。因此本文考虑用 Transformer 模型对 YOLO 模型进行改进。更进一步的,将特征金字塔 FPN 与 Transformer 模型相结合构成的 PVTv1 模型,通过调整 Multi-Head Attention,保证了特征图的分辨率与全局感受野的同时使得计算量也在一定程度有所降低。而在此基础上改进的 PVTv2 模型,用池化层替换了卷积操作,并对分块图像进行放大重叠处理,使得 PVTv2 模型能够获得更优的图像特征与局部连续性,且进一步降低了运算量。

综上,针对本文的 PCB 缺陷这类小缺陷目标检测,为更好地保留缺陷特征,并提升模型训练与检测效果。对 YOLOv5s 模型结构进行改进,具体改动点如下:

- 1) 采用卷积操作更少的 PVTv2 模型替换 YOLOv5s 模型的主干网 backbone 作为特征提取网络,以优化 YOLO 的特征提取效果。
- 2) 并使用 GFPN 策略调整 YOLOv5s 模型的 neck 网络的 PANet 策略,加强相邻层的多尺度融合以获取特征信息更好的特征图。

改进后的模型结构如图 3-28 所示。




图 3-28 改进后的模型框架

3.6 本章小结

本章从 YOLOv5s 的模型结构角度出发,对模型的改进方案进行了探究。在通过分析 YOLOv5s 模型、PVTv2 模型与 GFPN 的结构与优缺点后,选择了可行的方案与策略以改进 YOLOv5s 模型中的 backbone 网络与 neck 网络。

至此,在前两章研究基础上改进后的模型如下:

(1) 在数据增强中,使用基于 Scharrx 算子的图像锐化方法与 RGB 三通道的单阈值分割方法,强化了 PCB 小缺陷目标的信息特征,以辅助模型进行特征提取。

(2) 在 backbone 网络中,以 PVTv2 模型替换原有的特征提取网络,减少了卷积操作,并使用 Multi-Head Attention 机制进行特征提取,在增加模型精度、提高训练速度的同时,优化了卷积导致的特征丢失问题。

(3) 在 neck 网络中,以 GFPN 策略替代原有的 PANet 策略,加强了相邻层之间的信息融合,以保证 PCB 小缺陷目标特征的完整性。

第四章 软件系统设计与实验验证

改进后的 PCB 缺陷检测模型，是以 YOLOv5s 为原型，进行 backbone 与 neck 网络调整后的新结构。本文在第二章中完成了数据集扩充以及图像预处理策略的选取，在第三章中综合分析 YOLOv5s 模型、PVTv2 模型与 GFPN 后，提出了模型结构改进方案。本章基于上述成果，继续完成软件系统设计（包含模型的改进与训练、PCB 缺陷检测系统），并完成人机交互界面的搭建，随后对改进后的模型进行训练结果分析，最后对 PCB 缺陷检测系统进行效果测试。

4.1 软件系统实现

PCB 缺陷检测方案至此已经完成了模型优化方案的设计，为满足工业实际对 PCB 缺陷便捷、精确、实时的检测需求，需设计对应软件系统进行改进模型的调用与缺陷检测，首先准备环境配置如下：

（1）数据集

数据集采用第二章扩充后的 9000 余张图片，满足了模型训练要求，大致按照 5:3:2 的比例划分数据集，即选取其中 4500 张图片作为训练集、2500 张作为验证集、2000 张作为测试集。

（2）硬件设备

硬件设备为 i7-13700HX、RTX4070 的笔记本电脑，操作系统为 win 11。

（3）软件环境

软件主要包含 PyCharm 2023.2.2、Qt Designer5.15.0、Anaconda 等，软件扩展环境包含 OpenCV、LabelImg 等。

（4）训练环境

使用 GPU 租用平台 AutoDL 算力云平台，租用服务器进行模型训练。对应的服务器配置为：GPU--RTX3080；CPU--12 核，Xeon(R) Platinum 8255C；内存--40GB；操作系统--Ubuntu20.04；编程语言--Python 3.8；Cuda--11.3；框架--PyTorch 1.10.0。

4.1.1 软件设计

系统的软件设计主要使用 qtDesigner 完成界面设计，并使用基于 python 的 Anaconda 与 PyCharm 编辑器搭建 OpenCV、LabelImg、yolo 等环境进行实现。软件设计包含两个部分：模型的改进与训练，以及 PCB 缺陷检测系统。

模型改进与训练部分主要用于训练并生成模型对应的权重文件，以便于后续 PCB 缺陷检测系统进行使用，两个软件部分的工作流程如图 4-1 所示。




图 4-1 软件设计工作流程图

（1）模型的改进与训练

首先通过 GitHub 下载了 YOLOv5s 的模型框架与预训练权重，使用准备好的数据集进行模型训练；随后根据前文探究的模型改进方案对 YOLOv5s 模型进行改进，并再次进行模型训练。每次训练完成后保存对应模型的权重文件，用于后续 PCB 缺陷检测系统。

（2）PCB 缺陷检测系统

使用 qtDesigner 搭建 PCB 缺陷检测系统的软件界面，包含显示框、按键、输入框、输出框、模型权重选择等，而后通过 PyCharm 编写代码实现该 PCB 缺陷检测系统。

该系统调用来自模型训练部分的权重文件，并在模型初始化过程使用权重文件加载对应的模型，然后进行缺陷检测。PCB 缺陷检测系统主要有 3 项功能：一是图片检测，点击预选图片进行检测，并将检测后的图片进行返回；二是视频检测，

点击预选视频进行检测，动态检测视频中的缺陷信息；三是摄像头实时检测，打开设备摄像头，可将 PCB 板、PCB 图片、视频等置于摄像头前进行缺陷检测。

4.1.2 人机交互界面实现

人机交互界面是该系统使用人员调用模型与权重进行 PCB 缺陷检测的接口，该模块的设计应该遵循简洁、实用、易操作等原则。本文的人机交互界面仅在于 PCB 缺陷检测系统，而模型改进与训练部分，主要用于生成权重文件，故不额外设计交互界面。

在 Qt Designer 上设计页面的 UI，然后通过 PyUIC 将.ui 文件转为.py 文件；新建一个 main.py 文件，通过 PyQt5 的 QtWidgets 对象中的 QApplication 构建一个 app，然后通过 PyQt5 的 QtWidgets 对象中的 QMainWindow 来初始化上述已经将 ui 转过来的 python 布局文件，最后将 app 添加相关执行操作。系统的人机交互界面如图 4-2 所示。该系统包含两个部分，一是图片、视频及其检测结果的呈现界面（左半部分），二是系统参数设置、位置信息等展示界面（右半部分）。



图 4-2 PCB 缺陷检测系统-人机交互界面

系统的界面操作包含模型权重选择、权重初始化、置信度与 IOU 选择、功能选择等。

(1) 权重选择

点击模型权重选择，可以进入文件夹选择之前模型训练后生成的权重文件。

(2) 模型权重初始化

点击权重初始化，系统将根据权重文件加载对应的模型，完成初始化后，即可进行 PCB 缺陷检测。

(3) 图像检测

点击“选择图像”后，可以在文件中选择对应的图片，图片将会呈现于界面左上部分区域；随后点击“图像检测”，并在提示“检测完成”后点击“检测结果展示”，界面左下部分区域将呈现图片及其缺陷检测信息，每个缺陷的位置信息也会在右半部分呈现；若保存本次检测结果，可点击“图像检测结果导出”，即可保存至文件夹。

如图 4-3 所示，是一次图像检测的结果示意图。




图 4-3 PCB 缺陷检测-图像检测

(4) 视频检测

点击“选择视频”后，可以在文件中选择对应的视频，视频将会呈现于界面左上部分区域；随后点击“视频检测”，并在提示“检测完成”后点击“检测结果展示”，界面左下部分区域将呈现视频及其缺陷检测信息，每个缺陷的位置信息也会在右半部分呈现；若保存本次检测结果，可点击“视频检测结果导出”，即可保存至文件夹。

如图 4-4 所示，是一次视频检测的结果示意图。




图 4-4 PCB 缺陷检测-视频检测

(5) 摄像头检测

点击“打开摄像头”后，系统将会唤醒电脑的摄像头，此时可以用 PCB 样板、手机里的图片、视频等放置于摄像头前，即可实现实时检测。

如图 4-5 所示，是一次视频检测的结果示意图。




图 4-5 PCB 缺陷检测-摄像头检测

4.2 模型训练评价指标

(1) 混淆矩阵

混淆矩阵在机器学习的领域中又被称谓可能性矩阵。而在图像精度的评价中，可以将分类结果的精度显示在混淆矩阵中，主要用于比较其预测值与实际值的差异，混淆矩阵的结构如图 4-6 所示。




图 4-6 混淆矩阵

由图 4-6 可见,混淆矩阵可以很轻易地进行二分类,并且通过对矩阵添加行和列,可以拓展应用于多分类问题。

True Positive (TP): 真正类。指的是模型预测结果与样本真实结果一致,且都是正类的情况。

True Negative (TN): 真负类。指的是模型预测结果与样本真实结果一致,且都是负类的情况。

False Positive (FP): 假正类。指的是模型预测结果与样本真实结果不一致,即错误预测为正类的情况。

False Negative (FN): 假负类。指的是模型预测结果与样本真实结果不一致,即错误预测为负类的情况。

混淆矩阵是对分类问题的预测值与实际值之间的统计。使用计数值或者比例,可以按照每个类别,对正确与错误的结果进行汇总。从图中也能看出模型在进行预测时是哪一部分产生了混淆与错误,从而更加针对性地调整预测策略。如本文 PCB 缺陷检测的结果中,其中一次六种缺陷的混淆矩阵如图 4-7 所示。




图 4-7 PCB 缺陷检测混淆矩阵

从图中可以看出,在本次训练的结果中,missing_hole、short 与 spurious_copper 的最终预测效果较好,准确率都在 97%以上,而 mouse_bite、open_circuit 与 spur 的预测效果比较差,低于 95%,尤其是 spur 的预测效果只有 86%。

(2) 精确率 (Accuracy)

在深度学习中,精确率是最为常用、最直接的分类性能指标。它定义为在所有样本中,识别正确的样本个数所占的比重,可以用于表示模型的实际精度。一般而言,模型的准确率越高,其效果越好。模型精确率计算公式如(4-1):

$$Accuracy = (TP + TN) / (TP + TN + FP + FN) \quad (4-1)$$

(2) 正确率/准确率 (Precision)

准确率,也被称为查准率,是指模型识别为正类的样本中,真正属于正类样本的比例。通常而言,查准率越高,意味着模型在识别正类样本时的准确性越高,从而反映出模型的效果更为优秀。准确率计算公式如式(4-2)所示。

$$Precision = TP / (TP + FP) \quad (4-2)$$

(3) 召回率 (Recall)

召回率,亦称查全率,它反映了模型正确识别为正类的样本数量占实际正类样本总数的比例。这一指标体现了模型从真实正样本中筛选出正样本的能力。一般而言,召回率越高,表明模型成功识别并正确预测的正样本数量越多,进而体现了模型性能的优越性。召回率计算公式如式(4-3)所示。

$$Recall = TP / (TP + FN) \quad (4-3)$$

(4) 平均准确率均值 (mean Average Precision, mAP)

查全率与查准率是一对相互制衡的性能指标。通常情况下,当查准率较高时,查全率往往会有所下降,反之亦然。

由此引入平均准确率均值 (mAP),它综合衡量了检测结果中的查准率与查全率等。在目标检测衡量精度的指标中,最常见的就是 mAP,它是查准率与查全率的交点与原点形成的矩形面积,即 PR 曲线。在目标检测任务中,当涉及多个不同类别时,我们可以针对每个类别分别绘制 precision 与 recall 的曲线。这些曲线下的面积即为该类别的平均精度 (AP)。进一步地,多个类别 AP 的平均值即为 mAP。

mAP 通常又分为 mAP_0.5 和 mAP_0.5: 0.95。其中, mAP_0.5 表示缺陷预测框与实际框交并比 (交集大小: 并集大小) 为 0.5 时的 mAP 值; mAP_0.5: 0.95 代表交并比从 0.5 按一定步长 (一般为 0.05) 变化到 0.95 过程中的 mAP 值。

本文 PCB 缺陷检测的训练结果中,其中一次 PR 曲线如图 4-8 所示。




图 4-8 PCB 缺陷检测 PR 曲线

(5) 定位损失 `box_loss`

推测为 GIOU 的损失函数，该值越小，代表定位框越准确。

(6) 目标检测损失 `obj_loss`

表示错误检测为目标的损失度，该值越小，代表目标检测的结果越精确。

(7) 分类损失 `cls_loss`

表示分类错误的情况，该值越小，代表分类结果越准确。

综上所述，模型评价指标有着诸多参数，而其中最重要的就是 precision、recall 与 mAP。

4.3 模型训练

完成软件设计后，需要根据前文对模型改进方案与策略的论述，完成改进模型的训练与测试，以检验模型的实际改进效果。本文的模型精度测试，均以第二章扩充后的数据集为基础，epoch 为 100，batch 为 16 进行训练。

PCB 检测系统的改动点有：

- (1) 调整训练过程的数据增强策略，加入 Scharrx 锐化与 RGB 的单阈值分割。
- (2) 用 PVTv2 替换 YOLOv5s 的 backbone 网络，使用 GFPN 策略替换 neck 网络中的 PANet 策略。

故本节模型测试分为以下六项：

- (1) YOLOv5s 模型精度测试；

- (2) YOLOv5s 添加 Scharrx 锐化后的模型精度测试;
- (3) YOLOv5s 添加 Scharrx 锐化、RGB 单阈值分割后的模型精度测试;
- (4) YOLOv5s 改进 (调整 PVTv2、GFPN) 模型的精度测试;
- (5) YOLOv5s 改进模型添加 Scharrx 锐化后的模型精度测试;
- (6) YOLOv5s 改进模型添加 Scharrx 锐化、RGB 单阈值分割后的模型精度测试。

4.3.1 YOLOv5s 模型的训练结果

YOLOv5s 模型的 backbone 网络使用卷积进行特征提取，并在 neck 网络使用 PANet 进行特征融合，最后在 head 进行 80×80 、 40×40 、 20×20 三种尺度上的结果预测。

经过训练后，YOLOv5s 模型的训练结果如下：

- (1) 混淆矩阵，如图 4-9 所示。




图 4-9 YOLOv5s 混淆矩阵

从图中可以看出，YOLOv5s 模型本身的分类效果中，整体分类准确率较低，尤其是 spur 的分类准确率只有 86%。

- (2) 指标参数，如图 4-10 所示。




图 4-10 YOLOv5s 指标参数

读取训练结果文件，具体的参数值如下：Precision--96.72%，Recall--94.29%，mAP_0.5--95.99%。

综上，可以看出，YOLOv5s 模型本身在本文 PCB 数据集的训练效果上表现并不好，spur 分类准确率极低，且查准率只有 96.72%，查全率只有 94.29%，平均准确率均值只有 95.99%，故模型性能还有很大的提升空间。

4.3.2 YOLOv5s+Scharrx 的训练结果

优化 YOLOv5s 模型的数据增强策略，在数据增强中加入基于 Scharrx 算子的图像锐化，经过训练后，YOLOv5s 模型+Scharrx 的训练结果如下：

(1) 混淆矩阵，如图 4-11 所示。




图 4-11 YOLOv5s+Scharrx 混淆矩阵

从图中可以看出，相对于 YOLOv5s 模型，YOLOv5s 模型+Scharrx 的分类效果中，spur 的分类准确率由 86%提升到了 90%，而其余分类准确率基本不变。

(2) 指标参数，如图 4-12 所示。




图 4-12 YOLOv5s+Scharrx 指标参数

读取训练结果文件，可以看出，相对于 YOLOv5s 模型，其参数值有所提升，具体参数如下：Precision--96.72%提升至 97.46%，Recall--94.29%提升至 95.16%，mAP_0.5--95.99%提升至 97.07%。

综上，可以看出，优化了图像增强方法后的 YOLOv5s 模型+Scharrx，在 YOLOv5s 模型基础上，使得 PCB 数据集的训练效果得以提升。

4.3.3 YOLOv5s+Scharrx+threshold 的训练结果

进一步优化 YOLOv5s 模型的数据增强策略，在数据增强中加入基于 Scharrx 算子的图像锐化与阈值分割，经过训练后，YOLOv5s 模型+Scharrx+threshold 的训练结果如下：

(1) 改进后的混淆矩阵，如图 4-13 所示。




图 4-13 YOLOv5s+Scharrx+threshold 混淆矩阵

从图中可以看出，相对于 YOLOv5s 模型+Scharrx 的六种分类效果而言，YOLOv5s 模型+Scharrx+threshold 的缺陷分类情况中，spur 的分类准确率由 90%进一步提升到了 93%，mouse_bite 的分类准确率由 93%提升到了 98%，而其余分类准确率也略有提升。

(2) 指标参数，如图 4-14 所示。




图 4-14 YOLOv5s+Scharrx+threshold 指标参数

读取训练结果文件，可以看出，相对于 YOLOV5s 模型+Scharrx，其训练的参数值再次提升：Precision--97.46%提升至 98.01%，Recall--95.16%提升至 97.56%，mAP_0.5--97.07%提升至 98.20%。

综上，可以看出，进一步优化图像增强方法，YOLOv5s 模型+Scharrx+threshold 使得 PCB 数据集的训练效果得以进一步提升。

4.3.4 改进模型的训练结果

将 YOLOv5s 模型的 backbone 网络替换为 PVTv2 结构，并在 Neck 网络用 GFPN 策略替换 PANet 策略，加强相邻两层的信息融合，经过训练后，YOLOv5s 改进模型的训练结果如下：

(1) 混淆矩阵，如图 4-15 所示。




图 4-15 改进模型-混淆矩阵

从图中可以看出，相对于 YOLOv5s 模型，改进后的分类效果中，spur 的分类准确率由 86%提升至 90%，其余分类准确率也有一定提升。

(2) 指标参数，如图 4-16 所示。




图 4-16 改进模型-指标参数

读取训练结果文件，可以看出，改进模型的具体参数值相对于 YOLOv5s 有着一定提升：Precision--96.72%提升至 97.78%，Recall--94.29%提升至 95.17%，mAP_0.5--95.99%提升至 97.18%。

综上，可以看出，改进模型在 YOLOv5s 模型基础上，使得 PCB 数据集的训练效果得以提升。

4.3.5 改进模型+Scharrx 的训练结果

对于改进模型，继续优化其数据增强策略，在数据增强中加入基于 Scharrx 算子的图像锐化，经过训练后，改进模型+Scharrx 的训练结果如下：

(1) 混淆矩阵，如图 4-17 所示所示。




图 4-17 改进模型+Scharrx 混淆矩阵

从图中可以看出,改进模型+Scharrx 相对于改进模型+spur 的分类效果中,spur 的分类准确率由 90%进一步提升到了 93%,mouse_bite 的分类准确率由 94%提升到了 98%,且其余分类的准确率也有着一定提升。

(2) 指标参数,如图 4-18 所示。




图 4-18 改进模型+Scharrx 指标参数

读取训练结果文件,可以看出,改进模型+Scharrx,在改进模型的基础上,具体的参数值有着进一步的提升: Precision--97.78%提升至 98.05%, Recall--95.17%提升至 97.68%, mAP_0.5--97.18%提升至 98.52%。

综上,可以看出,改进模型+Scharrx,在改进模型的基础上,使得 PCB 数据集的训练效果进一步得以提升。

4.3.6 改进模型+Scharrx+threshold 的训练结果

对于改进模型,继续改进其数据增强策略,在数据增强中加入基于 Scharrx 算子的图像锐化与阈值分割,经过训练后,改进模型+Scharrx+threshold 的训练结果如下:

(1) 混淆矩阵,如图 4-19 所示。




图 4-19 改进模型+Scharrx+threshold 混淆矩阵

从图中可以看出，相对于改进模型+Scharrx 的六种分类效果而言，改进模型+Scharrx+threshold 模型的缺陷分类情况中，各缺陷分类准确率均有一定提升。

(2) 指标参数，如图 4-20 所示。




图 4-20 改进模型+Scharrx+threshold 指标参数

读取训练结果文件，可以看出，相对于改进模型+Scharrx，其具体的参数值再次提升：Precision--98.05%提升至 98.52%，Recall--97.68%提升至 98.11%，mAP_0.5--98.52%提升至 98.60%。

综上，可以看出，改进模型+Scharrx+threshold，在改进模型+Scharrx 的基础上，使得 PCB 数据集的训练效果得以进一步提升。

4.4 模型训练结果分析

4.4.1 数据整合与对比

用 1 代表 YOLOv5s 模型，用 2 代表 YOLOv5 模型+Scharrx，用 3 代表 YOLOv5s 模型+Scharrx+threshold，用 4 代表改进模型，用 5 代表改进模型+Scharrx，用 6 代表改进模型+Scharrx+threshold。

(1) 混淆矩阵，如表 4-1 所示。

表 4-1 六种模型的混淆矩阵

缺陷(%) 模型	Missing _hole	Mouse _bite	Open _circuit	Short	Spur	Spurious _copper
1	100	94	95	98	86	97
2	100	93	95	98	90	98
3	100	98	97	100	93	100
4	99	94	95	99	90	98
5	100	98	97	100	93	100
6	100	97	99	100	94	99

(2) precision、recall 及 mAP，如表 4-2 所示。

表 4-2 六种模型的指标参数

指标 (%) 模型	precision	recall	mAP
1	96.72	94.29	95.99
2	97.46	95.16	97.07
3	98.01	97.56	98.20
4	97.78	95.17	97.18
5	98.05	97.68	98.52
6	98.52	98.11	98.60

综合分析表 4-1 和表 4-2，做如下对照实验分析：

1) YOLOv5s 模型与改进模型

即对比两张表中 1 和 4 的数据，可以看出：混淆矩阵中分类准确率上，六种缺陷整体有着一定提升，尤其是 spur 缺陷的分类准确率由 86%提升到 90%。此外，模型的 precision 由 96.72%提升到 97.78%，recall 由 94.29%提升到 95.17%，mAP 指标由 95.99%提升到 97.18%。

2) YOLOv5s 模型与 YOLOv5s 模型+Scharrx，以及改进模型与改进模型+Scharrx

即对比两张表中 1 和 2、4 和 5 的数据，可以看出：混淆矩阵中分类准确率上，1 到 2 的 spur 准确率有着明显提升，由 86%提升至 90%；4 到 5 的 mouse_bite 准确率有着明显提升，由 94%提升至 98%。此外，1 与 2 对比，模型的 precision 由 96.72%提升到 97.46%，recall 由 94.29%提升到 95.16%，mAP 指标由 95.99%提升到 97.07%；4 与 5 对比，模型的 precision 由 97.78%提升到 98.05%，recall 由 95.17%提升到 97.68%，mAP 指标由 97.18%提升到 98.52%。

3) YOLOv5s 模型+Scharrx 与 YOLOv5s 模型+Scharrx+threshold，以及改进模型+Scharrx 与改进+Scharrx+threshold

即对比两张表中 2 和 3、5 和 6 的数据，可以看出：混淆矩阵中分类准确率上，六种缺陷整体有着一定提升，尤其是 2 到 3 的所有分类准确率均有明显提升。此外，2 与 3 对比，模型的 precision 由 97.46%提升到 98.01%，recall 由 95.16%提升到 97.56%，mAP 指标由 97.07%升到 98.20%；5 与 6 对比，模型的 precision 由 98.05%提升到 98.52%，recall 由 97.68%提升到 98.11%，mAP 指标由 98.52%提升到 98.60%。

4) YOLOv5s 模型与改进模型+Scharrx+threshold

即对比两张表中 1 和 6 的数据，也就是模型改进前后的效果对比，可以看出：混淆矩阵中分类准确率上，六种缺陷整体有着明显提升，mouse_bite 由 94%提升到 97%，open_circuit 由 95%提升到 99%，short 由 98%提升到 100%，spur 由 86%提升到 94%，spurious_copper 由 97%提升到 99%。此外，模型的 precision 由 96.72%提升到 98.52%，recall 由 94.29%提升到 98.11%，mAP 指标由 95.99%提升到 98.60%。

4.4.2 YOLOv8s 结果对比

深度学习领域中，为了更全面地检验改进模型的效果，通常需要与当前最前沿、最优秀的模型进行对比，这些最优模型一般被称为 SOTA（State of the Art）模型。目前 YOLOv8 作为 YOLO 系列最新的模型，它利用了与 YOLOv5 相似的代码，但

对其 backbone 网络进行了改进,使用 C2F 模块(类似 C3,取消分支卷积,并增加跳层连接)替换了 YOLOv5 的 C3/CSP 模块,在丰富特征信息的同时减少了计算量,具有运算速度更快、准确率更高等优点。

为了验证改进模型的检测性能,将本文模型与目前 YOLO 系列的 SOTA 模型 YOLOv8s 进行对比,对应结果见表 4-3。

表 4-3 本文模型与 YOLOv8 结果对比

模型	Params	GFLOPS	mAP (%)	Size (MB)
YOLOv5s	7026307	15.8	95.99	13.8
YOLOv8s	11128586	28.9	97.16	22.1
最终改进模型	9248899	19.4	98.60	18.0

从表 4-3 可以看出:

YOLOv8s 作为当前 YOLO 系列最优秀的模型,其 GFLOPS 均高于 YOLOv5s 模型与最终改进模型,说明其运算速度与运算能力均更强大;YOLOv8s 的检测精度也优于 YOLOv5s,其 mAP 由 95.99%提升到了 97.16%,但本文最终改进模型的 mAP 为 98.60%,较 YOLOv8s 效果更优;且 YOLOv8s 参数量更为庞大、模型复杂度更高。

总体而言,相对于 YOLOv8s,本文基于 YOLOv5s 的改进模型,其模型复杂度、计算量均较小,且其检测精度也更高,说明模型的改进具有泛用性。

4.4.3 结果分析

综合之前的所有对照试验结果,可以得到如下结论:

(1)用 PVTv2 替换 YOLOv5s 的 backbone 网络、用 GFPN 策略优化 neck 网络的 PANet 策略后,得到的改进模型使得检测精度上升、训练效果更好,对比 YOLOv5s 模型,其 mAP 从 95.99%提升到了 97.18%。

(2)加入 Scharrx 锐化或单阈值分割的数据增强策略,也能够改善模型、获取更高的检测精度,对比 YOLOv5s 模型,加入两种图像处理后的 mAP 从 95.99%提升到了 98.20%。

(3)融合了模型结构改进与数据增强策略的方案,其检测精度在 YOLOv5s 模型本身基础上,有了很大提升,使模型 precision、recall、mAP 均达到了 98%以上。对比 YOLOv5s 模型,其 mAP 从 95.99%提升到了 98.60%。

(4)相对于 YOLO 系列最新模型 YOLOv8s,本文最终改进模型的参数量更少,精度也更高,即改进具有泛用性。

4.5 PCB 缺陷检测效果测试

经过模型改进、训练,并获得权重文件后,结合设计好的 PCB 缺陷检测系统,对数据集中 2000 张数据样本进行测试,鉴于有 6 种缺陷,每种缺陷随机选择 150 张图片进行检测。选择改进后模型+Scharrx+threshold 作为基准模型,选择该权重进行测试。

合格判定标准:

(1) 对比预测缺陷种类与实际缺陷种类,当缺陷被错误判定为其它缺陷类型或漏检时,认定为不合格。

(2) 由于每张图片有若干缺陷,且数目不同,为统计方便,以单张 PCB 图为单位,若图内有任何一处缺陷检测不合格,则该 PCB 图判定为不合格。检测结果如表 4-4 所示。

表 4-4 PCB 缺陷检测系统效果测试

缺陷 \ 项目	样本数量 (张)	误检张数 (张)	漏检张数 (张)	误检率 (%)	漏检率 (%)
Missing-hole	150	0	0	0.00	0.00
Mouse_bite	150	2	2	1.33	1.33
Open_circuit	150	2	0	1.33	0.00
Short	150	0	1	0.00	0.67
Spur	150	3	3	2.00	2.00
Spurious_copper	150	1	1	0.67	0.67

由表 4-4 可知:

(1) 本系统的误检率基本低于 2.00%,漏检率也低于 2.00%;

(2) 每一类检测中,漏检与误检的样本总和均不超过 4.00%;

(3) 所有漏检与误检的样本总和占比为 1.67%,即该 PCB 缺陷检测系统的精度为 98.33%,但由于统计方式采用以单个缺陷检测不合格代替了整个 PCB 图的不合格,所以实际精度更高,与模型训练结果基本吻合。

(4) 其中 spurious_copper、spur 以及 mouse_bite 的误检率或漏检率略高,除了模型本身的误差损失,同其缺陷本身与背景颜色相近也有一定关联。

对于出现的漏检与误检情况,原因分析如下:

(1) 目标检测中,目标的大小、位置,以及前景目标与背景之间的差异不明显,都可能导致一定的预测误差。

(2) 就单类缺陷而言：本文研究的六种缺陷均为小缺陷目标，在图中占比非常小；此外，除了缺失孔以外的五类缺陷均发生在线路区域，线路的颜色也与背景区域相近。

(3) 就多类缺陷而言：除了缺失孔以外的五类缺陷，它们的颜色、物理表现均具有一定的相似度，同时受与背景颜色相近的影响。

(4) 故在特征提取与融合时，缺陷与缺陷之间、缺陷与背景之间，都可能发生混淆，从而导致最终缺陷预测的误检与漏检。

4.6 本章小结

本章节的主要工作在于对前文论述的模型改进方案进行测试验证。本章首先完成了软件系统的设计与实现，包含模型改进与训练，以及 PCB 缺陷检测系统；随后对 YOLOv5s 模型按照前文探究的改进方案进行优化并完成训练，保留了模型修改前后的训练指标参数与权重文件，并通过训练数据对比分析了实际模型的改进效果，同时通过对比 YOLO 系列最新的 YOLOv8s 验证了模型改进的泛用性；最后，调用训练好的权重文件，使用搭建的 PCB 缺陷检测系统进行了大量样本的缺陷检测，并从误检率、漏检率等角度分析了实际 PCB 缺陷检测系统的性能。结果表明：改进后的模型对应的 mAP 数值在原本模型的 95.99%基础上提升了 2.61%，达到了 98.60%，该结果也优于 YOLOv8s 的 mAP；基于改进模型设计的 PCB 缺陷检测系统的数据集缺陷检测精度达到 98.33%，与模型训练结果基本一致。可以看出，本文的模型改进达到了优化模型、提升检测精度的预期目标。

第五章 总结与展望

5.1 总结

随着芯片行业的发展, PCB 的设计需求量与生产量逐渐增大, 相对应的, 对其表面缺陷检测的速度、精度要求也越来越高。传统的人工目测法与电气检测法存在费时费力、易损坏产品等缺点, 而基于参考法的传统视觉检测法的检测精度又受限于缺陷背景的复杂度, 且检测速度缓慢。随之出现了基于深度学习的缺陷检测算法, 这类算法的核心在于设计有效的特征提取网络对缺陷特征进行提取, 并设计对应的特征融合网络与结果预测网络, 最终完成缺陷检测。该方法分为以 YOLO 为代表的一阶段网络算法与以 Faster R-CNN 为代表的二阶段网络算法。

但由于 PCB 数据集样本量的限制, 以及 PCB 缺陷属于可提取特征少的小缺陷目标, 国内外对于 PCB 缺陷检测所使用的模型较旧且精度较低, 而且近年来不断在衍生新的目标检测算法 (如 Transformer 等), 它们尚未被广泛应用于 PCB 缺陷检测, 故本文提出了一种基于改进 YOLOv5s 的 PCB 缺陷检测方法。该方法以 PVTv2 替换 YOLOv5s 的 backbone 特征提取网络、以 GFPN 策略替代 neck 网络的 PANet 策略, 并针对 PCB 这种小缺陷目标的数据集, 采用了图像预处理算法加强缺陷特征以辅助模型进行特征提取。

本文首先对比选取了合适的图像预处理算法, 之后完成了模型结构的分析与改进, 并在此基础上, 进行软件设计与实验测试, 最终验证了基于改进 YOLOv5s 模型的 PCB 缺陷检测方法的有效性。

本文的主要工作与最终结果如下:

(1) 针对 PCB 小缺陷目标可提取特征少、信息卷积过程易丢失的问题, 为强化其缺陷的信息特征, 辅助模型进行特征提取, 本文分别研究了图像增强与阈值分割的相关算法。对于图像增强, 在对比了直方图均衡方法和基于 Sobel 算子、Scharrx 算子、Laplacian 算子的图像锐化方法对 PCB 图像的处理效果后, 选取了基于 Scharrx 算子的图像锐化方法。对于阈值分割, 在对比了 OTSU 阈值分割与单阈值分割对 PCB 图像的实际处理效果后, 选取了单阈值分割法。最后使用选取的方法对 PCB 数据集完成了预处理工作, 凸显了缺陷特征。

(2) 针对目前 YOLOv5 模型对小缺陷目标检测精度较低的问题, 本文通过对比研究 YOLOv5s 模型以及 Transformer 系列模型的优缺点后, 设计了一种基于改进 YOLOv5s 的 PCB 缺陷检测模型。最终采用了 PVTv2 模型对 YOLOv5s 进行 backbone 特征提取网络的替换以获取更好的特征提取效果, 同时使用广义金字塔

GFPN 策略替换 YOLOv5s 模型 neck 网络的 PANet 策略加强了相邻两层之间的信息融合效果。

(3) 为满足工业对于 PCB 缺陷便捷、精确、实时的检测需求,本文基于前文的图像处理研究以及模型结构改进研究,设计了一种基于改进 YOLOv5s 模型的 PCB 缺陷检测系统,并且搭建了易于操作的人机交互界面,并实现了对图片、视频的缺陷检测,且进一步完成了摄像头实时检测。

根据最终的模型训练参数对比结果,以及 PCB 缺陷检测精度测试的实验结果,可知:加入了图像预处理策略并改进 backbone、neck 网络后的新模型,对比原有的 YOLOv5s 模型对 PCB 缺陷的检测效果,新模型的检测精度有一定程度提高,其平均准确率均值 (mAP) 由原本的 95.99% 提升至 98.60%, 提升了 2.61%, 且相对于 YOLOv8s 的 mAP 也更高,说明改进后的 YOLOv5s 模型在 PCB 缺陷检测的应用中达到了预期。

5.2 展望

本文提出的基于改进 YOLOv5s 的 PCB 缺陷检测模型,在通过实验验证后,确认取得了比较理想的结果。然而,由于个人能力水平与研究资源有限,这其中仍有不足之处,在后续研究中,还可以从如下几个方面进行深入学习与改进:

(1) 本文研究的 PCB 表面缺陷包含了常见的六种类型,但在实际的工业生产中,会因为工艺、运输等原因产生本文研究的六种缺陷以外的缺陷类型,为扩大模型的泛用性,后续的工作可以收集更多种缺陷类型的 PCB 数据图像用于实验。

(2) 本文所提出的模型改进策略在 PCB 缺陷的检测上体现出了比较理想的效果,这种改进模型的效果,还可以拓展到更多对象的缺陷检测任务中,比如磁瓦、断路器等。

(3) 本文的设计中,采用以 PVTv2 模型替换 backbone 网络、GFPN 策略替换 PANet 策略的方式进行了模型结构改进,后续可以学习其他更新、更优的模型与策略,进行进一步的模型改进。

参考文献

- [1] 李袁.基于改进 YOLOv4 的目标检测方法研究与应用[D].重庆邮电大学,2021.DOI:10.27675/d.cnki.gcydx.2021.000486.
- [2] Yu L., Zhang D., Peng N., et al. Research on the application of binary-like coding and Hough circle detection technology in PCB traceability system[J]. Journal of Ambient Intelligence and Humanized Computing, 2021, 2021(2): 1-11.
- [3] Moganti M., Ercal F., Dagli C. H., et al. Automatic PCB detection algorithms: A Survey[J]. Computer Vision & Image Understanding, 1996, 63(2): 287-313.
- [4] SENGUPTA S, BASAK S, SAIKIA P, et al. A review of deep learning with special emphasis on architectures, applications and recent trends[J]. Knowledge-Based Systems, 2020, 194: 105596.
- [5] POUYANFAR S, SADIQ S, YAN Y L, et al. A survey on deep learning[J]. ACM Computing Surveys, 2019, 51(5): 1-36.
- [6] GARCIA-GARCIA A, ORTS-ESCOLANO S, OPREA S, et al. A survey on deep learning techniques for image and video semantic segmentation[J]. Applied Soft Computing, 2018, 70: 41-65.
- [7] Krizhevsky A, Sutskever I, Hinton G. Image Net classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25:1097-1105.
- [8] K. Simonyan, A. Zisserman, Very deep convolutional networks for large-scale image recognition[A]. Proceedings of International conference on Learning Representations[C].San Diego, 2015: 1150-1210.
- [9] He Kaiming, Zhang Xiangyu, Ren Shaoqing, et al. Deep residual learning for image recognition[A]. Proceedings of IEEE Conference on Computer Vision & Pattern Recognition[C]. IEEE, 2016: 770-778.
- [10] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[A]. Proceedings of the IEEE conference on Computer Vision and Pattern Recognition[C]. IEEE, 2015: 1-9.
- [11] Iandola F N, Han S , Moskewicz M W, et al. Squeeze Net: Alex Net-level accuracy with 50x fewer parameters and <0.5MB model size[J]. 2016. 6-13.
- [12] Howard A G, Zhu M, Chen B, et al. Mobile Nets: Efficient convolutional neural networks for mobile vision applications[J]. ar Xiv preprint, ar Xiv: 1704.04861, 2017.
- [13] Zhang X, Zhou X, Lin M, et al. Shuffle Net: An extremely efficient convolutional neural network for mobile devices[A] Proceedings of the IEEE Conference on computer vision and pattern recognition(CVPR)[C]. Salt Lake City, UT: IEEE, 2018: 6848-6856.

- [14] Mehta S, Rastegari M, Shapiro L, et al. ESPNetv2: A light-weight, power efficient, and general Purpose convolutional neural network[A]. Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)[C]. IEEE, 2019:9190-9200.
- [15] WANG X L, SHRIVASTAVA A, GUPTA A. A-fast-RCNN: hard positive generation via adversary for object detection[C]// 2017 IEEE Conference on Computer Vision and Pattern Recognition. New York: IEEE Press, 2017: 3039-3048.
- [16] 周飞燕, 金林鹏, 董军. 卷积神经网络研究综述[J]. 计算机学报, 2017, 40(06): 1229- 1251.
- [17] Wang W ,Xie E ,Li X , et al.PVT v2: Improved baselines with Pyramid Vision Transformer[J].Computational Visual Media,2022,8(03):415-424.
- [18] Shi W., Lu Z., Wu W., et al. Single-shot detector with enriched semantics for PCB tiny defect detection[J]. The Journal of Engineering, 2020, 2020(13): 366-372.
- [19] Gaidhane V. H., Hote Y. V., Singh V. An efficient similarity measure approach for PCB surface defect detection[J]. Pattern Analysis & Applications, 2017, 21(1): 277 – 289.
- [20] Silva L., Azevedo G., Fernandes B., et al. Automatic optical detection for defective PCB detection using transfer learning[C]// 2019 IEEE Latin American Conference on Computational Intelligence (LA-CCI). Guayaquil, Ecuador: IEEE, 2019: 1-6.
- [21] Khalilian S., Hallaj Y., Balouchestani A., et al. PCB defect detection using denoising convolutional autoencoders[J]. arXiv preprint arXiv: 2008.12589, 2020.
- [22] Cha Y. J., Choi W., Suh G., et al. Autonomous structural visual detection using region-based deep learning for detecting multiple damage types[J]. Computer Aided Civil and Infrastructure Engineering, 2018, 33(9): 731-747.
- [23] Chen J., Liu Z., Wang H., et al. Automatic defect detection of fasteners on the catenary support device using deep convolutional neural network[J]. IEEE Transactions on Instrumentation and Measurement, 2018, 67(2): 257-269.
- [24] Mei S., Yang H., Yin Z. An Unsupervised-Learning-Based approach for automated defect detection on textured surfaces[J]. IEEE Transactions on Instrumentation and Measurement, 2018, 67(6): 1266-1277.
- [25] Tao X., Zhang D., Ma W., et al. Automatic metallic surface defect detection and recognition with convolutional neural networks[J]. Applied Sciences-Basel, 2018, 8(9): 1-15.
- [26] Volkau I., Mujeeb A., Wenting D., et al. Detection defect in printed circuit boards using unsupervised feature extraction upon transfer learning[C]. International Conference on Cyberworlds (CW), 2019.

- [27] Miao Y., Liu Z., Wu X., et al. Cost-sensitive siamese network for PCB defect classification[J]. Comput Intell Neurosci, 2021:1927-1939.
- [28] Gang S., Fabrice N., Chung D., et al. Character recognition of components mounted on printed circuit board using deep learning[J]. Sensors (Basel), 2021, 21(9): 2921.
- [29] 王永利,曹江涛,姬晓飞.基于卷积神经网络的 PCB 缺陷检测与识别算法[J].电子测量与仪器学报,2019,33(08):78-84.DOI:10.13382/j.jemi.B1902110.
- [30] 刘伟森,方亦建.基于多尺度轻量级卷积网络的 PCB 裸板缺陷识别算法[J].自动化与信息工程,2020,41(05):20-25+41.
- [31] 吴冬冬.基于深度学习的高密度柔性电路板缺陷检测研究[D].华南理工大学,2019.DOI:10.27151/d.cnki.ghnlu.2019.001697.
- [32] 沈非尧.基于深度学习的 PCB 裸板缺陷检测技术研究[D].西华大学,2020.DOI:10.27411/d.cnki.gscgc.2020.000395.
- [33] Adibhatla V. A., Shieh J., Abbod M. F., et al. Detecting defects in PCB using deep learning via convolution neural networks[C]// 2018 13th International Microsystems, Packaging, Assembly and Circuits Technology Conference (IMPACT), Taipei, Taiwan: IEEE Access, 2018: 202-205.
- [34] Ding R., Dai L., Li G., et al. TDD-Net: A tiny defect detection network for printed = circuit boards[J]. CAAI Transactions on Intelligence Technology, 2019, 4(2): 110- 116.
- [35] Hu B., Wang J. Detection of PCB surface defects with improved Faster-RCNN and feature pyramid network[J]. IEEE Access, 2020, 2020(8): 108335-108345.
- [36] Haojia X., Zibo C., Boyuan W. PCB electronic component defect detection method based on improved YOLOv4 algorithm[J]. Journal of Physics: Conference Series, 2021, 1827(1): 012167-12179.
- [37] 肖书浩,吴蕾,何为等.深度学习在表面质量检测方面的应用[J].机械设计与制造,2020,(01): 288-292.DOI:10.19356/j.cnki.1001-3997.2020.01.072.
- [38] 张凯旋.基于深度学习的 PCB 缺陷检测研究[D].陕西理工大学,2023.DOI:10.27733/d.cnki.gsxlq.2023.000298.
- [39] Shorten C., Khoshgoftaar T. M. A survey on image data augmentation for deep learning[J]. Journal of Big Data, 2019, 6(1): 1-48.
- [40] 温悦欣.基于机器视觉的 PCB 表面缺陷检测方法研究与系统实现[D].电子科技大学,2020. DOI:10.27005/d.cnki.gdzku.2020.001118.
- [41] 王姮,王曼,张华等.基于 PCA 模式和颜色特征的钢轨表面缺陷视觉显著性检测[J].自动化仪表,2017,38(01):73-76.DOI:10.16086/j.cnki.issn1000-0380.201701018.

- [42] 钱晓亮,张鹤庆,张焕龙等.基于视觉显著性的太阳能电池片表面缺陷检测[J].仪器仪表学报,2017,38(07):1570-1578.DOI:10.19650/j.cnki.cjsi.2017.07.002.
- [43] Tsai D M,Wu S C,Li W C.Defect detection of solar cells in electroluminescence images using Fourier image reconstruction [J].Solar Energy Materials & Solar Cells,2012(99):250-262.
- [44] Jeon Y J,Choi D C,Lee S J.Defect detection for corner cracks in steelbillets using a wavelet reconstruction method[J].Journal of the Optical Society of America A Optics Image Science & Vision,2014,31(2):227.
- [45] 张振尧,白瑞林,过志强等.磁瓦表面缺陷的机器视觉检测方法[J].光学技术,2014,40(05):434-439.DOI:10.13741/j.cnki.11-1879/o4.2014.05.012.
- [46] 张振尧,李新,白瑞林.基于 LSSVM 的磁瓦表面瑕疵偏向性分类[J].光电工程,2013,40(08):78-83.
- [47] 张宏杰,张建业,隋修武.基于贝叶斯图像模式识别技术的点焊质量评估[J].焊接学报,2014,35(01):109-112+118.
- [48] 涂德江. 基于卷积神经网络的 PCB 缺陷检测技术研究[D]. 安徽:合肥工业大学,2021.
- [49] 吴江.工业磁瓦缺陷图像的深度学习分类方法研究[D].安徽大学,2021.DOI:10.26917/d.cnki.ganhu.2021.000384.
- [50] Lecun Y, Bottou L. Gradient-based learning applied to document recognition[J].Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [51] 陈早早.PCB 表面缺陷视觉检测及锡膏焊缺陷识别技术研究[D].重庆理工大学,2022.DOI:10.27753/d.cnki.gcqgx.2022.000825.
- [52] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]// Computer Vision and Pattern Recognition.USA: IEEE,2014:580-587.
- [53] Girshick R. Fast R-CNN[A]. Proceedings of IEEE International Conference on Computer Vision. USA: IEEE,2015.1440-1448.
- [54] Region proposal networks[J]. IEEE Trans Pattern Anal Mach Intell, 2015,39(6) :1137-1149.
- [55] Jiang Y , Tan Z , Wang J ,et al.GiraffeDet: A Heavy-Neck Paradigm for Object Detection[J]. 2022.DOI:10.48550/arXiv.2202.04256.