

基于机器视觉和深度学习的材料缺陷检测应用综述

杨传礼¹, 张修庆^{2,✉}

1 华东理工大学机械与动力工程学院, 上海 200237

2 华东理工大学承压系统安全科学教育部重点实验室, 上海 200237

因材料缺陷而导致的安全问题一直是备受人们关注的热点问题, 如何实现对材料缺陷的快速准确识别与定位是当今材料缺陷问题的研究重点。传统的无损检测方法主要通过超声波、X 射线等实现对材料缺陷的识别与定位, 这种方法虽然解决了人工检测效率低等问题, 但是难以满足智能化、自动化与高精度的多重要求。

计算机领域的进步刺激了机器视觉在材料缺陷检测方面的飞速发展, 机器视觉检测技术的特点主要是将无损检测、自动化与智能化相结合, 不仅安全性好、效率高, 而且检测精度高。但是大多数机器视觉设备存在对不同缺陷识别任务需要不同图像处理算法的问题, 意味着设备的通用性低, 而且设备的生产与维护的成本也较高。

近年来, 深度学习的崛起推动人工智能领域迅猛发展, 并且解决了传统的机器视觉对不同任务进行分类需要不同图像处理算法的问题, 深度学习也成为材料缺陷检测方面的一个热门研究方向, 已经有很多学者将深度学习技术应用到材料缺陷检测方向, 而且无论是对材料的缺陷类别进行分类, 还是对材料的缺陷进行定位与分割, 相关研究都取得了不错的成果。

本文首先对传统方法和机器视觉方法在材料缺陷方面的应用进行了概述与分析, 叙述了深度学习在材料缺陷检测中的原理, 然后分别系统地阐述了国内外深度学习在缺陷的分类、定位以及分割技术方面最新的应用, 并对深度学习在材料缺陷检测领域应用的未来发展趋势进行了展望。

关键词 机器视觉 材料缺陷检测 深度学习 卷积神经网络

中图分类号: TP391.4 文献标识码: A

Survey of Applications of Material Defect Detection Based on Machine Vision and Deep Learning

YANG Chuanli¹, ZHANG Xiuqing^{2,✉}

1 School of Mechanical and Power Engineering, East China University of Science and Technology, Shanghai 200237, China

2 Key Laboratory of Pressure System Safety Science of Ministry of Education, East China University of Science and Technology, Shanghai 200237, China

The safety problem caused by material defects has always been a hot issue, and how to realize the rapid accurate identification and location of material defects is the focus of current research on material defects. The traditional non-destructive testing method mainly uses ultrasonic, X-ray and other advanced technologies to realize the identification and positioning of material defects. Although this method solves the problem of low manual testing efficiency, it is still difficult to achieve the requirements of intelligentization, automation and high precision.

Advances in the computer technology has stimulated the rapid development of machine vision in the detection of material defects. The advantages of machine vision inspection technology are mainly the combination of non-destructive inspection, automation and intelligentization, which has not only good safety and high efficiency, but also high detection accuracy. However, an image processing algorithm usually can be effective to the recognition of only one specific kind of defect, which causes low versatility of the equipment and elevated cost of production and maintenance.

In recent years, the rise of deep learning has promoted the rapid development of the field of artificial intelligence, and solved the problem that traditional machine vision needs different image processing algorithms to classify different tasks. Deep learning has also become a popular research direction in material defect detection. Many scholars have applied deep learning technology to the field of material defect detection, and they have achieved good results whether they are related to the classification of material defects, or the location and the segmentation of material defects.

The article summarizes the application of traditional methods and machine vision methods in material defects, introduces the principles of deep learning in material defect detection, and systematically describes the application of deep learning in the classification, positioning and segmentation of material defects at home and abroad, and the future development trend of the application of deep learning in the field of material defect detection is prospected.

Key words machine vision, material defect detection, deep learning, convolutional neural network

0 引言

材料的缺陷问题一直存在于工业生产中, 而且由材料的缺陷导致的安全问题也越来越多, 因此人们对材料缺陷的识别与检测更加重视。传统的材料缺陷识别和检测方法是依赖专业的技术人员手动操作进行的, 这种方法不仅检测效率低, 而且依赖操作人员主观判断, 检测的准确度难以得到保证。无损检测设备与工业生产线相结合的生产模式不仅确保了产品的质量, 而且降低了人工检测的成本、提高了生产的效率。后来, 随着计算机图像处理技术的迅猛兴起, 许多学者逐渐将这种技术扩展应用在材料缺陷检测领域, 使得材

料缺陷检测方法越来越成熟与完善。近年来, 深度学习也成为材料缺陷检测方面的一个热门研究方向, 已经有许多学者将深度学习技术应用到材料缺陷检测领域, 并且取得了非凡的效果。

1 传统的材料缺陷识别方法

传统的材料缺陷无损检测技术通常是通过磁粉、渗透、涡流、超声波、X 射线等探伤方法来对目标材料样本中的裂纹、白点、缺损和内部缺陷等缺陷信息进行检测识别。

磁粉探伤法^[1]是根据缺陷处磁导率和正常磁导率的差异, 使材料缺陷处的磁场因为磁化出现特定的变化, 从而生

成漏磁场吸引磁粉,导致磁粉在材料缺陷位置处聚集,在合适光照条件下,就会得到缺陷的位置与形状信息。陈朝等^[5]利用磁粉探伤对动车组钢弹簧进行检测,发现了其内侧的凹坑与微裂纹等缺陷。

渗透探伤法^[6]是将含有染料的着色剂或荧光的渗透剂涂在样本材料的外形轮廓上,再清理零件外形轮廓上残留的渗透剂,缺陷处的渗透剂会因为毛细作用存留下来,然后利用合适的灯光来观测相应缺陷。常文见等^[7]对不锈钢的管板角焊缝中的缺陷进行着色渗透探伤并取得预期的成果。

涡流探伤法^[8]是基于电磁感应来确认材料损伤位置的常见检测方法。激励线圈能使具有导电属性的材料中产生一定的涡电流,并且根据探测线圈得到的涡电流的差异量,进一步获得相关材料缺陷的有关信息。Xie等^[9]提出并研制了一种用于检测管道结构缺陷的新型磁力传递涡流阵列分体式探头,利用磁力探头对含有裂纹瑕疵的铝管进行检查,可以更加精确地确定裂纹的深度、轴向位置和周向位置。

超声波探伤法^[10]是基于超声能够传入材料的内部,当遇到缺陷时就会产生特定的反射波,在设备上过滤得到相应脉冲波形,从而得到缺陷位置等相关信息。Cheng等^[11]针对在风力机中关键部位主轴与轴承经常发生应力集中且容易产生外周横向裂纹的表面破裂的问题,建立了从端面对主轴进行检测的超声测量方法,并取得不错的效果。

X射线探伤^[12]是根据材料缺陷会导致材料厚度发生变化,使得材料不同位置的X射线吸收产生差异,再利用X射线成像技术得到材料的内部缺陷的位置等信息。Du等^[13]以特征金字塔网络作为基础,将深度学习与X射线检测方法相结合,改善了铸件X射线图像缺陷语义信息层次较低的问题,并且提出了一种基于软交联的准则,该准则能较好地评价附近区域的多个检测结果而获取较高层次的图像语义信

息,使其在铸件检测时得到更加准确的结果。

尽管传统的材料缺陷无损检测方法已取得一定的成果,但是还存在一些弊端:第一,对受检测样本的材料与形状要求较高,如磁粉探伤只适用于铁磁通材料、渗透探伤不适用于多孔材料、涡流探伤受工件形状的影响较大、超声波探伤对复杂构件的检测精度低等;第二,对操作人员的专业要求很高,如渗透探伤的检测结果受操作人员的影响较大、X射线探伤若操作不当会对操作人员产生辐射危害等;第三,传统的材料缺陷识别方法难以满足智能化、自动化与高精度的多重要求,例如磁粉探伤与渗透探伤就难以实现自动化检测,且存在检测效率低等问题。

2 基于机器视觉的缺陷检测技术

机器视觉技术在材料缺陷检测技术中扮演着重要的角色,特点主要是将无损检测、自动化与智能化相结合,不仅安全性好、效率高,而且检测精度高^[14]。

机器视觉检测技术基本是由图像采集、软件图像处理和图像分析三方面构成的。图像采集部分主要是选择合适的光源、专业相机与镜头来实现对样本的图片采集,原理主要是利用图像传感器将镜头汇聚的灯光转化成电信号,继而转化成数字信号,并传递到软件图像处理部分进行分析。软件图像处理部分主要涵盖图像去噪^[15]、图像增强^[16]、边缘检测^[17]等措施。图像分析部分包括特征信息的提取、有效特征的筛选和运用分类器进行图像的识别三个部分,主要是从图像的像素中提取有效的特征信息,常采用主成分分析(PCA)^[18]等算法对图像像素数据实行压缩,降低高维图像的维度来获取特征,这样在图像识别时,分类器更容易识别特征信息,从而提高分类的准确度,更加正确地进行分类识别,检测工作流程图如图1所示。




图1 机器视觉检测流程图

Fig.1 Machine vision inspection flow chart

机器视觉检测技术在材料表面检测方面得到大量的应用,陈麒麟等^[14]利用机器视觉技术实现在冲压磨削平板上进行表面缺陷的检测与识别,结合灰度异常区域信息与边缘线的位置和方向完成平板表面缺陷的识别,识别的正确率达到97%。张玉燕等^[15]针对金属点阵结构内部存在的缺陷,设计了一种利用电子计算机断层扫描(CT)来获取三个靠近并静止的像素点的灰度值的和,并计算各和的差值变化来检测缺陷,该方法对缺陷的检测正确率达到98.5%。Qi等^[16]提出了一种基于图像几何特征的方法来对焊接的缺陷类型进行识别,对焊接缺陷图像进行预处理,然后通过图像分割方法去除背景,获取有效的焊接缺陷图像,并结合八连通区域标

记法进行标记,提取到周长、面积和圆度等几何特征,实验结果表明,该方法具有良好的适用性和实用性。Yu等^[17]采用一种近红外光谱技术与机器视觉技术相结合的方法来检测落叶松的活结、死结、针孔和裂纹等缺陷,利用工业相机采集样本图像,结合形态学算法对缺陷进行定位,再利用神经网络进行分类识别,识别正确率达到92%。胡秀珍等^[18]针对铁芯表面上存在裂纹与扭曲等缺陷,设计了一种采用机器视觉为核心的缺陷检测方案,首先用电荷耦合器件(CCD)采集图像信息,再结合边缘检测和Douglas-Peucker算法实现对感兴趣目标的特征选取及分类,该方案对缺陷的检测正确率高达98.25%。Ding等^[19]设计了一种基于机器视觉技术的眼

镜分散缺陷自动识别方案,根据镜片的法线和瑕疵区域的折射率不同,收集正常透射照片与反射照片作为数据集,然后开发了一种图像处理算法来揭示上述差异并检测树脂眼镜中的分散缺陷,检测精度为 97.50%,平均检测时间为 0.636 s。Chao 等^[23]利用传统的机器视觉和深度学习的检测技术,开发了一套硅橡胶垫圈的自动光学检测系统,该系统可检测模具制造过程中引入的五种特征缺陷,通过高动态范围图像捕获和图像生成技术,对缺口和残胶缺陷的预测精度分别达到 100%、97%。Zhou 等^[23]针对啤酒瓶质量检验过程中瓶口瑕疵处存在识别难度大和识别精度低的弊端,提出了一种基于综合残差分析、分割阈值和机器视觉的缺陷识别技术,克服了图像灰度变化和瓶口破碎的影响,当瓶口图像中存在较大的缺陷区域和较多的噪声时,该算法可以达到较快的速度和较高的精度。Wang 等^[24]为克服齿轮缺陷识别精度低的弊端,提出了将机器视觉技术与传感器耦合技术相结合的方案,然后利用 CCD 相机获取齿轮产品的照片信息,利用 VS2010 与 Halcon 库合作对图像进行分析和处理,将结果反馈给控制端,并将被拒绝的器件移至收集箱,测试结果表明该系统能快速有效地识别齿轮缺陷。

虽然机器视觉技术对材料的缺陷识别检测具有自动化、高检测效率、高缺陷识别准确度等优点,但是也存在一些不足:第一,设备通用性低,一套检测设备往往仅能满足一种材料缺陷的识别;第二,对光源环境要求较高,需要高性能的 CCD 感光元件才能提升缺陷识别的准确度;第三,机器视觉检测装置的生产和维护需要较高的成本。

近年来深度学习在机器视觉方面的应用得到快速发展,并解决了传统的机器视觉对不同任务进行分类需要不同图

像处理算法的问题,深度学习通过构建多层深度网络模型,训练标注好的数据集,实现对输入图像高精度的检测分类,推动了深度学习在图像处理领域的进一步发展。

3 基于深度学习的材料缺陷检测技术

深度学习模型主要包括卷积神经网络(Convolutional neural network, CNN)^[25]、循环神经网络(Recurrent neural network, RNN)^[26]、深度信念网络(Deep belief nets, DBN)^[27]、自编码器(Autoencoder)^[28]、生成对抗网络(Generative adversarial networks, GAN)^[29]等。但是它们的应用场景大多不同, CNN 多应用于图像处理, RNN 常应用于自然语言处理, DBN 既可以作为分类器应用于语音识别领域,也可以作为生成模型生成训练数据,自编码器常应用于数据降维与图像生成, GAN 在图像生成领域取得了非凡的成果。

2012 年 AlexNet^[30]网络的问世对深度学习的发展产生了巨大的影响,因为 Alexnet 采用 GPU 集群来增加计算,使百万级或者更大的数据计算成为可能,复杂神经网络计算量大的问题得到解决,使得复杂网络模型的计算变得可能,从而推动了深度学习开始蓬勃发展。大量的学者将深度学习与各个领域相结合并且都取得不错的效果,也有很多学者致力于将深度学习技术应用在材料的缺陷检测中,无论是对材料的缺陷种类进行分类,还是对材料的缺陷进行定位和分割,都取得了不错的成果。

3.1 分类技术

卷积神经网络是应用于材料缺陷识别中比较普遍的深度学习模型,如图 2 所示,对一张裂纹图片的像素信息进行卷积、池化等操作实现特征提取,获取图像中抽象的特征信




图2 卷积神经网络基本结构

Fig.2 Basic structure of convolutional neural network

息,再结合全连接层实现目标分类。从 ImageNet^[31] 图像分类比赛到现在,有很多优秀的分类模型产生,如 AlexNet、VGG^[32]、GoogleNet^[33-35]、ResNet^[36-37]、DenseNet^[38]、MobileNet^[39]等优秀的卷积网络模型,针对实际遇到的分类问题,通常的做法就是获取足够的数据集,并且结合上述网络结构进行训练和预测。

卷积神经网络的核心和关键在于,通过局部连接、权值共享和池化等操作来减少参数量,从而优化网络结构,并降低网络模型的训练难度。现在已经有许多学者致力于使用监督式的卷积神经网络来解决材料缺陷分类的问题,2016 年, Park 等^[40]基于简单的 CNN 对构件上的污垢、磨损等缺陷实现分类,通过对 CNN 的模型深度和参数不断进行调整,优

化结构后的 CNN 模型对测试集的检测正确率为 98%,表明了 CNN 对构件上不同类型缺陷识别的有效性。2018 年,在半导体领域,由于模具晶圆的加工复杂化,导致模具晶圆内的混合缺陷增加, Kiryong 等^[41]提出了利用 CNN 对晶圆片内的混合类型缺陷进行分类,即使存在很多的随机缺陷, CNN 依然取得了良好的分类识别效果。姚明海等^[42]针对磁片表面缺陷的检测效率低、生产成本低和缺陷分类难度大的问题,提出一种基于 Inception-Resnet-v2^[43]深度学习模型的磁片表面缺陷检测方案,测试发现此方案不仅能对缺陷实现自动分类,而且能确保较高的精确度。2019 年, Deitsch 等^[44]通过电致发光图像技术获取光伏组件表面微小的缺陷,并结合 SVM 和 CNN 两种方法来检测图像中的缺陷,发现 CNN 的检

测效果优于 SVM,检测的平均准确率达到 88.42%,比 SVM 方法高 6%。杨延西等^[43]为了进一步改善钢铁行业中表面缺陷的自主检测效率低、识别率低的问题,构建卷积神经网络对带钢的表面缺陷进行自主识别,在实验测试阶段,带钢缺陷的识别精确度高达 99%,符合工业生产部署的要求,对带钢的缺陷检测有着深远的意义。Zhang 等^[44]开发了一种可以实时采集焊缝图像的图像采集系统,该系统可从焊缝顶前、顶后、后缝等不同角度获取实时焊缝图像信息,结合 11 层 CNN 分类模型实现对焊缝熔透缺陷的识别,采用加噪声和图像旋转方法进行数据增强,最后分类的准确率达到 99.38%。贯丽丽^[45]针对晶体表面缺陷形貌特征多样化的特点,提出了一种基于深度学习模型进行晶体缺陷分类检测的方法,对晶体常见缺陷水解、凹坑、裂纹等制作数据集,利用 VGG16 与 ZF^[46]的模型训练对比,发现 VGG16 的检测精度更好,其对验证集的精度比 ZF 模型高约 2.5%。Wei 等^[47]为了进一步改善铝型材表面缺陷的检测性能,避免在传统机器视觉方法中依赖手工制作特征、工序繁琐、鲁棒性差的问题,提出了一种基于深度学习的多尺度缺陷检测网络,并通过 10 种类型的铝型材表面缺陷图像进行网络模型评价,平均的检测精度为 75.9%,证明了深度学习在铝型材表面缺陷检测方法中的可行性。2020 年,詹湘琳等^[48]针对碳纤维复合材料(CFRP)的缺陷类型自动判别,提出一种超声一维卷积神经网络(U-1DCNN),结合贝叶斯优化方法进行超参数优选,通过自动提取超声 A-Scan 信号特征,实现分层、气孔、无缺陷三种不同类型缺陷的自动区分。针对复合材料层合板的缺陷检测问题,传统的热成像的无损检测方法不仅受环境因素的影响,而且对检测设备和人员的要求高。为了克服这一局限,Bang 等^[49]提出了一种结合热像测试和 CNN 来识别复合材料缺陷的框架,收集含有缺陷的复合材料的热像集作为数据集,对训练系统中的含缺陷热像图进行识别,在注塑成型的复合材料试件上手工制作缺陷,并进行测试评估,实验结果证明了此方法的有效性,也表明了 CNN 的灵活性与鲁棒性。

在将深度学习应用在材料的表面缺陷分类识别方法中,除了传统的有监督式的 CNN 模型外,半监督式的分类方法也有一定程度的发展。Di 等^[50]为了降低传统有监督式的深度学习对大批量的样本标记的依赖性,设计了一套利用卷积自编码器与半监督式生成对抗网络相结合的缺陷分类方案,并将其应用在钢材表面缺陷的分类任务中。该方法也被称为 CAE-SGAN,首先通过卷积自编码器进行特征提取和堆叠,结合 softmax 形成分类器,通过实际生产采集的图像和半监督式生成对抗网络随机生成的图像进行模型训练。实验结果表明,与传统方法相比,CAE-SGAN 拥有更优的性能。

由于钢材表面缺陷的分类识别中监督学习要求充足的样本数据,但是样本收集困难,样本做标记工序繁琐,且成本较大,Yu 等^[51]设计了一种结合 GAN 的半监督学习(SSL)缺陷识别方案并将其应用在钢材表面缺陷的分类识别任务中。该方案主要结合了两个网络进行模型训练,首先通过生成对抗网络训练生成大量未标记的钢材表面的缺陷图像,然后通过残差网络对有标记的缺陷图像进行训练,将这两个过程整合到 SSL 方法中。经过多次训练,验证了采用 SSL 方法的准确度和鲁棒性相比仅使用有标记的样本数据集都有很大的提升。从上述的文献案例中看出,将无监督和有监督的深度学习方法相结合是未来分类识别任务的主流研究方向之一,通过无监督学习算法,例如自动编码器和 GAN 来生成样本图像,实现数据扩充,不仅降低了对多样本的依赖性,还保证了分类识别的精度。

针对训练样本不足的问题,除了利用无监督的深度学习方法进行数据扩充外,还有一种方法是迁移学习,而且迁移学习^[52]在深度学习中的应用也越来越普遍,尤其是对小数据集分类问题取得了很好的效果。Sun 等^[53]提出了一种基于卷积神经网络的自适应多尺度图像采集的表面缺陷检测算法,利用 ImageNet 的预训练权重进行迁移学习,减少对大训练样本的依赖,并将其嵌入到表面缺陷检测仪中,实现对金属零件表面的压痕、划痕和麻点三种不同缺陷的分类,最终实验的准确度分别为 97.3%、99.5% 和 100%,表明了利用迁移学习进行预训练的可行性和有效性。采用传统手法对半导体晶圆上的颗粒缺陷进行分类,不仅成本大、效率低,而且对技术人员的要求较高。O'Leary 等^[54]针对上述问题,提出了一种通过 SEM 图像和 EDX 数据进行组合的缺陷识别 CNN 模型,首先将 SEM 图像作为训练数据,通过 CNN 模型进行预训练,再将 EDX 数据并入全连接层中,实现对半导体晶片上颗粒缺陷的分类,并通过迁移学习进行对比,发现迁移学习不仅可提高 CNN 模型的训练速度,而且能使准确度有一定的提升。

3.2 目标检测技术

近年来目标检测技术发展迅速,也逐渐被应用到人工智能、人脸识别、军事等多个领域,目标检测不仅能对感兴趣的物体进行分类,还能获取其相关的位置,完成对感兴趣的物体的精准检测。目前目标检测算法有两大发展历程。

第一个阶段是首先生成候选框(Proposal),再通过 CNN 获取特征,然后利用分类器与边界框回归结合来完成对感兴趣物体的分类和定位。图 3 是利用区域卷积神经网络(R-CNN)^[55]对金相图片中的凹坑缺陷进行检测识别。后来进一步发展的算法有 SPP-Net^[56]、Fast R-CNN^[57]、Faster R-CNN^[58]等。




图3 区域卷积网络结构

Fig. 3 Structure of regional convolution network

第二阶段是直接利用 CNN 回归预测候选框的位置、尺寸和物体类别,每张图片只要看一次,就可知道图片中存在哪些感兴趣的物体及其位置。第二阶段算法的发展里程为 YOLOv1^[61]、YOLOv2^[63]、YOLOv3^[63]、YOLOv4^[64],图4为 YOLOv1 的结构图。YOLO 系列算法的主要特点是实现了端到端的目标检测,而且通过非极大值抑制,减少对多余的候

选框的训练与计算,因此模型的训练和检测的效率得到很好的改善,检测速度很快,但是存在一定的弊端,如检测正确率不高、定位不准确,而且对小物体的检测识别效果差,后来多个版本通过优化主干特征提取网络、利用多种不同尺度的特征图进行目标检测、优化特征聚合网络和增加新的数据增强方法等措施改善网络模型,使得模型的检测准确度和检测速




图4 YOLOv1 结构^[61]
Fig. 4 YOLOv1 structure^[61]

度得到了良好的改善。

在目标检测算法中获取的不仅是图像中各对象的类别信息,还有图片中的具体类别对象的位置信息。对于目标检测算法的要求,不仅要求检测的准确度高,还要求具有一定的检测速度。常用的衡量检测算法的指标有各类别准确度 (AP)、平均准确度 (mAP) 和每秒检测图像的帧数 (FPS) 等,在不同的实际工程应用中,对各指标要求的侧重点也有差异。

表1主要对比了当前在材料缺陷检测领域应用比较广泛的几种目标检测算法,通过它们在公开的 VOC 和 COCO 数据集上的性能测试来对比各种算法检测性能的优劣。表1中 mAP50 的含义是非极大值抑制 (NMS) 过程中设定 IoU 阈值的参数为 0.5 得到的平均准确度, IoU 阈值目的是过滤冗余框,留下置信度较高的候选框。FPS 是在 Titan X 显卡下运行的结果,用于衡量不同算法的检测速度,从表1的数据看, YOLO 系列算法的整体性能更有优势,而且 YOLOv3 进一步兼顾了检测准确度和检测速度,在工业应用的前景更广阔。

表1 目标检测算法性能比较^[60-63]
Table 1 Performance comparison of target detection algorithm^[60-63]

算法	特征提取网络	mAP50 (VOC)	mAP50 (COCO)	FPS (Titan X)
Faster R-CNN	VGG-16	73.2	42.7	7
Faster R-CNN	Residual-101	76.4	45.3	2.4
SSD300	VGG-16	74.3	41.2	46
R-FCN	Residual-101	80.5	51.9	9
YOLOv1	24-layer convolution	63.4	—	45
YOLOv2	Darknet-19	76.8	44.0	67
YOLOv3	Darknet-53	—	55.3	34

在 YOLOv3 诞生之前, Faster R-CNN 是主流的目标检测网络,也是深度学习目标检测第一个阶段的代表作,因为检测效果好,所以在材料的缺陷检测领域得到了大量的应用。

2019 年,针对传统金属轴的缺陷检测的识别精度低、泛化能力不足的问题,赵欣洋等^[63]提出了一种基于 Faster R-CNN 的深度学习方法来提高金属轴的缺陷检测效率,首先对轴缺陷凹坑、划痕、磨损、缺口图像进行灰度化、去噪、边缘检测,实现缺陷图像数据增强,再改进了 Faster R-CNN 中的 RPN 网络和分类网络,并优化了模型的参数,实验最终的准确率可达到 94%~96%,有效地提升工业生产中金属轴的缺陷的检测效率。张玉燕等^[64]设计了一套利用深度学习识别金属三维多层点阵结构中不同缺陷的方案,在 Faster R-CNN 网络架构基础上设计特征提取网络,并对 RPN 网络进行了调整,结合工业 CT 扫描图片,对得到的断层灰度图像中在裂纹、未熔合、断层等缺陷部位进行检测识别和定位,测试集的缺陷检测识别率达到 99.5%,满足了工业生产的要求。Gao 等^[61]针对城市地铁隧道建设过程中隧道缺陷的检测问题,提出了一种基于改进的 Faster R-CNN 的深度学习缺陷检测方法,通过结合快速 Faster 和 FCN 构建了隧道多缺陷快速检测系统,并将其与单个 FCN 算法进行对比实验,发现此方法不仅抗干扰能力强,而且比传统算法的识别精度更高。针对光伏组件在日常操作过程中产生的热点缺陷的检测算法研究较少,而且传统方法存在精度不足、泛化能力差等弊端,Guo 等^[65]提出一种结合红外热像和 Faster R-CNN 进行热点缺陷检测的方法,结合迁移学习和改进特征提取网络等措施来优化模型,并将其与原始 Faster R-CNN 模型的训练结果进行对比。通过自制测试集进行测试,结果表明,改进后的模型 mAP 为 97.34%,比原始模型高 4.51%。针对传统的子弹表面缺陷检测方法的检测精度低、速度慢的问题,利照坚等^[63]设计了一种将改良的 CNN 与 Faster R-CNN 结合的方案,并利用该方案对子弹的表面缺陷进行检测与识别,首先将优化后的 VGG16 和 ResNet50 模型进行特征提取,结合 RPN 网络生成候选框,再通过 Faster R-CNN 进行模型训练,对比两种改进

的特征提取网络可知,改进的 ResNet50 的效果更优,检测缺陷的 mAP 可达到 90% 以上。彭煜等^[7] 为了实现对刨花板的表面缺陷的实时监测,设计了一种基于 Faster R-CNN 的缺陷检测方案,通过对比 ZF、VGG16 和 ResNet101 三种特征提取网络可知,实验测试后,以 ResNet101 为特征提取网络的 Faster R-CNN 模型的效果更好,胶块、水印、砂痕等缺陷的 mAP 为 93.37%,FPS 为 256 ms。

2020 年,随着目标检测网络的不断发展,许多学者通过不同的级联方法和融合特征的策略进一步提升 Faster R-CNN 的检测性能。He 等^[7] 提出了一种新的基于 Faster R-CNN 的缺陷检测系统并将其应用于钢板缺陷检测,该系统采用 CNN 在每一阶段生成特征图,然后利用多级特征融合网络(MFN)将多个层次特征组合成一个特征,其可以包含更多缺陷的位置信息,采用区域建议网络(RPN)生成感兴趣区域(ROIs),分类器和边界盒回归器组成的检测器产生最终的检测结果,使用 Resnet-50 作为特征提取网络,在测试数据集 NEU-DET 上的 mAP 能达到 82%。对于绝缘子缺陷检测问题,传统的手工特征或浅层学习方法的弊端是适用性低、抗干扰能力差,难以满足工业环境的更高要求,因此 Tao 等^[7] 通过设计新型 CNN 层叠架构来执行定位和检测绝缘子的缺陷,采用基于 Faster R-CNN 的级联网络将缺陷识别问题转化为两级目标检测问题,通过标准绝缘子数据集进行测试,缺陷检测精度和召回率分别为 91%、96%,满足绝缘子缺陷检测的精度要求,并具有良好的鲁棒性。针对传统的机器视觉方法对金属冲压件的复杂缺陷的检测过程复杂,且难以保证较高的准确度,苑丹丹等提出一种基于深层卷积神经网络(R-FCN)的缺陷自动检测方法,并将其缺陷特征提取部分与 ZF、VGG16、ResNet-50 和 ResNet-101 等网络模型进行对比,发现 ResNet-101 模型可提取更多的常见缺陷的高语义级别特征,并对 R-FCN 中生成候选区域的 Anchor box 机制进行了调整,最终将 Faster R-CNN 和改进的 R-FCN 的模型进行对比,研究结果表明,改进的 R-FCN 模型对金属冲压件表面的常见缺陷划痕和凹坑类的缺陷具有更好的检测效果^[73-74]。

YOLO 算法是端对端目标检测算法中的代表算法之一,主要思路是把目标检测进一步理解成回归问题,只需要通过

单一的网络结构就可以实现对图像目标的特征提取、候选框预测和类别判断,而且 YOLOv3 诞生后,对比之前的 Faster-RCNN,检测速度有了进一步的提升,因为其性能表现明显优于 Faster R-CNN,所以越来越多的学者倾向于基于 YOLOv3 搭建目标检测网络,并将其应用到实际的工程缺陷检测中,取得不错的成果。例如,Wei 等^[73] 针对要求铁路轨道检测更加快速、准确的问题,提出了一种基于图像处理和改进 YOLOv3 模型的铁路轨道缺陷识别方法,为降低模型复杂度和加快检测速度,特征提取网络选用了 DenseNet 模型,其可以实现多尺度特征融合,优化了模型的结构,此模型被命名为 DC-TLMDDNet 网络模型,通过实验测试发现缺陷的识别准确度和检测速度都有明显的改善,也证明了该方法的有效性。张逸等^[74] 为了实现对复合材料内部缺陷的高精度检测,首先利用 DR 技术将缺陷信息转化为图片,对 YOLOv3 的输入、输出进行改良,并采用自行构建的数据集对其进行标注与训练,完成了对复合材料中孔状缺陷的快速识别与定位。

3.3 图像分割技术

图像分割(Image semantic segmentation)^[7] 是通过计算机图像处理对若干个图像的感兴趣区域实现目标检测分割。近年来,图像分割技术发展迅猛,涌现了很多优秀的算法,总体来说可以分为三个大类:语义分割、实例分割和全景分割。

语义分割是通过像素点的划分进行语义类别分割,目前很多学者已经将图像语义分割技术应用于材料缺陷的检测,主要方法是将缺陷区域作为感兴趣区域,在正常的背景区域对其进行语义分割,这种方法不仅能将各种缺陷进行分类、定位与分割,还能得到相应缺陷的长度、宽度、面积等属性。采用全卷积网络对金相图片中的凹坑实现分割,如图 4 所示。现在已经有优秀的图像语义分割的网络模型,如 FCN^[75]、U-Net^[76]、SegNet^[80]、DeconvNet^[81]、DeepLab^[82] 等。实例分割的特点是结合了目标检测与语义分割,实现对每个实例的像素区域进行类别分割,而且同种类别的不同实例的标注信息也不同,代表性的算法就是 Mask R-CNN^[83]、PANet^[84] 等。全景分割是通过将图像中的所有像素点都标注类别信息与实例信息,从而实现对所有感兴趣区域(包括背景)的分割,代表性的算法有 OANet^[85]、EfficientPS^[86] 等。




图 5 全卷积网络结构

Fig.5 Structure of fully convolutional network

利用图像分割进行材料缺陷检测应用较多的方法为语义分割和实例分割,在语义分割的实际应用工程中常用的算法为 FCN 和 U-Net,这是因为它们的模型结构简单、检测效果

良好。为了进一步提升检测和分割的效果,许多学者通过融合不同的策略来改善材料的性能。2018 年, Han 等^[87] 提出了一种基于 CNNs 的多晶硅缺陷分割的新方法,利用区域建

议网络(RPN)生成缺陷区域,目的是减少像素间的不均匀分布,然后将生成的图像进一步统一尺寸,送入到基于U-Net和膨胀卷积的改进分割网络中,并用真实缺陷图像对该方法进行了测试。与之前的多晶硅缺陷分割方法相比,此方法不仅提升了多晶硅缺陷分割的速度,而且分割的准确率也有一定的改善,表现出更优的性能。2019年,He等^[83]针对实木表面缺陷检测方法中存在的实时性差和特征提取复杂的问题,提出了一种混合全卷积神经网络(Mix-FCN)的方法,并用该方法检测木材表面图像中的缺陷,首先准备了两个实木缺陷数据集,第一个数据集通过VGG16模型进行训练,得到预训练模型数据,将其作为Mix-FCN的初始化权重,再通过第二个数据集进行整体模型的训练与测试,结果表明,该方法不仅准确率达到91.31%,而且检测50张照片耗时0.368s,较之前的方法,其性能更加优越。Dung等^[84]为了实现混凝土裂缝的语义分割,设计了一种基于深度全卷积网络(FCN)的混凝土裂缝检测方案,利用VGG16模型作为编码器、FCN作为解码器,实现端对端的语义分割,将从混凝土试件循环加载试验视频中提取的图像作为测试集,裂纹语义分割的平均精度约为90%,此方法还可以进一步得到捕获裂纹的尺寸,对土木工程中的裂纹检测具有重要意义。Roberts等^[85]为了实现电子显微图中的纳米级晶体缺陷的语义分割,提出一种改良的卷积神经网络(CNN)架构DefectSegNet模型,该结构在模型内部将编码器和解码器进行跳跃连接,并通过钢常见晶体缺陷进行测试,证明了该方法的可行性,而且通过对比实验发现,对比度差异大是模型预测不确定性的主要来源之一。传统太阳能电池缺陷是利用电致发光图像来检测,但是存在电池缺陷类型严重不平衡和背景噪声的干扰性较大等弊端。2020年,Rahman等^[86]提出了一种基于改进的U-Net卷积网络的图像分割的表面缺陷检测方法,并将其应用于太阳能电池缺陷检测,首先利用两个多注意网络分别进行有效特征提取和背景噪声抑制,然后将二者合并到改进的U-Net卷积网络中,提出一种混合损失计算方法来减轻类不平衡问题和完成复杂缺陷样本的训练,利用五折验证评估该方法,结果表明改进的U-Net方法的分割和检测缺陷的准确率高于之前的方法,也表明该方法的有效性。

实例分割的特点是结合了目标检测与语义分割,在实际工程应用较多的算法为Mask R-CNN,在不同的工程应用中可结合不同的策略来改善检测和分割的效果。Zhang等^[87]为了快速解决交通事故中的车辆损伤如何进行赔偿的问题,缓解交通堵塞的情况,设计了一种基于迁移学习和改进的Mask R-CNN且用于车辆表面损伤检测的分割算法,通过结合优化的ResNet网络和FPN进行特征提取,调整了PRN网络中锚点的比例和阈值,对于不同比例的目标,调整了损失函数中各部分的权重。结果表明,车辆表面损伤分割算法在检测精度与速度上都有很好的表现,也表明了其用于解决交通事故赔偿的可行性。韩明等^[88]为了进一步提升齿轮中存在缺齿等细微缺陷的检出率,设计了一种将ResNet-401和Mask R-CNN结合的缺陷检测网络。首先通过对比五种残差网络,确定ResNet-401和改进的FPN作为特征提取网络,再通过对标注方案进行细微的调整,选出更有效的Anchor大小

及宽高比,提升了候选区域网络的训练性能,缺齿的检出率高达98.2%,而且此方法对微小缺陷对象的检测和分割具有一定的通用性,拥有良好的应用前景。

4 结语与展望

基于深度学习的材料缺陷识别的优势不仅在于深度学习的网络模型学习能力强,可以拟合任意复杂曲线,只要通过大数据的训练学习,就能提取材料的缺陷信息特征,实现对材料缺陷的高精度检测,而且可以直接实现端对端的材料缺陷检测,降低工程的复杂度。但是在运用深度学习进行缺陷识别的过程中,网络结构模型的学习都是基于大量数据进行训练的,而且大部分网络需要人工制作标签信息,这种监督式学习是有限度的,它依赖于训练数据的可用性,当材料缺陷信息采集难度大、可用样本数据集少时,其适用性降低。本文针对目前存在的一些问题,对其未来发展趋势进行了展望:(1)近年来对生成对抗网络(GAN)的研究非常火爆,其主要应用于图像生成等方向,考虑将GAN与目标检测算法进一步相融合,实现数据增强,使其适用于部分材料缺陷数据集获取困难的情况,也是一个值得研究与思考的方向。(2)对于相近领域,如金属、陶瓷、玻璃材料等,或可考虑针对跨区域迁移学习将相近领域的缺陷数据集进行迁移学习,从而在进行模型的训练学习时降低对大数据的依赖性。(3)目前对深度学习的材料缺陷检测方法大部分都是基于二维图像进行的,只能获取有限的平面特征信息,无法获得材料缺陷的空间特征信息,如何采集和利用三维缺陷信息并更加精确地对缺陷进行检测也是未来值得研究的一个方向。

参考文献

- Eisenmann D J, Enyart D, Lo C, et al. *AIP Conference Proceedings*, 2014, 1581, 1505.
- Chen Z, Wang J, Sun P. *Internal Combustion Engine & Parts*, 2020(4), 44(in Chinese).
陈朝,王靖,孙鹏. *内燃机与配件*, 2020(4), 44.
- Chiem T P, Wei Q Y. *International Journal of Digital Crime and Forensics*, 2014, 6(4), 50.
- Chang W J, Pan J, Meng F H. *Machine China*, 2014(10), 108(in Chinese).
常文见,潘杰,孟凡辉. *中国机械*, 2014(10), 108.
- John H G. *Quality*, 2016, 55(11), 41.
- Xie S J, Duan Z R, Li, J, et al. *Sensors and Actuators A: Physical*, 2020, 309, 112030.
- Chesnokova A A, Kalayeva S Z, Ivanova V A. *Journal of Physics: Conference Series*, 2017, 881(1), 012022.
- Cheng J, He C F, Zheng Y, et al. *NDT&E International*, 2020, 114, 102283.
- Anton D P, Ina Y B, Igor Y B. *Materials and Design*, 2020, 187, 108385.
- Du W Z, Shen H Y, Fu J Z, et al. *Journal of Intelligent Manufacturing*, 2021, 32, 141.
- Tang B, Kong J Y, Wu S Q. *Journal of Image and Graphics*, 2017, 22(12), 1640(in Chinese).
汤勃,孔建益,伍世虔. *中国图象图形学报*, 2017, 22(12), 1640.
- Zhai D, Ding Y N, Li T. *Electronic Science and Technology*, 2014, 27(1), 160(in Chinese).
翟栋,丁亚男,李涛. *电子科技*, 2014, 27(1), 160.
- Wang H, Zhang Y, Shen H H, et al. *Chinese Journal of Optics*, 2017, 10(4), 438(in Chinese).
王浩,张叶,沈宏海,等. *中国光学*, 2017, 10(4), 438.

- 14 Chen Y H. *Journal of Baoji University of Arts and Sciences (Natural Science Edition)*, 2013, 33(1), 16(in Chinese) .
陈一虎. 宝鸡文理学院学报(自然科学版), 2013, 33(1), 16.
- 15 Herve A, Williams L J. *Wiley Interdisciplinary Reviews Computational Stats*, 2010, 2(4), 433.
- 16 Chen Q L, Wang D X, Lin J G, et al. *Forging & Stamping Technology*, 2020(6), 168(in Chinese) .
陈麒麟, 王东兴, 林建钢, 等. 锻压技术, 2020(6), 168.
- 17 Zhang Y Y, Li Y B, Wen Y T, et al. *Acta Metrologica Sinica*, 2020, 41(5), 544(in Chinese) .
张玉燕, 李永保, 温银堂, 等. 计量学报, 2020, 41(5), 544.
- 18 Qi J Y, Li J Y. *China Welding*, 2019, 28(1), 56.
- 19 Yu H L, Hao L H, Liang H, et al. *Journal of Forestry Research*, 2019, 30(6), 2379.
- 20 Hu X Z, Sui Q M. *Instrumentation Customer*, 2017, 34(1), 21(in Chinese) .
胡秀珍, 隋青美. 仪器仪表用户, 2017, 34(1), 21.
- 21 Ding W, Wang Q G, Zhu J F. *IEEE Access*, 2020, 8, 44661.
- 22 Chao C H, Eugene S, Po L, et al. *Advances in Technology Innovation*, 2020, 5(2), 76.
- 23 Zhou X, Wang Y N, Zhu Q, et al. *Journal of Electronic Measurement and Instrument*, 2016, 30(5), 702.
- 24 Wang Y, Wu Z H, Duan X Y, et al. *IOP Conference Series-Earth and Environmental Science*, 2018, 108, 022025.
- 25 Yang J, Yang G. *Algorithms*, 2018, 11(3), 28.
- 26 Jieun P, Dokyun Y, Sangmin J. *Symmetry*, 2020, 12(4), 615.
- 27 Hinton G E, Osindero S, Teh Y W. *Neural Computation*, 2014, 18(7), 1527.
- 28 Hinton G, Salakhutdinov R. *Science*, 2006, 313(5786), 504.
- 29 Goodfellow I J, Pouget A J, Mirza M, et al. *Advances in Neural Information Processing Systems*, 2014, 3, 2672.
- 30 Krizhevsky A, Sutskever I, Hinton G. In: Conference Record of 2012 Conference and Workshop on Neural Information Processing Systems. Lake Tahoe, 2012, pp. 1097.
- 31 Deng J, Dong W, Socher R, et al. In: Conference Record of the 2009 IEEE Conference on Computer Vision and Pattern Recognition. Miami, Florida, USA, 2009, pp. 248.
- 32 Simonyan K, Zisserman A. *Computer Science*, DOI: 10.48550/arXiv.1409.1556.
- 33 Szegedy C, Liu W, Jia Y, et al. In: Conference Record of the 2015 IEEE Conference on Computer Vision and Pattern Recognition. Boston, 2015, pp. 1.
- 34 Ioffe S, Szegedy C. In: Conference Record of the 32nd International Conference on Machine Learning. Lille, 2015, pp. 448.
- 35 Szegedy C, Vanhoucke V, Ioffe S, et al. In: Conference Record of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, 2016, pp. 2818.
- 36 He K, Zhang X, Ren S, et al. In: Conference Record of Computer Vision and Pattern Recognition (CVPR) . Las Vegas, 2016, pp. 770.
- 37 He K, Zhang X, Ren S, et al. *Computer Vision*, 2016, 9908, 630.
- 38 Huang G, Liu Z, Van D M, et al. In: Conference Record of 2017 IEEE Conference on Computer Vision and Pattern Recognition. Hawaii, 2017, pp. 2261.
- 39 Howard A G, Zhu M, Chen B, et al. In: Conference Record of the 2017 IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, HI, USA, 2017.
- 40 Park J K, Kwon B K, Park J H, et al. *International Journal of Precision Engineering and Manufacturing-Green Technology*, 2016, 3(3), 303.
- 41 Kiryong K, Heeyoung K. *IEEE Transactions on Semiconductor Manufacturing*, 2018, 31(3), 395.
- 42 Yao M H, Chen Z H. *Computer Measurement & Control*, 2018, 26(9), 29(in Chinese) .
姚明海, 陈志浩. 计算机测量与控制, 2018, 26(9), 29.
- 43 Szegedy C, Ioffe S, Vanhoucke V. In: Conference Record of the Thirty-First AAAI Conference on Artificial Intelligence (AAAI-2017) . San Francisco, 2017.
- 44 Deitsch S, Christlein V, Berger S, et al. *Solar Energy*, 2019, 185, 455.
- 45 Yang Y X, Zhao M. *Heavy Machinery*, 2019(2), 25(in Chinese) .
杨延西, 赵梦. 重型机械, 2019(2), 25.
- 46 Zhang Z, Wen G, Chen S. *Journal of Manufacturing Processes*, 2019, 45, 208.
- 47 Guan L L. Research on crystal defect classification and detection technology based on deep learning. China Academy of Engineering Physics, China, 2019(in Chinese) .
贯丽丽. 基于深度学习的晶体缺陷分类检测技术研究. 硕士学位论文文, 中国工程物理研究院, 2019.
- 48 Fu L. *IFAC-Papers on Line*, 2018, 51(17), 45.
- 49 Wei R F, Bi Y B. *Materials*, 2019, 12(10), 1681.
- 50 Zhan X L, Zhao W T. *Laser & Optoelectronics Progress*, 2020, 57(10), 143(in Chinese) .
詹湘琳, 赵婉婷. 激光与光电子学进展, 2020, 57(10), 143.
- 51 Bang H T, Park S, Jeon H. *Composite Structures*, 2020, 246, 112405.
- 52 Di H, Ke X, Peng Z, et al. *Optics and Lasers in Engineering*, 2019, 117, 40.
- 53 Yu He, Song K, Dong H, et al. *Optics and Lasers in Engineering*, 2019, 122, 294.
- 54 Pan S J, Yang Q. *IEEE Transactions on Knowledge & Data Engineering*, 2010, 22(10), 1345.
- 55 Sun J, Wang P, Luo Y K, et al. *IEEE Transactions on Instrumentation & Measurement*, 2019, 68(12), 4787.
- 56 O'Leary J, Sawlani K, Mesbah A. *IEEE Transactions on Semiconductor Manufacturing*, 2020, 33(1), 72.
- 57 Zhang N, Donahue J, Girshick R, et al. In: European Conference on Computer Vision. Springer International Publishing, Germany, 2014.
- 58 He K, Zhang X, Ren S, et al. *IEEE Transactions on Pattern Analysis & Machine Intelligence*, 2014, 37(9), 1904.
- 59 Girshick R. In: Conference Record of the 2015 IEEE International Conference on Computer Vision. Santiago, Chile, 2015.
- 60 Ren S, He K, Girshick R, et al. *IEEE Transactions on Pattern Analysis & Machine Intelligence*, 2017, 39(6), 1137.
- 61 Redmon J, Divvala S, Girshick R, et al. In: Conference Record of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, NV, USA, 2016, pp. 779.
- 62 Redmon J, Farhadi A. In: Conference Record of the 2017 IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, HI, USA, 2017, pp. 6517.
- 63 Redmon J, Farhadi A. In: Conference Record of the 2018 IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City, UT, USA, 2018.
- 64 Bochkovskiy A, Wang C Y, Liao H Y M. In: Conference Record of the 2020 IEEE Conference on Computer Vision and Pattern Recognition. USA, 2020.
- 65 Zhao X Y, Cai C P, Wang S, et al. *Light Industry Machinery*, 2019, 37(3), 60(in Chinese) .
赵欣洋, 蔡超鹏, 王思, 等. 轻工机械, 2019, 37(3), 60.
- 66 Zhang Y Y, Li Y B, Wen Y T, et al. *Acta Armamentarii*, 2019, 40(11), 2329(in Chinese) .
张玉燕, 李永保, 温银堂, 等. 兵工学报, 2019, 40(11), 2329.
- 67 Gao X, Jian M, Hu M, et al. *Advances in Structural Engineering*, 2019, 22(13), 2907.
- 68 Guo M H, Xu H W. *Computer Systems & Applications*, 2019, 28(11), 265.
- 69 Li Z J, Jiang X J, Zhu Z T, et al. *Modular Machine Tool & Automatic Manufacturing Technique*, 2019(9), 102(in Chinese) .
利照坚, 江秀娟, 朱铮涛, 等. 组合机床与自动化加工技术, 2019(9), 102.
- 70 Peng Y, Xiao S H, Yuan J H, et al. *Modular Machine Tool & Automatic Manufacturing Technique*, 2020(3), 91(in Chinese) .
彭煜, 肖书浩, 阮金华, 等. 组合机床与自动化加工技术, 2020(3), 91.
- 71 He Y, Song K, Meng Q, et al. *IEEE Transactions on Instrumentation and Measurement*, 2020, 69(4), 1493.
- 72 Tao X, Zhang D P, Wang Z H, et al. *IEEE Transactions on Systems, Man and Cybernetics: Systems*, 2020, 50(4), 1486.
- 73 Yuan D D, Yan X Y, Lu D D, et al. *Construction Machinery and Equipment*, 2020, 51(1), 23(in Chinese) .
苑丹丹, 阎相伊, 路丹丹, 等. 工程机械, 2020, 51(1), 23.

- 74 Dai J F, Li Y, He K M, et al. In: Conference Record of the 2016 Conference on Neural Information Processing Systems. Barcelona, 2016.
- 75 Wei X, Wei D, Suo D, et al. *IEEE Access*, 2020, 8, 61973.
- 76 Zhang Y, Cheng X S, Chui H H, et al. *Optics & Optoelectronic Technology*, 2020, 18(3), 75(in Chinese).
- 张逸, 程筱胜, 崔海华, 等. *光学与光电技术*, 2020, 18(3), 75.
- 77 Athanasiadis T, Mylonas P, Avrithis Y, et al. *IEEE Transactions on Circuits & Systems for Video Technology*, 2007, 17, 298.
- 78 Long J, Shelhamer E, Darrell T. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2015, 39(4), 640.
- 79 Ronneberger O, Fischer P, Brox T. In: Conference Record of the 2015 International Conference on Medical Image Computing and Computer-Assisted Intervention(MICCAI). Switzerland, 2015, pp. 234.
- 80 Badrinarayanan V, Kendall A. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2019, 39(12), 2481.
- 81 Noh H, Hong S, Han B. In: Conference Record of the 2015 IEEE International Conference on Computer Vision (ICCV). Santiago, Chile, 2015, pp. 1520.
- 82 Liangchieh C, Papandreou G, Kokkinos I, et al. *Computer Science*, 2014(4), 357.
- 83 He K, Gkioxari G, Piotr D, et al. In: Conference Record of the 2017 IEEE International Conference on Computer Vision. Venice, Italy, 2017, pp. 322.
- 84 Liu S, Qi L, Qin H, et al. In: Conference Record of the 2018 IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City, UT, USA, 2018, pp. 8759.
- 85 Liu H, Peng C, Yu C, et al. In: Conference Record of the 2019 IEEE Conference on Computer Vision and Pattern Recognition. Long Beach, CA, USA, 2019, pp. 6172.
- 86 Mohan R, Valada A. *International Journal of Computer Vision*, 2021, 129, 1551.
- 87 Han H, Gao C, Zhao Y, et al. *Pattern Recognition Letters*, 2018, 130, 234.
- 88 He T, Liu Y, Xu C, et al. *IEEE Access*, 2019, 7, 123453.
- 89 Dung C V, Anh L D. *Automation in Construction*, 2019, 99, 52.
- 90 Roberts G, Haile S Y, Sainju R, et al. *Scientific Reports*, 2019, 9(1), 1.
- 91 Rahman M R, Chen H. *IEEE Access*, 2020, 8, 40547.
- 92 Zhang Q, Chang X, Bian S B, et al. *IEEE Access*, 2020, 8, 6997.
- 93 Han M, Wu Q X, Zeng X J. *Computer Systems & Applications*, 2020, 29(3), 100(in Chinese).
- 韩明, 吴庆祥, 曾雄军. *计算机系统应用*, 2020, 29(3), 100.

(责任编辑 杨霞)



杨传礼, 2016年6月毕业于江苏师范学院, 获得工学学士学位。现为华东理工大学机械与动力工程学院硕士研究生, 在张修庆副教授的指导下进行研究。目前主要研究领域为基于深度学习的金属材料缺陷识别。



张修庆, 华东理工大学副教授、硕士研究生导师。2006年博士毕业于上海交通大学材料加工工程专业, 然后到华东理工大学工作至今。2014.7—2015.2到美国伦斯勒理工学院进行访问、合作研究。在国内外学术期刊上发表论文60余篇, 申请国家发明专利11项。其团队主要研究方向包括: 表面工程技术, 先进制造技术, 材料的合成、结构与性能研究, 新型合金材料、材料的腐蚀、磨损及防护, 纳米材料制备、应用与工程, 金属基复合材料的研制与开发等。