



燕山大学
YANSHAN UNIVERSITY

硕士学位论文

MASTER'S DISSERTATION

(学 术 学 位)

论文题名 基于机器视觉技术的钢板表面缺陷检测
研究

作者姓名 盖晨阳

学科专业 机械设计及理论

指导教师 赵德颖 副教授

2025 年 6 月

中图分类号: TG176

UDC: 620

学校代码: 10216

密级: 公开

学术学位硕士学位论文

(应用研究型)

基于机器视觉技术的钢板表面缺陷检测研究

硕 士 研 究 生: 盖晨阳
导 师: 赵德颖 副教授
副 导 师: 李海滨 教授
申 请 学 位: 工学硕士
学 科 专 业: 机械设计及理论
所 属 学 院: 机械工程学院
答 辩 日 期: 2025 年 5 月
授 予 学 位 单 位: 燕山大学

Research On Surface Defect Detection Of Steel Plate Based On Machine Vision Technology

A dissertation submitted to

Yanshan University

in partial fulfillment of the requirement for the degree of

Master of Mechanical Engineering

in Mechanical Engineering

By

Chenyang Gai

Supervisor: Assistant Professor Deying Zhao

Assistant Supervisor: Professor Haibin Li

School of Mechanical Engineering, Yanshan University

June, 2025

基于机器视觉技术的钢板表面缺陷检测研究

摘要：随着产业对钢板表面高光洁度的要求提升，传统人力检测与打磨方法难以满足生产速度与检测精度需求。为实现生产环境下钢板表面快速检测，本文专注于钢板表面缺陷检测任务，提出基于 YOLO 模型改进的目标检测算法，以适应移动设备资源受限环境，本文内容主要包括以下四点：

（1）本文构建包含 3200 张工业实际热轧钢板表面缺陷图像的数据集，覆盖不同背景条件样本，并按缺陷特征详细划分，为算法训练和验证提供丰富多样数据，充分验证改进模型泛化性能。

（2）出于便捷利用 YOLO 系列算法进行检测的目的，我们设计了输入参数调整的判别公式来调整图像输入尺寸。同时针对检测出来的图形进行面积定位与宽高判别进行缺陷类型的二次检验，提高了检测模型识别的准确性。

（3）将轻量化 PP-LCNet、DsConv 可变性卷积与带有 transformer 的 C3-Triplet 全连接层融入 YOLOv5s 基础检测模型，设计出 PP-LCYOLOv5s 轻量化钢板表面检测模型。该模型在保证精度基础上大幅减少浮点运算数与训练时间，并在 NEU-DET 数据集实验取得预期效果。

（4）在实际钢板表面检测任务中，选择了 YOLOv8s 作为工业实际钢板检测的基础网络，设计了 CPCA 注意力与改进 SPPF 金字塔机制的融合，同时为增加检测缺陷网络的鲁棒性与数据融合能力引入了开集检测 YOLO-WORLD 融合网络算法，最后发现为重点解决检测数据中最为薄弱的划痕缺陷，采用轻量化 GhostNet 核心网络进行综合优化，取得了良好的实验效果。实验结果表明，本文提出的改进模型在关键指标如 mAP、Precision、Recall 和 FPS 上都取得了显著的提升，成功实现了检测效率与准确性的平衡。

本文设计了基于机器视觉的钢板表面检测模型，实现了宽厚热轧钢板表面细小缺陷的自动检测与有效缺陷定位与识别。为后续的三维钢板表面检测与自动修复工作打下基础。

关键词：钢板表面检测；YOLO 系列算法；深度学习；小目标检测

分类号：TG176

Research on Surface Defect Detection Of Steel Plate Based on Machine Vision Technology

Abstract: With the increasing requirements for high surface finish of steel plates in the industry, traditional manual inspection and grinding methods have struggled to meet the demands of production speed and detection accuracy. To achieve rapid detection of steel plate surfaces in a production environment, this paper has focused on the task of steel plate surface defect detection and has proposed an improved object detection algorithm based on the YOLO model, aiming to adapt to the resource-constrained environment of mobile devices. The main contents of this paper are as follows:

(1) A dataset containing 3200 industrial actual hot-rolled steel plate surface defect images has been constructed. This dataset covers samples under different background conditions and has been detailedly classified according to defect characteristics. It provides rich and diverse data for algorithm training and validation, fully verifying the generalization performance of the improved model.

(2) For the purpose of conveniently utilizing YOLO series algorithms for detection, we designed a discriminant formula for adjusting input parameters to modify the image input size. Meanwhile, we carried out secondary inspection of defect types through area positioning and width - height discrimination of the detected graphics, which improves the accuracy of the detection model's recognition.

(3) The lightweight PP-LCNet, DsConv deformable convolution, and C3-Triplet fully-connected layer with transformer have been integrated into the YOLOv5s basic detection model to design the PP-LCYOLOv5s lightweight steel plate surface detection model. This model has significantly reduced the number of floating-point operations and training time while ensuring accuracy, and has achieved expected results in experiments on the NEU-DET dataset.

(4) In the actual steel plate surface detection task, YOLOv8s has been selected as the basic network for industrial actual steel plate detection. The fusion of CPCA attention and the improved SPPF pyramid mechanism has been designed. To enhance the

(5) robustness and data fusion ability of the defect detection network, the open - set detection YOLO - WORLD fusion network algorithm has been introduced. Finally, to specifically address the most challenging scratch defects in the detection data, the lightweight GhostNet core network has been used for comprehensive optimization, resulting in excellent experimental results. The experimental results show that the improved model proposed in this paper has achieved significant improvements in key indicators such as mAP, Precision, Recall, and FPS, successfully balancing detection efficiency and accuracy.

This paper has designed a steel plate surface detection model based on machine vision, realizing the automatic detection, effective positioning, and recognition of tiny defects on the surface of wide and thick hot - rolled steel plates. It has laid a foundation for subsequent three-dimensional steel plate surface detection and automatic repair work.

Keywords: steel plate surface inspection; YOLO series algorithms; deep learning; small object detection

Classification: 620

目 录

第 1 章 绪论.....	1
1.1 钢板表面检测的研究背景与意义	1
1.2 轧制钢板常见表面缺陷种类	2
1.3 钢板表面缺陷检测方式.....	3
1.3.1 传统检测方法.....	3
1.3.2 机器视觉方法.....	4
1.4 目标检测算法在钢板表面缺陷检测中的应用	6
1.4.1 双阶段检测方法.....	6
1.4.2 单阶段检测方法.....	7
1.5 研究内容.....	9
第 2 章 热轧板表面缺陷检测系统整体规划	10
2.1 引言.....	10
2.2 钢板表面处理系统简述.....	10
2.2.1 钢板表面处理流程.....	10
2.2.2 钢板表面二维监测系统规划.....	11
2.3 检测硬件系统设计.....	13
2.3.1 检测设备需求.....	13
2.3.2 检测关键设备选型.....	14
2.3.3 检测数据采集平台设计	16
2.4 数据集的整理与制作过程	18
2.4.1 标准钢板表面检测数据集-NEU-DET	18
2.4.2 实际钢板表面检测数据集的收集.....	19
2.4.3 评价指标.....	22
2.5 本章小结.....	24
第 3 章 缺陷检测模型的实验设置与评估方法	25
3.1 引言.....	25
3.2 参数调整的判别方法.....	25
3.2.1 置信度与输入批次的设置.....	25
3.2.2 图像输入尺寸的设置.....	26
3.3 缺陷面积计算与位置判定的方法	29
3.3.1 基于边缘平面积分的计算方法.....	30
3.3.2 基于蒙特卡洛法的计算方法.....	31
3.3.3 基于框选的计算方法.....	31
3.4 实验结果与分析.....	33

3.5 本章小结.....	35
第4章 基于YOLOv5模型的改进钢板检测模型	37
4.1 引言.....	37
4.2 基于YOLOv5的表面高速检测改进算法	38
4.2.1 轻量化主干网络 PP-LCNet.....	41
4.2.2 可分布移位卷积 DS-conv	42
4.2.3 三重注意力机制 Triplet-attention	43
4.3 实验结果与相关条件.....	44
4.3.1 实验条件与评价.....	45
4.3.2 实验结果与讨论.....	46
4.4 本章小结.....	49
第5章 基于YOLOv8模型的钢板检测模型	51
5.1 引言.....	51
5.2 YOLOv8 检测模型概述.....	51
5.3 基于YOLOv8的表面高精度检测改进算法	55
5.3.1 CPCA 注意与改进 SPPF 融合	56
5.3.2 Ultralytics YOLO-WORLD 开放检测网络.....	59
5.3.3 可变形卷积 Ghost Convolution.....	61
5.4 实验条件与设备.....	63
5.4.1 实验数据集的分析.....	63
5.4.2 实验设备的选取与搭建.....	64
5.5 实验结果.....	64
5.5.1 基于 CPCA 注意与改进 SPPF 融合的实验结果	65
5.5.2 基于 YOLO-WORLD 改进网络的实验结果	66
5.5.3 基于强化 Ghost Net 的改进结果	67
5.5.4 结果分析.....	69
5.5.5 对比试验.....	71
5.5.6 鲁棒性验证实验.....	73
5.6 操作界面简介.....	76
5.7 本章小结.....	77
第6章 结论.....	78
参考文献.....	80
附录 A 分析检测结果的代码.....	87
附录 B 改进损失函数的伪代码输入形式.....	93
附录 C Ghostconv 伪代码	95

第1章 绪论

1.1 钢板表面检测的研究背景与意义

宽厚钢板是现代工业生产中常用的基础材料，因其高刚度、高强度和高耐久性而被广泛应用于机械制造、移动装备、建筑业等行业。宽厚钢板表面出现的裂纹等缺陷可能会引发受力不均，电化学腐蚀等原因造成零件开裂，结构解体甚至爆炸等重大生产事故。其表面质量直接影响后续生产过程中产品的安全性、可维护性以及使用寿命。由于难以溯源识别等原因，这种生产事故的具体损失金额通常难以统计^[1]。事故原因通常需要通过后期检查才能确定。表面检测是确保钢材质量的重要环节，能有效防止质量不达标或假冒伪劣钢材流入市场，从而保障客户权益和基础设施安全。

近年来，钢板表面检测在工业自动化生产中逐渐成为研究热点。由于钢板表面缺陷通常呈现形状不规则、特征模糊等复杂性，依赖肉眼观察或基于物理信号的传统检测方法在识别精度和实时性方面存在明显不足，难以满足现代制造对高效、精准检测的要求。随着近几年计算机图像识别技术的蓬勃发展，图像的获取难度大大降低，图像处理和视觉识别技术有了很大的突破，并且在过去几年中有了很大的发展和突破，深度卷积网络在视觉领域的应用成为解决众多缺陷检测任务的最新技术。这使得研究这项技术具有深远而紧要的现实意义：

（1）以机器视觉技术为基础的检测研究有助于为后续自动化打磨工序打下基础，在保证员工身体健康、降低劳动时间成本、提高劳动生产力和检测效率、实现检测过程完全自动化等方面，减少检测打磨过程中的人力和实际消耗。

（2）多方位提升企业竞争力。在生产中，先进的测试方法不仅能促进生产效率的提高和产品质量的提高，而且能为进一步改进生产工艺和提高生产水平提供数据参考。钢板产品的表面质量不仅仅是为了保证美观，更重要的是它直接反映了钢板的整体质量，影响了其在市场上的竞争力。对企业的社会声誉和经济效益都有很大影响。

（3）钢板表面缺陷检测在对数据特征进行相应调整后，一般也可以在其他表面缺陷检测中有效应用，是表面检测技术的重要组成部分。如果钢板表面检测技术一

且成功应用于生产中，将钢板表面生产过程中自动检测与修复的方法推广到其他相似金属材料构成的表面：诸如齿轮，铝板与其他机械设备零件自动检测与修复中将会成为深度神经网络应用于工业生产中的目标。

1.2 轧制钢板常见表面缺陷种类

在实际钢板生产中，由于原始板坯在生产过程中因为温度，轧制环境与轧辊表面质量等问题，会产生多种表面缺陷，这些表面缺陷会严重影响钢板在后期加工过程中的机械性能，甚至导致钢板报废。常见的缺陷主要包括：表面夹杂^[2]、表面结疤、星形裂纹^[3]、划痕与压痕以及异物压入等。这些缺陷会导致材料的强度降低：这些缺陷会改变材料的应力分布，导致应力集中，从而降低材料的抗拉强度、屈服强度和韧性等力学性能。继而减少疲劳寿命。在循环荷载下，裂纹易于扩展导致材料断裂和疲劳寿命降低，最终大幅增加成本。由于裂纹导致材料强度降低，可能需要更多的材料来承受相同的载荷，从而增加成本。图 1-1 是钢板表面常见的缺陷类型。




图 1-1 常见的钢板表面缺陷类型

常用的钢板表面处理包括表面热处理，机械处理等。热处理设备有诸如抛丸机^[4]。机械处理设备主要是以打磨机构为主，郭阿敏^[5]设计了一种基于 FANAC 串联机器人的船舶零件打磨装置，目前已经应用于非标准零件的打磨上，并取得了显著的经济效益。检测作为表面处理的第一个环节，得到了研究者的关注并基于钢板表面缺陷

特征的不同性质开发基于多种技术的缺陷检测方法。这些缺陷检测方法主要包括人力检测、基于物理信号的检测与基于机器视觉技术的检测等方法。

1.3 钢板表面缺陷检测方式

目前钢板表面缺陷识别方法主要分为三类：基于人力肉眼的传统检测、基于物理信号的检测和基于机器视觉技术的检测方法。

1.3.1 传统检测方法

传统钢板表面检测主要依赖熟练工人的目视检查，这种方法劳动条件差、生产率低，并容易导致生产事故。因此，在大型生产线上，工程人员开始研究缺陷规律，并将广泛使用的自动化技术引入钢板表面检测环节。大量人力检测也为后续研究提供了宝贵的资料。

在长期的生产实践中发现，钢板表面缺陷可以通过某些物理量进行探测和描述，目前常用的基于物理信号的检测方法主要有以下三种。

基于磁现象的检测方法，使用钢板自带的磁学属性进行检测，使用变化的磁场进行检测^[6]将交变磁场引入到被测工件之中，会发现缺陷使得感应电流产生偏转与集中并产生非均匀磁场，根据磁场的方向大小可以推断出缺陷类型与所处位置。另一些机械工程技术人员从导波理论出发^[7]，将磁致伸缩传感器引入到钢板表面处理之中设计了磁致伸缩传感器的检测方法。这种方法能有效检测钢板表面和内部的物理性质，但需要专业设备，成本较高。

基于涡流现象的检测方法，与磁场类似，涡流同样能够出现因为表面缺陷产生不同于平滑钢板表面的变化，所以基于涡流现象的检测方法被应用在了钢板表面检测的过程之中^[8]，GONG Z Q^[9]对比了切向磁化和法向磁化下裂纹引起磁导率扰动的机理。然后，基于有限元模型探究了切向和法向磁化下裂纹取向和磁化强度对磁导率扰动幅值的影响提出了基于常规磁化的涡流检测（NMB-ECT）方法。TERUYOSHI S^[10]借助矩形涡流对钢板表面缺陷进行检测，设计出了准确、简便、快速地检查厚钢板背面的缺陷方法。

基于红外线的检测方法：通过高频感应线圈使轧制板坯表面产生感应电流，在高频感应的集肤效应作用下产生穿透深度小于 1 mm 的红外线，引起连铸板坯局部表面

的温度上升的检测方法。这种可以在缺陷处看到其在表面的图像检测方法在焊缝^[11]识别上发挥了重要作用。

1.3.2 机器视觉方法

随着机器视觉技术的发展,以及相机、激光扫描等感知设备的日益成熟,基于机器视觉的缺陷检测技术因其在公开数据集中的优异表现,逐渐受到工业界与学术界的广泛关注。

视觉是指生物体的神经系统通过不断接触外界信号刺激,再集中识别出不同图像中一类或几类特征,通过大量学习来筛选并总结出来某一类物体的关键特征从而形成对某一类物体的认知与判断,这就是机器学习。而将机器学习中训练数据量进行提升则形成了深度学习。

机器视觉的核心是利用机器设备和计算机技术模拟人类视觉进行观测和识别。人类视觉能够准确检测和分类物体,这是建立在大量数据和样本训练的基础上的。在机器视觉中,视觉部分基于神经网络理论。首先,将收集到的数据转化为离散的 RGB 像素,然后针对大量数据进行训练,筛选出图像的主要特征,并形成一特征权重来描述一类图像的相似性。这样,就可以基于已经学习过的图像特征来对新图像进行分类。常用的机器视觉方法有以下三种。

(1) 基于图像采集设备的视觉检测方法

在目前的工程实践中,主要有两种方法对钢板表面信息进行采集。两种方法分别是基于激光扫描^[12]的方法与面阵 CMOS 工业相机^[13]。激光扫描基于高精度激光束反射原理,通过旋转棱镜或振动镜组将单点激光扩展为线性扫描光束,利用物体表面反射光强度差异识别形貌或缺陷。而工业相机中的线阵或面阵 CMOS 传感器因其高分辨率、高灵敏度与部署灵活等优势,在连续钢板检测中更具实际应用价值。针对自主钢板生产线,现阶段国内大多数研发机构和钢铁企业设计选用的是以 CCD 成像为基础的机器视觉检测系统^[14]。而激光扫描由于效率较低,使用较少。

(2) 基于点云数据的三维视觉方法

机器视觉按照检测目标的维度可以分为三维视觉目标检测与二维视觉目标检测。

为了提升对复杂几何缺陷(如凹坑、鼓包等)的识别能力,部分研究引入了三维点云数据作为补充信息。点云通过结构光、激光雷达或多目摄像获取,以三维坐

标形式记录表面形态，部分还包含颜色或强度信息。赵畅^[15]、兰欢^[16]等人使用多目工业摄像技术来获得钢板表面的数据进行训练，但也有使用雷达收集数据空间中点的数据集，点云可以表示三维形状或对象，通常由三维扫描仪获取。点云中每个点的位置都由一组笛卡尔坐标（ X, Y, Z ）描述，有些可能含有色彩信息（ R, G, B ）或物体反射面信号强度信息来判断目标特征，最后借助深度训练来对其进行解决的方法。

（3）基于神经网络的图像识别方法

神经网络模型通过数学公式模拟生物神经处理问题，是一种由大量节点（或神经元）相互连接而成的线性—非线性运算模型，由大量的节点（或神经元）相互连接而成。每一个节点都显示出特定的输出特性。通过对图像数组的处理，模拟出了人类运用视觉进行学习的过程。常见的视觉侦测方式主要有两种，一种是常用的机器学习（Machine-Learning），一种是深度学习。机器学习以人工划定的数据集特征为核心，适合低成本、低复杂度场景；深度学习以数据驱动为特点，适用于高精度和动态环境，但需要平衡数据和算力成本。

应用在图像的深度学习网络主要有以下结构组成-卷积函数，归一化层^[17]，非线性激活函数，池化层与数据合并层组成，基于这些基本网络原理，人们设计出了诸如 Faster-rcnn^[18]、SSD^[19]、YOLO^[20-26]等适用于实际图像检测与识别的卷积神经网络。其中，双阶段检测网络在早期精度较高，但计算成本也较高。后期，采用标准化 backbone 主干、FPN 特征融合层和 SPP 空间金字塔池化机制的单阶段 YOLO 网络，因其兼顾检测精度与速度，成为现场工业布局的常用基础模型。除此之外，还存在有 GroupNorm^[27]，LayerNorm^[28]等用于处理其他问题的全连接层也因为其在多重检测领域的优势被广泛应用于基于神经网络的目标检测模型之中。

线阵列倾向于对钢板表面数据信息的直接采集，点云倾向于对钢板表面三维分布信息的收集，而神经网络法则是模拟人类学习方式对钢板表面缺陷问题进行识别。

基于神经网络的非接触式机器视觉方法不仅精度高、检测速度快，还可以直接使用技术成熟、价格低廉、部署容易的 PC 和工业摄像机，对钢板轧制线上的钢板进行快速二维表面缺陷检测，从而快速定位缺陷。通过二维表面检测的结果为点云模型进行三维深度检测做参考。使得最终能够较为准确地找出缺陷的具体特征以避免错找缺陷造成后续处理过程中的不便。

1.4 目标检测算法在钢板表面缺陷检测中的应用

随着深度学习的发展,学者们将深度学习引入到目标检测任务之中以完成以钢板表面缺陷作为任务所要检测目标的目标检测相关任务。目前主要的表面检测网络主要有双阶段的 RCNN 系列网络与单阶段的 YOLO、SSD、RT-DETR 系列网络。

1.4.1 双阶段检测方法

通过系统获取输入图像,提取多个自下而上的区域在使用大型卷积神经网络(CNN)计算每个建议的特征,然后使用特定类别的线性支持向量机对每个区域进行分类以实现净赚的物体检测与语义分割。这种将特征提取、分类和语义分割分开进行的方法称为双阶段神经网络检测方法。在钢板表面检测中,双阶段深度卷积融合网络^[29]作为精度较高的检测器,在生产中投入了广泛应用。通过学习钢板表面缺陷的纹理,可以有效地分析出缺陷的类型、位置和大小。

东华大学吴越^[30]分析了两种常用的目标检测算法:二阶检测模型 Faster-RCNN 与一阶检测模型 YOLO 系列算法在钢板表面检测不同领域的优势与劣势,指出二阶检测模型在精度方面优势较高但是速度较一阶检测模型低并对模型 Faster-RCNN 进行了一些改良并提升了检测速度,刘轮^[31]在检测的基础上使用针对性的网络改进获得更加精准的检测结果,运用图像分割手段对特征进行了细化处理,并且使用 SSD 算法进行了验证。张宇^[32]在卷积神经网络上专门设计出了应用于钢板类目标检测的专门注意力机制 MFAM 与 FFAM 以用于提高钢板表面检测精度。另外还有姜乐兵^[33]改进了 AlexNet 网络并对钢板表面缺陷进行分类并基于此新网络搭建了相关平台,田思洋^[34]提出了 G-ELM 专业分类算法来进行钢板表面的深度学习检测用于同时应用于目标检测以减少计算资源的消耗。

这些方法基于图像数据的神经网络检测,利用相机和摄像机收集表面信息并进行标签分类,然后将数据分为训练集、验证集和测试集。主要用于获得二维表面信息。二维表面检测目前分为图像分割,图像检测两个体系。以钢板图像检测为例:主要出现了基于两阶段神经网络的 R-CNN^[35],以二阶段网络为基础模型。ZHAO W^[36], WANG S^[37]针对钢板表面的缺陷特征,对 Faster-RCNN 的特征提取网络进行修改,以获得更好的缺陷检测结果。

1.4.2 单阶段检测方法

尽管两阶段神经网络检测精度与检测速度相较于原有检测网络取得了很大进步，两自由度网络检测结构存在复杂，计算要求高且速度较慢等问题，随着更加省时，效果更为良好的单阶段神经网络的问世，诸如 YOLO^[38]，SSD^[39]等手段基于其较快的检测速度与较高的检测精度被引入到钢材表面这种不规则，随机性强且难以查找的缺陷类型。

HE D^[40]等人首先使用 MG-CNN 对图像进行分类，分别训练不同的卷积核组以提取不同类型缺陷的特征图，然后将这些特征图转装入 YOLO 网络中，达到了 96% 的检测准确率。KOU X^[41]等人利用无锚点特征选择机制为模型训练选择理想的特征尺度缩短计算时间，然后，在模型中引入专门设计的密集卷积块，提取丰富的特征信息有效提高了特征复用和特征传播能力，增强了网络的表征能力。徐镗^[42]等使用轻量级网络（MobileNet）来代替 YOLOv3 原有网络中的密集连接网络（Darknet-53），利用轻量化网络适当减少参数量的提取，使其能够在较少参数总量下使用深层网络提高了检测精度。Zhang Y^[43]使用聚类，C3BiFPN 等机制成功将 NEU-DET 上的精度提升至 86.8%，Nguyen H V^[44]比较了 YOLOv5、YOLO-X 和 YOLOv7 在 NEU-DET 上的性能并选择了 YOLO-X 作为检测器的极限模型。但大多数人仍选择在 YOLOv3 系列算法上继续努力，如 LI G^[45]等人在使用 YOLO-C 技术检测钢板表面缺陷时也取得了良好效果。Luo X^[46]着重于使用轻量化基础的注意力机制以提高检测精度与速度。Xia K^[47]提出了一种新颖的重新参数化大核 C3 模块，使模型能够获得更大的有效感受野，提高复杂纹理干扰下的特征提取能力。Xiao. D^[48]提出了 YOLOv5-Transformer-BiFPN（YOLOv5-TB）模型用于检测镀锌钢板。MA H^[49]直接将 YOLOv7 中的 ELAN 高深度网络引入到了次领域并得到了一些进展。在钢板表面纹理缺陷纹理数据集 NEU-DET 上取得了大量成果。张嘉雄^[50]提出了一种轻量化 YOLOv7 用于解决实际场景钢板表面缺陷的检测问题。

在直接检测之外，对钢板表面进行语义分割的 DeepLabv3+ 技术^[51]也在钢材表面缺陷检测上得以投入使用并且取得了良好效果，目前已经在特定检测领域投入应用。Pan.Y^[52]将建立了双注意力深度学习网络，对油污，划痕，裂纹 3 种类型的钢材缺陷进行分类，定位其位置，并在钢材表面自动准确地描绘其形状。名为 DAN-DeepLabv3+ 的新型像素级检测算法将双注意力模块集成到 DeepLabv3+ 框架中，以追求更精确的

分割结果。改进 Swin-Transformer 的钢板表面缺陷检测方法^[53]这种可以广泛应用于改进检测网络的机制如今已经投入钢板表面缺陷检测之中。Luya.Y^[54]等人提出了一种自适应包围盒提取算法，该算法利用图像分块和像素差分技术获取目标包围盒，辅助数据集标注取得了良好效果。

在引入先进算法进行验证的基础上，还有研究针对数据集数量较少的问题进行了其他交叉性质的研究。同时对于未标注重要特征的自适应性也是可以投入钢板表面缺陷识别研究的。吴坤鹏等人^[55]尝试将语义分割方法应用于钢板表面缺陷检测，并提出了利用半监督学习减少对于标记样本的依赖，该方法采用教师—学生模型分立方法来提高检测精度以支持精度检测之用。何彧等人^[56]将弱监督技术引入到钢板表面检测以减少钢板检测产生的误检物件，漏检等问题。李钧正^[57]等人专门开发出针对小样本，少见的特殊钢板加工缺陷来开发出了专用的小样本学习检测算法。为了识别出情况特殊的钢板表面缺陷，多尺度几何变换^[58]也被应用于钢板数据在缺陷处的强化检测，基于改进 RetinaNet-GHM^[59]的钢板表面缺陷检测算法也实现了特定形貌钢板表面缺陷上的较高检测精度。

YOLO 系列算法因其速度和准确性的出色平衡，相较于其他算法具有强泛化性、低部署难度和低计算成本等特点，被广泛应用于多种形式的应用中，如钢制非标准机械零件缺陷^[60]，多种板料缺陷联合检测^[61]之中。作为一种应用广泛，成本低廉易于使用与分析的检测模型，在诸如电池^[62-63]表面缺陷检测，铸铁件^[64-65]的质量诊断，特种工程零件^[66-67]的检修工作，安全工程^[68-69]，农业产品，动植物状态检测^[70-71]等领域得到了广泛且灵活的应用。YOLO 相较于 RCNN、SSD 和 RT-DETR 等其他目标检测模型，在目标检测领域具有以下几点优势：

（1）速度快、实时性强：作为单阶段算法，YOLO 一次前向传播即可完成检测、分类和定位，适用于视频监控、工业表面缺陷检测等实时应用。

（2）背景误检率低：YOLO 算法通过利用全局上下文信息使得其不仅关注局部特征，而且能够考虑到图像的整体结构和内容，从而降低复杂背景下的误检率。这种全局信息的整合有助于区分目标和背景，提升目标检测的准确度与查全率。

（3）检测精度高：相比 SSD，YOLO 能学习更多全局信息，提高检测准确性。网络结构简单高效：YOLO 采用简洁网络结构，直接预测目标位置和类别，实现高

效检测。计算资源需求低、训练难度小：与 RT-DETR 相比，YOLO 无需存储大规模键值对，计算资源消耗低，训练过程更简单。

（4）实时性能优越：相较于 RCNN 与 SSD 检测方法 YOLO 在速度、实时性、检测精度、计算资源需求、训练难度等方面均展现出独特优势，特别是在实时性要求高的应用场景中表现更加突出。

1.5 研究内容

通过对目前常用的钢板检测方法的调研，本文基于 YOLO 易于改进、便于分析和使用的优点，选择 YOLOv5 和 YOLOv8 这两种常用的目标检测算法进行改进，以满足钢板检测需求。本文研究内容如下：

第二章：根据实际工程需求设计监测系统，包括设备选型、结构设计和安装过程，并说明数据集制作方法及检测模型的评价指标。

第三章：基于 YOLOv5 模型的基本逻辑结构进行 YOLOv5 模型改进，并展示改进模型在 NEU-DET 公开数据集上的实验效果。

第四章：基于 YOLOv8 系列算法进行相关改进。同时记录在自创数据集上使用改进 YOLOv8 模型的实验结果并给出对比实验与泛化实验。

第五章：综合上述本文研究内容，对本文所做的具体工作进行总结，并对之后的研究方向和工作内容等进行展望。并且给出一些相关的技术方案。

第 2 章 热轧板表面缺陷检测系统整体规划

2.1 引言

为了满足用户对热轧宽厚 304 不锈钢板的需求，生产厂家需要对钢板表面进行表面质量检查。受限于轧机轧辊表面质量与翻转操作机构的冲击、振动等问题。钢板表面会产生多种缺陷。为满足客户对钢板表面质量的苛刻要求，必须经过一系列检查和处理才能出厂。

钢板缺陷的检查处理主要包括三个环节：二维缺陷形貌检测、三维深度缺陷检测和钢板表面处理。检测系统应具备可扩展性，以便于后续的功能升级和扩展。适用于工业生产中的检测系统性能需求满足三个方面要求：

- (1) 具有高准确性的缺陷检测和识别能力，以降低漏检和误检的概率的准确性。
- (2) 借助具备实时检测的能力，以适应热轧板生产线的快节奏生产环境的实时性。
- (3) 具有能够长时间稳定运行能力，从而减少故障与停机时间的稳定性。

2.2 钢板表面处理系统简述

钢板在轧制完成后，需要经历检测，打磨等处理流程才能达到出厂所要求的平面度，粗糙度，处理过程包括表面缺陷检测，形貌检测与打磨处理等环节本节主要对钢板表面处理流程与二维平面检测硬件系统进行研究。

2.2.1 钢板表面处理流程

离开轧机的钢板在完成平面检测以后，需要使用雷达进行三维采集表面数据，形成一张点云检测图。配合前期做的二维检测获得详尽的钢板表面三维缺陷与分布图像。这种三维分布图像能够解释钢板表面缺陷特征的存在与大小，在得到三维钢板表面缺陷图像。本文可以通过一定的判定规则对钢板表面进行后续环节的处理。主要处理逻辑图流程如图 2-1 所示。

根据图 2-1 中的表面处理流程，钢板从轧机出来后，首先通过二维缺陷检测识别缺陷的位置与种类，然后通过三维检测评估缺陷的深度。从而获取缺陷的具体信息，

为后续的平面磨削和点焊处理提供依据，实现钢板表面的自动修复。本文主要是针对热轧钢板表面缺陷的二维表面检测环节，这个环节主要是对二维钢板表面缺陷做出较为精确的定位与形貌识别，为后面的三维检测与打磨处理打下基础。在采用双面翻面轧制方法的轧制过程中，由于翻转机构的误差和轧机故障，会产生多种缺陷。本文主要针对热轧钢板表面缺陷的二维检测环节，该环节负责对二维钢板表面缺陷进行精确定位和形貌识别，为后续的三维检测和打磨处理奠定基础。




图 2-1 热轧钢板表面处理流程框图

2.2.2 钢板表面二维监测系统规划

作为用于自动检测热轧宽厚钢板表面缺陷的系统，需要能够自动检测并识别热轧板表面的各种缺陷，包括但不限于凹坑、麻点、龟裂、氧化皮、斑纹、结疤、边裂、辊印、刮伤、划伤、油污和水印等。并且要求能够对检测出的缺陷进行准确分类和定位，以便于后续的质量控制和改进。此外，为了便于维护与改进的需要，研究者还需要为工程技术人员提供缺陷的统计分析功能，帮助生产管理人员了解生产过程中的质量问题，从而起到优化生产工艺的作用。为确保系统在实际应用中的有效性和可靠性。热轧板表面缺陷系统的整体设计需要满足以下多种系统目标、功能需求和性能需求。

(1) 图像采集功能：系统需要具备高清晰度的图像采集设备，能够实时捕捉热轧板表面的图像信息。根据现场调查，钢板是在热轧生产线上以每秒钟 30cm 的速度移动运行，需要使用一定采集频率的设备对钢板表面信息进行采集。以获得钢板的表面信息，实际生产场景之中的钢板表面尺寸达到了 10m*4m，经过估算与实地测量

的经验得知必须将采集设备放在距离钢板表面 2m 的地方才能够采集较为完整的钢板表面信息。

(2) 图像处理与提取功能：在本文中，系统被赋予了强大的图像处理算法，能够对采集到的图像进行预处理、增强以及特征提取等一系列操作，从而显著提升缺陷检测的准确性和可靠性。为了获取用于后续分类检测的图像数据，主要采用工业相机在轧制现场进行数据采集。由于轧制现场存在高噪声和较大电磁干扰等复杂环境因素，为了确保采集的样本质量稳定，研究中创新性地采用了分贝采样方法，从而有效获取了高质量图像，为后续缺陷检测工作奠定了基础。

(3) 缺陷检测与识别功能：系统需要采用先进的机器学习或深度学习算法，自动检测和识别处理后的钢板图像，找出表面缺陷并识别其种类与分布。这涉及使用计算机图像识别算法来进行图像识别。

(4) 缺陷分类与定位功能：系统应能够对检测出的缺陷进行准确分类，并定位其在热轧板上的具体位置，以便于后续的修复和处理。

(5) 统计分析功能：系统需要具备完善的统计分析功能，能够对检测出的缺陷进行数量、类型、分布等方面的统计分析，为生产管理人员提供有力的数据支持。

(6) 报警与记录功能：当系统检测到严重缺陷时，应能够及时发出报警信号，并记录缺陷的详细信息，包括缺陷类型、位置、大小等，以便于后续的质量追溯和改进。

(7) 用户界面与交互功能：系统应具备友好的用户界面和便捷的交互方式，方便操作人员查看检测结果、设置参数和进行数据分析。

基于这些所需的系统功能，本文通过数据线与软件将计算机与相机进行连接，设计了一个可以兼顾信息采集与图像处理的多功能现代化自动识别与表面缺陷采集装置。并将此装置通过与专业技术人员进行讨论之后成功投入了生产现场应用于数据采集与远程图像剪切之中，实现了数据采集的标准化与自动化。克服了传统采集过程耗时长，效率低下等问题。设计出来的系统如图 2-2 所示。

系统包括高性能工业相机，可以进行 GPU 并行计算的计算机系统与显示器及装在计算机中的相关算法组成。最核心的主要是装在进行 GPU 并行计算的计算机系统计算机中的相关算法。这是钢板表面缺陷检测检测系统能够执行任务的根本与核心所在。




图 2-2 钢板表面二维采集装置流程设计逻辑图

2.3 检测硬件系统设计

要想实现生产任务所要求的效果，必须针对实际生产情况分析生产环境对检测设备的需求参数，进而对检测设备进行选型与平台搭建成为重要的任务，本章节主要说明检测设备的需求、选型与检测平台机械结构设计。

2.3.1 检测设备需求

热轧钢板表面检测系统工作时需要考虑工作环境的影响。由于生产时温度较高，导致钢材表面极易与氧气发生氧化反应产生等一系列问题。此外，由于钢板表面温度较高，会产生雾化效果，导致光线传播变形，这使得摄像机在采集图像时出现光线偏移，造成图像变形和噪声增加。最终影响图像整体质量。下文是对检测系统工作过程中现实的以下问题进行说明。

高温效应带来的采集图像质量问题，并且需要减少系统的复杂度。在设计过程中：本文通过测量与了解企业需求得知钢板表面轧制速度为 30cm/s，要求检测的最小缺陷尺寸为 0.2mm*0.2mm，可检测钢板的最大宽度为 4000mm。能够对于经常出现的裂纹、结疤、划伤、麻点、压入氧化铁皮、折叠和网纹等缺陷检出率达到 90%，对于不经常出现的重皮、凸包、压痕、夹杂和气泡等缺陷检测率达到 80%。

经过详细讨论与周密计算，本项研究选用面阵 CCD 相机配合条形光源与准确检测钢板表面缺陷种类与二维坐标位置。总体检测过程分为两个阶段：一阶段的二维


定位检测与二阶段的精确三维信息检测。本项研究中二维定位任务主要是通过摄像机与检测模型实现。

二维定位阶段用来检测缺陷类型与定位缺陷坐标位置，为后续检测三维缺陷深度信息与修复提供先验知识，系统的设计参数与指标会在分章节中予以详细说明。

2.3.2 检测关键设备选型

设计满足检测任务要求的设备需要对关键设备进行方案选型：主要需要选型的设备主要分为两部分：照明反光设备与摄像设备。这两部分构成了收集钢板表面图像的技术基础设备—照明取光与摄像器精度关系到所收集图像数据的质量最终对检测精度与速度造成根本性的影响。

图 2-3 展示了在钢板表面检测中广泛应用的明场照明与暗场照明两种方式：明场照明（Bright Field Illumination）又称亮视野照明。光线直接照明被观察物体，图像细节清晰且对比度明显，适用于边缘、纹理和图案特征的检测与识别。例如，在检测产品表面质量时，明场照明可以有效显示出产品的生长纹、双晶纹、解理和相对折射率低（即突起低）的包裹体等特征。但是明场照明会生成镜面反射不足的问题。研究中又使用了暗场照明（Dark Field Illumination），这是一种在无反射的黑背景下，用半球形反射面反射的光斜照被观察物体的方法。这种方法又称暗视野照明来进行照明采光。这两种照明方式的检测效果如图 2-3 所示。



(a)明场照明效果图

(b)暗场照明效果图

图 2-3 明场照明与暗场照明效果对比

成像原理：明场像是透射束成像，图像清晰；暗场像是衍射束成像，像有畸变、分辨率低。

光线反射：明场照明中，光线反射后进入照相机；暗场照明中，漫射光被反射进入照相机但镜面反射光线被反射离开。

从照明结果可以看出来，通过明场照明与暗场照明可以使得图像中表面缺陷的特征更加明显，提升了所采集图像的质量与图像使用效果，服务于后期的图像数据标注。

借助面阵 CCD 相机与漫射光源与线性光源分别构成明域照明与暗域照明的布局，明域照明检测可以清晰地表现二维三维缺陷。暗域照明可以更加突出三维缺陷显示出辊印缺陷。设备布局中明场照明使用的阵列 CCD 相机配有漫射光源，漫射光源可以有效地突出宽度方向上的缺陷。在检测精度为 0.2mm 的情况下，2K 面阵 CCD 相机采集速度最高可达到 0.04s，检测速度预估可以达到 2m/s。同时采用等距离采样技术已取得对钢板无遗漏无重复的效果。检测算法使用传统机器视觉和深度学习相结合的方式。初始阶段以传统机器视觉为主要方式对图像进行检测判别缺陷，将识别的结果打上标签作为训练集与验证集提供给深度学习网络进行学习。安装效果如图 2-4 所示。




图 2-4 设备布置结构效果图

从图 2-4 中可以看出设备主要有激光器、摄像头、定制红蓝光源等组成。可以得知先通过照明来提高摄像机对钢板表面缺陷的识别度。然后再进行拍摄彩图来进行

识别过程。激光器在定制红蓝光源与摄像头的对面安装，使得激光器与红蓝光源在钢板上照明显示出的缺陷能够在低光污染情况下清晰被摄取。

通过对市面上工业相机的选用与对钢板表面光学性质的分析，本文最终选用定制红蓝光源来增强宽厚热轧板的表面清晰度，在数据采集上选用一批 Baumer 公司的 VCXG.2-51C 全景摄像机来采集钢板表面的数据信息。同时将一台 LG 个人电脑通过网线与采集设备进行连接。同时使用不可发展式铝架来将相机安装在距离钢板表面的高处，在支架尾端加装电脑与金属废料作为配重来防止支架失稳，底部使用可调式轮来调整支架的水平度与位置，使得能够便于采集所需要的信息。中间使用三角形结构来确保摄像机与光源能够安全承载于收集支架上。

为了能够对采集而来的图像进行处理，需要一台专门应用于工业控制的计算机系统对图像的裁剪处理，出于稳定性与降低成本的考虑。本项研究选用一台 LG/联想无独立显卡 i5 核心的计算机作为控制图像处理设备来处理采集的视频。主要处理软件是摄像机配套的数据采集软件。

2.3.3 检测数据采集平台设计

在初步设计收集支架上安装了 1 台网络摄像机，摄像机固定在距离钢板大约 1.85m 处的收集架伸展臂上，安装位置如图 2-5 所示，初步记录时间大约为 1 个月，从 2 台分别配置在两侧的收集架收集视频。初步收集了一些视频，但是这样收集的视频普遍存在难以充分检测每块钢板上的缺陷，并且难以充分对钢板表面信息进行收集与审视，只能收集少量边缘数据信息以获得一些图像缺陷数据。




图 2-5 初步收集装置结构图

完整收集全部的钢板表面缺陷信息，需要让设备完全能够跨越钢板表面以能够有足够的视野来收集钢板表面的图像数据并且能够有一定的对光源强度，摄像位置的调控能力与对钢板运动的控制能力，这对于钢板检测设备与轧机末端适配性提出了新的要求。为了达到一定的可拓展性与对环境的适应能力（根据实际采光需要来获得最易于检测的钢板表面缺陷图像）以及对点云等二阶段系统的通用性，本文提出一种兼具可控制性、全面收集能力与收集稳定性的系统，系统的设计如图 2-5 所示。系统主要是由钢板通过架，相机支架，相机与光源阵列以及工控设备组成。其中相机支架在考虑到单个相机的视野与单个光源的照明范围后，采用多光源—多相机并联收集钢板表面数据以保证能够清晰检测钢板全貌信息。主要工控设备为一台 LG-lenovo 计算机来进行相机数据控制与收集。在数据采集装置结构图 2-6 中，展示出了钢板通过平台的布局。为了满足对多种平台特征进行驱动的需要，本文需要选择一定的驱动设备来针对收集装置进行驱动一对精密度要求较高的摄像机需要水平固定，竖直方向使用丝杠电机进行数值移位调节。




图 2-6 数据收集装置结构图

其实景如图 2-7 所示：主要由相机，可调整横梁，启停装置等组成。本设备在丝杠安装之外为了保证光源能够较好适应钢板表面环境进行照明。本文中采用了横向直线电机以驱动光源安装装置的方式来维持其顺应钢板对亮度需求的能力，最终设计出进行全面钢板数据采集的装置。



图 2-7 最终收集装置实景安装图

2.4 数据集的整理与制作过程

作为机器视觉中的重要组成部分，使用数据集进行训练视觉检测模型，进而得到检测所使用的权重，是机器视觉中深度学习的核心过程。目前常用的数据集主要包括图像数据集、音频数据集、视频数据集与文本数据集等。检测钢板表面缺陷使用的是图像数据集。本文采用了 NEU-DET 国际通用钢板表面检测数据集与自创的数据集并提供了相关参数与制作过程。

2.4.1 标准钢板表面检测数据集-NEU-DET

2019 年时，He Y^[72]等人在大量钢板实地生产数据之中收集，筛选制作出了一种钢板表面缺陷检测专业数据集 NEU-DET，用于描述了钢板表面生产中常见的六种缺陷：轧入氧化皮（Rs）、麻面（Ps）、夹杂物（In）、斑点（Pa）、裂纹（Cr）和划痕（Sc）每种缺陷各 300 张共计 1800 张图像，每张图像尺寸在 200*200。使用 Pascal VOC 格式进行标签，最终可以使用特定代码转化为适用于 YOLO 模型进行训练的格式。

这个数据集是目前钢板表面检测领域最为权威的数据集，被广泛应用于诸如算法设计与检验。常被用于测试检测钢板表面质量模型的性能。但是由于其采用了裁剪，统一尺寸与放大目标等方式处理，可作为一种测试改进算法的工具数据集使用。本

项研究中的钢板表面数据集就是受此数据的启发设计制作而成的。具体的 NEU-DET 缺陷图像特征如图 2-8 所示，在图 2-8 中展示了常见钢板表面缺陷的具体特征，可以看出这些缺陷之间的界限比较模糊。




图 2-8 NEU-DET 的六种表面缺陷图像示例

由于此数据集在钢板检测领域的稳定性，目前绝大多数用于检测钢板表面图像的模型均是基于 NEU-DET 钢板表面缺陷检测数据集设计与验证。

2.4.2 实际钢板表面检测数据集的收集

在实际工业生产中，钢板的表面状态往往是处于高度变化之中且板形尺寸变化，导致缺陷不能在很短时间内采集完成。需要大量采集数据才能够成功获得所需要的图像，考虑到钢板表面普遍较大而缺陷特征的尺度有可能极为微小，意味着在采集时必须考虑打光，采集架高度等因素。并且在较短时间内很难均匀收集到所需数据样本进行处理。往往收集过程较为漫长。这次本文在国内某家钢铁公司进行数据收集与标定工作。使用工业相机进行数据收集，实际上考虑到在流水线上每块宽钢板的长度为 10m，宽度为 4m。而且所有的表面缺陷图像数据都是需要在流动的钢板表面生产线上收集的。

在收集视频时本文采用 30 帧/秒的采样方式来进行收集,采集了 400 块钢板表面视频,每张视频的长度在 10 到 30 秒不等。借助视频帧提取技术每隔 5 帧对视频进行采样,共计采集到 6500 张图像。由于本身钢板表面积就远大于缺陷的面积,所以对采集到的图像进行了去除无缺陷图像的筛选。在采集到的视频图像中,很多因素干扰对于热轧宽厚钢板表面的检测。

如图 2-9 所示,在宽厚板上的缺陷一般小于 0.02 毫米以下,这就构成了机器视觉检测系统中小目标的范畴。考虑到钢厂内部环境与实验室中的相机均存在视野有限问题,表面可能反光使得对于因为背景相似导致的缺陷标记难度上升,难以识别真实缺陷与凹凸不平造成的背光区别。

这些问题表明,在后续研究中为了提高宽厚板表面小目标的检测效率,必须采用专门针对小目标检测的模型设计思路,并结合综合改进措施。这些改进措施包括优化数据集的采集质量、提高训练轮数(可能导致过拟合问题)、改进检测模型与扩充数据等常规方法。也有通过分割图像来突出强调缺陷特征,以获得更高理论检测精度的非常规方法。但是单纯分割图像来增强图像对训练实际工业用的检测模型并无益处,甚至可能会干扰模型对实际图像的理解。

由图 2-9 中可以看出,压坑相较于划痕缺陷更为圆润且深度相对于尺寸要浅,而划痕缺陷相对具有更加深而锐利的形态。因此本文在这里采用经典的 `labelimg` 标记工具来处理标签图像,将 `dent` 缺陷使用绿色最小边界矩形进行标记,同时对 `scratches` 缺陷使用紫色最小边界矩形进行标记。这种缺陷类别不平衡的情况按照工业实际情况:划痕缺陷与压坑缺陷是随机分布的,由于在实际钢板拍照上两种缺陷不易区分,因此一般放在同一张图像上进行处理。所以在研究时只能够采取标注所有异质缺陷进行处理。划痕缺陷整体呈狭长细小形状,多由于钢板轧制过程中翻转导致的尖锐物体表面造成的挫伤。压坑缺陷是因为轧机轧辊表面并非完全平整,存在有坑洼处轧辊凸起,粘上的金属碎屑对钢板表面轧压导致的坑洼状缺陷。整体呈小圆坑,椭圆坑形状。为了避免将同一处缺陷出现在不同的拍摄图像中,以反映真实钢板表面存在的缺陷情况,本文采用重拼接算法进行了复原实验。

确定的钢板表面图像之间不存在数据重叠,同时在校内钢板轧制工程专家指导下,经过对无缺陷钢板表面冗余图像的筛选剔除,得到了 3200 张存在有数量种类大小一致,但是真实反映钢板表面缺陷情况且分辨率为 950*1400 的图像。




图 2-9 所收集钢板表面数据，上图均为所收集钢板表面数据的效果图

标签文件以 PascalVOC 格式保存，在实际检测时转化为 txt 标签格式以供 YOLO 模型进行学习训练之用，这些缺陷的种类与数量如表 2-1 所示，所收集的缺陷总计分为压坑与划痕两种缺陷，其中压坑 10800 个，划痕 675 个。

表 2-1 钢板表面缺陷数量

缺陷种类	压坑	划痕
个数	10800	675

两种数据集的特征进行对比如表 2-2 所示，自制数据集与 NEU-DET 表面缺陷数据集在缺陷种类、个数、分布均匀度与图像张数、图像尺寸大小与图像的分布方式上均存在很大的差别。是由于钢板表面检测理论与实际生产场景的区别：实际生产中考虑到设备条件与时效性往往收集到的数据非常难以识别。实际生产中所采集的缺陷是随机出现的，受到采集时间，钢板轧机工作条件，钢板表面材质与钢板

表面尺寸的影响。而且往往会出现在同一张大图像上。NEU-DET 数据集中缺陷种类的评价方法可以协助验证模型的效果与性能，但是不能直接用来实际应用。

表 2-2 自制数据集与 NEU-DET 对比

数据集类型	数量	像素	氧化皮	麻面	夹杂物	斑点	裂纹	划痕	压坑
NEU-DET	1800	200*200	300	300	300	300	300	300	0
自制数据集	3200	950*1400	0	0	0	0	0	675	10800

本文主要以自建钢板缺陷数据集为研究对象，旨在解决工业现场中缺陷尺度小、类别不均衡等检测难题。同时引入 NEU-DET 公开数据集，作为性能评估的辅助测试平台，用于分析算法的通用性与对比性能。相较于 NEU-DET 表面缺陷数据集，自制数据集中缺陷面积占钢板表面图像总面积的比例更小，而且分部更加稀疏且没有准确的数量规律，反映了钢板表面轧制缺陷拍摄的实际情况。而且受限于拍摄高度，打光强度与钢板运动速率，采样噪声等工程因素的影响。很多微小缺陷在 950*1400 的钢板检测效果下只呈现出 5-10 个像素的尺度，并且缺陷图像的分页不明显。这会造成检测时容易出现失真现象。而 NEU-DET 数据集中的缺陷图像面积在总面积中比重更大也更加集中。实际收集的钢板表面缺陷面积占到总面积的比例可能占到 0.2% 以下，而 NEU-DET 的图像缺陷面积可能占到图像总面积的 10% 以上。这里通过对框大小的直观比较可以得到。本文主要采用研究一种实测数据集解决实际工业生产问题的检测模型，但是作为钢板检测领域的权威数据集，NEU-DET 公开表面数据集在本文的研究中承担了重要的作用，探索钢板表面检测模型选用，改进思路与实用数据集的制作原则。

2.4.3 评价指标

参照多数工业零件缺陷检测的训练集及测试集与验证集的划分方法，本文使用随机切分等手段保证不因为刻意划分造成精度检测结果不准的问题。为了评价本文模型的实验结果，引入了如下的检验指标：在本文中，使用 mAP 平均精度，多重缺陷各自检测的精度、F1 评分、参数量和 FLOPS 用于评估模型的好坏。考虑到实际应用的需要，还需要对检测速度进行评估，表 2-3 可被称之为混淆矩阵。

表 2-3 混淆矩阵

	正样本	负样本
正样本	真阳性 (True Positive, TP)	假阴性 (False Negative, FN)
负样本	假阳性 (False Positive, FP)	真阴性 (True Negative, TN)

精确率表示预测值为正样本中预测正确的比例。精确率用来衡量分类器输出正样本的准确率，其计算表达式为公式(2-1)：

$$P = \frac{TP}{TP + FP} \times 100\% \quad (2-1)$$

式中 TP ——正确分类的正例数量；

FP ——错误分类的正例数量。

召回率表示把所有正样本预测出来的比例，衡量的是分类器能把正样本预测正确的能力，其计算表达式为公式(2-2)：

$$R = \frac{TP}{TP + FN} \times 100\% \quad (2-2)$$

式中 TP ——正确分类的正例数量；

FN ——错误分类的反例数量。

精确率与召回率这两个评估指标通常是相互矛盾的。在神经网络训练过程中，如果精确率能够保持不变或者增长，同时召回率还能不断提高，就说明分类器性能提升了。相反的，如果只有召回率提升，精确率反而下降，则该分类器性能较差。通常情况下，会使用 PR 曲线来评价分类器在精确率与召回率之间的平衡。AP=精确率-召回率曲线与坐标轴所围成的面积。一般情况下，mAP 面积的大小与分类器性能好坏成正比。mAP 是多个类别 AP 值的平均值，越大越好，是衡量检测器性能优劣最重要的一个性能评估指标。目前 mAP 主要有多种

$$AP = \int_0^1 P(R) dR \quad (2-3)$$

$$mAP = \frac{1}{C} \sum_{i=1}^C AP_i \quad (2-4)$$

$$F1 = \frac{2PR}{R + P} \times 100\% \quad (2-5)$$

式中 P ——准确率；

R ——召回率；

C ——表示检测类别的数量。

不同数据集中检测类别的数量通常有所不同。但通常工业上为保证精度，查全率与通用性，一组数据集中检测类型数量通常在 2 到 10 之间。

2.5 本章小结

在本章中本文详细说明了钢板表面的处理流程与检测装备的设计过程以及数据集的制作。主要分为几个方面进行论述：

（1）钢板表面缺陷的处理流程主要包括二维检测、三维检测以及打磨与焊接处理。其中，本文着重说明了二维检测流程系统的具体流程与相关要求。

（2）根据宽厚热轧 304 不锈钢表面缺陷二维检测的工作条件，研究针对检测要求进行了设备的布局与选型，并设计了一种龙门式高度可调的检测支架。

（3）在数据处理方面，通过采集钢板表面的图片数据，并与标准的钢板表面缺陷数据集 NEU-DET 进行对比。研究详细介绍了图像数据的标注、筛选以及标注方法，并阐述了数据集训练、验证和检测的评价指标。这些步骤为后续算法的训练提供了丰富且有价值的参考。

第3章 缺陷检测模型的实验设置与评估方法

3.1 引言

深度学习,即机器在大量已知相似数据中寻找一定的数据分布规律从而实现对未知数据进行判断与识别的方法。其命名源自自然界中生物神经网络进行学习识别。而基于深度学习的目标检测则是通过机器对图像数据进行大量训练,从已知图像中找出分布规律并推出未知图像中相关信息的方法。目标检测网络的核心组成部分包括神经网络(Neural Network)、卷积函数、HE K^[73]提出的全连接层与激活函数、优化器等。在此之外目标检测模型参数结构与会极大程度影响目标检测的效果与速度的调参判别方法。本文在此基础上,基于检测算法的几种参数的调整方法与检测结果,提出了自己的基本操作界面。

3.2 参数调整的判别方法

在应用在目标检测的深度学习模型中,除了算法,关于参数调节的判别是另外一个非常值得注意的事项。为使得图像在基础模型上训练取得较好的效果,需要通过一定的规则来考虑调整参数。在本文使用的YOLO算法里面,出于检测兼顾速度与精度的效果的目的,需要根据硬件条件与图像数据集的质量来确定使用合适的超参数。

3.2.1 置信度与输入批次的设置

在YOLO系列模型中,最重要的三个超参数分别为置信度(IoU),即预测值与真实的交并比,常用于在检测中显示结果,其表示方法如图3-1所示。同一种模型在不同的置信度下会显示不同的检测精度效果。考虑到钢板表面缺陷的难检测,易混淆与宽厚不锈钢板生产的昂贵成本,这个对于后面的训练至关重要。图3-1就直观显示了置信度(IoU)的工作原理与工作效果,即预测至于真实值的交集并集比例,交并比越高则表明检测对执行的要求更加苛刻。在需要高精度检测的场景中适宜采用高交并比,本文中IoU调参设置为0.7。




图 3-1 IoU 逻辑结构简图

输入批次指的是一次优化模型参数的数据批次。在目标检测任务中，每个批次包含多张图像以及它们对应的标签信息。为了充分利用硬件，考虑到向量化，并行运算与内存对齐等要求，主要设置成 8 的倍数，比如 8、16、32 等。选用训练输入批次数主要受到以下三个因素的影响：

训练速度：较大的批次可以提高训练速度，因为可以一次性处理更多的数据，从而充分利用计算资源。

内存占用：较大的批次可能导致内存占用过大，不适用于资源受限的情况。相反，较小的批次能够更有效地利用内存和 GPU/CPU 计算能力。

模型稳定性：批次大小的选择也会影响模型的稳定性。较小的批次可能引入更多的噪声，但也可能有助于模型跳出局部最优解。

根据以上三条内容，研究者需要根据数据集的大小、计算资源和模型的复杂性对输入批次进行调整。在资源允许的情况下，可以尝试使用较大的批次来提高训练速度。同时，也需要注意监控内存占用情况，确保训练过程不会因内存不足而中断。

3.2.2 图像输入尺寸的设置

在计算机视觉中，测量图像面积大小的单位是像素。同样算法输入图像的单位也是像素。同样的图像数据集有同样的训练轮数，如果采用不同的输入尺寸（imgsz）可能会取得不同的效果。在初始设置使用基础 YOLO 模型训练时，所有的图像都会被拉成统一的输入尺寸以适应检测模型矩形输入框的结构，同时图像缺陷数据集可以设计成长方形或者正方形。

图像实际尺寸与输入尺寸的效果比可以有以下公式(3-1)，(3-2)定义：

$$S_{image} = L \times w \quad (3-1)$$

$$S_{input} = (D_{img})^2 \quad (3-2)$$

式中 L, w ——指的是输入图像的长度与宽度，单位是像素；

D_{img} ——指的是检测模型的输入尺寸，单位是像素。

按照检测模型的一般输入模型规则，检测模型的输入尺寸数主要是 32 的倍数，且检测模型的输入尺寸最好能够被 10 整除。本文按照最小公倍数计算得到这个数是 160。在实验时本文发现，为了保证训练速度与节省 GPU 的内存资源，必须确保输入尺寸尽可能小。通过讨论与对实验现象的总结发现一个常数规律。即式(3-3)的比值判别：

$$a = S_{image} / S_{input} \quad (3-3)$$

式中 S_{image} ——指的是事实图像像素面积，单位是像素；

S_{input} ——指的是图像输入面积，单位是像素。

当判别式中无量纲数 $a \geq 1$ 时，则不会出现因为图像过度压缩导致细小目标特征丢失使得初始训练精度极低的现象。但是过大的 a 可能会导致由于输入图像尺寸过大继而导致训练与检测速度过低，甚至造成 GPU 内存的浪费与不必要地过拟合问题。

这里推导输入尺寸中的 160 的倍数 n 与图像尺寸间的关系，通过联立(3-1)、(3-2)和(3-3)可以得到最后的倍数量纲式(3-4)：

$$n \geq \frac{\sqrt{L \times w}}{160} \quad (3-4)$$

根据两种不同的数据集 NEU-DET 与自制数据集的图像尺寸可以推出 n 的最小取值，并取一个整数再乘以 160 就是 `imgsz` 的值了。通常像素面积较小的数据集 n 主要取 4，但是如果发现 `imgsz` 输入为 160×4 时训练精度极低，且在大量训练后仍然效果差。就得根据判别式与数据集图像的情况进行重新计算取值。计算取值的大小可能会影响到单批次输入量与 GPU 内存占比。所以计算取值要尽量在满足此判别式的基础上要尽量小。

在实验中我们发现,使用参数判别公式算出来的不同输入参数来对自己所采集数据集进行测试的效果受到很多方面的影响,比如图像中所要识别的特征纹理站总面积的比值、图像纹路质量等因素。本文在分析了自制的钢板表面数据集的图像纹理特征与图像的总面积后,发现在 YOLO 检测模型默认的 640 输入尺寸框架下,大像素面积与极小目标的缺陷图像数据集可能会面临检测时特征丢失,检测平均精度低下的问题难以确认初始检测图像数据集的质量,难以做出合理的模型改进措施。对调整模型输入尺寸参数效果如图 3-2 所示。

```
YOLOv8s summary: 181 layers, 11127510 parameters, 0 gradients, 28.5 GFLOPs
Class      Images  Instances  Box(P      R      mAP50  mAP50-95): 100%| 21/21 [00:02<00:00, 9.06it/
all        324      1214      0.511      0.436      0.438      0.161
dents      324      1158      0.687      0.46      0.569      0.213
scratches  324       56      0.335      0.411      0.307      0.109
Speed: 0.2ms preprocess, 1.8ms inference, 0.0ms loss, 1.0ms postprocess per image
FPS:333.85
Results saved to runs\detect\train15
```

(a)输入参数尺寸为 640 时的检测平均精度

```
YOLOv8s summary (fused): 168 layers, 11126358 parameters, 0 gradients, 28.4 GFLOPs
Class      Images  Instances  Box(P      R      mAP50  mAP50-95): 100%| 21/21 [00:02<00:00, 8.78it/s]
all        324      1214      0.698      0.648      0.678      0.29
dents      324      1158      0.756      0.778      0.808      0.355
scratches  324       56      0.639      0.518      0.547      0.226
Speed: 0.3ms preprocess, 2.9ms inference, 0.0ms loss, 0.7ms postprocess per image
FPS:257.27
```

(b)输入参数尺寸为 1280 时的检测平均精度

图 3-2 不同输入尺寸参数下的检测平均精度

通过这个图 3-2 总结出来的表 3-1 的对比可以看出来,从经过判别式计算的输入参数中可以得出采用更大的输入尺寸参数可以有效提升模型对数据的训练效果,能够避免大量的特征丢失造成的基础模型检测精度过低对后面的研究造成干扰。其中表里的 d.代表 dents, scr.代表 scratches。

表 3-1 不同输入尺寸参数对初始训练精度的影响

基础模型	Imgshz	AP(d.)	AP(scr.)	P(d.)	R(d.)	P(scr.)	R(scr.)	mAP50
YOLOv8s	640	56.9%	30.7%	68.7%	46%	33.5/%	41.1%	43.8%
	1280	80.8%	54.7%	75.6%	77.8%	63.9/%	51.8%	67.8%

通过判别式调整输入尺寸参数对于数据集检测平均精度的上升式是有效的。这意味着数据集对压坑缺陷的检测基础精度已经达到了较为优良的水平。在对输入尺寸进行使用判别式进行调整后,对于自制数据集总体平均精度提升了 55%。说明这个输入尺寸能够让基础模型在资质的小目标钢板表面缺陷数据集上实现较为精确的检测与识别。这对于后面开展的对检测模型的改进研究非常重要,无需重新制作数据集而可以满足于进行检测模型改进与扩充已有数据集。

```
from ultralytics import YOLO

if __name__ == '__main__':
    model(YOLO(r"D:yoloxx.yaml")).train(**{"cfg":r'...\cfg\default.yaml'},imgsz=160*n,
batch_size=8,epochs= 200))
```

3.3 缺陷面积计算与位置判定的方法

的检测视角下很难给出明确的界限。这需要进行更加精确的面积尺寸校验计算。常用的校验算法有适用于语义分割的边缘二重积分的计算方法与基于蒙特卡罗统计的计算方法。也有基于 YOLO 模型的框选计算方法。

3.3.1 基于边缘平面积分的计算方法

平面积分，作为计算不规则图形面积常用的计算工具。其表达式如下式(3-5)所示：

$$S = \iint_{y=y(x)} f(x, y) dx dy \quad (3-5)$$

式中 x ——指的是图像在 x 坐标上的尺寸，单位是像素；

y ——指的是图像在 y 坐标上的尺寸，单位是像素。

此公式常被应用于对于不规则图像面积的计算，由于实际不规则的二维图像的边缘难以用确切的曲线方程来进行概述，故多利用二次曲线-直线或者插补思想来将缺陷空间边缘按小段再一定范围内进行积分。最后通过分段积分的累加求出缺陷面积与缺陷的中点。计算公式如(3-6)所示：

$$S = \sum \left(\int_{x_n}^{x_{n+1}} (y_{top}(x) - y_{bottom}(x)) dx \right) \quad (3-6)$$

式中 y_{bottom} ——指的是图像在顶部坐标，单位是像素；

y_{top} ——指的是图像底部坐标，单位是像素。

通过计算，同样可以采集到缺陷中心点位置的 x , y 坐标轴与确切位置，这需要使用简单公式(3-7), (3-8)：

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x \quad (3-7)$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y \quad (3-8)$$

式中 n ——指的是图像像素点的个数。

缺陷中心点 x 坐标的是缺陷内所有像素点的 x 坐标平均值, y 坐标值是缺陷内所有像素点的 y 坐标平均值。通过这种平均值与面积分结合的算法可以较为精确的求出缺陷的确切面积与位置信息，但是对后期打磨的路径规划没有太多参考价值。

在小目标缺陷的检测中，这种统计方法由于计算成本较高，数据实用性不大等缺陷。所以在实际的不规则缺陷面积检测中，通常会引入另一种基于数理统计面积于坐标的蒙特卡洛计算方法。

3.3.2 基于蒙特卡洛法的计算方法

蒙特卡洛法，也称统计模拟方法，其具有概率收敛的特性：随机数生成需满足均匀分布假设，若区域边界存在锐角或分形结构，需采用拉丁超立方抽样优化空间覆盖性收敛速度与维度成反比：在处理二维问题是效率最优，适用于拓扑结构复杂的断裂、腐蚀等工业缺陷

在计算不规则图形面积时，只需要统计落在缺陷内的点在总图像中的点数比例可以估计出缺陷的总面积。计算公式如式(3-9)所示：

$$S_D = \frac{N_1}{N_0} \times S_I \quad (3-9)$$

式中 S_D ——缺陷的近似面积；

N_1 ——落在缺陷图像内的随机点个数；

N_0 ——落在整张图像内的随机点个数；

S_I ——图像总面积。

相较于上面的积分近似计算，蒙特卡罗方法的计算速度更快，且在计算面积较大且难以确切求出缺陷轮廓曲线的缺陷面积估算中效果或较好，随机点数越多计算精度越高。但是对于小目标其实用性并不强。本文的是采用基于方框的缺陷面积计算与种类二次判断方法。

3.3.3 基于框选的计算方法

基于YOLO模型的检测方法-框选检测，是将检测出的缺陷主要被方框进行圈定。而且YOLO软件自带有缺陷检测结果框中中心位置、宽度与高度的有关信息；这些信息在实际的钢板平面上就对应了缺陷在钢板上的大小钢板的位置。从这些点配合计算可以得到缺陷框的边角点坐标于缺陷面积，其计算公式如下(3-10)到(3-14)所示：

$$x_l = x_0 - \frac{w}{2} \quad (3-10)$$

$$x_r = x_0 + \frac{w}{2} \quad (3-11)$$

$$y_u = y_0 + \frac{h}{2} \quad (3-12)$$

$$y_d = y_0 - \frac{h}{2} \quad (3-13)$$

$$S = h * w \quad (3-14)$$

式中 x_0 ——缺陷框中心位置 x 坐标;

y_0 ——缺陷框中心位置 y 坐标;

w ——缺陷框图像宽度;

h ——缺陷框图像高度;

S ——缺陷总面积;

x_l ——缺陷框左边缘坐标;

x_r ——缺陷框右边缘坐标;

y_d ——缺陷框下边缘坐标;

y_u ——缺陷框上边缘坐标。

在生产现场与采集回来的自制数据集中我们可以分析出,有时候压坑与划痕并没有明显的二维表面界限,这里我们针对自己收集的数据集,提出了二次校验框选的压坑与划痕判断原则,即比较二次校验生成的框的长短边比值,其判别式(3-15)如下所示:

$$a_{d-s} = \frac{\max(width, length)}{\min(width, length)} \quad (3-15)$$

式中 a_{d-s} ——缺陷种类的二次校验判别结果。

在现场钢板生产场景的板面缺陷检测中,常常会发现推理检测出的缺陷种类可能与事实上的缺陷种类存在于一定误差,特别是对于生产中较为常见的压坑与划痕缺陷而言。这两种缺陷是检测过程中唯一能够通过相机观察区分出来的。我们根据 YOLO 检测框的检测与二次矫正判别结果,给出了判断缺陷种类是压坑还是划痕的二次判断原则,还给出了基于次判别式的二次矫正缺陷评价指标,记作误标记率。

即位首次检测得到的某一类缺陷数与第二次矫正标注同类缺陷数差值与二次矫正标注同类缺陷数统计值的比较式(3-16):

$$\eta_{de} = \frac{n_{fi} - n_{se}}{n_{se}} \times 100\% \quad (3-16)$$

式中 η_{de} ——某类缺陷的二次校验误标记率;

n_{fi} ——缺陷种类的首次检测统计数;

n_{se} ——缺陷种类的二次校验统计数。

当判别式结果大于等于 2.4 时,可以确定缺陷种类压坑缺陷,反之则为划痕缺陷。

此外利用统计的方法对两类缺陷在钢板表面的面积分布与位置分布进行了图像绘制以揭示两类缺陷在钢板表面呈现的不同趋势。这些参数,在不同的印工艺那个场景进行显示与分析有助与分析图像缺陷分布于大小,为后续的打磨工作奠定位置路径规划相关的有用数据。

3.4 实验结果与分析

本文根据项目的实际情况,针对测试检测的 325 张图像进行了缺陷大小与位置的计算,发现了通过一定的点计算可以确定出所检测出来的打磨位置,本文设计了用于统计面积与确切位置的代码,代码在附录 A 中,检测结果如表 3-2 所示。

表 3-2 自制钢板表面数据集缺陷的二次分析结果


初次检测	二次校验		初次检测	二次校验	
总压坑缺	总压坑缺	压坑缺陷误标率	总划痕缺	总划痕缺	划痕缺陷误标率
陷数	陷数		陷数	陷数	
875	873	0.0023	33	35	0.061

相关的检测结果在图 3-3 中可以以较为直观的形式看出来,蓝色字是二次校验判断出的划痕,绿色字是二次校验判断出的压坑。在判断材料或产品中存在的缺陷是否被误标时,除了尺寸判定这一简单参考方法外,还需综合运用多种技术手段。诸如运用金相学通过分析材料微观结构,揭示内部组织和缺陷;化学检验则通过成分分析,识别材料中可能影响性能的杂质或不合规成分;三维检测技术则通过构建三维模型,直观展示和测量表面缺陷的尺寸、形状。这些方法相互补充,为准确判断缺陷提供了全面的技术支撑。综合运用这些技术,可以更准确地识别和评估本文中

所要研究的钢板表面缺陷的类型。



(a)一次推理与二次校验相同-压坑



(b)一次推理与二次校验相同-划痕



(c)一次推理与二次校验不同-压坑



(d)一次推理与二次校验不同-划痕

图 3-3 一次推理与二次检测效果图不同种类缺陷（蓝色是二次校验的压坑缺陷，绿色是二次校验的划痕缺陷）

在得到了误检率与统计检测出来的缺陷数后，缺陷在钢板表面的分布也是我们关心的通过这样的回归分析可以求得缺陷的集中分布点与面积大小。其通过回归分析得到的分析图如图 3-4 所示:这两张图展示了两种损伤类型（Dent 和 Scratch）在二维空间中的分布特征，分别通过颜色编码表示损伤面积的大小。从图中可以观察到以下几点：

首先，Dent 的分布呈现出高密度且均匀覆盖的特点，覆盖了整个 X-Y 平面，表明其形成机制可能具有较高的随机性或均匀性。颜色条显示，Dent 的面积变化范围较大（ $-0.35-0.35 \text{ mm}^2$ ），且颜色分布较为均匀，暗示其面积变化可能与位置无关，或受到某种全局性因素的影响。相比之下，Scratch 的分布则较为稀疏，且集中在某些特定区域，表明其形成机制可能与局部性或方向性因素相关。颜色条显示，Scratch 的面积变化范围较小（ $-0.5-3.0 \text{ mm}^2$ ），且颜色集中在某些区域，进一步表明其面积

分布可能与位置存在显著相关性。




图 3-4 基于自制数据集的表面缺陷数量与面积的分布

3.5 本章小结

在本章节中，本文首先系统阐述了深度学习与目标检测的基本理论，并对 YOLO 系列模型中关键的训练参数设置策略进行了分析，特别针对输入图像尺寸这一影响目标检测精度的重要超参数，提出了一种基于数据集分辨率自适应的输入尺寸调整方法。方法如下所示：

通过将图像输入尺寸与数据集图像像素尺寸做比值，在确保图像输入尺寸与像素尺寸比值大于 1 的前提下，通过公式对输入尺寸 `imgsz` 与 160 的比值取一个最小的整数来调整 `imgsz`，在确保不过分占用 GPU 内存资源的情况下就能得到最佳的一系列超参数调整值。本文在使用传统的 640 像素 `imgsz` 的情况下进行训练自制数据集的精度较低，平均高精度仅为 43.8%，经过合理的调参判别后改用 1280 像素的输入尺寸，成功将检测精度从 43.8% 提升到了 67.8%。证明了合理的超参数调整方法与能够为后文中使用 YOLO 模型进行检测训练做了充分的调试细节环境准备。

此外，针对检测结果的误报分析，本文结合基于框选面积的后处理分析方法，提出了一套用于划痕类与压坑类缺陷的二次判别准则。该准则依据检测框面积与缺陷真实面积之间的比例关系进行修正与再分类，可有效降低误检率与类别混淆情况。通过在可视化分析程序中绘制不同类型缺陷的散点图分布图谱，本文进一步观察到

两类缺陷在面积-位置空间中呈现出明显的聚类趋势。这一现象为后续缺陷标注质量提升、数据集扩展修复策略以及磨损路径优化提供了重要的统计支持与理论依据。

第4章 基于YOLOv5模型的改进钢板检测模型

4.1 引言

Ultralytics-LLC 公司的创始人 Glenn 将新一代 YOLOv5 的算法代码于 2020 年 6 月 10 日在 GitHub 上公开, 标志着 YOLOv5 的到来。开启 YOLO 算法大规模使用工程检测时代。其性能与 YOLOv4 并不相同, 但由于采用简化网络和空间金字塔池化机制, 推理速度可达 140FPS, 符合实时侦测需求。与 YOLOv4、YOLOv9、YOLOv7、YOLOv6 等先进的检测方法相比, 其网络结构非常简洁, YOLOv5 包含 YOLOv5s、YOLOv5m、YOLOv5l、YOLOv5x 四个网络结构相同的版本。不同的是, Ultralytics 团队通过 Depth_Multiple 和 Width_Multiple 两个参数分别对模型的深度和卷积核的数量进行控制。YOLOv5 网络结构也可以分为四个部分, 分别是 Input (输入端)、Backbone (骨干网)、Neck (多尺度特征融合模块) 和 Output (输出端)。YOLOv5s 具体结构见图 4-1 所示。




图 4-1 YOLOv5 网络结构简图

图 4-1 中，C3 为全连接层，SPPF 为空间金字塔池化层，Concat 为熔接机制，UpSample 为上采样机制。

通过随机缩放、随机裁剪、随机排布的方式进行特征提取和拼接的 Mosaic 数据增强方法，采用 k-means 聚类 and 遗传学习自适应地计算出最佳锚框值集。自适应锚框计算和自适应图像缩放等方法，显著提高了与前代模型相比的计算速度。提高了检测精度，同时标准化的函数包设计易于阅读和修改。

尽管基础模型具有兼顾检测精度，计算速度与检测成本等优点，但是在实际生产中仍然存在大量不足：训练时间较长，消耗浮点数较高与参数量较大难于在性能较差的实地设备上运算检测。为解决以上不足，本研究设计了一种轻量化的高速检测模型。

4.2 基于 YOLOv5 的表面高速检测改进算法

通过实验本文发现，对于 YOLO 系列模型的主要的改进方式有：基于更换颈部网络的改进机制，基于主干网络的改进机制，基于注意力机制的改进与卷积，下采样与损失函数等等改进方法。这些改进方法通常需要组合使用才能取得较为良好的效果，主要改进方法有如下四种：改进损失函数，基于主干网络的改进机制，基于注意力机制的改进，与空间金字塔池化层^[72]加以改进。在改进深度学习模型时，优化损失函数能提高预测精度与鲁棒性但可能增加计算复杂度；改进主干网络能增强特征提取能力与降低计算成本，但设计复杂性增加且可能牺牲精度；引入注意力机制能提升特征表示能力与模型可解释性，却也带来计算复杂度与参数调优的挑战；而空间金字塔池化层虽能提高尺度不变性与捕获多尺度特征，同样面临计算复杂度增加与过拟合的风险。因此，在实际应用中需综合考虑各因素进行权衡选择。

改进损失函数：可以根据目标任务的实际需求来确定的锚点机制之中，REZATOFIGHI, H^[74]给出了一种衡量损失的标准方式 IoU loss：即交并比损失函数。其表达形式如公式(4-1)所示：表示了 A，B 两种预测边界框交并比。

$$IoU = \frac{A \cap B}{A \cup B} \quad (4-1)$$

式中 A——计算预测边界框；

B——真实边界框。

在模型学习图像数据的特征时，由于神经网络的不可解释性，往往网络模型不可能完全将所有的特征全部学习到，在学习时会遇到各种可能的损失，这种损失在前文中被称为交并比（IoU）。交并比损失较好描述了在图像学习中检测模型引起图像损失的状况，其计算图像如图但是由于实际学习时图像往往是不规则图形，单纯使用IoU容易引起精度过低，在深入研究图像与检测框重合情况的基础上，研究人员开发出了多种损失函数计算方法目前常用的损失函数主要有GIoU^[75]，DIoU^[75]，EIoU^[76]，与WIoU^[77]，SIoU^[78]等若干种等综合考虑问题的损失函数。其总体改进方法在附录B中展示。

在基于主干网络的改进机制、基于注意力机制的改进与基于颈部网络的改进机制中，本文分别选择了改进轻量化网络PP-LCNet，替换特征融合网络里的Conv为DsConv，在检测头前段使用C3-Triplet三重注意力机制。

基于PP-LCNet轻量化模块来改进主干特征提取网络：利用深度可分离卷积（DepthSepConv）进行串联，以改进对输入图像数据的特征提取，通过将图像中的信息进行压缩，保留主要特征信息，去除无用信息以提高后期检测对目标的识别效率。改进主干网络中用于压缩图像数据的卷积函数与其排列方式，可以设计出多种高精度主干网络与轻量化主干网络，本文中由于需要一种可以快速部署在生产现场的模型，考虑到实际检测中设备受到限制的情况，决定使用具有强压缩比的PP-LCNet以代替传统带有空间金字塔的主干网络结构。

使用轻量化的PP-LCNet网络直接替换原有主干网络以进行信息提取，通过减少C3层中的熔接机制来减少不必要的运算，实现对于主干网络的轻量化设计同时保证在大幅减少计算浮点数是其中DepthSepConv是PP-LCNet的主干网络中的串联构件，通过直接引入轻量化网络不仅能够顺利使原有网络顺利运行，还能够有效减少网络计算强度。

替换特征融合网络里的Conv为DsConv：与基于主干网络进行的改进的YOLOv系列不同，研究人员开发的诸如YOLO-X^[79]，DAMO-YOLO^[80]，GOLD-YOLO^[81]，YOLO-WORLD^[82]之类的变形模型都是针对特征融合层网络进行了改进。为了增强对于融合提取后特征的学习效率，减少对图像中非标签（无用信息）的筛选，本文研究引入可变形移位卷积（DsConv）分别安装在需要对图像特征进行压缩输出的融合网络部分以替代原有卷积以提高卷积检测效率。通过可变形移位卷积通过将卷积计

算集中于重要的信息，在压缩计算中将无用信息直接忽略，提高融合卷积网络对图像特征信息的提取精度，较大程度适用于提取较为细小，难以直接进行识别的且分散于图像各处的特征。本文经过大量实验发现将可变性移位卷积安装在融合网络中原卷积处在保证运行良好的情况下可以有效提高计算效率。

基于 TripletAM 注意力机制的改进：诸如 SimAM^[83]，CBAM^[84]与 TripletAM^[85]等注意力机制模块旨在通过模仿人眼对物体的关注程度，利用数学方法增强模型对序列数据中关键信息的关注度，从而提升模型的精度和效率。注意力机制主要分为点积、加性和自注意力三大类，其中 TripletAM 是众多机制之一。本文给出了表面高速检测模型 PP-LCYOLOv5s。主要的改进已经使用红色方块进行标出，分别为加装在主干网络上的 PP-LCNet，加载在 Neck 融合网络上的 DsConv 与加载在最靠近检测头的全连接层的 C3-Triplet 三重注意力机制。其网络图结构如 4-2 所示。




图 4-2 改进 PP-LCYOLOv5s 网络结构图

实验表明，添加注意力机制的位置对性能有影响，且在轻量化网络改进后，为追求速度可能会牺牲精度。经过多次实验，发现将 TripletAM 直接连通至 Detect 处效果最佳，此改进在减少计算资源需求的同时，检测精度得到补偿甚至略有提升。

4.2.1 轻量化主干网络 PP-LCNet

为了解决在较小计算资源下的检测精度与速率问题，Cui C^[86]在 2021 年研发了一种针对解决 CPU 进行计算的卷积网络模块，此网络中采用在 MOBLIENETv1 中的 DepSepConv 作为卷积模块，简略了可能造成精度下降与时间耗费的 Concat 机制。

出于提高推理速度与质量的目的，Cui C 尽量在单层中只使用一种大小的卷积核，并确保在低延迟和高精度的情况下使用大卷积核。实验发现，与 SE 模块的放置类似，在网络尾部仅用 5×5 卷积核替换 3×3 卷积核将达到替换网络几乎所有层的效果，因此本文只在网络尾部进行了替换。同时在卷积层的激活函数上采用了 Hardswish 函数来代替原版网络的 sigmoid 函数运算，以避免大量的指数运算来提升计算速度。同时在网络尾部插入 SE 模块来达到精度与速度的平衡。其网络结构如图 4-3 所示。SE 模块作为提升分类性能的函数模块，其同样存在两个激活函数：RELU 与 sigmoid 两种形态。




图 4-3 PP-LCNet 网络结构图

在图 4-3 中清晰展示了 PP-LCNet 单个单元的网络逻辑结构，通过这个逻辑结构模块不仅可以有效提取图像的特征，还能凭借成功去除了多余的浅层卷积冗余成功实现了轻量化的效果。也防止了因为过度轻量化导致精度下降过大的问题。

4.2.2 可分布移位卷积 DS-conv

为了实现使用更低的内存与更高的计算精度，KAISER L^[87]等人在 2017 年设计出了一种称为 DSConv（分布移位卷积）的卷积层变体，将传统的卷积核分为两个部分，具体结构如图 4-4 所示，两个部分分别是分布变化与变量量化核模块，下面简要说明两个模块的特点与功能。




图 4-4 DSConv 网络结构图

(1) 可变量化核 (VQK) 是分布移位卷积 (DSConv) 中的一个重要组成部分，其核心目的是通过量化技术降低卷积核的内存占用，同时提高计算效率。具体来说，VQK 通过仅存储整数值来实现更低的内存使用量，从而允许执行更快且内存高效的乘法运算。VQK 的结构与传统的卷积核类似，但它将参数值从浮点数量化为整数。量化过程通常涉及将浮点数映射到一组有限的整数值，从而减少存储需求。在 DSConv 中，VQK 的公式如(4-2)所示。

$$VQK = 2 \bullet (cho, chi, k, k) \quad (4-2)$$

式中 cho ——是输出通道数；

chi ——是输入通道数；

k ——是卷积核的宽度和高度。

(2) 分布变化：该组件的目的是控制移动 VQK 的分布，以尝试模仿原始卷积核的分布。本文通过使用两个张量在两个域中移动来做到这一点。

可分布移位卷积使用迭代策略控制卷积核的移动，确保感知区域连续且不会因为变形偏移过大而发散。有效减少模型与计算设备的运算量与计算成本，通过对无用信息的忽略有效提高了训练的精度与速度。这种策略对于检测模糊性强的数据集具有较好的检测效果。能够有效减少训练的资源消耗并是算法更多将资源用于有效信息融合上。

4.2.3 三重注意力机制 Triplet-attention

在 2021 年，MISRA D^{[85]12} 等人观察到，CBAM 中的通道注意方法虽然提供了显著的性能改进，但并没有考虑到本文所展示的在捕获时对性能有良好影响的跨维交互。此外，CBAM 在计算通道注意力时引入维数降维以捕获通道之间的非线性局部依赖关系是存在冗余的，为了解决此问题，此团队提出了一种基于无参数的注意力机制—三重注意力机制（Triplet attention mechanism）原理图如 4-5 所示：




图 4-5 Triplet Attention 网络结构图

三重注意有三个平行分支组成其中两个分支负责捕获通道维 C 与空间维 H 或 w 之间的跨维交互作用，最后剩下的分支类似于 CBAM，用于构建空间注意。所有三

个分支的输出都使用简单平均进行聚合。在构建三重注意力机制之前，每层注意力上均有一个 Z-pool 池化层机制。

Z-pool: 这里的 Z-pool 层负责将张量的第 0 维减少到 2，方法是连接跨越该维的平均池化和最大池化特征。这使层能够保留实际张量的丰富表示，同时缩小其深度，使进一步的计算更轻量化，公式（4-3）所示：

$$Z-Pool(x)=[MaxPool_{6d}(x) \quad AvgPool_{6d}(x)] \quad (4-3)$$

式中 $MaxPool$ ——最大池化；

$AvgPool$ ——平均池化。

三重注意力由三个分支组成，每个分支负责捕捉输入的空间维度和通道维度之间的交叉维度。给定一个具有形状（C x H x W）的输入张量，每个分支负责聚集空间维度 H 或 W 与通道 C 之间的交叉维度交互特征。本文通过简单地置换每个分支中的输入张量，然后将张量通过一个 Z-POOL，随后是核心大小为 1 的卷积层来实现这一点。然后，注意力权重由 sigmoid 激活层生成，然后在将其置换回原始输入形状之前，应用于置换后的输入张量。与以前的通道注意力机制相比，此方法有助于以可忽略的计算开销捕获更为丰富的区分特征标识。从而实现更加良好的输入效果。

在本项目中，通过将三重注意力机制嵌入到输出端的最后 C3 层中，有效提升了轻量化后模型对于钢板表面缺陷特征的提取能力，有效补偿了因为轻量化可能造成的精度下降问题。

4.3 实验结果与相关条件

为了验证本文提出的检测模型的有效性，必须通过系统性的实验验证其性能和泛化能力。为此，本文在实验设计阶段对训练和测试所需的硬件设备进行了详细的选型工作与对训练进行了详尽的评价指标的引入工作。其次，在评价指标的引入方面，本文采用了多维度的评价体系，以全面评估模型的性能和泛化能力，同时引入了训练时间，检测平均精度等业内通用指标。

此外本文构建了一个高效、稳定且可扩展的实验环境，为模型性能和泛化能力的验证提供了坚实的硬件基础。这一阶段的工作不仅为后续实验的顺利开展奠定了基础，还确保了实验结果的可靠性和可重复性。

4.3.1 实验条件与评价

为了满足深度学习网络对于计算能力的庞大需求，本文设计一套基于Pytorch3.8/3.9，CUDA12.3环境与Windows10系统的实验平台。其系统最早搭载在一张NVIDIA Geforce RTX 2080Ti的显卡上，使用13th-i5-13490 CPU与32GBDDR内存以配合其进行运算训练。为了达到最好的训练效果。本文借鉴国内外研究论文中实验人员常用的训练方法，选择使用随机梯度下降法进行优化。训练次数选用200轮。权重衰减参数设为0.0005，学习率设为0.01，考虑到图像大小为200*200，选择使用最为常用的输入图像大小为640。既能够满足现场检测任务对高速度的要求又能够满足较高的检测精度。考虑到钢板缺陷识别需要较高的检测置信度，将IoU阈值设置为0.7，在最后10轮训练中使用Mosaic增强以减少过拟合对精度的冲击。其参数表如表4-1所示：

表4-1 YOLOv5 训练超参数表

参数种类	学习率	衰减策略	优化器	动量	权重衰减	Mosaic 增强	输入图像尺寸
参数值	0.01	Cosine	SGD	0.937	5e-4	10	640*640

为了验证本模型对于钢板表面缺陷识别的精确性与有效性，本文选用业内著名的NEU-DET作为训练的基础数据集来进行训练。由于模型完成设计时间早于自有数据集采集时间，所以只进行了公开数据集试验。

2020年时，HE Y^[87]等人在大量生产数据之中制作出了一种钢板表面检测专业数据集，描述了钢板表面生产中常见的六种缺陷NEU-DET：作为目前钢板表面最为重要的数据集，由东北大学宋克臣等人收集并制作。包含六种：轧入氧化皮（Rs）、麻面（Ps）、夹杂物（In）、斑点（Pa）、裂纹（Cr）和划痕（Sc）每种缺陷各300张共计1800张图像，每张图像尺寸在200*200。属于热轧领域的权威图像，本文使用此数据集进行训练。在训练时本文将训练集与验证集按照通用的9:1比例进行了划分。训练实验中，总体平均精度mAP、多重缺陷的检测平均精度AP、查全率、准确率等参数进行了分析。采用F1评分、参数量和FLOPS用于评估模型的好坏。考虑到实际应用的需要，对检测速度进行了评估。在NMS之后，模型选择置信度大于0.7的预测框作为正例，否则选择负例。本项研究中检测类别的数量为6。

4.3.2 实验结果与讨论

通过实验本文发现，所提出的 PP-LCYOLOv5s 模型在能够有效减少设备训练时间与计算量的基础上，能够适当提高模型的检测平均精度。为了确认本文所设计模型的检测效果，本文在设备上进行了消融实验，消融实验结果如下表 4-2 所示。

表 4-2 消融实验结果

模型方案	Cr	In	Pa	Rs	Sc	Ps	mAP	P	R	GFL OPS
YOLOv5s	0.411	0.725	0.961	0.838	0.746	0.882	0.760	0.676	0.754	16.0
Yolov5s +PP-LCNet	0.394	0.751	0.923	0.796	0.721	0.916	0.756	0.699	0.705	2.0
YOLOv5s +DsConv	0.394	0.744	0.924	0.815	0.722	0.916	0.758	0.721	0.314	1.8
YOLOv5s+Triplet_Attention	0.398	0.764	0.975	0.842	0.713	0.916	0.761	0.754	0.698	16.7
PP-LCYOLOv5s	0.393	0.753	0.96	0.823	0.722	0.923	0.762	0.745	0.718	1.8

为进一步验证所提出模型的检测效果，本文还将本次实验的结果与国内外先进的钢板表面检测算法进行了对比，两种不同模型比较实验的结果如图 4-6 所示。

```

YOLOv5s summary: 157 layers, 7026307 parameters, 0 gradients, 15.8 GFLOPs
Class      Images  Instances  P      R      mAP50  mAP50-95: 100% | 6/6 [00:01]
all         180      423        0.676  0.754  0.76    0.419
crazing     180      77         0.539  0.364  0.411   0.144
inclusion    180      96         0.538  0.823  0.725   0.369
patches     180      90         0.791  0.967  0.961   0.641
pitted_surface 180      52         0.803  0.708  0.838   0.464
rolled-in_scale 180      52         0.622  0.769  0.746   0.351
scratches   180      56         0.762  0.893  0.882   0.547

```

(a) 基础模型实验结果

```

YOLOv5s_GHOST4 summary: 223 layers, 903879 parameters, 0 gradients, 1.8 GFLOPs
Class      Images  Instances  P      R      mAP50  mAP50-95: 100% | 6/6 [00:01]
all         180      423        0.745  0.718  0.762   0.407
crazing     180      77         0.867  0.0851 0.393   0.121
inclusion    180      96         0.542  0.852  0.753   0.372
patches     180      90         0.819  0.978  0.96    0.606
pitted_surface 180      52         0.821  0.731  0.823   0.475
rolled-in_scale 180      52         0.602  0.731  0.722   0.337
scratches   180      56         0.818  0.929  0.923   0.528

```

(b) 改进模型实验结果

图 4-6 原有模型实验结果示意图

为了验证本文提出的改进模型在检测效果和效率方面的提升，本文对基础模型与改进模型的实验结果进行了系统性的整理与对比分析。具体而言，本文将图 4-6 中的实验数据进行了进一步的提炼与归纳，以便更直观地对比改进后的模型在检测效果和检测速率上的变化。表 4-3 详细列出了基础模型与改进模型在各项关键指标上的性能表现，包括检测精度、召回率、F1 分数、检测速率以及计算浮点数（FLOPs）等。

表 4-3 多种模型的对比实验结果

模型方案	Cr	In	Pa	Rs	Sc	Ps	mAP	P	R	GFL OPS
YOLOv5s	0.411	0.725	0.961	0.838	0.746	0.882	0.760	0.676	0.754	16.0
PP-LCYOLOv5s	0.393	0.753	0.96	0.823	0.722	0.923	0.762	0.745	0.718	1.8

通过实验结果表可以证明，可以证明改进版本的模型的每一处改进均发挥了其应有的作用，PP-LCNet 通过轻量化网络机制有效减少了浮点运算数（将浮点数由 16.0GFLOPS 减少至 1.8GFLOPS），并同时提高了计算速率。Dsconv 通过将可以适应特征变化的卷积成功提高了对微小形缺陷的识别精度（In 类型缺陷从 72.5%提高至 75.3%，Ps 类型缺陷从 88.2%上升至 92.3%），而三重注意力机制增强了针对某些特征的有效识别能力。在 NEU-DET 钢板表面数据集检测训练上有效减少了浮点运算数（GFLOPS 从 16.0 降低至 1.8）与训练时间（从 0.675h 减少至 0.594h），具有一定在工业化钢板表面检测场合使用的潜力。主要用于对钢板的出厂快速检测与涉及钢板在生产现场的自动化维护中，而且便于在计算能力较差的现场工控计算机上进行部署与强化训练。表 4-4 的为 NEU-DET 的实验结果对比。

表 4-4 NEU-DET 数据集的实验结果图对比











	YOLOv5s 模型的检测效果	改进 YOLOv5s 模型的检测效果
(a)夹杂物缺陷		

表 4-4 (续)

	YOLOv5s 模型的检测效果	改进 YOLOv5s 模型的检测效果
(b)轧入氧化皮缺陷	 The image shows a dark, textured surface with a yellow bounding box around a defect. The label 'rolled-in scale 0.4' is visible in the top right corner of the bounding box.	 The image shows the same dark, textured surface with a yellow bounding box around a defect. The label 'rolled-in scale 0.4' is visible in the top right corner of the bounding box.
(c)划痕缺陷	 The image shows a dark, textured surface with a green bounding box around a vertical scratch. The label 'scratches 0.4' is visible in the top right corner of the bounding box.	 The image shows the same dark, textured surface with a green bounding box around a vertical scratch. The label 'scratches 0.4' is visible in the top right corner of the bounding box.
(d)斑点缺陷	 The image shows a light, textured surface with an orange bounding box around a defect. The label 'pitted surface 0.6' is visible in the top right corner of the bounding box.	 The image shows the same light, textured surface with an orange bounding box around a defect. The label 'pitted surface 0.6' is visible in the top right corner of the bounding box.
(e)麻面缺陷	 The image shows a light, textured surface with an orange bounding box around a defect. The label 'pitted surface 0.5' is visible in the top right corner of the bounding box.	 The image shows the same light, textured surface with an orange bounding box around a defect. The label 'pitted surface 0.6' is visible in the top right corner of the bounding box.
(f)裂纹缺陷	 The image shows a dark, textured surface with a red bounding box around a defect. The label 'crazing 1.1' is visible in the top right corner of the bounding box.	 The image shows the same dark, textured surface with a red bounding box around a defect. The label 'crazing 1.1' is visible in the top right corner of the bounding box.

从表 4-4 里面可以看出。改进后的模型在保持了原有检测能力的基础上，在（a）图的两组实验结果的对比里，增加了对于大片模糊地区的检测精度与能够额外识别出原先难以识别的夹杂缺陷，检测精度为 0.4。在轧入氧化皮缺陷上，受限于图像质量，模型很难给出能够看懂的结论，但是在同样识别精准度的前提下实现了更微面积有所提升的定位。在（c）与两组划痕缺陷的识别上，成功实现了对难识别部分的精准识别。在（d）图的斑点识别中，改进模型明显比前模型更加精确的检测出了两张不同钢板划痕缺陷面缺陷的识别效果。同样（e）图的麻面缺陷的识别中，改进模型比原模型提升了 0.1，而裂纹缺陷实现了从无到有的识别效果。

在以 YOLOv5s 为基础模型开展钢板表面检测模型改进研究的过程中，经实验探究发现，与 YOLOv5s 同属一个技术体系的 YOLOv8s 模型，在检测精度与稳定性方面表现更为优异。鉴于此，本问后续选择基于 YOLOv8 易于操作的特性，确定以 YOLOv8 系列模型作为检测模型改进的基础模型，旨在为宽厚钢板小缺陷表面检测提供更为精准、高效且便于部署的解决方案。

4.4 本章小结

本章对 YOLOv5 算法的进行了改进，更换轻量化的可变形卷积与改造空间金字塔池化机制，来保证检测的精度与速度等改进方法以减少计算开销。本章研究结果如下：

（1）出于节约检测与训练时间，节省计算资源的目的。本文使用 PP-LCNet 轻量化主干网络，DsConv 可移位卷积与三重注意力机制来补偿因为主干提取网络轻量化造成的检测平均精度损失。设计了 PP-LCYOLOv5s 轻量化检测网络。

（2）在 NEU-DET 公开钢板表面数据集上，本文为了验证自己所提出模型的有效性，针对此模型提出了一系列消融与对比试验，发现其检测平均精度在原模型 76.0%提升至 76.2%的微小提升上。成功将检测时间从 0.675h 减少至 0.594h 和将检测浮点数从 16.0GFLOPS 减少至 2.0GFLOPS。

（3）轻量化检测算法大大降低了模型对检测设备性能的要求。具有一定在工业化钢板表面检测场合使用的潜力。主要适用于对钢板的出厂快速检测与涉及钢板在生产现场的自动化维护中。为本文进一步研究热轧宽厚钢板的自动表面检测提供了基础。

(4) 尽管上述改进使得 YOLOv5 模型在检测效率和计算资源消耗方面得到了有效优化,且在轻量化条件下取得了一定的精度提升,但在处理复杂背景、小目标(如划痕)和多尺度缺陷时,模型仍存在鲁棒性不强、特征表达能力不足等问题。尤其在面对实际工业采集图像中高噪声、低对比度样本时,其性能提升较为有限。因此,后续第五章在 YOLOv8 更强特征提取能力的基础上,进一步引入 CPCA 注意力机制、SPPF 改进结构与开集识别模块,以提升模型在复杂实际场景下的检测能力和泛化性能。

第 5 章 基于 YOLOv8 模型的钢板检测模型

5.1 引言

在运用 YOLO 系列检测模型开展实验过程中,本文对比分析了自制钢板表面缺陷数据集与 NEU-DET 公共数据集,发现自制数据集存在缺陷类别分布不均衡、缺陷目标尺寸极小等实际问题。这些因素导致 YOLOv5 系列模型在应对小目标与少样本检测任务时表现出特征提取能力有限、检测精度不稳定等不足,尤其在划痕类微小缺陷的检测上性能存在瓶颈。

为此,本文在评估 YOLOv5s 等多种检测模型性能的基础上,选择了在结构设计、推理效率与小样本适应性方面表现更优的 YOLOv8 系列模型作为后续研究的基础框架。针对宽厚热轧钢板表面小缺陷的检测难点,进一步在 YOLOv8 基础上引入三项关键改进:一是融合 CPCA 注意力机制以增强目标特征聚焦能力;二是构建适用于小目标识别的轻量化主干网络;三是集成开放词汇检测模型 YOLO-WORLD,以提升对类别不确定目标的鲁棒性与泛化能力。下文将简要介绍 YOLOv8 系列模型的基本原理,并详细分析所提出三项改进措施的设计动机与实验效果。

5.2 YOLOv8 检测模型概述

2023 年,Ultralytics-LLC 公司的开创者 Glenn 在 GitHub 上对 YOLOv5 进行了二次创新,公开了基于 YOLOv5 代码设计的 YOLOv8 代码。相较于原来的 YOLOv5,作者希望集中诸如分割,姿态估计与分类等功能,所以他将新的 YOLOv8 命名为 Ultralytics 模型。其中还将 YOLOv9/rt-detr 进行了一定改进放入到了结构网络之中。从网络结构图 5-1 不难看出,YOLOv8 整体与 YOLOv5 保持了一致。但是将几个卷积(C3 全连接层更换为 C2f)进行了替换与去除(去除了两个卷积层)。直接使用上采样机制和熔接机制来直接将空间金字塔池化层与颈部相连接,缺少卷积消除了过度卷积造成的小目标特征丢失,但是也导致同深度宽度网络下浮点计算数的提升。

通过实验与阅读代码注释,对比网络图中少掉两个卷积对计算浮点数的影响。本文做出了 YOLOv5s 与 YOLOv8s 进行对比展示了两种相同宽度与深度网络的检测效果如表 5-1 所示。

表 5-1 YOLOv5s 与 YOLOv8s 的对比

模型种类	depth_multiple	width_multiple	GFLOPS
YOLOv5s	0.33	0.50	16.0
YOLOv8s	0.33	0.50	28.6

可以看出，在相同的深度和宽度配置下，V8 相较于 V5 的浮点运算量显著增加，从 16.0 GFLOPS 上升至 28.6 GFLOPS。然而，在实际检测过程中，本文发现该网络在检测精度与鲁棒性方面取得了更为显著的提升。




图 5-1 YOLOv8 网络结构图

其相较于 YOLOv5 主要改进如下面所示：

(1) 将 C3 模块修改成 C2f 模块，YOLOv8 参考了 C3 模块的残差结构以及 YOLOv 的 ELAN 思想，设计出了 C2f 结构。通过去除分支 Conv 卷积层，可以在保证轻量化的同时获得更加丰富的梯度流信息，并根据模型尺度来调整通道数，大幅提升了模型性能；可以看到，C2f 模块相比于 C3 模块有更多的跳层连接，并增加了额外的 split 操作，取消了分支中的卷积操作，这样丰富了梯度回传时的支流，加强了特征信息并减少计算量。其结构比较图如图 5-2 所示。




图 5-2 C3 与 C2f 网络结构图对比

(2) **Anchor-free 机制**: **anchor** 也叫做锚, 在检测时通过预先设置目标可能存在的大概位置, 然后再在这些预设边框的基础上进行精细化的调整。而它的本质就是为了解决标签分配的问题。目标检测领域的发展存在从 **anchor-free** 到 **anchor-base**, 现在又有回到 **anchor-free** 的趋势。这两种检测方法实际上是两种不同的目标检测方法, 区别在于是否使用预定义的 **anchor** 框来匹配真实的 **目标框**。下文简略说明了两者的区别: **Anchor-Based**: 在同一个像素点上, 生成多个不同大小和比例的候选框, 覆盖几乎所有位置和尺度, 每个参考框负责检测与其交叉比大于阈值 (训练预设值, 常用 0.5 或 0.7) 的目标, 然后通过 **anchor** 中有没有认识的目标和 **目标框** 偏离参考框的偏移量完成目标检测, 不再需要多尺度遍历滑窗, 极大地提升了检测速度。

在训练过程中, 模型学习预测每个锚框的偏移量 (相对于真实目标框的偏移), 以调整它们以更好地匹配目标的位置。模型还负责为每个锚框预测目标类别。通常, 在预测结束后, 采用 **NMS** 非极大值抑制来排除高度重叠的锚框, 以确保每个目标只有一个最终的检测结果。

Anchor-free 无锚框在构建模型时将其看作一个点, 即目标框的中心点。不依赖于预定义的锚框, 而是直接预测目标的中心点。直接学习目标框的位置, 通常通过

回归目标框的四个顶点坐标来实现。同样，模型负责为每个目标预测其类别，在预测结束后，采用 NMS 进行后处理。

优点：相对简洁，无需设计大量的锚框。更适合小目标检测。所以在实际钢板表面检测中本文选择了 Anchor-free 的 YOLOv8 作为基础检测模型以供后来分析与改进之用。

作为 YOLOv5 检测算法的完善与增强，YOLOv8 的改进方法本质上还是诸如基于变换 Neck 网络结构的改进，针对主干网络进行修改与使用注意力机制几类。关于损失函数的改进，经过大量实验与综合分析：CIoU 凭借在多种数据集上较好的鲁棒性与对检测精度有较大提升作用，被广泛用在 YOLOv5 的改进算法中以后成为 YOLOv8 的标准损失函数，其表达式如式(5-1)，(5-2)，(5-3)所示：

$$L_{CIoU} = 1 + \beta\zeta + \frac{\alpha^2(b_p, b_g)}{\eta^2} - IoU \quad (5-1)$$

式中 IoU ——是预测边界框和真实边界框的交并比；

β ——是一个权重因子，用于平衡不同损失项的影响；

ξ ——是用于衡量预测边界框和真实边界框中心点距离的项；

α ——是一个权重系数，用于平衡长宽比一致性的修正因子；

η ——是覆盖预测边界框和真实边界框的最小闭包区域的对角线长度；

b_p ——预测边界框；

b_g ——真实边界框。

$$\zeta = \left\{ \frac{2}{\pi} \left[\tan^{-1}\left(\frac{w_g}{h_g}\right) - \tan^{-1}\left(\frac{w_p}{h_p}\right) \right] \right\}^2 \quad (5-2)$$

式中 w_g 、 h_g ——真实边界框的宽度和高度；

w_p 、 h_p ——预测边界框的宽度和高度。

$$\beta = \frac{\xi}{1-IoU} \quad (5-3)$$

式中 IoU ——是预测边界框和真实边界框的交并比；

ξ ——是用于衡量预测边界框和真实边界框中心点距离的项。

为了优化宽高比对CIoU损失参数的影响,利用特殊算法得到最优预测。在YOLO框架下的目标检测中,总损失函数标注为是由检测—目标框坐标预测误差, IoU 误差与分类误差项组成,总损失函数可以记作公式(5-4):

$$\Delta_l = \Delta_{cor} + \Delta_{IoU} + \Delta_{cl} \quad (5-4)$$

式中 Δ_{cor} ——这部分通常表示预测边界框和真实边界框之间的相关性损失,可能

涉及到中心点距离或其他相关性度量;

Δ_{IoU} ——这部分表示交并比 (Intersection over Union, IoU) 损失,用于衡量

预测边界框和真实边界框的重叠程度。IoU 是目标检测中常用的评估指标,用于评估预测框与真实框的匹配程度;

Δ_{cl} ——这部分可能表示与分类相关的损失,例如交叉熵损失,用于衡量预测类别与真实类别之间的差异。

在使用初始版本YOLOv8s模型进行检测训练时,发现模型在检测dents特征表现良好,但是对于较细小,难以区分其种类的dents与scratches特征的检测精度相对较差,基于解决细小特征难以区别与难以提取检测两个问题,本文提出了基于YOLOv8s的改进方案。

5.3 基于YOLOv8的表面高精度检测改进算法

通过图5-3展示的最终结构可以看出针对YOLOv8基础模型主要包括使用红色进行框柱的以下三种改进方案:添加注意力机制,修改主干网络与使用强化融合网络。其基本上与第三章针对YOLOv5进行的改进在大致思路保持一致。但又使用了全新的方案,最后呈现出来的方案如图5-3所示。

通过大量前面阅读过的论文的调查,本文选择分别在注意力机制,监测并部网络与主干网络更替上进行发力。选择了以下三个方案:

(1) 设计改进SPPF+CPCA通道注意金字塔安装在主干网络末尾,提升模型对于所提取薄弱细小特征的筛选能力,将重要特征信息通过有线通道加权输入到下一环节网络,减少了网络对于无效信息的传输,将对于薄弱信息的提取精度进行提升,有助于为构建融合网络提供更多高价值特征信息。增强后面颈部特征融合网络的特征融合效率。

(2) 借助基于开集检测网络的颈部结构，通过带有池化层注意力机制反复池化，将特征轮廓更加清晰画出后，将其传递至多层激活注意的融合网络在多个融合环节中反复进行精炼以提高对于所融合的小目标难识别特征检测查全率与正确率，本文将开集监测网络融入 YOLOv8 检测网络中有效提升了模型对薄弱目标的检测精度与检测效率。

(3) 基于更换 GhostNet 轻量化卷积的混合主干网络来代替原有模型中的传统卷积层。GhostNet 巧妙通过对卷积注意较小的核，将较大图像使用两个并联小核进行卷积处理，较好保留难于提取的小目标特征后再进行提取压缩，不仅减少了运算量，还通过减少无用的特征传递提高了小目标的检测精度。




图 5-3 改进 YOLOv8 网络结构图

5.3.1 CPCA 注意与改进 SPPF 融合

注意力机制作为深度学习中一种极为重要的数据处理方法，在模拟人类感知系统处理信息时可以选择性学习与权衡不同输入的重要性并为不同的信息分配不同的

权重实现独一无二有用信息的强效提取。本文设计了一种结合空间金字塔结构与通道优先注意 CPCA^[88]进行融合模块，其结构图如 5-4 所示。




图 5-4 CPCA 注意力与改进 SPPF 空间金字塔结构图

从图 5-4 中可以看出，这个模块主要分为两部分组成：前段空间金字塔结构，负责对提取的特征进行最大边缘池化，生成较为明显的边界轮廓。在生成较为精确的轮廓数据后。在空间金字塔中我们用 Mish 激活函数代替传统的 SILU 激活函数能够提升模块对于小目标的提取能力。同时减少运算参数量与浮点计算数。极而增大运算速度。后端就是我们所引入的通道优先注意力机制——CPCA 注意力机制，主要用于对目标进行强化的特征纹路信息进行筛选识别。这个注意力机制模块主要有空间金字塔池化，sigmoid 激活函数与单行多列向量与多行单列向量的深度智能卷积等组成。

在将数据传递至通道注意模块，该模块通过探索特征中存在的通道间关系来实现这一目标。采用 CBAM 中提出的方法，采用平均池化和最大池化操作，从特征图中聚合空间信息。此聚合过程产生两个独立的空间上下文描述符。这些描述符随后被输入到一个共享的多层感知器（MLP）中。通过元素求和，将共享 MLP 的输出组合在一起，得到频道示意图。为了减少参数开销，共享 MLP 由单个隐藏层组成，其

中隐藏激活的大小设置为 $RC/R \times 1 \times 1$ ，其中 R 表示缩减比。通道注意力的计算可以概括为公式(5-5)：

$$CA(F) = \sigma(MLP(AvgPool(F)) + MLP(MaxPool(F))) \quad (5-5)$$

式中 $Avgpool(F)$ ——表示对输入 F 进行平均池化 (Average Pooling) 操作；

$Maxpool(F)$ ——表示对输入 F 进行最大池化 (Max Pooling) 操作；

MLP ——表示多层感知机 (Multi-Layer Perceptron)，是一种神经网络结构，用于对池化后的特征进行进一步处理；

σ ——通常表示激活函数，如 sigmoid 函数，用于引入非线性。

本模块在通道注意力机制之后，借助深度卷积模块来构建空间注意力机制，并对每个空间注意图进行融合，将通道注意与空间注意相结合，使得通道注意能够在通道与空间维度上动态分布形成了先验卷积注意。公式(5-5)说明了利用深度卷积与池化来捕获特征之间的空间关系，确保保留通道间关系，同时降低计算复杂性。采用多尺度结构增强卷积运算捕捉空间关系的能力。通道混合由空间注意模块的尾部使用 1×1 卷积进行，从而生成更精细的注意图。后端空间注意力的描述可以使用公式(5-6)表示。

$$SA(F) = Conv1 \times 1 \ X3 \ i=0 \ Branchi \ DwConv F \quad (5-6)$$

式中 $DwConv(F)$ ——表示对输入 F 进行深度可分离卷积 (Depthwise Convolution)

操作，这是一种高效的卷积操作，它将标准卷积分解为深度卷积和逐点卷积两部分；

$Branchi$ ——表示一个分支函数或操作，它可能是一个特定的网络结构或算法的一部分；

$Conv1 \times 1$ ——表示 1×1 卷积操作，这是一种卷积操作，其中卷积核的尺寸为 1×1 ，通常用于改变特征图的通道数；

$X3$ ——表示一个重复三次的操作。

在通过使用深度卷积所提出的通道先验注意机制在保证较低的计算复杂度的同时，成功地增强了网络的自适应能力，从而使其易于与其他网络集成。实现在算力开销可忽略情况下的良好检测结果。从而能够在学习时廉价捕获精细的特征信息。本文将此金字塔机制替换了原本的单纯奎宿空间金字塔池化机制，以对主干网络所

提取出来的信息进行强化抽取，增加融合网络对有用信息的吸收量。从而有效提高网络对于精细表面缺陷特征的提取效率。

5.3.2 Ultralytics YOLO-WORLD 开放检测网络

2024 年时，腾讯团队在集中于固定语汇检测的网络上进行了有效延伸，设计了负责检查固定词汇之外对象的网络-YOLO-WORLD^[82]。这种网络使用 DarkNet 骨干网络作为图像编码器，通过一个多尺度特征金字塔的路径聚合网络 PAN，以及一个用于边界盒回归和对象嵌入的头部。

其整体结构如图所示，主要分为 YOLO 检测器，文本与图像编码器与可重参数的视觉语言路径聚合网络组成（RepVL-PAN），利用图像特征与文本嵌入之间的跨模态语言融合来增强文本与图像的表达。为提供更好的视觉语义功能，作者使用简单的，本文采用简单的 n-gram 算法提取名词短语，然后将其输入文本编码器。文本对比开头。根据之前的工作，本文采用解耦头部和两个 3×3 卷积回归边界框 $\{b_k\}_{K \times K=1}$ 和对象嵌入 $\{e_k\}_{K \times K=1}$ ，其中 K 表示对象的数量。本文提出了一个文本对比头，通过以下方法获得对象—文本相似度 sk, j ，公式描述如(5-7)：

$$sk, j = \alpha \cdot L2-Norm(e_k) \cdot L2-Norm(w_j)^T + \beta \quad (5-7)$$

式中 $L2Norm$ ——表示 $L2$ 范数，也称为欧几里得范数，用于计算向量的长度或大小。在这里，它被用于规范化向量 e_k 和 w_j ；

α, β ——权重参数，用于调整相似度计算中各部分的贡献；

sk, j ——表示第 sk 个对象与第 j 个文本之间的相似度；

e_k ——表示与第 k 个对象相关的特征向量；

w_j ——表示与第 j 个文本相关的特征向量；

此外，本文还加入了具有可学习缩放因子 α 和移位因子 β 的仿射变换。 $L2$ 范数和仿射变换对于稳定区域文本训练都很重要。在训练过程中，本文为每个包含 4 张图像的 mosaic 样本构建出了在线词汇集 T 。同时在推理阶段本文会着重使用离线词汇的提示—检测策略。其网络结构如图 5-5 所示： $C3$ 、 $C4$ 、 $C5$ 表示从不同尺寸输入的图像信息， $R3$ ， $R4$ ， $R5$ 表示以不同尺寸形式输出的图像信息。其中下标符号代表输入图像尺寸的 $1/2$ 次方数，与 PAFPN 很相似。

通过图 5-5 可以清晰看出，在传统融合机制的基础上设计出了 T-CspLayer 传递融合层，将文本机制引入到 CSP-Layer 中形成了文本引导的 CSP-Layer 中，在一定程度上提高了难识别小目标检测的效率。




图 5-5 YOLO-world 开集词汇检测网络逻辑结构图

T-CSPLayer 的结构如下图 5-6 所示。




图 5-6 T-CSPLayer 结构图

在图 5-6 中后方所加的 T-CSPLayer 结构图可以发现，在 Bottleneck 后面增加 Sigmoid 激活注意力机制有效增强了模型对文本与图像融合有效信息的效能。同时通过检出超出预定义类别的对象用于检测难以辨识的特征。有效提高了泛化能力，同时有效避免了使用传统开放词汇检测中重型探测器对算力成本的要求，实现了开机目标的高精度，低成本检测。

此外开集词汇检测网络在传统的 PAFPN 网络结构的基础上嵌入了一种 ImagePoolingAttention 机制，为了图像感知信息增强文本嵌入，图像池关注被用于聚

合图像特征来更新文本嵌入。设计者不是直接在图像特征上使用交叉灌注，而是利用多尺度特征上的最大池化来获得 3×3 区域，从而得到总共 27 个补丁集 $X \approx \in \mathbb{R}^{27 \times D}$ 。然后通过以下式(5-8)更新文本嵌入：

$$W' = W + \text{MultiHead-Attention}(W, X, X) \quad (5-8)$$

式中 W' ——经过多头注意力机制处理后的输出权重矩阵或特征矩阵；

W ——输入的权重矩阵或特征矩阵。

这里面的 Multihead-Attention 表示多头注意力机制的函数，它接受三个参数： W 、 X 和 X 。在这个上下文中， X 可能表示查询（query）、键（key）和值（value）向量，它们通常在注意力机制中使用。由于 X 出现了两次，这可能意味着在这个特定的应用中，查询、键和值都是相同的输入。这里设计者使用的注意力机制为 MHCA 文本注意力机制，这种多头卷积注意力机制能够对多个维度的特征进行提取，从而提高后面检测的精度与效率。

本文中本文利用开集检测网络在融合未知目标上的优势，在原有的 PAFPN 网络结构的基础上嵌入了 Imagepooling-Attention 池化融合机制以提高图像特征的结合度，提高了检测效率并有效融合了主干网络在不同阶段获得的薄弱特征。在通过网络结构中的 T-CSPLayer 对每一步进行注意，设计出了在融合阶段进行强注意的网络，提高了检测头的学习效率。

5.3.3 可变形卷积 Ghost Convolution

GhostNet^[89]是一种轻量级深度学习网络框架，它主要通过简单的运算来提取特征，旨在减少模型的复杂性和计算成本，同时保持良好的性能。GhostNet 的核心思想是“通过更简单的运算提取特征”。它采用了“Ghost 模块”，该模块通过简单的线性变换来生成更多的特征图，从而以较小的计算代价增加模型的特征提取能力。在 Ghost 模块中，首先通过常规的卷积操作生成一部分特征图，然后通过简单的线性操作（如 1×1 的卷积或分组卷积）来生成更多的“幻影”特征图。这些幻影特征图与原始特征图拼接起来，增加了模型的特征数量，同时保持了较低的计算复杂度。

GhostNet 由多个 Ghost 模块堆叠而成，形成了类似于 ResNet 中的残差结构的 Ghost bottleneck。这种结构有助于模型在保持性能的同时降低计算量。GhostNet 特

别适合于资源有限的设备上图像识别任务，如移动设备、边缘计算和自动驾驶等领域。由于其轻量级和高效的特点，它可以在这些设备上实现快速的推理和响应。其性能优势主要体现在三个方面。高效：GhostNet 的设计理念在于最大化性能与硬件限制之间的平衡，使得模型能够在低端设备上快速运行。通过实验验证，GhostNet 在保持高性能的同时，显著降低了模型的计算复杂度和参数量。轻量：相比于其他复杂的深度学习模型，GhostNet 的参数量更少，节省存储空间。这使得它更适合在资源受限的环境中部署和应用。两种卷积结构分别由图 5-7 与图 5-8 所示。




图 5-7 GhostConv 分层卷积示意图




图 5-8 Conv 卷积示意图

整体而言，GhostNet 是一款高效、轻便、易于执行的深度学习模型。它通过简单的运算提取特征，降低了模型的复杂性和计算成本，同时保持良好的性能。这使得它在资源受限的环境中具有广泛的应用。基于 GhostNet 的以下优势，Ultralytics 团队在之前的改进研究基础上，将可变形轻量卷积 GhostConvolution 进行了轻量的卷积操作，通过两个卷积层的结合。它提供了一个新的 Ghost 模块，目的是通过廉价的操作产生更多的特征图。以一组原始特征图为基础，应用一系列线性变换，以极小的计算量生成许多“魔鬼”的特征图（Ghostfeaturemaps），可以从原始特征中发掘出所需的信息。该模块具有即插即用的特性，通过堆叠 Ghost 模块得到

Ghost-Bottleneck，然后构建一个轻量级的神经网络 GhostNet。其主要功能是利用模组将原本的卷积层一分为二，先利用较少的卷积层生成原本的特征图，再进一步利用廉价的转换操作，高效制作出更多的 Magic 特征图，同时保持模型的轻量化。在基准模型和数据集上所做的实验显示，这种方法是一种即插即用的模块，可以在保持可观性能的同时，将原模型转化为一种更精巧的模型。网络也会进一步增强自己的感知和表达能力。

借助图 5-8 可以解释出其具体原理，首先一个卷积层按照输入通道数拆分为两部分：第一部分输入输出通道为 c_1 与 $c_2/2$ ，第二层输入输出通道均为 $c_2/2$ 。这里通过先将数据使用首层通道进行处理，然后一部分使用第二层通道处理，另一部分直接使用 Concat 熔接机制直接将其合并为一体，这就成为 Ghost-Convolution 函数，这个函数因为其对计算成本的低要求与较好的小目标检测能力，成为最新版本 Ultralytics-YOLOv8 上的标准化配置被直接投入应用。为了解释其结构，在附录 C 中描述了其伪代码形式。

通过伪代码可以看出来：通过两个小尺寸的卷积进行分块拼接来融合成为一个大尺寸卷积可以有助于减少计算成本。最初使用目的是提升计算速度。但是在本文使用小目标数据集进行试验时发现：通过小尺寸的卷积进行分块拼接可以有效减少模型对无用大区域特征的提取，减少了再进行卷积处理中细小目标特征和特征丢失的概率。这种检测网络在检测小目标，难以识别特征时，因为其对少量目标检测增强效果的提升能力，成为进行小目标改进的经典强化方法。下一章节主要讲述实验条件与相关设备选型以及对照迁移实验的结果。

5.4 实验条件与设备

5.4.1 实验数据集的分析

在分析图像数据的过程中，发现所收集的数据与 NEU-DET 存在很大不同，在公开数据集上为了便于比较与表示出表面缺陷的具体形貌，通常采用较近距离拍摄并进行标记，但是在实际钢板表面缺陷数据的采集中，由于摄像头距离钢板表面相对较远，使得所收集的缺陷往往过于微小纤细。这种微小目标的检测精度提升方法可能与较大目标的检测模型存在一定出入。在实际进行检测中，考虑到图片像素尺寸，目标特征大小与检测的速度，一般性质的图像输入大小通常限定在 640×640 但是涉

及大图像小目标时,这种输入尺寸可能会造成图像过压缩导致小目标特征丢失继而使检测精度极大下降,在调整输入尺寸时,本文要对数据集进行综合分析来防止因为中间参数调整导致的一些问题。通过改变输入图像数据尺寸可以发现,在1280*1280的规格下,基线模型可以满足安全性,精度和平均精度这三项的平衡,为后继深入研究奠定了良好基础。为给出更好的学习效果,研究借鉴了国际上常见的数据集分类技术,将数据按训练集,验证,测试集等按比例分类为8:1:1。

5.4.2 实验设备的选取与搭建

为了满足深度学习网络对于计算能力的庞大需求,本文设计一套基于Pytorch 3.8/3.9, CUDA12.3 环境与 Windows10 系统的实验平台。使用 13th-i5-13490 CPU 与 32GBDDR 内存以配合其进行运算训练。

为了训练更加先进,性能更强的YOLOv8模型,运算所用服务器升级为NVIDIA Geforce RTX 4080。为了达到最好的训练效果。基于钢板表面质量的严格要求本次实验中IoU阈值设为0.70,训练的具体参数表如表5-3所示。表中呈现了参数种类没学习率,优化器,衰减策略,输入图像尺寸等指标。

表 5-3 YOLOv8 训练超参数表

参数种类	学习率	衰减策略	优化器	动量	权重衰减	Mosaic 增强	输入图像 尺寸
参数值	0.01	Cosine	SGD	0.937	5e-4	10	1280*1280

本文借鉴国内外常用的训练方法,选择使用随机梯度下降进行优化。训练次数选用200轮。权重衰减参数设为0.0005,学习率设为0.01。表5-3中的输入图像尺寸是由公式(3-6)进行计算而得,为1280。下面是基于此实验条件与参数所得到的一系列结果。

5.5 实验结果

为验证本文所提出模型的有效性,本文进行了一系列消融实验并收集了在本数据集上使用的各个模型的实验数据。实验结果分为消融实验结果,对比实验结果两部分,消融实验解释了模型各部分改进的优点与改进效果,对比实验通过对所有先进检测模型的对比说明本改进模型的价值。

5.5.1 基于CPCA注意与改进SPPF融合的实验结果

在之前的实验中使用了两种加载方式，一种是在检测模型 Backbone 部分的主干网络前两个 C2f 层前面添加两个 CPCA^[88]注意力机制，另一种是在特征提取结束以后结合使用 CPCA 注意力+改进 SPPF 金字塔机制来进行信息强化提炼，使得能够直接使用经过提取的信息进行注意。这里发现使用第二种方法能够有效减少计算成本，受限于本文篇幅，这里本文将直接列举基于改进 SPPF+CPCA 注意金字塔机制的改进实验结果。并在本章节分别显示了原始模型与采取了改进 SPPF 与 CPCA 金字塔融合机制两种情况下的检测结果。

经过测试得知，通过计算机绘制的 P-R 图线 5-9 与 5-10 可以发现，在改进 SPPF+CPCA 以后，平均检测精度从原先的 67.8%上升到了现有的 68.6%，但是在 YOLOv8n 网络中可以将其上升从 62.7%上升至 63.1%。图 5-9 呈现了基础模型的训练结果。

图 5-10 呈现了添加了 CPCA 注意力与改进 SPPF 金字塔机制的训练结果。证明了在同等条件下，YOLOv8s 网络中是可以使用改进 SPPF+CPCA 通道有限注意力机制已取得较好的表面检测效果。在特征量较多的压坑与特征量较少的划痕中都取得了一定的检测精度提升。




图 5-9 未采用 CPCA 注意力与改进 SPPF 金字塔机制（基础 YOLOV8 模型）的训练效果




图 5-10 采用 CPCA 注意力与改进 SPPF 金字塔机制（YOLOv8 模型）的训练效果

此外，通过改进 SPPF 与 CPCA 通道优先注意同时有效增加了查全率（从 64.8% 扩充到了 65.9%）同时避免了高查全率导致精度可能出现下降的问题。特别是在数据样本不均衡且纹理特征细小而被有明确缺陷归类的数据集里，这中情况较为严重，而这正是工业实际钢板表面数据集缺陷的主要特征。需要通过模型网络改进与数据集的进一步收集来解决此问题。

5.5.2 基于 YOLO-WORLD 改进网络的实验结果

YOLO-WORLD 网络是一种借助开放词汇检测的专业工具，目前本文在使用的一种改进 Neck 特征融合网络，相较于传统需要定义图像类别的 YOLO 系列而言，其在难以检测识别且可见度差的工业实际钢板小目标检测上。取得了更高的效率与性能。其自带的离线词汇推理功能，与模型引入了“先提示后检测”策略，利用离线词汇嵌入简化检测过程提高了表面检测效率。基于 YOLO-WORLD 网络这些优势，本文在进行验证训练时引入了此功能，取得的检测结果如图 5-11 所示。

图 5-11 的结果表明了这项改进成功将检测平均精度由 68.6% 进一步提升到了 69.2%，主要的提升还是在数量较多的压坑类缺陷上，再划痕类缺陷上的减出效果较少。




图 5-11 引入 YOLO-WORLD 开集网络的训练效果

开集检测网络提示后检测的思路有效提升了模型对小目标，少数量的缺陷的识别精度。将划痕缺陷的检测精度有 55.8%提升到了 56.7%，通过对弱标记数据类型的学习实现了平均精度的突破。

5.5.3 基于强化 GhostNet 的改进结果

GhostNet^[89]网络是一种专门用于低成本检测难以检测小目标的网络，经常被用于小型目标的检测效果之中，这次在参考 YOLOv8 系列与 YOLOv5 系列的论文进行的改进的前提下，发现了 GhostNet 结构中 GhostConv 在减少因传递无用信息带来的浮点数增加方面有较为明显的效果，并且通过使用小卷积的熔接实现了节省浮点运算数与计算资源的效果有效适应了大钢板图像表面小目标检测。

经过训练实验可以发现：在改进 SPPF 与 CPCA 通道优先注意、YOLO-WORLD 开集检测增强与 GhostNet 作用的基础上，成功实现了将基于 YOLOv8 的精度从 67.8% 提升至 72.7% 的优良效果，特别是通过轻量卷积来重点处理较少的划痕特征，将其检测平均精度从 54.7% 提升到了 62.9%，提升了 8.2% 的平均精度。而对于压坑类缺陷也实现了从 80.8% 提升到了 82.5%。能够使其胜任一般钢板表面初步检测的工程要求。这种提升不仅推动了平均检测精度的提升，更为较为薄弱的少样本小目标检测提供了一种具有一定可行性的解决方案。效果在图 5-12 的 P-R 曲线中展示。




图 5-12 最终改进的训练结果

在工程实际上需要参照数据特征类型来针对模型进行优化改进而非单纯参考他人论文中的改进方案。总而言之，使用 GhostNet 进行处理有助于强化模型对难识别，分辨率低且特征精细的小目标进行检测。通过三种不同改进方式—在主干网络中加入注意力机制，采用更优化的特征融合网络与采用高精细度的提取网络有效说明了通过高精细度提取网络 GhostNet 可以大幅提升针对细小难以识别权限的提取查全率，同时开集网络与注意力机制也会对数量较多的压坑（dents）检测精度效率进行一定的提升，但是从数据集的分析知道，在整个数据集中数量最为薄弱的压坑部分的检测查全率的提升，才是进行整体数据集检测精度有效提升的重难点所在。这些检测效果呈现在表 5-4 中，展示了所有改进模型消融实验的对比。我们将本文改进模型称为 G-YOLOv8s。

表 5-4 不同 YOLOv8s 模型的 P-R 消融实验数据对比

模型种类	AP(d.)	AP(scr.)	P(d.)	R(d.)	P(scr.)	R(scr.)	mAP@50
YOLOv8s	0.808	0.547	0.756	0.778	0.639	0.518	0.678
+改进 SPPF 与 CPCA	0.814	0.558	0.773	0.779	0.557	0.539	0.686
+开集网络	0.817	0.567	0.833	0.696	0.685	0.504	0.692
G-YOLOv8s	0.825	0.629	0.804	0.751	0.605	0.607	0.727

结果显示,从表 5-4 中可以得知,使用高精细度的 GhostNet 就是能够有效提升对薄弱划痕缺陷提取效率提升的关键(将检测划痕类缺陷的效率从 54.7%直接提升很大的比例至 62.9%,同时查全率大幅提高从 51.8%提升至 60.7%),而另外两项改进方式也有效保证了对于数目较多的缺陷种类测量检测准确度的稳定提升(从 75.6%上升至 83.3%)。这说明单纯通过注意力机制与融合网络只能提升数量较多的压坑类缺陷的检测效率。这有效促进了两种缺陷因为样本种类不平衡导致的检测平均精度难以上升的问题。

5.5.4 结果分析

为了展示训练过程中损失的衰减和精度的提升规律,本文引入了损失与平均精度(mAP)随训练迭代变化的曲线图。这些曲线图清晰地展示了在训练过程中,损失值逐渐减小而平均精度逐渐提高的趋势。图 5-13 显示了模型在训练损失曲线与平均精度的变化。

在模型训练的初始阶段学习率很高,前 50 个 epoch 的损失曲线迅速下降。随着迭代的进行,损失曲线逐渐变慢,在 100 次左右收敛,损失值在 0.9-1.0 左右波动,模型达到稳定状态。同样,mAP(mAP@0.5/mAP@50)在前 100 个时期迅速增加,然后逐渐趋于平缓,在 72%左右波动。




图 5-13 训练过程参数变化曲线

但是精测平均精度图线在波动时并非一直为平缓上升趋势,而是在训练时出现小幅下降,可能是中间出现过拟合或这未知的技术原因导致。但是随着损失下降,总

体精度呈上升状态。经此本文所提出优化模型的 AP (dents) 的 AP (scratches) 分别为 82.5% 与 62.9%，比优化前的 YOLOv8s 分别提高了 1.10% 和 7.10%，而参数数量仅提升了 2M，FLOPs 和检测时间略有增加。综上所述，本文对 YOLOv8s 进行了各种优化，提高了检测冷轧宽厚钢板表面缺陷的准确性，特别是对微小划痕缺陷的识别。特别是对划痕 (scratches) 与压坑 (dents) 的 P 精度，R 查全率均进行了较大程度的提升。

实际场景中对于数量较少的缺陷需要使用特定的提取网络以提升检测的查全率以增加模型的实际数据学习量。在数量较多，单纯靠查全难以对缺陷数量进行有效提升则需要使用更强的注意力机制与特征融合来提高对数量较多缺陷地检测效果。改进高精度提取主干网络对小样本缺陷的提取能力。对于细小划痕缺陷的检测，就是使用 GhostNet 插入到主干 backbone 提取网络中进行优化的，实现了划痕缺陷查全率从 51.8% 上升至 60.7% 的巨大飞跃。下图 5-14 通过热力图的形式呈现了原模型与改进模型对各个部分的检测与训练效果与计算资源消耗情况。




图 5-14 基础模型与改进模型检测热力图对比

通过检测热力图 5-14 可以发现：对于同样的四张图像，a1 图像中基础模型只能达到 0.26 与 0.73 的检测准确度，但是在进行加强后准确度可以达到 0.41 与 0.74。在 b2 图像中未能检测出的压坑缺陷可以检测出来，对于 c，d 图中的划痕缺陷，基础模

型只能进行模糊的大范围定位，但是改进后的模型不仅能进行定位，还能够将图像中的划痕缺陷进行分辨找出。通过检测热力图的对比可以体现了本改进模型的有效性。

5.5.5 对比试验

为了证明本文所提出方法的有效性与使用价值，本文选用了较为常用的一系列对比试验的使用模型。经过一系列对比实验发现对比得到的实验结果如图 5-15 所示。

```
YOLOv5s summary: 157 layers, 7015519 parameters, 0 gradients, 15.8 GFLOPs
      Class      Images  Instances      P      R      mAP50  mAP50-95: 100%| 21/21 [00:02<00:00, 7.08it/s]
      all         324      1214      0.637    0.625    0.612    0.258
      dents       324      1158      0.687    0.843    0.827    0.345
      scratches   324        56      0.588    0.408    0.398    0.172
Results saved to runs\train\exp8
```

(a)YOLOv5s 的原始训练结果

```
YOLOv8s summary (fused): 168 layers, 11126358 parameters, 0 gradients, 28.4 GFLOPs
      Class      Images  Instances  Box(P      R      mAP50  mAP50-95): 100%| 21/21 [00:02<00:00, 8.78it/s]
      all         324      1214      0.698    0.648    0.678    0.29
      dents       324      1158      0.756    0.778    0.808    0.355
      scratches   324        56      0.639    0.518    0.547    0.226
Speed: 0.3ms preprocess, 2.9ms inference, 0.0ms loss, 0.7ms postprocess per image
FPS:257.27
```

(b)YOLOv8s 的原始训练结果

```
YOLOv8n summary (fused): 168 layers, 3006038 parameters, 0 gradients, 8.1 GFLOPs
      Class      Images  Instances  Box(P      R      mAP50  mAP50-95): 100%| 21/21 [00:01<00:00, 11.05it/s]
      all         324      1214      0.582    0.628    0.627    0.267
      dents       324      1158      0.717    0.809    0.814    0.356
      scratches   324        56      0.447    0.447    0.44    0.178
Speed: 0.4ms preprocess, 1.2ms inference, 0.0ms loss, 0.7ms postprocess per image
FPS:452.74
```

(c)YOLOv8n 的原始训练结果

```
YOLOv11s summary (fused): 238 layers, 9,413,574 parameters, 0 gradients, 21.3 GFLOPs
      Class      Images  Instances  Box(P      R      mAP50  mAP50-95): 100%| 21/21 [00:02<00:00, 8.01it/s]
      all         324      1214      0.708    0.651    0.699    0.288
      dents       313      1158      0.794    0.767    0.826    0.349
      scratches   32        56      0.622    0.536    0.571    0.226
Speed: 1.0ms preprocess, 3.1ms inference, 0.0ms loss, 0.7ms postprocess per image
Results saved to runs\train\exp12
```

(d)YOLOv11s 的原始训练结果

```
YOLOv8s-worlda21 summary: 246 layers, 13061800 parameters, 0 gradients, 35.9 GFLOPs
      Class      Images  Instances  Box(P      R      mAP50  mAP50-95): 100%| 21/21 [00:02<00:00, 8.36it/s]
      all         324      1214      0.705    0.679    0.727    0.307
      dents       324      1158      0.804    0.751    0.825    0.367
      scratches   324        56      0.605    0.607    0.629    0.248
Speed: 0.3ms preprocess, 3.6ms inference, 0.0ms loss, 1.5ms postprocess per image
FPS:184.14
```

(e)改进方法的原始训练结果

图 5-15 原始训练结果数据

基于图 5-15 中的五个图我们制作了对比表 5-5，展示了不同模型的对比实验，通过表 5-5 可以看出，本文所提出的 G-YOLOv8s 比起最先进的 YOLOv11s 检测模型，划痕类缺陷检测精度从 62.2%提升到了 62.9%，总体的检测精度从 69.9%升到了 72.7%。证明本文所提出的模型 G-YOLOv8s 的优越性。

表 5-5 多种不同模型的对比实验结果

模型名称	AP(d.)/%	AP(scr.)/%	mAP@50/%	GFLOPS	FPS	Parameters(M)
YOLOv5s	81.7	39.8	61.2	16.0	135.65	7.02
YOLOv8n	81.8	44.7	62.7	8.2	452.76	3.75
YOLOv8s	80.4	55.8	67.8	28.5	240.99	11.12
YOLOv11s	79.4	62.2	69.9	21.3	201.16	9.41
G-YOLOv8s	82.5	62.9	72.7	35.6	184.14	13.07

在计算参数量由 11.12M 上升至 13.07M 与浮点数运算量直接从 28.6 GFLOPS 提高至 35.6 GFLOPS 的背景下本文所提出的模型有效针对薄弱的划痕检测特征进行推理训练，成功将总体检测平均精度从 68%左右提升到 72.7%，而划痕缺陷类的识别上精度从 55.8%提升到了 62.9%，本文选择了 4 张以展示其检测效果如图 5-16 所示。




图 5-16 钢板表面最终检测效果与放大效果图

图 5-16 中第一行 a 图是检测出的压坑, b 图是检测出的划痕, c 图是检测出的划痕与压坑混合缺陷, d 图是检测出多个密集压坑缺陷; 下一行的 a 为压坑放大图, b 为划痕放大图, c 为划痕压坑放大图, d 多个密集压坑缺陷放大图, 以供细致观察模型对缺陷的检测推理效果。为了便于观察缺陷种类, 图使用了 1000mm 与 1mm 两种不同的比例尺来展现, 以看出模型在全局图像数据下的检测效果与对未知类型缺陷推理效果。

通过 5-16 所示的推理检测效果, 可以确认我们改进的模型能够满足在本文设计的工业生产实际场景下的二维表面检测用途, 从而为工业实际场景下的应用提供参考。本文所制作的检测模型在密集图像检测上还是可能会出现遗漏现象, 但是具有满足工业实际应用场景进行推理的能力。对于实际生产中存在的划痕与压坑混合检测也具有较好的区分度。

5.5.6 鲁棒性验证实验

检测模型在面对模型所检测的对象参数产生变化时, 能够保持其性能稳定并产生可靠输出的能力本文称为鲁棒性 (Robustness)。为了验证所提出模型在钢板检测领域的泛化性与稳定性, 本文在 NEU-DETA 上进行了改进模型的鲁棒性实验。实验结果如图 5-17 分别展示了原模型与改进模型的鲁棒性检测效果。

YOLOv8s summary: 181 layers, 11129058 parameters, 0 gradients, 28.5 GFLOPs

Class	Images	Instances	Box(P)	R	mAP50	mAP50-95)
all	180	423	0.745	0.731	0.786	0.465
crazing	180	77	0.63	0.299	0.461	0.175
inclusion	180	96	0.696	0.792	0.793	0.422
patches	180	90	0.866	0.937	0.967	0.655
pitted_surface	180	52	0.784	0.75	0.848	0.53
rolled-in_scale	180	52	0.689	0.681	0.728	0.416
scratches	180	56	0.806	0.929	0.917	0.591

Speed: 0.1ms preprocess, 1.1ms inference, 0.0ms loss, 0.8ms postprocess per image
FPS:491.84

(a)NEU-DET 上原模型的训练结果

YOLOv8s-worlda21 summary: 246 layers, 13061800 parameters, 0 gradients, 37.7 GFLOPs

Class	Images	Instances	Box(P)	R	mAP50	mAP50-95)
all	180	423	0.731	0.764	0.795	0.467
crazing	180	77	0.462	0.364	0.409	0.153
inclusion	180	96	0.634	0.793	0.77	0.393
patches	180	90	0.876	0.943	0.965	0.65
pitted_surface	180	52	0.953	0.788	0.896	0.567
rolled-in_scale	180	52	0.678	0.769	0.783	0.408
scratches	180	56	0.784	0.929	0.951	0.633

Speed: 0.2ms preprocess, 1.4ms inference, 0.0ms loss, 0.8ms postprocess per image
FPS:418.89

(b)NEU-DET 数据集在改进模型上的训练效果

5-17 鲁棒性实验效果

图 5-17 中对照实验中，原模型与改进模型分别实现了 78.6%与 79.5%的平均检测精度，说明了改进模型对 NEU-DET 数据集的检测能力是有所提升的。在表 5-6 中本文将本文提出的改进检测模型在 NEU-DET 上检测效果与第四章中所提出的 PP-LCYOLOv5s，YOLOv5s 模型和 YOLOv8s 基础模型进行了对比。

表 5-6 NEU-DET 数据集的对比实验结果

使用模型	Cr	In	Pa	Rs	Sc	Ps	mAP	P	R	GFL OPS
YOLOv5s	0.411	0.725	0.961	0.838	0.746	0.882	0.760	0.676	0.754	16.0
PP-LCYOL -Ov5s	0.393	0.753	0.96	0.823	0.722	0.923	0.762	0.745	0.718	1.8
YOLOv8s	0.461	0.793	0.967	0.848	0.728	0.917	0.786	0.745	0.731	28.6
G-YOLOv8s	0.409	0.77	0.965	0.896	0.783	0.951	0.795	0.731	0.764	37.9

从表 5-6 能够看出改进的 YOLOv8s 模型在最重要的 mAP 指标上均有较大程度的提高，但是单纯的数据对比表很难看出所改进的 G-YOLOv8s 检测模型的直观效果为直观展现效果本文选取了一些较为直观的训练结果如表 5-7 所示。

表 5-7 NEU-DET 数据集的实验图对比

























	YOLOv5s 模型的检测效果	改进 YOLOv5s 模型的检测效果	YOLOv8s 模型的检测效果	改进 YOLOv8s 模型的检测效果
斑点缺陷				
轧入氧化皮缺陷				

表 5-7 (续)

	YOLOv5s 模型的检测效果	改进 YOLOv5s 模型的检测效果	YOLOv8s 模型的检测效果	改进 YOLOv8s 模型的检测效果
划痕缺陷				
麻面缺陷				
夹杂缺陷				
裂纹缺陷				

从表 5-7 里面可以看出。改进后的模型在保持了原有精度的基础上，本模型在(a)图的左数两组关于 YOLOv5s 实验结果的对比里，增加了对于大片模糊地区的检测精度与能够额外识别出原先难以识别的夹杂缺陷。而右侧两列基于 YOLOv8s 模型的检测结果中，可以发现对于斑点缺陷的识别准确度相较于基于 YOLOv5s 的模型有了大幅提升，在最右端的改进 YOLOv8s 检测结果中，斑点的识别精度更是达到了惊人的 0.9。在 (b) 与 (e) 图中轧入氧化皮缺陷图像上，基于 YOLOv8s 的模型实现了更高

精度与更加广谱的检测效果，检测识别的准确度从 0.4 上升到了 0.7，并且检测面积也有了大幅提高。在（c）四组划痕缺陷的识别上，更是成功实现了对难识别部分的精准识别。在（d）图的斑点与麻面识别中，该基础模型明显比前面的基础模型更加精确的划分出了两个面缺陷的识别效果。而在最难识别的裂纹缺陷识别中取得了真正的定量突破。即识别精度成功达到了 0.4。

5.6 操作界面简介

GUI（Graphical User Interface，图形用户界面）界面的优势主要体现在以下几个方面：通过图形、图标、按钮和菜单等基本组件来展示信息和操作选项，用户可以直观地看到这些元素，无需记忆复杂的命令直观易用，用户可以使用鼠标、键盘、触摸屏等设备与界面进行直接交互，实现操作、输入和反馈。实现对用户体验的全方位提升，其软件界面如图 5-18 所示。



图 5-18 推理数据集 GUI 界面

为了避免输入复杂的权重指令，我们可以将训练权重指令单独保存在桌面或者便于保存的地方。设计了一个自己选择并配合 Window 可视化界面的推理 GUI 界面，界面内容包括选择模型，选择输入结果与输出结果以及进行训练可以选择保存推理的提醒他标签数据集。在有 GUI 的环境中更易于管理和操作，图形界面的配置和管理对于不熟悉命令行的使用者来说更为直观。也有效较低了一线操作者对计算机系统的使用门槛，实现了更高的作业效率与更好的作业上手度。

5.7 本章小结

本章展示了基于改进的 G-YOLOv8s 模型的钢板表面缺陷检测算法的结果。我们通过与原始网络以及其他当前主流网络进行全面的性能指标对比，提供了多角度的实验评估数据。这些数据有助于全面了解改进模型的性能：

（1）通过使用轻量化卷积 GhostConv 针对细微特征进行强提取，有效借助轻量卷积去除不必要的无用特征。保留重要信息，使得其能够减少部分参数的前提下获得大量有用信息。同时设计了 CPCA 注意力+改进 SPPF 金字塔机制与的融合改进。

（2）本文对改进后的算法的检测效果进行了深入分析，通过结果对比发现本文的模型在保证检测速度的基础上将总体检测精度从原来 YOLOv8s 的基础上从 67.8% 提升到了 72.7%。特别检测是在样本稀缺（只有 600 个），可见度极低与极为薄弱的划痕类缺陷，直接将检测精度从 55.8% 直接提升至 62.9%。

（3）为验证本文提出模型的先进性，在自制数据集的上将本模型与 YOLOv5s，基础 YOLOv8s 模型，YOLOv8n 等模型进行了对比，并将此算法在 NEU-DET 钢板表面缺陷数据集进行了拓展鲁棒性验证实验，将检测精度从 78.6% 提升至 79.5%。证明了本改进模型的鲁棒性与良好的检测通用性。

第 6 章 结论

本文提出了两种基于 YOLO 系列模型的钢板表面缺陷检测方法。针对当前钢板表面检测中的问题，我们对各模型进行了有效分析，并充分证明了基于 YOLOv5 和 YOLOv8 的两种算法在实际工业生产中检测钢板表面缺陷的有效性。本文主要研究成果如下：

(1) 搭建了基于工业相机和电子计算机系统的钢板表面缺陷数据采集平台，在工业生产中采集了 3200 张初期钢板表面缺陷图像，构建了实际工业生产中的钢板表面缺陷数据集。并按缺陷类型对图像进行分类和标注，为后续研究提供支持。

(2) 提出了目标检测缺陷算法中的输入参数调节原则，在满足输入参数调节公式最小整数下可以兼顾图像初始检测平均精度与速度。同时给出了基于标签法的缺陷类型二次判别方法并进行了验证计算。并设计出了可视化的表面检测界面。

(3) 设计了一种轻量化的 YOLOv5 检测模型 PP-LCYOLOv5s，并用于公开钢板表面数据集 NEU-DET 的检测训练，将此数据集涵盖的缺陷的平均精度从 76.0%提升到了 76.2%，但是训练时间从 0.675h 缩减到了 0.594h，对计算浮点数的要求从 16.0GFLOPS 减少到了 2.0GFLOPS。

(4) 采用了 YOLOv8s 作为改进的基础模型，并提出了一种用于小目标提取的关键算法。使用融合 CPCA 注意力+改进 SPPF 金字塔机制与 World 开放和词汇检测模型与 GhostNet 强化模型对细小划痕的检测效果。将检测平均精度从 67.8%上升到了 72.7%，在难以识别的薄弱划痕缺陷上检测平均精度 (mAP/mAP@50/mAP@0.5) 从 55.8%提升到了 62.9%。同时还做了 NEU-DET 数据集上的迁移实验，将检测平均精度由 78.6%提升到了 79.5%，证明了所提出模型的鲁棒性。

创新点：

(1) 引入 PP-LC 轻量化主干网络，结合 DsConv 移位可变形卷积与 Triplet 注意力机制在公开表面数据集上设计出了轻量化的 PP-LCYOLOv5s 检测模型。

(2) 针对长方形大尺寸小目标数据集，提出了一种输入参数判别方法。并结合此判别方法，引入分层 GhostConv 卷积设计新主干网络并引入开集检测网络与通道优先注意提出了改进高精度 G-YOLOv8s 检测模型。

未来研究展望:

数据集改进与图像分割技术: 受限于时间与经验, 当前数据集存在不均衡且小目标难以筛选的问题。未来计划引入图像分割技术, 增强对小目标的筛选能力, 并提高标签速度, 以训练出更高速、高精度的表面检测模型。

技术融合与轻量化设计: 期望通过不断的研究与创新, 将缺陷检测技术与图像分割、通用深度学习等技术相结合, 拓展至机械零件智能故障诊断与维修领域。同时, 致力于算法的轻量化设计, 以便在移动设备上实现更广泛的应用。

参考文献

- [1] 欧剑港. 基于深度卷积神经网络的钢板表面缺陷在线检测算法研究[D]. 广州: 华南理工大学, 2019: 16:13
- [2] 任新凯. 中厚钢板表面质量缺陷原因分析及优化措施[J]. 山西冶金, 2022, 45(04): 196-197.
- [3] 王超. 热轧工艺参数对典型钢板表面氧化层结构的影响研究[D]. 北京: 北京科技大学, 2022: 20:4-9
- [4] 徐建翔, 吴宇文. 中厚板热处理线抛丸钢板表面质量问题分析及解决[J]. 内燃机与配件, 2019(12): 125-126
- [5] 郭阿敏. 船体零件自由边机器人打磨系统的位力调控仿真研究[D]. 上海: 上海交通大学, 2021: 4-8
- [6] 胡江, 任尚坤, 祖瑞丽. 钢板近表面缺陷的交流电磁场检测[J]. 无损检测, 2017, 39(09): 11-14.
- [7] 胡游. 基于磁致伸缩效应导波钢板无损检测研究[D]. 杭州: 浙江大学, 2013: 14:16
- [8] 邢智翔, 何存富, 刘秀成等. 钢板硬斑的增量涡流扫查成像方法与仪器[J]. 仪器仪表学报, 2023, 44(02): 184-191
- [9] GONG Z Q, YI H K, JIAN T, et al. Normal Magnetizing-Based Eddy Current Testing Method for Multidirectional Cracks on Steel Plate Surface Based on Permeability Perturbation[J]. Journal of Nondestructive Evaluation, 2023, 42(2):
- [10] TERUYOSHI S, WATARU Y, KEIJI E, et al. Rectangular wave eddy current testing using for imaging of backside defects of steel plates[J]. International Journal of Applied Electromagnetics and Mechanics, 2020, 64(1-4): 255-262.
- [11] 赵元松, 李大鹏. 基于有限元方法的钢板焊缝缺陷红外无损检测[J]. 机电工程, 2005(12): 39-42.
- [12] 储藏祥. 钢板表面缺陷检测关键技术研究[D]. 沈阳: 东北大学, 2017: 12:17
- [13] 石军彦. 基于线阵 CCD 钢板表面缺陷检测系统的研究[D]. 秦皇岛: 燕山大学, 2010: 15:2-6.
- [14] SUBBARAO M, Lu M C. Image sensing model and computer simulation for CCD camera systems[J]. Machine Vision and Applications, 1994, 7: 277-289.
- [15] 赵畅. 基于点云数据的钢板表面缺陷三维检测方法研究[D]. 北京: 北京化工大学, 2021: 12.

- [16] 兰欢, 余建波. 基于深度学习三维成型的钢板表面缺陷检测[J]. 浙江大学学报(工学版), 2023, 57(03): 466-476+561.
- [17] IOFFE S, SZEGEDY C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]//International conference on machine learning. pmlr, 2015: 448-456.
- [18] REN S, HE K, GIRSHICK R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28.
- [19] LIU W, ANGUELOV D, ERHAN D, et al. Ssd: Single shot multibox detector[C] Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14. Springer International Publishing, 2016: 21-37.
- [20] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.
- [21] REDMON J, FARHADI A. YOLO9000: better, faster, stronger[C] Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 7263-7271.
- [22] REDMON J, FARHADI A. YOLOv3: An incremental improvement[J]. arxiv preprint arxiv:1804.02767, 2018.
- [23] BOCHKOVSKIY A, WANG C Y, LIAO H Y M. YOLOv4: Optimal speed and accuracy of object detection[J]. arxiv preprint arxiv:2004.10934, 2020.
- [24] ZHU X, LYU S, WANG X, et al. TPH-YOLOv5: Improved YOLOv5 based on transformer prediction head for object detection on drone-captured scenarios[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 2778-2788.
- [25] LI C, LI L, JIANG H, et al. YOLOv6: A single-stage object detection framework for industrial applications[J]. arxiv preprint arxiv:2209.02976, 2022.
- [26] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C] Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 7464-7475.
- [27] WU Y, HE K. Group normalization[C] Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.

- [28] VALIZADEHASLANI T, LIANG H. LayerNorm: A key component in parameter-efficient fine-tuning[J]. arxiv preprint arxiv:2403.20284, 2024.
- [29] 张庆超. 基于特征融合卷积神经网络的钢板表面缺陷识别研究与应用[D]. 沈阳: 东北大学, 2020: 24.
- [30] 吴越, 杨延竹, 苏雪龙等. 基于 Faster R-CNN 的钢板表面缺陷检测方法[J]. 东华大学学报(自然科学版), 2021, 47(03): 84-89.
- [31] 刘轮. 基于深度学习的钢板表面缺陷检测与分类[D]. 南京: 南京理工大学, 2021: 13:17.
- [32] 张宇. 基于深度学习的带钢表面缺陷检测方法[D]. 西安: 西安工业大学, 2022: 56:5-6.
- [33] 姜乐兵. 基于深度学习的钢板表面缺陷视觉检测方法研究[D]. 无锡: 江南大学, 2023: 16:2-8
- [34] 田思洋. 板带钢表面缺陷目标检测与分类算法研究[D]. 北京: 北京科技大学, 2019: 24:16
- [35] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 580-587.
- [36] ZHAO W, CHEN F, HUANG H, et al. A new steel defect detection algorithm based on deep learning[J]. Computational Intelligence and Neuroscience, 2021: 1-13.
- [37] WANG S, XIA X, YE L, et al. Automatic detection and classification of steel surface defect using deep convolutional neural networks[J]. Metals, 2021, 11(3): 388.
- [38] JIANG P, ERGU D, LIU F, et al. A Review of Yolo algorithm developments[J]. Procedia computer science, 2022, 199: 1066-1073.
- [39] LIU W, ANGUELOV D, ERHAN D, et al. Ssd: Single shot multibox detector[C]//Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14. Springer International Publishing, 2016: 21-37.
- [40] HE D, XU K, ZHOU P. Defect detection of hot rolled steels with a new object detection framework called classification priority network[J]. Computers & Industrial Engineering, 2019, 128: 290-297.
- [41] KOU X, LIU S, CHENG K, et al. Development of a YOLO-V3-based model for detecting defects on steel strip surface[J]. Measurement, 2021, 182: 109-121.
- [42] 徐镭, 朱洪锦, 范洪辉等. 改进的 YOLOv3 网络在钢板表面缺陷检测研究[J]. 计算机工程与应用, 2020, 56(16): 265-272.

- [43] ZHANG Y, WANG W, LI Z, et al. Development of a cross-scale weighted feature fusion network for hot-rolled steel surface defect detection[J]. Engineering Applications of Artificial Intelligence, 2023, 117: 105-128.
- [44] NGUYEN H V, BAE J H, LEE Y E, et al. Comparison of pre-trained YOLO models on steel surface defects detector based on transfer learning with GPU-based embedded devices[J]. Sensors, 2022, 22(24): 99-116.
- [45] LI G, ZHAO S, ZHOU M, et al. YOLO-RFF: An industrial defect detection method based on expanded field of feeling and feature fusion[J]. Electronics, 2022, 11(24): 124-135.
- [46] LUO X, NI Q, TAO R, et al. A lightweight detector based on attention mechanism for fabric defect detection[J]. IEEE Access, 2023, 11: 33554-33569.
- [47] XIA K, LV Z, ZHOU C, et al. Mixed receptive fields augmented YOLO with multi-path spatial pyramid pooling for steel surface defect detection[J]. Sensors, 2023, 23(11): 124-135.
- [48] XIAO D, XIE F T, GAO Y, et al. A detection method of spangle defects on zinc-coated steel surfaces based on improved YOLO-v5[J]. The International Journal of Advanced Manufacturing Technology, 2023, 128(1-2): 937-951.
- [49] MA H, ZHANG Z, ZHAO J. A Novel ST-YOLO Network for Steel-Surface-Defect Detection[J]. Sensors, 2023, 23(22): 915-922.
- [50] 张嘉雄, 曾水玲, 李昭贤. 基于改进 YOLOv7 的钢板表面缺陷检测的方法[J]. 控制工程, 2023(05):1-11.
- [51] 范瑶瑶, 王兴芬, 刘亚辉. 改进 DeepLabv3+网络的钢板表面缺陷检测研究[J]. 计算机工程与应用, 2023, 59(16): 150-158.
- [52] PAN Y, ZHANG L. Dual attention deep learning network for automatic steel surface defect segmentation[J]. Computer-Aided Civil and Infrastructure Engineering, 2022, 37(11): 1468-1487.
- [53] 代晓林, 刘梦玫, 李生群等. 基于改进 Swin Transformer 的钢板表面缺陷检测方法[J]. 装备制造技术, 2022(04): 88-91
- [54] LUYA Y, XINBO H, YUCHENG R, et al. Steel Plate Surface Defect Detection Based on Dataset Enhancement and Lightweight Convolution Neural Network[J]. Machines, 2022, 10(7)
- [55] 吴昆鹏, 石杰, 杨朝霖等. 基于半监督语义分割的钢板表面缺陷检测方法 [J]. 冶金自动化, 2023, 47(04): 93-99.

- [56] 何戡,宋克臣,张德富等.融合多层次特征的弱监督钢板表面缺陷检测算法[J].东北大学学报(自然科学版), 2021,42(05): 687-692.
- [57] 李钧正, 殷子玉, 乐心怡. 基于小样本学习的钢板表面缺陷检测技术 [J].航空科学技术, 2021,32(06): 65-70.
- [58] 刘小明. 多尺度几何变换在金属表面缺陷识别中的应用[D]. 北京: 北京科技大学, 2021: 15
- [59] 李雪露,杨永辉,储藏祥.基于改进 RetinaNet-GHM 算法的钢板表面缺陷检测[J].电子测量技术,2023,46(06):100- 105
- [60] ZHOU F, CHAO Y, WANG C, et al. A small sample nonstandard gear surface defect detection method[J]. Measurement, 2023, 221: 113472.
- [61] ZHANG Y, ZHANG H, HUANG Q, et al. DsP-YOLO: An anchor-free network with DsPAN for small object detection of multiscale defects[J]. Expert Systems with Applications, 2024, 241: 122669.
- [62] HU H, ZHU Z. Sim-YOLOv5s: A method for detecting defects on the end face of lithium battery steel shells[J]. Advanced Engineering Informatics, 2023, 55: 101824.
- [63] CAO Y, PANG D, ZHAO Q, et al. Improved YOLOv8-GD deep learning model for defect detection in electroluminescence images of solar photovoltaic modules[J]. Engineering Applications of Artificial Intelligence, 2024, 131: 107866.
- [64] XI D J, QIN Y, WANG S. YDRSNet: An integrated YOLOv5-Deeplabv3+ real-time segmentation network for gear pitting measurement[J]. Journal of Intelligent Manufacturing, 2023, 34(4): 1585-1599.
- [65] ZHAO C, SHU X, YAN X, et al. RDD-YOLO: A modified YOLO for detection of steel surface defects[J]. Measurement, 2023, 214: 112776.
- [66] LIU Y, ZHENG Y, SHAO Z, et al. Defect detection of the surface of wind turbine blades combining attention mechanism[J]. Advanced Engineering Informatics, 2024, 59: 102-292.
- [67] HAO K, CHEN G, ZHAO L, et al. An insulator defect detection model in aerial images based on multiscale feature pyramid network[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-12.
- [68] ZHANG Z, TAN L, TIONG R L K. Ship-Fire net: an improved YOLOv8 algorithm for ship fire detection[J]. Sensors, 2024, 24(3): 727-735.

- [69] WANG L, LIU B, SHAO W, et al. Enhancing hazardous material vehicle detection with advanced feature enhancement modules using HMV-YOLO[J]. *Frontiers in neurorobotics*, 2024, 18.
- [70] WANG Z, HUA Z, WEN Y, et al. E-YOLO: Recognition of estrus cow based on improved YOLOv8n model[J]. *Expert Systems with Applications*, 2024, 238: 122-1312.
- [71] JIANG H, HU F, FU X, et al. YOLOv8-Peas: a lightweight drought tolerance method for peas based on seed germination vigor[J]. *Frontiers in Plant Science*, 2023, 14: 125-147.
- [72] HE Y, SONG K C , MENG Q G, YAN Y H , “An End-to-end Steel Surface Defect Detection Approach via Fusing Multiple Hierarchical Features,” *IEEE Transactions on Instrumentation and Measurement*[J], 2020,69(4),1493-1504
- [73] HE K, ZHANG X, REN S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. *IEEE transactions on pattern analysis and machine intelligence*, 2015, 37(9): 1904-1916.
- [74] REZATOFIGHI, H., et al. "Generalized Intersection over Union: A Metric and A Loss for Bounding Box Regression." In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2019, pp. 658-666.
- [75] ZHENG, Z., et al. "Distance-IoU Loss: Faster and Better Learning for Bounding Box Regression[C]//." In *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 34, no. 07, 2020, pp. 12993-13000.
- [76] Zhang Y F, Ren W, Zhang Z, et al. Focal and efficient IOU loss for accurate bounding box regression[J]. *Neurocomputing*, 2022, 506: 146-157.
- [77] TONG Z, CHEN Y, XU Z, et al. Wise-IoU: bounding box regression loss with dynamic focusing mechanism[J]. *arxiv preprint arxiv:2301.10051*, 2023.
- [78] GEVORGYAN Z. SIoU loss: More powerful learning for bounding box regression[J]. *arxiv preprint arxiv:2205.12740*, 2022.
- [79] GE Z, LIU S, WANG F, et al. YOLOx: Exceeding yolo series in 2021[J]. *arxiv preprint arxiv:2107.08430*, 2021.
- [80] XU X, JIANG Y, CHEN W, et al. Damo-YOLO: A report on real-time object detection design[J]. *arxiv preprint arxiv:2211.15444*, 2022.

- [81] WANG C, HE W, NIE Y et al. Gold-YOLO: Efficient object detector via gather-and-distribute mechanism[J]. Advances in Neural Information Processing Systems, 2024, 36:387-389
- [82] CHENG T, SONG L, GE Y, et al. YOLO-World: Real-Time Open-Vocabulary Object Detection[J]. arxiv preprint arxiv:2401.17270, 2024.
- [83] YANG L, ZHANG R Y, LI L, et al. Simam: A simple, parameter-free attention module for convolutional neural networks[C]//International conference on machine learning. PMLR, 2021: 11863-11874.
- [84] WOO S, PARK J, LEE J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19
- [85] MISRA D, NALAMADA T, ARASANIPALAI A U, et al. Rotate to attend: Convolutional triplet attention module[C]//Proceedings of the IEEE/CVF winter conference on applications of computer vision. 2021: 3139-3148.
- [86] CUI C, GAO T, WEI S, et al. PP-LCNet: A lightweight CPU convolutional neural network[J]. arxiv preprint arxiv:2109.15099, 2021
- [87] KAISER L, GOMEZ A N, CHOLLET F. Depthwise separable convolutions for neural machine translation[J]. arxiv preprint arxiv:1706.03059, 2017
- [88] HUANG H, CHEN Z, ZOU Y, et al. Channel prior convolutional attention for medical image segmentation[J]. arxiv preprint arxiv:2306.05196, 2023
- [89] HAN K, WANG Y, TIAN. Q, et al. Ghostnet: More features from cheap operations[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 1580-1589..

附录 A 分析检测结果的代码

```
import cv2
import os
import numpy as np
import matplotlib.pyplot as plt
import matplotlib as mpl
import math
# 设置字体为 Times New Roman
mpl.rcParams['font.family'] = 'Times New Roman'
mpl.rcParams['font.size'] = 12

# 原图像文件夹路径
image_folder_path = r'C:\Users\Administrator\Desktop\test_set_predict12' # 替换为你的
# 图像文件夹路径
# 标签文件夹路径（假设每个图像都有一个对应的.txt 标签文件）
label_folder_path = r'C:\Users\Administrator\Desktop\test_set_predict12\labels' # 替换
# 为你的标签文件夹路径
# 输出文件夹路径
output_folder_path = r'C:\Users\Administrator\Desktop\pre_result' # 替换为你想要保
# 存结果图像的文件夹路径
# 如果输出文件夹不存在，则创建它
if not os.path.exists(output_folder_path):
    os.makedirs(output_folder_path)

# 图像分辨率和像素对应的物理尺寸
image_width = 950
image_height = 1400
```

```
pixel_size_mm = 0.01 # 每个像素对应的物理尺寸（毫米）
# 获取图像文件夹中的所有图像文件名
image_files = [f for f in os.listdir(image_folder_path) if f.endswith((''.bmp', '.png'))]
# 初始化缺陷类型计数器
dent_count_label = 0
scratch_count_label = 0
dent_count_predicted = 0
scratch_count_predicted = 0
dents = [] # 每个元素是一个元组：(x_center, y_center, area)
scratches = [] # 每个元素是一个元组：(x_center, y_center, area)

# 定义缺陷类型与颜色、标签文本的对应关系
defect_types = {0: ('压坑', 'green'), 1: ('划痕', 'blue')}
colors_dict = {'green': (0, 255, 0), 'blue': (0, 0, 255)}

# 遍历图像文件
for image_file in image_files:
    # 构建图像和标签文件的完整路径
    image_path = os.path.join(image_folder_path, image_file)
    label_file = os.path.splitext(image_file)[0] + '.txt'
    label_path = os.path.join(label_folder_path, label_file)

    # 检查标签文件是否存在
    if not os.path.exists(label_path):
        print(f"Warning: Label file not found for image {image_file}")
        continue

    # 读取图像
    image = cv2.imread(image_path)
```

```
image_rgb = cv2.cvtColor(image, cv2.COLOR_BGR2RGB) # 转换为 RGB 格式  
以便后续处理
```

```
# 读取 txt 文件中的标签信息  
with open(label_path, 'r') as file:  
    labels = file.readlines()  
  
# 遍历标签信息并绘制框  
for label in labels:  
    label_parts = label.strip().split()  
    if len(label_parts) < 5:  
        continue  
    label_type = int(label_parts[0])  
    center_x_ratio = float(label_parts[1])  
    center_y_ratio = float(label_parts[2])  
    width_ratio = float(label_parts[3])  
    height_ratio = float(label_parts[4])  
    # 根据原始标签类型更新计数器  
    if label_type == 0: # 假设 0 代表压坑  
        dent_count_label += 1  
    elif label_type == 1: # 假设 1 代表划痕  
        scratch_count_label += 1  
    # 计算框的实际位置和大小  
    center_x = int(center_x_ratio * image_width)  
    center_y = int(center_y_ratio * image_height)  
    width = int(width_ratio * image_width)  
    height = int(height_ratio * image_height)  
    # 计算框的左上角和右下角坐标  
    top_left_x = center_x - width // 2
```

```
top_left_y = center_y - height // 2
bottom_right_x = center_x + width // 2
bottom_right_y = center_y + height // 2

# 计算框的面积（单位：平方毫米）
area_mm2 = width * height * (pixel_size_mm ** 2)
center_x1 = center_x * math.sqrt(pixel_size_mm)
center_y1 = center_y * math.sqrt(pixel_size_mm)
# 进行二次判别
long_side = max(width, height)
short_side = min(width, height)
aspect_ratio = long_side / short_side
defect_type_predicted = 'Scratch' if aspect_ratio > 2.5 else 'Dent' # 假设长宽
比大于 2 为划痕
# 获取缺陷类型和对应的颜色（根据预测结果）
color_name = 'green' if defect_type_predicted == 'Dent' else 'blue'
color = colors_dict[color_name]
# 更新缺陷类型计数器
if defect_type_predicted == 'Dent':
    dent_count_predicted += 1
elif defect_type_predicted == 'Scratch':
    scratch_count_predicted += 1 # 正确的更新

# 根据预测结果更新列表
if defect_type_predicted == 'Dent':
    dents.append((center_x1, center_y1, area_mm2))
elif defect_type_predicted == 'Scratch':
    scratches.append((center_x1, center_y1, area_mm2))
```

```

# 绘制框
cv2.rectangle(image_rgb, (top_left_x, top_left_y), (bottom_right_x,
bottom_right_y), color, 1)
# 绘制面积和判定结果文本
font = cv2.FONT_HERSHEY_SIMPLEX
text = f'Area: {area_mm2:.3f} mm², type: {defect_type_predicted}'
text_size = cv2.getTextSize(text, font, 0.5, 2)[0]
text_x = top_left_x
text_y = top_left_y - text_size[1] - 5
if text_y < 0:
    text_y = top_left_y + height + 5 # 如果文本位置超出图像上方, 则放在
框的下方
cv2.putText(image_rgb, text, (text_x, text_y), font, 0.5, color, 2)
# 构建输出图像的完整路径
output_image_path = os.path.join(output_folder_path, image_file)
# 将处理后的图像保存为文件
image_bgr = cv2.cvtColor(image_rgb, cv2.COLOR_RGB2BGR) # 转换回 BGR
格式以便保存
cv2.imwrite(output_image_path, image_bgr)
# 在循环结束后计算误识别率
if dent_count_label > 0:
    ratio_mistake_dent = abs(dent_count_label - dent_count_predicted) /
dent_count_label
else:
    ratio_mistake_dent = 0 # 避免除以零
if scratch_count_label > 0:
    ratio_mistake_scratch = abs(scratch_count_label - scratch_count_predicted) /
scratch_count_label
else:

```

```
ratio_mistake_scratch = 0 # 避免除以零

print("Processing complete. Images saved to the output folder.")
print(f'Total Dents (based on label): {dent_count_label}')
print(f'Total Scratches (based on label): {scratch_count_label}')
print(f'Total Dents (based on prediction): {dent_count_predicted}')
print(f'Total Scratches (based on prediction): {scratch_count_predicted}')
print(f'Total ratio_mistake_dent: {ratio_mistake_dent}')
print(f'Total ratio_mistake_scratch: {ratio_mistake_scratch}')
# 可视化压坑和划痕的分布

plt.figure(figsize=(12, 6))
# 绘制压坑分布散点图
plt.subplot(1, 2, 1)

plt.scatter([d[0] for d in dents], [d[1] for d in dents], c=[d[2] for d in dents], cmap='hot',
s=10)

plt.title('Dent Distribution')
plt.xlabel('X Position (mm)')
plt.ylabel('Y Position (mm)')
plt.colorbar(label='Area (mm²)')
# 绘制划痕分布散点图
plt.subplot(1, 2, 2)

plt.scatter([s[0] for s in scratches], [s[1] for s in scratches], c=[s[2] for s in scratches],
cmap='cool', s=10)

plt.title('Scratch Distribution')
plt.xlabel('X Position (mm)')
plt.ylabel('Y Position (mm)')
plt.colorbar(label='Area (mm²)')

plt.tight_layout()
plt.show()
```

附录 B 改进损失函数的伪代码输入形式

类 WIoU_Scale: 属性:

iou_mean = 1.0

monotonous = False

_momentum = 1 - 0.5^(1/7000)

_is_train = True

构造函数 __init__(iou):

self.iou = iou

self._update(self)

类方法 _update(cls, self):

如果 cls._is_train 为真:

cls.iou_mean = (1 - cls._momentum) * cls.iou_mean + cls._momentum *

self.iou.detach().mean().item()

类方法 _scaled_loss(cls, self, gamma=1.9, delta=3):

如果 self.monotonous 是布尔类型:

如果 self.monotonous 为真:

返回 (self.iou.detach() / self.iou_mean).sqrt()

否则:

beta = self.iou.detach() / self.iou_mean

alpha = delta * torch.pow(gamma, beta - delta)

返回 beta / alpha

返回 1

函数 bbox_iou(box1, box2, xywh=True, ... [其他参数]):

如果 Inner 为真:

计算 box1 和 box2 的内部 IoU

否则:

如果 xywh 为真:

将 `box1` 和 `box2` 从 `xywh` 格式转换为 `xyxy` 格式

计算 `box1` 和 `box2` 的交集面积

计算 `box1` 和 `box2` 的并集面积

计算 IoU

根据参数（如 `CIoU`, `DIoU`, `GIoU` 等）计算相应的扩展 IoU:

对于每种 IoU 类型:

计算相应的距离、角度、形状等成本

根据成本调整 IoU 值

如果 `Focal` 为真:

返回 IoU 值和额外的焦点损失部分

否则:

返回 IoU 值

附录 C Ghostconv 伪代码

```
# 输入:
#   input: 输入特征图, 形状为 [batch_size, channels, height, width]
#   output_channels: 输出的通道数
#   ratio: 固有特征图和幻影特征图的比例 (例如, ratio=2 表示一半的特征图
是固有的, 一半是幻影的)

# 输出:
#   output: 输出特征图, 形状为 [batch_size, output_channels, height, width]

function
GhostConvolution(input, output_channels, ratio):
# 计算固有特征图和幻影特征图的数量
# 进行普通卷积以生成固有特征图
# 使用深度可分离卷积从固有特征图中生成幻影特征图
# 选择一个固有特征图作为输入
# 应用深度可分离卷积 (或简单的线性变换)
# 或者使用更简单的线性操作, 如:
# 其中 weight 和 bias 是可学习的参数 (需要初始化并在训练过程中更新)
# 沿着通道维度拼接固有特征图和幻影特征图
```