



中国科学院大学
University of Chinese Academy of Sciences

博士学位论文

基于机器视觉的产品表面缺陷检测关键算法研究

作者姓名: 王帅

指导教师: 夏筱筠 研究员 中国科学院沈阳计算技术研究所

学位类别: 工学博士

学科专业: 计算机应用技术

培养单位: 中国科学院沈阳计算技术研究所

2021 年 6 月

**Research on key algorithm of product surface defect
detection based on machine vision**

**A dissertation submitted to
University of Chinese Academy of Sciences
in partial fulfillment of the requirement
for the degree of
Doctor of Philosophy
in Computer Application Technology**

By

Wang Shuai

Supervisor: Professor Xia Xiaojun

**Shenyang Institute of Computing Technology,
Chinese Academy of Sciences**

June 2021

书脊（此页仅用于制作书脊，不用单独打印放入论文）

基于机器视觉的产品表面缺陷检测关键算法研究
王帅
中国科学院大学

摘 要

近年来,发达国家相继开始了对制造业进行产业升级,其中主要以德国的工业 4.0 为代表。制造业在我国既是国民社会经济中的支柱产业,而且也是我国推动创新以及产业升级的主战场。在中国制造 2025 这个战略中指出要更快的提高产品的质量,制定提升产品质量的实施计划。对于一个企业来说,产品质量是企业发展和竞争的基石。提高产品的质量对于企业十分重要。因此,在众多的工业领域,产品表面缺陷检测已经吸引了大量的研究人员对其进行深入的研究。

为了进一步提升产品表面缺陷检测的自动化程度,研究人员使用机器学习或者深度学习算法来进行检测。这类方法已经成为了新的发展方向。在工业生产过程中,由人工来做测量和判断会因为疲劳、操作人员个体差异等产生误差和错误,通过视觉显著性的方法来模拟人来进行产品的缺陷检测能够增加效率和准确率,能够很方便的区分出有缺陷的区域和没有缺陷的区域。因此研究基于机器视觉的产品缺陷检测算法对发展智能生产线有着至关重要的作用,也是我国工业生产智能制造的关键一步。因此,本课题研究机器视觉算法用于产品缺陷检测的有着重要的现实意义,对实现智能制造具有重要的理论意义及实际价值。具体研究内容如下:

1. 提出了一种基于区域特征聚类显著性检测的表面缺陷分割算法。针对传统的基于机器学习的表面缺陷检测算法中准确率低、鲁棒性弱的问题。本文提出了一种基于区域特征聚类显著性检测的表面缺陷分割算法。首先使用由 GPU 加速的超像素分割算法对图像进行分割,接着对分割的每个超像素区域求取特征向量。再使用多带宽无参聚类算法对特征向量聚类,得到十个不同带宽下的显著性图。通过神经网络对显著性图进行合并。把最后得到的显著性图作为一个新的特征再次重复以上过程。重复十次后得到最终的缺陷图像分割图。通过实验表明,本算法和其他算法比较,在效果、准确率、召回率、F 值以及 MAE 上都有提高。

2. 提出了基于 U-net 和迁移学习的表面缺陷检测算法。针对当前的深度学习图像分割算法在提高精度和减少计算量方面仍有很大的空间。采用迁移学习或改进算法,可以提高学习精度,取得较好的效果。将批归一化(BN)层合并到卷积层中,可以减少计算量。首先,使用数据扩充扩展数据集。然后使用 EfficientNet 作为主干网络来提取特征。使用 U-net 在多个尺度上对特征进行融合。最后,通

过一层卷积得到大小为 $512 \times 512 \times 4$ 的四类缺陷的映射。实验表明，该算法比其他算法具有更高的精度和鲁棒性。平均 Dice 系数达到 0.905。

3.提出了一种基于迁移学习和多尺度特征融合的表面缺陷检测算法。这种深度学习模型是一种端到端的表面缺陷检测算法。它由基于高效网络的主干网、自顶向下的特征金字塔网络（BiFPN）和基于反卷积网络的多尺度特征融合组成，以产生最终的输出。最终输出是四个与输入大小相同的分割图，表示四类缺陷。由于 Mish 激活函数能够获得更好的梯度并且不出现饱和现象，因此本文中的激活函数使用了 Mish，进而使得模型更准确泛化性更好。实验结果表明，该算法的平均 Dice 系数为 0.912。优于其他深度学习算法的钢材表面缺陷检测。

4. 提出了一种将分类与目标检测模型相结合的表面缺陷检测算法。基于深度学习的分类算法只能对图像进行分类，不能确定缺陷的位置和大小。这对以后的数据分析有很大的影响。基于 GAN 和强化学习，很难训练出一个稳定、准确的模型。本章实现了钢板表面缺陷的自动检测和定位，进一步提高了算法的精度和稳定性，减少了算法的平均运行时间。通过分析发现，麻点表面缺陷较小不明显，该类缺陷准确度不高。通过在 Faster R-CNN 的特征提取部分加入 FPN 和 SPP，提高了这类缺陷的识别精度。裂缝缺陷又窄又长检测的准确性不高。通过改变 Faster R-CNN 的默认锚的大小，提高了定位精度。在分类模型和目标识别模型的主干网络 ResNet50-vd 改进模型中，通过加入 DCN 和改进的 Cutout 数据增强，可以更好地检测出各种形状的缺陷，具有更高的精度和鲁棒性。最后对分类模型和目标检测模型的精度进行了分析，整个模型的精度为 0.982。

关键词：产品表面缺陷检测，机器视觉，深度学习，图像分割，物体检测

Abstract

In recent years, developed countries have started to upgrade their manufacturing industry, mainly represented by German industry 4.0. Manufacturing industry is not only the pillar industry in the national economy, but also the main battlefield to promote innovation and industrial upgrading. In the strategy of "Made in China 2025", it is pointed out that the quality of products should be improved faster and the implementation plan for improving product quality should be formulated. For an enterprise, product quality is the cornerstone of enterprise development and competition. Improving the quality of products is very important for enterprises. Therefore, in many industrial fields, product surface defect detection has attracted a large number of researchers to conduct in-depth research on it.

To further improve the automation of product defect detection, using machine learning or deep learning methods has become the development direction. In the industrial production process, manual measurement and judgment will produce errors and errors due to fatigue, individual differences of operators. Visual saliency method to simulate people for defect detection of products can increase efficiency and accuracy, and can easily distinguish defective areas from non-defective areas. Therefore, the research of defect detection algorithm based on machine vision plays an important role in the development of intelligent production lines, and is also a key step in the intelligent manufacturing of industrial production in China. Thus, it is of great practical significance to study the application of machine vision in product defect detection. The research of this topic has important theoretical significance and practical value for the realization of intelligent manufacturing. The specific research contents are as follows:

1. An image segmentation surface defect algorithm based on saliency detection of regional features clustering is presented. The traditional machine learning based surface defect detection algorithm has low accuracy and weak robustness. This paper presents an image segmentation surface defect algorithm based on saliency detection of regional features clustering. First, the image is segmented using a super-pixel algorithm, and then the eigenvectors of the segmented result are computed. Then the feature vectors are clustered using a multibandwidth parameterless clustering algorithm, and the saliency maps calculated under ten bandwidths is obtained. Saliency maps are merged using a neural network. Add the resulting saliency map as a new feature to the

eigenvector and repeat the process again. The final defect image segmentation map was obtained after ten repetitions. Experiments show that this algorithm improves the performance, accuracy, recall, F score and MAE compared with other algorithms.

2. A learning algorithm based on U-net and transfer learning is presented. For the current deep learning image segmentation algorithm, there is still a lot of space to improve the accuracy and reduce the amount of calculation. Using transfer learning or improved algorithm can improve the learning accuracy and achieve good results. Combining batch normalization (BN) layers into convolution layers can reduce the amount of calculation. First, extend the dataset using data augmentation. EfficientNet is then used as the backbone network to extract features. Use U-net to fuse features at multiple scales. Finally, four types of defects, size $512 \times 512 \times 4$, are obtained by a layer of convolution. Experiments show that the algorithm has higher accuracy and robustness than other algorithms. The average Dice coefficient is 0.905.

3. An algorithm based on transfer learning and image segmentation is presented. First, the data set is expanded using data augmentation technology. Next, we use EfficientNet as the backbone to get the feature map. Five different scales of feature map are obtained from the repeated BiFPN. Then the five feature maps are fused together by deconvolution, and a layer of convolution is used to get the masks of various defects. After the final training, we use batch normalization and convolution layer fusion to reduce the running time of the algorithm. Because the mish activation function can get better gradient without saturation, the activation function in this paper uses mish, which makes the model more accurate and has better generalization. The experimental results show that the average Dice coefficient of the algorithm is 0.912. Defect detection of steel surface is better than other deep learning algorithms.

4. A surface defect detection algorithm combining classification with object detection model is proposed. The classification method based on deep learning can only classify the image, but cannot determine the location and size of the defect. This has a great impact on the future data analysis. Based on GAN and reinforcement learning, it is difficult to train a stable and accurate model. This chapter realizes the automatic detection and location of steel plate surface defects, further improves the accuracy and stability of the algorithm, and reduces the average running time of the algorithm. Through the analysis, it is found that the surface defects of pits are usually small and not obvious, so the accuracy of such defects is not high. In the improved Faster R-CNN model, FPN and SPP are added to the feature extraction part of Faster R-CNN to

improve the recognition accuracy of this kind of defects. In addition, the accuracy of crazing defect detection is not high, because it is narrow and long. By changing the size of the default anchor of Faster R-CNN, the positioning accuracy is improved. In the improved Resnet50-vd model, which is the backbone of the classification model and the target recognition model, DCN and improved Cutout data augmentation are added to better detect various shapes of defects, with higher accuracy and robustness. Finally, the accuracy of classification model and object detection model is analyzed, and the accuracy of the whole model is 0.982.

Key Words: Product Surface Defect Detection, Machine Vision, Deep Learning, Image Segmentation, Object Detection

目 录

摘要.....	I
Abstract.....	III
第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外现状.....	2
1.3 课题研究内容.....	6
1.4 论文组织结构.....	6
1.5 本章小结.....	7
第 2 章 表面缺陷检测算法基础	8
2.1 引言.....	8
2.2 表面缺陷检测系统.....	8
2.2.1 表面缺陷图像采集.....	8
2.2.2 挑战.....	9
2.2.3 发展趋势.....	10
2.2.4 图像预处理.....	10
2.2.5 感兴趣区域检测.....	11
2.3 显著性物体检测算法用于表面缺陷检测.....	12
2.4 深度学习基础.....	13
2.4.1 卷积神经网络.....	13
2.4.2 图像分类.....	15
2.4.3 物体识别.....	17
2.4.4 语义分割.....	21
2.5 本章小结.....	25
第 3 章 基于区域特征聚类显著性检测的表面缺陷分割算法	26
3.1 引言.....	26
3.2 算法.....	26
3.2.1 基于改进的 SLIC 图像超像素分割.....	27
3.2.2 特征提取.....	29
3.2.3 Mean Shift 聚类.....	30
3.2.4 EBC 计算每个聚类的显著图.....	31
3.2.5 循环.....	32
3.3 实验结果与分析.....	32
3.3.1 数据集和实验环境.....	32
3.3.2 结果与分析.....	32
3.4 本章小结.....	36
第 4 章 基于迁移学习和图像分割的表面缺陷检测算法	37
4.1 引言.....	37
4.2 算法.....	37
4.2.1 基于迁移学习和多尺度特征融合的表面缺陷检测算法.....	38
4.2.2 基于迁移学习和 U-net 的表面缺陷检测算法	46

4.2.3	迁移学习.....	48
4.2.4	数据增强.....	48
4.2.5	后处理.....	49
4.2.6	融合批标准化和卷积层.....	49
4.3	实验结果与分析.....	51
4.3.1	数据集.....	51
4.3.2	评价指标.....	52
4.3.3	实验环境.....	53
4.3.4	效果与分析.....	53
4.4	本章小结.....	55
第 5 章	融合分类和物体检测的表面缺陷检测算法	57
5.1	引言.....	57
5.2	算法.....	57
5.2.1	分类模型-改进的 ResNet50	58
5.2.2	物体检测模型-增强的 Faster R-CNN	62
5.2.3	focal 损失函数.....	65
5.2.4	数据增强.....	66
5.2.5	k-means++聚类算法	67
5.3	实验结果与分析.....	68
5.3.1	数据集.....	68
5.3.2	训练.....	72
5.3.3	评价指标.....	74
5.3.4	分类模型结果分析.....	76
5.3.5	物体检测模型结果分析.....	78
5.3.6	整体模型结果分析.....	80
5.4	本章小结.....	80
第 6 章	结束语.....	82
6.1	全文总结.....	82
6.2	展望.....	84
参考文献		85
致 谢		95
作者简历及攻读学位期间发表的学术论文与研究成果		97

图表目录

图 2.1	表面缺陷检测系统结构图.....	8
图 2.2	表面缺陷感兴趣区域.....	12
图 2.3	LeNet 模型.....	15
图 2.4	R-CNN 模型	18
图 2.5	Fast-RCNN 模型架构	18
图 2.6	YOLO 物体检测模型架构	19
图 2.7	Single Shot MultiBox Detector (SSD) 模型架构	20
图 2.8	FCN 整体架构简图.....	22
图 2.9	空洞卷积示意图.....	23
图 2.10	DeepLabV3+整体架构.....	25
图 2.11	PSPNet 模型	25
图 3.1	算法流程图.....	27
图 3.2	缺陷图片例子.....	32
图 3.3	P-R 曲线	34
图 3.4	P-R-F 柱状图.....	35
图 3.5	MAE 柱状图.....	35
图 4.1	算法流程图.....	38
图 4.2	模型框架.....	39
图 4.3	深度可分离卷积.....	42
图 4.4	MBConv 模块图.....	42
图 4.5	FPN 结构	43
图 4.6	Mish 激活函数图像	45
图 4.7	网络架构.....	46
图 4.8	输入和它的四个分割结果图.....	48
图 4.9	数据增强示例.....	49
图 4.10	每个缺陷类别有多少个图片.....	51
图 4.11	每个图片包含的缺陷种类数.....	51
图 4.12	数据集的数据样本.....	52
图 4.13	原始图像和最终输出.....	54
图 4.14	原始图像和缺陷.....	54
图 5.1	总体算法框架.....	58
图 5.2	ResNet 的残差模块.....	59
图 5.3	ResNet 和 ResNet-vd 对比.....	60
图 5.4	ResNet-50-vd 网络结构图	61
图 5.5	可变形卷积网络.....	62
图 5.6	faster R-CNN	62
图 5.7	9 个候选框 (anchor) 示意图.....	63
图 5.8	改进的 faster R-CNN 的架构	64
图 5.9	空间金字塔池化.....	65
图 5.10	数据增强.....	66
图 5.11	多个类别的表面缺陷样本例子.....	69
图 5.12	各种缺陷面积大小的统计结果.....	70

图 5.13	各种缺陷高宽比的统计结果.....	71
图 5.14	寻找学习率.....	72
图 5.15	分类模型损失.....	73
图 5.16	分类模型准确率.....	73
图 5.17	目标检测模型的损失.....	74
图 5.18	目标检测模型的 Bbox_map 值	74
图 5.19	测试时增强 (TTA) 后分类模型的混淆矩阵	77
图 5.20	ResNet_vd_dcnv2_Improvedcutout 模型的结果	77
图 5.21	检测结果.....	79
表 4.1	EfficientNet-B4 结构.....	40
表 4.2	EfficientNet-B0 网络结构	47
表 4.3	算法效果比较.....	55
表 5.1	分类模型使用的数据集.....	69
表 5.2	物体检测模型使用的数据集.....	69
表 5.3	使用 k-means++ 算法聚类算法得到的的锚的结果	71
表 5.4	混淆矩阵.....	75
表 5.5	分类模型效果对比.....	76
表 5.6	每种缺陷的 AP 和模型的 mAP	78
表 5.7	模型精度与平均运行时间的比较.....	80

第 1 章 绪论

1.1 研究背景及意义

近年来，全世界众多国家都出台了自己的制造业产业升级计划，典型的代表是德国的工业 4.0。制造业在我国既是国民社会经济中的支柱产业，而且也是我国推动创新以及产业升级的主战场。我国已经是世界上的制造大国，但还不是制造强国，因此，实现由制造大国向制造强国的转变，是新时期我国经济发展所面临的重大课题。我国为了可以使制造业继续迅速高质量的发展，在 2016 年的时候同样提出了中国制造 2025 的制造业发展蓝图，并且以智能制造作为主要发展方向。工业 4.0 及中国制造 2025 的提出都预示着我国制造业将从传统的生产方式向着智能化生产发展转型，数字化、信息化、网络化、自动化和人工智能等技术高速发展，云计算、物联网、移动互联网、大数据和机器视觉等已经成为传统制造业向智能制造业转型升级过程中必备的关键技术。

在中国制造 2025 这个战略中指出要更快的提高产品的质量，制定提升产品质量的实施计划。并且鼓励企业推广采用智能化检测设备。提高我国产品的鲁棒性、可靠性、适应性以及使用寿命，并具有国际同类产品竞争力。对于一个企业来说，产品质量是企业发展和竞争的基石。提高产品的质量对于企业十分重要。因此，在纺织工业、钢铁工业、汽车工业、智能制造、半导体以及高分子材料加工等众多的工业领域（Abueidda 等，2021），产品表面缺陷检测已经吸引了大量的研究人员对其进行深入的研究。例如钢板生产行业（罗新斌，2016），高端或关键基础材料生产过程中表面质量的检测与控制水平甚至可以直接决定国内企业的生存和发展能力。产品质量包含内在性能品质和产品外观质量，其中对于基础性原材料，表面质量尤其重要，因为一些表面缺陷的存在远不止对于产品外观的影响，其对于后延产品的机械性能、使用性能、成品率、管理和销售，甚至对于民族企业品牌价值沉淀都起到决定性的作用。目前检测手段的落后正是制约产品质量的关键所在。国内外各行业企业已经开始引进必要的检测手段，极力提升对产品质量的监控力度，进而提升产品形象来获得国内外市场的综合竞争力。随着当前国内劳动力成本的上升、产能需求的扩大、相关政策的支持以及众多的产业布局，基于机器视觉的智能产品缺陷检测等新型方法迅速崛起。基于机器学习的智能产品缺陷检测也将被越来越多的应用到现代化的制造业中。以基于机器视觉

的方法代替人工也将成为工业发展的必然趋势。

表面缺陷检测的研究始于 1960 年, 研究分为几个方面: 人工检测、涡流检测(李翰超等, 2020)、红外检测、超声波检测(谷艳红等, 2020)、X-ray 检测以及基于机器视觉的检测(郑彬等, 2020; 陈海永 等, 2016b; Aiger 等, 2010)。但是因为人工检测缺陷的方法容易受到检测工人的主观意识的影响准确率和稳定性都比较低。这种方法已经逐渐的被更加智能化的方法所取代。随着 1990 年以来半导体技术的迅速发展, 基于工业相机采集图像的机器视觉表面缺陷检测系统渐渐的在企业中普及应用。这种方法首先通过相机采集产品表面的缺陷, 然后通过机器视觉算法自动化的找到缺陷的位置并对其分类。尤其是近些年爆炸式发展的深度学习(Chollet 等, 2018)技术更是比其他的检测方法精度更高, 鲁棒性更好。对提升产品的质量具有重要的作用。

为进一步提升产品缺陷检测的自动化程度, 使用机器学习或者深度学习方法来进行检测已经成为了发展的方向。在工业生产过程中, 由人工来做测量和判断会因为疲劳、操作人员个体差异等产生误差和错误, 通过机器视觉(Ciptadi 等, 2013)的方法来模拟人来进行产品的缺陷检测能够增加效率和准确率因此研究基于机器视觉的产品缺陷检测算法对发展智能生产线有着至关重要的作用, 也是我国工业生产智能制造的关键一步。因此, 本课题研究机器视觉方法用于产品缺陷检测的研究有着重要的现实意义, 本课题的研究对实现智能制造具有重要的理论意义及实际价值。

1.2 国内外现状

随着科技的发展, 表面质量检查方法也发生了很大的变化。从依靠人工的目视检测、使用磁痕辅助人工的磁粉检测、利用毛细作用的渗漏检测、利用电磁感应原理的涡流检测最后到近二十年来迅速发展的基于机器视觉的方法逐渐的被研究人员一一使用(秦钟伟 等, 2019; 甘胜丰 等, 2017)。

目视检测是一种融合了对物体的客观视觉评价的表面质量检测方法, 这种检查方法直接使用人眼或者是借助光学设备对产品进行表面缺陷的检测。基于目视的检测技术是最早发展起来的, 在工厂的质量控制系统中占据着主导地位, 并且都有相应的检测标准、检测流程以及检测工艺。这种方法在几十年前的实际应用中有很多的有点: 只需要通过培训人们就能容易的就行理解和掌握; 产品的材料、

形状以及大小等很少影响检测结果；不需要复杂昂贵的检测设备；检测的结果十分可靠。这种检测方法也有一定的缺点：缺陷比较小则难以检测；对检测人员的经验状态等要求高。

磁粉检测(吴德会等,2017)是对金属材料的产品进行缺陷检测的一种方法。原理是如果材料的表面和内部都很均匀,没有缺陷,那么会在其内部产生分布均匀的磁力线,但是材料上如果有缺陷像孔洞、裂痕或者麻点等就会产生漏磁现象,能够通过观察发现问题(杨理践等,2020)。首先把产品磁化饱和,然后通过在工作件上弄满磁铁粉,漏磁的地方就会吸附大量的磁粉,人工很容易看出来。磁粉检测的方法有如下优点:很直观的展示出缺陷的位置、形状及大小等;灵敏度高;工件的形状等性质对方法的影响很小。(孙瑜等,2004)。但是其缺点也很明显:工件退磁很复杂,需要人工帮助;不能够快速的进行缺陷的检测。

渗透检测是一种利用毛细原理发明的一种表面缺陷检测的方法。首先把产品侵入渗透液,然后拿出来清除表面的多余液体,这样缺陷中还留有液体。然后利用毛细现象用显像液吸出液体,从而实现了检测缺陷。其中,着色渗透检测采用无味航空煤油、滑油、荧蒽等组成的渗透剂,配合清洗剂、显像剂作为检测耗材。渗透检测优点:磁粉检测仅可检测铁磁性材质,而渗透检测还可以检测非金属材料,检测范围大大高于磁粉检测的检测范围。但也 有其局限性:由于多孔性材料的缺陷图像显示难以判断,渗透检测并不适合多孔材料的表面缺陷。

涡流检测方法使用了物理中电磁感应的原理。当正弦波电流的磁线圈距离金属表面很近时,线圈的周围超生的交变磁场会在金属表面生成涡流。同时它还会生成一个和磁线圈生成的磁场方向相反的磁场。这样检测线圈就能感应到磁场的变化,使得检测电路的阻抗发生改变,这样就能检测出来变化。当磁线圈在金属产品的表面移动的时候,碰到表面缺陷的时候,检测线圈就能感应到不同,这样就能使用涡流检测设备发现这个变化,缺陷就能检测出来了。涡流检测的有点主要有:由于磁力对裂纹、麻点等缺陷都十分的敏感,因此都能够检测出来,灵敏度较高;不接触工件。其不足之处在于:不适用于形状复杂的零件;只能检测导电材料表面缺陷;检测结果易受到材料本身及其他因素的干扰。

传统的人工方法很费时间,并且检测的准确率很容易受检测者的状态、经验等影响。自动化的表面缺陷检测对于提高工厂产品质量检测的智能化程度、节省开支节省时间非常重要。因此越来越多的研究人员来研究基于机器视觉的表面缺

陷检测算法（王一鸣等，2019），并应用在很多的工业产品生产中，例如：玻璃制品，纺织物，钢表面，轴承滚子，铸件表面。随着机器视觉算法的快速发展，基于视觉的通过摄像机获取图像的自动检测技术在表面缺陷检测中得到了广泛的应用（赵宇峰，2012）。这些算法大致分为三类：基于图像结构特征的传统方法、基于统计特征的机器学习方法以及基于卷积神经网络的深度学习方法（Luo 等，2020）。

传统的表面缺陷检测方法主要通过分析表面缺陷图像的纹理、骨架、边缘和光谱等结构特征。目前最常使用的图像处理技术有：Gabor 滤波（陈海永 等，2016a；Liu 等，2011）、局部二值模式（LBP）（Liu 等，2018）、阈值分析（郭皓然 等，2017）、边缘检测、混沌理论（王卓 等，2020）、Sobel（Shi 等，2016）以及小波分析（汤勃 等，2020；Liu 等，2014）等算法以及其改进方法。Medina 等（2017）提出了一种旋转不变 Gabor 滤波器用于缺陷图像处理，能够检测出各种方向的缺陷。周鹏等（2015）研究了一种结合剪切波变换和小波变换特征的表面缺陷检测方法。这种方法通过分析物体表面的结构学特征可以检测和分割缺陷。算法首先对图像进行剪切波和小波变换，接着对变换生成的子带计算平均值以及方差，并把结果组成特征向量。最后通过降维算法去除多余的特征，把处理过的特征向量输入到 SVM 中进行缺陷的分类。Zhang 等（2014）展示了一种自动铁轨缺陷检测和分类的方法。使用高速工业相机获取铁轨表面的图像，然后形态学和阈值分析从图像中分割出潜在的缺陷。接着使用基于距离直方图的能高效区分有缺陷和其他不相关的物体的形状描述子来提取特征。Liu 等（2019）提出了一种改进的多尺度快的局部二值模式（MB-LBP）方法。这个算法只是用了简单高效的 LBP 方法，但是它能够通过改变块大小快速的找到一个合适的尺度去描述缺陷特征，能够得到比较高的准确率。

融合了统计学特征和机器学习的方法主要是提取缺陷表面的统计学特征然后使用机器学习算法去学习这些特征来实现表面缺陷检测。通常使用的方法有：支持向量机（SVM）（郭慧 等，2018）、人工神经网络（ANN）（李炜 等，2003；Kang 等，2005）以及 Adaboost 等方法。Wang 等（2019）展示了一种基于支持向量机和新的无监督分类算法进行缺陷检测。该方法分为步骤：使用支持向量机和点云模型来提取表面缺陷的位置和形状，然后使用新的无监督分类算法名字叫扩展算法来对缺陷进行分类，并对缺陷数量进行识别，最后使用协方差矩阵三维测

量方法计算缺陷尺寸。Cao 等（2019）研究了在有限的数据集和噪声环境下，由于光照条件不稳定导致缺陷的检测算法，同时引入了特征向量来描述缺陷问题。最后利用特征向量和神经网络，能够成功的检测和分类管的表面缺陷。Ding 等（2011）通过融合 HOG 和 SVM 方法检测 表面缺陷。首先，利用对光照和噪声不敏感的方向梯度直方图（HOG）对图像的每个基于块的特征进行编码。然后，采用一种强大的特征选择算法 AdaBoost，自动选择一小部分有区别的 HOG 特征，以获得鲁棒的检测结果。最后利用支持向量机对织物表面缺陷进行分类。

随着 20 世纪以来深度学习（Lim 等，2016）技术的飞速发展，尤其是深度学习强大的自动特征提取的能力，在图像相关的工作中应用越来越广泛。这些图像相关的工作包括：图像分析、语义分割、物体分类、物体检测以及目标追踪等（Mikołajczyk 等，2017a；Liu 等，2019；Mikołajczyk 等，2017b）。深度学习被证明能够在不使用人工设计的特征的情况下自动的学习深度的稳定的特征。再多个领域展现出了最先进的性能，例如：图像分类、物体检测以及像素级别的分类（Prappacher 等，2020）技术。同时越来越多的研究人员把这个技术应用到表面缺陷检测的研究工作中用以替代传统的以及基于机器学习的方法来获得更高的准确率和鲁棒性同时提升生产效率和产品质量。使用基于深度学习的方法能够实现端到端的表面缺陷检测，输入一个图片输出缺陷的位置和类别。目前应用于缺陷检测的深度学习算法主要包括：自动编码器、生成式对抗网络（GAN）以及卷积神经网络等。Di 等（2019）结合使用卷积自编码器（CAE）以及半监督生成式对抗网络（SGAN）提出了一种新的半监督学习方法 CAE-SGAN。使用 GAN 能够提高再有限的样本情况下的性能，使用自编码器来进行提取图像特征。Schlegl 等（2017）研究了一种基于深层生成对抗网络的异常检测方法（AnoGAN），并提出了一种新的基于图像空间到空间映射的缺陷评分方案。Lee 等（2019）提出了一种基于 CNN 和类激活图的缺陷分类方法。它可以实现一个实时的决策过程。Tabemik 等（2020）提出了一种基于图像分割的网络结构，可以用较少的样本训练网络。这更适合工业环境。基于物体检测的表面缺陷检测算法主要分为两类：单阶段和两阶段方法。单阶段方法的主要代表是 YOLO 算法（李维刚 等，2020）。例如，Li 等（2018）改进了 YOLO 算法，它包含 27 个卷积层，可以提供端到端的解决方案。它可以同时预测缺陷的位置、大小和类别。两阶段的表面缺陷检测方法主要代表是快速区域卷积神经网络（Faster R-CNN）（Wei，2020）。首先对图

像使用候选区域方法，选择可能存在目标的区域，然后将第一步中作为正样本的候选图像作为子图像进行分类定位。Oh 等（2020）提出了一种基于 Faster R-CNN 的方法。他们使用 Inception-ResNet-V2 和数据扩充来提高模型的准确性。

1.3 课题研究内容

本论文为基于机器视觉的产品表面缺陷检测关键算法研究，研究内容总结如下：

1. 提出了一种基于区域特征聚类显著性检测的表面缺陷分割算法。针对传统的基于机器学习的表面缺陷检测算法中准确率低、鲁棒性弱的问题。本文提出了一种基于区域特征聚类显著性检测的表面缺陷分割算法。

2. 提出了基于 U-net 和迁移学习的表面缺陷检测算法。针对当前对缺陷形状和大小后期进行数据分析的需求，提出了基于深度学习的图像分割算法。当前的深度学习图像分割算法在提高精度和减少计算量方面仍有很大的空间。采用迁移学习或改进算法，可以提高学习精度，取得较好的效果。将批归一化（BN）层合并到卷积层中，可以减少计算量。

3. 提出了一种基于迁移学习和多尺度特征融合的表面缺陷检测算法。这种深度学习模型是一种端到端的表面缺陷检测算法。它由基于高效网络的主干网、自顶向下的特征金字塔网络（BiFPN）和基于反卷积网络的多尺度特征融合组成，以产生最终的输出。最终输出是四个与输入大小相同的分割图，表示四类缺陷。由于 Mish 激活函数能够获得更好的梯度并且不出现饱和现象，因此本文中的激活函数使用了 Mish，进而使得模型更准确泛化性更好。

4. 提出了一种将分类与目标检测模型相结合的表面缺陷检测算法。基于深度学习的分类方法只能对图像进行分类，不能确定缺陷的位置和大小。这对以后的数据分析有很大的影响。基于 GAN 和强化学习，很难训练出一个稳定、准确的模型。本章实现了钢板表面缺陷的自动检测和定位，进一步提高了算法的精度和稳定性，减少了算法的平均运行时间。

1.4 论文组织结构

本论文为基于机器视觉的产品表面缺陷检测关键算法研究，一共分为六章，具体如下：

第一章，绪论，详细的说明了本课题的研究背景和意义，然后从表面缺陷检测算法的研究现状进行了深刻的分析。最后对本课题的研究内容和论文的组织结构进行了详细的说明。

第二章，产品表面缺陷检测算法基础，第二章为算法基础的介绍。主要是对表面缺陷检测理论、显著性检测理论、深度学习理论等进行了阐述，为后面的章节提供理论支撑。

第三章，本章提出了一种基于区域特征聚类显著性检测的表面缺陷图像分割算法。并使用东北大学钢铁表面缺陷数据集对算法进行分析，并与其他六种算法进行对比。结果显示本文算法准确率最高。

第四章，本章提出了两种基于迁移学习和图像分割的算法。第一种：基于迁移学习和多尺度特征融合的表面缺陷检测算法。第二种：基于 U-net（Olaf 等，2015）和迁移学习的表面缺陷检测算法。本章详细的论述了这两个算法增提技术方案，并展示了缺陷检测结果。最后使用公开数据集对算法进行总结分析。

第五章，本章提出了一种融合分类和物体检测的表面缺陷检测算法。它可以增加准确率并且减少平均运行时间。首先对算法的整体框架进行了分析，然后分别详细阐述了改进的分类模型和改进的物体检测模型。并展示了缺陷检测的效果。最后对实验的结果进行了详细的分析。

第六章，总结和展望，总结本文的研究工作，同时对未来的研究方向进行展望。

1.5 本章小结

本章为前言部分，详细的说明了本课题的研究背景和意义，然后从表面缺陷检测算法的研究现状进行了深刻的分析。介绍了各种类型的前人的研究方法。最后对本课题的研究内容和论文的组织结构进行了详细的说明。

第2章 表面缺陷检测算法基础

2.1 引言

本章对表面缺陷检测、视觉显著性以及深度学习进行基础性阐述。为后面算法部分提供理论基础。

2.2 表面缺陷检测系统

表面缺陷检测系统通用结构如图 2.1 所示，其中有三个主要部分组成图像采集模块、信号控制模块以及缺陷检测模块。图像采集单元由上下表面两组 CCD 组成，一组采集上表面图像，另外一组采集下表面图像，每组 CCD 根据可采集范围和板带材宽度设置摄像头个数。每台 CCD 配图像处理卡、高强度光源，实时采集线材表面图像；信号控制单元是硬件控制模块，由 PLC 或控制类硬件组成，主要是将检测所需要的速度、生产数据、图像处理卡中的信息控制传输至图像检测与分类服务器，同时检测图像检测与分类服务器中的参数并传输至图像采集单元中。图像检测与分类服务器由计算机组成，主要将捕获到的图像中表面不连续的部分或与背景显著不一致的部分隔离开来，判断是否疑似缺陷，同时控制摄像头对缺陷的采集并显示缺陷图像或将缺陷图像提供给其他生产环节。




图 2.1 表面缺陷检测系统结构图

Figure 2.1 Structure diagram of surface defect detection system

2.2.1 表面缺陷图像采集

钢铁表面缺陷检测系统的两个关键组成部分是成像和检测灯光。灯光最具代表性的成像方法有激光扫描、线阵 CCD 扫描和面阵拼接成像 CCD 激光器扫描法具有扫描速度快的特点，但由于其获得的图像缺乏实用性激光扫描法，钢材表面缺陷的图像采集通常采用线阵 CCD 扫描检测和面阵拼接成像的方法 CCD 照明钢材表面缺陷图像采集装置采用均匀光源。均匀的光源可以保证带钢表面照度的均匀性，减少外界光线对图像采集的影响。常用的光源有闪光氙气光源、LED 及其棱镜照明装置、光学平行光源、，等等，根据钢材的工作条件，采用不同的照明装置和照明方法，可以获得钢材表面缺陷的图像。

面阵 CCD 图像采集效率高，后续图像处理算法简单，但对光源的均匀性要求较高。考虑到图像拼接的准确性，图像中也存在大量的冗余数据处理、检测钢材运行方向的速度和分辨率也是一个平衡的方向，特别是非垂直检测时，图像会有很大的失真，采集水平图像时会出现梯形失真，采集圆弧图像时会出现圆弧失真。

线阵 CCD 在采集时具有较小的畸变误差和光学不均匀性图像。在那里无论是水平图像还是弧形图像都没有失真收购另外，它具有数据冗余度低、成本低等优点，其扫描频率的提高也解决了钢材的速度限制操作。但是，调整对光源与 CCD 之间的位置关系和机械关系要求很高，而线阵 CCD 对固定检测点的位置要求也很高，这就要求将振动、细水雾等因素的干扰降到最低。

2.2.2 挑战

表面缺陷检测在生产过程中面临以下严峻挑战：

1、产品的表面有很高的反射率。金属和其他表面光滑的材料它们的表面拥有很高的反射率这样就会在获取图像的时候采集的高光影的区域。这样会导致采集的图像灰度分布不均匀，这样就可能引起产品边缘的错误检测。

2、存在一定的伪缺陷干扰问题。在钢板等生产过程中会有水滴、雨水线等伪缺陷，这些水渍样的特征并不会影响材料的品质但是它们会影响缺陷检测的准确率等。

3、钢板会在生产中存在随机弹性变形问题。随机弹性变形会在 CCD 相机采集图像时产生随机图像失真。

4、生产线的高速运行会产生海量图像数据。因为生产线的高速运行会在每

分钟 CCD 相机采集大量的图像数据，这样就需要检测算法能够快速实时的进行缺陷检测。

2.2.3 发展趋势

从国内外的研究和文献来看，基于机器视觉的钢铁表面缺陷检测的发展趋势可以概括如下。

1、整个机器视觉钢铁表面缺陷检测框架是多样化。机器视觉钢铁表面缺陷检测从最初的低端粗放型结构逐渐演变为较为完善的高端、涉及多方面的工作体系。随着工业化的发展，系统的整体结构应该朝着操作方便、显示人性化、图像清晰度高的方向发展。

2、优化和升级图像系统的硬件结构。图像硬件产品结构开发研究的主要成果是获得清晰的二维表面缺陷图像，在检测速度和图像数据处理速度上取得了重大突破，实现了更大的动态管理范围和更快的图像信息采集，进一步提高了采集与服务器之间的交流学习能力。随着图像采集硬件和电子设备的进一步升级，具有清晰图像和三维空间特征的三维图像采集与处理将成为钢铁图像检测硬件的发展趋势。

3、本文对图像检测算法进行了改进和创新，并将其应用于机器视觉钢铁表面缺陷检测。图像处理硬件设备的发展将对图像处理算法提出更高的要求。新的数学教学方法如小波变换、非线性降维等的出现和成熟，将迅速推动其发展。不同的数学方法是有方向性的，不能适用于所有情况。因此，将多种算法结合起来，优化算法的应用范围，提高企业应用效果，已成为国内外算法研究方法的主要发展趋势。

4、在实际应用中应注意的问题和算法的兼容性。在实际生产中，由于环境变化引起的问题很多，如相似缺陷图像的可变性；高反射金属表面缺陷检测不足；生产过程中钢材经常出现水渍和油渍；对可视化数据采集和处理的突然大量需求；超高速状态下，检测执行部分的能力足够。近年来，如何找出影响算法效果的主要因素并对算法进行合理的改进成为研究者关注的焦点。

2.2.4 图像预处理

图像预处理其实就是给图像去噪的过程，因为在图像的采集过程中、处理过程中一般都会产生一定的噪声，主要产生的原因有：钢铁在生产的过程中有对钢

铁表面及载体的干扰随意影响了产品,增强了产品表面光学性能的随机性,这样就产生了很多的噪声;工厂生产的过程中有大量的工业粉尘、生产环境中同时也漂浮着杂质、生产线有电磁噪声干扰等;设备产生的噪声,包括 CCD 的特性,如 A/D 转换中元件的不均匀性,光电转换过程中的量化噪声,传输过程中的人为因素和误差。

这些因素都会给钢材缺陷带来干扰,影响采集到的图像质量。图像主要噪声类型有以下几类。

1、高斯噪声和椒盐噪声。噪声的振幅分布为高斯分布的噪声称高斯噪声,主要由电子设备中的阻性元器件内部产生。噪声的振幅分布为泊松分布的噪声称椒盐噪声,主要在光电转换的过程中产生。

2、加性噪声和乘性噪声。前者与输入图像无关,含噪图像可表示为 $f(x, y) = g(x, y) + n(x, y)$ 后者往往随图像信号的变化而变化,其含噪图像可表示为:

$$f(x, y) = g(x, y) + n(x, y)g(x, y) \quad \dots (2.1)$$

式中: $f(x, y)$: 混有噪声的图像;

$g(x, y)$: 未被噪声污染的理想图像;

$n(x, y)$: 一图像中混有的噪声。

高斯白噪声是图像中最常见的一类加性噪声,而椒盐噪声一般表现为乘性噪声。

2.2.5 感兴趣区域检测

虽然钢材的表面有无缺陷都很清晰,但是如果直接对采集到的表面图像进行分析,那么会占用大量的存储空间以及计算量非常大,不能满足对缺陷的实时性检测。感兴趣区域检测是快速搜索产品采集的图片里有没有疑似缺陷的区域,是钢材表面缺陷检测系统应具有的基本功能,除了感兴趣的区域以外的部分都不需要进一步的分割和特征提取任务。如果某区域钢材图像中没有疑似缺陷存在,该区域图像就不需要进一步的处理。因为产品表面的绝大部分区域都没有缺陷都是合格的,因此经过感兴趣区域的检测只留下的少部分的区域,因此计算量大大的减少了,但感兴趣区域提取方法需要尽可能准确地提取所有缺陷图像以备后用。由于这个方法需要检测大量的区域而且其中绝大多数都是无缺陷区域,因此这个

步骤不能使用计算量大的算法，要能实时的检测，因此这个算法要实时的稳定的检测出感兴趣的区域。检测算法的不同会使检测的准确度和精度明显不同，影响系统的性能。钢材表面缺陷感兴趣区域检测如图 2.2 所示，从图像处理的角度来说，感兴趣区域检测的目的是要用最少的时间检测出来疑似的有缺陷的区域，这样的区域会影响整个区域的对比度的特征，使得区域的对比度产生了异常。所以，感兴趣区域的检测一般来说都是先估计出无缺陷的区域的对比度关系，然后就能计算各个区域与这个标准之间的对比度距离，最后就能使用这个距离值检测出感兴趣的区域。比较常用的感兴趣区域检测方法有投影方法以及背景差分法。




图 2.2 表面缺陷感兴趣区域

Figure2.2 Region of interest for surface defects

2.3 显著性物体检测算法用于表面缺陷检测

人类视觉注意的机制是当观察到一个场景时，人类视觉系统会自动分析和处理感兴趣的区域，同时选择性地忽略不感兴趣的区域（Li 等，2016）。这些是人们自己称之为显著区域的感兴趣区域。视觉显著性检测（Peng 等，2014）是通过模拟人类视觉从图像中提取显著区域。人类视觉注意主要有两种机制（Zhang 等，2017）：基于信息数据的自底向上驱动机制：在感知系统数据的驱动下，人类视觉注意可以被引导到图像或场景中的显著性影响区域；利用这些图像的亮度、边缘、颜色等特征，可以判断它们之间的差异将企业目标与周边区域进行对比（Zhang，等 2015），然后计算显著性。自上而下的任务驱动目标机制：人类认知

因素决定图像的具体特征，计算图像区域的重要性。

一般来说，对于一个好的视觉显著性检测系统模型，我们至少需要满足以下三个标准：好的检测率：丢失实际显著性区域的可能性要小，错误地将背景标记为显著性区域的错误要小。高分辨率：生成的显著图像需要高分辨率，才能准确定位显著目标并保留原始图像信息。计算效率：作为企业中其他复杂流程的起点，这些数据模型应该能够快速发现重要区域。

对于图像，用户只对图像中代表用户查询意图的部分区域感兴趣，而其他大部分感兴趣区域与用户的查询意图无关。显著区域是能够引起用户兴趣并代表图像内容的区域。事实上，显著改善区域的选择是非常主观的。由于企业用户管理任务的不同和知识经济的背景，对于同一个形象，不同的用户可能会选择通过不同的区域发展为一个重要区域。常用的方法是基于人的注意机制来计算图像的显著性。认知心理学的研究表明，图像中的某些区域能够显著地吸引人们的注意力，这些区域包含了大量的信息。认知科学家已经提出了许多数学学习模型来模拟中国学生的注意机制。由于在图像认知过程中使用了一般的规则，因此用这种方法提取的显著区域更符合人们的主观评价。

目前，国内有越来越多有意义的分析算法（Zhu 等，2014；Zhu 等，2016），有人对这些数据算法进行了分类。目前，显著性分析算法可分为三类：第一类是基于底层视觉特征的显著性分析算法，其代表算法是 ITTI 算法，这是一种模拟生物视觉注意机制的选择性注意算法，更适合于自然图像的处理。二是纯数学模型计算的教学方法，不以任何生物视觉设计原理为基础。这类问题主要包括基于网络空频域数据分析的全分辨率算法（AC 算法）和残差谱算法（SR 算法）。第三种是前两种方法的融合。代表性算法是基于图形算法（gbvs 算法）的。该算法类似于 ITTI 算法在函数提取过程中模拟视觉原理，但在重要图形生成过程中进入 Markov 环节，通过纯数学计算得到显著值。

2.4 深度学习基础

2.4.1 卷积神经网络

卷积神经网络（He 等，2015）是一种特殊的深度前馈神经网络。使用全连接的神经网络在处理图像信息的时候有大量的参数冗余，而导致参数量过多使得模型需要大量的样本进行训练。卷积神经网络为了解决这个问题提出了卷积的方

法来共享参数，这种方法和人类神经元的稀疏特征类似。神经网络层间的稀疏连接，例如在生物视觉神经网络系统中，大量的神经元，只有在一定的局部区域受到刺激才能激活神经元，从而大大降低了网络模型的参数规模和训练数据量的需求。

从生物神经研究的角度来看卷积神经网络的发展可知，1960s 年代研究人员提出了感受野这个概念；之后到了 1980s 提出了神经认知机这一卷积神经网络的前身。神经认知机将一个图像分解成若干个特征，然后对他们进行处理，它能够再物体有位移或者形变的时候也能够识别。人类的视觉皮层分类初级、中级和高级，每一层又有简单细胞和复杂细胞。其中的简单细胞感受野小，对边缘和直边敏感；复杂细胞有更大的感受野具有平移不变性。这便是卷积神经网络的设计灵感的来源。

一个卷积神经网络通常由四种操作卷积、池化、激活函数以及批标准化组成。其中的卷积层的关键理论是使用权值共享来减少大量的权值连接，同时在减少参数量的同时相对的提高了数据量的占比，进而可以减少过拟合现象的发生。又因为卷积层具有平移的不变性，因此通过卷积学习到的特征更加的稳定，效果更好。

本质上，池化操作执行的是特征的聚合，降低特征维度，通过池化操作能够通过减小下一层卷积等操作中特征图的大小而大大的减少计算量，同时也能使得模型对目标的平移不敏感。同时应用了池化操作的模型中能够一定程度的减少过拟合。常用的池化操作有：最大池化（MaxPooling）、平均池化（AvgPooling）、对数概率池化以及范数池化等。除了上面所列举的池化方式外，还有空间金字塔池化，它是一种多尺度的池化方式，可以获取输入的多尺度的信息。

激活函数的提出主要是增加深度卷积神经网络的非线性特征，这样就能显著的提高模型的拟合能力。若模型中没有这种激活函数似的非线性的计算，再多的卷积池化等层组合的也是非线性的，这样就不能很好的提取图像的特征。比较常见的激活函数有如下几个：修正线性单元 ReLU（它能够加速模型的收敛，并且它拥有稀疏性）、Softmax（通常应用于模型的最后一层，能够计算各种概率）、Softplus 函数（它是一个比 ReLU 激活函数更加光滑的激活函数）以及 Sigmoid。

批标准化（Batch Normalization）简称 BN（Ioffe 等，2015），它的出现是减少随着神经网络层数的增加导致的模型很难训练和收敛的问题。总所周知模型需要训练样本和测试样本同分布模型才能拥有更好的泛化性能。但是深度神经网络

中的每一层的输入经过操作后得到的特征图和输入的特征图不是同分布了,模型越深这个问题越大。为了解决这样的问题,就需要想办法使得样本同分布,这就出现了批标准化批标准化能够使得某些层或者所有层的输入规范化,进而使得每层输入信号的均值与方差都变得固定。

2.4.2 图像分类

图像分类是计算机视觉任务中最为基础的研究,其算法的发展也对目标检测、图像分割等产生积极的影响。最初的简单 10 分类任务 MNIST,到后来的 10 分类 cifar10 和 100 分类 cifar100,再最后到 Imagenet 任务。图像分类模型的发展历程也伴随着数据集中数据量的增加,并且最终达到了今日的规模。图像分类其实就是一个模式分类的问题,它的目标是把图像按类别分开,并实现最好的性能指标。图像分类的研究工作经历了传统方法到基于深度学习方法的转变,经历了几十年的发展。下面介绍几个比较重要的图像分类模型:

LeNet (Lecun 等, 1998) 初次被研究于 1994 年,后来经过多次的改进才有了我们常见的 LeNet5。LeNet 模型对深度学习的发展起到了关键作用,它是最造的关于深度学习的研究。其中的卷积操作、池化操作以及非线性激活函数等理论至今都在影响着深度学习的发展。




图 2.3 LeNet 模型

Figure2.3 LeNet model

AlexNet (Krizhevsky 等, 2012) 是公认的第一个真正的深度卷积神经网络。它比 LeNet5 的 5 层相比,它增加了额外的 3 层,这样就增加了参数量。那个时期使用 GPU 进行训练也发展起来了,极大的推动了深度学习的发展。AlexNet 的特点有:网络层数比 LeNet5 更多,它拥有 5 个卷积层以及 3 个全连接层。由于

在卷积层后面直接增加了 Relu 激活函数，所以模型收敛更快，同时避免了使用 Sigmoid 激活函数在更深的神经网络模型中导致的梯度消失的问题。为了减少过拟合对模型训练的影响模型中增加了 Dropout 层。因为早期的数据集都比较小，因此为了增加样本多样性使用了数据增强的操作。这些改进都使得模型的泛化性能更好。

VGGNet (Simonyan 等, 2015) 有 VGG16 和 VGG19 两个模型，他们的参数量差不多达到 550M。模型中的卷积都是 3×3 卷积核的卷积以及 2×2 最大池化层的池化层，统一的卷积和池化层使得 VGG 模型十分的简单。VGGNet 展示了如何通过简单地增加网络层的数量和深度来增加神经网络的性能。VGG 模型比其他最新的模型都更加的简单，但是对分类任务以及特征提取也会在模型中见到。尤其是分类模型的研究中都依然会把 VGG 模型作为对比对象。

GoogLeNet (Szegedy 等, 2015) 由谷歌公司的 Christian Szegedy 等人研究来的，它一共由 22 层的卷积。因为其架构在当时十分的先进，他在数据集中得到了 top-5 错误率 6.7% 的好成绩。GoogLeNet 最核心的改进是 Inception Module，它使用一个并行的结构进行特征提取。一个经典的 inception 结构由四个部分组成。其包括 1×1 的卷积层， 3×3 的卷积层， 5×5 的卷积层以及一个 3×3 的最大池化层，然后把四个部分的输出融合在一起。就得到了 inception 结构。这样的利用多种大小的卷积核获取到特征图的方法，能够提取到更为详细的特征，对大小物体都适用。

2015 年，ResNet (He 等, 2016) 获得了分类任务冠军。它以 3.57% 误识率的结果超过了人类视觉系统的水平，其最大的模型 ResNe-152 也创造了当时最深神经网络的记录。ResNet 创新性的提出了跨层连接的模块，这个简单的跨层连接能够大大的缓解深度神经网络模型中的梯度消失问题，为训练更深的模型提供了可能由于。

基于 ResNet 的 DenseNet 使用了密集连接，通过将前馈路径上的每一层与其他层连接在一起。在每一层中所有前面层级的特征图都被作为输入并把其输入到下面的层级中作为输入。使用了密集连接的 DenseNet 也能够减少梯度消失的问题，使得特征的传播和重用更加有效，同时减少了模型所需要的参数数量。DenseNet 与 ResNet 相比它的参数量和运算量更小，但是性能更好。

2.4.3 物体识别

物体识别（赵永强等，2020）模型能够检测出来一个图片中的多个物体，并且能够把物体进行定位，用边界框框出物体位置。物体识别的主要研究目的是使定位以及分类更准确，同时还要减少模型的运行时间。近些年来好多的模型研究都朝着这些目标进行。例如：R-CNN 系列、R-FCN、YOLO 以及 SSD 等，它们都对物体识别的研究做出了很大的贡献，从准确率以及运行速度上都得到了很大的提高。现阶段最优的目标检测算法都是基于深度学习的，它们主要被分为两类：一类是两阶段的目标检测算法，主要有 R-CNN 系列；另一类是一阶段的目标检测算法，主要包含 YOLO 和 SSD 系列。第一类是首先使用算法产生很多的图像的目标候选框，然后在使用卷积神经网络对候选框内的特征图进行分类并对边界框进行进一步的优化；第二类的一阶段的方法不生成候选框，直接再特征图上的边界框回归增高其精度并且进行分类。由于两种方法有根本上的差异，因此再效果是也不同，两阶段的算法准确率更高物体定位更加精准，一阶段的算法检测速度更快。接下来简要介绍了这些方法的主要思想和网络结构。

2.4.3.1 R-CNN

在介绍 R-CNN 之前首先要介绍一下选择性搜索（selective search）简称 SS。由于使用暴力的方法进行感兴趣区域选择太消耗计算资源，因此一般都是使用候选区域的方法（region proposal method）来获取到目标检测算法的感兴趣的区域（RoI）。选择性搜索是这样做的，首先把所有的像素都单独的当作一组，然后计算这些组的纹理，并把相近的纹理的两个组合并起来。但是为了阻止一个组把另外几个组合并需要把较小的组先进行分组。重复的合并各个组，知道所有的组都连接起来。

R-CNN 算法中使用候选区域方法生成了大概 2000 个候选区域。生成的这些区域首先使用 `Resize` 方法把他们的大小变换成一个固定的值，然后把他们输入到卷积神经网络中。这个用于分类和边界框回归的模型最后会使用几个全连接层。由于 R-CNN 使用的这种能够生成高质量的 RoI 的方法，所以与使用滑动窗口的方法相比，速度更快准确率更高。如下图所示，图像首先经过候选区域算法选择出感兴趣的区域（ROI），然后把每个感兴趣的区域先进行改变大小操作，并输入到分类器重，最后对该区域进行分类和对边界框进行回归获取到更准确的边界框。




图 2.4 R-CNN 模型

Figure2.4 R-CNN Model

R-CNN 只有在选取了大量的候选区域后才能获得比较高的准确率，但是在选择候选区域的时候会产生很多重叠的候选区域。所以 R-CNN 在训练和推理的时候都非常慢。如上所述一般都是选取 2000 个候选区域，那么每一个都需要输入到卷积神经网络中进行分类和边界框回归，需要大量的计算资源。要运行 2000 次。

Fast R-CNN 的提出解决了上面 R-CNN 的重复的特征提取的过程。Fast R-CNN 提出了特征提取器方法，首先提取整个图片的特征图，而不是像 R-CNN 一样从头开始对每个图像块提取多次。然后，使用候选区域方法在特征图上选取候选区。Fast R-CNN 就利用了 VGG16 网络模型中的第五组的卷积层输入的特征图来生成感兴趣区域。然后使用 RoI 池化层将感兴趣区域转换成固定的大小，并输入到全连接层进行分类和边界框定位。由于 Fast-RCNN 使用了全局的特征提取办法不会重复提取特征，所以它能够明显的减少算法的运行时间。如下图所示：




图 2.5 Fast-RCNN 模型架构

Figure2.5 Fast-RCNN Model

Faster R-CNN (Ren 等, 2016; Zhou 等, 2019) 采用与 Fast R-CNN 相同的设计, 只是它用内部深层网络代替了候选区域方法。这种新型的候选区域网络 (RPN) 模块能够以更高的效率生成 ROI, 而且每张输入的图像都能够在 10ms 左右完成候选区域选取。RPN 是用于提取候选区域的神经网络, 它提取候选框的方式是使用滑动窗口, 每个窗口的位置需要生成 9 个不同大小不同高宽比的候选框, 并且提取出相对应的 9 个候选框 (anchor) 的特征图, 用这个特征图来进行目标分类和边框回归。对于 $\text{IoU} \geq 0.7$ 的标记为前景样本 (正样本), $\text{IoU} < 0.3$ 的样本标记为背景样本 (负样本); 其他的为丢弃, 为边界样本。RPN 中还采用了两种损失函数, 分别是分类误差函数和前景样本窗口位置偏差函数。这有效地提升了损失函数的效果。

2.4.3.2 YOLO

YOLO (Redmon 等, 2016) 模型的主要思想是直接把全图输入到网络模型中, 然后直接在输出层输出目标的边界框的位置和边界框中目标的类别。faster RCNN 虽然和 YOLO 一样直接把整个图像输入到模型中, 但 faster RCNN 仍然和 R-CNN 一样, 候选区域使用分类模型进行分类和边界框回归, 在卷积神经网络中实现提取候选区域, 而 YOLO 则采用直接回归的思路。




图 2.6 YOLO 物体检测模型架构

Figure2.6 YOLO object detection model architecture

如上图所示, 使用 YOLO 模型来进行物体检测, 他的流程如下: 首先将图像 resize 到 $448 * 448$ 作为神经网络的输入; 然后通过运行神经网络, 得到一些边界框坐标、框中由检测到的物体的置信度和每个类别的概率。运行非极大值抑制算法 (NMS) (Neubeck 等, 2006), 筛选边界框。

YOLO 目标检测模型与以前的模型相比由很多的优点比如: 1、YOLO 模型进行目标检测比 R-CNN 系列都快, 同时它也是一个端到端的模型, 输入一个图

像直接能得到检测结果，算法检测流程简单。2、YOLO 模型能够通过学习背景信息避免背景的分类错误，与其他的使用滑动窗口的模型相比获取到的特征更为全面。YOLO 模型在训练以及测试的时候都可以使用整个图片的特征，因此能够更好的使用上下文信息，得到更好的背景和物体的区分。3、YOLO 模型能够更好的学习目标特征，对于自然图像来说 YOLO 模型能够更好的进行检测。YOLO 模型拥有这么多的优点的同时也有一些缺点：比如 YOLO 模型的目标检测精度低于其他最新的目标检测模型。YOLO 算法比较容易的输出定位错误的物体。最重要的是 YOLO 检测小物体的效果不太好，尤其是一张图中小物体比较多的时候。

2.4.3.3 SSD

SSD(Liu 等, 2016)由 Liu Wei 等研究出的，它的英文名为 Single Shot MultiBox Detector 是目标检测模型中的单个阶段的检测算法。SSD 创新性的使用小的卷积核在特征图上预测物体的类别和边界框的偏移。这种方案使得它在速度和精度方面都比 YOLOv1 好，并且精度和 Faster RCNN 类似。




图 2.7 Single Shot MultiBox Detector (SSD) 模型架构

Figure2.7 Single Shot MultiBox Detector Model architecture

为 SSD 算法的整体流程，首先输入一个 300x300 的图像，图片经过特征提取网络生成不同尺度的特征图。SSD 使用其中的 6 个作为有效的特征图。接着 SSD 对这些特征图进行目标位置和类别信息的提取，并合并多个特征图的结果。最后使用 NMS 算法选出最优的结果。就这样，SSD 算法得到了不同尺寸特征图

的特征映射，接着会把多尺度的特征图同时的进行目标的检测。这样的操作因为使用了多尺度的特征图，因此 SSD 算法的运算量和检测准确率都提升了。我们知道根据特征图往输入图片上映射候选框会根据特征图大小进行不同比例的映射，也就是说前面的特征图，比如第一个有效特征层和第二个有效特征层映射的候选框偏小，可以用来检测小物体；第三个有效特征层和第四个有效特征层映射的候选框尺寸中等，可以用来检测中等大小的物体，而第五个有效特征层和第六个有效特征层映射到原图的候选框偏大，则可以用来检测大物体。

2.4.4 语义分割

图像语义分割（Wang 等，2020；田启川等，2020）是把输入的图片里面的所有像素都分到一个语义类别中，最终得到对物体的分类和分割图像。通常情况下一个语义分割的网络模型是由一个编码器和一个解码器组合成的。编码器一般是一个使用其他大型的数据集与训练的用于分类的卷积神经网络编码器，比如 VGG 或者 ResNet，用于提取特征。解码器网络用于融合编码器网络生成的特征图，得到分割的结果。下面介绍的各种分割模型不同的地方主要在解码器中。和分类任务中输出是属于某一类的概率，语义分割是对所有像素各个进行分类。语义分割的主要代表有：全卷积神经网络(Fully Convolution Networks)简称为 FCN、U-net（Ronneberger 等，2015）系列、SegNet、Deep Lab 系列、RefineNet、PSPNet 等。

2.4.4.1 全卷积网络(FCN)

单独将全卷积神经网络（FCN）（Qiu 等，2019）列为一节，是因为 FCN 网络是首个使用全新的视野来处理语义分割问题的神经网络。之前的图像语义分割都是基于神经网络的方法，使用想要分类的像素的相邻的区域来一起预测该像素的标签，通常是使用卷积神经网络和全连接层来组成网络。很明显这样的方法没办法利用整个图像的信息，而且逐像素的计算速度很慢，计算量大；FCN 中没有使用全连接层，全部用卷积层构建网络，通过转置卷积以及不同层特征融合的策略，使得网络输出直接是输入图像的预测 mask，效率和精度得到大幅度提升。创新点有：全卷积网络（不含 fc 层）；转置卷积 deconv（反卷积）；不同层特征图跳跃连接（相加）。




图 2.8 FCN 整体架构简图

Figure2.8 FCN overall architecture diagram

2.4.4.2 U-net 系列

U-Net 一般来说也是对深度卷积神经网络的一种改进型，因为研究这个模型的作者把这个模型画的像一个 U 的形状，因此这个模型被叫做 U-Net。U-Net 由两个部分构成：分别是提取特征的编码器网络以及特征融合的解码器网络。编码器网络主要用来提取图片中的上下文信息的，而解码器是把编码器中的不同尺度的特征进行融合进而对图像中的物体进行分割，它能够分类和定位物体的位置和形状。因为 U-Net 是对全卷积神经网络(Fully Convolutional Neural Network: FCN)进行的改进；同时使用了数据增强(data augmentation)方法增加样本的多样性。这样就能够使用比较少的样本进行训练。尤其是因为医学诊断方面的研究数据非常难以获取到。U-Net 模型的提出使得样本量很少的医学影像处理得以快速发展。

如上所述，U-Net 的作者是在 FCN 的基础上进行的改进。比较吸引人的改进是 U-Net 不想 FCN 一样只是简单的对图像进行编码和解码的计算。U-Net 为了对图像中目标进行定位和分类。解码器网络会把编码器网络中的高级的特征使用上采样进行特征的融合，这样能够尽可能的利用好编码过程中生成的各种层级的特征。为了使得 U-Net 运行高效，减少计算量，减少参数量，网络中没有使用全连接层而都是卷积层。

编码器是每使用两个 3x3 卷积核的卷积层紧跟着会使用一个 2x2 卷积核步长为 2 的最大池化层来对特征图进行降采样，与此同时每个卷积层的后面都使用 relu 激活函数来对特征图进行非线性处理。而且在每次使用最大池化层降采样之

后都会增加一倍的卷积通道数。

在解码器网络部分中会进行上采样的操作，每一层的上采样都会使用一个 2×2 的带 relu 激活函数的卷积层和两个 3×3 的卷积层。而且每经过一次上采样都会减少一般的特征图通道数最后得到和原图像大小一样的特征图。

整个 U-Net 的最后的一层使用的是一个 1×1 的卷积，通道数设置为想要分类的类别数。最后我们得到的是一个总共有 23 层的卷积神经网络。同时 U-Net 能够处理任意大小的图片。

2.4.4.3 Deep Lab 系列

DeepLabv1 (Chen 等, 2018a) 模型使用了基于 VGG-16 结构的 CNN 用于提取特征，但是为了获取到像素级别的特征，这里把 VGG16 的最后面的全连接层改为了卷积层。这样更改后的模型输出采样间隔变成了 32 个像素，但是这样的分辨率对于分割任务来说不够用。该模型又参考了前人的方法把一些池化操作后面的下采样去掉，并且把卷积改为空洞卷积，这样就能在不使用池化操作损失特征信息同时也能够增加感受野，如下图所示：




图 2.9 空洞卷积示意图

Figure2.9 atrous convolution

卷积神经网络中，分类的精度和定位的精度之间存在自然的平衡；使用若干个最大池化层的更加深的模型能够取得更好的效果，但是它们增加的不变性使得从分数中推断出位置不容易。当前研究人员主要有两种解决方法来处理这个问题：使用卷积神经网络的多层次的特征图融合来增强检测效果，利用超像素分割来优化。Deep LabV1 使用的是 CNN 和条件随机场结合的方法，CNN 用于像素的分

类与确定大概像素边界，全连接条件随机场（CRFs）（Philipp 等，2011）用于后处理，恢复精确的物体像素边界。条件随机场能够利用原始图像优化检测出的物体的边界，能够使得带噪声的分割结果更加平滑，同时能够把分割结果种物体中间的空白去掉，最终使得分割结果更接近真实值。

DeepLabv2 是为了解决如下问题：1、比较低的特征分辨率；2、物体的大小不一；3、卷积神经网络不变性引起的定位精度降低。给卷积神经网络输入相同尺度的特征，并把这些特征进行融合能够一定程度的解决这个问题。基于空间金字塔（SPP），DeepLabv2 种作者提出了一种空洞卷积池化金字塔（atrous spatial pyramid pooling, ASPP）。它将特征图通过并行的空洞卷积层（不同的膨胀率），然后把输出的结果进行融合来预测分割结果。

DeepLabv3+（Chen 等，2018b）模型的结构如下图所示，首先是它的编码器模块，主要有带有空洞卷积的深度卷积神经网络以及 ASPP。这里的深度卷积神经网络一般使用 ResNet 或者 Xception 这种分类网络作为骨架网络，其中 Xception 加入了多尺度的信息并且使用了深度可分离卷积减少参数量。DeepLabv3+是在 Dilated_FCN 的基础上加入了解码器模块，这样与前面的编码器就组成了分割领域常见的编码器-解码器的结构。最后把高维度特征图和低维的进行融合来提升模型的分割精度。在这之前的研究工作种，在编码器之后直接使用插值操恢复特征图到输入图像大小，这样使得分割的分辨率不足边缘模糊。因此 DeepLabv3+种使用了 U-net 的想法，把 ASPP 输出的特征图上采样四倍后与编码器种的低层次特征融合来使得边缘更加的平滑。




图 2.10 DeepLabV3+整体架构

Figure2.10 DeepLabV3+ Model

2.4.4.4 PSPNet

PSPNet (pyramid scene parsing network) (Zhao 等, 2017) 模型会利用把不同区域的上下文特征进行融合, 显著的增加了模型获取到整个图片上下文特征的性能。SPPNet 通过使用金字塔池化来来获取不同层次的特征图, 把特征图融合在一起送入全连接层对图像进行分类, 这样就没有了卷积神经网络对输入大小一致的限制。然而在 PSPNet 使用的是池化-卷积-上采样得到上下文特征的然后和特征图融合, 最后进行标签的预测即图像分割。




图 2.11 PSPNet 模型

Figure2.11 PSPNet Model

2.5 本章小结

本章为算法基础的介绍。主要是对表面缺陷检测理论、显著性检测理论、深度学习理论等进行了阐述, 为后面的章节提供理论支撑。

第3章 基于区域特征聚类显著性检测的表面缺陷分割算法

3.1 引言

显著目标检测（Borji 等，2015；Chen 等，2016；Chen 等，2017）是计算机视觉中的一个基本问题。它模拟人的视觉注意力系统来突出图像中的显著区域或物体。在许多图像处理算法中，显著目标检测是一个重要的预处理步骤（Achanta 等，2009）。在模式识别和图像处理中有许多应用，如目标检测、目标识别、目标分割、运动检测、图像匹配、图像或视频压缩以及视觉跟踪。

本章提出了一种基于区域特征聚类显著性检测的表面缺陷图像分割算法。首先使用超像素算法对图像分割，然后对分割的算法求取特征向量。再使用多带宽无参聚类算法对特征向量聚类，然后得到十个带宽下的显著性图。通过神经网络对显著性图进行合并。把最后得到的显著性图作为一个新的特征再次重复以上过程。重复十次后得到最终的缺陷图像分割图。通过实验表明，本算法和其他算法比较，在效果、准确率、召回率、F 值以及 MAE 上都有提高。

3.2 算法

提出一种基于区域特征聚类（Jiang 等，2017）的显著性物体检测算法用于表面缺陷检测。图 1 显示了本算法的流程图。首先使用 gRGBSLIC 超像素算法对图片分割。然后提取分割后每个区域的特征构成特征向量。使用十个不同带宽的 MeanShift 算法对特征向量聚类得到聚类的图。再对十个聚类后的图进行显著性计算。通过神经网络把十个显著性图合并成一个显著性图。然后把该显著性图作为一个新特征加到上面提到在特征向量中。继续计算显著性图，直到循环达到十次。输出最终的缺陷检测结果。




图 3.1 算法流程图

Figure3.1 algorithm flow chart

3.2.1 基于改进的 SLIC 图像超像素分割

超像素的概念是 2003 年研究并发展的一种新型图像分割算法，它是拥有类似的纹理、颜色或者亮度等图像特征的相邻的像素区域构成的具有一定人类视觉原理的形状不规则的像素块。该方法使用相邻像素间的相似程度来把像素进行分组，用使用组内像素的统计特征代替整个区域像素。这种用区域特征（Jiang 等，2017）代替像素特征的方法能够显著的降低后面处理图像的计算量，因此图像处理的算法中经常把超像素分割作为一个预处理的步骤。目前已经在图像分割领域、姿态分析领域、目标跟踪领域以及目标识别等计算机视觉方面的研究（Agoes 等，2016）。

简单的线性迭代聚类算法（simple linear iterative clustering）简称 SLIC（Achanta 等，2012），由研究人员于 2010 年公开的一种方法简单、方面代码实现的一种方法。它首先把彩色的 RGB 图像转换到 CIELAB 颜色空间的 Lab 三个值并且结合 XY 两个坐标值结合成为 5 维特征向量。然后把这个向量作为计算像素间距离的计算基础，最后把图像的像素聚成一个个的区域。SLIC 算法能够产生紧凑的大小相似的超像素。该算法的运行速度、物体在超像素的轮廓以及超像素的形状都做得非常好，非常的贴近人们对分割的期望。下面详细的说明一下 SLIC 算法的运行步骤：

1. 首先初始化超像素的聚类中心：根据设置的期望的超像素的个数，在图像中均匀初始化初始的聚类中心。例如图像中一共包含 N 个像素，我们想把图像分成 K 个超像素，则每一个超像素中像素的个数为 N/K ，所以临近的初始化聚类中心的距离应该近似于 $S = \sqrt{N/K}$ 。本章中算法首先使用超像素算法把图片分割成 300 个超像素，即 $K=300$ 。

2. 在聚类中心的 3×3 范围内重新选取聚类中心。首先计算该范围内像素点的梯度值。然后把聚类中心换到该区域内梯度最小的点。这种方法能够使得聚类中心不在梯度比较大的边界上，防止对后面的聚类产生不好的影响。

3. 把聚类中心周围的像素分配类别标签（即该像素属于哪个聚类中心）。这里和 k -means 算法一般会在整个图片中搜索聚类中心不相同。SLIC 只搜索的搜索 $2S \times 2S$ 范围内的区域，这样算法速度快。

4. 像素间的距离计算。我们使用颜色距离以及空间距离结合的方法。区域内的每个像素点，都计算它与聚类中心的距离。距离公式如下：

$$d_c = \sqrt{(l_j - l_i)^2 + (a_j - a_i)^2 + (b_j - b_i)^2} \quad \dots (3.1)$$

$$d_s = \sqrt{(x_j - x_i)^2 + (y_j - y_i)^2} \quad \dots (3.2)$$

这里的， d_c 表示像素间的颜色距离； d_s 表示像素之间的空间距离； N_s 表示的是类别间的最大的空间距离，它的定义是定义为 $N_s = S = \sqrt{N/K}$ 。其中的 N_c 同时受到图片不同以及聚类不同的影响，因此算法中都是使用一个常数 m （它的取值范围是 $[1, 40]$ ，通常情况可以使用 10）来代替。当 m 比较大的时候，算法更重视空间的位置，这样获取的超像素拥有更加低的面积与周长比。当 m 比较小的时候，算法更重视颜色空间，这样获取的超像素会更加的粘附在图像的边界，同时生成的超像素的尺寸和形状都不太规则。本文中 m 取 32。最终的距离度量 D' 如公式 3.3：

$$D' = \sqrt{\left(\frac{d_c}{N_c}\right)^2 + \left(\frac{d_s}{N_s}\right)^2} = \sqrt{\left(\frac{d_c}{m}\right)^2 + \left(\frac{d_s}{S}\right)^2} \quad \dots (3.3)$$

5. 重复执行 2-5 步。知道聚类中心几乎不再变化。实验中一般都是取迭代 10 次，一般都能够收敛。

6. 通过合并小超像素以及连接起来不连接的超像素来增强超像素的连通性。

在使用该算法计算时发现其速度比较慢, 500x400 的图像需要 0.23 秒, 像素更大的计算需要更多的时间。为了加快其运行速度使用了 gSLIC 的方法(Ban 等, 2018), 该方法中使用 CUDA 来进行计算超像素, 计算时间提高了 70 倍左右。经过实际对比, 引入 GPU 计算的 gSLIC 比只使用 CPU 计算的算法快 50 倍左右。

3.2.2 特征提取

算法第二步是提取第一部中分割图像 I 得到的各个超像素 $\{S_1, S_2, \dots, S_N\}$ 的特征, 其中包括: CIELab 三个颜色通道以及两个 RGB 图像的区域特征图。以上特征组成了三个低级特征 $\{f_l, f_a, f_b\}$ 以及两个高级特征图 $\{c_{GC}, c_{BC}\}$ 。

低级特征通过对每个超像素 S_i Lab 三个通道的值求平均, 得到了 $\{f_l, f_a, f_b\}$ 。两个高级特征是全局对比度和背景对比度方法得到的。对比度特征反映了物体和背景的显著性, 它能够很好的区分相同的区域和不同的区域。同时考虑了颜色信息、亮度信息、区域对比度信息、以及背景对比度信息。使用这些信息能够更好的区分背景和显著性物体。下一步的聚类算法能够更好的把背景聚类到一起、显著性物体聚类到一起。本文中这五个特征作为聚类使用的特征向量。

全局对比度特征 (Cheng 等, 2015): 人类视觉是会优先关注图像与周围物体的对比度比较大的地方。而且空间的特征在人类注意力系统中也起着非常重要的作用。即相邻的区域对比度高比相距较远的区域对比度高更会使得人类视觉系统关注。在像素级别的区域对比度计算方法中加入空间特征计算量会非常高。本章中使用了一种全局对比度 (GC) 方法, 这种方法把区域对比度以及区域的空间特征进行组合。该算法首先会把图像使用超像素的方法分割成很多个区域, 然后计算好每个区域的颜色对比度, 最后通过公式同时把对比度和空间信息融合计算每个像素的显著性值。把相距较远的区域设置的权重小, 把相距近的却与设置权重大公式如下:

$$c_{GC} = \sum_{s_j \neq s_i} \omega(s_i) D_{RGB}(s_j, s_i) \quad \dots (3.4)$$

其中, $\omega(s_i)$ 是超像素 S_i 中像素的个数, 用来强调大的超像素。 c_{GC} 是 RGB 图像的全局对比度特征。两个区域 s_j 和 s_i 的颜色距离 D_{RGB} 为:

$$D_{RGB}(s_j, s_i) = \sum_{a=1}^{n_1} \sum_{b=1}^{n_2} f(c_{j,a}) f(c_{i,b}) D(c_{j,a}, c_{i,b}) \quad \dots (3.5)$$

其中, $f(c_{k,m})$ 为第 m 个颜色 $c_{k,m}$ 在第 k 个区域 r_k 的所有 n_k 种颜色中出现的概率, $k=\{i,j\}$ 。为了使得计算方便我们使用了每个区域中的概率密度函数颜色出现的概率作为区域的权重来强调各种颜色之间的差异。因为每个区域在图像的直方图中只包含一些颜色。

背景对比度方法: 这种基于背景的对比度方法鲁棒性很好, 能够为显著性计算增加有用的信息。具体来说, 我们证明了这种方法能够很大程度上的增加对比度计算的性能。该算法使用了图像中的边界信息, 更加的突出在图片中心的区域。许多文献将区域与周围环境的对比度作为显著性特征, 算法通过把区域与区域之间的距离相加, 然后基于其空间距离计算权重。在本章中一个超像素的背景对比度计算方法如下:

$$c_{BC} = \sum_{i=1}^N d_{appLab}(S_j, S_i) \omega_{spa}(S_j, S_i) \omega_i^{bg} \quad \dots (3.6)$$

其中, d_{app} 是相应特征的欧式距离。 ω_{spa} 描述的是两个超像素中心的距离信息。 ω_i^{bg} 表示超像素 S_i 和边界的关系系数。 c_{BC} 是 RGB 图像的背景对比度特征。

通过以上步骤得到了每个超像素 S_i 的五个特征值 $\{f_l, f_a, f_b, c_{GC}, c_{BC}\}$ 。

3.2.3 Mean Shift 聚类

MeanShift 算法其实是一种核密度估计算法, 它将每个点移动到密度函数的局部极大值点处, 即, 密度梯度为 0 的点, 也叫做模式点。该算法是一种无参数的聚类算法, 使用时只需要提供控制核函数尺度的参数即可。而不需要提供聚类个数等参数。由于算法复杂度为 $O(N^2)$ 所以本文中选取 300 个超像素来进行计算。这样比直接使用原图减少了大量的计算消耗。从而加快运算速度。在图像聚类中还需要提供超像素的位置特征 $\{x, y\}$ 。这样和上一节中的五个特征就组成了 **MeanShift** 算法的特征向量 $\{f_l, f_a, f_b, c_{GC}, c_{BC}, x, y\}$ 。使用的时候对其进行归一化。

传统的 **Mean Shift** (Comaniciu 等, 2002) 图像分割算法使用的是一维灰度或者三维 RGB 信息来结合位置信息进行计算的。对于 **Mean Shift** 算法来说, 是一个迭代的步骤, 即首先计算出来当前点的偏移均值, 然后把这个点移动到计算的偏移均值的地方。把这个点当作新的起始点, 继续移动, 直到满足最终的条件。它就是对于所有的像素做一下的操作: 首先把这个元素转移到邻域内所有像素的

均值的地方，重复的执行这个步骤知道算法收敛。更确切的来说，这种方法并不是真正把点移动，而是把该像素和偏移均值处的像素标记成一个类别。

本文中是使用两个位置特征和五个超像素特征来进行多元核 Mean Shift 聚类的。其核函数是：

$$K_{h_s, h_r}(x) = \frac{c}{h_s^2 h_r^8} K\left(\left\|\frac{x^s - s_i^s}{h_s}\right\|^2\right) K\left(\left\|\frac{x^r - s_i^r}{h_r}\right\|^2\right) \quad \dots (3.7)$$

其中 $K\left(\left\|\frac{x^s - s_i^s}{h_s}\right\|^2\right)$ 是坐标信息，两点距离越近，值越大。 $K\left(\left\|\frac{x^r - s_i^r}{h_r}\right\|^2\right)$

是特征信息，两点越相似值越大。 $K(x)$ 使用的是 Epanechnikov 核函数：

$$K(x) = \begin{cases} 1-x & \|x\| \leq 1 \\ 0 & \|x\| > 1 \end{cases} \quad \dots (3.8)$$

h_s 、 h_r 是核函数带宽。通过控制这两个参数的来获取不同带宽下的聚类结果。分别取 10 个值，从而获得不同带宽核函数的聚类图。如图 3。 h_s 、 h_r 的值越大类别越少。对检测大物体更有用。 h_s 、 h_r 值越小类别越多，对检测小物体更有用。

3.2.4 EBC 计算每个聚类的显著图

文章中使用的 Boundary Connectivity (BC) (Oh 等, 2017) 方法是基于边界特征的方法中很稳健的方法。在此基础上引入了一个新的空间权重来适应上一步得到的聚类图，进而计算显著性图。改进的 BC 方法公式如下：

$$EBC(R) = \frac{V_\omega(R) N(p|p \in Bnd, p \in R)}{\sqrt{N(p|p \in R)}} \quad \dots (3.9)$$

其中 $V_\omega(R) = 1 + e^{-\frac{|R_h - I_h|}{\sigma_{EBC} \times I_h}} + e^{-\frac{|R_w - I_w|}{\sigma_{EBC} \times I_w}}$ 。 I_w 、 I_h 是图像的宽和高， R_w 、 R_h 是区域 R 的宽和高。 $\sigma_{EBC} = 0.1$ 。

十个经过不同核带宽聚类得到的图像经过公式 3.9 得到 EBC 的值，然后通过式 3.10 计算显著性值：

$$Sc(R) = e^{-\frac{EBC(R)}{\sigma_{SC}}} \quad \dots (3.10)$$

通过以上步骤得到了十个显著性图，本文通过带有一个隐含层的神经网络训练得到权重把这十个显著性图合并为一个显著性图。每个显著性图的第 i 个像素的值组成一个向量作为神经网络的输入。经过一个十个节点的隐含层得到合并后

的显著性图。神经网络训练权重使用的是不进行 3.5 节循环计算的显著性图。

3.2.5 循环

3.4 节最后得到的显著性图使用 3.1 节中的分割结果计算每个超像素区域的平均显著性值，来作为 3.3 节中 Mean Shift 算法的一个新的特征值，加入到已有的特征中得到新的特征向量 $\{f_l, f_a, f_b, c_{GC}, c_{BC}, x, y, S_c\}$ 。重复 3.3 和 3.4 中的过程 10 次。得到最终的缺陷分割图。

3.3 实验结果与分析

3.3.1 数据集和实验环境

本章使用的数据集是东北大学热轧带钢表面缺陷数据集。数据集收集了夹杂、划痕、压入氧化皮、裂纹、麻点和斑块 6 种缺陷，每种缺陷 300 张，图像尺寸为 200×200 。数据集包括分类和目标检测两部分，不过目标检测的标注中有少量错误，需要注意。部分示例如下：




图 3.2 缺陷图片例子

Figure 3.2 The image with defect

本文中测试的系统环境为：Windows 10，软件环境为 Matlab 2017b。计算机 CPU 为 intel i7-7700HQ 2.8Ghz。GPU 为 GTX 1060 Max-Q。

3.3.2 结果与分析

为了评价本文提出的缺陷图像分割算法，本文选择了 6 个主流的方法进行比较，它们分别是 PCA-2013 算法、RBD-2014 算法、RC-2015 算法、MB+-2015 算法、MST-2016 算法以及 DRFI*-2017 算法。如图 3.3 展示了原始图像、本文算法检测结果、以及其他六种算法的分割结果。由图可知，本文算法缺陷检测的结果更为干净准确。




图 3.3 算法效果对比

Figure 3.3 Algorithm effect comparison

本文通过实验比较七个算法得到的缺陷分割结果的准确率 (Precision)、召回率 (recall)、F-measure 值 (F-score) 以及 MAE (mean absolute error) 平均绝对误差。这样能够直观的比较几种算法的效果。

首先把缺陷图像分割图 S 转化成二值缺陷图像分割图 M 。二值化在算法评估中是一个重要的步骤，我们使用的是通过计算一个阈值来对缺陷图像分割图 S 进行二值化为 M 。阈值计算公式如下：

$$T_a = \frac{2}{W \times H} \sum_{x=1}^W \sum_{y=1}^H S(x, y) \quad \dots (3.11)$$

其中， W 、 H 是图像的宽和高。设 M 是实际缺陷图像分割图，则准确率 (Precision)：

$$Precision = \frac{|M \cap G|}{|M|} \quad \dots (3.12)$$

召回率 (recall)：

$$Recall = \frac{|M \cap G|}{|G|} \quad \dots (3.13)$$

P-R 曲线：算法得到的缺陷图像分割图片 I 是灰度图，让阈值 T 取 $[0, 255]$ ，得到二值缺陷图像分割图 M 。又已知缺陷图像二值图真值图 G 。由公式 (3.12)、(3.13) 分别求取准确率 (P) 和召回率 (R)，得到 P-R 曲线。首先对一张图片使用 7 种算法得到七个缺陷图像分割图。然后使用 P-R 曲线计算方法计算 7 种算法得到七个 P-R 曲线。最后对所有图片的 P-R 曲线求平均就得到了图 3.3 所示

的曲线。如图 7 所示，本文算法与其他算法相比，P-R 曲线在其他算法的上方。有些算法在 T 值比较小的时候没有曲线，这是因为在计算准确率（Precision）的时候出现了分母为 0 的情况。




图 3.3 P-R 曲线

Figure 3.3 P-R curve

单独的使用准确率和召回率都不能很好的估计显著性的好坏。因此引入了 F-measure 值，它同时反映了准确率和召回率，计算公式如下：

$$F_{\beta} = \frac{(1 + \beta^2) \text{Precision} \times \text{Recall}}{\beta^2 \text{Precision} + \text{Recall}} \quad \dots (3.14)$$

当 $\beta=1$ 时，称为 F1-score，这时，精确率和召回率都很重要，权重相同。当有些情况下，我们认为精确率更重要些，那就调整 β 的值小于 1，如果我们认为召回率更重要些，那就调整 β 的值大于 1。首先对图片的缺陷图像分割图使用公式 (11) 计算阈值，然后使用公式 (12)、(13) 计算准确率和召回率。再使用公式 (14) 计算 F_{β} 。最后把所有图片得到的 F_{β} 求平均就得到了一个算法的 F_{β} 值。图 3.4 显示了七个算法的准确率、召回率以及 F 值。图中显示出本文算法在召回率和 F 值都比其他算法高。而准确率和 DIFI 算法相同，比其他算法都大。




图 3.4 P-R-F 柱状图

Figure 3.4 P-R-F Histogram

还有一种缺陷图像分割评价方法是平均绝对误差（MAE）。MAE 值通过式 3.15 计算：

$$MAE = \frac{1}{W \times H} \sum_{x=1}^W \sum_{y=1}^H |S(x, y) - G(x, y)| \quad \dots (3.15)$$

首先对一个图片求缺陷图像分割图，然后使用公式（3.15）求该图的平均绝对误差 MAE。然后对所有图片的 MAE 求平均就得到了一种算法在数据集中的 MAE。MAE 反映了最终的缺陷图像分割图和真值图的差别。越小越好，表明越和真值图相近。本文中算法计算出来的缺陷图像和背景有明显的区别所以在 MAE 上表现比较好。




图 3.5 MAE 柱状图

Figure3.5 MAE Histogram

3.4 本章小结

本章提出了一种基于区域特征聚类显著性检测的表面缺陷图像分割算法。首先使用超像素算法对图像分割，然后对分割的算法求取特征向量。再使用多带宽无参聚类算法对特征向量聚类，然后利用十个不同带宽得到显著性图。在使用神经网络对合并显著性图。最后再把得到的显著性图作为一个新的特征再次重复以上过程。重复十次后得到最终的缺陷图像分割图。通过实验表明，本算法和其他算法比较，在效果、准确率、召回率、F 值以及 MAE 上都有提高。

第4章 基于迁移学习和图像分割的表面缺陷检测算法

4.1 引言

在平板钢的生产过程中,由于技术的限制,容易产生裂纹、划痕等缺陷。这些缺陷对钢材的质量有很大的影响。近年来,随着深度学习技术在工业中的广泛应用,越来越多的研究者用深度学习代替传统的机器学习方法来检测钢铁表面缺陷。因此,研究基于迁移学习(Sinno 等, 2010)和图像分割的算法对提高算法的效果和速度具有重要意义。

近年来,深度学习的方法急剧增加,并取得了良好的效果。在工业上也有广泛的应用。这些方法一般采用完全卷积网络(FCN)、卷积神经网络(CNN)、生成对抗网络(GAN)等。Zhou 等人提出了一种改进的快速 R-CNN 模型。邱等提出了一种基于全卷积网络 FCN 的基于深度学习的像素级表面缺陷分割算法。

上述算法计算量大或精度低。很难在生产环境中使用。因此,在提高精度和减少计算量方面仍有很大的空间。将集成学习与多种算法相结合,或采用迁移学习或改进算法,可以提高学习精度,取得较好的效果。另外,通过剪枝和共享参数,设计有效的卷积层,将批归一化(BN)层合并到卷积层中,可以减少计算量。本章提出了两种种基于迁移学习和图像分割的方法。首先,数据扩充用于扩展数据集。接下来,我们使用 EfficientNet 作为主干来获得特征图。从 BiFPN 或者 U-net 模块中得到了一个新的五种不同尺度的特征图。然后,利用反卷积将五种特征图融合在一起,再利用一层卷积得到各种缺陷的分割图。在最后的训练之后,我们采用 BN 和卷积层融合的方法来减少算法的运行时间。实验结果表明,该算法的平均 Dice 系数为 0.92。优于其他基于分割的深度学习算法的钢材表面缺陷检测。

4.2 算法

本章提出了两种种基于迁移学习和图像分割的钢铁表面缺陷检测算法。该算法可以对各种缺陷进行分割和分类。和传统的基于人工进行特征提取的算法以及一些基于深度学习的算法比较,该算法具有更高的效率和准确性。

虽然本章提出的算法能够正确地对大部分缺陷进行分类和检测,但如果没有

GPU 加速，很难实现实时性。在未来的研究中，我们将致力于获取更多的数据集，并采用更有效的模型压缩方法。使其能够用于高性能嵌入式设备。同时，研究更高效的网络体系结构，进一步提高模型的精度。

如图 4.1 显示了算法的训练和测试过程。首先对数据集进行预处理和扩充，然后将数据集划分为训练集和测试集。利用训练集对数据进行训练，当经过几次训练后损失函数仍不减小时，停止训练。测试训练集用于评估模型的性能。




图 4.1 算法流程图

Figure 4.1 The overview of proposed model pipeline

4.2.1 基于迁移学习和多尺度特征融合的表面缺陷检测算法

这种深度学习模型是一种端到端的表面缺陷检测算法。它由基于高效网络的主干网、自顶向下的特征金字塔网络（FPN）和基于反卷积网络的多尺度特征融合组成，以产生最终的输出。最终输出是四个与输入大小相同的分割图，表示四类缺陷。模型架构如图 4.2 所示。




图 4.2 模型框架

Figure 4.2 Model architecture

4.2.1.1 EfficientNet

卷积神经网络（CNN）通常用于资源有限的情况。如果有更多的资源可用，可以扩展它们以获得更好的准确性。在以前的工作中，我们只缩放三个维度中的一个-深度、宽度或图像大小。但是，EfficientNet（Tan 等，2019）使用了一种新的尺度方法来生成一系列 CNN。它可以同时平衡模型的深度、宽度和输入大小，在受限计算条件下获得最佳性能。

在 EfficientNet 中提出了一种新的复合缩放方法，它利用一个复合系数 ϕ 来均匀缩放网络的宽度、深度和图像大小。

$$\begin{aligned}
 \text{深度} : d &= \alpha^\phi \\
 \text{宽度} : w &= \beta^\phi \\
 \text{输入大小} : r &= \gamma^\phi \\
 \text{s.t. } \alpha \cdot \beta^2 \cdot \gamma^2 &\approx 2 \\
 \alpha \geq 1, \beta \geq 1, \gamma &\geq 1
 \end{aligned}
 \quad \dots (4.1)$$

这里的其 ϕ 是用户指定的系数，用于控制可用于模型缩放的资源数量， α, β, γ 指定如何将这些额外资源分配给网络宽度、深度和分辨率。值得注意的是，常规卷积操作的 FLOPS 与 d, w^2, r^2 成正比，即网络深度加倍将使 FLOPS 加倍，但网络宽度或分辨率加倍将使 FLOPS 增加 4 倍。由于卷积运算通常在卷积神经网络中占主导地位，用方程 4.1 缩放卷积神经网络将使总的 FLOPS 大约增加

$(\alpha \cdot \beta^2 \cdot \gamma^2)^\phi$ 。在本章中，我们限制 $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$ ，使得对于任何新的 ϕ ，总的 FLOPS 将大约增加 2^ϕ 。

首先使用神经结构搜索（NAS）（Elsken 等，2018；Kirthevasan 等，2018）方法得到 EfficientNet-B0，然后使用复合标度方法生成 EfficientNet-B1-EfficientNet-B7。在本章中，我们选择使用 EfficientNet-B4，同时考虑到准确性和计算工作量。网络结构如表 4.1 所示。

表 4.1 EfficientNet-B4 结构

Table 4.1 EfficientNet-B4 structure

Stage	Operator	Resolution	Channels	Layers
1	Conv 3x3	380x380	48	1
2	MBConv 1, k3x3	190x190	24	2
3	MBConv 6, k3x3	190x190	32	4
4	MBConv 6, k5x5	95x95	56	4
5	MBConv 6, k3x3	48x48	112	6
6	MBConv 6, k5x5	24x24	160	6
7	MBConv 6, k5x5	24x24	272	8
8	MBConv 6, k3x3	12x12	448	2
9	Conv 1x1	12x12	1792	1

在 EfficientNet 中的基本模块是 MBConv，这是一个起源于 MobileNet（Howard 等，2017）的一个卷积模块。比正常的 ResNet 中的卷积模块有更少的计算量。下面详细介绍 MBConv。如果想理解 MBConv 我们需要先明白什么是深度可分离卷积（depthwise separable convolution: DCN）（Chollet 等，2017）。DCN 是由 depthwise(DW)以及 pointwise(PW)组合起来实现的，可以通过它获取到特征图。和传统意义上的卷积比较，DCN 它的参数量以及运算量都较小。

常规卷积操作中对于一张 5×5 像素、三通道的特征图（那么它的形状是 $5 \times 5 \times 3$ ），使用一个 3×3 的卷积核进行卷积（我们设置卷积通道数为 4，则卷积核形状为 $3 \times 3 \times 3 \times 4$ ，最后我们可以得到 4 个通道的特征图，如果填充类型为 same 那个输出的特征图大小和输入层的相同都是 5×5 ，如果设置的类型不是 same 则输出的特征图的大小为 3×3 。卷积层共 4 个 Filter，每个 Filter 包含了 3 个 Kernel，每个 Kernel 的大小为 3×3 。因此卷积层的参数数量可以用如下公式 4.1 来计算：

$$N_{std} = 4 \times 3 \times 3 \times 3 = 108 \quad \dots (4.1)$$

深度可分离卷积可分为两个步骤分别是：逐通道卷积和逐点卷积。逐通道卷积（DW）中的一个卷积核只对一个通道进行卷积并且一个通道只能同时被一个卷积核进行卷积。例如一张 5×5 像素、三个通道的输入图片（它形状是 $5 \times 5 \times 3$ ），逐通道卷积先使用卷积对图片进行计算，卷积核的数量和上一层的通道数相同本例中为 3（每个通道都对应一个卷积核）。因此最后生成了一个三通道的特征图（如果填充类型是 same 那么输出的特征图大小和输入层的相同都是 5×5 ），其中一个 Filter 只包含一个大小为 3×3 的 Kernel，卷积部分的参数个数计算如下公式 4.2：

$$N_{depthwise} = 3 \times 3 \times 3 = 27 \quad \dots (4.2)$$

逐通道卷积操作得到的特征图通道数与输入的特征图一样，不会把通道数增加。并且逐通道卷积只对每个通道进行单独的卷积运算，没有使用多个通道进行空间上的特征融合。所以在逐通道卷积后需要进行逐点卷积（Pointwise Convolution）操作把特征图的不同通道信息进行结合，得到新的特征图。

逐点卷积操作和传统的卷积非常相似，它是使用 $1 \times 1 \times M$ 的卷积核实现的，其中的 M 等于上一层的特征图通道数，例子中是 3。因此逐点卷积将会在逐通道卷积输出的特征的深度上就行加权，组合成为新的特征图。使用几个卷积核那么输出的特征图就多多少个通道。由于逐点卷积使用 1×1 卷积来实现的，因此计算逐点卷积的参数量的计算公式如下公式 4.3 所示：

$$N_{pointwise} = 1 \times 1 \times 3 \times 4 = 12 \quad \dots (4.3)$$

在进行了逐点卷积操作后，也得到了 4 个通道的特征图经过逐点卷积之后，与上面例子中的进行常规卷积得到的通道数相同。如下式 4.4 所示：

$$N_{pointwise} + N_{depthwise} = 39 \approx \frac{1}{3} N_{std} \quad \dots (4.4)$$

通过公式 4.4 可知，传统的卷积和深度可分离卷积输入相同，输出同样都是 4 个通道的特征图，深度可分离卷积的参数量比传统的卷积操作少 66%。并且一般情况下如果输出个特征图个数比较大，那么如果采用 3×3 卷积核的话，深度可分离卷积则可以比传统的卷积操作减少 89% 的计算量。因此，使用深度可分离卷积的模型在参数量和 ResNet 差不多的情况下，可以使得模型的深度设计的更深，效果更好。

前面讲述了深度可分离卷积的计算方法，这是 MBConv 模块的原理，但是

在真正应用中会加入批标准化，并使用 ReLU 激活函数。因此深度可分离卷积的具体实现如图 4.3 所示。




图 4.3 深度可分离卷积

Figure4.3 depthwise separable convolution

如图 4.4 所示，这个就是标准的 MBConv 模块，其中包含了左边的逐通道卷积模块右边的压缩激励模块(Squeeze-Excitation: SE)以及最后的逐点卷积模块。SE 模块利用了计算机视觉中的注意力机制，主要是学习了 channel 之间的相关性，筛选出了针对通道的注意力，稍微增加了一点计算量，但是效果比较好。




图 4.4 MBConv 模块图

Figure4.4 Mbconv module diagram

4.2.1.2 FPN

特征金字塔网络 (Lin 等, 2017) 首先执行传统的特征提取编码器网络, 然后融合编码器网络中相邻的特征图。左侧的部分叫做编码器, 右侧的部分叫做解码器, 连接两侧的箭头叫做横向连接。这样既能获取到高层的语义特征也能获取到低层的位置信息。




图 4.5 FPN 结构

Figure4.5 FPN structure

编码器网络中的特征图每层大小相差一倍, 但相邻层之间其实有很多的卷积层在同样大小的特征图上做卷积最后在进行一次池化操作, 我们把在大小相同特征图上做的操作称为一个阶段。图 4.5 展示的图是 FPN 结构中每个阶段最后的一个卷积层的特征, 因为每个阶段的最后一层特征语义信息最多。

详细的特征融合方法是对两个相邻特征层中的高层特征进行 2 倍上采样。通常可以使用内插法, 在原特征图的大小扩大两倍。低层的特征图使用 1×1 的卷积改变它的通道数, 然后把上采样和 1×1 卷积得到的特征图按像素相加。用 1×1 改变通道数, 以达到各个层级处理结果的通道数都为 256-d, 后面的步骤中方便的使用特征分类。

4.2.1.3 BiFPN

为了解决多尺度特征融合问题, 在特征金字塔网络 (FPN) 的基础上对 BiFPN 进行了改进。BiFPN (Tan 等, 2020) 增加了有效的双向交叉尺度连接和加权特

征融合方法。FPN 已被广泛应用于多尺度特征融合。近年来研究人员提出了多种多尺度特征融合模型，例如：PANET、NAS-FPN 等。其中的大多数研究工作都是不加区分的融合多尺度的特征，但是这些多尺度的特征大小不一样因而对最终输出的贡献也不同，因此该研究提出了加权双向特征金字塔网络(BiFPN)。它能够学习不同尺度特征的重要性，同时能够多次重复 FPN 操作。

在计算量没有明显增加的情况下，交叉尺度连接方法通过移除只有一个输入的节点，在输出的边缘增加一层输入，从而提高了多尺度特征融合的效果，把每一个双向的（自上而下和自下而上）路径看着是一个特征网络层，然后重复执行多次。在本章中，我们将 BiFPN 模块重复七次。

以往的特征融合方法对所有输入特征一视同仁。但是，不同层级的特征图尺度不同，表达的特征也是不同级别的，越高级的特征越抽象，因此这些不同尺度的特征对最后缺陷分割的贡献不同。基于这个原因，本章使用了一种加权的特征融合的算法。对每个尺度的特征赋予不同的权重，代表了它们的重要性。使网络学习每个输入特征的重要性。BiFPN 的结构如图 4.2 所示。

4.2.1.4 Mish 激活函数

激活函数是把神经元的输入映射到输出，它能够增加神经网络的非线性。在深度学习中，常用的激活函数有 sigmoid、Tanh、ReLU、PReLU、swish、mish(Misra, 2019)。Sigmoid 激活函数以及 tanh 激活函数都是把输出限制在(0,1)和(-1,1)之间，这样就使得这两种激活函数适合处理概率。ReLU 就不能用于概率计算，因为它没有最大值的限制。它的这个特征使得 Relu 激活函数更适合用来训练深层神经网络。而 Sigmoid 和 tanh 因为会出现梯度消失，所以不适合训练神经网络。

Sigmoid 激活函数的公式如 4.5，它也被称为 Logistic 函数。这是因为 Sigmoid 函数能够通过 Logistic 回归推理得到，同样 Sigmoid 也是逻辑回归模型中使用的激活函数。由于 Sigmoid 激活函数的取值范围是在 (0, 1) 之间，因此可以把神经网络的输出控制在这个范围内，能够方便分析。优点是函数曲线平滑、易于求导。缺点也很明显计算量大包含幂运算和除法、容易出现梯度消失的情况、Sigmoid 的输出不是 0 均值随着网络的加深，会改变数据的原始分布。

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad \dots (4.5)$$

tanh 为双曲正切函数公式为 4.6。tanh 激活函数和 sigmoid 激活函数一样是

饱和激活函数，它们的区别是输出值范围由 sigmoid 的 (0,1) 变为了 tanh 的 (-1,1)。tanh 解决了 Sigmoid 激活函数不是 0 均值输出的问题；但是幂运算引起的计算量大的问题仍然存在；tanh 激活函数的导数范围在(0, 1)之间梯度消失问题得到一定的缓解。

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad \dots (4.6)$$

Relu(Rectified Linear Unit)修正线性单元函数，该函数形式比较简单如公式 4.7 所示。ReLU 的有效导数是常数 1，解决了深层网络中出现的梯度消失问题，也就使得深层网络可训练。相比 Sigmoid 和 tanh，ReLU 摒弃了复杂的计算，提高了运算速度。解决了梯度消失问题，收敛速度快于 Sigmoid 和 tanh 函数，但要防范 ReLU 的梯度爆炸。

$$f(x) = \max(0, x) \quad \dots (4.7)$$

Swish 的设计受到了 LSTM 和高速网络中 gating 的 sigmoid 函数使用的启发。Swish 激活函数的主要优点如下：无界性有助于防止慢速训练期间，梯度逐渐接近 0 并导致饱和；导数恒>0；平滑度在优化和泛化中起了重要作用。公式如下：

$$y = x \times \text{sigmoid}(x) \quad \dots (4.8)$$

本章采用目前性能最好的 Mish 激活函数。在[13]中的实验表明，在许多具有挑战性的数据库中，Mish 激活函数比 Swish (+0.494%) 和 ReLU (+1.671%) 提高了最终精度。Mish 是一个非单调的神经激活函数。Mish 激活函数公式如下：

$$f(x) = x * \tanh(\log(1 + e^x)) \quad \dots (4.9)$$




图 4.6 Mish 激活函数图像

Figure 4.6 The Mish formula

根据图 4.6, Mish 激活函数无上限, 这就就能不出现因为封顶引起的饱和现象。并且该激活函数可以在负值的方向通过少量信息, 以获得更好的梯度。从而避免了 ReLU 激活函数中负值方向上全是 0。所以, Mish 激活函数能够获得更好的非线性特征, 进而使得模型更准确泛化性更好。

4.2.2 基于迁移学习和 U-net 的表面缺陷检测算法

在本算法中使用的是一种端到端的基于图像分割 U-net 的算法。输入原始图片输出四个缺陷类别的分割图由图 4.7 所示, 模型首先使用 EfficientNet-B0 作为编码器来对图片进行特征提取, 然后使用右边的解码网络进行特征的融合最终得到了检测和分类的结果。这两个部分组成了 U-Net 模型, 输出是四个(256*256*1)的图片, 代表的四类缺陷的分割结果, 为 1 的区域既是该类缺陷的检测到的缺陷位置。全为零则表示没有该类的缺陷。




图 4.7 网络架构

Figure4.7 Network architecture

4.2.2.1 EfficientNet

在工业环境中, 基于 CNN 的算法通常运行在一个资源受限的硬件环境中。如果深度学习的计算量太大就不能够实现对实时性的要求, 因此选择一个既满足运行时间又满足准确性的算法十分重要。本章中选择了 EfficientNet-B0 作为

编码器的架构，这个编码器能够大量的减少计算量。并且与其他编码器框架相比能够生成更好的特征。EfficientNet 使用了一种新的方法去平衡输入图片大小、通道数以及深度的方法。能够得到不同计算量要求的模型。表 4.2 展示了 EfficientNet-B0 的网络结构组成。这里的 EfficientNet-B0 与上一小节中的 EfficientNet-B4 在分辨率、通道数以及层数上都有了相应的减少。计算效率更高，但是也损失了一些精度。

4.2.2.2 U-Net

U-Net 是比较早的使用全卷积网络进行语义分割的算法之一，它是一个应用于医学影像分割的经典架构。它的创造者使用包含压缩路径和扩展路径的对称 U

表 4.2 EfficientNet-B0 的详细网络结构

Table4.2 Detailed network structure of EfficientNet-B0

编号	操作	分辨率	通道数	层数
1	Conv 3x3	224x224	32	1
2	MBConv 1, k3x3	112x112	16	1
3	MBConv 6, k3x3	112x112	24	2
4	MBConv 6, k5x5	56x56	40	2
5	MBConv 6, k3x3	28x28	80	3
6	MBConv 6, k5x5	14x14	112	3
7	MBConv 6, k5x5	14x14	192	4
8	MBConv 6, k3x3	7x7	320	1
9	Conv 1x1	7x7	1280	1

形结构在当时非常具有创新性，且一定程度上影响了后面若干个分割网络的设计，该网络的名字也是取自其 U 形形状。它由两部分组成分别是编码器和解码器如图 4.7 所示。这种 U 型的结构使得研究图像分割的算法十分简便。它的输入是一个三通道的图片，输出是不同类别的分割图。如图 4.7 所示，使用 EfficientNet 作为编码器进行特征提取，共提取了五层不同尺度的特征图，每层的大小和通道数不同。模型的右侧是解码器，每一层使用同一层的编码器特征图和下一层的特征图作为输入。最后，输出 $256\times256\times4$ ，这意味着输出四种不同类别的分割图像。输入和输出图像如图 4.8 所示。第一个图像是输入的原始图像（ $512\times512\times3$ ），最后四个图像是输出图像，分别表示第一到第四类缺陷的检测结果。第二图像不为

零的位置是检测到的第一类缺陷。最后三张图片没有不为 0 的位置，表示没有其他三类缺陷。



图 4.8 输入和它的四个分割结果图

Figure4.8 The input and the four outputs

4.2.3 迁移学习

迁移学习是一种将知识从一个领域转移到另一个领域的机器学习方法。这可以使目标域获得更好的性能。通常，源域中有足够的数据，而目标域中只有很少的数据。在这种情况下，有必要使用迁移学习。在计算机视觉中，通常使用 Imagenet 预先训练好的模型作为特征抽取器迁移到其他领域。使用迁移学习通常遵循以下步骤。

- a、网络层参数从先前训练的模型中获得。
- b、将其冻结，以避免破坏先前训练的参数信息。
- c、在 a 中获得的所有层之后添加一些新的可训练层。
- d、基于新数据集训练模型
- e、解冻整个模型并训练新的数据集。直到你得到更好的结果。

本章采用了基于 Imagenet 数据集预训练的 EfficientNet。

4.2.4 数据增强

钢铁表面缺陷检测算法通常需要大量的标记缺陷数据集。然而，在实际工业生产中很难获得不良产品的数据。这导致深度学习算法没有足够的数据来训练它。数据扩充是数据扩充方法的总称。数据扩充可以增加训练集样本数，有效地缓解模型的过度拟合，同时也可以给模型带来更大的泛化能力。数据扩充的目的是使训练数据尽可能接近测试数据，从而提高预测精度。

在该模型中，输入的钢材表面图像大小为 512×512 ，因此，图像的大小应通过使用 `resize` 函数处理为输入的大小。本章采用旋转、宽移、高移、亮度、变焦和翻转等方法进行数据增强（Cui 等，2014；Shorten 等，2019）。因此，通过对

训练集进行图像变换,可以使模型所使用的训练数据集更加多样化,最终提高本章提出的模型的鲁棒性。如图4.9(d)所示给出了上述随机变换的结果。




图4.9 数据增强示例。(a)原始图像。(b)水平旋转。(c)垂直旋转。(d)随机变换

Figure4.9 Examples of data augmentation. (a)Original image. (b) Horizontal Rotation. (c)Vertical Rotation. (d) Random transformation

4.2.5 后处理

为了提高模型的精度,本章在生成最终分割图时,采用了测试时增强(TTA)(Wang 等, 2019a)。该方法计算了三次计算结果,各结果的输入值不同。它们是原始图像、水平翻转图像和垂直翻转图像。最后的结果可以通过平均三次的结果得到。通过比较,发现 TTA 算法可以提高算法的精度。

由于算法有时检测到很小的单个缺陷区域或整个类别的缺陷区域很小,这是一个检测误差。通过删除两种缺陷检测结果,提高了算法的稳定性和准确性。本章研究了在最完整缺陷面积小于 500 像素时,不存在缺陷。如果单个缺陷区域中的像素少于 150 像素,则该区域直接设置为无缺陷。

4.2.6 融合批标准化和卷积层

在训练深度网络模型时,BN 层通常在卷积层之后加速网络收敛并控制过拟合。BN 层对数据进行归一化处理,可以有效地解决梯度消失和梯度爆炸问题。

虽然 BN 层在训练中起到了积极的作用，但是在网络的前向推理中存在着更多的操作计算，影响了模型的性能，占用了更多的内存或视频存储空间。目前，许多高级网络模型（ResNet、MobileNet、Xception、ShuffleNet（Zhang 等，2018）等）都使用了 BN 技术。因此，有必要将 BN 层参数合并到卷积层中，以加速正向推理。

这里假定 x 是网络的某一激活层特征，我们要对其进行归一化。若模型训练 batch 中共有 n 个样例，其特征分别是 $x_1, x_2, \dots, x_n$ ，我们采用下列公式进行归一化：

$$\hat{x}_i = \gamma \frac{x_i - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta = \frac{\gamma x_i}{\sqrt{\sigma^2 + \epsilon}} + \beta - \frac{\gamma \mu}{\sqrt{\sigma^2 + \epsilon}} \quad \dots (4.10)$$

值 μ 和 σ^2 是在一批中计算的均值和方差， ϵ 是一个小常数，包括数值稳定性， γ 是比例因子， β 是位移因子。培训期间，每批重新计算 μ 和 σ ：

$$\mu = \frac{1}{n} \sum x_i, \sigma^2 = \frac{1}{n} \sum (x_i - \mu)^2 \quad \dots (4.11)$$

参数 γ 和 β 与网络的其他参数一起用梯度下降法慢慢学习。在测试期间，我们通常不会在一批图像上运行网络。因此，前面提到的 μ 和 σ 的公式不能使用。相反，我们使用指数移动平均法在训练期间计算出的估计值。让我们把这些近似表示为 $\hat{\mu}$ 和 $\hat{\sigma}^2$ 。

卷积运算如下式所示：

$$F_{conv} = \mathbf{W}_{conv} \cdot F_{prev} + \mathbf{b}_{conv} \quad \dots (4.12)$$

F_{prev} - 卷积输入

F_{conv} - 卷积输出

$\mathbf{W}_{conv}$ 和 $\mathbf{b}_{conv}$ 是卷积的参数

由公式 4.11，我们令：

$$W_{BN} = \frac{\gamma}{\sqrt{\sigma^2 + \epsilon}}, b_{BN} = \beta - \frac{\gamma \mu}{\sqrt{\sigma^2 + \epsilon}} \quad \dots (4.13)$$

然后，合并的 CNN 和 BN 层可以使用以下公式进行计算：

$$\begin{aligned} F_{BN} &= \mathbf{W}_{BN} \cdot (\mathbf{W}_{conv} \cdot F_{prev} + \mathbf{b}_{conv}) + \mathbf{b}_{BN} \\ &= \mathbf{W}_{BN} \cdot \mathbf{W}_{conv} \cdot F_{prev} + \mathbf{W}_{BN} \cdot \mathbf{b}_{conv} + \mathbf{b}_{BN} \end{aligned} \quad \dots (4.14)$$

因此，我们可以用以下参数将这两个层替换为单个卷积层：

$$\mathbf{W} = \mathbf{W}_{BN} \cdot \mathbf{W}_{conv} \quad \dots (4.15)$$

$$\mathbf{b} = \mathbf{W}_{BN} \cdot \mathbf{b}_{conv} + \mathbf{b}_{BN} \quad \dots (4.16)$$

4.3 实验结果与分析

4.3.1 数据集

本章使用了 kaggle 钢铁缺陷检测数据集[21], 该数据集由 12568 张 1600*256 相同形状的图像组成。在 12568 张图像中, 6666 张图像有缺陷 (897 张第一类缺陷图像、247 张第二类缺陷图像、5150 张第三类缺陷图像和 801 张第四类缺陷图像) (图 4.10), 5902 张图像没有缺陷 (图 4.11)。




图 4.10 每个缺陷类别有多少个图片

Figure 4.10 The number of images for each defect class




图 4.11 每个图片包含的缺陷种类数

Figure 4.11 Number of classes included in each image

从图 4.10 可以明显看出, 数据集的类是不平衡的。本章将通过数据预处理

和修改损失函数中各类的权重来解决数据不平衡的问题。从图 4.11 可以看出，有缺陷图像和无缺陷图像的数量几乎相同，很少有图像有多个缺陷。




图 4.12 数据集的数据样本。（a）正常案例；（b）第一类缺陷案例；（c）第二类缺陷案例，（d）第三类缺陷案例；（e）第四类缺陷案例

Figure 4.12 Data samples from the dataset, (a)normal cases, (b) first class of defect cases, (c)second class of defect cases, (d)third class of defect cases, (e)fourth class of defect cases

如图 4.12 所示，图片的大小是 256*1600。如果直接使用调整大小功能来变换图片，则会丢失有关长度方向的信息。所以在模型训练之前，把一张图片分成四张 256*400 的图片。然后将每个分割的图片转换为 512*512。使用 5 倍交叉验证方法将数据集分成训练集和测试集。

4.3.2 评价指标

这个比赛是根据平均 Dice 系数来评估的。Dice 系数可用于比较预测分割与其对应的真实值之间的像素级一致性。公式如下：

$$Dice=\frac{2*|X \cap Y|}{|X|+|Y|} \quad \dots (4.17)$$

其中 X 是预测的值，Y 是真实值。当 X 和 Y 都为空时，Dice 系数被定义为 1。

4.3.3 实验环境

本实验是基于 GPU 加速 Tensorflow (Mart 等, 2016) (2.3 版) (Abadi 等, 2016) 的深度学习开发环境。Tensorflow 后端使用 CUDA10.1 软件开发工具包来使用 GPU 加速。GPU 加速器使用的 Geforce GTX 1080 Ti 拥有 11g 内存, 可以一次训练更多图片。CPU 使用 AMD Ryzen5 2600x, 训练一个模型大约需要 12 个小时。

4.3.4 效果与分析

为了充分利用数据集中的所有数据, 便于判断模型的稳定性, 本章采用了 5 次交叉验证的方法。在数据增强过程中, 需要对原始图像和掩码图像进行增强。该方法使用固定的随机种子对原始图像和掩码图像进行随机增强。从图 4.10 可以明显看出, 数据集的类是不平衡的。为了解决这个问题, 采用了二元交叉熵损失函数, 并设置了类别权重 (2.0, 2.0, 1.0, 1.5)。

本章使用的优化函数是 Radam, 它是最近提出的最有效的优化算法。它超越了原来的 Adam, 具有良好的稳定性。使用以下参数: learning_rate=0.0001, beta_1=0.9, beta_2=0.999, epsilon=1e-7, warmup_proportion=0.1。采用提前停止方法, 避免了由于训练次数过多而导致的过拟合, 多个训练次数后损失函数不降低则停止训练。使用 ReduceLROnPlateau 方法可以使模型更快地找到最优值。

在本研究中, 我们使用了 EfficientNet, 它是由 ImageNet 大型图像数据集预先训练的。通过删除 EfficientNet 中最后一个全连接层作为特征提取网络。将骨架网络中 5 个不同大小的卷积层输出连接到 BiFPN 模块作为特征融合层。最后, 对 BiFPN 的五种不同尺度特征进行反卷积融合, 得到 $128 \times 128 \times 4$ 的结果。生成的四个 128×128 掩码图像是算法的最终输出, 代表了四种表面缺陷的检测结果。图 4.13 显示了原始图像和模型输出。图 4.13 还显示了两种类型的缺陷, 即原始图像中的 3 级缺陷和 4 级缺陷。如果掩模图像全部为紫色, 则该类中不存在缺陷, 否则, 该类中存在缺陷。该算法在检测缺陷的同时对缺陷进行分类。

图 4.14 显示了仅检测图像中一个缺陷的结果。从左到右的缺陷检测结果分别为 1 到 4 类。显然, 检测结果是很好。与图 4.12 中手工标注的缺陷相比, 该算法生成的缺陷图像更加平滑。通过观察, 可以明显地看出, 所提出的模型对各种类型的缺陷表现出了有效的性能。




图 4.13 原始图像和最终输出。(a) 原始图像；(b) 1 类缺陷检测结果；(c) 2 类缺陷检测结果；(d) 3 类缺陷检测结果；(e) 4 类缺陷检测结果。

Figure 4.13 original image and final outputs. (a)original image. (b)class 1 defect detection results. (c)class 2 defect detection results. (d)class 3 defect detection results. (e)class 4 defect detection results.




图 4.14 原始图像和缺陷。(a) 原始图像及其 1 类缺陷检测；(b) 原始图像及其二类缺陷检测；(c) 原始图像及其 3 类缺陷检测；(d) 原始图像及其 4 类缺陷检测。

Figure 4.14 original image and defects. (a)original image and its class 1 detect. (b) original image and its class 2 detect. (c) original image and its class 3 detect. (d) original image and its class 4 detect.

表 4.3 说明了不同算法的骰子值和单个预测所用的时间。从表中可以清楚地看出，本章使用的 efficientnet-b4 使用的触发器与广泛使用的 ResNet-50 几乎相同，但性能更好。这是因为 efficientnet-b4 不仅使用更高效的卷积模块，而且还使用 AutoML 技术自动搜索更高效的体系结构。采用 resnet-50 作为特征提取主干的模型的 dice 值比采用 EfficientNet-B4 的模型低 0.03。

表 4.3 算法效果比较

Table 4.3 Comparison of algorithm effects

算法	参数量	平均 Dice 互相关系数	GPU 运行时间(ms)\图像
ResNet50+Unet	32.5M	0.877	34.1
ResNet50+FPN	26.9M	0.874	42.9
ResNet50+BiFPN	29.4M	0.882	106.2
EfficientNet-B4+Unet	25.7M	0.905	83.4
EfficientNet-B4+FPN	20.9M	0.906	91.1
EfficientNet-B4+BiFPN	23.4M	0.912	155.1

本实验采用了三种特征融合模块：U-Net[23]、FPN[11]和 bifpn。从表 2 可以看出,u-net 和 FPN 可以得到基本相同的 Dice 值,而 bifpn 则高于前两个 Dice 值。这主要是因为 BiFPN 减少了单个输入节点的数量,增加了同一层的输入输出边缘,并将每个双向(自上而下、自下而上)路径视为一个特征网络层。通过上述改进, bifpn 模块可以重复地用于高阶特征提取。

结果表明, EfficientNet-B4+BiFPN 的效果最好, Dice 值最高。虽然它比其他五种算法运行时间长,但也能满足算法的实时性要求。还有一些方法可以减少以后的运行时间。本章将 BN 层和卷积层合并在一起。该方法避免了 BN 层的增加,避免了计算量的增加。该方法使系统的运行时间缩短了 5%左右。EfficientNet-B4+BiFPN 算法的运行时间由 155.1ms 缩短为 147.4ms。

4.4 本章小结

本文提出了两种种基于迁移学习和图像分割的算法。第一种：首先,利用数据扩充技术对数据集进行扩展。接下来,我们使用 EfficientNet 作为主干来获取特征图。从重复的 BiFPN 模型中得到了五种不同尺度的特征映射。然后利用反卷积将五种特征图融合在一起,再利用一层卷积得到各种缺陷的掩码图。在最后的训练之后,我们采用批归一化和卷积层融合的方法来减少算法的运行时间。实验结果表明,该算法的平均 Dice 系数为 0.912。优于其他深度学习算法的钢材表面缺陷检测。第二种基于 U-net 和迁移学习的学习算法。首先,使用数据扩充扩

展数据集。然后使用 EfficientNet 作为主干来提取特征。使用 U-net 在多个尺度上融合特征。最后，通过一层卷积得到大小为 $512 \times 512 \times 4$ 的四类缺陷的映射。实验表明，该算法比其他算法具有更高的精度和鲁棒性。平均 Dice 系数达到 0.905。虽然本章提出的算法取得了很好的效果。但在运行时间和准确性方面仍有很大的改进空间。在未来，我们将研究更多有趣的模型，并使用一些后处理方法来加速计算。

第5章 融合分类和物体检测的表面缺陷检测算法

5.1 引言

随着机器学习和计算机视觉的发展,人们提出了各种各样的算法,它们各有优缺点。传统的基于机器学习的方法对缺陷规模和噪声非常敏感,容易受到影响。而且,该算法的精度不能满足自动缺陷检测的实际需要。有些功能需要手工设计,应用范围非常有限。基于深度学习的分类方法只能对图像进行分类,不能确定缺陷的位置和大小。这对以后的数据分析有很大的影响。基于 GAN 和强化学习,很难训练出一个稳定、准确的模型。本章实现了钢板表面缺陷的自动检测和定位,进一步提高了算法的精度和稳定性,减少了算法的平均运行时间。提出了一种将分类模型与目标识别模型相结合的方法。本文的主要贡献总结如下。

a、首先,我们提出了一种改进的快速 R-CNN 模型,通过添加空间金字塔池(SPP)(He 等,2015b)和增强特征金字塔网络(FPN)模块,可以更好地检测多尺度缺陷。为了提高裂纹缺陷的检测精度,我们修改了锚的纵横比。利用新的矩阵 NMS 算法,可以更快更好地得到边界盒

b、我们使用改进的 Resnet50-1d 模型作为分类模型和目标识别模型的主干。通过加入可变形旋转网络(DCN),以及改进的切口,我们可以更好地检测各种形状的缺陷,具有更高的精度和更好的鲁棒性。

c、本文采用分类模型和目标检测模型相结合的方法,大大提高了算法的准确率,减少了算法的平均运行时间。

本章的组织结构如下:第二节介绍了算法的结构,包括总体架构、分类模型、目标检测模型等;第三节对数据集进行分析,指导算法的改进。通过实验验证了算法的正确性和有效性,并与其他方法进行了比较。最后,对全章进行了总结并得出结论。

5.2 算法

深度学习的核心是特征学习,它能够通过多层次网络获得各种层级的特征。这种方式解决了从前需要手工设计特征的问题。本节中使用了深度学习中的卷积神经网络(CNN)中的卷积去学习钢板表面图片的特征并检测和定位缺陷。一个

典型的卷积神经网络是由若干个模块组成的，每个模块由卷积、池化、全连接层等组成。例如，ResNet 由卷积层、残差块和全连接层组成。由于实际生产环境中存在缺陷的样本很少，通过分类器对有缺陷或无缺陷的样本进行分类，将大大减少算法的平均运行时间。因此，本文采用二值图像分类和目标检测算法同时进行，以提高分类精度，减少平均运行时间。

如图 5.1 所示，首先，图像的大小调整为 224×224 。然后，在改进的 ResNet50 分类模型中，通过阈值=0.3 将样本分为无缺陷样本和其他样本，并加入了可变形旋转网络（DCN）和改进的裁剪。如果有缺陷的概率小于 0.3，算法直接输出无缺陷的样本。其他样本的大小调整为 800×1344 ，并进一步输入到改进的快速 R-CNN 目标检测模型中，加入空间金字塔池（SPP）、增强特征金字塔网络（FPN）和矩阵 NMS 对缺陷进行检测。最终输出是样本中缺陷或样本中无缺陷的位置和分类。下面将介绍算法的两个部分。




图 5.1 总体算法框架

Figure 5.1 Algorithm Framework.

5.2.1 分类模型-改进的 ResNet50

ResNet 是功能最强大的 CNN 之一，具有无可比拟的性能和广泛的用途，包括作为主干网络进行特征提取和直接对图像分类。它可以应用于目标检测和图像分割领域。ResNet 网络是在借鉴 VGG19 网络的基础上进行创新的。它的变化主要体现在增加了残差单元，使用了步长为 2 的卷积进行下采样，以及使用了全局平均池层来代替全连接层。ResNet 的一个重要设计原则是，当特征映射的大小减

少一半时，特征层的数目增加一倍，从而保持了网络层的复杂性。加入残差模块后，可以减少 ResNet 中深层 CNN 的退化，构建更深层的网络，达到更好的效果。

如图 5.2 所示，通过加入捷径连接（shortcut connections）的 x 路径，残差网络变得更容易优化。包含捷径连接的神经网络的若干层被称为残差块。残差块由两条路径组成，一条用于正常卷积层，一条用于捷径连接。Conv 3×3 表示使用 3×3 卷积核的卷积运算。BN 表示批标准化操作。当输入为 x 时，我们要学习的特征是 $F(x)+x$ 。当残差为零时，残差模块只执行计算，性能不会降低。实际上，残差不会为零，这将使残差模块根据输入特征学习新的特征，因此具有更好的性能。




图 5.2 ResNet 的残差模块

Figure 5.2 Residual block

为了提高 ResNet 的性能，He 等（2019）提出了一种改进的 ResNet-vd 方法。如图 5.3 所示，ResNet 的残差模块在图的左边，ResNet-vd 在右边。主要改进如下：将步长为 2 的左半部分卷积 1×1 的下采样运算转换为 3×3 的卷积运算，取消了右半部分卷积 1×1 的下采样运算，并在特征图的下采样中增加了平均池化层。通过这些改进，模型在不增加计算量的情况下，显著提高了精度和鲁棒性，能够生成更好的特征图。Conv 1×1 表示使用 1×1 卷积核的卷积运算。BA 代表批量规范化操作和 relu 激活。B 代表批标准化操作。Avgpool 表示平均池化层。步长是卷积运算的步长。将其设置为 2 可以减小特征图的大小。“+”表示两条路径的特征图按像素相加。




图 5.3 ResNet 和 ResNet-vd 对比。(a) ResNet 残差模块。(b) ResNet 残差模块。

Figure 5.3 Comparison of ResNet and ResNet-vd. (a) ResNet residual block, (b) ResNet-vd residual block.

图 5.4 显示了 ResNet50-vd 网络的详细架构。图 5.4 左侧中的整个网络由 stem 模块、四组残差模块和一个全连接的神经网络层组成。图中的数字 32、64、256 表示卷积通道的数量。Stem 模块由三个 3×3 卷积和最大池化层组成，在第一个卷积和最大池化中使用步长=2 实现下采样。因此，stem 模块的输出的特征是输入的一半大小，其通道数为 64。从第一组残差模块到第四组残差模块里面都包含一个第一种类型的残差块和几个第二种类型的残差块。从图 5.4b 可以看出，第一种类型的残差块由两条路径组成，以形成下采样块。左侧是由三个卷积组成的瓶颈结构，用于学习新特征。右侧是由卷积和 AvgPooling 组成的结构，用于将输入处理为与瓶颈结构的输出相同的大小和比例。但是对于第二组到第四组残差模块，第一种类型的残差块与图 5.3b 相同，使用 stride=2 参数将特征映射的大小缩放到一半。第一种和第二种类型的残差块一样，由两条路径组成。不同的是，区块 2 右侧的结构是与底部结构形成残差模块的快捷连接。从 stem 到 Stage4 的输出特征映射的大小是[7, 14, 28, 56, 112]。从 stem 到第四组残差模块的卷积通道数是[64, 256, 512, 1024, 2048]。因此，第四组残差模块的最终输出特征映射为 $7 \times 7 \times 2048$ 。该模型的最后一个 FC 层使用平均池化层和完全连接层。平均池化层将每个通道的特征图从 7×7 平均到一个值，以第四组残差模块的输出为输入得到 $1 \times 1 \times 2048$ 的特征图。最后，通过一个具有 softmax 激活函数的全

连接层，输出两个值，即图像是否存在缺陷的概率。




图 5.4 ResNet-50-vd 网络结构图。(a) Stem 模块；(b) 第一组残差模块中第一类残差块；(c) 第一组残差模块中第二类残差块；(d) 全连接层模块。

Figure 5.4 The architecture of ResNet-50-vd. (a) Stem block; (b) Stage1-Block1; (c) Stage1-Block2; (d) FC-Block.

传统的卷积方法由于定义了计算规则，在物体被放大或旋转时不能自适应地改变，而可变形卷积方法则可以通过改变输入采样位置来实现自适应的改变。因此，在 ResNet-vd 中增加了 dcn-v2，提高了物体变形的适应性。从图 5.5 中，我们可以清楚地看到，可变形卷积使用额外的卷积层来学习偏移量。然后将输入特征映射和偏移量一起用作可变形卷积层的输入。首先对采样点进行偏移，然后根据输入的特征映射对采样点进行卷积。本文将可变形卷积技术应用于 ResNet50-vd 第二组到第四组残差模块的所有 3×3 卷积层。因此，网络中有 13 层可变形

卷积。




图 5.5 可变形卷积网络

Figure 5.5 Deformable convolution network

5.2.2 物体检测模型-增强的 Faster R-CNN

Faster R-CNN（Ren 等，2016）是一种两阶段的目标检测算法，由特征提取网络、区域建议网络（RPN）和 R-CNN 三部分组成，如图 5.6 所示。首先利用特征提取网络提取图像的特征映射，然后将提取的特征输入到 RPN 中生成边界框。然后用 R-CNN 对生成的边界框进行回归，得到更精确的边界框，并对边界框中的图像进行分类。




图 5.6 faster R-CNN

Figure 5.6 faster R-CNN

区域建议网络(RPN)首先在 faster R-CNN 中提出,得到用来预测的特征图。图片在输入网络后,依次经过一系列卷积和激活函数 ReLU 得到的 $51 \times 39 \times 256$ 维特征图,准备后续用来选取建议区域。

锚是固定尺寸的边界框。获取特征图锚的方法如下:首先将特征图的每个点都映射到原始图像的感受野中心并作为一个参考点,然后在参考点周围选择大小和比例不同的 K 个锚点。对于 $W \times H$ 大小的卷积得到特征图(一般是 2400 个),总共有 $W \times H \times K$ 个锚。默认情况下,使用 3 个比例和 3 个纵横比在每个滑动位置获得 $k=9$ 个锚。在特征图上的每个特征点预测多个区域建议。比如一个图像的特征图大小为 10×10 ,那么他就会产生 $10 \times 10 \times 9$ 个候选框。虽然锚是基于卷积特征图定义的,但最终的 锚是相对于原始图片的。




图 5.7 9 个候选框 (anchor) 示意图

Figure5.7 Schematic diagram of 9 anchor

对于特征图里的某一个像素位置,其相应会产生 9 个候选框。由于 RPN 的输入是拥有 256 个通道的特征图,因此要把所有通道里该位置的像素点全部由不同的 3×3 的卷积核进行卷积。然后把所有的卷积结果加起来,就能在该位置生成一个新的特征值。这样我们会使用到 256 个不同的 3×3 的卷积核,然后再该位置就会获得一个 256 维的向量,这个向量就可以用于分类和回归边界。

如图 5.6 R-CNN 部分所示,256 维向量后面对应两条分支,一条目标和背景的二分类 (classification),因为是二分类所以每个像素点需要生成 2×9 个分数,

具体的实现方法是利用 $1 \times 1 \times 256 \times 18$ 卷积核对 256 维向量进行卷积。每一组分数表示该像素点是背景或者是物体的分数。如果第一条分支的预测结果是物体区域，那么就需要预测该像素点的边界框的位置和大小，这里我们通过一个 $1 \times 1 \times 256 \times 36$ 的卷积核对 256 维向量进行卷积，获取到 $4 \times 9 = 36$ 个值。每四个值代表的是边界框的起始位置和大小 (x, y, w, h)。但是如果第一步预测的结果是背景，则直接把这个候选框删除，不用再进一步的通过卷积获取目标的位置和大小。

如图 5.8 所示，为了提高多尺度缺陷的检测效果，我们使用删除最后一个全连接部分的分类网络 ResNet50-vd-dcn 加上和 FPN 作为特征提取网络。同时，在 FPN P1-P5 之前的 Convblock 中加入了空间金字塔池 (SPP，图 5.9)，提高了对不同尺寸缺陷的检测精度。为了提高特征提取网络的效果，我们进一步用 Coordconv (Liu 等，2018) 代替 FPN 中的 1×1 卷积。它可以提高模型训练的效率，更高效地提取特征。

在 Faster R-CNN 的 RPN 中，我们需要非最大值抑制 (NMS) 来从具有相同类的边界框中选出最佳的。实现这一点的方法是消除那些置信度较低且 IOU 高于同一类的某个阈值的人。为了解决传统非最大值抑制中物体重叠和软-非最大值抑制 (Soft NMS) (Bodla 等，2017) 的串行计算效率低的问题，本文采用矩阵-非最大值抑制 (matrix NMS)。总体架构如下所示。




图 5.8 改进的 faster R-CNN 的架构

Figure 5.8 The architecture of enhanced faster R-CNN




图 5.9 空间金字塔池化

Figure 5.9 Spatial pyramid pooling (SPP)

5.2.3 focal 损失函数

由表 5.1 和 5.2 可知，数据集中的各类缺陷的数量存在很大的不平衡性，尤其是开裂缺陷只占缺陷样本总数的百分之一一点六。而且，无缺陷样本数过大，占总损失的大部分，这使得模型的优化方向不是我们想要的。为了减少不平衡数据集对算法的影响，首先采用数据增强的方法，将银纹缺陷样本扩展到 800 个，以增加样本的多样性。此外，在训练中引入了加权交叉熵损失函数（Cai 等，2016）和 focal 损失函数函数（Lin 等，2020）。

我首先介绍一下标准的交叉熵损失函数。通常情况下交叉熵表示的是两个概率分布的距离，值越小两个分布就越接近。交叉熵损失函数也是算法输出和标签之间的交叉熵。值越高，输出越与标签相同，精度越高。公式 5.1 用于计算交叉熵损失。

$$j_{CE} = -\frac{1}{n} \sum_{i=1}^n \log(p_i) \quad \dots (5.1)$$

这里的 $p_i = \begin{cases} p, & \text{if } y = 1 \\ 1-p, & \text{if } y \neq 1 \end{cases}$, $p = \text{sigmoid}(x)$, x 是算法的输出, y 是实际的标签。

加权交叉熵的思想是用一个系数来描述样本在损失中的重要性。对于少量样品，加强其对损失的贡献，对于大量样品，减少其对损失的贡献。公式如 5.2。

$$j_{WCE} = -\frac{1}{n} \sum_{i=1}^n \log(p_i) \quad \dots (5.2)$$

这里的 $p_i = \begin{cases} w^* p, & \text{if } y = 1 \\ 1-p, & \text{if } y \neq 1 \end{cases}$, 这与交叉熵之间只有很小的变化，即在正样本

的判别中加入一个系数。在目标检测任务中，每个缺陷的权重由一个列表 [1.5, 2.0, 1.0, 1.5] 表示。在分类任务中，列表是 [1.0, 2.0]。

在交叉熵损失的基础上，提出的 focal 损失函数。这种新的损失函数可以减少容易分类的样本的权重，使模型更加注重困难样本的学习，公式如 5.3 所示。

$$j_F = -\alpha_t(1-p_t)^\gamma \log(p_t) \quad \dots (5.3)$$

这里的 $\alpha_t = \begin{cases} \alpha, & \text{for } y=1 \\ 1-\alpha, & \text{for } y \neq 1 \end{cases}$, p_t 和交叉熵损失的一样。 α 和 γ 是超参，本文中

使用的是 $\gamma=2$ 以及 $\alpha=0.75$ 。 γ 称为调制因子。它可以调整易分类样本的权重，使得模型在训练中更加注重学习难分类样本。

5.2.4 数据增强

由于训练 CNN 需要大量的样本，在实际生产环境中很难获得。本文利用数据增强来增加样本的多样性，提高算法的精度和鲁棒性。该模型采用正则化的数据增强方法，减少了过拟合，提高了网络的泛化能力。本文采用的方法包括改进的剪切、水平翻转、垂直翻转、随机裁剪、随机对比度和亮度变换。图 5.10 显示了各种数据扩充方法的结果。




图 5.10 数据增强。(a) 原始图像；(b) 改进的 cutout 方法；(c) 水平翻转；(d) 垂直翻转；(e) 随机裁剪；(f) 亮度和对比度变换；

Figure 5.10 Data augmentation. (a) Original image; (b) improved cutout; (d) horizontal flip; (e) vertical flip; (f) random crop; (g) random contrast and brightness transformation

原始的 Cutout 方法非常简单,即随机删除图像上的一个区域,并将其替换为零。本文研究了一个目标检测问题,包括四个缺陷的标签盒和类别信息。因此,我们改进了裁剪方法,概率为 0.5 的随机删除标签框,并用 0 填充。只有删除样本中的所有标签框后,标签才会更改为“无缺陷”。如图 5.10a, b 所示,原始图像中有两个划痕缺陷。随机改进的剪切数据增强后,只留下一个缺陷,另一个缺陷区域用 0 填充。图 5.10c, d 中使用了水平和垂直翻转,概率为 0.5。图 5.10e 中使用了随机裁剪。图像的顶部、底部、左侧和右侧的裁剪不超过 15%。之后,图像的大小调整为 400×256 。图 5.10f 中使用了随机对比度和亮度变换。使用 0.5 的概率来决定是进行对比度变换还是亮度变换。如果改变这两个参数,则图像的变换范围限制为 50%。

5.2.5 k-means++聚类算法

这里我们介绍的 K-means 算法是一个典型的利用样本点之间的距离来进行聚类的算法,通过计算两个样本之间的距离来评价他们的相似性,距离的值越小那么两个样本之间的相似性越大。该算法聚类的到的各个类是相互之间距离近的样本组成的,所以得到的各个类别类内距离小、类间距离大就是算法的目标。算法的执行步骤如下:

- a、首先再图片中随机的取 K 个种子点(即聚类中心);
- b、随后使用距离计算的公式计算全部的样本点到聚类中心的距离,那么样本距离那个聚类中心近,它就属于哪个类;
- c、计算新的聚类中心,使用类内的所有点的中心点替换原来的聚类中心;
- d、最后重复的执行 b、c 两个步骤,知道聚类中心几乎不变。

K-Means 聚类算法它的优点各重点体现在: 1、该算法简单运行速度快; 2、在处理大数据集的时候也效率也很高; 3、这个算法的时间复杂度几乎是线性的,这样使得该算法很适合挖掘大数据中的数据之间的关系。它的时间复杂度是 $O(n*k*t)$, 这里的 n 表示数据集中总共有多少数据, t 表示算法一共迭代多少次, k 表示我们想把数据聚类成几类。同时 K-Means 算法也有它自身的缺点: 1、在该算法中需要在运行前指定 k 的大小,并且这个值很影响算法的效果,因此选定一个好的 k 很难需要有一定的经验。2、在该算法中初始的 k 个类的中心也非常的难选择,因为后面的聚类算法的运行依赖这些初始化的类中心。如果选择的

类中心有问题，就很难得到想要的结果。3、从上面介绍的算法运行步骤我们可以知道，这个算法需要持续的计算出新的 k 个聚类中心，因此当数据量比较大的时候该算法计算量也会很大。因此原始的 **K-means** 算法需要在时间复杂度和性能上进行改进。

其中一种改进算法是对原始的 **K-means** 算法中简单的初始聚类中心选择进行的改进，该算法叫做 **k-means++** (Arthur 等, 2007)。**k-means++** 算法中为了克服随机选取造成的问题，改用的初始聚类中心选择方法步骤如下：

- a、首先我们从数据集中随机选取一个数据作为第一个中心；
- b、然后把数据集中的每个数据都和选取的聚类中心进行距离计算，得到 $D(x)$ ；
- c、选择一个 b 步骤中 $D(x)$ 比较大的数据，加入到聚类中心中；
- d、我们重复的执行步骤 b 和步骤 c，最后选出来 k 个聚类中心；
- e、把通过这个方法得到的 k 个聚类中心当作 **k-means** 算法初始聚类中心，那么就变成了 **k-means++** 算法。

5.3 实验结果与分析

5.3.1 数据集

本文中使用的是 Kaggle “Severstal: Steel Defect Detection” (Severstal 等, 2019) 比赛中的数据集进行研究的。这个数据集总共有 12568 个分辨率为 1600x256 的钢板灰度图片以及其标注信息。因为在原始的数据集中高和宽有很大的差距，因此我们把每个图片切分成了四个 400x256 的图片。因此我们一共研究了 50272 个样本，包括 37080 个没有缺陷的样本，12876 个有缺陷的样本以及 316 个有两类缺陷的样本。如图 5.11 所示，在数据集中有四类的缺陷分别是：麻点、开裂、划痕以及斑块。

如表 5.1 所示，分类模型把所有有缺陷的样本当作一类，把所有无缺陷的样本当作一类。表 5.2 展示了物体检测模型的样本分布。1306 个图片含有麻点缺陷、214 个图片含有开裂缺陷、9980 个图片含有划痕缺陷以及 1376 个图片含有斑块缺陷。最后有 316 个图片含有两类的缺陷。




图 5.11 多个类别的表面缺陷样本例子。(a) 麻点 (b) 开裂 (c) 划痕 (d) 斑块 (e) 无缺陷

Figure 5.11 Examples of various types surface defect. (a) Pitted surface; (b) crazing; (c) scratches; (d) patches; (e) no defect.

表 5.1 分类模型使用的数据集

Table 5.1 Classification model dataset

类别	训练集	测试集	总计
有缺陷	10553	2639	13192
无缺陷	29664	7416	37080
总计	40217	10055	50272

表 5.2 物体检测模型使用的数据集

Table 5.2 Object detection model dataset

类别	训练集	测试集	总计
麻点	1044	262	1306
开裂	171	43	214
划痕	7984	1996	9980
斑块	1100	276	1376
多类别缺陷	252	64	316
无缺陷	29664	7416	37080
总计	40215	10057	50272

由图 5.1, 我们可以看到再钢带表面缺陷检测工作中麻点表面缺陷通常很小。为了分析缺陷区域的面积大小我们绘制了图 5.12。从图 5.12 可以看出, 面积很小的缺陷占统计值的比例很大。裂纹缺陷面积较小。为了提高小缺陷检测的精度, 本文采用 SPP 和 FPN 来提高多尺度特征提取的效果。




图 5.12 各种缺陷面积大小的统计结果

Figure 5.12 Statistical results of area size of various defects.

通过计算各种缺陷的长宽比, 我们发现裂纹和划痕缺陷的长宽比很大, 如图 5.13a 所示。划痕比例很小的缺陷也占很大比例, 如图 5.13b 所示 (b 仅显示 0 - 2.4 范围内的数据, 更详细)。为了提高这两部分的检测精度, 将 faster R-CNN 中的锚设置从 [0.5, 1, 2.0] 改为 [0.25, 0.5, 1, 2, 5]。通过使用 k-means++ 算法对边界框进行聚类, 发现这种设置也能满足大多数缺陷的需要。聚类结果如表 5.3 所示。




图 5.13 各种缺陷高宽比的统计结果。(a) 各种缺陷的长宽比；(b) (a) 中 0-2.4 范围内更详细的数据

Figure5.13 Statistical results for the ratio of height to width of various defects. (a) aspect ratio of various defects; (b) data in (a) in the range of 0–2.4, in more detail

表 5.3 使用 k-means++ 算法聚类算法得到的的锚的结果

Table 5.3 Cluster anchor using k-means++ algorithm.

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25
长	34	436	134	252	38	72	510	512	320	62	172	106	510	82	246	136	510	74	190	508	252	114	504	144	312
宽	9	9	18	20	23	23	23	31	32	35	35	36	45	58	58	70	73	108	119	142	218	219	294	511	512

5.3.2 训练

由于存在缺陷的样本数较少,采用迁移学习的方法来提高分类和目标检测模型的准确性和稳定性。首先用 Imagenet 数据集对所有模型进行训练,然后将训练参数作为本文所用模型的初始参数。如表 5.1 和表 5.2 所示,我们将数据集划分为 80%比例的训练集和 20%比例的验证集。

本文研究了分类模型和目标检测模型。分类模型的任务是将样本分为有缺陷样本和无缺陷样本。目标检测模型的任务是识别样本中缺陷的位置和类别。

在分类模型中,为了找到更适合这个数据集的学习率,我们使用搜索方法在 $[10^{-7}-10]$ 范围内找到最佳学习率。搜索方法是设定一个学习率,然后训练一个批次,得到模型的损失。搜索结果如图 5.14 所示。最后,我们选择了 0.01 的学习率。为了优化函数,我们选择动量,它比原 SGD 收敛速度快,振荡小, $\text{momentum}=0.9$ 。




图 5.14 寻找学习率

Figure 5.14 Find learning rate (Lr)

该模型共训练了 80 次。训练 40 次后,每 20 次的学习率乘以 0.5。训练过程的损失如图 5.15 所示。训练中使用的硬件环境是 AMD Ryzen 5 2600x CPU、32G DDR4 RAM 和 NVIDIA GTX 1080 GPU,具有 8GB 的显存。深度学习框架使用开源的 paddle,版本 2.0。图 5.16 显示了训练过程中准确度的变化。最大值约为

0.974。




图 5.15 分类模型损失

Figure 5.15 Loss of the classification model.




图 5.16 分类模型准确率

Figure 5.16 Accuracy of the classification model.

在目标检测模型中，我们训练了 50 次，学习率为 0.0025，批量大小为 4，预热批次为 2500。训练 40 次后，每 5 次的学习率乘以 0.25。为了优化函数，我们选择了与 $\text{momentum}=0.9$ 的分类模型相同的动量。数据增强使用随机裁剪、水平翻转、垂直翻转、对比度和亮度变换。最后，将输入图像大小更改为 800×1344 。

训练中使用的硬件环境是 AMD Ryzen 5 2600x CPU、32G DDR4 RAM 和 NVIDIA GTX 1080 GPU。图 5.17 和图 5.18 分别显示了训练过程中损失和 bbox_map 的变化。Bbox_map 最大值为 87.6。




图 5.17 目标检测模型的损失

Figure 5.17 Loss of object detection model.




图 5.18 目标检测模型的 Bbox_map 值

Figure 5.18 Bbox_map of object detection model.

5.3.3 评价指标

为了准确评价模型的效果,本文选取了召回率、查准率、F1 评分、平均精度 (AP)、平均精度 (mAP) 等指标对模型进行比较。

表 5.4 显示了混淆矩阵,其中真阳性 (TP) 表示阳性样本被正确识别为阳性样本,真阴性 (TN) 表示阴性样本被正确识别为阴性样本,假阳性 (FP) 表示阴性样本被错误识别为阳性样本,而假阴性 (FN) 是指阳性样本被错误地识别为阴性样本。

表 5.4 混淆矩阵

Table 5.4 Confusion matrix.

真实类别	预测类别	
	真	假
真	TP	FN
假	FP	TN

召回率的定义如公式 5.4 所示,它表示样本中正确识别的阳性样本的比例。

$$Recall = \frac{TP}{TP + FN} \quad \dots (5.4)$$

查准率的定义如公式 5.5 所示,表示实际阳性样本在已识别阳性样本中所占的比例。

$$Precision = \frac{TP}{TP + FP} \quad \dots (5.5)$$

单独使用召回率或查准率不能很好地评估模型的性能。因此,引入 F1 分数来综合考虑召回率和查准率。F1 分数的定义如公式 5.6 所示。

$$F_1 = 2 \frac{Precision \cdot Recall}{Precision + Recall} \quad \dots (5.6)$$

精度一般用于评价模型的全局精度,不能包含太多的信息,不能全面评价模型的性能。其定义如公式 5.7 所示。

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad \dots (5.7)$$

AP 是 P-R 曲线下的面积。一般来说,分类越好,AP 值就越高。mAP 是多个类的 AP 的平均值。这意味着每个类的 AP 被再次平均,得到 mAP 的值。该指标是目标检测算法中最重要的指标。

5.3.4 分类模型结果分析

对于分类算法，我们比较了 ResNet 和 ResNet_vd、ResNet_vd_dcnv2、ResNet_vd_dcnv2_ImprovedCutout、Fadli 等（2020）和 konovalenko 等（2020）。结果表明，改进后的方法具有更好的性能，最高精度可达 0.9752。通过比较发现，改进的卷积块（Res-Net-vd）、DCN 和改进的 Cutout 方法可以提高模型的精度。表 5.5 中的最后一列显示了批处理大小为 4 的每个模型的平均运行时间。可以看出，在不显著增加运行时间的情况下，模型的精度得到了提高。对于 ResNet_vd_dcnv2_ImprovedCutout，它优化了训练过程中的数据增强，但只提高了模型训练的时间，提高了模型的精度。因为模型的结构没有改变，所以它预测需要的时间与 ResNet_vd_dcnv2 相同。

表 5.5 分类模型效果对比

Table 5.5 Comparison of the classification models

模型	原始图像		水平翻转		垂直翻转		测试时增强		运行时间
	F1	Acc	F1	Acc	F1	Acc	F1	Acc	
Fadli 等，2020	--	0.94	--	--	--	--	--	--	
ResNet	0.968	0.969	0.9627	0.9628	0.9626	0.9627	0.9673	0.9675	2.40ms
Konovalenko 等，2020	--	0.9691	--	--	--	--	--	--	
ResNet_vd	0.9707	0.9708	0.9694	0.9695	0.9689	0.9690	0.9710	0.9711	2.44ms
ResNet_vd_dcnV2	0.9732	0.9732	0.9726	0.9726	0.9730	0.9731	0.9739	0.9739	2.9ms
ResNet_vd_dcnV2_ImprovedCutout	0.9747	0.9747	0.9744	0.9744	0.9745	0.9745	0.9752	0.9752	2.9ms

该算法采用测试时增强（TTA）方法进行验证。从表 5.5 可以看出，测试时增强可以提高精度约 0.05%。图 5.19 显示了 TTA 之后分类模型的混淆矩阵。可以看出，无论是有缺陷还是无缺陷的样本，最后一种模型的分​​类错误率都是最低的。图 5.20 所示为 ResNet_vd_dcnv2_ImprovedCutout 的 P-R 曲线和 ROC 曲线。可以看出，该模型在均衡点的召回率和查准率都有较高的值，说明该模型具有较高的准确率和鲁棒性。




图 5.19 测试时增强 (TTA) 后分类模型的混淆矩阵。(a) ResNet (b) ResNet-vd (c) ResNet-vcd-dcnV2 (d) ResNet-vd-dcnV2-ImprovedCutout。

Figure 5.19 Confusion matrix of the classification model after test time augmentation (TTA). (a) ResNet (b) ResNet-vd (c) ResNet-vcd-dcnV2 (d) ResNet-vd-dcnV2-ImprovedCutout.




图 5.20 ResNet_vd_dcnv2_Improvedcutout 模型的结果。(a) P-R 曲线；(b) ROC 曲线

Figure 5.20 The result of ResNet_vd_dcnv2_Improvedcutout. (a) P-R Curve; (b) ROC Curve

5.3.5 物体检测模型结果分析

图 5.21 显示了改进的 faster R-CNN 目标检测模型的缺陷检测结果。在验证集中选择了每个类的三个缺陷图像。首先将它们调整为 800×1344 ，然后输入训练好的 faster R-CNN 模型，得到缺陷检测结果。将概率值大于 0.5 的边界框绘制到图片中，边框设置为绿色，如下图 5.21a-e 中的所示。原始数据集中标记的边界框以蓝色绘制到原始图像，得到了上排图像。从 (a) 到 (e) 分别显示了麻点表面缺陷、开裂缺陷、划痕缺陷、斑块缺陷和多个缺陷的检测结果。从 a 可以看出，该模型能够检测到真实标签没有标记的缺陷。这个缺陷确实存在，但并不明显。从 b 可以清楚地看出，裂纹缺陷非常细。通过对 R-CNN 中的锚进行改进，提高了该类锚的检测精度。该算法从 c 中样本中检测到的缺陷区域多于标记的边界框。这也显示了原始数据集中的一些样本标记不准确的问题。该数据集将在今后的研究中进一步处理。从 d 和 e 两个方面可以看出，该算法能够很好地检测缺陷，并确定缺陷的类别。特别是，可以检测到 e 中的多种缺陷。

mAP 是评价目标检测模型的一个重要指标。如表 5.6 所示，我们使用 mAP 来比较各种模型。我们可以看到，基于 faster R-CNN 的模型比基于 YOLO 的模型具有更高的 mAP。添加的 DCN 模块可以更好地适应各种形状的缺陷。FPN 和 SPP 能较好地检测多尺度缺陷，尤其是小而多的麻点缺陷。目标检测模型也是在像素块空间找到的，输出是笛卡尔空间中的边界框，所以 Coordconv 是非常合适的。加入 Coordconv 可以从整体上提高模型的 AP 值。最终模型的 mAP 值为 0.876，能够准确地检测出钢材表面缺陷。

表 5.6 每种缺陷的 AP 和模型的 mAP

Table 5.6 The AP of each type of defect and the total mAP of the model

模型	缺陷类别				mAP	平均运行 时间
	麻点	开裂	划痕	斑块		
YOLOv3	0.700	0.643	0.749	0.724	0.704	126.4ms
Faster-RCNN	0.801	0.767	0.874	0.865	0.827	208.7ms
Faster-RCNN + DCN	0.806	0.782	0.881	0.876	0.836	283.2ms
Faster-RCNN + DCN + FPN&SPP	0.840	0.818	0.902	0.895	0.864	210.3ms
Faster-RCNN + DCN + FPN&SPP + Coordconv	0.845	0.829	0.913	0.916	0.876	214.5ms




图 5.21 检测结果。(a) 麻点缺陷；(b) 开裂缺陷；(c) 划痕缺陷；(d) 斑块缺陷；
(e) 多个缺陷

Figure 5.21 Detection results. (a) Pitted surface defect; (b) crazing defect; (c) scratches defect;
(d) patches defect; (e) multiple defects

5.3.6 整体模型结果分析

为了提高算法的精度和稳定性，减少了处理每幅图像的平均运行时间。在本文中，我们结合使用分类模型和目标检测模型，如图 5.1 所示。首先，将图像输入分类模型，得到样本的缺陷概率。如果概率小于 0.3，我们将直接输出无缺陷的样品。通过这种方法，我们获得了 7224 个预计没有缺陷的样品。这些样品的准确度为 0.991，包括 7159 个预测结果正确的样本和 65 个预测结果错误的样本。其次，利用目标检测模型对剩余的 2830 个样本进行处理。这些样品的最终准确度为 0.961。这种精度比直接使用检测模型的所有样本要低，因为经过分类模型处理后，剩下的没有缺陷的样本更难检测。最后，从表 5.7 可以看出，对分类模型和目标检测模型的精度进行了分析，整个模型的精度为 0.982。

表 5.7 模型精度与平均运行时间的比较

Table 5.7 Comparison of model accuracy and average running time

模型	准确率	平均运行时间
Wei 等 (2020)	0.97	209.4 ms
增强的 Faster R-CNN	0.972	214.5 ms
分类和目标检测模型融合	0.982	63.3 ms

5.4 本章小结

本章实现了钢板表面缺陷的自动检测和定位，进一步提高了精度和稳定性，减少了算法的平均运行时间。在本章中，我们研究了一种将二值分类模型与目标检测模型相结合的方法来减少平均运行时间。通过分析发现，麻点表面缺陷通常较小且不明显，故该类缺陷的准确度不高。在改进的 faster R-CNN 模型中，通过在 faster R-CNN 的特征提取部分加入 FPN 和 SPP，提高了这类缺陷的识别精度。另外，裂缝缺陷检测的准确性不高，因为它又窄又长。通过改变 faster R-CNN 的默认锚的大小，提高了定位精度。利用新的矩阵 NMS 算法，可以在目标检测算法的最后阶段更快更好地得到边界框。在分类模型和目标识别模型的主干 ResNet50-vd 改进模型中，通过加入 DCN 和改进的 Cutout 数据增强，可以更好地检测出各种形状的缺陷，具有更高的精度和鲁棒性。

通过比较，我们发现该方法可以应用于钢铁表面缺陷检测，具有较高的精度。将改进的 ResNet 分类模型与改进的 faster-R-CNN 目标检测模型相结合，取得了

较好的效果。分类精度由单一分类模型的 0.975 和目标检测模型的 0.972 变为最终模型的 0.982。模型的平均运行时间明显缩短。

第 6 章 结束语

6.1 全文总结

在中国制造 2025 这个战略中指出要更快的提高产品的质量, 制定提升产品质量的实施计划。并且鼓励企业推广采用智能化检测设备。提高我国产品的鲁棒性、可靠性、适应性以及使用寿命, 并具有国际同类产品竞争力。对于一个企业来说, 产品质量是企业发展和竞争的基石。提高产品的质量对于企业十分重要。为进一步提升产品缺陷检测的自动化程度, 使用机器学习或者深度学习方法来进行检测已经成为了发展的方向。研究基于机器视觉的产品缺陷检测算法对发展智能生产线有着至关重要的作用, 也是我国工业生产智能制造的关键一步。在过去的几十年中, 有大量的研究人员参与了钢铁表面缺陷检测的研究。此外, 随着机器学习和计算机视觉的发展, 各种算法被提出。传统的基于机器学习的方法对缺陷规模和噪声非常敏感, 容易受到影响。而且, 该算法的精度不能满足自动缺陷检测的实际需要。有些功能需要手工设计, 应用范围非常有限。因此, 本课题研究机器视觉方法用于产品缺陷检测的研究有着重要的现实意义, 本课题的研究对实现智能制造具有重要的理论意义及实际价值。具体创新点和研究内容总结如下:

1. 提出了一种基于区域特征聚类显著性检测的表面缺陷图像分割算法。使用多带宽无参聚类算法得到显著性图、通过神经网络合并特征以及使用循环将每次检测结果作为新的特征输入到特征向量等方法提升算法效果, 使用 GPU 加速超像素分割的计算。首先使用超像素算法对图像分割, 然后对分割的算法求取特征向量。再使用多带宽无参聚类算法对特征向量聚类, 得到十个带宽下的显著性图。通过神经网络对显著性图进行合并。把最后得到的显著性图作为一个新的特征再次重复以上过程。重复十次后得到最终的缺陷图像分割图。通过实验表明, 本算法和其他算法比较, 在效果、准确率、召回率、F 值以及 MAE 上都有提高。

2. 提出了基于 U-net 和迁移学习的学习方法。通过使用 EfficientNet 作为主干网络来提取特征并使用 U-net 在多个尺度上融合特征, 实现了较高的精度。使用数据增强增加了样本的多样性, 使用迁移学习减少了样本量小对训练高精度模型的影响。首先, 使用数据增强扩展数据集。然后使用 EfficientNet 作为主干来提取特征。使用 U-net 在多个尺度上融合特征。最后, 通过一层卷积得到大小为

512×512×4 的四类缺陷的映射。实验表明,该算法比其他算法具有更高的精度和鲁棒性。平均 Dice 系数达到 0.905。虽然本章提出的算法取得了很好的效果。但在运行时间和准确性方面仍有很大的改进空间。

3. 提出了一种基于迁移学习和多尺度特征融合的表面缺陷检测算法。在获取了 5 种特征映射后利用反卷积进行融合,在提升算法精度的同时减少了算法的运行时间。同时采用批归一化和卷积层融合的方法来减少 5% 的算法运行时间。使用数据增强增加了样本的多样性,使用迁移学习减少了样本量小对训练高精度模型的影响。首先,利用数据增强技术对数据集进行扩展。接下来,我们使用 EfficientNet 作为主干来获取特征图。从重复的 BiFPN 模型中得到了五种不同尺度的特征映射。然后利用反卷积将五种特征图融合在一起,再利用一层卷积得到各种缺陷的掩码图。在最后的训练之后,我们采用批归一化和卷积层融合的方法来减少算法的运行时间。实验结果表明,该算法的平均 Dice 系数为 0.912。优于其他深度学习算法的钢材表面缺陷检测。

4. 提出了一种将改进的二值分类模型与增强的目标检测模型相结合的方法来减少平均运行时间。通过分析发现,麻点表面缺陷通常较小且不明显,故该类缺陷的准确度不高。在改进的 faster R-CNN 模型中,通过在 faster R-CNN 的特征提取部分加入 FPN 和 SPP,提高了这类缺陷的识别精度。另外,裂缝缺陷检测的准确性不高,因为它又窄又长。通过改变 faster R-CNN 的默认锚的大小,提高了定位精度。利用新的矩阵 NMS 算法,可以在目标检测算法的最后阶段更快更好地得到边界框。在分类模型和目标识别模型的主干 ResNet50-vd 改进模型中,通过加入 DCN 和改进的 Cutout 数据增强,可以更好地检测出各种形状的缺陷,具有更高的精度和鲁棒性。首先,图像的大小调整为 224×224。然后,在改进的 ResNet50 分类模型中,通过阈值=0.3 将样本分为无缺陷样本和其他样本,并加入了可变形旋转网络(DCN)和改进的裁剪。如果有缺陷的概率小于 0.3,算法直接输出无缺陷的样本。其他样本的大小调整为 800×1344,并进一步输入到改进的快速 R-CNN 目标检测模型中,加入空间金字塔池(SPP)、增强特征金字塔网络(FPN)和矩阵 NMS 对缺陷进行检测。最终输出是样本中缺陷或样本中无缺陷的位置和分类。最后对分类模型和目标检测模型的精度进行了分析,整个模型的精度为 0.982。

6.2 展望

表面缺陷检测是一个系统性的工程，从图像采集、图像处理到缺陷检测算法都还有很长的路要走。未来还有很大的挑战，还需要进一步的研究的工作有：

1. 数据集的标注信息存在一些问题。例如，一些麻面缺陷没有标记，一些标记有缺陷的区域有问题，一些有缺陷的图像放在没有缺陷的样品中。虽然对部分样本的标注信息进行了修改，但在今后的研究中还将进一步完善。经过对数据集的处理，算法将得到进一步的改进，达到更高的精度。

2. 因此使用了深度学习算法需要很大的计算量，为了满足工业中实时检测的需求。在未来的研究中，我们将研究模型压缩和加速的方法，这样可以大大减少算法的运行时间。

3. 因为工业环境中需要更加准确的缺陷检测算法，并且实际的生产环境中缺陷图片的获取很困难，就造成了数据集一般都比较小。因此需要进一步的研究小样本学习在缺陷检测中的应用。并开发更加准确的检测算法。

参考文献

- 陈海永, 徐森, 刘坤,等. 基于 Gabor 小波和加权马氏距离的带钢表面缺陷检测[J]. 电子测量与仪器学报, 2016(30):786-793.
- 陈海永, 徐森, 刘坤,等. 基于谱残差视觉显著性的带钢表面缺陷检测[J]. 光学精密工程, 2016, 24(010):2572-2580.
- 甘胜丰, 雷维新, 周成宏. 机器视觉表面缺陷检测技术及其在钢铁工业中的应用[M]. 武汉: 华中科技大学出版社, 2017.
- 谷艳红, 张振振, 高先和,等. 激光超声结合电磁超声在铝板无损检测中的应用研究[J]. 中国激光, 2020, v.47;No.521(05):422-428.
- 郭皓然, 邵伟, 周阿维,等. 全局阈值自适应的高亮金属表面缺陷识别新方法[J]. 仪器仪表学报, 2017, v.38(11):2797-2804.
- 郭慧, 徐威, 刘亚菲. 基于支持向量机的钢板表面缺陷检测[J]. 东华大学学报(自然科学版), 2018(4):635-639.
- 李翰超, 古阳, 于亚婷. 基于涡流无损检测技术的金属表面缺陷三维模拟分析[J]. 电子科技大学学报, 2020, v.49(06):145-151.
- 李维刚, 叶欣, 赵云涛,等. 基于改进 YOLOv3 算法的带钢表面缺陷检测[J]. 电子学报, 2020(7).
- 李炜, 黄心汉, 王敏,等. 基于机器视觉的带钢表面缺陷检测系统[J]. 华中科技大学学报(自然科学版), 2003, 31(2):72-74.
- 罗新斌 2016
- 秦钟伟, 陈捷, 洪荣晶,等. 摩擦片表面缺陷的视觉显著性检测算法[J]. 浙江大学学报:工学版, 2019(10):1883-1891.
- 孙瑜, 罗飞路, 赵东明. 利用交变磁场测量法的金属表面缺陷检测[J]. 兵工自动化, 2004, 23(2):44-44.
- 汤勃, 孔建益, 王兴东,等. 钢板表面低对比度微小缺陷图像增强和分割[J]. 中国图象图形学报, 2020(1):81-91.
- 王一鸣, 杜慧敏, 张霞,等. 视觉注意力网络在工件表面缺陷检测中的应用[J]. 计算机辅助设计与图形学学报, 2019(9).
- 王卓, 张长胜, 李伟,等. 结合混沌鸟群算法的阴极铜板表面缺陷检测[J]. 中国图象图形学报, 2020, v.25;No.288(04):73-83.
- 吴德会, 刘志天, 王晓红,等. 表面缺陷的方向性对漏磁场分布的影响[J]. 物理学报, 2017.
- 杨理践, 郑文学, 高松巍, 刘斌. 基于平衡电磁技术的钢板裂纹缺陷检测方法[J]. 仪器仪表

- 学报, 2020, v.41(10):198-205.
- 赵宇峰, 高超, 王建国. 基于机器视觉的工业产品表面缺陷检测算法研究[J]. 计算机应用与软件, 2012(02):158-160.
- 郑彬,王鑫. 基于机器视觉的型材表面缺陷图像处理[J]. 机械设计, 2020, v.37(S1):99-101.
- 周鹏, 徐科, 刘顺华. 基于剪切波和小波特征融合的金属表面缺陷识别方法[J]. 机械工程学报, 2015, 51(006):98-103.
- 左欧阳, 武美萍, 唐又红. 基于 COMSOL 的激光超声裂纹检测数值模拟研究[J]. 激光与红外, 2020(10).
- 赵永强, 饶元, 董世鹏,等. 深度学习目标检测方法综述[J]. 中国图象图形学报, 2020, v.25;No.288(04):5-30.
- Abadi, M.; Agarwal, A.; Barham, P.; Brevdo, E.; Chen, Z.; Citro, C.; Corrado, G.S.; Davis, A.; Dean, J.; Devin, M.; et al. Tensorflow: Large-scale machine learning on heterogeneous distributed systems. arXiv 2016, arXiv:1603.04467.
- Abueidda, D.W.; Koric, S.; Sobh, N.A.; Sehitoglu, H. Deep learning for plasticity and thermo-viscoplasticity. Int. J. Plasticity 2021, 136, 102852, doi:10.1016/j.ijplas.2020.102852.
- Achanta R, Hemami S, Estrada F, et al. Frequency-tuned salient region detection[C]. Computer Vision and Pattern Recognition. IEEE,CVPR 2009:1597-1604.
- Achanta R, Shaji A, Smith K, et al. SLIC Superpixels Compared to State-of-the-Art Superpixel Methods[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2012, 34(11):2274-2282.
- Agoes A S, Hu Z, Matsunaga N. DSLIC: A Superpixel Based Segmentation Algorithm for Depth Image[C]. Asian Conference on Computer Vision. Springer, Cham,ACCV 2016:77-87.
- Aiger, D.; Talbot, H. The phase only transform for unsupervised surface defect detection. In Proceedings of the 2010 IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2010), San Francisco, CA, USA, 13–18 June 2010; pp. 295–302.
- Arthur, D.; Vassilvitskii, S. k-means++: The advantages of careful seeding. In Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms, New Orleans, LA, USA, 7–9 January 2007; pp. 1027–1035.
- Badrinarayanan V , Kendall A , Cipolla R . SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017:1-1.
- Ban Z, Liu J, Fouriaux J. GLSC: LSC superpixels at over 130 FPS[J]. Journal of Real-Time Image Processing, 2018, 14(3): 605-616.
- Bodla, N.; Singh, B.; Chellappa, R.; Davis, L.S. Soft-NMS—Improving Object Detection with One Line of Code. In Proceedings of the 2017 International Conference on Computer Vision (ICCV 2017), Venice, Italy, 22–29 October 2017; pp. 5561–5569.
- Borji A, Cheng M M, Jiang H, et al. Salient Object Detection: A Benchmark[J]. IEEE Transactions

- on Image Processing, TIP, 2015, 24(12):5706-5722.
- Cai, Z.; Fan, Q.; Feris, R.S.; Vasconcelos, N. A unified multi-scale deep convolutional neural network for fast object detection. In Proceedings of the 14th European Conference on Computer Vision (ECCV 2016), Amsterdam, The Netherlands, 11–14 October 2016; pp. 354–370.
- Cao, C., Do, V. & Lee, B. Tube Defect Detection Algorithm Under Noisy Environment Using Feature Vector and Neural Networks. *Int. J. Precis. Eng. Manuf*, 2019, 20, 559–568.
- Chen L C , Papandreou G , Kokkinos I , et al. DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2018, 40(4):834-848.
- Chen L C , Zhu Y , Papandreou G , et al. Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation[C]. *European Conference on Computer Vision*, 2018.
- CHEN Nan-er, CHEN Ying. Image Saliency Detection Using Background and Centroid Prior [J]. *Journal of Chinese Computer Systems*, 2016, 37(10): 2371-2374.
- CHEN Nan-er, CHEN Ying. Multi-scale Image Saliency Detection Fusing Context Information [J]. *Journal of Chinese Computer Systems*, 2017, 38(9): 2161-2165.
- Cheng M M, Mitra N J, Huang X, et al. Global Contrast Based Salient Region Detection[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2015, 37(3):569-582.
- Chollet, F. Deep Learning with Python; Manning Publications Co.: Shelter Island, NY, USA, 2018.
- Chollet, F. Xception: Deep Learning with Depthwise Separable Convolutions. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition(CVPR), Honolulu, HI, USA, 21–26 July 2017; pp. 1251-1258.
- Ciptadi A, Hermans T, Rehg J. An In Depth View of Saliency[C]. *British Machine Vision Conference. BMVC 2013*:112.1-112.11.
- Comaniciu D, Meer P. Mean shift: a robust approach toward feature space analysis[J]. *IEEE Trans Pattern Analysis & Machine Intelligence*, 2002, 24(5):603-619.
- Cui, Xiaodong , V. Goel , and B. Kingsbury. "Data augmentation for deep convolutional neural network acoustic modeling." 2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP) , 2014.
- DeVries, T.; Taylor, G.W. Improved regularization of convolutional neural networks with cutout. *arXiv 2017*, arXiv:1708.04552.
- Di, H.; Ke, X.; Peng, Z.; Zhou, D. Surface defect classification of steels with a new semi-supervised learning method. *Opt. Laser. Eng.* 2019, 117, 40–48, doi:10.1016/j.optlaseng.2019.01.011.
- Ding, S.M.; Liu, Z.F.; Li, C.L. AdaBoost learning for fabric defect detection based on HOG and SVM. 2011 International Conference on Multimedia Technology, Hangzhou, China, 26-28 July 2011.
- Elsken, T.; Jan H.M.; Hutter, F. Neural architecture search: A survey. *arXiv 2018*, arXiv:1808.05377.

- Fadli, V.F.; Herlistiono, I.O. Steel Surface Defect Detection using Deep Learning. *Int. J. Innov. Sci. Res. Technol.* 2020, 5, 244–250, doi:10.38124/IJISRT20JUL240.
- He S, Lau R W, Liu W, et al. SuperCNN: A Superpixelwise Convolutional Neural Network for Salient Object Detection[J]. *International Journal of Computer Vision*, 2015, 115(3):330-344.
- He, K.; Zhang, X.; Ren, S.; Sun, J. Deep residual learning for image recognition. In *Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2016)*, Las Vegas, NV, USA, 27–30 June 2016; pp. 770–778.
- He, K.; Zhang, X.; Ren, S.; Sun, J. Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition. *IEEE Trans. Pattern Anal. Mach. Intell.* 2015, 37, 1904–1916, doi:10.1109/TPAMI.2015.2389824.
- He, T.; Zhang, Z.; Zhang, H.; Zhang, Z.; Xie, J.; Li, M. Bag of Tricks for Image Classification with Convolutional Neural Networks. In *Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR 2019)*, Long Beach, CA, USA, 15–20 June 2019; pp. 558–567.
- Howard, A.G.; Zhu, M.; Chen, B.; Kalenichenko, D.; Wang, W.; Weyand, T.; Andreetto, M.; Adam, H. MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications. *arXiv* 2017, arXiv:1704.04861.
- Ioffe, S.; Szegedy, C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. *arXiv* 2015, arXiv:1502.03167.
- Jiang H, Wang J, Yuan Z, et al. Salient Object Detection: A Discriminative Regional Feature Integration Approach[J]. *International Journal of Computer Vision*, 2017, 123(2):251-268.
- Kang, G.; Liu, H. Surface defects inspection of cold rolled strips based on neural network. In *Proceedings of the 2005 International Conference on Machine Learning and Cybernetics(ICMLC 2005)*, Guangzhou, China, 18–21 August 2005; pp. 5034–5037.
- Kirthevasan Kandasamy, Willie Neiswanger, Jeff Schneider, Barnabás Póczos, Eric P. Xing. “Neural architecture search with Bayesian optimisation and optimal transport,” *Proceedings of the 32nd International Conference on Neural Information Processing Systems(NIPS)*, 2018, pp.2020-2029.
- Konovalenko, I.; Maruschak, P.; Brezinová, J.; Viňáš, J.; Brezina, J. Steel Surface Defect Classification Using Deep Residual Neural Network. *Metals* 2020, 10, 846, doi:10.3390/met10060846.
- Krizhevsky A , Sutskever I , Hinton G . ImageNet Classification with Deep Convolutional Neural Networks[J]. *Advances in neural information processing systems*, 2012, 25(2).
- Lecun, Y.; Bottou, L. Gradient-based learning applied to document recognition[J]. *Proceedings of the IEEE*, 1998, 86(11):2278-2324.
- Lee, S.Y.; Tama, B.A.; Moon, S.J.; Lee, S. Steel Surface Defect Diagnostics Using Deep Convolutional Neural Network and Class Activation Map. *Appl. Sci.* 2019, 9, 5449, doi:10.3390/app9245449.

- Li G, Yu Y. Deep Contrast Learning for Salient Object Detection[C]. Computer Vision and Pattern Recognition. IEEE,CVPR 2016:478-487.
- Li, J.; Su, Z.; Geng, J.; Yin, Y. Real-time Detection of Steel Strip Surface Defects Based on Improved YOLO Detection Network. IFAC PapersOnLine 2018, 51, 76–81, doi:10.1016/j.ifacol.2018.09.412.
- Lim, W.; Jang, D.; Lee, T. Speech emotion recognition using convolutional and recurrent neural networks. In Proceedings of the 2016 Asia-Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA), Jeju, Korea, 13–15 December 2016; pp. 1–4.
- Lin, T.; Dollár, P.; Girshick, R.; He, K.; Hariharan, B.; Belongie, S. Feature Pyramid Networks for Object Detection. In Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2017), Honolulu, HI, USA, 21–26 July 2017; pp. 936–944.
- Lin, T.; Goyal, P.; Girshick, R.; He, K.; Dollár, P. Focal Loss for Dense Object Detection. IEEE Trans. Pattern Anal. Mach. Intell. 2020, 42, 318–327.
- Liu, R.; Lehman, J.; Molino, P.; Such, F.P.; Frank, E.; Sergeev, A.; Yosinski, J. An Intriguing Failing of Convolutional Neural Networks and the CoordConv Solution. In Proceedings of the 32nd Conference on Neural Information Processing Systems (NeurIPS 2018), Montréal, QC, Canada, 3–8 December 2018; pp. 9628–9639.
- Liu, W. et al. SSD: Single Shot MultiBox Detector. Computer Vision – ECCV 2016. vol 9905. Springer, Cham. https://doi.org/10.1007/978-3-319-46448-0_2
- Liu, W.; Yan, Y. Automated surface defect detection for cold-rolled steel strip based on wavelet anisotropic diffusion method. Int. J. Ind. Syst. Eng. 2014, 17, 224–239.
- Liu, Y.; Xu, K.; Wang, D. Online Surface Defect Identification of Cold Rolled Strips Based on Local Binary Pattern and Extreme Learning Machine. Metals 2018, 8, 197.
- Liu, Y.; Xu, K.; Xu, J. An Improved MB-LBP Defect Recognition Approach for the Surface of Steel Plates. Appl. Sci. 2019, 9, 4222.
- Liu, Y.; Xu, K.; Xu, J. Periodic Surface Defect Detection in Steel Plates Based on Deep Learning. Appl. Sci. 2019, 9, 3127.
- Liu, Y.B.; Xiao,Z.T.; Zhang, F.; Wu, J. Fabric Defect Detection Method Based on Gabor Filters. Advanced Materials Research 2011, 301, 229-234, doi: 10.4028/www.scientific.net/AMR.301-303.229.
- Luo, Q.; Fang, X.; Liu, L.; Yang, C.; Sun, Y. Automated Visual Defect Detection for Flat Steel Surface: A Survey. IEEE Trans. Instrum. Meas. 2020, 69, 626–644, doi:10.1109/TIM.2019.2963555.
- Martín Abadi, Paul Barham, Jianmin Chen, Zhifeng Chen, Andy Davis, et. al. “TensorFlow: a system for large-scale machine learning.” Proceedings of the 12th USENIX conference on Operating Systems Design and Implementation, 2016, pp.265-283.
- Medina, R.; Llamas, J.; Gómez-García-Bermejo, J.; Zalama, E.; Segarra, M.J. “Crack Detection in

- Concrete Tunnels Using a Gabor Filter Invariant to Rotation.” *Sensors*, 2017, vol. 17, 1670.
- Mikołajczyk, T.; Nowicki, K.; Bustillo, A.; Pimenov, D.Y. Predicting tool life in turning operations using neural networks and image processing. *Mech. Syst. Signal. Process.* 2018, 104, 503–513, doi:10.1016/j.ymssp.2017.11.022.
- Mikołajczyk, T.; Nowicki, K.; Kłodowski, A.; Pimenov, D.Y. Neural network approach for automatic image analysis of cutting edge wear. *Mech. Syst. Signal. Process.* 2017, 88, 100–110, doi:10.1016/j.ymssp.2016.11.026.
- Mingxing Tan, Quoc V. Le. “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks.” *arXiv* , 2019, arXiv:1905.11946 [cs.LG]
- Misra, D. Mish: A self regularized non-monotonic neural activation function. *arXiv* 2019, arXiv:1908.08681.
- Mohanty, A.; Wang, T.T. Image mosaicking of a section of a tunnel lining and the detection of cracks through the frequency histogram of connected elements concept. *International Workshop on Image Processing and Optical Engineering*, Harbin, China, 15 November 2011.
- Neubeck, A.; Van Gool, L. Efficient non-maximum suppression. In *Proceedings of the 18th International Conference on Pattern Recognition (ICPR 2006)*, Hong Kong, China, 20–24 August 2006; pp. 850–855.
- Oh K, Lee M, Lee Y, et al. Salient Object Detection using Recursive Regional Feature Clustering[J]. *Information Sciences*, 2017, 387(1):1-18.
- Oh, S.-J.; Jung, M.-J.; Lim, C.; Shin, S.-C. Automatic Detection of Welding Defects Using Faster R-CNN. *Appl. Sci.* 2020, 10, 8629.
- Olaf Ronneberger, Philipp Fischer, Thomas Brox. “U-Net: Convolutional Networks for Biomedical Image Segmentation.” *MICCAI 2015*, 2015, pp.234-241.
- Pan, S.J.L.; Yang, Q. A survey on transfer learning. *IEEE Transactions on knowledge and data engineering* 2009, 22, 1345-1359, doi: 10.1109/TKDE.2009.191.
- Peng H, Li B, Xiong W, et al. RGBD Salient Object Detection: A Benchmark and Algorithms[C]. *European Conference on Computer Vision*. Springer, Cham,ECCV 2014:92-109.
- Philipp Krahenbühl, Koltun V. Efficient Inference in Fully Connected CRFs with Gaussian Edge Potentials[C]// *International Conference on Neural Information Processing Systems*. 2011.
- Prappacher, N.; Bullmann, M.; Bohn, G.; Deinzer, F.; Linke, A. Defect Detection on Rolling Element Surface Scans Using Neural Image Segmentation. *Appl. Sci.* 2020, 10, 3290, doi:10.3390/app10093290.
- Qiu, L.T.; Wu, X.J.; Yu, Z.Y. A High-Efficiency Fully Convolutional Networks for Pixel-Wise Surface Defect Detection. *IEEE Access* 2019, 7, 2169-3536, doi: 10.1109/ACCESS.2019.2894420.
- Quo J, Ren T, Bei J. Salient object detection for RGB-D image via saliency evolution[C]. *IEEE International Conference on Multimedia and Expo*. IEEE, ICME 2016:1-6.
- Ran M, Tal A, Zelnik-Manor L. What Makes a Patch Distinct?[C]. *Computer Vision and Pattern*

- Recognition. IEEE, CVPR 2013:1139-1146.
- Redmon, J.; Divvala, S.; Girshick, R.; Farhadi, A. You Only Look Once: Unified, Real-Time Object Detection. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 779-788, doi: 10.1109/CVPR.2016.91.
- Ren, S.; He, K.; Girshick, R.; Sun, J. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. IEEE Trans. Pattern Anal. Mach. Intell. 2016, 39, 1137–1149, doi:10.1109/TPAMI.2016.2577031.
- Ronneberger, O.; Fischer, P.; Brox, T. U-Net: Convolutional Networks for Biomedical Image Segmentation. In Proceedings of the International Conference on Medical Image Computing and Computer-Assisted Intervention, Munich, Germany, 5–9 October 2015; pp. 234 – 241.
- Schlegl, T.; Seeböck, P.; Waldstein, S.M.; Schmidt-Erfurth, U.; Langs, G. Unsupervised Anomaly Detection with Generative Adversarial Networks to Guide Marker Discovery. In Proceedings of the 25th International Conference on Information Processing in Medical Imaging (IPMI 2017), Boone, NC, USA, 25–30 June 2017; pp.146–157.
- Severstal: Steel Defect Detection. 2019. Available online: <https://www.kaggle.com/c/severstal-steel-defect-detection> (accessed on 18 August 2020).
- Shi, T.; Kong, J.; Wang, X.; Liu, Z.; Zheng, G. Improved Sobel algorithm for defect detection of rail surfaces with enhanced efficiency and accuracy. J. Cent. South Univ. 2016, 23, 2867–2875, doi:10.1007/s11771-016-3350-3.
- Shorten, C.; Khoshgoftaar, T.M. A survey on image data augmentation for deep learning. Journal of Big Data 2019, 6, 60, doi: 10.1186/s40537-019-0197-0.
- Simonyan, K.; Zisserman, A. Very deep convolutional networks for large-scale image recognition. In Proceedings of the 3rd International Conference on Learning Representations (ICLR 2015), San Diego, CA, USA, 7–9 May 2015.
- Sinno Jialin Pan, Qiang Yang. “A Survey on Transfer Learning.” IEEE Transactions on Knowledge and Data Engineering, 2010, vol.22, pp.1345-1359.
- Szegedy, C.; Wei, L.; Jia, Y. et al. Going deeper with convolutions[C]// 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2015.
- Tabernik, D.; Šela, S.; Skvarč, J.; Skočaj, D. Segmentation-based deep-learning approach for surface-defect detection. J. Intell. Manuf. 2020, 31, 759–776, doi:10.1007/s10845-019-01476-x.
- Tan, M.; Le, Q.V. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. arXiv 2019, arXiv:1905.11946.
- Tan, M.X.; Pang, R.M.; Le, Q.V. EfficientDet: Scalable and Efficient Object Detection. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition(CVPR), Seattle, USA, 16-20 June 2020; pp. 10781-10790.
- Tang, B.; Kong, J.; Wang, X.; Chen, L. Surface Inspection System of Steel Strip Based on Machine Vision. In Proceedings of the 2009 First International Workshop on Database Technology and

- Applications, Wuhan, Hubei, China, 25–26 April 2009; pp. 359–362.
- Thomas, G.B.; Jenkins, M.S.; Mahapatra, R.B. Investigation of strand surface defects using mould instrumentation and modelling. *Ironmak. Steelmak.* 2004, 31, 485–494, doi:10.1179/030192304225019261.
- Tu W C, He S, Yang Q, et al. Real-Time Salient Object Detection with a Minimum Spanning Tree[C]. *Computer Vision and Pattern Recognition. IEEE,CVPR 2016*:2334-2342.
- Wang, Guotai , et al. "Aleatoric uncertainty estimation with test-time augmentation for medical image segmentation with convolutional neural networks." *Neurocomputing*, 2019, vol. 338, pp.34-45.
- Wang, X.; Zhang, R.; Kong, T.; Li, L.; Shen, C. SOLOv2: Dynamic and Fast Instance Segmentation. In *Proceedings of the Thirty-Fourth Conference on Neural Information Processing Systems (NeurIPS 2020)*, Vancouver, BC, Canada, 6–12 December 2020.
- Wang, Y.; Xia, H.; Yuan, X.; Li, L.; Sun, B. Distributed defect recognition on steel surfaces using an improved random forest algorithm with optimal multi-feature-set fusion. *Multimed. Tools Appl.* 2018, 77, 16741–16770, doi:10.1007/s11042-017-5238-0.
- Wang, Z.; Zhu, D. An accurate detection method for surface defects of complex components based on support vector machine and spreading algorithm. *Measurement* 2019, 147, 106886.
- Wei, R.; Song, Y.; Zhang, Y. Enhanced Faster Region Convolutional Neural Networks for Steel Surface Defect Detection. *ISIJ Int.* 2020, 60, 539–545, doi:10.2355/isijinternational.ISIJINT-2019-335.
- Y. Dong et al., "A Deep-Learning-Based Multiple Defect Detection Method for Tunnel Lining Damages." *IEEE Access*, 2019, vol. 7, pp. 182643-182657.
- Zhang J, Sclaroff S, Lin Z, et al. Minimum Barrier Salient Object Detection at 80 FPS[C]. *IEEE International Conference on Computer Vision. IEEE,ICCV 2015*:1404-1412.
- Zhang P, Wang D, Lu H, et al. Learning Uncertain Convolutional Features for Accurate Saliency Detection[C]. *IEEE International Conference on Computer Vision. IEEE Computer Society,ICCV 2017*:212-221.
- Zhang, W.; Zhang, Z.; Qi, D.; Liu, Y. Automatic Crack Detection and Classification Method for Subway Tunnel Safety Monitoring. *Sensors* 2014, 14, 19307-19328.
- Zhang, X.; Zhou, X.; Lin, M.; Sun, J. ShuffleNet: An extremely efficient convolutional neural network for mobile devices. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Salt Lake City, UT, USA, 18–22 June 2018; pp. 6848–6856.
- Zhao, H.; Shi, J.; X. Qi, Wang, X. and Jia, J. Pyramid Scene Parsing Network. in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Honolulu, HI, USA, 2017 pp. 6230-6239. doi: 10.1109/CVPR.2017.660
- Zhou, P.; Xu, K.; Liu, S. “Surface defect recognition for metals based on feature fusion of shearlets and wavelets.” *Chin. J. Mech. Eng.*, 2015, vol. 51, pp.98–103.
- Zhou, Z.; Lu, Q.; Wang, Z.; Huang, H. “Detection of Micro-Defects on Irregular Reflective Surfaces

- Based on Improved Faster R-CNN.” Sensors, 2019, vol. 19, 5000.
- ZHU Ling,XU Wei-hong,CHEN Yuan-tao,et al. Saliency Detection Model Using Contrast of Local Feature and Global Feature in Image [J]. Journal of Chinese Computer Systems, 2016, 37(9): 2109-2113.
- Zhu W, Liang S, Wei Y, et al. Saliency Optimization from Robust Background Detection[C]. Computer Vision and Pattern Recognition. IEEE,CVPR 2014:2814-2821.
- Zhu, X.; Hu, H.; Lin, S.; Dai, J. Deformable ConvNets V2: More Deformable, Better Results. In Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR 2019), Long Beach, CA, USA, 15–20 June 2019; pp. 9300–9308.

致 谢

时光荏苒，紧张而充实的四年博士生涯即将结束。回首过往，我每天都过着充实的生活充满力量。这四年的博士生涯是我人生中最有意义的旅程。

回顾博士研究生几年的科研工作学习的经历。首先想对我最尊敬的导师夏筱筠老师说一声谢谢。谢谢您在博士期间对我的教导，为我们提供了舒适的研究环境以及良好的学习氛围。您耐心的帮助无时无刻的不鞭策着我，您的一丝不苟的工作态度、艰苦奋斗的工作热情以及广阔的视野极大的鼓舞着我，您在学术上工作上的负责严谨的态度使我受益终生，我一定会牢记您的谆谆教导，在以后的工作学习中继续以饱满的热情、踏实的作风努力拼搏。在此，我和我的家人向恩师致以崇高的敬意和谢意。

衷心的感谢刘明烈老师。刘老师已经 80 多岁的高龄了，依然抽出宝贵的时候在我们科研的道路上给予我们耐心的帮助和教导。在我研究课题的开题、中期以及最后的毕业答辩中都提供了富有建设性的建议。在此，向刘老师表示衷心的感谢，祝刘老师身体健康。

衷心的感谢研究生部的丁健老师，感谢您在生活和学习上给与我的关心和鼓励。同时感谢研究生部的宁绍鹏老师、王淑玲老师、李玉萍老师以及何鹏老师在校期间给予我的关怀和帮助。

衷心的感谢我的家人。20 年的学习生涯父母是我最坚强的后盾。家人的鼓舞和对我的默默付出使我勇往直前。未婚妻的理解和支持是我前进的动力。

衷心的感谢各位评审专家审阅我的论文，并提出宝贵的建议。

最后，衷心的感谢中国科学院大学和中国科学院沈阳计算技术研究所对我的培养。

2021 年 6 月

申请或已获得的专利：

一种列车前方障碍物识别的方法（专利申请号:2019112910087）（已申请）