

基于机器视觉的啤酒金属盖表面缺陷检测方法

金怡君¹, 李振宇², 杨絮³

(1.常州大学怀德学院, 江苏 靖江 214500; 2.江南大学, 江苏 无锡 214122;

3.南京理工大学, 南京 210014)

摘要: **目的** 为了提高啤酒金属盖表面缺陷检测的精度和准确率, 提出一种基于机器视觉的金属盖表面缺陷检测方法。**方法** 以不同类型的啤酒金属盖表面缺陷为研究对象, 利用滤波抑噪和高反差保留算法对图像进行处理, 运用 YOLO-v5 网络完成瓶盖的缺陷检测。通过添加注意力机制 SE 模块、改进模型损失函数和预测框筛选方式等技术手段对原 YOLO-v5 模型作出优化, 抑制图像中的不重要特征, 提升小目标检测的准确率和模型的特征提取能力。**结果** 改进后的 YOLO-v5 模型与常用的检测模型的对比结果表明, 改进 YOLO-v5 模型在测试集上的 mPA 指标为 93.10%, 检测速度达到了 294 张/min, 优势较为明显。**结论** 针对不同类型的金属盖表面缺陷, 基于机器视觉的检测模型均有较高的检测精度和识别准确率, 小目标缺陷的漏检率和误检率情况较少, 满足生产线实时、高精度的检测要求。

关键词: 机器视觉; 金属盖; 表面缺陷; 改进的 YOLO-v5 模型

中图分类号: TS206.4 **文献标识码:** A **文章编号:** 1001-3563(2023)11-0259-09

DOI: 10.19554/j.cnki.1001-3563.2023.11.030

Surface Defect Detection of Beer Metal Covers Based on Machine Vision

JIN Yi-jun¹, LI Zhen-yu², YANG Xu³

(1. Changzhou University Huaide College, Jiangsu Jingjiang 214500, China; 2. Jiangnan University, Jiangsu Wuxi 214122, China; 3. Nanjing University of Technology, Nanjing 210014, China)

ABSTRACT: The work aims to propose a method based on machine vision for surface defect detection of beer metal covers to improve the precision and accuracy of surface defect detection of beer metal covers. Different types of beer metal cover surface defects were used as the research objects. The images were processed by filtering, noise suppression, and high contrast retention algorithms. The YOLO-v5 network was used to complete the defect detection of bottle covers. The original YOLO-v5 model was also optimized by adding the attention mechanism SE module and improving the model loss function and the prediction frame filtering method to suppress the unimportant features in the images and improve the accuracy of small target detection and the feature extraction ability of the model. The comparison between the improved YOLO-v5 model and the commonly used detection model showed that the mPA index of the improved YOLO-v5 model on the test set was 93.10%, and the detection speed reached 294 pieces/min, and the advantages were apparent. For different metal cover surface defects, the detection model based on machine vision has higher detection accuracy and recognition accuracy, and the leakage rate and misdetection rate of minor target defects are low, which meet the real-time and

收稿日期: 2022-06-05

基金项目: 2018 年江苏省高校哲学社会科学研究基金项目 (2018SJA2268); 常州市第十五届社会科学研究课题重点资助项目 (CZSKL-2019A002)

作者简介: 金怡君 (1987—) 女, 硕士, 讲师, 主要研究方向为艺术设计与品牌策划管理。

high-precision detection requirements of the production line.

KEY WORDS: machine vision; metal cover; surface defect; improved YOLO-v5 model

啤酒瓶金属盖是酒品包装中重要组成部分,金属盖图案与结构的完整性,是消费者对产品质量的直观判别依据之一。但受瓶盖制造设备以及工艺等因素的制约,成品盖往往会包含一些缺陷,如:污渍、划痕、破损、形变等^[1-2]。若含有包装缺陷的产品进入流通环节,势必会造成品牌形象下滑,加大企业的维护投入^[3]。因而需借助缺陷检测手段对金属盖表面进行检测,确保产品包装的完整性,提高产品的竞争力。

目前,瓶盖缺陷检测多采用传统人工和机器视觉2种方式。人工方式工作强度大、检测效率偏低且成本较高,无法满足自动化快速检测的需求^[4]。基于机器视觉的检测技术不仅能够弥补人工检测方式的不足,缺陷检测的准确性和效率有了一定的提升,但其检测部分所用的算法模型仍存在一些不足,如:计算量大,参数较多,模型结构灵活性差^[5];大规模训练样本难以实施,不适合规模化工业使用^[6];小目标检测精度较低^[7],导致整体识别准确率不高,无法满足实际检测需求。基于此,本文运用机器视觉技术,通过改进 YOLO-v5 模型来完成啤酒金属盖表面缺陷的检测,从而实现缺陷目标的快速精准定位,以期进一步提升缺陷检测的效率。

1 实现方法

1.1 缺陷检测框架

根据金属盖内表面的缺陷类型、检测的精度和时间要求,设计了基于机器视觉的检测框架。结构如图1所示。

金属盖缺陷检测主要由图像采集、缺陷检测以及残次品剔除等部分构成。由采集部分的 CCD 高速相机获取传输皮带上的金属盖图像,通过千兆网络将图像传输至缺陷检测检测模块。图像经平滑降噪等处理后,输入至 YOLO-v5 检测模型,对金属盖表面缺陷的检测和识别。最终,工控机输出相应的信号控制剔除装置对残次品进行分流处理。

1.2 图像预处理

平滑降噪处理的目的是降低噪声对图像的干扰,避免由于图像质量偏低导致后续检测过程计算量的增加^[8]。考虑到采集图像中易产生椒盐噪声以及边缘模糊现象,采用自适应中值滤波器来抑制图像噪声以及散斑,并利用高反差保留算法来强化图片的细节信息与边缘值,确保图像的感兴趣区域更为突出^[9]。图2为金属盖图像预处理结果。




图1 基于机器视觉的金属盖缺陷检测框架
Fig.1 Defect detection framework for metal cover based on machine vision



图2 图像预处理结果
Fig.2 Image preprocessing results

1.3 缺陷检测模型

1.3.1 YOLO-v5 网络

YOLO-v5 属于一种单阶段目标检测模型, 主要包含输入端、Backbone 网络、Neck 端、Head 预测端等部分构成。网络的输入端设置有图像处理过程, 用以完成图像的缩放和归一化等操作^[10]。Backbone 部分采用 CSPDarknet53+Focus 结构来提取高中低层的图像特征, 有助于提升小目标特征信息的提取能力, 还能够降低网格的敏感性。Neck 端将各层次的特征进行融合并提取出大中小的特征图, 确保特征的多样性和鲁棒性。Head 预测端包含有一个分类分支和一个回归分支, 通过在特征图上应用锚定框, 利用 GIOU Loss 反向传播更新模型的参数, 最终生成包含类概率、包围框以及对象得分的输出向量^[11]。YOLO-v5 网络结构如图 3 所示。

YOLO-v5 网络初始输入为 640 像素×640 像素的图像, 经切片操作和卷积操作后, 分别生成 320×320×12 和 320×320×32 的特征图。为了较好地保留图像的特征信息, 卷积过程中特征图的 H 和 W 信息被集中到通道上, 分别进行 32 倍、16 倍和 8 倍的下采样, 以获取不同层次的特征图^[12]。最后利用上采

样和张量拼接的方式将不同层次特征图融合转化为维度相同的特征图。由于网络梯度的变化一直被集成在特征图中, 避免了梯度信息的重复使用情况, 使得模型参数量与 FLOPS 数值有了较大幅度的降低, 能够在保证识别准确率的同时, 降低模型计算量, 提高收敛速度。考虑到啤酒瓶金属盖存在多种尺度的表面缺陷, 将像素为 13×13、26×26、52×52 的特征图作为不同尺度目标回归检测的依据。

1.3.2 改进 YOLO-v5 的检测模型

在实际情况下, YOLO-v5 模型对小型缺陷检测的准确率和速度并不理想。通过在主干网络 Backbone 中添加注意力机制 SE 模块, 来抑制图像中的不重要特征, 提升网络的表征能力^[13]。同时, 对模型的 CIOU_Loss 损失函数和预测框筛选方式进行改进, 进一步提升小目标检测的准确率和模型的特征提取能力。

1) 注意力机制 SE 模块。注意力机制 SE 模块内部结构如图 4 所示。

操作步骤如下:

1) 利用 Global pooling 层对特征图(h, b, C)进行降维操作, 以减少参数数量和计算量, 并输出大小为 $1 \times 1 \times C$ 的特征图。




图3 YOLO-v5 网络结构
Fig.3 YOLO-v5 network structure




图4 SE 模块内部结构
Fig.4 Internal structure of SE module

2) 将特征图输入到包含有 $C/12$ 个神经元的 FC1 层进行线性变换, 将特征空间映射到样本标记空间, 并利用 ReLU 激活函数将部分神经元的输出为 0, 使网络具备稀疏性, 减少模型参数的相互依存关系^[14]。特征 z 经全连接层 FC2 变换以及 Sigmoid 函数激活后, 可得到大小为 $1 \times 1 \times C$ 的归一化权重因子 s , 其表达式见式 (1)。

$$s = \sigma(g(z, b)) = \sigma(b_1 \delta(b_2 z)) \quad (1)$$

式中: σ 为 Sigmoid 激活函数; δ 为 ReLU 激活函数。

3) 利用权重因子计算原始特征图各通道 $J = [j_1, j_2, \dots, j_c]$ 的权重, 对应的输出为 $Y = [y_1, y_2, \dots, y_c]$ 。元素 y_c 的计算表达式见式 (2)。

$$y_c = F_{\text{scale}}(j_c, s_c) = j_c s_c \quad (2)$$

输出特征所对应的权重值表达了不同通道的重要程度。模型训练过程中, 通过注意力机制 SE 模块来加大重要特征通道的权值, 减小非重要特征通道的权值, 从而来提升模型的特征表达能力和图像识别准确率。

2) 改进损失函数。YOLO-v5 采用 GIoU Loss 损失函数来计算预测框 (Predicted Box, PB) 和真实框 (Ground Truth, GT) 之间的距离。GIoU Loss 具备尺度不变性的特点, 不再考虑两矩形框相似性与空间尺度之间的关系, 解决了不重叠条件下两框距离远近的判断问题^[15]。当预测框或真实框被对方覆盖时, GIoU Loss 则会退化为 IoU Loss, 计算过程过于依赖 IoU 项, 致使模型的收敛速度变慢, 预测精度偏低。CIoU Loss 函数由于考虑了矩形框的相对比例、IoU 以及中心点距离等多项指标, 不仅能够处理两矩形框距离远近的问题, 还能够避免 GIoU Loss 可能发生的退化问题。因此, 文中的 YOLO-v5 检测模型选用 CIoU Loss 作为损失函数。图 5 为 CIoU 示意图。

CIoU Loss 中的相对比例指标用于惩罚预测结果与真实框不一致的情况。该惩罚项的定义见式 (3)。

$$R_{\text{CIoU}} = \frac{\kappa^2(e, e')}{c^2} + \alpha\mu \quad (3)$$

则 CIoU 损失可表达为式 (4)。

$$L_{\text{CIoU}} = 1 - \left[U - \frac{\kappa^2(e, e')}{c^2} - \alpha\mu \right] \quad (4)$$




图 5 CIoU Loss 边框示意图
Fig.5 Diagram of CIoU Loss border

式中: $\kappa^2()$ 表示求欧式距离; U 为交并比; e 、 e' 分别为 PB 框和 GT 框的中心点; c 为两矩形框包围区域的对角线长度; a 为权重系数; μ 为两矩形框长宽比的一致性参数, 包含了要预测的 b 和 h 。 a 、 μ 的计算表达式见式 (5)。

$$\begin{cases} \mu = \frac{4}{\pi^2} \left(\arctan \frac{b'}{h'} - \arctan \frac{b}{h} \right) \\ a = \frac{\mu}{(1-U) + \mu} \end{cases} \quad (5)$$

式中: b 、 h 为 PB 框的宽和高; b' 、 h' 为 GT 框的宽和高。

3) GA-Kmeans 算法调整锚框大小。卷积神经网络的特征图感受野随网络深度的增加而逐渐变大, 其内部的像素点直接影响特征信息的输出。选择大小合理的 Anchor 可有效提升模型检测召回率^[16], 如图 6 所示。




图 6 不同特征层感受野对比

Fig.6 Comparison of receptive fields in different feature layers

Anchor 通过计算 Bboxes 与 Anchor 之间平均欧氏距离而得出。YOLO-v5 模型设计有多个不同大小和宽高比的 Anchor, 对各特征层级上不同尺度目标进行定位, 但这些依靠人工设计的 Anchor 无法保证很好地适应数据集。当 Anchor 框的大小与目标尺寸存在较大差异时, 会导致模型计算量增加, 检测准确率偏低^[17]。因此, 本文采用 GA-Kmeans 算法对训练集的 Bounding box 进行聚类, 继而自动生成一组更为适应当前数据集的 Anchor, 以确保网络具备更好的检测效果。

GA-Kmeans 聚类过程如下:

- 1) 提取所有 Bounding box 坐标, 并将坐标数据转换为框的宽高大小。
- 2) 随机选取 k 个 Bounding box 作为 Anchor 的初始簇中心, 运用 $1-\text{IOU}(\text{Bboxes}, \text{Anchors})$ 方法计算 Bboxes 与每个簇之间的距离, 并分配至距离它最近的簇中。
- 3) 根据簇中的 Anchors 数量, 利用中值方法重新计算每个簇中的中心。
- 4) 重复第 2 步和第 3 步操作, 一直到各簇中的元素不再发生改变, 即可获取 k 个宽、高组合的 Anchor boxes。
- 5) 运用 GA 算法对 Anchors 的高、宽进行变异操作。对变异后的 Anchors 进行适应度评估, 若变得更好, 则将变异后的结果赋值给 Anchors。反之, 则跳过。
- 6) 将变异操作得出的最优 Anchors 按面积进行

排序并返回。当 $k=3$ 时, Anchors 聚类过程如图 7 所示。

2 实验与分析

2.1 实验准备

2.1.1 运行环境及参数设置

使用 Pytorch 深度学习平台来完成改进 YOLO-v5 网络的训练和测试, 测试平台: 酷睿™I9-12900K 中央处理器, 美国 INTEL 公司; GeForce RTX3090TI 显卡, 美国 NVIDIA 公司; DDR5 5200 32G×2 内存, 美国 Kingston 公司; 操作系统 Ubuntu22.04, 编程语言 Python。为确保实验过程的合理性, 将 COCO 数据集上的预训练结果作为检测模型的初始化参数, 配置情况如表 1 所示。

2.1.2 样本集和评估指标

在某啤酒加工厂采集了 2 595 张金属盖图像, 经 Labelimg 工具标注后, 得到包含正常、污渍、破损、形变、划痕等 5 种特征的样本集, 并按 8:2 的比例随机划分为训练集和测试集。部分缺陷样本如图 8 所示。样本划分情况见表 2。

为了确定最优模型, 将查准率 (Precision)、召回率 (Rcall)、平均检测精度 (mAP) 作为目标检测模型性能的评估依据, 并将缺陷检测的准确率和用时作为整套方案的评价标准。




图 7 Anchors 聚类过程
Fig.7 Anchors clustering process

表 1 训练参数及设置
Tab.1 Training parameters and settings

参数	设置
图像输入尺寸	640 像素×640 像素
初始学习率	0.01
动量因子	0.92
权重衰减系数	0.0005
网络训练	Adam
损失函数	CIOU-loss



图 8 部分包含缺陷的数据样本
Fig.8 Data samples partially containing defects

表 2 金属盖样本数据划分
Tab.2 Metal cap sample data division

缺陷类型	标注名	训练集/张	测试集/张	合计/张
正常	Normal	632	158	790
污渍	Stain	428	107	535
破损	Damage	296	74	370
形变	Deformation	344	86	430
划痕	Scratch	376	94	470

表 3 多改进消融实验结果
Tab.3 Result of multiple improvement ablation tests

损失函数 CIOU-loss	注意力机制 SE 模块	GA-Kmeans 调整 后锚框	Precision 值/%	Rcall 值/%	mAP 值/%
—	—	—	90.13	93.53	88.27
√	—	—	90.48	94.12	88.48
√	√	—	92.94	94.91	91.82
√	√	√	94.33	95.82	92.90

2.2 消融实验

为了验证文中针对 YOLO-v5 改进项的有效性, 利用数据集展开消融实验。在初始 YOLO-v5 的基础上, 通过使用 CIOU Loss 函数, 添加注意力机制 SE 模块以及经过 GA-Kmeans 调整后的锚框逐步替代原网络的相关项, 以检验各改进项对网络性能的影响。图 9 为消融试验可视化结果的对比情况。




图 9 消融试验可视化对比
Fig.9 Visual comparison of ablation tests

图 9a 为未改进 YOLO-v5 的金属盖缺陷检测结果。有图 9a 可以看出网络检测精度较低, 存在检测框覆盖不完整和超出目标的情况, 小型缺陷漏检较多。图 9b、图 9c 为引入了 CIOU Loss、SE 模块后的金属盖缺陷检测结果, 相较于未改进前, 检测精度有了一定的提升, 部分小型缺陷被检测到, 但同样存在漏检现象。图 9d 为最终改进后模型的检测结果, 多处小型缺陷被检测到, 在保证较高检测精度的同时有效提升了目标特征提取能力。多改进消融实验结果如表 3 所示。

由表 3 可知, 未改进 YOLO-v5 模型的 Precision、Rcall 以及 mAP 指标相对较低。在修改损失函数并添加注意力机制 SE 模块后, 各项指标均有了一定的提升。但相较于 SE 模块, CIoU Loss 的目的是提升预测框回归的速度和精度, 对各项指标的提升较小。添加 SE 模块目的在于进一步提升模型对特征的提取能力, 因而各项指标提升较为明显。最终改进后模型的 Precision、Rcall 以及 mAP 指标较于改进前分别提高了 3.20%、2.31%、3.67%, 表明文中改进项具备一定的合理性和有效性。

2.3 不同模型检测结果对比

为了进一步验证文中检测模型的性能, 分别选用

Faster R-CNN、文献[5]、文献[6]的检测模型以及 YOLO 系列模型分别在同一数据集上进行实验。对比各模型的检测精度、检测速度以及准确率。图 10 为各模型可视化结果。

由图 10 可看出, 改进的 YOLO-v5 模型具备良好的特征提取能力, 多目标检测能力突出, 尤其在面对形变和破损缺陷时, 检测精度较高, 而其他检测模型的精度相对较低, 存在目标特征提取不完整和部分缺陷无法检测的情况。表 4 和表 5 分别为不同模型的检测速度、平均精度以及缺陷识别的准确率情况。




图 10 不同模型检测结果对比
Fig.10 Comparison of different model test results

表 4 不同模型性能对比
Tab.4 Performance comparison of different models

检测模型	Backbone	迭代次数	检测速度/(张·min ⁻¹)	mAP 值/%	模型大小/MB
Faster R-CNN	VGG	320	176	80.11	94.98
文献[5]	VGG	320	238	88.65	144.52
文献[6]	SVM	320	251	89.50	194.71
YOLO-v4	CSPDarknet53	320	193	86.46	134.92
YOLO-v5	BottleneckCSP	320	213	88.27	173.54
本文	BottleneckCSP	320	274	93.10	61.08

表 5 检测准确率对比结果
Tab.5 Detection accuracy comparison results

检测模型	检测准确率/%				
	正常	污渍	破损	形变	划痕
Faster R-CNN	87.52	80.41	82.23	84.59	78.58
文献[5]	92.72	88.05	91.84	87.94	83.22
文献[6]	93.13	89.20	93.15	87.52	84.31
YOLO-v4	87.48	81.32	87.40	84.18	80.04
YOLO-v5	91.03	85.84	88.52	87.09	83.65
本文	95.90	93.18	94.24	93.39	87.97

综合表 4 和表 5 可知, 本文改进的 YOLO-v5 模型各项性能指标均优于其他目标检测模型, 检测速度达到了 294 张/min, mPA 值相较于 Faster R-CNN、文献[5]、文献[6]、YOLO-v4、YOLO-v5 等模型分别提升了 13.95%、4.78%、3.87%、7.13%、5.19%。同时, 改进后的 YOLO-v5 模型针对不同类型的缺陷, 均有较高的检测准确率。表明经改进后的 YOLO-v5 模型具备较高的检测精度, 且漏检率较低, 能够进一步提升金属盖表面缺陷的识别准确率。

3 结语

1) 设计了基于机器视觉的缺陷检测框架, 通过添加注意力机制 SE 模块、改进损失函数和预测框筛选方式等技术手段对原 YOLO-v5 模型进行优化。消融实验结果表明, 改进后检测模型的 Precision、Recall 以及 mAP 指标相较于改进前分别提升了 3.20%、2.31%、3.67%; 小目标漏检率较低, 整体识别准确率提升明显。

2) 优化的 YOLO-v5 模型各项性能指标均和识别准确率均优于目前常用的检测模型, 检测速度为 294 张/min, 满足实时检测需求; mPA 指标相较于 Faster R-CNN、文献[5]、文献[6]、YOLO-v4 和 YOLO-v5 等模型分别提升了 13.95%、4.78%、3.87%、7.13%、5.19%, 模型的检测精度较高; 模型体积仅为 61.08 MB, 具备良好的移植潜力。

3) 针对瓶盖污渍、破损、形变、划痕等不同类型的缺陷, 所设计模型的检测准确率分别 93.18%、94.24%、93.39%、87.97%, 能够满足实际生产过程中的检测需求。

参考文献:

- [1] SEON-HONG LEE, DONG-HYUN KIM, TAE-YOUNG KIM, et al. Investigation on Failure Analysis and Optimization Of WC-Co Hard Metals after Long-Term Use in A Bottle Cap Forming Machine[J]. International Journal of Refractory Metals and Hard Materials, 2018, 74: 99-106.
- [2] 张哲, 朱铮涛, 李渊, 等. 瓶盖缺陷在线自动检测技术研究[J]. 计算机技术与发展, 2016, 26(6): 151-154.
ZHANG Zhe, ZHU Zheng-tao, LI Yuan, et al. Research on Online Automatic Detecting Technology for Bottle Cap Defects[J]. Computer Technology and Development, 2016, 26(6): 151-154.
- [3] 王银丹. 酒瓶盖印刷板印刷缺陷视觉检测系统的研究[D]. 沈阳: 沈阳工业大学, 2019: 1-3.
WANG Yin-dan. Research on Visual Inspection System for Printing Defects of Wine Cap Printing Plate[D]. Shenyang: Shenyang University of Technology, 2019: 1-3.
- [4] 杨健, 辛浪, 豆昌军. 基于机器视觉技术的瓶盖划痕检测[J]. 包装工程, 2019, 40(13): 227-232.
YANG Jian, XIN Lang, DOU Chang-jun. Bottle Cap Scratch Detection Based on Machine Vision Techno[J]. Packaging Engineering, 2019, 40(13): 227-232.
- [5] ARAKI R, FUJIYOSHI H, HIRAKAWA T, et al. MT-DSSD: Multi-Task Deconvolutional Single Shot Detector for Object Detection[J]. segmentation, and grasping detection, Advanced Robotics, 2022, 36(8): 373-387.
- [6] 王佳豪, 周哲海, 兰永亮. 基于 U-Net 和 SVM 的圆形工业品形变缺陷检测方法[J]. 激光杂志, 2020, 41(11): 25-31.

- WANG Jia-hao, ZHOU Zhe-hai, LAN Yong-liang. Defect Detection Method of Circular Industrial Parts Based on U-Net and SVM[J]. Laser Journal, 2020, 41(11): 25-31.
- [7] 方叶祥,甘平,陈俐. 金属表面缺陷检测的改进YOLOv3 算法研究[J]. 机械科学与技术, 2020, 39(9): 1390-1394.
- FANG Ye-xiang, GAN Ping, CHEN Li. Improved YOLOV3 Algorithm For Detection of Metal Surface Defect[J]. Mechanical Science and Technology for Aerospace Engineering, 2020, 39(9): 1390-1394.
- [8] 柳宗浦. 基于机器视觉的小型金属部件表面缺陷检测系统[D]. 上海: 东华大学, 2009: 32-33.
- LIU Zong-pu. On Machine Vision Based Surface Flaw Detection System for Minitype Metal Parts[D]. Shanghai: Donghua University, 2009: 32-33.
- [9] 袁治灵,陈俊波,黄伟源,等. 基于稳健性主成分分析算法的光学相干层析成像去除散斑噪声的研究[J]. 光学学报, 2018, 38(5): 105-110.
- YUAN Zhi-ling, CHEN Jun-bo, HUANG Wei-yuan, et al. Speckle Noise Reduction of Optical Coherence Tomography Based on Robust Principle Component Analysis Algorithm[J]. Acta Optica Sinica, 2018, 38(5): 105-110.
- [10] JIANG P, ERGU D, LIU F, et al. A Review of Yolo Algorithm Developments[J]. Procedia Computer Science, 2022, 199: 1066-1073.
- [11] WU W, LIU H, LI L, et al. Application of Local Fully Convolutional Neural Network Combined with YOLO v5 Algorithm in Small Target Detection of Remote Sensing Image[J]. PloS one, 2021, 16(10): 0259283.
- [12] 蒋润熙,阿里甫·库尔班,耿丽婷. 面向轻量化网络的安全帽检测算法[J]. 计算机工程与应用, 2021, 57(20): 263-270.
- JIANG Run-xi, ALIFU K, GENG Li-ting. Safety Helmet Detection Algorithm for Lightweight Network[J]. Computer Engineering and Applications, 2021, 57(20): 263-270.
- [13] 李科岑,王晓强,林浩,等. 深度学习中的单阶段小目标检测方法综述[J]. 计算机科学与探索, 2022, 16(1): 41-58.
- LI Ke-cen, WANG Xiao-qiang, LIN Hao, et al. Survey of One-Stage Small Object Detection Methods in Deep Learning[J]. Journal of Frontiers of Computer Science and Technology, 2022, 16(1): 41-58.
- [14] SHI G, HUANG J, J ZHANG, et al. Combined Channel and Spatial Attention for Yolov5 During Target Detection[C]// 2021 IEEE 2nd International Conference on Pattern Recognition and Machine Learning (PRML), Chengdu, 2021: 78-85.
- [15] LIU K, TANG H, HE S, et al. Performance Validation of YOLO Variants for Object Detection[C]// In Proceedings of the 2021 International Conference on Bioinformatics and Intelligent Computing. Guilin, 2021: 239-243.
- [16] VARADARAJAN V, GARG D, KOTTECHA K. An Efficient Deep Convolutional Neural Network Approach for Object Detection and Recognition Using a Multi-Scale Anchor Box in Real-Time[J]. Future Internet, 2021, 13(12): 307.
- [17] DUAN S, LU N, LYU Z, et al. An Anchor Box Setting Technique Based on Differences Between Categories for Object Detection[J]. International Journal of Intelligent Robotics and Applications, 2022, 6(1): 38-51.

责任编辑: 曾钰婵