

分 类 号： TP391

学校代码： 10109

密 级： 公 开

太原科技大学硕士学位论文

(专业型)

学位论文题目： 基于机器视觉的工业钢带表面缺陷检测

英 文 题 目： Surface Defect Detection of Industrial Steel
Strip Based on Machine Vision

研 究 生 姓 名： 贺智勇

导师姓名及职称： 谢刚 教授

培 养 单 位： 电子信息工程学院

工程领域/专业： 控制工程

论文提交日期： 2023 年 4 月

论文答辩日期： 2023 年 6 月

答辩委员会主席： 曾建潮

中文摘要

钢带是一种以碳钢为原材料的工业精密制品，常用于牵引构件、捆扎货物，其质量好坏与工业安全息息相关，缺陷检测是避免其残次品流入市场的一道重要关卡。目前，基于机器视觉的缺陷检测主要依赖于人为设计的图像特征，无法实现多类缺陷的通用性，而且模型的准确度和鲁棒性较差，具备较高的错判率，难以满足现代工厂自动化产线的生产需求。本文充分调研工业钢带图像缺陷机理和机器视觉相关算法理论，旨在提高检测模型性能，使之更加适配工业生产。为此本文基于实际工业钢带缺陷图像开展研究，主要研究内容如下：

(1) 本文分析工业钢带数据图像特点，从钢带不同缺陷类型开展研究，提出一种基于改进 YOLO V5 的工业钢带表面缺陷检测模型。针对工业钢带图像存在小缺陷占比高、特征信息难以提取等特点，本文在 YOLO V5S 骨干网络中引入 SE (Squeeze-and-Excitation) 注意力机制，来强化模型对缺陷重要信息的提取能力，解决特征信息损失较大问题；在此基础上分析 YOLO 特征金字塔结构，通过增大网络的检测区域来实现四尺度特征提取，加强模型深层与浅层语义信息的融合；并通过 k-means++ 算法分析钢带图像，重新设计模型锚框大小，解决部分小目标检测困难问题；最后结合工业钢带数据集开展了实验对比，结果显示改进模型在保证检测速度的同时有效地提升了小目标的检测精度。

(2) 为进一步提升缺陷检测模型的准确度和检测效率，使之适配精密工厂制备需求，本文融合 Swin Transformer 模块进行进一步优化。首先引入滑动注意力机制，通过滑动窗口交互，让信息在相邻的窗口中进行传递，达到了一种全局建模的效果；之后采用新型上采样算子，使模型具备较大感受野，能更好地利用周围信息，而且计算参数量少；同时为了保证检测网络的检测效果，还引入自适应空间特征融合(ASFF)，对特征金字塔结构输出的 3 个水平特征图分别进行加权特征融合，充分利用不同尺度的特征，通过设置可自适应学习的参数来抑制模型在训练过程中由于梯度反传而导致的 inconsistency；最终在数据集上的结果显示，模型在牺牲较少检测速度的情况下，均值平均精度提高了 7 个百分点，达到较高的缺陷检测效果。

综上所述，本文以工业钢带为研究目标，基于机器视觉开展研究工作，针对不同应用场景设计出相应的检测模型，具有一定的理论价值和实际意义。

关键词：钢带；缺陷检测；YOLO；Swin Transformer；注意力机制

ABSTRACT

Steel strip is an industrial precision product made of carbon steel as raw material, commonly used for pulling components and bundling goods. Its quality is closely related to industrial safety, and defect detection is an important barrier to prevent its defective products from entering the market. At present, defect detection based on machine vision mainly relies on artificially designed image features, which cannot achieve universality of multiple types of defects. Moreover, the accuracy and robustness of the model are poor, and it has a high error rate, making it difficult to meet the production needs of modern factory automation production lines. This article fully investigates the mechanism of industrial steel strip image defects and the theory of machine vision related algorithms, aiming to improve the performance of the detection model and make it more suitable for industrial production. Therefore, this article conducts research based on actual industrial steel strip defect images, and the main research content is as follows:

(1) This article analyzes the characteristics of industrial steel strip data images, conducts research on different defect types of steel strips, and proposes a surface defect detection model for industrial steel strips based on improved YOLO V5. In view of the high proportion of small defects in industrial steel strip images and the difficulty in extracting feature information, this paper introduces SE (Squeeze and Extraction) attention mechanism in YOLO V5S backbone network to strengthen the model's ability to extract important information about defects and solve the problem of large loss of feature information; On this basis, the YOLO feature pyramid structure is analyzed, and four scale feature extraction is realized by increasing the detection area of the network to strengthen the integration of deep and shallow Semantic information of the model; And analyze the steel strip image through k-means++ algorithm, redesign the size of the model anchor frame, and solve the problem of difficult detection of some small targets; Finally, experimental comparisons were conducted on the industrial steel strip dataset, and the results showed that the improved model effectively improved the detection accuracy of small targets while ensuring detection speed.

(2) To further improve the accuracy and efficiency of defect detection models and adapt them to the needs of precision factory preparation, this article integrates the Swin Transformer module for further optimization. Firstly, a sliding attention mechanism is introduced, which allows information to be transmitted between adjacent windows through sliding window interaction, achieving a global modeling effect; Then a new upsampling operator is used to make the model have a larger Receptive field, which can make better use of the surrounding information, and the amount of calculation parameters is less; At the same time, in order to ensure the detection effect of the detection network, Adaptive Spatial Feature Fusion (ASFF) is also introduced, which weights the three horizontal feature maps output by the feature pyramid structure for feature fusion. By fully utilizing features at different scales, adaptive learning parameters are set to suppress the inconsistency caused by gradient backpropagation during the training process of the model; The final results on the dataset show that the model improved the average accuracy of the mean by 7 percentage points, achieving a high defect detection effect at the expense of less detection speed.

In summary, this article takes industrial steel strips as the research objective, conducts research work based on machine vision, and designs corresponding detection models for different application scenarios, which has certain theoretical value and practical significance.

Keywords: steel strip; defect detection; YOLO; Swin Transformer; attention mechanism

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究状况.....	2
1.2.1 基于传统机器视觉的缺陷检测方法.....	2
1.2.2 基于深度学习的缺陷检测方法.....	3
1.3 当前工业场景缺陷检测主要存在的问题	5
1.4 本文主要工作.....	6
1.5 本文组织结构.....	6
第二章 相关理论与数据	9
2.1 工业钢带背景及缺陷机理分析	9
2.1.1 工业钢带.....	9
2.1.2 钢带表面缺陷.....	10
2.2 卷积神经网络.....	12
2.2.1 卷积层.....	12
2.2.2 池化层.....	13
2.2.3 激活函数层.....	14
2.2.4 全连接层.....	16
2.3 YOLO 系列网络.....	17
2.4 本章小结.....	22
第三章 基于 YOLO V5 的钢带缺陷检测模型	23
3.1 YOLO 模型选用.....	23
3.2 基于 YOLO V5 的钢带检测模型	24
3.2.1 融合注意力的主干网络.....	25
3.2.2 四尺度特征提取层.....	26
3.2.3 K-means++聚类锚框优化.....	27
3.3 数据集资源.....	29
3.3.1 数据集分类标注.....	29
3.3.2 数据集图像分析.....	30
3.4 模型实现与验证.....	31
3.4.1 实验环境与模型训练.....	31
3.4.2 评价指标.....	32
3.4.3 实验结果分析.....	33
3.5 本章小结.....	35
第四章 融合 Swin-Transformer 的检测模型	37

4.1 Swin Transformer 模型.....	37
4.2 SWTR-YOLO 模型	40
4.2.1 全局建模主干网络构建.....	41
4.2.2 CARAFE 上采样算子优化.....	41
4.2.3 特征融合	43
4.3 模型实现与验证.....	45
4.3.1 实验环境与模型训练.....	45
4.3.2 模型性能评估.....	46
4.3.3 实验结果分析.....	50
4.4 本章小结.....	51
第五章 结论与展望	53
5.1 全文总结.....	53
5.2 未来展望.....	53
参考文献.....	55

第一章 绪论

1.1 研究背景及意义

2013 年工业 4.0 的提出标志着第四次工业革命的开始,此次革命核心目标为实现工业信息智能化,充分结合互联网使工业信息化,成为国民经济的主体^[1]。我国也在 2015 年对应提出《中国制造 2025》,这是我国实施制造强国战略以来的第一个 10 年的行动纲领,纲领提出我国应坚持智能转型、创新驱动、保质保量,加快从制造大国转向制造强国。近年来,随着新兴信息技术与工业生产的深度融合,工业产品从制造到质检都在不断发生变化,逐渐由追求数量向更高品质转变,通过提高工艺制造和检测手段来推出高质量产品,从而实现产品的市场竞争力。通常工厂会通过提升生产技术手段和加强质量检验两种方式来提升产品质量,在生产设备和技术手段成型的前提下,加强质量检验技术则显得尤为重要^[2]。

在工业实际生产中,由于设备老化或者不确定的环境因素,难免会生产出部分质量不合格的产品,表面缺陷则是导致工业产品质量不合格的重要原因之一。比如在偏光片的生产过程中,容易出现划痕、脏污、气泡等缺陷,这些缺陷的形状和尺度大小各不相同,而且它们往往只存在于偏光片表面较小的区域,这些缺陷的存在可以直接影响显示屏的成像质量,严重的可能导致无法工作^[3]。为了确保生产出的工业产品具备可靠质量和高合格率,工厂在制备过程中必须对产品进行无损检测,筛选出存有缺陷的部分,然后检出或者进行二次加工,因此工业产品表面缺陷检测是产品生产不可或缺的一环,也是防止残次品流入市场的重要一步,对于提高产品质量、降低生产成本有着至关重要的作用^[4]。

较早的表面缺陷检测采用的是肉眼观察产品表面,这种检测方式受主观因素影响大,导致效率低下,而且浪费大量人力。随着工业智能制造的发展,自动化检测逐渐代替人眼识别,帮助企业提高生产效率,从而获得更高的经济效益^[5]。设备智能化的发展带动的市场需求量也越来越大,更多的企业开始引进先进的自动化检测装备,自动化检测的精度、速度要求也越来越高。

基于机器视觉的缺陷检测技术具有抗干扰能力强、非接触性、在线无损检测等突出优点,技术流程主要包括图像预处理、特征提取、特征学习、预测输出等,非常适合现代自动化流水线的需要。利用机器来模拟人类视觉,对生产的产品进行图像采集处理、位置计算、特征学习,最终输出检测结果。采用机器视觉技术对产品进行无损检测,可以有效地解决传统工人接触式检测的不足,满足工业生产中智能化的要求。然而,现有

的多种传统机器视觉缺陷检测方法由于模型参数设置复杂、开发周期长、环境适应性差等问题，难于满足广泛应用背景下对缺陷检测技术的通用性、复杂度和精度的要求^[6]。

近些年随着深度学习网络的不断更新换代，深度学习方法已经逐渐取代传统机器视觉方法，成功应用于各类图像处理任务中^[7]。深度学习算法有别于与传统机器视觉方法，它利用多层神经网络结构来学习训练图像数据中的输入与输出之间的特征关系，而不需要两者之间精确的数学表达式，可以自适应学习图像中的深、浅层关系，并摒弃干扰信息，从而通过数据驱动实现对图像特征的提取，满足当下自动化生产流程的实际需求。因此，基于深度学习的工业产品表面缺陷检测研究对推动工业经济发展具有重要意义。

另外在工业产品缺陷检测的实际场景中，由于工业相机拍摄环境稳定，工业产品表面的成像效果也相对固定，因此拍摄的工业产品数据通常会呈现出缺陷尺度小、背景过于单一等特点，这些特点给自动化机器视觉缺陷检测算法带来挑战，而如何应对这些问题也正是本文的重点研究内容。

1.2 国内外研究状况

工业产品表面缺陷检测由于其应用性强、涉及领域广，一直以来都是学者们研究的热点，对于不同类型的工业产品，生产使用的材料和制造方式、环境均不相同，缺陷的表现往往也不同。根据缺陷类型的复杂性、多样性和检测算法图像处理方式的不同，我们通常将基于机器视觉的缺陷检测算法分为传统机器视觉缺陷检测算法和深度学习缺陷检测算法。

1.2.1 基于传统机器视觉的缺陷检测方法

基于传统机器视觉的方法主要分析图像的纹理、边缘、形状，代表算法有阈值分割法^[8]，区域生长法^[9]和边缘检测法^[10]。设计思想为采用图像处理手段将图像数据中的正样本部分与负样本进行区分，把负样本部分从图像中分割出来，再对其进行分类。

阈值分割法是一种比较传统的图像分割算法，它通过设定灰度阈值来把图像中的像素点分成不同类别，然后进行边缘分割，从而达到将目标与背景分离的效果。曹宇等^[11]应用 PSO 权重因子来增强全局搜索能力，将最优位置赋值给 Otsu 算法，最终在光学镜片上达到一种较好的阈值分割效果。Gao 等^[12]采用图像配准和图像差分方法来分割图像，使用梯度阈值分割方法来进行检测，提出的改进算法针对大型复杂表面缺陷在检测精度上表现很好。张小琳等^[13]提出一种基于背景估计的焊缝缺陷检测方法，首先利用 Otsu 分割图像提取区域，其次利用多级梯度解决背景残余问题，最后通过自适应阈值分割方法提取出含有缺陷的图像。这些方法都性能较为稳定，且计算代价极低，缺点则是在图像

灰度值不明显时，分割结果较差。

区域生长法的设计思想主要是利用一定的生长准则，将一些相似的子区域合并成一个大的母区域。Wang 等^[14]提出了一种基于区域多种子生长的算法，该算法不仅保证了分割质量，而且具有线性执行时间，便于实现。彭道刚等^[15]采用基于生长区域灰度值和自适应阈值改进生长准则，对电厂高温管道多缺陷实现了精准提取。区域生长法的原理都较为简单，对于一些均匀的特征可以很好地分割出来，但在一些图像背景较为复杂的情况下，往往会造成细节特征无法精确识别。

边缘检测法主要是利用图像中局部的不连续性，采用不同的算子提取不同目标之间的交界线。Orujov 等^[16]开发出来一种基于轮廓检测的图像处理算法，该方法使用图像梯度算子来进行视网膜眼底图像边缘检测，具备动态性和灵活性。张建国等^[17]用最小二乘法滤波器对图像进行去噪，改进 Canny 算法来获取边缘，通过仿真实验表明算法可充分提取胶水缺陷区域。这些方法均表明边缘检测算法可以很好得到物体的边缘分布信息，并将物体的轮廓分割出来，但是却无法将其内部的特征信息描绘出来，而且需要根据不同情况选择不同的算子，灵活性较差。

1.2.2 基于深度学习的缺陷检测方法

基于深度学习的缺陷检测方法不会直接对图像进行处理，而是先提取图像中关键的特征信息，然后通过多层网络结构矢量化特征信息并学习，最后通过检测网络对图像进行预测输出。相较于传统机器视觉方法，基于深度学习的检测方法通常具备更强大的特征提取和表达能力，可以适用于更复杂的环境和检测任务；而且深度学习基于数据驱动进行自动化特征学习，不再需对输入图像进行繁杂的预处理和特征提取器设计，而是从数据中直接学习目标特征^[18]。如图 1.1 所示，基于深度学习的缺陷检测方法根据检测任务的不同，主要划分为有监督学习模型、无监督学习模型和其他学习模型。下面就这三类模型展开具体介绍。

（1）有监督学习模型

有监督学习模型需要将标注好的缺陷标签（包括缺陷类别、位置和识别框）输入模型中进行学习，通过模型的自适应学习特性提取出正常图像和缺陷图像特征信息，当训练中检测到缺陷特征，则将其标记为负样本输出。模型主要是基于卷积神经网络（Convolutional Neural Network, CNN）堆叠而成的，包括以 R-CNN^[19]、Faster R-CNN^[20]




图 1.1 深度学习模型分类

Fig1.1 Classification of Deep Learning Models

为代表的双阶段网络和以 Retina-Net^[21]、SSD^[22]、YOLO^[23]为代表的单阶段网络。

双阶段网络包含回归和分类两个阶段，需要通过专门模块生成预选框，再基于预选框进行下一步的分类以及调整边界框。陈仁祥等针对工业环境噪声干扰大问题，通过改进 Faster R-CNN 网络，融合非局部注意力机制进行全局建模，并进一步抑制噪声干扰，设计出的网络可适应高噪声印刷电路板缺陷检测。Sun 等^[24]通过特征拼接、多尺度训练、参数校准等策略改进 Faster R-CNN 网络，达到当时最先进的人脸特征检测水平。

单阶段网络则是直接基于锚框进行分类以及调整边界框，以速度快而见长。目前应用最为广泛的单阶段网络模型便是 YOLO 网络，在保持速度极快的同时兼顾了检测精度，一经问世便席卷整个机器视觉领域，成为最主流的算法之一。陈建强等人^[25]以单阶段 SSD 网络作为算法主框架，通过交叉特征融合方法来增强特征图谱的语义信息，提出的 CroSSD 网络在热轧钢带表面微小缺陷检测中的 mAP 值可达 73.7%，相比原网络有更好的效果。Chen 等人^[26]用密集连接的卷积网络（DenseNet）代替 Darknet-53 主干，研究出一种称为 YOLOv3-dense 的模型，该模型在识别发光二极管的缺失组件、错误放置等缺陷中精度高达 95.28%。

（2）无监督学习模型

无监督网络相比于有监督网络更加抽象化，不需要考虑输入样本的标签，只通过对正样本图像特征的学习，使网络具备较大的建模能力，从而实现对缺陷的识别，这类模

型往往需要较少的样本，节省了大量数据标注的成本。Di 等人^[27]基于生成对抗网络（GAN）提出一种新的钢带表面缺陷检测算法，该算法通过多个卷积模块组成的自动编码-解码结构来实现图像特征无监督学习，并在自动编码模块引入 GAN 模型作为特征判别器，提高了有限训练样本下的缺陷分类精度，识别精度高达 96.7%。

（3）其他学习模型

其他学习模型主要包含半监督学习和弱监督学习，这类模型在工业实际生产中应用较少，设计理念为采用尽可能少的训练数据来完成缺陷检测任务，主要手段为通过少量有标注数据的图像进行模型预训练，其网络精度往往不如有监督学习网络模型。如 Gao 等^[28]提出了一种基于半监督的钢表面检测算法，通过神经网络对无标注样本进行预测判断，定义为标签，并使用这类标签对网络进行下一步训练，在数据集上也达到良好的检测效果。

1.3 当前工业场景缺陷检测主要存在的问题

通过上一小节对于国内外方法研究现状的介绍可以看到，我国在工业场景下的缺陷检测方法研究已经取得了不错的成果，且在各个工业领域都得到了广泛的应用。但在实际应用场景下仍面临着一些挑战，导致网络模型不能完全满足工业行业的实际需求。目前基于机器视觉的工业缺陷检测模型设计所面临的挑战有以下几个方面：

（1）模型检测实时性

在工业实际生产过程中，产品检测多搭载工业相机进行实时在线检测，对实时性要求较高，而且工业设备无法与最新实验设备相媲美，因此对模型的复杂度也有着较大要求。大多基于深度学习的网络模型虽然能够实现高精度检测，但具有参数多、模型复杂、推理时间长等缺点，且对检测设备的计算能力要求高^[29]。因此，需要设计出满足轻量化和稳定性的工业缺陷检测模型，在保证检测精度的前提下，满足工业实时检测需求。

（2）训练数据集采集

随着工业生产技术的不断升级换代，在实际工业生产过程中缺陷发生的概率极低，因此难以搜集到较全的缺陷样本，进而导致训练数据集中缺陷样本分布不够均匀、数量不够充分、种类不够齐全^[30]。而深度学习网络模型是基于数据驱动的，没有充分的数据资料则不能准确地学习到不同缺陷的特征信息，使得模型达不到预想的预测精度。因此，进行模型训练前应准备充分、有效的数据资源，并采取一定的数据扩增、数据增强策略，使网络能够在保证数据资源优异的情况下进行稳定训练^[31]。

（3）模型的抗干扰性

图像数据的采集需要搭载工业相机，在采集过程中经常会受到光照、粉尘、原料碎

渣等因素的干扰,使得图像噪声过多,进而影响模型对图像特征的提取,导致检测精度不高^[32]。此外,缺陷类型形态多样、尺度不一,而且易受背景信息的干扰。例如检测背景与缺陷纹理相近时,模型对缺陷的特征提取效果不佳,导致无法实现高精度的缺陷判别、分类^[33]。因此,需要设计环境适应性好、抗干扰性强的工业化模型,能够适应光照变化、复杂背景、环境噪声等干扰,实现对缺陷的精准检测。

1.4 本文主要工作

本文针对当前工业钢带缺陷检测模型准确度不高、网络模型复杂等问题展开研究,并设计针对于不同缺陷检测需求的应用模型,主要工作及创新点如下:

(1) 结合工业钢带图像数据特点,本文提出一种基于改进 YOLO V5 的工业钢带表面缺陷检测模型。针对工业钢带图像存在小缺陷占比高、特征信息难以提取等特点,本文在 YOLO V5S 骨干网络中引入 SE (Squeeze-and-Excitation) 注意力机制,来强化模型对缺陷重要信息的提取能力,解决特征信息损失较大问题;然后基于特征金字塔结构实现多尺度特征提取,增大网络模型的检测区域,加强深层与浅层语义信息的融合;最后使用 k-means++ 算法针对钢带图像重新设计模型锚框值,解决部分小目标检测困难问题。

(2) 为进一步提升缺陷检测模型的检测效率,本文融合 swin transformer 模块进行进一步优化。首先引入滑动注意力机制,通过滑动窗口交互,让信息在相邻的窗口中进行传递,达到了一种全局建模的效果。之后采用上采样算子 CARAFE,使模型具备较大感受野,能更好地利用周围信息,而且计算参数量少。同时为了保证检测网络的检测效果,本文还引入自适应空间特征融合(ASFF),对特征金字塔结构输出的 3 个水平特征图分别进行加权特征融合,充分利用不同尺度的特征,通过设置可自适应学习的参数来抑制模型在训练过程中由于梯度反传而导致的 inconsistency。

1.5 本文组织结构

本文组织架构共分为 5 个章节,组织架构如下:

第一章,绪论。本章首先阐述工业缺陷检测的研究背景及意义,其次将国内外研究方法分为基于图像处理和基于深度学习两部分展开介绍,然后总结这些检测方法存在的问题及不足,最后对本文的研究内容和组织结构安排进行总结。

第二章,相关理论与数据。从本文所用到的相关理论和数据开展介绍,首先介绍了工业钢带的相关背景,然后分析其缺陷生成机理,确立数据划分策略,最后介绍相关理论知识,包括卷积神经网络、YOLO 网络模型等。

第三章,基于 YOLO V5 的钢带表面缺陷检测算法研究。本章根据钢带表面不同缺

陷数据类型开展研究，保证模型轻量化的前提下提高检测精度，进行结果分析，可匹配常规工厂工业生产需求。

第四章，融合 **swin-transformer** 的高精度检测模型构建。本章从多方面分析网络特征，采用多种策略融合利用特征信息，提出一种高精度的检测算法，在数据集中进行对比分析，验证了本章方法的可行性。

第五章，总结与展望。对本文所有的研究工作进行了分析总结，并规划了后续的科研工作安排。

第二章 相关理论与数据

2.1 工业钢带背景及缺陷机理分析

2.1.1 工业钢带

钢带又称带钢，是轧钢企业为了适配不同工业用途而生产的一种刚性强、厚度小的钢板，原材料为碳钢制成的钢材^[34]。钢带生产过程^[35]如图 2.1 所示，其成品宽度在 1300mm 以内，一般成卷供应，可用于牵引构件和运载货物，也可用做捆扎束带，具有尺寸精度高、便于加工、便于裁剪、用处广泛等优点^[36]。




图 2.1 钢带制造流程

Fig2.1 Steel strip manufacturing process

钢带按加工方法分热轧钢带和冷轧钢带两种，按所用材质优劣可分为优质钢带和普通钢带，按表面涂层分为原轧制表面和镀层表面钢带，按用途分为通用型和专用型钢带，专用型钢带一般特指用于航天、船体、包装等，以 4mm 为厚度阈值可分为薄钢带和厚钢带，以 600mm 为宽度阈值又可分为宽钢带和窄钢带。

如图 2.2 展示的为工业通用型卷状钢带^[37]，广泛用于生产焊接钢管、制造自行车车架、车辆轮圈、锯条、刀片、电缆、垫圈、打包铁皮等，合格的钢带通常表现为质地坚韧、表面光滑且富有光泽。



图 2.2 工业卷状钢带
Fig2.2 Industrial rolled steel strip

2.1.2 钢带表面缺陷

表面缺陷通常指的是产品表面的缺损、开裂、斑点、划痕、夹杂物等，在机器视觉中统称为图像像素点的不连续^[38]。图 2.3 为五张表面带有缺陷的工业钢带展开图。其表面有夹杂物、划痕、斑点、脏污等缺陷^[39]。




图 2.3 卷状钢带展开图
Fig2.3 Unfolded drawing of rolled steel strip

在钢带自动化生产流程中,由于受制备机器、生产环境等多种因素影响,在工艺流程的每个环节都有可能产生缺陷,导致生产出残次品^[40]。本文对工业钢带产品表面中常见的缺陷开展研究,主要包含六类缺陷,分别为轧制氧化皮、斑块、开裂、点蚀表面、夹杂物和划痕。

(1) 轧制氧化皮

氧化皮是钢铁在空气中与氧气发生反应而产生的腐蚀产物,主要成分为氧化亚铁、三氧化二铁、四氧化三铁,其中氧化亚铁结构较为疏松,保护作用较弱,很容易产生龟裂而脱落,其颜色呈灰黑色,覆盖于钢带表面,很大程度地减弱钢带的承载能力。

(2) 斑块

钢带表面斑块一般呈黑色块状,形成原因主要为机器轧制过程中周围溅散铁屑等外来杂物附着在钢带上面被压入,热轧原料没有得到充分清洁也会引起该缺陷的产生。

(3) 开裂

钢带表面会出现开裂现象,轧制前后期都有可能导致这种情况。轧制前期可能是由于夹杂物及渗碳体的析出,从而导致钢带刚度较脆,产生裂纹;后期可能为轧制过程中不同区域因机器速度不一从而拉裂产生裂纹。开裂断口不规则,多为细条性,呈现折线状。

(4) 点蚀表面

点蚀起因于某些侵蚀性阴离子对钢带表面钝化膜的局部腐蚀破坏,如氯离子容易与金属离子反应形成氯化物,附于钢带表面,形状多为点状,局部分布较为密集,颜色呈灰黑色。

(5) 夹杂物

夹杂物多呈黑色条纹状,来源主要分为以下两方面,一是在冶炼的过程中所产生的,也就是在浇铸的过程中钢液与空气的二氧化碳产生化学反应,称为内生夹杂物,这种的夹杂物一般的颗粒都是比较细小的,可以在钢中分布较为均匀的。其二就是由于多种环境因素,而从外部所带来的夹杂物,这种的夹杂物分布不均匀且形状多数为不规则的,块状可形成斑点,条纹状成为夹杂物。

(6) 划痕

划痕为不规则、不定形的锐器刮伤形成的,形成原因多为输送辊道的辊子回转不良或制造吊运时带钢过松。形状为连续或断续出现一条或几条深浅不同的线段,多呈光亮色。

2.2 卷积神经网络

卷积神经网络（Convolutional Neural Network，CNN）是当下机器学习中使用最为广泛的一种神经网络结构，广泛应用于图像的分类、分割、识别中。其设计思想来源于对小猫脑内神经元的研究，在猫的大脑里，视觉皮层细胞分布错综相连，这些细胞对视觉输入空间的子区域特别敏感，称其为感受野^[41]。卷积神经网络就是依托感受野机制提出的，其主要结构如图 2.4 所示，由输入层、隐藏层和输出层组成，隐藏层又由多个卷积层(Convolutional Layer)、池化层(Pooling Layer)、激活函数层(Activation Function Layer)、全连接层(Fully Connected Layer)组成。




图 2.4 卷积神经网络

Fig2.4 Convolutional neural network

输入层为卷积神经网络的第一层，主要负责对输入图像的预处理，将其图像转化为后续网络可识别的数据格式，具体操作包含图像去噪、尺寸调整、数据维度调整等。图像的除噪是为了去除图像中不必要的信息，从而提升网络提取重要特征信息的准确度；数据维度、尺寸调整则是改变原始图像信息，以满足后续网络的输入要求^[42]。

2.2.1 卷积层

卷积层主要用于学习输入图像数据的特征信息，由多个卷积核组成。卷积核在图像特征图中进行滑动取值，对各个局部进行加权求和，直到滑动到图像末端^[43]。计算公式原理如式 2-1 所示， $k(i, j)$ 表示卷积核， $p(x, y)$ 表示输入特征图， $q(x, y)$ 表示输出特征图， x, y 分别表示横纵坐标轴， m, n 分别表示特征数横纵维度。

$$q(x, y) = \sum_{i=x}^{x+n+1} \sum_{j=y}^{y+m-1} p(x, y) * k(x, y) \quad (2-1)$$

具体核卷积运算示意图如图 2.5 所示，用一个 3×3 的卷积核对一个 5×5 的特征图进行的卷积运算，滑动步长为 1，得到右边输出结果。




图 2.5 卷积运算示意图

Fig2.5 Schematic diagram of convolution operation

2.2.2 池化层

池化层又称下采样层，主要为了解决网络训练参数量过大不易收敛问题，能有效地去除特征图中的冗余信息，保存重要信息，可在一定程度上防止模型过拟合^[44]。通常的池化操作有两种，分别为平均池化和最大池化。如图 2.6 所示，采用 2×2 过滤器分别对 4×4 输入模块进行池化操作；平均池化是将 4×4 局部模块内的所有数值进行平均运算，作为采样最终的输出值，可以较多地保留了图像背景的信息；最大值池化将 4×4 局部模块内的其他数值去除，只保留最大数来作为采样最终输出值，可以更好的保留图像的纹理特征。




图 2.6 池化运算示意图

Fig2.6 Schematic diagram of pooling operation

2.2.3 激活函数层

激活函数是卷积神经网络中不可缺少的一部分，它的作用是在神经网络中引入非线性特性，从而提高模型的表达能力^[45]。没有激活函数的卷积池化层相当于矩阵相乘，可能导致输出无限大，使得模型数据不可解，从而影响网络的识别能力。缺点是容易出现梯度消失，函数输出并不是零均值。常见的激活函数有：

(1) Sigmoid 激活函数

Sigmoid 函数又称 S 型生长曲线，函数图像如图 2.7 所示，它能够将连续的输入数值转换成 0 到 1 之间的输出数值。当输入是很大的负数，输出就是 0；当输入是很大的正数，则输出就是 1。对应的数学计算公式为：

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2-2)$$




图 2.7 Sigmoid 函数图像

Fig2.7 Sigmaid function image

(2) Tanh 激活函数

Tanh 激活函数图形如图 2.8 所示，形状与 Sigmoid 函数相似，其输出间隔为 1，并且整个函数以 0 为中心，平均值也为 0，弥补了 Sigmoid 函数均值为 0.5 的缺陷，在一般的二元分类问题中，Tanh 函数用于隐藏层，而 Sigmoid 函数用于输出层。

$$\text{Tanh}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2-3)$$




图 2.8 Tanh 函数图像

Fig2.8 Tanh function image

(3) ReLu 激活函数

ReLU 激活函数又称为修正线性单元，在负区间恒为 0，正区间函数求导结果恒为 1，解决了前两种函数可能会出现梯度消失的问题，而且 ReLU 只需要一个阈值即可得到激活值，计算速度很快，因此应用较 Sigmoid 函数和 Tanh 激活函数更为广泛。但 ReLU 函数也存在缺点，其对参数初始化和学习率十分敏感，负区间恒为 0，对应参数难以更新，图像特征如图 2.9 所示。数学公式为：

$$f(x) = \max(0, x) \quad (2-4)$$




图 2.9 ReLu 函数图像

Fig2.9 ReLu function image

(4) ELU 激活函数

ELU 激活函数是在 Relu 函数基础上改进的，在负区间引入指数函数，使得激活的均值接近于 0，避免模型训练坏死。数学公式为：

$$f(x) = \begin{cases} x, & x \geq 0 \\ a(e^x - 1), & x < 0 \end{cases} \quad (2-5)$$




图 2.10 ELU 函数图像

Fig2.10 ELU function image

(5) Softmax 激活函数

Softmax 激活函数多用于多类分类问题，对于任意实向量，Softmax 函数可以将其输出范围压缩在 (0, 1) 范围内，并且向量中元素的总和为 1。数学公式为

$$y(k) = \frac{\exp(a_k)}{\sum_{i=1}^n \exp(a_i)} \quad (2-6)$$

上式表示假设输出层共有 n 个神经元，计算第 k 个神经元的输出 y(k)，式中 exp(x) 是表示 x 的指数函数。

2.2.4 全连接层

全连接层简称 FC，在整个卷积神经网络中起到分类器的作用，结构示意图如图 2.11 所示。每个神经元与前一层所有的神经元连接，整合所需区分性类别，实现对特征的分类工作。其多用于卷积神经网络的末端，将网络前面部分学习到的特征信息发送至样本标记区，从而实现分类的作用，全连接层一般与 Softmax 函数一起使用^[46]，来完成一个完整的分类任务。




图 2.11 全连接层结构

Fig2.11 Full connection layer structure

输出层位于卷积神经网络的最后一层，用于输出经卷积神经网络计算得到的数值。对于分类任务，输出的是一个概率分布情况，这个概率分布结果是对输出数值应用归一化函数得到的，以此来对应不同类别检出的概率。而对于回归任务，输出层输出的则是由输入数据计算得出的数值。对于图像分割、缺陷定位等要求输出结果为图像的任务，输出层输出的便是含有图像信息的数值矩阵。

2.3 YOLO 系列网络

YOLO V1 是 YOLO 系列的开山之作，设计的核心思想是通过回归思想预测目标的位置及类别，采用端到端的输出架构，图 2.12 展示其检测流程。将检测图像分成 $S \times S$ 个 grid（网格），每个网格预测若干个 Bounding boxes(预测框)，每个 Bounding boxes 不仅要回归自身位置，还要预测出一个 confidence（置信度）值，这个值需包含所预测 object（目标）的置信度及这个 box 预测准确度信息，计算公式如下：

$$confidence = \text{Pr}(\text{object}) * IOU_{pred}^{truth} \quad (2-12)$$

式中， $\text{Pr}(\text{object})$ 用于表示目标是否落在当前 grid 中，落入则取 1，否则取 0；后一项表示预测的 bounding box 和实际值之间的交互比。




Fig2.12 YOLO V1 testing process




Fig2.13 YOLO V1 Network Structure Diagram

- ### (1) 批量归一化

YOLO V2 使用 Batch Normalization 对网络进行优化，来解决在反向传播过程中容易出现的梯度消失问题，通过降低网络模型对学习率、激活函数等参数的敏感性，从而使网络达到更好的收敛效果。

（2）高分辨率分类器

采用 224*224 分辨率图像进行模型预训练，后采用 448*448 高分辨率对分类模型训练 10 个 epoch 进行微调，使网络适应更高分辨率，降低分辨率改变对检测产生的影响，极大提升了网络的整体性能。

（3）先验框机制

先验框机制来源于 Faster RCNN 网络，YOLO V2 中在检测中引入 anchor boxes 策略，在网络中预先设定不同长宽的先验锚框，来适应网络检测中对于图像缺陷位置的定位。

（4）聚类调整锚框

Faster RCNN 中锚框大小采用手动设置，为了更加适配检测对象，YOLO V2 采用 k-means 算法来优化锚框尺寸。对训练集中标注的锚框进行聚类分析，采用计算欧氏距离、比较交互比等方式匹配出更加适合的 anchor 尺寸。

（5）位置预测

将 YOLO V1 中的预测坐标改为偏移缩放，以适配 anchor box 机制。计算关系如图 2.14 所示，图中 t_x , t_y , t_w , t_h 为模型预测输出， $\sigma(*)$ 为 sigmoid 函数，归一化 t_x 和 t_y , p_w , p_h 为 anchor 宽高， c_x 、 c_y 为当前 grid 的坐标， b_x 、 b_y 、 b_w 、 b_h 为最终预测目标边框。




图 2.14 YOLO V2 位置预测

Fig2.14 YOLO V2 Location Prediction

（6）高低层特征融合

为了更好地检测出一些比较小的对象，YOLO V2 引入 passthrough 层，来保留可能遗失的一些细节特征，从而增强总网络提取特征能力。

YOLO V3 网络主要采用回归的思想直接判断目标的位置信息和类别，将 Darknet53 作为特征提取主干网络^[47]。Darknet53 网络由 DBL 和 RES-NET 组成，DBL 模块包含卷积层、归一化层和激活函数层，RES-NET 则是残差模块，可以避免梯度消失的问题。网络主要改进措施如下：

（1）采用多标签检测，用 sigmoid 替换 softmax 函数，可以预测一个 grid 中的多个类别物体；

（2）将当前层特征图与上层采样特征图相结合，组成新的特征图，这样充分结合了不同卷积层的特征，可预测更细粒的特征；

（3）采用了步长为 2 的卷积层代替池化层，有效地防止了池化操作引起的特征丢失问题；

（4）预设锚框由 5 个增为 9 个，可预测更多目标，提升模型召回率；

（5）损失函数上使用交叉熵损失函数来进行类别预测，模型交叉熵数值越小，则表明模型预测结果越好。

在 YOLO V3 提出两年后的 2020 年，Alexey 团队提出了 YOLO V4 模型，代码一经开源便在 CV 届引发不小的轰动，其结合了大量前人研究的技术，组合多种创新实用模块，实现了检测速度与精度的完美平衡。输入端主要包含 Mosaic 数据增强，通过将数据图像进行随机缩放、裁剪等操作来达到丰富数据集的作用；主干网络模块主要采用 YOLO V3 的 Darknet53，将原先的残差模块替换为 CSP 模块，目的为减少计算量；颈部网络主要引入了 SPP 模块，将不同尺度的特征图进行 Concat 操作，可以有效地增加主干网络的特征范围；预测模块主要包含损失函数，YOLO V4 采用 CIOU_Loss 损失函数，可以充分考虑边界框宽高比地尺度信息。

YOLO V5 是目前 YOLO 系列应用于工业场景较为广泛的算法，分为 YOLO V5s、YOLO V5m、YOLO V5l、YOLO V5x 等，其中 YOLO V5s 为深度、宽度以及体积最小的网络，其网络结构如图 2.15 所示，由四部分组成。

第一部分为输入层（Input），主要通过 Mosaic 数据增强、自适应锚框计算来实现数据训练前预处理，起到丰富数据集、减少 GPU、提高推理速度作用。第二部分为主干网络层（Backbone），首先是 Focus 模块，原始 608*608*3 的图像输入 Focus 结构，采用切片操作，先变成 304*304*12 的特征图，再经过 32 个卷积核的卷积操作，最终变

成 $304 \times 304 \times 32$ 的特征图；其次是 CSP 模块，先将基础层的特征映射划分为两部分，然后通过跨阶段层次结构将它们合并，在减少了计算量的同时，可以保证准确率；最后是 SPP 模块，又被称为空间金字塔池化，通过最大池化和张量拼接，解决了卷积神经网络对图像重复特征提取的问题，大大提高了产生候选框的速度，节省了计算成本。




图 2.15 YOLO V5 网络结构图

Fig2.15 YOLO V5 network structure diagram

第三部分为颈部(Neck)，由 FPN+PANET 组成，包含多个特征融合和上采样操作，FPN 层自顶向下传达强语义特征，而 PANET 自底向上传达定位特征，以此来实现不同特征传递，加强网络特征融合能力。第四部分为检测头层(Head)，包含 NMS 和边界框损失函数，对 Neck 层的输出分别进行卷积操作用来生成边界框并预测类别；NMS 为非极大值抑制，其作用为保留效果好的且去除冗余的预测框；在损失函数方面，包含分类损失 (cls_loss)、置信度损失 (obj_loss) 和定位损失 (box_loss) 三部分，前两者采用的是二元交叉熵损失函数 (BCE with Logit Loss) 计算，定位损失采用的是 CIOU_Loss 损失函数，计算公式如式 2-12、2-13 和 2-14 所示，相比于 IOU_Loss 更能精准地呈现

出预测框距离真实框有多远。式中， w 、 h 、 gt 、 p 分别表示宽、高、真实框、预测框， C 表示预测框和真实框的最小外接矩阵， $Distance_2$ 表示预测框的中心点和真实框中心点的欧氏距离， $Distance_C$ 表示 C 的对角线距离， v 表示长宽比影响因子。

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w^{gt}}{h^{gt}} - \arctan \frac{w^p}{h^p} \right)^2 \quad (2-13)$$

$$CIOU = IOU - \frac{Distance_2^2}{Distance_C^2} - \frac{v^2}{(1-IOU)+v} \quad (2-14)$$

$$CIOU_{Loss} = 1 - CIOU \quad (2-15)$$

2.4 本章小结

本章主要介绍本文工作的相关理论和数据，首先介绍工业钢带的生产工艺及表面缺陷产生机理，其次分析钢带数据集缺陷类型并划分类别，最后就机器视觉下的相关知识进行了详细描述。

第三章 基于 YOLO V5 的钢带缺陷检测模型

结合上一章节对工业钢带数据集的分析，钢带表面缺陷种类多样、大小不一，采用传统的缺陷检测模型难以直接兼顾不同缺陷特征。综合考虑数据特点和传统检测方法存在的问题，本章提出了基于 YOLO V5S 的钢带表面缺陷检测模型，主要工作内容是基于参数量较少的 YOLO V5S 网络设计出一种兼顾速度与精度的检测网络，使之匹配大部分工厂的检测设备。

3.1 YOLO 模型选用

YOLO 系列网络的检测核心是通过回归的思想来预测目标类别和概率，是通过端到端的卷积神经网络来完成的。其具体流程可以简单分为三个步骤：第一步，定义图像的尺寸，并将所有输入图像都转换到该尺寸大小，并进行预处理操作便于网络识别；第二步，将图像输入至堆叠而成的卷积神经网络中，通过网络学习图像特征；第三步，检测图像输入学习好的模型，根据置信度设定阈值最终输出类别及检测锚框。

YOLO V5 是基于 YOLO 系列发展而来，在网络架构上并没有进行很大地改动，但创造性地提出了很多检测技巧，普遍用于工业场景缺陷检测。YOLO V5 网络按照网络深度和宽度分为 YOLO V5s、YOLO V5m、YOLO V5l、YOLO V5x，其不同的网络结构计算量也不同。

网络的深度主要体现在网络中 CSP 模块层数，如表 3.1 所示，可以看出 s，m，l，x 四个版本 CSP1_X、CSP2_X 中的 X 不同，而 X 表示模块中残差块的数量，残差块越多则网络的层数越深。

表 3.1 不同网络 CSP 变化
Table 3.1 CSP changes across different networks

模型	YOLO V5s	YOLO V5m	YOLO V5l	YOLO V5x
第一个 CSP1	CSP1_1	CSP1_2	CSP1_3	CSP1_4
第二个 CSP1	CSP1_3	CSP1_6	CSP1_9	CSP1_12
第三个 CSP1	CSP1_3	CSP1_6	CSP1_9	CSP1_12
第一个 CSP2	CSP2_1	CSP2_2	CSP2_3	CSP2_4
第二个 CSP2	CSP2_1	CSP2_2	CSP2_3	CSP2_4
第三个 CSP2	CSP2_1	CSP2_2	CSP2_3	CSP2_4
第四个 CSP2	CSP2_1	CSP2_2	CSP2_3	CSP2_4
第五个 CSP2	CSP2_1	CSP2_2	CSP2_3	CSP2_4

网络的宽度与卷积核的数目相关，卷积核越多，则网络宽度越宽，相应的特征提取能力也越强，不同网络卷积核数目如表 3.2 所示。

表 3.2 不同网络卷积核个数

Table 3.2 Number of convolution cores in different networks

模型	YOLO V5s	YOLO V5m	YOLO V5l	YOLO V5x
Focus	32 个	48 个	64 个	80 个
第一个 CBL	64 个	96 个	128 个	160 个
第一个 CBL	128 个	192 个	256 个	320 个
第一个 CBL	256 个	384 个	512 个	640 个
第一个 CBL	512 个	768 个	1024 个	1280 个

3.2 基于 YOLO V5 的钢带检测模型

考虑到应用领域为工业场景，检测流程需同时具备速度与精度，模型的选用需具备一定的轻量化，故本文基于体积最小的 YOLO V5s 版本进行优化，提出了改进的 YOLO V5 算法，在保持 YOLO V5s 轻量化的基础上来提升检测精度。算法结构图如图 3.1 所示，改进点主要体现在主干网络层、特征提取层和锚框优化三部分。




图 3.1 YOLO V5 改进模型结构图

Fig3.1 YOLO V5 improved model structure diagram

3.2.1 融合注意力的主干网络

注意力机制源自于人类视觉原理，当人在观察某项事物时，通常会忽略背景及其余干扰物体，选择性地将目光聚焦在感兴趣的区域。注意力机制便是受此启发应运而生的，其最早用于机器翻译领域，主要关注能够表达主体情感、内容的语句，而忽略一些衔接词。近年来注意力机制开始应用于机器视觉领域，在神经网络中引入注意力机制可以选择性地决定输出部分，有利于网络筛选出有用特征。在神经网络中有很多种加入注意力机制的方法，如 SE-Net 是一种通道注意力，通过使用特征全局平均池化计算通道级的注意力权重，以反映每个通道的重要性程度；也有在空间维度引入注意力机制的情况，如 STN (Spatial Transformer Networks) 是对各种形变数据在空间中进行转换并自动捕获重要区域特征。

在 YOLO V5 模型主干网络中，每个 CSP 网络都是通过融合一定感受野而获得空间特征与通道特征，但其未能区分各个特征通道的重要性，为提高主干网络对缺陷目标特征的提取能力，本文在主干网络阶段引入 SE 注意力机制。

SE 注意力机制模块通过一些卷积操作让网络自动学习每个通道的重要程度，然后通过不同通道赋予权重，达到对特定通道重点关注的效果，即抑制对当前任务作用不大的通道来提升网络的性能。此外，SE 注意力模块具有计算开销小、可插性等优点，可很好地融入到神经网络模型架构中进行端对端特征传递，可以有效降低由通道特征不同引发的特征损失，其模块如图 3.2 所示，主要包括两部分，分别是 Squeeze (压缩) 和 Excitation (激励)。

Squeeze 操作将一个通道中的空间信息压缩为一个全局特征，具体操作是通过一个全局池化将每个通道的特征编码为一组实数，计算公式如 3-1 所示，其中 Z_c 为经过压缩的特征图， H 和 W 分别为特征图的高和宽， $u_c(i, j)$ 为一个通道维度上的元素值， Z_c 通过压缩操作后特征维度由 $H \times W \times C$ 变为 $1 \times 1 \times C$ 。

$$Z_c = F_{sq}(u_c) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W u_c(i, j) \quad (3-1)$$

Excitation 操作是为将压缩后的特征图生成不同的权重值，具体操作是通过两个神经元分别是 C/r 和 C 个的全连接层组成一个结构去构建通道间的相关性，输出不同通道的权重值，计算公式如 3-2 所示，其中 δ 为 ReLu 激活函数， σ 为 Sigmoid 函数。

$$s = F_{ex}(z, W) = \sigma(g(z, W)) = \sigma(W_2 \delta(W_1 z)) \quad (3-2)$$

采用两个全连接层主要是为了降低模型的复杂度，提升模型的泛化能力，第一个全连接层 W_1 的主要作用是将维度降为原来的 $1/r$ ，然后使用 ReLu 激活函数增加非线性

能力，第二个全连接层 $W2$ 将维度还原到原来的维度，通过 Sigmoid 函数将不同通道的数值转化到 $(0, 1)$ 区间，进而得到不同通道的激活值，即每个通道的权重。最后通过 Sigmoid 激活函数输出 $1 \times 1 \times C$ 大小的权重因子，对原始特征图各通道进行乘积，输出 $H \times W \times C$ 大小的特征图。




图 3.2 SE 注意力机制

Fig3.2 SE attention mechanism

SE 注意力模块的不同插入位置直接影响网络的最终特征学习、提取能力，若将其插入至 Neck 或 Head 层，将很难从融合后的特征信息中区分有效特征和冗余特征，从而达到增强网络特征提取能力的效果。而 Backbone 层处于特征融合前，主要包含图像的细节特征，这些细小特征的增强可有效提升网络对图像中小目标缺陷的提取，故本文将 SE 模块嵌入主干网络中，以增强关键特征，弱化冗余特征^[48]。

3.2.2 四尺度特征提取层

利用卷积神经网络来进行图像特征提取时，随着卷积层数的加深，图像输出分辨率在不断减小，局部感受野能感知到的原图像范围不断扩大，所以深层神经网络提取的深层特征十分不利于小目标检测。但是仅使用浅层特征检测图像时，又容易因缺乏高级语义信息引导而导致漏检、错检现象，于是诸多研究者便采用多尺度特征融合的方式来解决这类问题，可有效提升算法性能。

在 YOLO V5 中是使用的三尺度检测，对于尺度大小为 608×608 的输入图像，经过 8 倍、16 倍、32 倍下采样操作后，尺度大小变为 76×76 、 38×38 、 19×19 ，网络在

这三种不同尺度的特征图上进行目标检测，其对于尺寸分布稀疏的图像目标具有良好的检测效果，但是工业生产的钢带表面存在很多不同类型的小缺陷目标，而且存在缺陷目标分布密集现象。为了解决这种问题，本文在 YOLO V5 的检测头层增加 152×152 的检测尺度，高分辨率的尺度检测可提取更微小特征和更多边缘信息，从而更适合于稠密小目标缺陷的检测。

具体的操作方法如图 3.3 所示，在特征提取层增加多个卷积及上采样层，将获取到的大小为 152×152 的特征图与骨干网络中第 2 层特征图进行 **concat** 融合，以此获取更大的特征图来进行小目标预测输出。将三尺度检测改进为四尺度检测后，网络可以在四个不同尺度的特征图上做检测，能将更多的浅层特征信息传递到深层特征图中，使得网络对于小目标更加敏感，提升了网络的整体检测性能。




图 3.3 四尺度检测流程

Fig3.3 Four-scale inspection process

3.2.3 K-means++聚类锚框优化

NEU 数据集中，缺陷标注边界框具有不同的形状大小，在对模型锚框选择时，越接近于缺陷标注边界框形状则越容易得到较高的检测精度。在 YOLO V5 原模型框架中，有初始设定长宽的三类锚框，默认采用 K-means 算法聚类锚框，并结合遗传算法在训练过程中调整锚框，此类算法存在很大的缺陷，收敛情况严重依赖于簇中心的初始化情况，一旦初始值选择不好，则达不到有效的聚类效果^[49]。而锚框的选择对提取缺陷特征起着关键性的作用，本文针对的是工业钢带小目标检测困难问题，因此需降低锚框尺寸对钢带上小目标缺陷检测的误差。

本文选取 K-means++ 聚类算法，主要设计思想就是计算出每个簇的数据中心，然后

分别判断每个数据的距离状况，再进行更新每个簇内的质心。获取锚框尺寸步骤如下所示：

- (a) 首先，从数据集文件中读取数据，点和点集分别用元组、列表表示；
- (b) 其次，随机选择一个点 C_1 作为第一个聚类中心，对于数据集的每一个点 x_j ，计算它与每一个聚类中心 C_i 的最短距离 $D(x_j)$ ；

$D(x_j) = \min \{D(x_j, C_i)\}$ (3-3)
- (c) 然后重新选择一个点作为新的聚类中心（选取原则为： $D(x_j)$ 最大的点，被选取为新的聚类中心的概率最大），重复此步骤，直到 k 个聚类中心被选出来，并以此为下标提取出数据点，产生列表值；
- (d) 再将其余数据点分配到距离（欧式距离）最短的聚类中心中，产生列表值，计算其平均误差；
- (e) 然后更新聚类中心，计算每一簇中所有点的平均值，并再次进行分配，计算平均误差；
- (f) 最后比较前后两次平均误差是否相等，若不相等则进行循环，否则终止循环。

整个过程最少进行两次聚类，对比误差，输出较小误差时的结果，避免平均误差过大。基于数据集聚类结束后生成 12 组不同宽高的锚框，以此提高小目标检测精度。聚类后得到的锚框尺寸如表 3.3 所示，分别对应不同特征输出的锚框尺寸。

表 3.3 锚框尺寸表
Table 3.3 Table of Anchor Frame Dimensions

特征输出	感受野	锚框尺寸
19×19	大	(98, 87)
		(68, 94)
		(73, 128)
38×38	中	(40, 63)
		(62, 86)
		(39, 79)
76×76	小	(25, 24)
		(15, 38)
		(31, 12)
152×152	较小	(17, 6)
		(8, 14)
		(15, 19)

3.3 数据集资源

NEU-DET 数据集^[50], 该数据集是由东北大学团队收集并发布的, 是目前工业缺陷检测常用的一种公开数据集, 如图 3.4 所示, 其包含热轧钢带的六种典型表面缺陷, 即轧制氧化皮 (Rs)、斑块 (Pa)、开裂 (Cr)、点蚀表面 (Ps)、夹杂物 (In) 和划痕 (Sc), 此六类缺陷颜色、形状、大小各异, 基本涵盖钢带在工业制造中可能出现的各种缺陷。




图 3.4 NEU 数据集

Fig3.4 NEU Dataset

3.3.1 数据集分类标注

该数据集包括 1800 张灰度图像, 每一种缺陷类型都包含 300 个样本。对于缺陷检测任务, 该数据集提供了注释, 指示每个图像中缺陷的类别和位置。将已标注缺陷类型文件按照 PASCAL VOC^[51]格式保存成 XML 文件, 包含图片路径, 标签和缺陷位置, 便于数据训练。

数据训练时将数据集 6 类缺陷类型按 8: 2 的比例随机分为训练集和测试集, 即每类缺陷 240 张用于训练, 60 张用于测试。作为训练样本和测试样本, 然后编写 PyThon 脚本将 xml 文件转换为训练、测试集 txt 文件, 无缺陷的负样本图片, 设置其对应的空白 txt 文件, 这样可以在训练过程中提升深度神经网络模型的鲁棒性^[52]。




图 3.5 图像标签

Fig3.5 Image label

3.3.2 数据集图像分析

在实际缺陷检测任务中，数据集中的缺陷类别、缺陷数量以及缺陷区域形状等因素都会影响最终检测结果的准确性。为了能够针对性地设计检测模型，则需要了解数据集中缺陷数据大小和分布情况，本文针对 NEU 数据集进行了分析。该数据集由 1800 张 200*200 分辨率的图片组成，如图 3.6 展示了部分钢带图片缺陷识别框标注情况，可以直观清晰地看出数据集中不同缺陷类别的尺寸大小存在很大的不同。开裂、划痕、轧制氧化皮缺陷一般占据较多的区域，而对于夹杂物、点蚀表面和斑块缺陷一般占据较少的区域^[53]。




图 3.6 图像缺陷标注

Fig3.6 Image defect labeling

为进一步分析工业钢带表面缺陷之间的差异性，本文根据缺陷检测预测框的像素面积数值（检测框长所占像素×检测框宽所占像素）将缺陷类型分成大缺陷、中缺陷和小缺陷三种，详细的缺陷大小划分规则见表 3.4。

表 3.4 缺陷大小定义

Table 3.4 Defect size definition		
缺陷大小	最小像素面积	最大像素面积（包含）
小缺陷	0	3000
中缺陷	3000	10000
大缺陷	10000	40000

3.4 模型实现与验证

3.4.1 实验环境与模型训练

本章实验环境搭建在实验室服务器上，服务器具体参数如表 3.5 所示。

表 3.5 实验环境

Table 3.5 Experimental environment	
名称	配置
显卡	NVIDIA GTX 2080Ti
内存	10GB
硬盘	500G
操作系统	Ubuntu16.04
并行计算库	CUDA10.1+CUDNN7.6
深度学习框架平台	Pytorch 1.7

在模型训练过程中采用 SGD（随机梯度下降）优化器，SGD 是梯度下降算法的一种实现，在求解损失函数的最小值时，可以通过梯度下降法来一步步地迭代求解，从而得到最小化的损失函数和最佳的模型参数值。本次实验中设定初始学习率为 0.01，动量因子为 0.937，IOU 阈值设为 0.5，权重衰减系数为 0.001，总训练次数为 300 次。模型检测框架图如图 3.7 所示。




图 3.7 模型检测框架图

Fig3.7 Model inspection framework diagram

3.4.2 评价指标

对模型性能优劣评价需要有合适的评价指标，考虑到工业的实际需求，采用交并比（Intersection over Union，IoU）、召回率（Recall，R）、准确率（ Precision，P）、PR(precision-recall curve)曲线、平均精度(average precision，AP)、均值平均精度(mean average precision， mAP) 和每秒帧数（frames per second，fps）^[54]来作为模型的评价指标。

IoU 表示模型输出预测框与真实框交集面积占并集面积的多少，计算公式为：

$$IoU = (B_p \cap B_gt)/(B_p \cup B_gt) \tag{3-4}$$

P 为准确率，表示正确预测样本与全部预测为真样本的比值，R 为召回率，表示正确预测样本与全部实际为真样本的比值，AP 为 P-R 曲线与坐标轴围成的面积，mAP 为均值平均精度，计算公式如下所示：

$$P = \frac{TP}{TP + FP} \tag{3-5}$$

$$R = \frac{TP}{TP + FN} \quad (3-6)$$

$$AP = \int_0^1 (P(R)dR) \quad (3-7)$$

$$mAP = \frac{\sum AP}{n} \quad (3-8)$$

式中 TP 表示本该是正样本的样本被模型预测是正样本，预测正确；FP 表示本该是正样本的样本被模型认为是负样本，预测错误；N 为训练集中样本的总数。

每秒帧数 (fps) 用来衡量模型的运算能力，指的是模型算法每秒钟可以处理图片的张数，在模型评价中数值越大，表明模型处理图片速度越快。

3.4.3 实验结果分析

为了更加全面分析改进模块对于原算法的提升效果，本章在原 YOLO V5 基础上进行了消融实验，将 SE 注意力模块和四尺度检测分别单独融入原网络中，测试结果如表 3.6、3.7 所示。

(1) 模型 1 为原始 YOLO V5 模型，在 NEU 数据集上验证 map 值为 75.9%；模型 2 为在模型 1 基础上引入 SE 注意力机制，map 值提升至 77.8%，6 类不同缺陷 ap 值均有一定幅度提升，结果表明引入该模块可以有效突出图像中的关键特征，解决特征信息损失较大问题，大大提升网络检测精度。

(2) 模型 3 为在模型 1 基础上融合四尺度特征提取及 K-means++ 聚类算法优化锚框大小，由数据可以看出模型 3 的 map 值较模型 1 提升了 2.6 个百分点，较模型 2 高出 0.7 个百分点。说明该模块扩大了网络的感受野，提升了语义信息与浅层几何特征的融合能力，通过匹配更准确的先验锚框大小，使得点蚀表面 (Ps)、夹杂物 (In) 等小缺陷类型的检测能力大幅提升，有效地提升了网络整体性能，且该模块的引入较只引入注意力机制对网络的整体提升效果更加明显。

(3) 通过消融实验对比可知，同时引入 SE 注意力模块、四尺度机制和锚框优化的模型 4 性能提升最高，轧制氧化皮 (Rs)、斑块 (Pa)、开裂 (Cr)、点蚀表面 (Ps)、夹杂物 (In) 和划痕 (Sc) 六类缺陷 map 均有提升，其中斑块和划痕识别率较高，识别精度都达到 90% 以上，点蚀表面、夹杂物和划痕缺陷识别精度提升最为明显，单类最高提升 6.1 个百分点，也表明引入的模块可以很好地融合在一起，对模型整体性能提升都发挥不可或缺的作用，验证了本文改进的网络的有效性。

表 3.6 消融实验模块添加

Table 3.6 Addition of ablation experiment module				
模型	1	2	3	4
SE 注意力机制	×	√	×	√
四尺度特征提取及 优化锚框	×	×	√	√

表 3.7 消融实验结果

Table 3.7 Results of ablation experiment				
模型	1	2	3	4
Rs	70.8%	71.9%	71.1%	71.8%
Pa	93.7%	95.4%	94.4%	95.5%
Cr	50.2%	52.3%	50.3%	51.8%
Ps	80.8%	82.8%	86.7%	86.7%
In	73%	74.8%	78.9%	79.1%
Sc	86.7%	89.6%	89.5%	90.3%
map	75.9%	77.8%	78.5%	79.2%

为了进一步验证本章提出算法的优越性，选用了该领域不同的目标检测算法，采用相同实验配置和训练策略在 NEU-DET 数据集上进行了实验，选取准确率、平均精度和每秒帧数作为评价指标，实验结果对比如表 3.8 所示：

表 3.8 不同算法实验结果对比

Table 3.8 Comparison of experimental results of different algorithms

算法	准确率 P	平均精度 mAP	每秒帧数 fps
SSD	70.2%	71.4%	38.5
YOLO V3	57.2%	55.3%	42.3
YOLO V4	73.8%	74.2%	53.2
YOLO V5	76.8%	75.9%	50.2
Ours	79.4%	79.2%	50

将改进后的 YOLO V5 算法与一阶段主流网络模型 SSD、YOLO V3、YOLO V4、YOLO V5 进行了对比测试。结果显示，SSD 模型中简单的特征提取网络难以对钢带表面的 6 类缺陷进行有效提取，检测效果较差，且每秒检测图片张数仅为 38.5 张，速度也较慢；而采用 Darknet-53 作为主干网络的 YOLO V3、YOLO V4 由于主干网络过深导致检测过程中小目标特征信息丢失严重，检测精度也很不理想；改进后的算法在准确度及平均精度上都可达到最优，保证了特征信息能够在网络结构中有效传递，较 YOLO V5 算法在准确度上提升了 2.6 个百分点，均值平均精度提升了 3.3 个百分点，

检测速度可达每秒 50 张图片，具备速度快、精度高等特点，完全可用于工业场景下的检测系统，提高工厂钢带缺陷检测效率。

3.5 本章小结

本章针对工业钢带表面存在轧制氧化皮、斑块等多类缺陷，传统的目标检测方法难以高效检测问题，通过分析数据集中存在的缺陷类型及特征提出了一种基于 YOLO V5 的改进算法。首先在 YOLO V5 的主干网络阶段引入 SE 注意力机制，增强目标检测网络对特征图中缺陷重要信息提取；其次在特征提取层通过融合操作，将原来的三种检测尺度融合为四尺度检测，同时通过 K-means++ 聚类算法优化锚框，匹配更适合的先验锚框大小，使得小缺陷类型的检测能力大幅提升，有效地提升了网络整体性能。从实验结果可知，改进的 YOLO V5 网络模型在检测精度上有了一定的提高，可达 79.2%，且具备较快的检测速度。

第四章 融合 Swin-Transformer 的检测模型

上一章提出的基于 YOLO V5 的工业钢带表面缺陷检测算法,能够对工业场景中钢带表面缺陷进行有效的缺陷判别,且模型参数量较少,对于设备配置要求不高,搭载计算机、工业相机等设备后普遍适用于一般工厂。但是随着工业设备的不断更新迭代,技术手段的不断优化升级,其识别精度难以满足高端设备钢带制造工厂需求。高端制备工厂往往具备先进的机器设备,对产品的质量要求也较高,故本章通过研究各种先进网络结构,提出了 SWTR-YOLO 模型,旨在提升缺陷检测网络的检测精度,以适配精密制造公司需求。

4.1 Swin Transformer 模型

Transformer 是由谷歌团队提出的一种基于注意力的结构,先是在自然语言处理和机器翻译任务中表现出强大的性能,后来在多个领域都逐渐成为了主流^[55]。在 Transformer 中弃用了我们所熟知的 CNN 和 RNN 结构,采用的网络结构是由注意力机制组成的。相比于卷积神经网络,Transformer 网络主要优势便是在图像处理中对特征信息的全局建模能力上,目前可以通过堆叠 Transformer 的方式可以实现对于 Transformer 可训练神经网络的搭建,算法的并行性和传统网络结构相比有了较大的提升。Transformer 主要结构如图 4.1 所示,它主要由一个编码器模块和一个解码器模块组成,编码器模块则由多个编码器组成,解码器模块则由多个解码器组成。编码器主要负责将输入转化为特征向量,解码器再完成特征向量向最终结果的转换。其中编码器由子 self-attention 层和 feed-forward 神经网络组成,每个解码器由 self-attention 层、encoder-decoder attention 层和 feed-forward 神经网络三部分组成。

由于 Transformer 在 NLP 任务中大放异彩,许多学者开始在其它计算机视觉任务中探索 Transformer 的新舞台。目前基于 Transformer 的计算机视觉任务在多个领域均取得了成功,如图像分类、目标检测、分割、姿态估计、视频处理和图像增强等。

ViT 是最为原始的使用视觉 Transformer 的图像分类网络,它遵循了 Transformer 的原始设计^[56]。ViT 将输入图像分割成一系列非重叠的 patch,作为 Transformer 的输入,同时对每个 patch 进行一维可学习的位置编码,保留其空间信息。实验结果表明 ViT 获得了与大多数主流 CNN 方法相似甚至更好的结果,进而体现了 Transformer 在计算机视觉任务中的有效性,但存在的不足之处就是当训练数据不够时不能得到很好的推广。

目标检测也是 Transformer 的重要应用领域之一。在 2020 年,Carion 等^[57]提出首

个基于 Transformer 的目标检测模型 DETR(Detection with Transformer), DETR 是一种简单的端到端目标检测网络, 主要思路是将目标检测视为一个集合预测问题, 消除了对手工制作的模块和操作的依赖。DETR 是一种新的目标检测框架设计, 为开发出完整的端到端目标检测器提供了新的方向。DETR 在 COCO 基准测试上获得了具有竞争力的性能, 但也存在着如收敛速度慢, 在小对象上性能较差等问题。




图 4.1 Transformer 网络结构图

Fig4.1 Transformer Network Structure Diagram

受预训练转换器在自然语言处理中取得重大成功的启发, Dai 等^[58]提出了一种随机查询检测方法, 用于无监督预训练, 称之为 UP-DETR, 该方法显著地提升了 DETR 的性能, 具备更快的收敛速度和更高的平均精度。

尽管是 ViT 真正把 Transformer 应用于计算机视觉中, 但是由于视觉对象具有尺度差异性, 因此在目标检测中必须尤为注意。另一方面, 由于图像具备高像素和高分辨率等特点, 目前针对于 Transformer 的全局注意力算法计算起来比较复杂。Liu 等^[59]提出了一个具有普适性的 Transformer 网络模型, 将其命名为 Swin Transformer, 该模型在

设计思想上借鉴了 ResNet，从局部特征建模到全局特征建模，使得模型达到可以逐步扩大感受野的效果。

Swin Transformer 总体结构如图 4.2 所示，其网络架构和 CNN 网络十分相像，均是由 4 个 stage（阶段）组成的，每个 stage 中的单元模块也是相同的。主要是通过将输入的图像利用 patch 的方法进行划分处理，其中每个 patch 尺寸大小为 4×4 ，因此可以得到的 patch 块为 $H/4 \times W/4$ 个，之后采用平铺展开方法来处理 patch 的像素点，可以得到 $4 \times 4 \times 3$ 的初始特征。然后将所得的特征图输入到 stage1 中，其中 stage1 是通过两层 Swin Transformer Blocks 所构成的，分别为普通的窗口自注意模块(window attention)、滑动窗口的多头自注意模块(shift window attention)。接下来的 stage2-stage4，与 CNN 的降采样比较类似，它保持总体的 patch 数量不变，然后对 patch 的大小进行扩充，其中它们的尺寸大小分别为 8、16 和 32，最后模型输出的就是含有 $H/32 \times W/32$ 个 patch 的特征图，每个 patch 的特征维度为 $8C$ (C 是 Stage1 之后 patch 的特征维度)，而(b)即为两个连续的 Swin Transformer Block。Swin Transformer 结构的特点不仅增大了图像的感受野，同时也节省了总体计算量^[60]。




图 4.2 Swin Transformer 结构图

Fig4.2 Swin Transformer Structure Diagram

Swin Transformer划分patch的方式和ViT有很大区别，ViT先要确定patch的数目，然后计算确定每个patch的尺寸，而Swin Transformer与之相反，先确定每个patch的尺寸大小，然后再计算patch的数量。这样做虽然减少了计算量但也会隔绝不同窗口之间的信息传递，所以使用Shifted Windows Multi-Head Self-Attention(SW-MSA)操作，通过滑动窗口交互，让信息在相邻的窗口中进行传递，达到了一种全局建模的效果。

如图4.3所示，在Layer 1层(左)中，采用的是规则的窗口划分方案， 8×8 尺寸feature map划分成 2×2 个patch，每个patch尺寸为 4×4 ，在每个窗口中计算自注意。而在Layer $l+1$ 层(右边)，窗口被重新分割、移动，得到 3×3 个不重合的patch，产生了一种新的窗口划分方式，在新窗口中重新开始计算各自内部的自注意。由图可以清楚地看到，新窗口的

自注意计算机制打破了上一个窗口中规则的计算方式，使不重合的窗口之间产生联系，大大地增加了感受野，从而增强了模型的全局建模能力^[61]。




图 4.3 Swin Transformer 滑动窗口设计

Fig4.3 Sliding Window Design for Swin Transformer

Swin Transformer 的层级设计也至关重要，通过不同层级来构建特征映射，将模型计算复杂度与输入图像的大小表现为数学中常见的线性关系，该设计的思路是从更深层的图像块开始，然后慢慢合并与之相邻的图像块来共同组成分层特征图，这一方法将注意力计算限制在每个单独窗口内，从而对于模型整体计算复杂度也有了一定的限制。而之前的 ViT 模型都是基于图像全局进行自注意，所生成的特征图比较单一，而且需要计算图像大小，计算复杂度较高。所以，Swin Transformer 逐渐取代 ViT 应用于各种机器视觉任务中^[62]。

4.2 SWTR-YOLO 模型

模型的构建基于 YOLO V5 网络，表 4.1 为 YOLO V5s、YOLO V5m、YOLO V5l、YOLO V5x 四种网络的模型参数量、理论计算值和训练 map 值。

表 4.1 不同网络参数对比

Table 4.1 Comparison of different network parameters

算法	参数量	单张推理用时	map
YOLO V5s	7.2M	0.9ms	56.8%
YOLO V5m	21.2M	1.7ms	64.1%
YOLO V5l	46.5M	2.7ms	67.3%
YOLO V5x	86.7M	4.8ms	68.9%

由表可以看出，在采用相同训练策略在同一数据集上验证时，YOLO V5s 推理最快，YOLO V5m 在 map 数值上较 YOLO V5s 有很大的提升，模型推理用时变化不大，

而 YOLO V5l 和 YOLO V5x 在训练精度上较 YOLO V5m 提高不大，但其引入数倍的参数量，牺牲了较多的推理速度。综合考虑下，选用 YOLO V5m 网络来改进构建网络。

4.2.1 全局建模主干网络构建

YOLO V5m 网络将 Focus 模块引入其最前端，与下采样操作的方式相同，都是对图片进行切片处理。例如，原始的 $640 \times 640 \times 3$ 的彩色图片输入 Focus 结构，首先对图片进行切片处理，变为 $320 \times 320 \times 12$ 大小，经过一次 3×3 卷积操作后，将输出通道数变为了 32，使图像扩充为 $320 \times 320 \times 32$ 的特征图，这样操作的好处是下采样过程中没有特征信息损失，然而却无法有效提取图像中的关键特征信息。将 Focus 替换为 Conv 来实现对图像的卷积运算可以提高模型特征提取能力。

然后引入 Swin Transformer 模块 C3SWinTR 来代替原框架中第一个 CSP 模块，来达到提取特征、全局建模的效果。由上一节分析 Swin Transformer 结构可知，Swin Transformer 采用的是滑动注意力机制，可以有效地控制模型计算量，而且兼顾了 CNN 的局部特征提取能力，能使模型关注有效特征，抑制无关特征。不仅如此，其采用多头自注意力机制还可以增强检测窗口相互之间的联系，有效地提升了模型感知全局特征的能力。主干网络改进结构如图 4.4 所示。




图 4.4 主干网络结构图

Fig4.4 Backbone network structure diagram

由于 Transformer 结构在浅层网络中无法进行有效学习，且计算代价较高，所以将 C3SWinTR 放在特征提取网络的深层网络中，将第一个 CSP 模块替换为 C3SWinTR，有利于主干网络对全局信息进行提取，而且使模型达到并行化训练效果，在减少算力中也起到重要作用。

4.2.2 CARAFE 上采样算子优化

在特征金字塔结构中上采样操作是一个关键性步骤，目前常用的方法分别是双线性差值法、最近邻插值法和反卷积法。其中双线性差值法和最近邻差值法仅通过像素点的位置来决定上采样核，并没有利用到特征图的语义信息，都是比较“均匀”的上采样，而且感知域比较小。反卷积法主要是通过卷积的方式来扩大维度，但是在这一过程中整个图像都采用一个卷积核，因此该方法不仅降低模型对局部变化差异的感知能力，还增加了模型复杂度。

CARAFE (Content-Aware ReAssembly of FEatures) 是一种理想上采样算子，可巧妙

弥补以上几种方法的不足，不仅具备较大的感受野，可以基于输入内容进行上采样，还具备轻量化特性，模型参数量很少，复杂度较低。其网络结构如图4.5所示。总体架构分为两个主要模块，分别是上采样核预测模块和特征重组模块^[63]。




图 4.5 CARAFE 网络结构图

Fig4.5 CARAFE Network Structure Diagram

如图4.5所示，在上采样核预测模块中，首先将输入为 $H \times W \times C$ 的特征图进行通道压缩，用一个 1×1 的卷积将它的通道数压缩至 C_m ，以此减小后续步骤的计算量；其次进行内容编码，假设上采样核尺寸为 $K_{up} \times K_{up}$ ，对于输入的特征图利用一个 $K_{encoder} \times K_{encoder}$ 的卷积层来预测上采样核，输入通道数为 C_m ，输出通道数为 $\sigma^2 K_{up}^2$ ，将其展开，得到 $\sigma H \times \sigma W \times K_{up}^2$ 的上采样核；然后利用softmax函数进行核归一化，使得卷积核权重和为1。在特征重组模块中，通过将每个位置的输出特征图映射到输入特征图当中，将 $K_{up} \times K_{up}$ 为中心的区域取出，并且输出值是通过与预测出的该点的上采样核作点积所得到的，最终输出形状为 $\sigma H \times \sigma W \times C$ 的特征图^[64]。

颈部网络结构图如图4.6所示，使用CARAFE上采样算子代替最邻近插值上采样算子，通过输入特征图来预测上采样核，然后基于预测的上采样核完成特征重组，利用输入特征图的部分语义信息，在付出极少的计算代价的情况下基于输入内容进行上采样，最后通过Concat特征融合送入下一层级，迭代地完成三个层级的特征上采样操作，CARAFE上采样算子的加入可以使得不同尺度的特征图内部的上下文语义信息传递更充分，信息的缺失降低，可以有效地提升检测效果。在工业钢带数据集中，部分缺陷类型的特征较为相似，检测中容易出现错检问题，采用CARAFE上采样算子有助于模型恢复图像特征，得到高品质的图像信息，在很大程度上降低了模型的错检率。




图 4.6 颈部网络结构图

Fig4.6 Neck network structure diagram

4.2.3 特征融合

YOLO V5网络在颈部特征融合中采用多尺度特征金字塔结构（FPN）结构，证明了双向融合的有效性，但是特征金字塔结构过于简单，没有考虑特征图中各个位置之间的关联性。而本文研究的钢带数据集中存在多种微小缺陷目标，因此简单的拼接难以胜任检测任务。

为了有效抑制工业检测复杂背景中一些无用信息对检测的干扰，提高模型对数据集中缺陷部分的特征提取能力，需要采用多尺度特征融合操作。在原YOLO V5m网络中采用的FPN结构是将不同输出大小的特征图调适为相同大小后进行融合，这样简单的融合操作容易因尺度信息不一致导致融合特征图噪声变大，从而使得检测结果变差。ASFF（adaptive spatial feature fusion）是一种新型的数据驱动金字塔特征融合算法，首先利用自适应算法可以改变每个特征层的融合比例，其次通过删除空间噪声的方法改善了特征融合过程中尺度不一致的问题，并且ASFF操作计算量极少，仅需消耗较少的计算代价便可达到预期的效果^[65]，因此ASFF模块在任意的特征金字塔网络中都可以有效应用。其结构设计图如图4.6所示，包含特征调适和自适应融合两个部分。

特征调适是为了解决特征融合尺寸不同的问题。如图4.7所示， X_1 、 X_2 、 X_3 分别

为特征金字塔结构输出的三层特征，以ASFF-3为例，与来自不同层的特征乘上权重参数 α ， β 和 Γ 相乘，然后相加，就能得到新的融合特征ASFF-3[66]，具体公式如下所示

$$Y_L = \alpha_L * X_{(1-L)} + \beta_L * X_{(2-L)} + \Gamma_L * X_{(3-L)} \tag{4-1}$$

对于权重因子 α 、 β 和 Γ ，则是通过调适后的特征图经过 1×1 的卷积得到的， α 、 β 和 Γ 经过融合之后通过归一化操作使它们范围都在 $[0, 1]$ 内且和为1。计算公式如下：

$$a_L = \frac{e^{\lambda_a^L}}{e^{\lambda_a^L} + e^{\lambda_b^L} + e^{\lambda_\Gamma^L}} \tag{4-2}$$

上式中 λ 是分别对经过特征调适后的三个特征图层使用使用 1×1 卷积得到的，通过上式计算得到 α ，同理可得到 β 和 Γ ，这三个重要性权重参数通过标准的反向传播训练得到最终结果。




图 4.7 ASFF 网络结构图

Fig4.7 ASFF Network structure diagram

为了更好地改善缺陷目标特征信息丢失问题，本文在YOLO V5m网络多尺度特征提取的基础上，采用自适应特征融合ASFF操作，可以很好地融合不同尺度感受野下工业钢带缺陷目标的特征信息。此外，ASFF仅由两个卷积层组成，因此具有较少的参数量，并不会对整体模型额外增加过多的计算代价。

4.3 模型实现与验证

4.3.1 实验环境与模型训练

本文实验环境搭建在实验室服务器上，具体参数如表 4.2 所示。

表 4.2 实验环境

Table 4.2 Experimental environment

名称	配置
显卡	NVIDIA GTX 2080Ti
内存	10GB
硬盘	500G
操作系统	Ubuntu16.04
并行计算库	CUDA10.1+CuDNN7.6
深度学习框架平台	Pytorch 1.7

在模型训练过程中采用 SGD（随机梯度下降）优化器，设定初始学习率为 0.01，动量因子为 0.937，IOU 阈值设为 0.5，权重衰减系数为 0.001，优化后的网络模型训练了 300 个 epoch，各类损失函数及准确度、召回率训练图如图 4.8、4.9 所示。




图 4.8 训练损失函数图

Fig4.8 Training loss function diagram

图 4.8 为模型训练的损失函数，损失函数可反映出模型在训练过程中的健康情况，通过梯度下降的方式更新网络参数，从而减少损失，loss 越小表明训练结果越好。图中 box_loss 用于监督检测框的回归，预测框与标定框之间的误差（CIoU）；obj_loss 用于

监督 `grid` 中是否存在物体，计算网络的置信度；`cls_loss` 用于监督类别分类，计算锚框与对应的标定分类是否正确。由折点图可以看出，各类损失函数在训练前 30 个 `epoch` 时大幅下降，随后下降幅度减弱，200 个 `epoch` 左右时，模型数据基本不再发生变化，趋于稳定状态。




图 4.9 准确度和召回率损失

Fig4.9 Loss of accuracy and recall

图 4.9 中反映出模型各项指标的评估结果，在训练 100 个 `epoch` 前，模型起伏较大，整体呈现增长趋势并趋向稳定，直到 200 个 `epoch` 时数值不再有明显变动且接近于 1.0，表明训练次数 200-300 即可达到训练要求，过多的 `epoch` 不仅不会提升网络精度，还会耗费不少训练时间。

4.3.2 模型性能评估

YOLO V5m 与 SWTR-YOLO 两个模型在 NEU 数据集上生成的混淆矩阵如图 4.10 所示。由图可以看出，在 YOLO V5m 中 6 类缺陷的分类精度分别为 30%、70%、92%、68%、61%、88%，平均达 68.1%，其中 Pa 缺陷各有 1% 的概率被预测为 In 和 Ps，且均有较高的概率被预测为背景信息，分类精度一般，存在较高的错检率。而 SWTR-YOLO 中 6 类缺陷的分类精度分别为 30%、79%、95%、75%、64%、90%，Pa 缺陷不再出现错检现象，各类缺陷的分类精度均有小幅提升，平均分类精度可达 72.2%，较 YOLO V5m 提升了 4.1 个百分点，可见改进模型能够有效提升分类精度，改善各类缺陷的漏检错检问题，显著提升模型性能。




图 4.10 不同模型在数据集中的混淆矩阵

Fig4.10 Confusion matrix of different models in data set

如图 4.11 所示,是改进后的模型 SWTR-YOLO 对于 6 类缺陷各自及平均检测精度的 P-R 曲线图,它可以直观地展示出模型的查全率和查准率。图中,横坐标表示的为召回率 (Recall),纵坐标表示的为准确度 (Precision),横纵坐标与曲线围成的面积大小即可反映模型的优劣,即 AP 值。图中 6 条不同颜色细折线分别表示 6 类缺陷识别 AP 值,蓝色粗折线表示均值平均精度 mAP 值,模型检测的 6 类缺陷的 AP 值分别为 55.8%、87.6%、96.8%、90.4%、72.1%、96.3%,整体 mAP 值为 83.2%,这是目前机器视觉领域缺陷检测算法在工业钢带 NEU 数据集验证中较高的数值,反映出本章提出模型性能的先进性与优异性。














图 4.11 训练 P-R 曲线图

Fig4.11 Training P-R curve

为了更加直观展示改进模型的检测精度,将优化后的算法 SWTR-YOLO 与 YOLO V5m 检测效果进行了可视化对比,6 类缺陷部分检测效果图如表 4.3 所示。表中由 6 种不同颜色的检测框来区分 6 类不同的缺陷类型,由可视化对比表可以看出,YOLO V5m 模型在 Pa、Cr、Ps、Sc 四类缺陷检测中存在严重的漏检现象,有部分缺陷无法识别出来,且 6 类缺陷检测置信度均较低,而 SWTR-YOLO 网络则达到很好的检测效果,具备较高的检测置信度,而且不存在误检、漏检现象。

表 4.3 可视化实验对比

Table 4.3 Comparison of visualization experiments

检测模型 缺陷类别	YOLO V5m	SWTR-YOLO
Rs		
Pa		
Cr		
Ps		
In		
Sc		

4.3.3 实验结果分析

为了验证改进算法的优劣性，将模型与目前主流算法 SSD、Faster R-CNN、YOLO V5s、YOLO V5m 和第三章算法进行了实验对比，评价指标采用 6 类缺陷 AP 值、mAP 和每秒帧数 FPS。

由数据可以看出，本章提出的 SWTR-YOLO 算法总体性能优于当前目标检测领域主流算法，六类缺陷单项识别准确率和均值平均精度都达最高，模型对划痕和斑块两种缺陷检测效果最好，AP 值高达 96.3%和 96.8%，均值平均精度 mAP 值可达 83.2%，达到缺陷检测行业较高水平，比改进前的 YOLO V5m 模型提高了 7 个百分点，较第三章提出算法提高了 4 个百分点，表现出检测模型在精度方面的优异性。在速度方面检测速度可达每秒 34.8 张，与 FPS 最高的 YOLO V5s 相比相差不大，与单阶段网络主流网络 SSD 检测速度持平，在牺牲较少检测速度的前提下达到了较高的检测精度，可满足精密制备工厂检测需求。

表 4.4 实验结果对比
Table 4.4 Comparison of experimental results

Model	AP (%)						mAP (%)	FPS
	Cr	In	Pa	Ps	Rs	Sc		
SSD	51.1	80.2	90.8	82.5	56.3	67.5	71.4	38.5
Faster R-CNN	48.5	72.2	87.2	79.6	58.2	73.3	69.8	21.2
YOLO V5s	50.2	73	93.7	80.8	70.8	86.7	75.9	50.2
YOLO V5m	51.8	78.6	93.8	79.4	65.1	88.3	76.2	42.1
第三章算法	51.8	79.1	95.5	86.7	71.8	90.3	79.2	50
SWTR-YOLO	55.8	87.6	96.8	90.4	72.1	96.3	83.2	34.8

为了验证不同改进策略的必要性及其对模型性能的影响，分别对改进策略进行消融实验。实验结果如表 4.5 所示，“√”和“×”表示该模块在模型中是否应用。由数据可以看出，经过主干网络优化后的模型 2 比模型 1 的 mAP 值提升了 4.5%，在数值方面提升较大，且 6 类不同缺陷 AP 值均有提升；模型 3 和模型 4 分别在模型 2 的基础上采用 CARAFE 上采样算子和进行 ASFF 特征融合操作，训练结果可以看出，mAP 值相较于模型 2 分别提升 0.8、1.4 个百分点，由此可见两种改进策略对于模型性能的提升都发挥着不可或缺的作用；而本文提出的 SWTR-YOLO 模型相较模型 1、2、3、4 在各项训练指标上都达到了最佳，表明各种改进策略可以很好的融合在一起，对模型整体性能的提升都发挥着至关重要的作用。

表 4.5 消融实验对比

Table 4.5 Comparison of ablation experiments

Model	改进策略模块配置			各类缺陷 AP 值 (%)						mAP(%)
	主干优化	CARAFE	ASFF	Cr	In	Pa	Ps	Rs	Sc	
1	×	×	×	51.8	78.6	93.8	79.4	65.1	88.3	76.2
2	√	×	×	55	85.4	94.5	85.5	70.3	93.7	80.7
3	√	√	×	55.1	86.3	94.7	87.5	71.1	94.5	81.5
4	√	×	√	55.7	87	95.7	87.4	71.2	95.4	82.1
SWTR-YOLO	√	√	√	55.8	87.6	96.8	90.4	72.1	96.3	83.2

4.4 本章小结

本章为符合工业钢带高端制备工厂对产品质量的要求，通过融合高效模块来进一步提升检测效率。首先融合 Swin Transformer 模块，引入滑动注意力机制，通过滑动窗口交互，让信息在相邻的窗口中进行传递，达到了一种全局建模的效果；其次采用上采样算子 CARAFE，使模型具备较大感受野，能更好地利用周围信息；最后引入自适应空间特征融合(ASFF)，分别对 PANet 输出的 3 个水平特征图进行加权融合，充分利用不同尺度的特征。从实验结果来看，检测精度高达 83.2%，可适配高精度检测要求。

第五章 结论与展望

5.1 全文总结

在工业产品表面缺陷检测中,得益于机器设备强大的抗干扰性和特征表示能力,基于机器视觉的缺陷检测方法已广泛应用于各类工业制造工厂中,但是各类产品实际检测中往往会存在缺陷检测精度低和难以适配等问题,达不到正常工业生产要求。本文为了实现基于机器视觉方法在单一背景工业检测中的应用,选择使用最为广泛的目标检测算法YOLO开展研究,分析该算法的运行机制,并结合工业钢带在实际工业检测时出现的不同问题,探究提出工业钢带缺陷检测的改进策略。本文主要完成以下内容:

(1) 查阅机器视觉和缺陷检测相关的文献资料,总结国内外专家学者在缺陷检测中应用的技术与方法,同时对工业钢带的生产背景和缺陷特征进行了研究分析及总结,从而确立了工业钢带表面缺陷检测研究的主要内容。

(2) 针对工业钢带表面微小缺陷较多且难以检测的特点,本文提出一种基于YOLO V5的钢带表面缺陷检测方法。针对工业钢带图像缺陷存在多尺度、微小缺陷占比高等特点,本文在YOLO V5骨干网络中引入SE(Squeeze-and-Excitation)注意力机制,来强化模型对缺陷重要信息的提取能力,解决特征信息损失较大问题;在此基础上分析YOLO特征金字塔结构,通过增大网络的检测区域来实现四尺度特征提取,加强模型深层与浅层语义信息的融合;并使用K-means++算法针对钢带图像重新设计模型Anchor,解决部分小目标检测困难问题。通过第三章实验验证了所提算法能够有效提升小目标缺陷检测性能。

(3) 为进一步提升缺陷检测方法检测效率和鲁棒性,本文融合Swin Transformer模块进行进一步优化。首先引入滑动注意力机制,通过滑动窗口交互,让信息在相邻的窗口中进行传递,达到了一种全局建模的效果。之后采用上采样算子CARAFE,使模型具备较大感受野,能更好地利用周围信息,而且计算参数量少。同时为了保证检测网络的检测效果,本文还引入自适应空间特征融合(ASFF),对特征金字塔结构输出的3个水平特征图分别进行加权特征融合,充分利用不同尺度的特征,通过设置可自适应学习的参数来抑制模型在训练过程中由于梯度反传而导致的不一致性,充分利用不同尺度的特征。通过第四章实验结果对比,表明了所提算法的优异性。

5.2 未来展望

本文提出的改进后的单阶段目标检测算法在单一背景的工业产品表面缺陷检测任

务上取得了一定的成果，不过还有很多问题需要继续研究，主要包括以下几点：

（1）虽然对小目标缺陷的检测有了一定的改进，但影响小目标检测的关键因素仍是其有限的分辨率和语义信息，今后进一步的研究可以考虑利用更加有效的特征融合策略或者超分辨技术，从而增强小目标特征或减少小目标特征的丢失，以便进一步提高小目标缺陷检测的精度。

（2）类别间样本不均衡问题在实际工业场景中是普遍存在且较难解决的，进一步的研究可以在分析工业场景具体情况的前提下，探究合适的数据增强、代价敏感学习及采样和集成学习等策略，以缓解实际工业场景下的类别间样本不均衡问题。

（3）本文提出的高精度检测模型参数量比较大，增加了一定的模型检测时间，且需要占用较多的运行空间。从模型剪枝的角度考虑，可以对模型进行进一步的剪枝优化，使之具备轻量化、易移植特性，进一步提升模型的检测速度。

参考文献

- [1] 宋晓娜, 张峰. 高质量发展下工业发展质量测度及趋势研究[J]. 软科学, 2019, 33(12):36-41.
- [2] Kurniati. N, Yeh. R. H, Lin. J. J. Quality inspection and maintenance: the framework of interaction [J]. Procedia manufacturing, 2015, 4: 244-251.
- [3] 李春霖, 谢刚, 王银, 谢新林, 刘瑞珍. 基于YOLOv3-Tiny-D算法的偏光片缺陷检测[J]. 计算机集成制造系统, 2022, 28(03).
- [4] W. Y. Lin, C. Y. Lin, G. S. Chen, et al. Steel surface defects detection based on deep learning[C]//International Conference on Applied Human Factors and Ergonomics. Springer, Cham, 2018: 141-149.
- [5] Y. He, K. Song, Q. Meng and Y. Yan. An End-to-End Steel Surface Defect Detection Approach via Fusing Multiple Hierarchical Features [J]. IEEE transactions on instrumentation and measurement, 2020, 69 (4): 1493-1504.
- [6] X. Peng, Y. Chen, W. Yu, et al. An online defects inspection method for float glass fabrication based on machine vision [J]. The International Journal of Advanced Manufacturing Technology, 2008, 39: 1180-1189.
- [7] A. Krizhevsky, I. Sutskever, G. Hinton. ImageNet Classification with Deep Convolutional Neural Networks [C]. Conference and Workshop on Neural Information Processing Systems, 2012.
- [8] J. Fan, F. Zhao. Two-dimensional Otsu's curve thresholding segmentation method for gray-level images [J]. Acta Electronica Sinica, 2007, 35(4): 751.
- [9] F. Y. Shih, S. Cheng. Automatic seeded region growing for color image segmentation [J]. Image and vision computing, 2005, 23 (10): 877-886.
- [10] J. F. Cayula, P. Cornillon. Edge detection algorithm for SST images [J]. Journal of atmospheric and oceanic technology, 1992, 9 (1): 67-80.
- [11] 曹宇, 徐传鹏. 一种改进阈值分割算法在镜片缺陷检测中的应用[J]. 激光与光电子学进展, 2021, 58(16):219-224.
- [12] G. Cao, S. Ruan, Y. Peng, et al. Large-complex-surface defect detection by hybrid

- gradient threshold segmentation and image registration [J]. IEEE Access, 2018, 6: 36235-36246.
- [13] 张小琳, 刘祎, 白贇泓, 刘研, 李文强, 桂志国. 基于背景估计的焊缝缺陷检测[J]. 电子测量技术, 2022, 45(14):116-122.
- [14] Z. Wang, X. Guo, X. Wu, Z. Wang. Superpixel segmentation based on multiple seed growth [C]. International Symposium on Intelligent Signal Processing and Communication Systems, 2017: 529-534.
- [15] 彭道刚, 尹磊, 威尔江, 胡捷, 杨晓伟. 基于OTSU和区域生长的电厂管道缺陷检测与分割[J]. 红外技术, 2021, 43(05):502-509.
- [16] F. Orujov, R. Maskeliūnas, R. Damaševičius, et al. Fuzzy based image edge detection algorithm for blood vessel detection in retinal images [J]. Applied Soft Computing, 2020, 94: 106452.
- [17] 张建国, 季甜甜, 莘明星, 左春梅, 刘隽. 涂胶缺陷检测中的边缘提取方法[J]. 船舶工程, 2021, 43(02):128-133.
- [18] W. Zhao, F. Chen, H. Huang, et al. A new steel defect detection algorithm based on deep learning [J]. Computational Intelligence and Neuroscience, 2021: 1-13.
- [19] R. Girshick, J. Donahue, T. Darrell, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 580-587.
- [20] J. Redmon, A. Farhadi. YOLO9000: Better, Faster, Stronger[C]. IEEE Conference on Computer Vision & Pattern Recognition, 2017: 6517-6525.
- [21] T.Y. Lin, P. Goyal, R. Girshick, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2980-2988.
- [22] W. Liu, D. Anguelov, D. Erhan, et al. Ssd: Single shot multibox detector[C]. European conference on computer vision. Springer, Cham, 2016: 21-37.
- [23] J. Redmon, S. Divvala, R. Girshick, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.

- [24] X. Sun, P. Wu, S. C. H. Hoi. Face detection using deep learning: An improved faster RCNN approach [J]. *Neurocomputing*, 2018, 299: 42-50.
- [25] 陈建强, 刘明宇, 符秦沈等. 基于深度学习的热轧钢带表面缺陷检测方法[J]. *自动化与信息工程*, 2019, 40(04):11-16+19.
- [26] S. H. Chen, C. C. Tsai. SMD LED chips defect detection using a YOLOv3-dense model [J]. *Advanced engineering informatics*, 2021, 47: 101255.
- [27] H. Di, X. Ke, Z. Peng, et al. Surface defect classification of steels with a new semi-supervised learning method [J]. *Optics and Lasers in Engineering*, 2019, 117(JUN.): 40-48.
- [28] Y. Gao, L. Gao, X. Li, et al. A semi-supervised convolutional neural network-based method for steel surface defect recognition [J]. *Robotics and Computer-Integrated Manufacturing*, 2020, 61: 101825.
- [29] 张林, 谢刚, 谢新林, 张涛源. 融合MobileNetv3与Transformer的钢板缺陷实时检测算法[J/OL]. *计算机集成制造系统*:1-14.
- [30] 沈春光, 李虎威, 荆涛, 王晨充, 徐伟. 基于深度学习的带钢表面缺陷检测在小样本数据集的应用[J]. *轧钢*, 2022, 39(02):82-86.
- [31] H. Zheng, J. Fu, T. Mei, J. Luo. Learning Multi-attention Convolutional Neural Network for Fine-Grained Image Recognition [C]. *IEEE International Conference on Computer Vision*, 2017: 5219-5227.
- [32] Q. Zhou, R. Chen, B. Huang, et al. An automatic surface defect inspection system for automobiles using machine vision methods [J]. *Sensors*, 2019, 19(3): 644.
- [33] K. Hanbay, M. F. Talu, Ö. F. Özgüven. Fabric defect detection systems and methods—A systematic literature review [J]. *Optik*, 2016, 127(24): 11960-11973.
- [34] Q. Luo, X. Fang, L. Liu, et al. Automated visual defect detection for flat steel surface: A survey [J]. *IEEE Transactions on Instrumentation and Measurement*, 2020, 69(3): 626-644.
- [35] F. G. Bulnes, D. F. García, F. J. De la Calle, et al. A non-invasive technique for online defect detection on steel strip surfaces [J]. *Journal of Nondestructive Evaluation*, 2016,

35: 1-18.

- [36] J. Zhang, X. Kang, H. Ni, et al. Surface defect detection of steel strips based on classification priority YOLOv3-dense network [J]. Ironmaking & Steelmaking, 2021, 48(5): 547-558.
- [37] H. Wang, J. Zhang, Y. Tian, et al. A simple guidance template-based defect detection method for strip steel surfaces [J]. IEEE Transactions on Industrial Informatics, 2018, 15(5): 2798-2809.
- [38] D. He, K. Xu, P. Zhou. Defect detection of hot rolled steels with a new object detection framework called classification priority network [J]. Computers & Industrial Engineering, 2019, 128: 290-297.
- [39] 李宏洲. 冷轧带钢表面压斑缺陷分析[J]. 金属世界, 2021(06):38-40.
- [40] Z. Liu, X. Wang, X. Chen. Inception dual network for steel strip defect detection[C]//2019 IEEE 16th International Conference on Networking, Sensing and Control (ICNSC). IEEE, 2019: 409-414.
- [41] Z. Li, F. Liu, W. Yang, et al. A survey of convolutional neural networks: analysis, applications, and prospects [J]. IEEE transactions on neural networks and learning systems, 2021.
- [42] S. Albawi, T. A. Mohammed, S. Al-Zawi. Understanding of a convolutional neural network[C]//2017 international conference on engineering and technology (ICET). Ieee, 2017: 1-6.
- [43] A. Ajit, K. Acharya, A. Samanta. A review of convolutional neural networks[C]//2020 international conference on emerging trends in information technology and engineering (ic-ETITE). IEEE, 2020: 1-5.
- [44] R. Yamashita, M. Nishio, R. K. G. Do, et al. Convolutional neural networks: an overview and application in radiology [J]. Insights into imaging, 2018, 9: 611-629.
- [45] A. Lavin, S. Gray. Fast algorithms for convolutional neural networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 4013-4021.
- [46] Y. Li, Z. Hao, H. Lei. Survey of convolutional neural network [J]. Journal of Computer

- Applications, 2016, 36(9): 2508.
- [47] J. Redmon, A. Farhadi. Yolov3: An incremental improvement [J]. arXiv preprint arXiv:1804.02767, 2018.
- [48] I. Bello, B. Zoph, A. Vaswani, et al. Attention augmented convolutional networks[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 3286-3295.
- [49] 单明陶, 高玮玮. 改进YOLOv4的内丝接头密封面缺陷检测算法[J]. 电子测量与仪器学报, 2022, 36(05):120-127.
- [50] R. Hao, B. Lu, Y. Cheng, et al. A steel surface defect inspection approach towards smart industrial monitoring [J]. Journal of Intelligent Manufacturing, 2021, 32: 1833-1843.
- [51] T. Kong, F. Sun, A. Yao, et al. Ron: Reverse connection with objectness prior networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 5936-5944.
- [52] X. Wang, R. Zhang, C. Shen, et al. Dense contrastive learning for self-supervised visual pre-training[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 3024-3033.
- [53] 韩强, 张喆, 续欣莹, 谢新林. 基于FF R-CNN钢材表面缺陷检测算法[J]. 太原理工大学学报, 2021, 52(05):754-763.
- [54] 赵佳乐, 王广龙, 周冰, 应家驹, 王强辉, 邓磊. 深度学习下高光谱图像目标检测技术研究进展[J]. 激光杂志, 2022, 43(10):1-6.
- [55] A. Vaswani, N. Shazeer, N. Parmar, et al. Attention is all you need [J]. Advances in neural information processing systems, 2017, 30.
- [56] A. Dosovitskiy, L. Beyer, A. Kolesnikov, et al. An image is worth 16x16 words: Transformers for image recognition at scale [J]. arXiv preprint arXiv:2010.11929, 2020.
- [57] N. Carion, F. Massa, G. Synnaeve, et al. End-to-end object detection with transformers[C]//Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part I 16. Springer International Publishing, 2020: 213-229.

- [58] Z. Dai, B. Cai, Y. Lin, et al. Up-detr: Unsupervised pre-training for object detection with transformers[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 1601-1610.
- [59] Z. Liu, Y. Lin, Y. Cao, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.
- [60] W. Chen, Z. Huang, Q. Mu, et al. PCB Defect Detection Method Based on Transformer-YOLO [J]. IEEE Access, 2022, 10: 129480-129489.
- [61] H. Gong, T. Mu, Q. Li, et al. Swin-Transformer-Enabled YOLOv5 with Attention Mechanism for Small Object Detection on Satellite Images [J]. Remote Sensing, 2022, 14(12): 2861.
- [62] 雷承霖, 李敏, 王斌. 基于Swin Transformer的两阶段织物疵点检测[J].棉纺织技术, 2023, 51(02):41-47.
- [63] J. Wang, K. Chen, R. Xu, et al. Carafe: Content-aware reassembly of features[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 3007-3016.
- [64] 向华桥, 崔文超, 刘世焯, 孙水发. 基于高表征能力特征处理模块的小目标检测[J]. 计算机工程与设计, 2021, 42(05):1360-1367.
- [65] S. Liu, D. Huang, Y. Wang. Learning spatial fusion for single-shot object detection[J]. arXiv preprint arXiv:1911.09516, 2019.
- [66] 肖粲俊, 潘睿志, 李超, 黄纪刚. 基于改进YOLOv5s绝缘子缺陷检测技术研究[J]. 电子测量技术, 2022, 45(24):137-144.