

DOI: 10.19650/j.cnki.cjsi.J2108805

基于机器视觉的表面缺陷检测方法研究进展*

赵朗月, 吴一全

(南京航空航天大学电子信息工程学院 南京 211106)

摘 要: 在半导体、PCB、汽车装配、液晶屏、3C、光伏电池、纺织等行业中,产品外观与产品性能有着千丝万缕的联系。表面缺陷检测是阻止残次品流入市场的重要手段。利用机器视觉的技术进行检测效率高、成本低,是未来发展的主要方向。本文综述了近十年来基于机器视觉的表面缺陷检测方法的研究进展。首先给出了缺陷的定义、分类以及缺陷检测的一般步骤;然后重点阐述了使用传统图像处理方式、机器学习、深度学习进行缺陷检测的原理,并比较和分析了优缺点,其中传统图像处理方式分为分割与特征提取两个部分,机器学习包含无监督学习和有监督学习两大类,深度学习主要囊括了检测、分割及分类的大部分主流网络;随后介绍了 30 种工业缺陷数据集以及性能评价指标;最后指出缺陷检测方法目前存在的问题,对进一步的工作进行了展望。

关键词: 缺陷检测; 机器视觉; 机器学习; 深度学习; 数据集; 性能评价指标

中图分类号: TP391 TH89

文献标识码: A

国家标准学科分类代码: 510.4050

Research progress of surface defect detection methods based on machine vision

Zhao Langyue, Wu Yiquan

(College of Electronic and Information Engineering, Nanjing University of Aeronautics and Astronautics, Nanjing 211106, China)

Abstract: In semiconductor, printed circuit board (PCB), automobile assembly, liquid crystal display (LCD), 3C, photovoltaic cell, and textile industries, the appearance of the product is closely related to the performance of the product. Surface defect detection is an important way to prevent defective products from entering the market. The utilization of machine vision technology to perform inspections with high efficiency and low cost is the main direction of future development. This article reviews the research progress of surface defect detection methods based on machine vision in recent ten years. Firstly, the definition of defect is given, and the general steps of defect detection are described. Then, it focuses on the principle of defect detection using traditional image processing methods, machine learning, and deep learning. The advantages and disadvantages are compared and analyzed. The traditional image processing methods are divided into segmentation and feature extraction. Machine learning consists of unsupervised learning and supervised learning. Deep learning mainly covers most of the mainstream networks for detection, segmentation and classification. Then, 30 kinds of industrial defect data sets and performance evaluation indexes are introduced. Finally, the existing problems of defect detection methods are pointed out and the further work is prospected.

Keywords: defect detection; machine vision; machine learning algorithms; deep learning; the data set; performance evaluation index

0 引 言

产品质量与许多因素有关,如性能、功能、外观等,除性能与功能外,许多行业对于产品外观也格外重视,例如半导体、PCB、汽车装配、液晶屏、3C、光伏电池、纺织等行

业,其产品性能、功能与外观唇齿相依,表面缺陷检测作为阻止残次品进入市场的“司门守卫”,对工业生产有着重要的意义。除此之外,表面缺陷检测也适用于道路、铁轨、瓷砖、隧道内壁等设施以及农业、木材的质量检测中,关系着国计民生。

目前,表面缺陷可通过以下方式进行检测:电磁检测

收稿日期: 2021-11-01 Received Date: 2021-11-01

* 基金项目: 国家自然科学基金(61573183)项目资助

法、激光超声检测法、光学检测法、声学检测法、红外检测法、X射线检测法以及机器视觉检测法。其中使用机器视觉的方法进行无损检测,避免了传统人工检测效率低、耗时长、成本高、劳动强度大、人眼的分辨率有限并带有主观意识的问题,因此广泛应用于诸多领域^[1]。本文梳理和分析了大量的检测方法,旨在帮助研究人员可以快速、系统地了解相关技术。考虑至此,文中做了以下安排:第1部分给出缺陷及表面缺陷检测的定义。第2部分概述使用传统图像处理方式进行缺陷检测的核心技术,针对分割和特征提取两个部分进行归纳和对比分析。第3部分叙述基于机器学习的缺陷检测方法。按照聚类、无监督特征学习和概率密度估计3个方面对无监督学习进行概括分析;有监督学习则分成了非概率模型、概率判别模型及生成模型3个大类。第4部分阐述了基于深度学习的缺陷检测方法,主要从检测网络、分类网络、分割网络3个方面进行概括。第5部分梳理了30个工业领域缺陷数据集以及性能评估指标。最后,针对现有的缺陷检测方法的不足做了展望。

目前,相关综述文献情况如下:文献[2-5]主要介绍了一种具体对象(钢材、道路裂缝、钢轨、玻璃)的缺陷检测方法,有一定的局限性。文献[1,6-7]具有通用性,但文献[6]只介绍了传统的机器视觉方法,文献[7]仅对基于深度学习的缺陷检测方法进行总结,文献[1]主要按特征的显示提取与自动提取方向展开。而本文从不同的对象出发,涵盖了基于传统图像处理、基于机器学习和基于深度卷积神经网络的缺陷检测方法,并给出了每篇文献中算法之间性能上的逻辑关系,同时整理了大量的数据集,因此,本文是上述综述文献很好的扩展与深化。

1 缺陷及表面缺陷检测的定义

1) 缺陷的定义

表面缺陷检测中的缺陷,是指物品表面应力感生的结果,不同缺陷伴随着不同的成因,某些缺陷会具有一定的安全性威胁,但某些则不会,只是会影响物体的使用性和寿命等。例如,铸件和板材的表面由于机械加工、工人操作不当等因素造成的表面不平整现象,可能会包含如下缺陷类型,具体如表1所示(<https://wenku.baidu.com/view/0d299929c850ad02de8041ee.html>)。

2) 表面缺陷检测的定义

缺陷的检测,通常是指对物体表面的缺陷进行检测,可采用传统的图像处理算法,也可使用先进的机器学习技术,不管采用哪种方法,其目的都是对工件表面的斑点、裂痕、腐蚀、残缺等进行检测。在对缺陷进行检测时包含3个方面:(1)需要对其进行识别分类,判断是否为缺陷并区分缺陷的类型;(2)定位缺陷,给出其位置信

息;(3)对其进行分割,确定其形状、尺寸。以上3个方面分别实现了缺陷检测时不同的功能,但在实际检测中,并不是3个方面需要同时满足,比如在定位时也会进行分类,在分割时也需要对其进行定位,所以说这3个方面之间是相互渗透的,并没有严格的区分。

表1 铸件和板材的表面缺陷分类

Table 1 Surface defect classification of castings and plates

类型	图示				
凹缺陷					
	沟槽	擦痕	破裂	毛孔	砂眼
凸缺陷					
	缩孔	裂缝	缺损	瓢曲	窝陷
区域或外观缺陷					
	树瘤	刨疤	缝脊	飞边	瓢曲
混合表面缺陷					
	夹杂物	氧化皮	附着物		
区域或外观缺陷					
	划痕	磨蚀	腐蚀	麻点	裂纹
混合表面缺陷					
	斑点	条纹	褪色	斑纹	鳞片
混合表面缺陷					
	折叠	划痕	残余	环形坑	

2 基于传统图像处理方式的缺陷检测方法

在使用传统方法进行处理时,一般步骤为:图像采集、图像预处理(去噪、增强等)、图像分割、特征提取及分类识别。在此部分,主要概括了图像分割和特征提取两个方面,其中图像分割包含阈值分割、边缘检测和区域生长;特征提取则从颜色、纹理、形状3个角度进行概括。至于分类过程则留在机器学习部分再做详细介绍。

2.1 缺陷图像分割

望文生义,分割就是把感兴趣的目标或区域同其他部分区别出来^[8],一般包含阈值分割、边缘检测、区域生长。

1) 阈值分割

对于传统的阈值分割方法,Neogi等^[9]利用基于梯度图像的全局自适应百分比阈值法,解决了带钢表面起泡和水沉积问题。

郭浩然等^[10]使用全局阈值的最大类间方差法结合形态学分割法对高亮回转类零部件表面缺陷图像进行分割,王卓等^[11]提出一种结合混沌鸟群算法的铜板表面凸

起智能识别方法,Cao等^[13]提出一种基于混合梯度阈值分割的混合表面缺陷检测方法,上述方法精度都较高,但对光照条件依赖较强。马云鹏等^[13]则地解决了上述问题,提出一种通用性较强且不易受光照影响的自适应分割算法,且适用于多种类型的金属检测。

文献[14]对钢轨图像进行灰度拉伸和去噪,自适应地给出分割阈值,在包含了208种(其中T-I型126种,T-II型82种)缺陷图像中,T-I型缺陷的召回率为93.75%,T-II型缺陷的召回率为94.26%。

从以上文献可以看出,在阈值分割时,克服光照不均等因素很重要,常可通过自适应的方式选取阈值。

2) 边缘检测

边缘检测可通过计算像素灰度梯度得到感兴趣的轮廓信息。在面对裂纹类缺陷检测时,林丽君等^[15]使用基于图像加权信息熵结合小波模极大值,该方法很好地保留了磁瓦裂纹边缘信息。

为进一步提高边缘检测精度,Shi等^[16]通过增加6个不同方向的模板,以提高Sobel算法在 X 和 Y 方向的灵敏度,且改进的Sobel算法可以提取更精确的特征参数。郭萌等^[17]将Kirsch算子和Canny算子结合起来进行瓷瓦表面缺陷的边缘检测,实现了目标与背景的完全分离。Wang等^[18]提出了一种基于结构化随机森林和小波变换(structured random forests and wavelet transform,

SFW)的钢梁全景裂纹检测法,采用结构化随机森林法和反对称双正交小波半重建法相结合对裂纹进行检测。文献[17]中对SFW、FCN-8s(fully convolutional networks-8s)、SRF(structured random forests)、Canny算子和Roberts算子用于钢梁缺陷检测时的性能进行了比较与分析,Roberts算子的性能较差。

在使用边缘检测进行缺陷检测时,主要关注是否可以精准地定位缺陷,并协调好速度问题,最终实现又快又准的缺陷定位。

3) 区域生长

边缘检测算法可以得到缺陷的一些边缘和轮廓,但是无法具体地描述缺陷内部的像素点信息,此时便需要区域生长法。

文献[19]中,先对道路表面图像进行预处理,再标记车道,然后通过网格单元分析选择裂纹种子,并通过欧几里得最小生成树结构进行连接,据此可以快速有效地选择出裂纹。Zhang等^[20]提出了一种裂纹检测区域生长算法,以ROB的种子为起点,设计专门的规则确定搜索范围,该算法虽然可高效地检测缺陷,但细纹或麻点缺陷存在漏检。

在区域生长法中,种子的选择至关重要,很大程度上可以直接影响到图像分割的精确度,尽管性能可靠、高效,但是对于某些特定的缺陷,如细纹,麻点的识别率不高。方法对比如表2所示。

表2 基于传统图像处理方式的缺陷分割主要方法对比

Table 2 Comparison of main methods of defect segmentation based on traditional image processing

类别	文献	具体方法	贡献	局限性
阈值分割	[9]	基于梯度图像的全局自适应百分比阈值法	自适应度高;分割时可不考虑缺陷的大小和区域问题	-
	[10]	基于全局阈值的最大类间方差法和形态学图像分割法	自适应度高;可去除高光噪声	通用性差
	[11]	结合混沌鸟群分割法	自适应度高;快速	通用性差;易受光照影响
	[12]	混合梯度阈值分割法	有效地减少由特殊的图案区域引起的误检误差	易受光照影响
边缘检测	[15]	图像加权信息熵和小波模极大值相结合法	使裂纹的边缘信息很好地保留,双阈值可以更精确地寻找裂纹的边缘点	-
	[16]	改进的Sobel算法	提高边缘检测精度、提高抗噪性能	-
	[17]	基于结构化随机森林和小波变换法	提高边缘检测精度、克服光照不均匀的问题,减少冗余信息	-
生长区域	[18]	基于扩展和优化的种子裂缝检测法	高效且可靠;准确	-
	[19]	与可信区域结合的裂纹检测区域生长法	高效且可靠;可保证测得的裂缝的完整性	具有一定的遗漏和错误检测结果

2.2 缺陷特征提取

特征提取就是从一组数据开始,为后续的学习提取出一些特征,并且在某些情况下带来更好的可解释性^[21]。本节主要从颜色、纹理、形状3个角度进行概括。

1) 颜色特征

颜色特征鲁棒性较强,对图像的其他属性依赖较小,如方向、尺寸等^[22]。

李军华等^[23]对尺度不变特征变换(scale-invariant feature transform, SIFT)进行改进,然后同颜色矩融合特

征一起作为瓷砖图像的区域特征,实验表明,该算法可很好地对复杂瓷砖进行分类。Zhang 等^[23]提出了一种复杂纹理瓷砖表面缺陷检测方法,利用颜色空间分布方差特征和色斑面积权重特征得到了缺陷的显著性图,但其特征向量主要考虑颜色信息,具有一定的局限性。

在使用颜色特征时,考虑到目前计算机的算力有限会先将彩色图像进行二值化处理以此提高检测效率。

2) 纹理特征

纹理特征很直观,是一种重要的视觉线索^[24]。从统计学的角度出发,Li 等^[25]使用灰度共生矩阵分别对带钢、斜拉桥的斜拉索表面缺陷图像进行纹理特征提取。Li 等^[26]提出了一种基于局部二值模式(local binary pattern, LBP)和局部二值差分激励模式的桦木板裂纹和线状矿物线的纹理描述模型。

另一方面,将图像看作二维信号,Zhou 等^[27]针对玻璃瓶底缺陷检测任务,将感兴趣区域划分为中央面板和

环形纹理两个区域,纹理区域上采用基于小波变换和多尺度滤波算法的缺陷检测策略,在实验中获得了较优的结果。Yu 等^[28]提出了一种由粗到细的模型识别不同尺度下的钢轨缺陷,其中区域级的提取模型受到视觉显著性模型的后发,使用纯相位傅里叶变换定位缺陷区域。

3) 形状特征

形状特征不同于纹理与颜色特征,属于中间层,分为轮廓和区域两类方式。

Nieniewski^[29]设计了一种快速、高效的利用形态运算进行钢轨缺陷检测和形状提取的系统。Bhattacharya 等^[30]组建了一种由交叉细粒度密集模块和并行双注意模块相结合的体系,其中并行双注意模块用于提取在纹理、视角、形状和大小等方面变化的混凝土缺陷。

至此,第 2 部分主要概括了基于传统图像处理方式的缺陷检测方法,分别阐述了缺陷图像分割和缺陷特征提取,并对其进行分析。方法对比见表 3。

表 3 基于传统图像处理方式的缺陷特征提取主要方法对比

Table 3 Comparison of main methods of defect feature extraction based on traditional image processing

类别	文献	具体方法	贡献	局限性
颜色特征	[22]	多特征融合算法	对光照变化不敏感;灰度与彩色特征相结合,加强算法鉴别能力	-
	[23]	颜色空间分布方差特征与色斑面积权重结合法	-	只考虑了颜色信息,因此检测效果随着瓷砖表面颜色和纹理类型的增加而降低
纹理特征	[24]	灰度共生矩阵法	有效提取特征;可用于桥梁斜拉索表面各种类型的缺陷分类	-
	[25]	基于 LBP 和局部二值差分激励模式法	有效提取特征;快速	-
	[27]	小波变换和多尺度滤波结合法	有效提取特征;可提取对比度低、不均匀透光或照度的表面缺陷特征	误检(泛化性低,首次出现的缺陷无法检测)(缺陷对比度不明显时误检);手动调参,耗时
	[28]	纯相位傅里叶变换法	假阳性率低	误检(泛化性低,首次出现的缺陷无法检测)(缺陷对比度不明显时误检)
形状特征	[24]	灰度共生矩阵法	可提取形状特征、灰度特征和纹理特征	-
	[29]	形态运算法	适用于钢轨长而窄的结构	精度和召回率有一定的改进空间
	[30]	交叉细粒度密集模块与并行双注意模块结合法	可与无人机搭配使用,快速准确地检测大面积混凝土结构病害	-

3 基于机器学习的缺陷检测方法

机器学习算法目前已成为一个相当热门的研究课题,它被用来从非常丰富的实验数据集中获得系统的规则,并通过经验来改善系统的性能。下面将从无监督学习方法和有监督学习方法两个方面进行总结。

3.1 无监督学习方法

使用无监督学习训练样本时,计算机会在不借助任

何人工的情况下,根据相似性自行对所有原始样本数据进行分类。本节将通过无监督特征学习、聚类和概率密度估计 3 个方面概括无监督学习在表面缺陷检测中的应用。

1) 无监督特征学习法

无监督特征学习是指从无标签的数据中,挖掘出有效的数据特征或表示,主要方法有主成分分析、稀疏编码法、自编码器等。

(1) PCA(principal components analysis) 可用于降维。它能去除特征数据间的关联性,保留缺陷的必要信息。

姚明海等^[31]使用鲁棒PCA (robust principal component analysis, RPCA) 对太阳能电池片的缺陷进行检测,正确率达到100%。文献[32]中,同样使用了RPCA,并与HCDH (homogeneity cues difference histogram) 相结合来构造发光二极管陶瓷基片缺陷图,其中RPCA被用来检测缺陷像素,HCDH则用于估计模型大小,但该方法对光照因素敏感。

(2) 稀疏编码法(sparse coding, SC)是根据哺乳动物的视觉系统设计出的人工神经网络(artificial neural network, ANN)方法^[33]。

Huang等^[34]提出了一种基于纹理先验和低秩表示的表面缺陷检测法,并将缺陷检测的过程描述成一种新的加权低秩重建模型。周诗洋^[35]提出基于视觉显著性和稀疏表示的钢板表面缺陷图像检测方法,并引入了超像素分割,提高了效率。上述方法均可很好地处理具有复杂背景的缺陷图像。但文献[34]中方法的局限性不容忽视,具体见表4。

Wang等^[36]提出了一种用于表面缺陷识别的实体稀疏追踪(entity sparsity pursuit, ESP)方法,并将缺陷检测作为一个低秩的ESP问题,但在使用超像素分割时不能自适应选择像素个数。同样的,文献[35]中方法也具有同样的局限性。

Zhou等^[37]使用局部块近似自动分割织物疵点,该方法的核心思想是使用最小二乘意义下通过字典学习训练

出的图像块来表示局部纹理特征,不存在特征选择的问题。

(3) 自编码器(auto-encoder, AE)使用表征形式来重建数据。

刘珈彤等^[38]使用二维主成分分析卷积自编码器(two-dimensional principal component analysis-based convolutional autoencoder, PCACAE)用于识别晶圆表面缺陷,该方法使提取的缺陷特征更具有非线性特性,可以获取更有价值的特征信息。

除进行特征学习外,AE还可分割图像。文献[39]中,只使用合格样本进行模型训练,模型采用高斯金字塔结构,利用多尺度卷积降噪AE(convolutional denoising autoencoder, CDAE)重建各层纹理图像块,其多模态策略可以有效地提高方法的鲁棒性和准确性。

Liu等^[40]先分割绝缘子串,针对单个绝缘子构建了一种重构与分类卷积自编码器网络(reconstruction and classification convolutional autoencoder network, RCCAEN)用于进行恢复和识别,RCCAEN保留了目标的空间结构信息,降低了对图像边缘的敏感性。

无监督特征学习可用于降维且鲁棒性好。由于PCA的每个主分量都是原始变量的线性组合,主成分的解释通常带有一定的模糊性,所以可将稀疏性与主成分分析方法结合起来进行缺陷检测。表4总结了主要的无监督特征学习方法的贡献及局限性或期望。

表4 主要的无监督特征学习检测方法对比
Table 4 Comparison of main unsupervised learning detection methods

文献	具体方法	贡献	局限性或期望
[31]	稳健主成分分析法(RPCA)	准确率高	需要一次性输入4张及以上的图像,且不同批次的样本需要重新选取定位点
[34]	纹理先验与低秩表示结合法	使用低秩分解,能够处理具有简单或复杂纹理背景的各种缺陷的缺陷图像	性能依赖于先验图像,缺陷作为前景,当缺陷大于背景时,出错
[35]	双低秩和稀疏分解结合法	使用低秩分解,能够处理具有简单或复杂纹理背景的各种缺陷的缺陷图像	不可自适应决定超像素个数
[36]	实体稀疏追踪(ESP)法	提高鲁棒性;抗噪、泛化性强	不可自适应决定超像素个数
[37]	最小二乘意义下的字典学习法	提高鲁棒性;与传统的基于特征提取的方法相比不存在特征选择的问题	为了确保整个缺陷区域被识别出来,牺牲了召回率
[39]	多尺度卷积去噪自编码器(MSCDAE)	提高鲁棒性;精确率较高,在规则和不规则纹理表面上均有效	效率较低

2) 聚类

顾名思义,聚类是按照一定的规则对样本进行划分,是一种分类问题。

Yang等^[41]对AE进行改进,利用多个不同尺度的FACE特征聚类子网络重构纹理背景,并得到残差图像,将其融合形成一幅缺陷图像,其中对每个FCAE子网都进行特征聚类,以提高编码特征映射的鉴别能力,该方法

的精度为92.0%,处理一幅图像仅需82 ms。

Zhang等^[42]提出了一种基于模糊C均值非线性规划遗传算法(fuzzy c-means algorithm and the nonlinear programming genetic algorithm, FCM-NPGA)和多变量图像分析的苹果缺陷检测方法。其中FCM-NPGA用来分割可疑缺陷图像,后者检测分割后图像中的缺陷,整体检测精度高达98%。

使用聚类进行缺陷检测时,主要关注特征类型,使用传统的特征如位置、尺寸和形状等进行聚类时容易影响聚类精度^[4],为了克服这个问题,可使用复杂的相似度、加入深度估计等进行改进^[43]。

3) 密度估计

密度估计通过样本的分布来估量其与各个分组之间的相似性。主要包含 4 种类型: 深度信念网络、生成对抗网络、变分自编码器、玻尔兹曼机。

(1) 深度信念网络(deep belief network, DBN) 是一种概率有向图模型。DBN 既可用于无监督学习,也可用于有监督学习,此处应用均为无监督学习。

Yu 等^[43] 改进了 DBN,生成一种新的模型 KBDBN (knowledge based deep belief network),该模型将符号和分类规则与深度神经网络(deep neural network, DNN) 相结合,具有良好的特征学习性能。同年,Yu 等对 KBDBN 进行改进,使其可以有效地发现符号规则和分类规则等,在与 SVM、逻辑回归(logistic regression, LR) 和 DNN(如 DBN、堆叠式 AE) 等典型的机器学习模型相比时性能更好。

(2) 生成对抗网络(generative adversarial network, GAN) 是一种通过特殊的训练方式使网络产生的样本服从真实数据分布的框架。

针对数据不平衡问题,Wang 等^[44] 采用自适应平衡 GAN(adaptive balancing generative adversarial network, AdaBalGAN),解决晶圆缺陷类型不平衡问题,此外改进了一种分类生成对抗网络,以高保真度生成模拟晶圆图,并对所有缺陷类别进行分类。文献^[45] 针对磁环微裂纹缺陷改进了 GAN,得到 DEGAN (defect enhancement generative adversarial network) 用于扩充数据集,该模型产

生的缺陷图像其缺陷特征明显且具有多样性,且可以明显地优化 DNN,获得更高的缺陷检测精度。类似的,文献^[46] 提出了一种扩充换向器表面缺陷的 GAN(surface defect-generation adversarial network, SDGAN),实验证明该方法生成的缺陷图像建立的缺陷分类模型对光照不均匀和光线较暗具有更强的鲁棒性。

(3) 变分自编码器(variational auto encoder, VAE) 包含推断网路和生成网络,可将推断网络看作“编码器(encoder)”,生成网络看作“解码器(decoder)”。

针对金属缺陷数据不平衡问题,Yun 等^[47] 将卷积 VAE(convolutional variational autoencoder, CVAE) 与 DNN 相结合,实验证明利用 CCVAE 生成的数据具有很高的泛化性。

(4) 玻尔兹曼机(Boltzmann machine, BM) 是一种随机神经网络,在实际应用中,使用较广泛的是受限玻尔兹曼机(restricted Boltzmann machine, RBM)。

Liu^[48] 利用玻尔兹曼网络的自关联记忆与数据、特征、决策树和神经网络有机地结合起来对试纸缺陷进行智能诊断,建立了玻尔兹曼网络的记忆自关联模型。

使用概率密度估计方法进行表面缺陷检测时,GAN 及 VAE 多用于解决数据不平衡的问题。至于玻尔兹曼机,具有较复杂的结构且效率不高,因此,目前为止并未被大量使用。方法对比见表 5。

广义上讲,有监督学习也可以看作一类特殊的无监督学习。但目前,无监督学习并没有像有监督学习那样获得广泛的成功,其主要原因在于无监督学习缺少有效的客观评价方法,导致很难衡量一个无监督学习方法的好坏,评价时需要下游任务进行验证。

表 5 主要的密度估计检测方法对比

Table 5 Comparison of main density estimation detection methods

类别	文献	方法	贡献	局限性
生成 对抗网络	[44]	自适应平衡生成对抗网络(AdaBalGAN)	精度高、可解决数据不平衡问题	泛化性低
	[45]	缺陷增强生成对抗网络(DEGAN)	扩展数据集; 可显著优化 DNN, 获得更高的缺陷检测精度	-
	[46]	表面缺陷生成对抗网络(SDGAN)	扩展数据集; 对不均匀、光照差的缺陷识别具有较强的鲁棒性	-
差分自编码	[47]	卷积差分自动编码与 DNN 相结合法	扩展数据集; 使用 DNN 训练分类模型, 准确性高	-

3.2 有监督学习

本节将表面缺陷检测中应用的有监督学习分为以下 3 个类别: 非概率模型、概率判别模型、生成模型。

1) 非概率模型

非概率模型面对困难的解决途径比较直接,关键在于最优化问题的求解。在表面缺陷检测中一般包括: 多层感知机、支持向量机、K 近邻。

(1) 多层感知机(multilayer perceptron, MLP) 是一种前馈 ANN,可以处理非线性可分的问题。

Yousefian 等^[49] 针对液晶显示屏制造过程中的玻璃基板表面缺陷,提出一种自动检测的分类方法,采用模拟退火算法对 SVM 分类器和 MLP 分类器进行优化,得到最优调整参数,优化后的 SVM 和 MLP 模型比 CART (classification and regression tree) 模型更准确。Moallem

等^[5]根据每个苹果图像像素的 R 、 G 、 B 、 H 值,使用两层 MLP 神经网络进行缺陷分割,并对 SVM、MLP 和 KNN 分类器的性能进行了比较。文献 [49-50] 的实验结果表明,多种分类器中 SVM 的性能较为优良。

Basavarju 等^[51]提出了一种能较好地分类路面情况(坑洼、深横向裂缝和光滑路面)的缺陷检测方法,设计了一个完全连接的 MLP 网络。文献 [52] 中使用局部二值模式与 MLP 相结合检测固体火箭发动机衬垫的表面缺陷,可识别长度小于 1 mm 的缺陷。

(2) K 近邻(K-nearest neighbor, KNN)是在某一范围内找到与样本相似的目标。

将 KNN 与其他算法相结合来分类。Yildiz 等^[53]利用灰度共生矩阵提取缺陷图像特征,使用 KNN 进行分类;文献 [54] 中利用光度立体成像技术和 KNN 相结合辅助专家对火箭发动机中固体推进剂和隔热层之间的夹层进行表面缺陷检测;葛宵焱^[55]在 SVM 中引入 KNN,提出 KSVM 算法对带钢表面缺陷进行分类。

除了用于分类外,KNN 还可被用来进行降维。陈恺^[56]使用基于 KNN 的序列浮动前向特征选择法进行芯片表面缺陷的特征选择,并将 32 维特征降至 10 维。Chu 等^[57]采用 KNN 和 R 近邻算法相结合对带钢缺陷训练数据集进行剪枝,以提高分类器的准确率和效率。

(3) SVM 是一种经典的二分类的广义线性分类器。

为解决选择核函数的难题,Pasadas 等^[58]提出了多层支持向量机模型,使用 SVM 技术对铝 1050 的裂纹进行分类,其中每一层使用不同的特征和核。

针对核函数的选择问题,还可使用寻优算法优化参数。Li 等^[59]使用粒子群优化 SVM 模型参数,优化后的模型可自动识别桥梁斜拉索纵向裂纹、横向裂纹、表面腐蚀、坑槽缺陷,分类精度达到 96.25%。陈恺^[60]改进了萤火虫算法,并使用其优化了 SVM 模型的惩罚参数及高斯核函数。

此外,为提高分类精度可与其他算法相结合,葛宵焱^[55]设计了一个改进的 SVM-KNN 分类器,提高边界分类精度。Li 等^[59]基于机器视觉和 SVM 提出了一种用于表面缺陷准确识别和分类的无损检测方法。

在使用非概率模型进行表面缺陷检测时,大部分模型都是用来对缺陷进行分类,其中多层感知机除了用于分类,还可用于表征缺陷^[61]、分割^[62]及定位^[61]。对于支持向量机的优化主要在于结合其他方法以提升分类性能。非概率模型中的方法各有优势,其中 SVM 的性能较其他方法性能更佳,例如,在对一些物体(如苹果)的缺陷检测中 MLP 和 KNN 在一些特定环境中无法检测,而 SVM 在大多数情况下都可以成功检测^[63];经遗传算法优化后 SVM 的性能优于 KNN^[64]。

2) 概率判别模型

概率判别模型间接的使用条件概率进行判别。在表面缺陷检测中所采用的模型一般包括:决策树、逻辑回归、最大熵模型、条件随机场。

(1) 决策树(decision tree, DT)直接通过概率进行分类。根据缺陷的形状,岳彪^[65]利用 AdaBoost 多分类器组合方法,以 CART(classification and regression tree)作为弱分类算法设计组合分类器,实现钢轨表面缺陷分类,实验表明该方法能有效识别钢轨表面剥落块、胎面裂纹和鱼鳞裂纹 3 种缺陷。

(2) 逻辑回归是一种线性回归模型。为保证分类器的预测精度,Muhammad 等^[66]结合 LR、随机森林、梯度增强和 ANN 构建了一个集成系统,对晶圆图像特征进行提取。

(3) 最大熵模型(maximum entropy, ME)是按照模型熵最大的原则来选择。

最大熵模型在缺陷检测中常被用于分割,针对钢轨的表面缺陷图像采集时光照不均、对比度低等因素,袁小翠等^[64]根据熵与概率间的关系改进最大熵模型,且对对比度进行了拉伸,分割出包含噪声相对较少的图像。而对于钢轨表面毛刺多,灰度和梯度变化均较剧烈的情况,许文达^[63]提出使用灰度梯度共生矩阵以及最大熵模型提取缺陷边缘,具有较好的鲁棒性。Wu 等^[64]提出了一种灰度拉伸最大熵分割法,该方法着重对基于无人机的轨道图像进行灰度拉伸和去噪,并选择了最优分割阈值。

(4) 条件随机场(conditional random field, CRF)是一种直接建模的条件概率无向图模型。

鉴于 CRF 能充分利用图像特征上下文信息,董志劼^[67]使用 CRF 结合 LR 函数对柔性电路板(flexible printed circuit, FPC)缺陷进行分割,获得了较好的结果。Wang 等^[68]提出了一种网络 DilaSeg-CRF,将卷积神经网络(convolutional neural network, CNN)与 CRF 充分结合,提高下水道缺陷图像的分割精度。

使用决策树对缺陷进行分类时需注意树结构冗余、树剪枝复杂,在处理较大的特征时效率低等问题,可与 KNN、SVM 等结合解决上述问题。条件随机场可以在早期检测到基于传统图像处理方式无法检测到的不清晰的微裂纹。

3) 生成模型

生成模型与上述非概率模型、概率判别模型相比,解决问题的途径相对间接。先求解联合概率,然后利用贝叶斯定理进行判别,在表面缺陷检测中所采用的模型一般包括:朴素贝叶斯、受限玻尔兹曼机、隐马尔可夫模型。

(1) 朴素贝叶斯(naïve Bayes, NB)是在特征条件独立假设下运用贝叶斯定理进行分类的方法。

在面临训练样本不足的问题时,Lin 等^[69]提出了一种基于 NB 的小样本学习算法,通过学习少量具有斑点和无缺陷的织物的样品得到参考值后,使用贝叶斯算法

计算参考值与从待检测织物中提取的特征值之间的后验概率,以此为依据对织物进行分类。

(2) 受限玻尔兹曼机是一种随机生成的 ANN^[7]。除了用于无监督学习,也可用于有监督学习。

与传统网络相比,由 RBM 叠加生成的 DBN,可避免陷入局部最优解^[7],因此,王宪保等^[7]叠加多层 RBM,实现测试样本的缺陷检测。刘梦溪等^[7]构建了一个由 3 层 RBM 组成的 DBN 模型,同年,将稀疏约束引入该模型算法中,使得焊缝缺陷信息能够获取到有效的目标稀疏表示^[7]。

(3) 隐马尔可夫模型(hidden Markov model, HMM)是结构最简单的贝叶斯网。为提高 HMM 精度, Lin 等^[7]将自适应线条检测器、隐马尔可夫随机场模型及其期望最大化算法相结合,对道路裂纹区域可信度和条件连接

进行定量描述,增加了裂纹的完整性和连续性。

综上,从文献的年代可以看出,使用有监督学习的方法是表面缺陷检测近年来的研究热点,还具有很大的发展空间。

4 缺陷检测中的深度神经网络

本节主要总结缺陷检测方法中的 DNN。这种基于端到端的网络,将特征提取、选择和分类融合在一起^[7]。机器视觉对图像的处理主要包含以下 3 个层次:分类、检测、分割。此外, DNN 模型常常具有上百层的结构,参数量巨大,在某些场景中,需要对 DNN 进行轻量化处理。因此本节就按照缺陷检测中的分类、检测、分割和轻量级 DNN 进行总结。表 6 给出了部分网络的特征对比。

表 6 深度神经网络方式对比
Table 6 Deep neural network methods comparison

网络	数据标签类型	检测结果	功能			网络特点
			分类	定位	分割	
VGG、ResNet、GoogleNet 等	类别	缺陷是什么	✓			适用于单一图像中缺陷二分类问题,标注成本低
Faster RCNN、SSD、YOLO 等	矩形框	缺陷在哪里	✓	✓		适用于单一图像中缺陷多分类问题,标注成本较高
FCN、U-Net、Mask RCNN 等	多边形	缺陷怎么样	✓	✓	✓	适用于不同缺陷分类及定位,标注成本高,可直观地表达缺陷的具体外形

4.1 缺陷检测中的分类网络

基于深度学习的表面缺陷检测网络大都使用 VGG、GoogLeNet、ResNet 等作为“Backbone”,其通常被用于特征提取和分类。

1) VGG 结构简洁具有很强的实用性。Perez 等^[7]在对建筑物表面的霉菌、变质和污渍进行检测时,对 VGG-16 进行了微调,使用一个 1×4 的分类器替换最后的 1×1 000 Softmax 层,训练时只更新第 5 块的权值,该网络在缺陷分类及定位方面表现出了较高的可靠性和鲁棒性。Zhou 等^[7]利用随机加权平均(stochastic weight averaging, SWA)优化器和 W-Softmax 损失函数对 VGG 网络进行改进,用于生成一种青梅缺陷检测的网络模型。Guan 等^[7]根据 ZFNet 中的反卷积和反池化模块,构建了模型 DeVGG19 用来提取钢表面缺陷特征图。

2) GoogLeNet 采用的是模块化结构。薛勇等^[7]使用 GoogLeNet 迁移模型对苹果进行缺陷检测,在迁移中取代网络的最后 3 层,在层次图中添加全连接层、Softmax 层和分类输出层,具有泛化能力。肖旺等^[7]提出了一种 GoogLeNet-Mini 网络,将 3 层卷积层变为 1 层,并将原有 Inception 模块减少为 6 块,增加了卷积核数,使该模块更适合鸭蛋缺陷检测。

3) ResNet 是 VGG-16 的延申,增添了残差单元,解决了 DNN 退化问题。Mary 等^[8]对 ResNet-50 进行改进,在 Conv1 和 Conv3 中增加 1 个下采样,以保留更精确的空间信息。Xie 等^[8]融合了 ResNet-50、Densenet-121 和 VGG-16 以提高胡萝卜的缺陷检测效果。路雅诺等^[8]在 ResNet 上增加了注意力模块,并优化了模型参数,生成了一种适合带钢表面缺陷分类任务的网络结构 A-ResNet50 和 A-ResNet101。

分类网络应用广泛,还有一些网络结构未列出,例如 AlexNet, DenseNet, 以上这些方法各有利弊,可根据实际需求进行选择。

4.2 缺陷检测中的检测网络

所谓检测网络是指,依据网络中是否含有候选框,将网络分为单阶段和双阶段。单阶段网络中输入图像、输出备选框与分类是在一体化完成的;而双阶段网络中一半选择备选框,一半对备选框进行判断,两者之间进行级联。所以依据不同的思路,本节分为以下两类:双阶段网络、单阶段网络。

1) 双阶段网络

Faster R-CNN 是双阶段网络中的代表,检测速度较前两代有很大的提升。

Tao 等^[83]发现,使用单层 Faster R-CNN 直接检测航拍图像中的绝缘子缺陷所得到的精确度与召回率并不是很理想。便将两个 Faster R-CNN 级联起来,第 1 层用于绝缘子定位,第 2 层用于绝缘子中的缺陷定位,该方法能够适用于各种复杂背景下的绝缘子缺陷检测。文献 [84] 使用了 Position-Sensitive ROI-Pooling 取代了 ROI-Pooling,同时在特征提取时更改了 Anchor 的比例以便更好地适应裂纹缺陷较长的特点。Zhong 等^[85]在检测高速铁路悬链线开口销缺陷时更是直接使用了 54 个不同比例的 Anchor,并将底层特征图下采样,与上采样后的高层特征图进行级联,形成新的特征图。Ding 等^[86]通过 K-means 设计 Anchor 比例,并在 Faster RCNN 中引入特征金字塔网络(feature pyramid networks, FPN),以加强底层特征融合。陈海泳等^[87]在 FPN 中添加了自下而上的路径聚合形成一种新的网络 PA-FPN (path aggregation feature pyramid network),将 PA-FPN 引入到 Faster R-CNN 中,以此提升了模型对多尺度裂纹缺陷特征的表达能力。文献 [88] 在对铝材进行缺陷检测时,也使用 K-means 确定 Anchor 大小,在 Faster R-CNN 中引入 FPN,用 ROI-align 代替 ROI-Pooling,增强定位效果。

除此之外,Faster R-CNN 还被用于其他材料的缺陷检测上,例如:轮毂^[89]、隧道^[90]、光伏电池^[91]等。

2) 单阶段网络

单阶段网络主要包含 SSD (single shot multiBox detector) 和 YOLO (you only look once) 两种^[9]。两者都是只用一个网络同时进行感兴趣的区域检测以及输出类别。

Zheng 等^[92]针对 YOLOv3 对大中型目标不敏感、小缺陷漏检、误检等问题,进行改进,提出了一种新的轴承盖缺陷检测技术。首先使用 BNA-Net 取代传统的 Darknet-53,减少参数;接着提出了注意预测子网、缺陷定位子网,其中缺陷定位子网进一步处理注意预测子网的全局特征,该方法主要用于大中型目标的检测,保持了较快的速度也提高了检测精度。Duan 等^[93]引入双密度卷积层结构,增加模型预测尺度,对 YOLOv3 进行改进,得到更好的铸件缺陷检测网络模型。

Li 等^[94]在保证检测精度的前提下,优化 SSD 结构得到 MobileNet-SSD,该方法可应用于集装箱上灌装线密封面的破损、凹陷、毛刺、磨损等典型缺陷的检测。Liu 等^[95]在对悬链线支撑部件缺陷进行精确定位时,也使用了 MobileNet-SSD,修改了 SSD 网络输出层的深度,优化了网络结构。Ramalingam 等^[96]提出了一种改进的 MobileNet-SSD 框架,用于检测飞机表面由裂缝、腐蚀等引起的溢油等污渍。李善军等^[97]则采用 ResNet18 优化 SSD 模型,可有效地应用于实时检测分类柑橘是否有损伤、病变。

单阶段网络与双阶段网络各有利弊,如果追求检测速度,则基于单阶段的应用较多,若对检测精度有要求,则使用两阶段的网络。现阶段,研究人员已经开始关注将两者结合起来的检测网络,例如,RefineDet 融合了 RPN 网络、FPN 算法和 SSD 算法,既提高了检测精度,也保持了较快的检测速度,很好地做到了扬长避短。

4.3 缺陷检测中的分割网络

分割网络通常包括语义分割和实例分割,使用其对缺陷进行检测时,主要是区分缺陷与非缺陷区域。语义分割与实例分割最大的不同在于,实例分割在语义分割的基础上还可对缺陷进行定位、分类,并得到缺陷具体的几何形状。

1) 语义分割

常见的语义分割网络有: FCN、SegNet、DeepLab 系列、U-Net。

(1) FCN 是最初提出的语义分割网络,可以融合多层信息。王森等^[98]提出了一种 Crack FCN 模型,Dung 等^[99]提出了一种基于 VGG-16 的 FCN 网络,两种改进都实现了对裂纹的有效分割,提高了检测精度。He 等^[100]提出了一种混合的 FCN 网络来检测木材缺陷的位置并分类,识别精度高达 99.14%,实时性强。Qiu 等^[101]提出了一种 3 阶段 FCN 框架,即分割任务、检测任务和抠图任务的组合,将此框架应用于工业环境中逐像素的表面缺陷分割,精度达 99% 以上,但对于结构缺陷的检测较弱于纹理缺陷。刘思言等^[102]提出 R-FCN (region-FCN) 航拍电力线巡检图像分割方法,并利用在线难例挖掘、样本优化、Soft-NMS (soft-non maximum suppression) 等方法进行优化,有效提高了准确率。徐奇伟等^[103]使用 R-FCN 结合 OpenCV 对电网的高压引线接头缺陷进行检测,检测精度提升了 8.43%。

(2) SegNet 在 FCN 的基础上增添了解码器,是一个基本由卷积层组成的语义分割网络。Roberts 等^[104]将 SegNet 与 Focal-Loss 函数相结合——FL-SegNet,利用隧道损伤图像进行验证,该法能够较好地区分大尺度剥落损伤和小尺度裂纹,即使缺陷存在大小差异或重叠,也能同时识别多个损伤。Zou 等^[105]在 SegNet 的编解码器体系结构上构建 DeepCrack 网络,并在相同规模下对编码器网络和解码器网络产生的卷积特征进行成对融合以实现裂缝检测。

(3) DeepLab 系列解决了 FCN 分割结果较为粗糙的问题,更加注重了细节的学习。蒋美仙等^[106]使用 DeepLabV3 对焊缝缺陷进行检测,取得了较好的结果。

(4) U-Net 是一种具有编码-解码结构的 U 型网络。

刘畅等^[107]针对磁瓦缺陷使用空洞卷积替换 U-Net 中部分卷积层和池化层。文喆皓等^[108]在对磁瓦缺陷进行分割时使用了整合型 U-Net 以增强模型分割能力。

Liu 等^[10]在现有 U-Net 和 ResNet 的基础上,提出了 U-ResNet 架构,用于 TFT-LCD 制造过程中微米级导电粒子检测。Miao^[11]等在 U-ResNet 的基础上引入了挤压-激励(SE)块,提高了隧道衬砌缺陷的检测精度。

使用语义分割进行缺陷检测时,是将缺陷检测看作二分类问题,当要处理多种类型的缺陷时,就需要使用实例分割了。

2) 实例分割

实例分割可以在上述语义分割的基础上,区分出属于同类的不同实例。

Mask R-CNN 是实例分割中最常见的,最具有代表性的网络。Xiao 等^[11]改进 Mask R-CNN 提出了一种图像金字塔卷积神经网络(image pyramid convolution neural network, IPCNN),提取用于缺陷检测的金字塔特征,在货运列车漏油缺陷检测中精度和召回率较好。不过目前 Mask R-CNN 最常见的应用则是直接对缺陷进行分割,例如,利用 Mask R-CNN 对焊缝^[12]、路面裂缝、皮革表面缺陷进行分割等。

分割网络相比于分类和检测网络,在缺陷信息特征提取上有一定的优势,但同样也需要大量的数据集做支撑。

综上,基于传统图像处理的分割方法与基于深度学习的分割方法各有特点,如表 7 所示,与传统图像处理的缺陷分割方式相比,基于深度学习的缺陷分割方式还是技高一筹,能够取得更为理想的分割效果且具有较强的泛化能力。

表 7 缺陷分割方式对比

Table 7 Comparison of defect segmentation techniques

对比	基于传统图像处理的缺陷分割方式	基于深度学习的缺陷分割方式
方法	阈值分割、边缘检测(Sobel、Canny、Roberts 等) 区域生长	语义分割: FCN、SegNet、DeepLab 系列、U-Net 等 实例分割: Mask R-CNN
本质	像素划分(人工调参)	网络学习(自主学习特征)
分割条件	图像质量优良,对比度高	大量数据集
效果	差	较好
耗时	人工调参,少	模型训练,根据网络而定
泛化性	差	较强

4.4 缺陷检测中的轻量级深度神经网络

轻量级网络在保证精度的前提下,从提高速度和减小体积两个方面对 DNN 进行优化,参数少,可在算力较低的移动设备上部署。其在缺陷检测中的应用还不是很多,下文将总结 3 种轻量级网络在缺陷检测中的应用。

1) MobileNet 系列其核心采用了深度可分离卷积,包含 3 个类型 MobileNetV1、MobileNetV2、MobileNetV3。文献[95-97]中均使用 MobileNet 优化 SSD 结构。徐镏等^[13]使用 MobileNet 代替 YOLOv3 中的 Darknet-53,减少参数量,用于钢板表面缺陷检测,实时性得到很大提升。

2) SqueezeNet 结合了 GoogLeNet 与 VGG 的思想,提出了一种 Fire 模块并堆叠使用。徐文龙^[14]提出了 Fusion 模块代替 SqueezeNet 中的 Fire 模块,用于分级红枣品质。Yang 等^[15]根据 CNN 和迁移学习提出了一种模型尺寸小、计算复杂度低的预训练 SqueezeNet 模型,用于检测动力电池安全排气孔的焊接缺陷。

3) EfficientNet 结合了 MobileNetV2 与 SENet,可同时对网络的宽度、深度和图像尺寸进行调整。

Masood 等^[16]提出 EfficientNet-B3 C ResNext-101 网络对皮革缺陷进行检测,且在 AUC 和 F1 分数方面,优势显著。周天宇等^[17]提出 YOLO-EfficientNet 用于载波芯片缺陷检测,实时性高。Guo 等^[18]使用 EfficientNet 为骨干网,针对手机外观小尺寸缺陷,提出一种特征金字塔模块 GCSA-BiFPN,最后利用盒类预测网络实现有效的缺陷检测。

除上述网络外,还有许多轻量级网络没有列举出来,如分类网络 ShuffleNet 等,检测网络 Light-Head R-CNN、ThunderNet、YOLO-Fastest、CSPNet 等,分割网络 BiSeNet、DFANet 等,将轻量级网络与缺陷检测相结合也是未来的一个发展方向。

5 数据集及评价指标

5.1 数据集

数据是人工智能发展的要素之一,深度学习算法的广泛发展,就是源于数据集的大量出现。本节搜集整理了 30 个数据集,涵盖多个工业领域,具体如表 8 所示。“百度飞浆”网站(<https://aistudio.baidu.com/aistudio/index>)中也给出了大量的开源数据集,例如手扶电梯梯级、绝缘子自爆、苹果缺陷、焊接件、PCB、带钢、电力线等,页面如图 1 所示。



图 1 百度飞浆页面示意图

Fig. 1 Baidu AI studio page diagram

表 8 工业表面缺陷检测常用数据集
Table 8 Datasets commonly used in industrial surface defect detection

应用对象	数据集	是否带有分割标签	缺陷类型	下载链接
电子产品	KolektorSDD ^[11]	✓	裂纹	https://www.vicos.si/Downloads/KolektorSDD
PCB 板	DeepPCB	✓	开路、短路、孔洞、杂散、伪铜	https://github.com/tangsanli5201/DeepPCB
金属表面	GC10-DET ^[12]	—	麻点、刮伤、凹痕	https://github.com/lvxioming2019/GC10-DET-Metallic-Surface-Defect-Datasets
钢轨	RSDDs ^[12]	✓	孔洞、磨损、裂纹	http://icn.bjtu.edu.cn/Visint/resources/RSDDs.aspx
	NEU ^[12]	✓	斑块、划痕、破裂、点腐蚀、内含物	http://faculty.neu.edu.cn/yunhyan/NEU_surface_defect_database.html
钢材	Micro ^[12]	✓	点状、凹痕	http://faculty.neu.edu.cn/yunhyan/SCACM.html
	Oil pollution ^[12]	✓	油污干扰下划痕、擦痕	http://faculty.neu.edu.cn/yunhyan/SLSM.html
	Kaggle	✓	斑块、划痕、裂缝	https://www.kaggle.com/c/severstal-steel-defect-detection/data
	Crack Dataset ^[12]	✓		https://drive.google.com/drive/folders/1cplcUBmgHfD82YQTwNn1dssK2ZxRpx
混凝土产品	CrackForest ^[12]	✓	裂缝	https://github.com/cuilimeng/CrackForest-dataset
	Crack500 ^[12]	✓		https://github.com/fyangneil/pavement-crack-detection
	CODEBRIM ^[12]	✓	裂缝、剥落、钢筋外露、风化、腐蚀	https://paperswithcode.com/dataset/codebrim
桥梁	DCD ^[12]	—		http://perso.lcpc.fr/sylvie.chambon/FISSURES/Datasets.html
	GAPs ^[13]	✓	裂缝	https://www.tu-ilmenau.de/neurob/data-sets-code/german-asphalt-pavement-distress-dataset-gaps
	Bridge Crack ^[13]	✓		https://github.com/maweifei/Bridge_Crack_Image_Data
磁瓦	MTD ^[13]	✓	气孔、磨损、裂纹	https://github.com/abin24/Magnetic-tile-defect-datasets
木材	Wood defect ^[13]	—	节孔、节子、裂纹	http://www.ee.oulu.fi/~olli/Projects/Lumber.Grading.html
铸件	GDXray ^[13]	—	孔洞、划痕、焊缝	https://domingomery.ing.puc.cl/material/gdxray/
	KTH-TIPS	—		http://www.nada.kth.se/cvap/databases/kth-tips/download.html
纹理图像	Textures ^[13]	—	纹理缺陷	https://github.com/abin24/Textures-Dataset
	Kylberg	—		http://www.cb.uu.se/~gustaf/texture/
	DAGM2007	✓		https://hci.iwr.uni-heidelberg.de/node/3616
织物	AITEX ^[13]	—	污渍、毛球、折痕、纬裂	https://www.aitex.es/afid/
电纺材料	NanoTWICE ^[13]	—	污点	http://www.mi.imati.cnr.it/ettore/NanoTWICE/
电缆、胶囊、坚果、螺母、牙刷、拉链等	MVTec AD ^[13]	✓	纹理缺陷	https://www.mvtec.com/company/research/datasets/mvtec-ad/
光学元件	WSCRATCH512 ^[13]	✓	划痕	https://github.com/love6tao/ScratchDetection
太阳能板	Elpv-dataset ^[8]	✓	纹理缺陷	https://github.com/zae-bayern/elpv-dataset
电力线路	PLD-UAV	✓	城景、山景	https://github.com/SnorkerHeng/PLD-UAV
绝缘体	CPLID	✓	缺失、污渍	https://github.com/InsulatorData/InsulatorDataSet
铝型材		—	擦花、漆泡、脏点	https://tianchi.aliyun.com/competition/entrance/231682/information
瓷砖	TianChi	—	孔洞、污渍、缺角	https://tianchi.aliyun.com/competition/entrance/531846/information
布匹		—	孔洞、毛球、污渍	https://tianchi.aliyun.com/competition/entrance/231666/information

5.2 性能评估指标

当模型训练好时,需要对其性能进行评估。目前,基于机器视觉的缺陷检测方法,继续沿用通用目标分类、检测和分割中的评估指标。如何选择合适的评估指标作为模型评判的依据是个问题,毕竟没有一种指标可以直接判断出最佳模型,因此,不可以偏概全,草率得出结论,可根据实际需求对衡量方式进行取舍。

下文从二分类与多分类角度给出一些常见的评估指标。

1) 二分类问题

当缺陷类型只有一种或只需要识别出物体是否含有缺陷时,可以将缺陷检测看作二分类问题,即所关注的某类缺陷或含有缺陷为正样本(positive),其余皆为负样本(negative)。混淆矩阵作为一个重要的指标,常用于模型评估中,其中 TP(true positive)、FN(false negative)、FP(false positive)、TN(true negative)之间关系如表 9 所示。

以混淆矩阵中的指标作为基准,通过组合可得到更多适应不同需求的评估指标。

召回率(recall),也称真阳性率(true positive rate, TPR),灵敏度,查全率,针对实际为缺陷的样本,表示缺陷被正确预测的比率,公式为:

$$Recall(TPR) = \frac{TP}{TP + FN} \quad (1)$$

表 9 混淆矩阵

Table 9 Confusion matrix

实际类别	预测类别	
	缺陷	非缺陷
缺陷	TP	FN
非缺陷	FP	TN

精确度(precision)也称精度,查准率,阳性预测值(positive predictive value, PPV),针对预测为缺陷的样本,体现预测为缺陷的样本中有多少是正确的,公式为:

$$Precision(PPV) = \frac{TP}{TP + FP} \quad (2)$$

精确度反映误检情况,两者成反比,即反映的是缺陷检测时,有多少缺陷被正确检测出来;召回率则表示有多少缺陷被检测出来了。虽然从公式看 TPR 与 PPV 之间没有必然联系,其实两者间相互制约,譬如追求精确度时,模型会再三斟酌,不轻易判断出正样本,导致一些缺陷被判为负样本,召回率降低;而看重召回率时,模型倾向于将样本判为正样本,这必然会出现一些误判情况,导致精确度变低。因此实际中需对两者进行权衡,这就引出了 F-Score 这个指标。

Dice 相似系数也称 F1 分数(F1-Score),描述的是召回率与精确度之间的关系,公式为:

$$Dice = \frac{2TP}{2TP + FP + FN} \quad (3)$$

或

$$F1 = \frac{2 \times PPV \times TPR}{PPV + TPR} \quad (4)$$

F1 是一个特殊值,其更一般的表示为 F-Score 或 F-Measure,计算过程如式(5)所示。

$$F-Score = (\alpha^2 + 1) \frac{PPV \times TPR}{\alpha^2 \cdot PPV + TPR} \quad (5)$$

其中, α 为对 TPR 与 PPV 的加权调和。召回率与精确度一样重要时,令 $\alpha = 1$,即为 F1;当认为精确度重要时,令 $\alpha < 1$;反之认为召回率更为重要一些时,则令 $\alpha > 1$ 。

特效度(specificity)也称 TNR(true negative rate),表示负样本被准确预测,公式为:

$$Specificity(TNR) = \frac{TN}{TN + FP} \quad (6)$$

特效度与误判率成反比,在检测中特效度低,则说明部分样本原本是负样本被模型误判成了缺陷。

假阳性率(false positive rate, FPR),又称误检率,虚警率,含义为背景被判为缺陷的数量占有负样本的比率,公式为:

$$FPR = \frac{FP}{TN + FP} \quad (7)$$

假阴性率(false negative rate, FNR),又称漏检率,漏警率,表示本身是缺陷被误判为负样本时在所有缺陷样本中所占的比率,公式为:

$$FNR = \frac{FN}{TN + TP} \quad (8)$$

准确率(accuracy, ACC)顾名思义,其就是机器判断正确的比率,公式为:

$$ACC = \frac{TP + TN}{TP + FP + TN + FN} \quad (9)$$

一般情况下,ACC 越高模型越好,但样本不平衡时,ACC 不能很好地评估模型性能,例如,当有缺陷的样本占总样本的 85%,模型将所有样本判为缺陷,ACC 就等于 85%,这并不科学。因此针对这种情况,可以使用平衡准确率(balanced accuracy, BA),公式为:

$$BA = \frac{TPR + TNR}{2} \quad (10)$$

马修斯相关系数(Matthews correlation coefficient, MCC)综合了 TPR、TNR、FPR、FNR,是一种比较全面的指标,可以评估样本不平衡下的缺陷检测模型性能,公式如式(1)所示。

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \quad (11)$$

mAP(mean average precision) 是指各个类别预测正确的样本数占总样本数的平均值,越大越好。mAP 中的“AP(average precision)”是指平均精确度,即缺陷与负样本的精确度求和后除以总样本数 n ,公式如下:

$$AP = \frac{\sum PPV}{n} \quad (12)$$

则 mAP 计算方法如式(13)所示,式中分母为 2 因为是二分类问题,当遇到多分类问题时可将 2 换为类别数加一,因为需要加上背景。

$$mAP = \frac{\sum AP}{2} \quad (13)$$

像素准确率(pixel accuracy, PA),常用于语义分割判断分对的像素数量占总像素数量的比率,公式为:

$$PA = \frac{\sum_{i=0}^k p_{ii}}{\sum_{i=0}^k \sum_{j=0}^k p_{ij}} \quad (14)$$

平均像素准确率(mean pixel accuracy, mPA),是对 PA 求平均,公式为:

$$mPA = \frac{1}{k+1} \sum_{i=0}^k \frac{p_{ii}}{\sum_{j=0}^k p_{ij}} \quad (15)$$

平均交并比(mean intersection over union, mIoU) 表示标注的准确性,公式为:

$$mIoU = \frac{1}{k+1} \sum_{i=0}^k \frac{p_{ii}}{\sum_{j=0}^k p_{ij} + \sum_{j=0}^k p_{ji} - p_{ii}} \quad (16)$$

PA、mPA、mIoU 都为判断语义分割准确率的指标,其中 k 为缺陷总类别数, $k+1$ 为加上背景, p_{ij} 为第 i 类像素被判为 j 类的数量, p_{ji} 、 p_{ii} 的含义以此类推。

2) 多分类问题

当缺陷有多种类型时,就涉及到多分类的评估指标了。以 3 分类为例,每个类别的 TP_i 、 FN_i 、 FP_i 可根据表 10 所示的混淆矩阵计算出来。

表 10 混淆矩阵
Table 10 Confusion matrix

实际类别	预测类别		
	缺陷 1	缺陷 2	非缺陷
缺陷 1	$T_1 P_1$	$F_1 P_2$	$F_1 P_3$
缺陷 2	$F_2 P_1$	$T_2 P_1$	$F_2 P_3$
非缺陷	$F_3 P_1$	$F_3 P_2$	$T_3 P_3$

则有:

$$TP_i = T_i P_i \quad (17)$$

$$FN_i = \sum_{j=1, j \neq i}^3 F_j P_{ij} \quad (18)$$

$$FP_i = \sum_{j=1, j \neq i}^3 F_j P_j \quad (19)$$

多分类问题中的评估指标定义与二分类问题相同,计算过程略有不同,具体如表 11 所示。

表 11 评估指标
Table 11 Evaluation criterion

名称	公式
准确率	$ACC = \frac{\sum_{i=1}^3 FP_i}{\sum_{i=1}^3 TP_i + FP_i}$
错误率	$error\ rate = \frac{\sum_{i=1}^3 FP_i}{\sum_{i=1}^3 TP_i + FP_i}$
召回率	$recall(R_i) = \frac{TP_i}{TP_i + FN_i}$
精确度	$precision(p_i) = \frac{TP_i}{TP_i + FP_i}$
Dice 相似系数	$Dice = \frac{2 \times \frac{1}{3} \sum_{i=1}^3 P_i \times \frac{1}{3} \sum_{i=1}^3 R_i}{\frac{1}{3} \sum_{i=1}^3 P_i + \frac{1}{3} \sum_{i=1}^3 R_i}$

以上公式是以 3 分类为例,推广到更一般的情况时,将公式中“3”换为“ $k+1$ ”,其中 k 代表缺陷类别,包含背景则为 $k+1$ 。

6 主要问题和展望

近年来,随着精密制造的发展,某些工业元件的缺陷越来越难以检测,因此许多学者对物体表面缺陷的机器视觉检测方法进行了研究,并取得了很多的成果。虽然有些方法的检测准确率可以达到 95% 以上,但在实际生产过程中仍有诸多问题等待挑战。

1) 特征提取问题。(1) 特征维数与特征描述准确性间的矛盾。虽然可以采用基于颜色、纹理和形状的特征提取方法进行描述,但其准确性往往难以满足要求。基于数学方式的特征提取往往维数过高。寻找适合降维的特征提取方法需要进一步研究;(2) 目前针对机器视觉的公开数据集大多是二维的,不包含空间特征,如何提取三维特征信息值得思考。

2) 数据集有限问题。机器学习方法的性能优势在于学习能力强,但是学习的过程是需要大量数据做支撑的。

(1) 样本采集问题,缺陷样本很难采集,在工业生产中常会遇到缺陷样本不到一百张的窘态,而且缺陷类型不完整;(2) 标记工作量大,样本的标注过程存在主观因素,人工成本较大,耗时耗力;(3) 少量样本扩增问题,近年来 GAN 主要应用于虚拟图像生成,性能强大,生成的图像效果逼真,有一定的可行性,如何更好地将 GAN 与表面缺陷检测方法相融合用于生成大量的样本数据,也是一个值得思考的问题。

3) 实时性问题。在工业生产中,实时性是反映检测效率的关键。(1) 使用高分辨率设备采集图像时,图像分辨率高,利于检测精度,但计算时,网络参数量巨大,计算机算力有限,如何平衡实时性与检测精度,值得注意。(2) 大部分基于机器学习尤其是深度学习的网络有时具有几百层的结构,需要在大型的服务器上运行,速度慢。虽然研究人员已提出了很多轻量级网络,其中大部分都可以兼顾检测速度和精度的问题,但在缺陷检测领域的应用较少,有很大的发展空间。

4) 小目标问题。微小缺陷尺寸小、分辨率低、特征不明显、不易被发现,但其会对物体的使用和寿命有影响,有时更会带来安全隐患,使用基于传统的图像处理的方式很难检测出理想的结果,而通过深度学习的方式对其进行检测时需要专门的微小缺陷数据集和精度更高的算法,但现有的算法大多针对通用目标,且图像分辨率有限,小目标检测一直存在技术瓶颈。目前针对微小缺陷检测的方法,主要关注的是如何对微小缺陷特征进行提取,实现有效的分割。

5) 复杂背景问题。复杂背景下的缺陷检测是本领域的一个热门话题。(1) 成像问题。在复杂的工业环境中,成像条件有限,光照、采集设备、生产工艺等都会对样本采集产生影响,虽在某些高精密加工中为提高采集图像的质量,使用高分辨率采集设备,却牺牲了实时性。(2) 特征提取问题,有的缺陷图像本身背景图案就复杂多变(如织物),对缺陷检测技术的适应性要求更高。使用传统的图像处理方式解决复杂背景下缺陷特征提取时,多采用形态学、阈值分割等方法,但当缺陷与背景灰度级相似时,容易产生错误;或采用滤波器、小波变换等方式,排除背景干扰,增强疑似的缺陷区域,但在处理小目标缺陷时准确度较低。机器学习的方法可以很好地解决传统图像处理方式遗留的问题,可采用特征融合、语义补偿等增强特征信息,但随着网络的加深,实时性难以保证。

总体而言,目前的检测率良莠不齐,许多分类器仍然存在计算时间长、实时性差的问题;基于机器学习的分类器明显优于传统的分类器,但机器学习的网络在训练时假设各种缺陷样本是均匀分布的,这样容易导致一些不

常见的缺陷识别率过低;此外,样本的标注过程人工成本较大,因此无监督神经网络分类器具有很大的优势。

综上所述,检测技术还需要进一步改进。未来的研究可以从以下几个方面展开:

1) 传统的基于图像处理的检测过程先进行特征提取,然后分类并输出结果,使用人工设计特征,过程繁琐。DNN 将特征提取和分类结合在一起,通过学习训练集自动提取特征,简单且精度高,但是它需要大量的训练图像,并对训练集有特定的需求。而 DNN 在图像处理领域的优异性能使其在未来必将得到进一步的发展。样本小的 CNN 将是未来视觉检测领域的研究重点。

2) 对于数据的选择,不应局限于从普通相机中采集到的图像样本,对于一些特殊材料,比如玻璃,可以添加一些激光超声特征,墙体裂纹可以添加一些声学特征,此外触觉、嗅觉及红外信息也可以进行辅助检测,通过多信息融合来提高精度,这也是机器视觉缺陷检测未来的一个发展方向。

3) 在深度学习的模型训练好后,如果更换新的数据集,模型便需要重新训练,耗时耗力且影响精度,如何使模型具有记忆力,可在先前训练好的模型的基础上持续学习值得思考。

4) 对于相近领域或不同领域,某些材料的缺陷类型是相同的,可否通过迁移学习减轻一些网络对数据标注的依赖性,是未来一个重要的研究方向,基于不同领域的缺陷数据学习是一种趋势,各种不同的应用场景之间进行大融合可提升网络性能。

5) 虽然在机器学习中如何得到缺陷图像更丰富的语义特征发人思考,但是许多缺陷检测系统在工业应用时,更关注图像的底层特征,基于传统的图像处理方式则恰恰是针对底层特征进行处理的,如何取其精华将两者相结合也是未来重要的研究课题。

6) 目前的神经网络是一种基于人脑不完全认知的简化网络,这些网络不具有思考能力,虽然可以实现缺陷图像的分割、定位、分类,对图像进行描述及生成,但都是通过不同的网络完成的,因此如何利用生物视觉(尤其是仿人视觉)的一些先验知识同时达到各种目的令人深思。

7 结 论

通过总结及对比分析近几年表面缺陷检测领域的研究成果,在机器学习没有大量应用之前,大多数视觉软件也都包含有定位、测量、检测等功能。使用传统的方法进行缺陷检测时,大多是依靠样本的缺陷特征,从颜色、纹理、形状等角度进行判断,最终形成一定的规则进行缺陷检测。这些方法也有很好的应用,但大多数是应用在较

简单的检测中,如果被测对象更换,那所有的检测规则及算法就需要重新设计,也就是说通用性较低。随着机器学习发展得越来越火热,很多通过传统算法无法或很难直接量化的缺陷特征,研究人员发现使用机器学习便可解决。当然机器学习技术仍有很多弊端需要完善,如对数据集要求高,且数据集的收集成本较高,研究人员也在进一步研究希望通过自动网络结构设计,自动数据标注等进行解决。通过以上总结和分析,期望可以提供有价值的参考。

参考文献

- [1] 苏虎, 张家斌, 张博豪, 等. 基于视觉感知的表面缺陷检测综述 [J]. 计算机集成制造系统, 2021, 27(4): 1-31.
SU H, ZHANG J B, ZHANG B H, et al. Review of research on the inspection of surface defect based on visual perception [J]. Computer Integrated Manufacturing Systems, 2021, 27(4): 1-31.
- [2] SUN X H, GU J N, TANG S, et al. Research progress of visual inspection technology of steel products-A review [J]. Applied Sciences, 2018, 8(11): 2195-2220.
- [3] CAO W, LIU Q, HE Z. Review of pavement defect detection methods [J]. IEEE Access, 2020, 8: 14531-14544.
- [4] 唐伟. 声学缺陷检测中关键技术的研究 [D]. 天津: 天津大学, 2018.
TANG W. Research on key technologies of acoustic defect detection [D]. Tianjin: Tianjin University, 2018.
- [5] NEOGI N, MOHANTA D K, DUTTA P K. Defect detection of steel surfaces with global adaptive percentile thresholding of gradient image [J]. Journal of The Institution of Engineers, 2017, 98(6): 557-565.
- [6] 汤勃, 孔健益, 伍世虔. 机器视觉表面缺陷检测综述 [J]. 中国图象图形学报, 2017, 22(12): 1640-1663.
TANG B, KONG J Y, WU S H Q. Review of surface defect detection based on machine vision [J]. Journal of Image and Graphics, 2017, 22(12): 1640-1663.
- [7] 陶显, 侯伟, 徐德. 基于深度学习的表面缺陷检测方法综述 [J]. 自动化学报, 2021, 47(5): 1017-1034.
TAO X, HOU W, XU D. A survey of surface defect detection methods based on deep learning [J]. Acta Automatica Sinica, 2021, 47(5): 1017-1034.
- [8] 冈萨雷斯. 数字图像处理 [M]. 北京: 电子工业出版社, 2003.
RAFEAL C G. Digital image processing [M]. Beijing: Publishing House of Electronics Industry, 2003.
- [9] NEOGI N, DUSMANTA K M, PRANAB K D. Defect detection of steel surfaces with global adaptive percentile thresholding of gradient image [J]. Journal of The Institution of Engineers (India): Series B, 2017, 98(6): 557-565.
- [10] 郭皓然, 邵伟, 周阿维, 等. 全局阈值自适应的高亮金属表面缺陷识别新方法 [J]. 仪器仪表学报, 2017, 38(11): 2797-2804.
GUO H R, SHAO W, ZHOU A W, et al. Novel defect recognition method based on adaptive global threshold for highlight metal surface [J]. Chinese Journal of Scientific Instrument, 2017, 38(11): 2797-2804.
- [11] 王卓, 张长胜, 李伟, 等. 结合混沌鸟群算法的阴极铜板表面缺陷检测 [J]. 中国图象图形学报, 2020, 25(4): 697-707.
WANG ZH, ZHANG CH SH, LI W, et al. Cathodic copper plate surface defect detection based on bird swarm algorithm with chaotic theory [J]. Journal of Image and Graphics, 2020, 25(4): 697-707.
- [12] CAO G Z, SONG B R, YE P P, et al. Large-complex-surface defect detection by hybrid gradient threshold segmentation and image registration [J]. IEEE Access, 2018, 6(1): 36235-36246.
- [13] 马云鹏, 李庆武, 何飞佳, 等. 金属表面缺陷自适应分割算法 [J]. 仪器仪表学报, 2017, 38(1): 245-251.
MA Y P, LI Q W, HE F J, et al. Adaptive segmentation algorithm for metal surface defects [J]. Chinese Journal of Scientific Instrument, 2017, 38(1): 245-251.
- [14] WANG Y P, QIN Y, WANG Z P, et al. A UAV-based visual inspection method for rail surface defects [J]. Applied Sciences, 2018, 8(7): 1028-1047.
- [15] 林丽君, 殷鹰, 何明格, 等. 基于小波模极大值的磁瓦裂纹缺陷边缘检测算法 [J]. 电子科技大学学报, 2015, 44(2): 283-288.
LIN L J, YIN Y, HE M G, et al. Edge detection algorithm of magnetic tile crack based on wavelet modulus maxima [J]. Journal of University of Electronic Science and Technology of China, 2015, 44(2): 283-288.
- [16] SHI T, KONG J Y, WANG X D, et al. Improved sobel algorithm for defect detection of rail surfaces with enhanced efficiency and accuracy [J]. Journal of Central South University, 2016, 23(11): 2867-2875.

- [17] 郭萌, 胡辽林, 赵江涛. 基于 Kirsch 和 Canny 算子的陶瓷碗表面缺陷检测方法 [J]. 光学学报, 2016, 36(9): 27-33.
GUO M, HU L L, ZHAO J T. Surface defect detection method of ceramic bowl based on kirsch and canny operator [J]. Acta Optica Sinica, 2016, 36(9): 27-33.
- [18] WANG S, LIU X, YANG T, et al. Panoramic crack detection for steel beam based on structured random forests [J]. IEEE Access, 2018, 6: 16432-16444.
- [19] ZHOU Y, WANG F, MEGHANATHAN N, et al. Seed-based approach for automated crack detection from pavement images [J]. Transportation Research Record Journal of the Transportation Research Board, 2016, 2589(1): 162-171.
- [20] ZHANG D, LI Q, CHEN Y, et al. An efficient and reliable coarse-to-fine approach for asphalt pavement crack detection [J]. Image and Vision Computing, 2016, 57: 130-146.
- [21] 周志华. 机器学习 [M]. 北京: 清华大学出版社, 2020.
ZHOU ZH H. Machine learning [M]. Beijing: Tsinghua University Press, 2020.
- [22] 李军华, 权小霞, 汪宇玲. 多特征融合的瓷砖表面缺陷检测算法研究 [J]. 计算机工程与应用, 2020, 56(15): 191-198.
LI J H, QUAN X X, WANG Y L. Research on surface defect detection algorithm based on multi-feature fusion [J]. Computer Engineering and Applications, 2020, 56(15): 191-198.
- [23] ZHANG H, PENG L, YU S, et al. Detection of surface defects in ceramic tiles with complex texture [J]. IEEE Access, 2021, 9: 92788-92797.
- [24] 刘丽, 匡纲要. 图像纹理特征提取方法综述 [J]. 中国图象图形学报, 2009, 14(4): 622-635.
LIU L, KUANG G Y. Overview of image textural feature extraction methods [J]. Journal of Image and Graphics, 2009, 14(4): 622-635.
- [25] LI X, GUO Y, LI Y. Particle swarm optimization-based svm for classification of cable surface defects of the cable-stayed bridges [J]. IEEE Access, 2020, 8: 44485-44492.
- [26] LI S, LI D, YUAN W. Wood defect classification based on two-dimensional histogram constituted by lbp and local binary differential excitation pattern [J]. IEEE Access, 2019, 7: 145829-145842.
- [27] ZHOU X, WANG Y, ZHU Q, et al. A surface defect detection framework for glass bottle bottom using visual attention model and wavelet transform [J]. IEEE Transactions on Industrial Informatics, 2020, 16(4): 2189-2201.
- [28] YU H, LI Q. A coarse-to-fine model for rail surface defect detection [J]. IEEE Transactions on Instrumentation and Measurement, 2019, 68(3): 656-666.
- [29] NIENIEWSKI M. Morphological detection and extraction of rail surface defects [J]. IEEE Transactions on Instrumentation and Measurement, 2020, 69(9): 6870-6879.
- [30] BHATTACHARYA G, MANDAL B, PUHAN N B. Interleaved deep artifacts-aware attention mechanism for concrete structural defect classification [J]. IEEE Transactions on Image Processing, 2021, 30: 6957-6969.
- [31] 姚明海, 李洁, 王宪保. 基于 RPCA 的太阳能电池片表面缺陷检测 [J]. 计算机学报, 2013, 36(9): 1943-1952.
YAO M H, LI J, WANG X B. Solar cells surface defects detection using RPCA method [J]. Chinese Journal of Computers, 2013, 36(9): 1943-1952.
- [32] LIU H W, CHEN S H, PENG D B. Defect inspection of patterned thin-film ceramic light-emitting diode substrate using a fast randomized principal component analysis [J]. IEEE Transactions on Semiconductor Manufacturing, 2016, 29(3): 248-256.
- [33] 李蕙, 王江, 刘宝弟, 等. 基于快速字典学习和特征稀有性的显著目标提取 [J]. 吉林大学学报: 工学版, 2016, 46(5): 1710-1717.
LI H, WANG J, LIU B D, et al. Extraction algorithm of salient object by fast dictionary learning and feature rarity [J]. Journal of Jilin University (Engineering and Technology Edition), 2016, 46(5): 1710-1717.
- [34] HUANG P Q Z, ZHANG H, ZENG X R, et al. Automatic visual defect detection using texture prior and low-rank representation [J]. IEEE Access, 2018, 6: 37965-37976.
- [35] 周诗洋. 基于视觉显著性和稀疏表示的钢板表面缺陷图像检测方法研究 [D]. 武汉: 华中科技大学, 2017.
ZHAOU SH Y. Research on detecting method for image of surface defect of steel sheet based on visual saliency and sparse representation [D]. Wuhan: Huazhong

- University of Science and Technology, 2017.
- [36] WANG J Z, LI Q Y, GAN J, et al. Surface defect detection via entity sparsity pursuit with intrinsic priors [J]. IEEE Transactions on Industrial Informatics, 2020, 16(1): 141–150.
- [37] ZHOU J, WANG J A, GAO W, et al. Unsupervised fabric defect segmentation using local texture feature [J]. Journal of Textile Research, 2016, 37(12): 43–48.
- [38] 刘珈彤, 余建波. 晶圆表面缺陷模式识别的二维主成分分析卷积自编码器 [J]. 计算机辅助设计与图形学学报, 2020, 32(3): 425–436.
- LIU J T, YU J B. Recognition of wafer defect based on two-dimensional principal component analysis based convolutional autoencoder [J]. Journal of Computer-Aided Design & Computer Graphics, 2020, 32(3): 425–436.
- [39] MEI A, YANG H, YIN Z. An unsupervised-learning-based approach for automated defect inspection on textured surfaces [J]. IEEE Transactions on Instrumentation and Measurement, 2018, 67(6): 1266–1277.
- [40] LIU W, LIU Z, WANG H, et al. An automated defect detection approach for catenary rod insulator textured surfaces using unsupervised learning [J]. IEEE Transactions on Instrumentation and Measurement, 2020, 69(10): 8411–8423.
- [41] YANG H, CHEN Y, SONG K, et al. Multiscale feature-clustering-based fully convolutional autoencoder for fast accurate visual inspection of texture surface defects [J]. IEEE Transactions on Automation Science and Engineering, 2019, 16(3): 1450–1467.
- [42] ZHANG W, HU J, ZHOU G, et al. Detection of apple defects based on the FCM-NPGA and a multivariate image analysis [J]. IEEE Access, 2020, 8: 38833–38845.
- [43] YU J, LIU G. Knowledge-based deep belief network for machining roughness prediction and knowledge discovery [J]. Computers in Industry, 2020, 121: 103262.
- [44] WANG J, YANG Z, ZHANG J, et al. AdaBalGAN: An improved generative adversarial network with imbalanced learning for wafer defective pattern recognition [J]. IEEE Transactions on Semiconductor Manufacturing, 2019, 32(3): 310–319.
- [45] LIN S, HE Z, SUN L. Defect enhancement generative adversarial network for enlarging data set of microcrack defect [J]. IEEE Access, 2019, 7: 48413–48423.
- [46] NIU S, LI B, WANG X, et al. Defect image sample generation with gan for improving defect recognition [J]. IEEE Transactions on Automation Science and Engineering, 2020, 17(3): 1611–1622.
- [47] YUN J P, SHIN W C, KOO G, et al. Automated defect inspection system for metal surfaces based on deep learning and data augmentation [J]. Journal of Manufacturing Systems, 2020, 55: 317–324.
- [48] LIU Z J. The defect diagnosis of sheet drawing on self-associate with memory of boltzmann network [J]. Advanced Materials Research, 2014, 988: 540–543.
- [49] YOUSEFIAN-JAZI A, RYU J H, OON S, et al. Decision support in machine vision system for monitoring of tft-led glass substrates manufacturing [J]. Journal of Process Control, 2014, 24(6): 1015–1023.
- [50] MOALLEM P, SERAJODDIN A, POURGHASSEM H. Computer vision-based apple grading for golden delicious apples based on surface features [J]. Information Processing in Agriculture, 2016, 4(1): 33–40.
- [51] BASAVARAJU A, DU J, ZHOU F, et al. A machine learning approach to road surface anomaly assessment using smartphone sensors [J]. IEEE Sensors Journal, 2020, 20(5): 2635–2647.
- [52] HOFFMANN L, BIZARRIA F, BIZARRIZA J. Detection of liner surface defects in solid rocket motors using multilayer perceptron neural networks [J]. Polymer Testing, 2020, 88(45): 106559.
- [53] YILDIZ K, BULDU A, DEMETGUL M. A thermal-based defect classification method in textile fabrics with K-nearest neighbor algorithm [J]. Journal of Industrial Textiles, 2014, 45(5): 780–795.
- [54] HOFFMANN L F S, BIZARRIA F, BIZARRIA B, et al. Applied algorithm in the liner inspection of solid rocket motors [J]. Optics & Lasers in Engineering, 2018, 102: 143–153.
- [55] 葛宵焱. 基于支持向量机的带钢表面缺陷识别问题研究 [D]. 石家庄: 河北科技大学, 2016.
- GE X Y. The research on steel strip surface defect based on support vector machine [D]. Shijiazhuang: Hebei University of Science and Technology, 2016.
- [56] 陈恺. 集成电路芯片表面缺陷视觉检测关键技术研究 [D]. 南京: 东南大学, 2016.
- CHEN K. Research on key techniques for integrated

- circuit chip surface defects vision detection [D]. Nanjing: Southeast University, 2016.
- [57] CHU M, WANG A, GONG R, et al. Strip steel surface defect recognition based on novel feature extraction and enhanced least squares twin support vector machine [J]. ISIJ International, 2014, 54(7): 1638–1645.
- [58] PASADAS D J, BASKARAN P, RAMOS H G, et al. Detection and classification of defects using ECT and multi-level SVM model [J]. IEEE Sensors Journal, 2020, 20(5): 2329–2338.
- [59] LI X, GUO Y, LI Y. Particle swarm optimization-based SVM for classification of cable surface defects of the cable-stayed bridges [J]. IEEE Access, 2020, 8: 44485–44492.
- [60] HERIANSYAH R, NAHHAS A, et al. Quantitative defect characterization for passive thermography application [J]. Research in Nondestructive Evaluation, 2015, 26(3): 133–153.
- [61] LAROCCA C, FARIAS C, SIMAS F, et al. Wall thinning characterization of composite reinforced steel tube using frequency-domain PEC technique and neural networks [J]. Journal of Nondestructive Evaluation, 2018, 37(3): 44–52.
- [62] 岳彪. 图像式轨检系统中轨面缺陷的识别方法研究 [D]. 兰州: 兰州交通大学, 2018.
- YUE B. Research on identification methods of rail surface defects in image-based rail inspection system [D]. Lanzhou: Lanzhou Jiaotong University, 2018.
- [63] SAQLAIN M, JARGALSAIKHAN B, LEE J Y. A voting ensemble classifier for wafer map defect patterns identification in semiconductor manufacturing [J]. IEEE Transactions on Semiconductor Manufacturing, 2019, 32(2): 171–182.
- [64] 袁小翠, 吴禄慎, 陈华伟. 钢轨表面缺陷检测的图像预处理改进算法 [J]. 计算机辅助设计与图形学学报, 2014, 5: 800–805.
- YUAN X C, WU L SH, CHEN H W. Improved image preprocessing algorithm for rail surface defects detection [J]. Journal of Computer-Aided Design & Computer Graphics, 2014, 5: 800–805.
- [65] 许文达. 基于机器视觉的钢轨表面缺陷识别研究 [D]. 北京: 北京交通大学, 2015.
- XU W D. Study on defect recognition for rail surface based on machine vision [D]. Beijing: Beijing Jiaotong University. 2015.
- [66] WU Y, QIN Y, WANG Z, et al. A UAV-based visual inspection method for rail surface defects [J]. Applied Sciences, 2018, 8(7): 1028–1048.
- [67] 董志勤. 基于图像特征的FPC机器视觉检查关键技术研究 [D]. 广州: 华南理工大学, 2016.
- DONG ZH J. Study of key technologies on image features based machine vision inspection for FPC [D]. Guangzhou: South China University of Technology, 2016.
- [68] WANG M, CHENG J C P. A unified convolutional neural network integrated with conditional random field for pipe defect segmentation [J]. Computer-Aided Civil and Infrastructure Engineering, 2020, 35(2): 162–177.
- [69] LIN S, HE Z, ZHANG H. Fabric surface detection using small sample learning based on naive bayes [C]. Tenth International Conference on Digital Image Processing (ICDIP 2018), Sydney, Australia, 2018.
- [70] 王宪保, 李洁, 姚明海, 等. 基于深度学习的太阳能电池片表面缺陷检测方法 [J]. 模式识别与人工智能, 2014, 27(6): 517–523.
- WANG X B, LI J, YAO M H, et al. Solar cells surface defects detection based on deep learning [J]. Pattern Recognition and Artificial Intelligence, 2014, 27(6): 517–523.
- [71] 刘梦溪, 巨永锋, 高炜欣, 等. 焊缝缺陷图像分类识别的深度置信网络研究 [J]. 测控技术, 2018, 37(8): 5–15.
- LIU M X, JU Y F, GAO W X, et al. Research on deep belief network for images classification and recognition of weld defects [J]. Measurement & Control Technology, 2018, 37(8): 5–15.
- [72] 刘梦溪, 王征, 宋久旭, 等. 基于稀疏深度置信网络的图像分类识别研究 [J]. 微电子学与计算机, 2018, 35(9): 59–63.
- LIU M X, WANG ZH, SONG J X, et al. Weld defects images classification and recognition based on sparse deep belief network [J]. Microelectronics & Computer, 2018, 35(9): 59–63.
- [73] LIN M, ZHOU R, YAN Q, et al. Automatic pavement crack detection using Hmrf-EM algorithm [C]. 2019 International Conference on Computer, Information and Telecommunication Systems (CITS), Beijing, China, 2019: 256–260.

- [74] 赵永强, 饶元, 董世鹏, 等. 深度学习目标检测方法综述 [J]. 中国图象图形学报, 2020, 25(4): 5-30.
ZHAO Y Q, RAO Y, DONG SH P, et al. Survey on deep learning object detection [J]. Journal of Image and Graphics, 2020, 25(4): 5-30.
- [75] PEREZ H, TAH J, MOSAVI A. Deep learning for detecting building defects using convolutional neural networks [J]. Sensors, 2019, 19(16): 3356.
- [76] ZHOU H, ZHUANG Z, LIU Y, et al. Defect classification of green plums based on deep learning [J]. Sensors, 2020, 20(23): 6993.
- [77] GUAN S, LEI M, LU H. A steel surface defect recognition algorithm based on improved deep learning network model using feature visualization and quality evaluation [J]. IEEE Access, 2020, 8: 49885-49895.
- [78] 薛勇, 王立扬, 张瑜, 等. 基于 GoogLeNet 深度迁移学习的苹果缺陷检测方法 [J]. 农业机械学报, 2020, 51(7): 30-35.
XUE Y, WANG L Y, ZHANG Y, et al. Defect detection method of apples based on googlenet deep transfer learning [J]. Transactions of the Chinese Society for Agricultural Machinery, 2020, 51(7): 30-35.
- [79] 肖旺, 杨煜俊, 申启访, 等. 基于改进的 GoogLeNet 鸭蛋表面缺陷检测 [J]. 食品与机械, 2021, 37(6): 162-167.
XIAO W, YANG Y J, SHEN Q F, et al. Duck egg surface defect detection based on improved googLeNet [J]. Food & Machinery, 2021, 37(6): 162-167.
- [80] MAYR M, HOFFMANN M, MAIER A, et al. Weakly supervised segmentation of cracks on solar cells using normalized lp norm [C]. 2019 IEEE International Conference on Image Processing (ICIP), Taipei, 2019: 1885-1889.
- [81] XIE W, WEI S, ZHENG Z, et al. Recognition of defective carrots based on deep learning and transfer learning [J]. Food and Bioprocess Technology, 2021: 1-14.
- [82] 陆雅诺, 陈炳才, 陈德刚, 等. 一种基于注意力模型的带钢表面缺陷识别算法 [J]. 激光与光电子学进展, 2021, 58(14): 1-14.
LU Y N, CHEN B C, CHEN D G, et al. Recognition algorithm of strip steel surface defects based on attention model [J]. Laser & Optoelectronics Progress, 2021, 58(14): 1-14.
- [83] TAO X, ZHANG D, WANG Z, et al. Detection of power line insulator defects using aerial images analyzed with convolutional neural networks [J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2020, 50(4): 1486-1498.
- [84] XUE Y, LI Y. A fast detection method via region-based fully convolutional neural networks for shield tunnel lining defects [J]. Computer-Aided Civil and Infrastructure Engineering, 2018, 33(8): 638-654.
- [85] ZHONG J, LIU Z, HAN Z, et al. A CNN-based defect inspection method for catenary split pins in high-speed railway [J]. IEEE Transactions on Instrumentation and Measurement, 2018, 68(8): 2849-2860.
- [86] DING R, DAI L, LI G, et al. TDD-Net: A tiny defect detection network for printed circuit boards [J]. CAAI Transactions on Intelligence Technology, 2019, 4(2): 110-116.
- [87] 陈海永, 赵鹏, 闫皓炜. 融合注意力的多尺度 Faster RCNN 的裂纹检测 [J]. 光电工程, 2021, 48(1): 64-74.
CHEN H Y, ZHAO P, YAN H W. Crack detection based on multi-scale faster RCNN with attention [J]. Opto-Electronic Engineering, 2021, 48(1): 64-74.
- [88] 向宽, 李松松, 栾明慧, 等. 基于改进 Faster RCNN 的铝材表面缺陷检测方法 [J]. 仪器仪表学报, 2021, 42(1): 191-198.
XIANG K, LI S S, LUAN M H, et al. Aluminum product surface defect detection method based on improved Faster RCNN [J]. Chinese Journal of Scientific Instrument, 2021, 42(1): 191-198.
- [89] SUN X, GU J, HUANG R, et al. Surface defects recognition of wheel hub based on improved faster R-CNN [J]. Electronics, 2019, 8(5): 481-496.
- [90] CHENG J C P, WANG M. Automated detection of sewer pipe defects in closed-circuit television images using deep learning techniques [J]. Automation in Construction, 2018, 95: 155-171.
- [91] 伊欣同, 单亚峰. 基于改进 Faster R-CNN 的光伏电池内部缺陷检测 [J]. 电子测量与仪器学报, 2021, 35(1): 40-47.
YI X T, SHAN Y F. Photovoltaic cell internal defect detection based on improved faster R-CNN [J]. Journal of Electronic Measurement and Instrumentation, 2021, 35(1): 40-47.

- [92] ZHENG Z, ZHAO J, LI Y. Research on detecting bearing-cover defects based on improved YOLOv3 [J]. IEEE Access, 2021, 9: 10304-10315.
- [93] DUAN L, YANG K, LANG R. Research on automatic recognition of casting defects based on deep learning [J]. IEEE Access, 2021, 9: 12209-12216.
- [94] LI Y, HUANG H, XIE Q, et al. Research on a surface defect detection algorithm based on mobilenet-SSD [J]. Applied Sciences, 2018, 8(9): 1678-1695.
- [95] LIU Z, LIU K, ZHONG J, et al. A high-precision positioning approach for catenary support components with multiscale difference [J]. IEEE Transactions on Instrumentation and Measurement, 2020, 69(3): 700-711.
- [96] RAMALINGAM B, MANUEL V H, ELARA M R, et al. Visual inspection of the aircraft surface using a teleoperated reconfigurable climbing robot and enhanced deep learning technique [J]. International Journal of Aerospace Engineering, 2019(1): 1-14.
- [97] 李善军, 胡定一, 高淑敏, 等. 基于改进 SSD 的柑橘实时分类检测 [J]. 农业工程学报, 2019, 35(24): 307-313.
- LI SH J, HU D Y, GAO SH M, et al. Real-time classification and detection of citrus based on improved SSD [J]. Transactions of the Chinese Society of Agricultural Engineering, 2019, 35(24): 307-313.
- [98] 王森, 伍星, 张印辉, 等. 基于深度学习的全卷积网络图像裂纹检测 [J]. 计算机辅助设计与图形学学报, 2018, 30(5): 859-867.
- WANG S, WU X, ZHANG Y H, et al. Image crack detection with fully convolutional network based on deep learning [J]. Journal of Computer-Aided Design & Computer Graphics, 2018, 30(5): 859-867.
- [99] DUNG C V, ANH L D. Autonomous concrete crack detection using deep fully convolutional neural network [J]. Automation in Construction, 2018, 99: 52-58.
- [100] HE T, LIU Y, XU C, et al. A fully convolutional neural network for wood defect location and identification [J]. IEEE Access, 2019, 7: 123453-123462.
- [101] QIU L T, WU X, YU Z Y. A high-efficiency fully convolutional networks for pixel-wise surface defect detection [J]. IEEE Access, 2019, 7: 15884-15893.
- [102] 刘思言, 王博, 高昆仑, 等. 基于 R-FCN 的航拍巡检图像目标检测方法 [J]. 电力系统自动化, 2019, 43(13): 162-168.
- LIU S Y, WANG B, GAO K L, et al. Object detection method for aerial inspection image based on region-based fully convolutional network [J]. Automation of Electric Power Systems, 2019, 43(13): 162-168.
- [103] 徐奇伟, 黄宏, 张雪锋, 等. 基于改进区域全卷积网络的高压引线接头红外图像特征分析的在线故障诊断方法 [J]. 电工技术学报, 2021, 36(7): 1380-1388.
- XU Q W, HUANG H, ZHANG X F, et al. Online fault diagnosis method for infrared image feature analysis of high-voltage lead connectors based on improved R-FCN [J]. Transactions of China Electrotechnical Society, 2021, 36(7): 1380-1388.
- [104] ROBERTS G, HAILE S Y, SAINJU R, et al. Deep learning for semantic segmentation of defects in advanced STEM images of steels [J]. Scientific Reports, 2019, 9(1): 1-12.
- [105] ZOU Q, ZHANG Z, LI Q, et al. DeepCrack: Learning hierarchical convolutional features for crack detection [J]. IEEE Transactions on Image Processing, 2019, 28(3): 1498-1512.
- [106] 蒋美仙, 郑碧佩, 郑佳美, 等. 基于 Deeplab-V3 的焊缝缺陷检测应用研究 [J]. 浙江工业大学学报, 2021, 49(4): 416-422.
- JIANG M X, ZHENG B P, ZHENG J M, et al. Study on weld detection method based on Deplad-V3 [J]. Journal of Zhejiang University of Technology, 2021, 49(4): 416-422.
- [107] 刘畅, 张剑, 林建平. 基于神经网络的磁瓦表面缺陷检测识别 [J]. 表面技术, 2019, 48(8): 330-339.
- LIU CH, ZHANG J, LIN J P. Detection and identification of surface defects of magnetic tile based on neural network [J]. Surface Technology, 2019, 48(8): 330-339.
- [108] 文喆皓, 周敏. 基于深度学习的磁瓦表面孔洞和裂纹缺陷识别 [J]. 兵器材料科学与工程, 2020, 43(6): 106-112.
- WEN ZH H, ZHOU M. Recognition of blowholes and cracks on surface of magnetic tile based on deep learning [J]. Ordnance Material Science and Engineering, 2020, 43(6): 106-112.
- [109] LIU E, CHEN K, XIANG Z, et al. Conductive particle detection via deep learning for ACF bonding in TFT-

- LCD manufacturing [J]. Journal of Intelligent Manufacturing, 2020, 31(4): 1037–1049.
- [10] MIAO X, WANG J, WANG Z, et al. Automatic recognition of highway tunnel defects based on an improved U-Net model [J]. IEEE Sensors Journal, 2019, 19(23): 11413–11423.
- [11] XIAO L, WU B, HU Y. Surface defect detection using image pyramid [J]. IEEE Sensors Journal, 2020, 20(13): 7181–7188.
- [12] TAO X, LEI P, YU T, et al. Inspection of defects in weld using differential array ECT probe and deep learning algorithm [J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1–9.
- [13] 徐镔, 朱洪锦, 范洪辉, 等. 改进的 YOLOv3 网络在钢板表面缺陷检测研究 [J]. 计算机工程与应用, 2020, 56(16): 256–272.
- XU Q, ZHU H J, FAN H H, et al. Study on detection of steel plate surface defects by improved YOLOv3 network [J]. CEA, 2020, 56(16): 265–272.
- [14] 徐文龙. 基于卷积神经网络的红枣外观品质分级方法研究 [D]. 天津: 天津工业大学, 2019.
- XU W L. Study on appearance quality grading method of jujube based on convolutional neural network [D]. Tianjin: Tianjin Polytechnic University, 2019.
- [15] YANG Y, YANG R, PAN L, et al. A lightweight deep learning algorithm for inspection of laser welding defects on safety vent of power battery [J]. Computers in Industry, 2020, 123(4): 103306.
- [16] MASOOD A, TARIQ M K, SYES D N, et al. Ensemble convolutional neural networks with knowledge transfer for leather defect classification in industrial settings [J]. IEEE Access, 2020, 8: 198600–198614.
- [17] 周天宇, 朱启兵, 黄敏, 等. 基于轻量级卷积神经网络的载波芯片缺陷检测 [J/OL]. 计算机工程与应用, <http://kns.cnki.net/kcms/detail/11.2127.TP.20210726.0938.016.html>.
- ZHOU T Y, ZHU Q B, HUANG M, et al. Defect detection of chip on carrier based on lightweight convolutional neural network [J/OL]. Computer Engineering and Applications, <http://kns.cnki.net/kcms/detail/11.2127.TP.20210726.0938.016.html>.
- [18] GUO T, ZHANG L, DING R, et al. EDD-Net: An efficient defect detection network [C]. 2020 25th International Conference on Pattern Recognition (ICPR), Milan Italy, 2021: 8899–8905.
- [19] TABERNIK D, SELA S, SKVARC J, et al. Segmentation-based deep-learning approach for surface-defect detection [J]. Journal of Intelligent Manufacturing, 2020, 31(3): 759–776.
- [20] LYU X, DUAN F, JIANG J, et al. Deep metallic surface defect detection: The new benchmark and detection network [J]. Sensors, 2020, 20(6): 1562.
- [21] GAN J, LI Q, WANG J, et al. A hierarchical extractor-based visual rail surface inspection system [J]. IEEE Sensors Journal, 2017, 17(23): 7935–7944.
- [22] DONG H, SONG K, HE J, et al. PGA-Net: Pyramid feature fusion and global context attention network for automated surface defect detection [J]. IEEE Transactions on Industrial Informatics, 2020, 16(12): 7448–7458.
- [23] SONG K, YAN Y H. Micro surface defect detection method for silicon steel strip based on saliency convex active contour model, mathematical problems in engineering [J]. Mathematical Problems in Engineering, 2013, 17: 1–13.
- [24] SONG K C, SHAO-PENG H U, YAN Y H, et al. Surface defect detection method using saliency linear scanning morphology for silicon steel strip under oil pollution interference [J]. ISIJ International, 2014, 54(11): 2598–2607.
- [25] YANG X, LI H, YU Y, et al. Automatic pixel-level crack detection and measurement using fully convolutional network [J]. Computer-Aided Civil and Infrastructure Engineering, 2018, 33(12): 1090–1109.
- [26] SHI Y, CUI L, QI Z, et al. Automatic road crack detection using random structured forests [J]. IEEE Transactions on Intelligent Transportation Systems, 2016, 17(12): 3434–3445.
- [27] YANG F, ZHANG L, YU S, et al. Feature pyramid and hierarchical boosting network for pavement crack detection [J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 21(4): 1525–1535.
- [28] MUNDT M, MAJUMDER S, MURALI S, et al. Meta-learning convolutional neural architectures for multi-target concrete defect classification with the concrete defect bridge image dataset [C]. IEEE, Conference on Computer Vision and Pattern Recognition (CVPR), 2019: 11188–11197.

- [129] EISENBACH M, STRICKER R, SEICHTER D, et al. How to get pavement distress detection ready for deep learning? A systematic approach [C]. 2017 International Joint Conference on Neural Networks (IJCNN), Anchorage, Alaska, USA, 2017.
- [130] 李良福, 马卫飞, 李丽, 等. 基于深度学习的桥梁裂缝检测算法研究 [J]. 自动化学报. 2019, 45(9): 1727-1742.
- LI L F, MA W F, LI L, et al. Research on detection algorithm for bridge cracks based on deep learning [J]. Acta Automatica Sinica, 2019, 45(9): 1727-1742.
- [131] HUANG Y, QIU C, YUAN K. Surface defect saliency of magnetic tile [J]. Visual Computer, 2020, 36(1): 85-96.
- [132] SILVEN I, NISKANEN M, KAUPPINEN H. Wood inspection with non-supervised clustering [J]. Machine Vision and Applications, 2003, 13(5-6): 275-285.
- [133] FERGUSON M, AK R, LEE Y T, et al. Automatic localization of casting defects with convolutional neural networks [C]. IEEE International Conference on Big Data, Boston, 2017: 1726-1735.
- [134] HUANG Y, QIU C, WANG X, et al. A compact convolutional neural network for surface defect inspection [J]. Sensors, 2020, 209(7): 1974-1993.
- [135] SILVESTRE-BLANES J, ALBERO T, MIRALLES I, et al. A public fabric database for defect detection methods and results [J]. Autex Research Journal, 2019, 4: 363-374.
- [136] CARRERA D, MANGANINI F, BORACCHI G, et al. Defect detection in SEM images of nanofibrous materials [J]. IEEE Transactions on Industrial Informatics, 2016, 13(2): 551-561.
- [137] BERGMANN P, FAUSER M, SATTLEGGGER D, et al. MVTec AD-a comprehensive real-world dataset for

unsupervised anomaly detection [J]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 9592-9600.

- [138] TAO X, ZHANG D, HOU W, et al. Industrial weak scratches inspection based on multifeature fusion network [J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-14.

作者简介



赵朗月, 2015 年于陕西理工大学获得学士学位, 现为南京航空航天大学电子信息工程学院信号与信息处理专业博士研究生, 主要研究方向为图像处理与机器视觉检测。

E-mail: zlangyue@nuaa.edu.cn

Zhao Langyue received her B.Sc. degree from Shaanxi University of Technology in 2015. She is currently pursuing her Ph.D. degree in Department of Signal and Information Processing, College of Electronic and Information Engineering at Nanjing University of Aeronautics and Astronautics. Her research interests include image processing and machine vision detection.



吴一全(通信作者), 1998 年于南京航空航天大学获得博士学位, 现为南京航空航天大学教授、博士生导师, 主要研究方向为视觉检测与图像测量、遥感图像处理与理解、红外目标检测与识别、视频处理与智能分析等。

E-mail: nuaaimage@163.com

Wu Yiquan (Corresponding author) received his Ph.D. degree from Nanjing University of Aeronautics and Astronautics in 1998. He is currently a professor and a Ph.D. advisor at Nanjing University of Aeronautics and Astronautics. His main research interests include visual detection and image measurement, remote sensing image processing and understanding, infrared target detection and recognition, video processing and intelligent analysis, et al.