

分类号： TP391.41

单位代码： 10110

学 号： S1902047

中 北 大 学
硕 士 学 位 论 文
(学 硕)

基于机器视觉的轴承表面缺陷
检测系统研究

硕士研究生 _____ 赵明

指导教师 _____ 于大国教授、肖江剑研究员

学科专业 _____ 机械工程

图书分类号 TP

密级 非密

UDC ^{注 1} 391.41

硕 士 学 位 论 文

基于机器视觉的轴承表面缺陷检测系统研究

赵明

指导教师（姓名、职称） 于大国教授、肖江剑研究员(校外)

申请学位级别 工学硕士

专业名称 机械工程

论文提交日期 2022 年 5 月 27 日

论文答辩日期 2022 年 5 月 28 日

学位授予日期 年 月 日

论文评阅人 钱钧（副教授）、贾超（副教授）

答辩委员会主席 周进节

2022 年 6 月 1 日

注 1：注明《国际十进分类法 UDC》的分类

基于机器视觉的轴承表面缺陷检测系统研究

摘要

轴承作为一种机械设备中大量使用的基础零部件，其质量好坏将严重影响设备运行的稳定性。近年来，随着我国制造业的大力发展，各行业对轴承产品的需求量不断增加，同时对轴承外观质量的要求也日益提高，尤其是在轴承进出口贸易中。尽管我国的机械加工技术已经达到较高的水平，但在轴承批量生产中难免产生一定的损伤。目前，企业对于缺陷轴承的分拣工作仍采用人眼检测、手动分拣的方式进行，这种方式不仅存在工作量大、效率低的问题，而且由于工人的分拣标准不同和视觉疲劳，导致分拣结果存在较高的漏检率和误检率。

针对上述问题，本文基于机器视觉技术设计了一套轴承表面缺陷检测系统，代替人工目测分拣，实现轴承表面缺陷的自动化检测。论文的主要研究内容和成果如下：

(1) 为实现轴承表面缺陷的全检，根据轴承表面的缺陷类型和分布位置，设计了一种多工位组合式光源照明方案以完成图像采集工作，并对每个检测工位进行工业相机、光学镜头、视觉光源的选型和照明方式的设计等。(2) 根据系统检测需求设计并搭建一套自动化分拣系统，该套硬件系统主要由上料装置、拨料装置、图像采集装置、翻转装置、分拣装置和码料装置组成，整体由 PLC 负责控制运行。(3) 分别对不同的检测工位设计相应的检测算法，包括基于传统图像处理算法的边缘检测、EDCircles 圆检测、EDLines 直线检测、区域分割提取、Blob 分析等方法。此外，本文提出一种基于 SFCS-YOLO v3 的轴承防尘盖表面的凹坑缺陷检测算法，该算法实现了 97.50% 的检测准确率，以及提出一种基于两阶段神经网络（Attenitive GAN 和 AE-WGAN）的轴承图像去油滴算法，该算法可降低 93% 的轴承表面油滴误检率。(4) 本文基于 Qt Creator 平台开发了一套轴承表面缺陷检测软件，该软件集成了图像采集、图像处理、结果可视化、数据统计和参数配置等功能。最后经测试，本文设计的轴承表面检测系统的检测准确率为 95.80%，单个轴承检测时间约为 2.14s。

关键字：轴承，机器视觉，图像处理，缺陷检测

Research on Bearing Surface Defect Detection System Based on Machine Vision

Abstract

As a basic component widely used in mechanical equipment, the quality of bearing will seriously affect the stability of equipment operation. In recent years, with the vigorous development of China's manufacturing industry, the demand for bearing products in various industries is increasing, and the requirements for bearing appearance quality are also increasing, especially in bearing import and export trade. Although China's machining technology has achieved a high level, it is inevitable to produce some damage in the batch production of bearings. At present, enterprises still use the methods of human eye detection and manual sorting for the sorting of defective bearings. This method not only has the problems of heavy workload and low efficiency, but also has high missed detection rate and false detection rate due to different sorting standards and visual fatigue of workers.

In view of the above problems, this paper designs a set of bearing surface defect detection system based on machine vision technology to replace manual visual sorting and realize the automatic detection of bearing surface defects. The main research contents and achievements of this paper are as follows: (1) In order to realize the full inspection of bearing surface defects, according to the defect types and distribution positions of bearing surface, a multi station combined light source lighting scheme is designed to complete the image acquisition work, and the selection of industrial camera, optical lens and visual light source and the design of lighting mode are carried out for each inspection station. (2) According to the system detection requirements, an automatic sorting system is designed and built. The hardware system is mainly composed of feeding device, feeding device, image acquisition device, turnover device, sorting device and stacking device, and the overall operation is controlled by PLC. (3) Corresponding detection algorithms are designed for different

detection stations, including Edge Detection, EDCcircles Circle Detection, EDLines Line Detection, Region Segmentation and Extraction, Blob Analysis and other methods based on traditional image processing algorithms. In addition, this paper proposes a pit defect detection algorithm based on SFCS-YOLO v3 bearing dust cover surface, which achieves 97.50% detection accuracy, and a bearing image oil drop removal algorithm based on two-stage neural network (Attenitve GAN and AE-WGAN) is proposed, which can reduce the false detection rate of oil drops on the bearing surface by 93%. (4) This paper develops a set of bearing surface defect detection software based on QT creator platform. The software integrates the functions of image acquisition, image processing, result visualization, data statistics and parameter configuration. Finally, after testing, the detection accuracy of the bearing surface detection system designed in this paper is 95.80%, and the detection time of a single bearing is about 2.14s.

Key words: bearing, machine vision, image processing, defect detection

目 录

1. 引言

1.1 研究背景及意义	1
1.2 国内外研究现状	3
1.3 课题来源	6
1.4 主要研究内容	7

2. 检测系统分析规划与硬件系统设计

2.1 轴承表面缺陷类型和分布位置分析	8
2.2 检测系统的需求与整体规划	10
2.1.1 检测系统的需求	10
2.1.2 检测系统的整体规划	10
2.3 硬件系统的组成	11
2.4 硬件系统关键设备的选型与设计	12
2.4.1 工业相机和光学镜头选型	12
2.4.2 视觉光源选型	15
2.4.3 PLC 选型	18
2.4.4 IO 运动控制卡选型	20
2.4.5 图像采集装置的设计与搭建	21
2.5 硬件系统的运行流程	22
2.6 硬件系统的实物展示	26
2.7 本章小结	26

3. 轴承表面缺陷检测算法

3.1 图像直线和圆检测算法	27
3.1.1 常见的边缘检测算子	27
3.1.2 直线检测算法	34
3.1.3 圆检测算法	38
3.2 轴承外侧面缺陷检测	44
3.3 轴承内侧面缺陷检测	50
3.4 轴承端面缺陷检测	53
3.5 本章小结	70

4. 基于改进 YOLO v3 算法的防尘盖表面凹坑缺陷检测

4.1 目标检测算法的介绍	71
4.2 数据采集与处理	74
4.3 YOLO v3 检测网络改进与训练	75
4.4 检测结果分析与对比	80
4.5 本章小结	85

5. 轴承图像去油滴算法	
5.1 油滴的分布与影响分析	86
5.2 基于两阶段的图像去油滴网络设计	87
5.2.1 轴承图像去油滴网络	88
5.2.2 图像精修复网络	91
5.3 图像去油滴实验	95
5.3.1 制作训练数据集	95
5.3.2 图像去油滴实验	96
5.3.3 图像精修复实验	99
5.3.4 图像去油滴前后缺陷检测对比	100
5.4 本章小结	101
6. 系统软件设计与测试	
6.1 软件需求	102
6.2 开发环境	103
6.3 串口通信	103
6.4 多线程并行检测实现	103
6.5 软件其他功能实现	103
6.6 系统整体测试	105
6.7 本章小结	106
7. 结论与展望	
7.1 结论	107
7.2 展望	107
参考文献	
攻读硕士期间发表的论文及所取得的研究成果	
致谢	

1. 引言

1.1 研究背景及意义

轴承作为一种机械传动过程中起固定和减小载荷摩擦作用的零部件，在工业中被广泛应用于引导轴类零件的旋转运动和承受轴传递给机架的载荷^[1]。其中，图 1-1 显示现有轴承的大体分类情况，根据轴承的结构和运动摩擦特性的不同，总体分为两类：滚动轴承和滑动轴承。滚动轴承根据承受载荷方向的不同可分向心轴承和推力轴承，而滑动轴承根据其润滑方式的不同可分为动压滑动轴承和静压滑动轴承。




图 1-1 常见轴承的分类

Figure 1-1 classification of common bearings

轴承产品质量的好坏将严重影响整个机械设备运行的稳定性。但在轴承生产和装配过程中，由于受加工、装配方式和微小异物等因素的影响，导致生产的轴承表面产生一些缺陷。常见的表面缺陷类型有：裂纹、黑斑、锈蚀、擦伤、缺口、凹坑、缺盖、浮盖、内外圈倒角尺寸不达标以及字符刻印错误等。这些缺陷不仅影响轴承产品的外观品质，也在一定程度上影响轴承的使用性能。

众所周知，制造业作为我国国民经济的主体和国防军事的重要保障，是立国之本、兴国之器、强国之基^[2]。《中国制造 2025》规划的目的在于引导我国由制造大国转变为制造强国，倡导创新发展核心技术，摆脱对国外高新技术的依赖，提高我国制造业的国际竞争力，逐步建立和完善我国的现代化工业制造体系。但当前我国基础制造工艺和基础材料产业与发达国家相比还处于相对靠后的位置，许多国产基础零部件的

可靠性无法满足主机需求。为扭转这种发展现状，我国提出重点发展高速、精密、重载轴承等机械基础零部件行业，逐步加大对轴承产品研发制造的投入，提高生产轴承的可靠性和使用寿命。

近年来，随着国家对机械制造业发展的投入，使得对轴承产品的需求量不断提高，轴承产业的销售额也在不断增加。如图 1-2 所示，截止 2020 年我国轴承行业销售额为 1930 亿元，同比增长 9.04%^[2]。此外，宁波市作为我国轴承重要生产城市，仅慈溪市在 2021 年轴承出口总额为 43.76 亿元，同比增长 29.4%，比 2019 年增长 19.7%，所以轴承已然成为宁波重要的出口创汇产品^[4]。



图 1-2 2016-2020 年中国轴承行业销售额统计

Figure 1-2 statistics of China's bearing industry sales from 2016 to 2020

近年来，宁波市各轴承企业通过技术改造已实现了生产、装配自动化，唯独对缺陷轴承的分拣工作仍采用人工目测的方式，如图 1-3 所示。这种分拣方式不仅工作量大、效率低，而且由于人工因素造成检测的漏检率较高，严重影响产品生产和出货的效率，与高速自动化加工生产极不相称，所以各轴承企业迫切需要一种自动化轴承表面缺陷检测设备以弥补人工分拣的短板。虽然市场上已有部分轴承缺陷自动化检测设备，但其检测精度低，成本高、速度慢，无法满足轴承企业的实际检测需求。



图 1-3 人工分拣的现状

Figure 1-3 current situation of manual sorting

机器视觉是一种借助于图像处理技术从光学传感装置采集物的体图像中获取有效信息的技术^[5]。换言之，就是利用计算机和图像传感器仿照人的视觉能力，从客观事物中提取有用的信息，通过一系列的处理和分析，完成测量、检测和控制等工作。伴随着中国制造 2025 的推进，我国已经在自动化控制、图像处理、光学影像采集等技术领域实现了快速发展，机器视觉作为一种非接触式高新技术已被广泛应用于各种工业缺陷检测和机器人辅助控制当中。

本文针对轴承行业的需求现状，通过研究图像特征提取、图像分割、目标检测和图像增强等方法，将机器视觉技术与自动化控制技术相结合，旨在开发一套轴承表面缺陷自动化检测系统。该套系统不仅可以促进计算机图像处理技术的研究与发展，具有一定的理论研究价值；还可以解决众多轴承生产企业目前普遍存在的人工目测分拣的在速度和精度上的问题，提高企业的生产效率，降低企业的人工成本，推动轴承行业的自动化转型，具有一定的应用价值。

1.2 国内外研究现状

目前国内外基于机器视觉技术对轴承工件检测的研究相对较多，其研究方向大致集中在轴承尺寸检测和轴承表面缺陷检测。

(1) 在轴承尺寸检测方向: 2013 年苏俊宏等通过模板差分算法和 Hough 圆检测算法对圆柱形高精度轴承表面缺陷及外形尺寸实现微米级检测精度^[6]。2014 年刘胜利搭建一套轴承图像采集平台, 通过对轴承表面亚像素边缘提取, 实现内外径尺寸 μm 级检测精度, 并对轴承表面的锈斑、裂纹、划痕缺陷进行检测和分类^[7]。2016 年范帅等人研究轴承内外圈尺寸检测和分类方法, 通过对图像中两个特殊像素点的运算得出轴承内外半径尺寸, 并结合形态学操作和边缘提取实现缺陷检测和分类^[8]。2017 年崔灿等人基于机械抽样和最小二乘迭代法拟合轴承内外径和同心度, 其计算速度是 Hough 圆检测算法的 10.2 倍^[9]。

(2) 在轴承表面缺陷检测方向: 陈廉清等、陈向伟、刘晓杰、杜月荣等人均采用图像差分技术实现轴承表面缺陷的检测^[10,11,12,13]。袁红彬利用图像分割技术和图像差分法在排除字符干扰后实现对轴承表面缺陷的检测^[14]。KUNAKORN VONG 等人基于纹理单元的方法减少 ABS 亮度强度, 实现轴承表面缺陷的判别^[15]。王恒迪等人提出利用二值化、边缘检测实现图像定位与分割, 最后基于 8 连通域标记法对缺陷进行识别^[16]。郑越、杜克飞等人分别搭建一套轴承内圈缺陷检测平台, 并采用 ROI 定位、阈值分割等图像处理方法实现滑动轴承尺寸测量和表面缺陷检测^[17,18]。黄睿通过使用多角度不均匀光照图像融合方式结合邻域比较法, 实现了轴承端面四类缺陷的检测^[19]。Bin Liu, Yiqian Yang 等人针对轴承防尘盖表面的凹坑和划痕缺陷, 使用一种多角度光照法采集图像, 并通过极坐标变换和改进 OTSU 阈值的方法实现对轴承防尘盖表面凹坑和划痕缺陷的检测^[20]。陈廉清、袁红彬、王龙山等人利用 SUSAN 算子实现了对图像的分割和微小轴承表面缺陷的快速检测^[21]。张扬、朱善安等提出了一种基于小波变换和纹理特征量的 Canny 算子边缘检测算法, 并将其应用于轴承表面缺陷检测^[22]。陈文达等人为实现表面缺陷的检测, 通过 OTSU 阈值分割和 Roberts 边缘提取的方式消除轴承防尘盖表面字符对缺陷检测的干扰^[23]。任永强、潘浩、李广涛等人首先通过图像轮廓检测和最小二乘法提取轴承防尘盖圆环区域, 然后利用图像极坐标换、字符特征提取和支持向量机 (SVM) 实现对防尘盖字符的识别^[24]。王昌、高晶晶提出一种自动危险区域分析和阈值筛选的轴承防尘盖缺陷识别算法^[25]。周贤伟应用改进的小波变换算法和八邻域标记法识别轴承防尘盖表面的缺陷^[26]。兰叶深等人利用高斯金字塔、亚像素分

割提取轴承表面显著性特征，提高了缺陷检测识别的速度^[27]。张闯闯搭建了一套视觉的检测系统，采用轮廓增强、边缘检测、形态学操作和阈值分割等方法实现了对轴承套圈端面和侧面的检测^[28]。徐科、黄秀玲等人通过多角度照明方式，根据光度立体学原理，获取待测表面的梯度、深度和法向量信息，从而实现表面缺陷检测^[29,30,31]。

随着计算视觉领域的快速发展，一些基于深度学习的图像处理技术逐渐被提出，比如目标检测、图像分割、图像分类以及图像增强等神经网络被广泛应用于二维图像处理中。赵妍妍采用 LVQ 神经网络实现对轴承外侧面缺陷的分类^[32]。吴义权采用一种 PCA 分析法对不同类型的缺陷进行采样学习，实现了对轴承内圈和外圈缺陷的准确分类^[33]。宇文旋提出一种以小波变换为分类特征的局部多神经网络和综合运用标量特征选择、相关分析和特征向量选择的实用特征选择算法^[34]。王启祥针对轴承外圈侧面的擦伤、磨削过量、划痕、磕碰伤等缺陷，设计了一种卷积自动编码器和缺陷分类网络实现对轴承外圈侧面缺陷的分类^[35]。刘好斌等人通过 Mosaic 和 Copy-Pasting 策略的数据增强，使用 YOLO v5 实现了轴承端面缺陷的检测，其检测精度可达 94.7%^[36]。Zheng Z, Zhao J, Li Y 等人通过改进 YOLO v3 网络实现对轴承胶质密封盖表面缺陷的检测，在论文中作者将 Darknet-53 主干特征提取网络更换为 BNA-Net，并在网络中添加了缺陷定位子网络和注意力预测子网络（UF），最后在 Yolo Head 分支中增加了（104，104）尺度的分支，以提高网络对小目标的检测精度，最终作者实现的检测精度为 mAP = 69.74%，相比于 YOLO v3、YOLO v4 和 YOLO v5 提高 16.31%、10.9% 和 13%^[37,38,39]。

上述研究内容均为轴承表面的缺陷检测算法，而在实际的检测环境中，生产出的轴承表面带有一定的油滴，这对轴承表面缺陷检测产生极大的干扰，因此从图像增强角度研究一种图像去油滴的算法是当下研究的一个重点。而在图像增强领域，图像去雨滴作为一个广泛研究的方向，其目的是从带有雨滴的图像中恢复无雨滴的图像，从而提高图像质量，辅助视觉产品在户外场景中的应用。现有的去雨滴算法应用场景可分为三种：即雨线场景、雨雾场景和雨滴场景。目前，具有代表性的去雨线算法是 He Z, Patel V M 等人提出一种 DID-MDN 方法，该方法利用残差感知网络（Residual-aware Rain-density Classifier）对输入图像的雨点程度进行分类，并将得到的雨线密度信息融合输入多流密集连接网络（Multi-stream Densely-connected De-raining Network），实现

去除图像中的雨线^[40]。对于去雨雾算法，Zhang H，Patel V M 等人根据大气散射模型设计了一种 DCPDN 网络，该网络采用两个生成器 Pyramid Densely-connected Encoder-decoder 和 Unet，分别用于生成传输率图和大气图，然后根据大气散射模型生成去雨雾图，最后作者使用一个判别器对生成的图像进行判别^[41]。此外，作者针对雨雾场景设计了一种新的损失函数-边界感知损失，提高生成图像的边缘特征。而针对雨滴场景去除效果较好的算法为 2018 年 Rui Qian 等人提出的 Attentive GAN 网络模型，该网络创新点在于将雨滴注意力图 attention map 引入生成器网络（Generator）和判别器网络（Discriminator）中，使生成器能够更加关注雨滴所在区域，判别器能够根据 attention map 评估生成中的局部连续性，从而实现较好的雨滴去除效果^[42]。此外，在基于深度学习的图像修复方向，Pathak D 等人首次利用深度学习进行图像修复，通过将 Encoder-Decoder 结构和 GAN 模型相结合根据上下文信息学习图像特征和生成图像缺失区域的预测图^[43]。Yang C 等人利用 Context Encoder 和多尺度 neural patches 实现图像修复^[44]。Liu G 等人通过将部分卷积（Partial Convolutions）加入生成网络中改善修复图像中出现的颜色差异和模糊等伪影问题^[45]。此外许多人尝试使用两阶段网络进行图像处理，相比于单阶段网络的处理方法，两阶段网络的恢复效果更好。Liu H 等人提出一种两阶段的图像修复网络，并通过连贯性语义注意力机制 CSA 解决修复图像局部像素的不连续性问题^[46]。Song Y、Yu J 等人也均通过两阶段网络分别实现图像的粗修复和精修复^[47,48]。

虽然已有多人在研究轴承表面缺陷的检测方法，但是目前仍没有一套完整的检测系统可以实际应用于轴承行业的缺陷检测，而且随着工业自动化的快速发展，轴承行业的实际检测需求远超于目前的研究现状。

1.3 课题来源

本课题已获得宁波市科技创新项目的支持，其项目编号为：2021Z126 和 2021Z063。

1.4 主要研究内容

根据上述内容以及结合目前轴承企业的检测需求，本文旨在设计一套基于机器视觉的轴承表面缺陷检测系统，替代人工检测，提高缺陷轴承分拣的效率和精度。故本文主要研究内容包括：

（1）根据轴承表面缺陷类型和分布位置设计相应的图像采集方案，包括相机、光学镜头、视觉光源的选型以及照明方式的设计。

（2）搭建一套轴承缺陷自动化检测平台，包括上料装置、拨料装置、图像采集装置、翻转装置、分拣装置、码料装置以及 PLC 自动化控制等。

（3）研究轴承表面缺陷检测算法，结合轴承表面缺陷类型和图像采集方案对系统中不同的检测工位设计相应的缺陷检测算法。

（4）开发轴承缺陷检测软件，实现图像采集、图像处理、结果可视化、数据统计、串行通讯和参数配置等功能。

2. 检测系统分析规划与硬件系统设计

本章从分析轴承表面缺陷类型和缺陷分布位置的角度出发，简述本文设计的轴承表面缺陷检测系统的需求和整体规划。在此基础上，通过对硬件系统中的关键组件：工业相机、光学镜头、光源设备、PLC（可编程逻辑控制器）以及 IO 运动控制卡进行选型，进而介绍视觉系统的搭建、机械结构设计以及 PLC 自动化控制等工作。

2.1 轴承表面缺陷类型和分布位置分析

轴承作为机械系统中常用的零部件，其结构如图 2-1 所示，主要由内圈、外圈、滚动体、保持架以及防尘盖（密封圈）五部分组成。本文设计的轴承表面缺陷检测系统主要针对 608Z 型号的深沟球轴承，该类轴承在日常设备中的应用最为广泛，其国标尺寸规格为轴承外径为 22mm，轴承内径为 8mm，轴承高度为 7mm，主要特点是摩擦阻力小，转速高，既可以承受径向载荷也可以承受轴向载荷。




图 2-1 轴承的结构组成

Figure 2-1 structural composition of bearing

本文通过对大量表面带缺陷的轴承进行打光测试，将其表面常见的缺陷类型和分布位置进行了总结分析。表 2-1 显示了各类缺陷在轴承表面分布情况，其中轴承外侧面存在的缺陷类型有黑斑、锈蚀、擦伤、裂纹和倒角尺寸缺陷；轴承内侧面存在的缺陷类型有黑斑、锈蚀缺陷；而轴承正反端面存在的缺陷类型有黑斑、锈蚀、擦伤、裂

纹、缺口、凹坑、字符以及倒角尺寸等缺陷。

表 2-1 轴承各表面存在的缺陷类型

Table 2-1 types of defects on each surface of bearing

缺陷类型	轴承外侧面	轴承内侧面	轴承端面
黑斑缺陷	√	√	√
锈蚀缺陷	√	√	√
擦伤缺陷	√		√
缺口缺陷			√
裂纹缺陷	√		√
凹坑缺陷			√
字符缺陷			√
倒角尺寸缺陷	√		√

下图 2-2 则显示了轴承表面常见各类缺陷在图像中的特征表现。




图 2-2 608Z 型号深沟球轴承表面缺陷类型

Figure 2-2 types of defects on the surface of 608Z deep groove ball bearing

2.2 检测系统的需求与整体规划

2.1.1 检测系统的需求

通过前期在轴承生产企业的调研，本系统的检测需求主要包括三方面，分别为：

- （1）检测速度：为保证与轴承企业的生产进行连线工作，系统的整体检测速度需 ≤ 2 秒/个；
- （2）检测准确度：系统需完成轴承各个表面全检工作，包括轴承内圈、轴承外圈以及轴承上、下端面。主要检测的缺陷类型包括黑斑、锈蚀、缺口、裂纹、凹坑、浮盖、倒角尺寸、字符错印等，系统整体检测准确率 $\geq 95\%$ 。
- （3）检测稳定性：考虑工业缺陷的多样性，自动化检测设备相比于人工检测在速度和精度方面存在一定的差距，所以必须保证系统检测的可靠性和持续运行的稳定性。

2.1.2 检测系统的整体规划




Figure 2-3 overall composition of the system

根据上述轴承表面缺陷检测系统的检测需求，图 2-3 所示为本文所设计检测系统的整体组成，主要分为上位机和下位机，其中上位机是指 PC 端检测软件，该软件的功能包括：图像采集控制、图像处理算法、检测结果可视化、数据统计、与下位机实时通

讯以及软件参数配置；下位机则是指系统整个硬件控制，包括上料装置、拨料装置、翻转装置、图像采集装置、分拣装置、码料装置和 PLC 自动化控制系统。

根据上述系统检测需求，该系统共包含四个重要模块，分别为：

（1） 图像采集模块

针对轴承不同表面进行多工位图像采集，根据不同表面的缺陷类型和检测需求，选择不同型号相机、镜头和光源进行打光测试，保证缺陷在图像表现出较强的区分特征，减少算法的复杂度，在一定程度上提高检测的稳定性。

（2） 机械自动化模块

自动化模块包括机械机构和 PLC 控制。机械结构作为整个检测系统的硬件基础，配合其他各功能模块完成相应的检测和分拣功能。PLC 作为硬件系统的控制核心，主要用于控制整个系统的机械结构的运动以及与上位机通讯，保证系统的持续稳定运行。

（3） 缺陷检测算法模块

缺陷检测算法是整个检测系统的核心，用于检测轴承各表面存在的缺陷，其算法检测的精度和速度关系整个系统的检测性能和检测效率。

（4） 软件开发模块

检测软件主要用于控制图像采集、图像处理以及与下位机通讯，此外还包括检测结果可视化、相机、光源和算法参数设置以及数据统计等。

2.3 硬件系统的组成

本文设计的硬件系统主要由两部分组成，分别为机械结构和 PLC 自动化控制。其中，机械结构作为整个检测系统的硬件基础，用于配合控制模块完成相应的检测和分拣功能。如图 2-4 所示，本系统所需要的机械结构包括上料装置、拨料装置、图像采集装置、翻转装置、分拣装置以及码料装置，分别用于完成系统的上料、图像采集、分拣和码料等功能。其中图像采集装置作为本系统的关键装置，主要用于针对轴承不同表面的缺陷类型和检测需求，通过选择不同型号工业相机、光学镜头和光源设备完成多工位图像的采集，保证缺陷在图像表现出较强的区分特征，减少算法的复杂度，在一定程度上提高检测的稳定性。

PLC 自动化控制作为硬件系统的控制核心，主要包括机械装置运行的逻辑控制和轴承分拣的逻辑统计判断以及与上位机软件的实时通讯，以保证系统持续运行的稳定性。




图 2-4 轴承缺陷检测系统的硬件系统结构

Figure 2-4 hardware system structure of bearing defect detection system

2. 4 硬件系统关键设备的选型与设计

2. 4. 1 工业相机和光学镜头选型

1. 工业相机

工业相机作为机器视觉系统中的关键部件，用于将光信号转变为有序的电信号^[49]。工业相机选型作为机器视觉系统设计的重要步骤，它不仅直接决定采集图像分辨率和图像质量，还直接关系整个系统的运行模式。




图 2-5 相机成像流程图

Figure 2-5 camera imaging flow chart

如图 2-5 所示，工业相机的成像原理大致为：当光线通过光学镜头照射在感光传感器上时（通常为 CCD 或 CMOS），感光传感器会产生模拟电流信号。该信号经过模-数转换成数字信号，然后传输给图像处理器 DSP 得到的采集的图像。最后可将图像数据压缩保存或通过图像采集卡传入计算机，以便后续的图像处理工作。

在工业视觉检测领域，在没有颜色需求的情况下，应优先选择黑白工业相机，其原因是黑白相机利用单色光照得到的灰度信息具有图像对比度高、图像噪声小、处理速度快等优点，故所选工业相机均为黑白工业相机。

2. 光学镜头选型

光学镜头作为相机的重要组成部分，其主要作用是将目标物体的图像聚焦在图像传感器的光敏元件上，工业相机不同安装的工作距离和视野范围要求使用不同的镜头。对于光学镜头来时，在进行选型工作时需考虑的主要参数包括：

（1）焦距（ f ）：是指镜头中心点到交平面影像之间的距离。

（2）光圈（ $Iris$ ）：镜头光圈的数值约等于镜头焦距 f 和通光孔径 D 的比值，一般用 F 表示。

（3）视野范围（ FOV ）：指相机实际成像区域的大小。

（4）光学放大倍数（ β ）：光学放大倍数 $\beta = \frac{S}{FOV}$ 。

（5）工作距离（ WD ）：是指镜头首个工作面到被拍摄物体的距离。

3. 工业相机和光学镜头的选型

根据项目需求，设定项目中工业相机的工作距离 WD 、待检测的最大视场范围 FOV 、最小特征的尺寸 l_{min} 和检测特征像素数 p_{min} 的要求，然后根据上述已知参数来计算需要的相机和镜头型号。




图 2-6 相机成像光学系统

Figure 2-6 camera imaging optical system

如上图 2-6 所示，根据成像系统简化模型的参数约束关系：

$$\frac{S}{f} \times WD = FOV = \frac{R_{\min} \times l_{\min}}{p_{\min}} \quad (2-1)$$

我们可求得检测所需相机的最小分辨率 $R_{\min}$ 。

$$R_{\min} = \frac{FOV}{l_{\min}} \times p_{\min} \quad (2-2)$$

然后根据公式（2-3），我们进一步可求得镜头的焦距 f ：

$$f \leq \frac{S}{WD} \times FOV \quad (2-3)$$

根据相机的最小分辨率参数 f 和镜头焦距参数 $R_{\min}$ ，我们可以得到多种组合的相机和镜头，最后从中选择镜头空间分辨率大于相机分辨率的组合以及 $\frac{S}{f} > \frac{FOV}{WD}$ 的相机与镜头的组合。

下图 2-7 所示为工业相机和光学镜头选型的简化流程：




图 2-7 相机、镜头选型流程

Figure 2-7 camera and optical lens selection process

根据上述选型流程，本系统各检测工位所选定的相机与镜头型号如下表 2-2 和表 2-3 所示：

表 2-2 各检测工位选用的相机型号

Table 2-2 model of camera light source selected for each detection station

工位	相机型号	相机类型	相机分辨率	像元尺寸	靶面尺寸
工位 1	MV-CL021-40GM	2k 线阵黑白工业相机	2048 × 1	7 μm	28kHz@Mono10/12
工位 2	MV-CE050-31GMGC	面阵黑白工业相机	2592×1944	2.2 μm × 2.2 μm	1/2.5"
工位 3	MV-CA013-20GMGCGN	面阵黑白工业相机	1280×1024	4.8 μm × 4.8 μm	1/2"
工位 4	MV-CA013-20GMGCGN	面阵黑白工业相机	1280×1024	4.8 μm × 4.8 μm	1/2"

表 2-3 各检测工位选用的光学镜头型号

Table 2-3 optical lens models selected for each testing station

工位	镜头型号	镜头焦距	相面尺寸
工位 1	MVL-HF03524M-MP	35mm	Φ9mm(1/1.8")
工位 2	MVL-KF5028M-12MP	50mm	Φ17.6 mm(1.1")
工位 3	MVL-HF3528M-6MP	35mm	Φ9mm(1/1.8")
工位 4	MVL-HF3528M-6MP	35mm	Φ9mm(1/1.8")

2.4.2 视觉光源选型

在机器视觉系统中，视觉光源作为决定图像采集质量最重要的因素，其作用主要表现在：一方面避免环境光对系统的干扰，使目标特征极具显著性，提高视觉系统定位、测量、识别精度；另一方面可以简化图像处理算法和系统设计的复杂度，提高视

觉系统的运行速度。本文在进行光源选型时，主要从不同类型光源的光学特性和照明方案两个角度进行考虑。

目前，机器视觉系统常用的光源类型可分为以下几类：

（1）环形光源：如图 2-8 所示，环形光源可以组合成不同照明角度和照明颜色，能够突出物体的三维信息，其高密度 LED 阵列可以解决对角线照明阴影的问题，而漫射板的使用可以使光线均匀扩散。环形光源可分为高角度环形光源、低角度环形光源和分区段环形光源，通常使用采用前向照明的方式，即将光源和相机安装在待测物体的同侧。




图 2-8 环形光源和对应的打光方式

Figure 2-8 the ring lighting and corresponding lighting method

（2）平面光源：如图 2-9 所示，平面光源能够突出物体的轮廓特征，适用于背向照明，使用时通常将光源安装在相机镜头相对面，待测物体放置在光源放光面上方。




图 2-6 平面光源和对应的打光方式

Figure 2-9 plane lighting and corresponding lighting method

(3) 条形光源：如图 2-10 所示，条形光源的灯珠成长方形阵列分布，将其以一定角度照射物体，可突出物体的边缘特征，实际使用时也可以根据检测需求将多个条形光源自由组合进行打光。




图 2-10 条形光源和对应的打光方式

Figure 2-10 rectangular lighting and corresponding lighting method

(4) 同轴光源：如图 2-11 所示，同轴光源通过分光镜实现光线平行照射在待测物体表面，能够凸显表面不平整的特征，适用于高反射物体表面划伤、破损检测。




图 2-11 同轴光源和对应的打光方式

Figure 2-11 coaxial lighting and corresponding lighting method

根据上述不同类型光源所具有的光学特性，并结合轴承不同表面存在缺陷在光源下的特征表现，最终本系统的不同检测工位采用的照明方案分别为：

(1) 对于轴承的外侧圆弧面检测，需要使用线阵工业相机并配合旋转升降机构，并采用小型平面光源和条形光源组合搭配进行正面打光。其中小型平面光源主要对外圈平整弧面进行打光，凸显其表面存在的黑斑、裂纹、锈蚀、擦伤缺陷；条形光源作

用为给外侧面的圆倒角区域进行打光，用于检测外侧面上下倒角尺寸是否对称。

(2) 对于轴承的内侧圆弧面，由于轴承内孔的直径小，无法采用线阵相机采集内径面图像，所以采用平面光源进行背向照明的方案，突显内侧圆弧面存在的锈蚀和黑斑缺陷。

(3) 对于轴承的正反端面，由于其表面存在的缺陷种类较多，故采用组合式光源进行连续正面频闪打光。其中环形光源用于检测黑斑、锈蚀、擦伤、缺口、裂纹、字符缺陷；四分区光源用于检测凹坑、划痕缺陷；低角度环形光源用于检测倒角部位缺陷。

最终本系统各检测工位选用的光源类型和照明方式如下表 2-4 所示：

表 2-4 系统各检测工位所用光源类型及数量

Table 2-4 type and quantity of light sources used in each detection station of the system

检测工位	光源类型	光源型号	照明方式	光源数量
工位 1	平行面光源	P-PHFL-48-28-B	前向照明	1
	条形光源	P-BL2-57-18-B	前向照明	2
工位 2	平行面光源	P-FL2-50-50-W	背向照明	1
	分区段光源	P-4RL-90-70-B/W	前向照明	1
工位 3	环形光源	P-RL-170-90-B/W	前向照明	1
	低角度光源	P-RL-146-00-B/W	前向照明	1
	分区段光源	P-4RL-90-70-B/W	前向照明	1
工位 4	环形光源	P-RL-170-90-B/W	前向照明	1
	低角度光源	P-RL-146-00-B/W	前向照明	1

2.4.3 PLC 选型

PLC 作为自动化设备的核心控制器，不同型号的 PLC 具有不同的结构、性能、容量、指令系统、编程方式和适用场合。合理选用 PLC 型号可以提高系统的经济性和实用性。

一般在进行 PLC 选型时需从以下两方面重点考虑：

(1) 输入、输出 (I/O) 点数: 输入、输出 (I/O) 点数是 PLC 的基本参数之一, 也是实际应用必须考虑的参数。选型时可以根据控制设备所需的输入、输出点数的总和来确定 PLC 型号, 注意预留 10%~20% 的点数余量。

(2) 功能选择: 不同型号的 PLC, 其功能特性各不相同, 应根据系统的实际功能需求对 PLC 进行选型, 一般主要考虑的功能包括运算、控制、通讯、编程等功能。

本系统在选型时首先从实际控制需求入手, 归纳出 PLC 所要实现的控制功能:

1) 当接近开关 1 的信号被触发时, PLC 控制上料气缸 1 进行推料, 步进电机带动输送带进行输送;

2) 当接近开关 2 的信号被触发时, PLC 需控制拨料气缸 2 推动或拉动拨料台沿着直线滑轨完成一次拨料动作, 同时发出图像采集信号;

3) 拨料动作完成后, PLC 需控制翻转气缸 3 带动轴承进行正反端面翻转;

4) 当接收到上位机图像采集完成信号和图像处理完成信号时 PLC 需再进行一次拨料动作, 然后根据检测结果控制分拣气缸 4 对缺陷轴承进行分拣动作;

5) 对于合格轴承, 横向接近开关 3 被触发时, PLC 需控制横推气缸 5 进行横向码料;

6) 当竖向接近开关 4 被触发时, PLC 需控制竖推气缸 6 进行竖向码料;

7) 对于不合格轴承, 当接近开关 5 被触发时, PLC 需控制码料气缸运动进行码料。

此外, PLC 需要通过数据移位 (位左移功能) 的方式统计各检测工位图像处理结果, 以便对分拣动作进行控制。所以经过统计, 整个系统共需要 65 个 I/O 输入输出点。

综合上述 PLC 选型规则以及本系统所需的控制功能, 本文最终选择台达 DVP-64EH300T 型号的 PLC 可编程控制器主机和 DVP16HM11N 拓展模块, 如下图 2-12 所示。该型号 PLC 采用 220v 电压作为输入电压, 具有 64 个 I/O 输入输出端口, 属于 E 类标准型主机。而 DVP16HM11N 拓展模块具有 16 个 I/O 输入输出点数, 这样的组合具有 80 个可用的 I/O 点数, 满足本系统的需求且留有一定的余量, 方便后续功能的增加。



图 2-12 台达 DVP-64EH300 型号的 PLC 和 I/O 拓展模块

Figure 2-12 PLC and I/O expansion module of delta DVP-64EH300

2.4.4 IO 运动控制卡选型

在本文所设计系统中，硬件系统的运动和各检测工位的图像采集信号均通过 PLC 可编程控制器进行控制和发出，而上位机 PC 端的检测软件通过接收 PLC 发出的信号以完成图像采集和图像处理。所以在 PLC 与 PC 之间需要通过 IO 运动控制卡以高低电平的方式进行通讯，从而实现整个系统的持续稳定运行。

运动控制卡是一种基于 PC 机的上位控制单元，可利用多种高级编程语言进行开发，适用于多种运动控制场合，包括位移、速度、加速度等，使用时通过控制卡 API 接口函数即可轻松通讯功能。目前，工业自动化领域通常将运动控制卡、PLC、机器视觉配合使用。其中 PLC 负责运动逻辑控制，机器视觉通过 PC 端软件控制获取和处理图像，最后两者通过 IO 运动控制板卡进行信息通讯。这样可以充分利用了 PC 的强大功能和 IO 板卡的运动功能，同时也保留了 PLC 在逻辑控制方面的优势。

如下图 2-13 为本系统采用的 IO 运动控制卡（雷赛 IOC0640）的实际接线图。




图 2-13 雷赛 IOC0640 控制卡的通讯引脚的定义

Figure 2-13 definition of communication pin of Lacey IOC0640 motion control card

而如下表 2-5 为本系统采用的 IO 运动控制卡的输入输出端口分配表。

表 2-5 运动控制卡输入输出（I/O）端口分配表

Table 2-5 motion control card input/output (I/O) port allocation table

输入端	功能说明	备注	输出端	功能说明	备注
2	外径采集结束	X33	18	外径相机触发	Y30
3	外径检测 OK	X34	19	内径相机触发	Y31
4	外径检测 NG	X35	20	上端面相机触发	Y32
5	内径采集结束	X36	21	下端面相机触发	Y33
6	内径检测 OK	X37			
7	内径检测 NG	X40			
8	上端面采集结束	X41			
9	上端面检测 OK	X42			
10	上端面检测 NG	X43			
11	下端面采集结束	X44			
12	下端面检测 OK	X45			
13	下端面检测 NG	X46			

2. 4. 5 图像采集装置的设计与搭建

本文根据上述图像采集设备的选型结果分别对轴承的外侧圆弧面、内侧圆弧面和上

下端面设计了相应的图像采集装置。

其中，检测工位 1 用于检测轴承外径圆弧面存在的缺陷，如图 2-14 (a) 所示，该检测工位主要有线阵相机、平面和条形光源、升降旋转机构组成，这里的升降旋转机构是为了配合线阵工业相机采集图像，通过气缸推动步进电机沿直线导轨向上运动，进而带动轴承进行旋转运动。

检测工位 2 用于检测轴承内圈内侧面存在的缺陷，由于采用背向照明的方式，所以其安装结构设计如图 2-14 (b) 所示，通过在工位 2 工业相机对应的平台处铣削出一个大尺寸的通孔，将平面光源安装在通孔下方，上方安装一片耐磨玻璃，这样光线便可透过玻璃在照射到轴承内圈表面从而实现背向照明。

检测工位 3 和检测工位 4 分别用于检测轴承的正反面存在的缺陷，由于这两个工位采用组合式光源进行前向照明。所以相机光源的安装结构如图 2-14 (c)、2-14 (d) 所示。从上往下，光源的类型依次为：分区段环形光源、高角度环形光源、低角度环形光源。




图 2-14 各检测工位图像采集装置结构设计

Figure 2-14 structural design of image acquisition device at each detection station

2.5 硬件系统的运行流程

如图 2-15 所示，其中 0、1、2...表示轴承序号，本文设计的硬件系统运行流程简述如下：当启动系统运行时，PLC 通过输送带上的接近开关 1 判断输送带上是否有料，若无料，则控制上料装置的推料气缸 1 将串料台上的轴承推落至输送带上。当输送带上的待检轴承被输送至拨料端时，则触发接近开关 2 发送信号，PLC 接收到该信号后控制拨料气缸 2 将待检轴承依次拨料至检测工位 1。当拨料气缸 2 完成拨料动作

后，一方面 PLC 会通过 IO 控制板卡向上位机软件发送图像采集信号，另一方面控制检测工位 1 的气缸 3 将步进电机顶起，然后由步进电机的主轴带动轴承进行旋转。当软件控制工业相机完成图像采集和处理工作后，软件通过 IO 控制板卡反馈给下位机（PLC）图像采集完成信号和检测结果信号，此时完成轴承外侧面检测。当 PLC 接收到软件发送的信号后，则控制拨料气缸 2 将待检轴承拨料至检测工位 2，并给上位机发送图像采集信号。上位机收到信号后进行图像采集和处理工作，然后发送图像采集、检测完成信号至 PLC。PLC 收到该信号后继续将待检轴承输送至检测工位 3，由于该工位采用组合式光源，需要进行连续频闪拍照，所以当软件接收到开始图像采集信号后，会同时控制光源和相机进行图像采集，待到图像采集和处理完成后，PLC 控制拨料气缸 2 将待检轴承继续拨料至翻转机构，翻转机构的作用是将轴承进行正反面翻转以便继续进行反面检测。待到后一个轴承完成工位 3 检测后，PLC 将翻转后的轴承拨至工位 4，工位 4 的检测原理和工位 3 相同，也需要软件同时控制相机和光源完成连续频闪拍照。

轴承	上料	空	外径	内径	上端面	翻转	下端面	空	分拣
外径检测	0			1	2	3	4	5	6
内径检测				0	1	2	3	4	5
上端面检测					0	1	2	3	4
轴承翻转						0	1	2	3
下端面检测							0	1	2

图 2-15 硬件系统运行流程

Figure 2-15 Operation process of hardware system

当连续运行时，PLC 控制拨料装置完成一次拨料后，会统一向上位机软件系统发送一次图像采集信号，上位机软件会通过多线程的方式同时触发不同工位的工业相机和光源控制器采集图像，之后将采集的图像进行相应的算法处理，并将处理后结果分别发送给 PLC，PLC 利用其内部的寄存器和位左移功能统计每个轴承在各检测工位的检测结果，进而控制分拣工位对该轴承进行 OK 料和 NG 料分拣。最后由 PLC 控制码料装置分别对 OK 料和 NG 料进行有序排列，以供企业人员将质检后的轴承进行下一环节处理。

下表 2-6 表示 PLC 的输入输出（I/O）端口分配表：

表 2-6 PLC 的输入输出（I/O）端口分配表

Table 2-6 Input / Output (I/O) port allocation of PLC

输入端	功能说明	输出端	功能说明
X0	有料	Y0	上料步进脉冲
X1	满料	Y1	上料步进方向
X2	上料气缸原位	Y2	外径步进脉冲
X3	上料气缸工作位	Y3	外径步进方向
X4	夹持气缸 1 原位	Y4	输出点备用 1
X5	夹持气缸 1 工作位	Y5	输出点备用 2
X6	夹持气缸 2 原位	Y6	输出点备用 3
X7	夹持气缸 2 工作位	Y7	输出点备用 4
X10	横移气缸原位	Y10	上料气缸
X11	横移气缸工作位	Y11	夹持气缸
X12	外径检测气缸原位	Y12	横移气缸
X13	外径检测气缸工作位	Y13	外径检测气缸
X14	横向码料气缸原位	Y14	横向码料气缸
X15	横向码料气缸工作位	Y15	翻转气缸正向
X16	翻转气缸原位	Y16	翻转气缸反向
X17	翻转气缸工作位	Y17	纵向码料气缸
X20	纵向码料气缸原位	Y20	NG 下料气缸
X21	纵向码料气缸工作位	Y21	NG 推料气缸
X22	NG 下料气缸原位	Y22	NG 满料灯输出
X23	NG 下料气缸工作位	Y23	系统正常灯输出
X24	NG 推料气缸原位	Y24	系统异常灯输出
X25	NG 推料气缸工作位	Y25	OK 码料横向有料感应
X26	NG 满料	Y26	OK 码料横向满料感应
X27	启动（SB1）	Y27	OK 码料纵向有料感应
X30	停止（SB2）	Y30	外径相机触发
X31	复位（SB3）	Y31	内径相机触发
X32	急停（SE1）	Y32	上端面相机触发
X33	外径采集结束	Y33	下端面相机触发

表 2-6 PLC 的输入输出（I/O）端口分配表（续）

Table 2-6 Input / Output (I/O) port allocation of PLC (Continued)

输入端	功能说明	输出端	功能说明
X34	外径检测 OK	Y34	NG 有料感应
X35	外径检测 NG	Y35	输出点备用 5
X36	内径采集结束	Y36	输出点备用 6
X37	内径检测 OK	Y37	输出点备用 7
X40	内径检测 NG	Y40	输出点备用 8
X41	上端面采集结束	Y41	输出点备用 9
X42	上端面检测 OK	Y42	输出点备用 10
X43	上端面检测 NG	Y43	输出点备用 11
X44	下端面采集结束	Y44	输出点备用 12
X45	下端面检测 OK	Y45	输出点备用 13
X46	下端面检测 NG	Y46	输出点备用 14
X47	输入点备用	Y47	输出点备用 15

下图 2-16 表示轴承缺陷检测系统的 PLC 控制系统的实际接线图：




图 2-16 轴承缺陷检测系统的 PLC 实际接线图

Figure 2-16 actual wiring diagram of PLC of bearing defect detection system

2.6 硬件系统的实物展示

下图 2-17 为本文搭建的轴承表面缺陷检测系统的实体结构图：



图 2-17 左：轴承缺陷检测系统的内部结构，右：轴承缺陷检测系统的整体外观

Figure 2-17 left: internal structure of bearing defect detection system,
right: overall appearance of bearing defect detection system

2.7 本章小结

本章通过对轴承表面缺陷的分析统计，简述了轴承表面常见的缺陷的类型、分布位置和特征表现，并根据系统的检测需求，规划了系统的重要组成模块和模块相应功能，并对检测系统的关键组件：相机镜头选型、光源选型、PLC 选型和 IO 运动控制卡的选型出发，介绍硬件系统的组成、图像采集装置的设计和系统整体的运行流程，最后展示本文所搭建的检测设备的实体。

3. 轴承表面缺陷检测算法

本章将从系统缺陷检测的图像处理算法出发，介绍有关轴承表面缺陷检测的关键算法，包括：边缘检测、圆检测、直线检测、字符检测，并对各工位的检测流程进行详细描述。

3.1 图像直线和圆检测算法

3.1.1 常见的边缘检测算子

边缘检测作为数字图像处理，特别是特征检测的重要环节，其目的是为了标识图像中亮度发生明显变化的点。边缘检测可以大幅度地减少一个图像矩阵中的数据量，剔除图像中与所需目标不相关的的信息，保留图像中的重要结构属性^[50]。

常用的边缘检测算法可大致分为两种方式：1. 基于查找的方式：该方式通过寻找数字图像一阶导数中的极值实现边缘检测，通常将边界定位在梯度最大方向，常用的梯度算子有：Sobel 算子、Prewitt 算子、Canny 算子；2. 基于零穿越的方式：即将图像二阶导数的零点视为图像边界，通常是利用 Laplacian 算子计算其零点或非线性差分表示的过零点。

（1）Roberts 算子

Roberts 算子是一种利用局部差分算子寻找边缘的边缘检测算子，该算子采用对角线差分，不同于标准一阶差分。Roberts 算子包含有两个对角线方向上的模板，如图 3-1 所示：

-1	0
0	1

0	-1
1	0

图 3-1 Rober 算子两对角线方向的模板

Figure 3-1 template of two diagonal directions of Rober operator

对应在对角线方向上的梯度分别为：

$$\begin{aligned} G_x &= \frac{\partial f}{\partial x} = f(x+1, y+1) - f(x, y) \\ G_y &= \frac{\partial f}{\partial y} = f(x+1, y) - f(x, y+1) \end{aligned} \quad (3-1)$$

下图 3-2 所示为本文采用 Roberts 算子检测得到的边缘图。




图 3-2 Robert 算子边缘检测结果

Figure 3-2 results of Robert operator edge detection

(2) Prewitt 算子

Prewitt 算子也是一阶微分边缘检测算子，其通过使用水平和垂直方向的模板与原图像进行邻域卷积实现两个方向上的边缘检测。它与 Sobel 算子的不同点在于其两方向的模板卷积核不同。由于 Prewitt 算子通过像素平均方式抑制噪声，所以其边缘检测的精度比 Roberts 算子差。Prewitt 算子的水平和垂直方向模板如图 3-3 所示：

-1	0	+1	+1	+1	+1
-1	0	+1	0	0	0
-1	0	+1	-1	-1	-1

水平方向模板

垂直方向模板

图 3-3 Prewitt 算子在水平和垂直方向的模板

Figure 3-3 template of Prewitt operator in horizontal and vertical directions

其卷积展开式为：

$$\begin{aligned} G_x &= |f(x-1, y-1) + f(x-1, y) + f(x-1, y+1) - f(x+1, y-1) - f(x+1, y) - f(x+1, y+1)| \\ G_y &= |f(x-1, y+1) + f(x, y+1) + f(x+1, y+1) - f(x-1, y-1) - f(x, y-1) - f(x+1, y-1)| \end{aligned} \quad (3-2)$$

由此可得图像梯度为：

$$G = \max(G_x, G_y) \text{ 或者 } G = G_x + G_y$$

下图 3-4 为本文采用 Prewitt 算子检测得到的边缘图。




图 3-4 Prewitt 算子边缘检测结果

Figure 3-4 results of Prewitt operator edge detection

(3) Sobel 算子

Sobel 算子作为一种典型的一阶导数边缘检测算子，是一种离散性差分算子，该算子通过引入了类似局部平均的运算，能很好的消除噪声的影响。而且由于 Sobel 算子以加权的方式处理对像素的位置影响，所以相比于 Prewitt 算子、Roberts 算子其边缘检测的效果更好。

Sobel 算子具有两个方向的模板，即水平方向模板和垂直方向模板，如下图 3-5 所示：

-1	0	+1	+1	+2	+1
-2	0	+2	0	0	0
-1	0	+1	-1	-2	-1

水平方向模板

垂直方向模板

图 3-5 Sobel 算子在水平和垂直方向的模板

Figure 3-5 template of Sobel operator in horizontal and vertical directions

Sobel 算子的计算过程：首先，利用上述两个方向的模板，根据式 3-3 计算原图像 I 在垂直方向和水平方向的梯度。

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} * I, \quad G_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} * I \quad (3-3)$$

其计算展开式为式 3-4 和式 3-5：

$$\Delta_x f(x, y) = [f(x-1, y+1) + 2f(x, y+1) + f(x+1, y+1)] - [f(x-1, y-1) + 2f(x, y-1) + f(x+1, y-1)] \quad (3-4)$$

$$\Delta_y f(x, y) = [f(x-1, y-1) + 2f(x-1, y) + f(x-1, y+1)] - [f(x+1, y-1) + 2f(x+1, y) + f(x+1, y+1)] \quad (3-5)$$

然后，根据式 3-6 即可计算出整个图像的梯度。

$$G = \sqrt{G_x^2 + G_y^2} \quad (3-6)$$

下图 3-6 为本文采用 Sobel 算子检测得到的边缘图。



图 3-6 Sobel 算子边缘检测结果

Figure 3-6 results of Sobel operator edge detection

(4) Scharr 算子

Scharr 算子是对 Sobel 算子差异性的增强，其图像边缘的检测原理和使用方法与 Sobel 相同。Scharr 算子采用 3×3 边缘滤波核，它可以通过增加滤波核的权重系数来加大像素值间的差异。

Scharr 算子在水平方向和垂直方向的边缘检测模板为：

-3	0	+3	-3	-10	-3
-10	0	+10	0	0	0
-3	0	+3	3	10	3

水平方向模板

垂直方向模板

下图 3-7 为本文采用 Scharr 算子检测得到的边缘图。




图 3-7 Scharr 算子边缘检测结果

Figure 3-7 results of Scharr operator edge detection

(5) Laplacian 算子

Laplacian 算子通过对邻域中心像素的四个方向或八个方向求梯度，以其梯度和作为依据判断中心像素灰度与邻域内其他像素灰度的关系，最后通过梯度运算的结果对像素灰度进行调整，其计算公式为：

$$\Delta src = \frac{\partial^2 src}{\partial x^2} + \frac{\partial^2 src}{\partial y^2} \quad (3-7)$$

Laplacian 算子的四邻域模板和八邻域模板如下图 3-8 所示：

0	1	0	1	1	1
1	-4	1	1	-8	1
0	1	0	1	1	1

图 3-8 左：4 邻域模板，右：8 邻域模板

Figure 3-8 left image: 4 neighborhood template, right image: 8 neighborhood template




图 3-9 Laplacian 算子边缘检测结果

Figure 3-9 results of Laplacian operator edge detection

上图 3-9 为本文采用 Laplacian 算子检测得到的边缘图。

(6) Canny 边缘检测

相比于 Sobel、Prewitt 等算子没有充分利用边缘的梯度方向信息，只是利用单阈值处理得到二值图像的问题。Canny 算法通过非极大值抑制和双阈值处理方式对上述问题进行了相应的改进。Canny 边缘检测算法的检测步骤为：

- 1) 使用高斯滤波（ 3×3 滤波核）对图像进行平滑去噪。
- 2) 采用 sobel 算子计算水平方向和垂直方向的一阶导数 G_x 和 G_y ，并根据式 3-8 和式 3-9 计算图像梯度的幅值 $G(x,y)$ 和方向 θ 。

$$G(x,y) = \sqrt{G_x^2 + G_y^2} \quad (3-8)$$

$$\theta = \arctan\left(\frac{G_x}{G_y}\right) \quad (3-9)$$

- 3) 使用非极大值抑制（NMS）细化图像边缘。
- 4) 使用双阈值处理梯度幅值 $G(x,y)$ ，以去除错误边缘点。即通过设置高低阈值方式，保留梯度大于高阈值的像素点，舍弃小于低阈值的像素点。如果像素点的梯度值介于高低阈值之间，则需要判断该点是否与真正的边界点相连，如果是就认为它也是边界点。

下图 3-10 为本文采用上述 Canny 边缘检测算法得到的边缘图。




图 3-10 Canny 边缘检测结果

Figure 3-10 results of Canny edge detection

(7) ED (Edge Drawing) 边缘检测

尽管 Canny 边缘检测算法可以得到一个较好的二值化的边缘图像，但其通过梯度

阈值获取的边缘像素通常是独立、不连续的。而 ED (Edge Drawing) 边缘检测算法根据锚点 (一组像素的最大梯度值) 的行和列定位稀疏点, 通过启发式边缘跟踪将锚连接, 并以矢量形式输出边缘图^[51]。这种方法不仅可以检测到足够高质量的边缘, 而且获得的边缘轮廓不受梯度算子的影响。

ED (Edge Drawing) 算法的检测步骤为:

- 1) 将图像进行高通滤波处理, 抑制低频噪声, 输出平滑图像;
- 2) 计算图像上每个像素点的梯度的幅值和方向;
- 3) 选择一组像素链, 将梯度算子为最大值的像素点设置为锚 (anchors) 点;
- 4) 连接上述的锚点, 绘制图像的边缘轮廓。
- 5) 基于亥姆霍兹准则 (Helmholtz principle) 验证上检测的边缘。

所以, 下图 3-11 为本文采用 ED 算法检测得到的边缘图。




图 3-11 ED 边缘检测结果

Figure 3-10 results of ED edge detection

通过对比上述几种算子边缘检测的结果图可以看出: Robert 算子定位比较精确, 但对噪声敏感, Prewitt 算子采用平均滤波和 Sobel 算子用加权平均滤波, 二者对灰度渐变低噪声的图像有较好的检测效果。但这三种梯度算子检测的精度并不高, 只能检测出图像大致的轮廓。Scharr 算子是对 Sobel 算子的增强改进, 相比于 Sobel 算子能计算出更小的梯度变化。Laplacian 算子法作为一种二阶边缘检测算子, 虽然具有增强边缘的作用但对噪声比较敏感。虽然 Canny 检测通过高低阈值实现的边缘检测效果优于上述五种梯度算子, 但其输出的二值化的边缘像素链是不连续的。而 ED 边缘检测的精度是最好的, 且检测速度比 Canny 边缘检测要快, 适合实时检测。

3.1.2 直线检测算法

(1) 霍夫直线检测 (HoughLines)

霍夫变换作为一种经典的特征提取方法,通过内置的投票机制可实现提取特定类型的形状。该投票机制是在一个参数空间中进行的,候选对象被当作累加器空间(accumulator space)中的局部最大值(local maxim)来获得。

而霍夫线变换(HoughLines)是一种用来寻找直线的方法,其原理是把图像上的全部像素点变换到极坐标空间中,这样每一点则会形成一条曲线,若某些曲线能相交于一点上,则这些像素点就在同一条直线上。

我们知道,在笛卡尔坐标系中,直线的方程可由斜率和截距(k, b)表示,即式 3-10。


$$y = kx + b \quad (3-10)$$


图 3-12 直线的表示

Figure 3-12 representation of straight line

而在极坐标系中,如图 3-12 所示,直线则由极径和极角(r, θ)表示,其中极径 r 是指原点到直线上最近点的距离,极角 θ 指 x 轴与连接原点和最近点的直线之间的夹角,所以其表达式为:

$$y = \left(-\frac{\cos\theta}{\sin\theta}\right)x + \left(\frac{r}{\sin\theta}\right) \quad (3-11)$$

化简可得:

$$r = x \cdot \cos\theta + y \cdot \sin\theta \quad (3-12)$$

这样对于一点(x_0, y_0),可以将过该点的一簇直线统一定义为:

$$r_\theta = x_0 \cdot \cos\theta + y_0 \cdot \sin\theta \quad (3-13)$$

这意味着每一对(r_θ, θ)代表一条通过点(x_0, y_0)的直线。如果我们在极坐标系平面

中绘制出所有通过定点 (x_0, y_0) 的直线将得到一条正弦曲线。下图 3-13 显示了经过定点 $(3, 4)$ 的所有直线的集合对应于 (r, θ) 平面中的正弦曲线。




图 3-13 过一定点的所有可能直线的集合表示

Figure 3-13 The set representation of all possible lines passing through a certain point

这也证明一组由两个或更多点形成的直线将会在该直线的 (r, θ) 处产生交叉的正弦曲线，因此便可通过查找曲线交点方式来解决检测共线点的问题。霍夫线变换就是通过追踪图像中每个点对应的曲线间的交点，如果交点数量超过设定阈值则认为该交点所代表的参数对 (r_θ, θ) 在原图像中是一条直线。

本文基于 Opencv 图像处理算法对原图 3-14 轴承外圈外侧面图像进行霍夫线检测，这里使用累积概率霍夫变换（HoughLinesP）进行直线检测。




图 3-14 采集的轴承外侧面图像

Figure 3-14 image of bearing outer side collected




图 3-15 高斯滤波结果图

Figure 3-15 Gaussian filtering results

首先，使用 3×3 高斯滤波核进行图像滤波，消除低频噪声，得到平滑图像，如图 3-15 所示。

然后，使用 Canny 边缘检测算法对上述平滑图像进行边缘检测，通过设置高、低边缘像素阈值获得原图像对应的二值化的边缘轮廓图，如图 3-16 所示。




图 3-16 Canny 边缘检测

Figure 3-16 Canny edge detection

最后，使用累积概率霍夫变换（HoughLinesP）对上一步获取的边缘图像进行霍夫直线检测，这里将检测到直线最小长度阈值 `minLineLength` 设置为 20，直线相邻像素点最小间隙阈值 `minLineGap` 设置为 10，检测到的直线段如图 3-17 所示。



图 3-17 HoughLinesP 直线检测

Figure 3-17 HoughLinesP line detection

（2）EDlines 直线检测

EDLines 是在 ED（Edge Drawing）获得边缘轮廓的基础上，利用最小二乘线拟合法，从生成的像素链中检测直线的算法^[52]。首先 EDLines 从 ED 边缘检测到的结果中选取具有连续边缘像素链的边缘段，然后用最小二乘法拟合最小长度的初始线段，并依次追踪边缘上的像素点。通过计算当前像素点到拟合直线的距离，如果小于设定阈值则将当前像素点添加至该线段中，直到误差超过某个阈值，输出当前线段。接着递归处理剩余边缘链的像素。最后基于亥姆霍兹准则（Helmholtz principle）检验提取的线段，剔除错误的检测。

亥姆霍兹准则检验的原理是：首先对于一个具有感知意义的几何结构来说，在随机情况下，该结构偶然出现的期望必须非常低。EDLines 根据该原理使用一种反向方法，即将被检测对象作为背景模型的异常值进行检验。

在基于亥姆霍兹准则进行验证时通过定义一个评判指标 NFA (Number of False Alarms), 用它来评判目标图像中某个候选区域小于背景模型中相同位置区域同性点 k (aligned points) 的数量的概率, 如果 NFA 的值很大, 表明当前区域属于背景的一部分; 如果 NFA 的值很小, 则表明当前区域越有可能是一个合适的直线。假设在一个尺寸为 $N \times N$ 的图像下, 直线段 A 的长度为 n , 且至少有 k 个像素点与直线段方向对齐, 则定义 A 的 NFA 如下式 3-14:

$$NFA(n, k) = N^4 \cdot \sum_{i=k}^n \binom{n}{i} p^i (1-p)^{n-i} \quad (3-14)$$

其中 N^4 代表在 $N \times N$ 图像中潜在的线段数, 概率 p 采用二项分布, 用于精确线的方向。根据这些定义, 我们在检验提取的线段时, 沿长度为 n 的线段计算每个像素的梯度角和对齐像素点 k 的数量。根据 $NFA(n, k)$ 判断是否接受该线段。




图 3-18 EDLines 直线检测

Figure 3-18 EDLinesline detection



图 3-19 剔除非倒角边缘线段

Figure 3-19 removing non chamfered edge segments

以上是使用 EDLines 直线段检测算法对轴承外侧面倒角进行检测的结果, 其中图 3-18 为 EDLines 检测的直线段, 图 3-19 为去除噪音线段后的检测的倒角边缘直线段。

通过对比 HoughLinesP 算法和 EDLines 算法的直线检测结果, 可以发现: HoughLinesP 算法需要指定边缘点之间的最小距离和直线段的最小长度参数, 具体使用时需要大量测试参数值, 而且该算法的时间复杂度和空间复杂度较高, 在检测过程中只能确定直线方向, 无法的直接得到线段的长度信息, 不利于后续对直线段选择。EDLines 直线算法有效解决了上述缺点, 由于它使用 ED 算法进行边缘检测, 并基于亥

姆霍兹准则验证检测的直线段，所以 EDLines 检测精度高、抗干扰能力强，误检率低、检测速度快。

3.1.3 圆检测算法

(1) 霍夫圆检测 (HoughCircles)

霍夫圆变换的原理与霍夫线变换原理类似，对直线检测而言，霍夫变换将直线方程以极径和极角 (r, θ) 方式表示，而对于圆来说，则需要用三个参数：圆心 (a, b) 、半径 r 表示，如下图 3-20 所示：




图 3-20 圆的表示

Figure 3-20 representation of circle

我们知道，在笛卡尔坐标系下，圆的方程表达式为：

$$(x-a)^2 + (y-b)^2 = r^2 \quad (3-15)$$

化简得到：

$$\begin{aligned} a &= x - r \cos \theta \\ b &= y - r \sin \theta \end{aligned} \quad (3-16)$$

所以，对于点 (x_0, y_0) ，我们可通过该点将所有的圆统一定义为：

$$\begin{aligned} a &= x_0 - r \cos \theta \\ b &= y_0 - r \sin \theta \end{aligned} \quad (3-17)$$

这样每一组 (a, b, r) 即可代表一个通过 (x_0, y_0) 点的圆。所以如图 3-21 所示，对于一个给定的点 (x_0, y_0) ，在三维直角坐标系中绘出所有通过它的圆则会形成一条三维的曲线。




图 3-21 过定点 (x_0, y_0) 的所有圆形成的曲线

Figure 3-21 curve formed by all circles passing through the fixed point (x_0, y_0)

如果将图像中任意两个不同点进行上述操作，其得到的曲线在 $a-b-r$ 空间相交，则说明这两点在同一个圆上。越多曲线交于一点，就代表这个交点表示的圆是由更多的点组成。与霍夫线检测相同，霍夫圆检测也是通过判断图像中每个点对应曲线间的交点数量是否超过阈值，来判断该点所代表的参数 (a, b, r) 在原图像中是否为一个圆。




图 3-22 HoughCircles 在不同条件下检测圆的结果

Figure 3-22 results of houghcircles detecting circles under different conditions

上图 3-22 为霍夫圆检测结果，其中图（a）显示是为采集的轴承端面原图；图（b）显示的是 HoughCircles 通过限制圆心坐标范围检测的圆；图（c）显示的是 HoughCircles 通过限制圆心坐标范围和累加面圆的判断阈值 $T=70$ 时检测得到的圆；图（d）显示的是 HoughCircles 通过限制圆心坐标范围和累加面圆的判断阈值 $T=170$ 时检测得到的圆。因此可以看出，针对轴承端面的同心圆检测问题，采用 HoughCircles 圆检测的方法需要人为设置多种参数，而且该算法检测的结果无法满足实际的检测要求。

（2）基于最小二乘法圆拟合算法

除了使用霍夫变换可以进行圆检测外，常用的圆检测方式还包括基于边缘检测和最小二乘法进行的圆检测。其中最小二乘法（Least Square Method）作为最常用的拟合算法之一，其目标是通过最小化误差的平方和，找到一组数据的最佳匹配函数。利用最小二乘法获取拟合圆参数的过程如下：

假设圆心为 (x_0, y_0) ，半径为 r ，则圆的方程表达式为

$$(x - x_0)^2 + (y - y_0)^2 = r^2 \quad (3-18)$$

展开后可得式 3-19：

$$x^2 + y^2 - 2x_0x - 2y_0y + x_0^2 + y_0^2 - r^2 = 0 \quad (3-19)$$

此时可将其改为：

$$x^2 + y^2 + ax + by + c = 0 \quad (3-20)$$

其中 $a = -2x_0$ ， $b = -2y_0$ ， $c = x_0^2 + y_0^2 - r^2$ 。所以只要求出参数 a 、 b 、 c ，就可以得到圆心和半径为：

$$\begin{cases} x_0 = -\frac{a}{2} \\ y_0 = -\frac{b}{2} \\ r = \frac{\sqrt{a^2 + b^2 - 4c}}{2} \end{cases} \quad (3-21)$$

设点集 (x_i, y_i) ， $i \in (1, 2, \dots, n)$ 为图像中圆上的点，则圆上的点到圆心的距离的平方为：

$$d_i^2 = (x_i - x_0)^2 + (y_i - y_0)^2 \quad (3-22)$$

为了减少计算复杂度，本文这里选择将 d 与半径 r 平方的差作为目标误差，从而可得：

$$s_i = d_i^2 - r^2 = x_i^2 + y_i^2 + ax_i + by_i + c \quad (3-23)$$

为了使目标误差的平方和 $f(a,b,c) = \sum s_i^2$ 最小，需要有 $\frac{\partial f}{\partial a} = \frac{\partial f}{\partial b} = \frac{\partial f}{\partial c} = 0$ ，将式 3-23 展开后得到的方程组为：

$$\begin{cases} \frac{\partial f}{\partial a} = \sum 2(x_i^2 + y_i^2 + ax_i + by_i + c)x_i = 0 \\ \frac{\partial f}{\partial b} = \sum 2(x_i^2 + y_i^2 + ax_i + by_i + c)y_i = 0 \\ \frac{\partial f}{\partial c} = \sum 2(x_i^2 + y_i^2 + ax_i + by_i + c) = 0 \end{cases} \quad (3-24)$$

解方程组后可以得到：

$$\begin{cases} a = \frac{BE - CD}{AD - B^2} \\ b = \frac{AE - BC}{B^2 - AD} \\ c = -\frac{\sum (x_i^2 + y_i^2) + a \sum x_i^2 + b \sum y_i^2}{n} \end{cases} \quad (3-25)$$

其中

$$A = n \sum x_i^2 - \sum x_i \sum x_i$$

$$B = n \sum x_i y_i - \sum x_i \sum y_i$$

$$C = n \sum x_i^3 - n \sum x_i y_i^2 - \sum (x_i^2 + y_i^2) \sum x_i$$

$$D = n \sum y_i^2 - \sum y_i \sum y_i$$

$$E = n \sum x_i^2 y_i - n \sum y_i^3 - \sum (x_i^2 + y_i^2) \sum y_i$$

根据上述的公式，通过遍历图像空间中圆上的像素点，即可得到圆心坐标

$$\left(-\frac{a}{2}, -\frac{b}{2}\right), \text{ 半径 } \frac{\sqrt{a^2 + b^2 - 4c}}{2}。$$

本文基于最小二乘法检测圆的流程如图 3-23 所示：




图 3-23 基于最小二乘法进行圆检测

Figure 3-23 circle detection based on least square method




图 3-24 基于最小二乘法进行同心圆环检测

Figure 3-24 concentric ring detection based on least square method

使用该方法进行同心圆环拟合过程及结果如图 3-24 所示，从图中可以看出上述圆

检测方法虽然可以检测到轴承端面的所有同心圆，但需要在检测过程中判断每个圆环的轮廓是否发生断裂，若发生断裂，则需要依据轴承各圆环的像素尺寸进行修补，这一过程相对较复杂，影响算法的检测速度，且造成该算法不具备较好的泛化性。

(3) EDCircles 圆检测算法

EDCircles 是一种无参数的圆检测算法^[53]。该算法首先利用 EDPF 计算边缘段，之后将其转换为转换成圆弧，用两种启发式算法将圆弧连接起来，检测候选圆和椭圆。最后基于 Helmholtz 准则，通过一个反向验证步骤对候选点进行验证，消除检测错误圆和椭圆。

其中 EDPF 边缘检测是将 ED 边缘检测的参数设置为极端值的形式，对于 ED 边缘检测来说，它有两个可调参数梯度阈值和锚点阈值。对于梯度阈值的设置，当使用 Prewitt 边缘检测算子时，在图像 P 点处的 x、y 方向梯度分别为：

$$\text{grad}_x(P) = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix} * P, \quad \text{grad}_y(P) = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix} * P$$

由此可得， $\text{grad}(n) * P = \sqrt{6^2 + 6^2} = 8.48$ 。

考虑到图像量化误差，将其值设置为 8.48。而对锚点阈值，为了不错过任何锚点，故将其值设置为 0。所以，EDPF 就是将梯度阈值和锚点阈值分别设置为 8.48 和 0 的 ED 边缘检测算法。

EDCircles 圆检测算法中的圆弧段检测原理为：首先算法约束每个圆弧段至少包含 3 条与之相切的直线段。在这种约束下，在边缘段的直线列表中，沿直线方向计算连续直线之间的角度以及两条直线的转向。如果至少有三条线在同一方向上旋转且线与线之间的角度满足设定阈值，则这些线可能形成圆弧。然后对提取出的一个弧段，直接进行圆拟合，如果拟合误差小于 1.5pix，那么就将这个弧段添加到后选中。否则，先从 3 个弧段开始，继续拟合，直到拟合误差超过 1.5 像素。

此外，该算法采用组合弧段方式进行候选圆和近圆椭圆检测。首先根据弧段的长度来对弧段进行排序，之后先从最长的弧段开始扩展，扩展时需保证两个弧段拟合出的半径小于等于该圆半径的 25%，圆心距小于等于该圆半径的 25%。在得到一个满足条件的组合后进行圆拟合，如果参与拟合的弧段角度张量超过圆的一半，则作为一个

圆候选, 否则将这些弧段进行近圆或近椭圆检测。

EDCircles 基于 Helmholtz 准则验证圆和椭圆的原理是以相邻像素的水平线角度是否与圆对齐为依据来判断相邻像素是否可以构成圆。而像素和圆对齐的定义为: 如果在圆的边界上的像素点 P 与对应的圆的切向方向对齐, 则称 P 与圆对齐。

下图 3-25 为 EDCircles 检测同心圆的结果:




图 3-25 EDCircles 检测同心圆

Figure 3-25 concentric circles detected by EDCircles

通过上述对三种圆检测算法的介绍, 根据相应的检测结果可以看出:

(1) 霍夫变换在进行圆检测时需要设置多组参数, 较为复杂。在对单个圆进行拟合时, 可能拟合出多个圆, 而且霍夫圆拟合无法检测同心圆。

(2) 通过轮廓检测和最小二乘法拟合圆的检测方法虽然可以得到比较好的检测效果, 但容易受噪音的影响, 拟合出的圆可能偏移图像中的实际位置, 而且在进行轮廓检测时, 如果圆环断裂, 则会导致轮廓闭合在一起, 无法使用最小二乘法拟合出同心圆环。即使通过圆环修补可以解决多圆环轮廓合并问题, 但算法流程复杂且耗时。

(3) EDCircles 算法一种基于 EDPF 的无参数边缘检测算法和组合式弧段进行候选圆检测, 且最后基于 Helmholtz 准则验证候选圆, 使得该算法可以轻松解决上述同心圆环检测问题, 且无需大量调参, 检测速度是上述算法的 10 倍以上。

3.2 轴承外侧面缺陷检测

轴承外侧面常见的缺陷类型包括黑斑、裂纹、锈蚀、擦伤、上下倒角不对称等, 如图 3-26 所示。由于在光源下轴承外侧面倒角轮廓与背景的对比度低以及倒角区域存在的缺陷的特征不明显, 所以该表面主要检测难点在于: ①上下倒角边缘轮廓高精度检

测；② 倒角部位缺陷检测。




图 3-26 轴承外侧面缺陷

Figure 3-26 defects on outer side of bearing

针对上述缺陷，本文采用的外侧面缺陷检测算法流程如图 3-27 为：




图 3-27 轴承外侧面缺陷检测流程

Figure 3-27 defect detection process of bearing outer side

这以图 3-26 中的 side5 为例，轴承外侧面缺陷具体检测步骤为：

（1）边缘检测

对于图像边缘检测，目前使用较多的是 Canny 算法。Canny 边缘检测算法虽然可以输出一个二值边缘图像，但其检测到的边缘像素通常是独立不相交的，这对后续直线检测带来很大的难度。故本文采用 ED（Edge Drawing）边缘检测算法，输出一组矢量形式边缘段，每个边缘段由一个连续的像素链组成，然后使用 Helmholtz Principle 对检测到的边缘进行验证，去除虚假边缘，降低误检率。检测结果如图 3-28 所示：




图 3-28 ED 算法检测图像边缘

Figure 3-28 edge detection of image by ED algorithm

（2）直线拟合

在检测完轴承外侧面边缘轮廓后，需要对轴承外侧面的倒角部分进行直线段拟合。在直线检测算法中，虽然霍夫线变换（HoughLines）应用较为广泛，但其算法时间复杂度和空间复杂度高，并且在检测过程中只能确定直线方向，丢失了线段的长度信息，且需要大量测试以设置多个参数的阈值。所以本文使用 EDLines 算法进行直线检测，其检测结果（图 3-28）与 LSD 直线检测结果非常相似，包含有图像中所有主要的线段检测，并存在极少数误报，检测速度极快。其检测流程为：

- 1) 获取 ED 算法产生像素链，即边缘。
- 2) 采用最小二乘线拟合法，从生成的像素链中提取线段。
- 3) 使用 Helmholtz principle 检验提取的线段。




图 3-29 EDLines 算法检测倒角边缘的直线段

Figure 3-29 straight line segment of chamfer edge detected by edlines algorithm

利用 EDLines 虽然可以较好的检测到图像中的直线，如上图 3-29 所示。但由于轴承外侧表面存在各种缺陷，导致检测到的直线段存在断续性和少量非倒角直线段，需剔除非倒角直线段。针对这一问题，本文获取倒角直线段的方法为：

1) 遍历 EDLines 算法检测的直线段集合，统计每个直线段的长度 L 和方向 θ （与水平线夹角）；

2) 去除方向（这里的 θ 指检测的直线与水平线夹角） $\theta > 0^\circ$ 且 $\theta < 180^\circ$ 的直线段以及 $L < 150$ 像素的直线段，得到结果如图 3-30 所示；



图 3-30 对直线段集合筛选后的结果

Figure 3-30 results of screening straight line segment set

3) 由于噪音的存在，导致 EDLines 算法检测的倒角的边缘直线不能连续，存在一些近似同一水平方向的直线段。针对这一问题，本文通过对筛选后的直线段数组按其线段中点在图像坐标系中的纵坐标大小进行排序，然后将数组中第一个元素 L_1 与最后一个元素 L_n 比较，计算两直线段元素中点在垂直方向的距离 d 和线段方向差值；若不满足条件阈值，则将 L_1 与 L_{n-1} 进行比较计算；直到与 L_i （其中 $i=1,2,3,\dots,n$ ）比较结果满足条件阈值，说明 L_1 和 L_i 近似在同一水平方向上；然后继续对 L_{i+1} 按从后往前的顺序进行计算对比，最后将近似位于同一水平方向的直线段进行合并，得到轴承外侧面上下倒角边缘直线段，结果如图 3-31 所示。



图 3-31 同一水平方向的直线段合并结果

Figure 3-31 results of merging straight line segments in the same horizontal direction

3. 倒角宽度计算

根据上一步得到的轴承外侧倒角直线段，很容易计算的到轴承外侧面上倒角和下倒角的亚像素宽度，如图 3-32 所示。当对上下倒角宽度的差值满足设定阈值 T ，则认为倒角满足对称性要求；否则，不满足对称性要求，视为倒角瑕疵品。



图 3-32 倒角宽度检测结果

Figure 3-32 measurement results of chamfer width

4. 倒角区域和非倒角区域提取

根据上述获取的轴承外侧面上上下倒角边缘直线信息，我们需要分别提取轴承外侧面的倒角区域和非倒角区域。这里假设图像的宽、高为 w_0 、 h_0 ，四条倒角边缘直线段的在图像垂直方向的坐标依次为： h_1 、 h_2 、 h_3 、 h_4 ，故可得到轴承外侧面非倒角区域矩形坐标为： $cv::Rect(0, h_2, w_0, h_3 - h_2)$ ；倒角区域矩形坐标分别为： $cv::Rect(0, h_1, w_0, h_2 - h_1)$ 、 $cv::Rect(0, h_3, w_0, h_4 - h_3)$ 。由此便可根据图像逻辑与运算分别提取轴承外侧面的倒角区域和非倒角区域，如图 3-33 所示。



(a) 轴承外侧面非倒角区域



(b) 轴承外侧面倒角区域

图 3-33 轴承外侧面倒角区域和非倒角区域提取

Figure 3-33 extraction of chamfered area and non chamfered area on the outer side of bearing

5. 缺陷检测

对于轴承外侧面存在缺陷的检测问题，通过上述图像处理，最后本文采用 Blob 分析方法进行缺陷检测，具体过程为：首先，分别将上述得到的倒角区域和非倒角区域进行二值化操作以实现分割出缺陷区域，并通过 Opencv 中的轮廓检测算法的 `cv::findContours()` 函数获取缺陷轮廓信息（轮廓长度 Length、轮廓面积 Area、最小外接矩形的长宽比 k 等），然后根据缺陷轮廓信息对表面缺陷进行判别和定位，检测结果如图 3-34 所示：




图 3-34 轴承外侧面缺陷检测结果

Figure 3-34 inspection results of defects on the outer side of bearing

采用上述检测过程对图 3-26 中所示的轴承外侧面进行检测的结果如图 3-35 所示，从图中可以看出采用轴承外圈外侧面倒角区域和非倒角区域存在的缺陷均可以被很好的检测出。



图 3-35 对图 3-26 中的轴承外侧面缺陷检测结果

Figure 3-35 inspection results of bearing outer side defects in Figure 3-26

3.3 轴承内侧面缺陷检测

轴承内侧面主要存在锈蚀、黑斑等缺陷，其算法检测流程如下图 3-36 所示：




图 3-36 轴承内圈缺陷检测流程

Figure 3-36 defect detection process of bearing inner ring

具体检测算法为：

(1) 提取图像中的 ROI 区域

由于采集的原图像分辨率为 2592×1944 ，检测区域在整个图像中的比例较小，所以为减少图像处理的计算量和排除背景信息的干扰，需要对轴承内圈侧面图像设定 ROI。本文首先通过设定一个阈值进行图像二值化，然后根据轮廓检测寻找待检区域的外接矩形，实现 ROI 的粗定位，最后在得到的外接矩形大小的基础上提取长宽各大 100 个像素 (pixel) 区域作为最终的 ROI，如图 3-37 所示。




图 3-37 提取的 ROI 区域

Figure 3-37 extracted ROI region

(2) 圆检测

本文采用 EDCircles 算法对上述 ROI 进行圆检测，首先，使用 5×5 的高斯核进行图像滤波，然后使用 EDPF 算法进行图像边缘检测。本文这里选择将 ED 算法参数设置为使用 Peritt 边缘检测算子，梯度阈值设置为 15，锚点(Anchor)阈值设置为 0。在这样的参数下一方面尽可能获取所需圆的边缘，另一方面可以消除原图像背景边缘信息，获得的图像边缘结果如下图 3-38 所示。根据上述得到的边缘链使用 EDCircles 算

法进行候选圆检测，最后基于 Helmholtz Principle 验证候选圆，删除检测错误的圆。下表 3-1 为 EDCircles 检测轴承内侧面图像同心圆参数：

表 3-1 轴承内侧面同心圆参数

Table 3-1 concentric circle parameters of bearing inner		
序号	圆心 (x,y)	半径 r
0	(674.023, 471.761)	176.478
1	(674.568, 446.593)	140.520




图 3-38 EDCircles 检测的同心圆

Figure 3-38 concentric circles detected by edcircles

(3) 提取待检的圆环区域

根据上一步检测的圆环参数，我们可以生成一个圆环的模板（图 3-39），如下图所示，然后使用图像处理中的与运算提取待检测轴承内圈侧面区域（图 3-40）。




图 3-39 圆环模板

Figure 3-39 template of ring




图 3-40 提取的圆环区域

Figure 3-40 extracted ring region

(4) 缺陷检测

当提取到的待检测圆环区域，我们便可进行 Blob 分析，实现缺陷的检测。其过程为：首先通过计算 ROI 区域的像素均值，并依据像素均值进行图像二值化，分割出图像中缺陷区域和背景区域。接着我们便可以通过形态学操作消除图像中的噪声空洞，然后通过轮廓检测算法得到缺陷 Blob 的轮廓边缘点集，根据该点集可以计算出获取缺陷区域的像素面积和轮廓长度等信息，这些信息进而帮助我们进一步判断该区域是否为要求检测的缺陷，最后轮廓的最小外接矩形进行缺陷区域标注，下图 3-41 为轴承外圈侧面缺陷检测的结果。




图 3-41 该轴承内侧面检测结果

Figure 3-41 inspection results of the inner side of the bearing

使用该算法对其它轴承进行批量检测的结果如下图 3-42 所示：




图 3-42 轴承内侧面批量检测结果

Figure 3-42 batch test results of bearing inner side

3.4 轴承端面缺陷检测

由于轴承端面存在的黑斑、裂纹、锈蚀、擦伤以及倒角尺寸、防尘盖的凹坑、字符、是否浮盖等多种缺陷，所以这两个工位的检测算法相对较复杂。图 3-43 所示为轴承端面图像，根据其结构可分端面为轴承外圈区域、轴承盖槽区域、轴承防尘盖区域以及轴承内圈区域。所以检测时可以根据这种划分将轴承端面分割成不同区域，分别进行缺陷检测，避免其他表面特征对检测造成干扰。




图 3-43 轴承端面区域组成

Figure 3-43 composition of bearing end face area

根据第三章叙述的图像采集方案可知，轴承端面检测采用多类型组合式光源进行连续频闪采集，总共得到 6 张图像，分别为：1 张环光图像、1 张低角度光图像和 4 张分区段多角度图像，如下图 3-44 所示。端面存在的多数缺陷均可在环形光源下进行检测，而对于倒角磨削尺寸和防尘盖表面“凹坑”缺陷，则需在低角度环形光源和分区点光源下进行检测。

通过下图 3-44 我们可以看出：轴承正反端面的检测难度存在以下几方面：

① 同心圆的检测,其检测精度影响圆环分割精度，导致一些位于边缘上的小尺寸缺陷出现漏检现象。同时影响极坐标变换，产生边缘“弯曲”现象，双线性插值消除边缘“锯齿”现象；

② 由于轴承防尘盖表面刻印有轴承型号字符，这对缺陷检测产生一定的干扰，故在检测时需要对字符区域进行遮盖。

③ 轴承防尘盖表面的凹坑缺陷具有特征尺寸多样性，而且普通的正向和背向打光

无法提高缺陷的特征的显著性)；




图 3-44 工位 3/4 图像采集结果

Figure 3-44 image acquisition results of station 3 / 4

考虑到上述的检测难点和轴承端面的图像组成结构以及缺陷分布，轴承端面整体缺陷检测流程如下图 3-45 所示。




图 3-45 轴承端面缺陷检测流程

Figure 3-45 defect detection process of bearing end face

本节只介绍检测流程中环光图像下缺陷检测算法和低角度光源下的倒角缺陷检测算法。而多角度光源下的基于 YOLO v3 的轴承防尘盖表面凹坑缺陷检测算法将在下一节中详细介绍。

1. 环形光源下的缺陷检测

(1) 同心圆检测

根据本章第 3.1.3 节对霍夫圆检测和 EDCircles 圆检测算法分析对比，这里采用 EDCircles 圆检测算法检测轴承端面的同心圆，其检测同心圆的算法流程如下：

1) 首先，利用 EDPF 算法进行边缘段检测，提取完整的圆和椭圆。然后将剩余的边缘段转换为线段，用组合线段法来检测圆弧，并将检测到的圆弧尝试连接在一起进行候选圆检测，当圆弧段无法连接成圆时则进行近似圆形的椭圆候选对象检测。最后使用 Helmholtz Principle 验证候选圆/椭圆。去除错误的候选圆/椭圆，输出剩余的有效圆/椭圆。

下图 3-46 为 EDPF 检测边缘和 EDCircles 检测圆结果：




图 3-46 采用 EDPF 边缘检测和 EDCircles 圆检测结果

Figure 3-46 results of EDPF edge detection and edcircles circle detection

使用 EDCircles 算法对上面两个轴承图像进行圆检测到的所有圆心和半径，结果如下表 3-2 所示。

(2) 圆环区域分割提取：

根据上述检测到的圆，我们便可根据圆心 (x, y) 和半径 r 对轴承的端面进行分割提取。本文的采用的检测算法是将轴承端面分为三部分分别进行缺陷检测，即轴承外圈圆环面、内圈圆环面和防尘盖圆环面。但是从上一步的检测结果我们可以发现，EDCircles 算法将图像中的非轴承轮廓圆也检测出来，这对于我们分割轴承各圆环区域是不利的。所以在分割圆环区域前，我们需要对检测到的圆心和半径进行筛选，以得到我们需要的圆心 (x, y) 和半径 r ，筛选的步骤为：

1) 根据 EDCircles 算法检测得到的圆心和半径值，根据圆心坐标分布通过设定同心圆数量阈值剔除非轴承表面轮廓的圆；

2) 当得到轴承端面各圆的参数后，通过图像逻辑运算即可提取到轴承端面的各个圆环区域结果。

表 3-2 轴承 1 和轴承 2 采用 EDCircles 算法检测圆的圆心和半径

Table 3-2 the center and radius of the circle are detected by EDCircles algorithm
for bearing 1 and bearing 2

序号	圆心 (x_1, y_1)	半径 r_1	圆心 (x_2, y_2)	半径 r_2
0	(325.694, 252.437)	133.8940	(333.399, 255.699)	134.0100
1	(325.621, 252.439)	128.8870	(334.269, 256.041)	129.1170
2	(325.590, 253.279)	118.3520	(334.169, 256.027)	118.2550
3	(325.586, 252.929)	108.4970	(335.12, 256.107)	109.1640
4	(325.323, 251.657)	97.0441	(335.251, 255.734)	96.8481
5	(325.261, 251.493)	73.5762	(335.257, 256.128)	73.2754
6	(325.704, 252.365)	54.2721	(334.109, 256.224)	67.5120
7	(325.605, 252.507)	65.8055	(334.535, 256.674)	55.2003
8	(325.177, 252.176)	48.3225	(333.399, 255.699)	47.7386
9	(582.839, 251.555)	72.2810	(582.807, 251.612)	72.2893
10	(582.056, 251.794)	55.2548	(582.076, 254.186)	55.2466
11	(583.039, 252.168)	48.4843	(583.016, 252.456)	48.4168
12	(583.731, 251.916)	23.2075	(583.927, 251.850)	23.4215

根据上述的同心圆筛选方法进行同心圆分割提取的结果如下图 3-47 所示：




图 3-47 轴承端面圆环分割结果

Figure 3-47 ring segmentation results on bearing end face

(2) 防尘盖表面字符检测与识别

轴承防尘盖作为其端面的一部分，在基于 Blob 分析进行缺陷检测时，其表面的钢印字符对缺陷检测产生一定的干扰性，所以需要通过字符分割或字符检测定位的方式解决钢印字符对缺陷检测造成影响的问题。所以本文尝试使用最大稳定极值区域（MSER）进行字符分割，其中 MSER 算法是基于图像分水岭算法的思想进行图像中斑点的检测，它的计算公式为：

$$v(i) = \frac{|Q_{i+\Delta} - Q_{i-\Delta}|}{|Q_i|} \tag{3-26}$$

其中， Q_i 表示阈值为 i 时的某一连通区域， Δ 为灰度阈值的微小变化量， $v(i)$ 为阈值是 i 时的区域 Q_i 的变化率。当 $v(i)$ 为局部极小值时，则 Q_i 为最大稳定极值区域。

根据 MSER 算法检测到字符的矩形框可能存在一定的重叠性，故需要采用 NMS（非极大值抑制）以获取字符区域的最佳矩形框。本文首先将所有的检测框得分进行排序，选中得分最高的框；然后遍历计算其余检测框和当前最高分的框的重叠面积（IOU），当 IOU 大于设定阈值时，则将原来的框删除；然后循环这个过程，最后得到每个字符的最佳矩形区域，如图 3-49 所示。




图 3-48 对 MSER 算法检测结果进行非极大值抑制 (NMS)

Figure 3-48 non maximum suppression (NMS) on the detection results of MSER algorithm

通过上图 3-49 可以发现，当防尘盖表面“凹坑”缺陷深度较浅时 MSER 算法可以实现较好的检测到字符，但对于缺陷较深且位于字符区域时则无法检测到字符区域，故 MSER 算法不适合本系统的检测需求。而本文对轴承防尘盖表面字符识别的流程如下图所示 3-50 所示。



图 3-49 MSER 算法进行字符检测定位

Figure 3-49 MSER algorithm for character detection and location

首先，使用单字符模板进行旋转匹配，获得图像的旋转角，使字符区域位于图像的正上方或正下方，然后对旋转后的图像进行图像极坐标变换。这是因为轴承防尘盖

表面的字符呈圆弧状分布，如果直接进行字符识别，会导致某些字符出现识别错误，如 6 和 9、N 和 Z。所以需要通过图像极坐标变换使圆环上的字符分布在同一水平线上，避免某些弧形字符无法区分。接着通过 OCR 技术对图像中的字符进行检测和识别，从而可以判断轴承防尘盖表面的字符是否存在缺陷问题。此外，通过字符检测我们可以得到矩形图像中单字符区域的位置，最后再通过极坐标逆变换即可得到字符的掩膜，避免字符特征对后续表面缺陷造成干扰。




图 3-50 字符检测和识别流程图

Figure 3-50 flow chart of character detection and recognition

下面本文对轴承防尘盖表面字符检测、识别的过程进行详细介绍。我们知道，极坐标系和平面直角坐标系之间的转换关系为：

$$\begin{cases} x=r \cdot \cos \theta \\ y=r \cdot \sin \theta \end{cases} \quad (3-27)$$




图 3-51 图像极坐标变换的原理

Figure 3-51 principle of image polar coordinate transformation

如上图 3-51 所示，图像极坐标变换的原理就是找到方图上任一点 $P(m,n)$ 在圆图上对应的点 $P(u,v)$ ，然后通过插值算法将圆图上所有像素点在矩形图上进行赋值，其具体变换关系为：

假设左图的圆的极径为 r 和极角为 θ ，右图的矩形图像行列数分别为 M 、 N ，则左图圆的每条半径对应着右图矩形的每一列，且圆在半径方向存在的长度缩放因子为 $\delta_r = M/r$ ，在圆周方向上存在的角度因子 $\delta_\theta = 2\pi/N$ 。

我们知道图像上任意一点 P 在图像坐标系和世界坐标系之间的变换关系为：

$$\begin{cases} x = u - r \\ y = r - v \end{cases} \quad (3-28)$$

而左图世界坐标系中的点 $P(x,y)$ 对应圆的半径长度 r 和与水平线夹角 θ 。

$$\begin{cases} r = \sqrt{x^2 + y^2} \\ \theta = \arctan(\frac{y}{x}) \end{cases} \quad (3-29)$$

所以，左图圆上每一点 $P(u,v)$ 在右图矩形上对应行数和列数计算公式为：

$$\begin{cases} m = \frac{r}{\delta_r} = \frac{r^2}{M} \\ n = \frac{\theta}{\delta_\theta} = \frac{\theta N}{2\pi} \end{cases} \quad (3-30)$$

然而由于从原图像到极坐标图像的转换中，并非所有的点都可以一一对应，所以需要极坐标图中的点进行插值操作。常用的插值方法有：最临近插值算法和双线性内插值算法，其中最临近插值算法是通过像素值进行“四舍五入”以实现图像的缩放，这可能会造成生成图像在灰度变化处出现明显的锯齿状，效果不好。而双线性内插值算法是利用原图中某一点周围的四个真实存在的像素值来共同决定该点的像素值，因此其该方法实现的缩放效果比最邻近插值算法要好。故本文选择使用双线性插值法进行极坐标变换。

双线性内插值是分别在两个方向进行线性插值，如图 3-52 所示，根据 $S_{11} = (x_1, y_1)$ 、 $S_{12} = (x_1, y_2)$ 、 $S_{21} = (x_2, y_1)$ 、 $S_{22} = (x_2, y_2)$ 四个点的像素值便可求得点 $P(x,y)$ 处的像素值，其求解步骤为：




图 3-52 双线性插值原理

Figure 3-52 principle of bilinear interpolation

首先在 x 方向进行线性插值，可以得到

$$\begin{aligned} f(A_1) &\approx \frac{x_2 - x}{x_2 - x_1} f(S_{11}) + \frac{x - x_1}{x_2 - x_1} f(S_{21}) \\ f(A_2) &\approx \frac{x_2 - x}{x_2 - x_1} f(S_{12}) + \frac{x - x_1}{x_2 - x_1} f(S_{22}) \end{aligned} \quad (3-31)$$

其中 $A_1 = (x, y_1)$, $A_2 = (x, y_2)$ 。

然后再沿着 y 轴方向进行线性插值，可以得到：

$$f(P) \approx \frac{y_2 - y}{y_2 - y_1} f(A_2) + \frac{y - y_1}{y_2 - y_1} f(A_1) \quad (3-32)$$

由此可求得 $f(x, y)$ 为：

$$\begin{aligned} f(x, y) &\approx \frac{f(S_{11})}{(x_2 - x_1)(y_2 - y_1)} (x_2 - x)(y_2 - y) + \frac{f(S_{21})}{(x_2 - x_1)(y_2 - y_1)} (x - x_1)(y_2 - y) \\ &+ \frac{f(S_{12})}{(x_2 - x_1)(y_2 - y_1)} (x_2 - x)(y - y_1) + \frac{f(S_{22})}{(x_2 - x_1)(y_2 - y_1)} (x - x_1)(y - y_1) \end{aligned} \quad (3-33)$$

下图 3-53 所示为轴承端面进行极坐标变换的一些结果。

此外，从图 3-54 可以看出，经过双线性插值后的其图像边缘线相对平滑，不会出现因灰度像素突变产生的“锯齿”现象。




图 3-53 原图进行极坐标变换结果

Figure 3-53 polar coordinate transformation results of the original image




图 3-54 局部放大图像

Figure 3-54 partially enlarged image

在进行图像极坐标变换时，其图像展开的起始位置为默认为水平 0° ，如果我们直接对随机分布的轴承图像进行极坐标转换时，会出现字符被分割成两半的现象，如图 3-55 所示。所以在进行图像极坐标变换前，需要对图像进行一定角度的旋转，初始化字符区域的位置。




图 3-55 未经初始化旋转后的图像极坐标变换的结果

Figure 3-55 result of image polar coordinate transformation after uninitialized rotation

为解决这一问题，我们选择将字符区域统一旋转至图像 $\pm 90^\circ$ 区域附近。其方法是利用旋转模板匹配算法计算图像初始化旋转角度 θ ，通过获取单字符的旋转角度得到整个图像的旋转角度。具体过程为：首先，从一张字符区域正好位于正上方和正下方的图像提取单字符模板图，如下图 3-56（a）所示。然后基于模板匹配算法进行单字符匹配，从而获得单字符模板在图像中的位置信息。但普通基于滑动窗口的模板匹配算法的是通过计算滑动窗口与模板图像的像素距离进行匹配。当图像中的待匹配物体与模板存在角度差时，此时两者的相似性度量值变得很低，导致无法完成匹配。此外，这种模板匹配在进行旋转匹配时，由于需要对每次旋转的结果都进行匹配，导致完成最终的匹配十分耗时




图 3-56 图像初始化旋转

Figure 3-56 image initialization rotation

针对上述问题，本文采用一种基于图像轮廓的多角度模板匹配算法解决该问题。其原理是首先将待匹配图像和模板图像进行二值化，然后提取模板和匹配图像的轮廓，然后在轮廓图像上进行旋转模板匹配。匹配时本文采用多阶段匹配方式进行，从而缩短匹配时间，具体过程为：首先以图像中心为旋转轴将模板以 90° 步长进行旋转匹配，选取匹配度最高的角度范围；然后以 30° 为步长进行旋转匹配，选取匹配度最高的角度范围；接着以 10° 为步长，选取匹配度最高的角度范围，最后以 2° 为步长进行旋转模板匹配。这样只需匹配 12 次即可完成匹配，相比于基于像素值的旋转模板匹配，减少 168 次匹配，完成匹配的时间相当于减少了 1.4 倍。

此外，本文针对模板旋转时出现的模板尺寸变化问题使用的解决方法为：由于本文提出的基于轮廓的旋转模板匹配使用的是二值化轮廓图像，所以在完成一次旋转后，只需计算旋转后图像相比于最初模板图像的长宽增加的数值，对旋转后的图像进行裁剪，使其尺寸与模板图相等。

当初始化旋转完成后如图 3-56 (c) 所示，我们就可以根据之前检测的圆心和半径进行图像极坐标转换，变换的结果如图 3-57 所示：




图 3-57 经图像初始化旋转后的图像极坐标变换

Figure 3-57 result of image polar coordinate transformation after image initial rotation

Paddle-OCR 是百度研究院团队在 2020 年发表的一种端到端的文本识别、检测算法^[54]。该算法包含三部分，分别为文本检测，方向分类和文本识别。其中文本检测采用

目前，Paddle-OCR 官方提供的预训练模型分为两类，一类是基于移动端的轻量型模型，其大小仅 9.4M，另一类是基于服务器端的通用型模型，其大小为 143.4M。由于本系统需要识别的轴承表面字符相对简单，并且全是英文，所以选择轻量型的模型进行轴承字符训练。

在训练时，我们首先制作字符检测数据集，然后使用官方提供的标注工具（PPOCRLabel）进行字符的标注工作，并制作一个所要检测字符的字典，保存为.txt

文件。模型的训练过程共分为三步：1.训练字符方向模型；2.训练字符检测模型；3.训练字符识别模型。在训练完成后，会生成对应的三个模型分别存放在 cls、det、rec 文件夹中，每个文件夹分别包含三个模型相关文件，如图 3-58 所示。




图 3-58 生成的训练模型

Figure 3-58 generated training model

所以得到训练模型后，我们便可以利用得到的模型进行字符的检测与识别，如图 3-59 所示。



图 3-59 Paddleocr 字符检测与识别的结果

Figure 3-59 result of PaddleOCR character detection and recognition

对于上文中提到字符特征干扰轴承表面的缺陷检测问题，需要生成一张图像中字符区域的掩膜图，这时就可以利用 PaddleOCR 的字符检测结果进行掩膜图像的生成。由于本文检测是在极坐标变换后的图像上进行的识别，所以生成的字符掩膜图需要利用图像极坐标逆变换映射到原图像上。

这里图像极坐标逆变换与图像极坐标变换的原理相同，即在圆图上找到方图上所有的对应点，此时不再需要插值算法，得到的结果如图 3-60 所示：




图 3-60 图像极坐标逆变换生成掩膜图像

Figure 3-60 mask image generated by inverse polar coordinate transformation of image

(3) 缺陷检测

当提取到的待检测圆环区域，我们便可进行 Blob 分析，实现缺陷的检测。其过程为：首先，通过计算 ROI 区域的像素均值，并依据像素均值进行图像二值化，分割出图像中缺陷区域和背景区域。接着通过形态学操作消除图像中的噪声空洞，然后利用轮廓检测算法得到缺陷 Blob 的轮廓边缘点集，根据该点集可以计算出获取缺陷区域的像素面积和轮廓长度等信息，这些信息进而帮助我们判断该区域是否为缺陷，最后如图 3-61 所示，使用轮廓的最小外接矩来标注缺陷区域。



图 3-61 Blob 分析进行缺陷检测结果

Figure 3-61 results of defect detection by Blob analysis

使用上述算法检测批量缺陷检测结果如图 3-62 所示：




图 3-62 环形光源下轴承端面缺陷检测结果

Figure 3-62 inspection results of end face defects of bearing under circular light

2. 低角度环形光源下的倒角磨削尺寸和浮盖检测:



图 3-63 低角度光源下的轴承端面倒角和盖槽区域

Figure 3-63 bearing end face chamfer and cover groove area under low angle light

如上图 3-63 所示，低角度光源下，轴承的倒角区域的即图像中两个红色的圆环区域。由于加工轴承的内外圈倒角时，常见的缺陷问题主要为倒角的宽度尺寸，即多磨或少磨。本文检测倒角上存在的缺陷是通过检测图像中倒角区域的圆环宽度大小判断是否存在缺陷。所以具体的检测流程为：

(1) 圆检测

这里同样使用 EDCircles 进行同心圆的检测，检测得到的圆心和半径的参数如下表 3-3 所示，结果如图 3-64 所示。

表 3-3 EDCircles 检测的圆心和半径值

Table 3-3 values of circle center and radius detected by EDCircles

序号	圆心 (x,y)	半径 r
1	(687.484, 445.394)	101.552
2	(687.180, 446.038)	110.347
3	(687.438, 446.128)	131.273
4	(687.414, 446.037)	136.818
5	(687.090, 446.602)	198.141
6	(687.382, 446.951)	206.330
7	(687.112, 446.861)	235.358
8	(687.199, 446.312)	259.180
9	(687.690, 446.045)	269.042




图 3-64 EDCircles 算法检测同心圆的结果

Figure 3-64 results of concentric circles detected by edcircles algorithm

(2) 筛选所需圆

本算法旨在检测轴承倒角磨削宽度和浮盖缺陷，所以需要对上一步检测的圆进行筛选。根据上述分析可知，检测所需的圆为：筛选算法为：首先创建一种圆参数结构体，然后将检测到的圆结构体存到一个数组中，然后按半径大小进行排序；根据上表 3-3 可知，我们检测倒角所需圆为序号 2 和序号 8，这时我们可以通过获取数组中最大半径和最小半径的索引，即可相应得到所需圆参数（表 3-4）的索引。

表 3-4 倒角检测所需同心圆参数

Table 3-4 concentric circle parameters required for chamfer detection

序号	圆心 (x,y)	半径 r
2	(687.180, 446.038)	110.347
8	(687.199, 446.312)	259.180

(3) 根据环宽像素值判断是否存在缺陷

首先需要轴承的实际尺寸设定在低角度光源下轴承外圈和内圈圆的半径。本文这里根据每个像素代表的实际尺寸将其分别设置 $R_1 = 260$ 和 $R_2 = 90$ ，如下图中绿色圆所示。最后根据筛选出圆的参数，即可计算出倒角在图像中的宽度分别为 $W_1 = 9.180$ ， $W_2 = 10.347$ ，满足检测条件。

图 3-65 所示为低角度光源下轴承倒角尺寸和浮盖缺陷检测的结果。




图 3-65 低角度光源下轴承倒角尺寸和浮盖缺陷检测结果

Figure 3-65 inspection results of bearing chamfer size and floating cover defects under low angle light

而浮盖缺陷的检测原理即是在二值化后图像上统计图 3-63 中绿色圆环区域（盖槽区域）中的白色像素所占面积来判断是否存在浮盖缺陷。而图像中浮盖缺陷的特征表现如下图 3-66 所示：




图 3-66 轴承端面浮盖缺陷对比

Figure 3-66 Comparison of defects of bearing end face floating cover

下图 3-67 为浮盖缺陷检测的结果显示：




图 3-67 轴承压盖缺陷检测

Figure 3-67 inspection of bearing gland defects

3.5 本章小结

本章详细介绍了系统缺陷检测的算法，通过采用传统图像处理算法中边缘检测、圆检测、直线检测实现轴承各表面图像的区域分割，然后基于 Blob 分析法对各表面常见的缺陷进行检测，最后对轴承各表面的检测结果进行了展示。

4. 基于改进 YOLO v3 算法的防尘盖表面凹坑缺陷检测

针对轴承防尘盖上存在的凹坑缺陷具有形状尺寸不一，特征表现形式不定的特点，传统图像处理算法难以实现该类缺陷的检测。本章将从以下四个方面：现有的目标检测算法、数据集的准备、检测网络的改进与训练、检测实验分析与对比，介绍使用本文改进的 SFCS-YOLO v3 目标检测算法实现轴承防尘盖表面凹坑缺陷检测。

4.1 目标检测算法的介绍

在计算机视觉领域，目标检测作为一种对图像中感兴趣目标进行识别和定位的技术，主要用于解决图像中目标的位置和类别问题，其难点在于检测目标物体存在尺寸不一、姿态角度不定、分布位置随机以及类别繁多的特点。

目前，随着深度学习技术的发展以及各种大型数据集的公开，涌现出越来越多性能优秀的目标检测算法。在 2014 年 R-CNN 框架的提出后，目标检测算法逐渐转变为借助卷积网络（CNN）进行特征提取进而实现目标的分类与识别^[55]。其中以 R-CNN、fast R-CNN、faster R-CNN 为代表的两阶段（two-stage）目标检测算法，其通过显式的候选框（resign proposal）机制将检测问题转化为对候选区域内局部图像的分类问题，但由于候选框的数量较多，致使这类检测算法的检测精度高而速度较慢，无法满足实时检测需求^[56,57]。而以 YOLO 和 SSD 为代表的一阶段（one-stage）目标检测算法^[58]。它将目标检测任务直接以回归的方式得到物体的类别概率和位置坐标信息。这类算法相比于两阶段的检测算法，虽检测精度略低但检测速度较快。由于本系统对检测速度有较高的需求，所以重点考虑使用一阶段（one-stage）目标检测算法实现对轴承防尘盖表面的凹坑缺陷的检测。

YOLO v3 是 Joseph Redmon 等人提出的一种端到端的目标检测算法。其检测原理是将输入图片分割为 $S \times S$ 的网格（grid）区域，如下图 4-1 所示，每个网格负责检测中心点落在其内的目标。对于需要预测的目标，每个网格会预测出 B 个边界框（bounding box）和边界框的置信度（confidence score），这里的置信度包括边界框含有

目标的可能性 $Pre(obj)$ 和边界框的准确度。边界框的准确度可以使用预测框 pre 与实际框 GT 的交并比 (IOU) 表示, 即 IOU_{pre}^{GT} 。所以边界框的置信度等于 $Pre(obj) * IOU_{pre}^{GT}$ 。边界框的位置与大小, 是由边界框的中心坐标 (x, y) 和边界框的宽 w 、高 h 表示, 即 (x, y, w, h) 。中心坐标预测值是相对于每个网格单元左上角坐标点的偏移量, 而边界框的 w 和 h 的预测值是相对于整个图片的宽高。这样每个边界框的预测值由 5 个元素组成 (x, y, w, h, c) , c 指的是边界框的置信度。而对于类别问题, 每个网格需要预测出 C 个类别的概率值, 表示该网格负责预测的边界框在置信度 $pre(\frac{class_i}{obj})$ 条件下属于各个类别的概率。所以, 对于图像中的 $S \times S$ 个网格, 最终需要预测值的数量为 $S \times S \times (B \times 5 + C)$ 。




图 4-1 YOLO v3 目标检测原理[37]

Figure 4-1 YOLO v3 target detection principle [37]

YOLO v3 是在 YOLO v1、YOLO v2 目标检测算法上的改进检测算法^[59,60]。改进点包括:

1) 采用多尺度融合预测的方案, 提高对小目标的检测精度。YOLO v3 通过 FPN 操作将下采样得到的特征图 (feature map) 进行多尺度融合, 分别得到 13×13 、 26×26 和 52×52 的三种尺度特征图, 这样可以实现对大、中、小目标的预测。

2) YOLO v3 将原来的单标签分类改为多标签分类, 可实现对重叠区域的分类和框

选。

3) YOLO v3 借鉴残差结构的设计思想, 使用 Darknet-53 作为主干特征提取网络 (backbone), 整个网络没有使用池化层 (pooling) 和全连接层(FC), 而是通过增加卷积核步长的实现下采样。

其网络结构如下图 4-2 所示。




图 4-2 YOLO v3 的网络结构

Figure 4-2 network structure of YOLO v3

YOLO v3 将目标检测当做回归问题进行处理, 所以采用的损失函数为均方差损失函数。网络的整体损失函数为:

$$loss_{total} = loss_{coord} + loss_{confidence} + loss_{class} \quad (4-1)$$

由上式可知, YOLO v3 的损失函数由三部分组成。包括:

(1) 边界框预测损失函数计算公式为:

$$loss_{coord} = \lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{obj} [(x_i - x'_i)^2 + (y_i - y'_i)^2] + \lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{obj} [(\sqrt{w_i} - \sqrt{w'_i})^2 + ((\sqrt{w_y} - \sqrt{w'_y})^2] \quad (4-2)$$

其中, 第一项表示边界框的中心坐标误差; 第二项表示边界框的高与宽的误差;

I_{ij}^{obj} 表示第 i 个网格存在目标且该单元格的第 j 个边界框负责预测该目标。

(2) 边界框置信度损失函数计算公式为:

$$loss_{confidence} = \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{obj} (C_i - C'_i)^2 + \lambda_{noobj} \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{noobj} (C_i - C'_i)^2 \quad (4-3)$$

(3) 分类损失函数计算公式为:

$$loss_{class} = \sum_{i=0}^{S^2} I_i^{obj} \sum_{c \in class} (p_i(c) - p'_i(c))^2 \quad (4-4)$$

这里的 I_i^{obj} 指的是第 i 个单元格存在目标。

4.2 数据采集与处理

本文通过对轴承防尘盖表面的凹坑缺陷特征进行分析,对多种图像采集方案进行测试,设计了一种多视角图像采集方案。该方案采用面阵工业相机和分区段光源进行数据采集,采集的图像如下图 4-3 所示。




图 4-3 采集的凹坑缺陷图像

Figure 4-3 collected pit defect images

通过上述图像采集方式,本文共采集 3500 张缺陷样本图片(图 4-4),包含不同尺寸和分布位置的凹坑缺陷。然后按照 YOLO v3 网络的输入要求制作相应的训练数据集。首先,如图 4-5 所示,使用 Labelme 标注工具对缺陷数据集进行标注,通过编写脚本程序,将 Labelme 标注生成的 json 格式文件转化为 VOC 数据集的标注格式 xml 格式文件(图 4-6),进而生成 train.txt 和 val.txt。接着从数据集中随机选择 2800 个样本并按照 9:1 的比例进行划分进行训练,将 2500 个样本作为训练集,300 个样本作为验证

集，最后将剩余的 700 个样本作为测试集已测试网络模型检测的效果。




图 4-4 凹坑缺陷数据集

Figure 4-4 data set of pit defects



图 4-5 图像标注

Figure 4-5 image annotation



图 4-6 数据集存放格式

Figure 4-6 data set storage format

4.3 YOLO v3 检测网络改进与训练

本文结合轴承防尘盖表面的凹坑缺陷在图像的表现特征，对 YOLO v3 网络进行了如下改进：

(1) 引入 SKNet 注意力机制，使网络能够自适应调整感受野^[61]。

本文考虑到轴承防尘盖表面同一缺陷存在不同的尺寸大小的差别。欲通过使用空间注意力机制是网络自适应调节卷积核的大小实现网络对不同尺寸缺陷的特征信息提取。SKNet 是一种对卷积核的注意力机制，它可以对不同尺度的特征图动态生成卷积核，以实现检测目标更好的关注。




图 4-7 SKNet 原理

Figure 4-7 principle of SKNet

由上图 4-7 可知，SKNet 由三部分组成，分别为：Split、fuse 和 Select。

其中，Split 部分是对输入特征图使用不同尺寸的卷积核 kernel 分别进行卷积操作。图中所示为分别使用 3×3 和 5×5 的卷积核对输入 $X(1, H, W, C)$ 进行卷积操作得到 U_1' 和 U_2' 。

Fuse 部分用于计算每个卷积核的权重。首先将 Split 得到的 U_1' 和 U_2' 特征图按元素相加求和得到 U ，然后通过全局平均池化（Global Average Pooling）操作生成通道（Channel）的统计信息，得到 S 其维度为 $C \times 1$ 。

$$S = F_{\text{gap}}(U) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=2}^W U(i, j) \quad (4-6)$$

然后，通过全连接层 F_{fc} 生成压缩的特征图 Z ，经过 softmax 操作得到每个卷积的权重分布 a 和 b 。

$$Z = F_{fc}(S) = f(\text{BN}(WS)) \quad (4-7)$$

其中， f 代表激活函数；BN 代表批标准化； $W=d \times C$ ， d 为全连接层处理后的特征维度

$$d = \max(C/r, L) \quad (4-8)$$

Select 部分是根据 Fuse 得到的不同权重卷积核计算输出特征图。即将 a 和 b 分别与 U_1' 和 U_2' 按元素相乘在相加得到输出特征图 X' ，这里的 $a+b=1$ 。

$$X' = a \otimes U_1' \oplus b \otimes U_2' \quad (4-9)$$

本文分别在主干提取网络中的残差块 Residual Block 和输出的三个不同尺度的特征图部分添加 SKNet 操作，添加后的网络结构如图 4-8 所示。




图 4-8 添加 SKNet 注意力机制的 YOLO v3 网络结构

Figure 4-8 network structure of YOLO v3 with sknet attention mechanism

(2) 在损失函数方面, 本文在 YOLO v3 中添加 focal loss^[62]损失和 CIOU^[63]损失, 分别用于解决类别不均衡和目标框回归不稳定的问题。针对本文需要检测的防尘盖表面凹坑缺陷, 其相对于整个轴承背景, 特征像素尺寸占比很小, 导致正、负样本不平衡。虽然本文通过多视角图像采集方案可以增加对缺陷的检测率, 但对于一些小尺寸的缺陷仍存在难以检测的问题。

Focal Loss 的计算公式:

$$Focal_loss(p_t) = -\alpha_t(1-p_t)^\gamma \log(p_t) \quad (4-10)$$

$$p_t = \begin{cases} p & y=1 \\ 1-p & y \neq 1 \end{cases}$$

其中, p_t 是每个类别的分类概率; 常量权重因子 α_t 是个 0-1 之间的值; 常量缩放因子 γ 是个大于 0 的值。

所以, 这里本文将置信度损失 (Confidence_loss) 的改为:

$$Confidence_loss = -\alpha_t(1-p_t)^\gamma \log(p_t) \quad (4-11)$$

$$p_t = \begin{cases} sigmoid(p) & y=1 \\ 1-sigmoid(p) & y \neq 1 \end{cases}, \quad \alpha_t = \begin{cases} \alpha & y=1 \\ 1-\alpha & y \neq 1 \end{cases}$$

此外, IOU 作为检测任务中最常用的指标, 是目标预测框与真实框之间交集与并集的比值, 故 IOU 对目标物体的尺度 (Scale) 并不敏感^[64], 而且在 YOLO v3 目标检测中对回归损失和 IOU 损失并不完全一样。而 CIOU 能够考虑到目标与锚点 (Anchor) 之间的距离、预测框与真实框的重叠率、目标物体的尺度以及惩罚项等因素, 使得网络对目标框的回归更加稳定, 所以本文选择在 YOLO v3 网络中使用了 CIOU 损失代替 IOU 损失。

CIOU 的计算公式为:

$$CIOU = IOU - \frac{\rho^2(B, B^{GT})}{c^2} - \alpha v \quad (4-12)$$

$$IOU = \frac{|B \cap B^{GT}|}{|B \cup B^{GT}|}$$

其中, $\rho^2(B, B^{GT})$ 是指预测框 B 与真实框 B^{GT} 的中心点的欧式距离; c 是指同时覆盖预

测框和真实框的最小矩形的对角线长度；而 α 和 v 的计算公式分别为：

$$\begin{cases} \alpha = \frac{v}{1 - IOU + v} \\ v = \frac{4}{\pi^2} (\arctan(\frac{w^{GT}}{h^{GT}}) - \arctan(\frac{w}{h}))^2 \end{cases} \quad (4-13)$$

所以，CIOU 损失函数为：

$$Loss_{CIOU} = 1 - CIOU = 1 - IOU + \frac{\rho^2(b, b^{GT})}{c^2} - \alpha v$$

(3) 改用 swish 激活函数

激活函数在深度学习网络中用于提高模型的非线性。我们知道，在卷积神经网络中，常用的激活函数有 *Sigmoid()*、*Tanh()*、*Relu()*、*LeakyRelu()* 等，其函数曲线如图 4-9 所示，其中前两者存在“饱和”问题，易发生梯度消失或梯度爆炸，而后两者在一定程度上改善了“饱和”问题。




图 4-9 Sigmoid、Tanh、Relu、LeakyRelu 四种激活函数曲线

Figure 4-9 four activation function curves of Sigmoid, Tanh, Relu, LeakyRelu

如下图 4-10 所示, $\text{Swish}()$ 激活函数类似 $\text{Relu}()$ 和 $\text{Sigmoid}()$ 激活函数的结合, 兼具两者一定的优点。

其计算公式为:

$$\begin{cases} f(x) = x \cdot \text{Sigmoid}(\beta x) \\ \text{Sigmoid}(x) = \frac{1}{1 + e^{-x}} \end{cases} \quad (4-14)$$

其中, 参数 β 可以是常量, 也可参与训练, 本文这里选择将 β 参与训练。




图 4-10 Swish ($\beta=10$) 激活函数的曲线

Figure 4-10 curve of activation function Swish ($\beta=10$)

4.4 检测结果分析与对比

本文在基于 Windows10 系统配置 NVIDIA GeForce RTX 2080Ti 显卡的平台上分别对 YOLO v3 原网络和本文改进网络对制作的轴承防尘盖凹坑缺陷数据集进行训练, 设置最大 epoch=200。

本文主要训练模型在测试集上得到的 mAP 值作为评价指标, 对比不同算法模型在相同迭代训练次数下的 mAP 值。其中 mAP 是指所有的类别 AP 值的平均值, 而 AP 指的是利用不同的精确度 (Precision) 和召回率 (Recall) 的点的组合出曲线与坐标轴包围的面积。对于二分类来说, 精确度是指分类器认为是正样本并且确实是正样本的部分占有所有分类器认为是正样本的比例, 式 4-15 为 Precision 的计算公式。

$$Precision = \frac{TP}{TP + FP} \quad (4-15)$$

其中，TP 表示分类器认为是正样本而且确实是正样本的例子，即真阳性样本；FP 表示分类器认为是正样本但实际上不是正样本的例子，即假阳性样本。

召回率是指分类器认为是正样本并且确实是正样本的部分占有确实是样本的比例，其计算公式为：

$$Recall = \frac{TP}{TP + FN} \quad (4-16)$$

这里的 FN 表示分类器认为是负样本但实际上不是负样本的例子。

下面是五种算法模型训练过程损失函数和测试集 mAP 的对比：

1. 原始 YOLO v3 算法 (YOLO v3)；
2. 添加 SKNet 注意力机制改进网络的 YOLO v3 算法 (SK-YOLO v3)；
3. 使用 FoacI_loss 和 CIoU 优化损失函数的 YOLOv3 算法 (FLC-YOLO v3)；
4. 使用 Swish 激活函数的 YOLOv3 算法 (S-YOLO v3)；
5. 同时添加 SKNet、FoacI_loss、CIoU 损失和 Swish 激活函数的 YOLOv3 算法 (SFCS-YOLO V3)。

如图 4-11 所示为上述 5 种网络在验证集上的损失变化曲线：




图 4-11 5 种网络在验证集的损失变化曲线

Figure 4-11 loss curves of five networks on the verification dataset

通过上图 4-11 可以看出，SFCS-YOLO v3 和 SK-YOLO v3 相比于原网络损失收敛

速度相对慢点,但最终损失值很低,S-YOLO v3 和 FC-YOLO v3 网络收敛的速度差不多。这里需要对上图中每个网络训练的次数不相同的情况进行说明:本文对每个网络训练均设置相同迭代次数($epoch = 200$),而为防止网络训练时出现过拟合,添加了提前结束训练的代码,所以当验证集上的损失值迭代一个 $epoch$ 而没有下降时,则认为网络即将过拟合,提前终止训练。

上述 5 个网络模型在验证集上的 mAP 结果如图 4-12 所示。可以看出 *Swish* 激活函数相比于 *LeakyRelu* 激活函数对网络的优化并不明显,加入 SKNet 注意力机制的 SK-YOLO v3 相比原网络 mAP 提升了 2.43%,基于 focal loss 和 CIOU 改进损失函数的 FC-YOLO v3 相比原网络 mAP 提升了 1.57%,而将所有的改进方法同时使用训练出的 SFCS-YOLO v3 相比原网络 mAP 提升了 5.08%。通过对比可以证明本文对 YOLO v3 改进的方法对模型检测精度提升是有效的。




图 4-12 上述五种模型在验证集上的 mAP 对比

Figure 4-12 comparison of map values of the above five models on the verification dataset

最终在验证集上测试结果如图 4-13 所示,本文改进的 SFCS-YOLO v3 网络模型的 AP=0.9154,在 $score_thresh = 0.5$ 时,检测精确度 $Precision = 0.9154$ 。




图 4-13 SFCS-YOLO v3 算法训练模型的 AP 和 Precision 评价结果

Figure 4-13 AP and Precision evaluation results of SFCS-YOLO V3 algorithm training model

该模型的实际检测结果如图 4-14 所示：




图 4-14 基于 SFCS-YOLO v3 检测模型的凹坑缺陷检测结果

Figure 4-14 pit defect detection results based on the SFCS-YOLO v3 detection model




图 4-15 不同方向光源下凹坑缺陷检测结果

Figure 4-15 inspection results of pit defects under lights in different directions

鉴于上述本文改进的 SFCS-YOLO v3 检测网络在验证集上的检测精确度只有 91.54%，说明仍存在一些缺陷无法被检测到。而且由于凹坑缺陷在防尘盖表面的分布存在随机性，且在不同方向的光源下表现的特征不同，很可能只有在某一方向的光源下具有较强的缺陷特征。如上图 4-15 所示，红色虚线矩形框标注为某一轴承防尘盖上凹坑缺陷在不同方向的光源下的缺陷特征。

所以本文提出一种多视角检测策略：在实际进行缺陷检测算法设计时，对于每个轴承，选择将采集光源四个照射角度下的图像均输入模型进行检测，在这种情况下，只要检测模型能够在一张图像上识别出缺陷，系统即可判断该轴承防尘盖表面存在缺陷问题，这种方式可以提升一定的准确率。

本文选择 200 个轴承未训练的凹坑缺陷轴承（150 个带缺陷，50 不带缺陷），分别采集光源四个照射角度下的图像输入检测模型进行测试，测试结果如下表 4-1 所示：

表 4-1 单视角检测与多视角检测结果的对比

Table 4-1 comparison of single view detection and multi view detection results

	轴承总数	检出 ng 数量	检出 ok 数量	准确率	误检率	漏检率
单视角	200	139	61	93.50%	6.50%	7.33%
多视角	200	147	53	97.50%	2.50%	2.67%

注 4-1) 误检率和漏检率是针对检出缺陷轴承进行统计，其中误检率是指 SFCS-YOLO v3 将非缺陷区域检测为缺陷区域；漏检率是指 SFCS-YOLO v3 存在未检测到的缺陷区域。

4.5 本章小结

本章针对轴承防尘盖表面存在的凹坑缺陷，首先通过打光测试制作了相应的无油轴承数据集，通过采用改进的 SFCS-YOLO v3 网络进行凹坑缺陷目标模型的训练，结合多视角检测方法提升原网络对轴承表面凹坑缺陷检测率，最终实现的轴承防尘盖表面凹坑缺陷的检测率约为 97.50%。

5. 轴承图像去油滴算法

本文将上一章节中训练的 SFCS-YOLO v3 凹坑缺陷检测模型应用于实际检测时，发现模型存在一定的误检，其原因是轴承在生产中表面附着有一定的油滴，且油滴在检测光源下表现的特征与凹坑缺陷特征极为相似，这使得原来训练的检测模型存在较大的误检率，本章将基于深度学习的方法从图像恢复角度出发，设计一种基于两阶段神经网络的轴承图像去油滴算法，解决图像中油滴对缺陷检测造成的干扰问题。

5.1 油滴的分布与影响分析

如下图 5-1 所示，轴承在生产中其表面会带有不同程度的油滴或油膜，这些油滴或油膜分布于轴承的各个表面，对表面缺陷检测存在一定的干扰。对于该问题有人尝试使用机械除油或人工除油的方式解决，但其除油效果并不佳，仍有部分油滴残留在轴承表面且除油的效率较低。




图 5-1 油滴对已有的凹坑缺陷模型造成的误检现象

Figure 5-1 false detection phenomenon caused by oil drop on the existing pit defect model

本文针对油滴造成缺陷检测的干扰问题，首先对轴承表面油滴在图像中的特征表现进行分析。我们使用分区段环形光源进行打光测试时，发现轴承表面的油滴或油膜的在光源下发生较强的反射现象，导致采集的轴承图像出现类似“过度曝光”的情况，使得轴承表面部分缺陷特征被减弱，而且油滴在图像中呈现的特征与凹坑缺陷极为相似，同样表现为具有亮暗灰度特征的斑块，如图 5-2 所示。本文尝试将带油滴的轴承图像数据作为正样本加入凹坑缺陷检测数据集中继续训练，但这种尝试并没有解决油滴误检问题，反而导致目标缺陷检测模型的精确度下降。所以本文选择从图像恢复



Figure 5-2 characteristic performance of oil droplets under light sources in different directions

5.2 基于两阶段的图像去油滴网络设计

图 5-3 基于两阶段的图像去油滴网络架构

Figure 5-3 Network architecture of image degreasing based on two stages

在图像恢复领域，许多人尝试使用两阶段网络进行图像处理，相比于单阶段网络的处理方法，两阶段网络的恢复效果更好。故本文尝试基于一种两阶段的神经网络实现轴承图像中的去油滴操作。其中第一阶段网络是基于 Attentive GAN 网络实现轴承图像油滴区域的粗恢复，Attentive GAN 网络通过 attention-recurrent network 生成的一张区域雨滴的 attention map，并使用它引导生成器网络和判别网络关注油滴区域以实现图像

去油滴，第二阶段是基于 AE-WGAN 网络对第一阶段生成的无油滴图像纹理细节进行精修复。整体网络架构如上图 5-3 所示：

5.2.1 轴承图像去油滴网络

为实现去除轴承图像上的油滴，本文首先尝试使用论文[42]提出的 Attentive GAN 网络以端到端的形式实现轴承图像油滴区域的去除。通过对论文[42]算法的复现，生成去雨滴图像的结果如图 5-4 所示：



图 5-4 Attentive GAN 去雨滴的效果

Figure 5-4 results of removing raindrops by attentive Gan

从上图 5-4 可以发现，该方法虽然可以对图像中绝大部分雨滴有较好的效果，但对于一些密集的大雨滴经模型处理后会留下雨痕，本文认为产生该现象的原因有两点：

(1) 由注意力递归网络（Attention-recurrent Network）生成的注意力图（Attention map）对不同形态的雨滴关注度不够；

(2) 生成器网络（Context Autoencoder）只进行了空间维度的注意力工作，没有对不同通道信息进行融合，且判别器（Discriminator）网络的深度太浅，导致无法判别生成图像与真实图像之间的细节纹理差别。

所以本文对该网络模型进行如下的改进工作：

- (1) 增加注意力递归神经网络（Attention-recurrent Network）的时间步数 N ;
- (2) 在生成器网络中引入 SENet^[65]注意力机制以及将判别器网络的深度提升到 256 维。

改进后的 Attention GAN 网络的结构如图 5-5 所示:




图 5-5 Attentive GAN 改进后的网络结构

Figure 5-5 improved network structure of Attention GAN

首先，在[42]论文中作者认为增加 LSTM 的时间步数 N 将可能得到更好的 Attention map，故本文选择将 N 设置为 5，以提高注意力递归神经网络对雨滴区域的关注度。

Attentive GAN 网络采用类似 UNet 网络^[66]结构的自编码器（Autoencoder）作为图像生成器（Generator），并将带雨滴图像与注意力递归神经网络生成的 Attention map 以通道拼接的方式输入生成器网络中，以生成网络可以识别到图像中雨滴区域。虽然这种方式可以使编码器（encoder）在图像空间维度进行更好的信息提取，但却没有对图像的多维通道信息进行整合，所以本文选择在生成器网络的下采样操作后添加 SENet 注意力机制模块，SENet 是一种通道注意力机制，它可以使卷积神经网络更加关注信息量较多的图像通道，并抑制一些不重要的通道特征，从而实现网络对不同的通道信息进行整合。

此外, Attentive GAN 网络的判别器是由 7 层卷积和 1 层全连接组成, 且该网络对生成图像的特征只提取到 128 维, 本文认为该判别器网络的深度太浅, 不能有效提取足够的多的高层语义信息, 尤其是对复杂的街景图, 导致判别器无法较好的判别生成图像和真实图像的全局内容一致性。所以本文选择将判别器网络的深度提升到 256 维, 并在 256 维度上进行注意力图的生成。




图 5-6 改进论文[42]实现去雨滴和去油滴的效果

Figure 5-6 improve paper [42] to achieve the effect of removing raindrops and oil drops

如图 5-6 所示, 虽然通过迁移学习训练的模型可以很好的实现图像中轴承表面的油滴的去除, 但在也存在以下问题:

- (1) 由于模型过度关注油滴区域而造成生成图像出现某种程度的退化, 包括原有的部分凹坑缺陷特征也被减弱;
- (2) 当油滴覆盖在防尘盖字符, 无法透过油滴观察到部分背景信息时, 在去油滴处理后将导致少量字符纹理特征缺失。

5.2.2 图像精修复网络

第二阶段是一种基于 AE-WGAN 图像精修复网络，其网络结构如下图 5-7 所示：

(1) AE-WGA 的生成器网络

图像精修复网络（AE-WGAN）的生成器采用类似 Unet 网络结构的卷积自编码器（Convolutional Autoencoder）。卷积自编码器作为常用的图像生成网络，其通过对输入图像下采样编码和上采样解码以实现图像的生成，本文在生成器网络中采用跳跃连接（Skip-Connection），实现浅层特征与高层特征的融合，使网络能够保留更多地细节信息，辅助网络对退化的图像特征进行修复。




图 5-7 AE-WGAN 网络结构

Figure 5-7 network structure of AE-WGAN

此外，本文在 AE-WGAN 网络的生成器中引入了 CBAM 注意力机制^[67]。对于卷积神经网络（CNN）来说，其本质是通过卷积操作对所有通道的特征图不加区别的进行局部空间特征融合，从而获取更多的图像信息，但这些信息包含很多冗余信息，对目标任务的帮助作用并不大。而注意力机制的目的就是从融合的信息中选取重要的信息，使网络更加关注到对目标任务有帮助的特征。CBAM 注意力机制将空间注意力机制（spatial attention）和通道注意力机制（channel attention）结合在一起，以便网络可以提取更多有用的特征信息。

如下图 5-7 所示，CBAM 的工作原理为：对于通道注意力（Channel Attention）来说，首先是将输入的特征图分别进行最大池化操作（MaxPooling）和全局平均池化（AvgPooling）操作得到两个特征图，然后将获得的特征图分别通过 Shared MLP 进行特征信息重组，最后将两个特征图进行逐元素相加，并通过 Sigmoid 激活函数获得通道注意力特征图；而空间注意力机制（Spatial Attention）将原输入特征图和经过通道注意力机制获得的特征图一起作为输入，同样通过最大池化操作和全局平均池化操作得到两个特征图，并将两个特征图沿通道方向进行拼接（Concat），最后通过 Sigmoid 激活函数输入空间注意力特征图。




图 5-7 CBAM 注意力机制的原理

Figure 5-7 principle of CBAM attention mechanism

在损失函数方面，AE-WGAN 的生成器网络的总体损失函数为：

$$L_{generator} = \alpha L_{reconstruction} + \beta \cdot L_{perceptual} + \gamma \cdot L_{MS_SSIM_L1} \quad (5-1)$$

1) L_{rec_loss} 为重建损失函数，由于 L1 相比于 L2 损失可以得到更清晰的结果，所以选择使用 L1 损失函数计算真实图像 y 和生成图像 $G(x)$ 之间的损失，其计算公式为：

$$L_{rec_loss}(G(x), y) = \sum_{i=0}^N |y_i - G(x_i)| \quad (5-2)$$

2) $L_{perceptual}$ 是图像感知损失函数, 图像感知损失 (Perceptual Loss) 是 2016 年 Johnson J 等人提出的一种基于图像高层特征的损失函数^[68], 该损失函数可以在高层特征层面对原图和生成图进行约束, 使生成图像可以保留源图像中较多的高层语义信息。本文这里选择使用在 ImageNet 数据集上训练的 VGG19 网络模型对原图 y 和修复图像 $G(x)$ 进行特征提取, 然后使用第 3、8、13、16、22 层输出的特征图计算 y 和 $G(x)$ 之间的感知损失, 计算公式如下:

$$L_{perceptual}(y, G(x)) = \sum_{i=1}^N \frac{1}{C_j H_j W_j} \left[\left\| \phi_j(y) - \phi_j(G(x)) \right\|_1 \right] \quad (5-3)$$

其中 ϕ 表示预训练模型, j 表示该网络为第 j 层, $C_j \times H_j \times W_j$ 表示第 j 层特征图的尺寸参数。

3) $L_{MS_SSIM_L1}$ 是 Hang, Zhao 等人提出的一种新的基于 MS-SSIM 和 L1 的联合损失函数^[69]。MS-SSIM 是一种多尺度结构相似性损失函数, 该损失函数不仅考虑了图像的亮度、对比度和结构还考虑了图像的分辨率。虽然 MS-SSIM 损失可以使生成图像保留原图像的高频信息, 但极易导致生成图像发生亮度和颜色的改变问题, 而 L1 损失函数可以很好的解决该问题, 所以 MS-SSIM 和 L1 的联合损失可以促进生成图像的质量更好。 $L_{MS_SSIM_L1}$ 的计算公式 (5-6), 其中 α 是比例系数。

$$\begin{cases} L_{MS_SSIM_L1} = \alpha \cdot L_{MS_SSIM} + (1 - \alpha) \cdot G_{\sigma} L_{L1} \\ L_{MS_SSIM} = 1 - MS_SSIM(G(x)) \end{cases} \quad (5-4)$$

经过测试本文生成网络的总损失函数的各项损失权重分别为:

$$\alpha = 1, \beta = 10, \gamma = 0.01$$

(2) AE-WGA 的判别器网络

为了减少修复图像与真实图像之间的差异, 本文借鉴 GAN 网络的思想, 引入判别器网络辨别修复图像的“真假”。采用的判别器网络结构类似于 VGG16 网络, 通过卷积和最大池化下采样进行特征提取, 最后经过全连接层对生成图像进行判别^[70], 其网络结构如下表 5-1 所示:

表 5-1 AE-WGAN 判别器的网络层参数

Table 5-1 network layer parameters of AE-WGAN discriminator

Layer	Kernel size	Stride	Output
Conv_1 + LeakyRelu	(3, 3)	(1, 1)	(N, 64, 320, 480)
Conv_2 + LeakyRelu	(3, 3)	(1, 1)	(N, 64, 320, 480)
MaxPooling_1	(2, 2)	(1, 1)	(N, 64, 161, 241)
Conv_3 + LeakyRelu	(3, 3)	(1, 1)	(N, 128, 159, 239)
Conv_4 + LeakyRelu	(3, 3)	(1, 1)	(N, 128, 159, 239)
MaxPooling_2	(2, 2)	(1, 1)	(N, 128, 80, 120)
Conv_5 + LeakyRelu	(3, 3)	(1, 1)	(N, 256, 78, 118)
Conv_6 + LeakyRelu	(3, 3)	(1, 1)	(N, 256, 78, 118)
Conv_7 + LeakyRelu	(3, 3)	(1, 1)	(N, 256, 78, 118)
MaxPooling_3	(2, 2)	(1, 1)	(N, 256, 40, 60)
Conv_8+LeakyRelu	(3, 3)	(1, 1)	(N, 512, 38, 58)
Conv_9+LeakyRelu	(3, 3)	(1, 1)	(N, 512, 38, 58)
Conv_10+LeakyRelu	(3, 3)	(1, 1)	(N, 512, 38, 58)
Conv_11+LeakyRelu	(3, 3)	(1, 1)	(N, 512, 38, 58)
GlobalPooling	(2, 2)	(1, 1)	(N, 512, 29, 49)
FC_1 + Relu		(N, 512, 29, 1024)	
FC_2		(N, 512, 29, 1)	
Sigmoid		(N, 512, 29, 1)	

对于判别器的损失函数，本文参考 WGAN_GP 网络的判别器设计方法，通过使用梯度惩罚项 Gradient Penalty 实现 Lipschitz 限制，从而保证生成器与判别器平衡训练，防止网络在训练过程中出现梯度消失或梯度爆炸的现象^[71]，所以判别器网络的损失函数为：

$$L_{local} = E_{\tilde{x} \sim P_g} [D(\tilde{x})] - E_{x \sim P_r} [D(x)] + \lambda \left[\left(\left\| \nabla_x D(\hat{x}) \right\|_2 - 1 \right)^2 \right] \quad (5-5)$$

其中， $E_{\tilde{x} \sim P_g} [D(\tilde{x})] - E_{x \sim P_r} [D(x)]$ 为 GAN 的判别器损失函数项， $\lambda \left[\left(\left\| \nabla_x D(\hat{x}) \right\|_2 - 1 \right)^2 \right]$ 为梯度惩罚项， λ 是惩罚的权重系数，本文这里将其设置为 10。

5.3 图像去油滴实验

5.3.1 制作训练数据集

本文为解决轴承缺陷检测中油滴干扰的问题，基于上论文[42]Attentive GAN 网络进行轴承表面区域算法的研究，由于该网络采用监督学习的方式，训练时需要成对图像（即一张带油滴图像和一张对应不带油滴图像）的数据集进行模型训练，所以本文首先搭建了图像数据采集平台，如下图 5-9 所示。




图 5-9 图像采集平台

Figure 5-9 Image acquisition platform

该平台采用的图像采集方案为：选用海康 MV-CA013-20GMG 型号的面阵工业相机搭配 35mm 焦距的光学镜头。此外，由于去油滴算法主要用于解决油滴对防尘盖表面凹坑缺陷检测造成的误检问题，所以照明方式同样采用分区段光源和环形光源组合，通过频闪照明采集轴承在四个光照方向的图像，采集的图像如图 5-10 所示：

借助上述图像采集平台，本文共采集 2244 对带油滴和无油滴图像制作数据集，并从数据集随机选取 1844 对数据按 9:1 的比例进行划分数数据集，选择 1474 对轴承图像作为训练集，185 对作为验证集，最后将剩下的 585 对作为测试集，验证训练模型的有效性。




图 5-10 轴承图像去油滴数据集

Figure 5-10 dataset of bearing image oil drop removal

5.3.2 图像去油滴实验

本文使用改进的 Attentive GAN 网络在上述制作的轴承油滴数据集上进行迁移学习，并将原网络训练的去雨滴模型作为预训练权重，将迭代次数(iterations)设置为：iterations=100000。

训练结束后，本文使用峰值信噪比（PSNR）和结构相似性（SSIM）两种图像评价指标对训练的去油滴模型进行评价。其中 PSNR 是一种评价图像画质的客观标准，计算公式为：

$$PSNR = 10 \times \log_{10} \left(\frac{(2^n - 1)^2}{MSE} \right) \quad (5-6)$$

这里的 MSE 表示生成图与原图之间的均方差。

SSIM 是一种从亮度、对比度和结构三方面衡量两幅图像相似度的指标，其计算公式为：

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + c_1)(2\sigma_{xy} + c_2)}{(\mu_x^2 + \mu_y^2 + c_1)(\sigma_x^2 + \sigma_y^2 + c_2)} \quad (5-7)$$

其中 μ_x , μ_y 分别是 x , y 的平均值, σ_x^2 , σ_y^2 分别是 x , y 的方差, σ_{xy} 是 x , y 的协方差。 $c_1 = (k_1L)^2$, $c_2 = (k_2L)^2$ 是用来维持稳定的常数。 L 是像素值的动态范围, $k_1 = 0.01$, $k_2 = 0.03$ 。

下图 5-11 为本文改进的 Attention GAN 网络训练过程中，评价指标 PSNR 和 SSIM 在训练集和验证集上图像变化曲线。




图 5-11 PSNR 和 SSIM 在训练集和验证集上的变化曲线

Figure 5-11 variation curves of PSNR and SSIM on training set and verification dataset




图 5-12 油滴注意力图的对比

Figure 5-12 comparison of oil drop attention diagram

上图 5-12 所示为原网络 Attentive GAN 和本文改进网络的生成的油滴注意力图的

结果对比。可以发现，当增加注意力递归神经网络的时间步数 N ，可以使生成的注意力图对雨滴所在区域赋予更高的权重，且对雨滴的区域关注的更加准确，从这方面说明本文的做法是有效的。下图 5-13 可以更直观的看出改进后网络模型可以较好的实现图像的去油滴效果，被油滴覆盖的背景信息也基本恢复出来，但生成的图像也存在部分纹理特征的缺失和图像模糊化的问题。




图 5-13 网络模型改进前后生成图像的对比

Figure 5-13 comparison of images generated before and after the improvement of network model

最后本文分别在测试集上对训练原 Attention GAN 网络模型和本文改进的 Attention GAN 网络模型进行测试，得到的对比结果如下表 5-2 所示。

表 5-2 Attentive GAN 模型和改进模型在验证集上的评价结果

Table 5-2 evaluation results of attentive Gan model and improved model on the verification dataset

方法 (Method)	平均峰值信噪比 (PSNR)	结构相似性 (SSIM)
Attentive GAN	30.827	0.9058
本文改进 Attentive GAN	31.282	0.9162

5.3.3 图像精修复实验

在使用 AE-WGAN 网络进行图像精修复时，本文将 Attentive GAN 生成的无油滴图像作为输入，并设置 batch size=16，迭代次数为 $iterations = 7000$ ，并在训练过程中将图像峰值信噪比（PSNR）和结构相似性（SSIM）模型评价指标进行可视化（图 5-14）。




图 5-14 训练集和验证集上 PSNR 和 SSIM 曲线

Figure 5-14 variation curves of PSNR and SSIM on training and verification dataset

为验证本文设计的 AE-WGAN 方法的性能，我们将其与现有的方法 pix2pix 进行对比实验，这里的 pix2pix 的生成器选用的是 UNet_512，其网络深度和本文算法的网络深度相近^[72]。两个模型在测试集上得到的 PSNR 和 SSIM 评价指标的结果如下表 5-3 所示，可以看出基于 AE-WGAN 网络生成的图像具有更高的 PSNR 和 SSIM。

表 5-3 AE-WGAN 模型和 pix2pix 模型在验证集上的评价结果

Table 5-3 evaluation results of ae-wgan model and pix2pix model on the validation set

方法 (Method)	平均峰值信噪比 (PSNR)	结构相似性 (SSIM)
pix2pix	28.759	0.8906
AE-WGAN	31.252	0.9451

此外，通过下图 5-15 AE-WGAN 和 pix2pix 模型生成图像结果对比，可以发现 AE-WGAN 可以较好的修复 Attentive GAN 网络生成图像中残缺纹理并能够将退化的图像

得到增强，包括防尘盖表面的凹坑缺陷特征。而 pix2pix 模型生成的图像只能够在一定程度上修复图像缺失的特征。




图 5-15 AE-WGAN 与 pix2pix 算法结果对比

Figure 5-15 comparison of algorithm results between ae-wgan and pix2pix

5.3.4 图像去油滴前后缺陷检测对比

本文使用 4.3 节改进的 SFCS-YOLO v3 凹坑缺陷检测模型对去油滴前后的轴承图像进行缺陷检测对比，首次从测试集中随机选取 100 张带油滴的轴承图像，其中 80 个带凹坑缺陷和 20 个不带缺陷，然后分别进行图像去油滴处理和不去油滴处理。从表 5-4 和图 5-16 中均可以看出，经过两阶段图像恢复网络得到的去油滴图像可使 SFCS-YOLO v3 算法的误检率降低 93%。

表 5-4 图像去油滴前后凹坑缺陷误检率的对比

Table 5-4 comparison of false detection rate of pit defects before and after oil drop removal

	检测数量	NG 误检数量	OK 误检数量	误检率	准确率
图像去油前	100	76	20	96.00%	4.00%
图像去油后	100	2	1	3.00%	97.00%




图 5-16 图像去油滴前后凹坑缺陷的检测结果

Figure 5-16 detection results of pit defects before and after oil drop removal

5.4 本章小结

本章基于一种两阶段的神经网络解决实际检测中轴承表面的油滴对防尘盖表面的凹坑缺陷造成的误检问题。首先基于改进的 Attentive GAN 网络实现轴承图像的去油滴，然后基于 AE-WGAN 网络修复生成去油滴图像中缺失的纹理特征。最终通过将本文提出的方法与 pix2pix 对比以及通过 SFCS-YOLO v3 测试图像去油前后的凹坑缺陷检测误检情况，验证了本文采用两阶段网络实现图像去油滴方法的有效性。

6. 系统软件设计与测试

本章将介绍检测系统的上位机软件开发，重点从软件需求、串口通讯、多线程检测以及其他功能的实现等方面进行概述，最后对本文设计的轴承表面缺陷检测系统进行整体测试。

6.1 软件需求

本文针对轴承缺陷检测系统中的需求，需要开发一套上位机检测软件，用于配合 PLC 完成相应的检测功能。该软件需要实现的功能包括：

① 串口通讯

在本系统中，PLC 负责机械结构运动，包括上料、拨料、翻转、分拣以及码料等。上位机软件负责实现图像采集和图像处理以及其他系统相关功能。上位机软件与 PLC 之间需要进行通讯，以保证系统的稳定运行。

② 图像采集：

当 PLC 发出图像采集信号时，软件需要通过多线程控制多个检测工位的相机和光源进行图像的采集和保存工作，待采集完成后，要给 PLC 发送采集结束信号。

③ 图像处理：

当完成图像采集后，便要开始对采集的图像进行处理，检测轴承表面是否存在缺陷，然后将检测的结果发送给 PLC 系统，以便 PLC 进行分拣动作。

④ 检测结果可视化：

为了方便观察系统检测情况以及修改算法参数，需要在软件主界面实时显示每个轴承的图像处理结果。

⑤ 数据统计：

为了能够了解系统的整体检测结果，需要对检测的轴承进行数据的统计，包括检测总数量、ng 数量、ok 数量、每种缺陷在总的缺陷轴承的占比分布等。

⑥ 参数配置：

参数配置部分主要包括三部分：相机参数配置、光源参数配置、算法参数配置。

6.2 开发环境

本文检测软件是基于 Qt creator 4.11.0 进行开发的，Qt 具有一套完整的信号与槽机制，其中的信号是指在某个特定情况或动作下被触发的消息，而槽函数则是用于接收和处理信号，该机制能够实现任意两个 Qt 对象之间的通信，可用于完成界面操作的响应。

在图像处理算法方面，本文系统整体采用传统图像处理算法与深度学习技术相结合的方式。其系统大量使用的圆检测、直线检测以及 Blob 分析均是基于 Opencv，而字符识别、凹坑缺陷检测以及轴承表面去油算法分别是基于 PaddlePaddle 和 tensorflow 框架进行的。

6.3 串口通信

本文设计的轴承表面缺陷系统的上位机 PC 与下位机 PLC 之间的通讯是借助于 IOC6040 运动控制卡完成的。在 IOC6040 运动控制卡配套二次开发库的基础上，通过定义 PC 和 PLC 通讯的触点，以实现 PC 写入信号给 PLC 或接收 PLC 发送的信号。本系统主要的通讯内容为：当下位机 PLC 将待测轴承拨料至检测工位后，会发送图像采集开始信号；上位机 PC 接收到信号后，开始依次进行图像采集和图像处理；待检测完成后，上位机 PC 将图像采集结束信号和检测结果信号发送给 PLC，PLC 接收到该信号后便开始控制机械系统进行上料、拨料、翻转、分拣以及码料等。

6.4 多线程并行检测实现

由于本文系统设计有四个检测工位，所以当系统运行时，上位机软件需要同时控制四套相机和光源进行图像采集以及相应的图像算法处理。为了缩短检测时间，本文选择创建四个子线程（QThread）以并行的方式完成上述工作。每个子线程均负责完成相应检测工位的图像采集和图像处理工作，并将检测结果通过 IOC6040 运动控制卡接口函数发送给 PLC。

6.5 软件其他功能实现

(1) 主界面设计

如下图 6-3 所示，本文设计的上位机检测软件的主界面显示内容主要包括：检测结果可视化窗口、数据统计表、运行时间以及其他功能设置按钮。

在检测结果可视化窗口中，由于 3、4 工位显示的结果图像较多，本文在正反面窗口区域添加图像放大显示功能，通过点击想要查看的图片区域可实现放大显示该图片。

具体实现方法为：通过改写 Qt 的 QLabel 类，在其中添加 Click() 点击事件，这样当我们使用鼠标点击 Label 控件时，就通过信号与槽机制进行相应功能的实现。




图 6-3 检测软件的主界面设计

Figure 6-3 main interface design of detection software

(2) 参数配置

如下图 6-5 所示，通过在主窗口中添加 Widget 子窗口对象，当点击主窗口中的设置按钮（Button）时，可弹出软件中的相关参数配置界面。此外，本文选择在关闭软件时将参数配置信息写成.ini 配置文件，以便保存读取。



图 6-5 检测软件参数配置界面

Figure 6-5 parameter configuration interface of detection software

6.6 系统整体测试

本文为验证轴承外圈外侧面、内圈内侧面以及端面缺陷检测算法的有效性和可靠性，对每个表面分别随机挑选 100 个表面带缺陷的和 20 个表面无缺陷的轴承进行批量测试，测试结果如下表所示：

表 6-1 轴承各表面检测算法测试

Table 6-1 test of bearing surface detection algorithm

	轴承总数	检出 NG 数量	检出 OK 数量	误检率	漏检率	准确率
外圈外侧面	120	98	22	2.50%	2.00%	97.50%
内圈内侧面	120	99	21	0.83%	1.00%	99.17%
端面	120	96	24	4.17%	4.00%	95.83%

注 6-1）这里的漏检率是指 100 个缺陷轴承未检出缺陷的概率；误检率和准确率均是相对于 120 个轴承的检测概率。

通过上表可以看出，轴承外侧面检测算法的准确率为 97.50%，误检率为 2.50%，其中造成该表面出现误检的原因在于裂纹过细，阈值分割和形态学操作造成缺陷被分

割断裂，无法根据缺陷长宽比和像素面积判别缺陷。轴承内侧面缺陷检测算法的准确率为 99.17%，误检率为 0.83% 由于检测的缺陷类型较少，检测准确率相对较高，但其出现误检的原因在于其内表面存在的少量锈蚀缺陷，其在光源下表现的图像特征不明显，此时采用阈值分割时无法分割出缺陷。而对于轴承端面缺陷检测算法的准确率为 95.83%，误检率为 4.17%，漏检率为 4.00%。该表面检测算法误检率和漏检率较高的原因主要是部分防尘表面的凹坑缺陷尺寸太小且分布在字符区域，所以造成一定的误检。

表 6-2 系统各部分运行时间统计

Table 6-2 statistics of operation time of each part of the system		
系统	统计项	运行时间
硬件系统	PLC 控制运行	1.2~1.3s
	外侧面检测	≈0.152s
软件系统	内侧面检测	≈0.095s
	端面检测	≈0.643s

此外，本文针对系统的检测速度分别进行了软件系统和硬件系统的相关测试，测试结果如上表 6-2 所示，所以经过多次统计，本系统整体检测时间约为 2.09~2.19s。

6.7 本章小结

本章介绍检测系统的软件开发相关工作，包括设计需求、开发平台以及所需功能的实现，最后对整个系统各个检测工位的检测准确率和检测时间进行测试统计。

7. 结论与展望

7.1 结论

本文针对轴承表面存在的各种缺陷以及人工目测分拣存在的问题，设计了一套基于机器视觉的轴承表面缺陷检测系统。通过对大量轴承表面缺陷的打光测试与分析，完成视觉系统的选型工作，并根据轴承的结构特征和缺陷分布，设计一种多工位组合式照明图像采集方案。同时设计并搭建一套自动化分拣系统，该系统具有上料、检测、分拣和码料等功能，整个系统通过 DVP-64EH300T 型号的 PLC 进行自动化控制运行。

基于上述多工位缺陷检测方案，本文对每个检测工位均设计了相应的缺陷检测算法。对于黑斑、锈蚀、缺口、裂纹、倒角尺寸等易检测缺陷，本文通过采用 ED 边缘检测、EDCircles 圆检测、EDLines 直线检测、区域分割提取、Blob 分析等图像处理方法进行轴承表面缺陷检测。而对于难以检测的缺陷类型或传统图像处理算法难以保证检测结果鲁棒性的缺陷，本文采用基于深度学习的方法进行缺陷的检测和图像处理，如本文提出一种 SFCS-YOLO v3 轴承防尘盖表面凹坑缺陷检测算法，通过结合实际检测策略实现检测准确率为 97.50%；针对轴承表面油滴造成的检测干扰问题，本文提出一种基于两阶段神经网络的轴承表面图像去油滴算法，该算法使得因表面油滴造成 SFCS-YOLO v3 模型的误检率降低 93%。此外，本文基于 Qt Creator 平台开发了该系统的缺陷检测软件，该软件具有图像采集、图像处理、结果可视化、数据统计和串口通讯等功能。

最后通过对系统各检测算法的检测精度和运行时间进行测试统计，本文所设计的缺陷检测系统的检测准确率为 95.80%，检测速率为 2.14 秒/个。

7.2 展望

虽然本文已完成系统的整体设计，但该系统在缺陷检测算法的精度方面还存在一些不足点，如基于 SFCS-YOLO v3 的轴承防尘盖表面凹坑缺陷检测算法的仍需提高缺

陷检测精度、基于两阶段神经网络的轴承图像去油滴模型在一定程度上减弱缺陷特征显著性等。此外，由于疫情因素的影响，本文设计的轴承表面缺陷检测系统未能进入企业实际运行测试，无法验证检测系统的稳定性。在后续的工作中，我们会进一步的优化检测算法，并进行大量的测试工作，提升系统的检测准确性和运行稳定性。

参考文献

- [1] 濮良贵.机械设计第9版.出版社: 高等教育出版社, 出版年:2013.05
- [2] 周苏, 王硕苹等编著. 创新思维与方法: 中国铁道出版社, 2016.09: 42-43
- [3] 华经产业研究院. 2021-2026 年中国轴承行业市场供需格局及投资规划建议报告 [EB/OL]. (2021-11-10) [2022-2-25]. https://www.sohu.com/a/500305994_121135583
- [4] 慈溪日报社. 去年慈溪轴承出口逆势上涨 [EB/OL]. (2022-3-5) [2022-3-5]. http://epaper.cxnews.cn/html/2022-03/01/content_88937_14549054.htm
- [5] 程光. 机器视觉技术. 出版社: 北京:机械工业出版社, 陈玉芝. 出版年: 2019.7: 1-3
- [6] 苏俊宏, 刘胜利, 杨利红,等. 基于机器视觉的高精密轴承在线检测[J]. 光学与光电技术, 2013, 11(6):5.
- [7] 刘胜利. 基于工业视觉的轴承尺寸在线检测技术[D]. 西安工业大学, 2014.
- [8] 范帅, 汤倚婷, 卢满怀. 基于机器视觉的轴承内外圈尺寸检测及分类[J]. 自动化仪表, 2016, 37(11):5.
- [9] 崔灿, 景文博, 闫娜,等. 一种基于机器视觉的轴承内外径和同心度检测方法[J]. 长春理工大学学报: 自然科学版, 2017, 40(3):5.
- [10] 陈廉清, 崔治, 王龙山. 基于差影和模板匹配的微小轴承表面缺陷检测[J]. 中国机械工程, 2006, 17(10):4.
- [11] 陈向伟, 张学军, 关山. 基于计算机视觉的微小轴承表面缺陷检测[J]. 机床与液压, 2009, 37(9):3.
- [12] 刘晓杰, 罗印升, 张旻,等. 基于机器视觉的零部件表面缺陷检测方法研究[J]. 现代电子技术, 2017, 40(24):3.
- [13] 杜月荣. 基于机器视觉的滚针轴承表面及滚针针数缺陷检测技术研究[D]. 西安电子科技大学.
- [14] 袁红彬. 基于计算机视觉的微小轴承表面缺陷检测技术研究[D]. 吉林大学, 2007.
- [15] Kunakornvong, Tangkongkiet, Sooraksa. Defect detection on air bearing surface with luminance intensity invariance[C]// International Conference on Fuzzy Systems & Knowledge Discovery. IEEE, 2012.
- [16] 王恒迪, 李莎, 杨建玺,等. 轴承端面缺陷的视觉检测方法[J]. 轴承, 2016(3):4.
- [17] 郑越. 基于机器视觉的轴承内圈表面缺陷检测系统研究[D]. 沈阳工业大学.
- [18] 杜克飞. 基于机器视觉的滑动轴承内表面缺陷自动检测系统设计[J]. 机械工程师, 2018(1):4.
- [19] 黄睿. 基于影像的轴承缺陷检测系统的设计与实现[D]. 大连理工大学, 2016.
- [20] Liu B , Yang Y , Wang S , et al. An Automatic System for Bearing Surface Tiny Defect Detection Based on Multi-Angle Illuminations[J]. Optik - International Journal for Light and Electron Optics, 2020, 208:164517.
- [21] 陈廉清, 袁红彬, 王龙山. SUSAN 算子在微小轴承表面缺陷图像分割中的应用[J]. 光学技术, 2007, 33(2):3.
- [22] 张扬, 朱善安. 基于小波及纹理特征的轴承防尘盖缺陷检测[J]. 计算机工程, 2010, 36(8):4.

- [23] 陈文达, 白瑞林, 吉峰,等. 基于机器视觉的轴承防尘盖表面缺陷检测[J]. 计算机工程与应用, 2014(6):5.
- [24] 任永强, 潘浩, 李广涛. 基于机器视觉的轴承字符识别技术的研究[J]. 机床与液压, 2018(5).
- [25] 王昌, 高晶晶. 基于机器视觉的轴承生产中的表面质量在线检测与研究[J]. 机床与液压, 2013, 41(19):3.
- [26] 周贤伟. 基于机器视觉的轴承缺陷检测[D]. 中国计量大学.
- [27] 兰叶深, 刘文军, 毛建辉. 基于视觉显著性的轴承表面缺陷检测算法的研究[J]. 自动化应用, 2020(9):3.
- [28] 张闯闯. 基于机器视觉的轴承套圈全表面缺陷检测系统研究[D]. 中国矿业大学, 2021.001004.
- [29] 徐科, 周鹏, 杨朝霖. 基于光度立体学的金属板带表面微小缺陷在线检测方法[J]. 机械工程学报, 2013, 49(4):5.
- [30] 徐科, 王磊, 向境,等. 基于多点光源的金属表面三维缺陷检测方法[J]. 中国科技论文, 2017, 12(4):5.
- [31] 黄秀玲, 陆宏建, 任超,等. 基于四光源光度立体法的药品泡罩包装中铝箔缺陷检测方法[J]. 包装学报, 2018, 10(3):5.
- [32] 赵妍妍. 基于计算机视觉的微小轴承外圈表面缺陷检测技术研究[D]. 吉林大学, 2008.
- [33] 吴义权, 邓惠文. 对基于支持向量机的轴承表面缺陷检测研究[J]. 中国设备工程, 2019(2):2.
- [34] 宇文旋. 基于机器视觉的轴承表面缺陷检测与分类系统研究[D]. 电子科技大学.
- [35] 王启祥. 基于深度学习的轴承外圈表面缺陷分类关键技术研究[D]. 电子科技大学.
- [36] 刘好斌, 杨丰玉, 杨志勇,等. 基于 YoLov5 的轴承端面表面缺陷检测方法[J]. 失效分析与预防, 2021, 16(6):6.
- [37] Zheng Z , Zhao J , Li Y . Research on Detecting Bearing-Cover Defects Based on Improved YOLOv3[J]. IEEE Access, 2021, PP(99):1-1.
- [38] Redmon J , Farhadi A . YOLOv3: An Incremental Improvement[J]. arXiv e-prints, 2018.(yolov3)
- [39] Bochkovskiy A , Wang C Y , Liao H . YOLOv4: Optimal Speed and Accuracy of Object Detection[J]. 2020.
- [40] He Z , Patel V M . Density-Aware Single Image De-raining Using a Multi-stream Dense Network[J]. IEEE, 2018.
- [41] Zhang H , Patel V M . Densely Connected Pyramid Dehazing Network[J]. 2018
- [42] Qian R , Tan R T , Yang W , et al. Attentive Generative Adversarial Network for Raindrop Removal from a Single Image[J].
- [43] Pathak D , Krahenbuhl P , Donahue J , et al. Context Encoders: Feature Learning by Inpainting[J]. IEEE, 2016.
- [44] Yang C , Lu X , Lin Z , et al. High-Resolution Image Inpainting using Multi-Scale Neural Patch Synthesis[J]. IEEE, 2017.
- [45] Liu G , Reda F A , Shih K J , et al. Image Inpainting for Irregular Holes Using Partial Convolutions[J]. Springer, Cham, 2018.

- [46] Liu H , Jiang B , Xiao Y , et al. Coherent Semantic Attention for Image Inpainting[J]. IEEE, 2019.
- [47] Song Y , Yang C , Lin Z , et al. Contextual-based Image Inpainting: Infer, Match, and Translate[J]. 2017.
- [48] Yu J , Lin Z , Yang J , et al. Generative Image Inpainting with Contextual Attention[J]. IEEE, 2018.
- [49] 刘韬,葛大伟. 机器视觉及其应用技术. 出版社: 北京:机械工业出版社, 曲世海, 出版年: 2020.3 30-31
- [50] 曹荣军. 元胞自动机理论及其在图像边缘检测中的应用[J]. 电脑知识与技术:学术版, 2009(7X):2.
- [51] Topal C , Akinlar C . Edge Drawing: A combined real-time edge and segment detector[J]. Journal of Visual Communication and Image Representation, 2012, 23(6):862-872.
- [52] Akinlar C , Topal C . EDLines: A real-time line segment detector with a false detection control[J]. Pattern Recognition Letters, 2011, 32(13):1633-1642.
- [53] Akinlar C , Topal C . EDCircles: A real-time circle detector with a false detection control[J]. Pattern Recognition, 2013, 46(3):725–740.
- [54] Du Y , Li C , Guo R , et al. PP-OCR: A Practical Ultra Lightweight OCR System[J]. 2020.
- [55] Girshick R , Donahue J , Darrell T , et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[J]. IEEE Computer Society, 2013.
- [56] Girshick R . Fast R-CNN[J]. arXiv e-prints, 2015.
- [57] Ren S , He K , Girshick R , et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, 39(6):1137-1149.
- [58] Liu W , Anguelov D , Erhan D , et al. SSD: Single Shot MultiBox Detector[J]. 2015.
- [59] Redmon J , Divvala S , Girshick R , et al. You Only Look Once: Unified, Real-Time Object Detection[J]. IEEE, 2016.
- [60] Redmon J , Farhadi A . YOLO9000: Better, Faster, Stronger[J]. IEEE, 2017:6517-6525.
- [61] Li X , Wang W , Hu X , et al. Selective Kernel Networks[J]. IEEE, 2020.
- [62] Lin T Y , Goyal P , Girshick R , et al. Focal Loss for Dense Object Detection[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, PP(99):2999-3007.
- [63] Zheng Z , Wang P , Ren D , et al. Enhancing Geometric Factors in Model Learning and Inference for Object Detection and Instance Segmentation[J]. 2020.
- [64] Jiang B , Luo R , Mao J , et al. Acquisition of Localization Confidence for Accurate Object Detection[J]. 2018.
- [65] Jie H , Li S , Gang S , et al. Squeeze-and-Excitation Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, PP(99).
- [66] Ronneberger O , Fischer P , Brox T . U-Net: Convolutional Networks for Biomedical Image Segmentation[J]. Springer International Publishing, 2015.
- [67] Woo S , Park J , Lee J Y , et al. CBAM: Convolutional Block Attention Module[J]. Springer, Cham, 2018.
- [68] Johnson J , Alahi A , Fei-Fei L . Perceptual Losses for Real-Time Style Transfer and

- Super-Resolution[J]. Springer, Cham, 2016.
- [69] Hang, Zhao, Orazio, et al. Loss Functions for Image Restoration With Neural Networks[J]. IEEE Transactions on Computational Imaging, 2017.
- [70] Simonyan K , Zisserman A . Very Deep Convolutional Networks for Large-Scale Image Recognition[J]. Computer Science, 2014.
- [71] Arjovsky M , Chintala S , Bottou L . Wasserstein GAN[J]. 2017.
- [72] Isola P, Zhu J Y, Zhou T, et al. Image-to-image translation with conditional adversarial networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1125-1134.

攻读硕士期间发表的论文及所取得的研究成果

1. EI 期刊论文:

- [1] Yu D, Zhao M, Shi Y, et al. Internal Quality Nondestructive Detection and Sorting Principle of Walnut Based on Density and Digital Image [J]. Nongye Jixie Xuebao, 2021, 52(7): 373-378. (已见刊, 第二作者)

2. 专利:

- [1] 徐刚,赵明,肖江剑,许根,王菊. 一种 2D 图像采集设备及轴承三维缺陷检测装置[P]. 浙江省: CN215066100U,2021-12-07. (实用新型专利,已授权,第二作者)
- [2] 徐刚,赵明,肖江剑,许根,王菊. 一种轴承三维缺陷检测方法及系统[P]. 浙江省: CN113111828A,2021-07-13. (发明专利,已授权,第二作者)

3. 会议论文:

- [1] Song K K, Zhao M, Liao X H, et al. An Improved Bearing Defect Detection Algorithm Based on Yolo[C]. IEEE CS: Conference Publishing Services(CPS) (已见刊,第二作者)

其他成果

1. SCI 期刊论文:

- [1] Yu D , Zhao M . Centering deep hole drilling system with three oil films like centering rotating journal with oil films in bearing[J]. Industrial Lubrication and Tribology, 2021. (已见刊, 第二作者)

2. 专利:

- [1] 赵明,王峰,赵晓巍,于大国. 孔检测与矫正装备[P]. 山西省: CN212144002U,2020-12-15. (实用新型专利,已授权,第一作者)

致谢

时光飞逝，转眼间，三年的研究生生活即将迎来结束。现在停笔回想起来，过往的科研情景仍历历在目。在过去的三年时间里，我学到了很多宝贵的知识，从对深孔加工中的 BTA 钻刀具的力学研究，到基于机器视觉的轴承表面缺陷检测；从传统的机械加工领域转变到当下热潮的人工智能领域。虽然学习相关领域知识、克服研究难点的日子很是辛苦，但“宝剑锋从磨砺出”，现在已然成为我今后宝贵的财富。

我很感谢自己研究生期间的各位导师，首先是传授我深孔加工技术的于大国教授。我个人认为于老师既是我的良师，亦是益友，不仅极度负责的传授给我和同门师兄兄弟相关学业知识，同时也注重培养我们为人处世的道理。尽管我跟于老师仅相处短短一年时间，但在这段时间里，我不仅熟悉了与深孔加工技术相关的知识，同时在于老师的耐心指导下，设计了一种基于动压润滑原理的深孔钻的定心器装置，以及提出一种基于转动惯量的深孔直线度误差评定方法。虽然成果一般，但重要的是这些成果给予我很大的鼓励和信心，让我在以后的科研道路愈发努力。

然后，很感谢我在中国科学院宁波材料与工程研究所实习时的课题组导师：肖江剑研究员。肖老师是一个对科研极其认真和负责的老师，平时对学生的要求也很严格，每周都抽出宝贵的时间以组会的形式跟学生交流科研进展、指导研究方向以及给学生答疑。俗话说：“严师方可出高徒”，在肖老师一年多的培养下，我顺利完成了基于机器视觉的轴承表面缺陷检测系统的科研任务，其中虽有不少坎坷，但总算一步一个脚印的走了过来，并且找到了心仪的工作。

此外，还要感谢同在一个实验室的各位同学，分别为尹忠伟、李梦龙、王健、徐宁远、廖先华、田学宇等人，大家一起互帮互助，共同奋斗，在讨论声中解决科研难题，用欢声笑语分享成功喜悦，因为有他们的陪伴让我的研究生活变得丰富多彩，充满激情。

最后，感谢各位评阅老师在百忙之中评阅我的论文，望各位老师提出宝贵的指导意见，我自当积极改正。