

学校代号 10532

学 号 F2002W0035

分 类 号 TG386.1

密 级 公开



湖南大学
HUNAN UNIVERSITY

工程硕士学位论文

基于机器视觉的金属零件 表面缺陷检测方法研究

学位申请人姓名 周飞滔

培 养 单 位 湖南大学机械与运载工程学院

导师姓名及职称 刘坚 教授 孔朝阳 高级经济师

学 科 专 业 机械

研 究 方 向 机器视觉

论文提交日期 2023年4月25日

学校代号：10532

学 号：F2002W0035

密 级：公开

湖南大学工程硕士学位论文

基于机器视觉的 金属零件表面缺陷检测方法研究

学位申请人姓名：周飞滔

导师姓名及职称：刘坚 教授 孔朝阳 高级经济师

培 养 单 位：湖南大学机械与运载工程学院

专 业 名 称：机械

论文提交日期：2023 年 4 月 25 日

论文答辩日期：2023 年 5 月 24 日

答辩委员会主席：程军圣 教授

-

Research on metal part surface defect detection based on machine vision

by

FeiTao Zhou

B.E.(Hunan University)2020

A thesis submitted in partial satisfaction of the

Requirements for the degree of

Master of Engineering

in

Mechanical Engineering

in the

Graduate School

of

Hunan University

Supervisor

Professor Liu Jian, Senior Engineer Kong ChaoYan

May, 2023

摘要

在制造业“智能制造”升级转型的大背景下，基于机器视觉的金属零件表面缺陷检测方法逐渐得到了广泛应用，但目前面临小样本条件、检测算法泛化能力不足、数据集不平衡问题以及缺陷检测方法精度有待进一步提高等难点问题。

本文以某多型号金属零件的表面缺陷检测为研究对象，分别从提高缺陷检测算法对不同型号零件的泛化能力、数据集样本尺度不平衡和样本类别不平衡问题、提高算法精度三个方面展开了深入研究，并予以实验验证。

本文主要的研究工作如下：

(1) 针对该金属零件在小样本、多型号下的表面缺陷检测中的感兴趣区域分割任务，本文提出了一种基于迁移学习与混合注意力机制的 UNet 感兴趣区域分割算法。针对小样本条件下 UNet 分割精度有待提升及收敛速度较慢的问题，基于参数迁移学习提出了 VGG-UNet 模型，并与原 UNet 模型对比，实验结果表明，网络收敛速度从 80 轮减少至 10 轮，同时 Mean IoU 指标提高了 2.21%。针对多型号金属零件感兴趣区域分割泛化能力不足问题，在参数迁移学习的 UNet 模型长连接特征融合过程中嵌入了混合注意力机制 CBAM 模块，提出了基于 CBAM- VGG16 参数迁移的 UNet 分割模型，实验结果表明，改进后的模型相比于参数迁移的 UNet 模型用于感兴趣区域分割的 Mean IoU 指标提高了 3.35%，且在其它两种型号金属零件的感兴趣区域分割 Mean IoU 分别提高了 2.17%、1.87%，验证了 CBAM 注意力机制能够有效提高语义分割网络的分割性能与泛化能力。

(2) 针对金属零件表面缺陷数据集中存在的样本尺度不平衡与样本类别不平衡问题展开了深入研究。针对样本尺度不平衡问题，提出了基于多尺度分块策略与 SRGAN 图像增强的样本尺度平衡方法。将多尺度分块策略应用于 YOLOv5 模型中，对该金属零件进行表面缺陷检测，实验结果表明，该方法 Mean AP 指标相比使用原始数据集训练的模型提高了 19.78%；针对该方法中低分辨率图像块插值上采样方法图像质量差的问题，引入了基于 SRGAN 的超分辨率图像增强模型，实验结果表明该方法获得的高分辨率图像相比于利用插值上采样得到的高分辨率图像，在图像质量评价指标 PSNR、SSIM 上均有提升，且图像增强后得到的 YOLOv5 模型应用于金属零件表面缺陷检测的 Mean AP 指标相对提高了 1.87%。针对样本类别不平衡问题，提出了以 UNet 为生成器、YOLOv5 模型为鉴别器的 UYGAN 生成对抗网络，生成了有效的伪缺陷图像，使用 SRGAN 与 UYGAN 数据增强后得到的 YOLOv5 模型与仅使用 SRGAN 数据增强方法的模型 Mean AP 指标提高了 1.82%。

(3) 针对卷积神经网络感受野的局限性, 引入聚焦于全局注意力的主干网络 Swin Transformer, 提出了基于 Swin transformer 的 YOLO 目标检测算法(SW-YOLO)应用于金属表面缺陷检测, 实验结果表明, 该模型相比于原 YOLOv5 模型 Mean AP 指标提高了 1.18%, 验证了 SW-YOLO 在金属零件表面缺陷检测任务中的优越性。针对 SW-YOLO 算法通道域注意力表达能力不足的问题, 提出了一种基于 SRM 与 ECANet 的 ESCAM 模块, 结果表明嵌入 ESCAM 注意力机制后的 SW-YOLO 模型比于原 SW-YOLO 模型的 Mean AP 指标提升了 2.28%, ESCAM 模块具有更强的通道注意力表达能力, 可以提高 SW-YOLO 模型特征提取能力。

关键词: 机器视觉; 表面缺陷检测; 样本不平衡; 语义分割; 注意力机制; 生成对抗网络; 目标检测

Abstract

Under the background of the upgrading and transformation of "Intelligent manufacturing" in manufacturing industry, it is difficult to meet the needs of manufacturing industry with the traditional methods of manual detection of metal surface defects. With the development of machine vision and deep learning technology, the metal part surface defect detection method based on machine vision has made great progress, but it still faces many challenges and difficulties. In this paper, We take the surface defect detection of a multi-type metal product as an example. In order to improve the ability of defect detection algorithm generalization, algorithm performance, Some work has been done.

The main research work of this paper is as follows.

(1) A novel UNet region of interest segmentation algorithm based on transfer learning and mixed attention mechanism is proposed. Experiments show that UNet has more advantages than other deep learning semantic segmentation algorithms in small sample size, can reduce the cost of marking, improve the deployment efficiency; At the same time, based on migration learning, the down-sampling process of UNet network is replaced by VGG16 backbone network and the pre-training weight is retained, it is also important to speed up the efficiency of defect detection algorithm deployment. By embedding the CBAM module in the long-link feature fusion of UNET model, the Mean IOU index of UNET model is improved by 3.35% compared with the original UNET model, at the same time, Mean IOU improves 2.17% and 1.87% on the surface images of other two kinds of metal products, and improves the segmentation performance and generalization ability of semantic segmentation network.

(2) The unbalance of sample size and class in the data set of metal surface defects is analyzed, and the corresponding optimization method is put forward. In order to solve the scale imbalance problem, this chapter proposes a scale equalization method based on multi-scale block strategy and SRGAN image enhancement. Compared with the Yolov5 model trained with the original data set, the Mean AP index is improved by 19.78% .To solve the problem of poor image quality of sampling method on low-

resolution image interpolation, SRGAN super-resolution reconstruction model is constructed, compared with the high-resolution image sampled by interpolation, the SRGAN-based high-resolution image sampled on the low-resolution image is improved in PSNR and SSIM, the Mean AP of YOLOV5 model after image enhancement is increased by 1.87% . UYGAN generated antagonism network is proposed in this paper, which uses UNet as generator and YOLOV5 model as discriminator, can effectively generate realistic false defect image. The Mean AP index of YOLOv5 model was improved by 1.82% after adding the pseudo-defect image generated by UYGAN.

(3) Considering the limitation of convolutional neural network field, Swin Transformer, a main network focusing on global attention, is introduced, and a novel Yolo target detection algorithm (SW-YOLO) based on Swin Transformer is proposed. Based on the fact that the Mean AP of SW-YOLO is improved by 1.18% compared with YOLOV5 model, the superiority of SW-YOLO in metal surface defect detection is verified. ESCAM module based on SRM and ECA is proposed. Compared with the original model in SW-YOLO model, the performance of ESCAM module proposed in this paper is improved by 2.28%. ESCAM module has stronger ability of channel attention expression, the performance of the SW-YOLO model can be optimized.

Key words: Machine Vision; Deep Learning; Surface Detection; Semantic Segmentation; Attention mechanism; GAN; Super-Resolution; Object Detection

目 录

第 1 章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 基于机器视觉的金属零件表面缺陷检测国内外研究现状	2
1.2.1 基于传统图像处理的金属零件表面缺陷检测方法研究现状	2
1.2.2 基于深度学习的金属零件表面缺陷检测方法研究现状	3
1.3 本文的主要研究思路和研究内容	5
1.3.1 本文研究思路.....	5
1.3.2 论文章节安排及研究内容.....	6
第 2 章 金属零件表面感兴趣区域分割方法研究	7
2.1 引言.....	7
2.2 数据集说明.....	7
2.3 传统图像分割方法对比.....	8
2.3.1 基于阈值的图像分割方法.....	8
2.3.2 基于区域的图像分割方法.....	9
2.3.3 结果对比.....	9
2.4 语义分割网络.....	10
2.4.1 FCN	10
2.4.2 PSPNet	11
2.4.3 Deeplab	11
2.4.4 UNet	12
2.4.5 语义分割网络对比.....	13
2.5 UNet 语义分割算法优化.....	14
2.5.1 迁移学习	14
2.5.2 混合注意力机制.....	16
2.6 评价指标及实验结果分析	18
2.6.1 图像分割性能评价指标.....	18
2.6.2 实验结果分析.....	18
2.7 本章小结.....	19
第 3 章 金属零件表面缺陷样本平衡方法研究	20
3.1 引言.....	20
3.2 图像预处理与数据集说明	20
3.3 金属零件表面缺陷样本不平衡问题研究	22
3.3.1 样本尺度不平衡问题.....	22
3.3.2 样本类别不平衡问题.....	24

3.4 样本尺度平衡方法研究.....	25
3.4.1 多尺度分块策略.....	25
3.4.2 基于 SRGAN 的图像增强方法.....	28
3.5 基于 UYGAN 的样本类别平衡方法研究.....	30
3.6 评价指标及实验结果分析.....	33
3.6.1 图像质量评价指标.....	33
3.6.2 目标检测性能评价指标.....	35
3.6.3 样本尺度平衡方法问题结果分析.....	36
3.6.4 基于 UYGAN 的样本类别平衡方法实验结果分析.....	38
3.7 本章小节.....	39
第 4 章 基于目标检测的金属零件缺陷检测方法研究.....	40
4.1 引言.....	40
4.2 目标检测网络.....	40
4.2.1 两阶段目标检测算法.....	40
4.2.2 单阶段目标检测算法.....	41
4.3 损失函数.....	42
4.3.1 置信度损失与分类损失.....	42
4.3.2 定位损失.....	43
4.4 基于 SW-YOLO 的金属零件表面缺陷检测算法.....	44
4.4.1 卷积神经网络的局限性.....	44
4.4.2 Swin Transformer.....	46
4.4.3 SW-YOLO 算法.....	49
4.5 基于通道注意力机制的 SW-YOLO 模型.....	50
4.5.1 通道注意力机制.....	50
4.5.2 ESCAM 模块.....	52
4.6 实验结果与分析.....	52
4.7 本章小节.....	54
总结与展望.....	55
参考文献.....	57

插图索引

图 1.1 本文研究思路与组织结构.....	5
图 2.1 数据集部分数据展示	7
图 2.2 传统图像分割方法结果对比	9
图 2.3 FCN-8s 网络结构	10
图 2.4 PSPNet 网络结构	11
图 2.5 普通卷积与空洞卷积.....	12
图 2.6 deeplabv3+网络结构	12
图 2.7 UNet 网络结构.....	13
图 2.8 VGG16+UNet 网络结构	15
图 2.9 损失下降趋势对比	16
图 2.10 CBAM 模块	17
图 3.1 预处理过程	20
图 3.2 金属表面常见异常图像	21
图 3.3 误检图像展示	21
图 3.4 金属表面小目标缺陷样本	22
图 3.5 yolov5 中的图像缩放.....	22
图 3.6 降采样前后的缺陷图像对比	23
图 3.7 金属表面大目标缺陷样本	23
图 3.8 目标相对尺度分布情况	24
图 3.9 数据集中的样本类别不平衡问题	25
图 3.10 目标相对尺度分布情况	26
图 4.11 多尺度分块后的缺陷图像块图像	26
图 3.12 多尺度分块测试过程及结果	27
图 3.13 上采样前后的图像对比	28
图 3.14 SRGAN 网络结构	29
图 3.15 Mosaic 数据增强	30
图 3.16 UYGAN 样本生成模型	31
图 3.17 UYGAN 生成图片随训练轮次的变化.....	32
图 3.18 生成伪缺陷图像流程	32
图 3.19 部分伪缺陷图像展示	33
图 3.20 IoU	35
图 3.21 多尺度分块策略结果对比	36
图 4.22 上采样效果对比	37
图 4.1 Faster R- CNN 网络结构.....	41

图 4.2 yolov5s 网络结构	42
图 5.3 CIOU 示意图	43
图 4.4 理论感受野递推关系示意图	44
图 4.5 有效感受野	45
图 5.6 ViT 模型示意图与 Transformer Encoder	46
图 4.7 多头自注意力机制	47
图 4.8 Swin Transformer 模型	47
图 4.9 Windows and Shifted Windows	48
图 5.10 SW-YOLO 模型	50
图 4.11 通道注意力机制	51
图 4.12 ESCAM 模块	52

附表索引

表 2.1 不同样本量下语义分割网络性能对比	14
表 2.2 参数迁移实验结果对比	15
表 2.3 混淆矩阵	18
表 2.4 基于 CBAM 的 UNet 实验结果对比	19
表 3.1 多尺度分块策略实验结果对比	36
表 3.2 图像质量评估实验结果对比	37
表 3.3 SRGAN 目标检测实验结果对比	38
表 3.4 UYGAN 实验结果对比	38
表 4.1 SW-YOLO 实验结果对比	52
表 4.2 通道注意力机制改进实验结果对比	53

第 1 章 绪 论

1.1 研究背景与意义

近年来，在全球经济一体化冲击下，制造业发展面临着严峻的挑战，产品质量是制造业企业的核心竞争力。随着中国制造 2025 和智能制造^[1]等概念深入人心，把握制造业产业转型浪潮，提高制造业产品质量将成为推进制造业发展有力推手。以铁、铝、铜及其合金为代表的金属材料是制造业主要原材料之一，金属零件被广泛应用于汽车、船舶、航空航天等领域，金属零件表面质量是金属零件质量的重要组成部分。受生产工艺、工人素养、设备能力等因素影响，各种缺陷会产生在金属表面^[2]。这些缺陷不仅会影响材料本身以及后续产品的质量、机械性能，还有可能因为零件质量问题对企业带来不可估量的经济代价和社会影响。金属零件表面缺陷检测在控制产品质量方面具有重要意义，能够有效地提高产品质量，提高产品的安全性、稳定性；同时也能对生产过程形成有效的反馈机制，快速响应生产环节出现的问题，有效降低企业生产成本，提高生产效益。

常见的表面缺陷无损检测技术主要包括磁粉、涡流、渗透、超声波和 X 射线等检测方法^[2]，这些方法在其适用场景下都取得了不错的检测效果，但是它们对检测样本要求较高且依赖于操作人员技术水平，难以满足自动化和智能化条件。人工检测也是表面缺陷检测主要手段之一，可是人工检测也有着很强的局限性，例如，人工检测依赖于人的主观判断，而人会受到经验水平，检测标准等主观因素影响，其检测稳定性与准确性无法得到保障，因此也无法很好地解决缺陷检测问题^[3]。随着机器视觉技术的高速发展，机器视觉技术在表面缺陷检测领域展现出巨大优势，研究基于机器视觉技术的金属表面缺陷检测方法已成为主流趋势，由于其非接触式、检测效率高、满足自动化、智能化需求，各种基于机器视觉的金属零件表面缺陷检测方法层出不穷且取得了较好的效果^[4]。实践证明，利用机器视觉技术实现金属零件表面缺陷检测对提高产品质量，降低企业生产成本，提高企业竞争力、智能化、信息化水平有着重要意义。然而，基于机器视觉的金属零件表面缺陷检测方法存在着许多技术难点，面临的挑战主要有：

（1）算法需要适配多型号零件并提高部署效率

金属零件为了满足不同应用场景的实际要求，需要设计各种机械结构，因此不同型号零件图像差异较大，现有算法针对性较强，很难直接进行迁移。因此，研究一种能够快速响应多型号产品图像的缺陷检测方法是实现缺陷检测算

法快速部署的第一步；

（2）缺陷检测算法精度有待提升

由于实际生产中对于缺陷检测的性能要求较高，一旦出现漏检的缺陷不合格品，可能对企业造成不可估量的损失；而频繁地出现误检也会导致企业需要耗费较大成本进行复核。因此，需要针对金属零件表面缺陷检测任务研究检测性能更高的缺陷检测算法来满足企业的实际使用需求。

针对以上问题，本文将结合深度学习方法对金属零件表面缺陷检测领域展开深入研究，以提高缺陷检测性能，为金属零件表面质量控制与评价提供重要基础。

1.2 基于机器视觉的金属零件表面缺陷检测国内外研究现状

1.2.1 基于传统图像处理的金属零件表面缺陷检测方法研究现状

在金属零件表面缺陷检测领域，相较于传统检测方法，机器视觉检测技术能够适应不同的金属零件表面，具有更高的检测精度与效率，已经成为金属零件表面质量检测重要手段^[5]。

金属零件表面传统缺陷检测方法主要包括图像预处理、特征提取、缺陷检测三个步骤，国外相应研究起步较早，并且技术已趋近成熟。2011年Y. Jeon^[6]等人开发了一种检测钢板表面划痕缺陷的检测算法，采用Gabor滤波算法进行边缘轮廓提取，减少噪声干扰同时放大了缺陷特征，随后利用直方图和梯度纹理特征进行特征提取，最后利用支持向量机完成划痕的检测。2015年GK Nand^[7]等人提出了一种基于熵的钢表面缺陷检测算法，该算法采用直方图阈值法分割图像，采用差分法比较正常表面和缺陷表面的熵图像，成功实现了对水滴、气泡和划伤的检测。K Agarwal等人^[8]采用贝叶斯建模方实现了轧钢表面接缝、鳞片、裂纹等缺陷的检测，该方法将图像中的缺陷与轧钢压制过程中的物理量结合，再结合轧机上的传感器采用贝叶斯建模，有效实现了缺陷的分类。Neogi N等人^[9]为了检测带钢表面的气泡和水渍缺陷，提出了一种全局自适应百分位数梯度图像阈值分割方法，其根据灰度图一定阈值以上的像素，自适应调整图像分割的阈值，有效地进行了缺陷的分割。Suvdaa B等人^[10]提出了一种钢材表面的缺陷检测方法，该方法采用SIFT算法进行钢材图像的缺陷区域提取，并根据生成的特征向量，采用SVM支持向量机进行分类，有效实现了钢板表面的缺陷检测和分类。Jong Pil Yun^[11]等人提出了一种钢丝棒表面缺陷检测方法，该方法采用动态规划和小波变换进行缺陷定位，再利用局部自适应二值化生成的灰度图实现缺陷的检测。Siva Sarma等人^[12]提出了一种热轧钢表面缺陷检测方法，其采用了Haar小波变化提取表面纹理特征，利用人工神经网络

ANN分类器实现了缺陷图像的分类。

国内对金属零件表面缺陷检测方法研究起步较晚，但近年来，众多高校及学者展开了细致的研究，取得了较好的理论成果和实际应用。浙江大学张刘赞等人^[13]提出了一种金属板表面缺陷检测方法，采用FoPLBP特征的非局部均值算法去除图像噪声，运用Haar小波变换处理图像后采用HOG算法进行特征提取，根据特征信息利用SVM完成缺陷的分类。冯维等人^[14]提出了一种高反工业零部件表面缺陷检测方法，采用HDRI算法合成图像，利用自适应多阈值分割算法分割缺陷，采用Haar-like算法进行特征提取，实现了表面缺陷的检测。河北大学刘婷婷^[15]采用光照自适应矫正算法消除光照影响，将图片转换为灰度图像后采用BM3D滤波算法降噪，并设计渐变式边缘提取算法提取轮廓，最后采用灰度共生矩阵提取特征，设置阈值区分缺陷图像和正常图像，实现了高反金属表面缺陷检测方法。天津科技大学申雨千^[16]提出了一种针对金属活塞杆表面凹坑、划伤缺陷检测的算法，采用阈值分割、区域填充、形态学处理方法后完成工件图像的提取，利用高斯线检测方法完成了划痕的检测。2021年，宁波大学奚昌泽^[17]提出了一种金属刀具表面缺陷分割方法，采用频域滤波过滤噪声，再利用均值漂移与自适应阈值算法分割缺陷，达到了93%的准确率。安宗权等人^[18]提出了一种金属产品表面缺陷检测方法，该方法采用自适应中值滤波去噪，非线性扩散方法平滑图像像素梯度，与原图进行差分运算，利用差分图像块的标准差构造自适应二值化模型，利用生成的二值化图像，成功实现了金属表面划痕、裂纹、缺口、锈斑等缺陷的检测。

1.2.2 基于深度学习的金属零件表面缺陷检测方法研究现状

深度学习算法对比传统图像处理方法具有诸多优势，随着算力的发展与进步，在金属零件表面缺陷检测中的应用越来越广泛。

2016年荷兰S Faghih-Roohi等人^[19]提出了一种钢轨表面深度学习检测方法，采用DCNN卷积神经网络进行图像特征提取，并利用小批量梯度下降法优化网络结构，设计了3种不同的DCNN卷积神经网络进行图像的分类，达到了92%的缺陷分类精度。2018年土耳其Selamet F等人^[20]针对东北大学NEU金属表面数据集缺陷检测问题，根据图像阴影特征，利用SFS算法进行表面缺陷区域的提取，再采用Faster R-CNN进行缺陷识别，达到了82%的检测精度，比Faster R-CNN基础模型提高了8%。Ferguson M等人^[21]提出了一种基于R-CNN算法的金属铸件表面缺陷检测方法，该方法利用公开数据集进行迁移学习，并在网络训练时，对于输入的图片，在缺陷检测的同时进行缺陷分割，获得了更高的缺陷检测精度。Hsieh C C等人^[22]在平板轨道车上安装工业相机用于自动采集金属轨道扣件，再采用YOLOv3算法进行缺陷检测，达到了89%的识别


精度。Patar等人^[23]基于实际工程应用，利用工业相机采集的图片进行金属螺钉的表面缺陷检测，对比了传统模板匹配法、SSD模型和Faster R-CNN模型，结果表面Faster R-CNN算法更优，并达到了98.8%的检测精度。Fan等人^[24]提出了一种基于辅助分类器生成对抗性网络（ACGAN）的金属板焊接缺陷的检测方法，将ACGAN与CNN结合，不仅扩展了缺陷数据，还实现了图像的分类。Aein S L等人^[25]在实际工业应用中，利用英伟达Jetson Nano嵌入式开发板部署YOLO检测模型，针对NEU金属表面数据集进行了缺陷检测测试，实现了6种类型缺陷的检测。

近年来，国内的深度学习金属零件表面缺陷检测研究快速增长，并在工业生产当中得到了大量应用。张琛等人^[26]提出了一种目标检测方法来实现金属板材表面缺陷检测，该方法在YOLOv5模型引入了CBAM注意力机制，提高模型的特征提取能力；以Deformable Convolutional Network为基础设计了可变形探测头，改进的模型在NEU-DET数据集上比基础模型提升了7%的检测精度。李衍照等人^[27]提出了一种基于改进YOLOv5的金属焊缝检测方法，该方法引入GhostNet替代主干网络CSP的残差模块，实现了网络的轻量化，采用CIOU改进坐标损失函数，提高了模型性能，改进的YOLOv5检测精度达到了96.88%。重庆大学苏迎涛^[28]提出了一种金属齿轮加工端面缺陷检测方法，采用图像处理完成提取感兴趣区域，引入Res NET-21模块和Leaky ReLu激活函数改进YOLOv3模型，改进后的YOLOv3模型缺陷检测精度达到mAP 97%，单张图像检测仅耗时70ms。华南理工大学郭子兴^[29]对铝型材表面缺陷检测进行了研究，采用MobileNet模型实现了缺陷图像的分类，随后采用改进的Cascade R-CNN模型进一步进行缺陷的识别，分类准确率达到98.39%，检测mAP达到82.16%。天津理工大学李硕^[30]采用U-NET分割决策网络，实现了金属血管支架的表面缺陷检测。王道累等人^[31]提出了一种基于级联孪生密集网络的表面缺陷检测方法SCSEG-Net，加入了空洞空间金字塔模块结构，采用级联网络优化参数，解决了金属表面缺陷检测精度不高及定位难的问题。江南大学祁阳^[32]提出了一种基于改进的ACGAN生成对抗网络的金属表面缺陷检测方法，优化了网络结构和损失函数，引入注意力机制，实现了在数据集数量有限的情况下，获得的较好的缺陷检测能力。

1.3 本文的主要研究思路和研究内容

1.3.1 本文研究思路

本论文围绕金属零件表面缺陷检测展开深入研究，在分析国内外机器视觉技术现状与金属零件表面缺陷检测面临问题的基础上，以某一金属零件的多种型号产品为研究对象，将金属零件表面缺陷检测分为两个阶段：（1）图像感兴趣区域提取；（2）缺陷检测，聚焦于提高图像感兴趣区域分割算法对多型号零件的泛化能力以及小样本下的分割性能、解决数据集样本尺度不平衡和样本类别不平衡问题、提高缺陷检测算法精度三大难题。利用语义分割算法实现图像感兴趣区域提取，提出基于迁移学习与混合注意力机制的 UNet 图像分割算法。为提高金属表面缺陷检测性能，结合金属零件表面缺陷数据集特点，针对金属零件表面数据集尺度不平衡问题，提出一种基于多尺度分块策略与 SRGAN 图像增强的方法；针对数据集中的类别不平衡问题，提出基于 UYGAN 的数据增强方法。针对卷积神经网络局限性，提出基于 Swin transformer 的 SW-YOLO 算法来获取全局上下文特征，提高缺陷检测模型性能；针对目标检测算法通道注意力表达能力不足问题，提出 ESCAM 通道注意力模块并嵌入到目标检测模型中。如图 1.1 所示为本文的研究思路与组织结构。



1.3.2 论文章节安排及研究内容

本文共分为五个章节，各章节具体研究内容安排如下：

第 1 章，绪论。本章介绍了金属零件表面缺陷检测课题的研究背景与意义，提出了本文需要解决的问题与挑战；接着简要说明了基于机器视觉的金属零件表面缺陷检测算法发展与研究现状；最后引出了本文的研究思路与研究内容。

第 2 章，金属零件表面感兴趣区域分割方法研究。构建了金属表面图像分割数据集，在介绍了各种传统图像分割算法与深度学习分割算法的基础上，分别进行了金属表面图像分割实验，选择 UNet 模型作为基础模型。为进一步提高小样本下语义分割网络的分割性能，迁移 VGG16 模型作为 UNet 下采样主干网络，同时为了加强模型的泛化能力，提出基于 CBAM 混合注意力机制的 UNet 模型。最后通过实验对比验证相关工作的有效性。

第 3 章，金属零件表面缺陷样本平衡方法研究。利用第 2 章训练的 UNet 模型提取有缺陷图像的感兴趣区域，构建金属表面缺陷数据集。针对数据集中缺陷样本的尺度不均衡与类别不均衡问题开展分析与研究，针对尺度不均衡问题，提出多尺度分块策略的尺度均衡方法，同时训练 SRGAN 超分辨率网络来提高上采样图像质量；针对样本类别不均衡问题，提出了 UYGAN 伪缺陷图像生成对抗网络，丰富了数据集样本特征。最后通过实验对比验证相关工作的有效性。

第 4 章，基于目标检测的金属零件缺陷检测方法研究。针对目标检测算法在金属零件表面缺陷检测中的应用展开了深入研究，首先论述了卷积神经网络的局限性，针对卷积神经网络对全局上下文特征提取能力的不足，引入 Swin transformer 模型作为 YOLOv5 模型主干网络提出 SW-YOLO 算法，为了进一步提高模型的性能，针对 SW-YOLO 算法对于通道注意力机制的提取能力不足的问题，提出了 ESCAM 注意力机制并嵌入 SW-YOLO 模型中，最后通过实验对比验证相关工作的有效性。

第 2 章 金属零件表面感兴趣区域分割方法研究

2.1 引言

感兴趣区域简称 ROI，由于金属零件外形复杂，原始图像中存在较多非感兴趣区域（装夹夹具、图像模糊区域等）。若直接对采集到的表面图像进行分析，那么会占用大量算力，检测的效率也无法保证；而且非感兴趣区域中存在较多干扰信息，影响模型的学习收敛与性能，因此需要利用图像分割算法将图像中的 ROI 分割出来。图像分割是指根据区域特征把图像划分成若干个互不相交且特征表现出一致性或相似性的区域。基于传统图像处理的图像分割方法主要利用灰度特征进行分割，针对性较强，无法适应金属零件表面背景的复杂变化。本章将聚焦于基于深度学习的金属零件表面图像感兴趣区域分割算法研究，设计一种适合金属零件表面感兴趣区域分割的方法，为后续金属零件表面缺陷检测提供准确的信息。金属表面图像感兴趣区域分割属于金属表面缺陷检测中的预处理环节，为了快速适配不同型号的金属零件表面图像，设计的算法应能满足在小样本下拥有较高的分割性能与泛化能力。

2.2 数据集说明

本章共收集某金属零件表面图像 360 张，其中可分为 3 种不同型号零件表面图像，分别为 A 零件 200 张，B 零件 80 张，C 零件 80 张，每种金属零件上有 5-6 种需要检测的主要部位。如图 3.1 所示为数据集中三种型号的某一部位表面图像展示，图像中覆盖红色掩膜部分为金属零件表面感兴趣区域，可以看出图像中存在大量的非感兴趣区域，且图像上的目标区域是否为感兴趣区域与目标是否清晰有关，若目标区域模糊，图像信息丢失，也不符合感兴趣区域条件。本章将基于这一金属零件表面图像数据集展开研究，设计一种能够满足金属零件表面感兴趣区域提取需求的方法。




图 2.1 数据集部分数据展示

2.3 传统图像分割方法对比

2.3.1 基于阈值的图像分割方法

阈值方法的基本思想是基于图像的灰度特征来计算灰度分割阈值从而分割图像，其基本思路是将比较图像中每个像素的灰度值与阈值之间的差异，最后根据比较结果实现像素分类。由此可知，阈值方法最关键的一步就是求解最佳灰度阈值，像素分类方法可以用式（2.1）表示，其中 $f(x,y)$ 表示原始图像， T 为阈值， $g(x,y)$ 为分割后的图像。

$$g(x,y) = \begin{cases} 1 & , f(x,y) \geq T \\ 0 & , f(x,y) < T \end{cases} \quad (2.1)$$

基于阈值的图像分割方法计算简单，成本较低，适用于目标与背景占据不同灰度级范围的场景。阈值选取是阈值分割方法的关键，根据阈值选取方法的不同可分为固定阈值图像分割方法与 Otsu 图像分割方法^[33]。

Otsu 算法主要原理是通过遍历的方法，找到能使前景和背景这两类之间的组间方差最大的阈值，从图像灰度直方图的角度来说，就是找到位于两个波峰之间的波谷最低值作为阈值。假设整幅图像的平均灰度为 μ ，前景和背景像素点占整幅图像的比例分别为 k_0 、 k_1 ，灰度平均值分别为 μ_0 、 μ_1 ，前景和背景之间的方差设为 g 。假设灰度值小于 T 的像素点数为 N_0 ，灰度级别从 0 到 $l-1$ ，灰度值大于 T 的像素点数为 N_1 ，灰度级别从 l 到 $n-1$ ，灰度值为 i 的像素出现的概率为 p_i ，那么方差 g 的计算过程如下所示^[33]。

$$k_0 = \sum_{i=0}^{l-1} p_i, \mu_0 = \sum_{i=0}^{l-1} \frac{ip_i}{k_0} \quad (2.2)$$

$$k_1 = \sum_{i=l}^{n-1} p_i = 1 - k_0, \mu_1 = \sum_{i=l}^{n-1} \frac{ip_i}{k_1} \quad (2.3)$$

$$\mu = \sum_{i=0}^{n-1} \frac{ip_i}{k_0} = k_0\mu_0 + k_1\mu_1, k_0 + k_1 = 1 \quad (2.4)$$

$$g = k_0(\mu_0 - \mu)^2 + k_1(\mu_1 - \mu)^2 = k_0k_1(\mu_0 - \mu_1)^2 \quad (2.5)$$

在阈值 T 不断遍历的过程中， g 也在不断变化，当 g 达到最大时得到的阈值 T 即为最佳阈值。

2.3.2 基于区域的图像分割方法

Zucker 等人在 1976 年提出了一种基于区域的分割算法，区域生长算法^[34]。区域生长算法是根据同一区域内像素点的相似性（纹理、平均灰度值等）来聚集像素点的方法。具体步骤为：从初始某个像素或多个像素（种子点）出发，判断种子点连通区域内的像素是否符合生长准则，将符合准则的区域合并到区域内形成新的区域，这样向外生长的过程不断重复，直到满足一定条件时，区域生长终止。即使在不知道任何先验条件的前提下，区域生长能够取得不错的结果，适合用于在目标区域具有连通性的图像中。由区域生长的定义及以上过程不难发现，基于区域生长的分割算法结果由种子点位置的选取、区域生长的准则和终止条件共同决定，因此一致性较差，同样图像使用不同的准则或种子点会产生不同分割结果，这不利于最终结果的定性分析。

2.3.3 结果对比

如图 3.2 所示分别为 Otsu 算法、区域生长算法针对四种不同表面图像的分割效果。传统图像分割算法往往聚焦于图像中灰度特征以及边缘信息，无法对图像清晰与不清晰边界进行分割，并且金属零件表面具有外形多样、机加工痕迹深，表面光照条件不均匀等特点，且存在着较多边缘信息，目标区域可能会受到缺陷因素干扰，因此，传统图像分割算法分割效果无法满足感兴趣区域分割任务需求。基于此，本文将尝试采用语义分割网络进行感兴趣区域分割。




图 2.2 传统图像分割方法结果对比

2.4 语义分割网络

2.4.1 FCN

FCN 算法将 VGG16 分类网络最后的全连接层替换成两个卷积层，并连接转置卷积进行上采样，最终将特征解码为原图分割结果^[35]。FCN 共三个版本：FCN-32s、FCN-16s 和 FCN-8s，它们的分割性能依次提高，输入图片经过 VGG16 主干网络前 5 次卷积池化模块，最终得到大小为原图 1/32 的特征图，FCN-32s 直接对最终的特征图进行解码获取预测结果；而 FCN-16s 融合了 VGG16 模型中第四层池化层下采样特征；FCN-8s 相比 FCN-16s 结构，进一步融合了第三层池化层特征，FCN-8s 网络结构如图 2.3 所示。深层特征的细节信息会随着卷积网络深度的加深而丢失，造成了 FCN-32s 分割结果不佳，融合包含细节信息的浅层特征可以提高分割性能。浅层特征相比于深层特征更聚焦于图像局部特征，但无法对图像特征进行抽象表达，为避免浅层特征掩盖深层特征从而降低分割的效果，需构建合适的浅层特征融合机制。FCN 算法仍存在着许多不足，近年来，许多基于 FCN 思想改进的语义分割方法被提出，均取得了一定的优化效果。




图 2.3 FCN-8s 网络结构

2.4.2 PSPNet

PSPNet 全称 Pyramid Scene Parsing Network，PSPNet 模型的提出是为了解决场景分析问题，模型利用不同区域的上下文特征进行融合，显著提升模型获取全局上下文特征能力^[36]。PSPNet 通过对主干网络提取的特征设计金字塔池化获取不同层次特征，使用 1×1 卷积的方式减少通道数，再通过上采样并与原特征图进行堆叠，最后利用卷积融合上下文信息进行标签预测即图像分割。得益于 PSPNet 金字塔池化模块，PSPNet 具有融合特征图上下文信息与局部信息的能力。




图 2.4 PSPNet 网络结构

2.4.3 Deeplab

DeepLab 系列是由 GoogLe 团队提出的一种图像语义分割网络^[37]。为保证分割结果保留较好的细节信息，DeepLab 将编码特征图扩大到了输入图像的 $1/8$ ，而这又会导致特征对全局上下文信息表达能力不足的问题。因此，DeepLab-v1 算法引入了空洞卷积，空洞卷积的好处是在不增加网络参数的情况下提高了模型感受野。空洞卷积的计算方式如图 2.5 所示，图中方块代表图像或特征图像素，标黄部分代表与卷积核进行卷积操作的特征图像素。空洞卷积相比于传统卷积，卷积核与上一层特征图交互区域扩大了，因此通过空洞卷积获得的特征具有更大的感受野，更大的感受野能够获取更多的全局信息。




图 2.5 普通卷积与空洞卷积

DeepLab-v2 网络将主干网络替换成为了采用空洞卷积的 ResNet，为了提升网络的多尺度特征提取能力，借鉴 PSPNet 金字塔池化模块在网络中设计了空洞金字塔卷积（ASPP）模块。DeepLab-v3 网络改进了 DeepLab-v2 中 ASPP 模块，并且为进一步提升 DeepLab 网络分割效果，DeepLab-v3+ 将 Xception 网络中最大池化层改为了步长为 2 的卷积。整体网络结构如图 2.6 所示，采用 ASPP 模块来捕获特征图的多尺度信息，将不同尺度特征进行堆叠后利用卷积对通道进行降维，得到的深层特征上采样与主干网络中浅层特征进行融合，上采样后得到最终的分割结果。




图 2.6 deeplabv3+ 网络结构

2.4.4 UNet

为解决医学图像语义分割问题，UNet 网络被提出，因其速度快、所需数据量少、检测效果较好，被广泛用于图像分割任务中^[38]。根据模型结构的特点将每次下采样或上采样之前的操作称为一个台阶模块，左侧收缩路径为特征提取过程，经过 4 次下采样，图像特征从细节局部特征转变为抽象全局特征；右侧扩张路径经过 4 次上采样，使分割图像恢复到原图像大小。UNet 网络在收缩路径与扩张路径间对称的台阶模块之间使用了长跳跃连接，保证了最后复原的特征图能够包含更多的浅层特征，同时也使得解码过程不同层特征得到了融合，因此可以在解码部分进行多尺度预测，解码部分 4 次上采样也使得最终分割图边缘等细节信息更加精细。为了将最终输出分为目标类别，网络的最后使用一个 1×1 的卷积，将最终的分割结果分成两类，U-net 网络结构图如图 2.7

所示。




图 2.7 UNet 网络结构

2.4.5 语义分割网络对比

金属表面图像感兴趣区域分割属于金属缺陷检测的预处理过程，对部署效率要求较高。为了满足金属表面缺陷检测的快速部署，网络模型应在小样本下达到相对高的分割性能精度。为了优选适合本项目小样本情况下的金属零件表面感兴趣区域分割方法，本文选取了主流的三种语义分割网络模型 PSPNet、Deeplabv3+、UNet，从本文 2.2 节中提到的金属表面图像数据集中选取 A 产品表面图像作为训练集与测试集，分别在 40、60、80 等三种不同样本量条件下进行分割测试，结果如表 2.1 所示。

随着训练集容量的提升，各语义分割模型在测试集上的性能均有提升，样本量从 40 张图像增加到 80 张图像时，模型的 Mean IoU 性能均有所提升。在训练集容量较小的情况下，UNet 对比其他网络模型性能最优，在 40 张图像的训练集上，UNet 模型相对于 PSPNet、Deeplabv3+ 的 Mean IOU 指标分别提升了 21.24%、9.42%，在 80 张图像的训练集上，UNet 模型相对于其他模型的 Mean IOU 也提升了 12.59%、2.08%。实验进一步验证了 UNet 模型在小样本数据上的优势，UNet 模型更加适用于金属零件表面 ROI 区域分割任务。

表 2.1 不同样本量下语义分割网络性能对比

训练集容量	性能指标		PSPnet	Deeplabv3+	UNet
40	IoU	背景	48.78%	98.43%	99.06%
		ROI	95.78%	82.23%	87.98%
		Mean IoU	72.28%	90.33%	93.52%
60	IoU	背景	96.90%	98.66%	99.09%
		ROI	63.12%	83.66%	88.32%
		Mean IoU	80.01%	91.16%	93.71%
80	IoU	背景	97.17%	98.83%	99.18%
		ROI	66.14%	85.5%	89.31%
		Mean IoU	81.66%	92.17%	94.25%

2.5 UNet 语义分割算法优化

2.5.1 迁移学习

迁移学习是指将知识从源域迁移到目标域并使目标域获得更好性能的方法。按照迁移的具体知识不同，迁移学习可以被分为实例迁移学习、参数迁移学习、特征迁移学习与关系迁移学习四类^[39]。随着在 ImageNet 等大型数据集上训练的具有较好泛化能力的标准模型 ResNet、VGG16、DenseNet 等一系列网络的提出，基于参数的迁移学习成为应用最多的迁移学习方法之一。其基本思路是利用标准模型的特征提取能力提取图像特征，替换标准模型输出层为目标场景输出层，并冻结其中特征提取网络参数，在目标域中重新训练该网络。最后，在目标数据集上微调所有网络参数，对整体性能进行更为细致的优化^[40]。参数迁移学习已经在很多领域得到验证，并取得了非常好的优化效果。

在金属零件表面感兴趣区域检测任务中，期望能在小样本下得到较好的分割性能，将 UNet 网络下采样提取特征的过程替换为 VGG16 主干网络，去除全连接层，将 VGG16 中不同大小的池化层特征作为 UNet 的下采样特征，能够显著的提高模型性能，加快模型的收敛速度，基于 VGG16 的 UNet 网络模型如图 2.8 所示。





图 2.8 VGG16+UNet 网络结构


为验证迁移学习对模型收敛速度与性能的影响，本节设计了参数迁移前后的实验对比，从节 2.2 中提到的金属表面图像数据集中选取 A 产品表面图像作为训练集与测试集，其中 80 张为训练集，120 张为测试集。从收敛速度与模型性能两个角度进行比较，结果如表 2.2 和图 2.9 所示。由表 2.2 可知：经过参数迁移后的模型 Mean IOU 提升了 2.21%。由图 2.9 可知：模型收敛轮次从 80 轮降低至 10 轮，训练效率大大提升。上述实验结果表明：应用参数迁移学习对 Unet 网络模型应用于小样本下的金属零件表面感兴趣区域分割的收敛速度与分割性能具有显著的作用，有效减小了金属表面图像 ROI 分割网络的训练代价，提高了分割效果。

表 2.2 参数迁移实验结果对比

方法	类别	IOU	Mean IOU
参数迁移	背景	99.18%	94.25%
	ROI	89.31%	
无参数迁移	背景	98.82%	92.04%
	ROI	85.25%	



(a)无参数迁移



(b)参数迁移

图 2.9 损失下降趋势对比

2.5.2 混合注意力机制

在卷积神经网络中，特征所表达的语义信息随着模型深度增加而变得抽象，这也意味着细节局部特征的丢失，语义分割上采样过程中浅层特征的融合有助于网络更好地恢复图像细节。UNet 网络在上采样过程中通过长连接融合下采样过程的浅层特征。然而，浅层特征与深层特征对结果的贡献是不同的，若直接将不同深度特征进行融合可能会导致浅度特征对深层抽象特征的掩盖，从而使网络提取的特征中图像全局信息不足导致分割性能降低。为了提高图像细节和小目标的分割能力，需要加强采样过程中对浅层特征融合的针对性。传统的卷积神经网络假设所有特征信息重要性是一致的，没有考虑不同通道和不同位置特征的重要性区别。因此，在 UNet 长连接过程中引入注意力机制，增强融合浅层特征中重要特征的能力，提高网络的图像分割性能。

注意力机制是广泛应用在自然语言处理、图像识别及语音识别等各种不同类型的机器学习任务中的一种数据处理方法。注意力机制本质上与人类对图像的观察机制相似，人眼在观察时，首先会比较关注图像的某些显著性区域，然后再把重要区域信息进行融合形成对图像的整体认识，注意力机制的做法是为不同特征赋予不同权重，且权重是模型学习得来的。在机器视觉领域，注意力机制按照注意力关注的域可以分为通道域、空间域、时间域、混合域等^[41]。

CBAM 模块是一种通道注意力 CAM 模块在前，空间注意力 SAM 模块在后串联形成的混合注意力机制，综合考虑通道与空间注意力。与通道域注意力 SE 模块相比 CBAM 模块增加了空间域的注意力机制，强调了空间和通道两个维度上更重要的特征；同时，在通道注意力模块中增加了全局最大池化，使用两种不同的池化意味着能够提取更加丰富的通道注意力特征^[42]。在 UNet 模型中引入混合注意力模块 CBAM 模块，并将其添加到模型中浅层特征融合的过程中，进一步加强模型特征提取能力。在 U-net 网络中加入 CBAM 模块，不仅可以增强模型的特征提取能力，而且可以提高网络的泛化能力。因为 CBAM 模块可以抽取对结果更为重要的特征，提高了特征对图像的抽象表达能力，此时提取的特征应是图像中更为重要的共性特征，CBAM 模块示意图如图 2.10 所示。




图 2.10 CBAM 模块

2.6 评价指标及实验结果分析

2.6.1 图像分割性能评价指标

图像分割模型的任务可以看作是对图像像素点进行分类，与分类网络类似，针对图像中像素类别的真实标签与预测标签，可以统计出像素分类的 TP、FP、FN 并列混淆矩阵^[43]，如表 2.3 所示：

表 2.3 混淆矩阵

类别标签	预测类别		
	A	B	C
A	TP	FN	FN
B	FP	TP	FN
C	FP	FP	TP

依据混淆矩阵可以计算 IoU 指标，其与混淆矩阵中各统计量的关系如式 2.7 所示，它表示分割算法对图像当前类别像素的 TP 与 FP、TP、FN 之和的比值。各类别 IoU 指标的均值为 Mean IoU，如式（2.7）所示。

$$IoU = \frac{TP}{FP + TP + FN} \quad (2.6)$$

$$Mean IoU = \frac{\sum_{i=1}^n IoU_i}{n} \quad (2.7)$$

2.6.2 实验结果分析

为验证本文 2.5.2 节中所提出的基于 CBAM 注意力机制的 UNet 图像分割算法的有效性与优越性，从 2.2 节中提到的金属表面图像数据集中选取 A 产品表面图像作为训练集与测试集，其中 80 张为训练集，120 张为测试集，另外将 B 产品的 80 张图片、C 产品的 80 张图片全部作为测试集。分别训练 VGG16+UNet(base)模型与嵌入 CBAM 注意力机制的 VGG16+UNet 模型，测试模型对不同产品金属表面感兴趣区域的分割性能，测试结果如表 2.4 所示。

表 2.4 基于 CBAM 的 UNet 实验结果对比

产品类型	性能指标		base	CBAM
A	IoU	背景	99.18%	99.32%
		ROI	89.31%	91.46%
		Mean IoU	94.25%	95.39%
B	IoU	背景	97.60%	97.94%
		ROI	71.72%	75.72%
		Mean IoU	84.66%	86.83%
C	IoU	背景	96.07%	96.34%
		ROI	60.37%	63.84%
		Mean IoU	78.22%	80.09%

从表 2.4 中可知，在 UNet 中引入 CBAM 混合注意力机制有利于图像特征的提取，针对 A 类零件的 Mean IoU 指标相比 base 模型提高了 1.24%。而 UNet 模型对其他型号产品表面图像分割同样具有一定泛化能力，这意味着 UNet 模型可以满足通过少量标注分割不同型号产品图像的需求，引入 CBAM 注意力机制后的 UNet 模型有比 base 模型具有更强的泛化能力，相比 base 模型，引入 CBAM 模块后的 UNet 模型在 B、C 类型产品图像分割上 Mean IoU 指标分别提升了 2.17%，1.87%，这进一步说明了 CBAM 模块有利于模型学习更抽象、更具共性的特征表达。

2.7 本章小结

在介绍了各种传统图像分割算法与语义分割算法的基础上，针对金属零件表面感兴趣区域分割任务的特点，首先利用传统图像分割算法分别进行了金属零件表面图像分割实验。结果表明，传统的图像分割算法难以适配金属零件表面感兴趣区域分割任务的复杂性。在 PSPNet、DeepLabv3+、UNet 三种主流语义分割模型中，UNet 模型在小样本下性能最佳。以 UNet 模型为基础，本章提出了基于迁移学习与 CBAM 注意力机制的 UNet 模型应用于金属图像感兴趣区域分割，进一步提高了模型的性能与泛化能力。通过将 UNet 模型的下采样过程替换为 VGG16 主干网络并保留模型参数，网络的收敛速度与性能得到提升，实验结果表明迁移学习相比原始 UNet 收敛速度提升了 8 倍，模型 Mean IOU 也提升了 2.21%。为优化 UNet 模型的特征融合机制引入了混合注意力 CBAM 模块，与原 UNet 模型对比，模型的性能在不同型号零件上均有提升，分别为 1.24%，2.17%，1.87%，在训练集中没有出现的 B、C 类型产品图像分割上性能提升更大，这也说明了 CBAM 模块加强了模型泛化表达能力。

第 3 章 金属零件表面缺陷样本平衡方法研究

3.1 引言

深度学习是一种数据驱动的机器学习方法，其核心理念是通过训练大量数据来自动学习特征并进行预测，而无需手动提取特征。数据在深度学习算法中扮演着至关重要的角色，数据量的大小和数据质量的好坏将直接影响模型的效果和泛化能力。

然而，在金属零件表面缺陷检测领域，由于工业生产的不合格率很低，缺陷数据难以收集。同时，不同类别缺陷在金属零件表面出现的概率不相同，导致样本类间不平衡问题严重。此外，金属零件表面缺陷的尺度变化很大，在金属零件表面图像中的大小差异也很明显。这些问题都将对目标检测的性能产生很大的影响。为了解决这些问题，本章将对收集的金属表面缺陷数据集进行深入分析，并探讨从数据层面改善目标检测模型性能的方法。

3.2 图像预处理与数据集说明

第 3 章中，金属零件表面图像中的感兴趣区域已经通过 UNet 模型进行分割。通过语义分割模型得到获取感兴趣区域掩膜，利用得到的掩膜确定感兴趣区域的坐标信息，这里不直接使用分割后的图像作为目标检测的数据集，原因在于语义分割过程中可能会产生边缘锯齿、边缘信息不规整等问题，进而影响目标检测网络的训练过程，导致目标检测网络表现效果不佳，在后续的预测中可以利用该掩膜筛选出不在感兴趣区域内的缺陷目标。如图 3.1 为语义分割模型预处理金属表面图像过程，背景与模糊的金属零件表面区域均被去除。




图 3.1 预处理过程

本文数据集中的图像均在真实生产过程中采集。在真实生产过程中，不合格样本的获取相对困难。由于装备的稳定性及工艺的不断优化，通常情况下不合格样本出现的概率较低，同时不合格样品的不同种类缺陷间数量的均衡性也难以保证。在本章的目标检测模型数据集中共包含 5000 张 A 类型金属产品表面图像，但其中有缺陷图像仅有 456 张。数据集中的缺陷区域均被手工标记为 4 种类别，分别为损伤 212 个、脏污 562 个、纤维 416 个、油污 275 个，4 种类别的样本按 7: 3 的比例划分为训练集与测试集。

如图 3.2 所示为金属零件表面图像上的各种缺陷类型展示，由于大多数金属零件在生产过程中对表面洁净度要求不高，其表面会出现大量脏污、纤维、异物等干扰噪声。金属零件加工过程中，会伴随着车削液、润滑油、冷却液的使用，在加工完成后，出于金属零件对表面保护的要求，零件表面往往会涂抹防锈油，也会在零件表面产生油渍。如图 3.3 所示，仅对损伤缺陷进行训练时模型会出现大量误检情况，可以看出模型对于损伤特征的理解比较泛化，对于油渍、脏污、纤维等异常现象预测为损伤，若无法对这些噪声进行过滤，目标检测模型的检测性能可能会受到影响，无法满足缺陷检测需求。通过对干扰噪声的打标学习，可以使模型对缺陷的特征表达更加收敛，同时也能强化模型对表面的特征提取能力。




图 3.2 金属表面常见异常图像




图 3.3 误检图像展示

3.3 金属零件表面缺陷样本不平衡问题研究

3.3.1 样本尺度不平衡问题

在金属表面缺陷数据中，存在两种尺度不平衡问题。

（1）目标实例与输入图像的尺度不平衡

由于金属零件表面缺陷在某些情况下比较细微，需采取高分辨率、小视场的成像条件进行成像。如图 3.4 所示，金属表面缺陷目标区域仅占图像的很小部分区域，这会导致出现图像与目标的尺度不平衡问题。




图 3.4 金属表面小目标缺陷样本

在目标检测算法中，不同的图片长宽都不相同，通常的方式是将原始图片统一缩放到一个标准尺寸再输入检测网络中。Yolov5 算法中的具体实现步骤如下所述：首先根据原始图片大小以及输入到网络的图片大小计算缩放比例，然后根据原始图片大小与缩放比例计算缩放后的图片大小对图像进行缩放，最后根据缩放后的图像尺寸在图像边缘均匀地填充灰边，缩放后的金属表面图像如图 3.5 所示。




图 3.5 yolov5 中的图像缩放

若直接将原图降采样到网络框架要求的输入大小进行预测，小目标缺陷信息可能在降采样中被消除。如图 3.6(b)所示为直接对原图进行缩放后的结果，可以看出，图中小目标区域在降采样过程中信息严重丢失，即使图中依然保留了少量信息，也可能导致模型无法提取到准确的特征，从而影响模型检测效果。另一方面，图像与目标实例的尺度不平衡问题会导致边界框回归难度从像素级跃迁到亚像素级，边界框回归的精度难以保证。




图 3.6 降采样前后的缺陷图像对比

(2) 目标实例之间的尺度不均衡问题

由于金属零件表面缺陷产生的面积具有不确定性，既存在如图 3.4 所示的小目标缺陷区域，也存在如图 3.7 所示的大面积缺陷区域，这将导致另一种尺度不均衡现象，即目标之间的尺度不均衡问题。




图 3.7 金属表面大目标缺陷样本

目标之间的尺度不平衡问题会导致不同的特征层对最终结果的贡献不平衡，在很大程度上影响目标检测模型性能。本文选取的目标检测模型为 YOLOv5s 模型，输入图像在经过特征提取网络后下采样到原图大小的 $1/8$ 、 $1/16$ 、 $1/32$ ，然后针对特征图进行结果预测。理论上，特征图越小，感受野越大，不同的特征层将用于满足不同尺度的目标检测，而目标实例之间的尺度不均衡问题会导致网络训练时不同特征层表达能力的差异。如图 3.8 所示为样本相对尺度分布情况，其中横纵坐标分别代表目标实例的相对宽度 w_{scale} 与相对高度 h_{scale} ，具体的计算公式如下所示。

$$w_{scale} = \frac{w_{pixel}}{W_{pixel}} \quad (3.1)$$

$$h_{scale} = \frac{h_{pixel}}{H_{pixel}} \quad (3.2)$$

其中， W_{pixel} 与 H_{pixel} 分别代表最大目标实例的像素宽度与像素高度，其他目标的像素宽度与像素高度分别用 w_{pixel} 与 h_{pixel} 表示。

从图中可以看出，在本文所使用的数据集中，样本主要集中在相对较小的尺度上，随着目标尺度的扩大，样本量不断减少。




图 3.8 目标相对尺度分布情况

3.3.2 样本类别不平衡问题

金属零件表面数据集中存在两种类别不平衡问题，分别是前景与背景的种类不平衡问题以及前景与前景的种类不平衡问题。

前景与背景的种类不平衡问题是指在数据集中，由于不合格品的产生会对企业的成本与效益带来巨大影响，金属零件在生产过程会进行严格把控，不良品率通常很低，本章采集的金属零件表面数据中，缺陷图像占数据集<1%，前景与背景的不平衡可能会导致目标检测模型在小样本的数据集上出现过拟合现象：模型在训练集中表现良好而在测试集中性能大幅下降。

由于金属零件表面不同种类缺陷出现的概率大不相同，样本类别的不平衡问题是金属零件表面缺陷检测领域中的普遍性问题，在本文收集的数据集中，各类缺陷比例为，长尾数据失衡是指在训练样本中，其中头部有大量的样本点，但尾部仅有少部分样本，如图 3.9 所示。这种训练样本的类别不平衡导致深度学习模型的性能表现不佳。样本类别不平衡使模型在训练过程中过多地接收样本数量多的类别产生的贡献，而稀释样本数量少的类别对模型参数的影响，这

将直接导致模型在测试集上的性能降低。在本章采集的数据中位于头部，即样本量较多的样本类别为脏污、异物、油渍，而损伤位于样本数量分布的尾部，这种类别的不平衡会使训练得到的模型在样本较少的类别上性能上进一步降低。




图 3.9 数据集中的样本类别不平衡问题

3.4 样本尺度平衡方法研究

针对样本尺度不均衡问题，采用图像多尺度分块策略来平衡图像与目标之间的尺度不平衡、目标之间的尺度不平衡问题。采用多尺度分块策略的原因主要在于小目标区域相较于原图所占面积较小，利用不同尺度的上下文区域进行图像分块的策略可增加小目标区域在原图中的比例，同时可保证大目标实例的相对完整性，以提高数据的尺度不变性，进而平衡不同尺度目标特征的学习效果。图像增强策略作用在小目标上，可克服低分辨率小视野分块图像上采样过程中小目标特征失真情况。通过图像增强方法提升小目标特征，使得目标检测网络学习到更为真实的缺陷特征。

3.4.1 多尺度分块策略

(1) 多尺度分块训练策略

人类总是以固定的距离和大小关注物体。例如，当我们聚焦于附近的物体时，远处的物体会变得模糊。当然，我们很难同时关注不同尺度的物体。我们只处理任意给定焦点的小视场，并自适应地忽略图像中剩余的视觉内容。因此，即使现有的目标检测算法通过构建特征金字塔，融合不同尺度的特征来达到不同尺度目标检测的方法取得了一定的优化效果^[44]，但在图像与目标尺度不均衡问题严重时，这种特征金字塔的方法也难以取得很好的效果。由于金属表面某

些缺陷目标较小，而金属表面缺陷图像分辨率较高，以适当的比例选择目标周围的上下文区域来训练目标检测模型是一种较好的处理策略。根据图像的目标区域，选择不同尺度大小的上下文区域进行分块，再通过降采样或上采样的方式对图像块进行缩放，以满足目标检测模型标准输入大小，同时使目标尺度均衡化。本文共采取两种尺度选取接近网络框架标准输入大小作为大视野矩形通过对小视野的插值上采样缩放到网络框架，既增大了图像相对原图的比例，又平衡了图像中输入图像与目标的尺度分布,如图 3.10 所示：




图 3.10 目标相对尺度分布情况

经过多尺度分块之后的数据集目标实例相对输入图像的尺度分布情况相对均匀，目标实例之间的尺度分布也更为均衡，改善了数据集中的两种尺度不平衡现象。

另一方面，图像的分块策略也为样本带来了更丰富的样本，如图 3.11 所示，同一个缺陷目标实例在进行不同位置，不同大小的图像块切分后得到了新的四张缺陷样本，扩充了样本数据量。






图 4.11 多尺度分块后的缺陷图像块图像

(2) 多尺度测试策略


模型测试过程中，由于图像中的目标实例标签位置未知，需采用多尺度重叠切块的策略将图像切块。选取与训练集相同的两种尺度，将图像分块，相邻图像间保留一定的重叠区域，超出图像区域部分用灰边进行填充。图像切块完成后，将图像块送入目标检测模型中预测，图像块边缘部分存在重叠目标，需要将临块的相同检测目标进行堆叠，使用非极大值抑制（NMS）算法^[45]对检测结果进行合并，从而输出最终的检测结果。如图 3.12 所示。



(a)多尺度重叠分块与填充



(b)图像块检测结果堆叠



(c)非极大值抑制

图 3.12 多尺度分块测试过程及结果

3.4.2 基于 SRGAN 的图像增强方法

图像多尺度分块策略在平衡数据尺度不均衡问题起到了显著的作用，但由于其选取的小视野尺度图像块是通过上采样插值的方式归一化到模型标准输入的，图像块上的缺陷区域会出现失真的情况，这不利于目标检测网络对缺陷特征的学习。如图 3.13 所示，小视野图像块在经过插值后，图像上的缺陷特征与原图的缺陷特征呈现出一定程度的失真。为此，需要借助图像增强方法对图像进行更好地上采样，以恢复上采样图像的细节与质量。




图 3.13 上采样前后的图像对比

由于小视野图像包含的颜色、边缘方向、纹理特征等信息太少，特征表达不充分，即使是人类也很难在小视野图像分辨出语义信息，这从数据层面提高小视野图像质量的难度。使用图像增强技术可丰富小视野图像表达能力，提高小视野图像中的颜色、边缘方向、纹理等特征的显著性。小视野图像的高分辨率恢复的难点在于图像中信息过少，基于各种插值方法的传统图像增强技术手段很难解决这一难题。

超分辨率技术是指在原图像基础上增强原图像像素的方法，深度学习可以对图像进行超分辨率重建，原理是通过卷积网络学习低分辨率图像与原图像之间的映射关系，与图像插值上采样方法相比具有更加高维的表达能力，超分辨率重建网络模型能够有效提高小目标的特征质量^[46]。在金属表面图像中，由于金属表面的材质、表面形貌、成像条件等因素具有邻域相似性，这使得利用深度学习构建超分辨率重建模型具有理论可行性。

生成对抗网络是性能较好的用于图像生成的模型。它的基本思想是，构建生成器与鉴别器模型，生成器用于图像的生成，一般是编码-解码结构，目标是生成尽可能真实的图像；鉴别器是一个分类网络，用于鉴别图像是真实图像还是生成器生成的虚拟图像，目标是尽可能的区分输入图像来自真实数据还是生成数据^[47]。通过生成器与鉴别器的对抗训练，使得生成器具备生成真实的生成

图像。这一思路在图像超分辨率领域得到了很好的应用。

借鉴生成对抗网络的思想，2016 年 SRGAN 超分辨率生成对抗网络被提出^[48]，SRGAN 超分辨率网络的结构如图 4.14 所示，SRGAN 网络由两部分组成，即生成器和鉴别器，生成器中引入了 Subpixel 模块，该模块可以避免在超分辨率过程中，引入过多变量而影响超分辨率效果。具体的实现思路是：假设超分辨率倍数为 r ，对低分辨率输入进行多次卷积，最终得到 r^2 多维特征，而上采样过程则是将 r^2 维特征直接拼接为高分辨率图像，减少了转置卷积对高分辨率图像像素的影响。SRGAN 的鉴别器是一个分类网络，特征的数量随网络层数的增加而增加，而当网络层数减少时特征数量也随之降低，并且利用全局池化获取将特征降维到一维向量，利用 1×1 卷积获得预测类别。因为生成网络与预测网络均为全卷积网络，故 SRGAN 可以输入任意大小的图像，只需指定超分辨率倍数。此外，在 SRGAN 网络的训练过程中，还需使用预训练的 vgg19 模型，在 SRGAN 鉴别器的训练阶段，预训练的 vgg19 模型权重不参与训练过程中的权重更新，仅参与计算特征层面的内容损失。




图 3.14 SRGAN 网络结构

SRGAN 网络的损失函数由三部分组成，分别是：像素级内容损失、对抗损失和特征级内容损失。在超分辨率任务中，生成的超分辨率图像与真实的高分辨率图像无论是低层次的像素值上，还是高层次的抽象语义特征上，以及整体概念和风格上，都应当接近。利用 $MSELoss$ 计算生成的超分辨率图像与真实的高分辨率图像的像素匹配程度得到像素级内容损失；特征级内容损失通过 VGG19 模型提取生成的超分辨率图像与真实的高分辨率图像的高维特征，计算高维特征之间的匹配程度，使得生成的超分辨率图像尽可能的接近真实图像的语义与风格特征；借鉴生成对抗网络思想引入对抗损失，对抗损失是一个极大极小损失函数，该对抗损失期望对鉴别器而言，尽可能地区分生成图像与真实图像，生成器则期望生成的图像尽可能让鉴别器无法区分。总体的计算公式如式 (3.3) 所示，其中 $Loss^{SR}$ 代表 SRGAN 的总体损失， $Loss_X^{SR}$ 代表像素级内容损失， $Loss_{Gen}^{SR}$ 代表对抗损失， $Loss_{TV}^{SR}$ 代表特征级损失。

$$Loss^{SR} = Loss_X^{SR} + 10^{-3} Loss_{Gen}^{SR} + 10^{-8} Loss_{TV}^{SR} \quad (3.3)$$

3.5 基于 UYGAN 的样本类别平衡方法研究

总量丰富且类别平衡的数据集可提高目标检索网络的训练效果。由于实际样本获取困难,通常情况下,使用数据增强方法丰富数据集的总量,并改善数据的类别不平衡现象。众多研究人员探索了大量实现数据增强的方式,其中常用方法如图像裁剪、旋转、平移变换、颜色变化、缩放和噪声扰动等^[49]。经过数据增强后的数据集有益于提升目标检测的效果,由于训练样本的丰富度得到了提升,进而提高模型的鲁棒性,防止过拟合。YOLOv5 算法中使用了 Mosaic 数据增强方法,选取 4 张图像,随机利用裁剪、旋转、平移、缩放和噪声扰动等操作得到数据扩展的图像并将其粘贴到纯灰背景上得到 4 张数据拓展图,最后将 4 个图像拼接成一张新图像^[50],如图 3.15 所示。Mosaic 数据增强方法拼接得到的图像背景丰富,并且包含原图像上的目标对象,丰富了数据集的质量,强化了网络对于小目标对象的学习,但这些图像增强方式难以实现对目标实例特征丰富度的增强。




图 3.15 Mosaic 数据增强

基于已有的样本的学习,生成对抗网络(Generative Adversarial Networks, GAN)可自动生成大批类似样本。GAN 是两个网络,在训练时需要交替迭代训练,在训练判别器时依然需要海量的真实样本。当样本数量不足时,很难训练出理想的 GAN 模型,且 GAN 生成的缺陷图片也可能不符合真实的缺陷情况,例如在实际生产中缺陷产生的位置通常不是完全随机出现的,而 GAN 无法满足在某一位置生成伪缺陷实例。

为解决上述 GAN 算法无法满足金属零件表面缺陷数据增强的问题,本节提出了 UYGAN 网络结构,通过学习少量缺陷样本与背景之间的联系,生成新的相似缺陷样本。具体的实现框架如图 3.16 所示。




图 3.16 UYGAN 样本生成模型

其中生成器采用第 3 章中用于提取感兴趣区域的 UNet 模型的预训练参数，保证生成器本身具备金属表面图像特征提取的能力，利用 UNet 在上采样过程中的长连接保证在伪缺陷图像生成过程中，背景能够获得较好的细节重建效果。

鉴别器的目标是区分真实的缺陷区域和伪缺陷生成区域，利用 YOLOv5s 模型作为鉴别器可以增强其分辨能力，防止在 GAN 中用于鉴别的分类网络受到背景特征干扰，无法区分真实图像与伪缺陷图像。

在训练中引入随机变量 $Z(x,y)$ 的目的是通过 UYGAN 网络的训练学习，构建 $Z(x,y)$ 与缺陷样本之间的映射关系，在生成图像时获得特征更加丰富的伪缺陷图像，同时引入与 SRGAN 中相似的像素内容损失与特征内容损失，帮助模型更快速地学习缺陷特征。

选择金属表面缺陷训练集中的损伤缺陷样本作为 UYGAN 的训练集，如图 3.17 所示，模型在训练的过程中生成得到伪缺陷图像越来越逼真，经过 500 轮训练后，得到了用于生成的损伤缺陷图像的 UNet 模型。




图 3.17 UYGAN 生成图片随训练轮次的变化

生成缺陷图像的具体步骤为：在无缺陷图像中人工选取期望生成缺陷的区域与大小，截取期望区域以及它的邻近区域得到局部图像块，在局部图像块中的期望区域生成随机变量，最后将带有随机变量的图像块输入 UNet 模型中，最终输出伪缺陷图像。采用该方法生成图像的优势在于：（1）缺陷产生的区域与大小由人工选取，使得最终生成的伪缺陷图像具有现实意义；（2）通过随机变量，使得生成的伪缺陷图像具有与样本库中样本特征相似而不完全一样的特征信息，增强了样本的丰富度。




图 3.18 生成伪缺陷图像流程

生成的损伤伪缺陷图像如图 3.19 所示，当期望伪缺陷区域出现在金属表面图像边缘位置时，生成伪缺陷具有类似磕碰的表现特征，当期望区域出现在平滑表面上时，表现为类似划伤的特征，这直观反映了生成器学习了缺陷区域与背景之间的联系，生成的图像已经具有逼真的缺陷特征。




图 3.19 部分伪缺陷图像展示

3.6 评价指标及实验结果分析

3.6.1 图像质量评价指标

根据评价方法的不同，可以将图像质量评价(image quality assessment, IQA)方法分为：基于人类视觉的主观评价方法和基于定量分析的客观评价方法。其中，主观评价方法受评价人员的影响不具备可比性，所以目前图像质量评估领域的主流评价指标一般采用基于定量评估的客观评价方法，客观评价方法根据有无参照图像又可分为全参考评价方法与无参考评价方法，在本文中主要应用全参考评价方法来评价图像质量^[51]。

全参考评价方法通过比较待评价图像和参考图像之间的差异来评价图像质量,通常做法是设计特征比较图像之间的局部差异，再把图像质量与整幅图像的平均局部差异关联起来。最常见的全参考评价方法是结构相似性(structural

similarity index, SSIM) 与峰值信噪比(Peak Signal Noise Ratio, PSNR)。由于其计算复杂度小, 易于实现, 在图像处理领域中广泛应用。

(1) PSNR

均方误差 (Mean squared error, MSE) 可以衡量两幅图像像素之间的距离, 而峰值信噪比与其成反比, 可以用来评估图像保真性, 确定图像中引入噪声或失真的严重程度^[52]。对于待评价图像而言, 与参考图像的距离越小, MSE 越小, PSNR 也就越大, 其计算公式如下所示。

$$MSE = \frac{\sum_{i=1}^H \sum_{j=1}^W (x(i,j) - y(i,j))^2}{H \times W} \quad (3.4)$$

$$PSNR = 10 \log_{10} \left(\frac{MAX^2}{MSE} \right) \quad (3.5)$$

其中, H, W 代表图像的宽高, i, j 表示图像的像素坐标, MAX 代表图像颜色的最大数值, 8 位采样点表示为 255。

(2) SSIM

虽然 PSNR 可以衡量图像保真性, 但其与人眼视觉系统的习惯并不一致, 结构相似性是一种更契合人类主观感受特性的评价指标, SSIM 比较图像之间的结构信息相似性, 包括亮度、对比度、结构细节^[53]。SSIM 的取值范围为[0, 1]。结构相似性与图像质量之间呈正相关关系, SSIM 的计算过程如下所示。

$$SSIM(x, y) = l(x, y)^\alpha c(x, y)^\beta s(x, y)^\gamma \quad (3.6)$$

$$l(x, y) = \frac{2\mu_x\mu_y + C_1}{\mu_x^2 + \mu_y^2 + C_1} \quad (3.7)$$

$$c(x, y) = \frac{2\sigma_x\sigma_y + C_2}{\sigma_x^2 + \sigma_y^2 + C_2} \quad (3.8)$$

$$s(x, y) = \frac{2\sigma_{xy} + C_3}{\sigma_x\sigma_y + C_3} \quad (3.9)$$

其中 $l(x, y)$, $c(x, y)$, $s(x, y)$ 分别用于比较 x , y 两幅图像之间的亮度、对比度、结构差异; μ_x , μ_y , σ_x , σ_y 分别是 x , y 的均值和方差; σ_{xy} 是 x , y 之间的协方差; C_1 , C_2 , C_3 都为常数, 用来保证计算稳定性; α , β , γ 大于零, 用于调节指标中三种因素的相对重要性。

3.6.2 目标检测性能评价指标

目标检测需要完成两个任务，即预测目标的类别与坐标，因此目标检测性能的评价指标也是围绕这两个任务来设计的，检测结果的正确性需要从分类准确性以及坐标回归准确性两个方面进行评价，判定预测框正确检测需要满足分类正确且定位精准的两个条件。




图 3.20 IoU

如图 2.8 所示，包围框 A 为模型预测框，B 为真实框，如式 (3.10) 所示代表真实框与预测框的交并比 (Intersection over Union, IoU)^[54]:

$$IoU = \frac{A \cap B}{A \cup B} \quad (3.10)$$

与分类网络不同的是，目标检测模型在判定预测结果的准确性时不仅需要考虑预测框类别的准确性，还需要考虑预测框与真实框之间的差异，这一差异通常用交并比来衡量。设定交并比阈值 T 来确定判定边界，模型预测框与真实框 IoU 大于 T 且分类正确的结果为 TP，当模型预测框与真实框 IoU 小于 T 或者分类错误时即为 FP，FN 表示模型未能检出真实标签对应的预测框。如式 (2.11) ~ (2.12) 所示，目标检测算法的准确率 (Precision) 表示模型预测框中正确的比例，模型正确预测结果的数量与真实框总数的比例被称为召回率 (Recall)。通过改变模型预测时的置信度可以获得不同的准确率与召回率，为客观反映模型性能采用平均精度 (Average precision, AP) 指标对目标检测算法各类别检测性能进行评价，以 Recall 为横轴，Precision 为纵轴，对目标检测模型设置不同的置信度获取曲线坐标，得到的曲线下面积即为 AP，其计算公式如式 (3.13) 所示。

$$Precision = \frac{TP}{TP + FP} \quad (3.11)$$

$$Recall = \frac{TP}{TP + FN} \quad (3.12)$$

$$AP = \int_0^1 Precision \quad (3.13)$$

$$Mean AP = \frac{\sum_{i=1}^n AP_i}{n} \quad (3.14)$$

Mean AP 为各类别 AP 指标的均值，式中 AP_i 为各类别的 AP 指标。

3.6.3 样本尺度平衡方法问题结果分析

(1) 多尺度分块策略

为验证本文 3.4.1 节设计的多尺度分块策略对解决样本尺度不平衡的模型性能的影响, 选取标准的 YOLOv5s 模型作为检测模型, 分别对比直接使用原始数据进行训练与使用多尺度训练策略进行训练的模型应用于金属零件表面缺陷检测的检测性能, 如表 3.1 所示。

表 3.1 多尺度分块策略实验结果对比

方法	AP				Mean AP
	损伤	油渍	脏污	纤维	
原数据集	36.15%	75.86%	48.24%	74.15%	58.60%
多尺度分块策略	64.35%	91.80%	73.03%	84.32%	78.38%

从表 3.1 中可以看出, 使用多尺度分块策略训练的模型在对缺陷的检测性能效果显著, 使用多尺度分块策略后, 模型对于损伤类缺陷的 AP 指标提高了 28.20%, 这是由于表面损伤中小目标实例较多, 总体的 Mean AP 提升了 19.78%。这表明, 多尺度分块策略对于平衡数据集尺度不平衡, 提高目标检测模型性能具有重要的作用。如图 4.20 所示为两种方式下原始图像检测结果对比, 可以看出, 多尺度分块策略模型对小目标缺陷的检测效果显著提升, 使用原始数据的目标检测模型预测结果中遗漏的缺陷区域在多尺度分块策略模型中都能被检测到, 并且预测框回归的更为准确。这进一步的体现了多尺度分块策略在提高模型性能上的优越性。




图 3.21 多尺度分块策略结果对比

(2) SRGAN

为验证本文 3.4.2 节中提出的基于 SRGAN 图像增强方法对目标检测网络性能改善的有效性。共设计两个实验，第一个实验是直接对插值上采样的图像与超分辨率图像的图像质量进行评估，比较 SRGAN 的超分辨率性能；第二个实验是利用 SRGAN 生成目标检测模型的数据集，通过比较使用 SRGAN 前后的模型性能，验证 SRGAN 图像增强方法对目标检测模型的性能影响。

1) 图像质量评估实验

以高分辨率图像为参考图像，使用 3.4.1 节中提到的 PSNR、SSIM 两种评价指标，分别对比 SRGAN 超分辨率重建图像与低分辨率图像插值上采样的图像，采用 2 种图像质量评估指标来评价图像质量，两种指标均是望大指标，使用 5 组测试图片，分别对比 SRGAN 增强、低分辨率图像插值上采样的图像参考原图的质量评价指标均值。评估结果如表 3.2 所示。

表 3.2 图像质量评估实验结果对比

图例序号	插值上采样		SRGAN	
	PSNR	SSIM	PSNR	SSIM
1	34.224	0.950	40.624	0.985
2	27.998	0.749	41.492	0.988
3	29.971	0.800	42.319	0.988
4	34.484	0.927	44.985	0.991
5	32.396	0.900	40.064	0.986
Mean	31.815	0.865	41.897	0.988

由表 3.2 中可以看出使用 SRGAN 增强图像比插值方式上采样得到的图像在图像质量各方面指标都大幅提升。SRGAN 生成的高分辨率图像与插值上采样的图像的对比展示如图 3.22 所示。




图 4.22 上采样效果对比

2) 目标检测性能实验

本文的目标检测框架采用 YOLOv5s 模型，在使用多尺度分块训练策略的基础上分别使用插值上采样方法与基于 SRGAN 的图像增强方法得到的小尺度上采样图像用于训练时，对比目标检测模型用于金属零件表面缺陷检测的检测性能，如表 3.3 所示。

表 3.3 SRGAN 目标检测实验结果对比

方法	AP				Mean AP
	损伤	油渍	脏污	纤维	
插值上采样	64.35%	91.80%	73.03%	84.32%	78.38%
SRGAN	64.89%	97.76%	74.52%	83.83%	80.25%

从表 3.3 中可以看出，使用 SRGAN 上采样图像训练的检测模型比插值上采样图像训练的模型 Mean AP 提高了 1.87%，这进一步证明了 SRGAN 模型生成的上采样图像更为真实，目标检测模型能够学习到更好的特征，从而提升目标检测模型的性能。

3.6.4 基于 UYGAN 的样本类别平衡方法实验结果分析

由于没有直接的客观评价指标可以衡量基于 UYGAN 生成的伪缺陷图像质量，本节通过在训练集中加入 UYGAN 生成的伪损伤缺陷图片训练的目标检测模型，与通过对损伤缺陷样本的简单复制达到相同数据量级训练的 base 模型的性能对比，间接评价 UYGAN 网络的伪缺陷生成新数据的能力。实验结果如表 3.4 所示。

表 3.4 UYGAN 实验结果对比

方法	AP				Mean AP
	损伤	油渍	脏污	纤维	
base	65.39%	97.92%	74.64%	84.08%	80.51%
UYGAN	67.91%	97.82%	75.73%	87.86%	82.33%

从表 3.4 可知，使用 UYGAN 数据增强后的目标检测模型对比 base 模型，损伤类缺陷的 AP 提高了 2.52%，总体的 Mean AP 指标提高了 1.82%。实验结果表明，本文所提出的 UYGAN 缺陷生成模型有助于丰富数据集中缺陷样本的特征，提高目标检测模型的检测性能。

3.7 本章小节

本章针对金属零件表面缺陷数据集中存在的问题展开了深入的研究，详细分析了金属零件表面数据集中存在的样本尺度不平衡与样本类别不平衡问题并提出了相应的优化方法。针对样本尺度不平衡问题，本章提出了基于多尺度分块策略与 SRGAN 图像增强的尺度均衡方法。实验证明本章提出的多尺度分块策略能够有效提高目标检测模型的性能，Mean AP 指标相比使用原始数据集训练的 YOLOv5 模型提高了 19.78%，特别是损伤类缺陷 AP 指标提高了 28.20%，针对低分辨率图像插值上采样方法图像质量差的问题，构建了 SRGAN 超分辨率重建模型，应用 SRGAN 对低分辨率图像上采样得到的高分辨率图像相比于利用插值上采样得到的高分辨率图像在图像质量评价指标 PSNR、SSIM 上均有提升，且图像增强后得到的 YOLOv5 模型的 Mean AP 指标相对提高了 1.87%；针对样本类别不平衡问题，本章以 UNet 为生成器、YOLOv5 模型为鉴别器提出了 UYGAN 生成对抗网络，能够有效生成逼真的伪缺陷图像。实验表明，在加入 UYGAN 生成的伪缺陷图像后，YOLOv5 模型的 Mean AP 指标提高了 1.82%，损伤类缺陷 AP 指标提高了 2.52%，这进一步证明了 UYGAN 类别平衡方法的有效性。

第 4 章 基于目标检测的金属零件缺陷检测方法研究

4.1 引言

对于简单场景下的金属零件表面缺陷检测任务,采用传统的基于浅层特征(如纹理、形状和颜色等特征)的表面缺陷检测技术可以获得较好的检测性能。但是对于复杂场景下的表面缺陷检测,由于存在缺陷与背景对比度低、背景变化大、光照不均、噪声干扰等不利因素,大大增加了表面缺陷检测的难度,传统的基于人工浅层特征的检测方法表现不佳。随着目标检测技术的兴起,基于目标检测的表面缺陷检测方法已成为当前缺陷检测领域的热点路线之一,目标检测网络通过训练模型参数达到提取目标特征的目的,克服人工选取特征的弊端。更重要的是,它可以大大提高表面缺陷检测的性能。

目标检测技术能够解决目标在哪里、是什么的问题,这与表面缺陷检测的需求是相契合的。在本章中,通过目标检测网络检测金属零件表面图像感兴趣区域中所有缺陷以及缺陷在图像中的位置与类别。目前基于深度卷积神经网络的目标检测算法可分为两类:单阶段与双阶段的目标检测方法,根据金属表面缺陷工业应用的背景,选择效率更高的单阶段检测模型:YOLOv5s 模型,将其作为基准模型,并针对 YOLOv5s 模型进行改进,提高目标检测模型表面缺陷检测性能。

4.2 目标检测网络

目标检测能够综合解决分类和定位两个任务,是深度学习中的重要研究领域。目标检测算法可根据有无候选框生成阶段分为两种类型:一种是以 YOLO 系列算法为代表直接对特征预测生成检测结果的单阶段目标检测模型,后续推出的改进版本有 YOLO、YOLOv3、YOLOv4、YOLOv5 等;另一种是先提取候选区域,再对候选区域进行分类与二次修正得到检测结果的两阶段目标检测模型,以 R-CNN 系列算法为代表^[55]。

4.2.1 两阶段目标检测算法

两阶段目标检测算法的代表模型是 R-CNN 系列算法,两阶段目标检测算法首先利用区域建议网络生成候选区域,然后将目标检测任务转变为对候选区域图像的分类任务。R-CNN 是两阶段目标检测算法的开山之作,其中的结构设计也为此后的两阶段目标检测算法提供了基本思路。基于 R-CNN 的基本思路 Fast R-CNN 和 Faster R-CNN 相继被提出,Faster R-CNN 是其中表现效果

最好的一种方法^[56]，基于该算法国内外研究者展开了许多目标检测任务应用的研究。

Faster R-CNN 首先利用主干网络提取图像特征，在网络结构中加入区域生成网络(Region Proposal Network ,RPN)得到候选区域，RPN 的基本流程是借助先验锚定框对特征图上每个位置均生成不同尺寸的初始预测框；对每一个初始预测框进行二分类，判断其是否包含目标实例同时对包含目标实例的锚框进行修正，使其更接近真实框；然后利用非极大值抑制算法过滤掉冗余预测框得到候选区域。将候选区域输入到后续的 ROI 池化层、分类层进一步分类候选区域类别，二次修正候选区域框坐标完成检测任务。Faster R-CNN 的网络结构如图 4.1 所示。




图 4.1 Faster R- CNN 网络结构

4.2.2 单阶段目标检测算法

目标实例在整个图像中的上下文信息由对目标检测具有重要指导意义，而两阶段目标检测算法仅在候选区域生成时参考了上下文信息，这严重降低了模型的检测性能。为优化这一问题，单阶段目标检测算法被提出，它直接在原上下文背景下进行分类和定位结果的预测，加强了全局信息的利用。YOLO 系列经过几个版本的改进，YOLOv5 算法^[57]模型框架已相对完善，YOLOv5 模型按参数从小到大顺序可分为 YOLOv5s、YOLOv5m、YOLOv5l、YOLOv5x 四个版本,考虑到工业应用对效率的要求，本文选用 YOLOv5s 模型作为金属表面缺陷检测基准模型。

YOLOv5s 模型首先采用 Mosaic 数据增强方法对输入图片增强，丰富图片

背景且强化网络对小目标对象的检测效果，参考 CSPNet 中的网络结构设计了主干网络用于提取图像特征，将 SPPF 模块引入主干网络，使其能融合不同深度的特征，丰富特征信息。分别采用自上而下和自下而上的特征融合方式融合不同深度的特征，在不同尺度上融合其他深度的特征进行目标坐标回归和类别预测，预测结果时采用非极大值抑制对检测结果进行筛选，输出最终结果。




图 4.2 yolov5s 网络结构

4.3 损失函数

YOLOv5 的损失函数由置信度损失函数 (L_{conf})、类别损失函数 (L_{cls}) 和定位损失函数 (L_{box}) 三个部分组成，其计算公式如式 (4.1) 所示。式中 λ_1 、 λ_2 、 λ_3 分别表示对应的损失权重。

$$Loss = \lambda_1 L_{box} + \lambda_2 L_{conf} + \lambda_3 L_{cls} \quad (4.1)$$

4.3.1 置信度损失与分类损失

目标的置信度与分类可以看作一个分类任务,在传统的多分类任务中,一般使用的是 Softmax 函数,将预测得分转换为综合为 1 的概率,就会导致有极强的排他性。而在目标检测任务中,在计算分类损失进行训练时,对每个标签使用二元交叉熵,降低了计算复杂度,同时可以输出目标类别的可能性,二元交叉熵损失^[58]的公式如式 (4.2) 所示。

$$L_{ce}(y, \hat{p}) = \begin{cases} -\log(\hat{p}) & \text{if } y = 1 \\ -\log(1 - \hat{p}) & \text{if } y = 0 \end{cases} \quad (4.2)$$

交叉熵损失可以用来衡量两个概率分布之间的一致性，二元交叉熵损失预

测的结果只有两种， $\hat{p}$ 为预测概率大小， y 代表样本的标签，在二分类中对应 0，1。

YOLOv5 中引入 Focal loss^[59]来均衡各种样本不平衡问题，Focal loss 通过引入一个动态缩放的缩放因子来平衡二分类交叉熵损失权重，可以根据交叉熵预测概率动态调整训练过程中易区分样本的权重，从而使网络更聚焦于难区分样本的挖掘，Focal loss 的计算公式如式（4.4）所示：

$$\text{令 } p_t = \begin{cases} \hat{p} & \text{if } y = 1 \\ 1 - \hat{p} & \text{otherwise} \end{cases} \quad (4.3)$$

$$L_{focalloss} = -(1 - p_t)^\gamma \log(p_t) \quad (4.4)$$

p_t 反映了与类别 y 分布的接近程度， p_t 越大说明越接近类别 y ，即分类越准确， $\gamma > 0$ 为可调节因子。对比二元交叉熵损失，Focal loss 在损失计算的过程中加入了动态变化的系数 $(1 - p_t)^\gamma$ ，该系数随着 p_t 的减小而增大，实现放大难分类样本的损失权重。

4.3.2 定位损失

CIOU 损失函数是 YOLOv5 中使用最广泛的定位损失函数，CIOU 损失函数综合考虑了预测框与目标框之间的重叠程度、中心点距离，长宽比差异等因素^[60]。CIOU 损失函数其表达式如下所示。

$$L_{CIOU} = 1 - IoU + \frac{\rho^2(c_{gt}, c)}{d^2} + \alpha v \quad (4.5)$$

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w_{gt}}{h_{gt}} - \arctan \frac{w}{h} \right)^2 \quad (4.6)$$

$$\alpha = \frac{v}{(1 - IoU) + v} \quad (4.7)$$

w_{gt} 、 h_{gt} 和 w 、 h 分别表示真实框和预测框的宽和高； c_{gt} 、 c 表示真实框和预测框的中心； $\rho^2(c_{gt}, c)$ 表示两者之间的欧氏距离； d 表示真实框与预测框并集的对角线长度； v 表示两个框的长宽比差异； α 表示权重参数。




图 5.3 CIOU 示意图

4.4 基于 SW-YOLO 的金属零件表面缺陷检测算法

4.4.1 卷积神经网络的局限性

在生物学中，感受野（receptive field）是指感受器官受刺激兴奋时，通过神经元将信号脉冲传导至上层中枢中所能反应的刺激区域^[61]。

卷积神经网络作为具有仿生学特征的一种方法，其卷积核与神经元具有相似的构造，因此感受野的概念在卷积神经网络中同样适用，卷积核得到的特征受感受野区域中的像素影响。像人类通过局部感知目标图像整体信息一样，依靠不同神经元感知到的局部图像特征在更高的神经层次上进行融合来获取全局图像的感知，卷积神经网络也是利用卷积核提取局部特征的特性来完成计算机视觉中的各种任务。随着对感受野理论研究的深入，事实上输出特征受到感受野中不同像素的影响并非是一样的。感受野周围边缘区域对输出特征的贡献较小，而感受野中心区域对输出特征的贡献较大，卷积神经网络中的感受野可以分为理论感受野与实际感受野^[62]。

理论上，在卷积神经网络中，特征图上的每个位置都映射着输入图像上的某一块区域，这块区域的大小被称作理论感受野。在卷积神经网络中，卷积层由多个卷积核组成，图像的每一块区域与多个卷积核之间进行卷积运算，从而得到一组特征图，每个卷积核相当于一个神经元，特征图上的每一个位置都能通过卷积运算反推溯源其在上层特征图上的理论感受野，随着网络的加深，每个特征图上像素对应的理论感受野也越来越大。理论感受野的递推关系示意图如图 4.4 所示。




图 4.4 理论感受野递推关系示意图

假设输入图像为 P_{ip} ， P_k 是第 k 层特征图上的某个特征点，它映射到第 l ($l < k$) 层特征图的区域表示为 R_l ，而 R_l 上所有特征点映射到输入图像上的像素点并集为 R_k ， R_k 的大小即为理论感受野。因为感受野满足逐层递推的关系， P_k 的理论感受野等于 P_k 映射回第 l 层感受野内所有特征点对应输入图像中区域的并集。因此， P_k 的计算公式如式 (4.8) 所示。

$$R_k = \bigcup_l R_{lk} \quad (4.8)$$

不同特征层中特征信息的抽象程度与理论感受野呈正相关关系：感受野越小则表示其所包含的特征趋向于局部和细节，感受野越大表示其感知到的原始图像区域越大，包含更全局、语义层次更高的特征。

卷积神经网络中采用了多种不同方法来增加特征图的感受野，例如：加深网络层数、降采样、空洞卷积等。理论上，这些操作可以增加特征图的感受野。然而实际上，感受野中不同像素对特征的影响并非是一样的，感受野边缘区域仅通过少量路径对下一层特征图的对应特征点产生影响，而感受野中心区域可以通过多条不同的路径将其信息传递给其对应特征点，这直接导致了感受野不同位置像素对特征的贡献不同，仅只有理论感受野中心区域才是有效感受野。同样地，有效感受野与人眼的中央凹视力特性类似，即中心响应强烈，向周边区域辐射的感知信息迅速衰减。图 4.5(a)直观的展示了理论感受野范围内的像素对输出的贡献机制。




图 4.5 有效感受野

例如，对于输入图像 P_{ip} ，图像上 $5 \times 5 (x_{11} \sim x_{55})$ 区域经过两次卷积运算后，分别得到第一层特征图里 $(x'_{11} \sim x'_{33})$ 区域以及第二层特征图里的 x'' 。从图 5.5(a)可以看出， x_{11} 只能通过 $(x_{11} \sim x_{33})$ 一条路径影响 x'' ， x_{12} 可以通过 $(x_{11} \sim x_{33})$ 、 $(x_{12} \sim x_{34})$ 两条路径影响 x'' ， x_{13} 可以通过三条路径影响 x'' ，其中，理论感受野中心 x_{33} 可以通过九条路径影响 x'' 。因此，理论感受野边缘与中心对特征的贡献具有较大差异，因为越靠近感受野中心对特征点运算参与次数越多，靠近边缘区域参与次数越少，只有像素点对特征点的贡献达到一定程度才能被定义为有效感受野。因此，实际有效感受野仅占理论感受野一小部分，有效感受野在理论感受野中呈高斯分布，如图 4.5(b)所示。

以往的卷积神经网络为了提取更精确的全局语义特征，只考虑了扩张理论感受野，因此不断地加深网络深度。为扩大网络的关注区域，需多层堆叠卷积-池化结构，但随之带来的问题是有效感受野以某个中心为原点向外高斯衰减，有效感受野可能会远小于图像大小，导致网络学习能力不高。近年来，针对卷

积神经网络的卷积核存在有效感受野受限的问题，嵌入注意力机制用于卷积神经网络的特征学习来得到感受野范围更大的注意力特征图，其有效性得到了很多工作的证明。但受限于卷积运算天然的局限性，卷积神经网络感受野存在高斯衰减的问题仍无法得到很好的解决。

4.4.2 Swin Transformer

Transformer 模型主要由 Encoder 和 Decoder 组成，具有很强的全局上下文特征提取能力，在自然语言处理(NLP)中取得了较好的成绩^[63]。在 NLP 中，输入 transformer 中的是一个序列，而在视觉领域，需要考虑如何将一个二维矩阵转化为一维序列，最直接的做法是将图片中的像素点拉伸为一维序列输入到 transformer 中，但这样做计算复杂度过高。ViT(vision transformer)模型首次将 Transformer 作为特征提取层应用于计算机视觉领域中，与 CNN 中的特征提取层相比，Transformer encoder 结构可以提取更为精确的图像全局信息^[64]，ViT 模型示意图如图 4.6(a)所示。Transformer encoder 结构主要由前馈神经网络(MLP)和多头自注意力机制(Multi-Head Self-Attention)构成。具体结构如图 4.6(b)所示。




图 5.6 ViT 模型示意图与 Transformer Encoder

首先结合位置编码并将图片切分为固定大小的 Patches 得到一维向量，形成 Encoder 模块的输入，在序列头部添加一维可学习向量 Class token 作为图像分类时的特征，做的好处是：（1）分类向量并非基于图像内容，避免产生对序列中某些向量的偏向性；（2）位置编码固定，当切分的大小发生变化时，类别特征的位置仍然固定，具有更强的鲁棒性。将得到的一维向量序列输入 Transformer Encoder 中，学习图像特征并在输出端连接 MLP 分类器输出图像类别。多头自注意力机制是 Encoder 模块的重要组成部分，特征矩阵权值共享，减小了计算复杂度，可以并行地计算输入的多组数据，ViT 模型如图 4.6(a)所

示。




图 4.7 多头自注意力机制

如图 4.7 所示为多头自注意力机制的计算过程示意图，输入序列 x^i 与 w 矩阵相乘得到 a^i ，利用 a^i 分别与 w^q, w^k, w^v 矩阵相乘得到 q^i (query), k^i (key), v^i (value) 意为查询向量、键向量、值向量， q^i 与 k^j 的转置点乘后得到序列的相关性矩阵 α^{ij} 再与 v^i 矩阵相乘，得到加权后的输出结果 b^i ，而一组 w^q, w^k, w^v 被称作一个 Head，多头注意力机制可以设置多个 Head 来提取更丰富的上下文信息。Transformer 天然自带的 Long Range 特性(自注意力带来的全局感受野)使得从浅层到深层特征，都能利用全局的上下文信息，并且 Multi-Head 机制保证了网络可关注到多个不同特征的注意力区域，这是 Transformer 相比卷积神经网络的优势所在，但同时 ViT 模型虽然解决了卷积神经网络对于全局信息衰退的问题，也丢失了对于图像局部的注意力信息的学习。Swin transformer^[65]的出现是为了解决传统的 ViT 模型对局部注意力关注度不够的问题，它的整体结构图如 4.8 所示。




图 4.8 Swin Transformer 模型

Swin transformer 采用层次化的设计，包含 4 个 stage，每一层 stage 都会缩小输入特征图的分辨率，类似卷积神经网络中逐层扩大感受野。Swin transformer 在输入进入 Stage 前，需要对原始图片进行裁剪，裁剪为不重叠的、长宽均为块大小的窗口，该步骤可以通过步长和卷积核大小均为块大小的卷积操作来完成，再通过线性嵌入层(Linear Embedding)对图片维度进行投影。在每一个状态里由 Patch Merging 和多个 Black 组成，其中 Patch Merging 的作用主要是在每个 Stage 开始前降低图片的分辨率，类似 CNN 中的步长为 2 的卷积或池化；Black 的具体结构如图 5.8(b)所示，由归一化层(LayerNorm)、多层感知机(MLP)、窗口注意力机制(Window Attention, W-MSA)、滑动窗口注意力机制(Shifted Window Attention, SW-MSA)组成。

传统的 ViT 模型是基于全局来计算注意力，因此计算复杂度很高，而 Swin transformer 利用 W-MSA 模块来获取局部注意力，相比 ViT 模型提取到的局部注意力机制更加聚焦，同时将注意力的计算限制在每个窗口内，减少了计算量；为解决 W-MSA 模块不同的窗口之间没有进行信息交互，窗口之间注意力缺失的问题，引入了 SW-MSA 模块，通过对特征图的 Shifted 并在计算过程中添加 Mask 机制来间接获取不同窗口之间的注意力，如图 4.9 所示为 W-MSA 与 SW-MSA 的具体操作步骤。




图 4.9 Windows and Shifted Windows

Vision Transformer 模型中图片被分成了相等不重叠的 patches，如图 4.9(a)所示，在进行 MSA 计算时，任何一个 patch 都要与其他所有的 patch 进行 attention 计算，当 patch 的大小固定时，计算量与图片的大小成平方增长。Swin Transformer 中设计了 W-MSA，如图 4.9(b)所示，不同的 window 中包含了相同数量的 patch，只对 window 内部进行 MSA 计算，当图片大小增大时，计算量仅仅增加在新增的 window 上，故与图片大小是呈线性增长的。而为了更好的和其他窗口进行信息交互，引入了滑动窗口注意力机制，如图 4.9(d)所示，通过对特征图移位得到了 Shifted Windows，将上面和左边的图补齐到右边得到 Roll 后的新 Windows，如图 4.9(e)所示。这又带来了一个缺点：不相邻的 window 之间需要抑制相互之间的注意力，通过添加注意力 mask 机制来解决这一问题，如果相互交互的 patch 属于同一个区域（对应于 4.9(e)中相同颜色的 Patches），那么按照窗口注意力机制正常交互，如果不是同一个区域（对应于 4.9(e)中不同颜色的 Patches），那么他们交互之后将会加上一个极大的负值，这样通过 softmax 层消除本来不能交互的 Patches 之间的注意力。

Swin transformer 模型的性能已在大型图像分类数据集上得到了验证，下一步需要将 Swin transformer 模型嵌入到各种计算机视觉任务中，利用 transformer 特有的优越性获得性能更强的模型。

4.4.3 SW-YOLO 算法

在金属表面缺陷检测任务中，目标实例与背景的联系密不可分，缺陷很大程度上是由周边区域决定的。因此，提取全局的上下文信息对于金属表面缺陷检测有重要意义，受限于卷积神经网络提取特征的局部性，目标检测模型提取的特征缺乏全局的上下文信息，检测性能也因此受到影响。

借助 Swin transformer 模型全局特征学习的优势，将 Swin transformer 作为 YOLOv5s 模型的特征提取网络在理论上可以提高金属表面缺陷检测性能。具体做法是，在 Swin transformer 模型不同尺度的 stage 中 Swin transformer Block 模块后接入卷积层，可以得到三种不同尺度的特征图，与 YOLOv5s 模型中特征提取网络输出的特征图保持一致，具体的模型结构如图 5.10 所示。




图 5.10 SW-YOLO 模型

4.5 基于通道注意力机制的 SW-YOLO 模型

4.5.1 通道注意力机制

传统的卷积神经网络设计中认为不同通道的特征对于结果的贡献是一致的，而实际上不同通道的特征对结果的显著性是不一致的。因此，在卷积神经网络中引入通道注意力机制来获取不同通道的注意力在许多视觉任务中获得了巨大的成功。近年来，通道注意力机制衍生出很多版本以适配不同场景视觉任务，如 SENet、SRM、ECA 等^[66]。

(1) SENet

SENet 全称 Squeeze-and-Excitation Networks, 可分为 squeeze 模块与 excitation 模块, squeeze 模块对特征图进行全局平均池化(global average pooling, GAP), 得到长度为通道数的向量, 再通过 excitation 模块连接全连接层与非线性激活层将通道向量进行映射, 获取每个通道的注意力权重与原特征图相乘, 为每一个通道赋予了不同的权重^[66]。

(2) SRM

SRM 模块提出了 style-based recalibration module (SRM)^[67]。它利用输入特征的均值(mean)和标准差(std)来提高注意力模块对于全局信息的表达能力。它还采用了一个轻量级的通道全连接层(CFC)代替原有的全连接层(FC), 以减少计算需求。

(3) ECA

ECA 全称 Efficient Channel Attention Module, ECA 认为 SENet 所采用的降维操作会对通道注意力的预测产生负面影响, 且获取所有通道的依赖关系是低效且不必要的。一维卷积相比全连接层具有更好的跨通道信息获取能力^[68]。ECA 模块去除了 SE 模块中的全连接层, 在全球平均池化后的特征上通过一维卷积进行学习。




图 4.11 通道注意力机制

4.5.2 ESCAM 模块

SENet 作为通道注意力机制最先被提出，提供了捕捉通道注意力的基本思路，而 SRM 在对特征进行降维时引入多种特征获取更丰富的表达能力，ECA 对通道向量的映射方法进行优化，使用卷积提取注意力权重，避免了获取全通道依赖关系，通过卷积操作实现了局部跨通道交互。本文结合 SRM 与 ECA 的优势提出 ESCAM(Efficient style-based Channel Attention Module)模块嵌入模型中，借鉴 SRM 中特征降维的思路，分别从特征图中降维得到平均池化向量、区间池化向量、标准差池化向量，其中区间池化为最大池化与最小池化的距离，利用这三个向量表征通道信息相较于 SRM 中的降维方式更为全面，再通过一维卷积核对通道向量之间进行局部交互，得到的注意力权重与原特征图相乘，获取带有通道注意力的特征信息。




图 4.12 ESCAM 模块

SW-YOLO 模型利用 Swin transformer 模型提取了丰富的全局上下文信息，通过卷积层对维度进行映射得到了多尺度特征，但并没有捕捉通道上的注意力信息，而是将所有通道的显著性视为一致。因此，在 SW-YOLO 模型输出特征图后加入 ESCAM 通道注意力机制，期望模型学习具有通道注意力的全局特征信息，以提高金属表面缺陷检测性能。

4.6 实验结果与分析

为验证本文 4.3 节中提出的 SW-YOLO 算法的有效性，基于本文 3.2 节中收集的金属零件表面缺陷数据集进行测试，将测试结果与 YOLOv5 算法进行对比，并基于本文 3.6.2 节中提出的目标检测性能评价指标进行评估，实验结果如表 4.1 所示。

表 4.1 SW-YOLO 实验结果对比

	AP				Mean AP
	损伤	油渍	脏污	纤维	
SW-YOLO	69.45%	98.31%	76.56%	89.73%	83.51%
YOLOv5	67.91%	97.82%	75.73%	87.86%	82.33%

实验数据表明, 基于 Swin transformer 的 SW-YOLO 模型的 Mean AP 指标为 83.51%, 相较于 YOLOv5s 模型提高了 1.18%, 这进一步验证了 Swin transformer 模型在全局上下文信息捕捉上的优越性, 相较于传统卷积神经网络, SW-YOLO 模型更适合金属零件表面缺陷检测任务。

为验证本文 4.4 节中提出的基于 ESCAM 模块改进的 SW-YOLO 算法的有效性, 基于本文 3.2 节中收集的金属零件表面缺陷数据集进行测试, 分别将其与原始 SW-YOLO 算法、YOLOv5s 算法; 嵌入不同注意力模块的 SW-YOLO 算法、YOLOv5s 算法进行对比, 以验证通道注意力机制对 SW-YOLO 模型的影响, 以及本文提出的 ESCAM 通道注意力机制的优越性, 实验结果如表 4.2 所示。

表 4.2 通道注意力机制改进实验结果对比

方法	AP					Mean AP
	损伤	油渍	脏污	纤维		
SW-YOLO	-	69.45%	98.31%	76.56%	89.73%	83.51%
	SENet	69.82%	98.67%	77.41%	91.62%	84.38%
	SRM	72.65%	98.5%	80.49%	89.36%	85.25%
	ECA	71.35%	99.46%	77.32%	91.67%	84.95%
	ESCAM	73.94%	98.84%	80.92%	89.46%	85.79%
YOLOv5s	-	67.91%	97.82%	75.73%	87.86%	82.33%
	SENet	68.25%	98.03%	76.05%	87.91%	82.56%
	SRM	69.15%	98.39%	77.61%	88.21%	83.34%
	ECA	68.49%	98.38%	76.92%	88.73%	83.13%
	ESCAM	69.52%	99.18%	78.37%	88.65%	83.93%

从实验结果可知, SRM 和 ECA 通道注意力机制均能优化模型性能, 在 YOLOv5 中 Mean AP 分别提升了 0.8%, 0.91%, 而在 SW-YOLO 模型中提升更为可观, 达到了 1.74%, 1.44%, 这表明 SW-YOLO 模型相较于 YOLOv5s 模型更需要通道注意力的捕捉, 因为 SW-YOLO 模型中大部分都是基于空间域进行全局注意力计算, 而忽视了通道域上的注意力表达; 本文提出的 ESCAM 通道注意力机制在性能上有了进一步的提升, 相较原始模型在 YOLOv5 上 Mean AP 提升了 1.6%, 在 SW-YOLO 模型上提升了 2.28%, 实验结果进一步验证了本文提出的 ESCAM 通道注意力机制的优越性。

4.7 本章小节

本章针对金属零件表面缺陷检测任务，确定了基于深度卷积神经网络的目标检测技术路线并介绍了主要的目标检测算法。针对卷积神经网络感受野的局限性，引入聚焦于全局注意力的主干网络 Swin Transformer，提出了基于 Swin transformer 的 YOLO 目标检测算法(SW-YOLO)。实验结果表明，基于 SW-YOLO 相比于 YOLOv5 模型 Mean AP 指标提高了 1.18%，进一步验证了 SW-YOLO 在金属零件表面缺陷检测任务中的优势；针对 SW-YOLO 算法通道域注意力捕捉能力不足的问题，介绍了几种主要的通道注意力机制，并提出了一种基于 SRM 与 ECA 的注意力机制 ESCAM 模块，并嵌入 SW-YOLO 算法以改善 SW-YOLO 模型的通道注意力捕捉能力。实验结果表明，通道注意力机制的嵌入对 YOLOv5 模型与 SW-YOLO 模型表面缺陷检测性能均有提升，而本章提出的 ESCAM 模块相比于 SRM 与 ECA 模块提升效果更为明显，在 SW-YOLO 模型中表面缺陷检测性能提升了 2.28%，ESCAM 模块具有更强的通道注意力捕捉能力，可以优化 SW-YOLO 模型的表面缺陷检测性能。

总结与展望

在制造业“智能制造”升级转型的大背景下，以往的人工检测金属表面缺陷的方法难以满足制造业需求，随着机器视觉和深度学习技术的日益成熟，基于机器视觉的金属表面缺陷检测方法取得了有效的进展。但目前仍然面临小样本、检测算法泛化能力不足、数据集不平衡问题以及缺陷检测方法精度有待进一步提高等难点问题。本文以某多型号金属零件的表面缺陷检测为研究对象，分别从提高缺陷检测算法对不同型号零件的泛化能力、数据集样本尺度不平衡和样本类别不平衡问题、提高算法精度三个方面展开了深入研究，并予以实验验证。

本文主要的研究工作如下：

（1）针对该金属零件在小样本、多型号下的表面缺陷检测中的感兴趣区域分割任务，本文提出了一种基于迁移学习与混合注意力机制的 UNet 感兴趣区域分割算法。针对小样本条件下 UNet 分割精度有待提升及收敛速度较慢的问题，基于参数迁移学习提出了 VGG-UNet 模型，并与原 UNet 模型对比，实验结果表明，网络收敛速度从 80 轮减少至 10 轮，同时 Mean IoU 指标提高了 2.21%。针对多型号金属零件感兴趣区域分割泛化能力不足问题，在参数迁移学习的 UNet 模型长连接特征融合过程中嵌入了混合注意力机制 CBAM 模块，提出了基于 CBAM- VGG16 参数迁移的 UNet 分割模型，实验结果表明，改进后的模型相比于参数迁移的 UNet 模型用于感兴趣区域分割的 Mean IoU 指标提高了 3.35%，且在其它两种型号金属零件的感兴趣区域分割 Mean IoU 分别提高了 2.17%、1.87%，验证了 CBAM 注意力机制能够有效提高语义分割网络的分割性能与泛化能力。

（3）针对金属零件表面缺陷数据集中存在的样本尺度不平衡与样本类别不平衡问题展开了深入研究。针对样本尺度不平衡问题，提出了基于多尺度分块策略与 SRGAN 图像增强的样本尺度平衡方法。将多尺度分块策略应用于 YOLOv5 模型中，对该金属零件进行表面缺陷检测，实验结果表明，该方法 Mean AP 指标相比使用原始数据集训练的模型提高了 19.78%；针对该方法中低分辨率图像块插值上采样方法图像质量差的问题，引入了基于 SRGAN 的超分辨率图像增强模型，实验结果表明该方法获得的高分辨率图像相比于利用插值上采样得到的高分辨率图像，在图像质量评价指标 PSNR、SSIM 上均有提升，且图像增强后得到的 YOLOv5 模型应用于金属零件表面缺陷检测的 Mean

AP 指标相对提高了 1.87%。针对样本类别不平衡问题,提出了以 UNet 为生成器、YOLOv5 模型为鉴别器的 UYGAN 生成对抗网络,生成了有效的伪缺陷图像,使用 SRGAN 与 UYGAN 数据增强后得到的 YOLOv5 模型与仅使用 SRGAN 数据增强方法的模型 Mean AP 指标提高了 1.82%。

(3) 针对卷积神经网络感受野的局限性,引入聚焦于全局注意力的主干网络 Swin Transformer,提出了基于 Swin transformer 的 YOLO 目标检测算法 (SW-YOLO) 应用于金属表面缺陷检测,实验结果表明,该模型相比于原 YOLOv5 模型 Mean AP 指标提高了 1.18%,验证了 SW-YOLO 在金属零件表面缺陷检测任务中的优越性。针对 SW-YOLO 算法通道域注意力表达能力不足的问题,提出了一种基于 SRM 与 ECANet 的 ESCAM 模块,结果表明嵌入 ESCAM 注意力机制后的 SW-YOLO 模型比于原 SW-YOLO 模型的 Mean AP 指标提升了 2.28%,ESCAM 模块具有更强的通道注意力表达能力,可以提高 SW-YOLO 模型特征提取能力。

论文的主要创新点在于:

(1) 针对金属零件在小样本、多型号下的表面缺陷检测中的感兴趣区域分割任务,提出了一种基于迁移学习与混合注意力机制的 UNet 感兴趣区域分割算法。

(2) 为提高缺陷检测算法精度,针对金属零件表面缺陷尺度不均衡、类别不均衡问题,提出了基于多尺度分块策略与 SRGAN 上采样图像增强的尺度均衡方法;提出了基于 UYGAN 数据增强的类别均衡方法,针对卷积神经网络感受野的局限性,提出了基于 Swin transformer 的 SW-YOLO 算法,提高模型学习全局上下文特征的能力,针对 SW-YOLO 算法中通道注意力表达能力不足,在 SW-YOLO 模型中嵌入 ESCAM 通道注意力机制,提高了模型表面缺陷检测性能,实现了金属表面缺陷检测需求。

本文针对某金属零件表面缺陷检测需求,提出了图像分割-目标检测的缺陷检测技术路径,提出的方法具有广泛的应用前景,在后续研究工作中可进一步完善以下内容:

(1) 在其它非回转金属产品缺陷检测问题中存在着共性问题,应将本文提出的方法在其他非回转金属表面进行迁移应用,验证本文提出方法的泛化能力;

(2) 本文提出的多尺度分块策略中的分块大小是凭借经验设置的,在后续的研究工作中,应进一步分析不同尺度分块策略下对模型性能的影响,提高研究深度与理论严谨性;

(3) 本文提出的 UYGAN 数据增强方法应与其他数据增强方法对比,并将该方法应用于其他金属表面的缺陷数据中,验证方法的泛化能力。

参考文献

- [1] 崔慧明, 陈林. “中国制造 2025” 战略之 “智能制造” [J]. 科技经济市场, 2022(04):7-9.
- [2] 樊慧超. 机器视觉技术在工业检测中的应用 [J]. 数字通信世界, 2020(12):156-157.
- [3] 李跃, 王子铭, 李鑫林, 岳强. 带钢表面缺陷检测方法研究进展[J/OL]. 钢铁研究学报:1-17[2023-04-01]. DOI:10.13228/j.boyuan.issn1001-0963.20220363.
- [4] 李少波, 杨静, 王铮, 朱书德, 杨观赐. 缺陷检测技术的发展与应用研究综述[J]. 自动化学报, 2020, 46(11):2319-2336. DOI:10.16383/j.aas.c180538.
- [5] 汤勃, 孔建益, 伍世虔. 机器视觉表面缺陷检测综述[J]. 中国图象图形学报, 2017, 22(12):1640-1663.
- [6] Jeon Y J, Choi D C, Yun J P, et al. Detection of scratch defects on slab surface[C]// International Conference on Control. IEEE, 2011.
- [7] Nand G K, Noopur, Neogi N. Defect detection of steel surface using entropy segmentation[C] // 2014 Annual IEEE India Conference (INDICON). 0.
- [8] Agarwal K, Shivpuri R. On line prediction of surface defects in hot bar rolling based on Bayesian hierarchical modeling[J]. Journal of Intelligent Manufacturing, 2013, 26(4):785-800.
- [9] Neogi N, Mohanta D K, Dutta P K. Defect detection of steel surfaces with global adaptive percentile thresholding of gradient image[J]. Journal of the Institution of Engineers (india): Series B, 2017, 98: 557-565.
- [10] Suvdaa B, Ahn J, Ko J. Steel Surface Defects Detection and Classification Using SIFT and Voting Strategy[J]. International Journal of Software Engineering & Its Applications, 2012.
- [11] Yun J P, Choi D C, Yong-ju Jeon. Defect inspection system for steel wire rods produced by hot rolling process[J]. International Journal of Advanced Manufacturing Technology, 2014, 70(9-12):1625-1634.
- [12] Sarma A, Janani R, Sarma A. Detecting the surface defects on hot rolled steel sheets using texture analysis[C]// International Conference on Advanced Electronic Systems. IEEE, 2013.

- [13] 刘赞. 基于机器视觉的手机金属板表面缺陷检测技术研究[D]. 浙江大学, 2018.
- [14] 冯维, 刘红帝, 汤少靖等. 基于 HDRI 的高反光金属表面缺陷检测方法研究[J]. 仪表技术与传感器, 2019, No.439(08):112-116.
- [15] 刘婷婷. 基于深度学习的高反光金属工件表面缺陷检测研究[D]. 河北大学, 2020.
- [16] 申雨千. 基于机器视觉的金属活塞表面缺陷检测研究[D]. 天津科技大学, 2021.
- [17] 奚昌泽. 金属工件表面缺陷的机器视觉检测方法及应用研究[D]. 宁波大学, 2021.
- [18] 安宗权, 王匀. 一种非线性扩散与图像差分的金属表面缺陷检测方法[J]. 表面技术, 2018, 47(06):277-283.
- [19] Faghih-Roohi S, Siamak H, Alfredo Núñez, et al. Deep Convolutional Neural Networks for Detection of Rail Surface Defects[C]// International Joint Conference on Neural Networks (IJCNN 2016). IEEE, 2016.
- [20] Selamat F, Cakar S, Kotan M. Automatic Detection and Classification of Defective Areas on Metal Parts by Using Adaptive Fusion of Faster R-CNN and Shape From Shading[J]. IEEE Access, 10.
- [21] Ferguson M, Ak R, Lee Y, et al. Detection and Segmentation of Manufacturing Defects with Convolutional Neural Networks and Transfer Learning[J]. 2018.
- [22] Hsieh C C, Lin Y W, Tsai L H, et al. Offline Deep-learning-based Defective Track Fastener Detection and Inspection System[J]. Sensors and Materials, 2020, 32(10):3429.
- [23] Patar M N A A, Ayub M A, Zainal N A, et al. Detection of Micro-defects on Metal Screw Surfaces Based on Faster Region-Based Convolutional Neural Network[J]. 2022.
- [24] Fan K, Peng P, Zhou H, et al. Real-time high-performance laser welding defect detection by combining acgan-based data enhancement and multi-model fusion[J]. Sensors, 2021, 21(21): 7304.
- [25] Aein S L, Thu T T, Htun P P, et al. YOLO based deep learning network for metal surface inspection system[C]//Proceedings of the 11th International Conference on Robotics, Vision, Signal Processing and Power Applications: Enhancing Research and Innovation through the

- Fourth Industrial Revolution. Singapore: Springer Singapore, 2022: 923-929.
- [26] 张琛,白旭,张侠.融合注意力机制的金属板材表面缺陷检测方法[J/OL].计算机集成制造系统:1-19[2023-03-31].
- [27] 李衍照,于镭,田金文.基于改进 YOLOv5 的金属焊缝缺陷检测[J].电子测量技术,2022,45(19):70-75.
- [28] 苏迎涛. 基于显著区域提取和改进型 YOLO-V3 的金属齿轮加工端表面缺陷检测方法[D].重庆大学,2020.
- [29] 郭子兴. 基于深度学习的铝型材表面缺陷检测研究[D].华南理工大学,2021.DOI:10.27151/d.cnki.ghnlu.2021.004269.
- [30] 李硕. 基于深度学习的血管支架表面缺陷检测[D].天津理工大学,2022.
- [31] 王道累,刘易腾,杜文斌等.基于级联孪生密集网络的金属表面缺陷检测方法[J].计算机辅助设计与图形学学报,2022,34(06):946-952.
- [32] 祁阳. 基于生成对抗网络的金属表面缺陷视觉检测方法研究[D].江南大学,2022.
- [33] Otsu N. A threshold selection method from gray-level histograms[J]. IEEE transactions on systems, man, and cybernetics, 1979, 9(1): 62-66.
- [34] Adams R, Bischof L. Seeded region growing[J]. IEEE Transactions on pattern analysis and machine intelligence, 1994, 16(6): 641-647.
- [35] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 3431-3440.
- [36] Zhao H, Shi J, Qi X, et al. Pyramid scene parsing network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2881-2890.
- [37] Hao S, Zhou Y, Guo Y. A brief survey on semantic segmentation with deep learning[J]. Neurocomputing, 2020, 406: 302-321.
- [38] Li X, Chen H, Qi X, et al. H-DenseUNet: hybrid densely connected UNet for liver and tumor segmentation from CT volumes[J]. IEEE transactions on medical imaging, 2018, 37(12): 2663-2674.
- [39] Weiss K, Khoshgoftaar T M, Wang D D. A survey of transfer learning[J]. Journal of Big data, 2016, 3(1): 1-40.
- [40] Shin H C, Roth H R, Gao M, et al. Deep convolutional neural networks for computer-aided detection: CNN architectures, dataset characteristics and transfer learning[J]. IEEE transactions on medical

- p imaging, 2016, 35(5): 1285-1298.
-
- [41] Niu Z, Zhong G, Yu H. A review on the attention mechanism of deep learning[J]. Neurocomputing, 2021, 452: 48-62.
- [42] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [43] Liang J. Confusion Matrix: Machine Learning[J]. POGIL Activity Clearinghouse, 2022, 3(4).
- [44] Zhang M, Xu S, Song W, et al. Lightweight underwater object detection based on yolo v4 and multi-scale attentional feature fusion[J]. Remote Sensing, 2021, 13(22): 4706.
- [45] Neubeck A, Van Gool L. Efficient non-maximum suppression[C]//18th international conference on pattern recognition (ICPR'06). IEEE, 2006, 3: 850-855.
- [46] Farsiu S, Robinson D, Elad M, et al. Advances and challenges in super-resolution[J]. International Journal of Imaging Systems and Technology, 2004, 14(2): 47-57.
- [47] Creswell A, White T, Dumoulin V, et al. Generative adversarial networks: An overview[J]. IEEE signal processing magazine, 2018, 35(1): 53-65.
- [48] Ledig C, Theis L, Huszár F, et al. Photo-realistic single image super-resolution using a generative adversarial network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4681-4690.
- [49] Shorten C, Khoshgoftaar T M. A survey on image data augmentation for deep learning[J]. Journal of big data, 2019, 6(1): 1-48.
- [50] Dadboud F, Patel V, Mehta V, et al. Single-stage uav detection and classification with yolov5: Mosaic data augmentation and panet[C]//2021 17th IEEE International Conference on Advanced Video and Signal Based Surveillance (AVSS). IEEE, 2021: 1-8.
- [51] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE transactions on image processing, 2004, 13(4): 600-612.
- [52] Johnson D H. Signal-to-noise ratio[J]. Scholarpedia, 2006, 1(12): 2088.
- [53] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from

- error visibility to structural similarity[J]. IEEE transactions on image processing, 2004, 13(4): 600-612.
- [54] Özdemir B, Aksoy S, Eckert S, et al. Performance measures for object detection evaluation[J]. Pattern Recognition Letters, 2010, 31(10): 1128-1137.
- [55] Zou Z, Shi Z, Guo Y, et al. Object detection in 20 years: A survey[J]. arXiv preprint arXiv:1905.05055, 2019.
- [56] Girshick R. Fast r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1440-1448.
- [57] Zhu X, Lyu S, Wang X, et al. TPH-YOLOv5: Improved YOLOv5 based on transformer prediction head for object detection on drone-captured scenarios[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 2778-2788.
- [58] Pang T, Xu K, Dong Y, et al. Rethinking softmax cross-entropy loss for adversarial robustness[J]. arXiv preprint arXiv:1905.10626, 2019.
- [59] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2980-2988.
- [60] Zhao Z Q, Zheng P, Xu S, et al. Object detection with deep learning: A review[J]. IEEE transactions on neural networks and learning systems, 2019, 30(11): 3212-3232.
- [61] DeAngelis G C, Ohzawa I, Freeman R D. Receptive-field dynamics in the central visual pathways[J]. Trends in neurosciences, 1995, 18(10): 451-458.
- [62] Luo W, Li Y, Urtasun R, et al. Understanding the effective receptive field in deep convolutional neural networks[J]. Advances in neural information processing systems, 2016, 29.
- [63] Wolf T, Debut L, Sanh V, et al. Transformers: State-of-the-art natural language processing[C]//Proceedings of the 2020 conference on empirical methods in natural language processing: system demonstrations. 2020: 38-45.
- [64] Khan S, Naseer M, Hayat M, et al. Transformers in vision: A survey[J]. ACM computing surveys (CSUR), 2022, 54(10s): 1-41.
- [65] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF

- international conference on computer vision. 2021: 10012-10022.
- [66] Bastidas A A, Tang H. Channel attention networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2019: 0-0.
- [67] Lee H J, Kim H E, Nam H. Srm: A style-based recalibration module for convolutional neural networks[C]//Proceedings of the IEEE/CVF International conference on computer vision. 2019: 1854-1862.
- [68] Wang Q, Wu B, Zhu P, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 11534-11542.