

分 类 号 TE927
密 级

学 号 21212030383



全 日 制 专 业 学 位

硕 士 学 位 论 文



题 目 基于机器视觉的钻杆螺纹缺陷检测

关键技术研究

作 者 姓 名 张鑫鹏

导师姓名、职称 燕并男 副教授

专业学位论文领域 电子信息

提交论文日期 2024年6月

论 文 题 目：基于机器视觉的钻杆螺纹缺陷检测关键技术研究

专 业：电子信息

硕 士 生：张鑫鹏（签名）

导 师：燕并男（签名）

摘 要

石油钻杆是油气开采中重要的钻具，它的主要作用是对钻头和井架控制平台的连接传递动力。钻杆连接区域的螺纹损伤不但会降低石油开采的生产效率，同时也会增加井下安全事故的发生概率，导致高昂的修复及替换费用。因此，分析和研究钻杆联接螺纹的损坏问题变得尤为关键。钻杆螺纹缺陷检测常采用人工检测的方式，其检测效率低、误差大，因此实现钻杆螺纹缺陷的智能化检测可以提高螺纹检测的检测精度和工作效率，易于形成螺纹缺陷数据库，便于后续缺陷级别的量化与评估。对于钻杆螺纹缺陷的深度、分布范围以及对螺纹整体性能的影响往往不能从仅有的二维图像数据中完全捕捉和评估，因此研究螺纹的三维成像技术显得尤为重要。本文研究内容如下：

（1）基于计算机视觉，研究了钻杆螺纹裂缝缺陷的智能检测方法。首先，通过作业现场图像采集等方式建立了钻杆螺纹裂缝缺陷数据集，针对数据集数量不足的问题，对基础数据集进行了扩充。为了使数据集能在多种模型上训练，通过在 YOLOv5 中执行编译的归一化代码实现 VOC 格式到 YOLO 格式的转换。其次，开展 YOLOv5 及部分主流深度学习模型网络架构的研究分析，在扩充数据集上展开实验并对性能进行对比分析。结果表明，YOLOv5 在阈值为 50% 时获得了 69.3% 的平均检测率，目标检测速度达到 93.6FPS，验证了 YOLOv5 作为钻杆螺纹缺陷检测模型的可行性和优势。

（2）针对内容（1）二维图像在螺纹缺陷分析中缺少深度信息的问题，设计了一种基于双目法的三维成像系统，基于 FPGA 搭建了双目立体视觉硬件平台，主要包括时钟模块、DDR 控制器模块、摄像头驱动模块和 HDMI 顶层模块，编写程序进行软件实现，并对各模块进行了仿真测试，分析了模块的资源消耗，结果表明硬件资源利用效率高。通过实验，验证了双图像同步采集的正确性，结果表明系统能够有效的获取到钻杆螺纹的双目图像。

（3）在内容（2）的基础上，研究了钻杆螺纹三维重构方法。首先，研究了双目视觉成像系统中基线对螺纹双目成像的影响，分别设置基线参数为 169mm、84.5mm、35mm 开展了实验研究及分析。研究了三维重构的特征匹配方法，并实现了 SIFT 特征匹配算法，开展了基于基线为 169mm、84.5mm 和 35mm 图像的特征匹配融合实验。实验结果表明，双目摄像模组的基线对双目立体视觉的三维成像有着较大影响，基线距离为 84.5mm 时，立体校正、SIFT 特征匹配和成像效果最好。

关 键 词：无损检测 机器视觉 深度学习模型 三维成像方法

论文类型：应用研究

Subject : Research on key technology of drill pipe thread defect detection based on machine vision

Speciality : Electronic Information

Name : Zhang Xinpeng(signature)_____

Instructor : Yan Bingnan(signature)_____

ABSTRACT

Oil drill pipe is an important drill tool in oil and gas exploitation. Its main function is to transfer power between drill bit and derrick control platform. Thread damage in the drill pipe connection area not only reduces the productivity of oil production, but also increases the probability of downhole safety incidents, resulting in high repair and replacement costs. Therefore, it is very important to analyze and study the damage of drill pipe joint thread. The detection of drill pipe thread defects usually adopts manual detection, which has low detection efficiency and large error. Therefore, the realization of intelligent detection of drill pipe thread defects can improve the detection accuracy and work efficiency of thread detection, and it is easy to form a thread defect database, which is convenient for the subsequent quantification and evaluation of defect levels. The depth, distribution range and impact on the overall performance of drill pipe thread defects can not be fully captured and evaluated from the only two-dimensional image data, so it is particularly important to study the three-dimensional imaging technology of thread. The research content of this paper is as follows:

(1) Based on computer vision, an intelligent detection method for crack defects of drill pipe threads is studied. Firstly, the crack defect data set of drill pipe thread is established by means of job site image acquisition, and the basic data set is expanded to solve the problem of insufficient data set. In order to enable the data set to be trained on multiple models, the conversion of VOC format to YOLO format was implemented by executing compiled normalized code in YOLOv5. Secondly, research and analysis of YOLOv5 and some mainstream deep learning model network architectures are carried out, experiments are carried out on extended data sets, and performance is compared and analyzed. The results showed that YOLOv5 obtained an average detection rate of 69.3% when the threshold value was 50%, and the target detection speed reached 93.6FPS, which verified the feasibility and advantages of YOLOv5 as a drill pipe thread defect detection model.

(2) Aiming at the problem of (1) lack of depth information in thread defect analysis of two-dimensional images, a three-dimensional imaging system based on binocular method was designed, and a binocular stereo vision hardware platform was built based on FPGA, including

clock module, DDR controller module, camera driver module and HDMI top-level module, and software implementation was written. The simulation test of each module is carried out, and the resource consumption of the module is analyzed. The result shows that the hardware resource utilization efficiency is high. Through experiments, the correctness of dual image synchronous acquisition is verified, and the results show that the system can effectively obtain the binocular image of drill pipe thread.

(3) Based on content (2), the three-dimensional reconstruction method of drill pipe thread is studied. Firstly, the effect of baseline on the binocular vision imaging system was studied, and the baseline parameters were set as 169mm, 84.5mm and 35mm to carry out experimental research and analysis. The feature matching method of 3D reconstruction is studied, SIFT feature matching algorithm is implemented, and feature matching fusion experiments based on images with a baseline of 169mm, 84.5mm and 35mm are carried out. The experimental results show that the baseline of the binocular camera module has a great influence on the three-dimensional imaging of binocular stereo vision. When the baseline distance is 84.5mm, the stereo correction, SIFT feature matching and imaging effect are the best.

Keywords: Nondestructive testing, Machine vision, Deep learning models, 3D imaging methods

Thesis: Application Study

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	3
1.2.1 无损检测研究现状.....	3
1.2.2 基于深度学习的缺陷检测研究现状.....	4
1.2.3 三维成像研究现状.....	5
1.3 本文主要研究内容和文章结构	5
第二章 相关理论介绍	8
2.1 深度学习模型.....	8
2.1.1 用于缺陷检测的深度学习模型介绍.....	8
2.1.2 YOLO 系列模型分析.....	10
2.2 双目成像原理及方法研究	12
2.2.1 双目视觉成像原理.....	12
2.2.2 相机成像模型.....	13
2.3 本章小结.....	17
第三章 基于 YOLOv5 的钻杆螺纹缺陷检测研究与实验	18
3.1 引言.....	18
3.2 钻杆螺纹缺陷数据集的建立	18
3.3 YOLOv5 目标检测算法分析	21
3.3.1 输入层.....	22
3.3.2 SPP 模块	23
3.3.3 非极大值抑制.....	24
3.4 实验及结果分析.....	24
3.5 本章小结.....	29
第四章 基于双目法的钻杆螺纹三维成像系统设计	30
4.1 引言.....	30
4.2 基于双目法的三维成像方法研究及系统设计	30
4.2.1 基于 FPGA 的双目视觉系统整体设计	30
4.3 双目立体图像采集实现.....	32
4.3.1 OV5640 传感器及其配置.....	32
4.3.2 OV5640 驱动模块.....	36
4.3.3 图像采集实现.....	38
4.3.4 时钟控制模块实现.....	40
4.3.5 DDR3 控制模块	41

4.3.6 HDMI 顶层模块	44
4.4 实验结果及分析	47
4.5 本章小结	49
第五章 钻杆螺纹双目图像特征匹配方法研究与参数影响分析	50
5.1 双目距离对成像影响分析	50
5.1.1 图像传感模块基线参数设计分析	50
5.1.2 基线对双目成像影响的实验研究	50
5.2 SIFT 特征提取算法	54
5.2.1 尺度空间	55
5.2.2 金字塔	55
5.2.3 DOG 关键点定位	57
5.2.4 特征点方向及生成特征描述子	58
5.2.5 SIFT 特征匹配	59
5.3 实验结果与分析	59
5.4 本章小节	63
第六章 总结与展望	64
6.1 工作总结	64
6.2 研究展望	65
参考文献	66

第一章 绪论

1.1 研究背景及意义

石油钻杆是油气开采中重要的钻具，是连接钻头和井架控制平台传递动力、循环钻井液的重要部分。钻杆一般由钢材制造，设计有可旋合螺纹，使得钻杆能够轻松组合或分解，单根钻杆长约 9 米，根据钻进深度，通过公、母螺纹连接数根甚至数百根钻杆。在油田钻井作业中，由于要不断适应地质环境的复杂性以及进行高负荷钻探作业，钻杆衔接处受力复杂，容易导致螺纹出现磨损、螺牙变形、牙底裂纹等问题，导致钻具失效，从而引发钻井安全事故。如图 1-1 所示，钻杆连接区域^[1]的螺纹作为钻杆中一个容易损坏的重要部件，螺纹受损将会引起钻杆功效的降低，包含解体、连接不牢和泄露等风险。螺纹受损常导致钻杆断裂，频繁引发事故，不但会降低钻探的安全与生产效率，同样也会产生高额的修复与替换费用，对油田开发造成重大经济损失。因此，分析和研究钻杆联接区域螺纹的损坏问题变得尤为关键。



图 1-1 钻杆作业现场

钻杆螺纹的损伤类型有疲劳断裂^[2]、腐蚀^[3]、磨损^[4]、过度拉伸^[5]和过度压缩^[6]等不同情况。钻杆螺纹不同的缺陷如图 1-2 所示，若未及时维修或更换受损部分，可能会出现钻井事故，导致经济受到损失。因此，研究和分析钻杆接头螺纹的损伤原因、预测方法及其修复技术^[7]对于延长钻探设备的耐用性和确保作业稳定性至关重要，能够确保钻探操作的安全性。然而，由于钻杆联接结构的特殊性，螺纹缺陷区域检测空间非常有限，操作难度高。且钻杆螺纹处的缺陷种类繁多，螺纹缺陷位置多变，使缺陷区域的图像采

集和缺陷检测来说极具挑战。




图 1-2 钻杆螺纹的的不同缺陷

在工程中钻杆螺纹问题可以分为两种，一种是尺寸问题，包括螺纹外径、内径、公螺纹长度、螺纹距离等参数。如果钻具尺寸不符合国家标准，那么钻杆螺纹将无法通过验收，必须退回工厂重新加工。另一种是表面缺陷，主要包括毛刺过大、变形、表面划伤、漏冲孔等修边缺陷，金属板材拉伸缺陷有起皱、表面划伤、波纹、鼓起、凹陷、斑点等；而翻边的缺陷包括垂直度不够、高低不一、毛边等。

工业螺纹缺陷的主流的检测方法有目视检测法^[8]、漏磁检测法^[9]、渗透检测法^[10]、超声检测法^[11]以及机器视觉法^[12]等。表 1-1 是常用的金属表面缺陷检测技术。

表 1-1 常用的金属表面缺陷检测技术

性能指标	目视检测	漏磁检测	渗透检测	超声检测	机器视觉
效率	低	较高	较低	较低	高
速度	慢	较快	较慢	较慢	快
成本	高	较低	较低	较高	低
精度	低	较低	不可衡量	较高	高
可靠性	不稳定	稳定	稳定	稳定	稳定

由表 1-1 可得, 目视检测在检测速度、检成本、检测精度和检测可靠性等方面均存在不足, 超声检测虽然检测精度高, 但是检测率低, 且对检测对象的表面光滑度有很高要求。渗透检测法只适用于表面开口的缺陷, 漏磁检测法检测灵敏度较高, 检测速度快, 检测成本低, 但不适用于检测形状复杂的物体。相比之下, 机器视觉技术具有低成本、非接触和高度可视化等优点, 更适合进行螺纹缺陷检测。

1.2 国内外研究现状

1.2.1 无损检测研究现状

当前, 针对钻杆螺纹处缺陷检测的需求, 国内外的研究主要集中在以下几个方面。

超声无损检测技术: 当超声波探头与螺纹连接部位接触时, 它会接收反射的声波信号, 并通过评估螺纹部位声波信号的变化来检测内部是否存在缺损^[13]。巨西民等人设计的纵波小角度直探头和横波斜探头能检测 1mm 深度的裂纹缺陷^[14]。刘洪涛研究了超声检测在钻铤螺纹缺陷检测中的应用^[15], 而张鹏鲲则研究了超声检测在高强螺栓的无损检测方面的应用^[16]。郑承明等人研发了一种能够调节倾斜角度的超声检测探头和检测仪器, 准确检测到 1.2mm 深度的裂纹缺陷^[17]。

涡流无损检测技术: 利用涡流效应, 当交变电流以特定频率通入线圈时, 在其周边形成动态磁场。该磁场诱发导体表层产生环状电流, 即涡流, 这又会产生一个次级的磁场。这一初级磁场与次级磁场的交互作用, 进而改变了电路的电气参数, 例如改变了电阻值和电感量, 最终对线圈中的电压和电流幅值造成影响^[18]。涡流检测技术在微小裂纹检测方面表现优异, 然而会导致产生大量的检测数据, 这对检测设备的研发提出了较高的要求。孙金立等学者对涡流检测技术在钻杆螺纹裂纹的应用进行了研究, 他们使用带有屏蔽装置的涡流检测探头进行对钻杆螺纹疲劳裂纹的检测, 可以探测出长 1mm 深 3mm 的人工裂纹^[19]。

漏磁无损检测技术: 漏磁检测技术通过在螺纹连接处施加一个外部磁场, 并使用磁敏感探头来探测由于螺纹内部缺陷引发的磁场泄漏, 从而实现缺陷的检测^[20]。Hwang 对螺纹裂缝的深度及宽度对检测中漏磁场的影响进行了研究^[21]。Mingye Yan 等人利用有限元方法对漏磁检测中缺陷区域的漏磁场进行了数学模型分析, 并导出了缺陷区域漏磁场的矢量偏微分方程^[22]。辛荣亚等学者对漏磁检测技术展开了大量研究, 探讨了该技术在压力容器、钢丝绳和石油输送管中的应用^[23]。

机器视觉检测: 在机器视觉系统中, 通过图像处理技术对螺纹连接的表面进行综合检测和几何形态分析, 对捕获的图像进行详细处理与分析, 可以识别出螺纹表面的裂纹、磨损、剥落、变形等各类损伤^[24]。Hoiaud.R 等人利用图像识别技术在微型机上进行非接触测量, 针对螺纹参数进行检测, 并将所得参数与实际螺纹尺寸进行比对以评判测量精度^[25]。Ajay Pal Singh 等人将机器视觉技术应用于螺栓生产线, 通过摄像机采集原始图像, 利用图像处理技术进行线性增强和二值化分割, 运用边缘检测算子提取螺纹的边

缘线特征值,识别工件形状并对其分类,确定螺纹孔具体位置,然后将识别结果反馈至上位机,以方便后续处理^[26]。Mohamed A 等人则通过机器视觉技术来检测圆柱形工业零件,依赖外接圆的定位进行检测^[27]。王和顺采用 CCD 相机的机器视觉系统,研究了收集和处理螺纹边缘和参数数据的自动化装置^[28]。

1.2.2 基于深度学习的缺陷检测研究现状

人为设定的缺陷特征影响着传统目标检测,即便使用高效能的分类器,现场的检测效果仍未达标。为了增强特征的语义层次并提升检测系统的整体性能,同时降低人为操作对检测结果的影响,优化特征描述与分类技术^[29],学界开展了广泛研究。

随着计算机处理能力的增强及人工智能领域的理论进展,包括 Hinton 等学者在内的研究者们推动了深度学习理论的发展。基于深度学习的表面缺陷检测技术因此受到关注,已在图像识别和目标检测等领域得到了广泛应用^[30]。深度学习具备强大的表征和建模能力,能够自主学习待检测目标的深层特征,极大丰富了图像内在信息,提高了特征的表征能力。深度学习表征和建模能力强,能自主学习待检测目标的深层特征。叶少锋等在钣金折弯件表面缺陷检测中对传统视觉和深度学习方法进行对比,后者检测效果更好^[31]。海潮红枣表面缺陷识别研究采用 Inception V3 网络,相较于 Blob 算法准确性更高^[32]。在汽车轮毂表面缺陷检测方面,赵海文等运用卷积神经网络得到较高检测精度,但耗时较长^[33]。

为解决深度学习算法耗时长、速度慢等问题,目标检测领域经历了 RCNN、SPPNet、Fast RCNN、Faster RCNN 的发展,最终演进为 Faster RCNN 的理论与实践,逐渐解决了检测速度慢的难题。在具体的应用过程中,这一系列的技术进步显著提升了模型的处理效率。在实际应用过程中,国内各大钢铁生产企业逐渐接受了基于深度学习的检测技术。Tang 等学者^[34]通过将空间注意力机制与通道注意力机制相结合,并引入多样化的激活函数,使得模型在面对不同尺寸的 PCB 缺陷时仍能获得出色的检测效果。为了解决大纹理变化和小尺寸缺陷检测问题,Cui 等学者^[35]融合了具有不同分辨率的多个金字塔特征图,确保纹理信息在下采样过程中不会丢失,同时通过密集连接将细粒度较低的特征图与高维度的特征图相融合,以更好地预测小缺陷目标。Wang 等^[36]学者基于 YOLOv5 提出了一种协调注意力机制,通过在通道注意力中嵌入位置信息,缓解了由下采样引起的位置信息丢失问题。其次,通过解耦合的检测层,将分类和回归任务剥离开来,有效地提升了模型的检测精度和收敛速度。在 NEU-DET 数据集上,改良后的模型较原有的 YOLOv5 提升了 5.8% 的 mAP。此外,Xu 等人^[37]在引入通道位置关注和解耦检测层的基础上,增添了专为检测小目标而设计的浅层预测层,并在特征融合层中引入更多来自骨干网络的浅层特征,从而进一步提升了对小型物体纹理的检测效果。Chen 等人^[38]在基于 Swin Transformer 的基础上,增加了局部增强的特征提取模块,并采用多级特征图融合的方式,提高了模型的建模能力,在 PSDD 数据集上的 AP50 分数达到了 96.4%,优

于 YOLO、SSD、Faster R-CNN 等模型。

1.2.3 三维成像研究现状

在立体视觉系统中，立体匹配扮演着核心角色，它通过分析空间点在两个不同视角图像上的位置差异来计算视差值，进而根据视差值确定空间中点的三维坐标。这一过程的目标是在从不同视点拍摄的图像里识别出对应的点。为了深入探索图像匹配问题，国内外的研究者们进行了广泛的研究，这些研究大致可以分为两大类：一类是基于灰度值进行匹配的方法，另一类则是依赖于图像特征进行匹配的策略^[39]。

均值绝对差算法通过求取灰度值绝对差总和的平均值计算相似度，匹配准确率较高且计算量较小。归一化互相关(NCC)算法利用相关性度量公式，比较子图与模板图的灰度来计算匹配程度，提高了精度和速度^[40]。Silveman 等人开发的归一化互相关(NCC)算法，通过评估子图与模板图之间的灰度信息，使用归一化的相关性指标来确定匹配程度，从而提升了匹配过程的效率和准确性^[41]。Baumgartner 等人将广义霍夫变换应用于图像匹配算法，提高了计算精度和速度^[42]。孙远等人提出的 NCC 算法也达到了预期效果。薛利军等人基于全扫描检索最佳匹配点，提出立体匹配算法^[43]。彭晓明提出的坐标匹配算法利用最小正方盒距离变换的方式，快速进行目标搜索^[44]。

特征匹配算法提取检测物品图像的明显特征，用于立体图像匹配^[45]。Harris 等人提出的 Harris 角点检测算法通过比较滑动前后窗口中的像素灰度变化程度来判断是否为角点^[46]。Smith 等人利用 SUSAN 角点的特征，通过计算滑动过程中窗口内像素点的灰度值与中心像素的差值来判断^[47]。DavisLowe 等人总结了基于特征不变技术的检测方法，并引入了 SIFT 描述子检测法^[48]。SIFT 算法利用 SIFT 描述子用于抽取图像的位置、尺度等特征信息。Duan 利用 SIFT 寻找满足统计独立性和非高斯特性的成分来提取特征^[49]。Wang 等人提出的 BFSIFT 算法可以有效保留图像边缘信息^[50]。Zhou 等人为降低 SIFT 算法的误匹配率，利用图像的形状及色彩特征进行图像描述^[51]。

1.3 本文主要研究内容和文章结构

基于上文所述研究背景和研究现状，本文的主要研究内容是基于机器视觉的钻杆螺纹缺陷检测关键技术研究，首先，根据钻杆螺纹裂纹缺陷特征，研究基于深度学习模型的裂纹检测方法，建立螺纹裂纹缺陷数据集，通过实验分析 YOLO 模型在螺纹裂纹缺陷检测方面的性能。其次，由于在二维图像中研究螺纹缺陷检测方法，只能获得螺纹缺陷的面积大小，缺少缺陷深度信息，而缺陷深度是钻杆失效的关键因素，针对存在的不足，提出一种基于双目法的螺纹三维成像方法，研究双目成像原理，设计基于 FPGA 的双摄像头成像系统。最后，设计与实现系统软硬件部分，完成螺纹图像的双目采集与显示，通过实验研究与分析，研究双摄像头参数设置对螺纹图像显示的影响，基于 SIFT 图像匹配算法，实现了钻杆螺纹的三维成像，并对结果及不足进行分析。本文组织架构

图如图 1-3 所示。




图 1-3 本文组织架构图

本文的结构安排如下：

第一章：绪论。首先介绍基于机器视觉的钻杆螺纹缺陷检测的研究背景，明确了本文的研究意义与价值；其次，通过对无损检测技术、基于深度学习的缺陷检测和三维成像的研究现状的分析，阐述了适用于钻杆螺纹缺陷检测的方法及方法优势；最后，提出了本论文的主要研究内容及各章节的详细安排。

第二章：相关原理介绍。首先介绍了用于缺陷检测的深度学习模型，分析了主流目标检测算法以及 YOLO 系列模型的优缺点；然后详细阐述了双目立体视觉成像原理，并对相机成像模型及参考系之间的转换、极线约束等相关参数进行了介绍；最后，分析了双目立体图像的校正流程，并对双目立体匹配中两类算法进行了对比，为后续各模块的研究设计打下了基础。

第三章：基于 YOLOv5 的钻杆螺纹缺陷检测研究与实验。首先针对钻杆螺纹裂缝数据集缺少的情况，通过作业现场采集、油田相关单位收集的方式建立有关螺纹裂缝的基础数据集，通过数据增强等方式对数据集进行了扩充；其次，为了便于多模型之间的对比实验，设计实现了 VOC 格式文件转换为 YOLO 格式文件；然后选择 YOLOv5 模型作为螺纹缺陷检测的训练模型，对模型输入层、基础特征提取、多尺寸特征融合层以及检测层的结构与思路方法进行了介绍；最后将扩充后的数据集应用在 YOLOv5 与 YOLOv8s 等模型上进行对比分析，通过实验验证 YOLOv5 模型在缺陷检测中的有效性。

第四章：基于双目法的三维成像方法研究及系统设计与实现。首先，对图像采集系统的框架和各模块的作用进行了整体说明；随后阐述了各模块的具体设计，主要包括时钟控制模块、图像分辨率设置模块、DDR 控制器模块、摄像头驱动模块和 HDMI 顶层显示模块；最后，在 Vivado 平台上对上述模块的功能进行了验证，证明了系统采集的可行性，并对采集结果进行了分析。

第五章：钻杆螺纹三维重构方法研究。首先对双目距离对图像成像的影响进行了理论分析，设计并实现了改变双目摄像机基线距离的采集系统，通过实验验证了基线对于左右视图采集信息丰富量的影响；然后，阐述了本文所采用的 SIFT 匹配算法的基本原理，介绍了尺度空间的构造方法，对比了高斯金字塔与高斯差分金字塔的思路方法；最后，在 pycharm 中对采集到的不同基线距离的双目图像进行三维成像重构，验证了双目摄像头基线距离对三维成像的影响。

第六章为总结与展望。首先针对本设计的主要研究内容以及各章节结论做了总结；然后对本文各章节内容进一步分析，对下一步的研究方向提出了建议。

第二章 相关理论介绍

2.1 深度学习模型

2.1.1 用于缺陷检测的深度学习模型介绍

a. Mask R-CNN

由于钻杆螺纹与螺纹处裂纹形态相似，因此实现目标分割难度较大。针对目标检测和实例分割之间的瓶颈问题，Kaiming He 团队提出 Mask R-CNN 算法^[52]。与 R-CNN 相比，该算法不仅具有目标检测的功能，还引入了一个额外的全卷积网络（FCN）用于实例分割，可以获得像素级的目标分割掩膜，并增加了对实例分割的训练，通过多任务损失函数同时优化目标分类、边界框回归和实例分割，实现了联合训练，由此获得更精确的像素级分割结果。Mask R-CNN 网络结构如图 2-1 所示。




图 2-1 Mask R-CNN 网络结构

Mask R-CNN 算法检测流程为：首先，使用卷积神经网络对输入图像进行特征提取。可以使用预训练的 CNN 模型，如 ResNet、VGG 等，来获取图像的高层抽象特征。接下来，基于提取的特征，引入了 Region Proposal Network，用于生成候选区域。RPN 是一个小型神经网络，根据特征图的每个位置输出多个候选区域，并预测其是否包含目标。通过使用 IoU 作为标准，将候选区域分为正样本和负样本。然后，对于每一个正样本区域，进行目标分类和边界框回归。具体来说，它在每个正样本区域上应用 RoI Pooling 操作，将不同尺寸的特征图转化为固定大小的特征向量。然后，特征向量被输入到两个分支中，一个用于目标分类（如物体类别），另一个用于边界框回归（如物体的位置和大小）。最后，为了实现实例分割，在分类和边界框回归的基础上，引入了一个全卷积网络来生成每个正样本区域的像素级掩膜。具体地，它使用 RoIAlign 操作将每个正样本

区域对齐到固定大小的特征图，并将其输入到 FCN 中进行像素级的分割预测。这样，就可以获得每个物体的二值掩膜，进而实现实例分割。Mask R-CNN 算法通过结合目标检测和实例分割的方式在在物体识别和分割任务中取得了高精度、低漏检率的成绩。但由于其计算过于复杂，对硬件资源要求高，并不符合实际应用需求。

b. EfficientDet

EfficientDet^[53]是谷歌 Brain 团队于 2019 年提出的一种高效的单阶段目标检测算法。相对于 Mask R-CNN，该算法以 EfficientNet 作为特征提取网络，并利用双向特征金字塔网络（BiFPN）来实现跨尺度特征融合，在保持高效性能的同时达到较高的检测准确度。该算法中 EfficientNet 的复合缩放方法被延伸，通过明确架构决策，为不同的应用场景提供了 8 种模型，分别为 D0 至 D7。

根据实际环境中软硬件的性价比及精度、效率需求的考量，来对模型进行合理选择。随着 EfficientDet D0-D7 模型的逐渐升级，深度不断增加，输入分辨率也日益提高，精度随之提升，但计算负荷也随之增加。EfficientDet-d0 网络采用了端到端的设计，在 EfficientNet 的基础上引入了 BiFPN 作为特征网络，在接收到主干网络的特征后进行双向特征融合，最后将融合后的特征输入分类和边框回归网络，输出目标的类别和位置信息，从而实现目标检测。整个网络的结构如图 2-2 所示。




图 2-2 EfficientDet-d0 网络结构

EfficientDet 采用了模型复杂度可调的思想，可以根据不同的应用需求进行模型大小的调整，在速度和准确度之间找到平衡点，具有一定的灵活性。但是由于模型具有多个组件和超参数需要调优，因此模型的参数调优过程相对复杂，需要花费较多时间和精力来进行参数调优，且对于小规模数据集或者训练不充分的情况，EfficientDet 可能存在过拟合的风险，导致对小目标的检测效果仍然不佳。

c. YOLO

YOLO^[54]算法是一种经典的实时目标检测算法。相较于传统的目标检测方法，YOLO 不需要多次扫描图像，而是通过一个单一的神经网络模型，直接对整张图像进行目标检测和分类，并输出每个目标框的位置和类别概率。首先将输入图像划分为 $s \times s$ 个单元，若某一目标中心在该单元内，则该单元负责预测该目标。此外，每个单元需要预测 B 个边界框的位置信息和置信度，每个边界框对应四个位置信息和一个置信度，置信

度表示预测的边界框中是否含有目标，以及该预测的准确度。计算公式可由公式(2-1)表示为：

$$\text{置信度} = \text{Pr}(\text{Object}) * \text{IoU}(\text{pred}, \text{truth}) \quad (2-1)$$

其中，如果某个网格内存在目标物体，则第一项取 1 表示有目标，若该网格内未存在目标物，则取 0 表示无目标。 $\text{IoU}(\text{pred}, \text{truth})$ 表示预测的边界框和实际的 *ground truth* 之间的 *IoU* 值。

然后，每个网格还要预测一个类别信息，记为 C 类。因此，每个网格共需预测 $5B+C$ 个值。最终输出由公式(2-2)表示为：

$$W = s * s * (5B + C) \quad (2-2)$$

YOLO 算法检测原理如图 2-3 所示。




图 2-3 YOLO 算法原理图

与传统的两阶段目标检测算法不同，YOLO 是一种单阶段的目标检测方法，它将目标检测任务视为一个回归问题，并直接在图像上进行预测，因此能实现较快的检测速度。

2.1.2 YOLO 系列模型分析

a. YOLOv1

YOLOv1 是 YOLO 系列的第一个版本，采用了全卷积网络结构，将目标检测问题转化为一个回归问题。算法将输入的图像分割成许多小方块，每个小方块负责预测多个边界框和它们的置信度得分，以及每个类别的概率。通过对这些预测结果进行后处理，即可得到最终的目标检测结果。

优点：实时性高，可以在单次前向传播中得到整个图像的检测结果。同时，YOLOv1 在速度和准确性之间取得了一定的平衡，适用于实时目标检测应用。缺点：YOLOv1 存在一定的误检和定位不准确问题，特别是对小目标的检测效果相对较差，这可能导致一些目标被错过。此外，YOLOv1 对密集目标的检测效果较弱。

b. YOLOv2

YOLOv2^[55]在 YOLOv1 的基础上进行了改进和优化。它引入了 Darknet-19 作为基础网络，并采用多尺度特征图来提高对小目标的检测性能。此外，YOLOv2 还引入了 Anchor Boxes 技术用于，使用预定义的一组锚定框来预测不同尺寸和纵横比的目标。

优点：YOLOv2 相对于 YOLOv1 在准确性和速度方面有了显著提升。使用 Anchor Boxes 能够更好地适应目标的大小和形状变化。此外，YOLOv2 还引入了批标准化（Batch Normalization）等技术来提高训练和推理的稳定性。缺点：相较于 YOLOv1，YOLOv2 的训练时间和计算复杂度较高。同时，其存在针对一些类别样本不平衡的问题，而且在相对静止场景中定位精度可能不够高。

c. YOLOv3

YOLOv3^[56]在 YOLOv2 的基础上进一步改进。它引入了 FPN（Feature Pyramid Network）来处理多尺度的特征表示，并使用不同尺度的预测层来检测不同大小的目标。此外，YOLOv3 还采用了卷积核的跨通道信息交换和连接来增强特征表达。

优点：YOLOv3 相对于 YOLOv2 在准确性和多尺度检测能力上有所提升。FPN 结构可以更好地捕捉多尺度特征，使得模型能够检测更小的目标，并具有较强的泛化能力。此外，YOLOv3 还引入了更多的卷积层和参数量，提高了模型的表达能力，可以更好地处理复杂场景下的目标检测任务。缺点：YOLOv3 在速度上相对于 YOLOv2 有所下降，并且对于小目标的检测仍然有一定的限制。另外，YOLOv3 的网络结构较复杂，导致其模型体积较大，部署和运行的难度较大。

d. YOLOv4

YOLOv4^[57]引入了 CSPDarknet53 作为主干网络，并增加了 SAM（Spatial Attention Module）和 PANet（Path Aggregation Network）等模块来增强特征表达和多尺度特征融合。此外，YOLOv4 还使用了 Mosaic 数据增强和 CIOU 损失函数等优化技术来提高检测性能。

优点：YOLOv4 在准确性和速度上都取得了显著的提升。引入 CSPDarknet53 网络能够更好地提取特征，SAM 和 PANet 能够增强特征表达和信息融合。此外，YOLOv4 还采用了一些先进的技术来提高检测精度，如 Mosaic 数据增强和 CIOU 损失函数。缺点：YOLOv4 相对于其他版本的 YOLO 在计算资源方面要求较高，需要更多的存储和计算资源。此外，YOLOv4 的网络结构较复杂，对于部署和运行的要求也较高。

e. YOLOv5

YOLOv5^[58]引入了一种轻量级的特征提取网路，使用 CSPDarknet 作为主干网络。

相比于 YOLOv4 中的 Darknet-53, CSPDarknet 具有更少的参数和计算量, 使得 YOLOv5 更加轻量化。并且, YOLOv5 提供了自动化的训练工具, 使得整个训练流程更加简化 and 高效。这些工具包括数据集处理、模型配置和训练过程的自动化操作, 降低了训练的技术门槛。此外, YOLOv5 还提供了多个预训练模型和模型尺寸变体, 包括 YOLOv5s、YOLOv5m、YOLOv5l 和 YOLOv5x 等。这些模型尺寸的变体可以根据实际需求和资源限制进行选择, 满足不同应用场景的需求。YOLOv5 通过网络结构和代码优化, 提高了模型的推理速度, 并且减少了内存占用, 这使得 YOLOv5 在实时目标检测任务中更具效率。

2.2 双目成像原理及方法研究

2.2.1 双目视觉成像原理

双眼视觉中, 因为眼睛位置的差异, 两只眼睛接收到同一物体的图像在视平面上会存在微小的差别, 这种差别即为视差, 是我们感知深度和立体效果的重要依据。当两只眼睛分别观察同一个场景时, 由于它们位于不同的位置, 它们看到的图像会有细微的差别。这是因为物体距离观察者越近, 视差就越大; 物体距离观察者越远, 视差则越小。视差是由双目视觉系统的几何特性决定的。双目成像基本流程如图 2-4 所示, 选择一个图像作为参考图像, 然后在另一个图像中搜索具有相似特征的对应点。通过计算参考点和对应点之间的像素位移, 可以得到视差值, 从而推断出目标物体的距离。

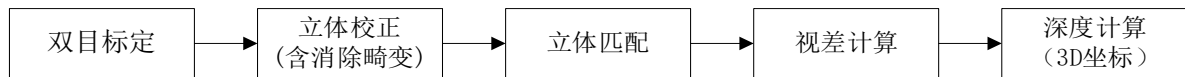


图 2-4 双目成像基本流程

因此, 在双目立体视觉中, 解决图像在左右视角投影的视差是至关重要的问题, 视差图的准确性直接影响整套系统的精度。通过分析左右图像中像素之间的差异, 系统能够计算出相应的视差, 确定不同物体在场景中的位置与距离。双目视觉视差图如图 2-5 所示。




图 2-5 双目视觉视差示意图

如图 2-5 所示，图中 B 表示两颗摄像头之间的距离即基线， P 为目标物体的空间坐标点， Z 为双目与目标物体的距离即深度， f 为焦距。当两摄像头在同一时刻观察目标物体 P ， p 为左摄像头采集的关于 P 的左图像， p' 为右摄像头采集的关于 P 的右图像。

视差 d 等于同名点在左视图的列坐标减去在右视图上的列坐标，是像素单位。视差 d 可表示为公式(2-3)：

$$d = x_l - x_r \quad (2-3)$$

从该公式中可推断出，物体的实际深度和其在左右图像上的视差成反比关系。当物体离相机光心较近时，在左右图像上呈现出较大的视差；而当物体离相机光心较远时，在左右图像上显示较小的视差。这种关系与我们在实际生活中观察物体时的直观感受是一致的。

2.2.2 相机成像模型

三维空间中的坐标点通过相机映射到二维图像平面的转换过程，可以通过几何学模型进行阐述。在众多相机模型中，针孔模型因其简洁性而广泛应用，同时也展现出了有效性。针孔相机模型用于构建三维空间到二维图像平面的映射关系^[59]。然而，由于相机透镜的存在，光线在投影时可能产生畸变。因此，通常需要将针孔模型与畸变模型相结合，以全面描述整个成像过程。在最佳情况下，相机成像模型呈线性特性，由此可知相机的成像过程可以用简单的线性变换或矩阵运算在齐次坐标系下加以描述。

a. 参考系

为了描述和定位物体、点或者图像在空间中位置在计算机视觉系统中引入以下几种坐标系，如图 2-6 所示。




图 2-6 参考坐标系

图像像素坐标系被用来精确定位图像中各个像素的具体位置，它将空间中的点映射到二维图像上。图像坐标系以 CCD 平面左上角为原点，向右的水平方向定义为 u 轴，垂直向下的方向为 v 轴。像素位置由其在矩阵内的列坐标 u 和行坐标 v 表示^[60]。

图像像素坐标系^[61]仅表示像素所在位置，并无物理大小含义。为此，建立了一个带有物理测量单位（如毫米）的笛卡尔坐标系，原点 (u_0, v_0) 位于 CCD 中央，其 X 和 Y 轴分别与像素坐标系的 u 、 v 轴对齐，使用 (x, y) 来定位。

摄像机坐标系^[62]参照是以摄像头本身为中心，原点设在光学中心， X 、 Y 轴保持与图像物理坐标系的 X 、 Y 轴平行， Z 轴与摄像头光轴对齐，遵守右手规则。这一系中的三维点位置用 (X_c, Y_c, Z_c) 来表述。

世界坐标系则描述物体在全局环境中的固定位置，通过三维坐标 (X_w, Y_w, Z_w) 来确定场景中任意点的位置。

在上述四种坐标系中，绝对坐标系可利用相机的外参矩阵(包括平移和旋转)将世界坐标系中的物体坐标转换为相机坐标系中的坐标。相机坐标系可通过相机的内参矩阵(包括焦距，主点等)将三维物体坐标从相机坐标系转换为归一化设备坐标系，再映射到像素坐标系。

b. 极线约束

来自同一场景的两幅图像之间具有一定的约束关系，这是由双目立体视觉系统所获得的，即对极几何关系。它基于相机的内参和外参，揭示了两个相机之间的对应关系和像素点在二维图像中的投影关系。根据两个相机光轴是否平行，双目立体视觉系统可分为平行和非平行两类。其中，平行双目立体视觉系统具有广泛的应用。

平行双目立体视觉系统的对极几何如图 2-7。该系统中两相机坐标系间只在 x 轴方向有一段基线距离 b ，此布局造成空间任一点在两相机成像时 v 方向的图像坐标一致，而 u 方向则存在差异，这种差异被称为“视差”。对极几何的典型特性是极线与图像扫描线（即垂直于 v 轴的线）平行。理论上，两极线应该是共线的，通过这种方式将匹配点搜索的空间缩减至一维。然而，因相机安装的微小误差或镜头的畸变作用，两极线通常只能近似共线。




图 2-7 平行双目立体视觉系统的对极几何

在图 2-7 中, 设 E_{1i} 与 E_{2i} 分别为两条极线, 空间中一点 $P(x_{1i}, y_{1i}, z_{1i})$ 在两个相机中的成像点分别为 p_{1i} 和 p_{2i} 。记 $m_{1i} = (u_1, v_1, 1)$ 表示左图像中 p_{1i} 点的图像齐次坐标, $m_{2i} = (u_2, v_2, 1)$ 表示右图像中 p_{1i} 对应的匹配点 p_{2i} 的齐次坐标, $l_{2i} = Fm_{1i} \equiv (\alpha'_i, \beta'_i, \gamma'_i)$ 表示 m_{1i} 在右图像中对应的极线方程, $l_{1i} = F^T m_{2i} \equiv (\alpha'_i, \beta'_i, \gamma'_i)^T$ 表示 m_{2i} 在左图像中对应的极线方程(其中, α, β, γ 分别表示直线方程的系数)。而两个对应点之间可以通过基础矩阵联系, 基础矩阵在数学上可描述为公式(2-4):

$$m_{2i}^T F m_{1i} = 0 \quad (2-4)$$

因而, 恢复对极几何问题就转变成为了基础矩阵的计算问题。

c. 双目立体图像校正

在图像采集的过程中, 镜头的畸变和相机摆放的位置等因素会导致非线性畸变, 影响图像的准确性。针对这个问题, 需执行校正程序以消弭图像畸变, 并运用相机标定得到的参数消除垂直视差。校正后的图像品质和精度提升, 误差降低, 从而增强后续图像处理与分析的效能。

如图 2-8 展示了双目立体图像校正的步骤。首先, 用左右相机独立获得的畸变参数进行纠正, 让图像重映射回成像面, 保障空间位置的精确性。然后, 通过极线校正技术进一步调整双目图像, 使其满足极线约束, 排除由于相机非水平放置引起的垂直视差。校正过程确保了图像的准确几何结构, 便于接下来进行立体匹配和深度估算。校正完成的图像可能会出现黑边或空白区域, 可通过裁切步骤移除。处理后的图像保持准确的几何关系, 有利于后续的立体匹配和深度计算。经校正后, 图像可能存在黑边或无效区域, 可通过裁剪操作进行清除。




图 2-8 双目立体图像校正流程

d. 立体匹配

立体匹配是指通过对左右相机拍摄到的图像进行比较和匹配, 找到对应的像素点或图像块, 在两幅图像之间建立像素点或像素块的对应关系, 通过这种方法可以计算视差值。立体匹配算法分为全局和局部两种^[63]。

局部立体匹配算法旨在通过寻找每个像素位置的最佳视差值来解决深度估计的问题, 这一过程通常涉及对每个像素及其周边的像素点或区块进行匹配。该算法基于局部最佳化原则, 通过最小化能量函数来判断像素与其邻近窗口的匹配程度。选择合适的窗口大小对于处理弱纹理、缺乏纹理和重复纹理的区域非常关键, 有助于保证深度信息的一致性。局部算法与全局算法在立体匹配中的一个主要差异在于, 局部算法构建的能量方程仅包括数据项, 不考虑平滑项。由此, 就噪声抵抗力方面, 局部立体匹配算法通常不如全局方法。但其运行速度更快, 可以满足实时性要求的需要。

不同算法在不同场景下可能表现出更好的匹配性能，从而提高深度估计的准确性。因此，根据具体的应用需求和环境特点，选择最适合的算法是实现高精度视差图的关键基础。常见的局部匹配算法的核心公式如表 2-1 所示。

表 2-1 局部立体匹配算法

算法	核心公式
AD	$\frac{1}{3} \sum_{u=R,G,B} I_u^{Left}(p) - I_u^{Right}(p, d_x) \quad (2-5)$
SAD	$\sum_{u=i} \sum_{v=j} I_L(x+u, y+v) - I_R(x+d_x+u, y+v) \quad (2-6)$
NCC	$\frac{\sum_{u=i} \sum_{v=j} I_L(x+u, y+v) I_R(x+d_x+u, y+v)}{\sqrt{\sum_{u=i} \sum_{v=j} I_L(x+u, y+v)^2 \sum_{u=i} \sum_{v=j} I_R(x+d_x+u, y+v)^2}} \quad (2-7)$
Census	$\sum_{u=i} \sum_{v=j} ham(I_L(x+u, v+j), I_R(x+u+d_x, v+j)) \quad (2-8)$
SCP	$\sum_{u=i} \sum_{v=j} I_L(x+u, y+v) - I_R(x+d_x+u, y+v) \quad (2-9)$

根据表格中的信息可以得知，以上的五种算法在特征匹配过程中均依赖于图像的灰度信息。进行像素对应时，首先确定待匹配图像中的某一指定像素 p ，随后在基准图像中遍历寻找与之灰度最接近的点，作为匹配的最优点。

全局立体匹配利用图像的全局约束信息，通过构建包括匹配代价的数据项和平滑项的全局能量函数，然后通过对其最小化以求得最终视差图，主要用来解决由于遮挡或重复纹理造成的像素误匹配问题，全局算法从整体的视角出发，通过优化理论方法进行视差值估计，有助于提高视差值的准确性和性能，在生成视差图方面通常效果更佳。然而，全局算法可能会陷入局部最优解的困境，并且其算法结构复杂，计算难度较高，因此需要根据具体情况选择适当的算法。全局立体匹配算法公式如(2-10)所示。

$$E(d) = E_{data}(d) + \lambda E_{smooth}(d) \quad (2-10)$$

公式(2-8)中 $E(d)$ 表示能量函数，数据项 $E_{data}(d)$ 被用来度量像素之间的相似性问题，它基于图像的亮度信息和纹理特征，用于判断两个像素之间的相似程度，通过最小化 $E_{data}(d)$ ，以使得具有相似亮度和纹理的像素具有较小的视差差异，从而提高深度图的准确性。平滑项 $E_{smooth}(d)$ 则用来表示像素间的视差平滑关系。通过最小化 $E_{smooth}(d)$ ，可以在深度图中保持相邻像素视差的平滑性，即相邻像素的视差变化应该尽可能小。这样做的目的是避免深度图中出现不连续、突变的视差值，以获得更加平滑和连贯的深度图结果。全局立体匹配算法具准确性高、对纹理复杂场景效果好，能够保持图像一致性等优点，同时也存在计算复杂度高、内存消耗大以及对大规模数据不友好的问题。常见的全局立体匹配算法有基于动态规划法的匹配方法、最大流-最小割法和协同迭代算法。

全局立体匹配算法和局部立体匹配算法区别如图 2-9 所示。




图 2-9 局部立体匹配算法和全局立体匹配算法对比

2.3 本章小结

本章首先介绍了主流目标检测算法的原理并对比分析了主流目标检测算法针对小目标的检测性能，介绍了 YOLOv5 算法相对于 YOLO 其他系列算法的优势。随后，介绍了双目视觉系统的成像原理，分析了成像模型的原理，并对相关参数（参考系、针孔模型、畸变模型和极线约束）进行了详细说明，明确了求得深度信息的步骤及方法。最后，介绍了立体匹配算法的基本原理，并详细对比分析局部立体匹配算法和全局立体匹配算法的优缺点。为接下来的基于双目法的三维成像系统设计提供了理论支持。

第三章 基于 YOLOv5 的钻杆螺纹缺陷检测研究与实验

3.1 引言

目前, 钻杆螺纹缺陷采用人工检测方式, 其效率低、误差大, 因此实现钻杆螺纹缺陷的智能化检测能够, 提高检测精度、工作效率, 易于提高检测精度, 形成缺陷数据库, 便于后续缺陷级别的量化与评估。钻杆螺纹裂缝缺陷是螺纹缺陷中危害最大的一种, 因此, 本章节研究螺纹裂缝的检测方法。因为缺少钻杆螺纹裂缝缺陷的公开数据集, 本章通过作业现场采集、油田相关单位收集等方式, 得到了多种规格的钻杆螺纹的裂缝缺陷, 建立有关裂缝的缺陷数据集, 分为训练集和测试集。为了便于在各种训练模型中对比实验, 本文数据集选择 VOC 格式, 通过编码代写实现 VOC 格式文件转换为 YOLO 格式文件。在此基础上, 将扩充的数据集在 YOLOv5 和 YOLOv8s 模型中分别进行训练, 对比分析检测效果, 验证 YOLOv5 作为钻杆螺纹缺陷检测模型的有效性。

3.2 钻杆螺纹缺陷数据集的建立

a. 数据集扩充

本项目共获得原始钻杆螺纹裂缝图像数据 49 张。针对原始数据量不足, 影响图像检测效果的情况, 实验中采用数据增强、翻转和切片等方法对数据集进行扩充, 先将数据集按照 9: 1 比例划分为训练集和测试集。然后将每幅图像均切割成 512×512 像素的小图像, 允许小图像之间重叠比例为 0.5, 并剔除冗余数据。将图像进行分类均衡化处理后, 最终得到包含训练集 337 张, 验证集 38 张, 测试集 43 张的切片图像数据集, 其中包括裂纹特征明显的图像 30 张, 以及裂纹特征模糊的图像 13 张。扩充后的部分样本如图 3-1 所示。




图 3-1 扩充后的部分样本集

b. YOLO 格式数据集的转换

YOLOv5 训练用的数据集格式是 YOLO 格式, YOLOv3 训练用的数据集格式是 VOC 格式, 这是两种训练模型使用数据集不同的地方, 关于数据集格式的选择, 本文选择 VOC 格式, 在打标签的时候就直接制作为 VOC 数据集格式, 当需要应用于不同训练模型时, 只需要用在 Python 中运行程序就可直接将 VOC 数据集转换为 YOLO 数据集, 这样就可以打一次标签的数据集用在多种训练模型上, 便于数据在不同模型上的对比训练。如图 3-2 为一张 16*16 的照片, 其中绿色为目标位置, 蓝色为目标背景。




图 3-2 16*16 照片

VOC 文件的目标信息为: $(weight, height, depth, (x_{min}, y_{min}), (x_{max}, y_{min}))$ 。若要将其转换为 YOLO 文件格式, 需要进行归一化处理, 转换公式如下。

归一化中心坐标:

$$x_{cen} = \frac{x_{min} + x_{max}}{2}, y_{cen} = \frac{y_{min} + y_{max}}{2} \quad (3-1)$$

$$x = \frac{x_{cen}}{weight}, y = \frac{y_{cen}}{height} \quad (3-2)$$

归一化锚框:

$$w = \frac{x_{max} - x_{min}}{weight}, h = \frac{y_{max} - y_{min}}{height} \quad (3-3)$$

转换以后可以得到 YOLO 文件的目标信息: $(1, x, y, w, h) = (1, 0.25, 0.25, 0.5, 0.5)$

VOC 格式文件详细内容如图 3-3。当选取任意的一个 xml 文件打开, 最外层是 annotation 标签, 其内部均为标注信息, 包括该图所在文件夹、该图文件名、来源及图像尺寸 (具体宽、高和通道数) 等参数信息, 其中会有多个 object 标签, 每个 object 标签都详细描述了对应的检测对象信息。VOC 格式标签: 图片实际宽和高, 标注框的左上角和右下角坐标。

```
<annotation>
  <folder>VOC2012</folder> # 图像所在文件夹
  <filename>2007_000032.jpg</filename> # 图像文件名
  <source> # 图像源
    <database>The VOC2007 Database</database>
    <annotation>PASCAL VOC2007</annotation>
    <image>flickr</image>
  </source>
  <size> # 图像尺寸信息
    <width>500</width> # 图像宽度
    <height>281</height> # 图像高度
    <depth>3</depth> # 图像深度, 也就是通道数
  </size>
  <segmented>1</segmented> # 图像是否用于分割, 对目标检测而言没关系
  <object> # 一个目标对象的信息
    <name>aeroplane</name> # 目标的类别名
    <pose>Frontal</pose> # 拍摄角度, 自己的数据集这里是Unspecified
    <truncated>0</truncated> # 是否被截断, 0表示完整未截断
    <difficult>0</difficult> # 是否难以识别, 0表示不难识别
    <bndbox> # 边界框信息
      <xmin>104</xmin> # 左上角x
      <ymin>78</ymin> # 左上角y
      <xmax>375</xmax> # 右下角x
      <ymax>183</ymax> # 右下角y
    </bndbox>
  </object>
  # 下面是其他目标的信息, 这里略掉
  <object>
    其他object信息, 这里省略
  </object>
</annotation>
```

图 3-3 VOC 格式文件详细内容

VOC 格式数据集转化为 YOLO 格式数据集, 采用 Yolov3 存放数据集的文件, 将包含 VOC 数据集的文件直接复制到 YOLOv5 的根目录下, 对 VOC 转换 YOLO 的原理进行代码的编写, 在 YOLOv5 项目中运行代码, 就可以直接将 VOC 格式数据集转为 YOLO 格式数据集, 代码会自动的分出训练集, 验证集, 分配比例可自定义设置。文件 VOCdevkit 中包含数据内容如图 3-4 所示。




图 3-4 文件 VOCdevkit 中包含的数据内容

由 VOC 转换为 YOLO 格式文件的详细内容如图 3-5，文件中主要包括目标名称标签、标注框中心坐标、标注框的宽和高（数值全部为归一化的）。YOLO 格式标签：目标名称标签，标注框的中心坐标（数值全部为归一化）。

2007_000032.txt - 记事本

文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)

```
11 0.34419263456090654 0.611 0.4164305949008499 0.262
14 0.509915014164306 0.51 0.9745042492917847 0.972
```

图 3-5 YOLO 格式文件的详细内容

新转换的 yolo 数据集如图 3-6 所示。即通过归一化实现将 VOC 格式的训练数据集转换为 YOLO 格式的训练数据集。




图 3-6 新转换得到的 YOLO 数据集

3.3 YOLOv5 目标检测算法分析

图 3-7 揭示了 YOLOv5 的网络架构细节。该模型主要分为四个关键部分：输入层、基础特征提取层、多尺寸特征合并层以及检测层^[64]。YOLOv5 的检测过程如下：图像在输入阶段进入模型后，核心网络 CSP-Darknet53 通过连续的卷积和池化操作，实现对目标对象的特征捕捉。接着，特征图经过三个不同尺寸的输出，分别为 80×80 、 40×40 、 20×20 ，这些特征图被送入 PANet 模块进行多尺度特征整合。该模块通过深度特征与浅层特征的相互融合，强化了目标的识别特征。最终，检测模块在特征整合后的输出图上，对目标的位置和类别进行预测。




图 3-7 YOLOv5 网络结构

3.3.1 输入层

a. 数据增强

Mosaic 数据扩充技术是一种随机性数据增强手段，旨在提升训练资料集的多样化与丰富度。它主要通过对四幅各异的图片施加随机变换，调整它们的尺寸与外形，确保彼此之间差异显著，再把它们拼合形成一幅全新图像，这种方式将不同图像的信息集成在一起，有效提升了模型对多样化场景和物体搭配的认识能力，进而增强了其泛化能力。通过将来自不同传感器、不同视角或不同时间段的图像数据进行融合，模型可以获取更丰富和全面的信息，从而提高对复杂场景和多样物体的识别能力。**Mosaic** 数据扩充的具体步骤见图 3-8。




图 3-8 Mosaic 数据扩充流程图

b. 锚框

YOLOv5 采用基于锚点的方法，在训练时并不直接预测实际边框的具体位置，而是

估计与先验锚框之间的偏移。这要求设定一组初始的锚框。YOLOv5 通过自动化调整获取适宜的锚框尺寸以匹配数据集，并利用预测的偏移更新网络参数以优化模型性能。正确设置锚框对保证网络训练的准确度至关重要。所以，在不同的数据集上，选择合适的锚框尺寸和比例至关重要。选择 COCO 数据集作为实验数据集，在 YOLOv5 中进行训练，其初始锚框大小详情见表 3-1。

表 3-1 YOLOv5 初始的锚框大小

特征图大小	先验框尺寸		
80×80	[116,90]	[156,198]	[373,326]
40×40	[30,61]	[62,45]	[59,119]
20×20	[10,13]	[16,30]	[33,23]

3.3.2 SPP 模块

在确定区域和辨识目标时，周围信息的考虑对选择定位区域和确认目标至关重要。YOLOv4 通过引入 SPP 模块，利用不同大小的感受野（ 5×5 、 9×9 、 13×13 ）和一个跳连分支来扩展特征图的感受野，增强了对深层特征图上下文信息的捕获。这一改进有效提升了模型的性能。不过，SPP 模块的大核卷积和并行结构增加了参数量并减缓了训练速度。为改善这一问题，YOLOv5 引进了 SPPF 模块，通过串联三种最大池化操作模拟不同感受野，达到了与 SPP 相似的检测效果，同时计算速度提升了两倍以上。这意味着通过采用 SPPF 模块，可以在保持检测性能的同时提升模型的计算效率和实时性。这种改进使得 YOLOv5 在目标检测任务中具备更好的性能和效率。因此，在选择适当的特征提取模块时，需要权衡性能与计算速度之间的关系，并根据具体应用需求来进行选择和优化。SPP 模块和 SPPF 模块的结构如图 3-9 所示。




图 3-9 SPP 与 SPPF 结构对比

3.3.3 非极大值抑制

检测模块的主要任务是生成携带类别信息及置信度评分的众多预测框，对单个目标往往会产生多个预测结果，但对于该目标只需输出最优的单个预测框。面对这种情况，YOLOv5 采用了 NMS 算法来保证对每个目标只生成一个最终的检测框。操作过程如下：

图像中形成诸多预选检测框，为这些框各自评估置信度后，依据得分进行排名，选择评分最高者作为参考框。

以此参考框为基点，评估其他所有检测框与之的交集情况。若交集区域超过既定阈值，则将相关框排除在候选名单之外。

原始检测结果从所有候选框中挑出得分顶尖者，接着通过执行非极大值抑制 (Non-maximum Suppression, NMS) 算法进行迭代筛选，直至筛选结束。NMS 的原理表达如公式(3-4)。

$$S_i = \begin{cases} S_i, & IoU(M, b_i) < \varepsilon \\ 0, & IoU(M, b_i) \geq \varepsilon \end{cases} \quad (3-4)$$

对于每个检测框，通过 S_i 来标识其置信度得分， M 代表得分最高的检测框，而 b_i 表示其他待评估的检测框。设定阈值 ε 为设定的 IoU 阈值， $IoU(M, b_i)$ 为最高分框 M 与剩余框 b_i 的交并比。若计算结果小于阈值，则保留预测框，否则将删除 b_i 框并将其分数清零。

对于每个检测框，通过 S_i 来标识其置信度得分， M 代表得分最高的检测框，而 b_i 表示其他待评估的检测框。设定阈值 ε 作为判定标准， $IoU(M, b_i)$ 代表最高得分框 M 与其他框 b_i 的交并比。如果 IoU 计算值小于阈值 ε ；反之，移除 b_i 框并将其得分设为零。

3.4 实验及结果分析

由于其他约束限制，大量钻杆螺纹缺陷样本获取较为困难，所以为了处理本文中的小样本数据集，选择基于权重的迁移学习来训练螺纹裂纹缺陷算法，以利用已有优质模型对自身数据进行微调，实现对小样本的高精度检测。在实验训练阶段，软件环境选择了 64 位 Windows10 系统，CPU 选择了 Intel(R) Core(TM) i5-10400F，在 Anaconda3、PyCharm2021 进行开发，编程语言为 Python3.9，并使用 YOLOv5 框架进行钻杆螺纹缺陷检测模型的训练和预测。

门限值(Confidence)是在将模型预测的概率转换为分类结果时使用的一个阈值，当模型对一个样本的预测概率高于门限值时，将其划分为正类别，否则划分为负类别。当门限值为 0.5 时，表示模型预测的概率高于 0.5 的样本将被划分为正类别，低于 0.5 的样本将被划分为负类别。因此，Recal 和 Precision 的计算将基于这一分类结果进行。精确率和召回率关系图如图 3-10(a)所示，F1 分数曲线图如图 3-10(b)所示，单一类准确率曲线图如图 3-10(c)所示，单一类召回率曲线图如图 3-10(d)所示。




图 3-10 模型曲线图

PR 曲线显示了在不同分类阈值下模型的精确度和召回率的关系，PR 曲线越靠近坐标轴的左上角，模型性能越好，越能够正确识别正样本，正确分类正样本的 Precision 值越高，而靠近右侧则说明模型对正样本的识别能力较差，即召回能力较差。由图 3-10(a) 可知，本模型性能相对较好。

F1 分数综合考虑了模型的精确度和召回率，提供了一个衡量模型性能的唯一指标。由图 3-10(b) 可知，模型对裂纹缺陷的识别较好。

置信度阈值-准确率曲线图表示判定概率超过置信度阈值时，各个类别识别的准确率。随着置信度的增加，各类别的识别准确率也随之提高。然而，随着置信度的提高，可能会错过一些概率较低但是真实的样本。由图 3-10(c) 可知，随着置信度的越来越高检测的准确率按理来说是越来越高的。

置信度阈值-召回率曲线图，当置信度越小的时候，类别检测更为全面，不易遗漏但容易出现检测错误。由图 3-10(d) 可知，随着置信度的越来越高召回率的准确率是越来越低的。

实验结果如下表 3-2。下表中的指标 AP、AP₅₀ 和 AP₇₅ 分别表示在不同的 IoU 阈值下的平均精确率。它们是评估目标检测算法性能的重要指标之一。具体来说，AP 表示在 0.5 到 0.95 范围内的 IoU 阈值下计算得到的平均精确率。这意味着在不同的 IoU 阈值

下，算法能够准确地检测出目标的能力。 AP_{50} 表示在 IoU 阈值为 0.5 时的精确率，而 AP_{75} 则表示在 IoU 阈值为 0.75 时的精确率。这两个指标可以提供更精细的评估，分别反映了在较宽松和较严格的 IoU 阈值下的性能表现。通过按照每隔 0.05 进行一次计算，以获得平均的 mAP 值。而 Recall 和 Precision 分别代表了当 score_threshold 为 0.5 时对应的召回率和精确率数值。

表 3-2 YOLOv5s 测试结果

Algorithm	Backbone	Recall	Precision	AP	AP_{50}	AP_{75}	Speed(FPS)
YOLOv5s	CSPDrknet-53	23.5	75.0	23.4	69.3	15.4	93.6

YOLOv5 在数据集中检测出的部分缺陷如图 3-11 所示。




图 3-11 YOLOv5 在数据集中检测出的部分缺陷

由图 3-11 可知，YOLOv5 模型对于裂纹缺陷测试集中的照片检测效果较好，成功对 31 张裂纹照片进行了检测，检测成功率达到 72%。

作为实验对照组，将相同数据集在另一种较为常用的模型 YOLOv8s 上进行测试训练，得到的测试结果如表 3-3 所示。

表 3-3 YOLOv8s 测试结果

Algorithm	Backbone	Recall	Precision	AP	AP ₅₀	AP ₇₅	Speed(FPS)
YOLOv8s	CSPDrknet-53	11.8	21.4	13.2	34.4	7.6	89.8

Yolov8 能检测的所有结果如图 3-12 所示。




图 3-12 YOLOv8s 在数据集中的的所有检测结果

由图 3-12 可知，YOLOv8 模型对于裂纹缺陷较模糊的照片检测效果较好，但对于特征明显的裂缝照片检测效果很差，只能检测出测试集中 37.2% 的裂纹缺陷，即在测试过程中存在漏检和误检的问题。

由以上结果表明，在检测明显的钻杆螺纹裂缝方面，YOLOv5 表现出较高的检测准确性，检测成功率达到 72%。相对地，YOLOv8s 在检测模糊的缺陷方面效果更优，但对于明显裂缝的辨识能力不如 YOLOv5，检测成功率仅有 26%。从整体上来看，YOLOv8s 和 YOLOv5 模型框架基本一致，都是 backbone+PANet+Head 的结构，且 PANet 部分都是先上采样融合再下采样融合。YOLOv8 的 Backbone 和 Neck 中采用的 C2f 结构用于替换 YOLOv5 中的 CSP 结构，C2f 结构有着更多的残差连接，所以其有着更丰富的梯度流。但 C2f 模块中存在 Split 操作，对特定硬件部署并不友好，导致 YOLOv8s 的检测效率不高。

为评估改进算法在目标检测任务中的表现，本研究选用了平均精度均值（MAP）、每秒处理帧数（FPS）、模型参数规模和浮点运算次数（FLOPs）作为衡量标准。其中，MAP 是所有类别的精度均值（AP）的均值，主要用来衡量模型的预测准确性，即检测的准确度。同时，在对模型进行综合评价时，除了考虑检测的准确性，还需关注模型的检测速率。检测速率指的是模型处理单个输入所需的时间，这一指标对于需要实时处理的应用场景非常关键，通常通过 FPS 来表示，FPS 值越高，表明模型的实时处理能力越强。

为更加准确的验证 YOLOv5 在钻杆螺纹缺陷检测上的有效性，本文将采取部分主流检测算法在相同的数据集中进行对比实验，以更加有力地分析 YOLOv5 模型的检测性能。本文选取的主流算法在数据集中的检测速度与模型参数量对比如表 3-4 所示，模型通过增强残差结构的数目，可以显著提升其在特征抽取与特征融合方面的能力，进而有效提高模型的检测精度及召回效率。然而，伴随着网络深度和宽度的持续扩增，模型的参数数量同样在上升，导致其检测速率逐步下降。

表 3-4 部分主流算法的检测速度与参数量对比

Algorithm	Backbone	Parameters(M)	Speed(FPS)
YOLOv5s	CSPDarknet-53	7.03	93.6
YOLOv8s	CSPDarknet-53	11.1	89.8
YOLOX-tiny	CSPDarknet-53	5.1	61.0
YOLOv7-tiny	Darknet	6.0	68.6
SSD	Mobilenetv2	3.9	76.8
Faster R-CNN	Resnet50	136.8	11.5

如表 3-5 所示，YOLOv5 模型在钻杆螺纹缺陷数据集中训练测试，在 IOU 阈值为 50%

到 95%范围内能够获取 23.4%的平均精确率，在阈值为 50%时能够获取 69.3%平均精确率，在阈值为 75%能够获取 15.4%平均精确率。与本文所选取的部分检测算法对比而言，YOLOX-tiny 在 IoU 阈值为 0.5 到 0.95 范围内平均精确率值最大为 29.1%，在阈值为 75%时平均精确率数值最大为 23.9%。由表 3-4 和 3-5 综合对比可得，YOLOv5 模型在阈值为 50%时平均精确率最高，阈值为 50%到 95%范围内和 75%时，平均精确率分别只低于 YOLOX-tiny 算法 5.7%和 8.5%，说明 YOLOv5 对钻杆螺纹裂纹定位效果较好，且 YOLOv5 的检测速度在对比算法中 fastest，验证了 YOLOv5 更适用于钻杆螺纹的裂纹缺陷检测。

表 3-5 不同算法在扩充数据集上的性能对比

Algorithm	Backbone	Recall	Precision	AP	AP ₅₀	AP ₇₅	mAP@0.5
YOLOv5s	CSPDarknet-53	23.5	75.0	23.4	69.3	15.4	67.7
YOLOv8s	CSPDarknet-53	11.8	21.4	13.2	34.4	7.6	35.3
YOLOX-tiny	CSPDarknet-53	9.8	55.5	29.1	64.1	23.9	70.7
YOLOv7-tiny	Darknet	3.9	8.3	6.0	23.5	-	24.8
SSD	mobilenetv2	23.5	100	21.5	67.5	5.9	61.5
Faster R-CNN	resnet50	80.4	27.0	18.7	55.6	5.3	59.8

3.5 本章小结

本章针对钻杆螺纹裂纹缺陷数据集不足的问题，通过切片，翻转，加入噪声等方法对已建立的数据集进行了扩充。基于 YOLOv5 搭建了钻杆螺纹裂纹缺陷检测模型，通过实验分析了 YOLOv5 在螺纹裂纹缺陷检测方面的性能与检测效果。通过对比 YOLOv5 与 YOLOv8s 的实验，研究分析了基于 YOLOv5 的钻杆螺纹裂纹缺陷检测的优点，并选取部分主流检测算法在相同的数据集中进行对比实验。实验结果证明，本文所采用的 YOLOv5 模型在自建螺纹裂纹数据集中当阈值为 50%到 95%范围内和 75%时，获取的平均检测率仅低于 YOLOX-tiny 算法 5.7%和 8.5%；在阈值为 50%时，平均检测率最高为 69.3%，且模型检测速度相较于其他模型最快，证明了 YOLOv5 在钻杆螺纹的裂纹缺陷检测的有效性，后续工程应用和算法优化提供了理论指导。

第四章 基于双目法的钻杆螺纹三维成像系统设计

4.1 引言

第三章中采用二维图像数据研究了钻杆螺纹缺陷检测方法，实验结果表明，该方法能够较好的检测到裂纹缺陷，估算出裂纹的数量、长度、宽度等参数，但是无法获取螺纹及缺陷的深度信息，而缺陷的深度是影响钻杆螺纹井下作业失效的重要因素。为了更好地、立体地检测螺纹缺陷，需要研究螺纹三维成像技术，在立体空间角度下呈现螺纹的结构能够清晰地展示螺纹的曲率、线深度、间距等详细参数。通过三维成像，并为后续的缺陷检测与评估提供立体的测量数据。

针对二维图像缺少深度信息的问题，本章旨在设计一种基于双目法的钻杆螺纹三维成像系统，能够将钻杆螺纹缺陷信息三维化，以便于后期的缺陷识别和研究。

4.2 基于双目法的三维成像方法研究及系统设计

4.2.1 基于 FPGA 的双目视觉系统整体设计

本节介绍了基于 FPGA 的双目视觉系统整体框架设计，如图 4-1 所示，系统分为时钟模块、图像分辨率设置模块、DDR 控制器模块、摄像头驱动模块和 HDMI 顶层模块。




图 4-1 整体系统设计

本设计中 OV5640 的像素时钟频率为 48MHz，而 HDMI 显示根据屏的分辨率不同时钟也不同，时钟和时序方面的均不匹配，HDMI 驱动对时序有着严格的要求。HDMI 的时序参数与 OV5640 并不是完全一致的。因此必须先把一帧图像缓存下来，然后再把

图像数据按照 HDMI 的时序发送到 HDMI 屏上显示。

本设计采用 OV5640 支持的最大分辨率 2592*1944, 摄像头的输入时钟为 24MHz, 摄像头的输出时钟为 48MHz, 摄像头输出的分辨率由外接的 RGB-LCD 屏幕分辨率决定, 使用 OV5640 的缩放处理, 本次实验使用的 RGB-LCD 屏幕分辨率为 800*480, 根据此可推导摄像头的帧率, 以 PCLK=48MHz (周期为 21ns) 为例, 计算 OV5640 输出一幅图像所需的时间如下:

一帧图像输出时间: $t_{\text{Frame}}=1800 \times 1000$ (行长 HTS 与帧长 VTS 根据实际经验得出) $\times 21\text{ns}=37800000\text{ns}=37.8\text{ms}$; 摄像头输出帧率: $1000\text{ms}/37.8\text{ms} \approx 26\text{Hz}$ 。

OV5640 根据本设计使用的 HDMI 屏幕分辨率输出对应的分辨率的 RGB565 格式数据, 一帧图像的数据量达到 $800 \times 480 \times 16\text{bit}=6114000\text{bit}=6000\text{kbit}=5.859375\text{Mbit}$ (1k=1024), 带宽 (每一秒的数据量) 为 $5.859375\text{Mbit} \times 26\text{Hz}$ (帧率) $=152.34375\text{Mbit/S}$, 达芬奇 Pro 开发板芯片型号为 xc7a35tfgg484/xc7a100tfgg484/xc7a200tfgg484 三种, 从 Xilinx 提供的 7 Series 器件手册中可知, xc7a35t 的片内存储资源为 1800Kbit, 芯片不能达到存储要求; xc7a100t 的片内存储资源为 4860Kbit, xc7a200t 的片内存储资源为 13140Kbit, 两个芯片能达到存储要求但是芯片的片内存储资源有限, 所以将大数据的存储存放在片外存储器。因此本设计使用板载的外部存储器 DDR3 来缓存图像数据, 达芬奇 Pro 板载的 2 片 DDR3 容量为 4096Mbit (1 块 ddr3 的容量为 2048Mbit), 2 块 ddr3 带宽为 25.6Gbit/S (实验使用 DDR3 的位宽为 16bit, DDR3 工作时钟频率为 400MHz, 时钟双沿采样, 带宽为: $2 \times 400\text{MHz} \times 2 \times 16\text{bit}=2 \times 800\text{MHz} \times 16\text{bit}=25.6\text{Gbit/S}$), 足以满足缓存图像数据的需求。

为了确保 OV5640 正常工作, 必须先通过配置寄存器进行初始化。由于配置寄存器使用 SCCB 协议和 I2C 协议进行写操作时几乎一样, 因此需要一个 I2C 驱动模块。为了使 OV5640 能够按照期望的模式运行并提高图像显示效果, 需要对许多寄存器进行配置。这些寄存器的地址和参数需要单独存放在一个模块中, 因此还需要一个用于寄存器配置信息的 I2C 配置模块。在摄像头配置完成后, 开始输出图像数据, 因此需要一个摄像头图像采集模块来采集图像; 外接 DDR3 存储器当然离不开 DDR3 控制器模块的支持, 最后 HDMI 顶层模块读取 DDR3 缓存的数据以达到最终实时显示的效果。

本研究所采用的双目图像采集系统采用了 Xilinx Artix-7 XC7A35T 开发板, 如图 4-2 所示。双目相机模组选用了两个 1/4 英寸 CMOS 图像传感器 OV5640 作为关键组件。摄像头的初始化配置通过串行摄像机控制总线 (SCCB) 来实现, 并且显示器采用 HDMI 接口连接。




图 4-2 系统开发板实物图

Artix-7 XC7A35T 开发板主要硬件配置如表 4-1 所示。

表 4-1 Artix-7 XC7A35T 开发板主要硬件配置

名称	参数
逻辑单元	33000片逻辑片
Block RAM	1.8Mbit存储资源
TF 卡	TF 卡插槽
电源	USB 供电或6-16V直流电源
晶振	50Mhz有源晶振
DDR3	型号为NT5CC128M16IP-DI，每片2Gbit，总容量为4Gbit
显示	两路 HDMI 接口(一路输入，一路输出)
以太网	一路千兆以太网PHY 芯片YT8511

4.3 双目立体图像采集实现

达芬奇 Pro 开发板上有两个扩展口，分别是 J3 和 J4。达芬奇 Pro 核心板有 3 个版本，分别是 35t、100t 和 200t 芯片，而 J4 扩展口只有在 100t/200t 芯片的时候才能用，故本设计采用 J3 扩展口来连接双目 OV5640 摄像头。

4.3.1 OV5640 传感器及其配置

本设计所采用两个 OV5640 CMOS 图像传感器以左右并行的方式连接在一起，以实现高速并行传输图像数据的功能。为了实现摄像头模组与开发板之间的连接，使用了杜邦线连接它们的扩展口。通过这样的设计，可以实现双目摄像头的独立工作，并将其图像数据传输给 FPGA 进行进一步的处理和分析。双目摄像模组的管脚布局见图 4-3。




图 4-3 双目 OV5640 摄像头模块引脚示意图

连接该模块与外部的方式是通过 2*20 排针（间距为 2.54 毫米），将双目摄像头模块的排针直接插入开发板上的 J3 扩展接口即可。可参考 4-4 图示来实际连接模块。




图 4-4 双目摄像头模块实物连接图

OV5640 图像传感器是双目图像采集系统的输入元件，通过使用背照式技术，图像传感器可以在相同感光面积下获得更高的光感度，使其具备更好的低光拍摄性能。同时，背照式技术还可降低图像的噪音水平，提供更清晰、细节更丰富的图像。该传感器具备轻盈的尺寸和广阔的工作温度区间（30 至 70 度摄氏）。图像传输通过与 FPGA 相连的数字视频端口（DVP）接口完成，其接口框图如图 4-5。




图 4-5 DVP 接口传输示意图

OV5640 传感器的视频输出接口 DATA[9:0]是一个 10 位宽的接口，用于传输图像数据。摄像头模组通信信号如表 4-2 所示。

表 4-2 图像传感器通讯信号

引脚	作用描述	引脚	作用描述
VCC3.3	接3.3V电源给传感器供电	XCLK	传感器驱动时钟输入
PCLK	像素时钟输出	PWDN	掉电使能(高有效)
SCL	SCCB通信时钟信号	VSYNC	帧同步信号输出
SDA	SCCB通信数据信号	HREF	行同步信号输出
DATA[9:0]	10bit数据格式输出	RESET	传感器复位输入(低有效)

在对 OV5640 摄像头进行正确的上电序列后，可以通过设置其内部寄存器来进行配置。OV5640 的配置是通过 SCCB（Serial Camera Control Bus）接口实现的，该总线有两条线路：a.SIO_C（SCL，时钟信号线）：由主设备控制的时钟信号线，用于同步数据传输。b.SIO_D（数据线）：用于传输配置数据的数据线。通过 SCCB 接口，主设备可以向 OV5640 传感器发送命令和配置数据，从而对其内部寄存器进行设置。SCCB 接口使用起来相对简单，只需要通过时钟信号线和数据线进行数据的读取和写入操作即可完成配置。

在实现基于 Artix-7 开发板的双目视觉系统时，为了确保左右相机图像数据的同步对齐，通常需要对相机进行同步操作。这项任务可以通过在程序逻辑（PL）端生成配置信号来克服，从而实现两个摄像头的并行初始化。具体方法是在 PL 中实例化两套独立的配置逻辑，利用共享的时钟信号来触发同时配置双目相机。通过这种方式，可以最小化左右相机初始化完成时间的差异。此外，在两个摄像头初始化完成后，额外等待一定的帧数（如 10 帧），有助于确保所采集到的图像数据已经稳定且可靠。只有在相机的输出数据完全同步后，后续进行立体匹配和视差图计算才能获得高精度的结果。

在同步配置后，为克服帧同步后的像素级异步问题，采用异步 FIFO 作为数据缓冲策略。此类 FIFO 结构特别适合跨时钟域数据通信，因其独立的读写时钟控制功能。具体实现当中，相机的 PCLK 信号负责推动图像数据进入 FIFO，而 FPGA 设计的内部时钟则管理数据读出。相较于 RAM 和 ROM，FIFO 不需外部地址线即可完成数据存取，遵循数据先入先出的处理顺序，简化了数据流管理。利用异步 FIFO 机制，便能安全地在两个非同步时钟域间传输像素数据，确保处理过程中像素点的时序一致性。

在 Vivado 工具环境下，可直接利用提供的 FIFO 生成器 IP 核构建基于块 RAM 的异步 FIFO 结构。鉴于 RGB565 格式每隔一个像素周期输出一个数据点，因此配置异步 FIFO 的数据宽度：输入为 9 位，输出为 18 位，同时设定深度为 8192 位置。此外，在写入像素数据时并行地将垂直同步（VSYNC）和水平同步（HSYNC）信号进行捆绑，每经过两个像素时钟周期（PCLK）完成一帧数据的写入操作，FIFO 的数据打包和结构格式如图 4-6。




图 4-6 FIFO 的数据打包格式

在数据读取环节，异步 FIFO 的输出宽度配置为 18 位，以便每个时钟周期同时提取出 16 位的 RGB565 像素信息及其关联的同步信号。这保障了图像数据与各自的垂直（VSYNC）和水平（HSYNC）同步信号保持一致性。出于输出宽度是输入宽度两倍的考虑，即使 FIFO 深度相对较小，亦足以避免因数据积压而导致的溢出问题。由于双摄像头经过精准的初始化程序同步，其产生的像素数据相位差已微乎其微，仅需存储数行数据便能实现完全同步。通过应用 Vivado 工具中集成的集成逻辑分析仪（ILA），可以观察到两个摄像头的像素数据流及其同步信号在时序上实现了同步，从而验证了数据传输和处理机制的正确性与效率。左右摄像机采集到的图像信号同步前与同步后仿真波形如图 4-7 和 4-8 所示。




图 4-7 同步前左右摄像机采集到的图像信号仿真图




图 4-8 同步后左右摄像机采集到的图像信号仿真图

4.3.2 OV5640 驱动模块

根据上述分析可知，OV5640 驱动模块负责驱动 OV5640 SCCB 接口总线，通过采集像素时钟驱动的传感器产生的场同步信号、行同步信号及 8 位数据，对数据进行处理后，可以转化为 DDR 读写控制模块所需的写使能信号和 16 位的写数据信号。此过程主要用于捕捉和保存 OV5640 传感器的图像数据。在这个过程中，场同步信号和行同步信号用于确定图像的边界和位置，而 8 位数据则包含了图像的像素信息。通过将这些信号和数据按照一定的规则组合和转换，最终可以得到符合 DDR 读写控制模块规范的写使能和数据信号，从而实现了 OV5640 传感器获取的图像数据有效地写入 DDR 存储器中，以便后续的处理和使用。图像分辨率模块框图 4-9。




图 4-9 图像分辨率设置模块框图

OV5640 驱动模块主要完成对 I2C 驱动模块(i2c_dri)、i2c 配置模块(i2c_ov5640_rgb565_cfg)、摄像头图像采集模块(cmos_capture_data)的例化。

I2C 驱动模块(i2c_dri)是一个用于控制 OV5640 相机模块的 SCCB（串行摄像机控制

总线) 驱动程序, 为了对 OV5640 相机内部寄存器进行调整和管理提供了接口。用户可以通过这个模块来调整相机的操作和设置, 如曝光时间、对焦模式、白平衡等。通过读取和写入寄存器中的值, 可以实现对相机功能的灵活控制。这个驱动模块简化了与 OV5640 相机之间的通信过程, 使得用户可以更加方便地进行相机的配置和控制, 提高了开发效率。I2C 驱动模块框架如图 4-10。




图 4-10 I2C 驱动模块模块框图

I2C 配置单元 (i2c_ov5640_rgb565_cfg) 的参数设定如下: 当 I2C 驱动单元提供时钟信号时, 该模块负责推动数据互通以实现与 I2C 配置模块的通信。用户可以通过配置寄存器地址、数据以及起始和停止指令来初始化 OV5640 相机。这些配置信息会通过用户接口传递给 I2C 驱动模块, 触发其执行任务的控制信号。通过这种方式, OV5640 图像传感器可以完成初始化工作。

摄像头驱动模块软件设计流程图如图 4-11 所示。编写摄像头控制代码, 通过 I2C 等接口发送配置命令, 接收数据通过 LVDS 或其他高速接口。上电后初始化摄像头, 配置基本工作模式 (分辨率、帧率等), 控制摄像头开始图像采集, 并将其发送到 DDR3 模块或直接到 HDMI 显示模块。




图 4-11 摄像头驱动模块程序流程图

在图像采集单元中，通过像素时钟激活，将传感器输出的场同步、行同步信号和 8 位图像数据转换成 DDR 读写控制模块所需的写使能信号和 16 位写数据信号，完成对 OV5640 图像传感器数据的采集过程。图 4-12 展示的是 OV5640 摄像头驱动单元的仿真波形图。从该图中可以观察到，在摄像头参数配置结束后，已经顺利获取了来自摄像头的图像输出数据，这一结果表明所设计的驱动模块运作正常，达到了预期的设计目标。




图 4-12 OV5640 驱动模块仿真图

OV5640 驱动模块资源利用率如表 4-3 所示。

表 4-3 DDR 模块资源利用率

Resource	Utilization	Available	Utilization%
Slice LUTs	423	20800	2.03
Slice Registers	264	41600	0.63
F7 muxes	52	16300	0.32
F8 muxes	2	8150	0.02

4.3.3 图像采集实现

CMOS 图像传感器的数据输出可以采用不同格式，常见的包括：RAW、RGB、YUV 和 JPEG。在各种图像格式中，RAW 代表原始图像数据，未经模数转换，每个像素点通常由 8 位数据组成。而 RGB 格式指的是红绿蓝三色构成的图像，适用于基于液晶技术的显示器，能够直接显示，无需转化。针对 OV5640 传感器输出的视频流，本文将 其设置为 RGB565 格式，如图 4-13 展示。RGB565 格式使用 16 位数据表示单个像素点颜色值，但由于 OV5640 每个像素周期仅输出 8 位数据，故完整输出一个像素点的 RGB565 数据需用两个时钟周期。




图 4-13 OV5640 输出 RGB565 格式图

图像采集模块通过像素时钟驱动，从 OV5640 传感器获取输出数据，并确保行和帧信号同步。它将连续两次输入的 8 位数据组合成 16 位 RGB565 格式，并通过在各颜色通道低位补零的方式将其扩展为 24 位 RGB888 格式，完成图像数据采集。配置 OV5640 传感器寄存器后，等待约 10 帧时间以确保配置生效。使用垂直同步信号 VSYNC 下降沿的计数实现延迟，达到所需帧数后，特定标志位信号变化表明图像数据准备就绪。这一系列操作确保了图像数据的稳定采集和写入过程。如图 4-14，即摄像头图像数据采集模块框架图。




图 4-14 摄像头数据采集模块

如图 4-15 即为图像采集模块的仿真图，相机输入的数据 cam_data 经过像素时钟 PCLK 的上升沿触发，每两个 8 位数据在像素时钟上升沿拼接成 16 位数据。然后，在颜色分量的低位填充零，将 16 位数据扩展为 24 位数据。最终，扩展后的 24 位 RGB 数据被输出。




图 4-15 摄像头数据采集模块波形图

从上图可以看出（根据 OV5640 帧时序图，摄像头输出时钟下降沿更新数据和行场信号），等待了一段时间才开始采集数据，是因为需要等待数据稳定。并且摄像头输出的 RGB565 格式数据（输出数据位宽为 8），分为两次输出，所以需要每两个数据进行位宽转换，同时为了和数据同步，对行场信号打两拍后输出。

4.3.4 时钟控制模块实现

FIFO 管理单元的功能是在特定时钟域中实现输入与输出数据流的调度，并执行数据位宽的适配转换。模块框图如图 4-16。为了实现乒乓缓存的功能，在 fifo 控制的端口信号添加了 wr_load 和 rd_load，用于对读写 fifo 进行复位。在程序设计时，为了便于后续生成复位电平信号，需要对 HDMI 输入源的场信号进行移位寄存。




图 4-16 FIFO 控制模块框图

时钟模块功能图如图 4-17 所示。时钟模块通过配置时钟管理单元（PLL 或 MMCM）

生成其他模块所需的工作时钟，如为摄像头驱动模块设定主时钟频率为 24MHz，为 HDMI 接口提供 74.25MHz 的时钟频率，为 DDR3 模块提供 200MHz 的参考时钟频率（驱动时钟由由 MIG IP 核提供），并将生成的时钟分配至各模块。




图 4-17 时钟模块功能图

FIFO 读写状态仿真波形图如图 4-18 和 4-19 所示。在帧结束时进行复位操作的目的是为了确保 FIFO（先进先出队列）在下一帧数据接收前被清空，保障数据处理的连续性和准确性。




图 4-18 FIFO 写状态仿真波形图




图 4-19 FIFO 读状态仿真波形图

4.3.5 DDR3 控制模块

本设计是两个摄像头采集数据并且把数据存入两个写 FIFO，两个写 FIFO 再将数据写入 DDR3 的两个不同的存储空间中，接着两个读 FIFO 分别从两个对应的 DDR3 地址空间中取出数据，最后两组数据一起拼接为完整一帧 LCD 图像，达到一个屏幕同时显示两幅图像的效果。在 DDR3 处理数据的时候，两组数据流相当于过独木桥，需要分时“排队”进出；同样在显示端，两组数据也要“排队”显示，所以本次实验的 FIFO 顶层调度模块的作用就是根据不同的情况对两个 FIFO 调度模块的信号进行切换。DDR3 控制模块框图如图 4-20。




图 4-20 DDR3 控制模块框图

DDR 读写模块：DDR 读写模块在 MIG 模块和 FIFO 顶层调度模块之间起着桥梁的作用，通过处理命令和地址的交互，实现了对 DDR3 内存的高效读写操作。此单元的核心任务是依据 FIFO 控制器顶层各个 FIFO 中的剩余数据量，来切换 DDR3 存储器的读写操作及其对应地址。为了使得两个摄像头的图像数据在 DDR3 的存储中互不影响同时方便调度，本设计开辟了四个存储空间。两幅影像通过两个摄像头分别采集，因此需要将影像分别存入两个 wfifo 中。只要有一个 wfifo 中的数据量超过本次实验设定的阈值，DDR 读写模块就会发送读数据请求信号，将 fifo 中的数据写入 DDR3，以确保 wfifo 不会溢出。只要有一个 rfifo 中的数据量低于本次实验设定的阈值，DDR 读写模块就会向对应的 rfifo 写入数据，确保 rfifo 不会空缺。DDR3 中有四个存储空间，每个输入源使用两个存储空间，一个用于实现输入源的交替操作以防止图像撕裂，另一个用于确保两个输入源的数据不会相互干扰。DDR 读写控制流程如图 4-21 所示。




图 4-21 DDR 读写控制流程图

DDR3 控制模块程序流程图如图 4-22 所示。使用 Artix-7 板外部的 DDR3 存储器，设计一个高效的存储控制器，用于管理数据读写操作，确保数据带宽和访问速率满足总系统的要求。通过 MIG 工具配置内存控制器，初始化 DDR3 内存，并进行自检。设计数据传输接口以支持高效的读写操作，供其他模块调用进行数据存取。




图 4-22 DDR3 控制模块程序流程图

本设计中读状态不是直接转换到 DDR 的空闲状态，而是转换到读取等待状态。从时序图 4-23 中可以观察到，当读取状态操作完成时，数据尚未完全读取。若在数据读取过程中直接切换至 DDR 的空闲模式，那么接下来可能会进入另一次读操作。这种情况下，来自 DDR3 的数据很难归属于特定的读取 FIFO (rfifo)，易引起信息错乱。为确保各条数据精准地流入相应的 rfifo，必须在数据完全传输结束后，才能进行到 DDR 的空闲状态转换。这样做可以避免数据处理时出现混淆。




图 4-23 DDR3 读写模块仿真图

DDR 模块资源利用率如表 4-4 所示。

表 4-4 DDR 模块资源利用率

Resource	Utilization	Available	Utilization%
Slice LUTs	7711	20800	37.07
Slice Registers	8202	41600	19.7
F7 muxes	67	16300	0.41
F8 muxes	0	8150	0.00

4.3.6 HDMI 顶层模块

系统所选显示器采用了 HDMI 接口。HDMI 标准与 DVI 兼容，而 DVI 仅支持视频信号的传递，不具备音频传输能力。鉴于本系统设计目标仅限于图像数据的传输，无涉及音频部分，故采用 DVI 接口协议进行驱动逻辑的实施。

在编码过程中，对编码器进行设计，要求其首先对视频源的像素数据、HDMI 额外数据，以及行同步与场同步信号进行 10 位编码，形成字符流。接着，在并串转换环节，这些字符流被转化为串行数据流，并通过三个差分输出通道传输。在 DVI 编码器的工作中，有效视频数据期间输出像素数据，而在消隐期则输出控制数据，如图 4-24。此时，VDE 信号高电平意味着视频数据处于有效状态，低电平则表示进入视频消隐期。




图 4-24 HDMI 连接框图

如图 4-26 中，展示了 DVI 编码器的三个通道。在处理 RGB 三色通道的像素数据时，编码逻辑保持一致。VDE 信号决定是否从各通道输出视频像素数据或控制数据。在蓝色通道，HSYNC 和 VSYNC 信号被编码成 10 位字符，并在消隐期间进行传输。根据 DVI 规范，这两个通道的控制信号未被使用，因此设定为 2'b00。




图 4-25 DVI 编码器示意图

在 DVI 规范下，使用 TMDS 编码方法对每个通道的视频像素数据进行处理。每个 8 位的数据被编码为 460 种可选的 10 位字符之一。此编码策略主要确保了传输过程的直流平衡，即在一定时间内传输的高电平（“1”）和低电平（“0”）数量基本持平。此外，任何编码后的 10 位字符中的状态变化（从“1”变到“0”或从“0”变到“1”）被限制在五次以下。对于控制信号，每个通道的 2 位信号同样进行编码，转换为四种不同的 10 位控制字符：10'b1101010100，10'b0010101011，10'b0101010100，和 10'b1010101011，每种控制字符的状态跳变至少七次。这些视频和控制字符的跳变次数的差异性用于辅助发送和接收设备之间的同步。

FPGA 与 HDMI 连接框图如图 4-26 所示。




图 4-26 HDMI 连接框图

HDMI 驱动单元负责生成行场信号，确保数据有效的使能信号，并计算像素的坐标位置。此外，该模块还通过发送 data_req 信号到 DDR 控制器的端口，以获取需要的图像数据。这个过程涉及到从 DDR 内存中读取数据的操作。当系统需要读取特定帧的图像数据时，它会向 DDR 控制器发送 data_req 信号，指示控制器将相应的数据传送给 FPGA 进行处理。HDMI 显示单元生成 HDMI 显示器要显示的像素内容，包括图像和叠加的字符。

HDMI 显示模块程序流程图如图 4-27 所示。使用 FPGA 内置的 HDMI 编码器或外部的 HDMI 发送芯片，从 DDR3 读取处理后的视频数据，以匹配显示的时序要求，实现视频格式转换，如从 YUV 转换为 RGB。设置视频分辨率和色彩格式（如 RGB），从 DDR3 或摄像头直接获取图像数据，再将图像数据编码成 TMDS 信号，并通过 HDMI 接口输出。




图 4-27 HDMI 显示模块程序流程图

HDMI 模块资源利用率如表 4-5 所示。

表 4-5 HDMI 模块资源利用率

Resource	Utilization	Available	Utilization%
Slice LUTs	182	20800	0.88
Slice Registers	145	41600	19.7
F7 muxes	8	16300	0.35
F8 muxes	4	8150	0.04

表格 4-6 是系统布线后的总线时序报告。Worst Negative Slack(WNS)表示所有时序

路径上的最坏负松弛，用于分析最大延迟，其值为 0.0952 表示没有冲突。Worst Hold Slack(WHS)表示最坏保持松弛，用于分析最小延时，其值 0.0543ns 表示没有冲突。Worst Pulse With Slack(WPWS)为最坏脉冲宽度松弛，其值为 0ns 表示时序无问题。Total Negative Slack(TNS)为 0ns 表示满足所有的时序约束。结果表明在 24M 运行时钟频率下，设计是满足时序要求的。

表 4-6 总线时序报告

Worst Negative Slack	Worst Hold Slack	Worst Pulse With Slack	Total Negative Slack
0.0952	0.0543	0.000	0.000

4.4 实验结果及分析

经过验证，成功地在开发板上搭建了立体双目图像采集系统。按照采集系统设计方案完成了硬件的组装和连接。经过综合检查，确认没有错误后，生成了比特流文件，并将其导入到 Vivado 软件中进行后续操作。在该软件环境下，编写及调试了控制程序以管理硬件模块，并对各个模块的功能进行了详细的调试与仿真。实验系统如图 4-28 所示。




图 4-28 实验系统图

对两个尺寸不同的钻杆螺纹进行图像采集，图像采集结果截图如图 4-29。由采集结果可知，系统中摄像头模组成功采集到了两种钻杆螺纹的双目视图，并在 HDMI 显示器进行了显示，表明基于 FPGA 的双目视觉系统的时钟模块、图像分辨率设置模块、DDR 控制器模块、摄像头驱动模块和 HDMI 顶层模块均稳定运行，证明了基于钻杆螺纹缺陷采集系统的可行性。



双目采集结果(a)



双目采集结果(b)



双目采集结果 (c)

图 4-29 实验结果图

在评估算法性能时，硬件资源的消耗也是一个关键因素。文章中提出的基于 FPGA 的立体视觉图像采集装置在硬件资源利用上的数据如表 4-7。数据显示，该系统对存储资源的需求较高，具体消耗为 7653 个查找表(LUT)，其中 922 个 LUT 用作分布式的 RAM/ROM（即 LUTRAM），以及 8499 个触发器(FF)，16 块存储块(BRAM)，和 110 个

输入输出端口(IO)，相比于 FPGA 开发板，这分别占据了 36.79%的 LUT 资源，9.60%的 LUTRAM 资源，20.43%的 FF 资源，32.00%的 BRAM 资源，以及 44.00%的 IO 资源。

表 4-7 本系统主要硬件资源消耗情况

Resource	Utilization	Available	Utilization%
LUT	7653	20800	36.79
LUTRAM	922	9600	9.60
FF	8499	41600	20.43
BRAM	16	50	32.00
IO	110	250	44.00

综上所述，本研究开发的基于 FPGA 的双目视觉系统展示了较强的实时处理性能，能够有效的获取到钻杆螺纹的双目图像，并且在满足实际应用中的实时性要求上基本符合预期。此外，系统的硬件资源利用效率高，实际使用的 LUT、IO 端口等硬件资源较少，使其适合以较低成本在嵌入式设备上部署实用的钻杆螺纹双目立体视觉系统。

4.5 本章小结

本节重点设计和实现了基于 FPGA 的双目图像采集系统。首先，对该系统的整体框架进行了详细阐述。整个系统可以分为多个模块，每个模块负责不同的功能，包括时钟模块、DDR 控制器模块、摄像头驱动模块和 HDMI 顶层模块。然后，分别对系统各模块进行了软件实现与仿真测试，并对整个系统进行了综合测试与实现，最后对实验结果做出了分析，本系统利用最小的逻辑资源消耗，验证了基于 FPGA 的双目视觉系统的完整性和各模块的可行性。

第五章 钻杆螺纹双目图像特征匹配方法研究与参数影响分析

5.1 双目距离对成像影响分析

5.1.1 图像传感模块基线参数设计分析

在立体视觉领域，基线描述的是两相机光心间的直距。根据成像时视角的不同，点匹配分作宽基线与窄基线两种情况。

宽基线匹配和窄基线匹配之间的区别模糊，在窄基线匹配中有一些假设：摄像机焦距和其他内部参数变化不大，摄像机的位置差别较小，转动较少，并且对应点的邻域具有相似性。窄基线匹配的一个典型方法是利用邻域的互相关方法。

宽基线匹配涉及在两个视图中寻找相同特征点的过程，这两个视图之间可能存在显著的视角或位置差异。这种差异可能由相机的不同放置位置、旋转动作或焦点调整等因素引起。在假设宽基线匹配的情况下，图像中的任意一个点都会的另一张图像中有对应的点，尽管这个对应点的位置可能会发生变化。相机可以自由移动，其焦距和其他内部参数也可能发生较大变化。一个图像中的物体在另一个图像中可能被遮挡，尽管对应点周边区域可能相似，但由于拍摄角度和光线条件的改变，仅依靠局部相似性很难准确确定对应点的位置。

5.1.2 基线对双目成像影响的实验研究

（1）实验平台搭建

硬件系统由基线可滑动摄像机与双目图像采集模组构成，软件系统主要为图像采集界面。双目图像传感模块采用了两个 ks861 型摄像头模块组成，采用三角测量法，采用了 NanEyeC 图像传感器，可提供 102.4w 像素的分辨率，1mm*1mm 的模组封装，58 帧每秒的帧率，数字输出接口，可以处理捕获的图像，并通过 USB2.0 接口将处理后的图像传输到图像采集界面。

双目法钻杆螺纹三维成像系统的工作流程如下图 5-1 所示。双目视觉传感器模块通过改变两相机间的间隔距离，捕获需要的图像数据。然后这些数据通过与图像采集卡相连的适配板完成输入过程。在图像采集卡中，采用 Xilinx 公司的 Artix-7 系列 FPGA 作为核心控制单元。这款芯片内嵌有串行和并行数据转换模块，它可以直接处理来自 CameraLink 接口的 LVDS 视频信号，并将其转换成便于系统进行并行处理的形式。这种转换模块的作用是将串行的 LVDS 信号转换为并行数据流，以便更高效地进行后续的图像处理和分析。此外，该芯片还采用了 DDR3 内存作为图像帧的存储单元，能够高效地管理输入信息。CYPRESS 的 CY7C68013A 芯片是 USB2.0 通讯模块的关键组件，它实现了图像采集卡与计算机间的连接。通过该 USB 接口，所采集的图像数据可以传输至计算机端进行展示、分析和保存等操作。




图 5-1 实验平台搭建

第四章所采用的 FPGA 芯片具有出色的性能和可编程性，能够满足复杂数据处理和转换的需求。其中，值得一提的是它内置的串并转换功能，可以直接将低压差分信号（LVDS）转换为并行 TTL/CMOS 信号。这项功能的重要性在于，LVDS 信号具有低功耗和噪声抑制等优势，而并行 TTL/CMOS 信号则更适用于连接其他外部设备和接口。通过适配板，FPGA 接收来自双目视觉传感器的 5 组 LVDS 信号，其中包括 4 组数据信号和 1 组时钟信号。这些数据信号携带着从每个传感器捕获的图像信息，而时钟信号用于保证数据的同步和准确性。

FPGA 内部的 LVDS 接收器模块负责将 LVDS 信号进行解码和重构，以还原其原始的数据表示。接着，数据信号会被进一步处理和转换，使其能够以 28 位并行数据的形式在 FPGA 内部进行操作。其中，24 位用于传输图像信息（RxOUT0~RxOUT23），而另外 4 位用于图像数据的同步控制（RxOUT24~RxOUT27），分别代表备用信号、行有效信号、帧有效信号和数据有效信号。在 FVAL、LVAL 和 DVAL 同时处于高电平状态，并伴随有效的时钟信号输入时，即可成功捕获图像数据。根据实验的不同成像要求，可以适当调节双目摄像机的基线距离。

主控模块主要负责 USB2.0 协议的通讯处理、图像数据的输入输出缓冲、外围设备接口逻辑控制及摄像机管理等功能。此外，它内置了串行与并行数据转换模块（ISERDESE），在图像数据传送过程中能够直接完成数据的串并变换，无需额外的专用串并转换芯片。ISERDESE2（输入串并转换器）是一款针对串行数据流进行串-并转换的专用设备，它配备了独特的时序和逻辑属性，设计用于促进高速数据源同步应用的发展。

USB2.0 控制模块对于实现 USB2.0 的高速数据传送至关重要。我们选择了赛普拉斯科技公司生产的 FX2 系列芯片 CY7C68013A 作为 USB2.0 通讯接口芯片，该接口能够与个人电脑端达到 60MB/s 的双向传输速率。USB2.0 控制单元 FX2 通过 SlaveFIFO 界面与 FPGA 连接，支持大量数据流的传递。经过处理，图像信息将按照标准的 UVC 协议格式传输至个人电脑端。

在传输过程中,输出数据采用了一种 8 位同步并行接口,这种接口能够有效地将图像数据进行并行处理,并提供高质量的传输性能。此外,为了提供更清晰和细腻的图像效果,分辨率被设置为 1280*720,这意味着图像中每行有 1280 个像素,每列有 720 个像素。同时,为了保证流畅的图像播放,帧率被设定为 30FPS,即每秒显示 30 帧图像。每个像素位深为 8 位,以及使用 YUV422 格式进行编码等参数。


(2) 实验结果及分析

为了验证基于双目法的钻杆螺纹图像采集结果及基线对图像质量的影响。从采油现场选取高度为 30cm,螺纹处管外径为 11.5cm,螺纹处厚度为 1.4cm 的公螺纹作为实验对象,使用金属清洁剂对附着在螺纹表面的油污进行处理,将设计了带有基线变化的双目相机如图 5-2 所示以便固定相机位置及方便对相机基线进行调整。




图 5-2 基于双目法的螺纹三维成像系统


实验针对钻杆公扣的侧面螺纹缺陷进行成像,在螺纹侧面面积为 180° 的两处进行标定,将螺纹区分为正反面,在实验过程中改变双目图像采集模组两颗摄像头之间的基线,分别采集公螺纹在摄像头基线最长 169mm、中间 84.5mm 以及最短 35mm 三处的正反面图像。实验结果如图 5-3 所示。



(a)双目图像采集模组基线 169mm



(b)双目图像采集模组基线 84.5mm



(c)双目图像采集模组基线为 35mm 的成像

图 5-3 实验结果图

经过上述三组实验验证,随着摄像头基线在 135mm、84.5mm 和 35mm 之间改变,两颗摄像头所采集的图像视野范围变小,图像信息变得丰富,对侧面螺纹缺陷成像变得全面,但对同一物体左右视图信息重复度变高。基线距离对三维立体成像有一定影响,由上述实验结果图可知,短基线所采集的双目图像会损失掉一部分特征。因此,提出短基线采集到的图像三维成像较困难的假设。所建立的基于双目法的螺纹三维成像系统可以实时获取钻杆侧螺纹处的二维图像深度信息,验证了所设计的硬件与软件系统对正确性与有效性。

5.2 SIFT 特征提取算法

SIFT (尺度不变特征变换) 是一项用于识别局部特征的技术,该技术通过计算图像中的感兴趣点(如角点)及其相关尺度和方向描述符来获取特征,并用于图像特征点的匹配,取得了显著的成果。

SIFT 特征提取算法查找到的特征点有着较好的稳定性,它的主要思想是:

a. 通过在各种尺度上检测图像极值来搜索对尺度具有不变性的兴趣点。这是通过构建高斯差分金字塔来实现的,利用高斯微分函数检测图像中的极值点。它可以在不同尺度下检测到具有不变性的特征点,因为高斯函数具备尺度不变性的特性。

b. 在考虑候选位置时,采用高精度模型对目标的具体位置和大小进行细致估计,并进一步分析这些估计的稳定性。在关键点周围的局部区域内进行插值和拟合,可以准确估计出关键点的位置和尺度参数。同时,对于每个关键点,还会进行稳定性评估,以筛选出稳定且可靠的特征点。

c. 根据局部梯度方向确定每个关键点的方向,实现关键点相对于方向、尺度和位置的不变性操作。在关键点周围的邻域内,计算局部梯度的方向,并为每个关键点指定一个主导方向。这样可以使得关键点对图像的旋转、平移和缩放具有不变性,从而提高特征点的鲁棒性和匹配准确性。

d. 对每个关键点附近的区域,在特定的尺寸等级上对图像的局部梯度进行量化,并将这些信息转换成特定的特征表述形式。这样的特征描述方法(如方向直方图、梯度直方图、局部二进制模式等)能够有效捕捉图像在各个尺度上的细节变化,且能够适应较大范围内的局部形态变化和光照变化。通过将局部梯度信息编码为特征向量或特征描述符,可以实现对大局部形状变形和光照变化的描述,提高特征的鲁棒性和可靠性。尺度不变特征变换特征提取算法的主要步骤如图 5-4 所示。




图 5-4 SIFT 算法提取特征的核心流程

5.2.1 尺度空间

尺度空间理论的核心思想是在图像处理的计算模型中引入尺度参数，并通过不断改变该参数以获得图像在多个尺度下的连续表示，接着对这连续表示中的尺度空间关键形态进行提取，形成特征向量集合，这些特征向量可用于完成诸如边缘检测、角点识别及在不同解析度条件下的特征抽取等任务。尺度空间理论的目的在于模拟数据在多个尺度上的特征。

构建尺度空间^[65]的是因为计算机本身无法识别物体的具体尺寸，因此需要对其进行尺度培训，即输入不同尺度的物体图像，让计算机进行识别与处理。建立尺度空间的核心步骤在于采用高斯核的卷积操作，这是实现图像尺度变换中唯一的线性过程。利用不同尺度参数的高斯核来创建整个尺度空间，二维图像尺度空间的定义可表述为以下形式：

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y) \quad (5-1)$$

在公式(5-1)中， $G(x, y, \sigma)$ 是一个尺度可调的高斯核函数，其中 (x, y) 表示尺度空间中的位置， σ 为高斯分布的标准差，该值反映了图像的平滑水平。标准差值较小意味着图像更平滑，相应的尺度也更小。在 SIFT 算法中引入差分高斯（Difference of Gaussian, DOG）作为极值判别标准以有效地在尺度空间内识别出稳定的特征点。DOG 子定义如下：

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma) \quad (5-2)$$

不同 σ 下图像尺度空间如图 5-5。




图 5-5 不同 σ 下图像尺度空间

5.2.2 金字塔

为了寻找图像中极值点，图像金字塔、高斯金字塔和高斯差分金字塔这三种金字塔结构都被广泛应用。

构造图像金字塔的过程涉及使用低通滤波来对原始图像进行平滑化，继而对平滑后

的图像执行下采样操作，即将水平和垂直方向的像素值减半，生成一系列尺寸较小的图像。传统的金字塔中，每一层的分辨率为上一层的一半，即由上一层图像的长和宽减半得到，像素数量为上一层的 1/4。

高斯金字塔^[66]通过对图像金字塔每一层进行下采样并施加高斯模糊处理构建而成。换言之，就是对金字塔每层图像实行高斯平滑。金字塔的每一组图像称为一个 **octave**，含有数张尺度变化的图像。值得注意的是，在执行下采样过程中，某个 **octave** 组内的首张图片（即最低层图像），实际上是由该组上方 **octave** 的第三张图片以跳跃式抽样生成的。**SIFT** 算法通过计算两幅邻近尺度空间图像的差异，产生差分高斯(DOG)图像，即 $D(x, y, \sigma)$ 。在实际操作中，DOG 的实现相对简单，只需对相邻尺度的高斯核进行减法操作。因此，用 DOG 替代 Laplacian of Gaussians (LOG) 更高效，计算速度更快。图 5-6 为高斯差分金字塔。




图 5-6 高斯差分图像的构建

在图 5-6 中，金字塔组数为 $Octave = [\log_2 \min(M, N)] - 2$ ， M 、 N 为初始图像的行数和列数。每组金字塔中包含 S 层不同 σ 的图片，其中 $S = n + 3$ ，例如 $6=3+3$ ，即只能提取 $n=3$ 层的特征。高斯金字塔中的每层图像表示为公式(5-3)：

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y) \quad (5-3)$$

其中 $G(x, y, \sigma) = \frac{1}{2\pi\sigma^2} e^{-(x^2+y^2)/2\sigma^2}$ 为高斯函数， σ 为高斯模糊系数。高斯差分金字塔响应值图像表示为公式(5-4)：

$$D(x, y, \sigma) = (G(x, y, k\sigma) - G(x, y, \sigma)) * I(x, y) = L(x, y, k\sigma) - L(x, y, \sigma) \quad (5-4)$$

式中 k 为两相邻尺度空间倍数，由公式可知在高斯差分金字塔中，位于第 x 组第 y 层的图像是通过从相同组的第 x 组第 $y + 1$ 层图像得出的。这种操作有效地突出了图像间的

局部强度变化，有助于增强图像特征。

5.2.3 DOG 关键点定位

关键点是通过 DOG 空间^[67]中的局部极值点组成的，它们必须大于或小于包括图像域和尺度域内所有点的邻域值，也就是说每个待检测点需与其所有相邻点进行比较，相邻点总数为 26 个。该方法通过局部比较来找到离散空间的极值点，而非真实极值点，因此可能存在一些不稳定的关键点。然而，良好的关键点必须具备较佳的稳定性，因此需要采取以下步骤来进一步确认关键点。

为了确定尺度空间的极值点，需将每个采样点与其周围点进行对照，评估其在图像平面和尺度范围内是否呈现出极大或极小的性质。

差分高斯(DOG)尺度空间的极值点识别，如图 5-7 所示。通过比较一个像素点在其所在层及相邻的上下两层内的 26 个周围像素点(中心点、其 8 个相邻点以及与之上下尺度层相对应的 9+9 个点)来进行检测。若该像素点在这些邻近区域内表现为极大值或极小值，则可以将其认定为在特定尺度下的图像特征点。采取这种方法确保了能够在尺度空间与二维平面空间中均有效识别到极值点。通过在不同尺度下进行特征点检测，可以提取到更全面和多样化的图像特征，从而为后续的图像分析和处理任务提供更准确的信息。因此，尺度空间和二维图像空间的综合分析对于有效地检测图像中的极值点至关重要。




图 5-7 DOG 尺度空间极值点检测

为提升关键点的可靠性，需要在尺度空间上对差分高斯(DOG)函数进行曲率估计。利用 DOG 函数的二阶泰勒级数展开，能够精确插值得到特征点的具体位置及其尺度坐标。通过在 DOG 函数中进行泰勒级数展开，可以将特征点的位置和尺度坐标与 DOG 函数的局部曲率相匹配，从而得到更精确的特征点位置。通过计算 DOG 函数在特征点附近的一阶和二阶导数，可以估计特征点的位置和尺度，进而实现特征点的精确插值。这

种插值方法可以在亚像素级别上精确定位特征点，提高了特征点检测的准确性和稳定性。

$$D(X) = D + \frac{\partial D^T}{\partial X} X + \frac{1}{2} X^T \frac{\partial^2 D}{\partial X^2} X \quad (5-5)$$

在公式 5-5 中，向量 $X(x, y, \sigma)$ 描述了采样点与特征点之间在空间范围内位置和尺度上的偏移关系。将方程(2)的导数设为零，可以求得特征点的准确位置。

5.2.4 特征点方向及生成特征描述子

直方图中的角度范围是 0~360 度，共有 36 个角度区间，每个区间间隔为 10 度。随着距离中心点越远，对直方图的贡献逐渐减小。Lowe 的论文指出，为了减少突变的影响，应当对直方图进行高斯平滑处理。

在处理过程中，围绕关键点的局部区域进行像素采样是一种常见的方法。通过对这些采样像素的梯度方向进行分析，统计其分布情况，从而得到一个梯度方向直方图，此梯度方向直方图包含的角度区间是从 0 度到 360 度，每个区间间隔 45 度，共有 8 个区间，或者每个区间间隔 10 度，共有 36 个区间。在研究中还提到，应用高斯滤波来对直方图进行平滑化处理，目的是降低突变带来的干扰。直方图的峰值体现了关键点周围梯度的主导方向，亦即关键点自身的定向，其他达到峰值 80% 的方向可被视为辅助方向。关键点的直方图^[68]如图 5-8 所示。




图 5-8 关键点方向直方图

将特征点作为中心，将坐标轴旋转至其主方向，然后在 16×16 像素的窗口内提取数据。每个 4×4 像素的小窗口内，对采样点周围的特征点进行方向性判定，并结合高斯权重计算后，将其分配到一个由 8 个方向构成的统计直方图之中。通过这种方式，形成了具有 128 个元素的特征向量。具体的实现步骤详见图 5-9。




图 5-9 生成 SIFT 特征点描述子

5.2.5 SIFT 特征匹配

根据先前步骤获得的采样图像 SIFT 特征，在另一幅图像中找到相应的 SIFT 特征，这即为 SIFT 特征匹配。在 SIFT 匹配的过程中，采用的是最近邻不相似度比（NNDR）策略，该方法需要计算两个 SIFT 描述子之间的距离，这里使用穷举法计算任意两个描述子之间的欧几里得距离：

$$d(R_i, S_i) = \sqrt{\sum_{j=1}^{128} (r_{ij} - s_{ij})^2} \quad (5-6)$$


假设一个图像的采样描述子为 $R_i = (r_{i1}, r_{i2}, \dots, r_{i128})$ ，另一幅图像的描述子为 $S_i = (s_{i1}, s_{i2}, \dots, s_{i128})$ ，根据计算结果，利用最近邻不同率（NNDR）策略，即通过计算最接近点和次接近点的距离比值来设定阈值 $ratio$ 来进行匹配：

$$\frac{\text{距离} R_i \text{最近点的} S_j \text{的欧式距离}}{\text{距离} R_i \text{次近点的} S_p \text{的欧式距离}} < ratio \quad (5-7)$$


经过大量实验验证，Lowe 得出结论：当匹配正确时，对应的比率较低；当匹配错误时，比率较高。当比率为 0.8 时，可以有效地消除匹配中的错误点，且仅牺牲少量正确匹配点，从而达到良好的匹配效果。

5.3 实验结果与分析


针对 5.1 中图像采集系统获取到的三种不同基线的图像在 Pycharm 平台中分别进行双目立体校正，SIFT 特征匹配的实验。



(a)双目立体校正




(b)SIFT特征匹配




(c)匹配融合


图 5-10 双目图像采集模组基线 169mm



(a)双目立体校正




(b)SIFT特征匹配



(c)匹配融合

图 5-11 双目图像采集模组基线 84.5mm



(a) 双目立体校正

图 5-12 双目图像采集模组基线 35mm

由上述三组实验中，图(a)上方两张图为双目相机获取的左右视图，下方两张图为对左右视图采用图像变换进行立体校正处理后的结果图，其中相机模组基线为 169mm 和 84.5mm 时，立体校正效果明显。在基线距离为 35mm 时，由于左右视图图像信息重复度高，遗失了钻杆螺纹部分图像信息，导致左右两张变换后，右视图没有和左视图对应的点，即右视图立体校正失效，在实验结果中表述为图 5-12 中右下角空白处，导致无法进行 SIFT 特征匹配和像素点融合成像实验。

图(b)是对立体校正后的左右图像进行 SIFT 特征匹配，由图可知 SIFT 特征匹配算法可对基线为 169mm 和 84.5mm 的左右视图进行特征点匹配。

图(c)是基于 SIFT 特征匹配后，对左右图像进行像素点融合成像，由图 5-10(c)和 5-11(c)对比可知，当基线距离为 169mm 时，左右视图中目标物体信息量减少，导致特征匹配点减少，成像效果相较于基线为 84.5mm 时差。

综上所述，当基线为 35mm 时，双目图像中细节信息丰富，但由于左右图像重复度高，左右视觉图像中匹配点变少，导致基线为 35mm 时双目立体校正无法获得足够多的匹配点而失效。对比基线为 169mm 与 84.5mm 的实验结果图可得，随着基线的增大，图像匹配的搜索范围变宽，匹配难度增加，导致匹配错误的几率上升，最终导致系统成像效果变差。因此推断，当基线距离满足双目视觉采集到的图像目标信息丰富且重合度小时，钻杆螺纹成像效果最好。

5.4 本章小节

本章首先搭建了基线参数影响分析实验平台，针对基线对双目图像采集的影响进行了研究，通过设置基线距离分别为 169mm、84.5mm 以及 35mm，研究了三种基线对钻杆螺纹双目成像的影响，实验结果表明，84.5mm 的基线设置最为合适。其次研究了双目图像的特征匹配方法，稳定的 SIFT 算法的特征描述子对尺度、光照、仿射都有着较好的不变性，能够根据特征点间的最小欧式距离进行匹配，编程实现了 SIFT 算法。最后，通过三组实验对比说明了，SFIT 特征匹配对钻杆螺纹成像的有效性；双目摄像模组的基线对双目立体视觉有着较大影响。最后，通过对基线为 169mm、84.5mm 以及 35mm 实验对比分析，得出结论：双目摄像模组的基线对双目立体视觉成像有着较大影响，当双目摄像机的基线距离使采集到的左右图像目标信息量丰富且图像重合度小时，84.5mm 的基线参数使得钻杆螺纹信息特征匹配和融合的效果最好。

第六章 总结与展望

6.1 工作总结

石油钻杆是油气开采中重要的钻具，它的主要作用是对钻头和井架控制平台的连接传递动力，在钻具中传递钻井液。钻杆连接区域的螺纹损伤不但会降低石油开采的生产效率，同时也会增加井下安全事故的发生概率，导致高昂的修复及替换费用。因此，分析和研究钻杆联接螺纹的损坏问题变得尤为关键。钻杆螺纹缺陷检测常采用人工检测的方式，其检测效率低、误差大，因此实现钻杆螺纹缺陷的智能化检测可以提高螺纹检测的检测精度和工作效率，易于形成螺纹缺陷数据库，便于后续缺陷级别的量化与评估。对于钻杆螺纹缺陷的深度、分布范围以及对螺纹整体性能的影响往往不能从仅有的二维图像数据中完全捕捉和评估，因此很难对螺纹内部的具体情况进行全面了解。正是因为二维图像在螺纹缺陷分析中的局限性，研究螺纹的三维成像技术显得尤为重要。本文具体内容如下：

(1) 针对钻杆螺纹裂缝缺陷数据集缺少的情况，通过作业现场采集和油田相关单位收集的方式建立有关螺纹裂缝的基础数据集，并通过数据增强、切片和翻转等方式对基础数据集进行扩充。为了使数据集能在多种模型上训练，将在 LabelImg 中标注后的数据集格式保存为 VOC 格式，通过在 YOLOv5 中执行编译的归一化代码实现 VOC 格式到 YOLO 格式的转换。对 YOLOv5 模型网络架构进行了分析，将扩充的数据集在 YOLOv5 及部分主流检测算法上进行对比分析，YOLOv5 在阈值为 50% 时获得了 69.3% 的平均检测率，目标检测速度达到 93.6FPS，与 YOLOv8s 等算法相比具有竞争力，证明了 YOLOv5 作为钻杆螺纹缺陷检测模型的可行性。

(2) 针对二维图像在螺纹缺陷分析中缺少深度信息的问题，分析设计了基于双目法的三维成像方法的系统设计软硬件实现方案，基于 FPGA 硬件平台，搭建了一个完整的双目立体视觉系统，系统使用模块化设计，具体分为时钟模块、图像分辨率设置模块、DDR 控制器模块、摄像头驱动模块和 HDMI 顶层模块，对各模块进行了仿真测试并分析了模块的资源消耗。图像采集结果验证了基于 FPGA 的双目视觉系统的完整性和有效性。

(3) 在基于钻杆螺纹三维重构方法研究中，通过对双目视觉成像原理中基线对成像后物体深度的影响，设计了基于双目法的钻杆螺纹三维成像系统，针对钻杆公螺纹侧面缺陷进行成像实验，分别设置基线参数为 169mm、84.5mm、35mm 等，当基线为 169mm 时，成像范围最大，缺陷细节信息量最少；当基线为 35mm 时成像范围最小，缺陷细节信息量最丰富。实验验证了图像传感模块基线变化对成像左右视图目标信息量的影响。在特征匹配中，对 SIFT 特征匹配算法原理框架进行了分析，通过对本章系统采集到的基线为 169mm、84.5mm 和 35mm 图像进行对照试验。实验结果表明，基线在

35mm 时, 双目图像中细节信息量丰富, 但由于图像重复度高, 丢失了部分目标信息, 导致立体校正失效, 基线距离为 196mm 时, 左右视图中目标信息量减少, 特征匹配点减少, 最终导致系统成像效果变差。基线距离为 84.5mm 时, 立体校正、SIFT 特征匹配和成像效果最好。实验验证了 SFIT 特征匹配对钻杆螺纹成像的有效性, 并根据实验结果推断双目摄像模组的基线对双目立体视觉的成像有着较大影响。

6.2 研究展望

本文利用机器视觉检测技术, 针对钻杆螺纹结构的特殊性进行研究, 分别设计了基于双目法的钻杆螺纹三维成像系统, 基于 Python 的钻杆螺纹双目图像的三维特征匹配及融合方法研究与实现以及基于 YOLOv5 模型的螺纹缺陷检测。通过实验及结果分析, 论文取得了一些结论, 但是也存在工作中的不足, 接下来对下一步研究做出展望:

(1) 针对基于双目法的钻杆螺纹三维成像系统, 研究中发现如果采集到的图像中存在噪声会对双目视觉采集与成像产生严重影响, 因此需要在系统中增加图像预处理模块, 对图像进行降噪、增强等预处理, 提高图像质量, 提高成像的清晰度和精度。同时, 可增加多组摄像头模组来降低实验操作难度。

(2) 针对钻杆螺纹三维重构的特征匹配与融合实现, 论文采用了 SIFT 算法构建的描述子为 128 维, 虽然包含的信息十分丰富, 但在构建描述子时, 计算量较大, 且在噪声较大时, 匹配准确率较低, 因此, 需要进一步研究计算量和噪声的抗干扰的优化算法。同时, 需要开展钻杆螺纹三维重构方法及缺陷三维显示方面的研究。

(3) 仅针对钻杆螺纹裂纹的缺陷检测研究, 需进一步增加相关缺陷图像数据、优化模型, 提高检测精度。同时, 可进一步研究基于深度学习模型的三维图像缺陷的智能检测方法。

参考文献

- [1] 罗军, 白马, 董海龙. 塔河油田钻具失效分析及预防措施[J]. 西部探矿工程, 2018, 30(01): 57-60+65.
- [2] 王四一. 煤矿井下近水平定向钻进黏滑振动产生机理及应对措施[J]. 煤矿安全, 2022, 53(06): 131-136.
- [3] 刘向阳. 基于交流电磁场的钻杆螺纹缺陷检测技术研究[D]. 中国石油大学(华东), 2021.
- [4] 顾炜炜. 防冲卸压自动钻机的夹持拧卸机构设计与分析[D]. 北京交通大学, 2022.
- [5] 彭著海. 钻杆螺纹接头力学特性分析及优化[D]. 西华大学, 2023.
- [6] 鄢忠方. 四/六面体网格在钻杆接头应力分析中的性能研究[J]. 煤矿机械, 2020, 41(09): 41-44.
- [7] 曹怀情. 石油钻杆螺纹电磁检测技术研究[D]. 东北石油大学, 2023.
- [8] 杨利强, 高雷雷, 李林聪, 等. 基于 3D 成像的钻杆螺纹自动化检测系统[J]. 工具技术, 2022, 56(01): 90-94.
- [9] 叶文超. 钻杆连接螺纹磁扰动检测方法系统与系统[D]. 华中科技大学, 2022.
- [10] 马国, 贾华东, 卢长煜, 等. 磁粉检测与渗透检测在工程机械结构件无损检测中的应用[J]. 无损检测, 2019, 41(02): 62-64.
- [11] 王银强. 油气管线穿越钻杆失效分析及预防[D]. 西安石油大学, 2016.
- [12] 葛恒赫. 基于机器视觉的外螺纹表面缺陷检测技术研究[D]. 重庆大学, 2015.
- [13] 万翔, 潘华伟, 张旭辉, 等. 基于超声导波的方钻杆检测方法研究[J]. 振动.测试与诊断, 2023, 43(06): 1088-1094+1241.
- [14] 巨西民, 莫润阳. 钻杆接头螺纹部位疲劳裂纹的超声波检测[J]. 西安石油学院学报(自然科学版), 2000(05): 64-67+1.
- [15] 刘洪涛. 钻铤螺纹小角度探头检测方法研究与应用[J]. 无损检测, 2020, 42(05): 79-80.
- [16] 张鹏鲲. 高强螺栓的应力分析与超声无损探伤研究[D]. 华北电力大学(北京), 2021.
- [17] 郑承明, 王新海, 王文军, 等. 钻杆螺纹缺陷检测装置的研制[J]. 石油机械, 2006(04): 34-37+87.
- [18] 钱政平, 章文显, 李广立, 等. 涡流检测技术在螺栓检测中的应用[J]. 轨道交通装备与技术, 2023(01): 33-34+37.
- [19] 孙金立, 陈新波, 袁英民, 等. 用涡流屏蔽式探头检测油田钻具接头疲劳裂纹[J]. 无损检测, 2002(12): 542-543.
- [20] 丁劲锋, 康宜华, 武新军. 油管螺纹检测方法的研究[J]. 现代科学仪器, 2007(05): 89-92.
- [21] Hwang H N. Defect characterization by magnetic leakage fields[J]. british journal of ndt, 1977.
- [22] Yan M, Udpa S, Mandayam S, et al. Solution of inverse problems in electromagnetic NDE using finite element methods[J]. IEEE Transactions on Magnetics, 2015, 34(5): 2924-2927.
- [23] 辛荣亚, 张启伟. 基于漏磁检测的桥梁拉索钢丝损伤评估[J]. 桥梁建设, 2019, 49(03): 51-56.
- [24] 汪杰, 陈曼龙, 李奎, 等. 机器视觉螺纹图像评价方法[J]. 应用光学, 2022, 43(05): 904-912.

- [25] Hunsicker, Randal J, Patten John, Ledford Alton, Ferman Cathie, Allen Michael, Ellis Clark. Automatic vision inspection and measurement system for external screw threads[J]. Journal of Manufacturing Systems, 1994, 13(5): 370-384.
- [26] Pal Singh A, Julka N. Screw classification using machine vision[J]. IJECT, 2011, 2(1): 31-33.
- [27] Mohamed A, Esa A H, Ayub M A. Roundness measurement of cylindrical part by machine vision[C]. International Conference on Electrical Control and Computer Engineering, 2011: 486-490.
- [28] 王和顺. 螺纹参数自动化测量仪的研究[D]. 四川大学, 2002.
- [29] 赵月. 基于深度学习的螺纹钢表面缺陷检测关键技术研究[D]. 山东建筑大学, 2022.
- [30] Hinton,G,E, et al. Reducing the Dimensionality of Data with Neural Networks.[J]. Science, 2006.
- [31] 叶少锋. 钣金折弯件微裂纹图像分类研究[D]. 厦门大学, 2019.
- [32] 海潮. 基于深度学习的红枣缺陷识别技术研究[D]. 郑州大学, 2019.
- [33] 赵海文, 赵亚川, 齐兴悦, 等. 基于深度学习的汽车轮毂表面缺陷检测算法研究[J]. 组合机床与自动化加工技术, 2019(11): 4.
- [34] TANG J, WANG Z, ZHANG H, et al. A lightweight surface defect detection framework combined with dual-domain attention mechanism[J]. Expert Systems with Applications, 2023: 121726.
- [35] Cui L, Jiang X, Xu M, et al. SDDNet: A Fast and Accurate Network for Surface Defect Detection[J]. IEEE Transactions on Instrumentation and Measurement, 2021, PP(99): 1-1.
- [36] WANG B, WANG M, YANG J, et al. YOLOv5-CD: Strip steel surface defect detection method based on coordinate attention and a decoupled head[J]. Measurement: Sensors, 2023: 100909.
- [37] XU H. FCD-YOLO: Improved YOLOv5 Based on Decoupled Head and Attention Mechanism for Defect Detection on Printed Circuit Board; proceedings of the 2022 2nd International Conference on Networking Systems of AI (INSAI), F, 2022[C]. IEEE.
- [38] Chen C, Shen F, Dai C. SwinTD: Transformer-based detection network for foreign objects in the cut section of tobacco packets[J]. Measurement, 2023.
- [39] 田婷. 基于立体匹配技术的 X 射线三维立体成像方法研究[D]. 中北大学, 2023.
- [40] 陈佳星, 沈毅, 周浩, 等. 基于机器视觉的钢卷尺表面缺陷检测系统设计[J]. 软件工程, 2022,25(12): 21-25.
- [41] D.I. Barnea and H. F. Silverman, "A Class of Algorithms for Fast Digital ImageRegistration," in IEEE Transactions on Computers, vol. C-21, no. 2, pp. 179-186, Feb. 1972.
- [42] Ulrich M, Steger C, Baumgartner A .Real-time object recognition using a modified generalized Hough transform[J]. Pattern Recognition: The Journal of the Pattern Recognition Society, 2003(11): 36.
- [43] 薛利军, 张虎, 李自田. 基于削减搜索分支的快速模板匹配算法[J]. 计算机工程, 2003(16): 87-89.
- [44] 彭晓明, 丁明跃, 周成平, 等. 一种利用 Hausdorff 距离的高效目标搜索算法[J]. 中国图象图形学报, 2004(01): 25-30.
- [45] 许洁平. 凝视光学成像卫星遥感图像超分辨率重建技术研究[D]. 国防科技大学, 2020.
- [46] Harris C G, Stephens M J. A combined corner and edge detector[C]//Alvey vision conference.1988.

- [47] Sm. S, Jm. B. SUSAN - A NEW APPROACH TO LOW LEVEL IMAGE PROCESSING[J]. International Journal of Computer Vision, 1997(1): 23.
- [48] Lowe D G. Distinctive image features from scale-invariant keypoints[J]. International Journal of Computer Vision, 2004(2): 60.
- [49] Duan C, Meng X, Tu C, et al. How to make local image features more efficient and distinctive[J]. IET Computer Vision, 2008, 2(3): 178-189.
- [50] Wang S. BFSIFT: A Novel Method to Find Feature Matches for SAR Image Registration[J]. IEEE Geoscience and Remote Sensing Letters, 2012, 9(4): p.649-653.
- [51] Dongyao Z, Yueqing W U, Yu Y. Retrieval of medical images based on fusion of global feature and scale-invariant feature transform feature[J]. Journal of Computer Applications, 2015.
- [52] 王嘉奇. 基于深度学习的淋巴结自动检测算法研究[D]. 浙江大学, 2019.
- [53] 刘逸凡, 王淑青, 庆毅辉, 等. 基于 EfficientDet 和双目摄像头的绝缘子缺陷检测[J]. 中国电力, 2021, 54(02): 156-163+196.
- [54] 王宇宁, 庞智恒, 袁德明. 基于 YOLO 算法的车辆实时检测[J]. 武汉理工大学学报, 2016, 38(10): 41-46.
- [55] 张瑞林, 张俊为, 桂江生, 等. 基于改进 YOLOv2 网络的遗留物检测算法[J]. 浙江理工大学学报(自然科学版), 2018, 39(03): 325-332.
- [56] 谭俊. 一个改进的 YOLOv3 目标识别算法研究[D]. 华中科技大学, 2019.
- [57] 张威. 基于 YOLOv4 的交通标志实时检测算法研究[D]. 北京交通大学, 2022.
- [58] 舒朗, 张智杰, 雷波. 一种针对红外目标检测的 Dense-Yolov5 算法研究[J]. 光学与光电技术, 2021, 19(01): 69-75.
- [59] 温凡彪. 融合频率注意力机制和轮廓先验的网格重建方法[D]. 广西大学, 2023.
- [60] 齐翔宇. 基于 3D 视觉的番茄花朵检测与定位方法[D]. 沈阳农业大学, 2023.
- [61] 郎宇健. 基于立体视觉的堆叠药盒识别与抓取方法研究[D]. 浙江科技大学, 2024.
- [62] 孔慧芳, 刘润武, 胡杰. 基于多模态中间表示的端到端自动驾驶模型[J]. 现代制造工程, 2024(03): 70-78.
- [63] 姜宇扬, 黄开基, 潘先锋, 等. 融合双目与 ToF 的高速三维视觉感知系统[J/OL]. 机械科学与技术: 1-9[2024-04-15].
- [64] 李嘉欣. 基于深度学习的小目标检测算法研究[D]. 西安石油大学, 2024.
- [65] 李梦蝶. 基于彩色各向异性 SIFT 特征的双目图像匹配算法[D]. 西安电子科技大学, 2020.
- [66] 姚贇. 无人机多路航拍视频拼接方法研究[D]. 西安理工大学, 2024.
- [67] 吴天. 基于激光 SLAM 的栅格地图构建与导航[D]. 西北农林科技大学, 2023.
- [68] 李雨泽, 张岩, 陈宇, 等. 基于深层-浅层双流学习图模型的无监督少样本红外空中目标识别网络[J]. 红外与毫米波学报, 2023, 42(06): 917-924.