

类 ☐全日制学术学位
☒全日制专业学位
☐非全日制专业学位
别 ☐在职工程硕士

硕士学位论文

论文题目： 基于机器视觉缺陷检测的研究

学科（专业）名称： 机械

研究方向： 机械系统检测与精密仪器

论文编号：

分类号：TP2
U D C：621

密级：公开
编号：

专业学位硕士学位论文

基于机器视觉缺陷检测的研究

硕士研究生：梁世金

指导教师：杨旗 教授

学科、专业：机械

沈阳理工大学

2023 年 03 月

分类号：TP2
U D C：621

密级：公开
编号：

专业学位硕士学位论文

基于机器视觉缺陷检测的研究

硕士研究生：梁世金
指导教师：杨旗 教授
学科、专业：机械
所在单位：机械工程学院
论文提交日期：2023 年 12 月 03 日
论文答辩日期：2024 年 03 月 05 日
学位授予单位：沈阳理工大学

Classification Index: TP2
U.D.C: 621

A Thesis for the Professional Master's Degree

Research on Machine Vision Defect Detection

Candidate : Liang Shijin

Supervisor: Prof. Yang Qi

Speciality : Mechatronic Engineering

Date of Submission: December 3, 2023

Date of Examination: March 5, 2024

University : Shenyang Ligong University

摘 要

由于生产工艺的缺陷以及运输过程中的磕碰以及人工操作失误会导致零件产生缺陷。以轴承座为例会产生缺边，凹坑，豁口，划痕，污染等缺陷。这些缺陷会减轻零件的使用寿命，严重可能会影响到生产安全从而导致生产事故。上述的缺陷有些很细微不易观察，人工质量检测存在难点。因此，设计一种能准确识别上述多种缺陷，检测性能强且能够自动分拣的目标检测模型系统具有重要的意义。本文对 YOLOv5s 模型进行一系列改进，并且与机械臂进行联动，提出高性能和轻量化的检测模型分拣系统，主要研究内容如下：

（1）围绕着轴承座表面缺陷检测，自主采集缺陷图像，并通过翻转，增加对比度等进行图像的数据增强。使用 labellmg 软件手动进行缺陷标注，构建了轴承座表面缺陷的数据集。该数据集共涉及 5 类缺陷，共 780 张图片。

（2）针对原始 YOLOv5s 模型检测精度低，速度慢的问题提出一种改进的 YOLOv5s 模型 YOLOv5s-WGCA。在特征提取方面，添加了 CA 注意力机制，使网络模型更加关注目标区域，提升检测精度。在锚框机制方面，使用 WIoUv3 代替原本的 CIoU，增强对数据集的适应性，提高检测精度。在模型轻量化方面，使用 GSConv 代替标准卷积，降低模型参数量与计算量，使模型轻量化，提升检测速度。

（3）针对分拣问题，本文采用越疆臂魔术师系列机械臂进行缺陷零件的自动分拣。通过串口使机械臂与上位机连接，针对网络模型检测出来结果，实时把坐标传给机械臂，使其自动对缺陷零件进行分拣。

（4）针对本文提出的 YOLOv5s-WGCA 模型，基于 PyQt5 和工业相机搭建轴承座表面缺陷检测实时系统。使之操作更直观更简便。

综上所述，本文提出的基于 YOLOv5s 的高性能轻量化模型，使平均检测精度 mAP 从原来的 91.7%提升到 92.9%，检测速度从原来的 47.6 提升到 49.2。与机械臂联动，自动分拣缺陷样本，最后编写 UI 界面使之更加简便直观。

关键词：目标检测；YOLOv5；注意力机制；轻量化；深度学习

Abstract

Defects in parts can occur due to defects in the production process, as well as bumps and manual errors during transportation. Taking the bearing housing as an example, defects such as missing edges, pits, gaps, scratches, and contamination will occur. These defects can reduce the service life of the parts and may seriously affect the safety of production and lead to production accidents. Some of the above-mentioned defects are very subtle and difficult to observe, and there are difficulties in manual quality inspection. Therefore, it is of great significance to design an object detection model system that can accurately identify the above defects, have strong detection performance and can be automatically sorted. In this paper, a series of improvements are made to the YOLOv5s model, and a high-performance and lightweight detection model sorting system is proposed in conjunction with the robotic arm, and the main research contents are as follows:

(1) Focusing on the surface defect detection of the bearing seat, the defect image is collected independently, and the data enhancement of the image is carried out by flipping, random color jitter, etc. The defect annotation was carried out manually by labelling software, and the dataset of surface defects of the bearing seat was constructed. The dataset involves a total of 780 images in 5 categories of defects.

(2) In order to solve the problem of low accuracy and slow speed of the original YOLOv5s model for the detection of surface defects of bearing housings, an improved YOLOv5s model YOLOv5s-WGCA was proposed. In terms of feature extraction, the CA attention mechanism is added to make the network model pay more attention to the target region and improve the detection accuracy. In terms of anchor frame mechanism, WIoUv3 is used to replace the original CIoU to enhance the adaptability of the model to the dataset and improve the detection accuracy. In terms of model lightweight, GSConv is used instead of the original standard convolution, which reduces the number of model

parameters and the amount of model calculation, which makes the model lighter and improves the detection speed.

(3) In order to solve the sorting problem, this paper uses the cross-border arm magician series robotic arm to automatically sort defective parts. The robotic arm is connected with the host computer through the serial port, and the coordinates are transmitted to the robotic arm in real time according to the detection results of the network model, so that it can automatically sort the defective parts.

(4) According to the YOLOv5s-WGCA model proposed in this paper, a real-time system for surface defect detection of bearing housing is built based on PyQt5 and industrial cameras. Make it more intuitive and easy to operate.

In summary, this paper proposes a high-performance lightweight model based on YOLOv5s by increasing the CA attention mechanism, replacing the WIoUv3 loss function, and improving the lightweight convolution, so that the average detection accuracy mAP is increased from 91.7% to 92.9%, and the detection speed is increased from 47.6 to 49.2. It is linked with the robotic arm to automatically sort defective samples, and finally the UI interface is written to make it more convenient and intuitive.

Key words: Object detection; YOLOv5; Attention mechanism; Lightweighting; Deep learning.

目 录

第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 传统的表面缺陷检测方法.....	2
1.2.2 基于机器学习的表面缺陷检测方法.....	4
1.2.3 基于深度学习的表面缺陷检测方法.....	5
1.3 本文研究内容和组织结构	6
第 2 章 基于深度学习的目标检测理论分析	8
2.1 卷积神经网络组成.....	8
2.2 YOLOv5 模型.....	11
2.2.1 基础模型	11
2.2.2 YOLOv5 网络结构.....	12
2.2.3 定位损失函数.....	17
2.3 本章小结.....	21
第 3 章 基于改进 YOLOv5 的高性能与轻量化模型	23
3.1 注意力机制.....	23
3.1.1 SE 注意力机制	24
3.1.2 CBAM 注意力机制	26
3.1.3 CA 注意力机制	28
3.2 损失函数的改进.....	30
3.3 模型轻量化改进.....	31
3.3.1 深度可分离卷积.....	32
3.3.2 GSCnov	33
3.4 实验结果分析.....	34
3.4.1 数据集制作	34
3.4.2 数据集标注	36
3.4.3 评价指标	37
3.4.4 实验环境.....	40
3.4.5 实验结果对比分析	40
3.5 本章小结.....	45
第 4 章 系统设计实现与实验平台搭建	46
4.1 系统硬件选型介绍.....	46
4.2 机械臂运动学求解及标定	46
4.2.1 正运动学	46

4.2.2 逆运行学.....	48
4.2.3 手眼标定.....	51
4.3 UI 界面	52
4.4 本章小结.....	54
结论.....	55
参考文献.....	57

第 1 章 绪论

1.1 研究背景及意义

在工业制造领域中，零件加工是一个至关重要的环节。它涉及到将原材料加工成符合特定设计要求的零部件，为产品的制造提供了必要的基础。伴随着工业智能化的发展，工业零件的制造设备以及生产出来的产品质量也提出了更高的要求。从零件制造技术方面考虑，要求生产出来的零件尺寸标准、精度高、表面无划痕凹坑等、零件完整度得到保障。这些外观以及尺寸的精度就是质量好的体现。

工业零件作为机器生产过程中的重要部分，扮演着保证机器正常运转的重要角色。一个有缺陷的零件如果流通到市场中，轻则对公司名誉带来不好的影响，给公司带来财产上的损失。如果被用到机器中，很有可能损坏机器，重则带来人身安全，造成重大安全事故，所以对零件进行高效的质量检测很有必要，及时发现不合格产品并进行处理。传统的缺陷检测技术是人工检测，仍然存在一些问题。如：在生产速度慢的时候人工检测可以满足要求，但如果生产水平的提高，人工检测速度慢的缺点越来越明显；检测人员的判断和经验对检测结果起着重要的决定性，不同的人都有一套不同的检测标准，无法统一，不符合客观判断标准；经过长时间的劳作，人工的误检率和漏检率会显著提升，影响检测结果；对于一些微小的缺陷或者外观相似度的缺陷人工很难发现并区分，例如小凹坑与表面脏污、细小的划痕等。机器视觉结合了图像处理、计算机图形学、人工智能、模式识别等学科^[1]。近些年，随着硬件技术、图像处理技术、光源技术等等相关技术的飞速发展，机器视觉迎来了快速发展期，使得基于机器视觉的缺陷检测技术有了广泛的应用场景^[2]。机器视觉技术已不知不觉的应用到了人们身边，并影响了人们的生活和行为方式。深度学习诞生以来，被广泛应用到各个领域，包括生活、科技、军事等。例如当下热门的自动驾驶领域，人脸识别，又或者是早已经成熟的拍照搜题等。同样基于深度学习结合机器视觉的缺陷检测技术也取得了显著的进展，在提高生产质量以及生产效率，生产安全方面有很大意义。随着深度学习技术的发展，目标检测方法也得到了极大的改进。传统的目标检测方法主要基于手工设计的特征和分类器，存在着识别

精度低、对不同尺度和姿态的目标识别困难等问题。而深度学习方法通过使用卷积神经网络（CNN）等深度模型，能够自动学习特征表示和目标的位置信息，从而实现更准确和高效的目标检测。

在缺陷检测领域，深度学习方法的发展主要集中在两个方面。首先，深度学习方法能够处理各种类型的缺陷，例如表面缺陷、内部缺陷、微小缺陷等。相比传统的方法，深度学习方法能够从大量的数据中学习得到不同类型缺陷的特征表示，提高了检测的准确性和泛化能力。其次，深度学习方法能够处理复杂的场景和变化的光照条件，具有较强的鲁棒性。这使得深度学习方法在工业生产中的应用更加可靠和稳定。同时，使用机器检测可以有效解决人工检测遇到的种种问题，比如检测标准不一致，人工劳动强度大，细小缺陷难以发现等问题。因此，基于机器视觉的工业零件检测技术具有良好的应用前景。

本文研究课题以工业零件轴承座为例，通过对轴承座缺陷检测技术的研究，依托深度模型、机器视觉检测技术检测速度快和精度高等特点，采用工业相机对轴承座进行大量的数据采集，并进行数据增强，通过深度模型网络完成图像处理，然后对缺陷的部位进行类别分类和位置定位，最后结合机械臂等自动化设备实现自动分拣，避免缺陷零件流入市场、投入使用对企业形象和经济造成不良影响，防止安全事故发生，本文的研究对于推动工业生产的智能化和提高产品质量具有重要的意义。

1.2 国内外研究现状

在过去的数十年里，大量研究人员对表面缺陷检测进行了深入的研究。这些方法主要可以分为传统的表面缺陷检测方法和基于深度学习的表面缺陷检测方法。在本章中，我们就以这两个方面展开来回顾现有的表面缺陷检测及其相关技术：传统的表面缺陷检测方法、基于深度学习的表面缺陷检测方法^[3]。

1.2.1 传统的表面缺陷检测方法

图像处理技术的发展让表面缺陷检测技术上升到一个新的台阶，计算机通过对图像的处理，可以有效的提取到金属表面的缺陷特征，进而实现表面缺陷检测。传统图像处理方法主要包括图像变换、增强、分割和分类等，这些方法对单一类型

的缺陷有着较好的检测能力^[4]。传统的表面缺陷检测方法大概分为以下几步：首先对图像进行增强，这样能够突出图像的特征以及细节。其次通过边缘提取的算法对物体表面区域进行提取。最后利用分割算法检测出物体表面的缺陷。如：Hang 等人^[5]对陶瓷表面提出了一种基于邻域像素灰度阈值的缺陷检测方法，该方法通过缺陷及其邻近像素的灰度情况来判断缺陷类型，获得了良好的结果，然而由于有些缺陷与产品的边缘相连，会产生缺陷被划分到背景中从而导致错误分类的情况。Zheng 等人通过灰度转换和中值滤波对工业相机获得的活塞表面缺陷图像进行预处理，然后利用灰度直方图进行阈值分割、边缘检测和形态学处理，最后利用区域特征进行缺陷检测，实验获得了较好的结果^[6]。Lee 等人提出表面正态 Gabor 滤波器（SNGF）算法和激光扫描点云数据结合的表面缺陷检测方法^[7]。SNGF 方法使用 3D 点云数据规范化表面拓扑几何形状，然后将表面法向量转换为复数并由 Gabor 滤波器处理以提取缺陷的几何特征，最后使用纹理表面不同类型缺陷验证了 SNGF 方法的可行性。王提出一种基于背景差分和改进遗传算法最大熵的轨面缺陷分割方法，首先利用改进的列灰度均值背景图像建模方法对轨面图像进行背景建模，并将轨面图像与背景图进行差分操作以此来得到轨面差分图像，然后利用改进遗传算法的最大熵来确定差分图的最佳分割阈值并对其进行二值化处理，最后对轨面二值图进行形态学处理和滤波处理得到轨面缺陷分割图^[8]。该方法提高了缺陷分类的精度，但对于轨面存在偏转角度的情况时能否完成轨面区域的缺陷特征提取还需要进一步的研究。

除了单独的使用图像处理算法进行表面缺陷检测，还可以将图像处理算法和机器学习模型结合实现表面缺陷检测，如：Li 等人提出一种多特征融合算法用于瓷砖缺陷检测，该算法采用改进的尺度不变特征转换（Scale Invariant Feature Transform, SIFT）算法和色矩融合算法作为瓷砖图像的区域特征描述^[9]。然后根据每个特征分类的准确率，对提取的两个区域特征分别赋予各自的权重系数，实现特征的加权融合，最后将融合特征向量输入 SVM 实现表面缺陷分类。Xu 等人为实现锂电池极片表面缺陷的自动检测，提出一种基于多特征融合的 PSO-SVM 方法^[10]。首先采用图像减法和对比度调整算法对缺陷图像进行预处理，增强缺陷特征。然后，利用 Canny 算法和 AND 逻辑运算提取缺陷区域图像，并结合纹理特征、边

缘特征和 HOG 特征来提取缺陷区域特征。最后, 利用粒子群化 (Particle Swarm Optimization, PSO) 算法优化支持向量机 (Support Vector Machines, SVM) 对缺陷图像进行自动识别。实验结果表明, 该方法能够有效检测锂电池极片表面多种类型缺陷, 但是其步骤繁琐, 不适应于实际工业场景。

综上, 基于传统图像处理算法的缺陷检测方法虽能适用于低算力以及缺陷样本较少的场景, 但对于图像的质量要求较高, 光源分布不均时会导致检测结果变差。由于不同的缺陷特征对于缺陷图像的表征能力不一样, 当缺陷的种类增加时该方法的局限性也越来越大。

1.2.2 基于机器学习的表面缺陷检测方法

机器视觉检测是一种自动化性能较高的技术, 它精度高、速度快, 即使在复杂环境下, 也能够保持长时间的作业, 不仅可以应用于金属表面缺陷检测, 还可以应用于织物、陶瓷和外壳等多种产品的表面缺陷检测。目前, 基于机器视觉的表面缺陷检测方法主要有两种: 机器学习方法和深度学习方法^[11]。

机器学习通过对表面缺陷的特征进行有效提取, 然后训练模型达到缺陷分类的效果。常用的机器学习模型有: BP 神经网络 (Back Propagation Neural Network)、K 近邻算法 (K-Nearest Neighbor, KNN)、随机森林 (Random Forest, RT) 和 SVM^[12]。Liu 等人提出一种新的机器学习方法, 通过使用 Renyi 熵选择关键统计和结构特征来检测和分类金属表面缺陷, 实验结果表明该方法优于传统决策树 (Decision Tree, DT) 分类器^[13]。2022 年, Yousef 等人对金属铸件缺陷图像进行特征提取, 利用 SVM 和 KNN 模型检测金属铸件中与尺寸不平等和表面不连续相关的缺陷, 并通过改善环境条件和图像分辨率进一步提高这两种模型的检测准确率, 但该方法的智能化程度较低^[14]。Arshad 等人从每个图像中提取来自 HSV 颜色空间的 3D 颜色直方图, 使用 KNN 对钢铁表面缺陷进行分类后, 检测精度相对于直接使用 KNN 分类提升了 13%, 但该方法相比深度学习方法的检测精度差距仍然很大^[15]。

SVM 是机器学习中应用较多的模型之一, 被广泛应用于各研究领域, 通过构造出最优分类超平面, SVM 可以达到表面缺陷分类的效果, 但原始的 SVM 算法只擅长处理二分类问题, 要想在多分类问题上得到好的结果需要在模型上进行改

进。如：Singh 等人使用 ResNet-101 模型进行缺陷特征提取，结合多分类 SVM 实现缺陷检测^[16]。该方法研究了不同特征提取层和池化层的表面缺陷检测效果，实验结果表明，所提出的方法可以克服深度学习模型对大型训练数据集和更高计算能力的要求，在数据增强方法下，有效提高了圆锥滚子的三种常见表面缺陷，但是该方法在缺陷种类多时，检测精度一般。郭等人提出一种基于直方图梯度（HOG）和 Gabor 特征组合的图像特征提取算法，实验结果表明，组合特征提取后的多分类 SVM 的识别率比只采用其中一种图像特征提取方法的识别率提高了 7%以上^[17]。刘等人提出一种基于双侧滤波的降噪方法和基于差分的对比度增强算法对刀具缺陷图像进行预处理，然后通过提取形状和纹理等缺陷区域特征训练 SVM 分类器，实验结果表明，该算法的缺陷检出率为 97.2%，分类准确率为 94.3%，但是其单张检测速度为 165ms，不满足实际工业需求^[18]。Huang 等人提出一种基于 SVM 的无纺布网状表面缺陷检测方法，通过提取描述纹理参数的灰度共生矩阵的四个特征值，然后使用 SVM 进行训练，实验结果表明，该算法可以正确检测网状缺陷^[19]。

虽然机器学习算法相对于传统图像处理算法的检测效果有很大提升，但背景干扰严重时模型的检测效果明显降低。此外，大多数机器学习模型只能够实现缺陷分类，无法检测出缺陷的具体位置，需要根据具体的缺陷特征通过图像处理方法分割出缺陷本身。而工业场景中通常需要得到缺陷的位置来分析缺陷产生原因，因此使用机器学习方法检测表面缺陷存在一定的短板^[20]。

1.2.3 基于深度学习的表面缺陷检测方法

机器学习虽然在表面缺陷检测中有着较好的效果，但是随着数据量的加大，机器学习模型的性能受到限制，导致模型的泛化能力低，训练耗时长等问题。基于深度学习的表面缺陷检测技术很好地解决了上述问题，深度学习具有更强的提取特征能力，弥补了机器学习在特征提取方面的不足^[21]。目标检测技术主要是用区域级别检测方法对图像缺陷进行定位和分类，对缺陷用锚框标记。常见的目标检测算法主要分为两阶段算法和一阶段算法。常见的二阶段目标检测算法有 FasterR-CNN^[22]，CenterNet^[23]等。Hu 等人提出基于 FasterR-CNN 对印刷电路板的缺陷检测方法，克服了传统方法计算成本高和易受噪声影响等缺点^[24]。Zhang 等人提出基于

FasterR-CNN 结构的自适应缺陷检测方法,能够有效检测出 3D 打印晶格结构样品内部的微小缺陷^[25]。Ding 等人基于 FasterR-CNN 提出了 TDD-Net 对印刷电路板微小缺陷的检测,结合多层次多尺度特征金字塔,提升了对微小缺陷的检测能力^[26]。以上一些两阶段检测算法虽然具有较高的检测精度,但是在实际工业场景中除了精度,检测速度也是至关重要的。因此,出于对检测速度的需求,一些研究人员提出了一阶段的目标检测算法。常见的一阶段目标检测算法有 SSD^[27], EfficientDet^[28], YOLO 系列^[29-35]等。楼豪杰等人提出了一种基于 YOLOv4 的改进算法 SiameseYOLOv4,提升了对印刷纸盒的缺陷检测精度,但是在速度方面有着不小的损失^[36]。Zhou 等人提出了一种基于 SSD 的表面缺陷检测方法,同时具有很高的准确率和实时性^[37]。Aboah 等人实现了基于 YOLOv8 的自动头盔检测系统,利用一种被称为少样本数据采样的独特数据处理策略,在对交通视频的头盔检测具有较好的有效性^[38]。

综上所述,目前表面缺陷检测技术主要以深度学习算法为主,其中 YOLO 具有显著的优越性能,克服了很多传统方法的问题^[39]。因此,本文在结合深度学习方法的基础上,提出一种基于改进 YOLOv5 的轴承座表面缺陷检测技术,并对其自动分拣,对表面缺陷检测的智能化发展具有重要的意义。

1.3 本文研究内容和组织结构

本文针对现有的轴承座表面缺陷检测技术不完备,在工厂实际成产中的精度与实时性比较低、没有自动分拣功能的问题,提出一种基于改进 YOLOv5 的轴承座表面缺陷检测系统,包括算法改进与自动分拣。首先对轴承座表面缺陷数据集进行数据增强,保证数据充足,然后改进 YOLOv5,提高轴承座表面缺陷的检测速度和检测精度,其次与机械臂联动,使之自动分拣有缺陷样本,最后编写 UI 界面,搭建实验平台。本文的具体结构安排如下:

第一章,绪论。主要介绍本文的研究背景,指出现阶段零件表面缺陷检测算法的研究意义,其次分别以传统图像处理、机器学习、深度学习来展开说明总结表面缺陷检测算法的国内外研究现状。

第二章,基于深度学习目标检测的相关知识。介绍了卷积神经网络的各个部分

以及作用。紧接着对本文所使用的 YOLO 系列进行展开讲解。

第三章,对本文所使用的 YOLOv5s 模型进行高性能改进,使之提升检测性能;对模型进行轻量化改进,使之提升检测速度。最后进行实验验证。

第四章,对本文所使用的机械臂进行讲解并与网络模型进行联动,使整个系统进行分拣,最后编写 UI 界面,使操作更加方便,视觉效果更直观。

第五章,对本文的所做内容进行总结,以及不足之处的展望。

第 2 章 基于深度学习的目标检测理论分析

2.1 卷积神经网络组成

目前卷积神经网络在目标检测任务中得到了充分的运用。对于常见的卷积神经网络一般有三层结构，依次为输入层、隐藏层和输出层。这些层组合在一起成为了基本的卷积神经网络。本节将从输入层、隐藏层和输出层三部分展开介绍卷积神经网络的构成。




图 2.1 两层隐藏层神经网络示意图

Fig2.1 Schematic diagram of a two-layer hidden layer neural network

神经网络就是模仿生物神经系统，有很多神经元节点组成。神经元越多代表模型越庞大，性能越强。常说的神经网络层数指的是隐藏层的层数。如图 2.1 所示就是一个含有两层隐藏层的简单神经网络示意图。

根据任务的需求，我们可以增加神经网络的层数和神经元的数量，使得神经网络具有更丰富的结构。理论上层数和神经元的数量越多，模型的准确性越强，但我们不能无休止的增加这些数量，因为庞大的模型需要付出巨大的计算量，需要更高性能的设备才可以驱动运行。同时不同类型的神经网络适用于不同的应用场景。举例来说，卷积神经网络适用于图像分类、目标检测和图像分割等任务；而循环神经网络^[40]适用于自然语言处理领域的一些任务。这些不同类型的神经网络通过其特定的结构和算法，能够更好地处理对应领域的数据和问题。

目前，主流的目标检测模型都使用卷积神经网络来提取目标的特征。下面将简要介绍卷积神经网络的各个组成部分和它们的主要作用。

(1) 输入层, 作为卷积神经网络的第一层, 作用是接收输入进来的图像像素矩阵并为后续层提供合适的输入。输入图像的质量会直接影响网络的输出结果, 因此会在输入层对原始的输入数据进行一系列的数据预处理操作。

(2) 卷积层, 卷积层是卷积神经网络的核心组件, 负责对输入数据进行卷积操作, 以提取图像或特征的局部特征。卷积是一种数学运算方式, 对于两个连续函数 $f(x)$ 和 $g(x)$ 卷积的定义公式为公式(2-1)所示。若函数是离散的, 那么卷积运算定义公式为公式(2-2)所示。卷积示意图如图 2.2 所示。

$$h(t) = f(t) * g(t) = \int f(\tau)g(t-\tau)d\tau \quad (2-1)$$

$$h(n) = f(n) * g(n) = \sum_m f(n-m)g(m) \quad (2-2)$$




图 2.2 卷积示意图

Fig2.2 Convolution diagram

(3) 激活层, 激活层在神经网络中起着关键作用。它通过激活函数来判断输出值与设定的阈值之间的关系, 决定是否将输出传递给下一层的神经元。当输出值小于设定的阈值时, 激活函数会将输出置为 0, 表示当前卷积层提取到的特征不足以构成有效的特征, 因此后续卷积层也不会再提取该特征。如果不使用激活函数, 当前神经元的输入与上一层神经元的输出之间将构成线性关系。可以验证, 最终网络的输出也将是输入的线性组合。这种情况下, 模型的逼近能力非常有限, 类似于最原始的感知机模型。为了提高模型提取特征的能力, 通常引入非线性的激活函数, 对卷积层的结果进行非线性映射。这样可以使神经网络具备更强大的表达能力。

(4) 池化层^[41], 用于对输出特征图进行特征压缩, 也称为降采样。池化操作通过选择一个窗口, 然后在特征图上滑动窗口, 选择窗口内的数据并用一个单一的值代替这个区域的数据。常见的池化方式包括最大池化和平均池化。

最大池化是一种常见的池化方式, 它选择池化窗口内的最大值作为代表性值。这样得到的特征图对纹理信息更加敏感, 能够有效地提取图像的纹理特征。在网

络的浅层，通常存在较多的干扰信息，因此最大池化被广泛应用。最大池化过程示意图如图 2.3 所示。




图 2.3 最大池化过程

Fig2.3 Maximum pooling process

相比于最大池化，平均池化采用了不同的策略，使用平均算子来代替最大值。平均池化计算池化窗口内数值的平均值。这种池化方式保留了整体的数据特征，使得得到的特征图对背景信息更加敏感。在网络的深层，输入特征图已经经过浅层的筛选，包含了更多的语义信息。因此，使用平均池化更为合适，以保留整体的特征信息。如图 2.4 为平均池化的示意图。




图 2.4 平均池化过程

Fig2.4 Average pooling process

经过池化操作后，部分信息可能会丢失。然而，卷积神经网络中的特征图包含了冗余信息，并且图像特征具有一定的不变性，因此池化操作不会丢失图像的原有特征，也不会损坏模型的识别效果。池化操作只与滤波器的尺寸大小和步长有关，不涉及其他需要学习的参数。它只会增加很少的计算量，主要的作用是减小数据的空间尺寸。周期性地插入池化层可以有效降低网络的参数数量，从而节省计算资源，并在一定程度上防止模型过拟合。通过合理选择池化操作的参数，可以在减小数据尺寸的同时保留重要的特征信息。这使得网络更加高效，并能够在处理大规模图像数据时节省计算资源。

(5) 全连接层，它的每个节点都与上一层的所有节点相连接，因此被称为全

连接层。它的主要作用是将二维特征图转换为一维特征向量，实现端到端的学习过程。全连接层能够对输出进行降维，减少特征的维度。全连接层还具有降低特征位置对分类结果影响的作用，使得模型更具鲁棒性。然而，由于全连接层的参数量较大，计算量较大，因此在卷积神经网络中很少使用全连接层。

2.2 YOLOv5 模型

YOLOv5 是一种基于深度学习的目标检测模型，它是在 YOLOv4 的基础上进行改进的。YOLOv5 的网络模型由主干网、颈部网和目标检测头三个部分组成。主要改进点如下：主干网改进，YOLOv5 采用了 Focus 网络结构对主干网进行改进。Focus 网络在每个像素点进行一次采样，得到四个包含图像浅层信息的特征层，并将这四个特征层进行通道拼接。这样可以将输入图像的宽高信息集中在通道信息中，提高了特征提取的效果；数据增强改进，YOLOv5 引入了 Mosaic 数据增强方法。Mosaic 通过将四张图片进行拼接，提高了检测目标的背景复杂度。同时，在主干网标准化层中也需要同时计算四张图片的数据，以适应 Mosaic 的数据增强方式；训练效率改进，为了提高模型的训练效率，YOLOv5 增加了正样本数量。在训练过程中，每个真实框都会由多个先验框进行预测，这样可以增加正样本的数量，提高模型的训练效果。

2.2.1 基础模型

根据表（2-1）中的性能对比，可以得出以下结论：YOLOv5s 是 YOLOv5 系列中最小的模型，适用于计算资源有限的设备，如移动设备或边缘设备。它具有最快的检测速度，但相对准确度较低。YOLOv5m 是 YOLOv5 系列中的中等大小模型，它在速度和准确度之间提供了较好的平衡。适用于具有一定计算能力的设备。YOLOv5l 是 YOLOv5 系列中较大的模型，具有相对较高的准确度，但检测速度较

表 2-1 不同模型性能对比

Tab.2-1 Comparison of the performance of different models

模型	平均精度/%	推理时间/ms	参数量/M
YOLOv5s	56.7	3.2	7.24
YOLOv5m	64.1	5.2	2.12
YOLOv5l	67.1	7.9	4.76
YOLOv5x	68.7	13.7	8.68

慢。适用于需要高准确度且具备较强计算能力的设备。YOLOv5x 是 YOLOv5 系列中最大的模型，在准确度方面表现最好，但检测速度最慢。适用于需要极高准确度且具备强大计算能力的任务。根据轴承座缺陷检测对检测速度和应用场景的需求，选择参数量最小的 YOLOv5s 模型，以在计算资源有限的情况下获得较好的性能。

2.2.2 YOLOv5 网络结构

YOLOv5s 的网络结构如图 2.5 所示，主要分为三个部分：主干特征提取网络、颈部网络以及目标检测头。整个算法的流程可以概括为特征提取、特征加强和目标预测三个步骤。




图 2.5 YOLOv5 整体结构

Fig.2.5 Structure of YOLOv5

步骤一为主干特征提取网络：在 YOLOv5 的主干特征提取网络部分，使用了三个有效特征层，这些特征层是从主干网络中提取出来的。主干网络的主要功能是将原始输入图像转换为多层特征图，以供后续的目标检测任务使用。YOLOv5 采用了相对轻量级的 CSPDarknet53 主干网络结构，以在保持较高检测精度的同时尽量减少参数量和内存占用。主干网络中包含了标准卷积模块（CBS）、C3 模块和 SPPF 模块等关键结构。通过这些结构，YOLOv5 能够有效地提取图像特征，并为目标检

测任务提供高质量的特征表示。

（1）标准卷积模块（CBS）

标准卷积模块是卷积神经网络中常用的基础模块。如图 2.6 所示，标准卷积模块实现了将输入特征经过卷积层、标准化层和激活函数得到输出层的操作过程。卷积层是卷积神经网络中最基础的层之一，它用于提取输入特征中的局部特征。通过卷积操作，卷积层可以有效地捕捉输入特征的空间结构和模式。标准化层是在卷积层之后加入的结构，用于规范化神经网络中特征值的分布。它可以帮助提高网络的稳定性和收敛速度，并加速模型的训练过程。




图 2.6 标准卷积模块

Fig.2.6 CBS module

激活函数是一种非线性函数，用于给神经网络引入非线性变换能力。在标准卷积模块中，采用 SiLU（SigmoidLinearUnit）函数作为激活函数。SiLU 函数在近似线性的范围内保持平滑性，并在较大的输入值范围内饱和，有助于提高模型的表达能力。综上所述，标准卷积模块由卷积层、标准化层和激活函数组成，它是卷积神经网络中常用的基础模块，用于提取特征和引入非线性变换。

（2）瓶颈模块（Bottleneck）

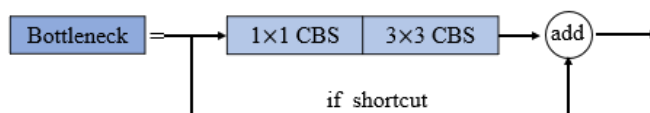


图 2.7 颈部模块

Fig.2.7 Bottleneck Module

瓶颈模块使用两个标准卷积模块对特征图的通道数进行减小（默认减半）再扩大的操作，并保持输入与输出的通道数不变。具体步骤如下：首先，通过一个卷积核大小为（1×1）的标准卷积将通道数减半；然后，通过一个卷积核大小为（3×3）的标准卷积将通道数加倍，得到最终的输出特征图。这样的设计可以减少模型的参数量和计算量，同时保持输入与输出的通道数一致。在瓶颈模块中，还可以选择是否使用直连层（shortcut）来控制是否进行残差连接。残差连接可以帮助信息在网络中更快地传递和保持梯度的稳定性，进一步提升模型的性能。通过残差连接，瓶颈模块可以更好地学习输入特征的细节和上下文信息。

如图 2.7 所示, 在 YOLOv5 模型的主干网络中, 瓶颈模块的直连层参数默认为 True。该模块首先通过包含 (1×1) 卷积层的标准卷积模块进行特征变换, 然后再通过包含 (3×3) 卷积层的标准卷积模块进行进一步的特征提取。最后, 通过残差结构将瓶颈模块的输出与初始输入进行特征融合。在特征融合过程中, 采用像素叠加操作 (add) 而不是通道拼接 (Concat) 来进行特征融合。然而, 在目标检测头中的瓶颈模块中, 并没有添加残差结构, 直连层参数默认为 False。这意味着目标检测头中的瓶颈模块不进行特征融合的操作, 直接将输出传递给后续的目标检测任务。

(3) C3 模块




图 2.8 C3 模块

Fig.2.8 C3 Module

YOLOv5 主干网络中的 C3 模块是通过改进 YOLOv3 主干网络中的 CSP 模块而来, 两者的结构基本相同, 但在修正模块的选择上有所不同。C3 模块由三个标准卷积层和多个瓶颈模块组成, 瓶颈模块的数量取决于配置文件中的检测类别数量和网络模型的深度两个参数的乘积。C3 模块是模型对残差特征进行学习的主要模块, 其主要作用是增加网络的深度和感受野, 提高网络的特征提取能力。根据图 2.8 所示, C3 模块由三个标准卷积模块构成。其中, 第一个标准卷积模块的步幅为 2, 可以将特征图的尺寸减半; 后两个标准卷积模块的步幅为 1。C3 模块中的标准卷积模块都采用 (3×3) 的卷积核。

(4) 快速金字塔池化模块 (Spatial Pyramid Pooling-Fast, SPPF)

空间金字塔池化 (SPP) 模块通过三个不同大小的最大池化操作对输入进行降维, 并在通道数上进行拼接, 从而在一定程度上解决了目标多尺度的问题。如图 2-

9 (a) 所示, SPP 模块首先通过一个标准卷积模块将输入的通道数减半。然后, 分别对输入进行卷积核大小为 5、9 和 13 的最大池化操作, 并对不同的卷积核大小进行自适应填充。最后, 将三次最大池化的结果与未经池化操作的数据进行通道数拼接 (Concat) 操作, 最终输出的特征图的通道数是原来的两倍。




图 2.9 SPP 与 SPPF 模块

Fig.2.9 Structure of SPP and SPPF

快速金字塔池化模块对金字塔池化模块的结构进行了改进, 以提高模型的效率。该模块采用了三个串联的最大池化层, 用于提取更深层次的特征图, 并通过拼接操作对特征图进行融合。如图 2-9 (b) 所示, 快速金字塔池化模块先经过标准卷积模块, 然后进行一次、两次和三次池化操作, 得到多个池化后的特征图。这些特征图经过通道数拼接后, 再利用标准卷积模块提取特征。在快速金字塔池化模块中, 尽管特征图经历了多次池化操作, 但其尺寸和通道数没有发生变化。因此, 池化后的输出特征图可以在通道维度上进行融合。

步骤二为颈部网络: 为了处理不同尺度和大小的目标, 需要一种机制来提取多尺度的特征。在 YOLOv5 中, 颈部网模块结合了 FPN 和 PAN 的功能, 通过在主干网中添加不同尺度的特征层来实现多尺度融合特征提取。颈部网模块由标准卷积模块、上采样模块 (Upsample)、通道数拼接 (Concat) 和不带直连层 (shortcut=False) 的 C3 模块构成。它将 FPN 和 PAN 结合在一起, 通过上采样和下采样操作将不同层次的特征图融合, 生成多尺度的特征金字塔。FPN 采用自顶向下的侧边拼接结

构，将不同尺寸特征层的输出进行融合，构建高级语义特征图，形成特征金字塔的经典结构。而特征金字塔中的底层特征图信息已经非常稀疏，为了解决这个问题，YOLOv5 在颈部网中引入了 PAN，通过不断上采样操作来弥补特征融合过程中特征图信息稀疏衰减的问题。特征金字塔自顶向下传递强语义特征，通过上采样和与更粗粒度的特征图融合来实现不同层次特征的融合。PAN 则自底向上传递定位特征，通过卷积层融合不同层次的特征图。具体而言，PAN 包括以下三个步骤：（1）对最底层特征图进行卷积，得到更丰富的特征表达；（2）将卷积后的特征图与上一层特征图融合，得到更丰富的特征表达；（3）重复以上两个步骤，直到达到最高层。最后，在颈部网的最后阶段，将自顶向下部分和自下向上部分的特征图进行融合，得到最终的特征图，作为目标检测头的输入用于目标检测。如图 2.10 所示。

步骤三为目标检测头：检测头是 YOLOv5 模型的输出端，其主要功能是在不同尺度的特征图上利用基于网格的预测框进行目标检测。检测头的输出包括三种预测框：置信度、类别概率和边界框位置。




图 2.10 特征金字塔+路径聚合网络结构

Fig.2.10 Structure of Feature pyramid and path aggregation network

每个预测框的含义如下：置信度：表示该框内是否存在目标的概率，取值范围为 0 到 1。类别概率：表示该框内目标属于各个类别的概率，通常是预先定义好的类别数量。边界框位置：表示目标的位置和大小，一般用矩形框来表示。损失函数在图像检测中起着重要作用，它衡量了模型预测的精确度。损失函数的大小反映了手绘框与真实框之间的相似度、重叠度以及偏差值。选择适当的损失函数对于验证

模型的精确度至关重要。损失函数的收敛性可能快也可能慢，因此选择合适的损失函数对于训练模型的性能和准确度非常重要。

2.2.3 定位损失函数

在 YOLOv5 中，损失函数可分为三种，分别为定位损失函数(localizationloss)、分类损失函数(classificationloss)和置信度损失函数(confidenceloss)。整体的损失为上述三种函数加权相加，通过改变加权值可以调整对三者损失的关注度。

$$Loss_{YOLOv5} = \alpha \cdot L_{CioU} + \beta \cdot L_{conf} + \gamma \cdot L_{cla} \quad (2-3)$$

式中： $Loss_{YOLOv5}$ 为网络模型的整体损失函数值， L_{cla} 为网络模型的分损失函数值， L_{conf} 为网络模型的置信度损失函数值， L_{CioU} 为网络模型的定位损失函数值， α 、 β 和 γ 为不同函数的加权值。分类损失函数和置信度损失函数默认使用二元交叉熵计算。而定位损失函数则采用完全交并比(Complete-IoU, CIOU)计算预测边框的定位损失。CIOU 损失函数是在传统的交并比(IoU)基础上改进而来，它考虑了三个重要的目标框回归函数的几何因素，包括重叠面积、中心点距离和长宽比。交并比系列损失函数的原理和优缺点将在本小节中详细介绍。

(1) 交并比(IntersectionoverUnion, IoU)

如图 2.11 所示展示了传统的交并比函数，它是本文在检测中衡量检测准确性的一个标准，用来表示真实框和预测框的相关程度，相关程度越高其值越高，代表越准确，反之则不准确。




图 2.11 交并比

Fig.2.11 IoU

如图 2.11 (a) 所示，其中绿色边框内区域代表网络模型的预测框，代表预测框 B_{gt} ，红色边框内部的区域代表人为数据标注的真实情况，代表真实框 B 。图 2.11 (b) 中的浅蓝色部分表示预测框 B_{gt} 与真实框 B 的交集，图 2.11 (c) 橙色部分表

示预测框 B_{gt} 与真实框 B 的并集。

顾名思义,交并比的定义为上述的交集与并集的比值,交并比不光能评估算法模型边界框预测的准确性,还用于非极大抑制值(NMS)中,NMS 通过比较不同框的 IoU 值来选取高置信度的边界框,减少冗余的检测结果。同时交并比具有非负性、对称性、不受尺度影响的特性,即不受目标尺度变化的影响,这个特性使得其在检测中具有一定的鲁棒性。交并比和交并比的损失函数 L_{IoU} 的表达式如式(2-4)和式(2-5)所示

$$IoU = \frac{|B \cap B_{gt}|}{|B \cup B_{gt}|} \quad (2-4)$$

$$L_{IoU} = 1 - IoU = 1 - \frac{|B \cap B_{gt}|}{|B \cup B_{gt}|} \quad (2-5)$$

如图 2.12 所示,交并比在下面这两种情况下存在缺陷:如果真实框 B 与预测框 B_{gt} 没有相交,根据交并比的定义,此时的 $IoU = 0$,没有办法反映出真实框 B 与预测框 B_{gt} 之间的距离,进而导致模型没有梯度回传从而无法进行学习训练;图 2.12 (b) 与图 2.12 (c) 所示,此时两种情况的交并比相等,但是可以看出来差异比较大,图 2.12 (b) 的预测情况明显优于图 2.12 (c) 的预测情况,因此,此时交并比无法精准反映出真实框 B 与预测框 B_{gt} 的重合程度。




图 2.12 交并比特殊情况

Fig.2.12 Special case of IOU

(2) 广义交并比 (GeneralizedIoU,GIoU)

广义交并比在交并比的基础上考虑了并集以外的面积比例,即通过建立预测框与真实框的最小外接矩形包围他们,使其能够更好的捕捉边界框的位置信息。如图 2.13 (a) 所示,红色边框内区域为人工标注的真实框 B_{gt} ,绿色线内的区域为网络模型预测的预测框 B 。图 2.13 (b) 的灰色部分为真实框 B_{gt} 与预测框 B 的并集

C, 图 2.13 (c) 中蓝色区域为并集 C 在最小外接矩形下的补集, $|C - (B \cap B_{gt})|$ 。




图 2.13 广义交并比

Fig.2.13 GIoU

广义交并比的定义公式如式(2-6)和式(2-7)所示, 广义交并比与交并比一样具有尺度不变性, 当同一目标进行同比例放大或者缩小时, 其值大小依旧不变, 无需模型对不同尺度的目标进行边界框处理。

$$GIoU = IoU - \frac{|C - (B \cap B_{gt})|}{|C|} \quad (2-6)$$

$$L_{GIoU} = 1 - GIoU = 1 - IoU + \frac{|C - (B \cap B_{gt})|}{|C|} \quad (2-7)$$




图 2.14 广义交并比特殊情况

Fig.2.14 Special case of GIoU

相比于交并比, 广义交并比考虑了边框的位置, 当边界框的位置远离目标时 $GIoU$ 的值还会相应的减小, 从而更准确的反应边界框的位置信息。如图 2.14 (a) 和图 2.14 (b) 所示, 真实框与预测框没有交集时, 此时 $IoU = 0$, 无法确定两个框之间的距离对值的影响, 随着两个框的之间距离越来越远, 会导致广义交并比无限趋于负一, 从而导致广义交并比的损失函数变大。图 2.14 (c) 所示, 当两个框呈

现此种位置时，两个框的交集在最小外接矩形集合下的补集 $|C - (B \cap B_{gt})|$ 为 0，此时广义交并比退化为交并比。

(3) 距离交并比 (Distance-IoU, DIoU)

距离交并比把广义交并比的并集与其在最小外接矩形下并集补集的比值惩罚项改为真实框中心点与预测框中心点的欧氏距离与最小外接矩形框对角线距离比值的平方，从而解决了广义交并比的缺陷。




图 2.15 距离交并比

Fig.2.15 DIoU

如图 2.15 所示为距离交并比的原理图，图 2.15 (a) 红色区域为人为标注的真实框 B_{gt} ，绿色区域为网络模型预测的预测框 B 。图 2.15 (b) 中黑色实线为真实框中心点与预测框中心点的欧氏距离 ρ ，图 2.15 (c) 为真实框和预测框最小外接矩形的对角线距离 c ，距离交并比的表达式与损失函数如式(2-8)和式(2-9)所示。

$$DIoU = IoU - \frac{\rho^2(b, b^{gt})}{c^2} \quad (2-8)$$

$$L_{DIoU} = 1 - DIoU = 1 - IoU + \frac{\rho^2(b, b^{gt})}{c^2} \quad (2-9)$$

式中：

ρ ---- 预测框 B 的中心点 b 与真实框 B_{gt} 的中心点 b^{gt} 之间的欧氏距离；

c ---- 预测框与真实框的最小外接矩形对角线的距离。

如图 2.16 所示，距离交并比也有缺陷，上述三种情况中预测框的中心点与真实框的中心点保持位置不变，但不难看出三种情况的预测准确性天差地别，所以此种情况时距离交并比失去了它的作用，没有考虑到宽高比。




图 2.16 距离交并比特殊情况

Fig.2.16 Special case of DIOU

(4) 完全交并比 (Complete Intersection over Union, CIOU)

完全交并比损失函数在距离交并比的基础上在惩罚项中增加了能够反映检测框尺度的宽高比,使得预测框更加符合真实框。完全交并比的损失函数表达式如式(2-10)所示。当然完全交并比也有一定缺陷,其比对边界框的位置、尺度和形状信息更敏感。这可能导致在边界框稍微变化时,值可能会有较大的变动。这种敏感性可能使得在某些情况下对于边界框的评估不够稳定。同时其未考虑低质量样本和高质量样本对损失贡献不平衡的问题。

$$L_{CIOU} = L_{DIOU} + \alpha V = 1 - IoU + \frac{\rho^2(b, b^{gt})}{c^2} + \alpha V \quad (2-10)$$

$$V = \frac{4}{\pi^2} \cdot \left(\arctan \frac{w_{gt}}{h_{gt}} - \arctan \frac{w}{h} \right)^2 \quad (2-11)$$

式中:

α ----权重值; V ----检测框的宽高比。

2.3 本章小结

本章从目标检测的相关知识出发,介绍了卷积神经网络的组成:输入层、卷积层、激活层、池化层以及全连接层的作用及原理。在本章的第二小节中首先对YOLOv5的不同模型进行了对比,对比了不同型号模型的检测精度、推理时间以及参数量,并且根据本文所研究内容的实际情况结合模型的情况选出了本文的基础模型YOLOv5s。紧接着对YOLOv5s网络结构进行讲解。分别对模型的主干提取网络、颈部网络和目标检测头三部分进行原理讲解。同时对主干提取网络中用到的

标准卷积模块、瓶颈模块、C3 模块以及快速金字塔模块进行了详细说明。同时对下一章所用的损失函数进行分类说明。说明了损失函数在网络中的作用以及重要性。举例说明了交并比、广义交并比、距离交并比以及完全交并比的区别和各自的优缺点，为下一章更改损失函数打下基础。

第 3 章 基于改进 YOLOv5 的高性能与轻量化模型

经过第二章的 YOLOv5 模型介绍，本章将使用改进的 YOLOv5 模型对轴承座表面缺陷数据集进行检测。为提高轴承座表面缺陷检测精度，需要对数据集进行增强，增加数据的多样性，防止过拟合，增加模型的鲁棒性。同时对模型的损失函数进行改进，降低低质量样本对模型的影响，提升模型检测精度与性能。注意力机制在深度学习中是一个很重要的模块，通过添加注意力机制，能使模型更加关注目标区域，更好的提取重要特征信息并赋予较高权重。本章介绍了 SE、CBAM、和 CA 三种注意力机制并将 CA 注意力机制引入 YOLOv5s 模型中，提升对小目标的检测能力，增加检测精度。最后使用轻量化卷积层代替原始标准卷积层，降低模型计算量，降低模型大小，使模型更加轻量化。综合上述多方面改进，本章最终提出了 YOLOv5s-WGCA 轴承座表面缺陷检测模型。

3.1 注意力机制




图 3.1 注意力机制分类

Fig.3.1 Category of attention mechanism

注意力机制是深度学习模型中的重要组成部分。它通过使网络模型更加关注输入图像的特定部分特征，并为其分配更高的权重，以达到忽略不相关特征信息的目的。注意力机制可以分为通道注意力、空间注意力、时间注意力、分支注意力、通道-空间注意力和空间-时间注意力^[42]。这种机制的应用可以提高模型对关键特征的捕捉能力，增强模型的表达能力和性能，六种注意力机制模型如图 3.1 所示。

通道注意力机制可以根据需要自适应地确定关注的对象，并为不同通道分不同的权重。空间注意力机制能够在空间中自动捕捉输入数据的重要区域特征，并确保在进行裁剪、平移或旋转等操作后，获得与原始图像相同的结果。时间注意力机制则适用于时序数据，可以看作是一种动态的时间选择机制。分支注意力机制用于分支结构中，为不同分支分配不同的权重。通道-空间注意力机制将通道注意力和空间注意力有效地结合在一起。空间-时间注意力机制综合考虑了时域注意力和空间注意力机制，提出了混合注意力机制，主要应用于视频检测领域^[43]。

3.1.1 SE 注意力机制




图 3.2 SE 注意力机制

Fig.3.2 SE attention

SENet 是通道注意力机制的代表作，它在 CNN 中引入一个新的 SE 模块，建立了不同卷积特征通道之间的关联性，在增加少量参数的情况下使网络模型的资源分配合理，达到大幅提升网络性能的目的^[44]。为了表示每个通道与关键信息的关联性，SE 注意力机制通过为每个通道分配不同的权重来选择出重要的信息。这样可以使网络模型整体增加对关键特征的权重，同时降低无关特征的影响。SE 注意力是一个嵌入式可移植的模块，能够应用在不同的网络模型中，并且都得到了理想的结果^[45]，SE 注意力机制的结构图如图 3.2 所示。由图可知 SE 注意力机制的原理可以分为两个步骤：压缩（squeeze）和激励（excitation）。

SE 注意力首先对输入图像 X 经过特征提取网络 F_{tr}，将其转换为特征图 U。然后，通过全局平均池化（GlobalAveragePooling, GAP）操作，将特征图 U 的维度从 H×W 变为 1×1，同时保持输入通道数不变。这样做可以将二维的特征图转化为一个常量，从而表示全局感受野，其计算公式如下：

$$z_c = F_{sq}(u_c) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W u_c(i, j) \quad (3-1)$$

式中:

z_c ----第 c 个通道的压缩权重;

$u_c(i, j)$ ----输入的特征图 U 的第 i 行 j 列的像素点。

(1) 压缩 (squeeze)

压缩 (squeeze) 部分的作用顾名思义就是将输入的特征图 U 压缩到一个向量中, 把原本具有宽度高度的特征图进行降维。具体而言, 压缩部分通过全局平均池化操作把每个通道的特征值汇总到一个标量上, 接着使用全连接层把他映射到一个小的向量上, 这个向量就表示了每一个通道的全局统计信息。通过压缩操作, SENet 可以提取不同通道之间的关系, 进而提升图像处理的精度。

(2) 激励 (excitation)

通过使用压缩的方法, 网络有了描述全局的特征。但是为了抓取到不同通道之间的关系, 还需要引入另一种新的运算。这种运算需要满足两个方面: 首先, 它需要具备灵活性, 能够学习到不同通道之间的非线性关系; 其次, 它需要能够处理多个通道的特征, 而不仅仅适用于独热码形式的特征表示。为了满足上述要求, SENet 采用一种称为 sigmoidgating 机制的方法, 其公式如式(3-2)所示。

$$s = F_{ex}(z, W) = \sigma(g(z, W)) = \sigma(W_2 \text{ReLU}(W_1 z)) \quad (3-2)$$

这种方法能够学习到不同通道之间的关系, 并且能够处理多个通道特征, 从而提升图像处理的精度。通过引入这种运算, SENet 可以更好地提取不同通道之间的关系, 从而进一步优化图像处理的效果。

式中: $W_1 \in R^{\frac{C}{r} \times C}$; $W_2 \in R^{C \times \frac{C}{r}}$ 。

为了提高模型的泛化能力并减小复杂度, 在 SE 注意力机制中使用了一种特殊的结构, 即 bottleneck 结构, 它包括两层全连接层。其中, 第一层全连接层具有降维的功能, 降维系数 r 是一个超参数。结构上, 首先对特征进行降维, 然后应用 ReLU 激活函数进行处理。最后, 通过另一层全连接层将特征恢复到原始维度。这种结构有效地降低了模型的复杂度, 并且可以通过调整超参数 r 在性能和复杂度之间达到平衡

在该结构中,紧接着是一个增维层,该层将特征的维度返回到转换输出 U 的通道维度。在这个层中,将学习到的各个通道的激活值与 U 上的原始特征相乘。通过这种方式,能够更好地提取不同通道之间的关系,进而提高模型的精度。最后,该块的输出经过公式(3-3)进行重新缩放,得到最终的输出 U 。这种结构能够有效地提高模型的性能,并且可以通过调整不同的超参数来平衡模型的性能和复杂度。引入这种结构使模型能够更好地提取特征,从而进一步提高图像处理的精度。

$$\tilde{X} = Fscale(u_c, s_c) = s_c \cdot u_c \quad (3-3)$$

其中 $\tilde{X} = [\tilde{x}_1, \tilde{x}_2, \dots, \tilde{x}_c]$, $Fscale(u_c, s_c)$ 是指标量 s_c 和特征图 u_c 之间的通道相乘。

整个操作实际上可以被视为一种学习各个通道权重系数的过程。通过这种方式,模型能够更好地利用每个通道所提供的信息,从而提高对图像特征的辨别能力。这种过程类似于一种注意力机制,可以有效地提高模型的性能。通过引入这种机制,在主干网络中加入 SE 模块可以加强整体的通道特性,并进一步提高图像处理的精度。

3.1.2 CBAM 注意力机制

CBAM 模块的全称为 ConvolutionalBlockAttentionModule^[46], 其结构如图 3.3 所示。




图 3.3 CBAM 注意力

Fig.3.3 CBAM attention

CBAM 注意力模块是一种能够在通道和空间维度上进行注意力机制的方法。它由两个子模块组成:通道注意力模块(CAM)和空间注意力模块(SAM)。相比 SEBlock 而言,CBAM 注意力模块的一个显著改进是增加了一个空间注意力模块。通道注意力模块和 SEBlock 类似,都通过共享一个多层感知机(MLP)来提取特征,并通过最大池化操作增强特征的表征能力。在通道注意力模块中,该部分与空

间注意力模块的输出相加，并经过 Sigmoid 激活函数处理。在空间注意力模块中，利用不同尺度的卷积核处理特征图，以捕捉不同大小的空间信息。通过引入这两个注意力子模块，CBAM 注意力模块能够更好地提取不同通道之间的关系，并处理不同尺度的空间信息，从而提高模型的性能。

(1) CAM 结构

CAM 通道注意力模块如图 3.4 所示。




图 3.4 通道注意力

Fig.3.4 Channel attention

相较于 SEBlock，CBAM 模块在通道注意力部分加入了一个并行的最大池化层。通道注意力部分的结构与 SEBlock 基本相同，只是增加了一个分支的最大池化层。在该部分中，通过共享一个 MLP 来提取特征，并通过最大池化层增强特征的代表能力。最后，将通道注意力部分和空间注意力部分的输出相加，并经过 Sigmoid 激活函数处理，如公式(3-4)所示。通过这种方式，该模块能够更好地提取特征，并处理不同尺度的空间信息，进一步提高图像处理的精度。

$$\begin{aligned}
 M_c(F) &= \sigma \left(\text{MLP} \left(\text{AvgPool}(F) \right) + \text{MLP} \left(\text{MaxPool}(F) \right) \right) \\
 &= \sigma \left(W_1 \left(W_0 \left(F_{avg}^c \right) \right) + W_1 \left(W_0 \left(F_{max}^c \right) \right) \right)
 \end{aligned} \quad (3-4)$$

式中：

$W_0 \in R^{\frac{C}{r} \times C}$ 和 $W_1 \in R^{C \times \frac{C}{r}}$ 表示两层 MLP 的权重，二者共享权重并使用 RULE 激活函数；

r 为中间通道 reduction 的比例。

(2) SAM 结构

该模块的具体结构如图 3.5 所。

该结构首先对输入的特征图进行通道层面上的压缩操作，通过平均池化和最

大池化在通道维度上执行均值和最大值运算，得到两种二维特征。然后，将这两




图 3.5 空间注意力

Fig.3.5 Spatial attention

种特征按通道维度进行拼接，形成一个通道数为 2 的特征图，并使用带有单个卷积核图层的卷积操作。为了确保最终的特征和输入的特征图在空间维度上一致，使用特定的计算公式(3-5)。由于这种简单的结构能有效处理各种尺度的空间信息，从而提高图像处理的准确性。

$$M_C(F) = \sigma \left(f^{7*7} \left(\left[\text{AvgPool}(F); \text{MaxPool}(F) \right] \right) \right) = \sigma \left(F^{7*7} \left(\left[F_{\text{avg}}^s; F_{\text{max}}^s \right] \right) \right) \quad 3-5$$

式中：σ ----sigmoid 函数； f^{7*7} ----7*7 的卷积核； $F_{\text{avg}}^s \in R^{1*H*W}$ 和 $F_{\text{max}}^s \in R^{1*H*W}$ 是最

大池化操作和平均池化操作在通道维度上操作后的表现。

3.1.3 CA 注意力机制

CA 注意力机制全称为 CoordinateAttention^[47]，由上述两个已知注意力机制可知，SE 注意力机制只有通道信息，忽略了位置信息，而 CBAM 注意力对长距离依赖关系不能很好的捕捉，因此，Hou 等人提出 CoordinateAttention (CA) 注意力，对 CA 注意力进行了创新，类似于 CBAM 注意力一样，在通道注意力中嵌入位置信息，从而避免位置信息在二维全局池化中丢失。这种方式能够保留位置信息，同时能够捕捉长距离的依赖关系，从而提升注意力机制的效果。其结构图如图 3.6 所示。CA 注意力将通道注意力分解成 X 和 Y 两个一维特征，然后按照每个通道进行平均池化，按照 X 和 Y 轴方向进行池化编码，从而得到两个一维特征图 $C \times H \times 1$ 和 $C \times 1 \times W$ ，这种特征图能够很好的提取输入特征在一个长距离方向上的长距离相关特征，能够让注意力机制更加准确地定位目标，提升准确性。CA 注意力可以将一个任意中间向量 X 转换成带有重要特征信息的向量 Y。

CA 注意力首先是坐标信息嵌入，将输入的 $H \times W \times C$ 大小的特征图在空间维度

上进行全局平均池化操作，得到水平方向特征图 X 和竖直方向特征图 Y 。水平方向使用的池化核大小为 $H \times 1$ ，得到的特征图 X 为 $H \times 1 \times C$ ；竖直方向的池化核大小为 $1 \times W$ ，得到的特征图 Y 为 $1 \times W \times C$ ，其计算方式如式(3-6)和式(3-7)所示。

$$Z_c^h(h) = \frac{1}{W} \sum_{i=0}^W x_c(h, i) \quad (3-6)$$




图 3.6 CA 注意力机制

Fig.3.6 CA attention

$$Z_c^w(w) = \frac{1}{H} \sum_{j=0}^H x_c(j, w) \quad (3-7)$$

式中：

$Z_c^h(h)$ 和 $Z_c^w(w)$ 分别为水平方向和竖直方向上全局平均池化的结果；

x_c ----输入的特征向量。

CA 注意力机制其次的操作是注意力的生成操作，对于之前生成的 X 和 Y 两个特征图在空间上进行拼接操作，通过 1×1 的卷积核进行卷积操作从而降维，紧接着经过归一化 BN 层得到了特征图 f ，大小为 $C/r \times 1 \times (W+H)$ 。如式(3-8)所示

$$f = \sigma(F_1([z^h, z^w])) \quad (3-8)$$

式中：

F_1 ----通过 BN 层计算出的结果；

f ----对水平方向和竖直方向进行了编码得到的中间特征图，操作与第一步操

作一样，把 f 在空间维度上进行特征图分解，分解出 f_h 和 f_w 两个特征图，紧接着通过激活函数 Simoid 进行操作，从而得到水平方向注意力权重 g^h ，大小为 $C \times 1 \times W$ ，竖直方向注意力权重 g^w ，大小为 $C \times H \times 1$ ，其计算公式如式(3-9)和(3-10)所示：

$$g^h = \sigma(F_h(f^h)) \quad (3-9)$$

$$g^w = \sigma(F_w(f^w)) \quad (3-10)$$

式中：

F_h 和 F_w 是将特征图 f_h 和特征图 f_w 转化为同维度的变换函数：

CA 注意力机制的最后一步操作是特征图修正操作，将上述得到的两个注意力权重 g^h 和 g^w 转换为与一开始输入特征一样的大小，即 $C \times H \times W$ ，紧接着与输入的特征对应元素相乘，即残差连接，最后得到注意力特征，如式(3-11)所示

$$y_c = x_c \times g^h \times g^w \quad (3-11)$$

3.2 损失函数的改进

前面已经介绍了一部分损失函数，各有各的优缺点。在模型进行训练的过程中存在一定低质量样本，目前使用的主流损失函数 CIoU 等引入了几何因子会使低质量样本的惩罚项变大，从而影响模型的检测性能与泛化能力。当目标的边界框与锚框能够很好的重合时，性能良好的损失函数应该降低几何因子惩罚项的惩罚力度，尽量减少在训练中的干预，使模型能够有更好的性能与泛化能力。为解决上述问题，本文采用 Wise-IoU(WIoU)第三个版本作为定位损失函数^[48]。动态非单调聚焦机制使用“离群度”替代 IoU 对锚框进行质量评估，并提供了明智的梯度增益分配策略。该策略在降低高质量锚框的竞争力的同时，也减小了低质量样本产生的有害梯度。这使得 WIoU 可以聚焦于普通质量的锚框，并提高检测器的整体性能。定义离群度以描述锚框的质量，其定义如式(3-12)所示。式(3-13)中 L_{WIoUv1} 没有引入新的度量参数，有效的消除了如纵横比等影响模型收敛的阻碍因子； L_{WIoUv2} 解决了模型训练后期训练速度缓慢的问题。

$$\beta = \frac{\mathcal{L}_{IoU}^*}{\mathcal{L}_{IoU}} \in [0, +\infty) \quad (3-12)$$

式中:

$\overline{\mathcal{L}_{IoU}}$ ---动态滑动平均值; L_{IoU}^* ----从计算图中分离的结果。

β 越小代表锚框质量越高, 在值小和值大时都应对其分配较小的梯度增益, 降低其对边界框回归的影响。WIoUv3 损失函数如下式:

$$\left\{ \begin{array}{l} L_{WIoUv1} = R_{WIoU} L_{IoU} \\ R_{WIoU} = \exp \left(\frac{(x - x_{gt})^2 + (y - y_{gt})^2}{(W_g^2 + H_g^2)^*} \right) \\ L_{WIoUv2} = \left(\frac{\mathcal{L}_{IoU}^*}{\mathcal{L}_{IoU}} \right)^\gamma L_{WIoUv1} \\ \mathcal{L}_{WIoUv3} = r \mathcal{L}_{WIoUv1} \\ r = \frac{\beta}{\delta \alpha^{\beta - \delta}} \end{array} \right. \quad (3-13)$$

式中: W_g 和 H_g 为最小外接矩形尺寸; W_g 和 H_g 从计算图中分离出来用*表示; r 为梯度增益; δ 与 α 为超参数。

当 $\beta = \delta$ 时 $r = 1$, 当离群程度满足 $\beta = C$ (C 为定值) 时, 锚框获得最高的梯度增益。

由于 $\overline{\mathcal{L}_{IoU}}$ 是动态的, 锚框质量划分标准也是动态的, 所以 WIoUv3 每时每刻都能做出最符合当前情况的梯度增益分配策略, 聚焦普通质量的锚框, 重点关注中心的距离, 提高模型的定位性能。

3.3 模型轻量化改进

目前的目标检测算法为了保证获取高准确率的检测效果绝大多数会使用庞大且复杂的网络模型, 但是这类算法的计算量和参数量会很巨大, 导致检测速度低, 检测效率慢, 影响生产效率。同时在模型部署时, 或者在便携设备上使用时局有很大难度。为了解决上述问题很多研究者提出了参数量更少, 计算量更低, 结构更简单的轻量化目标检测模型, 仅需要占用很小的内存和很少的计算资源就更获得更快的推理速度, 更适合工业检测和部署。针对 YOLOv5 网络模型的网络结构复杂、网络结构参数量大、计算量大、检测效率低的问题, 本节在前两节提升检测性能而

改进的 YOLOv5s 网络模型的基础上, 对其进行轻量化改进, 在保持第三章较优检测精度的同时, 减小网络模型的参数量和计算量, 从而是网络模型更加轻量化, 提升检测速度。

3.3.1 深度可分离卷积

深度可分离卷积 (DepthwiseSeparableConvolution, DSC) 最早出现在 Sifre 的文献 “Rigid-MotionScatteringforTextureClassification” 中。在 2017 年, Howard 等人将其作为核心结构应用于轻量化网络模型 MobileNet 中, 取得了显著的轻量化效果。深度可分离卷积通过将卷积操作拆分为深度卷积和点卷积两部分来构建网络结构, 具体过程如图 3.7 所示。首先, 对输入通道执行深度卷积, 然后通过点卷积对输出通道进行融合。这种方式可以减少计算量和参数量, 从而实现轻量化模型的设计。




图 3.7 深度可分离卷积原理图

Fig.3.7 Deplyly separable convolution schematic

如图 3.7 所示, 深度卷积比正常标准卷积计算更加简单, 首先对输入特征图的每个通道都使用一个卷积核进行卷积, 然后将所有卷积的结果进行拼接从而形最终的输出结果。如图所示假设输入特征图的空间尺寸大小为 (H 和 W 分别为特征图的宽度和高度, M 为输入通道数, 卷积核的尺寸为 $K \times K$, N 为输出的卷积通道数, 则深度卷积的计算总量为 , 输出的特征图大小为 。

点卷积与标准卷积的运算很相似, 它的卷积核尺寸为 1×1 , 主要作用的自由改变输出的通道数, 同时对深度卷积输出的特征图在深度上进行加权融合。点卷积的计算总量为 $H \times W \times M \times N$ 。

深度可分离卷积就是将深度卷积和点卷积在卷积过程中进行线性排列，它的计算量也为深度卷积和点卷积线性排列和，计算公式为：

$$S_{DSC} = H \times W \times K^2 \times M + H \times W \times M \times N \quad (3-14)$$

标准卷积的计算量总量为：

$$S = H \times W \times K^2 \times M \times N \quad (3-15)$$

深度可分离卷积和标准卷积的比值为：

$$\frac{S_{dsc}}{S} = \frac{1}{N} + \frac{1}{K^2} \quad (3-16)$$

由此可见深度可分离卷积的计算量远远小于标准卷积的计算量。

3.3.2 GSCnov

轻量化模型的设计主要旨在通过优化卷积方式来实现更高效的计算，同时在保持网络相对优异性能的前提下，尽可能减少网络结构的参数数量。然而，在实际应用中，一些轻量化模型如 Xception、MobileNets 和 ShuffleNets 在提高检测器速度方面取得了显著进展，但在精度方面存在一定的缺陷。深度可分离卷积的计算过程忽略了输入通道之间的相关性，将提取的特征进行分离，导致网络的特征提取和融合能力较传统卷积方式低很多。虽然 Xception、MobileNets 和 ShuffleNets 等模型提出了一些缓解这一缺陷的方法，但却增加了更多的计算资源的消耗。




图 3.8 GSCConv 原理图

Fig.3.8 GSCConv schematic

如图 3.8 所示，GSCnov 是一种由标准卷积、深度可分离卷积和 Shuffle 操作混合在一起的混合卷积。

首先对输入进来的原始图像进行标准卷积下采样操作，紧接着用 DWConv 深度卷积进行操作生成新的结果，最后使用拼接操作使两个卷积生成的结果按顺序拼接起来，最后使用 Shuffle 洗牌操作，按照一定顺序使将标准卷积生成的信息渗透到深度可分离卷积生成的信息中。这种方法使得来自 SC 的信息完全混合到 DSC 的输出中，最大限度减少了 DSC 缺陷对模型的影响且有效利用 DSC 的优势。但如




图 3.9 GSConv 效果图

Fig.3.9 GSConv renderings

果模型所有阶段都使用 GSConv，会使模型的网络层更深，从而加剧对数据流的阻力，增加推理时间。特征图到 neck 时通道维度最大，宽度维度最小，不需要再进行变换，所以在 neck 使用 GSConv 效果最好。GSConv 的计算总量为：

$H \times W \times K^2 \times \frac{N}{2} (M+1)$ 。如图 3.9 所示。展示了标准卷积，深度可分离卷积和 GSConv 卷积的特征图。图中的 GSConv 与标准卷积的相似度明显强于深度可分离卷积与标准卷积的相似度。

3.4 实验结果分析

3.4.1 数据集制作

本实验使用的数据集均由本人在实验室搭建采集平台，使用工业相机和补光灯进行拍摄采集，并进行制作。共采集带缺陷样本共计 195 张图片，共有 5 类缺陷分别为凹坑，划痕，缺边，脏污和豁口等。数据大多数在同一场景中存在多个缺陷类别。如图 3.10(a)所示为数据采集平台图，3.10(b)为数据采集界面。使用的相机为 Mshwi 工业相机，型号为 MS-U300C。

如图 3.10(c)所示，为未标注的缺陷样本。深度学习模型的训练需要大量的训练样本，样本数据缺乏可能会导致模型训练过程中过度拟合或检测精度低的问题。自主采集的 195 张样本远远不够，因此需要对数据集进行数据增强来扩充图像的数量，来产生相似但又不同的样本的数量，以此来减轻模型对某些特征的依赖。




图 3.10 数据采集平台与数据采集界面

Fig.3.10 Data collection platform and interface for data collection

基于传统图像处理等方法，常用的最有效的数据集扩充方式为翻转、旋转、缩放、改变亮度等。其中翻转和旋转可以模拟相机与图像处于不同位置时得到的缺陷样本。经过现有问题有效的解决方案验证，简单的图像几何变换可以有效的扩充数据集。本文采用水平翻转和垂直翻转对数据进行增强。

通过几何变换的方法在图像处理中最常用最有效，但此类方法在本质上并没有改变图像本身的质量，仅仅通过不同方向的翻转操作生成的数据集数据样本并




图 3.11 数据增强后的样本

Fig.3.11 Samples after augmentation of data

不丰富，应用效果较差。通过上述分析本文继续采用增加对比度方法再次对数据集进行增强，增加对比度使图像像素方面进行微调，可在一定程度上提升模型的鲁棒性。如图 3.11 所示（正常，两个反转一个抖动）。经过三倍的数据增强，加上原有的原始 195 张数据集，共构成了 780 样本的数据集，我们按照训练集、验证集、测试集比例为 6:2:2 的标准比例划分数据，到此为止训练集共有 468 张含有 5 类缺陷

的样本，验证集和测试集各有 156 张含有 5 类缺陷的样本。

3.4.2 数据集标注

(1) 数据集标注工具




图 3.12 LabelImg 图像标注工具

Fig.3.12 Image annotation tools

图像在送入到模型在进行训练之前要对图像进行标注，就是划分出来感兴趣区域告诉模型此处区域就是要学习和识别的内容。标注完还要进行格式转化，转化为 YOLO 可识别的文件格式。本文采用了名为 LabelImg 的软件进行数据标注，如下图 3.12 所示，此图展示了软件的界面。图像所在位置为编辑框，对图片中选中的物体进行标注分类，界面右边展示了目标不同类别的标签：划痕 scratch、凹坑 pit、少边 edge missing、豁口 notch、脏污 dirty。

(2) 格式转换

由于本文的模型使用的是.txt 文件的格式，但其他部分模型使用的是.xml 类型的文件格式，所以为了方便我们会默认生成.xml 的标注文件，然后通过文件格式转换脚本，对 xml 格式进行转换，转换为能用的.txt 文件格式。如图 3.13 所示展示了两种文件格式的信息内容。.txt 文件中有 5 列数据，第一列代表标注的类别，从 0 开始计数，后续几列数据代表矩形标注框的四个顶点坐标的归一化比值，即通过四个数据能确定出唯一的矩形框。.xml 文件显得更为直观，类别和矩形框的四个顶点值清晰可见，通过四个值也可以唯一确定一个矩形框。



图 3.13.txt 和 xml

Fig.3.13.txt and xml

3.4.3 评价指标

在目标检测领域，当训练集在网络模中训练完毕以后需要在测试集上进行测试，已得到关乎模型性能的评价指标。目标检测领域有一些公认的指标用于评价模型的性能。本节将介绍这些指标，以便在后续实验部分进行对比。

(1) 平均精度值

在目标检测领域，用平均精度均值（mean average precision,mAP）作为模型的评价指标。评价过程首先计算数据集中每个类别的平均精度（average precision,AP），然后对数据集中所有类别的 AP 求平均得到 mAP。在计算平均精度之前，需要先对精度（precision,P）和召回率（recall,R）进行说明。

在目标检测模型的检测过程中，通常会生成多个预测框。为了对这些预测框进行分类，常常使用交并比（IntersectionoverUnion,IoU）来衡量预测框与真实框之间的重叠程度。根据计算得到的 IoU 值，可以将预测框分成以下四种情况：

分类情况	预测为正样本	预测为负样本
真正正样本	TP	FN
真实负样本	FP	TN

图 3.14 混淆矩阵示意图

Fig.3.14 Schematic diagram of the confusion matrix

真的正样本(TruePositive,TP)，被模型分类成了正样本，但目标本身标注为正样本的情况。真的负样本(TrueNegative,TN)，被模型分类成了负样本，但目标本身

标注为负样本的情况。假的正样本(FalsePositive,FP),被模型分类成了正样本,但目标本身标注为负样本的情况。假的负样本(FalseNegative,FN),被模型分类成了负样本,但目标本身标注为正样本的情况。为了更直观地表示上述四种预测框的分类情况,可以使用一个混淆矩阵,如图 3.14 所示。

精度的定义为,在所有网络模型预测为正样本中,实际有多少标注也是正样本,这是从预测角度来进行统计的,可根据精度的定义得到其定义公式,如公式(3-17)所示。召回率的定义为,在所有标注为正样本里,实际有多少也被网络模型预测为正样本,这是从真实样本集进行统计的,可根据召回率的定义得到其定义公式,如公式(3-18)所示。

$$P = \frac{TP}{TP + FP} \quad (3-17)$$

$$R = \frac{TP}{TP + FN} \quad (3-18)$$

模型的好坏不仅与精度有关,还与召回率息息相关。仅仅通过精度或召回率来评价模型无法全面衡量其性能。在实际的检测中,精度和召回率经常存在着相互矛盾的关系,需要在二者之间尽可能地平衡。当固定 IoU 阈值后,可以得到模型在某一状态下的输出精度和召回率,可以用一个点在坐标轴上表示,其中召回率为横坐标,精度为纵坐标。通过收集足够多的状态点,可以在坐标轴上绘制出 P-R 曲线,曲线上的每个点代表模型在某一状态下的精度和召回率。因此,平均精度(AP)不是简单地对精度求平均,而是定义为 P-R 曲线下的面积。用 $P(r)$ 表示 P-R 曲线,AP 的定义式如公式(3-19)所示。

$$AP = \int P(r) dr \quad (3-19)$$

AP 同时考虑了模型对某一类别的精度和召回率,但单个类别的 AP 并不足以评价一个模型的好坏,除非模型只需要检测一种类别。因此,使用 mAP 来评价模型的优劣,mAP 是对数据集上每个类别的 AP 求平均。其定义式如公式(3-20)所示。

$$mAP = \frac{1}{n} \sum_{i=1}^n AP_i \quad (3-20)$$

因为 mAP 能够很好的反映模型的性能。因此, mAP 将作为本文检测模型性能的额主要指标。

(2) 参数量与浮点计算量

参数量是指网络中的参数个数，它与具体的输入数据无关，而与模型的网络结构有关。一般来说，模型越复杂，对应神经网络的层数也就越深，这意味着模型所需计算和调节的参数也越多，从而对显存等资源的需求也更大。因此，可以用参数量来描述一个模型的大小。卷积层是统计参数量的主要层，也就是参数量大小取决于一个模型中卷积层的大小，假设某一层卷积层的高度为 k_h ，宽度为 k_w ，输入的通道数为 c_{in} ，输出端的通道数为 c_{out} ，那么该卷积层的参数量计算方式为式(3-21)所示：

$$parameter = k_w * k_h * c_{in} * c_{out} + c_{out} \quad (3-21)$$

浮点计算量（FloatingPointOperations, FLOPs）是用来衡量模型计算量的指标，一般指处理一张图片所需要的浮点运算量，它通常用于评估模型的复杂度和计算资源的消耗。浮点计算量的计算与模型的网络结构和参数量有关，不涉及到具体的硬件条件，所以在比较不同模型时比较公正。用 W 和 H 来分别表示输入卷积层的特征图的宽度和高度，那么该卷积的浮点计算量如公式(3-22)所示。

$$FLOPs = (k_w * k_h * c_{in} * c_{out} + c_{out}) * H * W \quad (3-22)$$

根据上述公式可以看出，参数量乘以输出特征图的尺寸大小就等于浮点计算量。

(3) 每秒帧数

每秒帧数（FramesPerSecond, FPS）是指模型在一秒内能够检测的图像数量，是衡量模型处理图像流畅度和性能的指标。每秒帧数计算公式为式(3-23)所示。

$$FPS = \frac{Frame\ Count}{End\ Time - Start\ Time} \quad (3-23)$$

式中：

StartTime 为开始时间；EndTime 为结束时间；FrameCount 为这段时间里模型共处理的帧数。

需要注意的是。FPS 计算的结果是平均每秒的帧数，是在实际检测中测量出来

的，与模型部署运行的硬件平台有关，高配置的运行平台性能比低配置的高，所测出来的 FPS 自然会高，运行环境不同前后检测的结果会有很大差异。所以，用此指标评价比较不同模型检测速度时，需要保证模型在相同环境下运行测试。

3.4.4 实验环境

本实验需要用到 GPU 加速来增加训练速度，减小模型训练时间，所以一张质量高的 GPU 显得尤为重要，本实验所用参数配置如下表：

本文实验硬件环境为：中央处理器（CPU）选择 AMD Ryzen 75800H CPU@3.20GHz；图形处理器（GPU）选择 NVIDIA GeForce RTX3060 Laptop，6GB 显存；运行内存为 16GB。

软件环境：Pycharm，编译语言为 Python3.9，深度学习框架为 PyTorch1.12.1，用于加速 GPU 计算的 CUDA 版本为 11.6，操作系统为 Windows11。

输入图像分辨率为 640*640，训练没有采用预先训练好的模型，每批训练样本（batchsize）设 4 份，训练迭代（epoch）次数为 500。

3.4.5 实验结果对比分析

(1) 注意力机制改进实验




图 3.15 改进后的模型结构

Fig.3.15 Improved model structure

根据前面章节介绍的注意力机制后，本文决定采用 CA 注意力机制作为模型改进方案，加的位置在主干网络 SPPF 后面，作为主干网络的最后一层。加完 CA 注意力机制后网络模型结构如图 3.15 所示。

为了验证本文所添加的注意力机制对模型的性能有提升效果，分别对加注意力机制和不加注意力机制进行对比实验，实验结果如表（3.1）和图 3.15 所示。由于加了注意力机制后增加了网络模型的复杂度，增加了计算量所以在精度上升的同值，即通过四个数据能确定出唯一的矩形框。xml 文件显得更为直观，类别和矩形框的四个顶点值清晰可见，通过四个值也可以唯一确定一个矩形框。时检测速度大幅度下降。加了注意力机制后，豁口缺陷的检测精度增长最多，由原来的 92.7%上

表 3-1 对比实验

Tab.3-1 Comparative experiments

模型	脏污	划痕	豁口	少边	凹坑
YOLOv5s	87.9	91.0	92.7	93.3	93.5
YOLOv5s-CA	87.8	91.2	95.0	95.0	93.3
	mAP	参数量/M	计算量/GFLOPs	FPS	
YOLOv5s	91.7	7.0	15.8	47.6	
YOLOv5s-CA	92.5	7.2	16.0	39.5	

升到 95.0%，增长了 2.3 个百分点。同时少边的缺陷由原来的 93.3% 上升到 95.0%，上涨了 1.7 个百分点。平均检测精度 mAP 由原来的 91.7% 上升到 92.5%，上升了 0.8 个百分点。当然随着精度的增加也带来的负面的影响，参数量从原来的 7.0 上涨到了 7.2，网络模型的计算量从 15.8 上涨到 16.0。速度 FPS 从 47.6 降低到 39.5。




图 3.16 检测对比图

Fig.3.16 Detection comparison chart

如图 3.16 (a) 所示，为 YOLOv5s 原版检测结果，3.16 (b) 为加了注意力机制后的检测结果，由图可知，加了注意力机制后的模型，检测效果置信度稳步提升。

综上所述，本文所改进的网络模型 YOLOv5s-CA 能有效提升模型检测精度，使模型检测的 mAP 提升。

(2) 损失函数的改进实验

在损失函数改进的实验中，本文使用 WIoUv3 替换原有 YOLOv5s 模型网络中的 CIoU 损失函数。为了验证本文所改进的损失函数有明显的提升效果，设计了一下几组实验：第一组使用 YOLOv5s 原有的损失函数 CIoU；第二组使用前一章所提到的 SIoU；第三组使用本文所使用的 WIoUv3。实验结果如表 (3.2) 所示，实验效果图如图 3.16 所示。

表 3.2 损失函数对比实验

Tab.3.2 Comparative experiment with loss function

损失函数	脏污	划痕	豁口	少边	凹坑
CIoU	87.9	91.0	92.7	93.3	93.5
SIoU	87.1	90.4	95.3	91.7	91.2
WIoUv3	86.3	91.9	94.9	92.7	93.6
	Map/%	参数量/M	计算量/ GFLOPs	FPS	
CIoU	91.7	7.0	15.8	47.6	
SIoU	91.1	7.0	15.8	47.7	
WIoUv3	91.9	7.0	15.8	47.2	

由表（3.2）可知，在更换为 SIoU 损失函数后，只有豁口的缺陷检测精度上涨了，其他四类缺陷均呈现下降趋势，其中少边缺陷的检测精度由原来的 93.3% 下降到现在的 91.7%，下降了 1.6%，凹坑缺陷由原来的 93.5% 下降到现在的 91.2%，下降了 2.3%，下降最多。正因如此，所以总的平均检测精度 mAP 由原来的 91.7% 下降到 91.1%，可见 SIoU 带来了负收益。当模型损失函数更换为 WIoUv3 后，豁口缺陷和划痕缺陷的检测精度成功上涨，其中划痕从原来的 91.0% 提升到 91.9%，上涨了 0.9%，豁口从原来的 92.7% 提升到 94.9%，上涨了 2.2%。总的平均检测精度 mAP 从 91.7% 提升到 91.9%，提升了 0.2%。由此可见所更换的 WIoUv3 起到了效果。




图 3.17 检测对比图

Fig.3.17 Detection comparison chart

如图 3.17 所示，图 3.17(a)为原版的 CIoU 损失函数检测图，图 3.17(b)为 SIoU 损失函数检测图，图 3.17(c)为 WIoUv3 损失函数检测图，在三个检测图中 WIoUv3 效果最好，置信度最高。

为进一步证明上述两项改进有效果，再次设计一组实验，同时改进损失函数和注意力机制，如表（3.3）所示：

表 3.3 同时改进 CA 和 WIoUv3
Tab.3.3 Improved CA and WIoUv3 at the same time

模型	脏污	划痕	豁口	少边	凹坑
YOLOv5s-CA-WIoUv3	89.2	92.2	96.6	94.6	94.0
	mAP/%	参数量/M	计算量/GFLOPs	FPS	
YOLOv5s-CA-WIoUv3	93.3	7.2	16.0	39.2	

相比于原始 YOLOv5 网络模型，改进的模型在精度上有巨大提升，特别是豁口缺陷从原来的 92.7%直接提升到 96.6%，上升了 3.9%。总的平均检测精度从原来的 91.7%提升到 93.3%，照比单更改损失函数的 91.9%，以及单换注意力机制的 92.5%都要高。但换来的代价也是最大的，由于提升精度改变了模型结构，增加了模型的计算量和参数量，所以模型运行变得缓慢，在相同设备上检测时速度 FPS 从原来的 47.6 降到了 39.2。




图 3.18 检测对比图

Fig.3.18 Detection comparison chart

如图 3.18 所示，与精度较高的改进方案加入注意力机制相比，同时加入注意力机制和损失函数后，精度达到最高，同时误检率也降低，模型改进有效。

(3)轻量化模型改进实验




图 3.19 加入 GSConv 后的颈部网络

Fig.3.19 Neck network after joining GSConv

上述两个改进虽然大幅度提升了检测精度，但是检测速度骤降。在上述实验的基础上把颈部网络的标准卷积改为 GSConv 轻量化卷积，改进后的颈部模型如图 3.19 所示。

由表（3.4）可知，由于把颈部网络的标准卷积层替换为轻量化卷积，参数量从最高的 7.2 下降到 6.7，计算量从最高的 16.0 下降到 15.5，速度 FPS 由最低的 39.2 上涨到 49.2，上升 10fps。随着标准卷积替换成轻量化卷积，会影响特征图的输出效果，所以精度从最高的 93.3% 降到 92.9%，下降了 0.4%，但仍旧比原始 YOLOv5 要高出 1.2%，fps 高出 1.6。

表 3.4 改进 GSConv 后的模型性能

Tab.3.4 Improved model performance after GSConv

模型	脏污	划痕	豁口	少边	凹坑
YOLOv5s-WGCA	89.2	91.6	95.0	94.8	94.1
	mAP/%	参数量/M	计算量/GFLOPs	FPS	
YOLOv5s- WGCA	92.9	6.7	15.5	49.2	

如图 3.20 所示，为 YOLOv5s-WGCA 在训练过程中产生的相关参数图。由图可看出模型在训练中的学习正常。如图 3.21 所示，为训练好的模型最后的精度与召回率。




图 3.20 模型训练图

Fig.3.20 Model training graph




图 3.21 模型召回率与精度

Fig.3.21 Recall and precision

(4) 主流模型检测对比

为探究模型性能做了六组对比实验，由表（3.5）实验结果可知，本文所改进的算法模型相比几种主流的目标检测算法在综合性能上更具有优势，相比于两阶段算法 FasterR-CNN 在精度上领先 0.6 个百分点，检测速度上领先 29.9。相比于上一代算法 YOLOv3 与 YOLOv4，改进算法在检测速度与精度两方面遥遥领先。相比一阶段算法 SSD 在检测速度上略低，但精度领先 2.9 个百分点，更具有优势。

表 3.5 主流模型性能对比

Tab.3.5 Comparison of the performance of mainstream models

模型	AP/%					mAP/%	FPS
	脏污	划痕	豁口	少边	凹坑		
FasterR-CNN	90.6	91.9	94.1	92.3	92.8	92.3	19.3
SSD	88.8	89.6	92.4	91.1	88.5	90.1	54.4
YOLOv3	78.0	82.1	81.7	75.6	85.3	80.5	27.6
YOLOv4	85.8	87.4	88.9	86.7	87.5	87.3	35.8
YOLOv5s	87.9	91.0	92.7	93.3	93.5	91.7	47.6
本文算法	89.2	91.6	95.0	94.8	94.1	92.9	49.2

3.5 本章小结

本章以 YOLOv5s 作为基础模型，对模型存在的精度不足，速度不足等缺陷进行改进。本章先介绍了三种代表性很强的注意力机制、WIoUv3 损失函数、深度可分离卷积和 GSConv 轻量卷积、目标检测的评价指标和数据集的增强与标注。紧接着在注意力机制中选择了效果最好的 CA 注意力机制作为本文改进方案；选择主流的损失函数进行实验对比；选择 WIoUv3 作为本文的改进方案，同时把其与 CA 注意力机制结合再次进行实验探索模型各项性能，实验表明其精度提升效果明显。最后加入轻量化卷积再次进行实验。实验表明本文所改进的算法港剧有优势。

第4章 系统设计实现与实验平台搭建

4.1 系统硬件选型介绍

本文所选用的机械臂为越疆魔术师机械臂，以及越疆配套的传送带，气泵，吸盘等。具体如下图所示。



图 4.1 硬件平台

Tab.4.1 Hardware platform

本文研究采用的是越疆魔术师桌面轻工业级机械臂，该机械臂不同于一般的多关节机械臂，他的内部组成由四杆机构及链传动的方式使得一个驱动器同时驱动一个甚至多个铰链，其末端为气动吸盘。

4.2 机械臂运动学求解及标定

4.2.1 正运动学

图 4.1 为越疆魔术师机械臂，根据其结构图建立 D-H 坐标系，如图 4.2 所示。




图 4.2 越疆魔术师机械臂连杆坐标系

Fig.4.2 The coordinate system of the connecting rod of the magician robot arm

表（4.1）为机械臂在该坐标系下各个关节对应的参数。

表 4.1 越疆魔术师的 D-H 参数表

Tab.4.1 D-H parameters of the Magician

编号	α_{i-1}	a_{i-1}	d_i	θ_i
1	0	0	0	θ_1
2	90°	0	8	θ_2
3	0	135	0	θ_3
4	0	147	0	θ_4
5	90°	59.7	0	θ_5

由坐标系的变换原理可知，D-H 法建立的坐标系中，相邻两个连杆 i 和 $i-1$ 之间的齐次坐标系变换关系如式(4-1)所示：

$${}^{i-1}_iT = R_x(\alpha_{i-1})D_x(\alpha_{i-1})R_z(\theta_i)D_z(d_i)$$

$$= \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & \cos\theta_i & -\sin\theta_i & 0 \\ 0 & \sin\theta_i & \cos\theta_i & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & \alpha_i \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \cos\theta_i & -\sin\theta_i & 0 & 0 \\ -\sin\theta_i & \cos\theta_i & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & d_i \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4-1)$$

矩阵相乘得：

$${}^{i-1}_iT = \begin{bmatrix} \cos\theta_i & -\sin\theta_i & 0 & \alpha_{i-1} \\ \sin\theta_i \cos\alpha_{i-1} & \cos\theta_i \cos\alpha_{i-1} & -\sin\alpha_{i-1} & -\sin\alpha_{i-1}d_i \\ \sin\theta_i \sin\alpha_{i-1} & \cos\theta_i \sin\alpha_{i-1} & \cos\alpha_{i-1} & \cos\alpha_{i-1}d_i \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4-2)$$

参考式(4-1)，可推导出机器人末端位置在机器人基坐标系下的坐标变换矩阵：

$${}^0T = {}^0T_1 {}^1T_2 {}^2T_3 {}^3T_4 {}^4T_5 {}^5T_6 \quad (4-3)$$

根据 D-H 参数表，通过式(4-3)的坐标变换原理可以计算出由 0 到 5 各临近杆的关系转换矩阵：

$${}^0T_1 = R_z(\theta_1) = \begin{bmatrix} \cos\theta_1 & -\sin\theta_1 & 0 & 0 \\ \sin\theta_1 & \cos\theta_1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix};$$

$$\begin{aligned}
{}^1_2T &= R_{x_1}(\alpha_1)R_{z_2}(\theta_2)D_{z_2}(d_2) = \begin{bmatrix} \cos\theta_2 & -\sin\theta_2 & 0 & 0 \\ 0 & 0 & -1 & -8 \\ \sin\theta_2 & \cos\theta_2 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}; \\
{}^2_3T &= D_{x_2}(\alpha_2)R_{z_3}(\theta_3) = \begin{bmatrix} \cos\theta_3 & -\sin\theta_3 & 0 & 135 \\ 0 & 1 & 0 & 0 \\ \sin\theta_3 & \cos\theta_3 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}; \\
{}^3_4T &= D_{x_3}(\alpha_3)R_{z_4}(\theta_4) = \begin{bmatrix} \cos\theta_4 & -\sin\theta_4 & 0 & 147 \\ \sin\theta_4 & \cos\theta_4 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}; \\
{}^4_5T &= R_{x_4}(\alpha_4)D_{x_4}(\alpha_4)R_{z_5}(\theta_5) = \begin{bmatrix} \cos\theta_5 & -\sin\theta_5 & 0 & 59.7 \\ 0 & 0 & -1 & 0 \\ \sin\theta_5 & \cos\theta_5 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}; \quad (4-4)
\end{aligned}$$

将以上的关系式带入到式(4-1)中可得机械臂正运动学的变换矩阵为:

$${}^0_5T = \begin{bmatrix} r_{11} & r_{12} & r_{13} & P_x \\ r_{21} & r_{22} & r_{23} & P_y \\ r_{31} & r_{32} & r_{33} & P_z \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4-5)$$

其中:

$$\begin{aligned}
r_{11} &= \cos\theta_5 \left[\cos\theta_4 (\cos\theta_1 \cos\theta_2 \cos\theta_3 - \cos\theta_1 \sin\theta_2 \sin\theta_3) \right. \\
&\quad \left. + \sin\theta_4 (\cos\theta_1 \sin\theta_2 \cos\theta_3 - \cos\theta_1 \sin\theta_2 \cos\theta_3) \right] + \sin\theta_1 \sin\theta_5
\end{aligned}$$

4.2.2 逆运行学

当知道了机械臂末端位置和姿态信息以后,可以通过连杆坐标系表达式计算各个运动关节变量参数,此过程为求解运动学逆解。机器人逆运动学求解大概分为两类:封闭解、数值解,其中封闭解因其迭代次数较少,计算速度快,所以被广泛使用^[49]。本文先使用几何法求解关节角 θ_1 、 θ_2 、 θ_3 。再根据连杆间的矩阵变换关系和已知关节角 θ_2 、 θ_3 求解 θ_5 和 θ_4 的值。

(1) 计算关节变量 θ_1 、 θ_2 、 θ_3

解析法部分计算中,由于腕部关节与工具坐标系关节Z方向相同且轴线重合,本文研究以先取机械臂的前5个旋转关节,取 $i=5$,对式(4-3)两边同时左乘 $\begin{pmatrix} 0 \\ 1 \end{pmatrix} T^{-1}$ 得:

$$\begin{pmatrix} 0 \\ 1 \end{pmatrix} T^{-1} {}^0_5 T = {}^1_2 T {}^2_3 T {}^3_4 T {}^4_5 T \quad (4-6)$$

计算得到左边式:

$$\begin{pmatrix} c_1 r_{11} + s_1 r_{21} & c_1 r_{12} + s_1 r_{22} & c_1 r_{13} + s_1 r_{23} & c_1 P_x + s_1 P_y \\ -r_{31} & -r_{32} & -r_{33} & -P_z \\ -s_1 r_{11} + c_1 r_{21} & -s_1 r_{12} + c_1 r_{22} & -s_1 r_{13} + c_1 r_{23} & -s_1 P_x + c_1 P_y \\ 0 & 0 & 0 & 1 \end{pmatrix} \quad (4-7)$$

等式的右边为:

$${}^1_5 T = \begin{pmatrix} * & * & * & 59.7(\cos \theta_4 c_{23} - \sin \theta_4 s_{23}) + 147c_{23} + 135 \cos \theta_2 \\ -\sin \theta_5 & -\cos \theta_5 & 0 & 8 \\ * & * & * & * \\ 0 & 0 & 0 & 1 \end{pmatrix} \quad (4-8)$$

其中:

$c_i = \cos \theta_i$; $s_i = \sin \theta_i$; * 表示计算时使用不到的元素 ;

$c_{23} = \cos \theta_2 \cos \theta_3 - \sin \theta_2 \sin \theta_3$; $s_{23} = \sin \theta_2 \cos \theta_3 + \cos \theta_2 \sin \theta_3$ 。




图 4.3 平面内的越疆魔术师机械臂

Fig.4.3 Cross-border magician manipulator in plane

因为解析法无法直接计算机械臂的关节角,所以采用几何法。假设不考虑回转机构坐标系 O_1 ,使坐标系 O_0 、 O_1 与坐标系 O_2 原点重合。机械臂只有4个主动驱动关节,所以机械臂的工作范围由各关节组成一个操作臂平面,如图4.4所示,机械臂操作平面内关节2处的点A、关节3处的点B,关节4处的点C和关节5处

的点 D。假设 D 点即关节 5 在位姿空间的坐标为 (P_x, P_y, P_z) ，由于连杆 l_4 在驱动器 1 和驱动器 2 的特殊连接结构作用下，使得连杆 l_4 总是与平面 XO_1Y 面平行，如图 4.3 所示，C 点的坐标可以通过 D 点平移计算得来。




图 4.4 XOY 平面内 C、D 点的坐标关系

Fig.4.4 The coordinate relationship between points C and D in the XOY plane

在图 4.4 中可知，FD 的长度和 CF 的长度分别为 y 与 x ，易得 $x = l_4 \cos \theta_1$ ， $x = l_4 \sin \theta_1$ 。所以 C 点的坐标为 $(P_x - l_4 \cos \theta_1, P_y - l_4 \sin \theta_1)$ ，同时可得 θ_1 为：

$$\theta_1 = \text{Atan} 2(P_y, P_x) \quad (4-9)$$

根据图 4.3 可得：

$$\tan \alpha = \frac{P_z}{\sqrt{(P_x - l_4 \cos \theta_1)^2 + (P_y - l_4 \sin \theta_1)^2}} \quad (4-10)$$

计算反三角函数可得：

$$\alpha = \text{Atan} 2\left(P_z, \sqrt{(P_x - l_4 \cos \theta_1)^2 + (P_y - l_4 \sin \theta_1)^2}\right) \quad (4-11)$$

$$\cos \beta = \frac{l_2^2 + l_{AC}^2 - l_3^2}{2l_2 l_{AC}} \quad (4-12)$$

其中： $l_{AC}^2 = (p_y - \sin \theta_1)^2 + (p_x - \cos \theta_1)^2 + p_z^2$ ； $\beta = \text{Atan} 2(\pm \sqrt{1 - \cos^2 \beta}, \cos \beta)$

可得 θ_2 的值为：

$$\theta_2 = \alpha \pm \beta \quad (4-13)$$

$$\cos \theta_3 = -\frac{l_2^2 + l_3^2 - l_{AC}^2}{2l_2 l_3} = -\frac{(P_x - \cos \theta_1)^2 + (P_y - \sin \theta_1)^2 + P_z^2 - l_2^2 - l_3^2}{2l_2 l_3} \quad (4-14)$$

最后可得：

$$\theta_3 = A \tan 2 \left(\pm \sqrt{1 - \cos \theta_3}, \cos \theta_3 \right) \quad (4-15)$$

式中：±代表可能有双解， $l_2 = 135\text{mm}$ ， $l_3 = 147\text{mm}$ ， $l_4 = 59.7\text{mm}$ 。

(2) 计算关节变量 θ_4 、 θ_5

令等式(4-6)左右两侧元素(2,1)相等得：

$$r_{33} = \sin \theta_4 (\sin \theta_2 \cos \theta_3 + \cos \theta_2 \sin \theta_3) - \cos \theta_4 (\cos \theta_2 \cos \theta_3 - \sin \theta_2 \sin \theta_3) = 0 \quad (4-16)$$

经计算得：

$$\theta_4 = A \tan 2 (\cos (\theta_2 + \theta_3), \sin (\theta_2 + \theta_3)) \quad (4-17)$$

令式(4-6)左右中元素(2,3)相等可得：

$$\sin \theta_5 = r_{31} \quad (4-18)$$

且已知：

$$r_{31} = \cos \theta_5 [\cos \theta_4 (\sin \theta_2 \cos \theta_3 + \cos \theta_2 \sin \theta_3) + \sin \theta_4 (-\sin \theta_2 \sin \theta_3 + \cos \theta_2 \cos \theta_3)] \quad (4-19)$$

计算可得：

$$\theta_5 = \arctan [\cos \theta_4 \sin (\theta_2 + \theta_3) + \sin \theta_4 \cos (\theta_2 + \theta_3)] \quad (4-20)$$

4.2.3 手眼标定

根据相机安装的位置，手眼标定有两种方式，一种是眼在手上(Eye-in-Hand)，另一种是眼在手外(Eye-to-Hand)。顾名思义眼在手上即为相机固定在机械臂的末端是执行器上，眼在手外即为相机固定在一个固定的区域上。因为本文所进行的缺陷检测需要时时刻刻检测传送带上面的零件，所以相机不能放在移动的机械臂机械臂末端，故本文选择眼在手外这种方式。

眼在手外的相机安装方式中，相机被安装固定在机械臂外部，相对于机械臂底座是静止不动的。因此，这两个部分之间的位置关系始终保持不变。设相机坐标系为 O_{cam} ，机械臂末端执行器坐标系为 O_{end} ，标定板的坐标系为 O_w ，机械臂底座坐标系为 O_b 。同时还是涉及到几个坐标系之间的转换，机械臂底座到机械臂末端执行器之间的坐标系转换为 T_b^{end} ，标定板坐标系到相机坐标系的转换关系为 T_w^{cam} ，相机

坐标系到机械臂底座的坐标系转换关系为 X ， X 即为我们要求解的对象。




图 4.5 手眼标定位置转换关系

Fig.4.5 Hand-eye calibration position transformation relationship

在标定的过程中，需要将棋盘格用机械臂末端执行器固定，并且放置在相机的视野范围内。同时改变机械臂的空间位置，相机再次进行采集。

对于上述的转述关系，在某一位姿下，标定板上的点在标定板坐标系下的坐标值为 Q_1 ，经过 T_w^{cam} 、 T_{cam}^b 、 T_b^{end} 的坐标系转换关系转换后，标定板上的点转到机械臂末端执行器上的坐标值为 Q_3 ，转换关系如下：

$$T_b^{end} X T_w^{cam} Q_1 = Q_3 \quad (4-21)$$

改变机械臂位姿再次得到一组等式：

$$T_b^{end'} X T_w^{cam'} Q_1 = Q_3 \quad (4-22)$$

其中 T_b^{end} 与 $T_b^{end'}$ 通过机械臂的位姿信息输出可得， T_w^{cam} 与 $T_w^{cam'}$ 通过相机标定可得，所以上述公式可以转化为：

$$T_b^{end} X T_w^{cam} = T_b^{end'} X T_w^{cam'} \quad (4-23)$$

进而可得：

$$T_b^{end-1} T_b^{end} X = X T_b^{cam'} T_b^{cam-1} \quad (4-24)$$

上述公式可以看成是 $AX=XB$ 的形式，通过多次变换机械臂的位姿，对手眼标定方程 $AX=XB$ 求解，使用 Tsai's 两步法求解此方程。最终可得到手眼转换矩阵 X 值。

4.3 UI 界面

Qt 是一个跨平台的 C++ 开发库，它与多种脚本语言，如 Python、Ruby 和 Perl 等




图 4.8 系统工作图

Fig.4.8 System working diagram

4.4 本章小结

本章对检测系统所需要的硬件进行了简单介绍，包括机械臂、传送带、气泵、吸盘以及相机。其次对机械臂的正逆运动学进行了讲解以及求解，对机械臂的手眼标定方法进行了简单的阐述并且根据本文实验的特性选择了眼在外的相机放置和标定方式。最后对 UI 界面进行了编写，使检测系统操作更加直观与方便。

结 论

针对轴承座工业零件在生产运输过程中存在缺陷,传统人工检测效率低,漏检率和误检率高的问题,本文设计了一套轴承座缺陷检测与分拣系统,该系统基于深度学习目标检测技术,针对轴承座缺边、凹坑、豁口、划痕、污染等缺陷表面缺陷的关键问题开展研究,并使系统连接机械臂,形成自定分拣。

本文的主要工作内容如下:

(1) 提出本文零件的深度学习目标检测的零件缺陷检测方案,并利用现有设备进行实验平台的搭建。本文通过主采集的方式,对缺陷样本的数据进行采集,共采集到缺陷数据图片 195 张。为防止数据过少使模型过拟合,故通过翻转、增强对比度等在形状和像素层面对数据进行增强,共 780 张图片,并使用 labellmg 进行数据标注,构建了轴承座缺陷检测数据集,该数据集涉及到 5 种缺陷类别。

(2) 基于 YOLOv5s 网络模型,分别对基础模型的主干网络、损失函数和颈部网络设计改进方案,提出高性能的轻量化改进模型,并通过实验验证方案的可行性。首先针对原始 YOLOv5s 网络模型检测精度低的问题,在主干网络里加入了 CA 注意力机制,使模型更加关注感兴趣区域,从而提升检测精度。同时对模型的锚框机制损失函数进行改进,最终实验表明 WIoU 表现出色,增强了模型对数据集的适应程度,提升检测精度。同时结合上述两种改进,模型性能得到大幅度提升。

(3) 在网络模型的颈部使用轻量化卷积替换原始标准卷积,减少参数量与计算量,使模型的检测速度的到提升。改进后的高性能与轻量化网络模型较原版的 YOLOv5s 网络模型,平均检测精度 mAP 提升了 1.2%,参数量降低 6.1%,计算量降低 3%,检测速度 FPS 提升了 1.6。能更好的满足轴承座表面缺陷检测的要求。

(4) 针对自动分拣问题,本文采用越疆魔术师机械臂等相关套件,与模型进行连接,使网络检测出来的缺陷坐标传给机械臂,并控制机械臂进行自动抓取,使其自动分拣缺陷零件。最后编写 UI 操作界面,使操作更见简便,效果更直观。经过实验验证,该分拣系统稳定、高效,可以完成相关检测与分拣任务。

本文研究了轴承座工业零件的缺陷检测技术，参考国内外研究现状，结合深度学习目标检测技术研究了轴承座表面缺陷检测与自动分拣系统，然而该系统在以下几个方面还需改进。

（1）本文所改进的模型检测精度以及检测速度任有提升的空间，后续可对其各个模块进行新的改进和优化，如数据增强、设计检测头、改进主干网络和 Neck 等。同时也可以做旋转目标检测，这样检测细长缺陷时效果更好。

（2）后续的分拣功能可根据缺陷种类不同，分拣到不同的位置，实现精准分拣。

参考文献

- [1] 张涛,刘玉婷,杨亚宁等.基于机器视觉的表面缺陷检测研究综述[J].科学技术与工程,2020,20(35):14366-14376.
- [2] 程锦锋,方贵盛,高惠芳.表面缺陷检测的机器视觉技术研究进展[EB/OL].计算机应用研究.
- [3] 薛意达.基于深度学习的印刷纸箱缺陷检测方法研究[D].西安理工大学,2023.
- [4] Bhatt P M, Malhan R K, Rajendran P, et al. Image-based surface defect detection using deep learning: A review[J]. Journal of Computing and Information Science in Engineering, 2021, 21(4).
- [5] Hang J, Yang X, Yu X. Sanitary ceramic surface defect detection method based on neighborhood pixel gray information[C]//IECON 2020 The 46th Annual Conference of the IEEE Industrial Electronics Society. IEEE, 2020: 5337-5342.
- [6] Zheng B, Wang C, Qing S. Piston Surface Defect Recognition Method Based on Image Processing[C]//2022 IEEE 10th Joint International Information Technology and Artificial Intelligence Conference (ITAIC). IEEE, 2022, 10: 928-932.
- [7] Lee E T, Fan Z, Sencer B. A new approach to detect surface defects from 3D point cloud data with surface normal Gabor filter (SNGF)[J]. Journal of Manufacturing Processes, 2023, 92: 196-205.
- [8] 王国伟. 基于图像处理的钢轨表面缺陷检测方法研究[D]. 兰州交通大学, 2022.
- [9] Li J, Quan X, Wang Y. Research on defect detection algorithm of ceramic tile surface with multi-feature fusion[J]. Comput. Eng. Appl, 2020, 56: 191-198.
- [10] Xu C, Li L, Li J, et al. Surface defects detection and identification of lithium battery pole piece based on multi-feature fusion and PSO-SVM[J]. IEEE Access, 2021, 9: 85232-85239.
- [11] 杨乐淼, 周富强. 基于机器视觉的划痕检测技术综述[J]. 激光与光电子学进展. 2022, 59(14): 118-125.
- [12] 汤勃, 孔建益, 伍世虔. 机器视觉表面缺陷检测综述[J]. 中国图象图形学报.

- 2017, 22(12): 1640-1663.
- [13] Liu W, Yan K, Wu H C, et al. Real-Time Metal-Surface-Defect Detection and Classification Using Advanced Machine Learning Technique[C]//2022 IEEE International Symposium on Broadband Multimedia Systems and Broadcasting (BMSB). IEEE, 2022: 1-5.
- [14] Yousef N, Parmar C, Sata A. Intelligent inspection of surface defects in metal castings using machine learning[J]. Materials Today: Proceedings, 2022, 67: 517-522.
- [15] Arshad S R, Obaid I, Gull R, et al. Steel defect classification using machinelearning[C]//2022 16th International Conference on Ubiquitous Information Management and Communication (IMCOM). IEEE, 2022: 1-6.
- [16] Singh S A, Desai K A. Automated surface defect detection framework using machine vision and convolutional neural networks[J]. Journal of Intelligent Manufacturing, 2022: 1-17.
- [17] 郭良, 舒亮, 吴桂初. 基于机器学习的灭弧栅片表面缺陷检测方法[J]. 机械工程与自动化. 2019(01): 4-7.
- [18] 刘浩, 陈再良, 张良. 基于机器学习的刀具表面缺陷检测及分类方法[J]. 计算机测量与控制. 2021, 29(06): 64-68.
- [19] Huang Y, Yi M, Yang W, et al. Research on surface defect intelligent detection technology of non-woven fabric based on support vector machine[C]//2022 IEEE International Conference on Electrical Engineering, Big Data and Algorithms (EEBDA). IEEE, 2022: 895-898.
- [20] 刘亚姣, 于海涛, 王江, 等. 基于深度学习的型钢表面多形态微小缺陷检测算法[J]. 计算机应用. 2022, 42(08): 2601-2608.
- [21] 陶显, 侯伟, 徐德. 基于深度学习的表面缺陷检测方法综述[J]. 自动化学报. 2021, 47(05): 1017-1034.
- [22] Ren S Q, He K M, Girshick R, Sun J. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis

- and Machine Intelligence, 2017, 39(6): 91–99.
- [23] Zhou X, Wang D, Krähenbühl P. Objects as points[EB/OL]. <https://arxiv.org/abs/1904.07850>,2019-04-16.
- [24] Hu B, Wang J. Detection of PCB surface defects with improved faster-RCNN and featurepyramid network[J]. Ieee Access, 2020, 8: 108335-108345.
- [25] Zhang Y, Zhang Z, Fu K, et al. Adaptive defect detection for 3-D printed lattice structures based on improved faster R-CNN[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-9.
- [26] Ding R, Dai L, Li G, Liu H. TDD-net: a tiny defect detection network for printed circuit boards[J]. CAAI Transactions on Intelligence Technology, 2019, 4(2): 110–116.
- [27] LIU W, ANGUELOV D, ERHAN D, et al. SSD: single shot multiBox detector[C]. Proceedings of the 2016 European Conference on Computer Vision, LNCS 9905. Piscataway: IEEE, 2016: 21-37.
- [28] TAN M X, PANG R M, LE Q V. EfficientDet: scalable and efficient object detection[C].Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE Computer Society, 2020: 10778-10787.
- [29] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. Piscataway: IEEE Computer Society, 2016: 779-788.
- [30] Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. Piscataway: IEEE Computer Society,2017: 7263-7271.
- [31] Redmon J, Farhadi A. Yolov3: An incremental improvement[EB/OL]. <https://arxiv.org/abs/1804.02767>, 2018-04-08.
- [32] Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: Optimal speed and accuracy of object detection[EB/OL]. <https://arxiv.org/abs/2004.10934>, 2020-04-23.
- [33] Ge Z, Liu S, Wang F, et al. YoloX: Exceeding yolo series in 2021[EB/OL].

- <https://arxiv.org/abs/2107.08430>, 2021-07-18.
- [34] Li C, Li L, Jiang H, et al. YOLOv6: A single-stage object detection framework for industrial applications[EB/OL]. <https://arxiv.org/abs/2209.02976>, 2022-09-07.
- [35] Wang C Y, Bochkovskiy A, Liao H Y M. YOLOv7: Trainable bag-of-freebies sets new stateof-the-art for real-time object detectors[EB/OL]. <https://arxiv.org/abs/2207.02696>, 2022-07-06.
- [36] 楼豪杰, 郑元林, 廖开阳, 等. 基于 Siamese-YOLOv4 的印刷品缺陷目标检测[J]. 计算机应用, 2021, 41(11): 3206.
- [37] Zhou J, Zhao W, Guo L, et al. Real time detection of surface defects with inception-baseMobileNet-SSD detection network[C]. Advances in Brain Inspired Cognitive Systems: 10th International Conference, BICS 2019, Guangzhou, China, July 13–14, 2019, Proceedings 10. Springer International Publishing, 2020: 510-519.
- [38] Aboah A, Wang B, Bagci U, et al. Real-time multi-class helmet violation detection using few-shot data sampling technique and yolov8[EB/OL]. <https://arxiv.org/abs/2304.08256>, 2023-04-13.
- [39] 邱天衡, 王玲, 王鹏, 等. 基于改进 Yolov5 的目标检测算法研究[J]. 计算机工程与应用. 2022, 58(13): 63-73.
- [40] W. Zaremba, I. Sutskever, O. Vinyals. Recurrent neural network regularization[J]. arXiv preprintarXiv:1409.2329, 2014
- [41] M. Sun, Z. Song, X. Jiang, et al. Learning pooling for convolutional neural network[J]. Neurocomputing, 2017, 224: 96-104
- [42] 李康顺, 杨振盛, 江梓锋, 等. 基于改进 YOLOX-Nano 的农作物叶片病害检测与识别方法[J]. 华南农业大学学报. 2023: 1-16.
- [43] 程旭, 崔一平, 宋晨, 等. 基于时空注意力机制的目标跟踪算法[J]. 计算机科学. 2021, 48(04): 123-129.
- [44] Wang B, Yan Y, Lan Y, et al. Accurate Detection and Precision Spraying of Corn and Weeds Using the Improved YOLOv5 Model[J]. IEEE Access, 2023, 11: 29868-29882.

- [45] Wang Y, Ding H, Sun X. Residual Life Prediction of Bearings Based on SENet-TCN and Transfer Learning[J]. IEEE Access, 2022, 10: 123007-123019.
- [46] Woo S, Park J, Lee J.-Y, et al. Cbam: Convolutional block attention module[C]. Proceedings of the European conference on computer vision (ECCV), 2018, 3-19.
- [47] Hou Q, Zhou D, Feng J. Coordinate attention for efficient mobile network design[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021, 13713-13722.
- [48] Tong Z, Chen Y, Xu Z, et al. Wise-IoU: Bounding Box Regression Loss with Dynamic Focusing Mechanism[J]. arXiv preprint arXiv:2301.10051, 2023.
- [49] 宋伟刚. 机器人学—运动学、动力学与控制[M]. 北京: 科学出版社, 2007.