

分类号: TP391.4

单位代码: 10335

密 级: _____

学 号: 22025047



硕士学位论文

中文论文题目: 基于离散掩膜差分与 FM-YOLO
的陶瓷插芯表面缺陷重生与检测
研究

英文论文题目: Ferrule surface defect generation and
detection research based on discrete
mask difference and FM-YOLO model

申请人姓名: 刘子迪

指导教师: 李凌丰

合作导师: _____

专业名称: 机械设计及理论

研究方向: 机器视觉

所在学院: 机械工程学院

论文提交日期 2022 年 12 月 23 日

基于离散掩膜差分与 FM-YOLO 的陶瓷插芯表面缺陷

重生与检测研究



论文作者签名:_____

指导教师签名:_____

论文评阅人 1: _____ 隐名

评阅人 2: _____ 隐名

评阅人 3: _____ 隐名

评阅人 4: _____

评阅人 5: _____

答辩委员会主席: _____ 纪杨建 教授

委员 1: _____ 孙毅 教授

委员 2: _____ 张树有 教授

委员 3: _____ 刘振宇 教授

委员 4: _____

委员 5: _____

答辩日期: _____ 2023 年 03 月 22 日

**Ferrule surface defect generation and detection research
based on discrete mask difference and FM-YOLO model**



Author's signature: _____

Supervisor's signature: _____

Thesis reviewer 1: _____ Anonymous

Thesis reviewer 2: _____ Anonymous

Thesis reviewer 3: _____ Anonymous

Thesis reviewer 4: _____

Thesis reviewer 5: _____

Chair: _____ Prof.JI Yangjian
(Committee of oral defence)

Committeeman 1: _____ Prof.Sun Yi

Committeeman 2: _____ Prof.Zhang Shuyou

Committeeman 3: _____ Prof.LIU Zhenyu

Committeeman 4: _____

Committeeman 5: _____

Date of oral defence: _____ 2023.03.22

摘要

陶瓷插芯作为光纤通信的核心元器件，其表面质量的管控是生产过程中的关键一环。当前工业上陶瓷插芯的表面缺陷检测仍以人工目视为主，检测效率和质量低下，但基于深度学习的机器视觉方法在该领域中仍存在许多问题，如模型尺寸臃肿、数据集样本少、样本类别不均衡、小目标缺陷难以检测等。本文针对上述问题展开研究，论文内容主要包括 4 个方面：

(1) 针对陶瓷插芯表面缺陷数据领域的空白，搭建图像采集平台并提出一种陶瓷插芯表面缺陷原始数据集，同时通过分析数据集的缺陷特点设计陶瓷插芯表面缺陷整体检测流程和模型选型。

(2) 针对陶瓷插芯原始数据集图像有效缺陷信息少、难以采用传统方法直接对抗生成的问题，提出一种离散掩膜差分的缺陷特征提取方法，从原始缺陷图像中提取特征并提出一种小尺寸、低分辨率的仅含离散缺陷特征的图像数据集，再通过新数据集输入到对抗网络生成新的离散缺陷特征，最后将新特征融合掩膜图像并重构生成新的陶瓷插芯表面缺陷图像，解决了陶瓷插芯表面缺陷图像直接对抗生成的低效率及原始数据集缺陷类别分布不均衡的问题。

(3) 针对 YOLOv4 模型臃肿、小目标检测精度低等问题，提出 FM-YOLO 模型，通过轻量化全局网络单元、自适应空间特征融合、增强空间及通道激励、新增多尺寸预测头、引入 DIoU-NMS 算法等改进，实现陶瓷插芯表面缺陷检测模型的轻量化、高精度、高效率。

(4) 设计开发陶瓷插芯表面缺陷检测软件，实现工业现场的缺陷数据集的长期扩充和二次训练机制，保证模型与时俱进的鲁棒性和泛化能力。

关键词：陶瓷插芯表面缺陷，离散掩膜差分，缺陷特征提取，FM-YOLO 模型，缺陷图像重生与检测

Abstract

As a core component of optical fiber communication, the control of surface quality of ferrule is a key part of the production process. The current surface defect detection of ferrule in industry is still dominated by manual visual inspection, which has low efficiency and quality, but there are still many problems in this field based on deep learning machine vision methods, such as bloated model size, small data set samples, unbalanced sample categories, and difficult to detect small target defects. In this paper, we address the above problems, and the paper covers four main aspects.

(1) To address the gap in the field of ferrule surface defect data, build an image acquisition platform and propose a ferrule surface defect original dataset, and also design the overall ferrule surface defect detection process and model selection by analyzing the defect characteristics of the dataset.

(2) To address the problem of low effective information in the original dataset of ferrule cores, a discrete mask differential defect feature extraction method is proposed to extract features from the dataset images and propose a small size and low resolution dataset containing only discrete defect features, the new features are fused with the mask image and reconstructed to generate a new ceramic core surface defect image, which solves the problem of the uneven distribution of defect categories.

(3) To address the problems of bloated YOLOv4 model and low accuracy of small target detection, FM-YOLO model is proposed to achieve lightweight, high accuracy and high efficiency of ceramic core surface defect detection model through improvements such as lightweight global network unit, adaptive spatial feature fusion, enhanced spatial and channel excitation, new multi-size prediction head, and introduction of DIoU-NMS algorithm.

(4) Design and develop ferrule surface defect detection software to realize long-term expansion and secondary training mechanism for defect data sets in industrial sites to ensure robustness and generalization ability of the model with time.

Key Words: ferrule surface defect, discrete mask difference, defect feature extraction, FM-YOLO model, defect generation and detection.

目 录

第 1 章 绪论.....	7
1.1 论文研究背景与意义.....	7
1.2 研究现状分析.....	8
1.2.1 陶瓷工件表面缺陷检测研究现状.....	10
1.2.2 基于深度学习的小目标缺陷检测研究现状	12
1.2.3 不平衡数据集数据增强方法研究现状	14
1.3 论文研究内容与架构.....	16
1.4 本章小结.....	18
第 2 章 陶瓷插芯表面缺陷检测方案总体研究	19
2.1 引言.....	19
2.2 陶瓷插芯表面缺陷分析.....	19
2.3 图像采集平台选型与搭建	22
2.4 陶瓷插芯表面缺陷数据集构建	23
2.5 缺陷检测整体流程设计.....	26
2.6 检测模型选型.....	27
2.6.1 Two-Stage 检测模型	28
2.6.2 One-Stage 检测模型.....	29
2.6.3 对照模型选型.....	31
2.7 评价指标.....	31
2.7.1 目标检测模型评价指标.....	31
2.7.2 图像生成效果评价指标.....	33
2.8 本章小结.....	34
第 3 章 基于离散掩膜差分的缺陷图像重生方法研究	35
3.1 引言.....	35
3.2 离散掩膜差分缺陷图像重生方法框架	36
3.3 掩膜差分缺陷提取算法研究	36
3.3.1 图像正位归一化.....	38
3.3.2 离散特征差分提取.....	42
3.4 对抗网络离散数据生成模型设计	46
3.4.1 离散图像数据集搭建.....	48
3.4.2 对抗网络结构设计与训练.....	48
3.5 融合重构数据混合增强策略研究	52
3.5.1 离散缺陷特征融合	52
3.5.2 位姿重构混合增强.....	54

3.6 离散掩膜差分对抗的缺陷图像重生方法验证	56
3.6.1 方法过程独立有效验证	57
3.6.2 方法组合综合消融验证	63
3.7 本章小结	64
第 4 章 基于 FM-YOLO 模型的缺陷检测方法研究	65
4.1 引言	65
4.2 YOLOv4 模型结构与原理	65
4.2.1 模型结构	65
4.2.2 边界框检测原理	68
4.2.3 损失函数	69
4.3 基于 YOLOv4 的 FM-YOLO 模型改进设计	70
4.3.1 基于深度可分离卷积的轻量化融合设计	71
4.3.2 基于自适应空间特征融合的多尺度改进	74
4.3.3 基于 sc SE 模块的空间及通道激励增强	76
4.3.4 基于 DIoU-NMS 的非极大值抑制算法优化	80
4.4 FM-YOLO 模型的训练过程与实验验证	83
4.4.1 基于深度迁移学习的 FM-YOLO 模型训练	83
4.4.2 FM-YOLO 模型有效性实验验证	87
4.5 本章小结	92
第 5 章 陶瓷插芯表面缺陷检测软件设计与综合实验验证	93
5.1 引言	93
5.2 陶瓷插芯表面缺陷检测软件设计	93
5.2.1 软件总体框架	93
5.2.2 软件模块实现	94
5.3 陶瓷插芯表面缺陷检测综合实验验证	99
5.3.1 表面缺陷检测组合实验验证	99
5.3.2 多尺度下的检测结果比较研究	102
5.3.3 多类别下的检测结果比较研究	104
5.4 本章小结	105
第 6 章 总结与展望	107
6.1 工作总结	107
6.2 工作展望	108
参考文献	109

第 1 章 绪论

1.1 论文研究背景与意义

在信息化时代的二十一世纪的今天，由于计算机网络业务蓬勃发展和多媒体应用的迅速增长，对于大容量、长距离、超高速的通信技术有更加迫切的发展需求。光纤通信自 1966 年诞生以来，包揽传输频带宽、通信容量大、传输损耗低、中继距离长等多个优点，现已成为现代通信主要的通信方式^[1]。伴随着未来数字经济的发展和未来工业自动化、智能化、数字化的融合，光纤通信技术的未来仍然有相当大的发展潜力和空间^[2]。

陶瓷插芯，又名光纤陶瓷插针体，由于陶瓷材料和石英光纤匹配性能表现优秀，是目前光纤通信中使用最普遍的基础光无源器件材料^[3]。陶瓷插芯是光纤连接器中精密对中的圆柱体，其圆柱体中心的微孔用作于固定光纤。当前光纤通信生产行业中光纤连接器主要使用 2.5mm 直径的陶瓷插芯作为其核心器件，陶瓷插芯的实物和机械结构图如图 1.1 所示。




图 1.1 陶瓷插芯实物和机械结构图

陶瓷插芯的制造生产主要由纳米氧化锆材料经过多段工艺流程，工艺工序通常由机器加工完成，最终的检验工序是保证陶瓷插芯产品合格率的重要步骤。由于陶瓷插芯采用的陶瓷脆性材料加工难度大、工艺加工精度和表面质量要求高，光纤连接时需要通过陶瓷插芯精准对接实现。陶瓷插芯的表面缺陷会严重影响光纤连接器的光学性能和机械性能，影响对接精度、增大插入损耗和回波损耗^[4]，

因此陶瓷插芯在制造过程中需要进行严格的表面质量控制。

据现行中华人民共和国工业和信息化部发布的通信行业标准 YD/T 1198.1-2014《光纤活动连接器插芯技术条件 第一部分：陶瓷插芯》中的规定，陶瓷插芯的质量控制过程中包括外观检查^[5]。目前工业上陶瓷插芯的外观检查主要通过人工方式实现肉眼检验，由于陶瓷插芯具有自身尺寸偏小、缺陷特征不明显、常规光源下不易观察等问题，导致陶瓷插芯的肉眼检测效率低下，且对人员的工作状态要求严格，检测成本较高。长期的人工肉眼检测极易产生疲劳，从而发生漏检、误判等现象，变相增大陶瓷插芯的生产成本。因此，陶瓷插芯生产线迫切需要一种效率高、准确率高、实时性强、自动化程度高的机器视觉检测方式。然而，目前工业上在陶瓷插芯缺陷检测的机器视觉的理论研究寥寥无几，因此将机器视觉和陶瓷插芯结合应用在实际生产制造检测流程中是陶瓷插芯行业实现工业自动化、智能化的重大突破。同时机器视觉技术带来的高效率和高精确率可以明显减少工艺流程时间，提高检测效率，陶瓷插芯生产线结合机器视觉检测技术的研究具有重要意义。

基于以上背景，本文依托于湖北省光纤陶瓷插芯制造厂商所委托的项目“基于机器视觉的陶瓷插芯表面缺陷检测系统开发”，主要以外径 2.5mm，长度 12mm 的 SC 型陶瓷插芯为研究对象开展机器视觉相关问题的研究。应项目方要求，检测系统不仅需要对陶瓷插芯图像的缺陷进行完整的识别，还需要对缺陷种类进行正确的分类，准确的缺陷分类与统计有利于工程师快速从缺陷数据获取工艺不良信息，从而更快定位到具体的工艺流程进行排查，方便及时发现工艺问题和提升整体产品良率；同时为提高工艺流程生产和检测效率，对检测系统的速度也提出了一定的要求，因此本文对于陶瓷插芯的缺陷检测有以下目标：第一，正确并完整地检测出陶瓷插芯样本图像的缺陷类型和数量，整体检测准确率大于 95%，查全率大于 95%；第二，满足单张图像在 GPU 环境下检测时间小于 50ms。

1.2 研究现状分析

和其他机器视觉系统类似^[6]，陶瓷插芯机器视觉检测系统也是建立在光学装

置和非接触式传感器的基础之上获取数字图像，借助计算机从数字图像获取目标特征，从而分析理解出数字图像的特征分类、特征数量，然后利用计算出的特征结果对工业硬件进行控制如分级、筛选等操作，进而实现检测自动化控制的结果。陶瓷插芯表面缺陷检测的机器视觉系统设计如图 1.2 所示，该系统由工业相机、光源、上位机、通信模块、传感器、旋转装置、控制机构等部分构成。工业相机、光源、传感器作为机器视觉系统的输入硬件设备，配合陶瓷插芯和旋转装置获取多角度的插芯表面图像，然后通过上位机分析数字图像判断陶瓷插芯的合格程度，最后根据检测结果和通信模块操作控制机构决定工件的去留走向。




图 1.2 陶瓷插芯表面缺陷检测的机器视觉系统组成图

机械工程领域中，机器视觉应用于工业表面检测缺陷检测的文献和研究较多，但是陶瓷插芯表面检测相关的技术研究展开较少。同为陶瓷材料，陶瓷插芯表面也存在陶瓷工件普遍存在的裂纹、凹坑、污点、擦伤、崩缺等类别的表面缺陷，因此陶瓷类表面检测的研究方法和设计对陶瓷插芯工件的表面缺陷检测方法研究也有很大的帮助。

基于以上，本节介绍当前机器视觉在陶瓷工件表面缺陷检测的研究现状，同时根据陶瓷插芯缺陷特点，引申介绍基于深度学习的小目标缺陷检测方法和不平衡数据集的数据增强方法研究现状。

1.2.1 陶瓷工件表面缺陷检测研究现状

陶瓷工件表面缺陷检测通常有以下难点：第一，陶瓷表面结构通常较为复杂，同一类型的表面缺陷在不同位置的特征表达表现不同，不同类型的缺陷特点差异较大，难以直观的设计出统一的特征描述数学模型；第二，陶瓷工件表面缺陷通常具有非结构性、跨尺度性、各向异性、样本缺少等特点，更增加了检测的难度。

与本文研究的陶瓷插芯表面缺陷检测问题类似，陶瓷表面缺陷检测本质上也是目标检测分类问题。机器视觉领域上的目标检测分类问题，一般按照特征提取的方法的不同分为两种，分别为基于数字图像处理和基于深度学习的表面缺陷检测。

基于数字图像处理的表面缺陷检测方法通常的流程为：第一，对获取的数字图像进行预处理，根据图像像素数据分割选取得到缺陷感兴趣区域，第二，对选取的感兴趣区域采用人工设计的特征提取方法如集合运算、区域变换、模板匹配等方法进行处理，从而得到目标缺陷特征区域，第三，对提取到的目标缺陷特征区域按一定规则输入到分类器进行分类得到缺陷信息和分类结果。目前常用的特征提取算法有 Canny^[7]、Gabor^[8]、HOG^[9]、LBP^[10]、SIFT^[11]等方法，常用的分类器有 SVM^[12]、KNN^[13]等方法。

Zhang 等^[14]在传统图像处理方法的基础上，利用颜色空间分布方差特征和颜色面积权重特征得到显著图，再将缺陷图像和显著图以指数形式融合得到缺陷显著图，然后切割出包含缺陷区域的图像子块进行二次检测，去除误检缺陷完成最终检测。实验结果表明，所提缺陷检测方法的最佳准确率为 98.75%，但实验的检测效果会随着瓷砖表面颜色和纹理类型的增加而降低。Chen 等^[15]针对陶瓷贴花表面缺陷检测中因陶瓷眩光导致的检测精度低、检测速度慢等问题，提出了一种基于同态滤波的抗眩光陶瓷贴花缺陷检测技术。

Younas 等^[16]提出了一种基于图像处理和形态学运算的瓷砖自动缺陷检测方法，将边缘检测算法应用于灰度图像增强裂纹的边缘，再使用形态学侵蚀和扩张操作得到中间图像。最后通过膨胀中间图像减去被侵蚀中间图像来检测边缘。实

验结果表明最终的平均检测精度达到 92%。**Rajashri** 等人^[17]提出了一种基于高斯算子的拉普拉斯缺陷检测算法。为了识别裂缝,该算法将边缘检测图像与完美瓷砖的参考图像进行逐像素比较,但只能用于识别平面或单色瓷砖的缺陷。

Li 等^[18]使用改进的 **SIFT** 和色矩融合特征作为瓷砖图像的区域描述,然后根据每个特征分配相应的权重系数,将融合后的特征再输入支持向量机。但该模型的准确率仅为 90%。**Sioma** 等^[19]人利用激光三角法构建了陶瓷瓦面三维图像,并介绍了陶瓷瓦面图像分析算法在滤波和图像识别中的应用。

基于深度学习的表面缺陷检测方法不同于基于数字图像处理的表面缺陷检测方法,通常的检测流程为:第一步,将采集的数字图像样本进行预处理来增强训练数据的多样性,常用的方法有:图像变换、均值归一化、通道变化等,数据集分为训练集、测试集、验证集;第二步,将数据集的数据输入预先设计的检测网络进行训练,提取出图像的深层次、高维度的特征,训练过程中通过验证集中的检测反馈来动态调整网络结构或参数、学习策略等,最终训练出满足预期准确率的网络模型。下文介绍当前基于深度学习的陶瓷表面缺陷检测方法研究现状。

Huang 等^[20]对陶瓷手机背板表面缺陷检测方法进行研究,将训练好的深度学习模型应用于嵌入式平台。实验结果表明,该模型的识别精度可达 89.9%,在嵌入式平台上的识别效率可达 2 帧/秒。**Lu** 等^[21]提出了一种基于改进 **YOLO** 的瓷砖表面缺陷智能检测方法,针对瓷砖原始图像的检测提出了多滑动窗口的检测方法,该方法比单滑动窗口的检测方法更快。实验结果表明,与原 **YOLO** 检测算法相比,该方法的模型参数降低了 20.46%,浮点运算减少了 26.22%,**mAP** 提高了 1.93%。

Ren 等^[22]针对卫生陶瓷数据不足的问题提出了一种数据增强方法,缩小训练集与测试集分布的显著差异,应用该方法在不同分类网络的实验中准确率从约 75%提高到近 90%。**Nogay** 等^[23]研究设计了一种基于声学噪声数据和迁移学习技术的陶瓷板裂纹深度学习模型,实验使用了 3 个不可见裂纹的陶瓷板和 1 个正常陶瓷板作为实验材料,结果表明基于噪声的深度学习模型准确率达到 99.5%。

Wang 等^[24]在瓷砖表面缺陷检测研究中,在原始 **YOLO** 模型中增加注意机制 **CBAM** 模块和小尺度检测层,并用深度可分离卷积代替原来的卷积,实验结果表

明该模型能够有效地解决小缺陷特征信息不足等问题。**Kim** 等^[25]针对陶瓷粉末检测研究中提出了一种新的放大变换算法,用于放大均匀纹理和微观尺度尺寸值的变化。这种方法相比传统的计算机视觉方法能获得更好的定量性能。

Huang 等^[26]提出一种基于无监督学习的缺陷检测方法来解决陶瓷基板缺陷检测问题。首先,该方法根据分组实例固有的复杂特征进行 **K-means** 聚类;其次,通过扩展过滤器来平衡少数类和多数类之间的分布。最后,利用平衡后数据集来训练卷积神经网络,并通过与其他方法的比较验证了该方法的有效性。

基于以上研究现状,传统数字图像处理表面缺陷检测方法应用在陶瓷插芯表面缺陷检测有以下问题:一方面,陶瓷插芯的材料属性决定了工件的数字图像特征容易受照明条件如光源不同、强度不同、角度不同影响和干扰,基于数字图像处理的方法需要在不同环境下需要做不同的特征提取方法的设计,导致最终提取算法的泛化性和鲁棒性不足;另一方面,基于数字图像处理算法对特征提取方法的人工设计依赖严重,复杂背景中的特征提取下通常需要针对对应背景进行复杂调参,设计难度大且模型推广效果差。

陶瓷插芯的表面缺陷检测中,缺陷特征可能形态多变如裂纹、崩缺等,缺陷位置可能相互叠加如多个缺陷集中在同一位置,采用传统数字图像处理方法如边缘提取、梯度直方图等方法在本场景下表现欠佳。基于深度学习的表面缺陷检测方法相较于传统数字图像处理方法而言,自学习的特征提取过程能够提取图像更多深层、高维的语义,泛化性和解释性更强,更适用于本研究场景。

1.2.2 基于深度学习的小目标缺陷检测研究现状

实际的工业应用中,基于深度学习的表面缺陷检测性能主要取决于训练样本图像的数量和质量。相较于其他类型的工件缺陷样本图像,陶瓷插芯的部分缺陷如污点、小裂纹等在采集图像上的尺寸占比微乎其微,深度学习过程更难以学习到小目标特征,因此小目标检测在基于深度学习的目标分类领域也是较为棘手突出的问题;

近年来在小目标检测的问题研究上,**Zhao** 等^[27]提出一种新的改进的钢铁表面

缺陷检测目标检测算法来解决表面缺陷检测小而复杂缺陷目标方面的不足。Zhao 等对模型网络进行多尺度融合训练,并采用可变形卷积网络代替了部分传统卷积网络。Yang 等^[28]针对铝材表面小目标缺陷漏检和误检的问题,提出了一种改进的 Faster R-CNN 模型来检测油漆气泡和脏点,比原 Faster R-CNN 网络提高了 6.59%。

Li 等^[29]提出了一种满足工业实时生产需求的轻量级分割模型进行织物疵点的小目标检测。该模型通过对抗训练、优化目标函数、图像二次处理实现。实验结果表明该模型优于传统语义分割模型。Feng 等^[30]针对现有的低分辨率图像的带钢表面缺陷检测提出了一种热轧带钢表面缺陷数据集,并对 ResNet 进行了改进。

J.Li^[31]等针对汽车导光板图像纹理复杂渐变、亮度不均、缺陷较小等特点,提出了一种基于视网膜网改进的导光板缺陷视觉检测方法。该方法更有效融合骨干特征并提取网络中的浅层语义信息和高层语义信息,进一步提高小目标缺陷的检测能力。Xue 等^[32]借鉴传统的 TCM 方法,采用基于深度学习的机器视觉检测方法,实现了金刚石工具磨削质量的机上检测。该方法对金刚石工具小尺寸缺陷目标的识别过程进行优化,改善小数据量对识别网络训练的影响。

Zhou 等^[33]提出了一种基于快速区域卷积神经网络的道路缺陷检测框架,并在车载摄像头道路缺陷检测领域中取得效果,平均精度提高 1.83%。Liu 等^[34]提出了一种基于深度学习目标检测网络的高压输电线路关键目标和缺陷检测方法,优化后的检测网络的检测准确率和召回率分别为 93.5%和 96.2%。并能够检测复杂环境中的小目标缺陷。

Yang 等^[35]提出了一种基于频移-卷积自编码器网络的表面缺陷检测方法。该方法仅需要对无缺陷样本进行模型训练,较大程度上减少人工标注时间。实验结果表明,该方法的检测性能优于其他基于图像重建和物体检测算法的表面缺陷检测方法。Zhang 等^[36]提出了一种多尺度渐进生成对抗网络 MAS-GAN,该模型采用渐近增长策略合成多尺度表面缺陷图像,并采用非泄漏数据增强方法处理生成模型在样本不足情况下的性能退化问题。

She 等^[37]提出了一种利用小样本、数据增强和迁移学习实现的卷积神经网络

集成应用于绝缘子破损检测。该方法对绝缘子破损的识别准确率可达 98.7%。Yu 等^[38]提出了基于 Pelenet 模块的轻量级网络 WM-Pelenet, 并提出了一种基于卷积自编码器的数据增强方法, 与未经优化的原始 Pelenet 网络相比, 参数数量和 FLOP 分别减少了 92.68%和 58.85%, 同时对少数类的识别准确率也有明显提高。

综上所述, 以上各个领域基于深度学习的表面缺陷检测研究现状中, 对各自的小目标缺陷检测问题均提出了对应的解决策略, 并实现满足实际需求的检测任务目标, 这些研究对陶瓷插芯表面缺陷检测中需解决出现的小目标难以检测等问题提供了解决思路。

1.2.3 不平衡数据集数据增强方法研究现状

在深度学习领域, 数据集是模型训练的原材料, 数据集的数据大小和数据分布直接关系到最终模型的性能好坏。然而数据的获取和收集有时是困难的, 这直接导致数据集的不平衡和不足等问题。数据的匮乏是当前深度学习模型训练的主要挑战之一, 下文介绍在各个领域解决深度学习中数据集不充分不平衡问题的研究现状。

Haruna 等^[39]针对农业领域水稻病叶图像数据缺乏和不平衡问题, 提出生成对抗网络自适应判别器增强(SG2-ADA)和拉普拉斯滤波器的方差来生成新水稻叶数据, 以提高 Fast-RCNN 和 SSD 模型在检测水稻是否病变的检测性能。

Kate 等^[40]对金融领域 ACRM 问题中的信用卡流失预测、保险欺诈检测、贷款违约预测的数据不平衡问题, 提出了两种数据平衡的方法, 首先提出一种基于生成对抗网络的 ChaoticGAN 方法, 其次采用一类支持向量机(OCSVM)获得的欠采样的多数类数据来增加 GAN 及其变体获得的超采样的合成少数类数据。实验结果表明在所有数据集上都与最先进的 CTGAN 统计学上相似, 同时在交叉验证的 AUC 上比其他方法显著。

Du 等^[41]为解决工业控制系统中不平衡的数据集和标记样本不足的难题, 提出了一种基于长短期记忆自动编码器(LSTM-Autoencoder)网络和生成对抗网络的无监督异常检测方法, 模型使用正常数据进行训练来重建新数据。

Baca 等^[42]提出了一种只使用正常数据并带有自我标签的旋转机械的异常检测方法,采用了一种自我标记的方法来生成新的标记数据集,解决了旋转机械异常数据不足和不平衡的问题,结果显示所提出的算法可以检测轴承试验台和压缩机的故障,准确率超过 99.7%。

Liu 等^[43]在网络安全领域针对攻击数据集的稀缺性和不平衡性,提出了一种基于生成对抗网络和特征选择的过度采样技术。Liu 等基于梯度惩罚同时对复杂的高维攻击分布进行建模产生额外的攻击样本,然后根据方差分析选择代表整个数据集的特征子集,最终生成一个重新平衡的低维数据集用于机器学习训练。实验结果表明该方法可以有效地提高机器学习模型的检测性能。

Zhao 等^[44]针对病叶图像样本数量的不平衡性,提出使用双生成对抗网络来生成不健康植物叶片的图像。与 DCGAN 生成的图像进行比较,该方法生成的图像比 DCGAN 更清晰,植物种类和疾病的识别准确率分别达到 99.80%和 99.53%,识别结果远优于原始数据集结果。

Hou 等^[45]为解决电力物联网背景下网络流量数据集不平衡的问题,提出了一种基于 GAN 样本增强的 PloT 恶意流量检测方法,来改善模型泛化能力差的问题。Shin 等^[46]在基础设施领域针对退化的建筑结构数据短缺和不平衡等问题,使用生成对抗网络开发了一种数据增强的方法。与使用小数据集训练的模型相比,该方法的平均性能提高了约 16%。

Yun 等^[47]对训练对象图像不平衡和不足的问题上提出一种全新的剪切和粘贴法,传统的剪切和粘贴法通过从训练图像中剪切物体区域并将其粘贴到其他背景图像上来生成训练数据集,然而这种训练方法易受到传统领域转换问题的影响,Yun 等通过用 GAN 生成种子图像使前景多样化,并使用图像处理技术简化背景,从而平衡不平衡的域间差距。实验结果表明该方法能够有效地平衡域间差距,并在杂乱的室内环境中仅用几张种子图像就能提高物体实例检测的准确性。

综上所述,各个领域基于不充分不平衡的数据集的深度学习研究现状中,均在训练模型前对数据集的少数类进行不同方法上的增强和扩充。本文在解决陶瓷插芯表面缺陷数据集不平衡和样本不足问题的过程中,能够从以上研究中得到借

鉴和参考。

1.3 论文研究内容与架构

当前基于深度学习的陶瓷插芯表面缺陷检测研究仍存在以下难题：

第一，陶瓷插芯表面的各类缺陷样本数量极不均衡。污点、裂纹等缺陷样本较易获取，但如凹坑、擦伤、崩缺等缺陷样本数量严重不足，工业实际场景中获取此类稀缺缺陷的条件也非常有限。基于深度学习的缺陷检测模型的训练过程通常需要尽量多的数据集样本作为基础，而这些特定种类缺陷样本的稀缺会导致模型训练过程容易发生过拟合或欠拟合现象，泛化能力不足。因此如何利用好部分少数类缺陷类别的图像，以此来适应检测模型的整体训练是迫切需要解决的问题。

第二，直径 2.5mm 的陶瓷插芯的尺寸整体偏小，陶瓷插芯的如小污点、小裂纹等超小尺寸缺陷在图像中更是微乎其微。如果直接将陶瓷插芯缺陷图像作为无监督的对抗网络的输入，很难学习到在图像面积占比小的缺陷特征，生成效果容易偏离预想方向。因此如何使对抗生成网络从信息众多的原始图像学习到缺陷特征，更好的生成并扩充少数类缺陷图像也是本文的难题。

第三，在训练模型的过程中随着网络结构的深度增加，小目标特征如小裂纹、小污点等很可能在深层次的网络丢失，导致模型对小尺寸缺陷的学习能力不足。因此合理设计网络结构使其能满足小尺度缺陷目标检测也是需要的解决难题之一。

第四，工业上相机设备和图像算法平台的批量配置可能会考虑到成本问题无法普遍达到研究水平，因此工业上如何保证在要求的准确率的前提下尽可能降低模型内存和提高模型的检测速度也是需要重点考量的问题。

根据上述问题，本文展开研究工作如下：

(1) 本文结合陶瓷插芯表面各类缺陷的特点，通过搭建实验平台采集了陶瓷插芯图像并完成数据标注，提出一种陶瓷插芯表面缺陷的原始数据集。该数据集可用于陶瓷插芯表面缺陷检测模型的训练与验证，填补了陶瓷插芯表面缺陷检测领域的数据集的空白。

(2)本文针对陶瓷插芯缺陷样本数据集规模和分布不平衡且采用传统手段难以扩充的问题,提出了一种结合对抗网络的基于离散掩膜差分的缺陷图像重生方法,并提出该方法的 3 个过程:掩膜差分提取算法、对抗网络离散数据生成、融合重构混合数据增强,实现缺陷的重构与生成,对数据集的少数类缺陷进行扩充,对多数类缺陷进行增强,实现数据集分布的再平衡和扩充增强。

(3)本文提出了一种基于 YOLOv4 的轻量化高效的陶瓷插芯表面缺陷检测模型 FM-YOLO。该模型在全局网络上采用深度可分离卷积轻量化替代,引入 scSE 模块进行空间及通道激励,引入 ASFF 模块实现自适应空间融合,边界预测阶段引入 DIoU-NMS 算法优化,新增第 4 种预测尺度,最终实现模型在检测精度和检测速度的双提升。

(4)基于陶瓷插芯表面缺陷检测总体方案,设计并开发一种可视化图形界面的检测软件,其能够对生产环境中的陶瓷插芯进行实时检测。软件在检测过程中逐渐积累缺陷样本,后续能对 FM-YOLO 模型进行二次训练和校准,保持模型在不断迭代的过程中的泛化能力和鲁棒性。

本文共分为六章,各章的内容安排如下:

第 1 章,首先阐述本文的研究背景和意义;然后介绍了陶瓷工件和小目标检测问题的表面缺陷深度学习检测技术的研究现状;最后给出了本文的主要工作和论文框架。

第 2 章,设计陶瓷插芯表面缺陷检测整体方案,构建陶瓷插芯表面缺陷的原始数据集;同时对检测模型的对照模型、目标检测模型和图像生成效果的评价指标进行选型。

第 3 章,提出了一种结合对抗网络的基于离散掩膜差分的缺陷图像重生方法,详细阐述重生方法的 3 个主要过程的设计过程和原理依据;同时通过对缺陷图像重生方案 3 个过程各自的独立有效验证和组合消融验证对方案的可行性进行实验论述。

第 4 章,提出了基于 YOLOv4 的 FM-YOLO 模型,从网络结构、网络模块、预测算法的多方面上进行 5 个改进,并对提出的 FM-YOLO 模型进行基于深度迁

移学习的训练验证和实验验证。

第 5 章，设计并开发陶瓷插芯表面缺陷检测软件，并采用检测软件进行第 3 章和第 4 章提出的基于离散掩膜差分的缺陷图像重生方法和 FM-YOLO 模型的组合综合实验验证。

第 6 章，对全文研究工作进行总结，并对研究工作的后续进行展望。

本文的内容框架如图 1.3 所示。




图 1.3 本文的内容框架

1.4 本章小结

本章阐述了陶瓷插芯表面缺陷检测的研究背景和意义，分析研究领域存在的问题及国内外的研究现状，最后对本文的研究内容进行概述，并给出本文的文章结构和内容框架。

第 2 章 陶瓷插芯表面缺陷检测方案总体研究

2.1 引言

本章首先介绍陶瓷插芯加工工艺的简要流程，对陶瓷插芯表面缺陷检测对象进行缺陷特点分析并设计了陶瓷插芯表面缺陷的检测方案总体流程；然后对陶瓷插芯检测任务进行实验平台和原始数据集的构建并分析数据集特点；最后对检测模型和评价指标进行选型。

2.2 陶瓷插芯表面缺陷分析

如图 2.1 所示，陶瓷插芯主要材料为二氧化锆(ZrO_2)材料，其制备的主要工序包括^[48]：原料配置、毛坯制作、混炼、脱脂、烧结、粗磨、内外径研磨抛光、PC(Physical Contact)研磨、表面检测等工序。主要流程为：首先采用特殊处理后的二氧化锆原料造粒，在专用模具中注射成型，脱脂后高温烧结成毛坯，然后毛坯再在一系列超精密研磨、抛光等机械加工后达到高质量、高精度的陶瓷插芯。工业现场由于材料质量、工艺特殊、设备老化、人员失误等诸多因素，陶瓷插芯在不同生产工艺过程中可能会产生各异的表面缺陷，会严重影响陶瓷插芯的对中精度，降低光纤通信的性能甚至中断。因此需要在检测阶段及时把表面质量不达标的陶瓷插芯样品筛选出来进行二次工艺，以提高产品良率和利用率。




图 2.1 陶瓷插芯工艺流程图

光纤陶瓷插芯按照传输波长的不同可以分为多模光纤和单模光纤陶瓷插芯，

单模相较于多模光纤陶瓷插芯精度要求更高，孔径更小；按照插针体外径的不同可以分为外径 2.5mm 的 SC 陶瓷插芯以及外径 1.25mm 的 LC 陶瓷插芯。如图 2.2 所示，陶瓷插芯机械结构主要包括陶瓷体、插芯头部、端面倒角、插芯内孔。




图 2.2 陶瓷插芯结构组成图

目前工业上用于光纤通信主要使用的型号是 SC 型单模陶瓷插芯，同时也是本文的研究对象，下文提到的陶瓷插芯均默认为此型号和尺寸，其尺寸参数如表 2.1 所示。

表 2.1 SC 型单模陶瓷插芯尺寸参数

型号	模数	外径	内径	总长
SC 型	1	2.50mm	0.125mm	10.50mm

陶瓷插芯需要检测的表面缺陷有：裂纹、凹坑、崩缺、污点、擦伤。其中裂纹缺陷通常发生在陶瓷插芯加工的脱脂阶段，脱脂工艺的作业不规范或参数不正确可能会使陶瓷在注射成型过程中导致开裂，从而产生裂纹缺陷。如图 2.2，裂纹一般呈均匀线状，宽度一般为 0.1mm~0.2mm，长度区间较大，一般为 5mm~12mm，因此不同裂纹在图像中的占比可能会有较大的差异。




图 2.2 陶瓷插芯裂纹缺陷图

凹坑的形成一般有工艺成因和运输成因，一方面，烧结工艺过程中气体未能完全排出可能会导致陶瓷插芯成品出现凹坑缺陷；另一方面，陶瓷插芯在加工运输过程中与其他物体产生剧烈的摩擦碰撞也可能产生表面凹坑。如图 2.3，凹坑在形态上呈近圆形，直径约 1mm-3mm。




图 2.3 陶瓷插芯凹坑缺陷图

崩缺缺陷一般发生在机械精密加工阶段如研磨、抛光等，加工过程的夹具故障可能会导致部分陶瓷插芯在外力作用下发生倒角或孔口处的崩缺。如图 2.4 所示，崩缺的大小一般占陶瓷插芯体积的 $1/20 \sim 1/10$ ，具有崩缺缺陷的陶瓷插芯工作期间会出现严重的对接异常，导致光纤通信问题。




图 2.4 陶瓷插芯崩缺缺陷图

如图 2.5 所示，污点缺陷由陶瓷插芯加工阶段的油脂残余或其余杂质附着在陶瓷插芯表面所致所产生，一般为深色圆状，直径约 $1\text{mm}-2\text{mm}$ ，此类缺陷的存在导致不美观的同时还会造成陶瓷插芯长时间工作表面载荷分布不均，从而产生陶瓷插芯表面剥落等现象。




图 2.5 陶瓷插芯污点缺陷图

擦伤缺陷的产生原因通常有两种：第一，毛坯制作切割过程中原料破碎导致的擦伤；第二，陶瓷插芯和其他异物刮擦所致。如图 2.6，短小的擦伤在形态上和裂纹类似，但宽度略大以及长度略小于裂纹缺陷，宽度一般为 $0.3\text{mm}-0.5\text{mm}$ ，长度一般为 $4\text{mm}-8\text{mm}$ ，在检测阶段容易与裂纹发生混淆。



图 2.6 陶瓷插芯擦伤缺陷图

2.3 图像采集平台选型与搭建

实验平台的搭建是展开陶瓷插芯表面缺陷研究的基础。而图像采集是构建数据集的必不可少的步骤，陶瓷插芯具有尺寸小，打光过程易反光等特点，因此图像采集硬件设备选择和光照条件布置都会直接影响到图像上缺陷的特征提取难度，从而影响到最终模型检测性能的优劣。如图 2.7 所示为陶瓷插芯表面缺陷检测系统的图像采集实验平台搭建图。其中图像采集平台最核心的 3 个部件为：工业相机、光学镜头、照明光源。




图 2.7 实验平台搭建图

工业相机作为机器视觉系统中的眼睛，其主要功能是收集成像产生的电信号，统一输出到放大器生成陶瓷插芯图像数据样本。工业相机较于一般摄像机，具有抗冲击、快响应、高灵敏等特点，适用于工业现场的图像采集。本研究中所选型的工业相机型号为：MER-132-30GM 型 CCD 工业相机，帧率为 30FPS。

光学镜头的主要参数有焦距、光圈、分辨率等。焦距反映了被测物体和其成像之间的比例，镜头的焦距越长成像越大；光圈与镜头的入光量相关，调整光圈可以改变图像的亮度；分辨率是像面镜头在单位毫米内能分辨的黑白条纹对数，描述了镜头清晰再现被测物体的能力，分辨率越高的镜头，拍摄的图像越细腻越清晰；本研究中所选型的镜头为 OPT-C2514-2M 型 C 口镜头，焦距为 25mm，最大分辨率为 1292×964 。

照明光源的选型在陶瓷插芯表面缺陷检测研究中影响很大，陶瓷插芯表面呈圆柱曲面、高亮易导致强反光，容易受光源影响导致图像明暗不均、掩盖缺陷等问题，从而干扰图像特征的提取，因此照明光源在选型上需要满足供光性能稳、光照均匀性好、亮度范围大。环形光源配合漫射板使用具有安装方便、光照均匀、光源稳定等优点，本研究中所选型 YSC-R9060W 型白色 LED 环形光源及 YSC-KZQ-2 型光源控制器。

本研究中所用服务器硬件和软件配置如表 2.2。

表 2.2 本研究服务器硬件及软件配置

硬件配置	软件配置
NVIDIA GeForce RTX 2080Ti 11GB GPU ×2	CUDA 11.6.2
Intel Core i9-9900K 3.60GHz CPU ×1	PyTorch 1.13.0
Kingston DDR4 3200MHz 32GB Memory ×2	Python 3.7

2.4 陶瓷插芯表面缺陷数据集构建

数据集是由一系列数据构成的集合。本研究中的数据集的组成部分主要为陶瓷插芯缺陷图像数据、缺陷标注数据和缺陷类别数据。有监督学习深度学习检测任务中，模型训练的鲁棒性是以大量充足的数据集为基础的。目前深度学习目标检测领域中常用的公开数据集有 COCO^[49]、PASCAL VOC^[50]、ImageNet^[51]等，但当前公开数据集并未包含本研究中的陶瓷插芯表面缺陷图像数据，因此本文通过搭建的图像采集平台采集陶瓷插芯 2540 张图像，并对其缺陷进行分类和标注，提出了一种陶瓷插芯表面缺陷数据集，填补了此前深度学习领域在陶瓷插芯数据集的空缺。

本研究中采用图像标注软件 LabelImg[®]进行标注，标注时采用矩形框选出陶瓷插芯的表面缺陷位置和类别，标注内容有矩形框的左上角坐标值、右下角坐标值和类别标签，最终按照 PASCAL VOC 和 YOLO 数据集两种格式保存。模型能够借助标注信息中的左上角和右下角的坐标值计算出标注框的中心坐标值 (x, y) 和标注框的宽 (w) 和高 (h) 。

数据集共有 5 种标签，分别为 4 种缺陷和 1 种陶瓷插芯结构，包含裂纹(crack)、

擦伤(bruise)、凹坑(pit)、污点(blots)和芯头(head)。其中崩缺缺陷在采集图像中体现为陶瓷插芯芯头的部分或全部缺失,由于数据标注过程无法标注出未出现在图像的对象,因此本研究转而对陶瓷插芯芯头(head)特征进行标注并加入需要识别的类别,检测过程中对未识别出芯头(head)结构特征的图像即可判定为存在崩缺缺陷。为确保数据集标注精度和有效性,本研究中的数据集的每张图像都经过2名人员复核和确认,并取其2人标注矩形框的坐标、宽高的平均值作为最终的标注数据。图2.8所示为陶瓷插芯表面缺陷数据集标注实例,其中图2.9的a~c为凹坑缺陷;d~f为裂纹缺陷;h~j为污点缺陷;k~m为擦伤缺陷;g、n为芯头特征。




图 2.8 陶瓷插芯表面各缺陷数据集标注图

本数据集根据目标标注框的面积占图像的像素多少划分为超小、小、中、大目标四种尺度。本文拍摄陶瓷插芯图像分辨率为 800×800 , 共 64 万个像素点, 其中超小目标定义为占图像面积小于 0.05% 即像素点数小于 320 个的缺陷目标, 该尺度下的表面缺陷一般为污点居多; 小目标指占图像面积占比 0.1%~0.2% 区间即像素点数处于 640~1280 区间的缺陷目标; 中目标指占图像面积占比 0.2%~1% 区间即像素点数处于 1280~6400 个数区间的缺陷目标; 大目标指占图像面积占比大于 1% 区间即像素点数大于 6400 个的缺陷目标。裂纹缺陷在小、中、大目标均有占比; 污点缺陷在超小、小目标占比较多; 芯头特征均为中目标尺寸, 凹坑缺陷大部分集中在为中等尺寸。

本研究数据集中各缺陷按照类别数量统计如表 2.3, 其中崩缺缺陷无尺度特征, 这里通过判断有无芯头特征来确定是否为崩缺缺陷。

表 2.3 陶瓷插芯原数据集类别及尺寸分布情况

类别	数量	不同尺度			
		超小	小	中等	大
陶瓷插芯	2540	-			
芯头	2127	0	0	2127	0
凹坑	146	4	19	123	0
污点	2132	540	1560	32	0
裂纹	1634	0	111	1034	489
擦伤	173	23	53	65	32
崩缺	413	-			

各类样本分布具有不平衡不均匀性，最多和最少的缺陷样本数量比甚至达到悬殊的 15:1。同一个陶瓷插芯可能存在多个污点、裂纹表面缺陷，且工业现场易产生此类缺陷因此污点、裂纹样本数量在数据集中占比较大；然而，凹坑、擦伤、崩缺缺陷由于工业现场难以获得导致数据集中的样本极少；崩缺缺陷的识别可以通过有无芯头特征进行判断，而芯头特征数量丰富，可供训练学习的样本充足；凹坑和擦伤样本则需要通过后续的数据增强方法对数据集进行平衡。数据集缺陷和特征的总体分布图如图 2.9 所示。




图 2.9 数据集缺陷特征及不同尺寸数量分布饼状图

2.5 缺陷检测整体流程设计

本研究采用深度学习目标检测模型实现陶瓷插芯表面缺陷检测，如图 2.10 所示，整体流程包括：数据集构建、检测模型训练、在线检测。




图 2.10 陶瓷插芯表面缺陷检测整体流程设计

(1) 数据集构建

数据集的构建是开展基于深度学习的目标检测模型的基础。表面缺陷深度学习目标检测模型依赖于大量图像数据，以充分提取图像深层、高维度特征。本文的陶瓷插芯数据集的来源主要分两部分：原始数据集和检测后数据集。其中原始数据集的缺陷图像数据来源于通过图像采集设备对原始陶瓷插芯样本的采样，是模型训练的原材料。原始缺陷图像数据的主要作用是训练出能初步投入工业机器视觉检测的模型，检测后新缺陷图像数据是初始模型投入工业使用后在生产过程中识别为缺陷的新样本，这些新样本数据可以作为数据集的扩充，帮助模型进行二次训练，完善模型的初始参数并让模型向理想真实模型趋近，避免模型出现过拟合或欠拟合现象。

本研究通过陶瓷插芯图像采集实验平台对陶瓷插芯进行采样，并对采集后的图像中的缺陷进行数据标注，最后将数据集按照 8:1:1 的比例划分为训练集、验

证集和测试集。

(2) 检测模型训练

检测模型的训练是本研究实验的核心。数据集搭建完成后,采用训练集作为模型的学习输入,采用测试集验证模型的泛化性能,采用验证集调整模型的超参数。训练模型的过程中可能会因为初始参数的设置或策略方案的选择造成模型无法收敛,此时需要对模型及时调整参数或改变策略后重新训练,直到训练模型收敛。若测试集的精度不满足预期要求,就需要对网络结构进行调整,直到下次收敛的模型达到预先目标的精度要求。

(3) 在线检测

在线检测步骤是本研究中检验实验成果的关键。上述的模型训练完成后,将工业流水线上实际待测试陶瓷插芯的图像输入模型,可以得到陶瓷插芯表面的缺陷位置和类别。同时本研究实现一种检测结果扩充数据集机制,如模型检测识别的缺陷识别正确的新缺陷图像,当新图像积累到一定数量后能扩充原有数据集,并对模型进行二次训练,增强模型的鲁棒性和泛化性。

数据集的构建是后续训练模型的基石,训练模型过程训练策略的选择和模型网络结构的调整是保证后续在线检测精度的关键,在线检测过程产生的新缺陷图像也可以作为原始数据集的扩充二次训练,继续提升检测模型的精度,这些流程环环相扣,形成一个正反馈的闭环。

2.6 检测模型选型

如2.5节缺陷检测整体流程设计所述,本研究通过实验平台构建数据后,需要输入到深度学习模型进行训练,而合理选择适用于陶瓷插芯表面检测任务的模型是影响本研究模型最终检测效果的关键点。

检测模型选型要考虑的因素有两方面:第一,陶瓷插芯表面缺陷上的缺陷尺度跨度较大,裂纹等缺陷在形态上呈现各向异性、大小不一,污点等超小目标缺陷特征可能在深层网络卷积过程中丢失,候选框的预设大小和比例难以学习,且陶瓷插芯圆柱状,一张图像无法描述陶瓷插芯的全部特征,确定一个陶瓷插芯的

缺陷类型和数量需要多次旋转陶瓷插芯，因此对检测速度有较高的要求，本文旨在找到一个能满足小目标检测和高检测速度的目标检测模型。

目前基于深度学习的目标检测领域主要根据提取特征的阶段数目的不同分为两阶段(Two-Stage)模型和单阶段(One-Stage)模型。

2.6.1 Two-Stage 检测模型

Two-Stage 模型最早由 Ross^[52]等在 2014 年提出的一种结合深度卷积网络(Deep Convolutional Neural Network, DCNN)和区域生成方法(Region Proposal Approach)的 R-CNN 模型。该模型的提出在基于区域生成的 Two-Stage 检测框架领域的具有里程碑意义。




图 2.11 R-CNN 检测原理图

R-CNN 的检测流程如图 2.11 所示,R-CNN 第一阶段采用选择性搜索(Selective Search, SS)算法^[53]计算出 2000 多个可能包含检测目标的候选区域,第二阶段将候选区域放缩到固定的像素尺寸,以满足后续的卷积神经网络(Convolutional Neural Network, CNN)的初始输入尺寸要求,之后在 CNN 中训练得到图像特征向量后输入到 SVM 进行目标类别概率的预测,R-CNN 回归器能对候选框的原始尺寸和比例进行微调,最终得到较为准确的候选框和目标分类结果。由于 SS 算法在搜寻候选框过程需要消耗大量计算资源,训练和检测的速度慢,对训练硬件环境要求高,无法完成实时检测任务。

Fast R-CNN 是 Ross^[54]在 2015 年提出的对原 R-CNN 模型的改进版, Fast R-CNN 提出了感兴趣区域 (Region on Interesting, ROI)池化层。相较于 R-CNN 将所有 2000 多个候选框全部输入 CNN 获取特征, Fast R-CNN 直接将整张图像输

入 CNN 得到特征图，候选框直接从特征图的映射关系中获取对应的特征矩阵，特征矩阵再通过 ROI 池化层归一化为统一尺寸后再输出到全连接层进行分类任务。这种方法避免了候选框的大量重叠而造成的冗余重复计算，极大程度上提升检测速度，减少了训练所需硬件内存。

尽管 Fast R-CNN 相对于 R-CNN 有较大的改进，但第一阶段的 SS 算法的大量无效重复计算没有得到解决，因此 Ross^[55]又提出了 Faster R-CNN 模型，引入区域建议网络(Region Proposal Network, RPN)来替代缓慢的 SS 算法，同时 RPN 和 CNN 的结合让 Faster R-CNN 模型真正实现了端对端学习，将区域提取、特征提取、目标分类、预测框回归统一到同一框架，所有计算可以完全在 GPU 中完成，极大提升运算速度。

R-FCN 是由 Dai 等^[56]在 2016 年提出的 Faster R-CNN 演变而来的 Two-Stage 模型。Dai 等人引入位置敏感得分机制，解决了目标检测和目标区域分类对位置平移不变性敏感度不同的矛盾。基于投票的位置敏感得分机制融合 ROI 池化层，用卷积层替代全连接层，减少了网络模型的参数数量，进一步降低了模型的计算量，提高了检测速度。

Two-Stage 模型将目标检测分类任务分解成了提取区域及区域内目标分类两个子问题。Two-Stage 比 One-Stage 模型增加了第一阶段的候选区域预先提取，因此识别准确率通常比 One-Stage 模型更高，但检测速度较慢，计算资源要求较高，适用于对实时检测要求不高的场合。

2.6.2 One-Stage 检测模型

One-Stage 不同于 Two-Stage 检测模型，其核心思想是将目标检测任务视为对图像划分的每个网格的类别、候选框位置、尺寸的回归问题，节省了 Two-Stage 第一阶段筛选出候选区域的过程。常见的 One-Stage 检测模型有 YOLO(You Only Look Once)系列模型和 SSD(Single Shot MultiBox Detector)模型。

YOLO 系列模型始于 Redmon 等^[57]于 2015 年提出 YOLOv1 模型，将整张图像输入 CNN 并回归计算预测框的坐标位置、尺度、类别及置信度。如图 2.12 所

示, YOLOv1 首先将图像划分成 $S \times S$ 的网格, 每个网格预测两种类别的预测框, 最后通过 NMS 算法合并、消除重复重叠的预测框得到最终检测结果。YOLOv1 相较于 Two-Stage 检测模型, 检测速度得到极大提升, 但检测精度不高, 尤其难以定位小物体, 容易漏检多目标重叠的区域。




图 2.12 YOLO 模型原理图

YOLOv2 是 Redmon 等^[58]对 YOLOv1 检测精度低等问题做出的改进版本。该模型借鉴 Two-Stage 模型中的锚框(anchor)概念, 结合 K-means 聚类算法对预测框进行聚类, 得出最适合用于检测标注的预测框的形状比例; 同时 YOLOv2 在 YOLOv1 网络结构的基础上增加批量归一化(Batch Normalization, BN)层, 加快模型学习的收敛速度, 降低学习速度和难度, 增强模型鲁棒性和泛化能力。

2018 年, Redmon 等^[59]再次对 YOLO 系列模型做出改进, 提出 YOLOv3 网络, 结合特征金字塔网络(Feature Pyramid Network, FPN)融合网络深层和浅层特征信息, 同时将主干网络(backbone)的 DarkNet-19 替换成 DarkNet-53 残差网络, 分类层由 Softmax 替换成 Logistic, 使 YOLOv3 可以完成多标签目标分类任务。

Wang 等^[60]在 2020 年提出 YOLOv4, backbone 上将 YOLOv3 的 DarkNet53 残差网络替换成 CSPDarknet53 (Cross Stage Partial DenseNet), 同时采用空间金字塔池化(Spatial Pyramid Pooling, SPP)模块^[61]、FPN 和路径聚合网络(Path Aggregation Network, PAN)作为网络 Neck 部分, 有效增加主干网络的感受野, 增强学习能力的同时减小模型内存占用, 降低计算瓶颈。YOLOv5 是由 Ultralytics 公司提出的基于 YOLOv4 网络的大型开源项目, 目前仍保持更新状态。

SSD 模型结合了 Two-stage 模型的 Faster R-CNN 锚框及 One-Stage 模型的 YOLO 系列的回归思想, 于 2016 年被 Liu 等^[62]提出。SSD 模型融合了 Two-stage 模型的高检测精度和 One-Stage 模型的高检测速度优点, 锚框在特征提取网络的

多层上产生，可以在不同感受野下检测目标。

2.6.3 对照模型选型

本研究在选取目标检测的对照模型过程中，考虑到工业现场陶瓷插芯检测准确率、速度、计算资源因素，Two-Stage 模型选取具有代表性的 Faster R-CNN 和 R-FCN 模型，One-Stage 模型选取 YOLOv4、开源版本的 YOLOv5 以及具有综合优势的 SSD 模型。陶瓷插芯表面缺陷检测任务中，一方面由于实时检测是工业现场刚需，对检测速度要求更高；另一方面工业实际场景大量部署检测模型更追求小内存模型、低计算消耗、易移植可灵活部署等特点；因此选取 YOLOv4、YOLOv5、Faster R-CNN、R-FCN、SSD 模型选用为本研究的基本模型。

2.7 评价指标

2.7.1 目标检测模型评价指标

目标检测算法中有不同的评价指标，通常通过准确率(Precision)和查全率(Recall)来表现模型的检测性能，其中 mAP(Mean Average Precision)作为评价指标可以综合体现检测模型的准确率和查全率，也是目前目标检测模型性能评价体系中最频繁最常见的评价方式。

表 2.4 混淆矩阵

		预测结果	
		正例	负例
真实结果	正例	正确正例（TP）	错误负例（FN）
	负例	错误正例（FP）	正确负例（TN）

本研究陶瓷插芯的检测场景中，图像中的待检测的缺陷目标为正例(Positive)，而背景非缺陷部分目标为负例(Negative)。根据模型在图像中预测和实际情况的正例和反例的不同情况，可以分为表 2.4 中混淆矩阵的 4 种情形：即正确正例(True Positive， TP)，错误正例(False Negative)，正确负例(True Negative， TN)，错误负例(False Negative， FN)。

本研究的目标检测过程对正例和负例的区分是根据模型生成的预测矩形框(Bounding Box, BB)和真实矩形框(Ground Truth, GT)即数据集标注的矩形框的重合程度大小是否超过规定阈值,通常该项指标用交并比(Intersection over Union, IoU)来描述。如图 2.13 所示, IoU 的几何意义为两个矩形框的交集部分和并集部分之比,即粉色区域与所有带颜色的区域面积之比。




图 2.13 IoU 计算方式原理图

IoU 的数学表达如式 2-1 所示。本研究中正例反例的判别中 IoU 的阈值默认设置为 0.5。

$$IoU = \frac{GT \cap BB}{GT \cup BB} \quad (2-1)$$

本研究中准确率(Precisison)能够描述检测模型对单一类别预测结果的正确程度,计算方式为式 2-2,数学意义上为该类别预测正确的正例样本数量与所有被预测为正例的样本数量之比。

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2-2)$$

查全率(Recall)是检测模型中对单一类别预测结果是否完全、有无漏检的表现指标,定义公式如式 2-3 所示,数学意义上为该类别预测正确的正例样本数量与所有实际应预测为正例样本数量之比。

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2-3)$$

通常情况下准确率和查全率有着类似相互抑制的关系,很难同时兼顾。比如在实验中 IoU 阈值设置过高时,模型的准确率会有大幅度提升,但同时也会产生更多的漏检,查全率会相应下降。因此对于一个检测任务,可以绘制 PR(Precision - Recall)曲线来综合表现模型的准确率和查全率。单个类别的平均准确率(Average

Precision, AP)被定义为 PR 曲线和坐标轴围成的面积,数学定义为如式 2-4, AP 是综合描述该类别检测性能的重要指标。

$$AP = \int_0^1 P(R) dR \quad (2-4)$$

mAP 描述了检测模型多个类别的样本下的总体检测性能,计算如式子 2-5 所示:

$$mAP = \frac{\sum_{i=1}^n AP_i}{n} \quad (2-5)$$

本研究陶瓷插芯数据集存在样本不均衡问题,如果仅参考传统的精确率无法准确衡量少数类样本的分类精度,例如样本数据集中少数类样本仅占 2%,多数类样本占 98%,在极端情况下如少数类样本全部分类错误,准确率仍高达 98%,这样的计算方式容易忽略少数类样本检测精度。因此,本文引入 G_mean 指标, G_mean 指标是少数类和多数类分类精度的均值,更能反映数据集分布不均衡的检测模型的准确率;其中, G_mean 指标表达如式 2-6:

$$G_mean = \sqrt{\frac{TP}{TP + PN} \cdot \frac{TN}{TN + FP}} \quad (2-6)$$

本文选用 mAP、G_mean 指标来综合评价目标检测模型的在平衡数据集和不平衡数据集上的检测性能。

2.7.2 图像生成效果评价指标

陶瓷插芯数据集分布不平衡问题通常需要在数据层面上增加少数类缺陷的数据量来解决。该思想在本研究中体现的具体做法为:根据原有数据集的数据分布,通过生成图像算法产生近似少数类的缺陷图像,弥补原数据集少数类缺陷的数量不足。因此,为验证本文后续第 3 章中提出的生成图像方案的效果,需要参考相应的生成质量评价指标。本研究采用 FID 指标(Feche Inception Distance,)与相似结构指标(Structured Similarity Index Method, SSIM)的图像生成评价指标进行有效性验证。

FID 指标在本研究中是描述陶瓷插芯真实缺陷图像和生成图像的距离, FID

指标越小，生成图像越接近真实图像的分布，说明生成效果越好。FID 的基本思想是直接考虑两个数据分布在特征层次的差距，FID 使用 Inception Net-V3^[63]全连接层前的特征向量作为生成图像的特征，FID 的本质是计算两个多元正态分布数据的距离，数学描述如式 2-7：

$$FID = \|\mu_r - \mu_g\|^2 + Tr(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2}) \quad (2-7)$$

其中， μ_r 和 μ_g 指陶瓷插芯真实图像和生成图像的特征均值； Σ_r 和 Σ_g 指陶瓷插芯真实图像和生成图像的协方差矩阵； Tr 指矩阵的迹。

SSIM 指标的基本思路是模仿人类视觉感知主观评判而提出的结构相似度指标。SSIM 通过亮度、对比度、结构三个方面对两张图像的相似度进行评估，在图像样本中，以上的像素结构特征是相互关联的，因此 SSIM 指标通过衡量关联性进行评估，用数学语言可以描述为式 2-8：

$$SSIM(x, y) = [l(x, y)]^\alpha [c(x, y)]^\beta [s(x, y)]^\gamma \quad (2-8)$$

其中 $l(x, y)$ ， $c(x, y)$ ， $s(x, y)$ 指亮度、对比度、结构上 x 和 y 的对比； α, β, γ 指亮度、对比度、结构的权重指数。SSIM 指标取值于 $[0, 1]$ 区间，SSIM 越接近 1，说明生成图像和真实图像越相似。

2.8 本章小结

本章阐述了陶瓷插芯表面缺陷检测方案的研究和设计。首先介绍了陶瓷插芯的工艺制备流程和表面缺陷之间的关系，并总结出表面缺陷的几何特点和出现场合；其次根据陶瓷插芯的材料特点和表面缺陷的形状特性设计了检测方案并搭建了实验平台，从工业相机、光学镜头、光照条件等方面进行选型，并通过实验平台的图像采集构建了陶瓷插芯表面缺陷的数据集，分析数据集中的样本不平衡、存在超小目标等特点；然后根据检测方案和检测任务特点对当目标检测模型如 Faster R-CNN、R-FCN、YOLOv4、YOLOv5、SSD 等模型的基本原理进行介绍并选型为本研究的基本模型；最后给出检测评价指标和图像生成效果评价指标。

第3章 基于离散掩膜差分的缺陷图像重生方法研究

3.1 引言

陶瓷插芯表面缺陷数据集中的凹坑、擦伤、污点、裂纹、芯头在数量上的比例为 1:1:15:11:15，原始数据集的缺陷类别数量分布严重失衡。本文的少数类样本类别为凹坑和擦伤，多数类样本类别为污点、裂纹、芯头，不平衡数据集样本在检测模型的训练过程中，会导致多数类信息占据主导地位，使分类预测更偏向多数类，从而造成少数类缺陷的识别精度不足，无法满足工业实际需求。

传统解决数据集不平衡的手段一般是在数据层面上扩充少数类样本，常用的手段是采用对抗生成网络生成新的少数类缺陷图像进行样本均衡。然而，陶瓷插芯的表面缺陷特征在原始数据集图像中占比很小，直接输入无监督的对抗网络学习方向容易偏离，难以生成预期的新缺陷图像。因此，本文提出一种基于离散掩膜差分的缺陷图像重生方法，根据陶瓷插芯自身特点从原始缺陷图像中提取小尺寸、低分辨率的离散缺陷特征，并据此重新构建新的离散图像数据集，然后再通过新数据集输入到对抗网络生成新的离散缺陷特征，最后将新特征融合掩膜图像并重构生成新的陶瓷插芯表面缺陷图像，解决了陶瓷插芯表面缺陷图像直接对抗生成的低效率及原始数据集缺陷类别分布不均衡的问题。基于离散掩膜差分的缺陷图像重生方法的执行流程框架如图 3.1 所示，该方法包括了本文提出的 3 个重要算法流程：掩膜差分缺陷提取、对抗生成网络模型、融合重构混合增强。




图 3.1 本章提出的缺陷图像重生方法的执行流程框架

3.2 离散掩膜差分缺陷图像重生方法框架

本节针对陶瓷插芯缺陷样本不平衡问题在数据和算法层面上，提出了一种新的数据平衡和增强方法：基于离散掩膜差分的缺陷图像重生方法。该方法的主要过程为：首先提出了一种高阶掩膜缺陷差分提取算法来完成缺陷离散特征的提取，并据此新建一种浓缩的离散缺陷特征数据集；然后设计生成对抗网络模型完成离散缺陷图像的生成；最后离散特征和掩膜图像融合位姿重构并进行混合增强，实现少数类缺陷样本的数据扩充和多数类缺陷样本的数据增强，形成数据分布平衡、具有多样性的、适用于训练模型的增强后的缺陷图像重生数据集。




图 3.2 基于离散掩膜差分的缺陷图像重生的数据增强方法流程图

3.3 掩膜差分缺陷提取算法研究

陶瓷插芯数据集图像分辨率为 800×800 像素，单个缺陷在图像中占比很小，凹坑和擦伤缺陷的最大长和宽通常在 80 个像素点以内，缺陷占整个图像不足 1% 的面积。如果直接将整张图像作为生成对抗网络的输入进行训练，生成网络不仅受尺寸影响训练缓慢且容易受图像绝大部分无关信息的干扰而很难学习到真正

需要学习的缺陷的特征。因此本节提出一种基于掩膜差分提取的图像预处理流程，将关注的缺陷特征直接提取出来，使后续的生成对抗网络更高效的学习。

本文根据陶瓷插芯缺陷图像特点，总结并提出了一组正位姿无缺陷标准图像：掩膜图像(Mask)。本研究选取 100 组经过品质认证的无缺陷合格的陶瓷插芯，考虑到实际拍摄位置的抖动以及标准陶瓷插芯间的微小差异，在同一实验平台固定光照条件和固定位姿进行标准图像群的采集。标准图像群首先采用高斯双边滤波处理，保护陶瓷插芯的边缘高频细节的同时去除环境噪声；然后经过像素级别的位姿归一化调整，确保 100 组陶瓷插芯均在图像空间中完全一致的位置；最后取校正后的图像群的像素平均值生成 1 张最终的图像即掩膜图像。掩膜图像和缺陷图像如图 3.3 所示。




图 3.3 掩膜图像(左)和原始缺陷(右)图像对比图

本节提出的掩膜差分缺陷提取算法主要由图像正位归一化预处理、特征差分提取两个过程组成，如图 3.4 所示。




图 3.4 掩膜差分缺陷提取算法流程图

3.3.1 图像正位归一化

图像正位归一化预处理旨在将缺陷图像规范化，使其和掩膜图像的陶瓷插芯工件的位置姿势及噪声分布一致，方便后续的差分操作。该流程包括背景噪声去除、图像位姿矫正、腐蚀滤波归一化。如图 3.5 所示。




图 3.5 图像归一化流程图

背景噪声去除的目的是去除和陶瓷插芯主体无关的背景噪声；图像位姿校正过程是指统一缺陷样本图像和掩膜图像的陶瓷插芯在图像中的方位和角度，避免缺陷图像采集过程中出现的位姿随机性给后续的差分操作带来的误差；腐蚀滤波归一化是对校正过后的缺陷图像做高斯双边滤波处理，这个过程的目的是让缺陷图像在特征分布上更接近经过归一化处理的掩膜图像。下文将对这三个过程的具体细节进行阐述。

(1) 背景噪声去除

背景噪声去除的关键是保留陶瓷插芯主体前景图像的同时，去除其余部分的背景。陶瓷插芯缺陷图像采集环境结构较为简单，背景干扰主要是光照条件下实验平台底座纹理以及背景颗粒的椒盐噪声^[64]，如图 3.6(a)，本研究首先采用中值滤波器去除椒盐噪声；然后采用 OSTU-最大类间方差法^[65]，按照 L 个灰度级别将陶瓷插芯表面缺陷图像分为背景区域 G_1 和陶瓷插芯 G_2 两部分，如图 3.6(b)所示。本研究假设存在自适应阈值 $T(k) = k(0 < k < L-1)$ ，其中背景区域 G_1 由灰度级别处于 $[0, k]$ 的像素点组成，陶瓷插芯 G_2 由灰度级别处于 $[k+1, L-1]$ 的像素点组成。 G_1 、 G_2 的分类概率和区域像素平均灰度值分别定义为 $P_1(k)$ 、 $P_2(k)$ 和 $m_1(k)$ 、 $m_2(k)$ ，

其计算公式如式 3-1 所示：

$$\begin{cases} P_1(k) = \sum_{i=0}^k p_i, & P_2(k) = \sum_{i=k+1}^{L-1} p_i = 1 - P_1(k) \\ m_1(k) = \frac{1}{P_1(k)} \sum_{i=0}^k ip_i, & m_2(k) = \frac{1}{P_2(k)} \sum_{i=k+1}^{L-1} ip_i \end{cases} \quad (3-1)$$

则 G1 和 G2 类间方差计算为式 3-2 所示：

$$\sigma_B^2(k) = \max_{0 \leq k \leq L-1} [P_1(k)P_2(k)(m_1(k) - m_2(k))^2] \quad (3-2)$$

当两个子区域方差值 $\sigma_B^2(k)$ 最大时，即可求解得到将图像分为两个区域的最优阈值 $k=93$ ，本文对 Ostu 二值化算法进行微调，将识别为陶瓷插芯主体的前景区域保留原有的像素特征，结果如图 3.6(c)。




图 3.6 背景去除过程结果图

(2) 图像位姿矫正

图像位姿矫正旨在调整缺陷图像的陶瓷插芯主体的位置和角度，保持和掩膜图像一致，方便后续的差分处理。图像位姿矫正的流程主要包括最小外接矩形 (Minimum Enclosing Rectangle, MER) 求解和仿射变换。首先采用在 MER 的求解上，采用基于离散格林和顶点链码的主轴法^[66]，首先通过链码凸集算法获取陶瓷插芯的顶点码值 $C_i \in \{0,1,2,3\}$ 、边界坐标 (x_i, y_i) 、行走方向链 D_i ，行走方向规则如式 3-3 所示：

$$\begin{cases} D_{i+1} = (D_i + 1) \% 4, & C_{i+1} = 1 \\ D_{i+1} = D_n, & C_{i+1} = 2 \\ D_{i+1} = (D_i + 3) \% 4, & C_{i+1} = 3 \end{cases} \quad (3-3)$$

通过目标曲线积分值求解出陶瓷插芯的形心、面积及主轴，根据由离散格林，

在垂直方向和水平方向上的积分计算过程为式 3-4 所示：

$$\begin{cases} \iint_D f(x, y) dx dy = \int_L \left(\int_0^1 f_1(x, y-t) dt - \int_0^1 f_1(x, y-t) dt \right) dy \\ \iint_D f(x, y) dx dy = \int_L \left(-\int_0^1 f_2(x+t, y-t) dt + \int_0^1 f_2(x-t, y) dt \right) dy \\ f_1(x, y) = \int^x f(x, y) dx, f_2(x, y) = \int^y f(x, y) dy \end{cases} \quad (3-4)$$

M_{uv} 为陶瓷插芯图像 $f(x, y)$ 的 $u+v$ 阶矩，则主轴的方向角计算为式 3-5 所示：

$$\tan 2\alpha = \frac{2M_{11} - 2y \cdot M_{10}}{M_{20} - x \cdot M_{10} + y \cdot M_{01} - M_{02}} \quad (3-5)$$

由于陶瓷插芯为均匀工件，形心工件即 MER 的坐标中心。形心作为原点，定义旋转的 X 轴与主轴 X' 轴的方向角为 α ，则两个坐标系的转换关系为式 3-6 所示：

$$\begin{cases} x' = p + x \cos \alpha + y \sin \alpha \\ y' = q - x \sin \alpha + y \cos \alpha \end{cases} \quad (3-6)$$

经过主轴法的计算出最大最小新坐标 $(x'_{\min}, y'_{\min})$ 和 $(x'_{\max}, y'_{\max})$ 的 4 个坐标并转化到原坐标系，即得到 MER。

MER 以及方向角 α 的求解可以得到缺陷图像中陶瓷插芯主体与掩模图像的相对角度和位置，后续采用仿射变换对陶瓷插芯主体进行平移和旋转，使其与掩模图像中的标准陶瓷插芯位置重合。

陶瓷插芯缺陷主体的形心 (x, y) 平移到掩模图像的形心 $(\tilde{x}, \tilde{y}) = (x + t_x, y + t_y)$ ，其仿射变换的过程可表示为式 3-7：

$$\begin{pmatrix} \tilde{x} \\ \tilde{y} \\ 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & t_x \\ 0 & 1 & t_y \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \\ 1 \end{pmatrix} \quad (3-7)$$

陶瓷插芯缺陷根据上述 MER 求解出的方向角 α 围绕形心 $(\tilde{x}, \tilde{y})$ 进行旋转正位，原坐标 (x, y) 和变换后的 (x', y') 的仿射变换的过程可表示为式 3-8：

$$\begin{pmatrix} x' \\ y' \end{pmatrix} = \begin{pmatrix} \tilde{x} + (x - \tilde{x}) \cos \alpha + (y - \tilde{y}) \sin \alpha \\ \tilde{y} - (x - \tilde{x}) \sin \alpha + (y - \tilde{y}) \cos \alpha \end{pmatrix} \quad (3-8)$$

至此，本研究完成了陶瓷插芯表面缺陷图像的位姿矫正并和掩模图像保持一致。调整前、调整后、掩模图像对比图如图 3.7。




图 3.7 位姿校正过程缺陷图像与掩膜图像对比图

(3) 腐蚀滤波归一化

陶瓷插芯缺陷图像经过图像位姿矫正后，由于图像在仿射变换过程中插值算法或机器浮点精度等原因，陶瓷插芯主体的边缘会出现锯齿状的微小矩形色块，在后续的差分处理可能会被误判为缺陷特征，本文采用基于形态学的腐蚀操作^[67]，去除缺陷图像的伪边缘，以陶瓷插芯二值化图像为输入图像 I ，选取 3×3 作为结构元 S ，结构元 S 遍历 I 图像每个点 x ， I 中完全包含 S 的区域即腐蚀后的区域，腐蚀操作可以表示为式 3-9：

$$A \ominus B = \{x : B + x \subset A\} \quad (3-9)$$

得到结果腐蚀后和腐蚀前的如图 3.8 所示。




图 3.8 腐蚀前后对比图

同时，由于陶瓷插芯缺陷图像的采样具有随机性，不同摆放角度在同一光照下也可能呈现截然不同的光照噪声分布，需要进行归一化处理，尽量减少光照环

境对原图像特征提取的影响。本文采用高斯滤波^[68]配合双边滤波^[69]对缺陷图像进行非线性的平滑处理，高斯滤波能有效缓解光照噪声的影响，而双边滤波能弥补高斯滤波造成的边缘模糊的不足，对高频细节的保护效果较佳。高斯滤波和双边滤波公式表达如式 3-10，其中双边滤波公式中的 i 和 j 指卷积像素中心坐标， k 和 l 指邻域像素坐标， w 指权重函数；高斯滤波公式中的 x 和 y 指像素坐标， σ 指高斯分布的方差。

$$g(i, j) = \frac{\sum_{k,l} f(k, l) w(i, j, k, l)}{\sum_{k,l} w(i, j, k, l)} \quad (3-10)$$

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

经过高斯和双边滤波处理前后如图 3.9 所示，图像相较于原图像不仅去除了部分光照和拍摄引起的噪声，整体像素重塑的更加平滑，同时还保留了陶瓷插芯边缘的高频特征。




图 3.9 滤波处理前后图

至此，图像正位归一化步骤完成，陶瓷插芯缺陷图像实现和掩模图像相同的位姿和噪声分布，后续可以通过与掩模图像的差分方法提取出缺陷特征，大大增加了图像可学习区域的利用率。

3.3.2 离散特征差分提取

陶瓷插芯缺陷图像和正常图像的本质区别是图像上存在呈群落状分布的缺陷特征，而在这些特征上缺陷图像的像素灰度值会和正常图像呈现明显的差异性。本文提出的差分提取法就是基于前文的图像正位归一化处理后，将缺陷图像和掩模图像置于相同的位姿后，再利用图像差分技术处理，削弱两图的相似部分的干

扰，突出图像的缺陷部分的特征并提取出来。特征差分提取能充分利用图像的本研究感兴趣的占小面积的缺陷特征，而抛弃占图像绝大部分面积的不感兴趣的环境特征。

在传统数字图像处理技术中，图像差分处理指将两张相似图像的像素灰度值相减，最后得到的绝对值作为判断缺陷和正常图像的差距，并利用提前设置的阈值得到差异图。然而在本研究中，采用传统的绝对值差异作为阈值参考标准会产生大量的非缺陷误判。本文结合陶瓷插芯缺陷提取的特点，提出了一种离散特征差分提取算法，如图 3.10 所示，其主要包括互相关性步进校准和高阶阈值差分提取两个过程。




图 3.10 离散特征差分提取算法流程图

(1) 互相关性步进校准

考虑到陶瓷插芯由于制备过程的工艺尺寸微小差别或者图像采集、预处理过程中产生的偶然误差都会造成陶瓷插芯图像的非缺陷部分的差异，经过 3.3.1 节所述的图像位姿矫正过程后，缺陷图像中的陶瓷插芯可能仍未处于和掩膜图像最贴合的位置，这会给后续的图像差分算法计算结果产生较大的干扰，因此本文提出一种互相关性步进校准算法， $f(x,y)$ 为缺陷图像， $g(x',y')$ 为掩模图像，二者的互相关系数表示二者分布的相似程度，互相关性系数的计算这里设计为式 3-11：

$$cor(x,y) = \frac{\sum_x \sum_y (f(x,y) - \bar{f})(g(x+x',y+y') - \bar{g})}{\sqrt{\sum_x \sum_y (f(x,y) - \bar{f})^2 \cdot \sum_x \sum_y (g(x+x',y+y') - \bar{g})^2}} \quad (3-11)$$

如图 3.11 所示，本文提出的互相关性步进校准过程设计为如下流程：每次确定出一个新的匹配位置即形心位置 H_0 时，需要计算以当前形心位置像素周边的 8 个像素 ($H_1 \sim H_8$) 所有的互相关系数，若当前位置的互相关系数已经是局部最大值，

则表示当前陶瓷插芯主体和掩模图像处于最佳匹配的位置，校准过程完毕；若其他8个的候选点存在比当前的互相关系数大的像素点，例如假设图中的 H_3 位置计算的互相关系数为局部最大值，则取 H_3 作为新的匹配位置 H'_0 实现步进校准，然后循环以上流程，直至寻找到一个局部互相关系数最大的像素点作为最佳匹配位置。




图 3.11 互相关性步进校准过程原理设计图

同时，在步进寻找最佳匹配位置过程中，本研究采用哈希映射(HashMap)来保存已计算过的系数值的像素点，减少系数的大量重复计算，提高运算资源利用率。

(2) 高阶阈值差分

经过互相关性步进校准后，缺陷图像陶瓷插芯已处于和掩模图像最佳匹配的位置。在缺陷特征较大较明显时，缺陷部分会明显高于其余部分的差分绝对值，此时采取合理的阈值是可以清晰地把缺陷部分和其余部分区分开来，但当缺陷的差异性不足时，缺陷处的差分值高度和噪声高度接近，仅仅通过图像绝对值差异很难区分缺陷，如图 3.12(a)所示的具有凹坑缺陷的缺陷原图像，在绝对值差分处理后的图 3.12(b~d)中可以看出，由于不同陶瓷插芯之间的个体差异和噪声差异，陷特征和其他无关信息无法明显区分，若采用简单的阈值做取舍处理，容易留下大量无关的环境信息和带走原有缺陷的部分特征，因此采用传统的绝对值差分做缺陷特征的阈值提取的效果不理想。





图 3.12 陶瓷插芯缺陷图像绝对值差分后处理二维及三维视图

本文提出一种缺陷图像和掩模图像高阶矩的阈值确定算法，突出缺陷区域的差异性，扩大阈值的可选择范围，并将位置因素考虑在内，增大相邻像素的影响力。提出的缺陷图像和掩模图像的差分高阶矩描述为式 3-12：

$$\begin{cases} \bar{I}(x,y) = \frac{1}{N} \sum_{(i,j) \in n(x,y)} I(i,j) \\ M(x,y) = \frac{1}{N} \sum_{(i,j) \in n(x,y)} (\bar{I}(x,y) - I_0(i,j))^k \end{cases} \quad (3-12)$$

其中 $I_0(x,y)$ 指掩模图像的像素值； $\bar{I}(x,y)$ 指以 (x,y) 为中心的一组相邻像素组； N 指 $\bar{I}(x,y)$ 像素组的像素数量，本文中取 $N=3 \times 3=9$ ； k 指高阶矩的阶数，为防止高阶矩结果为负数，这里 k 限制为偶数； $M(x,y)$ 即高阶矩值。

本研究采用绝对值差分法、 $k=2$ 阶矩和 $k=4$ 阶矩应用于差分图像，绝对值差分法(图 3.12)无法明显区分缺陷和背景，如图 3.13 所示，2 阶矩差分相对于绝对值差分法，缺陷特征差异化更明显，在考虑相邻像素的影响之后，使得缺陷的面积范围可以勾勒得更清晰；4 阶矩差分法区分效果最优，且阈值可选取的范围从绝对值差分法的 $0 \sim 255$ 扩大到了 $0 \sim 10^7$ ，使得缺陷和背景更加易分。

图 3.13 $k=2$ 和 $k=4$ 时的高阶差分处理后二维及三维视图

本研究引入缺陷概率的概念：将差分图像像素值除以最大的差分高阶矩值得到差分图像的缺陷概率分布信息，概率阈值的大小选取会直接影响到缺陷特征的保留程度，若概率阈值选取过大可能会导致缺陷特征的漏取；反之则可能导致过多无关环境特征保留到差分图像。本文通过 100 组缺陷图像的测试，寻求本实验概率阈值的最优值，最终确定概率阈值为 0.23 时，差分图像区分效果最优，达成缺陷全检的同时尽可能少的让环境信息进入差分图像结果。

选取概率阈值(0.23)和高阶矩($k=4$)后，本研究采用传统的固定阈值、Otsu 自适应阈值、本文提出的高阶矩差分法进行对比实验，可以发现当缺陷特征和掩模图像差异化不明显时，Otsu 算法检测到许多错误的缺陷，固定阈值算法在阈值较高时易发生漏检，阈值较低时易发生错检，本文的 4 阶矩差分算法清晰地缺陷特征分离出来，受背景信息影响小，鲁棒性更强。

3.4 对抗网络离散数据生成模型设计

传统数据增强方法所扩充的数据集样本缺乏多样性，因此本研究采用生成对

抗网络(GAN)进一步实现缺陷图像。原本图像存在大量无关的环境信息,在3.3节的掩码差分特征算法预处理之后,提取出了占原图像不足0.2%面积的缺陷特征,分离了占绝大部分面积的陶瓷插芯正常特征,极大程度上降低GAN缺陷图像生成的学习难度。




图 3.14 生成对抗网络原理图

生成对抗网络的主要原理和结构如图 3.14 所示, GAN^[70]的核心思想是利用神经网络的学习优势来避开求解最大似然函数,其中的生成器(Generator, G)的目的是生成图像模拟趋近真实图像,通常是将随机噪声作为输入进行放大逼近真实图像的数据分布并卷积放大生成新的生成图像;而判别器(Discriminator, D)主要用于分辨真实图像和生成器输出的伪图像的真伪性,本质上是对真实图像和生成图像的分布规律进行二分类;二者不断对抗学习,促使生成器输出图像逼近真实,而判别器训练辨别真伪能力,最后模型达到平衡态后能稳定输出符合真是图像分布的的生成图像。

本文使用的对抗生成网络模型设计包括浓缩图像的数据集搭建和对抗网络结构的设计和训练,其中对抗网络的结构设计包括生成器网络模型和判别器网络模型设计。

3.4.1 离散图像数据集搭建

本研究中的少数类缺陷样本(凹坑、擦伤)在形态上普遍呈现为扁平状而非细长状,即缺陷的最大宽长尺寸上相差较小,而陶瓷插芯的最大宽度在图像中不超过100个像素,因此少数类的单个缺陷特征能够用 100×100 的图像完全容纳。陶瓷插芯缺陷图像的尺寸为 800×800 ,在二次提取特征图像后可以“浓缩”到 100×100 ,在保留缺陷特征的同时还降低了像素计算量约98.4%。

低分辨率的离散缺陷特征图像能加速生成对抗网络的收敛速度,生成效果较好。本实验对输入生成网络的浓缩图像数据集进行搭建,具体搭建流程为:首先,将所有少数类缺陷样本经过3.3节的掩膜差分特征算法预处理,得到仅含缺陷特征的新图像;然后,与创建原数据集的标注过程类似,在新缺陷图像中用 100×100 的矩形框对单个缺陷进行分离,最后重新标注并保存为数据集格式,即得到少数类样本的新尺寸和新标签的离散缺陷特征数据集。

离散缺陷特征图像数据集只包含少数类缺陷(凹坑、擦伤),数据集图像如图3.15所示,图3.15(a~c)为凹坑缺陷的离散特征;图d~e为擦伤缺陷的离散特征。




图 3.15 离散缺陷特征数据集图像

3.4.2 对抗网络结构设计及训练

基于前文所述的浓缩图像数据集的重建,本研究结合数据集尺寸和特点,在模型选型上采用训练稳定性高、生成质量优的深度神经生成对抗网络(DCGAN)作为生成模型。

DCGAN 是 2016 年 Radford^[71]提出的原始 GAN 的改进和延伸。相较于原始 GAN, DCGAN 采用卷积层(conv)和转置卷积层(deconv)替代原有的多层感知机,降低计算量的同时在低分辨率的图片生成方面表现较好。为满足 DCGAN 的尺寸

要求，本研究将浓缩数据集的 100×100 图像压缩至 64×64 作为生成网络的真实图像输入。网络结构如图 3.16 所示。




图 3.16 陶瓷插芯离散图像生成模型 DCGAN 结构图

(1) 生成器与判别器模型设计

本文的生成器模型的输入是一个大小为 100 的一维随机高斯向量，经过生成器多层反卷积后放大为 64×64 的随机噪声图像，其尺寸和本文的离散缺陷图像相同。本研究的生成器网络结构如表 3.1 所示。

表 3.1 生成器网络结构组成

网络层	类型	输入尺寸	卷积核尺寸/步长	激活函数	是否正则归一	输出尺寸
1	随机向量	[100,]	3/1	-	否	[16, 16, 128]
2	Deconv1	[16, 16, 128]	3/2	ReLU	是	[32, 32, 64]
3	Deconv2	[32, 32, 64]	3/1	ReLU	是	[32, 32, 32]
4	Deconv3	[32, 32, 32]	3/2	ReLU	否	[64, 64, 1]

DCGAN 中的判别器实质是二分类器的 CNN，陶瓷插芯真实离散缺陷图像标记为真类，从生成器生成的伪离散图像输出标记为伪类。判别器中的每个卷积块都采用 $\alpha=0.2$ 的 LeakyReLU 激活函数。在前三个卷积中分别使用了 Dropout 和正则归一化来稳定学习过程。判别器中的输出层使用 Sigmoid 激活函数进行分类。

判别器网络构成如表 3.2 所示。

表 3.2 判别器网络结构组成

网络层	类型	输入尺寸	卷积核尺寸/步长	激活函数	是否正则归一	输出尺寸
1	Conv1	[64, 64, 1]	3/2	L.ReLU	Dropout	[32, 32, 32]
2	Conv2	[32, 32, 32]	3/2	L.ReLU	是	[16, 16, 64]
3	Conv3	[16, 16, 64]	3/2	L.ReLU	是	[8, 8, 128]
4	全连接	[8, 8, 128]	-	-	否	[8192,]
5	分类	[8192,]	-	Sigmoid	否	[1,]

训练过程中，生成器不断生成更趋近于真实离散缺陷特征的伪图像，而判别器不断训练自身区分真图像和伪图像方面的能力，直到判别器无法再区分真实图像和生成图像的真伪时，此时训练过程即达到了平衡态。本研究引用 Goodfellow 等^[72]提出的极大极小概念来对 DCGAN 进行训练，如式 3-13 所示， $D(x)$ 表示真实数据 x 被判断为真实图像数据分布的概率； $G(z)$ 指生成器产生的数据分布被判断为真实数据的概率函数， $1-G(z)$ 即将生成器产生的伪图像判断为真图像的损失惩罚； E 指下标函数范围的期望值。

$$\min_G \max_D V(D, G) = E_{x \sim p_{data}(x)} [\log(D(x))] + E_{z \sim p_z(z)} [\log(1 - G(z))] \quad (3-13)$$

判别器的训练目标是使自身区分真伪图像的能力达到最优，即正确判断真实图像和生成图像的概率对数 $\log(D(x))$ 达到最大；生成器的训练目标本质是使真实图像和生成图像的散度最小，即使概率对数 $\log(1 - G(z))$ 最小化。如式 3-14 所示，判别器使用二值交叉熵损失函数来惩罚判别器将真伪图像错误分类的情形。

$$J_q(w) = -\frac{1}{N} \sum_{n=1}^N y_n \cdot \log(q(y_n)) + (1 - y_n) \cdot \log(1 - q(y_n)) \quad (3-14)$$

其中， y_n 是样本类别为 n 的标签(1 为真实图像样本，0 为生成图像样本)， $q(y)$ 是对 N 个样本全部判断为真实标签的预测概率。实验中本研究采用 Pearson 相关系数(Pearson correlation coefficients, PCC)来判断 DCGAN 生成的图像与真实图像的相似性。PCC 计算方式^[73]如式 3-15 所示，通过计算相关性来匹配和比较两

张图像, 其中 x_i 为图像 A 中第 i 个像素值, y_i 为图像中第 i 个像素值, x_m 为图像 A 的像素平均值, y_m 为图像 B 的像素平均值。PCC 值描述了两幅图像的相似程度, 取值范围于 0 到 1 之间, PCC 值越接近 1 说明两幅图像之间的相似性就越大。

$$PCC = \frac{\sum_i (x_i - x_m) \cdot (y_i - y_m)}{\sqrt{\sum_i (x_i - x_m)^2} \cdot \sqrt{\sum_i (y_i - y_m)^2}} \quad (3-15)$$

本研究对 DCGAN 生成结果再进行二次筛选, 经过多次校准最终取 PCC 阈值 0.92 作为 DCGAN 生成的图像是否合格的依据, 即将和真实离散图像的 PCC 小于阈值部分的生成图像淘汰, 保留剩余相关性系数较大的部分作为生成图像的最终结果。

(2) 模型训练

本研究中的离散图像生成模型训练过程如下: 训练伊始, 数据集中的每 64 个真实图像作为判别器真实图像输入的一个 Batch, 生成器将在一个 Step 内学习同一个 Batch 的离散图像分布特点; 生成器的输入是长度为 100 的一维随机向量, 并经过卷积和上采样后生成和真实离散图像相同的 64×64 尺寸, 前 50 Epoch 的生成过程如图 3.17, 生成图像从一开始的随机分布(图 3.17(a)), 逐渐学习出部分离散缺陷图像周边的特征(图 3.17(b~d))。




图 3.17 DCGAN 前 50 Epoch 训练中间结果

随着训练的继续进行, 判别器将生成器的生成图像和输入的真实图像进行二分类辨别真伪, 通过分类过程产生的 G-Loss 反向传播, 学习并训练判别器网络的权重参数, 生成器通过纠正和缩小被准确判断出伪图像的 D-Loss, 反向传播调整生成器网络的参数权重, 使其产生的生成图像能更趋近真实离散图像。实验共训

练 2000 个 Epoch, 从图 3.18 可以看出, 随着 Epoch 的推进, 生成图像的中间结果越来越趋近于真实的离散图像, 在 1000Epoch 左右后达到了判别器的平衡状态, 此时判别器难以分辨生成图像和真实图像的真伪, 最终效果图如图 3.18(h)所示。




图 3.18 100~2000Epoch 训练过程生成图像中间结果

3.5 融合重构数据混合增强策略研究

经过 3.4 节的生成对抗网络学习并生成缺陷特征(图 3.18(h))后, 还需要将缺陷特征融合到掩模图像(Mask)上形成真正意义上的陶瓷插芯表面缺陷图像。生成特征的尺寸是 100×100 , 而掩模图像中陶瓷插芯主体(不考虑陶瓷插芯倒角头部)的长度占 407 像素, 宽度占 100 像素, 考虑到真实工业上陶瓷插芯的缺陷分布密度, 每个陶瓷插芯至多同时融合 2 个缺陷特征。

基于上述, 本文提出一种缺陷特征融合重构的数据增强策略, 是本章提出的主数据集的数据分布平衡和数据增强方法的最后步骤。其主要过程可以分解成掩膜缺陷特征融合和图像位姿重构两个步骤。

3.5.1 离散缺陷特征融合

本研究提出一种掩膜缺陷特征融合算法, 掩模图像是一组标准模板合格的陶

瓷插芯图像，掩膜主体的形状、位置、光照条件均已标准化，其图像特点可以作为基础图像通过本算法融合其他特征后进行推广。掩膜缺陷特征融合算法主要由融合缺陷分布选取和图像融合两个操作构成。

融合缺陷分布选取即在图像融合前确定要融合的缺陷特征种类 n 、缺陷存在总数量 N 、缺陷特征的位置分布，其中 $n \leq N \leq 2$ ，具体方案体现为：浓缩数据集合并 DCGAN 扩充的缺陷特征后，其中每 2 张缺陷特征产生一系列融合图像，从中随机抽取 $n \in \{1, 2\}$ 个缺陷特征后，掩模图像融合 $N \in \{1, 2\}$ 种不同缺陷特征，因此每 2 张缺陷特征即可以产生缺陷特征的排列组合数目为 5，统计排列组合数目计算过程如式 3-16 所示。

$$\begin{aligned} S_{N=1, n=1} &= C_2^1 = 2 \\ S_{N=2, n=1, 2} &= C_2^1 + C_2^2 = 3 \\ S &= S_{N=1, n=1} + S_{N=2, n=1, 2} = 5 \end{aligned} \quad (3-16)$$

产生一系列排列组合方案矩阵如表 3.3 所示：

表 3.3 融合组合方案矩阵

$n \backslash N$	1	2
1	$n=1, N=1$	$n=1, N=2$
2	-	$n=2, N=2$

缺陷特征分布安排如图 3.19 所示，为保证缺陷特征在掩膜图像的陶瓷插芯主体不出现溢出情况，预留左右的边缘(Margin)为 10~100 个像素，剩余空间在保证多个缺陷图像不发生重叠的情况下，随机融合在陶瓷插芯上，即随机选取两个缺陷间的边距(Gap)，Gap 满足式 3-17：

$$Gap \leq (407 - 2 \cdot \text{Margin} - N \cdot 100) \quad (3-17)$$

其中 407 为掩模图像主体像素长度；100 为缺陷特征像素长度；N 为选取的缺陷特征数；Margin 从 10~100 像素长度中随机选取；Gap 从满足式 3-17 的可选择范围中随机选取。




图 3.19 缺陷特征分布安排示意图

缺陷特征的数量和分布选取后进行图像融合，本研究提出一种融合算法，保留掩模图像原有环境数据分布的同时融入缺陷特征。算法如下：假设掩模图像的像素分布为 $M(x,y)$ ，缺陷特征的像素分布为 $D(x,y)$ ，则融合后的掩模图像的分布 $M'(x,y)$ 可以表达为式 3-18：

$$M'(x,y) = \begin{cases} D(x,y), (x,y) \subseteq D \wedge D(x,y) \neq 0 \\ M(x,y), other \end{cases} \quad (3-18)$$

融合后图像效果图如图 3.20，其中包括三种不同情况即 n 与 N 在取不同值时的组合方案效果。




图 3.20 不同融合组合方案效果图

3.5.2 位姿重构混合增强

掩模图像在融合缺陷特征后已经得到主数据集样式的少数类缺陷图像，但由于掩模图像的陶瓷插芯位姿为固定位姿，位置和角度具有单一性，然而实际工业场合陶瓷插芯的摆放位置具有随机性，因此本节提出位姿重构的数据增强方法，主数据集原有多数类缺陷图像也加入这个过程，和掩模融合缺陷图像的少数类同时进行旋转、平移、翻转三种的几何组合变换方法，模拟实际采集图像过程中陶瓷插芯位姿和数量的随机性和多样性，实现数据集整体的数据增强。具体流程如图 3.21。




图 3.21 位姿重构混合增强流程图

旋转变换：为模拟陶瓷插芯采集过程位置的随机性，每张陶瓷插芯图像随机旋转 $30^{\circ} \sim 330^{\circ}$ ，此时需要对标注框进行重新标注，原有标注矩形框经过旋转后的斜矩形框需要正位成水平矩形框，如图 3.22(b)。

平移变换：陶瓷插芯主体进行左右平移和上下平移，其仿射变换求解如式 3-7，平移量为陶瓷插芯图像(800×800)对应尺寸的 $1/3 \sim 1/2$ 的随机值，即左右平移移动量。此时标注框形状不变，跟随移动量平移相同尺度的位移量，最终效果图如图 3.22(c)。

翻转变换：每张陶瓷插芯缺陷图像进行随机的水平翻转和垂直翻转，模拟陶瓷插芯在采集过程中镜像对称的情况，此时标注框形状不变，坐标随着翻转类型而对称变化，效果图如图 3.22(d)。

高斯噪声：考虑到工业场景下由于照明、灰尘等偶然因素对陶瓷插芯表面图像造成的噪声影响，为提高基于数据集的检测模型的推广性和泛化度，本研究对陶瓷插芯图像添加噪声对缺陷图像数据进行二次增强。每组图像随机添加高斯噪声，本实验中采用 $\mu = 0$ ， $\sigma = 0.01 \sim 0.05$ 的高斯噪声，效果图如图 3.22(e)。




图 3.22 位姿重构效果图

陶瓷插芯的大目标缺陷如裂纹等，中目标缺陷如擦伤、凹坑、芯头等，小和超小目标缺陷如污点等的尺度多样性有限，本文提出了一种基于混合样本的离线

数据增强方案，为缓解缺陷尺度不平衡性，能够使检测模型在小尺度上也有检测出这些缺陷的能力；同时，由于数据集中的每张图像仅包含一组陶瓷插芯，信息量有限，混合样本方案有助于成倍地增加单张陶瓷插芯缺陷图像的缺陷信息。

本文提出的混合样本数据方案的步骤如下：首先，从已经进行融合重构的数据集中选取含有中大目标缺陷的不同4张图像，随机裁剪后并将图像的横纵向尺寸缩放到原来的1/2；然后将4张图像拼接起来，形成一组和原来相同尺寸的混合样本，其中的标注框形状不变，尺寸大小随着缩放幅度减小到原来的1/2，混合样本数据增强方法为原数据集引入更丰富的缺陷信息，使后续目标检测模型在单张图像上学习到缺陷特征，加快收敛速度，提升检测性能，最终混合增强后效果如图3.23。




图 3.23 混合增强后示意图

3.6 离散掩膜差分对抗的缺陷图像重生方法验证

为了验证本文3.3~3.5节提出的离散掩膜差分对抗的缺陷图像重生方法的有效性，本节分别以原主数据集和数据增强后的数据集为数据源，基于2.6节选型的不同的检测模型展开实验，验证新方法的改进有效性。

本节的论述将分解成两个部分：一方面是验证基于离散掩膜差分的缺陷图像重生方法中的3个过程各自独立的有效性验证；另一方面是对基于离散掩膜差分的缺陷图像重生方法中的3个过程所有排列组合进行消融实验论述，最终验证基于离散掩膜差分的缺陷图像重生方法整体的有效性和优越性。

3.6.1 方法过程独立有效验证

本节论述验证本文提出的离散掩膜差分对抗的缺陷图像重生方法中的各个过程单独的有效性：即掩膜差分提取算法、对抗网络离散数据生成、融合重构混合数据增强在各自过程相对于其他方法或不采用该方法的优越性。

(1) 掩膜差分缺陷提取算法实验验证

掩膜差分缺陷提取算法的本质是通过图像差分的方式，尽量提取缺陷特征，最大化过滤环境特征，帮助后续的对抗生成过程更高效、更精确地学习到离散缺陷特征。经过掩膜差分缺陷提取算法预处理的浓缩数据集和原数据集少数类缺陷凹坑、擦伤缺陷的平均有效像素数目以及图像数量比较如图 3.24，其中有效像素数目占比指数据集中单张图像中非背景信息即像素值非 0 的区域的像素占比；由图 3.24 可见数据集的少数类经过掩膜差分提取并重构后，绝对数量增加到原来的 6.2 倍，特征数量得到较大补充。




图 3.24 掩膜差分缺陷提取前后有效像素占比与缺陷数量比较图

本文提出的基于高阶矩的掩膜差分提取算法中对不同阶数和不同概率阈值下的误检率实验对比表如表，实验过程中对阶数为 0(绝对值差分法)、2、4(本文提出的高阶差分法)以及概率阈值取值在 0.1~0.5 中进行综合对比，其中误检率指通过掩膜差分法提取出的缺陷特征像素落在缺陷边界框外的比例；缺陷特征边界框指在数据集标注时的矩形框；计算是否误检的方式为：通过和标注矩形框的左上、右下坐标进行比较来获得像素点是否落在矩形框。表 3.4 中可以看出随着矩

阶数的增大，误检率逐渐降低；当概率阈值取值较小时，更多无效像素信息被误检为缺陷特征，因此对应误检率较高；当概率阈值取值较大时，筛选过程中可能会将真实缺陷特征误判淘汰，也可能使整体的误检率增高；本研究通过多组实验最终确定矩阶数为 4，概率阈值为 0.23 时，误检率最低为 1.2%，实验效果最优。

表 3.4 不同阶数(0/2/4)与不同概率阈值(0.1~0.5)的误检率实验结果表

概率阈值 /阶数	0.1	0.2	0.21	0.22	0.23	0.24	0.25	0.3	0.5
0	0.263	0.252	0.251	0.144	0.175	0.193	0.212	0.344	0.353
2	0.046	0.046	0.038	0.025	0.041	0.042	0.042	0.082	0.106
4	0.027	0.022	0.020	0.015	0.012	0.014	0.028	0.029	0.038

采用传统绝对值差分的缺陷提取算法和本文提出的高阶差分提取算法的缺陷图像结果在后续 DCGAN 生成图像质量的对比表如表所示，其中引用 2.7.2 节的生成图像效果指标 FID 和 SSIM 来衡量提取出来的离散缺陷特征的有效性，其中指标所参考的图像是原数据集中矩形边界框的真实缺陷图像，表 3.5 中可以看出，采用本文的高阶差分提取方法的 FID 指标较小，SSIM 指标较大，说明用该方法提取出来的离散缺陷图像更接近陶瓷插芯的真实缺陷图像，生成效果更好，验证了高阶差分提取缺陷方法的有效性和优越性。

表 3.5 高阶差分和绝对值差分的提取特征在后续 DCGAN 的生成图像质量比较

方法		指标数值
绝对值差分后 图像生成质量	FID	128.53
	SSIM	0.62
高阶差分后 图像生成质量	FID	67.56
	SSIM	0.87

(2) 对抗网络离散数据生成模型实验验证

本文设计的 DCGAN 网络以掩膜差分提取后二次处理的浓缩数据集作为原材料，通过训练生成器和判别器之间的不断对抗、生成，最终产生与真实缺陷相近的离散缺陷特征，为后续的融合重构提供了良好的基础。相较于直接将陶瓷插芯

缺陷原图像(800×800)作为 DCGAN 的输入, 经过掩膜差分预处理的离散缺陷图像(100×100)包含的有效像素占比更大, DCGAN 生成器学习缺陷的效率也越高。表 3.6 所示为 DCGAN 的迭代次数均为 1500 次时, 原图像(800×800)直接输入对抗网络产生的生成图像和经过掩膜差分的离散缺陷图像(100×100)再融合重构后的生成图像质量对比,

表 3.6 Epoch 为 1500 时不同输入图像和本文方法生成的缺陷图像质量对比

输入图像		指标数值
原缺陷图像 (800×800)	FID	185.5
	SSIM	0.41
离散缺陷图像 (100×100 , 本文)	FID	78.63
	SSIM	0.71

表 3.6 中可以看出, 原缺陷图像直接作为生成模型的输入所生成图像的 FID 指标超过 150, 和原图像特征层次的差距相对较大, SSIM 相似性指标低于 0.5 也不够理想; 经过掩膜差分的离散缺陷图像(100×100)再融合重构后的生成图像质量有明显的提升, 其中 FID 指标增大约 2.4 倍, SSIM 相似性指标也有明显提升, 进一步证明了本文方法不仅在生成效率上更高, 在生成模型效果上也更具有有效性。

表 3.7 DCGAN(本文)与 SMOTE、GAN 对离散缺陷的生成图像质量对比

方法		指标数值
DCGAN(本文)	FID	67.56
	SSIM	0.87
SMOTE	FID	98.32
	SSIM	0.73
GAN	FID	93.53
	SSIM	0.82

本研究还采用过采样合成技术 SMOTE、GAN 和本文的 DCGAN 对离散缺陷图像进行生成效果进行对比, SMOTE 方法的原理是通过真实样本进行分析和模拟, 然后计算出 K 个相邻并对其中 N 个样本采用随机线性插值的方法进行生成新

的图像。如表 3.7 所示, DCGAN 相较于 SMOTE 和 GAN, FID 指标和 SSIM 指标均优于其余方法, 其中 SMOTE 和 GAN 方法的 FID 指标接近, 说明其生成图像的数据分布与真实离散缺陷图像相似程度较为接近, 但 GAN 方法在 SSIM 指标上更为出色; DCGAN 继承了 GAN 在生成图像在创造性的出色效果更进一步, 在 FID 指标上有显著的优势。因此通过对比试验可以验证本文的对抗生成模型在低分辨率的离散缺陷图像上的优势。

(3) 融合重构混合数据增强实验验证

融合重构混合数据增强通过对少数类融合图像进行位姿重构, 并对整体数据集的多数类和少数类综合进行平移、旋转、翻转、滤波以及混合增强, 其产生的新数据集为少数类缺陷样本增加了多样性, 为多数类缺陷样本扩充了绝对数量, 对后续的检测模型训练材料增加了鲁棒性和泛化能力。融合重构混合增强后的新数据集和原数据集的数量绝对值和特征类别分布如图 3.25 所示。




图 3.25 本文增强后数据集和原数据集的特征数量与分布对比图

由图 3.25 可见, 原数据集的少数类(凹坑、擦伤)缺陷经过离散特征提取、对抗网络生成、融合重构混合增强一系列数据增强方法后得到了极大的补充, 进一步平衡数据集的缺陷分布, 最值比例从原来的 1:14 平衡到 1:1.8; 同时原数据集的多数类(芯头、污点、裂纹)经过位姿重构和混合增强后也得到了一定的扩充,

特征总量由 6212 扩大为原来的 2.6 倍至 16160，进一步夯实了数据集的深度。数据集特征数目绝对值数量得到原有的 1.5~20 倍的扩充，在分布上相比原数据集也更趋于均衡，有助于提高检测模型对少数类缺陷的识别能力和鲁棒性。

增强后数据集和原数据集在 2.4.3 选型的 5 种基本模型 Faster R-CNN、R-FCN、YOLOv4、YOLOv5、SSD 上模型收敛后的准确率 AP 和 G_mean 指标的表现如表 3.9 所示。表中的“综合”指考虑缺陷数量权重的综合平均指标数值，“时间”指不同模型在 GPU 环境下的每张图像的平均检测时间。

表 3.9 增强后数据集和原数据集在不同基本检测模型上的表现

			芯头	凹坑	裂纹	擦伤	污点	综合	时间
Faster-RCNN	原始数据	AP	0.832	0.763	0.782	0.751	0.725	0.789	325ms
		G_mean	0.684	0.422	0.635	0.418	0.712	0.588	
	增强数据	AP	0.923	0.800	0.836	0.842	0.756	0.865	322ms
		G_mean	0.723	0.685	0.701	0.693	0.731	0.708	
R-FCN	原始数据	AP	0.845	0.721	0.813	0.734	0.728	0.799	208ms
		G_mean	0.737	0.493	0.668	0.515	0.726	0.641	
	增强数据	AP	0.931	0.832	0.862	0.839	0.788	0.878	208ms
		G_mean	0.781	0.693	0.756	0.712	0.741	0.743	
YOLOv4	原始数据	AP	0.815	0.754	0.781	0.768	0.688	0.786	30ms
		G_mean	0.741	0.563	0.712	0.581	0.676	0.666	
	增强数据	AP	0.912	0.798	0.827	0.803	0.713	0.846	29ms
		G_mean	0.834	0.796	0.793	0.802	0.706	0.792	
YOLOv5	原始数据	AP	0.802	0.753	0.779	0.759	0.683	0.776	26ms
		G_mean	0.738	0.543	0.709	0.568	0.670	0.659	
	增强数据	AP	0.902	0.782	0.819	0.796	0.711	0.843	25ms
		G_mean	0.826	0.783	0.791	0.802	0.689	0.762	
SSD	原始数据	AP	0.796	0.525	0.691	0.583	0.708	0.695	45ms
		G_mean	0.652	0.451	0.624	0.486	0.702	0.593	
	增强数据	AP	0.835	0.725	0.760	0.732	0.753	0.776	46ms
		G_mean	0.753	0.701	0.722	0.711	0.746	0.730	

从表 3.9 可以看出，经过融合重构混合增强的新数据集在准确率 AP 和 G_mean

指标均明显优于原不平衡数据集，其中少数类凹坑、擦伤在数据扩充后，AP 准确率有明显提升，平均提升 19.8%，多数类缺陷如裂纹、污点等通过混合增强后也有 3.5% 的增长，初始数据集中分布不平衡，其中多数类的样本较为充足，模型更容易学到多数类缺陷的特征，导致多数类明显高于少数类的 AP 指标，但随着数据增强后数据集得到平衡，少数类的 AP 得到明显增长；模型 G_mean 指标的计算方式考虑了数据集不平衡的情形，因此少数类凹坑、擦伤缺陷在数据增强前的 G_mean 指标远远低于多数类，在数据增强后 G_mean 指标平均提升 23.1% 和多数类的 G_mean 指标基本实现持平，多数类的 G_mean 也获得了平均约 9.2% 的增长；因此综合增强前后的指标数据可以验证融合重构混合增强的新数据集的优越性和对模型检测能力提升的有效性。

从 5 种不同模型在表中的表现来看，Two-Stage 模型的 Faster-RCNN 和 R-FCN 准确率 AP 上略高于 One-Stage 模型的 YOLOv4 和 SSD 模型，其中在 AP 指标上 R-FCN 的表现最优，但仅高于 YOLOv4 模型 3.2 个百分点；在 G_mean 指标上 YOLOv4 表现最出色，在数据增强后达到 0.792，其余模型在 G_mean 的指标上表现基本持平；检测速度上，YOLOv4 和 YOLOv5 有着明显优势，相较于其他模型的准确率有着 7~10 倍的效率优势；SSD 模型在检测速度上明显优于 Two-Stage 模型，但准确率 AP 和 G_mean 指标处于落后水平；YOLOv4 和 YOLOv5 兼具检测速度和检测精度的优势，更适合用于在对检测时间要求严格的陶瓷插芯工业现场；YOLOv5 相较于 YOLOv4 有轻微的速度优势，但牺牲了部分精度性能；综上所述因素考虑，本研究最终选用 YOLOv4 作为后续检测模型研究的基础模型。

虽然 YOLOv4 在检测精度和效率方面表现较为出色，然而在目前增强后的数据集上的表现仍存在多个问题：从表可见，芯头特征的图像较为单一，在 YOLOv4 模型训练过程中较易学习到该特征，整体准确率 AP 高达 0.912，但其余缺陷由于缺陷形状多变且数据集有限，AP 指标仅处于 0.70~0.85 范围之内，仍不符合工业现场的质量检测要求；同时 YOLOv4 对小目标尺寸居多的污点缺陷检测精度较低，AP 仅为 0.713；YOLOv4 虽然是 2.4.3 节选型的 5 种基本模型中模型尺寸最小的，但仍达到可观的 234.63MB，在内存小、嵌入式设备居多的工业现场增添了计算

成本；综上所述，后续章节将基于 YOLOv4 模型进行改进，以适应陶瓷插芯表面缺陷检测的实际需求。

3.6.2 方法组合综合消融验证

上述 3.6.1 节中论述了本文提出的离散掩膜差分对抗的缺陷图像重生方法中掩膜差分提取算法、对抗网络离散数据生成、融合重构混合数据增强的 3 个过程单独的有效性，本节将继续论述验证这 3 个过程组合方法的优越性，并通过不同替代方法的组合进行消融实验验证本研究提出的数据平衡增强方法的可行性。

在掩膜差分提取算法部分中，本文提出了一种高阶(4 阶)差分的方法来提取缺陷，本实验安排的对照组为高阶(2 阶)差分、不采用差分的方法进行对比验证；在融合重构混合数据增强部分中，本文提出采用少数类融合位姿重构、所有类数据混合增强的方法用以扩充数据集，本实验安排的对照组为仅进行混合增强和仅融合重构的方式进行对比验证。方法组合的综合消融验证实验结果如表 3.10 所示。该实验基于 YOLOv4 模型展开，其衡量指标为采用不同的数据增强方法后产生的数据集在模型检测精度对比，由于数据增强前后的数据集不平衡度差异较大，这里使用更能真实体现模型精度的 G_mean 指标。

表 3.10 不同组合数据增强方法下的 YOLOv4 的 G_mean 指标对比

对照	操作	芯头	凹坑	裂纹	擦伤	污点	综合
1	初始状态	0.812	0.563	0.723	0.532	0.638	0.671
2	2 阶差分/DCGAN/融合重构/混合增强	0.826	0.762	0.785	0.768	0.712	0.782
3	4 阶差分/GAN /融合重构/混合增强	0.824	0.701	0.745	0.624	0.697	0.727
4	4 阶差分/SMOTE /融合重构/混合增强	0.821	0.691	0.738	0.618	0.688	0.721
5	DCGAN /混合增强	0.818	0.683	0.733	0.612	0.688	0.717
6	4 阶差分/DCGAN/融合重构	0.828	0.711	0.765	0.751	0.691	0.769
7	/混合增强	0.816	0.625	0.735	0.585	0.685	0.703
8	4 阶差分/DCGAN/融合重构/混合增强	0.834	0.796	0.793	0.802	0.706	0.792

由表 3.10 可见，不进行任何处理的初始状态下(对照 1)相较于其他数据增强手段处理后的 G_mean 指标均处于偏低水平，说明其他数据增强手段均有使模型精

度提升的效用；对照1与对照7相比仅多进行混合增强，使整体的 G_mean 指标提升了 3.2%，但对照7组的少数类凹坑、擦伤缺陷精度仍处于 0.50-0.65 较低的水平，数据增强效果不够理想；对照3、4、8组采用不同的生成图像手段，相较于初始状态的 G_mean 指标均有较大提升，在生成图像效果方面表现为 $DCGAN > GAN > SMOTE$ ，其中 DCGAN 相较于 SMOTE 有着约 7% 的指标差距；对照2和对照8(本文)可见本文提出的4阶差分提取法的优越性主要体现在对少数类缺陷上的 G_mean 提升，精度增加 4.3%，对所有类别的缺陷综合提升 1%；对照8相对于对照6有 2.3% 的提升，验证了混合增强在组合方案的效用，对照8和对照5相比有 7.5% 的提升，证明了掩膜差分对缺陷学习效率有着较大的作用；综合所有组合对照消融实验来看，本文提出的4阶差分/DCGAN/融合重构混合增强的缺陷图像重生方法在所有对照组中表现最优，综合 G_mean 指标达到了 0.792，唯一落后指标的污点缺陷和对照组2仅 0.6% 的差距，可见4阶差分提取算法在污点小目标尺寸的缺陷的提升优势不大。综上，本实验通过8组对照实验证明了本文提出的离散掩膜差分对抗的缺陷图像重生方法的优越性。

3.7 本章小结

本章针对陶瓷插芯缺陷图像的缺陷特征占比小、有效信息少、难以直接通过生成对抗网络扩充数据集少数类新图像等问题，提出了一种结合生成对抗网络和基于离散掩膜差分的缺陷图像重生方法，并分别提出该方法的3个过程：掩膜差分提取算法、对抗网络离散数据生成、融合重构混合数据增强的设计研究过程和验证组合实验。在掩膜差分提取算法研究中提出互相关性校准方法和高阶阈值差分方法；在对抗网络模型设计中提出采用 DCGAN 作为生成模型；在融合重构混合数据增强提出采用位姿重构和混合增强的方法进行数据扩充；同时在经过本章提出的方法增强后的数据集上进行4种常见检测模型的实验比较，最后确认使用 YOLOv4 模型作为本研究后续的陶瓷插芯表面缺陷检测的模型基础。

第 4 章 基于 FM-YOLO 模型的缺陷检测方法研究

4.1 引言

3.6.2 节综合模型检测速度和精度的表现，最终选取 YOLOv4 模型作为本章改进的基础模型。然而 YOLOv4 应用在本研究的陶瓷插芯表面缺陷研究中仍存在模型尺寸偏大、整体模型尤其是小目标缺陷的精度偏低、训练效率较低等问题。

本章首先介绍 YOLOv4 模型的结构、原理、损失函数的组成；然后基于 YOLOv4 模型上述问题提出模型轻量化、新增小尺寸检测头、引入 ASFF 和 scSE 模块增强空间或通道的自适应融合激励增强，同时优化 NMS 算法，提出了更适合本研究检测任务的 FM-YOLO (Ferrule MobileNet-YOLO)模型。FM-YOLO 的改进方向和训练实验流程如图 4.1 所示。




图 4.1 本章对原始 YOLOv4 模型设计及训练流程图

4.2 YOLOv4 模型结构与原理

4.2.1 模型结构

YOLOv4 模型网络结构主要由 Backbone、Neck、Head 三个部分组成。其中，Backbone 是检测模型的核心骨架，YOLOv4 模型中采用 CSPDarknet53 作为模型

骨架，对输入陶瓷插芯图像进行特征提取；Neck是连接Backbone和Head的网络辅助层，其功能主要是对Backbone提取出的图像特征进行拼接和融合；Head是网络模型的预测部分，根据不同网络尺寸对图像的缺陷部分进行定位锚框及判断类别。

(1) Backbone

YOLOv4模型的Backbone的CSPDarknet53骨架的实质是具有CSPNet结构的Darknet53网络，CSPNet结构采用了梯度信息结合的思想，有助于减少模型权重参数量的计算量，缓解神经网络体系结构的大量推理过程。Darknet53网络结合了残差块(Residual Block)的特点，即保留特征表达的同时避免网络过深带来的梯度爆炸或梯度消失问题。Darknet53融合上文CSPNet结构思想，每个卷积层由卷积(Conv)、批量归一化(Batch Normalization, BN)、Mish激活函数构成CBM(Conv-BN-Mish)块，构成CSPDarknet53主干网络。

(2) Neck

YOLOv4模型的Neck部分主要采用SPP模块、FPN结构、PAN结构组成。其中，空间金字塔SPP模块^[74]作为Backbone的全连接层的替代，融合不同大小的池化层的同时也极大扩充了感受野区域，可以适应不同尺寸的输入而输出固定的特征表示；FPN^[75]采用自顶向下的下采样来捕获图像的强语义特征；如图4.2所示，PAN结构采用自底向上的路径聚合策略传递图像的位置信息，通过组合FPN和PAN结构可以更好地完成检测目标的定位。




图 4.2 YOLOv4 Neck 的 FPN 与 PAN 结构示意图

Neck 中采用 Leaky Relu 作为激活函数。Leaky Relu 激活函数的表达式如下：

$$LR(x) = \max(0, x) + \alpha \cdot \min(0, x) \quad (4-1)$$

其中 α 是一个较小的常数，保留负轴值信息不完全丢失的同时可以通过控制 α 的大小保证负轴的值不会过多影响到后续的神经元，本研究中取 $\alpha = 0.01$ 。

(3) Head

YOLOv4 的 Head 部分的主要作用是通过负责预测 Neck 输出的尺寸区域中的目标，Neck 部分通过 FPN 的下采样和 PAN 的上采样，并结合 SPP 的池化层融合，得到了 13×13 、 26×26 、 52×52 的三种特征图分别对应检测目标的不同尺寸，其中 13×13 的感受野最大，适合进行大目标的检测任务， 26×26 和 52×52 则负责进行图像中的中、小目标的检测任务。每个预测任务包括预测 3 个边界框的横纵坐标、宽、高、置信度 5 个参数值及各类别条件概率 N 个， N 指需要预测类别的种类数目，陶瓷插芯表面缺陷检测任务中 N 取 4。

(4) 总体网络结构

YOLOv4 模型总体网络结构示意图如图 4.3 所示。输入图像首先缩放调整为固定尺寸 416×416 ，Backbone 部分采用上文介绍的 CSPDarknet53 进行 5 次降采样，并将其中提取的 3 种尺寸的特征图输入到 Neck 进行特征融合增强；然后 Neck 部分借助 SPP 模块及上采样将多层次的特征图进行拼接与融合；最后将经过 Neck 的不同感受野的 3 种特征图输出到 Head 的 3 个预测头进行判别类别和定位目标；其中，卷积(Conv)、批量归一化(BN)层、Mish 激活函数组成一个 CBM 模块；另外，卷积(Conv)、BN 层、Leaky Relu 激活函数共同构成一个 CBL 模块；残差单元由两个 CBM 和前端输入的跳跃连接组成；CBM 配合 n 个 Res Unit 采用 CSP 跨阶段局部连接的思想串联构成了 CSPX 结构。

Backbone 中输入端经过 CSP1、CSP2、CSP8 的 3 次降采样共 $2^3 = 8$ 倍，输入尺寸 416×416 得到 $416/8 = 52 \times 52$ 的特征图尺寸，再经过 CSP8 的 1 次降采样和 CSP4 的 1 次降采样分别得到 26×26 和 13×13 的两种特征图尺寸；Neck 部分将这三种尺寸通过 SPP 和上采样进行多尺度特征融合后，将拼接结果输出到 Head 的三个预测头进行定位和分类任务，陶瓷插芯表面缺陷种类 $N = 4$ 种，Head 预测头通道数为 $(4+5) \times 3 = 27$ 个。最终实现不同感受野下的多尺度的目标检测。





图 4.3 YOLOv4 网络结构原理图

4.2.2 边界框检测原理

YOLOv4 通过 Head 的不同的 3 个特征图, 计算特征图中各个网格的预测框位置和置信度分数。如图 4.4 所示, 预测框位置指检测目标矩形框中心落在网格中的情况时的实际中心点 (b_x, b_y) 以及宽和高 (b_w, b_h) 的数值。



置信度分数指预测框包含一个物体且属于某个类别的概率，YOLOv4 引入锚框(Anchor)机制。锚框是训练前设置的一组宽度、高度、比例固定的先验边界框，即图中的虚线部分， P_w 和 P_h 是锚框预设的宽和高。锚框和检测目标的实际边界框大小比例越相近，训练的过程中就更易学习调整得到准确的预测框。图 4.4 中的 $\sigma(t_x), \sigma(t_y)$ 为经过 *Sigmoid* 函数归一化计算出的中心坐标比例。经过学习调整后的边界框 (b_x, b_y, b_w, b_h) 如图中实线框所示，计算过程为式 4-2：

$$\begin{cases} b_x = \sigma(t_x) + C_x, b_y = \sigma(t_y) + C_y \\ b_w = p_w e^{t_w}, b_h = p_h e^{t_h} \end{cases} \quad (4-2)$$

4.2.3 损失函数

YOLOv4 的损失函数由定位损失 E_{IoU} 、置信度损失 E_{conf} 、分类损失 E_{class} 三个部分构成，表达如式 4-3 所示：

$$L = \sum_{i=0}^{S^2} E_{IoU} + E_{conf} + E_{class} \quad (4-3)$$

其中定位损失 E_{IoU} 位置损失采用计算真实框和预测框的 $CIoU$ 的方式统计如式 4-4 所示：

$$E_{IoU} = \lambda_{IoU} \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{obj} L_{CIoU} \quad (4-4)$$

式子 4-5 中， λ_{IoU} 表示位置损失的权重； S^2 是 $S \times S$ 的网格数； B 为每个网格的边界框数； I_{ij}^{obj} 表示第 i 个网格中第 j 个边界框中是否存在目标对象； $CIoU$ 是基于 IoU 的变形，计算过程如式 4-5：

$$\begin{cases} CIoU = IoU - \left(\frac{\rho^2(\hat{b}, b)}{c^2} + \alpha v \right) \\ v = \frac{4}{\pi^2} \left(\arctan \frac{w}{h} - \arctan \frac{\hat{w}}{\hat{h}} \right)^2, \alpha = \frac{v}{(1 - IoU) + v} \end{cases} \quad (4-5)$$

其中， α 和 v 为长宽比， $w, h, \hat{w}, \hat{h}$ 分别为预测框和真实框的宽和高。式子()

的置信度损失 E_{conf} 定义为式 4-6:

$$E_{conf} = \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{obj} [C_{ij} \log(C_{ij}) + (1 - \hat{C}_{ij}) \log(1 - \hat{C}_{ij})] \\ + \lambda_{noobj} \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{noobj} [\hat{C}_{ij} \log(\hat{C}_{ij}) + (1 - C_{ij}) \log(1 - C_{ij})] \quad (4-6)$$

其中, λ_{noobj} 为网格中不存在目标时的置信度损失系数; $C_{ij}, \hat{C}_{ij}$ 表示第 i 个网格中第 j 个边界框中预测和真实的置信度; 式中分类损失 E_{class} 定义为式 4-7:

$$E_{class} = - \sum_{i=0}^{S^2} \sum_{j=0}^B I_{ij}^{obj} \sum_{c \in classes} \lambda_c [\hat{p}_{ij}(c) \log(p_{ij}(c)) + (1 - \hat{p}_{ij}(c)) \log(1 - p_{ij}(c))] \quad (4-7)$$

其中 λ_c 为类别损失权重系数; c 指目标检测任务需要识别的类别; $p_{ij}(c), \hat{p}_{ij}(c)$ 指第 i 个网格中第 j 个边界框中 c 类别的预测和真实概率。

4.3 基于 YOLOv4 的 FM-YOLO 模型改进设计

陶瓷插芯数据集经过第 3 章所述的离散掩膜差分对抗的缺陷图像重生的数据增强后, 本研究基于该数据集, 并以 YOLOv4 模型作为陶瓷插芯表面缺陷检测的检测模型, 模型的表现如表 3.9 所示, 实验结果表明, 目前 YOLOv4 模型直接应用在本研究上仍存在以下问题: 首先, 前文使用的 YOLOv4 模型大小高达 234.63MB, 考虑到设备成本问题, 在实际工业场景下的陶瓷插芯表面检测任务通常无法在多流水线上批量布置价格昂贵的算力优质设备, 取而代之的是廉价低配、算力平平的计算设备, 因此尽可能地轻量化模型大小有助于检测模型在工业场景的成本降低和大规模推广; 其次, YOLOv4 在总体 mAP 和 G-means 上精度为 0.85 和 0.79, 尤其在超小目标缺陷如污点的检测精度仅为 0.71 和 0.70, 不满足实际生产检测要求; 然后, YOLOv4 的 Head 预测头仅三个尺度, 在本研究的表面缺陷的 4 种尺寸中表现欠佳; 最后, 实验中缺陷分布较为分散的场景下能够表现出较高的查全率, 但当陶瓷插芯图像的缺陷群的真实框出现重叠情况时, YOLOv4 模型容易出现漏检, 在一定程度上降低了模型的检测性能。

本章基于上述 YOLOv4 模型目前存在的问题, 提出了基于 YOLOv4 改进的

FM-YOLO(Ferrule MobileNet-YOLO)模型, BackBone 部分在原有的网络结构上引入深度可分离卷积替代做轻量化处理; Neck 部分引入 ASFF 模块对不同尺度的卷积结果进行空间特征的自适应融合, 引入 scSE 模块增强模型对空间和通道二者的学习激励增强; Head 部分增加一种尺度预测头; 边界预测部分引入 DIoU-NMS 替代传统 NMS 算法。

4.3.1 基于深度可分离卷积的轻量化融合设计

本研究提出的 FM-YOLO 模型中, 采用 MobileNet 结构^[76]替代 CSPDarknet53 作为更为轻量级的骨干网络, MobileNet 的核心思想是深度可分离卷积(DW-Conv), 能够保证检测精度变动较小的前提下, 实现参数计算量和模型大小的大幅缩减, 对陶瓷插芯工业检测现场的低算力和低性能的计算设备较为友好。




图 4.5 普通卷积层卷积原理图

MobileNet 相较于普通卷积层的特征提取过程, 普通卷积层从卷积核得到特征, 一般为了得到高维的特征信息会采用多个过滤器(Filters)进行堆叠以获取更多的特征, 如图 4.5 所示, 一个 5×5 的 3 通道的特征图输入, 经过卷积核大小为 3×3 的 4 个过滤器卷积操作升维成 5×5 的 4 通道特征图输出, 期间普通卷积层的计算量为 $(5 \times 5) \times (3 \times 3 \times 3 \times 4) = 2700$ 。普通卷积层会随着过滤器的增多, 不可避免的显著增加算法计算量和参数个数。

MobileNet 的深度可分离卷积思想是将普通卷积过程分为 DW(Depthwise)卷积和 PW(Pointwise)卷积两个步骤, DW 卷积负责对输入特征图进行滤波, 输入特

征图的每个通道在输出一个特征时仅卷积 1 次，而普通卷积在此过程的卷积次数为输入特征的通道数；PW 卷积负责转换通道，用更小的 1×1 卷积核进行升维转换。仍以上文为例，如图 4.6 所示，相同的一个 5×5 的 3 通道的特征图输入，首先经过 DW 卷积，卷积核大小为 3×3 ，得到和原来通道数相同数量的中间特征图；然后中间特征经过 PW 卷积，卷积核大小为 1×1 ，通道融合卷积后得到输出特征图。相同输入和输出特征图下，DW 卷积过程的计算量为： $(5 \times 5 \times 3 \times 3 \times 3) = 675$ ，PW 卷积过程的计算量为 $(3 \times 4 \times 5 \times 5) = 300$ ，总计算量为 975，显著低于普通卷积层的 2700，FM-YOLO 主干网络的通道数显著大于此场景中的通道数 3 和 4，减少计算量的效果会成倍的显著。




图 4.6 MobileNet 的深度可分离卷积原理图

假设卷积过程中输入特征图的空间高度和宽度为 $D_F \times D_F$ ；输入通道数为 M ；卷积核大小为 $D_K \times D_K \times M$ ，卷积核数量为 N ，步距为 1，采用 Same Padding 方式填充；则一个普通卷积计算量为： $D_K \cdot D_K \cdot M \cdot N \cdot D_F \cdot D_F$ ，一个 DW 卷积计算量为： $D_K \cdot D_K \cdot M \cdot D_F \cdot D_F$ ，一个 PW 卷积计算量为： $M \cdot N \cdot D_F \cdot D_F$ ，因此将 MobileNet 的深度可分离卷积与标准卷积相比结果为：

$$\frac{D_K \cdot D_K \cdot M \cdot D_F \cdot D_F + M \cdot N \cdot D_F \cdot D_F}{D_K \cdot D_K \cdot M \cdot N \cdot D_F \cdot D_F} = \frac{1}{N} + \frac{1}{D_K^2} \quad (4-8)$$

本研究中卷积核大小 D_K 为 3，输出通道数 N 大于 $D_K^2=9$ ，因此深度可分离卷

积计算量相对普通卷积减少了 1/8~1/9。

MobileNet v2^[77]借鉴残差块(Residual block)有助于避免过深的网络学习阶段出现梯度问题的思想，在原有结构上在步距 $stride=1$ 及输入输出矩阵尺寸相同的结构上增加 shortcut 连接，首先进行投影卷积升维，然后通过深度卷积后再投影卷积降维，形成与残差结构相反的倒残差结构，同时 MobileNet v2 为防止特征信息从高维空间映射到低维空间过程中非线性激活函数会导致信息坍塌，结合了线性 Bottlenecks 结构，在降维过程中采用线性激活的方式保留信息，其中 Bottleneck 模块中的升维及 DW 卷积过程中均采用 Relu6 激活函数，降维过程采用线性激活即对输出不做改变。

本研究中将 MobileNet v2 结构替换 YOLOv4 骨架网络的 CSPDarknet53 结构，改进后的和原 YOLOv4 的主干网络 Backbone 结构对比如表 4.2 所示：

表 4.2 MobileNet 替换主干结构(左)后和原 YOLOv4 主干网络(右)对比表

网络层/ 步长		卷积核× 过滤器	输出	网络层/ 步长		卷积核× 过滤器	输出
输入			416×416	输入			416×416
DW 层/2		3×3×32	208×208	卷积层/1		3×3×32	416×416
卷积层/1		3×3×32	208×208	卷积层/2		3×3×64	208×208
1 ×	DW 层/2	3×3×64	104×104	1 ×	卷积层/1	1×1×32	208×208
	卷积层/1	1×1×128	104×104		卷积层/1	3×3×64	208×208
	DW 层/1	3×3×128	104×104		残差单元		208×208
	卷积层/1	1×1×128	104×104	卷积层/2		3×3×128	104×104
				2 ×	卷积层/1	1×1×64	104×104
1 ×	DW 层/2	3×3×128	52×52		卷积层/1	3×3×64	104×104
	卷积层/1	1×1×256	52×52		残差单元		104×104
	DW 层/1	3×3×256	52×52	卷积层/2		3×3×256	52×52
	卷积层/1	1×1×256	52×52	8 ×	卷积层/1	1×1×128	52×52
					卷积层/1	3×3×128	52×52
1 ×	DW 层/2	3×3×128	26×26		残差单元		52×52
	卷积层/1	1×1×256	26×26	卷积层/2		3×3×512	26×26
				8 ×	卷积层/1	1×1×256	26×26
5 ×	DW 层/1	3×3×256	26×26		卷积层/1	3×3×256	26×26
	卷积层/1	1×1×256	26×26		残差单元		26×26
1 ×	DW 层/2	3×3×128	13×13	卷积层/2		3×3×1024	13×13
	卷积层/1	1×1×256	13×13	8 ×	卷积层/1	1×1×512	13×13
	DW 层/1	3×3×256	13×13		卷积层/1	3×3×512	13×13
	卷积层/1	1×1×256	13×13		残差单元		13×13

FM-YOLO 网络的 BackBone 融合 MobileNet 的深度可分离卷积结构后，如图 4.8 所示改进后参数量相较于原始 YOLOv4 网络下降 36.3%，与原网络的计算量

相比已明显减少,但整体参数量仍有 4000 万左右,因此本文对网络的 Neck 部分的卷积网络同时进行全局的深度可分离卷积替换,采用 DW-Conv 替换采用 3×3 卷积核的中间卷积层,改进后的 3 层卷积和 5 层卷积的新结构设计如图 4.7 所示。




图 4.7 本文改进的 3/5 层卷积的轻量化方式

由图 4.8 可见,采用 MobileNet 深度可分离卷积的思想对全局网络改进后,模型参数量更进一步降低到 1000 万的数量级,较原始 YOLOv4 模型参数量减少 82.8%。同时,将深度可分离卷积的思想应用到整个网络更有利于深层网络中浅层特征信息的保留,有助于提高浅层的目标检测精度。整体的模型大小由原始的 234.63M 降低到 48.56M,仅为原模型的 20.7%,增强了工业嵌入式设备的可扩展性和算力成本。




图 4.8 MobileNet 融合 YOLOv4 后的 FM-YOLO 模型参数计算量变化图

4.3.2 基于自适应空间特征融合的多尺度改进

YOLOv4 中的主干神经网络随着网络的层数加深,浅层特征的忽略和丢失容易造成小尺寸目标的漏检,因此网络在浅层学习的本章提出在原始 YOLOv4 的 Head 结构上新增第 4 种预测尺度,分别为 104×104 、 52×52 、 26×26 、 13×13 ,

对应超小、小、中、大的感受野，用以保留和检测陶瓷插芯表面缺陷检测任务中不同尺寸目标特征。增强模型对超小目标和小目标如小裂纹、污点等缺陷的特征提取能力。本文提出的 FM-YOLO 模型的多尺度预测结构如图 4.15 所示，其中 104×104 、 52×52 、 26×26 、 13×13 是预测阶段输出的特征图尺寸，其中 104×104 的特征图感受野最小，适合提高陶瓷插芯中的超小目标、小目标缺陷的检测精度。

FM-YOLO 模型在 Neck 部分的输出特征图通过 FPN 和 PAN 结构融合不同阶段不同深度不同尺寸间的位置特征和语义特征，每一层特征图获取的信息都在后阶段的预测中实现复用，实现多尺度跨阶段的目标预测。考虑到原 PAN 结构仅仅只是将不同尺度特征图变换的结构简单的相加，无法充分有针对性地学习不同尺度特征之间的相关性，为了更好地促进浅层和深层的不同尺寸的融合，本文提出了一种改进的 PAN 结构，如图 4.9 所示，引入一种自适应空间融合(Adaptively Spatial Feature Fusion, ASFF)机制^[78]，通过学习得到不同尺度之间融合的权重，抑制和惩罚当前尺度不重要的特征，仅保留和激励该阶层关注有用的信息。




图 4.9 自适应空间融合机制原理设计图

ASFF 具体细节设计如图 4.10 所示， X_1, X_2, X_3, X_4 分别代表从本研究的 FM-YOLO 模型的主干网络提取到的不同尺度的特征图，经过原 PAN 结构中的 FPN 的上采样融合后得到特征图 level 1~level 4，ASFF 的本质是在原来得到 level 1~level 4 的 add 的基础上增加一组权重系数 $[\alpha, \beta, \gamma, \delta]$ ，这组参数能够通过训练过程进行自适应的调整和学习，实现多尺度的自适应融合效果，得到融合后的结

果即 ASFF 1 到 ASFF4。




图 4.10 ASFF 模块原理细节图

由于 level 1~level 4 尺寸和通道数各不相同,在乘以各自的权重系数之前需要进行空间尺寸和通道数上的匹配,如 ASFF4 由 level 1~level 4 通过 1×1 的卷积核控制步长 stride 进行 2、4、8 倍的上采样,并压缩成与 level 4 相同的通道数后,由各自的 level 乘以上各自的权重系数 $[\alpha, \beta, \gamma, \delta]$ 再相加得到融合结果 ASFF4。求解如式 4-9:

$$y_{ij}^l = \alpha_{ij}^l \cdot x_{ij}^{1 \rightarrow l} + \beta_{ij}^l \cdot x_{ij}^{2 \rightarrow l} + \gamma_{ij}^l \cdot x_{ij}^{3 \rightarrow l} + \delta_{ij}^l \cdot x_{ij}^{4 \rightarrow l} \quad (4-9)$$

其中 i, j 表示特征图的 (i, j) 坐标的特征值, y_{ij}^l 代表第 l 个 ASFF 的特征图,即输出值; $x_{ij}^{n \rightarrow l}$ 代表第 n 个 level 经过上采样或下采样、压缩通道转换成第 l 个 level 的输入特征图; $\alpha, \beta, \gamma, \delta$ 指各层对应的映射系数即权重参数;最后通过自适应学习的参数线性相加得到 ASFF。这里通过 softmax 函数使 $\alpha_{ij}^l + \beta_{ij}^l + \gamma_{ij}^l + \delta_{ij}^l = 1$ 满足, $\alpha_{ij}^l, \beta_{ij}^l, \gamma_{ij}^l, \delta_{ij}^l \in [0, 1]$, 以 α_{ij}^l 为例, λ 为映射权控制参数,则数学上表达为式 4-10:

$$\alpha_{ij}^l = \frac{e^{\lambda_{\alpha ij}^l}}{e^{\lambda_{\alpha ij}^l} + e^{\lambda_{\beta ij}^l} + e^{\lambda_{\gamma ij}^l} + e^{\lambda_{\delta ij}^l}} \quad (4-10)$$

4.3.3 基于 scSE 模块的空间及通道激励增强

本文的神经网络中的卷积层的卷积操作的本质是通过上一个神经元输入的特征图学习特征并输出到下一个神经元。其中先前输入的特征图包括 H、W 维度

的空间特征和 C 维度的通道特征，普通的卷积操作是对输入特征进行所有通道之间的卷积计算，最后再结合空间特征最终融合成输出特征图。然而，陶瓷插芯表面缺陷图像中经过卷积到高维特征后，无论是通道还是空间均有一定的相互关系，并且直接卷积所有特征的运算在信息处理的角度上，并没有通道或者空间上的侧重学习，让深度学习的过程更关注到目标检测任务需要关注的通道和空间特征上。这种无的放矢的学习方式可能会使训练过程的学习效率降低，甚至可能会丢失关键的通道和空间信息。

为了检测模型更关注特征图的陶瓷插芯表面缺陷相关的通道和空间信息，本文提出在改进后的 Backbone 种引入 scSE(Spatial Channel Squeeze and Excitation) 模块^[79]激励对关键空间和通道信息的关注度，从而更快更精确地学到期望的缺陷特征信息。scSE 模块采用了注意力机制的思想，能够自适应地为特征图的空间和通道进行相互依赖的学习，在学习过程中不断调整空间和通道的重要程度权重值，分化卷积层对不同特征图的学习倾向，更有利于目标强相关的特征空间和通道的激励增强，而惩罚和抑制无用信息。scSE 模块主要由 sSE 模块和 cSE 模块两部分组成。




图 4.11 cSE 模块原理图

cSE(Spatial Squeeze and Channel Excitation)模块关注通道信息权重的学习，cSE 原理图如图 4.11 所示。原特征图 $U (H \times W \times C)$ 首先通过对空间上的全局平均池化操作得到压缩后的 Z 向量 $(1 \times 1 \times C)$ ，其空间维度也从 $(H \times W)$ 被压缩到了 (1×1) ；然后长度为 C 的 Z 向量经过两个全连接层进行通道特征权重的学习，第一个全连接层为长度为 $C/2$ 的特征向量，第二个全连接层长度为 C ，分别采用 ReLU 和 sigmoid 激活函数进行归一化输出，控制学习的激励权重值在 $[0, 1]$ 间。图中的颜色象征着全连接层特征向量在 C 个通道各自在训练过程自适应学习的权重和激

励值；最后将学习得到的激励值($1 \times 1 \times C$)和原特征图($H \times W \times C$)各个通道相乘得到经过通道激励校准的新特征图 $\hat{U}$ ($H \times W \times C$)，提高了网络提取通道信息的能力。




图 4.12 sSE 模块原理图

sSE(Channel Squeeze and Spatial excitation)模块原理示意图如图 4.12 所示，sSE 相较于 cSE 模块更侧重于增强空间特征的注意力，原特征图 U ($H \times W \times C$) 首先通过 $1 \times 1 \times 1$ 的卷积核的通道压缩从通道维度为 C 的被压缩成维度为 1 的 ($H \times W \times 1$) 尺寸，使中间特征图仅剩空间信息，避免了通道对空间特征学习的干扰；然后中间特征图 ($H \times W \times 1$) 经过 sigmoid 激活函数得到了空间特征上的权重信息；最后原特征图 ($H \times W \times C$) 和权重进行对应相乘，实现空间信息权重分配的校准，得到新特征图 $\hat{U}$ 。sSE 能够显著增强空间特征中与目标相关的位置的学习关注度，提高了空间特征信息的学习能力。




图 4.13 scSE 模块原理图

scSE 的原理图如图 4.13 所示，scSE 模块融合了 sSE 模块在空间特征上和 cSE 模块在通道特征上的关注能力，将 sSE 模块和 cSE 模块得到的特征图结果线性相加，使原特征图在空间和通道两个不同方向上均进行激励增强，并提高整个网络的检测精度。

本研究的陶瓷插芯表面缺陷检测网络中，考虑到小目标缺陷难以识别性以及大目标特征如长裂纹的在边界框占比小造成的难以提取性，本文在 Head 连接到 Neck 部分前的超小感受野和大感受野的 2 个通道前嵌入 scSE 模块，提高浅层和中深层提取超小目标和大目标特征的能力。表 4.3 的灰色部分即为 scSE 模块的嵌入位置和方式。

表 4.3 FM-YOLO 模型的 scSE 嵌入位置与方式

网络层/步长		卷积核×过滤器	输出
输入			416×416
1×	DW 层/2	3×3×32	208×208
	卷积层/1	3×3×32	208×208
1×	DW 层/2	3×3×64	104×104
	卷积层/1	1×1×128	104×104
	DW 层/1	3×3×128	104×104
	卷积层/1	1×1×128	104×104
scSE 模块			
1×	DW 层/2	3×3×128	52×52
	卷积层/1	1×1×256	52×52
	DW 层/1	3×3×256	52×52
	卷积层/1	1×1×256	52×52
1×	DW 层/2	3×3×128	26×26
	卷积层/1	1×1×256	26×26
5×	DW 层/1	3×3×256	26×26
	卷积层/1	1×1×256	26×26
scSE 模块			
1×	DW 层/2	3×3×128	13×13
	卷积层/1	1×1×256	13×13
	DW 层/1	3×3×256	13×13
	卷积层/1	1×1×256	13×13

如图 4.14 所示，对嵌入 scSE 模块的 FM-YOLO 模型与未嵌入 scSE 的原始 YOLOv4 模型的中间卷积层的权重参数进行热力学分析进行比较，颜色越鲜艳的区域代表着模型网络在训练学习过程中对该区域分配的卷积权重越大，说明模型更关心该区域的特征。由图 4.14 可见，YOLOv4 原模型的热力图分布较为分散，其中部分注意力还集中在与缺陷特征无关的区域；而嵌入 scSE 模块的 FM-YOLO 模型的热力图关注的区域能够更集中在真实缺陷特征周围，使模型更易学习到缺陷区域的特征，加快模型收敛和模型准确率。




图 4.14 嵌入(左)和未嵌入(右)scSE 模块的权重热力学分析图

基于 YOLOv4 模型, 经过 4.3.1 节在主干网络引入 MobileNet 网络、4.3.2 节引入自适应空间特征融合的 ASFF 结构、增加超小目标尺度的预测改进以及本节在主干网络中嵌入的两个 scSE 模块后, 构成了本文提出的 FM-YOLO 模型总体网络结构, 具体细节如图 4.15 所示。




图 4.15 本文提出的 FM-YOLO 模型结构图

4.3.4 基于 DIoU-NMS 的非极大值抑制算法优化

边界框预测是陶瓷插芯表面缺陷检测任务中检测结果的关键部分, 同时也是描述检测精度的重要指标。目标检测模型中, 非极大值抑制(NMS)算法^[80]是边界

框预测阶段的最后一个步骤：输入特征图在得到一系列潜在目标的预选框后，同一个目标会出现很多重叠重复的预选框，而NMS算法的目的就是消除抑制冗余的并保留最优的预测边界框。

传统NMS算法的步骤如下：第一步，给定所有候选的预测边框(Boxes)的集合 $B = \{b_1, b_2, \dots, b_n\}$ 以及相应的置信度分数(Scores)的集合 $S = \{s_1, s_2, \dots, s_n\}$ ，并且设置一个IoU阈值 N_t ；第二步，初始化集合 D 为空集，将集合 B 中分数最高的预测边框 M 从 B 中删除并加入集合 D ；第三步，集合 B 中删除所有与 M 的IoU重叠程度大于先前设定的阈值 N_t 的所有预测框；第四步，重复步骤1~3直到集合 B 为空集，第三步中删除的预测框即本算法判定为冗余重叠的部分，对其抑制淘汰处理，集合 D 则为通过非极大值抑制得到的一系列最优预测框即结果集。

传统NMS采用的是IoU作为判断两个预测框是否重叠即重复表示同一个目标物体的依据，然而在本研究的陶瓷插芯表面缺陷检测的一些场景中，采用与 M 的IoU阈值作为抑制的判断标准可能会造成误判，最后将部分置信度分数略低于 M 但IoU重叠程度较高的需要保留的预测边界框进行错误的淘汰。例如陶瓷插芯中检测出候选的裂纹缺陷的预测边界1和边界框2，其置信度分数分别为0.95和0.92，按照传统NMS算法，优先选择置信度较高的边界框1，然而由于边界框1、2中心点距离相对于边界框的比例较小，二者的IoU重叠程度大于设置的阈值0.5，边界框2被抑制并剔除，从而导致实际不同裂纹的理论最优边界框被错删，甚至可能出现漏检的情况。

IoU的局限性体现在对目标重叠方式和目标尺度变化的不敏感型。相同的IoU下可能体现不同的重叠方式和不同的尺度变化，由于堆叠方式不同以及尺度上的变化均导致不同程度的重叠方式下IoU指标可能相等，无法准确地反映两个边界框的实际距离，在相交面积相等但中心点距离不相等的情况下没有区分能力。

基于上述，本文提出引入用DIoU^[81]的方式替代传统NMS算法中的IoU计算方式即DIoU-NMS，以改善IoU在目标检测上的局限性。DIoU(Distance-IoU)不同于经典IoU的计算方式，并不仅仅计算两个边界框的交并比，同时引入了位置距离参数，通过两个边界框并集的最小外接矩形进行计算，当两个边界框不发生重

叠时，DIoU 会惩罚两个中心点距离之间的损失，其表达式如式 4-11:

$$DIoU = IoU - \frac{\rho^2(b, b^{gt})}{c^2} \quad (4-11)$$

其中, b, b^{gt} 分别指预测边界框和真实标注框的中心坐标点; $\rho()$ 指两点间的欧氏距离; c 指预测边界框和真实标注框并集的最小外接矩形的对角线长度; DIoU 相较于 IoU, 综合考虑了两个重叠边界框的距离、尺度、堆叠方式等因素, 其中两个中心点的距离 $d = \rho^2(b, b^{gt})$ 衡量了边界框 A 和边界框 B 的实际距离, 最小外接矩形对角线 c 一定程度上描述了边界框 AB 之间的堆叠方式。

本文提出的 FM-YOLO 模型在训练阶段和检测阶段的边界框预测过程中均用 DIoU-NMS 替代传统 NMS 算法, 实验结果如图 4.16 所示, 采用传统 NMS (左) 和 DIoU-NMS(右)后在本研究数据集中的缺陷图像的识别效果, 采用 NMS 的检测方法会出现部分缺陷未识别的情况, 而采用 DIoU-NMS 的方法能够检测出该缺陷。




图 4.16 传统 NMS 算法预测框(左)与 DIoU-NMS(本文)预测框(右)检测效果对比

图 4.17 中表明在 IoU 阈值取 $N_t = 0.45$ 、 0.5 、 0.55 的情况下，本研究分别采用 NMS 和 DIoU-NMS 在的陶瓷插芯表面缺陷检测中得到的平均精确率(AP)的变化趋势图表，可以看出采用 DIoU-NMS 的检测效果更好，比采用 NMS 的平均高出 0.53 个百分点。




图 4.17 采用 DiIoU-NMS 和 NMS 算法在 FM-YOLO 的 AP 表现对比图

4.4 FM-YOLO 模型的训练过程与实验验证

4.4.1 基于深度迁移学习的 FM-YOLO 模型训练

本文提出的 FM-YOLO 模型训练的开始时, 由于网络的初始权重参数是随机生成的, 直接从头开始训练很容易出现学习过程中的偶然的梯度消失现象, 造成权重参数的学习速率慢甚至目标模型无法收敛的情况。为了使模型学习的过程更有确定性, 本文引入了深度迁移学习过程和思想, 在 4.3 节改进的基础上, 进一步提升陶瓷插芯表面缺陷检测模型的训练效率和检测精度。

深度迁移学习本质上是利用卷积神经网络中浅层学习特征的通用性, 借助用来解决任务 A 的网络结构和权重参数值迁移到任务 B 中, 同样有较好的训练效果。陶瓷插芯数据集局限的情况下, 深度迁移学习可以在利用类似任务的数据集训练出的模型权重, 实现学习模型的迁移, 加速和促进训练过程。

假定本研究的陶瓷插芯表面缺陷检测任务记为 T_t , 经过本文提出的数据增强方法后的目标数据集记为 D_t ; 迁移模型源任务记为 T_s , 源数据集 D_s ; 其中通常源任务和源数据集构成的源域 A_s 远远大于目标任务和数据集构成的 A_t , 陶瓷插芯表面缺陷数据集和目前公开的数据集中相似程度不高, 浅层特征网络的借鉴意义不大, 但数据集中图像的深层特征仍具有参考和迁移的意义。COCO 数据集是 Microsoft 发布的一个大型目标检测数据集, 其在 2017 年的版本包含了 22 万张以

上标注过的图像，包括行人、动物、物品等 150 万多个目标数量和 80 种目标类别。

本文采用 COCO 数据集作为 D_i 进行深度迁移学习，主要目的是学习 COCO 数据集中的深层特征，并将其权重参数迁移到本文的目标检测模型高层网络作为训练开始的初始值。




图 4.18 深度迁移学习训练过程原理图

训练过程如图 4.18 所示，第 1 步，初始阶段采用 COCO 数据集作为初始数据集，采用本文提出的 FM-YOLO 作为训练网络，网络初始权重值采用均值 $E=0$ ，标准差 $\sigma^2=1$ 的正态分布进行随机生成，同时设置批处理 $Batch=128$ ，总迭代次数为 150 次初始学习率 LR 设置为 0.001，并采用动量系数为 0.9、衰减权重为 0.005 的 Adam 自适应学习率算法进行训练过程中过的梯度下降；第 2 步，采用 Warm-up 策略，即在开始的 10 个 Epoch 中保持低学习率并逐步提升，到达中期的 30~40 Epoch 时，学习率达到最高，并在中后期放缓学习率 0.1 倍，确保模型在梯度变化小的训练后期更好地收敛；第 3 步，Warm-up 期间即前 10 个 Epoch 中，FM-YOLO 网络正常训练每一个网络层，在 10 个 Epoch 之后，冻结 FM-YOLO 的特征提取网络 Backbone 的前 8 层网络的 DW 卷积单元，在接下来的 Epoch 中仅训练高层的网络来更精确地学习到深层网络的特征权重，冻结的网络层在训练过程中不参与反向传播的梯度推理，权重参数不会发生变化；第 4 步，用 COCO 数据集训练到 150 个 Epoch 后，保存 Backbone 的 8 层后的网络权重参数，将其作为本实验中的深层网络权重参数的初始值。采用本文经过第 3 章提出的数据增强处理后的数据集，取第 1 步相同的初始设置和策略安排及第 3 步学习的深层网络权重作为

预加载权重进行训练,至此完成了从 COCO 数据集学习到的深层特征权重向本研究的陶瓷插芯数据集及 FM-YOLO 模型的深度迁移学习。

其中第 1 步的 Adam 算法是一种基于梯度下降的自适应学习率优化算法,梯度下降的主要思想是在训练过程后期主动调整学习率 LR ,使损失函数优化方向变化为梯度的负方向,让网络权重参数逐步逼近真实权重值。Adam 算法采用一二阶矩估计来调整训练过程中每个参数的学习率 LR ,相较于传统的批量梯度下降算法 BGD 和随机梯度下降法 SGD,Adam 算法保证更新跨度的步长不会过大而导致无法收敛,计算效率更高,所需内存更小。假定 θ 为模型参数, LR 为学习率, $\hat{m}, \hat{n}$ 为对梯度一阶矩和二阶矩估计的校正, ε 为维持数值稳定的常数,本研究中取 $\varepsilon = 10^{-8}$,则 Adam 的模型参数数学表达如式 4-12 所示:

$$\Delta \theta_t = -\frac{\hat{m}_t}{\sqrt{\hat{n}_t + \varepsilon}} \cdot LR \quad (4-12)$$

第 2 步中的 Warm-up 策略的核心是控制训练初始阶段的学习率。由于神经网络初始的 Loss 较大导致梯度较大,若不及时调整此时的学习率 LR 可能会造成模型学习的不稳定,导致学习方向飘忽不定和难以收敛。Warm-up 将训练伊始的学习率设置的较低,随着训练进程逐渐增加学习率到正常水准,在模型接近收敛时再将学习率逐步调低,使训练的最后阶段逐步逼近真实模型并加速收敛过程。

Warm-up 策略过程的学习率可以表达为式 4-13:

$$LR(t) = \left(1 - \frac{t - LR_{wm}}{LR_{tl} - LR_{wm}}\right)^p \cdot LR_0 \quad (4-13)$$

其中 $LR(t)$ 指随着训练步数 t 变化的学习率 LR ; LR_{wm} 指 Warm-up 开始时的学习率,这里设置为 0.001; LR_{tl} 指总共设定的训练步数,这里设置为 150 个 Epoch; p 为控制学习率变化的速率,这里取 $p < 1, p = 0.9$,在 LR_0 为正式训练时的正常学习率,设置为 0.005;图为本研究模型训练过程的学习率变化趋势,当 $t = LR_{wm}$ 时,学习率为 LR_0 ,学习率呈先上升后下降的趋势,当正式训练的进程接近末期时,学习率迅速下降并逼近 0,控制梯度变化的稳定性,保证模型的收敛。

图 4.19 为 FM-YOLO 模型在训练过程中的特征图可视化,其左上角为数据集的原始陶瓷插芯缺陷图像;其余图像为特征图随着 FM-YOLO 模型网络深度的增大而提取出的不同特征图;从图 4.19 可以观察到,在浅层网络特征图着重关注于陶瓷插芯缺陷的形状、纹理等特征,而随着卷积次数的增多和网络深度的推进,深层网络特征图显示出的内容不再是图像细节,取而代之的是抽象的高层语义特征,这些特征能够在高维度下进行类别的区分,但难以直接用肉眼分辨。




图 4.19 训练过程不同通道/深度下的中间卷积特征图可视化

图 4.20 为本研究在提出的 FM-YOLO 模型在正常训练和深度迁移学习后的训练的 AP 曲线,曲线从 Warm-up 过程结束后开始统计,其中 AP 指陶瓷插芯表面缺陷的所有类别的平均准确率。从曲线可以观察到:随着训练过程的推进,训练到 60~70 个 Epoch 时 AP 曲线的上升速度达到了峰值,到 120 个 Epoch 后 AP 曲线开始趋于稳定;从图中的深度迁移学习后训练和正常训练的过程对比来看:AP 曲线的变化趋势大体一致,然而整体 AP 值和初始 AP 值都比正常训练更优越,且 AP 曲线收敛速度更快;正常训练过程在 60~100 Epoch 过程中 AP 曲线出现先下降再上升的波动形态,表明正常训练过程中模型在调整自身的学习方向;而深度迁移学习后训练过程的 AP 曲线波动幅度较小,表明模型向期望的方向进行收

敛；其中深度迁移学习后的模型整体 AP 值提高约 5.8%，AP 斜率在 15~20 Epoch 时达到峰值，到达 110 个 Epoch 后开始趋于稳定，深度迁移学习后的训练过程整体领先正常训练 10~30 个 Epoch，最终的准确率和损失值也优于正常训练的模型性能，实验验证了 COCO 数据集深层特征的距离迁移学习对陶瓷插芯检测模型训练过程的有效性。




图 4.20 正常训练和深度迁移后训练的平均准确率 AP 变化图

4.4.2 FM-YOLO 模型有效性实验验证

FM-YOLO 模型是本研究基于 YOLOv4 模型分别在网络结构上、网络模块上、边界框预测算法提出并改进的更适用于陶瓷插芯表面缺陷检测的网络模型。其骨干网络 Backbone 采用轻量化 MobileNet 替换，并对网络其他部分的多层卷积替换成 DW 卷积结构；Neck 部分增加 ASFF 模块，改善不同尺寸间的自适应空间融合，并引入 scSE 模块增强空间和通道的注意力激励；Head 部分增加 104×104 预测头以增强对小尺寸缺陷的识别能力；最后在预测边界框的 NMS 算法进行 DIoU-NMS 算法以改善部分因 IoU 机制不完善而造成的漏检。本节从本研究提出的这些改进方向进行模型的消融实验验证，进行了 17 组不同改进的组合对照试验以证明本文提出的 FM-YOLO 的合理性和有效性。

如表 4.4 所示，消融实验采用 mAP、准确率、查全率作为模型精度的衡量指

标，检测时间指 GPU 环境下单张陶瓷插芯缺陷图像的检测时间。

表 4.4 FM-YOLO 模型不同改进方向的消融实验(不同指标下)

对 照	改进方法				指标			
	MobileNet	scSE	ASFF	DIoU-NMS	mAP	准确率	查全率	检测时间
1					0.783	0.792	0.835	29ms
2	√				0.780	0.789	0.834	6ms
3		√			0.883	0.895	0.831	33ms
4			√		0.865	0.878	0.845	35ms
5				√	0.843	0.831	0.896	35ms
6	√	√			0.893	0.908	0.835	8ms
8	√		√		0.903	0.915	0.843	8ms
9	√			√	0.889	0.883	0.892	9ms
10		√	√		0.912	0.938	0.879	37ms
11		√		√	0.928	0.923	0.932	35ms
12			√	√	0.930	0.928	0.934	34ms
13	√	√	√		0.912	0.946	0.895	11ms
14	√	√		√	0.947	0.942	0.962	11ms
15	√		√	√	0.960	0.948	0.968	13ms
16		√	√	√	0.972	0.968	0.981	36ms
17	√	√	√	√	0.978	0.970	0.986	14ms

表 4.4 中所示的 17 组不同组合对照实验中,初始状态不做任何改进的 YOLOv4 的检测精度指标 mAP 仅为 0.783 无法满足工业需求,对照 2 实验在引入 MobileNet 结构后,在检测准确率上略微降低 0.3%,但模型大小和模型检测速度得到显著的提升,相较于原始 YOLOv4 的 29ms 降低了 4.8 倍至 6ms,查全率与 YOLOv4 基本持平;对照 3 实验引入 scSE 的空间及通道激励模块后,虽然检测时间略微增加 4ms,但 mAP 提升了 10.0%,效果显著;对照 4 引入 ASFF 模块后,同样也增加了网络的复杂度,导致检测时间的轻微上升,但 mAP 同时也增长了 8.6%;对照 5 引入新的边框预测的 DIoU-NMS 后,查全率得到了 6.1%的显著提升,同时增加了边框预测过程的计算时间;在对照 6~12 实验中,实验分别只引入 2 种不

同的改动,模型检测准确率指标开始跃升到0.9以上,表明了改动组合同样对模型精度有较大的提升效果;对照13~16实验中,模型的精度进一步得到提升,mAP指标达0.95以上;对照17即本文提出的FM-YOLO模型在精度指标性能均为最优,同时检测时间相较于原始模型减少了51.7%,整体模型的实用性更好;综上所述本文提出的FM-YOLO模型从改进方法的组合消融实验结果来看,每个改进均为模型的精度或速度提供了贡献,将方案组合后,原YOLOv4的mAP由0.783提升了24.9%至0.978,效果显著,验证了各改进方法独立及组合方案的优越性。

表4.5是FM-YOLO模型消融实验在不同缺陷特征的表现对比,其中衡量指标为平均准确率AP,其实验结果是基于增强后数据集并按训练集、测试集、验证集的分配比例为8:1:1展开实验得到。

表4.5 FM-YOLO模型不同改动方向的消融实验(不同缺陷下)

对照	改进方法				缺陷(特征)				
	MobileNet	scSE	ASFF	DIoU-NMS	芯头	凹坑	裂纹	擦伤	污点
1					0.832	0.763	0.782	0.751	0.725
2	√				0.829	0.762	0.779	0.748	0.722
3		√			0.935	0.866	0.885	0.854	0.828
4			√		0.918	0.849	0.868	0.837	0.811
5				√	0.871	0.802	0.821	0.790	0.764
6	√	√			0.948	0.879	0.898	0.867	0.841
8	√		√		0.955	0.886	0.905	0.874	0.848
9	√			√	0.923	0.854	0.873	0.842	0.816
10		√	√		0.978	0.909	0.928	0.897	0.871
11		√		√	0.963	0.894	0.913	0.882	0.856
12			√	√	0.968	0.899	0.918	0.887	0.861
13	√	√	√		0.986	0.917	0.936	0.905	0.879
14	√	√		√	0.982	0.913	0.932	0.923	0.875
15	√		√	√	0.988	0.919	0.948	0.927	0.881
16		√	√	√	0.989	0.941	0.96	0.938	0.913
17	√	√	√	√	0.991	0.962	0.973	0.965	0.939

由表 4.5 可见，芯头由于特征单一，学习特征较易，因此在所有特征中是检测效果表现最优，FM-YOLO 上的平均准确率 AP 高达 0.992；凹坑、擦伤等中小尺寸居多的缺陷在引入 scSE 和 ASFF 模块后，AP 指标平均飙升 21.2%，说明这两个改进方向对中小尺寸的提升较大；裂纹缺陷由于尺度种类较多，跨尺寸的缺陷在 ASFF 模块和 DIoU-NMS 算法的引入后，AP 指标上升 13.1%；污点缺陷属于超小尺寸缺陷，在整体网络增加 Head 预测头后，检测能力也从原来的 0.725 上升到 0.939，处于所有特征识别种类中准确率较低水平，但已能满足陶瓷插芯工业现场要求；综上可见本研究做出的不同的改进方向分别对不同缺陷特征的精度有很大的改善，验证了 FM-YOLO 在陶瓷插芯表面缺陷检测任务上的有效性。




图 4.21 陶瓷插芯表面缺陷 FM-YOLO 检测模型 P-R 曲线

不同缺陷特征在 FM-YOLO 模型的 P-R 曲线如图 4.21 所示。P-R 曲线是描述模型准确率和查全率间的变化趋势，是衡量模型在不同缺陷上的检测能力的指标体现。从图 4.21 可见，head 特征在 P-R 图中的学习效率最高，其曲线处于其他缺陷的上方，mAP 指标高达 0.991；崩缺缺陷是通过有无 head 特征来判断，因此间接使崩缺的识别率达到了同样的较高水平；pit 和 bruise 缺陷在 P-R 曲线的表现基本持平，重合度较高，二者同属于原数据集中的少数类缺陷，经过第三章的数据增强后在识别精度上也是得到了一致的提升；crack 缺陷由于在尺寸上跨尺度较大，crack 的 P-R 曲线在查全率 Recall 大于 0.5 后逐渐开始整体高于 pit 和 bruise 的 P-R

曲线；blot缺陷以小尺寸居多，在所有缺陷中的识别难度最大因此 blot 的 P-R 曲线处于其他缺陷特征的 P-R 曲线的下方，但相较于原始 YOLOv4 模型的 mAP 已有很大的改善，从原来的 0.706 上升了 33.3%至 0.939。




图 4.22 FM-YOLO 与 YOLOv4 检测效果对比图一

FM-YOLO 实际检测效果图如图 4.22 所示，图 4.22 的对比图中，YOLOv4 对小尺寸的 blot 缺陷会产生漏检现象，FM-YOLO 在引入 104×104 新的预测头与 DIoU-NMS 算法后能够增加小尺寸 blot 缺陷和重叠率较高缺陷的识别率。




图 4.23 FM-YOLO 与 YOLOv4 检测效果对比图二

如图 4.23 的对比图所示，FM-YOLO 相较于原始 YOLOv4 能够区分 bruise 和 crack 缺陷，并在更小尺度上识别出来，图 b 中 YOLOv4 模型将多个缺陷简单的识别为一个大的 bruise 缺陷，本研究提出的 FM-YOLO 在引入 ASFF 模块后，对尺度的变化更敏感，能够更细化程度上的识别出多个小缺陷。




图 4.24 FM-YOLO 与 YOLOv4 检测效果对比图三

如图 4.24 的对比图所示, FM-YOLO 模型借着引入的 DIoU-NMS 算法能够将原始 YOLOv4 误检的 crack 缺陷进行正确的识别, 并更细化的将重叠较多的缺陷区分开并识别。

4.5 本章小结

本章阐述了本研究提出的 FM-YOLO 的设计过程。首先, 简单介绍 YOLOv4 模型的结构与原理, 并分析 YOLOv4 在陶瓷插芯表面缺陷检测任务中的局限性; 然后, 本文针对模型检测的问题, 在 YOLOv4 模型的基础上进行了深度可分离卷积的轻量化融合设计, 并引入 ASFF 模块和 scSE 模块增强模型对空间和通道的自适应融合与增强, 新增一个尺寸预测头来缓解小目标检测精度低的问题, 用 DIoU 替换传统 NMS 算法解决部分重叠缺陷漏检的情况; 最后 FM-YOLO 通过基于深度迁移学习的模型训练和消融实验验证了 FM-YOLO 模型的改进策略的有效性和优越性。

第5章 陶瓷插芯表面缺陷检测软件设计与综合实验验证

5.1 引言

本章设计开发一种具有图形交互界面的陶瓷插芯表面缺陷检测软件，将FM-YOLO模型封装到软件功能函数中，同时应用此软件完成对前文提出的基于离散掩膜差分的缺陷图像重生方法和FM-YOLO模型进行综合的组合实验验证与分析。

5.2 陶瓷插芯表面缺陷检测软件设计

5.2.1 软件总体框架

本文基于MATLAB® R2020b的图形工具包开发出一种图形化人机交互界面的陶瓷插芯表面缺陷检测软件，封装FM-YOLO模型的同时增加了工业上缺陷检测常用功能作为软件模块。软件包括以下4个模块：缺陷检测模块、数据矫正模块、数据统计模块、数据存储模块。

缺陷检测模块是软件的核心模块同时也是检验本研究成果最关键的功能，该模块在图形化界面上主要展示内容有：陶瓷插芯批次和型号、拍摄环境、检测结果等，并将检测模式分为在线检测和离线检测两种模式；数据矫正模块是陶瓷插芯工业线上使软件适应更多现场样本、维持检测精度的重要模块，该模块主要用于及时手动矫正实时检测场景下的软件判断失误以及调整检测模型版本的选择，矫正以及二次训练的结果会连接数据库，保存到一个新分支以保证能够进行版本控制；数据统计模块可以实现根据时间、缺陷类型、批次信息为查询条件的历史数据展示，同时根据历史记录可以链接到数据矫正模块，并对检测结果存在问题的历史图像做校正并扩充数据集；数据存储模块能够直接链接到基于MySQL数据库的陶瓷插芯图像库，查看所有检测过的陶瓷插芯图像以及数据集中已验证和未验证的缺陷图像。4大模块之间的关系和软件检测流程如图5.1。




图 5.1 陶瓷插芯表面缺陷检测软件模块间联系图

如图 5.1 所示，待检测的陶瓷插芯图像输入软件后，首先进入缺陷检测模块并加载 FM-YOLO 模型后返回检测结果到图形化界面上，同时将检测结果为不合格的陶瓷插芯原图和检测结果转化并保存为数据集格式文件到数据存储模块的未验证部分；人员复核检测结果是否合理，若检测结果合理可以将图像加入已验证部分作为数据集的扩充。若检测结果不合理，则可以通过数据矫正模块进行人工修改后重新加入数据存储模块的已验证部分，在数据统计模块的已验证部分积累到人工设定的规模时，可以通过手动触发或者自动触发的方式将扩充数据集和以前的历史数据进行二次训练增强模型的泛化能力和鲁棒性，并将新模型的权重文件保存在数据库的新分支下供调用；数据统计模块和数据存储模块分别承担展示和存储的功能，是整个软件的统计中心和数据中心。

5.2.2 软件模块实现

（1）缺陷检测模块

陶瓷插芯表面缺陷检测软件的检测缺陷模块主界面如图 5.2 所示，界面按照展示功能的不同分为不同区域栏：“陶瓷插芯信息”、“检测参数”、“原图和检测结果”、“当前陶瓷插芯检测分析”、“数据统计”、“其他操作”。




图 5.2 检测软件主界面

“陶瓷插芯信息”包括输入图像的“批次号”、“图像编号”、陶瓷插芯“型号”以及“检测时间”。“检测参数”主要包括软件状态参数和实时检测参数，其中软件状态参数指“Online”和“Offline”监测，在线监测需要切换“软件状态”选项，实现工业信号和后台数据库的连接，读取相机实时检测的陶瓷插芯参数和拍摄环境参数；离线监测指人员可以选择不同的图像来源进行缺陷检测。实时检测参数指图像加载过程时的硬件参数如“光照强度”、镜头相机的“焦距物距”、“图像分辨率”和软件参数如“图像来源”和“模型版本”，其中模型版本指本文 FM-YOLO 模型加载不同版本的网络权重参数而产生的多版本选项，其不同版本指陶瓷插芯检测过程经过数据集扩充后的二次训练的结果，模型也因此获得更优的鲁棒性和泛化能力；

“原图和检测结果”即输入的陶瓷插芯原图和经过模型推理出的检测结果；“当前陶瓷插芯检测分析”通过在线监测判断陶瓷插芯是否有缺陷特征来判别合格与否，同时将检测出的表面缺陷类型和个数显示在该区域栏里。陶瓷插芯检测过程可以通过该区域栏的“开始检测”和“停止检测”进行启停，并可以通过“详

情”选项跳转到数据统计模块，通过“校正”选项跳转到数据矫正模块。

“数据统计”区域项主要记录软件启动后参与检测的陶瓷插芯总量、合格率以及不合格率；“其他操作”中的“历史数据查询”可以跳转到数据统计模块查看历史处理结果，“数据存储库”选项可以跳转到数据存储模块，查看当前陶瓷插芯图库的已验证和未验证数据集数据。

(2) 数据矫正模块

数据矫正模块的陶瓷插芯检测结果校正界面如图 5.3 所示，本界面可以通过主界面的“校准”选项及“历史数据查询”中的查看详情选项 跳转至此。界面展示了人员重新选定需要校准的图像信息如每一张图像的唯一标识符“编号”，同时提供“开始校准”、“保存校准”选项可供人员进行启停和存储校准过程。




图 5.3 结果校正界面

数据矫正模块植入了 Labellmg 标注软件接口，选择“开始校准”后，即可跳转到标注软件进行标注，并将新标注的图像 xml 文件信息替换原图像的检测结果。人员对图像中误差较大的检测结果进行修改之后，退出调用的 Labellmg 软件接口，选择“保存校准”即可连接数据统计模块的数据库，并将新的标注格式文件存储

到数据库的“已验证”数据集分支，方便数据集的扩充和再利用；界面中所示意的左下方和右下方的为陶瓷插芯图像校正前和校正后的预测边界框坐标。

(3) 数据统计模块

数据统计模块的历史数据查询界面如图 5.4 所示，该模块连接后台 MySQL 数据库，提供以陶瓷插芯型号批次号、图像编号、型号、起始时间、缺陷类别、有无验证作为查询条件字段的接口，人员可以通过选择一个或多个条件进行数据筛选，查找到符合条件的历史数据记录。同时，数据统计模块界面的查询结果中提供“详情”的选项，通过该选项可以跳转到上文的数据矫正模块进行陶瓷插芯检测结果的查看和重新校准。

历史数据查询

批次号

L208

图像编号

型号

SC-2.5

查询所选

起始时间

2022-03-05

结束时间

2022-03-05

☒ 凹坑

☐ 崩缺

☐ 污点

☐ 擦伤

☒ 裂纹

☐ 已验证

☒ 未验证

图像编号	检测结果	特征类别	检测时间	选项
A235	不合格	凹坑 裂纹	2022-03-05 13:05	详情
A286	不合格	凹坑 裂纹	2022-03-05 13:05	详情
B002	不合格	凹坑 裂纹	2022-03-05 13:05	详情
B082	不合格	凹坑 裂纹	2022-03-05 13:05	详情

图 5.4 历史数据查询界面

(4) 数据存储模块

数据存储模的数据存储库界面如图 5.5 所示，该模块直接控制陶瓷插芯数据集图库，数据内容由“已验证检测结果”和“未验证检测结果”两大部分组成。其中未验证检测结果指陶瓷插芯在离线或者在线检测表面缺陷过程中不合格产品的检测结果，检测结果已保存为数据集的文件格式，详细记录检测出来的图像编号、缺陷数量、缺陷类别、加入时间、缩略图等检测信息； 由于检测结果直

接由 FM-YOLO 模型推理得到，检测结果存在不完全正确的可能性，因此归类到未验证数据集中；人员检查过后能够通过界面上半部分的选取可以直接将一部分未验证数据集图像直接加入已验证数据集，或通过未验证数据集图像的“查看详情”进行二次校准后自动加入已验证的数据集。通过此界面可以控制已验证和未验证数据集的移入和移出。



图 5.5 数据存储库界面

已验证数据集不仅包括人为加入的新数据还包括前文用以训练 FM-YOLO 模型的初始数据集，其目的是防止二次训练过程丢失先前的学习成果，使模型权重参数出现大幅波动。当已验证数据集积累到人为设定的一定规模时，本研究设置为新增 3000 张已验证数据集图像后，可以选择“重新训练”选项，将已验证数据集作为 FM-YOLO 的数据源进行二次训练，训练成功的新模型权重会作为新文件以新版本的身份加入数据库，主界面可以通过和数据库的连接使用模型的新权重版本，也可以选择回退使用旧版本，以防止版本变动带来的检测性能上的风险。

5.3 陶瓷插芯表面缺陷检测综合实验验证

5.3.1 表面缺陷检测组合实验验证

本节采用 5.2 节设计开发的检测软件完成 4 组组合对照试验，并论述本研究提出的基于离散掩膜差分的缺陷图像重生方法和 FM-YOLO 模型组合的优越性。

表 5.1 为本研究提出的 2 个改进方案在各个缺陷特征上的组合对照实验结果，其中√表示使用改进方法，空白表示不使用改进方法，使用“增强后数据集”改进方法即在模型训练时采用第三章提出的离散掩膜差分和对抗网络结合的缺陷图像重生方法后增强的数据集，不使用“增强后数据集”改进方法即实验采用原数据集作为对照组；不使用“FM-YOLO”改进方法时采用原始 YOLOv4 模型作为对照组；其中指标采用平均准确率 AP 衡量。

表 5.1 离散掩膜差分对抗-FM-YOLO 模型组合方案对照实验结果

对 照	改进方法		缺陷/特征				
	增强后数据集	FM-YOLO	芯头	凹坑	裂纹	擦伤	污点
1			0.815	0.754	0.781	0.768	0.688
2	√		0.912	0.798	0.827	0.803	0.713
3		√	0.982	0.763	0.893	0.786	0.892
4	√	√	0.991	0.962	0.973	0.965	0.939

由表 5.1 可见，原始的 YOLOv4 模型(对照 1)在不进行任何操作的情况下，由于数据集分布不均、网络结构没有改进等原因，其在小目标缺陷的污点和少数类缺陷的凹坑、裂纹的检测上准确率都低于 0.82，表现不佳，无法满足工业实际需求;单独引入离散掩膜差分的缺陷图像重生方法后(对照 2)，少数类缺陷凹坑、裂纹的准确率平均提升了 4%，芯头缺陷的 AP 提升了 16.7%。然而，污点缺陷的 AP 指标没有得到显著提升，与未增强前的表现基本持平；单独引入 FM-YOLO 模型(对照 3)后，各个缺陷的 AP 值得到进一步提升，尤其是在污点缺陷的检测上，AP 指标上升了 20.4%。这表明 FM-YOLO 模型在小目标缺陷检测方面有较大的提升作用，而其它缺陷的 AP 值也有不同程度的改善，平均提升了 6.3%；本文提出


的两个改进方案（对照 4）的实验结果表明，对照 4 实验的所有缺陷的 AP 指标都表现出色，是所有对照组中表现最优的。其中，芯头缺陷的检测精度更是高达 0.991，而小目标缺陷和少数类缺陷也获得了不同程度的检测精度提升；综上实验结果可以验证，基于离散掩膜差分的缺陷图像重生方法和 FM-YOLO 模型的独立及组合均具有优越性和有效性。

表 5.2 离散掩膜差分对抗-FM-YOLO 模型组合方案对照实验结果


对 照	改进方法		指标			
	增强后数据集	FM-YOLO	mAP	准确率	查全率	检测时间
1			0.695	0.762	0.635	29ms
2	√		0.783	0.792	0.835	29ms
3		√	0.873	0.915	0.854	14ms
4	√	√	0.978	0.970	0.986	14ms

表 5.2 显示了本研究提出的 2 个改进方案在综合的组合对照实验结果。从表中可见，与对照组 1、2、3 相比，引入 FM-YOLO 模型相比于离散掩膜差分对抗的方案对原始模型的提升更大，mAP 指标分别提升了 17.8% 和 8.8%。由于 FM-YOLO 模型采用深度可分离卷积进行轻量化处理，整体模型的计算参数量大幅降低，因此从对照 1 和对照 3 实验结果可以看出，FM-YOLO 模型的检测时间从原来的 29ms 降低到 14ms 有显著的降幅，这大大提高了工业上的检测效率；从对照 1 和对照 2 的实验结果来看，离散掩膜差分方法的引入主要对查全率有显著贡献。相对于原始数据集，该方法实现了 20% 的查全率提升；从对照 1 和对照 3 的实验结果来看，FM-YOLO 模型虽然没有为原始模型的查全率带来质变的提升，但准确率从 0.762 飙升到 0.915，证明了 FM-YOLO 模型引入的 ASFF 模块和 scSE 模块对模型精度提升的显著效果；从对照 1 和对照 4 的实验结果来看，本研究提出的基于离散掩膜差分的数据增强方法和改进模型 FM-YOLO 的组合最终相对于原始数据集和原始 YOLOv4 的组合，在 mAP 上提高了 28.3%，准确率提高了 20.8%，查全率提高了 35.1%，检测时间降低了 51.7%，其中查全率在单独引入增强后数据集或 FM-YOLO 的情况下没有明显提升，但在两个方法组合后实验结果的查全

率出现了显著提升,这验证了本文提出的两个方案对模型的检测精度有相互促进的作用,同时也证明了本研究提出的两个方案组合的有效性和可用性。



(a) FM-YOLO模型的Precision和Loss表现



(b) 原始YOLOv4模型的Precision和Loss表现

图 5.6 FM-YOLO+增强后数据集和原始 YOLOv4+原始数据集训练过程表现对比

图 5.6 为 FM-YOLO 和 YOLOv4 模型在增强后数据集和原始数据集上的 AP 曲线和 Loss 曲线,其中不包括模型的 Warm-up 过程。由图可见,FM-YOLO 和 YOLOv4 均在前 15 Epoch 中出现 AP 的快速上升和 Loss 的急剧下降,FM-YOLO 在训练过程的 AP 和 Loss 均优于 YOLOv4,达到高峰的速度基本保持一致,在 100 个 Epoch 后逐渐趋于稳定,并在 140 Epoch 左右实现收敛;从 AP 曲线的波动程度上看 FM-YOLO 在 80 Epoch 后逐渐趋于稳定,YOLOv4 模型波动程度始终较大,说明 FM-YOLO 模型在 80 Epoch 后模型寻找到良好的收敛和梯度下降方向,而

YOLOv4 在 150 Epoch 之前一直没有寻找到正确方向,波动幅度较大;从 Loss 曲线来看,YOLOv4 模型前 100 Epoch 和 AP 曲线变化一致,处于波动较大的状态,在 100 Epoch 左右后,波动幅度下降并趋于稳定,FM-YOLO 在 50 Epoch 之前的 Loss 曲线有较小的波动,随后趋于平稳,说明 FM-YOLO 引入的 ASFF 模块和 scSE 模块有助于加快模型收敛和寻找正确学习方向;在 150 Epoch 时,FM-YOLO 模型在 AP 高于原始 YOLOv4 有 21.2 个百分点,并且最终 Loss 也更低,说明了 FM-YOLO 和增强后数据集的组合能够显著增加模型检测精度,且检测时间更少,验证了本研究提出的两个方案组合的有效性和实用性。

5.3.2 多尺度下的检测结果比较研究

本节论述原始方案和本文方案在不同尺寸的陶瓷插芯表面缺陷检测上的效果对比。如图 5.7 所示为原始方案和本文方案在陶瓷插芯表面缺陷大尺寸上的检测效果对比图。由图可见,原始方案在面对 crack 的大尺寸缺陷存在缺陷数量上的误判,本文方案能够清晰的检测出完整的同一条大尺寸 crack(图 5.7 左),而原始方案将其误判为两条 crack 缺陷;在原始方案无法检测到颜色较浅的 crack 时(图 5.7 中、右),本文方案能够捕捉到大尺寸范围的缺陷特征,说明本文方案在大尺寸、难以识别的缺陷上检测性能的优越性。




图 5.7 原始方案和本文方案在大尺寸下的检测表现

如图 5.8 所示为原始方案和本文方案在陶瓷插芯表面缺陷中等尺寸上的检测效果对比图。从图 5.8 左、中可见，本文方案在捕捉中等尺寸的 **pit** 和 **bruise** 上的预测框更贴合真实框，定位损失更小；从图 5.8 右中可见，原始方案将崩缺缺陷误判为正常形态的 **head** 特征，本文方案能清晰分辨中等尺寸的有崩缺和无崩缺的图像，验证了中等尺度下本文方案改进的有效性。




图 5.8 原始方案和本文方案在中尺寸下的检测表现

图 5.9 为原始方案和本文方案在陶瓷插芯表面缺陷小、超小等尺寸上的检测效果对比图。本文方案较于有原始方案能更准确地检测出难以识别的小、超小尺寸的 **blot** 缺陷；同时在两种方案均识别出缺陷的情况下，本文方案对小目标的检测置信度更高，说明本文方案在小目标检测上的识别能力更高。




图 5.9 原始方案和本文方案在小、超小尺寸下的检测表现

5.3.3 多类别下的检测结果比较研究

本节论述原始方案和本文方案在陶瓷插芯表面不同缺陷在复杂情况下的检测效果对比。图 5.10 为采用本文方案与原始方案在部分图像的 head 和 crack 重叠缺陷上检测效果区别图。由图可见，得益于 DIoU-NMS 在重叠缺陷识别的优越性，本文方案成功将原始方案漏检的裂纹缺陷检出，提高了重叠缺陷的识别率，增大模型检测整体的查全率。




图 5.10 原始方案和本文方案在 head 和 crack 重叠缺陷上的表现差异

图 5.11 为采用本文方案与原始方案对不易检测缺陷目标的效果差异图。从图 5.11(a)可见，原始方案能够检出芯头和污点特征和缺陷，但由于原始方案对颜色对比度不明显的裂纹识别能力较弱，造成 crack 的漏检；本文方案引入 scSE 模块有助于缺陷特征在空间和通道上的注意力激励，图 5.11(b)中显示本文方案能够检测出难以识别的 crack 缺陷。




图 5.11 原始方案和本文方案在难以识别的 crack 检测效果差异图

图 5.12 为采用本文方案与原始方案对片状 bruise 缺陷的检测效果差异图。由图可见，原始方案和本文方案相比，虽都能检测出擦伤缺陷，但是对缺陷的边界

框标注存在较大的误差，本文方案的边界框和真实框更加贴合，且置信度也明显高于原始方案，证明本文方案在边界框预测方面的优势。




图 5.12 原始方案与本文方案对片状 bruise 缺陷的检测效果差异图

本文方案虽然远优于原始方案，但目前在陶瓷插芯表面缺陷检测任务中仍存在以下问题，如本文方案对超小目标的缺陷的识别能力仍不如中大尺寸的缺陷，有较大的提升空间，然而小、超小目标的总体检测 mAP 达 0.945，已经满足工业现场的要求；同时本文方案并且对部分交错的 crack 缺陷存在误判现象，如图 5.13 所示，采用本文方案检测的结果中将部分连接一起的裂纹重复识别，导致 crack 的识别结果错乱，这也是未来研究需要解决探讨的改进点。




图 5.13 本文方案存在不足的检测结果

5.4 本章小结

本章通过设计陶瓷插芯表面缺陷检测软件并开发了对应的 4 大模块：缺陷检测模块、数据矫正模块、数据统计模块、数据存储模块；后续通过检测软件进行

本文主要提出的两个方案：结合对抗网络的基于离散掩膜差分的缺陷图像重生方法、基于 YOLOv4 改进的 FM-YOLO 模型的组合方案进行实验验证，并和原始方案的总体检测效果进行对比，最后分析在本文方案和原始方案不同尺度和不同类别下的检测效果对比。

第6章 总结与展望

6.1 工作总结

陶瓷插芯表面缺陷检测任务中,本文提出了离散掩膜差分对抗的缺陷图像重生方法和 FM-YOLO 模型,实现了数据集内的数据平衡和扩充以及模型在精度、速度、大小上的大幅优化,达到陶瓷插芯表面缺陷任务的工业现场要求。本文主要工作包括以下四个方面:

第一,针对陶瓷插芯的缺陷特点,本研究设计了陶瓷插芯表面缺陷检测流程总体方案,并建立了实验平台。同时,提出了一种陶瓷插芯表面缺陷原始数据集。

第二,针对陶瓷插芯表面缺陷数据集样本不均衡的问题,难以采用传统方法直接对抗生成的问题,本研究提出了基于离散掩膜差分的缺陷图像重生方法。该方法通过对少数类的缺陷特征进行高阶差分算法提取,然后采用设计的对抗生成网络 DCGAN 进行新的离散特征生成,最后将新的离散特征和掩膜图像进行融合、位姿重构、混合增强,形成增强后的数据集。经过处理后数据集的分布规模由原来的 1:1:11:15:15 均衡为 1:1:1.1:1.3:1.3 比例,数据集由极不平衡状态达到正常水平。

第三,针对 YOLOv4 在陶瓷插芯表面缺陷检测中存在的模型过大和小目标难以检测等问题,进行了一系列改进:轻量化网络结构、引入 scSE 和 ASFF 模块、新增预测头、引入 DIoU-NMS 算法,并提出了新的模型:FM-YOLO。实验结果表明,相对于 YOLOv4,FM-YOLO 在 mAP 上提升了 19.5 个百分点,在检测速度上加快了 51.7%,实现了精度和速度的双向优势。

第四,研究设计开发了陶瓷插芯表面缺陷检测软件,并进行了离散掩膜差分对抗的缺陷图像重生方法和 FM-YOLO 的组合实验验证。实验结果表明,相对于初始组合,本研究的方案组合在 mAP 上提升了 28.3 个百分点,并在检测效果上表现出明显的优势。

6.2 工作展望

本文提出的离散掩膜差分对抗的缺陷图像重生方法和FM-YOLO检测模型在陶瓷插芯表面缺陷检测任务展现出了较高的鲁棒性和泛化能力，并拥有高精度和高速度的优点，但限于作者自身水平与研究时间，目前仍存在一些问题需要在未来进行解决和展望：

首先，虽然陶瓷插芯缺陷整体检测水平 mAP 达较高水平的 0.978，但在小目标居多的污点缺陷仍存在部分漏检现象，多条方向各异的裂纹缺陷难以判断具体缺陷数量，后续研究可以考虑用二次检测的方式对检测置信度不高的缺陷进行判断巩固，以提高缺陷种类的识别率。

然后，目前的研究已能够很好地将陶瓷插芯表面缺陷进行已知缺陷的分类，然而在工业现场上有可能出现一些未知缺陷，此时本研究的模型由于基于先验的学习过程而无法识别出未知的缺陷异常，可能会误判为已知缺陷的类别，后续研究可以对已有的缺陷数据进行无监督学习，通过生成网络模拟并生成缺陷的数据分布，增强模型识别异常缺陷的鲁棒性。

最后，本研究采用目标检测分类的方式将不同陶瓷插芯缺陷进行边界矩形框区分识别，对缺陷实际形状、长度、宽度、面积无法进行提取，后续研究可以引入图像分割算法，将缺陷和背景分离开来，实现缺陷具体尺寸的量化，更容易实现产品分级划分。

参考文献

- [1] 邓增君. 氧化锆陶瓷插针加工工艺及材料去除机理研究[D]. 湖南:中南大学, 2005.
- [2] 张立伟. 光纤连接器陶瓷插针用纳米二氧化锆的研究[D]. 广东:华南理工大学, 2006.
- [3] 胡少华. 高速光纤通信系统不同信号损伤下的性能增强技术研究[D]. 四川:电子科技大学, 2022.
- [4] 张勤丰. 项目管理在陶瓷插芯制造项目中的应用[D]. 上海:上海交通大学, 2010.
- [5] 张舜德. 光纤连接器陶瓷插芯超精密加工与检测技术研究[D]. 上海:上海交通大学, 2005.
- [6] 魏洪修. 基于机器视觉的陶瓷基板图像缺陷检测研究[D]. 山东:山东大学, 2016.
- [7] Canny J. A Computational Approach to Edge Detection[J]. IEEE transactions on pattern analysis and machine intelligence, 1986, PAMI-8(6): 679-698.
- [8] Gabor D. Theory of communication. Part 1: The analysis of information[J]. Journal of the Institution of Electrical Engineers - Part III: Radio and Communication Engineering, 1946, 93(26): 429-441.
- [9] Dalal N, B T. Histograms of oriented gradients for human detection[C]//IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2005: 1-8.
- [10] Lowe D. Object recognition from local scale-invariant features[C]// Proceedings of the Seventh IEEE International Conference on Computer Vision. IEEE, 1999: 1-8.
- [11] Li X K, Gao C, Guo Y C, et al. Image Mosaic Using SIFT for Bridge Cable Surface Flaw Detection[J]. Applied Mechanics and Materials, 2013: 333-335.
- [12] Lu J, Lin M, Huang Y, et al. A High-Accuracy Algorithm for Surface Defect Detection of Steel Based on DAG-SVM[J]. Sensors & Transducers, 2013: 412.

- [13] Keller J M, Gray M R, Givens J A. A fuzzy K-nearest neighbor algorithm[J]. IEEE Transactions on Systems Man & Cybernetics, 2012: 580-585.
- [14] H. Zhang, L. Peng, S. Yu, W. Qu. Detection of surface defects in ceramic tiles with complex texture[J], IEEE Access, 2021: 1-9.
- [15] X. Chen, Y. Zhang, L. Lin, J, et al. Ni. Efficient anti-glare ceramic decals defect detection by incorporating homomorphic filtering[J], Comput. Syst. Sci. Eng, 2021: 551-564.
- [16] M. Younas, Q. Nawaz, I. Hamid, S. M. Mustuzhar Gilani, et al. A novel approach of ceramic tile crack detection using morphological operations[J]. Mehran University Research Journal of Engineering and Technology, 2022: 146 – 154.
- [17] A. N. Shire, M. M. Khanapurkar, R. S. Mundewadikar. Plain Ceramic Tiles Surface Defect Detection Using Image Processing[C]. 2011 Fourth International Conference on Emerging Trends in Engineering & Technology, 2011: 215-220
- [18] Li J, Jiang N, Liao J, Feng Y, Liu Q, Li H. Nonstoichiometric $\text{Cu}_{0.6}\text{Ni}_{0.4}\text{Co}_2\text{O}_4$ Nanowires as an Anode Material for High Performance Lithium Storage[J]. Nanomaterials, 2020, 10(2): 191
- [19] Sioma A. Automated Control of Surface Defects on Ceramic Tiles Using 3D Image Analysis[J/OL]. Materials, 2020, 13(5): 1250. doi:10.3390/ma13051250.
- [20] Huang W, et al. The detection of defects in ceramic cell phone backplane with embedded system[J]. Measurement : Journal of the International Measurement Confederation, 2021: 181.
- [21] Lu Q et al. A supervised approach for automated surface defect detection in ceramic tile quality control[J]. Advanced Engineering Informatics, 2022: 53-63.
- [22] Ren X, Lin W, Yang X, Yu X, Gao H. Data Augmentation in Defect Detection of Sanitary Ceramics in Small and Non-i.i.d Datasets[J/OL]. IEEE Transactions on Neural Networks and Learning Systems, 2021, doi: 10.1109/ TNNLS. 2022. 3152245
- [23] Nogay, H S, Akinci, T C, Yilmaz M. Detection of invisible cracks in ceramic materials using by pre-trained deep convolutional neural network[J]. Neural Comput & Applic, 2022: 1423-1432

- [24] Wan G et al.Ceramic tile surface defect detection based on deep learning[J].
Ceramics International, 2022,48(8): 11085-11093.
- [25] Kim H S,Han Y,Kim J.3D Measurement Using a Single Image for Smart
Manufacturing of Microscopic Products in a Ceramic Powder Pressing
Process[J].Int.J. of Precis. Eng. and Manuf.-Green Tech, 2022: 233-243
- [26] Huang Y-P, Su C-M, Basanta H, Tsai Y-L. Imbalance Modelling for Defect
Detection in Ceramic Substrate by Using Convolutional Neural Network[J].
Processes. 2021, 9(9): 1678
- [27] Zhao W,Chen F,Huang H,Li D,Cheng W.A New Steel Defect Detection Algorithm
Based on Deep Learning[J/OL].Comput Intell Neurosci, 2021: 01-13. doi:
10.1155/ 2021/5592878.
- [28] Y Yang, Q Sun, D Zhang, L Shao, X Song,X Li.Improved Method Based on
Faster R-CNN Network Optimization for Small Target Surface Defects Detection
of Aluminum Profile[C].2021 IEEE 15th International Conference on Electronic
Measurement & Instruments (ICEMI), 2021: 465-470.
- [29] B. Li et al.Fabric Defect Segmentation System Based on a Lightweight GAN for
Industrial Internet of Things[J], Wireless Communications and Mobile
Computing, 2022: 1-17.
- [30] Feng X,Gao X,Luo L.High-resolution image-based surface defect detection
method for hot-rolled strip steel[J].Journal of Electronic Imaging, 2022,31(3):
20-32.
- [31] Wang H.Surface defect detection of vehicle light guide plates based on an
improved RetinaNet[J].Measurement Science & Technology, 2022,33(4): 01-12.
- [32] Xue W,Zhao C,Fu W,Du J,Yao Y.Micro Vision-based Sharpening Quality
Detection of Diamond Tools[C]//Intelligent Robotics and Applications.ICIRA,
2022: 13-29.
- [33] Zhou W et al.Road defect detection from on-board cameras with scarce and
cross-domain data[J].Automation in Construction, 2022: 14-26.
- [34] Liu Z et al.Key target and defect detection of high-voltage power transmission
lines with deep learning[J].International Journal of Electrical Power & Energy

- Systems, 2022: 142-154.
- [35] Yang Z et al.Surface defect detection method for air rudder based on positive samples[J].Journal of Intelligent Manufacturing, 2022: 53-68
- [36] Zhang H et al.A novel MAS-GAN-based data synthesis method for object surface defect detection[J].Neurocomputing (Amsterdam), 2022: 106-114.
- [37] She L et al. Insulator Breakage Detection Utilizing a Convolutional Neural Network Ensemble Implemented With Small Sample Data Augmentation and Transfer Learning[J].IEEE Transactions on Power Delivery, 2021 :2787-2796.
- [38] Yu N et al. Wafer map defect patterns classification based on a lightweight network and data augmentation[J].CAAI Transactions on Intelligence Technology, 2022: 12-35.
- [39] Haruna Y, Qin S, Mbyamm Kiki M J. An Improved Approach to Detection of Rice Leaf Disease with GAN-Based Data Augmentation Pipeline[J].Applied Sciences, 2023,13(3): 13-46.
- [40] Kate P, Ravi V, Gangwar A. FinGAN: Chaotic generative adversarial network for analytical customer relationship management in banking and insurance[J].Neural Comput & Applic, 2023:6015-6028
- [41] Du Y et al. Deep Learning-Based Cyber – Physical Feature Fusion for Anomaly Detection in Industrial Control Systems[J].Mathematics (Basel), 2022,10(22): 102-121.
- [42] J Baea, W Jung, Y Park. Normal data based rotating machine anomaly detection using CNN with self-labeling[J], Smart Structures and Systems, 2022: 757-766.
- [43] Liu X, Li T, Zhang R, Wu D, Liu Y, Yang Z. A GAN and Feature Selection-Based Oversampling Technique for Intrusion Detection[J].Security and Communication Networks, 2021: 994-1005.
- [44] Zhao Y et al. Plant Disease Detection Using Generated Leaves Based on DoubleGAN[J].IEEE/ACM Transactions on Computational Biology and Bioinformatics, 2021,19(3): 1817-1826.
- [45] Hou B, Zhang K, Zuo X, Zhao J, Xi B. IIoT Malicious Traffic Detection Method Based on GAN Sample Enhancement[J].Security and Communication Networks,

- 2022: 92-110.
- [46] Shin H,Ahn Y,Tae S,Gil H,Song M,Lee S.Enhancement of Multi-Class Structural Defect Recognition Using Generative Adversarial Network[J].Sustainability, 2021,13(22): 126-138.
- [47] W H,Yun T,Kim J,Lee J.Cut-and-Paste Dataset Generation for Balancing Domain Gaps in Object Instance Detection[J],IEEE Access, 2021: 14319-14329
- [48] 章美敏. 陶瓷光纤插芯注射成型模具设计及其CAE仿真[D]. 天津:天津大学,2005.
- [49] Lin T, Maire M, Belongie S, et al. Microsoft COCO: Common Objects in Context[C]//European Conference on Computer Vision. LNCS, 2014: 740-755.
- [50] Everingham M, Van Gool L, Williams C K I, et al. The PASCAL Visual Object Classes (VOC) Challenge[J].International Journal of Computer Vision, 2010,88: 303-338.
- [51] Deng J, Dong W, Socher R, et al. ImageNet: A large-scale hierarchical image database[C]//IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2009: 248-255.
- [52] Girshick R, Donahue J, Darrell T, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2014: 580-587.
- [53] Uijlings J R R, van de Sande K E A, Gevers T, et al. Selective Search for Object Recognition[J]. International Journal of Computer Vision, 2013, 104: 154-171.
- [54] Girshick R. Fast R-CNN[C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). IEEE, 2015: 1440-1448.
- [55] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks.[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2016:1-1.
- [56] Dai J, Li Y, He K. R-FCN: Object Detection via Region-based Fully Convolutional Networks[C]//Conference and Workshop on Neural Information Processing Systems. IEEE, 2016: 1-11.

- [57] Redmon J, Divvala S, Girshick R. You Only Look Once: Unified, Real-Time Object Detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2016: 779-788.
- [58] Redmon J, Farhadi A. YOLO9000: Better, Faster, Stronger[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2017: 7263-7271.
- [59] Redmon J, Farhadi A. YOLOv3: An Incremental Improvement[J]. arXiv preprint arXiv:1804.02767, 2018: 1-6.
- [60] Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: optimal speed and accuracy of object detection[J]. arXiv preprint arxiv:2004.10934, 2020.
- [61] He K, Zhang X, Ren S, et al. Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(9): 1904-1916.
- [62] Liu W, Anguelov D, Erhan D, et al. Single Shot MultiBox Detector[C]//European conference on computer vision. LNCS, 2016: 21-37.
- [63] Ren S, He K, Girshick R, Sun J. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[C]//IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2015: 1-14.
- [64] 王阳. 高密度椒盐噪声污染图像修复方法研究[D]. 辽宁:大连理工大学, 2016.
- [65] Otsu N. A Threshold Selection Method from Gray-Level Histograms[J]. IEEE transactions on systems, man, and cybernetics, 1979, 9(1): 62-66.
- [66] 刘瑶. 最小有向外接矩形算法的CUDA并行实现[D]. 辽宁:大连理工大学, 2014.
- [67] 陈武. 基于CCD图像的等待车辆数传感器的研究-等待车辆图像的腐蚀-膨胀识别算法[D]. 上海:上海交通大学, 2004.
- [68] Klapper J, Harris C. On the response and approximation of Gaussian filters[J]. IRE Transactions on Audio, 1959, AU-7(3).
- [69] 张晨旭. 基于机器视觉的智能制造产品识别与检测方法研究[D]. 黑龙江:哈尔滨工业大学, 2018.
- [70] Zhang H, Goodfellow I, Metaxas D, et al. Self-attention generative adversarial

- networks[C]//International conference on machine learning. PMLR, 2019: 7354-7363.
- [71] Radford A, Metz L, Chintala S. Unsupervised representation learning with deep convolutional generative adversarial networks[J]. arXiv preprint arXiv: 1511.06434, 2015.
- [72] Zhang H, Goodfellow I, Metaxas D, et al. Self-attention generative adversarial networks[C]//International conference on machine learning. PMLR, 2019: 7354-7363.
- [73] Y Zhou, Q Zhang, V P Singh. An adaptive multilevel correlation analysis: A new algorithm and case study[J], Hydrol. Sci. J, 2016: 2718 – 2728.
- [74] He K, Zhang X, Ren S, et al. Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(9): 1904-1916.
- [75] Lin T, Dollar P, Girshick R, et al. Feature Pyramid Networks for Object Detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2017: 2117-2125.
- [76] Howard A G, Zhu M, Chen B, Kalenichenko D, Wang W, Weyand T, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv preprint arXiv:1704.04861, 2017.
- [77] Sandler M, Howard A, Zhu M, Zhmoginov A, Chen L. Mobilenet v2: Inverted residuals and linear bottlenecks[C]. 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2018: 4510 – 4520.
- [78] Liang X, Zhang J, Zhuo L, Li Y. Small Object Detection in Unmanned Aerial Vehicle Images Using Feature Fusion and Scaling-Based Single Shot Detector With Spatial Context Analysis[J], IEEE Transactions on Circuits and Systems for Video Technology, IEEE, 2020: 1758-1770
- [79] Roy A G, Navab N, Wachinger C. Concurrent spatial and channel Squeeze & excitation in fully convolutional networks[J], Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics): Springer International Publishing, 2018: 421-429.

-
- [80] Lowe D G. Distinctive Image Features from Scale-Invariant Keypoints[J].
International Journal of Computer Vision, 2004, 60: 91-110.
- [81] Chen D,Miao D.Control distance IoU and control distance IoU loss function for
better bounding box regression[J], Cornell University Library,Pattern recognition,
2023: 137-150.