

引用格式:董朋林,陈久朋,王森,等.复杂背景下基于 YOLO-insulator 模型的绝缘子小目标缺陷检测研究[J].电力科学与技术学报,2026,41(1):262-276.

Citation: DONG Penglin, CHEN Jiupeng, WANG Sen, et al. Small object defect detection of insulators based on YOLO-insulator model in complex background[J]. Journal of Electric Power Science and Technology, 2026, 41(1): 262-276.

复杂背景下基于 YOLO-insulator 模型的绝缘子小目标缺陷检测研究

董朋林¹, 陈久朋^{1,2}, 王 森^{1,2}, 伞红军^{1,2}, 胡宏伟³

(1. 昆明理工大学机电工程学院, 云南 昆明 650504; 2. 云南省先进装备智能制造技术重点实验室, 云南 昆明 650500;

3. 长沙理工大学机械与运载工程学院, 湖南 长沙 410114)

摘 要: 基于计算机视觉的航拍绝缘子缺陷检测方法被广泛应用于电力巡检。针对绝缘子缺陷易受背景复杂、目标尺度较小等因素的影响而导致漏检、误检的问题, 提出了一种旨在提高绝缘子缺陷检测精度的绝缘子缺陷检测模型 YOLO-insulator。首先, 引入基于通道混洗的重参数化卷积(reparameterized convolution based on channel shuffle-one-shot aggregation, RCS-OSA)替换传统的二维卷积 C2f, 以增强网络的特征提取能力; 其次, 在颈部网络使用 RCS-OSA 模块替换部分的 C2f 卷积, 同时引入挤压激励网络(squeeze and excitation network, SENet), 以增强模型对通道间关系的捕捉和整体特征的表达能力; 最后, 针对多种缺陷区域小导致难以检测的问题, 提出小目标检测层方法, 该层包含更多的缺陷细节信息, 有利于缺陷的检测。在自制绝缘子数据集上进行实验验证的结果表明, 相对于基线 YOLOv8n, YOLO-insulator 模型在查准率、召回率、平均精度均值上都实现了提升, 有效提高了模型的综合性能。

关 键 词: 绝缘子缺陷检测; 复杂背景; 注意力机制; 挤压激励; 小目标检测层

DOI: 10.19781/j.issn.1673-9140.2026.01.025

中图分类号: TP242

文章编号: 1673-9140(2026)01-0262-15

Small object defect detection of insulators based on YOLO-insulator model in complex background

DONG Penglin¹, CHEN Jiupeng^{1,2}, WANG Sen^{1,2}, SAN Hongjun^{1,2}, HU Hongwei³

(1. Faculty of Mechanical and Electrical Engineering, Kunming University of Science and Technology, Kunming 650504, China;

2. Key Laboratory of Advanced Equipment Intelligent Manufacturing Technology of Yunnan Province, Kunming 650500, China;

3. College of Mechanical and Vehicle Engineering, Changsha University of Science & Technology, Changsha 410114, China)

Abstract: Computer vision-based methods for insulator defect detection from aerial images are widely used in power inspection. To address missed and false detections caused by complex backgrounds and small target scales, a YOLO-insulator defect detection model is proposed to improve detection accuracy. First, the reparameterized convolution based on channel shuffle-one-shot aggregation (RCS-OSA) is introduced to replace the traditional two-dimensional convolution C2f, thus enhancing the network's feature extraction capability. In the neck network, the RCS-OSA module is used to replace some of the C2f convolutions, and the squeeze-and-excitation network (SENet) is introduced to enhance the model's ability to capture inter-channel relationships and express overall features. Finally, to address the difficulty in detecting multiple defect regions due to their small size, a small object detection layer method is proposed. This layer contains more detailed defect information and is more conducive to defect detection. Experimental results on a self-made insulator dataset demonstrate that, compared with the baseline YOLOv8n, the YOLO-insulator model

收稿日期: 2024-11-14; 修回日期: 2025-02-27

基金项目: 云南省基础研究计划项目(202301AU070059); 昆明理工大学人才培养项目(KKZ3202301041)

通信作者: 伞红军(1976—), 男, 副教授, 主要从事机器人技术及理论、空间机构学等研究; E-mail: sanhjun@163.com

achieves higher precision, recall, and mean average precision, improving overall model performance.

Key words: insulator defect detection; complex background; attention mechanism; squeeze-and-excitation; small object detection layer

绝缘子在输电线路中起着机械支撑和电气绝缘的作用,对输电线路乃至整个电力系统的安全运行具有重要意义^[1]。由于长期暴露在大气中,绝缘子在受到鸟啄、风蚀、覆冰施压、高温等多种恶劣因素的影响后,可能出现缺损、闪络、自爆等缺陷,绝缘强度的降低给输电线路的稳定运行带来了严重的安全隐患^[2-3]。为确保电网安全稳定运行,对绝缘子进行缺陷检测是电力巡检的关键环节。传统的绝缘子检测方法包括人工巡检、传统图像检测等^[4]。绝大部分高压输电线路分布在跨越江河和山区的地段,人工巡检的危险系数较高^[5]且效率低下,不能及时准确地反映线路设备的运行情况。传统的图像检测方法包括直方图均衡化、支持向量机、Canny边缘检测、Hough变换等算法。这些算法首先对绝缘子图像进行预处理,其次初步提取绝缘子区域,最后再对缺陷区域进行检测^[6]。由于拍摄条件的限制以及绝缘子分布的环境复杂,传统的检测算法对绝缘子的检测准确率较低^[7]。

深度学习技术的发展,推动了人工智能在各行业的广泛应用^[8]。基于深度学习的目标检测算法由于具有良好的泛化能力以及在复杂背景中强大的特征提取能力,已经开始被广泛应用于电力系统的巡检^[9]。目标检测算法按照识别阶段划分,有以快速区域卷积神经网络(faster region-based convolutional neural network, Faster R-CNN)^[10]为代表的两阶段目标检测算法,以及YOLO系列算法、ReinaNet^[11]等单阶段目标检测算法。如文献[12]提出了一种基于反馈机制的卷积神经网络(convolutional neural network, CNN)绝缘子状态检测方法,能够较准确地对绝缘子的正常状态和缺陷状态进行分类,但是无法对缺陷进行定位。文献[13]利用随机森林分类方法实现图像分割,依靠CNN对绝缘子的正常、缺陷状态进行分类,最后利用Faster R-CNN实现自爆缺陷的位置识别。但两阶段的目标检测算法引入了更高的模型复杂性和更大的参数量,导致检测速度严重下降。文献[14]融合MobileNetv3的特征提取网络和YOLOv3特征融合网络后进行通道剪枝,可以有效缩小模型体积,但会对识别精度产生一定的负面影响。文献[15]在

YOLOv5的骨干网络中引入轻量级的Ghost模块和卷积块注意力模块(convolutional block attention module, CBAM),可以在保证绝缘子检测精度的前提下提高检测速度,但缺陷样本过于单一导致模型的泛化性不强。文献[16]使用k-means++算法对绝缘子目标框进行聚类,以生成更适合缺陷检测的锚框,并在YOLOv7中添加CoordAttention模块和HorBlock模块,引入损失函数并改进非极大值抑制方法,以有效提升复杂背景下小目标的检测精度。但其仅对缺损和闪络两类缺陷进行识别,忽略了常见且危害性很大的自爆缺陷,降低了模型的通用性。文献[17]所提模型在原YOLOv8模型中加入可变形ConvNets v2模块和全局注意力机制,并且用加权交并比(weighted intersection over union version 3, WIoUv3)替换完全交并比(complete intersection over union, CIoU),优化了损失函数,但数据尺度单一,且图像背景较为简单,导致模型对分布位置复杂、尺度多样的绝缘子的缺陷检测能力降低。

为了更好地解决绝缘子缺陷目标种类多、尺度大小不一、背景复杂导致的检测精度不高的问题,本文提出一种改进的YOLOv8n深度学习网络模型YOLO-insulator,并建立了一个包含3种常见绝缘子缺陷的数据集,以便更好地满足移动设备准确检测绝缘子缺陷的需求。本文的创新点列举如下。

1) 针对图像中缺陷被复杂背景干扰而导致特征提取不足的问题,在主干网络和颈部网络中引入基于通道混洗的重参数化卷积(reparameterized convolution based on channel shuffle-one-shot aggregation, RCS-OSA),强化了模型缺陷特征提取能力,帮助模型精准定位缺陷目标。

2) 在颈部网络中引入挤压激励网络(squeeze and excitation network, SENet),增强模型对通道间关系的捕捉和整体的特征表达能力。

3) 针对缺陷目标种类多、目标尺度小而导致误检、漏检的问题,引入 160×160 小目标检测层,增强了模型对微小目标缺陷的检测能力。

1 算法描述

1.1 基线 YOLOv8n 模型

YOLOv8n 模型主要由骨干特征提取网络、颈部特征融合网络以及检测头这 3 个部分组成。在骨干特征提取网络中, YOLOv8n 参考 YOLOv7 中的高效层聚合网络 (efficient layer aggregation network, ELAN) 设计出 C2f 模块, 通过融合跨级局部网络 (cross stage partial network, CSPNet)^[18] 和替换 YOLOv5 的 C3 模块, 使其在保持轻量化的同时获得更加丰富的梯度流信息, 而根据模型尺度调整通道数的方式也强化了模型特征提取的能力。YOLOv8n 改进模块结构如图 1 所示, 图 1(a) 展示了 C3 模块和 C2f 模块的结构。C3 模块通过两个分支进行特征提取: 主分支通过多个堆叠的 Bottleneck 层提取深层特征, 另一分支经过卷积层-批归一化层-SiLU 激活函数 (convolutional-batch normalization-SiLU, CBS) 的处理, 两路特征最终通过 Concat 操作进行拼接。而 C2f 模块则在此基础上进行了改进, 引入了 Split 节点。特征经过首个 CBS 后, 由 Split 操作进行切分, 一部分特征直接连接至后续处理, 另一部分输入 Bottleneck 堆叠层中。最终, 经过 Split 和 Bottleneck 处理的所有特征流汇聚于 Concat 节点, 并经过末端的 CBS 输出。

在检测头部分, YOLOv8n 使用目前主流的解耦头将分类和定位分支分开, 并行地提取类别特征和位置特征, 不再采用参数共享的方式以减少两种任务之间的冲突。在标签分配和损失函数方面, YOLOv8n 采用的无锚框思想避免了与锚框相关的复杂计算和超参数设置, 显著提升了模型的处理速

度。而动态标签匹配策略则增加了正样本框选择的灵活性。此外, 本文使用分布焦点损失 (distribution focal loss, DFL) 函数+CIoU 损失函数作为回归损失, 将二元交叉熵 (binary cross-entropy, BCE) 损失函数作为分类损失, 以此优化模型训练。

DFL 函数主要用于处理目标检测中预测框位置的分布情况, 其基于焦点损失函数的思想可以更好地聚焦于难以检测的样本学习。DFL 函数的计算如下:

$$L_{\text{DFL}} = - \sum_{i=1}^N q_i \log(p_i) \times S_i \quad (1)$$

$$S_i = -(1 - p_i)^\gamma \log(p_i)^\alpha \quad (2)$$

式中, L_{DFL} 为焦点损失函数; N 为划分的区间总数; p_i 为预测第 i 个区间的分布; q_i 为真实的分布; S_i 为调节因子, 使模型能够更加聚焦于难以检测的样本; α, γ 为可调节的超参数, 用于控制聚焦的程度。

CIoU 损失函数的设计融合了多个几何要素, 主要包括预测框与真实框的交并比 (intersection over union, IoU)、中心点距离和长宽比一致性。CIoU 损失函数的计算如下:

$$L_{\text{CIoU}} = 1 - I_{\text{IoU}} + \frac{\rho^2(x, x^{\text{gt}})}{c^2} + \alpha v \quad (3)$$

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w^{\text{gt}}}{h^{\text{gt}}} - \arctan \frac{w}{h} \right)^2 \quad (4)$$

$$\alpha = \frac{v}{(1 - I_{\text{IoU}}) + v} \quad (5)$$

式中, L_{CIoU} 为 CIoU 损失函数; x, x^{gt} 分别为预测框与真实框的中心点坐标; $\rho^2(x, x^{\text{gt}})$ 为这两个中心点的欧氏距离; c 为能够同时包围预测框与真实框的最小外接矩形的对角线长度; αv 表示长宽比惩罚项, α




图 1 YOLOv8n 改进模块结构

Figure 1 YOLOv8n improvement module

为权重系数, v 为预测两个矩形框相对比例的系数; w^{gt} 、 h^{gt} 分别为真实框的宽度和高度; w 、 h 分别为预测框的宽度和高度; I_{IoU} 为两框的 IoU。

BCE 损失函数可用于衡量预测概率与真实标签之间的差异。设预测概率为 $\hat{y}$ (取值范围为 0~1), 真实标签为 y (取值范围为 0~1), 则 BCE 损失函数为

$$L_{BCE} = -(y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})) \quad (6)$$

1.2 YOLO-insulator 算法

针对绝缘子缺陷易受背景复杂、种类繁多、目标尺度小等因素的影响而出现漏检、误检的问题, 本文以 YOLOv8n 为基线模型, 提出一种旨在提升绝缘子缺陷检测精度的 YOLO-insulator 模型。首先, 通过在骨干特征提取网络中引入空间对象注意力模块 RCS-OSA, 替换传统的二维卷积 C2f 模块, 从而有效地抑制绝缘子图像复杂背景的干扰, 增强网络的特征提取能力。其次, 在颈部特征融合网络中, 使用 RCS-OSA 模块替换部分的 C2f 模块, 并引入了 SENet 增强模型对通道间关系的捕捉和整体特征的表达能力。最后, 针对绝缘子闪络、缺损等部分缺陷区域小导致难以检测的问题, 构建小目标检测层以获得更多缺陷细节信息。

1.2.1 RCS-OSA 网络结构

由于绝缘子分布在山川、河流、都市等各种复杂的环境中, 且受采集目标图像时设备所处位置的限制, 绝缘子及其缺陷在图像中所占据的像素信息一般较少^[19]。为了使网络能够更多地关注缺陷区域, 实现更精准的定位, 本文通过引入空间对象注意力模块 RCS-OSA^[20]使模型能够获取不同特征的重要程度, 及时更新特征图的权重占比, 将计算资源投入到更重要的绝缘子缺陷部分。

训练阶段 RCS 模块如图 2 所示, 推理阶段的 RCS 模块如图 3 所示。在训练阶段, 输入特征图通过 Split 进行通道分离后, 一部分特征通过 RepVGG 处理(包括未做处理、 1×1 卷积处理和 3×3 卷积处理, 并使用 SiLU 作为唯一的激活函数)。随后, 对

经 RepVGG 块处理后的输入和未做改变的输入进行拼接和通道混洗。与训练阶段不同的是, 推理阶段的输入经过通道分离后, 一部分会经过更简单的 RepConv 处理(包括未做处理和 3×3 卷积处理, 并使用 SiLU 作为唯一的激活函数)。RCS 模块的设计理念在于: 训练时使用多分支卷积, 推理时通过重新参数化将分支合并至主分支, 这样既可以在训练阶段获取丰富的特征表示, 又可以在推理阶段减少计算成本和内存消耗。

一次性聚合(one-shot aggregation, OSA)模块能够提取多尺度特征, 并在最后进行 OSA, 从而克服了 DenseNet 密集连接的低效问题, 能够有效提高网络在处理密集连接时的效率。RCS-OSA 模块如图 4 所示, OSA 模块与 RCS 模块相结合形成的 RCS-OSA 模块将输入数据分流, 一部分直接输出, 另一部分则经过堆叠的 RCS 模块进行特征提取。处理后的特征和直接通过的特征经通道混洗后融合, 这样可以在提高空间对象注意力的同时有效降低通道维度^[21]。




图 2 训练阶段的 RCS 模块

Figure 2 RCS module during training phase




图 3 推理阶段的 RCS 模块

Figure 3 RCS module in inference stage




图 4 RCS-OSA 模块

Figure 4 RCS-OSA module

1.2.2 挤压激励模块

由于绝缘子缺损、闪络等缺陷区域尺度大小不一,且形状不规则,模型在学习过程中可能会学习到非缺陷区域。为了使模型更多地关注识别缺陷区域而降低对非缺陷区域的关注能力,本文引入了 SENet。SE 模块网络结构如图 5 所示。SE 模块^[22]

是 SENet 中的核心部分,该模块通过学习的方式自动获取每个特征通道的重要程度,并根据其重要程度对特征的权重进行调节,在提升有用特征的同时抑制非关键特征。

SE 模块主要包括挤压操作、激励操作、特征重标定这 3 个步骤。




图 5 SE 模块网络结构

Figure 5 Network structure of squeeze-and-excitation module

本文设定待输入特征图 U 的高度、宽度、通道数分别为 H 、 W 和 C 。 U 中第 c 个通道的特征图为 u_c , 向量 Z 的第 c 个通道的特征向量为 z_c :

$$z_c = F_{sq}(u_c) = \frac{1}{H \times W} \sum_{m=1}^W \sum_{n=1}^H u_c(m, n) \quad (7)$$

式中, $F_{sq}(\cdot)$ 为挤压操作。

挤压操作采用全局平均池化(global average pooling, GAP)将特征图 U (尺寸为 $H \times W \times C$) 压缩为向量 Z (尺寸为 $1 \times 1 \times C$)。这一过程使得 Z 能够捕获特征图的全局信息,其维度与 U 的通道数相同。激励操作是将拥有全局信息的向量 Z 经过两次全连接层操作,自适应学习其权重 W_1 和 W_2 , 并进行运算形成新的 $1 \times 1 \times C$ 向量 S :

$$S = F_{ex}(Z, W) = \sigma(g(Z, W)) = \sigma(W_2 \delta(W_1 Z)) \quad (8)$$

式中, $F_{ex}(\cdot)$ 为空间激励操作; $\delta(\cdot)$ 为第一次全连接层后的激活函数 ReLU; $\sigma(\cdot)$ 为第二次全连接层后的激活函数 Sigmoid; W 为用于特征变换的可学习参数; $W_1 \in \mathbb{R}^{\frac{C}{r} \times C}$ 为降维层参数; $W_2 \in \mathbb{R}^{\frac{C}{r} \times C}$ 为升维层参数; r 为维度缩减率。经过激励操作, S 掌握了各通道重要程度的权重:

$$\tilde{x}_c = F_{scale}(u_c, s_c) = s_c u_c \quad (9)$$

式中, $F_{scale}(\cdot)$ 为特征重标定操作,其过程是将 $1 \times 1 \times C$ 向量 S 的第 c 个权重因子 s_c 与未加权的 U 逐通道相乘,得到加权的特征图 $\tilde{X}$ 。 $\tilde{x}_c$ 为 $\tilde{X}$ 中第 c 个通

道的特征图,且每个通道均被赋予不同的权重,因此模块达到了提升重要特征并抑制非关键特征的效果。

1.2.3 添加小目标检测层

YOLOv8n 网络检测层架构由 3 个检测层 P_3 、 P_4 和 P_5 组成,经此输出的小、中、大目标的特征图尺寸分别为 80×80 、 40×40 、 20×20 。 80×80 的特征图中的每个像素都概括了原始图像中一个 8×8 像素区域的信息。由于航拍绝缘子图像中一部分自爆、缺损、闪络等小目标缺陷的尺寸比 8×8 像素更小,会导致模型在检测小目标缺陷时存在误检、漏检等问题,本文将检测层特征图尺寸增加至 160×160 , 以较大的视野检测 4×4 像素以上的小目标中的滤波尺寸,在一定程度上解决了自爆、缺损、闪络等小目标缺陷信息特征捕获不足的问题。改进前、后检测层架构对比如图 6 所示。




图 6 改进前、后检测层架构对比

Figure 6 Detection layer architectures before and after improvement

特征融合模块采用了双向路径:一条是自上而下的深层语义信息流,另一条是自下而上的浅层语义信息流,二者共同完成了 20×20 、 40×40 、 80×80 和 160×160 这4个尺度特征的融合。改进后的4个检测层架构虽然增加了少量的模型参数和计算量,但其结构可在很大程度上缓解较大缺陷目标尺度误差对模型检测精度的负面

影响,同时对小目标缺陷的检测性能有很大提升^[23]。

改进后的YOLOv8网络结构如图7所示,其中 K 代表卷积操作中卷积核的尺寸(如 $K=1$ 表示 1×1 卷积核); S 代表卷积操作中卷积核移动的步幅(如 $S=1$ 表示每次移动1个像素); n 代表Bottleneck模块的重复次数。




图7 改进后的YOLOv8网络结构

Figure 7 Improved YOLOv8 network structure

2 实验相关工作

2.1 自制数据集

本文使用的数据集包含两部分,其中一部分是中国电力线绝缘子数据集(Chinese power line insulator dataset, CPLID)。CPLID包括无人机拍摄的600幅正常绝缘子图像和248幅自爆缺陷绝缘子图像^[24],其中随机挑选的部分自爆缺陷绝缘子图像为本文数据集的来源之一。数据集的第二部分是公开图像,涵盖了绝缘子缺损、闪络及自爆这3种缺陷类型。两部

分共计1542幅图像构成了本文数据集。数据集集中的部分图像既包含了缺陷样本又包含了非缺陷样本,能够对模型的泛化性进行较好地检验。

本文利用Labelme软件严格按照标注规范对得到的绝缘子图像样本进行标注,4类图像样本如图8所示,相关标签分别为自爆、缺损、闪络。数据标注完成后,数据集按照7:1.5:1.5的比例被划分为训练集(1079个样本)、测试集(232个样本)和验证集(231个样本),其中训练集和测试集中的各类缺陷样本数量如表1所示。




图8 图像样本

Figure 8 Image samples

表1 训练集和测试集中3种绝缘子缺陷的样本数

Table1 Sample sizes of three types of insulator defects in training and testing sets

数据集	缺陷种类	数量
训练集	自爆	217
	缺损	791
	闪络	1 690
测试集	自爆	58
	缺损	171
	闪络	323

2.2 实验参数配置

实验环境为64位Windows 10专业版系统,基于PyTorch 2.0.0深度学习框架,具体配置为3th Gen Intel (R) Core (TM) i5-13600KF, NVIDIA GeForce RTX 4060Ti(16GB)。编程语言和加速软件分别是Python3.8和CUDA12.3。模型训练时,样本图像大小统一调整为 640×640 ,批次大小(batch)为16,训练次数(epochs)为350,初始学习率为0.01,权重衰减系数为0.000 5,学习率动量为0.937,优化器采用Adamax更新网络参数。

3 实验结果与分析

3.1 评价指标

为了更好地评价模型在绝缘子缺陷检测任务中的检测精度,实验采用的评价指标为平均精度(average precision, AP)、平均精度均值(mean average precision, mAP)、帧率(frames per second, FPS)以及模型规模(parameters)。AP由召回率与查准率决定,相关评价指标为

$$P = \frac{P_{TP}}{P_{TP} + P_{FP}} \times 100\% \quad (10)$$

$$R = \frac{P_{TP}}{P_{TP} + P_{FN}} \times 100\% \quad (11)$$

$$P_{AP} = \int_0^1 P dR \quad (12)$$

$$P_{mAP} = \frac{\sum_{j=1}^n (P_{AP})_j}{n} \quad (13)$$

式中, P 为查准率; R 为召回率; P_{TP} 、 P_{FP} 、 P_{FN} 分别表示真正例、假正例和假反例的数量; P_{AP} 为平均精度; P_{mAP} 为 n 个类别的平均精度均值; j 为类别索引。

3.2 实验结果

本文利用上述环境训练的模型,进行了绝缘子缺陷检测,3种目标缺陷测试结果如表2所示,其中mAP@0.5、mAP@0.5:0.95分别表示IoU阈值为0.5和IoU阈值从0.5到0.95(步长为0.05)时计算的mAP。

由表2可知,自爆缺陷因目标较大、轮廓清晰且特征相似度高而易于提取,其检测精度最高,误检与漏检率也最低。缺损缺陷区域的大小不一致,形状多样且与雪地等背景具有很大的相似度,所以其各项精度指标均低于其他目标。闪络缺陷是局部放电产生的灼烧痕迹,与正常的绝缘子往往只有颜色差异,且缺陷目标较小,造成其各项精度指标较低。对所有类别目标进行整体分析可以看出,改进后的算法能够较为高效精确地完成绝缘子缺陷的检测任务。

表2 3种目标测试结果

Table 2 Test results of three targets

序号	缺陷	标签	查准率/ %	召回率/ %	mAP@ 0.5/%	mAP@ 0.5:0.95/%
1	自爆	self-explosion	88.6	86.2	93.3	69.0
2	缺损	broken disc	92.5	79.7	83.0	60.9
2	闪络	pollution- flashover	95.6	85.8	91.7	61.1
3	整体	all	92.2	83.9	89.3	63.7

3.3 消融实验

为了进一步验证所提的3个优化模块在绝缘子检测任务中的可行性以及对基线模型YOLOv8n网络性能的提升效果,本文基于构建的数据集展开了6组消融实验(分别为A、B、C、D、E、F,其中实验F使用本文所提算法YOLO-insulator)。每组实验使

用相同的超参数及训练技巧,并对 YOLOv8n 基线模型进行 3 个方面的改进:在检测层部分添加 160×160 的小目标检测层;在特征提取骨干网络中用 RCS-OSA 模块替换 C2f 模块,在特征融合的颈部网络中用 RCS-OSA 模块替换部分的 C2f 模块;在特征融合的头部分添加 SENet 模块。实验在基线模型上通过累加不同模块来形成多种组合策略,分别训练所得的 mAP@0.5 曲线如图 9 所示,召回率-查准率曲线如图 10 所示,消融实验结果如表 3 所示。




图 9 基于改进 YOLOv8n 的消融实验 mAP@0.5 曲线

Figure 9 mAP (IoU is 0.5) curves of ablation experiment based on improved YOLOv8n

由图 9、10 及表 3 可知,与基线模型 YOLOv8n 以及各组消融实验相比,本文所提出的改进算法在检测精度指标上有较大提升。实验 A 中对 YOLOv8n 原模型进行训练后,可以获得较高的精度;实验 B 是在原模型 3 个检测层架构的基础上添加了一个 160×160 的小目标检测层,能够在一定程度上解决原模型难以检测小于 8×8 像素特征图而造成漏检的问题。这一改进使得查准率、召回率、mAP@0.5 和 mAP@0.5:0.95 分别提升了 0.3、1.8、1.7、3.2 个百分点。实验 C 是在特征融合颈部网络中添加 SENet,从而增强了模型对通道间关系的捕捉能力。这种提升整体特征表达能力的方式使得

查准率、mAP@0.5、mAP@0.5:0.95 分别提升了 2.3、1.9、0.7 个百分点。实验 D 是在特征提取骨干网络和特征融合颈部网络中用 RCS-OSA 模块替换 C2f 模块,在模型中堆叠的 RCS 模块确保了不同特征的复用并加强了不同特征层的信息交流,查准率、召回率、mAP@0.5、mAP@0.5:0.95 分别提升了 2.0、0.8、1.5、0.8 个百分点。实验 E 是对实验 B 和实验 C 的融合,相比于原模型,使得查准率、召回率、mAP@0.5、mAP@0.5:0.95 分别提升了 3.0、1.9、2.0、3.6 个百分点,且相比于实验 B 和实验 C 在各项指标上均有所提升,表明小目标检测层和 SENet 两种改进方法的融合能够进一步促进检测模型性能的提升。实验 F 是在实验 E 成功的基础上将其与实验 D 进行融合,即将所有的改进方法添加到原网络模型中,结果相比于原模型使得查准率、召回率、mAP@0.5、mAP@0.5:0.95 分别提升了 1.5、2.0、2.4、3.6 个百分点,且相比于实验 D 和 E,除了查准率略微有所下降,其余指标均有所上升,证明了将 3 种改进策略同时加入 YOLOv8n 原模型中能够实现网络模型综合性能的最大提升。

为了更清楚地展示不同模型在测试集上对绝缘子 3 种缺陷的检测与分类效果,本文绘制了消融实验中 6 种模型的混淆矩阵,如图 11 所示。图 11 展示出每个缺陷类别被正确分类和被错误分类的情况。混淆矩阵主对角线的数值表示正确分类的比例,数值越大,则分类越准确。实验 F 中,混淆矩阵的主对角线上自爆缺陷和闪络缺陷的数值在所有消融实验中最大,均达到了 90.0%,即 YOLO-insulator 模型对绝缘子自爆和绝缘子闪络两种缺陷的分类准确率均达到了 90.0%。缺陷的分类准确率达到了 81%,略低于实验 B 和实验 E 的 82%。混淆矩阵也有一定的局限性,它主要关注分类结果,而对于边界框的位置偏差、重叠等情况则无法体现,所以出现了实验 F 中缺陷识别率略低的情况。结合

表 3 基于改进 YOLOv8n 的消融实验

Table 3 Ablation experiments based on improved YOLOv8n

实验	YOLOv8n	160×160	SENet	RCS-OSA	查准率/%				mAP@0.5/%	mAP@0.5:0.95/%	召回率/%
					自爆	缺损	闪络	整体			
A	✓				91.7	87.5	92.7	90.7	86.9	60.1	81.9
B	✓	✓			84.2	92.8	96.0	91.0	88.6	63.3	83.7
C	✓		✓		89.3	93.6	96.0	93.0	87.8	61.8	81.6
D	✓			✓	94.4	88.9	94.8	92.7	88.4	60.9	82.7
E	✓	✓	✓		90.6	94.1	96.5	93.7	88.9	63.7	83.8
F	✓	✓	✓	✓	88.6	92.5	95.6	92.2	89.3	63.7	83.9




图 10 消融实验召回率-查准率曲线

Figure 10 Precision-recall curves of ablation experiment




图 11 不同模型测试结果的混淆矩阵

Figure 11 Confusion matrix of test results for different models

表 3 中召回率、mAP@0.5 相关数值及不同测试结果混淆矩阵分类精度, 可得 YOLO-insulator 的综合性能仍然是最高的。

综上所述, 本文所提模型的 3 个主要改进方法在实现绝缘子缺陷目标检测精度提升的目标上的

成效是不断递进的, 且其网络精度明显优于基线模型以及实验中的其他模型, 因此消融实验验证了该方法用于目标检测的有效性。

3.4 对比实验

为了验证 YOLO-insulator 的有效性, 本文选取

了 Faster R-CNN、CenterNet、EfficientDet、RetinaNet 等经典目标检测网络, YOLOv5n、YOLOv6、YOLOv7-tiny、YOLOv8n、YOLOv9、YOLOv10s、RT-DETR 等主流目标检测网络以及 YOLO-ELA^[25]、CACS-YOLO^[26]等绝缘子缺陷专用检测网络进行对比实验,并在完全相同的实验条件下使用相同的绝缘子缺陷数据集对这些目标检测模型进行训练。实验所得的 9 种算法对比实验的 mAP 曲线如图 12 所示,不同模型的对比结果如表 4 所示。




图 12 9 种算法对比实验的 mAP 曲线

Figure 12 mAP curves of nine algorithm comparison experiments

本文数据集中绝缘子缺陷目标背景复杂、尺度差异较大,检测网络特征提取困难,导致 Faster-

RCNN、CenterNet、EfficientDet、RetinaNet 这 4 种经典目标检测算法训练过程不稳定、振荡频率较高、收敛速度较慢。在与上述模型的对比中,YOLO-insulator 在查准率、mAP@0.5、mAP@0.5:0.95 和召回率等指标上均达到最高。在查准率的性能对比中,YOLO-insulator 分别比 Faster R-CNN、CenterNet、EfficientDet 及 RetinaNet 高出 56.5、4.1、1.4、3.2 个百分点,在 mAP@0.5 上分别高出 40.0、15.4、43.5、30.5 个百分点,在 mAP@0.5:0.95 上分别高出 38.6、22.4、40.0、25.4 个百分点,在召回率上分别高出 23.0、11.9、47.5、33.5 个百分点。其中 Faster R-CNN 是两阶段目标检测算法,需要用区域候选的方法绘制候选框:首先,通过卷积神经网络进行绝缘子缺陷特征提取;然后,对感兴趣的区域进行池化操作;最后,利用分类器和边界框回归对缺陷目标生成候选框^[27]。由于 FasterR-CNN 的每个单独训练步骤会使其训练时间大幅延长,模型需要较大的参数量和计算量,两者分别达到了 137.1×10^6 和 370.21×10^9 次/s,而检测帧率仅为 11.65 帧/s。EfficientDet 结合了 EfficientNet 主干网络和 BiFPN 特征融合机制,是一种轻量化的目标检测模型,在对比实验中其参数量和计算量仅为 3.87×10^6 、 5.23×10^9 次/s,但检测帧率为 27.24 帧/s,远远达不到实时检测的要求。所以,在与上述经典检测算法的对比中可知,YOLO-insulator 模型在各项精度指标上表现最好,除了参数量和计算量超过

表 4 不同模型的对比

Table 4 Comparison of different models

模型	查准率/%	mAP@0.5/%				mAP@0.5:0.95/%	召回率/%	参数量/ (10^6)	浮点运算速度/ (10^9 s^{-1})	帧率/ (帧·s ⁻¹)
		自爆	缺损	闪络	整体					
FasterR-CNN	35.7	63.1	54.7	30.3	49.3	25.1	60.9	137.10	370.21	11.65
CenterNet	88.1	71.1	74.6	76.0	73.9	41.3	72.0	32.67	70.22	125.87
EfficientDet	90.8	60.7	51.8	24.8	45.8	23.7	36.4	3.87	5.23	27.24
RetinaNet	89.0	67.5	67.2	41.6	58.8	38.3	50.4	37.97	170.09	55.83
YOLOv5n	90.6	84.3	79.6	85.9	83.3	51.1	77.9	1.76	4.10	217.39
YOLOv6	91.8	83.5	74.3	81.3	79.7	52.6	67.9	4.23	11.80	62.11
YOLOv7-tiny	76.1	76.8	69.0	77.9	74.6	43.2	72.0	6.01	13.00	131.58
YOLOv8n	90.7	88.7	81.0	90.9	86.9	60.1	81.9	3.01	8.10	250.00
YOLOv9	89.0	90.9	83.3	89.5	87.9	63.1	80.3	15.58	67.50	70.42
YOLOv10s	86.9	86.9	83.8	90.9	87.2	63.6	82.6	8.04	24.50	172.41
RT-DETR	88.5	74.7	84.9	94.4	84.7	53.4	77.6	41.94	125.60	52.91
YOLO-ELA	90.2	88.5	82.7	89.4	86.9	58.6	83.0	3.01	8.10	147.06
CACS-YOLO	90.1	88.6	82.5	90.1	87.1	57.6	83.4	2.65	7.00	169.49
YOLO-insulator	92.2	93.3	83.0	91.7	89.3	63.7	83.9	7.00	22.60	161.29

EfficientDet 外,其余各项轻量化指标均表现最佳。

在与结构相似的 YOLO 系列算法对比中, YOLO-insulator 在查准率、 $mAP@0.5$ 、 $mAP@0.5:0.95$ 和召回率等指标上均达到最高。在查准率的性能对比中,本文算法比 YOLOv5n、YOLOv6、YOLOv7-tiny、YOLOv8n、YOLOv9、YOLOv10s 分别高出 1.6、0.4、16.1、1.5、3.2、5.3 个百分点,在 $mAP@0.5$ 上分别高出 6.0、9.6、14.7、2.4、1.4、2.1 个百分点,在 $mAP@0.5:0.95$ 上分别高出 12.6、11.1、20.5、3.6、0.6、0.1 个百分点,在 R 上分别高出 6.0、16.0、11.9、2.0、3.6、1.3 个百分点。在精度指标全面领先的情况下,本文所提算法在其他轻量化指标上也处于中上游水平,所以其综合性能也远远高于结构相似的 YOLO 系列算法。

RT-DETR 算法通过引入 Transformer 注意力机制,能够较好地捕捉目标之间的关系和上下文信息^[28],有助于提升绝缘子缺陷检测的准确性,但本文数据量相对不够丰富,不能很好地满足 RT-DETR 对数据量的依赖性,导致查准率、召回率、 $mAP@0.5$ 、 $mAP@0.5:0.95$ 等指标较低,与 YOLO-insulator 相比,分别低了 3.7、6.3、4.6、10.3 个百分点,同时在参数量、计算量及检测帧率等性能上均不如本文所提算法。

YOLO-ELA 和 CACS-YOLO 是现有的专门针对绝缘子缺陷检测的目标检测模型。YOLO-ELA 模型是在 YOLOv8 的基础上,通过引入高效局部注意力模块和 SiIoU 损失函数改进得到的; CACS-YOLO 模型是在 YOLOv8 的特征提取层加入基于特征复用的坐标注意力机制和特征通道混洗操作而得到的。在查准率、召回率、 $mAP@0.5$ 、 $mAP@0.5:0.95$ 等性能指标的对比中, YOLO-ELA 分别比 YOLO-insulator 低出 2.0、0.9、2.4、5.1 个百分点; CACS-YOLO 分别比 YOLO-insulator 低出 2.1、0.5、2.2、6.1 个百分点。在其他部分轻量化指标中, YOLO-insulator 的表现略逊于这两种模型,但在保证实时检测的基础上 YOLO-insulator 的综合性能远远优于这两种模型。

综上所述,本文所提改进算法在所有与精度相关的评估指标中均表现为最优,在模型轻量化方面的表现也良好。本文主要针对的问题是绝缘子缺陷检测的准确性,而上述对比实验也表明了,在保持算法具有较好实时性的前提下, YOLO-insulator 模型在多场景绝缘子缺陷检测中比其他主流算法更

实用。

为了能够直观地对算法的检测精度进行对比,本文分别在 YOLO-insulator 及其他对比算法上进行了可视化实验。图 13~26 选取了遮挡严重、背景复杂、目标多尺度、目标尺寸小这 4 类具有代表性的场景进行绝缘子缺陷检测的可视化表示。在可视化实验中, YOLO-insulator 算法在所有的测试图像中均未出现漏检和误检的情况。

在图 13~26 中的每个分图(a)中,绝缘子自爆缺陷被严重遮挡,导致 YOLOv5、YOLOv6、YOLOv8n、YOLOv10s、YOLO-ELA 及 CACS-YOLO 均出现了漏检现象, RetinaNet、YOLOv7-tiny 和 RT-DETR 出现了误检现象。YOLO-insulator 不仅能够成功检测出遮挡严重的自爆缺陷,且置信度较高,仅次于 Faster R-CNN。图 13~26 中的每个分图(b)的背景都复杂,背景中的树枝等物和绝缘子的缺陷有一定的相似度,从而导致 Faster R-CNN、RetinaNet 及 YOLOv6 出现了误检的情况。其他算法虽然能够正确识别出缺陷,但置信度远低于 YOLO-insulator 的 0.94。图 13~26 中的每个分图(c)中的缺陷目标较小,且陶瓷绝缘子的光斑和闪络等缺陷的特征相似,这加剧了模型检测的困难程度,因此 RetinaNet 和 YOLOv5n 均出现误检现象,其余模型虽然能够成功检测出缺陷,但大多数算法的置信度较低,而 YOLO-insulator 的置信度高达 0.95,仅次于 Faster R-CNN 的 0.97。图 13~26 中的每个分图(d)中,两种缺陷的尺度相差较大,这对模型的泛化性能提出了一定的要求。像素信息较少的小目标缺陷不容易被识别,导致 EfficientDet 和 YOLOv7-tiny 两类算法出现了漏检现象。同样,陶瓷绝缘子光斑及部分边缘纹理特征和闪络缺陷特征相似,导致 RetinaNet、YOLOv7-tiny 及 RT-DETR 算法出现了误检现象。其余算法均能够识别出两种尺度差异较大的缺陷,但 YOLO-insulator 取得了最好的综合置信度。

可视化结果表明,本文提出的融合注意力机制和小目标检测层的 YOLO-insulator 算法在检测上述 4 种场景航拍绝缘子缺陷时,均未出现漏检或误检现象,在缺陷目标识别的准确率上表现最好。由此可知,本文所提算法在准确、高效识别绝缘子缺陷方面更加符合实际要求,拥有良好的泛化性和鲁棒性。



图 13 FasterR-CNN 的检测可视化图像

Figure 13 Detection visualization images of FasterR-CNN



图 14 CenterNet 的检测可视化图像

Figure 14 Detection visualization images of CenterNet



图 15 EfficientDet 的检测可视化图像

Figure 15 Detection visualization image of EfficientDet



图 16 RetinaNet 的检测可视化图像

Figure 16 Detection visualization images of RetinaNet



图 17 YOLOv5 的检测可视化图像

Figure 17 Detection visualization images of YOLOv5



图 18 YOLOv6 的检测可视化图像

Figure 18 Detection visualization images of YOLOv6



图 19 YOLOv7-tiny 的检测可视化图像

Figure 19 Detection visualization images of YOLOv7-tiny



图 20 YOLOv8n 的检测可视化图像

Figure 20 Detection visualization images of YOLOv8n



图 21 RT-DETR 的检测可视化图像

Figure 21 Detection visualization images of RT-DETR



图 22 YOLOv9 的检测可视化图像

Figure 22 Detection visualization images of YOLOv9



图 23 YOLOv10s 的检测可视化图像

Figure 23 Detection visualization images of YOLOv10s



图 24 YOLO-ELA 的检测可视化图像

Figure 24 Detection visualization images of YOLO-ELA



图 25 CACS-YOLO 的检测可视化图像

Figure 25 Detection visualization images of CACS-YOLO



图 26 YOLO-insulator 的检测可视化图像

Figure 26 Detection visualization images of YOLO-insulator

4 结语

本文构建了包含航拍绝缘子自爆、缺损、闪络这 3 类缺陷的数据集,提出了一种融合注意力机制和小目标检测层的绝缘子缺陷检测算法 YOLO-insulator。该算法在数据集上训练所得的查准率达 92.2%、mAP@0.5 为 89.3%、mAP@0.5:0.95 为 63.7%、召回率为 83.9%,均高于目前常见的目标检测算法。这也在很大程度上解决了输电线路绝缘子缺陷检测中由于缺陷类别多、尺度多样、遮挡严重等因素引起的误检、漏检问题。

本文的研究重点集中在如何最大程度地提升检测精度。未来的研究重点为在提升目标检测速度的基础上实现检测精度的大幅提升。另外,缺损缺陷各项精度指标均低于其他两种缺陷,拉低了模型的整体识别精度,所以后期也会重点从提升缺损缺陷检测精度的角度对模型进行改进。

参考文献:

- [1] 彭曙蓉,刘登港,何洁妮,等. 基于改进 YOLOv4 的架空线路电力设备故障检测[J]. 电力科学与技术学报, 2023, 38(5): 169-176.
- PENG Shurong, LIU Denggang, HE Jieni, et al. Fault detection for overhead line power equipment based on improved YOLOv4[J]. Journal of Electric Power Science and Technology, 2023, 38(5): 169-176.
- [2] 宋智伟,黄新波,纪超,等. 基于 Flexible YOLOv7 的输电线路绝缘子缺陷检测和故障预警方法[J]. 高电压技术, 2023, 49(12): 5084-5094.

- SONG Zhiwei, HUANG Xinbo, JI Chao, et al. Insulator defect detection and fault warning method for transmission line based on flexible YOLOv7[J]. High Voltage Engineering, 2023, 49(12): 5084-5094.
- [3] 谢静,杜耀文,刘志坚,等. 基于轻量化改进型 YOLOv5s 的可见光绝缘子缺陷检测算法[J]. 电网技术, 2023, 47(12): 5273-5283.
- XIE Jing, DU Yaowen, LIU Zhijian, et al. Defect detection algorithm of visible light insulator based on lightweight and improved YOLOv5s[J]. Power System Technology, 2023, 47(12): 5273-5283.
- [4] ZHAO Z B, JIANG Z G, LI Y X, et al. Overview of visual defect detection of transmission line components[J]. Journal of Image and Graphics, 2021, 26(11): 2545-2560.
- [5] 丘浩,张炜,彭博雅,等. 基于 YOLOv3 的特定电力作业场景下的违规操作识别算法[J]. 电力科学与技术学报, 2021, 36(3): 195-202.
- QIU Hao, ZHANG Wei, PENG Boya, et al. Illegal operation recognition algorithm based on YOLOv3 in specific power operation scenario[J]. Journal of Electric Power Science and Technology, 2021, 36(3): 195-202.
- [6] HAO K, CHEN G K, ZHAO L, et al. An insulator defect detection model in aerial images based on multiscale feature pyramid network[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 3522412.
- [7] HAN G J, ZHAO L, LI Q, et al. A lightweight algorithm for insulator target detection and defect identification[J]. Sensors, 2023, 23(3): 1216.
- [8] 刘瑶,贾晓芬. 融合残差结构与注意力机制的暗光图像增强算法[J]. 重庆工商大学学报(自然科学版), 2024, 41(4): 86-96.
- LIU Yao, JIA Xiaofen. Low-light image enhancement algorithm integrating residual structure and attention

- mechanism[J]. Journal of Chongqing Technology and Business University (Natural Science Edition), 2024, 41(4): 86-96.
- [9] HAN G J, LI T, LI Q, et al. Improved algorithm for insulator and its defect detection based on YOLOX[J]. Sensors, 2022, 22(16): 6186.
- [10] ZHAO Z B, ZHEN Z, ZHANG L, et al. Insulator detection method in inspection image based on improved faster R-CNN[J]. Energies, 2019, 12(7): 1204.
- [11] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE International Conference on Computer Vision. Venice, Italy: IEEE, 2017: 2999-3007.
- [12] 张倩, 王建平, 李帷韬. 基于反馈机制的卷积神经网络绝缘子状态检测方法[J]. 电工技术学报, 2019, 34(16): 3311-3321. ZHANG Qian, WANG Jianping, LI Weitao. Insulator state detection of convolutional neural networks based on feedback mechanism[J]. Transactions of China Electrotechnical Society, 2019, 34(16): 3311-3321.
- [13] FAN P, SHEN H M, ZHAO C, et al. Defect identification detection research for insulator of transmission lines based on deep learning[J]. Journal of Physics: Conference Series, 2021, 1828(1): 012019.
- [14] 张鋆, 王继业, 宋睿, 等. 基于边缘智能的输电线路异常目标高效检测方法研究[J]. 电网技术, 2022, 46(5): 1652-1661. ZHANG Jun, WANG Jiye, SONG Rui, et al. Research on efficient detection technology of transmission line abnormal target based on edge intelligence[J]. Power System Technology, 2022, 46(5): 1652-1661.
- [15] LAN Y, XU W X. Insulator defect detection algorithm based on a lightweight network[J]. Journal of Physics: Conference Series, 2022, 2181(1): 012007.
- [16] CHANG R, ZHOU S, ZHANG Y, et al. Research on insulator defect detection based on improved YOLOv7 and multi-UAV cooperative system[J]. Coatings, 2023, 13(5): 880.
- [17] HU D, YU M, WU X, et al. DGW-YOLOv8: A small insulator target detection algorithm based on deformable attention backbone and WIoU loss function[J]. IET Image Processing, 2024, 18(4): 1096-1108.
- [18] WANG C Y, MARK LIAO H Y, WU Y H, et al. CSPNet: a new backbone that can enhance learning capability of CNN[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). Seattle, WA, USA. IEEE, 2020: 390-391.
- [19] 左国玉, 马蕾, 徐长福, 等. 基于跨连接卷积神经网络的绝缘子检测方法[J]. 电力系统自动化, 2019, 43(4): 101-106. ZUO Guoyu, MA Lei, XU Changfu, et al. Insulator detection method based on cross-connected convolutional neural network[J]. Automation of Electric Power Systems, 2019, 43(4): 101-106.
- [20] KANG M, TING C M, TING F F, et al. RCS-YOLO: a fast and high-accuracy object detector for brain tumor detection[M]//Medical Image Computing and Computer Assisted Intervention-MICCAI 2023. Cham: Springer Nature Switzerland, 2023: 600-610.
- [21] ZHANG X S, SHEN B L, LI J C, et al. Lightweight algorithm for rail fastener status detection based on YOLOv8n[J]. Electronics, 2024, 13(17): 3399.
- [22] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City, UT, USA. IEEE, 2018: 7132-7141.
- [23] 宋耀莲, 王桢, 李大焱, 等. 基于改进 YOLOv5s 的无人机小目标检测算法[J]. 浙江大学学报(工学版), 2024, 58(12): 2417-2426. SONG Yaolian, WANG Can, LI Dayan, et al. UAV small target detection algorithm based on improved YOLOv5s [J]. Journal of Zhejiang University (Engineering Science), 2024, 58(12): 2417-2426.
- [24] WANG T, ZHAI Y D, LI Y H, et al. Insulator defect detection based on ML-YOLOv5 algorithm[J]. Sensors, 2023, 24(1): 204.
- [25] AKINDELE O, ATOLAGBE J. YOLO-ELA: efficient local attention modeling for high-performance real-time insulator defect detection[EB/OL]. 2024: arXiv: 2410.11727. <https://arxiv.org/abs/2410.11727>.
- [26] CAO Z, CHEN K H, CHEN J Z, et al. CACS-YOLO: a lightweight model for insulator defect detection based on improved YOLOv8m[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 3530710.
- [27] REN S Q, HE K M, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[EB/OL]. 2015: arXiv: 1506.01497. <https://arxiv.org/abs/1506.01497>.
- [28] ZHAO Y A, LV W Y, XU S L, et al. DETRs beat YOLOs on real-time object detection[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA. IEEE, 2024: 16965-16974.