

博士学位论文

工业场景下铝板带表面缺陷的多尺度深度
学习视觉检测方法研究

Research on visual detection method based on
multi-scale deep learning for surface defects of
aluminum sheet and strip in industrial scenario

一 级 学 科

机械工程

二 级 学 科

机械制造及其自动化

作 者 姓 名

马逐曦

指 导 教 师

李毅波 教授

2023 年 7 月

中图分类号 TP391

学校代码 10533

UDC 621

学位类别 学术学位

博士学位论文

工业场景下铝板带表面缺陷的多尺度深度 学习视觉检测方法研究

**Research on visual detection method based on
multi-scale deep learning for surface defects of
aluminum sheet and strip in industrial
scenario**

作者姓名

马逐曦

一级学科

机械工程

二级学科

机械制造及其自动化

研究方向

工业视觉缺陷检测

二级培养单位

机电工程学院

指导教师

李毅波 教授

副指导教师

论文答辩日期 2023.7.5

答辩委员会主席 _____

中南大学

2023年7月

工业场景下铝板带表面缺陷的多尺度深度学习视觉检测方法研究

摘要：大幅宽、高精度、高附加值的汽车铝板带、阳极氧化料、CTP 基板等高端铝板带材是我国重点发展的基础材料，其产品品质与表面质量依靠人工目视检测或离线式开卷检测的传统质检方式无法满足高端铝板带高速生产的实时监控、在线预警、缺陷分析、成品分级等新形式下的生产制造需求。为此，论文将引入结合深度学习的视觉检测技术（Automated Optical Inspection, AOI）对铝板带表面缺陷进行非接触在线检测，以满足高端铝板带材高精度、高效率及高稳定的检测要求，并为提高生产质量和产能利用率、推动铝板带生产向信息技术驱动的智能制造转型升级提供支持。

基于深度学习的视觉检测方法由于良好的泛化性和鲁棒性迅速取代传统缺陷检测方法，被应用于工业质量检测任务中。但将其应用于铝板带连续生产加工现场，应对少样本和目标遮挡等复杂生产场景时的检测性能和运行速度难以满足生产要求，制约了视觉检测系统的应用和发展。针对该问题，论文设计面向某宽幅高精铝板带精整生产线的在线视觉检测系统，完整采集各类铝板带表面缺陷图像以建立缺陷图像数据库，开展基于深度学习的表面缺陷在线检测方法研究。针对缺陷目标密集重叠、部分缺陷样本数量稀缺和满足在线要求的深度学习系统轻量化部署等突出难题，改进基于深度学习目标检测的 YOLO（You Only Look Once）框架，同步提升检测精度与检测速度，为推动基于深度学习铝板带表面缺陷检测系统在线工业应用提供理论依据与技术支撑。论文完成的主要研究工作如下：

（1）针对少数非频发缺陷工业数据样本稀缺及特征分布不均衡引起的模型泛化能力差的问题，利用缺陷的先验元知识提出一种基于元学习的特征再加权少样本端到端缺陷检测方法。在 YOLO 框架的多尺度结构中引入元学习理论，根据样本图像和掩码信息提取多尺度元特征信息，并利用重新加权向量对各元特征图重加权以强化特定类别语义特征。基于自适应缩放锚框解析重新加权后的多尺度元特征信息实现缺陷目标的预测和定位。通过“大量基类数据预训

练和少量带标记全类别数据微调”的元学习训练策略，实现面对不同缺陷类别的多种任务场景下的少样本模型快速部署。实验结果表明，该方法在训练图像 60 张以下的少样本条件下表现出优异性能，可有效克服工业缺陷数据稀缺时 YOLO 模型过拟合导致的检测性能下降问题。

(2) 针对多工序缺陷相互交叠遮挡的复杂检测场景，提出一种基于上下文信息和斥力损失的多层级遮挡缺陷检测方法。论文构建基于多分支感受野卷积块（Receptive Fields Block Network, RFB-Net）的上下文信息提取结构和多层级交叉特征融合结构，增强网络对缺陷特征的抗干扰分析能力；设计加权斥力损失函数及筛选机制，优化生成预测框的准确定位能力，缓解冗余计算负担。实验结果表明：该方法可有效缓解缺陷密集交叠及异物干扰条件下 YOLO 检测算法的严重漏检、误分问题。

(3) 针对铝板带表面缺陷检测效率与检测精度难以同时保证的问题，提出一种嵌入并行注意力机制的卷积轻量化缺陷检测方法。利用轻量化 Ghost 卷积和深度可分离卷积操作替换冗余特征图，嵌入通道空间注意力并行模块，压缩网络规模的同时增强网络对缺陷有效信息通道的关注；结合通道层及亚像素卷积采样和双金字塔特征融合结构，丰富不同尺度特征的细节信息和语义信息，进一步提高模型检测精度。实验结果表明：该方法可有效压缩 YOLO 网络规模提高检测速度，消除模型轻量化对缺陷检测精度的影响。

(4) 面向真实生产场景下的铝板带表面缺陷视觉检测的工业化应用需求，基于论文所提出改进的深度学习 YOLO 框架端到端检测算法，在国内某厂宽幅铝板带冷轧生产车间精整生产线上构建了铝板带表面缺陷实时在线视觉检测系统。应用效果表明：论文所提方法与检测系统满足工业场景下各类缺陷检出率、检测速度和缺陷分级的生产要求。

图 100 幅，表 42 个，参考文献 227 篇

关键词：铝板带材；表面缺陷；视觉在线检测系统；深度学习；少样本目标检测；遮挡目标检测；轻量化网络

分类号：TP391

Research on visual detection method based on multi-scale deep learning for surface defects of aluminum sheet and strip in industrial scenario

Abstract: Large-width, high-precision, high-value-added automotive aluminum sheets, anodized materials, CTP substrates and other high-end aluminum alloy sheets and strips are the basic materials that China focuses on development. The product and surface quality rely on traditional quality inspection methods such as manual visual inspection or offline uncoiling inspection, which have long been unable to meet new manufacturing needs of high-end aluminum strips produced at high speed, including real-time monitoring, online warning, defect analysis, and finished product classification. The non-contact on-line detection of surface defects of aluminum strips through Automated Optical Inspection (AOI) can meet the detection requirements of high precision, high efficiency and high stability. At the same time, it will improve production quality and capacity utilization, and promote the transformation and upgrading of aluminum strip production from traditional manufacturing to intelligent manufacturing driven by information technology. Due to good generalization and robustness, deep learning-based visual inspection methods quickly replace traditional defect detection methods, which are applied to industrial quality inspection tasks. However, the continuous processing characteristics of aluminum strips make it difficult for deep learning detection methods to meet production requirements when dealing with complex production scenarios such as too few samples and objects overlapping and occlusion, which restricts the application and development of visual inspection systems.

To overcome these limitations, an online visual inspection system is designed for wide-width and high-precision aluminum alloy strip for the finishing production line. The surface defect images of various aluminum strips are completely collected to establish a defect image database, which is used to conduct research on online detection methods for surface

defects based on deep learning. Focusing on outstanding problems such as scarcity of samples, dense overlapping of defects, lightweight deployment of deep learning systems, the YOLO (You Only Look Once) framework based on deep learning is improved and optimized to simultaneously improve detection accuracy and detection speed, providing theoretical basis and technical support for promoting the online industrial application of the deep learning-based defect detection system. The main research work completed in the thesis is divided into the following four parts:

In the first part of this thesis, we investigate how to address the problem of detection performance degradation caused by the sample scarcity and uneven distribution of a few and infrequent defect industrial data. An end-to-end few-shot defect detection method based on feature reweighting is proposed by exploiting the prior meta-knowledge of defects. The meta-learning theory is introduced into the multi-scale structure of the YOLOv4 framework, and multi-scale meta-feature information is extracted according to the image and mask. Afterwards, a reweighting vector is generated to reweight each meta-feature map to strengthen category-specific semantic features. Through the adaptive scaling of the Anchor box, the reweighted multi-scale meta-feature information is analyzed to realize the prediction and location of the defects. In addition, the meta-learning training strategy is designed that a large amount of base class data pre-training and a small amount of labeled full-class data fine-tuning, which achieves rapid deployment of few-shot models in various scenarios facing different defect categories. Compared with different detection methods, our method showed excellent performance under the condition of fewer than 60 training images, which can effectively overcome the detection performance degradation caused by the overfitting of YOLO.

In the second part, we focus on the detection of overlapping occlusion scenarios of multi-process defects. A multi-scale occluded defect detection method based on context information and repulsion loss is proposed. By constructing the extraction structure of context information based on RFB-Net (Receptive Fields Block Network) and the

fusion structure of multi-scale cross feature, the anti-interference analysis ability of the network to defect characteristics is enhanced. The design of weighted repulsion loss function and filtering mechanism can improve the positioning ability of the generated prediction box and alleviate the redundant calculation burden. The experimental results show that our method can effectively alleviate the serious phenomenon of missed detection and misclassification caused by defect overlap and foreign matter interference in the YOLO.

In the third part of this thesis, we aim how to ensure the positive correlation between detection efficiency and detection accuracy. A lightweight defect detection method embedded with a parallel attention mechanism is proposed. The original redundant feature maps are replaced by GhostNet and depthwise separable convolution. And the attention parallel module of channel and space is embedded in the lightweight network structure, which can enhance the network's attention to the effective information channel of the feature map while compressing the network scale. Combined with Pixelshuffle and Passthrough sampling and double pyramid feature fusion structure, the detailed information and semantic information of different scale features are enriched, and the accuracy of model detection is further improved. According to the experimental results, this method effectively compresses the scale of YOLO to improve the detection speed, and eliminates the impact of model lightweight on the defect detection accuracy.

In the last part, we implemented the real-time online visual detection system for surface defects on the finishing production line at the cold rolling production workshop of wide-width aluminum strip. The system is based on the improved deep learning YOLO framework detection algorithm proposed in the thesis, which is used to realize the industrial application of visual detection of aluminum strips surface defects in real production scenarios. The application resulted show that the proposed method and detection system meet the production requirements of various defect detection rates, detection speed and defect classification in industrial scenarios.

Full total figures 100, tables 42, references 227.

Keywords: Aluminum alloy strip; Surface defects; Visual online inspection system; Deep learning; Few-shot object detection; Occluded object detection; Lightweight neural network

Classification: TP391

目 录

第 1 章 绪论.....	1
1.1 研究背景和选题意义.....	1
1.2 铝合金等金属带材表面缺陷检测系统的发展	3
1.3 铝板带表面缺陷检测算法研究现状	7
1.3.1 传统视觉缺陷检测方法.....	8
1.3.2 基于深度学习分类网络的检测方法.....	9
1.3.3 基于深度学习框架的目标检测方法.....	12
1.4 铝板带表面缺陷工业检测存在的问题	15
1.5 本文研究内容以及论文结构	18
第 2 章 铝板带表面缺陷端到端视觉检测方法 with 缺陷图片库构建	22
2.1 工业场景下铝板带表面视觉检测特点及难点	22
2.1.1 铝板带生产工艺及检测环境特点.....	22
2.1.2 端到端检测需求及技术难点.....	23
2.2 基于 YOLO 框架的铝板带表面缺陷端到端视觉缺陷检测方法	24
2.2.1 铝板带表面缺陷的端到端检测方法.....	24
2.2.2 YOLOv4 的基本框架.....	26
2.2.3 YOLO 框架的铝板带表面缺陷端到端全检测流程	28
2.3 铝板带表面缺陷类型及其图像特征	30
2.4 缺陷数据的获取及数据库的构建	36
2.5 本章小结.....	41
第 3 章 少样本条件下的特征再加权 YOLOv4 缺陷检测方法	42
3.1 少样本条件下缺陷检测的突出问题	42
3.1.1 少样本问题的定义和解决方式.....	43
3.1.2 结合少样本学习的目标检测难点及主要方法	47
3.2 基于元学习特征再加权的 YOLOv4 少样本缺陷检测方法 ...	50
3.2.1 少样本缺陷检测网络框架.....	51
3.2.2 多尺度元特征图提取与融合模块设计	51
3.2.3 特征再加权网络模块设计.....	54
3.2.4 多尺度加权特征的预测网络模块设计	56
3.2.5 锚框(Anchor box)自适应缩放方法.....	57
3.3 铝板带表面缺陷少样本检测的实验及对比	59
3.3.1 少样本训练数据集的建立.....	59
3.3.2 模型训练的策略和评价标准.....	61

3.3.3 铝板带表面缺陷少样本检测结果.....	63
3.3.4 少样本条件下缺陷检测效果对比.....	68
3.3.5 缺陷样本数量对模型性能的影响.....	71
3.3.6 少样本缺陷检测模型的实时性验证.....	72
3.4 本章小结.....	73
第 4 章 结合上下文信息和斥力损失的 YOLO 抗遮挡缺陷检测方法.....	75
4.1 缺陷遮挡问题及其解决思路	75
4.1.1 缺陷检测中遮挡问题的定义.....	75
4.1.2 遮挡缺陷目标检测的难点及解决方法	76
4.2 面向遮挡缺陷检测的上下文特征增强 YOLO 模型设计与优化.....	78
4.2.1 整体网络结构设计	78
4.2.2 基于上下文信息的自适应特征提取.....	79
4.2.3 多尺度的双路径级联融合模块设计.....	83
4.2.4 基于斥力损失的加权损失函数设计.....	85
4.2.5 预测框筛选策略的抗遮挡优化.....	87
4.3 铝板带表面遮挡缺陷的检测实验与对比	90
4.3.1 遮挡缺陷数据集的构建.....	90
4.3.2 遮挡目标检测效果评价指标.....	91
4.3.3 模型训练及超参数设计.....	92
4.3.4 遮挡缺陷的检测结果与消融实验.....	93
4.3.5 遮挡缺陷检测性能对比实验.....	96
4.4 本章小结.....	99
第 5 章 融入注意力机制的 YOLO 网络轻量化与铝板带表面缺陷检测.....	101
5.1 卷积神经网络的轻量化技术	101
5.2 融入注意力机制的 YOLOv4 网络 Ghost Net 轻量化方法...106	
5.2.1 YOLOv4 轻量化网络整体框架.....	106
5.2.2 基于 Ghost 卷积的轻量化主干网络构建	107
5.2.3 融入注意力机制的轻量化主干网络优化	109
5.2.4 基于多尺度的特征融合网络构建.....	113
5.2.5 面对样本不均衡的自适应预测解析层构建	115
5.3 铝板带表面缺陷检测的模型轻量化性能验证	116
5.3.1 轻量化模型训练的数据集构建.....	117
5.3.2 检测性能评价标准及实验环境.....	117
5.3.3 模型训练和超参数优化.....	118
5.3.4 模型检测结果及鲁棒性验证.....	120

5.3.5 轻量化模型检测性能与效率对比.....	123
5.4 本章小结.....	129
第 6 章 面向精整线铝板带表面缺陷检测系统设计及工程应用	131
6.1 宽幅高精铝板带表面检测需求及设备安装	131
6.1.1 精整生产线宽幅高精铝板带生产情况及安装需求	131
6.1.2 视觉检测系统功能需求.....	132
6.2 铝板带表面缺陷检测系统的总体构架	134
6.3 宽幅铝板带表面缺陷检测系统的硬件系统	135
6.3.1 系统总体方案设计	136
6.3.2 关键部件设计.....	140
6.4 检测系统算法集成与可视化软件系统	144
6.4.1 系统软件结构.....	144
6.4.2 软件交互客户端功能设计.....	145
6.5 铝板带表面缺陷在线检测及结果验证	149
6.6 本章小结.....	153
第 7 章 总结与展望	154
7.1 工作总结.....	154
7.1.1 主要研究工作.....	154
7.1.2 特色与创新点.....	155
7.2 研究展望.....	156
参考文献.....	158

第 1 章 绪论

1.1 研究背景和选题意义

近年来,伴随着新兴产业迅速发展及铝行业产能过剩的影响,我国对铝合金板带材的需求逐渐转向大幅宽、高精度、高附加值的高端产品,例如汽车铝板带、阳极氧化料、CTP 板基等一些重点发展的基础材料。但是,由于制造理念和技术水平滞后、研发投入不足等原因,国内加工企业在高端铝板带材的表面质量控制和产能利用率等方面与国外发达国家相比仍有明显差距,这迫使铝产业制造模式需要进行根本性升级。

深度融合信息技术的智能制造系统是实现高端产品质量及产能的提升的重要途径之一。而其中实现产品质量感知和制造设备控制之间的反馈是建立具有感知、决策、控制、执行功能的铝板带智能制造生产线^[3, 4]的首要问题。对持续移动状态下的高端铝板带材产品进行智能化、高精度、实时性的产品质量监控及准确的检测数据反馈,不仅避免了产品质量问题引发的安全隐患和经济损失,而且可为生产过程的智能化工艺控制提供关键数据支撑。

然而,以人工视检为主的产品质量监控与检测手段,在面对当前高端铝板带材的高精度质量要求时,由于人眼视觉生理限制难以在高速、宽幅表面捕捉到微小缺陷造成漏检、误检现象严重;并且缺陷判定标准受人员判断标准、身体状况、操作经验等主观因素影响较大,其质量检测结果的一致性和稳定性无法保证。视觉检测技术 AOI(Automated Optical Inspection)或 ASI(Automated Surface Inspection)作为智能制造装备环境感知和自主控制的关键核心,可代替人工进行检测、分析、判断和决策控制^[5],如图 1-1 所示。通过高速数字图像采集、实时在线图像处理与分析技术对产品表面质量进行实时高精度检测并对生产状况进行及时反馈,对运行数据的自动分析可为成品管理提供重要数据信息。随着成像器件与计算处理技术的成熟和全球视觉部件的市场规模的不断扩大,视觉检测的硬件设备模块集成化程度越来越高,零部件升级改造对整体设备的影响越来越小,技术条件对检测系统应用范围的限制逐渐减小。将视觉检测技术引入高精度、高速度的铝板带生产线中建立表面缺陷检测系统。相比其他质量检测手段,表面缺陷视觉检测系统具有以下优点:(1)智能化程度高,检测过程中数据计算的一致性和重复性克服了人工检测结果不稳定的弊端;(2)信息感知手段丰富,可以通过多种成像方案获取板带表面精确的空间位置、形貌特征和动态信息;(3)检测准确率高,发生漏检率和误检率的机率较低;经过现场调研,人工检测的良品率仅为 57.3%,客户针对表面质量问题的月投诉量在二十起左右。视觉检测的高准确度可避免不符合质检要求的非良品

流入下游企业或后续工序以及信息滞后处理不及时造成的材料和时间浪费。

(4) 检测实时性可满足高速大批量生产在线检测的需求, 不受视觉生理极限和离线开卷检测信息延迟的限制, 操作人员及时准确的掌握设备运行状况, 提高高端产品产能利用率并且缩短产线停机时间; (5) 视觉成像与智能监控、数据处理、网络信息、生产管理等技术结合, 可实现全生产流程的智能分析、监控和管理, 有利于企业柔性化、服务化、智能化的生产管理, 推动铝加工产业转型升级为由信息技术驱动的智能制造模式。(6) 检测系统独立化、模块化, 产线设备后续的改造升级便捷。




图 1-1 视觉表面检测系统在铝行业的应用

虽然已有部分表面视觉检测系统被应用于金属板带材的制造中, 但传统依靠人力的在线或离线检测依然是行业内的主流检测方式。一方面是由于视觉检测技术均垄断在国外几家专业检测设备生产公司。单套设备的引进价格较为昂贵, 并且后续设备维护、调试, 以及软件系统升级更新和人员操作培训均需要支付额外费用。除了大型铝板带材生产企业在部分生产线使用, 大部分企业难以负担其高昂的部署费用, 从而制约了视觉检测系统的发展和应用, 阻碍了大部分生产企业的智能化转型升级。另一方面, 目前缺陷检测算法应对特定检测场景的智能化程度不足, 难以满足复杂生产环境的检测需求导致应用场景受限。大部分检测方法均是针对单一特定目标或检测对象的传统图像处理方法, 当检测对象或环境发生细微变化后, 系统的检测精度常常难以达到检测要求, 需要花费较高的时间成本重新进行安装和参数调试以及算法的重新调整。

近年来, 深度学习方法在目标检测领域逐渐展现出强大的检测能力, 但是依然有许多问题导致基于深度学习的缺陷检测方法对特定对象的检测效果并不理想, 从而阻碍了深度学习表面缺陷检测系统在实际生产中的应用和发展。从深度学习方法检测精度的角度分析, 一方面, 工业缺陷数据获取难度大且数量严重不均衡的情况, 难以保证模型充分掌握各类别缺陷特征的分布规律, 严重

影响缺陷检测效果；另一方面，铝板带连续性的加工特点造成缺陷相互重叠、遮挡，以及环境光源、图像传输噪声和油渍水渍等干扰，导致实际复杂生产环境下出现漏检、误检和定位偏差等现象。从检测速度的角度分析，如何平衡深度学习方法的庞大算法规模与快速实时性之间的矛盾，在保证检测精度的同时提升检测速度，解决铝板带流程化加工面临的实时工业检测速度问题。

综上，本文在“广西特聘专家”专项项目“基于板形/缺陷视觉检测的铝板带轧制工艺过程的智能控制”（GuiRenzi2019（13））的资助下，以 2800mm 精整生产线宽幅铝合金板带表面缺陷为研究对象，基于多尺度深度学习 YOLO 框架深入研究制约其检测效果的根源问题。设计面向宽幅铝板带的在线视觉检测系统为生产加工提供实时、准确的监控和预测，推动深度学习检测方法在复杂工业场景下的工程应用。

1.2 铝合金等金属带材表面缺陷检测系统的发展

工业生产中利用智能化的科技手段识别金属材料表面的加工缺陷起步于 20 世纪中叶。金属带材的制造由于生产规模大、生产速度快、生产环境恶劣，其表面质量的监控一直是工业质量检测领域的重点发展方向。金属带材的表面缺陷检测跟随着电子元件、成像技术和计算处理能力的升级从涡流检测、超声检测、红外检测、漏磁检测发展至今，逐渐转向利用不同光源和成像原理的机器视觉检测方法。

传统人工开卷或者在线视检的方法，根据操作员的判断经验对金属带材表面质量进行检测，仅适用于生产速度较慢、检测精度不高、且工作环境良好的生产线。人工在线视检，其漏检、误检的出现频率较高导致其检测结果的可信度降低；离线开卷检测虽然可以保证检测结果的精确性，但是离线检测模式导致检测效率降低，生产情况的结果反馈延迟，并且容易对产品造成二次损伤。由于人工检测的诸多局限性，钢板的生产制造已经逐渐替换为智能化的检测手段，但是铝板带生产环境限制较小、高精度产品生产需求较小、生产成本较低等诸多原因，目前大部分生产企业依然大量沿用人工检测的产品质量方式。

涡流检测方法利用电磁感应产生温度变化的原理，探测金属板带中涡流信号的变化情况从而分析其内部和外部的损伤。最初的涡流探伤设备是法国洛林连轧公司在 1989 年研制的应用在热连轧铸板坯生产线的板坯裂纹缺陷检测设备 EDISOL^[6]。目前，脉冲涡流检测常被使用在航空铝合金板^[7]和汽车镁铝合金板^[8]的表面缺陷和内部缺陷的定性检测中，但是这种检测方法无法提供多类型缺陷的定量检测，仅适用于缺陷深度、大小明显的中厚板材。红外检测方法则是通过传感器检测感应电流对金属表面产生的温度变化，从而达到识别缺陷的目

的。1990 年,挪威的 Elkem 公司研发了第一台红外检测设备 Therm-o-matic 用于连铸板坯表面缺陷的检测。该方法需要建立材料属性、环境干扰、电流运行参数、感应线圈参数等多种变量与缺陷温度变化之间的联系,因此其检测稳定性较低,对检测环境的要求较高,导致可使用范围受限^[9]。射线检测方法是利用电磁波或者电磁辐射的能量在穿透不同物质时衰减系数不同,通过强弱变化并结合投影图像判断缺陷的存在。由于射线检测的使用方便,检测速度较快,常被用于汽车铝制板材、零部件的表面及内部缺陷检测^[10-12]。超声检测方法利用超声波作用于工件,通过对反射、透射和散射的回波进行分析,实现宏观缺陷的检测。目前,超声波检测常被应用于铝合金板^[13, 14]、厚铝板^[15]的裂纹检测。但是超声波必须依靠介质传播,容易损耗散射。激光扫描检测方法则是利用激光的高聚性和金属材料的高反光性特点,通过激光干涉变化反应表面情况。最早在 1971 年由英国钢铁公司研发应用于带钢的表面检测^[16]。由于激光检测的灵敏度较高,不仅应用于铝板等表面缺陷的检测中,还被应用于金属零部件和焊缝的形状、质量检测^[17, 18]。但是其系统结构较为复杂,对环境的抗干扰能力弱,对于伪缺陷和微小缺陷的识别能力较低。由于后期维护成本和可检测缺陷范围小的问题,难以在板带生产企业大量推广。

随着成像传感器(如 CCD)的出现和不断发展,通过获取的图像数字信号反映金属板带表面信息的基于数字图像的视觉检测方法逐渐被研究和推广应用。早期的 CCD 成像技术由于硬件配置和处理技术较为落后,检测的精度、成像的分辨率不高阻碍了检测设备可以识别的缺陷范围以及可适用的生产设备。1983 年,美国 Honeywell 公司首次研制出基于 CCD 成像的视觉检测系统,并将其应用于连铸板坯的生产^[19]。在其影响下,钢铁行业逐渐成为最早引入视觉检测系统作为检测手段的金属带材制造企业。1986 年,美国 Westinghouse 和 Eastman Kodak 公司利用线阵相机和线光源研制出检测分辨率在 2mm 的钢坯表面缺陷检测设备^[20]。意大利的 Centro Sviluppo Materiali 公司研发出用于不锈钢和带钢的表面缺陷检测设备^[21]。SIPAR 公司也采用线阵相机研发出带钢表面缺陷检测系统,可实现 21×1 mm 的缺陷检测分辨率^[22]。英国的 EES 表面缺陷检测系统在荷兰的 Hoogovens 热轧生产线上实现了 21.02×2.03 mm 缺陷检测分辨率。早期的检测系统受限于硬件处理能力的不足,只能实现缺陷的检出,无法对缺陷的类别进行判断。直到芬兰的 Rautaruukki New Technology 公司的 Smartvis 表面检测系统才成功使用决策树进行简单的缺陷分类工作^[23]。

与其他工业产品的缺陷检测不同,金属带材的表面检测系统面对的检测对象为幅宽大的单一性带状材料,其表面缺陷多样且相似。检测过程需要采集单元连续扫描,处理单元连续的计算处理。成像技术和设备的不断升级,信号采

集、处理和传输手段不断更新, 自动化智能计算和识别理论飞速发展以及硬件计算处理能力的不断飞跃, 基于视觉的自动检测系统逐渐成为金属板带材表面缺陷检测的主流方案。自动化视觉表面缺陷检测系统具有非接触性、高集成化、模块化等特点, 独立部署, 独立控制, 生产设备不受安装影响, 并且系统各硬件部件模块化设计, 方便维护管理和后期维修。因此, 视觉检测系统的研发与应用也逐渐从企业方自行投入资金开发转变为专业机器视觉检测公司面向不同对象的检测系统研发。

国外发达国家在智能检测技术的研究领域起步较早, 目前美国 Cognex 公司和德国伊斯拉公司已经开发多种金属板带材表面缺陷检测系统, 并应用于生产企业。1996 年, 美国 Cognex 公司研制的 iS-2000 表面缺陷检测系统, 通过集成 iLearn 分类器软件被成功应用于美国 LTV 钢铁公司的镀锌生产线。利用线阵像采集图像, 对图像进行自动的增益校正和阈值分割获取缺陷区域。之后, 根据尺寸、密度特征, 通过决策树分级判断, 实现缺陷类别判断。Cognex 在 2005 年又推出了模块化、集成化和智能化更高的 Smartview 系统, 采用模糊模式匹配对不同缺陷进行分类。1997 年, 德国 Parsytec 公司在冷轧带钢和热轧带钢产线上设计开发了表面检测系统 HTS-2/HTS-2W, 采用多面阵相机组合的模式采集图像, 并利用人工神经网络技术进行缺陷分类^[24, 25]。2004 年, Parsytec 公司在此基础上利用决策理论优化缺陷检测系统, 开发了可对热轧带钢进行分级的 EXPERT-5i 表面检测系统。目前, 德国 ISRA 公司 (Parsytec 公司) 的最新表面缺陷检测系统 Surface Master, 通过面阵相机和线阵相机相结合的方式, 基于 EPROMI 质量管理体系实现多条产线的质量检测。除了以上所述, 日本 NKK 公司的 Delta-eye 带钢表面缺陷检测系统可以实现 $20 \times 3\text{mm}$ 的检测分辨率^[26]。

由于铝加工行业的发展较晚, 针对铝板带材或铝箔表面质量检测的相关研究少于钢铁行业。德国 ISRA 公司基于 Surface Master 系统的铝带材表面检测系统, 采用 FPGA 处理技术的线扫描相机配合 Standard SMASH 软件, 可在光滑均匀的背景背景下检出多种缺陷类型。德国 IMS 公司的 Surcon 2D 表面检测系统, 利用线阵相机采集方式, 通过多分类器并行检测, 实现铝板表面质量检测。美国 Wintriss 公司的 Web Ranger 在线表面质量检测系统可实现铝板带材的表面缺陷检测。

由于我国金属带材制造企业智能化升级起步较晚, 针对金属板带材表面缺陷检测系统的研究发展较慢, 主要以高校、科研院所为主。1995 年, 华中科技大学的罗志勇课题组^[27]首次利用多面阵相机结合 DSP 处理器研制了带钢表面检测系统, 实现了对冷轧钢板表面凹陷、锯齿、折痕等缺陷的检测和定位。天津大学的胡亮课题组基于 FPGA 图像预处理和 DSP 缺陷特征计算, 设计了冷轧带

钢表面缺陷在线检测系统方案^[28, 29]。北京科技大学表面检测课题组^[30-33]于 2002 年研制了国内第一台冷轧带钢表面缺陷检测系统，应用于武钢公司的冷轧带钢精整生产线。之后，结合对光源、采集方案和检测算法的研究基础，于 2009 年研制了应用于热轧带钢生产的表面缺陷检测系统 HXSI^[34]。目前，其研制的金属板带表面质量在线监测系统 BKvision 系列，实现了钢铁领域全流程的表面缺陷在线检测。2008 年，上海宝钢公司旗下宝星公司研发了表面缺陷在线检测设备 BaoVision-SIS^[35, 36]，用于宝钢公司的带钢热轧生产线。

国内铝行业的表面检测系统在近几年发展迅速。如中色科技苏州有色金属研究院^[37]开发的表面缺陷检测系统，利用线阵相机采集图像，通过前端机预处理和数据库服务器进行分类的模式，实现缺陷的分割定位和分类识别。将其应用于铝板带拉矫生产线的表面检测，实现十种缺陷的识别和定位。无锡精质视觉科技有限公司的铝板带箔表面缺陷检测仪，利用神经网络分类实现铝箔表面漏涂、黑点、蚊虫、气泡等四种缺陷的在线检测。如表 1-1 所示，展示了国内部分检测系统开发企业所研制的精整线铝板带表面检测设备的技术参数。

表 1-1 国内企业所研发的铝板带表面缺陷检测系统检测参数

安装机组名称	带料宽度	最高检测速度	检测精度	可检测缺陷种类
铝带拉弯矫直机组	500mm~2050mm	50m/min	0.5×1mm ²	裂纹、起皮、擦伤、磕伤
铝带剪切机组	1400mm	40m/min	1×1.2mm ²	复合层脱落、起皮、擦伤、裂纹
铝带纵剪机组	1400mm	60m/min	0.5×0.87mm ²	复合层脱落、辊印、起皮、气泡

可以看出，表 1-1 中的检测产品带宽在 2 米的范围内，最高检测速度在 40 到 60m/min 之间，可满足 0.5mm 以上的 4-5 种缺陷类型的检出。而本文研究所面向的 2800 精整生产线生产的各品类产品幅宽在 500-2620mm 之间，产线生产速度为 10-70m/min。由于生产设备均属于重型机械，检测系统需要抵抗运行过程中的产生的振动和传输噪声，并保持良好的检测精度和检出率。针对该企业质量管控要求、生产设备运行情况及安装环境要求，工业场景下的 2800 精整生产线表面质量检测系统需满足表 1-2 所示设计要求。

表 1-2 2800 宽幅精整产线质量检测设计要求

项目名称	设计要求
相机安装高度	高于铝板带表面 500mm
检测速度范围	10m/min 到 70m/min
可检测最小缺陷尺寸	0.5×0.5mm ²
可检测最大幅宽	2800mm
缺陷检出率	大于 90%
时间延迟	500ms
可检出缺陷类型	企业质检操作要求的 10 类缺陷 (提供缺陷分级功能)

目前已被实际应用的表面质量检测系统虽然能够实现特定检测对象的质量监控，但是大部分仍使用图像处理结合机器学习的方法完成缺陷的检出或是分类任务，其检测算法的设计需要人工先验知识的干预。由于金属板带材的生产特点和环境以及运行设备振动等因素影响，表面检测系统的应用效果并不理想且应用场景受限。（1）检测算法的自适应能力有限。当检测对象发生变化或环境光源变化时，需要重新对算法的相关阈值参数进行调试。（2）检测算法面对缺陷特征多样且复杂背景干扰的场景时，智能性和泛化性不足。缺陷目标的类内差异大或类间较相似会对高精度的缺陷检测造成影响。此外，板带材表面出现的水渍、油渍等会干扰缺陷的检测和识别。（3）检测系统运行时间难以满足高精度高速度的生产要求。表面精度要求的提高使得高清采集图像的处理数据量越来越大，从而影响了检测算法的运行速度。分辨率的提高带来了缺陷种类增加和缺陷形态变化，算法的设计逐渐复杂，运行速度难以满足现阶段的生产要求。

1.3 铝板带表面缺陷检测算法研究现状

面向流程化的金属板带材加工现场的基于视觉表面质量缺陷检测技术 AOI（Automated Optical Inspection）或 ASI（Automated surface inspection）主要具备两个功能^[38-40]：一是缺陷区域的定位，从正常的采集图像中获取缺陷区域及位置信息；二是缺陷类别的判断，对缺陷区域进行识别分析，判断缺陷的类别信息。因此，快速、稳定、准确的得到检测结果是衡量检测系统有效性的重要指标。数十年中，对于视觉缺陷检测技术的研究也随着硬件升级和算法理论的优化发生了巨大的变化。从传统机器学习视觉检测到基于深度学习分类网络的检测方法，再到目前应用最为广泛的深度学习目标检测方法，通过数据驱动逐渐实现对输入图像与输出结果间复杂关系的自动化建模。

1.3.1 传统视觉缺陷检测方法

相比于日常物体的目标检测,金属带材幅面较宽且需要提供缺陷出现位置信息,AOI 的缺陷检测步骤通常分为四步:图像预处理,缺陷区域的分割,缺陷特征的提取以及特征的识别分类,各步骤独立进行设计和处理。

(1) 图像预处理阶段,由于采集图像在传输过程受到运行设备、接口线路或是采集环境、温度等原因的影响,出现图像的噪声或光照不均衡等情况,对后续缺陷区域的分割和特征的提取造成干扰。因此,消除噪声、增强缺陷特征、弱化背景干扰或不均匀影响尤为重要。图像去噪,通常是利用滤波原理(空间域和频率域)通过预定义规则(邻域像素均值法、排序中值法等)对一定范围内的像素灰度值进行替换运算实现图像降噪目的,如结合加权、开关、迭代等空域滤波技术^[41, 42],以及适用于周期性噪声去除的小波变换或傅立叶变换^[43, 44]结合频谱分析的频率域滤波技术。图像增强的目的是强化图像中表示缺陷的特征信息,弱化背景干扰信息,使显著的缺陷信息可以更好的被算法捕捉。利用非线性运算,扩大缺陷区域与背景之间的像素值灰度差,如边缘增强,对比度增强等。图像非均匀性校正(Non-Uniformity Calibration, NUC)利用场景模板中的信息,建立非线性联系通过调整参数校正、平衡图像像素灰度值,在一定程度上消除不均匀的光照度对缺陷特征表达的影响,如基于场景的代数校正法^[45],卡尔曼滤波算法^[46, 47],高斯-马尔科夫校正法^[48]。

(2) 缺陷区域的分割,由于铝板带表面图像尺寸较大,而缺陷区域往往较小,将缺陷区域从原始采集图像中提取出来,一方面可以得到缺陷区域的准确位置和面积信息,完成定位任务。另一方面,仅对提取的缺陷区域进行后续的特征计算和分类,更好的突出缺陷特征,并且大大缩减运算量和数据量,保证系统的运行实时性。常用的缺陷分割方法有:对比标准模板灰度变化的背景差影法,如基于 Vibe 的缺陷区域提取用于实现板带表面缺陷检测^[49]和针对局部熵的背景差影法提取缺陷用于检测劣质钢表面缺陷^[50];根据灰度值相近原则的区域分割法^[51-53],如基于超像素的两级聚类的冷轧带钢的表面质量检测^[54],基于谱多流形和密度聚类的方法实现直线导轨表面交叉划痕的分割^[55];以及根据缺陷边缘灰度梯度变化的边缘提取法,如基于 Sobel 算子的钢轨表面缺陷分割^[56]、基于 Kirsch 算子的钢板微小缺陷检测^[57]和基于 Canny 算子^[58]的高亮金属产品表面缺陷分割等。

(3) 缺陷特征的提取,通过人工经验知识,设计提取算子或函数分析和统计像素点之间不同的空间、分布、灰度关系,从而获取具有类间离散度和类内聚集度的缺陷特征数据。常见方法包括:通过统计特征寻找像素之间的分布规律的提取方法,如基于方差标准差^[59]和卡方方差^[60]等直方图特征信息的缺陷检

测方法, 基于共生灰度矩阵的铝型材表面缺陷^[61]和钢铁表面缺陷^[62, 63]的提取、检测方法, 以及基于广义完备局部二元模式的非均匀模式下钢板表面缺陷检测^[64], 改进的局部三元模式的缺陷检测^[65, 66]; 根据缺陷结构信息特征的提取方法, 如铝合金车轮的表面检测^[67]; 利用滤波或线性变换的信号提取方法, 如单独的 Shearlet 变换检测铝板表面缺陷^[68]和相互结合的双 Gabor 滤波^[69]、小波变换结合 Hilbert-Huang 变换^[70]、及多尺度几何分析 (MGA)^[71]的缺陷特征提取方法; 通过寻找缺陷特征特定分布信息的模型提取方法, 如基于引导模板^[72]和哈尔威布尔方差 (HWV) 模型^[73]的缺陷检测方法。

(4) 缺陷特征的分类, 根据提取到的缺陷特征设计分类模型对缺陷类别进行判别。由于工业样本的特征类间离散度较小且样本数量有效, 工业缺陷检测一般都利用有监督模式下的分类方法, 根据已知标签样本建立判别模型, 对缺陷样本判断归类。常用方法有: 基于贝叶斯理论的分类模型, 支持向量机 (SVM)^[74], K 最邻近 (KNN) 分类算法及人工神经网络 (ANN) 分类。算法利用不同的核函数划分空间, 避免了样本空间维数过大的维数灾难。由于在解决工业中小样本、非线性的检测展现出较好的有效性和鲁棒性, 支持向量机是工业缺陷检测时最常用的分类器^[75, 76]。

传统视觉缺陷检测方法的运算规模简单, 算法结构较浅, 因此运算速度较快, 在目标形态固定、类间区分度较高、缺陷种类较少的简单场景下具有较好的效果。但该类算法需要人为确定提取特征, 严重依赖于算法设计者对当前检测目标特征的认知分析, 而人类难以完整地复杂高维的图像数据特征认知分析。因此, 检测对象和检测环境的细微变化、样本数量较小以及算法超参数调优均会影响算法的检测效果, 出现过拟合现象。更重要的是, 传统检测方法需要顺序分阶段执行不同算法完成定位和分类两项任务, 两项结果相互影响, 最终的检测效果受到的干扰因素较多。这类方法仅适用于缺陷目标特征单一, 图像环境较为单一的情况。

1.3.2 基于深度学习分类网络的检测方法

卷积神经网络 (CNN) 的不断发展在图像分类领域展现出巨大的优势。CNN 网络模型可以直接实现特征提取到分类的处理过程, 避免了人工设计复杂的提取规则, 克服了特征提取、分析时的认知偏差, 并且提高系统在缺陷分类时的泛化性。因此, 视觉缺陷检测技术通过传统缺陷分割方法或者滑窗法对缺陷区域进行定位, 之后利用 CNN 网络完成定位区域图像的特征提取和缺陷类别判断。常规的 CNN 网络结构有卷积层和池化层不断重复叠加组合实现图像特征的抽象提取, 最后进入全连接层将特征图降维映射到样本标记空间, 完成分类预测, CNN 网络结构如图 1-2 所示。




图 1-2 LeNET CNN 的结构示意图

通过不断的加深卷积层和池化层的网络深度，能够更有效更全面的提取图像特征，在 LeNET^[77] CNN 结构的基础上，众多研究者又设计出分类问题基础卷积网络 VGG16 和 VGG19 模型^[78]，识别性能较高的 Inception 模型^[79]。当网络深度达到一定程度时，会产生梯度消失现象导致网络深度和检测性能无法呈现正相关性。在 2015 年，何凯明等引入残差结构，设计了 ResNet 模型^[80]解决了梯度消失问题。通过与 Inception 结构结合，推出的 Inception-ResNet^[81]模型在图像分类任务中的模型性能不断提高。在此基础上，不断出现的 CNN 模型以其优越的识别性能，为 CNN 模型的工业应用奠定了基础。Liu 等人^[82]使用双 CNN 模型融合框架对铝型材中的缺陷进行分类。Zhong 等人^[83]在铁轨的表面检测中结合霍夫变换和 CNN 结构，实现缺陷的识别。Duan 等人^[84]基于 CNN 网络对原始 RGB 图像和 Sobel 算子生成的梯度图像提取特征，利用小波变换融合策略实现两个特征融合，输入支持向量机分类器进行铝型材表面缺陷分类识别。Sison 等人^[56]针对覆铜板表面缺陷，通过 Sobel 边缘滤波器和二进制阈值来提取感兴趣区域，之后建立卷积神经网络结构学习缺陷的局部特征和背景纹理实现缺陷检测。Gao 等人^[85]引入了三级高斯金字塔生成缺陷的多级信息，增加模型训练样本。建立三个 VGG16 网络对三级图像提取特征、输出融合得到钢板缺陷识别结果。Liang 等人^[86]提出了一种基于掩模梯度响应的阈值分割方法（MGRTS），将 MGRTS 和高斯差分（DOG）相结合可以有效地从掩模梯度响应图中提取各种缺陷。并采用数据增强技术和焦点损失对 Inception-v3 网络进行训练，克服铝锭表面缺陷检测分类不平衡问题，提高分类精度。He 等人^[87]将 CNN 模型中各层特征图进行融合，实现基于多层级融合特征的钢铁表面检测。Song 等人^[88]基于小波变换的散射卷积网络（SCN）来提高对局部和线性变形的容忍能力，实现热轧带钢表面缺陷检测。Cha 和 Choi^[89]利用深层 CNN 网络检测钢板表面的裂缝。Song 等人^[90]通过混淆深层 CNN 和主干网络提取特征，实现对金属表面弱划痕的精确检测。

CNN 分类网络需要预先载入大规模数据集的预训练权重，但是在铝板带等

金属带材的表面缺陷特征往往与大规模数据相差较大,因此部分缺陷检测方法通过对 CNN 网络的优化解决领域转移的问题。Zhang 等人^[91]通过结合域自适应 (DA) 和自适应卷积神经网络 (ACNN) 实现钢表面缺陷检测的跨域和跨任务识别。Shi 等人^[92]基于中心的迁移特征学习和分类器自适应方法 (CTFLCA) 实现钢板表面缺陷识别。

由于 CNN 模型中卷积结构对图像特征提取的良好效果,逐渐发展的自编码器网络、循环神经网络以及 Transformer 结构均通过与 CNN 模型结合,实现更准确的分类效果^[93]。Transformer 结构只需要根据学习获得重要性的空间位置,改变了 CNN 模型对图像中每个位置的学习注意力相同的弊端。但是自编码器网络、循环神经网络以及 Transformer 结构主要针对与图像分割、语言处理等领域,应用于缺陷检测任务时对处理硬件和数据计算速度的要求较高,其适用范围较小。如 Li 等人^[94]融合了 CNN 和 Transformer 编码器对带钢表面缺陷进行特征提取,并使用多层感知器分类器进行缺陷分类。Liu 等人^[95]通过循环神经网络结构对 CNN 模型提取的缺陷特征进行融合,实现焊接缺陷检测。Yun 等人^[96]提出了基于变分自编码器的 CNN 网络模型,通过变分自编码器实现数据增强提高缺陷检测模型的泛化能力。Di 等人^[97]提出了一种基于自动编码器和生成对抗网络 (GAN) 的半监督学习方法来对钢材表面缺陷进行分类。Gao 等人^[98]提出了一种 PLCNN 的半监督深度学习方法,通过 Pseudo-label 改进的卷积神经网络对钢材表面缺陷进行识别。赵等人^[99]基于 LBP 特征结合 GAN 和自动编码器 (AE) 检测表面缺陷的纹理特征。梅等人^[100]利用卷积去噪 AE 网络重建图像,训练网络学习以获得最终检测结果。Chen 等人^[101]通过在 CNN 网络残差结构中嵌入深度自注意力机制,实现在混合噪声条件下铝型材表面缺陷的高精度识别。

随着 GAN 等半监督学习的发展,通过数据增强的手段降低深度学习的训练难度,可扩大和提高在深度学习相关算法在缺陷检测领域的应用范围和检测精度。Jain 等人^[102]通过 GAN 和 CNN 架构的结合,显著提高了 CNN 网络对热轧钢板表面缺陷的分类性能。Zhang 等人^[103]提出了一种增量双网络检测模型 (IDDM) 用于大型复杂产品外观的高效、高精度检测。Gao^[104]等人为解决钢板背景纹理对缺陷检测精度的影响,提出了一种基于特征对齐的 CNN 分类网络。Luo 等人^[105]针对主动水滴跟踪和细粒度图像的渐进式递归生成对抗网络 (PReGAN),以减小板面上清洗残留的水滴用于缺陷检测方法效果的干扰。Zhou 等人^[106]提出一种端到端密集注意力引导级联网络 (DACNet) 来检测带钢表面的显著物体

基于深度学习分类网络的检测方法使用卷积神经网络提取缺陷特征,避免

了人工提取特征的局限性，当缺陷种类较多且类间区分度较小时，具有较好的检测效果，适用于检测对象的尺寸较小，无需精确定位的场景下。这类方法不仅能充分提取到缺陷的深层特征信息可以应对较为复杂的工业检测环境和变化的检测对象，而且模型结构较为简单，相对于大型检测网络可以缩短模型训练时间和检测过程。但是仍需要将 CNN 模型与基于传统图像处理方法并行使用，无法满足现场端到端的检测需求，在一定程度上损失了 CNN 网络的智能性和概括性。

1.3.3 基于深度学习框架的目标检测方法

随着深度学习方法的不断发展，目标检测方法通过多种 CNN 模块相互嵌套可以在一个网络架构中同时完成缺陷特征的提取、分类和定位，实现输入图像的端到端检测，简化了缺陷检测的流程并且减少了人工经验介入模型训练产生的影响^[107]，同时，提高了目标检测算法的检测速度和检测精度，具有一定的鲁棒性和可移植性。2014 年，R.Girshick 等人^[108]提出了 R-CNN 目标检测算法，利用选择性搜索（Selective Search）寻找到可能出现目标的目标候选框，将调整后的图像候选框输入 CNN 网络提取目标特征。之后利用线性 SVM 分类器对每个目标候选框的目标类别进行预测。R CNN 模型极大的提升了目标检测算法的检测精度，虽然模型内部依然进行了多次分阶段计算，导致训练时间较长，并且损失了系统连贯性。但是为后续目标检测算法的发展奠定了基础。

随着近几年的技术发展，在工业缺陷检测中目标检测算法由于同时实现定位和分类两个任务，逐渐被国内外的研究者进行研究和探索^[109, 110]。目前，常用于工业缺陷表面检测任务的目标检测算法主要分为三种方式：利用锚框的（Anchor-based）基于候选区域的两阶段目标检测方法，基于回归的单阶段检测方法和基于无锚框（Anchor-free）的检测方法。目标检测算法发展结构如图 1-3 所示。




图 1-3 目标检测算法的发展

(1) 基于候选区域的两阶段目标检测方法, 通过 selective search, 区域候选框生成网络 (Region Proposal Networks, RPN) 等方法生成候选区域确定缺陷位置候选框区域 (region proposal), 再通过卷积网络提取候选框中疑似缺陷的深层次语义特征进行分类, 如 R-CNN^[108], Fast R-CNN^[111], Faster R-CNN^[112], Mask R-CNN^[113], Cascade R-CNN^[114]。目前, Faster R-CNN 算法由于较高的检测精度被大量应用在金属带材的表面缺陷检测中。首先, 通过 CNN 网络提取缺陷图像特征信息, 即特征图 (feature maps)。之后, 经过 Region Proposal Networks (RPN) 网络获得目标候选区域 (proposals)。然后, 输出的特征图与目标候选区域结合, 提取到候选区域特征图 (proposal feature maps)。最后, 利用 proposal feature maps 计算缺陷的类别, 并通过边界框 (bounding box) 回归得到缺陷区域的精确坐标和大小。He 等人^[87]基于 Faster R-CNN 在骨干网络中增加多级特征融合网络 (MFN) 实现多阶段分层特征的融合, 使二阶段目标检测方法在钢板表面缺陷的检测精度提升。Ren 等人^[115]对 Faster R-CNN 中用于特征提取的卷积层进行改进提高了网络速度, 并且加入中心损失以提高网络区分不同类型缺陷的能力。Wei 等人^[116]针对铝型材表面 10 类缺陷在 Faster R-CNN 算法中加入了基于 FPN 的特征融合思想, 以提高缺陷检测性能。Chen 等人^[117]基于 Faster R-CNN 检测框架, 通过可变形卷积和特征金字塔结构实现铝合金表面缺陷的自动化检测。Liu 等人^[118]提出基于多尺度上下文的缺陷检测模块 (MSC-DNet), 可对缺陷的位置进行精确定位, 并对表面缺陷的特定类别进行分类。同时, 也满足了多尺度缺陷检测任务对准实时性要求。Tang 等人^[119]在 Faster R-CNN 结构的基础上, 利用 Swin Transformer 提取钢带表面缺陷特征, 并构建多尺度特征融合结构实现缺陷的分类和定位。Liu 等人^[120]在 Faster R-CNN 主干网络的残差结构中植入可变形卷积和级联检测头, 缓解了高精度、大尺寸的钢板表面缺陷难以准确定位的问题。Wei 等人基于 Faster R-CNN 框架, 通过增加四层级特征融合结构和 15 个 anchor box 设置, 实现铝型材表面缺陷的自适应检测。

两阶段目标检测方法的候选框生成模块能够很好的定位缺陷位置减小了分类错误的概率。并且使用深层卷积结构提取特征, 避免了在背景干扰、类内差异和类间相似三个因素下复杂环境和多变缺陷特征对检测的影响。因此检测精度较高满足工业检测端到端的需求, 并且克服了样本不平衡对结果的影响。但是候选模块的加入增加了模型的规模和计算量从而使检测速度较低, 训练所花费的时间较多。

(2) 基于回归的单阶段检测方法, 主要是利用回归原理直接在网络中提取特征, 对特征图划分网格 (cell) 结合 anchor box 组来预测物体分类和位置。单

阶段方法的网络结构较简单,检测速度较快,主要被用于对于实时性要求较高的缺陷检测场景,但是精度难以保证,如 SSD^[121],YOLO 系列^[122-124],SqueezeDet^[125]。随着 YOLO 框架的不断升级更新,通过使用残差结构、多特征融合、非极大值抑制等方式,使其检测精度和检测速度不断提高。因此,对于 YOLO 系列方法的研究也在不断增多,被应用于工业检测或其他实时性较高的目标检测中^[126, 127]。如 Kou 等人^[128]基于 YOLOv3 利用无锚特征选择机制和密集卷积块,设计了端到端钢板缺陷检测模型。Li 等人^[129]改进 YOLO 算法,通过全卷积网络预测缺陷区域的类别、位置和大小信息,实现钢带表面缺陷检测端到端的解决方案。

随着 YOLO 等单阶段算法的成熟应用,研究重点逐渐分为对精度的提升和对速度的两个方向。在精度方面,如 Cheng 等人^[130]设计了具有差异通道注意力和自适应空间特征融合的 RetinaNet 网络,用于钢铁表面缺陷检测。Xu 等人^[131]通过改进 YOLOv3,将浅层特征与深层特征跳跃连接,增加对铝型材表面微小缺陷的检测敏感度。Ikechukwu 等人^[132]为解决热轧钢表面缺陷精度低、鲁棒性有限的问题,基于 YOLO v3 增加多尺度结构,实现热轧钢带表面缺陷检测的工业需求。Li 等人^[133]提出一种基于改进型 YOLOv5 和优化型 Inception-ResnetV2 的两阶段工业缺陷检测框架,第一阶段利用 YOLO 进行微小缺陷的定位,第二阶段采用融入注意力机制的 CNN 分类网络更好的提取特征进行分类。该方法在工业环境中的精度达到了 91.0%。Wen 等人^[134]提出一种基于多尺度多注意力的细粒度 SSD 表面缺陷检测方法,提高工业检测中对于微小缺陷的检测精度。Wang 等人^[135]设计 PE-Neck 结构代替 YOLOv5 中的原融合结构,以增强模型在不同尺度上提取和定位缺陷的能力,并且使用 Multi-StreamNet 提高模型识别分布式随机缺陷的能力。解决铝型材表面缺陷分布随机、差异大的问题。

在速度方面,由于只需要一个端到端的网络结构,计算量降低,检测速度较快。针对特征图的 Cell 进行预测可以更好的利用图像的全局特征,较少结果中出现假阳性,但是也会导致对小物体的检测效果下降。如 Li 等人^[136]提出了一种快速的表面缺陷检测方法,采用 SSD 网络结合 MobileNet 来识别表面缺陷的类型和位置。Yang 等人^[137]提出了一种基于 SSD 和速度模型的微小零件实时缺陷检测算法。Qi 等人^[138]提出了一种 MYOLOv3-Tiny 检测模型,用于铁路轨道结构扣件的实时检测。Chen 等人^[139]提出一种基于可变形卷积与注意力机制(DCAM-Net)的带钢表面缺陷快速检测网络,通过增强变形特征提取块和协调注意力模块保证模块提高 YOLO 网络缺陷检测精度,并有效提高了带钢表面缺陷的检测效率。Hu 等人^[140]在 YOLOv5 网络结构中嵌入具有自注意力机制的 Transformer 结构增强高级特征的表达能力,提高钢轨表面缺陷的检测精度和速

度。

随着 YOLO 系列模型的不断更新与优化, YOLOv1 和 YOLOv2 算法的单尺度结构已经难以满足目标密集、尺寸变化较大的铝板带缺陷检测要求。而 YOLOv3 通过多尺度结构设计, 解决了对于尺度变化较大的多目标漏检率高的问题; 同时, 通过对应锚框 (Anchor box) 的分组设定, 实现了不同感受野尺寸各异目标的独立预测, 使检测性能有了大幅度的提升。之后, YOLO 模型形成了以 YOLOv3 为基础的稳定结构和分组解码的预测设定, 并根据不同的任务需求逐渐优化精度、提升速度, 衍生出了 YOLOv4 至 YOLOv8 模型^[141-143]可针对不同检测目标。YOLOv3 仅包含下采样过程对于不同层级特征的融合程度较差, 当缺陷目标较密集时的漏检情况较严重。YOLOv5 及后续的 YOLOv7、YOLOv8 均是针对于移动嵌入式设备, 侧重于对检测速度的优化而损失了部分检测精度。而 YOLOv4 模型在 YOLOv3 各模块结构的基础上增加了上采样的融合结构, 该结构在后续算法中依然起到了重要的精度提升作用。而沿用 YOLOv3 主干结构并增加残差结构, 可有效的强化模型的特征学习能力, 移除计算瓶颈。YOLOv4 框架作为 YOLO 系列中功能结构最完整的网络, 更适合于对检测准确度要求较高的复杂工业场景的缺陷检测。

(3) 基于 Anchor-free 的检测方法, 摆脱了 anchor 对模型生成目标预测框的影响, 通过检测物体中心点或者关键点的信息来生成缺陷区域并对分类预测, 如 CenterNet, FCOS^[144, 145]。这类方法避免了 anchor 中超参数对模型泛化性的影响以及不断的进行 IoU 计算带来的计算量增加。但是检测结果也变得不稳定, 需要更多的方法去控制算法的鲁棒性。由于 Anchor-free 方法摆脱了 anchor 的不准确定义对检测精度的影响, 也逐渐从日常物体检测推广到缺陷检测中。如 Tian 等人基于 CenterNet 提出了具有扩张特征增强模型、中心权重和 CIoU 损失的 DCC-CenterNet, 以实现钢板检测的速度-准确度平衡。Yu 等人^[146]提出了一种通道注意力和双向特征融合的全卷积单阶段 (CABF-FCOS) 网络以实现快速有效的缺陷检测。Shi 等人^[147]提出一种针对极端尺寸缺陷的 FCOS 检测方法, 通过自适应中心采样和损失函数优化等手段, 减小细长缺陷的漏检和误检问题。这种方法虽然可以避免设定的 Anchor box 尺寸设置的局限性, 增强自适应能力, 但是过于依赖卷积网络所提取的热力信息指导。对于极端尺寸居多的且分布较密集的工业缺陷检测效果并不理想。

1.4 铝板带表面缺陷工业检测存在的问题

基于深度学习的目标检测方法具有快速稳定的检测性能且无主观因素干预检测过程的特征提取和定位预测, 依然是工业缺陷检测最好的发展方向。但是

目前基于深度学习的缺陷检测方法依然存在以下几个问题,限制了其在工业质量检测领域的应用和发展:

(1) 缺乏完善的铝板带表面缺陷图片数据集。

铝板带表面缺陷检测系统高效、高精度的检测性能依赖于核心图像处理算法和缺陷识别算法的计算速度和检测准确度。无论是基于图像处理的传统检测方法还是基于深度学习的智能检测方法,均需要利用大量实际检测环境下的真实缺陷样本通过参数调试和模型训练从中提取、分析特征信息。目前,缺乏可用于实验研究和算法开发的实际工业现场的铝板带缺陷公开数据集,大部分研究工作只能先采用其他具有相似特质的公开数据集完成前期的算法开发和模型训练、调试,如钢板、铝型材等检测对象。之后,通过系统在产线试运行过程中收集的缺陷样本对模型进行参数微调。这种算法开发模式,一方面,由于公开数据集样本与实际检测对象的贴合程度不一致,缺陷形貌、类型和特征也不一致,学习到的模型权重无法衡量是否能够适合于真实检测对象;另一方面,公开数据集中样本均是经过筛选和处理的具有代表性且各项特征分布均衡的数据,其采集质量和特征分布情况远远好于实际检测场景。因此,考虑实际工程应用背景,围绕精整生产线所生产的铝板带产品,构建专用表面缺陷数据库是非常有必要的,可为后续检测问题研究、检测算法设计、性能提升提供有效的数据支撑。

(2) 工业缺陷数据收集难度大制约深度学习模型的应用效果。

深度学习检测方法良好的检测效果依赖于多样化、大规模、高区分度的训练样本,以确保模型在训练中可以学习到足够多且有代表性的特征信息,从而掌握各类别缺陷特征的分布规律。然而,在实际的工程应用中,深度学习检测方法对于铝板带表面缺陷的检测效果却并不理想。一方面,工业真实数据的收集难度大。工业生产中缺陷的出现属于小概率事件且不同缺陷的出现频率变化较大,无论从样本特征的信息多样性还是样本丰富性上都难以保证模型训练的需求,从而影响检测效果;另一方面,模型所需大规模样本的标注难度大、耗时长。铝板带生产环境和生产过程造成的采集图像成像质量不佳或伪缺陷背景干扰,以及缺陷形态特征的类内离散和类间一致等多种原因使得数据标注难度较大,低质量的标注容易误导模型的训练,影响检测效果。如何仅使用少量的训练样本获得良好检测效果,是消除深度学习缺陷检测方法工业应用限制的重要问题。

结合少样本学习技术在小规模样本分类中的良好表现,通过将其中特征区分方法的学习能力植入目标检测算法,实现对新类别缺陷仅通过少量样本就可快速达到良好的识别和定位效果。在实际生产中,当检测设备面对不同产品型

号、不同生产工艺、不同尺寸规格的检测目标时，可快速实现模型更新升级以适应新的生产场景变化，提升检测系统的灵活度和可移植性。

(3) 多缺陷密集目标的相互遮挡导致实际检测过程中漏检现象严重。

以 YOLO 为代表的单阶段方法，其基于回归的预测框生成方式要求图像成像质量较高并且缺陷目标不受其他因素的干扰外观呈现形态独立、完整。而铝板带连续性的生产特点，产线中多个工序连续操作导致位于尾部的检测工位处出现上游不同工序产生缺陷间相互交叠、遮挡以及反光、水渍油渍等伪缺陷干扰的现象。遮挡现象的出现不仅破坏了原本缺陷特征的清晰表达，并且改变了不同类型缺陷的特征信息分布形式，干扰模型对于缺陷主体与背景的区分，从而导致 YOLO 的漏检和定位偏差更加严重。而图像中环境光源以及清洁不彻底的油渍水渍等干扰因素则会导致误检现象的出现。

通过分析 YOLO 方法的预测框生成原理，一方面，从全局特征的范围扩大和局部特征的强化，增强遮挡缺陷的信息提取能力；另一方面，从预测框筛选标准的角度，提高重叠预测框间的区分能力。探索一种对密集遮挡条件下缺陷检测方法，解决目前铝板带表面检测系统出现的漏检、误检问题，提升检测系统检测性能，降低目前视觉检测系统对于适用对象、检测环境及应用场景的要求。

(4) 系统检测时间与检测精度难以同时保证。

由于宽幅铝板带的连续性和高速化生产特点，要求检测系统具有实时计算处理连续图像数据流的能力以保证对生产状况的实时反馈和预警。基于深度学习的缺陷检测方法其检测性能的可靠性和泛化性依赖于庞大的网络规模和复杂的网络结构。虽然不断组合、重复的卷积运算可以提高缺陷特征的抓取能力，但是也极大的增加了网络的运算参数量和内存消耗。这导致了基于深度学习的缺陷检测系统的检测精度越高检测速度越慢。如何在保证深度学习检测方法良好检测性能的同时，充分压缩网络规模以保证检测实时性和数据传输稳定性，是深度学习检测方法从实验研究转向工业应用的最基本的问题。

借鉴轻量化卷积操作可有效减少计算参数量的特点，探索一种采用轻量化卷积的网络结构并与目前的 YOLO 框架结合，以缩减 YOLO 网络规模。但是轻量化的网络势必会造成特征信息的损失，从而降低 YOLO 框架原本的检测性能。通过强化特征等小规模优化方法在不大量增加网络规模的前提下，弥补轻量化卷积损失的特征信息，最终实现缺陷检测系统速度和精度的提升。

(5) 铝板带表面缺陷形貌变化范围较大。

铝板带带幅尺寸范围通常在 300mm-3000mm 之间，尤其对于宽幅大尺寸对象，同一幅采集图像中缺陷目标形成机理和种类的不同呈现出的区域像素面积

往往相差几个数量级。高端铝板带产品表面出现的微小缺陷，其尺寸仅在 0.5 到 1mm 之间；而连续的条状缺陷其尺寸规格往往随着铝板带和辊轴的不断接触、摩擦长达几米。高精度的检测要求导致系统需要对出现的微小缺陷保持较高的检测灵敏度。但是微小缺陷反应在图像中的像素表达仅仅几个像素点大小。并随着深度学习的检测方法不断的卷积、池化操作，损失了微小缺陷的特征信息，导致小缺陷目标的识别率较低，无法达到高精度表面要求的检测分辨率大小。

考虑到铝板带表面缺陷的工业检测场景中，缺陷目标具有尺寸变化大、目标分布密度变化大、类间相似度高和类内差异度大等特点，以及检测准确度高、漏检率低和检测速度快的检测要求。结合上述 YOLO 系列中不同结构的特点及优势，权衡项目实施企业的检测要求，本文利用 YOLOv4 框架作为铝板带表面缺陷检测任务的基本结构，通过 YOLOv4 完整模型所具有的强大提取、分析能力和计算处理结构具有的快速、高效的检测效率，开展后续问题的研究。

1.5 本文研究内容以及论文结构

针对上述亟待解决的问题，本文的主要研究目标是设计一种适用于宽幅铝板生产的工业视觉实时检测系统。围绕少样本条件、遮挡目标和模型轻量化等主题，通过基于 YOLO 基本检测框架的改进优化以解决检测系统在真实生产条件下检测精度与检测速度无法平衡的矛盾。本文主要研究内容如下：

（1）设计面向工业场景的铝板带表面缺陷端到端实时检测方法，并通过对原始数据的自动化筛选、标注、裁剪构建符合深度学习网络训练要求的铝板带表面缺陷数据库。（2）针对工业数据样本稀缺和特征分布不均衡问题，提出一种基于元学习的端到端少样本缺陷检测方法，克服工业缺陷数据稀缺时 YOLO 模型过拟合导致的检测准确度下降。（3）针对多工序缺陷相互交叠遮挡的复杂检测场景，提出一种基于上下文信息和斥力损失的多层级遮挡缺陷检测方法，缓解面对密集遮挡目标时 YOLO 方法因特征信息干扰造成的漏检、误分现象。（4）针对缺陷检测方法大规模、高精度与小型化、高效率的矛盾，提出一种嵌入并行注意力机制的卷积轻量化缺陷检测方法，在保证 YOLO 算法检测精度的基础上，压缩网络规模加快检测速度。（5）结合精整产线和检测需求，设计铝板带表面缺陷检测系统和可视化交互客户端，实现实际生产场景下本文研究方法的工业化应用。

论文的章节结构如下：

（1）第一章，绪论。介绍了本文的研究背景和意义。简要介绍了金属带材缺陷检测系统的发展历程和国内外应用现状，对目前金属带材表面缺陷视觉检

测方法的研究现状进行了梳理、总结。围绕目前铝板带表面缺陷视觉检测存在的问题进行分析,并概述本文的主要研究内容和文章结构安排。

(2) 第二章,铝板带表面缺陷端到端视觉检测方法与缺陷图片库构建。介绍了有色金属加工行业中铝合金板带材的生产流程和检测场景基本情况;根据实际生产调研和技术交流,分析总结常见铝板带表面端到端检测方法优缺点;根据铝板带表面缺陷的形貌特点和端到端检测技术难点,提出基于 YOLO 框架的铝板带表面缺陷检测方法并制定端到端检测流程;设计标准生产背景模板筛选缺陷图像,并结合人工标注信息建立铝板带表面缺陷数据库。

(3) 第三章,少样本条件下的特征再加权 YOLOv4 缺陷检测方法。首先详细介绍了有关少样本问题的定义以及少样本目标检测方法的相关概念和原理;结合铝板带检测特点提出本章所提模型的网络框架,并分别对元特征提取模块、多尺度特征融合模块、特征再加权模块以及多尺度预测模块进行详细说明;针对铝板带表面缺陷尺寸特点,通过自适应线性缩放 anchor box 计算方法,获得合适的 anchor box 用于后续模型训练;根据少样本学习特点,构建适用于网络模型训练的少样本数据集以及结合预训练和微调的训练策略和评价标准;通过检测结果和多项对比实验,展示本章检测模型在新类和基类缺陷的优越的检测性能,并研究了少样本数量的变化对模型检测精度的影响趋势。

(4) 第四章,结合上下文信息和斥力损失的 YOLO 抗遮挡缺陷检测方法。首先详细介绍了缺陷检测中遮挡目标的相关概念和遮挡缺陷检测的难点问题和解决方法;提出本章所提模型的网络框架,并分别对上下文信息骨干网络、多层级融合结构和改进的斥力损失函数及筛选机制进行详细说明;构建基于遮挡问题的缺陷检测数据集、评价标准,并且验证模型训练的超参数设计;通过消融和对比实验,验证本章方法可以提升在不同遮挡等级的检测效果,其漏检率远低于其他常规目标检测方法。


(5) 第五章,融入注意力机制的 YOLO 网络轻量化与铝板带表面缺陷检测。首先详细介绍了基于低冗余卷积结构的轻量化技术;提出了基于 Ghost 和并行通道注意力机制的轻量化主干网络用于提取缺陷特征;结合 Pixelshuffle 和 Passthrough 采样方式,提出轻量化特征融合网络丰富特征信息的基础上进一步压缩网络规模;引入 Focal loss 缓解样本不均衡导致的过拟合问题;根据对训练策略和超参数的研究,展示了轻量化网络在缩短模型收敛时间上的优越性;通过对其他轻量化技术、不同注意力机制和其他目标检测网络框架的对比实验,验证了本章轻量化方法在检测速度与检测精度之间取得了良好的平衡。

(6) 第六章,面向精整线铝板带表面缺陷检测系统设计及工程应用。首先,对所设计的铝板带表面缺陷检测系统的生产设备、安装需求及系统需具备

的功能进行详细介绍；针对检测系统总体结构和相关配置进行说明，并分别介绍了检测系统的硬件部分和软件流程，以及对所设计的可视化交互客户端的功能进行说明；结合上述研究模型和系统结构，对检测系统进行调试和验证。

（7）第七章，总结与展望。对本文所开展的研究工作和创新点进行总结，并结合研究内容提出本文有待完善的研究内容，展望未来潜在的研究分方向。

本文研究思路与论文结构如图 1-4 所示。



第 2 章 铝板带表面缺陷端到端视觉检测方法与缺陷图片库构建

实际调研工业环境下铝板带生产状况，分析铝板带高速度、连续性的工艺特点，高精度、实时性的端到端检测需求，以及干扰因素多和对象较复杂的工业检测环境，从而制定适合于本文检测背景的端到端在线检测方案；研究铝板带表面缺陷类型及其形貌特征，分析其产生原因并围绕检测需求和生产背景，建立铝板带表面缺陷图片数据库，为基于深度学习的缺陷检测方法的模型训练和技术优化提供准确可靠的数据支撑。

2.1 工业场景下铝板带表面视觉检测特点及难点

2.1.1 铝板带生产工艺及检测环境特点

铝板带通常指厚度大于 0.20mm 的轧制薄片，作为重要的工业支柱性基础材料，其产量占铝制品总产量的 30%以上。图 2-1 展示了铝板带全生产流程中相关生产工序示意图，铝合金铸锭经“1+4”热连轧后形成的中厚板，通过高精度冷轧、精轧成形后形成符合产品性能与质量要求的冷轧铝卷。




图 2-1 铝板带生产工艺流程

为保证铝板带材产品表面品质、外观规格符合出厂质量要求，完成冷轧的铝卷在制成成品出厂之前需要经过精整工艺，获得平整度较高，尺寸规格较精确的铝板带材，其中包括开卷、切边、横切、清洗、烘干、拉弯矫直、质检、重卷包装等工序。精整工艺的主要目的是清洗铝板表面残留的轧制油污、铝屑异物，修整冷轧带材边缘毛刺并控制尺寸规格，以及消除材料内应力造成的板形缺陷。铝板带精整作为铝加工生产线的关键工序，70%的铝板带材在通过精

整后进入成品包装车间直接面对消费者。因而，精整通常也作为铝板带产品质量控制及检测的最后一关。铝加工企业通常在精整产线收卷前设置人工质检工序，但是受生理条件限制，人工目测难以满足现阶段宽幅铝板带生产的高速、高精度质检要求。采用视觉检测技术可以满足铝板带质量检测大视野、高精度、实时性的检测需求，提高产品质量可靠性和成品率，避免漏检、误检和主观经验等人为因素对结果一致性和稳定性的影响。

不同于零件表面缺陷检测或产品结构检测等其他工业视觉检测技术，在工业环境下的宽幅高精铝板带视觉检测具有以下特点：

(1) 铝板带高速的生产速度以及连续的生产特性，导致图像采集端输出连续不断的图像流数据。视觉检测系统不仅需要具备对海量数据的快速处理、计算分析能力，并且需要数据的缓存要求、传输速度和现实反馈保持与图像信息源头较一致的响应速度。

(2) 同一产线所生产产品的表面形貌随着工艺程序、工况参数和原材料不断变化，相对应其板面的颜色、背景纹理等也随之产生一定程度的变化。视觉检测系统需要具备面向多种检测对象和多种检测环境的适应能力。

(3) 铝板带通过多组辊轴的不断旋转实现平稳移动，由于辊轴表面异物持续地接触摩擦造成连续性、周期性缺陷较多。大部分呈现为纵向线性缺陷和不同密度分布的区域性缺陷，这类缺陷往往尺寸规格变化较大且极端尺寸较多。因此，不同于常规缺陷检测对象，铝板带视觉检测系统主要针对于微小缺陷、条状缺陷及边缘特征不明显的区域缺陷的检测识别。同时由于板材幅面较大、检测精度较高等因素，缺陷往往仅为高分辨率图像中的极小部分区域。

(4) 铝合金材料的高反射性率容易引起局部或大面积的反光或阴影区域，导致缺陷特征无法清晰表达。此外，不同光照条件对铝板带的成像亮度有较大影响，破坏了原本成像系统的参数设定，使得缺陷与周围背景的对比度变低，特征的显著性下降，增加了缺陷目标的检测难度。

(5) 图像传输噪声、运行设备振动等原因造成图像成像质量的一致性受影响，并且轧辊转速微差、轧制速度变化、板带张紧力等容易引起图像随机畸变。

(6) 铝板带表面残留的油污、水渍覆盖在缺陷目标或破坏背景纹理的表达，干扰算法对缺陷特征的学习和判断，增加了缺陷检测难度并引起漏检、误检的产生。

2.1.2 端到端检测需求及技术难点

根据上述特点，为实现铝板带表面缺陷的实时在线检测，要求检测系统能够端到端对不同干扰环境下缺陷目标的准确位置进行标记，类别信息进行判

断、分级统计。

工业检测中端到端是指输入原始采集图像，输出最终预测结果，无人工干预中间检测过程、不破坏或提取中间特征数据。端到端视觉检测，一方面，不需要足够的经验去设计特征提取网络，缺陷特征可以被自动的学习并实现区分。当面对较大数量和较多类型时，网络对特征的提取和学习越充分，使高维的缺陷特征可以更充分的保留。因此，端到端的检测具有更好的可移植性和自适应性，能够面对更多的场景变化；另一方面，端到端检测中统一的网络结构，避免了分阶段数据传递的延时和转换时间，提高了网络的运行速度。端到端的检测更适合于对检测效率有较高要求的实时检测场景。

面向铝板带材工业检测场景的表面缺陷检测任务需要保证稳定性、检测性能与检测速度之间达到良好的平衡。

(1) 稳定性：检测对象规格及类型、光照条件以及工艺参数发生变化均会导致采集图像的亮度、背景、纹理等信息发生相应的变化。同时，生产设备振动、板形异常、电子元件的电磁影响、数据传输等因素会造成表成像质量的不理想。铝板带检测任务需要在检测场景发生一定程度变化时，能够自动适应并保持稳定运行。输出结果不受影响，具有一致性。

(2) 检测性能：铝板带缺陷产生原因的多样性导致其形态变化具有复杂性和不可预测性。缺陷的尺度差异、类间相似度和类内差异度等因素均会影响缺陷特征的学习难度，从而影响检测性能。检测性能反映为检测精度和检出率，是指检测过程中缺陷目标被正确分类的比例和被检出的比例。铝板带工业检测要求检出率需满足企业生产标准，分类精度尽量高以实现产品质量分级需求。同时，铝板带的缺陷检测任务不仅需要实现缺陷的识别和位置判断，更为重要的是需要准确的定位缺陷在整个铝卷的位置信息。产线所生产铝卷的幅宽在 500-2620mm 之间，长度为 4000m 左右。检测系统需结合图像和传感器信号准确的计算缺陷在铝板中的位置信息和区域大小。特别是，对高精铝板中的微小缺陷和区域类缺陷的准确定位。

(3) 检测速度：铝板带在正常生产时的运行速度在 10-70m/min 之间，检测系统需要保证检测结果的实时反馈，因此，端到端检测算法的设计需要满足最高运行速度，并保留一定余量防止图像流的积压导致数据丢失。

2.2 基于 YOLO 框架的铝板带表面缺陷端到端视觉缺陷检测方法

2.2.1 铝板带表面缺陷的端到端检测方法

为实现工业检测场景下的端到端检测需求并解决缺陷区域定位问题和快速结果反馈等难点问题，目前针对工业实时视觉的端到端质量检测主要分为，利

用图像处理和机器学习的传统检测方法和基于卷积神经网络的端到端目标检测算法。

（1）传统目标检测方法

传统的端到端目标检测方法主要利用统计知识对人工设计、提取的特征进行分析判断并结合滑动窗口进行缺陷区域的定位。传统检测方法的本质依然是对于滑动窗口所选择到的小图像进行分类，从检测速度上看，由于分阶段的算法计算和滑动窗口的遍历，参与运算量巨大，难以实现实时检测要求；缺陷目标的定位准确度与滑动窗口的形状有关，而铝板带缺陷的几何尺寸各异，大小差异大，极端尺寸较多，难以使用固定的滑窗尺寸准确计算缺陷区域。并且滑窗所选择的小图像的分类需要保证图像中仅包含一个缺陷目标，不适用于本文铝板带上密集分布的缺陷检测场景；从分类准确度衡量，其特征的提取依赖于算法设计者的先验知识，难以全面覆盖较为复杂的铝板带表面缺陷的形状和区域性缺陷。因此，传统的根据特定对象设置参数的分阶段视觉检测方法已经不能满足现阶段的检测任务对于精度、定位和速度的要求。

（2）基于卷积神经网络的端到端目标检测算法

深度学习的端到端目标检测算法不仅通过嵌套的 CNN 网络自主的提取缺陷的不同层级特征，并且设计了 anchor box 或 ROI 等用于缺陷区域定位的网络结构或计算方法，使针对图像的缺陷检测过程不需要人工经验干预，简化了检测流程的同时加快了分析过程。多层级特征信息的充分提取使网络对于缺陷特征的分析更加充分，检测的精度和泛化性有了明显的提升。嵌入模型中的定位方法设计，共享了所提取的特征信息，使缺陷区域的提取更加准确和快速，减少了滑窗遍历的重复计算。目前主要分为 Anchor free 目标检测方法和 Anchor box 目标检测方法。

采用预设的关键点或寻找目标中心点进一步回归目标边界框的 Anchor free 目标检测方法，虽然可以避免设定的 Anchor box 无法完全覆盖目标形状的弊端，使检测方法的自适应能力更强，但是过于依赖卷积网络所提取的热力信息。对于本文的铝板带检测对象，如具有极端尺寸且类间相似度较高的条状缺陷和微小尺寸且呈聚集状态的区域性缺陷，检测效果并不理想。

对比 Anchor free 目标检测方法，基于 Anchor box 的检测方法以预先设定的预定义边界框为基础，可预测不同尺度的多个检测目标。主要分为两阶段检测方法和单阶段检测方法。以 Faster R-CNN 为代表的两阶段方法，通过对 CNN 主干网络和 RPN 候选框生成网络进行并行模型训练，使检测精度相比上述传统方法有了明显的提升。但是为了充分提取和分析缺陷特征以保证检测精度，其主干网络和候选框生成网络的模型规模较大，运行效率较低，导致无法满足工

业检测对实时性的要求。此外,经过前期实验验证,对于铝板带表面缺陷,Faster R-CNN 方法的漏检率较低,但是对于不同类别的分类误检率却较高,难以实现工业检测时对于质量分级的要求。特别是分布密度较小的区域型缺陷和微小尺寸的聚集性单独型缺陷。

相较于两阶段的检测方法,以 YOLO 为代表的单阶段检测方法通过一个 CNN 卷积网络提取特征后,利用特征图网格划分配合 Anchor box 进行目标的预测。由于不需要单独的区域提议网络,其检测速度优于 Faster R-CNN 算法,是目前应用于工业生产等要求实时检测的场景下的主流方法。检测速度的提升极易导致检测精度的损失,YOLOv1 和 YOLOv2 算法由于漏检率较高难以真正被用于铝板带的缺陷检测中。YOLOv3 通过多尺度结构设计,解决了 YOLO 算法对于尺度变化较大以及相邻目标漏检率过大的问题,检测性能有了大幅度的提升,并且检测范围逐渐扩大;同时,通过锚框(Anchor box)的分组预测设定,可全面覆盖不同感受野大小特征图所包含的尺寸各异的目标,实现对应层级检测目标的独立预测,进一步提高了微小尺寸缺陷的检出率。考虑到铝板带表面缺陷的工业检测场景中,缺陷目标具有尺寸变化大、目标分布密度变化大、类间相似度高和类内差异度大等特点,并且检测准确度高、漏检率低和检测速度快的检测要求,YOLO 框架的目标检测方法适合于工业环境下的端到端缺陷检测。

随着 YOLO 模型的不断优化和更新,具有类似多尺度结构的 YOLOv3、YOLOv4、YOLOv5 均可针对不同检测目标实现较高精度的检测。但是,根据相关研究^[148, 149]和铝板带表面检测的实际验证:YOLOv3 仅包含下采样过程对于不同层级特征的融合程度较差,当缺陷目标较密集时的漏检情况较严重;YOLOv5 框架的设计针对于嵌入式设备的应用,侧重于对检测速度的优化而忽略了检测精度。权衡工业检测环境下对于高速度、低漏检和高精度的检测要求,本文利用 YOLOv4 框架作为铝板带表面缺陷检测任务的基本结构,实现输入图像的缺陷特征提取、分类和定位的端到端检测过程。

2.2.2 YOLOv4 的基本框架

YOLO 方法作为代表性的单阶段目标检测方法,通过单独的端到端网络完成从原始图像的输入到物体位置和类别的输出的全部过程。多年来不断优化,其网络结构逐渐形成以主干网络(backbone),颈部网络(neck)和头部(head)三大模块串联组合的基本架构。Backbone 主干网络主要用于缺陷的全局形状特征、局部细节特征以及深层语义信息的提取。Neck 部分为特征融合部分,由于不同层级特征信息所反映的感受野大小不一,通过将不同层级特征图叠加、融合使特征图所含信息可以更合适的被表达。Head 部分作为预测部分,

对特征图信息进行解析后获得预测结果。

本文以 YOLOv4 作为基本框架，通过优化主干网络结构，激活函数和损失函数等多种手段组合，实现缺陷目标的端到端检测。其网络结构如图 2-2 所示。




图 2-2 YOLOv4 的网络结构

Backbone 部分：嵌入 CSPNet^[150]的主干网络 CSPDarknet53，主要由 CBM 单元和五个 CSP_Resblock 单元串联组成。CBM 单元包括卷积层，批量归一化层^[151]和 Mish 激活函数。Mish 激活函数如公式 2-1 所示：

$$y = x * \tanh(\ln(1 + \exp(x))) \quad (2-1)$$

CSP_Resblock 单元由 CBM 单元和多个堆叠的残差结构形成双路结构，将输入特征图的浅层特征分开提取，达到梯度联合差异最大化，避免不同层级重复学习梯度信息，增强网络学习能力的同时加快网络推理速度。

Neck 颈部网络由 SPP^[152]空间金字塔池化结构（Spatial pyramid pooling）、FPN^[153]特征金字塔结构和改进的 PANet（Path Aggregation Network）^[154]融合结构组成。通过对不同层级的特征图进行反复的局部特征和全局特征融合，丰富浅层特征的细节信息和深层特征的语义信息，对小目标的检测效果有明显的提升。SPP 结构将深层特征图通过三种最大池化（5×5，9×9，13×13）操作与原始特征图进行通道维度堆叠，增大网络感受野，分离显著特征。改进的 PANet 模块将上采样后的特征图与原位置特征图堆叠后经过多个 CBL 单元（卷积层、批量归一化层和 leaky-ReLU 激活函数）完成相互融合。自底向上和自顶向下的双向特征金字塔结构保留了更多的浅层位置特征以提高目标定位精度，并进一步提升深层语义特征的提取能力。

Head 头部网络，由 YOLO Head 单元及对应损失函数解析策略组成，通过

9 个 anchor box 解码到输入图像生成的网格中获得预测框并计算损失函数值进行类别预测和定位。其中 YOLO head 通过 3×3 和 1×1 卷积层控制输出特征图的尺寸与输入特征图保持一致，并利用 1×1 卷积控制输出特征图通道数为对应解析 anchor box 数量 $\times (5 + \text{目标类别数量})$ 。其中各组特征图对应 anchor box 数量为 3。5 表示先验框位置参数（中心坐标 x 、 y 、长度 w 和宽度 h ）和目标置信度。输出特征图维度结构示意图，如图 2-3 所示。




图 2-3 输出特征图维度结构

输出的特征图为 $(76 \times 76 \times 33)$ $(38 \times 38 \times 33)$ $(19 \times 19 \times 33)$ ，通过 anchor box 产生大量的预测候选框。设置相关的阈值条件和非极大值抑制 NMS 方法筛选出可能性最大的预测框和预测类别作为最终输出结果。

2.2.3 YOLO 框架的铝板带表面缺陷端到端全检测流程

由于高端铝板带视觉检测对精度和幅宽的要求，采集到的图像分辨率及形状大小不适合于直接输入上述目标检测算法进行计算，并且工业实时检测的连续图像流对算法的分析速度提出了较高的要求。

因此，需要在 YOLO 模型的基础上增加图像的前处理缓存策略和后处理实时显示和缺陷区域实际定位的功能，才能真正实现工业环境下的端到端检测。图 2-4 展示了基于 YOLO 框架的铝板带表面检测系统的端到端检测流程。通过工业相机获得原始采集图像后，依次顺序完成图像分割缓存、YOLO 缺陷检测、图像合并及缺陷区域定位、结果可视化显示等流程，实现原始图像输入及缺陷实际位置和类别信息输出的全封闭端到端检测过程。




图 2-4 铝板带表面检测系统图像检测流程

(1) 图像的缓存及切分

采集原始图像的分辨率为 I_x , I_y , 将图像切分为大小为 I_{sx} , I_{sy} 的相互重叠 r 的子图像子图像, 并按顺序缓存至处理单元存储区, 依次输入 YOLO 模型。图 2-5 为具体过程示意图。




图 2-5 铝板带表面图像切分缓存示意图

(2) 端到端的缺陷预测

由于卷积神经网络计算的输入要求, 将长宽一致的子图像输入缺陷检测模型, 避免直接输入原始采集图像会造成缺陷特征变形及微小缺陷的信息损失。YOLO 模型输出为第 i 幅图像的第 j 个子图像的检测结果向量 $O_{i,j} = \{x_{\min}, y_{\min}, x_{\max}, y_{\max}, cls\}$, 其中包含坐标信息和类别信息。根据公式 2-2 将基于子图像的缺陷位置信息进行合并获得最终缺陷区域的像素位置信息 P_x, P_y 。

$$\begin{cases} P_x = \left(\left(\frac{x_{\max}^j - x_{\min}^j}{2} \right) + j \times I_{sx} \right) - j \times r \\ P_y = \left(\frac{y_{\max}^j - y_{\min}^j}{2} \right) \end{cases}, j = 0, 1, \dots \quad (2-2)$$

(3) 缺陷区域的定位

由于 YOLO 模型所输出的预测信息仅为图像像素位置, 无法表示缺陷区域实际在铝卷中的位置。同时相机视场大于铝板带宽度, 需要提取到边缘位置才能获得铝板上横向实际位置信息。因此, 通过提取铝板边缘后, 结合分割图像缓存信息和编码器触发信号, 实现缺陷区域在实际铝带的准确定位。

根据铝板带的产品规格信息, 设定铝板带横向实际宽度为 w_s , 线性相机的横向分辨率为 r_w , 则缺陷区域的横向位置信息 D_x, D_y 可以表示为:

$$\begin{cases} D_x = (w_s / r_w) \times (P_x - e) \\ D_y = (w_s / r_w) \times (P_y + i \times I_{sy}) \end{cases}, i = 0, 1, \dots \quad (2-3)$$

式中, e 为铝板边缘像素位置。

2.3 铝板带表面缺陷类型及其图像特征

根据 GB/T26492.3—2011《变形铝及铝合金铸锭及加工产品缺陷第3部分: 板、带缺陷》^[155]中对于铝板带表面缺陷的定义, 并结合精整生产线中质量检测工序实际出现的缺陷, 本文将铝板带表面缺陷根据形成机理分为设备缺陷, 生产缺陷以及伪缺陷三类。设备缺陷主要是生产设备辊轴等相对运动的部件由于辊面受损、黏着杂质以及轧制过程的辊轴间受力不均、控制误差等问题产生的一些缺陷类型, 如辊印、划痕、波浪纹、压过划痕。生产类缺陷主要是在加工过程中由于外界杂质的残留或带入以及上游制造阶段造成的材质问题产生的一类缺陷, 如起皮、黑点、脏污、凹坑以及压入金属等。伪缺陷主要由外界杂质进入检测视野、轧制和清洗过程中残留的油污、油斑和水迹, 以及铝板带规格不同板面高低差造成的反光和环境光源影响产生光泽不均等问题, 使采集图像中出现异常干扰真正缺陷的检测, 但是这些缺陷并未对检测平面的质量产生影响, 因此定义为伪缺陷。

同一生产线上生产的产品通常具有不同精度或厚度，以及不同的加工工序和加工参数，并且其用途和使用领域不一样也对铝板带表面质量的检测需求各有差异。因此，基于上述缺陷形成原因，本文将精整生产线中出现的缺陷根据对于后续产品质量影响的严重程度划分为三个等级（致命/严重/一般），为后续检测系统提供不同的检测标准和需求。

（1）**致命缺陷**，指影响产品的关键特性，影响下游产品的使用寿命，造成使用者安全隐患或设备的运行故障等严重质量问题。包括裂边、金属压入、凹坑、起皮和波浪纹五类缺陷，其形貌特征及产生原因如下：

裂边（broken edge），表现为板带材边缘破裂，呈锯齿状，如图 2-6 所示。这类缺陷由于破坏了铝板带整体结构，容易造成断带等对下游产品安全的严重后果，属于致命缺陷级别。其产生的主要原因为：前期熔铸和轧制过程中的温度、应力等工艺参数控制不当，以及剪切和卷取时张力调整不合适产生的拉应力导致。




图 2-6 裂边

金属压入（roll-in metal），由于加工过程中金属屑或金属碎片压入板、带材表面导致铝板带表面出现大小不一的连续性凹陷，如图 2-7 所示。这类缺陷破坏了板带材表面的结构，对产品安全质量造成影响，属于致命缺陷。




图 2-7 金属压入

凹坑（pit）类特征的表现形式为板、带材表面单个且不规则分布的小面积

凹陷，且凹陷处表面不光滑，如图 2-8 所示。由于板带材表面金属层被破坏，影响产品安全质量，属于致命缺陷级别。其产生的主要原因是在卷取过程中异物卷入带卷，以及剪切时的铝屑等杂物未及时清理。




图 2-8 凹坑

起皮（peeling）是指板材表面的局部起层，其成层较薄，部分材料破裂翻起，如图 2-9 所示。这类缺陷对表面及内部材料的破坏性较大，严重影响下游工序及产品安全性能，属于致命缺陷等级。




图 2-9 起皮

波浪纹（wave），是指由于不均匀变形导致板带材边部产生的尺寸较小且通常呈圆形凹凸的波浪，如图 2-10 所示。主要原因是轧制过程中的辊型控制不合理，以及卷取张力不均匀所致。该类缺陷会对后续产品的质量产生影响，属于致命缺陷级别。




图 2-10 波浪纹

(2) **严重缺陷**，指在某些性能上无法达到规定要求，对下游工序造成影响并且可能会引起故障但可以进行修复，在产品外观上产生较大影响的造成用户投诉的质量问题。包括辊印、擦伤、压过划痕、黑点和脏污五类缺陷，其形貌特征及产生原因如下：

辊印 (dent)，表现为周期性的深浅粗细不同的凹陷或凸起，沿横向或纵向分布，如图 2-11 所示。这类缺陷会破坏铝板的局部表面造成材料的抗腐蚀性和机械性能下降，属于严重缺陷级别。产生的原因通常是由于轧辊、工作辊、粘有金属屑或异物，以及生产设备辊轴表面有缺陷或粘附异物，表面清洁不及时等原因。




图 2-11 辊印

擦伤 (rub mark)，是由于操作不当造成的板件滑动或卷材松卷，加工过程中的设备接触产生摩擦，以及尖锐的物体接触等原因，导致的板带材层间的异物与板面接触或者板面之间接触，发生相对滑动或错动在表面形成成组分布或单条状分布的痕迹，如图 2-12 所示。这类缺陷的形成对板带表面造成了轻微的破坏，降低了材料的抗腐蚀性能和机械性能，但没有危害到最终产品的质量，属于严重缺陷级别。




图 2-12 擦伤

压过划痕 (roll-in scratch)，是指经轧机工作辊压过的擦、划伤、粘铝等表面无手感缺陷，通常是由于辊面粘铝后擦伤板带表面，之后经过工作辊轧制形

成的呈周期性纹理的单条状伤痕，如图 2-13 所示。该类缺陷主要是对板带表面外观造成影响，属于严重缺陷级别。




图 2-13 压过划痕

黑点 (black pitches)，表现为板、带材表面沿轧制方向分布的黑色点/线条状缺陷，如图 2-14 所示。主要产生原因为工艺润滑不良或使用试剂不洁净，金属原材料中有夹杂，以及开坯轧制时产生大量氧化铝粉并压入，在进一步轧制时产生黑点或黑条。这类缺陷会降低材料的抗腐蚀性能，影响产品外观，属于严重缺陷级别。




图 2-14 黑点

脏污 (corrosion) 指板、带材表面失去金属光泽，呈区域性的黑色氧化情况，如图 2-15 所示。通常是由于生产、贮存不当，空气潮湿或水滴浸润表面，或者加工后表面残留物质没有及时清理干净。这类缺陷破坏了铝板的抗腐蚀性能，可能会影响产品的使用寿命，属于严重缺陷级别。




图 2-15 脏污

(3) **一般缺陷**，指不会影响产品使用且不会影响下游工序，仅对产品外观略有影响。包括油斑、油污、水痕和反光等伪缺陷。油斑、油污均是在轧制过程中残留在表面的油性污渍，由于轧制油和乳化液的纯度不高或是后续吹扫和清洗不充分导致残留在表面，其形态并不固定，呈乳白色或灰黑色。水痕表现为浅白色或浅灰色椭圆形水渍痕迹，由于清洗后烘干不充分或者停机后未及时处理干净造成的水分残留后的痕迹。反光，则是由于环境光、人为干扰，以及板带表面不平整造成的表面区域出现明暗对比。




图 2-16 伪缺陷

上述几类伪缺陷不会对产品的机械性能、安全性能、产品质量以及外观造成影响，但是作为干扰因素常常会产生误报为缺陷的情况。图 2-16 所示为油斑、油污、水痕和反光四类缺陷图像。

通过上述对缺陷类型、外观形态、和产生机理的分析，可以发现铝板带表面缺陷存在一些特点，如图 2-17 所示。(1) 由于材料自身的高反光性和金属颜色，铝板带表面图像的颜色表达较为单一。缺陷对铝板带表面的破坏状况仅能通过材料反光带来的亮度变化和与背景的对亮度变化反应。(2) 部分缺陷具有完整独立形态，边界与背景的区分明显；另一部分缺陷不仅呈区域性分布而且在多个局部区域分散排列。相较于单独类缺陷，区域类缺陷形态具有周期性和重复性，边界特征不明显，缺陷区域不连通但工艺要求判定为一个整体。(3) 不同缺陷类别间几何尺寸和长宽比差异较大，属于多尺度物体目标检测^[156]，如

凹坑和黑点类缺陷属于小目标，长宽尺寸均小于 18 pixel。金属压入、擦伤、起皮和压过划痕等缺陷的长宽比接近 20:1，属于条状缺陷啊。辊印，脏污类缺陷的长宽比为 2:1，但长宽尺寸大于 100 pixel，属于大目标。4) 由于工况、环境变化或者伪缺陷干扰，导致缺陷与背景的对比度产生变化。




图 2-17 缺陷特点：(a) 类间尺寸差异，(b) 类内尺寸差异，(c) 区域类缺陷边界难判定，(d) 不同缺陷特征相似，(e) 干扰

2.4 缺陷数据的获取及数据库的构建

深度学习被应用于实际工业检测需要大量真实、科学的数据样本，并以此针对具体问题改进算法和训练模型，最终获得客观、真实、稳定的检测方法。然而目前面临的问题一是没有铝板带表面缺陷的数据样本。而且不同的工艺阶段出现的缺陷种类、形态也各不相同，其他工艺阶段的缺陷数据样本或其他材料、产品的缺陷数据被用于精整产线的模型训练，无法真实反映需检测缺陷的特征，影响检测性能；二则，其他金属工业缺陷相关公开数据集的迁移使用，增加了算法二次数据处理的难度，需设计更复杂的检测方法缩小迁移模型产生的差异，由此增加的计算数据量影响了实时检测的响应。因此，为保证模型的正常训练和实际检测的准确性，本文从生产企业的实际生产现场采集精整产线的铝板带表面图像，并从中收集缺陷图像构建铝板带表面缺陷数据库用于后续多种检测任务。




图 2-18 原始采集图像

宽幅铝板带表面原始采集图像如图 2-18 所示，图像分辨率为 4096×1024 pixels，图像大小为 4MB。原始采集图片中的大部分图像并没有缺陷，其中仅有大约 5% 的图像出现异常特征，包括缺陷、伪缺陷和穿带编织部分等。并且采集的原始图像无法直接进行模型训练，其原因如下：1) 原始采集图像分辨率过高，计算数据量过大，增加了网络的训练时间和模型容量，提升了检测系统对训练服务器的硬件要求。2) 不满足深度学习卷积操作输入要求的图像通过像素填充转化为长宽一致、分辨率一定的正方形矩阵，这导致原始图像中缺陷信息损失及特征变化，从而影响不同缺陷特征的识别。3) 铝板带表面特征的高精度表现，使得缺陷区域面积相差较大，小目标往往在图像中表现为几个像素点。深度学习检测网络的过度数据压缩导致部分缺陷信息损失以及放大的数据噪声对特征分析的干扰。因此，为从海量数据中快速提取出有效的缺陷目标作为训练样本，从而建立适合于深度学习模型训练的铝板带表面数据集，本文基于缺陷像素灰度值的突变现象，通过对比将采集原始图像中含有疑似缺陷区域的图像筛选出来。人工标注缺陷后，根据标注区域位置裁剪图像为符合模型训练的

要求的子图像,完成铝板带表面缺陷数据库的建立。需要注意的是,该部分图像预处理操作仅用于缺陷图像数据库的快速建立,不涉及后续在线缺陷检测过程。裁剪后的子图像仅在模型的训练和性能验证中使用,现场的实际检测过程依然是输入原始图像。

(1) 疑似缺陷图像的筛选

铝板带表面原始图像中的每个像素分别属于无缺陷背景区域或疑似缺陷的前景区域。其中背景区域的像素灰度值保持在一定范围内波动较小,而疑似缺陷区域的部分像素灰度值分布较为零散,并且有灰度突变现象。对比两者的灰度值特征可将含有疑似缺陷区域的图像快速筛选出来,大大提高后续人工标记的效率。

因此,本文利用差影法^[157]将无缺陷图像作为标准模板与疑似缺陷图像进行求差计算,设定合适的阈值用于判断二者差值是否符合疑似缺陷图像的灰度值变化特征,最终从原始采集图像中筛选出疑似含有缺陷的图像。首先,构建基于无缺陷背景的标准背景图像模板。将多个无缺陷的背景图像分别划分为 16 个 512×512 的计算单元。对每张图像相同位置的计算单元进行中值滤波后,叠加取平均值得到多个标准背景计算单元。每个标准背景计算单元表示为 $p_{m_i}(x_i, y_i)$, x_i, y_i 为像素点坐标, $i \in \{0, 1, \dots, 15\}$ 表示第 i 个计算单元。当筛选一定的图像数量后,更新标准背景计算单元以适应工况变化导致的图像背景的变化。之后,筛选含有疑似缺陷区域的图像。将待检测的图像也划分为相同尺寸的 16 个计算单元,每个计算单元的像素矩阵表示为 $p_{u_i}(x_i, y_i)$ 。采用差影法计算该计算单元与标准背景单元间对应的像素值 $p_{diff_i}(x_i, y_i)$:

$$p_{diff_i} = |p_{u_i}(x_i, y_i) - p_{m_i}(x_i, y_i) \cdot R_{a1}(i)| \quad (2-4)$$

其中, $R_{a1}(n) = \text{mean}_{sub}(n) / \text{mean}_{back}(n)$ 为标准背景单元与待检单元均值的比值。 T_{a1} 为根据实际图像情况人为设定的判断阈值。当计算得出的差值大于 T_{a1} 时,该图像为疑似缺陷图像,反之为无缺陷图像。

(2) 图像的标注

对筛选所得全部含有疑似缺陷区域的图像通过 Labelimg 软件人工标注位置和种类信息。将缺陷区域以矩形框的形式表示,记录矩形框坐标和长宽等位置信息和该缺陷类别。每张图像的标注信息以 xml 格式保存。需要注意的是,矩形框的标注尽量以缺陷的最小外接矩形为标准,以避免背景信息和多目标交叠、相邻等因素干扰网络提取相关缺陷特征。图 2-19 展示了缺陷的人工标注情况。



图 2-19 人工标注界面

(3) 图像裁剪获取子图像

为适应网络模型的输入结构并且降低输入数据量，对采集宽幅图像进行自动图像剪裁获得尺寸较小的子图像用于深度学习网络的模型训练。如果直接以像素坐标从左至右、从上至下顺序划分剪裁，容易将完整的缺陷分割为多个独立区域以及将密度较低的区域性缺陷分割为不连通的区域，破坏了缺陷的形貌特征。因此，基于人工标注的位置信息设计合理的图像裁剪方法，可以避免对图像的破坏，提高缺陷图像的利用率。

首先，根据人工标注的缺陷位置信息，提取到缺陷矩形框的左上角坐标和右下角坐标，经过换算得到矩形框的中心点坐标 (x_i, y_i) 和长宽距离 (w_i, h_i) 。之后，以缺陷区域中心点为基点，在一定的范围内随机生成围绕基点的 608×608 pixel 大小的矩形区域。范围的设定遵循边框不超出原始采集图像，并且缺陷区域最大程度地被包含在正方形矩形区域内。最后，以正方形矩形区域边界作为裁剪子图像的边界，并重新将坐标信息转换为以子图像为基准的标注信息，完成子图像文件和标注信息文件的保存。重复上述操作，直至该原始图像中的全部缺陷目标均被提取为子图像。

(4) 缺陷数据库的构建

根据 2.3 节缺陷类型的描述，本文构建的铝板表面缺陷数据库包括 10 类常见缺陷类型和 3 类伪缺陷类型，即辊印，裂边，波浪纹，凹坑，金属压入，压过划痕，起皮，擦伤，脏污，黑点，油污，水痕，反光。由于实际生产中不同缺陷的出现频率和产生位置各异，图像数量相差较多。各类别缺陷图像数量如表 2-1 所示，其中一张缺陷图像中可能出现单一缺陷、两种以上缺陷类型的缺

陷、相互交叠干扰缺陷等多种形式。数据库中缺陷样本具有以下特点：

- 网络模型对缺陷的分类主要是依靠不同类别的缺陷之间的特征信息。不同缺陷相互之间的特征差异性较小，但是工艺过程和形成原因却不一样。如辊轴与板带表面间的相互运动造成的相似外观的条状缺陷（金属压入，压过划痕，起皮，擦伤），如图 2-20 所示。




图 2-20 缺陷类间特征相似性

- 同一类缺陷的特征越明显，变化越少，网络对该特征判别条件的越具体越统一，网络对这一类缺陷的检测准确率则越高。然而，相同缺陷由于工艺参数、加工阶段和生产设备变化等原因，部分缺陷类别（擦伤、辊印）的形态随机性较大，导致类内特征差异性较大，如图 2-21 所示。




图 2-21 缺陷类内特征差异性

- 产线中缺陷出现的频率不一样，造成部分缺陷类型的目标数量巨大，而另一部分缺陷类型的目标仅仅几百个。

因此，本文后续章节中根据不同的研究目的分别从数据库中选择相应缺陷图像，建立符合研究需求的对应任务数据集用于模型的训练和性能验证。

表 2-1 铝板带表面数据库图像统计

缺陷类别	图像数量	等级
辊印	1432	严重
裂边	49615	致命
波浪纹	1118	致命
凹坑	5217	致命
金属压入	3562	严重
压过划痕	1947	严重
起皮	1465	致命
擦伤	3827	严重
脏污	3820	致命
黑点	1083	严重
油污	710	一般
水痕	1039	一般
反光	234	一般

2.5 本章小结

本章简单介绍铝合金板带材的生产流程，并着重说明了精整生产线的清洗、矫直工序和检测环境。结合实地调研结果和行业标准，对常出现缺陷的形成原因、形态特点和质量分级要求进行了详尽介绍和分析。结合生产设备运行状况、生产环境以及检测需求，设计铝板带工业检测场景下的表面缺陷端到端检测方案，并针对技术难点问题进行分析论证。以采集到的宽幅铝板带原始图像数据为对象，通过差影法筛选出现疑似缺陷的原始图像。之后，根据人工标注的缺陷位置信息，设计自适应的随机缺陷区域图像裁剪算法，将原始图像裁剪为完成包含缺陷区域的 608×608 pixels 子图像，以满足检测网络对训练数据的尺寸要求，有效避免图像压缩或图像裁剪造成的缺陷特征损坏或丢失。构建真实工业背景下的铝板带表面缺陷图像数据库，包含 10 类精整线常见缺陷类型以及 3 类伪缺陷类型，为后续章节中基于深度学习的大数据网络模型训练提供了数据支撑。

第 3 章 少样本条件下的特征再加权 YOLOv4 缺陷检测方法

基于深度学习的缺陷检测方法由于其强大的特征提取能力和泛化能力以及简洁的端到端检测流程，逐渐被引入以金属带材为代表的工业表面缺陷检测领域。而深度学习良好的缺陷识别效果依赖于大规模、高区分度的训练样本，以确保模型在训练中可以学习到足够多且有代表性的特征信息，从而掌握各类别缺陷特征的分布规律，最终实现缺陷的准确检测。但是在实际检测过程中发现存在大规模、多样化的工业真实数据难以收集，以及复杂背景的数据标注花费时间、人力成本巨大等问题，导致检测效果难以达到预期，从而遏制了深度学习缺陷检测方法在工业实时检测的应用。

针对上述问题，本章提出一种基于特征再加权的端到端少样本检测方法突破训练数据稀少对工业检测应用的制约。在 YOLOv4 框架的多尺度结构中引入元学习理论，通过骨干网络提取多尺度元特征图，利用获得的重新加权向量对各元特征图重加权以强化不同类别的特定特征，并且设计基于多尺度元特征的预测模块以实现对重新加权元特征的解析，最终获得缺陷的位置和类别信息。此外，通过“大量基类数据预训练+少量带标记全类别数据微调”的训练策略，实现少样本模型在多任务场景下的快速部署，增强了检测系统的工业实用性和便捷性。

3.1 少样本条件下缺陷检测的突出问题

根据 2.4 节所述，为构建全面的铝板带表面缺陷图像数据库，我们对精整生产线所加工的铝板带表面进行了数月的图像采集。通过对采集到的原始图像进行分析，发现铝板带表面缺陷的发生不仅出现概率较小且不同缺陷的出现频率相差较大。如裂边类缺陷其表现特征较为单一，但因为工艺原因出现较为频繁。而辊印类缺陷由于粘附异物的随机性较大以及辊轴的受力不同，其形貌特征的表现较为多样。并且粘附异物的偶然性导致采集到的样本数量较少、特征分布不均匀。经过对原始图像中缺陷类型的统计，样本数量较多的凹坑、裂边、划痕等缺陷的采集图像大概在 10 万张以上；而波浪纹、黑点等缺陷的所采集到的图像数量仅有 500 张左右，辊印类缺陷虽然采集的图像数量较多，但其形貌特征分布不均，部分形状仅出现几张。因此，无论从样本特征的信息多样性还是类别的均衡性上，真实的铝板带数据都难以保证深度学习模型的训练需求。

3.1.1 少样本问题的定义和解决方式

少样本问题是指当用于训练的缺陷样本数量过少,无法满足深度学习模型对样本特征的充分学习,从而导致模型出现过拟合等影响模型检测性能的情况。结合本文中面临的铝板带缺陷检测现状,本文将铝板带缺陷检测的少样本问题定义为:当训练集中某一类别的缺陷数量明显小于类别平均数量时,则这个类别的缺陷就被看作是少样本。

为摆脱深度学习模型对大规模数据的依赖,避免特定罕见缺陷导致的昂贵准备成本和应用限制。大量研究人员也试图寻找一种新的检测机制或是学习策略解决少样本条件下的工业缺陷检测。早期研究通常利用简单的数据增强方式进行数据数量的扩充,例如对图像进行旋转(rotation)、镜像(flip)、缩放(scale)、移动(translation)或者尺度不变性转换等不改变缺陷本身特征信息的方式。但是当样本量过少时,特征多样性分布过小依然会造成模型过拟合,对准确度的提升效果有限。之后,基于模型迁移的微调方法^[158]被应用于缺陷检测的研究。通过公开大型数据集的丰富特征信息对模型权重参数进行预训练,以提高模型的泛化能力。之后,将预训练权重迁移到任务数据集中重新训练模型调整权重参数。这种方式可以加快模型的收敛过程,缩短训练时间,防止模型陷入过拟合。但是这种方法依然需要保证任务数据集的样本数量和类别分布符合深度学习模型训练的基本要求,并且避免真实场景下的任务数据集和公开的源数据集的特征相似程度过低导致的迁移模型过拟合现象。随着深度学习领域的不断扩大,生成对抗网络如 GAN^[159]等模型的问世为样本数量的扩充提出了新的处理思路,利用网络提取缺陷特征生成相似的缺陷图像用于扩充训练数据^[160, 161]。如 Božič 等人^[162]使用混合监督的缺陷分类方法,Zhao 等人结合 GAN 和自动编码器重建缺陷图像,只需要正样本实现检测任务。这种方法只需要利用现有辅助信息扩充增强特征,但是可能会引入无关噪声数据或异常特征信息,反而对模型的训练和缺陷的检测产生负作用。

随着 2015 年第一个解决少样本分类问题的学习网络 Siamese Net 诞生,少样本学习技术也逐渐被引入工业缺陷检测方法的设计研究中^[163, 164],真正从小数量样本的角度解决缺陷图像的分类任务,如基于衡量相似度距离的度量学习^[165-167],从先验任务中学习元知识的元学习^[168-170]等。少样本学习理论^[171]的提出,可在少量样本数量下对图像所包含的新类别进行分类判断,减少数量过少对模型分类效果的影响。与传统的图像分类、识别任务不同的是,少样本学习模型训练的目的在于使模型学会区分不同类别的能力,而不是传统分类任务模型训练仅仅是区分特定类别。因此,少样本学习的训练设置也区别于传统的分类方法,训练数据被分为三组,包括带有标签的目标支持集 $\mathcal{S}$, 没有标签信息的

查询集 $\mathcal{Q}$ 以及与少样本目标类别不相连的辅助集 $\mathcal{A}$ 。其中仅包含少样本数据量的 $\mathcal{S}$ 和 $\mathcal{Q}$ 类似于传统分类任务的训练集和测试集。由于其每个类别的标记样本过少无法训练有效的分类模型，少样本学习通过具有更多数量但与少样本类别不相交的辅助集 $\mathcal{A}$ 来帮助模型学习类别区分知识，并有效的将这种知识转移到少量标签样本的情况下使 $\mathcal{S}$ 快速适应新任务（基于元学习和微调）或是寻找泛化方式（基于度量学习）。所以，少样本问题又被称作 N-way K-shot 问题，既在支持集 $\mathcal{S}$ 中有 N 个类别的检测目标，但是每个类别仅包含 K 个带标签的样本（通常情况下 K 小于 50）。

具体的说，给定一个数据集 $\mathcal{D}$ ，辅助集 $\mathcal{A}$ 作为基类样本集，由图像 X_i 和相对应的掩码向量 y_i 组成。对于一个 N-way K-shot 分类任务，支持集为 $\mathcal{S} = \{\mathcal{S}_1, \dots, \mathcal{S}_C\} = \{X_i, y_i\}_{i=1}^{N_K}$ 包含有新类样本，其中每一个 $\mathcal{S}_i = \{X_i, y_i\}_{i=1}^{K_i}$ 表示支持集中第 i 类目标具有 k 张图像样本，以及查询集为 $\mathcal{Q} = \{Q, y\}_{i=1}^{M_1}$ 。设 $f_\theta(\bullet)$ 和 $C_\omega(\bullet)$ 分别表示少样本网络的主干部分和分类器部分，可以通过集成在统一的少样本网络中以端到端的方式进行训练。为了获得泛化性好的模型，少样本学习的训练策略为采用 episodic-training 机制^[172]将整体分类任务 $\mathcal{T}$ 划分为多个相互独立子任务 $\{T_1, \dots, T_i\}$ 进行模型的训练。

目前应用于图像分类任务的主流少样本学习方法有基于模型微调、基于度量学习和基于元学习三种方式。

(1) 基于模型微调的方法

基于微调的方法^[173]遵循标准迁移学习过程，利用基类进行预训练和利用新类进行微调，不需要遵循 episodic-training 机制划分子任务，如图 3-1 所示。预训练阶段，通过标准交叉熵损失函数（ $\mathcal{L}^{CE}$ ）对全部辅助集 $\mathcal{A}$ 样本进行训练，得到分类数量为 N_{base} 的基类样本分类器，如公式 3-1 所示。

$$\Gamma = \arg \min \sum_{i=1}^{N_{base}} \mathcal{L}^{CE}(C_\omega(f_\theta(X_i)), y) \quad (3-1)$$

在微调阶段，对于每个特定的新任务 $\mathcal{T} = \langle \mathcal{S}, \mathcal{Q} \rangle$ 都将基于 $\mathcal{S}$ 重新训练一个全部类别数量的分类器，并且载入预训练的模型权重参数避免样本过少导致的过拟合。当新任务 $\mathcal{T}$ 的模型训练完成后，便可以用于预测 $\mathcal{Q}$ 中的待测图像。

基于模型微调的方法结构简单，训练过程简洁。但在特定应用场景下，当基类数据与新类数据的特征相差较大时，该类方法对于新类的泛化能力下降，往往容易造成模型过拟合、分类效果不理想。




图 3-1 基于模型微调的少样本学习

(2) 基于度量学习的方法

基于度量学习的方法，包括常见的原型网络^[174]（Prototypical Networks, ProtoNet），关系网络^[166]（Relation Network, RelationNet）等。通过前馈传递计算输入的查询图像和支持集 $\mathcal{A}_s$ 之间的相似性或距离，找到不同类别之间相互关系来预测查询图像类别，如图 3-2 所示。这种方法可以调节支持集的样本集合适用不同任务并相互迁移。以原型网络为例，将每个支持集中样本图像映射为类别平均向量，比较输入的查询图像和类别平均向量之间的关系，同类目标的特征比异类特征更接近。给定一个少样本分类任务 $\mathcal{T}$ ，则每一个类别原型被表示为：

$$c_i = \frac{1}{|S_i|} \sum_{j=1}^K f_{\theta}(X_j) \quad (3-2)$$

其中， $X_j \in S_i$ ， S_i 表示第 i 个支持类中有 K 个图像。 $f_{\theta}(\cdot)$ 为主干网络，提取每个输入图像的 d 维全局特征。给定距离函数 $D(\cdot, \cdot)$ ，则查询图像 Q 的预测概率为：

$$\rho(y=i|Q) = \frac{\exp(-D(f_{\theta}(Q), c_i))}{\sum_{j=1}^C \exp(-D(f_{\theta}(Q), c_j))} \quad (3-3)$$

最后，使用最近邻分类器（1-NN）对相似度得分进行分类预测。基于度量

学习的方法便于计算, 模型更易公式化, 但采用传统距离函数的方法很难在样本数量较少时分类准确率得到较大提升。




图 3-2 基于度量学习的少样本学习

(3) 基于元学习的方法

基于元学习的方法, 是通过在训练阶段从具有大量样本数量的基类目标中学习元知识 (模型的超参数、神经网络的初始参数、神经网络的结构和优化器等), 之后利用以往的先验元知识指导模型快速适应测试阶段新的少样本任务。给定少样本任务 $\mathcal{T} = \langle \mathcal{A}_s, \mathcal{A}_q \rangle$, 使用每个子任务中训练数据 $\mathcal{A}_s$ 学习不同任务之间的泛化信息, 缓慢更新模型权重; 之后, 使用每个子任务中的测试数据 $\mathcal{A}_q$ 优化模型权重快速适应新任务。如基于元学习的注意力权重生成方法, 通过设计基于注意力网络的权重生成器将类别权重向量与基类特征进行结合, 获得用于新类的对应类别的分类权重。其权重参数可以表示为:

$$\omega_{att} = \frac{1}{N_{novel}} \sum_{i=1}^{N_{novel}} \sum_{b=1}^{K_{base}} Att(\phi_q \bar{z}_i, k_b) \cdot \bar{\omega}_b \quad (3-4)$$

其中, 式中 N_{novel} 表示新类样本数量, ϕ_q 表示变换矩阵, 用于将新类样本对应的特征向量 $\bar{z}_i$ 转化为查询向量, k_b 表示基类每个类别对应的键, $\bar{\omega}_b$ 表示基类权重, $Att()$ 代表注意力机制网络。基于元学习的少样本分类方法使模型具有学习能力, 能够学习到更多帮助模型分类的相关元知识, 但是需要前期大量的样本数据进行模型的预训练。




图 3-3 基于元学习的少样本学习

3.1.2 结合少样本学习的目标检测难点及主要方法

目前有关于少样本缺陷检测的应用研究基本上集中在利用公开数据集实现缺陷图像或特征的分类，但是无法满足于工业检测的端到端定位需求。并且为提升检测精度，其网络结构较为庞大，不具备工业在线检测的能力。受少样本学习的启发，面向实际检测场景的少样本目标检测方法（Few-shot object detection, FSOD）可以完成缺陷类别判断的同时，实现缺陷区域位置的检测。现阶段的相关研究沿用经典的检测框架，通过结合少样本学习的训练策略和优化方式，在极少量数据条件下学习具有一定泛化性能的目标检测模型，克服检测对象较大的类内差异随之而来的较低类间差异，以及数据多样性较低难以提取有效的特征数据等实际问题。

少样本目标检测框架通常将训练集中样本分为不相交的两个组别，基类（base class）具有大量训练样本的类别；新类（novel class）一个类别只有几个训练样本。大多数少样本目标检测方法默认模型主干已经在大型图像分类数据集（如 ImageNet）上进行了预训练。少样本目标检测方法的检测形式如图 3-4 所示：

1. 基类训练（Base training）：通过大量具有标注的基类样本进行模型训练。
2. 少样本微调（Few-shot finetuning）：通过支持集中少量来自基类和新类的带标注样本对模型进行微调（无微调方法除外）。

3. 少样本测试（Few-shot evaluation）：对测试集中基类和新类样本进行联合检测，并评估的模型性能。




图 3-4 少样本目标检测原理

少样本目标检测（FSOD）与少样本分类（FSC）之间除了实现功能不一样，还存在着许多差异。（1）图像中多检测对象。在 FSOD 中，同一图像中可能存在来自基类和新类的多个检测对象，基类训练时仅删除其他目标的标注信息，而 FSC 只针对图像中最主要的对象，训练过程中会过滤所有新类样本。（2）基类和新类的联合预测。在少样本微调 and 测试时，基类和新类同时存在联合检测，而少样本分类器只针对新类样本。并且 FSC 的评估通常抽取多个子任务支持集，数百次运行后得到结果的平均值作为评价标准。而少样本目标检测方法，只有一个固定的支持集参与运算，当支持集中样本数量过小，结果容易过拟合。（3）微调训练。如元学习的少样本分类方法非常依赖于元知识模型的建立。并通过支持集和查询集梯度下降更新模型。使用梯度下降来最小化查询集损失，并用于调整支持集梯度传播。相反，大多数 FSOD 方法通常不考虑通过梯度下降或反向传播将单独查询集用于校准微调模型。

结合上述少样本分类原理，目前主流的少样本目标检测方法有三类：基于模型微调的检测方法、基于度量学习的检测方法以及基于元学习的检测方法。

基于模型微调的方法对 Faster RCNN 框架进行少量修改和优化后，利用基

类数据预训练和少量样本参数微调的训练策略，解决基类和新类之间极端不平衡引起的新类的过拟合问题。在参数微调时，将上一步权重参数复制到除分类层之外的“目标”域网络后，对剩余权重参数进行微调，实现对新类目标的简单、有效检测。基本结构如图 3-5 所示。为弥补源域和目标域之间目标知识传递的损失，通常通过背景抑制正则化与知识迁移正则化等手段使网络聚焦于前景目标，减少背景干扰。




图 3-5 基于模型微调的基本结构

基于度量学习的检测方法，大部分以 Faster RCNN 框架，设计编码网络将支持集样本对象的特征映射到嵌入空间，并通过距离或相似度度量对特征向量进行计算分类，进而实现对不同类别的检测。图 3-6 所示为基于度量学习检测方法的基本结构，将待测样本通过完成参数共享的特征提取网络和候选区域网络得到潜在的目标区域特征，之后通过编码网络对特征进行转换用于后续的相似度计算。为提高模型的分类精度和网络泛化能力，大部分方法通过对编码网络，相似度度量，损失函数和分类器的进一步优化，使相同类别向量间的相似度计算尽量接近，不同类别尽量远离。




图 3-6 基于度量学习的少样本检测方法

基于元学习的少样本检测方法，通常设计单独的条件模型（重新加权模块、引导模块或重塑网络）计算每个类单独的支持权重（类嵌入、权重或关注向量），将支持权重与查询特征合并为特定类的查询特征用于各类别预测。图 3-7 为基于元学习的少样本检测方法的基本流程。以任务为单位利用丰富的基类样本训练元模型预测权重，通过元知识迁移在元测试阶段对支持集样本类相关参数进行参数预测。基于元学习的检测方法可以针对不同的任务快速更新优化模型，实际应用时具备良好的通用性。




图 3-7 基于元学习的少样本检测方法的基本流程

目前，将 FSOD 方法^[175-177]拓展到工业应用中，实现少样本条件下的缺陷端到端检测的难度依然较大，在金属板带材缺陷检测领域，仅有以 Faster-RCNN 为框架的钢板缺陷检测方法^[178]通过公开数据集验证检测性能。一方面，缺乏真实工业数据检测的相关研究，特别针对铝板带表面缺陷检测的少样本研究还是空白。另一方面，其他领域的少样本工业应用研究均是以 Faster RCNN 作为框架着重于检测精度的提升，庞大的计算量无法满足工业检测的检测速率。这也说明了基于少样本学习的目标检测方法面临着巨大的挑战。

3.2 基于元学习特征再加权的 YOLOv4 少样本缺陷检测方法

考虑本文检测系统面对多种检测对象和环境需要具备快速更新模型以适应新任务场景的需求，本章基于元学习少样本检测的优势，结合 YOLO 网络框架在工业在线检测中良好的实时性和准确性，开展少样本条件下的铝板带表面缺陷检测研究。前期研究中^[179]已经证明了 YOLOv4 良好的平衡检测速度和检测准确度在铝板带表面缺陷检测应用中的可行性，因此，本章提出的少样本铝板

带表面缺陷检测算法 (YR-FSAD) 以 YOLOv4 作为基本结构框架, 利用基类数据提取特征元知识, 之后通过设计元特征加权网络获取特征再加权向量, 将其很好地转移到对新类的分类识别中, 实现铝板带表面缺陷的少样本检测。

3.2.1 少样本缺陷检测网络框架

本章提出的少样本条件下铝板带表面缺陷检测方法 YR-FSAD 的网络结构如图 3-8 所示, 包括多尺度元特征图提取与融合模块, 特征重加权模块和多尺度预测模块。




图 3-8 少样本缺陷检测网络 YR-FSAD 框架

多尺度元特征图提取与融合模块：通过多个残差结构卷积单元的堆叠构成主干网络提取多层次元特征信息。并基于 PANet 的双向特征金字塔结构和 SPP 加强特征结构对多层次元特征进行反复融合，更好地学习多层次的复杂特征映射，提高模型捕捉不同尺寸缺陷特征的灵敏度。

特征重加权模块：构建轻量化特征加权网络用于捕获支持集图像的全局特征，并将其嵌入到重加权系数中调整查询图像的元特征，在特定类别维度上被分配更大的权重，有效地放大元特征图中对此类检测对象分类提供信息的部分，从而使该类别的缺陷特征区分度更大，分类更有利。

多尺度预测模块：基于优化后的 anchor box 解码重新调整加权的元特征矩阵，结合优化后的 CIoU loss^[180]损失函数获取最终预测结果和定位信息。

3.2.2 多尺度元特征图提取与融合模块设计

元特征提取和融合模块由用于元特征提取的 CSP 主干网络和用于多尺度

特征融合的 MDPF 网络组成，旨在融合图像的浅层和深层元特征信息提升模型对不同尺寸的缺陷目标的检测能力。由于浅层特征表达了缺陷的边缘和灰度信息等局部特征，感受野较小；深层特征更多的包含语义信息等全局特征，其感受野较大。当检测如凹坑和擦伤等小目标时，仅仅通过分辨率较低的深层语义信息难以区分目标与背景，从而完成目标捕捉。

因此，设计将多尺度特征的跨层级提取融合模块可以丰富元特征的信息表达，提高少样本条件下缺陷特征区分度。首先，令 $I^q \in \mathcal{Q}(q \in \{1, 2, \dots, N_q\})$ 为输入的查询图像，经过主干网络后提取的元特征可以表示为：

$$MF_i^q = \mathcal{B}_\lambda(I) \in \mathbb{R}^{h_i \times w_i \times m_i} \quad (3-5)$$

其中， $\mathcal{B}_\lambda$ 表示为第 λ 层的主干网络卷积层， $i \in \{1, 2, 3\}$ 表示不同尺度， h_i, w_i, m_i 表示第 i 个尺度的特征图的通道维度。

具体来说，查询图像（ $608 \times 608 \times 3$ ）输入主干网络，分别在第 54 层、第 85 层和第 104 层输出三个尺度元特征图（ $76 \times 76 \times 256$ ， $38 \times 38 \times 512$ ， $19 \times 19 \times 1024$ ）。主干网络由堆叠的 Res Unit 残差组件和 CBM 卷积组件多级串联组成，结构如表 3-1 所示。其中 Res Unit 结构如图 3-9 所示，Route 表示将不同层的输出进行通道维度的拼接操作。




图 3-9 Res 模块结构示意图

表 3-1 CSP 主干网络结构

编号	输入	层名称	通道数	核尺寸	步长	输出
0	608×608×3	CBM	32	3×3	1	608×608×32
1	608×608×32	CBM	64	3×3	2	304×304×64
2	304×304×64	CBM	64	1×1	1	304×304×64
3		Route	1			304×304×64
4	304×304×64	CBM	64	1×1	1	304×304×64
5~7	304×304×64	Res Unit×1				304×304×64
8	304×304×64	CBM	64	1×1	1	304×304×64
9		Route	8, 2			304×304×128
10	304×304×128	CBM	64	1×1	1	304×304×64
11	304×304×64	CBM	128	3×3	2	152×152×128
12	152×152×128	CBM	64	1×1	1	152×152×64
13		Route	11			152×152×128
14	152×152×128	CBM	64	1×1	1	152×152×64
15~20	152×152×64	Res Unit×2				152×152×64
21	152×152×64	CBM	64	1×1	1	152×152×64
22		Route	21, 12			152×152×128
23	152×152×128	CBM	128	1×1	1	152×152×128
24	152×152×128	CBM	256	3×3	2	76×76×256
25	76×76×256	CBM	128	1×1	1	76×76×128
26		Route	24			76×76×256
27	76×76×256	CBM	128	1×1	1	76×76×128
28~51	76×76×128	Res Unit×8				76×76×128
52	76×76×128	CBM	128	1×1	1	76×76×128
53		Route	52, 25			76×76×256
54	76×76×256	CBM	256	1×1	1	76×76×256
55	76×76×256	CBM	512	3×3	2	38×38×512
56	38×38×512	CBM	256	1×1	1	38×38×256
57		Route	55			38×38×512
58	38×38×512	CBM	256	1×1	1	38×38×256
59~82	38×38×256	Res Unit×8				38×38×256
83	38×38×256	CBM	256	1×1	1	38×38×256
84		Route	83, 56			38×38×512
85	38×38×512	CBM	512	1×1	1	38×38×512
86	38×38×512	CBM	1024	3×3	2	19×19×1024
87	19×19×1024	CBM	512	1×1	1	19×19×512
88		Route	86			19×19×1024
89	19×19×1024	CBM	512	1×1	1	19×19×512
90~101	19×19×512	Res Unit×4				19×19×512
102	19×19×512	CBM	512	1×1	1	19×19×512
103		Route	102, 87			19×19×1024
104	19×19×1024	CBM	1024	1×1	1	19×19×1024

之后，将三组元特征图输入跨级融合网络 MDPF，该网络基于 PANet 和 FPN 结构设计自上而下和自下而上的双路径融合结构。通过插值和池化的上下采样操作将不同维度的元特征进行统一后，先将深层特征逐级放大与相应浅层特征拼接，后通过多层 CBL 卷积单元完成自下而上信息传递。同理，沿自上而

下路径完成二次特征融合，保证了特征的完整性和多样性。元特征图融合后的新特征图可被表示为：

$$F_i^q = \mathcal{F}_\lambda(MF_i^q) \in \mathbb{R}^{h_i \times w_i \times m_i} \quad (3-6)$$

其中， $\mathcal{F}_\lambda$ 表示为第 λ 层的融合网络卷积层。例如，元特征图（ $19 \times 19 \times 256$ ）上采样后得到新特征图（ $38 \times 38 \times 256$ ），并与经过通道整理的原始 $38 \times 38 \times 256$ 特征图拼接，输出元特征图为 $38 \times 38 \times 512$ 。最终，输出的三个不同尺度大小的元特征图为（ $19 \times 19 \times 1024$ ， $38 \times 38 \times 512$ ， $76 \times 76 \times 256$ ），作为提取到的缺陷元特征提供不同类别对象（包括基类和新类）的通用视觉信息。

3.2.3 特征再加权网络模块设计

尽管元特征可以为数据集中的缺陷目标特征提供一些通用的视觉信息，但统一的提取网络中缺少 Ground truth 和类别标签的干预。因此，不同类别的缺陷中特定特征的表达被忽视，特别是对于样本数量较少的 novel 类难以捕捉区分不同类别的特征。因此，本章设计了特征加权轻量化网络，如图 3-10 所示。将每个支持集图像和对应的标签掩码通过网络映射为一组加权向量作用于相应尺度的元特征图上，重新对元特征图中的权重参数进行校准。向量中提取到缺陷的特定语义特征，可以在元特征图的特定类别维度上分配更大的权重，突显该类别特征图所提供的更重要的特征信息，从而提高模型的对特定类别分类有效性和检测精度。例如，波浪纹中重复的圆形凸起特征反应在波浪纹特征重加权向量中的某一维度，具有较大的权重进而促进网络对波浪纹的识别。




图 3-10 特征加权轻量化网络结构图

表 3-2 特征再加权网络结构

编号	输入	层名称	通道数	核尺寸	步长	输出
1	608×608×4	CBL Unit	32	3×3	1	608×608×32
2	608×608×32	Max-pooling		2×2	2	304×304×32
3	304×304×32	CBL Unit	64	3×3	1	304×304×64
4	304×304×64	Max-pooling		2×2	2	152×152×64
5	152×152×64	CBL Unit	128	3×3	1	152×152×128
6	152×152×128	Max-pooling		2×2	2	76×76×128
7	76×76×128	CBL Unit	256	3×3	1	76×76×256
8	76×76×256	Max-pooling		2×2	2	38×38×256
9	38×38×256	CBL Unit	256	3×3	1	38×38×256
10	38×38×256	GlobalMax		38×38	1	1×1×256
11		Route	8			
12	38×38×256	CBL Unit	512	3×3	1	38×38×512
13	38×38×512	Max-pooling		2×2	2	19×19×512
14	19×19×512	CBL Unit	512	3×3	1	19×19×512
15	19×19×512	GlobalMax		19×19	1	1×1×512
16		Route	13			
17	19×19×512	CBL Unit	1024	3×3	1	19×19×1024
18	19×19×1024	Max-pooling		2×2	2	9×9×1024
19	9×9×1024	CBL Unit	1024	3×3	1	9×9×1024
20	9×9×1024	GlobalMax	-	9×9	1	1×1×1024

特征重加权网络的具体结构参数，如表 3-2 所示。“CBL Unit”表示由卷积操作，批量归一化层和 Leaky ReLU 激活函数组成的卷积单元，“Max-pooling”表示最大池化层；“GlobalMax”表示全局最大池化层。在第 10、15 和 20 层“GlobalMax”操作后，输出与对应的元特征具有相同维度的重加权向量。

假设支持集样本包含 N 个对象类别， $N \times K$ 个支持集图像以及对应的标签掩码组成 4 维集合 (I^r, M^r) 输入特征重加权网络，输入图像被表示为 $I^r = \{I_{ck}\}_{k=1}^K$ ，相应的标签信息被表示为 $M^r = \{M_{ck}\}_{k=1}^K$ ， $c \in \{1, 2, \dots, N\}$ 为支持集样本类别， k 表示支持集中每一类图片的数量。特征重加权网络 $\mathcal{R}_\phi$ 提取各类别的特征重加权向量并分别对其取平均值，得到特定类的类别特征向量 V_{ic} ：

$$V_{ic} = \text{average} \{ \mathcal{R}_\phi(I_{ck}, M_{ck}) \}_{k=1}^K \in \mathbb{R}^{m_i}, i \in \{1, 2, 3\} \quad (3-7)$$

该特征向量用于对元特征图的特征元素重新调整权重，突出了不同尺度下不同类别中有用的特征信息。之后，将特征向量 V_{ic} 与特征提取模块提取到的元特征图 F_i^q 进行加权计算得到重新加权的带有权重信息的元特征图 $\hat{F}_{ic}^q$ ：

$$\hat{F}_{ic}^q = F_i^q \otimes V_{ic} \quad (3-8)$$

其中， $\otimes$ 表示通道乘法，可以看作将特征加权向量作为 1×1 卷积核对元特征图进行卷积操作。

最后，输出不同尺度下的三组（ 19×19 ， 38×38 和 72×72 ）重加权的元特

征图组。在每一个尺度下的元特征组包含 10 个重加权的元特征图，每一个特征图负责检测一个类别的缺陷。

3.2.4 多尺度加权特征的预测网络模块设计

为适应多尺度结构的重加权特征图解析，设计预测模块 $\mathcal{P}$ 分别针对各尺度特征图进行预测。根据 YOLOv4 的 anchor box 设置，将 anchor box 按面积大小和长宽比分为三组分别对应不同尺度特征图。以特征图中单元格位置作为中心生成在预定义 anchor box 范围内的 3 个最契合预测框，并计算得到 6 维预测向量，包含类别预测框边界信息 (x, y, h, w) ，置信度概率 (o_p) ，以及分类概率 (c_p) 。

$$\{o_p, x, y, h, w, c_p\} = \mathcal{P}(\hat{F}) \quad (3-9)$$

根据 6 维预测向量中包含的信息，设计少样本检测损失函数以衡量网络预测的定位和分类准确度。整体损失函数分为三个部分：定位损失 $\mathcal{L}_{CIoU}$ 、置信度损失 $\mathcal{L}_o$ 和分类损失 $\mathcal{L}_{cls}$ ，如公式 3-10 所示。

$$\mathcal{L}(o_p, x, y, h, w, c_p) = \sum_{i=1}^3 \mathcal{L}_{CIoU}^i + \mathcal{L}_o^i + \mathcal{L}_{cls}^i \quad (3-10)$$

考虑 IOU 计算时预测框与 Ground truth 之间重叠面积、中心点距离和长宽比的影响，利用 CIOU loss 来计算缺陷目标检测时预测框的位置回归，使模型的收敛精度更高。CIOU loss 的值越小则表示两个框的重合程度越高，预测框定位的准确性越高。

$$\begin{aligned} \mathcal{L}_{CIoU}(x, y, h, w) &= 1 - IOU + \frac{\rho^2(b, b^{gt})}{c^2} + \alpha v \\ \alpha &= \frac{v}{1 - IOU + v}, \quad v = \frac{4}{\pi^2} \left(\arctan \frac{w^{gt}}{h^{gt}} - \arctan \frac{w}{h} \right) \end{aligned} \quad (3-11)$$

其中， $\rho^2(b, b^{gt})$ 表示预测框中心点 b 与真实框中心点 b^{gt} 之间的欧氏距离； c 表示能够同时包含预测框与真实框的最小闭包区域的对角线距离； α, v 为影响因素，分别用作拟合长宽比时 trade-off 和衡量一致性； w, h 表示预测框宽和高， w^{gt}, h^{gt} 表示真实框宽和高。

采用二进制交叉熵来计算置信度的损失函数，通过控制正负样本权重解决实际预测产生的正负样本数量失衡导致的准确率下降，如公式 3-12 至 3-14 所示。

$$\begin{aligned}\mathcal{L}_{obj} &= \frac{1}{N_{pos}} \sum_{pos} -[P_t \cdot \log P_o + (1 - P_t) \cdot \log(1 - P_o)] \\ &= \frac{1}{N_{pos}} \sum_{pos} -\log P_o\end{aligned}\quad (3-12)$$

$$\begin{aligned}\mathcal{L}_{noobj} &= \frac{1}{N_{neg}} \sum_{neg} -[P_t \cdot \log P_o + (1 - P_t) \cdot \log(1 - P_o)] \\ &= \frac{1}{N_{neg}} \sum_{neg} -\log(1 - P_o)\end{aligned}\quad (3-13)$$

$$\mathcal{L}_o = w_{obj} \cdot \mathcal{L}_{obj} + w_{noobj} \cdot \mathcal{L}_{noobj} \quad (3-14)$$

其中, P_o 表示目标的预测置信度; P_t 表示目标真实值, 当框内为正样本时, 值为 1, 反之为 0; w_{obj}, w_{noobj} 为控制正负样本的权重系数, 考虑到负框的数量远远大于正框的数量, 因此分别取 1 和 100 用于平衡两个损失的值; pos 表示所有正样本, neg 表示所有负样本。

缺陷目标分类的损失函数通过交叉熵来衡量预测类别与真实类别之间准确程度, 如公式 3-15 所示:

$$\mathcal{L}_{cls} = \frac{1}{N_{pos}} \sum_{pos} C_{pt} \log C_{po} - (1 - C_{pt}) \log(1 - C_{po}) \quad (3-15)$$

其中, C_{pt} 表示真实目标类别; C_{po} 表示预测目标类别。

3.2.5 锚框 (Anchor box) 自适应缩放方法

由于 YOLOv4 中不同的层级的感受野大小不一致, 因此将 9 组 anchor boxes 分为三组用于预测不同尺度下的特征图。其中, 19×19 的深层特征图的感受野较大, 对应设置较小尺寸的三个 anchor box; 38×38 的特征图设置尺寸中等的三个特征图; 76×76 特征图作为浅层特征感受野较小, 对应较大尺寸的 anchor box。

如图 3-11 所示, 对全部训练集中缺陷样本的 Ground truth 尺寸统计分析, 可以看出铝板带表面缺陷的几何尺寸较为特殊, 不适用于日常对象目标检测的 anchor box 设置。为了更准确的计算预测框与 Ground truth 间的重合率, 提升模型检出率, 本章利用 K-means++ 聚类对缺陷 Ground truth 面积进行聚类计算, 根据最高 Avg IOU 生成 9 个 anchor box, 如公式 3-16 所示:

$$f = \arg \max \frac{\sum_{i=1}^k \sum_{j=1}^{n_k} I_{IOU}(B, B^{gt})}{n} \quad (3-16)$$

其中, $I_{IOU}(B, B^{gt})$ 为目标 Ground truth 框与聚类簇中心框的交并比, B 为目

标 Ground truth, B^g 为簇中心框; k 表示簇的个数, 设置为 9; n 表示所有样本的总个数, n_k 为第 k 个聚类中心的样本个数。




图 3-11 不同类型缺陷真实标签尺寸分布图。Y 表示 Ground truth 对角线长度

但是, 当缺陷 Ground truth 尺寸范围较为集中且变化范围较小时, 聚类计算得到的 anchor box 对应检测效果较好, 如凹坑, 脏污和起皮; 但是若 Ground truth 尺寸范围较大且分布零散时, 聚类无法寻找到准确覆盖 anchor box 范围的结果, 检测效果反而没有预期的好。因此, 我们设计通过线性尺度缩放的方式对聚类计算得到的 anchor box 进行缩放, 以更全面的覆盖 anchor box 范围, 公式如 3-17 所示。

$$\begin{cases} x_{ai}^n = \frac{(x_{ai} - x_{a1})}{(x_{a9} - x_{a1})} (x_{a9}^n - x_{a1}^n) + x_{a1}^n \\ y_{ai}^n = \frac{x_{ai}^n}{x_{ai}} y_{ai} \end{cases} \quad (3-17)$$

其中, x_{ai}, y_{ai} 表示为当前第 i 组 anchor box 的 x, y 值, $i=1, \dots, 9$; $x_{a1}^n = \alpha x_{a1}$, $x_{a9}^n = \beta x_{a9}$ 根据缩放因子 α, β 计算得到。

设置 $\alpha = 0.8, \beta = 1.5$ 时, 生成的三组 anchor box 分别为用于在 19×19 特征图中检测大目标的 (27,43)、(54,64)、(36,181), 在 38×38 特征图中检测中目标的 (31,605)、(90,114)、(216,67) 和在 72×72 特征图中检测小目标的 (100,209)、(78,608)、(434,192)。图 3-12 显示生成的三组 anchor box 在不同尺度缺陷的可视化情况, 以及 anchor box 框与对应 Ground truth 框的覆盖程度契合。




图 3-12 不同尺度 anchor box 可视化。红色框为 Ground-truth，绿色框为不同比例的 anchor box。(a) (d) 为 19×19 小尺度，(b) (e) 为 38×38 中等尺度，(c) (f) 为 76×76 大尺度

3.3 铝板带表面缺陷少样本检测的实验及对比

3.3.1 少样本训练数据集的建立

基于前文所述，少样本条件下目标检测模型的训练策略和数据集设置均与传统深度学习方法有所区别。为了保证模型的良好泛化性能，避免不同的支持集样本训练和测试对模型产生不可预测的影响，本章根据 2.4 节所构建的铝板带表面缺陷数据库，构建少样本铝板带表面缺陷数据集用于本章所提方法 YR-FSAD 的模型训练和验证。

所建立的少样本数据集中包含精整质检工位出现的 10 种缺陷类型共 9710 张图像样本，即裂边，波浪纹，凹坑，辊印，金属压入，压过划痕，起皮，擦伤，脏污和黑点。使用 labeling 软件对图像中缺陷目标进行人工标注。由于一张图像中可能包含多个类型的多个缺陷目标，统计后数据集共包含目标数量为 12198 个。具体缺陷目标数量见表 3-3 所示。

表 3-3 数据集中各缺陷目标数量

缺陷类别	基类							新类		
	起皮	裂边	擦伤	凹坑	脏污	金属压入	压过划痕	辊印	波浪边	黑点
数量	990	1765	1800	2448	1056	1129	1322	470	699	519
共计	12198									

从表 3-3 中可以看出，辊印、波浪边、黑点三类缺陷的数量与其他类型数

量差距过大。结合 2.4 节中表 2-1 的数据可知，真实生产场景中这三种缺陷的发生频率较低，属于少样本缺陷类型。设置辊印，波浪边，黑点三类缺陷为新类（novel），而其他 7 类缺陷为基类（base）。




图 3-13 少样本数据集结构

根据少样本元学习原理并参照自然对象的少样本检测数据集结构^[181]，本章所构建的少样本缺陷检测数据集结构，如图 3-13 所示。将数据集中样本随机分为用于模型训练和验证的集合 $\mathcal{D}_{trainval}$ ，样本数量占总数量的 80%，以及用于模型性能测试的集合 $\mathcal{D}_{test}$ ，占总数的 20% 并保持每个类型数量基本一致。基本训练阶段，仅输入大量具有标签信息的基类数据样本进行模型的预训练，学习元知识实现模型对同类特征和异类特征的基本区分能力。模型微调训练阶段，输入包含新类的少量样本在预训练的元知识基础上加强对特定新类缺陷特征的区分，提升模型对稀缺数据快速学习的能力。具体的训练集设置如下：

将 $\mathcal{D}_{trainval}$ 中来自基类和新类的图像样本重新随机抽样，组成包含不同 shot 数量的子任务 $\mathcal{T}_j$ 的样本集合 $\mathcal{D}_{tune}$ 。每个任务由独立的支持集 ($\mathcal{S}_j$) 和查询集 ($\mathcal{Q}_j$) 组成：

$$\mathcal{T}_j = \mathcal{S}_j \cup \mathcal{Q}_j = \left\{ (I_{j1}, M_{j1}), \dots, (I_{jN}, M_{jN}) \right\} \cup \left\{ (I_{qj}, M_{qj}) \right\} \quad (3-18)$$

其中，每个支持集包含 N 个类别且每个类别 shot 数量的支持图像 I_{jN} 和对应边界框掩码 M_{jN} 。掩码根据缺陷目标的 **Ground truth** 框信息设置二元矩阵，框内元素设置为 1，相反设置为 0；同样地，查询集用于评估模型对特征的区分性能，包含查询图像及其掩码 M_{qj} 。

为保证模型的鲁棒性和验证模型在不同子任务快速部署的能力，本章设置 4 组少样本子任务支持集，具体内容如表 3-4 所示。每个子任务均设置三组 shot 值为 15, 30 和 60。由于支持集是随机抽选，同一张图像可能出现在不同 shot 数量的支持集样本中。

表 3-4 数据集中各缺陷目标数量

编号	训练集缺陷类别（新类型加粗）	Shot	图像数量
1	起皮，裂边，擦伤，凹坑，脏污，金属压入，压过划痕， 辊印	15	91
		30	201
		60	352
2	起皮，裂边，擦伤，凹坑，脏污，金属压入，压过划痕， 波浪边	15	95
		30	205
		60	368
3	起皮，裂边，擦伤，凹坑，脏污，金属压入，压过划痕， 黑点	15	94
		30	205
		60	361
4	起皮，裂边，擦伤，凹坑，脏污，金属压入，压过划痕， 辊印，波浪边，黑点	15	120
		30	261
		60	465

3.3.2 模型训练的策略和评价标准

本章少样本模型的训练过程分为两个步骤：第一步，基类预训练（**base training**）：使用 $\mathcal{D}_{\text{base}}$ 作为训练样本进行训练。由于样本数量规模较大，训练过程耗时较长，但预训练后的模型权重可在后续不同新类的子任务模型微调阶段重复使用。**Batch size** 设置为 8，采用余弦学习策略来调节学习率，初始学习率设置为 0.001 并逐步降低至 0.0001，设置动量为 0.9。当 **epoch** 到达 200 后，**loss** 值保持稳定，该阶段训练结束。图 3-14（a）为基类预训练阶段训练过程损失函数曲线图。第二步，少样本模型微调（**fine tuning**）：分别利用包含新类的少样本支持集进行模型微调，加强模型对新类的快速学习能力。由于支持集中样本数量为 $N \times K$ 个，训练时间较短，模型收敛较快。仅通过调整不同的新类样本便可快速适应不同场景下的缺陷检测任务。设置学习率为 0.0001 并逐步降低至

0.00001, batch size 为 8, 动量为 0.9。当训练 loss 值保持一段时间的稳定后, 训练停止防止样本过少模型更容易出现过拟合。图 3-14 (b) 为不同 shot 数量时 4 组少样本任务的模型训练损失函数曲线。从图中可以看出, 在不同 shot 数量下, 4 组任务的模型曲线均保持较为一致的收敛趋势且在较短的时间内实现模型的收敛。当 shot 为 15 时, 模型的泛化性和稳定性受到样本数量过少的影响, 相比于其他数量模型收敛速度较慢。从模型基类训练损失函数曲线和微调阶段的损失函数缺陷可以看出, 在面对不同的新类缺陷时可以使用预训练的基类权重模型直接进行少样本的微调, 实现模型的快速训练和部署, 保证了工业场景下的良好可移植性。

本章节所有实验均在 Intel (R) Xeon (R) CPU E5-2660 v3 @ 2.60GHz 的工作站上进行, 采用 128 GB DDR4 内存和 8 GB NVIDIA Quadro M4000 图形处理单元 (GPU)。实验所用代码编译环境均基于 Python 3.6, Pytorch 1.7, CUDA 10.1 和 CUDNN 7.6 实现。




图 3-14 少样本模型训练过程损失函数曲线, (a) 基类训练, (b) 新类微调

本章实验中模型性能的评价指标通过精度、召回率和 mAP (mean Average Precision) 衡量。当一张图片输入模型, 对各目标均会生成多个预测框及相应标签和置信度信息。当预测框与真实框 (Ground truth) 之间的 IOU 值 (公式 3-20) 大于 0.5 且标签置信值高于设定阈值时, 该目标被判断为缺陷。在目标检测任务中, 一个缺陷目标的检测结果被判定为四种情况: 真正例 (True Positive, TP) 表示该类缺陷被模型正确预测的目标数量; 假正例 (False Positive, FP) 表示不是该类缺陷但被模型误分为该类缺陷的目标数量; 真负例 (True Negative, TN) 表示不是该类缺陷也没有被预测为该类缺陷的目标数量; 假负例 (False Negative, FN) 表示是这类缺陷但没有被模型正确预测的数量。

根据四种检测结果, 精度 (Precision) 也称查准率, 衡量模型是否将缺陷目标正确分类, 如公式 3-20 所示。精度值越高说明模型对于目标类别的预测越准确; 召回率 (Recall) 又称查全率, 衡量模型是否可以将全部缺陷目标检测出来, 如公式 3-21 所示。召回值越高说明模型对目标的漏检率越低。平均精度 (Average Precision, AP) 通过对某类缺陷预测置信度排序, 以精度为纵坐标 (prec), 召回度为横坐标 (rec) 所构成的精度召回曲线 (P-R 曲线) 下方面积值, 定义为该类缺陷的 AP 值。面积越大, 模型的检测精度越高。mAP 是所有 AP 的平均值, 用于综合衡量模型的平均准确度, 如公式 3-22 所示。其中, C 表示缺陷类别数量。此外, 使用 FPS 评估所提出方法的检测速度, 表示每秒可检测的图像数量。

$$IoU(R_{pb}, R_{gt}) = \frac{|R_{pb} \cap R_{gt}|}{|R_{pb} \cup R_{gt}|} \quad (3-19)$$

$$precision = \frac{TP}{TP + FP} \times 100\% \quad (3-20)$$

$$recall = \frac{TP}{TP + FN} \times 100\% \quad (3-21)$$

$$mAP = \frac{\sum_{c=1}^C AP(c)}{C} = \frac{1}{C} \int prec(rec) \cdot d(rec) \quad (3-22)$$

3.3.3 铝板带表面缺陷少样本检测结果

本文根据上述 3.4.1 节四组少样本子任务设置, 共训练 12 个基于 YR-FSAD 的模型权重。通过测试集 $\mathcal{D}_{test}$ 对模型准确度和有效性进行评估, 结果如表 3-5 至 3-8 所示, 分别显示在少样本支持集不同样本数量下各缺陷的评价指标值。

表 3-5 第 1 组子任务模型测试集检测结果

	15 shot			30 shot			60 shot		
	Precision	Recall	mAP	Precision	Recall	mAP	Precision	Recall	mAP
脏污	0.923	0.955	0.944	0.989	0.948	0.976	0.986	0.996	0.974
裂边	0.819	0.918	0.871	0.763	0.895	0.827	0.764	0.924	0.908
凹坑	0.581	0.904	0.818	0.733	0.954	0.880	0.765	0.974	0.899
压过划痕	0.190	0.906	0.326	0.653	0.918	0.768	0.719	0.939	0.800
擦伤	0.553	0.798	0.688	0.628	0.887	0.767	0.646	0.886	0.784
起皮	0.317	0.781	0.332	0.633	0.978	0.813	0.686	0.975	0.844
金属压入	0.642	0.850	0.780	0.728	0.953	0.823	0.734	0.969	0.882
黑点	0.628	0.671	0.472	0.623	0.936	0.742	0.472	0.959	0.821
平均值	0.582	0.848	0.654	0.719	0.934	0.825	0.723	0.957	0.864

表 3-6 第 2 组子任务模型测试集检测结果

	15 shot			30 shot			60 shot		
	Precision	Recall	mAP	Precision	Recall	mAP	Precision	Recall	mAP
脏污	0.973	0.915	0.944	0.989	0.979	0.982	0.998	0.988	0.975
裂边	0.885	0.905	0.877	0.759	0.913	0.848	0.771	0.925	0.897
凹坑	0.651	0.926	0.783	0.744	0.918	0.824	0.772	0.967	0.899
压过划痕	0.190	0.862	0.260	0.681	0.947	0.781	0.710	0.940	0.814
擦伤	0.544	0.812	0.512	0.653	0.875	0.795	0.639	0.891	0.784
起皮	0.396	0.813	0.408	0.693	0.942	0.821	0.681	0.996	0.848
金属压入	0.689	0.921	0.829	0.771	0.992	0.881	0.733	0.974	0.884
辊印	0.727	0.856	0.801	0.641	0.882	0.709	0.466	0.956	0.829
平均值	0.632	0.876	0.677	0.742	0.931	0.830	0.721	0.954	0.866

表 3-7 第 3 组子任务模型测试集检测结果

	15 shot			30 shot			60 shot		
	Precision	Recall	mAP	Precision	Recall	mAP	Precision	Recall	mAP
脏污	0.992	0.942	0.981	0.995	0.958	0.981	0.996	0.989	0.973
裂边	0.837	0.896	0.813	0.725	0.950	0.881	0.772	0.931	0.897
凹坑	0.748	0.915	0.832	0.740	0.899	0.831	0.771	0.974	0.893
压过划痕	0.216	0.901	0.302	0.694	0.942	0.800	0.719	0.939	0.811
擦伤	0.602	0.721	0.491	0.633	0.859	0.734	0.638	0.883	0.788
起皮	0.338	0.837	0.343	0.628	0.930	0.778	0.688	0.996	0.852
金属压入	0.606	0.898	0.794	0.720	0.974	0.832	0.734	0.969	0.880
波浪纹	0.710	0.981	0.901	0.773	0.990	0.904	0.463	0.960	0.821
平均值	0.631	0.886	0.682	0.739	0.938	0.843	0.723	0.955	0.864

表 3-8 第 4 组子任务模型测试集检测结果

	15 shot			30 shot			60 shot		
	Precision	Recall	mAP	Precision	Recall	mAP	Precision	Recall	mAP
脏污	0.990	0.937	0.979	0.990	0.976	0.987	0.986	0.981	0.955
裂边	0.843	0.899	0.813	0.742	0.927	0.895	0.758	0.912	0.891
凹坑	0.713	0.934	0.864	0.734	0.937	0.869	0.755	0.956	0.883
压过划痕	0.282	0.928	0.351	0.637	0.953	0.779	0.701	0.933	0.794
擦伤	0.652	0.763	0.573	0.609	0.879	0.746	0.631	0.875	0.773
起皮	0.357	0.800	0.349	0.645	0.961	0.807	0.668	0.987	0.837
金属压入	0.673	0.941	0.822	0.737	0.995	0.841	0.726	0.959	0.864
黑点	0.621	0.809	0.726	0.575	0.843	0.729	0.452	0.944	0.812
辊印	0.601	0.703	0.514	0.642	0.976	0.768	0.737	0.877	0.797
波浪纹	0.697	0.973	0.877	0.762	0.995	0.908	0.740	0.989	0.920
平均值	0.643	0.869	0.687	0.707	0.944	0.833	0.715	0.941	0.853

结合 4 组检测结果可以看出，对于不同新类样本，YR-FSAD 方法的检测结果保持稳定，特别是，三种新类缺陷单独训练效果与综合训练效果相差不大。由此证明，本章所提出的基于元学习的少样本检测方法，通过大量基类样本预训练和少样本新类微调的训练模式可以保证通用缺陷特征的提取没有损失，证明了该训练模式在少样本检测中的有效性。同时验证了完成基类训练的模型权重可载入至由不同新类组成的其他检测任务中进行快速微调，实现少样本数据集的快速搭建和多任务模型的快速部署及升级更新。

针对表 3-8 中结果具体分析，随着 shot 数量增加，模型检测性能逐步提高并保持稳定，mAP 从 68.7%增加到 85.3%。由于，工业检测往往对模型召回率的容错空间远远小于检测系统的分类准确度，在三组 shot 条件下，YR-FSAD 方法的平均召回率分别为 0.869、0.944 和 0.941，而模型的平均精准度分别为 0.643、0.707 和 0.715。这证明了所提出的方法具有全面检出板带材料表面缺陷的能力，有效地控制了工业缺陷检测时的漏检情况，但是在对缺陷类型的判断方面还有待加强。对于单独型缺陷（凹坑和裂边）和两种区域型缺陷（脏污和波浪），其检测准确度 mAP 较高。一方面其局部的形状特征和灰度特征较为明显且全局特征变化较少，相对于其他缺陷的区别度非常高；另一方面，边界特征完整性高且受背景和其他缺陷的干扰较小。而擦伤、压过划痕、起皮和金属压入 4 类缺陷均属于条状缺陷，其成因都是辊轴异物与铝板带之间的相对运动。类间相似度非常高，如形状特征、灰度特征和边界特征等。其主要区别在于不同类别所呈现的纹理特征不同，如压过划痕具有周期性的纹理特征，起皮具有明显的明暗变化和边界信息，而擦伤的尺寸变化和角度变化具有随机性。当缺陷宽度较窄或者图像存在噪声干扰时，无法清晰展示出纹理信息并被算法

捕捉到，造成上述条状缺陷的准确率和召回率都相对较低。对于辊印，由于所覆盖区域的形状和面积密度相对随机，且缺陷形貌特征的差异性较大导致类内相似度较低，样本较少时无法充分提取到出现的全部特征信息。因此对该类缺陷检测准确度影响较大，且相较于其他缺陷类型模型的收敛时间也花费较长。

图 3-15 和图 3-16 分别显示了测试集数据新类和基类缺陷的检测结果。从中可以直观看出，本章模型能够成功地检测到所有类别中的大多数目标，对于小尺寸的缺陷目标具有良好的检测效果。新类缺陷也能够保证准确的检测，特别是区域型缺陷可以实现完整缺陷区域覆盖。




图 3-15 新类缺陷检测结果可视化




图 3-16 基类缺陷检测结果可视化。红色框为目标 Ground truth。

大多数失败的原因来自于丢失或错误地检测到背景伪缺陷的干扰，以及未

能完成判断出区域类缺陷为一个整体,如图 3-17 所示。




图 3-17 失败案例

3.3.4 少样本条件下缺陷检测效果对比

为了验证模型在少样本检测场景下的检测效果和稳定性,将本文方法与经典目标检测算法,以及主流的少样本检测方法进行对比实验,采用平均精度(mAP)评估各模型的检测性能。对比方法包括目标检测算法中具有代表性的两阶段方法 Faster R-CNN,单阶段方法 YOLOv3 和 YOLOv4,以及 anchor free 方法 CenterNet;少样本目标检测方法包括基于元学习的两类方法 Meta-RCNN 和 Meta-YOLO。由于经典检测算法的训练策略不同于少样本检测方法,为减少训练策略对检测结果的影响,对比实验中经典目标检测方法的训练策略设置如下:第一,预训练阶段,将数据集中新类的样本剔除,仅针对基类缺陷数据进行正常的模型训练。第二,微调阶段,将完成基类预训练的权重参数载入模型,将包含全部类别的少样本检测支持集数据输入模型进行微调。此外,为了保证模型训练的合理性,本章对比实验均删除其中数据增强的功能。而对于 Meta-RCNN 和 Meta-YOLO 少样本检测方法,其训练策略与本文 3.4.2 节所述步骤一致,遵循基类预训练和少样本微调。

(1) 新类缺陷的少样本检测对比检测结果

表 3-9 显示了本章方法及相关对比方法在不同 shot 下的三种新类缺陷的 mAP 以及平均 mAP 值。

从表 3-9 中可以看出,本章方法 YR-FSAD 的检测性能相较于其他目标检测方法和少样本检测方法具有显著提升。基于元学习的 YR-FSAD 方法对于三种新类缺陷的检测性能远优于常规目标检测方法,说明本章模型能够有效的解决少样本造成的模型过拟合问题。可以看出,对于检测难度较大的辊印类缺陷, Faster RCNN 方法也仅能达到 0.382 和 0.459,而本章方法在 15 shot 和 30 shot 分别达到 0.514 和 0.768。对比三种少样本检测方法,本章方法的平均 mAP 为 0.705 和 0.802 略高于以 Faster RCNN 作为框架的 Meta-RCNN 方法。并且与以

YOLOv2 为框架的 Meta-YOLO 相比，基于多尺度的网络架构设计有效地提升了对小目标类缺陷黑点的检测效果。同时当 shot 数量增加至 30 时，模型对于辊印类缺陷的准确度大幅提升，mAP 比 Meta-YOLO 高出 27.4%。此外，除了 YOLOv3，随着新类样本的 shot 增加，各个模型的检测性能也随之保持稳定或小幅度提高。上述结果表明，本章提出的基于元学习的 YOLOv4 少样本缺陷检测方法在少样本条件下针对新类别的缺陷具有良好的检测效果，可以减少工业检测对于丰富样本数量的依赖。

表 3-9 不同少样本检测方法的新类缺陷检测性能（mAP）

方法	网络主干模块	Shot	黑点	辊印	波浪纹	平均值
Faster R-CNN	ResNet101	15	0.283	0.382	0.855	0.506
		30	0.256	0.459	0.880	0.532
YOLOv3	Darknet53	15	0.604	0.219	0.749	0.524
		30	0.613	0.280	0.553	0.482
YOLOv4	CSPDarknet53	15	0.628	0.223	0.826	0.559
		30	0.760	0.363	0.803	0.642
CenterNet	ResNet50	15	0.560	0.255	0.767	0.527
		30	0.631	0.370	0.707	0.569
Meta-RCNN	Faster R-CNN-ResNet101	15	0.541	0.692	0.871	0.701
		30	0.652	0.751	0.919	0.774
Meta-YOLO	YOLOv2-darknet19	15	0.691	0.462	0.929	0.694
		30	0.659	0.494	0.904	0.686
Ours (YR-FSAD)	CSP+MDPF	15	0.726	0.514	0.877	0.705
		30	0.729	0.768	0.908	0.802

（2）基类缺陷检测性能对比

衡量少样本检测模型的检测性能，不仅需要考虑对新类类别缺陷具备良好的检测效果，还需要保证模型对基类缺陷的检测准确度不损失，以此证明少样本检测方法在样本数据丰富的条件下不会产生过拟合现象，仍能满足工业检测准确度要求。因此，设置 shot 为 15 和 30，对比不同方法对基类缺陷的检测效果。

从表 3-10 可以看出，当 shot 数量为 15 时，本章方法 YR-FSAD 的检测准确度略低于其他常规目标检测基线方法，但总体检测准确度略高于其他少样本检测方法。其中压过划痕和起皮类缺陷的检测效果较低，可能是二者在图像 x 方向过窄导致有限的像素无法完全展现内部纹理，从而造成特征不充分提取的区

分混淆。此外，与 YOLOv4 基线方法相比，本章模型对于基类缺陷的平均 mAP 值相差 0.03 左右，说明模型基于特征再加权的特定类特征增强手段能够较好的保持基类特征的检测性能。从表 3-11 可以看出，当 shot 数量为 30 时，在少样本条件下本章模型的检测性能趋于稳定，达到了较好的检测效果。其 mAP 值相较于其他少样本检测方法有了大幅度的提高，并且多尺度架构的网络设计提高了小尺寸缺陷的检测精度，自适应缩放的 anchor box 的优化更加契合对条状缺陷的检测。和 YOLOv4 基线方法相比，对于裂边等特征明显的缺陷检测精度仍有差距，但是通过自适应的缩放手段优化 anchor box 对条状缺陷的检测性能有了一定的提升。需要注意的是，部分传统检测方法在 shot 从 15 增加至 30 后，极端的样本数量不平衡造成的网络泛化性降低，其 mAP 值反而出现降低。图 3-18 显示了本章方法和对比方法在 15 shot 和 30 shot 下 7 类基类缺陷的平均 mAP。




图 3-18 不同检测方法对基类缺陷的检测结果

结合上述所述，当提供的样本数量达到 30 之后的少样本检测场景下，本章模型可以基本达到与传统 YOLOv4 基线模型相似的检测能力，并且可以更好地保持基类缺陷的检测准确性和网络泛化性。

表 3-10 15 shot 基类检测结果

对比方法	Faster R-CNN	YOLO v3	YOLO v4	CenterNet	Meta- RCNN	Meta- YOLO	Ours YR-FSAD
裂边	0.828	0.949	0.954	0.970	0.859	0.850	0.813
脏污	0.996	0.993	0.997	0.991	0.971	0.994	0.979
起皮	0.737	0.437	0.797	0.760	0.621	0.528	0.349
金属压入	0.649	0.733	0.608	0.740	0.523	0.421	0.822
凹坑	0.233	0.917	0.647	0.720	0.419	0.866	0.864
压过划痕	0.318	0.391	0.341	0.400	0.435	0.461	0.351
擦伤	0.469	0.518	0.603	0.610	0.578	0.519	0.573
平均 mAP	0.604	0.705	0.707	0.742	0.629	0.663	0.679

表 3-11 30 shot 基类检测结果

对比方法	Faster R-CNN	YOLO v3	YOLO v4	CenterNet	Meta- RCNN	Meta- YOLO	Ours YR-FSAD
裂边	0.855	0.844	0.934	0.928	0.826	0.882	0.895
脏污	0.997	0.976	0.997	0.981	0.996	0.976	0.987
起皮	0.786	0.134	0.851	0.629	0.727	0.462	0.807
金属压入	0.674	0.463	0.891	0.637	0.792	0.350	0.841
凹坑	0.408	0.811	0.818	0.728	0.392	0.879	0.869
压过划痕	0.478	0.191	0.676	0.552	0.502	0.403	0.779
擦伤	0.427	0.327	0.593	0.528	0.491	0.466	0.746
平均 mAP	0.661	0.535	0.823	0.712	0.675	0.631	0.846

3.3.5 缺陷样本数量对模型性能的影响

为验证本章提出的基于元学习特征再加权的 YOLOv4 少样本缺陷检测方法在不同 shot 数量下对新类缺陷的检测性能，并且寻找适合于铝板带检测现状的 shot 设置条件为模型后续在不同的任务扩展做铺垫。通过设置在 1-50 的范围内 的多组 shot 进行模型微调训练，并使用测试集 $\mathcal{D}_{\text{test}}$ 对其进行性能检测。为验证 试验效果，使用 YOLOv4 基线模型对 3.4.1 所述的少样本表面缺陷数据集中 $\mathcal{D}_{\text{train}}$ 的全部样本进行常规模式训练。图 3-19 所示为三种新类缺陷在不同 shot 设置下的检测效果。




图 3-19 不同的 shot 数量设置下新类缺陷检测结果对比。水平虚线表示使用数据集中所有训练样本在基线模型常规训练后的检测结果。

从图 3-19 可以看出，本章模型在新类样本数量为 30 时，能够达到与基线模型相同的检测效果并保持稳定；当 shot 数量增加到 60 时，本章模型对新类缺陷的检测精度超越了常规训练的基线模型精度。这是由于少样本检测模型可以将基类中学习的元知识快速的转移到对新类的检测中。而基线模型训练时需要独立地对各类别特征进行学习，基类与新类的样本数量相差较大导致对检测效果的影响更明显。当 shot 数量达到 10 之后，本章模型对于全部 10 类缺陷的 mAP 值变化趋势和仅基类缺陷的 mAP 值变化趋势基本一致。这个现象说明模型对于新类缺陷的特征学习能力达到了与基类通用特征学习能力相同水平，进一步证明了本章提出的从大数据样本中学习缺陷通用元特征，将其转移到稀有缺陷元特征的训练策略的有效性。其中，波浪纹类缺陷由于类内差异较小，类间差异较大，其特征较为明显可以很容易地从少量样本中识别特征结构，快速地达到与基线模型几乎相同的检测精度。相比辊印类缺陷，由于其边界信息模糊且类内差异较大，类间差异较小，导致模型收敛较慢并与基线模型的检测准确度相差较大。黑点类缺陷，虽然缺陷特征较为明显，当 shot 较小时就能够达到 50% 以上的准确度，但由于其尺寸和形状变化较大，作为小目标缺陷与脏污类缺陷的边界区域容易混淆，导致检测 mAP 值与基线模型具有一定的差距。

3.3.6 少样本缺陷检测模型的实时性验证

由于工业检测的速度会影响到生产效率，通过对比不同方法的检测速度和模型容量，以保证本章 YR-FSAD 方法在铝板带生产现场的检测实时性。以下

对比实验所用权重模型均为 10 way 30 shot 支持集训练，对比结果展示在表 3-12 中。

表 3-12 不同方法的检测速度对比结果

对比方法	主干网络	模型大小 (MB)	检测速度 (f/s)
Faster R-CNN	ResNet50	478	3.294
YOLOv3	DarkNet53	235	8.046
YOLOv4	CSPDarkNet53	245	7.113
CenterNet	ResNet50	124	16.496
Meta-RCNN	ResNet50	357.3	3.778
Meta-YOLO	DarkNet19	252	13.326
Ours YR-FSAD	CSPDarkNet53+MDPF	307	7.912

在表 3-12 中可以看出，本文提出的基于元学习的 YOLOv4 少样本缺陷检测方法（YR-FSAD）对于铝板带表面图像的检测速度与 YOLOv4 基线模型相差较小，并且远远快于 Faster R-CNN 基线模型和以 Faster R-CNN 为框架的 Meta-RCNN 少样本检测方法。而 CenterNet 和 Meta-YOLO 方法的检测速度均快于本章 YR-FSAD 方法，其中 CenterNet 不需要使用 anchor box 对多尺度的特征图进行解码，网络结构较简单，检测速度可达 16.496 f/s；Meta-YOLO 使用 YOLOv2 的单尺度框架，主干网络层级较浅，检测速度比本文方法快大约 40%。但是，权衡检测的速度和检测性能，本章 YR-FSAD 方法依然具有较大优势，可满足实际工业检测要求。

3.4 本章小结

本章针对基于深度学习的 YOLO 目标检测方法在实际工业检测时，工业缺陷数据难以收集导致模型训练陷入过拟合，限制深度学习方法在工业应用场景的检测效果。因此，本章提出了一种基于特征加权的元学习少样本目标检测网络实现工业端到端实时检测，以解决工业应用过程中部分样本稀缺或特征分布不均衡导致性能低下的问题，并扩大深度学习方法的适用场景以实现多任务多对象的模型快速部署、系统的快速升级。具体总结如下：

（1）在 YOLOv4 框架下引入了元学习理论，利用元特征再加权结构设计一种少样本缺陷检测方法，保持 YOLO 框架网络快速的计算速度和检测速度的优势，结合元学习对少样本对象检测性能的提升。通过元特征提取骨干网络提取缺陷的多尺度元特征信息，并通过特征重加权网络的设计，获取重新加权向量提取特定类别的相关语义特征信息。将二者相互重新加权后可放大特定类别

维度的元特征权重,提供更多便于分类的缺陷视觉信息。之后,通过新解析策略的多尺度预测模块,实现对重新加权的元特征在不同尺度上的缺陷进行定位和分类。

(2) 基于多尺度架构的元特征提取模块、特征重加权模块和边界框预测模块的设计用于映射不同尺度的缺陷特征,增强网络对于小目标缺陷捕捉的敏感性。通过充分融合不同尺度的细粒度特征和语义特征,提高模型对多尺度多类别的缺陷特征的解析,特别是对铝板带表面凹坑、黑点等微小缺陷的检测精度,从而增强模型的鲁棒性和泛化性。

(3) 构建基于少样本缺陷检测的模型训练策略。提前在大规模、多类别的基类标注数据上完成预训练权重的生成。之后,加载预训练权重,结合包含新类的全部类别的少量标注数据上完成模型快速微调训练,实现检测模型在适应多型号、多工况检测目标和多任务场景时具有快速训练、快速部署的能力。

(4) 实验证明,所提出的方法在仅有 30 张训练图片时表现出优异的性能,整体检测精度达到 83.3mAP。相比标准目标检测方法,对于基类缺陷保持正常检测准确度,对新类缺陷的准确性提高了 14.6%以上,以较大的优势体现了少样本的有效性和该技术的可行性。

第4章 结合上下文信息和斥力损失的 YOLO 抗遮挡缺陷检测方法

铝板带的多工序连续化生产引起不同阶段工序产生的缺陷相互重叠、遮挡,以及复杂工业生产环境下环境光源反光和板面清洁不彻底产生的油渍水渍干扰,均会造成缺陷检测时的漏检、误检和定位偏差问题,影响实际检测效果。而实际工业检测对系统的漏检率要求往往高于对缺陷的分类精度。因此,本章提出一种端到端的 YOLO 抗遮挡缺陷检测方法,通过构建基于 RFB-Net 的上下文信息提取结构和多层级交叉特征融合结构,增强网络对缺陷特征的抗干扰分析能力。设计加权斥力损失函数及筛选机制,优化生成预测框的准确定位能力,缓解冗余计算负担。该方法缓解了面对密集遮挡目标时缺陷交叠及异物干扰导致的漏检、误分现象,有效地提升了深度学习缺陷检测方法的适应性。

4.1 缺陷遮挡问题及其解决思路

4.1.1 缺陷检测中遮挡问题的定义

在实际铝板带表面缺陷的检测过程中,通过对检测结果进行分析,发现检测精度不佳的原因主要有两个方面:缺陷之间相互遮挡、重叠造成漏检和非缺陷的反光、水渍油渍、异物等干扰造成的误检。由于精整产线铝板带需要与多个辊轴接触并且连续完成多个工序,不同辊轴的异物重复作用于铝板表面和上游工序中产生的缺陷及干扰在产线尾部的检测工位则呈现出同类或多种缺陷相互交叠的现象。如图 4-1 所示,缺陷之间的相互遮挡不仅破坏了原本特征直观、清晰的表达,并且改变了不同类型缺陷的特征信息分布形式,干扰模型对于缺陷主体与背景的分,从而导致检测系统出现漏检和定位偏差的情况;环境光源以及清洁不彻底的油渍水渍等因素的干扰,导致反光、水渍油渍等伪缺陷被误判为缺陷。

由于遮挡现象的出现频率非常高且形式多样,为更好的解决遮挡问题带来的检测影响,将缺陷的遮挡问题分为三类:类内遮挡、类间遮挡和干扰。当出现某类缺陷对象被相同类型的缺陷对象遮挡时,这类情况称之为类内遮挡。通常相同目标的重叠会破坏缺陷原本的形状特征,大量的干扰信息导致网络对于缺陷特征的分类出现混淆;当某类缺陷对象被不同类型的缺陷对象进行遮挡时,这类为类间遮挡。不同于日常物体检测具有特殊的结构、颜色信息,铝板带缺陷由重复的、周期的纹理信息组成。当不同类别特征相互遮挡时,单独型缺陷与区域类缺陷中的部分结构难以区分特征的类间相似度;当缺陷对象被反光、清洗水渍以及高压水冲击痕等伪缺陷造成遮挡,称之为干扰。缺陷、伪缺

陷与背景间的差异性被改变，导致特征间信息的干扰和缺失，以及网络对缺陷目标的丢失。




图 4-1 遮挡情况示意图，蓝色框与红色框分别表示不同的缺陷目标：(a)，(b) 类内遮挡，(d)，(e) 干扰，(c)，(f) 类间遮挡

对于两个缺陷目标相互遮挡的情况，通过两者 Ground truth 的 IoU 交集来衡量。令两个目标分别表示为 A ， B ，则两者的遮挡程度 IoU 表示为：

$$IoU = \frac{GT_A \cap GT_B}{GT_A \cup GT_B} \quad (4-1)$$

为了进一步量化遮挡程度对缺陷检测精确度的影响，根据遮挡程度不同分为 4 个等级：无遮挡，遮挡缺陷与被遮挡对象之间的 IoU 值为 0；部分遮挡，遮挡缺陷与被遮挡对象之间的 IoU 值在 1~35% 范围内；严重遮挡，遮挡缺陷与被遮挡对象之间的 IoU 值在 35~65% 之间。当遮挡缺陷与被遮挡对象之间的 IoU 达到 65% 以上，表示缺陷目标为完全遮挡。目标检测方法的检测精度会随着遮挡程度的增加而下降，常规缺陷检测方法在遮挡程度在 0~10% 之间时，能够保持较好的检测精度，但当遮挡度超过 40% 时，几乎无法检测到被遮挡的缺陷目标。

4.1.2 遮挡缺陷目标检测的难点及解决方法

在目标检测中，处理遮挡问题的难点主要有：(1) 遮挡的形态具有复杂性和多样性，数据集的样本无法涵盖全部可能出现的情况，从而影响模型对特征

的学习。在遮挡情况较为严重时,基于深度学习的网络模型会丧失对于检测结果的鲁棒性;(2)目标之间相互的交叠破坏了目标的原本形态特征,干扰模型对特征信息的提取。并且不同目标的交叠部分特征相互影响,弱化了特异性从而误导模型区分能力的学习训练。(3)交叠目标生成的预测框的重合程度较高,在后续剔除冗余预测框的非极大值抑制计算时容易被误删,从而造成遮挡检测时的漏检率较高。

针对上述检测难点,基于深度学习的检测算法在面对多样的遮挡目标和复杂的遮挡情况时难以设计特定的网络模型满足所有的检测任务。因此,目前针对遮挡目标的解决思路主要分为三种:数据增强和遮挡部分的信息重建;优化网络的判断机制;在网络的特定层引入特定概念以强化特征表达。

数据增强一般用于处理较为单一或简单的检测任务,通过增加大量的检测对象样本以提高网络精度,但是其本质并没有改进网络对相互遮挡特征的区分手段,效果非常有限。**缺陷遮挡部分的图像重构**,以生成对抗网络和模态感知为基础,通过网络推断被遮挡缺陷的形态、纹理结构信息或弥补形变影响以确保样本数据的数量和完整性。如基于 SeGAN 的物体遮挡区域生成^[182],基于循环 LSTM 的端到端检测模型^[183],以及基于 Mask RCNN 的遮挡状态预测模型^[184]。这种思路可以直观地填补遮挡区域信息,解决特征被异物遮盖的问题。但是无法解决实际检测场景中密集交叠缺陷相互区分的问题,并且其网络复杂度较高导致检测速度较慢,不适用于工业场景下的铝板带质量检测应用。

优化网络的判断机制是通过合理的计算方法优化损失函数和对应的判断标准,以此改善模型的训练结果,从而提高网络的检测性能。基于优化损失函数的方法,通过优化检测模型的定位损失函数来提升遮挡对象的定位精度。常见的损失函数包括改善交叠区域计算方式的 GIoU Loss^[185], DIoU Loss^[186], EIoU Loss, 以及专门针对遮挡目标检测的 Repulsion loss^[187], NMS Loss 等。这些损失函数改进了遮挡目标在 IoU 计算时无法精确的反映两者之间的重合关系的情况。通过与合适的目标检测框架相结合,被应用于密集人群和物体的检测中,如聚拢损失函数和 YOLOv3^[188], Repulsion loss 与 GIoU Loss^[189], Faster R-CNN 和 Aggregation Loss^[184]。基于优化预测框判断标准的方法,通过增强预测框之间的相互区分度避免遮挡物体预测框被剔除。如 Soft-NMS 和为解决检测目标严重遮挡的情况设计的 Adaptive-NMS^[190]。为改善重叠关系描述不够全面导致的遮挡物体检测精度被限制的情况,将优化损失函数和改进非极大值抑制筛选机制结合,提升预测框与 Ground truth 之间的匹配度,如 DIoU-NMS 等。这种方法提高预测框的定位精确性和合理性,解决分类置信度与预测框定位之间非正相关的问题。但是,通过改进损失函数和筛选条件提高模型对于遮挡目标的

检测性能的方式简单高效，但是不能改变缺陷特征交叠时模型无法捕捉到缺陷目标的复杂情况。

特定强化手段植入的检测网络作为目前被重点研究的解决方案，利用卷积神经分类网络（CNN）^[191]或者目标检测网络，通过在网络模型中改进或植入不同组件使其对于遮挡对象的整体特征的提取、推断更加敏感，降低背景或非检测对象的噪声干扰，如上下文信息^[192]、可变形卷积^[193, 194]、成分卷积神经网络结构^[195]以及注意力机制^[196]等。由于目标检测网络的深度不断加深，信息传输过程中缺陷的特征会发生变化或衰减，对遮挡缺陷的定位识别会更加困难。因此，通过上下文信息提取等方式扩大特征对于全局环境的表达，增强网络前景和背景环境的区分，提高模型区分单独缺陷和区域缺陷中组成元素的能力。目前，这类方案主要应用于行人检测^[197]和遥感图像的云雾遮挡领域。由于铝板带表面缺陷形态的周期性和重复性，利用目标结构特征划分为多个区域进行单独检测的方式无法提高对遮挡部分的识别能力，反而破坏了缺陷的整体特征导致检测精度下降。因此，较少研究着眼于解决工业加工中金属板带材表面重叠缺陷的检测。

4.2 面向遮挡缺陷检测的上下文特征增强YOLO模型设计与优化

YOLO 算法具有良好的检测速度和准确性，并且多尺度的结构设计可以有效提高对于不同目标的特征表达，适合于实际的工业质量检测。在前期的研究中，已经证明了其对于铝板带表面的多种类型缺陷良好的检测效果，以及可满足实时质量检测的速度要求。但是，面对铝板带表面出现的部分缺陷相互密集交叠导致的遮挡情况和生产过程中造成的伪缺陷干扰等问题，YOLO 算法的检测效果达不到与面对稀疏目标时较为一致的检测效果。而导致YOLO 算法在遮挡目标检测时性能不佳的原因，一方面是因为特征提取网络结构较深、较复杂，不断的传递过程中细节特征被模糊或衰减，并且忽略了特征图中对于前景和背景之间的平衡；另一方面，多目标的重叠现象使得预测生成的预测框聚集在一起，YOLO 算法中的预测框计算筛选机制会导致大量候选框被删除，从而导致遮挡目标的漏检情况严重。

4.2.1 整体网络结构设计

为解决YOLO 算法面对遮挡目标检测时的漏检严重的现象，无法满足实际工业检测需求，本文基于YOLO 多尺度目标检测结构，提出一种铝板带表面遮挡缺陷检测方法（AO-YMAD），避免上下文冗余背景噪声和特征信息不平衡的负面影响，更有效和准确的对密集遮挡的目标进行检测，网络结构如图4-2所示。

首先，为了更好的获取缺陷特征以及上下文信息，并且平衡前景与背景之间的环境理解，设计基于像素级的上下文信息自适应特征提取网络。利用 RFB-Net 结构并结合空洞卷积结构，构建多尺度上下文模块增强网络对全局特征和前景之间的权重。

其次，优化融合网络的结构更有效的提取和融合不同尺度间的特征信息。提出基于 Bi-FPN 结构^[198]的多尺度融合网络，通过不同对三个尺度特征构建双向路径重复融合浅层和深层的特征图，并将层聚合单元用于融合网络中使语义信息得以加强。

最后，融合后的特征图进入预测层，通过设计加权斥力函数的损失函数和优化的 Soft-NMS 预测框筛选机制等措施，进一步提高网络对于高重叠预测候选框的区分能力，降低被遮挡对象的漏检概率，并且改善相邻子特征相似导致的稀疏检测对象过度生成预测框的情况。




图 4-2 抗遮挡 YOLO 网络（AO-YMAD）框架原理图

4.2.2 基于上下文信息的自适应特征提取

利用目标周边信息的上下文信息是一种有效的帮助网络模型判断缺陷目标及对应定位的方法。特别是，铝板带表面检测时单独型缺陷与区域型缺陷中的

组成元素常常是检测出现混淆较多的地方。同时，裂边或者波浪纹等缺陷周围不仅会出现铝板带边缘，板面，还会出现生产线背景等多种检测因素。图像中的不同背景通常会提供多种信息用于判断不同类别的缺陷目标，其中包括了可有效地用于区分被遮挡目标的上下文信息。较小的遮挡区域可能需要较少的上下文信息，而较大区域的遮挡可能会依靠大区域的上下文信息。因此，在主干网络中融入上下文信息的结构，可以对遮挡目标检测提供更多的特征信息。

(1) 空洞卷积

空洞卷积 (dilated convolution) [199]，又称为扩张卷积，通过引入扩张率 (dilation rate) 在卷积操作时采用不同的间距填 0 操作，增加感受野的同时不改变输出特征图尺寸，代替了反复池化操作造成的信息损失。通过设置不同的扩张率提取不同的特征信息，将其组合增加了上下文信息的多样性。空洞卷积如图 4-3 所示。




图 4-3 空洞卷积示意图

当扩张率 $l=1$ 时，空洞卷积与普通卷积作用相同；当扩张率大于 1 时，卷积操作根据扩张率大小对特征图中元素间隔采样。一次普通卷积计算被定义为：

$$(F * k)(p) = \sum_{u=-r}^r \sum_{v=-r}^r F(u+p, v+p) k(u, v) \quad (4-2)$$

而一次空洞卷积计算被定义为：

$$(F * lk)(p) = \sum_{u=-r}^r \sum_{v=-r}^r F(lu+p, lv+p) k(u, v) \quad (4-3)$$

其中， F 为输入特征图， p 为特征图中元素的坐标， k 为 $(2r+1) \times (2r+1)$ 卷积核， $(F * k)(p)$ 表示为输入特征图和卷积核 k 卷积操作后 p 点处的值。空洞卷积操作后，感受野面积增大，说明空洞卷积操作可以在扩大感受野的同时不丢失特征分辨率，并且保持像素的相对空间位置不变。当多个不同扩展率的空洞

卷积叠加，可以获取多尺度的上下文信息。相比于普通卷积操作先卷积后池化，空洞卷积可以不引入额外超参数并降低运算量。因此，对于遮挡对象的检测，可以有助于改善特征的全局和局部表示，提高检测性能。

(2) RFB 多分支卷积结构

考虑到空洞卷积在遮挡目标检测时改善特征表达的有效性，本文结合空洞卷积和 RFB-Net^[199]的多分支卷积结构，在主干网络中构建多分支上下文信息缺陷特征提取单元，更好的捕获特征图中的上下文信息并避免背景中的冗余噪声对检测性能的负面影响。

基于 RFB-Net 的上下文信息特征提取单元 (CFE Unit) 采取多分支卷积结构，通过在不同的支路上堆叠不同尺寸和不同数量的卷积层和空洞卷积，相互结合不同分辨率和不同扩张率的特征图弥补不同尺度之间的信息损失，同时不同支路的不同扩张程度能够获得不同区域的上下文信息。该单元包括一个 shortcut 残差分支和三个具有不同扩张率的卷积分支，具体结构如图 4-4 所示。




图 4-4 多分支上下文信息特征提取单元 (CFE Unit)

其中，残差结构的设计为避免主干网络不断的卷积计算后训练误差累积导致的梯度退化和梯度爆炸。为了减少特征图的通道数，在三个扩张卷积分支中先使用 1×1 卷积。之后，分别在各分支中构建 3×3 、 5×5 和 7×7 卷积层以激活多个感受野，感知输入图像中的不同检测范围。为了减少参与计算的参数量并增加非线性拟合和网络深度以有效的挖掘模型的深层特征，使用两个 3×3 和三个 3×3 卷积层分别代替 5×5 和 7×7 卷积，获得更优的提取效果。接着，在

各分支中使用扩张率 l 为 1、3、5 的 3×3 空洞卷积，融合不同感受野的上下文信息。最后，各分支特征图经过拼接操作输出最终特征图。本文构建的上下文信息特征提取单元通过控制最短最长梯度路径，使较深的网络也能够更好的梯度收敛，提取前景特征和相关的上下文信息。同时，降低背景不相关噪声或伪缺陷等非目标对象对检测的干扰，使模型的性能更加稳定。

为了减小池化下采样操作的特征信息损失，通过最大池化单元（MPU）的双分支结构弥补单独池化操作或卷积操作的不足。该单元结构如图 4-5 所示，分支一利用最大池化下采样，之后经过 1×1 卷积整理通道数；分支二先通过 1×1 卷积调整维度后利用 3×3 卷积核（步长为 2）完成下采样。最后，将两部分特征矩阵拼接后作为输出特征图。




图 4-5 最大池化单元（MPU）

（3）上下文信息缺陷特征提取主干网络

借鉴 YOLO 算法中多尺度输出特征主干网络结构，通过堆叠多个卷积层和上下文信息特征提取单元构建面对遮挡缺陷目标的主干网络，如表 4-1 所示。首先，输入图像（ $608 \times 608 \times 3$ ）通过不同步长的卷积块（卷积层+BN 层+激活函数）得到特征图（ $152 \times 152 \times 128$ ）。之后，经过两个 CFE Unit 和最大池化单元（MPU）加深网络深度减小特征图尺寸，得到浅层特征图（ $76 \times 76 \times 512$ ）作为大尺度层级。将其继续输入 CFE Unit 和最大池化单元（MPU）可依次获得中层特征图（ $38 \times 38 \times 1024$ ）和深层特征图（ $19 \times 19 \times 1024$ ），分别作为中尺度层级和小尺度层级。

表 4-1 主干网络结构

编号	输入	层名称	通道数	步长	输出
0	608×608×3	CBS	32	1	608×608×32
1	608×608×32	CBS	64	2	304×304×64
2	304×304×64	CBS	64	1	304×304×64
4	304×304×64	CBS	128	1	152×152×128
8	152×152×128	CFE Unit	256	1	152×152×256
10	152×152×256	MPU	256	1	76×76×256
		Output			76×76×256
11	76×76×256	CFE Unit	512	1	76×76×512
12	76×76×512	MPU	512		38×38×512
		Output			38×38×512
13	38×38×512	CFE Unit	1024	1	38×38×1024
14	38×38×1024	MPU			19×19×1024
15	19×19×1024	CFE Unit	64	1	19×19×1024
16	19×19×1024	CBM	1024	1	19×19×1024

4.2.3 多尺度的双路径级联融合模块设计

经过主干网络提取到的特征图，不断的下采样导致密集重叠的目标的细节信息在逐层提取与传递过程中会逐渐变少。当两个目标高度重叠时，其空间位置不断靠近，最终在深层特征图中被同一个子特征元素表达，难以区分。对于深层特征图，重叠程度高意味着目标之间共享像素比例高，造成被遮挡的目标的深度特征与遮挡者相似度高，从而影响了网络对于遮挡目标的检测性能。

因此，为解决主干网络提取到的深层特征图分辨率较低难以对高重叠的缺陷目标进行区分和顺序采样造成的特征信息损失。本文提出一种基于 BiFPN 结构的双路径级联融合结构，如图 4-6 所示。

首先，将不同层级输出的特征图通过上采样统一分辨率大小，与横向同层特征图拼接输入层聚合单元完成不同层级间的第一路径特征融合。之后，继续根据由下至上的路径完成全部层级的第一路径单层特征融合。然后，再将特征图下采样后与横向同层和跨级特征图拼接，输入层聚合单元完成不同层级间的第二路径特征融合。最后，继续下采样构成由上至下的第二路径单层特征融合网络，输出三层级特征图（76×76、38×38、19×19）进入预测模块。其中，层聚合单元基于分割梯度流的思想，通过多个 1×1 卷积对特征图通道降维后，分别对特征图通过通道数相同的 3×3 卷积层级联并增加 shortcut 连接。然后将输出的多支路通道的特征图拼接，完成特征融合。该单元具体结构如图 4-7 所示。由于分通道的计算结构，层聚合单元能够节省内存的访问成本，并且并行的卷积计算提高了卷积的计算效率。相比于普通融合网络中对特征图重复的全卷积计算，本章的融合结构可以减小网络的规模，提高检测精度和训练、计算速度。




图 4-6 基于 BiFPN 的融合网络结构




图 4-7 层聚合单元

基于 BiFPN 结构的级联融合结构将浅层特征与包含高级语义信息的深层特征融合，一方面，通过在相邻子特征中融入具有区分度的浅层细节信息，保留

深层特征的高级语义信息。不同尺度特征图中包含的语义信息与空间细节信息,提高模型对被遮挡目标的信息提取能力;另一方面,浅层特征的感受野较小更有利于保留小目标缺陷特征信息,有助于提高网络对于小尺寸缺陷的检测精度。并且级联的结构可对不同检测特征按照跨尺度权重进行抑制或者增强特征表达,从而进一步缓解缺陷重叠导致漏检问题。

4.2.4 基于斥力损失的加权损失函数设计

YOLO 方法作为通过回归的方式进行缺陷检测的方法,通过边界框回归,缩小预测框与真实框之间的距离度量。为了能够更准确更平均的匹配不同尺度的 anchor box 组,不同尺度的每个网格通过损失函数的分类损失和定位损失来衡量 anchor box 与目标之间的匹配程度。而不同于常规目标检测对象特征表现完整,位置分布稀疏,遮挡问题中的缺陷往往相互重叠导致的预测特征向量与真实向量之间的差异较为特殊。并且考虑到铝板带表面缺陷中较为单一的颜色特征和较小的类间差距,以及需要全局考量判断的区域类缺陷等特点,在训练过程中 YOLO 模型通常会倾向于将更多的重叠或密集的缺陷包含在预测框中,使得遮挡目标中的部分特征信息与被遮挡目标产生混淆,从而导致预测框的偏移。模型则无法仅通过定位损失和分类损失对相互重叠的物体进行较为准确的定位和分类。

为了加强模型对遮挡问题检测时区分相似物体的学习能力及对在背景和密集目标干扰情况下的准确定位能力,本章借鉴针对遮挡人群检测所设计的斥力损失 Repulsion loss 的吸引排斥思想,结合 YOLO 模型的预测框生成策略,设计加权斥力损失函数以帮助模型对铝板带表面重叠缺陷的准确定位和分类。

(1) 斥力函数

斥力损失 (Repulsion Loss)^[187]于 2018 年提出,用于解决目标检测中的人群遮挡问题。通过两个因素驱动边界框的回归计算,使预测框靠近目标 Ground truth 框的同时远离其他不属于目标的 Ground truth 框。该损失函数可以有效地防止预测的边界框移动到相邻的重叠对象,使得检测模型对人群场景的检测时具有更强的鲁棒性。斥力函数由吸引项 L_{Attr} 和排斥项 L_{RepGT}, L_{RepBox} 三个部分组成,如公式 4-4 所示。

$$RepLoss = L_{Attr} + \alpha L_{RepGT} + \beta L_{RepBox} \quad (4-4)$$

L_{Attr} 起到吸引的作用,使预测框接近其指定的目标,如公式 4-5 所示; L_{RepGT}, L_{RepBox} 作为排斥项,分别使预测框远离周围其他对象的 Ground truth 和其他具有不同类别的目标预测框,见公式 4-6 和 4-7。系数 α 和 β 作为权重因子用于平衡辅助损失。

$$L_{Attr} = \frac{\sum_{P \in P+} Smooth_{L1}(B_P, G_{Attr}^P)}{|P+|} \quad (4-5)$$

$$G_{Attr}^P = \arg \max_{G \in g} IOU(G, P)$$

$$L_{RepGT} = \frac{\sum_{P \in P+} Smooth_{ln}(IoG(B_P, G_{Rep}^P))}{|P+|} \quad (4-6)$$

$$\begin{cases} G_{Rep}^P = \arg \max IoU(G, P) \\ IoG(B_P, G_{Rep}^P) = \frac{B_P \cap G_{Rep}^P}{G_{Rep}^P} \end{cases}$$

$$L_{RepBox} = \frac{\sum_{i \neq j} Smooth_{ln}(IoU(B^i, B^j))}{\sum_{i \neq j} identity(IoU(B^i, B^j) > 0) + \varepsilon} \quad (4-7)$$

其中, P 和 G 分别表示检测对象的预测建议框和 Ground-truth 框。 $P+$ 表示所有正样本的集合(预测建议框与 Ground-truth 框的 $IoU \geq 0.5$), 并且被划分为多个互斥的子集。 G 表示是一张图像中所有对象 Ground-truth 框的集合。

(2) 结合 YOLO 目标框回归的加权斥力损失函数

由于斥力函数最初是针对 Faster RCNN 框架而设计的, 其中 L_{RepGT} 的作用是为了解决在训练时 anchor 无法对应归属于某个 Ground truth 的问题。而 YOLO 模型的 anchor 解码规则是根据已经确定的网络对应的 anchor 进行回归计算, 直接将斥力函数应用于 YOLO 模型反而会起到相反的作用。因此, 本章利用 L_{RepBox} 原理, 设计合适的加权斥力损失函数引导模型提高对不同类别相似对象预测框的排斥权重, 以提高对相互遮挡的不同类别缺陷间的区分能力。

模型的整体损失函数可表示为:

$$Loss_{WR} = \alpha Loss_{loc} + \beta Loss_{repB} + Loss_{conf} + Loss_{cls} \quad (4-8)$$

其中, $Loss_{loc}$ 和 $Loss_{repb}$ 控制模型中预测框的定位准确性, $Loss_{conf}$ 用于表示置信度损失, $Loss_{cls}$ 为分类损失, α, β 是加权控制因子。

置信度损失通过 BCEWithLogitsLoss 计算当前预测框中存在目标的可能性, 如公式 4-9 所示。值越接近 1 表示该预测框中存在目标的可能性越大; 相反接近 0 表示存在目标的可能性越小。

$$Loss_{conf} = -\sum_{i=0}^G \sum_{j=0}^B I_{ij}^{obj} \left(\hat{C}_i^j \log(C_i^j) + (1 - \hat{C}_i^j) \log(1 - C_i^j) \right) - \lambda_{noobj} \sum_{i=0}^G \sum_{j=0}^B I_{ij}^{noobj} \left(\hat{C}_i^j \log(C_i^j) + (1 - \hat{C}_i^j) \log(1 - C_i^j) \right) \quad (4-9)$$

其中, $\hat{C}_i^j, C_i^j$ 分别表示预测置信度和真实置信度, 用于衡量每个网格中对对应目标预测框的可靠性。 λ_{noobj} 为控制因子, 当出现预测框中不存在预测对象时, 输出尽量小的置信度, 防止多检测对象的干扰情况。

同样,引入 BCE 交叉熵可以得到分类损失,判断预测框内目标属于的缺陷类别,如公式 4-10 所示。

$$Loss_{cls} = - \sum_{i=0}^G I_{ij}^{obj} \sum_{c \in classes} (\hat{P}_i^j \log(P_i^j) + (1 - \hat{P}_i^j) \log(1 - P_i^j)) \quad (4-10)$$

其中, I_{ij}^{obj} 表示第 i 个网格中的第 j 个 anchor box 是否负责对该目标进行预测。如果负责进行预测则其大小为 1, 否则等于 0。

定位损失由 CIOU 损失和 RepBox Loss 损失构成,通过预测矩形框的坐标点位置和长宽计算与对应 Ground truth 之间的 CIOU 差距,训练模型对于预测框大小和位置的定位。结合斥力损失函数中的 $Loss_{RepB}$,设计多预测框之间相互排斥,从而抵抗不同检测对象之间的预测框的相互干扰,使预测框的定位更加准确。 $Loss_{repB}$ 损失函数,如公式 4-11 所示,将全部生成的候选预测框组成建议集 $P+$,并且基于每个预测目标划分为多个互不相交的子集: $P+=P1 \cap P2 \cap \dots \cap P_{|G|}$ 。之后,从两个不同子集随机抽取的两个候选预测框,使预测框 B^{P_i} 和 B^{P_j} 重叠的面积尽可能小。

$$Loss_{repB} = \frac{\sum_{i \neq j} Smooth_{ln}(CIOU(B^{P_i}, B^{P_j}))}{\sum_{i \neq j} identity(CIOU(B^{P_i}, B^{P_j}) > 0) + \varepsilon}$$

$$Smooth_{ln}(x) = \begin{cases} 0.5x^2, & |x| < 1 \\ |x| - 0.5, & |x| \geq 1 \end{cases} \quad (4-11)$$

其中, $identity$ 为恒等函数, ε 在除以零的情况下是一个小常数。 $Loss_{RepB}$ 能够降低不同检测目标的边界框在后续 NMS 时被错误判断为一个目标的概率,使得检测器在面对遮挡场景时具有更好的鲁棒性。最后,对定位损失函数的两个部分 $Loss_{repB}$ 和 $Loss_{cls}$ 进行加权计算,得到最终的定位损失。

4.2.5 预测框筛选策略的抗遮挡优化

基于 YOLO 的目标检测方法,基本都遵循着相似的原理对缺陷目标进行预测。通过 anchor box 产生大量的预测候选框并设置相关的阈值条件筛选合适的预测框和预测类别。筛选机制的原理,首先一张图像中针对一个对象网络会预测产生多个候选框,通过设置置信度阈值对候选框进行预清理,获得预测目标可能性较高的候选预测框。之后根据置信度分数对所有检测框进行排序,选择最大分数的预测框与剩余预测框计算 IoU 值,抑制 IoU 大于设定 IoU 阈值的预测框。最后重复上述步骤,遍历全部预测框,得到最终目标预测框和置信度。见图 4-8 和 4-9 所示。




图 4-8 筛选机制流程

非极大值抑制方法（NMS）可以在无遮挡情况下筛选出其中可能性较高的预测结果。但面对遮挡缺陷时，多目标相互重叠导致生成的预测框之间重叠面积较大，传统的非极大值抑制方法会将相互重叠的预测框判定为同一个目标从而删除其他冗余的预测框，造成遮挡目标检测的漏检现象。并且缺陷之间的相互遮挡会破坏缺陷的原有的可视结构和形态特征，使得被遮挡目标的标注框被占据了大部分的区域，对后续提取到的高维深度特征区分不同缺陷造成影响。




图 4-9 NMS 计算原理

针对上述传统 NMS 方法筛选策略的缺点，本文分别将 Soft NMS^[200]和 DIoU NMS 加入本文方法中替换传统 NMS 方法，以探索适用于铝板带遮挡缺陷的检测场景的筛选策略。

(1) Soft NMS

Soft-NMS 通过线性加权或高斯加权的方式抑制重叠度高的其他预测框的置信度，降低同一目标的其他预测框的重要程度，更多的保留被遮盖物体生成的预测框。不同于传统 NMS 方法中直接对置信度赋 0 的抑制方法，Soft NMS 设置分数更新函数（公式 4-12），通过衰减当前最高得分检测框 M 有重叠的相邻检测框的置信度分数，有效减少高度重叠预测框的假阳性结果，在一定程度上防止了过度的删除产生的漏检情况。

$$S_i = s_i e^{-\frac{iou(M, b_i)}{\sigma}}, \forall b_i \notin D \quad (4-12)$$

其中， b_i 表示当前预测框， s_i 表示当前预测框置信度分数， D 表示预测框集合， σ 表示高斯函数惩罚系数。分数更新函数的连续性变化可以防止置信度排序的突变，保持相互不重叠时置信度分数不发生变化，而高度重叠时的抑制效果明显。

Soft-NMS 的计算复杂度为 $O(N^2)$ ，其中 N 为全部参与计算的预测候选框数量。与传统 NMS 的计算量相差不大，不会对网络的检测时间产生较大影响。

(2) DIoU NMS

上述筛选方法均是以 IoU 作为衡量标准。对于重叠关系的描述不够全面依然会限制遮挡物体检测精度，普通 IoU 的计算方法只考虑了预测框与 Ground truth 框的重叠面积，而忽略了两者的中心点距离所反映的位置信息和长宽比所反映的形状信息。对于遮挡情况仅考虑重叠面积，无法全面的反映相互重叠的预测框之间的实际情况，从而导致遮挡目标的预测框被错误抑制。

DIoU-NMS 将损失函数优化和非极大值抑制筛选机制改进结合，通过距离交并比（Distance-IoU，DIoU）重新定义重叠面积，添加一个惩罚项以直接最小化两个边界框中心点之间的归一化距离，如公式 4-13 所示。

$$DIoU(M, b_i) = IoU(M, b_i) - \frac{\rho^2(M, b_i)}{d^2} \quad (4-13)$$

其中， d 表示当前预测框 b_i 与最高分预测框 M 的最小外接矩形的对角线距离， $\rho^2(M, b_i)$ 表示两者的中心点距离。设置分数更新函数，如公式 4-14 所示。

$$S_i = \begin{cases} s_i, DIoU(M, b_i) < set \\ 0, DIoU(M, b_i) \geq set \end{cases} \quad (4-14)$$

DIoU NMS 在抑制冗余框时不仅考虑了重叠区域，还考虑了两个边界框中心点之间的距离。中心点较远并且属于不同对象的两个预测框通过惩罚因子衰减置信度分数而不是直接赋 0，在一定程度上提升对于距离相近的遮挡物体的检测精度。其算法复杂度与传统 NMS 相差不大，便于嵌入任何目标检测算法的边界框回归计算中。筛选后的预测框与真实 Ground truth 之间的匹配度更高，有效地改善遮挡情况下预测框之间相互交叠导致的过度删除的漏检情况。

4.3 铝板带表面遮挡缺陷的检测实验与对比

4.3.1 遮挡缺陷数据集的构建

目前,针对遮挡目标检测的标准数据集均是面向日常物体检测和人群检测等场景,缺乏相关的工业缺陷遮挡目标开源数据集。由于遮挡场景的特殊性,本文构建的铝板带表面缺陷数据库中真实场景下的遮挡缺陷图像的数量很难符合用于模型训练的专业要求。因此,为了更准确的验证和衡量本文方法对于遮挡缺陷的检测效果,本文构建铝板带表面遮挡缺陷数据集,通过将数据库中真实缺陷人为添加多种遮挡效果,实现遮挡图像的生成。

该数据集包含图像共 8652 张,包括实际场景中出现遮挡情况的 7 种缺陷类型:凸点,脏污,黑点,辊印,擦伤,压过划痕和波浪纹,以及干扰缺陷检测的两种伪缺陷:水痕和冲击反光。其中训练及验证集占总图像数量的 80%,共 6921 张。测试集图像数量为 1731 张,占数据集总图像数量的 20%。为了保证测试集对于模型检测效果的准确性,全部测试图像均为实际检测场景中采集的真实遮挡图像,包括类间遮挡、类内遮挡、无遮挡、伪缺陷遮挡等多种情况。而训练及验证集通过人为添加随机遮挡效果,保证训练集中各类型缺陷数量较为平衡且不同遮挡程度的图像数量较为平衡,从而控制样本不均衡和少样本条件等多种因素对模型训练的影响。

本文通过裁剪不同缺陷类型及多种背景干扰的子图块对训练集图像样本进行不同程度的随机遮挡,其中遮挡程度按 4.2.1 节的定义,设置为无遮挡(0%),轻微遮挡(0-30%),部分遮挡(30-65%)以及严重遮挡(65%以上)。同时用于遮挡的裁剪后子图块主要包括黑点、凹坑、擦伤、压过划痕、脏污、水痕和冲击反光。遮挡后缺陷图像样本如图 4-10 所示。

为保证模型训练的泛化性,训练集中各遮挡缺陷类型数量保持一致防止样本不平衡造成的过拟合现象,并且设置一部分的独立缺陷样本(一个样本图像中只含有一个检测目标)使模型能更好的学习区分不同缺陷类型特征信息。训练集和测试集中各类型目标统计情况如表 4-2 和 4-3 所示。




图 4-10 遮挡后缺陷图像样本：(a) ~ (e) 缺陷间遮挡，(f) ~ (j) 干扰遮挡

表 4-2 训练集和测试集各缺陷类型数量

缺陷类型	训练集及验证集	测试集
凸点	1842	474
脏污	2433	828
黑点	2498	638
辊印	2298	778
擦伤	3313	624
压过划痕	1352	371
波浪纹	1552	274

表 4-3 训练集和测试集样本遮挡等级数量统计

	训练集及验证集	测试集
伪缺陷遮挡	1200	300
无遮挡（0%）	806	202
轻微遮挡（0-30%）	1469	367
部分遮挡（30-65%）	1031	258
严重遮挡（65%以上）	1235	309
单独缺陷	1187	297
共计	6929	1732

4.3.2 遮挡目标检测效果评价指标

本文结合日常目标遮挡检测的评价指标，设置五个指标用于评价铝板带表面遮挡缺陷检测的模型检测性能，分别为 mAP，精度，召回率和丢失率

(MR)。前三项作为目标检测模型检测性能的主要评价指标，全面的衡量了模型在检测准确度和分类正确率上的性能，已在上一章节中进行了详细的阐述。丢失率 MR (Miss Rate) 表示了检测结果中的缺陷目标没有被检出的数量与总体样本数量的比值，数值越小表示检测性能越好。

4.3.3 模型训练及超参数设计

基于 3.3.5 节的自适应 anchor box 缩放方法，通过对训练集中目标 Ground truth 的尺寸分析，设置 3 组 9 个 anchor box 为 (11, 16), (53, 60), (26, 147), (235, 62), (111, 372), (94, 608), (127, 608), (608, 244) 和 (338, 608)，如图 4-11 所示。




图 4-11 聚类后原始 anchor box 和线性缩放后的 anchor box 对比 (灰色为聚类后 anchor box, 红绿蓝分别为三组缩放后 anchor box)

本章节中数据集样本的分辨率尺寸为 608 pixel×608 pixel，并且加入 Mosaic 和 Mixup 的数据增强策略。为防止模型过快收敛训练不完全等情况，本章全部实验通过预训练模型迁移和主干网络微调的方式对网络模型进行训练以提高训练效果。训练过程分为两个阶段：首先将大型数据集的预训练权重载入缺陷检测网络模型。前 30 epoch 作为主干冻结训练阶段，用于特征提取的主干网络权重固定为预训练权重，对其他权重参数进行训练，这样可以防止缺陷数据集在网络训练初始阶段对模型训练的误导和超参数调节能力不足从而影响网络正常收敛，导致模型泛化性下降。该阶段的 batch size 设置为 8，动量设置为 0.9。30 epoch 之后，解冻主干网络，模型中的全部权重参数参与模型的训练。由于参与计算的参数量过多，将该阶段的 batch size 设置为 4，动量设置为 0.9。总训练 epoch 设置为 100 次，通过验证集验证保留最优 mAP 值的权重作为最终模型训练权重，用于后续测试集的性能验证。训练过程中本文模型的验证集和训练集损失曲线，如图 4-12 所示。

为了减缓模型在初始阶段对 mini-batch 的提前过拟合现象以及模型深度的

稳定性在前 3 个 epoch 使用 warm up 策略。随后的 epoch 采用随机梯度下降 (SGD) 优化器对模型进行迭代优化, 并采用余弦退火衰减法调整学习率, 设置初始学习率为 0.01, 终止学习率为 0.0001。权值衰减系数为 0.0005。

本章节所有实验均在 Intel (R) Xeon (R) CPU E5-2660 v3 @ 2.60GHz 的工作站上进行, 采用 128 GB DDR4 内存和 8 GB NVIDIA Quadro M4000 图形处理单元 (GPU)。实验所用代码编译环境均基于 Python 3.6, Pytorch 1.7, CUDA 10.1 和 CUDNN 7.6 实现。




图 4-12 训练过程损失函数

4.3.4 遮挡缺陷的检测结果与消融实验

(1) 遮挡缺陷检测结果

将训练后的模型权重载入, 对由真实遮挡数据组成的测试集样本进行检测实验, 以评估模型在不同的遮挡等级下各缺陷类别的准确度和有效性。表 4-4 显示了本章所提出方法面对不同程度遮挡问题时 7 种类型缺陷的检测 mAP、精度 Prec、召回率 Rec 和丢失率 MR。

从表 4-4 中可以看出, 本章所提出的抗遮挡的缺陷检测方法在遮挡程度不严重的情况下能够保持良好的检测性能, 缺陷目标的丢失率小于 10%。当缺陷目标的遮挡程度大于 30% 时, 对缺陷目标的分类精度保持稳定, 但是丢失率却大大升高; 特别是当缺陷遮挡程度达到 65% 以上时, 检测性能下降较为严重, 丢失率较高。这直观证明了本章方法对轻微遮挡等级的缺陷目标可以达到检测要求的准确度; 而面对严重遮挡时, 依然没有较好的手段提升检测精度。造成

这种现象的主要原因是大面积的遮挡破坏了缺陷间的特定类别特征的信息表达，仅通过对直观特征的分析或者是通过候选框的生成和筛选是无法解决的。而小面积遮挡通过增强上下文信息的提取能力能够弥补相互遮挡造成的特征信息损失，从而实现良好的检测准确度。对于伪缺陷的遮挡，各缺陷类型的准确率为正常情况下的检测结果基本保持一致，说明在复杂背景环境中本章方法具有优秀的抗干扰能力。

表 4-4 不同遮挡程度各类型缺陷检测结果 (%)

遮挡程度	评价指标	凸点	脏污	黑点	辊印	擦伤	压过划痕	波浪纹
无遮挡	mAP	90.15	88.66	93.91	95.28	91.55	87.54	99.46
	Prec	90.18	87.14	91.04	93.75	90.41	86.94	94.05
	Rec	94.68	98.69	93.24	97.56	92.25	96.32	98.75
	MR	5.32	1.31	6.76	2.44	7.75	3.68	1.25
轻微遮挡 (0-30%)	mAP	99.20	99.13	96.67	89.94	94.75	91.49	99.03
	Prec	86.15	98.94	95.05	88.94	94.50	96.30	98.69
	Rec	100.00	100.00	92.31	91.47	89.29	87.43	100.00
	MR	0.00	0.00	7.69	8.53	10.71	12.57	0.00
部分遮挡 (30-65%)	mAP	93.00	83.28	87.85	90.14	73.28	76.01	85.07
	Prec	96.19	92.98	92.09	95.35	72.98	79.01	97.92
	Rec	84.87	75.88	83.43	78.56	85.12	69.02	80.13
	MR	15.13	24.12	16.57	21.44	14.88	30.98	19.87
严重遮挡 (65%以上)	mAP	68.97	79.37	75.73	77.08	39.76	28.49	73.32
	Prec	90.48	95.10	90.24	95.02	40.91	32.45	90.62
	Rec	50.33	76.38	67.89	66.57	42.86	39.92	59.29
	MR	49.67	23.62	32.11	33.43	57.14	60.08	40.71
伪缺陷遮挡	mAP	94.52	99.20	88.75	97.13	90.56	88.52	97.25
	Prec	92.16	98.00	87.69	95.88	82.76	86.63	95.40
	Rec	95.92	100.00	85.00	94.90	90.01	89.05	100.00
	MR	4.08	0.00	15.00	5.10	9.99	10.95	0.00
总计	mAP	89.17	89.93	88.58	89.91	77.98	74.41	90.83
	Prec	91.03	94.43	91.22	93.79	76.31	76.27	95.34
	Rec	85.16	90.19	84.37	85.81	79.91	76.35	87.63
	MR	14.84	9.81	15.63	14.19	20.09	23.65	12.37

具体分析各缺陷类型的检测结果,可以看出单独型缺陷(如黑点、凹坑)由于类间差异性较大,检测的分类精度一直保持在90%以上,但是丢失率随着遮挡程度的严重而上升,特别是小尺寸的缺陷目标漏检情况较为严重。遮挡问题对于条状缺陷(如擦伤和压过划痕)的影响较为严重,在遮挡面积超过30%时,其检测精度和检出率都出现了严重下降。这主要是因为条状缺陷被遮挡后,模型容易将部分区域判断为一个目标。对于区域型缺陷(如辊印、波浪纹和脏污)由于目标自身尺寸较大,相互的交叠对模型的判断影响较小。检测结果可视化情况如图4-13所示。




图 4-13 检测结果

(2) 消融实验

本文以 YOLOv4 作为基线模型对本章方法进行消融实验对比，以验证改进模块对于遮挡缺陷检测性能的有效性。实验通过在基线模型中分别加入包含 CFE Unit 的提取网络、多层级融合网络 MBF、加权斥力损失函数 $Loss_{WR}$ 以及改进的 NMS 预测筛选模块等，采用上节所用训练策略和超参数设置进行模型训练，所得训练权重均在测试集中完成实验对比，实验结果如表 4-5 所示。

表 4-5 基于 YOLOv4 基线模型的消融实验结果

实验 编号	CFE Unit	MBF	$Loss_{WR}$	改进的 NMS 预测筛选	mAP
1	-	-	-	-	74.01
2	√	-	-	-	81.92
3	-	√	-	-	79.47
4	-	-	√	-	77.38
5	-	-	-	√	76.92
6	√	√	-	-	84.13
7	-	-	√	√	78.81
8	√	√	√	√	88.53

由表 4-5 结果可以看出，本章所提出的方法将遮挡目标的检测性能从 mAP 值 74.01% 提升至 88.53%，证明上述模块改进措施的有效性。相较于原始 YOLOv4 基线模型，CFE 特征提取模块的嵌入将检测性能提升了 7.91%，MBF 融合网络的改进使 mAP 上升了 5.46%，说明通过空洞卷积特征提取模块和多层级特征融合，丰富了特征图种所含的语义信息，增强了特征的表达能力。加权损失函数模块的改进，使模型的准确度比原始基线模型增加了 3.37%，改进后的筛选机制使检测性能上升 2.91%，证明了斥力函数增强生成预测框的定位准确度。但是根据实验 6 和实验 7 的结果对比，说明对于特征信息提取的改进手段其检测效果比仅仅改进损失函数和筛选机制更有效。

4.3.5 遮挡缺陷检测性能对比实验

为了验证本章所提方法对于遮挡缺陷检测的有效性和性能提升程度，将本章所提模型与目前经典的目标检测主流方法进行对比实验，其中包括 Faster R-CNN，YOLOv3，YOLOv4，SSD 以及 CenterNet 等。对比实验均采用 4.4.1 所述训练集进行模型训练，训练权重均在同一测试集中进行性能验证，训练策略和相关超参数设置均与 4.4.3 所述保持一致。表 4-6 显示了不同算法对于不同遮挡等级的缺陷目标的检测性能。

由表 4-6 的结果可以看出，本章所提模型在降低缺陷目标丢失率方面的先

进性。相比于 YOLOv3 和 YOLOv4 基线模型，在轻微遮挡和部分遮挡等级，缺陷目标的丢失率分别减小了 38.99%和 46.57%以上。SSD 模型虽然分类准确度较高，但是丢失率也非常大。特别是对于条状缺陷，检出率只能达到 10-20%。与 Faster R-CNN 相比，本章模型在无遮挡、轻微遮挡及伪缺陷遮挡的精度与其相差不大。但是当遮挡面积超过 30%时，Faster R-CNN 模型的目标丢失率较高。值得注意的是，对于严重遮挡的缺陷目标，全部对比方法的检测精度较低，丢失率均达到 60%以上，说明了被严重遮挡的缺陷目标的检出难度较大。

表 4-6 与其他经典目标检测方法对比结果 (%)

算法	评价标准	无遮挡	轻微遮挡	部分遮挡	严重遮挡	伪缺陷	总计
Faster R-CNN	mAP	74.96	89.81	85.58	58.57	87.15	80.76
	MR	13.32	5.77	8.17	34.68	9.94	12.86
SSD	mAP	66.96	75.18	63.18	33.12	83.20	70.43
	MR	52.22	36.11	46.50	64.83	37.21	51.91
YOLOv3	mAP	78.07	86.04	73.47	40.63	81.33	69.42
	MR	31.99	32.08	51.09	63.23	16.21	35.36
YOLOv4	mAP	83.07	83.26	67.64	40.37	75.62	74.01
	MR	32.62	41.89	57.47	66.52	41.62	45.53
CenterNet	mAP	74.86	96.25	85.03	53.29	85.30	80.62
	MR	43.77	32.16	49.79	61.03	49.84	45.17
Ours	mAP	89.34	98.28	94.09	73.49	93.98	88.53
(AO-YMAD)	MR	7.97	2.90	10.90	62.45	7.19	13.59

同时为探寻最优损失函数及预测筛选机制，将不同的损失函数与 NMS 筛选机制进行多种组合，植入不同的目标检测框架中进行对比训练。其中用于对比的组合有基于 YOLOv4 的 CIoU, SIoU 的损失函数，基于 Faster RCNN 的 Rep Loss，以及本章所提网络框架结合 Soft NMS 和 DIoU NMS 的组合方式等。使用相同训练集训练后所得权重在测试集数据进行验证，网络检测性能结果如表 4-7 所示。

由表 4-7 结果可知，将本章所提出模型的损失函数筛选机制替换为 DIoU NMS 后，检测准确度下降了 1.69%，缺陷目标的丢失率上升了 2.32%，说明了 Loss_{SWR} 结合 Soft NMS 的筛选机制在遮挡检测中的有效性。而通过改进 IoU 计算方式，YOLOv4 基线模型的检测性能并没有较大的提升，说明在遮挡目标检测问题上仅改进不同的 IoU 计算方式并不能有效的解决密集目标的漏检问题。

对于 Faster R-CNN 模型结合斥力损失函数的方法，可进一步提升 Faster R-CNN 模型的检测精度，有效改善遮挡情况下漏检的问题。这也说明斥力函数可更精准地对生成预测框进行定位。

表 4-7 不同筛选机制检测结果对比 (%)

对比方法	损失函数及筛选机制	mAP	MR
Faster R-CNN	Rep Loss	93.51	17.92
	CIoU	74.01	45.53
YOLOv4	SIoU	73.61	44.82
	DIoU NMS	75.03	41.37
Ours (AO-YMAD)	Loss _{WR} +Soft NMS	88.53	13.59
	DIoU NMS	86.84	15.91

为保证生产效率不会受到检测速度的影响，通过对比不同方法的检测速度和模型容量，以保证本章所提方法可适用于铝板带生产现场的工业检测任务。表 4-8 中展示了不同的检测方法的实验检测速度和模型权重大小。

表 4-8 不同方法的检测速度对比结果

对比方法	模型大小 (MB)	检测速度 (f/s)
Faster R-CNN	478	3.294
SSD	93.1	19.836
YOLOv3	235	8.046
YOLOv4	245	7.113
CenterNet	127.9	16.475
Ours (AO-YMAD)	146	11.046

在表 4-8 中可以看出，本章提出的基于 YOLO 的遮挡缺陷检测方法在 mAP 为 85.5%时实现了 11.046 f/s 的推理速度，达到了单阶段检测方法保证检测速度和检测准确性的目的，适合于铝板带表面工业检测对于检测速度精度的要求。相比于 YOLOv3 和 YOLOv4 基线模型，在检测速度相差 3 和 3.933 的情况下，检测精度提升了 20%。Faster R-CNN 方法需要额外的候选框预测网络，所以其检测速度明显慢于其他检测方法。CenterNet 由于不需要使用 anchor box 对多尺度的特征图进行解码，其网络结构较简单，检测速度快于本文方法。SSD 使用单尺度框架且层级较浅结构简单，因此检测速度比本文方法快大约 40%。上述结果进一步证明了本文提出的方法可以在面对遮挡目标检测时，保持更精准、

快速、稳定的检测性能。图 4-14 展示了不同方法在速度与精度的对比结果。




图 4-14 检测速度与精度的对比结果

4.4 本章小结

本章针对工业场景下铝板带表面出现的缺陷相互交叠以及反光、污渍等伪缺陷干扰，导致的检测系统出现严重的漏检、误检现象，难以保证较高的准确度和满足工业生产的质量分级检测要求。因此，本章提出了一种基于上下文信息和斥力损失的多层级遮挡缺陷检测方法，适用于铝板带表面的端到端在线检测，提升 YOLO 检测方法在面对密集、重叠缺陷目标时的检测性能。具体总结如下：

（1）首先，构建基于 RFB-Net 结构的空洞卷积特征提取网络。利用空洞卷积可有效扩大感受野的特点，结合 RFB 网络的多分支卷积结构，构建基于上下文信息缺陷特征提取网络。通过不同支路所提取的不同扩张程度的缺陷特征相互融合，弥补不同尺度之间的信息损失并有效规避了单一空洞卷积出现的网格效应。主干网络更好的捕获特征图中的上下文信息并避免背景中的冗余噪声对检测性能的负面影响。

（2）设计基于 Bi-FPN 的多层级交叉特征融合网络，多尺度特征图间通过跨层双路径融合结构，充分融合不同尺度的浅层细节特征和深层语义特征，避免顺序采样造成的特征信息损失并解决低分辨率的深层特征难以区分密集重叠的缺陷特征。同时，植入层聚合单元代替融合网络的普通卷积操作，达到节省内存的访问成本、提高计算效率的作用。

（3）提出一种结合斥力损失函数和 Soft-NMS 的加权损失函数及筛选机

制，通过目标的真实框驱动预测框的回归计算，引导模型提高对不同类别相似对象预测框的排斥权重，以提高对相互遮挡的不同类别缺陷间的区分能力。并且结合 Soft-NMS 的自适应置信度更新函数，提高模型对冗余预测框的筛选能力，减小重叠目标预测框被过度删除的弊端。该模块加强了遮挡目标检测时模型对相似物体的区分能力以及在背景和密集目标干扰情况下的准确定位能力，

（4）实验结果表明，本章节所提算法对于密集遮挡缺陷检测的优秀的抗干扰性能，整体检测精度达到 88.53mAP。当缺陷遮挡面积小于 65%时，本文方法的缺陷目标丢失率均小于 10.9%。与其他目标检测方法相比，对于遮挡缺陷的检测准确度提高了 15.02%以上，丢失率下降了 38.9%以上。证明了本章方法有效地改善了目标检测方法对于不同遮挡等级缺陷的漏检现象，并且具有良好的诊断速度满足实际工业在线检测的要求。

第5章 融入注意力机制的YOLO网络轻量化与铝板带表面缺陷检测

深度学习在检测、分类等任务中的良好表现依赖于其庞大的网络规模，而实际工业检测要求系统具有良好的精度、较高的实时性和高度集成化。庞大算法规模与快速实时性之间的矛盾制约了基于深度学习检测算法的工业实时应用。前两章中针对铝板带表面缺陷存在的检测精度不佳问题进行了研究，但是YOLO框架的模型规模和检测速度依然无法满足工业生产的检测实时性要求。

因此，本章提出一种基于注意力机制的轻量化表面缺陷检测方法。在YOLO框架的基础上，结合深度可分离卷积和GhostNet轻量化卷积操作压缩网络规模，减小计算消耗，加快缺陷检测速度。同时，利用基于通道信息的采样方式和嵌入通道空间注意力并行计算结构，保证算法检测精度。实现轻量级模型对多尺度目标的准确检测，解决铝板带流程化加工面临的实时工业检测速度问题，为后续嵌入式平台的部署提供了理论支持。

5.1 卷积神经网络的轻量化技术

由于铝板带生产过程的连续性和高速化，要求检测系统能够保证对生产状况的实时反馈和预警。缺陷检测算法需要具有处理连续图像流和数据运算的能力，不能出现漏检或者较长的延时。因此，检测系统的可靠性和实时性是衡量检测系统是否适应于实际检测的重要标准。

基于深度学习的缺陷检测算法，为保证检测结果的可靠性需求往往设计复杂的网络结构和庞大的网络层数，通过对卷积操作的不断组合、重复运算以提高网络对于缺陷特征的抓取能力，这也极大的降低了深度学习方法的检测效率。一方面，模型中大量的权重参数的存储消耗设备内存；另一方面，网络中运算参数量的增加导致图像的数据运算时间延长。为了解决这个瓶颈问题，通常采用提升处理硬件或模型轻量化的手段。高性能运算服务器的部署需要随之提升系统的数据通讯传输能力以保证系统的实时性和稳定性。而工业检测现场的环境干扰因素较多，特别是会对数据传输通讯造成影响，从而对检测系统的稳定性造成隐患。另一个需要面临的问题是，铝板带材的生产设备形式多样，部分生产设备可允许的安裝空间有限，现阶段的大型检测设备无法进行部署。因此，通过对深度学习检测模型的轻量化研究，实现检测系统由大型化向小型化、集成化的嵌入式边缘设备转型，降低设备安装对于环境、空间等硬件条件的要求，拓宽检测系统的适用范围和适用对象。

目前，关于深度学习网络的模型轻量化^[201]研究主要分为两个方向：现有模型的结构压缩和低冗余度网络的设计。基于现有模型压缩方法，在预训练模型

原有结构的基础上, 通过一些简化策略对模型的权重参数和网络结构进行删减, 达到模型缩减的目的。如模型参数修剪^[202]、卷积核稀疏性^[203]、权重量化^[204]、蒸馏^[205]和张量分解^[206], 均已被应用在农业生产^[207]、交通运输^[208]、航空航天^[209]等领域。但是这类方法改变了原有网络结构中不同网络层之间的通道数, 从而限制了嵌入优化模块的自由度, 并且原有模型中植入的先验知识对简化后模型的性能和稳定性有显著的影响; 低冗余网络结构的设计, 直接利用更高效的卷积计算方式获取特征信息, 减少传统卷积的计算冗余的同时不损失卷积提取到的特征信息表达。相比于预训练后结构压缩, 这种方式具有更好的可移植性, 可以与多种目标检测网络结构相互结合, 最大程度利用原本目标检测框架的优势。因此, 许多金属材料的工业缺陷检测研究^[138, 210, 211]着眼于低冗余卷积结构与目标检测框架相结合的网络设计, 实现网络规模的压缩和内存消耗的减少, 从而提升工业检测速度。常见的低冗余卷积计算结构包括 SqueezeNet^[212], MobileNet^[213-215], ShuffleNet^[216, 217], GhostNet^[218]等。

(1) MobileNet

MobileNet 模型框架^[213]是 Google 于 2017 年提出的一种用于移动端的轻量化卷积神经网络结构, 通过深度可分离卷积来降低传统卷积计算参数过多的问题。在后续的优化中引入倒残差结构^[80]、线性瓶颈层、激活函数和注意力机制等, 逐渐形成 MobileNet V2^[214]、MobileNet V3^[215]。这些优化模块减小了激活函数导致的有效特征信息丢失, 并且增强了特征图中重要通道的权重, 削弱作用较小的特征通道, 使得模型规模减小的同时, 检测性能不断提升。

深度可分离卷积是将传统的卷积操作分解为深度卷积 (Depthwise Convolution) 和逐点卷积 (Pointwise Convolution) 两步。首先, 深度卷积是将卷积核拆分成单通道形式 $D_K \times D_K \times 1$, 针对特征图的每一个通道分别采用对应的单通道卷积核进行卷积操作。由于单通道操作不改变特征图深度, 所以输出特征图通道数与输入特征图通道数一致。之后, 逐点卷积采用 1×1 卷积核调整深度卷积后输出的特征图通道数, 使特征图升维或降维符合卷积操作要求, 如图 5-1 所示。

设置输入特征图大小为 $D_F \times D_F \times M$, 输出特征图大小为 $D_F \times D_F \times N$, 卷积核为 $D_K \times D_K$ 。完成一次深度可分离卷积的参数量为:

$$P_1 = D_F \times D_F \times M \times D_K \times D_K + D_F \times D_F \times M \times N \quad (5-1)$$

而一次传统卷积操作参数量为:

$$P_2 = D_F \times D_F \times M \times N \times D_K \times D_K \quad (5-2)$$

结合公式 5-1 和 5-2, 可知深度可分离卷积与传统卷积操作一次卷积计算量

的比为：

$$\begin{aligned} P_{Dw} &= \frac{P_1}{P_2} \\ &= \frac{D_F \times D_F \times M \times D_K \times D_K + D_F \times D_F \times M \times N}{D_F \times D_F \times M \times N \times D_K \times D_K} \\ &= \frac{1}{N} + \frac{1}{D_K^2} \end{aligned} \tag{5-3}$$




图 5-1 深度可分离卷积原理示意图




图 5-2 MobileNet 卷积模块 Bneck block

可以看出单次卷积操作，深度可分离卷积的计算量和参数量急剧减少。利用深度可分离卷积并结合宽度因子和分辨率因子构建 MobileNet 卷积模块 Bneck block，如图 5-2 所示。线性瓶颈层的设计可以减少非线性激活函数在特征图维度较低时造成的有效特征信息丢失；逆残差结构中升维再降维的设计可以弥补深度可分离卷积操作导致的特征复杂度不足的情况；注意力机制提升了网络的特征提取能力。最终，在提升 MobileNet 卷积的识别精度的同时，保持高速的计算速度。

(2) ShuffleNet

2017 年，旷视科技在深度可分离卷积的基础上提出了一种基于分组思想的轻量化网络结构 ShuffleNet^[216]，通过通道重排（channel shuffle）操作减少残差结构中 1×1 卷积（pointwise group convolutions）导致的通道数量拥挤，进一步降低网络中大量的逐点卷积计算成本并保持特征提取的信息不损失。

ShuffleNet 卷积块基于 ResNet 网络残差结构（图 5-3 所示）由 1×1 卷积、 3×3 深度可分离卷积和 1×1 卷积顺序连接组成。由于密集的全通道 1×1 卷积计算依然存在巨大计算量，因此引入逐点分组卷积将特征图分组与相应卷积核进行操作并将各组结果拼接后作为最终输出。根据公式 5-4 所示，没有分组的情况下，例如深度可分离卷积中的逐点卷积计算量为 $D_F \times D_F \times M \times N$ 。当分组数为 g 时， 1×1 逐点分组卷积的计算量为：

$$P_3 = \frac{D_F \times D_F \times M \times N}{g} \quad (5-4)$$




图 5-3 ShuffleNet 卷积块

可以看出，相比于不分组的逐点卷积，逐点分组卷积分组数量越多计算量缩减程度越明显。但是由于分组计算后不同组别的特征信息无法相互通信，使得网络对特征的提取能力降低，因此，通过通道重排将分组的特征图打乱重新组合，使不同组的特征信息相互流动，避免特征信息无法传递或丢失的问题，如图 5-4 所示。




图 5-4 通道重排过程

(3) GhostNet

逐点卷积或者逐点分组卷积使用的 1×1 卷积核依然会占用相当大的内存和 FLOPs。因此，华为于 2020 年提出了一种新的冗余特征图删减模式 GhostNet^[218]，通过线性变换在相似特征图对之间进行替代来减少特征图的大量冗余信息，降低计算参数。首先，采用 1×1 卷积对特征图维数进行压缩，然后利用线性变换扩展得到这些特征图的 Ghost 特征。将两部分拼接生成输出的特征图，原理如图 5-5 所示。




图 5-5 Ghost 模块原理示意图

输入特征图 X 为 $D_F \times D_F \times M$ ，输出特征图 Y 为 $D_F' \times D_F' \times N$ 。首先，使用卷积核 $f' \in M \times D_K \times D_K \times c$ 将输入特征图转换为映射特征图 $Y' \in D_F' \times D_F' \times c$ ，且 c 小于 N 。

$$Y' = X * f' \quad (5-5)$$

之后，对输出的映射特征图 Y' 的每一维分别进行线性运算，生成 s 个 Ghost 特征图：

$$y_{ij} = \Phi_{i,j}(y'_i), \quad \forall i=1, \dots, c, j=1, \dots, s \quad (5-6)$$

其中， y'_i 是映射特征图 Y' 中的第 i 个特征图， $\Phi_{i,j}$ 表示第 i 个特征图的第 j 个线性运算，表明了 y'_i 可以生成多个 Ghost feature。 $\Phi_{i,s}$ 用于保留特征图 Y' 的恒等映射。最后，输出的特征图 Y 为 $[y_{11}, y_{12}, \dots, y_{cs}]$ ，其中特征图维度 $n=c \times s$ 。

相比于以上两种均使用逐点卷积的轻量化卷积结构，Ghost 结构利用计算量较小的线性运算去增强特征和增加通道，避免了深度卷积或者通道重排运算的限制。同时 Ghost 结构中的线性运算和恒定映射结合，可以更好的保存本征特征。对于 Ghost 卷积结构完成一次卷积操作的计算量为：

$$G_1 = \frac{N}{s} \times D_F' \times D_F' \times M \times D_k \times D_k + (s-1) \times \frac{N}{s} \times D_F' \times D_F' \times d \times d \quad (5-7)$$

其中线性运算的内核大小为 $d \times d$ 。而一次普通卷积操作计算量为：

$$G_2 = N \times D_F' \times D_F' \times M \times D_k \times D_k \quad (5-8)$$

结合公式 5-7 和 5-8，可知 Ghost 模块与普通卷积计算量之比为：

$$\begin{aligned} S = \frac{S_1}{S_2} &= \frac{\frac{N}{s} \times D_F' \times D_F' \times M \times D_k \times D_k + (s-1) \times \frac{N}{s} \times D_F' \times D_F' \times d \times d}{N \times D_F' \times D_F' \times M \times D_k \times D_k} \\ &= \frac{\frac{1}{s} \times M \times D_k \times D_k + \frac{(s-1)}{s} \times d \times d}{M \times D_k \times D_k} \approx \frac{s+M-1}{M \times s} \approx \frac{1}{s} \end{aligned} \quad (5-9)$$

其中， $d \times d$ 与 $D_k \times D_k$ 的数量级别相似， $s \ll M$ 。与此相似，Ghost 模块与普通卷积的参数压缩比为：

$$C = \frac{C_1}{C_2} = \frac{\frac{N}{s} \times M \times D_k \times D_k + (s-1) \times \frac{N}{s} \times d \times d}{N \times M \times D_k \times D_k} \approx \frac{M+s-1}{s \times M} \approx \frac{1}{s} \quad (5-10)$$

从上述计算结果可以看出，Ghost 模块可以使参数运算量和压缩率明显减小，并且避免使用逐点卷积造成的内存消耗。

5.2 融入注意力机制的YOLOv4网络 GhostNet 轻量化方法

5.2.1 YOLOv4 轻量化网络整体框架

为了探究上述轻量化卷积技术能否实现在 YOLO 框架中实现铝板带表面缺

陷检测，并解决实际缺陷检测工业应用时轻量化网络压缩率与缺陷检测准确度无法平衡的矛盾。本章基于 YOLOv4 基本结构框架，通过融合注意力机制的轻量化卷积网络模块和基于多通道多尺度的特征融合模块的结合，缩减 YOLO 网络规模，进一步提高检测速度和检测精度，实现铝板带表面缺陷的快速、准确检测。本章所提出的轻量化检测方法（YAD-GM）网络框架如图 5-6 所示。




图 5-6 轻量化检测方法（YAD-GM）网络框架

Backbone 中，将样本图像（ $608 \times 608 \times 3$ ）输入由轻量化卷积块单元堆叠组成的特征提取网络 GMANet 中，从三个层级获取不同尺度的缺陷特征图，分别为浅层特征图（ $76 \times 76 \times 40$ ），中层特征图（ $38 \times 38 \times 112$ ）和深层特征图（ $19 \times 19 \times 960$ ）。同时，在部分层级的卷积块中嵌入基于并行通道空间联合注意力机制模块（UAM），自适应细化特征提高模型泛化能力。Neck 部分，构建基于 PANet 的双路径特征金字塔结构进行特征融合并在深层级中加入 SPP 结构，多层次特征图的缺陷信息相互融合使模型更好的学习多层次的复杂特征映射并扩大感受野。利用 Pixelshuffle 和 Passthrough 采样模块对特征图多次反复缩放以统一不同尺度特征图尺寸。在 Head 预测层中，设计基于 CIOU loss 和 Focal loss 的损失函数并结合自适应 anchor box 对输出特征图（ $76 \times 76 \times 36$ ）、（ $38 \times 38 \times 36$ ）和（ $19 \times 19 \times 36$ ）3 个尺度矩阵解码，实现样本不均衡条件下铝板带表面缺陷的快速准确检测。

5.2.2 基于 Ghost 卷积的轻量化主干网络构建

主干网络通过不断堆叠卷积层增加网络深度强化拟合能力，减小网络误

差。但是实际训练中，网络深度增加到一定程度时，会产生网络梯度消失的问题，导致训练效果不理想。借鉴 ResNet 中残差结构的设计，基于 Ghost 卷积的优势，设计 Ghost block 卷积单元用于整合卷积层和捷径层，解决网络退化和梯度消失的问题。同时，结合 MobileNet V3 轻量化网络结构，通过堆叠多个不同步长的 Ghost block 构成轻量化主干网络 GMANet 以替换 YOLO 主干网络部分，缩减主干网络规模，加快特征提取计算速度和网络收敛速度，并精准提取不同缺陷所表达的特征信息。

(1) Ghost block 卷积单元

如图 5-7 所示，Ghost block 卷积单元由堆叠的 Ghost 模块和 short cut 结构组成。当步长为 1 时，通过两个 Ghost 模块先增加后缩减通道数和膨胀层，形成纺锤型结构用于匹配 short cut 捷径层的通道数量；当步长为 2 时，在两个 Ghost 模块之间插入步长为 2 的 3×3 深度卷积实现下采样功能，达到减小输入特征图尺寸并控制卷积操作占用计算量的目的。此外，每一层 Ghost 模块后使用 ReLU 激活函数和批归一化操作。




图 5-7 Ghost block 卷积单元结构

(2) GMANet 网络结构构建

借鉴 MobileNet V3 结构设置，通过不同步长的 Ghost block 组合不断增加模型深度并减小特征图尺寸，从而构建缺陷检测的轻量化主干网络 GMANet。输入 $608\times 608\times 3$ 的样本图像利用 1×1 的标准卷积和标准化激活后，顺序通过多层 Ghost Block 单元。在第 6 层和第 12 层分别输出特征图 ($76\times 76\times 40$) 和 ($38\times 38\times 112$)，作为浅层级特征图和中层级特征图进入后续 Neck 结构。（而网络最终输出的小尺度特征 ($19\times 19\times 160$) 传递到 1×1 卷积中调整通道数

后，作为深层级特征图（ $19\times19\times960$ ）输出。相比于 YOLOv4 基线模型的主干网络 CPSDarknet，GMANet 主干网络不仅压缩了网络中各层级特征图深度，同时删除了特征图每一维度的冗余特征信息，从而将主干网络参与计算的参数数量缩减了 63.25%。图 5-8 展示了不同层级最终输出的特征图可视化情况，可以看出轻量化模型 GMANet 所提取到的缺陷特征信息并没损失，依然清晰地表达了缺陷特征。




图 5-8 轻量化网络各层级特征图可视化

5.2.3 融入注意力机制的轻量化主干网络优化

特征提取网络轻量化操作会造成特征信息的损失。为了增强不同通道间的

相互依赖关系并强化缺陷特征信息表达,通过在主干网络的 Ghost Block 单元中嵌入注意力机制以增强有效信息较多的通道特征,抑制有效信息少或无效的通道特征,从而弥补轻量化处理后对模型检测准确度造成的损失。常见的注意力机制模块如下:

(1) SE 模块

SE 模块 (Squeeze-and-Excitation module) [219] 由压缩、激发以及特征重标定三个部分组成,结构如图 5-9 所示。首先,通过全局平均池化将输入特征图压缩为 $1 \times 1 \times c$, 获得全局感受野的特征图中每一个通道表示该通道特征信息的权重。之后,通过两个全连接层并结合 ReLU 激活函数,对 $1 \times 1 \times c$ 特征图降维后升维,可以更好的拟合不同通道间复杂的相关性。最后,将激发得到的权重与输入特征图加权操作,实现对特征图中各通道特征的权重重标定。由于 SE 模块通过全连接网络对 Loss 损失进行特征权重自动学习,不可避免的增加了参数量和计算量。




图 5-9 SE 注意力机制结构图

(2) CBAM

CBAM 模块 (Convolutional Block Attention Module) [220] 通过融合特征图的空间注意力与通道注意力,不仅增强了各通道间特征相互的依赖关系,而且更加关注对缺陷分类起作用的区域,忽略无关紧要的区域,从而实现模型检测性能的提升。

输入特征图 $F \in R^{C \times H \times W}$ 首先进入通道注意力模块,分别对其进行全局最大池化和全局平均池化得到压缩后的两个 $1 \times 1 \times c$ 特征向量。将其放入多层感知器,通过两个全连接层对特征向量进行缩放得到各通道统一权重,最大程度的捕获图中纹理信息。使用逐元素求和合并输出通道注意力映射 (channel attention map) $M_C \in R^{C \times 1 \times 1}$ 。通道特征加权后的特征图输入空间注意力模块,通过池化操作聚合特征图中的通道信息,生成两个特征映射 $H \times W \times 1$ 。将其拼接后进行卷积操作和 Sigmoid 函数标准化得到空间注意力映射 (spatial attention map) $M_S \in R^{1 \times H \times W}$ 。具体过程如图 5-10 所示。




图 5-10 CBAM 注意力机制原理

(3) UAM

本章设计了一种基于并行通道空间联合注意机制模块（UAM），通过融合通道注意和空间注意更好地增强具有更有效信息的通道特征，并抑制较少或无效信息；并行结构可以高效地利用特征图中上下文信息，提高了模型的表征能力，自适应细化的特征地图。同时解决了单通道注意力模块无法准确自动定位目标的问题，避免了背景对识别过程的干扰。

图 5-11 为 UAM 的结构示意图。特征图 F_{Input} 并行输入通道和空间注意力模块分别生成两个独立的通道注意力特征图和空间注意力特征图。在通道注意力模块中，通过全局平均池化生成通道特征向量 $F_C \in \mathbb{R}^{C \times 1 \times 1}$ ，将其输入一个隐藏层的多层感知器（multi-layer perceptron, MLP）实现跨通道的注意力估计，可通过设置缩减率控制参数运算量。之后，通过添加批量归一化层（BN）来调整输出的通道比例，最终输出通道注意力特征图 $F_{channel}$ 。

$$F_{channel} = BN(MLP_r(AvgPool(F_{Input}))) \quad (5-11)$$

在空间注意力模块中，特征图 F_{Input} 通过 1×1 卷积在信道维度上进行整合和压缩。压缩后，采用两个 3×3 的扩张卷积来扩大感受野，更高效地利用上下文信息构建特征的空间信息。之后，通过 1×1 卷积和批归一化层获得空间注意力的特征图 $F_{spatial}$ ，用于强调或抑制不同位置的特征。

$$F_{spatial} = BN(f_3^{1 \times 1}(f_2^{3 \times 3}(f_1^{3 \times 3}(f_0^{1 \times 1}(F))))) \quad (5-12)$$

将生成的两个注意力特征图逐元素相加后，使用 Sigmoid 函数对特征图进行标准化处理并嵌入到主干网络 Ghost block 的残差结构中，实现网络准确度的提升，如公式 5-13 所示。该注意力模块的结构简单，参数量和计算量较小，对整个轻量化网络的结构变化影响较小。

$$F_{Output} = F_{Input} + F_{Input} \otimes \sigma(F_{spatial} + F_{channel}) \quad (5-13)$$

经过多次不同组合的测试，将 UAM 注意力模块嵌入主干网络 GMANet 部分层级的 Ghost 单元中构成本章缺陷检测模型的主干网络用于缺陷特征的提

取，具体结构如表 5-1 所示。




图 5-11 UAM 的结构示意图

表 5-1 主干网络结构

输入	卷积结构	扩展层通道数	输出通道	Att	步长
608×608×3	Conv2d,3×3	-	16	-	2
304×304×16	Ghost-Bneck	16	16	-	1
304×304×16	Ghost-Bneck(s=2)	48	24	-	2
152×152×24	Ghost-Bneck	72	24	-	1
152×152×24	Ghost-Bneck(s=2)	72	40	√	2
76×76×40	Ghost-Bneck	120	40	√	1
76×76×40	Ghost-Bneck(s=2)	240	80	-	2
38×38×80	Ghost-Bneck	200	80	-	1
38×38×80	Ghost-Bneck	184	80	-	1
38×38×80	Ghost-Bneck	184	80	-	1
38×38×80	Ghost-Bneck	480	112	√	1
38×38×112	Ghost-Bneck	672	112	√	1
38×38×112	Ghost-Bneck(s=2)	672	160	√	2
19×19×160	Ghost-Bneck	960	160	-	1
19×19×160	Ghost-Bneck	960	160	√	1
19×19×160	Ghost-Bneck	960	160	-	1
19×19×160	Ghost-Bneck	960	160	√	1
19×19×160	Conv2d,1×1	-	960	-	1

5.2.4 基于多尺度的特征融合网络构建

为了丰富多尺度特征图中包含信息并提高模型对不同尺度目标的检测效果，通过对不同层级特征图的相互融合，保证特征的完整性和多样性。因此，结合深度可分离卷积，设计基于 Pixelshuffle 和 Passthrough 的双路径轻量化特征融合结构，通过自下而上和自上而下结构设计解决了高级和低级特征之间路径过长导致的目标定位不准确的问题，同时减小融合操作时频繁卷积计算导致的巨大的参数量。

(1) 基于 Pixelshuffle 和 Passthrough 的采样模块

在不同层级特征融合之前，需要通过上下采样统一不同层级间特征图尺寸。上采样通过插值的方式将低分辨率特征图映射到高分辨率，但是当没有附加信息时插值方法在元素重建和映射过程无法解决适应性低的问题。下采样通过池化操作将高分辨率转换到低分辨率，但是池化方法忽略了不同通道间的相互影响。插值和池化采样方式虽然简单高效，但是依然存在弊端，导致在特殊检测场景中的检测性能受限。




图 5-12 Pixelshuffle 和 Passthrough 的采样原理

受到文章^[124, 221]的启发，Pixelshuffle 和 Passthrough 可代替上述常规采样方法，将不同通道中的特征元素重新排列调整特征图尺寸大小。如图 5-12 所示，Pixelshuffle 将特征图中同一位置的不同通道元素排列组合在同一通道中实现上采样，增加了不同通道特征提取比例从而得到更多的细节信息。特征图从低分辨率 $r^2C \times H \times W$ 转换为高分辨率 $C \times rH \times rW$ ，其中 r 表示缩放比例。与之相反的 Passthrough，通过将相邻的特征元素拆分到不同通道完成高分辨率到低分辨率的下采样，特征图从 $C \times rH \times rW$ 转换为 $r^2C \times H \times W$ 。与插值和池化相比，

Pixelshuffle 和 Passthrough 的采样方式组合不同通道中的特征元素调整特征图的尺寸，能够使网络隐式地、自动地学习特征映射过程，避免人为信息对采样过程的干扰。

(2) 轻量化颈部网络结构优化

由于基于 PANet 结构的双路径融合网络中反复的采样和拼接后依然伴随着大量卷积计算，导致整体网络并没有达到预期的轻量化效果。鉴于上述深度可分离卷积计算量较少的优点，将深度可分离卷积嵌入融合网络并结合 Pixelshuffle 和 Passthrough 采样模块，构建轻量化特征融合网络用于不同尺度间的信息聚合，保证特征表征的完整性和多样性，局部融合结构如图 5-13 所示。




图 5-13 轻量化融合卷积模块

首先，将主干网络输出的深层特征图输入 SPP 模块，进一步提高小目标的局部特征和全局特征的融合效果。之后，将三个层级的特征图（ $76 \times 76 \times 40$ ， $38 \times 38 \times 112$ ， $19 \times 19 \times 960$ ）沿自底向上路径和自上向下路径通过上下采样和多个串联深度可分离卷积层计算，实现不同层级的特征图融合。以中层特征图

(38×38) 为例，浅层特征图 76×76 通过下采样得到 (38×38) 的特征图与原本中层特征图进行拼接后，通过轻量化卷积块处理，最终送入检测层网络。模型的参与计算参数量由 YOLOv4 基线模型的 64,429,405 减少到 12,997,183，模型规模缩减程度达 79.83%。从结构设计上实现了模型的轻量化任务，极大地减小了 YOLOv4 的模型体积和内存消耗。

5.2.5 面对样本不均衡的自适应预测解析层构建

当训练样本中各类别数量不均衡时，模型的训练会受到样本比例的相关先验知识的影响，导致整体检测性能下降。以辊印和擦伤为例，设置不同数量的训练样本，用于验证正负样本和各类别样本数量不均衡对检测精度造成的影响。检测精度变化如图 5-14 所示，保持其他类别样本数量在 300 个左右，当辊印和擦伤数量达到其他类别的 50%，75%，125%和 150%时，训练所得模型的整体精度变化随着样本数量的增加呈现出先增加后减小的趋势。




图 5-14 样本数量与检测精度变化（实线为整体 mAP 值，虚线为该缺陷单独 AP 值）

因此，为了克服样本不均衡对轻量化模型检测精度造成的影响，本章设计了基于 Focal loss^[222]的自适应预测层用于三个尺度特征图的解析和预测框的回归，从而实现最终缺陷目标的预测和定位任务。根据上述章节中自适应 Anchor box 线性缩放聚类方法，计算生成针对本章数据集样本的 Anchor box (27, 43)、(54, 64)、(36, 181)、(31, 605)、(90, 114)、(216, 67)、(100,

209)、(78, 608)、(434, 192), 由小到大对应3个尺度。

整体损失函数 CIOU-Focal loss 如公式 5-14 所示:

$$LOSS_{class} = \sum_{i=1}^3 \mathcal{L}_{CIOU}^i + \mathcal{L}_{focal}^i + \mathcal{L}_{class}^i \quad (5-14)$$

CIOU loss 作为定位损失实现预测框的位置回归, 通过惩罚项 $\mathcal{R}_{CIOU}$ 更精确的衡量预测框的定位准确性, 如公式 5-15 所示:

$$\begin{aligned} \mathcal{L}_{CIOU} &= 1 - CIOU = 1 - (IOU - \mathcal{R}_{CIOU}) \\ &= 1 - IoU + \frac{\rho^2(b^p, b^{gt})}{c^2} + \alpha\nu \end{aligned} \quad (5-15)$$

其中, $\rho^2(b, b^{gt})$ 表示预测框中心点 b 与真实框中心点 b^{gt} 之间的欧氏距离。 c 表示能够同时包含预测框与真实框的最小闭包区域的对角线距离。 ν 用于衡量预测框与 Ground truth 相对比例的一致性, 如公式 5-16 所示。

$$\nu = \frac{4}{\pi^2} \left(\arctan \frac{w^{gt}}{h^{gt}} - \arctan \frac{w^p}{h^p} \right)^2 \quad (5-16)$$

其中, w^p, h^p 表示预测框宽和高, w^{gt}, h^{gt} 表示真实框宽和高。 α 为影响因子, 如公式 5-17 所示。

$$\alpha = \frac{\nu}{1 - IOU + \nu} \quad (5-17)$$

目标置信度损失通过 Focal loss 控制正负样本的权重和易分类样本和难分类样本的权重进行回归, 解决实际训练中正负样本数量失衡的问题, 如公式 5-18 所示:

$$\mathcal{L}_{focal} = -\beta_1 \times (y^{gt} - y)^\gamma - \beta_2 \times (y^{gt} - y)^\gamma (1 - y^{gt}) \log(1 - y) \quad (5-18)$$

其中, y^{gt} 表示真实目标置信度; y 表示预测目标置信度; β_1, β_2 为权重系数取 1; γ 为调制系数取 2。

对于分类损失利用二进制交叉熵进行计算, 如公式 5-19 所示:

$$\mathcal{L}_{class} = C^{gt} \log C - (1 - C^{gt}) \log(1 - C) \quad (5-19)$$

其中, C^{gt} 表示真实目标类别; C 表示预测目标类别。

5.3 铝板带表面缺陷检测的模型轻量化性能验证

为评估所提出的针对铝板带表面缺陷检测轻量化模型的有效性和鲁棒性, 本章节通过建立铝板带表面缺陷数据集对上述方法进行了实验测试和对比实验验证。

5.3.1 轻量化模型训练的数据集构建

本章围绕 2.4 节铝板带缺陷数据库，构建精整工位关键缺陷的实验数据集，用于轻量化缺陷检测模型与其他对比方法的训练测试。数据集中有缺陷图像 6320 张，无缺陷图像 500 张，样本图像大小为 608×608 像素。其中包含缺陷类别 7 类，分别是辊印、裂边、凹坑、擦伤、黑点、压过划痕和波浪边。数据集中各类别缺陷数量见表 5-2 所示。

表 5-2 数据集缺陷数量

缺陷类别	数量
辊印	1431
裂边	861
凹坑	990
擦伤	1251
黑点	756
压过划痕	1321
波浪边	737

对数据集中所有图像随机抽样，其中 80% 的图像用于构成训练和验证集，20% 的图像构成测试集，用于对比实验的测试以评估模型最终的检测性能。训练和验证集中，随机选择 90% 的样本作为训练集用于模型权重训练，剩余 10% 的图片作为验证集，用于调整模型超参数和对模型的训练效果进行初步评估。

5.3.2 检测性能评价标准及实验环境

本章实验中模型性能的评估指标包括 mAP，精度（precision），召回率（recall），漏检率（miss）和误检率（over），如公式 5-20 至 5-25 所示。其中，精度、召回率、mAP 在本文 3.3.2 节已有详细阐述。漏检率表示没有被检测到的正样本数目占正样本总数的比例衡量模型未检测到缺陷的比例。误检率表示所有检测为缺陷的目标中，不是缺陷的比例。FPS 用于评估所提出方法的检测速度，表示每秒可处理的图像数。MB 为模型的权重文件大小单位。

$$IoU(R_{pb}, R_{gt}) = \frac{|R_{pb} \cap R_{gt}|}{|R_{pb} \cup R_{gt}|} \tag{5-20}$$

$$precision = \frac{TP}{TP + FP} \times 100\% \tag{5-21}$$

$$recall = \frac{TP}{TP + FN} \times 100\% \tag{5-22}$$

$$mAP = \frac{\sum_{c=1}^C AP(c)}{C} \quad (5-23)$$

$$miss = \frac{FN}{TP + FN} \times 100\% \quad (5-24)$$

$$over = \frac{FP}{TN + FP} \times 100\% \quad (5-25)$$

其中, R_{gt} 为该目标缺陷人工标注的 Ground truth; R_{pb} 表示模型对该目标的预测区域; TP 表示正确预测缺陷类别的数量; FP 表示非该类别的缺陷被预测为该类别的数量; FN 表示正确预测不属于该类别的数量; C 表示数据集的类别数量。

本章节所有实验均在 Intel (R) Xeon (R) CPU E5-2660 v3 @ 2.60GHz 的工作站上进行, 采用 128 GB DDR4 内存和 8 GB NVIDIA Quadro M4000 图形处理单元 (GPU)。实验所用代码编译环境均基于 Python 3.6, Pytorch 1.7, CUDA 10.1 和 CUDNN 7.6 实现。

5.3.3 模型训练和超参数优化

由于模型训练数据样本量较小且网络结构较简单, 为防止模型收敛过快及训练不完全等情况出现, 本章全部实验通过预训练模型迁移和主干网络微调的方式对网络模型进行训练以提高训练效果。训练过程分为两个阶段: 首先将大型数据集的预训练权重载入缺陷检测网络模型。前 30 epoch 作为主干冻结训练阶段, 特征提取主干网络权重参数固定, 仅对其他权重参数进行训练, 这样可以防止缺陷数据集中特征分布不均匀在网络训练初始阶段对模型训练的误导, 以及超参数调节能力不足影响网络正常收敛, 从而导致模型泛化性下降。该阶段的 batch size 设置为 8, 动量设置为 0.9。30 epoch 之后, 解冻主干网络, 模型中的全部权重参数参与模型训练。由于参与计算的参数量过多, 将该阶段的 batch size 设置为 4, 动量设置为 0.9。为了减缓模型在初始阶段对 mini-batch 的提前过拟合现象以及保持模型深度稳定性在前 3 个 epoch 使用 warm up 策略, 之后通过设置余弦退火衰减法, 将学习率从 0.0001 下降至 0.00001。

为了防止模型过度训练的时间浪费和过拟合对检测性能的影响, 利用 YOLOv4 基线模型验证训练 epoch 次数与验证集各缺陷 mAP 曲线以及损失函数的变化关系。图 5-15 表示 YOLOv4 基线模型训练过程中训练集和验证集的损失函数变化情况, 图 5-16 表示随训练 epoch 的变化各缺陷 mAP 变化曲线。




图 5-15 YOLOv4 模型训练损失函数曲线




图 5-16 mAP 曲线变化趋势

从图 5-15 损失曲线可以看出，训练集损失曲线一直呈先下降后上升的趋

势。在第 85 epoch 之后，训练集损失缺陷保持稳定，验证集损失曲线出现上升的现象。结合图 5-16 所示，模型的 mAP 值从第 1 至 85 epoch 一直保持上升，但 95 epoch 的 mAP 出现下降并在之后一直保持小范围的下降趋势。因此，根据上述分析，可以判断当训练达到 85 epoch 之后，mAP 不再增加且验证损失不再逐渐减少，模型出现过拟合的现象。为了节省训练的时间成本，本章所提模型以及所有对比实验的总 epoch 值设置为 100，保存验证集 mAP 最高的权重参数作为最终训练完成的权重。图 5-17 为本章节所提出的轻量化检测方法训练过程的损失函数曲线。可以看出从 95-100 的区间内，损失函数值已经出现上升趋势，模型训练已经完成。




图 5-17 YOLOv4 轻量化模型训练损失函数曲线

5.3.4 模型检测结果及鲁棒性验证

为验证本章所提出的轻量化缺陷检测方法的鲁棒性，通过 5 折交叉验证法对数据集进行训练和测试。首先将数据集随机分成 5 个互不相交且样本数量相等的子集，每次训练取其中 4 个子集作为训练集，剩余 1 个子集作为测试集。模型的训练过程重复进行 5 次。5 次模型训练的检测结果，见表 5-3 至表 5-7 所示。比较模型检测结果，第 5 次训练模型性能最佳，因此后续对比实验均以第五次训练样本和权重参数作为标准。

表 5-3 五折交叉验证法子集 1 检测结果 (%)

	裂边	黑点	辊印	凹坑	压过划痕	擦伤	波浪边	mAP
精度	93.41	97.01	83.16	98.98	90.49	86.24	97.00	94.19
召回	92.39	87.25	84.34	99.49	91.39	72.66	100.00	
漏检	7.61	12.75	15.66	0.51	8.61	27.34	0.00	
误检	0.67	0.22	1.11	0.00	1.41	2.30%	0.00	

表 5-4 五折交叉验证法子集 2 检测结果 (%)

	裂边	黑点	辊印	凹坑	压过划痕	擦伤	波浪边	mAP
精度	96.35	93.66	82.67	98.08	88.66	83.66	96.36	93.88
召回	91.67	91.10	78.69	98.55	89.39	70.56	100.00	
漏检	8.33	8.90	21.31	1.45	10.61	29.44	0.00	
误检	0.69	0.31	1.15	0.23	2.00	2.23	0.00	

表 5-5 五折交叉验证法子集 3 检测结果 (%)

	裂边	黑点	辊印	凹坑	压过划痕	擦伤	波浪边	mAP
精度	92.91	97.00	85.76	98.94	88.14	81.49	93.40	94.67
召回	92.19	96.04	82.62	98.94	85.95	70.36	100.00	
漏检	7.81	3.96	17.38	1.06	14.05	29.64	0.00	
误检	0.45	0.60	1.06	0.15	1.58	2.56	0.30	

表 5-6 五折交叉验证法子集 4 检测结果 (%)

	裂边	黑点	辊印	凹坑	压过划痕	擦伤	波浪边	mAP
精度	96.40	98.25	85.71	96.84	89.73	85.64	98.26	94.27
召回	97.81	93.85	80.46	95.83	91.12	72.30	99.12	
漏检	2.19	6.15	19.54	4.17	8.88	27.70	0.88	
误检	0.23	0.38	0.98	0.23	1.59	2.80	0.00	

表 5-7 五折交叉验证法子集 5 检测结果 (%)

	裂边	黑点	辊印	凹坑	压过划痕	擦伤	波浪边	mAP
精度	94.19	97.46	87.91	99.53	87.90	83.70	98.37	94.68
召回	98.29	94.19	80.00	98.10	90.20	75.31	100.00	
漏检	1.71	5.81	20.00	1.90	9.80	24.69	0.00	
误检	0.88	0.24	1.03	0.00	1.51	2.39	0.00	

如表 5-3 至表 5-7 所示，五次实验的检测结果显示波动较小，证明了所提出的方法具有较高的可靠性和良好的泛化性。对于黑点、凹坑和裂边三种单独型缺陷，由于其形貌特征具有明显的特异性，且工艺原因受背景和其他缺陷的干扰较小，检测精度和召回率都保持在 92% 以上，只有出现少数漏检的现象。与此相同的波浪边，作为区域性缺陷，具有明显的类内特征和几何形状，且出现位置固定在铝板带边缘，因此该类缺陷的精度和召回率分别达到 93% 和接近 100%。然而，对比带状缺陷压过划痕和擦伤类缺陷，二者的几何相似度较高。区别在于，划痕呈现出周期性的纹理变化并均为竖直方向，而擦痕呈现出随机的方向变化和整体高亮的特征。当缺陷宽度较窄时，算法无法清晰地显示和捕获内部纹理信息，两者的分类准确度相对较低。并且由于工艺原因其分布较为密集特征变化随机性较大，其漏检率情况出现频率较高，分别达到 29.64% 和 27.7%。区域类缺陷辊印，由于覆盖面积和区域内的密度相对随机，当区域中的密度较稀疏时，容易与单独型缺陷形成干扰，难以完整精确的捕捉缺陷边界。因此，此类缺陷的检测性能与其他缺陷相比还有一定的差距。

综合对比五组结果，本章所提出的基于 YOLOv4 的轻量化缺陷检测方法可以准确实现缺陷的定位和分类功能，针对精整工位出现的七类关键缺陷具有良好稳定的检测效果，平均检测准确度达到 94% 左右。7 类缺陷相互错分的情况非常少，其自身漏检是影响检测性能的主要因素。缺陷图像的检测可视化结果如图 5-18 所示。




图 5-18 轻量化模型缺陷检测结果可视化：(a) 裂边与辊印，(b) 辊印，(c) 擦伤，(d) 黑点与凹坑，(e) 压入划痕与擦伤，(f) 波浪纹与黑点

5.3.5 轻量化模型检测性能与效率对比

为验证本章轻量化检测算法的相关改进模块对提高缺陷检测性能的有效性，本节分别从多个角度进行模型性能对比，包括消融实验、其他检测基线模

型的性能对比、嵌入不同注意力机制性能影响以及结合不同轻量化方式的检测性能对比。

(1) 消融实验

该部分实验通过在 YOLOv4 基线模型上，依次增加自适应线性缩放 anchor box 尺寸、改进的 CIOU-Focal loss 损失函数、轻量化主干网络、轻量化特征融合模块以及注意力机制等模块，用于验证算法中改进模块的有效性和必要性。所有模型训练过程均设置如 5.4.3 节所述，消融实验检测结果见表 5-8 所示。

表 5-8 消融实验检测结果

编号	网络框架	自适应 anchor	CIOU- Focal loss	改进的采 样模块	注意力 机制	mAP (%)
1	YOLOv4 baseline	-	-	-	-	86.98
2	YOLOv4 baseline	√	-	-	-	88.43
3	YOLOv4 baseline	√	√	-	-	90.55
4	YOLOv4 轻量化 GMANet 网络	√	√	-	√	94.30
5	YOLOv4 轻量化 GMANet 网络+轻量化融合结构	√	√	-	√	93.66
6	Our (YAD-GM)	√	√	√	√	94.68

从表 5-8 检测结果可知，自适应聚类并进行线性缩放后的 anchor box 更适应于铝板带缺陷的尺寸，有助于算法更好的定位和分类。与 YOLOv4 比较，其准确率上升了 1.45%。CIOU-Focal loss 损失函数对缺陷检测性能的提升有帮助。实验 3 与实验 2 相比，其 mAP 已从 88.43%增加到 90.55%。将算法的主干网络替换为轻量化模型结构后，可以从实验 4 和实验 3 的结果中发现，mAP 上升 3.75%，说明主干网络中注意力机制的加入对性能的提高有正向作用。而继续对融合网络进行轻量化之后，模型性能是有小幅下降的。这说明虽然轻量化模块中的深度可分离卷积操作可以缩减 PANet 融合网络结构中反复卷积操作带来的庞大计算量，但是剔除的冗余特征依然会对缺陷特征的表达产生影响。为了抵消轻量化后的性能下降，通过加入基于 Pixelshuffle 和 Passthrough 的多尺度特征采样方式，mAP 值从实验 5 的 93.66%上升到实验 6 的 94.68%。

上述所有结果，验证了本章所提出的轻量化铝板带表面缺陷检测方法中各模块对性能的提升是有效的。通过轻量化结构大幅减少网络计算的参数量和复杂度，压缩网络模型大小，并且加入注意力机制和多尺度融合模块有效保证网络的检测精度。

(2) 不同注意力机制模块在轻量化检测模型的对比

为了验证本章所提出的并行注意力机制模块对于检测精度提升的有效性，通过在轻量化主干网络的 Ghost block 单元中植入的不同的注意力模块层（SENet, CBAM, 轻量化注意力模块 ECA layer^[223]以及本章的并行注意力机制 UAM）进行模型训练和结果对比，检测结果如表 5-9 所示。为了更好的了解注意力机制的效果，我们采用 Grad-CAM（Gradient-weighted Class Activation Mapping）^[224]对检测图片预测区域的重要程度进行可视化，颜色越红表示分数越高，代表了原始图片对应区域对缺陷预测响应越高、贡献越大，如图 5-19 所示。




图 5-19 注意力模块热力图可视化：(a) 输入原始图像，(b) 无注意力机制模块，(c) SE 模块，(d) ECA 模块，(e) CBAM 模块，(f) 本文所提 UAM 模块

表 5-9 不同注意力机制模块对比检测结果

编号	注意力模块	mAP (%)	整体模型大小 (MB)	检测速度 (FPS)
1	None	92.98	46.51	21.831
2	SENet	94.74	52.34	19.954
3	CBAM	94.13	49.50	20.994
4	ECAlayer	93.09	46.61	21.473
5	Our (UAM)	94.68	49.58	20.749

从表 5-9 实验结果可知，注意力机制的对于检测性能是有提升的。其中 SENet 结构的检测精度最高，但是检测模型整体运行时间最长。轻量化模块 ECAlayer 虽然缩减模型规模效果不错，但对于检测精度的提高作用较小。相比 CBAM，本章 UAM 模块的模型规模相差不大，但并行结构提高了特征表征能力，其 mAP 较高。

（3）与其他常见检测方法对比实验

为了验证本章所提出的轻量化检测方法在铝板带表面缺陷检测场景中的优越性，分别对其他经典目标检测方法（Faster R-CNN、SSD、YOLOv3、YOLOv4）进行训练和测试，通过对比 mAP、模型大小、检测速度，以及各类型缺陷详细的检测精度、召回率、漏检率和误检率，证明了本章轻量化检测方法能够保持良好的检测精度和检测速度。检测结果见表 5-10，各类别缺陷检测结果混淆矩阵见图 5-20。

表 5-10 与其他经典目标检测方法对比结果

对比算法	mAP (%)	精度	召回率	漏检率	误分率	模型大小 (MB)	检测速度 (FPS)
Faster R-CNN	90.48	57.73	95.17	4.83	8.83	478	3.294
SSD	85.20	88.51	56.88	43.12	0.55	101.2	12.836
YOLOv3	82.37	86.25	86.37	13.63	0.80	235	8.046
YOLOv4	86.98	87.71	85.18	14.82	1.45	245	7.113
Ours (YAD-GM)	94.68	92.72	90.87	9.13	0.86	48.5	20.749

在表 5-10 中可以看出，所提出的方法对铝板带表面缺陷的检测精度高于其他目标检测算法。其中 Faster R-CNN 的召回率较高而检测精度不佳，说明对缺陷检出的效果较好，而对缺陷类别的判断不准确。相反，SSD 的召回率较低，说明该方法的漏检情况严重，特别是压入划痕、擦伤和黑点等密集分布或尺寸较小的缺陷。相比 YOLOv3、YOLOv4 基线模型，本章检测方法在检测精度和

召回率上均有提高。在检测速度方面，本章方法相较于 YOLOv4 基线模型提高了 13.636 FPS，并且均高于其他三种方法。关于模型尺寸，本章方法的模型大小为 48.5MB，相比模型最大的 Faster R-CNN 的 478MB 以及原始 YOLOv4 方法的 245MB 网络的轻量化改进工作是有有效的。




图 5-20 混淆矩阵：(a) Faster R-CNN，(b) SSD，(c) YOLOv3，(d) YOLOv4，(e) 本文轻量化方法。注：BE（裂边），BP（黑点），RS（压入划痕），RM（擦伤），False（误分），Miss（漏检）

此外，将 YOLOv4 框架与其他轻量化卷积技术结合进行对比实验，包括 MobileNetV1，MobileNetV2，MobileNetV3，ShuffleNet，Efficientdet^[198] 和 YOLOv4-tiny。实验结果证明了本章提出的方法在检测精度和检测速度的平衡上具有良好的效果，更符合铝板带表面缺陷检测的生产要求和检测需求。轻量化方法的检测速度与精度对比如图 5-21 所示，具体检测结果见表 5-11。




图 5-21 轻量化卷积方法速度与精度对比

表 5-11 与其他轻量化卷积方法对比检测结果

网络框架	mAP(%)	精度	召回率	模型大小 (MB)	检测速度 (FPS)
SSD+ MobileNetv2	83.58	96.43	65.69	33.16	16.658
YOLOv4+CSPdarknet53-tiny	76.06	73.10	80.34	22.5	34.119
YOLOv4+ MobileNetv1	93.77	92.47	89.01	59.8	18.073
YOLOv4+ MobileNetv2	94.11	92.65	87.62	55.3	18.577
YOLOv4+ MobileNetv3	93.00	91.81	85.45	53.8	19.598
YOLOv4+ Efficientdet	65.22	94.38	42.98	26.12	33.971
YOLOv4+ ShuffleNet	72.22	95.97	47.79	44.5	21.671
Our (YAD-GM)	94.68	92.72	90.87	48.5	20.749

从表 5-11 中可以看出，所提出方法与基于 MobileNet 的轻量化方法相比，mAP 和检测精度变化不大，但是召回率有了提升，说明本章检测方法对缺陷的

检出率较高。同时模型大小和检测速度也有了提高,达到 48.5MB 和 20.749 f/s。而结合 SSD 和 MobileNet 的轻量化方法平均召回率仅仅达到 65.69%,特别是对于压入划痕,预测框的回归计算不适应于条状缺陷,导致漏检情况严重,召回率仅有 34.27%。对于 YOLOv4-tiny,模型大小仅为 22.5MB,其规模缩减非常有效,检测速度也比本章方法快 40%。但是网络卷积层的缩减造成特征信息的丢失导致 mAP 下降了 18.62%。而基于 Efficientdet 的轻量化方法其模型压缩情况大幅度提升,但是导致误检率较高,模型的平均召回率仅为 42.98%。基于 ShuffleNet 的轻量化方法模型的大小与本章方法相差不大,但是检测准确率却只达到 72.22%,说明这种压缩方式不适用于本文的检测场景。

综上所述,本章所提出的轻量化检测模型在铝板带表面缺陷检测任务的检测精度、模型规模以及检测时间三个方面均有一定程度的提高。

5.4 本章小结

本章围绕基于深度学习的缺陷检测方法无法同时实现检测性能和检测速度提升的弊端,提出一种基于注意力机制的轻量化网络用于工业场景下铝板带表面缺陷的检测,实现了检测速度极大提升的基础上进一步优化模型对于复杂、微小缺陷的检测能力,为后续检测系统向硬件和软件一体化的低功耗集成边缘设备的方向发展提供支持。具体总结如下:

(1) 利用 GhostNet 冗余特征图替换的卷积操作轻量化思想,设计具有线性瓶颈和逆残差结构的高效、轻量化卷积模块。通过多层反复嵌套构建轻量化主干网络 GMANet 用于提取不同尺度的缺陷深层和浅层特征。在 YOLOv4 框架下,植入轻量化网络 GMANet,大幅度压缩网络规模,并且保证了提取到的特征图对缺陷特征的信息表达没有损失。结合深度可分离卷积的轻量化思想,对基于 PANet 结构的特征融合网络的卷积操作进行轻量化压缩,减小不断的上下采样和特征融合的卷积操作导致的大量计算量,进一步压缩整体模型规模,降低模型训练时对内存的消耗。在保证检测精度和预测效率不损失的情况下,通过减小网络运算量和计算复杂度,提高检测速度和训练速度,为实现集成式边缘设备在实时工业表面检测中的应用提供了可能。

(2) 设计基于并行通道和空间联合注意力机制模块(UAM),通过提取特征图的通道和空间特征并行融合以增强网络对有效信息通道的关注,抑制无效或较少信息通道。两者并行的结构可以高效地利用特征图中上下文信息,提高了模型的表征能力,实现自适应细化的特征地图。同时解决了单通道注意力模块无法准确自动定位目标的问题,避免了背景对识别过程的干扰。通过与多种注意力机制模块对比,UAM 模块具有更好的检测性能和较小的计算量大小,弥

补网络轻量化导致的准确性下降。

(3) 设计基于通道层和亚像素卷积层的采样方式,通过重新排列不同通道中的特征以调整特征图的大小,实现不同分辨率间相互的特征映射。不同于插值和池化的采样方式,可以避免人工补 0 的操作对高维度特征的破坏。结合双重特征金字塔融合结构和深度可分离卷积,充分融合不同尺度的细粒度特征和语义特征。减小冗余训练参数的前提下,进一步提高了模型的检测精度。

(4) 与正常目标检测方法,所提出的轻量化检测方法将网络规模压缩 80.2%的同时,进一步提升整体检测精度至 94.68% mAP,实现检测系统实时监控和检测的生产需求。相比其他目标检测网络和轻量化检测方法,本文方法具有较高的诊断准确率、较快的诊断速度和较小的模型规模,在速度和精度之间取得了更好的平衡。并且模型训练的收敛速度提高,减小深度学习网络在系统更新和模型部署时投入的时间成本。

第 6 章 面向精整线铝板带表面缺陷检测系统设计及工程应用

本文上述章节中针对铝板带表面缺陷检测的难点问题进行了研究，并提出了相关解决方案。为了进一步在实际生产场景下实现解决方案的工业化应用，本章从工业现场检测需求出发，针对铝板带精整生产线的质量检测需求，提供完整缺陷检测系统的设计和应用。本章首先介绍了铝板带表面检测系统的总体结构和检测流程。根据现场调研，提出了实际铝板带表面检测系统需要满足的功能需求和相关系统配置。之后，详细介绍了系统的硬件系统构成和软件系统架构，特别是系统中多线程协同的硬件单元与可视化交互客户端的集成控制，以满足实际生产应用环境中的系统的运行性能和稳定性。最后，通过集成深度学习缺陷检测算法的检测系统对生产中铝卷进行在线表面质量检测，验证系统实际生产时的检测性能，实现基于深度学习的缺陷检测系统的实际工程应用。

6.1 宽幅高精铝板带表面检测需求及设备安装

6.1.1 精整生产线宽幅高精铝板带生产情况及安装需求

广西柳州银海铝业有限公司冷轧成形车间部署的 2800mm 4 辊冷轧机组，最大入口厚度达 12mm，卷取张力达 40 吨，可满足 2800mm 以下宽幅大规格板材卷式生产需求。同时配置先进 AGC 控制系统，保证铝板带材板厚精度及控制板形变化。2800mm 冷轧产线可生产铝板带产品规格及基本质量性能，如表 6-1 所示。

表 6-1 广西柳州银海铝业 2800mm 宽幅铝板带产品规格

类别	参数
厚度	0.15~6.0 mm
厚度公差	±1.0%
宽度	500~2620 mm
宽度公差	-0~+2 mm
卷径	≤2500 mm
重量	≤26.5 t

本文视觉检测系统安装于精整生产线矫直机组后收卷前的原人工终检处。图 6-1 展示了精整生产线视觉检测系统安装位置布局图，检测位置为红框标示范围。安装位置的选择考虑到以下几点原因：（1）该位置作为原人工终检工序

处，是产品进入成品包装区的最后一道工序，检测后的铝板带受外界因素影响导致产生缺陷的可能性较小，检测结果可以完整、真实、客观的反映铝板带表面的实际情况。（2）该位置操作空间较大，无遮挡，便于检测设备的安装调试，并且避免了生产设备运行对检测系统光源的干扰。检测设备的安装运行不会与生产设备的运行/检修，以及操作人员的取样、装卸引起干涉。（3）该位置接近于产线操作间便于监控设备的安装，防止过长的安装线路对网络传输和数据噪声的产生造成成像质量的影响。（4）该位置离高温清洗、烘干工序较远，铝板带表面温度已经降低至 40℃ 以下，不会对采集系统中各部件的稳定工作造成影响。精整线矫直机组的运行信息见表 6-2 所示。




图 6-1 精整生产线机组及检测工位现场

表 6-2 视觉检测系统搭设精整生产线机组信息

参数名称	数值
可生产最大幅宽	2620mm
需检测板材厚度范围	0.1-3mm
最高生产速度	70m/min

6.1.2 视觉检测系统功能需求

为满足生产企业对于铝板带表面缺陷检测需求，表面检测系统不仅能够实现将原始采集图像中的缺陷识别并正确分类，还需要具备一定的检测分辨率和检测速度，以及为生产管理提供数据支持的条件。因此，根据生产现场的实际调研，本文所设计的检测系统需要具备以下功能：

（1）提高检测效率和检测精度

检测系统最重要的任务是解决现阶段人工检测技术的弊端并在一定程度上提高检测极限。一方面，目前人工检测在速度和精度方面都无法跟随生产要求的提高而提升性能。精整产线的生产过程中运行速度为 10 至 70 m/min，人工检

测通过在易出现缺陷的位置降低运行速度来识别周期性的大面积缺陷,但是对于运行时的无规律偶发性缺陷难以在高速运行中进行精确分类和定位。高精度、宽幅面产品由于对表面精度要求的不断提高,人眼无法准确全面的捕捉微小缺陷的存在,并且运行时的安全距离要求使得检测人员无法实现在高速运动时发现表面微小缺陷。另一方面,人工检测的检测标准受检测人员经验、状态、环境等主观因素影响巨大,无法定量衡量检测结果准确程度和定位误差程度,仅通过卷尺在移动的铝板带上大致测量和判断。综上,表面检测系统需要具备精确、高速、高效、全面、客观的检测能力,不受外界环境因素的干扰,尽量减少漏检和误检情况导致对下游产品造成安全隐患。

(2) 生产设备的实时监控

检测系统需具备对产品表面生产现状的实时监控功能,配合操作人员及时对异常情况进行干预。一方面,铝板带表面情况的实时反应,使现场操作人员可以快速精准的查看产品当前生产情况。当出现由设备异常引起的缺陷(如辊轴表面出现异物,辊轴张紧力不平衡,辊面受损等原因造成的裂边、凹坑、大面积辊印、周期性擦伤等现象)时,可及时提醒操作人员进行干预,避免不及时处理造成的产品报废从而影响生产效率和经济效益,提高生产良品率。另一方面,铝板带表面存在的异常问题侧面反映了材料性能、工艺参数或者上游工序遗留等方面还存在不足。将实时生产缺陷数据作为依据,通过对缺陷形成机理的研究和实际缺陷数据的分析总结,可以探索出某类缺陷产生的原因,为操作人员及时处理异常和技术人员的工艺改进提供判断和参考依据,有助于快速解决异常生产状况和避免缺陷问题的重复出现,从而提升生产质量和产品性能。

(3) 有效的数据分析和全面的质量报告回溯

检测系统可提供详细的检测数据信息和全面的质量统计和分析报告,包括实时的缺陷类型、数量、面积区域、精确的位置数据(横向和径向)展示和产品整体的缺陷类型统计、良品率情况,以满足不同产品的质量分级检测需求。产品用途不同对表面质量的检测标准也不一致,分级检测可以提高检测系统的应用范围。同时精准的定位信息便于后续局部分切,将铝卷中的不合格部分剔除,提高成品合格率和材料利用率,避免产品报废造成的材料浪费。同时提供了长期的数据存储和有效的数据回溯功能,防止数据修改、数据丢失等情况。不仅避免了安全隐患的发生,而且为后续的工艺改善、技术创新升级提供了数据支持。

6.2 铝板带表面缺陷检测系统的总体构架

铝板带表面缺陷检测系统由硬件机械系统、电气控制和软件系统三大部分构成，其中包括机械主体支架、图像采集系统、算法服务器及监控端、总线控制和电源系统等四大基本结构，如图 6-2 所示。通过图像采集系统获取铝板带表面图像，利用现场总线和局域网将图像数据传输至算法服务器进行缺陷识别计算和数据储存。操作人员可在监控端的可视化软件系统中实时监控表面质量状况、查看检测结果，以及控制、调节检测系统运行。本文铝板带表面缺陷视觉检测系统主要配置，如表 6-3 所示。




图 6-2 铝板带表面缺陷检测系统结构

表 6-3 视觉检测系统配置情况

名称	参数值	数量
线阵相机	4k 线阵工业相机	6 台
线阵光源	白色高光 LED 线性光源	3 根
计算处理器	Dell 图形工作站	4 台
图像采集卡	GigE 接口	1 台
单像素分辨率	小于 0.2×0.2mm/pixel	-
最大检测宽度	2620mm	-
检测软件	专用铝板带表面检测系统	1

6.3 宽幅铝板带表面缺陷检测系统的硬件系统

根据宽幅、高精度铝板带表面缺陷视觉检测的功能需求,本文以2.4节中已在实际生产现场经过性能验证的图像采集系统为基础,构建面向实际生产加工的基于深度学习检测模型的在线表面缺陷检测硬件系统,主要由图像采集单元、图像传输和集成单元、计算处理与存储服务器、信号传输控制单元组成,图6-3展示了硬件系统的组织构成。

图像采集系统作为缺陷检测系统中最为重要的部分,决定了系统的运行速率、检测准确度、结果可靠性等诸多指标能否满足设计需求。通过成像设备和光源采集到反映铝板带表面情况的数字化图像,其中包括机械结构、成像模块、光源。

图像传输和集成单元主要作用是将多台线阵相机采集的图像由GigE接口通过千兆光纤网络传输至图像采集处理卡中,统一将全部采集数据优化处理后传输至服务器。由于在线检测的高实时性要求和宽幅板材图像的大数据量,高效的传输速度和一致的图像传输效果为后续采集图像的缺陷识别提供了可靠的基础支持。

计算处理与存储服务器由监控计算机和计算及存储服务器通过工业交换机连接组成。监控计算机安装在产线操作间内,主要通过可视化检测软件对整个检测系统进行监控、调节和管理维护。不仅能够根据服务器检测结果提供缺陷数据的查询,检测参数的设置以及缺陷数据库的维护等功能,同时可以实现对相机拍摄状态参数调节和控制。计算及存储服务器接收采集到的表面图像通过图像前处理后,输入缺陷检测网络模型进行计算分析,完成缺陷识别和定位后结合采集信号还原为铝板带实际位置信息。之后,对相关检测结果、统计数据及缺陷图像数据进行存储。由于计算服务器承担检测系统中的全部计算分析和储存功能,需配置高性能的并行计算处理模块和高容量的存储空间,以满足实时检测对连续图像流数据的处理和存储需求。

信号传输控制单元由传感模块、通信模块和电源模块组成。传感模块利用旋转编码器向图像采集系统提供触发信号,使相机配合铝板带传输速度完成图像的精准采集。反馈铝板传送速度的机械执行机构设计,不仅为缺陷的精确定位提供数据支持,并且避免采集过程出现掉帧或重叠等问题。通信模块负责各硬件单元间的数据、信号传输,不同相机采集到的图像数据经过千兆光纤网络和图像采集卡统一,之后通过现场总线传输至计算服务器中进行后续计算。计算结果、实时数据和控制指令通过工业局域网在监控器和服务器之间相互传输。电源模块负责为检测系统中的相机、光源、传感模块和服务器等设备提供供电。




图 6-3 表面缺陷硬件系统的结构：(a) 各模块示意图，(b) 信号流程图

6.3.1 系统总体方案设计

结合实际生产现场和技术优劣，系统的总体方案设计从三个方面进行设计制定：机械结构设计，成像方式和数据传输。

(1) 机械结构设计

图像采集系统的机械结构设计，一方面需要根据现场情况合理规划各个部件的安装位置和光路角度，保证采集图像质量满足检测要求；另一方面，检测设备的安装不能影响产线原本的加工生产、人员操作，并且可为检测设备安装、调试、维护提供操作空间。考虑检测系统的抗振性和使用寿命，图像采集系统的机械结构采取桥架模式并独立于生产设备。主体框架的长高宽分别为 $L=3500\text{mm}$ ， $H=1700\text{mm}$ ， $W=300\text{mm}$ ，采用米思米工业级 50mm 正方形铝型材 NFS6-5050 配合槽型反转支架通过螺栓连接组装而成，便于安装拆卸和位置调

节。相机及光源采用导向轴连接 T 型导向轴支座螺栓固定，可以调节横向位移和轴向旋转角度形成多种光路模式。

考虑到铝板带材料的介电常数较大，通过 BRDF (Bidirectional Reflectance Distribution Function) 分布函数计算铝板带表面散射，从而设计适合于铝板带检测的光路结构。根据入射光角度和光通量等参数，可知被测表面单位面积上的入射光与出射光的照度比为：

$$f_r(\theta_i; \theta_r) = \frac{dL_r(\theta_i; \theta_r)}{dE_i(\theta_i)} \quad (6-1)$$

其中， L_r 为亮度， E_i 为照度， θ_i 为入射光角度， θ_r 为出射光角度。通过对金属板材三种不同照明方式成像效果的研究并结合实际测试结果，过渡场照明方式可以同时兼顾暗场照明效果更好的起皮等三维形貌变化较大的缺陷和明场照明效果较好的油斑等色差变化的缺陷，因此设计光源和相机位置关系为过渡场位置关系，相机位于光源上部两者高度差为 $d=350\text{mm}$ ，光源距离采集板带表面高度为 450mm 。同时可以避免光源漫反射、遮挡阴影以及生产设备穿带操作时板带凸起对相机的损害。机械结构设计图，如图 6-4 所示。




图 6-4 机械结构设计图

(2) 成像方式

图像的采集通过成像模块中的工业线阵相机和 LED 光源完成。目前主流成像采集技术分为面扫描采集^[225, 226]和线扫描采集^[71, 73]两种方式，如图 6-5 所示。两种方案所获得的图像清晰度相差不大，面阵相机较长的感光时间和较低的帧频限制了采集速率，并且考虑到运动过程中板面振动导致的偏移会对多个

采集视野区域的图像拼接产生影响；面采集模式对面光源覆盖区域要求较高，导致设备安装空间增大的同时受环境干扰的可能性也增大。线扫描采集方式，线光源与线阵相机的采集面积仅覆盖一条线的区域，采集帧率更高，空间占用较小。由于铝板带的现场生产过程的连续性，线采集方式能避免采集间隔时间的计算和图像重叠区域处理等问题。线采集位于辊面的检测位置振动较小，采集信号不容易受到设备运行和板面移动产生的板面振动的影响。因此，线扫描采集方案较多的被使用在宽幅、高精度、高速率的卷带、板材的工业图像采集中，但是其对于光源和相机的光路设计要求较高^[227]。为保证成像质量不受生产设备和铝板带移动所产生轻微的振动影响，本文采用更高采集帧率和分辨率的线采集方案，确保响应速度满足铝板带生产对高速度、高精度和大成像范围的要求。




图 6-5 面扫描采集方式和线扫描采集方式




图 6-6 成像原理

线扫描成像方式包括工业线阵 CCD 相机和对应定焦镜头, 其成像原理如图 6-6 所示。假设铝板带以最大速度 $v=70\text{m/min}$ 进行运动, 相机距离铝板带表面 h_c 为 800mm , 根据公式 6-2 至 6-4 所示, 可计算 4k 分辨率相机和镜头的最小像素分辨率能否达到实际检测精度要求。

$$w = \frac{h_c P l_w}{f} = \frac{800\text{mm} \times 4096 \times 7\mu\text{m}}{50\text{mm}} = 458.75\text{mm} \quad (6-2)$$

$$r_w = \frac{w}{P} = \frac{458.75\text{mm}}{4096} = 0.112 < 0.5\text{mm} \quad (6-3)$$

$$r_v = \frac{v}{F} = \frac{70\text{m/min}}{26} = 0.045 < 0.5\text{mm} \quad (6-4)$$

其中, w 为实际采集最大宽度, P 表示相机分辨率, F 为相机的行频, f 表示镜头的焦距, l_w 表示相机单像素尺寸。根据上述计算可知, 成像单元实际采集宽度为 458.75mm , 在实际铝带表面的 x, y 方向上可达到的最小分辨率 r_w 和 r_v 是 0.112mm 和 0.045mm , 远低于检测要求。

光源的照明方式主要有 LED 光源、激光光源以及荧光光源等。其中激光光源亮度较高、聚光性较好, 主要用于零件形状和板材的形状检测。荧光光源光照效率高, 但整流器和电源带来的成像闪烁问题使得荧光光源在在线扫描领域已被逐步淘汰。最常用的 LED 光源, 可提供多元色彩并且无频闪。光照效率较高、体积小、使用寿命长等多种优势逐渐在工业检测领域被广泛使用, 但是 LED 光源要求的工作温度较低, 需要考虑产线环境温度和大功率使用时的散热问题。基于精整生产线的检测系统安装环境, 光源的选择主要根据以下几个因素考虑分析: 检测对象的金属成像特性; 光源的散热结构设计、体积及工作环境; 光源的照度、光效率和聚光特性受环境光的影响以及对环境中其他监测设备的影响; 光源的使用寿命、稳定性及价格成本; 后期的维修更换的便捷性。综合分析, 选择 LED 线光源作为采集系统光源。当采集设备光场角度设计符合反光特性时, 铝板带高反光的特性能够得到聚光性更强、亮度更高的光照区域。线性光源提供的均匀光照、高聚光的细长矩形区域可避免光源的直线性不足导致的光照不均匀现象。精整生产线检测工位的铝板带周围环境温度较低, 不会对其使用寿命造成影响。

(3) 图像传输及采集信号控制

精整生产线在正常生产时的铝板带运行速度在 10m/min 至 70m/min 。当处于最大运行速度时, 不仅需要考虑相机的行频是否能够满足响应要求, 而且需要考虑传输线路和图像信号的处理能否支持不断传入连续数据流的响应。在最高运行数据时, 图像信号数据吞吐量 Q 为 6MBps , 计算过程如公式 6-5 所示。

$$Q = \frac{w}{r_w} \times \frac{v}{r_v} = \frac{458.75\text{mm} \times 70\text{m} / \text{min}}{0.112\text{mm} \times 0.045\text{mm}} = 6.4 \times 10^6 \text{ pixel/s} \quad (6-5)$$

因此, 本文选择 GigE 接口配合千兆网线缆的数据传输方案, 可以提供 100 米内高达 0.96 Gbit/s 的数据率, 满足长距离的稳定图像传输质量, 节省了有限的安装空间。

采集系统中工业相机接收触发信号, 执行拍摄动作。工业相机的触发方式通常分为两种: 由软件控制相机采集的软触发模式和通过外部硬件控制相机执行采集的硬触发模式。精整生产线面对不同尺寸规格、工艺参数以及合金含量时, 其生产速度往往不一致, 并且同一卷铝带在不同位置进行操作时生产设备的状况存在小幅度波动。为保证相机触发信号在不同运行速度下纵向像素间不漏帧、不重复采集, 以及图像采集频率与铝板带运动速度保持正相关, 本文中图像采集系统的相机触发模式采用硬触发模式, 通过增量式编码器和机械安装支座与旋转辊轮接触, 同步编码器与铝板运动速度并发送相应频率的脉冲信号, 转化为相机的扫描频率, 实现相机的同步持续采集。已知编码器支架橡胶轮直径为 d_c 和 y 方向最小检测精度分辨率 R_v , 则通过公式 6-6 可以计算得到编码器频率 f_b , 即旋转一周输出的脉冲个数。

$$f_b = \frac{\pi d_c}{R_v} = \frac{\pi \times 120\text{mm}}{0.5} = 753.6 \approx 754 \quad (6-6)$$

根据计算可知符合相机采集要求的编码器频率需大于 754。

6.3.2 关键部件设计

(1) 成像单元

图像采集单元主要由多个一体化光源组件和线扫描成像设备构成, 以解决单台线阵相机拍摄范围有限无法完整覆盖宽幅面铝板带表面的问题。相机选用 Basler 公司 BASLER ral 4096-24gm 线阵工业相机, 如图 6-7 所示。其具体参数如表 6-4 所示。



图 6-7 BASLER raL 4096-24gm 线阵工业相机

表 6-4 线阵相机参数

型号	BASLER raL 4096-24gm
分辨率	4096 像素/行
行频	26 kHz
单像素尺寸	7 μm × 7 μm
像素位深	8/12bits
感光芯片	Awaiba-CMOS
数据传输	GigE
触发模式	software trigger/hardware trigger/free-run
电源	12-24 VDC
工作温度	0-50℃



图 6-8 自动对焦尼康镜头

为配合不同规格铝板带的板厚变化造成的聚焦表面位置变化现象，镜头选择具有自动对焦功能的尼康 *AF – Nikkor – 50mm – f / 1.8D*，如图 6-8 所示。其具体规格参数如表 6-5 所示。

表 6-5 镜头参数

型号	AF Nikkor 50mm-f/1.8D
镜头类型	定焦
镜头结构	5 组 6 片
对焦方式	自动对焦
光圈范围	<i>f 1.8-f 22</i>
焦距范围	50mm
滤镜尺寸	52mm
最近对焦距离	0.45m

(3) 光源

为保证不同成像相机可获取到光照均匀且一致的表面图像，减小因不同区域光源变化而产生的同一线平面上的成像质量差异，光源组件依然选择功率较小的 LED 高亮线形同轴光源，如图 6-9 所示，将多组 LED 发光源、聚光棒、扩散膜、散热型材和散热风扇进行一体化结构集成，通过外接直流电源进行供电。具体规格参数表 6-6 所示。光源组件可在 80mm 宽度区域内提供 2000Klux 的亮度均匀白色光亮。通过两端螺栓固定的夹持式安装与 T 型导向轴支座配合固定转轴，可保证光源在工作角度的稳定固定防止生产设备运行振动的影响并且方便生产不同规格产品时光路的调整。




图 6-9 LED 光源

表 6-6 光源参数

参数名称	高亮线形同轴 LED 光源
光源外形尺寸	800×5×10 mm
颜色	白光
Ra	>90
有效发光面长度	560 mm
散热风扇	6 只
电源	24V/48V

考虑到各成像设备及光源空间位置关系的安装调试和后期维护，各成像相机间采取独立安装模式。由于宽幅铝带材图像的采集需要多台线阵相机并联触发信号，为保证相机间的安装状态（相机 x 轴， y 轴的旋转角度）的高精度调节。每台线阵相机均使用四点弹簧自锁装置，通过 4 个点的螺钉与弹簧配合调节底座与连接板之间的距离，实现相机姿态在多个角度的微调。同时通过将自锁装置与高强度导向轴固定，不仅实现单个相机相对铝板带表面仰角、倾角的拍摄角度调节，而且固定多台相机的平行安装空间位置。

（3）编码器控制及其机械结构

根据上小节中编码器相关数据的计算，为保证纵向精度要求，编码器频率需大于 754。因此，本文选择欧姆龙增量式旋转编码器 E6C3-CWZ3XH（ $f_b=3600$ ），图 6-10 展示了编码器支架连接编码器的结构示意图。首先，主动辊轮通过表面的橡胶产生摩擦力，使辊轮表面线速度与铝板带的运动速度保持一致。将编码器支架的橡胶轮通过弹簧装置压在主动辊轮表面，使橡胶轮表面获得与铝板带运动速度相同的线速度，并带动同轴连接的编码器旋转。之后，编码器旋转一周向相机发送触发信号，相机完成拍摄，建立了相机行频与速度之间的自适应，保证了采集图像的质量。通过图像像素距离与实际板带运动距离间的关系，可获得缺陷实际位置信息为后续缺陷定位提供数据。




图 6-10 编码器及触发结构

6.4 检测系统算法集成与可视化软件系统

6.4.1 系统软件结构

软件系统作为铝板带表面检测系统的重要核心，是实现缺陷检测从方法研究到工程应用的重要载体。本文的主要研究方法均通过软件系统的设计架构实现从采集图像到实时检测结果展示的转换。软件系统采用 C/S 结构，分为基础层、功能层和界面层，其中包含计算处理单元，硬件采集控制单元，数据库存储单元和可视化客户端单元。图 6-11 展示了检测系统软件系统的整体构架。




图 6-11 检测系统软件结构

硬件采集控制单元和可视化客户端单元被部署在监控计算机平台上，通过可视化客户端获取检测人员的控制指令信号。经过串口通讯传输至硬件采集控制单元，触发多个采集通道并行执行对应图像采集动作。之后，采集到的图像数据通过总线传输和以太网通信模块上传至计算服务器平台。为保证数据量巨大的原始采集图像可以实时处理，传输和通信模块的带宽和通道数量可以自定义增减，以提高系统稳定性防止数据丢失。最后，经过算法模块分析后的检测结果经过后续数据处理和可视化转换被传回客户端单元，实现生产状态的监控、缺陷数据的查询、管理等功能。除了检测结果的查看等功能，通过通讯单

元传输客户端可以实现检测系统的参数设置、动作控制以及服务器数据库的远程设置和维护管理。

算法计算单元和数据库存储单元被部署在计算存储服务器平台上。算法计算单元作为检测系统核心,主要基于深度学习 YOLO 检测框架对采集图像进行预测判断,实现原始图像预处理、缺陷的提取分析以及定位分类、以及实时检测结果可视化和缺陷实际定位转换计算等任务。获得实时检测结果通过以太网通讯模块传输至客户端用于人机实时交互,同时含有缺陷的图像和检测结果日志被提交至数据库存储单元进行存储和管理。

6.4.2 软件交互客户端功能设计

(1) 客户端系统功能

软件系统的可视化交互客户端作为功能实现和人员操控的直接展现,决定了本文所研究的铝板带表面缺陷检测系统能否最终实现工程应用。根据对于现场操作规程和检测要求的调研,面向铝板带的表面缺陷检测可视化交互客户端可满足以下基本功能:

- 检测模式选择:系统具备手动检测、自动检测两种模式,手动检测模式可以将保存的原始采集数据进行回溯式检测,便于操作人员寻找缺陷成因。
- 检测模型设置:检测系统具备多任务多对象的检测功能,可以通过载入不同检测对象的算法模型实现系统可调节可更新的功能,解决生产产品更新升级的系统的升级问题。
- 生产状态实时监控:系统可实时显示产品高精度表面状态和检测信息,便于操作人员及时监控生产状态。
- 缺陷报警:系统可根据缺陷库中缺陷类型的分级设置对致命、严重等级缺陷提供报警功能,及时提醒工作人员停机检查。
- 缺陷位置记录:以整卷铝卷为坐标,记录全部缺陷在宽度和卷长的坐标位置和类型,为客户提供产品质量状态的证明依据。
- 缺陷区域图像管理:对检出缺陷的原始图像进行保存,为企业建立缺陷样本数据库,便于后续算法模型针对性更新升级。
- 缺陷统计分析:系统提供缺陷信息的种类、区域大小、数量、分布情况的统计分析和数据储存,并支持日期、类型或批号等多种查询方式,为后续产品的质量分析提供数据支持。
- 采集设备控制:可对采集相机的各性能参数进行设置,以适应不同的成像条件和环境变化,包括图像分辨率、触发条件、频率、曝光参数、校正模式、亮度变化、白平衡等。
- 三级用户管理:系统具备三级人员权限管理模式(操作人员、调试人员

和管理人员)。提供用户登录、退出、增加、删除、权限分级等多种功能,保证系统数据的真实、完整、可靠,保障系统的稳定运行。

- 缺陷样本管理:系统可根据检测缺陷图像建立不同产品的缺陷样本数据库,并提供缺陷类型的增减、修改等功能。具有针对性的样本库可用于后续算法的升级和检测模型的训练。

- 系统参数设置:可设置数据备份周期、过期数据清除、数据保存路径更改等多种系统运行参数的设置。

(2) 软件界面

铝板带表面缺陷检测系统可视化客户端的开发在 Windows 平台下基于 Qt 框架和 PyQt5 模块,在可视化的界面设计软件 Qt Designer 上实现图形用户界面(GUI)功能的设计。基于 Python 3.6, Pytorch 1.7, CUDA 10.1 和 CUDNN 7.6 实现算法功能的程序设计。




图 6-12 检测系统可视化客户端主界面

图 6-12 所示为铝板带表面检测系统可视化客户端的主界面,由操作区、实时界面显示区、检测结果显示区和菜单栏组成。操作区通过检测模式的选择、载入可实现手动检测、视频检测和实时检测三种模式,并且可随时暂停/继续、停止检测。实时界面显示区展示了当前生产表面的实时检测结果,红色区域表示该区域存在缺陷,绿色区域表面该区域没有缺陷,便于操作人员的快速判断和监控。检测结果显示区右边部分实时显示了当前检测出的缺陷类型、坐标位

置和面积大小,并且该缺陷图像的保存地址。左边部分表示为当前被检测铝卷的缺陷地图, x 坐标对应铝卷的宽度坐标, y 坐标对应铝卷的长度坐标,地图中标点位置表示该位置有缺陷。检测结果的文字信息和地图图像数据可被保存。菜单栏提供产品参数信息的录入、缺陷数据的信息统计、样本库管理、用户管理和相机参数设置等功能,均可进入相应界面操作。

进入软件系统需进行用户登录,系统登录界面如图6-13所示。

产品参数设置界面如图6-14所示,可输入产品批号、产品型号、生产日期等信息,并根据产品输入的参数信息保存后续检测结果和缺陷图像。可选择产品的检测等级,系统对不同的检测等级的检测精度、正确率标准和缺陷类型的计算标准也会相应变化。



图 6-13 检测系统可视化客户端登录




图 6-14 产品参数设置界面

缺陷数据的信息统计界面如图6-15所示,可显示该批次生产的铝卷检测缺

陷的缺陷类型、面积大小、对应位置信息和缺陷图像的保存地址。并统计了该批次的检出缺陷的具体类别数量信息。系统提供缺陷图像的查看、缺陷数据信息的打印、历史数据查询等功能。




图 6-15 缺陷数据的信息统计界面

相机参数设置界面，提供相机曝光、增益、触发模式、白平衡等多种运行参数设置，如图 6-16 所示。




图 6-16 相机参数设置界面

用户管理界面提供用户的新增、删除、编辑等功能，并提供权限的分组功能，图 6-17 显示了用户管理界面和注册界面。




图 6-17 缺陷数据的信息统计界面

6.5 铝板带表面缺陷在线检测及结果验证

根据本文 2.2 节检测方案，铝板带表面缺陷检测系统的现场安装情况如图 6-18 所示。




图 6-18 现场安装情况

(1) 检测实时结果显示

图 6-19 所示为检测系统验证的实时检测结果显示，证明了检测系统对于条状缺陷、密集遮挡缺陷以及小目标缺陷良好的检测性能。图 6-20 和 6-21 所示为无缺陷表面和水渍油渍等干扰下的检测结果，证明了检测系统在板面反光、水渍及油斑等伪缺陷和传输噪声干扰下依然保持良好的抗干扰性能。




图 6-21 噪声水渍干扰下的检测结果

(2) 铝卷开卷检测结果验证

本文选取规格为 1405mm 宽，3240 米长，板厚为 1.2mm 的铝卷进行在线检测和人工开卷检测，用于验证实际生产中系统检测的有效性和准确性。铝板带正常生产运行速度为 60m/min。由于换卷时需要停机和点动进行穿带操作，因此摩擦、清洗及板形调整等原因导致铝卷前后 300 米范围内人为缺陷较多，属于废料不包含在质检要求中。因此，铝卷表面缺陷检测从 200 米位置开始统计检测结果。通过设置不同的检测等级，验证检测系统对各类型缺陷的检测准确度是否满足质检要求，并且验证系统对于分级检测的效果，其中 A 等级要求检测系统检出致命缺陷和严重缺陷；B 等级要求检测系统仅检出致命缺陷。表 6-7 至 6-8 显示了分别在 A 等级和 B 等级检测标准下的检测系统识别结果。本文 2.5 节所述其他缺陷类型则没有出现在本次检测的铝卷中。其中，检出率的计算如公式 6-7 所示，该类别的缺陷总数=正确识别的缺陷个数+错误分类的缺陷个数+漏检的缺陷个数。

$$\text{检出率} = \frac{\text{正确识别的缺陷个数}}{\text{缺陷总数}} \tag{6-7}$$

表 6-7 铝板带表面检测系统 A 等级检测结果

缺陷类型	漏检数量	总数	检出率
辊印	12	225	90.72%
裂边	0	13	100.00%
凹坑	3	152	96.13%
金属压入	2	111	92.92%
压过划痕	6	350	91.85%
黑点	1	62	95.24%
起皮	1	17	88.89%
擦伤	23	1004	90.75%
总计	48	2634	93.31%

表 6-8 铝板带表面检测系统 B 等级检测结果

缺陷类型	漏检数量	总数	检出率
裂边	0	13	100%
凹坑	2	153	97.42%
起皮	0	18	88.89%
总计	2	184	95.44%

根据表 6-7 和表 6-8 所示，检测系统在两种检测标准下的平均检出率均达到 90%以上，满足 6.1.2 节所提出的检测系统需求。对于 A 等级检测标准，实验验证所用铝卷中出现致命缺陷和严重缺陷共 7 种缺陷类型。其中，裂边和起皮类缺陷出现频率较低，因此检出率结果受到检出数量影响较大。起皮类缺陷未正确分类的目标数量仅为 2 个，但是导致检出率为 88.89%。擦伤类缺陷出现频率最高且密集分布，因此漏检数量大于其他缺陷。辊印类缺陷在本次实验用铝卷中出现频率较高，但是辊印缺陷作为区域类缺陷，在区域内密度变化较大，缺陷边界难以区分，系统对辊印的检测准确度较低。特别是密度较小的区域，容易误分为凹坑类缺陷。因此，在后续研究中需要继续提升对于区域类缺陷的边界判断，从而进一步提高检测准确率。对于 B 等级检测标准，系统可检出铝卷中的致命缺陷共 3 种缺陷类型，平均检出率达到 95.44%并且仅出现 2 个漏检目标，满足系统检测精度要求和对致命缺陷漏检率的要求。此外，上述两种检测标准下，没有出现将伪缺陷误分为缺陷的情况，证明检测系统具有良好的抗干扰能力。

根据 6.1.2 节所述对精整生产线主机运行信息和系统检测要求，可计算得出检测系统是否满足最高生产速度要求。已知铝板带生产运行速度最高为 70 m/min，则检测系统每秒需要处理约 1.167 米长的铝板表面图像。检测系统采用

的线阵相机分辨率为 0.12mm/pixel ，原始采集图像的长度为 1024 pixel ，则一幅原始采集图像在实际铝板带表面的采集长度为 $0.12 \times 1024 = 122.88\text{mm}$ 。综上，为满足铝板带最高生产速度，检测系统的检测速度需达到 $122.88/1.167 = 105.3\text{ms/幅}$ 。经过检测，系统实际检测一幅原始采集图像平均耗时为 94.81ms ，时间消耗小于最高生产速度下的检测要求，可以满足在线检测要求。

6.6 本章小结

本章针对铝板带冷轧生产车间精整生产线，根据铝板带生产特点和表面视觉检测的生产要求并结合本文所提出的缺陷检测方法，设计了铝板带表面缺陷检测系统的工业化应用方案。详细地介绍了检测系统的总体结构和具体的图像采集和检测过程，分别对系统的软、硬件构成和多线程协同运行原理进行了分析说明。特别，从工业现场检测需求出发，针对铝板带精整生产线提供了集成控制的缺陷检测系统可视化交互客户端软件系统支持，并对软件系统各项功能进行详细说明，以满足实际生产应用环境中的系统的运行性能和稳定性。

第7章 总结与展望

7.1 工作总结

7.1.1 主要研究工作

为了实现宽幅、高精度铝板带表面质量的实时在线检测,保证产品出厂品质,提升铝板带生产企业制造智能化和管理调控自动化的水平,本文以柳州银海铝业有限公司精整生产线铝板带为研究对象,对目前基于深度学习的缺陷检测技术进行深入研究,解决目前样本数量稀缺以及复杂检测背景等制约检测系统在工业检测领域应用的因素。同时,从检测性能、检测速度以及使用便捷性等角度,开发一款能够在工业生产中长期稳定运行、快速高效部署的面向铝板带表面缺陷的检测系统,对有色金属制造行业的智能化质量检测提供支持。论文完成的主要研究工作如下:

(1) 以柳州银海铝业有限公司精整生产线的铝板带产品为背景,结合生产设备运行状况、生产环境以及检测需求,设计铝板带工业检测场景下的表面缺陷端到端检测方案,并基于真实生产场景构建铝板带表面缺陷数据库。首先,分析介绍铝板带表面端到端检测方法并针对技术难点问题进一步分析应用可行性。设计面向铝板带表面缺陷的端到端检测方案;之后,结合实地调研结果和行业标准,对常出现缺陷的形成原因、形态特点和质量分级要求进行了详尽介绍和分析。其次,通过标准背景图像与差影法相结合,实现疑似缺陷图像的筛选。最后,结合人工标注的缺陷信息,设计随机缺陷子图像的生成方法。获取适应于深度学习模型训练的缺陷图像,并构建铝板带表面缺陷图像数据库,包含十类典型缺陷及三类伪缺陷。

(2) 针对工业数据样本稀缺和分布不均衡问题,提出一种基于元学习的端到端少样本缺陷检测方法,克服工业缺陷数据稀缺时 YOLO 方法过拟合导致的检测准确度下降。首先,在 YOLOv4 框架的多尺度结构中引入了元学习理论,通过骨干网络提取缺陷的多尺度元特征信息。其次,设计特征重加权网络,获取重新加权向量提取特定类别的相关语义特征信息。之后,将多尺度的元特征图和重加权向量结合,得到重加权后的元特征图。通过新解析策略的多尺度预测模块,实现对重新加权的元特征在不同尺度上的缺陷进行定位和分类。最后,构建基于少样本缺陷检测的模型训练策略。通过大量基类数据预训练和少量带标记全类别数据微调,实现模型在多任务场景下的快速部署。实验证明,所提出的方法表现出优异性能,相较于其他检测方法以较大的优势体现了少样本检测的可行性和有效性。

(3) 针对多工序缺陷相互交叠遮挡的复杂检测场景, 提出一种基于上下文信息和斥力损失的多层级遮挡缺陷检测方法, 缓解面对密集遮挡目标时 YOLO 方法因特征信息干扰造成的漏检、误分现象。首先, 提出基于 RFB-Net 结构的空洞卷积特征提取网络, 增强网络对上下文信息的捕获能力。其次, 根据 Bi-FPN 结构, 设计多层级交叉特征融合网络, 减小逐级融合模式产生的信息干扰。最后, 为了加强模型对遮挡问题检测时区分相似物体的学习能力及对在背景和密集目标干扰情况下的准确定位能力, 设计加权斥力损失函数和 softer-NMS 筛选机制以帮助 YOLO 模型的更准确的定位和分类。实验结果表明, 本章节所提算法对于密集遮挡缺陷检测的有效性。

(4) 针对缺陷检测方法大规模、高精度与小型化高效率的矛盾, 提出一种嵌入并行注意力机制的卷积轻量化缺陷检测方法, 在保证 YOLO 算法检测精度的基础上, 压缩网络规模加快检测速度。首先, 利用 GhostNet 和深度可分离卷积操作替换冗余特征图卷积计算, 轻量化处理后大幅度压缩网络规模。其次, 设计基于通道和空间特征的并行注意力机制模块, 植入轻量化主干网络, 增强网络对缺陷有效信息通道的关注。之后, 结合通道层和亚像素卷积采样和双金字塔特征融合结构, 充分融合不同尺度的细粒度特征和语义特征, 进一步提高了模型的检测精度。实验结果表明, 本章节所提算法可以有效压缩 YOLO 模型的网络规模提高检测速度, 并且有效消除模型轻量化对缺陷检测精度的影响。相较于其他缺陷检测方法具有更好的检测效果, 在速度和精度之间取得了更好的平衡。

(5) 结合铝板带冷轧生产车间精整生产线生产现状和检测需求, 设计铝板带表面缺陷检测系统和可视化交互客户端, 实现实际生产场景下本文研究方法的工业化应用。首先, 设计了铝板带表面缺陷检测系统的工业化应用方案, 并说明了检测系统的总体结构和图像检测流程; 之后, 分别对检测系统的硬件系统结构和多线程软件系统进行了分析说明; 最后, 从工业现场检测需求出发, 设计了检测系统的可视化交互客户端软件, 并对软件系统各项功能进行详细说明, 以满足实际生产应用环境中的系统的运行性能和稳定性。

7.1.2 特色与创新点

本文的主要创新点如下:

(1) 针对工业检测场景下, 真实数据集的样本数量稀缺和样本分布极不均衡导致检测模型性能崩溃的问题, 寻找到一种基于 YOLO 框架下的少样本缺陷检测方法。以 YOLOv4 检测原理为基础, 将元学习的特征加权思想与多尺度结构结合, 强化不同类别元特征图的特定信息, 实现少样本条件下铝板带表面缺陷的快速、准确的端到端检测。该方法通过在 YOLO 框架下实现少样本条件目

标检测, 不仅解决了工业多任务检测场景中深度学习应用效果不佳的问题, 而且验证了元学习结合单阶段目标检测方法的方案在工业实时检测中的可行性和先进性。

(2) 针对连续性生产中多工序出现缺陷间相互交叠导致检测系统的漏检现象, 提出了基于多尺度上下文信息和斥力函数的抗遮挡缺陷检测方法。从增强缺陷特征表达的角度, 通过构建基于 RFB-Net 结构的特征提取模块和基于 Bi-FPN 思想的特征融合模块, 获取更多上下文信息并加强不同层级之间的语义特征。从生成预测框的筛选机制的角度, 通过斥力函数和 Soft-NMS 提高网络对高重叠预测框的区分能力, 有效降低 YOLO 模型对于密集遮挡目标的漏检率。该方法不仅改善了 YOLO 方法在真实检测环境中对于密集目标漏检现象, 提高了检测性能, 并且对于铝板带生产时不同工序缺陷的区分提供了数据支持, 为后续检测系统对加工过程质量预测奠定了基础。

(3) 针对传统目标检测方法网络规模庞大, 无法满足实际工业检测高精度、高速度的检测要求, 提出一种基于注意力机制的轻量化铝板表面缺陷检测方法。通过基于 GhostNet 和深度可分离卷积的轻量化卷积网络, 压缩 YOLO 网络规模以减小计算消耗加快检测速度。并且通过基于通道特征的采样融合网络和嵌入通道空间并行注意力机制, 丰富模型的特征信息以提高轻量化网络的检测精度。该方法成功的实现了缺陷检测方法检测速度和检测精度的共同提升, 为工业实时在线检测的实际应用和检测系统的集成化设计提供了支持。

7.2 研究展望

本文对基于 YOLO 检测框架的铝板带表面缺陷检测问题进行了初步探索, 目前开展的工作也只达到了工程实践中缺陷检测基本功能的实现和部分难点问题的可行性研究。基于 YOLO 的检测方法在表面缺陷检测领域仍有大量未开展的工作值得进一步深入研究。因此, 本文未来的工作将计划围绕以下几个方法展开:

(1) 少样本条件下检测性能的提升。少样本学习和少样本目标检测尚处于起步阶段, 本文提出的基于元特征重加权的特征提取模式只是一种适合于 YOLO 检测框架的尝试, 仍存在许多优化、改进的空间。一, 从数据集的构建角度, 基类预训练的数据样本的多样性扩充, 以增加对于缺陷通用特征的更全面覆盖。二, 模型中元特征提取模块和特征加权向量提取模块, 通过加入细粒度区分和注意力增强等机制强化对于样本中细微特征和特定特征的区分能力。三, 优化少样本检测时对于新类样本微调训练的策略设定, 增加训练过程的自适应性和灵活性。

(2) 基于生成思想对样本多样性现象的可行性探索。本文主要通过多尺度架构丰富缺陷特征间的表达,而并未针对样本分布特点的多样性和不均衡性对检测结果产生的影响进行深入研究。通过基于生成思想的网络模型(生成对抗网络, GAN),研究不同缺陷样本间的特征潜在分布规律,以少量样本为基础利用特征信息形成特定的知识,引导网络丰富缺陷特征多样性,解决少样本检测时特征维度缺少导致的性能不佳。

(3) 借鉴分割思想优化数据的标注,提升遮挡缺陷检测的性能。本文采取基于矩形模板的样本标注标准,而部分表面缺陷呈现为带有不同角度的细条状或不规则区域形,矩形标注框会导致部分背景区域被作为缺陷特征。当缺陷之间出现相互遮挡时,矩形标注框中出现无关特征会干扰模型对于遮挡缺陷、被遮挡缺陷以及背景之间的特征区分学习能力。因此,借鉴基于目标分割的相关算法,实现对于缺陷区域特征的自适应提取,增加像素间的从属区域信息,避免特征提取时无关信息对于模型的干扰和误导,降低模型对于不同程度遮挡缺陷的漏检率。同时,可以降低工业复杂环境对于检测系统采集质量造成的影响。

(4) 轻量化检测方法的性能优化及嵌入集成设备的研究。本文采用低冗余结构网络设计,对表面缺陷检测模型进行了轻量化处理。目前的轻量化工作均是基于单一方法或是不同方法的分阶段优化的研究,可以通过将不同压缩技术合理的融合,实现进一步的压缩网络和提高性能,从而探索一种更高效的轻量化思路。此外,本文仅对轻量化技术进行了探索,没有实现铝板带表面缺陷检测方法在边缘设备上的部署、验证和集成。后续研究可以将检测系统硬件结构向微型化、集成化的方向发展,实现低功耗、硬件和软件一体化的集成边缘设备,便于在安装空间较小的生产设备上或其他检测场景下使用,拓宽检测系统的应用范围和领域。

参考文献

- [1] 张衬新. 中国铝加工行业市场现状及发展趋势 [J]. 有色冶金设计与研究, 2017, 38(02): 27-30.
- [2] 陈良. 国内铝板带箔加工行业的现状分析 [J]. 有色金属加工, 2014, 43(03): 1-4.
- [3] WANG F Y. The Emergence of Intelligent Enterprises: From CPS to CPSS [J]. IEEE Intelligent Systems, 2010, 25(4): 85-88.
- [4] HARRISON R, VERA D, AHMAD B. Engineering Methods and Tools for Cyber-Physical Automation Systems [J]. Proceedings of the IEEE, 2016, 104(5): 973-985.
- [5] 王耀南, 陈铁健, 贺振东, et al. 智能制造装备视觉检测控制方法综述 [J]. 控制理论与应用, 2015, 32(03): 273-286.
- [6] HELIFA B, OULHADJ A, BENBELGHIT A, et al. Detection and measurement of surface cracks in ferromagnetic materials using eddy current testing [J]. NDT & E International, 2006, 39(5): 384-390.
- [7] DENG W, BAO J, LUO S, et al. Simulation Analysis of Eddy Current Testing Parameters for Surface and Subsurface Defect Detection of Aviation Aluminum Alloy Plate [J]. Journal of Sensors, 2022, 2022: 8111998.
- [8] ZHANG K, HE Y, DONG Z. Pulsed Eddy Current Nondestructive Testing for Defect Evaluation and Imaging of Automotive Lightweight Alloy Materials [J]. Journal of Sensors, 2018, 2018: 1639387.
- [9] D'ACCARDI E, PALUMBO D, TAMBORRINO R, et al. A Quantitative Comparison among Different Algorithms for Defects Detection on Aluminum with the Pulsed Thermography Technique [J]. Metals, 2018, 8(10): 859.
- [10] DU W, SHEN H, FU J, et al. Approaches for improvement of the X-ray image defect detection of automobile casting aluminum parts based on deep learning [J]. NDT & E International, 2019, 107: 102144.
- [11] WANG D, XIAO H, WU D. Application of unsupervised adversarial learning in radiographic testing of aeroengine turbine blades [J]. NDT & E International, 2023, 134: 102766.
- [12] PARLAK İ E, EMEL E. Deep learning-based detection of aluminum casting defects and their types [J]. Engineering Applications of Artificial Intelligence, 2023, 118: 105636.
- [13] LIANG X, LIN B, LIU Z, et al. Detection of surface defects based on the optimized scanning laser source method [J]. Wave Motion, 2023, 118: 103113.

- [14] ZHOU Y, CAO Y, WANG N, et al. Crack detection in l-shaped aluminum plate via electromagnetic ultrasonic measurements [J]. Theoretical and Applied Fracture Mechanics, 2022, 121.
- [15] LIU H, LIU M, ZHANG L, et al. Directed acoustic shearography for crack detection around fastener holes in aluminum plates [J]. NDT & E International, 2018, 100: 124-131.
- [16] BATCHELOR B. Industrial Applications of Solid-State Image Scanners [J]. Optica Acta, 1979, 26(7): 836.
- [17] HUANG C, WANG G, SONG H, et al. Rapid surface defects detection in wire and arc additive manufacturing based on laser profilometer [J]. Measurement, 2022, 189: 110503.
- [18] YAN Z, SHI B, SUN L, et al. Surface defect detection of aluminum alloy welds with 3D depth image and 2D gray image [J]. The International Journal of Advanced Manufacturing Technology, 2020, 110(3-4): 741-752.
- [19] SURESH B R, FUNDAKOWSKI R A, LEVITT T S, et al. A real-time automated visual inspection system for hot steel slabs [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1983, (6): 563-572.
- [20] PORTER T, SYLVESTER R, BOUYOUCAS T. Automatic strip surface defect detection system [J]. Iron and Steel Engineer, 1988, 65(12): 17-20.
- [21] CANELLA G, FALESSI R. Surface inspection and classification plant for stainless steel strip [J]. Non-Destructive Testing, 1992, 4: 1185-1189.
- [22] VASCOTTO M. High speed surface defect identification on steel strip [J]. Metallurgical Plant and Technology International(Germany), 1996, 4: 70-73.
- [23] JOUET ET AL J. Defect Classification in surface inspection of strip steel [J]. Steel Times, 1992, 16(5): 214-216.
- [24] CHOI K, KOO K, LEE J S. Development of defect classification algorithm for POSCO rolling strip surface inspection system [C]// proceedings of the 2006 SICE-ICASE International Joint Conference. Busan, Korea (South): IEEE, 2006: 2499-2502.
- [25] RINN R, BECKER M, FOEHR R, et al. Steel mill defect detection and classification at 3000 ft/min using mainstream technology [C]// proceedings of the Real-Time Imaging III. SPIE, 1998: 20-26.
- [26] UEMURA A, SHIRAI M. New technologies for steel manufacturing based upon plant engineering [J]. NKK Technical Review(Japan), 2003, 88: 37-45.
- [27] 吕红军, 罗志勇. 冷轧钢板表面缺陷检测的信号处理 [J]. 量子电子学, 1991, (01): 91-92.
- [28] 胡亮, 段发阶, 丁克勤, et al. 带钢表面缺陷计算机视觉在线检测系统的设计 [J]. 无损检测, 2003, (06): 287-290.

- [29] 胡亮, 段发阶, 丁克勤, et al. 钢板表面缺陷计算机视觉在线检测系统的研制 [J]. 钢铁, 2005, (02): 59-61.
- [30] 徐科, 徐金梧, 鹿守理, et al. 冷轧带钢表面自动监测系统的研究 [J]. 钢铁, 2000, (10): 63-66.
- [31] 徐科, 徐金梧, 班晓娟. 冷轧带钢表面质量自动监测系统的模式识别方法研究 [J]. 钢铁, 2002, (06): 28-31.
- [32] 徐科, 徐金梧, 陈雨来. 冷轧带钢表面缺陷在线监测系统 [J]. 北京科技大学学报, 2002, (03): 329-332.
- [33] 徐科, 徐金梧, 梁治国, et al. 冷轧带钢表面质量自动检测系统的在线应用研究 [J]. 冶金自动化, 2003, (01): 51-53+74.
- [34] 徐科, 杨朝霖, 周鹏. 热轧带钢表面缺陷在线检测的方法与工业应用 [J]. 机械工程学报, 2009, 45(04): 111-114+124.
- [35] 刘钟, 吴杰, 张华. 热轧带钢表面质量检测系统的工程设计与实践 [J]. 宝钢技术, 2005, (06): 57-61.
- [36] 王军. 梅钢 1422 热轧在线检测技术的应用 [J]. 金属材料与冶金工程, 2010, 38(04): 50-52.
- [37] 黄秀琴, 罗新斌, 贾建昇, et al. 在线铝带材表面检测系统 [J]. 轻合金加工技术, 2014, 42(12): 40-45.
- [38] LUO Q, FANG X, LIU L, et al. Automated Visual Defect Detection for Flat Steel Surface: A Survey [J]. IEEE Transactions on Instrumentation and Measurement, 2020, 69(3): 626-644.
- [39] LUO Q, FANG X, SU J, et al. Automated Visual Defect Classification for Flat Steel Surface: A Survey [J]. IEEE Transactions on Instrumentation and Measurement, 2020, 69(12): 9329-9349.
- [40] NEOGI N, MOHANTA D K, DUTTA P K. Review of vision-based steel surface inspection systems [J]. Eurasip J Image Vide, 2014, 2014(1): 1-19.
- [41] 郭晨龙, 赵旭阳, 郑海燕, et al. 一种基于改进非局部均值滤波算法的红外图像去噪 [J]. 红外技术, 2018, 40(07): 638-641.
- [42] 胡旺, 李志蜀, 黄奇. 基于双窗口和极值压缩的自适应中值滤波 [J]. 中国图象图形学报, 2007, (01): 43-50.
- [43] 吴炬卓, 牛海清, 张煌, et al. 一种应用小波系数 GSM 模型的混合傅里叶-小波电缆瓷套终端红外图像去噪方法 [J]. 电测与仪表, 2018, 55(04): 113-117.
- [44] 周先春, 吴婷, 石兰芳, et al. 一种基于曲率变分正则化的小波变换图像去噪方法 [J]. 电子学报, 2018, 46(03): 621-628.
- [45] RATLIFF B M, HAYAT M M, HARDIE R C. An algebraic algorithm for nonuniformity correction in focal-plane arrays [J]. Journal of the Optical Society of America A: Optics and Image Science, and Vision, 2002, 19(9): 1737-1747.
- [46] TORRES S N, HAYAT M M. Kalman filtering for adaptive nonuniformity

- correction in infrared focal-plane arrays [J]. Journal of the Optical Society of America A: Optics and Image Science, and Vision, 2003, 20(3): 470-480.
- [47] PEZOA J E, HAYAT M M, TORRES S N, et al. Multimodel Kalman filtering for adaptive nonuniformity correction in infrared sensors [J]. Journal of the Optical Society of America A: Optics and Image Science, and Vision, 2006, 23(6): 1282-1291.
- [48] 罗新斌. 机器视觉带材表面缺陷检测关键技术研究 [D]. 上海: 上海交通大学, 2016.
- [49] 叶刚, 李毅波, 马逐曦, et al. 基于 ViBe 的端到端铝带表面缺陷检测识别方法 [J]. 浙江大学学报(工学版), 2020, 54(10): 1906-1914.
- [50] NAND G K, NOOPUR, NEOGI N. Defect detection of steel surface using entropy segmentation [C]// proceedings of the 2014 Annual IEEE India Conference (INDICON). Pune, India: IEEE, 2014: 1-6.
- [51] 闵永智, 岳彪, 马宏锋, et al. 基于图像灰度梯度特征的钢轨表面缺陷检测 [J]. 仪器仪表学报, 2018, 39(04): 220-229.
- [52] CHEN J, ZHENG H, LIN X, et al. A novel image segmentation method based on fast density clustering algorithm [J]. Engineering Applications of Artificial Intelligence, 2018, 73: 92-110.
- [53] WU Y, LIU J, ZHANG Y, et al. Detection Algorithm of Aluminum Surface Defects Using Machine Vision [C]// proceedings of the the 2019 International Conference on Image, Video and Signal Processing. Shanghai, China: Association for Computing Machinery, 2019: 16-22.
- [54] ZHAO Y J, YAN Y H, SONG K C. Vision-based automatic detection of steel surface defects in the cold rolling process: considering the influence of industrial liquids and surface textures [J]. The International Journal of Advanced Manufacturing Technology, 2017, 90(5-8): 1665-1678.
- [55] ZHOU Y, MA Z, SHI X, et al. An adaptive clustering method detecting the surface defects on linear guide rails [J]. International Journal of Computer Integrated Manufacturing, 2019, 32(8): 798-808.
- [56] SISON H, KONGHUAYROB P, KAITWANIDVILAI S. A Convolutional Neural Network for Segmentation of Background Texture and Defect on Copper Clad Lamination Surface [C]// proceedings of the 2018 International Conference on Engineering, Applied Sciences, and Technology (ICEAST). Phuket, Thailand, 2018: 1-4.
- [57] TANG B, KONG J Y, WANG X D, et al. Surface Inspection System of Steel Strip Based on Machine Vision [C]// proceedings of the 2009 First International Workshop on Database Technology and Applications. Wuhan, China: IEEE, 2009: 359-362.

- [58] 郭皓然, 邵伟, 周阿维, et al. 全局阈值自适应的高亮金属表面缺陷识别新方法 [J]. 仪器仪表学报, 2017, 38(11): 2797-2804.
- [59] LEE S, CHANG L-M, SKIBNIEWSKI M. Automated recognition of surface defects using digital color image processing [J]. Automation in Construction, 2006, 15(4): 540-549.
- [60] ZHAI M, FU S, GU S, et al. Defect detection in aluminum foil by measurement-residual-based chi-square detector [J]. The International Journal of Advanced Manufacturing Technology, 2010, 53(5-8): 661-667.
- [61] CHONDRONASIOS A, POPOV I, JORDANOV I. Feature selection for surface defect classification of extruded aluminum profiles [J]. The International Journal of Advanced Manufacturing Technology, 2016, 83: 33-41.
- [62] WANG Y, XIA H, YUAN X, et al. Distributed defect recognition on steel surfaces using an improved random forest algorithm with optimal multi-feature-set fusion [J]. Multimedia Tools and Applications, 2018, 77: 16741-16770.
- [63] 陈后金, 许文达, 郝晓莉. 基于灰度-梯度共生矩阵的钢轨表面缺陷检测方法 [J]. 北京交通大学学报, 2015, 39(02): 7-12.
- [64] LUO Q, SUN Y, LI P, et al. Generalized Completed Local Binary Patterns for Time-Efficient Steel Surface Defect Classification [J]. IEEE Transactions on Instrumentation and Measurement, 2019, 68(3): 667-679.
- [65] FEKRI-ERSHAD S, TAJERIPOUR F. Multi-resolution and noise-resistant surface defect detection approach using new version of local binary patterns [J]. Applied Artificial Intelligence, 2017, 31(5-6): 395-410.
- [66] YAN K, DONG Q, SUN T, et al. Weld defect detection based on completed local ternary patterns [C]// proceedings of the ICVIP 2017: International Conference on Video and Image Processing. Singapore, Singapore: Association for Computing Machinery, 2017: 6-14.
- [67] ZHANG J, GUO Z, JIAO T, et al. Defect detection of aluminum alloy wheels in radiography images using adaptive threshold and morphological reconstruction [J]. Applied Sciences, 2018, 8(12): 2365.
- [68] LIU X, XU K, ZHOU D. Improvements for the Recognition Rate of Surface Defects of Aluminum Sheets [C]// proceedings of the Light Metals 2019. Springer International Publishing, 2019: 513-518.
- [69] CHOI D-C, JEON Y-J, KIM S H, et al. Detection of Pinholes in Steel Slabs Using Gabor Filter Combination and Morphological Features [J]. ISIJ International, 2017, 57(6): 1045-1053.
- [70] DAS B, PAL S, BAG S. A combined wavelet packet and Hilbert-Huang transform for defect detection and modelling of weld strength in friction stir welding process [J]. Journal of Manufacturing Processes, 2016, 22: 260-268.

- [71] XU K, XU Y, ZHOU P, et al. Application of RNAMlet to surface defect identification of steels [J]. Optics and Lasers in Engineering, 2018, 105: 110-117.
- [72] WANG H, ZHANG J, TIAN Y, et al. A Simple Guidance Template-Based Defect Detection Method for Strip Steel Surfaces [J]. IEEE Transactions on Industrial Informatics, 2019, 15(5): 2798-2809.
- [73] LIU K, WANG H, CHEN H, et al. Steel surface defect detection using a new Haar-Weibull-variance model in unsupervised manner [J]. IEEE Transactions on Instrumentation and Measurement, 2017, 66(10): 2585-2596.
- [74] TAO X, ZHANG D, WANG Z, et al. Detection of Power Line Insulator Defects Using Aerial Images Analyzed With Convolutional Neural Networks [J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2020, 50(4): 1486-1498.
- [75] CHU M-X, WANG A-N, GONG R-F, et al. Multi-class Classification Methods of Enhanced LS-TWSVM for Strip Steel Surface Defects [J]. Journal of Iron and Steel Research International, 2014, 21(2): 174-180.
- [76] LIU Z, YANG B, DUAN G, et al. Visual Defect Inspection of Metal Part Surface via Deformable Convolution and Concatenate Feature Pyramid Neural Networks [J]. IEEE Transactions on Instrumentation and Measurement, 2020, 69(12): 9681-9694.
- [77] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition [J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [78] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition [J]. arXiv preprint arXiv:1409.1556, 2014.
- [79] SZEGEDY C, LIU W, JIA Y, et al. Going deeper with convolutions [C]// proceedings of the 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Boston, MA, USA: IEEE, 2015: 1-9.
- [80] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition [C]// proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas, NV, USA: IEEE, 2016: 770-778.
- [81] SZEGEDY C, IOFFE S, VANHOUCKE V, et al. Inception-v4, inception-resnet and the impact of residual connections on learning [C]// proceedings of the the Thirty-First AAAI Conference on Artificial Intelligence (AAAI 17). San Francisco, California, USA: AAAI Press, 2017
- [82] LIU X, HE W, ZHANG Y, et al. Effect of dual-convolutional neural network model fusion for Aluminum profile surface defects classification and recognition [J]. Mathematical Biosciences and Engineering, 2022, 19(1): 997-1025.
- [83] ZHONG J, LIU Z, HAN Z, et al. A CNN-based defect inspection method for catenary split pins in high-speed railway [J]. IEEE Transactions on

- Instrumentation and Measurement, 2018, 68(8): 2849-2860.
- [84] DUAN C, ZHANG T. Two-Stream Convolutional Neural Network Based on Gradient Image for Aluminum Profile Surface Defects Classification and Recognition [J]. IEEE Access, 2020, 8: 172152-172165.
- [85] GAO Y P, GAO L, LI X Y, et al. A Multilevel Information Fusion-Based Deep Learning Method for Vision-Based Defect Recognition [J]. IEEE Transactions on Instrumentation and Measurement, 2020, 69(7): 3980-3991.
- [86] LIANG Y, XU K, ZHOU P. Mask Gradient Response-Based Threshold Segmentation for Surface Defect Detection of Milled Aluminum Ingot [J]. Sensors, 2020, 20(16): 4519.
- [87] HE Y, SONG K C, MENG Q G, et al. An End-to-End Steel Surface Defect Detection Approach via Fusing Multiple Hierarchical Features [J]. IEEE Transactions on Instrumentation and Measurement, 2020, 69(4): 1493-1504.
- [88] SONG K, HU S, YAN Y. Automatic recognition of surface defects on hot-rolled steel strip using scattering convolution network [J]. Journal of Computer Information Systems, 2014, 10(7): 3049-3055.
- [89] CHEN F C, JAHANSHAH M R. NB-CNN: Deep Learning-Based Crack Detection Using Convolutional Neural Network and Naïve Bayes Data Fusion [J]. IEEE Transactions on Industrial Electronics, 2018, 65(5): 4392-4400.
- [90] SONG L, LIN W, YANG Y G, et al. Weak Micro-Scratch Detection Based on Deep Convolutional Neural Network [J]. IEEE Access, 2019, 7: 27547-27554.
- [91] ZHANG S, ZHANG Q, GU J, et al. Visual inspection of steel surface defects based on domain adaptation and adaptive convolutional neural network [J]. Mechanical Systems and Signal Processing, 2021, 153: 107541.
- [92] SHI Y, LI L, YANG J, et al. Center-based Transfer Feature Learning With Classifier Adaptation for surface defect recognition [J]. Mechanical Systems and Signal Processing, 2023, 188: 110001.
- [93] SCHLEGL T, SEEBÖCK P, WALDSTEIN S M, et al. Unsupervised anomaly detection with generative adversarial networks to guide marker discovery [C]// proceedings of the Information Processing in Medical Imaging: 25th International Conference (IPMI 2017). Boone, NC, USA: Springer, 2017: 146-157.
- [94] LI S, WU C, XIONG N. Hybrid architecture based on CNN and Transformer for strip steel surface defect classification [J]. Electronics, 2022, 11(8): 1200.
- [95] LIU T, BAO J, WANG J, et al. A hybrid CNN-LSTM algorithm for online defect recognition of CO2 welding [J]. Sensors, 2018, 18(12): 4369.
- [96] YUN J P, SHIN W C, KOO G, et al. Automated defect inspection system for metal surfaces based on deep learning and data augmentation [J]. Journal of

- Manufacturing Systems, 2020, 55: 317-324.
- [97] ZHENG X, ZHENG S, KONG Y, et al. Recent advances in surface defect inspection of industrial products using deep learning techniques [J]. The International Journal of Advanced Manufacturing Technology, 2021, 113: 35-58.
- [98] GAO Y, GAO L, LI X, et al. A semi-supervised convolutional neural network-based method for steel surface defect recognition [J]. Robotics and Computer-Integrated Manufacturing, 2020, 61: 101825.
- [99] ZHAO Z, LI B, DONG R, et al. A surface defect detection method based on positive samples [C]// proceedings of the PRICAI 2018: Trends in Artificial Intelligence: 15th Pacific Rim International Conference on Artificial Intelligence. Nanjing, China: Springer, 2018: 473-481.
- [100] MEI S, YANG H, YIN Z. An unsupervised-learning-based approach for automated defect inspection on textured surfaces [J]. IEEE Transactions on Instrumentation and Measurement, 2018, 67(6): 1266-1277.
- [101] CHEN R, CAI D, HU X, et al. Defect Detection Method of Aluminum Profile Surface Using Deep Self-Attention Mechanism Under Hybrid Noise Conditions [J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-9.
- [102] JAIN S, SETH G, PARUTHI A, et al. Synthetic data augmentation for surface defect detection and classification using deep learning [J]. Journal of Intelligent Manufacturing, 2020, 33(4): 1007-1020.
- [103] ZHANG F, CHEN Z. IDDM: An incremental dual-network detection model for in-situ inspection of large-scale complex product [J]. Journal of Industrial Information Integration, 2023, 33: 100463.
- [104] GAO Y P, GAO L, LI X Y. A hierarchical training-convolutional neural network with feature alignment for steel surface defect recognition [J]. Robotics and Computer-Integrated Manufacturing, 2023, 81: 102507.
- [105] LUO Q, LIU K, SU J, et al. Waterdrop Removal From Hot-Rolled Steel Strip Surfaces Based on Progressive Recurrent Generative Adversarial Networks [J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-11.
- [106] ZHOU X, FANG H, LIU Z, et al. Dense Attention-Guided Cascaded Network for Salient Object Detection of Strip Steel Surface Defects [J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-14.
- [107] ZOU Z, SHI Z, GUO Y, et al. Object Detection in 20 Years: A Survey [J]. Proceedings of the IEEE, 2023, 111(3): 257-276.
- [108] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation [C]// proceedings of the 2014 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Columbus, OH, USA: IEEE, 2014: 580-587.

- [109] ZHANG Y, XIE F, HUANG L, et al. A Lightweight One-Stage Defect Detection Network for Small Object Based on Dual Attention Mechanism and PAFPN [J]. *Frontiers in Physics*, 2021, 9.
- [110] TIAN R, JIA M. DCC-CenterNet: A rapid detection method for steel surface defects [J]. *Measurement*, 2022, 187: 110211.
- [111] GIRSHICK R. Fast R-CNN [C]// proceedings of the 2015 IEEE International Conference on Computer Vision (ICCV). Santiago, Chile: IEEE, 2015: 1440-1448.
- [112] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2017, 39(6): 1137-1149.
- [113] HE K, GKIOXARI G, DOLLÁR P, et al. Mask R-CNN [C]// proceedings of the 2017 IEEE International Conference on Computer Vision (ICCV). Venice, Italy: IEEE, 2017: 2980-2988.
- [114] CAI Z, VASCONCELOS N. Cascade r-cnn: Delving into high quality object detection [C]// proceedings of the 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Salt Lake City, UT, USA: IEEE, 2018: 6154-6162.
- [115] REN Q, GENG J, LI J. Slighter Faster R-CNN for real-time detection of steel strip surface defects [C]// proceedings of the 2018 Chinese Automation Congress (CAC). Xi'an, China: IEEE, 2018: 2173-2178.
- [116] WEI R, BI Y. Research on Recognition Technology of Aluminum Profile Surface Defects Based on Deep Learning [J]. *Materials (Basel)*, 2019, 12(10): 1681.
- [117] CHEN K, ZENG Z, YANG J. A deep region-based pyramid neural network for automatic detection and multi-classification of various surface defects of aluminum alloys [J]. *Journal of Building Engineering*, 2021, 43: 102523.
- [118] LIU R, HUANG M, GAO Z, et al. MSC-DNet: An efficient detector with multi-scale context for defect detection on strip steel surface [J]. *Measurement*, 2023, 209: 112467.
- [119] TANG B, SONG Z K, SUN W, et al. An end - to - end steel surface defect detection approach via Swin transformer [J]. *IET Image Processing*, 2022, 17(5): 1334-1345.
- [120] LIU Z, TANG R, DUAN G, et al. TruingDet: Towards high-quality visual automatic defect inspection for metal surface [J]. *Optics and Lasers in Engineering*, 2021, 138: 106423.
- [121] LIU W, ANGUELOV D, ERHAN D, et al. SSD: Single Shot MultiBox Detector [C]// proceedings of the Computer Vision-ECCV 2016: 14th European

- Conference. Amsterdam, The Netherlands: Springer International Publishing, 2016: 21-37.
- [122] REDMON J, DIVVALA S, GIRSHICK R, et al. You Only Look Once: Unified, Real-Time Object Detection [C]// proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas, NV, USA: IEEE Computer Society, 2016: 779-788.
- [123] REDMON J, FARHADI A. YOLOv3: An Incremental Improvement [J]. arXiv preprint arXiv:1804.02767, 2018.
- [124] REDMON J, FARHADI A, IEEE. YOLO9000: Better, Faster, Stronger [C]// proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu, HI, USA: IEEE, 2017: 6517-6525.
- [125] WU B, WAN A, IANDOLA F, et al. SqueezeDet: Unified, Small, Low Power Fully Convolutional Neural Networks for Real-Time Object Detection for Autonomous Driving [C]// proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). Honolulu, HI, USA: IEEE, 2017: 446-454.
- [126] WU D, SHEN X, CHEN L. Detection of Defects on Aluminum Profile Surface Based on Improved YOLO [C]// proceedings of the 2022 Prognostics and Health Management Conference (PHM-2022 London). 2022: 468-472.
- [127] XING J J, JIA M P. A convolutional neural network-based method for workpiece surface defect detection [J]. Measurement, 2021, 176: 109185.
- [128] KOU X, LIU S, CHENG K, et al. Development of a YOLO-V3-based model for detecting defects on steel strip surface [J]. Measurement, 2021, 182: 109454.
- [129] LI J, SU Z, GENG J, et al. Real-time detection of steel strip surface defects based on improved yolo detection network [J]. IFAC-PapersOnLine, 2018, 51(21): 76-81.
- [130] CHENG X, YU J. RetinaNet With Difference Channel Attention and Adaptively Spatial Feature Fusion for Steel Surface Defect Detection [J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-11.
- [131] XU Y, ZHANG K, WANG L. Metal surface defect detection using modified YOLO [J]. Algorithms, 2021, 14(9): 257.
- [132] IKECHUKWU S, AKIN E. High Performance Network for Detection of Surface Defects on Hot-Rolled Steel Strips Based on an Optimized Yolo V3 [C]// proceedings of the 2022 9th International Conference on Electrical and Electronics Engineering (ICEEE). 2022: 1-6.
- [133] LI Z, TIAN X, LIU X, et al. A Two-Stage Industrial Defect Detection Framework Based on Improved-YOLOv5 and Optimized-Inception-ResnetV2 Models [J]. Applied Sciences, 2022, 12(2): 834.

- [134] WEN L, ZHANG Y, GAO L, et al. A New Multiscale Multiattention Convolutional Neural Network for Fine-Grained Surface Defect Detection [J]. IEEE Transactions on Instrumentation and Measurement, 2023, 72: 1-11.
- [135] WANG T, SU J, XU C, et al. An Intelligent Method for Detecting Surface Defects in Aluminium Profiles Based on the Improved YOLOv5 Algorithm [J]. Electronics, 2022, 11(15): 2304.
- [136] LI Y, HUANG H, XIE Q, et al. Research on a Surface Defect Detection Algorithm Based on MobileNet-SSD [J]. Applied Sciences, 2018, 8(9): 1678.
- [137] YANG J, LI S, WANG Z, et al. Real-Time Tiny Part Defect Detection System in Manufacturing Using Deep Learning [J]. IEEE Access, 2019, 7: 89278-89291.
- [138] QI H, XU T, WANG G, et al. MYOLOv3-Tiny: A new convolutional neural network architecture for real-time detection of track fasteners [J]. Computers in Industry, 2020, 123: 103303.
- [139] CHEN H, DU Y, FU Y, et al. DCAM-Net: A Rapid Detection Network for Strip Steel Surface Defects Based on Deformable Convolution and Attention Mechanism [J]. IEEE Transactions on Instrumentation and Measurement, 2023, 72: 1-12.
- [140] HU Q, TANG B, JIANG L, et al. Rail Surface Defects Detection Based on Yolo v5 Integrated with Transformer [C]// proceedings of the 2022 IEEE 5th International Conference on Electronics Technology (ICET). 2022: 1131-1135.
- [141] BOCHKOVSKIY A, WANG C-Y, LIAO H-Y M. YOLOv4: Optimal Speed and Accuracy of Object Detection [J]. arXiv preprint arXiv:2004.10934, 2020.
- [142] LI C, LI L, JIANG H, et al. YOLOv6: A Single-Stage Object Detection Framework for Industrial Applications [J]. arXiv preprint arXiv:2209.02976, 2022.
- [143] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: Trainable Bag-of-Freebies Sets New State-of-the-Art for Real-Time Object Detectors [C]// proceedings of the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver, BC, Canada: IEEE, 2023: 7464-7475.
- [144] TIAN Z, SHEN C, CHEN H, et al. Fcos: Fully convolutional one-stage object detection [C]// proceedings of the 2019 IEEE/CVF International Conference on Computer Vision (ICCV). Seoul, Korea (South): IEEE, 2019: 9627-9636.
- [145] DUAN K, BAI S, XIE L, et al. Centernet: Keypoint triplets for object detection [C]// proceedings of the 2019 IEEE/CVF International Conference on Computer Vision (ICCV). Seoul, Korea (South): IEEE, 2019: 6569-6578.
- [146] YU J, CHENG X, LI Q. Surface Defect Detection of Steel Strips Based on Anchor-Free Network With Channel Attention and Bidirectional Feature Fusion [J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-10.

- [147] SHI H, LAI R, LI G, et al. Visual inspection of surface defects of extreme size based on an advanced FCOS [J]. *Applied Artificial Intelligence*, 2022, 36(1).
- [148] TERVEN J, CORDOVA-ESPARZA D. A Comprehensive Review of YOLO: From YOLOv1 and Beyond [J]. *arXiv preprint arXiv:2304.00501*, 2023.
- [149] 邵延华, 张铎, 楚红雨, et al. 基于深度学习的 YOLO 目标检测综述 [J]. *电子与信息学报*, 2022, 44(10): 3697-3708.
- [150] WANG C-Y, HONG Y, YE H I H, et al. CSPNet: A New Backbone that can Enhance Learning Capability of CNN [J]. *arXiv preprint arXiv:1911.11929*, 2019.
- [151] IOFFE S, SZEGEDY C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift [C]// *proceedings of the 32nd International Conference on International Conference on Machine Learning*. Lille, France: JMLR.org, 2015: 448-456.
- [152] HE K, ZHANG X, REN S, et al. Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2015, 37(9): 1904-1916.
- [153] LIN T Y, DOLLÁR P, GIRSHICK R, et al. Feature Pyramid Networks for Object Detection [C]// *proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. Honolulu, HI, USA: IEEE, 2017: 936-944.
- [154] LIU S, QI L, QIN H, et al. Path Aggregation Network for Instance Segmentation [J]. *arXiv preprint arXiv:1803.01534*, 2018.
- [155] 东北轻合金有限责任公司. 变形铝及铝合金铸锭及加工产品缺陷 第 3 部分: 板、带缺陷 [Z]. 中华人民共和国国家质量监督检验检疫总局;中国国家标准化管理委员会. 2011: 32
- [156] KISANTAL M, WOJNA Z, MURAWSKI J, et al. Augmentation for small object detection [M]. 2019.
- [157] 刘伟嵬. 冷轧带钢表面缺陷检测中非缺陷信息滤除问题的研究 [D]. 沈阳: 东北大学, 2009.
- [158] NAKAMURA A, HARADA T. Revisiting fine-tuning for few-shot learning [J]. *arXiv preprint arXiv:1910.00216*, 2019.
- [159] GOODFELLOW I J, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets [C]// *proceedings of the 27th International Conference on Neural Information Processing Systems*. Montreal, Canada: MIT Press, 2014: 2672-2680.
- [160] XIAN Y, SHARMA S, SCHIELE B, et al. f-vaegan-d2: A feature generating framework for any-shot learning [C]// *proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. Long Beach,

- CA, USA: IEEE, 2019: 10275-10284.
- [161] HARIHARAN B, GIRSHICK R. Low-shot visual recognition by shrinking and hallucinating features [C]// proceedings of the 2017 IEEE International Conference on Computer Vision (ICCV). Venice, Italy: IEEE, 2017: 3018-3027.
- [162] BOŽIČ J, TABERNIK D, SKOČAJ D. Mixed supervision for surface-defect detection: From weakly to fully supervised learning [J]. Computers in Industry, 2021, 129: 103459.
- [163] DESHPANDE A M, MINAI A A, KUMAR M. One-shot recognition of manufacturing defects in steel surfaces [J]. Procedia Manufacturing, 2020, 48: 1064-1071.
- [164] 黄彭奇子, 段晓君, 黄文伟, et al. 基于元学习的小样本图像非对称缺陷检测方法 [J]. 吉林大学学报(工学版), 2023, 53(01): 234-240.
- [165] KOCH G, ZEMEL R, SALAKHUTDINOV R. Siamese neural networks for one-shot image recognition [C]// proceedings of the ICML deep learning workshop. Lille, 2015
- [166] SUNG F, YANG Y, ZHANG L, et al. Learning to compare: Relation network for few-shot learning [C]// proceedings of the 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Salt Lake City, UT, USA: IEEE, 2018: 1199-1208.
- [167] KARLINSKY L, SHTOK J, HARARY S, et al. Repmet: Representative-based metric learning for classification and few-shot object detection [C]// proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach, CA, USA: IEEE, 2019: 5197-5206.
- [168] MUNKHDALAI T, YU H. Meta networks [C]// proceedings of the 34th International Conference on Machine Learning. Sydney, NSW, Australia: JMLR.org, 2017: 2554-2563.
- [169] FINN C, ABBEEL P, LEVINE S. Model-agnostic meta-learning for fast adaptation of deep networks [C]// proceedings of the 34th International Conference on Machine Learning. Sydney, NSW, Australia: JMLR.org, 2017: 1126-1135.
- [170] GIDARIS S, KOMODAKIS N. Dynamic few-shot visual learning without forgetting [C]// proceedings of the 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Salt Lake City, UT, USA: IEEE, 2018: 4367-4375.
- [171] WANG Y X, GIRSHICK R, HEBERT M, et al. Low-Shot Learning from Imaginary Data [C]// proceedings of the 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Salt Lake City, UT, USA: IEEE, 2018: 7278-7286.

- [172] VINYALS O, BLUNDELL C, LILLICRAP T, et al. Matching networks for one shot learning [C]// proceedings of the 30th International Conference on Neural Information Processing Systems. Barcelona, Spain: Curran Associates Inc., 2016: 3637–3645.
- [173] TIAN Y, WANG Y, KRISHNAN D, et al. Rethinking few-shot image classification: a good embedding is all you need? [C]// proceedings of the Computer Vision-ECCV 2020: 16th European Conference. Glasgow, UK: Springer, 2020: 266-282.
- [174] SNELL J, SWERSKY K, ZEMEL R. Prototypical networks for few-shot learning [C]// proceedings of the 31st International Conference on Neural Information Processing Systems. Long Beach, California, USA: Curran Associates Inc., 2017: 4080–4090.
- [175] KANG B, LIU Z, WANG X, et al. Few-Shot Object Detection via Feature Reweighting [C]// proceedings of the 2019 IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 8419-8428.
- [176] YAN X, CHEN Z, XU A, et al. Meta r-cnn: Towards general solver for instance-level low-shot learning [C]// proceedings of the 2019 IEEE/CVF International Conference on Computer Vision (ICCV). Seoul, Korea (South): IEEE, 2019: 9577-9586.
- [177] CZIMMERMANN T, CIUTI G, MILAZZO M, et al. Visual-Based Defect Detection and Classification Approaches for Industrial Applications-A SURVEY [J]. Sensors (Basel), 2020, 20(5): 1459.
- [178] WANG H, LI Z, WANG H. Few-shot steel surface defect detection [J]. IEEE Transactions on Instrumentation and Measurement, 2021, 71: 1-12.
- [179] MA Z, LI Y, HUANG M, et al. A lightweight detector based on attention mechanism for aluminum strip surface defect detection [J]. Computers in Industry, 2022, 136: 103585.
- [180] ZHENG Z, WANG P, LIU W, et al. Distance-IoU Loss: Faster and Better Learning for Bounding Box Regression [J]. arXiv preprint arXiv:1911.08287, 2019.
- [181] RAVI S, LAROCHELLE H. Optimization as a model for few-shot learning [C]// proceedings of the 5th International conference on learning representations (ICLR 2017). Toulon, France, 2017
- [182] EHSANI K, MOTTAGHI R, FARHADI A. SeGAN: Segmenting and Generating the Invisible [C]// proceedings of the 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 6144-6153.
- [183] STEWART R, ANDRILUKA M, NG A Y. End-to-End People Detection in Crowded Scenes [C]// proceedings of the 2016 IEEE Conference on Computer

- Vision and Pattern Recognition (CVPR). Las Vegas, NV, USA: IEEE Computer Society, 2016: 2325-2333.
- [184] ZHANG S, WEN L, BIAN X, et al. Occlusion-Aware R-CNN: Detecting Pedestrians in a Crowd [C]// proceedings of the Computer Vision-ECCV 2018: 15th European Conference. Munich, Germany: Springer International Publishing, 2018: 657-674.
- [185] REZATOFIGHI H, TSOI N, GWAK J, et al. Generalized Intersection Over Union: A Metric and a Loss for Bounding Box Regression [C]// proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 658-666.
- [186] ZHANG J, WANG H, TIAN Y, et al. An accurate fuzzy measure-based detection method for various types of defects on strip steel surfaces [J]. Computers in Industry, 2020, 122: 103231.
- [187] WANG X, XIAO T, JIANG Y, et al. Repulsion Loss: Detecting Pedestrians in a Crowd [C]// proceedings of the 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Salt Lake City, UT, USA: IEEE, 2018: 7774-7783.
- [188] 李翔, 何淼, 罗海波. 一种面向遮挡行人检测的改进 YOLOv3 算法 [J]. 光学学报, 2022, 42(14): 160-169.
- [189] 阳珊, 王建, 胡莉, et al. 改进 RetinaNet 的遮挡目标检测算法研究 [J]. 计算机工程与应用, 2022, 58(11): 209-214.
- [190] LIU S, HUANG D, WANG Y. Adaptive NMS: Refining Pedestrian Detection in a Crowd [C]// proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach, CA, USA: IEEE, 2019: 6452-6461.
- [191] FAWZI A, FROSSARD P. Measuring the effect of nuisance variables on classifiers [C]// proceedings of the British Machine Vision Conference 2016 (BMVC). York, UK: BMVA Press, 2016
- [192] GAO T, PACKER B, KOLLER D. A segmentation-aware object detection model with occlusion handling [C]// proceedings of the CVPR 2011. Colorado Springs, CO, USA: IEEE Computer Society, 2011: 1361-1368.
- [193] DAI J, QI H, XIONG Y, et al. Deformable Convolutional Networks [C]// proceedings of the 2017 IEEE International Conference on Computer Vision (ICCV). Venice, Italy: IEEE, 2017: 764-773.
- [194] WANG A, SUN Y, KORTYLEWSKI A, et al. Robust Object Detection Under Occlusion With Context-Aware CompositionalNets [C]// proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 12642-12651.

- [195] KORTYLEWSKI A, LIU Q, WANG H, et al. Combining Compositional Models and Deep Networks For Robust Object Classification under Occlusion [C]// proceedings of the 2020 IEEE Winter Conference on Applications of Computer Vision (WACV). 2020: 1322-1330.
- [196] XIAO M, KORTYLEWSKI A, WU R, et al. Tdapnet: Prototype network with recurrent top-down attention for robust object classification under partial occlusion [J]. arXiv preprint arXiv:1909.03879, 2019.
- [197] SHAO X, WANG Q, YANG W, et al. Multi-scale feature pyramid network: A heavily occluded pedestrian detection network based on ResNet [J]. Sensors, 2021, 21(5): 1820.
- [198] TAN M, PANG R, LE Q V. EfficientDet: Scalable and Efficient Object Detection [C]// proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2020: 10778-10787.
- [199] LIU S, HUANG D, WANG Y. Receptive Field Block Net for Accurate and Fast Object Detection [C]// proceedings of the Computer Vision-ECCV 2018: 15th European Conference. Munich, Germany: Springer International Publishing, 2018: 404-419.
- [200] BODLA N, SINGH B, CHELLAPPA R, et al. Soft-NMS — Improving Object Detection with One Line of Code [C]// proceedings of the 2017 IEEE International Conference on Computer Vision (ICCV). Venice, Italy: IEEE, 2017: 5562-5570.
- [201] LI Y, LIU J, WANG L. Lightweight Network Research Based on Deep Learning: A Review [C]// proceedings of 2018 37th Chinese Control Conference (CCC). Wuhan, China: IEEE, 2018: 9021-9026.
- [202] SONG H, MAO H, DALLY W J. Deep Compression: Compressing Deep Neural Networks with Pruning, Trained Quantization and Huffman Coding [J]. arXiv preprint arXiv:1510.00149, 2015.
- [203] WEN W, WU C, WANG Y, et al. Learning structured sparsity in deep neural networks [C]// proceedings of the 30th International Conference on Neural Information Processing Systems. Barcelona, Spain: Curran Associates Inc., 2016: 2082–2090.
- [204] MATHEW M, DESAPPAN K, SWAMI P K, et al. Sparse, Quantized, Full Frame CNN for Low Power Embedded Devices [C]// proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). Honolulu, HI, USA: IEEE, 2017: 328-336.
- [205] HINTON G, VINYALS O, DEAN J. Distilling the Knowledge in a Neural Network [J]. Computer Science, 2015, 14(7): 38-39.

- [206] KIM Y-D, PARK E, YOO S, et al. Compression of Deep Convolutional Neural Networks for Fast and Low Power Mobile Applications [J]. CoRR, 2015, abs/1511.06530.
- [207] WU D, LV S, JIANG M, et al. Using channel pruning-based YOLO v4 deep learning algorithm for the real-time and accurate detection of apple flowers in natural environments [J]. Computers and Electronics in Agriculture, 2020, 178: 105742.
- [208] CHANG F, DONG M, LIU M, et al. A lightweight appearance quality assessment system based on parallel deep learning for painted car body [J]. IEEE Transactions on Instrumentation and Measurement, 2020, 69(8): 5298-5307.
- [209] LIU H, HE B, HE Y, et al. Lightweight detection algorithm for fine-grained surface defects of aerospace seal rings [J]. Journal of Intelligent and Fuzzy Systems, 2021, 40(6): 11423-11440.
- [210] LIU R, SUN Z, WANG A, et al. Real-time defect detection network for polarizer based on deep learning [J]. Journal of Intelligent Manufacturing, 2020, 31(8): 1813-1823.
- [211] FU G, SUN P, ZHU W, et al. A deep-learning-based approach for fast and robust steel surface defects classification [J]. Optics and Lasers in Engineering, 2019, 121: 397-405.
- [212] IANDOLA F N, MOSKEWICZ M W, ASHRAF K, et al. SqueezeNet: AlexNet-level accuracy with 50x fewer parameters and <1MB model size [J]. arXiv preprint arXiv:1602.07360, 2016.
- [213] ANDREW, ZHU M, CHEN B, et al. MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications [J]. arXiv preprint arXiv:1704.04861, 2017.
- [214] SANDLER M, HOWARD A, ZHU M, et al. MobileNetV2: Inverted Residuals and Linear Bottlenecks [J]. arXiv preprint arXiv:1801.04381, 2019.
- [215] HOWARD A, SANDLER M, CHEN B, et al. Searching for MobileNetV3 [C]// proceedings of the 2019 IEEE/CVF International Conference on Computer Vision (ICCV). Seoul, Korea (South): IEEE, 2019: 1314-1324.
- [216] ZHANG X, ZHOU X, LIN M, et al. ShuffleNet: An Extremely Efficient Convolutional Neural Network for Mobile Devices [C]// proceedings of the 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Salt Lake City, UT, USA: IEEE, 2018: 6848-6856.
- [217] MA N, ZHANG X, ZHENG H T, et al. ShuffleNet V2: Practical Guidelines for Efficient CNN Architecture Design [C]// proceedings of the Computer Vision-ECCV 2018: 15th European Conference. Munich, Germany: Springer International Publishing, 2018: 122-138.

- [218] HAN K, WANG Y, TIAN Q, et al. GhostNet: More features from cheap operations [C]// proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2020: 1577-1586.
- [219] HU J, SHEN L, SUN G. Squeeze-and-Excitation Networks [C]// proceedings of the 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Salt Lake City, UT, USA: IEEE, 2018: 7132-7141.
- [220] WOO S, PARK J, LEE J-Y, et al. CBAM: Convolutional Block Attention Module [C]// proceedings of the Computer Vision-ECCV 2018: 15th European Conference. Munich, Germany: Springer International Publishing, 2018: 3-19.
- [221] SHI W, CABALLERO J, HUSZÁR F, et al. Real-Time Single Image and Video Super-Resolution Using an Efficient Sub-Pixel Convolutional Neural Network [C]// proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas, NV, USA: IEEE Computer Society, 2016: 1874-1883.
- [222] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal Loss for Dense Object Detection [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 42(2): 318-327.
- [223] WANG Q, WU B, ZHU P, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks [C]// proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2020: 11534-11542.
- [224] SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization [J]. International Journal of Computer Vision, 2020, 128(2): 336-359.
- [225] GHORAI S, MUKHERJEE A, GANGADARAN M, et al. Automatic defect detection on hot-rolled flat steel products [J]. IEEE Transactions on Instrumentation and Measurement, 2012, 62(3): 612-621.
- [226] SONG K-C, HU S-P, YAN Y-H, et al. Surface defect detection method using saliency linear scanning morphology for silicon steel strip under oil pollution interference [J]. ISIJ International, 2014, 54(11): 2598-2607.
- [227] JEON Y-J, CHOI D-C, LEE S J, et al. Steel-surface defect detection using a switching-lighting scheme [J]. Applied Optics, 2016, 55(1): 47-57.