

分类号: TP391

学校代码: 10363

密 级: 公开

学 号: 2200120129



安徽工程大学

Anhui Polytechnic University

硕士学位论文

题 目 轴承特征尺寸与表面缺陷
视觉检测方法研究

论 文 作 者 杜欣
校 内 导 师 江本赤 副教授 吴路路 讲师
校 外 导 师 宗旻 工程师
专业学位类别 机械
研究方向 (领域) 机器视觉

论文提交日期: 2023 年 4 月 16 日

分类号：TP391

单位代码：10363

密 级：公开

学 号：2200120129

轴承特征尺寸与表面缺陷视觉检测方法研究
**Research on Visual Inspection Method for Bearing
Feature Size and Surface Defects**

学生姓名：_____杜 欣_____

指导教师：江本赤（副教授）

吴路路（讲师）

校外导师：宗旻（工程师）

专 业：_____机 械_____

研究方向：_____机器视觉_____

论文答辩日期：2023 年 5 月 19 日

轴承特征尺寸与表面缺陷视觉检测方法研究

摘 要

轴承是机械装备领域广泛使用的核心基础件，其质量对机械装备的性能及寿命有重要的影响。然而轴承在制造过程中会出现各种缺陷，需要对其质量进行检测。目前，对于轴承的特征尺寸与表面缺陷检测主要由人工抽样完成，存在效率低、检测不全面且易受主观因素影响等缺点。基于机器视觉的检测技术具备高效、非接触、智能化等优点，目前已经广泛应用于工业制造领域。本文为实现轴承尺寸测量与表面缺陷检测，研究了基于视觉的检测方法，探索了实现轴承特征尺寸高精度测量与表面缺陷高效识别的过程。主要研究内容如下：

首先，搭建了视觉检测系统。在分析被检测轴承零件特点的基础上，针对尺寸测量和缺陷检测的需求，设计并搭建了视觉测量系统装置。

其次，研究了实现轴承外圈尺寸检测的方法。针对常用棋盘格标定法中角点检测精度不高的问题，提出了一种局部区域线性拟合求交的角点检测新方法，提升相机标定精度；并采用基于单应性矩阵的坐标转化方法，克服了常用的比例系数法存在的可靠性差、精度低等问题；此外，通过改进基于局部面积效应的亚像素边缘检测方法，进一步提高了尺寸检测的精度。

然后，设计了基于视觉的轴承内外圈圆度误差检测算法。利用视觉装置获取的轮廓数据，依据圆度误差判定模型，构建非线性目标函

数，在此基础上，改进蜂群算法用以求解非线性目标函数，实现圆度误差检测，提升圆度误差计算精度和效率。

最后，探索了基于常规分类方法与深度学习方法实现轴承表面缺陷识别的过程。构建了表面缺陷数据集，分别训练了传统机器学习和深度学习缺陷检测模型。通过图像纹理加灰度统计特征构建缺陷图像的特征向量，使用 SVM 分类器对缺陷类型进行分类；使用 YOLOv5 深度学习模型对表面缺陷进行检测。

实验结果表明，本文所提角点检测算法定位角点的重投影误差为 0.028pixel，优于 OpenCV 的 0.117pixel 和 MATLAB 工具箱的 0.203pixel，检测精度更高；对现有轴承直径尺寸进行测量，检测精度可达 0.5pixel 以内；对于轮廓数据的圆度误差计算，改进人工蜂群算法的求解精度高于最小二乘法。通过增加灰度统计组成特征向量，能够有效实现表面缺陷分类与检测，缺陷分类的准确率为 96.11%，使用 YOLO 进行缺陷检测的 mAP 为 0.837。

关键词：机器视觉，角点检测，轴承尺寸测量，改进蜂群算法，表面缺陷检测

RESEARCH ON VISUAL INSPECTION METHOD FOR BEARING FEATURE SIZE AND SURFACE DEFECTS

ABSTRACT

Bearings are widely used core basic components in the field of mechanical equipment, and their quality has a significant impact on the performance and lifespan of mechanical equipment. However, various defects may occur during the manufacturing process of bearings, and their quality needs to be tested. At present, the detection of characteristic dimensions and surface defects of bearings is mainly completed by manual sampling, which has disadvantages such as low efficiency, incomplete detection, and susceptibility to subjective factors. Machine vision based detection technology has the advantages of high efficiency, non-contact, and intelligence, and has been widely applied in the field of industrial manufacturing. This article focuses on the issue of bearing size measurement and surface defect detection, and studies a vision based detection method to explore the process of achieving high-precision measurement of bearing feature size and efficient recognition of surface defects. The main research content is as follows:

Firstly, a visual inspection system was established. Based on the analysis of the characteristics of the tested bearing parts, a visual

measurement system device was designed and built to meet the requirements of size measurement and defect detection.

Secondly, a method for detecting the size of the bearing outer ring was studied. Aiming at the problem of low corner detection accuracy in commonly used checkerboard calibration methods, a new corner detection method based on local area linear fitting intersection is proposed to improve camera calibration accuracy; And the coordinate transformation method based on homography matrix is adopted to overcome the problems of poor reliability and low accuracy of commonly used proportional coefficient methods; In addition, by improving the subpixel edge detection method based on local area effect, the accuracy of size detection has been further improved.

Then, a vision based algorithm for detecting the roundness error of the inner and outer rings of bearings was designed. Based on the contour data obtained by visual devices and the roundness error judgment model, a nonlinear objective function is constructed. On this basis, an improved bee colony algorithm is used to solve the nonlinear objective function, achieve roundness error detection, and improve the accuracy and efficiency of roundness error calculation.

Finally, the process of identifying bearing surface defects based on conventional classification methods and deep learning methods was explored. We constructed a surface defect dataset and trained traditional

machine learning and deep learning defect detection models, respectively. Construct feature vectors for defect images using image texture and grayscale statistical features, and use SVM classifiers to classify defect types; Use YOLOv5 deep learning model to detect surface defects.

The experimental results show that the re projection error of the corner detection algorithm proposed in this paper is 0.028 pixels, which is better than 0.117 pixels of OpenCV and 0.203 pixels of MATLAB toolbox, and has higher detection accuracy; Measure the diameter size of existing bearings with a detection accuracy of within 0.5 pixel; For the calculation of roundness error in contour data, the improved artificial bee colony algorithm has a higher solving accuracy than the least squares method. By adding grayscale statistics to form feature vectors, surface defect classification and detection can be effectively achieved. The accuracy of defect classification is 96.11%, and the mAP for defect detection using YOLO is 0.837.

KEY WORDS: machine vision, corner detection, measurement of bearing dimensions, improve bee colony algorithm, surface defect detection

目 录

第 1 章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 视觉检测技术研究现状.....	2
1.2.2 轴承缺陷视觉检测技术研究现状.....	7
1.3 本文研究内容.....	8
1.4 论文章节安排.....	9
第 2 章 视觉检测装置系统搭建	11
2.1 轴承结构与特征分析.....	11
2.2 视觉检测系统整体方案设计	12
2.2.1 光源选型	12
2.2.2 系统结构设计.....	12
2.2.3 相机与镜头.....	14
2.3 相机标定.....	14
2.3.1 相机成像模型.....	14
2.3.2 参数标定	16
2.4 基于局部区域线性拟合的棋盘格角点检测	17
2.4.1 角点粗定位.....	17
2.4.2 角点邻域边缘检测与分类.....	18
2.4.3 基于线性拟合求交点的精确定位.....	20
2.5 角点检测性能验证.....	22
2.5.1 精度对比实验.....	22
2.5.2 光源亮度鲁棒性验证.....	23
2.6 本章小结.....	25
第 3 章 轴承外径尺寸视觉测量	27
3.1 相机外参单应性矩阵标定	27
3.1.1 成像平面确定.....	27
3.1.2 单应性矩阵.....	28
3.2 亚像素边缘检测.....	29
3.2.1 光源亮度确定.....	29
3.2.2 像素边缘检测.....	30
3.2.3 亚像素边缘检测.....	31
3.3 单应性矩阵变换与改进亚像素边缘检测	33
3.4 外圈直径视觉测量实验验证	33

3.4.1 光源亮度调整.....	34
3.4.2 单应性矩阵外参描述.....	35
3.4.3 改进亚像素边缘检测.....	36
3.5 本章小结.....	37
第 4 章 基于视觉的轴承外圈圆度计算	39
4.1 目标函数构建.....	39
4.2 改进人工蜂群圆度误差视觉评定	39
4.2.1 人工蜂群算法.....	39
4.2.2 改进人工蜂群算法圆度误差视觉评定	40
4.3 圆度误差检测实验.....	43
4.3.1 实验验证.....	43
4.3.2 同类算法对比分析.....	43
4.4 本章小结.....	45
第 5 章 轴承表面缺陷检测	46
5.1 基于传统机器学习的表面缺陷分类	46
5.1.1 特征提取.....	46
5.1.2 SVM 分类.....	48
5.2 基于深度学习的表面缺陷检测	49
5.2.1 深度学习模型.....	49
5.2.2 YOLOv5.....	49
5.2.3 缺陷检测.....	52
5.3 缺陷分类与检测实验验证	53
5.3.1 传统方法缺陷检测.....	53
5.3.2 YOLOv5 缺陷检测.....	54
5.3.3 轴承表面缺陷检测.....	56
5.4 本章小结.....	58
第 6 章 总结与展望	59
6.1 总结.....	59
6.2 展望.....	60
参考文献.....	61

第1章 绪 论

1.1 研究背景与意义

轴承是一种用于支撑旋转零件（如转轴、芯轴等），并保持旋转零件旋转精度和减少旋转零件与支撑之间摩擦和磨损的装置，如图 1-1 所示，作为一种常用的重要基础零部件，广泛应用于各类机械装备中^[1-2]。轴承质量对于机械装备正常高效的运转，具有重要的影响作用。



图 1-1 轴承部件

为提升轴承加工质量，延长其使用寿命，在轴承的生产制造过程中需要对其进行质量检测。轴承检测主要包含三部分内容^[3]：（1）零件检验：对轴承的组成零件内圈、外圈、钢球等尺寸和表面质量检验；（2）装配检验：对轴承各个零件的完整性和表面及振动情况进行检测；（3）成品检验：针对装配过程造成的表面缺陷进行全面检测。当前，对于轴承的尺寸测量与表面缺陷检测主要采用人工抽查的方式，由技术人员定时选择一定数量的样本进行检测，难以覆盖到每件产品，同时人工检测存在着以下问题^[4]：

- （1）依靠人力的检测方法检测效率低、易于产生人为误差；
- （2）缺陷检测依靠人工肉眼进行，容易引起视觉疲劳而漏检；
- （3）人力成本增加，人工检测会增加产品的成本。

对此,为实现轴承生产的自动化与智能化,需研究并解决轴承特征尺寸测量与表面缺陷检测的方法。



图 1-2 视觉检测工程应用

机器视觉是一种利用相机获取图像或视频数据,通过计算机进行图像处理与数据分析提取物体信息,进而实现物体定位、检测与测量的技术,如图 1-2 所示。机器视觉技术萌芽于上世纪 50 年代,上世纪 80 年代得到广泛研究与应用并引入我国,上世纪 90 年代在我国开始得到重视和发展^[5]。机器视觉在工业上的应用主要包括两个方面:机器人运动控制与视觉检测,其中机器人运动控制包含目标的识别、定位与跟踪,视觉检测包含目标的表面质量检测与尺寸测量^[6-8]。其中,视觉检测已经成为产品质检的主要方法,是取代人工最多的环节。基于机器视觉技术的零件质量检测具有无接触、无损伤、可实现自动化、智能化、实时性好的特点^[9]。在检测过程中不需要人员参与,不需要接触零件,而且可以直接配置在工业生产线上,实现零件质量流水线检测。因此,通过机器视觉技术,实现对轴承尺寸测量与表面缺陷检测,具有重要的现实意义与价值。

1.2 国内外研究现状

1.2.1 视觉检测技术研究现状

按照相机个数与是否具有辅助光源,视觉检测可以分为单目、双目和结构光检测,其中双目与结构光检测主要用于三维尺寸测量与空间定位,如机器人环境感知与焊缝检测,而单目检测通常应用于工业生产的零件检测。

基于机器视觉的零件尺寸测量首先对检测装置进行标定,获得相机成像模型

的基本参数,然后对获取的零件图像采用边缘检测获取零件的轮廓数据,通过曲线拟合的方式计算得到零件的像素尺寸,最后根据标定结果通过尺寸坐标转换,将像素尺寸转换为实际尺寸。基于机器视觉的零件缺陷检测则需要提取图像的特征,组成特征向量,通过对特征向量进行分类实现缺陷的检测与定位。

为提高尺寸测量的精度与缺陷检测的准确度,大量研究者对相机标定过程中的角点检测、尺寸坐标转化与零件边缘检测、零件轮廓数据处理和零件表面缺陷检测方面进行了研究,取得了众多成果。

(1) 相机标定及棋盘格角点检测

相机标定作为视觉测量中的重要步骤之一,其标定精度对视觉测量精度有着决定性影响。由于棋盘格结构简单、标定鲁棒性好,被广泛应用于工业相机标定^[10]。棋盘格角点位置,是建立世界坐标系与图像坐标系间映射关系的基础依据,因此,如何精确获取棋盘格角点坐标是实现高精度相机标定的关键^[11]。

棋盘格的角点检测主要有两大类算法,第一类主要根据棋盘格角点所在区域的灰度特征实现角点定位。文献[12]通过研究角点图像形状和灰度分布对称性等特征,提出一种基于 SUSAN 算子的棋盘格亚像素角点检测算法,所得定位误差值达 0.1pixel; Bok Y^[13]等根据角点所在圆形区域内的灰度变化规律,研究了在 Harris 角点检测算法基础上迭代细化求取角点的方法; Yan Y^[14]等根据角点所在矩形区域灰度值的对称性,提出一种先粗定位角点再利用自相关性精确定位的角点检测算法,获得了较高的准确度; Bennett S^[15]提出一种 ChESS 棋盘角点特征检测器,根据区域灰度值的 SR、DR 和 MR 综合响应结果求取角点; Placht S^[16]等针对棋盘格的极端姿态提出了一种基于鞍点的亚像素角点检测方法; 王刚^[17]等研究了通过模板匹配初定角点,再基于梯度峰值筛选角点的方法; 骆荣坤^[18]等通过角点的四邻域中心几何特征及其对角方向上的最大灰度值,结合 SINC 函数实现了亚像素精度的角点检测。第二类是基于棋盘格轮廓信息的角点检测算法,研究者主要通过棋盘格轮廓的曲率等特征进行角点定位。Chen S^[19]等提出了根据轮廓曲线上点的 KD 曲率进行角点检测并通过角强度提高检测精度的方法,具有准确度高灵活性好的特点; Duda A^[20]等研究了一种基于大盒滤波器的局部 Randon 变换棋盘格角点检测,对低对比度和图像噪声具有较优的鲁棒性; 陈圣

峰^[21]等提出了一种基于边缘方向投影的棋盘格角点亚像素细化方法；Wang Z^[22]等根据棋盘格角点为直线交点的特点，使用霍夫直线检测求取棋盘格轮廓，根据直线交点求取棋盘格角点；Meng C^[23]等依据矩形块边缘的灰度值变化求取角点所在直线的四个极限点，根据直线交点定位角点。

综上，现有文献大多通过灰度信息来提取角点，即直接通过棋盘格角点的灰度特征进行角点检测，或在常规角点检测方法进行粗定位的基础上再根据棋盘格特征进行角点筛选，计算量较大。基于轮廓的角点检测方法较少，容易受噪声点和相机畸变所致直线弯曲的影响，导致精度较低。

(2) 尺寸坐标转换与零件边缘检测

在单目视觉尺寸测量系统中，零件信息由目标图像的轮廓边缘点表示，边缘检测的性能是实现高精度测量的关键性因素^[24]。同时，相机外参作为测量系统的重要参数，对测量精度有着重要影响，需要精确标定与描述^[25]，实现像素尺寸转换为实际尺寸。因此，获取准确的待测零件的轮廓边缘点，高精度的相机外参标定与描述是单目视觉测量的重要组成部分。

在相机外参标定与描述方面，宋超群^[26]等研究了一种基于改进 FAST 和 BRIEF 的双目视觉测量方法，通过 FAST 和 BRIEF 进行特征点匹配，基于双目视觉将特征点映射至世界坐标系，根据世界坐标系中的特征点进行尺寸检测。Dang A^[27]等提出一种利用图像处理技术测量大型环形物体尺寸的方法，采用对比法，通过背景已知标志点与零件之间的位置关系，确定零件尺寸。唐正宗^[28]等研究了一种基于摄影测量校正的斜光轴数字图像相关方法，在测量平面上粘贴控制点，利用已知的控制点拟合得到控制面，通过图像点的投影射线与控制面相交得到三维坐标点，进行变形测量。

对于零件轮廓边缘检测，Xie X^[29]等提出一种两步法亚像素边缘检测方法，使用 8 邻域 Roberts 算子进行边缘粗定位，然后通过 Otsu 实现 Zernike 自适应阈值精定位，以 Cognex's 检测结果为标准，验证了该方法优于传统 Zernike。Gadelmawla E S^[30]研究了一种外螺纹测量和检测的视觉算法，测量精度为 0.9~1.1pixel。Peng G^[31]等提出了一种 O 形环测量和检测视觉算法，通过三次样条拟合函数计算亚像素坐标，测量精度为 1.5~0.5pixel。Xiao G^[32]等研究了一种

旋转工件在线尺寸测量方法,通过将边缘轮廓进行精细划分,用以提高检测精度,测量精度为 0.04mm。宋薇^[33]等提出一种基于视觉的环形密封件在线检测方法,使用边缘进行最小二乘拟合,圆形圈的测量精度为 0.1mm。江涛^[34]等提出一种基于轮廓角点的螺纹关键参数视觉测量方法,通过双边滤波联合迭代阈值法改进 Canny 算子,求取精确轮廓,实验表明该方法求解精度更高。

由此可得,对于视觉尺寸测量,现有相机外参大多采用像素当量及比例法的方式进行描述,通过已知尺寸的标定物进行标定计算。然而,像素当量的求解过程就是一次尺寸测量的过程,会引入各种误差,导致相机标定精度较低,导致求解结果误差较大。而对于亚像素边缘检测,现有方法并没有充分考虑零件的几何特性,求解方式较为复杂,整体尺寸测量精度在 1.0pixel 左右。

(3) 圆度误差测量技术研究现状

轴孔类零件具有广泛的应用,圆度误差是其尺寸测量的重要组成部分。圆度误差的评定算法有四种,分别是最小二乘法、最小外接圆法、最大内接圆法和最小区域法^[35]。其中符合圆度误差定义的是最小区域法,然而最小区域法属于无约束非线性优化问题,求解困难。为了进行圆度误差评定,学者们对最小区域法圆度误差求解进行了大量研究,实现对最小区域法的非线性优化求解。

圆度误差计算方法主要可以划分为三种,第一种为区域搜索算法^[36],根据最小区域法的定义寻找圆心。张春阳^[37]等提出一种基于几何优化的圆度误差评定算法,通过搜索圆形来确定圆度误差。Huang Q^[38]等研究了一种渐进搜索方法来得到最小带圆模型的同心中心坐标,并计算圆度误差的方法。Singh D^[39]等研究了一种基于之字型迭代的圆度误差评估方法,具有较高的计算效率。第二种为基于约束的区域搜索,通过对数据点进行筛选,减少计算量。文献[40]研究了一种基于力学思想的最小外接圆度误差评定方法,求解结果正确。张学昌^[41]等提出一种基于误差转换及图像域的圆度评定方法,将误差模型线性化,并通过遗传算法求解。吴伟仁^[42]等提出一种基于计算几何的圆度误差评定算法,利用计算机的凸包理论,将轮廓数据点分为内接圆与外切圆点集,用较少的数据点进行后续拟合计算,极大提高了计算效率。岳武陵^[43]等提出一种按最小外接圆法和最小区域法和最小区域法评定圆度误差的仿增量算法,耗时较少。宋慈^[44]等按照

多边形去除法则优化了最小外接圆和最大内接圆的控制点求解过程,提出了改进了最小区域圆法圆度误差评定。岳龙龙^[45]等研究了一种利用区域搜索算法准确定位圆心,再根据准圆心位置和几何结构计算圆度误差的方法。第三种为智能优化算法,基于评价模型确定目标函数,使用群智能算法进行优化求解。张珂^[46]等根据最小二乘法建立圆度误差模型,基于 BP 神经网络算法优化目标函数参数,对于圆度误差评定的非线性优化问题得到了最优解。叶明^[47]等提出了一种改进人工鱼群与几何混合优化算法求解圆度误差评定方法,具有较好的收敛速度和稳定性。

然而,基于区域搜索的圆度误差评定适用于少量轮廓数据点,基于视觉获取的零件轮廓数据点较多,计算量较大。同时粒子群等优化算法需要人为设定大量参数,参数的设定对于求解结果具有重要的影响作用。

(4) 零件表面缺陷检测

按照特征提取方式的不同,现有的缺陷检测主要分为两类,一种是人工设计特征的机器学习方法,另一种是自动学习特征的深度学习方法。

机器学习方法需要人为根据问题与经验设计提取特征的模型,针对问题,选择不同的图像处理流程,获得不同的参数组成的可解释特征向量。张尧^[48]等提取钢带表面缺陷图像的灰度特征、纹理特征、投影特征、变换域特征、几何形状特征,通过并行多分类器进行缺陷识别,具有较好的准确度。Ghorai S^[49]等,提取热轧扁钢图像的三级 Haar 小波特征集,使用 SVM 进行缺陷分类,取得了较好的结果。张鹏^[50]提出一种针对激光增材制造中的铺粉表面缺陷检测,通过阈值分割,将图像中的可能缺陷分离开来,然后提取缺陷的形状、灰度等特征组成特征向量,使用决策树进行分类,平均识别率达到 96%。师彬彬^[51]等提出一种基于图像特征融合的增材制造过程粉末床缺陷检测方法,使用 SIFT 方法、灰度共生矩阵和 Hu 不变矩阵提取图像特征组成特征向量,对特征向量进行数据融合与特征降维,使用随机森林分类器进行训练与分类,算法平均准确率达到 97.46%。

而深度学习方法只需要将图片输入统一的特征提取模型,卷积神经网络,就可以通过学习自动获得不可解释的特征向量,然后通过分类实现缺陷检测。李天华^[52]等提出一种基于 YOLO v4+HSV 的自然环境下成熟番茄识别方法,在 YOLO

v4 网络的检测框内增加 HSV 处理,对番茄的红色区域进行分割,提高了番茄识别的准确率。蒲良^[53]等提出一种基于深度学习的无人机视觉目标检测与跟踪算法,使用卡尔曼滤波对 YOLOv3 网络的检测框进行调整,有效提高了目标检测的精度。彭道刚^[54]等研究了一种基于改进 YOLOv5 的电厂管道油液泄露检测方法,通过融入 CBAM 注意力机制模块,双向特征金字塔网络和 Focal EIoU Loss 损失函数进行优化,加快收敛速度,提高魔性的回归精度和鲁棒性。张志远^[55]等研究了一种基于改进 YOLOv5 的自然环境下樱桃果实识别方法,在骨干网络上增添具有注意力机制的 Transformer 模块,颈部端由原来的 PAFPN 改成可以进行双向加权融合的 BiFPN,预测端增加了浅层下采样的 P2 模块,提高了检测精度。

1.2.2 轴承缺陷视觉检测技术研究现状

轴承的缺陷可以分为尺寸缺陷与表面缺陷,轴承缺陷视觉检测即是通过机器视觉技术,实现对轴承尺寸的测量与表面缺陷的检测。文献[56-57]研究了一种基于机器视觉的轴承尺寸测量技术,采用坐标排序亚像素边缘检测法获取轴承内外圈轮廓,通过像素当量将零件像素尺寸转换为实际尺寸,实现对轴承的内外圈直径尺寸测量与分类。

Shen H^[3]等针对轴承盖表面存在的变形、生锈、划痕等缺陷,设计了一种新的图像采集系统以增强缺陷外观,通过轴承盖表面共性和投影分布规律对缺陷进行缺陷检测,实验结果表明,该视觉系统具有较高的精度和效率。郝勇^[58]等研究了一种保持架缺陷检测方法,提取保持架区域的 Hu 矩和旋转不变均匀局部二值模式作为纹理特征,使用 SVM 模型分类。温振市^[59]针对轴承侧面与防尘盖的表面质量,研究与开发了基于机器视觉技术的实时检测系统。使用自适应阈值法分割缺陷,通过分割区域大小和模板匹配进行缺陷检测。陈文达^[60]对轴承防尘盖表面缺陷的自动监测,将防尘盖字符、非字符区域分开检测,方法克服轴承防尘盖表面缺陷分割字符干扰的影响,实验结果表明该检测算法的正确率在 96% 以上。郑越^[61]结合轴承生产企业规定的质检标准,设计与实现了一套轴承内圈缺陷视觉检测装置,采用局部阈值的方法分割缺陷,基于分割区域的大小对缺陷进行分类。吴景^[62]使用线阵相机对滚子柱面扫描成像,使用面阵相机对滚子端

面拍照采图,通过自适应阈值进行缺陷分割,基于缺陷区域的 Hu 不变矩特征进行分类,实现了对轴承滚子的缺陷检测。宇文旋^[63]针对轴承内外圈端面缺陷,采用机器视觉进行检测,提出了一种以小波变换为分类特征的局部多神经网络图像分割算法,提取多个图像特征,使用 BP 神经网络进行分类,缺陷识别率达 99.5%。吴英松^[64]针对轴承套圈缺陷检测,设计了基于阈值分割与形态学方法的图像预处理算法、基于改进 Steger 方法的裂纹缺陷提取算法和基于动态阈值方法的斑点缺陷和磕碰伤缺陷的提取算法,并搭建了一套机器视觉检测装置。文生平^[65]等针对滚子表面存在的缺陷,将传统机器视觉方法与深度学习相结合,并采用改进的 RetinaNet 模型,实现了轴承滚子的表面缺陷检测,准确率达到 96%。Liu B^[66]等针对轴承表面微小缺陷,设计了一种多角度照明的轴承缺陷视觉检测系统,通过拍摄多角度打光轴承图像进行处理,提高轴承表面的间隙、污渍、盖子缩小和刮痕缺陷检测检测精度和准确率。文献[67]采用深度学习,实现了轴承表面缺陷检测,使用合成数据集,检测准确率为 95.4%。刘良江^[68]等提出了一套基于机器视觉的轴承内外径检测方法,基于轮廓边缘进行分割,根据轮廓半径构建特征向量,通过支持向量机进行分类,将不合格产品进行剔除,实验结果表明针对尺寸误差分类的正确率为 97%。

1.3 本文研究内容

(1) 视觉检测系统总体方案设计

分析了轴承的结构特点,根据机器视觉检测原理,针对尺寸测量和缺陷检测的要求,设计并搭建了轴承尺寸测量与缺陷检测装置。

(2) 角点高精度检测与相机标定

介绍并分析了相机成像模型,使用棋盘格利用传统标定法对检测装置进行相机标定。在此基础之上,针对传统标定法中棋盘格角点检测精度不高的问题,研究了一种基于局部区域线性拟合的棋盘格角点检测方法,实现对角点的精确定位。

(3) 轴承外圈外径尺寸测量

分析了视觉尺寸测量的基本原理与步骤,获取零件边缘轮廓数据,进行曲线拟合得到像素尺寸,进一步通过坐标转换,将像素尺寸转换为实际尺寸。在此基

础之上,研究了一种基于局部面积效应的亚像素边缘检测方法,获取零件亚像素边缘轮廓,同时采用单应性矩阵进行坐标转换,实现像素尺寸向实际尺寸的转换,提升了轴承外圈外径的尺寸视觉测量精度。

(4) 基于视觉轮廓数据的圆度误差计算

通过视觉检测装置获取轴承轮廓数据,根据圆度误差判定准则,构建了目标函数,采用群智能算法求解非线性目标函数。根据圆度误差评定特性对人工蜂群算法进行改进,用以提升算法的检测效率。

(5) 表面缺陷检测

分析了基于传统机器学习与基于深度学习的视觉缺陷检测方法,使用表面缺陷数据分别训练了传统机器学习和深度学习算法。针对缺陷的分类问题,研究了一种基于灰度统计特征与图像纹理的图像分类方法。同时,研究了基于 YOLO 模型的目标检测方法,将其应用于缺陷检测之上,使用 YOLOv5 模型,实现了对缺陷的检测。

1.4 论文章节安排

本文主要围绕探索基于机器视觉的轴承特征尺寸与表面缺陷检测方法展开。为提高视觉尺寸测量的精度和视觉表面缺陷检测的速度和准确度提供了有效的解决方法。

本论文分六个部分进行写作,论文结构如图 1-3 所示,各章节主要内容如下:

第一章:绪论。介绍了本文选题的研究背景与意义,归纳总结了视觉检测的国内外研究现状,阐述了本课题的研究内容和论文的结构安排。

第二章:系统方案设计与相机标定。针对轴承的特征尺寸与表面缺陷特点,确定了检测装置的系统方案。分析了相机的成像模型,并对相机进行标定。在标定过程中,分析了棋盘格的结构特点,研究了一种基于邻域拟合的棋盘格角点检测方法,实验验证了该方法检测精度更高。

第三章:轴承外圈外径尺寸测量。使用机器视觉方法,实现对轴承外圈外径尺寸测量。分析了机器视觉尺寸测量方法,在此基础之上,研究了一种基于单应性矩阵与改进的基于面积效应的亚像素边缘检测方法,实验检测结果表明该方法

测量的精度更高。

第四章：轴承外圈外径圆度误差计算。在使用机器视觉对轴承进行尺寸测量的基础上，进行圆度误差计算，分析现有圆度误差评价准则，研究了人工蜂群算法，针对圆度误差的求解特点，对人工蜂群算法进行改进。

第五章：轴承表面缺陷检测。分析了表面缺陷检测方法，研究了一种基于灰度统计特征与灰度共生矩阵的缺陷图像分类方法，实现了对缺陷的分类。同时实现了基于深度学习模型 YOLOv5 的表面缺陷的检测。

第六章：总结与展望。对论文工作的总结，同时说明了研究的不足，指出了未来的研究方向。




图 1-3 主要章节结构图

第2章 视觉检测装置系统搭建

为实现轴承缺陷检测，本章在分析轴承组成与结构特征的基础上，选择适当的视觉成像方式，设计并搭建检测装置。推导了视觉成像模型，使用棋盘格对视觉测量装置进行标定，同时针对棋盘格角点的特点，提出一种新的角点检测方法，并实验验证该方法的准确性与精度。

2.1 轴承结构与特征分析

本文以滚动轴承为例，如图 2-1 所示，轴承主要由内外圈、滚动体和保持架组成，对于性能要求较高的轴承还要安装密封圈（防尘盖）来隔绝外部异物的影响。其特征尺寸主要包括内外圈直径、宽度，滚动体直径，表面主要包括内外圈端面，内侧面与外侧面，滚动体表面。几何形状主要包括圆形侧面与端面，形状较为规则。




图 2-1 轴承的典型结构

轴承主要通过轴承钢制成，不透光，同时零件表面会反光。因此，对于轴承的尺寸与表面缺陷首先需要选定光源，根据打光方式确定检测装置基本状况，进而根据检测精度确定相机零部件。基于视觉的检测是通过获取检测对象的图像，进而分析零件，具有一定的相似性，本文研究轴承外圈外径尺寸与端面缺陷，采用视觉检测的方式进行尺寸测量与缺陷检测研究。

2.2 视觉检测系统整体方案设计

根据轴承的结构特征与检测内容，设计视觉检测系统。视觉检测装置主要由相机、镜头、光源和夹持装置组成，图像的质量直接影响检测算法的准确性与精度。为获取高质量图像，需根据检测对象与检测内容对检测装置进行设计。

2.2.1 光源选型

根据待检测对象的尺寸、颜色、透光性和空间位置等具体情况，选择合适的光源与打光方式。基于 LED 的室内和室外照明产品的发光效率已经超过了白炽灯、卤素灯、荧光灯和高强度放电光源的发光效率^[69]，同时光源亮度一致性好，因此，本文选择 LED 光源。

按照光源的形状划分，主要使用的光源类型有条形光源、环形光源、平面光源和同轴光源，如图 2-2 所示。其中，条形光源主要应用于大型零件表面缺陷，环形光源主要应用零件表面缺陷，平面光源主要用于零件尺寸测量，同轴光源适用于高反光零件表面质量检测。




图 2-2 光源类型

2.2.2 系统结构设计

目前，机器视觉领域常用的照射方式主要包括前向照明、背光照明、侧向照明等。

(1) 前向照明：光源位于工业相机和待测工件之间的照射方式。按照光源与零件的距离可以分为高角度照射、低角度照射；按照光源类型的不同又可以分为垂直照射、多角度照射、半球积分照明、同轴管光照明等。该照明方式主要应用于表面缺陷的检测，对于不同材料与不同类型的缺陷，选择合适的光源类型。

(2) 背光照明：待测工件位于工业相机和光源之间的照射方式。用于突出显示不透明物体的外形轮廓，仅适用于待测目标需要的信息可以从轮廓中获得的场合。常使用平面光源，用于尺寸测量。

(3) 侧向照明：光源位于待测工件与光源侧面的照射方式。用于显示零件微小缺陷，或者透光性较好的工件，采用前向照明会导致零件微小缺陷难以显示出来。




图 2-3 视觉检测装置光源及其调节器

根据整体检测目标，选择环形光源对零件表面进行打光，选择平面光源对零件轮廓进行打光，通过电流调节器对光源进行亮度的调节，调节等级为 0~255 级，光源及调节器如图 2-3 所示。

针对轴承特征尺寸与表面缺陷检测的需求，使用环形光源通过前向照明的方式获取零件表面图像，用于缺陷检测；使用平面光源进行背光照明的方式获取零件背光图像，用于尺寸测量，搭建装置，如图 2-4 所示。




图 2-4 检测装置

2.2.3 相机与镜头

相机采用面阵相机，镜头采用定焦镜头，如图 2-5 所示。相机型号为 Basler acA4600-7gc，镜头焦距为 8mm，型号为 C125-0818-5M-P。



(a) 相机

(b) 镜头

图 2-5 相机与镜头

2.3 相机标定

2.3.1 相机成像模型

相机成像是将客观世界的三维场景投影到二维平面的过程，图像上像素点的位置与摄像机和空间物体的相对位置和摄像机的内部结构有关。视觉测量就是从相机获取的图像出发，通过图像处理与分析解算被测目标的尺寸信息，在根据相机成像模型将像素尺寸转换为实际尺寸，因此，相机成像模型是基于视觉进行测量的各种方法和算法的基础。

相机成像模型涉及到世界坐标系、相机坐标系、图像物理坐标系和像素坐标系，坐标系之间的变换关系如图 2-6 所示。




图 2-6 相机成像模型坐标转换

小孔成像模型因为最接近透镜成像几何的本质，得到了广泛的使用。相机小孔成像模型如图 2-7 所示。




图 2-7 小孔成像模型

设物点 P 在世界坐标系下的坐标为 $P_w = (X_w, Y_w, Z_w, 1)^T$ ，在相机坐标系下的坐标为 $P_c = (X_c, Y_c, Z_c, 1)^T$ ，世界坐标系到相机坐标系的转换关系可以通过刚体变换，即坐标轴的旋转 R 和平移 t 进行转换，如下所示：

$$\begin{bmatrix} X_c \\ Y_c \\ Z_c \\ 1 \end{bmatrix} = \begin{bmatrix} R & t \\ 0_3^T & 1 \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} \quad (2-1)$$

设物点 P 在图像坐标系下的坐标为 $(x, y)^T$ ，根据小孔成像模型的定义，可以得出其在相机坐标系下的坐标为 $(x, y, f)^T$ ，根据三角形相似原理可以得出：

$$\begin{cases} x = f \frac{X_c}{Z_c} \\ y = f \frac{Y_c}{Z_c} \end{cases} \quad (2-2)$$

其中， f 为相机焦距。以齐次坐标形式表示，得到矩阵线性方程为：

$$Z_c \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} = \begin{bmatrix} f & 0 & 0 & 0 \\ 0 & f & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} X_c \\ Y_c \\ Z_c \\ 1 \end{bmatrix} \quad (2-3)$$

图像坐标系与像素坐标系之间的定义相差一定距离，设位于像素坐标系下的点的坐标为 $(u, v)^T$ ，则图像坐标系与像素坐标系之间的变化关系为：

$$\begin{cases} u = x + u_0 \\ v = y + v_0 \end{cases} \quad (2-4)$$

其中， u_0 ， v_0 为图像坐标系与像素坐标系之间的偏移距离。

综上可得，像素坐标与世界坐标之间的映射关系为：

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = s \begin{bmatrix} f_x & 0 & u_0 \\ 0 & f_y & v_0 \\ 0 & 0 & 1 \end{bmatrix} [R \quad t] \begin{bmatrix} X_w \\ Y_w \\ 1 \end{bmatrix} \quad (2-5)$$

其中， s 表示尺度因子。

2.3.2 参数标定

为实现对零件尺寸的测量，需要对相机成像模型进行标定，确定相机的内外参数。根据相机内参，对图像进行畸变矫正，加上相机外参，将像素尺寸转换为实际尺寸。

现有标定方法主要分为传统标定法与主动标定法，其中主动标定法由于需要精密运动部件，因此在视觉测量领域应用较少。而传统标定法使用已知几何参数的标志物，通过建立标志物与图像特征的几何关系，求取相机参数，求解方便且求解精度较高，因此应用广泛。传统标定法中的张正友标定法使用广泛，通常采用棋盘格作为标定物，如图 2-8 所示。通过检测其角点进行参数求解，角点检测的精度直接影响参数标定的精度，对此为提高角点检测精度，本文研究了一种基于局部区域线性拟合的棋盘格角点检测方法。




图 2-8 棋盘格标定板

2.4 基于局部区域线性拟合的棋盘格角点检测

为提高棋盘格角点检测的准确度和精度,本文探索一种基于邻域线性拟合的棋盘格角点检测方法。本方法主要分为三步,首先,根据深色方块的邻接性求出各个角点的初始位置,记为标记点;然后,根据标记点和标记点之间的距离关系确定角点所在的 ROI(感兴趣)区域,通过 Canny 边缘检测获取 ROI 区域内的棋盘格轮廓;最后,对轮廓点进行横、纵分类和线性拟合得到两条相交直线,直线交点即为所求棋盘格角点。

2.4.1 角点粗定位

(1) 棋盘格深色方块分割

通过检测装置获取的棋盘格图像为彩色,然而棋盘格呈现出黑白色,彩色图像并不能提供更多有用的信息,同时为提高图像处理的速度,使用公式(2-6)对原图进行加权灰度化。

$$G(x,y)=0.30\times R(x,y)+0.59\times G(x,y)+0.11\times B(x,y) \quad (2-6)$$

其中, G 为图像灰度值, R 为红色通道灰度值, G 为绿色通道灰度值, B 为蓝色通道灰度值, x 、 y 为像素点坐标。

通过背光照射的方式获取到棋盘格图像,图像黑白区域对比明显,采用大津法自适应阈值对图像进行分割。为避免深色方块互相粘连,获取单个的深色方块,采用形态学膨胀的方式,使得棋盘格单个黑色区域分隔开,处理结果如图 2-9 所示。




图 2-9 棋盘格深色区域分割

(2) 深色方块特征点定位

棋盘格深色方块分割之后,棋盘格上的单个深色方块都为独立的小矩形个体,

通过求取深色方块的最小外接矩形，定位棋盘格深色方块坐标。以棋盘格深色方块最小外接矩形的四个极限点作为特征点，将其作为初始角点。

(3) 角点筛选

根据棋盘格角点的定义，角点为相邻黑色区域相交的部分，而定位的特征点存在着冗余，需要筛选出符合角点定义的初始角点。设定初始角点之间的距离阈值为 D_C ，若两个初始角点之间的距离小于该距离阈值，则将这一对初始角点归为一组。这样可以实现对棋盘格最外围单个初始角点，并将相邻的初始角点进行归类。设 (P_{1x}, P_{1y}) 、 (P_{2x}, P_{2y}) 为一组角点的坐标，如公式 (2-7) 所示通过平均法将一组角点进行合并，得到单个角点 (P_x, P_y) 。

$$\begin{cases} P_x = \frac{1}{2}(P_{1x} + P_{2x}) \\ P_y = \frac{1}{2}(P_{1y} + P_{2y}) \end{cases} \quad (2-7)$$

筛选合并后的初始角点组成的参考点阵如图所示，为棋盘格角点粗定位的结果。




图 2-10 参考点阵

2.4.2 角点邻域边缘检测与分类

(1) 角点邻域 ROI 提取

对角点所在局部区域进行 ROI 提取，计算两两角点之间的距离，以其中最小值的一般作为半径，以参考点阵为中心，画出一个圆形区域，作为 ROI 区域，

提取结果如图 2-11（a）所示。




图 2-11 局部区域边缘检测

（2）ROI 区域边缘检测

首先对 ROI 图像进行高斯滤波，然后使用 Canny 边缘检测求取 ROI 区域的棋盘格轮廓，处理结果如图 2-11（b）所示。获取的角点粗定位结果与边缘轮廓之间的关系如图 2-12 所示。




图 2-12 角点粗定位与局部边缘轮廓

（3）边缘分类




图 2-13 轮廓分类

为对边缘点进行直线拟合求取交点，需要对边缘点进行分类，将边缘点分为横、纵数据点。对此，本文采取通过斜率对数据点进行分类的方法，如图 2-13 所示，求取轮廓与中心点之间的斜率，通过斜率对数据点进行分类，其中，“中心点”为粗定位角点。将角度值为 $[315^\circ; 45^\circ)$ 和 $[135^\circ; 225^\circ)$ 的数据点分为横类数据点，将角度值为 $[45^\circ; 135^\circ)$ 和 $[225^\circ; 315^\circ)$ 的数据点分为纵类数据点。

2.4.3 基于线性拟合求交点的精确定位

(1) 分类边缘线性拟合求交点

边缘点分类之后，需要对横、纵轮廓数据点进行线性拟合。设直线方程为 $y=kx+b$ ，对于线性拟合，要求观测值 y_i 的偏差加权平方和最小，如下所示：

$$f_{\min}(k, b) = \sum_{i=1}^N [y_i - (b + kx_i)]^2 \quad (2-8)$$

其中， k 为直线斜率， b 为直线截距， (x_i, y_i) 为轮廓数据点， N 为轮廓点序号。

上式分别对 k ， b 求偏导可得：

$$\begin{aligned} \frac{\partial}{\partial b} \sum_{i=1}^N [y_i - (b + kx_i)]^2 &= -2 \sum_{i=1}^N (y_i - b - kx_i) = 0 \\ \frac{\partial}{\partial k} \sum_{i=1}^N [y_i - (b + kx_i)]^2 &= -2 \sum_{i=1}^N [(y_i - b - kx_i)x_i] = 0 \end{aligned} \quad (2-9)$$

整理求解后可得直线参数的最佳估计值：

$$\begin{cases} \hat{b} = \frac{(\sum x_i^2)(\sum y_i) - (\sum x_i)(\sum x_i y_i)}{N(\sum x_i^2) - (\sum x_i)^2} \\ k = \frac{N(\sum x_i y_i) - (\sum x_i)(\sum y_i)}{N(\sum x_i^2) - (\sum x_i)^2} \end{cases} \quad (2-10)$$

对于横向数据点，可以直接使用以上公式进行直线拟合，但是对于纵向数据点，若数据点为“竖直”状态，则一个 x 坐标对应于多个 y 坐标，拟合结果有误。对此，本文对数据点进行转置，变换坐标点数据 x ， y 坐标轴关系带入以上公式求得参数 k ， b 。则拟合直线的方程如公式所示：

$$x = \frac{1}{k}y - \frac{b}{k} \quad (2-11)$$

设横、纵直线方程为：

$$\begin{cases} y_1 = k_1 x_1 + b_1 \\ y_2 = k_2 x_2 + b_2 \end{cases} \quad (2-12)$$

式中, y_1 、 x_1 为第一条直线的数据点, y_2 、 x_2 为第二条数据点; k_1 、 k_2 , b_1 、 b_2 分别为第一条直线与第二条直线的斜率与截距。

则求取的角点坐标为:

$$\begin{cases} x = \frac{b_2 - b_1}{k_1 - k_2} \\ y = k_1 \times \left(\frac{b_2 - b_1}{k_1 - k_2} \right) + b_1 \end{cases} \quad (2-13)$$

通过对边缘轮廓进行线性拟合, 求取交点如图 2-14 所示。

(2) 基于交点的全局角点定位

获取单个 ROI 区域的角点坐标之后, 根据 ROI 提取坐标, 将局部角点坐标变换为全局坐标, 完成对角点的检测。




图 2-14 直线拟合求交点

2.5 角点检测性能验证

为验证所提方法的精度与鲁棒性，分别进行精度与鲁棒性实验，与现有常用方法进行比较。

2.5.1 精度对比实验

为验证算法标定结果的准确性，采用本文方法、OpenCV 库函数方法、MATLAB 相机标定方法，对同一组数据进行相机标定。标定板角点个数为 8×11 ，角点之间的距离为 15mm。将标定板置于检测装置平面光源之上，调节光源强度参数至 125（0-250）时，此时人眼观察图像显示最清晰，调整光源位姿，拍摄 20 张标定图像。

三种算法主要步骤如下所述：

（1）本文方法：第一步，自定义亚像素角点获取；第二步，使用 Opencv 中的库函数 `calibrateCamera()` 进行相机标定；

（2）OpenCV 库函数：第一步，使用 Opencv 库函数 `findChessbordCorners()`、`find4QuadCornerSubpix()` 进行像素、亚像素角点提取；第二步，使用 Opencv 中的库函数 `calibrateCamera()` 进行相机标定；

（3）MATLAB 相机标定：使用 MATLAB 中的单目相机标定功能进行相机标定。

相机标定结果内参矩阵与畸变系数如表 2-1 所示。观察数据可知，本文所提与现有方法标定结果相近，标定结果正确。

表 2-1 相机标定内参与畸变系数对比

		本文方法	OpenCV	MATLAB
内参矩阵	f_x	6245.443924	6309.110115	6275.150352
	c_x	2300.355385	2300.854412	2302.108520
	f_y	6244.278682	6307.619136	6273.900904
	c_y	1666.266073	1658.613531	1668.789139
	k_1	-0.109217494	-0.106926129	-0.108833254
畸变系数	k_2	0.517974675	0.3101828010	0.4678780650
	p_1	-0.000516971	-0.000793840	-0.000515115
	p_2	-0.000558267	-0.000178968	-0.000584562
	k_3	-4.95177595	-2.671947947	-4.636106807

在相机标定中，通常采用重投影误差来判断相机标定精度。计算每张图像中对应角点的重投影误差，并求取平均值，对同组图像进行重投影误差计算，结果

如表 2-2 所示。

表 2-2 重投影误差

序号	本文	OpenCV	MATLAB	序号	本文	OpenCV	MATLAB
1	0.04003	0.18134	0.17280	11	0.01800	0.09986	0.22195
2	0.01848	0.08924	0.18236	12	0.01930	0.09372	0.17198
3	0.02785	0.09270	0.16274	13	0.02632	0.17520	0.18644
4	0.01989	0.10504	0.16625	14	0.02655	0.12332	0.19533
5	0.02097	0.10134	0.18217	15	0.02785	0.13749	0.24637
6	0.01803	0.12154	0.16133	16	0.03515	0.15302	0.29224
7	0.03605	0.11720	0.16743	17	0.03276	0.103758	0.27381
8	0.023096	0.11731	0.18733	18	0.03248	0.13714	0.26315
9	0.020216	0.08927	0.17192	19	0.03324	0.11241	0.28168
10	0.058107	0.11666	0.13795	20	0.02717	0.08294	0.24848

图 2-15 显示了每张图像的重投影平均误差，对于同一组用于相机标定的棋盘格图像，如表 2-3 所示，本文提取角点重投影平均误差为 0.0280812pixel，远小于通用 OpenCV 方法的 0.1175300pixel 和 MATLAB 工具箱的 0.2036910pixel。




图 2-15 重投影误差

表 2-3 平均重投影误差

	本文	OpenCV	MATLAB
平均值	0.0280812	0.1175300	0.2036910

2.5.2 光源亮度鲁棒性验证

在拍摄图像进行角点检测时，需要通过过人眼观察拍摄图像的清晰度，以此调整相关参数获得高质量图像。若图像光源强度过大、过小或相机曝光时间过长、过短，则会出现过曝光或欠曝光的情况，标定图像表现在棋盘格深色区域断裂或

者相连，如下图 2-16 所示。




图 2-16 光源对棋盘格图像的影响

为验证本文所提方法对光源强度的鲁棒性，固定平面光源的位姿，调节光源亮度调节器，分别获取平面光源强度为 100、105、110、115、120、125、130、135、140、145、150 级的标定图像。使用本文方法与 OpenCV 库函数方法对角点检测进行对比实验，角点检测个数如表 2-4 所示。由表中数据可知，对于光源强度较低的图像，OpenCV 将检测不出角点，本文方法优于 OpenCV 库函数方法。

表 2-4 角点检测个数

光源强度	100	105	110	115	120	125	130	135	140	145	150
OpenCV	出错	出错	88	88	88	88	88	88	88	88	88
本文	88	88	88	88	88	88	88	88	88	88	88

以光源强度为 125 拍摄的图像检测出的角点坐标为标准图像，对于标准图像计算本文方法与 OpenCV 库函数方法之间的误差，如图 2-17 (a) 所示，可以得出本文求得的角点坐标与 OpenCV 库函数求得角点坐标相差较小。




图 2-17 光源亮度变化误差

对比本文方法与 OpenCV 库函数方法，求取各个光源强度下获取检测的角点

与标准图像检测角点坐标的误差，求取平均值，如图 2-17 (b) 所示，可以得出本文方法检测角点的稳定性较强，对于光源强度的变化，误差变化较为平稳，优于 OpenCV 库函数方法。

对比光源强度为 110 和 150 与 125 时拍摄图像求取角点坐标之间的误差，本文方法求取结果如图 2-18 (a) (b) 所示，OpenCV 库函数方法求取结果如图 2-18 (c) (d) 所示。观察散点图可以得出，本文求取误差较小，在 1pixel 以内且更加集中，而 OpenCV 库函数求取误差在 4pixel 以内且更加分散。综上，可得本文角点检测方法对光源强度具有一定的鲁棒性，光源强度的变化对所求角点的坐标影响较小。




图 2-18 光源亮度变化角点误差

2.6 本章小结

针对轴承表面缺陷检测与尺寸测量的要求，根据零件的成像特点，设计了合

适的视觉检测装置。同时推导了相机成像模型,采用张正友标定法使用棋盘格对检测装置进行相机标定。针对相机标定中的棋盘格角点检测问题,本文提出了一种基于角点局部区域棋盘格边缘线性拟合的检测方法,该方法根据角点与棋盘格边缘轮廓的位置关系,通过边缘检测与线性拟合,实现了棋盘格角点高精度检测。对同一组棋盘格标定图像的角点检测实验表明,基于本文方法检测角点的标定结果与 OpenCV 库函数方法及 MATLAB 工具箱的标定结果基本一致,而重投影误差平均值为 0.0280812pixel,优于 OpenCV 的 0.1175300pixel 和 MATLAB 工具箱的 0.2036910pixel,性能优于现有方法。此外,本文所提方法在进行角点检测时,对光源亮度变化的稳定性优于 OpenCV 库函数方法,具有较好的鲁棒性。

第3章 轴承外径尺寸视觉测量

对于来自检测装置的轴承图像,采用图像处理技术提取轴承边缘轮廓,进而计算出轴承的像素尺寸;通过对相机的成像模型进行标定,将像素尺寸转换为实际尺寸。轴承的边缘轮廓提取精度与成像模型参数标定精度直接影响尺寸测量精度,为此,本章研究了一种实现轴承轮廓的亚像素边缘检测方法,并探讨一种实现轴承轮廓像素尺寸与实际尺寸的转换方法。同时,分析现有测量方式存在的误差,并对误差进行矫正,以提高视觉测量的精度。

3.1 相机外参单应性矩阵标定

现有方法大多采用像素当量(mm/pixel)对单目视觉成像模型进行描述,即通过实际尺寸与像素尺寸之间的比值,将像素特征尺寸映射成实际特征尺寸,通常采用标定板与标准尺寸的标定块进行像素当量的标定。然而,当待测零件具有一定的高度或者待测零件与标定块高度不一致的时候,由于标定平面与零件成像平面的不同,将会导致标定结果不准确,进而影响测量精度。对此,本文研究了一种通过单应性矩阵进行相机外参标定,使用局部面积效应进行亚像素边缘检测的轴承尺寸测量方法。根据单目相机尺寸测量的原理,采用统一的计算方式,使用单应性矩阵描述相机外参;根据待测零件的轮廓特征,使用改进的基于局部面积效应的亚像素边缘检测获取零件轮廓数据点。

3.1.1 成像平面确定

在针孔成像模型下,相机内参为相机固有属性,不会随着相机位置的变化而变化。而在固定位置下,相机外参实际反映了相机在空间中的位置,使用不同的棋盘格进行标定,外参都会有所不同。棋盘格的厚度较低,可以近似为一个平面,其标定平面为 P_1 ,而待测零件具有一定的高度,其成像平面为 P_2 ,如图3-1所示。




图 3-1 成像平面高度影响

依据像素当量的计算方式,标定平面 P_1 与像素平面 P 之间的像素当量 p_1 为:

$$p_1 = \frac{L}{l_1} = \frac{H}{f} \quad (3-1)$$

其中, L 为零件的实际长度, l_1 为零件的像素长度, H 为标定平面与光心之间的距离, f 为焦距。

然而由于零件存在高度的影响,实际成像平面为 P_2 , 实际成像平面 P_2 与像素平面 P 之间的投影关系为:

$$\frac{L}{l_2} = \frac{H-h}{f} \quad (3-2)$$

其中, l_2 为零件的像素长度, h 为零件高度。

则获得的待测零件像素长度为:

$$l_2 = \frac{L \times f}{H-h} \quad (3-3)$$

根据标定平面求得的像素当量 p_2 与待测零件的像素长度可以求得零件的测量尺寸 l 为:

$$l = l_2 \times p_1 = \frac{L \times f}{H-h} \times \frac{H}{f} = L \times \frac{H}{H-h} \quad (3-4)$$

由此可得,当零件存在高度时,即 $h>0$ 时,会导致标定平面与成像平面的不重合,造成测量尺寸大于实际尺寸。因此,需要根据零件高度,对标定平面进行调整,以此提高测量的准确度。

3.1.2 单应性矩阵

对于通过标定板进行像素当量标定,通常采用计算中心标志点之间的距离平均值作为像素当量,但是该方法容易收到相机畸变的影响;而通过标定块求解像素当量时,需要精确求取标定块的边缘轮廓,而大多采用自己所提出的边缘检测

方法, 标定结果不具备统一性, 在使用自定义边缘检测方法求取轮廓进行尺寸测量时, 会有偶然性。对此, 本文采用单应性矩阵来描述像素坐标系到实际坐标系的映射关系, 通过棋盘格标定板进行成像模型的标定。

单应性变换是用来描述两个平面相关点之间的变换, 这里用来描述物体在世界坐标系和像素坐标系之间的位置映射关系, 对应的变换矩阵称为单应性矩阵, 包含了相机的内参与外参系数。在相机成像模型中, 单应性矩阵 H 为:

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = H \begin{bmatrix} x_w \\ y_w \\ 1 \end{bmatrix} \quad (3-5)$$

$$H = s \begin{bmatrix} f_x & 0 & u_0 \\ 0 & f_y & v_0 \\ 0 & 0 & 1 \end{bmatrix} [R \quad t] \quad (3-6)$$

根据已知尺寸的棋盘格, 提取拍摄图像中的角点坐标, 根据两者之间的对应关系计算单应性矩阵。本文根据零件高度, 调整棋盘格位置, 计算世界坐标系下的成像平面与像素坐标系的单应性矩阵。

3.2 亚像素边缘检测

为提高测量精度, 需要精确获取零件测量轮廓的边缘数据点。在硬件层面上, 使用背光照明的方式提高零件与背景之间的对比度, 获得清晰的单个像素轮廓; 在软件层面上, 通过对边缘轮廓进行亚像素细化, 提高测量精度。对此, 本文通过正交实验的方式确定光源亮度, 并提出一种改进的基于局部面积效应的亚像素边缘检测方法, 用以提高轮廓的测量精度。

3.2.1 光源亮度确定

为提高边缘检测的精度, 通常需要增强光源亮度, 然而, 随着光源亮度的增加, 零件轮廓会缩小, 如图 3-2 所示, 随着光源亮度的增加, 轴承外圈所占黑色区域变小, 会导致测量结果不准确。对此, 本文选择通过实验确定光源亮度。

将待测零件至于测量装置上, 使用 Canny 边缘检测和圆拟合获取零件的直径。调整光源亮度, 直至当光源亮度变化不会导致零件直径变化为止, 将该光源亮度作为测量光源亮度。





图 3-2 光源亮度变化对边缘影响

3.2.2 像素边缘检测

像素级的边缘检测算法利用各种边缘检测算子与图像进行卷积操作，常用的边缘检测算法有 Sobel 算子、Laplacian 和 Canny 算子。其中 Canny 边缘检测法因具有好的信噪比、定位精度与边缘响应，应用最为广泛。

边缘检测结果如图 3-3 所示，其中 Canny 检测效果最好，可以获得单一连续轮廓。






图 3-3 边缘检测

3.2.3 亚像素边缘检测

Trujillo-Pino A^[70]等与 2013 年提出一种局部面积效应的亚像素边缘检测方法，因其具有精度高、效率好的特点，在许多领域等到应用^{[71][72][73]}。然而，该方法却存在着如下两个问题，一是面积效应区域大小固定为 5×3 ，对于不同的灰度边缘情况难以具有普适性；二是亚像素边缘只是向着 y 轴方向偏移，对于 x 轴方向则固定不变，这显然是不合理的。

对此，本文提出一种改进的基于局部面积效应的亚像素边缘检测方法，根据图像实际灰度值选择合适的面积区域大小，并增加对于 x 轴方向的偏移量计算，以此提高检测的精度。




图 3-4 边缘线的求解过程

如图 3-4 所示，轮廓两侧的强度值为 A 和 B ，假设 A 和 B 已知（ A 的灰度值

大，白色； B 的灰度值小，黑色），若像素点未被轮廓贯穿，则其强度即为其灰度值；若像素点被轮廓贯穿，则被贯穿的像素点强度按照公式计算：

$$G(i, j) = B + \frac{A-B}{h^2} E_{i,j} \quad (3-7)$$

其中， $G(i, j)$ 表示 (i, j) 处的替代灰度值， h 表示边缘的长度，一般取单位 1， $E_{i,j}$ 表示边缘点 (i, j) 内边缘线下方的面积。

为高效求解二次边缘线的表达式，在目标边缘点局部取一个满足求解要求的最小子区域，即大小为 $n \times 3$ 的窗口（其中 n 为奇数），如图 3-4 所示。设 S_L 、 S_M 、 S_N 分别为子窗口中左、中、右三列像素的强度之和，表达式为：

$$\begin{cases} S_L = \sum_{n=j-2}^{j+2} F_{i-1,n} = nB + \frac{A-B}{h^2} E_L \\ S_M = \sum_{n=j-2}^{j+2} F_{i,n} = nB + \frac{A-B}{h^2} E_M \\ S_N = \sum_{n=j-2}^{j+2} F_{i+1,n} = nB + \frac{A-B}{h^2} E_N \end{cases} \quad (3-8)$$

其中， E_L 、 E_M 、 E_N 分别表示左、中和右列二次边缘线下方的面积，可由公式求出：

$$\begin{cases} E_L = \int_{-3h/2}^{-h/2} (ax^2 + bx + c + nh/2) dx = ch - bh^2 + \frac{13}{12} ah^3 + \frac{n}{2} h^2 \\ E_M = \int_{-h/2}^{h/2} (ax^2 + bx + c + nh/2) dx = ch + \frac{1}{12} ah^3 + \frac{n}{2} h^2 \\ E_N = \int_{h/2}^{3h/2} (ax^2 + bx + c + nh/2) dx = ch + bh^2 + \frac{13}{12} ah^3 + \frac{n}{2} h^2 \end{cases} \quad (3-9)$$

因此，基于局部区域面积特征的二阶边缘系数即可通过公式求解。求解得到边缘线方程即可将整个像素边缘坐标细化为亚像素，从而提高标识点边缘检测精度。设细化前边缘点的坐标位置为 $p(x, y)$ ，则边缘细化后的坐标位置即为 $p(x, y+c)$ 。

$$\begin{cases} a = \frac{S_L + S_N - 2S_M}{2(A-B)} \\ b = \frac{S_N - S_L}{2(A-B)} \\ c = \frac{2S_M - 5(A+B)}{2(A-B)} - \frac{1}{12} a \end{cases} \quad (3-10)$$

重复以上过程，求解亚像素点在 x 轴方向上的偏移，可求得细化后的坐标位置 $p(x+c, y+c)$ 。窗口大小 n 按照如下规则选择，根据轮廓数据点沿坐标轴方

向生长，直至上下边界处存在着与 A 和 B 灰度值十分接近的数据点。

3.3 单应性矩阵变换与改进亚像素边缘检测

针对轴承外圈外径测量，分析当前视觉测量存在的问题。使用标定板标定轴承实际成像平面，并通过单应性矩阵进行像素尺寸向实际尺寸转换，结合改进的局部面积效应的亚像素边缘检测方法，实现对轴承外圈外径的尺寸测量。算法步骤如下所述：

步骤 1：相机标定。拍摄 20 张标定图片，使用张正友相机标定法进行相机内参与畸变系数的标定，使用畸变系数对后续图片进行畸变矫正。

步骤 2：单应性矩阵求解。将标定板放置于轴承的成像平面上，拍摄棋盘格图像，对图片进行畸变矫正，提取棋盘格角点，根据像素坐标系下角点坐标与自定义的世界坐标系下角点坐标对应关系，求解对应的单应性矩阵。

步骤 3：ROI 提取。采集轴承图片，进行畸变矫正，使用投影法对轴承进行 ROI 提取。

步骤 4：Canny 边缘检测。使用 Canny 边缘检测进行像素级边缘检测。

步骤 5：亚像素边缘检测。在 Canny 边缘检测的基础上，使用本文所提基于面积效应的亚像素边缘检测方法提高边缘检测的精度。

步骤 6：曲线拟合。根据单应性矩阵，将提取到的亚像素边缘数据点映射到世界坐标系下，通过圆形曲线拟合的方式求取轴承的特征尺寸。此时，求取的结果即为实际尺寸值（mm）。

3.4 外圈直径视觉测量实验验证

为验证本文所提方法，对标准轴承进行尺寸测量，进行实验验证。选择人本 6207 型号轴承，其外圈外径为 72.00mm，如图 3-5 所示。



图 3-5 6207 轴承

通过第 2 章所提角点检测方法,通过张正友相机标定,求取相机内参与畸变系数,对图像进行畸变矫正,求取结果如表 3-1 所示。

表 3-1 相机内参与畸变系数

内参矩阵			畸变系数				
6204.061	0	2297.495	[-0.08912 0.07704 -0.00157 0.00134 -1.73743]				
0	6203.820	1646.4084					
0	0	1					

3.4.1 光源亮度调整

为检验光源亮度对测量结果的影响,同时确定合适的光源亮度。放置零件,只调整平面光源的亮度。使用 Canny 边缘检测求取零件的轮廓尺寸,圆拟合求取直径,结果如表 3-2 所示,光源亮度与直径关系如图 3-6 所示。

表 3-2 光源亮度对测量结果影响

亮度 (级)	直径 (pixel)	亮度 (级)	直径 (pixel)
40	681.632	73	681.553
45	681.582	74	681.533
50	681.592	75	681.318
55	681.524	76	681.479
60	681.535	77	681.447
61	681.593	78	681.366
62	681.607	79	681.349
63	681.593	80	681.092
64	681.589	85	680.697
65	681.497	90	680.307
66	681.611	95	679.967
67	681.614	100	679.666
68	681.618	105	679.348
69	681.64	110	679.039
70	681.419	115	678.755
71	681.605	120	678.434
72	681.579		

由图 3-6 可得,随着光源亮度的降低,零件测量直径逐渐增大,当光源亮度达到 80 级左右时,出现拐点,零件测量直径保持不变。

由此可得,随着平面光源亮度的增强,金属反光零件的轮廓会向内逐渐收缩,导致结果精度较低,测量值偏小。同时考虑到,平面光源亮度越高,零件轮廓与背景的对比度越高,使用边缘检测算法获取的零件轮廓质量较高,可以得到清晰的“细”轮廓。因此,为获得精确的高质量零件轮廓,本文根据实验确定平面光源亮度为 75 级。当光源亮度低于 40 时,实验装置拍摄点的图像质量变得较差,使用 canny 边缘检测,获取的轴承外圈外径轮廓不再呈现出一个完整的圆形。




图 3-6 光源亮度对直径的影响

3.4.2 单应性矩阵外参描述

为验证不同标定平面对测量结果的影响,设计对比实验测试。调整平面光源亮度为 125 级,此时,棋盘格角点较为清晰,分别获取平面 P_1 与平面 P_2 的标定图片,其中平面 P_1 为光源平面,即零件放置的平面,而平面 P_2 为待测零件成像平面。分别求取两个平面的外参,根据棋盘格的角点,求取像素当量,使用 Opencv 库函数求取单应性矩阵,结果如表 3-3 所示。

表 3-3 相机外参

平面	像素当量	单应性矩阵		
P1	0.108172	0.0013946	0.1089043	-53.2099787
		0.1083881	-0.0011997	-152.4644164
		$-8.9840639 \times 10^{-7}$	3.0459679×10^{-6}	0.9998352
P2	0.106011	0.0014782	0.1064883	-49.9001282
		0.1061168	-0.0013771	-150.7858931
		$-1.1711053 \times 10^{-6}$	2.2957786×10^{-6}	1.00064058

根据 3.4.1 结论调整平面光源亮度为 75 级,对于 10 个轴承零件,轴承外圈公称直径为 72.00mm,使用 Canny 边缘检测获取零件的轮廓像素,其中上下限阈值分别设置为 20 和 100。对于不同标定平面与标定方法的测量结果如表 3-4 所示。以公称直径为标准,误差结果如图 3-7 所示。

由图 3-7 可以看出,对比不同的标定平面,可得平面 P_1 的标定结果误差偏大,而平面 P_2 的标定结果误差较小,且两个平面的相同标定方法求取误差成比例关系,即符合本文 3.1.1 所提标定平面对测量结果的影响所述结论,零件高度

会导致测量结果大于实际尺寸；对比平面 P_2 的不同外参标定方式，使用单应性矩阵标定结果更加接近于公称尺寸。综上，使用平面 P_2 进行单应性矩阵求取相机外参进行尺寸测量的结果更加准确。

表 3-4 不同相机外参测量结果

序号	平面 P_1		平面 P_2	
	像素当量	单应性矩阵	像素当量	单应性矩阵
1	73.2901	73.6043	73.2901	73.6043
2	73.2853	73.5956	73.2853	73.5956
3	73.2971	73.5961	73.2971	73.5961
4	73.352	73.6436	73.352	73.6436
5	73.2471	73.5695	73.2471	73.5695
6	73.2799	73.5844	73.2799	73.5844
7	73.3186	73.6164	73.3186	73.6164
8	73.2995	73.5883	73.2995	73.5883
9	73.305	73.5951	73.305	73.5951
10	73.3046	73.6002	73.3046	73.6002
11	73.288	73.5772	73.288	73.5772




图 3-7 相机外参标定

3.4.3 改进亚像素边缘检测

为验证本文所提改进亚像素边缘检测对测量精度的提升，分别使用 Zernike 矩亚像素边缘检测、传统基于面积效应的亚像素边缘检测和本文所提改进基于传统面积效应的亚像素边缘检测进行尺寸的测量。参数设置与实验 3.4.2 相同，相机外参使用实验 3.4.2 所得的平面 P_2 的单应性矩阵，测量结果如表 3-5 所示，误

差如图 3-8 所示。

表 3-5 亚像素边缘检测测量结果

序号	公称直径/mm	Canny/mm	Zernike/mm	传统/mm	本文/mm
1	72.00	71.9701	71.9701	71.9764	71.9811
2	72.00	71.9616	71.9616	71.9832	71.9981
3	72.00	71.9623	71.9623	71.9656	71.9683
4	72.00	72.0086	72.0086	72.0066	72.0043
5	72.00	71.936	71.9360	71.9436	71.9488
6	72.00	71.9506	71.9506	71.9532	71.9561
7	72.00	71.9823	71.9823	71.9916	71.9981
8	72.00	71.9548	71.9548	71.9554	71.956
9	72.00	71.9615	71.9614	71.9653	71.9682
10	72.00	71.9662	71.9662	71.9708	71.9741

如图所示，本文改进的基于局部面积效应的亚像素边缘检测算法求取的轮廓误差最小，优于传统基于局部面积效应的亚像素边缘检测算法、Canny 边缘检测与 Zernike 矩亚像素边缘检测。从结果可以看出，Zernike 矩亚像素边缘检测对圆拟合的结果提升并不明显，而基于局部面积效应的亚像素边缘检测提升了圆拟合的直线检测结果的精度。测量结果误差在 0.05mm 以内，即 0.5 个像素以内（像素当量）。




图 3-8 亚像素边缘检测误差

3.5 本章小结

为提高轴承尺寸视觉测量的精度，提出一种基于单应性矩阵和改进局部面积效应的轴承尺寸测量方法。该方法通过单应性矩阵对相机外参进行标定，用以将像素尺寸映射至实际尺寸，通过改进基于局部面积效应的亚像素边缘检测提高边缘检测的精度。同时，分析了光源亮度和零件高度对检测结果的影响，并通过实

验的方式确定了光源亮度。对同一规格的轴承进行测量，实验结果表明，由于零件高度导致的成像平面与标定平面的不同会使得测量结果偏大；通过相机外参标定，将像素尺寸映射至世界坐标系下，基于单应性矩阵的标定方式优于像素当量，求解精度更高；本文提出的改性局部面积效应的亚像素边缘检测优于局部面积效应亚像素边缘检测，求取的边缘更加准确。使用本文方法求解的轴承外圈直径误差小于 0.05mm，在 0.5 个像素值以内。

第4章 基于视觉的轴承外圈圆度计算

通过图像处理技术获取轴承外圈轮廓数据,根据所提取数据点信息计算圆度误差。相较于传统采样获取的离散点,基于视觉方法获取的轴承轮廓数据点较多,为提升圆度误差估计计算效率,提高检测精度,本章研究了一种改进的人工蜂群算法。

4.1 目标函数构建

将来自图像的轮廓边界数据点集记为 $P=\{(x_i, y_i) | i=1, 2, \dots, n\}$, 其中, (x_i, y_i) 为像素坐标位置, n 为数据点数。如图 4-1 所示, 基于最小区域法的圆度误差评定, 首先需要确定包络采样数据点且半径差为最小的两个圆的圆心位置, 两同心圆的半径差即为圆度误差。最小区域法圆度误差评定的准则如下所述:

$$f = e = \min\{\max(\sqrt{(x_i - X)^2 + (y_i - Y)^2}) - \min(\sqrt{(x_i - X)^2 + (y_i - Y)^2})\} \quad (4-1)$$

其中, e 为目标函数值即圆度误差, (X, Y) 为最小区域圆心坐标, (x_i, y_i) 为采集的零件轮廓数据点, i 为数据点序号。




图 4-1 圆度误差示意图

4.2 改进人工蜂群圆度误差视觉评定

4.2.1 人工蜂群算法

人工蜂群算法是一种通过种群协同来完成目标函数求解寻优过程的智能算法, 种群被分为引领蜂、跟随蜂和侦查蜂三类^[74]。首先需要进行种群初始化,

然后通过对引领蜂、观察蜂和侦查蜂的循环迭代进行参数寻优，当算法达到预定循环次数或满足误差条件时将当前最优解视为最终结果。算法实现步骤如下：

(1) 种群初始化：一般采用随机方式进行种群初始化生成新的蜜源，随机产生初始种群，如下所述：

$$x_{ij} = x_j^{\min} + rand(0,1)(x_j^{\max} - x_j^{\min}) \quad (4-2)$$

其中： i 为蜜源的序号， j 为解空间的维数， $x_j^{\max}$ ， $x_j^{\min}$ 为解在 j 维空间的上、下界， $rand$ 为随机数。

(2) 引领蜂阶段：引领蜂随机选择一个蜜源的 j 维 x_{ij} ，再根据公式 (4-3) 随机生成新开采源。并通过适应度函数对该蜜源进行适应值评价，即求取该开采源的目标函数值。

$$v_{ij} = x_{ij} + rand(0,1)(x_{kj} - x_{ij}) \quad (4-3)$$

$$fit_i = \begin{cases} 1/(1+f_i), & f_i \geq 0 \\ 1+abs(f_i), & f_i < 0 \end{cases} \quad (4-4)$$

其中， x_{kj} 为所选蜜源邻域蜜源的 j 维， v_{ij} 为所选蜜源的 j 维开采源， f_i 为目标函数值， fit_i 为适应值。

(3) 跟随蜂阶段：跟随蜂依据适应值 fit_i 开采对应蜜源， fit_i 数值越大，跟随概率越大，其概率通过公式 (4-5) 求取。

$$P_i = \frac{fit_i}{\sum_{j=1}^{SN} fit_j} \quad (4-5)$$

与引领蜂一样，跟随蜂蜜源选择之后采用公式 (4-3) 随机生成一个新的开采源。

(4) 侦查蜂阶段：若一个蜜源被跟随一定次数以后目标函数适应值 fit_i 未增大，即表明这个解陷入局部最优，应被放弃，引领蜂转变为侦查蜂，重新生成一个新的蜜源，其生成公式与种群初始化方式相同，通过公式 (4-3) 随机产生。

4.2.2 改进人工蜂群算法圆度误差视觉评定

上述的传统人工蜂群算法，在解区间内随机生成初始解，可保证随机性即全域探索能力，但不能保证初始种群在解空间分布的合理性，由公式 (4-3) 可

知,新蜜源的获得完全依赖于随机数产生质量,会导致算法初始种群出现聚集现象,影响了算法的稳定性和迭代效率。

为此,为提高误差评定圆圆心坐标解的算法收敛速度,此处对传统蜂群算法进行了改进。首先依据原始轮廓数据确定局部搜索域;然后采用步长递减法迭代计算出圆心的收敛解。

(1) 圆心解的搜索域确定

为合理限定搜索域,依据原始轮廓数据点坐标确定种群初始化区域,即评定圆圆心的求解范围,具体步骤如下:

设种群规模为 $2 \times (S_N)^2$, 其中蜜源即圆心候选解为 $X_i = \{(x_1, y_1), (x_2, y_2), \dots, (x_i, y_i)\}$, 其中 $i \in \{1, 2, \dots, (S_N)^2\}$ 。

在求解外接圆和内切圆时,对于前述零件外围轮廓,根据对称性首先采用公式(4-6)求取初始圆心,通过公式(4-7), (4-8)获取圆心所在范围。

$$\begin{cases} x_0 = \sum_{i=1}^n \frac{x_i}{n} \\ y_0 = \sum_{i=1}^n \frac{y_i}{n} \end{cases} \quad (4-6)$$

$$\begin{cases} r_{\min} = \min \sqrt{(x_i - x_0)^2 + (y_i - y_0)^2} \\ r_{\max} = \max \sqrt{(x_i - x_0)^2 + (y_i - y_0)^2} \end{cases} \quad (4-7)$$

$$R_0 = e_0 = r_{\max} - r_{\min} \quad (4-8)$$

式中, x_i, y_i 的 $i=1, 2, \dots, n$, n 为数据点个数, x_0, y_0 为初始圆心坐标, $r_{\max}, r_{\min}$ 为初始圆心至轮廓的最大距离与最小距离, e_0 为初始圆度误差假定值, R_0 为初始圆心的圆度误差即圆心所在区域半径。

初始解分布越均匀,在最优解邻域搜索的可能性就越大^[75]。为保证初始种群的均匀性,此处将可行域均匀划分,同时,为便于将圆形区域均匀离散处理,以初始圆心坐标 (x_0, y_0) 为中心,以上述误差假定值 e_0 的 2 倍即 $2R_0$ 作为边长,构建一个解的矩形可行域。将其平均分成 S_N^2 个区域,取每个区域的中心作为蜂群算法的初始解,如图 4-2 所示。单个区间的长度可由公式(4-9)计算得到

$$l = \frac{2R_0}{S_N} \quad (4-9)$$




图 4-2 局部区域种群平均初始化

(2) 步长递减搜索机制

为吸引跟随蜂在适应值高的蜜源附近迭代更新，引导随机数的方向性，改善算法的收敛速度，此处采用步长递减搜索法，在上述均匀离散区间内采用邻域搜索机制。

为避免传统算法陷入局部最小值的问题，采用步长递减搜索方式，将蜜源更新次数 t 引入开采源更新公式中，随着蜜源被开采次数的增加搜索范围逐渐缩小，以提高求解精度。同时，对于传统蜂群算法仅在一维上的参数更新，此处在二维空间上进行参数迭代，有利于提高局部搜索能力。新解的搜索方式如公式(4-10)所示。

$$\begin{cases} x = x_{ibest} + rand(-1,1) \times (l/t) \\ y = y_{ibest} + rand(-1,1) \times (l/t) \end{cases} \quad (4-10)$$

其中， x_{ibest} ， y_{ibest} 为当前最优解， $rand(-1, 1)$ 为 $[-1, 1]$ 区间上的随机数， t 为开采次数。

(3) 全局最优引导

当适应值 fit 连续 $limit$ 次未更新，即 $t=limit$ ，表明陷入了局部最优值，需在解的可行域上随机生成新解。为充分利用此前产生的种群信息，此处采用最优个体引导机制，对传统蜂群算法中的公式进行改进。将前一次迭代产生的最优个体信息，引入到下一次迭代计算公式中，即更新的圆心解 (x_{i+1}, y_{i+1}) 通过可公式(4-11)求取。

$$\begin{cases} x_{i+1} = x_{ibest} + rand(-1,1)(X_{max} - x_{ibest})if : rand(-1,1) \geq 0 \\ x_{i+1} = x_{ibest} + rand(-1,1)(x_{ibest} - X_{max})if : rand(-1,1) < 0 \\ y_{i+1} = y_{ibest} + rand(-1,1)(Y_{max} - y_{ibest})if : rand(-1,1) \geq 0 \\ y_{i+1} = y_{ibest} + rand(-1,1)(y_{ibest} - Y_{max})if : rand(-1,1) < 0 \end{cases} \quad (4-11)$$

其中, x_{ibest} , y_{ibest} 为此前 i 次迭代的最优解, X_{max} , X_{min} , Y_{max} , Y_{min} 为可行域边界。

4.3 圆度误差检测实验

4.3.1 实验验证

获取 3.4 节标准轴承轮廓数据, 使用本文所述算法进行圆度误差计算。本算法的总群规模设定为 50, 总迭代次数为 100, 同一蜜源迭代最大次数 limit 设为 15, 对算法运行 50 次的计算结果求取平均值。对比最小二乘法圆度误差评定计算, 结果如表 4-1 所示。

表 4-1 测量尺寸

序号	最小二乘法/pixel	本文算法/pixel
1	0.8613	0.7186
2	0.7110	0.6266
3	0.8611	0.6777
4	0.7071	0.6577
5	0.7336	0.7004
6	0.7295	0.7127
7	0.5941	0.5299
8	0.7494	0.5970
9	0.6807	0.6002
10	0.9719	0.6387

由表可知, 基于本文算法的圆度误差评定结果更小, 结果优于最小二乘法。

4.3.2 同类算法对比分析

表 4-2 现有文献中的数据点坐标

序号	x/mm	y/mm	序号	x/mm	y/mm	序号	x/mm	y/mm	序号	x/mm	y/mm
1	1.0249	0.0863	11	-0.0683	0.9382	21	-0.5795	-0.8424	31	0.9950	-0.3272
2	0.9991	0.2226	12	-0.8432	0.4157	22	-0.9618	0.0170	32	1.0218	-0.1921
3	0.5974	0.7736	13	-0.9022	0.2890	23	-0.9454	-0.2605	33	-0.0686	-1.0521
4	0.4731	0.8485	14	-0.9394	0.1561	24	-0.9077	-0.3956	34	0.0710	-1.0568
5	0.8803	0.4794	15	-0.2071	0.9218	25	-0.8443	-0.5203	35	0.2087	-1.0377
6	0.8017	0.5899	16	-0.3381	0.8782	26	-0.7764	-0.6394	36	0.3445	-1.0078
7	0.9527	0.3551	17	-0.4643	0.8132	27	-0.4635	-0.9195	37	0.7082	-0.7982
8	0.7047	0.6884	18	-0.5771	0.7369	28	0.4736	-0.9507	38	0.8873	-0.5832
9	0.2101	0.9295	19	-0.7763	0.5367	29	0.5942	-0.8781	39	0.9510	-0.4578
10	0.0708	0.9483	20	-0.6838	-0.7485	30	-0.2059	-1.0269			

为进一步验证本文算法的效果, 对文献[35]和[76]中的同一组测量数据, 进

行圆度误差评定对比分析。数据点坐标如下表 4-2 所示。

本文算法运行的相关参数设置与 4.3.1 相同，评定结果与最小二乘[76]、粒子群算法[35]、MZC 法[76]进行比较，如表 4-3 所示。

表 4-3 数据处理结果对比

方法	圆心 (a, b)	圆度误差 e
最小二乘法	(0.035535201, -0.053585512)	0.0091672738
粒子群算法[35]	(0.035613523, -0.052928923)	0.0085384689
MZC法[76]	(0.035600000, -0.052900000)	0.0086000000
本文方法	(0.035614971, -0.052929481)	0.0085374645

可见，本文算法结果与最小二乘法、文献[76]中的 MZC 法、文献[35]中的粒子群算法的圆心位置相接近，此外，与最小二乘法的圆度误差评定值（0.0091672738mm）、文献[76]中的 MZC 求得的评定值（0.0086mm）、文献[35]中的粒子群算法的评定值（0.0085384689mm）相比，本文得到的圆度误差评定值（0.0085374645mm）更小。




图 4-3 迭代曲线收敛图

本文计算的中心位置和圆度误差具有较高的精度。从图 4-3 中迭代曲线的收敛图可以看出,改进的蜂群算法获得的初始解优于传统的蜂群算法,收敛速度更快,最终解的精度更高。

4.4 本章小结

针对轴孔类零件的圆度误差评定问题,本文从种群初始化区域和搜索机制两个方面,对传统人工蜂群算法进行了改进,在此基础上优化了基于最小区域的圆度误差评定方法。对轴承进行检测与评定结果显示,其计算数值精度优于最小二乘法。此外,利用同一组原始数据,将本文方法与常用的最小二乘法、粒子群算法及 MZC 法效果进行了对比分析,进一步验证了本文方法的可行性和准确率,具有一定的理论和工程应用价值。

第5章 轴承表面缺陷检测

为实现缺陷检测的自动化,一般采用机器学习的方法对缺陷进行分类。本章在传统机器学习图像分类方法的基础上,通过增加图像的灰度统计特征,来提升图像分类准确率;同时研究了基于深度学习的单阶段目标检测算法 YOLO,以实现轴承表面缺陷检测。

5.1 基于传统机器学习的表面缺陷分类

机器学习的缺陷分类首先需要提取图像的特征信息,将图像数据数量化,组成特征向量,然后使用分类算法对特征向量进行分类,基于特征向量的类别来表征图像的类别,实现图像的分类。

5.1.1 特征提取

图像的特征主要分为 3 类,分别为形状特征、颜色特征和纹理特征。对于金属零件图像的特征主要采用纹理特征进行描述,同时由于灰度统计特征包含原始数据的大量数据,因此本文综合提取图像的纹理特征与灰度统计特征,构建特征向量。其中纹理特征使用局部二值模式和灰度共生矩阵,相关求取方式如下所述。

(2) 局部二值模式

以中心像素为阈值,将相邻的 8 个像素的灰度值与中心点进行比较,若像素值大于中心像素值,则该像素点的位置被标记为 1,否则为 0。这样邻域 8 个点经比较可产生 8 位 2 进制数,将其转换为 10 进制数,即可得到该窗口中心像素点的 LBP 值,并用这个值来反应该区域的纹理信息,如下图所示。




图 5-1 LBP 算子

对整幅图像的每个像素点进行上述处理,即可得到图像的 LBP 描述图,通过统计 LBP 描述图的 LBP 编码直方图,将直方图作为特征向量,特征向量的维度为 256。

(2) 灰度统计特征

灰度统计特征是对图像灰度进行统计学的计算,为提高计算的效率,通常先获取图像的灰度直方图,基于灰度直方图快速计算相关统计量。灰度直方图的计算方式如下所示:

$$Hist(i) = \frac{n_i}{N} \quad (i = 0, 1, \dots, 255) \quad (5-1)$$

式中, i 为灰度级; n_i 为灰度级为 i 的像素点个数; N 为总像素点个数; $Hist(i)$ 为 i 灰度级出现的概率。灰度统计特征主要包括灰度均值、灰度方差、灰度歪斜度、灰度峰态、灰度能量。计算方式如表 5-1 所列:

表 5-1 灰度统计特征

灰度统计特征	计算公式
灰度均值	$Mean = \mu = \sum_{i=0}^{255} iHist(i)$
灰度方差	$Variance = \sigma^2 = \frac{1}{N} \sum_{i=0}^{255} n_i (i - \mu)^2$
灰度歪斜度	$Skewness = \frac{1}{\sigma^3} \sum_{i=0}^{255} (i - \mu)^3 Hist(i)$
灰度峰态	$Kurtosis = \frac{1}{\sigma^4} \sum_{i=0}^{255} (i - \mu)^4 Hist(i)$
灰度能量	$Energy = \sum_{i=0}^{255} Hist(i)^2$

(3) 灰度共生矩阵

灰度共生矩阵被定义为从灰度为 i 的像素点出发,离开某个固定方向和距离的点上灰度值为 j 的概率,所有估计值可以组成一个矩阵,这个矩阵称为灰度共生矩阵。再计算灰度共生矩阵的过程中,首先需要确定固定方向,进而确定距离。与 LBP 类似的特征求取方式一样,将图像“转化”至另一个“维度”,对新维度中的数据进行统计特征计算。

在对图像纹理分析研究中，可从灰度共生矩阵中提取 14 种特征参数来描述不同的纹理特征。其中，最常用的统计量为对比度/惯性矩、自相关性、有角二阶矩、协同性/逆差矩等，计算方式如下表示。

表 5-2 灰度共生矩阵特征

灰度共生矩阵特征	计算公式
纹理对比度	$contrast = \sum_{n=0}^{255} n^2 \left\{ \sum_{i=0}^{255} \sum_{j=0}^{255} P(i, j, l, \alpha)^2 \right\}$
纹理相关性	$correlation = \sum_{i=0}^{255} \sum_{j=0}^{255} \frac{ijP(i, j, l, \alpha) - u_1 u_2}{\sigma_1^2 \sigma_2^2}$
纹理角二阶矩	$ASM = \sum_{i=0}^{255} \sum_{j=0}^{255} P(i, j, l, \alpha)^2$
纹理同质性	$Homogeneity = \sum_{i=0}^{255} \sum_{j=0}^{255} \frac{P(i, j, l, \alpha)}{1 + (i - j)^2}$

式中，矩阵 $P(i, j, l, \alpha)$ 表示为像素点 (x, y) 的所有 α 方向，相邻间隔为 l 的像素对中一个取 i 值，另一个取 j 值的相邻像素对出现的次数， α 通常取 0° 、 45° 、 90° 和 135° 。

5.1.2 SVM 分类

支持向量机（SVM）是一种基于统计学的分类器，具有较强的鲁棒性，同时在训练过程中，SVM 的最终模型只与支持向量有关，大部分训练样本向量都不会保留，避免了维数灾难问题。




图 5-2 SVM 算法原理

如图 5-2 所示，为一个二分类模型，将实例的特征向量映射为空间中的一个

点，“+”表示正例，“-”表示负例，支持向量机的目标就是找到一条之间，将两个类别进行划分，并且两个类别间隔最大。对于多分类问题，采用一类对余类的方式进行多分类，将每种类别一一分出。

5.2 基于深度学习的表面缺陷检测

5.2.1 深度学习模型

深度学习是机器学习技术分支之一，通过搭建深层的人工神经网络来进行知识的学习。基于深度学习的缺陷检测流程如下所述，主要分为以下步骤：

（1）准备数据：根据不同的检测任务，准备好规定类型的数据，并对数据进行相关预处理，以提高数据的平衡性与显著性；

（2）定义神经网络模型：确定神经网络的结构，各个神经元之间的连接方式，即数据流动方式与计算规则；

（3）定义损失函数与优化方法：确定网络输出结果与理想值之间的误差计算准则，计算损失函数，根据损失函数与反向传播原则，选择合适的优化方式计算并更新神经元中的参数；

（4）模型训练：使用准备好的数据，对模型进行迭代训练，获得训练好的神经网络；

（5）性能检测：使用训练好的神经网络进行目标检测实验验证，并进行性能评级。

5.2.2 YOLOv5

YOLO 系列算法将图像进行网格分割，每个网格预测 B 个边界框和一个类别信息，边界框包含位置信息和置信度信息。YOLOv5 和 YOLOv4 是 YOLOv3 的社区改进版，整体结构基本相同。YOLOv5 的网络结构由输入端、主干网络、颈部网络和输出端 4 个部分组成。

（1）输入端：对图像进行了预处理。

对图像进行缩放，这统一了图像的标准尺寸，同时还增加了自适应的锚框计算功能。通过 Mosaic 数据增强，提升了数据的表达能力和数据的全面性。同时计算 4 张图像数据，提高了模型的训练速度和检测能力。

(2) 主干网络：对图像进行特征提取。

主干网络主要由 CBL、Focus、SPP 和 CSP 模块组成。CBL 模块的组成如图所示，由卷积层、批次归一化层和激活层组成。




图 5-3 CBL 模块

Focus 模块是 YOLOv5 的特有模块，组成如图 5-4 所示，将图像进行切片与拼接操作。该模块将图像的宽度和高度信息集中到了通道空间，通道的维数扩大到了原来的 4 倍，即拼接后的结果相当于将原先 RGB 的三通道模式变为 12 通道模式，结果如图 5-5 所示。




图 5-4 Focus 模块

通过图像分割，获得了不同尺度的特征，融合不同尺度的特征可以提高检测模型的性能。按照融合时期的不同，特征融合主要分为早融合和晚融合两种类型。早融合首先融合多层的特征，然后在融合后的特征上训练预测器，例如 concat 和 add 操作。而晚融合则在尚未完成最终的融合前，在部分层上开始进行目标检测，最终将多个检测结果进行融合。




图 5-5 Focus 原理

SPP 模块是标准通单层，通过对图像进行标准的池化操作，使得图像输出一致，作为全连接层的输入，用于对检测目标进行预测。如图 5-6 所示，该结构分别采用 1×1 、 5×5 、 9×9 和 13×13 的最大池化，再将所得结果拼接，得到融合后的特征。




图 5-6 SPP 模块

CSP 模块用于减少模型推理的计算量。CSPNet 将底层的特征图按通道拆分为两部分，一部分经过密集块（由多个全连接层组成）和过渡层（通常是卷积核大小为 1×1 的卷积层），另一部分与传输的特征图结合，在减少计算量的而同时也提高了推理的速度和准确性。YOLOv5 设计了两种 CSPNet 结构，如图 5-7 所示，分别为 CSP1_X 和 CSP2_X。CSP1_X 结构应用于骨干网络，CSP2_X 结构则应用于 Neck 部分。利用 CSPNet 改进骨干网络能够提升检测的性能，增强了 CNN 的学习能力，同时减少计算量，提升推理的速度。




图 5-7 CSP 模块

其中，残差模块如下图所示。




图 5-8 残差模块

(3) 颈部网络：生成特征金字塔，增强网络模型对不同尺度物体的检测能力。

其采用 FPN-PAN 网络结构，FPN 通过上采样将深层语义信息与底层目标位置信息进行融合，增强网络对特征学习能力。PAN 结构自底向上传达强定位特征，全面提升网络学习能力。

(4) 输出端：输出端 3 个检测头，预测图像、生成边界框和图像中目标类别和置信度。

YOLOv5s 整体网络结构如图所示。




图 5-9 YOLOv5s 网络结构

5.2.3 缺陷检测

基于深度学习的缺陷检测需要使用训练数据，根据训练数据计算模型中的相

关参数，然后使用训练好的模型对缺陷进行检测。本文使用现有的带钢表面缺陷数据集，将数据集分为训练集与测试集，使用训练集对模型进行训练，将测试集数据使用训练好的模型进行检测。

5.3 缺陷分类与检测实验验证

5.3.1 传统方法缺陷检测

使用文献[77]中的数据进行图像的纹理分类。共有六种缺陷，每种缺陷 300 张图像，缺陷类型分别为轧屑、斑块、龟裂、麻面、夹杂物和划痕，如图 5-10 所示。按照 6:4 的比例，将数据划分为训练集与测试集，按照 1 至 6，将缺陷类型进行编码。




图 5-10 表面缺陷类型

为验证不同特征向量对分类结果的影响，选择 3 组不同的特征组合加 SVM 的方式进行分类，如下所述：

- (1) 特征组 1：灰度统计特征、GLCM 统计特征、LBP 灰度直方图；
- (2) 特征组 2：灰度统计特征、灰度共生矩阵；
- (3) 特征组 3：LBP 灰色直方图；

表 5-3 缺陷分类准确率

缺陷类型	准确率		
	特征组1	特征组2	特征组3
轧屑	100%	100%	100%
斑块	99.17%	98.33%	95.00%
龟裂	86.67%	98.33%	85.83%
麻面	66.67%	100%	68.33%
夹杂物	84.17%	89.17%	100%
划痕	60.00%	90.83%	63.33%
平均值	82.78%	96.11%	85.42%

图像分类结果如表 5-3 所示，由图可得 3 种不同的特征描述组合中，特征组 2 的分类效果最好，达到了 96.11%。各组分类准确率如下图所示。




图 5-11 特征组 1 分类




图 5-12 特征组 2 分类




图 5-13 特征组 3 分类

5.3.2 YOLOv5 缺陷检测

使用文献[78]中的缺陷检测数据集，将数据分为训练集、验证集和测试集（6:2:2），使用 yolov5s 网络模型进行训练，训练次数调整为 150 次，对网络进行训练。使用 Windows 系统，其中 torch 版本为 1.13.1+cu116，显卡型号为 NVIDIA A30。YOLOv5 训练包含三个方面的损失，矩形框损失，置信度损失和分类损失，训练结果如下图 5-14 所示。由图可知，随着模型的迭代，损失函数在逐渐减小。




图 5-14 训练结果分析

TP、TN、FP 和 FN 含义如下表所示。

表 5-4 检测结果分类

	正例预测	反例预测
正例实际	TP	FN
反例实际	FP	TN

IOU 是目标检测中，检测框与标注框之间的交集面积与并集面积之间的比值，如图 5-15 所示，用来表示目标检测的正确性，若检测框与标注框之间的 IOU 大于设定阈值，则判断检测正确，若检测框与标注框之间的 IOU 小于设定阈值，则判断检测错误，通常将 IOU 阈值设定为 0.5。




图 5-15 IOU 计算

精度 Precision 表示模型预测正确的正样本数 (TP) 早模型预测的总的正样本数中 (TP+TF) 的占比。召回率 Recall 指预测正确的正样本数 (TP) 在总的标签数中 (TP+FN) 的占比。设定置信度阈值，可以得到模型在不同阈值下所计算出的 P 值和 R 值，其中曲线的面积称为 AP。对所有的 AP 值求平均可以得到模型的均值密度 mAP，mAP 越大，表示模型的性能越好。

训练精度与召回率如图 5-16 (a) (b) 所示，设置检测目标 IOU 为 0.5，得到训练 mAP 曲线如图 5-16 (c) 所示。验证集 PR 曲线如图 5-17 所示，最终全类别平均分类结果达到 0.753。




图 5-16 训练精度与召回率




图 5-17 验证集 PR 曲线

5.3.3 轴承表面缺陷检测

常见的轴承表面缺陷为：1、磕碰缺陷；2、擦伤缺陷；3、锈蚀缺陷；4、裂纹缺陷；5、划痕缺陷。然而，现在还没有被大家认可的公开轴承表面缺陷的数据集。对此，本文自行构建轴承表面缺陷数据集，购买完好的轴承，人为进行损害，模拟实际生产过程中出现的表面缺陷，以此数据集进行表面缺陷检测实验。由于轴承端面硬度较大，因此选择柱面进行人为破坏，获取划痕（SC）、磕碰（KA）缺陷，使用固定区域分割的方式，获取零件反光区域图像，并对图像进行灰度化，处理结果如图所示。




图 5-18 轴承表面缺陷

其中，划痕、磕碰缺陷各 160 张图片，共计 320 张图片。使用 labeling 软件进标注，获得 YOLO 模型适用的标签。将数据集划分为训练集、验证集和测试集（6:2:2）。模型参数设置与 5.3.2 实验相同，轴承检测 PR 曲线如下所示。




图 5-19 轴承表面缺陷检测 PR 曲线

对于验证集图像，由图 5-19 的轴承表面缺陷检测 PR 曲线可得，随着召回率的增加，精度逐渐下降。对于划痕缺陷，检测结果为 0.835，磕碰缺陷检测结果为 0.839，最终全类别平均分类结果达到 0.837。测试集缺陷检测结果如图 5-20 所示。




图 5-20 轴承表面缺陷检测结果

5.4 本章小结

针对轴承表面缺陷检测,研究了基于特征工程表面缺陷分类和基于深度学习表面缺陷检测方法。提取图像的灰度统计特征和纹理特征,使用 SVM 进行图像分类,组合不同特征进行实验,实验结果表明,使用灰度统计特征和灰度共生矩阵的分类结果最好,分类平均准确率为 96.11%。通过 YOLOv5 模型,实现了带钢表面缺陷检测,其 mAP 为 0.753。自制轴承表面缺陷,使用 YOLOv5 模型进行检测,其 mAP 为 0.837。

第6章 总结与展望

6.1 总结

本文以轴承为研究对象,采用机器视觉技术,探索了实现其尺寸测量与表面缺陷检测的方法。基于尺寸测量与表面缺陷检测要求,搭建了视觉检测装置;通过图像处理技术,获取零件像素尺寸,根据相机成像模型,将像素尺寸转换为实际尺寸;分析了轴承表面缺陷形式,采用传统方法实现了表面缺陷的分裂,深度学习方法实现对表面缺陷的检测。最后使用 C/C++、Python 编程语言, OpenCV、Pytorch 函数库编写测量与检测程序进行验证。对于提升轴承的品质具有重要的应用价值和实际意义。具体总结如下:

(1) 搭建了视觉测量装置并推导了相机成像模型,采用张正友相机标定法对其进行标定,针对标定过程中棋盘格角点检测的精度不足问题,根据棋盘格角点的几何特性,提出了一种基于棋盘格局部区域线性拟合的角点检测方法。对比了现有角点检测方法,实验验证了本文所提方法的检测精度和鲁棒性更优。

(2) 研究了视觉测量的方法,对轴承外圈外径进行检测,现有像素尺寸转换为实际尺寸的方式多采用比例系数像素当量的描述方式,但是该方式求解方式会引入测量误差、模型误差等,因此使用了一种基于单应性矩阵的相机外参描述方式;为提高视觉测量的精度,改进了一种的基于局部面积效应的亚像素边缘检测方法,用以提高零件边缘检测的精度,分析了零件高度对视觉测量的影响。通过实验,验证了零件高度对测量结果的影响与分析一致,基于单应性矩阵与局部面积效应亚像素边缘检测的轴承尺寸测量方法精度可以达到亚像素。

(3) 研究了零件圆度误差的评定方式,针对视觉测量获取的零件轮廓点数据较多,圆度误差评定的非线性与计算量大的问题,改进了一种基于蜂群算法的非线性优化算法,实现对圆度误差的评定,实验验证了该方法的精度优于最小二乘法。

(4) 探索了基于视觉的表面缺陷检测方法,针对传统方法对缺陷进行分类时准确率不高的问题,研究了基于灰度特征与纹理特征组合的方式构建特征向量,

采用 SVM 分类器进行分类，对公有数据集的实验表明，不同特征组合的特征向量进行缺陷分类的精度相差较大，采用灰度统计特征和灰度共生矩阵组成的特征向量分类精度最优；实现了基于 YOLOv5 模型的零件表面缺陷检测，使用自制数据集进行实验，验证了该方法的准确性。

6.2 展望

由于时间原因，现有研究还存着不足，仍需进一步研究和改进：

（1）针对相机标定，本文在张正友相机标定法的基础上，提出了一种新的棋盘格角点检测方法，提高了相机标定过程中角点检测的精度，为提升尺寸测量的精度，尚需对更高精度的标定方法进行探索。

（2）对于轴承尺寸测量的研究中，只分析了外接环境中光源强度对尺寸测量精度的影响，还需要进一步研究外接环境的干扰，以提升测量的精度。

（3）本文获取的轴承表面缺陷数据集是在实验室中获取，尚未在实际工况下对轴承表面缺陷进行检测。同时，本文获取的轴承表面缺陷类型有限，对于剩余缺陷类型的检测精度和准确性还需进一步验证。

参考文献

- [1] Lu M, Chen C L. Detection and Classification of Bearing Surface Defects Based on Machine Vision[J]. Applied Sciences. 2021, 11(04): 1825.
- [2] 段杰. 滚动轴承微弱冲击信号的检测与特征提取方法研究[D]. 华中科技大学, 2019.
- [3] Shen H, Li S, Gu D, et al. Bearing Defect Inspection Based on Machine Vision[J]. Measurement. 2012, 45(04): 719-733.
- [4] 肖强. 圆锥滚子轴承视觉检测研究[D]. 华东交通大学, 2009.
- [5] 朱铮涛. 基于计算机视觉图像精密测量的关键技术研究[D]. 华南理工大学, 2004.
- [6] 尹仕斌, 任永杰, 刘涛, 等. 机器视觉技术在现代汽车制造中的应用综述[J]. 光学学报, 2018, 38(08): 11-22.
- [7] Connolly C. Machine vision advances and applications[J]. Assembly Automation, 2009, 29(02): 106-111.
- [8] Robert E. Jones. Machine vision applications[J]. Mechatronics, 1991, 1(04): 439-446.
- [9] 汤勃, 孔建益, 伍世虔. 机器视觉表面缺陷检测综述[J]. 中国图象图形学报, 2017, 22(12): 1640-1663.
- [10] Kang J, Yoon H, Lee S, et al. Sparse Checkerboard Corner Detection from Global Perspective[C]. 2021 IEEE International Conference on Signal and Image Processing Applications (ICSIPA). IEEE, 2021: 12-17.
- [11] 储珺, 郭卢安政, 赵桂花. 采用环形模板的棋盘格角点检测[J]. 光学精密工程, 2013, 21(01): 189-196.
- [12] 杨幸芳, 黄玉美, 李艳, 等. 基于改进的 SUSAN 算子的棋盘格亚像素角点检测算法[J]. 中国机械工程, 2010, 21(21): 2541-2545.
- [13] Bok Y, Ha H, Kweon I S. Automated checkerboard detection and indexing using circular boundaries[J]. Pattern Recognition Letters, 2016, 71: 66-72.
- [14] Yan Y, Yang P, Yan L, et al. Automatic checkerboard detection for camera calibration using self-correlation[J]. Journal of Electronic Imaging, 2018, 27(03): 033014-033014.
- [15] Bennett S, Lasenby J. ChESS-Quick and robust detection of chess-board features[J]. Computer Vision and Image Understanding, 2014, 118: 197-210.
- [16] Placht S, Fürsattel P, Mengue E A, et al. ROCHADE: Robust Checkerboard Advanced Detection for Camera Calibration[C]. European conference on computer vision. Springer, Cham, 2014: 766-779.
- [17] 王刚, 施忠臣, 尚洋, 等. 结合模板匹配和梯度峰值的对角标志自动提取方法[J]. 光学学报, 2018, 38(08): 156-163.
- [18] 骆荣坤, 刘桂礼, 孔全存, 等. 基于四邻域对角线上灰度约束的亚像素角点检测[J]. 计

- 计算机工程与设计, 2019, 40(01): 77-83.
- [19] Chen S, Meng H, Zhang C, et al. A KD curvature based corner detector[J]. Neurocomputing, 2016, 173: 434-441.
- [20] Duda A, Frese U. Accurate Detection and Localization of Checkerboard Corners for Calibration[C]. 29TH BRITISH MACHINE VISION CONFERENCE. 2018.
- [21] 陈圣峰, 陈兵, 刘坚. 基于边缘方向投影的棋盘格角点亚像素细化[J]. 光学学报, 2022, 42(08): 186-194.
- [22] Wang Z, Wu W, Xu X, et al. Recongnition and location of the internal corners of planar checkerboard calibration pattern image[J]. Applied Mathematics and Computation., 2007, 185: 894-906.
- [23] Meng C, Wang Q, Wu L, et al. A fast X-corner detection method based on block-search strategy[J]. Advances in Mechanical Engineering, 2019, 11(03): 1-11.
- [24] Sun W, Cao X, Chen B, et al. A two-stage vision-based method for measuring the key parameters of ball screws[J]. Precision Engineering, 2020, 66: 76-86.
- [25] 段振云, 王宁, 赵文辉, 等. 基于点阵标定板的视觉测量系统的标定方法[J]. 光学学报, 2016, 36(05): 151-159.
- [26] 宋超群, 许四祥, 杨宇, 等. 基于改进 FAST 和 BRIEF 的双目视觉测量方法[J]. 激光与光电子学进展, 2022, 59(08): 173-180.
- [27] Dang A T, Hsu Q C, Truong T T, Tat-Tai Truong. A simple method for dimensional measurement of ring-shaped objects using image processing technique[J]. The International Journal of Advanced Manufacturing Technology, 2021, 115(11): 3657-3678.
- [28] 唐正宗, 梁晋, 郭成. 基于摄影测量校正的斜光轴数字图像相关方法[J]. 光学学报, 2011, 31(11): 157-165.
- [29] Xie X, Ge S, Xie M, et al. An improved industrial sub-pixel edge detection algorithm based on coarse and precise location[J]. Journal of Ambient Intelligence and Humanized Computing, 2020, 11(5): 2061-2070.
- [30] Gadelmawla E S. Computer vision algorithms for measurement and inspection of spur gears[J]. Measurement, 2011, 44(9): 1669-1678.
- [31] Peng G, Zhang Z, Li W. Computer vision algorithm for measurement and inspection of O-rings[J]. Measurement, 2016, 94: 828-836.
- [32] Xiao G, Li Y, Xia Q, et al. Research on the on-line dimensional accuracy measurement method of conical spun workpieces based on machine vision technology[J]. Measurement, 2019, 148: 106881.
- [33] 宋薇, 陈兴, 沈林勇. 基于视觉的环形密封件在线检测[J]. 仪表技术与传感器, 2020, (05): 62-67.

- [34] 江涛, 李媛, 贺晨龙. 基于轮廓角点检测的螺纹关键参数视觉测量方法[J]. 电子测量与仪器学报, 2022, 36(07): 54-61.
- [35] 崔长彩, 黄富贵, 张认成, 等. 粒子群优化算法及其在圆度误差评定中的应用[J]. 计量学报, 2006, (04): 317-320.
- [36] 黄富贵, 郑育军. 基于区域搜索的圆度误差评定方法[J]. 计量学报, 2008, (02): 117-119.
- [37] 张春阳, 雷贤卿, 李济顺, 等. 基于几何优化的圆度误差评定算法[J]. 机械工程学报, 2010, 46(12): 8-12.
- [38] Huang Q, Mei J, Yue L, et al. A simple method for estimating the roundness of minimum zone circle[J]. Materialwissenschaft und Werkstofftechnik, 2020, 51(1): 38-46.
- [39] Singh D, Arunachalam N, Srinivasu D S. A novel iterative-based field search technique for roundness evaluation[J]. Procedia Manufacturing, 2021, 53: 268-275.
- [40] 林家春, 石照耀. 基于力学思想的最小外接圆度误差评定[J]. 仪器仪表学报, 2010, 31(06): 1405-1410.
- [41] 张学昌, 梁涛, 唐艳梅. 基于误差转换及图像域的圆度评定方法[J]. 中国机械工程, 2014, 25(12): 1645-1650.
- [42] 吴伟仁, 姜黎, 张之敬, 等. 以计算几何为基础的圆度误差评定算法[J]. 宇航学报, 2012, 33(06): 816-822.
- [43] 岳武陵, 吴勇. 基于仿增量算法的圆度误差快速准确评定[J]. 机械工程学报, 2008, 44(01): 87-91.
- [44] 宋慈, 焦黎, 王西彬, 等. 面向轴孔类零件圆度误差评定的改进式最小区域圆法[J]. 中国机械工程, 2022, 33(09): 1090-1097+1114.
- [45] 岳龙龙, 黄强先, 梅腱, 等. 基于最小包容区域法的圆度误差评定方法[J]. 机械工程学报, 2020, 56(04): 42-48.
- [46] 张珂, 张玮, 阎卫增, 等. 圆度误差的神经网络评定及测量不确定度研究[J]. 机械科学与技术, 2019, 38(03): 428-432.
- [47] 叶明, 唐敦兵, 赵转萍, 等. 基于人工鱼群与几何混合优化的圆度误差评定算法[J]. 南京航空航天大学学报, 2013, 45(04): 526-531.
- [48] 张尧, 刘伟鬼, 邢芝涛, 等. 采用多分类器集成方法的带钢表面缺陷图像识别[J]. 东北大学学报(自然科学版), 2012, 33(02): 267-270.
- [49] Ghorai S, Mukherjee A, Gangadaran M, et al. Automatic Defect Detection on Hot-Rolled Flat Steel Products[J]. IEEE Transactions on Instrumentation and Measurement, 2013, 62(03): 612-621.
- [50] 张鹏. 基于视觉的激光选区熔化成形铺粉质量在线监控系统研究[D]. 华中科技大学, 2017.
- [51] 师彬彬, 陈哲涵. 基于图像特征融合的粉末床缺陷检测方法[J]. 航空学报, 2021, 42(10):

- 427-438.
- [52] 李天华, 孙萌, 丁小明, 等. 基于 YOLOv4+HSV 的成熟期番茄识别方法[J]. 农业工程学报, 2021, 37(21): 183-190.
- [53] 蒲良, 张学军. 基于深度学习的无人机视觉目标检测与跟踪[J]. 北京航空航天大学学报, 2022, 48(05): 872-880.
- [54] 彭道刚, 潘俊臻, 王丹豪, 等. 基于改进 YOLOv5 的电厂管道油液泄漏检测[J]. 电子测量与仪器学报, 2022, 36(12): 200-209.
- [55] 张志远, 罗铭毅, 郭树欣, 等. 基于改进 YOLOv5 的自然环境下樱桃果实识别方法[J]. 农业机械学报, 2022, 53(S1): 232-240.
- [56] 刘胜利. 基于工业视觉的轴承尺寸在线检测技术[D]. 西安工业大学, 2014.
- [57] 范帅, 汤倚婷, 卢满怀. 基于机器视觉的轴承内外圈尺寸检测及分类[J]. 自动化仪表, 2016, 37(11): 77-85.
- [58] 郝勇, 耿佩, 温钦华, 等. 滚动轴承保持架缺陷的图像处理及模式识别方法研究[J]. 仪器仪表学报, 2019, 40(09): 162-169.
- [59] 温振市. 轴承表面品质监测系统的研究与开发[D]. 江南大学, 2013.
- [60] 陈文达, 白瑞林, 吉峰, 等. 基于机器视觉的轴承防尘盖表面缺陷检测[J]. 计算机工程与应用, 2014, 50(06): 250-254.
- [61] 郑越. 基于机器视觉的轴承内圈表面缺陷检测系统研究[D]. 沈阳工业大学, 2017.
- [62] 吴景. 基于机器视觉的轴承滚子表面缺陷检测系统[D]. 浙江大学, 2018.
- [63] 宇文旋. 基于机器视觉的轴承表面缺陷检测与分类系统研究[D]. 电子科技大学, 2018.
- [64] 吴英松. 轴承套圈外观缺陷视觉检测方法研究[D]. 沈阳工业大学, 2020.
- [65] 文生平, 周正军, 张啸言, 等. 基于计算机视觉的轴承滚子表面缺陷在线检测系统[J]. 华南理工大学学报(自然科学版), 2020, 48(10): 76-87.
- [66] Liu B, Yang Y, Wang S, et al. An Automatic System for Bearing Surface Tiny Defect Detection Based on Multi-Angle Illuminations[J]. Optik, 2020, 208: 164517.
- [67] 陈进. 基于机器视觉的轴承缺陷检测技术研究[D]. 浙江大学, 2021.
- [68] 刘良江, 王耀南. 基于机器视觉的滚动轴承外径检测系统[J]. 系统仿真学报, 2007, 19(21): 4981-4984+4989.
- [69] 李晋闽, 刘志强, 魏同波, 等. 中国半导体照明发展综述[J]. 光学学报, 2021, 41(01): 285-297.
- [70] Trujillo-Pino A, Krissian K, Alemán-Flores M, et al. Accurate Subpixel Edge Location Based on Partial Area Effect[J]. Image and Vision Computing, 2013, 31(01): 72-90.
- [71] Zhang Y, Jiang J, Zhang G, et al. High-Accuracy Location Algorithm of Planetary Centers for Spacecraft Autonomous Optical Navigation[J]. Acta Astronautica, 2019, 161: 542-551.
- [72] Li D, Ye Z, Tang J, et al. Visual Measurement of Valve Opening Area with Improved

- Subpixel Edge Location[J]. Measurement, 2022, 198: 111410.
- [73] 娄群, 吕钧瀚, 文立华, 等. 基于亚像素边缘检测的高精度相机标定方法[J]. 光学学报, 2022, 42(20): 90-98.
- [74] Karaboga D, Gorkemli B, Ozturk C, et al. A Comprehensive Survey: Artificial Bee Colony (ABC) Algorithm and Applications[J]. Artificial Intelligence Review, 2014, 42(01): 684-693.
- [75] 刘晓芳, 柳培忠, 骆炎民, 等. 一种增强局部搜索能力的改进人工蜂群算法[J]. 智能系统学报, 2017, 12(05): 684-693.
- [76] Li X, Shi Z. The Relationship Between the Minimum Zone Circle and the Maximum Inscribed Circle and the Minimum Circumscribed Circle[J]. Precision Engineering, 2009, 33(03): 284-290.
- [77] Song K, Yan Y. A Noise Roust Method Based on Completed Local Binary Pattrens for Hot-Rolled Steel Strip Surface Defects[J]. Applied Surface Science, 2013, 285: 858-864.
- [78] He Y, Song K, Meng Q g, et al. An End-to-End Steel Surface Defect Detection Approach Via Fusing Multiple Hierarchical Features[J]. IEEE Transactions on Instrumentation and Measurement, 2020, 69(04): 1493-1504.

尚德敏学 唯实惟新

