

分类号 TN911.73

U D C 621.39

密 级 公 开

学 号 2020203050



重庆科技学院

硕士学位论文

(专业学位)

金属印刷品表面缺陷视觉检测关键技术研究

论 文 作 者 谢锡坤


指导教师（校内） 李长江 教授

指导教师（校外） 邓果 高级工程师

专 业 名 称 资源与环境

答 辩 日 期 2023 年 5 月 20 日

金属印刷品表面缺陷视觉检测关键技术研究



重庆科技学院硕士学位论文 (专业学位)

论 文 作 者：谢锡坤

指导教师（校内）：李长江 教授

指导教师（校外）：邓果 高级工程师

专 业 名 称：资源与环境

二〇二三 年六月

Research on the key technology of visual inspection of metal printed surface defects



Master's Dissertation of Chongqing University of Science and Technology

Postgraduate: XiKun Xie

Supervisor: Professor Changjiang Li

Senior Engineer Guo Deng

Major: Resource and Environment

June 2023

摘 要

金属印刷品具有工艺复杂、图案丰富、视觉效果强烈等特点,在自动化生产过程中不可避免产生错印、漏印、墨污、划痕等表面缺陷,这类缺陷的产生对产品质量控制具有重要影响,因此金属印刷品表面缺陷检测意义重大。金属印刷品表面缺陷检测是光电检测中的难点,近年来,国内外学者进行了大量研究,然而金属表面缺陷检测技术目前仍然面临着如光照不均、缺陷与非缺陷之间对比度低、噪音与细微缺陷相似度高等问题,造成识别精度低、检测效率低下。目前缺陷样本检出主要依靠人工目检方式,容易产生主观依赖性强、且人工成本高问题。工业检测方法分为传统机器视觉以及深度学习方法,针对具有复杂层次图案的金属类印刷品表面缺陷任务时,基于模板匹配及区域生长法等传统机器视觉检测方法对复杂色彩图案缺陷提取具有局限性,因此采用基于深度学习方法能够有效解决复杂背景图案下的特征识别问题。本文选题来源于真实企业需求,主要研究金属印刷品表面缺陷检测,完成了以下研究工作:

1. 搭建高反光金属表面缺陷检测图像采集系统。针对被测金属印刷品表面反光特性及缺陷形貌、尺寸信息进行硬件选型与光源选择。根据该金属品表面具有的强反光特性选择照明方案,分析同轴光源显现复杂背景图像缺陷特征的有效性,设计实验平台并完成高质量金属印刷品图像采集任务。
2. 设计了一种基于生成对抗网络的高分辨率匹配迁移模型,实现缺陷图像样本扩增。通过实验采集方式获取含缺陷类别的负样本图像数量仍不能满足深度学习训练的海量数据,因此改进生成对抗网络,采用高分辨率匹配迁移算法解决图像融合生成问题。迁移模型通过控制隐变量的信息迁移同类缺陷于金属样品背景材质并生成多样性特征图像,提升了缺陷检测识别任务的准确率。
3. 提出了一种基于 EMV2-YOLOX 缺陷检测模型,实现了缺陷检测精度与检测速度的平衡要求。EMV2-YOLOX 模型采用改进 ECA-MobileNetV2 模块代替骨干提取网络模块,通过融入注意力机制加强各特征层的纹理信息提取。实验表明在钢板缺陷数据集 GCT 及 NEU 缺陷数据集中平均检测精度 mAP 值达到 0.86 与 0.68。最终迁移学习至金属印刷品表面缺陷检测数据集中检测精度 mAP 为 0.813,参数量为 8.945M,迁移实验结果表明 EMV2-YOLOX 模型解决了 YOLO 算法模型在金属类缺陷识别中的低精度与在线部署低帧率问题。
4. 设计了基于 PyQt5 的缺陷检测软件系统,实现了在线检测任务以及信息统计功能。同时设计基于 Streamlit 的网页端部署,实现了远程交互式在线检测功能。

关键词: 金属表面缺陷检测, 生成对抗网络, 隐变量, EMV2-YOLOX 模型, 缺陷检测系统

ABSTRACT

Metal prints are characterized by complex processes, rich patterns and strong visual effects, and surface defects such as misprints, omissions, ink stains and scratches. They are inevitable in the automated production process, which have an important impact on product quality control. Therefore, the detection of surface defects on metal prints has great significance. Metal printed surface defects detection is a difficult point in photoelectric detection, in recent years, domestic and foreign scholars have conducted a lot of research. However, metal surface defects detection technology is still facing problems such as uneven illumination, low contrast between defects and non-defects, noise and subtle defects similarity, resulting in low recognition accuracy and low detection efficiency. At present, defect sample detection mainly relies on manual visual inspection, which is prone to strong subjective dependence and high labor costs. The main detection methods are divided into traditional machine vision and deep learning methods. When dealing with metal printed surface defects with complex patterns relied on stacked layers, traditional machine vision detection methods such as template matching and area growth methods have limitations for complex color pattern defect extraction, so deep learning-based methods can effectively solve the problem of complex background pattern feature recognition. The topic of this paper is selected from real enterprise requirements and focuses on metal printed surface defect category and localization detection. Completed the following research work:

1. a highly reflective metal surface defect detection image acquisition system was built. Hardware selection and light source selection for the reflective characteristics of the measured metal print surface and the defect shape and size information. According to the strong reflective characteristics of the metal surface, choose the lighting scheme, analyze the effectiveness of the coaxial light source to reveal the complex background image defect characteristics, design the experimental platform and complete the task of high-quality metal print image acquisition.

2. a high-resolution matching migration model based on generative adversarial network (GAN) is proposed to realize the negative sample augmentation of defective images. The number of negative sample images containing defect categories obtained by experimental acquisition still cannot meet the massive data for deep learning training, so this paper proposes an improved generative adversarial network method, with high resolution matching migration algorithm, to solve the image fusion generation problem. The migration model migrates similar defects in metal sample background material and generates diversity feature images by controlling the information of hidden variables. The increase of defect images in the sample library

improves the accuracy of defect detection and recognition tasks.

3. an EMV2-YOLOX defect detection model based on EMV2-YOLOX is proposed to balance the requirements of defect detection accuracy and detection speed. The EMV2-YOLOX model uses a modified ECA-MobileNetV2 module instead of the backbone extraction network module to enhance the texture information extraction of each feature layer by incorporating an attention mechanism. The mean averaging precision (mAP) values are 0.86 and 0.68 in the GCT and NEU defect datasets from the steel plate. The value of mAP and parameters are 0.813 and 8.945 million respectively by migration to the metal printed surface defect detection dataset. The experimental results show that the model in this paper solves the problem of low accuracy of the YOLO algorithm model in metal-like defect recognition and low frame rate of online deployment.

4. a PyQt5-based defect detection software system is designed to implement online detection tasks and information statistics functions. The website deployment based on Streamlit is also designed and implemented to realize the remote interactive online inspection function.

Keywords: Metal printed surface defects detection, generative adversarial network, hidden variables, EMV2-YOLOX model, defect detection system

目 录

第 1 章 绪论.....	1
1.1 课题研究背景及意义.....	1
1.1.1 研究背景.....	1
1.1.2 研究意义.....	2
1.2 国内外研究现状.....	3
1.2.1 机器视觉表面缺陷检测方法.....	4
1.2.2 基于生成对抗网络的样本扩增.....	7
1.3 研究内容及主要创新点.....	8
1.3.1 研究内容.....	8
1.3.2 主要创新点.....	9
1.4 技术路线.....	10
1.5 论文章节安排.....	10
第 2 章 印刷品缺陷图像采集系统.....	12
2.1 实验平台硬件选型.....	12
2.1.1 图像采集卡.....	12
2.1.2 相机选型.....	13
2.1.3 镜头选型光学原理.....	14
2.1.4 镜头景深的配置.....	16
2.2 光源设计.....	16
2.2.1 光源选择与光照方式.....	16
2.2.2 同轴光源成像.....	18
2.3 金属印刷品缺陷图像实验方案.....	19
2.4 本章小结.....	22
第 3 章 基于 HMTGAN 网络的样本扩增.....	23
3.1 变分自编码器与生成对抗网络发展.....	23
3.1.1 变分自编码器.....	23
3.1.2 生成对抗网络原理.....	24
3.2 高分辨率匹配迁移模型.....	27
3.2.1 基于 HMTGAN 模型的基本原理.....	27
3.2.2 直通梯度优化策略.....	28
3.2.3 隐变量优化网络架构.....	30
3.2.4 HMTGAN 模型架构.....	31
3.3 实验结果与分析.....	32
3.3.1 基于 HMTGAN 生成图像评价标准.....	32

3.3.2 样本扩充实验设置.....	33
3.3.3 消融实验.....	34
3.3.4 方法比较.....	36
3.4 本章小结.....	40
第4章 基于 EMV2-YOLOX 模型的图像缺陷检测.....	41
4.1 常用图像检测方法介绍.....	41
4.1.1 基于模板匹配提取缺陷.....	41
4.1.2 连通区域扫描法与区域生长法提取缺陷	42
4.2 深度学习算法介绍.....	44
4.2.1 深度学习介绍.....	44
4.2.2 注意力机制网络模型介绍.....	45
4.2.3 YOLO 系列模型介绍.....	48
4.3 基于 EMV2-YOLOX 缺陷检测算法模型	50
4.3.1 EMV2 轻量化提取模块.....	50
4.3.2 EMV2-YOLOX 网络结构	53
4.4 实验结果与分析.....	54
4.4.1 实验设置.....	54
4.4.2 算法对比实验结果分析.....	56
4.4.3 EMV2-YOLOX 消融实验	59
4.5 本章小结.....	60
第5章 金属印刷品缺陷检测系统	62
5.1 缺陷检测方案设计.....	62
5.2 软件开发环境介绍.....	63
5.2.1 图像界面开发工具简介.....	63
5.2.2 网页开发简介.....	64
5.2.3 OpenCV 开发库.....	65
5.3 缺陷检测系统设计及实验	65
5.3.1 基于 HMTGAN 金属印刷品缺陷迁移	65
5.3.2 基于 EMV2-YOLOX 缺陷检测	66
5.3.3 软件方案设计.....	68
5.4 本章小结.....	70
第6章 结论与展望	71
6.1 本文总结.....	71
6.2 工作展望.....	72
参考文献.....	73

第 1 章 绪论

1.1 课题研究背景及意义

1.1.1 研究背景

2021 年国内印刷品产业贸易快速增长,面对严峻的国内外形势以及疫情影响,印刷品行业的内外贸易量体现了我国印刷品行业的需求。印刷品进出口是国内印刷产业进出口的主力,根据国家海关总署发布数据,国内印刷品及印刷装备、印刷器材三大类商品进出口在国内印刷产业进出口贸易总值的比重保持稳定,2021 年国内印刷产业进出口贸易总值为 240.52 亿美元,其中,印刷品进出口 172.35 亿美元、印刷装备进出口 53.64 亿美元,印刷器材进出口 14.52 亿美元。印刷品及印刷装备、印刷器材三大类商品的进出口占国内印刷产业进出口贸易总值的比重分别为 72%、22%和 6%。

2021 年国内包装印刷品进口在全球各大区域市场的分布情况为,亚洲 59%、欧洲 36%、北美洲 4%、其他区域不到 1%。国内包装印刷品出口商品可划分为瓦楞纸箱、非瓦楞折叠纸盒、纸袋和其他纸质包装容器四个品种。其中我国总印刷量以及包装印刷产业涉及全球其他国家与数额如图 1.1 所示,基于较大的基数和较高增长速度,印刷品对国内印刷产业进出口增长的贡献率为 66%,是推动 2021 年国内印刷产业进出口增长的最大贡献者。国内包装印刷品由进出口组成,截至 2022 年 2 月统计为国内印刷品、印刷装备、印刷器材进出口总值为 35.04 亿美元,同比增长 9%。其中,进口总值 7.09 亿美元(同比下降 11%),出口总值 27.95 亿美元(同比增长 15%)。同期,国内印刷品及印刷装备、印刷器材进出口贸易顺差合计 20.86 亿美元(同比增长 28%)。




图 1.1 全国印刷品进出口贸易

Fig.1.1 National import and export trade of printing products

包装印刷行业常分为纸质包装、塑料包装、金属包装三种状态,在数字化及物联网

浪潮的助推下，智能包装也应运而生，要求包装除了具有承载、保护的基本属性外，还需兼备与智能设备相连接、读取内外部环境信息、按要求做出相应反馈的能力。同时在供应链管理领域，通过 RFID（Radio Frequency Identification，射频识别技术）对货物位置进行实时追踪几乎已经成为标配，因此，在全球经济形势大变革下，重新审视并通过包装创造更大的价值，已经成为产业链上下游越来越多参与者所达成的共识。

随着市场份额的不断增加，传统制造业开始转向轻工制造。在机械行业，金属印刷品不断涌入市场，而金属制品的完整度是衡量产品成品质量的重要指标，对产品的外观要求以及产品的质量评估产生重要影响。如图 1.2 所示为金属印刷品包装，其中金属印刷存在少量最终制品的印刷，更多是各种容器、盖类、建材、家用电器制品、家具、铭牌以及各种杂用品等加工工艺过程的组成部分，这些制品大都是以丰富人们的生活为主要目的。金属类产品表面质量控制主要源于产品生产过程中产生的各类缺陷，通过缺陷类型识别进行样品检出能提升缺陷样品检出率，提高产率以及合格率。由于金属印刷品材质特殊以及工艺复杂性高，产品表面容易产生各类缺陷，针对传统人工检查的劣势，本文主要研究金属印刷品表面缺陷的视觉检测关键技术。



(a) 金属印刷板

(b) 罐装金属印刷

图 1.2 金属印刷品包装

Fig.1.2 Metal printed packaging

1.1.2 研究意义

随着科学技术发展，“数字化”逐渐成为现代印刷工业的重要力量。传统金属包装的工业技术、工艺和质检效率面临前所未有挑战，应用数字化与物联网技术能够改造生产流程、提高制造的效率和产品质量，产品包装生产模式向数字化转变成为发展趋势。目前，金属包装印刷行业普遍存在的表面缺陷为套印、变色印刷不良、凹陷，油墨浸染等。为了严格控制印刷品的废品率，印刷过程需要检测印刷品表面质量。

传统包装印刷企业质检方式是借助印刷控制条分析和印刷质量工人的技术经验，但采用人工目测方式具有较强主观性，容易产生主观性误差增加人工成本。当印刷幅面较大时，控制条所反映的信息与实际印刷画面的信息偏差增大。影响抽样检测误差率，造

成印刷材料与工时损耗。目前解决人工目检的主要方式为基于机器视觉与深度学习方法进行缺陷的定位检测与分类识别。其中采用机器视觉检测方法可提高生产效率与生产的自动化程度，且机器视觉易于实现信息集成，通过采用工控机硬件为其提供平台支撑，集成应用光源、工业镜头、工业相机、图像采集卡等，搭配后台软件系统来实现图像采集与处理、尺寸测量、识别定位、缺陷检测等功能，满足印刷品表面缺陷在线系统高速、高分辨率、高准确率的检测要求。但机器视觉的方式容易存在模板复用性差，缺陷类别不易区分的问题。采用神经网络的方式进行目标缺陷的定位与识别，能有效实现金属印刷品缺陷的识别，使精度保持稳定，实现动态实时检测功能，同时在进行其他同等类型缺陷检数据集中进行模型训练，使用迁移学习方式提升模型检测的复用性，能够有效扩充各种缺陷类型的数据库。视觉缺陷检测中图像采集质量是影响特征提取的重要影响因素之一，采用合理的光源照明方案与硬件采集选型策略搭建的实验平台部署方案成为近年的研究重点。如图 1.3 所示为近 5 年来缺陷检测研究的学术研究与论文发表量。本文研究领域能够加强印刷品行业与智能化产业的紧密结合，达到智能制造新阶段。高标准的检测方案能够保障产品质量，在目前微利化的行业现状下，通过最优化合理质量管理体系来控制生产成本、提高利润率，加强企业的综合竞争力将是包装印刷企业谋求长远发展的重要道路。




图 1.3 缺陷检测关键词图谱

Fig.1.3 Defect detection keyword mapping

1.2 国内外研究现状

目前金属印刷产品控制质量的方式仍然主要依靠人工目检方式对工件进行质量检查，存在主观性强、准确性不高、且检出效率低下等问题。工件表面的缺陷检测方法众多，其中主要检测方法为非机器视觉检测与机器视觉检测方法。

在非机器视觉检测方法中,李海洋^[1]提出投射法与评估缺陷深度的表面缺陷方法,采用了激光超声方法能够实现具有深度表面缺陷的测量,最终实现误差16%,深度为0.3mm的特征检测,但搭建激光超声检测实验平台对检测零件要求较高,在高精度零件检测中作为主要考量方式。杨思远^[2]使用三维激光的方式实现了复杂特征的目标分类算法,结果表明准确率为95.2%。邓淇天^[3]使用激光雷达获取特征数据集,提出基于多特征融合的目标检测算法,实验结果表明在多种场景下能够有效提升检测准确率,但对检测环境要求高。Han F^[4]采用镜像D形线圈和巨型磁阻传感器进行电磁涡流无损检测的方法,检测的样品缺陷被用来模拟金属添加剂制造过程中可能出现的缺陷,结果表明,该传感器能够检测铜、黄铜和铝样品中的表面和亚表面缺陷,但对于钢板类型缺陷检测有限。Ciampa F^[5]研究热成像方法,涡流激发热成像技术对缺陷物理检测的方式,提供了快速、低功耗、准确可靠的航空航天复合材料损伤评估。Dong G^[6]在陶瓷产品缺陷检测中提出无损检测方式(DNT),实验表明实时性好,效率更高。

非机器视觉方法在成本以及检测周期内具有一定局限性,因此采用机器视觉检测方法能缩短检测流程以及自动化程度部署。其中机器视觉方法按类别分为反光特性平面缺陷检测、传统缺陷检测方法、基于深度学习的缺陷检测方法。

1.2.1 机器视觉表面缺陷检测方法

(1) 基于数字图像处理的缺陷检测方法

缺陷检测对产品质量检测产生重要影响,缺陷的分类识别任务中主要存在模板匹配、SVM(Support Vector Machine)分类、HOG(histogram of oriented gradients)变换特征提取等数字图像处理方式进行图像缺陷类别判定,能够满足高精度要求。周心悦^[7]在微小型金属片进行缺陷检测任务时,提出基于连通域分析的检测方法与卷积神经网络的方法进行缺陷的分类任务,实验结果准确率达到96.85%。胡宣笑^[8]采用改进图像的差影法以及区域生长法定位缺陷,设计缺陷检测软件进行缺陷检测任务,图像分类准确率达到97%以上。针对工业印刷品表面缺陷检测的检测效率低、误判率高问题,吕明珠^[9]研究印刷品套准偏差检测技术,提出K-means聚类 and 基于区域生长的四色提取方法,能够有效提高检测精度,引入Gamma和局部动态方式解决图像不均匀问题,在检测算法设计上使用决策树方式得到分类准确率为93.3%。邢旭朋^[10]提出基于改进Perona-Malik(P-K)非线性扩散模型与图像差分模型配准的印刷品表面缺陷检测方法,实现准确率为99.97%,满足印刷品生产质量的需求。

图像处理与分析是获取缺陷信息的关键技术,基于数字图像处理方法对缺陷表面特征提取具有重意义。Xu J^[11]解决自适应油漆缺陷边缘检测问题,提出了一种基于汽车喷漆特征的蚁群优化边缘检测算法(APF-ACO)对五种缺陷类型进行分类识别,设计基于HSV颜色空间的反射区域检测算法能有效清除反光干扰性与反射区检测,实验表明识别准确率为97.76%。Zhou X^[12]提出表面缺陷检测框架,由熵率超级像素圆检测(ERSCD)

进行缺陷定位、频率调整各向异性扩散超级像素分割 (FTADSP) 与小波变换多尺度滤波 (WTMF) 进行特征提取, 并最终在数据及上进行试验, 最终相比单一模式的缺陷检测算法效果更好。Ren Z^[13]系统地讨论了光学照明、图像采集、图像处理和图像分析在视觉检测领域的历史和现状, 详细描述了深度学习在缺陷分类、定位和分割方面的应用, 并对深度学习方式在缺陷检测领域做出展望。在提高检测源图像成像质量方面, 表面光洁度与加工表面缺陷测量对于零件缺陷检测至关重要, Manish R^[14]采用Canny边缘检测和直方图分析方法研究表面光洁度对像素强度分布的影响, 并利用机器视觉系统对软钢矩形试件进行边缘检测。该方法利用像素级值观察图像的灰度强度分布, 对检测结果进行了可视化比较, 观察不同磨削表面条件下的边缘检测结果。

Zhang Z^[15]设计一种新型的移动检测平台检测涂装表面缺陷, 结合边缘、角点检测方法制作特征模板, 以模板匹配法实现印刷品表面缺陷检测功能, 但存在识别精度不高且周期长导致效率低下等问题。Hao Z^[16]在基于机器视觉方法的钢板表面缺陷检测的基础上, 研究了多维特征信息的采集、提取和融合。

综上, 以数字图像处理技术为基础的传统缺陷检测在处理简单背景图像以及缺陷形态明显特征时具有明显优势, 但在复杂金属印刷品表面缺陷检测中存在提取错误特征、识别周期长以及定位准确率不高问题。

(2) 金属反光特性平面缺陷检测

金属表面的缺陷检测对产品质量提升有着重要影响, 缺陷检测检出质量的重要因素来源于光照的合理布局, 高反光零件的缺陷检测识别率低、成像困难, 给缺陷检测领域带来巨大挑战, 目前对高反光金属零件的处理方式主要是基于图像本身光照实验条件的改变与高反光去除算法的研究。北京邮电大学沈壮壮^[17]研究汽车轮毂高反光表面特性时, 使用基于多视点特征匹配的高光去除方法消除金属表面的反光特性, 并采用目标检测网络预测缺陷特征, 实验中对比生成对抗网络下的非高光数据集缺陷采用网络结构具有良好可行性。实验中同样采用混合数据集的方式能够有效提高缺陷检测的效果。针对高反射类零件产生的划痕擦伤类表面缺陷产生的镜面特性时, 郭皓然^[18]提出基于全局阈值自适应调整的高亮表面缺陷识别方法, 使用Canny边缘检测器与空域值域滤波方式保护边缘信息, 完成阈值的自适应调整。实验结果表明能有效识别在高反光零件下的缺陷种类。

针对少反光零件的特性, 采用合理的照明方案能够有效提高检测的图像采集质量。阀板表面刀纹的反光特性对不同角度光源存在成像的差异性, 陈麒麟^[19]设计一种平面光与有向光结合的打光方式, 通过采集缺陷特征, 采用有向光源照射方案凸显缺陷细节特征, 最后使用Halcon视觉检测软件实现检测算法的自动化打光、提取、运动控制的方式, 实验表明该系统稳定, 检测精度高。工件产品的瑕疵检测中, 郝丽^[20]针对光滑物体强反射表面噪声问题提出一种基于多阈值的瑕疵检测算法, 并使用去雾算法减轻过度曝光的影响, 在不需要严苛照明环境的条件下能够有效识别瑕疵, 提高检测的效率。汽车

零件涂装缺陷检测中,周鼎贺^[21]使用一种带阻滤波器对图像进行预处理的方式减少表面反光的特性,设计了基于机器视觉的孔洞边缘缺陷检测系统,在halcon中实现缺陷检测算法,最终实验表明单次时间为320ms,准确率为97%。

在研究电子元器件镀锡引脚的不规则高反射表面缺陷中,郭志烨^[22]根据引脚的高反光特性设计并搭建了实验平台设计并改进新的光源方案,能够有效消除高反射性质表面的阴影,采用通道滤波、图像分割的方式实现产品表面缺陷的检测,构建了神经网络算法进行缺陷的分类任务。实验表明检出率达到97.9%。刘红帝^[23]采用HDRI技术缺陷检测方法,提出颜色校正模型的梯度自适应色调映射改进算法,最终满足高反光表面缺陷检测的要求,具有良好可行性。在汽车等反光零件检测中,南京航空航天大学谢芳^[24]根据汽车表面强反射特性,设计一种基于偏折技术与图像融合的采集方案,解决了反光表面微小缺陷检测困难的问题,并提出了PCA-SURF-FSC的算法提高图像配准速度与精度,最后提出基于VAR-sobel的自适应缺陷检测算法,在检测反光类镜面微小缺陷任务中效果明显。

(3) 基于深度学习的表面缺陷检测方法

机器视觉是智能制造的“智慧之眼”,用于产品表面信息检测、非接触式测量产品外观尺寸、判断物体位置坐标以及识别物体的颜色、形状等特征。金属制品表面缺陷特征不明显,并且不同类型缺陷存在较大的相似性,同种类型缺陷也不尽相同,造成传统视觉检测很大程度上依赖于图像处理结果且步骤繁琐难以满足实际生产需求。

在对金属制品的零件检测中,机器视觉方式在检测平面缺陷中,存在类别缺陷种类单一,模板的复用性不佳等特点,因此提出深度学习的方式进行类别的学习与预测。其中刘婷婷^[25]采用基于二维伽马函数的光照不均自适应算法进行图形的校正,提出改进滤波算法作为图像增强预处理,采用ResNet50的深度学习网络进行缺陷分类,最终可达到分类准确率为98.3%。王启祥^[26]设计改进卷积自动编码器,在缺陷分类任务中使用InceptionV3网络进行迁移学习轴承缺陷的分类与最优参数的调节,实验结果模型准确率达到94.69%。杨婉琪^[27]设计六种卷积神经网络进行带钢表面缺陷图像的特征提取与分类研究,实验结果最终分类准确率为94.89%,通过改进网络结构层,最终提升模型推理时间。赵丰^[28]总结了卷积神经网络与自编码类网络以及残差网络的特点,分析优缺点以及准确率的比较能够有效检测缺陷类型。传统焊缝类缺陷检测中,封雨鑫^[29]提出基于神经网络的工业钢板缺陷检测方法对缺陷类别进行预测,得到焊缝缺陷检测精度能达到97%以上,检测时间为300ms,满足工业检测要求。最新缺陷检测研究中,注意力机制的引入能够有效加强对特定缺陷类别的学习,以及模型的泛化能力,提升训练模型的检测精度。张昌凡^[30]提出YOLOV4的框架结构,融入FPANet与注意力机制的方式加强对缺陷特征提取,实验结果对灌装成品缺陷多目标检测中mAP为97.15%,检测时间为61ms,实现较高检测精度。王一鸣^[31]构建了3级视觉注意力网络,图像中的缺陷区域特征被赋予更

高的权重,较好地增强了缺陷区域特征并抑制背景区域特征。

基于传统视觉检测的高成本和低适配性问题,YS Balcioglu^[32]将深度卷积神经网络(DCNN)方法用于齿轮金属制造表面的缺陷检测。然而,与一般的DCNN模型相比,该缺陷检测方法仍有改进空间,未考虑金属表面的反射特性对算法准确性的影响。YOLO(You Only Look Once)^[33]系列的单阶段检测的计算机视觉方法实现了缺陷特征的提取和分类。Santoso^[34]将YOLO算法用于PCB的缺陷检测,提高了对PCB上损坏的路径和钻孔的检测率。Yue^[35]用CEIOU代替CIOU来改进YOLOV4^[36]算法的损失函数,并增加了注意力模块,使微小目标缺陷识别的平均精度提高了3%。但模型参数量大,硬件设备端部署困难。Zheng^[37]引入了SENet(Squeeze-and-Excitation Networks)和HaloNet^[38]的混合注意力机制模块来改进YOLOV3^[39]模型,在NEU数据集上效果较好,但由于特征增强模块不足和缺乏解耦操作,准确率和检测率不高。

YOLO模型可以大大提升检测精度要求,实现再实时检测速度,满足工业需求。因此,许多学者在基于YOLO模型的改进中解决了小尺度信息处理能力不足和检测精度与速度之间的平衡问题。在Yanju Liu^[40]提出的改进型YOLOV4模型中,采用K-means聚类方法重新定义置信度损失,以及用MobileNetv3^[41]轻量级网络替代YOLOV4骨干特征提取网络。但由于样本不平衡导致的检测效果不佳的问题没有得到解决,准确率也不能满足在线检测的要求。为了在铝带缺陷检测中实现精度和速度的平衡,Zhuxi MA^[42]提出了一种基于注意力机制的轻量级检测方法。骨干网络用YOLO-DCSAM代替了YOLOV4模型,检测速度有了很大提高。然而,在小规模的缺陷检测中,模型参数复杂且低帧率导致操作速度较慢。同样,Xuan^[43]采用坐标关注机制改进了YOLOX^[44],增强了对PCB表面微缺陷的识别,相比其他模块结构平均准确率为99.13%,对网络之前的系统也表现出色,表明YOLOX改进的潜力巨大。

1.2.2 基于生成对抗网络的样本扩增

基于视觉的表面缺陷或异常检测技术已得到长足发展,极大地推进了机械制造、半导体及电子等行业生产过程的智能化。深度学习方法因其在处理复杂背景及含有微弱缺陷的工业图像中展现出卓越的性能优势,逐渐在缺陷检测领域占据主导地位。但该方法在工业应用中面临的关键问题是训练样本不足导致模型精度普遍不高。真实工业环境中形成的工业缺陷样本存在缺陷可视性低、缺陷未知性和无规则性以及缺陷类别不均衡等问题,该问题极大削弱深度学习模型的训练性能与检测准确性。针对模型训练中含缺陷样本数据匮乏问题,目前采用数据扩增、合成与生成、迁移训练、无监督与半监督等方法进行数据的扩充。数据扩增、迁移训练与监督学习在缺陷多样化特征方面表现乏力,因此基于图像的多形态生成模型成为研究热点。近年来,由于GAN在图像生成领域的强大的能力,不少基于GAN^[45]的工作也应用于表面缺陷样本生成。GAN由生成器(generator, G)和判别器(discriminator, D)组成,其中生成器与判别器的对抗训练机制是

GAN 生成清晰图像的关键。DCGAN^[46]加入卷积神经网络代替普通池化操作增加了模型的稳定性。为了控制图像生成的范围,图像输入中添加约束能够控制图像生成的方向,目前基于风格迁移的 CycleGan^[47]加入循环一致性损失能够调控图像多样化,避免产生模式崩溃。相比 pix2pix 网络^[48]简单图像的单向迁移, CycleGan 实现了双向多种类风格迁移,结构中的 Resnet Blocks (残差结构)作为原始特征提取模块对特征细节纹理识别率不高,难以进行迁移训练,并不能解决样本不均问题。因此本文进行改进生成网络模型解决不平衡样本分布,实现样本扩充与迁移目标。

近年来,深度学习方法在工业图像检测方面发挥作用,通过卷积神经网络训练实现特征提取和分类的功能,取得了不错的检测效果。硬件性能的提升减少网络模型训练时间,在一定程度上能够缓解性能瓶颈,但模型的训练消耗大量预训练数据。为了增加原始数据样本量,大量学者使用对抗生成网络GAN实现了数据集扩充。其中SEM图像使用改进生成网络模拟缺陷解决样本不平衡^[49]。Defect-GAN基于组成层架构方式在不同纹理与外观图像背景中生成含有真实的高分辨率缺陷图像,并控制生成缺陷类别与位置^[50]。含缺陷织物纹理图案的检测中,通过改进GAN网络产生自适应缺陷特征融合无缺陷样本,加入语义分割模型检测织物样本缺陷^[51]获得精度提升。在Kolektor数据集表面缺陷检测中基于GAN网络结构,增加隐变量输入控制生成区域强度,融入注意力结构对缺陷区域的关注能够提高缺陷分割性能^[52]。产生真假难辨图像的同时,生成网络也会出现模式崩溃现象,在实际生成模型训练中容易产生训练不稳定,难收敛等问题。以GAN网络为代表的无监督学习方式在图像领域具有生成不可控的特点,生成的缺陷形态不匹配容易影响检测实验精度,因此在工业产品缺陷检测中提出半监督缺陷检测方法,融合残差网络与双学习策略方式进行多重训练具有高精度与稳定性^[53]。相比于GAN容易产生的模式崩溃问题,变分自编码器(VAE)^[54-55]使用显式极大似然估计的方式,能够近似拟合原始数据分布,使得模型收敛稳定,生成含缺陷类别的高清晰度图像。金属表面缺陷检测中提出结合VAE与CNN分类器的CCVAE模型,能生成具有较高泛化能力的缺陷图像^[56]。

1.3 研究内容及主要创新点

1.3.1 研究内容

本文选题来源于真实企业需求,针对金属印刷品高反光问题需要进行特征成像研究,实验详细介绍了各部件的选型配置以及图像采集平台搭建。目前依靠人工目检的低效率方式存在主观性强,且人工成本高,导致金属印刷品表面质量工业检测处于停滞不前状态。传统机器视觉方法缺乏完整缺陷特征建模与迁移能力,可复用性有限,对工况区分不足造成人工成本增加。而深度学习在颜色、亮度、对比度方面具有稳定性判别优势,提升背景复杂金属品的辨识度,抑制噪声对主要检测特征影响。因此,本文针对反光性金属印刷品表面缺陷的识别与定位的研究,结合传统数字化处理方法的局限性以及应用

特点,提出基于深度学习的缺陷检测模型与样本扩增方法,具体包含以下研究内容。

(1) 搭建缺陷图像采集系统

基础图像数据采集平台主要涉及实验平台硬件选型与光源选择方案,其中详细分析了相机成像原理与倍率、景深配置原则。机器视觉系统通过分析物品反射光线成像,需要对生产环境、物品材料、尺寸以及表面处理探究,LED普通光源仅适合检测一定视野范围内平面高对比度缺陷,而金属印刷品具有背景复杂,特征区分不明显,高反射性强等特点,因此采用光镜设计的同轴光源能减少噪声干扰、光损失、提升成像清晰度、均匀照射成像物体表面。通过搭建高质量图像采集平台最终得到基础图像数据库。

(2) 提出基于HMTGAN样本扩增模型

原始GAN网络存在训练不稳定,生成图像分辨率低以及复杂纹理图像容易产生模式崩溃等问题。因此本文提出基于高分辨率匹配迁移模型,通过隐变量控制生成风格指导图像生成将裂纹等缺陷特征并迁移至金属材质背景以及木板背景材质图像(扩充实验)。实验采用定性与定量研究结合的方法作为图形真实的评判标准,最终实验表明该生成模型具有良好迁移特性,因此对类似缺陷样本数据集进行迁移训练至金属印刷品表面,最终结果表明HMTGAN网络在迁移训练中生成更加“真实”样本缺陷图像,为目标识别任务在精度提升方面提供数据准备。

(3) 提出基于EMV2-YOLOX缺陷检测算法

针对金属表面缺陷检测的轻量化部署及精度的要求,本文提出EMV2-YOLOX检测网络,完成在NEU与GCT10两类钢板缺陷数据集的检测实验,实验结果表明本文检测算法在一般缺陷特征的识别具有高精度以及高帧率等特点,同时迁移训练至金属印刷品表面的缺陷检测时达到高精度、低参数量特点。满足在线检测以及客户端部署的帧率要求。

(4) 设计了一种缺陷检测软件系统

本文主要设计金属印刷品表面检测的软件系统,采用基于PyQt的图形设计基础界面布局,使用本节缺陷检测算法模型为理论依据。同时搭建了基于Streamlit的网页端远程交互式检测系统,从而简化了网页端设计的流程。通过界面可视化展示以及模型检测结果,表明基于EMV2-YOLOX模型在金属印刷品表面缺陷检测的有效性。

1.3.2 主要创新点

(1) 改进生成对抗网络模型实现样本迁移

本文提出不同材质的缺陷形态迁移新方法—HMTGAN。它采用多维隐变量在特定隐空间随机采样的方式控制缺陷与背景材质的样式变换,通过 mask 编码切换解耦合提取目标样式变换的隐码空间。与原始网络相比,改进生成网络提高了图像生成稳定性与多样化缺陷的生成形态,生成高分辨率合成图像。

网络结构中通过改进直通梯度 STE(Straight-Through Estimator)的技术,解决了引入二值化图像无法反向梯度更新的问题。无法反向传播容易产生模型训练无法更新权重系

数, 导致模型震荡不收敛。相比 GAN、CycleGAN 等模型, 添加直通梯度优化的损失函数能够带来有效的模型收敛性, 避免模式崩溃。

(2) 改进YOLOX缺陷检测算法

本文改进YOLOX缺陷检测模型提升小目标缺陷识别精度, 其中MobileNetV2-YOLOX是一个基于YOLOX算法的轻量级金属表面缺陷检测模块。MobileNetV2-YOLOX能够减轻网络模型复杂度, 解决检测任务中的低帧率与难以在线部署的问题。

同时设计融入注意力机制模块的ECA-MobileNetV2(EMV2)骨干提取网络, 通过用ECA模块替代MobilenetV2网络来增强多类形态的特征提取。EMV2的核心是将高效通道注意(ECA)与MobilenetV2模块集成, 以加强图像处理任务中小范围的特征提取。同时EMV2可以解决小规模缺陷识别精度低的问题。

1.4 技术路线

如图1.4为本文技术路线图:




图1.4 技术路线图

Fig.1.4 Technical flow chart

1.5 论文章节安排

本文研究内容分为六章, 具体安排如下。

第一章主要研究金属印刷品缺陷的研究背景与意义, 课题来源于调研现状分析缺陷检测在印刷品行业的实际应用。通过对国内外研究现状详细分析传统机器视觉表面检测

方法与基于深度学习方式的缺陷检测研究。其中应对数据不足带来的训练瓶颈问题，介绍了基于生成对抗网络的样本扩增可行性研究。

第二章主要搭建了一套图像采集系统，描述了部分重要元件的选型、相机光学部分成像基本原理以及景深配置对图像清晰度的重要影响。基于本文研究对象的高反光、复杂背景干扰特性，最后重点介绍采用同轴光源方式成像的有效性。

第三章提出了基于高分辨匹配迁移的样本扩增模型。首先详细介绍了生成对抗网络的基本原理以及图像负样本数据集扩充的重要意义；其次设计高分辨率匹配迁移模型有条件控制图像的生长范围；最后进行实验结果的对比分析以及迁移训练，成功扩充了金属印刷品表面缺陷图像数据库。

第四章提出了一种基于 EMV2-YOLOX 的缺陷检测算法。主要介绍了常用传统图像检测方法以及局限性；其次介绍了深度学习方法的基本原理与基础模型结构；最后通过实验对比分析得到本文算法在金属印刷品表面缺陷识别的高效性，同样迁移至扩充金属印刷品样本集识别效果最佳，并满足在线设备部署以及实时检测的要求。

第五章设计了一种缺陷检测软件系统。主要介绍缺陷检测软件的设计要求以及开发环境介绍，实现总体设计需求并进行可视化界面展示。本文设计基于 PyQt5 的缺陷检测系统以及网页端优化部署，完成本地客户端以及网页端的实时检测功能。

第六章总结了本文主要研究内容，提出降低模型训练难度，扩增局部特征缺陷的进一步展望。其次在企业需求前提下，对定位形式以及缺陷的具体轮廓形态上的优化调整作出讨论与研究。

第 2 章 印刷品缺陷图像采集系统

普通图像金属类缺陷图像采集系统的组建需要根据产品特点、工业安装环境以及客户需求等进行合理化配置，因此本节针对部件特性、技术参数以及工作原理进行正确选型，搭建符合高反光特性金属表面图像的采集要求。实验图像采集系统主要分为实验平台硬件的选型、相机镜头的配置与光学原理以及光源设计部分。

2.1 实验平台硬件选型

2.1.1 图像采集卡

机器视觉技术在工业生产检测、医疗检测、石油机械勘探等领域应用广泛，在整个机器视觉系统中主要有图像采集和图像处理模块。工业相机进行图像采集过程中，图像采集卡能够连接视觉系统中采集与处理两大模块，可以实现模拟信号与数字信号的转换，在整个图像采集过程中具有传递信息作用，采集中实现的模数转换称为 A/D 转换，相应的组件为 A/D 转换器。

实际工业生产中存在多系统协同作用才能保证一定的生产效率，通常图像采集卡需要同时对多相机进行模数转换才能满足系统运行需求，因此图像采集卡在实际运行过程中需要进行通道数的转换，目前市场研发的采集卡具有单双通道以及四通道的模式处理信号。采集卡中采样频率能够衡量图像采集卡对图像的处理速度与能力，使用较高频率的采集卡能够提高采集效率防止图像或视频失帧。帧和场是衡量图像采集卡中的图像采样方式，单个视频信号通过一系列帧进行渐进采样，也可以通过一个序列的隔行扫描场进行采样，而在这个隔行扫描采样的视频序列里，每帧的数据是在时间采样间隔基础上采样的，表 2.1 为图形采集卡型号参数选择。

表 2.1 图像采集卡型号参数

Table2.1 Image capture card model parameters						
型号	接口类型	总线类型	图像格式	采样频率(max)	信号源数量	图像处理调用
APX-520	I/O 输入输出	PCI-E	彩色/黑白	200KHz	16 通道	LabView
APX-3404	GigE	PCI-E×4	彩色/黑白	85MHz	4×GigE	LabView
MV-810	GigE	PCI-E	彩色/黑白	20MHz	GigE	Matlab、Lab-View、Halcon
MV-900E	GigE	PCI-E X1	彩色/黑白	40MHz	2×GigE	DirectShow 、VFW、python、LabView

图像采集卡工作特点:

(1) 图像采集卡接收视频输入端的模拟信号, 在 PC 端进行信号的采集与量化形成数字信号, 最终进行压缩编码成为数字视频或图像的方式。

(2) 图像采集关键是每一帧所需的处理时间, 当视频图像处理时间超过相邻两帧质检的相隔时间时, 将会出现丢帧现象。

(3) 采集卡是将获取视频序列进行压缩处理、存入硬盘的并行处理方式解决图像二次压缩的效率问题。

2.1.2 相机选型

相机作为图像采集系统中的重要硬件采集设备, 能够直接反映图像的成像质量。在相机的选型中重要参数有相机分辨率、曝光方式、帧速率、图像传感器、镜头 CS 接口、传输接口、相机颜色、相机维度与相机的系统等。根据检测要求, 对于静止或低速类检测时选用面阵相机检测, 而高速或滚轴运动物体采用线阵相机较合适。分辨率是相机像素点的个数, 分辨率越高图像像素越高, 图像成像质量越好, 但分辨率过高导致帧率降低, 在 PC 端进行图像处理时速度将会降低, 一般根据项目硬件设备处理图像能力进行合理选择, 在缺陷检测实验中微小缺陷检测容易受到噪声干扰, 实验一般采用 500W 像素获取图像适宜。实际运动物体会考虑帧率对检测速度的影响, 帧率越高处理速度越快, 但选用高帧率曝光容易引起图像画面的变形, 需要外加强光照射的方式会引起成本增加, 处理速度也较慢。因此帧率的选择需要根据检测物体实际运动速度进行匹配。曝光是相机中用来控制光纤照射感光元件照射时间的装置, 工业相机中的曝光方式分为全局与滚动, 一般实验研究中选择静态图像的拍摄模式选用滚动曝光, 而实际工业生产线上实时检测采用全局模式拍摄动态图像, 最终在实际运动物体图像的拍摄中可以替换为全局模式。

图像传感器是相机中的感光元件, 能够将光学图像转化为电子信号, 主要以 CCD 和 CMOS 类型为主, 两者在成像过程、集成性、速度已经噪声方面都有不同, 随着制作工艺和性能提升 CMOS 相机成为市场主流, 在成像速度方面优势更大。工业视觉检测一般采用黑白相机, 因为软件处理过程中采用灰度图模式进行图像数据处理, 而彩色相机需要进行 Bayer 算法进行色彩的转换, 与真实图像具有一定差异性。相机与镜头接口类型有 C 口、F 口、CS 口, 不同类型之间需要加装接口转换器。相机维度分为 2D 相机与 3D 相机, 其中 2D 主要检测平面物体的缺陷特征, 3D 相机主要应用于具有深度信息特征の場合。

相机传输接口是相机传输图片的方式, 常用类型为 GigE、USB3.0、CameraLink 等, 不同接口类型会影响图像采集的速度, 实验中选用 GigE 接口适配千兆网卡的方式, 同样线缆与接口需要配合使用避免接触不良。相机系统有智能相机系统与 PC-Based 系统, 智能相机集成模块多、结构紧凑, 方便使用但成本较高, 而 PC-Based 系统常用语工业

相机图像采集, 基于 PC 图像处理系统, 能够进行算法的二次开发实验, 系统中能够多相机集成的方式。如图 2.1 所示, 本文实验搭建中采用维视科技 MV-HS 系列工业相机以及 BT-MPX 系列工业镜头配置。BT-MPX 系列工业镜头是具有高性能、高分辨率的工业镜头, 同时具有低照度大通光孔径, 低畸变率的特点。该系列工业镜头有多种光学校正方式, 可最大限度的减少像差发生。成像方面对比度与清晰度较高, 采用机械设计结构紧固镜头方位, 防止镜头偏移图像视野中心, 以及设定调节后的锁定装置, 适合工厂自动化、机器视觉、图像处理等场合。




图 2.1 MV-HS 系列工业相机

Fig.2.1 MV-HS series industrial camera

2.1.3 镜头选型光学原理

地球坐标系中使用针孔摄像机标定进行测量被测物体尺寸的要求, 但孔摄像机存在针孔较小, 极少光线通过小孔到达成像平面等问题, 使用简单小孔成像模型并不能反映真实成像, 摄像机使用镜头收集光线信息, 采用长时曝光方式能获取高亮度图像。

镜头基本原理是根据光学理论中光折射定律构成, 在近轴近似原理基础上, 为了能够了解光学系统成像性质与规律, 建立理想光学模型, 即高斯高斯光学模型。高斯光学是一种理想化的光学系统, 以空气为传播介质, 同心光束通过球面透镜构成的镜头后能够汇聚到一点。光学设计目标是使镜头竞购在满足高斯光学基础上使入射角度足够大, 满足实际的应用。

真实相机镜头系统通常由多个球心在光轴上的简单厚透镜组成, 主要元素仍可以以单个镜头要素表示, 如图 2.2 所示, D 为系统光阑, 控制可以到达像平面光线的多少。其中最大程度限制通光量的光阑称作镜头的孔径光阑。ENP 为入瞳, 决定镜头入口可以接受光线的面积。EXP 为出瞳, 是孔径光阑被其后面的光学系统在像方所成的像。




图 2.2 光学原理示意图

Fig.2.2 Optical principle diagram

研究厚透镜的成像原理能够更好理解相机镜头的光学原理,有利于镜头选型。在现代光学工程中,如果已知光学系统的基点,光学系统成像的位置和大小就被确定,图 2.4 标识光线通过焦点和驻点的光路图,图中 y 和 y' 标物高和像高, f 和 f' 标识焦距, s 和 s' 标识物距和像距, x 和 x' 标识焦点到物体和像的距离。其中 x' 和 s' 为正, x 、 s 和 y' 为负值。根据相似原理可以得到式 2.1 所示,方程右端相等整理得到式 2.2。

$$\frac{h}{(-h')} = \frac{(-x)}{f} \text{ 和 } \frac{h}{(-h')} = \frac{f'}{x} \quad (2.1)$$

$$ff' = -xx' \quad (2.2)$$

$$x' = \frac{-f^2}{x} \quad (2.3)$$

光学系统处在空气介质中时,则 f 和 f' 相等,式 2.3 为成像公式的牛顿形式。将 $x = s + f$ 和 $x' = s' - f$ 引入公式 2.3 中得到高斯形式的计算成像位置公式 2.4-2.6 所示

$$f^2 = -xx' = -(s+f)(s'-f) \quad (2.4)$$

$$= -ss' + sf - s'f + f^2$$

$$\frac{1}{s} = \frac{1}{f} + \frac{1}{s'} \quad (2.5)$$

$$s' = \frac{sf}{(s+f)} \text{ 或 } f = \frac{ss'}{(s-s')} \quad (2.6)$$

像与物体的大小比 h/h' 可以用来确定光学系统的横向放大比率,调整公式 (2.1) 得到放大率 m (式 2.7),将 $x = s + f$ 带入公式,得到式 2.8,由公式 (2.5) 可知 $f/(s+f)$ 等于 s'/s 得到式 2.9-2.13。

$$m = \frac{h'}{h} = \frac{f}{x} = \frac{-x'}{f} \quad (2.7)$$

$$m = \frac{h'}{h} = \frac{f}{(s+f)} \quad (2.8)$$

$$m = \frac{h'}{h} = \frac{s'}{s} \quad (2.9)$$

$$s' = f(1-m) \quad (2.10)$$

$$s = f \left(\frac{1}{m} - 1 \right) \quad (2.11)$$

透镜成像遵循镜头前平行光轴的光线过 F' ; 过 F 点的光线通过镜头后平行于光轴; 经过 N 点的光线也会经过 N' 点, 像的几何尺寸取决于 F 、 F' 、 N 、 N' 四要素, 如公式 2.10 所知, 物距 S 变化时, 通过镜头光线相交于 F' 进行成像, 当 s 变大时, 由于 f' 不变, 所以相距变小时, 物距值将会不同。

2.1.4 镜头景深的配置

景深DOF(Depth Of Filed)是指摄像机镜头或其他成像器前沿能够取清晰图像的成像所测定的被摄物体前后距离范围。影响因素有光圈、拍摄距离与镜头焦距。光圈越小、焦距越短、拍摄距离越远都会增加景深长度, 拍摄物体更清晰。不同物距的物体在像平面上形成不同程度的模糊产生一定范围内的景深, 不同物距产生相距并不一致, 但在测量行业中需要不同物距的相同物体通过镜头成像后大小一致, 因此使用远心镜头能够调节像距不一致的问题。远心镜头的出现主要是改变工业镜头中视差不同, 在一定物距范围内使图像放大倍率不发生变化, 独特的平行光路设计能够适用在机器视觉中镜头畸变要求高的场合。实验设计中采用镜头为分辨率为5M的BT-118C1220MPS型号进行测试, 与相机接口为C口, 像面尺寸选择1/1.8"尺寸标准。

式2.12为景深公式, 其中 f 表示焦距, D 表示有效光圈孔径, c 表示可允许弥散圆直径, u 表示物距, v 表示相距, A 光圈值为 f/D , n 表示出入瞳孔径比, M 放大倍率为 v/u 。当大倍率越大时, 景深越小。因此选择合适的倍率能控制成像质量。

$$DOF = \frac{2Acf^2(u-f)(u-f+f/n)}{f^4 - A^2c^2(u-f)^2} \quad (2.12)$$

2.2 光源设计

2.2.1 光源选择与光照方式

光源影响机器视觉图像成像质量, 使被测物体的重要特征显现, 抑制非重点区域特征。通过适当光源设计照明能够使图像目标信息与背景分离, 能够降低图像处理算法的分割与识别难度, 提高系统定位与测量精度, 使可靠性与综合性能提高。其中光源设计分为光源选型与光照方式。光源设计涉及光源的选择、不同视觉构建以及定向方式图像质量增强, 选择合适光源也能使机器效率发生显著性变化。普通可见光源照明有三类: 卤素灯(光纤光源)、荧光灯光源、LED光源。其中将卤素气体的注入附着钨丝产生的卤素灯亮度较高, 但响应速度慢, 对光亮度和色温敏感度不高; 荧光灯源是电流激发水银蒸汽产生紫外辐射, 使管壁涂层发出荧光, 具有扩散性好、适合大面积均匀照射的情

况，但存在光谱分布不均，亮度较暗的缺点；LED 等寿命长，组合 LED 形成高亮度与不同形状，响应速度快，波长与形状可调的优点。综合以上光源分布性能与成本，实验平台选用 LED 光源研究缺陷成像的光源系统。


LED 光源中主要分为正面照射光源与背面光源。其中正面光源能够检测物体纹理、微小缺陷以及其他类型表面缺陷。背面光源能够检测被测物体轮廓特征以及凹坑、凸起等特征缺陷。如图 2.3 所示，按照形状可分为条形光源、环形光源、同轴光源、穹顶光源、线光源。其中条形光源能够检测物体表面划痕与零件的边缘检测以及条码的识别与定位，但存在光效性能低的问题。环形 LED 组合角度形成环形光源，能够检测裂纹缺陷以及光滑表面的划痕检测，但对反光物体表面不敏感，容易产生过度曝光，增加高亮白噪声，影响图像缺陷检测精度，且在环形光源下产生过曝光照明。穹顶光源主要针对不平整表面的反光表面检测，但针对光滑表面漫反射特性不明显。同轴光源一般应用于金属类高反光表面类型的缺陷检测以及罐装产品字符的识别。



(a) 条形光源检测字符



(b) 环形光源晶振图像检测



(c) 穹顶光源下的划痕缺陷



(d) 同轴光源下的晶片封装检查

图 2.3 不同光源条件下缺陷检测

Fig.2.3 Defect detection under different light source conditions

常见光源照明方式分为直接照明与散射照明。其中直接照明光源分为沐光方式、低角度照明、条形与聚光方式，散射照明光源分为低角度方式、扁平环状照明与圆顶方式。

如图 2.4 所示为低角度方式散射照明光源显现缺陷。





图 2.4 低角度散射照明下的划痕与污点缺陷

Fig.2.4 Scratch and stain defects under low-angle scattered illumination

沐光方式照明具有增强图像亮度、使用灵活、适用包装类印刷品要求等特点，但存在阴影以及反光现象，常用于检测平面以及纹理表面；如图 2.5 所示 LED 环形光源低角度方式照明能够有效凸显表面结构，但存在热点以及极度阴影现象，常用于纹理表面检测；条形方式照明能够适应调节光线的监督与方向，能够检测表面物体光泽、纹路以及表面特征细信息。由于金属印刷品表面存在较强反光特性与表面划痕类型缺陷，因此选用同轴光源能抑制反光和消除物体表面不平整引起的阴影，适合检测类镜面物体划痕缺陷、包装条码以及芯片破损检测等。同轴光源是从侧面将光线发射半反射镜面上，反射镜将光线反射到零件上，镜面反射光能返回 CCD 相机中，而零件表面凹凸不平处产生的漫反射光无法接收，在零件边缘形成对比度，如果来自工件的光线较远，能接收的漫反射光越多，形成更大视野的清晰度与图像对比度。



(a) 沐光方式照明

(b) LED 环形光源低角度方式照明

图 2.5 LED 环形光源低角度方式照明

Fig.2.5 LED ring light source low angle way lighting

2.2.2 同轴光源成像

同轴光源主要工作原理是通过光源控制器调节成像，光源透过漫反射进入半反射镜中，并将光线反射至物体表面，再通过物体反射镜头中，由于物体反射光与相机处于同一轴线上，因此称为同轴光。由同轴光源方式照射易产生均匀光线，成像清晰。检测反光表面划伤、裂纹、以及异物等缺陷具有良好光学效果。

光源能够影响机器视觉图像质量，目的是使被测物体的重要特征显现，抑制不重要特征。通过适当光源设计照明能够使图像目标信息与背景分离，能够降低图像处理算法的分割与识别难度，提高系统定位于测量精度，使可靠性与综合性能提高。如图 2.6 所示为涉及同轴光源示意图，本文实验采用 MV-RC198X 型号定制同轴光源的视野范围为 110*150 (mm)。




图 2.6 同轴光源设计示意图

Fig.2.6 Coaxial light source design diagram

如图 2.7 所示为使用同轴光源照射下的 PCB 板焊盘和划痕缺陷图像，通过同轴光照射图像具有光照均匀，成像清晰特点，在划痕、凹坑等难检测特征缺陷具有凸显作用。




图 2.7 同轴光源照射下的 PCB 表面焊盘和划痕缺陷检测

Fig.2.7 PCB surface pad and scratch defect detection under coaxial light source irradiation

2.3 金属印刷品缺陷图像实验方案

本文图像采集实验使用 MV-RC198X 型号同轴光源，图像采集卡选择维视 MV-900E 型号，相机选用 MV-HS 系列 CCD 工业相机，实验设计采用镜头为分辨率为 5 百万像素的 BT-118C1220MPS 型号进行测试，与相机接口为 C 口，光源控制器频率范围 1.15-1.5。其中包含支撑台架、同轴光源、相机（图像上方），最终实验整体搭建结构如图 2.8 所示。





图 2.8 实验图像采集系统


Fig.2.8 Image acquisition system

金属印刷品结构分为两层：第一层为冲压成型的金属方底；第二层为油墨层。金属进行成品印刷后一般经过上光和成型工序，涂有均匀亮光油墨能够保护墨膜，在经过墨膜处理后能增加印刷品光泽，抵抗金属罐装制品加工时弯曲以及冲击能力。当光线透过油墨层时具有较强的反光效果。经过反光薄膜作用，入射光线进入金属反光零件表面后产生反射光线，进入相机镜头后在图像中产生的光斑会影响成像质量，当采用同轴光源方式将会抑制背景噪声干扰。


表面缺陷检测中光源选择，除一般选择光源标准，将最大程度显现缺陷，加大背景区分度，其中对比度、光照度、均匀度以及稳定性作为指标参照，其中基于图像亮度的直方图能直观显示不同光照条件下图像成像质量。如图 2.9(a)中图像在直方图中比较靠左的位置，波峰比较高而且比较密集为欠曝光暗区。(b)中采用环形光源，亮度分布显示波峰出现中部偏右为过曝区，掩盖部分缺陷特征信息。(c)为采用实验搭建同轴光源成像，成像均匀，清晰度高，能凸显印刷字符缺陷特征。



(a) 自然环境光下成像及亮度直方图分布



(b) 环形 LED 光照下成像及亮度直方图分布



(c) 同轴光源下成像及亮度直方图分布

图 2.9 不同光光源下的成像特点以及亮度对比

Fig.2.9 Imaging characteristics under different light sources and brightness comparison

实验采集金属印刷品表面缺陷主要检测类别含有字符印刷缺陷 (Character-Error)、油污 (Ink-Stains)、麻点 (Pockmark)、划痕 (Scratches) 以及微小凹坑 (Tiny-pit) 五类缺陷, 如图 2.10 所示。



(a) 印刷缺陷

(b) 油污

(c) 麻点




图 2.10 实验平台采集缺陷图像

Fig.2.10 collect defect images experimental platform

2.4 本章小结

缺陷检测系统广泛应用于图像处理系统，不同系统使用的硬件选型方式存在差异，本节主要介绍了试验平台中工业相机组成部分的选型、相机镜头的成像原理、镜头基本配置与光源选型。其中重点对光源进行了方案设计，通过金属印刷品表面的反光特性进行定制化设计光源，完成实验平台的高质量图像采集工作，最终获取的高质量缺陷采集图像能为图像处理任务提供部分缺陷图像源数据库。工业环境中有限的负样本数据集，不能完全依靠图像采集端完成，因此采用更为高效的图像生成模型作为样本扩充更为合理。

第 3 章 基于 HMTGAN 网络的样本扩增

实际工业产品图像中,含缺陷样本数量不足,收集大规模含缺陷数据样本耗时,且存在的次品缺陷样本不均衡导致缺陷检测模型训练性能减弱、泛化能力不足。采用图像扩增方式拓展数据规模能大幅增强检测网络识别率。其中以 VAE 为基础的变分自编码器网络结构与噪声模拟分布的生成对抗网络方法是近年来的研究热点。因此,为了解决样本量不足,正负样本不均衡问题,本章提出基于改进生成对抗网络的方法扩充含缺陷图像数据库。实验采用公共数据集进行迁移模型训练,实现了 HMTGAN (High-quality Matched Transfer Generation Adversarial Network) 网络在金属印刷品缺陷样本集的扩充。

3.1 变分自编码器与生成对抗网络发展

基于图像生成的深度学习方式是建立人工与智能计算方面的重要途径,目前深度学习任务主要集中在计算机视觉与自然语言处理领域。在数字图像处理任务中,真实图像的样本量并不能满足人工智能所需要的海量数据,因此图像样本的扩充以及重建成为影响视觉任务精度的重要因素。其中基于深度学习方法的图像扩充主要分为生成对抗网络模型以及变分自编码器结构。生成对抗网络模型与变分自编码作为图像生成领域的主要研究热点,在样本数据生成、图像修复、图像风格装换、文本生成等领域应用广泛。

3.1.1 变分自编码器

深度学习图像扩充任务中以自编码结构为主的无监督学习方法应用在图像分类、目标识别以及图像重建等方面,相比传统方式的特征提取方法,能有效避免过拟合问题。如图 3.1 所示,自编码 AE 分为编码与解码两部分,传统 PCA 降维方式无法特征表达输入信息的有效性,而 AE 中的编码器使用卷积神经网络结构将原始图像语义信息保留为隐码空间信息,通过解码器还原原始图像空间信息,最后设置原始输入与输出图像的重构损失误差并作出微调得到训练模型参数。但存在离散空间不收敛问题、训练时间较长以及无法使用物理意义描述物理特征等问题。因此采用改进的变分自编码器能有效解决特征不足以及难以重建连续空间内图像特征信息的问题。




图 3.1 变分自编码器结构

Fig.3.1 Variational Auto Encoder structure

以 VAE 为基础的变分自编码器结构通过最大似然估计的方式拟合真实样本分布，但存在难拟合的复杂分布模型时，最大化似然函数的下边界评估变得困难。而基于迭代生成方式的生成对抗网络(Generative Adversarial Network)通过模拟复杂噪声分布生成多形态清晰图像，解决模型下边界偏差导致生成图像模糊问题。其中 GAN 的训练能提供一个最优的网络拓扑结构，表明生成的特征具有向量的计算特性。

3.1.2 生成对抗网络原理

图像样本扩增方法分为数值模拟扩增、数字图像处理以及基于深度学习图像生成。数值模拟方法主要是以马尔科夫链模型构建状态转移矩阵获取概率分布函数，但图像生成方式需要对同一时空下的序列数据严格定义，且具有复杂推断过程，导致生成效率低、收敛时间长等问题。当存在复杂概率密度不可求解问题时将难以生成满足要求的图像分布，通过生成样本的噪声模拟原始样本的概率分布能规避求解复杂的显示解。数字图像处理中图像数量的扩充依赖原始图像的数字变化方式，如图像随机裁剪、添加图像噪点、图像翻转以及仿射变换等能在一定范围内增加数据样本量，但存在样本多样性不足、特征信息单一等问题，仍无法满足一定规模数据样本的扩充。随着无监督学习方法大规模应用在图像、文本缺失等领域，基于生成对抗网络模型避开了依赖前后时间序列信息的相关性以及像素之间的逐步预测，形成了交替训练模式下能模拟原始图像的概率密度分布，最终达到高质量图像的生成。

Goodfellow 在 2014 年提出一种生成对抗模式的无监督深度学习模型框架，模型构造主要分为生成模块与判别模块。生成模块模拟原始数据样本分布形成假图像，而判别模块对原始真图像与生成假图像二分类判别真假，在判别与生成交替迭代中彼此博弈，最终达到纳什均衡，使得人眼真假难辨的图像数据。如图 3.2 所示，原始 GAN 网络中生成器 G 与判别器 D 采用多层感知器结构联结随机噪声输入与图像输出，使用深度学习中的反向传播算法与 dropout 方法训练生成对抗网络模型。




图 3.2 GAN 网络结构图

Fig.3.2 GAN network structure diagram

在生成对抗网络结构中 G 是一个生成器，负责捕捉训练数据的概率分布，并通过模拟样本空间的真实形态分布生成与源图像相似的实际图像。 D 是判别器，负责判别是否是合成数据。该框架的训练过程交替迭代，类似于博弈游戏，循环往复，最终达到纳什均衡，导致模型收敛。最后训练数据分布被成功模拟，以实现生成真实图像的目标。式 3.1 为损失函数的设计公式。

$$\min_G \max_D V(D, G) = E_{x \sim p_{\text{data}}(x)} [\log D(x)] + E_{z \sim p_z(z)} [\log(1 - D(G(z)))] \quad (3.1)$$

生成对抗网络能够模拟任意分布而不需要建立繁杂的理论模型，因此在图像重建方向应用广泛。但 GAN 网络出现的模式崩溃现象引起学者新的方法改进原始网络，模式崩溃现象主要分为两种，其一是在训练初期训练噪声的难拟合现象，导致生成图像为噪声图像。另一种产生在训练中期模型不收敛导致的训练图像单一化，而 GAN 模型生成主要为多样化的特征生成。由于卷积神经网络的发展对特征提取能够更好获得上下语义信息，避免过拟合以及模式崩溃现象，因此将原始网络中单一的感知器模型替换为复杂的卷积神经网络结构（CNN 模型）能提升判别模型的识别精度以及生成高分辨率图像。

为了提高 GAN 生成样本的质量和训练稳定性，经典的 DCGAN 被用于图像样本量的扩展。它是一个结合了卷积神经网络和无监督学习的神经网络架构。将卷积网络与强大的特征提取和专门学习数据分布的 GAN 相结合，可以显著提高生成样本的质量。与普通 GAN 相比，DCGAN 使用卷积层而不是全连接和上采样。同时批量归一化方法（BN）被应用于网络架构，它将特征层的结果输出映射到一个特定的空间，提高了模型的训练速度。DCGAN 模型的结构如图 3.3 所示。




图 3.3 DCGAN 模型结构图

Fig.3.3 DCGAN model structure

DCGAN 模型能生成局部范围内的清晰图像，但仍未解决模式崩溃现象，进一步训练中导致判别器将生成假图像作为真实图像训练产生过度生成现象。在训练中 DCGAN 同样容易导致梯度消失无法产生对抗训练过程。在新的改进方法中，基于 Wasserstein GAN (WGAN) 模型使用 Wasserstein 距离解决了 JS 散度衡量分布差异产生的不合理性以及生成图像分布与真实数据分布不重叠导致训练不稳定问题。条件 GAN 通过控制隐变量信息生成定向图像的方法能够控制图像生成。图 3.4 所示为条件 Infogan 的结构，相比原始 GAN 网络结构中增加隐变量信息输入，经过生成器 G 生成假图像中含有隐码信息，在判别网络中最终的判别信息输出为真假类别以及隐变量信息的重构。如式 3.2 所示为在原始基础上对输入限制条件模拟真实图像条件概率分布。




图 3.4 InfoGAN 结构图

Fig.3.4 InfoGAN structure diagram

$$\min_G \max_D V(D, G) = E_{x \sim p_{\text{data}}(x)} [\log D(x | y)] + E_{z \sim p_z(z)} [\log(1 - D(G(z | y)))] \quad (3.2)$$

条件 GAN 主要应用于图像文本以及图像与图像信息的转换。为了更好控制图像生成的范围,图像输入中添加约束能够引导图像的生成,目前基于风格迁移的 CycleGan 网络通过加入循环一致性损失能够调控图像多样化,避免崩溃。相比 pix2pix 网络简单形状的单向迁移,它实现了双向多种类风格迁移。图 3.5 所示为风格迁移实验中的裂纹与金属材质的迁移图像。由于自然形成的裂纹与钢板数据集中裂纹存在相似性且形态各异,满足缺陷检测任务中缺陷形态的多样性,因此采用裂纹图像迁移至钢板材质的实验,通过迭代 300 次的实验最终实现形态迁移。但最终生成图像质量不高,仅在微小部分实现小范围内迁移,因此在 3.2 节中将提出高分辨率图像特征的迁移模型实现缺陷样本的多样性扩充。




图 3.5 裂纹与钢板材质迁移

Fig.3.5 Cracks and steel material migration

3.2 高分辨率匹配迁移模型

本节首先提出基于 HMTGAN 网络合成缺陷的基本原理,该网络通过隐变量控制方式调节缺陷与背景材质的样式变换,指导图像生成高分辨率迁移图像,提高了图像生成稳定性与特征多样性。其次提出改进直通梯度方式使训练模型逐渐收敛,避免模式崩溃导致的图像失真,设计直通梯度 STE(Straight-Through Estimator)的技术解决了二值化图像无法反向梯度更新的问题。最后对优化后的隐变量与直通梯度方式进行 HMTGAN 模型整合,构建了 HMTGAN 模型的微观架构。

3.2.1 基于 HMTGAN 模型的基本原理

HMTGAN 网络整体架构如图 3.6 所示。图中 S_a 为目标缺陷数据集, S_b 为源缺陷数据集。数据集 S_a 中分别包含有冲孔(Pu)、刮痕(Scratch)、油斑(Os)、裂纹(Cr)等缺陷。设 S_a 、 S_b 的某种材质缺陷为 $[D_{a1}, D_{a2}, \dots, D_{an}]$ 类、另一种材质缺陷 $[D_{b1}, D_{b2}, \dots, D_{bm}]$ 类。假设 $[D_{a1}, D_{a2}, \dots, D_{an}]$ 中裂纹(Cr)缺陷存在样本量少不均衡问题,需要进行扩充。实验选择

$[D_{b1}, D_{b2} \dots D_{bm}]$ 中的裂纹(Cr)缺陷作为条件输入网络拟合真实分布。隐变量 z 是输入缺陷图像, 其采样 m 个随机样本 $\{l_{(1)} \dots l_{(m)}\}$, 作为学习条件指导生成图像的范围, 同时控制迁移风格与缺陷生成。引入直通梯度的方式将离散化空间变量反向传播更新参数 w 。网络训练中迭代 N 次以最大化负对数似然更新 G 参数, 得到通过真实样本数据与生成数据的欧氏距离(L_2)减少损失。判别网络中使用卷积神经网络 CBL(CNN-BatchNorm-leakyRelu)模块提取特征, 进行二分类判别真假, 最终达到均衡状态, 停止更新参数。




图 3.6 缺陷合成整体架构图

Fig.3.6 Defect synthesis overall architecture diagram

3.2.2 直通梯度优化策略

(1) 直通梯度简介

深度学习方法中连续图像以及数据存在反向传播机制, 其作用于整个网络传播过程的梯度更新, 对模型进行微调能得到最优化参数。但面对离散化数据时将会阻隔梯度反向传播导致网络模型的鲁棒性低, 因此使用直通梯度 STE (straight-through estimator) 的方式作为一种映射能进行二值化参数更新。与深度学习中的残差网络存在相似性, 在反向不可导函数更新时通过设置阈值横跨该模型端, 转向对“上游”网络结构的梯度更新。在实际应用中由于 opencv 获取的二值化图像引入新的生成对抗网络中是离散方式, 无法反向梯度更新以及衡量真实与生成概率分布的差异性, 采用直通梯度方式能够更有效解决离散图像引入连续网络的问题。如图 3.7 所示为直通梯度传播过程。




图 3.7 直通梯度反向传播

Fig.3.7 Straight through gradient back propagation

(2) 直通梯度的优化设计

深度学习中学习参数是连续可导且能不断更新梯度，但去材质后提取缺陷的过程是离散化的序列。重建缺陷误差的梯度无法传导到生成器 G 中。因此，通过引入直通梯度的方法重新定义反向传播梯度的方式对参数进行更新并计算网络输出。

式 3.3-3.5 所示，GAN 采用二值化函数 $y = \text{Sign}(x)$ 存在不可导，HMTGAN 采用拟合近似函数 clip 代替 sign 函数进行梯度权值更新，其中 $l_{|x| \leq 1}$ 为 $|x| \leq 1$ 时 sign 函数梯度为 1，其它为 0，可近似为 $H \tanh(x)$ 进行求导。

$$g_x = \frac{\partial \text{loss}}{\partial y} l_{|x| \leq 1} \quad (3.3)$$

$$H \tanh(x) = \text{Clip}(x, -1, 1) = \max(-1, \min(1, x)) \quad (3.4)$$

$$\frac{\partial \text{loss}}{\partial x} = \frac{\partial \text{loss}}{\partial y} \frac{\partial H \tanh}{\partial x} \quad (3.5)$$

式 3.6-3.8 所示，实验 Pytorch 框架中 detach 方法将连续化序列图像离散化为 D'_{src} ，与二值化得到的缺陷 D_{st} 进行能量差运算产生离散差值量 ΔS ，离散能量差引进原始连续图像 D_{src} 得到连续型差值 D^{no}_{st} ，原始二值化图像 B' 指导生成 $R(X_q, z)$ 。最终产生成与离散化图像 A 与二值化缺陷 D 得到能量差值 ΔS 。

$$\Delta S = D'_{src} - D_{st} \quad (3.6)$$

$$D^{no}_{st} = D_{src} - \Delta S \quad (3.7)$$

$$R(X_q, z) = \frac{1}{n} \sum_{i=1}^n (B'_i - D^{no}_{st})^2 \quad (3.8)$$

在优化损失函数过程中，交替训练生成器与判别器达到均衡是基本结构 GAN 的目标函数组成。开始训练阶段，条件 GAN 在条件 y （本文 S_b ）作用下生成联合概率密度 $D(x, y)$ ，匹配联合分布为 $p(G(x), y) \sim P(x, y)$ 。然后条件 GAN 的目标是取得最小化生成器

G 与真样本相似而欺骗判别器, 最大化判别器 D 能够判给假样本低分。最终获得最佳分类器 G^* 进行图像生成任务。

$$G' = \arg \min_G \max_D \mathcal{L}_{co-GAN}(G, D) = E_{x,y}[\log D(x, y)] + E_{x,z}[\log(1 - D(x, G(x, z)))] \quad (3.9)$$

在损失的优化中, 生成数据集 S_c 与真实数据集 S_a 的分布越接近越好, 引入 L2 距离衡量含缺陷样本与真实迁移目标样本之间的距离。设置可学习参数 α 。

$$\mathcal{L}_{L2}(G) = E_{x,y,z}[\|y - G(x, z)\|_2] \quad (3.10)$$

在去材质过程中产生离散化, 引入直通梯度进行反向传播时产生缺陷损失, 同样希望生成器 G 生成的网络去材质与原始样本 S_b 接近越好, 同样设置学习参数 β 。其中 sg 表示 stop gradient, X_q 表示输入图像的二值化, $R(X_q, z)$ 表示生成图像的二值化。

$$\mathcal{R}_{L2}(G) = \|X_q - (G(x, z) + sg[\|R(X_q, z) - G(x, z)\|_2])\|_2 \quad (3.11)$$

最终本节设计的目标函数为:

$$G^* = G' + \alpha \mathcal{L}_{L2}(G) + \beta \mathcal{R}_{L2}(G) \quad (3.12)$$

隐变量空间中通过 l_z 衡量相邻节点的生成图像距离, 潜在空间距离越短表现为学到更优的潜在空间。在空间中相邻时刻 θ 使用 S (spherical interpolation)方法进行采样, 并在与 VGG 特征空间距离度量 d 中得到距离均值。

$$l_z = E\left[\frac{1}{\theta^2} d(G(S(z_1, z_2; t)), G(S(z_1, z_2; t + \theta)))\right] \quad (3.13)$$

3.2.3 隐变量优化网络架构

隐变量是能控制生成图像的类型、角度、宽度等信息的语义变量, 由多个子变量 $z_1, z_2, \dots, z_n$ 组成, 相互之间独立, 可以得到:

$$p(z_1, z_2, \dots, z_n) = \prod_{i=1}^n p(z_i) \quad (3.14)$$

每一个隐码都有明确的物理关系控制变量生成图像, 具有生成信息可解释特点。隐变量输入生成器 G 产生假图像, 该图像中也包含隐变量的隐码信息。特征隐向量包含子变量空间能够存储模型训练提取的特征向量, 但图像在有限隐空间内存储含有复杂多样特征时会产生信息纠缠。通过调整特征隐码而产生对生成图片的约束时, 也会影响其他特征的调整。为了不改变其他特征信息, 只提取需要调整的隐变量会使用解耦合操作。

本节假设隐码空间分布为三个区域控制: control steel style、control wood、control crack 设置为 z_1, z_2, z_3 , 使用 GE 函数制作 mask 表进行模型切换训练操作。通过在 z_1 空间进行随机采样, z_2, z_3 隐码置零生成钢板材质风格背景。同样在模型训练中对 z_2 进行随机分布采样, z_1, z_3 隐码置零生成含木材风格背景。当 z_1, z_3 空间同时采样, z_2 进行置零

操作时指导模型生成含有裂纹缺陷的钢板背景材质。同样通过切换的方式产生含裂纹的木材背景材质。通过使用隐变量空间切换的方式能够实现解耦合操作，提取特定隐变量空间信息进行缺陷合成图像的的细节特征控制。

3.2.4 HMTGAN 模型架构

图 3.8 中 HMTGAN 的网络 G 为改进 Stylegan^[57]模型，相比于普通卷积网络提取特征能够更好理解图像风格语义信息。在输入隐变量 $z \in Z$ 中，部分向量维度控制目标材质风格区域，其它部分控制缺陷形态，使用 mask 方式遮挡(one-hot 编码)能够固定风格迁移生成缺陷，设计隐变量输入能够转换不同风格形态与缺陷的生成，固定采样中使用高斯随机采样的方式能够随机生成样本，增加泛化能力与多样性。在隐变量 Z 基础上增加原始图像数据集输入，为生成器添加条件约束产生与数据集 B 缺陷类似的图像，通过隐变量进行空间映射网络 Mapping Network F: $z \rightarrow w \in W$ 保持 512 维向量。

使用映射网络能够摆脱输入向量 z 受输入数据集分布的影响，更好地实现属性解耦合。 W 空间向量经过仿射变换 A 得到属性控制因子 S_i, b_i ，通过改变每个通道 C_i 内缩放因子与偏移系数实现图像风格控制，在 N 维向量中参数为 $2*N$ 维向量空间，最后经过归一化 AdaIN 实现不同样式与属性的缺陷生成。

$$\text{AdaIN}(C_i, S_i, b_i) = S_i \frac{C_i - \mu(C_i)}{\sigma(C_i)} + b_i \quad (3.15)$$

合成网络 (Synthesis Network) 采用底层 4×4 进行抽象层训练，进行尺寸扩张达到分辨率升高为 512×512 大小输出生成图像与判别网络进行损失求取最优生成器。经过空间维度扩张后得到 $1 \times 512 \rightarrow 16 \times 512$ 维向量。由于隐变量 Z 中同时产生风格与样式的生成变化，能够替换噪声对细节纹理的控制。实验证明这种方法的融合能不损坏数据条件下真实模拟了缺陷的分布，在相异材质上的缺陷迁移扩充目标数据集样本量。




图 3.8 HMTGAN 网络架构图

Fig.3.8 HMTGAN network architecture diagram

3.3 实验结果与分析

3.3.1 基于 HMTGAN 生成图像评价标准

(1) 主要评价标准

Inception Score(IS) 是评价 GAN 模型对生成图像质量的重要指标。本质是将生成图像 x 输入训练完成的 Inception 分类网络, 最终输出为 1000 维的标签向量, 其中向量的每一维表示样本输入的类别概率。如式 3.16 所示, 当采用熵衡量该指标时, 定义条件分布函数为 $P(y|x)$, 其中 $P(y_i|x)$ 表示 x 属于第 i 类的概率。

$$H(y|x) = -\sum_{i=1} p(y_i|x) \log[p(y_i|x)] \quad (3.16)$$

$$D_{KL}(p(y|x^{(i)})||\hat{p}(y)) = \sum_j p(y_j|x^{(i)}) \log \frac{p(y_j|x^{(i)})}{\hat{p}(y_j)} \quad (3.17)$$

$$E_x[D_{KL}(p(y|x)||p(y))] = H(y) - H(y|x) \quad (3.18)$$

又根据 KL 散度衡量 GAN 网络两个分布的差异性, 当 KL 散度越大表示差异性越大; 同样 KL 散度值越小表示分布差异性越小, 越能够表现网络模型性能更好。同样作为增益方式评价这一差异性, 得到式 3.17、3.18。式 3.19 中 $p(y)$ 为经验分布, 将生成模型产生的 N 个样本输入分类器中所得到的 N 项标签向量。通过推导得到最终 IS 指标公式 3.20 所示。

$$\hat{p}(y) \approx \frac{1}{N} \sum_i p(y^{(i)}) \quad (3.19)$$

$$\exp\left(\frac{1}{N} \sum_{i=1}^N D_{KL}(p(y|x^{(i)})||\hat{p}(y))\right) \quad (3.20)$$

IS 作为 GAN 网络的评价指标被广泛接受衡量图像生成质量, 但存在泛化能力差, 无法检测其他类别的生成问题。IS 采用的 Inception 网络在 ImageNet 数据集上训练将会形成类别的偏向性, 将会对 ImageNet 以外数据得分较低。因此当产生模式崩溃问题时, IS 指标无法探测真实性能。同样 IS 指标对像素值敏感, 单一关注生成器分布而忽略真实样本的分布导致拟合效果不理想。

另一重要指标中, 与 IS 指标不同的是 SSIM(Structural SIMilarity)评价图像相似性, 主要对生成样本以及真实样本的亮度、对比度以及结构的比较衡量。与 MSE(Mean Square Error)或者 PSNR(Peak Signal to Noise Ratio)等图像相似性评价指标不同, SSIM 作为感知模型, 能将图像亮度、对比度的改变视为结构信息的感知变化。如式 3.21 所示为 SSIM 指标计算方法, 其中 μ_x 为 x 样本均值 σ_{xy} 为样本 x, y 协方差, $C_i (i=1,2)$ 为常数 $C_i = (K_i L)^2, L$ 为像素动态范围值, 常识 K_i 取值为 0.01 与 0.03。

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (3.21)$$

SSIM 取值范围为[0,1],数值越大表示图像越相似。GAN 网络在学习分布中将会生成特征多样性,以及神经网络学习中将会忽略感知性因素,因此数值的改变并不能完全作为图像生成质量的唯一性指标。针对上述评价指标的不足,将选用合适的评价新标准。

(2) 实验采用评价标准

IS 指标的缺陷极大限制了这一评价指标的评价性能,因此采用改进 IS 评价标准的 Frechet Inception Distance(FID)^[58]与 Kernel Inception Distance(KID)^[59]指标。本文实验常用指标 FID 和 KID 衡量生成图像与原始图像的质量和多样性。FID 作为计算真实图像和生成图像的特征向量之间距离的一种度量方法,能够更好地计算生成图像与真实图像的相似性。FID 评价指标相比 Inception score 指标对模式坍塌更加敏感,对噪声产生更好鲁棒性,能够更好描述 GAN 网络多样特点。较低的 FID 与 KID 分数表明性能更好,在小型数据集上也是一个更稳定的指标。如式 3.22 所示, μ_r 、 μ_f 表示真实图像与生成图像均值, A_r 、 A_f 表示真实图像与生成图像的协方差矩阵。

$$d_0 = \text{tr}(A_r + A_f - 2\sqrt{A_r A_f}) \quad (3.22)$$

$$\text{fid} = \|\mu_r - \mu_f\|^2 + d_0 \quad (3.23)$$

在不假设真实数据集服从正态分布的假设下,使用 KID 无偏估计能够更好评估 GAN 网络的收敛程度。KID 评价核心是最大化平均差异 (MMD),寻找在不同分布样本在样本空间连续函数的函数均值,通过不同样本的均差得到平均差异 (MD),最后获得这种平均差异的最大化函数。如式 3.24、3.25 所示。其中 f^* 表示最优化函数, $k(x_i, y_i)$ 表示在 Inception 网络的 2048 维向量空间的卷卷积核大小,其中 m 是生成图像的样本量, n 是真实图像的样本量, k 是 kernel 大小。

$$\text{MMD}_f = \arg \max_{f^*} (Ef(X) - Ef(Y)) \quad (3.24)$$

$$k(x_i, y_i) = \left(\frac{1}{d} x_i^\top y_i + 1 \right)^3 \quad (3.25)$$

$$\text{MMD}_f^2(X, Y) = \frac{1}{m(m-1)} \sum_{i \neq j}^m k(x_i, x_j) + \frac{1}{n(n-1)} \sum_{i \neq j}^n k(y_i, y_j) - \frac{2}{mn} \sum_{i=1}^m \sum_{j=1}^n k(x_i, y_j) \quad (3.26)$$

$$\text{KID} = \text{MMD}_f^2(X, Y) \quad (3.27)$$

3.3.2 样本扩充实验设置

实验数据集采用钢板缺陷为目标迁移样本 A, 墙面裂缝缺陷为迁移数据集 B, 材质

差异较大的木质纹理背景为补充实验样本 C。实验基本观点是通过去材质方法将 A 数据集样本缺陷迁移至数据集 B 扩充负样本率, C 样本作为其他材质迁移对比实验。

本文提出不同材质的缺陷形态迁移是一种新的方法,能从本质上能够解决这一问题。目前科研上以生成对抗网络进行缺陷样本的扩充存在一种悖论,生成模型是一种插值生成图像的方式,对输入真实样本生成逼真假样本并拥有较强模型泛化能力,表明模型已经能够很好地理解缺陷特征,再进入其他多阶段模型训练任务存在重复训练问题。因此本节模型改进方法是将常见的含同类型缺陷特征迁移至难获取的其他材质缺陷样本中,解决各类产品中次品缺陷不足的问题。

采样中发现含裂纹缺陷类数据样本不均衡,在分类以及目标检测算法等下游任务中精度低,因此需要进行钢板裂纹数据集的扩充实验。实际观察中发现钢板裂纹缺陷与其他裂纹具有强相似性,所以源数据集采用公开数据集 Archive 中的 Crack 进行缺陷的迁移训练。同样在木质材质中裂纹缺陷为常见缺陷,存在训练数据样本少、缺陷形态单一等问题,因此作为迁移实验 2。

实验采用英伟达 GTX1660Supper(6G)、3060Ti 显卡, i7-7700 CPU @ 3.60GHz, GPU 为 cuda10.2、cuda11.1 的实验硬件设备。实验参数设置如表 3.1 所示。

表 3.1 网络训练参数对比设置

Table3.1 Network training parameters comparison setting

Generate Net		Parameter Setting				
Type	InputSize	Epoch	Bachsize	Train Mode dataA/dataB	Generator Net/Discriminator Net	Latent Dim
GAN	(64,64)	200	64	1627	Full Layer	100

续表 3.1:

Type	InputSize	Epoch	Bachsize	Train Mode dataA/dataB	Generator Net/Discriminator Net	Latent Dim
DCGAN	(96,96)	300	64	1627	CNN Layer	100
CycleGAN	(256,256)	300	8	384	CNN Layer	64
HMTGAN(Ours)	(512,512)	200	2	300	CNN Layer + Full Layer	512

3.3.3 消融实验

如表 3.2 所示,通过 crack 缺陷迁移不同材质背景下的消融实验。基于 StyleGAN 框

架改进的 HMTGAN 在 FID 与 KID 得分最低，在引入直通梯度的方法加入损失 L_{STE} 后相似性得到提升。训练时长表明模型提取特征的速度与流畅性，最终在 300 张训练集上迭代 200 次就能生成逼真图像。网络同时能够减少信道消耗，耗时更少，在少量数据集中图像生成率更高。

表 3.2 消融实验结果

Table3.2 Results of ablation experiments						
Method	Crack-Steel			Crack-Wood		
	FID	KID	Trian Time(h)	FID	KID	Trian Time(h)
Stylegan	168.27	1.1	16	160	1.62	12
HMTGAN+ L_1	120.34	1.2	6	110.32	1.41	6
HMTGAN+ L_1	120.34	1.2	6	110.32	1.41	6
HMTGAN+ L_1+L_{STE}	41.89	0.83	3	39.40	0.91	3

在材质变换中将缺陷迁移至钢板形成次品钢板(含裂纹)，增加了负样本采样率。同时为了验证算法的通用性，表明在其他材质表面上同样表现良好，扩展实验选择木材作为其它对比背景材质。结果如图 3.9 所示，在 Stylegan 对缺陷细节特征提取不令人满意，而在木材等含有纹理信息的材质中学习较好。通过分析由于缺陷样本少，在钢板材质中含有噪声信息多，产生干扰，难捕捉到复杂和不规则运动。相反，在加入直通梯度引入离散学习特征的方法无论在缺陷生成以及背景生成方面都表现更好。因为随机采样缺陷分布，在最终联合训练生成含缺陷钢板风格 style1 与 style2 木材背景中生成高分辨率缺陷迁移图像具有多样性特征。在分类与检测任务中训练分类器性能，提高模型鲁棒性。




图 3.9 不同形态缺陷迁移变换为不同材质

Fig.3.9 Migration of different forms of defects into different materials

在得到最优生成器后,通过生成图像与真实图像进行像素级相似度评价,分别在生成缺陷、背景 B、背景 C 进行相关性实验。在直观感受基础上将原始图像压缩为 3 通道,尺寸大小为 126×126 图像,进行降维处理,得到 47628 位像素值大小的相关性对比实验,将生成 4 张含钢板材质裂纹缺陷的图像与真实样本图像像素区域相关性划分。如图 3.10 所示,对比分析中采用相关性统计策略,HMTGAN 生成假样本与原始图像相关度得分较高。




图 3.10 矩阵像素相关度比较

Fig.3.10 Matrix Pixel Correlation Comparison

3.3.4 方法比较

(1) 损失比较验证

图 3.11 为采用不同损失函数的 GAN 收敛性可视化图。(a)所示的 GAN 模型损失出现震荡不收敛现象。(b)所示的 DCGAN 训练中模型稳定性较好,但收敛时间随着迭代次数的递增而明显下降。(c)所示的在 CycleGAN 循环网络结构中生成网络损失逐渐收敛,但判别器出现稳定波动,从而形成对生成假图像的弱判别性能。图中(d)为本文提出的 HMTGAN 网络收敛性可视化图,显然 HMTGAN 出现训练收敛快,在 200epoch 内训练具有一定稳定性。HMTGAN 中的损失函数策略能够大幅提高训练稳定,减少性能瓶颈,避免模型产生模式崩溃。后续实验结果也证明引入直通梯度的方法能够大提升生成器 G 的模拟真实样本分布,生成高清晰图像模块。




图 3.11 不同生成网络损失

Fig.3.11 different generation network losses

(2) 基本生成图像算法对比

GAN 网络的极大似然估计方法会产生高方差，在高维空间变现不佳导致模型在裂缝数据集上产生模式崩溃现象，出现训练过程不收敛，通过分析是因为缺陷数据集分布拟合难训练，在改进激活函数层使用 LeakyRelu 函数能改变收敛性。DCGAN 在缺陷生成较清晰图像，但不存在目标数据集的融合。CycleGAN 通过循环一致性对比损失将裂纹图像转义为钢板风格图像再生成裂纹，同时钢板材质经过裂纹转义再生成钢板材质的图像，最终图像能够融合目标材质与裂纹数据集缺陷的语义信息。HMTGAN 网络采用隐变量改变风格特点与离散型网络结构模式，将更多融合不同数据集特征，同时在能够生成高分辨率图像。图 3.12 所示为迁移训练结果。










G-Category	DataSetA	DataSetB	Intermediate Layer		output	Target
Normal-GAN						Mode Collapse
DCGAN						Not Fusion
CycleGAN						Fusion
Ours						Fusion

图 3.12 不同算法生成结果

Fig.3.12 Different algorithms generate results

（3）定性定量评价

如 3.13 所示，人工视觉可对生成图像与真实图像的纹理、灰度分布基本一致，缺陷的形态、尺度也是完全一致的。特别是缺陷与背景的分辨率、轮廓的精细度非常有利于后续的缺陷检测，即使无先验知识的人工很容易从生成图像中识别这个缺陷。后续的定性评价也能证明，HMRT 网络能获得高分辨率的缺陷再生图像，且性能上优于其它的 GAN 网络。




图 3.13 HMTGAN 网络得到从木材迁移至钢板的生成结果

Fig.3.13 HMTGAN network to obtain the generation results of migration from wood to steel plate

如表 3.3 所示。在实际结果中，在钢板材质生成的真实生成缺陷容易被评为假样本，

分析发现结果存在输入样本数据集像素较低,在生成样本时同样样本分辨率不高,难以欺骗受试者。DCGAN 与 GAN 网络在生成网络部分判别为假样本的识别率较高,并且不能实现背景切换。实验发现 HMTGAN 网络能够在裂纹缺陷到钢板缺陷转义识别率低,能够在一定程度上欺骗测试者,是因为网络在低语义空间层 4×4 进行训练,高语义空间 512×512 进行扩展控制合成样式与细节纹理信息,产生真假难辨图像。证明本文模型方法在合成图像领域的优越性。

表 3.3 人工评价得分

Table3.3 Manual evaluation score

Method	Dataset			
	Label real	Label real	Label real	Label real
	(crack→ steel defect)	(steel defect→ crack)	(crack→wood)	(wood→crack)
GAN	$0.2 \pm 0.5\%$	-	$0.1 \pm 0.5\%$	-
DCGAN	$1.8 \pm 10\%$	-	$5.28 \pm 10\%$	-
CycleGAN	$11.2 \pm 10\%$	$10.78 \pm 10\%$	$10.32 \pm 10\%$	$10.72 \pm 10\%$
HMTGAN	$27.3 \pm 0.8\%$	$11.7 \pm 0.8\%$	$32.7 \pm 0.8\%$	$13.7 \pm 0.8\%$

表 3.4 中评估了小尺寸数据集上 FID 与 KID 指标,对类别精度指标生成图像对比,可知 HMTGAN 模型的 FID 值相比其他类别方法(baseline)在精度都有较大提升。使用 Class IOU 作为用于测量真实和预测之间的相关度,关联性越强则值越高。实验发现在普通生成网络对比中类别 IOU 值得分较低,分析表明在原始 GAN 网络中生成网络存在简单提取特征,判别器性能较弱,在没有条件指导情况下容易产生无规则生成,并不能较好拟合真实样本 P_{data} 分布。CycleGAN 网络带来的循环一致性损失 $l_{identity}$ 无论在背景材质生成以及缺陷迁移过程中表现并不明显。

表 3.4 相似性与定性评价指标

Table3.4 Similarity and qualitative evaluation indicators

Method	Class IOU	FID	KID	Image Resolution
GAN	0.07	330.08	1.62	Lower
DCGAN	0.07	216.36	1.56	Middle
CycleGAN	0.08	120.76	1.18	Middle
HMTGAN	0.11	80.34	1.268	Middle

3.4 本章小结

本章首先详细介绍了生成对抗网络的基本原理以及改进方法，其次提出一种应用于跨材质表面缺陷合成的新方法：HMTGAN，通过隐变量控制风格指导图像生成的方法合成含不同类型缺陷的样本，能够解决缺陷与背景材质无法融合，生成缺陷图像范围不可控的问题。其中创新性地引入离散随机变量反向传播梯度的方法设计生成缺陷图像与二值化图像的损失函数，能够实现特征多样化，解决了缺陷种类单一，无法生成高清晰度图像问题。

最后综合采用定量与定性的方法进行图像生成的相似度评判。实验结果表明，相比于 DCGAN，CycleGAN，StyleGAN 模型，HMTGAN 的 FID 值降低了 136.02，40.42，87.96，以及 KID 值分别降低了 0.29，0.35，0.27。为了验证跨材质迁移能力，本文同样在不同纹理木料材质上进行扩展实验。最终实现在没有像素级标签的件下能最大化将图像背景与缺陷分离出来，并迁移其他类型材质图像上，同样能够在有限样本扩充中实现对象与风格转移的目标。根据本文提出的 HMTGAN 训练模型能迁移学习至金属印刷品缺陷，本文第 5 章实现金属印刷品缺陷特征的扩增实验。为深度学习缺陷识别研究奠定了数据基础。

第4章 基于 EMV2-YOLOX 模型的图像缺陷检测

图像缺陷检测算法是印刷品缺陷检测的核心技术之一，针对印刷品表面出现的油污、划痕以及麻点等表面缺陷问题，传统方法开展了基于形态学研究以及数字图像处理技术的检测方法。其中缺陷检测的难点出现在工业环境所影响的零件表面亮度、纹理、姿态匹配以及定位和识别问题，因此对于图像检测算法的选择尤为重要。本章主要介绍常用图像检测方法以及深度学习方法在金属印刷品表面缺陷检测中的应用，提出改进注意力机制的EMV2-YOLOX模型结构，在公共钢板缺陷数据集中使用该模型进行优化训练，最终迁移训练至扩充金属印刷品表面缺陷数据集，实验表明样本扩充对印刷品缺陷检测精度提升的有效性。

4.1 常用图像检测方法介绍

4.1.1 基于模板匹配提取缺陷

机器视觉主要由图像采集系统与图像处理组成，其中针对数字图像处理的研究一直是近年来的研究热点。传统方法对缺陷的识别与定位主要依赖模板匹配以及相关改进算法，图像配准任务是研究感兴趣区域物体位于目标区域的位置进而识别物体。如图4.1所示为模板匹配流程，模板匹配的核心在于制作缺陷模板，使用滑窗方式与输入待检测图像进行查找与匹配，通过计算模板与对应区域的相似度分值判定所属缺陷位置，其中相似度的计算分为系数匹配、互相关匹配、归一化互相关匹配、平方差匹配、归一化平方差匹配等方法。在复杂图案背景下，基于模板匹配方法存在计算量大、速度慢以及鲁棒性差等问题，因此使用基于特征方法的模板匹配能产生较强鲁棒性的同时快速定位缺陷特征。基于特征提取方法主要依赖对目标图像形状、纹理、颜色等特征提取，主要方法分为机器学习特征分类提取以及数字图像提取特征。




图 4.1 模板匹配流程

Fig.4.1 Template matching process

4.1.2 连通区域扫描法与区域生长法提取缺陷

连通区域是指图像中具有相同像素值且位置相邻像的前景像素点组成的图像区域，连通区域的图像域分析广泛应用于字符分割提取、目标分割以及医学图像处理等领域。通常连通区域分析处理图像是一张二值化后的图像。其中连通区域提取缺陷的主要方法为两遍扫描法，两遍扫描法（Two-Pass）是通过扫描两遍图像，区分标记图像中存在的所有连通区域。像素点附近区域的排列分为4连通区域与8连通区域两种，当采用4连通区域时第一次扫描方案如下：

- （1）从左上角开始遍历像素点，遇见第一个像素点值为 255 的点时标记为 1；
- （2）当该像素的左邻域像素与上邻域像素值无效时，设置新像素标记序列，序列号为上一个标记自增 1；
- （3）当该像素左、上邻域有一个为有效值时，将有效值像素标记序号分配给这一像素标记；
- （4）当左、上邻域同为有效值时，将标记序列号较小值分配给该像素。

当获取第一次扫描点序列号将会进行第二遍扫描：

- （1）将同一区域内扫描点序列号归纳为一个集合；
- （2）由于在第一遍扫描过程中右、下邻域将会记录信息来源，最终将同一区域内所有点同一为最小标记序列号。

如图 4.2 所示为连通区域方法形成的各区域连通图像




图 4.2 两遍扫描法形成连通区域

Fig.4.2 Two-Pass method to form connected areas

连通区域的选择对目标缺陷的分割具有重要影响，扫描法选择不同的邻域将会产生区域连通的结果不同，并且两次扫描时间较长，效率低。因此使用区域生长的方法更好提取目标缺陷区域。如图 4.3 所示，区域生长法是一种串行区域图像分割方法，区域的生长是从某像素触发，按照生长准则，满足一定条件时，区域生长结束。区域生长的优劣主要取决于初始种子点的选取以及生长准则、终止条件。基本原理是将具有相似性质

的像素点集合一起构成连通区域。区域生长算法适用于二维以及三维区域内图像灰度点的不断生长、扩张，直到形成区域连通区域。其步骤主要分为以下：

- (1) 对图像进行顺序扫描，找到第一个未分配像素，设该像素为 (X_0, Y_0) ；
- (2) 以 (X_0, Y_0) 为中心，考虑 (X_0, Y_0) 的4领域像素 (X, Y) ，如果 (X_0, Y_0) 满足生长准则时，将 (X, Y) 与 (X_0, Y_0) 合并为同一区域内，同时将 (X, Y) 存入堆栈内；
- (3) 从堆栈内取出一个单个像素，将其作为 (X_0, Y_0) ，返回步骤 b 中；
- (4) 当堆栈为空时，返回步骤 1；
- (5) 重复步骤 a-d 直到图像中的每个点都有归属时，生长结束。




图 4.3 区域生长法

Fig.4.3 Regional growth method

区域生长法应用于原始图像目标缺陷提取方法中能将像素独立区域进行最大化分割，最终实现结果如图 4.4 所示。

图像	划痕	斑点	油污	裂纹	金属品划痕
原始图像					
区域生长结果					

图 4.4 区域生长法缺陷提取结果

Fig.4.4 Regional growth method defect extraction results

区域生长法能够有效提取简单图像缺陷特征，但复杂图案图像提取存在效率低下、高分辨率图像生长缓慢、提取率较低等问题。图像存在噪声点面积多以及反光零件时该方法对目标缺陷的分割误差较大。如图 4.4 所示，金属印刷品存在强反光特性，因此引用区域生长法提取目标缺陷划痕以及印刷字符错误时无法获取该范围内细节纹理信息。针对传统方法提取缺陷特征均存在一定范围内局限性，因此采用深度学习方法能够有效提升效率以及准确率。

4.2 深度学习算法介绍

4.2.1 深度学习介绍

深度学习作为机器学习的一个分支，在自然语言处理、计算机视觉、图像合成等领域具有深度特征提取优势。早期由于各类数据大、存储成本高，可用于训练数据匮乏，计算机图像处理存在算力制约，无法满足机器学习训练需要，导致深度学习发展出现停滞。相比于大数据带来的数据规模量，深度学习可利用学习范围变小。经过 60 年曲折发展，人工智能具备强大数据支撑，人工智能系统由此开始感知、认识世界。如图 4.5 所示，初始深度神经网络（Deep Neural Network）结构由输入层、隐藏层、输出层组成，作为初步特征提取网络仅由单层全连接网络构成，无法形成反向连续传播。广泛应用于逻辑回归、机器学习的激活函数 Sigmoid，弱化了反向传播过程中容易出现梯度弥散问题，深度神经网络仍存在层数制约。随着人工智能向前发展，AlexNet 在官方大型公共数据集 ImageNet 中以平均精度 85.37%位列第一，通过增加深层网络结构、改进激活函数、减弱过拟合的 Dropout 方式表明该网络结构设计的优越性。以卷积层、池化层、全连接层的堆叠结构开始作为深度学习网络基础结构。




图 4.5 DNN 神经网络

Fig.4.5. DNN network structure

神经网络层经过迭代发展，图像处理领域逐渐发展为图像分类、目标检测、图像分割等主流视觉检测任务。如图 4.6 所示为 VGG 模型网络，通过加深 AlexNet 网络得到的 VGG 分类网络提升网络性能，但存在参数量较大，耗费更多计算资源导致内存占用

更大,在移动设备端进行工业部署存在困难等问题,因此在不损失模型精度条件下的轻量化网络成为主流改进模型。




图 4.6 VGG 模型结构

Fig.4.6 VGG network structure

4.2.2 注意力机制网络模型介绍

传统卷积神经网络内存需求高、运算量大导致无法在移动设备以及嵌入式设备上运行,而轻量级网络专注于移动端或嵌入式设备中,在准确率小幅度下降前提下极大减少了模型参数与运算量,因此对本节将介绍轻量级神经网络的基本原理与网络结构。针对轻量级网络带来的优越性,将在 4.3 节中提出改进模型适应嵌入式设备的实时检测性能要求,同时提升网络对金属印刷品缺陷的检测精度。

(1) MobileNet 系列

Google 团队在 2017 年提出 MobileNet 网络并在移动端设备中测试,最终实验表明该网络相比于 VGG 分类网络模型在准确率降低 0.9%的基础上,模型参数仅为 VGG 的 1/32。MobileNet 系列主要分为 MobilNetV1^[60]、MobileNetV2^[61]以及 MobileNetV3 网络。MobilNetV1 主要采用深度可分离卷积,同时引入新的卷积核个数的超参数 α 以及控制输入图像尺寸的 β 。当引入深度可分离卷积模块将减少模型参数量。其中为 D_F 为输入矩阵的高和宽, D_K 表示卷积核大小, M 表示输入矩阵的深度, N 表示输出矩阵的深度,即卷积核个数,如式 4.1, 4.2 所示,普通 CNN 卷积相比深度卷积参数量增加 9 倍数量,因此采用深度可分类卷积能有效提升模型硬件端部署能力。

$$P_2 = D_K \cdot D_K \cdot M \cdot D_F \cdot D_E + M \cdot N \cdot D_F \cdot D_E = \frac{1}{N} + \frac{1}{D_K^2} = \frac{1}{N} + \frac{1}{9} \quad (4.1)$$

$$P_1 = D_K \cdot D_K \cdot M \cdot N \cdot D_F \cdot D_F \quad (4.2)$$

MobileNetV2 沿用 MobileNetV1 的深度可分离卷积,同时增加倒残差结构,相比于

MobileNetV1 网络准确率更高, 模型参数量更小。如图 4.7 所示为普通残差与倒残差结构, 将普通卷积替换深度可分离卷积时效果模型明显提升。




图 4.7 MobileNetV2 倒残差结构

Fig.4.7 MobileNetV2 inverted residual structure

MobileNetV3 相比 MobileNetV2 引入了 SE 注意力机制对通道进行权重比例的分配, 同样 V3 在 V2 基础上更新 block 结构, 使用 NAS 搜索参数, 重新设计耗时层的结构, 其中采用 swish 函数作为激活函数部分时, 由于移动设备加速推理过程中需要有量化过程, ReLU 激活函数对特征信息造成大量损失, 因此重新定义设计新的激活函数 H-swish 函数。如式 4.3-4.7 所示。

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (4.3)$$

$$ReLU6(x) = \min(\max(x, 0), 6) \quad (4.4)$$

$$h-sigmoid = \frac{ReLU6(x+3)}{6} \quad (4.5)$$

$$swishx = x \cdot \sigma(x) \quad (4.6)$$

$$h-swish[x] = x \frac{ReLU6(x+3)}{6} \quad (4.7)$$

MobileNetV3 中的 SE 模块首先为每个通道独立采用全局平均池化, 然后使用两个全连接 (FC) 层以及非线性 Sigmoid 函数来生成通道权重。两个 FC 层旨在捕获非线性跨通道交互, 其中涉及降低维度以控制模型的复杂性。尽管此策略在后续的通道注意力模块中被广泛使用, 但降维会给通道注意力预测带来副作用, 并且捕获所有通道之间的依存关系效率不高且不必要。

如图 4.8 为 MobileNetV3 中 block 结构, 输入尺寸进行 1×1 升维, 使用线性激活函数得到不同特征层的 feature map, 使用 3×3 深度可分离卷积加速特征提取, 得到的特征层 3 作为注意力机制 SE 层的输入, 进一步池化操作, 将每一个通道进行全连接加 Relu 激活函数获取单层通道信息, 通过全连接 HS 函数获得输出通道信息, 将特征层 3 与注意力机制 SE 层进行通道权重赋值匹配, 得到输出特征层 4, 最后进行 1×1 普通卷积进行降维。

SE 层包括 Squeeze 以及 Excitation 操作部分, 在卷积核大小 $V = [x_1, x_2, x_3, x_4 \dots x_c]$, 式 4.8 中 x_c 代表卷积核个数, 输出 $O = [u_1, u_2, u_3 \dots u_c]$, 在进行系列卷积操作后学习得到混合空间特征信息, SE 模块加入能够直接续通道信息。@ 表示卷积操作方式, x_c^s 表示 S 通道上的二维卷积。




图 4.8 MobileNetV3 结构

Fig.4.8 MobileNetV3 architecture

(2) GhostNet 和 EfficientNet 轻量级网络

华为诺亚方舟实验室 2020 年设计一种全新的轻量级 GhostNet^[62]神经网络结构。针对深度学习网络中出现丰富纹理信息的冗余特征图具有重要价值, 因此可以通过计算量更低的操作生成这类特征图, 生成特征图与原始特征提取存在 Ghost 一样的高相似性。最终能够在保证良好检测效果前提下, 减少模型参数以及提升模型的执行速度。其中该网络的主体结构包括 Ghost 模块代替普通卷积的方式得到压缩特征图信息, 实现高性能目标的特征分类。如图 4.9 所示为 Ghost 模块。该模块采用 1×1 普通卷积进行特征整合, 其次使用计算成本低的深度可分离卷积生成 Ghost 特征图, 同样采用残差连接进行基于高低上下语义信息的通道堆叠, 最终达到参数量优化适配移动端或嵌入式设备中。GhostNet 作为简单即用的分类网络, 作为初步特征提取的 YOLOV4 主干网络能够有效提升模型整体精度与检测速度, 本节实验中同样采用 Ghost-YOLOV4 作为对比网络评价缺陷检测的整体性能。




图 4.9 Ghost 模块结构

Fig.4.9 Ghost Module Structure

2019 谷歌提出 EfficientNet^[63]进行网络结构的创新，关注目标不仅存在于堆叠的数量，而在于模型更好学习特征信息，能提升测速度与压缩参数量。EfficientNet 网络通过网络深度实现深层次信息提取能力，同时改变特征层提取数量以及在大尺度输入图像中准确率继续提升的能力。EfficientNet 网络中主要由 Efficient 模块的叠加产生，同样结合深度可分离卷积结构集合注意力机制的倒残差架构，如图 4.10 所示主要路径使用 1×1 卷积升维，结合 3×3 与 5×5 的逐层卷积进行特征点的特征提取，提取完成使用通道注意力机制，最终同样采用 1×1 卷积进行降维。Efficientdet^[64]的主干提取网络主要以 EfficientNet 作为主体结构的特征提取，本节实验中采用 Efficientdet 网络结构作为对比网络评价缺陷检测的整体性能。




图 4.10 Efficient 模块结构

Fig.4.10 Efficient module structure

4.2.3 YOLO 系列模型介绍


(1) YOLO 缺陷检测模型

YOLO (You Look Only Once) 模型是目标检测任务中普遍使用的单阶段检测模型，相比于双阶段模型在模型适用性以及模型训练等方面具有显著优势。YOLOV1 中提出单一 CNN 网络结构实现端到端目标检测方法，实现快速实时监测，但存在邻近区域漏检、小目标特征无法识别问题。YOLOV2 改进检测框架网络与批归一化方式等提升检测精度同时，提升误检率，但存在感受野增加导致小目标缺陷漏检。YOLOV3 引入残差网

络结构增加模型提取性能,并区分大、中、小预测分类框,实现不同尺度下的缺陷预测。

YOLOV4 是使 YOLO 系列性能提升最快的目标检测算法。在原有目标检测框架基础上,分别在加强特征提取、增强网络模型非线性、防止过拟合方面具有显著影响。在版本不断迭代过程中弥补了许多缺陷。但 YOLOV4 存在的模型参数较大,在硬件设备上运行速度低等问题。因此针对 YOLOV4 模型主干网络冗余部分进行轻量化的改进。

如图 4.11 所示为 YOLOV4 整体模型结构, YOLOV4 模型主要分为初步特征提取模型 CSPDarkNet53、特征增强提取模块 SPP 与 PAN 模块以及预测特征模块。相比传统 YOLOV3 模型系列,主干提取网络由 DarkNet53 替换成了由多个残差堆叠形成的 CSPDarkNet53 网络结构,在特征颗粒度提取方面具有重要提升。特征金字塔中的 SPP 与 PAN 增强模块的引入能融合上下层不同特征通道的语义信息,在连通特征空间中对微小难检测特征具有更优对的特征处理能力。预测特征模块主要针对提取的 19、38、76 三种尺度的特征预测,分别预测不同尺度下的大目标、中目标、小目标物体。YOLOV4 在平衡精度与检测速度的优势在图像检测领域的目标物体识别领域快速发展。



(2) YOLOX 检测模型

YOLOX 模型是基于 YOLOV5 以及 YOLOV4 模型的改进版本。其中使用 CSPDarkNet 作为特征主干提取网络对图像进行特征强提取。主干提取模型中 Focus 将宽度、高度信息集中在通道空间,使输入通道扩充了 4 倍,采用这种方式可以减少下采样带来的信息损失以及减少参数量和模型复杂度。YOLOX 中同样适用 YOLOV4 中的路径聚合网络 (PANet),能够更好表达语义和位置信息。新的变化中相比于以前 YOLO 系列改变中采用无 Anchor 的检测模型,以及进行解耦合头操作。能够更精确判断类别信息属于回归预测框内。因此,作为改进的原始模型能够在精度提升以及轻量化中有更多表现。YOLOX 的结构如图 4.12 所示。




图 4.12 YOLOX 模型结构示意图

Fig.4.12 YOLOX model structure diagram

4.3 基于 EMV2-YOLOX 缺陷检测算法模型

4.3.1 EMV2 轻量化提取模块

通道数据能够控制缺陷表面的纹理、颜色以及形状等信息。各通道之间的信息交互通过权重不同进行整合能够加强对各特征层的信息提取,但 SENet 代表的通道注意力机制采用降维操作会对通道注意力的预测产生负面影响,且获取依赖关系效率低。因此本文采用 ECA 的跨信道交互策略,能够明显监督模型复杂度的同时保持检测性能提升。同时,拥有深度可分离卷积的轻量级网络 MobileNetV2 在嵌入式移动设备端具有实时检测速率快,检测精度较高的特点。因此采用 ECA-MobileNetV2 模型作为主干提取网络进行特征提取能够有效改进复杂度、精度以及轻量化设备部署难题。

通道注意机制已被证明在改善深度卷积神经网络(CNN)的性能方面具有巨大潜力,代表性的方法是挤压和激励网络(SENNet),以及用于深层 CNN 的有效通道注意力网络(ECA)^[65]。为了关注每个通道的信息交互,ECA 注意力机制采用了一种不依赖降维的跨通道交互技术。通过考虑每个通道及其 k 个近邻来捕获本地跨通道交互,有效提升检测模型特征提取能力和效率。ECA 模块创新地使用一维卷积来整合通道,并在图 4.13 中的 GAP(全局平均池)操作后共享多通道信息的权重。它利用局部信息交互可以增加相邻层之间的对角线相关性,并且可以减少训练参数,提高检测模型的特征提取能力和效率,不容易过拟合。在公式 4.10 中,通道 " C " 和卷积核大小 " k " 可以对不同通道数量的卷积核大小进行自适应选择。 k 代表局部跨通道交互覆盖。同时设定 γ 和 b 为模型的超参数器。

$$W = \begin{bmatrix} w^{1,1} & \dots & w^{1,k} & 0 & 0 & \dots & \dots & 0 \\ 0 & w^{2,2} & \dots & w^{2,k+1} & 0 & \dots & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & \dots & 0 & 0 & \dots & w^{c,c-k+1} & \dots & w^{c,c} \end{bmatrix} \quad (4.9)$$

$$C = \phi(k) = 2^{(\gamma * k - b)} \quad (4.10)$$

$$k = \psi(C) = \left\lfloor \frac{\log_2(C)}{\gamma} + \frac{b}{\gamma} \right\rfloor_{\text{odd}} \quad (4.11)$$




图 4.13 ECA 模块结构

Fig.4.13 ECA Module Structure

MobileNetV2 网络是一种使用深度可分离卷积及倒残差结构来构建的轻量级深度神经可分离网络模型。如图 4.14 所示，深度可分离卷积 DWConv2D (Depth-separable convolution) 由深度卷积 DW (depth-wise) 和点卷积 PW (point-wise convolution) 组成，卷积核个数与输入通道相同，大小通常使用 3×3 。式 4.12 为深度卷积 DW 表达式，式中： G 为输出特征图， K 为 $W \times H$ 的卷积核， X 为输入特征图， m 表示特征图的第 m 通道， i 、 j 表示输出特征图在第 m 通道上的 i 、 j 坐标； w 、 h 为第 m 通道的卷积核权重元素坐标。逐点卷积和普通卷积基本相同，其卷积核的尺寸设置为 1×1 。深度可分离卷积 DwConv2D 以较少的参数和计算量代替标准卷积，计算量仅为标准卷积的 $1/9$ 。

$$G_{i,j,m} = \sum_{w,h} K_{w,h,m} \cdot X_{i+w,j+h,m} \quad (4.12)$$




图 4.14 深度可分离卷积(DwConv2D)结构

Fig.4.14 Depth-separable convolutional (DwConv2D) structures

如图 4.15 所示, ECA-MobileNetV2 模块主要由普通卷积模块 CBS (Convolution-BatchNorm-SiLU Function)和 ECA-Block 模块组成。使用残差网络的特点是容易优化,并且能够通过增加网络深度来提高准确率。其内部的残差块使用了跳跃连接,缓解了在深度神经网络中增加深度带来的梯度消失问题。结合了注意力机制的 MobileNet 残差结构能够使网络融合通道信息,能够增强提取微小缺陷所在位置以及分类的准确率。




图 4.15 ECA-MobileNetV2 结构

Fig.4.15 ECA-MobileNetV2 structure

本节改进 ECA-MobileNetV2 结构如图所示。输入层尺寸大小为 416,为了减小参数量与模型复杂度,采用 YOLOX 中的 Focus 结构进行通道扩张,接着使用 CBS 结构将通道调整为 64。同样经过 CBS 与 CSPlayer 结构的组合多次重叠得到输出特征层 1 与输出层 2,最终得到通道数为 256 与 512。在骨干提取网络中采用 SPP 结构进行特征加强提取,最后经过最后的 CSPlayer 结构得到输出结构层 3。ECA-MobileNet 结构如图 4.16 所示。




图 4.16 ECA-MobileNet 整体结构

Fig.4.16 ECA-MobileNet overall structure

4.3.2 EMV2-YOLOX 网络结构

如图 4.17 所示, EMV2-YOLOX 网络结构主要由三部分组成, 包含骨干特征提取网络, 强特征提取网络以及预测网络。在输入部分采用 416 大小图像作为输入, 经过 4.3.1 节中 ECA-MobileNet 网络整合得到初步提取网络的三个特征层 Pri-Layer1, pri-Layer2 和 Pri-Layer3。其中 CSPlayer 主要由 CBS (卷积层与归一化层以及激活函数层) 组成, 本节中多次使用 CSPlayer 结构代替普通卷积方式加对深层网络结果进行有效提取。经过 PANet 加强提取网络能够对语义信息和定位信息传递到不同特征层, 多信息层的尺度融合能够进一步充分提取缺陷的特征信息。在最终的预测特征层采用 Anchor-free 定位减少预测结果数量。最后利用 SimOTA 方法进行预测网络选择, 得到最终预测结果。通过对目标特征的多尺度特征融合和重复上采样和下采样操作, 输出的特征图有三种不同尺度。




图 4.17 EMV2-YOLOX 网络结构

Fig.4.17 EMV2-YOLOX network structure

4.4 实验结果与分析

4.4.1 实验设置

实验采用英伟达 GTX1660Supper(6G)显卡, Intel(R)Core(TM)i7-7700 CPU@ 3.60GHz 为实验硬件设备, 采用 Pytorch 学习框架在 win10 操作系统平台搭建检测模型。在两类金属缺陷数据集进行检测实验, 比较传统的多尺度融合检测网络 FasterRCNN、SSD300、融入注意力的 MobileNetV3 轻量化网络 MV3YOLOV4、EfficientDet、轻量化网络 GhostYOLOV4, 实验对比 EMV2-YOLOX 检测精度、参数量以及帧分辨率 FPS 的变化情况。实验中发现模型收敛速度上 100 次迭代效果与 200、300 次 epoch 迭代效果区别不明显, 实际模型训练时模型在 100 个 epoch 时模型已经完全收敛, 并不需要迭代多次训练, 最后实验采用模型中 MobileNetV2_YOLOV4 在 VOC 数据集训练权重作为预训练参数迁移学习到本次缺陷检测实验模型的训练权重, 其中设置 Batch_size 大小为 16, 初始 50 个 epoch 采用学习率为 $1e^{-3}$, 50 至 100 个 epoch 采用学习率为 $1e^{-4}$ 进行冻结权重训练, Batch_size 设置为 8。

基础数据集采用天津大学工业金属表面缺陷数据集 (GCT10 数据集) 以及东北大学钢板表面缺陷数据集 (NEU 数据集)。GCT10 数据集采用 512×512 大小输入, 一共 3500 张图像, 表面缺陷有 10 类, 包含冲孔 (Pu)、焊缝 (Wl)、新月形缝隙 (Cg)、水斑 (Ws)、油斑 (Os)、丝斑 (Ss)、夹杂物 (In)、轧坑 (Rp)、折痕 (Ce)、腰部折痕 (Wf)。NEU 数据集采用 200×200 尺寸大小为输入, 表面缺陷有 6 类, 每类 300 张, 包含轧入氧化皮 (Rs), 斑块 (Pa), 裂纹 (Cr), 麻点 (Ps), 夹杂物 (IN), 划痕 (Sc)。

实验结果采用准确率 P (Precision) 和召回率 R (Recall), 以及两类数据集的 mAP 为模型评判标准, 其中 Precision 表示分类器分类准确的比例, Recall 表示分类器识别正确占正类的比例。以 Precision 和 recall 组成面积类的平均值 mAP 作为网络模型的整体性能指标, 其中 Precision 和 Recall 计算公式如式 4.13、4.14:

$$P = \frac{TP}{TP+FP} \quad R = \frac{TP}{TP+FN}, \quad (4.13)$$

$$mAP = \frac{\sum_{i=0}^n AP(i)}{n} \quad (4.14)$$

其中 TP 为正确预测数量, FP 为被错误预测正确样本数量, FN 为错误预测负样本数量, n 为检测缺陷类别数量, AP 为各缺陷种类精确度。

为检测图像在轻量化模型的使用, 以单张图像推理时间(ms)以及 FPS 作为模型检测速度评判标准。本文算法 EMV2-YOLOX 在 NEU 数据集上的检测及 GCT10 数据集上的预测情况如图 4.18 和图 4.19 所示。





图 4.18 NEU数据集预测缺陷

Fig4.18. NEU prediction of various defects






图 4.19 GCT10 预测缺陷

Fig.4.19 GCT10 prediction of various defects

4.4.2 算法对比实验结果分析

实验将 EMV2-YOLOX 与其他主流的轻量级网络算法以及传统算法进行了比较，如表 4.1 所示。

EMV2-YOLOV4 与 EMV2-YOLOX 模型精度普遍高于其他网络结构，表明引入 EMV2 注意力机制的有效性。其中除了 Wf，EMV2-YOLOX 算法对 GCT10 上所有缺陷的检测准确率 AP 值最高。相比之下，Pu、Wl 和 Cg 类缺陷的检测精度在 95%以上。平均检测精度 mAP 达 0.733。该相比于 FasterRCNN^[66]和 SSD300^[67]增加了 27.6%和 40%，与带有多尺度轻量级网络的 EfficientDet 相比增加了 39.5%，而对于纳入轻量级模块 GhostNet 的 GhostYOLOV4 模型来说增加了 10%。在 NEU 数据集上，所有缺陷的检测精度均为最高，mAP 值为 0.877。实验中精度和召回率指标的可视化情况见图 4.20 和图 4.21。

表 4.1 算法对比

Table4.1 Comparison of algorithm accuracy						
Types	AP					
	Faster RCNN	SSD300	EfficientDet	GhostY-OLOV4	EMV2-YOLOV4	EMV2-YOLOX
Pu	0.55	0.59	0.61	0.94	0.99	1
Wl	0.52	0.70	0.03	0.95	0.98	0.97
Cg	0.88	0.58	0.93	0.96	0.97	0.96
Ws	0.70	0.34	0.71	0.78	0.84	0.94
Os	0.51	0.28	0.30	0.68	0.81	0.72
Ss	0.43	0.44	0.52	0.70	0.80	0.85
In	0.07	0.03	0.02	0.35	0.44	0.29
Rp	0.40	0.14	0.10	0.22	0.32	0.34

续表 4.1:

Types	Faster RCNN	SSD300	EfficientDet	GhostY- OLOV4	EMV2- YOLOV4	EMV2- YOLOX
Ce	0.36	0.20	0.13	0.58	0.59	0.68
Wf	0.15	0.03	0.03	0.17	0.10	0.58
GCT10_mAP	0.457	0.333	0.338	0.633	0.684	0.733
Cs	0.50	0.24	0.38	0.46	0.59	0.78
IN	0.86	0.35	0.65	0.88	0.89	0.85
Pa	0.96	0.66	0.87	0.97	0.96	0.94
Ps	0.83	0.61	0.67	0.85	0.88	0.90
Rs	0.73	0.34	0.59	0.80	0.83	0.81
Sc	0.96	0.41	0.40	0.97	0.98	0.98
NEU_mAP	0.807	0.435	0.593	0.822	0.855	0.877




图 4.20 GCT10 数据集准确率与召回率比较

Fig.4.20. Comparison from accuracy and recall in GCT10 sets.




图 4.21 NEU 数据集准确率与召回率的比较

Fig.4.21 Comparison from accuracy and recall in NEU sets

在平均精度实验中，采用 YOLOX 的 anchor-free 检测方法，相比传统的定位方式，有显著提升效果。采用 ECA 方式的融入能够使模型主干网络提取特征不明显缺陷细节，如在 Cg，Ws，Os，Ss 等缺陷类型中得到巨大改善。相比于 EMV2-YOLOV4^[68]算法，平均精度也由原来的 0.32,0.59 与 0.1 各自增加到 0.34,0.68,0.58。EMV2-YOLOX 算法同样在 GCT10 数据集中难识别缺陷类型 Cr 的精度提升了 19%，其他类别精度同样小幅提升。

参数量过大将会导致过拟合问题，推理时间与模型推理速度负相关关系。能够决定模型在嵌入式设备运行的性能。本文进一步实验对比了算法的检测速度以及参数量关系，如表 4.2 所示，参数量相比 EMV2-YOLOV4 模型推理时间略微减少，但在推理速度上各自提升 1.77f/s 与 4.48f/s。最终参数量仅有 8.968M 大小,能够在轻量化设备满足实时检测的要求。

表 4.2 实时检测速度与推理时间

Table4.2 Real-time detection speed and inference time

algorithm	Dataset					
	NEU			GCT10		
	Inference		Inference		Light-Pa-	
Type	Time	FPS	Time	FPS	rame-	FLOPs
	(ms/img)		(ms/img)		ter(M)	
FasterRCNN	143.17	6.98	167.41	5.97	-	-
SSD300	44.95	22.25	46.65	21.44	-	-
EfficientDet	46.11	21.7	45.19	22.13	-	-
YOLOV4	83.42	11.99	83.3	12.01	64.04	70796973200
MV1YOLOV4	38.49	26.0	36.77	27.21	12.692	5015106265
MV2YOLOV4	21.84	45.44	21.91	45.73	10.801	4076341347
MV3YOLOV4(SE)	36.56	27.36	38.16	26.24	11.729	3544338193
GhostYOLOV4	24.76	40.42	25.86	38.71	11.052	3823182841
EMV2-YOLOV4	18.44	54.25	18.50	54.09	10.424	3799475803
EMV2-YOLOX	17.21	56.02	20.59	58.57	8.945	3277906917

与 FasterRCNN 和 EfficientDet 等传统网络模型相比，本节提出的 EMV2-YOLOX 能显著缩短推理时间。FasterRCNN 作为两阶段网络结构在参数数量上比较大，对模型轻

量化部署的影响不明显。相比之下,原始 EMV2-YOLOV4 参数量较低,但是缺乏通道信息的交互导致模型的精度不高。EMV2-YOLOX 算法的推理时间低于其他轻量级网络模型,如 EMV2-YOLOV4、GhostYOLOV4 和 MV3YOLOV4。MV3YOLOV4 在强加注意机制后,模型精度会有提高,但参数数量伴随式增长。与此同时,随着内存消耗也会同步增加。其中计算参数量的公式如式 4.16 和 4.17 所示。

模型的复杂度不仅会影响模型在特定问题和数据上的可学习性,模型在看不见的数据上的泛化能力也与之有关。模型复杂度与模型精度同样对改进的新模型具有重要作用。由于受到网络 GPU 性能以及显存的影响,在硬件设备条件下最大程度发挥模型的性能成为普遍关注的问题。如式 4.15 所示为模型复杂度推理。在最终的实验中得到各模型在不同阶段的 FLOPs (floating point operations) 对比,通过分析比较发现,改进模型的复杂度明显低于原始模型,在低性能设备上能够轻量化部署需求。卷积层和全连接层的模型参数和 FLOPs 计算公式如下。

$$\text{FLOPs} = H \times W \times C_{out} \times (2C_{in} \times K^2 - 1) \quad (4.15)$$

$$\text{C-Params} = C_{out} \times (K_h \times K_w \times C_{in} + 1) \quad (4.16)$$

$$\text{F-Params} = C_{out} \times (C_{in} + 1) \quad (4.17)$$

式中 K 代表卷积核大小, H 和 W 代表输出特征图大小, C_{in} 是输入通道, C_{out} 表示输出通道。如表 4.2 所示,模型参数量为 8.945M, FLOPs 为 3277906917。

4.4.3 EMV2-YOLOX 消融实验

本节算法的消融实验结果见表 4.3。以金属表面缺陷数据集的平均检测精确度 mAP 为基础,比较本文 Eibenck 模块的 ECA、MV3YOLOV4 的 SE、迁移学习 Transfer learning 和不同宽度因子 α 等指标,以证明对于 YOLOV4 与 YOLOX 模型的各项改进的性能提升贡献能力。最终结果包括 ECA 模块对 MobilenetV2 网络的贡献比较,利用迁移训练检测模型的权重参数从 GCT10 数据集向 NEU 数据集的迁移情况,以及验证迁移学习方法对 EMV2-YOLOV4、MV3YOLOV4、MV2YOLOV4 和 EMV2-YOLOX 的贡献比较。

表 4.3 消融实验结果

Table 4.3 Ablation study results						
Network-Models	Factors				GCT10- map/%	NEU- map/%
	α	SE	ECA	Transfer learning		
YOLOV4	-	-	-	-	47.2	64.5
	-	-	-	-	56.74	77.71
MV3YOLOV4	0.5	-	-	-	53.3	73.0
	-	$\sqrt{\quad}$	-	-	56.74	75.89

续表 4.3:

Network-Models	α	SE	ECA	Transfer learning	GCT10- map/%	NEU- map/%
MV3YOLOV4	-	-	-	√	56.74	75.68
	-	-	-	-	57.49	74.97
MV2YOLOV4	0.5	-	-	-	56.90	79.3
	-	-	-	√	57.49	77.61
EMV2-YOLOV4	0.5	-	√	√	68.40	85.50
YOLOX	-	-	-	-	67.83	82.14
EMV2-YOLOX	0.5	-	√	√	73.30	87.70

加入 SE 的 MV3YOLOV4 的轻重效果与 EMV2-YOLOV4 相似, 但检测精度的提高远远低于 EMV2-YOLOV4。加入 ECA 的 EMV2-YOLOX 的检测精度比 MV2YOLOV4 提高了 4.9%, 而参数量减少了 1.48M。在 YOLOX 的基础上使用宽度系数为 α 的迁移学习 EMV2-YOLOX 进行训练会牺牲精度, 增加模型推理时间。然而最终的检测精度提升了 5.47%, 参数数量也略有减少。综上所述, 通过消融实验的控制变量比较, 最终 EMV2-YOLOX 模型在两类数据集上检测精度均为最高, 证明了融入 ECA 注意力机制模块作为整体主干网络后对缺陷检测的有效性。

4.5 本章小结

本节首先介绍了常用图像检测的传统方法提取特征, 其中阐述了基于滑窗方式的模板匹配方法与评判标准。在匹配流程中, 模板匹配方法存在单一匹配以及计算量缓慢等原因, 导致对基于模板方式匹配存在局限性, 在改进的方法中主要针对基于机器学习方式的模板匹配将对形状、纹理与颜色等进行有效提取。针对模板匹配适用性等问题, 介绍了连通区域方法以及区域生长的方式对缺陷提取识别能力, 并进行钢板缺陷提取实验, 结果表明该方法对背景缺陷区域有明显区分的简单图像具有显著分类效果。但区域生长属于辐射式增长, 在面对复杂背景以及光照不均图像中误差较大, 产生全局噪点崩溃等现象。本节最后介绍了深度学习算法, 其中简单介绍轻量化网络在参数量与精度平衡方面的优异能力, 为软件部署以及在线检测提供算法支持。随后介绍了单阶段目标缺陷检测网络框架 YOLO 系列。最后本节提出了融入了通道注意力机制的 EMV2-YOLOX 算法。该算法将 ECA 模块融入轻量化骨干提取网络 MobileNetV2, 实现通道信息权值自适应调整, 能够提高算法的提取能力。同时引入 YOLOX 模型增强模型对微小缺陷的识别与定位。改进算法能够保证模型精度的条件下, 提高模型检测性能以及硬件设备的承载能力。实验结果表明在 GCT10 以及 NEU 两类公共缺陷数据集上精度最高, mAP 值分

别为 0.86 与 0.68，高于 EMV2yoloV4 模型精度。模型参数量仅为 10.24M 大小，检测速率为 54.25f/s，在嵌入式设备中运行性能最高。EMV2-YOLOV4 结合注意力机制能高效提取难检测缺陷的位置与语义信息在智能检测方法中重要作用。最后使用迁移学习方式将 EMV2-YOLOX 模型权重进行迁移，并对相关参数进行微调，最终第 5 章中实现在复杂金属印刷品表面的高精度缺陷检测。

第5章 金属印刷品缺陷检测系统

本节依据前文算法模型理论研究为基础,设计金属印刷品表面缺陷检测软件,利用 OpenCV 和 Pycharm 开发平台,使用 C#以及 Python 语言进行软件界面编写控制。通过设计软件交互式在线检测系统,集成智能化应用客户端产品。同时满足环境要求使用 Streamlit 创建网页端检测,实现远程测试功能。

5.1 缺陷检测方案设计

缺陷检测系统设计应满足以下基本要求:

- (1) 检测精度满足一定要求,能识别微小缺陷;
- (2) 小范围内光线浮动准确率变化在一定范围内;
- (3) 软件界面实现交互式点击操作,检测速度较快;
- (4) 软件页面简洁,便于理解,用户体验良好;
- (5) 完善数据库信息,可在一定范围内添加人员信息以及其他功能;
- (6) 对缺陷准确判类别以及定位缺陷能力;
- (7) 基本统计信息数据可视化信息展示;
- (8) 实时检测帧率,满足基本软件客户端的识别缺陷流畅性;
- (9) 网页端界面实现远程部署可控、易用性特征。

本节印刷品表面缺陷检测系统主要由用户操作界面模块以及后端处理模块组成,通过 MVC 的架构模式能够灵活改变整体结构以及后台逻辑功能。后端模块主要涉及本文研究的 EMV2-YOLOX 缺陷检测算法的整体模型,GUI 可视化界面主要由 PyQt 界面程序设计。整体设计流程如图 5.1 所示。




图 5.1 缺陷检测软件系统整体设计流程图

Fig.5.1 Defect detection software system overall design flow chart

其中文件读取模块主要为 PyQt 中 QtWidgets 基类下的 `getOpenFileName` 接口,作为文件类别过滤器能读取所有类型文件并加载入模型输入部分。基于 EMV2-YOLOX 模型

的缺陷检测模型后端部分主要涉及缺陷的识别检测、判断以及定位。通过 PyQt 代码界面的融合。

5.2 软件开发环境介绍

本文软件开发环境为 Win10 操作系统下，基于 Java 以及 python 开发环境下采用 Pycharm 开发工具完成部署以及开发。最终制作为 Docker 镜像方式，便于镜像拉取重复使用。

5.2.1 图像界面开发工具简介

PyQt5 是 python 语言下的 Qt 框架，底层使用 C++ 进行封装处理，同时基于原生的 Qt 具有良好跨平台操作性，成为最强大的 GUI 图像软件界面库之一。PyQt5 提供了一个良好的窗口控件集合，与 Qt 底层逻辑接近，因此两者 API 接口在语法方面也存在相似性。作为高性能图形界面库，具有 MVC 结构模式，其中 MVC 是模型(Model)、视图(View)、控制器(Controller)简称，该软件模式具有界面设计与逻辑代码分离的开发机制，界面简洁用户体验良好且开源免费、开发稳定、安全性好的优势。因此作为软件设计快速交付具有明显效果的前提下的重要选择。PyQt5 图形界面编写方式分为两种，一种为可视化界面编程设计，另一种为代码驱动的编程设计方法。其中可视化界面方法主要使用 Qt Designer 进行设计，应用于 GUI 界面设计模式。通过 python 调试软件包集成的 Anaconda 平台安装 Qt-designer.exe 编译器自动将界面布局转化为代码形式。能够简化代码开发流程。本节将采用 Qt Designer 的方式快速构建界面布局方式作为软件基础使用部分，如图 5.2 所示为 Qt Designer 界面布局。Qt Designer 可视化设计部分主要分为控件区域、主窗口区域以及控件属性与信号处理。




图 5.2 Qt Designer 界面布局

Fig.5.2 Qt Designer interface layout

PyQt5 继承了 C++ 语言的优越性，但存在 Python 语法执行效率的不足，在实现缺陷

检测算法模型性能方面容易形成“假死”现象。无法维持该软件运行效率。因此可以采用多线程处理方式,使用并行计算机机制能快速形成交互式响应。其中线程包含在进程中,是操作系统进行调度的最小单元。单进程中只能有一个主线程,其他线程为子线程,进程的所有线程将会共享它的全部系统资源。由于线程存在资源共享机制,因此线程间通讯更为方便,但同样容易存在数据的同步与互斥现象。一般单核 CPU 只能在同一时间运行一个进程,多核 GPU 能进行多个线程并行计算。此次实验设备为 8 核 GPU,因此采用多线程方式能够解决后端调用问题。具体可以通过使用 `threading` 模块实例化线程对象,实现响应用户操作,避免信息阻塞问题。下面是 PyQt5 中多线程核心代码:

```
def sendRequest(self):
    method = self.ui.boxMethod.currentText()
    url = self.ui.editUrl.text()
    payload = self.ui.editBody.toPlainText()
    # 获取消息头
    headers = {}
    req = requests.Request(method, url, headers=headers, data=payload)
    prepared = req.prepare()
    self.pretty_print_request(prepared)
    s = requests.Session()
    thread = Thread (target = self.threadSend, args= (s, prepared) )
    thread.start()
    #新线程入口函数
def threadSend(self,s,prepared):
    try:
        r = s.send(prepared)
        self.pretty_print_response(r)
    except:
        self.ui.outputWindow.append(traceback.format_exc())
```

通过使用 MVC 机制与多线程操作模型,将软件界面代码作为主线程方法,缺陷检测识别方法作为后台逻辑的子线程处理方法,最终实现该软件检测系统功能的快速创建与应用,解决前端显示、程序奔溃等问题。

5.2.2 网页开发简介

金属印刷品缺陷检测软件系统需要搭建普通环境,但存在专业知识较强,因此采用网页部署的方法能够更好针对使用人群的需求。网页开发主要面向前后端信息传输以及摄像头流媒体技术等。但由于检测模型以 python 代码为主,因此采用 Flask 模板开发能

够减少开发周期流程,通过 Flask 开发网页同时能够减少对其他语言的学习成本,通过最终开发模板能成功部署在阿里云服务器中,避免了 Flask 开发中断交互现象的出现。因此通过查阅大量技术文档,实现网页界面开发并识别系统。网页开发中同样存在信息阻塞问题,而且阿里云部署服务器成本较高,因此本节采用 Streamlit 进行网页端缺陷检测系统的设计。

Streamlit 是一个用于机器学习数据可视化的开源 Python 库,通过代码能够快速构建定制化在线软件应用,同时具有分享功能,满足远程操作等需求,在数据分析领域具有显著优势。同时在不具备 JavaScript、HTML、CSS 等前端基础的先验知识内对网页开发人员具有极大优势。因此本节缺陷检测算法部署网页端,进行实时远程在线检测。如图 5.3 所示为 Streamlit 启动界面与官方 yolov3 目标检测实现。




图 5.3 Streamlit 启动界面与 YOLOV3 目标检测测试

Fig.5.3 Streamlit startup interface with YOLOV3 target detection test

5.2.3 OpenCV 开发库

OpenCV (Open Source Computer Vision Library) 是跨平台开放源代码的计算机视觉库,可用于开发实时的图像处理、计算机视觉以及模式识别,在工业领域得到广泛采用。同样 OpenCV 有 C 语言版本以及 Python 版本,其中图像处理领域的使用主要涉及图像读取,以及图形图像的数字化操作。作为沟通视觉与机器学习算法的桥梁,在使用上具有灵活、便捷、开发速度快等特性,能适应各平台操作系统的基础底层应用。

5.3 缺陷检测系统设计及实验

5.3.1 基于 HMTGAN 金属印刷品缺陷迁移

基于 HMTGAN 模型能有效将裂纹缺陷迁移至钢板材质以及木板材质,并合成具有高质量图像的样本数据库。通过训练完成的模型参数进行迁移式生成学习金属印刷品缺陷样本。油斑与划痕普遍存在于钢板缺陷中,且形态各异,通过迁移生成方式扩充金属印刷品表面缺陷,能有效增强模型对缺陷特征迁移的泛化能力。如图 5.4 所示为将钢板

油斑缺陷以及裂纹缺陷类别作为迁移缺陷集，HMTGAN 网络在迁移训练中独立生成目标缺陷金属图像以及迁移合成缺陷两部分。两种方式的负样本扩充使得原始数据样本的样本容量得到最大化扩增，为目标识别任务在精度提升方面提供数据准备。



图 5.4 缺陷迁移与生成结果

Fig.5.4 Defect migration and generation of results

5.3.2 基于 EMV2-YOLOX 缺陷检测

金属印刷品缺陷含有字符印刷缺陷 (Character-Error)、油污 (Ink-Stains)、麻点 (Pockmark)、划痕 (Scratches) 以及微小凹坑 (Tiny-pit) 五类缺陷。相比与普通钢板缺陷检测具有对微小缺陷特征提取能力需求更高，本文数据集来自于真实企业样本缺陷，通过搭建实验平台相机获取，使用相机获取的高质量图像分辨率更高。因此使用深度学习算法对图像处理能力要求更为严格，与此同时在终端设备以及软件中的部署相比其他类别缺陷识别更具有难度。基于 EMV2-YOLOX 模型在钢板缺陷的识别任务中具有对微小缺陷的强提取特性，本节采用迁移学习的方法将 4.4.3 中模型训练权重进行迁移训练。通过 HMTGAN 网络的条件扩增实验数据由原始采集的 300 张图像数量增至 30000 张，改进参数学习率，设置训练为 3000 次，实验训练与测试数据集比例为 8:1 分布。最终获得检测结果如图 5.6 所示。其中图 5.5 为 CAM (Class Activation Mapping) 类激活热力图，通过训练中间层特征可视化部分得到融入 ECA 注意力机制产生的中间通道图像，对特定区域的语义信息提取具有显著效果，能从全局图像中捕捉重点区域特征信息，实现凹坑、划痕等难检测微小缺陷识别。




图 5.5 EMV2-YOLOX 缺陷检测中间层可视化

Fig.5.5 EMV2-YOLOX defect detection intermediate layer visualization






图 5.6 EMV2-YOLOX 测试数据集上检测结果

Fig.5.6 Detection results on EMV2-YOLOX test dataset

如图 5.7 所示，最终通过迁移训练平均精度均值化得到的 mAP 值达到 81.33%，参数量为 8.945M，相比同等分辨率数据集上的 GCT10 数据集中依然保持少量提升。其中 HMTGAN 扩充数据集使模型学习形态更具有多样性，增强泛化能力的同时对精度提升具有显著影响。实验证明本文 EMV2-YOLOX 模型在四类缺陷识别的精度达到最高，能满足单张图像识别以及在线帧率检测要求。



(a) EMV2-YOLOX 模型在金属印刷品缺陷训练收敛性



(b) HMTGAN 模型扩充前后金属印刷品缺陷平均精度

图 5.7 金属印刷品迁移训练平均精度

Fig.5.7 Average accuracy of transfer training for metal prints

5.3.3 软件方案设计

图像预处理模块封装于缺陷检测模块中，与触发按钮控件相连，使用鼠标加载图像预测，最终可视化界面展示如图 5.8 所示。其中主要功能可实现视频的实时检测以及图像检测等功能，右侧显示界面可记录人员信息以及检测记录等，便于提升负样本检出率。其中对缺陷类别以及置信度数值展示右侧便于进一步对该缺陷类别进行判别使用。界面下层区间内分为模型的训练曲线可视化以及整个模型的平均准确率的显示。其中需要对模型进行预训练标准，然后进行实时检测与静态图像定位识别。当模型训练完成时，动

态曲线完成训练阶段。模型的 mAP 值变化是根据预测样本量大小决定，此次设计软件可实现批量图像数据读取预测功能。证明 EMV2-YOLOX 模型精度的有效性，在软件实时检测中可实时显示检测图像的帧率变化。




图 5.8 软件可视化界面设计

Fig5.8 Software visualization interface design

本文设计了基于 PyQt 的缺陷检测系统，在完成最终封装程序后，需要进行项目程序的封包，便于在其他平台使用。为了将整个算法程序以及图形界面设计程序转换为可执行程序，此次使用 auto-py-to-exe 开源图形化工具进行封包处理。auto-py-to-exe 在最新的工具库中使用了可视化界面操作模式，降低了代码转化的复杂度。其中可视化界面如图 5.9 所示。




图 5.9 auto-py-to-exe 封包界面

Fig.5.9 auto-py-to-exe packet interface

本文同时设计基于网页端部分的缺陷检测系统设计, 基于 streamlit 开源库, 最终实现界面可视化如图 5.10 所示, 默认 8501 端口进行测试, 加载缺陷图像以及识别种类与置信度的方法能通过远程输入图像系统检测, 获取各类记录信息并通过强大分享功能实现移动端的查看与交互式操作。



图 5.10 基于 streamlit 的网页缺陷检测设计

Fig.5.10 Web defect detection design based on streamlit

5.4 本章小结

缺陷检测软件系统设计是缺陷检测算法研究的重要载体, 是直接检验理论研究的实例转化。本节主要设计金属印刷品表面检测的软件系统, 其中介绍了软件设计要求、以及软件整体开发环境。详细描述了基于 PyQt 的图形界面工具的使用以及重要优势, 并介绍了 Streamlit 的网页开发开源库, 从而简化了网页端设计的流程。最后介绍了 opencv 基本图像处理视觉库, 对数字化处理以及图像图形学分析等具有重要作用。在最后的软件总体设计与可视化部分对最终结果进行了可视化展示, 完成了能迁移使用至其他平台的封装处理。结果表明基于 EMV2-YOLOX 模型在金属印刷品表面缺陷检测的有效性, 准确度高于其他模型算法, 并成功部署在软件客户端以及网页端在线检测。

第 6 章 结论与展望

6.1 本文总结

随着工业自动化技术的快速发展,国内自动化印刷技术逐渐成熟,对印刷品表面缺陷的质量检测需求尤为迫切。其中金属印刷品因材质特殊、工艺复杂等特点,导致加工过程中印刷品表面产生各类缺陷。智能化的检测方法逐渐取代以“人工目检”为主的传统检测方式。基于视觉的表面缺陷检测技术已得到长足的发展,推进了机械制造、半导体及电子等行业的生产过程智能化。深度学习方法因其在处理背景复杂、缺陷微弱的工业图像时展现出卓越的性能优势,逐渐在该领域占据主导地位。本文为了降低金属印刷品表面高反光特性对自动化缺陷识别产生的重要影响,搭建了图像采集系统。因深度学习算法模型对数据容量需求庞大,因此提出基于生成对抗网络技术对负样本图像进行扩增,最终本文提出的研究算法模型获得各类缺陷的高精度识别结果。为满足生产线中金属印刷品实时检测需求,本文实现了基于 PyQt 的软件缺陷检测系统,融入所提出的检测模型框架实现了在线检测与视频检测要求。同时实现了基于 Streamlit 的网页端远程缺陷检测识别系统。

本文的主要工作及研究成果包括以下几点:

(1) 搭建适应高反光金属表面视觉检测的图像采集模拟仿真系统。根据金属印刷品表面反光特性,实验选择同轴光源照明方式以及垂直照射方法成功抑制周围环境对成像的干扰,在抑制背景噪声干扰同时突出显现了印刷品表面复杂缺陷特征。通过系统设计以及采集方案设计最终获取高质量缺陷图像数据集。

(2) 提出了一种基于改进 GAN 网络的图像迁移匹配模型。为了解决图像负样本不足导致缺陷检测对特征识别精度不高的影响,本文提出基于改进 GAN 网络模型进行高质量图像生成与跨材质迁移。本文提出的 HMTGAN 网络解决了源图像缺陷无法融合生成高质量缺陷样本问题,相比原始 GAN 网络带来的在低特征条件下隐变量解耦能力的不足问题,通过改进隐变量的方式能够提高缺陷与背景材质的融合能力。在引入直通梯度方法改进损失函数的反向传播方式,提高了生成图像鲁棒性同时能够改善模型训练的稳定性与收敛。由于明确的风格(背景材质)与缺陷内容进行分离实现了高保真度图像生成、缺陷差异以及背景与前景的控制。同时在真实数据集中提高了采样效率,证明在缺陷图像扩增任务中 HMTGAN 生成缺陷样本的可行性与优势。

(3) 提出了一种基于 EMV2-YOLOX 的缺陷检测模型。为了平衡缺陷检测精度和轻量级配置条件,解决 YOLO 算法在高反光金属印刷品数据集上的低精度问题,本文提出 EMV2-YOLOX 模型。与原 YOLOX 模型存在的模型提取精度低的问题相比,改进的骨干网络 ECA-MobileNetV2 代替 CSPDarkNet 网络提高了对难检测缺陷以及微小缺陷类

别的检测精度。在公共数据集的实验比较表明,所提出的模型在参数数量和各门类的准确度方面可以表现最好。最终使用迁移学习方式迁移训练至金属印刷品数据集,提升了对各类别缺陷的识别率。

(4)设计了一套金属印刷品软件缺陷检测系统。根据缺陷检测特点与设计需求,本文基于 PyQt 设计了一套图像自动化检测系统,通过本文算法模型的深度嵌入实现了在客户端软件缺陷检测的需求。同时使用 Streamlit 进行网页部署实现远程在线检测功能。通过测试,实时检测帧率较高,对缺陷种类识别率高,满足生产线上实时检测需求。

6.2 工作展望

本文在缺陷检测任务中提出基于 EMV2-YOLOX 模型使用无锚定位框方式增强了上下特征语义信息,提升样本预测的准确率,为实际生产线上的部署提供理论依据。为满足缺陷检测模型在实际应用中的检测需求,采用基于 PyQt 的软件检测系统以及网页在线部署能有效提升缺陷样本检出率。在本文研究基础上,将对金属类缺陷属性进行完善。因此在未来研究中进行以下方面改进。

(1)降低模型训练难度,扩增局部缺陷特征。用于图像识别任务的深度学习方法依赖于许多原始数据集,而缺乏大量真实的负面样本集给模型训练带来许多问题。本文提出的缺陷合成模型在扩增数据集上具有明显效果,但存在大尺度训练数据的模型消耗,因此在未来工作中可以降低模型训练难度。同时由于生成模型对全局特征的信息生成具有方向性,因此可以添加约束进行精细化控制,产生对局部特征细节的生成,进一步降低模型训练难度。

(2)改进识别模型识别定位框,对不规则特征以及形态特征进行提取。缺陷检测模型中的难点为微小缺陷的识别以及不规则特征的定位问题。由于在实际检测中需要设置一定标准,并对缺陷形态进行判定,因此需要提取固定缺陷轮廓,采用旋转方式定位对缺陷轮廓的识别以及提取参数具有一定优势。

参 考 文 献

- [1] 李海洋, 李巧霞, 王召巴, 吴其洲, 陈友兴. 金属材料表面缺陷的激光超声检测技术[J]. 火力与指挥控制, 2019, 44(08): 61-64.
- [2] 杨思远, 郑建颖. 基于路侧三维激光雷达的车辆目标分类算法[J]. 传感器与微系统, 2020, 39(07): 123-126.
- [3] 邓淇天, 李旭. 基于多特征融合的车辆检测算法[J]. 传感器与微系统, 2020, 39(06): 131-134.
- [4] Han F, Hill S, Rout R, et al. The Use of Eddy Current Testing for Defect Detection in Additive Manufactured Metals[R]. 2022.
- [5] Ciampa F, Mahmoodi P, Pinto F, et al. Recent advances in active infrared thermography for non-destructive testing of aerospace components. *Sensors*, 2018, 18(2): 609.
- [6] Dong G, Sun S, Wang Z, et al. Application of machine vision-based NDT technology in ceramic surface defect detection-a review. *Materials Testing*, 2022, 64(2): 202-219.
- [7] 周心悦. 基于机器视觉的金属片表面缺陷实时检测与分类研究[D]. 中国科学技术大学, 2021. DOI:10.27517/d.cnki.gzkju.2021.001157.
- [8] 胡宜笑. 印刷品缺陷检测研究与应用[D]. 湖南大学, 2020.
- [9] 吕明珠. 基于机器视觉的印刷品表面缺陷检测研究[D]. 西安理工大学, 2019.
- [10] 邢旭朋. 基于非线性扩散与图像配准的印刷品表面缺陷检测[J]. 轻工机械, 2021, 39(02): 77-81.
- [11] Xu J, Zhang J, Zhang K, et al. An APF-ACO algorithm for automatic defect detection on vehicle paint[J]. *Multimedia Tools and Applications*, vol.79, pp.25315-25333, 2020.
- [12] Zhou X, Wang Y, Zhu Q, et al. A surface defect detection framework for glass bottle bottom using visual attention model and wavelet transform[J]. *IEEE Transactions on Industrial Informatics*, vol.16, no.4, pp. 2189-2201, 2019.
- [13] Ren Z, Fengzhou Fang, Ning Yan, et al. State of the Art in Defect Detection Based on Machine Vision[J]. *International Journal of Precision Engineering and Manufacturing-Green Technology*, 2022(9-12).
- [14] Manish R, Venkatesh A, Ashok S D. Machine vision based image processing techniques for surface finish and defect inspection in a grinding process. *Materials Today: Proceedings*, vol.5, no.5, pp.12792-12802, 2018.
- [15] Zhang Z, Fang J, et al. Research on defect detection of printing surface. *ICIC Express Lett*, vol.9, no.6, pp.541-549, 2018.
- [16] Hao Z, Wang Z, Bai D, et al. Towards the steel plate defect detection: Multidimensional feature information extraction and fusion. *Concurrency and Computation Practice and Experience*, 2021(4).

- [17] 沈壮壮. 基于深度学习的高光曲面表面缺陷检测[D]. 北京邮电大学, 2020. DOI:10.26969/d.cnki.gbydu.2020.001136.
- [18] 郭皓然, 邵伟, 周阿维, 杨宇祥, 刘凯斌. 全局阈值自适应的高亮金属表面缺陷识别新方法[J]. 仪器仪表学报, 2017, 38(11): 2797-2804.
- [19] 陈麒麟. 阀板表面缺陷视觉检测技术研究[D]. 烟台大学, 2020. DOI:10.27437/d.cnki.gytd.2020.000274.
- [20] 郝丽, 杨旭, 王峥, 黄亚平, 宋元涛. 复杂背景下基于多阈值的光滑工件表面瑕疵检测[J]. 计算机应用与软件, 2020, 37(09): 183-187, 226.
- [21] 周鼎贺, 宋志峰, 林富生. 基于机器视觉的汽车零件涂装缺陷检测方法[J]. 电镀与涂饰, 2021, 40(16): 1292-1300. DOI:10.19289/j.1004-227x.2021.16.011.
- [22] 郭志烨. 高反射表面缺陷检测技术研究[D]. 厦门大学, 2018.
- [23] 刘红帝. 基于 HDRI 的高反光表面缺陷检测方法研究[D]. 湖北工业大学, 2020.
- [24] 谢芳. 用于汽车外观缺陷检测的图像处理关键技术研究[D]. 南京航空航天大学, 2020. DOI:10.27239/d.cnki.gnhhu.2020.001180.
- [25] 刘婷婷. 基于深度学习的高反光金属工件表面缺陷检测研究[D]. 河北大学, 2020. DOI:10.27103/d.cnki.ghebu.2020.001122.
- [26] 王启祥. 基于深度学习的轴承外圈表面缺陷分类关键技术研究[D]. 电子科技大学, 2020. DOI:10.27005/d.cnki.gdzku.2020.000669.
- [27] 杨婉琪. 基于卷积神经网络的带钢表面缺陷图像分类算法研究与实现[D]. 华中科技大学, 2019. DOI:10.27157/d.cnki.ghzku.2019.003773.
- [28] 赵丰, 张兴会, 高慧敏, 张立波. 基于卷积神经网络的表面缺陷检测方法综述[C]. 第十四届全国信号和智能信息处理与应用学术会议论文集, 2021: 441-444. DOI:10.26914/c.cnkihy.2021.003016.
- [29] 封雨鑫, 邓宏贵, 程钰. 基于卷积神经网络的焊缝表面缺陷检测方法[J]. 计算机测量与控制, 2021, 29(7): 6.
- [30] 张昌凡, 孟德志, 王燕囡. 基于轻量化 YOLOv4 的黏稠食品灌装成品缺陷检测[J]. 包装学报, 2021.
- [31] 王一鸣, 杜慧敏, 张霞, 徐一丁. 视觉注意力网络在工件表面缺陷检测中的应用[J]. 计算机辅助设计与图形学学报, 2019, 31(09): 1528-1534.
- [32] Balcioglu Y S, Sezen B, Gok M S, et al. Image Processing with Deep Learning: Surface Defect Detection of Metal Gears through Deep Learning. *Materials Evaluation*, vol.80, no.2, 2022.
- [33] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection. *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp.779-788, 2016.
- [34] Santoso A D, Cahyono F B, Prahasta B, et al. Development of PCB Defect Detection System Using Image Processing With YOLO CNN Method. *International Journal of Artificial Intelligence Research*, vol.6, no.1, 2022.

- [35] Yue X, Wang Q, He L, et al. Research on Tiny Target Detection Technology of Fabric Defects Based on Improved YOLO. *Applied Sciences*, vol.12, no.13, 2022.
- [36] Alexey B, Wang C Y, Mark Liao H Y. Optimal speed and accuracy of object detection, arXiv preprint arXiv.10934, 2020.
- [37] Zheng J, Zhuang Z, Liao T, et al. Improved Yolo V3 for Steel Surface Defect Detection, *Computer Engineering and Networks*, Singapore, (Springer Nature Singapore), pp.729-739, 2022.
- [38] Vaswani A, Ramachandran P, Srinivas A, et al. Scaling local self-attention for parameter efficient visual backbones, *Computer Vision and Pattern Recognition*, pp.12894-12904, 2021
- [39] Redmon J, Farhadi A. Yolov3: An incremental improvement. arXiv preprint arXiv:1804.02767, 2018.
- [40] Yanju Liu, Qiuji Wang, Real-Time Defect Detection of Metal Surface Based on Improved YOLOv4. in *International Journal of Innovative Computing, Information and Control*, vol.18, pp.1329-1338, 2022. doi:10.24507/ijicic.18.04.1329.
- [41] Howard A, Sandler M, Chu G, et al. Searching for mobilenetv3Proceedings of the IEEE/CVF international conference on computer vision, pp.1314-1324, 2019.
- [42] Zhuxi MA, Yibo Li, Minghui Huang, et al. A lightweight detector based on attention mechanism for aluminum strip surface defect detection, *Computers in Industry*, vol.136, pp.103585, 2022.
- [43] Xuan W, Jian-She G, Bo-Jie H, et al. A lightweight modified YOLOX network using coordinate attention mechanism for PCB surface defect detection, *IEEE Sensors Journal*, 2022.
- [44] Ge Z, Liu S, Wang F, et al. YoloX: Exceeding yolo series in 2021. arXiv preprint arXiv. (2021) 08430.
- [45] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[J]. *Advances in neural information processing systems*, vol.27, 2014.
- [46] Radford A, Metz L, Chintala S. Unsupervised representation learning with deep convolutional generative adversarial networks. arXiv preprint arXiv:1511.06434, 2015.
- [47] Zhu J Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks. *Proceedings of the IEEE international conference on computer vision*, pp.2223-2232, 2017.
- [48] Isola P, Zhu J Y, Zhou T, et al. Image-to-image translation with conditional adversarial networks. *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp.1125-1134, 2017.
- [49] Linfeng Gao, Jianxun Zhang, Changhui Yang, Yuechuan Zhou, Cas-VSwin transformer: A variant swin transformer for surface-defect detection, *Computers in Industry*, vol.140, 2022, doi:10.1016/j.compind.2022.103689.
- [50] Wang Z, Yu L, Pu L. Defect simulation in SEM images using generative adversarial networks. *Metrology, Inspection, and Process Control for Semiconductor Manufacturing XXXV*. 2021.
- [51] Zhang G. Defect-GAN: High-Fidelity Defect Synthesis for Automated Defect Inspection. *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*. pp. 2524-2534, 2021.

- [52] Liu J, Wang C, Su H, et al. Multistage GAN for Fabric Defect Detection. *IEEE Transactions on Image Processing*, vol.29, pp.1-1, 2019.
- [53] S.Niu, B. Li, X. Wang and Y. Peng, Region- and Strength-Controllable GAN for Defect Generation and Segmentation in Industrial Images, in *IEEE Transactions on Industrial Informatics*, vol. 18, no.7, pp. 4531-4541, July 2022, doi: 10.1109/TII.2021.3127188.
- [54] He Y, Song K, Dong H, et al. Semi-supervised defect classification of steel surface based on multi-training and generative adversarial network. *Optics and Lasers in Engineering*, pp.294-302, 2019.
- [55] Kingma D P, Welling M. Auto-encoding variational bayes. arXiv preprint arXiv:1312.6114, 2013.
- [56] YUN, JONG PIL, SHIN, WOOSANG CRINO, KOO, GYOGWON, et al. Automated defect inspection system for metal surfaces based on deep learning and data augmentation. *Journal of Manufacturing Systems*, pp.55317-324, 2020, doi:10.1016/j.jmsy.2020.03.009.
- [57] Karras T, Laine S, Aila T. A style-based generator architecture for generative adversarial networks. *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp.4401-4410, 2019.
- [58] Martin Heusel, Hubert Ramsauer, Thomas Unterthiner, Bernhard Nessler, and S. Hochreiter. Gans trained by a two time-scale update rule converge to a local nash equilibrium. In *NIPS*, 2017.
- [59] Mikolaj Binkowski, Danica J. Sutherland, Michael Arbel, and A. Gretton. Demystifying MMD GANs. *ArXiv*, abs/1801.01401, 2018.
- [60] Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications. arXiv preprint arXiv:1704.04861, 2017.
- [61] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks. *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp.4510-4520, 2018.
- [62] Han K, Wang Y, Tian Q, et al. Ghostnet: More features from cheap operations. *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp.1580-1589, 2020.
- [63] Tan M, Le Q. Efficientnet: Rethinking model scaling for convolutional neural networks. *International conference on machine learning*. PMLR, pp.6105-6114, 2019.
- [64] Tan M, Pang R, Le Q V. Efficientdet: Scalable and efficient object detection. *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp.10781-10790, 2020.
- [65] Wang Q, Wu B, Zhu P, et al. ECA-Net: Efficient Channel Attention for Deep Convolutional Neural Networks. *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. IEEE, 2020.
- [66] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. *Advances in neural information processing systems*, vol.28, 2015.
- [67] Kumar A, Zhang Z J, Lyu H. Object detection in real time based on improved single shot multi-box detector algorithm. *EURASIP Journal on Wireless Communications and Networking*, vol.2020, no.1, 2020.
- [68] Xikun X, Changjiang L, Meng X. Application of attention YOLOV4 algorithm in metal defect detection. *2021 IEEE International Conference on Emergency Science and Information Technology (ICESIT)*, pp. 465-468, 2021.