



华南理工大学

South China University of Technology

硕士学位论文

锂电池极片表面缺陷视觉检测算法研究

作者姓名	李雅雯
学科专业	控制科学与工程
指导教师	胡跃明 教授
所在学院	自动化科学与工程学院
论文提交日期	2024 年 4 月 19 日

Research on Visual Detection Algorithm for Surface Defects of Lithium Battery Electrode

A Dissertation Submitted for the Degree of Master

Candidate: Li Yawen

Supervisor: Prof. Hu Yueming

South China University of Technology

Guangzhou, China

分类号：TP391.4

学校代号：10561

学 号：202120117791

华南理工大学硕士学位论文

锂电池极片表面缺陷视觉检测算法研究

作者姓名：李雅雯

指导教师姓名、职称：胡跃明 教授

申请学位级别：工学硕士

学科专业名称：控制科学与工程

研究方向：控制理论与控制工程

论文提交日期：2024 年 4 月 19 日

论文答辩日期：2024 年 6 月 5 日

学位授予单位：华南理工大学

学位授予日期： 年 月 日

答辩委员会成员：

主席：周雪峰

委员：胡跃明，罗家祥，杜娟，袁鹏

摘 要

近年来随着锂电池制造产业的蓬勃发展，保证锂电产品的质量安全已经成为业界关注的重中之重。极片作为影响锂电池性能及安全的核心部件，其表面不同类型的缺陷会对电池造成不同程度地负面影响，因此亟需研发出一套高精度高效的锂电池极片缺陷检测系统，推动锂电产业自动化与智能化的发展。

针对现阶段的极片缺陷检测方案存在着检测速度慢、精度低、难以检测微小复杂多变缺陷的问题。本文结合深度学习算法与传统的视觉检测技术，研究实现一套目标分类定位及像素级分割的极片缺陷检测系统。本文主要研究内容如下：

1. 为高速高效的识别极片表面缺陷，提出一种基于改进 YOLO 的极片缺陷目标定位与分类算法。针对原模型对极片缺陷表征能力较低的问题，首先提出一种基于深度卷积的多尺度动态注意力机制并引入 SimCSPSPF 模块，在有限计算资源的情况下提升网络对于缺陷特征的提取能力；接着为解决微小缺陷漏检错检的问题，提出一种基于稠密连接的多尺度双向特征金字塔进行特征融合，显著提升跨尺度缺陷的检测性能；最后引入 Slide-NWD 损失函数解决难易样本不均衡及小目标定位敏感的问题。本文所提目标识别算法平均检测精度高达 94.42%且检测速率达 40.06FPS，具备优越的检测性能。

2. 本文提出一种基于像素级分割的缺陷区域精密提取算法，以精准高效提取缺陷区域的几何数据从而进行产品的有效分拣。为解决极片背景纹理及噪声干扰过多的检测难点，首先提出一种基于自适应快速双边滤波的双树复小波变换算法对图像进行保边降噪处理；接着为增强图像关键边缘特征并解决低对比度等问题，提出一种结合梯度域引导滤波及全局双亮度伽马变换的 Retinex 图像增强算法；为实现可容忍性极片缺陷检测系统，最终提出一种改进的 Canny 算子实现对极片缺陷的像素级高精度分割。

3. 搭建硬件系统进行图像采集并在上述研究的基础上对软件系统进行研发。经过极片实际生产环境的模拟测试，验证算法的准确性、有效性及稳定性。

本文研发的极片缺陷检测算法满足工业生产的检测需求，展现出较高的实用价值。

关键词：锂离子电池极片；缺陷检测；机器视觉；YOLOv8；Canny 算子

Abstract

In recent years, with the booming development of the lithium battery manufacturing industry, ensuring the quality and safety of lithium battery products has become a top priority in the industry. As a core component that affects the performance and safety of lithium batteries, different types of defects on the surface of the electrode can have varying degrees of negative impact on the battery. Therefore, it is urgent to develop a high-precision and efficient lithium battery electrode defect detection system to promote the development of automation and intelligence in the lithium battery industry.

The current electrode defect detection scheme has problems such as slow detection speed, low accuracy, and difficulty in detecting small, complex, and variable defects. This article combines deep learning algorithms with traditional visual detection techniques to achieve a electrode defect detection system for object classification, localization, and pixel level segmentation. The main research content of this article is as follows:

1. For the high-speed and efficient identification of surface defects on electrode, a target detection and classification algorithm for electrode defects based on an improved YOLO model is proposed. Addressing the original model's low capability in representing electrode defects, this paper first introduces a multi-scale dynamic attention mechanism based on deep convolution and integrates the SimCSPSPF module to enhance the network's capability to extract defect features under limited computational resources. To tackle the issue of missing and falsely detecting minor defects, a feature fusion based on a dense connection-based multi-scale bidirectional feature pyramid is proposed, significantly improving the detection performance for cross-scale defects. Lastly, the inclusion of the Slide-NWD loss function addresses the problem of imbalance between easy and difficult samples and the sensitivity of locating small targets. The proposed target recognition algorithm achieves an average detection precision of 94.42% and a detection rate of 40.06 FPS, demonstrating superior detection performance.

2. This article proposes a precise defect area extraction algorithm based on pixel level segmentation to efficiently extract accurate data of defect areas for effective sorting of products. To solve the detection difficulties of excessive interference from electrode background texture and noise, a dual tree complex wavelet transform algorithm based on adaptive fast bilateral filtering is first proposed to perform edge preserving and denoising processing on the image; Next, to enhance the key edge features of the image and solve the problem of low contrast, a Retinex image enhancement algorithm combining gradient domain

guided filtering and global dual brightness gamma transform is proposed; To achieve a tolerable electrode defect detection system, an improved Canny operator is proposed to achieve pixel level high-precision segmentation of electrode defects.

3. Construct a hardware system for image capture and develop software systems based on the aforementioned research. Through simulation tests in an actual production environment, verify the algorithm's accuracy, effectiveness, and stability.

The electrode defect detection algorithm developed in this paper meets the inspection requirements of industrial production and demonstrates high practical value.

Keywords: Lithium-ion battery electrode; Defect detection; Machine vision; YOLOv8; Canny algorithm

目 录

第一章 绪论.....	1
1.1 课题研究背景和意义.....	1
1.2 国内外研究现状.....	2
1.2.1 视觉检测技术的发展及应用.....	2
1.2.2 锂电池极片缺陷检测技术国内外研究现状	5
1.3 论文研究内容及章节安排	6
1.3.1 主要内容及难点分析.....	6
1.3.2 论文结构安排.....	8
第二章 极片缺陷检测系统的分析及设计	10
2.1 引言.....	10
2.2 锂电池极片制备工艺及缺陷分析	10
2.2.1 极片制备流程.....	10
2.2.2 极片缺陷成因及特征分析.....	12
2.3 检测系统的设计路线.....	14
2.4 硬件系统设计.....	15
2.4.1 成像系统的搭建.....	15
2.4.2 运动控制系统的设计.....	19
2.5 整体系统设计.....	20
2.6 本章小结.....	22
第三章 基于改进 YOLO 的极片缺陷目标分类与定位算法.....	23
3.1 引言.....	23
3.2 目标检测算法.....	23
3.2.1 双阶段目标检测算法.....	23
3.2.2 YOLO 系列检测算法.....	24
3.3 基于 YOLOv8 的改进检测方案	27
3.3.1 主干网络的改进.....	27
3.3.2 特征融合部分的改进.....	30
3.3.3 改进损失函数.....	33
3.4 实验结果分析.....	34
3.4.1 改进的 YOLOv8 整体框架	34
3.4.2 数据集制作及环境配置.....	35
3.4.3 主要评估指标.....	35
3.4.4 实验结果对比及分析.....	36
3.5 本章小结.....	43

第四章 基于像素级分割的缺陷区域精密提取算法	44
4.1 引言	44
4.2 图像预处理	44
4.2.1 极片缺陷图像去噪算法	44
4.2.2 极片缺陷图像增强算法	47
4.3 改进 Canny 图像边缘检测算子	51
4.3.1 Canny 边缘检测算子	52
4.3.2 改进滤波算子	52
4.3.3 改进 Sobel 算子	52
4.3.4 基于改进麻雀搜索算法的最大熵算法	53
4.3.5 边缘判定与完善	58
4.4 实验结果及分析	58
4.4.1 缺陷区域精密提取算法的整体流程	58
4.4.2 主要评估指标	58
4.4.3 实验结果及分析	60
4.5 本章小结	65
第五章 极片缺陷检测软件系统的设计及验证	67
5.1 引言	67
5.2 开发环境与工具	67
5.3 极片缺陷检测软件流程设计	68
5.4 软件异常处理机制	69
5.5 用户界面设计	69
5.6 软件系统测试与性能分析	70
5.6.1 系统稳定性测试	70
5.6.2 系统功能性测试	71
5.7 本章小结	72
总结与展望	73
参考文献	75

第一章 绪论

1.1 课题研究背景和意义

伴随全球经济腾飞以及工业迅速发展所带来的能源与环境问题是当今各国面临的巨大挑战，从传统能源向绿色可再生能源的转换已经成为全球性的趋势。在国际上，瑞士经济论坛、国际货币基金组织和多国政府等机构相继推出促进低碳技术发展和清洁能源解决方案的政策和法规。在我国，习主席提出绿色、低碳、可持续发展的新理念。为响应国家的号召，经济与科技的发展应伫立在节能减排绿色可持续性的基石之上。现阶段太阳能、风能等清洁能源发电的方案被广泛采用，但是由于其间歇性、不可预测性供能导致当今大时代下大容量储能设备的研发成为了一个热点与难点^[1]。锂离子电池作为一种新型储能设备，因其具备高能量密度、长循环寿命、低自放电率、高稳定性、低污染等优点被广泛应用在储能系统、新能源汽车、便携电子设备、航空航天、医疗器械等领域中^[2,3]。在当今的国家政策与市场需求的推动下，锂电产业仍会不断加速壮大，具有广阔的发展前景与巨大的研究价值^[4]。

锂电池一般分为锂金属电池和锂离子电池。锂金属电池是一种初期的锂电池技术，其使用金属形态的锂作为极片材料，但充放电过程中可能形成的锂枝晶会导致电池过热或是短路。现在更为普及的是锂离子电池，使用碳材料如石墨和金属作为极片材料。锂离子电池一般是由正负极极片、隔膜、电解质溶液等部件构成^[5]。圆柱形锂离子电池内部结构图如图 1-1 所示。




图 1-1 圆柱形锂离子电池内部结构图

正积极片通常以铝箔作为载体，使用锂金属氧化物进行涂覆，如锂钴氧(LiCoO_2)、锂铁磷(LiFePO_4)、锂镍锰钴氧(LiNiMnCoO_2)等。负积极片通常以铜箔为载体，大多采用人造石墨进行表面涂覆^[6]。通过电解质溶液进行锂离子的传递，隔膜进行正负极的隔

离，防止短路。锂离子电池的材料构造使其相对体积下可以存储更多电能，单个锂电池电压高达 3.6V，是镍镉电池的两倍以上。除电池高能量密度、高电压等储能方面的优势外，其还具有高能效、高寿命等节能环保的优势^[7]。

尽管锂离子电池因其诸多优势占据大半市场份额，但其仍存在诸多挑战。尤其是近年社会上多起质量安全事故的发生，带来较为严重的经济损失和伤亡，如特斯拉、蔚来等能源电池起火、三星手机“电池门”事件等。锂电产品的质量安全问题已经成为业界关注的重中之重^[8,9]。极片作为锂离子电池最核心的部件，其生产经过制浆、涂布、烘干、辊压、分切等多个工艺，受到环境、机器、工艺等多变复杂的外界干扰因素的影响，其表面易出现如气泡、凹坑、划痕、漏金属等缺陷^[10]。这些缺陷根据其位置、大小直接不同程度地影响到电池的性能及安全，比如其可能会造成电池充放电时的电压不稳定，或是导致极片间或是极片与电解质间形成导电路径，引起内短路，进而引发电池的热失控反应，造成起火甚至爆炸。高质量的极片是确保锂电池稳定性与安全性的基础。因此高速高效的锂电池极片表面缺陷检测系统是突破目前制约锂电产业发展的关键。

现阶段实际生产中极片缺陷的检测大多还是采用人工目检，但由于人眼的限制以及主观性，导致漏检、错检的现象频出，严重的限制了锂离子电池的生产效率。随着视觉检测技术的发展，逐渐出现了基于传统的图像处理算法以及新兴的深度学习算法的极片缺陷检测技术，这些技术实现了通过 CPU 或是 GPU 计算以提取目标特征，具备高稳定性、高精度、高速度、高准确性等优点。因此本文旨在实现一套目标定位分类及像素级分割的极片缺陷检测系统，精准地分类定位缺陷的同时，根据生产复盘以及绿色环保节约成本的原则，高精度实现缺陷的分割及缺陷大小的计算，保证锂离子电池的产品质量并提升其生产效率，解决当今锂电产业所面临的卡脖子问题。

1.2 国内外研究现状

1.2.1 视觉检测技术的发展及应用

二十世纪五十年代起，人们从对二维图像的研究中打开机器视觉技术的大门，比如尝试识别图像的字符，提取医学图像特征等^[11]。六十年代初，Roberts 通过一种算法从二维图像中感知三维几何结构，提出由多面体构成“积木世界”的机器视觉领域的新概念，开启了三维视觉研究的新篇章^[12]。七八十年代起，越来越多的学者聚焦于机器视觉的研究上，Marr 视觉计算理论作为视觉领域第一套完整的视觉理论体系被 David Marr 教授提出，对于视觉领域的研究有着指导性的意义^[13]。八十年代后，机器视觉技术开启

了新时代,随着数字处理器、机器学习、人工智能等概念的出现视觉相关的新研究新理论蓬勃发展,相关技术相继走出实验室步入实际应用中,落实到各个领域并发展成相应的产业,在我国首先应用在精密电子与半导体元器件制造产业^[14]。二十一世纪,国外机器视觉的相关产业愈发成熟,我国在这样的时代背景下将视觉技术应用在交通运输、医学图像、工业制造、农业生产等领域中,实现了经济的腾飞。其中视觉检测技术已经成为机器视觉领域中最为核心的成果之一。

除本文所研究的锂电极片检测目标外,在各种制造业领域中视觉检测都是保证产品质量的必要技术。传统目检存在着人工成本过高、精度不够、效率低下等缺点且工人的接触易对产品造成一定的损伤,无法满足实时工业生产流水线的需求。随着视觉检测等自动化技术的发展以及电子元器件技术的飞跃,越来越多人将镜头、相机、工控机等设备结合起来应用在工业实时生产流水线上,通过合适的检测算法对目标进行定位、识别、控制等操作,实现无损的视觉自动检测系统,从而取代原始的人工目检^[15]。由于不同检测对象间的差异过大,实际生产中工作人员需根据不同的产品、工艺流程、现场环境、应用背景、检测需求等研究相应匹配的检测算法以实现工业生产检测的基本需求。

对于完整的视觉检测系统,一般是由图像采集装备、图像处理算法以及一些其他的硬件设备组成,相关的硬件装备是基础,而缺陷识别算法是决定检测系统效率的核心。表面缺陷检测算法一般分为基于传统和基于深度学习的两大类图像处理算法。

传统图像处理算法是指在现代深度学习技术兴起之前所采用的图像处理技术,在缺陷检测中一般通过数学和统计学原理对图像的结构进行分析,从而进行特征提取。一般的检测步骤分为三步,首先对图像进行预处理操作,可通过图像降噪或是增强算法滤除无关干扰,增强关键特征的辨识度;其次通过相关算法对图像的特征进行提取,比如通过阈值化、边缘检测或是聚类算法进行图像分割;最后利用提取的特征对其进行分类,比如通过支持向量机、决策树等分类器实现对缺陷种类的识别。传统图像处理算法需结合实际的缺陷特征设计相应的检测方案,可实现像素级高精度的目标区域分割并达到较高检测效率。相较于深度学习算法,其耗费计算资源较少,对硬件设备要求较低,且无需大量的标注数据来训练模型,综合成本较低,被广泛应用于工业生产中。

Taniguchi 研究出一种基于小波分析的图像处理技术,结合涡流检测技术实现对于印刷电路板(Printed Circuit Board, PCB)表面缺陷进行识别^[16]。Jaffery 等分别将 Canny 算子、区域生长、标记控制分水岭分割、K-means 聚类四种算法应用于轨道表面缺陷检测中,进行性能比较^[17]。慕德旭等提出了一种改进多尺度图像增强技术并结合了自适应

Gamma 矫正算法, 使用支持向量机(Support Vector Machine, SVM)实现苹果表面的缺陷检测和分类^[18]。徐学谦等研究出一种基于改进型区域生长的焊缝缺陷识别算法, 结合均值滤波并改进普通开运算卷积核, 最终检测精度高达 89.19%^[19]。柴子凡等提出一种基于霍夫变换与 K-means 聚类算法结合的玻璃瓶分模线缺陷检测, 有效改善分模线识别困难的问题, 最终准确率高达 96%^[20]。尽管传统图像算法在各个应用场景中都有着较为优异的表现, 但其泛化能力、实时性等方面依然存在一些局限性。

深度学习通过构建神经网络结构, 自动从大量数据集中学习可以用于检测的有效特征, 在训练的过程中根据网络预测值与标注真实值的差异进行权值优化, 在不断迭代并逐渐优化模型权重的过程中, 提升模型对于检测目标关键特征的表征能力, 最终训练得到的模型可对检测目标进行自动的定位和分类。该算法对于同类别检测对象有着较好的泛化能力与鲁棒性, 且检测速率较高。随着计算机硬件设备的更新迭代, 适用于各个场景的深度学习算法陆续被提出并被广泛的应用于制造业的自动化检测系统中。伴随足够的计算资源与数据量, 其模型能够实现高精度和高可靠性, 在保证工业生产实时性的同时降低检测的错检率与漏检率。

Zuo 等提出了一种基于自适应金字塔的复杂焊缝缺陷检测算法, 首先通过一种自应对比度增强方法, 有效生成优化的 X 射线图像, 有利于后续的特征提取; 接着提出一种配备可变形卷积的自适应特征金字塔网络去拟合不同大小和形状的缺陷, 大大地提高了模型的准确率和泛化能力^[21]。Tang 等研究出一种基于 Yolov5(You Only Look Once version5)的改进型带钢表面缺陷检测模型, 通过在网络的主干部分嵌入注意力机制, 提升了网络对于缺陷的表征能力, 又通过引入 SIoU(Symmetrical Intersection over Union)损失函数, 缩短模型训练的收敛时间^[22]。最终该实验算法的召回率提升 8.3%, 平均检测精度提高 3.6%。Wu 等设计一种基于改进 VGG16(Visual Geometry Group 16)的高精度波纹燃料管缺陷检测模型, 针对缺陷分布不均匀的问题通过人工高斯权重降低漏检率, 引入多头注意力模块提高块分类的精度, 通过区块分类模块使用较少的样本获得更大的模型容量, 该算法在两个不同数据集上皆有较高的检测效率^[23]。Zhang 等基于轻量级神经网络设计一套实时 PCB 缺陷检测系统, 将大型网络的不重要的神经元和权值进行剪枝, 在网络擅长准确定位和分类缺陷的同时, 大大提高了模型的实时性, 结果证明该模型在 PCB 数据集中的平均准确率高达 92%, 每帧延迟低于 200ms, 满足实时性的检测需求^[24]。

深度学习算法对 GPU 以及数据量的要求较高, 但是可以对目标精确地分类和定位, 有着较高的识别速率, 模型地泛化性能和鲁棒性都较好, 在目标检测方面较传统算法有

着更为先进且强大的性能。对于高精度的像素级区域分割,深度学习算法耗费资源过大,且工作量较传统算法大大提升,应用于实际工程时相较传统算法优势不大。

1.2.2 锂电池极片缺陷检测技术国内外研究现状

根据上文所述,随着视觉检测技术的发展与应用,越来越多领域将新兴的检测成果与制造业生产结合起来,大大提升了生产效率。锂离子电池产业也顺应时代发展,结合机器视觉技术,大力发展极片缺陷检测技术,提高极片的检测效率和精度。

许长路等提出一种基于 Gamma 矫正和 LOG(Laplacian of Gaussian)算法结合的锂电池极片表面缺陷检测算法,使用 Gamma 算法增强感兴趣区域(Region of Interest, ROI)的缺陷特征的同时通过 LOG 算法实现目标区域的分割,最后通过形态学处理和 Sobel 算子实现极片缺陷检测^[25]。该算法对于极片的多种缺陷皆能有效检测。王露首先使用双边滤波在保证边缘细节的同时进行图像的降噪处理,通过自适应阈值算法进行图像分割,最后通过 SVM 实现缺陷分类^[26]。该算法的平均准确率达 94.43%,具备较好的识别和分类性能。Xu 等提出一种基于多特征融合和粒子群优化的锂电池极片表面缺陷识别算法,通过图像减运算和对比度调整对待测图像的缺陷特征进行增强,后通过 Canny 算子和与运算进行缺陷区域的提取,将纹理特征、边缘特征、HOG 特征结合并利用粒子群优化算法优化的 SVM 对缺陷进行自动分类和识别,该方法不仅能准确检测出极片表面各类缺陷,而且平均准确率可达 98.3%^[27]。黄梦涛等提出了一种基于改进 Canny 算子的锂离子电池极片缺陷检测算法,引入双边滤波和多尺度细节增强算法均匀光照并进行图像细节处理,同时引入最大熵和最大类间方差法有效进行缺陷特征的分割^[28]。该算法检测准确率高达 98%,但对于划痕缺陷的定位精度略有不足。Tao 等针对极片缺陷复杂微小等检测难点,使用均值漂移算法进行降噪操作,并通过 Otsu 算法(Otsu Thresholding Method)增强图像的对比度,最后使用灰度共生矩阵进行缺陷特征的分割,该算法对于极片表面的脱碳、漏金属、白点等多类缺陷皆可实现有效检测,具备一定的应用价值^[29]。

现阶段出现的锂电池极片视觉检测技术大多基于传统算法,且研究成果参差不齐。针对极片缺陷种类繁多且对比度微小、生产环境复杂、背景纹理较多等客观问题所带来的检测难点,目前公开的检测算法无法满足工业生产现场中高准确率、高精度、高速度、高鲁棒性、高可靠性等质检需求。国内的锂电极片检测算法大多未走出实验室形成一套工程上的完善缺陷质检系统,只有极少数的国内公司具备极片缺陷检测的工程成果。如广东奥普特科技公司研发出一款极片表面缺陷检测系统,该系统包括成像装置、图像识

别模块、极片传送装置、极片翻转装置、极片分拣装置、极片打标装置等，对于极片缺陷可以高速高精度的检测并分拣^[30]。深圳信宇人科技公司则结合神经网络推出一款高频锂电池极片毛刺缺陷检测装置，具备较高的质检效率^[31]。而在国外，锂电极片检测装备业发展较为成熟，Polytype 公司是锂电极片缺陷检测装置的全球头号供应商，将诸多学术成果应用于其产品之上，远远领先于其他检测装置制造商。此外 FUTECH 公司、Hilti 公司、松下电器等都在锂电产业占据着较高的市场份额。



图 1-2 锂离子电池极片缺陷检测装置

尽管国内很多公司也相继研发出锂电池极片缺陷检测装置，但是由于研发投入较低、时间较短，导致国内厂商的检测精度和实时性与国外产品相差较大，缺乏外部市场的核心竞争力，也是阻塞国内锂电产业发展的一个重大原因。面对我国锂电发展的一大技术滞后，国家的投入也随之加大，未来锂电极片检测一定会突破技术壁垒，达到新的高峰。

1.3 论文研究内容及章节安排

1.3.1 主要内容及难点分析

本文研究的主题是锂电池极片表面缺陷视觉检测算法。在实际生产与应用中，由于锂离子电池的不同应用场景，不同厂商的生产线有着各自的检测标准和流程，对于产品的质检指标也要求各异。锂电池极片缺陷检测在工业上一般分为严格检测和可容忍性检测。严格检测即针对极片表面只进行目标缺陷的定位和分类，对于有缺陷的极片直接选择分拣丢弃。而可容忍性检测即对极片不光需进行缺陷的目标识别和分类，还需对分类后的缺陷极片进行 ROI 的区域分割，获得缺陷的详细轮廓，计算其具体的长度、宽度、周长、面积等几何结构信息。根据流水线具体的质量指标进行二次判断，从而对不合格的极片产品进行分拣。本文的研究即围绕可容忍性极片缺陷检测开展的，该类型检测在符合产品质量需求的同时更加节省原材料，符合国家的绿色可持续新理念，同时也符合工厂内部生产复盘的需求。

根据上述应用场景,结合国内外视觉检测技术的研究现状、如今锂电产业检测方面的理论成果和工业实时生产的指标需求,本文研究设计了一套锂离子电池极片表面缺陷定位分类及像素级分割的集成检测系统,可以对于凹坑、暗斑、划痕、孔洞、气泡、压痕、漏金属在内的七种缺陷进行精确检测,能够满足实时工业流水线上的 0.05mm 以上的检测精度标准和 1000mm/s 以上的实时性需求。以下所述是本文所进行的主要工作内容和研究的重点难点。

1. 前期准备工作:

1). 根据实际生产时所拍摄的锂电池极片图像进行缺陷成因的分析,并对各个种类缺陷进行特征归类,从而设计基于深度学习实现目标检测和基于传统算法实现像素级高精度分割的检测方案。

2). 对工业生产流水线进行模拟,选型光源和相机搭建成像系统,并对运动控制系统进行设计,完成对于极片的图像采集和运动控制。

3). 制作符合神经网络训练模型的数据集,进行样本标注、数据增强以及数据集划分。

2. 极片表面缺陷检测的研究要点:

1). 针对极片表面的缺陷实现快速定位,进行 ROI 区域提取,并对该缺陷进行精准分类。实现输入极片图像内多种缺陷的高速高精度识别。

2). 对于提取出来的 ROI 区域设计像素级高精度的分割算法,保证检测实时性的同时进行精确几何结构数据的提取,实现不合格极片的高效分拣。

3). 通过综合客观评价指标对本文所提检测算法的有效性进行验证,同时对本文算法的优缺点进行评估,给出检测系统打破技术壁垒的改进方向。

3. 极片表面缺陷检测研究的难点:

1). 极片制造环境可能存在尘埃、水汽、震动、电磁干扰等干扰因素,导致极片会受到不同程度的噪声影响,比如高斯噪声、条纹噪声、雪花点等。且受到环境光线影响,极片表面可能会存在光照不均匀的问题,因此应通过特定算法消除上述干扰的同时选取鲁棒性高、稳定性高的检测算法。

2). 极片缺陷的种类繁多且复杂,同时这些缺陷尺寸和形态各异,部分缺陷微小且对比度较低,导致缺陷难以分辨,例如划痕的方向长短、凹坑的大小、暗斑的形状不一等,应根据上述检测难点设计算法。

3). 符合工业生产流水线的极片检测系统一般要兼顾检测精度与检测速率,为实现

上述目标应在算法选型和改进模块时综合考虑算法实时性与准确性间的均衡性及鲁棒性，提升检测系统的综合性能。

1.3.2 论文结构安排

本文围绕上述研究要点及检测难点进行算法的深入研究，设计一种检测效率与实时性兼顾的锂电池极片目标识别和像素级分割的算法。

考虑到当前目标检测领域应用最为广泛且高效的为 YOLO(You Only Look Once)算法，其具备较高的实时性与检测精度，但原始 YOLO 对于本文微小极片缺陷的识别与分类存在着漏检错检等问题。因此本文第三章将围绕 YOLO 算法进行针对性地改进以实现准确高速的极片缺陷识别算法。针对极片缺陷分割算法，考虑到新兴的语义分割模型所需数据集成本过大且精度无法满足工业生产流水线的需求，而传统分割算法中 Canny 算子以其高效性著称且应用较为广泛，因此本文第四章将针对 Canny 算子进行针对性的改进，以实现极片微小缺陷的高精度分割。

首先提出一种改进的 YOLO 目标检测算法，对极片的缺陷进行精准地识别分类并进行 ROI 区域的提取，其次设计一种基于传统图像处理的高精度目标分割算法，基于改进的图像降噪和图像增强算法，改善噪声和缺陷微小对比度低导致难以分辨的问题，又提出一种基于 Canny 的改进边缘检测算子，在最大保留边缘细节的同时，实现极片表面缺陷的高精度分割。本文的章节安排如下所示：

第一章主要是绪论。首先以现阶段锂离子电池的发展背景为前提，对本文的研究背景和研究意义进行阐述；接着针对视觉检测技术的历史发展及应用进行了概述，并围绕锂离子电池极片缺陷检测的国内外研究成果及现状进行了详细调研；最后对本文的研究要点难点以及论文的章节安排进行介绍。

第二章主要是极片缺陷检测系统的设计及分析。首先对于锂电池极片的制备工艺进行介绍，并对极片待测缺陷的成因及特征进行分析；接着选取合适的相机、光源、镜头、图像采集卡及工控机以搭建成像系统并对运动控制系统进行设计；最后对本文检测算法的整体思路和技术路线进行阐述。

第三章主要介绍基于改进 YOLO 的极片缺陷目标定位与分类算法。首先阐述选取 YOLOv8(You Only Look Once version8)模型作为缺陷识别分类的基本框架的原因，并介绍双阶段检测模型及 YOLO 系列算法演变；接着针对极片缺陷微小、尺寸差异大、对比度低等问题，对特征主干网络进行改进，设计一种基于动态分布权重的多尺度通道注意力机制；然后对特征融合网络部分进行优化，引入 SimCSPSPFF 模块在大幅提升检测精

度的同时保持较低的运算量，并设计一种改进的基于密集网络的双向传播特征金字塔多头检测器；最后提出一种改进损失函数，解决难易样本不均衡及小目标定位敏感等问题。

第四章主要阐述基于像素级分割的高精度缺陷提取算法。首先对本章的技术路线进行概述，分析选择基于传统算法进行区域分割的原因；接着对图像进行预处理，采用基于改进双树复小波变换的图像降噪算法和改进的 Retinex 图像增强算法，去除噪声干扰的同时保持缺陷的完整边缘；最后设计一种基于麻雀算法优化的改进 Canny 算子，实现像素级高精度的图像分割，保证缺陷几何结构数据的完整。

第五章主要介绍极片缺陷检测软件系统的设计及验证。首先对于软件系统的开发环境和相关工具进行介绍；其次基于第二章所设计的硬件系统以及三四章所设计的极片检测算法模型对软件系统总体框架设计和极片缺陷检测软件流程进行阐述；最后对于异常处理机制及用户交互界面进行介绍并进行相关的系统测试。

最终进行总结和展望，分析本文所提检测方案的优劣之处，并提出后续展望。

第二章 极片缺陷检测系统的分析及设计

2.1 引言

锂离子电池极片的制备工艺环环相扣较为复杂，因此实现极片表面的高速高效实时检测，不但需要了解缺陷的表面特征和具体特性，也需要将检测系统部署到制备过程当中。本章从极片的制备工艺出发，对其制备流程及待测缺陷进行分析，接着概述本文检测系统的总体设计方案，随后对本文硬件系统中的成像系统与运动控制系统的构成进行阐述，最终对本文软件算法的技术路线进行详述并给出检测系统的整体流程图。

2.2 锂电池极片制备工艺及缺陷分析

2.2.1 极片制备流程

锂离子电池的制备过程一般分为极片制造、电芯制造、电池封装和电池组装，如下图所示^[32,33]。在完成极片的制造后，一般会根据应用场景的不同，通过卷绕或是叠加等方式将极片与隔膜制成圆柱、方壳或是软包型电芯。




图 2-1 锂离子电池制备流程

由上述流程也可以看出，极片是锂离子电池最为重要的部分，极片的质量和电池的使用寿命、安全周期、正常性能息息相关。极片的制造流程一般包括五个步骤：浆料制备、极片涂布、极片干燥、极片辊压和极片裁切，如下图所示^[34]。对于锂电池负极极片一般由铜箔作为集流体，将活性物质（大多为人造石墨）、导电剂（如导电石墨、导电碳黑等）、增稠剂和粘结剂等涂覆于其表面。





图 2-2 极片制备工艺图

浆料制备一般分为材料混合、搅拌两道工序，为保证极片微观结构的合理性，从而保证极片的质量，不仅需注意各个材料的混合比例、投放顺序，同时也需要选取合适的搅拌工艺。最终通过对浆料的固含量、密度粘度流变曲线、细粒度、流平性、Zeta 电位等指标进行评估，从而确保浆料的稳定性和合规性。负极极片的颜色一般呈现出铅灰色，如图 2-3a)所示，辊压后表面的材料与铜箔相贴相对不够紧密，更容易受到损伤，如划痕、漏金属等缺陷的出现概率会远高于正极^[35]。正极极片的涂布材料相对比较复杂，其一般是以铝箔为载体，其表面涂覆活性物质（锂氧化物）、导电剂和粘结剂（丁苯橡胶乳液）。由于材料的不同，导致正极极片在辊压后浆料与铝箔紧密贴合，质感硬实光滑形同塑料，颜色为纯黑色，涂布材料相对负极不易脱落，如图 2-3b)所示^[36]。



a) 锂电池负极极片

b) 锂电池正极极片

图 2-3 锂电池极片

极片涂布是将制备好的浆料均匀稳定地涂布到金属集流体的正反面上。根据浆料附着载体的方式，常见的涂布工艺分为刮刀涂布、狭缝挤压涂布、逗号辊刮刀转移涂布、喷嘴式涂布等。要想保证均匀稳定的涂布，首先涂覆的浆料需性质稳定，不发生沉降效应，其次浆料上料供应需平稳，对于走箔也要进行张力和纠偏控制。而评判涂布工艺的质量一般是通过涂布密度、涂层厚度等指标来验证涂布的一致性。涂布工艺和辊压工艺是极片生产过程中最易产生缺陷的工序，本文所研究的大多缺陷皆是在该工序中产生的，具体会在下一小节详述。

在进行完浆料涂布后极片需进行干燥处理，使用加热的方式精准控温使极片表面的水分或是其他溶剂汽化，令浆料内的固态部分更好地和载流体粘接。在该环节中需严格控制温度、湿度和时间，以避免极片表面的膜层因温度过高引起变形变色甚至化学成分发生改变，引起火灾等事故的发生。

随后需将极片送入辊压机进行压实操，通过上辊和下辊将极片膜压扁的同时使极片膜的颗粒与导电剂更加紧密地结合，如下图 2-4 所示。通过辊压之后的极片能量密度和导电率更高，但若参数控制不合理极片表面易出现打皱、毛刺、脱碳甚至断裂等缺陷。

在该工艺的流程中需关注并控制辊轮压力、辊轮速度、辊压次数等重要指标，根据极片的设计和需求确认具体的参数，从而合理的增加极片膜的紧密度和压缩度，提高电池的使用性能并延长电池的寿命。




图 2-4 极片辊压工艺图

极片裁切分为极片分切和模切两种方式。极片分切一般是将大极片送入电子线切割机中，通过张力控制和纠偏控制机构将其分割成若干个预设大小极片卷料的过程，确保尺寸、形状满足后续要求。极片模切是通过激光将正负极片周期性地切割出极耳，如下图所示。在该环节中需注意刀具的锋利度，确保裁切后的极片边缘整齐、没有残留异物和其他损伤，避免锂电池内部短路等问题的发生。



图 2-5 极片模切工艺图

2.2.2 极片缺陷成因及特征分析

锂电池极片制备工艺十分复杂，在制备流程中每个环节都可能导致缺陷的形成。为实现高速高效地检测出生产过程中的不当操作导致的极片表面缺陷，需对极片缺陷成因以及各类缺陷的不同表征进行分析。以下是各生产环节中常见的缺陷成因。

1. 浆料纯净度不达标

在浆料制备时，极片生产所需的正负极材料、导电剂和粘接剂可能会含有杂质，这些杂质会导致极片表面的颗粒大小不一致、分布不均和粘接力较差，从而使极片表面不平整、孔隙较多，形成不规则暗斑等多种缺陷。

2. 涂布工艺的不稳定

在极片表面涂布的过程中若相关参数控制不当，如涂布速率、涂布窗口等，会导致涂层的厚薄不均匀、竖条道等缺陷。在喷洒浆料的过程中工厂环境内存在各种灰尘、油

污、金属颗粒或异物，其会导致极片表面出现如气泡、异物缩孔甚至划痕等缺陷。

3. 干燥工艺控制问题

对极片表面湿润涂层进行干燥的过程中，若干燥速度过快或是温度过高，极片表面的涂层会产生裂纹和脱落。相反若干燥不足，则会引起极片内部湿度过高，导致电化学性能降低等相关问题。

4. 机械性操作问题

在生产处理极片的过程中，若辊轮压力过大的话极片表面可能会出现长条形压痕、凹坑等相关缺陷问题。若设备调校不当或刀具磨损，可能会对极片表面造成划伤甚至破损，导致孔洞、漏金属等缺陷。

本文以锂电池极片的实时生产线上所采集的数据作为基础，将本文检测系统的研究对象定为以下七种常见的缺陷：漏金属（简称 LJS）、划痕（简称 HH）、孔洞（简称 KD）、压痕（简称 YH）、气泡（简称 QP）、暗斑（简称 AB）、凹坑（简称 AK），缺陷如下图 2-6 所示。




图 2-6 极片表面常见的七种缺陷类型

对于其中漏金属、划痕、孔洞这三类缺陷都属于极片较为严重的破损类缺陷，其会造成锂电池严重的安全问题。漏金属缺陷是指极片因表面膜层的破损而漏出内部的铜箔或铝箔，金属部分的像素灰度值接近 255，而极片背景灰度值接近为 0，具体如图 2-6a) 所示。划痕缺陷一般呈细长状且深浅不一，若划痕较深则极片表面破损明显会明显看到箔材甚至穿透，若划痕较浅则缺陷部分呈现较背景部分较深的灰度值，如图 2-6b) 所示。孔洞缺陷则是极片表面因尖锐异物刺穿导致的不规则形态的破孔，通过孔洞可以看到辊

带表面的纹理和黑色背景，如图 2-6c)所示。

压痕、气泡、暗斑和凹坑属于相对轻微的表面缺陷。压痕缺陷一般在辊压阶段由辊轮上的异物产生，其为规则长条状、边缘清晰且缺陷区域大部分灰度值与背景相接近，唯有头尾部分呈现较为明显的区别，如图 2-6d)所示。气泡缺陷一般由涂布过程中混入的颗粒异物或是气体导致，其一般呈边缘模糊的规则性圆状且周围环绕一圈灰度值较高的圆环，内圆则接近黑色，如图 2-6e)所示。暗斑缺陷一般是由极片表层的石墨碳层过厚等因素引起，其呈现不规则大小的黑斑且轮廓清晰，如图 2-6f)所示。凹坑缺陷则是因涂布工艺中混入颗粒性物质或是辊压机表面粉尘过多导致极片表面呈现深浅不一的坑状，中心区域面积较小且整体缺陷肉眼检测困难以致难以分辨，如图 2-6g)所示。

上述缺陷面积微小且在极片的正负极上表现略有不同，各类缺陷间形态差异不大且对比度较低，同时由于外部噪声干扰以及光照不均等各类因素的影响，大大增加本文检测系统的缺陷识别与提取的难度。后续本文将针对各类缺陷特征及检测难点进行算法的研究与改进，实现一套实时在线的极片表面缺陷检测系统。

2.3 检测系统的设计路线

结合极片缺陷的检测难点与要点，本小节将对极片缺陷检测系统的整体技术路线进行概述，本文检测系统的设计方案图如下图 2-7 所示。由下图可看出来本文设计的检测系统分为硬件系统和软件系统。




图 2-7 缺陷检测系统的总体设计方案图

对于硬件系统，本文在 2.4 节中结合检测目标并模拟极片的实时工业生产线，详述极片成像系统中相机、镜头、光源、工控机及图像采集卡的硬件选型，介绍运动控制系

统中的传动装置、机械平台与缺陷打标系统，实现极片在传送带上的实时传输及图像采集，并根据软件系统的识别结果对极片进行打标处理。本文在 2.5 节中详述缺陷软件系统的设计方案，首先通过预设图像采集控制模块实现待测极片的输入，接着通过搭建的用户操作界面选择对极片图像进行缺陷分类与区域分割，最终将相关数据进行数据库的入库操作并进行统计分析。

2.4 硬件系统设计

硬件平台属于极片缺陷检测系统的重要组成部分，其传动控制装置的稳定性和采集的极片图像质量直接影响后续软件模块对极片表面缺陷的检测性能。因此搭建一套完善的硬件平台是实现工业级极片缺陷检测系统的基石，接下来的小节将围绕极片成像系统的搭建与运动控制系统的设计进行探讨。本文的硬件系统由成像平台和运动控制系统组成，其硬件平台的结构如下图 2-8 所示。




图 2-8 极片缺陷检测系统硬件平台结构图

2.4.1 成像系统的搭建

在锂离子电池的制造过程中，极片表面任何微小的缺陷都可能导致电池性能的显著降低，因此精确稳定的极片成像平台对于极片缺陷检测系统至关重要。当成像系统能够获取高质量的极片图像时，既可以降低对后续图像预处理算法的依赖程度也可以提高检测系统的识别精度。搭建一套模拟极片工业生产线的成像硬件平台需根据成像分辨率、拍摄速度、系统稳定性等综合性能需求对硬件组件进行仔细评估和选择，最终进行严谨的系统集成。本文所设计的成像方案中的核心模块包括相机、镜头、光源、工控机、图

像采集卡，因此接下来将对这几个模块的选型进行探讨。

1. 相机选型

工业相机的选型对于成像系统至关重要，其决定了成像质量与速度。工业相机与大众所用的民用相机有所不同，其具备更高的图像处理速度和更好的耐用性，可在恶劣的产业环境中持续稳定工作，有着高适用性、长寿命、强抗干扰能力、高稳定性等优点。在进行相机选择的过程中需要根据实际情况考虑分辨率、帧率、传感器大小等需求，其中高分辨率的相机对识别微小缺陷至关重要，合适的帧率能够保证极片表面图像的实时捕获，足够大的感光元件可以覆盖较大的检测区域从而避免图像拼接。下文将结合本文的检测目标与需求进行相机的选型及分析。

依照相机传感器的结构将工业相机分为面阵相机和线阵相机。面阵相机是以“面”为单位对整体的场景图进行完整的采集，提供二维的图像数据，适用于静态或是低速移动的采集对象。而线阵相机则是选取线状的感光元件去采集单行或双行像素，在拍摄过程中通过目标或相机的移动对待采集物体进行整体的扫描，最后将带状像素进行连续拼接形成完整的二维图像。线阵相机更适用于运动中的成像目标，常被用于高速连续的工业生产线，如电路板、金属带、印刷材料的检测。因此在极片的缺陷检测过程中，线阵相机可以更高效地对表面进行扫描，对于气泡、划痕、压痕等缺陷可采集出更多微小细节。根据感光元件的工艺不同，工业相机可以分成电荷耦合器件(Charge-Coupled Device, CCD)和互补金属氧化物半导体(Complementary Metal-Oxide-Semiconductor, CMOS)相机。其虽都采用光电二极管将光信号与电信号进行转换，但这两者处理信号的路径有着根本的差别。CCD 是按照捕捉图像时产生电荷的顺序进行像素的传达，最终由模拟信号放大器进行信号的放大输出和转换；CMOS 是在每个像素点处集成一个模拟信号放大器和 A/D 转换器，直接进行输出^[37,38]。由于内部工艺的差异，导致 CCD 相机以良好的成像质量、稳定的色彩而著称，而 CMOS 相机则以高集成、低功耗、高速率等特点被广泛应用于工业自动检测、精密测量等领域。

综上所述，本文成像平台采用 CMOS 线阵相机类型。线阵相机具体的选型还需根据合适的行频和分辨率这两个参数进行判断，由于本文检测精度需求是 0.05mm 以上且待测极片最大宽度是 200mm，因此线阵相机的分辨率 R 应满足公式(2-1)。

$$R > \frac{200\text{mm}}{0.05\text{mm}} = 4000 \quad (2-1)$$

并且极片的传送速度要求 1000mm/s 以上，因此线阵相机的行频 fr 应满足公式(2-2)。

$$fr > \frac{1000\text{mm/s}}{0.05\text{mm}} = 20000\text{Hz} \quad (2-2)$$

因此应选择分辨率大于 4k 且最高行频大于 20kHz 的工业相机，最终本文选用大恒图像的 LA-CM-08K08A，如下图 2-9 所示，其具体参数如表 2-1 所示。



图 2-9 LA-CM-08K08A 线阵相机

表 2-1 LA-CM-08K08A 线阵相机参数

参数类型	参数值
分辨率	8192×1
行频(kHz)	80
传感器	CMOS
像元尺寸	7.04μm

2. 镜头选型

在挑选完合适的线阵相机后，需精选出与之相匹配的镜头，并将二者组合成完善的视觉传感系统。镜头是利用凸透镜以及其他光学组件将光束进行转换，进而在相机的感光元件上形成目标图像。镜头的品质是决定成像系统质量的关键，因此在进行工业线阵相机镜头的选型时，必须根据实际的模拟情况对镜头焦距、工作间距、水平视场范围以及光学放大系数等参数进行计算，感光元件横向尺寸 X 的计算公式见式(2-3)，其中 A 为线阵相机的像元尺寸， C 为扫描分辨率。

$$X = A * C \quad (2-3)$$

由于像元尺寸为 $7.04\mu\text{m}$ ，扫描分辨率为 8192，通过上述公式计算后感光元件横向尺寸等于 57.672mm 。水平视场范围 S 即极片最大的宽度 200mm ，因此光学放大系数 ω 通过公式(2-4)计算得 0.288。成像精度 Γ 通过公式(2-5)计算得 0.244mm ，满足检测精度 0.05mm 的需求。

$$\omega = \frac{X}{S} \quad (2-4)$$

$$\Gamma = \frac{A}{\omega} \tag{2-5}$$

本文成像系统中的工作间距即极片与镜头的间距为 200mm，镜头焦距 B 的计算公式见式(2-6)，其中工作间距为 k ，因此镜头的焦距应大于 57.6mm。

$$B = k * \omega \tag{2-6}$$

综上所述，本文选择适用于 8K 线阵相机的 HN-P-6040-L 线扫镜头，如下图 2-10 所示。该镜头的焦距为 60mm，最小工作距离为 167mm，满足本文硬件成像系统的需求。



图 2-10 HN-P-6040-L 线扫镜头

3. 光源选型

选择恰当的光源对于在工业实时生产环境中捕获高质量的极片图像至关重要。光源的适宜选型不仅有助于增强极片图像的清晰度与对比度，还能最大程度避免反光现象及噪声的干扰，进而便于进行后续的缺陷识别与分割。在目前工业应用场景中，常用的照明光源主要有白炽灯、金属卤素灯、荧光灯和 LED 灯等^[39]。各类光源的性能对比如表 2-2 所示。

表 2-2 工业场景的常用照明光源

	寿命/小时	耗能	发光效率	优点	缺点
白炽灯	1000	高	一般	暖色温，成本较低	效率较低，发热量大且寿命短
金属卤素灯	3000	高	一般	色温范围宽，光效好	能耗高，响应慢，发热高，较为昂贵
荧光灯	5000	一般	高	色温选型多样，发热低，扩散性好	稳定性低，降低非彩色图像质量
LED	100000	低	极高	低发热，高响应，高安全性，体积小	初始成本较高

由前述的对比研究，可以看出 LED 照明光源具备光源稳定、高响应速度、低发热、长寿命等优势。由于本文采取线阵相机对极片表面进行扫描成像且线性光源一般用于带状材料的检测，因此线性光源更适用于本文的成像平台。综上所述，本文的成像平台选

用线性 LED 光源进行照明。

4. 图像采集卡

图像采集卡是将图像从外部来源获取到计算机系统硬件设备，它是图像采集模块与处理模块间的纽带，承担着图像数据高速传递的任务。图像采集卡可以处理各种类型的信号，包括数字信号、模拟信号等，常被应用于实时的视觉检测中。本文的成像平台根据输入信号格式、数据传输率、数据吞吐量、数字 I/O 等参数进行图像采集卡的选型，从而使检测系统可以对采集到的图像进行高速高效的识别与存储^[40]。最终本文采用大恒公司的 Xtium-CL MX4 图像采集卡，其支持高于 1.7GB/s 的带宽，具备数字 I/O 控制功能的同时相关的软件开发工具包也较为完善。

5. 工控机选型

工控机是针对工业控制环境进行设计的计算机，其在保留商业电脑的核心功能时集成了特定的传输协议、控制网络及操作系统，可以更快更可靠地采集并管理工业生产过程中的关键数据与流程。工控机一般分为基于 PC 的工业电脑、分散型控制系统、可编程逻辑控制器、数控系统、现场总线系统^[41]。基于 PC 的工业电脑因为其高可靠性、优秀的实时性以及出色的兼容性被广泛应用于工业生产中的实时缺陷检测，因此本文选择该类型的工控机作为极片缺陷检测系统的核心硬件设备，具体型号为集特公司的 IPC-610L，其参数如表 2-3 所示。

表 2-3 IPC-610L 工控机参数

配置	参数
CPU	Intel i7-9700
内存	32GB
显存	16G
硬盘	2TB

2.4.2 运动控制系统的设计

为模拟锂电池极片生产流水线，确保图像采集模块可以高效地拍摄极片表面图像数据，必须精准控制传送装置的移动速率并传达贴标分拣等指令操作。因此实现一套高性能的运动控制系统对确保整个缺陷检测系统的平稳运作有着至关重要的作用。本文所设计的运动控制系统由收卷机、辊轴、机械平台、打标机及传感器等关键部件组成，这些部件协同工作以保证极片在传输过程中的拍摄稳定，并根据缺陷的识别结果来驱动打标

机在极片缺陷位置的精确标注。运动控制系统流程图如下图 2-11 所示。




图 2-11 运动控制系统流程图

在本文软件模块对极片完成缺陷检测后，会把具体的位置坐标及类别信息存于队列中，并根据传送带的工作速度去设定打标机的延迟时间，在计时器到时之后目标缺陷会被传送到打标区域，依据队列中的缺陷类型和坐标信息进行精确标注。在完成相关的打标动作后反馈贴标结果，最终根据缺陷检测队列是否为空进行收卷及产品的包装分流。

2.5 整体系统设计

本文是基于可容忍性检测进行缺陷检测系统的软件设计，将硬件平台获取到的图像数据进行缺陷分类及定位，提取出 ROI 后进行进一步的实时分割，在实现人机交互的同时指挥其他辅助单元执行下一步操作。因此，极片缺陷检测系统中软件部分的核心工作包含三部分，分别是极片图像的缺陷分类及定位算法、缺陷区域的像素级分割算法、人机交互可视化平台。立足于锂电池极片工业生产需求之上，在实现上述三个核心工作时需重点考虑检测精度与实时性这两个关键指标。

目前工业背景下，广泛应用的缺陷检测技术路线主要分为三种类型。第一类是“分割-识别”策略，该类检测方案先对整张待测图片进行特征区域的提取，接着将分割出来的缺陷送入分类器中，根据不同分割图像的物理特征进行分类。这类检测方案虽不依靠大数据样本，但其处理速度慢，对于本文中微小极片缺陷难以有效的实时分类和分割。第二类是深度学习识别策略，该类方法单独使用目标检测的深度学习大模型直接对图像

中的缺陷进行分类和定位，和第一类方案相比检测速度与模型的泛化能力大幅提升，但是不能实现高精度的缺陷边缘提取和具体几何结构的测量。第三类是基于语义分割的深度学习算法，可以实现目标的识别及分割。但该类检测方案需大量的图像数据并进行像素级的详细标注，其数据的制作费时费力，且在训练时间与检测时间上都有大幅增加，对于类别较多的复杂场景检测精度较低，并不适合直接应用于多类复杂的微小缺陷表面检测^[42]。本文极片缺陷目标微小且种类多变，各类缺陷特征区别并不十分明显，若直接使用语义分割算法，识别准确率与实时性难以满足本文要求，若使用“分割-识别”策略，检测速率较低不满足工业生产流水线的实时性且成本较高，因此本文提出一种针对锂离子电池极片的“识别-分割”策略，结合高可靠性的基于深度学习的目标识别模型与高精度的基于传统图像处理的区域分割算法，在大大缩小数据成本的同时实现高速高精度的极片表面缺陷检测系统，软件系统检测流程图如下图 2-12 所示。




图 2-12 软件系统检测流程图

本文的检测方案首先依靠大量极片图像数据进行数据集的标注、划分，针对极片图像的特征提取、融合等问题对网络改进并训练，通过最终得到的深度学习模型对待测极片图像中的各个缺陷进行迅速而精确的识别与定位，以确保精准获取缺陷相关的区域信息；接着本文基于传统图像算法进行缺陷提取，针对 ROI 区域的图像结构特性进行图像降噪操作、图像增强操作，接下来对缺陷轮廓进行细致划分的同时精确量化缺陷的几何

结构信息；最终将缺陷相关信息进行入库入队处理。

本文检测系统中软件模块的“识别-分割”策略不仅能够精确快速地检测并划分极片表面的各类细小缺陷，而且最大程度地减少整个检测周期的耗时。此外，该技术路线的初期准备如数据集标注等工作简单易行且耗费成本较低，最终检测系统的鲁棒性和泛化能力较强，为其在工业生产中的应用提供了高度的可行性。

2.6 本章小结

本章首先介绍锂离子电池极片的制备流程，并针对极片的缺陷成因及本文主要研究的七种缺陷特征进行分析。接着根据本文的检测需求与难点，设计极片缺陷检测系统的整体技术路线，其包括硬件及软件两大关键部分。缺陷检测的硬件平台模拟极片工业生产的实时流水线，分为成像系统和运动控制系统，在 2.4 节中分别对其进行深度剖析并详述其设计路线及硬件选型。最后结合可容忍性检测以及相关的需求指标重点提出“识别-分割”的软件模块策略，探讨该策略的实用性及相对优势并给出软件系统的检测流程图。本章引出本文的主旨研究课题——针对锂离子电池极片的兼顾检测效率与实时性的缺陷识别和像素级分割算法，其算法细节将在后续章节展开阐释。

第三章 基于改进 YOLO 的极片缺陷目标分类与定位算法

3.1 引言

依照第二章所指出的检测系统的技术路线,本文基于目标检测算法对极片表面的微小复杂缺陷进行分类与定位。当极片表面存在不同种类的多个细小缺陷时,该算法需对缺陷进行准确地分类从而尽量避免漏检、错检的现象,同时该算法需实现精准地缺陷定位,在消除无关信息干扰的同时降低后续所需处理的数据量,减少检测流程所耗时间。

结合第二章分析内容,极片表面缺陷的检测存在诸多要点与难点,如待测图像像素大、极片表面缺陷微小且对比度低、缺陷形态多变、检测实时性要求较高等。由于双阶段目标检测模型较为复杂且实时性较低,因此本文基于 YOLOv8 网络模型进行创新性的结构改进并针对性的引入多种增强算法性能的策略,最大程度的提升目标检测模型在极片缺陷检测方面的应用效率。最终本章所提出的改进 YOLO 算法可实现极片缺陷的高准确率分类与高精度定位,在 3.4 小节得到实验验证,通过各类实验的对比与多种性能评估参数的比较展现了本文所提 YOLO 算法在极片缺陷检测领域中的卓越性能。

3.2 目标检测算法

目标检测技术在深度学习领域可以分为双阶段目标检测算法和单阶段目标检测算法两大类。双阶段检测算法顾名思义,分为先确定图像中的感兴趣区域和对这些区域进行分类识别这两个步骤,从而对图像中的目标进行精确检测。而单阶段检测算法将目标定位与分类融合在一起,简化检测流程的同时更全面的利用图像中的空间信息,从而实现检测精度与检测速度的均衡。

3.2.1 双阶段目标检测算法

典型的双阶段目标检测算法的典型有 R-CNN(Regions with Convolutional Neural Networks)、Fast R-CNN、Faster R-CNN 等。R-CNN 于 2014 年被 GIRSHICK 等人提出,其首次将选择搜索算法与卷积神经网络(Convolutional Neural Network, CNN)进行结合,通过选择搜索算法产生候选区域,利用卷积神经网络实现候选区的特征提取,最终使用 SVM 分类器和回归器实现各个区域的目标分类和定位^[43]。Fast R-CNN 是 R-CNN 的改进版,其将整张图像输入全卷积网络进行特征提取,利用池化技术对 ROI 区域进行划分,极大地提高了检测精度与速率^[44]。Faster R-CNN 则是对 R-CNN 和 Fast R-CNN 的进一步改进,其引入全新的全卷积网络 RPN(Region Proposal Network)代替选择搜索算法去生成候选区域,RPN 和分类网络共享卷积特征提取从而实现端对端的训练和预测。综合来

看, Faster R-CNN 是双阶段算法中较为有效的一种, 实现了更快地检测速度和更好地检测精度^[45]。

3.2.2 YOLO 系列检测算法

单阶段目标检测算法的优势在于检测精度与检测速度的均衡性, 相比于双阶段检测算法, 其通过将分类和定位融合成同一任务从而更好地利用图像的空间信息。YOLO 系列算法是单阶段目标检测算法中综合性能最佳的代表作, 在经过多个版本演变优化后, 目前 YOLO 算法已经发布了 8 个版本。

YOLOv1 是 2015 年的 YOLO 首发版本, 其将输入图像直接划分为 $S \times S$ 个网格, 接着针对每个网格预测出 B 个边界框的同时计算相应的类别置信度, 最终通过回归得到每个边界框的位置^[46]。YOLOv2 是于 2016 年提出, 在 v1 的基础上提出 Darknet-19 网络、锚框、批量归一化、多尺度训练、联合训练机制等优化方式, 其在 VOC2007 和 VOC2012 数据集上的检测准确率分别提升 15.2% 和 15.5%, 在加速检测流程的同时提升算法的稳定性^[47]。YOLOv3 是在 2018 年发布, 其在 v2 的基础上将 Darknet-19 改成更加高效的 Darknet-53 网络同时添加多尺度检测, 引入特征金字塔进行特征融合从而大幅提升模型的识别性能并在实际应用中取得较高的评价^[48]。YOLOv4 结合许多近年提出的优化策略进行改进, 该模型于 2020 年发布。其首先提出 CSPDarknet53 作为主干网络并引入空间池化金字塔 SPP 模块(Spatial Pyramid Pooling)和路径聚合网络 PANnet(Path Aggregation Network)等机制, 增强细粒度特征和小目标的识别能力, 最终引入 CIoU(Complete Intersection over Union)损失函数、自对抗训练(Self-Adversarial Training, SAT)、马赛克(Mosica)数据增强、类标签平滑等创新点, 大幅增强模型的抗过拟合能力和收敛速度^[49-52]。2021 年 Ultralytics 团队在 Github 发布 YOLOv5, 依照网络深度和宽度的不同分为 YOLOv5s、YOLOv5m、YOLOv5x、YOLOv5l、YOLOv5n, 实际应用时可根据不同需求选择合适版本进行相应的检测任务^[53]。YOLOv5 相比于 v4 增加了自适应锚框、SPPF 模块(Spatial Pyramid Pooling with Features)、GIoU(Generalized Intersection over Union)损失函数等优化点, 延续 YOLO 系列算法快速、准确的特性^[54]。2022 年美团致力于工业检测任务, 研发了 YOLOv6 检测模型。该模型基于 Rep 算子提出 EfficientRep 网络和 Rep-PAN, 同时引入解耦头、SimOTA(Simplified Optimal Transport Assignment)标签分配策略、SIoU 损失函数等创新策略, 兼顾检测精度的同时大幅减少硬件导致的时延^[55,56]。同年原 YOLOv4 团队研发出 YOLOv7 检测器, 使用 ELAN 模块替换 CSP 模块(Cross Stage Partial)并将下采样变成 MP2(Max Pooling 2)层, 为防止过拟合在每个卷积层后使用批量

归一化和 SiLU(Sigmoid-Weighted Linear Unit)激活函数,减少参数运算量的同时小幅提升模型性能^[57]。

2023 年 YOLOv8 出世,其是由 Ultralytics 团队发布的最新版 YOLO 算法框架,其进一步的提升 YOLO 系列模型的灵活性、可扩展性及综合性能,可实现目标检测及图像分割任务^[58]。相对于其他的单阶段算法以及前序 YOLO 系列模型,YOLOv8 的优势在于提供最新的 SOTA(State of the Art)技术并具备用户友好的 API,且检测速度更快、准确率更高。YOLOv8 由骨干网络(Backbone)、特征融合网络(Neck)、检测头(Head)组成,其网络结构图如下图 3-1 所示。从整体结构来看,YOLOv8 是在 YOLOv5 的基础上结合 YOLOv6、YOLOv7、YOLOvX 的改进策略创建一个全新的骨干网络和检测头,并沿用 PANnet 特征融合方式^[50,53,56,57,59]。v8 也基于模型的深度、宽度、比率分为 n/s/m/l/x 五种不同尺度大小的模型从而适用于不同的检测场景。

1. 输入

为满足 YOLOv8 的预设图像尺寸 $640 \times 640 \times 3$,先将输入图像进行缩放并保持其纵横比,同时为避免变形在图像边缘添加黑色像素来填充空白区域;接着将图像转换到 RGB 色彩空间,将图像维度的顺序从高宽通道(HWC)变换到通道高宽(CHW);最后将像素值的数据类型转换成 0-1 的浮点类型。对于数据增强依然沿用 v5 的马赛克增强(Mosica)、混合增强(Mixup)、空间扰动(Random Perspective)和颜色扰动(HSV augment)^[53]。

2. 骨干网络

v8 的骨干网络主要参考 CSPDarkNet-53 结构,通过框架图可知该骨干网络主要由 CBS 模块、C2F1_X 模块组成^[60]。CBS 模块是由二维卷积、批归一化和 SiLU 激活函数组成。C2F1 模块则是由 CBS、Split 操作、Bottleneck_1 模块及 Concat 组成,其在 v5 结构的基础上参考 v7 中 ELAN 的设计路线并结合 DenseNet 的核心思想,从而增加更多的跨层连接^[53,57,61]。对于 C2F1_X 的 X 是指 Bottleneck_1 模块的个数,该模块由两个 CBS 加残差边组成^[62]。Concat 操作是将深浅层通道信息进行组合。从整体来看主干网络先对输入图像进行两个 3×3 的卷积操作,在降低图像分辨率的同时加深特征图的深度,C2F1 模块的配置是 3/6/6/3,在一定程度下压缩网络规模的同时大幅减少计算参数,同时对模型的梯度特征流进行丰富并增强网络的收敛程度。

3. 特征融合网络

对于 Neck 部分,首先采用 SPPF 模块,接着将主干网络中的三个特征层借鉴 PAN 思想也就是自下向上和自上向下的双向通道进行特征融合,在这里主要使用 C2F2 模块、

上采样、Concat 等操作进行特征通道的整合。SPPF 是 SPP 的优化版本，通过创建一个池化金字塔保持空间信息的同时提取尺度不变的特征，结合残差结构与稠密连接的思路，将 SPP 简单并行最大池化的方式改成串行加并行，大大加快了模块的计算速度。C2F2 模块则是由 CBS、Split 操作、Bottleneck_2 模块及 Concat 组成，其中的 Bottleneck_2 模块相比于 Bottleneck_1 减少了残差结构。




图 3-1 YOLOv8 网络结构图

4. 检测头

在 v8 版本中，通过采纳一种解耦式的检测头架构，每个尺度均配备独立的检测器，并去除了 Obj 分支，转而只采用分类与回归两个分支^[59]。对于分类任务，采用二分类交叉熵损失函数(Binary Cross-Entropy Loss, BCE Loss)；回归任务则采取完全交并比损失函数和分布式焦点损失(Distribution Focal Loss)。此外，v8 弃用了传统的锚框(Anchor Box)设计，转向无锚框(Anchor free)的方法，并引入一种动态的任务对齐分配器(Task Aligned Assigner)，用于更加高效地进行正负样本的匹配。

相对于其他目标检测算法，YOLOv8 不但具备着更快、更准的顶尖性能，还更加高效灵活，且提供完整的 CLI API 和 Python SDK，方便依照预设检测目标的特点对代码进

行具体的更改与提升。因此,本文以 YOLOv8 网络模型为基础对极片表面的七种缺陷进行目标识别。

3.3 基于 YOLOv8 的改进检测方案

尽管 YOLOv8 引入多项创新点大幅提高模型的综合性能,但由于其作为单阶段检测模型,存在因集成分类与回归所带来检测精度方面的限制,导致直接将该模型应用在锂电池极片缺陷的检测时,对一些微小、形态不规则的缺陷,例如划痕缺陷长短深浅不一、暗斑缺陷形态多变、凹坑及压痕缺陷对比度低、部分缺陷间形态差异不大等场景存在识别精度大幅受限的问题。上述难点给网络的特征提取带来很大的挑战,因此本文结合极片表面七种缺陷的检测需求从注意力机制、特征融合、损失函数等方面对 YOLOv8 进行综合性的创新改进,以实现兼顾识别精度与实时性的目标检测算法,从而解决网络表征能力较弱及定位精度较低等难题。

3.3.1 主干网络的改进

YOLOv8 主干网络采用连续两个 3×3 且步长为 2 的卷积核对输入进行下采样,该操作可以增大网络中后续层的感受野,从而捕获图像更细致和丰富的语义细节信息,同时能够使网络在不同尺度上对特征进行学习以提高模型对大小尺寸物体的检测能力。然而连续下采样也可能带来一些负面影响,比如对于小目标的特征信息可能会被过度降低以致丢失。为解决上述问题并结合极片缺陷微小对比度低的实际特点,引入一种基于深度卷积的多尺度动态注意力机制在最大程度提升网络表征能力的同时减少模型的计算量,满足模型高实时性的需求。

1. 多尺度动态注意力机制

现被广泛应用的注意力机制有 SE(Squeeze-and-Excitation)模块和 CBAM(Convolutional Block Attention Module)模块^[63,64]。SE 模块主要关注通道的注意力,通过给不同特征通道赋予权重从而对关键特征进行重标定,如图 3-2a)所示。CBAM 模块则是一个既关注通道信息又关注空间信息的序列,其先后对输入特征进行通道上和空间上的注意力加权,如图 3-2b)所示。通道注意力有助于提取更具区分性的特征,空间注意力能够加强网络对待测目标的空间定位能力。相对于 SE 模块,CBAM 模块虽将通道和空间注意力进行整合,具备更好地特征提取性能和关键区域选择能力,但它在所有输出特征通道中强制实现一致的空间注意力分布,导致空间注意力权重不能基于每个通道的特性动态调整从而限制了注意力的自适应能力。

为解决上述问题,本文引入多尺度动态注意力机制,通过采用多尺度的深度可分离卷积模块依次提取每个通道的关键空间区域,从而在每个通道上动态分布空间注意力,模块图如图 3-2c)所示,具体的流程图如图 3-3 所示^[65]。




图 3-2 三种注意力模块图

假设输入特征图的维度为 $H \times W \times C$,其中 H 是高度, W 是宽度, C 是通道数,首先对输入特征分别进行全局最大池化和全局平均池化,可得到两个 $1 \times 1 \times C$ 的向量。全局最大池化得到向量的每个元素代表相对应通道中所有特征的最大值,而全局平均池化得到向量的每个元素代表相对应通道中全部特征的平均值。接着将这两个向量送入一个共享多层感知器(Multi-Layer Perceptron, MLP)中,处理不同通道间的复杂关系,接着将 MLP 输出的两个向量在通道维度上进行相加操作,后通过 sigmoid 激活函数对权重值进行归一化处理,再将输入特征进行逐元素加权,最终得到通道注意力重标定特征图。




图 3-3 多尺度动态注意力机制流程图

对于空间注意力机制部分，先将重标定的特征图送入一个 5×5 的深度卷积中，从而对局部信息进行聚合。结合本文目标考虑到需提升对小目标的特征提取能力所以接着将其送入一个多分支的深度条形卷积中以捕获多尺度的上下文信息^[66]。在此处分别使用 7、11、21 大小的卷积核，同时通过使用连续条形卷积的策略在大大减少模型计算量的同时，有效地模拟较大的感受野，在保持网络深度和特征学习能力的同时大幅提升了运行效率。之后将各尺度的卷积结果进行空间维度上的相加后，通过一个 1×1 的卷积实现各通道的混合，最终将混合结果与通道权重重标定后的特征图进行逐元素相乘，最终得到基于多尺度卷积模块的动态注意力特征图。该注意力机制结合了通道注意力和空间注意力，通过多分支深度卷积模块令特征通道上自适应生成空间注意力权重从而着重提高对微小目标的特征提取能力，在最大程度提升网络表征能力的同时保持较低的计算复杂度。

2. 改进后的 C2F 模块

注意力机制插入网络的位置也对模型的特征表达能力与学习能力有着巨大的影响。如果直接将多尺度动态注意力模块插入特征融合部分或是检测头中，可能会导致后续网络层难以从融合后的特征图中辨别出冗余信息与关键特征。这种辨识特征的模糊性可能会造成特征信息的传递误差，并大幅削弱模型的识别精度。在浅层网络中，特征图包含着丰富的图像细节信息，如纹理特征、边缘特征及颜色变化等，对于小尺寸目标的检测格外重要。对于深层网络提取到的特征信息往往更加复杂和抽象，包含着更多的语义信息及上下文信息，以便于模型对目标的分类和识别。

由于本文待测缺陷目标微小且对比度低，低层次的网络细节信息就尤为重要，因此本文提出在主干网络 C2F1 模块的残差单元中插入多尺度动态注意力模块，改进后的 Attn_C2F1 模块如下图 3-4 所示。通过该注意力机制可以强调关键的位置信息与通道特征，同时淡化冗余信息，随后通过残差模块对这些重要特征进行深度提取。该种嵌入注意力的策略对关键特征信息的增强贯穿整个网络结构，不但缓解图像纹理轮廓等细节信息的流失还在仅增加较低计算资源的同时显著提升主干网络对于关键特征的提取性能与学习能力。




图 3-4 改进后的 Attn_C2F1 结构示意图

3.3.2 特征融合部分的改进

1. SPFF 模块的改进

SPP 模块在网络中起到扩大感受野、固定输出尺寸、减少信息损失、降低相关计算量等综合作用。而 SPFF 模块是基于 SPP 模块的改进，在保持精度的同时比 SPP 快 2 倍以上。YOLOv6 框架的 3.0 版本中引出了 SimCSPSPFF 模块，其在大幅提升检测精度的同时保持较低的运算量，对本文的待测极片缺陷较为适用，因此本文选取该模块对 SPFF 进行改进，其框图如下图 3-5 所示^[67]。

SimCSPSPFF 这个模块融合 CSP 与 SPFF 的特性，并通过替换激活函数等精简设计实现了性能均衡^[53,60]。该模块虽稍稍牺牲了网络的实时性但对模型的准确率做出显著提升。将 SiLU 激活函数替换成 ReLU(Rectified Linear Unit)激活函数，单个 SimConv 比原 CBS 模块快 18%。CSP 将网络中的特征层分成两个部分，对其中一个路径执行卷积操作从而使减半通道数量，接着对另一个路径引入梯度流分支，随后将这两条路径进行重新合并，该方法在计算资源有限的情况下大幅提升了模型的表征能力与学习能力。




图 3-5 SimCSPSPPF 模块结构示意图

2. 改进的多尺度特征金字塔

在 YOLOv8 的网络模型里,经过特征主干网络进行特征提取之后可以获得一系列具有不同深度和粒度的特征层。这些特征层由浅到深对图像从低级到高级的特征依次进行了学习与提取。深层特征蕴含较复杂且丰富的全局语义信息且具备较大的感受野,更擅长对目标进行整体性的识别和分类,但其分辨率较低且图像的细节纹理等细节信息表现力较弱,这导致深层特征在预测小尺寸目标方面的性能不佳。与此同时,浅层特征虽然包括丰富的细节纹理及空间定位信息,其对于小目标的识别相对具备一定的优势,但是浅层所捕捉的语义信息较为有限,不足以有效地对大型目标进行检测。为了克服上述的限制并提升对各尺寸目标的检测能力,不同深度的特征映射需要按一定策略进行融合。原始的 YOLOv8 通过 PANet 结构使深浅层次特征进行合理融合。三个分辨率不同的特征层(分别对应着输入图像分辨率的 $1/8$ 、 $1/16$ 、 $1/32$ 即 80×80 、 40×40 、 20×20)被输入到网络中进行处理。PANet 通过从深层到浅层的顺序进行上采样和特征融合,以及反向的从浅层特征到深层特征的融合,实现了双向的特征流动,如下图 3-6a)所示^[50]。该种特征融合方式增强了深层与浅层语义信息及位置信息的综合整合能力,进而提升了

对大小目标的识别及定位性能。在经过特征融合网络对不同通道的融合后，PANet 输出的结果分别对应着三种不同尺寸级别的目标预测分支。每一分支均可有效地结合高维特征层的语义信息与低维特征层的定位信息，以实现尺寸分布范围较广目标的有效检测。然而针对锂电池极片表面缺陷细小、低对比度且形态多变不规则等特点，YOLOv8 的原有结构在捕获细粒度信息方面的表现有限，可能会导致对小目标缺陷的漏检或误检。为提高整体模型的检测性能，本文对特征融合网络进行创新性的优化，提出一种 Dense-BiFPN 的多头检测器，旨在更高效地利用浅层特征所包含的丰富纹理细节，增强对图像边缘等细粒度特征等的学习能力，并促进高层语义信息与低层位置信息的融合。

浅层特征的高分辨率强几何表征能力是精准识别微小目标的关键，因此本文首先在 YOLOv8 的三个检测头的基础上，再引出一个输入图像 1/4 分辨率即 160×160 的浅层检测头，其可以在保留更多空间信息的同时传递丰富的低层次细粒度特征，帮助网络更好地进行浅层特征映射以改善梯度流动，从而加速模型收敛并提升整体训练效果。接着为提升跨尺度特征融合的效果并最大程度地降低 PANet 结构的冗余性，受深度学习网络 EfficientNet 中的双向特征金字塔网络(Bidirectional Feature Pyramid Network, BiFPN)启发，本文引入一种四尺度的 BiFPN，该特征融合方式通过多个自上而下和自下而上的双向路径加强特征学习，使每个特征层都经过多次迭代从而进行充分的信息融合，同时引入可学习的权重使网络在特征融合时根据不同特征图的重要性进行自动平衡，相比于 PANet 的简单特征相加或是连接更能捕捉关键信息，如下图 3-6b)所示^[68]。同时该种多尺度融合方式使用了更为高效的深度卷积并消除部分冗余连接，具备更高效的计算能力和更清晰的信息流动路径，从而可以在处理多尺度特征和高实时性场景中有着较为优越的表现。对于特征图间的加权融合选取快速归一融合方法，见式(3-1)，其中 i 和 j 是特征融合节点输入层的数量且 $i=j$ ， $\varepsilon = 0.0001$ ； ω 为各输入特征层所学习的权重值； I 为节点的输入特征图； O 为节点的输出特征图。

$$O = \sum_i \frac{\omega_i}{\varepsilon + \sum_j \omega_j} \cdot I_i \quad (3-1)$$

鉴于高分辨率的浅层特征对细小目标的识别有着显著的帮助，为大幅提升极片表面微小缺陷的检测性能，本文旨在通过更深入地整合这些细节信息以提升模型的识别精度。因此，本文将稠密连接策略应用到 BiFPN 特征金字塔中，以便更好地对浅层特征进行相应的融合，在均衡网络复杂度和计算负载的同时使该结构能够在本文识别目标中表现出高准确率与高精度的优秀性能，如下图 3-6c)所示^[61]。其中新增的高分辨率预测分支

对微小缺陷的检测做出巨大贡献，其融合了丰富的细节信息和更高层次的语义信息，使得模型能够更好地理解目标的上下文结构并捕捉极片表面缺陷的细微变化，大幅提高了网络对微小的检测性能。




图 3-6 三种特征融合网络对比图

3.3.3 改进损失函数

极片表面的缺陷大多尺寸微小且包含的像素极少，不仅如此对于原始数据集也存在着难易样本不均衡等问题，给模型的精准识别带来巨大挑战。而原 YOLOv8 网络是基于完全交并比损失函数和分布式焦点损失函数进行边界框回归损失的计算，其中 CIOU 并未考虑困难样本的问题，且由于 IoU(Intersection over Union)对小目标的位置偏差过于 CIOU 敏感，导致其更适合中大型检测对象，在小目标检测方面难以取得较好的效果。综上所述，在损失函数方面本文引入滑动损失函数(Slide Loss)和 NWD(Normalized Wasserstein Distance)以分别克服难易样本不均衡及小目标识别性能低等困难^[69,70]。

对于本文待测极片数据集难易样本分布不均衡导致原始 YOLOv8 对暗斑、凹坑这类缺陷的识别能力较差、模型泛化能力较差等问题，引入一种滑动损失函数。难易样本依据预测框和真实框之间的交并比指标的值进行判断。一般选取所有检测框的 IoU 值的均值 μ 作为一个边界阈值，低于该值的标定为负样本，高于该值的视为正样本。由于边界

的样本通常因分类模糊导致较为严重的识别损失，如果能在模型中对这部分样本给予额外的关注并在训练中更多地利用它们，可以实现对模型的大幅优化。因此，本文通过自定义加权函数为这些困难样本分配高权重，从而使网络将更多的注意力置于错识别的困难样本中。首先通过参数 μ 对正负样本分类，接着通过加权函数 Slide 对边界样本进行强调，加权函数见式(3-2)。该种损失函数可以自适应地对正负样本进行学习，通过动态调整提高模型对困难样本的整体识别和分类能力。

$$f(x) = \begin{cases} 1 & x \leq \mu - 0.1 \\ e^{1-\mu} & \mu < x < \mu + 0.1 \\ e^{1-x} & x \geq \mu \end{cases} \quad (3-2)$$

为解决交并比在小目标检测过于敏感的劣势，引入一种基于 NWD 的回归损失函数，基于 Wasserstein 距离原理将 BBox 建模成二维的高斯分布并引入 NWD 新度量，从而通过比较各自的高斯分布来计算边界框间的相似度。NWD 具体的计算公式见式(3-3)，其中 C 是根据数据集实验而得的最佳参数， $W_2^2(N_a, N_b)$ 则是相应的距离度量。该度量值的计算方式见式(3-4)所示， N_a 和 N_b 分别是由真实框 $A = (cx_a, cy_a, w_a/2, h_a/2)$ 和预测框 $B = (cx_b, cy_b, w_b/2, h_b/2)$ 建模的高斯分布。

$$NWD(N_a, N_b) = \exp\left(-\frac{\sqrt{W_2^2(N_a, N_b)}}{C}\right) \quad (3-3)$$

$$W_2^2(N_a, N_b) = \left\| \begin{bmatrix} cx_a, cy_a, \frac{w_a}{2}, \frac{h_a}{2} \end{bmatrix}^T, \begin{bmatrix} cx_b, cy_b, \frac{w_b}{2}, \frac{h_b}{2} \end{bmatrix}^T \right\|_2^2 \quad (3-4)$$

由于 NWD 损失函数在检测小目标时具备对微小差异的响应更光滑从而提升梯度下降优化过程的稳定性，并且在评估不重叠的边界框时其能够赋予非零的相似度值等优势，导致其相对 IoU 损失函数可以更好地完成微小目标的检测任务。因此在回归损失函数中引入 NWD 损失以改善 IoU 在极片缺陷检测方面的不足，并且将二者比例调整为 4:6，见式(3-5)。

$$Loss_{loc} = IoU \times 0.6 + NWD \times 0.4 \quad (3-5)$$

3.4 实验结果分析

3.4.1 改进的 YOLOv8 整体框架

为解决锂电池极片表面缺陷微小且形态多变等综合检测难点，在精准识别分类极片表面缺陷的同时提取 ROI，对 YOLOv8 算法进行创新性改进。本文所提出的改进 YOLO

算法结构图如下图 3-7 所示，其中 Attn_C2F1_X 模块、SimCSPSPPF 模块的结构图及 BiFPN_Cat 的计算方式如上几个小节所述。




图 3-7 改进 YOLO 算法结构图

3.4.2 数据集制作及环境配置

本文于 2.3.1 小节对硬件系统中的成像系统进行介绍，最先采集到的待测极片原图的横向分辨率为 8192，若直接对其进行目标检测，可能会因分辨率过大导致极片的识别速度和精准率受到影响。除此之外考虑到分割边界可能存在缺陷的问题，将初次采集到的极片图像分割成横向分辨率为 2200，纵向分辨率为 1300 的图像。为验证本文检测算法的泛化性及鲁棒性并扩充缺陷的种类，待测原材料选取两种颜色深浅略有不同的极片，最终共采集到七类缺陷图像 3416 张。接着采用 LabelImg 软件对凹坑、暗斑、划痕、孔洞、气泡、压痕、漏金属这七类缺陷进行标注和定位并导出 YOLO 格式的数据集，之后按照 75%、15%、10% 的比例对训练集、验证集、测试集进行划分。

本文进行模型训练和测试的软硬件环境配置为：Windows10 操作系统、PyTorch v2.0.0、Python v3.8、CUDA v11.8、GPU NVIDIA GeForce RTX 3060、CPU Intel i5-7300HQ@2.50GHz、16GB RAM。

3.4.3 主要评估指标

为评判本文改进的 YOLOv8 检测算法的高效性，通过一些指标进行检测性能的综合评估，主要选取准确率(Precision)、召回率(Recall)、平均检测精度(Average Precision, AP)、全类别平均检测精度(Mean Average Precision, mAP)等指标来衡量模型性能。计算上述指标时，会涉及到 TP (True Positive)、FN (False Negative)和 FP (False Positive)三个参数。

在本文的检测场景中，正样本指应被准确识别的极片表面缺陷。 TP 为真阳性，表示模型正确识别出的正样本的数量， FN 为假阴性，表示检测过程中遗漏正样本的数量， FP 为假阳性，表示非正样本的对象被误检为正样本的数量。下面将对这些指标进行详细解释。

1. 召回率

召回率直接反映模型正确检测到正样本的能力，该参数用来评估所有真实缺陷中有多少可被模型检测出。召回率的值范围从 0 到 1，该值越高代表模型遗漏正样本的比例越低，模型识别正样本的能力越强。该值在缺陷检测中较为重要，计算公式见式(3-6)。

$$Recall = \frac{TP}{TP + FN} \quad (3-6)$$

2. 准确率

准确率描述了模型所做预测的正确性，其为正确识别的正样本数量与总检测出目标个数的比例。该值越高代表模型识别的准确率越高，但当数据中的类分布不平衡时，该参数可能会给出一个过于乐观的性能评估，计算公式见式(3-7)。

$$Precision = \frac{TP}{TP + FP} \quad (3-7)$$

3. 平均检测精度

考虑到单独使用准确率和召回率参数的局限性，引入 AP 以综合衡量模型对于特定缺陷类别的检测性能。通常 AP 是基于准确率-召回率曲线进行计算，该曲线是在不同阈值设置下模型所产生的不同精度和召回率，将召回率作为横坐标，准确率作为纵坐标生成一条曲线， AP 即这条曲线下的面积，对于多类别识别问题 mAP 是所有类别 AP 的均值。 AP 的值越大表示模型对该类别目标检测性能越好， mAP 的值越高代表模型的识别性能及泛化能力越强，计算公式见式(3-8)和式(3-9)。

$$AP = \int_0^1 p(r)dr \quad (3-8)$$

$$mAP = \text{Average}(\sum AP) \quad (3-9)$$

3.4.4 实验结果对比及分析

本实验将输入图像分辨率统一调整到 640×640 ，在数据预处理阶段使用 Mosaic 和 Mixup 两种数据增强方式，在最后十个 epoch 时关闭 Mosaic，对于训练过程使用随机梯度下降法对网络参数进行优化，设学习率为 0.01，学习率动量为 0.937，权重衰减为 0.0005，

batch 为 16, epoch 为 150。原 YOLOv8 和本文所提改进 YOLO 模型的网络训练损失对比曲线如下图 3-8 所示,图中横坐标为迭代次数,纵坐标为训练的分类损失和定位损失,从图中观察可知前 10 次迭代过程中损失值快速下降后在 120 次迭代以后趋于平稳。显然改进后 YOLO 算法的分类与定位损失的收敛速度都大幅提升,网络收敛速度加快且最终损失收敛值得到明显降低,分类损失收敛值接近于 0.08 且定位损失收敛值接近于 0.3 左右。本文所提的改进模块及损失函数等优化策略使模型的检测结果最大程度的接近真实值,从损失变化对比图可综合展现出本文模型相对原 YOLOv8 的性能提升。





图 3-8 改进前后模型分类与定位损失变化对比图


通过上述训练后,得到原 YOLOv8 模型和本文所提的优化 YOLO 模型。基于先前小节所描述的评估指标,将这两种模型分别于测试集上执行识别任务,计算相关缺陷类别的准确率和召回率并绘制 P-R 曲线(准确率-召回率曲线),分别如下图 3-9a)和 3-9b)所示。图中 HH、KD、AB、AK、LJS、QP、YH 分别代表划痕、孔洞、暗斑、凹坑、漏金属、气泡及压痕缺陷。通过对比可发现本文所提模型的 P-R 曲线整体包围面积更接近 1,跨全类别预测性能的大幅提升,体现出优化模型在检测精度方面的优越性。

下表 3-1 为两类检测模型各类别准确率、召回率、AP 和 mAP,对于原始模型其召回率整体较低,且因暗斑、划痕、凹坑这三类缺陷形态多变且尺寸微小导致平均检测精度过低,特别是对于暗斑缺陷 AP 只有 62.12%,这三类缺陷的低 AP 导致当 IoU 选取 0.5 时原模型的 mAP 只有 86.42%。改进算法针对形态不规则缺陷的检测难点进行针对性的性能提升,提升暗斑缺陷的平均检测精度至 88.24%,对于划痕、凹坑缺陷的 AP 也分别提升了 7.69%和 9.53%,对于其他四类检测结果较好的缺陷也分别有不同程度的提升。最终,与原模型相比本文所提改进模型的准确率提升 6.18%,召回率大幅提升 11.08%,

全类别平均检测精度整体提升 8%，*mAP* 高达 94.42%，直观地展现出本文所提模型的显著优势，验证其在极片缺陷检测任务中的强大性能。



a) YOLOv8 模型的 P-R 曲线



b) 本文改进 YOLO 模型的 P-R 曲线

图 3-9 原始与改进模型的 P-R 曲线对比图

表 3-1 原始与改进算各类别评估指标对比

	YOLOv8				本文改进 YOLO 算法			
	准确率/%	召回率/%	<i>AP</i> /%	<i>mAP</i> /%	准确率/%	召回率/%	<i>AP</i> /%	<i>mAP</i> /%
HH	83.46	78.76	84.14	86.42	93.66	90.86	91.83	94.42
KD	88.92	92.95	94.66		96.52	97.08	98.51	
AB	76.31	54.89	62.12		91.34	85.49	88.24	
AK	87.28	69.51	82.58		95.81	89.96	92.11	
LJS	97.46	90.23	95.21		94.41	98.14	97.89	
QP	93.49	88.48	92.79		92.76	90.53	95.77	
YH	91.12	89.31	93.42		92.77	89.61	96.56	

根据上述 P-R 曲线与表格可以直观地看出改进模型相对原模型的识别性能的综合提升, 但为验证本文改进算法中各个模块对网络性能提升的贡献程度, 本文搭建一系列消融实验, 将本文所提的改进模块逐步添加进 YOLOv8 网络中, 并分析各模块对各类别缺陷的 AP 、 mAP 的影响。除上述指标的分析, 本文还通过绘制类激活映射图, 直观展示不同模块对网络表征能力和关键特征提取能力的积极影响。各模型实验结果参数如表 3-2 所示 (表中使用★代表引入相应模块), 类激活图如下图 3-10 所示, 图中红色表示高激活而蓝色表示低激活。

表 3-2 原始与改进算各类别评估指标对比

模型	Attn_ C2F1	SimCSP SPPF	Dense- BiFPN	改进损 失函数	AP /%							mAP /%
					HH	KD	AB	AK	LJS	QP	YH	
1					84.14	94.66	62.12	82.58	95.21	92.79	93.42	86.42
2	★				88.32	97.11	79.21	86.43	96.62	93.88	95.09	90.95
3		★			85.91	95.03	70.49	85.12	95.99	93.45	93.88	88.55
4			★		88.93	97.28	80.51	86.09	96.91	94.01	95.33	91.29
5	★			★	89.69	97.87	85.91	90.05	96.87	94.31	96.04	92.96
6			★	★	90.97	97.92	86.96	89.78	97.41	94.68	95.82	93.36
7	★	★	★	★	91.83	98.51	88.24	92.11	97.89	95.77	96.56	94.42




图 3-10 消融实验各类模型类激活图

结合图表分析各个模块对各类检测精度的贡献程度:

1. 模型 2 为大幅提升网络的表征能力, 引入本文所提的 Attn_C2F1 模块。该模块在 C2F1 的基础上嵌入多尺度注意力机制, 在淡化网络无关信息的同时强调模型识别的关键特征, 同时通过多尺度的深度卷积提升微小特征的提取能力。通过分析各类别的 AP 和

发现, 该模型在模型 1 表现较差的缺陷类别上皆取得较大的性能提高, 整体 mAP 提升至 90.95%, 大幅提升检测精度。对比类激活图可知在引入注意力机制后, 有效解决特征提取困难及网络传播过程中细节损失严重的问题。

2. 模型 3 通过把模型 1 的 SPPF 模块更换为 SimCSPSPPF 模块, 实现全类别检测精度的提升。该模块在保留多尺度空间信息的同时扩大感受野, 提升对于划痕、暗斑这类跨尺度缺陷的识别能力。通过 CSP 结构实现在较少计算成本下模型深层特征学习能力的提升, 最终整体 mAP 较模型 1 提高 2.14%, 验证了该模块的高效性。

3. 模型 4 是将模型 1 的 PANet 特征融合网络改进成基于多尺度的稠密连接双向特征金字塔网络。该模块提供双向路径的深浅层次特征融合并通过稠密连接降低冗余信息, 因此对形态多变且尺寸跨度较大的检测对象可以取得更为显著的性能提升。通过分析检测精度指标发现与模型 1 相比, 该模型针对划痕、暗斑缺陷皆有较好的检测结果, AP 分别提升了 4.79% 和 18.39%, 同时由于该模块增加浅层检测头以增强网络对浅层语义信息的提取能力, 从而提升小目标对象的检测精度, 因此其对凹坑、孔洞等微小缺陷的识别能力得到显著提升。通过绘制热力图也可对多尺度 Dense-BiFPN 模块的正向积极性进行再次验证。

4. 为验证改进损失函数在解决 IoU 对小目标位置偏差过于敏感以及难易样本不均衡问题的能力, 分别在模型 2 嵌入注意力机制的基础上和模型 4 更换特征融合网络方式的基础上加入改进的 Slide-NWD 损失函数作为模型 5 和模型 6 进行验证。观察热力图可知, 相比模型 2 和模型 4, 模型 5 与模型 6 的缺陷目标区域大范围得到高激活, 模型 5 相对模型 6 的特征提取能力更强而模型 6 相对模型 5 的高激活范围更为精准, 体现出改进损失函数模块与不同模块结合时对网络的识别与定位能力皆会有不同程度的性能提升。通过对比各类别检测精度指标发现, 模型 5 和模型 6 对于原模型检测精度较低的划痕、暗斑及凹坑缺陷分别提升 5.55% 和 6.83%、23.79% 和 24.84%、7.47% 和 7.2%, 整体 mAP 分别提高 6.55% 和 6.95%。改进模块通过将自适应学习正负样本阈值参数的滑动损失函数与 NWD 结合, 从而提升对困难样本及小目标的识别性能, 以上实验对其有效性进行了验证。

模型 7 则是本文所提出的改进 YOLO 算法, 其融合所有模块的创新点, 并在极片各类缺陷识别方面取得检测精度的最高幅度提升。类激活图也直观表明模型 7 的缺陷表征能力更强且高激活定位更为精准。通过一系列消融对比实验发现, 本文所提的改进 YOLO 算法对于尺寸微小、形态跨度大且边缘模糊的极片缺陷具备较为优异的检测效果,

较原算法具有显著优势。

为进一步客观地验证本文所提出的改进 YOLO 算法的优越性,本文将其与现阶段工业生产中缺陷检测常用的几种经典算法进行识别精度与检测速率的比较,其包括双阶段检测模型结合特征金字塔与柔性非极大值抑制的改进 Faster R-CNN 和单阶段检测模型中较为先进的 YOLOv6、YOLOv7 及 YOLOv8,其实验结果指标如下表 3-3 所示,其中 Attn-CSPDarknet 表示本文所提出的嵌入多尺度注意力机制的主干网络^[71]。


表 3-3 算法实验的评估指标对比

模型	主干网络	mAP /%	检测速度/FPS
改进的 Faster R-CNN	Resnet50	89.92	11.36
YOLOv6	EfficientRep	83.18	43.32
YOLOv7	RepConvN	61.08	51.91
YOLOv8	CSPDarknet	86.42	45.85
本文改进 YOLO 算法	Attn-CSPDarknet	94.42	40.06

通过分析表中数据可知,相对原始 YOLO 系列算法,针对小目标所改进的 Faster RCNN 模型具备双阶段检测算法的优势,平均检测精度较高,但检测速率只有 11.36FPS,难以满足工业生产实时检测的需求。而将 YOLOv6 至 v8 系列算法应用于锂电池极片表面缺陷检测时,YOLOv8 虽检测速度略低于 v7 但其识别精度最高,模型平衡性最强,验证本文基于 YOLOv8 算法进行改进的正确性。由于本文改进算法在主干网络嵌入注意力机制并于特征融合网络中多引出一个小目标检测头,导致该模型的识别速率略低于原 YOLO 系列算法,但检测速率还是远高于双阶段系列网络模型,完全满足工业生产的实时性需求,且 mAP 较 v6、v7、v8 分别提升了 11.24%、33.34%、8%,相较近年来流行的检测模型具备一定的工业应用优势。

为进一步验证本文所提改进模型对缺陷区域的精准定位,将改进前后的模型识别结果进行直观对比,如下图 3-11 所示。通过观察下图,本文所提的改进 YOLO 算法对极片七类缺陷的置信度得分均高于原模型,针对微小的凹坑缺陷也未出现漏检的问题且对于较为模糊的气泡缺陷也未将其错分类成易混淆的暗斑缺陷,具备优秀的分类性能。与原模型相比,改进算法的预测框更接近缺陷的真实分布情况,对感兴趣区域的定位更加准确,有着精准的 ROI 提取能力。

结合上述实验分析,本文所提出的改进 YOLO 算法在保证高精度识别效果的同时具备较低的检测耗时,展现出优秀的综合性能,可较好地满足工业实时生产的检测需求。



a) 待测极片原图 b) YOLOv8 c) 改进 YOLO 算法

图 3-11 YOLOv8 与本文改进 YOLO 算法的识别结果对比图

3.5 本章小结

本章针对锂离子电池极片表面缺陷形态多变、微小、对比度低等极片缺陷识别的难点，在兼具检测精度与实时性的 YOLOv8 模型的基础上提出多项针对性的创新点，在保持单阶段模型具备较高实时性优势的同时，打破其在检测精度方面的限制，解决检测任务的难点。首先提出基于深度卷积的多尺度动态注意力机制并将其嵌入特征提取主干网络中的 C2F 模块，在节约计算成本的同时通过对通道注意力的重标定及空间注意力的动态调整大幅增强网络的表征能力，使模型更加关注待测图像中的感兴趣区域；接着引入 SimCSPSPF 模块代替 YOLOv8 原有的 SPPF，该模块通过 CSP 结构使模型在保持计算复杂度不变的情况下大幅提升检测精度；为解决小目标缺陷漏检错检及跨尺度缺陷识别精度不够的问题，提出基于稠密连接的多尺度双向特征金字塔，通过多引出一个浅层特征检测头，大幅提升模型对微小缺陷的识别准确率；同时结合稠密连接并通过 BiFPN 的双向跨尺度连接和加权特征融合，减少冗余信息干扰并使深浅层特征得到更好的利用；最后针对极片数据集难易样本不均衡及 IoU 对微小物体位置偏差过于敏感的问题引入 Slide-NWD 损失函数，通过 Slide 加权函数使模型更加关注困难样本，结合 NWD 度量解决小目标位置回归的精准性问题。

通过最终综合实验结果分析，本文所提出的基于改进 YOLO 的极片缺陷目标分类与定位算法 mAP 高达 94.42%且检测速率高达 40.06FPS，同时模型定位能力大幅提升，能够较好地对极片表面的缺陷进行分类并精准提取 ROI 区域，有助于后续缺陷部分几何特征分割工作的开展。

第四章 基于像素级分割的缺陷区域精密提取算法

4.1 引言

考虑到本文基于可容忍性检测进行设计,该种检测方式根据极片的不同应用需求允许一定尺寸范围内的缺陷存在,因此需对极片表面缺陷进行分割处理以获取精准的几何结构数据。本文第三章所提出的改进 YOLO 算法虽具备语义分割的能力,但由于极片缺陷所占像素与全图相比比例过于微小,若直接将待测图像送入模型进行分割会导致缺陷区域提取精度与速度受限。且语义分割模型的精度依赖大量数据集,其标注成本过高,尤其是对于较为复杂的语义类别和精度要求较高的细粒度分割场景。综上所述,本文基于第三章所提取出的缺陷区域进行进一步处理,提出一种基于像素级分割的缺陷区域精密提取算法。

基于前面章节分析可知,极片图像背景存在很多细小纹理和噪声且面临光照不均和低对比度等检测难点的挑战。因此,本章首先使用改进的双树复小波变换算法对图像进行保边降噪处理,在去除极片背景干扰的同时最大程度地保留缺陷边缘特征;接着采用改进的 Retinex 算法改善光照不均的同时增强缺陷特征信息;之后采用改进的 Canny 算子实现微小缺陷的精准分割。本章将结合极片图像的实际特征,基于工业生产中的高精度识别需求设计缺陷分割算法在保证缺陷边缘几何数据完整的同时实现像素级的高精度缺陷区域提取。

4.2 图像预处理

4.2.1 极片缺陷图像去噪算法

在采集极片图像的过程中会因各种难以避免的主客观因素导致图像中存在噪声干扰,其大幅影响缺陷边缘细节特征的提取从而降低后续图像分割的精度。目前图像降噪算法主要包括空域滤波法和频域滤波法,空域滤波法是基于像素的空间域进行操作的图像处理算法,常见的空域滤波法有均值滤波、中值滤波、高斯滤波、双边滤波等,频域滤波法是基于图像的频率域进行操作的图像处理算法,常见的频域滤波法包括傅里叶变换、小波变换、双树复小波变换等^[72,73]。在图像的频率域中,低频信息主要反映图像中的整体特征,对感兴趣区域的大体轮廓及整体特征有着描述作用,而高频信息主要包含着图像细节纹理及边缘信息且图像噪声一般以高频信号的形式存在。

针对本文极片缺陷边缘信息复杂和细粒度分割高要求的检测难点,相对空域滤波,频域滤波可以对低频成分和高频成分进行选择性地处理,从而达到最大程度去除图像噪

声干扰的同时保留完整边缘信息，因此选取频域滤波对图像进行降噪处理。考虑到小波变换存在着边缘和局部细节信息丢失的问题，缺乏平移不变性与方向选择性，因此本章选择双树复小波变换算法对图像进行降噪，引入改进小波阈值收缩法实现对高频分量的降噪处理，保留图像的特征信息；并引入结合像素亮度信息和空间距离的双边滤波实现低频分量和重构后图像的整体降噪^[74]。但考虑到传统双边滤波计算量较大且无法自适应选择滤波器参数，因此结合快速自适应双边滤波对双树复小波变换进行改进，在降低算法复杂度的同时最大程度的保留图像边缘信息^[75]。本小节降噪算法流程图如下图 4-1 所示。




图 4-1 改进双树复小波变换降噪算法流程图

通过流程图可知，对于输入图像首先使用树结构的双树复小波变换进行多尺度分解，将其分解成低频子带与高频子带。为简化算法复杂度且考虑到大部分噪声集中于高频分量，因此仅对分解后的低频子带进行垂直方向和水平方向的小波变换，从而得到一个最低频子带和若干高频子带。

对于高频子带采用改进阈值收缩法进行降噪处理，由于图像噪声为系数较小的部分，而系数较大的部分为图像的关键特征，而阈值收缩法的作用便是在最大程度保持完整特征信息的同时过滤噪声系数。常见的阈值法有软阈值、硬阈值法，软阈值法中当小波系数的绝对值小于阈值时将其设置为 0，反之则保留原始符号进行缩放；硬阈值法则是直接将小波系数值与阈值进行比较，小于则设为 0，反之保留原始系数值。软阈值法会产生更平滑的图像但可能导致损失过多细节信息，而硬阈值法虽可保留更多图像细节但可能会造成轮廓失真等问题。为克服软硬阈值法的不足之处，后续又出现各种改进阈值方法，如半软阈值法、折中阈值法。半软阈值法指对于小于阈值的系数将其缩小至 0，对于大于阈值的系数将其减去阈值，而折中阈值与半软阈值不同的地方在于折中阈值减去的是阈值的一半，这两种方法结合了软阈值法的平滑性和硬阈值法的稀疏性，可通过调整阈值的大小更好地平衡图像的降噪效果与边缘细节信息的保留。因此，本文结合半软

阈值法和折中阈值法，通过对阈值附近范围的小波系数进行细化处理从而使降噪后的图像边缘细节保持完整，克服软硬阈值法的不足之处，具体公式如下式(4-1)所示，其中 ω 为处理前的小波系数， $\bar{\omega}$ 为阈值收缩法处理后的小波系数， sign 为确定小波系数符号的函数， T 为阈值，其值为对应子频带标准差的 2 倍， T_0 为阈值的上下限范围且 $T_0 = kT$ ， k 和 α 为调节参数，当 $\alpha = 0$ 的时候，上分段函数变成硬阈值法，而 $\alpha = 1$ 时，上分段函数接近于半软阈值法。本文实验中 $k = 0.5$ ， $\alpha = 0.4$ 时降噪效果最好，可以有效避免图像重构后出现边缘震荡、过于平滑等现象。

$$\bar{\omega} = \begin{cases} \text{sign}(\omega) \frac{(|\omega| - \alpha T + ||\omega| - \alpha T|)}{2} & |\omega| \geq T \\ \text{sign}(\omega) \frac{(T - \alpha T)(|\omega| - T_0 + ||\omega| - \alpha T_0|)}{2} & T_0 \leq |\omega| < T \\ 0 & |\omega| < T_0 \end{cases} \quad (4-1)$$

对于低频子带采取自适应快速双边滤波算法进行降噪处理，快速双边滤波算法是双边滤波算法的改进，其克服了传统双边滤波算法计算复杂度高的缺点，通过多项式代替直方图、积分代替有限范围空间和解析函数近似滤波器实现更高效的运算速度^[76]。自适应快速双边滤波算法则是在快速双边滤波算法的基础上引入自适应的参数选择机制，能够根据图像自身特点动态调整滤波器参数，以适应不同区域和不同纹理的图像细节^[75]。对于传统双边滤波器其公式见下式(4-2)、(4-3)、(4-4)，其中 f 为输入图像， g 为输出图像， Ω 指一个以原点为中心的窗口， $\theta(i)$ 指中心点， $\omega_s(k,l)$ 和 $\omega_r(k,l)$ 分别是当前像素点的空间域权重和灰度域权重， σ_s 和 σ_r 分别是空间域和灰度域的高斯标准差。

$$g(i) = \frac{\sum_{j \in \Omega} \omega_s(j) \omega_r(f(i-j) - \theta(i)) f(i-j)}{\sum_{j \in \Omega} \omega_s(j) \omega_r(f(i-j) - \theta(i))} \quad (4-2)$$

$$\omega_s(j) = \exp\left(-\frac{\|j\|^2}{2\sigma_s^2}\right) \quad (4-3)$$

$$\omega_r(t) = \exp\left(-\frac{t^2}{2\sigma_r^2}\right) \quad (4-4)$$

由上式可以发现双边滤波逐像素点进行时间复杂度高达 $O(n^2)$ 的运算，实时性较低。因此引入自适应快速双边滤波模型，其时间复杂度只有 $O(1)$ ，具备较高的运算效率。对

于 $i \in \Pi$, $\Lambda_i = \{f(i-j): j \in \Omega\}$, $t \in \Lambda_i$, $h_i(t)$ 为加权直方图, δ 为 Kronecker 增量, 其公式见下式(4-5)、(4-6)、(4-7)。

$$\delta(t) = \begin{cases} 1 & t = 0 \\ 0 & t \neq 0 \end{cases} \quad (4-5)$$

$$h_i(t) = \sum_{j \in \Omega} \omega_s(j) \delta(f(i-j) - t) \quad (4-6)$$

$$g(i) = \frac{\sum_{t \in \Lambda_i} t h_i(t) \omega_r(t - \theta(i))}{\sum_{t \in \Lambda_i} h_i(t) \omega_r(t - \theta(i))} \quad (4-7)$$

使用积分代替公式(4-7), 其中 $\alpha_i = \min\{t: t \in \Lambda_i\}$, $\beta_i = \max\{t: t \in \Lambda_i\}$, 定义在区间 $[\alpha_i, \beta_i]$ 的 p_i 近似于 h_i 函数, 见式(4-8)。若 p_i 是一个多项式, 设 $p_i(t) = c_0 + c_1 + \dots + c_N t^N$, 通过多项式直方图可以得到滤波器输出, 见式(4-9)。

$$\hat{g}(i) = \frac{\int_{\alpha_i}^{\beta_i} t p_i(t) \omega_r(t - \theta(i)) dt}{\int_{\alpha_i}^{\beta_i} p_i(t) \omega_r(t - \theta(i)) dt} \quad (4-8)$$

$$\hat{g}(i) = \alpha_i + (\beta_i - \alpha_i) \frac{c_0 I_1 + \dots + c_N I_{N+1}}{c_0 I_0 + \dots + c_N I_N} \quad (4-9)$$

综上所述, 本文对低频子带分量使用自适应快速双边滤波进行降噪处理, 首先用多项式近似表示原始图像的直方图信息, 以减少计算量和数据的复杂程度, 接着通过快速卷积和分部积分递归运算, 可以快速有效地获取滤波后图像结果; 随后将降噪后的高低频子带进行双树复小波逆变换, 最终对重构图像进行二次自适应快速双边滤波, 从而在快速降噪的同时保持图像的细节信息, 最大程度地达到保边降噪的目的。

4.2.2 极片缺陷图像增强算法

经过上一小节所述的降噪算法处理后, 在最大程度的保留图像边缘细节信息的同时实现了缺陷图像中无关信息的有效抑制。然而针对凹坑、划痕、压痕等低对比度缺陷, 仍存在因灰度值差异较小导致边缘模糊的问题, 且通过分析缺陷区域图像易发现因硬件环境等外界因素影响目标区域存在一定的反光现象, 导致后续分割较为困难。因此若直接将降噪图像送入改进边缘检测算子中可能会出现虚假边缘、轮廓分割不精准等问题, 严重影响极片二次分类的精准性。为解决上述问题, 本文基于梯度域引导滤波与 Gamma 变换对 Retinex 算法进行改进, 实现极片缺陷区域的图像增强, 在强调目标边缘的同时

达到图像矫正的效果。

Retinex 算法是一种用于图像增强的经典算法，其核心原理是通过模拟人类视觉系统的工作方式，对图像的光照与反射成分进行分离从而达到提高改善图像对比度和亮度的目的^[77]。其中单尺度 Retinex 算法(Single-Scale Retinex, SSR)使用单个尺度的高斯滤波来估计照明分量，然后通过在对数域中将输入图像减去估计的照明分量来计算反射分量，计算公式见下式(4-10)、(4-11)、(4-12)，其中 $I(x, y)$ 代表输入图像， $R(x, y)$ 代表反射分量， $L(x, y)$ 代表光照分量， $F(x, y)$ 代表高斯环绕函数， $*$ 代表卷积操作。

$$I(x, y) = R(x, y) \times L(x, y) \quad (4-10)$$

$$\log R(x, y) = \log I(x, y) - \log L(x, y) \quad (4-11)$$

$$L(x, y) = I(x, y) * F(x, y) \quad (4-12)$$

但该方法在增强图像对比度的同时可能会造成伪轮廓、光晕等现象，因此本文首先使用梯度域引导滤波代替高斯滤波对光照分量进行估计，在避免图像阴影和光晕的同时保持图像的边缘细节，接着使用改进的全局双亮度 Gamma 变换函数对光照分量进行明暗矫正，并使用对比度受限的自适应直方图均衡化(Contrast Limited Adaptive Histogram Equalization, CLAHE)算法对反射分量进行对比度增强；最终对两个分量进行归一化加权求和得到本文的增强图像，算法流程图如下图 4-2 所示^[78-80]。




图 4-2 改进 Retinex 图像增强算法流程图

引导滤波是一种边缘保持滤波器，其可以在模糊图像的同时保持其边缘特征，在一定程度上避免了梯度反转的情况^[81]。引导滤波通过引导图像指导输出图像，使其在局部窗口内对输入图像的每个局部区域进行线性变换。双边滤波的模型见下式(4-13)，其中 q 为输出图像， I 为引导图像， p 为输入图像， i 与 k 为像素点位置， w_k 为以 k 为中心点， r 为半径的局部滤波窗口， a_k 与 b_k 为局部窗口 w_k 的线性系数。

$$q_i = a_k I_i + b_k, \forall i \in w_k \quad (4-13)$$

通过下式(4-14)令输入输出图像间差异最小，可以确定线性系数 a_k 与 b_k ，其中的 $E(a_k, b_k)$ 代表图像间的差异， ε 是正则化参数，其用来避免 a_k 过大的情况。

$$E(a_k, b_k) = \sum_{i \in w_k} \left[(a_k I_i + b_k - p_i)^2 + \varepsilon a_k^2 \right] \quad (4-14)$$

由于 ε 是一个常数，其在边缘部分与平滑部分具备同样的权重，造成滤波后的图像易出现丧失边缘细节的情况，从而导致边缘区域出现光晕伪影的现象。为解决这个问题，加权引导滤波借鉴加权最小二乘滤波器的思路，通过引入一个边缘信息权重 $\Gamma_I(k)$ 实现正则化参数的自适应调整^[82]。 $\Gamma_I(k)$ 表示引导图像 I 中像素点 k 所对应的边缘信息权重，见下式(4-15)，其中 N 表示像素总数， $\sigma_{I,1}^2()$ 表示引导图像对应像素点 3×3 区域范围内的方差， α 为一个较小的常数，一般取值 $(0.001 \times L)^2$ ， L 是图像的动态范围。最终的确定线性系数的函数见下式(4-16)。

$$\Gamma_I(k) = \frac{1}{N} \sum_{i=1}^N \frac{\sigma_{I,1}^2(k) + \alpha}{\sigma_{I,1}^2(i) + \alpha} \quad (4-15)$$

$$E(a_k, b_k) = \sum_{i \in w_k} \left[(a_k I_i + b_k - p_i)^2 + \frac{\varepsilon a_k^2}{\Gamma_I(k)} \right] \quad (4-16)$$

考虑到加权引导滤波仅从单尺度方面通过权重因子实现边缘限制，梯度域引导滤波 (Gradient Domain Guided Filter, GDGF) 为提高边缘区域细节信息保持能力，通过多尺度方差改进边缘信息权重 $\hat{\Gamma}_I(k)$ 并提出一个新的边缘感知因子 β_k ，从而提升输入图像和输出图像的梯度相似度。 $\hat{\Gamma}_I(k)$ 的公式见下式(4-17)， $\varphi(k)$ 为 $\sigma_{I,1}^2(k)$ 与 $\sigma_{I,r}^2(k)$ 的乘积， $\sigma_{I,r}^2(k)$ 则为引导图像以对应像素点为中心且 r 为半径的区域范围方差。最终函数见下式(4-18)、(4-19)，其中 $\varphi_u(k)$ 和 $\varphi_{\min}(k)$ 分别为 $\varphi(k)$ 的均值和最小值。

$$\hat{\Gamma}_I(k) = \frac{1}{N} \sum_{i=1}^N \frac{\varphi(k) + \alpha}{\varphi(i) + \alpha} \quad (4-17)$$

$$E(a_k, b_k) = \sum_{i \in w_k} \left[(a_k I_i + b_k - p_i)^2 + \frac{\varepsilon}{\hat{\Gamma}_I(k)} (a_k - \beta_k)^2 \right] \quad (4-18)$$

$$\beta_k = 1 - \frac{1}{1 + e^{\left[\frac{4}{\varphi_u(k) - \varphi_{\min}(k)} \right] [\varphi(k) - \varphi_u(k)]}} \quad (4-19)$$

通过最小二乘法求得 a_k 与 b_k ，见下式(4-20)和(4-21)，其中 u_k 和 σ_k^2 分别是引导图像在 w_k 的均值和方差， $|w|$ 是 w_k 中像素点的个数， $\bar{p}_k$ 是输入图像在 w_k 的均值。

$$a_k = \frac{\frac{1}{|w|} \sum_{i \in w_k} I_i p_i - u_k \bar{p}_k + \frac{\varepsilon}{\hat{\Gamma}_I(k)} \beta_k}{\sigma_k^2 + \frac{\varepsilon}{\hat{\Gamma}_I(k)}} \quad (4-20)$$

$$b_k = \bar{p}_k - a_k u_k \quad (4-21)$$

通过上式可以得到每个窗口的 a_k 与 b_k ，图像的每个像素点都被 $|w|$ 个窗口包围，因此每个像素点具备 $|w|$ 个输出值，求其平均值即可得到输出图像，见下式(4-22)。

$$q_i = \frac{1}{|w|} \sum_{k \in w_k} (a_k I_i + b_k) = \left(\frac{1}{|w|} \sum_{k \in w_k} a_k \right) I_i + \frac{1}{|w|} \sum_{k \in w_k} b_k \quad (4-22)$$

考虑到高斯滤波存在着模糊边缘细节的问题，从而导致增强后的图像存在伪边缘及光晕现象，因此本文的改进 Retinex 算法使用上述的梯度域引导滤波代替高斯滤波，并选择三个尺度的正则参数以实现图像光照分量和反射分量的分离，在兼顾算法的快速性的同时最大程度的保持边缘，所求得的光照分量 $L(x, y)$ 见下式(4-23)，其中 $I(x, y)$ 为输入的缺陷图像， $r=3$ ，三个尺度的 ε_i 分别等于 1, 0.1, 0.01。

$$L(x, y) = \frac{1}{3} \sum_{i=1}^3 \text{GDGF}[I(x, y), I(x, y), r, \varepsilon_i] \quad (4-23)$$

由于缺陷图像存在着整体灰度值较高且亮度较低的情况，对后续的边缘检测具有一定的负面影响。因此需对光照分量进行明暗矫正以提升图像整体的亮度与对比度。伽马变换是通过对图像的像素值进行非线性变换以增强图像的细节并改善其亮度与对比度。考虑到缺陷图像中相对背景区域缺陷部分的灰度值会偏高或偏低，传统的伽马变换函数只能实现单一方向的图像增强，若增强低灰度值区域则会导致图像亮度过高出现细节损失，若增强高灰度值区域则会造成整体图像过暗从而导致图像模糊。因此本文提出一种改进的全局双亮度 Gamma 变换的方式在增强图像暗部分的同时调整图像的高亮区域，从而达到矫正灰度值及增强图像对比度的目的，其函数公式见下式(4-24)、(4-25)、(4-26)。 $\tilde{L}(x, y)$ 为矫正后的光照分量， $G_a(x)$ 为凸函数可以增强图像阴影部分的对比度从而突出暗区域及细节， $G_b(x)$ 则是凹函数可以压缩图像的高亮区域以增强缺陷细节于亮区域的可见性， γ 是可调节的变量， λ 是双伽马函数的加权参数，其取值范围皆为[0,1]，通过 λ 参数的调节可以达到矫正缺陷图像灰度值以增强图像对比度的目的。经过多次实验，本文的 γ 取值 1.5， λ 取值 0.7 时可以使缺陷图像对比度增强与亮度矫正达到平衡。

$$G_a(x) = x^{\frac{1}{\gamma}} \quad (4-24)$$

$$G_b(x) = 1 - (1 - x)^{\frac{1}{\gamma}} \quad (4-25)$$

$$\tilde{L}(x, y) = 256 * \left(\lambda * G_a\left(\frac{L(x, y)}{256}\right) - (1 - \lambda) G_b\left(\frac{L(x, y)}{256}\right) \right) \quad (4-26)$$

根据上述 Retinex 算法原理, 可通过式(4-11)求得反射分量 $R(x, y)$, 反射分量见下式(4-27)。

$$R(x, y) = \log I(x, y) - \log \tilde{L}(x, y) \quad (4-27)$$

反射分量中主要包含着缺陷的边缘细节及纹理信息, 其动态范围较窄且灰度值过于集中, 导致边缘和纹理背景难以区分, 因此选取对比度限制的自适应直方图均衡化算法在抑制纹理背景噪声的同时提高图像细节的可见性, 避免了传统直方图均衡化算法在处理局部细节的时候产生对比度过度增强和噪声放大的情况, 整体提升缺陷图像的质量^[83]。该算法将图像细分为若干个局部区域, 接着对每个局部区域中的像素执行直方图均衡化处理, 在提升区域内图像对比度的同时增强细节特征的清晰度。同时在直方图均衡化的过程中限制每个区域的像素的最大值以避免对比度过度增强, 最终对所有局部区域内的像素进行插值或拼接, 以获取最终的增强图像。处理后的反射分量 $\tilde{R}(x, y)$ 见下式(4-28)。

$$\tilde{R}(x, y) = \text{CLAHE}(R(x, y)) \quad (4-28)$$

最终将处理后的光照分量和反射分量进行融合, 得到的增强后的图像 $\tilde{I}(x, y)$ 见下式(4-29)。

$$\tilde{I}(x, y) = \exp(\log(\tilde{R}(x, y)) + \log(\tilde{L}(x, y))) \quad (4-29)$$

综上所述, 本章对于降噪后的图像采用改进的 Retinex 算法对其进行图像增强, 首先通过梯度域引导滤波对其进行多尺度地保边降噪处理, 使待测图像在时间复杂度较低的情况下实现最大程度地保持边缘细节, 从而完成对于光照分量与反射分量的分离; 然后对光照分量进行全局双亮度伽马变换, 在增强图像暗区域的同时调整图像的高光部分从而达到明暗矫正及对比度增强的目的; 接着对于反射分量灰度值集中导致边缘细节与背景纹理无法分辨的问题, 采取对比度限制的自适应直方图均衡化算法在抑制背景无关信息干扰的同时突出图像细节; 最终将处理后的光照分量和反射分量进行融合, 解决感兴趣区域不明显、边缘模糊及光照等问题, 实现图像的增强。

4.3 改进 Canny 图像边缘检测算子

经上述小节算法对图像进行预处理后, 待分割极片图像的噪声得到一定抑制且边缘细节区域得到有效增强, 大幅降低后续缺陷分割的难度。基于前文所提技术路线, 设计一种高精度的边缘检测算法实现缺陷区域的有效分割, 解决缺陷形态多变且对比度低等分割难点。本小节基于现阶段被普遍应用的 Canny 边缘检测算子, 引入滤波降噪、多方向 Sobel 算子、自适应阈值等方面的改进, 实现缺陷区域的自适应提取。

4.3.1 Canny 边缘检测算子

Canny 边缘检测算子是一种多级边缘检测算法，其以高准确性、单一响应、确定性及鲁棒性等优点被广泛认为是效果最佳的边缘检测算法之一^[84]。以下是 Canny 边缘检测算法的主要执行步骤：

1. 高斯滤波：Canny 算子首先通过高斯滤波对输入图像进行平滑处理，消除无关噪声的干扰。
2. 梯度计算：经过降噪处理后，Canny 算子通过将图像的每个像素点与 Sobel 梯度算子或 Prewitt 梯度算子进行卷积以获取图像的强度与梯度方向。
3. 非极大值抑制(Non-Maximum Suppression, NMS)：在梯度计算后，Canny 算子通过使用 NMS 确保只有在梯度方向上强度最大的像素点被保留，其他设为 0，从而实现冗余信息的过滤，避免图像产生重复边缘。
4. 双阈值检测：接着 Canny 算子通过预设的高低阈值进行强边缘和弱边缘的判定，进一步实现非边缘点的过滤。
5. 边缘判定：最后 Canny 算子通过强边缘像素来判定弱边缘像素是否是真实边缘，若弱边缘像素与强边缘像素在 8 领域内相连则划分其为真实边缘。

Canny 边缘检测算子通过上述步骤实现目标区域的边缘提取，但将其应用于极片缺陷分割时，原始 Canny 算子无法实现自适应阈值获取且定位精度无法满足本文应用场景的实际需求。因此需对原 Canny 进行针对性的整体优化，在精准保留边缘信息的同时实现更加完整的轮廓获取，整体提升极片表面目标分割的效果。

4.3.2 改进滤波算子

根据上述 Canny 算子的运算步骤，在进行梯度计算前需通过滤波算法对图像进行降噪平滑处理，而原始算子采用的高斯滤波可能会导致图像边缘的模糊，从而造成缺陷分割精确性的大幅降低。因此，为提升边缘检测算子降噪能力及边缘保持能力以改善算法的综合分割性能，本文使用在 4.2.1 小节所提出的改进双树复小波变换算法替换原有的高斯滤波进行降噪处理，使改进 Canny 算子在快速抑制图像冗余信息干扰的同时克服边缘模糊的问题。

4.3.3 改进 Sobel 算子

在传统 Canny 边缘检测算子中，Sobel 算子仅捕捉水平和垂直两方向的边缘信息，其对于分割的关键特征提取较为片面。针对本文待分割极片缺陷图像形态多变且细节微

小等检测难点对 Sobel 算子的梯度计算方向进行优化。考虑到若使用 5×5 的八方向模板会导致算子计算量大幅增加从而降低算子实时性，因此本文采用 3×3 方向模板以新增 45° 、 90° 、 135° 、 180° 、 225° 、 270° 及 315° 七个方向的梯度信息，使其能够捕获更细致的边缘方向信息从而提高边缘检测的准确性，改进 Sobel 算子八个方向的梯度模板分别如下图 4-3 所示^[85]。

<table><tr><td>1</td><td>0</td><td>-1</td></tr><tr><td>2</td><td>0</td><td>-2</td></tr><tr><td>1</td><td>0</td><td>-1</td></tr></table>	1	0	-1	2	0	-2	1	0	-1	<table><tr><td>2</td><td>1</td><td>0</td></tr><tr><td>1</td><td>0</td><td>-1</td></tr><tr><td>0</td><td>-1</td><td>-2</td></tr></table>	2	1	0	1	0	-1	0	-1	-2	<table><tr><td>1</td><td>2</td><td>1</td></tr><tr><td>0</td><td>0</td><td>0</td></tr><tr><td>-1</td><td>-2</td><td>-1</td></tr></table>	1	2	1	0	0	0	-1	-2	-1	<table><tr><td>0</td><td>1</td><td>2</td></tr><tr><td>-1</td><td>0</td><td>1</td></tr><tr><td>-2</td><td>-1</td><td>0</td></tr></table>	0	1	2	-1	0	1	-2	-1	0
1	0	-1																																					
2	0	-2																																					
1	0	-1																																					
2	1	0																																					
1	0	-1																																					
0	-1	-2																																					
1	2	1																																					
0	0	0																																					
-1	-2	-1																																					
0	1	2																																					
-1	0	1																																					
-2	-1	0																																					
a) Sobel 0°	b) Sobel 45°	c) Sobel 90°	d) Sobel 135°																																				
<table><tr><td>-1</td><td>0</td><td>1</td></tr><tr><td>-2</td><td>0</td><td>2</td></tr><tr><td>-1</td><td>0</td><td>1</td></tr></table>	-1	0	1	-2	0	2	-1	0	1	<table><tr><td>-2</td><td>-1</td><td>0</td></tr><tr><td>-1</td><td>0</td><td>1</td></tr><tr><td>0</td><td>1</td><td>2</td></tr></table>	-2	-1	0	-1	0	1	0	1	2	<table><tr><td>-1</td><td>-2</td><td>-1</td></tr><tr><td>0</td><td>0</td><td>0</td></tr><tr><td>1</td><td>2</td><td>1</td></tr></table>	-1	-2	-1	0	0	0	1	2	1	<table><tr><td>0</td><td>-1</td><td>-2</td></tr><tr><td>1</td><td>0</td><td>-1</td></tr><tr><td>2</td><td>1</td><td>0</td></tr></table>	0	-1	-2	1	0	-1	2	1	0
-1	0	1																																					
-2	0	2																																					
-1	0	1																																					
-2	-1	0																																					
-1	0	1																																					
0	1	2																																					
-1	-2	-1																																					
0	0	0																																					
1	2	1																																					
0	-1	-2																																					
1	0	-1																																					
2	1	0																																					
e) Sobel 180°	f) Sobel 225°	g) Sobel 270°	h) Sobel 315°																																				

图 4-3 八方向 Sobel 算子梯度模板

将各像素点与上述八方向梯度模板进行卷积运算后可得到各个方向的轮廓信息 g_{0° 、 g_{45° 、 g_{90° 、 g_{135° 、 g_{180° 、 g_{225° 、 g_{270° 及 g_{315° 。接着将八方向的轮廓梯度值按照下式(4-30)、(4-31)、(4-32)进行加权计算，从而得到合成后的灰度值 $g'(x)$ 。

$$g_a = g_{0^\circ}^2 + g_{45^\circ}^2 + g_{90^\circ}^2 + g_{135^\circ}^2 \quad (4-30)$$

$$g_b = g_{180^\circ}^2 + g_{225^\circ}^2 + g_{270^\circ}^2 + g_{315^\circ}^2 \quad (4-31)$$

$$g'(x) = \frac{1}{2} \sqrt{g_a + g_b} \quad (4-32)$$

4.3.4 基于改进麻雀搜索算法的最大熵算法

原始 Canny 边缘检测算子无法自适应确定分割阈值，用户需根据待分割图像的实际特征与分割实验结果进行经验性的阈值调整以选取最佳高低阈值，该种方式耗费大量的时间与成本。在本文多类极片缺陷图像的分割场景下，缺陷间的形态差异导致不同种类的待分割图像具备不同的对比度和边缘特征，且极片缺陷边缘细节微小导致其对高低阈值参数较为敏感，因此针对上述问题本文选取相对抗噪声能力较强且适用于复杂分布的最大熵算法以自适应获取 Canny 检测算子的分割阈值，提高算法的鲁棒性能。同时考虑

到最大熵算法存在时间复杂度过高且耗时较长等问题，基于改进的麻雀搜索算法对其进行改进以提升阈值参数的全局寻优性，提高极片缺陷图像的分割精度。

1. 最大熵算法

最大熵算法是一种基于信息论的图像阈值分割技术，其核心思想来自信息论中的熵概念^[86]。熵用来表示图像中像素灰度分布的不确定性。该算法把图像分成前景熵和背景熵两个部分，其通过最大化前景和背景熵的和来确定最佳的分割阈值。最大熵算法一般分为统计图像灰度值分布、计算前景和背景熵和寻找最大化熵的阈值这三个步骤。

对于一副图像可根据灰度分割阈值 $t(0 \leq t < N-1)$ ，将其分成两个图像区域 A 和 B ， A 区域中所有像素点的灰度值范围在 $\{0, 1, \dots, t\}$ ，而 B 中所有像素点的灰度值皆在 $\{t+1, t+2, \dots, N-1\}$ 范围内，区域内各个像素点灰度值对应的归一化概率分布见式(4-33)和(4-34)。

$$\begin{cases} p_A(t) = \sum_{i=0}^t p(i) = p(t) \\ A: \left(\frac{p(0)}{p_A(t)}, \frac{p(1)}{p_A(t)}, \frac{p(2)}{p_A(t)}, \dots, \frac{p(t)}{p_A(t)}, 0, \dots, 0 \right) \end{cases} \quad (4-33)$$

$$\begin{cases} p_B(t) = \sum_{i=t+1}^{N-1} p(i) = 1 - p(t) \\ B: \left(0, \dots, 0, \frac{p(t+1)}{p_B(t)}, \frac{p(t+2)}{p_B(t)}, \frac{p(t+3)}{p_B(t)}, \dots, \frac{p(N-1)}{p_B(t)} \right) \end{cases} \quad (4-34)$$

其中 $p_A(t)$ 和 $p_B(t)$ 之和为 1，代表图像中的全部像素点，若图像大小为 $P \times Q$ ，则各灰度值概率 $p(i)$ 见下式(4-35)，其中 n_i 是图像中灰度值等于 i 的像素点个数。

$$p(i) = \frac{n_i}{P \times Q} \quad (4-35)$$

图像区域 A 和 B 的信息熵计算公式见下式(4-36)和(4-37)，总信息熵见下式(4-38)。

$$H_A(t) = - \sum_{i=0}^t \frac{p(i)}{p_A(t)} \times \log \left(\frac{p(i)}{p_A(t)} \right) \quad (4-36)$$

$$H_B(t) = - \sum_{i=t+1}^{N-1} \frac{p(i)}{p_B(t)} \times \log \left(\frac{p(i)}{p_B(t)} \right) \quad (4-37)$$

$$H(t) = H_A(t) + H_B(t) \quad (4-38)$$

最大熵算法通过令总信息熵最大从而找到最佳分割阈值，传统方法需要对所有可能

的阈值进行遍历并计算每个阈值下的信息熵，最终选择信息熵最高的阈值作为最佳分割点，但该种计算方式过于复杂且耗时过长。为解决上述问题，本文采用改进的麻雀搜索算法简化最优阈值的搜索过程，提高全局寻优性的同时增强算法整体检测效率，具体设计思路在下面小节阐述。

2. 改进麻雀搜索优化算法

麻雀搜索算法(Sparrow Search Algorithm, SSA)是一种启发式优化算法，其受到麻雀种群的社会行为和觅食方式所启发，用于解决各类优化问题^[87]。在 SSA 算法中，麻雀种群被划分为发现者、跟随者和侦察者这三种角色，以模拟麻雀社会对危险的预警与躲避。发现者代表最佳的解决方案，即该部分麻雀找到了当前评价标准下最好的食物来源，在算法的迭代过程中，其他麻雀会参考发现者的解决方案来更新自己的位置。跟随者是种群中的其余麻雀，其通过跟随发现者的行为来提高找到优良解的机会，同时其在搜索过程中会考虑周围的环境因素以模拟自然环境中的警戒行为。发现者是引导群体搜索方向的领导者，而跟随者充当信息利用者，通过这种合作与竞争的机制实现了信息的有效共享和传播，从而使种群能够共同进化找到最优解。

用一个 $m \times n$ 的矩阵对麻雀种群进行描述，见式(4-39)，其中 m 代表麻雀的数量， n 代表维度， X_{mn} 代表第 m 只麻雀在 n 维时的位置信息。麻雀种群的适应度值 f 即评估每个麻雀个体在问题空间中的优劣程度，见式(4-40)。

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1n} \\ x_{21} & x_{22} & \cdots & x_{2n} \\ & & \cdots & \\ x_{m1} & x_{m2} & \cdots & x_{mn} \end{bmatrix} \quad (4-39)$$

$$F_x = \begin{bmatrix} f([x_{11} & x_{12} & \cdots & x_{1n}]) \\ f([x_{21} & x_{22} & \cdots & x_{2n}]) \\ & & \cdots & \\ f([x_{m1} & x_{m2} & \cdots & x_{mn}]) \end{bmatrix} \quad (4-40)$$

在算法的迭代过程中，麻雀根据角色的不同被划分为发现者、追随者和侦察者，其将依序更新自己的位置及适应度评价函数，以优化搜索过程。发现者的位置更新公式见式(4-41)，其中 t 指迭代次数， $iter_{\max}$ 指迭代次数的最大值， α 为一个范围在 $(0,1]$ 的随机数， β 为一个符合正态分布的随机数， L 为一个 $1 \times n$ 的全 1 矩阵， R 代表警戒值， ST 为安全值。当 R 大于 ST 时，发现者会带领种群离开危险位置。

$$X_{ij}^{t+1} = \begin{cases} X_{ij} \times \exp(-\frac{i}{\alpha \times iter_{\max}}) & R < ST \\ X_{ij} + \beta \times L & R \geq ST \end{cases} \quad R \in [0,1], ST \in [0.5,1] \quad (4-41)$$

跟随者的位置更新公式见式(4-42)，其中 X_{best} 代表全局最优位置， X_{worst} 代表全局最差位置， A 为一个 $1 \times n$ 的矩阵，其矩阵内元素值随机为 1 或 -1， $A^+ = A^T(AA^T)^{-1}$ 。当 $i > m/2$ 时代表较低适应值的跟随者需前去较远的地方获取食物。

$$X_{ij}^{t+1} = \begin{cases} \beta \times \exp(\frac{X_{worst} - X_{ij}^t}{\alpha \times iter_{\max}}) & i > \frac{m}{2} \\ X_{best}^{t+1} + |X_{ij} - X_{best}^{t+1}| \times A^+ \times L & \text{其他} \end{cases} \quad (4-42)$$

当麻雀种群受到威胁时会做出反捕食行为，侦察者的位置更新公式见式(4-43)， f_i 为麻雀当前的适应度值， f_g 和 f_w 分别为全局最好和最差的适应度值， K 为一个在 $[-1,1]$ 范围内的随机数，代表麻雀的移动方向和步长控制参数， ε 为一个避免分母为零的较小的常数。当 $f_i > f_g$ 时代表麻雀靠近种群边缘，易被捕食者所攻击，而 $f_i = f_g$ 时代表种群中的麻雀感知到危险，需向其他麻雀靠近。

$$X_{ij}^{t+1} = \begin{cases} X_{best}^t + \beta \times |X_{ij}^t - X_{best}^t| & f_i > f_g \\ X_{ij}^t + K \times \left(\frac{|X_{ij}^t - X_{worst}^t|}{(f_i - f_w) + \varepsilon} \right) & f_i = f_g \end{cases} \quad (4-43)$$

SSA 算法具备结构简单、收敛速度快、精度高等优点，但其存在后期因种群多样性的降低而陷入局部最优，从而造成算法精度的降低等问题。为解决上述问题，首先引入混沌映射以提高麻雀种群初始的多样性，提升优化算法的全局寻优性，其次为增加解的多样性以跳出局部最优区域，结合随机游走策略大幅提高算法获取全局最优解的概率。

混沌映射以其产生不规则的混沌序列而著称，常见的这类映射包括 Tent 映射、Circle 映射、Logistic 映射等，其中 Singer 映射因其简单和高效性被广泛应用于各类混沌伪随机数生成器和优化算法中，其公式简单且具备遍历性，因此本文选取 Singer 映射对麻雀搜索算法的种群进行初始化^[88,89]。Singer 映射的公式见下式(4-44)，其中 μ 在 $(0.9,1.08)$ 范围内， x 的取值在 $[0,1]$ 之间。该种映射可实现对搜索区域的均匀探索，增强麻雀群体的均衡分布及其多样性，从而提升全局寻优能力。

$$x_{k+1} = \mu(7.86x_k - 23.31x_k^2 + 28.75x_k^3 - 13.302875x_k^4) \quad (4-44)$$

在搜索之后，引入随机游走策略对最优麻雀进行扰动变异，从而增强局部解的寻优

性以实现全局寻优与局部寻优的平衡。该策略核心思想为：在每次迭代时，算法随机选取一个临近点与当前解进行比较，若优于当前解则用该点对中心点进行替换。若连续 N 次都没有找到更优解，则将最佳解视为位于以当前最佳解为中心且以当前步长为半径的 N 维球范围内。若步长小于阈值则算法停止，否则将步长减半并继续下一轮的搜索。该过程的表达式见下式(4-45)，其中 $X(t)$ 为随机游走的步数集， c_{ussum} 为游走步数累计和， t 为当前游走步数， t_n 为第 n 次游走步数。随机函数 $r(t)$ 见下式(4-46)，其中 $rand$ 为一个在 $[0,1]$ 范围内的随机数。

$$X(t) = \{0, c_{ussum}[2r(t_1) - 1], c_{ussum}[2r(t_2) - 1], \dots, c_{ussum}[2r(t_n) - 1]\} \quad (4-45)$$

$$r(t) = \begin{cases} 1 & rand > 0.5 \\ 0 & rand \leq 0.5 \end{cases} \quad (4-46)$$

在迭代的初始过程中，随机游走边界较大，对算法的全局寻优性有一定的提升；到迭代的后期时，游走边界缩小，从而提高算法的局部寻优性。但由于麻雀的行动轨迹存在着边界范围，因此需对其进行归一化处理，其计算公式见式(4-47)，其中 a_i 与 b_i 分别为第 i 维随机游走变量的最大值与最小值， d_i^t 和 c_i^t 分别为第 i 维随机游走变量在第 t 次迭代时的最大值和最小值。

$$X_i^t = \frac{(X_i^t - a_i) \times (d_i^t - c_i^t)}{b_i - a_i} + c_i^t \quad (4-47)$$

3. 基于改进麻雀优化的最大熵算法

结合上述改进麻雀搜索算法对最大熵算法进行优化从而获取极片缺陷图像分割的高低阈值，即在麻雀搜索算法的不断迭代寻优中获取令熵最大的阈值，在增强算法的鲁棒性的同时大幅提升算法效率。算法的具体流程如下所示：

- 1) 对算法的各个参数进行初始化。
- 2) 通过混沌映射对种群进行初始化，并对麻雀个体进行排序。
- 3) 更新捕食者、跟随者及侦察者的相应位置。
- 4) 计算适应度值并更新发现者的位置
- 5) 通过随机游走策略对最优麻雀进行更新
- 6) 当达到预设最大迭代次数时结束算法，此时的最优麻雀位置即最佳的分割阈值。

将得到的最佳分割阈值作为改进 Canny 算子的高阈值，将该分割阈值的一半作为低阈值，从而实现改进 Canny 算子自适应获取高低阈值。

4.3.5 边缘判定与完善

通过融合最大熵算法和改进麻雀优化搜索算法,实现改进 Canny 算子自适应获取精确的高低阈值,接着根据高低阈值进行边缘点的判定与完善。若图像中像素点的灰度值超过设定的高阈值,该像素点即被判定为边缘像素;反之,若其灰度值低于预设的低阈值,则认定为非边缘像素。对于灰度值位于这两个阈值间的像素点,则被视作弱边缘像素,并将通过后续的连通域分析进一步进行边缘确认。在完成边缘像素点的判定后,采取形态学处理算法对边缘轮廓进行优化,改善其连续性与完整性,以实现极片缺陷区域的精确分割,获得高质量的极片分割图像。

同时本文采取 OpenCV 库中的一系列函数,以精确测量分割出缺陷的几何属性。首先,通过 approxPolyDP 函数对图像边缘进行多边形拟合,后使用 findContours 函数识别并追踪图像中的闭合轮廓,进而通过 contourArea 函数和 arcLength 函数分别获取极片缺陷区域的面积和周长,最终将几何结构数据与缺陷区域的详细分割图像一并展示在用户界面上,以便进行进一步的分析和评估。

4.4 实验结果及分析

4.4.1 缺陷区域精密提取算法的整体流程

对于极片缺陷图像背景纹理及噪声干扰较大、对比度较低且分割精度要求高等检测难点,本文所提基于像素级分割的缺陷区域精密提取算法整体流程图见下图 4-4。




图 4-4 缺陷区域高精度提取算法整体流程

4.4.2 主要评估指标

在上述小节对本文所提的高精度极片缺陷分割算法进行了详述,为验证上述分割算法的有效性,除将算法的实验结果进行主观对比分析外,本小节将引入一系列的评估参数对算法进行进一步客观评估。

1. 峰值信噪比

峰值信噪比(Peak Signal Noise Ratio, $PSNR$)是一种常用的图像质量评价指标,一般用其衡量原始图像与处理后图像间的质量损失程度,其计算公式见下式(4-48)。式中 m 和 n 代表输入图像的长和宽,均方根误差(Mean Square Error, MSE)代表原始图像与处理后图像间每个像素的差值的平方和的均值,其计算公式见下式(4-49),其中 X 为原始图像而 Y 为算法处理后的图像。

$$PSNR = 10 \times \log_{10} \left(\frac{(2^n - 1)^2}{MSE} \right) \quad (4-48)$$

$$MSE = \frac{1}{m \times n} \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} \|X(i, j) - Y(i, j)\|^2 \quad (4-49)$$

为更精确地衡量图像处理算法的有效性和稳定性,引入 $PSNR_{ave}$ 即峰值信噪比的均值,其计算公式见下式(4-50),其中 N 表示参与评估的图像数目。峰值信噪比均值的取值范围一般在 0 到正无穷之间,其数值越大代表图像质量损失越小,即图像相应的质量越高。同时引入 $PSNR_v$ 即峰值信噪比的标准差,其计算公式见下式(4-51),该值越小则代表算法的稳定性越高。 $PSNR$ 依然存在一些局限性,比如其对于人眼感知的误差并不一致,不能完全反映人类主观感知的视觉质量,因此本文还结合其他图像质量评价指标以获取更为全面和准确的图像质量评估。

$$PSNR_{ave} = \frac{\sum_{i=1}^N PSNR_i}{N} \quad (4-50)$$

$$PSNR_v = \sqrt{\frac{\sum_{i=1}^N (PSNR_i - PSNR_{ave})^2}{N - 1}} \quad (4-51)$$

2. 结构相似度

结构相似度(Structural Similarity Index, $SSIM$)是一种用于衡量图像相似性或失真程度的指标,通过模拟人类对图像质量的感知,包括亮度、对比度及结构三个方面,来评估图像处理算法对图像质量的影响,其计算公式见下式(4-52)。式中 X 和 Y 分别为两张输入图像, μ_x 与 μ_y 分别为 X 与 Y 的均值, σ_x 与 σ_y 分别是 X 与 Y 的方差, σ_{xy} 则是 X 和 Y 的协方差,其中 $c_1 = (255 \times 0.01)^2$, $c_2 = (255 \times 0.03)^2$,这两个值用来维持稳定并避免分母为零。

$$SSIM(X, Y) = \frac{(2\mu_X \mu_Y + c_1)(2\sigma_{XY} + c_2)}{(\mu_X^2 + \mu_Y^2 + c_1)(\sigma_X^2 + \sigma_Y^2 + c_2)} \quad (4-52)$$

$SSIM$ 的取值范围在-1 和 1 之间，其越接近 1 越代表两图像间的相似程度越高，该指标比 $PSNR$ 更符合人类视觉感知从而可以更好地反映图像的结构信息和感知质量。

3. 特征相似性指标

特征相似性(Feature Similarity Index, $FSIM$)考虑了图像局部结构相似性、全局亮度及对比度等特征，通过结合相位一致性特征(Phase Congruency, PC)与梯度特征(Gradient Magnitude, GM)进行综合评价，其计算公式见下式(4-53)。式中 ψ 代表图像的空间域，两幅图像 X 与 Y 其对应的相位一致性特征分别为 PC_X 与 PC_Y ，则 $PC_m(i) = \max(PC_X(i), PC_Y(i))$ ， $S_L(i)$ 代表 X 与 Y 间的相似值。 $FSIM$ 越接近 1 代表相应的图像处理算法质量越高。

$$FSIM = \frac{\sum_{i \in \psi} S_L(i) PC_m(i)}{\sum_{i \in \psi} PC_m(i)} \quad (4-53)$$

4. 交并比

交并比 IoU 代表算法所得区域与真实区域的重叠程度，通过该值可以评估分割算法的精准程度，其求解公式见下式(4-54)，式中 R_a 与 R_b 分别表示算法所得分割区域与实际区域。为更全面客观地对分割算法进行验证，引入平均交并比(mean Intersection over Union, mIoU)进行综合评估，其计算公式见下式(4-55)，其中 N 为输入图像个数。mIoU 越大则代表分割算法的精度越高。

$$IoU = \frac{S(R_a \cap R_b)}{S(R_a \cup R_b)} \quad (4-54)$$

$$mIoU = \frac{IoU}{N} \quad (4-55)$$

4.4.3 实验结果及分析

本小节基于上述软硬件环境及 OpenCV 库进行本章算法的实现及实验验证。将第三章目标检测算法所得的缺陷 ROI 区域作为本章算法的输入，易发现输入图像皆为像素分辨率较低且根据缺陷区域的面积而变化的灰度图像。下面将根据上述评价指标对各部分算法进行主观及客观验证。

1. 图像降噪算法

为验证本文所提改进双树复小波变换降噪算法对不同类型噪声的滤除效果,选取了 50 张缺陷极片图像并对其添加了标准差 $\sigma=0.001$ 的高斯噪声,分别使用高斯滤波(Gaussian filtering, GF)、中值滤波(Median Filtering, MF)、自适应中值滤波(Adaptive Median Filtering, AMF)、维纳滤波(Wiener Filtering, WF)、双边滤波(Bilateral Filtering, BF)、自适应双边滤波(Adaptive Bilateral Filtering, ABF)、小波阈值(Wavelet Thresholding, WT)及本文所提降噪算法进行实验对比,各个降噪算法结果对比图见下图 4-5。通过观察下图可以发现高斯滤波、中值滤波、小波阈值皆对图像细节有一定的模糊且对噪声的滤除不够彻底;自适应中值滤波与维纳滤波相对前三者的降噪性能与保边能力有一定的提升,但对边缘细节信息仍有一定的损失;双边滤波与自适应双边滤波在视觉效果方面较前几类算法有着明显的提升,在噪声抑制和边缘保护间保持着较好的平衡性;而显然本文所提改进双树复小波变换降噪算法在视觉方面处理效果最为优秀,通过对低频子带及重构图像进行快速自适应双边滤波并对高频子带进行相应的阈值收缩法,将图像背景中的无关噪声基本去除又最大程度地保持边缘纹理信息,在降除背景冗余信息干扰的同时对重要细节特征进行了有效保护。




图 4-5 各滤波算法降噪结果对比图

根据上述公式计算各个算法处理后图像的峰值信噪比均值及标准差,得到各去噪算法的信噪比参数见下表 4-1。 $PSNR_{ave}$ 的值越高代表滤波后的图像与原图间相似度越高,代表该算法的降噪效果越好, $PSNR_v$ 越小则代表该算法的稳定性越高,对于加噪图像无需计算其 $PSNR_v$ 。通过以上两个信噪比参数可对各个去噪算法的降噪能力、保边性能、稳定性进行客观的综合评价。对比各个参数易发现本文所提的改进双树复小波变换降噪

算法信噪比均值最高且信噪比标准差较低，在最大程度保证图像不失真的同时具备优秀的降噪性能。

表 4-1 各去噪算法峰值信噪比参数对比

	加噪声图像	高斯滤波	中值滤波	自适应中值滤波	维纳滤波	双边滤波	自适应双边滤波	小波阈值	本文降噪方法
$PSNR_{ave}$	33.048	37.124	36.463	37.149	37.143	38.681	39.875	34.980	41.059
$PSNR_v$	—	0.0190	0.0281	0.0322	0.0410	0.0201	0.0224	0.0246	0.0209

2. 图像增强算法

为验证本文所提改进 Retinex 算法对图像增强的有效性，将本文增强算法与 Gamma 变换、全局双亮度 Gamma 变换、Retinex、多尺度 Retinex 及 CLAHE 算法进行对比，图像增强前后对比图见下图 4-6。




图 4-6 各图像增强算法处理结果对比图

从主观角度观察发现，Gamma 变换对图像感兴趣区域进行了一定的增强，但图像整体亮度较暗的问题没有得到有效解决；全局双亮度 Gamma 变换在实现对暗区域增强的同时调整了图像整体亮度，有效增强图像对比度，但部分边缘细节信息被忽略；单尺度 Retinex 与多尺度 Retinex 效果相差不大且都存在光晕与伪轮廓现象。本文所提增强算法结合上述算法的优点，在增强图像感兴趣区域的同时保留了丰富的边缘细节信息，视觉上较其他几类图像增强算法具备明显的优势。

为客观验证本文算法的优越性，通过上述公式计算峰值信噪比、结构相似度及特征相似性评价指标，各算法具体参数指标如下表 4-2 所示。通过观察可知本文增强算法的

SSIM 与 *FSIM* 皆大于其他算法，*PSNR* 仅次于 Gamma 变换，说明本文所提的改进 Retinex 图像增强算法对关键边缘特征突出效果较好且失真程度较小，图像整体细节信息及结构特点保留完整，相对于其他算法具备显著优势。

表 4-2 各增强算法评估参数对比表

	Gamma 变换	全局双亮度 Gamma	单尺度 Retinex	多尺度 Retinex	CLAHE	本文增强算法
<i>PSNR</i>	18.3562	11.8765	16.2521	12.8786	17.7204	18.1252
<i>SSIM</i>	0.69273	0.56336	0.73014	0.68838	0.63104	0.75364
<i>FSIM</i>	0.78621	0.75029	0.83997	0.80224	0.86364	0.90042

结合主客观分析结果，易得本文增强算法在极片缺陷图像增强方面具备较高的处理性能，其有效性得以验证。

3. 改进 Canny 算子

为验证本文所提改进 Canny 算子对感兴趣区域的精准分割，将本文所提算法进行消融实验并与文献[90]的高效 Canny 进行对比，即将不同种类的极片缺陷图像作为输入，分别送入原始 Canny、结合改进滤波和改进 Sobel 算子的 Canny、结合改进滤波和基于改进麻雀优化的最大熵算法的 Canny、强噪声下的自适应 Canny 以及本文改进 Canny 进行缺陷区域的精密提取^[90]。为方便标识，在下面分析时分别将上述五种 Canny 算子其简称为 Canny、Canny1、Canny2、Canny3 及本文算法，同时对五种不同算法的处理结果分别计算 *FSIM* 和 mIoU 的值，检测结果及参数分别如表 4-3 及图 4-7 所示。

表 4-3 各算法评估参数对比表

	mIoU	<i>FSIM</i>						
		AK	KD	AB	HH	YH	QP	LJS
Canny	0.6814	0.70932	0.70868	0.67773	0.81046	0.78621	0.78989	0.68161
Canny1	0.7741	0.71313	0.71407	0.69615	0.83238	0.80754	0.80927	0.69624
Canny2	0.7685	0.71895	0.71471	0.69412	0.88084	0.81361	0.81814	0.70015
Canny3	0.8732	0.78096	0.79612	0.75432	0.89001	0.84781	0.83316	0.74974
本文 Canny	0.9083	0.80018	0.82039	0.78363	0.91647	0.85938	0.86985	0.79747




图 4-7 各算法缺陷提取结果对比图

从主观视角对实验结果对比图进行分析,易发现原始 Canny 算子可以较为有效的提取出边缘清晰、易识别缺陷的轮廓,但其受到背景无关噪声的影响较大且无法自适应获取精确的分割阈值,对于边缘细节较为模糊的难分割缺陷识别效果较差;加入降噪滤波及八方向 Sobel 的 Canny1 算子与原始算子相比,对缺陷的细节特征信息获取更为完整且抗干扰能力有一定的提升;与前述算法相比,融合降噪算法与改进最大熵算法的 Canny2 算子对缺陷轮廓的定位能力与无关信息的抑制能力明显增强;Canny3 算子在原始 Canny 的基础上,通过自适应模糊中值滤波、八方向 Sobel 及自适应迭代 Ostu 算法对其进行改进,综合识别效果较前三类算法有着明显的提升,但对边缘细节的定位不够精准且边缘获取的完整度有待提高;而本文 Canny 相较于前几种算法不但具备较高的噪声抑制能力,并对缺陷轮廓的定位精准程度有一定提升,且边缘的获取更为清晰完整,针对对比度较低提取难度较大的缺陷也有着良好的分割效果。

为客观评估本文算法的性能,通过观察表 4-3 参数易发现,本文所提 Canny 算子的 mIoU 值和其他四种 Canny 算法相比分别高 33.29%、17.33%、18.19%、4.02%,各类缺陷的 *FSIM* 值皆高于其他几类算子,证明缺陷提取出的图像较原始图像在结构、纹理、感兴趣区域的实际范围等方面更加一致。这代表本文改进算子能够有效地保留图像的关键信息,对于目标缺陷特征的失真程度较低,进一步证明了本文改进算法对极片缺陷分割的高精准性及高鲁棒性。

4.5 本章小结

本章围绕锂离子电池极片表面缺陷提取的要点与难点,对传统图像处理方法进行创新性的优化,提出一种高精度的缺陷区域分割算法。首先提出一种基于改进双树复小波变换的去噪技术,结合了改进阈值收缩法和自适应快速双边滤波以实现算法在最大程度减少无关噪声与纹理干扰的同时保留完整的边缘信息;接着通过改进的 Retinex 算法增强极片缺陷图像中的关键特征信息,通过梯度域引导滤波替换高斯滤波解决细节信息被模糊的问题,通过全局双亮度伽马变换及 CLAHE 算法分别对光照分量与反射分量进行处理,在平衡光照的同时增强图像的对比度;然后对原始的 Canny 边缘检测算子进行针对性的改进,先通过上述改进的去噪算法替换原本的高斯滤波,保证边缘特征的完整性,接着引入八方向 Sobel 算子进行梯度计算,之后通过最大熵算法自适应获取分割的阈值并通过麻雀搜索算法对阈值的搜索过程进行优化;最后采取形态学处理对缺陷的边缘进行连续性处理,并利用 OpenCV 提取缺陷区域的精准几何结构信息。

通过 4.4 节的对比实验进一步验证了本章所提分割算法在极片表面缺陷提取的有效性，其中算法的平均交并比高达 0.9083，*FSIM* 也高于其他分割算法，证明了该算法在保证高分割精度的同时，具备良好的鲁棒性能，成功实现了锂离子电池极片的像素级缺陷区域精密分割。

第五章 极片缺陷检测软件系统的设计及验证

5.1 引言

基于前几章详述的缺陷检测与分割算法的设计、实现与测试成果，本章首先从锂离子电池极片生产流水线的实际检测需求出发，并对预期功能进行整合优化，介绍软件系统流程设计与具体实现，同时构建了直观易用的用户交互界面。完成整体系统的搭建后，接下来对工业生产中的高强度长时间运行场景进行模拟，并选取综合评价指标以评估系统性能，确保投入实际生产线后，系统在复杂工作环境中的功能稳定性在符合设计预期的同时保持优越的检测性能。

5.2 开发环境与工具

本文软件系统基于 Pycharm 环境进行开发。Pycharm 是为 Python 开发者打造的一款强大的集成开发环境，它提供了丰富的代码编辑、调试、测试和部署工具，并支持大量的框架与外部库，其中本文主要用到了 Anaconda、Tensorflow、OpenCV 与 PyQt:

1. Anaconda 是当前较为流行的开源 Python 和 R 语言的发行版本，其包含大量数据科学和机器学习所需工具包如 NumPy、Pandas 等，同时可通过包管理器 conda 简化虚拟环境的创建和管理，确保不同项目间的依赖互不干扰。基于上述功能，采用 Anaconda 框架将大幅提升模型训练过程的效率。

2. Tensorflow 是由 Google 开发并维护的开源机器学习框架，当前在人工智能领域被广泛应用。其采用数据流(flow)的方式，对多维数组即张量(tensor)进行高效的数据计算，这样的架构使得 Tensorflow 在大规模数据集和复杂神经网络结构的处理方面具备十分优秀的性能。此外其支持多种 CPU/GPU 架构，并支持分布式训练，为模型迭代的过程提供了高质高效的技术支撑。

3. OpenCV 是一个功能强大的开源计算机视觉库，其提供了丰富的图像处理工具与大量的跨平台接口并支持多种编程语言，在图像增强、特征提取、图像分割等领域均表现出十分优秀的性能。同时其较强的灵活性使其在工业生产和学术研究应用领域愈加广泛，成为机器视觉领域的重要工具之一。

4. PyQt 是一个融合了 Python 开发环境与 Qt 库的图形用户界面（GUI）工具包。Qt 是依赖 C++ 语言编程的图形用户界面开发框架，PyQt 基于 Qt 为 Python 开发者提供丰富的桌面应用程序的控件与 API。它支持跨系统、跨平台开发，具备较高的可扩展性与兼容性，使用户可以灵活高效地实现桌面应用程序的构建。

5.3 极片缺陷检测软件流程设计

本文设计的锂离子电池极片表面缺陷检测软件流程如图 5-1 所示。




图 5-1 极片缺陷检测软件流程图

极片缺陷检测具体步骤如下：

1. 整体检测系统启动，运动控制、软件检测系统等子系统自检，运行正常则流程继续，出现异常则抛出警示；
2. 限位开关持续监测极片样本通过情况，当前检测到进件则发送信号；
3. 信号接收并处理完成后，相机将依照预设频率持续捕捉图像；
4. 对原始数据进行初步缺陷检测与识别；
5. 若检测结果为无缺陷极片，则流程结束，等待后续封装；
6. 若识别出缺陷，将对其进行分类与框定，并依据缺陷坐标与传送系统运行速度计算得到实际位置信息，迅速发送至贴标机，执行对应缺陷类型的贴标指令；
7. 将识别的目标缺陷送入分割算法模块中，获取缺陷提取结果及其几何数据，并将其同步于用户界面展示检测结果；
8. 将上述缺陷处理得到的详细数据进行入库处理。
9. 根据预设的质量指标对缺陷的长宽、周长、面积等信息进行判断；

10. 低于预设指标值, 则将其判断为合格品, 流程结束, 等待后续封装;
11. 高于预设指标值, 则将其判为不合格品, 进行进一步的分拣;
12. 结束。

5.4 软件异常处理机制

锂离子电池极片的工业生产环境复杂且工艺繁琐, 同时工作人员的操作具有一定主观性, 存在因失误、干扰等因素导致各种突发情况的风险, 例如可能出现硬件连接异常、传感器信号失真、传送带卡带受阻等问题, 给极片流水线的正常生产与检测环节带来挑战。为迅速应对突发异常情况, 最大程度降低损失, 本文软件检测系统针对性的设计故障告警和处理机制, 以保障极片生产线的稳定高效运行。

极片检测系统启动时, 首先检测相机与光源系统的运行情况, 若发现相机连接与启动失败则弹出告警信息“Open Camera Failed!”; 光源系统开启异常则弹出告警“Activate Light Source Failed!”, 此时用户需依据提示信息尽快排除故障并重启硬件以解除告警。相机与光源检测无误后, 接下来将确认运动控制系统与传感器运行情况, 若运动控制系统启动失败将弹出告警窗口“Start MC Failed!”同时机器红色指示灯亮起; 若传感器连入失败, 则提示告警信息“Start Sensor Failed!”。如出现上述异常, 工作人员需首先确认对应硬件模块功能正常, 并对整体通讯线路与电源接口进行排查, 直至排除故障告警解除后, 整体检测系统方可正常运行。

在检测系统运行的过程中, 传送装置将按照预设速度传输电池极片, 同时工业相机将按照预设频率拍摄原始图像, 二者若出现异常将导致检测系统失效, 甚至造成严重的经济损失。针对运行过程的突发情况, 若因线路、接口等问题导致相机异常中断, 软件界面会立即弹出告警信息“Lose Camera!”, 同时传送装置紧急制动, 极片检测系统暂时停止。而传送装置的异常情况则是通过传感器进行实时监测的, 如出现异物或极片卡住等突发问题, 速度传感器与压力传感器示数将出现显著异常, 超出阈值范围则立刻触发警报, 检测系统紧急制动。如出现上述故障, 需等待工作人员完成问题的诊断与修复后, 极片检测系统才可继续检测流程。

5.5 用户界面设计

本文软件系统基于 PyQt 框架, 遵循清晰、高效、美观的原则进行用户界面的设计, 如图 5-2 所示。交互页面主要包含三大功能区域: 输入与输出图像、检测数据与日志、预设参数配置。界面左上方的输入图像窗口直接向用户展示工业相机采集到的原始待测

极片图像，目标识别窗口则显示了目标分类与定位算法处理后的缺陷框定结果，缺陷种类、置信度等具体数据在二者下方实时输出；左下方的2个窗口分别展示了框定所得缺陷ROI与缺陷区域精密提取算法的分割结果，缺陷的长宽、面积等几何数据计算结果在二者正下方实时输出。在界面右上侧区域，用户可以在检测数据与日志窗口中查看软件系统的工作时间、检测样本总数与缺陷数等信息。页面右下部为预设参数配置与系统控制区域，具体功能涵盖了通讯串口参数设置如波特率、数据位、奇偶校验位等，传送装置参数设置与运行状态的实时监测及整体系统控制按钮。



图 5-2 极片缺陷检测软件用户界面

5.6 软件系统测试与性能分析

为确保本文设计的锂离子电池极片缺陷检测系统应用到工业流水线中也展现出优越的检测性能，本节对实际极片生产过程进行模拟，针对系统的稳定性和功能性分别进行测试，以验证本文系统在高工作强度流水线生产环境中的检测表现满足预期，可保质保量完成高精度的实时监测任务。

5.6.1 系统稳定性测试

系统稳定性测试是评估软件系统在复杂工作环境、高工作压力与突发异常等场景下，运行性能维持稳定的关键技术指标，是确保系统后续被长期投入检测生产线依然可以维

持高可靠性的重要环节。本文设计的锂离子电池极片缺陷检测系统涵盖了较多子系统，任一模块的软件或硬件出现问题都会对整体检测的稳定性造成直接影响，例如软件的编写是否存在漏洞从而在长时间运行过程中触发死锁、异常中断等常见程序错误；在持续检测缺陷密集样本等运算量急剧增加的场景中是否会出现程序错误，从而影响检测精度与速度；执行拍摄、贴标与分拣等硬件指令时是否会遇到兼容性错误等。考虑到以上多方面因素，本文对高强度持续运行的极片工业生产流水线环境进行模拟，令缺陷检测系统不间断运行 7 天以上的时间，期间分批次送入传送带数量不同、缺陷密度不同的极片样本进行 8 小时以上的循环检测，观察软硬件系统是否出现异常情况。

稳定性验证结果如下表 5-1 所示，本文检测系统持续运行 200 小时，完成了 33 批次极片样本的检测，期间软、硬件系统均未爆出错误，客观验证本文设计的锂离子电池极片缺陷检测系统具备卓越的稳定性，充分满足实际生产所需的高负荷持续检测的需求。

表 5-1 软件稳定性验证结果

连续运行时间/h	样本总批次	硬件系统异常/次	硬件系统异常/次	算法结果异常/次
200	33	0	0	0

5.6.2 系统功能性测试

功能性测试是极片缺陷检测系统被正式投入工业生产之前必要的验证过程，其核心目的是在模拟实际流水线环境时检验系统各项功能能否可有效实现，同时性能表现能够达到预期设计标准。基于上述考虑，本文在系统长时间连续运行的过程中，将 2000 张缺陷极片样本混入正常极片，分为多个批次送入检验，运行结束后围绕整体缺陷检测的检测精度、准确率等指标进行统计与分析。实验结果如表 5-2 所示，验证了本文设计的锂离子电池极片缺陷检测系统在高强度流水线环境中，对于孔洞、漏金属、压痕、凹坑、划痕、气泡、暗斑等常见缺陷均具备优秀的识别和分割效果，检测性能指标符合预期，满足实际工业生产需求。

表 5-2 软件功能性验证结果

缺陷种类	划痕	孔洞	暗斑	凹坑	漏金属	气泡	压痕
样本数/个	233	309	256	240	330	325	314
检出/个	214	298	234	217	308	308	296
错检/个	11	6	13	10	7	10	10
漏检/个	8	5	9	13	15	7	8
准确率/%	95.11%	98.03%	94.74%	95.60%	97.78%	96.86%	96.73%
召回率/%	96.40%	98.35%	96.30%	94.35%	95.36%	97.78%	97.37%

5.7 本章小结

本章主要围绕锂离子电池极片缺陷检测系统的研发与测试过程进行了详细介绍。系统研发过程主要包含软件检测流程与用户界面的创新性设计，以及系统运行时应对突发异常的处理机制。接下来，本章针对整体系统的稳定性与功能性测试展开全面测试，实验结果充分验证了本文所设计的锂离子电池极片缺陷检测系统在具备较高实时性与准确率的同时，在长时间高强度运行的测试条件下依然能够保持较高的稳定性与检测精度，足以满足实际工业生产流水线的检测需求。

总结与展望

工作总结

本文主要围绕锂离子电池极片表面缺陷检测的要点与难点,为实现极片表面缺陷的准确分类与精准分割提出一套基于工业生产流水线的极片缺陷检测方案。该技术方案涵盖了从硬件系统构建到软件算法应用的全面高精度检测流程。在硬件系统方面,本文重点设计了极片的成像系统和运动控制系统,其中包括硬件设备的选型与核心技术路线的设计;在软件算法方面,着重于缺陷识别与提取的核心算法的开发与优化,最终实现一种兼顾检测效率与实时性的锂离子电池极片缺陷高精度识别和像素级分割的检测系统。

本文的主要研究成果如下:

1. 依照锂离子电池极片的制备流程,分析极片表面的缺陷特征与成因,并根据极片缺陷检测的要点与难点,设计极片缺陷检测系统的软硬件技术路线,其包括相机、镜头、光源等成像系统的硬件设备选型及运动控制系统的实现,使本文实验平台满足 0.05mm 的检测精度及 1000mm/s 的检测速度需求。最终基于可容忍性检测的策略提出本文“识别-分割”的软件模块,给出本文检测系统的整体技术路线。

2. 对于极片缺陷分类与定位的阶段,本文基于兼顾检测精度与实时性的 YOLOv8 模型提出多类创新点,首先提出基于深度卷积的多尺度动态注意力机制,将其嵌入特征提取主干网络中,以较低的计算成本置换更强的网络表征能力,大幅度提升模型对于缺陷的特征识别能力;其次引入 SimCSPSPF 模块在提升检测精度的同时保持网络的低计算复杂度;同时为解决微小、跨尺度缺陷漏检错检的问题,提出一种基于稠密连接的多尺度双向特征金字塔对特征融合的方式进行改进,减少冗余信息的干扰以提升模型识别的效率;最后针对极片缺陷难易样本不均衡及微小目标位置敏感等问题,引入 Slide-NWD 损失函数以提升目标定位的精准性。最终本文所研发的改进 YOLO 极片目标识别算法的平均检测精度高达 94.42%且检测速率达 40.06FPS,在极片缺陷检测任务中具备强大的性能,可应用于工业生产流水线中。

3. 为实现不合格极片的有效分拣,针对识别出的极片缺陷进行进一步的精准分割与相关几何数据提取,本文研发出一种基于改进 Canny 算子的像素级缺陷提取算法。首先根据极片表面存在噪声污染及纹理干扰,结合改进阈值收缩法与自适应快速双边滤波提出一种改进的双树复小波变换算法对图像进行保边降噪的处理;接着为强调图像中关键边缘特征并弱化无关信息的干扰,提出一种改进的 Retinex 图像增强算法,通过梯度域

引导滤波替换高斯滤波避免图像细节的模糊，同时使用全局双亮度伽马变换及 CLAHE 算法改善光照不均的同时增强图像对比度；最终结合极片缺陷的分割难点对 Canny 边缘检测算子进行针对性改进，使用改进的滤波算法保持缺陷边缘的完整性，通过八方向 Sobel 算子提升算法对目标区域关键特征的捕捉能力，接着提出一种改进的麻雀搜索算法对最大熵算法进行阈值的寻优优化，令本文的 Canny 算子可以快速自适应获取缺陷分割的高低阈值，有效地提升了算法的泛化能力与鲁棒性，最终通过边缘判定与形态学处理增强边缘的连续性。通过实验及多种评估指标从主客观方面分别验证了本文所提的基于像素级分割的缺陷区域精密提取算法的精准性与鲁棒性，成功实现了极片表面微小缺陷的高精度分割。

4. 在针对缺陷检测软件系统的研究阶段，主要对于软件检测流程、系统异常的预警机制及用户界面进行了创新性的设计。同时针对系统的稳定性及功能性进行全方位的测试，实验结果验证了本文所设计的锂离子电池极片缺陷检测系统在长时间高压的模拟运行中仍具备较高的实时性与准确性，能够高性能的完成工业生产中高强度的极片缺陷检测任务，具备较高的实际应用价值。

前景展望

本文基于锂离子电池极片高精度实时缺陷检测的需求，研发出一种高效的极片缺陷识别与分割系统，其可以较好地满足工业生产流水线上的实时监测需求，取得了初步的研究成果。但受到个人能力和研发时间等限制条件的影响，本文的检测系统仍存在着进一步改进和提升的空间，未来将从以下几个方面对其进行完善。

1. 由于客观条件的限制，与实际生产出现的缺陷相比，本文样本的种类与数量仍不够丰富，后续可以针对极片表面的脱碳、亮点等缺陷进行研究，扩充数据集的同时使缺陷检测系统的功能更加完善。

2. 本文所提的极片缺陷目标分类与定位算法虽具备优秀的综合性能，但是对于暗斑、凹坑、划痕这几类缺陷的平均检测精度有待提升。后续可针对这几类缺陷形态多变、对比度低、跨尺度大等检测难点进行针对性的算法优化，提升检测系统的综合识别精度。

3. 尽管本文所研究的缺陷区域提取算法 mIoU 可达 0.9083，具备较高的分割精度，但仍存在一定的进步空间，后续可结合一些优化算法对目标区域提取过程的边缘定位精度及效率进行提升，使缺陷分割算法得到鲁棒性和精准性的综合提高。

参考文献

- [1] 张金龙, 佟微, 漆汉宏. 锂电池发展浅谈[J]. 电源技术, 2017, 41(09): 1377-1379.
- [2] 杨冬进, 娄建安. 锂离子电池及其在线检测前沿与发展综述[J]. 电源技术, 2018, 42(09): 1402—1419.
- [3] Zubi G, Dufo-López R, Carvalho M, et al. The lithium-ion battery: State of the art and future perspectives[J]. Renewable and Sustainable Energy Reviews, 2018, 89: 292-308.
- [4] MASIAS A, MARCICKI J, PAXTON W A. Opportunities and challenges of lithium ion batteries in automotive applications[J]. ACS Energy Letters, 2021, 6(2): 621-630.
- [5] 黄彦瑜. 锂电池发展简史[J]. 物理, 2007, 36(8): 643-651.
- [6] Xu Y X, Niu L C, Yang H, et al. Optimization of lithium battery pole piece thickness control system based on GA-BP neural network[J]. Journal of Nanoelectronics and Optoelectronics, 2019, 14(7): 978-986.
- [7] 田慧欣, 秦鹏亮, 李坤, 等. 基于 HI-DD-AdaBoost. RT 的锂离子动力电池 SOH 预测[J]. 控制与决策, 2021, 36(3): 686-692.
- [8] Lai X, Jin C, Yi W, et al. Mechanism, modeling, detection, and prevention of the internal short circuit in lithium-ion batteries: Recent advances and perspectives[J]. Energy Storage Materials, 2021, 35: 470-499.
- [9] Xiong R, Sun W, Yu Q, et al. Research progress, challenges and prospects of fault diagnosis on battery system of electric vehicles[J]. Applied Energy, 2020, 279: 870-872.
- [10] Tagawa K, Brodd R J. Production processes for fabrication of lithium-ion batteries[J]. Lithium-ion batteries: Science and technologies, 2009: 181-194.
- [11] 赵鹏. 机器视觉理论及应用[M]. 北京: 电子工业出版社, 2011: 1-9.
- [12] Roberts L G. Machine perception of three-dimensional solids[D]. Massachusetts Institute of Technology, 1963.
- [13] Marr D. Vision: A Computational Investigation into the Human Representation and Processing of Visual Information[M]. New York: W.H. Freeman and Company, 1983: 8-38.
- [14] 龚健雅. 人工智能时代测绘遥感技术的发展机遇与挑战 [J]. 武汉大学学报, 2018, 43 (12): 1788-1796.
- [15] Han X X, Geng S Y, Li H Y. Application review of defect detection based on machine vision[J]. Electric Engineering, 2019, 40(14): 117-118.
- [16] Taniguchi T, Kacprzak D, Yamada S, et al. Wavelet-based processing of ECT images for

- inspection of printed circuit board[J]. IEEE Transactions on Magnetics, 2001, 37(4):2790-2793.
- [17] Jaffery Z A, Ahmad N, Sharma D. Performance comparison of segmentation techniques for detection of defect in rail head surface images[C]. 2017 International Conference on Multimedia, Signal Processing and Communication Technologies (IMPACT). IEEE, 2017: 132-136.
- [18] 慕德旭, 杨蕾, 吴志强. 基于改进多尺度 Retinex 图像增强和支持向量机的苹果表面缺陷检测[J]. 食品安全质量检测学报, 2023, 14(20): 183-191.
- [19] 徐学谦, 李克铭, 徐开源等. 基于改进型区域生长法的焊接缺陷 DR 图像自动识别[J/OL]. 航空制造技术: 1-7 [2023-12-25].
- [20] 柴子凡, 赵丽琴, 蒋海波等. 基于 Hough 变换和 K-means 聚类的玻璃瓶分模线缺陷检测[J]. 机械设计与研究, 2023, 39(03): 171-174.
- [21] Zuo F, Liu J, Fu M, et al. An Effective Detection Method for Complex Weld Defects Based on Adaptive Feature Pyramid[C]. 2023 CAA Symposium on Fault Detection, Supervision and Safety for Technical Processes (SAFEPROCESS). IEEE, 2023: 1-5.
- [22] Tang L, Cheng K, Wang X, et al. Improved Yolov5n strip surface defect detection algorithm[C]. 2023 CAA Symposium on Fault Detection, Supervision and Safety for Technical Processes (SAFEPROCESS). IEEE, 2023: 1-5.
- [23] Wu Z, Zhang Z, Xu J, et al. A Deep Learning Based Surface Defect Detection Method with Coarse Granularity for Corrugated Fuel Tubes[C]. 2022 41st Chinese Control Conference (CCC). IEEE, 2022: 6725-6730.
- [24] Zhang Y, Zou H, Wang J, et al. Lightweight Neural Network-based Real-time PCB Defect Detection System[C]. 2023 CAA Symposium on Fault Detection, Supervision and Safety for Technical Processes (SAFEPROCESS). IEEE, 2023: 1-6.
- [25] 许长路, 李林升, 立济伟. 基于 Gamma 矫正与 LOG 算法融合的锂电池极片缺陷检测方法[J]. 机械设计与研究, 2020, 36(06): 105-109.
- [26] 王露. 基于机器视觉的锂电池极片缺陷检测与分类系统[D]. 西安科技大学, 2021.
- [27] Xu C, Li L, Li J, et al. Surface defects detection and identification of lithium battery pole piece based on multi-feature fusion and PSO-SVM[J]. Ieee Access, 2021, 9: 85232-85239.
- [28] 黄梦涛, 连一鑫. 基于改进 Canny 算子的锂电池极片表面缺陷检测[J]. 仪器仪表学报, 2021, 42(10): 199-209.

-
- [29] Tao Y, Li L, Mao W, et al. Lithium Battery Pole Piece Defect Detection Method Based on Mean Shift and Gray-level Co-occurrence Matrix[C]//2022 2nd International Conference on Electrical Engineering and Control Science (IC2ECS). IEEE, 2022: 695-699.
- [30] 莫慧芳. 锂电池检测系统的设计[J]. 自动化技术与应用, 2016 (6): 139-140.
- [31] 查闯. 动力锂离子电池极片自动检测分选装置设计研究[D]. 南京: 东南大学, 2016.
- [32] 罗锋华. 论高性能锂电池材料的应用趋势[J]. 湖北农机化, 2020, 42(10): 47-48.
- [33] Liu Y, Zhang R, Wang J, et al. Current and future lithium-ion battery manufacturing[J]. IScience, 2021, 24(4).
- [34] 王金鹏. 锂电池极片全连续制造设备与关键技术研究[D]. 太原: 太原科技大学, 2018.
- [35] 陈三仔. 锂电池负极材料的研究进展及展望分析[J]. 科技风, 2020, 33(3): 161.
- [36] 关志波, 朱素冰. 锂电正极材料市场状况及发展趋势[J]. 新材料产业, 2018, 20(9): 23-27.
- [37] Litwiller D. CCD vs. CMOS[J]. Photonics spectra, 2001, 35(1): 154-158.
- [38] 孙波, 王晓艳. CCD 图像传感器和 CMOS 图像传感器的比较研究[J]. 信息通信, 2015(12): 35-36.
- [39] Montoya F G, Peña-García A, Juaidi A, et al. Indoor lighting techniques: An overview of evolution and new trends for energy saving[J]. Energy and buildings, 2017, 140: 50-60.
- [40] 王义轩. 基于图像采集卡的图像显示与处理软件开发研究[J]. 信息与电脑, 2019, 31(21): 99-100.
- [41] 廖琼章, 邓广. 工控机在智能制造系统中的应用研究[J]. 轻工科技, 2019, 35(10): 100-101.
- [42] 刘国栋. 基于深度学习的锂电池极片表面缺陷检测方法研究[D]. 广东工业大学, 2022.
- [43] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]. 2014 IEEE Conference on Computer Vision and Pattern Recognition(CVPR). Columbus: IEEE, 2014: 580-587.
- [44] Girshick R. Fast R-CNN[C]. 2015 IEEE International Conference on Computer Vision (ICCV). Santiago: IEEE, 2015: 1440-1448.
- [45] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[J]. IEEE Transactions on Pattern Analysis and Machine

- Intelligence, 2017, 39(6): 1137-1149.
- [46] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas: IEEE, 2016: 779-788.
- [47] Redmon J, Farhadi A. YOLO9000: Better, Faster, Stronger[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2017, 7263-7271.
- [48] Redmon J, Farhadi A. YOLOv3: An Incremental Improvement[J]. arXiv e-prints, 2018.
- [49] He K, Zhang X, Ren S, et al. Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition[C]. 2014:1904-16.
- [50] LIU S, QI L, QIN H, et al. Path aggregation network for instance segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Salt Lake City, USA, June 18-23,2018:8759-8768.
- [51] Zheng Z, Wang P, Liu W, et al. Distance-IoU Loss: Faster and Better Learning for Bounding Box Regression[J]. arXiv, 2019.
- [52] Bochkovskiy A, Wang C Y, Liao H. YOLOv4: Optimal Speed and Accuracy of Object Detection[J]. 2020.
- [53] Glenn J. YOLOv5. <https://github.com/ultralytics/yolov5>,2020.
- [54] Rezatofighi H, Tsoi N, Gwak J Y, et al. Generalized Intersection Over Union: A Metric and a Loss for Bounding Box Regression[C]. 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR).IEEE, 2019.
- [55] Gevorgyan Z. SIoU loss: More powerful learning for bounding box regression[J]. arxiv preprint arxiv:2205.12740, 2022.
- [56] Li C, Li L, Jiang H, et al. YOLOv6: A single-stage object detection framework for industrial applications[J]. arXiv preprint arXiv:2209.02976, 2022.
- [57] Wang C Y, Liao H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]. arXiv.arXiv, 2022.
- [58] Glenn J. YOLOv8. <https://github.com/ultralytics/ultralytics>.
- [59] Zou X, Wu Z, Zhou W, et al. YOLOX-PAI: An Improved YOLOX, Stronger and Faster than YOLOv6[J]. arxiv preprint arxiv:2208.13040, 2022.
- [60] Wang C Y, Liao H Y M, Wu Y H, et al. CSPNet: A New Backbone that can Enhance Learning Capability of CNN[C].2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. IEEE, 2020.
- [61] Huang G, Liu Z, Laurens V D M, et al. Densely Connected Convolutional Networks[J]. IEEE Computer Society, 2016.

-
- [62] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]. IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2016.
- [63] Hu J, Shen L, Albanie S, et al. Squeeze-and-Excitation Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 42(8): 2011-2023.
- [64] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]. Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [65] Meng-Hao G, Cheng-Ze L, Qibin H, Zhengning L, Ming-Ming C, Shi-Min H, et al. SegNeXt: Rethinking Convolutional Attention Design for Semantic Segmentation[C]. Conference on Neural Information Processing Systems, 2022.
- [66] Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arxiv preprint arxiv:1704.04861, 2017.
- [67] Li C, Li L, Geng Y, et al. Yolov6 v3. 0: A full-scale reloading[J]. arxiv preprint arxiv:2301.05586, 2023.
- [68] Tan M, Pang R, Le Q V. Efficientdet: Scalable and efficient object detection[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 10781-10790.
- [69] Yu Z, Huang H, Chen W, et al. Yolo-facev2: A scale and occlusion aware face detector. arxiv 2022[J]. arxiv preprint arxiv:2208.02019.
- [70] Wang J, Xu C, Yang W, et al. A normalized Gaussian Wasserstein distance for tiny object detection. arxiv 2021[J]. arxiv preprint arxiv:2110.13389.
- [71] Li L, Jiang Z, Li Y. Surface Defect Detection Algorithm of Aluminum Based on Improved Faster RCNN[C]. 2021 IEEE 9th International Conference on Information, Communication and Networks (ICICN). Xi'an: IEEE, 2021: 527-531.
- [72] Zhang M, Gunturk B K. Multiresolution bilateral filtering for image denoising[J]. IEEE Transactions on image processing, 2008, 17(12): 2324-2333.
- [73] Zhou Y, Fu X. Image denoising based on dual-tree complex wavelet transform and convolutional neural network[C]. Journal of Physics: Conference Series. IOP Publishing, 2021, 1995(1): 012030.
- [74] 崔金鸽, 陈炳权, 徐庆. 基于 Dual-Tree CWT 和自适应双边滤波器的图像去噪算法[J]. 计算机工程与应用, 2018, 54(18): 223-228.
- [75] Gavaskar R G, Chaudhury K N. Fast adaptive bilateral filtering of color images[C]. 2019 IEEE International Conference on Image Processing (ICIP). IEEE, 2019: 180-184.
- [76] Durand F, Dorsey J. Fast bilateral filtering for the display of high-dynamic-range

- images[C]. Proceedings of the 29th annual conference on Computer graphics and interactive techniques. 2002: 257-266.
- [77] Jobson D J, Rahman Z, Woodell G A. Properties and performance of a center/surround retinex[J]. IEEE transactions on image processing, 1997, 6(3): 451-462.
- [78] Kou F, Chen W, Wen C, et al. Gradient domain guided image filtering[J]. IEEE Transactions on Image Processing, 2015, 24(11): 4528-4539.
- [79] Sazzad T M S, Hasan M Z, Mohammed F, et al. Gamma encoding on image processing considering human visualization, analysis and comparison[J]. International Journal on Computer Science and Engineering, 2012, 4(12): 1868.
- [80] 苏波, 李超, 王莉. 基于多权重融合策略的 Retinex 矿井图像增强算法[J/OL]. 煤炭学报: 1-11[2023-04-20].
- [81] He K, Sun J, Tang X. Guided image filtering[J]. IEEE transactions on pattern analysis and machine intelligence, 2012, 35(6): 1397-1409.
- [82] Liu N, Zhao D. Detail enhancement for high-dynamic-range infrared images based on guided image filter[J]. Infrared Physics & Technology, 2014, 67: 138-147.
- [83] Li Z. Contrast Limited Adaptive Histogram Equalization[J]. Computer Knowledge and Technology, 2010.
- [84] CANNY J. A computational approach to edge detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1986, 8(6): 679-698.
- [85] 韦德鹏, 陈继清, 罗天等. 基于改进八方向 Sobel 算子的图像轮廓提取方法[J]. 现代电子技术, 2022, 45(19): 54-58.
- [86] Wang Z, Nie F, Wang R, et al. Local structured feature learning with dynamic maximum entropy graph[J]. Pattern Recognition, 2021, 111: 107673.
- [87] Xue J, Shen B. A novel swarm intelligence optimization approach: sparrow search algorithm[J]. Systems science & control engineering, 2020, 8(1): 22-34.
- [88] 李鹏, 丁倩雯. 基于麻雀算法优化的 OSTU 分割算法[J]. 电子测量技术, 2021, 44(19): 148-154.
- [89] 杨雪松, 张长胜, 王卓等. 基于改进麻雀优化算法的阴极铜板图像结瘤分割[J]. 陕西理工大学学报(自然科学版), 2022, 38(05): 48-57+92.
- [90] 刘宇涵, 闫河, 陈早早等. 强噪声下自适应 Canny 算子边缘检测[J]. 光学精密工程, 2022, 30(03): 350-362.