

面向同轴封装金属底座缺陷的 Metal-YOLO 检测算法

张不凡^{1,2}, 俞经虎^{1,2}, 朱行飞^{1,2}, 孙召飞^{1,2}, 陆煜^{1,2}¹江南大学机械工程学院, 江苏 无锡 214122;²江苏省食品先进制造装备技术重点实验室, 江苏 无锡 214122

摘要 针对同轴封装金属底座缺陷检测中存在的检测精度不足、误检和漏检的问题,提出了一种基于 YOLO v5s 的改进模型,即 Metal-YOLO 检测算法。通过引入跨层特征增强连接(CFEC)显著增强模型对复杂小目标缺陷的表征能力,从而有效降低漏检率。为进一步提升模型对不同尺度缺陷特征的感知和判别能力,在模型中融入自适应注意力模块(AAM),有效减少背景信息的干扰。此外,针对完全交并比(CIoU)损失函数在缺陷目标框定位方面的不足,采用有效交并比(EIoU)损失函数,显著提升预测框的定位精度。实验结果表明,Metal-YOLO 在金属表面缺陷检测任务中展现出卓越的性能,其召回率和平均精度均值分别达到 74.1% 和 78.3%,相较于基准模型 YOLO v5s 分别提升了 5.0 个百分点和 4.1 个百分点,显著提升了模型对金属表面缺陷的检测效果。

关键词 机器视觉; 缺陷检测; YOLO 算法; 同轴封装金属底座

中图分类号 TP391

文献标志码 A

DOI: 10.3788/LOP240829

Metal-YOLO Detection Algorithm for Defects in Coaxial Packaged Metal Base

Zhang Bufan^{1,2}, Yu Jinghu^{1,2}, Zhu Xingfei^{1,2}, Sun Zhaofei^{1,2}, Lu Yu^{1,2}¹School of Mechanical Engineering, Jiangnan University, Wuxi 214122, Jiangsu, China;²Jiangsu Key Laboratory of Advanced Food Manufacturing Equipment and Technology, Wuxi 214122, Jiangsu, China

Abstract To resolve issues of insufficient detection accuracy, false detection, and missing detection in defect detection of coaxial packaged metal bases, this paper proposes an improved model called Metal-YOLO, which builds upon YOLO v5s. By introducing cross-layer feature enhancement connection(CFEC), the model ability to represent complex small object defects is substantially enhanced, effectively reducing the missing detection rate. To further improve the model ability to perceive and discriminate defect features across different scales, an adaptive attention module is integrated into the model, which effectively minimizes background information. Additionally, recognizing the shortcomings of the complete intersection over union (CIoU) loss function in the localization of defect object boxes, the effective intersection over union (EIoU) loss function is adopted. This change remarkably improves the precision of the prediction box positioning. Experimental results demonstrate that Metal-YOLO excels in metal surface defect detection tasks. Furthermore, the proposed model achieves a recall rate and mean average precision values of 74.1% and 78.3%, showing an improvement of 5.0 percentage points and 4.1 percentage points, respectively, compared to the baseline model YOLO v5s, substantially enhancing the effectiveness of metal surface defect detection.

Key words machine vision; defect detection; YOLO algorithm; coaxial packaged metal base

1 引言

激光二极管在光通信领域的应用广泛,同轴封装是激光二极管行业中最常见的封装手段之一,尤其适用于小功率激光器件的封装。金属底座作为同轴封装

器件的重要组成部分,用于连接发光二极管和引脚。然而,受制于制造工艺、加工设备以及原材料等因素,使用过程中金属底座表面不可避免地出现锈迹、裂纹、磕碰等缺陷^[1]。这些缺陷不但损害了零件的外观质量,更对其可靠性构成了潜在威胁。因此,对同轴封装

收稿日期: 2024-03-06; 修回日期: 2024-03-13; 录用日期: 2024-03-25; 网络首发日期: 2024-04-12

基金项目: 国家自然科学基金(51375209)

通信作者: *jnxxjinhuyu@163.com

金属底座进行高效且精确的缺陷检测,对于确保产品金属底座质量具有重要意义^[2]。

传统的金属零件外观缺陷检测主要依赖于人工目检,这种方法受限于检测人员的主观经验,因此其准确率和效率均较低,难以满足大规模工业生产的实际需求。后来传统机器学习方法通过手工设计特征并将特征输入分类器进行分类,在一定程度上提升了检测的效率和精度。然而,在实际生产环境中,金属零件的结构缺陷较为复杂,手工设计的特征往往缺乏针对性,自动化程度也不高,因此难以保证检测的准确性和效率。随着计算机视觉和硬件设备的快速发展,深度学习在缺陷检测领域逐渐取代了传统方法。在目标检测任务方面,深度学习能够深度挖掘图像数据的内在信息,相较于传统机器学习方法,不仅提升了检测效果,还表现出更强的鲁棒性。深度学习目标检测方法主要分为单阶段和双阶段两类。典型的双阶段算法如区域卷积神经网络(R-CNN)^[3]、Faster R-CNN^[4]将目标检测分为候选框生成和目标类别识别两个阶段,实现了较高的检测精度。而单阶段算法如 YOLO(you only look once)^[5]、SSD(single shot MultiBox detector)^[6]等,通过预设锚框直接预测目标位置和类别,从而实现较快的检测速度。目前,基于深度学习的目标检测方法已广泛应用于金属零件表面缺陷的检测。程婧怡等^[7]通过增加检测头的方法提取更多的小目标缺陷信息,有效提升了小目标缺陷的召回率。吴磊等^[8]针对铝合金焊缝缺陷检测中检测精度低的问题,使用 Focus 模块并将损失函数替换为加权交并比(WIoU)函数以改进 YOLO v8 算法,实验结果表明改进后的算法显著提高了模型的锚框质量和检测效果。凌强等^[9]采用深度可分离卷积和基于规范化的注意力模块(NAM)构建了一种轻量级的主干网络,确保模型在具有较高检测率的同时显著降低了模型的复杂度和计算量。曾耀等^[10]利用加权双向特征金字塔(BiFPN)^[11]和坐标注意力(CA)模块提升了模型对多尺度缺陷特征的定位和识别能力。

目前在金属表面缺陷检测中,大多数研究侧重于从改进模块层面提升模型的检测效果^[12-14],然而缺陷的类型、尺寸、形状及其特征的复杂性仍然是影响检测精度的关键因素。特别是在检测像素小于 $32 \text{ pixel} \times 32 \text{ pixel}$ 的缺损、锈迹类等小目标缺陷时,现有方法往往难以取得理想效果。鉴于此,本文基于 YOLO v5s 算法提出了一种 Metal-YOLO 缺陷检测模型,从金属表面缺陷特征层面改进模型以提升检测效果。首先,通过引入跨层特征增强连接(CFEC)以丰富深层局部信息,从而提升小目标缺陷的表征能力。其次,添加自适应注意力模块(AAM),提高模型对不同缺陷特征的判别能力,进而更好地感知多尺度缺陷的特征信息。最后,通过引入有效交并比(EIoU)损失函数进一步优化模型预测框的回归精度。实验结果表明,改进后的

Metal-YOLO 模型在检测精度、误检率和漏检率等方面均有所改善。

2 Metal-YOLO 网络

目标检测任务中,根据 MS COCO (microsoft common objects in context)数据集的绝对尺度定义,小尺寸目标特指分辨率低于 $32 \text{ pixel} \times 32 \text{ pixel}$ 的目标。对于同轴封装金属底座表面的缺陷检测而言,缺损、锈迹和沾银等缺陷常常以小尺寸目标的形式出现,给检测任务带来了极大的挑战。YOLO v5 在检测速度和检测精度上实现了较好的平衡,并展现了出色的检测性能,但在实际应用中仍面临诸多难题。由于拍摄条件限制,在反光的情况下金属底座的浅层缺损与白斑缺陷的视觉效果极为相似,这种类型间相似性显著增加了模型区分这两类缺陷的难度。同时,同一类缺陷中也存在显著的差异性,部分缺陷的尺度变化大、形状不规则,这一问题进一步增加了模型检测的难度。此外,大量小目标缺陷在图像中占据像素较少,所携带的特征信息有限,使模型难以将其从复杂的背景中准确分离。

经过广泛的测试和优化,已经证明 YOLO v5 在多种任务中具有有良好的性能,稳定性较高。此外,YOLO v5 在性能和精度之间取得了很好的平衡。在工业检测领域中,模型需要在保证一定精度的同时具有较快的推理速度和较小的模型尺寸。为解决上述问题,本文以 YOLO v5s 7.0 版本为基准模型提出了 Metal-YOLO 改进模型。模型主要由输入端、主干网络、颈部和头部 4 个部分组成,具体结构如图 1 所示,其中 SPPF 模块为快速空间金字塔池化模块,BN 为批归一化,ReLU 为线性修正单元激活函数,MLP 为多层感知机。

Metal-YOLO 通过主干网络对输入图像进行多次卷积和下采样操作,以提取金属表面缺陷的局部特征。为了提升模型对多尺度缺陷的检测能力,在主干网络末端引入 AAM。此外,在颈部部分使用路径聚合网络(PANet)结构以增强特征的融合,并通过 CFEC 进一步融合深层和浅层特征信息,进而提高模型对小目标缺陷的检测能力。最后,检测头部分采用 EIoU 损失函数提升预测框定位效果,确保模型能够更精确地定位金属表面的缺陷。

2.1 CFEC

同轴封装金属底座表面缺陷通常包含大量小目标缺陷。这些小目标缺陷在原始图像中的覆盖面积较小,其自身携带的特征信息相当有限。此外,随着卷积神经网络的多次下采样后操作,输入特征图的尺寸不断减小,导致小目标缺陷的细节信息在特征图中丢失严重。为了有效应对这一难题,在小目标检测任务中广泛应用多尺度策略。浅层网络更加注重细节信息的捕捉,其特征图富含局部信息,有利于模型捕捉更多的




图1 Metal-YOLO结构图

Fig. 1 Structure diagram of Metal-YOLO

小目标信息。受到特征金字塔网络(FPN)^[15]、PANet^[16]、BiFPN^[11]和交叉卷积特征加强连接(CCFSC)^[17]等结构的启发,本文提出CFEC,旨在促进浅层定位信息与深层语义信息的融合,从而解决网络深度增加时小目标缺陷信息退化的问题。

CFEC的具体实现方式是在上下采样得到相同分辨率的金属表面缺陷特征融合的基础上,当原始输入和输出节点尺度相同时,引入一条额外的路径,在不过度增加计算成本的情况下实现同尺度的特征融合,融合路径如图1中的弯曲虚线所示。

在CFEC中,采用轻量化多层感知机^[18]捕捉目标缺陷的局部信息和长距离依赖关系,轻量化多层感知机的结构如图2所示。该结构由深度可分离卷积模块和通道多层感知机模块串联而成。此外,为了提高模型的特征泛化能力和鲁棒性,在两个模块中引入了通道修剪操作和DropPath操作。

具体而言,首先将主干网络的输出特征图通过一个stem模块,接着对其进行组归一化,并将组归一化的结果作为深度可分离卷积模块的输入(F_{in})。相对于传统的二维卷积,深度可分离卷积在保留通道信息的同时,有效降低了计算开销。然后对输出的特征图依次执行通道修剪操作和DropPath操作,最后与一个残差连接,以提供更多的信息。以上过程可表示为




图2 轻量化多层感知机结构图

Fig. 2 Structure diagram of lightweight MLP

$$F_{dw} = Dw \left\{ Drop \left\{ CS \left[GN(F_{in}) \right] \right\} \right\}, \quad (1)$$

式中: F_{dw} 为深度可分离卷积模块的输出; $GN(\cdot)$ 为组归一化; $CS(\cdot)$ 和 $Drop(\cdot)$ 分别为通道修剪和DropPath操

作; $Dw(\cdot)$ 为卷积核为 1×1 的深度可分离卷积。

在通道多层感知机模块中,对经组归一化后的 F_{dw} 进行处理得到 F_{MLP} 。然后,对 F_{MLP} 依次执行通道修剪操作、DropPath操作,并且与 F_{dw} 进行特征融合。其过程为

$$F_{MLP} = \text{Drop}\left\{\text{CS}\left[\text{GN}\left(F_{dw}\right)\right]\right\}, \quad (2)$$

$$F_{out} = \text{Channel MLP}\left(F_{MLP}\right) + F_{dw}, \quad (3)$$

式中: F_{out} 为轻量化多层感知机的输出;Channel MLP($\cdot$)表示通道多层感知机模块。

最终,将颈部网络中原有特征与 F_{out} 进行特征融

合,得到具有最抽象的语义信息和丰富的定位信息的特征。

2.2 AAM

在同轴封装金属底座表面的缺陷检测中,同一类缺陷之间往往具有不同的尺度,而不同尺度的图像提供了不同的缺陷信息:粗尺度主要显示整体轮廓和位置;细尺度主要强调纹理、边缘和灰度变化等细节。为了提升模型对多尺度缺陷目标的特征提取能力,并降低背景噪声的干扰,本文引入AAM,并将其嵌入到SPPF^[19]下一层,其结构如图3(a)所示,其中SA为空间注意力机制。




图3 网络结构图。(a) AAM; (b)自适应池化层; (c)SA; (d)卷积层

Fig. 3 Structure diagram of network. (a) AAM; (b) adaptive pooling layer; (c) SA; (d) Conv layer

将SPPF的输出 F 作为自适应池化层的输入,以生成不同尺度的上下文特征。自适应池化层包含两个平均池化层(AvgPool)和一个最大池化层(MaxPool),其结构如图3(b)所示。通过平均池化操作,将输入特征下采样至更小的尺寸,此举有助于模型专注于缺陷的整体特征。同时,为了突出缺陷的关键特征,采用最大池化操作将输入特征下采样到一个适度的尺寸。经过细致调整和实验验证,最终确定平均池化系数为0.1,最大池化系数为0.64^[20]。

与最邻近插值法、双三次插值法相比,双线性插值法既考虑了相邻像素点的影响,又保持了相对较少的计算量和较低的复杂度。此外,为了与颈部上采样模式保持一致,利用双线性插值操作将三种不同尺度的特征图上采样至最初的输入尺寸,以获得连续且精细的特征。这一操作能够确保模型在不同尺度上都能提取到有效的特征信息。将三个分支提取的特征沿通道

拼接,不仅可以保留丰富的上下文信息,还能凸显关键缺陷特征。此外,不同分支特征的拼接能够充分利用计算资源,实现在相同计算量下提取到更丰富的特征。拼接特征计算为

$$F_{cat} = \text{Cat}\left\{\text{Up}\left[\text{AvgPool}\left(F\right), \text{AvgPool}\left(F\right), \text{MaxPool}\left(F\right)\right]\right\}, \quad (4)$$

式中:Up($\cdot$)为上采样操作;Cat($\cdot$)为沿通道拼接操作; F_{cat} 为拼接特征。

将拼接后的特征 F_{cat} 输入空间注意机制(SA)^[21], SA结构如图3(c)所示。SA对输入特征进行平均池化操作和最大池化操作,并将输出结果进行拼接,拼接后的结果经过 7×7 的卷积操作,通过Sigmoid函数生成空间注意权重,并将生成权重应用于 F_{cat} 。其过程为

$$M_S(\mathbf{F}_{cat}) =$$

$$\sigma\left\{f^{7 \times 7}\left\{\left[\text{AvgPool}\left(\mathbf{F}_{cat}\right); \text{MaxPool}\left(\mathbf{F}_{cat}\right)\right]\right\}\right\}, \quad (5)$$

式中: $M_S(\mathbf{F}_{cat})$ 为 SA 的输出; $f^{7 \times 7}(\cdot)$ 为卷积核大小为 7×7 的卷积; $\sigma(\cdot)$ 为 Sigmoid 函数。

考虑到 3 个 3×3 的卷积感受野与 1 个 7×7 的感受野具有相同的覆盖范围,但是前者的参数量小于后者^[22],本文利用卷积层(Conv layer)替换 SA 中的 7×7 卷积操作以减少 AAM 的参数量并增大特征提取的感受野。卷积层由 3 个 3×3 的卷积串联组成,其中第 3 个卷积使用了空洞卷积以增大模型的感受野,卷积层结构如图 3(d)所示。

对 SA 的输出进行 BN 处理,以加速网络收敛。将 BN 处理后的特征沿通道拆分成特征 1、2、3。这些特征与 SPPF 的输出依次相加,得到最终的输出特征图。通过这一系列操作,模型能够在不同尺度上有效地提取和融合缺陷特征,从而提高检测精度和鲁棒性。

2.3 优化损失函数

YOLO v5s 7.0 版本采用 CIoU 损失函数量化预测框与真实框之间的误差。在 CIoU 中引入惩罚参数,用来评估预测框与真实框之间宽高的一致性。然而,当预测框与真实框的宽高比成线性关系时,惩罚参数会失效,可能会降低模型的定位精度并影响对缺陷特征的准确识别。

为了解决这一问题,采用 EIoU 损失函数替代 CIoU 损失函数。EIoU 通过分解惩罚参数的宽高比,分别计算预测框与真实框在宽度和高度上的损失。这种方法可以确保在真实框与预测框的宽高比变化的情况下进行有效的误差量化,从而避免 CIoU 损失函数中惩罚参数失效的问题。EIoU 损失函数的表达式为

$$L_{EIoU} = 1 - L_{IoU} + \frac{\rho^2(b, b_g)}{c_b^2} + \frac{\rho^2(w, w_g)}{c_w^2} + \frac{\rho^2(h, h_g)}{c_h^2}, \quad (6)$$

式中: L_{IoU} 为 IoU 损失; $\rho^2(b, b_g)/c_b^2$ 为真实框与预测框中心点的欧氏距离; $\rho^2(w, w_g)/c_w^2$ 为真实框与预测框宽度的欧氏距离; $\rho^2(h, h_g)/c_h^2$ 为真实框与预测框高度的欧氏距离。

3 实验设置与结果分析

本文研究采用 TO56 型同轴封装金属底座缺陷数据集(ILS-MB)^[17,23]。该数据集覆盖了白斑(baiban)、缺损(quesun)、银不均(yinbujun)、沾银(zhanyin)、锈迹(xiuji)和划痕(huahen) 6 种缺陷类型,共包含 1500 幅图像,以 8:1:1 的数量比将其划分为训练集、验证集和测试集。

实验基于 Windows10 操作系统,采用 Nvidia GeForce RTX3060Ti GPU 进行加速计算。编写语言为 Python3.8,深度学习框架为 PyTorch 1.13.1,计算统一设备体系结构(CUDA)版本为 11.7。在训练过

程中,网络输入图像尺寸为 $640 \text{ pixel} \times 640 \text{ pixel}$,不使用预训练权重。学习率设置为 0.001,并采用 AdamW 优化器进行参数更新。批量大小设定为 16,训练总轮次为 300 轮。

为了全面评估 Metal-YOLO 模型的检测效果,实验采用精确度(P)、召回率(R)和平均精度均值(mAP_{50})等评价指标:

$$P = \frac{n_{TP}}{n_{TP} + n_{FP}}, \quad (7)$$

$$R = \frac{n_{TP}}{n_{TP} + n_{FN}}, \quad (8)$$

$$m_{mAP_{50}} = \frac{\sum_{i=1}^n \int_0^1 P(R) dR}{n}, \quad (9)$$

式中: $m_{mAP_{50}}$ 为所有类别的精确度在召回率上的积分的均值; n 为类别个数; n_{TP} 为被正确预测为正样本的个数; n_{FP} 为被错误预测为正样本的个数; n_{FN} 为被错误预测为负样本的个数。

为了更全面地衡量模型的性能,还额外引入了 F1 值作为评价指标。F1 值是精确度和召回率的调和平均数,能够综合反映模型在精确度和召回率两方面的表现。其计算为

$$F_{F1} = \frac{2PR}{P + R}. \quad (10)$$

3.1 AAM 对比试验

为了验证嵌入 AAM 可有效提升模型检测效果以及 AAM 对卷积层的影响,在基准模型 YOLO v5s 7.0 版本的 SPPF 后引入 AAM,并在 ILS-MB 数据集基础上进行消融实验,结果如表 1 所示。实验结果表明,在模型参数量(parameter)和运算量(FLOPs)保持不变的情况下,引入 AAM 后, mAP_{50} 提升了 2.7 百分点。这一改进显著提升了模型检测精度。此外,利用卷积层替换 7×7 卷积操作在参数更少的情况下展现了更高的平均识别精度。相较于采用 7×7 卷积操作的 AAM(7×7),采用卷积层替代的 AAM 在平均识别精度上提升了 1.3 百分点。表明利用卷积层替换 7×7 卷积操作可有效减少模型参数量、增大感受野,有助于提升模型的检测效果。

表 1 AAM 消融实验结果
Table 1 Ablation experimental results of AAM

Method	$m_{mAP_{50}}/\%$	FLOPs/G	Parameter/M
YOLO v5s	74.2	15.8	14.5
YOLO v5s + AAM(7×7)	75.6	15.8	14.6
YOLO v5s + AAM	76.9	15.8	14.5

为了进一步验证 AAM 对多尺度缺陷目标的检测性能,采用相同的方法将不同的注意力机制嵌入到 YOLO v5s 中进行训练和测试。对比分析表 2 实验结

表 2 不同注意力机制实验结果比较

Table 2 Comparison of results for different attention mechanisms

Method	$m_{\text{mAP}_{50}} / \%$	FLOPs /G	Parameter /M
YOLO v5s+AAM	76.9	15.8	14.5
YOLO v5s+SE	73.0	15.8	14.5
YOLO v5s+ECA	74.9	15.8	14.5
YOLO v5s+CBAM	75.3	15.8	14.5
YOLO v5s+CA	75.5	15.9	14.5
YOLO v5s+GAM	75.6	17.2	17.9
YOLO v5s+EMA	73.9	15.8	14.5
YOLO v5s+SimAM	74.8	15.8	14.5
YOLO v5s+TripletA	75.1	15.9	14.5

果,发现与轻量级注意力机制相比,嵌入AAM的模型的 $m\text{AP}_{50}$ 相对于嵌入 SE、ECA、CBAM、EMA、SimAM 提高了 3.9 百分点、2.0 百分点、1.6 百分点、3.0 百分点、2.1 百分点。而与有参注意力机制相比,嵌入 AAM 的模型的 $m\text{AP}_{50}$ 相对于 CA、GAM、TripletA 提高了 1.4 百分点、1.3 百分点、1.8 百分点。因此,提出的 AAM 可有效检测金属表面多尺度缺陷特征。

为了评估 AAM 在不同模型上的适应性,将 AAM 分别嵌入 YOLO v3tiny、YOLO v5n、YOLO v5m、

YOLO v5l 和 YOLO v7tiny 的主干网络末端,结果如表 3 所示。以上模型引入 AAM 后, $m\text{AP}_{50}$ 分别提高了 1.1 百分点、0.3 百分点、1.2 百分点、1.3 百分点和 2.3 百分点,表明 AAM 能够有效增强模型的检测精度。

表 3 不同模型引入 AAM 后的检测结果

Table 3 Detection results of different models after adding AAM

Method	$m_{\text{mAP}_{50}} / \%$
YOLO v3tiny	72.2
YOLO v3tiny+AAM	73.3
YOLO v5n	70.8
YOLO v5n+AAM	71.1
YOLO v5m	74.2
YOLO v5m+AAM	75.4
YOLO v5l	73.8
YOLO v5l+AAM	75.1
YOLO v7tiny	53.9
YOLO v7tiny+AAM	56.2

3.2 改进点消融实验

为了验证 CFEC、AAM 和 EIou 的改进效果,设计了消融实验来详尽评估每种方法的性能,实验结果见表 4,其中“√”表明应用相应模块。实验以 YOLO v5s 为基准模型,并在 ILS-MB 数据集上进行。

表 4 Metal-YOLO 模型消融实验结果

Table 4 Ablation experiment results of Metal-YOLO

YOLOv5s	CFEC	AAM	EIoU	$P / \%$	$R / \%$	$F_{\text{F1}} / \%$	$m_{\text{mAP}_{50}} / \%$	Frame rate / (frame · s ⁻¹)
√				83.3	69.1	75.5	74.2	37
√	√			84.3	72.1	77.7	75.9	39
√		√		84.3	73.1	78.3	76.9	37
√			√	82.1	72.9	77.2	76.4	40
√	√	√	√	83.9	74.1	78.7	78.3	34

由表 4 可知,添加 CFEC 后,模型的 F1 值和 $m\text{AP}_{50}$ 分别增加了 2.2 百分点和 1.7 百分点,表明模型提升了对缺陷的识别能力,证明了 CFEC 策略在缓解网络深度引起的小目标缺陷信息弥散方面的有效性。添加 AAM 后,模型的 F1 值和 $m\text{AP}_{50}$ 分别增加了 2.8 百分点和 2.7 百分点,进一步说明 AAM 能够全局聚焦不同尺度的缺陷目标,抑制背景噪声的干扰,提高了网络对不同尺度缺陷的辨别能力。使用 EIou 损失函数后,模型的精确度略有下降,但 F1 值和 $m\text{AP}_{50}$ 分别增加了 1.7 百分点和 2.2 百分点,召回率增加了 3.8 百分点,表明用 EIou 损失函数分别计算真实框与预测框的宽和高的策略是有效的,并且能够提升缺陷回归的精度,降低了漏检率。应用全部模块的结果表明,提出的 Metal-YOLO 模型在 F1 值和 $m\text{AP}_{50}$ 上分别达到了 78.7% 和 78.3%,相较于基准模型 YOLO v5s,分别增加了 3.2 百分点和 4.1 百分点。虽然 Metal-YOLO 在帧率上下降了 3 frame/s,但仍然能满

足实际的检测需求。此外,Metal-YOLO 模型的召回率相比于基准模型增加了 5.0 百分点,表明该方法能够检测出不明显缺陷,显著缓解了金属表面缺陷检测漏检率高的问题。图 4 展示了 Metal-YOLO 与 YOLO v5s 的检测效果对比。可以看出,Metal-YOLO 具有更高的检测精度,并且能够识别 YOLO v5s 未能检测到的金属表面缺陷,从而有效缓解误检和漏检问题。

3.3 主流目标检测模型性能对比

为深入剖析 Metal-YOLO 的检测性能,在 ILS-MB 数据集上使用目前主流目标检测模型进行训练和测试。模型包括 Faster-RCNN 双阶段算法、SSD、RetinaNet、YOLO v3~v5、YOLO v7tiny 和 YOLOX 单阶段算法。具体实验结果见表 5,其中括号内容为模型的主干网络。

由表 5 可知,Metal-YOLO 在 ILS-MB 数据集上对各类别缺陷的检测精度明显优于现有的主流算法,

mAP₅₀达到了78.3%。与YOLO v5s相比,在尺度跨距相差2857倍的锈迹类别上,Metal-YOLO的精度提升幅度达到7.6个百分点,展现了所提算法在处理不同尺度缺陷时的优越性能。模型在检测白斑、缺损和划痕缺陷时识别率较低的原因可能多个:首先,白斑类内的颜色特征存在较大的差异性,使得模型较难区分不同白斑;其次,在反光条件下,浅层缺损与白斑的特征相似度较高,容易造成模型的误判;此外,划痕因其呈乱向分布且长宽比较大,在真实框中往往伴随着较多的背景噪声,增加了模型准确识别的难度,从而导致划痕缺陷的识别精度较低。总体而言,所提出的Metal-YOLO模型能较为有效地检测同轴封装金属底座缺陷。

4 结 论

提出了一种基于改进YOLO v5s模型的同轴封装金属底座缺陷检测模型,通过引入CFEC有效缓解了小目标缺陷漏检问题,显著增强了模型对小目标信息的提取与识别能力。同时,嵌入AAM进一步增强了模型对多尺度缺陷的特征提取能力,使其能够检测不同尺寸和形态的缺陷。此外,采用EIoU损失函数替换CIoU损失,不仅加速了模型的收敛速度,还显著提升了缺陷的检测精度。在ILS-MB数据集上的详尽对比实验和消融实验结果表明,相较于基准YOLO v5s模型,Metal-YOLO的召回率提升了5.0个百分点,F1提升了3.2个百分点,mAP₅₀提升了4.1个百分点。与其他主流算法相比,Metal-YOLO的整体性能也更加具有优势。综上所述,提出的Metal-YOLO检测模型能够有效提高同轴封装金属底座缺陷的检测性能,显著减少误检和漏检,为实际应用中的缺陷检测提供了更为准确和可靠的解决方案。

参 考 文 献

- [1] 曹义亲,周一纬,徐露.基于E-YOLOX的实时金属表面缺陷检测算法[J].图学学报,2023,44(4):677-690.
Cao Y Q, Zhou Y W, Xu L. A real-time metallic surface defect detection algorithm based on E-YOLOX[J]. Journal of Graphics, 2023, 44(4): 677-690.
- [2] 吴忍,孙渊.基于深度学习的风机塔筒焊缝外部缺陷检测[J].上海电机学院学报,2021,24(3):169-174.
Wu R, Sun Y. External defect detection of welding seam of wind turbine tower based on deep learning[J]. Journal of Shanghai Dianji University, 2021, 24(3): 169-174.
- [3] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the 2014 IEEE Conference on Computer Vision and Pattern Recognition, June 23-28, 2014, Columbus, OH, USA. New York: IEEE Press, 2014: 580-587.
- [4] Ren S Q, He K M, Girshick R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.
- [5] Redmon J, Divvala S, Girshick R, et al. You only look once: unified, real-time object detection[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), June 27-30, 2016, Las Vegas, NV, USA. New York: IEEE Press, 2016: 779-788.
- [6] Liu W, Anguelov D, Erhan D, et al. SSD: single shot MultiBox detector[M]//Leibe B, Matas J, Sebe N, et al. Computer vision-ECCV 2016. Lecture notes in computer science. Cham: Springer, 2016, 9905: 21-37.
- [7] 程婧怡,段先华,朱伟.改进YOLOv3的金属表面缺陷检测研究[J].计算机工程与应用,2021,57(19):252-258.
Cheng J Y, Duan X H, Zhu W. Research on metal surface defect detection by improved YOLOv3[J]. Computer Engineering and Applications, 2021, 57(19): 252-258.
- [8] 吴磊,储钰昆,杨洪刚,等.面向铝合金焊缝DR图像缺陷的Sim-YOLOv8目标检测模型[J].中国激光,2024,51(16):1602103.
Wu L, Chu Y K, Yang H G, et al. Sim-YOLOv8 object detection model for DR image defects in aluminum alloy welds[J]. Chinese Journal of Lasers, 2024, 51(16): 1602103.
- [9] 凌强,刘宇,王春举,等.DN-YOLOv5的金属双极板表面缺陷检测算法[J].哈尔滨工业大学学报,2023,55(12):104-112.
Ling Q, Liu Y, Wang C J, et al. DN-YOLOv5 algorithm for detecting surface defects of metal bipolar plates[J]. Journal of Harbin Institute of Technology, 2023, 55(12): 104-112.
- [10] 曾耀,高法钦.基于改进YOLOv5的电子元件表面缺陷检测算法[J].浙江大学学报(工学版),2023,57(3):455-465.
Zeng Y, Gao F Q. Surface defect detection algorithm of electronic components based on improved YOLOv5[J]. Journal of Zhejiang University (Engineering Science), 2023, 57(3): 455-465.
- [11] Tan M X, Pang R M, Le Q V. EfficientDet: scalable and efficient object detection[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), June 13-19, 2019, Seattle, WA, USA. New York: IEEE Press, 2020: 10778-10787.
- [12] 程松,杨洪刚,徐学谦,等.基于YOLOv5的改进轻量型X射线铝合金焊缝缺陷检测算法[J].中国激光,2022,49(21):2104005.
Cheng S, Yang H G, Xu X Q, et al. Improved lightweight X-ray aluminum alloy weld defects detection algorithm based on YOLOv5[J]. Chinese Journal of Lasers, 2022, 49(21): 2104005.
- [13] 刘兰,叶芸,郭太良.基于拓展型特征金字塔的OLED像素缺陷检测方法[J].光学学报,2023,43(2):0212005.
Liu L, Ye Y, Guo T L. Detection method for OLED pixel defects based on extended feature pyramid[J]. Acta Optica Sinica, 2023, 43(2): 0212005.
- [14] 郝柏桥,范玉刚,宋执环.基于深度迁移学习的脉冲涡流热成像裂纹缺陷检测[J].光学学报,2023,43(4):

0415002.

Hao B Q, Fan Y G, Song Z H. Deep transfer learning-based pulsed eddy current thermography for crack defect detection[J]. *Acta Optica Sinica*, 2023, 43(4): 0415002.

[15] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), July 21-26, 2017, Honolulu, HI, USA. New York: IEEE Press, 2017: 936-944.

[16] Liu S, Qi L, Qin H F, et al. Path aggregation network for instance segmentation[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, June 18-23, 2018, Salt Lake City, UT, USA. New York: IEEE Press, 2018: 8759-8768.

[17] Zhu X F, Liu J Y, Zhou X Y, et al. Enhanced feature Fusion structure of YOLO v5 for detecting small defects on metal surfaces[J]. *International Journal of Machine Learning and Cybernetics*, 2023, 14(6): 2041-2051.

[18] Quan Y, Zhang D, Zhang L Y, et al. Centralized feature pyramid for object detection[J]. *IEEE Transactions on Image Processing*, 2023, 32: 4341-4354.

[19] He K M, Zhang X Y, Ren S Q, et al. Spatial pyramid pooling in deep convolutional networks for visual

recognition[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2015, 37(9): 1904-1916.

[20] Wang J F, Chen Y, Dong Z K, et al. Improved YOLOv5 network for real-time multi-scale traffic sign detection[J]. *Neural Computing and Applications*, 2023, 35(10): 7853-7865.

[21] Zhu X Z, Cheng D Z, Zhang Z, et al. An empirical study of spatial attention mechanisms in deep networks[C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV), October 27-November 2, 2019, Seoul, Republic of Korea. New York: IEEE Press, 2019: 6687-6696.

[22] 乔健, 陈能达, 伍雁雄, 等. 融合注意力机制的金属锅圆柱表面缺陷检测[J]. *光学精密工程*, 2023, 31(3): 404-416.

Qiao J, Chen N D, Wu Y X, et al. Defect detection of cylindrical surface of metal pot combining attention mechanism[J]. *Optics and Precision Engineering*, 2023, 31(3): 404-416.

[23] Liu J Y, Zhu X F, Zhou X Y, et al. Defect detection for metal base of TO-can packaged laser diode based on improved YOLO algorithm[J]. *Electronics*, 2022, 11(10): 1561.