

◎YOLOv8 改进及应用专题◎

面向工业场景带钢表面缺陷检测的 LF-YOLO

马肖瑶¹, 黎 睿¹, 李自力¹, 翟文正²

1. 华中科技大学 软件学院, 武汉 430074

2. 华中科技大学 机械学院, 武汉 430074

摘 要: 针对工业场景下带钢表面缺陷尺寸大小不一、采集图像模糊导致传统缺陷检测算法在实际应用中精度低的问题, 提出一种面向工业场景带钢表面缺陷检测的 LF-YOLO 算法。模型通过设计一种局部填充上采样模块对输入像素进行上采样, 提高模型对模糊图片的识别能力, 降低模型对小目标缺陷的漏检率。通过引入专注视觉任务的 FReLU 激活函数, 提高模型定位缺陷的准确率。提出一种轻量级的漏斗注意力机制并与特征提取模块 C2f 进行结合, 增强模型对不同尺寸缺陷的特征提取能力。在开源数据集 NEU-DET 与 GC10-DET 上的实验结果表明, 改进后的模型平均检测精度比原始 YOLOv8 算法精度分别高 7.0 和 15.4 个百分点, 且相较于其他目标缺陷检测模型在平均检测精度方面具有优势, 并进一步通过消融实验验证了每个模块的有效性。

关键词: 带钢表面缺陷检测; 深度学习; 上采样; 注意力机制; 激活函数

文献标志码: A **中图分类号:** TP391.4 **doi:** 10.3778/j.issn.1002-8331.2404-0411

LF-YOLO for Strip Surface Defect Detection in Industrial Scenes

MA Xiaoyao¹, LI Rui¹, LI Zili¹, ZHAI Wenzheng²

1. School of Software Engineering, Huazhong University of Science and Technology, Wuhan 430074, China

2. School of Mechanical Engineering, Huazhong University of Science and Technology, Wuhan 430074, China

Abstract: Aiming at the problem of low accuracy of traditional defect detection algorithms in practical applications due to the small size of strip surface defects and blurry collected images in industrial scenarios, an LF-YOLO algorithm for strip surface defect detection in industrial scenarios is proposed. The model upsamples the input pixels by designing a local filling upsampling module to improve the recognition ability of blurred images, and reduce the missed detection rate of small target defects. The FReLU activation function that focuses on visual tasks is introduced to improve the accuracy of model location defects. In addition, a lightweight local attention mechanism is proposed and combined with the feature extraction module C2f to enhance the feature extraction capability of defects of different sizes during the feature extraction process of the model. Experimental results on the Northeastern University open source strip steel dataset NEU-DET and GC10-DET show that the average detection accuracy of the improved model is 7.0 and 15.4 percentage points higher than the accuracy of the original YOLOv8 algorithm, and is better than other classic target detection models. It has advantages in average detection accuracy, and the validity of each module is further verified through ablation experiments.

Key words: strip surface defect detection; deep learning; upsampling; attention mechanism; activation function

随着现代工业的发展,带钢作为工业产品之一早已用于各行各业,是诸多大型器械不可或缺的一部分。而在其生产过程中,表面质量的控制对产品最终成型性能至关重要。因此有必要在其生产过程中进行表面缺陷检测。

不同于早期表面缺陷检测依赖于手工筛查,基于机器学习的缺陷检测将特征提取部分改为自动化实现,在效率上获得了巨大提升。但在实际工业场景中,仍面临需要人工设计特征提取规则且在处理高维度复杂数据时效果不佳等问题^[1]。深度学习技术的快速发展,将表

基金项目: 湖北省科技创新人才计划(2023DJC053)。

作者简介: 马肖瑶(1999—),男,硕士研究生,CCF 会员,研究方向为深度学习、目标检测;李自力(1965—),通信作者,男,博士,教授,研究方向为计算机图形学与虚拟现实, E-mail: lizili_hust@hust.edu.cn。

收稿日期: 2024-04-26 **修回日期:** 2024-06-25 **文章编号:** 1002-8331(2024)18-0078-10

面缺陷检测引入新的阶段。

目前目标检测神经网络可分为单阶段网络和双阶段网络。双阶段网络的检测过程由两个阶段组成,第一阶段用于推理目标物体可能存在的位置,得出建议框,第二阶段则将建议框进行分类。双阶段网络代表模型为RCNN^[2]、Fast-RCNN^[3]、Faster-RCNN^[4]等。单阶段网络则直接产生待检测目标的位置和分类结果,没有产生建议框的过程。单阶段网络代表模型为SSD^[5]、YOLO^[6]系列。与双阶段检测网络相比,单阶段网络虽精度略有下降,但推理速度更快,更符合工业场景下的实际需求。因此后续研究更多是对单阶段网络进行改进。

文献[7]通过将深度可分离卷积与YOLO结合,大大降低模型的参数量,构建出轻量化模型,使其满足工业缺陷检测的实时需要。文献[8]采用了双特征金字塔网络用于聚合不同尺度的特征并融合特征图,对带钢表面进行不同尺度缺陷的检测。文献[9]在YOLOv7骨干部分结合ECA(efficient channel attention)注意力机制,强化重要特征通道,使小目标的带钢缺陷检测更准确。文献[10]中对YOLOv3算法填充密集残差块,显著提高带钢缺陷检测正确率。文献[11]在骨干网络中使用ShuffleNetv2作为特征提取网络来减少参数的数量,并且设计轻量级特征金字塔网络,进一步提高了YOLO框架的性能。文献[12]通过对YOLOv8损失函数进行优化,在不增加参数量的同时获得了2.7个百分点的提高。文献[13]通过在YOLO中添加ECA注意力提高了缺陷检测的精准率。文献[14]通过设计一种多尺度卷积模块与YOLOv8的特征提取模块C2f进行结合,将不同尺度缺陷进行融合。文献[15]通过设计全新的注意力机制,加强了网络的特征提取能力。文献[16]通过将网络主干替换为轻量级的VanillaNet,在保证模型精度的前提下降低模型所需计算量和参数量。文献[17]通过设计多尺度特征提取网络,使模型在低分辨率图像检测中表现优异。为进一步提高缺陷检测的精准率,本文采用YOLOv8算法的m版本,并在此基础上进行改进。本文主要贡献如下:

(1)针对工业带钢生产环境恶劣导致采集图像模糊且缺陷尺寸偏小使得网络推理效果不佳的问题,通过设计局部填充上采样模块对输入像素进行上采样,以较低的计算代价增强模型对小目标缺陷的识别能力。

(2)针对SiLU一维激活函数对2D空间信息建模能力不足导致缺陷定位欠佳的问题,将专注视觉任务的FReLU激活函数引入YOLO模型中,使普通卷积具备空间建模能力,提高算法定位缺陷的精度。

(3)针对图像中缺陷尺寸大小不一的问题,通过设计一种轻量级漏斗注意力模块,嵌入特征提取模块C2f中,使模型在训练过程中基于提取的特征重点关注可能

存在缺陷的高频信息区域,提高模型对多尺度缺陷的检测能力。

1 相关工作

1.1 网络结构

YOLO系列版本迭代十分迅速,其中v5版本广为应用,算法改进相关研究已经较为成熟,但v8版本改进尚待大量研究。YOLOv8网络结构按照功能可划分为:Backbone主干层,用于对特征进行提取;Neck特征融合层,用于将提取到的不同维度的特征进行融合;Head预测层,通过Neck层输入的特征对目标进行位置预测和分类。

YOLOv8仍采用YOLOv5的Backbone主干层结构,但将YOLOv5中的C3模块替换成了梯度流更丰富的C2f模块。C2f模块相比较C3模块更加地轻量化,具有更强的特征融合能力,且推理速度进一步加快。Neck层仍由FPN(feature pyramid network)^[18]和PANet(path aggregation network)^[19]结构组成。FPN结构用于提取多尺度特征,而PANet结构在高维语义特征和低维空间特征之间增加新的上下通路,增强了高维和低维之间的特征信息融合。Head部分则首次借鉴YOLOx^[20]的解耦头思想,将分类和检测任务分离开来。YOLOv8继续选用SiLU^[21]作为模型激活函数。

1.2 上采样

高维特征图通过上采样操作放大尺寸以便与低维特征图结合,实现不同尺度间的特征融合,这种方法在目标检测领域应用十分广泛,但常用的上采样操作各自存在问题。

传统的上采样方法一般是基于插值操作对图像进行缩放,包括最近邻插值^[22]、双线性插值^[23]、双三次插值^[24]等方法。最近邻插值算法原理简单,直接基于像素本身进行坐标映射,将原图中的像素填入放大图的对应坐标点中,不需要通过计算得到放大图中的像素值,因此运算速度快。但通过此方法采样后的灰度值具有明显的不连续性,且在放大图上马赛克现象较严重,在保留小目标缺陷信息的同时无法避免背景噪声的影响。而工业场景下受生产环境影响,采集图像往往存在大量噪声,导致最近邻插值算法使用效果受到影响。双线性插值算法很大程度上消除了马赛克现象,但存在边缘模糊的问题。双三次插值是双线性插值的改进算法,和前两种经典插值方法相比,可以取得较好的插值效果,但近邻的16个点加权会损失插值图像的高频部分,导致上采样过程中小目标缺陷信息丢失。

不同于手工设计的插值方法,转置卷积^[25]利用卷积核进行上采样。卷积核可通过网络学习最适合的参数,大大提高上采样的效果。但过多的卷积核也大大增加

了模型计算的负担。CARAFE^[26]是一种通用轻量级上采样模块,不同于转置卷积使用固定大小的卷积核,CARAFE可以根据内容实时生成自适应的卷积核,且在计算量上也比转置卷积低。CARAFE基于输入图像自适应生成用于上采样的卷积核,而在工业环境下采集的图像往往存在大量的背景噪声,导致CARAFE模块的适用性受到限制。

1.3 激活函数

激活函数是神经网络具备学习能力的关键,非线性的设计使得其理论上能够拟合任意函数。最早使用的Sigmoid激活函数被用作二分类问题。但在数值趋近于0或1时,变化率会变得平坦,出现梯度消失的问题。ReLU^[27]激活函数是一种分段函数,它解决了梯度消失的问题,在目前的神经网络中被广泛使用。但由于其 $x < 0$ 条件的设计,使得当输入为负数时,梯度会完全消失,导致函数失效。为了解决输入小于0时ReLU失效的问题,LeakyReLU^[28]通过设置一个比例系数,不再简单地将 $x < 0$ 的部分摒弃。PreLU^[29]则是在LeakyReLU的思想进一步优化,将比例系数设置成可学习的超参数,使得效果更好。不同于之前的激活函数都聚焦于一维空间进行非线性变换,FReLU^[30]通过引入2D空间条件,将非线性变换扩展到二维空间上,使其专注于视觉任务,提高模型在目标检测中的表现。

1.4 注意力机制

深度学习中的注意力机制是一种模仿人类视觉和

认知系统的方法,它允许神经网络在处理输入数据时集中注意力于相关的部分。通过引入注意力机制,神经网络能够自动地学习并选择性地关注输入中的特征重要信息,提高模型的性能和泛化能力。SE注意力机制(squeeze-and-excitation networks)^[31]在通道维度增加注意力机制,从通道角度考虑图像中各像素的重要程度,得到更重要的信息,但在空间维度上欠缺考虑。Woo等^[32]提出CBAM(convolutional block attention module),通过空间和通道双重注意力机制兼顾通道和空间双重信息,但计算负担显著增加。Wang等^[33]提出ECA取消降维操作,通过一维卷积实现跨通道交互的信息,模型复杂度低,但是利用到的通道信息较少,在工业场景中的效果较差。自注意力机制^[34]通过设计 Q 、 K 、 V 查询矩阵,捕捉不同像素间的长距离依赖关系,在文本领域大放异彩,但计算量十分庞大,不太适用于资源有限、对实时性高要求的工业领域。

2 LF-YOLO 算法

2.1 YOLOv8改进

为了提升模型推理精度,通过对NEU-DET^[35]和GC10-DET^[36]工业数据集进行研究,本文提出了一个基于YOLOv8改进的LF-YOLO(local fill YOLO)算法模型,模型结构如图1所示。模型首先利用自行设计的局部填充上采样模块(local fill, LF)来替换v8原始网络中的最近邻插值模块,通过对输入像素进行上采样,提




图1 LF-YOLO网络结构

Fig.1 LF-YOLO network structure

高小目标缺陷信息在特征图中所占比重,降低网络对小目标的漏检率。其次,用二维激活函数 FReLU 代替 YOLOv8 网络中的一维激活函数 SiLU,让模型具备 2D 空间级建模能力,加强模型对缺陷的定位能力,提高算法检测精度。最后,C2f 模块是 YOLOv8 模型中对残差信息和特征进行提取的主要模块,通过设计一种漏斗注意力机制,将 C2f 模块改进为基于漏斗注意力的 FA-C2f (funnel attention C2f) 模块,进一步提升模型对高频空间信息的建模和提取能力,提高模型对多尺度缺陷的检测能力。

2.2 局部填充上采样模块

基于插值的上采样方法计算简单、速度快,但上采样过程仅基于像素本身内容,生成的特征图质量低,且成块状。基于卷积的上采样方法处理效果好,但全程使用卷积核大大增加了计算量,在硬件资源有限的工业设备中应用场景受限。为解决以上问题,本文提出一种局部填充(LF)上采样模块。

直接通过卷积上采样会带来巨大的计算量,因此模块先行设计一种局部插值(local interpolation)方法,利用插值将特征图上采样至高分辨率,再利用自校正卷积(self-calibrated convolutions)^[37]对上采样的特征图进行微调。

局部插值模块设计如图 2(a)所示。最近邻插值算法直接依据像素自身进行像素填充,上采样过程中对像素与周围像素的关系缺乏考虑,导致生成图有明显锯齿感。双三次插值通过对邻近的 4×4 像素作加权,避免了锯齿感,但过多的加权会导致像素本身信息的丢失。设计的局部插值模块通过对像素点四周顶角处进行采




图2 局部填充上采样模块

Fig.2 Local fill upsample module

样,以便对像素空间上下文信息进行考虑,避免了最近邻插值算法缺失周围信息导致的锯齿感问题。同时将像素自身与四角采样的像素均值进行比较,考虑像素相较于空间上下文的重要程度,并根据比较结果展开两种不同的上采样策略。

当像素点的值大于采样均值时,采用双三次插值对四周进行加权和操作会导致自身高频信息的部分丢失,导致小目标缺陷像素信息丢失的问题。本文设计将像素点与采样均值进行除法操作得出用于放大高频信息的权重值,并将权重值与像素点做点乘运算,保留高频信息的同时进一步扩大其影响力,然后将放大后的高频像素进行上采样。

若像素点值小于采样均值,此时采用最近邻插值算法直接基于像素本身进行扩充会导致不重要的信息被保留且放大。而双三次插值虽然通过加权的方式对其进行考虑,但对不重要信息仍有所保留,导致上采样的特征图中存在噪声问题。为解决该问题,本文用四角像素均值直接替代像素点进行上采样操作,对不重要的信息直接摒弃。

通过将最困难的上采样部分交给插值操作,大大降低了模块所需的计算量。再用自校正卷积对插值上采样的特征图进行微调。如图 3 所示,自校正卷积通过将卷积核均分成四个子核(Conv1、Conv2、Conv3、Conv4),在不增加额外参数和计算量,以及在不同的尺度下进行特征变换,加强网络对差异化特征的关注,相比于标准卷积,产生的特征图更具有区分度。不同的子核可以关注图像的不同频率成分,通过特定的组合策略提升对局部结构和整体布局的敏感度,可用于弥补插值操作带来的像素分布不均,在不同的抽象层次上增强特征的表达能力。




图3 自校正卷积模块

Fig.3 Self-calibrated module

2.3 FReLU 激活函数

最先提出的激活函数是 Sigmoid 函数,后续人们又陆续提出了诸如 ReLU、SiLU 函数等,但它们都是在一维空间上对数据进行处理。而与之相对,FReLU 是二维非线性激活函数,在略微增加计算负担的情况下,将一维的 ReLU 激活函数扩展成 2D 空间上的激活函数。如图 4 所示,FReLU 通过将 ReLU 函数中的 $x < 0$ 部分替换

成2D空间条件,解决了一维激活函数对空间信息不敏感的问题,使模型具备2D空间像素级建模能力,使模型更专注于视觉任务。




图4 激活函数示意图

Fig.4 Schematic diagram of activation function

ReLU激活函数通过将输入数据 x 与 0 比大小,将负值截断并摒弃,以此进行非线性变换。

$$y = \max(x, 0)$$

SiLU激活函数不同于ReLU激活函数对负值的直接摒弃,在接近0时具有更加平滑的曲线。

$$y = \frac{x}{1 + e^{-x}}$$

FReLU保留了ReLU的max函数用作非线性变换,但不同于ReLU的0条件和SiLU的Sigmoid等一维条件,FReLU将条件扩展到2D空间上,通过引入 $T(x)$ 函数,对每个像素2D空间上下文进行卷积,得到基于空间的截断条件。

$$y = \max(x, T(x))$$

$$T(x_{c,i,j}) = x_{c,i,j}^w \cdot p_c^w$$

式中, x 为通道 c 上 (i,j) 处的输入像素; w 是参数池窗口, p 表示通道层 c 中窗口 w 上的系数, $(\cdot)$ 为点乘操作。

2.4 基于漏斗注意力的FA-C2f模块

C3模块是YOLOv5模型中对残差特征进行学习的主要模块,其主要作用是提高网络的特征提取能力。YOLOv8将YOLOv5的C3结构换成了梯度流更丰富的C2f结构。为了加强模型对多尺度缺陷的特征提取能力,本文设计一种轻量化的漏斗注意力机制(funnel attention, FA)并将该注意力与C2f模块进行结合以加强网络对不同尺寸缺陷的提取能力。

通道平均化模块(channel mean)用于计算所有通道的像素平均值。该模块可以在考虑不同通道之间联系的同时保留全局信息并加速注意力的收敛速度,使得模型快速收敛,同时使得后续模块的计算量大大降低。计算公式如下:

$$F_{avg}(x_{i,j,n}) = \frac{\sum_{n=1}^c x_{i,j,n}}{c}$$

式中, (i,j) 为图片中像素位置,大小不超过图片宽高 (w,h) , c 为通道总数, n 为具体通道数。

局部对比模块(local contrasts)用于筛选出像素及其周围区域中的高频信息。具体操作为将输入像素与

其周围 w 参数池范围内卷积提取的亚像素平均值做max操作,综合考虑像素与其周围区域强弱关系。该操作有利于捕捉小目标缺陷特征的局部极值,且相较于自注意力机制,将计算区域从全局改进为像素周围,大幅减低模块所需计算量。过程如下所示, $Avg(x)$ 函数用于计算参数池范围内卷积提取的亚像素平均值。

$$f(x_{c,i,j}) = \max(x_{c,i,j}, Avg(x_{c,i,j}))$$

整体计算过程如图5所示。首先计算输入像素 x_{in} 的通道平均值,表示保留全局信息的权重值,记为 x_1 。再通过局部对比模块计算 x_{in} 的局部极值,并将其进行通道平均值的计算,表示考虑像素周围极值信息的权重,记为 x_2 。将考虑全局信息的 x_1 与考虑局部信息的 x_2 进行add操作,用以综合考虑不同尺度特征的信息,再与 x_{in} 进行点乘。利用add操作产生的多尺度权重信息,加强模型对多尺度缺陷中高频信息的关注度,并最终得到输出的特征图。




图5 漏斗注意力模块结构图

Fig.5 Structure of funnel attention module

通过基于像素二维空间上下文进行局部权重的计算,将C2f模块改进为FA-C2f模块。模块整体结构如图6所示,C2f模块使用 1×1 卷积对输入特征的通道进行升降维,再用Split操作对输入特征进行通道拆分,将通道数为 C 的特征图拆分成 $C/2$ 的两部分,一部分通过多个瓶颈层块以便增大感受野,另一部分则形成残差通路保留原始信息,与瓶颈层提取的特征图进行结合,在减




图6 FA-C2f模块结构图

Fig.6 Structure of FA-C2f module

少参数量的同时得到更丰富的梯度流信息。Split操作对输入像素通道进行切分,降低模块计算量的同时也导致通道间联系的减弱。模块FA-C2f通过将切分部分输入漏斗注意力模块,紧密通道间联系的同时加强了对不同尺寸缺陷信息的关注度。

3 数据集实验与结果分析

3.1 数据集描述

采用东北大学开源的带钢表面缺陷数据集 NEU-DET 和真实工业中收集的表面缺陷数据集 GC10-DET 进行研究。NEU-DET 数据集由划痕(scratches, Sc)、裂纹(crazing, Cr)、麻点(pitted surface, Ps)、夹杂(in-clusion, In)、斑块(patches, Pa)、压入氧化铁皮(rolled-in scale, Rs)六类缺陷组成。数据集总共包含 1 800 张图像,每类缺陷数量为 300 张图像,每张图像大小为 200×200。

GC10-DET 数据集由冲孔、焊缝、新月形缝隙、水斑、油斑、丝斑、夹杂物、轧坑、折痕、腰部折痕十种类型表面缺陷构成。数据集包括 3 570 张灰度图像。两个数据集均按 8:1:1 的比例随机生成训练集、验证集和测试集进行训练。

3.2 模型评价指标

二维目标检测领域常用交并比(intersection over union, IoU)表示预测区域和真实标签之间的相关度,值越高则代表预测与真实的相关度越高,一般以 0.5 作为预测成功与否的分界。而精确率(precision)和召回率(recall)则是用于评估模型性能的重要指标。二者计算公式如下所示:

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

式中,TP(true positive)为正例且模型被预测为正例,FP(false positive)为误判为正例的负例,FN(false negative)则表示被模型错误判定为负例的正例。平均精度(average precision, AP)定义为以 P 为纵坐标,R 为横坐标绘制的曲线与坐标轴围成的面积,可兼顾精确率和召回率。所有类别 AP 的均值则是 mAP,一般被用作模型性能最终评价指标。计算公式如下:

$$mAP = \frac{\sum_{i=1}^n AP_i}{n}$$

式中,AP_i为某一类缺陷的检测精度,类别数 n 在本文中大小为 6。

3.3 实验结果与分析

LF-YOLO 实验环境:pytorch 1.10、python3.11.5、Windows10 操作系统、NVIDIA RTX 3060 GPU。由于显存限制,使用 YOLOv8m.pt 文件作为预训练权重以加

快模型的收敛速度。训练总轮次设置为 300。批次大小设置为 16。初始学习率设置为 0.01,权重衰减大小设置为 0.000 5。使用 SGD 优化器。

3.3.1 局部填充上采样模块效果

将提出的 LF 模块与其他上采样模块分别嵌入到 YOLOv8 中。

对比图 7 和表 1 可知,图 7(d)最近邻插值算法和图 7(e)双三次插值算法虽然计算简单,模型计算量未出现明显增长,但均出现了小目标缺陷漏检的情况。且 mAP 指标均低于基于卷积核的模块,在工业场景下使用受限。转置卷积的上采样效果比最近邻插值高 1.7 个百分点,但对每个像素位置使用固定大小卷积核进行反卷积计算导致 YOLOv8 计算量从 79.1 增至 104.8,在硬件资源有限的工业环境下需占据更多的硬件资源。Carafe 轻量级模块将上采样过程分成预测上采样卷积核与基于卷积核进行特征重组的两阶段。在基于卷积核进行上采样的同时对卷积核大小进行基于输入特征图的动态调整,相较于转置卷积所需计算量减少 25.4,且 mAP 相较于最近邻插值高 1.5 个百分点。Carafe 模块基于输入图像生成上采样卷积核,而工业环境下采集的图像存在大量的背景噪声,且小目标缺陷在图像中占比较少,导致生成的上采样卷积核易被背景噪声干扰,使得对小目标缺陷进行上采样的效果受限。




图7 NEU-DET 数据集检测效果
Fig.7 Detection effect of NEU-DET dataset

表1 YOLOv8 添加各种上采样模块

Table 1 Various upsampling modules added in YOLOv8					
Method	mAP50/%	P/%	R/%	GFLOPs	FPS
Nearest	76.7	74.5	69.2	79.1	58
Bicubic	77.9	75.9	71.1	80.8	60
TransposeConv	78.4	74.3	73.8	104.8	51
Carafe	78.2	72.5	75.4	79.4	56
Ours	80.1	75.2	74.4	86.2	55

本文提出的局部上采样模块以较低的计算量增长代价(+7.1),取得了比其他模块更好的检测结果。采用

先插值上采样再卷积微调的思路使得本文所设计模块计算量大大低于全程使用固定大小卷积核的转置卷积。Carafe 模块因工业环境下采集的图像存在大量背景噪声而使用受限。本文通过设计两种不同的上采样策略,对背景噪声进行去除的同时对小目标缺陷信息所占比重进行扩充,并最后使用自校正卷积对上采样的特征图进行微调,使像素分布更加平滑。实验结果显示,本文算法与 Carafe 相近的计算量相比,取得了高于其 1.9 个百分点的效果。

3.3.2 注意力的可视化

对比不同尺寸缺陷的可视化效果,并对比分析加入各注意力之后计算量与参数量的变化。

由图 8(a)的测试图(Test)可知,在大尺寸缺陷检测方面,漏斗注意力的关注区域最为贴合实际尺寸大小,其他注意力机制均存在只关注部分区域的情况。而在图 8(b)小目标缺陷检测中,SE、ECA、CBAM 等注意力均出现了漏检的情况,自注意力机制虽然同时检测出所有的缺陷,但同时关注了其他区域,注意力发散较为严重。漏斗注意力关注区域则较为集中,且不存在漏检情




图8 不同尺寸缺陷的热力图

Fig.8 Heat maps of defects of different sizes

况。结合表 1 与表 2, SE、ECA、CBAM 等注意力计算负担增加较小,但对模型缺陷检测精度提升在 1.0 个百分点以内。自注意力机制的平均检测精度比 SE、ECA、CBAM 等轻量级注意力机制平均高 1.0 个百分点,但每个像素都对全局像素计算 Q 、 K 、 V 查询矩阵导致计算代价大量增加。本文设计的漏斗注意力机制通过计算局部关系,使得所需计算量为自注意力模块的一半。漏斗注意力机制相较于自注意力大幅提升了缺陷检测的召回率(+8.3 个百分点),表明模型多尺度缺陷的漏检率大大降低。通过对比热力图与 mAP50、计算量、参数量等,漏斗注意力机制显然更适合工业场景下的多尺寸带钢表面缺陷检测任务。

表2 各种注意力模块对比

Table 2 Comparison of various attention modules

注意力	mAP50/%	P/%	R/%	GFLOPs	Parameters/MB
SE	77.6	75.2	71.6	+0.3	+0.158
CBAM	77.2	73.3	74.6	+0.2	+1.268
ECA	77.3	77.0	69.2	+0	+0.012
自注意力	78.2	76.6	70.7	+1.5	+3.803
Ours	82.2	74.9	78.3	+0.7	+1.743

3.3.3 LF-YOLO 模型与其他算法对比

为了验证模型修改的有效性,将 LF-YOLO 模型与 YOLOv5、YOLOv7、YOLOv8 等在内的经典目标检测模型进行对比,并选取同一数据集下其他 YOLO 改进算法进行对比,且选取最新开源的 YOLOv9^[38] 先进模型作为对比。得到的结果统计成表 3 所示。

表3 NEU-DET 数据集实验结果

Table 3 Experimental results of NEU-DET dataset

模型	mAP/%	P/%	R/%	GFLOPs	FPS
YOLOv5m	74.8	71.2	69.0	48.0	72
YOLOv7	73.7	66.3	68.6	104.7	49
YOLOv8s	74.7	69.1	69.0	28.4	137
YOLOv8m	76.7	74.5	69.2	79.1	58
YOLOv8L	78.2	75.8	71.0	165.0	40
YOLOv9c	77.7	79.7	71.0	238.9	22
文献[12]	79.4	73.6	75.9	32.6	—
文献[13]	81.9	79.2	76.5	—	55
Ours	83.7	80.2	76.8	88.7	56

在平均检测精度方面,LF-YOLO 模型取得最好的结果 83.7%,且模型推理缺陷速度(FPS)为 56,满足工业场景下的实时性要求(至少为 30)。YOLOv5 通过特征金字塔网络和空间金字塔池化模块对多尺度特征进行提取和融合,使平均检测精度达到 74.8%。YOLOv7 通过控制最短和最长的梯度路径使网络学习更多的特征,但检测效果不佳。YOLOv8 通过将 YOLOv5 中的特征提取模块 C3 改进为梯度流更加丰富的 C2f 模块,获得了显著的效果提升(+1.9 个百分点),且随着不同版本计算量和参数量提升,平均检测精度也有较大提升。

YOLOv9是最新开源的YOLO模型,模型通过设计可编程梯度信息解决输入数据经过逐层特征提取和空间变换时出现大量信息丢失的问题,但目前只开放了较大的预训练权重版本,实验表明过低的FPS并不满足工业下实时性要求。文献[12]通过优化YOLOv8损失函数在不增加参数数量的同时获得2.7个百分点的提高,文献[13]通过添加ECA注意力提高了缺陷检测的平均精度,但总体提升均不如本文模型。

3.3.4 消融实验

为了验证各模块的有效性,设计消融实验对各模块进行分析。首先选取原始YOLOv8模型。从该模型开始,不断添加新的模块实验结果如表4所示。

表4 NEU-DET数据集消融实验结果
Table 4 Ablation results of NEU-DET dataset

A	B	C	mAP/%	P/%	R/%	GFLOPs
×	×	×	76.7	74.5	69.2	79.1
√	×	×	80.1	75.2	74.4	+7.1
×	√	×	77.6	74.4	70.2	+0.1
×	×	√	82.2	74.9	78.3	+0.7
√	√	×	78.3	76.4	68.9	+7.4
√	×	√	77.2	75.3	70.7	+9.4
×	√	√	80.4	75.1	77.5	+0.9
√	√	√	83.7	80.2	76.8	+9.6

分析表4可知,三个模块对检测精度均有提升作用。自行设计的上采样模块有效提高模型检测缺陷的精确率,降低了误判风险。FRReLU激活函数将召回率提高了1.0个百分点,且模型计算开销增加较少。FA-C2f模块对模型召回率提升较为显著(+9.1个百分点),证明所设计的模块可以有效地对空间特征添加自适应权重,更加关注高频信息,提高了模型对多尺度缺陷的检测能力,降低了缺陷的漏检率。在计算量方面,LF上采样模块对模型计算负担增加最大,其主要来自于插值上采样后由自校正卷积对特征图进行微调的阶段。在综合加入三个模块后,模型计算量增加了9.6,对硬件资源要求有所增加,但对比表3可知,FPS由58降低至56,仍满足工业场景下的实时性要求。

3.3.5 模型泛化性

为了验证模型的泛化性,将NEU-DET数据集更替为GC10-DET数据集,输入各模型中并统计结果,如表5。将算法检测结果进行对比可以发现,本文模型相较于YOLO各版本均有更优的表现。同行对比方面,文献[13]虽然比本模型精确率高0.2个百分点,但召回率大幅下降,表明文献模型存在较多的缺陷漏检情况,而过多的漏检缺陷将导致工业零件成形的质量降低。YOLOv8系列计算量随着版本大量增加,FPS由118降低至40,不适合工业场景下硬件资源有限的情况。

表5 GC10-DET数据集实验结果

Table 5 Experimental results of GC10-DET dataset

模型	mAP/%	P/%	R/%	GFLOPs	FPS
YOLOv5m	69.0	76.4	63.1	48.3	86
YOLOv7	64.2	69.3	57.8	105.0	52
YOLOv8s	65.6	29.9	61.6	28.5	118
YOLOv8m	67.0	60.6	65.3	78.9	60
YOLOv8L	68.6	81.0	55.5	165.0	40
YOLOv9c	69.8	68.9	65.6	238.9	34
文献[12]	69.4	64.8	62.6	32.6	—
文献[13]	80.2	82.1	70.3	—	105
Ours	82.4	81.9	76.1	88.5	64

由NEU-DET数据集的P-R曲线图(图9、图10)可知,本文模型在除裂纹外的其他缺陷类别识别中表现优异,但裂纹缺陷的平均检测精度只有54.1%,远远低于其他类别缺陷的检测效果。




图9 NEU-DET数据集P-R曲线图
Fig.9 P-R curve of NEU-DET dataset




图10 GC10-DET数据集P-R曲线图
Fig.10 P-R curve of GC10-DET dataset

由图 11 可以看出, NEU-DET 数据集中裂纹缺陷大多是暗光环境, 且裂纹与周围正常区域区别不明显。本文设计的 LF 上采样模块通过将缺陷像素与周围像素均值进行比较从而达到对小目标缺陷信息所占比重进行扩充的目的, 以便提高模型对小目标缺陷的检测率, 相关效果已在图 7 中验证。但在裂纹缺陷中, 暗光环境下缺陷像素值与周围正常区域像素值数值差异不大, 使得模块对不重要信息的判定受到干扰, 有效信息保存的完整性受到影响, 导致所设计的基于像素值比较结果进行上采样的 LF 模块效果受限, 使得模型的平均检测精度下降。




图 11 裂纹检测失败图

Fig.11 Crack detection failure diagram

4 结语

本文针对工业环境下带钢表面缺陷尺寸小且采集图像模糊导致模型推理精度低的问题, 基于 YOLO 提出 LF-YOLO 模型。通过设计一种局部上采样模块对输入像素进行上采样, 动态放大特征图中的缺陷信息, 提高模型对模糊图片的识别能力, 降低模型对小目标缺陷的漏检率。通过引入 FReLU 激活函数, 提升模型对 2D 空间信息的建模能力, 增强模型对缺陷的定位能力。在此基础上设计一种漏斗注意力机制并嵌入特征提取模块 C2f 中, 将 C2f 模块改进为基于漏斗注意力的特征提取模块 FA-C2f, 进一步优化模型对高频空间信息的感知效果, 提升模型多尺度缺陷的检测能力。在 NEU-DET 和 GC10-NET 数据集上的实验结果表明 LF-YOLO 模型可以高精度地推理出工业环境下带钢的表面缺陷, 且相较于其他经典检测算法 mAP 更高, 推理速度也符合工业实时性要求, 所设计模块对模型计算量和参数量的增加负担较小, 对工业环境下表面缺陷检测的研究具有参考价值。与此同时, 所设计模块在暗光环境下对裂纹缺陷检测效果欠佳, 文中虽给出相关分析但并未解决该问题, 因此针对该问题的后续改进尚待研究。

参考文献:

- [1] 卢俊哲, 张铨怡, 刘世鹏, 等. 面向复杂环境中带钢表面缺陷检测的轻量级 DCN-YOLO[J]. 计算机工程与应用, 2023, 59(15): 318-328.
- LU J Z, ZHANG C Y, LIU S P, et al. Lightweight DCN-YOLO for strip surface defect detection in complex environments[J]. Computer Engineering and Applications, 2023,

59(15): 318-328.

- [2] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2014: 580-587.
- [3] GIRSHICK R. Fast R-CNN[C]//Proceedings of the IEEE International Conference on Computer Vision, 2015: 1440-1448.
- [4] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[C]//Advances in Neural Information Processing Systems, 2015.
- [5] LIU W, ANGUELOV D, ERHAN D, et al. SSD: single shot multibox detector[C]//Proceedings of the 14th European Conference on Computer Vision (ECCV 2016), Amsterdam, The Netherlands, October 11-14, 2016.[S.l.]: Springer International Publishing, 2016: 21-37.
- [6] JIANG P, ERGU D, LIU F, et al. A review of Yolo algorithm developments[J]. Procedia Computer Science, 2022, 199: 1066-1073.
- [7] XIE Y, HU W, XIE S, et al. Surface defect detection algorithm based on feature-enhanced YOLO[J]. Cognitive Computation, 2023, 15(2): 565-579.
- [8] ZHAO C, SHU X, YAN X, et al. RDD-YOLO: a modified YOLO for detection of steel surface defects[J]. Measurement, 2023, 214: 112776.
- [9] WANG Y, WANG H, XIN Z. Efficient detection model of steel strip surface defects based on YOLO-V7[J]. IEEE Access, 2022, 10: 133936-133944.
- [10] KOU X, LIU S, CHENG K, et al. Development of a YOLO-V3 based model for detecting defects on steel strip surface[J]. Measurement, 2021, 182: 109454.
- [11] QIAN X, WANG X, YANG S, et al. LFF-YOLO: a YOLO algorithm with lightweight feature fusion network for multi-scale defect detection[J]. IEEE Access, 2022, 10: 130339-130349.
- [12] HUANG Y, TAN W, LI L, et al. WFRE-YOLOv8s: a new type of defect detector for steel surfaces[J]. Coatings, 2023, 13(12): 2011.
- [13] ZHANG J, WEI X, ZHANG L, et al. YOLO v7-ECA-PConv-NWD detects defective insulators on transmission lines[J]. Electronics, 2023, 12(18): 3969.
- [14] XIE W, SUN X, MA W. A light weight multi-scale feature fusion steel surface defect detection model based on YOLOv8[J]. Measurement Science and Technology, 2024, 35(5): 055017.
- [15] 何湘杰, 宋晓宁. YOLOv4-Tiny 的改进轻量级目标检测算法[J]. 计算机科学与探索, 2024, 18(1): 138-150.
- HE X J, SONG X N. Improved YOLOv4-Tiny lightweight target detection algorithm[J]. Journal of Frontiers of Computer Science and Technology, 2024, 18(1): 138-150.

- [16] 王春梅, 刘欢. YOLOv8-VSC: 一种轻量级的带钢表面缺陷检测算法[J]. 计算机科学与探索, 2024, 18(1): 151-160.
- WANG C M, LIU H. YOLOv8-VSC: lightweight algorithm for strip surface defect detection[J]. Journal of Frontiers of Computer Science and Technology, 2024, 18(1): 151-160.
- [17] ZHOU J, ZHANG B, YUAN X, et al. YOLO-CIR: the network based on YOLO and ConvNeXt for infrared object detection[J]. Infrared Physics and Technology, 2023, 131: 104703.
- [18] LIN T Y, DOLLÁR P, GIRSHICK R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 2117-2125.
- [19] LI H, XIONG P, AN J, et al. Pyramid attention network for semantic segmentation[J]. arXiv:1805.10180, 2018.
- [20] GE Z, LIU S, WANG F, et al. YoloX: exceeding yolo series in 2021[J]. arXiv:2107.08430, 2021.
- [21] ELFWING S, UCHIBE E, DOYAK K. Sigmoid-weighted linear units for neural network function approximation in reinforcement learning[J]. Neural Networks, 2018, 107: 3-11.
- [22] RUKUNDO O, CAO H. Nearest neighbor value interpolation[J]. arXiv:1211.1768, 2012.
- [23] KIRKLAND E J. Bilinear interpolation[C]//Advanced Computing in Electron Microscopy, 2010: 261-263.
- [24] MCKINLEY S, LEVINE M. Cubic spline interpolation[J]. College of the Redwoods, 1998, 45(1): 1049-1060.
- [25] GAO H, YUAN H, WANG Z, et al. Pixel transposed convolutional networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 42(5): 1218-1227.
- [26] WANG J, CHEN K, XU R, et al. Carafe: content-aware reassembly of features[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 3007-3016.
- [27] GLOROT X, BORDES A, BENGIO Y. Deep sparse rectifier neural networks[C]//Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics, 2011: 315-323.
- [28] XU J, LI Z, DU B, et al. Reluplex made more practical: leaky ReLU[C]//Proceedings of the 2020 IEEE Symposium on Computers and Communications (ISCC), 2020: 1-7.
- [29] CRNJANSKI J, KRSTIĆ M, TOTOVIĆ A, et al. Adaptive sigmoid-like and PReLU activation functions for all-optical perceptron[J]. Optics Letters, 2021, 46(9): 2003-2006.
- [30] MA N, ZHANG X, SUN J. Funnel activation for visual recognition[C]//Proceedings of the 16th European Conference on Computer Vision (ECCV 2020), Glasgow, UK, August 23-28, 2020. [S.l.]: Springer International Publishing, 2020: 351-368.
- [31] HU J, SHEN L, SUN G. Squeeze-and-excitation network [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 7132-7141.
- [32] WOO S, PARK J, LEE J Y, et al. CBAM: convolutional block attention module[C]//Proceedings of the European Conference on Computer Vision (ECCV), 2018: 3-19.
- [33] WANG Q, WU B, ZHU P, et al. ECA-Net: efficient channel attention for deep convolutional neural networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 11534-11542.
- [34] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems, 2017.
- [35] LI Z, WEI X, HASSABALLAH M, et al. A deep learning model for steel surface defect detection[J]. Complex & Intelligent Systems, 2023, 10: 885-897.
- [36] LV X, DUAN F, JIANG J, et al. Deep metallic surface defect detection: the new benchmark and detection network [J]. Sensors, 2020, 20(6): 1562.
- [37] LIU J J, HOU Q, CHENG M M, et al. Improving convolutional networks with self-calibrated convolutions[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 10096-10105.
- [38] WANG C Y, YEH I H, LIAO H Y M. YOLOv9: learning what you want to learn using programmable gradient information[J]. arXiv:2402.13616, 2024.