

面向带钢表面缺陷的 GSS-YOLO 目标检测算法

肖轶磊¹, 汪 诚¹, 渠 逸¹, 孔亚康¹, 陈贤聪¹, 王小旭²

(1. 空军工程大学基础部, 西安, 710051; 2. 西北工业大学自动化学院, 西安, 710072)

摘要 基于计算机视觉的智能检测技术应用于带钢材料工业生产时,漏检、错检情况严重和识别精度低下等问题频频发生,针对此业内痛点,提出一种基于 Ultralytics 框架的目标检测优化算法 GSS-YOLO。该模型将 GOLDYOLO 算法的 Neck 网络与原始 YOLOv8n 有机融合,以提高模型对不同尺寸和形状缺陷的检测精度。为平衡不同缺陷种类识别效果的差距并降低网络结构的复杂性,引入了 SlimNeck 结构中的轻量级卷积 VoVGSCSP 和高效通道注意力机制 SimAM 2 个轻量级模块,提高模型的检测精度和泛化能力的同时,限制了模型计算量和权重体积的膨胀。依靠经典的带钢表面缺陷数据集 NEU-DET,进行消融实验及横向对比实验。结果表明,模型的平均精度较基准模型提高了 3.7%,且各类缺陷检测精度差距减小,均衡了检测精度和运行速度。所提模型相较于当前主流模型在检测精度具有一定优势,并对实际工业生产中的缺陷检测应用具有参考价值。

关键词 带钢表面缺陷检测; Ultralytics; GOLD-YOLO; SimAM 注意力机制

DOI 10.3969/j.issn.2097-1915.2025.05.004

中图分类号 TP242.2 **文献标志码** A **文章编号** 2097-1915(2025)05-0031-011

An Algorithm of Detecting GSS-YOLO Object Geared to Surface Defects of Strip Materials

XIAO Yilei¹, WANG Cheng¹, QU Yi¹, KONG Yakang¹, CHEN Xiancong¹, WANG Xiaoxu²

(1. Fundamentals Department, Air Force Engineering University, Xi'an 710051, China;

2. School of Automation, Northwestern Polytechnical University, Xi'an 710072, China)

Abstract In view of the problems that intelligent detection technology in the process of strip surface defect detection is low in accuracy, missing in detection and false in detection, a GSS-YOLO object detection optimization algorithm is proposed based on YOLOv8n. The model is to organically integrate the Neck network of the GOLD-YOLO algorithm with the Ultralytics to improve the detection accuracy of the model for defects of different sizes and shapes. In order to balance the gap in identifying the effect of different defect types and reducing the complexity of the network structure, two lightweight modules in the SlimNeck structure are introduced, i. e. lightweight convolution VoVGSCSP and efficient channel attention mechanism SimAM, enable to improve the detection accuracy and generalization ability of the model, and to simultaneously limit the expansion of the computational and weight volume of the model. It appears

收稿日期: 2024-10-28

基金项目: 陕西省自然科学基金研究计划(2023-JC-QN-0696)

作者简介: 肖轶磊(2001—),男,江西宜春人,硕士,研究方向为表面微缺陷智能技术。E-mail:15979517067@163.com

通信作者: 汪 诚(1974—),男,江苏扬州人,教授,博士,研究方向为航空测试技术与表面强化。E-mail:valid_01@163.com

引用格式: 肖轶磊,汪诚,渠逸,等. 面向带钢表面缺陷的 GSS-YOLO 目标检测算法[J]. 空军工程大学学报, 2025, 26(5): 31-41. XIAO Yilei, WANG Cheng, QU Yi, et al. An Algorithm of Detecting GSS-YOLO Object Geared to Surface Defects of Strip Materials[J]. Journal of Air Force Engineering University, 2025, 26(5): 31-41.

from relying on the classical strip surface defect dataset NEU-DET, thaw experiment, lateral comparison experiment that the average accuracy of the model is 3.7% higher than that of the benchmark model, and the gap between the detection accuracy of various defects is reduced, thus the detection accuracy meeting not only the requirements, but also guaranteeing at running speed. In comparison with the current mainstream models, this model has a certain advantage in detection accuracy, and is in reference value to the application of defect detection in actual industrial production.

Key words steel surface defects; Ultralytics; GOLD-YOLO; SimAM attention mechanism

随着现代工业水平的发展,带钢材料已成为当今应用最广的金属材料。形态各异的带钢产品的生产加工涉及复杂的工艺,导致带钢材料表面缺陷的复杂性和频发性。这些表面缺陷,即构件表面理化性质不均匀的区域^[1],限制了带钢材料的结构强度、使用年限和抗磨耐蚀性能,研究其产生机理并优化生产工艺,需要高效的带钢材料表面缺陷检测技术。

表面缺陷检测技术大致为 3 个发展阶段:人工筛查检测、基于机器学习的自动检测以及基于深度学习的智能检测。早期的人工筛查检测主观性强、效率低下;机器学习检测方法的规范性和效率进步明显,但受限于步骤繁琐、识别率低等缺点。近几年,深度学习算法迅速发展,计算机视觉广泛应用于各个领域,基于深度学习的缺陷检测技术应运而生。该技术大幅降低了人工成本,并且具有稳定、高效、准确度高等优势,已广泛应用于带钢表面的缺陷检测中,实现了自动化和高效率的检测^[2],大幅提升了检测效率,降低了检测人工成本。

本文的算法基石为卷积神经网络(convolutional neural network, CNN),其深度学习能力被广泛认可,是当前应用最广的目标检测算法。依据结构上的差异,CNN 算法大致划分为 2 类:一是以 Faster R-CNN(faster region convolutional neural networks)^[3]、Mask R-CNN^[4] 等为代表的双阶段(two-stage)网络,二是以 SSD(single shot multibox detector)^[5] 与 YOLO^[6-8] 为代表的单阶段(one-stage)网络。它们的检测流程截然不同:双阶段算法优先目标选定候选区域(region proposal),通过对候选框分类操作和定位信息回归计算,求解目标的检测结果;单阶段算法的检测流程通常只涉及一次前向传播,边界框位置的预测和目标的类别信息的判定可由单个卷积神经网络快速求解。双阶段算法的特征是检测速度较慢,虽然检测准确度表现尚可,但表面缺陷检测时对时效性要求较高,因此,其检测速度难以满足工业需求。单阶段算法虽然在检测准确度上略有劣势,但仍有实时效率高、检测速度快、算法体量和易移植部署等诸多优势。因此,在带钢材料表面缺陷检测领域,单阶段目标检测算法更受研

究人员青睐。

单阶段算法中,基于 SSD 和 YOLO 等经典算法的表面缺陷检测技术已较为成熟。SSD 简洁高效,在微小目标、复杂类别等目标识别领域性能出色。例如,刘艳菊等^[9]通过改进 SSD 的特征层,即将深层特征反卷积操作并与浅层特征融合,使得算法效率提升显著。Li 等^[10]开发了一种基于 MobileNet 的 SSD 的容器密封表面缺陷检测方法,简化了检测模型参数,优化了检测精度。

YOLO 系列检测算法不仅有简洁的计算模型网络,而且识别精度和速度更加均衡,因此其在工业领域的应用硕果累累。KOU 等^[11]中通过添加无锚特征选择机制和密集卷积块增强网络的表征能力,改进了 YOLOv3 算法,精简了模型的运算量,实现了带钢表面缺陷的高速检测。叶卓勋等^[12]基于 GhostNet 和 PANet 改进 YOLOv4 网络,增强了网络特征提取能力,简化了复杂的骨干网络结构,优化了对金属材料表面小目标缺陷的检测性能。李鑫等^[13]基于 YOLO 算法,提出了缺陷检测 YOLOv5-GSD,较同期其他算法具有高准确率和检测精度。渠逸等^[14]研发了 YOLOv5-DAFC 模型,优化了轧制带钢缺陷检测系统,在工业检测领域有较高应用价值。张涛源等^[15]提出了 TRSD-YOLO 算法,在带钢缺陷实时检测任务中提高了检测精度。Huang 等^[16]针对带钢表面缺陷检测中识别速度慢、精度低等局限,结合 GhostNetv2 模块改进 YOLOv8 算法,使模型的表达能力提高,达到符合预期的检测效果。

本文基于 Ultralytics (YOLOv8) 算法并结合 GOLD-YOLO 算法,引入无参数注意力机制(simple parameter-free attention module, SimAM)改进跨阶段局部网络融合(Cross Stage Partial Network Fusion, C2f)模块,通过了基于 FasterNet 轻量化模型的 C3-Faster 模块替换 YOLOv8 网络用于提取特征的 C2f 模块,研发了一个适用于小目标、多尺度缺陷的轻量化 GSS-YOLO 模型。

1 YOLOv8 模型基本原理

YOLOv8 是 Ultralytics 公司首发于 2023 年的

开源 YOLO 类算法模型。作为 YOLOv5 版本的延续,保留了核心框架与优势,并进行了深度优化与创新,构建了一个性能卓越且更加灵活的目标检测模型。

YOLOv8 组成结构如图 1 所示。卷积模块 Conv 是架构的模块基石,由二维卷积层 Conv2d、归一化处理层 BatchNorm2d 以及 SiLU 激活函数

组成,对输入图片进行特征提取;瓶颈模块 Bottle-Neck 由 2 个 Conv 拼接而成,执行数据的精简、增效任务;C2f 模块包括 Split 分割模块、Concat 特征融合模块以及上述 2 种模块,其作用是深度提取图像特征并输出最终特征图;空间金字塔快速池化模块 SPPF,包括 Conv、最大池化层 Maxpool2 以及 Concat,其功能是高效捕捉多尺度信息。




图 1 YOLOv8 模块的结构

Fig. 1 Structure of each module in YOLOv8

2 改进模型与方法

2.1 GOLD-YOLO 原理

GOLD-YOLO 是华为诺亚方舟实验室于 2023 年开源 YOLO 类目标检测算法模型。针对主流算法常见的信息损失问题,研发人员提出了信息聚集-分发机制^[17],即 GD 机制。GD 机制主要分成 3 个模块:信息融合模块 (information fusion module, IFM)、信息注入模块 (information injection mod-

ule, Inject)、特征对齐模块 (feature alignment module, FAM)。

如图 2 所示,GOLD-YOLO 的网络结构与 YOLO 非常相似,不同之处在于:Neck 部分,低阶段聚合分发 (Low-GD) 模块代替了路径聚合网络 (PANet) 的上采样融合阶段,高阶阶段聚合分发 (High-GD) 模块代替了 PANet 的下采样融合阶段,Low-GD 和 High-GD 开发者面向不同尺寸物体的特征提取和融合能力而研发的模块,分别适用于大、小尺寸目标。




图 2 GOLD-YOLO 的网络结构

Fig. 2 Architecture of the proposed GOLD-YOLO

Low-GD 模块选取了 Backbone 即骨干网络输出的小尺寸高分辨率的特征信息并注入低阶段特征

对其模块 (Low-FAM) 后经低阶段信息融合模块 (Low-IFM) 输出至信息注入模块 (Inject) 生成特征

信息 P3 和 P4; High-GD 模块与前者相似, 选取 P3、P4 和 P5 的特征信息经高阶特征对其模块(High-FAM)和高阶信息融合模块(High-IFM)后输出至 Inject 生成 N4 和 N5 特征信息。

如图 3(a)所示, Low-FAM 以 B4 为基准, 对大尺寸特征 B2、B3 通过平均池化(AvgPool)进行下采样, 对小尺寸特征 B5 采用双线性插值(Bilinear)进行上采样, 实现特征尺寸的统一, 然后进行 Concat 融合操作, 得到合并后的特征信息 F_{align} , 此模块能够确保特征信息有效聚合并保持较小尺寸的特征以降低后续处理的技术复杂度。

如图 3(b)所示, High-FAM 由 AvgPool 和 Concat 构成, 通过对 P3 和 P5 特征进行平均池化操作将输入特征的宽和高的信息降维到统一尺寸, 即 P3 和 P4 降维到 P5 大小, 然后再通过 Concat 进行特征图合并, 此模块提取较大尺寸的特征并降低后续的技术复杂度。

如图 3(c)所示, Low-IFM 模块包括 Conv 卷积块、Rep-Block 多层重参数化卷积块、Split 拆分模块。Low-FAM 模块输出的特征信息经过 Rep-Block 模块转化为融合的特征信息, Conv 调节通道数以适应模型的尺寸, 随后特征信息拆分为 2 份, 分别与不同的层级进行下一步特征融合。

如图 3(d)所示, High-IFM 主要由 Multi-Head Attention 多头注意力模块、Feed-Forward Network 前馈网络模块和 Split 构成, 流程步骤如下: High-FAM 输出的特征信息经多头注意力模块和前馈网络处理得到初步融合的信息, 经过 Conv 通道调整后, 再历经 Split, 输出特征切片。

如图 3(e)所示, Inject 模块采用类似自注意力的形式, 输入为待被分发的当前尺度下的特征 X_{Local} , 以及前面由 IFM 生成的全局特征 Y_{Global} 。Inject 模块增加了不同尺寸的特征信息间的信息流通道数, 有助于提升性能并减缓信息延迟。




图 3 GOLD-YOLO 模块结构

Fig. 3 Structure of each module in GOLD-YOLO

2.2 SimAM 注意力机制

注意力机制是一种聚焦重要信息、调整权重、提升模型性能的算法模块,能够选择和聚焦与目标相关的区域或特征,并优化检测准确性和鲁棒性。本文引入的 SimAM 注意力机制是中山大学的 Yang 等基于神经科学理论开发的一项兼具灵活性和稳定性的无参数注意力模块^[18]。该注意力机制以简洁且高效著称,绝大部分操作基于所定义的能量函数选择,无需额外参数为特征图推导出 3D 注意力权重。得益于其在能量函数上的创新,该模块在注意力权值的计算方面更加迅速且精准。

神经科学理论指出:信息丰富的神经元的放电模式与周围的正常神经元相异;呈现激活态势的神经元会削弱周遭神经元的活性,这被称为“空域抑制”效应,即具备“空域抑制”效应的神经元值得被委以重任。因此,可以通过衡量神经元间的影响力权重,寻找更加重要的神经元。

将此思路运用在神经网络中,可得到简洁高效的能量函数,如式(1)所示,该能量函数有助于高效计算注意力权重:

$$e_t(w_t, b_t, y, x_i) = (y_t - \hat{t})^2 + \frac{1}{M-1} \sum_{i=1}^{M-1} (y_0 - \hat{x}_i)^2 \quad (1)$$

式中: t 为输入特征图单通道上的目标神经元; M 为神经元个数对应输入特征的维度信息。

式(2)为最小解析解,其含义为训练同一通道内神经元 t 和另外的神经元的线性可分性。

$$\hat{t} = w_t + b_t, \hat{x}_i = w_i x_i + b_i \quad (2)$$

将式(2)代入式(1),可得出最终的能量函数方程为:

$$e_t(w_t, b_t, y, x_i) = (1 - (w_t t + b_t))^2 + \lambda w_t^2 + \frac{1}{M-1} \sum_{i=1}^{M-1} (1 + (w_i x_i + b_i))^2 \quad (3)$$

理论上,各通道的能量函数的数量等同于神经元个数 M ,其定义如式(4):

$$M = H \times W \quad (4)$$

式中: H 和 W 分别为特征图的高和宽。

式(5)和式(6)为求得能量函数方程的一个巧妙的解析解。

$$w_t = \frac{-2(t - \mu_t)}{(t - \mu_t)^2 + 2\sigma_t^2 + 2\lambda}, b_t = -\frac{(t + \mu_t)w_t}{2} \quad (5)$$

其中:

$$\mu_t = \frac{1}{M-1} \sum_{i=1}^{M-1} x_i, \sigma_t^2 = \frac{1}{M-1} \sum_{i=1}^{M-1} (x_i - \mu_t)^2 \quad (6)$$

将上述解析解代入式(3),可推导出衡量目标神

经元权重的关键指标,即最小能量 e_t^* 的定义,如式(7)所示:

$$e_t^* = \frac{4(\hat{\sigma}^2 + \lambda)}{(t - \hat{\mu})^2 + 2\hat{\sigma}^2 + 2\lambda} \quad (7)$$

式中: $\hat{\mu}$ 为所有神经元在单通道上的平均值; $\hat{\sigma}^2$ 为所有神经元在单通道上的方差。当最小能量 e_t^* 越低,缺陷特征中的目标神经元 t 与该神经元对应维度上其他神经元的区别就越大,对应重要性也就越高。这也符合上文提及的“空域抑制”:神经元 t 呈现高活性,即较区域内的其他神经元状态相异,它的影响力权重越大。

最后,根据注意力机制的定义对上述特征信息进行特征增强得到最后的输出特征信息 $\tilde{X}$:

$$\tilde{X} = \text{sigmoid}\left(\frac{1}{E}\right) \odot X \quad (8)$$

式中: $\odot$ 为按元素相乘; E 为特征图上所有最小能量 e_t^* 的集合。通过 sigmoid 函数限制 E 值的大小,避免其影响到每个神经元的重要性。

SimAM 注意力机制已被证实适用于复杂种类的小目标检测领域^[19-21]。总的来说,SimAM 注意力机制与本文研究的带钢材料表面缺陷这类环境匹配程度较高,因此选择基于此优化目标算法。

2.3 SlimNeck 结构与 VoVGSCSP 模块

研发检测算法时,通常引入深度可分离卷积以轻量化模型,但这却导致计算结果准确度显著下降。为了平衡目标检测算法的准确度和速度, Li 等^[22]基于 DensNet、VoVNet 和 CSPNet 等 CNN 通用方法,提出了 SlimNeck 结构,以实现检测器的高效计算。其优异性能取决于 2 个关键模块: GSConv 模块和 VoVGSCSP 模块。

如图 4(a)所示,首先,GSConv 对输入项进行标准卷积(standard convolution, SC)的下采样;然后进行深度可分离卷积(depth-wise separable convolution, DSC)运算,拼接 SC 和 DSC 的结果;最后,进行 shuffle 操作,让之前 2 个卷积的对应通道数统一合并。为了使 DSC 的输出尽可能接近 SC。研究人员引入 shuffle 环节,使标准卷积得出的信息蔓延至 DSC 生成的信息的每个部分。GSConv 方法的贡献包括:代替 SC 操作,使卷积计算的输出尽可能接近 SC,同时降低计算成本,在保留其精简的长处的同时,尽可能地规避了 DSC 的缺陷的不足。

图 4(b)展示了 VoVGSCSP 的结构。其延续了单次聚合的思路,对模块的网格结构进行优化。VoVGSCSP 模块得益于跨局域网络式的结构,有效降低了模块的运算量和结构网络的复杂度。

本文算法选择将原算法 Neck 部位的 C2f 替换

为 VoVGSCSP 模块, 以求适合 SimAM 注意力机制

的同时避免该模块加剧对数据流的阻力。




图 4 Slim-Neck 的关键模块

Fig. 4 Structure of each module in Slim-Neck

2.4 改进后的网络结构

根据前文, 本文基于 Ultralytics 中 YOLOv8n 模型, 在 Backbone 的末端引入 SimAM 注意力机制; 将 Neck 部分进行 GOLD 化, 即引入 2 种 GD 机制并调节对应通道接口, 使其与 GOLD-YOLO 的

Neck 部分有机融合的同时能够保证 GD 机制无障碍运行; 最后使用 SlimNeck 的 VoVGSCSP 模块 Neck 替换原本的 C2f。改进后的 GSS-YOLO 模型网络结构如图 5 所示。




图 5 GSS-YOLO 网络结构

Fig. 5 Network structure of GSS-YOLO

3 实验

3.1 实验环境与参数

本文实验环境基于云服务器,运行内存 60 GB,使用 Pytorch 2.0.0 作为深度学习框架,Python 版本为 3.8,CUDA 版本为 11.8。CPU 为 AMD EPYC 9754 128-Core Processor。GPU 为 RTX 4090×1。

训练参数如下:图像尺寸设置为 640,批量大小设置为 16,迭代次数设置为 300,学习率为默认值 0.01,动量参数为默认值 0.937,权重衰减系数 weight_decay 为默认值 0.000 5,使用 SGD 随机梯度下降优化器。

3.2 数据集

本文数据集为东北大学开源的带钢材料表面缺陷数据集 NEU-DET^[23]。如图 6 所示,数据集包含 6 类热轧带钢表面缺陷,每类缺陷均含有 300 张图片,共 1 800 张 200×200 的图片,其中,裂纹(crazing, Ca)、夹杂(inclusion, In)、斑块(patches, Pa)、麻点(pitted surface, Ps)、氧化铁皮(rolled-in scale, Rs)、划痕(scratches, Sc),这 6 种带钢表面缺陷为实际钢材生产与质检任务中最普遍的表面缺陷。




图 6 6 种带钢材料的表面缺陷

Fig. 6 Surface defects of six strip materials

将数据集的 1 800 张图片按照 8:1:1 划分为训练集、验证集和测试集,得到训练集图片 1 440 张,验证集图片 180 张,测试集图片 180 张。

3.3 实验评价标准

在主流的目标检测实验中,往往借助检测框与真实框(ground truth, GT)的交并比(intersection over union, IoU)评价模型预测能力的准确度,一般只有大于 0.5 时,才认为目标检测定位成功。检验目标模型的识别能力时,常通过其精确率(precision, P)与召回率(recall, R)等指标判断:精确率指所有被预测为正例的样本中,真实样本所占的比例;召回率指所有真实正例中,模型成功预测为正例的

比例。分析实验结果时常参考其 AP 值预估模型的对各类目标的识别精度,它能衡量模型在预测中不同置信度阈值下的平均精度,并使用一个特定的 IoU 阈值来确定正例和负例的匹配;mAP 是当前主流的目标检测评价指标,考核的是准确率和召回率的综合表现;每秒帧数(frames per second, FPS)常用来衡量模型的推断速度,与图像预处理时间(pre-processing time, PP)、推理时间(inference time, In)和后处理时间(non-maximum suppression, NMS)有关。相关计算式为:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (9)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (10)$$

$$AP = \sum_{i=1}^n P(i) \Delta R(i) = \int_0^1 P(R) dR \quad (11)$$

$$mAP = \frac{1}{n} \sum_{i=1}^n AP(i) \quad (12)$$

$$EPS = \frac{1\ 000}{PP + In + NMS} \quad (13)$$

式中:TP 为正确识别的的案例;FP 为被误判为正例的错误案例;FN 为本身正确案例,但被识别为错误案例的情况;mAP 为各类别的检测精度,即 AP 的均值,它通常被用作衡量网络模型在目标检测任务中整体性能的标准。在这个指标中,AP(i) 为针对某一特定类别的检测精度,n 为对应该目标数据集中缺陷类别数量,即为 6 种缺陷。

4 结果分析与评估

4.1 模型性能对比

通过系列消融实验,展示各改进模块对检测效果的影响,进而体现各个模块较 YOLOv8n 的性能提升和各项参数。消融实验数据如表 1 所示。

从表 1 可以看出,原模型 GOLD 化后, G-YOLO 模型(即 YOLO+GOLD)明显变得复杂,其相关指标参数量(Params)、GPU 每秒所执行的浮点运算次数(GFLOPS)和权重体积(Weight)都有不同幅度的增长,Params 和 Weight 近乎翻倍,GFLOPS 较原模型扩大 25.92%;改进后模型的检查精度指标 mAP 指标有了较大幅度的提升,增加了 1.6%,同比提升 2.11%。究其原因,引入 GD 机制后, G-YOLO 模型变得更加复杂,增加了更多的耦合计算环节,显著提升了模型的检测能力。引入 Slim-Neck 模块后, SN-YOLO 模型(即 YOLO+SlimNeck)变得精简,其 Params 减小 6.98%, Weight 减小 0.4 MB,同比减小 6.7%, GFLOPS 同比缩减 9.88%;与此同时,模型的检测精度并未出现明显下降。

表 1 消融实验结果

Tab. 1 Results of ablation test

序号	GOLD	SlimNeck	SimAM	Params	GFLOPS	$P/\%$	$R/\%$	mAP/ $\%$	Weight/MB	FPS/(帧 $\cdot$ s $^{-1}$)
1	×	×	×	3 006 818	8.1	72.6	71.7	75.8	6.0	2 247.5
2	✓	×	×	5 976 994	10.2	82.4	68.3	77.4	11.9	838.4
3	×	✓	×	2 796 834	7.3	70.6	72.3	75.8	5.6	2 199.5
4	×	×	✓	3 006 818	8.1	75.6	73.3	76.0	6.0	2 232.7
5	✓	✓	×	5 853 186	9.7	78.1	70.6	77.7	11.7	815.9
6	✓	×	✓	5 976 994	11.8	75.8	72.5	77.7	11.8	844.3
7	✓	✓	✓	5 853 186	11.2	82.6	72.1	79.5	11.7	831.2

不同的模块改进后再经 GOLD 化,模型的检查精度均有提升,这也证实了 GD 机制能够更高效地优化图像的整体结构特征,进而起到优化模型检测精度的作用;此外,将 SlimNeck 引入 GOLD 化的 Y-G 模型中,GSN-YOLO(即 YOLO+GOLD+SlimNeck)的 Params 和 Weight 小幅度精简,分别缩减 2.07%和 1.68%,GFLOPS 同比缩减 4.9%,但模型的精度不降反升,达到了降本增效的目的。引入 Slimneck 模块的目的是通过优化可分离卷积模块 VoVGSCSP,达到降低模型的复杂度、提升模型运算速度的作用并缓解模型 GD 化后激增的模型复杂度。

将 SimAM 注意力机制引入 GOLD 化中的 SlimNeck 模块,GSN-YOLO 模型(即 YOLO+GOLD+SlimNeck+SimAM)较 GSN-YOLO 的检测精度有了大幅度的提升,mAP 增加 1.8%的同时,GFLOPS 仅增加 15.46%,而 Params 和 Weight 未出现明显增大。对比召回率 P 值,引入模块后分别上涨了 1.6%和 4.2%。这是由于 SimAM 注意力机制是无参数注意力机制,引入该模块有助于调节 GD 机制中多头注意力机制引起的信息流传递时

的丢包并增强特征的捕捉和覆盖能力,进而提升检测精度并避免模型复杂度再次扩张。

将 3 个模块有机融合后,GSS-YOLO 大幅提升检测精度的同时,控制了模型参数量和权重体积,相较原版模型,其 mAP 增加了 3.7%,同比增加 4.8%,不仅抑制了模型的计算量的膨胀,且提升了模型的检测性能。

4.2 各类目标识别效果

图 7 为缺陷识别统计结果。为测试 GSS-YOLO 与各模块在各类具体缺陷上的识别效果,对如表 2 所示的实验数据进行分析讨论。

表 2 不同类别缺陷的实验结果

Tab. 2 Experiment results of various defects %

模型	mAP	AP50					
		Cr	In	Pa	Ps	Rs	Sc
YOLOv8n	75.8	37.1	84.2	90.7	84.8	69.0	89.1
GOLD	77.4	38.3	84.2	92.1	84.9	73.9	91.8
SimAM	76.0	37.0	84.4	90.7	82.9	72.2	88.9
SlimNeck	75.8	43.2	78.4	91.0	84.4	70.6	87.4
GSS-YOLO	79.5	48.6	82.7	92.9	87.6	72.8	92.4




图 7 缺陷数据统计图

Fig. 7 Statistical chart of defect data

分析可得:原模型 GOLD 化后,各类缺陷的检测精度均有不同程度的上升,尤其是其在斑块 Pa、划痕 Sc 和压入氧化铁皮 Rs 上的提升最为明显,分别增加了 1.4%、2.7% 和 4.9%。由于这 3 类缺陷都属于大面积、现状不规则的缺陷,经 GOLD 化后的模型拥有 GD 机制,该机制在处理此类缺陷的数据集时,往往能得到更高的检测精度。

在引入 SlimNeck 模块后,模型在对裂纹 Cr 类缺陷的检测精度提升明显,增加 6.1%,但美中不足的是,改进后模型在对夹杂 In 类缺陷的检测出现了掉点,其较原模型减少了 5.8%,我们认为这是改进模型中 VoVGSCSP 模块的对同屏大数目缺陷检测时,为确保其检测效果和平衡检测速度会采取多检测框的策略,正是这种策略在改善 Cr 类缺陷漏检率的同时,不可避免地增加了 In 类缺陷的误检率,因此,后续通过引入擅长处理复杂种类的小目标缺陷的 SimAM 注意力机制以缓解其不利影响。

融合了所有改进点的 GSS-YOLO 模型无疑是成功的。相较原模型,其在几乎所有种类缺陷的检测精度上都有不同程度的提升,提升最为明显当属 Cr 类缺陷(同时也是该数据集检测精度最低的一类缺陷),达到 0.486,增加了 11.5%,同比提升 31%;此外,在 Pa、Ps、Rs 和 Sc 类缺陷的检测中,其优越性也是不言而喻,分别较原模型增加了 2.2%、

2.8%、3.8% 和 3.3%;最后,改进模型在 In 类缺陷的检测能力看似削弱,即下降 1.5%,但需注意,引入 SlimNeck 模块后,模型对 In 类缺陷的检测能力大幅削弱,直到加入 SimAM 模块后,才使其明显回升。

从模块的结构与功能角度分析,得益于 GD 机制的引入,GOLD 化的模型更加擅长处理多尺度的特征信息,体现在实验中,明显优化了对长、宽分布不规则和面积占比大的缺陷种类如 Pa、Sc 和 Rs 的检测效果;SlimNeck 模块则得益于 VoVGSCSP 的特征信息处理策略:模块处理大量特征信息时,会采取类似“广撒网”的方式,增加检测框以控制特征信息的缺失幅度,因此 Cr 类和 Rs 类等单图多数量类缺陷的检测精度得以提升;SimAM 模块很好地兼容了 GD 机制和 VoVGSCSP 模块,并有效提炼特征和聚焦主体目标,添加此模块后模型的召回率显著提升。

由此可见,GSS-YOLO 模型不仅在带钢表面的整体缺陷检测效果取得了大幅提升,并在原版模型检测效果较差的裂纹类缺陷领域提升巨大,对实际检测场景有较高应用价值。

4.3 具体缺陷识别对比

为直观展示优化模型识别能力的提升,现将优化模型与原版模型同时对测试集中 180 张图片执行推理预测任务,部分检测效果如图 8 所示。




图 8 YOLOv8n 与 GSS-YOLO 检测可视化对比

Fig. 8 Comparison of YOLOv8n and GSS-YOLO detection performance

4.4 主流检测算法性能对比

为体现 GSS-YOLO 模型较同类主流模型的检测效果的优越性,现在相同实验条件下,选择了经典的双阶段算法 Faster-RCNN 和 YOLO 系类算法等以及最新的 YOLOv11 算法进行比较,并记录了其检测精度、检测速度、权重体积,如表 3 所示。

通过对比实验结果,可以发现本文所提的改进

模型在检测精度上相较于传统算法和同系列算法有明显的优势,不仅全线超过经典的 Faster-RCNN 和 YOLO 系列算法,而且整体检测精度和模型体积超过了新一代的 YOLOv11 模型。并且针对性改进后模型在目标定位精度、小目标识别、难检目标识别等方面表现更好,基本可以实现高精度和轻量化需求的带钢表面材料缺陷检测的工业应用。

表 3 主流模型对比

Tab. 3 Comparison of mainstream models

算法	mAP50/%	FPS/(帧·s ⁻¹)	Weight/MB
Faster-RCNN	75.3	27.3	38.5
YOLOv3	74.8	150.5	198.2
YOLOv5	73.9	2 485.1	5.0
YOLOv8	75.8	2 247.5	6.0
YOLOv9	75.3	352.9	40.9
YOLOv10	75.1	1 812.9	5.5
YOLOv11	77.7	2 087.1	19.2
GSS-YOLO	79.5	831.2	11.7

5 结论与展望

本文为优化带钢材料工业生产中缺陷检测任务,基于 YOLOv8n 模型的高精度检测算法,提出 GSS-YOLO 改进模型,模型的主要贡献如下:

1)受华为诺亚实验室研发的 GOLD-YOLO 启发,将其中的 GD 信息聚集-分发机制开创性地与 YOLOv8 的 Neck 部分有机融合,使得 GD 机制能够无障碍运行,改善模型在处理面积大且复杂的缺陷的检测性能。

2)引入 SlimNeck 后出现的夹杂类缺陷大幅误检时,添加 SimAM 注意力机制,保证改进模型在面对复杂种类的小目标缺陷时仍有一战之力,并一定程度上达到轻量化的效果,更适应实际生产应用。

在未来的工作中,将沿着 2 个方向进行研究:

1)继续深挖 GOLD-YOLO 模型的特性。本研究团队认为其在缺陷检测领域的价值被严重低估,因此,想发掘该模型的优秀特性,并推进其与新型目标识别算法(如 YOLOv11)的结合,为缺陷检测提供相应理论支撑与成果转化的新思路。

2)将理论模型在工业生产中的实际应用作为努力方向。未来将专注于优化模型的泛化性、轻量化和兼容性,保证模型能够应用于不同的工业场景、不同的硬件设备,检测精度提升的同时,拥有更快的运行速度和更小体积容量。为此,本研究团队将在模型减枝操作和知识蒸馏处理方面继续研究。

参考文献

[1] 汤勃,孔建益,伍世虔. 机器视觉表面缺陷检测综述[J]. 中国图象图形学报,2017,22(12):1640-1663.
TANG B, KONG J Y, WU S Q. Review of Surface Defect Detection Based on Machine Vision[J]. Journal of Image and Graphics, 2017, 22(12): 1640-1663. (in

Chinese)

- [2] 李维刚,叶欣,赵云涛,等. 基于改进 YOLOv3 算法的带钢表面缺陷检测[J]. 电子学报, 2020, 48(7): 1284-1292.
LI W G, YE X, ZHAO Y T, et al. Strip Steel Surface Defect Detection Based on Improved YOLOv3 Algorithm[J]. Acta Electronica Sinica, 2020, 48(7): 1284-1292. (in Chinese)
- [3] REN S Q, HE K M, GIRSHICK R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.
- [4] HE K M, GKIOXARI G, DOLLÁR P, et al. Mask R-CNN[C]//2017 IEEE International Conference on Computer Vision (ICCV). Venice: IEEE, 2017: 2980-2988.
- [5] GIRSHICK R. Fast R-CNN[C]//2015 IEEE International Conference on Computer Vision (ICCV). Santiago: IEEE, 2015: 1440-1448.
- [6] REDMON J, DIVVALA S, GIRSHICK R, et al. You Only Look Once: Unified, Real-Time Object Detection [C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas, NV: IEEE, 2016: 779-788.
- [7] 管声后,杨振,党慧,等. 一种改进 YOLOv8 的陶瓷环缺陷检测算法[J/OL]. 西安工程大学学报, 1-9. [2025-09-04]. <https://link.cnki.net/urlid/61.1471.n.20250804.0931.002>.
GUAN S Q, YANG Z, DANG H, et al. An improved YOLOv8 ceramic ring defect detection algorithm[J/OL]. Journal of Xi'an Polytechnic University, [2025-09-04]. <https://link.cnki.net/urlid/61.1471.n.20250804.0931.002>. (in Chinese)
- [8] 宦涣,孙艳文. 改进 YOLO 算法的复杂交通场景目标检测[J]. 西安工程大学学报, 2022, 36(6): 86-92.
GUAN H, SUN Y W. Target Detection method in complex traffic scene based on improved YOLO algorithm[J]. Journal of Xi'an Polytechnic University, 2022, 36(6): 86-92. (in Chinese)
- [9] 刘艳菊,王秋霁,张惠玉,等. 基于改进 SSD 的工件表面缺陷检测[J]. 热加工工艺, 2024, 53(2): 134-139.
LIU Y J, WANG Q J, ZHANG H Y, et al. Defect Detection of Workpiece Surface Based on Improved SSD [J]. Hot Working Technology, 2024, 53(2): 134-139. (in Chinese)
- [10] LI Y T, HUANG H S, XIE Q S, et al. Research on a Surface Defect Detection Algorithm Based on MobileNet-SSD[J]. Applied Sciences, 2018, 8(9): 1678.
- [11] KOU X P, LIU S J, CHENG K Q, et al. Development of a YOLO-V3-Based Model for Detecting Defects on

- Steel Strip Surface [J]. Measurement, 2021, 182:109454.
- [12] 叶卓勋,刘妹琴,张森林. 基于轻量化深度学习网络的工业环境小目标缺陷检测[J]. 控制与决策, 2023, 38(5):1231-1238.
- YE Z X, LIU M Q, ZHANG S L. Small-Scale Defect Detection in Industrial Environment Based on Lightweight Deep Learning Network[J]. Control and Decision, 2023, 38(5):1231-1238. (in Chinese)
- [13] 李鑫,汪诚,李彬,等. 改进 YOLOv5 的钢材表面缺陷检测算法[J]. 空军工程大学学报(自然科学版), 2022, 23(2):26-33.
- LI X, WANG C, LI B, et al. Steel Surface Defect Detection Algorithm Based on Improved YOLOv5[J]. Journal of Air Force Engineering University (Natural Science Edition), 2022, 23(2):26-33. (in Chinese)
- [14] 渠逸,汪诚,余嘉博,等. 基于 YOLOv5 的表面缺陷检测优化算法[J]. 空军工程大学学报, 2023, 24(5):80-87.
- QU Y, WANG C, YU J B, et al. Optimized Algorithm for Surface Defect Detection Based on YOLOv5[J]. Journal of Air Force Engineering University, 2023, 24(5):80-87. (in Chinese)
- [15] 张涛源,谢新林,谢刚,等. 融合 Transformer 的带钢缺陷实时检测算法[J]. 计算机工程与应用, 2023, 59(16):232-239.
- ZHANG T Y, XIE X L, XIE G, et al. Real-Time Detection Algorithm for Steel Strip Defects Incorporating Transformer[J]. Computer Engineering and Applications, 2023, 59(16):232-239. (in Chinese)
- [16] HUANG M H, CAI Z M. Steel Surface Defect Detection Based on Improved YOLOv8[C]//International Conference on Algorithms, High Performance Computing, and Artificial Intelligence (AHPICAI 2023). Yinchuan: SPIE, 2023:1356-1360.
- [17] WANG C C, HE W, NIE J Y, et al. Gold-YOLO: Efficient Object Detector via Gather-and-Distribute Mechanism[EB/OL]. (2023-10-23)[2024-10-01]. https://arxiv.org/abs/2309.11331v5.
- [18] YANG L X, ZHANG R Y, LI L, et al. SimAM: A Simple, Parameter-Free Attention Module for Convolutional Neural Networks[C]//International Conference on Machine Learning, 2021.
- [19] MAHADEVAN V C, NARAYANAMOORTHY R, GONO R, et al. Automatic Identifier of Socket for Electrical Vehicles Using SWIN-Transformer and SimAM Attention Mechanism-Based EVS YOLO[J]. IEEE Access, 2023, 11:111238-111254.
- [20] YOU H T, LU Y F, TANG H H. Plant Disease Classification and Adversarial Attack Using SimAM-EfficientNet and GP-MI-FGSM[J]. Sustainability, 2023, 15(2):1233.
- [21] CHEN J R, KAO S H, HE H, et al. Run, Don't Walk; Chasing Higher FLOPS for Faster Neural Networks[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver, BC: IEEE, 2023:12021-12031.
- [22] LI H L, LI J, WEI H B, et al. Slim-Neck by GSConv: A Lightweight-Design for Real-Time Detector Architectures[J]. Journal of Real-Time Image Processing, 2024, 21(3):62.
- [23] ZHAO Z X, LI B, DONG R, et al. A Surface Defect Detection Method Based on Positive Samples[M]//PRICAI 2018: Trends in Artificial Intelligence. Cham: Springer International Publishing, 2018:473-481.

(编辑:徐楠楠)