

学校代码: 11078



学 号: 2112207013

广州大学

硕士学位论文

题目: 面向锂电池涂布过程的视觉缺陷检测

方法研究

学 生 类 型: ☒ 学术学位硕士
☐ 专业学位硕士

学 位 论 文 作 者: 郭健烽

导师姓名及职称: 马鸽 副教授

学 院: 机械与电气工程学院

学 科 专 业: 机械电子工程

论 文 提 交 日 期: 二〇二五 年 五 月

学校代码： 11078

学 号： 2112207013

广州大学硕士学位论文

面向锂电池涂布过程的视觉缺陷检测方法研究

Research on visual defect detection method
for lithium battery coating process

郭健烽

学 科 专 业： 机械电子工程

研 究 方 向： 工业缺陷检测

论 文 答 辩 日 期： 2025年5月19日

指导教师（签名）：

答辩委员会主席（签名）：

答辩委员会委员（签名）：

摘要

在锂电池极片涂布工艺流程中，因掺杂空气或粉尘等颗粒物导致的极片表面气泡、凹坑等缺陷会对锂电池的质量造成严重影响，甚至引发安全事故。因此，研究面向锂电池涂布过程的视觉缺陷检测方法具有重要意义。基于机器视觉的缺陷检测方法主要采用工业相机采集生产线上的锂电池极片图像，通过图像处理和识别技术对极片表面的缺陷进行检测，并将检测结果反馈给产线工程师，为其调整生产工艺流程提供依据。然而，由于相机受电子元件发热和外部振动等因素影响，采集到的极片表面图像往往存在噪声、模糊等退化问题，将会降低缺陷检测精度。因此，如何提供特征明显、清晰度高的图像并同时能够精准识别图像上的缺陷是亟需解决的问题。本文研究涂布过程中锂电池极片的图像复原方法和图像识别，主要研究工作如下：

(1) 针对卷积神经网络的局部感受野难以提取全局特征信息，进而影响图像去噪性能的问题，本文设计了一个新的有效结合 Transformer 全局建模能力与卷积局部建模能力的双 U 型多尺度信息融合网络。首先，设计了由 CSC-Block 模块构成的内 U 全局特征提取模块，该模块通过全局自注意力建立特征图上不同位置像素点的联系，扩大了感受野的范围，提高了网络对全局图像特征的提取能力，从而提升网络去噪性能；其次，由 MR-Block 模块构成的外 U 局部特征提取模块，拼接全局特征信息和局部特征信息，并通过多重的跳跃残差连接卷积层，能够有效地利用全局信息中的局部特征，提高了网络对局部特征的提取能力，从而更好地保持图像细节纹理；第三，由 DRSFT-Block 模块构成的空间特征融合模块，将提取的全局特征和局部特征经过卷积层进行自适应调制融合，实现图像去噪和细节保持的平衡，提高网络的鲁棒性和泛化能力。实验表明该方法能够很好地去除退化图像上小噪声和大噪声的同时有效地保持特征细节，为后续检测提供清晰度高的图像。

(2) 针对图像复原模型中线性算子不可逆和传统特定正则项先验信息不足，继而影响复原模型去模糊和去噪效果的问题，本文研究了一种基于深度去噪先验的伪逆变换图像复原方法。首先，引入伪逆变换构建伪逆保真项，消除了线性算子矩阵的不可逆所带来的求解难题；其次，通过交替迭代最小化算法将图像复原模型分解为两个子

问题进行求解；第三，采用跨尺度信息交互的深度卷积神经网络求解去噪子问题，为复原模型提供深度去噪先验。由 HCF-Block 构成的三种不同大小的卷积核获得了多种感受野范围，加强了多尺度特征的提取能力，进而提升网络的去噪能力。同时，FSF-Block 模块通过空间变换来聚合多维度的局部特征信息，获得更丰富的图像信息，从而更好地保护纹理细节；最后，在迭代过程中采用自适应参数调节，加快算法的收敛的同时获得了更好的模型复原效果。实验结果表明，该方法能有效地解决不同模糊类型引起的图像退化问题，并且从直观复原效果和客观指标上均优于对比算法，实现了复原结果和特征细节保持的平衡。

（3）针对因锂电池表面缺陷间存在特征相似性带来的误检问题，本文设计了一种聚合分发信息融合的 YOLOv8s_AD 网络。首先，DSCDownsample 模块采用大小不同的卷积核获得了多种感受野范围，逐级丰富了该尺度下的图像特征信息，增强了不同类型缺陷的可辨识度；其次，在浅层网络中 C2f_CDW 将特征图的通道一分为二，并经过两种不同大小的深度卷积提取局部信息，能够有效地避免传统普通卷积的冗余特性，降低网络计算复杂度同时提取局部特征信息。在深层网络中 C2f_CIB 采用单通路和深度卷积，建立跳跃连接改善网络梯度流，有效缓解深层网络中梯度消失问题，并提取深层特征图映射的全局特征信息；第三，颈部结构 Cross_Neck 融合不同尺度间的信息并分发到对应的检测层中，增强了网络对全局与局部的特征提取能力。实验结果表明，YOLOv8s_AD 相较于对比的一阶段目标检测网络，拥有更低的网络复杂度和更高的检测精度，对于复杂环境下的锂电池极片表面缺陷检测具有更好的适用性。

关键词：锂电池极片；图像复原；缺陷检测；正则化；深度神经网络

ABSTRACT

In the lithium battery wafer coating process, defects such as bubbles and pits on the surface of the wafer caused by air or dust particles will have a serious impact on the quality of lithium batteries, and even cause safety accidents. Therefore, it is of great significance to study the visual defect detection method for lithium battery coating process. The defect detection method based on machine vision mainly adopts industrial camera to collect images of lithium battery pole piece on the production line, detects defects on the surface of the pole piece through image processing and recognition technology, and feeds back the detection results to the line engineers to provide a basis for them to adjust the production process. However, due to the camera is affected by factors such as heat from electronic components and external vibration, the collected wafer surface images often have noise, blur and other degradation problems, which will reduce the defect detection accuracy. Therefore, how to provide images with obvious features and high clarity and at the same time accurately recognize defects on the image is an urgent problem. In this paper, we study the image restoration method and image recognition of lithium battery pole piece under natural environment conditions, and the main research work is as follows:

(1) Aiming at the problem that the local receptive field of convolutional neural network is difficult to extract global feature information, which in turn affects the performance of image denoising, this paper designs a new double-U multi-scale information fusion network that effectively combines the global modeling capability of Transformer with the local modeling capability of convolution. Firstly, an inner U global feature extraction module consisting of CSC-Block module is designed, which establishes the connection of pixel points at different locations on the feature map through global self-attention, which expands the range of the receptive field and improves the network's ability to extract global image features, thus enhancing the network denoising performance; secondly, an outer U local feature extraction module consisting of MR-Block module is designed, which splices the global

feature information and local feature information, and connects the convolutional layer through multiple jump residuals, which can effectively utilize the local features in the global information and improve the network's ability to extract local features, thus better maintaining the image detail texture; third, the spatial feature fusion module composed of the DRSFT-Block module, which adapts the extracted global and local features through the convolutional layer for adaptive modulation fusion to achieve a balance between image denoising and detail preservation, and improve the robustness and generalization ability of the network. Experiments show that this method can effectively remove small and large noise from the degraded image while effectively maintaining the feature details, and provide clear images for subsequent detection.

(2) Aiming at the problem of insufficient a priori information of linear operator irreversibility and traditional specific regular terms in the image restoration model, which then affects the de-blurring and denoising effect of the restoration model, this paper investigates a pseudo-inverse transform image restoration method based on the depth denoising a priori. First, the pseudo-inverse transformation is introduced to construct the pseudo-inverse fidelity term, which eliminates the solution problem caused by the irreversibility of the linear operator matrix; second, the image restoration model is decomposed into two subproblems by the alternating iteration minimization algorithm; third, the deep convolutional neural network interacting with cross-scale information is used to solve the denoising subproblem, which provides a deep denoising prior for the restoration model. Three different sizes of convolutional kernels consisting of HCF-Block obtain a variety of sensory field ranges, which strengthens the multi-scale feature extraction capability and thus improves the denoising capability of the network. Meanwhile, the FSF-Block module aggregates multi-dimensional local feature information through spatial transformations to obtain richer image information, which better protects the texture details; finally, adaptive parameter tuning is used in the iterative process, which speeds up the convergence of the algorithm and at the same time obtains a better model restoration effect. The experimental results show that the method can effectively solve the image degradation

problem caused by different blur types, and it is better than the comparison algorithm in terms of intuitive restoration effect and objective indexes, which realizes the balance between restoration results and feature details preservation.

(3) Aiming at the misdetection problem due to the feature similarity among the surface defects of lithium batteries, this paper designs an aggregated distribution information fusion YOLOv8s_AD network. First, the DSCDownsample module uses convolution kernels of different sizes to obtain a variety of sensory field ranges, which enriches the image feature information at this scale step by step and enhances the recognizability of different types of defects; second, the C2f_CDW in the shallow network splits the channel of the feature map in two and extracts the local information through two different sizes of depth convolution, which can effectively avoid the redundancy characteristics of the traditional redundant characteristics of ordinary convolution, reducing the computational complexity of the network while extracting local feature information. In the deep network C2f_CIB adopts single pass and deep convolution, establishes jump connections to improve the gradient flow of the network, effectively alleviates the problem of gradient vanishing in the deep network, and extracts the global feature information of the deep feature map mapping; thirdly, the neck structure Cross_Neck fuses information between different scales and distributes it to the corresponding detection layer, which strengthens the network's ability of global and local feature extraction. The experimental results show that YOLOv8s_AD possesses lower network complexity and higher detection accuracy compared to the comparative one-stage target detection network, and has better applicability for surface defect detection of Li-ion battery pole pieces in complex environments.

Key words: Lithium battery pole piece; Image restoration; Defect detection; Regularization; Deep neural network

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 图像复原方法的研究现状及分析	3
1.3 锂电池极片表面检测的研究现状及分析	7
1.4 本文主要研究内容与结构安排	10
第二章 双 U 型多尺度信息融合网络的图像复原方法	12
2.1 引言.....	12
2.2 双 U 型多尺度信息融合网络设计.....	12
2.3 实验结果与分析.....	16
2.3.1 标准灰度图像实验结果及分析.....	17
2.3.2 标准彩色图像实验结果及分析.....	19
2.3.3 锂电池极片缺陷图像实验结果及分析	21
2.4 本章小结.....	25
第三章 基于深度去噪先验的伪逆变换图像复原方法	26
3.1 引言.....	26
3.2 深度去噪先验的伪逆变换图像复原模型	26
3.3 跨尺度信息交互的 U 型网络设计.....	28
3.4 实验结果与分析.....	30
3.4.1 标准彩色图像实验结果及分析.....	30
3.4.2 自适应参数分析.....	34
3.4.3 锂电池极片缺陷图像实验结果及分析	34
3.5 本章小结.....	39
第四章 聚合分发信息融合的目标检测网络	40
4.1 引言.....	40
4.2 YOLOv8 网络基础结构.....	40
4.3 聚合分发信息融合的网络设计	41
4.4 实验结果及分析.....	45
4.4.1 实验环境配置.....	45
4.4.2 实验结果分析.....	47
4.5 本章小结.....	51
第五章 总结与展望	52
5.1 总结.....	52
5.2 展望.....	53
参考文献.....	54

第一章 绪论

1.1 研究背景及意义

锂电池作为新能源技术研究领域中的一项标志性成果，凭借其体积轻薄、循环寿命长、易于激活、能量密度高、工作温度范围广、充电时间短、节能环保等优点，广泛应用于消费类电子器件和新能源车辆等产品^[1,2]。据工信部发布的统计数据显示，我国锂电池产量逐年实现快速增长，2024 年全国锂电池累计总产量为 1170GWh，同比增长 24%，行业总值超过 1.2 万亿元，我国 2021 年至 2024 年的锂电池年度总产量情况如图 1-1 所示。




图 1-1 2021 年至 2024 年中国锂电池的总体产量情况

锂电池产业需求的急剧扩张促使锂电池产量呈现快速增长的态势，在此背景下市场对于锂电池的品质与安全性的要求也在逐步提高。锂电池的组成部分包括极片、电解液、隔膜和封装材料等。其中，极片是电池电荷的传输通道，负责锂电池的充放电过程，其质量直接影响到锂电池的整体容量、使用寿命和输出功率等性能。锂电池极片的制备流程可分为制浆、涂布、烘干、辊压和分切等多个工艺，其生产过程如图 1-2 所示。因制造工艺较为繁琐，锂电池极片不可避免地会受到一些损伤，导致极片表面产生脱碳、气泡、颗粒、漏金属、凹坑和褶皱等缺陷，如图 1-3 所示。当浆料搅拌不均会造成后续涂布时某区域石墨碳粉含量不足，从而产生脱碳缺陷；当浆料搅拌或者涂

布过程中混入较多气体会造成浆料与基材表面存在间隙，从而形成气穴导致气泡缺陷；当浆料搅拌或者涂布过程中混入了粉尘等颗粒物，极片受到颗粒物的挤压后便会出现颗粒、凹坑、漏金属和褶皱缺陷。这些锂电池极片缺陷可能会影响到锂电池的安全性和可靠性，严重时将引发自燃和爆炸等安全事故^[3,4]，给人们的日常生活中带来了巨大的安全隐患。而采用视觉缺陷检测方法能够精确识别并定位锂电池极片缺陷，具有无接触、无二次损伤等优点。因此，研究面向锂电池涂布过程的视觉缺陷检测方法具有理论意义和应用价值。




图 1-2 锂电池极片生产工艺流程图




图 1-3 六种常见的锂电池电极片缺陷

在实际的生产线上，锂电池极片表面缺陷检测的精度十分容易受到图像的清晰度、对比度等影响。具体表现在图像采集和传输两个方面：（1）在锂电池极片图像采集过程中，工业相机容易受快速启停或外部振动等影响而发生抖动，从而改变缺陷原本的

位置和尺寸，导致图像的几何失真或模糊。这些模糊在一定程度上降低了图像的质量，将会给缺陷检测带来困难；（2）在锂电池极片图像传输过程中，极片图像会不可避免地被噪声干扰，而这些噪声主要来源于设备的物理特性和工作环境。如长时间工作的电子元器件因电阻发热导致电子随机热运动，从而产生了电子噪声。它会影响极片图像中缺陷原有的特征表现，增加后续检测的难度。因此，如何得到一幅特征清晰、分辨率高的待检测极片图像至关重要。常用的图像复原方法有正则化模型和深度神经网络等，其中正则化模型能够提取图像先验信息，通过特定的数学表达式灵活处理不同退化类型的图像，求解退化模型的逆问题后得出复原图像。而深度神经网络以端到端的方式学习图像特征信息，训练多个神经网络能够适应不同的图像复原任务，具有泛化能力强、复原性能好的特点。因此，本文分别研究了正则化框架和深度学习框架下的图像复原方法。

锂电池极片的缺陷特征多样且细小，传统的人工目检方法依赖于技术人员的经验和主观判定，存在效率低下、容易出现漏检或误检的情况，难以适应高速高精度生产线的需求。运用机器视觉技术^[5]进行缺陷检测可以有效改善人工目检的弊端，该技术的核心在于协同计算机和工业相机来替代传统人工目检进行检测。具体而言，工业相机在完成图像采集后，将图像数据传输至计算机软件系统，随后软件采用相应的图像处理或者深度学习模型等视觉检测技术进行缺陷识别。深度学习的视觉检测方法能够精确地识别缺陷的类别和定位缺陷的位置信息，实现良好的检测精度和较快的检测速度。因此，本文研究深度学习框架下的视觉缺陷检测方法。

本文在深入分析锂电池涂布过程的基础上，研究了图像复原和视觉检测方法，解决了工业缺陷检测领域的共性技术难题——图像去模糊、图像去噪和高精度检测，可方便地移植于精密零件检测和印刷电路板检测等领域，具有理论意义和应用价值。

1.2 图像复原方法的研究现状及分析

图像复原(Image Restoration, IR)一直是一个热门的研究问题，其目的是从低质量的观察图像中恢复出高质量的干净图像，在各种基础视觉应用^[6,7]中具有很高的实用价值。为了简单起见，图像的退化过程用数学公式抽象地表示为式子(1-1)：

$$y = Mx + n \quad (1-1)$$

其中 x 和 y 分别是原始图像和观测图像； M 是模拟采集过程的线性算子，它与噪声无关； n 是标准偏差为 σ 的加性高斯白噪声。

实现图像复原的主要途径有两种，一种是采用高性能的硬件成像设备，减少线性算子 M 与噪声 n 的干扰，使采集到的图像与原图尽可能地一致。该方法简单有效，但市面上这种成像设备价格昂贵、便捷性差，限制了其在不同成像环境的广泛应用。另一种是通过软件算法部署到设备中，兼容多种检测环境。这种方法具有广泛适用性、灵活便捷的优点，并逐渐成为图像复原技术的研究热点。图像复原方法主要可以划分为正则化方法和深度神经网络算法。

正则化方法依据已有的先验信息构建图像复原模型，并对该模型进行迭代求解以恢复原始图像。由于线性算子 M 通常是病态的，从退化图像 y 中复原出潜在干净图像 x 是一个不适定反问题，通常采用正则化来对解空间进行约束^[8]。经典的图像复原模型一般包括保真项和正则项，可以表示为优化问题(1-2)：

$$\min_x E(x) = \min_x \left[\frac{1}{2\sigma^2} \|y - Mx\|_2^2 + \lambda \phi(x) \right] \quad (1-2)$$

其中 $\frac{1}{2\sigma^2} \|y - Mx\|_2^2$ 为保真项， $\phi(x)$ 是正则项。 λ 为正则项参数，用于平衡保真项和正则项的作用。

具体来说，保真项保证求解符合退化过程，而正则项对解空间施加强制约束来缓解和问题的不适定性。因此，许多正则项相继被提出用于求解问题(1-2)，从而获得更好的解。常见的正则项如 Tikhonov 正则项^[9]、 ℓ_1 正则项^[10]、全变分（Total Variation, TV）正则项^[11]、总广义变分（Total Generalized Variation, TGV）正则项^[12]等。TV 正则项利用图像梯度的 ℓ_1 范数，能够在去除图像噪声的同时有效保持边缘特征，但容易产生阶梯效应，对于纹理丰富或结构复杂的图像来说不适用。受 TV 影响，TGV 正则项构建了趋近任意阶的分段多项式函数，具备 TV 的边缘保持能力的同时有效去除了阶梯效应，但容易模糊复原图像中细小结构等重要特征。为了有效求解上述含特定正则项的图像复原模型，众多研究学者还对模型的求解算法展开了深入研究。对于 TV、TGV 正则项模型，学者们提出了 HQS(Half Quadratic Splitting)，ADMM(Alternating Direction Method of Multipliers)和 Split Bregman 等分裂变量算法进行求解。这些算法通常引入一个辅助变量，将原本复杂的最小优化问题(1-2)分解为多个较为简单的子问题，并在迭

代求解过程逐步逼近求解最优解。在多个子问题中包含了一个标准去噪的问题，该问题在大多数情况下可以利用软阈值进行求解。相反，在不考虑 $\phi(x)$ 的具体形式的情况下，直接使用一些传统去噪器也能够求解这一标准去噪问题，如 BM3D^[13](Block-Matching and 3D filtering) 和 WNNM^[14](Weighted Nuclear Norm Minimization)。IDBP(Iterative Denoising and Backward Projections)^[15]通过构建伪逆保真项消除 M 不满秩的影响，并采用 BM3D 作为去噪器用于解决 ADMM 分裂算法中的去噪问题，取得了较好的去噪效果。但 BM3D 在纹理区域过度平滑，导致细节信息辨识度降低，不利于后续的锂电池极片缺陷检测。

随着深度学习的发展，深度卷积神经网络(Deep Convolution Neural Networks, DCNN)同样能够用于单独处理图像去噪问题，并且具有更好的去噪效果和更快的去噪速度。在图像去噪任务方面，研究学者们提出了一系列基于 DCNN 的深度去噪方法，如 DnCNN^[16]、FFDNet^[17]、MSSNet^[18]、ADNet^[19]和 DPDNN^[20]等。DnCNN 采用 17 层卷积层和残差学习的思想从噪声图像中分离出噪声映射图，更好地去除噪声，但可能会导致细小的图像纹理丢失。FFDNet 提出一个快速灵活的去噪卷积神经网络，该网络以可调节的噪声水平图与下采样子图像作为输入进行去噪，不仅实现灵活地去除不同等级的噪声，同时能够鲁棒地控制去噪和细节保留之间的平衡。DPDNN 提出基于去噪的图像复原算法，利用多尺度特征和迭代求解结构将算法展开成深度神经网络。该网络不仅拥有深度神经网络强大的去噪能力，还采用了观测模型的先验特征，使得其在经典复原任务上取得优越的结果。ADNet 提出了一种注意力引导的去噪卷积神经网络，通过将浅层特征与深层特征转化为权重向量相乘来实现通道级的自注意，加深了浅层网络对深层网络的影响，并在去噪任务中表现优异。上述基于 DCNN 的深度去噪方法得益于端到端的训练，有效地提取出图像上更多的细节特征，能够为正则化模型提供更好的去噪先验。因此，一些学者将 DCNN 作为深度去噪器用于解决正则化模型经分裂变量算法后得到的去噪子问题，也灵活的利用保真项确保图像复原符合退化逆求解过程，从而完成不同的 M 所对应的图像复原任务。如 IRCNN^[21]提出一种学习小噪声水平间隔的 7 层去噪网络，采用扩张卷积和残差学习更好地捕捉大范围的图像特征，将训练后的去噪网络用于解决 HQS 分裂算法中的去噪问题，利用 DCNN 高效的去噪效率能够灵活且快速地应对图像去模糊或超分辨率任务。Li 等人采用 IRCNN 深度去噪器解

决 Split Bregman 分裂算法中的去噪问题^[22]，图像修补实验结果表明该方法在视觉质量和客观指标方面都取得非常可观的结果。与传统正则化方法相比，DCNN 在复原性能上都有了显著提升，能够较好地复原出原始图像的细节纹理。然而，受制于有限范围的卷积感受野，DCNN 并不能有效地建立全局图像上像素间的联系，难以提取图像的全局特征信息，一定程度上限制了其在图像去噪和去模糊方面的性能。

作为 DCNN 的替代方案，Transformer^[23]设计了一种自注意力(Self Attention, SA)机制来捕捉语言序列上下文信息间的全局相关，并在图像分类、缺陷检测等视觉任务中显示出良好的性能^[24-26]。用于视觉上的自注意力机制通过对图像上所有像素点的加权和来计算给定像素处的响应，建立单像素点和全像素点之间的联系。尽管 SA 在对远程像素依赖关系建模方面非常有效，但其复杂性随着空间分辨率呈二次增长，因此难以应用于高分辨率图像复原。为了减轻运算成本，如 Restormer^[27]提出一种高效的 Transformer 用于图像恢复，它通过多头深度卷积转置注意力，跨特征维度而不是空间维度应用 SA 来隐式地模拟全局上下文，实现建模全像素连通性的同时仍然适用于大图像。应用在图像恢复任务上的 Vision Transformer^[28-30]通常将输入图像分割成固定大小（如 48×48 像素值）的方块特征，并在每个小块上独立计算 SA。但这种划分方块的策略使得边缘像素不能与方块外的邻近像素建立联系，因此可能会导致复原后的图像在每个方块的周围引入边界伪影，对于纹理和边缘等局部特征表示并不是最优的。为此，Swin Transformer^[31]引入了窗口和移动窗口的自注意力，如在 8×8 的小窗内计算 SA 后，通过滑动窗口的策略实现了边缘像素跨窗口间的联系，有效避免边界伪影的同时能够减少计算量。如文献^[32,33]使用 Swin Transformer 作为主干的基本块对图像特征图进行深层次提取，有效地恢复出图像的细节特征。

深度神经网络方法支持端到端的训练方式，拥有高效的学习能力、自动提取特征和泛化能力强等优点。同时正则化框架可以采用许多数学方法以及性能更好的深度神经网络去噪器对图像复原模型进行求解。因此，基于深度神经网络的特征表达力强和现有正则化框架理论体系完备的优点，本文研究了深度神经网络算法和正则化框架以准确恢复图像的细节特征，为后续目标检测模块提供对比度高、特征明显的清晰图像。

1.3 锂电池极片表面检测的研究现状及分析

在锂电池生产过程中极片的缺陷检测是不可或缺的环节。依据检测结果的分析，企业通过优化工艺流程来提升产品的出厂合格率。随着计算机硬件性能的提高推动着图像检测技术的快速发展和广泛应用，基于视觉的缺陷检测主要分为两类方法：一种是传统视觉缺陷检测方法，另一种是基于深度学习的缺陷检测模型。

（1）传统视觉缺陷检测

传统视觉缺陷检测的主要步骤由三个部分组成：图像预处理、缺陷特征的提取以及特征检测。孙正军等人^[34]基于 SUSAN(Smallest Univalued Segment Assimilating Nucleus) 算子和中值滤波，针对锂电池电极片缺陷提出了自适应边缘检测算法。但所提出的方法存在耗时较长、检测精度不足和检测类别较少的问题。刘学山等人^[35]设计出一个锂电池电极表面缺陷检测系统，其中包括图像预处理、图像分割、特征提取、缺陷分类。但该系统内算法只能实现部分缺陷检测，存在处理速度慢和精度低等缺点。刘妍等人^[36]基于同轴光源和面阵工业相机搭建了亮度均匀的采集环境，并在此成像基础上接入了图像处理算法和后端执行模块，从而设计出一个电池极片涂布缺陷检测系统。该系统采用了中值滤波去除采集图像的孤立点噪声，同时采用差影法对采集图像和背景蒙版进行计算，区分出确定的 ROI(Region of interest)区域。随后在 ROI 区域中补强缺陷细节，并对缺陷进行标记后提取标记缺陷所对应的统计特征，如重心位置、圆形度等。将这些特征作为样本输入到决策树分类器中，最后成功地将划痕、露箔、颗粒、裂纹这四类缺陷检测出来，分类正确率达到了 96%。但由于其人工提取的特征缺陷样本量不多，且缺陷特征形状单一，因此该方法的泛化检测能力有待进一步提高。Gisela Lanza 等人^[37]采用了单点分析技术实现了锂电池极片表面颗粒和划痕缺陷的自动检测。但随着生产工艺的日益复杂，仅依赖单点分析法是不足以应对现代工业生产中的多样化缺陷检测任务需求。赵晓云^[38]使用中值滤波进行预处理来去除噪声，并且采用 Sobel 算子来提取缺陷边缘。处理后的图像通过背景模板匹配判断极片表面是否存在缺陷，并依据轮廓形状分布和像素阈值判断缺陷种类，实现了露铜、极耳带料、气泡、白/黑点和白色/黑色条纹的分类识别。但该项研究的阈值分割时会剔除掉像素点在阈值附近的缺陷，同时缺乏足够样本验证，存在鲁棒性较差和泛化性不高的缺点。王

露^[39]同样采用滤波进行图像预处理，后续通过 Sobel 算子和自适应阈值分割算法完成缺陷轮廓的提取，并使用优化的 K-Means 算法进行缺陷的形态学特征提取，并融合灰度特征后放入 SVM(Support Vector Machine)分类器进行分类识别。有效地改善了光照不佳影响分类准确率的问题，实现了锂电池极片的暗斑、漏金属和划痕三种缺陷的识别检测，分类准确率达到 94.43%。但该研究样本种类较少，且没统计缺陷轮廓的数据，导致泛化性能较差。基于传统视觉的缺陷检测方法需要耗费大量时间进行人工提取图像特征，存在样本量少、效率低等问题，在检测复杂缺陷特征时鲁棒性较差，难以适应当前锂电池极片的生产发展。

(2) 基于深度学习的缺陷检测

随着图形处理器(Graphics Processing Unit, GPU)对图像的计算能力越来越强，利用深度学习进行目标分类与识别方法被广泛地应用到缺陷检测中来。基于深度学习的缺陷检测方法依托海量的数据集，以端到端的形式自动学习复杂的缺陷特征。该方法有效地解决了样本量少和人工设计特征的问题，具有良好的鲁棒性和泛化性能。因此，深度学习方法在缺陷检测领域具有显著优势，并逐渐成为了目标检测研究的重点。基于深度学习的目标检测方法主要根据过程划分为二阶段检测和一阶段检测的方法，比如二阶段检测算法在第一阶段中先计算出一系列候选框定位 ROI 区域，在第二阶段再对候选框进行精确的边界框回归和类别预测。2014 年 Ross Girshick 率先将卷积网络应用于目标检测，提出了著名的两阶段检测算法 RCNN(Regions with CNN features)网络^[40]。该网络通过选择性算法筛选对象框并放入卷积神经网络进行特征提取，最后通过分类器进行预测。实验表明在 VOC-07 数据集上的平均精度由 33.7%提升到 58.5%，相比较于传统方法而言提升了 24.8%。基于深度学习的检测方法在检测精度上取得了质的飞跃，随后的 Fast RCNN^[41]、Faster RCNN^[42]以及 Mask RCNN^[43]均在 RCNN 的基础上进行一系列的优化以进一步提高检测精度。而研究学者们也尝试将二阶段检测算法应用在锂电池表面缺陷检测领域中，提高工业生产中的检测效率和精度。李瑞坤^[44]在 Faster R-CNN 网络的基础上，设计了卷积稠密连接提取高分辨率特征图中的局部特征和低分辨率特征图中的映射的全局特征形成多尺度信息交流，有效解决锂电池表面缺陷尺寸差距过大带来的检测困难。但该网络的检测速度相对较慢，处理一组图片需要约 4 秒，检测准确度最高为 95.88%。封学勇^[45]将 Cascade R-CNN 网络应用于柱形锂电

池钢壳表面缺陷,通过调整数据集标注问题和置信度阈值,在六种缺陷的检测中模型漏检率为 6.21%,误检率为 3.91%,减少了网络的漏检和误检的情况。

与二阶段检测算法不同,一阶段检测算法省略了候选框的生成步骤,直接从输入图像生成目标类别和边界框预测结果,具有更高的检测效率。经典的一阶段检测算法之一是 YOLO(You Only Look Once)系列算法,该系列中最早的 YOLOv1 是由 J.Redmon 等人^[46]提出。YOLOv1 采用单级卷积神经网络提取目标特征,其预测目标时是在每个网格中直接输出预测的目标框和置信度,该算法简单且检测速度快,可在端与端之间直接优化^[47,48]。张旭^[49]针对铝型材数据集的缺陷尺度差异大和传统算法检测速度缓慢的问题,提出了一种改进的 YOLOv3 网络。该网络结合锚点框的设计思想和感受野的理论知识,在三个尺度上各新增一个锚点框来提高网络的小目标检测能力。实验结果表明优化后的 YOLOv3 网络对铝型材数据集的小缺陷的检测精度比优化前的提高了 3.4%,平均检测精度达到了 87.1%。Hu Haibing 等人^[50]提出了一种改进的 YOLOv5s 的锂电池钢壳缺陷检测模型 Sim-YOLOv5s,针对类似缺陷容易出现漏检或误检的情况,通过结合快速的空间池金字塔结构(Sim Spatial Pyramid Pooling layer, SimSPPF)与注意机制卷积块注意模块加快模型收敛,并且进行了跨层连接操作,将浅层特征信息与深层特征信息融合,实验结果表明该模型达到了 88.3%的平均检测精度,比原始的 YOLOv5s 提高了 6.9%。Yang Yatao 等人^[51]提出了一种基于改进 YOLOv5 算法的新模型,为了针对锂电池极杆激光焊接中小缺陷与实际工业生产要求,使用 6×6 的卷积核与改进后的 SPPSE 模块、RepVGG 模块提高模型对小缺陷检测能力和推理能力,并且采用 SIoU(Scale-Invariant IoU)作为边界盒回归损失函数,提高模型的准确率和训练速度。实验结果表明改进算法在数据集上实现了 97%的平均检测精度,比原始 YOLOv5 的检测精度提高了 1.1%,并且推理速度保持在 2ms 以内,每秒 270 张检测图像,完全能够进行实时工业检测。

传统视觉检测方法能用已有的数学方法进行求解,但存在着实时性差,效率低等问题。而深度学习的缺陷检测方法通过图像数量较多的数据集来学习复杂多样的缺陷特征,具有较好的检测精度和广泛适用性,进而愈发地被应用到缺陷检测当中。相对于两阶段检测算法,一阶段检测算法在缺陷检测中表现出了更低的复杂度和更高的效率,更能满足工业产线上对于检测快速性的要求。因此,本文研究深度学习框架下的

一阶段检测算法以精准检测出锂电池极片图像上存在的缺陷类型位置信息，有效地为后续产线优化调整提供数据支撑。

1.4 本文主要研究内容与结构安排

本论文研究的面向锂电池涂布过程的视觉缺陷检测方法主要包括图像复原模块和图像识别模块两部分。其中图像复原模块旨在从观测图像中复原出原始干净的图像，以便后续图像识别模块使用；图像识别模块设计高精度的识别方法，完成缺陷特征的快速精准识别，提高生产可靠性。本文的结构安排如图 1-4 所示，主要内容安排如下：

第一章首先介绍锂电池极片缺陷检测的背景、目的和意义，接着分析了图像复原算法和目标检测算法的研究现状，最后对后续章节的安排和研究内容进行了介绍。

第二章研究了一种双 U 型多尺度信息融合网络的图像复原方法。首先，内 U 结构作为全局特征提取模块，通过 CSC-Block 的移动窗口自注意力和深度可分离卷积的门控调节抓取更精细的全局图像特征；其次，外 U 结构作为局部特征提取模块，通过 MR-Block 的多重跳跃连接深度卷积块学习相邻空间像素间的关联，提取图像的局部特征；第三，空间特征融合模块通过 DRSFT-Block 调节内 U 和外 U 结构的输入图像信息，将局部信息融入全局特征当中，增强了模型的特征表达能力。实验结果表明，相较于其他复原算法，本章所提出的网络具有更强的去噪性能，同时能够保留原始图像上的一些细小纹理特征，为后续锂电池极片图像检测缺陷的准确性奠定了基础。

第三章研究了一种基于深度去噪先验的伪逆变换图像复原方法。首先，通过伪逆变换将线性算子 M 的保真项构造伪逆保真项，消除线性算子 M 不可逆的影响；其次，采用迭代交替最小化的算法框架分裂出两个子问题；第三，采用不同尺度间信息互补的思想设计了跨尺度的深度卷积神经网络，增强对图像整体特征信息的抓取能力。该网络作为深度去噪器解决其中的去噪子问题。实验结果表明，本章所提出的结合深度卷积神经网络的正则化图像复原模型具有更强的去除强模糊和小噪声的性能，同时拥有细节保持的能力，为后续提供清晰度高、特征明显的锂电池极片图像进行缺陷检测。

第四章研究了一种聚合分发信息融合的目标检测网络 YOLOv8s_AD。首先，使用了 DSCDownsample 下采样模块通过不同分支的不同卷积尺度提取多种感受野信息，充分利用图像的空间特征信息，更多地抓取图像中的目标特征信息；其次，通过

C2f_CDW 和 C2f_CIB 采用全局特征分流与局部残差连接的方式，整合浅层局部特征信息和深层整体特征信息，有助于提高网络的检测性能和表示能力；第三，颈部结构中通过 Cross_Neck 模块实现不同层级间信息交互，全局融合各个尺度间的特征信息，增强网络的全局特征提取的能力。实验结果表明，该网络有效提高了锂电池极片图像缺陷的检测精度，有效减少了漏检和误检情况的发生。

第五章总结与展望。对本文的相关工作及内容进行总结，讨论研究存在的不足，并提出了进一步研究方向的分析和展望。




图 1-4 论文结构安排

第二章 双 U 型多尺度信息融合网络的图像复原方法

2.1 引言

由于卷积神经网络只能提取感受野内的局部信息，难以建立全局图像上不同位置的特征信息联系，进而限制了网络在图像去噪方面的性能。而基于窗口自关注的 Transformer 能够在图像全局范围内建立像素间多级联系，但在捕获局部响应和空间上下文方面仍然存在一定的局限性。为了解决这些问题，本文提出了一个新的有效结合 Transformer 全局建模能力与 CNN 局部建模能力的双 U 型多尺度信息融合网络 SCSNet。该方法包括内 U 全局特征提取、外 U 局部特征提取和空间特征融合三个部分。首先，内 U 全局特征提取模块由 CSC-Block 组成，通过移动窗口自注意力和深度可分离卷积的门控调节提高了全局特征的代表能力；其次，外 U 局部特征提取模块由 MR-Block 组成，通过构建卷积块的多重跳跃连接更好提取局部特征信息；第三，空间特征融合由 DRSFT-Block 组成，自适应调制融合不同尺度下的全局和局部特征信息，从而更好地复原出整体图像特征。

2.2 双 U 型多尺度信息融合网络设计

结合 Swin Transformer 移动窗口的全局自注意机制与卷积局部抓取特征的能力，本文提出了双 U 型多尺度信息融合网络 SCSNet，如图 2-1 所示。退化图作为网络输入，通过双 U 结构和空间特征融合结构提取图像的全局-局部特征与信息统合，同时采取跳跃连接丰富同一尺度下的不同特征图间的沟通联系，有效提升网络对图像的复原性能；SCSNet 共有四个尺度，采取上/下采样的操作逐级充分利用从浅层到深层的多尺度、分层特征信息，使网络学习更深层次的图像特征，有利于细微的图像细节的保持；最后由双 U 结构所提取的特征图与原始浅层特征三者相叠加，从而获得噪声去除和细节保持的平衡，更好地恢复图像。




图 2-1 双 U 型多尺度信息融合网络结构

(1) 内 U 全局特征提取模块：在 CSC-Block 中，如图 2-2 所示，采取了一种并分路结构，其中一个分路是全局分路，包含门控 Swin Transformer 层（Gate Swin Transformer Layer, G-STL）来抓取更精细的全局图像特征。另一个分路是局部分路，结合普通卷积和深度可分离卷积提取细微的局部信息来完善全局图像特征。




图 2-2 CSC-Block 模块结构图

全局分路的 G-STL 是引入了基于原有的 Transformer 层中标准多头自关注所改进的移动窗口自注意力，通过非重叠的局部窗口中计算注意力来降低计算复杂度，同时采取移位窗口划分来保持非重叠窗口间的像素联系，旨在提高网络对图像全局特征信息的提取和融合能力。在自注意力计算中，若输入特征图大小为 $F \in R^{H \times W \times C}$ ，那么将会通过 $M \times M$ 个不重叠的局部窗口将输入的总特征图大小转化为 $F \in R^{\frac{HW}{M^2} \times M^2 \times C}$ 。接着，与标准多头自关注的原理无异，它分别计算出每个局部窗口内特征图 $F_{local} \in R^{M^2 \times C}$ 的

自相关，则每个窗口内其查询矩阵、键矩阵与值矩阵 Q 、 K 、 V 分别是

$$Q = F_{local}P_Q, K = F_{local}P_K, V = F_{local}P_V \quad (2-1)$$

其中 P_Q ， P_K 与 P_V 分别是在每个局部窗口内共享的投影矩阵。因此，每个窗口便由 $Q, K, V \in R^{M^2 \times d}$ 来根据注意力机制计算出如下注意矩阵。

$$Attention(Q, K, V) = SoftMax(\frac{QK^T}{\sqrt{d}} + B)V \quad (2-2)$$

其中 B 是相对位置编码信息， d 是窗口内像素展开成一维后的维度数。在代码中，本文一致地将该注意矩阵执行 n 次并将得到的多头自注意力（Multi-Head Self Attention, MSA）结果均相加连接起来得到最终自注意矩阵。

在得到自注意力后续的特征提取方面，G-STL 采用了基于可深度分离卷积的门控调节 (Depthwise Convolution Gating, DCG)。特征图进行多头自相关后通过深度卷积对输入的每个通道进行独立的卷积操作，使得深度卷积只捕捉空间特征而不混合通道信息，再由并行分流的结构来控制着不同分支的特征流，从而使全局自注意特征专注于补充分控特征流的细微特征，得到更丰富的全局特征信息。具体来说，DCG-Block 对输入通道扩展成特征通道（本章设置扩张因子 $\gamma = 3$ ）后分化为两条平行通道，两条通道前端均使用两个 1×1 卷积与 3×3 的深度可分离卷积，促使其调节到空间相近的像素信息，同时也能够帮助其有效恢复局部特征。而后其中一条分路用于 GELU 非线性函数激活，另一条分路用于与经过非线性激活的信息进行逐元素点积，从而更细致地捕捉图像中的细节信息。若输入为 $F \in R^{H \times W \times C}$ ，再经过拓展后变为 $F_{in} \in R^{H \times W \times \gamma C}$ ，那么 DCG 块操作如下：

$$\hat{F} = Gating(F_{in}) + F_{in} \quad (2-3)$$

$$Gating(F_{in}) = C_{1 \times 1}^1(\varphi(C_{dw-3 \times 3}^1(C_{1 \times 1}^1(F_{in}))) \odot (C_{dw-3 \times 3}^1(C_{1 \times 1}^1(F_{in}))) \quad (2-4)$$

其中，输出特征图为 $\hat{F} \in R^{H \times W \times C}$ ， φ 代表 GELU 激活函数， $C_{dw-3 \times 3}^1$ 表示步长为 1 的 3×3 的深度可分离卷积层。

在局部分路的 SDCL 块中，通过采用首尾的 1×1 和 3×3 普通卷积来对所有特征图的不同通道提取局部信息，有效地建立通道间的特征联系。而中间的 3×3 的深度卷积关注特征图的空间特征，进一步提升 SDCL 块对局部区域的信息提取能力。通过全局分路来捕获图像的全局特征后，结合局部分路所带来的通道-空间的局部信息，使得整

个内 U 结构提取的全局特征更加丰富。

(2) 外 U 局部特征提取模块：MR-Block 是根据残差网络(Residual Network, ResNet)^[52]的残差学习思想进行设计的，主要采用单个 1×1 卷积和多个多头残差连接的 DDCL 块构成外 U 模块的深层结构，如图 2-3 所示。




图 2-3 MR-Block 模块结构图

在 MR-Block 中将内 U 模块所提取的全局特征和上一尺度传递的局部特征进行通道拼接后，采用 1×1 卷积对拼接特征进行通道降维处理，同时能够有效地促进全局特征和局部特征的融合。DDCL 块中包含一个 3×3 的卷积层，两个 1×1 的卷积层和两个 3×3 深度可分离卷积层，首尾采用 1×1 的卷积层能够高效地融合前端输入和中间输出的局部特征信息， 3×3 的深度卷积不仅显著降低卷积层的计算复杂度，还单独学习相邻空间像素间的关联，提高了外 U 模块的局部建模能力，有助于增强外 U 模块提取局部特征的能力。

(3) 空间特征融合模块：DRSFT-Block 如图 2-4 所示，通过第一个 RSFT 块将全局特征和局部特征进行调制融合，再经过 1×1 的卷积层融合输出特征后，然后采用第二个 RSFT 块将输出特征和原始输入的局部特征再次调制融合，同样后续经过 1×1 的卷积层融合特征信息。这个操作能够有效地调节多尺度所提取的不同种类的特征信息，有助于将局部信息融入全局特征当中，提高模型的鲁棒性和泛化能力。




图 2-4 DRSFT-Block 模块结构图

RSFT 块共有两条分支，第一个分支的全局特征信息与第二分支里第一通路的局部信息 α 进行元素乘积相联后，引入残差连接促进浅层信息传递，然后通过 1×1 的卷积层融合操作后的全局特征信息再与第二分支里第二通路的局部信息 β 相加，有效促进特征相融合的过程。第二个分支的两条通路分别采用一个 3×3 的卷积层和一个 1×1 的卷积层，将局部特征映射成两个调制系数 α 和 β ，并与第一个分支信息进行调制融合，提高了网络对细节特征信息的抓取能力，实现了不同层级的特征交互，增强了模型的特征表达能力。

2.3 实验结果与分析

考虑到深度神经网络能够从噪声/干净图像对中学习其关系映射，越丰富的图像信息将会有利于其学习。因此，本章选取了具有丰富场景的图像作为训练集，分别选取来自 Waterloo Exploration 数据库^[53] 的 4744 张图像，来自 DIV2K 数据集^[54] 800 张图像，来自 Flickr2K 数据集^[55] 2650 张图像与来自伯克利分割数据集(Berkeley Segmentation Dataset, BSD)图像^[17]400 张图像，训练图像一共是 8594 张，覆盖了种类多样的特征景象。为了进一步增强网络的特征提取能力，训练时会随机从干净图像的随机位置提取大小为 128×128 的图像块，同时对图像块进行随机的几何旋转与翻转，并加入噪声等级为 σ 的高斯噪声合成对应的噪声图像，形成一一对应的图像对后放入网络中训练。在

参数设置上, 本章将窗口大小设置为 8×8 , 注意力的头数设置为当前层内通道数的一半。优化器采用 Adam, 损失函数采用 ℓ_1 损失来优化参数^[56]。学习率从 1×10^{-4} 开始, 每 20 万次迭代衰减 0.5 倍, 最终学习率小于 3.125×10^{-6} 时停止迭代。

本章均在 PyTorch 框架上使用显卡型号为 NVIDIA GeForce RTX 3090 GPU(24G 显存)的计算机进行所有实验。实验所采用的噪声干扰是加性高斯白噪声, 测试实验时分别采用的噪声水平是 $\sigma = 15$ 、25 和 50。客观评价指标采用峰值信噪比(Peak Signal to Noise Ratio, PSNR)和结构相似性(Structural Similarity, SSIM)。为了公平比较, 实验结果均采用作者论文中的结果或采用作者公开的源代码运行结果。

2.3.1 标准灰度图像实验结果及分析

本小节实验所采用的测试集为 Set12 的 12 幅图像、BSD68 的 68 幅图像和 PIPAL^[57] 的 200 幅图像, 这三个测试集均覆盖丰富的场景, 有助于验证所提出方法的有效性。在相同的实验条件下, 本章将提出的 SCSNet 和几种先进的的复原方法进行比较, 包括传统的模型 BM3D, 一系列基于 CNN 的模型如 DnCNN、FFDNet、DPDNN、BRDNet^[58]、DeamNet^[59]、DAGL^[60]和 DRUNet^[61]。

表 2-1 至表 2-2 列出了不同方法在三个不同测试集上复原的平均 PSNR 和 SSIM 结果, 其中最好的结果进行加粗表示。从表 2-1 可以看出, SCSNet 在大部分测试集上取得了最好的结果, 优于其它方法 0.05dB 至 0.2dB。特别地, SCSNet 在小噪声水平 $\sigma = 15$ 和 25 的 PSNR 去噪结果大幅高于其它方法, 这得益于内 U 结构中 CSC-Block 窗口和移动窗口的自注意力机制能够有效地结合图像全局位置的特征信息, 达到更好的去噪效果。从表 2-2 可以看出, 借助于外 U 结构中 MR-Block 的多头残差局部特征提取和空间模块 DRSFT-Block 的信息融合, SCSNet 在小噪声水平 $\sigma = 15$ 和 25 条件下取得了最佳的实验结果, 相比于传统模型 BM3D 高 0.0147 和 0.0226, 比 DnCNN 高 0.0084 和 0.0124, 拥有较好的细节保持能力。但是从表 2-1 和表 2-2 的大噪声水平 $\sigma = 50$ 条件下来看, SCSNet 复原后实验结果略低于 DRUNet。这是因为在大噪声下整幅灰度图像的各位置像素信息都受到较大的干扰, SCSNet 的内 U 模块通过不同位置的像素信息提取到较少原图的全局特征信息, 难以精确地分辨出原特征与噪声特征。而 DRUNet 通过堆叠多个残差卷积块能更好地保留先前所提取的局部特征信息, 在强噪声干扰全局图像时局部连接建模更具有优势, 有利于处理大噪声干扰图像。

表 2-1 不同灰度测试集下各算法对比的平均 PSNR 结果

Datasets	σ	BM3D	DnCNN	FFDNet	DPDNN	BRDNet	DeamNet	DRUNet	DAGL	SCSNet
Set12	15	32.39	32.85	32.74	32.95	33.03	33.19	33.25	33.27	33.32
	25	29.97	30.43	30.42	30.54	30.61	30.81	30.94	30.90	30.99
	50	26.74	27.17	27.30	27.44	27.45	27.74	27.90	27.76	27.90
BSD68	15	31.13	31.74	31.64	31.79	31.79	31.91	31.91	31.92	31.95
	25	28.61	29.23	29.19	29.28	29.29	29.44	29.48	29.46	29.50
	50	25.69	26.24	26.29	26.36	26.36	26.54	26.59	26.52	26.57
PIPAL	15	31.04	31.56	31.47	31.69	31.71	31.86	31.91	31.96	31.98
	25	28.33	28.81	28.81	28.93	28.97	29.18	29.28	29.29	29.34
	50	24.95	25.35	25.50	25.58	25.59	25.86	25.98	25.92	25.98

表 2-2 不同灰度测试集下各算法对比的平均 SSIM 结果

Datasets	σ	BM3D	DnCNN	FFDNet	DPDNN	BRDNet	DeamNet	DRUNet	DAGL	SCSNet
Set12	15	0.8962	0.9025	0.9024	0.9055	0.9050	0.9092	0.9098	0.9097	0.9109
	25	0.8515	0.8617	0.8631	0.8655	0.8652	0.8712	0.8732	0.8718	0.8741
	50	0.7660	0.7828	0.7899	0.7954	0.7930	0.8052	0.8096	0.8040	0.8094
BSD68	15	0.8751	0.8907	0.8902	0.8928	0.8921	0.8952	0.8952	0.8952	0.8959
	25	0.8038	0.8279	0.8288	0.8300	0.8305	0.8368	0.8371	0.8364	0.8378
	50	0.6886	0.7189	0.7239	0.7266	0.7261	0.7364	0.7378	0.7328	0.7371
PIPAL	15	0.9090	0.9167	0.9170	0.9201	0.9194	0.9223	0.9232	0.9228	0.9239
	25	0.8486	0.8625	0.8649	0.8666	0.8673	0.8732	0.8759	0.8744	0.8766
	50	0.7275	0.7508	0.7596	0.7642	0.7628	0.7754	0.7811	0.7746	0.7806




图 2-5 不同方法对“A0099”图像的灰度去噪视觉对比结果

为了直观地感受 SCSNet 的复原效果，本节从 PIPAL 测试集中选出的“A0099”图像后添加了噪声水平 $\sigma=50$ 的加性高斯白噪声，并将其由不同方法进行去噪，视觉结果如图 2-5。从放大区域中可以看出，BM3D 过度平滑了细节特征，难以保留原有的瓦

片纹理细节。而 DnCNN、FFDNet、DPDNN 和 DeamNet 则复原出过度光滑的边缘和纹理。尽管 DRUNet 和 DAGL 能够保留住较突出的瓦片细节，但是在恢复边缘处的纹理效果并不理想。SCSNet 在保留边缘和纹理结构方面非常有效，其通过外 U 结构所提取的局部特征来完善内 U 结构中所提取的全局特征信息，去除图像噪声的同时又极大程度地保留下原有图像的瓦片细节特征。

2.3.2 标准彩色图像实验结果及分析

本小结实验选取了 Set14^[62]、CBSD68^[63]、PIPAL、CC^[64]以及 PolyU^[65]作为测试集。而 Set14 中存在两张灰度图，因此将其剔除后并重新将该测试集命名为 CSet12。本章将提出的 SCSNet 与传统方法 CBM3D，基于 CNN 的模型如 DnCNN、IRCNN、FFDNet、ADNet、BRDNet 和 DRUNet 进行比较。表 2-3 至表 2-4 展示出了不同方法在五个不同测试集上复原的 PSNR 和 SSIM 结果，其中最好的结果进行加粗表示。

表 2-3 不同彩色测试集下各算法对比的平均 PSNR 结果

Datasets	σ	CBM3D	DnCNN	IRCNN	FFDNet	ADNet	BRDNet	DRUNet	SCSNet
CSet12	15	33.15	32.34	33.30	33.25	33.60	33.73	34.02	34.16
	25	30.92	30.53	31.06	31.15	31.39	31.55	31.92	32.01
	50	27.96	27.81	28.03	28.27	28.42	28.56	29.14	29.15
CBSD68	15	33.55	33.90	33.87	33.88	33.95	34.10	34.30	34.38
	25	30.80	31.24	31.18	31.22	31.28	31.43	31.69	31.74
	50	27.49	27.95	27.88	27.97	28.02	28.16	28.51	28.52
PIPAL	15	32.99	32.81	33.34	33.38	33.52	33.71	33.97	34.09
	25	30.32	30.32	30.60	30.71	30.81	31.01	31.35	31.45
	50	26.85	26.96	27.08	27.24	27.33	27.50	27.98	28.01
CC	15	39.76	39.53	39.61	40.18	40.15	40.31	41.23	41.36
	25	37.08	36.95	36.93	37.59	37.56	37.77	38.90	39.02
	50	33.22	33.13	33.13	33.92	33.88	34.11	35.63	35.73
PolyU	15	41.20	40.95	40.99	41.48	41.40	40.95	42.22	42.34
	25	38.68	38.59	38.63	39.29	39.21	39.32	40.43	40.51
	50	34.86	34.89	35.03	35.98	35.86	35.98	37.78	37.84

从表 2-3 和表 2-4 的实验结果可以看出，相较于对比的算法，本章所提出的方法在不同的噪声水平干扰的大多数测试集中均取得了最佳的 PSNR 和 SSIM 结果。值得注意的是，与上小节中表 2-1 和表 2-2 的大噪声条件下的实验结果不同，SCSNet 受大噪声的干扰下仍在大部分的彩色测试集中取得了最优的 PSNR 和 SSIM 结果，这是因为输入由单通道的灰度图像转变成三通道的彩色图像，SCSNet 中的内 U 模块能够从多通道中

提取到更有效的全局先验信息，进而结合外 U 模块的局部信息进行完善，丰富了一系列的特征图信息。总的来说，本章提出的 SCSNet 具有强去噪能力的同时，还能保留住更多的原始图像特征。

表 2-4 不同彩色测试集下各算法对比的平均 SSIM 结果

Datasets	σ	CBM3D	DnCNN	IRCNN	FFDNet	ADNet	BRDNet	DRUNet	SCSNet
CSet12	15	0.8968	0.8852	0.8983	0.8988	0.9036	0.9051	0.9113	0.9128
	25	0.8554	0.8504	0.8599	0.8612	0.8655	0.8678	0.8759	0.8765
	50	0.7797	0.7793	0.7877	0.7926	0.7965	0.7992	0.8151	0.8146
CBSD68	15	0.9239	0.929	0.9285	0.9290	0.9298	0.9313	0.9344	0.9352
	25	0.8703	0.883	0.8824	0.8821	0.8843	0.8873	0.8926	0.8934
	50	0.7680	0.790	0.7898	0.7887	0.7936	0.7969	0.8103	0.8103
PIPAL	15	0.9376	0.936	0.9414	0.9424	0.9437	0.9452	0.9486	0.9495
	25	0.8973	0.898	0.9036	0.9051	0.9073	0.9105	0.9166	0.9175
	50	0.8074	0.814	0.8200	0.8229	0.8269	0.8310	0.8470	0.8473
CC	15	0.9638	0.963	0.9643	0.9678	0.9675	0.9676	0.9732	0.9737
	25	0.9440	0.943	0.9447	0.9511	0.9504	0.9513	0.9600	0.9604
	50	0.8983	0.896	0.8977	0.9152	0.9124	0.9135	0.9332	0.9337
PolyU	15	0.9718	0.970	0.9701	0.9731	0.9724	0.9687	0.9765	0.9769
	25	0.9573	0.956	0.9568	0.9620	0.9611	0.9612	0.9688	0.9690
	50	0.9227	0.922	0.9248	0.9390	0.9363	0.9350	0.9539	0.9544




图 2-6 不同方法对“Sony_4-5_125_3200_plant_14”图像的彩色去噪视觉对比结果

图 2-6 展示了不同方法对受到噪声水平 50 所干扰 PolyU 数据集中“Sony_4-5_125_3200_plant_14”图像的去噪视觉效果对比。从整体图像可以观察到，CBM3D、DnCNN 和 IRCNN 的去噪效果较差，图像中仍留有一些噪声。从局部放大图可以看到，FFDNet、ADNet 和 BRDNet 能够去除图像上的噪声，但其过度光滑了原本叶片的纹理

细节。DRUNet 具有强有力的去噪效果，但也仅保留了原始图像的一条叶脉纹理。而本章所提出的 SCSNet 得益于内外双 U 结构的信息互补，不仅去噪效果好，还能恢复锐利的边缘和两条微小的叶脉纹理，实现了去噪效果和微小特征保持之间的平衡。

2.3.3 锂电池极片缺陷图像实验结果及分析

本小节选取锂电池极片缺陷图像的验证数据集作为测试实验数据集，通过添加小噪声模拟电子元器件电子噪声验证算法实用性和大噪声进一步验证算法鲁棒性。

(1) 直观视觉对比实验结果及分析

本小节对工业产线下的大目标漏金属缺陷和小目标凹坑缺陷图像进行实验，噪声水平分别采用 $\sigma = 15$ 、25 和 50，实验视觉结果如图 2-7 和图 2-8 所示。

从整体图像的感观上可以看到，不管是在小噪声还是大噪声的干扰下，SCSNet 仍能有效去除图像上噪声。从小目标缺陷如凹坑的微小特征图中可以看出，SCSNet 复原出的凹坑特征有着保留着原有明显边缘的凹陷纹理和内部破损的细节，复原效果十分明显。实验结果表明，本章提出的算法可以有效地复原图像，保留所需的目标特征。同时 SCSNet 具有大范围的去噪能力和复杂环境的适应性，为后续目标检测提供了特征明显、清晰度高的图像。




图 2-7 极片漏金属缺陷的噪声图和复原图像




图 2-8 极片凹坑缺陷的噪声图和复原图像

(2) 退化图与复原图的检测实验结果及分析

为了更客观地体现出本章算法的实用性，本小节采用不同噪声水平干扰的极片图像和经过本章算法复原后的极片图像进行实验，并且使用基础的 YOLOv8s 检测网络对退化图和复原图分别进行检测对比。噪声水平分别采用 $\sigma = 15$ 、20 和 50，评判指标包括精确度(Precision)、召回率(Recall)、平均检测精度(mAP50)和综合平均检测精度(mAP50-95)，实验结果如表 2-5 所示。

表 2-5 锂电池极片验证集复原前后的检测指标结果

Datasets	σ	Precision(%)	Recall(%)	mAP50(%)	mAP50-95(%)
退化图	15	57.6	0.184	0.149	0.0706
	25	28.6	0.128	0.0129	0.00305
	50	0.0271	0.393	0.0139	0.00334
复原图	15	88.5	86	88	56.6
	25	85.8	83.6	85	53.7
	50	79	71.8	74.7	44

从表 2-5 中看出，在不同噪声等级干扰下，退化图的平均检测精度较低，仅有 0.014%至 0.15%，这表明噪声干扰下的缺陷特征不明显，检测网络难以识别。随着噪声水平的提高，退化图的检测精确度、召回率、平均检测精度和综合平均检测精度都在逐级减少，检测效果并不理想。而经过 SCSNet 进行复原后，在 $\sigma = 15$ 的噪声水平下，检测精确度由 57.6%提高至 88.5%，召回率由 0.184%提高至 86%，平均检测精度由

0.149%提高至 88%，综合平均检测精度更是由 0.0706%提高至 56.6%。在 $\sigma=25$ 的噪声条件下，检测精确度由 28.6%提高至 85.8%，召回率由 0.128%提高至 83.6%，平均检测精度由 0.0129%提高至 85%，综合平均检测精度是由 0.00305%提高至 53.7%。在 $\sigma=50$ 的噪声条件下，检测精确度由 0.0271%提高至 79%，召回率由 0.393%提高至 71.8%，平均检测精度由 0.139%提高至 74.7%，综合平均检测精度更是由 0.00334%提高至 44%。这说明经过 SCSNet 复原后的图像相比于退化图具有缺陷特征明显、轮廓清晰的特点，能够被后续检测网络精确地识别出缺陷类别与位置。

图 2-9 至 2-11 给出了不同噪声下视觉缺陷检测效果比较。从图 2-9 可以看出，噪声等级 $\sigma=15$ 条件下，极片图像中的缺陷特征受到小程度干扰，检测网络仍能识别出图像上有缺陷，但难以正确识别出缺陷的类别和位置。如图 2-9(a)和(c)中，检测网络错误将脱碳缺陷和褶皱缺陷都识别成条痕的缺陷。而在图 2-9(b)中，检测网络则将颗粒缺陷错误地识别成漏金属缺陷。这说明小噪声掩盖了原有缺陷中的一些特征细节，造成后续检测网络的误判。而经过复原后的图像中缺陷具有更加锐利的边缘和明显的纹理细节，有效提升了后续缺陷检测的效果。




图 2-9 噪声水平 $\sigma=15$ 下不同缺陷检测结果

从图 2-10 和 2-11 中看出，由于噪声水平的提高，极片中缺陷的原始特征和像素分布特性受到大幅度的掩盖或扭曲，从而增加了基于特征进行检测的任务难度，因此检测网络在识别退化图的缺陷时均出现了漏检情况。相反，从复原后图像检测效果上看，

得益于 SCSNet 的空间特征融合模块中对全局特征信息和局部特征信息的调制输出，丰富了特征图上的局部细节，所以检测网络不仅能有效地识别出各种缺陷的类别，还能精确定位出缺陷边缘，检测出缺陷的具体位置。




图 2-10 噪声水平 $\sigma=25$ 下不同缺陷检测结果




图 2-11 噪声水平 $\sigma=50$ 下不同缺陷检测结果

2.4 本章小结

本章在 Swin Transformer 的全局建模与 CNN 的局部建模基础上，提出了双 U 型多尺度信息融合网络，该网络以内外双 U 结构聚合图像特征建立信息位置间关系和局部信息响应，从而更有效地获取全局和局部图像特征。通过空间特征融合模块丰富双 U 结构所提取到的图像信息，促进多尺度空间变换的信息融合。实验结果表明，相对于其他方法，本章所提出的网络具有更强的去噪性能，同时能够复原出原始图像上的一些细小纹理特征，为后续图像检测缺陷的准确性奠定了基础。

第三章 基于深度去噪先验的伪逆变换图像复原方法

3.1 引言

基于正则化框架的方法构建图像复原的优化模型，并对该模型进行迭代求解，能够有效地求解不同的逆问题。当模型中存在保真项的线性算子 M 不可逆、正则项先验不理想的情况时，复原的结果也会受到一定影响。针对正则项先验问题，一方面可采用特定正则项进行求解，如采用TV正则项求解，但容易给图像带来阶梯效应。另一方面可不限制某个特定的正则项模型，通过分裂算法将模型分解为两个子问题后，采用去噪器解决去噪子问题。因此，本章设计了基于深度先验的伪逆变换图像复原方法。首先，通过对优化模型中的保真项进行伪逆变换进而消除线性算子 M 不可逆的影响。其次，采用交替最小化迭代方法将模型分解为两个子问题，同时进行迭代求解。第三，采用深度神经网络解决去噪子问题所得到的图像去噪先验，从而有效去除噪声的同时保留原有图像特征细节。尤其地，在正则化框架下，单个原始的图像复原模型能够解决多种退化类型的模糊和噪声的逆问题，克服了端到端网络需要单独训练多个模型来学习不同退化类型的图像才能达到较好效果的问题，实现统一求解。

3.2 深度去噪先验的伪逆变换图像复原模型

为了进一步克服线性算子 M 不可逆所带来的消极影响，提升图像复原模型的有效性，本章引入伪逆矩阵 M^+ 建立起基于深度去噪先验的伪逆变换图像复原模型，优化问题(1-2)中的保真项可等效变换成伪逆保真项，如(3-1)所示。

$$\min_x \left\{ \begin{aligned} E(x) &= \frac{1}{2\sigma^2} \|y - Mx\|_2^2 + \lambda\phi(x) = \frac{1}{2\sigma^2} \|M(M^+y - x)\|_2^2 + \lambda\phi(x) \\ &= \frac{1}{2\sigma^2} \|M^+y - x\|_{M^TM}^2 + \lambda\phi(x) \end{aligned} \right\} \quad (3-1)$$

其中 $M^+ = M^T(MM^T)^{-1}$ 为 M 的伪逆矩阵， $\|u\|_{M^TM}^2 \triangleq u^T M^T M u$ 为半范数， σ 表示加性高斯白噪声水平。

令 $y^+ = M^+y$ ，则 $\min_x E(x)$ 的最优化问题(3-1)转化成关于 x 和 y^+ 的有约束问题(3-2)：

$$\min_{x, y^+} \frac{1}{2\sigma^2} \|y^+ - x\|_{M^TM}^2 + \lambda\phi(x), \quad s. t. \quad y^+ = M^+y \quad (3-2)$$

采用欧几里得范数 $\|y^+ - x\|_2^2$ 代替式子(3-1)中的半范数 $\|y^+ - x\|_{M^TM}^2$ ^[66]，解决 M 不可

逆造成的不适定影响。使用约束条件 $My^+ = y$ 来替代原来的 $y^+ = M^+y$ 来放宽 y^+ 的约束。采用交替最小化方式来求解式子(3-2)，将问题(3-2)转化为两个子问题(3-3)和(3-4)：

$$y_k^+ = \underset{y^+}{\operatorname{argmin}} \|y^+ - x_{k-1}\|_2^2, \text{ s.t. } My^+ = y \quad (3-3)$$

$$x_k = \underset{x}{\operatorname{argmin}} \frac{1}{2\sigma_k^2} \|y_k^+ - x\|_2^2 + \lambda\phi(x) \quad (3-4)$$

式子(3-3)可以看作是 x_{k-1} 到超平面 $My^+ = y$ 的投影，此时投影矩阵 P_M 如式子(3-5)所示：

$$P_M = I - M(M^T M)^{-1} M^T = I - M^T (M M^T)^{-1} M = I - M^+ M \quad (3-5)$$

根据得到的投影矩阵 P_M 通过梯度投影法可求解子问题(3-3)，可解得式子(3-6)：

$$y_k^+ = M^+(y - Mx_{k-1}) + x_{k-1} \quad (3-6)$$

为了解决伪逆矩阵 M^+ 中 MM^T 不可逆带来的运算难题，引入自适应参数 α_k ，则变成式子(3-7)。

$$y_k^+ = M^T (M M^T + \alpha_k)^{-1} (y - Mx_{k-1}) + x_{k-1} \quad (3-7)$$

从贝叶斯的角度来看，式子(3-4)可以描述成使用了方差为 $\sigma^2 = \lambda\sigma_k^2$ 的高斯去噪器^[67]来获得 x_k ，因此本章设计了深度神经网络作为高斯去噪器获得退化图像的去噪先验，有效地提高模型的去噪能力，并将子问题(3-4)改写成式子(3-8)：

$$x_k = D_\sigma(y_k^+; \sigma_k \sqrt{\lambda}) \quad (3-8)$$

式子(3-8)中引入自适应参数 $\beta_k = \sigma_k \sqrt{\lambda}$ ，自适应调整每次迭代中的 σ_k 值和正则化参数 λ ，从而获得更好的去噪先验。两个适应参数 α_k 和 β_k 均由三个全连接层获得，每层的隐藏节点数为 64，前两层全连接层采用 ReLU 激活函数，最后一层使用 Softplus^[68] 激活函数。考虑到 α_k 和 β_k 应该为正数，以及式子(3-7)应避免极小的 α_k ，因此在 Softplus 输出层后面将两个参数额外加了 1×10^{-6} 。

综上所述，基于深度去噪先验的伪逆变换图像复原模型的交替最小化迭代算法流程如表 3-1 所示。

表 3-1 基于深度去噪先验的伪逆变换的图像复原算法流程

基于深度去噪先验的伪逆变换的图像复原算法流程

输入：模糊矩阵 M ，退化图像 y ，正则化参数 λ ，图像噪声 σ ，迭代次数 K 和第 k 次迭代的噪声水平 σ_k

输出：复原后图像 x_k

步骤 1：初始化 $x_0 = y$, $\beta_k = \sigma_k \sqrt{\lambda}$

步骤 2：迭代求解下列式子，循环次数 $k = 1, 2, \dots, K$

$$y_k^+ = M^T(MM^T + \alpha_k)^{-1}(y - Mx_{k-1}) + x_{k-1}$$

$$x_k = \text{Denoiser}(y_k^+, \beta_k)$$

步骤 3：判断截止条件

若满足 $k = K$ ，输出 x_k

3.3 跨尺度信息交互的 U 型网络设计

卷积神经网络通过局部感受野提取特征，在图像去噪时能够更好地保护细节纹理，但在抓取图像整体特征信息方面相对较弱，进而影响对整幅图像的去噪性能。针对这一问题，本章基于 HCF-Block 和 FSF-Block 提出了跨尺度信息交互的 U 型网络 CSUNet，其结构如图 3-1 所示。




图 3-1 跨尺度信息交互的 U 型网络结构

首先，采用 U 型结构对输入图像和自适应参数 β_k 的水平图进行下采样和上采样，

并在不同空间分辨率的特征图中提取图像信息，更加有效地识别不同大小的细节特征；其次，HCF-Block 通过不同大小的残差卷积块与池化层的并行分支分别建立了远距离和短距离的信息联通，加强了不同尺度下特征的提取能力，进而提高了网络对全局和局部信息进行融合的能力；最后 FSF-Block 利用上/下采样操作有效地实现跨尺度的信息交互，将所提取到的不同尺度下特征信息进行互补，增强了对图像整体特征信息的抓取能力，在提高了网络去噪性能的同时，更能够保留原有的细节特征。

(1) HCF-Block 模块：如图 3-2 所示，HCF-Block 是该网络中负责不同维度特征提取的核心模块，主要采用 1×1 残差卷积块、 7×7 残差卷积块、 3×3 池化层和 5×5 池化层抓取全局特征和局部特征，有利于网络获得更全面的图像信息。




图 3-2 HCF-Block 模块结构图

HCF-Block 首先采用 1×1 的卷积对采样后的图像特征进行融合，并进行通道拆分。拆分后，第一个分支采用 1×1 残差卷积块提取输入特征的局部信息，接着通过 3×3 平均池化层和 5×5 平均池化层将像素值与其邻域的平均值进行比较，模拟自注意力的像素比较，增加特征的多样性与丰富性。第二个分支采用 7×7 残差卷积块，扩大卷积层的感受野范围，抓取全局图像特征信息，然后通过层归一化来进行逐通道维度参数更新，有助于提高网络处理不同范围噪声的能力，增强对不同输入的参数 β_k 的适应性。最后将两个分支所收集到的全局特征和局部特征进行拼接后，由 1×1 的卷积进行融合后输出，实现不同层级的信息交互，从而增强网络的去噪性能。

(2) FSF-Block 模块：该模块是引入多级特征组合思想进行设计，它聚合了由不同级别的 HCF-Block 所提取的特征信息，丰富了每个层级的特征图信息，有助于网络保留原有图像细节特征。

如图 3-1 是以第二尺度的 $\text{FSF}_2\text{-Block}$ 为例子，首先是调整由第一尺度和第三尺度分别提取的特征图大小，使得它们等尺寸后相加，得到跨尺度间的特征信息概述。其

次采用 3×3 的残差卷积块对总体的信息概述进行总结，捕获其中的局部特征细节。最后将当前第二尺度的特征信息与跨尺度的局部特征细节进行联通合并，用来自其他级别特征的信息丰富当前尺度下的特征图，旨在增强网络的特征表达能力，从而能在退化图中复原出更多原有的局部细节纹理。

3.4 实验结果与分析

为了 CSUNet 能够更好地学习到图像的特征细节，本章选取的训练集与第二章所使用的一致，并在训练时会随机从干净图像的随机位置提取大小为 96×96 的图像块，也会对图像块进行随机的几何旋转与翻转，随机添加核大小为 25×25 的各向异性高斯模糊^[69,70]，并随机加入区间为 $[0, 25]$ 噪声等级的高斯噪声合成对应的退化图像，形成一一对应的图像对后放入网络中训练。理论上采用尽可能多类型的模糊核和噪声水平进行测试是全面的，但这也会导致繁重的测试过程。因此，本章挑选了具有代表性的 8 个多样化模糊核进行实验，其中包括 4 个宽度不同的各向同性高斯核，即宽度分别为 0.7、1.2、1.6 和 2.0，以及 4 个各向异性高斯核^[71]。具体测试配置如表 3-2 所示

表 3-2 测试实验配置表

参数	配置说明							
训练框架	PyTorch 深度学习框架							
显卡型号	NVIDIA GeForce RTX 4090 GPU(24G 显存)							
噪声等级	2.55 和 7.65							
模糊核类型	各向同性				各向异性			
								

3.4.1 标准彩色图像实验结果及分析

本小节实验所采用的测试集为 PIPAL 的 200 幅图像和 PolyU 的 100 幅图像，这两个大型测试集均覆盖多种类型的对象和场景，有助于验证所提出方法的有效性。在相同的实验条件下，本章将提出的 CSUNet 与几种先进的复原方法进行比较，如盲去模糊的 DMPHN^[72]、大范围非盲图像去模糊模型 DWDN^[73]和基于半二次分裂算法的算法 IRCNN、DPIR 和 USRNet^[74]。

表 3-3 和 3-4 展示出了不同方法在两个不同测试集上复原的 PSNR 和 SSIM 结果，

其中最好的结果进行加粗表示。

表 3-3 不同测试集下各算法对比的平均 PSNR 结果

Method	σ	模糊核							
									
PolyU 测试集									
DMPHN	2.55	24.65	24.42	24.19	24.01	24.00	23.91	23.97	23.84
DWDN		42.96	40.88	39.69	38.43	38.07	37.76	37.76	36.77
IRCNN		40.60	35.57	35.71	35.86	35.75	35.70	35.85	35.89
DPIR		46.22	44.37	42.27	40.62	40.66	39.97	40.01	39.17
USRNet		46.34	44.82	43.75	42.72	42.58	42.26	42.28	41.59
CSUNet		46.52	44.95	43.87	42.86	42.73	42.41	42.43	41.76
DMPHN	7.65	20.44	20.25	20.21	20.24	20.29	20.12	20.45	20.36
DWDN		41.78	39.52	38.16	37.20	37.28	36.80	36.77	36.17
IRCNN		41.16	35.31	34.92	34.95	35.00	35.11	34.91	34.92
DPIR		43.03	41.74	40.08	38.82	38.87	38.32	38.37	37.63
USRNet		43.29	42.32	41.44	40.54	40.47	40.22	40.24	39.61
CSUNet		43.39	42.44	41.58	40.72	40.64	40.39	40.41	39.82
PIPAL 测试集									
DMPHN	2.55	23.38	20.47	19.30	18.51	18.20	18.24	18.09	17.85
DWDN		32.44	30.02	27.81	26.12	25.96	25.42	25.62	24.75
IRCNN		35.80	30.34	28.18	26.62	26.47	26.06	26.31	25.35
DPIR		37.76	31.24	28.64	26.87	26.77	26.30	26.53	25.48
USRNet		37.54	32.06	29.55	27.83	27.73	27.34	27.56	26.49
CSUNet		37.51	32.17	29.68	27.95	27.87	27.46	27.68	26.60
DMPHN	7.65	19.79	17.46	16.67	16.31	16.30	16.43	16.53	16.21
DWDN		31.42	28.29	26.45	25.18	25.10	24.64	24.82	24.05
IRCNN		32.39	28.41	26.58	25.33	25.20	24.88	25.08	24.26
DPIR		33.37	28.93	26.95	25.56	25.46	25.08	25.28	24.38
USRNet		33.20	29.56	27.68	26.34	26.28	25.97	26.13	25.26
CSUNet		33.23	29.65	27.76	26.42	26.38	26.05	26.21	25.33

根据表 3-3 和表 3-4 的实验结果可以看出，在两个测试集受到不同程度的模糊和噪声干扰下，本章提出的 CSUNet 模型均取得了不错的 PSNR 和 SSIM 结果。在噪声水平 $\sigma = 2.55$ 干扰下，CSUNet 优于其它对比模型 0.13dB 至 14dB。在噪声水平 $\sigma = 7.65$ 干扰下，CSUNet 优于其它对比模型 0.03dB 至 14dB。DMPHN 是盲去模糊方法，在高斯模糊图像上恢复效果较差。DWDN 采用维纳反卷积框架和深度特征层预测去模糊图像，但其特征层深度较低，网络提取到的信息十分有限，因此模型去噪效果一般。IRCNN、DPIR 和 USRNet 均采用半二次分裂框架结合深度去噪器进行图像复原，然而 IRCNN 去噪器仅有七层深度网络架构，去噪效果较差。DPIR 和 USRNet 的深度去噪器均堆叠

多个残差块到 U 型结构中, 充分提取浅层和深层的特征信息, 去噪效果相比于 IRCNN 有显著提升。但其深度去噪网络缺乏全局特征信息融合, 在 PSNR 指标上比 CSUNet 复原的结果低。CSUNet 模型通过增大卷积核感受野和跨尺度局部信息交互, 提取全局特征信息去除退化图像中的模糊和噪声, 同时局部特征信息的跨尺度互补来保留原始图像的纹理信息。

表 3-4 不同测试集下各算法对比的平均 SSIM 结果

Method	σ	模糊核							
									
PolyU 测试集									
DMPHN	2.55	0.7723	0.7559	0.7418	0.7312	0.7328	0.7264	0.7329	0.7240
DWDN		0.9885	0.9834	0.9776	0.9702	0.9682	0.9668	0.9667	0.9573
IRCNN		0.9420	0.8334	0.8498	0.8726	0.8721	0.8756	0.8794	0.8965
DPIR		0.9893	0.9844	0.9791	0.9731	0.9726	0.9711	0.9712	0.9660
USRNet		0.9882	0.9844	0.9798	0.9747	0.9742	0.9728	0.9731	0.9685
CSUNet		0.9886	0.9845	0.9802	0.9750	0.9746	0.9733	0.9736	0.9691
DMPHN	7.65	0.3839	0.3718	0.3659	0.3626	0.3668	0.3590	0.3670	0.3618
DWDN		0.9794	0.9735	0.9670	0.9592	0.9593	0.9565	0.9572	0.9502
IRCNN		0.9652	0.8472	0.8507	0.8751	0.8767	0.8867	0.8791	0.8971
DPIR		0.9798	0.9743	0.9682	0.9619	0.9619	0.9597	0.9601	0.9544
USRNet		0.9796	0.9749	0.9696	0.9640	0.9637	0.9623	0.9625	0.9577
CSUNet		0.9799	0.9752	0.9700	0.9647	0.9645	0.9632	0.9633	0.9587
PIPAL 测试集									
DMPHN	2.55	0.7731	0.6267	0.5410	0.4800	0.4671	0.4595	0.4551	0.4294
DWDN		0.9588	0.9180	0.8637	0.8060	0.8015	0.7801	0.7899	0.7430
IRCNN		0.9583	0.8800	0.8321	0.7846	0.7839	0.7691	0.7790	0.7362
DPIR		0.9762	0.9179	0.8648	0.8106	0.8103	0.7934	0.8026	0.7549
USRNet		0.9753	0.9292	0.8825	0.8346	0.8345	0.8211	0.8296	0.7866
CSUNet		0.9746	0.9297	0.8842	0.8369	0.8369	0.8239	0.8325	0.7895
DMPHN	7.65	0.5497	0.3954	0.3320	0.2965	0.3046	0.2988	0.3008	0.2725
DWDN		0.9326	0.8715	0.8129	0.7596	0.7553	0.7347	0.7457	0.7012
IRCNN		0.9325	0.8390	0.7797	0.7312	0.7308	0.7173	0.7257	0.6822
DPIR		0.9431	0.8697	0.8103	0.7549	0.7539	0.7371	0.7467	0.6988
USRNet		0.9415	0.8821	0.8298	0.7802	0.7813	0.7681	0.7756	0.7329
CSUNet		0.9407	0.8823	0.8307	0.7819	0.7835	0.7707	0.7781	0.7347

图 3-3 展示了各种算法对受到噪声水平 $\sigma = 7.65$ 和各向异性高斯模糊所干扰 PolyU 数据集中“NikonD800_8_100_6400_bulletin_3_mean”的复原视觉效果对比。从整体图像可以观察到, DMPHN 复原效果最差。从放大区域可以观察到, 对于字符细节的复原, DWDN、IRCNN 和 DPIR 均能去除掉图像的噪声, 但其恢复的字符仍然存在模糊的现

象。USRNet 能够去除图像中的噪声和模糊，但恢复的字符存在粘连的问题。相比之下，得益于 CSUNet 中不同层级的局部特征组合，提取图像原有的局部细节特征，从而恢复的字符细节更贴近原图。




图 3-3 不同方法对“NikonD800_8_100_6400_bulletin_3_mean”图像的彩色去模糊视觉对比结果

图 3-4 展示了各种算法对受到噪声水平 $\sigma = 7.65$ 和各向同性高斯模糊所干扰 PIPAL 数据集中“A0086”的复原视觉效果对比。从放大显示的区域可以观察到，对于这种纹理较密集的图像，USRNet 能够恢复出部分网格特征，而 CSUNet 采用伪逆变换消除了线性算子不可逆的影响，并结合深度去噪器获得的去噪先验信息，尽可能的保留住了原始的网络纹理细节，实现了去模糊、去噪与细节保持的平衡。




图 3-4 不同方法对“A0086”图像的彩色去模糊视觉对比结果

3.4.2 自适应参数分析

图 3-5 展示了不同水平的噪声影响下自适应参数 α_k 和 β_k 的数值变化。从图 3-5(a)中可以看出， α_k 与噪声水平呈正相关，并随迭代次数的增加而增加。这实际上正与算法流程推导一致，随着迭代次数的增加， y_k^+ 会越来越接近 x_{k-1} 。从图 3-5(b)中可以看出， β_k 与噪声水平呈负相关，并随迭代次数的增加而减少。这意味着随着去噪器每次对图像进行去噪后，所估计的噪声等级也在逐渐降低，进一步印证了算法的有效性。综上，自适应参数 α_k 和 β_k 在算法迭代过程中发挥了重要的作用，有效地提升算法的复原效果。




图 3-5 自适应参数 α_k 和 β_k 的数值变化

3.4.3 锂电池极片缺陷图像实验结果及分析

本小节选取锂电池极片缺陷图像的验证数据集作为测试实验数据集，通过给图像添加高斯模糊核来模拟相机抖动时拍摄的模糊图像，以及添加小噪声模拟电子元器件产生的电子噪声，进一步验证复原算法的实用性。

(1) 直观视觉对比实验结果及分析

本小节对工业产线下的小目标颗粒缺陷和大目标气泡缺陷图像进行实验，并添加了随机的高斯模糊核和噪声干扰，算法运行环境条件不变，直观视觉实验结果如图 3-6 和图 3-7 所示。

实验结果显示，如图 3-6 对于小目标缺陷颗粒，本章提出的算法能有效去除图像种的模糊和噪声，处理后的缺陷特征表现得十分清晰。如图 3-7 对于大目标缺陷气泡，本章所提出的算法同样能够有效地复原图像，成功保留住气泡缺陷的黑白边界，并提高

了图像的对比度。综上所述，本章提出的算法，能有效复原图像，保留所需的目标特征，为后续目标检测提供了特征明显、对比度高的图像。




图 3-6 颗粒缺陷的图像复原结果




图 3-7 气泡缺陷的图像复原结果

（2）退化图与复原图的检测实验结果及分析

为了更客观地体现出本章算法的实用性，本小节采用不同噪声等级和不同类型模糊干扰极片图像和经过本章算法复原后的极片图像，并且使用基础的 YOLOv8s 网络框架对退化图和复原图分别进行检测对比。采用 3.4 节中的模糊核和噪声等级进行实验，评判指标包括精确度(Precision)、召回率(Recall)、平均检测精度(mAP50)和综合平均检测精度(mAP50-95)，实验结果如表 3-4 所示。

从表 3-5 的退化图测试看出，由于 k1 和 k2 模糊核宽度较小，极片图像中的缺陷特征完好，容易被检测网络识别，所以精度降幅不明显。但在 k3 模糊核的干扰下，噪声水平从 $\sigma = 2.55$ 提升至 $\sigma = 7.65$ ，网络的检测精确度降低 17.7%，召回率降低 16.2%，平均检测精度降低 17.3%，综合检测精度降低 11.8%。同样的，在 k4 模糊核的干扰下，噪声水平从 $\sigma = 2.55$ 提升至 $\sigma = 7.65$ ，网络的检测精确度降低 26.1%，召回率降低 17.5%，

平均检测精度降低 22.6%，综合检测精度降低 13.7%。后面的 k5 模糊核到 k6 模糊核中，随着噪声等级的提高，退化图的检测精确度、召回率、平均检测精度和综合平均检测精度的降低幅度也在增加。这表明随着模糊和噪声干扰程度的提高，退化图中的缺陷像素特征不清晰，难以被识别出来。

表 3-5 锂电池极片验证集复原前后的检测指标结果

指标	σ	模糊核							
		k1	k2	k3	k4	k5	k6	k7	k8
									
退化图									
Precision(%)	2.55	88.1	86.6	84.3	82.4	80.5	80.7	82.2	76.7
Recall(%)		86.1	83.9	81	74.8	75.2	72.6	73.9	71.6
mAP50(%)		87.9	85.9	82.9	78.6	77	74.9	77.4	73.4
Map50-95(%)		50.4	48.5	44.9	41.9	41.5	40.4	41.8	38.9
Precision(%)	7.65	79.3	73.8	66.6	56.3	55.3	52.9	55	49
Recall(%)		76.2	71.8	64.8	57.3	53.1	52.3	56.6	47.5
mAP50(%)		78.8	72.9	65.6	56	54.4	52.3	55.6	46.7
Map50-95(%)		41.1	37.3	33.1	28.2	27.6	26.7	27.9	23.5
复原图									
Precision(%)	2.55	89.1	87.3	84.6	82.8	82.6	82.5	83	81.3
Recall(%)		87.4	84.2	81.3	78.3	79.2	78.9	78.5	75.7
mAP50(%)		89.2	86.3	83.2	80	80.7	80.8	80.1	77.9
Map50-95(%)		53.2	49	45.7	42.3	42.7	43	42.3	40
Precision(%)	7.65	84.4	82.8	81.2	78.9	80.3	80.5	81.2	79.1
Recall(%)		80.4	79.7	77.3	77.3	76.5	76.1	75.7	75.7
mAP50(%)		82.7	81.1	79.1	78	78.3	78	78	77
Map50-95(%)		44.5	42.8	41.1	40.5	40.8	40.5	40.4	40

从表 3-5 的复原图测试结果看出，在噪声水平 $\sigma = 7.65$ 实验条件下，相比于退化图，k1 模糊干扰下复原后的平均检测精度从 78.8% 提升到 82.7%、k2 模糊干扰下复原后的平均检测精度从 72.9% 提升到 81.1%、k3 模糊干扰下复原后的平均检测精度从 65.6% 提升到 79.1%、k4 模糊干扰下复原后的平均检测精度从 56% 提升到 78%、k5 模糊干扰下复原后的平均检测精度从 54.4% 提升到 78.3%、k6 模糊干扰下复原后的平均检测精度从 52.3% 提升到 78%、k7 模糊干扰下复原后的平均检测精度从 55.6% 提升到 78%、k8 模糊干扰下复原后的平均检测精度从 46.7% 提升到 77%。这说明得益于 CSUNet 中的深度去噪器所获得的深度去噪先验，有效地去除图像中的噪声。经过图像复原后，相较于退化图，复原图呈现出的特征更为显著且轮廓界定清晰。这种清晰的特征表现使得

后续的检测网络能够精确地识别出缺陷的类别与位置。

图 3-8 和图 3-9 分别给出了各向同性模糊核 k_3 和 k_4 ，以及噪声水平 $\sigma = 7.65$ 干扰下退化图和复原图的视觉缺陷检测效果比较。




图 3-8 噪声水平 $\sigma = 7.65$ 和 k_3 模糊干扰下检测对比图




图 3-9 噪声水平 $\sigma = 7.65$ 和 k_4 模糊干扰下检测对比图

从图 3-8(b)和(c)可以看出，检测网络出现了漏检缺陷的情况，但在复原图 3-8(e)和(f)上检测网络均能精确识别出缺陷的类型以及所出现的位置。退化图 3-8(a)中检测网络

能够识别出其中三个漏金属缺陷，但由于模糊和噪声的干扰使得漏金属缺陷呈现隆起的特征，检测时错误地将其余两个漏金属缺陷识别成褶皱。然而，在复原图 3-8(d)上检测网络能够正确地识别出所有漏金属目标。同样的，从图 3-9 的退化图(a)、(b)和(c)中观察到，受到退化影响的极片图像容易呈现出与其它特征相似的地方，如(a)中脱碳出现白圈特征与气泡缺陷类似，误导检测网络的判定。经过复原后的图 3-9(d)、(e)和(f)的缺陷特征突出，检测网络均能精确识别缺陷特征。这表明本章提出的方法通过伪逆变换消除线性算子的不可逆影响，有效地降低模糊核所带来的干扰，同时结合深度去噪器得到的去噪先验，使得在迭代求解过程中缺陷区域的边缘变得更加锐利，纹理细节也更为突出，增强了后续缺陷检测的准确性和效率。

图 3-10 至 3-11 分别给出了各向异性模糊核 k_7 和 k_8 ，以及噪声水平 $\sigma = 7.65$ 干扰下退化图和复原图的视觉缺陷检测效果比较。从图 3-10 的退化图(a)、(b)和(c)中观察到，与图 3-9 的情况类似，受退化影响的缺陷往往表现出与其他特征具有较高的相似性，检测网络难以区分。如图 3-10(a)中脱碳缺陷受模糊影响呈现凹坑特征的凹陷破损现象，(b)中凹坑周围受模糊影响呈现气泡特征的白圈。经过复原后的图 3-10(d)、(e)和(f)的缺陷特征清晰可辨，提高检测网络识别的精确性。




图 3-10 噪声水平 $\sigma = 7.65$ 和 k_7 模糊干扰下检测对比图

从图 3-11(a)和(b)可以看出，检测网络出现了漏检缺陷的情况，退化图上的气泡和划痕缺陷被模糊干扰，导致特征不突出难以被识别到。然而，在复原图 3-11(d)和(e)上

检测网络能够精准地判定缺陷的种类及具体位置。退化图 3-11(c)中检测网络能够识别出其中一个漏金属缺陷，但由于模糊和噪声的干扰使得漏金属缺陷呈现与类似凹坑缺陷凹进去的特征，检测时错误地将其中一个漏金属缺陷识别成凹坑，另一个漏金属缺陷则漏检。但在复原图 3-11(f)上检测网络能够正确地识别出所有漏金属目标且定位准确。这进一步说明，CSUNet 的跨尺度 FSF-Block 模块组合多层次特征思想，由其它级别的信息来增强当前级别的特征，进而丰富了每个层级的特征图，有助于网络保留原有图像细节特征。因此，检测网络不仅能够正确地辨别各种类型的缺陷，还能精确地确定缺陷的边界，并检测出缺陷的详细位置。




图 3-11 噪声水平 $\sigma=7.65$ 和 k8 模糊干扰下检测对比图

3.5 本章小结

本章设计了一种基于深度去噪先验的伪逆变换图像复原方法。采用交替迭代最小化的方法将伪逆保真项与正则项解耦，分裂成两个子问题进行求解，并将深度神经网络作为去噪器提高复原方法的去噪性能。实验结果表明，本章所提出的结合神经网络的伪逆变换图像复原模型具有更强的去除模糊和噪声的性能，同时拥有细节保持的能力，能够更好地保留原始图像的纹理信息，为后续提供清晰度高、特征明显的图像进行检测。

第四章 聚合分发信息融合的目标检测网络

4.1 引言

目前 CNN 在目标检测中常采用 PAN(Path Aggregation Network)和 FPN(Feature Pyramid Network)的金字塔结构,这会限制跨层级特征的信息整合,导致检测网络难以识别锂电池极片图像上不同位置的缺陷,出现漏检的情况。同时受限于小范围 3×3 的感受野,检测网络难以捕获缺陷特征的整体结构信息,容易误判特征相似的缺陷类型,从而降低网络的检测性能。针对这些问题,本章设计了聚合分发信息融合的 YOLOv8s_AD 网络,通过 DSCDownsample、C2f 变体和 Cross_Neck 三个模块实现。首先, DSCDownsample 同时利用不同卷积尺度大小获得了多种感受野信息,减少目标特征在下采样后的信息丢失,尽可能保留原始特征传递;其次, C2f_CDW 和 C2f_CIB 作为主要特征提取模块,在浅层结构中使用 C2f_CDW 提取大范围特征图中局部特征信息,在深层结构中使用 C2f_CIB 映射小范围特征图内全局特征信息,有效地减少信息冗余,提高网络对不同特征识别的能力;第三,该网络在颈部结构中采用 Cross_Neck 结构实现跨级别和跨位置的信息交互,全局融合各层级间的特征信息,增强网络的全局特征提取的能力。

4.2 YOLOv8 网络基础结构

YOLOv8 主要由三个部分组成:骨干结构(Backbone)、颈部结构(Neck)和检测结构(Prediction),其网络结构如图 4-1 所示。Backbone 主要负责特征提取,采用轻量级 C2f 模块实现额外的特征通道分离和多层跳跃连接操作,深度融合各个层级的图像特征信息,提高网络的特征提取能力。Neck 主要负责多尺度信息融合,将来自 Backbone 的特征信息分尺度融合,增强特征的表示能力。Prediction 采用解耦检测头,将类别检测头和定位检测头分离计算损失,提高了网络的灵活性和适应性。YOLOv8 的各模型版本如表 4-1 所示, YOLOv8s 是 YOLOv8 系列中参数量和运算量均不高的网络模型,但该网络在 COCO 数据集上能够达到较好的检测精度,满足实时的应用场景的同时符合工业检测设备的要求。因此,本章选用 YOLOv8s 的网络作为基础研究对象。




图 4-1 YOLOv8 网络结构图

表 4-1 YOLOv8 的各模型参数和 COCO 数据集上的检测精度

模型名称	参数量	每秒浮点运算数(B)	模型大小(M)	mAP50(%)
YOLOv8n	3157200	8.9	6.5	37.3
YOLOv8s	11128293	28.5	22.5	44.9
YOLOv8m	25902640	79.3	52.1	50.2
YOLOv8l	43691520	165.7	87.8	52.9
YOLOv8x	68229648	258.5	136.9	53.9

4.3 聚合分发信息融合的网络设计

基于 YOLOv8 的目标检测网络结构模型通常由两个重要部分组成：Backbone 和 Neck。主干结构负责提取基础的对象特征，而颈部结构促进同一尺度间浅层与深层特征的融合，以实现最终的目标检测。而锂电池极片表面缺陷存在多缺陷目标和缺陷形

状相似的情况，为图像缺陷识别检测带来了困难。因此，本章针对丰富高级特征信息和提高多尺度信息互补能力的需求，提出了聚合分发信息融合的 YOLOv8s_AD 网络，其网络结构如图 4-2 所示。




图 4-2 YOLOv8s_AD 网络结构图

(1) DSCDownsample 模块：针对 YOLOv8s 仅采用一个 3×3 普通卷积进行下采样，没有充分利用图像的空间特征信息，且普通卷积进行计算时参数量过大等问题。设计了下采样模块 DSCDownsample，该模块采用深度可分离卷积和通道混合操作，能够有效地降低网络的计算复杂度，同时提高网络的融合特征能力，其结构如图 4-3 所示。




图 4-3 DSCDownsample 模块结构图

该下采样模块 DSCDownsample 包括两个分支，第一个分支是由 5×5 深度可分离卷积进行下采样，然后通过 1×1 普通卷积整合下采样后的特征信息；第二个分支则是

由 3×3 深度可分离卷积进行下采样，然后同样经过 1×1 普通卷积进行处理。通过这两个不同分支的卷积下采样，不同大小的感受野范围有助于捕获不同尺度的特征。两个分支经过特征拼接后进行通道打乱操作，能够更好地保留和混合目标特征，增加信息的多样性与丰富性，提取并传递高级图像信息到下一层结构中，提高网络的检测性能。此外，采用深度可分离卷积对输入的通道进行一对一的卷积操作，能够显著地减少计算量，并在深层结构中随着输入特征通道数较多时能有效减少图像信息冗余，更多地抓取图像中的目标特征信息。

(2) C2f_CDW 和 C2f_CIB 模块：C2f 模块是 YOLOv8 算法中的一个重要模块，它采用了 CSP Bottleneck 的设计理念，通过特征转换、多分支处理和特征融合等操作，提取和转换输入图像的目标特征，传递更具表征能力的输出特征。这有助于提高网络的检测性能和表示能力，使得网络能够更好地适应复杂的检测任务。因此，本章分别设计和引入了 C2f_CDW 和 C2f_CIB 模块，提升网络对浅层整体局部信息和深层全局特征信息的捕捉能力。




图 4-4 C2f_CDW 模块及其构件结构图

C2f_CDW 模块如图 4-4 所示，其中的 CDWBottleneck 结构是根据特征分流的思想设计的，旨在增强网络对局部特征信息的提取能力，减少冗余信息的干扰。CDWBottleneck 结构主要是由 CDW Module 提取特征信息，首先经过普通卷积进行通道分流，一半传递给后续拥有较大感受野的深度可分离卷积，从而提取小目标整体信息。另一半则保留并提取的小目标整体信息进行通道拼接，保持输入输出通道一致。

通过特征分流的操作，能够有效地避免传统卷积的冗余特性，提升网络的检测效率。同时，在 C2f_CDW 模块中堆叠的 CDWBottleneck 所提取到的局部特征信息，然后将每个模块特征进行通道拼接后采用普通卷积降维，有助于网络在多层次信息中学习到了更复杂的特征表示，提升检测精度。

C2f_CIB 模块如图 4-5 所示。该模块是引入 YOLOv10^[75]改进的 C2f 模块，CIB 结构是该模块中主要的特征提取块。CIB 结构采用一条通路的方式，通过深度可分离卷积提取低分辨率特征图的全局空间特征，普通卷积进行通道特征混合，相对传统普通卷积来说以较少的计算量实现更好的特征提取，在计算成本和特征提取能力之间达到了良好的平衡。此外，CIB 结构中还采用了残差连接的方式，改进了梯度流，有助于缓解深层网络中梯度消失问题，并加快深度网络的收敛速度。




图 4-5 C2f_CIB 模块及其构件结构图

(3) Cross_Neck 模块：为增强网络对相似缺陷特征的识别能力，提升检测精度，本章设计了跨位置信息融合的颈部网络 Cross_Neck 结构，如图 4-2 中 Neck 部分所示。

首先，Cross_Neck 收集主干网络中各层级所提取的图像特征信息，并采用池化或上采样操作确保不同层次信息处于同一尺度下。然后，采用通道拼接将收集信息聚合到一起，通过 C2f_CIB 模块将不同层级的信息相互融合以抓取更全面且更具代表性的目标特征信息，提高网络感知不同缺陷特征的能力。随后，将全面的特征信息分发到不同的检测尺度上，将融合后的信息注入到相应的层级上，并与相应尺度下的主干结构所提取的浅层信息相结合，这种跨位置的信息交流产生了更丰富多样化的信息流，

减少了不同深度特征之间的连通性差距，从而增强每个分支的检测能力。同时，在 Cross_Neck 结构后端仍保留了自上而下的途径来传递信息流，促进相邻层间的信息融合，有效地提高了网络对多尺度目标的检测能力与鲁棒性。

4.4 实验结果及分析

4.4.1 实验环境配置

本章所采用的数据集为工厂提供的原始锂电池极片图像，由于原始图像的分辨率较高，但实际的缺陷尺寸相较于整幅图像来说十分的小，如脱碳、凹坑等小型缺陷。因此为了减少原始图像在神经网络中的运算时间和计算量，同时放大相应的缺陷特征，从而提升检测精度。在预处理的过程中将原图像上分割成了大小一致的多副子图，如图 4-6 所示，左侧图像是经过预处理后得到了锂电池极片表面图像，右侧图像是等份分割后的多幅子图像。




图 4-6 网格分割图像

将分割后的图像整合后形成锂电池极片表面缺陷数据集，每张图像包含一个或多个缺陷实例，图像的标注文件格式为 txt 格式。数据集总共涵盖七个类别，分别是：气泡(bubble)、颗粒(particle)、脱碳(decaburization)、凹坑(pit)、漏金属(leaky_metal)、条纹(strip)和褶皱(wrinkle)。训练数据集包含 23577 张图像，测试数据集包含 5898 张图像，

整体数据集共有 29475 张图像。具体的缺陷实例数量如表 4-2 所示，各类缺陷图像数量如图 4-7 所示。实际生产过程中，由于浆料制备过程时难以避免浆料搅拌不均和混入气体的情况，因此采集到的锂电池极片图像数据集中脱碳和气泡缺陷占比数量较多。其中，气泡图像数量约占数据集数量的 26.2%，脱碳图像数量约占数据集数量的 34.1%，其它缺陷图像数量约占数据集数量的 39.7%。

表 4-2 实例标签分布

类别名	气泡	颗粒	脱碳	凹坑	漏金属	条痕	褶皱
训练集数量/个	6193	2063	11410	4167	2248	2888	332
测试集数量/个	1547	517	2902	1049	566	697	82




图 4-7 数据集中各类缺陷图像的数量

实验评价标准采用：参数量(Parameters)、每秒十亿次浮点运算数(GFLOPs)、模型大小(Size)、精确率(Precision)、召回率(Recall)、平均精度(Average-Precision, AP)、多类别平均精度(mean Average Precision, mAP)作为检测实验的客观评价指标。实验详细设备环境参数以及实验参数如表 4-3 所示。

Precision 和 Recall 计算公式如公式(4-1)和公式(4-2)所示。

$$Precision = \frac{TP}{TP+FP} \quad (4-1)$$

$$Recall = \frac{TP}{TP+FN} \quad (4-2)$$

其中， TP 表示正样本被正确预测， FP 表示负样本被错误预测为正样本， FN 表示正样本被错误预测为负样本。

AP 是每个类别的真实标签和预测概率进行计算的指标，其对应 Precision 和 Recall 的值作所形成的区域面积称为平均精度(AP)，表示单一类别的检测精度； mAP 则是将所有类别的 AP 值取平均，其取值范围为[0,1]，表示所有类别的平均检测精度。其中，mAP50 是一个固定的评估标准，它只考虑 IoU 为 0.5 的情况，适用于一般情况下模型间的检测性能评估；mAP50-95 提供了一个更全面的评估，它考虑了从 0.5 到 0.95(以 0.05 为步长)的一系列 IoU 阈值，更能反映模型在不同重叠程度下的检测精度，是一个更严格的评估指标。

表 4-3 实验环境详细配置	
参数	配置说明
操作系统	Ubuntu 22.04
处理器	Intel Xeon Gold 6226R@2.9GHz
GPU	RTX-4090 24G
加速环境	CUDA 12.2、cuDNN 9.1.1
深度学习框架	Pytorch
图像尺寸	480*480
训练迭代次数	500
每批次图像数量	96
学习率	0.001
优化器	SGD
模型学习衰减方式	线性学习率衰减

4.4.2 实验结果分析

（1）消融实验

为验证本章算法改进的有效性，对 YOLOv8s_AD 算法进行消融实验，验证分析 DSCDownsample 模块、C2f 变体模块和 Cross_Neck 模块对模型性能的影响，实验结果如表 4-4 所示。

由表 4-4 的数据所示，在实验 2 中，将 DSCDownsample 模块替换掉原有卷积下采样模块，模型的参数量、浮点运算次数和模型大小分别减少了 18.1%、13.7%和 17.3%，精确度和召回率分别提高了 0.9%和 0.2%，mAP50 和 mAP50-95 分别提高了 0.1%和 1.3%。这表明 DSCDownsample 模块在降低模型运算冗余的同时提取到更有效的目标特征信息，提高检测精度。实验 3 中，通过将主干网络和颈部网络中的 C3 模块替换成 C2f_CDW 和 C2f_CIB 模块，相较于实验 2，改进后模型的参数量、浮点运算次数和模

型大小分别大幅度减少了 34.5%、35%和 33.4%，精确度、召回率、mAP50 和 mAP50-95 分别提高了 0.6%、0.1%、0.3%和 2.8%。这表明引入改进的 C2f 变体模块后能有效的降低模型的复杂度，提高网络在检测任务上的整体性能。实验 4 中，采用 Cross_Neck 作为颈部结构，模型的复杂度略有升高，但精确度、召回率和 mAP50-95 相较于实验 3 的数据分别提高了 0.2%、0.2%和 0.4%。这表明改进后的颈部结构能够有效地融合不同层级间的特征信息，提升网络的检测性能。

表 4-4 YOLOv8s_AD 消融实验结果

实验	YOLOv8s	DSC	C2f	Neck	Parameters	GFLOPs	Size (M)	Precision (%)	Recall (%)	mAP50 (%)	mAP50-95 (%)
1	√				11128293	28.5	22.5	94.8	95.9	97	73.3
2	√	√			9110737	24.6	18.6	95.7	96.1	97.1	74.6
3	√	√	√		5971273	16	12.4	96.3	96.2	97.4	77.4
4	√	√	√	√	6287529	16.7	13	96.5	96.4	97.4	77.8

整体改进后的 YOLOv8s_AD 与原始的 YOLOv8s 相比，参数量、浮点运算次数和模型大小分别大幅度减少了 43.5%、41.4%和 42.2%，精确度、召回率、mAP50 和 mAP50-95 分别提高了 1.7%、0.5%、0.4%和 4.5%。说明改进后的 YOLOv8s_AD 模型有效提升识别缺陷特征的准确率，且运算复杂度较低，满足产业线上锂电池极片表面缺陷检测的需求。

(2) 对比实验

为进一步验证改进后 YOLOv8s_AD 模型的检测性能，将本章所提出的改进模型与目前常用的一阶段 YOLO 系列^[76]检测方法进行比较，包括 YOLOv5s、YOLOv6s、YOLOv7、YOLOv8s、YOLOv9s 和 YOLOv10s 进行实验，如表 4-5 所示。

表 4-5 各算法对比实验结果

	Parameters	GFLOPs	Size (M)	Precision (%)	Recall (%)	mAP50 (%)	mAP50-95 (%)
YOLOv5s	7029004	15.8	14.3	95.3	96	96.5	69.7
YOLOv6s	18504353	25.41	40.6	94.7	95.1	95.9	68.1
YOLOv7	36514136	103.3	74.8	94.2	93.4	95.1	65.8
YOLOv8s	11128293	28.5	22.5	94.8	95.9	97	73.3
YOLOv9s	9602666	38.7	20.3	94.4	95.6	96.8	71.9
YOLOv10s	8040378	24.5	16.6	95.8	95.8	96.9	72.8
YOLOv8s_AD	6287529	16.7	13	96.5	96.4	97.4	77.8

由表 4-4 看出，尽管 YOLOv5s 的浮点运算量最小，但其检测精度较低。由于

YOLOv9s 采用广义高效层聚合结构,使得网络运算较为复杂,浮点运算量达到 38.7G,信息冗余程度较高,从而在 mAP50-95 的检测精度指标上分别比 YOLOv8s 和 YOLOv10s 低 1.4%和 0.9%。而 YOLOv10s 采用一对一检测策略,无极大值抑制方案的后端处理,在多目标缺陷检测时容易出现漏检或误检的情况,其 mAP50-95 的检测精度指标上略比 YOLOv8s 低 0.5%。相较于其他的模型,本章提出的 YOLOv8s_AD 在精确度、召回率、mAP50 和 mAP50-95 的检测指标上均达到了最优的效果,同时也达到了最低的参数量与模型大小。值得注意的是,YOLOv8s_AD 在 mAP50-95 的检测指标精度大幅优于其他检测方法,这说明在更大的 IoU 阈值下我们的方法对缺陷目标识别精确,定位精准。

综上,改进后网络采用的轻量化模块和颈部结构十分有效,实验数据说明该网络比基准的 YOLOv8s 模型能准确识别更多的极片表面缺陷目标,在精确度、召回率和多类别平均检测精度上均比其它 YOLO 系列检测网络高,能够很好的满足了提升锂电池极片表面缺陷目标检测精度的研究目的。

为了更清晰地展示 YOLOv8s_AD 在实际锂电池极片图像缺陷特征中的检测性能,现对各种不同的目标缺陷图像进行检测和展示,并与表 4-4 中其它算法的检测结果图进行比较。检测的实验视觉对比结果如图 4-8 至图 4-9 所示。

根据图 4-8 可以看出 YOLOv8s_AD 网络能够准确地检测出图像中的四个脱碳缺陷,且检测置信度较高,未发生漏检情况。与之相比,除算法 YOLOv5s 外的其它检测算法在本次检测中均漏检了左侧特征不明显的脱碳缺陷,存在明显的漏检现象。尽管 YOLOv5s 均能检测出四个脱碳缺陷,但检测置信度方面比 YOLOv8s_AD 低。这表明在多目标缺陷情况下,YOLOv8s_AD 网络通过 C2f_CDW 模块能够提取浅层特征图中的局部特征信息,有效地识别出细小的脱碳缺陷特征,具有更高的检测准确性和更低的漏检率。

从图 4-9 可以观察到,图像上该凹坑缺陷与颗粒缺陷具有十分相似的特征。YOLOv7、YOLOv8s 和 YOLOv10s 都将该缺陷误检成颗粒缺陷,YOLOv5s、YOLOv6s 和 YOLOv9s 将该缺陷检测出两种缺陷类型,同样存在误检的情况。而本章提出的 YOLOv8s_AD 算法采用 Cross_Neck 模块融合浅层局部特征和深层全局特征,能够准确识别出凹坑缺陷。这表明 YOLOv8s_AD 算法具有更强的特征分类能力,在处理相似缺

陷的情况下能够精准检测出对应的缺陷对象。




图 4-8 脱碳缺陷实验结果对比图




图 4-9 凹坑缺陷实验结果对比图

综上所述，通过锂电池极片缺陷检测图的对比实验表明，本章所提出的 YOLOv8s_AD 算法通过添加 DSCDownsample、引入 C2f 变体模块和改进的 Cross_Neck 模块，能够提取更多整体和局部的缺陷特征信息，提高各类缺陷目标的检测精度有效地减少了极片缺陷检测中漏检误检的现象。尤其是在待检测图像中出现多个缺陷目标或特征相似的缺陷目标时，YOLOv8s_AD 算法能够精准地识别出多个目标

或正确的对应缺陷，提升了极片缺陷检测效果。

4.5 本章小结

本章首先介绍了 YOLOv8s 网络基础，然后在 YOLOv8s 基础上采用 DSCDownsample、C2f 变体模块和 Cross_Neck 模块设计了聚合分发信息融合的 YOLOv8s_AD 网络。通过在自制的锂电池极片缺陷图像数据集上进行消融实验和对比实验，验证本章提出方法的有效性。实验表明，YOLOv8s_AD 拥有更低的算法复杂度和更优的检测性能，能有效地减少极片缺陷检测中的漏检误检现象，尤其对多缺陷目标和缺陷特征相似的复杂情况的检测性能良好，能满足实际工业检测的准确性和可用性的要求。

第五章 总结与展望

5.1 总结

视觉缺陷检测方法具有速度快、非接触和精确度高等优点，极大提高锂电池极片的缺陷检测效率。然而，在工业产线的复杂环境下，锂电池极片图像的采集过程往往会受到不同程度的干扰，如电子元件发热和外部振动等问题，导致采集图像存在噪声和模糊的退化情况，影响后续缺陷检测的精度。此外，实际存在的极片缺陷常有特征相似、特征大小不一等情况，也为产线涂布过程时检测极片缺陷带来了挑战。因此，本文研究面向锂电池涂布过程的视觉缺陷检测方法，主要研究工作如下：

(1) 针对卷积神经网络的局部卷积核仅关注局部特征信息，难以有效实现全局图像去噪的问题。本文研究了一个新的有效结合 Transformer 全局建模能力与卷积局部建模能力的双 U 型多尺度信息融合网络，采用全局移动窗口自注意力与局部卷积层促进图像上全局特征和局部特征的融合，提高网络的复原性能。标准灰度和彩色测试集下的实验结果表明，相较于对比算法，本文提出的双 U 型多尺度信息融合网络在大部分的测试集中均取得了最佳的 PSNR 和 SSIM 结果，这表明了本文方法在去除图像的噪声方面的具有较好的效果，同时能够保留更多的原始纹理细节信息。在锂电池极片退化图和复原图的检测实验结果表明，复原图的平均检测精度远高于退化图的平均检测精度，并从直观检测图可以观察到，复原图明显减少了发生漏检或误检的情况。

(2) 针对传统图像复原模型中保真项线性算子不可逆和正则项提供的图像先验信息不足，进而降低模型去模糊和去噪性能的问题。本文研究了一种基于深度去噪先验的伪逆变换图像复原方法。首先，引入伪逆变换构建伪逆保真项，从而消除了保真项中线性算子矩阵不可逆对模型求解的不良影响；其次，通过交替迭代最小化算法，将该模型拆解为两个子问题分别求解；第三，采用具备跨尺度信息交互特性的深度卷积神经网络作为模型的去噪器，为模型提供更丰富的图像先验信息，以此增强模型去除噪声的能力。在模型迭代求解过程中采取自适应参数调整策略，促使算法更快收敛，进而达成更佳的复原成效。自然光图像测试集的实验数据表明，该方法在八个模糊核和两种噪声水平干扰下，相较于对比方法均能取得最高的 PSNR 和 SSIM 结果，能够有效解决不同模糊类型所引发的图像退化问题。在锂电池极片退化图和复原图的检测实

验结果表明，复原图的平均检测精度均比退化图的平均检测精度要高，降低误检发生的概率，提高检测网络识别的精确性。

(3) 针对锂电池极片表面缺陷存在特征相似且大小不同导致误检或漏检的问题，本文研究了一种聚合分发信息融合的 YOLOv8s_AD 网络。该网络采用 DSCDownsample 模块获取多种感受野范围，逐步提取不同尺度下的图像的空间特征信息；其次，C2f_CDW 通过特征分流的方式过滤冗余的图像特征信息，有效提升检测精度。C2f_CIB 利用单通路和深度卷积，建立跳跃连接，改善网络梯度流，有效缓解深层网络中的梯度消失问题，加速网络收敛；颈部结构 Cross_Neck 融合不同尺度间的信息，并将其分配到相应尺度的检测层，增强网络对全局和局部特征的提取能力。实验结果表明，相比于 YOLOv8s，改进后的 YOLOv8s_AD 降低了网络运算复杂度和参数量，且拥有更高的检测精度。与其他单阶段目标检测网络相比，从数据上看 YOLOv8s_AD 获得了最高的 mAP50 和 mAP50-95 精度，缺陷定位和分类更加准确。同时在特征相似、多缺陷目标等检测环境中的表现出色，更能满足锂电池极片图像缺陷检测的精确性和有效性要求。

5.2 展望

现如今锂电池自动化产线发展愈发迅猛，企业对于锂电池极片缺陷检测的效率和精度要求也在提高。因此如何设计出能有效去除退化因素并保留特征细节的图像复原模型算法和快速、精确的便部署型检测网络，这仍然是未来在视觉缺陷检测方法的研究重点。具体可以从以下这两个方面进行深入探究：

(1) 针对复原模型方面，设计自适应层次模块的深度神经网络。本文的深度神经网络模块结构固定，并没有根据实际输入图像特征调整。因此，未来的研究可以设计一种自适应调整层次模块的神经网络，能够根据输入图像特征的复杂程度来调整模块的尺度，提高模型在多样化场景下的适应性。

(2) 针对极片缺陷检测方面，在保证精确度的情况下可以进一步对网络轻量化进行研究，采用模型压缩和量化技术，进一步降低模型的计算量和存储需求，使其更适合在工业产线设备上部署；其次，引入更加高效的标签分配策略正确分配正负样本，提升网络的训练效率和泛化能力。

参考文献

- [1] 王鹏博, 郑俊超. 锂离子电池的发展现状及展望[J]. 自然杂志, 2017, 39(4): 283-289.
- [2] 杨冬进, 娄建安. 锂离子电池及其在线检测前沿与发展综述[J]. 电源技术, 2018, 42(9): 1402-1403, 1419.
- [3] 蔡晶菁. 锂离子电池储能电站火灾防控技术研究综述[J]. 消防科学与技术, 2022, 41(4): 472-477.
- [4] 牛志远, 姜欣, 谢镔, 等. 电动汽车过充燃爆事故模拟及安全防护研究[J]. 电工技术学报, 2022, 37(1): 36-47, 57.
- [5] 李莉杰, 高方, 李元涛, 等. 储能设备电池极片缺陷检测网络研究[J]. 电力大数据, 2024, 27(6): 22-31.
- [6] Hunt. Bayesian methods in nonlinear digital image restoration[J]. IEEE Transactions on Computers, 1977, 100(3): 219-229.
- [7] Richardson W H. Bayesian-based iterative method of image restoration[J]. Journal of the optical society of America, 1972, 62(1): 55-59.
- [8] 马鸽. 面向极大规模集成电路封装 X 射线检测的图像处理关键问题研究[D]. 广州: 华南理工大学, 2017.
- [9] Wang W, Qu G, Song C, et al. Tikhonov regularization with conjugate gradient least squares method for large-scale discrete ill-posed problem in image restoration[J]. Applied Numerical Mathematics, 2024, 204: 147-161.
- [10] Zhang X, Li Z, Nan N, et al. Denoising algorithm of OCT images via sparse representation based on noise estimation and global dictionary[J]. Optics Express, 2022, 30(4): 5788-5802.
- [11] Chen Y, Cao W, Pang L, et al. Hyperspectral image denoising via texture-preserved total variation regularizer[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-14.
- [12] Zou T, Li G, Ma G, et al. A derivative fidelity-based total generalized variation method for image restoration[J]. Mathematics, 2022, 10(21): 3942.

- [13] Ri G I, Kim S J, Kim M S. Improved BM3D method with modified block-matching and multi-scaled images[J]. Multimedia Tools and Applications, 2022, 81(9): 12661-12679.
- [14] Peng C, Zhu K, Fan T, et al. Denoising for airborne transient electromagnetic data using noise-whitening-based weighted nuclear norm minimization[J]. Journal of Geophysics and Engineering, 2023, 20(4): 735-750.
- [15] Tirer T, Giryes R. Image Restoration by Iterative Denoising and Backward Projections[J]. IEEE Transactions on Image Processing, 2019, 28(3): 1220-1234.
- [16] Zhang K, Zuo W, Chen Y, et al. Beyond a gaussian denoiser: Residual learning of deep cnn for image denoising[J]. IEEE Transactions on Image Processing, 2017, 26(7): 3142-3155.
- [17] Zhang K, Zuo W, Zhang L. FFDNet: Toward a fast and flexible solution for CNN-based image denoising[J]. IEEE Transactions on Image Processing, 2018, 27(9): 4608-4622.
- [18] Kim K, Lee S, Cho S. Mssnet: Multi-scale-stage network for single image deblurring[A]. 2022 European Conference on Computer Vision(ECCV 2022)[C]. Cham: Springer Nature Switzerland, 2022: 524-539.
- [19] Tian C, Xu Y, Li Z, et al. Attention-guided CNN for image denoising[J]. Neural Networks, 2020, 124: 117-129.
- [20] Dong W, Wang P, Yin W, et al. Denoising prior driven deep neural network for image restoration[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 41(10): 2305-2318.
- [21] Zhang K, Zuo W, Gu S, et al. Learning deep CNN denoiser prior for image restoration[A]. 2017 IEEE Conference on Computer Vision and Pattern Recognition(CVPR 2017)[C]. IEEE, 2017: 3929-3938.
- [22] Li Z, Wu J. Learning deep CNN denoiser priors for depth image inpainting[J]. Applied Sciences, 2019, 9(6): 1103.
- [23] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 30.
- [24] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words:

- Transformers for image recognition at scale[J]. arXiv, 2020.
- [25] Carion N, Massa F, Synnaeve G, et al. End-to-End Object Detection with Transformers[A]. 2020 European Conference on Computer Vision(ECCV 2020)[C]. Cham: Springer International Publishing, 2020: 213-229.
- [26] Touvron H, Cord M, Douze M, et al. Training data-efficient image transformers & distillation through attention[A]. 2021 International Conference on Machine Learning(ICML 2021)[C]. PMLR, 2021: 10347-10357.
- [27] Zamir S W, Arora A, Khan S, et al. Restormer: Efficient Transformer for High-Resolution Image Restoration[A]. 2022 IEEE Conference on Computer Vision and Pattern Recognition(CVPR 2022)[C]. IEEE, 2022: 5728-5739.
- [28] Chen H, Wang Y, Guo T, et al. Pre-trained image processing transformer[A]. 2021 IEEE Conference on Computer Vision and Pattern Recognition(CVPR 2021)[C]. IEEE, 2021: 12299-12310.
- [29] Cao J, Li Y, Zhang K, et al. Video Super-Resolution Transformer[A]. arXiv, 2023.
- [30] Wang Z, Cun X, Bao J, et al. Uformer: A general u-shaped transformer for image restoration[A]. 2022 IEEE Conference on Computer Vision and Pattern Recognition(CVPR 2022)[C]. IEEE, 2022: 17683-17693.
- [31] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[A]. 2021 IEEE Conference on Computer Vision and Pattern Recognition(CVPR 2021)[C]. IEEE, 2021: 10012-10022.
- [32] Fan C M, Liu T J, Liu K H. SUNet: Swin transformer UNet for image denoising[A].2022 IEEE International Symposium on Circuits and Systems (ISCAS 2022)[C]. IEEE, 2022: 2333-2337.
- [33] Liang J, Cao J, Sun G, et al. Swinir: Image restoration using swin transformer[A]. 2021 IEEE Conference on Computer Vision and Pattern Recognition(CVPR 2021)[C]. IEEE, 2021: 1833-1844.
- [34] 孙正军. 基于图像边缘提取的电池极片瑕疵检测研究[D]. 长沙: 中南大学, 2010.
- [35] 刘学山. 基于机器视觉的锂离子电池极片检测系统的研究与设计[D]. 广州: 华南理

- 工大学, 2011.
- [36] 刘妍. 基于机器视觉的锂电池极片涂布缺陷检测系统设计[D]. 太原: 中北大学, 2012.
- [37] Lanza G, Koelmel A, Peters S, et al. Automated optical detection of particles and defects on a Li-Ion-cell surface using a single-point analysis[A]. 2013 IEEE International Conference on Automation Science and Engineering (CASE 2013)[C]. IEEE, 2013: 675-680.
- [38] 赵晓云, 郑治华, 韩洪伟, 等. 锂电池极片表面缺陷特征提取方法研究[J]. 河南科技, 2017(5): 137-139.
- [39] 王露. 基于机器视觉的锂电池极片缺陷检测与分类系统[D]. 西安: 西安科技大学, 2021.
- [40] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[A]. 2014 IEEE Conference on Computer Vision and Pattern Recognition(CVPR 2014)[C]. IEEE, 2014: 580-587.
- [41] Priyadharshini G, Dolly D R J. Comparative investigations on tomato leaf disease detection and classification using CNN, R-CNN, fast R-CNN and faster R-CNN[A]. 2023 International conference on advanced computing and communication systems (ICACCS 2023)[C]. IEEE, 2023: 1540-1545.
- [42] Xu J, Ren H, Cai S, et al. An improved faster R-CNN algorithm for assisted detection of lung nodules[J]. Computers In Biology And Medicine, 2023, 153: 106470.
- [43] Xu X, Zhao M, Shi P, et al. Crack detection and comparison study based on faster R-CNN and mask R-CNN[J]. Sensors, 2022, 22(3): 1215.
- [44] 李瑞坤. 基于多尺度特征的锂电池表面缺陷检测方法研究[D]. 哈尔滨: 哈尔滨工业大学, 2020.
- [45] 封学勇. 基于深度学习的柱形锂电池钢壳表面缺陷识别与分类方法[D]. 合肥: 合肥工业大学, 2021.
- [46] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[A]. 2016 IEEE Conference on Computer Vision and Pattern Recognition(CVPR 2016)[C]. IEEE, 2016: 779-788.

- [47] 马鸽, 李洪伟, 严梓维, 等. 基于多注意力的改进 YOLOv5s 小目标检测算法[J]. 工程科学学报, 2024(9): 1647-1658.
- [48] Ma G, Guo J, Wang T. A Lightweight Object Detection Network for Vehicle Environment Perception Based on Improved YOLOv5s[A]. 2024 International Annual Conference on Complex Systems and Intelligent Science (CSIS-IAC 2024)[C]. IEEE, 2024: 494-501.
- [49] 张旭. 基于深度卷积神经网络的铝材表面缺陷检测[D]. 上海: 华东理工大学, 2021.
- [50] Hu H, Zhu Z. Sim-YOLOv5s: A method for detecting defects on the end face of lithium battery steel shells[J]. Advanced Engineering Informatics, 2023, 55: 101824.
- [51] Yang Y, Zhou Y, Din N U, et al. An improved YOLOv5 model for detecting laser welding defects of lithium battery pole[J]. Applied Sciences, 2023, 13(4): 2402.
- [52] Xu W, Fu Y L, Zhu D. ResNet and its application to medical image processing: Research progress and challenges[J]. Computer Methods and Programs in Biomedicine, 2023, 240: 107660.
- [53] Ma K, Duanmu Z, Wu Q, et al. Waterloo exploration database: New challenges for image quality assessment models[J]. IEEE Transactions on Image Processing, 2016, 26(2): 1004-1016.
- [54] Agustsson E, Timofte R. Ntire 2017 challenge on single image super-resolution: Dataset and study[A]. 2017 IEEE Conference on Computer Vision and Pattern Recognition workshops[C]. IEEE, 2017: 126-135.
- [55] Lim B, Son S, Kim H, et al. Enhanced Deep Residual Networks for Single Image Super-Resolution[A]. 2017 IEEE Conference on Computer Vision and Pattern Recognition Workshops[C]. IEEE, 2017: 136-144.
- [56] Kingma D P, Ba J. Adam: A Method for Stochastic Optimization[A]. arXiv, 2017.
- [57] Jinjin G, Haoming C, Haoyu C, et al. PIPAL: A Large-Scale Image Quality Assessment Dataset for Perceptual Image Restoration[A]. 2020 European Conference on Computer Vision(ECCV 2020)[C]. Cham: Springer International Publishing, 2020: 633-651.
- [58] Tian C, Xu Y, Zuo W. Image denoising using deep CNN with batch renormalization[J].

- Neural Networks, 2020, 121: 461-473.
- [59] Ren C, He X, Wang C, et al. Adaptive consistency prior based deep network for image denoising[A]. 2021 IEEE Conference on Computer Vision and Pattern Recognition(CVPR 2021)[C]. IEEE, 2021: 8596-8606.
- [60] Mou C, Zhang J, Wu Z. Dynamic attentive graph learning for image restoration[A]. 2021 IEEE International Conference on Computer Vision(ICCV 2021)[C]. IEEE, 2021: 4328-4337.
- [61] Zhang K, Li Y, Zuo W, et al. Plug-and-play image restoration with deep denoiser prior[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 44(10): 6360-6376.
- [62] Zeyde R, Elad M, Protter M. On Single Image Scale-Up Using Sparse-Representations[A]. 2012 International Conference on Curves and Surfaces[C]. Heidelberg: Springer Berlin Heidelberg, 2012: 711-730.
- [63] Martin D, Fowlkes C, Tal D, et al. A database of human segmented natural images and its application to evaluating segmentation algorithms and measuring ecological statistics[A]. 2001 IEEE International Conference on Computer Vision(ICCV 2001)[C]. IEEE, 2001: 416-423.
- [64] Nam S, Hwang Y, Matsushita Y, et al. A holistic approach to cross-channel image noise modeling and its application to image denoising[A]. 2016 IEEE Conference on Computer Vision and Pattern Recognition(CVPR 2016)[C]. IEEE, 2016: 1683-1691.
- [65] Xu J, Li H, Liang Z, et al. Real-world Noisy Image Denoising: A New Benchmark[A]. arXiv, 2018.
- [66] Ttirer T, Giryes R. Image Restoration by Iterative Denoising and Backward Projections[J]. IEEE Transactions on Image Processing, 2019, 28(3): 1220-1234.
- [67] Chan S H, Wang X, Elgendy O A. Plug-and-Play ADMM for Image Restoration: Fixed-Point Convergence and Applications[J]. IEEE Transactions on Computational Imaging, 2017, 3(1): 84-98.
- [68] Glorot X, Bordes A, Bengio Y. Deep sparse rectifier neural networks[A]. 2011

- International Conference on Artificial Intelligence and Statistics(AISTATS 2011)[C]. PMLR, 2011: 315-323.
- [69] Shocher A, Cohen N, Irani M. “zero-shot” super-resolution using deep internal learning[A]. 2018 IEEE Conference on Computer Vision and Pattern Recognition(CVPR 2018)[C]. IEEE, 2018: 3118-3126.
- [70] Riegler G, Schuler S, Ruther M, et al. Conditioned regression models for non-blind single image super-resolution[A]. 2015 IEEE International Conference on Computer Vision(ICCV 2015)[C]. IEEE, 2015: 522-530.
- [71] Zhang K, Zuo W, Zhang L. Learning a single convolutional super-resolution network for multiple degradations[A]. 2018 IEEE Conference on Computer Vision and Pattern Recognition(CVPR 2018)[C]. IEEE, 2018: 3262-3271.
- [72] Zhang H, Dai Y, Li H, et al. Deep stacked hierarchical multi-patch network for image deblurring[A]. 2019 IEEE Conference on Computer Vision and Pattern Recognition(CVPR 2019)[C]. IEEE, 2019: 5978-5986.
- [73] Dong J, Roth S, Schiele B. DWDN: Deep Wiener Deconvolution Network for Non-Blind Image Deblurring[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(12): 9960-9976.
- [74] Zhang K, Gool L V, Timofte R. Deep unfolding network for image super-resolution[A]. 2020 IEEE Conference on Computer Vision and Pattern Recognition(CVPR 2020)[C]. IEEE, 2020: 3217-3226.
- [75] Wang A, Chen H, Liu L, et al. Yolov10: Real-time end-to-end object detection[J]. Advances in Neural Information Processing Systems, 2025, 37: 107984-108011.
- [76] Terven J, Córdova-Esparza D M, Romero-González J A. A comprehensive review of yolo architectures in computer vision: From yolov1 to yolov8 and yolo-nas[J]. Machine Learning and Knowledge Extraction, 2023, 5(4): 1680-1716.