

DOI:10.13475/j.fzxb.20230505901

印花面料的边缘轮廓快速提取方法

文嘉琪^{1,2}, 李新荣^{1,2}, 冯文倩^{1,2}, 李瀚森^{1,2}

(1. 天津工业大学 机械工程学院, 天津 300387; 2. 天津市现代机电装备技术重点实验室, 天津 300387)

摘 要 工业协作型缝纫机器人代替操作工自动完成缝合是未来发展的必然趋势,但当前的工业协作型缝纫机器人难以快速精准地定位面料边缘轮廓信息,影响缝纫效率与缝纫质量。针对印花面料提出线下使用深度学习建立面料检测模型,线上调用面料检测模型分割面料与背景并结合传统轮廓检测算法快速准确提取面料边缘轮廓的方法。首先,建立面料图像数据集,并通过卷积拆分和融合损失函数对 VGG-UNet 模型进行优化,将面料数据集输入至优化的 VGG-UNet 模型进行训练学习并构建最优面料检测模型;其次,利用最优面料检测模型分割面料与背景;然后,采用数学形态学算法对分割后的面料图像进行自适应开运算去除面料边缘的毛边;最后,利用 Canny 算子对去除毛边后的面料图像进行轮廓提取。实验结果表明,本文方法可较好去除面料毛边并快速精准提取印花面料的边缘轮廓,所提取的轮廓与面料边缘轮廓高度拟合,轮廓提取精度高于 99%,轮廓提取时间仅需 0.216 s。本研究可为后续机器人的轨迹规划提供快速准确的坐标信息,提高缝合质量和效率,推进无人化、自动化缝合生产线的实现。

关键词 印花面料; 边缘轮廓提取; 机器视觉; 深度学习; VGG-UNet 模型; 缝纫质量

中图分类号: TP 317.4 **文献标志码**: A

当前服装生产中主要依靠操作工完成缝纫,工人一直重复无技术性的缝纫工作,因此使用机器人代替工人完成缝合是今后发展的必然趋势。但传统工业机器人无法满足服装行业未来全自动化、无人化的生产需要,面对多品种、小批量的个性化消费市场,使用基于轮廓提取的工业协作型缝纫机器人是未来服装生产的必然选择^[1-2]。基于轮廓提取的工业协作型缝纫机器人借助视觉辅助设备提取面料边缘轮廓,并根据面料边缘轮廓信息来规划机器人的运动轨迹,从而与缝纫机配合实现面料的缝制,因此,提取的面料边缘轮廓精度直接影响缝合精度。面料在裁剪后边缘存在的大量毛边、面料的印花图案以及采集面料图像时的背景都会影响面料边缘轮廓提取精度,同时提取时间又直接影响缝合效率,因此快速准确地提取面料边缘轮廓是自动化缝合的关键所在。

当前对面料轮廓提取的研究大都为基于传统算子的面料轮廓提取方法。安立新等^[3]首先通过多项式拟合获得面料的初步轮廓,并删除轮廓误差大的纹理噪声数据段,最后再利用多项式拟合生成真实轮廓;周佳等^[4]利用改进的 Canny 算法

检测并分割平滑处理后的服装样板,然后利用骨架提取算法来优化样板的轮廓;李东等^[5]先将采集的服装图像转化为灰度图像,然后使用最大类间方差法进行二值化,再使用形态学开运算处理和孔洞填充,最后使用 Canny 算子进行边缘检测获取服装的外部轮廓。Jia 等^[6]首先将面料图像转换为灰度图像,然后使用 Liu 等^[7]提出的分割阈值方法对灰度图像进行二值化,最后使用轮廓跟踪提取轮廓。以上方法易受噪声影响,无法较好地实现对面料印花图案以及色彩方面的处理,且未对毛边着重考虑,易产生无法精准提取面料边缘轮廓等问题。

本文针对自动缝合时传统轮廓提取方法无法快速准确提取带有印花图案的面料边缘轮廓以及未考虑裁切面料后面料边缘产生大量毛边等问题进行研究。首先,采集印花面料图像并标注制作数据集;其次,通过卷积拆分和融合损失函数对 VGG-UNet 模型进行优化,提高模型的推理速度以及分割精度;然后,使用优化 VGG-UNet 模型训练并构建的最优面料检测模型快速精准分割印花面料与桌面背景;之后使用自适应开运

收稿日期:2023-05-23

修回日期:2023-12-23

基金项目:工信部产业技术基础公共服务平台项目(2021-0173-2-1);国家重点研发计划项目(2018YFB1308801)

第一作者:文嘉琪(1999—),女,硕士生。主要研究方向为面向鞋服行业的机器人关键技术。

通信作者:李新荣(1975—),男,教授,博士。主要研究方向为纺织服装装备智能化。E-mail:lixinrong7507@hotmail.com。

算去除面料毛边;最后,采用 Canny 算子对图像进行边缘检测,获得准确的面料边缘轮廓。本文提出通过线下训练学习并构建面料检测模型,线上调用面料检测模型分割面料与背景并结合传统轮廓检测算法快速提取面料边缘轮廓的方法,同时考虑了实际应用中裁切面料后面料边缘产生的毛边影响边缘轮廓定位的问题,为工业协作性缝纫机器人的运动轨迹提供了快速、准确的坐标信息,并提高了缝合机器人的生产效率和缝纫质量;此外,指出未来采集多种类和多形状的面料来扩充训练图像数据集在实际应用中有重要意义。该研究可为自动化生产线缝合技术提供理论参考。




图 1 构建最优面料检测模型的流程

Fig. 1 Flow of building optimal fabric inspection model

1.1 面料数据集建立

裁剪面料时由于裁切刀不够锋利、裁剪速度不够快以及裁切刀刀片摩擦发热等因素导致面料边缘产生大量毛边,其会严重影响面料边缘轮廓的提取,导致机器人的运动轨迹无法正常规划,因此需要先去毛边再对边缘轮廓进行提取。机织物是由互相垂直的 2 个方向的纱线相互交错沉浮而形成的,裁剪后机织物边缘的纱线会从织物组织中脱落,因此机织物产生的毛边相较其它织物更多。此外,由于方形面料相较于其它面料更为常见,本文选择带有印花图案的方形机织物建立数据集。

采用 RealSense d435i 相机,对平整摆放在不同背景下的带有印花图案的方形机织物进行拍摄,照片分辨率为 1 280 像素×720 像素。采集的图像如图 2(a)所示,共计实验样本 200 张,再对采集到的样本数据集进行镜像以及 180°的旋转和裁剪等操作来增强原始数据集在每次迭代训练中的可变性,增加模型的鲁棒性。最终得到样本集数据 800 张,以 9:1 的比例随机划分训练集和验证集,分别为 720 张和 80 张。

使用 Lableme 对采集的面料图像进行标注,标注后的面料图像如图 2(b)所示。

1.2 VGG-UNet 模型优化

UNet 的跳跃连接 (skip-connection) 结构提高了网络的特征提取能力,可缓解训练过程中的梯度消

1 面料检测模型

为实现快速精准地提取面料边缘轮廓,首先需要分割面料与背景。本文提出利用优化的 VGG-UNet 模型训练并构建最优面料检测模型,其流程如图 1 所示。建立面料数据集后划分为训练集与验证集,将训练集输入至优化 VGG-UNet 模型中进行模型训练,同时利用验证集进行模型测试,获得最优面料检测模型,并对最优面料检测模型进行精度验证,证明 VGG-UNet 模型优化的有效性。获得最优面料检测模型后,在面料边缘轮廓提取时调用该检测模型即可快速精准地分割面料与背景。




图 2 采集的面料图像与标注后的面料图像

Fig. 2 Collected fabric image (a) and annotated fabric image (b)

失问题,这使得 UNet 解码器能够更好地处理面料边缘的像素点信息,从而提高分割面料和背景的准确性。由于本文所用的数据较少,如果使用大型的网络结构如 DeeplabV3+等模型,很容易导致过拟合;而 UNet 的网络层数少,所需的训练样本数量和训练时间也更少,但检测准确率高,也不需要迁移学习的方法进行训练^[8],因此本文选用 U-Net 作为基线。

UNet 是一种主要为图像分割^[9]而设计的神经网络结构,可分为编码、解码和预测 3 个部分。编码部分负责提取抽象的、缩小的特征图。本文在保留 U 型编码器-解码器结构的基础上选择 VGG 16 作为 UNet 中的编码模块,通过结合 VGG16 与 UNet 网络构建,实现对印花面料与背景的精准分割^[10-11]。VGGNet 16 是一种传统的卷积神经网络模型,首先使用 22 的卷积进行上采样,使特征层的维数减半,

然后与对应的初步有效特征层串联,再接2个 3×3 的卷积层,并重复这个结构,最终获得一个融合了所有特征的有效特征层。预测部分利用1个 1×1 卷积核和softmax激活函数对通道进行调整^[12],将最终特征层的通道数调整成需要分割的类别数,判断该像素点属于面料还是背景。

VGG-UNet模型是由基于VGG16的下采样块和

基于UNet的上采样块组成,采用对称扩展路径实现精确定位^[13]。为更有效地提取面料特征,减少面料图像预测时间,对VGG-UNet模型进行优化。本文通过拆分卷积和融合损失函数实现模型优化,减小卷积核大小,从而参数数量;再融合Cross Entropy Loss和Dice Loss损失函数使模型能够更有效地提取面料特征。优化的VGG-UNet模型如图3所示。




图3 优化的VGG-UNet模型

Fig. 3 Optimized VGG-UNet model

1.2.1 卷积拆分

卷积拆分是将大卷积核拆分成小卷积核的一种模型压缩方法,通过在解码部分将 3×3 的二维卷积拆分为2个串联的 1×3 和 3×1 的非对称卷积核,有助于防止模型过拟合,提高模型的泛化能力^[14]。 3×3 卷积和2个串联的 1×3 和 3×1 的卷积运算如图4所示,拆分前完成1次卷积需要进行9次运算,而拆分后只需要6次,参数量和计算次数大大降低,且拆分后的感受野仍为 3×3 ,大大降低了计算复杂度并加快了模型的训练速度,对于在工业协同缝合机器人中部署网络模型具有重要意义。

卷积层参数量计算公式如下:

$$P = O \times W \times H \times I + O$$

式中: P 为卷积层参数量; M ; O 为输出图像的通道数; I 为输入图像的通道数; W 为卷积核宽; H 为卷积核高。

由于 O 相同,因此不加入计算,当 $I=64$ 时,1个 3×3 的卷积核和2个串联的 3×1 与 1×3 的卷积核参数如下所示:




图4 3×3 卷积和卷积拆分

Fig. 4 3×3 convolution(a) and convolution splitting (b)

$$P_{3\times 3} = 3 \times 3 \times 64 + 1 = 577$$

$P_{3\times 1\text{and}1\times 3} = (3 \times 1 \times 64 + 1) + (1 \times 3 \times 64 + 1) = 386$ 可见,前者的参数量是后者的1.49倍,因此将 3×3 的卷积核替换为2个串联的 1×3 与 3×1 的卷积核可有效减少参数量,且拆分后结构层次更多,可在保证检测精度的同时加速运算。卷积拆分还可被视为一种正则化技术,其通过对卷积核进行约束来防止模型过拟合,这有助于模型更好地适应训练数据之外的数据,提高泛化能力^[15],因此本文通过卷积拆分来优化VGG-UNet模型,减少模型预测时间,实现

实时检测印花面料图像。

1.2.2 融合损失函数

损失函数表示样本输入模型后得到的输出结果,反映与该样本真实标签的差异程度。本文在二分类场景下对面料进行分割,引入适合二分类的混合损失函数来解决衣片边缘难以分割和正负样本不均衡的问题。该混合损失函数由 Cross Entropy Loss 和 Dice Loss 组成。Cross Entropy Loss 被采用在原始 UNet 网络结构中,用于反映预测结构与真实值之间的差距,辅助模型训练,对分割网络进行优化, Cross Entropy Loss 损失函数 L_{CE} 的计算公式如下:

$$L_{CE} = -\frac{1}{N} \sum_{i=1}^N [(1 - G_i) \ln(1 - P_i) + G_i \ln(P_i)]$$

式中: G_i 为像素点 i 的真实类别; P_i 为语义分割网络对像素点 i 的预测结果; N 为图像中的所有像素点。

Dice Loss 可引导模型持续学习,使预测结果逐渐逼近真实结果,最终实现预测结果与真实结果完全重合;而 Cross Entropy Loss 适用于对像素数多的区域进行分割,因此适用于本文印花面料的检测^[16]。混合 Cross Entropy Loss 和 Dice Loss 函数,可使模型更适用于印花面料的检测,同时解决了直接使用 Dice Loss 会对模型训练时反向传播造成不利影响使得训练的稳定性降低的问题,有利于模型的收敛与训练,从而提高模型训练的稳定性。此外,融合损失函数具有一定的抗噪声性,可减少噪声数据对模型训练的影响,提高了模型的分割精度^[17]。

Dice Loss 损失函数取值范围在 $[0, 1]$ 之间,取值越大表示与真实值越接近。Dice Loss 损失函数 L_{DCE} 的计算公式如下:

$$L_{DCE} = 1 - \frac{2 \sum_{i=1}^N (G_i \times P_i)}{\sum_{i=1}^N G_i + \sum_{i=1}^N P_i}$$

式中, $G_i \times P_i$ 为 2 个像素矩阵点乘。

本文将 Dice Loss 和 Cross Entropy Loss 进行融合,作为模型的总损失函数,设置参数 a 使得 2 部分对应不同的权重。损失函数以 Cross Entropy Loss 为主,以 Dice Loss 为辅,优化面料与背景样本不均匀的情况,设置 Cross Entropy Loss 与 Dice Loss 比值为 2 : 1,所得参数 a 为 0.33,融合损失函数 L 表示为

$$L = aL_{CE} + (1 - a)L_{DCE}$$

1.3 精度验证

为验证优化 VGG-UNet 模型的有效性,本文采用精确率(E)、召回率(R)、均交并比(MIoU)、均像素精度(MPA)、模型总参数量和单张图片推理时间

作为模型优化前后的精度评价指标。其中:面料提取的精确率(E)表示正确预测的样本个数占总预测结果的比例;召回率(R)表示分类器中正确预测数量占总正例的比例;均像素精度 MPA 表示每个类被正确分类像素数的比例;均交并比 MIoU 表示真实值与预测值像素间的交集和并集之比,能够充分反映分割区域完整性和分割位置准确性。

精确率表达式为

$$E = \frac{T}{T + F} \times 100\%$$

召回率表达式为

$$R = \frac{T}{T + N} \times 100\%$$

均交并比表达式为

$$MIoU = \frac{1}{k+1} \sum_{i=0}^k (p_{ii} / (\sum_{j=0}^k p_{ij} + \sum_{j=0}^k p_{ji} - p_{ii}))$$

均像素精度表达式为

$$MPA = \frac{1}{k+1} \sum_{i=1}^k (p_{ii} / \sum_{j=0}^k p_{ij})$$

式中: p_{ii} 表示本属于类 i 但被预测为 i 类的像素数量; p_{ij} 表示本属于类 i 但被预测为 j 类的像素数量; $k+1$ 表示类别数,本文 k 取 1; T 表示提取为面料且标注结果也为面料的像素集合; F 为提取为面料但标注结果为背景的像素集合; N 为提取为背景但标注结果为面料的像素集合。

VGG-UNet 和优化的 VGG-UNet 模型训练结果参数如表 1 所示。可见,优化 VGG-Unet 模型最优训练结果各指标比 VGG-UNet 模型分别高出 0.79%, 0.79%, 1.60%, 0.79%, 推理时间减少了 10.368 ms,且优化率 VGG-UNet 模型的总参数量大大减少,训练并构建的最优面料检测模型在内存资源占用、检测效率方面具有明显优势。

表 1 VGG-UNet 与优化 VGG-UNet 模型性能对比

Tab.1 Performance comparison of VGG-UNet and

optimized VGG-UNet models

模型类别	精确率/%	召回率/%	均交并比/%	均像素精度/%	参数量/M	推理时间/ms
模型 1	98.83	98.83	97.64	98.83	2 489 2 437	40.479
模型 2	99.62	99.62	99.24	99.62	2 432 5 429	30.111

注:模型 1 为 VGG-UNet 模型;模型 2 为优化 VGG-UNet 模型。

2 面料边缘轮廓提取

提取带有印花图案的面料边缘轮廓时,首先需

要利用最优面料检测模型实现面料与背景的分割,然后利用自适应开运算去除面料毛边,最后使用Canny算子提取面料边缘轮廓,最终实现面料的边缘轮廓提取。

2.1 分割面料与背景

相机采集的面料图像如图5(a)所示,将其输入至最优面料检测模型中,推理结果如图5(b)所示。可以看出,使用优化VGG-UNet模型训练的最优面料检测模型可准确分割面料与背景,且分割结果不受印花图案、颜色、桌面背景和光源的影响。




图5 采集的面料图像与推理结果

Fig. 5 Collected fabric images (a) and inference result (b)

2.2 自适应开运算去毛边

分割完面料与背景后,采用数学形态学算法中的自适应开运算达到去除面料毛边的效果。数学形态学的实质是选取合适的结构元素去度量和提取图像中的对应形状以达到对图像分析和识别的目的^[18],因此结构元素的选择至关重要。数学形态学有2个基本的运算:腐蚀和膨胀,先腐蚀再膨胀即为开运算。腐蚀可抹除小于一定阈值的孤立像素点,使图像达到消除面料边缘轮廓毛边的效果;膨胀可对小于一定阈值的孔洞进行填充,使面料边缘轮廓平滑,达到填补腐蚀所损失的面料边缘轮廓的效果。腐蚀的原理是卷积核沿着图像滑动,如果与卷积核对应的原图像像素值都是1,那么中心元素保持原值,否则为0;膨胀与腐蚀相反,因此,对二值面料图像进行先腐蚀再膨胀的操作可在保持面料边缘轮廓的情况下去除毛边。

形态学中腐蚀的表达式为

$$A \ominus B = \{x, y \mid (B)_{xy} \subseteq A\}$$

形态学中膨胀的表达式为

$$A \oplus B = \{x, y \mid (B)_{xy} \cap A \neq \emptyset\}$$

形态学中开运算的表达式为

$$A \circ B = (A \ominus B) \oplus B$$

式中: A 为目标图像; B 为结构元素; (x, y) 为像元; $\ominus$ 为腐蚀运算的运算符; $\oplus$ 为膨胀运算的运算符。

本文根据图像大小自适应确定结构元素大小,结构元素的计算公式如下所示:

$$k = \begin{cases} \max(\text{img}_s)/40, & \max(\text{img}_s)/40 \neq 0 \\ (\max(\text{img}_s)/40) + 1, & \max(\text{img}_s)/40 = 0 \end{cases}$$

式中: $\max(\text{img}_s)$ 表示图像的最大维度; k 表示结构元素大小。

由于结构元素大小为奇数时,结构元素的中心点可与图像上的像素点一一对应,且处理边缘像素时可保证结构元素对称,从而避免腐蚀处理出现偏差,因此当图像的最大维度除以40的值为偶数时,使其加上1成为奇数,对图5使用自适应开运算去除面料毛边,处理后的图像如图6所示。




图6 数学形态学去除毛边

Fig. 6 Raw edges removal by mathematical morphology

2.3 Canny算子提取面料边缘轮廓

传统的检测算子有Roberts算子、Prewitt算子、Sobel算子和Laplacian算子等。上述算子简单、速度快,但其微分运算对噪声不够敏感,抗干扰性差,提取的边缘轮廓不够清晰且不连续^[19]。本文在去除织物毛边后采用信噪比、定位精度和单边缘响应均较好的Canny算子提取面料的边缘轮廓。Canny算子边缘检测是提取图像中亮度变化最明显的点,并保留图像的重要结构信息,主要步骤^[20]如下。

1)采用 3×3 邻域4邻点计算梯度幅值和方向。即寻找灰度强度变化最强的位置,用梯度来表示灰度强度变化的程度和方向,按照下式计算梯度强度和方向:

$$G = \sqrt{G_x^2 + G_y^2}$$

$$\theta = \arctan\left(\frac{G_y}{G_x}\right)$$

式中: G_x 为 x 方向上的梯度幅值; G_y 为 y 方向上的梯度幅值; θ 为梯度方向。

2)根据梯度方向对梯度幅值进行非极大值抑制。其原理为遍历梯度矩阵上的所有点,保留边缘方向上具有极大值的像素点。将 3×3 的梯度幅值矩阵内每个点均作为中心像素点,与沿着该中心点梯度方向上的2个邻域的梯度幅值相比较。若中心像素点的梯度幅值小于这2个方向上邻域的梯度幅值,则令该点为0;否则保留该中心像素点为轮廓点。

3)边缘检测和连接轮廓。Canny算子采用双阈值来区分边缘像素点,将梯度幅值小于低阈值的像

素点所对应的灰度值设为 0,将梯度幅值高于高阈值的像素点的灰度值设为 255,将梯度幅值而大于低阈值小于高阈值的像素点的灰度值标记为弱边缘像素。当弱边缘像素的 8 邻域内有强边缘时,则将其灰度值赋为 255。

使用 Canny 算子对图 6 中的图像进行轮廓检测,通过实验设定阈值范围在 $[50, 60]$ 之间可提取连续完整的面料边缘轮廓。由于检测后图像中的轮廓较细,使用 5×5 的结构元素对提取的轮廓进行膨胀处理,加粗后的面料边缘轮廓如图 7 所示。




图 7 提取的面料边缘轮廓

Fig. 7 Extracted fabric edge contour

3 实验验证与讨论

为验证本文方法提取面料边缘轮廓的准确度,采集了 15 幅放置在不同桌面背景上的印花面料图像,对其进行边缘轮廓提取。选择其中的 2 张印花面料图像,如图 8(a)、图 9(a) 所示,其中图 9(a) 面料颜色与桌面背景颜色相近,且桌面反光较严重。语义分割印花面料与桌面的结果如图 8(b)、9(b) 所示,可以看出,即使印花图案复杂、面料颜色与背景颜色相近且桌面反光严重,优化的 VGG-UNet 网络也能够精准分割印花面料与背景。自适应开运算结果如图 8(c)、9(c) 所示,最终 Canny 算子提取的印花面料边缘轮廓图像如图 8(d)、9(d) 所示。

为直观展示所提取的面料边缘轮廓与原图像轮廓拟合的程度,将提取的面料边缘轮廓中的黑色像素点转换为白色,将白色像素点转换为红色;将颜色转换后的面料边缘轮廓与原图像按比例混合叠加,达到让所提取的面料边缘轮廓在原图像上展现的效果。面料轮廓图像与原图像叠加的公式如下:

$$Z = (1 - \alpha)Y + \alpha X$$

式中: α 为选择的比例; X 为拍摄的原图像; Y 为提取的面料边缘轮廓; Z 为相加后的图像。

经多次实验发现设置原图像的比例为 0.3 时对比效果最好,能够将提取到的面料轮廓以红色线条




图 8 面料 1 的提取过程及结果

Fig. 8 Experimental process and results of fabric 1.

(a) Original image; (b) Semantic segmentation result;
(c) Deburring result; (d) Edge contour




图 9 面料 2 的提取过程及结果

Fig. 9 Experimental process and results of fabric 2.

(a) Original image; (b) Semantic segmentation result;
(c) Deburring result; (d) Edge contour

的方式在原图中展示。将图 5 中采集的面料原图像与图 7 中颜色转换后的轮廓进行叠加,再将图 8(a)、9(a) 分别与颜色转换后的图 8(d)、9(d) 进行叠加对比,叠加后的图片如图 10 所示。可以看出,即使印花面料与桌面背景颜色相近且光照不均匀,也不影响轮廓提取精度。

本文将完整算法在 Windows 11 操作系统、GPU 使用 NVIDIA GeForce GTX 1650、16 G 内存计算机上经 pytorch 编程实现,提取 1 张面料图像中的面料边缘轮廓仅需要 0.216 s,而提出的传统轮廓提取方法需要 2.852 s。传统轮廓提取方法所提取的印花面料边缘轮廓如图 11 中的红色线条所示,可见当面料颜色与桌面背景颜色相近且桌面反光严重时边缘轮廓的提取结果最差。此外,传统轮廓提取方法并未考虑织物裁切后产生的毛边问题,因此传统轮廓提




图 10 印花面料原图与本文提取的边缘轮廓图像叠加对比

Fig. 10 Comparison between original image of printed fabric and superimposed edge contour image extracted in this paper.

(a) Superposition of Fig. 5 and Fig. 7; (b) Superposition of Fig. 8 (a) and 8 (d); (c) Superposition of Fig. 9 (a) and 9 (d)

取算法不仅提取时间长,还无法有效去除噪声以及毛边,难以准确提取印花面料的边缘轮廓。

此外,在原图上手绘轮廓并将其与本文提取的面料边缘轮廓通过 OpenCV 计算 2 个轮廓的重合度,轮廓提取精度在 99% 以上。由此可见,本文方

法具有明显的速度优势和精度优势,该方法能够有效去除面料毛边,快速精准提取面料边缘轮廓,且提取过程不受印花图案、桌面背景、色彩、织物纹理以及光源的影响,通用性佳,提取结果与面料的边缘轮廓高度拟合。




图 11 用传统轮廓提取方法的效果

Fig. 11 traditional contour extraction method. (a) Fig. 5 fabric image; (b) Original image of Fig. 8(a) fabric; (c) Original image of Fig. 9(a) fabric

4 结 论

本文针对基于轮廓提取的工业协作型缝纫机器人难以快速准确提取面料边缘轮廓信息的问题,提出一种印花面料的边缘轮廓快速提取方法。通过卷积拆分和融合损失函数优化 VGG-UNet 模型,使用优化 VGG-UNet 模型对面料图像数据集进行训练学习并构建最优面料检测模型。在提取印花面料的边缘轮廓时首先使用最优面料检测模型分割面料与背景,然后使用自适应开运算去除面料毛边,最后利用 Canny 算子提取面料边缘轮廓。结论如下:

1) 优化 VGG-UNet 模型的精确率与均交比传统 VGG-UNet 模型训练出的最优面料检测模型分别高出 0.79% 和 1.6%,推理时间减少了 10.368 ms,证明优化的 VGG-UNet 模型可提高面料分割的精确程度和效率。

2) 本文提出的线下建立面料检测模型,线上调用该模型分割面料与背景并结合传统轮廓检测算法

提取印花面料的边缘轮廓仅需 0.216 s,且轮廓提取精度在 99% 以上,精度与速度均可满足工业生产需求。此外,本文方法可有效去除裁切面料后面料边缘产生的大量毛边,在实际应用中具有重要意义。与传统面料边缘检测方法相比,本文方法有明显速度优势和精度优势,可提高基于轮廓检测的工业协作性机器人的工作效率与缝合精度。

3) 本文较早提出使用传统轮廓检测算法结合深度学习提取面料边缘轮廓,解决了传统面料轮廓提取方法受面料颜色、印花图案、织物纹理以及桌面背景的影响,在带有复杂印花图案面料的边缘轮廓提取上具有优异的性能。但本文所建立的面料图像数据集较小,未来可采集多种类和多形状的面料图像扩充数据集,以达到在实际生产中可以准确提取各类面料边缘轮廓,为工业协作性机器人提供精准的缝合路径,推进无人化、自动化缝合生产线的实现。

FZXB

参考文献:

[1] 吴柳波,李新荣,杜金丽.基于轮廓提取的缝纫机器人运动轨迹规划研究进展[J].纺织学报,2021,

- 42(4):191-200.
WU Liubo, LI Xinrong, DU Jinli. Research progress on contour extraction-based trajectory plan-ning for sewing robots[J]. Journal of Textile Research, 2021, 42(4): 191-200.
- [2] 王晓华, 王育合, 张蕾, 等. 缝纫机器人对织物张力与位置的模糊阻抗控制[J]. 纺织学报, 2021, 42(11):173-178.
WANG Xiaohua, WANG Yuhe, ZHANG Lei, et al. Fuzzy impedance control of fabric tension and position by a sewing robot[J]. Journal of Textile Research, 2021, 42(11):173-178.
- [3] 安立新, 李炜. 一种带有印花图案服装图像的轮廓提取[J]. 纺织学报, 2013, 34(3):132-136.
AN Lixin, LI Wei. An outline extraction of garment images with printed patterns[J]. Journal of Textile Research, 2013, 34(3):132-136.
- [4] 周佳, 宗雅倩, 刘其思, 等. 基于图像处理的服装样板轮廓提取[J]. 纺织科学与工程学报, 2018, 35(4):133-136, 157.
ZHOU Jia, ZONG Yaqian, LIU Qisi, et al. Image processing based garment sample outline extraction[J]. Journal of Textile Science and Engineering, 2018, 35(4):133-136, 157.
- [5] 李东, 万贤福, 汪军. 采用傅里叶描述子和支持向量机的服装款式识别方法[J]. 纺织学报, 2017, 38(5):122-127.
LI Dong, WAN Xianfu, WANG Jun. A clothing style recognition method using Fourier descriptors and support vector machines[J]. Journal of Textile Research, 2017, 38(5):122-127.
- [6] JIA X, LIU Z. Element extraction and convolutional neural network-based classification for blue calico[J]. Textile Research Journal, 2020. DOI: 0.1177/0040517520939573.
- [7] LIU ZH, CHENG F, ZHANG W. A novel segmentation algorithm for clustered flexional agricultural products based on image analysis[J]. Computers and Electronics in Agriculture, 2016(126):44-54.
- [8] FU Leiyang, LI Shaowen. A new semantic segmentation framewok based on UNet[J]. Sensors, 2023, 23(19):8123.
- [9] WENG W, ZHU X. U-Net: convolutional networks for biomedical image segmentation[J]. IEEE Access, 2021(99):1-10.
- [10] 徐欢, 任沂斌. 基于混合损失 U-Net 的 SAR 图像渤海海冰检测研究[J]. 海洋学报, 2021, 43(6):157-170.
XU Huan, REN Yibin. Research on sea ice detection in Bohai sea based on mixed-loss U-Net for SAR images[J]. Acta Oceanologica Sinica, 2021, 43(6):157-170.
- [11] HOU Yuewu, LIU Zhaoying, ZHANG Ting, et al. C-UNet: complement UNet for remote sensing road extraction[J]. Sensors, 2021, 21(6):2153.
- [12] SGASHIDHAR R, SUDARSHAN Patilkulkarni. Visual speech recognition for small scale dataset using VGG16 convolution neural network[J]. Multimedia Tools and Applications, 2021, 80(19):28941-28952.
- [13] SHI Jiyuan, JI Dang, CUI Mida, et al. Improvement of damage segmentation based on pixel-level data balance using VGG-UNet[J]. Applied Sciences, 2021. DOI: 10.3390/app11020518.
- [14] DING Xiaohan, GUO Yuchen, DING Guiguang, et al. ACNet: strengthening the kernel skeletons for powerful CNN via asymmetric convolution blocks[C]// IEEE / CVF International Conference on Computer Vision (ICCV 2019). [S.l.]:IEEE, 2019:1911-1920.
- [15] 张占军, 彭艳兵, 程光. 基于 CIFAR-10 的图像分类模型优化[J]. 计算机应用与软件, 2018, 35(3):177-181.
ZHANG Zhanjun, PENG Yanbing, CHENG Guang. Opti-mization of image classification model based on CIFAR-10[J]. Computer Applications and Software, 2018, 35(3):177-181.
- [16] 张达, 熊凌. 基于改进 PSPNet 的氩花图像分割算法[J]. 计算机工程与设计, 2022, 43(10):2843-2849.
ZHANG Da, XIONG Ling. Semantic segmentation algorithm of flower image based on improved PSPNet[J]. Computer Engineering and Design, 2022, 43(10):2843-2849.
- [17] 王欣, 王美丽, 边党伟. 融合 MobileNetv2 和注意力机制的轻量级人像分割算法[J]. 计算机工程与应用, 2022, 58(7):220-228.
WANG Xin, WANG Meili, BIAN Dangwei. A lightweight portrait segmentation algorithm incorporating MobileNetv2 and attention mechanism[J]. Computer Engineering and Applications, 2022, 58(7):220-228.
- [18] 崔丽群, 张月, 田鑫. 融合双阈值和改进形态学的边缘检测[J]. 计算机工程与应用, 2017, 53(9):190-194, 200.
CUI Liqun, ZHANG Yue, TIAN Xin. Fusion of double thresholding and improved morphology for edge detection[J]. Computer Engineering and Applications, 2017, 53(9):190-194, 200.
- [19] 冯文倩, 李新荣, 杨帅. 人体轮廓机器视觉检测算法的研究进展[J]. 纺织学报, 2021, 42(3):190-196.
FENG Wenqian, LI Xinrong, YANG Shuai. Research progress of machine vision detection algorithms for human contours[J]. Journal of Textile Research, 2021, 42(3):190-196.
- [20] FUENTES-ALVENTOSA A, GOMEZ-LUNA J, MEDINA-CARNICER R. GUD-Canny: a real-time GPU-based unsupervised and distributed Canny edge detector[J]. Journal of Real-Time Image Processing, 2022, 19(3):591-605.

Rapid extraction of edge contours of printed fabrics

WEN Jiaqi^{1,2}, LI Xinrong^{1,2}, FENG Wenqian^{1,2}, LI Hansen^{1,2}

(1. School of Mechanical Engineering, Tiangong University, Tianjin 300387, China; 2. Key Laboratory of Modern Mechanical and Electrical Equipment Technology, Tianjin 300387, China)

Abstract

Objective The industrial sewing robot based on contour extraction detects fabric edge contours with visual aids and works out the robot's movement trajectory based on the fabric edge contour information to achieve the sewing of the fabric in conjunction with the sewing machine. However, the large number of raw edges of the fabric after cutting, the print pattern of the fabric and the background of the fabric image acquisition all affect the accuracy of the fabric edge contour extraction, and the extraction time directly affects the sewing efficiency.

Method The conventional VGG-UNet model was optimized by convolutional splitting and fusion loss functions to improve the inference speed and segmentation accuracy of the model. The optimal fabric detection model was then constructed and trained using the optimized VGG-UNet to segment quickly and accurately the printed fabric and the desktop background, and the fabric burrs were removed using adaptive open operations before the Canny operator was used for edge detection to obtain accurate fabric edge contours.

Results The optimized VGG-UNet optimal training results were 0.79%, 0.79%, 1.6%, 0.79% higher than those of the VGG-UNet model in each index, and the inference speed was reduced by 10.368 ms, and the number of total parameters of the optimized VGG-UNet model was greatly reduced. The optimal fabric detection model that was trained and constructed showed obvious advantages in terms of memory resource consumption and detection efficiency. The superimposed image showed that the contour extraction accuracy was not affected even though the printed fabric was similar in color to the desktop background and the lighting was not uniform. In addition, the contour lines were hand-drawn on the original image, and the fabric edge contour lines extracted in this paper were computed by OpenCV to find out the overlap of the two contour lines, and the accuracy of the contour line extraction was more than 99%. The complete algorithm was obtained by pytorch programming on a computer with Windows 11 operating system, GPU using NVIDIA GeForce GTX 1650 and 16 G memory, and it took only 0.216 s to extract the edge contour of the fabric in a fabric image, while the proposed conventional contour extraction method took 2.852 s. The edge contour of the printed fabric was the worst when the fabric color is close to the background color of the desktop and when the reflection of the desktop was severe. In addition, the conventional contour extraction method does not consider the burr problem generated by the fabric cutting, so the conventional contour extraction algorithm not only has a long extraction time but also cannot remove the noise and the burr efficiently, making it difficult to accurately extract the edge contour of the printed fabric.

Conclusion This paper proposes the use of deep learning combined with conventional contour detection algorithms to extract fabric edge contours for the first time. It solves the problem that traditional fabric contour extraction methods are affected by fabric color, print pattern, fabric texture and desktop background, and has excellent performance in extracting edge contours of fabrics with complex prints. In this paper, we consider the large number of raw edges generated by the fabric edges after cutting the fabric. This method can effectively remove the raw edges and extract the fabric edge contours quickly and accurately, and the extraction process is not affected by the print pattern, table background, color, fabric texture and light source, the method is good in generality and the extraction results fit the fabric edge contours highly.

Keywords printed fabric; edge contouring extraction; machine vision; deep learning; VGG-UNet model; sewing quality